RA-SGG：通过多原型学习实现检索增强的场景图生成框架

Kanghoon Yoon[1]、Kibum Kim[1]、Jaehyung Jeon[1]、Yeonjun In[1]、Donghyun Kim[2]、Chanyoung Park[1]*

[1] 韩国科学技术院（KAIST）工业与系统工程系；[2] 高丽大学人工智能系。

{ykhoon08, kb.kim, wogud405, yeonjun.in, cy.park}@kaist.ac.kr；d_kim@korea.ac.kr

* 通讯作者。

原文：arXiv:2412.12788v1 [cs.CV]，2024 年 12 月 17 日。

Copyright © 2025, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.

版权 © 2025，美国人工智能促进协会（www.aaai.org）。保留所有权利。

> 非官方中文全文译本，仅供用户私下阅读。依据用户上传的 11 页 PDF 翻译，非公开发布，未赋予原文或译文任何开放许可。公式及图表原样保留，以维护原始符号、数值与视觉信息；对应中文说明附在相邻位置。

摘要

场景图生成（SGG）研究长期面临两项根本挑战：谓词分布的长尾性，以及谓词之间的语义歧义。这些挑战使 SGG 模型偏向头部谓词，倾向于占主导地位的通用谓词，而忽略细粒度谓词。本文通过将 SGG 表述为带有部分标注的多标签分类问题来应对这些挑战；其中，细粒度谓词的相关标签缺失。在这一新框架下，我们提出检索增强的场景图生成（RA-SGG）：通过从所建立的记忆库中检索相关样本，识别可能具有多个标签的实例，并将单标签扩充为与原标签语义相似的多个标签。基于增强后的关系（即发现的多标签），我们采用多原型学习来训练 SGG 模型。多项全面实验表明，RA-SGG 超越最先进的基线，在 VG 和 GQA 上分别最多提高 3.6% 和 5.9%，尤其在 F@K 指标上表现突出。这说明 RA-SGG 有效缓解了谓词长尾分布与语义歧义所引起的预测偏差。RA-SGG 的代码见 https://github.com/KanghoonYoon/torch-rasgg 。

1 引言

SGG 是场景理解中的关键任务，旨在检测图像中的物体并预测它们之间的关系。SGG 模型善于捕捉丰富的视觉信息，构建同时包含物体层面和关系层面信息的场景图。场景图的这种组合式表示有益于多种视觉应用（Hildebrandt et al. 2020；Schroeder and Tripathi 2020）。然而，现有 SGG 方法遇到了两项根本挑战：

1）长尾问题。 SGG 基准数据集（例如 Visual Genome）中的谓词类别服从严重偏斜的分布：某些谓词具有大量样本（头部类别），另一些谓词的标注则十分稀少（尾部类别）。这一挑战源于标注者更倾向于标注“on”（在……上）等通用谓词，而不是“walking in”（在……中行走）等细粒度谓词。因此，在这种偏斜分布的数据集上训练的 SGG 模型往往偏向头部谓词，其生成的场景图主要由通用谓词构成。然而，这些场景图缺乏尾部谓词所提供的细致描述，而尾部谓词能够提供详细的关系信息。

2）语义歧义。 另一项挑战来自谓词类别之间模糊的语义边界。对于某个关系实例，“on”“walking on”（在……上行走）和“walking in”等谓词可能难以区分，因为这些谓词共享语义含义，因此 SGG 模型需要捕捉细微的视觉线索来区分它们。然而，学习这些详细的视觉差异很困难，因为“walking in”等尾部谓词在谓词类别分布通常偏斜的数据集中很少出现。解决这些挑战对于生成包含细粒度谓词、信息丰富的场景图至关重要。

开创性研究通过缓解上述挑战来关注细粒度场景图的生成。重采样、重加权以及多种去偏方法（Li et al. 2021；Lyu et al. 2022；Kaihua et al. 2020；Kim et al. 2024b）被用于生成细粒度场景图。最近，（Li et al. 2022；Zhang et al. 2022；Yu et al. 2023）提出了数据增强方法，将通用谓词重新标注为细粒度谓词。然而，这种细化过程产生了一种权衡，即对通用谓词的理解有所下降。此外，我们发现，先前框架中的根本挑战依然存在。当前 SGG 模型依赖单标签分类，预测时各谓词相互竞争，迫使模型只选择一个谓词，同时抑制其他谓词。这种方法存在问题，因为它忽略了自然语言的细微特性：多个谓词可以表达同一个关系。因此，我们将单标签分类转化为带有部分标注的多标签分类问题（Ben-Baruch et al. 2022）。也就是说，我们发现原始训练数据中潜在的细粒度谓词，并为关系增加语义相近的谓词。

在这项工作中，我们提出检索增强的场景图生成（RA-SGG）框架，通过细粒度谓词将单标签标注扩充为多标签，以应对谓词长尾分布与语义歧义的挑战。其核心思想是检索与原谓词共享语义的潜在谓词，并将它们用作该关系的伪标签，如图 1 所示。我们的方法受到视觉语义空间中观察结果的启发。利用预训练 SGG 模型 PE-Net（Zheng et al. 2023）对训练实例进行最近邻检索时，我们发现，尽管谓词标签不同，查询关系与检索到的实例往往具有共同的语义。例如，真实谓词为“on”的关系会检索到不同的细粒度谓词：对于 ⟨cat, on, table⟩（猫，在……上，桌子），检索到 {“lying on”（躺在……上），“laying on”（卧在……上）}；对于 ⟨man, on, street⟩（男子，在……上，街道），检索到 {“walking in”，“walking in”}。值得注意的是，这种模式在头部、中部和尾部谓词类别中均持续出现（图 1.b），表明当前仅标注一个谓词的关系实例，实际上可能共同指向多个含义相近的潜在谓词。

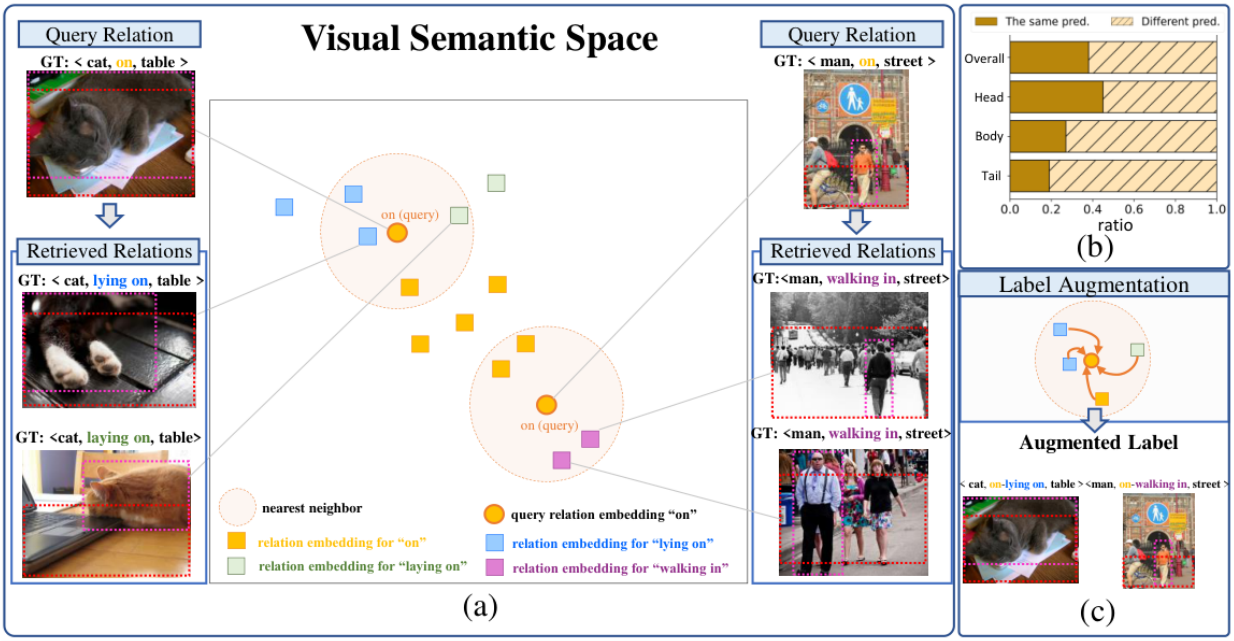


图 1： RA-SGG 在 SGG 中进行标签增强的示意图。（a）查询关系实例及其在嵌入空间中检索得到的关系实例。“GT”表示真实标注。（b）训练数据中，检索实例与查询关系具有相同／不同谓词的比例。（c）细粒度谓词标签增强。图内文字：Query Relation＝查询关系；Retrieved Relations＝检索到的关系；Visual Semantic Space＝视觉语义空间；nearest neighbor＝最近邻；query relation embedding＝查询关系嵌入；relation embedding for＝对应谓词的关系嵌入；Overall／Head／Body／Tail＝总体／头部／中部／尾部；The same pred.／Different pred.＝相同／不同谓词；ratio＝比例；Label Augmentation＝标签增强；Augmented Label＝增强后的标签。

基于这些观察，RA-SGG 旨在通过从记忆库检索语义相似的关系实例，发现关系实例的潜在谓词。我们引入三项关键机制：（1）**可靠的多标签实例选择：** 简单地为所有关系实例分配伪标签会降低可靠性。为获得可靠的伪标签，我们提出标签不一致性分数，用于衡量真实谓词与检索到的关系实例之间的差异。（2）**无偏多标签增强：** 我们引入基于逆倾向分数的采样策略，从检索到的关系实例中采样出现频率较低（即细粒度）的谓词。（3）**具有多个谓词的多原型学习：** 确保关系实例嵌入同时捕捉原谓词及新发现细粒度谓词的语义。全面实验表明，RA-SGG 超过最先进的 SGG 模型，尤其在 F@K 上表现突出；这一指标强调在细粒度类别（即尾部类别）上获得高性能，同时尽量减少通用类别（即头部类别）的性能损失。我们的贡献可概括如下：

1. 我们强调了 SGG 中单标签分类的问题，并从带有部分标注的多标签分类问题的角度重新表述该任务。
2. 我们提出新的检索增强 SGG 框架（RA-SGG），通过发现仅标注单一谓词的关系实例中的潜在谓词，同时缓解长尾分布与语义歧义问题。
3. 广泛研究表明，RA-SGG 在 F@K 上实现了最先进的性能，说明它能有效生成细粒度场景图，同时不牺牲对通用谓词的理解。

2 相关工作

场景图生成

SGG 能够实现对场景的密集理解，连接视觉与语言两种模态，因此受到关注。早期工作侧重于使用消息传递网络和 Transformer 架构捕捉场景中的上下文信息（Zellers et al. 2018；Yang et al. 2018；Li et al. 2021；Shit et al. 2022）。近期 SGG 研究集中于提高细粒度谓词（即尾部类别）的性能，以获得信息丰富的场景图。然而，预测细粒度谓词十分困难：受到长尾分布与语义歧义双重影响，SGG 模型的预测很容易坍缩为通用、平凡的谓词。为解决这一问题，（Li et al. 2021；Lyu et al. 2022）通过重采样／重加权使训练关注尾部谓词类别，而（Kaihua et al. 2020；Dong et al. 2022；Jeon et al. 2024）提出去偏方法，减轻对头部类别的偏向。然而，仅增大尾部类别的权重，可能使 SGG 模型对数量有限的尾部实例过拟合（Zhai et al. 2022），因为这些方法并未增加尾部类别数据的变化多样性（S. Hasegawa and Umeda 2022）。作为替代，增强训练数据的方法开始出现。具体而言，NICE（Li et al. 2022）使用预训练模型识别数据中的噪声谓词；IE-Trans（Zhang et al. 2022）将通用谓词替换为细粒度谓词，或使用细粒度谓词补充训练数据中缺失的标注；ST-SGG（Kim et al. 2024a）为缺少标注的实例分配伪标签。

然而，这些数据增强方法会从数据集中移除通用谓词，导致这些通用谓词的性能显著下降。该策略为了获得细粒度场景图，忽略了对通用谓词的全面理解。此外，我们认为，鉴于 SGG 模型是在极度长尾分布上训练的，仅依据模型的单次预测调整数据存在风险。为解决这些问题，我们从多标签分类问题的角度处理 SGG，以全面理解所有谓词类别。此外，RA-SGG 不依赖单一模型预测，而是考虑针对目标关系检索到的关系实例的谓词分布，从而将谓词准确地分配为多标签。

检索增强生成

检索增强生成（RAG）是自然语言处理（NLP）中的一种广泛使用的方法。RAG 利用非参数记忆，从知识库中检索相关段落来补充语言模型的内在知识（Borgeaud et al. 2022；Guu et al. 2020；Lewis et al. 2020）。类似地，在图像合成领域，（Casanova et al. 2021；Blattmann et al. 2022）等方法通过参考近邻样本提高生成图像的质量。此外，RAG 验证了其处理训练数据集内稀有样本的能力。Re-Imagen（Chen et al. 2023）通过参考具有相似文本描述的图像，有效生成稀有实体。（Long et al. 2022）借助记忆库中的图像特征，提高尾部类别上的图像分类性能。在本文中，我们提出检索增强的场景图生成框架，以发现训练数据集中的潜在多标签。检索过程在所建立的记忆库上执行，其中存储了由预训练 SGG 模型产生的关系嵌入。我们的工作首次展示了基于检索的增强方法对于 SGG 任务的有效性。

3 预备知识

场景图生成任务

首先介绍场景图生成问题，它包括物体检测，以及物体类别和物体间关系类别的预测。形式化地，给定一幅图像，我们的目标是生成场景图 $\mathbf{G} = \langle \mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i \rangle_{i=1}^{N}$，其中 N 为图像中的三元组数。$\mathbf{s}_i$ 表示主体，包括边界框位置与物体类别；$\mathbf{o}_i$ 表示客体，定义与主体相同。$\mathbf{p}_i$ 表示 $\mathbf{s}_i$ 与 $\mathbf{o}_i$ 之间的谓词，包含谓词类别。

SGG 中的视觉语义嵌入空间

PE-Net（Zheng et al. 2023）提出一种新的 SGG 学习策略，缩小视觉语义空间中原型与视觉关系嵌入之间的距离。该范式通过衡量关系嵌入与其谓词类别原型之间的距离，鼓励 SGG 模型辨别难以区分的谓词。

形式化地，令 $\boldsymbol{v_s} \in \mathbb{R}^d$ 和 $\boldsymbol{v_o} \in \mathbb{R}^d$ 分别表示主体与客体的视觉语义特征，它们从视觉特征和实体类别的词嵌入中共同提取。用 $\boldsymbol{u_p} \in \mathbb{R}^d$ 表示从联合框视觉特征中提取的关系嵌入，用 $\boldsymbol{t_p} \in \mathbb{R}^{d'}$ 表示谓词类别的词嵌入。原型学习的核心思想是通过 $\mathcal{F}(\boldsymbol{v_s}, \boldsymbol{v_o}) \approx \mathbf{W}_p \boldsymbol{t_p} + \boldsymbol{u_p}$ 将主体和客体实例与谓词实例匹配，其中 $\mathcal{F}$ 是融合层（Zheng et al. 2023），$\mathbf{W}_p \in \mathbb{R}^{d \times d'}$ 是特征变换矩阵。为实现这一点，PE-Net 将谓词的语言语义作为原型（即 $\mathbf{W}_p \boldsymbol{t_p}$），并使关系嵌入（即 $\mathbf{r} = \mathcal{F}(\boldsymbol{v_s}, \boldsymbol{v_o}) - \boldsymbol{u_p}$）接近其对应的谓词原型。原型学习损失定义为：

$$\mathcal{L}_{\text{proto}} = -\log \frac{\exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_{\text{gt}} \rangle)/\gamma}{\sum_{j=1}^{N_p} \exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_j \rangle)/\gamma}, \tag{1}$$

$$\text{where} \quad \bar{\boldsymbol{r}} = \text{Proj}(\boldsymbol{r}) \text{and} \quad \bar{\boldsymbol{c}}_j = \text{Proj}(\mathbf{W}_p \boldsymbol{t_p})$$

式（1）中，where＝其中；N_p 是谓词类别数，γ 是可学习的温度超参数，Proj 是一个两层 MLP，由关系嵌入 $\mathbf{r}$ 和原型共享。$\bar{\mathbf{c}}_{\text{gt}}$ 表示真实谓词的类别原型。相较于传统的基于分类器的 SGG 模型，这种原型引导的学习已被证明能够在视觉语义空间中产生具有判别性的关系嵌入。因此，我们提出的 RA-SGG 利用从上述目标学习得到的训练实例关系嵌入，来实现 SGG 的检索增强方法。

4 检索增强的 SGG

本节介绍 RA-SGG：一种利用检索过程发现并增强潜在细粒度谓词的新方法。我们首先将 SGG 任务表述为带有部分（即单个）标注的多标签分类问题，目标是基于部分标注样本，对真实的无偏谓词分布建模。随后说明 RA-SGG 如何识别包含潜在多标签的关系实例，并通过分配语义相近的谓词作为额外伪标签，增强这些实例的标签。最后说明 RA-SGG 的训练过程：采用多原型学习策略，有效学习增强后的关系标签。RA-SGG 的流程如图 2 所示。

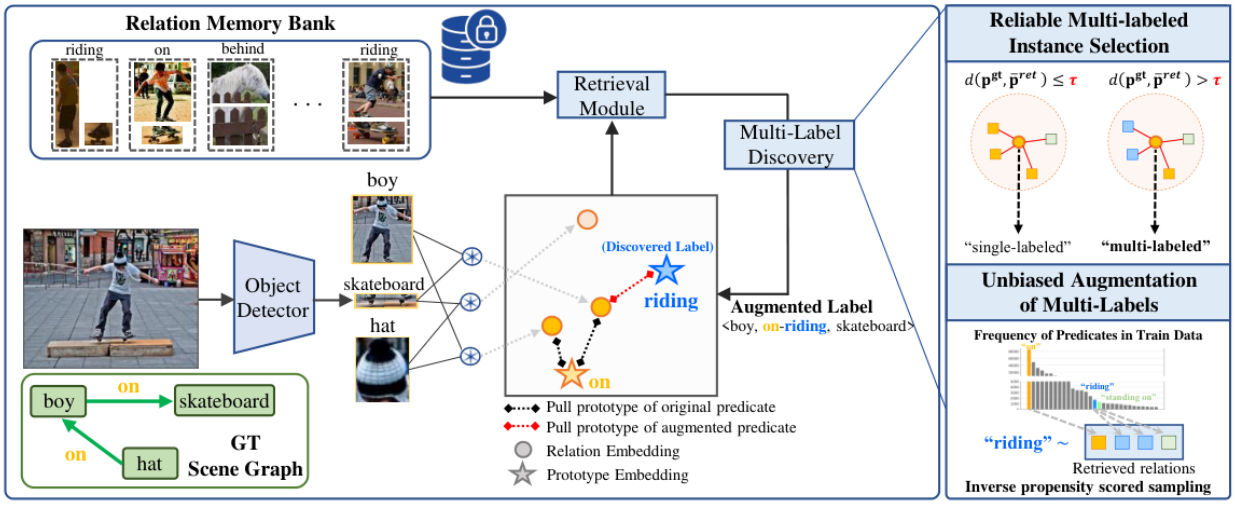


图 2： RA-SGG 首先使用关系嵌入查询记忆库中的实例，检索视觉与语义上相似的实例。随后，通过为潜在多标签实例分配伪标签来进行多标签增强。图内文字：Relation Memory Bank＝关系记忆库；Retrieval Module＝检索模块；Multi-Label Discovery＝多标签发现；Reliable Multi-labeled Instance Selection＝可靠的多标签实例选择；single-labeled／multi-labeled＝单标签／多标签；Object Detector＝物体检测器；Discovered Label＝发现的标签；Augmented Label＝增强后的标签；Unbiased Augmentation of Multi-Labels＝无偏多标签增强；Frequency of Predicates in Train Data＝训练数据中的谓词频率；Pull prototype of original／augmented predicate＝拉近原始／增强谓词的原型；Relation／Prototype Embedding＝关系／原型嵌入；Retrieved relations＝检索到的关系；Inverse propensity scored sampling＝逆倾向分数采样；Scene Graph＝场景图；boy／skateboard／hat＝男孩／滑板／帽子；riding／on／behind／standing on＝骑乘／在……上／在……后／站在……上。图中的阈值不等式按原图保留，正文式（3）亦按原式保留。

带有部分标注的多标签分类

回顾现有 SGG 研究，它们依赖每个关系的单一标注，忽略了具有相似语义的潜在谓词。这一忽视限制了模型表示复杂视觉场景的能力，尤其由于数据变化不足，影响了对不常见谓词或尾部谓词的表示。在此，我们首先将 SGG 任务形式化为带有部分标注的多标签分类问题，以利用潜在的细粒度谓词。

令 $\mathbf{y}^* \in \{0, 1\}^{N_p}$ 表示来自无偏真实分布的关系实例的真实标签向量。该分布是一种理想分布，不存在潜在未观测标注。$\mathbf{y}^*$ 容纳包括语义相关谓词在内的多个标签，即 $\sum_{i=1}^{N_p} y_i \geq 1$。在通常的 SGG 设置中，我们处理的是部分观测标注，其观测标签向量为 $\mathbf{y} \in \{0, 1\}^{N_p}$，其中 $\mathbf{y}$ 只有单个标签或没有标签，即 $\sum_{i=1}^{N_p} y_i = 1$ 或 $\sum_{i=1}^{N_p} y_i = 0$。我们的目标是利用观测谓词标签 $\mathbf{y}$，最小化在无偏真实分布的样本上计算的损失函数 $\mathcal{L}(\mathbf{y}^*, \hat{\mathbf{y}})$，其中 $\hat{\mathbf{y}}$ 是 SGG 模型预测的概率。然而，由于无法获得来自无偏真实分布的样本，我们使用可用的观测样本近似该损失。因此，引入以下逆倾向分数损失：

$$\mathcal{L}_{ips} = -\sum_{i=1}^{N_p} \underbrace{P(\mathbf{y}_i = 1 | \mathbf{y}_i^* = 1)^{-1}}_{\text{inverse propensity score}} \mathbf{y}_i \log \hat{\mathbf{y}}_i \qquad (2)$$

式（2）中的 inverse propensity score 意为逆倾向分数。$\mathcal{L}_{\text{ips}}$ 是按各谓词类别的逆倾向加权的交叉熵；倾向分数就是标签频率（Jain, Prabhu, and Varma 2016；Chiou et al. 2021），即无偏真实分布的全部谓词中，已观测谓词所占的比例。为简化起见，我们遵循（Jain, Prabhu, and Varma 2016），使用训练数据集中每个谓词类别的频率作为倾向分数。需要注意，优化 $\mathcal{L}_{\text{ips}}$ 近似于使用无偏真实分布的样本来最小化损失，因为 $\mathcal{L}_{\text{ips}}$ 是损失函数 $\mathcal{L}\left(\mathbf{y}^{*}, \widehat{\mathbf{y}}\right)$ 的无偏估计量。然而，对 SGG 模型直接最小化逆倾向分数损失仍然存在限制：它不会增加尾部谓词类别数据实例的变化多样性，因此会对少量尾部谓词过拟合。我们不优化上述 $\mathcal{L}_{\text{ips}}$，而选择依据逆倾向分数对谓词标签进行采样（Han et al. 2022），以增强关系实例，并将采样得到的谓词标签作为伪标签分配给该关系实例。我们将在第 4 节详细讨论这一点。

检索增强的场景图生成

我们采用检索过程，基于部分观测谓词有效训练 SGG 模型。具体而言，通过参考检索实例的谓词，发现并增强关系实例的潜在细粒度谓词。该过程首先从记忆库检索语义相似的样本。随后利用这些检索样本关联的谓词，识别可以被赋予多个谓词的关系实例，并用这些多标签增强数据集。尽管我们的方法可集成到任何 SGG 模型中，本文具体以 PE-Net 为骨干展示其应用。

关系检索模块。关系检索模块依据关系嵌入，寻找语义相似的关系实例。具体地，在 RA-SGG 训练之前，使用预训练 SGG 模型建立一个冻结的记忆库。在记忆库中存储键值对 $\left(k_1, v_1\right), \ldots, \left(k_M, v_M\right)$，其中键为关系嵌入（对于 PE-Net，即式（1）中的 $\mathbf{r}$），值为表示谓词类别的相关独热向量。我们的方法将每个不同三元组的记忆存储限制为最多 10 条，仅使用 8% 的训练数据。需要注意，记忆库构建在预处理阶段执行，不会为 RA-SGG 的训练阶段增加计算开销。

在训练阶段，RA-SGG 为训练批次中每个主体—客体对生成关系嵌入 $\mathbf{r}$。这些关系嵌入充当查询，基于余弦相似度从记忆库检索 K 个邻近实例。在检索到的实例中，我们排除第一个实例，以避免检索到实例自身这一平凡情况。

可靠的多标签实例选择。由于一些关系实例只包含单一语义，简单地向所有关系实例分配伪标签会降低可靠性。给定查询关系的 K 个最近邻实例 $\{\left(\mathbf{r}_1^{\text{ret}}, \mathbf{p}_1^{\text{ret}}\right), \ldots, \left(\mathbf{r}_K^{\text{ret}}, \mathbf{p}_K^{\text{ret}}\right)\}$，RA-SGG 首先识别查询关系是只有一个谓词的单标签实例，还是尽管可能具有多个标签、但目前仅有一个谓词的多标签实例。选择依据是查询关系的真实谓词 $\mathbf{p}^{q}$ 与检索实例的平均独热谓词 $\bar{\mathbf{p}}^{\text{ret}} = \frac{1}{K}\sum_{i=1}^{K}\mathbf{p}_i^{\text{ret}}$ 之间的标签不一致性。通过计算训练批次中所有查询关系实例的标签不一致性距离 $d(\cdot, \cdot)$，得到以下 $\mathcal{D}_{\text{single}}$ 和 $\mathcal{D}_{\text{multi}}$：

$$\mathcal{D}_{\text{single}} \leftarrow \left\{\left(\mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i\right) \middle| d\left(\mathbf{p}^{\text{q}}, \bar{\mathbf{p}}^{\text{ret}}\right) < \tau, \forall\left(\mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i\right) \in \mathcal{D}_{\text{Tr}}\right\} \quad (3)$$

$$\mathcal{D}_{\text{multi-}} \leftarrow \left\{\left(\mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i\right) \middle| d\left(\mathbf{p}^{\text{q}}, \bar{\mathbf{p}}^{\text{ret}}\right) \geq \tau, \forall\left(\mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i\right) \in \mathcal{D}_{\text{Tr}}\right\}$$

其中 τ 为阈值超参数，d 为距离度量。如果查询关系给定的真实谓词与最近邻样本的谓词差异显著，即不一致性较大，那么该查询关系很可能还共同指向邻居样本谓词中的其他潜在谓词标签。

无偏多标签增强。识别出潜在多标签关系实例后，我们通过向 $\mathcal{D}_{\text{multi}}$ 中的训练实例分配特定多标签，增强细粒度谓词。在这一增强阶段，通过采用基于逆倾向分数的采样，我们希望获得遵循无偏真实分布的增强标签。具体地，对检索谓词的逆倾向进行聚合，得到采样权重 $w \in \mathbb{R}^{N_p}$，即 $w = \text{Softmax}\left(\sum_{k=1}^{K} s_k^{\text{ret}} \mathbf{p}_k^{\text{ret}}\right)$，其中 $s_1^{\text{ret}}, \ldots, s_K^{\text{ret}} \in \mathbb{R}$ 是检索谓词的逆倾向，预先计算为训练数据集中谓词频率的倒数。对于 $\mathcal{D}_{\text{multi}}$ 中的每个三元组 $(\mathbf{s}_i, \mathbf{p}_i, \mathbf{o}_i)$，我们使用以下采样权重增强谓词标签：

$$\mathbf{p}_i \leftarrow \lambda_i \mathbf{p}_i^{\text{gt}} + (1-\lambda_i)\mathbf{p}_i^{\text{aug}}, \text{where } \mathbf{p}_i^{\text{aug}} \sim \text{Multinomial}(w) \quad (4)$$

式（4）中的 where 意为其中。$\lambda_i \sim \text{Beta}(\alpha, \beta)$ 控制混合系数的程度。我们的增强策略在生成伪标签时，不仅考虑最近邻的整体语义，也考虑谓词的频率。该方法有效利用部分标注来创建多标签实例，可应对 SGG 中的长尾分布问题和语义歧义。

具有多个谓词的多原型学习

当关系实例增强为具有多个谓词标签之后，我们采用多原型学习策略训练 RA-SGG。对于每个关系实例，最小化其关系嵌入 $\mathbf{r}$ 与多标签谓词对应的原型（即 $\bar{\mathbf{c}}_{\text{gt}}$ 和 $\bar{\mathbf{c}}_{\text{aug}}$）之间的距离，形式如下：

$$\begin{aligned}\mathcal{L}_{\text{multi-proto}} = &-\lambda_i \log \frac{\exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_{\text{gt}} \rangle)/\gamma}{\sum_{j=1}^{N_p} \exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_j \rangle)/\gamma} \\ &-(1-\lambda_i) \log \frac{\exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_{\text{aug}} \rangle)/\gamma}{\sum_{j=1}^{N_p} \exp(\langle \bar{\boldsymbol{r}}, \bar{\boldsymbol{c}}_j \rangle)/\gamma}\end{aligned} \quad (5)$$

其中 $\bar{\mathbf{r}} = \text{Proj}(\mathbf{r})$ 是应用投影层后的关系嵌入，$\bar{\mathbf{c}}_{\text{gt}}$ 表示真实谓词所对应的类别原型，$\bar{\mathbf{c}}_{\text{aug}}$ 表示增强谓词的原型。重要的是，尽管多原型学习损失的计算对每个关系实例最多考虑两个谓词类别，我们基于采样的谓词增强方法通过在每次批迭代时改变增强谓词，允许纳入两个以上的谓词。多原型学习确保关系实例嵌入不仅包含其真实谓词的原始语义，也包含所发现的潜在细粒度谓词的语义。

训练 RA-SGG 时，最终损失 $\mathcal{L}_{\text{final}}$ 表示为：

$$\mathcal{L}_{\text{final}} = \mathcal{L}_{\text{multi-proto}} + \mathcal{L}_{\text{reg1}} + \mathcal{L}_{\text{reg2}} \quad (6)$$

其中 $\mathcal{L}_{\text{reg1}} = \sqrt{\sum_{i \neq j} \left(\bar{\mathbf{c}}_i^{\top} \bar{\mathbf{c}}_j\right)^2}$ 是原型相似度正则化（Zheng et al. 2023），旨在最小化各个原型两两之间的余弦相似度；$\mathcal{L}_{\text{reg2}} = \max\{\gamma' - \frac{1}{N_p}\sum_{i \neq j} \| \bar{\mathbf{c}}_i - \bar{\mathbf{c}}_j \|_2^2, 0\}$ 是原型距离正则化（Zheng et al. 2023），用于增大原型之间的欧氏距离。这些正则化用于防止语义相近的谓词原型发生坍缩。

注意，检索过程与多原型学习策略仅在训练阶段使用。在推理阶段，我们计算每个关系嵌入与原型集合之间的余弦相似度，选取余弦相似度最高的原型所对应的谓词作为模型预测。

5 实验

实验设置

数据集与实现细节。 遵循先前方法（Dong et al. 2022；Li et al. 2023, 2021；Zellers et al. 2018；Zhang et al. 2022），我们使用基准数据集 VG（Krishna et al. 2017）和 GQA（Hudson and Manning 2019）。VG 的划分包含最常见的 150 个物体类别和 50 个谓词类别。GQA 是另一项视觉与语言基准，包含频率最高的 200 个物体类别和 100 个谓词类别。对于所有基线，我们采用 ResNeXt-101-FPN（Xie et al. 2017）和 Faster R-CNN（Ren et al. 2015）作为物体检测器。对于 RA-SGG，在可靠的多标签实例选择中设置阈值 $\tau = 0.3$，并在 $\{1, 3, 5, 10, 20\}$ 上进行网格搜索，选择检索数 K。

评估协议。 我们在三种传统 SGG 任务上评估最先进的模型与 RA-SGG：（1）谓词分类（PredCls），（2）场景图分类（SGCls），以及场景图检测（SGDet）。PredCls 在给定所有真实物体边界框和物体类别的条件下预测谓词类别。SGCls 在给定真实物体边界框的条件下预测谓词类别。SGGen 在给定图像的条件下检测所有实体及其两两间的谓词。

指标。 我们使用三项指标评估 SGG 模型：（1）Recall@K（R@K）计算排名前 K 的预测三元组中属于真实标注的比例。（2）Mean Recall@K（mR@K）计算每个谓词类别的平均召回率，旨在衡量谓词长尾分布下 SGG 模型的性能。（3）近期 SGG 研究指出，R@K 与 mR@K 存在权衡（Kim et al. 2024a）。因此，近期工作着重获得较高的 F@K，其中 F@K 计算 R@K 与 mR@K 的调和平均值。

B	Methods	Predicate Classification		
		R@50/100	mR@50/100	F@50/100
Specific	KERN(Chen et al. 2019)CVPR'19	65.8/67.6	17.7/19.2	27.9/29.9
	BGNN(Li et al. 2021)CVPR'21	59.2/61.3	30.4/32.9	40.2/42.8
	DT2ACBS(Desai et al. 2021)ICCV'21	23.3/25.6	35.9/**39.7**	28.3/31.1
	HL-Net(Lin et al. 2022)CVPR'22	67.0/68.9	- /22.8	- /34.3
	HetSGG(Yoon et al. 2023)AAAI'23	57.8/59.1	31.6/33.5	40.9/42.8
	SQUAT(Jung et al. 2023)CVPR'23	55.7/57.9	30.9/33.4	39.7/42.4
Motif	Motif(Zellers et al. 2018)CVPR'18	64.6/66.0	15.2/16.2	24.6/26.0
	TDE(Kaihua et al. 2020)CVPR'20	46.2/51.4	25.5/29.1	32.9/37.2
	DLFE(Chiou et al. 2021)MM'21	52.5/54.2	26.9/28.8	35.6/37.6
	NICE(Li et al. 2022)CVPR'22	55.1/57.2	29.9/32.3	38.8/41.3
	GCL(Dong et al. 2022)CVPR'22	42.7/44.4	36.1/38.2	39.1/41.1
	IETrans(Zhang et al. 2022)ECCV'22	54.7/56.7	30.9/33.6	39.5/42.2
	CFA (Li et al. 2023)ICCV'23	54.1/56.6	35.7/38.2	43.0/45.6
	ST-SGG(Kim et al. 2024a)ICLR'24	53.9/57.7	28.1/31.5	36.9/40.8
PE-Net	PE-Net†(Zheng et al. 2023)CVPR'23	64.9/67.2	31.5/33.8	42.4/45.0
	IETrans†(Zhang et al. 2022)ECCV'22	49.3/51.8	33.5/36.0	39.9/42.5
	CFA†(Li et al. 2023)ICCV'23	57.8/61.6	30.0/33.2	39.5/43.1
	RA-SGG	62.2/64.1	**36.2**/39.1	**45.7/48.6**

B	Methods	Scene Graph Classification			Scene Graph Detection		
		R@50/100	mR@50/100	F@50/100	R@50/100	mR@50/100	F@50/100
Specific	KERN(Chen et al. 2019)CVPR'19	36.7/37.4	9.4/10.0	15.0/15.8	27.1/29.8	6.4/7.3	10.4/11.7
	BGNN(Li et al. 2021)CVPR'21	37.4/38.5	14.3/16.5	20.7/23.1	31.0/35.8	10.7/12.6	15.9/18.6
	DT2ACBS(Desai et al. 2021)ICCV'21	16.2/17.6	**24.8/27.5**	19.6/21.5	15.0/16.3	**22.0/24.0**	17.8/19.4
	HL-Net(Lin et al. 2022)CVPR'22	42.6/43.5	- /13.5	- /20.6	33.7/38.1	- /9.2	- /14.8
	HetSGG(Yoon et al. 2023)AAAI'23	37.6/38.7	17.2/18.7	23.6/25.2	30.0/34.6	12.2/14.4	17.3/20.3
	SQUAT(Jung et al. 2023)CVPR'23	33.1/34.4	17.5/18.8	22.9/24.3	24.5/28.9	14.1/16.5	17.9/21.0
Motif	Motif(Zellers et al. 2018)CVPR'18	38.0/38.9	8.7/9.3	14.2/15.0	31.0/35.1	6.7/7.7	11.0/12.6
	TDE(Kaihua et al. 2020)CVPR'20	27.7/29.9	13.1/14.9	17.8/19.9	16.9/20.3	8.2/9.8	11.0/13.2
	DLFE(Chiou et al. 2021)MM'21	32.3/33.1	15.2/15.9	20.7/21.5	25.4/29.4	11.7/13.8	16.0/18.8
	NICE(Li et al. 2022)CVPR'22	33.1/34.0	16.6/17.9	22.1/23.5	27.8/31.8	12.2/14.4	17.0/19.8
	GCL(Dong et al. 2022)CVPR'22	26.1/27.1	20.8/21.8	23.2/24.1	18.4/22.0	16.8/19.3	17.6/20.6
	IETrans(Zhang et al. 2022)ECCV'22	32.5/33.4	16.8/17.9	22.2/23.3	26.4/30.6	12.4/14.9	16.9/20.0
	CFA (Li et al. 2023)ICCV'23	34.9/36.1	17.0/18.4	22.9/24.4	27.4/31.8	13.2/15.5	17.8/20.8
	ST-SGG(Kim et al. 2024a)ICLR'24	33.4/34.9	16.9/18.0	22.4/23.8	26.7/30.7	11.6/14.2	16.2/19.4
PE-Net	PE-Net†(Zheng et al. 2023)CVPR'23	39.4/40.7	17.8/18.9	24.5/25.8	30.7/35.2	12.4/14.5	17.7/20.4
	IETrans†(Zhang et al. 2022)ECCV'22	31.2/32.3	18.3/19.4	23.1/24.2	24.2/28.4	13.7/16.2	17.5/20.6
	CFA†(Li et al. 2023)ICCV'23	36.2/37.1	15.9/18.2	22.1/24.4	25.6/29.8	14.4/17.1	18.4/21.7
	RA-SGG	38.2/39.1	20.9/22.5	**27.0/28.6**	26.0/30.3	14.4/17.1	**18.5/21.9**

表 1： 最先进 SGG 模型在 Visual Genome（Krishna et al. 2017）上的性能（%）。F@K 是 mR@50/100 与 R@50/100 的调和平均值。† 表示我们使用其官方代码得到的结果。列标题：B＝骨干；Methods＝方法；Predicate Classification＝谓词分类；Scene Graph Classification＝场景图分类；Scene Graph Detection＝场景图检测；Specific＝专用骨干。原始数值、引文、加粗与下划线完整保留。

Models	Predicate Classification		
	R@50/100	mR@50/100	F@50/100
VTransE(Zhang et al. 2017)CVPR'17	55.7/57.9	14.0/15.0	22.4/23.8
Motif(Zellers et al. 2018)CVPR'18	65.3/66.8	16.4/17.1	26.2/27.2
VCTree(Tang et al. 2019)ICCV'19	63.8/65.7	16.6/17.4	26.4/27.5
PE-Net† (Zheng et al. 2023)CVPR'23	54.3/56.0	26.2/27.1	35.4/36.5
PE-Net+RA-SGG	48.3/50.1	**35.4/36.8**	**40.9/42.4**

Models	Scene Graph Classification			Scene Graph Detection		
	R@50/100	mR@50/100	F@50/100	R@50/100	mR@50/100	F@50/100
VTransE(Zhang et al. 2017)CVPR'17	33.4/34.2	8.1/8.7	13.0/13.9	27.2/30.7	5.8/6.6	9.6/10.9
Motif(Zellers et al. 2018)CVPR'18	34.2/34.9	8.2/8.6	13.2/13.8	28.9/33.1	6.4/7.7	10.5/12.5
VCTree(Tang et al. 2019)ICCV'19	34.1/34.8	7.9/8.3	12.8/13.4	28.3/31.9	6.5/7.4	10.6/12.0
PE-Net† (Zheng et al. 2023)CVPR'23	26.2/27.0	11.2/11.5	15.7/16.1	19.5/22.9	10.3/11.9	13.5/15.7
PE-Net+RA-SGG	19.9/20.8	**16.4/17.2**	**18.0/18.8**	16.3/19.0	**12.9/15.0**	**14.4/16.8**

表 2： 最先进 SGG 模型在 GQA（Hudson and Manning 2019）上的性能（%）。Models＝模型，其余任务与指标列标题同表 1。

与最先进方法的比较

Visual Genome 上的结果。 我们将 RA-SGG 应用于专门捕捉关系表示空间的 PE-Net 骨干（Zheng et al. 2023），并在表 1 中将其与最先进基线进行比较。根据实验结果，我们总结出以下结论：**1）RA-SGG 在传统 SGG 任务下实现了最先进的性能，尤其是在 mR@K 和 F@K 方面。** 我们的方法不仅比 HetSGG（Yoon et al. 2023）和 SQUAT（Jung et al. 2023）等前沿 SGG 模型的 F@K 最多高出 6.2%，而且获得了更高的 R@K。与骨干模型 PE-Net 相比，我们大幅提高了 mR@K，仅使 R@K 略有下降。这些结果表明，RA-SGG 通过检索发现潜在细粒度谓词的策略，可以有效提升模型在所有谓词类别上的泛化能力，同时不损害对通用谓词的识别。**2）在应对 SGG 挑战方面，发现潜在多标签是比数据增强／扩充方法更有效的策略。** 在使用 PE-Net 骨干时，RA-SGG 的所有指标均超过 IE-Trans 和 CFA。我们认为，这是因为 IE-Trans 和 CFA 为获得细粒度谓词而忽略了对通用谓词的全面理解，而我们的多标签发现同时有效处理了通用谓词与细粒度谓词。该结果表明，将任务表述为带有部分标注的多标签分类，从根本上解决了长尾问题与语义歧义。

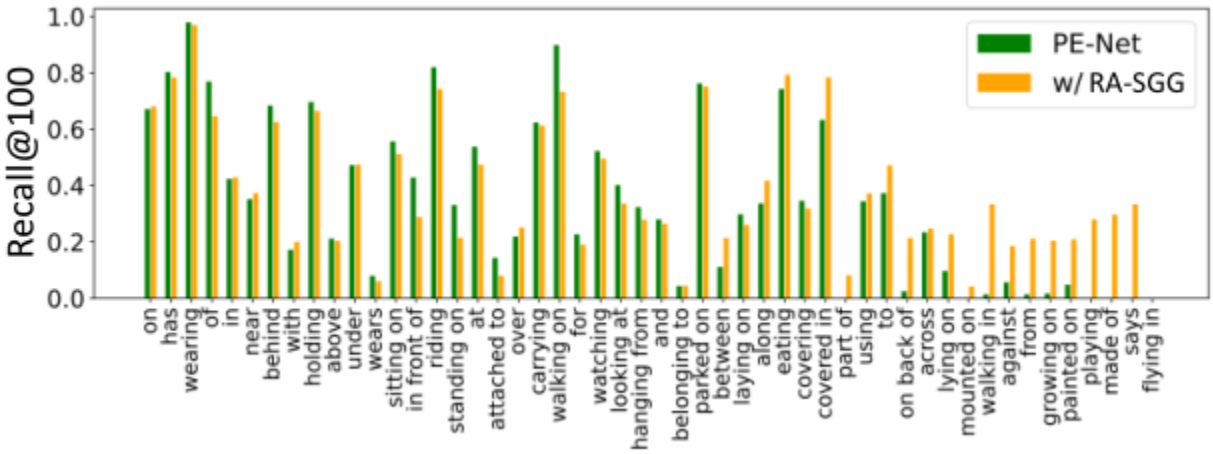


图 3： 在 VG 上逐谓词比较 RA-SGG 与 PE-Net。任务为 PredCls。Recall@100＝召回率@100；横轴为原始谓词类别名。

逐谓词比较。 图 3 通过逐谓词性能分析，详细比较使用 PE-Net 骨干的 RA-SGG 和原版 PE-Net。分析发现，RA-SGG 显著提高了“lying on”（躺在……上）、“walking in”（在……中行走）、“made of”（由……制成）以及“says”（写着）等细粒度谓词的性能，而原版 PE-Net 完全忽略了这些谓词。这一提升表明，RA-SGG 善于捕捉细微的视觉线索来预测细粒度谓词，证明了发现潜在谓词的有效性。

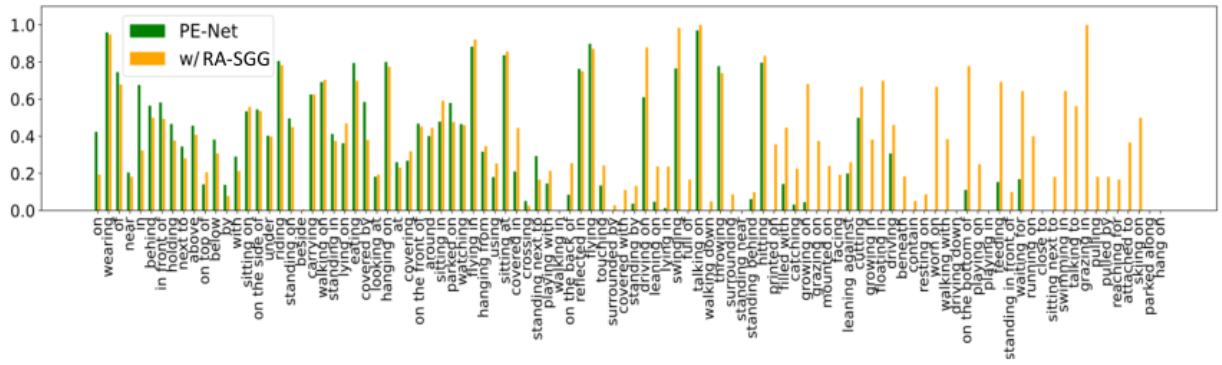


图 4： 在 GQA 上逐谓词比较 RA-SGG 与 PE-Net。任务为 PredCls。谓词按频率排序；横轴保留原始谓词类别名。

图 3 与图 4 的坐标轴及图例文字译注

Recall@100 = 召回率@100；PE-Net = PE-Net（绿色）；w/ RA-SGG = 使用 RA-SGG（橙色）。以下按图 3 的标签顺序列出对应译文，再补充图 4 中新增的标签；英文保留原图拼写与措辞。

图 3 的 50 个谓词标签：

on = 在……上；has = 有；wearing = 穿戴着；of = 属于；in = 在……中；near = 靠近；behind = 在……后面；with = 带有；holding = 拿着；above = 在……上方；under = 在……下；wears = 穿戴；sitting on = 坐在……上；in front of = 在……前面；riding = 骑乘；standing on = 站在……上；at = 在……处；attached to = 连接于；over = 在……上方；carrying = 携带；walking on = 行走在……上；for = 为了；watching = 观看；looking at = 看着；hanging from = 悬挂于；and = 和；belonging to = 归属于；parked on = 停放在……上；between = 在……之间；laying on = 平放在……上；along = 沿着；eating = 吃；covering = 覆盖；covered in = 被……覆盖；part of = 是……的一部分；using = 使用；to = 向；on back of = 在……背上；across = 横跨；lying on = 躺在……上；mounted on = 安装在……上；walking in = 行走在……中；against = 靠着；from = 来自；growing on = 生长在……上；painted on = 绘在……上；playing = 玩；made of = 由……制成；says = 写着；flying in = 飞行在……中。

图 4 中其余谓词标签（与上述共同构成两图标签的并集）：

next to = 紧邻；on top of = 在……顶部；below = 在……下方；by = 在……旁；on the side of = 在……侧面；beside = 在……旁边；standing in = 站在……中；covered by = 被……覆盖；hanging on = 挂在……上；on the front of = 在……正面；around = 在……周围；sitting in = 坐在……中；sitting at = 坐在……旁；crossing = 穿过；standing next to = 站在……旁边；playing with = 与……玩耍；on the back of = 在……背面；reflected in = 映在……中；flying = 飞翔；touching =

接触；surrounded by = 被……包围；covered with = 覆盖着；standing by = 站在……旁；driving on = 驾驶在……上；leaning on = 倚在……上；lying in = 躺在……中；swinging = 挥动；full of = 充满；talking on = 通过……交谈；walking down = 沿……走下；throwing = 投掷；surrounding = 围绕；standing near = 站在……附近；standing behind = 站在……后面；hitting = 击打；printed on = 印在……上；filled with = 装满；catching = 接住；grazing on = 在……上吃草；facing = 面向；leaning against = 倚靠着；cutting = 切割；growing in = 生长在……中；floating in = 漂浮在……中；driving = 驾驶；beneath = 在……下方；contain = 包含；resting on = 靠放在……上；worn on = 穿戴在……上；walking with = 与……同行；driving down = 沿……驶下；on the bottom of = 在……底部；playing on = 在……上玩；playing in = 在……中玩；feeding = 喂养；standing in front of = 站在……前面；waiting for = 等待；running on = 奔跑在……上；close to = 接近；sitting next to = 坐在……旁边；swimming in = 游泳在……中；talking to = 与……交谈；grazing in = 在……中吃草；pulling = 拉；pulled by = 被……拉着；reaching for = 伸手去够；skiing on = 滑雪在……上；parked along = 沿……停放；hang on = 挂在……上。

GQA 上的结果。 在表 2 中，我们观察到，相较于强基线 PE-Net，RA-SGG 大幅提高了 mR@K 和 F@K，展示了它在包含大量谓词类别的大型数据集上的有效性。同样，图 4 展示出 RA-SGG 能提高对 PE-Net 容易忽视的细粒度谓词的识别。这些结果说明，即使使用含有大量谓词类别的数据集，RA-SGG 也能有效发现潜在细粒度谓词。

消融研究

Model	Predicate Classification			Scene Graph Classification		
	R@50/100	mR@50/100	F@50/100	R@50/100	mR@50/100	F@50/100
Vanilla PE-Net	64.9/67.2	31.5/33.8	42.4/45.0	39.4/40.7	17.8/18.9	24.5/25.8
RA-SGG w/o select.	64.4/66.4	33.4/36.4	44.0/47.0	38.5/39.4	19.6/20.9	26.0/27.3
RA-SGG w/o IPSS	64.6/66.7	32.9/35.1	43.6/46.0	38.6/39.5	18.6/19.8	25.1/26.3
RA-SGG	62.2/64.1	**36.2/39.1**	**45.7/48.6**	38.2/39.1	**20.9/22.5**	**27.0/28.6**

表 3： RA-SGG 的消融研究。Model＝模型；Vanilla＝原版；w/o select.＝不使用可靠实例选择；w/o IPSS＝不使用逆倾向分数采样；任务及指标列标题同表 1。

模块组件分析。 我们对 RA-SGG 进行消融研究，评估每个组件的影响。我们消融了 RA-SGG 的两个组件。对于 RA-SGG w/o select.，跳过用于确定关系实例是单标签还是多标签的可靠多标签实例选择。对于 RA-SGG w/o IPSS，将无偏增强模块中的逆倾向分数替换为常数。在表 3 中，我们得到以下观察：1）RA-SGG w/o select. 的 mR@K 和 F@K 仍优于 PE-Net。也就是说，依据检索实例粗略地为所有关系分配伪标签，也能提高细粒度谓词的性能。我们认为，这归因于检索增强方法的优势，它利用记忆库发现语义相近的谓词。2）与 RA-SGG 相比，RA-SGG w/o IPSS 的 mR@K 和 F@K 下降。这表明基于逆倾向分数的采样对于提高细粒度谓词性能十分重要。3）结合所有组件，RA-SGG 可以获得最佳泛化能力。

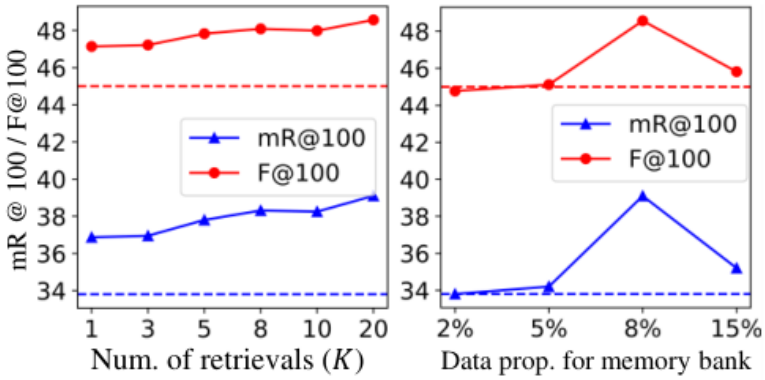


Figure 5: Sensitivity analysis on hyperparameters. The dotted line represents the result of PE-Net.

图 5： 超参数敏感性分析。虚线表示 PE-Net 的结果。Num. of retrievals (K)＝检索数（K）；Data prop. for memory bank＝用于记忆库的数据比例；纵轴为 mR@100／F@100。

检索数量分析。 在 PredCls 任务下，我们分析 $K \in \{1, 3, 5, 8, 10, 20\}$ 的影响。图 5.(a) 显示，RA-SGG 始终优于 PE-Net，说明即使只利用一个近邻，也有助于提高 PE-Net 的性能。RA-SGG 在 $K = 20$ 时获得最佳性能，表明参考更多邻居有助于提高细粒度谓词的性能。

记忆库规模分析。 我们分析记忆库大小的影响，改变每个不同三元组所存储的关系实例数，测试每个不同三元组存储 $\{1, 5, 10, 100\}$ 个实例的情况。这些数量分别约占全部训练实例的 $\{2\%, 5\%, 8\%, 15\%\}$。图 5.(b) 中可以看到，RA-SGG 总体优于原版 PE-Net，并在记忆库包含 8% 训练实例时获得最佳性能。该结果表明，利用训练数据集的一小部分即可显著提升 SGG 模型的性能。此外，记忆库的紧凑规模不仅提高了效率，也有利于 RA-SGG 的可扩展性。

检索策略的性能。 由于没有检索的真实标签，难以衡量检索准确率。因此，我们对 100 个采样实例的检索过程进行了人工评估，获得 84.20% 的准确率。这说明我们的方法能准确检索，并有效增强多标签。

复杂度分析。 注意，RA-SGG 的推理时间与 PE-Net 相同。在训练阶段，我们观察到 RA-SGG 所需训练时间是 PE-Net 的 1.3 倍，说明检索过程的计算成本可控。

6 结论

虽然细粒度 SGG 研究受到关注，但先前框架仍存在根本挑战。它们要么由于 SGG 固有的长尾问题和语义歧义而难以捕捉细粒度谓词，要么通过将通用谓词重新标注为细粒度谓词而忽略了通用谓词。在本文中，我们首次通过发现训练数据中潜在的细粒度谓词，将 SGG 任务重新表述为带有部分标注的多标签分类问题。为此，提出新颖的检索增强 SGG 框架（RA-SGG），通过检索过程将原始标签增强为多标签。RA-SGG 有效发现了训练数据集中的潜在细粒度谓词，使整体谓词性能显著提升。我们的工作考虑了自然语言中多个谓词可以表达同一个关系的特性，为 SGG 研究提供了新的视角。

致谢

本研究获得了以下支持：韩国科学技术信息通信部资助的韩国国家研究基金会（NRF）项目（NRF-2022M3J6A1063021，10%；No. RS-2024-00341514，10%）；韩国政府（MSIT）资助的信息通信技术规划与评估院（IITP）项目（RS-2023-00216011，“开发像人类一样进行概念性理解与推理的人工复合智能”，79%）；以及项目 No. 2019-0-00079（“人工智能研究生院计划”，高丽大学，1%）。

参考文献

Ben-Baruch, E.; Ridnik, T.; Friedman, I.; Ben-Cohen, A.; Zamir, N.; Noy, A.; and Zelnik-Manor, L. 2022. Multi-Label Classification With Partial Annotations Using Class-Aware Selective Loss. [使用类别感知选择性损失进行部分标注的多标签分类。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 4764–4772.

Blattmann, A.; Rombach, R.; Oktay, K.; Müller, J.; and Ommer, B. 2022. Retrieval-Augmented Diffusion Models. [检索增强扩散模型。] In Koyejo, S.; Mohamed, S.; Agarwal, A.; Belgrave, D.; Cho, K.; and Oh, A., eds., Advances in Neural Information Processing Systems, volume 35, 15309–15324. Curran Associates, Inc.

Borgeaud, S.; Mensch, A.; Hoffmann, J.; Cai, T.; Rutherford, E.; Millican, K.; Van Den Driessche, G. B.; Lespiau, J.-B.; Damoc, B.; Clark, A.; De Las Casas, D.; Guy, A.; Menick, J.; Ring, R.; Hennigan, T.; Huang, S.; Maggiore, L.; Jones, C.; Cassirer, A.; Brock, A.; Paganini, M.; Irving, G.; Vinyals, O.; Osindero, S.; Simonyan, K.; Rae, J.; Elsen, E.; and Sifre, L. 2022. Improving Language Models by Retrieving from Trillions of Tokens. [通过从数万亿词元中检索来改进语言模型。] In Proceedings of the 39th International Conference on Machine Learning, volume 162 of Proceedings of Machine Learning Research, 2206–2240. PMLR.

Casanova, A.; Careil, M.; Verbeek, J.; Drozdzal, M.; and Romero-Soriano, A. 2021. Instance-Conditioned GAN. [实例条件 GAN。] In Advances in Neural Information Processing Systems (NeurIPS).

Chen, T.; Yu, W.; Chen, R.; and Lin, L. 2019. Knowledge-embedded routing network for scene graph generation. [用于场景图生成的知识嵌入路由网络。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 6163–6171.

Chen, W.; Hu, H.; Saharia, C.; and Cohen, W. W. 2023. Re-Imagen: Retrieval-Augmented Text-to-Image Generator. [Re-Imagen：检索增强文本到图像生成器。] In The Eleventh International Conference on Learning Representations.

Chiou, M.-J.; Ding, H.; Yan, H.; Wang, C.; Zimmermann, R.; and Feng, J. 2021. Recovering the Unbiased Scene Graphs from the Biased Ones. [从有偏场景图中恢复无偏场景图。] In Proceedings of the 29th ACM International Conference on Multimedia, MM ’21, 1581–1590. New York, NY, USA: Association for Computing Machinery. ISBN 9781450386517.

Desai, A.; Wu, T.-Y.; Tripathi, S.; and Vasconcelos, N. 2021. Learning of Visual Relations: The Devil Is in the Tails. [视觉关系学习：难点在尾部类别。] In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 15404–15413.

Dong, X.; Gan, T.; Song, X.; Wu, J.; Cheng, Y.; and Nie, L. 2022. Stacked Hybrid-Attention and Group Collaborative Learning for Unbiased Scene Graph Generation. [用于无偏场景图生成的堆叠混合注意力与分组协同学习。] In CVPR.

Guu, K.; Lee, K.; Tung, Z.; Pasupat, P.; and Chang, M.-W. 2020. REALM: retrieval-augmented language model pre-training. [REALM：检索增强语言模型预训练。] In Proceedings of the 37th International Conference on Machine Learning, ICML’20. JMLR.org.

Han, S.; Choi, E.; Lim, C.; Shim, H.; and Lee, J. 2022. Long-tail Mixup for Extreme Multi-label Classification. [面向极端多标签分类的长尾 Mixup。] In Proceedings of the 31st ACM International Conference on Information & Knowledge Management, CIKM’22, 3998–4002. New York, NY, USA: Association for Computing Machinery. ISBN 9781450392365.

Hildebrandt, M.; Li, H.; Koner, R.; Tresp, V.; and Günnemann, S. 2020. Scene Graph Reasoning for Visual Question Answering. [用于视觉问答的场景图推理。]

Hudson, D. A.; and Manning, C. D. 2019. GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering. [GQA：用于真实世界视觉推理和组合式问答的新数据集。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

Jain, H.; Prabhu, Y.; and Varma, M. 2016. Extreme Multi-label Loss Functions for Recommendation, Tagging, Ranking & Other Missing Label Applications. [用于推荐、标记、排序及其他缺失标签应用的极端多标签损失函数。] In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD’16, 935–944. New York, NY, USA: Association for Computing Machinery.

Jeon, J.; Kim, K.; Yoon, K.; and Park, C. 2024. Semantic Diversity-Aware Prototype-Based Learning for Unbiased Scene Graph Generation. [用于无偏场景图生成的语义多样性感知原型学习。] In Computer Vision – ECCV 2024. Springer Nature Switzerland.

Jung, D.; Kim, S.; Kim, W. H.; and Cho, M. 2023. Devil’s on the Edges: Selective Quad Attention for Scene Graph Generation. [难点在边上：用于场景图生成的选择性四重注意力。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 18664–18674.

Kaihua, T.; Yulei, N.; Jianqiang, H.; Jiaxin, S.; and Hanwang, Z. 2020. Unbiased scene graph generation from biased training. [从有偏训练中进行无偏场景图生成。] CVPR, 3716–3725.

Kim, K.; Yoon, K.; In, Y.; Moon, J.; Kim, D.; and Park, C. 2024a. Adaptive Self-training Framework for Fine-grained Scene Graph Generation. [用于细粒度场景图生成的自适应自训练框架。] In The Twelfth International Conference on Learning Representations.

Kim, K.; Yoon, K.; Jeon, J.; In, Y.; Moon, J.; Kim, D.; and Park, C. 2024b. LLM4SGG: Large Language Models for Weakly Supervised Scene Graph Generation. [LLM4SGG：用于弱监督场景图生成的大语言模型。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 28306–28316.

Krishna, R.; Zhu, Y.; Groth, O.; Johnson, J.; Hata, K.; Kravitz, J.; Chen, S.; Kalantidis, Y.; Li, L.-J.; Shamma, D. A.; et al. 2017. Visual genome: Connecting language and vision using crowdsourced dense image annotations. [Visual Genome：利用众包密集图像标注连接语言与视觉。] International journal of computer vision, 123: 32–73.

Lewis, P.; Perez, E.; Piktus, A.; Petroni, F.; Karpukhin, V.; Goyal, N.; Küttler, H.; Lewis, M.; Yih, W.-t.; Rocktäschel, T.; Riedel, S.; and Kiela, D. 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. [面向知识密集型自然语言处理任务的检索增强生成。] In Proceedings of the 34th International Conference on Neural Information Processing Systems, NIPS’20. Curran Associates Inc.

Li, L.; Chen, G.; Xiao, J.; Yang, Y.; Wang, C.; and Chen, L. 2023. Compositional Feature Augmentation for Unbiased Scene Graph Generation. [用于无偏场景图生成的组合特征增强。] In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 21685–21695.

Li, L.; Chen, L.; Huang, Y.; Zhang, Z.; Zhang, S.; and Xiao, J. 2022. The devil is in the labels: Noisy label correction for robust scene graph generation. [难点在标签中：用于鲁棒场景图生成的噪声标签校正。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 18869–18878.

Li, R.; Zhang, S.; Wan, B.; and He, X. 2021. Bipartite graph network with adaptive message passing for unbiased scene graph generation. [用于无偏场景图生成的自适应消息传递二部图网络。] CVPR.

Lin, X.; Ding, C.; Zhan, Y.; Li, Z.; and Tao, D. 2022. HL-Net: Heterophily Learning Network for Scene Graph Generation. [HL-Net：用于场景图生成的异配性学习网络。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 19476–19485.

Long, A.; Yin, W.; Ajanthan, T.; Nguyen, V.; Purkait, P.; Garg, R.; Blair, A.; Shen, C.; and van den Hengel, A. 2022. Retrieval Augmented Classification for Long-Tail Visual Recognition. [用于长尾视觉识别的检索增强分类。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 6959–6969.

Lyu, X.; Gao, L.; Guo, Y.; Zhao, Z.; Huang, H.; Shen, H. T.; and Song, J. 2022. Fine-Grained Predicates Learning for Scene Graph Generation. [用于场景图生成的细粒度谓词学习。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 19467–19475.

Ren, S.; He, K.; Girshick, R.; and Sun, J. 2015. Faster r-cnn: Towards real-time object detection with region proposal networks. [Faster R-CNN：通过区域提议网络实现实时目标检测。] NeurIPS.

S. Hasegawa, A. N., M. Hiromoto; and Umeda, Y. 2022. Improving Predicate Representation in Scene Graph Generation by Self-Supervised Learning. [通过自监督学习改进场景图生成中的谓词表示。] In 2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), Waikoloa, HI, USA, 2023, pp. 2739-2748.

Schroeder, B.; and Tripathi, S. 2020. Structured query-based image retrieval using scene graphs. [利用场景图进行基于结构化查询的图像检索。] CVPR Workshops, 178–179.

Shit, S.; Koner, R.; Wittmann, B.; Paetzold, J.; Ezhov, I.; Li, H.; Pan, J.; Sharifzadeh, S.; Kaissis, G.; Tresp, V.; and Menze, B. 2022. Relationformer: A Unified Framework for Image-to-Graph Generation. [Relationformer：图像到图生成的统一框架。] In ECCV’2022.

Tang, K.; Zhang, H.; Wu, B.; Luo, W.; and Liu, W. 2019. Learning to compose dynamic tree structures for visual contexts. [学习为视觉上下文组合动态树结构。] In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 6619–6628.

Xie, S.; Girshick, R.; Dollár, P.; Tu, Z.; and He, K. 2017. Aggregated residual transformations for deep neural networks. [用于深度神经网络的聚合残差变换。] Proceedings of the IEEE conference on computer vision and pattern recognition(CVPR), 1492–1500.

Yang, J.; Lu, J.; Lee, S.; Batra, D.; and Parikh, D. 2018. Graph r-cnn for scene graph generation. [用于场景图生成的 Graph R-CNN。] ECCV, 128(7): 670–685.

Yoon, K.; Kim, K.; Moon, J.; and Park, C. 2023. Unbiased Heterogeneous Scene Graph Generation with Relation-aware Message Passing Neural Network. [使用关系感知消息传递神经网络进行无偏异构场景图生成。] In The 37th AAAI Conference on Artificial Intelligence.

Yu, Q.; Li, J.; Wu, Y.; Tang, S.; Ji, W.; and Zhuang, Y. 2023. Visually-Prompted Language Model for Fine-Grained Scene Graph Generation in an Open World. [用于开放世界细粒度场景图生成的视觉提示语言模型。] In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 21560–21571.

Zellers, R.; Yatskar, M.; Thomson, S.; and Choi, Y. 2018. Neural motifs: Scene graph parsing with global context. [Neural Motifs：具有全局上下文的场景图解析。] In Proceedings of the IEEE conference on computer vision and pattern recognition, 5831–5840.

Zhai, R.; Dan, C.; Kolter, J. Z.; and Ravikumar, P. K. 2022. Understanding Overfitting in Reweighting Algorithms for Worst-group Performance. [理解面向最差组性能的重加权算法中的过拟合。]

Zhang, A.; Yao, Y.; Chen, Q.; Ji, W.; Liu, Z.; Sun, M.; and Chua, T.-S. 2022. Fine-Grained Scene Graph Generation with Data Transfer. [使用数据迁移进行细粒度场景图生成。] In ECCV.

Zhang, H.; Cisse, M.; Dauphin, Y. N.; and Lopez-Paz, D. 2018. mixup: Beyond Empirical Risk Minimization. [mixup：超越经验风险最小化。] In International Conference on Learning Representations.

Zhang, H.; Kyaw, Z.; Chang, S.-F.; and Chua, T.-S. 2017. Visual translation embedding network for visual relation detection. [用于视觉关系检测的视觉平移嵌入网络。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

Zheng, C.; Lyu, X.; Gao, L.; Dai, B.; and Song, J. 2023. Prototype-Based Embedding Network for Scene Graph Generation. [用于场景图生成的基于原型的嵌入网络。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

A 实现细节

为公平比较，我们遵循以往研究（Zellers et al. 2018; Zhang et al. 2022; Li et al. 2023）的设置，使用预训练的 ResNeXt-101-FPN 骨干网络和 Faster R-CNN 检测器（Ren et al. 2015）。对于 RA-SGG，我们利用留出集在 $\{1, 3, 5, 10, 20\}$ 中进行网格搜索，以确定检索数量 K，并选择 F@K 性能最佳的模型。我们将阈值设为 $\tau = 0.3$。此外，为背景关系赋予多标签时，我们跳过可靠多标签实例选择阶段，仅执行基于逆倾向得分采样的无偏多标签增强。实验使用 NVIDIA A6000 48GB 设备。

B RA-SGG 的补充分析

复杂度分析

Method	Time (s) per 100 batch iterations
PENet† (Zheng et al. 2023)CVPR'23	20.42
RA-SGG	26.03

表 4：每 100 次批次迭代的耗时（秒）。RA-SGG 采用 PE-Net 骨干网络。

表内文字：Method = 方法；Time (s) per 100 batch iterations = 每 100 次批次迭代的耗时（秒）。

我们进行复杂度分析，以验证在 RA-SGG 中使用记忆库所需的计算成本是可承受的。在该实验中，我们设置 $K = 5$，检索过程中使用的记忆库包含训练数据集的 8%（即约 90,000 个关系实例）。实验使用 NVIDIA A6000 设备。表 4 分别给出了训练 PE-Net 和 RA-SGG 所需的时间。我们观察到，RA-SGG 的训练时间约为 PE-Net 的 1.3 倍，表明检索过程的计算成本是可控的。在测试阶段，RA-SGG 的推理时间与 PE-Net 相同。

定性分析

检索过程中的示例。在图 6 中，我们随机选择查询关系及其检索实例的示例，并将其可视化。给定查询关系，RA-SGG 从记忆库中找到语义相似的关系实例。可以观察到，检索实例的谓词类别可以成为查询关系的潜在关系。此外，由检索实例的逆倾向得分计算得到的采样概率，鼓励在细粒度谓词类别上生成伪标签。



图 6： RA-SGG 中的查询关系、检索关系及采样概率示例。给定查询关系，我们从记忆库中检索最相似的 3 个实例。然后，根据检索实例的逆倾向得分计算采样概率。我们根据该采样概率对谓词标签进行采样，以生成多标签。

图内文字译注：Query Relation = 查询关系；Retrieved Relations = 检索关系；Sample Prob. = 采样概率；subject = 主体；object = 客体。三元组依原图顺序：⟨腿，属于，人⟩；⟨腿，连接于，人⟩、⟨腿，归属于，人⟩、⟨腿，是……的一部分，人⟩；⟨枕头，在……上方，床⟩；⟨枕头，在……上，床⟩、⟨枕头，平放在……上，床⟩、⟨枕头，在……中，床⟩；⟨狗，坐在……上，长凳⟩；⟨狗，躺在……上，长

凳⟩、⟨狗，平躺在……上，长凳⟩、⟨狗，在……上，长凳⟩；⟨树，生长在……上，山丘⟩；⟨树，在……中，山丘⟩、⟨树，靠近，山丘⟩、⟨树，覆盖，山丘⟩；⟨人，携带，伞⟩；⟨人，使用，伞⟩、⟨人，带有，伞⟩、⟨人，带有，伞⟩。

视觉语义空间的可视化。在图 7 中，单原型学习使“growing on”（生长在……上）和“walking in”（行走在……中）等尾部类别的原型与其样本相距较远，表明对尾部类别的学习效果不佳。相比之下，多原型学习将这些类别的原型训练到更靠近样本的位置，表明细粒度谓词的预测得到改善。

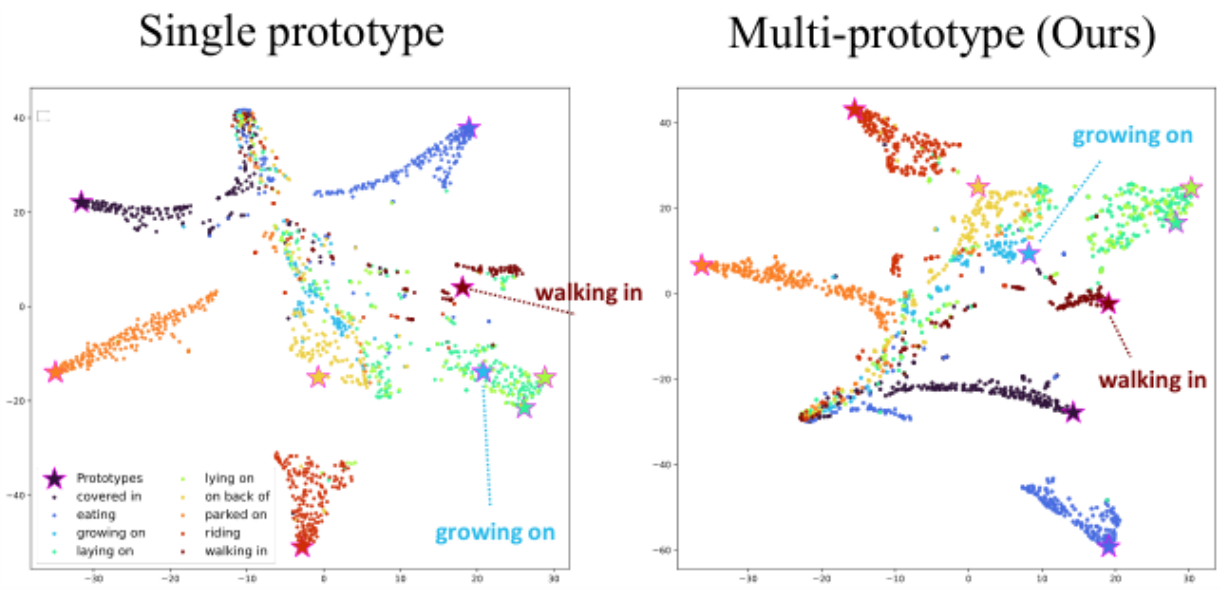


图 7：单原型学习和多原型学习的 t-SNE 可视化。

图内文字译注：Single prototype = 单原型；Multi-prototype (Ours) = 多原型（我们的方法）；Prototypes = 原型；covered in = 被……覆盖；eating = 吃；growing on = 生长在……上；laying on = 平放在……上；lying on = 躺在……上；on back of = 在……背上；parked on = 停放在……上；riding = 骑乘；walking in = 行走在……中。

不同检索增强方法的分析

我们分析了利用检索实例实现细粒度 SGG 的不同策略。具体而言，给定查询关系 $\left(\mathbf{r}^{\text{query}}, \mathbf{p}^{\text{query}}\right)$ 以及检索实例 $\{\left(\mathbf{r}_1^{\text{ret}}, \mathbf{p}_1^{\text{ret}}\right), \ldots, \left(\mathbf{r}_K^{\text{ret}}, \mathbf{p}_K^{\text{ret}}\right)\}$，我们提出三种利用检索实例的方式。

1. **Feat Aug（特征增强）：**使用 MLP，将检索到的谓词直接用于增强查询关系嵌入，而不进行标签增强，即 $\mathbf{r}^{\text{query}} \leftarrow \mathbf{r}^{\text{query}} + \text{MLP}\left(\{\mathbf{p}_i^{\text{ret}}\}_{i=1}^{K}\right)$。
2. **Label Aug（标签增强，RA-SGG）：**使用我们提出的方法增强查询关系的谓词标签，即 $\mathbf{p}^{\text{query}} \leftarrow \lambda \mathbf{p}^{\text{query}} + (1-\lambda)\mathbf{p}^{\text{aug}}$。
3. **Mix-up：**使用 mix-up（Zhang et al. 2018）同时增强查询关系的关系嵌入和谓词标签，即 $\mathbf{r}^{\text{query}} \leftarrow \lambda \mathbf{r}^{\text{query}} + (1-\lambda)\mathbf{r}^{\text{aug}}$，以及 $\mathbf{p}^{\text{query}} \leftarrow \lambda \mathbf{p}^{\text{query}} + (1-\lambda)\mathbf{p}^{\text{aug}}$。

Task: PredCls	R@50/100	mR@50/100	F@50/100
Vanilla PE-Net	**64.9/67.2**	31.5/33.8	42.4/45.0
Feat Aug	**68.3/70.3**	20.9/22.8	32.0/34.5
Label Aug (RA-SGG)	62.2/64.1	**36.2/39.1**	**45.8/48.6**
Mix-up	67.3/69.4	25.9/28.2	37.4/40.1

表 5：采用不同检索增强方法时在 VG 上的结果。

表内文字译注：Task: PredCls = 任务：谓词分类；Vanilla PE-Net = 原始 PE-Net；Feat Aug = 特征增强；Label Aug (RA-SGG) = 标签增强（RA-SGG）；Mix-up = 混合增强。R@50/100、mR@50/100 和 F@50/100 保留原指标符号。

在表 5 中，我们观察到 FeatAug 和 Mixup 在提升 R@K 的同时导致 mR@K 下降。这一结果偏离了我们生成细粒度场景图的目标。该现象可归因于尾部类别信息被整合到特征中，无意间形成了通向一般谓词的捷径。例如，当模型学习根据检索到的 “walking on”（行走在……上）预测 “on”（在……上）时，它倾向于采用捷径模式（即 “walking on” → “on”），从而提高头部类别的性能。相反，Label Aug 的 mR@K 和 F@K 均大幅提高，表明 RA-SGG 仅增强标签的策略对于改善细粒度谓词预测特别有效。

C 局限性

在本研究中，我们展示了检索增强 SGG 的有效性，它能够发现潜在的细粒度谓词。虽然 RA-SGG 仅限于记忆库由训练实例填充的情形，但我们基于检索的方法可以通过将外部数据集作为额外信息来源而进一步扩展，并有望从中受益。我们将这一方向留作未来探索。