# 自动识别与纠正：噪声场景下的鲁棒深度对比多视图聚类

**非官方中文全文译文 · P065 · AIRMVC**

Xihong Yang[12]、Siwei Wang[3]、Fangdi Wang[1]、Jiaqi Jin[1]、Suyuan Liu[1]、Yue Liu[2]、En Zhu[1]、Xinwang Liu[1]、Yueming Jin[2]

单位：[1]中国湖南长沙，国防科技大学计算机学院；[2]新加坡国立大学，新加坡；[3]中国北京，智能博弈与决策实验室。联系邮箱：xihong_edu@163.com。通讯作者：Xinwang Liu（xinwangliu@nudt.edu.cn）。

原文：Automatically Identify and Rectify: Robust Deep Contrastive Multi-view Clustering in Noisy Scenarios. 第42届国际机器学习大会，温哥华，加拿大。PMLR 267:71383–71404，2025。原作者保留版权。原文链接：https://proceedings.mlr.press/v267/yang25am.html。

本译文依据该页链接的正式出版版本制作，依 PMLR 出版协议第2–3条所述 CC BY 4.0 许可提供。许可：https://creativecommons.org/licenses/by/4.0/。本文件为翻译及重排版本，未获原作者审校或背书。公式、数据表与图形保留原版字形和数值；图内英文及表头在正文给出中文对照。原文的笔误、交叉引用及数据集计数不一致不作静默修正。

## 摘要

近年来，借助强大的表征学习能力，深度多视图聚类方法通过有效整合来自不同视图的多源信息，展现出可靠的性能。现有大多数方法以视图干净为假设。然而，现实场景中噪声普遍存在，导致性能显著下降。为解决这一问题，我们提出一种新颖的多视图聚类框架 AIRMVC，用于自动识别与纠正带噪数据。具体而言，我们利用高斯混合模型（GMM），将噪声识别重新表述为异常识别问题。随后，根据识别结果设计混合纠正策略，减轻带噪数据的不利影响。此外，我们引入噪声鲁棒对比机制，以生成可靠的表征。我们还提供理论证明，说明这些表征能够丢弃噪声信息，从而改善下游任务性能。在六个基准数据集上的大量实验表明，AIRMVC 在噪声场景的鲁棒性方面优于最先进的算法。AIRMVC 代码已在 GitHub 上公开：https://github.com/xihongyang1999/AIRMVC。

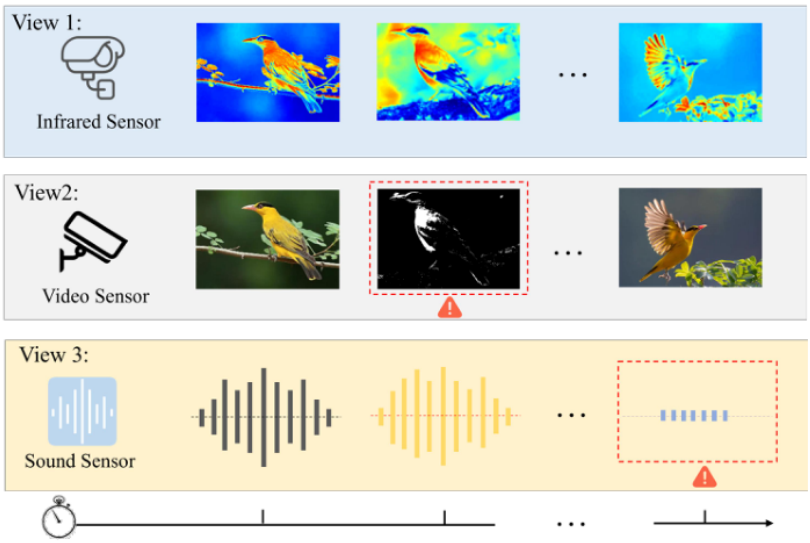



**图1：**多视图场景中的噪声示意图。图中红色感叹号标记的区域表示传感器在特定时刻发生故障或失灵，导致数据损坏。相对于其他视图，这些实例被视为带噪数据。图内：View＝视图；Infrared Sensor＝红外传感器；Video Sensor＝视频传感器；Sound Sensor＝声音传感器。

## 1. 引言

在现实场景中，多源信息数据普遍存在。为有效处理此类数据，多视图聚类（MVC）已成为一种强大的无监督方法。近年来，MVC 获得广泛关注，并成为重要研究热点。现有 MVC 方法大体可分为两类。第一类是传统方法，包括多核聚类（MKC）（Liu et al., 2021）、非负矩阵分解（NMF）（Wen et al., 2018）、子空间聚类（Zhou et al., 2019）以及基于图的聚类（Liu et al., 2022a）。随着深度神经网络的发展，作为第二类 MVC 方法的深度多视图聚类算法（Yang et al., 2023b; Sun et al., 2024）受到研究者的广泛关注。

尽管现有 MVC 算法取得了显著的聚类性能，它们主要依赖于所有视图特征均干净的假设。这些方法通常遵循标准流程：先通过编码器提取表征，再采用特征融合策略，最后用于下游聚类任务。干净视图的整合能够利用同一样本不同视角中的互补信息，从而取得比单视图聚类更好的性能。视图间的互补信息对于揭示数据潜在的簇结构至关重要。如何有效捕获多个视图之间的互补信息？对比学习提供了一种利用自监督技术学习跨视图一致性的范式，确保不同视图之间的预测一致（Lu et al., 2024; Yang et al., 2023b; Xu et al., 2022b）。另一种途径是自训练，通过生成统一的簇划分来探索一致性，进而促进互补信息的发现（Xu et al., 2022a; Wang et al., 2021）。

尽管上述方法取得了良好结果，我们发现，当它们应用于包含噪声数据的现实场景时，存在明显局限。图1给出了多视图场景中带噪数据的例子，其中有三个视图，部分视图包含随机噪声。此外，我们观察到，现有方法在此类噪声条件下性能显著下降（表4）。带噪数据不仅无法在多视图特征融合中作出积极贡献，还会破坏潜在的簇结构。而且，带噪数据的错误影响给优化过程引入较大偏差，削弱视图间互补信息的优势。因此，这些方法的性能甚至可能低于单视图模型。支持这一结论的详细实验证据见第5.3节。近期，一些面向噪声的深度多视图聚类方法被提出，以缓解这一问题。RMCNC（Sun et al.,

2024）设计了容噪对比损失，以减轻带噪对应关系的影响。MVCAN（Xu et al., 2024）采用非共享网络结构，并为多视图聚类设计了两级优化。虽然取得了较大改进，这些方法对噪声数据的探索仍集中于增强特征鲁棒性，尚未建立专门的噪声识别与纠正框架。

为在多视图场景中自动识别和纠正带噪数据，我们提出一种新的深度对比多视图聚类框架 AIRMVC。具体而言，我们将噪声识别重新表述为异常识别问题，并引入高斯混合模型（GMM）加以解决。通过用软预测替代 GMM 的潜变量，我们能够动态更新 GMM 参数。基于识别结果，我们引入混合纠正策略，采用插值机制缓解带噪数据的不利影响，从而增强纠正过程的鲁棒性。这样便可减轻带噪数据的负面影响。此外，通过仔细优化软预测分布，我们设计了噪声鲁棒对比机制，以增强所学表征的判别能力。我们还对该对比机制进行理论研究，验证所学表征的稳定性和鲁棒性。在六个基准数据集上进行的大量实验证明了所提方法的有效性和鲁棒性。本文主要贡献如下：

- 将噪声识别重新表述为异常识别问题，并用 GMM 求解。基于其结果，提出混合纠正策略，自动纠正带噪数据。
- 提出噪声鲁棒对比机制，以生成更加可靠的表征。此外，我们从理论上证明，所生成的表征能够丢弃噪声信息，使下游任务受益。
- 在六个基准数据集上开展大量实验，验证 AIRMVC 的有效性和鲁棒性。

## 2. 预备知识与问题定义

本文关注输入含噪的多视图聚类任务，因为在现实场景的多源信息输入中，噪声是一种常见现象。为应对这一挑战，我们旨在无监督多视图环境中自动识别与纠正带噪数据，从而增强网络鲁棒性。为简便起见，我们给出如下符号定义。给定包含 $V$ 个视图和 $N$ 个样本的数据集 $\{x^v\}_{v=1}^V$，分别用 $\mathbf{E}_i^v$ 和 $y_i^v$ 表示每个样本提取的表征以及类别概率的软预测。编码器和解码器网络分别记为 $\mathcal{F}^v(x^v;\Theta^v)$ 和 $\mathcal{G}^v(\mathbf{E}^v;\Phi^v)$。其他符号汇总于附录表5。

大多数现有多视图聚类（MVC）方法假设输入的多视图数据完整且一致。在这种理想场景下，MVC 的主要学习范式是先为 $V$ 个独立视图学习表征，再应用各种融合策略，有效提取并利用各视图之间的共享信息。尽管这些模型在理想条件下表现良好，当引入低质量的带噪视图时，我们观察到其鲁棒性明显下降，造成显著的性能退化。然而，噪声在现实场景中普遍存在。为进一步说明此问题，我们在 BBCSport 和 WebKB 数据集上开展聚类示例实验，涵盖带噪多视图、干净单视图和干净多视图等不同条件。图3和表4的结果表明，面对带噪数据时，模型性能大幅下降，甚至劣于单视图聚类。因此，在多视图聚类任务中减轻带噪数据的不利影响至关重要。下文详细介绍我们提出的自动噪声识别与纠正策略。

## 3. 方法

为减轻带噪数据的负面影响，我们提出面向带噪视图的鲁棒自动识别与纠正深度对比多视图聚类框架，称为 AIRMVC。整体框架如图2所示。具体而言，我们首先详细描述 AIRMVC 的三个组成部分：噪声识别、混合纠正以及噪声鲁棒对比机制。然后定义优化整个模型的目标函数。最后，对所设计的噪声鲁棒对比组件进行理论分析。

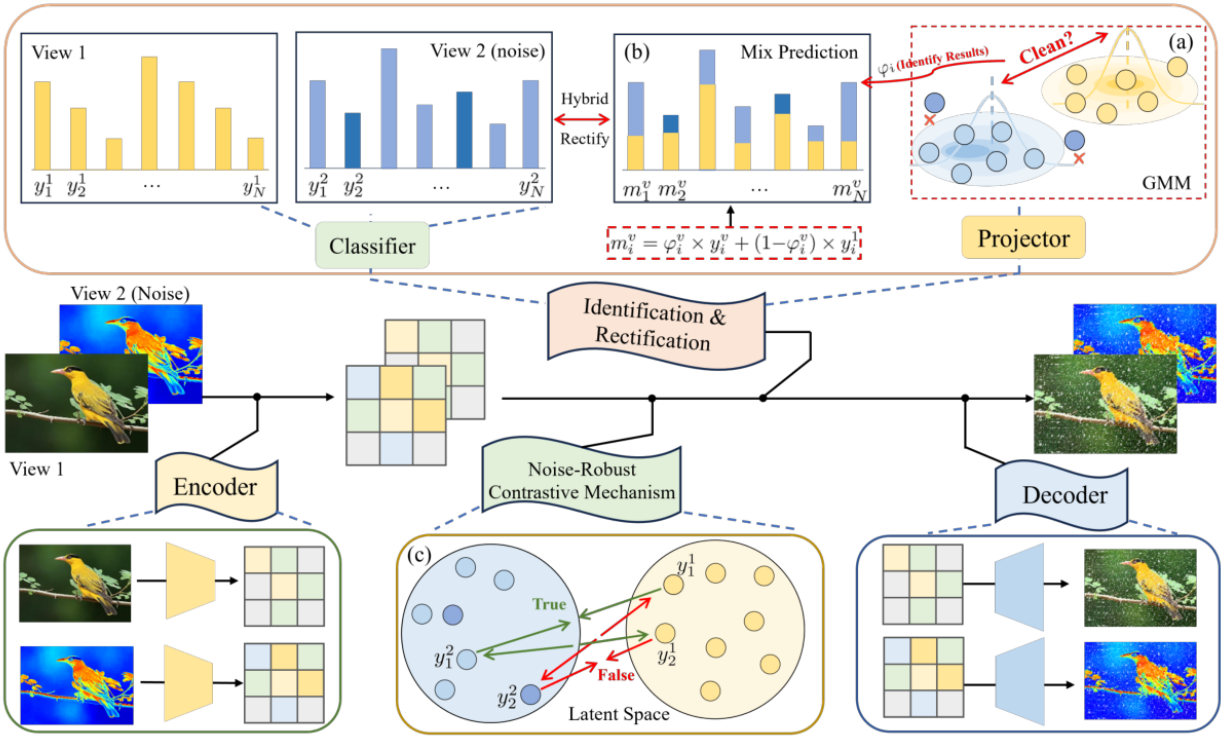



**图2：** 所提 AIRMVC 的整体框架。首先，对输入的多视图数据编码，生成表征。随后，引入自动噪声识别与纠正策略，减轻带噪数据的不利影响。同时，提出噪声鲁棒对比机制，为下游聚类任务生成更加可靠、具有更强判别能力的表征。图内：View＝视图；noisy＝带噪；Mix Prediction＝混合预测；Hybrid Rectify＝混合纠正；Classifier＝分类器；Projector＝投影器；Encoder＝编码器；Decoder＝解码器；Identification & Rectification＝识别与纠正；Noise-Robust Contrastive Mechanism＝噪声鲁棒对比机制；Latent Space＝潜在空间；True/False＝正确/错误；Clean/Noise＝干净/噪声；Identify Results＝识别结果。

### 3.1. 噪声识别

对于给定的多视图数据集 $\{x^v\}_{v=1}^V$，利用编码器网络生成表征，表示为 $\mathbf{E}^v = \mathcal{F}^v(x^v; \Theta^v)$。对于每个表征，首先用多层感知器（MLP）层作为投影器进行处理。然后用高斯混合模型（GMM）对其分布建模。该过程可描述为：

$$
\begin{aligned}
p(\mathbf{E}) &= \sum_{k=1}^{K} p(\mathbf{E}, q=k) \\
&= \sum_{k=1}^{K} p(q=k)\mathcal{N}(\mathbf{E}|\mu_k, \sigma_k),
\end{aligned}
\tag{1}
$$

其中，$q \in \{1, 2, \ldots, K\}$ 表示离散潜变量，$\mu_k$ 和 $\sigma_k$ 分别表示均值和方差。假设 $q$ 服从均匀分布，则 $q=k$ 的概率为 $p(q=k) = 1/K$。在此基础上，将 $x_i$ 分配至第 $k$ 个簇的后验概率可计算为：

$$\chi_{ik} = p(q_i = k|x_i) \propto \mathcal{N}(x_i|\mu_k, \sigma_k). \tag{2}$$

在理想条件下，离散变量 $q$ 可以直接对应标签。整个过程可使用期望最大化（EM）算法优化求解。然而，现实场景中带噪输入普遍且不可避免，会导致优化过程产生偏差。因此，带噪数据的识别与纠正极其重要。在无监督场景中，识别噪声仍是一项挑战。为解决这一问题，我们以无监督方式建立潜变量 $q$ 与模型预测 $y$ 之间的联系。具体而言，用网络软预测 $p(y_i = k \mid x_i)$ 替代分配概率 $p(q_i = k \mid x_i)$。随后，GMM 参数可计算为：

$$\begin{aligned} \mu_k &= \text{Norm}\left(\frac{\sum_i p(y_i = k|x_i)\mathbf{E}_i}{\sum_i p(y_i = k|x_i)}\right), \\ \sigma_k &= \frac{\sum_i p(y_i = k|x_i)(\mathbf{E}_i - \mu_k)(\mathbf{E}_i - \mu_k)^\mathsf{T}}{\sum_i p(y_i = k|x_i)}, \end{aligned} \tag{3}$$

其中 Norm 表示 $\ell_2$ 归一化。基于式（3），通过考虑簇内距离，重新表述式（2）。由于实施了 $\ell_2$ 归一化，有 $(\mathbf{E} - \mu_k)^\mathsf{T}(\mathbf{E} - \mu_k) = 2 - 2\mathbf{E}^\mathsf{T}\mu_k$，式（2）的过程可表示为：

$$\begin{aligned} \chi_{ik} &= p(q_i = k|x_i) \\ &= \frac{\exp\left(-(\mathbf{E}_i - \mu_k)^\mathsf{T}(\mathbf{E}_i - \mu_k)/2\sigma_k\right)}{\sum_k \exp\left(-(\mathbf{E}_i - \mu_k)^\mathsf{T}(\mathbf{E}_i - \mu_k)/2\sigma_k\right)} \\ &= \frac{\exp\left(\mathbf{E}_i^\mathsf{T}\mu_k/\sigma_k\right)}{\sum_k \exp\left(\mathbf{E}_i^\mathsf{T}\mu_k/\sigma_k\right)}. \end{aligned} \tag{4}$$

这样，我们得到样本属于第 $k$ 个簇（$\mu_k$）的软预测。此外，我们以无监督方式将模型预测与表征分布结合，并使用 GMM 更新。通过构造 GMM 对表征及软预测的分布建模，将噪声识别问题转化为异常识别问题。在多视图场景下，如果某样本干净，它在不同视图中的软预测与簇分配就应保持一致。对于给定样本 $x_i$，将其划分为干净（正常数据）或带噪（异常数据）。基于上述分析，给出判断 $x_i$ 包含干净信息的可能性的条件概率：

$$\chi_{y=q|i} = p(y_i = q_i|x_i) = \frac{\exp\left(\mathbf{E}_i^\mathsf{T}\mu_{qi}/\sigma_{qi}\right)}{\sum_k \exp\left(\mathbf{E}_i^\mathsf{T}\mu_k/\sigma_k\right)}. \tag{5}$$

随后引入双分量 GMM，自动识别给定样本的干净概率：

$$p(\chi_{y=q|i}) = \underbrace{p(\chi_{y=q|i}, a=1)}_{\varphi_i} + \underbrace{p(\chi_{y=q|i}, a=0)}_{1-\varphi_i} \quad (6)$$

其中， $a=1$ 表示均值较高的干净样本簇，而 $a=0$ 对应均值较低的簇。因此， $\varphi_i$ 可以解释为样本 $x_i$ 干净的概率， $1-\varphi_i$ 则为其带噪的概率。利用式（6）即可计算判定 $x_i$ 是否干净的后验概率，如图2(a)所示。

### 3.2. 混合纠正策略设计

第3.1节估计了第 $v$ 个视图中每个样本被归为干净的概率 $\varphi_i^v$ 。接下来，我们提出混合纠正策略处理带噪样本，细节见图2(b)。具体而言，组合预测软分布以进行噪声纠正：

$$\begin{aligned} y_i^v &= h(\mathbf{E}_i^v), \\ m_i^v &= \varphi_i^v \times y_i^v + (1-\varphi_i^v) \times y_i^1, v = \{2, \ldots, V\}, \end{aligned} \quad (7)$$

其中， $m_i^v$ 表示混合软预测， $h(\cdot)$ 表示分类头。我们采用带 softmax 函数的多层感知器（MLP）作为 $h(\cdot)$ 的骨干。本文关注无监督聚类任务，获得可靠监督信息尤其困难。遵循先前的噪声鲁棒 MVC 方法（Huang et al., 2020; Yang et al., 2023a; Sun et al., 2024; Yang et al., 2021），假设第一视图为干净视图。因此，在式（6）中，混合软预测主要受干净样本影响。反之，当 $\varphi_i$ 趋于0时，依据第一视图的预测调整混合软预测。[译注：此处“式（6）”为原文引用，混合预测公式实际为式（7）。]

有了混合软预测，可给出以下纠正损失：

$$\mathcal{L}_{rs} = \frac{1}{V-1} \sum_{v=2}^{V} \left( - \sum_{i=1}^{N} \sum_{j=1}^{K} m_{ij}^v \log\left(y_{ij}^v\right) \right), \quad (8)$$

其中 $y^v$ 为第 $v$ 个软预测， $v \in \{2, \ldots, V\}$ 。这样，就可以通过交叉熵损失纠正带噪数据。混合纠正策略更详细的实验分析见第5.3节。

### 3.3. 噪声鲁棒对比机制

对比学习（Yang et al., 2024b）已被证明是一种增强表征鲁棒性的有效技术。本节提出噪声鲁棒对比机制，进一步减轻多视图聚类任务中带噪数据的影响。在无监督多视图噪声场景中，仅根据索引构造正负样本对可能导致错误配对（Sun et al., 2024）。保证样本对构造的可靠性是一项重要挑战。为提高配对准确性，引入软预测作为额外验证标准。与以往方法类似，第一步计算跨视图样本相似度：

$$s(\mathbf{E}_i^m, \mathbf{E}_j^n) = \frac{\text{sim}(\mathbf{E}_i^m, \mathbf{E}_j^n)}{||\mathbf{E}_i^m||_2 ||\mathbf{E}_j^n||_2}, \tag{9}$$

其中 $\text{sim}(\cdot)$ 表示相似度函数，例如余弦相似度。接下来，对第 $m$ 和第 $n$ 个视图中的第 $i$ 和第 $j$ 个样本给出噪声鲁棒对比损失：

$$\begin{aligned} \ell^{mn} = & \mathbb{I}\{(y_i^m)^\top (y_j^n) \geq \tau\} \\ & \left(\log(1 - s(\mathbf{E}_i^m, \mathbf{E}_j^n)) + \log(1 - s(\mathbf{E}_j^m, \mathbf{E}_i^n))\right), \end{aligned} \tag{10}$$

其中 $\tau$ 为置信度阈值，通过选择相似样本控制对比学习样本对的构造。图2(c)中，绿色表示正确构造的样本对，红色表示错误样本对。所提策略显著提高配对准确性，进而增强整个对比学习过程的可靠性。所有跨视图的鲁棒对比损失定义为：

$$\mathcal{L}_{con} = \frac{1}{V(V-1)} \sum_{m=1}^{V} \sum_{n=1}^{V} \ell^{mn}, m \neq n. \tag{11}$$

### 3.4. 目标函数

AIRMVC 主要使用三个目标函数优化：重建损失 $\mathcal{L}_{rec}$、纠正损失 $\mathcal{L}_{rs}$ 和噪声鲁棒对比损失 $\mathcal{L}_{con}$。具体而言， $\mathcal{L}_{rec}$ 表示通过自编码器网络进行重建，在潜在空间学习表征 $\mathbf{E}$。该过程为：

$$\mathcal{L}_{rec} = \sum_{v=1}^{V} \sum_{i=1}^{N} \left\| x_i^v - \mathcal{G}^v(\mathcal{F}^v(x_i^v; \Theta^v); \Phi^v) \right\|_2^2, \tag{12}$$

其中 $\mathcal{G}^v$ 与 $\mathcal{F}^v$ 分别为第 $v$ 个视图的解码器和编码器网络。综上，AIRMVC 的总体目标函数为：

$$\mathcal{L} = \mathcal{L}_{rec} + \alpha \cdot \mathcal{L}_{rs} + \beta \cdot \mathcal{L}_{con}, \tag{13}$$

其中 $\alpha$ 和 $\beta$ 为权衡超参数。通过优化总体目标函数，AIRMVC 能够在无监督多视图聚类任务中自动识别与纠正带噪数据。由于篇幅有限，训练算法列于附录算法1。

## 4. 理论分析

本节从理论角度考察所提噪声鲁棒对比机制的依据。为清楚起见，先给出符号定义。用 $x$ 和 $x^+$ 表示噪声鲁棒对比机制中的输入样本及其正样本， $y$ 和 $y'$ 分别表示干净与带噪软预测。令 $\mathbf{E}^*$ 为最大化 $\mathbf{E}$ 与 $x^+$ 之间互信息得到的表征，即 $\mathbf{E}^* = \text{argmax}_{\mathbf{E}} I(\mathbf{E}, x^+)$。此外，定义 $I(x; y \mid x^+) \leq \vartheta$ 以及 $I(x; y' \mid x^+) > \eta$。对于输入样本 $x$、干净软预测 $y$ 和带噪软预测 $y'$，有以下结果：

**定理4.1**。表征 $\boldsymbol{E}^*$ 保留干净信息并丢弃噪声信息，可表示为：

$$\begin{aligned} I(x;y) - \vartheta \leq I(\boldsymbol{E}^*;y) \leq I(x;y), \\ I(\boldsymbol{E}^*;y') \leq I(x;y') - \eta + \vartheta. \end{aligned} \tag{14}$$

**说明：**对于输入样本 $x$、对应正样本 $x^+$ 及预测 $y_i$， $\vartheta$ 可解释为正样本 $x^+$ 带来的相对较小的信息增益。对于固定的 $x$ 及其正样本 $x^+$，类别预测 $y$ 的信息增益有限。相反， $x^+$ 对带噪预测 $y'$ 带来的信息增益较大，记为 $\eta$。通过计算互信息 $I(x_i; y_i)$，定理14表明，对比机制学习到的表征 $\mathbf{E}^*$ 能够丢弃噪声信息并保留干净信息。证明见第A.2节。[译注：“定理14”为原文措辞，正文定理编号为4.1、相应公式编号为（14）。]

## 5. 实验

本节通过一系列实验评估所提方法的有效性与优势。具体回答以下研究问题（RQ）：**RQ1：**AIRMVC 的性能与其他领先的深度多视图聚类技术相比如何？**RQ2：**AIRMVC 的各组件对提升多视图聚类结果有何影响？**RQ3：**AIRMVC 识别出了怎样的簇结构？**RQ4：**超参数对 AIRMVC 效果有何影响？

**表1：六个基准数据集的统计汇总。**

| 数据集 | 视图数 | 样本数 | 簇数 |
|---|---|---|---|
| BBCSport | 2 | 544 | 5 |
| WebKB | 2 | 1051 | 2 |
| Reuters | 5 | 1200 | 6 |
| UCI-digit | 3 | 2000 | 10 |
| Caltech101 | 5 | 9144 | 102 |
| STL10 | 4 | 13000 | 10 |

## 5.1. 实验设置

**数据集：**为评估 AIRMVC 框架的有效性，我们在六个广泛使用的数据集上开展全面实验：BBCSport、Reuters、Caltech101、UCI-digit、WebKB、SUNRGB-D 和 STL10。表1给出了所有数据集的详细统计信息。为模拟含噪输入环境，以 $\{10\%, 30\%, 50\%, 70\%, 90\%\}$ 的不同比例随机向多视图输入数据 $x$ 中引入噪声。[译注：原文称“六个”，但本句实际列出七个名称；表1列出六个数据集，未列 SUNRGB-D。]

**评估指标：**为全面评价模型聚类性能，采用三种广泛认可的指标：准确率（ACC）、归一化互信息（NMI）和纯度（PUR）。为保证公平比较，所有方法独立运行10次，报告平均结果。

**对比算法：**为展示 AIRMVC 的广泛适用性和优越性能，我们将其与11种最先进的深度多视图聚类方法比较。这些基线分为两类：经典深度多视图聚类方法，包括 CoMVC（Trosten et al., 2021）、SiMVC（Trosten et al., 2021）、MFLVC（Xu et al., 2022b）、DealMVC（Yang et al., 2023b）、SURE（Yang et al., 2023a）、CANDY（Guo et al.）、DIVIDE（Lu et al., 2024）、TGM-MVC（Wang et al., 2024a）以及 SCE-MVC（Wang et al., 2024b）；另一类为抗噪深度多视图聚类方法 RMCNC（Sun et al., 2024）与 MVCAN（Xu et al., 2024）。各基线的详细信息见附录第A.5节。

**实现细节：**所有实验在 PyTorch（Imambi et al., 2021）平台上使用 NVIDIA A6000 GPU 进行。为公平比较，所有基线均使用作者提供的原始代码和配置复现。AIRMVC 使用默认设置的 Adam 优化器（Kingma & Ba, 2014）训练。为增强网络判别力，并在无监督条件下获得可靠软预测，先以自编码器模块预训练模型100轮。权衡超参数 $\alpha$ 与 $\beta$ 均固定为1.0。所有数据集最大训练轮数均设为400。超参数设置详见附录表7。

## 5.2. 对比实验（RQ1）

本节开展全面实验，展示所设计 AIRMVC 的优越性和有效性。具体而言，在不同噪声比例下与11种最先进基线比较。结果见表2、3、6、8、9。最优结果以红色粗体突出，次优结果用蓝色表示。由于篇幅限制，表6、8、9放在附录第A.3节。结果支持以下观察：

**表2：六个基准数据集上的多视图聚类性能（第1/4部分）**。最高指标以红色强调，次优结果以蓝色标注。表头：Noisy Rate＝噪声比例；Metric＝指标；Ours＝本文方法。ACC、NMI、PUR 数值越高越好；下同。

*Table 2.* Multi-view clustering performance on six benchmark datasets (Part 1/4). The highest performance metrics are emphasized in **red**, while the runner-up results are marked in blue.

| | Noisy Rate | | 10% | | | 30% | | | 50% | | | 70% | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | Metric | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| BBCSport | CANDY | NeurIPS 2024 | 23.16 | 05.60 | 40.62 | 19.49 | 03.93 | 38.79 | 17.10 | 03.72 | 38.42 | 16.36 | 02.68 | 36.58 |
| | RMCNC | TKDE 2024 | 35.48 | 15.80 | 35.48 | 30.57 | 12.87 | 30.57 | 28.56 | 10.67 | 28.05 | 24.26 | 04.57 | 24.26 |
| | TGM-MVC | ACM MM 2024 | 37.28 | 08.39 | 40.84 | 36.37 | 06.33 | 38.82 | 30.19 | 05.81 | 30.40 | 25.13 | 04.16 | 25.13 |
| | SCE-MVC | NeurIPS 2024 | 47.06 | 15.96 | 47.98 | 45.40 | 15.67 | 45.96 | 43.57 | 12.72 | 45.22 | 39.73 | 12.95 | 39.46 |
| | MVCAN | CVPR 2024 | 44.85 | 18.99 | 44.85 | 39.15 | 15.81 | 39.15 | 26.65 | 11.85 | 25.97 | 24.26 | 06.57 | 23.76 |
| | DIVIDE | AAAI 2024 | 31.25 | 04.57 | 38.60 | 30.15 | 03.28 | 36.76 | 28.68 | 02.65 | 35.66 | 27.02 | 02.22 | 36.03 |
| | AIRMVC | Ours | **49.45** | **28.63** | **49.44** | **45.59** | **20.11** | **47.24** | **45.04** | **23.34** | **53.13** | **40.99** | **16.52** | **45.59** |
| WebKB | CANDY | NeurIPS 2024 | 19.03 | 12.41 | 19.03 | 18.08 | 10.85 | 18.10 | 16.56 | 07.84 | 16.56 | 15.60 | 04.87 | 15.60 |
| | RMCNC | TKDE 2024 | 78.12 | 10.77 | 78.10 | 66.98 | 08.78 | 66.98 | 60.04 | 06.24 | 60.00 | 52.71 | 04.35 | 52.16 |
| | TGM-MVC | ACM MM 2024 | 76.86 | 13.81 | 76.86 | 71.87 | 11.65 | 71.87 | 62.86 | 08.04 | 62.86 | 55.51 | **06.87** | 55.50 |
| | MVCAN | CVPR 2024 | 77.83 | 12.39 | 78.12 | 67.46 | 06.20 | 67.46 | 64.22 | 05.94 | 64.22 | 55.66 | 05.74 | 55.65 |
| | SCE-MVC | NeurIPS 2024 | 76.78 | 18.78 | 69.65 | 74.12 | 13.22 | 68.19 | 65.75 | 08.17 | 62.18 | 60.08 | 03.52 | 60.77 |
| | DIVIDE | AAAI 2024 | 66.41 | 15.14 | 69.28 | 53.66 | 10.91 | 57.65 | 52.24 | 07.70 | 56.26 | 51.38 | 05.60 | 55.34 |
| | AIRMVC | Ours | **83.73** | **27.15** | **83.73** | **77.93** | **13.48** | **78.12** | **74.98** | **08.42** | **74.98** | **62.89** | 06.69 | **62.32** |
| Reuters | CANDY | NeurIPS 2024 | 24.58 | 08.50 | 33.75 | 22.17 | 08.09 | 33.08 | 20.83 | 05.57 | 29.25 | 18.83 | 04.44 | 26.75 |
| | RMCNC | TKDE 2024 | 39.42 | 24.21 | 41.83 | 35.83 | 16.96 | 37.83 | 30.17 | 10.92 | 31.67 | 26.83 | 09.07 | 28.75 |
| | TGM-MVC | ACM MM 2024 | 31.28 | 09.05 | 31.53 | 30.30 | 08.51 | 30.30 | 26.44 | 06.78 | 27.59 | 23.90 | 04.58 | 25.42 |
| | SCE-MVC | NeurIPS 2024 | 43.25 | 22.89 | 43.23 | 41.25 | 20.00 | 41.92 | 39.92 | **22.42** | 39.09 | 39.33 | 19.87 | 39.08 |
| | MVCAN | CVPR 2024 | 45.25 | 23.50 | 45.50 | 37.67 | 14.53 | 38.75 | 29.67 | 14.04 | 30.25 | 23.25 | 18.47 | 25.08 |
| | DIVIDE | AAAI 2024 | 41.08 | 16.82 | 42.50 | 33.42 | 13.42 | 34.42 | 30.50 | 10.03 | 33.25 | 27.92 | 09.39 | 28.61 |
| | AIRMVC | Ours | **48.25** | **26.34** | **48.25** | **46.67** | **23.54** | **46.67** | **44.83** | 21.72 | **45.58** | **41.75** | **20.91** | **42.33** |

**表3：六个基准数据集上的多视图聚类性能（第2/4部分）**。最高指标以红色强调，次优结果以蓝色标注。

*Table 3.* Multi-view clustering performance on six benchmark datasets (Part 2/4). The highest performance metrics are emphasized in **red**, while the runner-up results are marked in blue.

| | Noisy Rate | | 10% | | | 30% | | | 50% | | | 70% | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | Metric | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| UCI-digit | CANDY | NeurIPS 2024 | 80.90 | 67.70 | 80.90 | 72.30 | 61.19 | 72.30 | 67.10 | 54.94 | 67.10 | 63.10 | 52.50 | 65.20 |
| | RMCNC | TKDE 2024 | 27.40 | 14.74 | 29.50 | 25.20 | 12.17 | 26.80 | 23.65 | 11.22 | 25.30 | 22.20 | 10.10 | 24.05 |
| | TGM-MVC | ACM MM 2024 | 60.23 | 65.08 | 64.89 | 59.52 | 64.03 | 63.60 | 56.31 | 60.23 | 60.25 | 52.01 | 56.88 | 58.28 |
| | SCE-MVC | NeurIPS 2024 | 72.60 | 71.70 | 72.55 | 68.30 | 67.49 | 70.00 | 66.55 | 67.10 | 68.80 | 64.45 | 55.58 | 66.30 |
| | MVCAN | CVPR 2024 | 86.50 | 79.00 | 86.50 | 74.35 | 72.78 | 76.90 | 64.15 | 66.54 | 67.65 | 63.10 | 54.21 | 63.24 |
| | DIVIDE | AAAI 2024 | 88.20 | 80.28 | 88.20 | 76.00 | 71.56 | 78.45 | 71.00 | 62.80 | 74.20 | 66.25 | 54.72 | **68.25** |
| | AIRMVC | Ours | **93.95** | **89.08** | **93.95** | **77.60** | **76.65** | **80.75** | **76.05** | **68.17** | **76.05** | **69.20** | **60.38** | **69.20** |
| Caltech101 | CANDY | NeurIPS 2024 | 16.67 | 16.93 | 19.67 | 15.87 | 16.62 | 19.19 | 10.64 | 10.91 | 10.94 | 10.98 | 15.14 | 17.35 |
| | RMCNC | TKDE 2024 | 08.75 | 16.57 | 08.71 | 07.20 | 16.02 | 07.21 | 06.94 | 12.87 | 06.87 | 06.71 | 11.58 | 06.71 |
| | TGM-MVC | ACM MM 2024 | 12.81 | 31.50 | 28.95 | 10.58 | 26.57 | 26.25 | 07.16 | 21.84 | 19.54 | 06.66 | 20.46 | 18.57 |
| | MVCAN | CVPR 2024 | 20.53 | 35.81 | 24.60 | 14.30 | 26.02 | 14.14 | 10.28 | 23.19 | 10.99 | 10.34 | 20.43 | 10.44 |
| | SCE-MVC | NeurIPS 2024 | 20.33 | 35.28 | 17.62 | 14.25 | 25.74 | 14.01 | 10.78 | 20.51 | 10.44 | 10.77 | 19.46 | 08.54 |
| | DIVIDE | AAAI 2024 | 18.03 | 35.40 | 20.41 | 15.10 | 25.80 | 20.08 | 11.10 | 23.33 | 16.33 | 10.16 | 18.88 | 14.87 |
| | AIRMVC | Ours | **21.45** | **37.16** | **34.69** | **15.89** | **29.39** | **27.60** | **11.80** | **23.66** | **23.33** | **11.89** | **21.14** | **20.14** |
| STL10 | CANDY | NeurIPS 2024 | 27.08 | 21.03 | 27.33 | 20.56 | 19.23 | 20.21 | 18.19 | 18.48 | 18.77 | 17.49 | 16.79 | 17.80 |
| | RMCNC | TKDE 2024 | 16.51 | 03.56 | 16.92 | 15.85 | 02.94 | 16.22 | 14.78 | 02.33 | 15.12 | 14.12 | 01.70 | 14.95 |
| | TGM-MVC | ACM MM 2024 | 27.50 | 19.51 | 28.10 | 21.80 | 21.62 | 21.65 | 20.01 | 20.02 | 20.78 | 19.87 | 14.05 | 19.77 |
| | SCE-MVC | NeurIPS 2024 | 27.58 | 23.97 | 27.05 | 20.77 | 19.34 | 20.92 | 18.45 | 14.51 | 20.10 | 15.85 | 12.60 | 16.93 |
| | MVCAN | CVPR 2024 | 26.64 | 24.05 | 26.57 | 21.62 | 20.17 | 20.52 | 19.36 | 20.01 | 19.09 | 17.25 | 17.96 | 17.37 |
| | DIVIDE | AAAI 2024 | 27.58 | 24.54 | 27.08 | 22.03 | 20.55 | 22.17 | 20.78 | 20.25 | 20.61 | 16.86 | 20.25 | **20.28** |
| | AIRMVC | Ours | **28.81** | **25.04** | **29.01** | **22.46** | **23.64** | **22.46** | **21.95** | **23.09** | **22.02** | **20.14** | **22.66** | 20.14 |

1. AIRMVC 在多数指标和数据集上显著优于最先进基线。具体而言，在噪声为10%的 BBCSport 数据集上，相对于最优多视图聚类算法，AIRMVC 的 ACC、NMI、PUR 分别提高2.39%、9.64%和1.46%。我们认为，这是因为 AIRMVC 能自动识别并纠正带噪数据，从而实现鲁棒学习。
2. 多视图数据含噪时，深度多视图聚类模型的性能往往变得不稳定。随着噪声比例增大，聚类性能呈下降趋势。我们将其归因于带噪数据使潜在簇结构发生扭曲。
3. 与经典深度多视图聚类方法（例如 TGM-MVC，Wang et al., 2024a）相比，AIRMVC 能取得更好性能。这些方法缺乏专门减轻噪声负面影响的策略，因此性能下降。

4. 尽管噪声深度多视图聚类方法（例如 MVCAN，Xu et al., 2024）能够取得良好性能，复杂噪声场景中的噪声影响仍未完全消除。AIRMVC 的噪声识别纠正策略及噪声鲁棒对比机制能够识别、纠正带噪数据，从而实现更好性能。

总之，AIRMVC 能够在不同噪声水平下进行鲁棒训练。上述观察及实验结果进一步验证了 AIRMVC 的有效性与泛化能力。

### 5.3. 消融研究（RQ2）

本节通过实验考察 AIRMVC 各组件的有效性。由于篇幅限制，噪声比例为30%的实验结果见附录第A.3.2节。

**所设计模块的有效性：**开展消融研究，验证噪声识别纠正策略以及噪声鲁棒对比机制。用“(w/o) D&R”“(w/o) Con”和“(w/o) D&R&Con”分别表示移除噪声识别纠正策略、移除噪声鲁棒对比机制，以及同时移除两者。此外，在“(w/o) D&R&Con”中使用自编码器网络作为骨干，提取下游聚类任务所需的表征。我们在六个数据集上使用三项指标进行实验，结果见图4。可以得出：

1. 移除任一组件都会使模型性能下降，说明设计中的每一部分都对总体聚类性能有所贡献。
2. 与移除噪声鲁棒对比机制（“(w/o) Con”）相比，移除噪声识别纠正策略（“(w/o) D&R”）造成更明显的性能下降，突出说明噪声识别纠正策略对模型性能的相对重要性。

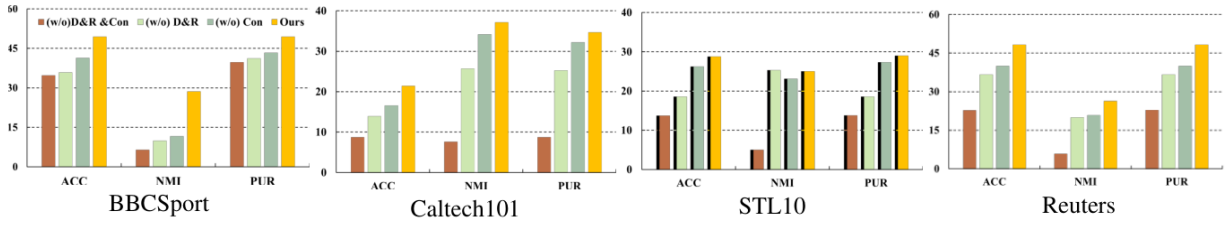


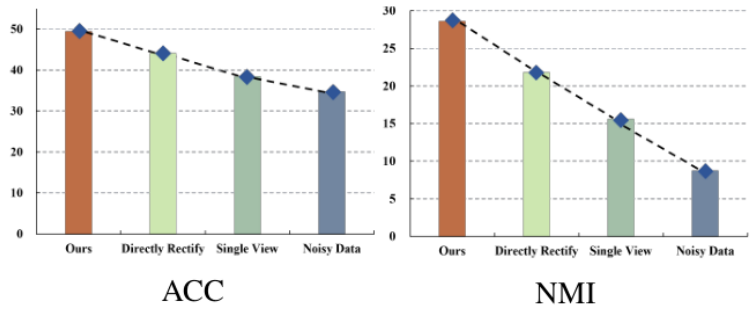

**图4：**在噪声比例为10%的 BBCSport、Caltech101、STL10 和 Reuters 数据集上的消融研究。图例的 w/o 表示不使用对应组件，Ours 表示本文完整方法。

**纠正策略的有效性：**在 AIRMVC 中分两步纠正带噪数据。首先使用双分量 GMM 识别带噪数据，然后根据识别结果纠正。为说明噪声的不利影响，表4给出了 WebKB 数据集上的实验证据，显示噪声场景中性能显著下降，凸显了设计专门噪声识别纠正策略的必要性。为进一步验证该策略的有效性，在10%噪声比例的 BBCSport 数据集上开展实验。为全面评价，定义四种不同实验设置。为简便起见，以“Noisy Data”表示直接融合带噪多视图特征；“Single View”表示单个带噪视图的结果；“Directly Rectify”表示直接以第一视图的交叉熵进行纠正；“Ours”表示所提策略。结果见图3，可得到以下观察：

**表4：**噪声比例为10%时，WebKB 数据集上多视图聚类性能的变化。Methods＝方法；Metrics＝指标；Clean＝干净；Noise＝带噪；向下箭头表示性能下降。

*Table 4.* Performance variation of multi-view clustering on WebKB dataset in noisy scenario with 10% noisy ratio.

| Methods | TGM-MVC | | | SCE-MVC | | |
|---|---|---|---|---|---|---|
| Metrics | ACC | NMI | PUR | ACC | NMI | PUR |
| Clean | 81.45 | 15.70 | 81.45 | 83.43 | 20.64 | 83.43 |
| Noise | 76.86↓ | 13.81↓ | 76.86↓ | 76.78↓ | 18.78↓ | 69.65↓ |



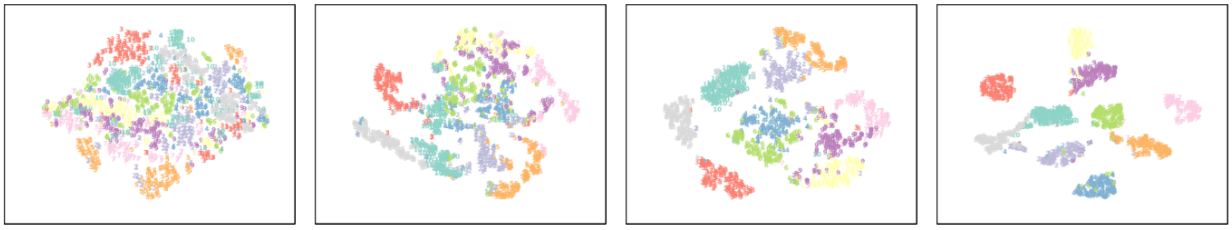

ACC　　NMI

**图3：**BBCSport 数据集上所提噪声识别与纠正策略的消融研究。横轴依次为本文方法、直接纠正、单视图、带噪数据；两幅图分别为 ACC 和 NMI。

1. 直接融合带噪多视图数据的聚类性能最差。原因在于缺乏任何噪声纠正机制，带噪视图会相互放大其不利影响。此外，融合过程进一步加剧噪声影响。不加纠正时，多视图数据的聚类性能甚至劣于单视图。
2. 相比直接利用第一视图纠正，AIRMVC 的性能更好。这可以归因于直接使用第一视图纠正结果倾向于使不同视图的特征同质化。相比之下，所提噪声识别纠正策略能有效过滤每个视图的带噪数据，同时保留有利于下游任务的互补信息。

## 5.4. 可视化分析（RQ3）

为可视化潜在表征空间并评估 AIRMVC 的有效性，实验使用 t-SNE（Van der Maaten & Hinton, 2008）作为可视化工具。具体而言，从 UCI-digit 数据集中提取表征。图5结果表明，随着训练推进，UCI-digit 中的簇结构越来越清晰。到第200轮时，已形成界限清楚且可区分的簇结构。这一观察表明，AIRMVC 能有效揭示特征表征中的潜在簇结构。



20 Epoch　　80 Epoch　　140 Epoch　　200 Epoch

**图5：**UCI-digit 数据集上训练过程中表征的可视化。从左至右为第20、80、140、200轮。

## 5.5. 超参数分析（RQ4）

本节通过实验分析本文超参数的敏感性。

**权衡超参数 $\alpha$ 与 $\beta$ 的敏感性分析：**为进一步考察参数 $\alpha$ 和 $\beta$ 对模型的影响，在六个数据集、10%噪声比例下进行敏感性实验。具体分析的参数取值范围为 $\{0.01, 0.1, 1.0, 10\}$。根据图7，有以下观察：（1）当 $\alpha$ 与 $\beta$ 接近极端取值时，聚类性能明显恶化。这可归因于损失函数平衡被破坏。两者均取1.0时模型取得最优聚类性能，因此设为1.0。（2）相比 $\beta$ 的变化，$\alpha$ 的变化引起更明显的性能变化，表明噪声识别纠正模块对性能提升的贡献更大。

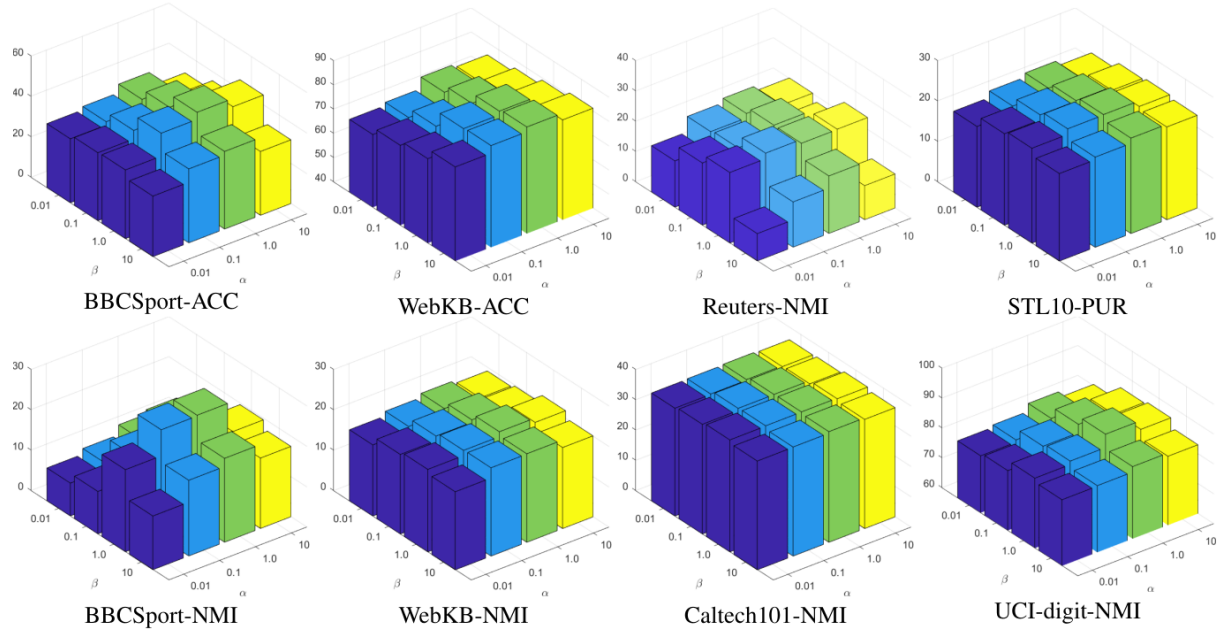



**图7：**在噪声比例为10%的 BBCSport、WebKB、Reuters、UCI-digits、Caltech101 和 STL10 数据集上，以 ACC、NMI、PUR 对 $\alpha$ 与 $\beta$ 进行敏感性分析。各子图数据集及指标名称保留原文。

**阈值 $\tau$ 的敏感性分析：**实验评估阈值参数 $\tau$ 的影响，将其取值在 $\{0.2, 0.4, 0.6, 0.8\}$ 范围内变化。图6展示结果。随着阈值增大，模型聚类性能逐步改善。我们认为，较高阈值减少了对比学习中错误样本对的数量。

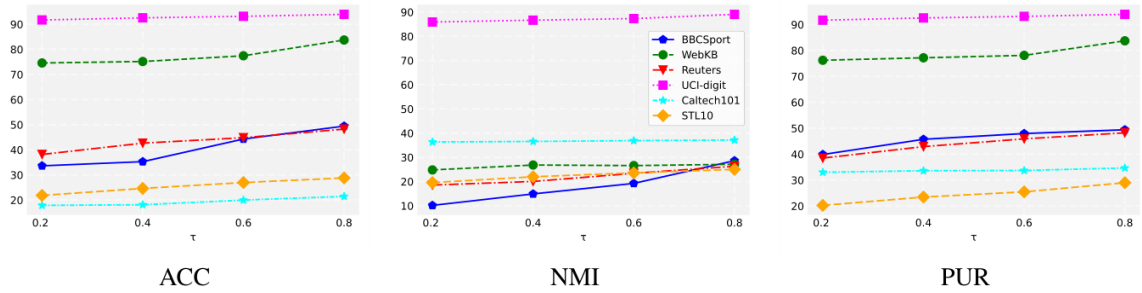



**图6：**六个数据集、10%噪声比例下超参数 $\tau$ 的敏感性分析。三幅子图从左至右为 ACC、NMI、PUR。

## 6. 结论

本文提出新的深度对比多视图聚类网络 AIRMVC，自动识别与纠正带噪数据。在 AIRMVC 中，首先将噪声识别视为异常识别问题。然后根据识别结果引入混合纠正策略，减轻带噪数据的不利影响。之后，设计噪声鲁棒对比机制，获得更具判别力的表征。此外，从理论上证明所学表征能够丢弃噪声信息。在六个基准数据集上进行的全面实验验证了 AIRMVC 的有效性与鲁棒性。

## 致谢

本工作得到科技创新2030重大项目（项目号2022ZD0209103）、国家自然科学基金（项目号62325604、62441618、62476281、U24A20323及62276271）以及国家留学基金项目（编号202406110009）的支持。

## 影响声明

本文所述工作的目标是推动机器学习领域的发展。我们的工作可能产生许多社会影响，但我们认为没有需要在此特别强调的影响。

## 参考文献

为便于检索，完整保留每条参考文献的作者、原文题名、刊物或会议、卷期页码及 DOI；每条首先给出题名的中文翻译。原文未提供的年份或书目信息不作补写。

1. **视觉表征对比学习的简单框架**。 Chen, T., Kornblith, S., Norouzi, M., and Hinton, G. A simple framework for contrastive learning of visual representations. In International conference on machine learning, pp. 1597–1607. PMLR, 2020.

2. **信息论基础**。 Cover, T. M. Elements of information theory. John Wiley & Sons, 1999.

3. **高效且自适应的推荐遗忘：用于擦除过时偏好的引导滤波框架**。 Dang, Y., Liu, Y., Yang, E., Guo, G., Jiang, L., Zhao, J., and Wang, X. Efficient and adaptive recommendation unlearning: A guided filtering framework to erase outdated preferences. ACM Transactions on Information Systems, 43(2):1–25, 2025a.

4. **数据增强作为免费午餐：探索序列推荐的测试时增强**。 Dang, Y., Liu, Y., Yang, E., Huang, M., Guo, G., Zhao, J., and Wang, X. Data augmentation as free lunch: Exploring the test-time augmentation for sequential recommendation. arXiv preprint arXiv:2504.04843, 2025b.

5. **面向多视图原始数据的迭代式深度结构图对比聚类**。 Dong, Z., Jin, J., Xiao, Y., Wang, S., Zhu, X., Liu, X., and Zhu, E. Iterative deep structural graph contrast clustering for multiview raw data. IEEE Transactions on Neural Networks and Learning Systems, pp. 1–13, 2023a. doi: 10.1109/TNNLS.2023.3313692.

6. **面向深度多视图聚类的基于跨视图拓扑的一致与互补信息**。 Dong, Z., Wang, S., Jin, J., Liu, X., and Zhu, E. Cross-view topology based consistent and complementary information for deep multi-view clustering. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 19440–19451, October 2023b.

7. **抵御双重带噪对应关系的鲁棒对比多视图聚类**。 Guo, R., Yang, M., Lin, Y., Peng, X., and Hu, P. Robust contrastive multi-view clustering against dual noisy correspondence. In The Thirty-eighth Annual Conference on Neural Information Processing Systems.

8. **图上的对比多视图表征学习**。 Hassani, K. and Khasahmadi, A. H. Contrastive multi-view representation learning on graphs. In International Conference on Machine Learning, pp. 4116–4126. PMLR, 2020.

9. **无监督视觉表征学习的动量对比**。 He, K., Fan, H., Wu, Y., Xie, S., and Girshick, R. Momentum contrast for unsupervised visual representation learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 9729–9738, 2020.

10. **通过最小化对比散度训练专家乘积模型**。 Hinton, G. E. Training products of experts by minimizing contrastive divergence. Neural computation, 14(8):1771– 1800, 2002.

11. **通过互信息估计与最大化学习深度表征**。 Hjelm, R. D., Fedorov, A., Lavoie-Marchildon, S., Grewal, K., Bachman, P., Trischler, A., and Bengio, Y. Learning deep representations by mutual information estimation and maximization. arXiv preprint arXiv:1808.06670, 2018.

12. **探索节点多样性在有向图表征学习中的作用**。 Huang, J., Mo, Y., Hu, P., Shi, X., Yuan, S., Zhang, Z., and Zhu, X. Exploring the role of node diversity in directed graph representation learning. In Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, pp. 2072–2080, 2024a.

13. **GCN 在哪些节点上失败？从节点视角增强 GCN**。 Huang, J., Shen, J., Shi, X., and Zhu, X. On which nodes does gcn fail? enhancing gcn from the node perspective. In Forty-first International Conference on Machine Learning, 2024b.

14. **部分视图对齐聚类**。 Huang, Z., Hu, P., Zhou, J. T., Lv, J., and Peng, X. Partially view-aligned clustering. Advances in Neural Information Processing Systems, 33:2892–2902, 2020.

15. **通过得分匹配估计非归一化统计模型**。 Hyvärinen, A. and Dayan, P. Estimation of non-normalized statistical models by score matching. Journal of Machine Learning Research, 6(4), 2005.

16. **PyTorch**。 Imambi, S., Prakash, K. B., and Kanagachidambaresan, G. Pytorch. Programming with TensorFlow: solution for edge computing applications, pp. 87–104, 2021.

17. **Adam：一种随机优化方法**。 Kingma, D. P. and Ba, J. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014.

18. **用于不完整多视图聚类的跨视图图匹配引导锚点对齐**。 Li, X., Sun, Y., Sun, Q., Ren, Z., and Sun, Y. Cross-view graph matching guided anchor alignment for incomplete multi-view clustering. Information Fusion, 100:101941, 2023.

19. **通过配对且平衡的动态锚点学习进行不完整多视图聚类**。 Li, X., Pan, Y. P., Sun, Y., Sun, Q., Sun, Y., W. Tsang, I., and Ren, Z. Incomplete multi-view clustering with paired and balanced dynamic anchor learning. IEEE Transactions on Multimedia, pp. 7087–7098, 2025.

20. **多视图聚类的共识图学习**。 Li, Z., Tang, C., Liu, X., Zheng, X., Zhang, W., and Zhu, E. Consensus graph learning for multi-view clustering. IEEE Transactions on Multimedia, 24:2461–2472, 2021.

21. **带共识锚点的高效单遍多视图子空间聚类**。 Liu, S., Wang, S., Zhang, P., Xu, K., Liu, X., Zhang, C., and Gao, F. Efficient one-pass multi-view subspace clustering with consensus anchors. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 36, pp. 7576–7584, 2022a.

22. **单遍后期融合多视图聚类**。 Liu, X., Liu, L., Liao, Q., Wang, S., Zhang, Y., Tu, W., Tang, C., Liu, J., and Zhu, E. One pass late fusion multiview clustering. In International Conference on Machine Learning, pp. 6850–6859. PMLR, 2021.

23. **通过双重相关性削减进行深度图聚类**。 Liu, Y., Tu, W., Zhou, S., Liu, X., Song, L., Yang, X., and Zhu, E. Deep graph clustering via dual correlation reduction. In AAAI Conference on Artificial Intelligence, 2022b.

24. **简单对比图聚类**。 Liu, Y., Yang, X., Zhou, S., Liu, X., Wang, S., Liang, K., Tu, W., and Li, L. Simple contrastive graph clustering. IEEE Transactions on Neural Networks and Learning Systems, 2023.

25. **带高阶随机游走的解耦对比多视图聚类**。 Lu, Y., Lin, Y., Yang, M., Peng, D., Hu, P., and Peng, X. Decoupled contrastive multi-view clustering with high-order random walks. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 14193–14201, 2024.

26. **从谱聚类视角重新审视自监督异构图学习**。 Mo, Y., Lu, Z., Yu, R., Zhu, X., and Wang, X. Revisiting self-supervised heterogeneous graph learning from spectral clustering perspective. In NeurIPS, 2024.

27. **HG-Adapter：利用双适配器改进预训练异构图神经网络**。 Mo, Y., Yu, R., Zhu, X., and Wang, X. Hg-adapter: Improving pre-trained heterogeneous graph neural networks with dual adapters. In ICLR, 2025.

28. **带噪对应关系下的鲁棒多视图聚类**。 Sun, Y., Qin, Y., Li, Y., Peng, D., Peng, X., and Hu, P. Robust multi-view clustering with noisy correspondence. IEEE Transactions on Knowledge and Data Engineering, 2024.

29. **对比多视图编码**。 Tian, Y., Krishnan, D., and Isola, P. Contrastive multiview coding. In Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16, pp. 776–794. Springer, 2020.

30. **重新思考多视图聚类的表征对齐**。 Trosten, D. J., Lokse, S., Jenssen, R., and Kampffmeyer, M. Reconsidering representation alignment for multi-view clustering. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 1255–1265, 2021.

31. **多视图视角下的自监督学习**。 Tsai, Y.-H. H., Wu, Y., Salakhutdinov, R., and Morency, L.-P. Self-supervised learning from a multi-view perspective. arXiv preprint arXiv:2006.05576, 2020.

32. **利用对比预测编码进行表征学习**。 Van den Oord, A., Li, Y., Vinyals, O., et al. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748, 2(3):4, 2018.

33. **利用 t-SNE 可视化数据**。 Van der Maaten, L. and Hinton, G. Visualizing data using t-sne. Journal of machine learning research, 9(11), 2008.

34. **持续多视图聚类**。 Wan, X., Liu, J., Liang, W., Liu, X., Wen, Y., and Zhu, E. Continual multi-view clustering. In Proceedings of the 30th ACM International Conference on Multimedia, pp. 3676–3684, 2022.

35. **视图不完整时的快速持续多视图聚类**。 Wan, X., Xiao, B., Liu, X., Liu, J., Liang, W., and Zhu, E. Fast continual multi-view clustering with incomplete views. IEEE Transactions on Image Processing, 33:2995– 3008, 2024. doi: 10.1109/TIP.2024.3388974.

36. **视图差距很重要：多视图聚类的跨视图拓扑与信息解耦**。 Wang, F., Jin, J., Dong, Z., Yang, X., Feng, Y., Liu, X., Zhu, X., Wang, S., Liu, T., and Zhu, E. View gap matters: Cross-view topology and information decoupling for multi-view clustering. In Proceedings of the 32nd ACM International Conference on Multimedia, pp. 8431–8440, 2024a.

37. **先评价后协作：基于 Shapley 的多视图聚类视图协作增强**。 Wang, F., Jin, J., Hu, J., Liu, S., Yang, X., Wang, S., Liu, X., and Zhu, E. Evaluate then cooperate: Shapley-based view cooperation enhancement for multi-view clustering. In The Thirty-eighth Annual Conference on Neural Information Processing Systems, 2024b.

38. **具有自适应融合与循环一致性的生成式部分多视图聚类**。 Wang, Q., Ding, Z., Tao, Z., Gao, Q., and Fu, Y. Generative partial multi-view clustering with adaptive fusion and cycle consistency. IEEE Transactions on Image Processing, 30:1771–1783, 2021.

39. **通过图正则化矩阵分解进行不完整多视图聚类**。 Wen, J., Zhang, Z., Xu, Y., and Zhong, Z. Incomplete multiview clustering via graph regularized matrix factorization. In Proceedings of the European conference on computer vision (ECCV) workshops, pp. 0–0, 2018.

40. **深度多视图聚类的自监督判别特征学习**。 Xu, J., Ren, Y., Tang, H., Yang, Z., Pan, L., Yang, Y., Pu, X., Philip, S. Y., and He, L. Self-supervised discriminative feature learning for deep multi-view clustering. IEEE Transactions on Knowledge and Data Engineering, 35 (7):7470–7482, 2022a.

41. **对比多视图聚类的多层次特征学习**。 Xu, J., Tang, H., Ren, Y., Peng, L., Zhu, X., and He, L. Multi-level feature learning for contrastive multi-view clustering. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 16051– 16060, 2022b.

42. **研究并减轻实际多视图场景中带噪视图对自监督聚类算法的副作用**。 Xu, J., Ren, Y., Wang, X., Feng, L., Zhang, Z., Niu, G., and Zhu, X. Investigating and mitigating the side effects of noisy views for self-supervised clustering algorithms in practical multi-view scenarios. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 22957–22966, 2024.

43. **带噪声鲁棒对比损失的部分视图对齐表征学习**。 Yang, M., Li, Y., Huang, Z., Liu, Z., Hu, P., and Peng, X. Partially view-aligned representation learning with noise-robust contrastive loss. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 1134–1143, 2021.

44. **信息不完整时的鲁棒多视图聚类**。 Yang, M., Li, Y., Hu, P., Bai, J., Lv, J., and Peng, X. Robust multi-view clustering with incomplete information. IEEE transactions on pattern analysis and machine intelligence, 45(1):1055–1069, 2023a.

45. **面向少标签半监督学习的基于插值的对比学习**。 Yang, X., Hu, X., Zhou, S., Liu, X., and Zhu, E. Interpolation-based contrastive learning for few-label semi-supervised learning. IEEE Transactions on Neural Networks and Learning Systems, pp. 1–12, 2022. doi: 10.1109/TNNLS.2022.3186512.

46. **DealMVC：多视图聚类的双重对比校准**。 Yang, X., Jin, J., Wang, S., Liang, K., Liu, Y., Wen, Y., Liu, S., Zhou, S., Liu, X., and Zhu, E. Dealmvc: Dual contrastive calibration for multi-view clustering. In Proceedings of the 31th ACM International Conference on Multimedia, 2023b.

47. **簇引导的对比图聚类网络**。 Yang, X., Liu, Y., Zhou, S., Wang, S., Tu, W., Zheng, Q., Liu, X., Fang, L., and Zhu, E. Cluster-guided contrastive graph clustering network. In Proceedings of the AAAI conference on artificial intelligence, volume 37, pp. 10834–10842, 2023c.

48. **CONVERT：具有可靠增强的对比图聚类**。 Yang, X., Tan, C., Liu, Y., Liang, K., Wang, S., Zhou, S., Xia, J., Li, S. Z., Liu, X., and Zhu, E. Convert: Contrastive graph clustering with reliable augmentation. In Proceedings of the 31st ACM International Conference on Multimedia, pp. 319–327, 2023d.

49. **跨领域推荐的双曲对比学习**。 Yang, X., Chang, H., Lai, Z., Yang, J., Li, X., Lu, Y., Wang, S., Yin, D., and Min, E. Hyperbolic contrastive learning for cross-domain recommendation. In Proceedings of the 33rd ACM International Conference on Information and Knowledge Management, pp. 2920–2929, 2024a.

50. **GraphLearner：具有完全可学习增强的图节点聚类**。 Yang, X., Min, E., Liang, K., Liu, Y., Wang, S., Zhou, S., Wu, H., Liu, X., and Zhu, E. Graphlearner: Graph node clustering with fully learnable augmentation. In Proceedings of the 32nd ACM International Conference on Multimedia, pp. 5517–5526, 2024b.

51. **用于半监督节点分类的混合图对比网络**。 Yang, X., Wang, Y., Liu, Y., Wen, Y., Meng, L., Zhou, S., Liu, X., and Zhu, E. Mixed graph contrastive network for semi-supervised node classification. ACM Transactions on Knowledge Discovery from Data, 2024c.

52. **DARec：面向大语言模型与推荐系统的解耦对齐框架**。 Yang, X., Jing, H., Zhang, Z., Wang, J., Niu, H., Wang, S., Lu, Y., Wang, J., Yin, D., Liu, X., Zhu, E., Lian, D., and Min, E. Darec: A disentangled alignment framework for large language model and recommender system. In 2025 IEEE 41rd International Conference on Data Engineering (ICDE). IEEE, 2025a.

53. **分布外推荐系统的双重测试时训练**。 Yang, X., Wang, Y., Chen, J., Fan, W., Zhao, X., Zhu, E., Liu, X., and Lian, D. Dual test-time training for out-of-distribution recommender system. IEEE Transactions on Knowledge and Data Engineering, 37(6):3312–3326, 2025b. doi: 10.1109/TKDE.2025.3548160.

54. **APGL4SR：在序列推荐中利用自适应、个性化全局协同信息的通用框架**。 Yin, M., Wang, H., Xu, X., Wu, L., Zhao, S., Guo, W., Liu, Y., Tang, R., Lian, D., and Chen, E. Apgl4sr: A generic framework with adaptive and personalized global collaborative information in sequential recommendation. In Proceedings of the 32nd ACM international conference on information and knowledge management, pp. 3009– 3019, 2023.

55. **序列推荐的数据集再生成**。 Yin, M., Wang, H., Guo, W., Liu, Y., Zhang, S., Zhao, S., Lian, D., and Chen, E. Dataset regeneration for sequential recommendation. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 3954–3965, 2024.

56. **GZOO：通过零阶优化对图神经网络进行黑盒节点注入攻击**。 Yu, H., Liang, K., Hu, D., Tu, W., Ma, C., Zhou, S., and Liu, X. Gzoo: Black-box node injection attack on graph neural networks via zeroth-order optimization. IEEE Transactions on Knowledge and Data Engineering, 2024a.

57. **DShield：通过差异学习防御图神经网络后门攻击**。 Yu, H., Ma, C., Wan, X., Wang, J., Xiang, T., Shen, M., and Liu, X. Dshield: Defending against backdoor attacks on graph neural networks via discrepancy learning. Network and Distributed System Security Symposium, NDSS, 2025.

58. **具有共识锚点与统一二部图的稀疏低秩多视图子空间聚类**。 Yu, S., Liu, S., Wang, S., et al. Sparse low-rank multi-view subspace clustering with consensus anchors and unified bipartite graph. IEEE Transactions on Neural Networks and Learning Systems, 2023a.

59. **如何为不完整多视图聚类构造对应锚点**。 Yu, S., Wang, S., et al. How to construct corresponding anchors for incomplete multiview clustering. IEEE Transactions on Circuits and Systems for Video Technology, 34 (4):2845–2860, 2023b.

60. **面向资源友好、可扩展且稳定的不完整多视图聚类**。 Yu, S., Dong, Z., Wang, S., et al. Towards resource-friendly, extensible and stable incomplete multi-view clustering. In International Conference on Machine Learning, pp. 57415–57440. PMLR, 2024b.

61. **通过用户兴趣对齐进行跨领域推荐**。 Zhao, C., Zhao, H., He, M., Zhang, J., and Fan, J. Cross-domain recommendation via user interest alignment. In Proceedings of the ACM Web Conference 2023, pp. 887– 896, 2023a.

62. **通过渐进结构对齐进行跨领域推荐**。 Zhao, C., Zhao, H., Li, X., He, M., Wang, J., and Fan, J. Cross-domain recommendation via progressive structural alignment. IEEE Transactions on Knowledge and Data Engineering, 2023b.

63. **用于探索多样与一致信息的非对称双翼多视图聚类网络**。 Zheng, Q., Yang, X., Wang, S., An, X., and Liu, Q. Asymmetric double-winged multi-view clustering network for exploring diverse and consistent information. Neural Networks, 179:106563, 2024.

64. **带邻域核子空间分割的多核聚类**。 Zhou, S., Liu, X., Li, M., Zhu, E., Liu, L., Zhang, C., and Yin, J. Multiple kernel clustering with neighbor-kernel subspace segmentation. IEEE transactions on neural networks and learning systems, 31(4):1351–1362, 2019.

# A. 附录

## A.1. 符号与相关工作

### A.1.1. 符号

本小节在表 5 中给出所用符号。

**表 5. AIRMVC 中的符号汇总。**

| 符号 | 含义 |
|---|---|
| $V$ | 视图数量 |
| $N$ | 每个视图中的样本数量 |
| $K$ | 类别数量 |
| $x^v$ | 多视图数据中第 v 个视图的输入数据 |
| $\mathbf{E}$ | 提取的表示 |
| $y$ | 类别概率的软预测 |
| $y'$ | 含噪的类别概率软预测 |
| $\mathcal{F}^v$ | 编码器网络 |
| $\mathcal{G}^v$ | 解码器网络 |
| $\Theta^v$ | 编码器网络的参数 |
| $\Phi^v$ | 解码器网络的参数 |
| $m$ | 混合后的类别概率软预测 |
| $h(\cdot)$ | 分类头 |
| $\varphi$ | 干净概率 |
| $s(;)$ | 相似度函数 |
| $\alpha,\ \beta$ | 权衡超参数 |
| $\mathcal{L}_{rs}$ | 纠正损失 |
| $\mathcal{L}_{con}$ | 对比损失 |
| $\mathcal{L}_{rec}$ | 重构损失 |

### A.1.2. 相关工作

**对比学习：** 对比学习（Yang et al., 2022）因其提取稳健内在监督信号的能力而受到认可，并在各个领域引起广泛关注，例如推荐系统（Yang et al., 2025a;b; Zhao et al., 2023a;b; Dang et al., 2025b;a; Yin et al., 2023; 2024; Yang et al., 2024a）和图学习（Liu et al., 2022b; 2023; Yang et al., 2023c; 2024c; 2023d; Yu et al., 2025; 2024a; Mo et al., 2025; 2024; Huang et al., 2024b;a）。对比学习的核心思想是在潜在空间中最大化正样本之间的相似度，同时最小化负样本之间的相似度。噪声对比估计（NCE）（Hinton, 2002; Hyvärinen & Dayan, 2005）首先被提出，随后出现了 InfoNCE（Van den Oord et al., 2018），其目标是在其他样本存在的情况下区分一个样本的不同视图。此后，MoCo（He et al., 2020）和 SimCLR（Chen et al., 2020）等方法通过拉近正样本对、推远负样本对，推动了图像特定特征的学习。在多视图聚类领域，也已提出若干对比学习方法（Tian et al., 2020; Hassani

& Khasahmadi, 2020; Xu et al., 2022b）。例如，CMC（Tian et al., 2020）提出了对比多视图编码框架，以提取有意义的语义信息。MVGRL（Hassani & Khasahmadi, 2020）利用图扩散矩阵生成增强图，并进一步利用这些图为下游任务建立多视图对比机制。

近期，MFLVC（Xu et al., 2022b）在对比学习框架中利用高层特征和伪标签，提出了两个多视图聚类目标。DealMVC（Yang et al., 2023b）提出了一种专门针对深度多视图聚类的双重校准机制，其校准对比损失能够有效区分多个视图中相似但不同的样本。为进一步提高对比学习样本对的质量，DIVIDE（Lu et al., 2024）采用随机游走方法迭代识别可靠数据对，从而提高多视图聚类中对比学习的稳定性与鲁棒性。CANDY（Guo et al.）利用视图间相似度作为上下文线索来发现假负样本，同时集成基于谱的去噪模块，以改进多视图场景中的对应关系。对比学习作为提高特征质量的有力方法，已在 MVC 领域证明了其高度有效性。在本研究中，我们提出一种噪声鲁棒的对比学习机制，以提高模型在含噪环境中的性能和鲁棒性。

**多视图学习：** 近年来，多视图聚类（MVC）（Wan et al., 2022; 2024; Dong et al., 2023b;a; Yu et al., 2023a; 2024b; 2023b; Li et al., 2025; 2023; Zheng et al., 2024）引起了研究者的广泛兴趣。现有 MVC 方法通常可以依据跨视图对应关系分为两类：完全对齐数据上的 MVC 和部分对齐数据上的 MVC。完全对齐数据假定每一对跨视图样本之间都具有预先定义的映射关系。在这一假设下发展出了多种方法，大致可以分为五个主要类别：（1）基于非负矩阵分解的方法（Wen et al., 2018），旨在发现共享潜在因子，以整合多个视图的信息；（2）基于核学习的方法（Liu et al., 2021），为每个视图分配一组预定义的基核，并对核权重进行最优融合以提高聚类性能；（3）基于子空间的方法（Liu et al., 2022a），假设所有视图共享一个公共低维潜在空间，并通过学习该共享表示得到聚类结果；（4）基于图的方法（Li et al., 2021），由多视图数据构建统一图，并利用谱分解获得聚类结果；（5）基于深度学习的方法（Yang et al., 2023b），利用深度神经网络强大的表示能力，为聚类捕获更复杂、更稳健的特征。

尽管这些方法展现了较强的聚类性能，但通常假设所有视图的特征都不含噪声。然而，在真实场景中，噪声往往存在，并可能显著降低这些方法的有效性。为应对含噪数据的挑战，MVCAN（Xu et al., 2024）采用非共享网络结构，并引入两级优化策略，以增强含噪环境中的鲁棒性。类似地，RMCNC（Sun et al., 2024）引入一种容噪对比损失，以抵消多视图数据中噪声的影响。尽管取得了这些进展，现有方法仍然缺乏显式检测和纠正噪声的专门策略。

为弥补这一不足，本文提出一种旨在自动识别并纠正噪声的新型多视图聚类框架。该框架致力于提高面对真实世界含噪数据时的聚类性能和鲁棒性。

## A.2. 定理 14 的证明

本小节给出定理 14 的详细证明。

**定理 A.1.** 表示 $\mathbf{E}^*$ 保留干净信息并舍弃噪声信息，可表示为：

$$I(x;y) - \vartheta \leq I(\boldsymbol{E}^*;y) \leq I(x;y),$$
$$I(\boldsymbol{E}^*;y') \leq I(x;y') - \eta + \vartheta.$$

**证明**。 为证明定理 14，我们首先给出以下定义。

**定义 A.2（互信息）**。 多视图场景下表示与输入数据之间的互信息可以表示为：

$$I(\mathbf{E};x^+)=\int\int p(\mathbf{E},x^+)\log\frac{p(\mathbf{E}|x^+)}{p(\mathbf{E})}dx^+d\mathbf{E} \tag{15}$$

其中， $x^+$ 是 $x$ 的正样本。 $\mathbf{E}$ 是编码器网络在潜在空间中提取的表示。

**定义 A.3（互信息与表示的关系）**。 通过最小化式（10）学得的表示 $\mathbf{E}$ 会最大化互信息，即 $I\left(\mathbf{E};\,x^+\right)$。

具体而言，式（10）最大化正样本的相似度，同时最小化负样本的相似度。由于 $x^+$ 与 $x$ 相似，在给定 $x^+$ 的条件下，对 $\mathbf{E}$ 的估计更加准确。因此，通过最小化式（10），互信息 $\log\left[p\left(\mathbf{E}\mid x^+\right)/p\left(\mathbf{E}\right)\right]$ 将增大。类似定义已在许多其他领域被广泛采用（Tsai et al., 2020; Hjelm et al., 2018）。根据定义 A.3，我们定义 $\mathbf{E}^*=\text{argmax}_{\mathbf{E}}I\left(\mathbf{E};\,x^+\right)$，用以表示通过最小化对比损失（即最大化互信息）所得到的表示。

**定义 A.4（互信息约束）**。 对于输入数据 $x$、正样本 $x^+$、干净预测 $y$ 和含噪预测 $y'$，若存在 $I\left(x;\,y\mid x^+\right)\leq\vartheta$ 且 $I\left(x;\,y'\mid x^+\right)>\eta$，则定义上述互信息约束。

具体而言，对于固定的 $x$ 及其正样本 $x^+$，类别预测 $y$ 的信息增益是有限的。 $\vartheta$ 可以解释为正样本 $x^+$ 所贡献的一个较小的信息增益值。相比之下， $x^+$ 对含噪预测 $y'$ 贡献了更大的信息增益，我们将其记为 $\eta$。

基于上述定义，我们给出详细证明。与 Tsai et al.（2020）类似，第一步是证明第一个不等式。在马尔可夫链 $y\leftrightarrow x\rightarrow\mathbf{E}$ 中应用数据处理不等式（Cover, 1999），对于任意 $\mathbf{E}$，我们有：

$$I(x;y)\leq I(\mathbf{E};y) \tag{16}$$

因此，得到 $I\left(x;\,y\right)\leq I\left(\mathbf{E}^*;\,y\right)$。此外，学得的表示 $\mathbf{E}^*$ 最大化 $I\left(\mathbf{E};\,x^+\right)$，而 $I\left(\mathbf{E}^*;\,x^+\right)$ 在 $I\left(x;\,x^+\right)$ 处取得最大值，因此可以得到：

$$\begin{aligned}I(\mathbf{E}^*;x^+)&=I(x;x^+),\\I(\mathbf{E}^*;x^*|y)&=I(x;x^+|y)\end{aligned} \tag{17}$$

于是，对于分布 $\left(\mathbf{E}^*,\,x^+,\,y\right)$，有 $I\left(\mathbf{E}^*;\,x^+;\,y\right)=I\left(\mathbf{E}^*;\,x^+\right)-I\left(\mathbf{E}^*;\,x^+\mid y\right)$。代入后可得：

$$\begin{aligned}I(\mathbf{E}^*;x^+;y)&=I(x;x^+)-I(x;x^+|y)\\&=I(x;x^+;y)\end{aligned} \tag{18}$$

随后，我们有：

$$\begin{aligned}I(\mathbf{E}^*;y)&=I(x;x^+;y)+I(\mathbf{E}^*;y|x^+)\\&=I(x;y)-I(x;y|x^+)+I(\mathbf{E}^*;y|x^+)\end{aligned} \tag{19}$$

因此，我们有：

$$
\begin{aligned}
&I(\mathbf{E}^*; y) \leq I(x; y), \\
&I(\mathbf{E}^*; y) \geq I(x; y) - I(x; y|x^+) \geq I(x; y) - \vartheta
\end{aligned}
\tag{20}
$$

对于第二个不等式，展开 $I\left(\mathbf{E}^*,\ y'\right)$ 后可以得到以下公式：

$$
I(\mathbf{E}^*; y') = I(x; y') - I(x; y'|x^+) + I(\mathbf{E}^*; y'|x^+) \tag{21}
$$

此外，根据定义 A.4 中的 $\eta$ 以及马尔可夫链 $y' \leftarrow y \leftrightarrow x \rightarrow \mathbf{E}$，我们有：

$$
\begin{aligned}
I(\mathbf{E}^*; y') &\leq I(x; y') - \eta + I(\mathbf{E}^*; y'|x^+) \\
&\quad I(x; y') - \eta + I(\mathbf{E}^*; y|x^+) \\
&\quad I(x; y') - \eta + \vartheta
\end{aligned}
\tag{22}
$$

至此，证明完成。

> 译注：以上公式均按正式论文原样保留。原文式（16）的不等号方向与后文式（20）不一致；式（17）第二行使用 $x^*$；式（22）后两行未印出关系符号。此处不擅自修订。

## A.3. 补充实验结果

本节补充开展了比较实验、敏感性分析和可视化分析等实验，这些实验因原论文篇幅限制未能在正文中展开。

### A.3.1. 比较实验

我们与五种深度多视图聚类方法进行实验比较，即 SiMVC（Trosten et al., 2021）、CoMVC（Trosten et al., 2021）、MFLVC（Xu et al., 2022b）、DealMVC（Yang et al., 2023b）和 SURE（Yang et al., 2023a）。结果见表 6、8、9。特别地，表 9 给出了噪声比例为 90% 时的实验结果。从这些实验结果中，我们可以得到以下观察。

- AIRMVC 在多种指标和数据集上始终优于最先进的基线。具体而言，在噪声比例为 10% 的 BBCSport 数据集上，与最佳多视图聚类算法相比，AIRMVC 的 ACC、NMI 和 PUR 分别显著提高了 2.58%、9.94% 和 2.56%。这一提升可归因于 AIRMVC 自动识别并纠正含噪数据的能力，该能力保证了更稳健的学习过程。
- 多视图数据中噪声的存在往往会使深度多视图聚类模型的性能不稳定。随着噪声比例上升，聚类性能下降。这种下降可以用含噪数据对底层聚类结构的扭曲来解释。

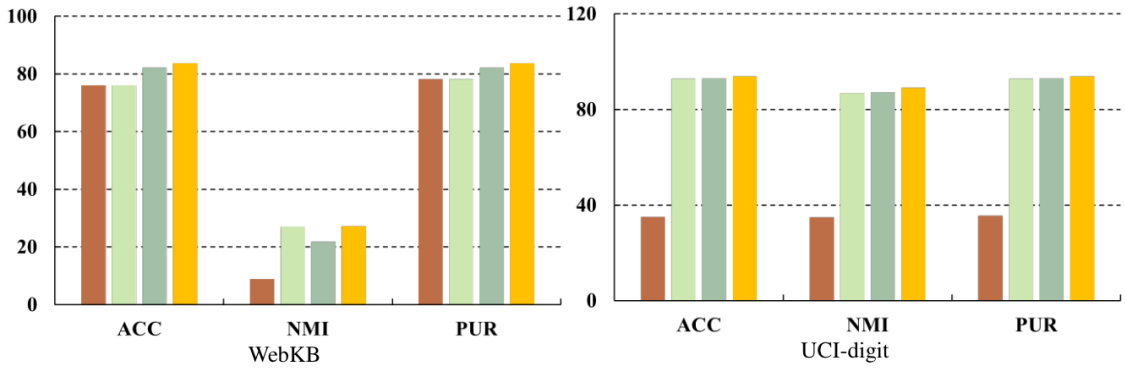



**图 8.** 在噪声比例为 10% 的 UCI-digit 和 WebKB 数据集上开展的消融研究。图中 ACC、NMI、PUR 分别表示准确率、归一化互信息和纯度；AIRMVC 为完整模型；w/o 表示移除相应模块。

### A.3.2. 消融研究

本小节通过实验评估 AIRMVC 内部各组成部分的有效性。由于篇幅限制，我们给出噪声比例为 30% 时的实验结果。

我们开展消融研究，以验证所设计组成部分的贡献，包括噪声识别与纠正策略，以及噪声鲁棒对比机制。具体而言，消融模型采用以下记号：“(w/o) D&R” 表示移除噪声识别与纠正策略，“(w/o) Con” 表示移除噪声鲁棒对比机制，“(w/o) D&R&Con” 表示同时移除这两个模块。此外，在 “(w/o) D&R&Con” 中，使用自编码器网络作为骨干，为下游聚类任务提取表示。我们在六个数据集上采用三项指标进行实验，结果如图 9 所示。根据这些结果，我们得到以下观察：

- 从所提出的模型中移除任何一个组成部分都会导致明显的性能下降，说明每个模块都对整体聚类效果有所贡献。
- 移除噪声识别与纠正策略（“(w/o) D&R”）造成的性能下降大于移除噪声鲁棒对比机制（“(w/o) Con”）造成的下降，凸显了噪声识别与纠正对于保持稳健聚类性能的关键重要性。

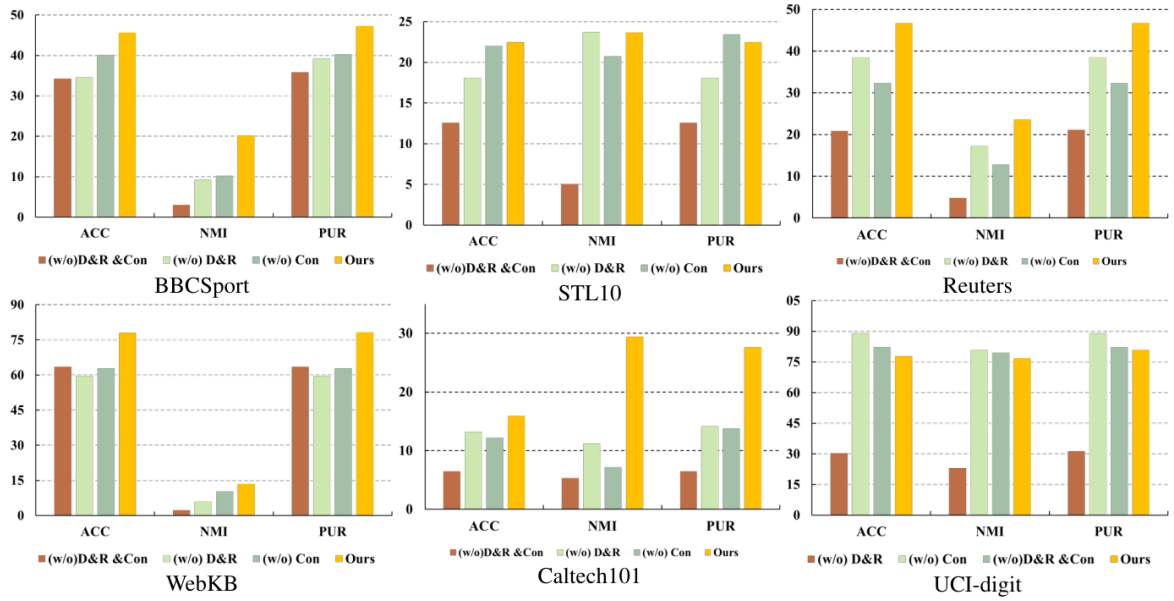



**图 9.** 在噪声比例为 30% 的 BBCSport、Caltech101、STL10、UCI-digit、WebKB 和 Reuters 数据集上开展的消融研究。图例中 Ours 表示本文方法；(w/o) D&R、(w/o) Con 和 (w/o) D&R&Con 分别表示移除噪声识别与纠正策略、移除噪声鲁棒对比机制，以及同时移除两个模块。

### A.3.3. 详细的超参数分析

本小节通过详细实验分析本文超参数 $\alpha$ 和 $\beta$ 的敏感性。

**权衡超参数 $\alpha$ 和 $\beta$ 的敏感性分析：**

为进一步考察参数 $\alpha$ 和 $\beta$ 对模型的影响，我们在六个噪声比例为 10% 的数据集上进行了敏感性实验。具体而言，我们分析了 {0.01, 0.1, 1.0, 10} 范围内的参数取值。根据图 10 中的结果，可得到以下观察。

- 当 $\alpha$ 和 $\beta$ 接近极端值（例如 0.01）时，模型的聚类性能显著下降。这一下降可归因于损失函数平衡被破坏。此外，可以观察到，当 $\alpha$ 和 $\beta$ 均设为 1.0 时，模型取得最优聚类性能。因此，我们在实验中将平衡参数设为 1.0。
- 与 $\beta$ 的变化相比，$\alpha$ 的变化使模型性能发生更明显的变化。这表明，噪声识别与纠正模块对提升模型性能的贡献更大。

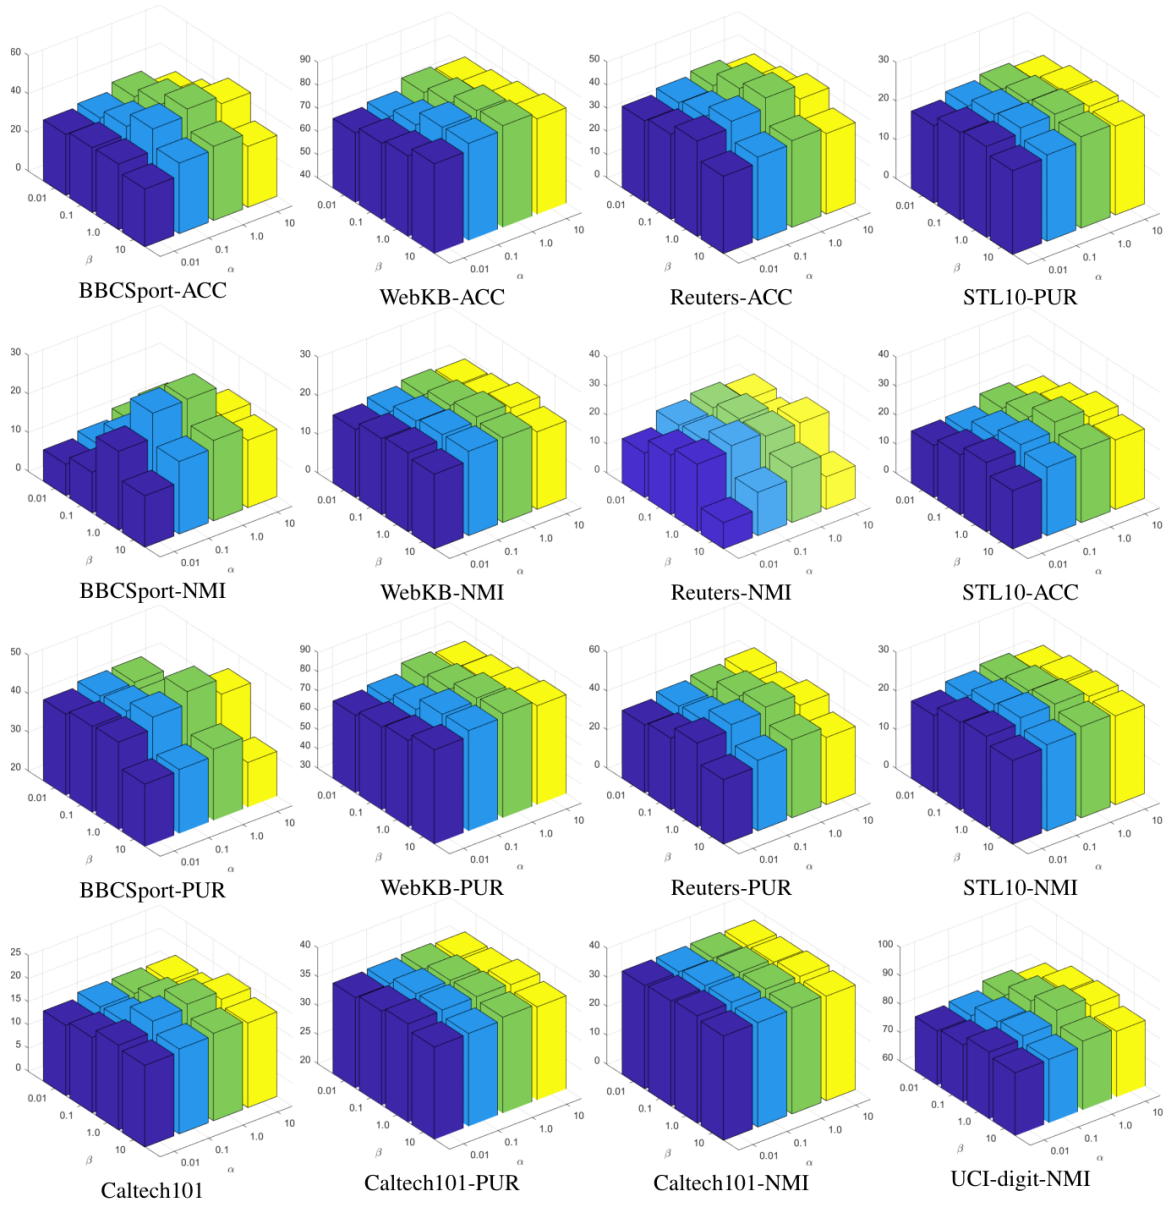



**图 10.** 在噪声比例为 10% 的 BBCSport、WebKB、Reuters、Caltech101、UCI-digit 和 STL10 数据集上，使用 ACC、NMI 和 PUR 对 $\alpha$ 和 $\beta$ 进行敏感性分析。ACC、NMI、PUR 分别为准确率、归一化互信息、纯度；子图标题中的数据集名与指标缩写保持原文。

**阈值 $\tau$ 的敏感性分析：**

我们开展实验以评估阈值参数 $\tau$ 的影响，将 $\tau$ 的取值在 $\{0.2, 0.4, 0.6, 0.8\}$ 范围内变化。结果见图 6。根据结果，我们有如下观察：随着阈值增大，模型的聚类性能逐渐提高。我们将其归因于较高阈值减少了错误对比学习样本对的数量，从而增强了模型的判别能力。

### A.3.4. 可视化分析

为更深入地理解 AIRMVC 学得的表示，我们使用 t-SNE（Van der Maaten & Hinton, 2008）对潜在特征空间进行可视化。具体而言，我们在 UCI-digit 数据集上提取表示，并将其映射到低维空间进行可视化。图 11 的结果揭示了如下现象：随着训练推进，UCI-digit 数据集中的聚类结构变得越来越清晰。在第 200 个训练轮次时，可以观察到分离良好、易于辨识的簇结构。这些结果凸显了 AIRMVC 揭示数据内在聚类结构的有效性。

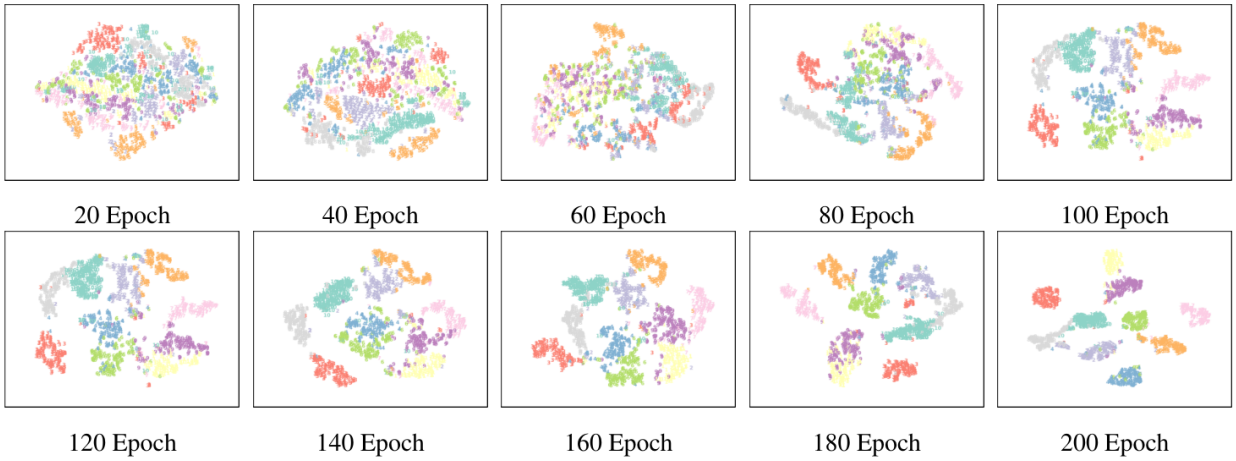



**图 11.** UCI-digit 数据集训练过程中表示的可视化。Epoch 表示训练轮次；各子图依次对应第 20、40、60、80、100、120、140、160、180 和 200 轮。

**表 6. 六个基准数据集上的多视图聚类性能（第 3/4 部分）。最高性能指标以红色强调，次优结果以蓝色标记。**

*Table 6.* Multi-view clustering performance on six benchmark datasets (Part 3/4). The highest performance metrics are emphasized in **red**, while the runner-up results are marked in blue.

| | Noisy Rate | | 10% | | | 30% | | | 50% | | | 70% | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | Metric | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| BBCSport | SiMVC | CVPR 2021 | 42.83 | 11.90 | 46.88 | 39.52 | 12.48 | 41.54 | 35.29 | 11.02 | 40.07 | 32.35 | 05.09 | 36.76 |
| | CoMVC | CVPR 2021 | 39.71 | 05.38 | 40.62 | 37.50 | 04.03 | 37.13 | 35.48 | 02.13 | 35.85 | 32.17 | 01.62 | 35.48 |
| | MFLVC | CVPR 2022 | 46.87 | 18.69 | 46.87 | 44.12 | 15.49 | 44.12 | 40.51 | 14.44 | 40.51 | 39.15 | 12.18 | 40.43 |
| | DealMVC | ACM MM 2023 | 40.25 | 07.56 | 40.44 | 35.48 | 06.27 | 35.48 | 31.80 | 03.94 | 35.47 | 30.38 | 02.89 | 31.78 |
| | SURE | TPAMI 2023 | 35.26 | 12.80 | 37.24 | 32.35 | 10.27 | 36.51 | 31.55 | 08.23 | 36.47 | 29.27 | 06.84 | 26.31 |
| | AIRMVC | Ours | **49.45** | **28.63** | **49.44** | **45.59** | **20.11** | **47.24** | **45.04** | **23.34** | **53.13** | **40.99** | **16.52** | **45.59** |
| WebKB | SiMVC | CVPR 2021 | 77.26 | 13.72 | 69.82 | 62.04 | 10.99 | 65.19 | 60.61 | 08.00 | 63.71 | 55.00 | **06.80** | 56.43 |
| | CoMVC | CVPR 2021 | 77.74 | 10.62 | 69.80 | 66.89 | 08.10 | 64.58 | 56.23 | 07.27 | 58.12 | 54.42 | 05.17 | 55.28 |
| | MFLVC | CVPR 2022 | 77.83 | 19.56 | 78.12 | 64.61 | 09.42 | 64.53 | 62.13 | 07.43 | 62.13 | 58.61 | 03.07 | 58.61 |
| | DealMVC | ACM MM 2023 | 66.03 | 15.02 | 65.27 | 60.32 | 04.85 | 60.32 | 59.66 | 04.63 | 58.47 | 55.57 | 01.92 | 55.57 |
| | SURE | TPAMI 2023 | 67.27 | 11.10 | 67.11 | 62.55 | 7.80 | 63.05 | 55.77 | 06.12 | 58.92 | 53.91 | 05.80 | 57.71 |
| | AIRMVC | Ours | **83.73** | **27.15** | **83.73** | **77.93** | **13.48** | **78.12** | **74.98** | **08.42** | **74.98** | **62.89** | 06.69 | **62.32** |
| Reuters | SiMVC | CVPR 2021 | 25.83 | 07.80 | 26.67 | 22.50 | 04.69 | 22.67 | 19.17 | 04.12 | 19.17 | 17.75 | 01.83 | 17.92 |
| | CoMVC | CVPR 2021 | 25.92 | 06.35 | 24.50 | 22.67 | 05.47 | 22.67 | 19.75 | 02.92 | 19.75 | 18.25 | 01.93 | 18.25 |
| | MFLVC | CVPR 2022 | 34.92 | 21.24 | 36.00 | 31.08 | 17.94 | 29.50 | 29.91 | 15.77 | 30.33 | 27.42 | 12.07 | 27.42 |
| | DealMVC | ACM MM 2023 | 30.92 | 14.14 | 30.92 | 28.50 | 10.53 | 28.50 | 27.92 | 06.16 | 27.92 | 26.58 | 05.74 | 26.58 |
| | SURE | TPAMI 2023 | 28.35 | 07.13 | 28.90 | 25.58 | 06.14 | 26.18 | 24.57 | 04.63 | 25.23 | 23.07 | 03.43 | 23.27 |
| | AIRMVC | Ours | **48.25** | **26.34** | **48.25** | **46.67** | **23.54** | **46.67** | **44.83** | **21.72** | **45.58** | **41.75** | **20.91** | **42.33** |

表头译文：Noisy Rate＝噪声比例；Metric＝指标；Ours＝本文方法。每一噪声比例下依次列出 ACC↑（准确率）、NMI↑（归一化互信息）、PUR↑（纯度）；↑ 表示越高越好。方法名、会议／期刊名与数据集名保持原文，全部数值与颜色保持原表。

## A.4. AIRMVC 的设置细节

**AIRMVC 的超参数设置：**

本小节在表 7 中报告所提出方法的统计汇总与超参数设置。

**表 7. AIRMVC 的超参数统计。**

| 项目 | BBCSport | WebKB | Reuters | UCI-digit | Caltech101 | STL10 |
|---|---|---|---|---|---|---|
| 视图数 | 2 | 2 | 5 | 3 | 5 | 4 |
| 样本数 | 544 | 1051 | 1200 | 2000 | 9144 | 13000 |
| 簇数 | 5 | 2 | 6 | 10 | 102 | 10 |
| 学习率 | 1e-4 | 1e-4 | 1e-5 | 1e-4 | 1e-4 | 1e-4 |
| $\tau$ | 0.8 | 0.8 | 0.8 | 0.8 | 0.8 | 0.8 |
| $\alpha$ | 1.0 | 1.0 | 1.0 | 1.0 | 1.0 | 1.0 |
| $\beta$ | 1.0 | 1.0 | 1.0 | 1.0 | 1.0 | 1.0 |

**数据集的详细信息：**

- **BBCSport[1]：** BBCSport 数据集包含 544 篇体育新闻文章，分为田径、板球、足球、橄榄球和网球五个类别。每篇文档从三个不同视图进行描述，其维度分别为 2582、2544 和 2465。该数据集对于多视图学习、文本分类和自然语言处理研究十分重要，为先进算法的开发与评估提供了坚实基础。
- **Reuters[2]：** Reuters 是一个文档集合，包含 1200 个样本，可分为 5 个类别。该数据集广泛用于文本分类、信息检索和主题建模，是机器学习的基准数据集。它还通过提供真实世界的示例，支持数据分析与模型开发的实践教学，显著促进了对文本分类挑战的理解及其解决方案的发展。
- **UCI-digit[3]：** UCI-digit 数据集也称为手写数字的光学识别数据集，包含手写数字（0–9）的图像，以 8×8 灰度矩阵表示，因此每幅图像具有 64 个特征。每幅图像均标注了对应数字。该数据集广泛用于学术研究，以评估机器学习模型在图像识别和分类方面的能力，是推动模式识别和计算机视觉方法发展的宝贵资源。
- **WebKB[4]：** WebKB 数据集包含来自威斯康星州四所大学的网页，同时关注网页内容及其相互链接。这种具有双重信息的数据集非常适合网页挖掘、超链接分析和多视图学习研究，为开发和评估探索学术网页环境中关系与内容动态的算法提供了全面资源。
- **SUNRGBD[5]：** SUNRGBD 数据集对室内场景理解至关重要，包含分属 45 个类别的 10,335 个样本，涵盖 RGB 图像、深度图像和三维点云数据。每个样本均具有详细的语义标注，包括物体类别和空间位置。这一多模态数据集支持场景理解、目标检测、语义分割和三维重建等任务。研究人员使用 SUNRGBD 开发和评估融合多模态信息的算法，推动室内场景分析与计算机视觉研究。
- **STL10[6]：** STL10 是无监督特征学习、深度学习和自学式学习的重要基准。它包含分属 10 个类别的 13,000 幅带标签图像和 100,000 幅无标签图像，每幅图像为 96×96 像素，具有四个视图。该数据集允许在无标签数据上预训练模型，以模拟真实世界场景，并且对于评估特征学习与泛化能力十分关键，从而推动表示学习和机器学习研究。

· **Caltech101[7]：** Caltech101 是机器学习和计算机视觉领域广泛使用的基准数据集，由分属 102 个不同簇的 9,144 个样本组成。该数据集具有多样性和复杂性，包含五个不同视图，为每个样本提供互补信息。这些视图通常包括不同类型的特征或表示，使其适合评估多视图聚类和表示学习方法。由于具有丰富的异构结构，Caltech101 已成为评估聚类算法处理多视图和高维数据能力的标准测试平台。

[1] http://mlg.ucd.ie/datasets/bbc.html

[2] http://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection

[3] https://cs.nyu.edu/roweis/data.html

[4] https://lig-membres.imag.fr/grimal/data.html

[5] https://rgbd.cs.princeton.edu/

[6] https://cs.stanford.edu/~acoates/stl10/

[7] https://data.caltech.edu/records/mzrjq-6wc02

译注：数据集描述与表 7 的个别统计并不一致（例如 BBCSport 的视图数、Reuters 的类别数）；本译文分别忠实保留原文，不作统一改写。

**表 8. 六个基准数据集上的多视图聚类性能（第 4/4 部分）。最高性能指标以红色强调，次优结果以蓝色标记。**

*Table 8.* Multi-view clustering performance on six benchmark datasets (Part 4/4). The highest performance metrics are emphasized in **red**, while the runner-up results are marked in blue.

| | Noisy Rate | | 10% | | | 30% | | | 50% | | | 70% | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | Metric | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| UCI-digit | SiMVC | CVPR 2021 | 30.50 | 30.14 | 31.10 | 26.50 | 19.00 | 26.50 | 23.45 | 18.01 | 23.70 | 19.95 | 11.80 | 20.00 |
| | CoMVC | CVPR 2021 | 44.80 | 42.42 | 45.10 | 34.60 | 33.58 | 34.85 | 32.20 | 31.31 | 32.55 | 28.45 | 27.00 | 29.45 |
| | MFLVC | CVPR 2022 | 89.80 | 82.37 | 89.80 | 60.50 | 63.35 | 60.50 | 47.05 | 48.91 | 47.05 | 31.90 | 28.14 | 31.90 |
| | DealMVC | ACM MM 2023 | 84.85 | 80.98 | 84.85 | 70.80 | 67.38 | 70.80 | 65.55 | 62.12 | 65.55 | 48.90 | 49.82 | 48.90 |
| | SURE | TPAMI 2023 | 34.96 | 14.82 | 34.96 | 31.73 | 13.49 | 33.29 | 28.29 | 11.96 | 29.35 | 26.14 | 10.08 | 27.05 |
| | AIRMVC | Ours | **93.95** | **89.08** | **93.95** | **77.60** | **76.65** | **80.75** | **76.05** | **68.17** | **76.05** | **69.20** | **60.38** | **69.20** |
| Caltech101 | SiMVC | CVPR 2021 | 14.88 | 10.98 | 16.28 | 11.72 | 6.55 | 12.98 | 10.79 | 5.57 | 11.94 | 9.63 | 5.05 | 10.97 |
| | CoMVC | CVPR 2021 | 15.00 | 12.92 | 15.80 | 14.34 | 12.26 | 15.49 | 10.04 | 11.66 | 10.42 | 9.58 | 6.53 | 9.95 |
| | MFLVC | CVPR 2022 | 19.63 | 20.27 | 21.78 | 14.87 | 16.52 | 14.33 | 10.59 | 13.76 | 10.79 | 9.60 | 6.80 | 9.63 |
| | DealMVC | ACM MM 2023 | 19.90 | 20.73 | 22.07 | 13.09 | 11.96 | 17.80 | 10.14 | 5.55 | 10.14 | 10.05 | 5.03 | 10.08 |
| | SURE | TPAMI 2023 | 7.44 | 17.91 | 16.29 | 7.09 | 15.85 | 16.03 | 6.84 | 14.57 | 15.01 | 6.33 | 12.58 | 10.62 |
| | AIRMVC | Ours | **21.45** | **37.16** | **34.69** | **15.89** | **29.39** | **27.60** | **11.80** | **23.66** | **23.33** | **11.89** | **21.14** | **20.14** |
| STL10 | SiMVC | CVPR 2021 | 19.51 | 11.33 | 19.52 | 17.52 | 6.83 | 18.06 | 15.91 | 5.45 | 16.04 | 13.44 | 3.62 | 14.00 |
| | CoMVC | CVPR 2021 | 27.07 | 21.49 | 27.36 | 20.78 | 15.57 | 20.70 | 17.68 | 16.15 | 17.75 | 15.37 | 13.92 | 15.56 |
| | MFLVC | CVPR 2022 | 24.39 | 23.34 | 24.39 | 21.14 | 20.19 | 21.47 | 20.58 | 21.92 | 20.14 | 19.08 | 18.24 | 19.08 |
| | DealMVC | ACM MM 2023 | 24.59 | 23.51 | 24.59 | 21.23 | 22.83 | 21.33 | 20.56 | 21.78 | 20.56 | 19.12 | 18.27 | 19.12 |
| | SURE | TPAMI 2023 | 21.14 | 6.72 | 21.66 | 19.36 | 5.87 | 20.76 | 18.34 | 5.64 | 19.11 | 17.33 | 5.45 | 18.15 |
| | AIRMVC | Ours | **28.81** | **25.04** | **29.01** | **22.46** | **23.64** | **22.46** | **21.95** | **23.09** | **22.02** | **20.14** | **22.66** | **20.14** |

表头译文：Noisy Rate＝噪声比例；Metric＝指标；Ours＝本文方法。各组依次为 ACC↑（准确率）、NMI↑（归一化互信息）、PUR↑（纯度）；↑ 表示越高越好。所有方法名、发表会议／期刊、数据集名、数值和颜色按原表保留。

**算法：** 由于原论文篇幅有限，我们在本部分给出算法。详细训练过程见算法 1。

**算法 1. 所设计的 AIRMVC 的训练算法**

输入：多视图数据集 $\{x^v\}_{v=1}^V$；训练轮数 $e$；批大小 $B$。

输出：聚类结果 $\mathbf{R}$。

1. 对第 1 至第 $e$ 个训练轮次执行：
2. E 步：更新 AIRMVC 中的参数 $\{(\mu_k, \sigma_k)\}_{k=1}^K$，以及 $\{\varphi_i\}_{i=1}^N$。
3. M 步：
4. 重复：
5. 通过编码器网络获得表征 $\mathbf{E}$。
6. 使用式（6）识别含噪数据。
7. 使用式（7）纠正含噪数据。
8. 使用式（8）、（11）、（12）计算纠正损失、对比损失和重构损失。
9. 依据式（13）计算总损失 $\mathcal{L}$。
10. 使用 Adam 优化器，通过最小化 $\mathcal{L}$ 更新模型。
11. 直到该训练轮次结束。
12. 结束循环。
13. 输出聚类结果 $\mathbf{R}$。

**表 9. 在噪声比例为 90% 的六个基准数据集上的多视图聚类性能。最高性能指标以红色强调，次优结果以蓝色标记。**

*Table 9.* Multi-view clustering performance on six benchmark datasets with 90% noise ratio. The highest performance metrics are emphasized in **red**, while the runner-up results are marked in blue.

| Dataset | | BBCSport | | | WebKB | | | Reuters | | |
|---|---|---|---|---|---|---|---|---|---|---|
| Metrics | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| SiMVC | CVPR 2021 | 29.78 | 04.15 | 35.85 | 52.43 | 04.60 | 56.47 | 16.92 | 01.08 | 17.00 |
| CoMVC | CVPR 2021 | 30.33 | 01.59 | 32.75 | 51.67 | 03.85 | 50.15 | 16.67 | 01.41 | 16.67 |
| MFLVC | CVPR 2022 | 37.13 | 07.14 | 32.52 | 56.14 | 01.68 | 56.14 | 21.33 | 04.35 | 21.33 |
| DealMVC | ACM MM 2023 | 29.78 | 02.76 | 30.47 | 50.77 | 01.28 | 50.77 | 20.87 | 03.58 | 20.87 |
| SURE | TPAMI 2023 | 28.20 | 03.13 | 24.26 | 52.98 | 04.20 | 56.61 | 21.18 | 02.82 | 21.75 |
| CANDY | NeurIPS 2024 | 15.26 | 01.42 | 33.48 | 14.27 | 02.39 | 14.27 | 17.84 | 04.70 | 26.50 |
| RMCNC | TKDE 2024 | 23.90 | 03.78 | 23.87 | 51.87 | 03.47 | 50.48 | 20.17 | 05.23 | 20.25 |
| TGM-MVC | ACM MM 2024 | 17.38 | 03.57 | 17.38 | 50.24 | 05.21 | 50.24 | 20.58 | 03.87 | 20.58 |
| SCE-MVC | NeurIPS 2024 | 37.62 | 08.47 | 37.28 | 51.67 | 01.20 | 51.67 | 16.67 | 04.76 | 16.67 |
| MVCAN | CVPR 2024 | 23.34 | 01.79 | 24.68 | 57.71 | 03.05 | 57.15 | 19.41 | 04.97 | 19.83 |
| DIVIDE | AAAI 2024 | 26.29 | 02.04 | 37.32 | 50.05 | 03.70 | 54.34 | 24.08 | 06.25 | 26.42 |
| AIRMVC | Ours | **39.52** | **09.33** | **40.26** | **59.18** | **05.36** | **60.08** | **33.50** | **20.60** | **35.35** |
| Dataset | | UCI-digit | | | Caltech101 | | | STL10 | | |
| Metrics | | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ | ACC↑ | NMI↑ | PUR↑ |
| SiMVC | CVPR 2021 | 15.55 | 08.64 | 16.00 | 07.78 | 03.16 | 09.61 | 11.72 | 01.71 | 12.66 |
| CoMVC | CVPR 2021 | 24.15 | 26.41 | 26.95 | 08.61 | 05.55 | 10.56 | 12.63 | 08.21 | 12.75 |
| MFLVC | CVPR 2022 | 29.25 | 29.18 | 29.25 | 08.43 | 05.29 | 08.98 | 18.04 | 13.93 | 18.04 |
| DealMVC | ACM MM 2023 | 37.40 | 39.04 | 37.45 | 09.96 | 04.03 | 09.38 | 18.45 | 17.32 | 18.45 |
| SURE | TPAMI 2023 | 23.92 | 08.83 | 25.13 | 06.21 | 10.41 | 06.85 | 16.93 | 04.97 | 17.59 |
| CANDY | NeurIPS 2024 | 51.05 | 42.16 | 53.70 | 10.00 | 10.60 | 16.56 | 16.32 | 15.44 | 16.72 |
| RMCNC | TKDE 2024 | 19.15 | 08.81 | 21.15 | 06.56 | 10.89 | 06.10 | 13.35 | 01.26 | 13.57 |
| TGM-MVC | ACM MM 2024 | 49.83 | 63.42 | 55.59 | 05.45 | 17.53 | 16.21 | 17.74 | 15.66 | 17.24 |
| SCE-MVC | NeurIPS 2024 | 57.70 | 49.43 | 57.15 | 10.08 | 18.16 | 18.41 | 13.85 | 10.93 | 13.59 |
| MVCAN | CVPR 2024 | 57.25 | 50.87 | 57.48 | 9.07 | 13.49 | 3.77 | 16.15 | 15.35 | 16.33 |
| DIVIDE | AAAI 2024 | 57.05 | 50.09 | 57.75 | 9.02 | 15.85 | 13.28 | 18.09 | 12.00 | 18.63 |
| AIRMVC | Ours | **58.20** | **51.94** | **58.20** | **10.85** | **19.01** | **18.96** | **19.90** | **19.92** | **19.90** |

表头译文：Dataset＝数据集；Metrics＝指标；Ours＝本文方法。各数据集下依次为 ACC↑（准确率）、NMI↑（归一化互信息）、PUR↑（纯度）；↑ 表示越高越好。方法、发表会议／期刊和数据集名称保留原文；所有数值及优劣颜色标记完整保留。

## A.5. 比较算法

本文将 AIRMVC 与 11 种基线进行比较，包括 CoMVC（Trosten et al., 2021）、SiMVC（Trosten et al., 2021）、MFLVC（Xu et al., 2022b）、DealMVC（Yang et al., 2023b）、SURE（Yang et al., 2023a）、CANDY（Guo et al.）、TGM-MVC（Wang et al., 2024a）、SCE-MVC（Wang et al., 2024b）、RMCNC（Sun et al., 2024）和 MVCAN（Xu et al., 2024）。这些方法的具体信息如下：

- **CoMVC 与 SiMVC（Trosten et al., 2021）：** CoMVC 和 SiMVC 是避免同时对齐所有表示的深度多视图聚类方法。这些方法引入对比学习策略，以提高聚类性能。
- **MFLVC（Xu et al., 2022b）：** MFLVC 在高层特征空间和语义标签空间中都采用对比学习策略，为深度多视图聚类引入两个一致性目标。
- **DealMVC（Yang et al., 2023b）：** DealMVC 提出一种为深度多视图聚类量身设计的双重校准机制。其校准对比损失能够有效区分多个视图中相似但不同的样本。
- **SURE（Yang et al., 2023a）：** SURE 通过构建噪声鲁棒对比损失，解决不完整多视图数据的相关挑战。该方法通过理论分析来处理部分未对齐视图和缺失样本。
- **CANDY（Guo et al.）：** CANDY 利用视图间相似度作为上下文来发现假负样本，并集成基于谱的模块，对多视图场景中的对应关系进行去噪。
- **TGM-MVC（Wang et al., 2024a）：** TGM-MVC 采用基于树的框架，有效捕获不同视图之间的异质性，为多视图聚类提供独特视角。
- **SCE-MVC（Wang et al., 2024b）：** SCE-MVC 采用博弈论原理和 Shapley 值来应对多视图聚类挑战，提供一种提高聚类鲁棒性的创新解决方案。
- **RMCNC（Sun et al., 2024）：** RMCNC 引入一种容噪对比损失，旨在减轻多视图聚类任务中未对齐样本对的影响。
- **MVCAN（Xu et al., 2024）：** MVCAN 采用非共享网络结构，并实施两级优化策略，从而提高多视图场景中的聚类性能。
- **DIVIDE（Lu et al., 2024）：** DIVIDE 利用随机游走方法逐步识别可靠数据对，增强多视图聚类中对比学习的稳定性和鲁棒性。