策略与架构协同：
面向一致性表示的多视图图对比范式

Strategy-Architecture Synergy: A Multi-View Graph Contrastive Paradigm for Consistent Representations

Shuman Zhuang[1]，Zhihao Wu[2]，Yuhong Chen[3]，Zihan Fang[1]，Jiali Yin[1]*，Ximeng Liu[1]

[1] 福州大学计算机与大数据学院，中国福州
[2] 浙江大学计算机科学与技术学院，中国杭州
[3] 厦门大学人工智能研究院，中国厦门

联系方式：shumanzhuang@163.com；zhihaowu1999@gmail.com；yhchen2320@163.com；fzihan11@163.com；jlyin@fzu.edu.cn；snbnix@gmail.com。* 通讯作者。

出处： 第三十四届国际人工智能联合会议论文集（IJCAI-25），原文页码 7291-7299。

非官方中文全文译文 · 仅供用户私人阅读。 本译文依据用户上传的 9 页原始 PDF 制作，仅保存在 dot cloud；原作者及出版方的权利不变，公开再分发许可尚未核实。图、表和编号公式保留原稿裁图及排印，并附中文说明。本文引用的附录 A-D 不在所上传的 9 页文件中，本译文不编造或补写这些附录。文末“译注”与原文内容明确区分。

摘要

面对日益多样化的多视图数据，基于多视图图的模型在处理建模为图的多视图数据方面取得了令人鼓舞的进展。图对比学习（Graph Contrastive Learning，GCL）将多视图图数据固有的视图视为增强，因此天然适合这类数据。然而，GCL 在多视图图数据上的发展仍处于起步阶段。如何设计能够协调预处理与对比学习的策略，以及如何开发自动满足不同视图需求的模型架构，仍然面临挑战。为此，我们提出了名为 CAMEL 的框架，通过引入专门面向多视图图的对比范式来改进一致性学习。首先，我们从理论上分析删边预处理对一致性的积极作用，并量化影响这一作用的因素。所提出的自适应删边预处理策略与可学习模型架构相结合，由动态拓扑引导，使视图间的异质性更加可控，并使其更好地适应对比学习。最后，我们设计了一种邻域一致性多视图对比目标，通过扩展正样本来增强一致性信息的交互。在节点分类和聚类等下游任务上开展的大量实验验证了所提模型的优越性。

1 引言

多媒体技术的进步使数据采集方式更加多样，能够获取丰富且多方面的信息。例如，在多媒体分析中，可以通过同一内容的图像、音频和文本描述来获取互补信息。这种来自不同来源的数据可以建模为多视图数据 [Wan et al., 2024b; Xu et al., 2025a; Zhuang et al., 2024]。已有众多传统多视图学习方法致力于将这些互补视图整合为连贯的表示 [Zhang et al., 2025; Fu et al., 2023]。然而，它们难以建模样

本之间复杂的内在关系，尤其是这些关系超出特征空间时。在真实场景中，样本往往具有相互依赖性和复杂的语义关系，因此图数据成为建模这些复杂连接的通用方式 [Wu et al., 2023b; Tu et al., 2025]。通过将多视图数据组织为图，可以有效捕获和利用潜在关系。

图对比学习（GCL）是一种用于图结构数据分析的无监督范式，它利用无标签样本提供丰富的信息 [Li et al., 2023; Zhuang et al., 2025]。值得注意的是，多视图图数据以其固有的多个视图作为增强，天然适合 GCL。然而，面向多视图数据的 GCL 仍处于发展早期 [Liu et al., 2023a; Wang et al., 2023]。对比学习遵循“增强-对比”范式，增强方式与对比策略相互依赖。通常，人们手工设计增强，使其与对比目标相适配。例如，GRACE [Zhu et al., 2020] 的对比目标是在两个增强视图中的同一节点之间最大化互信息。为此，它采用边丢弃、特征掩蔽等扰动策略，生成两个受到轻微破坏的视图以开展对比学习。同样，DGI [Velickovic et al., 2019] 的对比目标是最大化局部块-摘要对之间的互信息，并采用特征打乱等随机破坏技术来引入负样本。

然而，将 GCL 范式直接应用于多视图图并非最优选择，因为传统 GCL 方法未考虑多视图场景固有的复杂异质性。具体而言，在对比学习中，多个视图通常通过人工定义的扰动产生，往往采用简单、可控的变换，视图间关系明确且相对容易建模。相比之下，多视图数据固有的各个视图之间存在难以捕获的复杂一致性和互补性关系 [Sun et al., 2024; Wang et al., 2021]。这些关系包含视图共享信息、视图特有且与任务相关的信息，以及视图特有但与任务无关的信息，超出了传统量化与建模范式的处理能力。直接将这些多视图视为增强，会忽略潜在的分布差异与对齐问题，可能使共享 GNN 编码器无法在异质视图之间学习到期望的表示。因此，需要专门面向多视图数据设计预处理策略，使视图间的差异及相互依赖更加易于处理。此外，GCL 的对比目标和模型架构也缺少对多视图数据复杂性以及图特有性质的考虑，导致信息交互不完整，甚至可能出错。

基于上述分析，我们希望设计一种专门适用于多视图图数据的新型对比学习范式。在多视图情境下，对比学习仍存在两个关键挑战：（1）在策略层面，如何设计预处理策略，使多个视图与 GCL 更好地适配，同时设计能够捕获更丰富信息的对比策略？（2）在结构层面，如何设计适合多视图图的模型架构?

为应对这些挑战，我们提出一种新型多视图学习框架，称为一致性感知多视图图对比学习（Consistency-Aware Multi-view graph contrastivE Learning，CAMEL）。该框架整合了专门针对多视图图数据精心设计的策略与架构。通过严格的数学分析，我们首先揭示了删边预处理能够促进多视图表示的一致性。此外，我们量化了删边操作的影响与重加权因子之间的关系。为了更好地学习一致性信息并适应不同视图之间的异质性，我们开发了可学习模型架构，使每个视图能够自主吸收信息，并选择最适合自身的结构。由此，我们自然地设计出一种自适应删边预处理策略：由自适应拓扑引导删边操作，以确保其与不同视图兼容。最后，我们提出邻域一致性多视图对比策略，在考虑图性质的基础上重新定义正负样本对的构造。具体来说，将锚节点在同一视图内以及跨视图的一阶邻居扩展为正样本，从而促进一致性信息的流动。CAMEL 的流程图见图 1。我们的贡献总结如下：

- 进行理论分析，证实删边预处理能够促进一致性学习，并量化影响一致性的因素。
- 提出一种面向多视图图数据的新型对比范式 CAMEL，将可学习模型架构、自适应删边预处理策略与邻域一致性多视图对比目标整合在一起。
- 在三类数据集上开展大量实验，表明所提框架优于最先进的多视图 GNN。

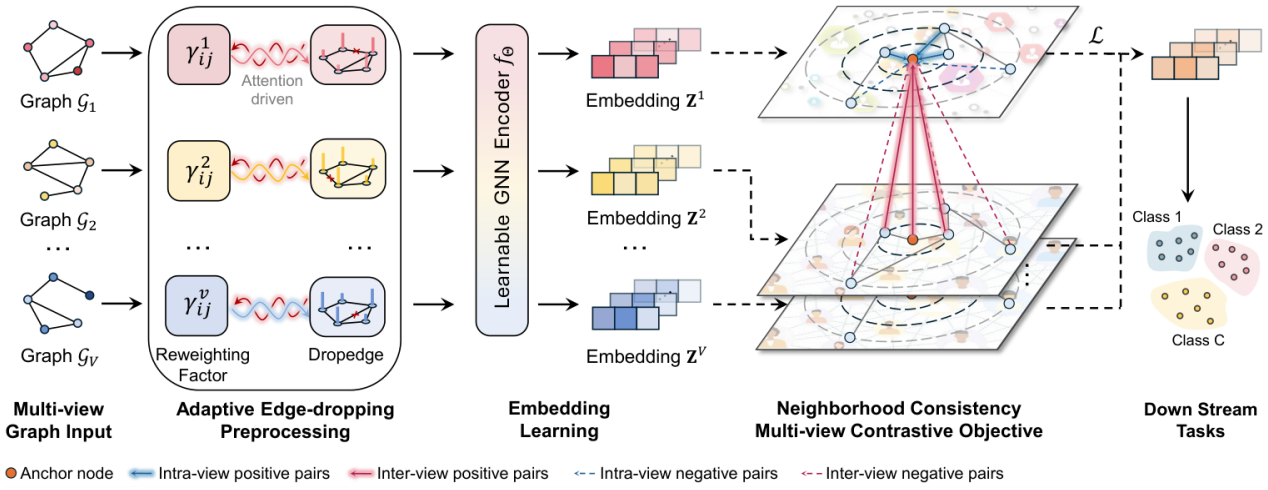


图 1：CAMEL 总体框架。 在可学习 GNN 架构中，由重加权因子引导，对每个视图进行删边预处理；随后采用邻域一致性多视图对比目标，获得一致性表示。

图内文字：Multi-view Graph Input＝多视图图输入；Graph＝图；Reweighting Factor＝重加权因子；Attention driven＝注意力驱动；Dropedge＝删边；Adaptive Edge-dropping Preprocessing＝自适应删边预处理；Learnable GNN Encoder＝可学习 GNN 编码器；Embedding＝嵌入；Embedding Learning＝嵌入学习；Neighborhood Consistency Multi-view Contrastive Objective＝邻域一致性多视图对比目标；Down Stream Tasks＝下游任务；Class 1、Class 2、Class C＝类别 1、类别 2、类别 C。图例依次为锚节点、视图内正样本对、视图间正样本对、视图内负样本对、视图间负样本对。

2 相关工作

2.1 图对比学习

图对比学习（GCL）已成为图数据学习的重要研究方向，重点是在正样本对之间最大化互信息，同时在负样本对之间最小化互信息。GCL 的核心研究问题在于设计图增强策略，其中删边和属性掩蔽是最常见的技术 [Zhu et al., 2020; Liu et al., 2024b; Bu et al., 2024]。此外，一些方法采用计算机视觉中常用的对比损失，例如 InfoNCE 和 Triplet loss（三元组损失）[Wu et al., 2022; Koromilas et al., 2024]，遵循 InfoMax 原则，从不同增强视图中提取共享的核心信息。尽管 GCL 取得了显著进展，标准范式仍存在一些局限，尤其是在图增强和对比目标方面。因此，也有研究提出其他新型图增强范式，以扩展增强技术的范围。例如，[Shen et al., 2023] 采用多头图注意力机制来学习图增强。其他值得关注的方法包括基于模体中心性的自适应增强 [Li et al., 2023]，以及保持相似性的对抗增强 [In et al., 2023]。不过，GCL 在多视图数据中的应用仍十分有限，主要原因是严重缺乏专门针对这类数据集设计的增强和对比策略。

2.2 多视图学习

多视图学习旨在整合并编码多个来源的信息，得到能够捕获不同视图之间一致性与互补性的低维表示。基于图的多视图学习 [Wan et al., 2024a; Lu et al., 2024; Wu et al., 2024] 凭借对复杂关系的强大建模能力，已成为广泛采用的学习范式。例如，[Liang et al., 2022] 为鲁棒学习定义了一种极小极大形式，以解决局部最优问题。[Huang et al., 2023] 则利用注意力分配方法与样本加权策略，增强基于图

的多视图模型。近期方法也将对比技术引入多视图学习，以利用并对比每个视图的独有特征。例如，[Shen et al., 2023] 引入一种对比多视图核，将各视图隐式嵌入联合语义空间，而 [Su et al., 2024] 在此基础上解决假负样本问题。尽管这些融入 GCL 的方法在捕获图特有性质方面取得了显著进展，但它们依赖经验性启发式规则且缺乏严格理论，这可能限制其在不同任务和数据集上的泛化能力。

3 所提方法

3.1 预备知识与符号

令 $\mathcal{G} = \{\mathcal{G}^v\}_{v=1}^{V}$ 表示多视图图，其中 V 为视图数，$\mathcal{G}^v$ 为第 v 个视图的数据。特征矩阵 $\mathbf{X} \in \mathbb{R}^{n \times m}$ 包含节点信息，每个节点具有一个 m 维特征向量。对于第 v 个视图 $\mathcal{G}^v = (\mathcal{V}, \mathcal{E}^v)$，$\mathcal{V}$ 是节点集，$|\mathcal{V}| = n$，$\mathcal{E}^v \subseteq \mathcal{V} \times \mathcal{V}$ 为边集。第 v 个视图的邻接矩阵定义为 $\mathbf{A}^v \in \{0, 1\}^{n \times n}$，其度矩阵为 $\mathbf{D}^v$，其中 $d_i^v = \sum_j A_{ij}^v$，且 $A_{ij}^v = 1$ 当且仅当 $\left(v_i, v_j\right) \in \mathcal{E}^v$。

GCL 旨在最大化不同视图表示的一致程度，因此天然适合处理多视图数据。与常规对比学习不同，图对比多视图学习将多视图数据视为样本的自然增强。具体而言，将来自同一样本的实例归为正样本对，其余归为负样本对，以此构造样本对 [Liu et al., 2023b]。通常，首先由共享的 GNN 编码器编码每个视图图，得到归一化的数据表示，记为 $\mathbf{Z}^v = f_\Theta(\mathbf{A}^v, \mathbf{X})$。遵循 InfoNCE [Oord et al., 2018]，第 i 个数据样本在第 v 和第 v' 个视图之间的损失可定义为：

$$\ell_{f_\Theta}(\boldsymbol{z}_i^v) = -\log \frac{e^{\theta(\boldsymbol{z}_i^v, \boldsymbol{z}_i^{v'})/\tau}}{\underbrace{e^{\theta(\boldsymbol{z}_i^v, \boldsymbol{z}_i^{v'})/\tau}}_{\text{positive pairs}} + \underbrace{\sum_{j \neq i} e^{\theta(\boldsymbol{z}_i^v, \boldsymbol{z}_j^v)/\tau} + \sum_{j \neq i} e^{\theta(\boldsymbol{z}_i^v, \boldsymbol{z}_j^{v'})\tau}}_{\text{negtive pairs}}}, \quad (1)$$

式（1）中，positive pairs＝正样本对，negtive pairs（原文拼写）＝负样本对。θ 为定义在节点表示上的相似性度量，τ 为温度参数。编码器 f_Θ 可以替换为任意 GNN 模型。通常，可以用单层 GNN 编码器中消息传递的基本形式来概括第 v 个视图中第 i 个节点的表示：

$$\boldsymbol{z}_i^v = \sum_{j \in \{\mathcal{N}_i \cup i\}} \gamma_{i,j}^v \boldsymbol{z}_j^v, \quad (2)$$

其中，γ_{ij}^v 是沿边 $\left(v_i, v_j\right)$ 传递消息的权重，称为重加权因子；在普通 GCN 中，其示例为 $\gamma_{i,j}^v = 1/\sqrt{d_i d_j}$。

3.2 关于预处理的一致性分析

根据前面的分析，直接将多视图数据固有的视图视为增强并不合理。这里受 [Xu et al., 2025b] 启发，我们进行理论分析，探究视图预处理对多视图图内一致性信息的影响。首先，可以通过追踪信息在非一致性边上的传播来评估每个视图的扰乱指数，定义如下。

定义 1（扰乱指数，Disruptive Index）。给定多视图图 $\mathcal{G}^v = (\mathcal{V}, \mathcal{E}^v)$，扰乱指数（DI）量化每个视图阻碍跨视图一致决策的程度，定义为：

$$\mathfrak{I}^v = \frac{\sum_{i\in\mathcal{V}} \sum_{j\in\mathcal{N}_i^{\text{non}}} \gamma_{ij}^v}{\sum_{i\in\mathcal{V}} \sum_{j\in\mathcal{N}_i} \gamma_{ij}^v}, \tag{3}$$

其中，$\mathcal{N}_i$ 表示节点 i 的邻居集合；$\mathcal{N}_i^{\text{non}} \subseteq \mathcal{N}_i$ 是通过阻碍一致性学习的边连接的邻居子集，这些边即非一致性边。相反，一致性边集定义为 $\mathcal{N}_i \backslash \mathcal{N}_i^{\text{non}}$ 中对应的边，它们对多视图学习有积极贡献。

根据非一致性信息所占比例定义每个视图的 DI 后，有效的预处理策略应寻求更小的 DI。这里我们关注常用的边扰动技术，分析其在增强跨视图表示一致性以及减轻非一致性边负面影响方面的作用。具体而言，我们考察删除或添加任意一条边 $(a, b) \in \mathcal{E}^v$ 对 DI 的影响。令 $\widetilde{\mathfrak{I}}^v$ 表示修改后视图的 DI，对应的重加权因子为 $\widetilde{\gamma}_{ij}^v$，则 DI 的变化可进一步表示为：

$$\Delta = \tilde{\mathfrak{I}}^v - \mathfrak{I}^v. \tag{4}$$

设 $s = \sum_{i\in\mathcal{V}} \sum_{j\in\mathcal{N}_i} \gamma_{ij}^v$，$\tilde{s} = \sum_{i\in\mathcal{V}} \sum_{j\in\mathcal{N}_i} \widetilde{\gamma}_{ij}^v$，我们推导出如下量化算子 ω：

$$\omega = s \cdot \tilde{s} \cdot \Delta, \tag{5}$$

它满足 $\omega \propto \Delta$，能够有效反映视图内部非一致性信息的变化。为进一步探究 DI 的变化，我们对 ω 作如下精确量化。

引理 1。假设视图中每个节点 v_i 接收的非一致性信息占总信息的比例为 m，则可推导出：

$$\begin{cases} \omega = 2\left(m - \mathbb{1}_{\{a,b\}\in\mathscr{E}^v}\right) \cdot \tilde{s} \cdot \gamma_{ij}^v, & \textit{if an edge is dropped}, \\ \omega = 2\left(\mathbb{1}_{\{a,b\}\in\mathscr{E}^v} - m\right) \cdot \tilde{s} \cdot \gamma_{ij}^v, & \textit{if an edge is added}, \end{cases} \tag{6}$$

where $\mathscr{E}^v \in \mathcal{E}^v$ *is the set of non-consensual edges.*

式（6）的两行分别对应“删除一条边时”和“添加一条边时”。其中，式后所示的 $\mathscr{E}^v \in \mathcal{E}^v$ 为非一致性边集；该集合关系及两个边集符号的字体差异完整保留在上方原稿裁图中。

式（5）和引理 1 的完整推导见附录 B。总体而言，结合式（5）和式（6）可以推导出以下定理。

定理 1。 当从图 $\mathcal{G}^v$ 中删除或向其中添加任意边 $(a,\ b) \in \mathcal{E}^v$ 时，有：

$$\begin{cases} \Delta = \frac{2(m-\mathbb{1}_{\{a,b\}\in\mathcal{E}^v})}{s} \cdot \gamma_{ij}^v, & \textit{if an edge is dropped} \\ \Delta = \frac{2(\mathbb{1}_{\{a,b\}\in\mathcal{E}^v}-m)}{s} \cdot \gamma_{ij}^v, & \textit{if an edge is added} \end{cases} \tag{7}$$

式（7）的两行分别对应删边和加边。对于删边，以下关系成立：

$$\begin{cases} \Delta = \frac{2(m-1)}{s} \cdot \gamma_{ij}^v, & if\ (a,b) \in \mathcal{E}^v \\ \Delta = \frac{2m}{s} \cdot \gamma_{ij}^v, & if\ (a,b) \notin \mathcal{E}^v \end{cases} \tag{8}$$

对于加边，以下关系成立：

$$\begin{cases} \Delta = \frac{2(1-m)}{s} \cdot \gamma_{ij}^v, & if\ (a,b) \in \mathcal{E}^v \\ \Delta = \frac{-2m}{s} \cdot \gamma_{ij}^v, & if\ (a,b) \notin \mathcal{E}^v \end{cases} \tag{9}$$

假设多视图数据中各视图的 DI 小于 0.5，即 $m < 0.5$，这在大多数情况下都成立，则可以观察到边扰动的以下影响。对于删边，如果删除的是非一致性边，则 $\Delta < 0$，表示一致性改善，且一致性收益较大；如果删除的是一致性边，则 $\Delta > 0$，会破坏一致性，但损害相对较小。删边带来的一致性收益大于损失，而加边操作呈现相反趋势。因此，定理 1 证实，删边比加边更有效地促进一致性学习。

3.3 自适应删边 GNN 架构

前述理论分析表明，删边能够促进多视图一致性学习，因此我们将删边作为每个视图的预处理步骤。根据定理 1，DI 的变化满足 $\Delta \propto \gamma_{ij}^v$，这促使我们利用 γ_{ij}^v 控制删边。以往采用 GNN 编码器的 GCL 模型会不加区分地平滑邻域内所有节点表示，往往难以适应多视图数据的异质性。因此，我们提出一种适用于多视图情境的、更通用且灵活的模型架构，采用自适应重加权因子 $\gamma_{ij}^v = \eta_{ij}^v/\sqrt{d_i d_j}$，其中 η_{ij}^v 的取值范围为 0 到 1。这使节点能够在不同视图的消息传递过程中选择性地吸收信息。具体而言，我们采用门控机制来学习 η_{ij}^v：

$$\eta_{i,j}^v = \mathrm{softmax}(\sigma(\mathbf{W}^\top[\boldsymbol{z}_i^v||\boldsymbol{z}_j^v])), \tag{10}$$

其中，$\sigma(\cdot)$ 为激活函数，$\mathbf{W} \in \mathbb{R}^{2F'}$ 为可训练权重矩阵，隐藏单元数为 F'。结合重加权因子与定理 1，边 $\left(v_i,\ v_j\right)$ 被删除的概率由重加权因子引导，如下所示：

$$p_{ij}^v = \min\left(\frac{\gamma_{ij}^v - \min(\gamma^v)}{\mathrm{mean}(\gamma^v) - \min(\gamma^v)} \cdot \alpha, p_\tau\right), \tag{11}$$

其中，α 是控制删边概率的超参数，p_τ 是不超过 1 的截断概率。根据删边概率 p_{ij}^v，可以采样一个掩码变量 s_{ij}^v，其值服从伯努利分布：$s_{ij}^v \sim \mathcal{B}\left(p_{ij}^v\right)$。重加权因子的计算方式为：若 $s_{ij}^v = 1$，则 $\gamma_{ij}^v = \left(1 - s_{ij}^v\right) \cdot \gamma_{ij}^v$；否则 $\gamma_{ij}^v = 0$，其中 $s_{ij}^v = 1$ 的概率由 p_{ij}^v 决定。（此句按原文保留；其与式（14）的关系见文末译注。）

对于每个第 v 个视图，单层可学习 GNN 编码器 $f_\Theta(\cdot)$ 通过自适应结构聚合邻居嵌入，学习每个节点的嵌入，可总结为：

$$\boldsymbol{z}_i^v = \sigma(\mathbf{W}_{\text{in}}^\top \boldsymbol{x}_i), \tag{12}$$

$$\gamma_{i,j}^v = \text{softmax}(\sigma(\mathbf{W}^\top [\boldsymbol{z}_i^v || \boldsymbol{z}_j^v])) / \sqrt{d_i d_j}, \tag{13}$$

$$\gamma_{ij}^v = (1 - s_{ij}^v) \cdot \gamma_{ij}^v, \quad \text{s.t. } s_{ij}^v \in \{0, 1\} \tag{14}$$

$$\boldsymbol{z}_i^v = (1 - \beta) \sum_{j \in \mathcal{N}_i} \gamma_{i,j}^v \boldsymbol{z}_j^v + \beta \boldsymbol{z}_i^v, \tag{15}$$

其中，引入 $\left(1 - \beta\right)$ 以权衡自身特征与来自邻居的消息。所提出的自适应删边架构方法的优势可总结为：（1）删边预处理促进多视图一致性，确保视图间差异可控，与理论分析一致。（2）不同于固定结构，共享的可学习模型架构无需依赖先验知识，就能让每个视图自主适应，并发现适合其具体需求的最优结构。（3）删边操作与动态学习到的拓扑高度相关，从而能够与各个视图兼容。

3.4 邻域一致性多视图对比目标

被建模为图的多视图数据天然具有同质性等图性质，即相连节点往往具有相同标签。然而，式（1）的配对策略将来自同一样本的实例指定为正样本对，而将其他所有实例视为负样本，可能使通过一致性边连接的节点彼此分离。为解决这一问题，我们提出一种针对多视图图数据的邻域一致性对比目标，重新定义正负样本对的构造。具体而言，我们将锚节点在同一视图内以及不同视图中的一阶邻居纳入正样本，以扩展正样本集合。式（1）定义的第 i 个数据样本在第 v 和第 v' 个视图之间的损失也可以表示为：

$$\ell_{f_\Theta}(\boldsymbol{z}_i^v) = -\log \frac{\text{pos}_{f_\Theta(\boldsymbol{z}_i^v)}}{\text{pos}_{f_\Theta(\boldsymbol{z}_i^v)} + \text{neg}_{f_\Theta(\boldsymbol{z}_i^v)}}. \tag{16}$$

在所提出的对比目标中，基于一阶邻域重新构造正样本对和负样本对：

$$\mathrm{pos}_{f_\Theta}(\boldsymbol{z}_i^v) = \underbrace{\sum_{j\in\mathcal{N}_i^v} e^{\theta\left(\boldsymbol{z}_i^v,\boldsymbol{z}_j^v\right)/\tau}}_{\text{intra-view positive pairs}} + \underbrace{\sum_{j\in\{\mathcal{N}_i^{v'}\cup i\}} e^{\theta\left(\boldsymbol{z}_i^v,\boldsymbol{z}_j^{v'}\right)/\tau}}_{\text{inter-view positive pairs}}, \tag{17}$$

$$\mathrm{neg}_{f_\Theta}(\boldsymbol{z}_i^v) = \underbrace{\sum_{j\notin\{\mathcal{N}_i^v\cup i\}} e^{\theta\left(\boldsymbol{z}_i^v,\boldsymbol{z}_j^v\right)/\tau}}_{\text{intra-view negative pairs}} + \underbrace{\sum_{j\notin\{\mathcal{N}_i^{v'}\cup i\}} e^{\theta\left(\boldsymbol{z}_i^v,\boldsymbol{z}_j^{v'}\right)/\tau}}_{\text{inter-view negative pairs}}, \tag{18}$$

式（17）中的两项依次为视图内正样本对和视图间正样本对；式（18）中的两项依次为视图内负样本对和视图间负样本对。其中，$\mathcal{N}_i^v$、$\mathcal{N}_i^{v'}$ 分别为视图 v 和 v' 中节点 i 的邻居集合。具体而言，以 $\mathbf{z}_i^v$ 为锚点时，正样本对不仅来自另一视图 v' 中的实例 $\mathbf{z}_i^{v'}$，还分别包含同一视图内和跨视图的邻居，即 $\{\mathbf{z}_j^v \mid j \in \mathcal{N}_i^v\}$ 和 $\{\mathbf{z}_j^{v'} \mid j \in \mathcal{N}_i^{v'}\}$。自然地，视图 v 和 v' 中样本 i 的所有非邻居分别充当视图内和视图间负样本。通过邻域结构扩展正样本，能够充分利用拓扑信息，特别是一致性边，从而捕获视图内部及视图之间的一致性和互补性。

由于任何一个数据视图都可以视为另一个视图的语义增强，我们随机选择一个视图作为枢轴视图，记为 $\mathbf{z}^p$。以这种方式构造损失的原理详见附录 C。随后，总体损失实现为枢轴视图与其他视图之间损失之和，如下所示：

$$\mathcal{L} = \frac{1}{2V}\sum_{v=1,v\neq p}^{V} \ell_{f_\Theta}(\boldsymbol{z}_i^v, \boldsymbol{z}_i^p), \tag{19}$$

$$\ell_{f_\Theta}(\boldsymbol{z}_i^v, \boldsymbol{z}_i^p) = \frac{1}{2N}\sum_{i}^{N}(\ell_{f_\Theta}(\boldsymbol{z}_i^v), \ell_{f_\Theta}(\boldsymbol{z}_i^p)). \tag{20}$$

CAMEL 的算法过程见附录 A。

4 实验

4.1 实验设置

数据集。 为评估 CAMEL 的性能，我们在三类数据集上开展实验，包括四个多关系数据集（ACM、DBLP、IMDB、YELP）、两个多属性数据集（COIL20、NoisyMNIST），以及两个多模态数据集（Iaprtc12、NUS-Wide）。

对比方法。 我们将 CAMEL 与 21 种代表性方法进行比较，分类如下：（1）基线方法：GCN [Kipf and Welling, 2017] 和 SGC [Wu et al., 2019]；（2）异质方法：HAN [Wang et al., 2019]、DMGI [Park et al., 2020]、IGNN [Gu et al., 2020]、MRGCN [Huang et al., 2020]、SSDCM [Mitra et al., 2021]、MHGCN [Yu et al., 2022] 和 AMOGCN [Chen et al., 2024]；（3）多视图分类方法：ERL-MVSC [Huang et al., 2021]、Dynamics [Han et al., 2022]、PDMF [Xu et al., 2023]、IMvGCN [Wu et al., 2023a]、LGCN-FF [Chen et al., 2023a] 和 RCML [Xu et al., 2024]；（4）多视图聚类方法：OMSC [Chen et al., 2022]、SDSNE [Liu et al., 2022]、DSMVC [Tang and Liu, 2022]、FSMSC [Chen et al., 2023b]、RCAGL [Liu et al., 2024a] 和 SMVAGC [Wang et al., 2024]。

实验设置。 实现细节和参数设置见附录 D。

4.2 节点分类性能

本节研究半监督分类任务，评估 CAMEL 处理三类多视图图中复杂数据的有效性。

（1）多关系图。 四个多关系图在 20% 训练比例下的分类结果详见表 1。从这些结果可以看出，CAMEL 超过了大多数专为多关系数据设计的方法，证实了其有效性。此外，CAMEL 显著优于 GCN 和 SGC 等基线模型，说明静态架构难以应对复杂数据集固有的异质性。

Datasets	ACM		DBLP		IMDB		YELP	
# Nodes	3,025		4,057		4,780		2,614	
Metrics	Macro F1	Micro F1	Macro F1	Micro F1	Macro F1	Micro F1	Macro F1	Micro F1
GCN	76.7 (5.2)	78.0 (4.5)	90.7 (0.6)	91.4 (0.5)	23.6 (0.1)	54.6 (0.0)	55.5 (0.9)	74.0 (0.4)
SGC	67.5 (1.1)	70.2 (0.8)	66.3 (0.5)	81.5 (0.6)	27.0 (1.4)	54.8 (0.7)	51.9 (0.7)	67.4 (1.5)
HAN	87.9 (0.4)	88.0 (0.4)	89.3 (0.2)	90.4 (0.2)	24.0 (1.2)	55.9 (1.2)	55.3 (4.5)	68.0 (5.0)
DMGI	66.7 (1.8)	70.4 (1.1)	75.4 (1.3)	81.2 (0.7)	38.3 (3.1)	57.0 (0.4)	52.7 (2.3)	69.5 (0.7)
IGNN	82.9 (0.0)	82.7 (0.0)	86.8 (0.0)	87.5 (0.0)	45.3 (0.0)	54.8 (0.0)	71.4 (0.0)	75.0 (0.0)
MRGCN	87.6 (0.2)	87.5 (0.2)	89.5 (1.6)	90.5 (1.2)	45.2 (2.3)	47.7 (2.3)	54.4 (0.4)	73.7 (0.5)
SSDCM	84.3 (3.5)	85.2 (2.9)	87.7 (2.7)	88.8 (3.9)	35.3 (3.5)	50.8 (2.7)	55.9 (3.0)	68.9 (5.6)
MHGCN	88.8 (1.6)	89.1 (0.7)	**92.5 (0.3)**	**93.0 (0.2)**	**51.2 (1.3)**	**61.2 (1.3)**	60.9 (1.0)	73.3 (0.2)
AMOGCN	**91.4 (0.5)**	**90.0 (0.6)**	92.3 (0.4)	92.8 (0.4)	49.1 (0.8)	61.0 (1.3)	**71.8 (2.1)**	**77.4 (0.4)**
CAMEL	**93.1 (0.1)**	**92.2 (0.3)**	**93.1 (0.1)**	**93.6 (0.1)**	**50.2 (0.4)**	**61.3 (0.0)**	**91.3 (0.5)**	**90.1 (0.6)**

表 1：所有方法在多关系数据集上的宏平均 F1 和微平均 F1 分数。 最优结果以橙色突出显示，次优结果以蓝色突出显示。表头 Datasets＝数据集，# Nodes＝节点数，Metrics＝评价指标，Macro F1＝宏平均 F1，Micro F1＝微平均 F1。数据集名称与方法名称保留原文；全部数值、括号内数值和原文颜色完整保留。

（2）多属性与多模态图。 我们以 10% 的训练比例运行六种多视图分类方法，结果见表 2。可以观察到，基于图的方法在性能上占据主导地位，凸显了利用多视图样本之间关系信息对提升性能的重要作用。其中，CAMEL 借助先进的对比策略与模型架构，能够有效适应多视图数据的异质性，从而取得更优结果。

Datasets #Nodes	COIL20 1440		NoisyMNIST 15000		Iaprtc12 7855		NUS-Wide 20000	
Task	Node Classification							
Metrics	Macro F1	Micro F1	Macro F1	Micro F1	Macro F1	Micro F1	Macro F1	Micro F1
ERL-MVSC	87.1 (1.5)	87.4 (1.4)	89.4 (0.0)	89.3 (0.0)	**59.8 (0.8)**	**60.1 (1.2)**	51.2 (0.2)	51.3 (0.1)
Dynamics	70.7 (0.1)	71.6 (0.1)	70.4 (0.6)	72.8 (0.4)	50.1 (0.5)	50.8 (0.3)	60.5 (0.1)	62.7 (0.1)
PDMF	63.6 (1.7)	64.9 (1.7)	66.6 (1.9)	69.7 (1.3)	47.6 (2.6)	46.2 (2.2)	37.1 (1.5)	40.5 (1.3)
IMvGCN	71.3 (0.3)	70.9 (0.4)	86.3 (0.6)	86.0 (0.8)	52.9 (1.0)	53.6 (0.7)	51.9 (1.5)	53.2 (1.2)
LGCN-FF	**89.7 (0.4)**	**89.4 (0.3)**	**89.6 (0.5)**	**89.8 (0.5)**	59.3 (1.4)	57.8 (1.3)	OM	OM
RCML	64.0 (0.3)	66.3 (0.3)	84.5 (0.1)	85.2 (0.1)	39.4 (0.2)	40.7 (0.2)	**54.2 (0.7)**	**56.8 (0.4)**
CAMEL	**92.5 (0.3)**	**92.4 (0.3)**	**91.9 (1.7)**	**92.2 (1.6)**	**61.6 (0.5)**	**60.7 (0.3)**	**69.2 (0.6)**	**69.6 (0.2)**
Task	Node Clustering							
Metrics	ACC	NMI	ACC	NMI	ACC	NMI	ACC	NMI
OMSC	52.0 (2.1)	71.4 (2.4)	49.6 (0.9)	44.3 (1.7)	**44.9 (1.4)**	22.9 (0.6)	36.3 (1.1)	21.6 (1.4)
SDSNE	64.2 (3.0)	77.8 (2.3)	40.0 (11.7)	51.1 (16.7)	36.3 (2.9)	19.4 (3.7)	25.9 (5.9)	19.0 (6.9)
DSMVC	66.7 (3.9)	79.3 (1.5)	33.5 (3.2)	26.6 (3.3)	35.1 (1.9)	14.3 (1.4)	29.7 (1.9)	13.9 (1.4)
FSMSC	**74.7 (1.4)**	**82.8 (0.7)**	**55.5 (0.7)**	**51.3 (1.1)**	44.6 (0.8)	22.2 (0.6)	37.3 (0.2)	21.7 (0.1)
RCAGL	66.8 (0.9)	81.2 (0.5)	55.2 (1.4)	49.8 (1.7)	43.6 (0.6)	**24.7 (0.5)**	**40.2 (0.7)**	**23.5 (0.4)**
SMVAGC	65.0 (4.2)	79.1 (1.7)	53.9 (2.4)	46.2 (1.1)	39.2 (0.8)	17.7 (0.4)	36.1 (2.3)	22.9 (0.9)
CAMEL	**78.7 (0.3)**	**86.2 (0.2)**	**84.8 (1.4)**	**81.7 (2.5)**	**45.3 (1.3)**	**25.4 (1.1)**	**42.4 (0.6)**	**26.1 (1.2)**

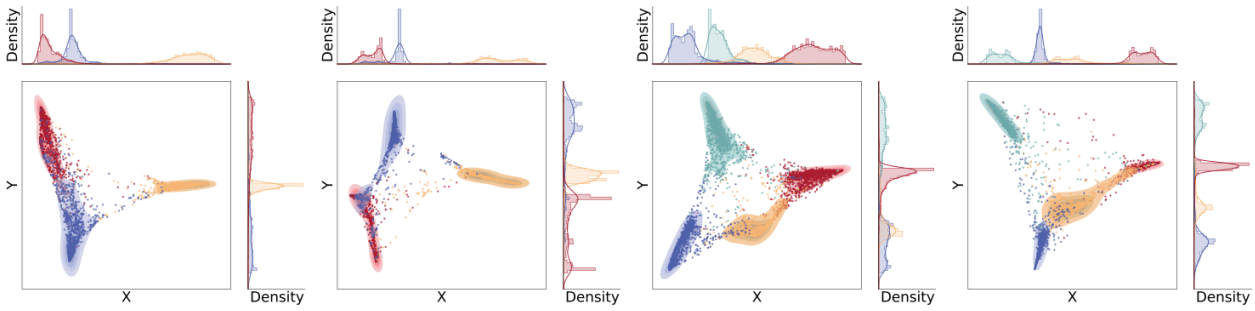
表 2：在多属性和多模态数据集上，节点分类任务的宏平均 F1、微平均 F1，以及节点聚类任务的 ACC 和 NMI。 最优结果以橙色突出显示，次优结果以蓝色突出显示。表头 Datasets＝数据集，#Nodes＝节点数，Task＝任务，Node Classification＝节点分类，Node Clustering＝节点聚类，Metrics＝评价指标，Macro F1＝宏平均 F1，Micro F1＝微平均 F1；ACC 为聚类准确率，NMI 为归一化互信息。表中 OM 按原文保留，原文没有解释该缩写。全部数值和括号内数值直接保留原稿。

4.3 节点聚类性能

本节在多属性数据集 COIL20、NoisyMNIST，以及多模态数据集 Iaprtc12、NUS-wide 上评估节点聚类性能。表 2 表明，CAMEL 在 ACC 和 NMI 两项指标上均大幅超过最先进的聚类方法，证实了所提对比范式能够生成可区分的表示。优越的聚类结果主要源于 CAMEL 增强了远离估计决策边界的节点对之间的连接密度，从而有助于形成紧凑、边界清晰的簇。

4.4 可视化

除定量分析外，我们还采用 t-SNE [Van der Maaten L, 2008]，在图 2 中可视化了具有竞争力的基线算法 AMOGCN 和所提方法 CAMEL 在 ACM、DBLP 数据集上得到的表示。彩色阴影区域内的等高线表示不同类别的密度水平。此外，每幅图顶部和右侧的直方图分别展示了经 t-SNE 变换的数据在 X 轴和 Y 轴上的分布。从可视化结果可以观察到，与 AMOGCN 相比，CAMEL 产生的嵌入具有明显更清晰的类别边界和更紧密的类内聚合。这种区别在密度图中也可见：CAMEL 嵌入的类别重叠更少，每个类别分布中的峰值更鲜明。直方图进一步补充了这些发现，显示出沿两条坐标轴更明显的分离。这些结果表明，CAMEL 擅长学习高质量节点表示，其生成的表示具有边界明确且相互分离的类别簇。

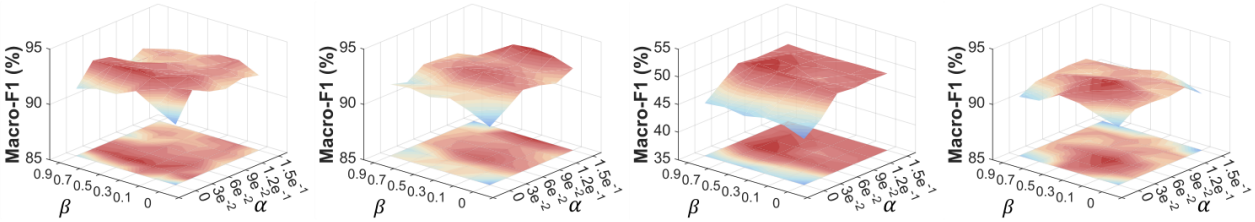


(a) $\text{ACM}_{\text{AMOGCN}}$ (b) $\text{ACM}_{\text{CAMEL}}$ (c) $\text{DBLP}_{\text{AMOGCN}}$ (d) $\text{DBLP}_{\text{CAMEL}}$

图 2：ACM 和 DBLP 数据集上所学习表示的 t-SNE 可视化。 每个节点根据其标签着色。（a）ACM 上的 AMOGCN；（b）ACM 上的 CAMEL；（c）DBLP 上的 AMOGCN；（d）DBLP 上的 CAMEL。Density＝密度，X、Y 为 t-SNE 坐标轴。

4.5 超参数分析

本小节进行参数敏感性分析，探究式（11）中的 α 和式（15）中的 β 对模型性能的影响。具体而言，α 调节自适应删边概率，而 β 调节可学习 GNN 编码器中自身特征与邻居消息之间的平衡。总体上，在各数据集上，α 取中间范围的值时性能达到峰值，表明适度删边能够有效捕获关键语义信息，促进多视图数据的一致性学习。随着 α 和 β 的取值变化，大多数数据集上的性能波动保持稳定，反映出 CAMEL 框架对参数变化不敏感。值得注意的是，当 α 和 β 分别设为零时，性能均不是最优，尤其是在 IMDB 上；这凸显了自适应删边架构对优化模型效能的关键作用。



(a) ACM (b) DBLP (c) IMDB (d) YELP

图 3：所有多关系数据集上的参数敏感性。 （a）ACM；（b）DBLP；（c）IMDB；（d）YELP。纵轴 Macro-F1 (%)＝宏平均 F1（百分比）；水平轴分别为 α 与 β，刻度与曲面保留原文。

4.6 消融研究

为评估 CAMEL 各组成部分的重要性，我们通过移除关键要素开展消融实验：删边（记为 E）、自适应删边架构（记为 AE），以及邻域一致性多视图对比目标（记为 N）。具体而言，为评估自适应删边架构，我们将编码器替换为普通 GCN；为评估对比目标，我们采用经典 GCL 方法 GRACE [Zhu et al., 2020] 的对比损失。实验结果见图 4。值得注意的是，移除自适应删边架构（w/o AE）会导致性能急剧下降，凸显了可学习架构适应异质视图的优势。其次，缺少删边预处理或对比目标也会引起一定程度的性能下降。总体而言，CAMEL 始终优于各个变体，验证了其有效利用跨视图一致性与互补性的能力。

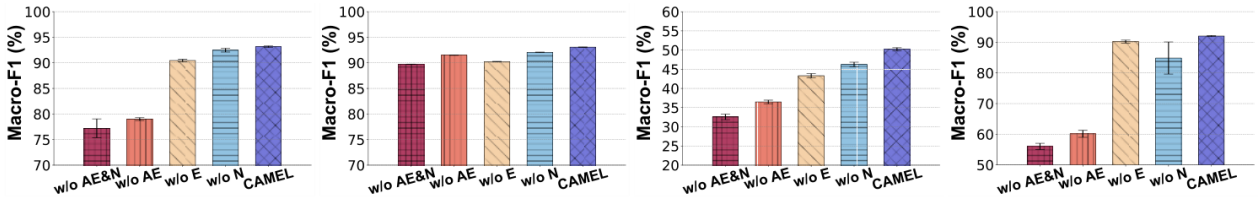


图 4：消融研究（均值百分比与标准差百分比）。 （a）ACM；（b）DBLP；（c）IMDB；（d）YELP。纵轴 Macro-F1 (%)＝宏平均 F1（百分比）。横轴 w/o AE&N＝不使用 AE 和 N；w/o AE＝不使用自适应删边架构；w/o E＝不使用删边；w/o N＝不使用邻域一致性对比目标；CAMEL＝完整方法。

5 结论

本文揭示了多视图图对比学习需要预处理，并通过数学推导支持删边策略对一致性的促进作用。受这些发现启发，我们提出了名为 CAMEL 的多视图对比范式，通过协同增强策略与架构来学习一致性表示。在策略层面，所提出的动态拓扑引导的自适应删边预处理策略与邻域一致性对比目标，能够有效提取多视图数据中的一致性信息。在架构层面，可学习 GNN 编码器提高了对不同视图的适应能力。在多个数据集上开展的大量实验验证了 CAMEL 的优越性。

致谢

本工作得到国家重点研发计划（2023YFE0111100）以及国家自然科学基金项目（62202104、U2441239）的部分资助。

参考文献

以下保留原文全部书目信息与引文键，题名后附中文译名。原文中重复的条目、作者排列和出版信息不作静默更正。

[Bu et al., 2024] Weixin Bu, Xiaofeng Cao, Yizhen Zheng, and Shirui Pan. Improving augmentation consistency for graph contrastive learning. Pattern Recognition, 148:110182, 2024. 题名译文：《提升图对比学习的增强一致性》。

[Chen et al., 2022] Man-Sheng Chen, Chang-Dong Wang, Dong Huang, Jian-Huang Lai, and Philip S Yu. Efficient orthogonal multi-view subspace clustering. In SIGKDD, pages 127-135, 2022. 题名译文：《高效正交多视图子空间聚类》。

[Chen et al., 2023a] Zhaoliang Chen, Lele Fu, Jie Yao, Wenzhong Guo, Claudia Plant, and Shiping Wang. Learnable graph convolutional network and feature fusion for multi-view learning. Information Fusion, 95:109-119, 2023. 题名译文：《用于多视图学习的可学习图卷积网络与特征融合》。

[Chen et al., 2023b] Zhe Chen, Xiao-Jun Wu, Tianyang Xu, and Josef Kittler. Fast self-guided multi-view subspace clustering. IEEE TIP, 32:6514-6525, 2023. 题名译文：《快速自引导多视图子空间聚类》。

[Chen et al., 2024] Zhaoliang Chen, Zhihao Wu, Luying Zhong, Claudia Plant, Shiping Wang, and Wenzhong Guo. Attributed multi-order graph convolutional network for heterogeneous graphs. Neural Networks, page 106225, 2024. 题名译文：《面向异质图的属性多阶图卷积网络》。

[Fu et al., 2023] Lele Fu, Zhaoliang Chen, Yongyong Chen, and Shiping Wang. Unified low-rank tensor learning and spectral embedding for multi-view subspace clustering. IEEE TMM, 25:4972-4985, 2023. 题名译文：《用于多视图子空间聚类的统一低秩张量学习与谱嵌入》。

[Gu et al., 2020] Fangda Gu, Heng Chang, Wenwu Zhu, Somayeh Sojoudi, and Laurent El Ghaoui. Implicit graph nn. In NeurIPS, 2020. 题名译文：《隐式图神经网络》。

[Han et al., 2022] Zongbo Han, Fan Yang, Junzhou Huang, Changqing Zhang, and Jianhua Yao. Multimodal dynamics: Dynamical fusion for trustworthy multimodal classification. In CVPR, pages 20707-20717, 2022. 题名译文：《多模态动态机制：面向可信多模态分类的动态融合》。

[Huang et al., 2020] Zhichao Huang, Xutao Li, Yunming Ye, and Michael K. Ng. MR-GCN: multi-relational graph convolutional networks based on generalized tensor product. In IJCAI, pages 1258-1264, 2020. 题名译文：《MR-GCN：基于广义张量积的多关系图卷积网络》。

[Huang et al., 2021] Aiping Huang, Zheng Wang, Yannan Zheng, Tiesong Zhao, and Chia-Wen Lin. Embedding regularizer learning for multi-view semi-supervised classification. IEEE TIP, 30:6997-7011, 2021. 题名译文：《用于多视图半监督分类的嵌入正则化器学习》。

[Huang et al., 2023] Zongmo Huang, Yazhou Ren, Xiaorong Pu, Shudong Huang, Zenglin Xu, and Lifang He. Self-supervised graph attention networks for deep weighted multi-view clustering. In AAAI, volume 37, pages 7936- 7943, 2023. 题名译文：《用于深度加权多视图聚类的自监督图注意力网络》。

[In et al., 2023] Yeonjun In, Kanghoon Yoon, and Chanyoung Park. Similarity preserving adversarial graph contrastive learning. In SIGKDD, pages 867-878, 2023. 题名译文：《保持相似性的对抗图对比学习》。

[Kipf and Welling, 2017] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In ICLR, 2017. 题名译文：《采用图卷积网络的半监督分类》。

[Koromilas et al., 2024] Panagiotis Koromilas, Giorgos Bouritsas, Theodoros Giannakopoulos, Mihalis Nicolaou, and Yannis Panagakis. Bridging mini-batch and asymptotic analysis in contrastive learning: From infonce to kernel-based losses. In ICML, 2024. 题名译文：《衔接对比学习中的小批量分析与渐近分析：从 InfoNCE 到基于核的损失》。

[Li et al., 2023] Wen-Zhi Li, Chang-Dong Wang, Jian-Huang Lai, and S Yu Philip. Towards effective and robust graph contrastive learning with graph autoencoding. IEEE TKDE, 36(2):868-881, 2023. 题名译文：《借助图自编码实现有效且鲁棒的图对比学习》。

[Liang et al., 2022] Weixuan Liang, Xinwang Liu, Sihang Zhou, Jiyuan Liu, Siwei Wang, and En Zhu. Robust graph-based multi-view clustering. In AAAI, volume 36, pages 7462-7469, 2022. 题名译文：《鲁棒的基于图的多视图聚类》。

[Liu et al., 2022] Chenghua Liu, Zhuolin Liao, Yixuan Ma, and Kun Zhan. Stationary diffusion state neural estimation for multiview clustering. In AAAI, volume 36, pages 7542- 7549, 2022. 题名译文：《用于多视图聚类的稳态扩散状态神经估计》。

[Liu et al., 2023a] Jiyuan Liu, Xinwang Liu, Yuexiang Yang, Qing Liao, and Yuanqing Xia. Contrastive multi-view kernel learning. IEEE TPAMI, 45(8):9552-9566, 2023. 题名译文：《对比多视图核学习》。

[Liu et al., 2023b] Jiyuan Liu, Xinwang Liu, Yuexiang Yang, Qing Liao, and Yuanqing Xia. Contrastive multi-view kernel learning. IEEE TPAMI, 45(8):9552-9566, 2023. 题名译文：《对比多视图核学习》。

[Liu et al., 2024a] Suyuan Liu, Qing Liao, Siwei Wang, Xinwang Liu, and En Zhu. Robust and consistent anchor graph learning for multi-view clustering. IEEE TKDE, 2024. 题名译文：《用于多视图聚类的鲁棒且一致的锚点图学习》。

[Liu et al., 2024b] Yixin Liu, Shiyuan Li, Yu Zheng, Qingfeng Chen, Chengqi Zhang, and Shirui Pan. Arc: A generalist graph anomaly detector with in-context learning. In NeurIPS, volume 37, pages 50772-50804, 2024. 题名译文：《Arc：采用上下文学习的通用图异常检测器》。

[Lu et al., 2024] Jielong Lu, Zhihao Wu, Luying Zhong, Zhaoliang Chen, Hong Zhao, and Shiping Wang. Generative essential graph convolutional network for multi-view semi-supervised classification. IEEE TMM, 26:7987- 7999, 2024. 题名译文：《用于多视图半监督分类的生成式本质图卷积网络》。

[Mitra et al., 2021] Anasua Mitra, Priyesh Vijayan, Sanasam Ranbir Singh, Diganta Goswami, Srinivasan Parthasarathy, and Balaraman Ravindran. Semi-supervised deep learning for multiplex networks. In SIGKDD, pages 1234-1244, 2021. 题名译文：《面向多层网络的半监督深度学习》。

[Oord et al., 2018] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748, 2018. 题名译文：《采用对比预测编码的表示学习》。

[Park et al., 2020] Chanyoung Park, Donghyun Kim, Jiawei Han, and Hwanjo Yu. Unsupervised attributed multiplex network embedding. In AAAI, pages 5371-5378, 2020. 题名译文：《无监督属性多层网络嵌入》。

[Shen et al., 2023] Xiao Shen, Dewang Sun, Shirui Pan, Xi Zhou, and Laurence T Yang. Neighbor contrastive learning on learnable graph augmentation. In AAAI, volume 37, pages 9782-9791, 2023. 题名译文：《基于可学习图增强的邻居对比学习》。

[Su et al., 2024] Peng Su, Yixi Liu, Shujian Li, Shudong Huang, and Jiancheng Lv. Robust contrastive multi-view kernel clustering. In IJCAI, pages 4938-4945, 2024. 题名译文：《鲁棒对比多视图核聚类》。

[Sun et al., 2024] Yuan Sun, Yang Qin, Yongxiang Li, Dezhong Peng, Xi Peng, and Peng Hu. Robust multi-view clustering with noisy correspondence. IEEE TKDE, 36(12):9150-9162, 2024. 题名译文：《具有噪声对应关系的鲁棒多视图聚类》。

[Tang and Liu, 2022] Huayi Tang and Yong Liu. Deep safe multi-view clustering: Reducing the risk of clustering performance degradation caused by view increase. In CVPR, pages 202-211, 2022. 题名译文：《深度安全多视图聚类：降低因视图增加而导致聚类性能退化的风险》。

[Tu et al., 2025] Wenxuan Tu, Sihang Zhou, Xinwang Liu, Zhiping Cai, Yawei Zhao, Yue Liu, and Kunlun He. Wage: Weight-sharing attribute-missing graph autoencoder. IEEE TPAMI, 47(7):5760-5777, 2025. 题名译文：《Wage：权重共享的属性缺失图自编码器》。

[Van der Maaten L, 2008] Hinton G Van der Maaten L. Visualizing data using t-sne. Journal of Machine Learning Research, 2008. 题名译文：《使用 t-SNE 可视化数据》。

[Velickovic et al., 2019] Petar Velickovic, William Fedus, William L Hamilton, Pietro Liò, Yoshua Bengio, and R Devon Hjelm. Deep graph infomax. In ICLR, 2019. 题名译文：《深度图互信息最大化》。

[Wan et al., 2024a] Xinhang Wan, Jiyuan Liu, Hao Yu, Qian Qu, Ao Li, Xinwang Liu, Ke Liang, Zhibin Dong, and En Zhu. Contrastive continual multiview clustering with filtered structural fusion. IEEE TNNLS, pages 1-14, 2024. 题名译文：《采用过滤式结构融合的对比持续多视图聚类》。

[Wan et al., 2024b] Xinhang Wan, Bin Xiao, Xinwang Liu, Jiyuan Liu, Weixuan Liang, and En Zhu. Fast continual multi-view clustering with incomplete views. IEEE TIP, 33:2995-3008, 2024. 题名译文：《具有不完整视图的快速持续多视图聚类》。

[Wang et al., 2019] Xiao Wang, Houye Ji, Chuan Shi, Bai Wang, Yanfang Ye, Peng Cui, and Philip S Yu. Heterogeneous graph attention network. In WWW, pages 2022- 2032, 2019. 题名译文：《异质图注意力网络》。

[Wang et al., 2021] Qianqian Wang, Zhengming Ding, Zhiqiang Tao, Quanxue Gao, and Yun Fu. Generative partial multi-view clustering with adaptive fusion and cycle consistency. IEEE TIP, 30:1771-1783, 2021. 题名译文：《采用自适应融合与循环一致性的生成式部分多视图聚类》。

[Wang et al., 2023] Zehong Wang, Qi Li, Donghua Yu, Xiaolong Han, Xiao-Zhi Gao, and Shigen Shen. Heterogeneous graph contrastive multi-view learning. In SDM, pages 136-144, 2023. 题名译文：《异质图对比多视图学习》。

[Wang et al., 2024] Siwei Wang, Xinwang Liu, Suyuan Liu, Wenxuan Tu, and En Zhu. Scalable and structural multi-view graph clustering with adaptive anchor fusion. IEEE TIP, 2024. 题名译文：《采用自适应锚点融合的可扩展结构化多视图图聚类》。

[Wu et al., 2019] Felix Wu, Amauri H. Souza Jr., Tianyi Zhang, Christopher Fifty, Tao Yu, and Kilian Q. Weinberger. Simplifying graph convolutional networks. In ICML, volume 97, pages 6861-6871, 2019. 题名译文：《简化图卷积网络》。

[Wu et al., 2022] Chuhan Wu, Fangzhao Wu, and Yongfeng Huang. Rethinking infonce: How many negative samples do you need? In IJCAI, pages 2509-2515, 2022. 题名译文：《重新思考InfoNCE：你需要多少负样本》。

[Wu et al., 2023a] Zhihao Wu, Xincan Lin, Zhenghong Lin, Zhaoliang Chen, Yang Bai, and Shiping Wang. Interpretable graph convolutional network for multi-view semi-supervised learning. IEEE TMM, 25:8593-8606, 2023. 题名译文：《用于多视图半监督学习的可解释图卷积网络》。

[Wu et al., 2023b] Zhihao Wu, Zhao Zhang, and Jicong Fan. Graph convolutional kernel machine versus graph convolutional networks. In NeurIPS, volume 36, pages 19650- 19672, 2023. 题名译文：《图卷积核机与图卷积网络的比较》。

[Wu et al., 2024] Zhihao Wu, Zhaoliang Chen, Shide Du, Sujia Huang, and Shiping Wang. Graph convolutional network with elastic topology. Pattern Recognition, 151:110364, 2024. 题名译文：《具有弹性拓扑的图卷积网络》。

[Xu et al., 2023] Cai Xu, Wei Zhao, Jinglong Zhao, Ziyu Guan, Yaming Yang, Long Chen, and Xiangyu Song. Progressive deep multi-view comprehensive representation learning. In AAAI, volume 37, pages 10557-10565, 2023. 题名译文：《渐进式深度多视图综合表示学习》。

[Xu et al., 2024] Cai Xu, Jiajun Si, Ziyu Guan, Wei Zhao, Yue Wu, and Xiyue Gao. Reliable conflictive multi-view learning. In AAAI, volume 38, pages 16129-16137, 2024. 题名译文：《可靠的冲突多视图学习》。

[Xu et al., 2025a] Shilin Xu, Yuan Sun, Xingfeng Li, Siyuan Duan, Zhenwen Ren, Zheng Liu, and Dezhong Peng. Noisy label calibration for multi-view classification. In Toby Walsh, Julie Shah, and Zico Kolter, editors, AAAI, pages 21797-21805, 2025. 题名译文：《用于多视图分类的噪声标签校准》。

[Xu et al., 2025b] Yanchen Xu, Siqi Huang, Hongyuan Zhang, and Xuelong Li. Why does dropping edges usually outperform adding edges in graph contrastive learning? In AAAI, volume 39, pages 21824-21832, 2025. 题名译文：《为什么在图对比学习中删边通常优于加边》。

[Yu et al., 2022] Pengyang Yu, Chaofan Fu, Yanwei Yu, Chao Huang, Zhongying Zhao, and Junyu Dong. Multiplex heterogeneous graph convolutional network. In SIGKDD, pages 2377-2387, 2022. 题名译文：《多层异质图卷积网络》。

[Zhang et al., 2025] Chao Zhang, Deng Xu, Chunlin Chen, and Huaxiong Li. Semi-supervised multi-view clustering with active constraints. In SIGKDD, pages 1903-1912, 2025. 题名译文：《具有主动约束的半监督多视图聚类》。

[Zhu et al., 2020] Yanqiao Zhu, Yichen Xu, Feng Yu, Qiang Liu, Shu Wu, and Liang Wang. Deep graph contrastive representation learning. arXiv preprint arXiv:2006.04131, 2020. 题名译文：《深度图对比表示学习》。

[Zhuang et al., 2024] Shuman Zhuang, Sujia Huang, Wei Huang, Yuhong Chen, Zhihao Wu, and Ximeng Liu. Enhancing multi-view graph neural network with cross-view confluent message passing. In ACM MM, pages 10065- 10074, 2024. 题名译文：《通过跨视图汇流消息传递增强多视图图神经网络》。

[Zhuang et al., 2025] Shuman Zhuang, Zhihao Wu, Zhaoliang Chen, Hong-Ning Dai, and Ximeng Liu. Refine then classify: Robust graph nn with reliable neighborhood contrastive refinement. In AAAI, volume 39, pages 13473- 13482, 2025. 题名译文：《先精炼再分类：采用可靠邻域对比精炼的鲁棒图神经网络》。

译注（不属于原文）

1. **输入范围**。 上传文件共 9 页，含正文、致谢和参考文献，未附原文所引用的附录 A（算法）、B（推导）、C（损失原理）、D（实现与参数）。本译文保留交叉引用，但不补写未提供的附录。文件标识 MVGCP 与正文方法名 CAMEL 均按来源保留。
2. **公式**。 20 个编号公式均采用原稿裁图。式（1）最后一个指数项印为乘以温度参数，而前两项为除以温度参数；式（20）两个损失之间印为逗号而非加号，原有归一化系数也完整保留。非一致性边集与完整边集的不同字体及引理 1 后印出的属于符号，均不自行更正。
3. **掩码**。 第 3.3 节写道，掩码为 1 时权重乘以“1 减掩码”，否则置零；按字面两种情况均为零，与式（14）掩码为 0 时保留权重不一致。译文照录文字与公式，不擅自修正。
4. **条件和符号**。 原文关于删边收益的讨论以非一致性信息比例小于 0.5 为条件；本译文不将其扩展为无条件保证。第 3.1 节节点数记为 n，式（20）使用 N，附近正文未另作定义。
5. **引文和实验**。 第 2.2 节将对比多视图核归于 [Shen et al., 2023]，但该条目题名为邻居对比学习；[Liu et al., 2023a] 与 [Liu et al., 2023b] 为原文重复条目。表 1 中 CAMEL 的 IMDB Macro F1 并非最优，表 2 中 Iaprtc12 ACC 的改进较小；作者的概括性表述须结合逐项数值理解。表 2 的 OM 原文未解释，译文不推断。
6. **书目**。 作者姓名保留拉丁字母，全部 52 条文献保留作者、英文题名、出处与出版信息，并附中文题名；包括 [Van der Maaten L, 2008] 在内的原有书目格式不作静默修订。