图与异质性相遇：多视图协同图专家

Where Graph Meets Heterogeneity: Multi-View Collaborative Graph Experts

NeurIPS 2025 · 中文翻译版（论文正文）

作者：Zhihao Wu, Jinyu Cai, Yunhe Zhang, Jielong Lu, Zhaoliang Chen, Shuman Zhuang, Haishuai Wang

说明：本文件按原论文正文结构翻译摘要、引言、相关工作、方法、实验、结论与致谢；参考文献和 NeurIPS Paper Checklist 未逐条翻译。公式按原文重新排版，不额外加入对论文方法的改写或延伸解释。

摘要

图学习与多视图学习的融合推动了多视图图神经网络（Multi-view Graph Neural Networks,MGNNs）的发展，使其能够有效处理由异质且相互连接的信息构成的复杂现实数据。尽管现有 MGNN 已经能够利用多视图图的潜力，但多视图学习中的两个关键归纳偏置——一致性（consistency）与互补性（complementarity）——之间仍存在内在冲突。因此，在多视图图这一新场景下，如何界定并解决这种矛盾，仍缺乏充分研究。

为弥补这一空缺，本文提出多视图协同图专家（Multi-view Collaborative Graph Experts,MvCGE），一个基于混合专家（Mixture-of-Experts, MoE）范式的新框架。MvCGE 通过共享参数建立架构层面的一致性，同时利用逐层协同图专家保留不同视图的互补信息；这些专家由图感知路由机制根据各视图的结构特征动态激活。

此外，本文提出负载均衡损失以防止专家坍塌并促进均衡专门化，又提出基于分布差异的图差异损失，以增强不同专家及视图之间的互补性。多个数据集上的大量实验表明，MvCGE 取得了优越性能。

引言 1

随着数据采集和分析能力的发展，现代数据不再被视为孤立的单一对象。实体之间广泛存在复杂关系，图作为一种通用结构，能够有效刻画这类依赖关系，并已成为机器学习中重要的表示工具。与此同时，现实数据还往往来自多个异质信息源，即不同视图。例如，在社交网络中，同一用户可能具有好友关系和行为交互等不同类型的关系；在多媒体系统中，同一对象也可能由视觉特征和语义标签等多种模态描述。

多视图学习通常建立在两个核心性质之上。其一是互补性：不同视图提供各自独有的信息；其二是一致性：不同视图虽然形式不同，但它们描述的是同一批底层实体，因此存在共同信息。这两种性质共同支撑了多视图学习相较单视图学习的优势，但二者也可能发生冲突。过度强调独特信息或共享信息，都会削弱多视图学习的优势，因此如何在二者之间取得平衡一直是关键问题。

近年来，图神经网络（GNN）快速发展。多视图 GNN（MGNN）显式地将异质信息建模为多视图图，并使用现代 GNN 架构进行学习。虽然图结构为不同信息源提供了一个统一的建模基础，但多视图学习中的一致性—互补性矛盾仍然存在。

现有 MGNN 大致有两条路线。第一类使用统一共享模型处理所有视图，通过共享权重自然增强视图间协作和一致性，但这种做法可能过度强调一致性，损失视图特有信息；从图信号处理角度看，同一个图滤波器也未必适合结构差异很大的多个视图。第二类采用多通道结构，为不同视图设置独立参数，以增强互补性，但视图间交互通常只发生在后期融合阶段，可能削弱内在的跨视图协作，并且模型结构会随着视图数量线性增长。

因此本文关注的问题是：如何设计一种合理的 MGNN 范式，在多视图图场景中更灵活地平衡一致性与互补性？

本文提出 MvCGE。其核心做法是：在每一层中设置多个共享的图专家（graph experts），并通过图感知路由器，根据每个视图和节点的结构特征动态选择合适的专家组合。专家库在各视图之间共享，从而保留架构一

致性；而不同样本/视图可以激活不同专家组合，从而保留视图特有信息。专家数量 M 与视图数量 V 解耦，使模型具有更强的灵活性。

为防止多个专家最终只剩少数专家被频繁使用，本文设计负载均衡损失；为防止不同专家虽然都被使用却学习到几乎相同的表示，又设计图差异损失，使不同专家学习到更有差异性的潜在空间。

本文的主要贡献可概括为：

系统分析现有 MGNN 范式，指出共享模型和完全视图独立模型都难以灵活适配异质多视图图结构。

提出基于 MoE 的 MvCGE 框架，在架构一致性与视图互补性之间建立更灵活的折中。

提出负载均衡与图差异两种机制，从专家使用频率与潜在表示空间两个角度缓解模型坍塌。

在单视图和多视图图数据集上进行了实验，验证了方法的有效性和泛化能力。

2 相关工作

2.1 多视图学习

多视图学习利用多个视角的信息提升学习性能，其中一致性用于捕获不同视图之间的共享信息，互补性用于利用各视图的独特贡献。图结构因能够刻画非欧式关系而被广泛用于多视图学习，例如自动加权多视图图、利用图增强不完整多视图学习、利用图细化跨视图对应关系等。但传统方法往往没有充分利用现代深度图学习能力。

混合专家（MoE）2.2MoE 的基本思想是由多个专门化模型共同解决复杂任务，并通过路由机制动态组合专家。现代 MoE 已广泛用于视觉和语言模型，但在多视图学习中的潜力仍未被充分探索；图 MoE 研究也仍处于早期阶段，针对多视图图的研究尤其有限。

2.3 GNN 图神经网络与多视图

GNN 可大致分为谱域与空间域方法。GCN 在二者之间建立了经典联系。多视图 GNN 通常遵循两种模式：要么让多个视图共享参数，从而保证一致性；要么采用多通道、视图独立的参数，从而保留互补信息。这两种模式分别容易走向“过度一致”与“过度独立”的极端。

方法 3

3.1 记号

定义带属性图 G=(V,E,X)，其中 V 为节点集合，|V|=N；E 为边集合；A∈{0,1}^{N×N}为邻接矩阵；X∈R^{N×D}为节点特征矩阵。度矩阵记为 D，图拉普拉斯矩阵可写为 L=D−A，或其对称归一化形式 L=I−D^{-1/2}AD^{-1/2}。

多视图图由{G_v : v∈[V]}构成，不同视图共享同一节点集合，但具有不同的边结构 E_v /邻接矩阵 A_v，本文记 G_v=(V,E_v,X)。

3.2 动机：共享图滤波器为什么不够

图拉普拉斯可分解为 $L=U\Lambda U^T$，其特征向量对应图傅里叶基，特征值对应图频率。一般的图卷积层可写为：

$$\hat{\mathbf{X}} = f_\Theta(\mathcal{G}, \mathbf{X}), \quad \text{（式 1）}$$

早期谱域 GNN 使用参数化图滤波器 hΘ(L)X，后续方法常用多项式近似，例如：

$$f_\Theta(\mathcal{G},\mathbf{X}) = \sum_{t=0}^{T} \quad \theta_t \mathbf{L}^t \mathbf{X}, \quad （式 2）$$

多层 GNN 的递推形式可写为：

$$\mathbf{H}^{(l+1)} = f_{\Theta^{(l)}}(\mathcal{G},\mathbf{H}^{(l)}), \quad （式 3）$$

如果不同视图共享同一个图滤波器，可以自然增强一致性，但当不同视图的图结构差异较大时，一个滤波器难以同时适配多个异质图。相反，为每个视图单独配置滤波器虽然更能保留互补性，却牺牲了架构层面的共享与交互，而且模型规模会随视图数增长。

3.3 整体框架

对于第 v 个视图，第 l 层的表示更新写为：

$$\mathbf{H}_v^{(l+1)} = \mathcal{F}_{\Phi^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)}), \quad （式 4）$$

其中 F(Φ)⁽ˡ⁾不是单一图卷积，而是由多个图专家共同组成，并由路由函数 R(Ψ)⁽ˡ⁾选择和组合：

$$\mathcal{F}_{\Phi^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)}) = \mathcal{R}_{\Psi^{(l)}}(\{f_{\Theta_m^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)}) : m \in [M]\}), \quad （式 5）$$

在整个网络中，各层 F(Φ)⁽ˡ⁾串联构成 F(Φ)。各视图分别得到最终表示 H_v，之后通过多视图聚合函数 A(Ξ)得到整体表示 H：

$$\mathbf{H} = \mathcal{A}_\Xi(\{\mathbf{H}_v = \mathcal{F}_\Phi(\mathcal{G}_v,\mathbf{X}) : v \in [V]\}), \quad （式 6）$$

各层逐层函数复合为：

$$\mathcal{F}_\Phi := \mathcal{F}_{\Phi^{(0)}} \circ \cdots \circ \mathcal{F}_{\Phi^{(l)}} \circ \cdots \circ \mathcal{F}_{\Phi^{(L-1)}}, \quad （式 7）$$

关键点是：F(Φ)在所有视图之间共享，因此所有专家与路由器都共同从多个视图中学习，形成架构层面的一致性；同时，每层包含 M 个不同参数的图专家，使模型可以根据具体视图和节点选择不同的处理方式，从而保留互补性。此外，专家数 M 与视图数 V 相互独立。

3.4 逐层协同图专家

对于第 v 个视图、第 l 层的第 i 个节点，MvCGE 将多个专家输出按路由权重进行加权：

$$[\mathbf{H}_v^{(l+1)}]_{i,:} = \sum_{m\in[M]} \quad [\mathbf{\Gamma}_v^{(l)}]_{i,m} f_{\Theta_m^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)})_{i,:}, \quad （式 8）$$

其中 $\Gamma_v^{(l)} \in R^{\{N\times M\}}$是路由矩阵，表示每个节点对各个专家的权重。因此，每一层都可以被视为一个独立的 MoE，由自己的 router 控制。

3.5 图感知 Top-K 路由

Top-K 图感知路由器的目标是在每个视图中，为每个节点选择合适的专家组合。首先，router 为节点 i 产生 M 维门控分数，然后只保留 Top-K 个专家，其余专家分数置为−∞，最后对保留项做 Softmax。

为使 router 不只依赖节点本身，而能感知图结构与视图级信息，作者将两个上下文拼接：

$$[\mathbf{\Gamma}_v^{(l)}]_{i,m} = Softmax(g_{\Psi^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)})_{i,:})_m, \text{s.t.} \|\mathbf{\Gamma}_v^{(l)}\|_0 = K, \forall i \in [N],$$

$$g_{\Psi^{(l)}}(\mathcal{G}_v,\mathbf{H}_v^{(l)})_{i,:} = TopK([\mathcal{P}(\{[\mathbf{H}_v^{(l)}]_{j,:} : j \in \mathcal{S}_i\}) \| \mathcal{P}(\mathbf{H}_v^{(l)})]\mathbf{W}_{\text{gate}}^{(l)}). \quad （式 9）$$

其中 S_i 是节点 i 对应的局部子图节点集合；P(·)为 pooling。第一部分编码节点附近的局部图结构，第二部分编码当前视图的全局信息。最终只保留 Top-K 专家，使路由具有稀疏性。

3.6 加速技巧

多个图专家会带来额外图卷积开销。为降低成本，作者将某类谱 GNN 专家写为：

$$f_{\Theta_m^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)}) = \zeta(\mathbf{P}_v \mathbf{H}_v^{(l)} \mathbf{\Theta}_m^{(l)}), \quad \text{（式 10）}$$

其中 P_v 是与图结构相关但无参数的滤波算子，$\Theta_m^{(l)}$是专家特有的可训练权重。这样每层只需要计算一次 $P_v H_v^{(l)}$，然后把该结果共享给多个专家，再分别乘以不同的 $\Theta_m^{(l)}$，从而显著减少重复图传播的开销。

3.7 正则化：避免专家坍塌

3.7.1 负载均衡损失

稀疏门控会产生“强者愈强”的问题：某些专家一开始被选得更多，因此训练得更充分，随后又更容易被路由器继续选择，最终可能只剩少数专家活跃。为此，作者定义每个专家的平均门控权重 ρ_v^m和被选中比例 ω_v^m，并构造负载均衡损失 L_{eqm}，使不同专家具有更接近的使用频率和平均权重。

$$\rho_v^m = \frac{1}{N}\sum\nolimits_i \quad [\mathbf{\Gamma}_v^{(l)}]_{i,m}, \omega_v^m = \frac{1}{N}\sum\nolimits_i \quad \mathbb{I}\{[\mathbf{\Gamma}_v^{(l)}]_{i,m} > 0\},$$

$$\mathcal{L}_{\text{eqm}} = \frac{1}{V}\sum\nolimits_{v=1}^{V} \quad \frac{1}{M}\sum\nolimits_{m=1}^{M} \quad \omega_v^m \rho_v^m \log \rho_v^m. \quad \text{（式 11）}$$

3.7.2 图差异损失

即使专家的使用频率比较均衡，不同专家仍可能学习到几乎相同的潜在空间。因此作者进一步比较不同专家产生的图级表示分布。对于专家 m，先得到专家特定节点表示 Z_v^m，再通过 readout/pooling 得到图级向量 z_v^m。随后将各视图上的 z_v^m看作由专家 m 诱导的分布样本，利用最大均值差异（MMD）衡量不同专家分布之间的差异。

最终的图差异损失 L_{dsp}取不同专家对之间 MMD 的负值，因此最小化 L_{dsp}等价于增大不同专家潜在分布之间的差异，鼓励专家学习不同的图过滤行为和表示空间。

$$[\mathbf{Z}_v^m]_{i,:} := [\mathbf{\Gamma}_v]_{i,m} f_{\Theta_m}(\mathcal{G}_v, \mathbf{X})_{i,:}, \quad \text{（式 12）}$$

$$\mathbf{z}_v^m := \mathcal{P}(\mathbf{Z}_v^m), \quad \text{（式 13）}$$

$$\mathcal{M}_{\mathcal{H}}^2(\mathbb{P}_{Q_m}, \mathbb{P}_{Q_{m'}}) = \|\mu_{Q_m} - \mu_{Q_{m'}}\|_{\mathcal{H}}^2 =$$

$$\mathbb{E}_{Q_m Q_m'}[\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^m)] + \mathbb{E}_{Q_{m'} Q_{m'}'}[\kappa(\mathbf{z}_v^{m'}, \mathbf{z}_{v'}^{m'})]$$

$$-2\mathbb{E}_{Q_m Q_{m'}}[\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^{m'})], \quad \text{（式 14）}$$

$$\mathcal{M}_{\mathcal{H}}^2(\mathbb{P}_{Q_m}, \mathbb{P}_{Q_{m'}}) = sup_{\kappa \in \mathcal{K}} \|\mu_{Q_m} - \mu_{Q_{m'}}\|_{\mathcal{H}}^2, \quad \text{（式 15）}$$

$$\hat{\mathcal{M}}_{\mathcal{H}}^2(\mathbb{P}_{Q_m}^{(l)}, \mathbb{P}_{Q_{m'}}^{(l)}) = sup_{\kappa \in \mathcal{K}}[\frac{1}{V^2}\sum\nolimits_v \quad \sum\nolimits_{v'} \quad \kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^m) + \frac{1}{V^2}\sum\nolimits_v \quad \sum\nolimits_{v'} \quad \kappa(\mathbf{z}_v^{m'}, \mathbf{z}_{v'}^{m'}) - \frac{2}{V^2}\sum\nolimits_v \quad \sum\nolimits_{v'} \quad \kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^{m'})],$$
（式 16）

$$\mathcal{L}_{\text{dsp}} = -\frac{1}{L}\sum\nolimits_l \quad \frac{1}{M(M-1)}\sum\nolimits_{m<m'} \quad \hat{\mathcal{M}}_{\mathcal{H}}^2(\mathbb{P}_{Q_m}^{(l)}, \mathbb{P}_{Q_{m'}}^{(l)}), \quad \text{（式 17）}$$

3.8 训练目标

总体损失为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{tsk}} + \alpha\mathcal{L}_{\text{eqm}} + \beta\mathcal{L}_{\text{dsp}}, \quad （式 18）$$

$$\mathcal{L}_{\text{tsk}} = -\sum_{i\in\Omega} \sum_{j} Y_{i,j}\log\hat{Y}_{i,j}. \quad （式 19）$$

其中 $L_{(tsk)}$为下游任务损失。半监督节点分类任务中，作者采用交叉熵损失。

4 实验

4.1 实验设置

作者在 5 个原生多视图图数据集（ACM-M、DBLP、IMDB、YELP、AMINER）以及 5 个常见单视图图数据集（ACM、Citeseer、CoraFull、Flickr、UAI）上进行主要实验，并在大规模多视图 Freebase 与单视图 OGBN-arXiv 上进一步测试可扩展性。对于单视图图，作者通过 kNN（k=10）构造一个补充视图，使 MvCGE 能应用到单视图场景。

多视图数据实验中训练比例设为 20%，指标为 Macro-F1 和 Micro-F1；单视图半监督节点分类采用常见设置，每类随机选 20 个训练样本，另取 500 个验证样本和 1000 个测试样本。

4.2 多视图数据主要结果

表：多视图数据主要结果

数据集	Macro-F1	Micro-F1
ACM-M	0.9348	0.9245
DBLP	0.9256	0.9317
IMDB	0.5157	0.6883
YELP	0.7776	0.8008
AMINER	0.7897	0.8640

论文报告 MvCGE 在多数多视图数据集上优于对比方法。作者特别指出，YELP 上提升较明显，并将其归因于传统基于 meta-path 的方法难以刻画复杂的非线性跨视图关系，而 MvCGE 能通过 MoE 路由更灵活地平衡一致性与互补性。

4.3 单视图数据主要结果

表：单视图数据主要结果

数据集	Macro-F1	Micro-F1
ACM	0.9110	0.9114
Citeseer	0.6908	0.7356
CoraFull	0.5924	0.6693
Flickr	0.7675	0.7790
UAI	0.4797	0.6591

在单视图数据上，作者通过人为构造补充视图后使用 MvCGE，并报告其在多个数据集上同样具有较强性能，说明该框架具有一定兼容性。

4.4 可视化与敏感性分析

作者使用 t-SNE 对 YELP 与 ACM 上学习到的表示进行可视化，认为 MvCGE 得到的类别簇分离更清晰、类内更紧凑。

对于超参数 α 和 β，作者在 ACM 与 YELP 上进行敏感性实验。结果显示，当 α、β 取合适范围时，两种正则损失能够稳定改善性能。

作者还考察了专家总数与 Top-K 选择数。实验表明，并不是专家越多或每次激活越多越好；选择一个合适的专家子集通常比激活过少或过多专家获得更好结果。

5 结论

本文研究多视图图学习中一致性与互补性的平衡问题。传统多视图 GNN 要么采用刚性的参数共享，难以适配不同视图的异质结构；要么采用彼此隔离的多通道模型，削弱跨视图协作。MvCGE 受 MoE 启发，通过逐层协同图专家动态处理不同多视图图，同时保留共享信息与视图特有信息。

负载均衡损失和图差异损失用于缓解专家坍塌并增强表示的判别性。多个数据集上的实验表明，MvCGE 在复杂多视图图数据上具有较好的灵活性与性能。作者同时指出，一个可能的局限是：虽然实验中包含同配图与异配图，但论文没有系统讨论图的 homophily / heterophily 对方法的影响。

6 致谢

本工作由中国国家自然科学基金（项目编号 62202422、62372408）资助。

附：阅读提示（仅标记原论文结构，不添加额外结论）

原论文第 11–15 页为参考文献，第 16–22 页为 NeurIPS Paper Checklist。本中文文件未逐条翻译这些部分；若你需要，我可以再单独做“全文逐页对照翻译版”。