图与异质性相遇：多视图协同图专家

Where Graph Meets Heterogeneity: Multi-View Collaborative Graph Experts

Zhihao Wu[1]、Jinyu Cai[2]、Yunhe Zhang[3]、Jielong Lu[1]、Zhaoliang Chen[4]、Shuman Zhuang[5]、Haishuai Wang[1] †

[1] 浙江大学计算机科学与技术学院，浙江省无障碍感知与智能系统重点实验室；[2] 新加坡国立大学数据科学研究所；[3] 澳门大学计算机与信息科学系；[4] 香港浸会大学计算机科学系；[5] 福州大学计算机与大数据学院。

{zhihaowu1999,jinyucai1995,zhangyhannie}@gmail.com；jielonglu2022@163.com；chenzl23@outlook.com；shumanzhuang@163.com；haishuai.wang@zju.edu.cn

· 同等贡献。† 通信作者：Haishuai Wang。

第39届神经信息处理系统大会（NeurIPS 2025）。

译本说明：本译本仅供用户私人阅读，以用户提供的22页PDF为唯一原文，完整覆盖正文、参考文献及论文检查清单。原文提及的附录并不包含在该PDF中，本译本不补造或另行获取。图、表及编号公式直接保留原文图像，以维护数值、数学字体和编号；图注及说明译为中文。原作者及原出版方权利保留；未核实公开再分发许可，不作CC许可或可公开发布的声明。原文疑似笔误保留，不擅自纠正。

摘要

图学习与多视图学习的融合推动了多视图图神经网络（MGNN）的出现，使其具有强大的能力，能够处理以异质且相互关联的信息为特征的复杂现实数据。尽管现有MGNN挖掘了多视图图的潜力，多视图学习的两个关键归纳偏置——一致性与互补性——之间仍存在内在冲突。因此，如何在多视图图的新背景下定义并化解这一矛盾，仍是一个基本未得到充分探索的挑战。为弥补这一空白，我们提出多视图协同图专家（MvCGE），一种以混合专家（MoE）范式为基础的新框架。MvCGE通过共享参数建立架构上的一致性，同时通过逐层协同图专家保留互补性；这些专家由图感知路由机制动态激活，该机制适应各视图细微的结构差异。两个新组件进一步强化了这一双层设计：负载均衡损失防止专家坍塌并确保均衡的专门化；基于分布散度的图差异损失增强视图间互补性。在多种数据集上的大量实验证明了MvCGE的优越性。

1 引言

随着数据采集和分析能力的发展，现代数据不再被视为孤立或单一的对象。相反，人们开始认识到，实体通过复杂且普遍的关系紧密相连，而这些关系正得到越来越准确的捕捉。图因其通用性而被广泛用于表示这些关系，是一种强大的建模工具。图擅长捕捉复杂依赖关系，已成为机器学习的基石，并促成了从结构化数据学习表示的先进技术[Liang et al., 2024; Cai et al., 2024; Dai et al., 2016]。除实体间的关系之外，数据的“非孤立性”还表现在异质信息源上，这些信息源被称为不同视图。例如，在社交网络中，一个用户可能关联多种类型的交互（如友谊关系与行为交互）；在多媒体系统中，对象可以使用

多种模态（如视觉特征与语义标签）描述。这种多样性带来了独特挑战，催生了多视图学习等新范式[Liang et al., 2025; Zhang et al., 2025; Chen et al., 2023a; Xu et al., 2015]。对于此类异质数据，既有多视图学习工作提供了一个以两个众所周知的关键性质为基础的框架。具体而言，每个视图提供能够补充其他视图的独有信息，这一性质称为互补性。由于这些视图植根于相同的底层实体，它们之间存在内在的契合，称为一致性。这两个不同特性使多视图学习能够优于单视图方法[Tao et al., 2019]。但是，这两个特性可能存在内在冲突[Dong et al., 2023]。过度强调独特信息或共享信息中的任何一方，都会削弱多视图学习的优势。因此，有效促进这两个性质之间的平衡已成为一个主要关注点。

普遍存在的相互关系与日益增加的视图，分别从不同角度进一步拓展了数据的异质性。但有趣的是，图学习以拓扑作为统一结构，为锚定、对齐和整合多样化信息提供了共同基础。研究人员发现，基于图的多视图学习展现出良好的性能[Li et al., 2025; Wan et al., 2024]。例如，Zhang等人和Chen等人通过构图促进视图对齐，显著改善了聚类；Duan等人和Huang等人则关注半监督学习，充分利用图放大监督信号。然而，这些方法仍属传统方法，缺乏对图理论的深入理解，主要建立在相似性保持概念上，难以应对复杂数据。在深度学习时代，利用先进图技术增强多视图学习引起了广泛兴趣。

近来，图神经网络（GNN）迅速发展，已成为图学习的强大技术。谱GNN[Defferrard et al., 2016]有效地将卷积扩展到非欧几里得图数据；在此基础上提出的图卷积网络（GCN）[Kipf and Welling, 2017]很快成为一个现象级模型。由于GNN的强大能力[Xu et al., 2019]以及多视图学习与图之间的协同效应，多视图GNN（MGNN）已成为有效范式。与既有工作不同，MGNN通常将异质数据显式表述为多视图图，并采用现代GNN架构。虽然图结构是协调异质性的有力工具，一致性与互补性之间的经典困境仍然存在。主要挑战转变为如何在多视图图的新背景下定义并解决这一长期存在的冲突。现有方法已作出尝试：具体而言，许多MGNN采用统一模型，通过共享权重自然地实现视图间高度协同[Lin et al., 2024; Chen et al., 2023b; Cheng et al., 2020; Xia et al., 2022]。但这可能导致过度强调一致性，从而破坏互补性。此外，从图信号处理的角度看，一个图滤波器可能无法匹配潜在异质的多视图图结构。另一条路线构建多通道模型[Chen et al., 2024a; Lu et al., 2024a; Wu et al., 2023; Li et al., 2020]，为每个视图分配独有参数，以确保互补性。由于视图间交互完全依赖后融合，这种方法可能牺牲视图间内在交互，并缺乏架构灵活性。图1展示了现有的两条路线。这引出一个关键问题：如何设计一种合理的MGNN范式，在一致性与互补性之间取得平衡?

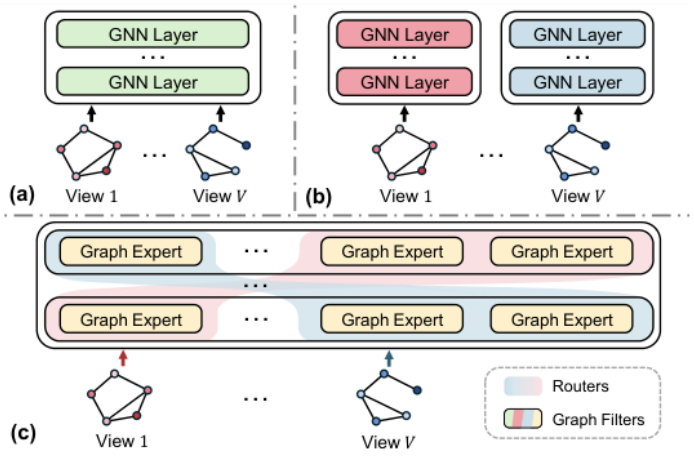


图1：基于(a)共享模型、(b)多通道模型和(c)MvCGE的MGNN范式示意图。图中文字：GNN Layer＝GNN层；Graph Expert＝图专家；View＝视图；Routers＝路由器；Graph Filters＝图滤波器。

针对这一挑战，本文引入一种灵活且有效的MGNN框架，称为多视图协同图专家（MvCGE）。图2简要展示了其架构。首先，从图谱理论的角度回顾现有MGNN，我们发现一个关键局限：共享图滤波器无法有效处理多视图图的异质结构性质。受混合专家（MoE）启发，我们提出逐层协同图专家，作为MvCGE的基本构建模块。该模块使不同图滤波器——亦可视为GNN层——能够协同处理多视图图，从而保留视图特有信息。值得注意的是，专家在视图间共享，为一致性建立架构基础。此外，图专家数量与视图数量解耦，提供了更好的灵活性。引入的图感知路由根据各视图的结构特征动态选择合适的图专家。为避免模型坍塌及其导致的互补信息丢失，我们引入两个新机制。负载均衡损失确保训练投入在专家间均衡分配，避免某些专家占据主导或过度扩张。以图同构为基础的图差异损失将多视图图潜在表示视为离散分布，鼓励专家学习不同的表示，防止坍塌到相同潜在空间。本文的主要贡献如下：

- 充分回顾现有MGNN路线，揭示一个关键挑战：共享模型或视图专属模型无法灵活适应多视图图。
- 提出新的MoE启发式MGNN框架MvCGE，在处理异质数据时有效平衡一致性和互补性要求。
- 引入两个创新机制，从不同角度解决模型坍塌，并增强对视图特有信息的保护。
- 在单视图和多视图图数据集上的实验表明，MvCGE优于竞争方法，展现出出色的性能和泛化能力。

2 相关工作

多视图学习 多视图学习[Liu et al., 2023, 2022; Chen et al., 2022a]利用多个视角的信息提高性能，其中一致性捕捉共享信息，互补性利用独有贡献。基于图的方法因能够建模任意分布的数据，在该领域受到重视[Sun et al., 2024; Wan et al., 2023; Li et al., 2019]。Nie等人提出在多视图聚类中自动为各视图图加权。Li等人利用图增强不完整多视图学习。Wen等人利用图细化跨视图对应关系。然而，这些方法未能充分挖掘图的潜力，也缺少与深度学习进展的融合。

混合专家 MoE概念可以追溯至早期工作[Jacobs et al., 1991; Jordan and Jacobs, 1994]，其设计目标是动态组合多个专门模型，以解决复杂任务。现代进展将MoE应用于深度学习，使其在视觉和语言模型中表现强大[Shazeer et al., 2017; Lepikhin et al., 2021; Fedus et al., 2022; Fang et al., 2022; Shen et al., 2025; Miao et al., 2025]。然而，MoE在多视图学习中的潜力尚未得到探索。与此同时，图MoE仍处于起步阶段，只有少量研究尝试面向图任务发展MoE[Ma et al., 2024; Wang et al., 2023; Hu et al., 2022]。对多视图图的研究仍然不足[Wang et al., 2023]。

图神经网络 GNN是基于图的机器学习的重要工具[Cai et al., 2025; Wang et al., 2025; Fang et al., 2025b,a]，可大致分为谱方法和空间方法。谱GNN借助谱图理论将卷积操作扩展至非欧几里得空间，曾主导这一领域。Kipf和Welling提出GCN，弥合谱范式与空间范式之间的鸿沟，为现代GNN奠定基础。在这些成功之上，MGNN应运而生，以应对多视图学习的挑战。当前MGNN遵循两条主要路线。一种策略构建共享参数的统一模型，共同处理所有视图，内在地确保视图间一致性。为实现这一目标，Chen等人提出融合多视图图，Lu等人则提出图生成方法。另一种策略采用多通道架构，为各视图学习独立参数，例如[Lin et al., 2024; Chen et al., 2024b]。然而，这两条路线常倾向两个极端，即过度强调一致性或互补性。前者牺牲视图特有信息，后者则可能引起视图间分歧和失配。

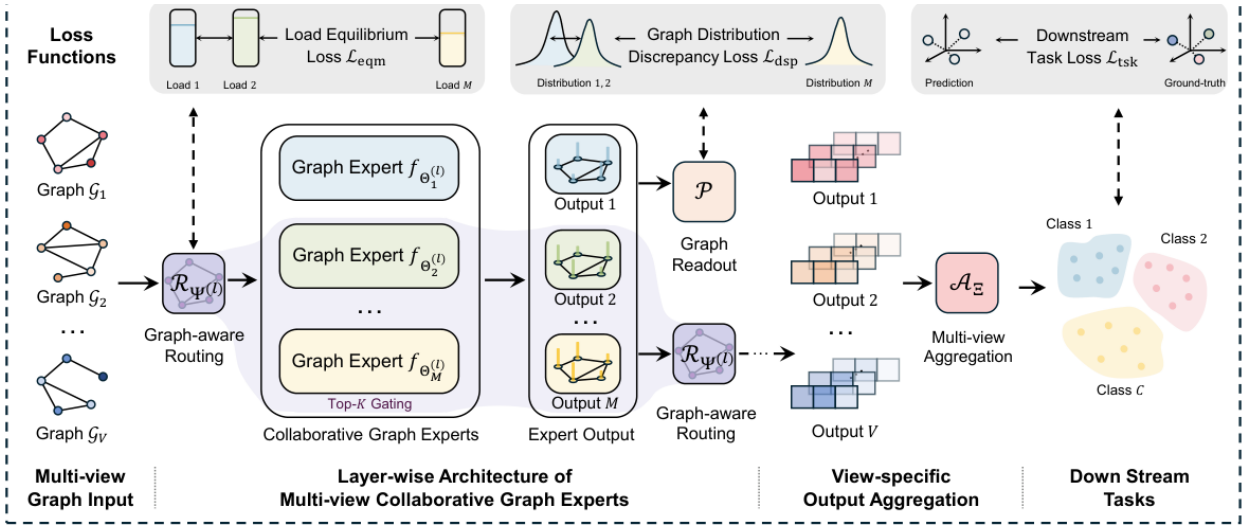


图2：所提出MvCGE的单层示意图。图中文字：Loss Functions＝损失函数；Load Equilibrium Loss＝负载均衡损失；Graph Distribution Discrepancy Loss＝图分布差异损失；Downstream Task Loss＝下游任务损失；Load＝负载；Distribution＝分布；Prediction＝预测；Ground-truth＝真实标签；Graph＝图；Graph Expert＝图专家；Graph-aware Routing＝图感知路由；Top-K Gating＝Top-K门控；Collaborative Graph Experts＝协同图专家；Expert Output＝专家输出；Graph Readout＝图读出；Multi-view Aggregation＝多视图聚合；Output＝输出；Class＝类别；Multi-view Graph Input＝多视图图输入；Layer-wise Architecture of Multi-view Collaborative Graph Experts＝多视图协同图专家的逐层架构；View-specific Output Aggregation＝视图专属输出聚合；Down Stream Tasks＝下游任务。

3 方法

符号 我们将属性图定义为 $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{X})$，其中 $\mathcal{V}$ 为节点集合，其基数为 $|\mathcal{V}| = N$， $\mathcal{E}$ 为边集合。图拓扑以邻接矩阵 $\mathbf{A} \in \{0, 1\}^{N\times N}$ 表示。节点属性以特征矩阵 $\mathbf{X} \in \mathbb{R}^{N\times D}$ 表示，其中 D 为节点特征维数。度矩阵 $\mathbf{D} \in \mathbb{R}^{N\times N}$ 为对角矩阵，其中 $\mathbf{D}_{ii} = \sum_j \mathbf{A}_{ij}$。图拉普拉斯矩阵定义为 $\mathbf{L} = \mathbf{D} - \mathbf{A}$，其对称版本为 $\mathbf{L} = \mathbf{I} - \mathbf{D}^{-1/2}\mathbf{A}\mathbf{D}^{-1/2}$。多视图图描述一组图 $\{\mathcal{G}_v : v \in [V]\}$，其节点集合 $\mathcal{V}$ 关联异质信息。第 v 个图可以定义为 $\mathcal{G}_v = (\mathcal{V}, \mathcal{E}_v, \mathbf{X})$，具有相应邻接矩阵 $\mathbf{A}_v$ 和共享属性 $\mathbf{X}$。

动机 本小节从图滤波器的角度讨论现有范式。首先，已知拉普拉斯矩阵可分解为 $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$，这实际上在图域上引入了傅里叶变换，其中特征向量对应傅里叶分量，特征值表示图的频率。将 $\mathbf{X}$ 作为输入信号，图卷积层的一般形式可写为

$$\hat{\mathbf{X}} = f_\Theta(\mathcal{G}, \mathbf{X}), \tag{1}$$

其中 f_Θ 为以 Θ 参数化的函数。对于早期谱GNN[Bruna et al., 2014]，该函数具体为 $h_\Theta(\mathbf{L})\mathbf{X}$，其中 $h_\Theta(\mathbf{L})$ 为参数化图滤波器。由于计算负担较重，研究者随后提出以多项式近似图滤波器[Defferrard et al., 2016]：

$$f_{\Theta}(\mathcal{G}, \mathbf{X}) = \sum_{t=0}^{T} \theta_t \mathbf{L}^t \mathbf{X}, \tag{2}$$

其中 $\Theta = \{\theta_t : t \in [T]\}$ 为参数。[Defferrard et al., 2016]通过切比雪夫展开实现快速局部化滤波器，著名的GCN[Kipf and Welling, 2017]进一步固定 $T = 2$ 并简化卷积，以统一形式连接谱GNN和空间GNN。因此，不失一般性，我们描述多层现代GNN的递推公式：

$$\mathbf{H}^{(l+1)} = f_{\Theta^{(l)}}(\mathcal{G}, \mathbf{H}^{(l)}), \tag{3}$$

其中 $\mathbf{H}^{(l)} \in \mathbb{R}^{N \times D_l}$ 为第 l 层输入，初始化为 $\mathbf{H}^{(0)} = \mathbf{X}$， $\Theta^{(l)}$ 可视为图滤波器扩展后的多通道参数。通过优化每一层的图滤波器参数 $\Theta^{(l)}$ 来训练GNN，使其在基于图的机器学习任务中表现强大。

这些GNN很快被应用于更复杂、更贴近现实的多视图图场景。为了确保视图间一致性，许多方法通常在所有视图之间采用统一且共享的模型。该策略通过权重共享，自然实现视图间高度协同学习，从而获得良好的一致性，但往往难以有效建模不同视图固有的多重图结构。考虑任意两个视图，我们通常希望图滤波器产生具有共识而非明显分歧的结果。然而，将共享图滤波器应用于两种图结构时，其有效性受到两图之间谱间隙的显著影响。关于图滤波器可迁移性或稳定性的讨论通常基于严格的假设[Ruiz et al., 2020; Gama et al., 2020; Levie et al., 2021]。换言之，当两个图的结构差异很大时，就难以确保图滤波器在两个视图中都取得最优性能。一种直观方案是为每个视图分配独立图滤波器，使各视图学习符合自身需求的参数。这种方法已被广泛考虑。然而，与共享滤波器相比，它虽然考虑了更多互补性，却不可避免地走向另一极端，牺牲了架构上的一致性。此外，子模块数量与视图数量直接相关，限制了其灵活性。为解决这些局限，我们希望构建一种MGNN框架，确保可扩展地整合视图间动态关系，从而更好地捕捉并平衡一致性和互补性。

整体框架 首先考虑第 v 个视图的输入，并定义以下逐层形式：

$$\mathbf{H}_v^{(l+1)} = \mathcal{F}_{\Phi^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)}), \tag{4}$$

其中 $\mathbf{H}_v^{(l)}$ 表示第 v 个图在第 l 层的嵌入，且 $\mathbf{H}_v^{(0)} = \mathbf{X}$；具有可训练参数集 $\Phi^{(l)}$ 的函数 $\mathcal{F}_{\Phi^{(l)}}$ 由多个图卷积组成：

$$\mathcal{F}_{\Phi^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)}) = \mathcal{R}_{\Psi^{(l)}}\left(\left\{f_{\Theta_m^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)}) : m \in [M]\right\}\right), \tag{5}$$

其中 $\mathcal{R}_{\Psi^{(l)}}$ 表示以 $\Psi^{(l)}$ 参数化的路由函数，且 $\Phi^{(l)} = \{\Psi^{(l)}, \Theta_m^{(l)} : m \in [M]\}$。在此基础上，我们引入多个图滤波器的集成 $\mathcal{F}_{\Phi^{(l)}}$，希望利用具有不同参数的图滤波器协同处理来自不同视图的图信息。具体而言，通过设计路由器 $\mathcal{R}_{\Psi^{(l)}}$，选择合适的图滤波器组合，以处理各视图潜在异质的结构。随后，我们考虑处理多视图图并构建多层网络。所提出的MvCGE框架通过下式计算最终表示 $\mathbf{H} \in \mathbb{R}^{N \times C}$：

$$\mathbf{H} = \mathcal{A}_{\Xi}\left(\left\{\mathbf{H}_v = \mathcal{F}_{\Phi}(\mathcal{G}_v, \mathbf{X}) : v \in [V]\right\}\right), \tag{6}$$

其中 $\mathbf{H}_v \in \mathbb{R}^{N \times C}$ 为第 v 个视图学得的最终嵌入， $\mathcal{A}_{\Xi}$ 为参数集为 Ξ 的多视图聚合函数， $\mathcal{F}_{\Phi}$ 由串接 L 个逐层函数定义：

$$\mathcal{F}_{\Phi} := \mathcal{F}_{\Phi^{(0)}} \circ \cdots \circ \mathcal{F}_{\Phi^{(l)}} \circ \cdots \circ \mathcal{F}_{\Phi^{(L-1)}}, \tag{7}$$

整个函数 $\mathcal{F}_{\Phi^{(l)}}$ 预期在视图间共享，从而促进内在的视图间交互。在我们的框架中， $\mathcal{F}_{\Phi}$ 在视图间共享，这一特征从架构层面确保不同视图图之间有充分交互。也就是说，模型的所有参数 Φ 均在所有视图的图上训练，以捕捉共识。另外， $\mathcal{F}_{\Phi}$ 的每一层 $\mathcal{F}_{\Phi^{(l)}}$ 整合多个图专家 $f_{\Theta_m^{(l)}}$，确保模型具备足够能力适应各视图数据，从而捕捉其互补性。注意，图专家数量 M 独立于视图数量 V，这为模型提供额外灵活性。因此，MvCGE在多视图学习内在的一致性与互补性需求之间取得平衡。在概述MvCGE框架之后，下一小节讨论其细节与具体实现。

逐层协同图专家 针对上述设计思路，我们借鉴MoE概念实现框架。形式上，给定第 l 层中第 v 个视图的输入 $\mathbf{H}_v^{(l)}$，规定 $\mathcal{F}_{\Phi^{(l)}}$ 按下式聚合若干图专家的决策：

$$[\mathbf{H}_v^{(l+1)}]_{i,:} = \sum_{m\in[M]} [\mathbf{\Gamma}_v^{(l)}]_{i,m} f_{\mathbf{\Theta}_m^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)})_{i,:}, \tag{8}$$

其中 $\mathbf{\Gamma}_v^{(l)} \in \mathbb{R}^{N\times M}$ 为第 v 个视图的路由矩阵，包含第 l 层所有图滤波器的路由权重；这些滤波器在框架中充当图专家。通过这一逐层设计，MvCGE的每一层均可视为独立MoE，由特定路由器控制，从而能够更灵活地选择和组合图专家。

接下来具体说明路由函数 $\mathcal{R}_{\Psi^{(l)}}$，它负责为各视图中的每个节点选择适当的专家组合。我们提出一种改进的图感知top-k门控机制。具体而言，将第 v 个视图中第 i 个样本对于第 m 个专家的门控权重表示为：

$$[\mathbf{\Gamma}_v^{(l)}]_{i,m} = \mathrm{Softmax}\big(g_{\Psi^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)})_{i,:}\big) \quad \text{s.t. } \big\|[\mathbf{\Gamma}_v^{(l)}]_{i,:}\big\|_0 = K,\ \forall i \in [N],$$

其中门控模块 $g_{\Psi^{(l)}}$ 输出一个 M 维向量，作为整合不同专家输出的权重。注意，该模块具有约束以保证稀疏门控。在多视图图学习场景中， $g_{\Psi^{(l)}}$ 的设计至关重要，因为它是保留视图特性的关键，必须同时感知图模式和视图级模式。

$$g_{\Psi^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)})_{i,:} = \mathrm{Top}K\Big([\mathcal{P}(\{[\mathbf{H}_v^{(l)}]_{j,:}, j \in \mathcal{S}_i\}) \| \mathcal{P}(\mathbf{H}_v^{(l)})]\mathbf{W}_{\text{gate}}^{(l)}\Big). \tag{9}$$

其中 $\mathcal{P}$ 为池化函数， $\mathcal{S}_i$ 为与节点 i 的采样局部子图关联的节点集合。因此， $\mathcal{P}\Big(\{\big[\mathbf{H}_v^{(l)}\big]_{i,j},\ j \in \mathcal{S}_i\}\Big)$ 和 $\mathcal{P}\Big(\mathbf{H}_v^{(l)}\Big)$ 分别编码局部图结构与视图特有的全局信息。 $\mathbf{W}_{\text{gate}} \in \mathbb{R}^{2D\times M}$ 为将输入映射到门控得分的可训练参数矩阵。我们采用Top-K稀疏门控：对于每个节点 i，仅保留Top-K专家logit，其余在应用softmax之前被屏蔽（置为 $-\infty$）。由此得到 $\| \left[\mathbf{\Gamma}_v^{(l)}\right]_{i,:} \|_0 = K$，剩余权重严格为零，因此仅选择门控权重最高的K个专家。

加速技巧 处理大规模图时，由于边数量庞大，图卷积操作可能成为主要瓶颈。使用多个图专家会带来额外计算开销。因此，我们考虑进一步具体化图专家，并提出一种加速技巧。将图专家形式化为：

$$f_{\Theta_m^{(l)}}(\mathcal{G}_v, \mathbf{H}_v^{(l)}) = \zeta(\mathbf{P}_v \mathbf{H}_v^{(l)} \mathbf{\Theta}_m^{(l)}), \tag{10}$$

其中 ζ 为非线性激活函数， $\mathbf{P}_v$ 为视图 v 的滤波算子， $\mathbf{\Theta}_m^{(l)} \in \mathbb{R}^{D_l \times D_{l+1}}$ 为可训练权重矩阵。这里考虑一类简化的谱GNN，其滤波器参数被视为编码于可训练权重 $\mathbf{\Theta}_m^{(l)}$ 中，从而分离出无参数算子 $\mathbf{P}_v$ 。例如，它可以是ChebNet[Defferrard et al., 2016]的切比雪夫多项式 $\sum_{t=0}^{T} T_t(\mathbf{L}_v)$ ，或者GCN[Kipf and Welling, 2017]的 $\mathbf{I} - \mathbf{L}_v$ 。对于此类图专家，每个MvCGE层仅需计算一次无参数图滤波。随后，不同专家共享这一结果，施加各自不同的可训练权重以进行不同的图卷积。这显著加快了整个框架。

正则化 虽然MvCGE通过灵活架构确保一致性，但其训练仍面临可能导致模型坍塌的挑战，从而丢失视图间互补信息。

负载均衡：从优化角度看，由于门控机制[Shazeer et al., 2017]，MvCGE在某些情况下可能过度依赖一组图专家，而使其他专家无法获得训练。这种不平衡会自我强化，导致被选专家不断扩张，其他专家则越来越不可能被选择。最终，MvCGE将坍塌为仅激活少数专家的模型，失去捕捉视图特有信息的优势。为解决这一问题，我们引入负载均衡损失。对于第 v 个视图，令

$$\rho_v^m = \frac{1}{N}\sum_i [\mathbf{\Gamma}_v^{(l)}]_{i,m},\ \omega_v^m = \frac{1}{N}\sum_i \mathbb{I}\{[\mathbf{\Gamma}_v^{(l)}]_{i,m} > 0\}$$

分别为专家 m 的平均门控权重与负载，则有

$$\mathcal{L}_{\text{eqm}} = \frac{1}{V}\sum_{v=1}^{V}\frac{1}{M}\sum_{m=1}^{M}\omega_v^m \cdot \rho_v^m \log \rho_v^m, \tag{11}$$

其中先考虑视图内均衡，再考虑视图间均衡。通过最小化 $\mathcal{L}_{\text{eqm}}$ ，鼓励各图专家具有相近的选择得分和频率。

图差异：从潜在空间角度看，即使保证负载均衡、给予不同图专家相同的训练机会，它们仍可能坍塌到相近潜在空间。不同图专家应当对多视图图进行不同的滤波，而不是坍塌为单个图滤波器。为应对这一挑战，我们以单层MvCGE为例阐明图差异损失的计算机制。给定第 v 个视图图 $\mathcal{G}_v$ ，令 $f_{\mathbf{\Theta}_m}$ 与 $f_{\mathbf{\Theta}_{m'}}$ 表示任意两个不同图专家，专家特有的嵌入定义为：

$$[\mathbf{Z}_v^m]_{i,:} = [\mathbf{\Gamma}_v]_{i,m} f_{\mathbf{\Theta}_m}(\mathcal{G}_v, \mathbf{X})_{i,:}, \tag{12}$$

其中 $\mathbf{\Gamma}_v$ 表示路由矩阵， $\mathbf{Z}_v^m$ 表示专家 $f_{\mathbf{\Theta}_m}$ 产生的专家特有嵌入。类似地，可得到另一图专家的 $\mathbf{Z}_v^{m'}$ 。为清楚起见，在这个单层示例中省略层索引。随后，将两个嵌入送入读出函数（也称池化函数）：

$$\mathbf{z}_v^m = \mathcal{P}(\mathbf{Z}_v^m). \tag{13}$$

这里， $\mathbf{z}_v^m$ 可以解释为全局图嵌入，概括专家 $f_{\mathbf{\Theta}_m}$ 所捕捉的语义与结构信息。近期研究表明，读出函数与GNN配合能够有效进行图同构计算[Xu et al., 2019]。因此，我们将读出函数与一层GNN组合成模型 $\mathcal{Q}$ 。随后，对所有 V 个视图，将这些图嵌入 $\{\mathbf{z}_v^m : v \in [V]\}$ 视为从函数 $f_{\mathbf{\Theta}_m}$ 诱导的分布 $\mathbb{P}_{\mathcal{Q}_m}$ 中抽取的样本，其中 $\mathcal{Q}_m = \mathcal{P} \circ f_{\mathbf{\Theta}_m}$ 。

此后，利用最大均值差异（MMD）[Gretton et al., 2012]量化不同图专家分布之间的差异：

$$\mathcal{M}_{\mathcal{H}}^2(\mathbb{P}_{\mathcal{Q}}, \mathbb{P}_{\mathcal{Q}'}) = \|\mu_{\mathcal{Q}_m} - \mu_{\mathcal{Q}_{m'}}\|_{\mathcal{H}}^2 = \mathbb{E}_{\mathbb{P}_{\mathcal{Q}}}[\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^m)] + \mathbb{E}_{\mathbb{P}_{\mathcal{Q}'}}[\kappa(\mathbf{z}_v^{m'}, \mathbf{z}_{v'}^{m'})] - 2\mathbb{E}_{\mathbb{P}_{\mathcal{Q}}, \mathbb{P}_{\mathcal{Q}'}}[\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^{m'})], \tag{14}$$

其中 κ 为核函数，例如径向基函数核 $\kappa(\mathbf{z},\ \mathbf{z}') = \exp\left(\parallel \mathbf{z} - \mathbf{z}' \parallel^2 / \left(2\sigma^2\right)\right)$。图嵌入 $\mathbf{z}$ 和 $\mathbf{z}'$ 分别采样自分布 $\mathbb{P}_{\mathcal{Q}}$ 和 $\mathbb{P}_{\mathcal{Q}'}$。 $\mu_{\mathbb{P}_{\mathcal{Q}}}$ 和 $\mu_{\mathbb{P}_{\mathcal{Q}'}}$ 分别为分布 $\mathbb{P}_{\mathcal{Q}_m}$ 和 $\mathbb{P}_{\mathcal{Q}_{m'}}$ 在再生核希尔伯特空间（RKHS） $\mathcal{H}$ 中的均值。随后引入MMD的推广形式：

$$\mathcal{M}_{\mathcal{H}}^2(\mathbb{P}_{\mathcal{Q}}, \mathbb{P}_{\mathcal{Q}'}) = \sup\left\{\|\mu_{\mathcal{Q}} - \mu_{\mathcal{Q}'}\|_{\mathcal{H}}^2 : \kappa \in \mathcal{K}\right\}, \tag{15}$$

其中 $\mathcal{K}$ 为核函数族。按照[Gretton et al., 2012]，具体通过以下方式估计MMD：

$$\mathcal{M}_{\mathcal{H}}^2\left(\mathbb{P}_{\mathcal{Q}_m^{(l)}}, \mathbb{P}_{\mathcal{Q}_{m'}^{(l)}}\right) = \sup_{\kappa \in \mathcal{K}}\left[\frac{1}{V^2}\sum_v\sum_{v'}\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^m) + \frac{1}{V^2}\sum_v\sum_{v'}\kappa(\mathbf{z}_v^{m'}, \mathbf{z}_{v'}^{m'}) - \frac{2}{V^2}\sum_v\sum_{v'}\kappa(\mathbf{z}_v^m, \mathbf{z}_{v'}^{m'})\right]. \tag{16}$$

因此，考虑多层情形，提出图差异损失：

$$\mathcal{L}_{\text{dsp}} = -\frac{1}{L}\sum_l \frac{1}{M(M-1)}\sum_{m<m'}\mathcal{M}_{\mathcal{H}}^2\left(\mathbb{P}_{\mathcal{Q}_m^{(l)}}, \mathbb{P}_{\mathcal{Q}_{m'}^{(l)}}\right), \tag{17}$$

其中 $\mathcal{Q}_m^{(l)} = \mathcal{P} \circ f_{\Theta_m^{(l)}}$ 为结合读出函数与图专家的模型。联合使用这两个损失，确保图专家获得相近机会并学到有意义的潜在表示，从而促进MvCGE捕捉互补信息。

训练策略 使用以下目标函数训练所提出的MvCGE：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{tsk}} + \alpha\mathcal{L}_{\text{eqm}} + \beta\mathcal{L}_{\text{dsp}}, \tag{18}$$

其中 $\mathcal{L}_{\text{tsk}}$ 为下游任务损失。对于半监督分类任务，采用广泛使用的交叉熵损失：

$$\mathcal{L}_{\text{tsk}} = -\sum_{i \in \Omega}\sum_j \mathbf{Y}_{i,j}\log\hat{\mathbf{Y}}_{i,j}, \tag{19}$$

其中 $\widehat{\mathbf{Y}}$, $\mathbf{Y} \in \mathbb{R}^{|\Omega| \times C}$ 分别为预测标签与真实标签， Ω 为训练集。注意 $\widehat{\mathbf{Y}_{i,:}} = \text{Softmax}\left(\mathbf{H}_{i,:}\right)$。

4 实验

Datasets	ACM-M		DBLP		IMDB		YELP		AMINER	
Metrics	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1
GCN	0.7860	0.7881	0.9012	0.9163	0.2429	0.5544	0.5196	0.6743	0.6842	0.8156
DGI	0.2235	0.3690	0.2432	0.3763	0.2626	0.5519	0.5034	0.6831	0.3449	0.6460
HAN	0.9147	0.9139	0.8927	0.9039	0.2389	0.5586	0.4829	0.4893	0.7234	0.8476
DMGI	0.8666	0.8681	0.6567	0.7106	0.3533	0.5726	0.5161	0.6985	0.3029	0.6546
IGNN	0.8290	0.8270	0.8681	0.8750	0.4531	0.5481	0.6449	0.7123	0.7453	0.8521
MRGCN	0.8758	0.8745	0.8949	0.9047	0.4517	0.4769	0.5435	0.7370	0.7335	0.8294
SSDCM	0.8765	0.8763	0.8942	0.8990	0.4940	0.5910	0.5270	0.7020	0.2620	0.5548
MHGCN	0.8887	0.8907	**0.9300**	**0.9360**	**0.5154**	0.6423	0.6085	0.7328	0.7500	0.8517
AMOGCN	**0.9241**	**0.9238**	0.9227	0.9280	0.5016	**0.6506**	**0.6753**	0.7241	**0.7570**	**0.8338**
HMGE	0.9080	0.9066	0.9156	0.9235	0.3293	0.5735	0.5857	**0.7484**	0.7371	0.8478
MvCGE	**0.9348**	**0.9245**	**0.9256**	**0.9317**	**0.5157**	**0.6883**	**0.7776**	**0.8008**	**0.7897**	**0.8640**

表1：所有方法在多视图数据集上的Macro F1和Micro F1得分（十次运行的均值），最优和次优结果分别以橙色和蓝色突出显示。Datasets＝数据集；Metrics＝评价指标；MaF1＝宏平均F1；MiF1＝微平均F1。

Datasets	ACM		Citeseer		CoraFull		Flickr		UAI	
Metrics	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1	MaF1	MiF1
GCN	0.8827	0.8842	0.6523	0.6909	0.5277	0.6279	0.5002	0.5104	0.4506	0.5851
SGC	0.8116	0.8087	0.6157	0.6642	0.5320	0.6292	0.4422	0.5101	0.4679	0.5652
APPNP	0.8837	0.8824	0.6510	0.6972	0.5236	0.6395	0.5124	0.5212	0.4655	0.6189
JKNet	0.8524	0.8545	0.6813	0.7292	0.5126	0.6268	0.5112	0.5431	0.4134	0.5623
DAGNN	0.8699	0.8917	0.6812	0.7290	0.5353	0.6481	0.6214	0.6065	0.4778	0.5927
GCNII	0.8978	0.8980	0.6712	0.7064	0.5828	0.6403	0.5904	0.5771	**0.4869**	0.6382
GNNHF	**0.9052**	**0.9067**	0.6760	0.7249	**0.5846**	**0.6672**	0.5867	0.6078	0.4495	0.5764
AMGNN	0.8996	0.8993	**0.6873**	**0.7292**	0.5664	0.6185	**0.7580**	**0.7569**	0.4787	**0.6431**
HiDNet	0.8958	0.8961	0.6661	0.7146	0.5304	0.6531	0.6200	0.6333	0.4568	0.6165
AGNN	0.8973	0.8974	0.6264	0.6721	0.5065	0.5930	0.5721	0.5844	0.4697	0.6206
MvCGE	**0.9110**	**0.9114**	**0.6908**	**0.7356**	**0.5924**	**0.6693**	**0.7675**	**0.7790**	**0.4797**	**0.6591**

表2：所有方法在单视图数据集上的Macro F1和Micro F1得分（十次运行的均值），最优和次优结果分别以橙色和蓝色突出显示。列标题含义与表1相同。

实验设置 为评价MvCGE的有效性，我们在十个数据集上进行了实验，包括五个多视图图数据集（ACM、DBLP、IMDB、YELP、AMINER）及五个典型单视图图数据集（ACM、Citeseer、CoraFull、Flickr、UAI），另外还有一个大规模多视图图Freebase和一个大规模单视图图OGBN-arXiv。为使MvCGE适用于单视图图，我们基于k近邻算法为各单视图数据集生成补充视图，设置 $k = 10$ 。注意，为区分不同的ACM数据集，将原生多视图图ACM记为ACM-M。对于不同类型的数据集，我们将MvCGE与多种竞争方法进行比较，包括九种面向多视图数据集的方法：DGI[Velickovic et al., 2019]、HAN[Wang et al., 2019]、DMGI[Park et al., 2020]、IGNN[Gu et al., 2020]、MRGCN[Huang et al., 2020]、SSDCM[Mitra et al., 2021]、MHGCN[Yu et al., 2022]、AMOGCN[Chen et al., 2024b]、HMGE[Abdous et al., 2024]；以及十种面向单视图数据集的方法：GCN[Kipf and Welling, 2017]、SGC[Wu et al., 2019]、APPNP[Gasteiger et al., 2018]、JKNet[Xu et al., 2018]、DAGNN[Liu et al., 2020]、GCNII[Chen et al., 2020]、GNNHF[Zhu et al., 2021]、AMGNN[Zhu et al., 2023]、HiDNet[Li et al., 2024]、AGNN[Chen et al., 2023c]。

性能 本小节全面评价MvCGE在不同数据集半监督分类任务中的性能，通过实证说明其优于当前最先进方法。这些数据集上的实验设置与分析如下。1）**多视图图**。训练比例设为20%，Macro F1和Micro F1得分记录于表1。实验结果显示，所提出的MvCGE在大多数数据集上优于基线。特别是在Yelp数据集上取得显著性能提升，主要原因是基于元路径的方法在有效建模复杂非线性跨视图关系方面存在固有局限。相比之下，在MoE原则指导下，MvCGE有效解决一致性与互补性的权衡，同时保留多视图学习中的视图特有信息；实验对此作出了验证。2）**单视图图**。按照常用半监督节点分类设置，每类随机选择20个样本用于训练，500个样本用于验证，1,000个样本用于测试，详细结果见表2。该图显示MvCGE持续优于所有基线，在单视图数据集上展现强大的兼容性和适应性。另外，如附录所示，我们还在大规模图OGBN-arXiv和Freebase上测试MvCGE，展示其可扩展性。

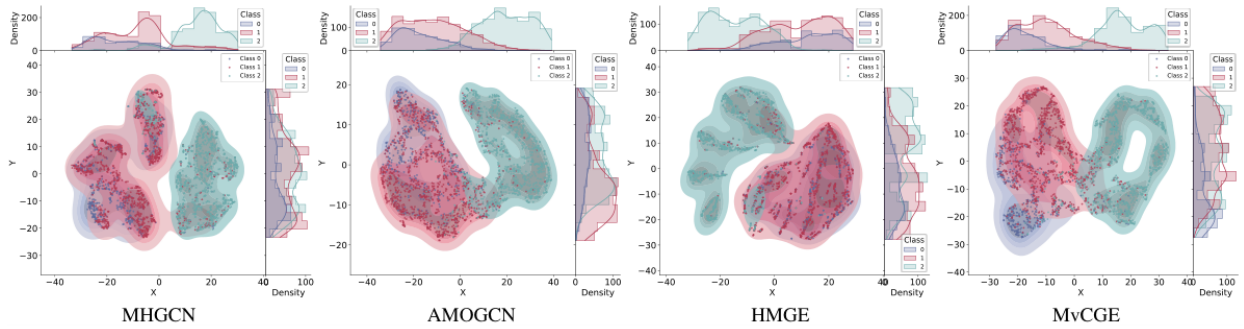


图3：MHGCN、AMOGCN、HMGE和MvCGE在YELP数据集上学得表示的可视化。Class＝类别；Density＝密度。

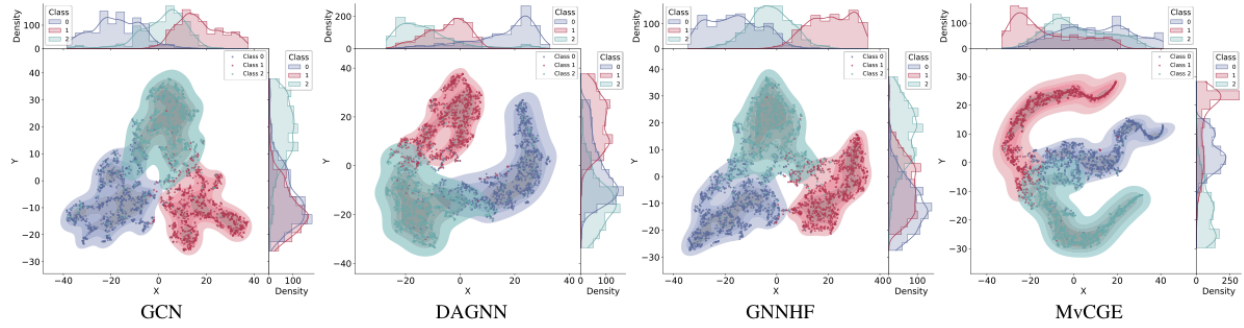


图4：GCN、DAGNN、GNNHF和MvCGE在ACM数据集上学得表示的可视化。Class＝类别；Density＝密度。

可视化 采用t-SNE[Van der Maaten L, 2008]对表现最好的基线在YELP（图3）和ACM（图4）上学得的表示进行可视化。每个节点表示为一个点，按其类别标签着色，等高线表示类别密度分布。坐标轴旁的辅助直方图揭示各维度上的嵌入分布。可视化显示，MvCGE具有更好的簇分离性，类别边界清晰，类内分布紧凑。直方图分布分析表明，MvCGE在特征空间中获得了分离更好的表示。

敏感性 本节评价参数 α 和 β 变化对MvCGE性能的影响，其中 α 和 β 平衡损失 $\mathcal{L}_{\text{eqm}}$ 与 $\mathcal{L}_{\text{dsp}}$，如图5(a)、(b)所示。可以看到，在ACM和YELP数据集上，模型性能对于 α 和 β 均表现出类似的稳定波动模式；当 $\alpha = 1e^{-1}$ 或 $1e^{-2}$、$\beta = 1e^{-1}$ 或 $1e^{-3}$ 时，达到最优性能。这说明，所整合的两个损失能够有效捕捉互补信息，并在参数值选取适当时持续提高性能。除此之外，我们还评价了模型对专家数量的敏

感性。具体而言，改变专家总数，并选择其中的一半，对应结果见图6(a)。在图6(b)中，将专家总数固定为10，改变所选择的专家数量。结果表明，选择最优专家子集，而不是过多或过少专家，可以增强模型性能。

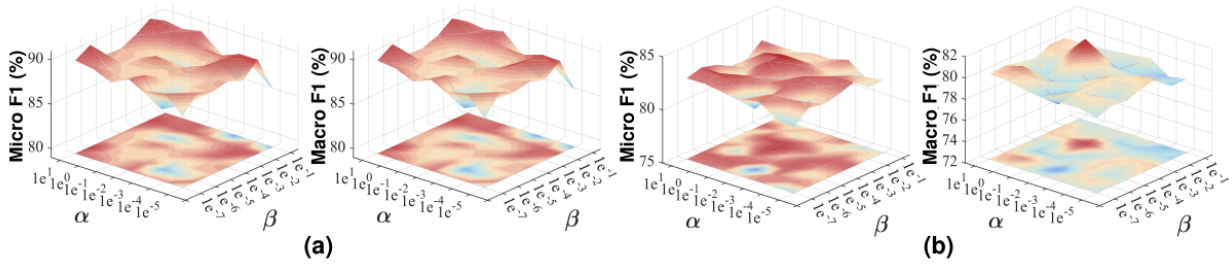


图5：MvCGE在(a)ACM、(b)YELP数据集上的分类性能随超参数 α 和 β 的变化。Micro F1 (%)＝微平均F1（%）；Macro F1 (%)＝宏平均F1（%）。

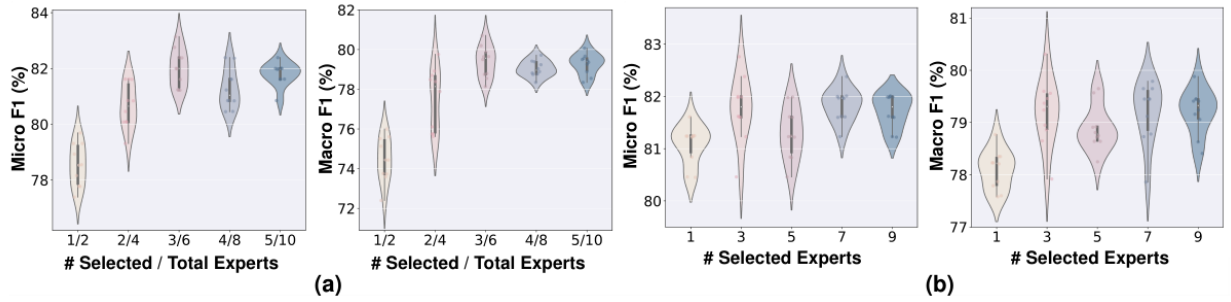


图6：MvCGE在YELP数据集上的分类性能随(a)选定专家数量及图专家总数、(b)选定图专家数量的变化。# Selected / Total Experts＝选定专家数/专家总数；# Selected Experts＝选定专家数；其余纵轴同图5。

5 结论

本文解决多视图图学习中平衡一致性与互补性的关键挑战。传统多视图GNN由于僵化的权重共享或相互隔离的多通道设计，往往难以适应多视图图的异质结构性质。为克服这些局限，我们提出受混合专家启发的新框架MvCGE，引入逐层协同图专家，在保留共享信息和视图特有信息的同时动态处理多视图图。结合负载均衡损失与图差异损失，有效缓解模型坍塌，增强学得表示的判别能力。在多种数据集上的大量实验表明，MvCGE达到当前最先进性能，展现出处理复杂多视图图数据的灵活性与稳健性。一个可能的局限是，我们没有讨论图的同配性和异配性，尽管实验采用了这两类图。

6 致谢

本工作得到国家自然科学基金支持（项目编号62202422和62372408）。

参考文献

Kamel Abdous, Nairouz Mrabah, and Mohamed Bouguessa. Hierarchical aggregations for high-dimensional multiplex graph embedding. IEEE Transactions on Knowledge and Data Engineering, 2024. 题名译文：用于高维多层图嵌入的层次聚合。

Joan Bruna, Wojciech Zaremba, Arthur Szlam, and Yann LeCun. Spectral networks and locally connected networks on graphs. In International Conference on Learning Representations, 2014. 题名译文：图上的谱网络与局部连接网络。

Jinyu Cai, Yunhe Zhang, Jicong Fan, and See-Kiong Ng. Lg-fgad: An effective federated graph anomaly detection framework. In Proceedings of the International Joint Conference on Artificial Intelligence, pages 3760–3769, 2024. 题名译文：Lg-fgad：一种有效的联邦图异常检测框架。

Jinyu Cai, Yunhe Zhang, and Jicong Fan. Self-discriminative modeling for anomalous graph detection. In Proceedings of the International Conference on Machine Learning, 2025. 题名译文：用于异常图检测的自判别建模。

Ming Chen, Zhewei Wei, Zengfeng Huang, Bolin Ding, and Yaliang Li. Simple and deep graph convolutional networks. In International conference on machine learning, pages 1725–1735, 2020. 题名译文：简单而深层的图卷积网络。

Mansheng Chen, Tuo Liu, Chang-Dong Wang, Dong Huang, and Jian-Huang Lai. Adaptively-weighted integral space for fast multiview clustering. In Proceedings of the 30th ACM International Conference on Multimedia, pages 3774–3782. ACM, 2022. 题名译文：用于快速多视图聚类的自适应加权整体空间。

Yongyong Chen, Xiaolin Xiao, Chong Peng, Guangming Lu, and Yicong Zhou. Low-rank tensor graph learning for multi-view subspace clustering. IEEE Transactions on Circuits and Systems for Video Technology, 32(1):92–104, 2022. 题名译文：用于多视图子空间聚类的低秩张量图学习。

Man-Sheng Chen, Jia-Qi Lin, Chang-Dong Wang, Wudong Xi, and Dong Huang. On regularizing multiple clusterings for ensemble clustering by graph tensor learning. In Proceedings of the 31st ACM International Conference on Multimedia, pages 3069–3077, 2023. 题名译文：通过图张量学习正则化多个聚类以实现集成聚类。

Zhaoliang Chen, Lele Fu, Jie Yao, Wenzhong Guo, Claudia Plant, and Shiping Wang. Learnable graph convolutional network and feature fusion for multi-view learning. Information Fusion, 95:109–119, 2023. 题名译文：用于多视图学习的可学习图卷积网络与特征融合。

Zhaoliang Chen, Zhihao Wu, Zhenghong Lin, Shiping Wang, Claudia Plant, and Wenzhong Guo. Agnn: Alternating graph-regularized neural networks to alleviate over-smoothing. IEEE Transactions on Neural Networks and Learning Systems, 2023. 题名译文：Agnn：缓解过平滑的交替图正则化神经网络。

Man-Sheng Chen, Xi-Ran Zhu, Jia-Qi Lin, and Chang-Dong Wang. Contrastive multiview attribute graph clustering with adaptive encoders. IEEE Transactions on Neural Networks and Learning Systems, pages 1–12, 2024. 题名译文：采用自适应编码器的对比式多视图属性图聚类。

Zhaoliang Chen, Zhihao Wu, Luying Zhong, Claudia Plant, Shiping Wang, and Wenzhong Guo. Attributed multi-order graph convolutional network for heterogeneous graphs. Neural Networks, 174:106225, 2024. 题名译文：面向异构图的属性多阶图卷积网络。

Jiafeng Cheng, Qianqian Wang, Zhiqiang Tao, De-Yan Xie, and Quanxue Gao. Multi-view attribute graph convolution networks for clustering. In Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence, pages 2973–2979, 2020. 题名译文：用于聚类的多视图属性图卷积网络。

Hanjun Dai, Bo Dai, and Le Song. Discriminative embeddings of latent variable models for structured data. In International conference on machine learning, pages 2702–2711. PMLR, 2016. 题名译文：面向结构化数据的潜变量模型判别式嵌入。

Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional neural networks on graphs with fast localized spectral filtering. In Advances in Neural Information Processing Systems, 2016. 题名译文：采用快速局部化谱滤波的图上卷积神经网络。

Zhibin Dong, Siwei Wang, Jiaqi Jin, Xinwang Liu, and En Zhu. Cross-view topology based consistent and complementary information for deep multi-view clustering. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 19440–19451, 2023. 题名译文：用于深度多视图聚类的基于跨视图拓扑的一致性与互补性信息。

Yu Duan, Zhoumin Lu, Rong Wang, Xuelong Li, and Feiping Nie. Toward balance deep semisupervised clustering. IEEE Transactions on Neural Networks and Learning Systems, pages 1–13, 2024. 题名译文：迈向平衡的深度半监督聚类。

Xiang Fang, Daizong Liu, Pan Zhou, and Yuchong Hu. Multi-modal cross-domain alignment network for video moment retrieval. IEEE Transactions on Multimedia, 25:7517–7532, 2022. 题名译文：用于视频片段检索的多模态跨域对齐网络。

Hui Fang, Yang Gao, Peng Zhang, Sheng Zhou, Hongyang Chen, Jiajun Bu, and Haishuai Wang. Contrastive federated learning for graph anomaly detection. IEEE Transactions on Neural Networks and Learning Systems, 2025. 题名译文：用于图异常检测的对比式联邦学习。

Hui Fang, Haishuai Wang, Yang Gao, Yonggang Zhang, Jiajun Bu, Bo Han, and Hui Lin. Insgnn: Interpretable spatio-temporal graph neural networks via information bottleneck. Information Fusion, 119:102997, 2025. 题名译文：Insgnn：通过信息瓶颈实现可解释的时空图神经网络。

William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. Journal of Machine Learning Research, 23(120):1–39, 2022. 题名译文：Switch Transformers：通过简单而高效的稀疏性扩展至万亿参数模型。

Fernando Gama, Joan Bruna, and Alejandro Ribeiro. Stability properties of graph neural networks. IEEE Transactions on Signal Processing, 68:5680–5695, 2020. 题名译文：图神经网络的稳定性性质。

Johannes Gasteiger, Aleksandar Bojchevski, and Stephan Günnemann. Predict then propagate: Graph neural networks meet personalized pagerank. In Proceedings of the International Conference on Learning Representations, 2018. 题名译文：先预测再传播：图神经网络与个性化 PageRank 的结合。

Arthur Gretton, Karsten M Borgwardt, Malte J Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. The Journal of Machine Learning Research, 13(1):723–773, 2012. 题名译文：核双样本检验。

Fangda Gu, Heng Chang, Wenwu Zhu, Somayeh Sojoudi, and Laurent El Ghaoui. Implicit graph neural networks. In Advances in Neural Information Processing Systems, 2020. 题名译文：隐式图神经网络。

Fenyu Hu, Liping Wang, Qiang Liu, Shu Wu, Liang Wang, and Tieniu Tan. Graphdive: Graph classification by mixture of diverse experts. In Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, pages 2080–2086, 2022. 题名译文：Graphdive：通过多样化专家混合进行图分类。

Zhichao Huang, Xutao Li, Yunming Ye, and Michael K. Ng. MR-GCN: multi-relational graph convolutional networks based on generalized tensor product. In Proceedings of the International Joint Conference on Artificial Intelligence, pages 1258–1264, 2020. 题名译文：MR-GCN：基于广义张量积的多关系图卷积网络。

Aiping Huang, Zheng Wang, Yannan Zheng, Tiesong Zhao, and Chia-Wen Lin. Embedding regularizer learning for multi-view semi-supervised classification. IEEE Transactions on Image Processing, 30:6997–7011, 2021. 题名译文：用于多视图半监督分类的嵌入正则化器学习。

Robert A Jacobs, Michael I Jordan, Steven J Nowlan, and Geoffrey E Hinton. Adaptive mixtures of local experts. Neural computation, 3(1):79–87, 1991. 题名译文：局部专家的自适应混合。

Michael I Jordan and Robert A Jacobs. Hierarchical mixtures of experts and the em algorithm. Neural computation, 6(2):181–214, 1994. 题名译文：层次混合专家与 EM 算法。

Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In International Conference on Learning Representations, 2017. 题名译文：利用图卷积网络进行半监督分类。

Dmitry Lepikhin, HyoukJoong Lee, Yuanzhong Xu, Dehao Chen, Orhan Firat, Yanping Huang, Maxim Krikun, Noam Shazeer, and Zhifeng Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. In International Conference on Learning Representations, 2021. 题名译文：Gshard：通过条件计算与自动分片扩展巨型模型。

Ron Levie, Wei Huang, Lorenzo Bucci, Michael Bronstein, and Gitta Kutyniok. Transferability of spectral graph convolutional neural networks. Journal of Machine Learning Research, 22(272):1–59, 2021. 题名译文：谱图卷积神经网络的可迁移性。

Zhaoyang Li, Qianqian Wang, Zhiqiang Tao, Quanxue Gao, and Zhaohua Yang. Deep adversarial multi-view clustering network. In Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, pages 2952–2958, 2019. 题名译文：深度对抗式多视图聚类网络。

Shu Li, Wen-Tao Li, and Wei Wang. Co-gcn for multi-view semi-supervised learning. In The Thirty-Fourth AAAI Conference on Artificial Intelligence, pages 4691–4698, 2020. 题名译文：用于多视图半监督学习的 Co-gcn。

Xingfeng Li, Yinghui Sun, Quansen Sun, Zhenwen Ren, and Yuan Sun. Cross-view graph matching guided anchor alignment for incomplete multi-view clustering. Information Fusion, 100:101941, 2023. 题名译文：用于不完整多视图聚类的跨视图图匹配引导锚点对齐。

Yibo Li, Xiao Wang, Hongrui Liu, and Chuan Shi. A generalized neural diffusion framework on graphs. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pages 8707–8715, 2024. 题名译文：图上的广义神经扩散框架。

Xingfeng Li, Yuangang Pan, Yuan Sun, Yinghui Sun, Quansen Sun, Zhenwen Ren, and Ivor W. Tsang. Scalable unpaired multi-view clustering with bipartite graph matching. Information Fusion, 116:102786, 2025. 题名译文：采用二部图匹配的可扩展非配对多视图聚类。

Ke Liang, Yue Liu, Sihang Zhou, Wenxuan Tu, Yi Wen, Xihong Yang, Xiangjun Dong, and Xinwang Liu. Knowledge graph contrastive learning based on relation-symmetrical structure. IEEE Transactions on Knowledge and Data Engineering, 36(1):226–238, 2024. 题名译文：基于关系对称结构的知识图谱对比学习。

Ke Liang, Lingyuan Meng, Hao Li, Jun Wang, Long Lan, Miaomiao Li, Xinwang Liu, and Huaimin Wang. From concrete to abstract: Multi-view clustering on relational knowledge. IEEE Transactions on Pattern Analysis and Machine Intelligence, 47(10):9043–9060, 2025. 题名译文：从具体到抽象：关系知识上的多视图聚类。

Jia-Qi Lin, Man-Sheng Chen, Xi-Ran Zhu, Chang-Dong Wang, and Haizhang Zhang. Dual information enhanced multiview attributed graph clustering. IEEE Transactions on Neural Networks and Learning Systems, pages 1–12, 2024. 题名译文：双重信息增强的多视图属性图聚类。

Meng Liu, Hongyang Gao, and Shuiwang Ji. Towards deeper graph neural networks. In Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pages 338–348, 2020. 题名译文：迈向更深的图神经网络。

Jiyuan Liu, Xinwang Liu, Yuexiang Yang, Xifeng Guo, Marius Kloft, and Liangzhong He. Multiview subspace clustering via co-training robust data representation. IEEE Transactions on Neural Networks and Learning Systems, 33(10):5177–5189, 2022. 题名译文：通过协同训练鲁棒数据表示实现多视图子空间聚类。

Jiyuan Liu, Xinwang Liu, Yuexiang Yang, Qing Liao, and Yuanqing Xia. Contrastive multi-view kernel learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(8):9552–9566, 2023. 题名译文：对比式多视图核学习。

Jielong Lu, Zhihao Wu, Zhaoliang Chen, Zhiling Cai, and Shiping Wang. Towards multi-view consistent graph diffusion. In Proceedings of the 32nd ACM International Conference on Multimedia, pages 186–195, 2024. 题名译文：迈向多视图一致图扩散。

Jielong Lu, Zhihao Wu, Luying Zhong, Zhaoliang Chen, Hong Zhao, and Shiping Wang. Generative essential graph convolutional network for multi-view semi-supervised classification. IEEE Transactions on Multimedia, 26:7987–7999, 2024. 题名译文：用于多视图半监督分类的生成式本质图卷积网络。

Li Ma, Haoyu Han, Juanhui Li, Harry Shomer, Hui Liu, Xiaofeng Gao, and Jiliang Tang. Mixture of link predictors on graphs. In Advances in Neural Information Processing Systems, 2024. 题名译文：图上的链接预测器混合。

Rui Miao, Yixin Liu, Yili Wang, Xu Shen, Yue Tan, Yiwei Dai, Shirui Pan, and Xin Wang. Blindguard: Safeguarding llm-based multi-agent systems under unknown attacks. arXiv, 2025. 题名译文：Blindguard：在未知攻击下保护基于大型语言模型的多智能体系统。

Anasua Mitra, Priyesh Vijayan, Sanasam Ranbir Singh, Diganta Goswami, Srinivasan Parthasarathy, and Balaraman Ravindran. Semi-supervised deep learning for multiplex networks. In Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pages 1234–1244, 2021. 题名译文：面向多层网络的半监督深度学习。

Feiping Nie, Jing Li, and Xuelong Li. Parameter-free auto-weighted multiple graph learning: A framework for multiview clustering and semi-supervised classification. In Subbarao Kambhampati, editor, Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence, pages 1881–1887, 2016. 题名译文：无参数自动加权多图学习：多视图聚类与半监督分类框架。

Chanyoung Park, Donghyun Kim, Jiawei Han, and Hwanjo Yu. Unsupervised attributed multiplex network embedding. In Proceedings of the AAAI conference on artificial intelligence, pages 5371–5378, 2020. 题名译文：无监督属性多层网络嵌入。

Luana Ruiz, Luiz Chamon, and Alejandro Ribeiro. Graphon neural networks and the transferability of graph neural networks. In Advances in Neural Information Processing Systems, pages 1702–1712, 2020. 题名译文：Graphon 神经网络与图神经网络的可迁移性。

Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc Le, Geoffrey Hinton, and Jeff Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In International Conference on Learning Representations, 2017. 题名译文：超大规模神经网络：稀疏门控混合专家层。

Xu Shen, Yixin Liu, Yiwei Dai, Yili Wang, Rui Miao, Yue Tan, Shirui Pan, and Xin Wang. Understanding the information propagation effects of communication topologies in llm-based multi-agent systems. In EMNLP, 2025. 题名译文：理解通信拓扑在基于大型语言模型的多智能体系统中的信息传播效应。

Yuan Sun, Jian Dai, Zhenwen Ren, Yingke Chen, Dezhong Peng, and Peng Hu. Dual self-paced cross-modal hashing. In Thirty-Eighth AAAI Conference on Artificial Intelligence, pages 15184–15192, 2024. 题名译文：双重自步跨模态哈希。

Zhiqiang Tao, Hongfu Liu, Sheng Li, Zhengming Ding, and Yun Fu. Marginalized multiview ensemble clustering. IEEE Transactions on Neural Networks and Learning Systems, 31(2):600–611, 2019. 题名译文：边缘化多视图集成聚类。

Hinton G Van der Maaten L. Visualizing data using t-sne. Journal of Machine Learning Research, 2008. 题名译文：利用 t-SNE 可视化数据。

Petar Velickovic, William Fedus, William L Hamilton, Pietro Liò, Yoshua Bengio, and R Devon Hjelm. Deep graph infomax. In Proceedings of the International Conference on Learning Representations, 2019. 题名译文：深度图信息最大化。

Xinhang Wan, Xinwang Liu, Jiyuan Liu, Siwei Wang, Yi Wen, Weixuan Liang, En Zhu, Zhe Liu, and Lu Zhou. Auto-weighted multi-view clustering for large-scale data. In Thirty-Seventh AAAI Conference on Artificial Intelligence, pages 10078–10086, 2023. 题名译文：面向大规模数据的自动加权多视图聚类。

Xinhang Wan, Jiyuan Liu, Xinbiao Gan, Xinwang Liu, Siwei Wang, Yi Wen, Tianjiao Wan, and En Zhu. One-step multi-view clustering with diverse representation. IEEE Transactions on Neural Networks and Learning Systems, pages 1–13, 2024. 题名译文：采用多样化表示的一步式多视图聚类。

Xiao Wang, Houye Ji, Chuan Shi, Bai Wang, Yanfang Ye, Peng Cui, and Philip S Yu. Heterogeneous graph attention network. In Proceedings of the International World Wide Web Conference, pages 2022–2032, 2019. 题名译文：异构图注意力网络。

Haotao Wang, Ziyu Jiang, Yuning You, Yan Han, Gaowen Liu, Jayanth Srinivasa, Ramana Kompella, and Zhangyang “Atlas” Wang. Graph mixture of experts: Learning on large-scale graphs with explicit diversity modeling. In Advances in Neural Information Processing Systems, pages 50825–50837, 2023. 题名译文：图混合专家：通过显式多样性建模在大规模图上学习。

Haishuai Wang, Yang Gao, Xin Zheng, Peng Zhang, Jiajun Bu, and Philip S. Yu. Graph neural architecture search with large language models. In Science China Information Sciences, 2025. 题名译文：利用大型语言模型进行图神经架构搜索。

Yi Wen, Siwei Wang, Qing Liao, Weixuan Liang, Ke Liang, Xinhang Wan, and Xinwang Liu. Unpaired multi-view graph clustering with cross-view structure matching. IEEE Transactions on Neural Networks and Learning Systems, 35(11):16049–16063, 2024. 题名译文：采用跨视图结构匹配的非配对多视图图聚类。

Felix Wu, Amauri H. Souza Jr., Tianyi Zhang, Christopher Fifty, Tao Yu, and Kilian Q. Weinberger. Simplifying graph convolutional networks. In Proceedings of the International Conference on Machine Learning, volume 97, pages 6861–6871, 2019. 题名译文：简化图卷积网络。

Zhihao Wu, Xincan Lin, Zhenghong Lin, Zhaoliang Chen, Yang Bai, and Shiping Wang. Interpretable graph convolutional network for multi-view semi-supervised learning. IEEE Transactions on Multimedia, 25:8593–8606, 2023. 题名译文：用于多视图半监督学习的可解释图卷积网络。

Wei Xia, Qianqian Wang, Quanxue Gao, Xiangdong Zhang, and Xinbo Gao. Self-supervised graph convolutional network for multi-view clustering. IEEE Transactions on Multimedia, 24:3182–3192, 2022. 题名译文：用于多视图聚类的自监督图卷积网络。

Chang Xu, Dacheng Tao, and Chao Xu. Multi-view self-paced learning for clustering. In Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence, pages 3974–3980, 2015. 题名译文：用于聚类的多视图自步学习。

Keyulu Xu, Chengtao Li, Yonglong Tian, Tomohiro Sonobe, Ken-ichi Kawarabayashi, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In International conference on machine learning, pages 5453–5462, 2018. 题名译文：利用跳跃知识网络进行图表示学习。

Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. How powerful are graph neural networks? In International Conference on Learning Representations, 2019. 题名译文：图神经网络有多强大?

Pengyang Yu, Chaofan Fu, Yanwei Yu, Chao Huang, Zhongying Zhao, and Junyu Dong. Multiplex heterogeneous graph convolutional network. In Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pages 2377–2387, 2022. 题名译文：多层异构图卷积网络。

Chao Zhang, Deng Xu, Xiuyi Jia, Chunlin Chen, and Huaxiong Li. Continual multi-view clustering with consistent anchor guidance. In Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, pages 5434–5442, 2024. 题名译文：采用一致锚点引导的持续多视图聚类。

Yunhe Zhang, Jinyu Cai, Zhihao Wu, Pengyang Wang, and See-Kiong Ng. Mixture of experts as representation learner for deep multi-view clustering. In Proceedings of the AAAI Conference on Artificial Intelligence, pages 22704–22713, 2025. 题名译文：作为深度多视图聚类表示学习器的混合专家。

Meiqi Zhu, Xiao Wang, Chuan Shi, Houye Ji, and Peng Cui. Interpreting and unifying graph neural networks with an optimization framework. In Proceedings of the International World Wide Web Conference, pages 1215–1226, 2021. 题名译文：通过优化框架解释并统一图神经网络。

Meiqi Zhu, Xiao Wang, Chuan Shi, Yibo Li, and Junping Du. Towards adaptive information fusion in graph convolutional networks. IEEE Transactions on Knowledge and Data Engineering, 35(12):13055–13069, 2023. 题名译文：迈向图卷积网络中的自适应信息融合。

NeurIPS 论文检查清单

本检查清单旨在鼓励负责任的机器学习研究最佳实践，涵盖可复现性、透明度、研究伦理和社会影响等问题。请勿删除检查清单：不包含检查清单的论文将被直接拒稿。检查清单应置于参考文献及（可选的）补充材料之后。检查清单不计入页数限制。

请仔细阅读检查清单指南，了解如何回答这些问题。对于检查清单中的每个问题：

- 应回答 [Yes]、[No] 或 [NA]。
- [NA] 表示该问题对这篇论文不适用，或相关信息不可获得。
- 请在答案之后立即给出简短的（1–2 句）理由说明（即使答案为 NA 也应如此）。

检查清单的回答是论文投稿不可分割的组成部分。审稿人、领域主席、高级领域主席和伦理审稿人都可以看到这些回答。您还需要将其（经过可能的修订后）纳入论文最终版本，最终版本的检查清单将与论文一同发表。

论文审稿人将被要求把检查清单作为评估因素之一。虽然一般而言 “[Yes]” 优于 “[No]”，但只要给出适当理由，回答 “[No]” 完全可以接受（例如，“未报告误差条，因为计算成本过高”，或“我们未能找到所使用数据集的许可证”）。通常，回答 “[No]” 或 “[NA]” 并不构成拒稿理由。虽然问题

采用二元形式表述，但我们承认真实答案往往更加复杂，因此请根据自己的最佳判断作答，并通过理由说明加以阐释。所有支持性证据都可以出现在论文正文中，也可以出现在以附录形式提供的补充材料中。如果某个问题回答为 [Yes]，请在理由说明中指出可找到相关材料的章节。

重要事项，请：

- 删除本说明块，但保留“NeurIPS Paper Checklist”这一节标题。
- 保留下方检查清单的子节标题、问题／答案以及指南。
- 不要修改问题，且仅使用所提供的宏来填写答案。

1. 主张

问题： 摘要和引言中的主要主张是否准确反映了论文的贡献和范围?

回答： [Yes]

理由说明： 摘要和引言准确反映了论文的主张。

指南：

- 回答 NA 表示摘要和引言未包含论文提出的主张。
- 摘要和／或引言应明确陈述所提出的主张，包括论文的贡献以及重要的假设和局限性。对此问题回答 No 或 NA 不会得到审稿人的良好评价。
- 所提出的主张应与理论和实验结果相符，并反映这些结果在多大程度上有望推广到其他情境。
- 可以把愿景性目标作为动机，但必须明确指出论文尚未实现这些目标。

2. 局限性

问题： 论文是否讨论了作者所开展工作的局限性?

回答： [Yes]

理由说明： 结论中讨论了局限性。

指南：

- 回答 NA 表示论文没有局限性；回答 No 则表示论文存在局限性，但未在文中讨论。
- 鼓励作者在论文中设置独立的“局限性”一节。
- 论文应指出任何较强的假设，以及当这些假设被违反时结果的稳健程度（例如，独立性假设、无噪声情境、模型设定正确、仅在局部成立的渐近近似）。作者应思考这些假设在实践中可能如何被违反，以及会产生什么后果。
- 作者应思考所提出主张的适用范围，例如，方法是否只在少量数据集上或通过少数几次运行进行了测试。一般而言，实证结果往往依赖隐含假设，应明确阐述这些假设。
- 作者应思考影响方法性能的因素。例如，人脸识别算法在图像分辨率低或光线较暗的拍摄条件下可能表现不佳。又如，语音转文字系统可能因无法处理技术术语，而不能可靠地用于给在线讲座提供隐藏式字幕。

- 作者应讨论所提出算法的计算效率，以及其随数据集规模变化的扩展性。
- 如适用，作者应讨论其方法在解决隐私和公平性问题方面可能存在的局限性。
- 作者可能担心完全坦诚地说明局限性会被审稿人用作拒稿理由，但更糟糕的结果可能是审稿人发现了论文中未承认的局限性。作者应运用最佳判断，并认识到促进透明度的个体行动对于形成维护学术共同体诚信的规范具有重要作用。审稿人将被明确告知，不得因作者坦诚说明局限性而予以惩罚。

3. 理论假设与证明

问题： 对于每项理论结果，论文是否提供了全部假设以及完整（且正确）的证明?

回答： [Yes]

理由说明： 假设和证明包含在附录中。

指南：

- 回答 NA 表示论文不包含理论结果。
- 论文中的所有定理、公式和证明都应编号并进行交叉引用。
- 在陈述任何定理时，都应明确说明或引用全部假设。
- 证明可以出现在论文正文或补充材料中，但如果证明放在补充材料中，鼓励作者提供简短的证明概要，以帮助读者形成直观理解。
- 反过来，论文正文中给出的任何非正式证明，都应在附录或补充材料中以正式证明作为补充。
- 应恰当地引用证明所依赖的定理和引理。

4. 实验结果的可复现性

问题： 对于影响论文主要主张和／或结论的部分，论文是否充分披露了复现主要实验结果所需的全部信息（无论是否提供代码和数据）？

回答： [Yes]

理由说明： 复现论文主要实验结果所需的全部信息均已在正文、附录和源代码中提供。

指南：

- 回答 NA 表示论文不包含实验。
- 如果论文包含实验，对此问题回答 No 不会得到审稿人的良好评价：无论是否提供代码和数据，确保论文可复现都很重要。
- 如果贡献是数据集和／或模型，作者应描述为使结果可复现或可验证而采取的步骤。
- 根据贡献的不同，可以通过多种方式实现可复现性。例如，如果贡献是一种新架构，完整描述该架构可能就已足够；如果贡献是某个具体模型及其实证评估，则可能需要让他人能够使用同一数据集复现该模型，或者提供对模型的访问。一般而言，发布代码和数据往往是实现这一目标的良好方式，但也可以通过提供复现结果的详细说明、提供对托管模型的访问（例如大型语言模型）、发布模型检查点，或其他适合所开展研究的方式来实现可复现性。

- 尽管 NeurIPS 不要求发布代码，但会议确实要求所有投稿提供某种合理的复现途径，具体方式可取决于贡献的性质。例如：
  - (a) 如果贡献主要是一个新算法，论文应明确说明如何复现该算法。
  - (b) 如果贡献主要是一种新模型架构，论文应清晰、完整地描述该架构。
  - (c) 如果贡献是一个新模型（例如大型语言模型），则应提供访问该模型以复现结果的途径，或者提供复现该模型的方法（例如，使用开源数据集，或提供构建数据集的说明）。
  - (d) 我们认识到，在某些情况下实现可复现性可能较为困难，此时欢迎作者描述他们为复现所提供的具体方式。对于闭源模型，对模型的访问可能受到某种限制（例如，仅限注册用户），但其他研究者仍应有某种途径来复现或验证结果。

5. 数据和代码的开放获取

问题： 论文是否提供了对数据和代码的开放获取，并如补充材料所述，给出了足够的说明以忠实复现主要实验结果?

回答： [Yes]

理由说明： 代码可通过一个匿名链接获取。

指南：

- 回答 NA 表示论文不包含需要代码的实验。
- 更多详情请参阅 NeurIPS 代码和数据提交指南（https://nips.cc/public/guides/CodeSubmissionPolicy）。
- 虽然我们鼓励发布代码和数据，但我们理解这可能无法实现，因此“No”是可以接受的回答。不能仅因论文未包含代码就拒稿，除非代码是其贡献的核心部分（例如，提出一个新的开源基准）。
- 说明应包含复现结果时所需运行的准确命令及环境。更多详情请参阅 NeurIPS 代码和数据提交指南（https://nips.cc/public/guides/CodeSubmissionPolicy）。
- 作者应提供数据访问与准备说明，包括如何访问原始数据、预处理数据、中间数据和生成数据等。
- 作者应提供脚本，以复现所提出新方法和基线方法的全部实验结果。如果只能复现部分实验，应说明脚本省略了哪些实验以及原因。
- 投稿时，为保持匿名，作者应发布匿名化版本（如适用）。
- 建议在补充材料（附于论文之后）中提供尽可能多的信息，但也允许包含数据和代码的 URL。

6. 实验设置／细节

问题： 论文是否说明了理解结果所必需的全部训练和测试细节（例如，数据划分、超参数、超参数的选择方式、优化器类型等）？

回答： [Yes]

理由说明： 细节包含在附录中。

指南：

- 回答 NA 表示论文不包含实验。
- 论文正文中应以足以评估和理解结果的详细程度介绍实验设置。
- 完整细节可以随代码提供，也可以放在附录或补充材料中。

7. 实验的统计显著性

问题： 论文是否报告了定义恰当且正确的误差条，或关于实验统计显著性的其他适当信息?

回答： [NA]

理由说明： [NA]

指南：

- 回答 NA 表示论文不包含实验。
- 至少对于支持论文主要主张的实验，如果结果附有误差条、置信区间或统计显著性检验，作者就应回答“Yes”。
- 应明确说明误差条所涵盖的变异因素（例如，训练／测试划分、初始化、某些参数的随机抽取，或给定实验条件下的整体运行）。
- 应解释误差条的计算方法（闭式公式、调用库函数、自助法等）。
- 应给出所采用的假设（例如，误差服从正态分布）。
- 应明确说明误差条表示的是标准差还是均值的标准误。
- 可以报告 1-sigma 误差条，但应明确说明。如果尚未验证误差正态性假设，作者最好报告 2-sigma 误差条，而不是声称具有 96% 的置信区间。
- 对于非对称分布，作者应注意，不要在表格或图中展示会产生超出取值范围结果的对称误差条（例如，负的错误率）。
- 如果表格或图中报告了误差条，作者应在正文中解释其计算方式，并在正文中引用对应的图或表。

8. 实验计算资源

问题： 对于每项实验，论文是否提供了足够的信息，说明复现实验所需的计算资源（计算工作节点类型、内存、执行时间）？

回答： [Yes]

理由说明： 计算资源在附录中有详细说明。

指南：

- 回答 NA 表示论文不包含实验。
- 论文应说明计算工作节点的类型（CPU 或 GPU）、内部集群或云服务提供商，并包括相关的内存和存储信息。
- 论文应提供每次单独实验运行所需的计算量，并估算总计算量。

- 论文应披露整个研究项目是否需要比文中报告的实验更多的计算资源（例如，未被纳入论文的初步实验或失败实验）。

9. 伦理准则

问题： 论文所开展的研究是否在各方面都符合 NeurIPS 伦理准则（https://neurips.cc/public/EthicsGuidelines）？

回答： [Yes]

理由说明： 论文所开展的研究符合 NeurIPS 伦理准则。

指南：

- 回答 NA 表示作者未查阅 NeurIPS 伦理准则。
- 如果作者回答 No，应解释为何特殊情况要求偏离伦理准则。
- 作者应确保保持匿名（例如，若由于所在司法辖区的法律或法规而有特殊考虑）。

10. 更广泛的影响

问题： 论文是否讨论了所开展工作潜在的正面和负面社会影响?

回答： [NA]

理由说明： 所开展的工作没有社会影响。

指南：

- 回答 NA 表示所开展的工作没有社会影响。
- 如果作者回答 NA 或 No，应解释为什么其工作没有社会影响，或为什么论文未讨论社会影响。
- 负面社会影响的例子包括潜在的恶意或非预期用途（例如，虚假信息、生成虚假个人档案、监控）、公平性考量（例如，部署可能作出对特定群体造成不公平影响之决策的技术）、隐私考量和安全考量。
- 会议预期许多论文属于基础研究，并不与特定应用相关，更不用说部署。然而，如果存在通向任何负面应用的直接路径，作者应予以指出。例如，指出生成模型质量的提升可能被用于生成深度伪造内容以传播虚假信息，是合理的。另一方面，无需指出一个用于优化神经网络的通用算法可能使人们更快地训练生成深度伪造内容的模型。
- 作者应考虑以下情况下可能出现的危害：技术按预期使用且正常运行时；技术按预期使用但给出错误结果时；以及技术被（有意或无意）滥用时。
- 如果存在负面社会影响，作者也可以讨论可能的缓解策略（例如，限制模型发布和访问、除攻击方法外也提供防御方法、监测滥用的机制、监测系统如何随时间从反馈中学习的机制，以及提高机器学习的效率和可及性）。

11. 防护措施

问题： 论文是否描述了为负责任地发布具有较高滥用风险的数据或模型（例如，预训练语言模型、图像生成器或抓取的数据集）而采取的防护措施?

回答： [NA]

理由说明： 论文不存在此类风险。

指南：

- 回答 NA 表示论文不存在此类风险。
- 对于具有较高滥用或双重用途风险的模型，应在发布时配套必要的防护措施，以实现对模型使用的管控，例如，要求用户遵守使用指南或访问模型的限制，或实施安全过滤器。
- 从互联网抓取的数据集可能带来安全风险。作者应描述如何避免发布不安全的图像。
- 我们认识到，提供有效的防护措施具有挑战性，而且许多论文并不需要这些措施；但我们鼓励作者考虑这一点，并尽最大诚意作出努力。

12. 现有资源的许可证

问题： 论文所使用资源（例如，代码、数据、模型）的创建者或原始所有者是否得到了恰当的署名致谢，是否明确提及并恰当遵守了许可证及使用条款?

回答： [Yes]

理由说明： 论文所使用资源（例如，代码、数据、模型）的创建者或原始所有者得到了恰当的署名致谢，并且明确提及且恰当遵守了许可证及使用条款。

指南：

- 回答 NA 表示论文未使用现有资源。
- 作者应引用产生该代码包或数据集的原始论文。
- 作者应说明所使用资源的版本，并尽可能提供 URL。
- 应列出每项资源的许可证名称（例如，CC-BY 4.0）。
- 对于从特定来源（例如，网站）抓取的数据，应提供该来源的版权和服务条款。
- 如果发布资源，应提供资源包中的许可证、版权信息和使用条款。对于常用数据集，paperswithcode.com/datasets 已整理了一些数据集的许可证。其许可指南可以帮助确定数据集的许可证。
- 对于重新打包的现有数据集，应同时提供原始许可证和衍生资源的许可证（如有变更）。
- 如果无法在线获取此信息，鼓励作者联系资源的创建者。

13. 新资源

问题： 论文中引入的新资源是否有完善的文档，并且文档是否随资源一并提供?

回答： [NA]

理由说明： 本文未发布新资源。

指南：

- 回答 NA 表示论文未发布新资源。
- 研究者应通过结构化模板，将数据集／代码／模型的详细信息作为投稿的一部分进行说明。这包括训练、许可证、局限性等方面的细节。
- 论文应讨论是否以及如何获得了其资源被使用者的同意。
- 投稿时，请记得对资源进行匿名化处理（如适用）。可以创建匿名 URL，或附上匿名化的 zip 文件。

14. 众包和涉及人类受试者的研究

问题： 对于众包实验和涉及人类受试者的研究，论文是否包含了向参与者提供的说明全文及截图（如适用），以及报酬的详细信息（如有）？

回答： [NA]

理由说明： 论文不涉及众包，也不涉及人类受试者研究。

指南：

- 回答 NA 表示论文不涉及众包，也不涉及人类受试者研究。
- 可以将这些信息放在补充材料中，但如果论文的主要贡献涉及人类受试者，则应在正文中尽可能详细地说明。
- 根据 NeurIPS 伦理准则，从事数据收集、整理或其他劳动的工作人员，其报酬至少应达到数据收集者所在国家的最低工资标准。

15. 涉及人类受试者研究的机构审查委员会（IRB）批准或同等批准

问题： 论文是否描述了研究参与者可能面临的风险、是否向受试者披露了这些风险，以及是否获得了机构审查委员会（IRB）的批准（或根据所在国家或机构的要求获得同等的批准／审查）？

回答： [NA]

理由说明： 论文不涉及众包，也不涉及人类受试者研究。

指南：

- 回答 NA 表示论文不涉及众包，也不涉及人类受试者研究。
- 根据研究所在国家的规定，任何人类受试者研究都可能需要 IRB 批准（或同等批准）。如果已获得 IRB 批准，应在论文中明确说明。
- 我们认识到，不同机构和地区的相关程序可能有很大差异；我们希望作者遵守 NeurIPS 伦理准则以及所属机构的指南。
- 首次投稿时，不要包含任何会破坏匿名性的信息（如适用），例如开展审查的机构名称。

16. 大型语言模型使用声明

问题： 如果大型语言模型（LLM）是本研究核心方法中重要的、原创的或非常规的组成部分，论文是否描述了其使用情况？请注意，如果 LLM 仅用于写作、编辑或排版，且不影响研究的核心方法、科学严谨性或原创性，则无需声明。

回答： [NA]

理由说明： 本研究的核心方法开发不涉及将 LLM 用作任何重要的、原创的或非常规的组成部分。

指南：

- 回答 NA 表示本研究的核心方法开发不涉及将 LLM 用作任何重要的、原创的或非常规的组成部分。
- 关于哪些内容应当或不应当描述，请参阅我们的 LLM 政策（https://neurips.cc/Conferences/2025/LLM）。