裁出并回放：一种简单而通用的多标签在线持续学习策略

Xinrui Wang[12]、Shao-Yuan Li[123]、Jiaqiang Zhang[12]、Songcan Chen[12]

[1] 南京航空航天大学计算机科学与技术学院，南京 211106。[2] 南京航空航天大学模式分析与机器智能工业和信息化部重点实验室，南京 211106。[3] 南京大学计算机软件新技术国家重点实验室，中国。通讯作者：Songcan Chen，s.chen@nuaa.edu.cn。

原文：Wang, X., Li, S.-Y., Zhang, J., & Chen, S. (2025). Cut out and Replay: A Simple yet Versatile Strategy for Multi-Label Online Continual Learning. 第42届国际机器学习大会，温哥华，加拿大；PMLR 267:63530–63548。官方出版页：https://proceedings.mlr.press/v267/wang25bg.html 。版权归原作者所有。本译文为依据官方出版版本制作的非官方中文翻译，未获作者审定；翻译、排版及图表中文字释义为本次改编。原文采用 CC BY 4.0，详见同目录许可说明。图表数值、符号及图像保留原貌，全部说明文字另译。

摘要

多标签在线持续学习（MOCL）要求模型持续地从无尽的多标签数据流中学习，面临持续存在的灾难性遗忘、潜在的标签缺失以及不可控的类别分布不平衡等复杂挑战。现有 MOCL 方法虽尝试通过各种技术处理这些挑战，却都忽略了标签特定区域识别和特征学习——这是植根于多标签学习的根本解决途径，但在监督信息增量到达且不完整的在线场景中很难实现。为此，我们首先利用输入数据固有的结构信息，评估并验证不同预训练模型内在的定位能力。随后，我们提出 CUTER（CUT-out-and-Experience-Replay，裁出与经验回放）：这是一种简单而通用的策略，通过进一步识别、增强并裁出标签特定区域，为高效的经验回放提供细粒度监督信号。它不仅使模型能够同时应对灾难性遗忘、标签缺失和类别不平衡，也是一种可与现有方法无缝集成的正交解决方案。在多个多标签图像基准上的大量实验证明了所提方法的优越性。代码：https://github.com/wxr99/Cut-Replay 。

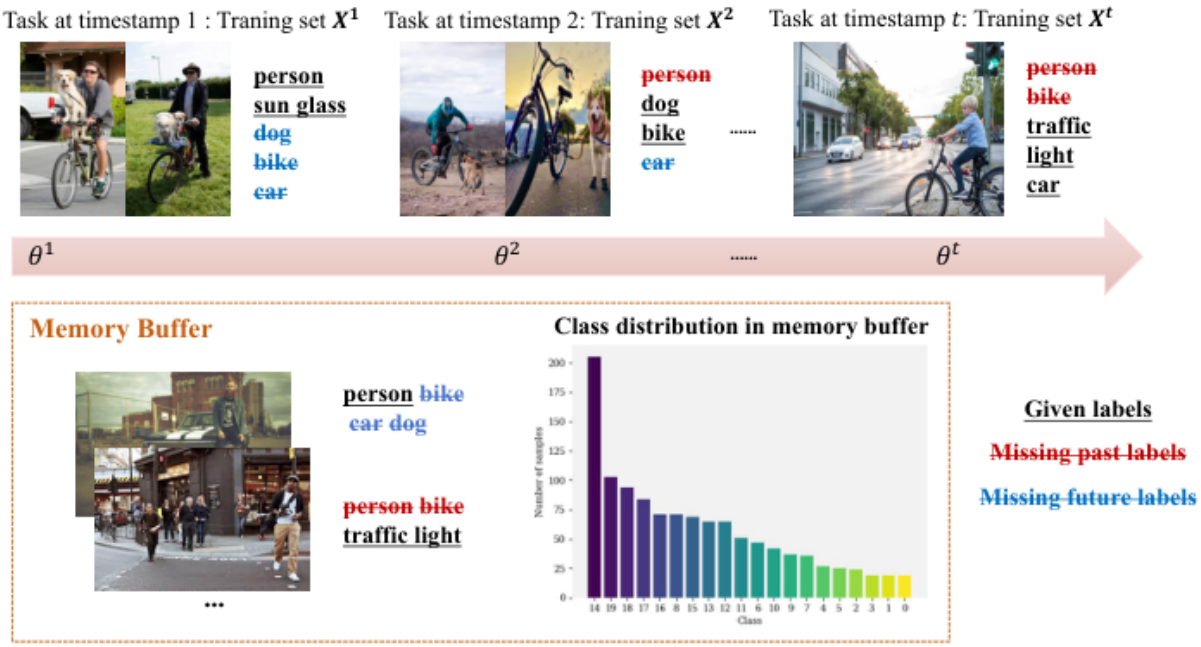


图1。 相较于传统 OCL，MOCL 特有的两个挑战：（1）到达的数据流和记忆缓冲区中，都存在大量缺失的过去标签和未来标签。（2）即使采用 CEBS（Wei & Li, 2019a；Yan et al., 2021）等再平衡策略，记忆缓冲区仍存在严重类别不平衡。图内文字：时间戳1/2/ t 的任务；训练集；记忆缓冲区；记忆缓冲区中的类别分布；给定标签、缺失的过去标签、缺失的未来标签。类别：人、太阳镜、狗、自行车、汽车、交通灯。

1. 引言

在线持续学习（OCL）使模型能够从连续、无尽的数据流中学习。通过知识蒸馏、梯度正则化、经验回放等各种缓解灾难性遗忘的技术，该领域已取得显著进展。

然而，这些 OCL 方法主要关注单标签分类，而现实数据往往包含多个语义概念和对象，这推动了多标签在线持续学习（MOCL）的研究（Kim et al., 2020）。图1给出示例。在每个时间步 t，任务 t 中与标签空间 Y_t 相关的训练数据 D_t 以流的形式到达。对于每个样本 $(x, y) \in D_t$，$y \subset Y_t$ 表示已标注的相关标签集合。给定由 T 个任务构成的序列，MOCL 的目标是在防止先前所学任务发生灾难性遗忘的同时，使学习模型高效适应当前任务。

与单标签场景相比，MOCL 面临两个特有的数据挑战：（1）普遍存在的标签缺失：任务 t 中的样本仅标注来自 Y_t 的标签，即使其中包含旧类别 $Y_{1:t-1}$ 或未来类别 $Y_{t+1:T}$ 的对象。这些未标注类别成为假负例，加剧灾难性遗忘。（2）不可控的类别不平衡：类别通常服从长尾分布。在此类数据上训练，会使模型偏向于对头部类别过拟合、对尾部类别欠拟合。同一样本中头部与尾部类别的共现进一步增加了问题的复杂性。

已有若干工作尝试解决这些挑战。Kim et al. (2020) 首先发现长尾场景中少数类别的严重遗忘，并提出分区蓄水池采样（PRS）策略，在基于回放的方法中平衡头部与尾部类别。为解决 PRS 的计算效率问题，Liang & Li (2022) 提出记忆中类别分布优化（OCDM），将记忆更新重写为样本选择优化问题，并用线性时间贪心算法求解。Du et al. (2022) 首先强调 MOCL 中的标签缺失挑战，提出增强图卷积网

络（AGCN）。该模型为此前见过的类别生成预测，同时刻画连续任务之间的动态标签关系，并通过蒸馏损失和关系保持损失缓解遗忘。在此基础上，Dong et al. (2023) 提出知识恢复与迁移（KRT）框架，将旧类别的动态伪标签与会话特定的知识迁移相结合。近期，Du et al. (2024) 通过非对称知识蒸馏（AKD）和在线重标注（OR）两个关键组件同时处理这两项挑战。AKD 在分类损失中强调负标签学习，同时减少蒸馏损失中过度自信预测的影响，从而重新平衡学习过程。OR 则通过在线重标注恢复记忆缓冲区中的缺失标签，与其形成互补。

尽管这些工作取得了有希望的结果，其特征学习机制对于多标签数据仍有固有局限。传统做法为每个样本提取一个特征向量，再结合伪标签、重采样等技术，会受到头部和尾部类别之间共现偏差的影响。这一局限在标签缺失和类别不平衡下尤其关键，因为学习判别性特征需要尽量减少标签共现模式的干扰。

基于上述认识，我们转向标签特定特征学习。在离线多标签学习中，这类特征已被证明优于统一的样本级特征（Zhang & Wu, 2014）。假设我们能够通过直接的裁出并回放机制，成功识别图像中标签特定的区域，即裁出这些区域并存入记忆缓冲区用于回放。该机制便会自然避免标签共现干扰和标签缺失问题。此外，通过在缓冲区存储对象级区域与监督信号，可以在相同记忆开销下实现更有效的经验回放，并通过控制缓冲区的类别分布轻松解决类别不平衡。

为此，我们提出 CUTER（裁出与经验回放），一种简单而通用的方法，通过高效定位、增强并裁出标签特定区域，为 MOCL 提供更丰富的细粒度监督信号。受近期视觉预训练模型零样本粗分割能力探索的启发（Caron et al., 2021；Siméoni et al., 2021；Wang et al., 2023b），我们深入研究了预训练模型的定位能力。通过在若干广泛使用的预训练模型（例如 DINO、MoCo、MAE）上开展大量实证验证，并建立图论支持，我们表明：特征图块相似度图的平均 Fiedler 值（图拉普拉斯矩阵的第二小特征值），可以作为有效的评估指标，用于选择擅长精确定位标签特定区域的预训练模型。随后，根据预测置信度和标签对齐关系，将识别出的显著区域选择性地存入记忆缓冲区，从而有效地把多标签图像分类回放转化为多个单标签子图像分类任务。为进一步抵御持续学习过程中模型定位能力的遗忘，我们借鉴图像分割原理，在基于特征的相似度邻接矩阵上加入低秩约束，改善图块间可分性，以获得更精确的区域裁剪，并以图谱理论为依据。

作为与现有 OCL 模型正交的方案，本方法能够与已有模型无缝集成，共同应对灾难性遗忘、标签缺失和类别不平衡。我们在多个多标签图像基准上进行了大量实验，表明本方法显著优于 MOCL 中的最先进方法。总之，主要贡献有三点：（i）将标签特定学习引入 MOCL，并首次系统分析预训练模型用于 MOCL 的潜力；（ii）提出简单而通用的回放策略 CUTER，在处理灾难性遗忘、标签缺失、类别不平衡的同时提升模型性能；（iii）大量实验和消融研究表明，CUTER 不仅达到最先进性能，也可作为互补组件与现有方法无缝集成。

2. 方法

本节关注如何更好地提取并利用标签特定区域来解决 MOCL 问题。方法包含三个关键步骤。首先，提出无需标注的评估协议，评估常见预训练模型在 MOCL 中的零样本定位潜力。其次，利用选定预训练模型及其定位能力，设计简单而通用的裁出并回放策略，实现有效、高效的区域—标签匹配、裁剪和存储。最后，为防止 MOCL 过程中模型定位能力退化，加入一个正则项，持续巩固并增强模型的定位与分割能力。

2.1. 预训练模型的零样本定位评估

裁出并回放策略的一项关键前提，是根据预训练模型固有的定位能力找到合适的模型。近期研究表明，先进的视觉预训练模型能通过特征聚类自然定位对象（Caron et al., 2021；Siméoni et al., 2021），因此可能适用于 MOCL。然而，传统评估指标需要真实框或掩码，这并不现实，因为大多数多标签数据集缺乏此类标注。这促使我们开发无需标注的评估协议。

为解决该挑战，我们提出一种受图论和谱聚类启发的新评估指标。关键洞见来自对 Normalized Cut（NCut；Shi & Malik, 2000）、Mask Cut（MCut；Wang et al., 2023a）以及 Token Cut（TCut；Wang et al., 2023b）等常见无监督定位方法的考察。当特征图构成的图具有更强分离性（更弱连通性）时，这些方法表现更好；数学上可用 Cheeger 常数刻画这一性质：

定义2.1。（Royle & Godsil, 2001）设 $G = (V, E, W)$ 是加权图，顶点集为 V，边集为 E，边权矩阵为 W。Cheeger 常数 $h(G)$ 定义为：

$$h(G) = \min_{S \subset V} \frac{\mathcal{C}(S, V \setminus S)}{\min\{\mathcal{C}(S, V), \mathcal{C}(V \setminus S, V)\}}$$

其中，S 是 V 的非空子集，$V\setminus S$ 为其补集，$\mathcal{C}(\cdot)$ 度量两个集合之间的相似性，例如 $\mathcal{C}(A, B) = \sum_{v_i \in A, v_j \in B} W_{ij}$。

虽然计算 Cheeger 常数是 NP 难的，但可以利用它与图 Fiedler 值之间的关系，如下述引理2.2所示。给定样本的特征图 $\theta(x)$，可构造加权无向图 $G = (V, E, A)$，其中顶点代表图像图块的特征向量，边权 $A_{ij} = exp\left(- \| \theta(x_i) - \theta(x_j) \|^2 / (2\sigma^2) \right)$ 用高斯核编码图块连通性。随后，将 Fiedler 值 λ_2 计算为图拉普拉斯矩阵 $L = D - A$ 的第二小特征值，其中 D 为 $N \times N$ 对角度矩阵，其元素 $d(i) = \sum_j A_{ij}$。

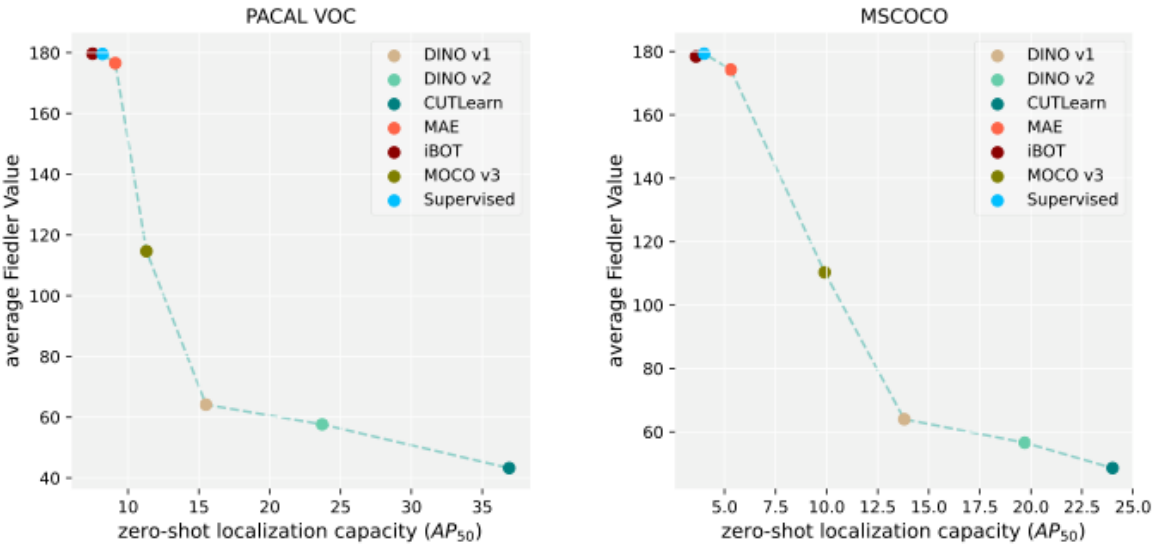


图2。 Pascal VOC07 与 MSCOCO 上平均 Fiedler 值和零样本检测性能（ AP_{50} ）之间的相关性。纵轴：平均 Fiedler 值；横轴：零样本定位能力（ AP_{50} ）。图例中的 Supervised 表示有监督预训练。

引理2.2。（Chung, 1997）对于加权无向图 G，令 λ_2 为其 Fiedler 值， $h(G)$ 为其 Cheeger 常数， $\Delta = \max_i d(i)$ 为图中的最大度，则：

$$\frac{\lambda_2}{2} \leq h(G) \leq \sqrt{2\Delta\lambda_2}$$

基于这一理论基础，我们提出：在下游数据集的一个小型子集上提取特征，计算其平均 Fiedler 值，以评估模型潜在的零样本定位能力。如图2和图3所示，零样本定位性能与图块特征图的平均 Fiedler 值之间存在明显相关性。这与图论原理一致：较低的平均 Fiedler 值表示较弱的图连通性（Royle & Godsil, 2001），意味着更强的特征可分性，因而更适合 MCut、NCut 等基于划分的操作。

将该指标用于 MoCo（He et al., 2020；Chen et al., 2020；Chen* et al., 2021）、DINO（Caron et al., 2021；Oquab et al., 2023）、MAE（He et al., 2022）、iBOT（Zhou et al., 2022）等常用预训练模型，我们发现多裁剪一致性训练显著增强了内在定位能力。相反，基于重建的训练天然鼓励恢复过程中的特征共享，可能限制基于谱聚类的定位方法的效果。详细分析见附录D。简言之，如果能够获得部分下游任务数据，就可以通过计算平均 Fiedler 值评估模型；但若未来任务完全未知，选择采用多裁剪一致性预训练的模型可能更可靠。

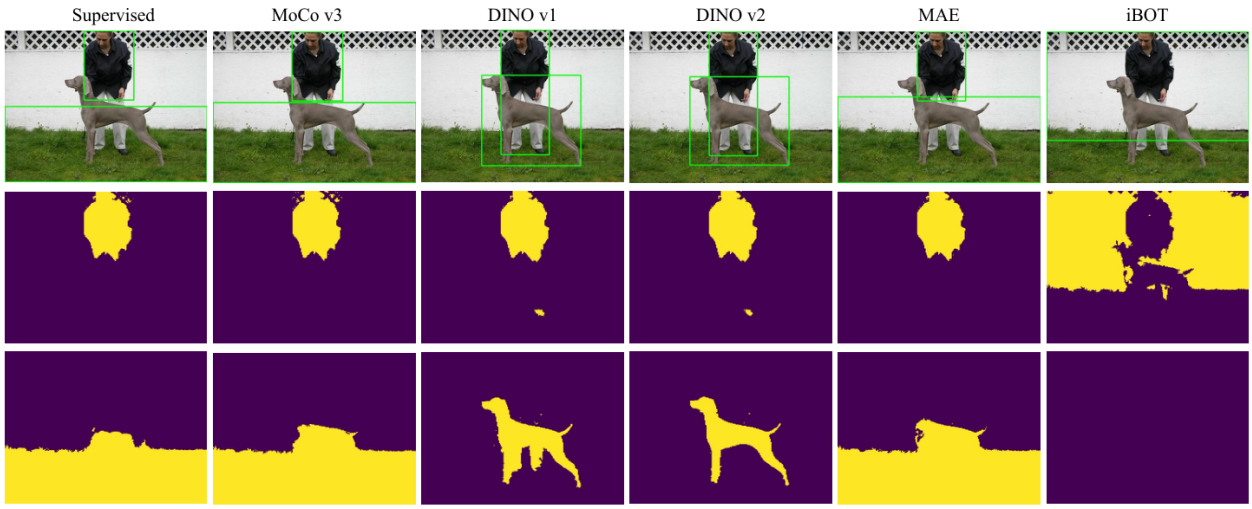


图3。 采用 ViT-S/16 骨干的不同预训练模型，在两轮 MaskCut（Wang et al., 2023a）处理后得到的检测（粗边界框）和分割（粗掩码）能力的可视化比较。Supervised：有监督模型；其余列为 MoCo v3、DINO v1、DINO v2、MAE、iBOT。

2.2. 通过标签—区域匹配进行选择性回放

根据所提出的平均 Fiedler 值选择初始化模型后，要实现设想中的裁出并回放策略，下一项障碍是建立图像区域与相应标签之间精确的一一对应关系。

$$L_{asl} = \frac{1}{|\mathcal{C}_k|}\sum_{c=1}^{|\mathcal{C}_k|}\begin{cases}(1-p_c)^{\gamma^+}log(p_c), & y_c = 1,\\ p_c^{\gamma^-}log(1-p_c), & y_c = 0,\end{cases} \tag{1}$$

式（1）。 保留官方原版公式的符号字形与正负号。

为此，对每个到达的数据对 $(x,\ y)$，计算预测 $p = f(x)$，并与多数 MOCL 方法一样采用非对称损失（式1）。其中，y_c 是表示类别 c 是否存在的二元标签，$\gamma^+,\ \gamma^-$ 分别为正、负聚焦参数。随后采用 MCut 生成一组二元掩码 $\{m_j\}_{j=1}^{N}$，识别潜在前景对象；N 是决定 MCut 迭代次数的超参数（MCut 的详细背景与过程见附录B）。利用这些二元掩码得到边界框 $\{(h_1^j,\ w_1^j,\ h_2^j,\ w_2^j)\}_{j=1}^{N}$，从输入图像 x 提取 N 个潜在前景对象 $\{x_{obj}^j\}_{j=1}^{N}$。

调整提取对象 $\{x_{obj}^j\}$ 的大小后，再次将其送入分类模型，得到前景对象预测 $p_{obj}^j = f\left(x_{obj}^j\right)$。表6（CUTER 与固定骨干 CUTER 的对比）的实验结果表明：对于 MOCL 中的对象定位，采用非对称损失（式1；Ridnik et al., 2021）训练的模型，优于 DINO 等固定预训练骨干，在识别当前任务类别（$\mathcal{C}^k$）以及定位给定标签对应区域方面表现更好。利用这一持续更新的模型裁出区域后，我们希望回放提取出的对象，而非像以往工作那样回放整幅图像。

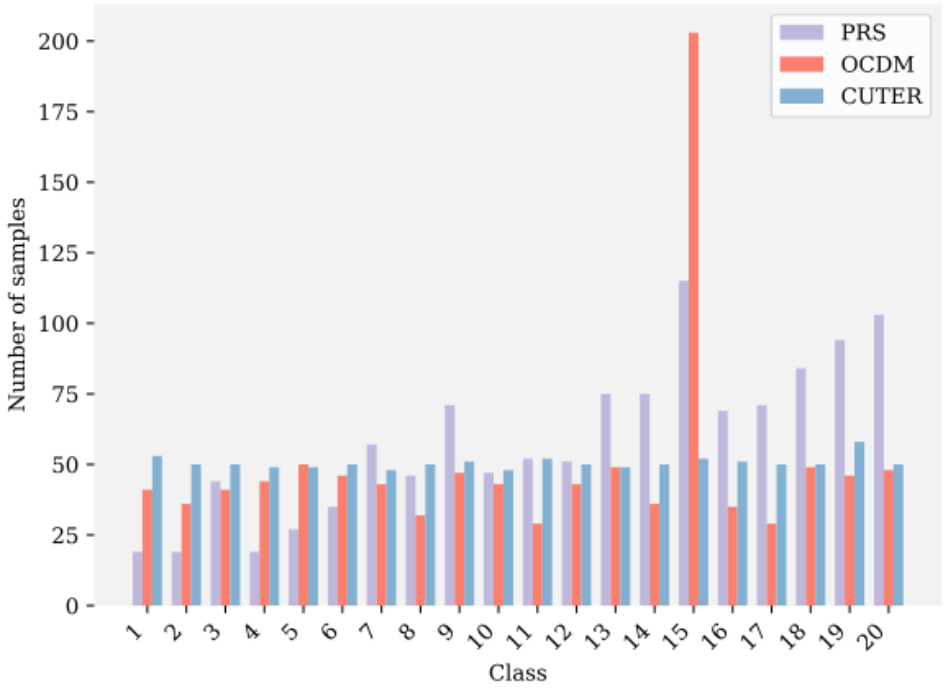


图4。 在 VOC 数据集上训练后，不同再平衡方法的记忆缓冲区（大小为1000）中的类别分布。纵轴：样本数；横轴：类别；图例：PRS、OCDM、CUTER。

对象集合 $\{x_{obj}^{j}\}_{j=1}^{N}$ 的存储包含两个步骤。首先，为建立可靠的标签—区域对应关系，只保留调整大小后仍有较高分类置信度、且对应单个标签的对象。具体而言，对于预测 p_{obj}^{j}，若满足下式，则将提取对象 x_{obj}^{j} 选入记忆缓冲区候选集：

$$p_{obj,(1)}^{j} > \tau \wedge p_{obj,(2)}^{j} < 0.5 \qquad (2)$$

其中，$p_{obj,(k)}^{j}$ 表示 p_{obj}^{j} 中第 k 大元素，τ 为置信度阈值。同时，为平衡记忆缓冲区的类别分布，我们根据类别频率采用两个阈值 τ_1 和 τ_2（$\tau_1 < \tau_2$）。对于频率低于最常见类别一半的类别，使用较低阈值 τ_1，其余使用 τ_2。

其次，对记忆缓冲区采用改进的再平衡蓄水池采样策略。新候选对象的采样概率为 $1 - m/m_{max}$，其中 m 表示缓冲区中预测标签 $y = argmax\left(p_{obj}^{j}\right)$ 的样本数，m_{max} 是最常见类别的样本数。为保持类别平衡，缓冲区满时从最常见类别中随机删除样本。如图4所示，这种直接的采样策略以较低计算开销获得了比 OCDM（Liang & Li, 2022）和 PRS（Kim et al., 2020）更好的类别平衡。仅存储与单标签对应的区域，使我们可以直接控制类别分布，以更少记忆成本保留更多判别信息。

2.3. 定位感知特征正则化

目前，我们已介绍保存单标签区域及其对应特征的裁出并回放策略。尽管该策略通过节省记忆的回放机制有效维持了模型对过去类别的分类性能，并表现出对新类别的良好适应性，我们仍观察到：从预训练模型继承的定位能力会在 MOCL 过程中逐渐退化，这一现象类似持续学习中的灾难性遗忘。如图5所示，退化表现为平均 Fiedler 值升高和对象定位失败增多。

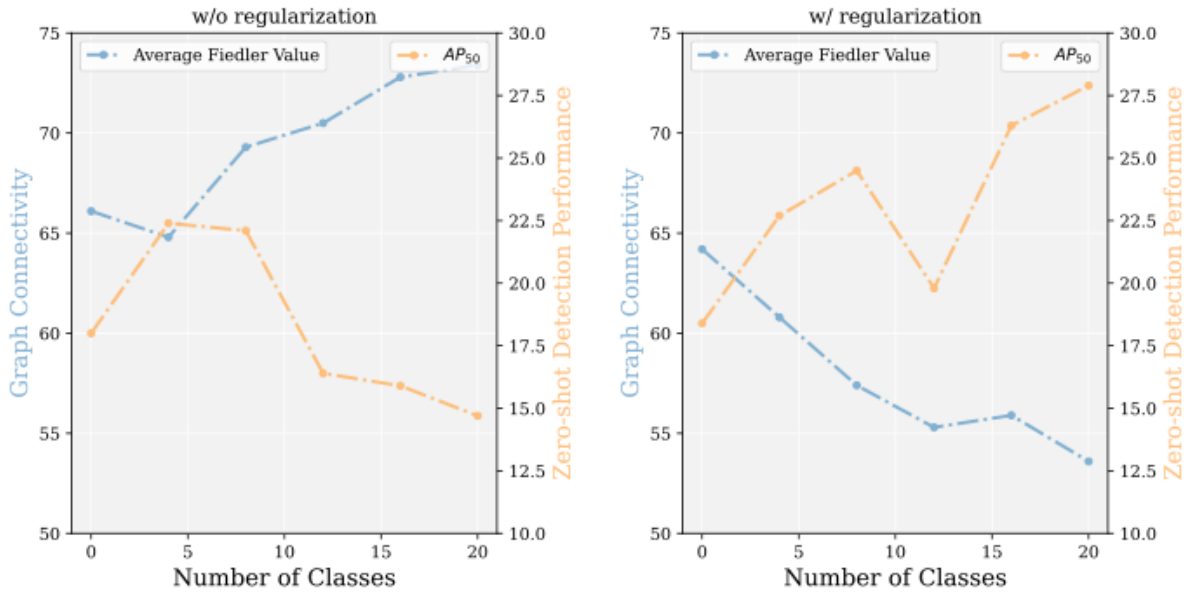


图5。 MOCL 训练期间模型在 PASCAL VOC 数据集上的零样本定位能力可视化。左：无正则化；右：有正则化。横轴：类别数量；左纵轴：图连通性；右纵轴：零样本检测性能。曲线：平均 Fiedler 值、AP_{50}。

上一节分析揭示，模型定位性能与图块特征图的平均 Fiedler 值之间有很强的相关性。由此自然产生一个问题：能否通过最小化特征图的图拉普拉斯 Fiedler 值，改善定位精度，进而改善 MOCL 性能？然而，由于图拉普拉斯矩阵特征值排序操作不可微，无法直接通过神经网络优化 Fiedler 值。受对称矩阵谱扰动理论启发，我们从另一角度处理该问题。为有效定位对象，理想特征图应具有较高的对象内特征相似度，同时保持较低的对象间相关性。数学上，这一性质可以表示为近似对称块对角结构的邻接矩阵 A，其秩 k 对应输入图像 x 中不同对象的数量。从理论上可保证，这种结构化邻接矩阵在 NCut 或 MCut 准则下产生最优二划分。

不失一般性，可假设训练期间每个特征图的邻接矩阵都可分解为 $A = A^* + \epsilon$，其中 A^* 是理想块对角矩阵，ϵ 是非稀疏噪声矩阵。基于这些假设，可证明特征图的 Fiedler 值直接以上述扰动矩阵 ϵ 的范数为上界。

定理2.3。 对于任意可写为块对角矩阵 A^* 与对角元素为零的噪声矩阵 ϵ 之和的邻接矩阵 A，其拉普拉斯矩阵 L 的第二小特征值（Fiedler 值）满足：

$$\lambda_2(L) \leq \|\epsilon\|_2 + \|\epsilon\|_\infty$$

定理2.3提供了一个可计算、可微的替代途径，以增强模型定位能力。虽然在 MOCL 训练中无法得到每个样本特征的理想邻接矩阵 A^*，因而不能直接约束对应噪声矩阵 ϵ，但考虑到我们的目标是引导邻接矩阵 A 趋向理想块对角结构，直接约束 A 也是可行选择，如式3所示。

$$L = L_{asy}(f, x, y) + R(A) \tag{3}$$

这种矩阵分解视角与通过抑制噪声实现稳健图结构学习相关。借鉴图学习中常用的正则项（低秩、稀疏性、平滑性），我们发现核范数 $R(A) = \| A \|_*$ 在减少 MOCL 中噪声矩阵 ϵ 方面尤其有效（图5）。详细比较与进一步分析见表3和附录D。至此，我们已完整介绍用于 MOCL 的裁出与经验回放策略 CUTER，详细算法流程见算法1。证明见附录C.2，详细解释见附录D.2。

算法1：带正则化的多标签在线持续学习 CUTER。

1. 输入：在线流式数据 (x, y)，预训练编码器 θ_0，分类器 ϕ，模型 $f = \phi \circ \theta$。
2. 初始化：记忆缓冲区 $\mathcal{M} \leftarrow \{\}$，候选集 $\mathcal{C} \leftarrow \{\}$，$\theta \leftarrow \theta_0$。
3. 对 $i = 1$ 至 N 执行:
4. 　　执行 MCut 得到前景对象 x_{obj}：
5. 　　　　最小化式4。
6. 　　　　用式6计算掩码。
7. 　　按照以下规则将对象选入候选集 $\mathcal{C}$：
8. 　　　　预测 $p_{obj} = f(x_{obj})$。
9. 　　　　选择阈值（式2）。
10. 结束循环。
11. 根据特征 $\theta(x)$ 计算邻接矩阵 A，并用式3计算损失。
12. 按照式1回放记忆数据 (x^m, y^m)。
13. 更新模型参数 f。
14. 若 $\mathcal{M}$ 未满:
15. 　　将候选集 $\mathcal{C}$ 放入记忆缓冲区 $\mathcal{M}$。
16. 结束条件分支。
17. 若 $\mathcal{M}$ 已满:
18. 　　按类别平衡概率从 $\mathcal{C}$ 中采样，更新记忆缓冲区 $\mathcal{M}$。
19. 结束条件分支。

3. 实验

3.1. 数据集与实验设置

数据集。 遵循以往工作（Dong et al., 2023；Liang & Li, 2022）的实验框架，我们在 MS-COCO 2014（Lin et al., 2014）、PASCAL VOC 2007（Everingham et al., 2015）以及 NUS-WIDE（Chua et al., 2009）三个基准数据集上评估方法。具体而言，PASCAL VOC 2007 含20类、5011张训

练图像和4952张测试图像，平均每张图像2.4个标签。MS-COCO 含80类、82081张训练图像和40504张验证图像，平均每张图像2.9个标签。由于 NUS-WIDE 已不再公开可用，我们从 Flickr 重新抓取并重建数据集，得到81类、126034张训练图像和84226张测试图像，平均每张图像2.4个标签。

实验设置。 遵循以往研究（Mai et al., 2021；Liang & Li, 2022；Dong et al., 2023），将数据集划分为若干任务：给定标签集互不相交，但真实标签支持集重叠，以模拟现实多标签数据流。不同于依赖基础任务的一些多标签类别增量研究，我们认为，在使用预训练模型的情况下，在线学习器应能够从任何起点迅速适应动态数据流。因此，将 PASCAL VOC 2007 分为5个任务，每个4类；MS-COCO 分为8个任务，每个10类；NUS-WIDE 分为8个任务，首个11类，其余每个10类。对所有数据集，类别分配至任务的顺序遵循类别名称的字典序，具体如 Dong et al. (2023) 和 Du et al. (2024; 2025) 所述。

基线方法。 实验将 CUTER 与涵盖 OCL、多标签类别增量学习（MLCIL）及 MOCL 的10种先进持续学习方法比较。为全面评估，我们通过修改分类器结构与分类损失函数，将4种 OCL 方法适配到 MOCL 设置，包括有代表性的回放方法 RS（Chaudhry et al., 2019b）、GSS（Aljundi et al., 2019b）、iCarl（Rebuffi et al., 2017），以及近期的综合方法 NsCE（Xinrui et al., 2024）。此外，评估6种覆盖 MLCIL 和 MOCL 的多标签持续学习方法。其中，KRT（Dong et al., 2023）、APPLE（Song et al., 2024）、AGCN 与 AGCN++（Du et al., 2022; 2023）主要通过知识蒸馏或标签相关性处理标签缺失；PRS（Kim et al., 2020）与 OCDM（Liang & Li, 2022）则通过精心设计的采样策略处理类别不平衡。各方法的更多细节见附录E.1。

评估指标。 遵循 Du et al. (2023; 2024)，采用平均精度均值（mAP）、逐类别 F1 分数（CF1）以及总体 F1 分数（OF1）等标准指标。除常规多标签分类评估外，同时报告跨任务平均性能（已见类别上）以及模型在全部类别 $\mathcal{C}^{1:K}$ 上的最终性能。

Table 1. Comparison results on PASCAL VOC dataset with memory size being $1000 \times 224 \times 224 \times 3$.

Method	Source Task	Average Performance			Last Performance		
		Avg mAP	Avg CF1	Avg OF1	mAP	CF1	OF1
RS	OCL	75.05±1.28	60.32±1.35	61.29±0.74	59.71±1.75	39.88±1.04	46.09±1.24
GSS		76.01±1.24	60.84±0.82	62.37±1.14	58.64±1.29	40.10±0.82	45.13±0.90
iCarl		72.67±3.14	56.24±2.31	58.46±1.78	50.77±2.18	36.51±1.70	41.02±1.91
NsCE		75.24±1.41	64.42±1.05	65.30±0.97	56.87±1.14	40.78±1.22	42.39±1.50
KRT*	MLCIL	59.45±1.17	46.49±0.88	57.12±1.38	38.90±0.77	33.47±1.14	36.82±0.95
APPLE		76.24±1.25	67.01±2.12	66.74±1.23	58.27±0.82	43.77±1.03	50.21±0.98
PRS	MOCL	75.87±0.82	58.15±1.46	61.62±1.69	54.67±0.64	42.15±1.15	43.87±0.86
OCDM		76.14±1.14	52.84±0.79	65.08±1.11	45.35±1.12	36.41±0.25	40.45±1.01
AGCN		75.06±1.01	62.37±0.89	61.87±2.04	57.21±0.74	42.06±1.47	44.79±1.91
AGCN++		74.14±0.78	65.04±1.24	63.55±1.45	55.34±0.87	40.06±0.75	44.21±1.14
CUTER w/ R_l		**82.07±0.53**	**72.19±0.70**	**75.27±0.57**	**67.89±1.28**	**51.35±0.98**	**59.98±1.17**

表1。 PASCAL VOC 数据集上的比较，记忆大小为 $1000\times224\times224\times3$。表头译文：方法；来源任务；平均性能（平均 mAP、平均 CF1、平均 OF1）；最终性能（mAP、CF1、OF1）。CUTER w/ R_l：带低秩正则化的 CUTER。

Table 2. Comparison results on MSCOCO dataset with memory size being $1000 \times 224 \times 224 \times 3$.

Method	Source Task	Average Performance			Last Performance		
		Avg mAP	Avg CF1	Avg OF1	mAP	CF1	OF1
RS	OCL	48.12±1.78	32.21±1.04	37.36±0.92	18.97±2.01	6.44±1.56	12.84±1.05
GSS		49.41±0.84	32.85±0.70	38.26±0.55	25.67±1.34	11.82±0.96	17.40±1.18
iCarl		47.51±1.30	33.09±0.86	37.51±1.09	19.24±1.37	7.62±1.38	12.51±0.89
NsCE		51.24±0.95	37.10±1.10	44.73±0.96	26.19±1.24	17.07±1.04	22.30±0.94
KRT*	MLCIL	44.34±0.95	39.06±1.08	43.51±1.17	36.51±0.87	27.41±0.92	30.16±1.15
APPLE		48.67±1.28	42.34±0.85	46.86±1.31	38.47±0.94	30.12±1.08	33.51±0.67
PRS	MOCL	51.79±1.08	33.64±1.32	38.06±0.94	27.95±1.98	15.33±2.47	18.22±1.29
OCDM		55.45±0.87	46.78±1.02	50.59±0.92	40.56±0.80	28.45±0.71	31.29±0.52
AGCN		56.45±0.92	48.03±1.35	51.27±0.91	37.48±0.73	27.82±0.96	32.38±1.29
AGCN++		54.31±0.82	47.69±0.47	52.27±0.85	36.45±0.74	29.64±0.83	33.05±0.71
CUTER w/ R_l		**60.14±0.60**	**51.53±0.61**	**54.92±0.62**	**47.82±0.60**	**35.94±0.71**	**39.18±0.65**

表2。 MSCOCO 数据集上的比较，记忆大小为 $1000\times224\times224\times3$ 。表头含义同表1。

实现细节。 评估不同预训练模型的定位能力后，我们采用在 ImageNet-21k 上预训练的（DINO v1）ViT-S/16 作为骨干。表1、表2、表4中所有比较方法都使用相同骨干和预训练初始化，KRT 除外；KRT 使用 TresnetM，因为我们尝试以 ViT-S/16 复现 KRT 时，未得到优于原始 TresnetM 实现的性能。数据增强策略遵循 Dong et al. (2023)。正文中的全部实验重复5次，报告均值与标准差。更多实现细节见附录E.1。

3.2. 总体性能

首先，通过与现有最先进 MOCL 方法和各种持续学习变体比较，全面评估 CUTER。比较涵盖在线持续学习方法、多标签类别增量学习方法（MLCIL）与 MOCL 方法。虽然还存在 CSC、RebLL（Du et al., 2024; 2025）等更新的 MLCIL 方法，但由于实现细节不可得（没有公开代码链接），且实验设置不同，我们未纳入比较。表1、表2和表4展示三个合成基准数据集上的平均性能与总体性能。结果表明，CUTER 始终优于其他方法。值得注意的是，CUTER 在持续学习后期任务中的提升特别显著，在全部类别上的最终性能优势更为突出。

其次，我们比较稳健图结构学习中的三种常用正则化，将其作为额外损失项来巩固定位能力。具体采用低秩正则化 $R_l = \| A \|_*$、稀疏正则化 $R_{sp} = \| A \|_{l_1} / \| A \|_{l_2}$，其中 $\| A \|_{l_1}$ 和 $\| A \|_{l_2}$ 表示将矩阵 A 展平为向量后计算的 l_1 与 l_2 范数，遵循 Xinrui et al. (2024) 的稀疏性定义与约束；以及平滑正则化 $R_{sm} = \frac{1}{2}\sum_{i,j=1}^{N} A_{ij}\left(\theta(x_i) - \theta(x_j)\right)^2$，其中 $\theta(x_i)$ 是输入图像第 i 个图块的对应特征。如表3所示，R_l 能够稳定提升性能，而 R_{sm} 与 R_{sp} 往往导致性能下降。我们推测，这种不一致可能源于这些所谓理想图结构与模型分类目标之间的潜在冲突，附录D将详细讨论。

第三，将 CUTER 作为插件组件，与 PRS、OCDM、KRT、AGCN 等方法中的其他常用技术结合评估。为公平比较，使用不含再平衡采样与低秩正则化的基础版本（Cut.Rep）。如表5所示，我们的策略能够有效补充不同的再平衡采样方法，还能借助知识蒸馏、基于图的标签挖掘等技术进一步增强。

其他可视化与实验结果，包括整个训练过程的 mAP 曲线、不同骨干结构（预训练初始化）下的性能以及不同方法的吞吐量评估，见附录E.2。

Table 3. Comparison of different regularization terms for preserving localization ability.

Model	Cut.Rep	R_l	R_{sp}	R_{sm}	VOC		COCO		NUSWIDE	
					Avg mAP	Last mAP	Avg mAP	Last mAP	Avg mAP	Last mAP
CUTER w/ R_{sp}	✓		✓		78.34±0.76	66.27±0.85	58.68±1.03	46.74±0.62	49.73±0.50	37.06±1.16
CUTER w/ R_{sm}	✓			✓	79.01±0.84	65.63±0.92	58.31±0.68	44.90±0.85	50.14±0.76	**38.09±1.34**
CUTER w/ R_l	✓	✓			**82.07±0.53**	**67.89±1.28**	**60.14±0.60**	**47.82±0.60**	**51.14±0.72**	37.17±1.46

表3。 不同正则项在保持定位能力方面的比较。表头：模型；裁出并回放（Cut.Rep）；低秩正则化 R_l；稀疏正则化 R_{sp}；平滑正则化 R_{sm}；各数据集上的平均 mAP 与最终 mAP。勾号表示采用相应组件。

Table 4. Comparison results on NUSWIDE dataset with memory size being $1000 \times 224 \times 224 \times 3$.

Method	Avg mAP	Avg CF1	Last mAP
RS	43.90±1.08	36.79±0.76	26.78±0.59
GSS	44.28±0.76	37.01±1.14	28.22±0.90
iCarl	43.50±0.83	35.74±0.95	27.60±0.85
NsCE	45.72±0.52	34.95±0.75	27.14±0.60
KRT*	47.30±1.07	39.70±1.24	31.25±1.19
APPLE	47.53±0.76	40.89±0.97	32.40±1.34
PRS	42.74±0.84	35.01±0.92	22.78±0.72
AGCN	49.16±0.97	38.41±1.05	33.49±0.88
AGCN++	49.03±1.35	40.17±1.28	32.09±1.41
OCDM	40.05±0.42	33.66±0.87	29.41±0.65
CUTER w/ R_l	**51.14±0.72**	**42.92±1.03**	**37.57±1.46**

表4。 NUSWIDE 数据集上的比较，记忆大小为 $1000\times224\times224\times3$。表头：方法；平均 mAP；平均 CF1；最终 mAP。

Table 5. Cut and Replay (CutRep) works as a plug-in component for several MOCL methods (Averaged mAP reported).

Method	VOC	MSCOCO	NUSWIDE
Cut.Rep	77.92±0.78	53.40±0.82	46.30±1.02
Cut.Rep w/ PRS	**81.35±1.02**	58.72±0.94	50.69±0.45
Cut.Rep w/ OCDM	81.09±0.67	57.90±0.73	**51.21±1.38**
CUTER	79.45±0.92	59.23±0.72	50.51±0.64
CUTER w/ KRT	79.37±1.25	57.09±1.32	50.56±0.95
CUTER w/ AGCN	76.95±1.14	**59.31±0.94**	48.95±0.89

表5。 裁出并回放（CutRep）作为多种 MOCL 方法的插件组件（报告平均 mAP）。表头：方法；VOC；MSCOCO；NUSWIDE。w/ 表示与相应方法结合。

3.3. 消融研究

本节通过一系列消融研究，考察各提出组件的具体作用。由表5和表6可得：（1）各组件（裁出并回放、再平衡采样、低秩正则化）均带来稳定性能提升，其中裁出并回放（Cut.Rep）作用最显著。（2）所提再平衡采样方法虽未必在所有数据集与设置下都优于 PRS、OCDM 等精心设计的方法，但能

以更低计算成本取得相当结果：其复杂度为 $O(B)$，而 OCDM 为 $O(B|\mathcal{M}|)$，其中 B 为批大小。

（3）相较于固定骨干，在训练期间持续更新模型能改善性能，因为这自然会提高当前任务的定位与裁出质量。

Table 6. Ablation studies. We denote low rank regularization as R_l, sparse regularization as R_{sp}, and smooth regularization as R_{sm}. CUTER$^-$ refers to CUTER using a fixed backbone for object localization and the later cut out operation.

Model	Rep	Cut.Rep	Re-balance	R_l	VOC		COCO		NUSWIDE	
					Avg mAP	Last mAP	Avg mAP	Last mAP	Avg mAP	Last mAP
Baseline(RS)	✓				75.05±1.28	59.71±1.75	48.12±1.78	18.97±2.01	43.90±1.08	26.78±0.59
Cut.Rep		✓			77.92±0.78	64.52±1.07	53.40±0.82	31.17±0.69	46.30±1.02	30.41±0.73
Cut.Rep w/ R_l		✓		✓	78.24±0.93	63.95±0.76	56.37±0.64	33.84±1.01	48.12±0.85	31.46±0.71
CUTER$^-$		✓	✓		78.62±0.77	64.95±0.83	59.01±0.45	45.19±0.80	49.67±0.72	36.42±0.91
CUTER		✓	✓		79.45±0.92	66.09±1.03	59.23±0.72	45.79±0.85	50.51±0.64	**37.35±0.42**
CUTER w/ R_l		✓	✓	✓	**82.07±0.53**	**67.89±1.28**	**60.14±0.60**	**47.82±0.60**	**51.14±0.72**	37.17±1.46

表6。 消融研究。R_l 表示低秩正则化，R_{sp} 表示稀疏正则化，R_{sm} 表示平滑正则化。CUTER$^-$ 表示采用固定骨干进行对象定位及后续裁出操作的 CUTER。表头：模型；回放（Rep）；裁出并回放（Cut.Rep）；再平衡（Re-balance）；低秩正则化；各数据集的平均 mAP、最终 mAP。Baseline：基线。

3.4. 敏感性分析

本节分析低秩正则项系数 α 以及阈值 τ_1、τ_2 对经验回放中记忆缓冲区前景对象选择的影响。如图6所示，当 α, τ_1, τ_2 保持在一定范围内时，所提方法表现相对稳健。需要注意，系数 α 不应过大，因为本方法实施低秩正则化时，没有加入通常用于控制邻接矩阵 A 变化幅度的约束。因此，过大的 α 会使 A 趋于零矩阵，显然不可取。同时，过大的 τ_1 会使模型难以选择足够数量的尾部类别样本，进而影响总体性能。

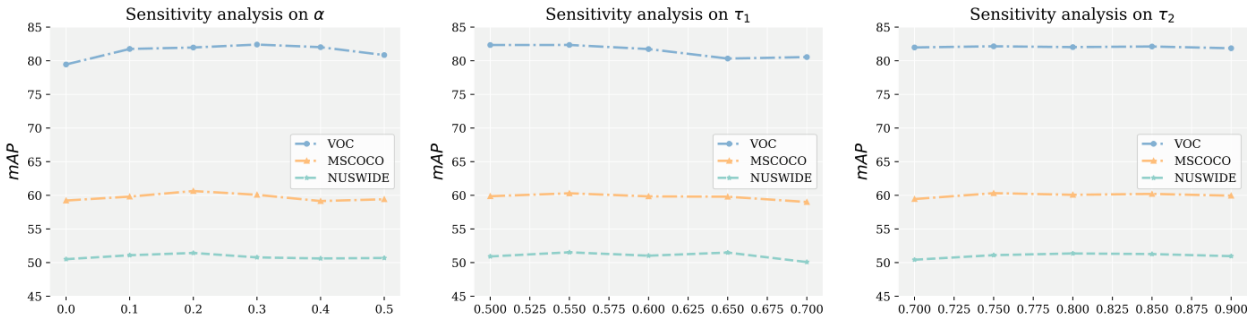


图6。 系数 α 以及置信度阈值 τ_1、τ_2 的敏感性分析。三个子图依次分析 α、τ_1、τ_2；纵轴均为 mAP。

4. 结论

本研究强调现有 MOCL 方法力图解决的两项关键挑战——普遍的标签缺失与不可控的类别不平衡——背后的根本问题。通过探索并利用广泛使用的预训练模型固有的定位能力，我们提出 CUTER，通过识别并回放不同给定标签对应的区域，全面应对现有 MOCL 方法的局限。此外，从图谱理论角度，进一步探索如何在这一在线增量学习框架中提高模型定位（无监督检测与分割）性能。我们的方法不仅带来显著性能提升，而且与现有 MOCL 方法有明显差异。希望本研究能为这种持续场景下的多标签学习领域带来新的视角。

影响声明

本研究旨在推动机器学习领域的发展。尽管本工作可能产生社会影响，我们认为讨论具体场景超出了本技术论文的范围。

致谢

本工作得到国家科技重大专项（2022ZD0114801）、国家自然科学基金（62376126）、南京航空航天大学优秀博士学位论文培育基金（BCXJ25-21），以及航空发动机及燃气轮机重大专项基础研究项目“典型传动部件故障诊断与预测技术研究”（J2019-IV-0018-0086）的支持。同时，感谢匿名审稿人提出的宝贵意见和建议。

参考文献

1. Aljundi, R., Belilovsky, E., Tuytelaars, T., Charlin, L., Caccia, M., Lin, M., and Page-Caccia, L. 通过最大干扰检索实现在线持续学习。《神经信息处理系统进展》，卷32，2019a。

2. Aljundi, R., Lin, M., Goujaud, B., and Bengio, Y. 面向在线持续学习的基于梯度的样本选择。《神经信息处理系统进展》，32，2019b。

3. Caccia, L., Aljundi, R., Asadi, N., Tuytelaars, T., Pineau, J., and Belilovsky, E. 关于减少在线持续学习中突发表示变化的新见解。国际学习表征会议（ICLR），2022。

4. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., and Joulin, A. 自监督视觉 Transformer 的涌现性质。《国际计算机视觉会议（ICCV）论文集》，2021。

5. Cha, H., Lee, J., and Shin, J. Co2l：对比持续学习。《IEEE/CVF 国际计算机视觉会议论文集》，9516–9525页，2021。

6. Chaudhry, A., Ranzato, M., Rohrbach, M., and Elhoseiny, M. 使用 A-GEM 进行高效终身学习。ICLR，2019a。

7. Chaudhry, A., Rohrbach, M., Elhoseiny, M., Ajanthan, T., Dokania, P. K., Torr, P. H., and Ranzato, M. 论持续学习中的微小情景记忆。arXiv 预印本 arXiv:1902.10486，2019b。

8. Chaudhry, A., Khan, N., Dokania, P., and Torr, P. 低秩正交子空间中的持续学习。《神经信息处理系统进展》，33:9900–9911，2020。

9. Chen, T., Xu, M., Hui, X., Wu, H., and Lin, L. 面向多标签图像识别的语义特定图表示学习。《IEEE/CVF 国际计算机视觉会议论文集》，522–531页，2019。

10. Chen, X., Fan, H., Girshick, R., and He, K. 通过动量对比学习改进基线。arXiv 预印本 arXiv:2003.04297，2020。

11. Chen*, X., Xie*, S., and He, K. 自监督视觉 Transformer 训练的实证研究。arXiv 预印本 arXiv:2104.02057，2021。

12. Chua, T.-S., Tang, J., Hong, R., Li, H., Luo, Z., and Zheng, Y. NUS-WIDE：来自新加坡国立大学的真实世界网络图像数据库。《ACM 国际图像与视频检索会议论文集》，1–9页，2009。

13. Chung, F. R.《谱图论》，卷92。美国数学学会，1997。

14. Darcet, T., Oquab, M., Mairal, J., and Bojanowski, P. 视觉 Transformer 需要寄存器。arXiv 预印本 arXiv:2309.16588，2023。

15. Dong, S., Luo, H., He, Y., Wei, X., Cheng, J., and Gong, Y. 面向多标签类别增量学习的知识恢复与迁移。《IEEE/CVF 国际计算机视觉会议论文集》，18711–18720页，2023。

16. Du, K., Lyu, F., Hu, F., Li, L., Feng, W., Xu, F., and Fu, Q. AGCN：面向终身多标签图像识别的增强图卷积网络。《2022年 IEEE 国际多媒体与博览会议（ICME）》，01–06页。IEEE，2022。

17. Du, K., Lyu, F., Li, L., Hu, F., Feng, W., Xu, F., Xi, X., and Cheng, H. 使用增强图卷积网络进行多标签持续学习。《IEEE 多媒体汇刊》，2023。

18. Du, K., Zhou, Y., Lyu, F., Li, Y., Xie, J., Shen, Y., Hu, F., and Liu, G. 多标签类别增量学习的再平衡。arXiv 预印本 arXiv:2408.12161，2024。

19. Du, K., Zhou, Y., Lyu, F., Li, Y., Lu, C., and Liu, G. 面向多标签类别增量学习的置信度自校准。《欧洲计算机视觉会议》，234–252页。Springer，2025。

20. Everingham, M., Eslami, S. A., Van Gool, L., Williams, C. K., Winn, J., and Zisserman, A. PASCAL 视觉对象类别挑战：回顾。《国际计算机视觉杂志》，111:98–136，2015。

21. Gao, B.-B. and Zhou, H.-Y. 学习发现多类别注意力区域以进行多标签图像识别。《IEEE 图像处理汇刊》，30:5920–5932，2021。

22. Ghunaim, Y., Bibi, A., Alhamoud, K., Alfarra, M., Al Kader Hammoud, H. A., Prabhu, A., Torr, P. H., and Ghanem, B. 在线持续学习中的实时评估：新的希望。《IEEE/CVF 计算机视觉与模式识别会议论文集》，11888–11897页，2023。

23. Gu, Y., Yang, X., Wei, K., and Deng, C. 不只是选择，更是探索：通过双视图一致性实现在线类别增量持续学习。《IEEE/CVF 计算机视觉与模式识别会议论文集》，7442–7451页，2022。

24. Gunasekara, N., Pfahringer, B., Gomes, H. M., and Bifet, A. 在线流式持续学习综述。国际人工智能联合会议（IJCAI），6628–6637页，2023。

25. Guo, Y., Liu, B., and Zhao, D. 通过互信息最大化进行在线持续学习。《国际机器学习大会》，8109–8126页。PMLR，2022。

26. Hang, J.-Y. and Zhang, M.-L. 面向多标签分类的标签语义与深度标签特定特征协同学习。《IEEE 模式分析与机器智能汇刊》，44(12):9860–9871，2021。

27. Hang, J.-Y. and Zhang, M.-L. 多标签分类中标签特定特征学习的双重视角。《国际机器学习大会》，8375–8386页。PMLR，2022。

28. Hang, J.-Y., Zhang, M.-L., Feng, Y., and Song, X. 面向多标签分类的端到端概率标签特定特征学习。《AAAI 人工智能会议论文集》，卷36，6847–6855页，2022。

29. He, K., Fan, H., Wu, Y., Xie, S., and Girshick, R. 用于无监督视觉表示学习的动量对比。《IEEE/CVF 计算机视觉与模式识别会议论文集》，9729–9738页，2020。

30. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. 掩码自编码器是可扩展的视觉学习器。《IEEE/CVF 计算机视觉与模式识别会议论文集》，16000–16009页，2022。

31. Huang, J., Li, G., Huang, Q., and Wu, X. 为多标签分类学习标签特定特征。《2015年 IEEE 国际数据挖掘会议》，181–190页。IEEE，2015。

32. Huang, J., Li, G., Huang, Q., and Wu, X. 面向多标签分类的标签特定特征和类别依赖标签学习。《IEEE 知识与数据工程汇刊》，28(12):3309–3323，2016。

33. Kim, C. D., Jeong, J., and Kim, G. 使用分区蓄水池采样进行不平衡持续学习。《计算机视觉—ECCV 2020：第16届欧洲会议，英国格拉斯哥，2020年8月23–28日，论文集，第XIII部分16》，411–428页。Springer，2020。

34. Li, J., Li, P., Hu, X., and Yu, K. 利用相关信息为多标签分类学习公共和标签特定特征。《模式识别》，121:108259，2022。

35. Li, M., Wang, D., Liu, X., Zeng, Z., Lu, R., Chen, B., and Zhou, M. PatchCT：使用条件传输对齐图块集合与标签集合以进行多标签图像分类。《IEEE/CVF 国际计算机视觉会议论文集》，15348–15358页，2023。

36. Li, X., Liu, J., Wang, X., and Chen, S. 不完整多标签学习综述：近期进展与未来趋势。arXiv 预印本 arXiv:2406.06119，2024。

37. Li, X., Wang, X., and Chen, S. 在多标签学习中每次推开一对标签：从单个正标签到完整标签。《中国科学：信息科学》，68(6):1–18，2025。

38. Liang, Y.-S. and Li, W.-J. 为多标签在线持续学习优化记忆中的类别分布。arXiv 预印本 arXiv:2209.11469，2022。

39. Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. Microsoft COCO：上下文中的常见对象。《计算机视觉—ECCV 2014：第13届欧洲会议，瑞士苏黎世，2014年9月6–12日，论文集，第V部分13》，740–755页。Springer，2014。

40. Mai, Z., Li, R., Kim, H., and Sanner, S. 监督对比回放：重新审视在线类别增量持续学习中的最近类别均值分类器。《IEEE/CVF 计算机视觉与模式识别会议论文集》，3589–3599页，2021。

41. Narayan, S., Gupta, A., Khan, S., Khan, F. S., Shao, L., and Shah, M. 基于判别性区域的多标签零样本学习。《IEEE/CVF 国际计算机视觉会议论文集》，8731–8740页，2021。

42. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., 等。DINOv2：无监督学习稳健视觉特征。arXiv 预印本 arXiv:2304.07193，2023。

43. Rebuffi, S.-A., Kolesnikov, A., Sperl, G., and Lampert, C. H. iCaRL：增量分类器与表示学习。《IEEE 计算机视觉与模式识别会议论文集》，2001–2010页，2017。

44. Ren, T., Jia, X., Li, W., Chen, L., and Li, Z. 使用标签特定特征进行标签分布学习。IJCAI，卷1，3页，2019。

45. Ridnik, T., Ben-Baruch, E., Zamir, N., Noy, A., Friedman, I., Protter, M., and Zelnik-Manor, L. 多标签分类的非对称损失。《IEEE/CVF 国际计算机视觉会议论文集》，82–91页，2021。

46. Royle, G. F. and Godsil, C. 《代数图论》，卷207。纽约：Springer，2001。

47. Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D. Grad-CAM：通过基于梯度的定位从深度网络获得视觉解释。《IEEE 国际计算机视觉会议论文集》，618–626页，2017。

48. Shi, J. and Malik, J. 归一化割与图像分割。《IEEE 模式分析与机器智能汇刊》，22(8):888–905，2000。

49. Shim, D., Mai, Z., Jeong, J., Sanner, S., Kim, H., and Jang, J. 使用对抗 Shapley 值进行在线类别增量持续学习。《AAAI 人工智能会议论文集》，卷35，9630–9638页，2021。

50. Siméoni, O., Puy, G., Vo, H. V., Roburin, S., Gidaris, S., Bursuc, A., Pérez, P., Marlet, R., and Ponce, J. 使用自监督 Transformer 在无标签条件下定位对象。arXiv 预印本 arXiv:2109.14279，2021。

51. Song, X., Shu, K., Dong, S., Cheng, J., Wei, X., and Gong, Y. 克服多标签类别增量学习中的灾难性遗忘。《IEEE/CVF 计算机视觉应用冬季会议论文集》，2389–2398页，2024。

52. Wang, L., Zhang, X., Yang, K., Yu, L., Li, C., Hong, L., Zhang, S., Li, Z., Zhong, Y., and Zhu, J. 使用数据压缩进行持续学习的记忆回放。ICLR，2022。

53. Wang, X., Girdhar, R., Yu, S. X., and Misra, I. 用于无监督对象检测和实例分割的裁剪与学习。《IEEE/CVF 计算机视觉与模式识别会议论文集》，3124–3134页，2023a。

54. Wang, Y., Shen, X., Yuan, Y., Du, Y., Li, M., Hu, S. X., Crowley, J. L., and Vaufreydaz, D. TokenCut：利用自监督 Transformer 和归一化割分割图像与视频中的对象。《IEEE 模式分析与机器智能汇刊》，2023b。

55. Wang, Z., Chen, T., Li, G., Xu, R., and Lin, L. 通过循环发现注意力区域实现多标签图像识别。《IEEE 国际计算机视觉会议论文集》，464–472页，2017。

56. Wei, T. and Li, Y.-F. 尾部标签有助于大规模多标签学习吗？《IEEE 神经网络与学习系统汇刊》，31(7):2315–2324，2019a。

57. Wei, T. and Li, Y.-F. 面向大规模多标签数据学习紧凑模型。《AAAI 人工智能会议论文集》，卷33，5385–5392页，2019b。

58. Wei, T., Guo, L.-Z., Li, Y.-F., and Gao, W. 为弱标注数据学习安全的多标签预测。《机器学习》，107:703–725，2018。

59. Wei, T., Shi, J.-X., and Li, Y.-F. 面向流式多标签学习的概率标签树。《第27届 ACM SIGKDD 知识发现与数据挖掘会议论文集》，1801–1811页，2021。

60. Wei, Y., Ye, J., Huang, Z., Zhang, J., and Shan, H. 面向在线持续学习的在线原型学习。《IEEE/CVF 国际计算机视觉会议论文集》，18764–18774页，2023。

61. Xinrui, W., Geng, C., Wan, W., Li, S.-Y., and Chen, S. 遗忘、无知还是短视：重新审视在线持续学习的关键挑战。《第38届神经信息处理系统年会》，2024。

62. Yan, S., Zhou, J., Xie, J., Zhang, S., and He, X. 面向语义分割在线增量学习的 EM 框架。《第29届 ACM 国际多媒体会议论文集》，3052–3060页，2021。

63. Yu, Z.-B. and Zhang, M.-L. 通过标签特定特征生成进行多标签分类：一种包裹式方法。《IEEE 模式分析与机器智能汇刊》，44(9):5199–5210，2021。

64. Zhang, F. 四元数与四元数矩阵。《线性代数及其应用》，251:21–57，1997。

65. Zhang, M.-L. and Wu, L. LIFT：使用标签特定特征进行多标签学习。《IEEE 模式分析与机器智能汇刊》，37(1):107–120，2014。

66. Zhang, M.-L. and Zhou, Z.-H. ML-kNN：一种多标签学习的惰性学习方法。《模式识别》，40(7):2038–2048，2007。

67. Zhang, M.-L. and Zhou, Z.-H. 多标签学习算法综述。《IEEE 知识与数据工程汇刊》，26(8):1819–1837，2013。

68. Zhang, M.-L., Li, Y.-K., Yang, H., and Liu, X.-Y. 走向类别不平衡感知的多标签学习。《IEEE 控制论汇刊》，52(6):4459–4471，2020。

69. Zhao, H., Jin, Y., and Ma, L. 面向多标签类别增量学习的动态提示调整。arXiv 预印本 arXiv:2501.00340，2025。

70. Zhao, K., Chu, W.-S., and Zhang, H. 面向面部动作单元检测的深度区域与多标签学习。《IEEE 计算机视觉与模式识别会议论文集》，3391–3399页，2016。

71. Zhou, J., Wei, C., Wang, H., Shen, W., Xie, C., Yuille, A., and Kong, T. 使用在线分词器进行图像 BERT 预训练。《国际学习表征会议》，2022。

72. Zhu, F., Zhang, X.-Y., Wang, C., Yin, F., and Liu, C.-L. 面向增量学习的原型增强与自监督。《IEEE/CVF 计算机视觉与模式识别会议论文集》，5871–5880页，2021。

A. 相关工作的详细讨论

A.1. 在线持续学习

在线持续学习（OCL）是持续学习的一种更符合现实的扩展，用于处理数据分布随时间动态变化的情形；与之相对，在传统批量学习中，完整的任务数据集预先可得（Gunasekara et al., 2023）。为缓解灾难性遗忘，大多数 OCL 方法维护一个用于经验回放的记忆缓冲区，并采用各种记忆管理和样本选择策略（Chaudhry et al., 2019a;b; Aljundi et al., 2019a;b; Chaudhry et al., 2020; Shim et al., 2021; Wang et al., 2022; Caccia et al., 2022; Ghunaim et al., 2023; Xinrui et al., 2024）。此外，研究者也探索了在单遍训练情形下增强特征学习与分类器适应能力的方法（Rebuffi et al., 2017）。近期进展引入了对比学习（Mai et al., 2021; Cha et al., 2021）、互信息最大化（Gu et al., 2022; Guo et al., 2022）和原型学习（Zhu et al., 2021; Wei et al., 2023）等技术，以提高模型的判别能力和整体性能。

A.2. 多标签分类

多标签学习长期以来一直是机器学习中的一种基本范式（Zhang & Zhou, 2013; Wei & Li, 2019b; Li et al., 2024），受到研究者的广泛关注。在本综述中，我们聚焦于提取标签特定特征或区域的工作，因为这些工作与我们的方法密切相关。这些研究大体可以分为两类。

第一类将多标签分类分解为二元（一对其余）子问题，其中每个标签被映射到一个不同的特征子集。这一类包含三种主要方法：（1）基于聚类的方法（Zhang & Wu, 2014; Ren et al., 2019）利用特征与标签之间的独立模式和共现模式，将特征空间划分为标签特定的簇；（2）标签相关性挖掘方法（Huang et al., 2015; 2016; Hang & Zhang, 2022）通过图编码器（Hang & Zhang, 2021）等专门设计的模块构建标签相关性矩阵，发现并利用标签间的相互依赖关系来指导特征选择，通常采用矩阵分解或基于图的技术；（3）正则化特征学习方法（Wei et al., 2018; Li et al., 2022; 2025）对特征选择过程施加结构约束，通常使用 ℓ_1 或组稀疏正则项来促进标签特定的特征稀疏性。然而，由于这些方法作用于抽象特征向量而非空间表示，因此不能支持裁剪增强这类直接的样本级操作。

第二类采用更直接的方式，利用视觉注意力机制定位标签特定区域（Chen et al., 2019; Narayan et al., 2021; Li et al., 2023）。具体而言，这些方法或利用深度网络固有的注意力机制，或使用 Grad-CAM（Selvaraju et al., 2017）等可视化技术，或引入专门的注意力模块（Wang et al., 2017; Gao & Zhou, 2021）。尽管这些方法能够对标签相关区域进行粗粒度定位，其注意力图通常聚焦于局部判别性特征，而非完整的物体区域。这一局限使其不太适合 MOCL，因为后者需要精确的物体边界和全面的物体表示。

鉴于传统多标签学习中已有大量标签特定特征学习方法（Yu & Zhang, 2021; Hang & Zhang, 2021; Hang et al., 2022; Hang & Zhang, 2022; Chen et al., 2019; Narayan et al., 2021; Li et al., 2023），我们强调：这些方法要么依赖完整标签集且计算开销很大，要么无法识别标签特定区域；对于存在标签缺失因素且要求高效率的 MOCL 任务而言，这些都是其固有缺陷。

A.3. 多标签在线持续学习

多标签在线持续学习或多标签类别增量学习是一个新兴研究领域，融合了持续学习与多标签学习的优势（Zhang & Zhou, 2007; 2013; Zhang & Wu, 2014; Zhang et al., 2020; Wei et al., 2021）。除广泛讨论的灾难性遗忘外，现有 MOCL 研究主要处理两项关键挑战：（1）持续学习与多标签分类交叉时固有的过去及未来标签缺失；（2）常规多标签数据流中普遍存在的、内在且不可控的类别不平衡。研究者利用保存的历史模型，通过已在多标签学习和持续学习中证明有效的技术来解决标签缺失问题，例如 GCN（Du et al., 2022; 2023; 2025）、知识蒸馏（Dong et al., 2023）以及视觉语言模型（Zhao et al., 2025）。类别不平衡问题则通过为回放方法精心设计采样策略来处理。典型例子包括采用启发式采样的 PRS（Kim et al., 2020）和采用基于优化的采样的 OCDM（Liang & Li, 2022）；二者均旨在减轻持续多标签情形下长尾类别分布的影响。然而，这些现有方法忽略了上述挑战的根本原因，以及多标签学习中的一个关键问题（Zhao et al., 2016; Wang et al., 2017; Gao & Zhou, 2021）：如何在线识别并区分标签特定区域及其对应特征？我们的工作直接针对这一根本问题。

B. 预备知识

本节首先回顾两种无监督分割技术：归一化割（Normalized Cut；Shi & Malik, 2000）和掩码割（Mask Cut；Wang et al., 2023a）；它们启发了我们对 MOCL 中标签特定区域识别的研究。

归一化割（NCut）将图像分割表述为图划分问题。设 $G = (V, E)$ 为一个加权无向图，其中 V 表示顶点集，每个顶点 v 对应一个图像块（特征块），E 表示边集，W 为边权矩阵，其元素 W_{ij} 编码顶点 i 与 j 之间的相似度。NCut 通过最小化 NCut 能量 $\mathcal{E}(A, B, V)$，旨在将图划分为不相交的集合 A（背景）与 B（前景物体 b）：

$$\mathcal{E}(A,B,V) = \frac{\mathcal{C}(A,B)}{\mathcal{C}(A,V)} + \frac{\mathcal{C}(A,B)}{\mathcal{C}(B,V)}, \tag{4}$$

其中，$\mathcal{C}$ 衡量两个集合之间的相似度，例如 $\mathcal{C}(A, B) = \sum_{v_i \in A, v_j \in B} W_{ij}$。

与此同时，掩码割（MCut）通过对掩码后的相似度矩阵迭代应用 NCut，将 NCut 扩展为识别每幅图像中的多个物体。在第 t 次迭代中，算法获得 NCut 的二分结果后，将图像块分为两个不相交的组（背景 a^t 与物体 b^t），并构造二元掩码 M^t，其中

$$M_{ij}^t = \begin{cases} 1, & \text{if } M_{ij} > \text{mean}(b^t) \\ 0, & \text{otherwise} \end{cases} \tag{5}$$

式（5）的分段条件为：若 $M_{ij} > \text{mean}\left(b^t\right)$，取值为 1；否则取值为 0。

确定前景组 b^t 后，MCut 通过屏蔽先前阶段 t 中与前景对应的节点，更新节点相似度 W_{ij}^{t+1}：

$$W_{ij}^{t+1} = \frac{(v_i \prod_{s=1}^{t} \hat{M}_{ij}^s)(v_j \prod_{s=1}^{t} \hat{M}_{ij}^s)}{||v_i||_2 ||v_j||_2} \tag{6}$$

其中 $\widehat{M}_{ij}^{s} = 1 - M_{ij}^{s}$。利用更新后的 W_{ij}^{t+1}，MCut 迭代地最小化式（4）并计算式（6），为不同物体生成多个分割掩码。

C. CUTER 的理论基础

C.1. 归一化割与谱图理论之间的关系

如 B 节所述，归一化割（NCut）可以表述为图划分问题。给定图 $G = (V, E)$，其顶点集为 V、边集为 E，边权 W_{ij} 表示节点 i 与 j 之间的相似度，目标是将图划分为不相交的子集 A 和 B，使得：（1）子集间相似度最小；（2）子集内相似度最大。NCut 目标函数定义为：

$$\frac{\mathcal{C}(A,B)}{\mathcal{C}(A,V)} + \frac{\mathcal{C}(A,B)}{\mathcal{C}(B,V)}$$

其中 $\mathcal{C}$ 衡量两个集合之间的相似度：$\mathcal{C}(A,\ B) = \sum_{v_i \in A, v_j \in B} W_{ij}$。

NCut 问题因其离散性质而属于 NP 难问题。为使其在计算上可处理，可利用谱图理论将其松弛为一个连续优化问题。这涉及图拉普拉斯矩阵 $L = D - W$。为避免度极大的节点主导图结构，采用对称归一化拉普拉斯矩阵 L_{sym}：

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2} \tag{7}$$

随后，该问题可重新表述为最小化 $y^{\top} L_{\text{sym}} y$，并施加约束，确保 y 平衡且与平凡解正交（即 $y^{\top} D\mathbf{1} = 0$，其中 $\mathbf{1}$ 为全 1 向量）。将 y 松弛为可取连续值后，问题变为：

$$\min_{y} y^{\top} L_{\text{sym}} y$$

约束为：

$$y^{\top} D\mathbf{1} = 0, \quad y^{\top} D y = 1$$

其解是 L_{sym} 的第二小特征值对应的特征向量。对这一连续解进行阈值化离散处理，即可获得最终划分。完整证明参见 Shi & Malik（2000）。

C.2. 定理 2.3 的证明

本节首先详细描述每个特征图的邻接矩阵。输入数据的特征可以划分为不同的块，使用高斯核等函数构建一个具有 $N \times N$ 邻接矩阵 A 的无向图。于是，不失一般性，我们可以作出以下假设：

假设 C.1。每个特征图的邻接矩阵 A 可以分解为一个理想的块对角矩阵 A^{*} 和一个非稀疏且可能具有高秩的噪声矩阵 ϵ：

$$A = A^{*} + \epsilon$$

根据假设 C.1，我们可以将图拉普拉斯矩阵 L 重写为：

$$L = D - A = D^* + \Delta D - (A^* + \epsilon)$$

其中 $\Delta D = D - D^*$， D^* 是一个 $N \times N$ 的对角度矩阵，其元素为 $d(i) = \sum_j A^*_{ij}$。因此，我们可以将 ΔD 的元素写为：

$$\Delta D_{ii} = \sum_{j=1}^{N} (A_{ij} - A^*_{ij}) = \sum_{j=1}^{N} \epsilon_{ij}.$$

由于显然 ΔD 也是一个对角矩阵，我们有：

$$||\Delta D||_2 = max_i |\Delta D_{ii}| \leq max_i \sum_{j=1}^{N} |\epsilon_{ij}| = ||\epsilon||_\infty.$$

我们可以得出， $\| \Delta D \|_2$ 直接受 ϵ 给出的上界控制。在此基础上，现在可以转而分析图拉普拉斯矩阵扰动的上界。容易得出：

$$\Delta L = L - (D^* - A^*) = \Delta D - \epsilon.$$

因此，有：

$$||\Delta L||_2 \leq ||\Delta D||_2 + ||\epsilon||_2 \leq ||\epsilon||_\infty + ||\epsilon||_2.$$

这意味着，如果我们能用 $\| \Delta L \|_2$ 给出 $\lambda_2(L)$ 的界，就能完成证明。在进行这一步之前，我们先引入一个重要引理：

引理 C.2（Courant-Fischer 公式；Zhang, 1997）。 对于厄米矩阵 $A \in \mathbb{C}^{N \times N}$，

$$\lambda_k = \min_{\dim(S)=n-k+1} \max_{0 \neq x \in S} \frac{x^* A x}{x^* x} = \max_{\dim(S)=k} \min_{0 \neq x \in S} \frac{x^* A x}{x^* x}, \quad k = 1 : n.$$

由引理 C.2，Courant-Fischer 定理给出以下上下界：

$$\lambda_k(A) + \lambda_n(B) \leq \lambda_k(A + B) \leq \lambda_k(A) + \lambda_1(B).$$

由此可得：

$$\max_k |\lambda_k(A + B) - \lambda_k(A)| \leq \max(|\lambda_n(B)|, |\lambda_1(B)|) = \|B\|_2.$$

这一不等式表明，厄米矩阵的特征值在扰动下具有良好的条件性。我们可以将该不等式重写为对称形式：

$$\max_k |\lambda_k(A) - \lambda_k(B)| \leq \|A - B\|_2.$$

以 L 代入 A、以 $L^* = D^* - A^*$ 代入 B，并取 $k = 2$，得到：

$$\lambda_2(L) - \lambda_2(L^*) \leq ||\Delta L||_2.$$

接着，根据假设 C.1，可以推得 L^* 也是一个理想的块对角矩阵，因此其第二小特征值 $\lambda_2\left(L^*\right)=0$。结合前述结果，得到：

$$\lambda_2(L) \leq ||\Delta L||_2 \leq ||\epsilon||_\infty + ||\epsilon||_2.$$

证明完毕。

D. 模型定位能力分析

D.1. 预训练模型

本节讨论预训练模型的定位能力及其内在机制。根据图 2 和表 7 所示的实验结果，我们观察到，在零样本物体定位能力和应用于 MOCL 的潜力方面，存在清晰的层次关系：采用多裁剪增强的对比学习模型（如 DINO v1、DINO v2）的定位能力优于标准对比学习方法（如 MoCo、SimCLR），而后者又优于常规监督训练方法。MAE 和 iBOT 等基于重建的方法在这方面表现相对较弱。我们未将 CUTLearn 纳入这一比较，因为它是专为零样本检测设计、需要额外微调的专用模型，与上述通用预训练模型存在本质差异。

从谱图理论的角度审视时，这些结果就更加直观。对比学习所采用的增强视图间一致性，自然地引导模型关注图像中最显著的物体。由于 ImageNet 等预训练数据集通常是单标签且以物体为中心的，这一作用尤为显著，使得多裁剪增强一致性特别有效。这种训练动态隐式地促进属于同一物体的图像块之间的特征相似性，从而增强由特征构建的图的可分性（例如以 Cheeger 常数衡量）。相比之下，监督学习在这方面表现较弱，但仍保留一定的定位能力，因为同一类别的图像通常包含相似物体，即使没有显式的图像内部对比，也会产生相近的特征表示。然而，掩码重建预训练方法虽然已被证明能有效学习用于各种下游任务的特征，但在这方面表现最差。从特征图的角度来看，不加区分的随机掩码与重建可能削弱了同一物体不同图像块之间的特征一致性，从而不利于直接基于特征的零样本定位或分割能力。

D.2. 对低秩正则化的进一步分析

约束矩阵 A 的核范数（即最小化 $\| A \|_*$，也就是 A 的奇异值之和）对减小谱范数 $\| \Delta A \|_2$ 和无穷范数 $\| \Delta A \|_\infty$ 均有显著影响，其中 $\Delta A = \epsilon = A - A^*$。下面给出详细解释。

减小谱范数 $\| \Delta A \|_2$： 最小化 $\| A \|_*$ 会对 A 的奇异值施加软阈值处理，降低 A 的秩，并抑制 ΔA 的奇异值：

$$\|\Delta A\|_2 \leq \|\Delta A\|_*.$$

减小无穷范数 $\| \Delta A \|_\infty$： 低秩矩阵的行变化程度有限，这会约束 $\| \Delta A \|_\infty$。由于：

$$\|\Delta A\|_\infty \leq \sqrt{n}\|\Delta A\|_2,$$

减小 $\| \Delta A \|_2$ 会间接减小 $\| \Delta A \|_\infty$。

类似地，稀疏正则化在对 ϵ 去噪方面具有相近效果。然而，与低秩正则化不同，它会破坏 ViT 参数的固有结构性质（Darcet et al., 2023），可能损害分类能力。这或许解释了表 3 中它在 MOCL 上表现较差的原因。对于平滑正则化，我们认为它可能无益于定位能力，因为过于相似的节点特征可能妨碍类似谱聚类的操作。

E. 补充实验与实现细节

E.1. 实现细节

本部分给出表 1、表 2 和表 4 中所比较方法的实现细节与配置：

对于 RS（Chaudhry et al., 2019b）、GSS（Aljundi et al., 2019b）、iCarl 和 NsCE（Xinrui et al., 2024），我们采用其原始代码库，并对分类器架构及分类损失函数作了少量修改。对于采用原型分类器的方法（iCarl 和 NsCE），我们计算余弦相似度，并采用 0.5 的阈值确定正标签。对于分类损失，我们将为单标签情形设计的常规交叉熵损失替换为多标签分类中广泛采用的非对称损失。

对于 PRS（Kim et al., 2020），我们直接使用其提供的代码[1]，以及其报告的最优超参数 $\rho = 0.5$。对于 OCDM（Liang & Li, 2022），由于其代码未公开，但原理与 PRS 相近，我们采用相同的超参数 $\rho = 0.5$ 实现该方法，并报告复现结果。

对于 KRT 和 APPLE，这两种方法均面向多标签类别增量学习，我们基于 KRT 官方代码库[2]实现普通经验回放，每种方法均训练一个轮次，以确保公平比较。

对于 AGCN 和 AGCN++，我们采用 AGCN 的官方实现[3]及其报告的最优超参数。由于 AGCN++（Liang & Li, 2022）的代码未公开，但原理与 AGCN 相近，我们采用相同超参数实现该方法，并报告复现结果。

对于学习率、权重衰减、批大小等其他通用超参数，我们进行网格搜索，并报告所有比较方法的最佳结果。除上述另有说明外，我们统一采用 AdamW 优化器，学习率为 1e-4，权重衰减为 1e-4。对于 PASCAL VOC，数据流批大小设为 12，记忆缓冲区采样批大小设为 6。对于 COCO 和 NUSWIDE，数据流批大小设为 20，记忆缓冲区采样批大小设为 5。

[1] https://github.com/cdjkim/PRS

[2] https://github.com/witdsl/KRT-MLCIL

[3] https://github.com/Kaile-Du/AGCN

E.2. 补充实验

首先，我们详细可视化了不同方法在各个数据集上的性能（mAP%）。如图 7 所示，我们提出的 CUTER 在整个训练过程中始终表现更优。我们观察到，与离线实现相比，MLCIL 方法（例如 APPLE 和 AGCN++）的性能显著下降，尤其是在训练早期。这一性能差距凸显了 MOCL 与 MLCIL 之间的一个关键区别：依赖迭代伪标签的方法难以适应高速数据流。

其次，我们研究骨干架构与预训练策略如何影响 MOCL 的下游性能，结果见表 7。我们的方法更加依赖具有较强定位能力的骨干网络及其相应的预训练方法。如附录 D 所讨论，DINO 预训练的 ViT 模型表现更优。我们还复现了当前达到最先进水平的 MOCL 方法 OCDM，用于比较分析。结果表明，在采用 ViT 作为骨干网络时，我们的方法保持优势，而采用 ResNet 骨干网络时表现相对较弱。这种差异可能源于我们对 ResNet 特征图的处理方式：尽管我们仿照 ViT 将其划分为图像块，并应用 MCut 进行前景物体检测与裁剪，但这种适配方式对于基于 CNN 的架构可能并非最优。

第三，我们分析了我们的方法相对于最先进方法的模型吞吐量。如图 8 所示，虽然普通经验回放（RS）的模型吞吐量最高，但其性能相对较弱。我们的方法以增加计算开销为代价取得了更优结果，开销主要来自无法在 GPU 上并行化的多轮 MCut 操作。此外，计算图邻接矩阵的秩近似（核范数）需要维护并计算多个前景物体预测的梯度。这些因素在模型吞吐量与性能之间形成了权衡。未来工作将着重开发加速技术，以及基于数据流速度的自适应处理策略。

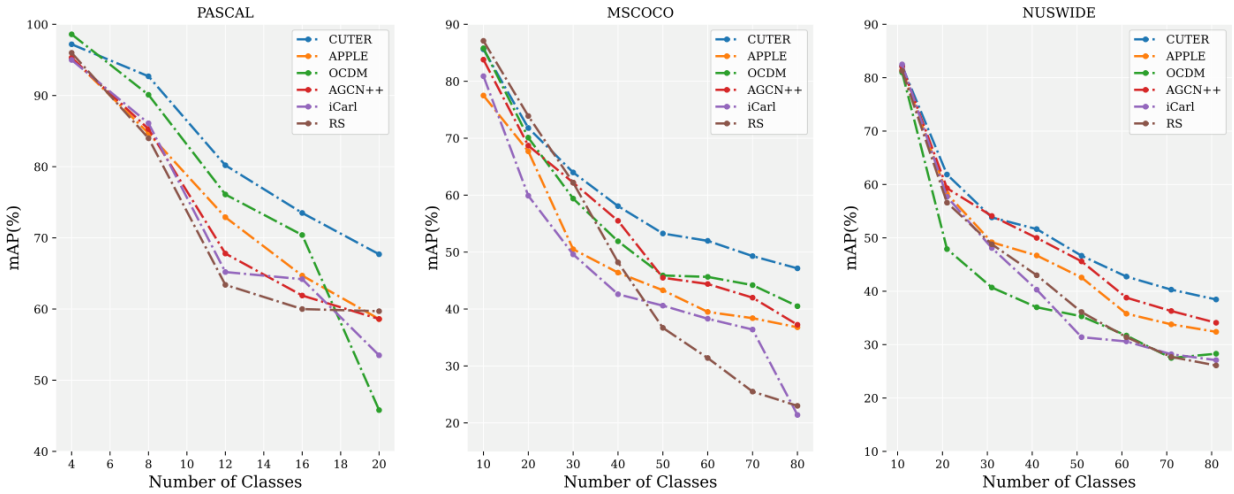


图 7。 在 PASCAL VOC、MSCOCO 和 NUSWIDE 上的整体训练结果。我们纳入了涵盖 OCL、MLCIL 和 MOCL 的 5 种不同方法。图内横轴“Number of Classes”意为“类别数”，纵轴“mAP(%)”意为“平均精度均值（%）”。

表 7。 不同骨干架构与预训练方法的性能比较。

Table 7. Performance comparison across different backbone architectures and pre-training methods.

Model	Backbone	Pre-training Method	VOC		COCO		NUSWIDE	
			Avg mAP	Last mAP	Avg mAP	Last mAP	Avg mAP	Last mAP
CUTER w/ R_l	Vit-S	Supervised	79.56	63.82	57.92	43.04	48.36	35.42
OCDM	Vit-S	Supervised	75.35	44.21	53.26	39.84	41.05	26.87
CUTER w/ R_l	Vit-S	MoCo v3	80.47	64.92	58.10	45.72	50.29	34.70
OCDM	Vit-S	MoCo v3	75.94	46.32	56.14	42.75	40.85	30.01
CUTER w/ R_l	Vit-T	DINO v1	81.84	67.50	59.38	47.95	52.08	36.68
CUTER w/ R_l	Vit-S	DINO v1	82.07	67.89	60.14	47.82	51.14	37.47
CUTER w/ R_l	Vit-B	DINO v1	83.25	68.14	61.08	45.70	50.91	37.52
OCDM	Vit-S	DINO v1	76.14	45.35	55.45	40.56	40.37	29.41
CUTER w/ R_l	Vit-S	MAE	77.31	60.45	56.42	44.06	47.24	32.40
OCDM	Vit-S	MAE	75.42	45.18	56.03	41.53	41.26	29.68
CUTER w/ R_l	ResNet50	Supervised	74.35	46.80	46.34	37.15	38.30	22.53
OCDM	ResNet50	Supervised	72.32	36.71	41.89	30.72	27.94	17.80
CUTER w/ R_l	ResNet50	MoCo v3	75.04	48.31	47.20	37.48	40.06	23.41
OCDM	ResNet50	MoCo v3	75.31	47.05	42.45	30.30	33.45	21.08
CUTER w/ R_l	ResNet50	DINO v1	76.43	50.42	48.52	40.35	40.42	23.79
OCDM	ResNet50	DINO v1	75.09	48.42	46.31	33.17	39.28	21.55
CUTER w/ R_l	ResNet50	MAE	73.62	45.14	43.52	36.68	37.45	22.15
OCDM	ResNet50	MAE	74.25	44.97	42.13	35.90	38.07	21.94

表头与术语对应：Model＝模型；Backbone＝骨干网络；Pre-training Method＝预训练方法；Avg mAP＝平均 mAP；Last mAP＝最终 mAP；Supervised＝监督学习；CUTER w/ R_l ＝带 R_l 的 CUTER。VOC、COCO、NUSWIDE 各列依次报告平均 mAP 与最终 mAP。所有模型名称、配置与数值逐项保留于上表。

最后，我们可视化 CUTER 模型在 PASCAL VOC 多物体持续学习过程中的定位能力。我们从两个角度进行评估：首先，计算所构建特征图的平均 Fiedler 值；其次，对每个增量任务，衡量生成的边界框相对于对应真实标注的零样本定位性能（AP50）。如图 8 所示，随着训练进行，由流式数据构建的图的连通性逐渐下降，而可分性提高。这种图可分性的增强与生成的伪边界框准确率提升相关。

F. 局限性

在正文中，我们主要讨论采用 ViT 骨干网络的情形，因为我们需要图像块一类的结构来形成特征块，从而帮助构建图。虽然 ResNet 等基于 CNN 的骨干网络也能够构造类似的图像块，但如附录 E.2 所示，CUTER 在这些情形下的性能有所下降。此外，我们承认，执行裁剪操作会引入额外计算开销，如图 8 所示，这有时可能影响模型在在线情形下的泛化性。然而，作为探索 MOCL 中物体定位的开创性工作，这些局限也为我们未来的研究指明了有前景的方向。

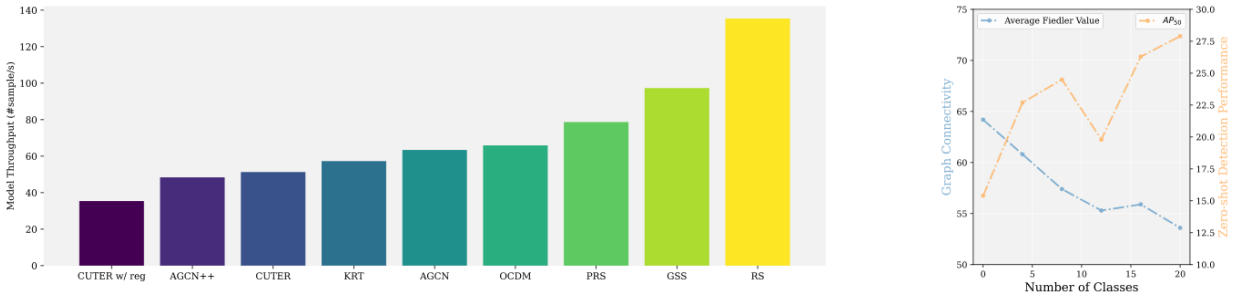


图 8。 左：在 6 个数据集上评估的 9 种方法的平均模型吞吐量比较。右：定位性能的演化，从两个角度追踪我们提出的 CUTER 模型在 PASCAL VOC 上的定位能力。图内文字对应：Model Throughput (#sample/s)＝模型吞吐量（样本数/秒）；CUTER w/ reg＝带正则化的 CUTER；Number of Classes＝类别数；Graph Connectivity＝图连通性；Average Fiedler Value＝平均 Fiedler 值；Zero-shot Detection Performance＝零样本检测性能；AP50 保持原指标名称。