EmoGrowth：利用增强情绪关系图进行增量多标签情绪解码

非官方中文全文译文

Kaicheng Fu[1]*，Changde Du[1]*，Jie Peng[12]，Kunpeng Wang[13]，Shuangchen Zhao[1]，Xiaoyu Chen[12]，Huiguang He[123]

*共同第一作者。[1]中国科学院自动化研究所，脑认知与类脑智能技术全国重点实验室，中国北京；[2]中国科学院大学人工智能学院，中国北京 100049；[3]上海科技大学生物医学工程学院，中国上海。通讯作者：Huiguang He（huiguang.he@ia.ac.cn）。

原文：Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267:17746-17763, 2025。版权归原作者所有。

出处：PMLR 正式论文页面。本文依 CC BY 4.0 制作中文翻译；翻译和版式调整为本译本所作改动，未经原作者审定。图表原始数据和图内英文保留，中文图注、表头释义及情绪名称对照随文提供。图 1 含数据集视频示例，未见单独授权例外声明；本译本仅按论文原有语境保留，并不声称拥有其独立素材权利。原文个别引用、记号和表图标签不一致之处见译注，未擅自修改实验数据。

摘要

在现实应用中，新情绪类别不断出现，而且多种情绪经常共同发生，情绪识别系统因此面临重大挑战。本文提出多标签细粒度类别增量情绪解码，旨在开发能够增量学习新情绪类别，同时保持识别多种并存情绪能力的模型。我们提出增强情绪语义学习（Augmented Emotional Semantics Learning, AESL）框架，以解决两个关键挑战：过去缺失和未来缺失的部分标签问题。AESL 融合增强情绪关系图（Emotional Relation Graph，ERG），以生成可靠的软标签，并利用基于情感维度的知识蒸馏学习面向未来的特征。我们在涵盖脑活动和多媒体领域的三个数据集上评估该方法，展示其解码多达 28 种细粒度情绪类别的有效性。结果表明，AESL 显著优于现有方法，并有效缓解灾难性遗忘。代码位于 https://github.com/ChangdeDu/EmoGrowth。

1. 引言

准确解码人类情绪状态，仍是情感计算研究中的一项基础挑战。尽管传统深度学习方法已经展现出良好性能（Li & Deng, 2020；Poria et al., 2017），但它们难以适应不断演变的现实场景：新情绪类别持续涌现，以刻画日益细腻的情绪体验。正如著名小说家 Jeffrey Eugenides（Eugenides, 2003）所说：“依我的经验，情绪不是单个词就能涵盖的。我不相信‘悲伤’、‘喜悦’或‘遗憾’。”这一深刻观察凸显了人类情绪固有的复杂性。实际上，面对情绪刺激时，人们往往同时体验多种情绪的复杂混合（Fu et al., 2022）。受此启发，我们提出一个新的研究范式：多标签细粒度类别增量情绪解码。

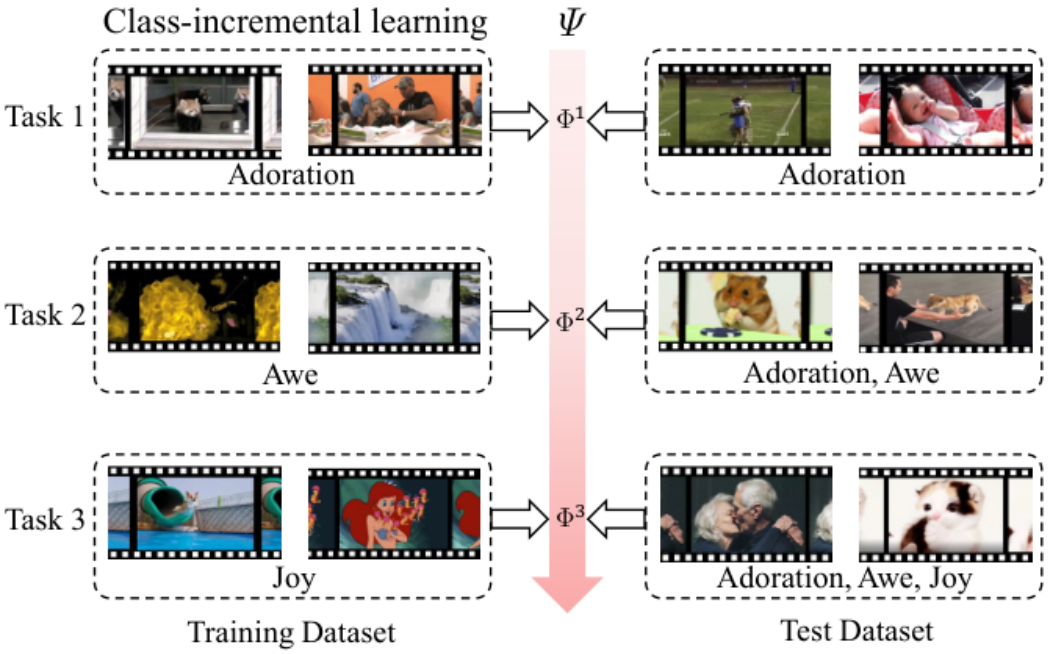


图 1. 类别增量学习过程通过三个顺序任务展示：任务 1 从“喜爱”（Adoration）开始，任务 2 引入“敬畏”（Awe），任务 3 加入“喜悦”（Joy）。统一模型 ψ 的参数依次为 Φ^1, Φ^2, Φ^3，模型在任务间演进，同时保持识别所有已学习情绪的能力。图中 Class-incremental learning 为类别增量学习，Training Dataset 为训练数据集，Test Dataset 为测试数据集，Task 为任务。

如图 1 所示，多标签类别增量情绪解码旨在开发一个统一模型，使之能够增量学习和整合既有及新出现情绪类别的知识，同时全面解码多种并存的情绪状态。不同于传统单标签类别增量学习（SLCIL），多标签类别增量学习（MLCIL）在应对灾难性遗忘时具有独特挑战，主要源于过去缺失和未来缺失的部分标签问题。以过去缺失为例：任务 3 训练数据集左侧的截图（柯基犬正在潜水）具有“喜爱”标签，但该情绪在当前任务中对模型不可见。类似地，在未来缺失的情形下，任务 1 数据集右侧的截图（父亲正在给女儿梳头）包含“喜悦”标签，但模型在当前任务中无法访问它。现有 MLCIL 方法要么依赖存储历史实例（Kim et al., 2020；Liang & Li, 2022），从而限制实际适用性；要么忽略关键的未来缺失部分标签问题（Du et al., 2022），因而性能欠佳。

为应对这些挑战，我们提出新的增强情绪语义学习（AESL）框架。首先，针对过去缺失部分标签问题，我们引入带有基于图的标签消歧的增强情绪关系图（ERG）模块。遇到新任务时，该模块不仅为已有情绪类别生成可靠软标签，还将历史 ERG 与新数据整合，构造增强 ERG，保留关键的情绪标签相关性。其次，为解决未来缺失部分标签问题，我们利用情感维度空间这一能够表达无限种情绪类别的另一种情绪模型（Russell & Mehrabian, 1977），为持续情绪学习提供互补的领域知识（Le et al., 2023）。基于这一认识，我们开发基于关系的知识蒸馏框架，使模型特征与情感维度空间对齐。此外，我们利用 ERG 设计包含图自编码器的情绪语义学习模块，学习情绪嵌入，促进语义特定特征解耦，这对增强多标签学习至关重要。我们在三个数据集上开展广泛评估：包含 5 名受试者的人脑活动数据集 Brain27，以及两个多媒体数据集 Video27 和 Audio28；使用多种增量学习协议，涵盖多达 28 种细粒度情绪类别。主要贡献有三项：

- 首次研究多标签类别增量情绪解码，推动动态现实环境中的情绪识别能力。

- 开发创新的增强情绪语义学习框架，在提升情绪解码性能的同时，有效缓解 MLCIL 场景中的灾难性遗忘。
- 通过三个数据集和多种增量学习协议上的综合实验，验证该方法的优越有效性。

2. 相关工作

类别增量学习。 类别增量学习受到机器学习研究的广泛关注（De Lange et al., 2021；Masana et al., 2020）。传统方法主要通过正则化（Kirkpatrick et al., 2017）、知识蒸馏（Li & Hoiem, 2017）或记忆回放（Rebuffi et al., 2017）防止灾难性遗忘。近期工作探索了参数隔离（Serra et al., 2018）和动态架构适应（Yan et al., 2021）等更复杂的方法。

多标签类别增量学习。 MLCIL 处理同时进行类别增量学习与多标签分类这一关键挑战。近期研究探索了多种方法：Dong et al.（2023）提出基于注意力的知识恢复和迁移框架；AGCN（Du et al., 2022）采用 GCN 学习标签关系。PRS（Kim et al., 2020）和 OCDM（Liang & Li, 2022）则通过专门的回放缓冲区设计处理在线类别增量学习。此外，还有针对 MLCIL 的原型学习（Zhang et al., 2021）和知识蒸馏（Liu et al., 2022）研究。然而，专门面向情绪解码的 MLCIL 在很大程度上仍未得到探索，尤其是部分标签问题与情绪语义保留方面。

类别增量情绪解码。 持续学习新情绪类别已成为情感计算的重要研究方向。Churamani & Gunes（2020）提出 CLIFER，将生成模型与基于互补学习的双记忆模型结合，实现持续面部表情识别。Ma et al.（2022）开发基于 GCN 的方法，对情绪类别进行少样本类别增量分类；Jiménez-Guarneros et al.（2022）引入权重对齐，以处理新情绪类别中的偏差。更近期工作探索了自适应架构（Wang et al., 2023）和元学习方法（Zhang et al., 2022）。然而，这些研究主要局限于少量粗粒度情绪类别，未能处理人类情绪表达的复杂性。

3. 方法

3.1. 问题形式化

在 MLCIL 场景中，我们有一个由 B 个训练任务构成的序列 $\{\mathcal{D}^1, \mathcal{D}^2, ..., \mathcal{D}^B\}$，各任务的情绪类别互不重叠。其中，第 b 个增量任务为 $\mathcal{D}^b = \{\left(\mathbf{x}_i^b, Y_i^b\right)\}_{i=1}^{n_b}$，包含 n_b 个训练实例。 $\mathbf{x}_i^b \in \mathbb{R}^D$ 是一个实例，其类别为 $Y_i^b \subseteq C^b$。 C^b 为任务 b 的标签集合，当 $b \neq b'$ 时有 $C^b \cap C^{b'} = \varnothing$。任务 b 训练期间只能访问 $\mathcal{D}^b$ 的数据。 $\mathbf{y}_i^b \in \mathbb{R}^{|C^b|}$ 是多热标签向量，其中 $y_{ic}^b \in \{0, 1\}$ 表示情绪 c 是否与实例 $\mathbf{x}_i^b$ 相关。完成任务 b 后，在所有已见情绪类别 $\mathcal{C}^b = C^1 \cup \cdots \cup C^b$ 上评估模型。

3.2. 框架概述

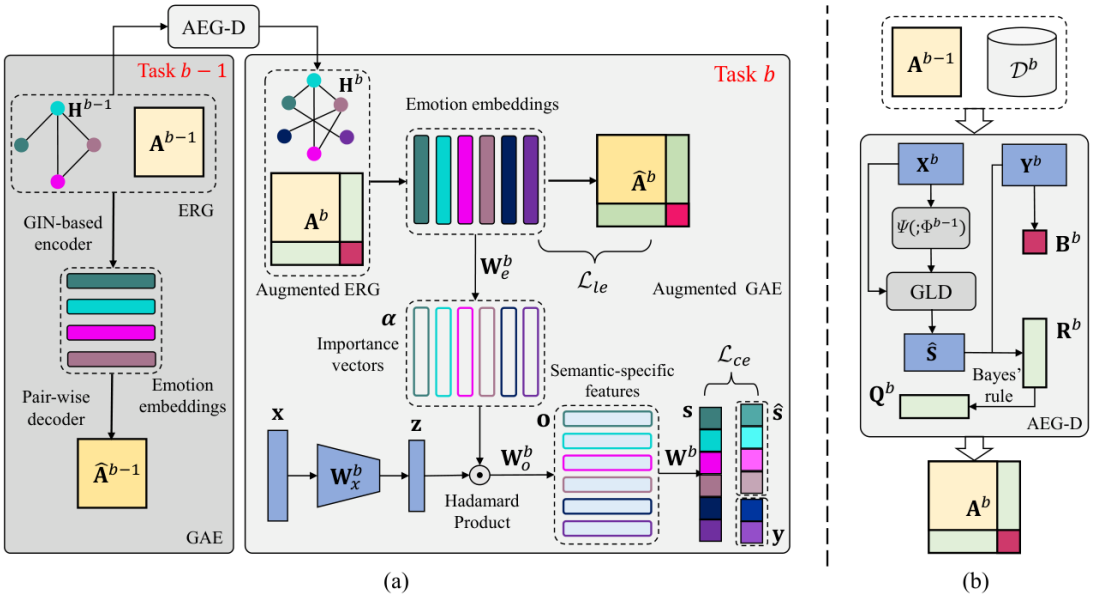


图 2. 面向多标签类别增量情绪解码的 AESL 框架。（a）增量学习场景中的情绪语义学习与语义引导特征解耦流程。为清晰起见，省略任务 $b-1$ 中的语义引导特征解耦模块。（b）在任务 b 中通过标签消歧构建增强 ERG 的过程。图内 GIN-based encoder：基于 GIN 的编码器；Pair-wise decoder：成对解码器；Emotion embeddings：情绪嵌入；Augmented ERG/GAE：增强 ERG/GAE；Importance vectors：重要性向量；Semantic-specific features：语义特定特征；Hadamard Product：Hadamard 积；Bayes' rule：贝叶斯规则。

如图 2(a) 所示，AESL 通过四个相互关联的模块处理各增量任务。ERG 模块首先构建并维护情绪关系图，为情绪语义学习提供基础。随后，图自编码器（GAE）从 ERG 中学习情绪嵌入，引导特征解耦模块提取标签特定特征。最后，基于关系的知识蒸馏在适应新情绪类别的同时保留此前学习的知识。这些组件共同处理 MLCIL 中过去缺失与未来缺失两种部分标签问题。

3.3. 增强情绪关系图

首先介绍带标签消歧的增强情绪关系图模块（AEG-D），如图 2(b) 所示。在任务 b 开始时，我们能够访问新标签 $\mathcal{C}^b$。相对于已有情绪关系图 $\mathcal{G}^{b-1}$，需要分别将节点集与邻接矩阵扩充为 V^b 和 $\mathbf{A}^b$。对于前者，只需从标准高斯分布中采样 $|\mathcal{C}^b|$ 个向量。（译注：此处原文使用累计类别集合的基数，与按新标签数 $|\mathcal{C}^b|$ 扩充节点的意图不同；照录原记号。）对于后者，由于部分标签问题，难以直接通过标签共现统计推断 $\mathbf{A}^b$。给定类别集合 $\mathcal{C}$，基于标签共现定义其邻接矩阵：

$$\mathbf{A}_{ij} = P\left(\ell_i \in \mathcal{C} \mid \ell_j \in \mathcal{C}\right)\big|_{i\neq j} = \frac{N_{ij}}{N_j}. \qquad (1)$$

其中，N_{ij} 为同时具有类别 ℓ_i 与 ℓ_j 的实例数，N_j 为具有类别 ℓ_j 的实例数。任务 b 到来时，增强邻接矩阵 $\mathbf{A}^b$ 可写为如下分块形式（Du et al., 2022）：

$$\mathbf{A}^b = \begin{bmatrix} \mathbf{A}^{b-1} & \mathbf{R}^b \\ \mathbf{Q}^b & \mathbf{B}^b \end{bmatrix} \Leftrightarrow \begin{bmatrix} \text{Old-Old} & \text{Old-New} \\ \text{New-Old} & \text{New-New} \end{bmatrix}. \qquad (2)$$

四个分块依次表示旧-旧、旧-新、新-旧、新-新类别关系。$\mathbf{A}^{b-1}$ 可以直接从先前任务继承，而 $\mathbf{B}^b$ 可以由 $\mathcal{D}^b$ 方便地计算得到。（译注：原文此处写为“从任务 b 继承”，与矩阵上标所指前一任务不一致。）然而，$\mathbf{R}^b$ 和 $\mathbf{Q}^b$ 涉及过去任务的旧类别与任务 b 新类别之间的跨任务标签关系。为了后续计算，首先应为新数据集 $\mathcal{D}^b$ 的实例赋予过去标签集合 $\mathcal{C}^{b-1}$ 上的软标签。为清晰起见，用 $\mathbf{s} = \psi(\mathbf{x}, \mathbf{A}; \Phi)$ 表示情绪语义学习与语义引导特征解耦过程，其中 $\Phi = \{\theta, \phi, \mathbf{W}\}$。虽然 $\mathbf{s}^b = \psi\left(\mathbf{x}^b, \mathbf{A}^{b-1}; \Phi^{b-1}\right)$ 是构建软标签的一种可行方案，但这种软标签包含大量噪声，也未利用实例之间的相关性。

为解决这一问题，我们对标签置信分数 $\mathbf{s}^b$ 采用基于图的标签消歧（GLD）模块。首先，使用高斯核计算两个实例的相似度；不引起歧义时省略 b：$\mathbf{P}_{ij} = \exp\left(-\parallel \mathbf{x}_i - \mathbf{x}_j \parallel^2/\left(2\sigma^2\right)\right)$，其中 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 是 $\mathcal{D}^b$ 中的两个不同样本。按照标签传播过程，对权重矩阵 $\mathbf{P}$ 按列归一化，令传播矩阵 $\widehat{\mathbf{P}} = \mathbf{P}\mathbf{D}^{-1}$，其中 $\mathbf{D} = \mathrm{diag}\left[d_1, \ldots, d_{n_b}\right]$，$d_j = \sum_{i=1}^{n}\mathbf{P}_{ij}$。假设通过 $\psi\left(; \Phi^{b-1}\right)$，能够获得 $\mathcal{D}^b$ 的过去标签置信矩阵，记为 $\mathbf{S} \in \mathbb{R}^{n_b \times |\mathcal{C}^{b-1}|}$。令初始标签置信矩阵 $\mathbf{F}^0 = \mathbf{S}$。在第 t 次迭代，通过沿 $\widehat{\mathbf{P}}$ 传播当前标注置信度来更新细化后的标签置信矩阵：

$$\mathbf{F}_t = \beta\widehat{\mathbf{P}}^T\mathbf{F}_{t-1} + \left(1-\beta\right)\mathbf{F}_0. \qquad (3)$$

平衡参数 $\beta \in [0, 1]$ 控制从迭代标签传播与 $\mathbf{F}^0$ 中继承的标注信息量。令 $\mathbf{F}^*$ 为最终标签置信矩阵，同时作为消歧后的软标签，即 $\widehat{\mathbf{S}} = \mathbf{F}^*$。按照 Chen et al.（2020），标签消歧时将 β 设为 0.95。

有了数据集 $\mathcal{D}^b$ 和软标签矩阵 $\widehat{\mathbf{S}}$，便可计算 $\mathbf{R}^b \in \mathbb{R}^{|\mathcal{C}^{b-1}| \times |C^b|}$：

$$\mathbf{R}_{ij}^b = P\left(\ell_i \in \mathcal{C}^{b-1} \mid \ell_j \in C^b\right) = \frac{\sum_{\mathbf{x}} \hat{s}_i y_j}{N_j}. \qquad (4)$$

其中，$\hat{s}_i$ 表示软标签矩阵中实例 $\mathbf{x}$ 对应类别 i 的值，y_j 表示由 $\mathcal{D}^b$ 得到的标签矩阵中同一实例对应类别 j 的值。自然地，根据贝叶斯规则可获得 $\mathbf{Q}^b \in \mathbb{R}^{|C^b| \times |\mathcal{C}^{b-1}|}$：

$$\begin{aligned}\mathbf{Q}_{ji}^b &= P\left(\ell_j \in C^b \mid \ell_i \in \mathcal{C}^{b-1}\right) \\ &= \frac{P\left(\ell_i \in \mathcal{C}^{b-1} \mid \ell_j \in C^b\right)P\left(\ell_j \in C^b\right)}{P\left(\ell_i \in \mathcal{C}^{b-1}\right)} = \frac{\mathbf{R}_{ij}^b N_j}{\sum_{\mathbf{x}} \hat{s}_i}.\end{aligned} \qquad (5)$$

至此，我们构建了邻接矩阵 $\mathbf{A}^b$，实现了多标签场景中新情绪类别的持续学习。值得注意的是，在实验中实际使用对称邻接矩阵进行模型训练，即应用 $\left(\mathbf{A} + \mathbf{A}^T\right)/2$ 运算。

3.4. 情绪语义学习

下面关注如何获得任务 b 中的情绪嵌入。构建增强 ERG $\mathcal{G}^b = \left(V^b, E^b\right)$，其中 V^b 表示对应类别标签 $\mathcal{C}^b$ 的节点，E^b 表示边。随后利用 GAE，借助 ERG 将情绪标签投影到标签共现语义空间。由于图同构网络（GIN）（Xu et al., 2019）具有强大的表征学习能力，我们采用它作为 GAE 的编码器。具体而言，给定节点特征矩阵 $\mathbf{H}_l^b \in \mathbb{R}^{|\mathcal{C}^b| \times d_l}$，每一行表示一种情绪标签的嵌入，$d_l$ 为第 l 个 GIN 层的节点特征维度。节点特征可在 GIN 层内通过消息传递策略更新：

$$\mathbf{H}_{l+1}^b = f_{l+1}\left[\left(1+\epsilon_{l+1}\right)\mathbf{H}_l^b + \mathbf{A}^b\mathbf{H}_l^b; \theta_{l+1}^b\right]. \qquad (6)$$

其中，$\mathbf{H}_{l+1}^b \in \mathbb{R}^{|\mathcal{C}^b| \times d_{l+1}}$ 是更新后的节点特征矩阵，$f_{l+1}\left(:, \theta_{l+1}\right)$ 表示全连接神经网络。此外，ϵ_{l+1} 是可学习参数，用于调节邻域聚合中节点自身特征的重要性。不同于图像分类中的物体标签（Chen et al., 2019），情绪类别标签很难直接从语言模型获得初始词嵌入。因此，初始节点特征矩阵 $\mathbf{H}_0^b \in \mathbb{R}^{|\mathcal{C}^b| \times d_0}$ 由标准高斯分布初始化，并设 $d_0 = |\mathcal{C}^b|$（也可以取其他与任务无关的常数）。叠加 L 个 GIN 层后，使用 $\mathbf{E}^b = \mathbf{H}_L^b \in \mathbb{R}^{|\mathcal{C}^b| \times d_L}$ 作为任务 b 的最终情绪标签语义嵌入，以进一步提取语义特定特征。

此外，引入成对解码器重建邻接矩阵 $\mathbf{A}^b$，确保获得的标签嵌入能够良好捕捉标签语义空间的拓扑结构。成对解码器的损失函数为：

$$\mathcal{L}_{le} = \frac{1}{|\mathcal{C}^b|^2}\sum_{i=1}^{|\mathcal{C}^b|}\sum_{j=1}^{|\mathcal{C}^b|}\left[\frac{\left(\mathbf{e}_i^b - \bar{\mathbf{e}}^b\right)^T\left(\mathbf{e}_j^b - \bar{\mathbf{e}}^b\right)}{\| \mathbf{e}_i^b - \bar{\mathbf{e}}^b \| \ \| \mathbf{e}_j^b - \bar{\mathbf{e}}^b \|} - \widehat{\mathbf{A}}_{ij}^b\right]^2. \qquad (7)$$

其中，$\bar{\mathbf{e}}^b = \mathbb{E}_i\left[\mathbf{e}_i^b\right]$ 为任务 b 的平均情绪嵌入，$\mathbf{e}_i^b$ 表示 $\mathbf{E}^b$ 的第 i 行；$\widehat{\mathbf{A}}^b = \mathbf{A}^b + \mathbf{I}^b$，其中 $\mathbf{I}^b$ 为单位矩阵。总体而言，情绪语义学习旨在拟合函数 $f\left(\cdot, \theta^b\right)$，在任务 b 中得到 $\mathbf{E}^b = f\left(\mathbf{H}_0^b, \mathbf{A}^b; \theta^b\right)$。

3.5. 语义引导的特征解耦

带有语义引导特征解耦的多标签分类模型，可以视为语义特定特征提取器 g 与分类头 $\mathbf{W}$ 的组合（为简洁起见，省略偏置）。任务 b 中，$g\left(; \phi^b\right): \mathbb{R}^D \times \mathbb{R}^{|\mathcal{C}^b| \times d_L} \to \mathbb{R}^{|\mathcal{C}^b| \times d}$，$\mathbf{W}^b \in \mathbb{R}^{d \times |\mathcal{C}^b|}$。对于特定情绪标签 $\ell_k \in \mathcal{C}^b$，其语义特定映射为 $g_k\left(\mathbf{x}^b, \mathbf{e}_k^b; \phi^b\right) \in \mathbb{R}^d$。线性层可进一步分解为分类器组合 $\mathbf{W}^b = \left[\mathbf{w}_1, \ldots, \mathbf{w}_{|\mathcal{C}^b|}\right]$，每个分类器对应一个情绪嵌入。随着持续学习推进，分类头将为新类别扩展。关键在于设计语义特定特征提取器 g_k。

为此，首先利用全连接网络，将实例表征 $\mathbf{x}^b$ 从原始特征空间映射到更具表达力的深层潜在特征 $\mathbf{z}$，其参数为 $\mathbf{W}_x^b \in \mathbb{R}^{D \times d_z}$ 和 $\mathbf{b}_x^b \in \mathbb{R}^{d_z}$。为了利用情绪语义引导每个标签的特征提取，我们采用类似注意力的机制。具体来说，将 $\mathbf{e}_k^b$ 输入全连接网络后接 sigmoid 函数，得到各情绪类别的特征重要性值 α_k，网络参数为 $\mathbf{W}_e^b \in \mathbb{R}^{d_L \times d_z}$ 和 $\mathbf{b}_e^b \in \mathbb{R}^{d_z}$。随后，通过特征重要性向量与潜在表征的 Hadamard 积，为各情绪类别选择相关特征。接着，用另一全连接网络获得各类别的语义特定特征。此过程可表述为：

$$\mathbf{o}_k = \zeta\left[\left(\mathbf{W}_o^b\right)^T\left(\mathbf{z}\odot\boldsymbol{\alpha}_k\right)+\mathbf{b}_o^b\right]. \qquad (8)$$

其中，$\mathbf{W}_o^b \in \mathbb{R}^{d_z \times d}$ 和 $\mathbf{b}_o^b \in \mathbb{R}^d$ 是共享的可学习参数；$\odot$ 表示 Hadamard 积，ζ 表示激活函数。此时，已经定义了语义特定特征提取器 $\mathbf{o}_k = g_k\left(\mathbf{x}^b, \mathbf{e}_k^b; \phi^b\right)$，其中 $\phi = \{\mathbf{W}_x, \mathbf{W}_e, \mathbf{W}_o, \mathbf{b}_x, \mathbf{b}_e, \mathbf{b}_o\}$。于是可通过对应分类器预测情绪标签 ℓ_k 存在的置信分数：

$$\begin{aligned} s_k &= \sigma\left(\mathbf{w}_k^T\mathbf{o}_k + b_k\right) \\ &= \sigma\left(\mathbf{w}_k^T g_k\left(\mathbf{x}^b, \mathbf{e}_k^b; \phi^b\right) + b_k\right), \quad k \in \{1, \ldots, |\mathcal{C}^b|\}. \end{aligned} \qquad (9)$$

3.6. 基于关系的知识蒸馏

尽管已经实现语义特定特征学习，并通过 AEG-D 克服过去缺失部分标签问题，但仍未解决 MLCIL 中未来缺失部分标签的问题。既有研究（Schlosberg, 1954；Russell & Mehrabian, 1977）表明，情感维度作为情绪类别模型的互补模型，可以在其构成的情感空间中表示无限种情绪类别。我们认为，将情感维度空间的领域知识纳入模型，能够缓解未来缺失部分标签问题。各任务训练期间，尝试将模型特征空间与预定义情感空间对齐；该空间由唤醒度和效价等情感维度构成。考虑到两个空间的异质性，我们采用基于关系的知识蒸馏（RKD）。具体而言，首先计算任务 b 的模型特征 $\mathbf{z}$ 对应的表征相似性矩阵（RSM）（Kriegeskorte et al., 2008）：

$$\mathbf{M}_{ij}^b = \frac{\left(\mathbf{z}_i - \bar{\mathbf{z}}\right)^T\left(\mathbf{z}_j - \bar{\mathbf{z}}\right)}{\| \mathbf{z}_i - \bar{\mathbf{z}} \| \ \| \mathbf{z}_j - \bar{\mathbf{z}} \|}. \qquad (10)$$

其中，$\bar{\mathbf{z}} = \mathbb{E}_i\left[\mathbf{z}_i\right]$ 为所有实例的模型特征均值。类似地，情感维度特征 $\boldsymbol{\tau}$ 对应的 RSM 为：

$$\mathbf{M}_{ij}^{aff} = \frac{\left(\tau_i - \bar{\tau}\right)^T\left(\tau_j - \bar{\tau}\right)}{\| \tau_i - \bar{\tau} \| \ \| \tau_j - \bar{\tau} \|}. \qquad (11)$$

随后定义相似性损失：

$$\begin{aligned} \mathcal{L}_{kd_{aff}} &= \mathbb{E}_{i\neq j}\left[\mathcal{L}_{kd_{aff}}^{ij}\right] \\ &= \mathbb{E}_{i\neq j}\left[\left(\operatorname{arctanh}\left(\mathbf{M}_{ij}^b\right) - \operatorname{arctanh}\left(\mathbf{M}_{ij}^{aff}\right)\right)^2\right]. \end{aligned} \qquad (12)$$

其中，$\mathcal{L}_{kd_{aff}}^{ij}$ 是基于样本的中心化核对齐指标。利用 arctanh 将相似性值从区间 $(-1, 1)$ 重新参数化到 $(-\infty, \infty)$，使之近似服从高斯分布。此外，为保证训练稳定，采用同样方法拉近 $\mathbf{M}_{ij}^b$ 与 $\mathbf{M}_{ij}^{b-1}$，得到 $\mathcal{L}_{kd_{model}}$。这样，模型便能访问两个教师：情感维度与旧模型，如图 3 所示。由此得到总体知识蒸馏损失：

$$\mathcal{L}_{kd} = \lambda_1\mathcal{L}_{kd_{model}} + \lambda_2\mathcal{L}_{kd_{aff}}. \qquad (13)$$

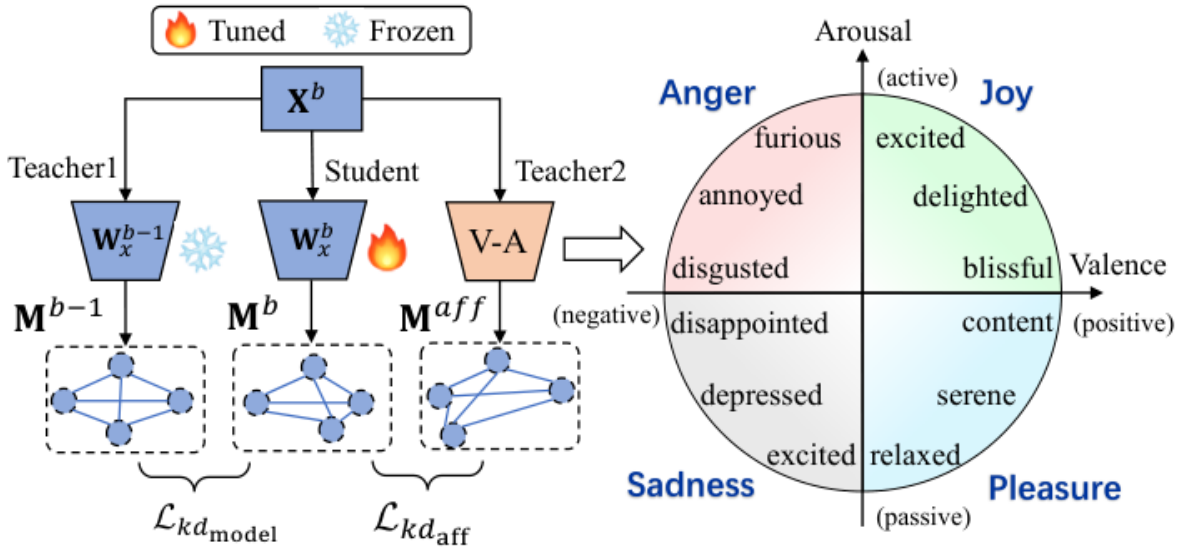


图 3. 训练任务 b 期间，具有两个教师的基于关系的知识蒸馏示意图。教师 1 和教师 2 在训练中被冻结。每一种离散情绪类别对应唤醒度（Arousal）和效价（Valence）构成的情感空间中的一点。Tuned：调优；Frozen：冻结；Teacher：教师；Student：学生。纵轴 active/passive：活跃/被动；横轴 negative/positive：负性/正性。四个区域 Anger/Joy/Sadness/Pleasure：愤怒/喜悦/悲伤/愉悦。示例词 furious、annoyed、disgusted、disappointed、depressed、excited、delighted、blissful、content、serene、relaxed 依次为暴怒、烦恼、厌恶、失望、低落、兴奋、欣喜、幸福、满足、安宁、放松（原图底部左侧也标为 excited，照原样保留）。

3.7. 目标函数

如前所述，实例 $\mathbf{x}$ 的预测置信分数可用式（9）计算。在任务 b 中记为 $\mathbf{s} = [s_1, \ldots, s_{|\mathcal{C}^b|}]^T \in \mathbb{R}^{|\mathcal{C}^b|}$。我们能够访问 $\mathcal{D}^b$ 的真值，记为多热向量 $\mathbf{y} = [y_1, \ldots, y_{C^b}]^T \in \mathbb{R}^{|C^b|}$。此外，第 3.3 节已利用模型 $b-1$ 计算过去情绪类别的软标签，记为 $\hat{\mathbf{s}} = [\hat{s}_1, \ldots, \hat{s}_{|\mathcal{C}^{b-1}|}]^T \in \mathbb{R}^{|\mathcal{C}^{b-1}|}$，且 $C^b \cup \mathcal{C}^{b-1} = \mathcal{C}^b$。综上，使用混合真值 $\widetilde{\mathbf{y}} = [\hat{\mathbf{s}}^T, \mathbf{y}^T]^T \in \mathbb{R}^{|\mathcal{C}^b|}$ 训练任务 b，采用二元交叉熵损失：

$$\mathcal{L}_{ce} = -\sum_{i=1}^{|\mathcal{C}^b|} \left[\widetilde{y}_i \log(s_i) + (1-\widetilde{y}_i)\log(1-s_i)\right]. \qquad (14)$$

最终，以如下目标函数端到端训练模型：

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda_1 \mathcal{L}_{kd_{model}} + \lambda_2 \mathcal{L}_{kd_{aff}} + \lambda_3 \mathcal{L}_{le}. \qquad (15)$$

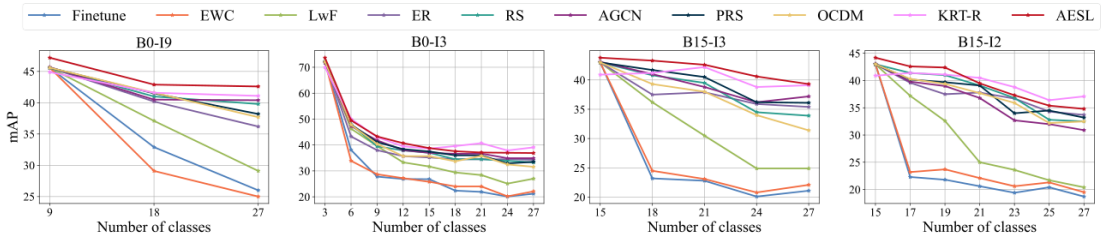
任务 b 训练完毕后，对给定未见实例，预测其关联标签集合为 $\{\ell_k \mid s_k > 0.5,\ 1 \le k \le \mathcal{C}^b\}$。（译注：本节原文向量末项写作 y_{C^b}，预测范围上界写作 $\mathcal{C}^b$，未显式取集合基数；此处保留原记号。）AESL 算法见附录 A。

4. 实验

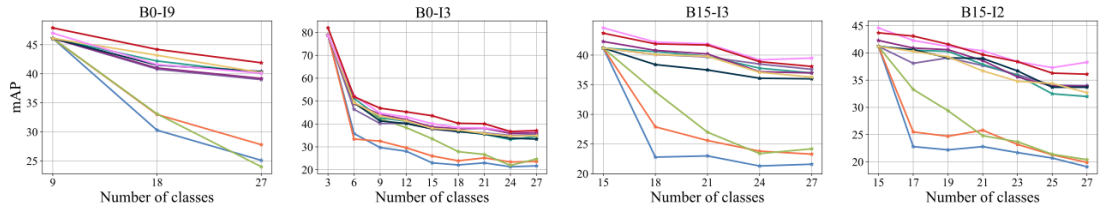
4.1. 实验设置

数据集。 为全面评估 AESL 和对比方法的性能，实验使用三个数据集：Brain27（Horikawa et al., 2020）、Video27（Cowen & Keltner, 2017）和 Audio28（Cowen et al., 2020）。采用类别增量学习研究中两种常用协议（Dong et al., 2023）：（1）将全部情绪类别分成若干部分依次训练；（2）先用少量类别训练基础模型，再将剩余类别划分成若干任务。对 Brain27 和 Video27，数据集划分采用 B0-I9（基础类别数为 0、每次增量类别数为 9）、B0-I3、B15-I3 和 B15-I2。对 Audio28，则采用 B0-I7、B0-I4、B16-I3 和 B16-I2。

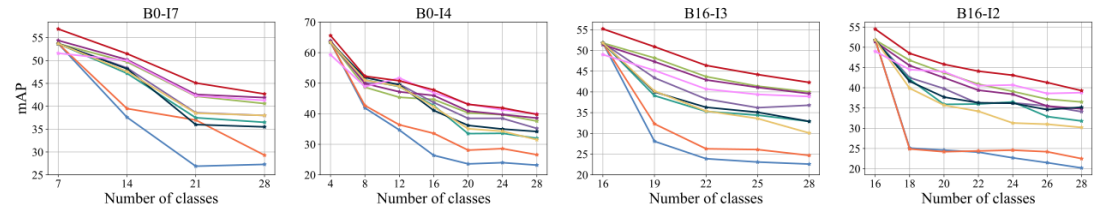
基线。 我们将 AESL 与多种基础和先进的类别增量方法进行比较。Finetune 是不施加任何抗遗忘约束、只对模型微调的基线。选取四种 SLCIL 方法进行比较：EWC（Kirkpatrick et al., 2017）、LwF（Lee et al., 2019）、ER（Rolnick et al., 2019）和 RS（Vitter, 1985）。此外，采用成熟的 MLCIL 方法 AGCN（Du et al., 2022）、PRS（Kim et al., 2020）、OCDM（Liang & Li, 2022）和 KRT-R（Dong et al., 2023）作为对比。上界（Upper-bound）设为在所有任务数据上进行监督训练。更多实验设置详见附录 B。（译注：原文称“三种” MLCIL 方法，但实际列出四种；此处完整保留四种名称。）



(a) *Brain27*(1)



(b) *Video27*



(c) *Audio28*

图 4. 在实验所用三个数据集及不同协议下，与各 CIL 对比方法的比较结果（mAP）。（a）Brain27 受试者 1；（b）Video27；（c）Audio28。横轴 Number of classes 为类别数量，纵轴为 mAP；图例为各方法名称。

4.2. 实验结果

对比研究。 表 1、2 和 3 分别展示 Brain27 受试者 1（更多结果见附录 C）、Video27 和 Audio 的结果。可以看到，在不同数据集和协议下，AESL 在三个广泛使用的指标 mAP、maF1 和 miF1（Zhang & Zhou, 2013）上表现出明显优势。尤其在 Brain27 上，相对于第二名方法，AESL 的 mAP 相对提升 9.6%（四种协议平均），maF1 相对提升 9.7%。图 4 展示 AESL 与对比方法的性能曲线，表明本文方法在增量学习的各任务上始终最优。在对比方法中，EWC 和 LwF 是传统 SLCIL 方法。EWC 的表现较差，说明它不适合直接用于 MLCIL 任务。相比之下，LwF 在 Audio28 数据集上取得令人印象深刻的性能。我们推测，知识蒸馏实质上为旧类别提供了软标签，从而帮助克服 MLCIL 中的灾难性遗忘。

表 1. Brain27 数据集受试者 1 的类别增量结果。对比方法中的 AGCN、PRS、OCDM 和 KRT-R 为 MLCIL 算法。以下结果表保留全部原始数值与方法名称；Method：方法；Upper-bound：上界；Avg. Acc：平均准确性能；Last Acc：最终任务准确性能。每种协议下依次给出平均 mAP，以及最终任务的 maF1、miF1、mAP。

Table 1. Class incremental results on subject 1 of *Brain27* dataset. AGCN, PRS, OCDM and KRT-R are MLCIL algorithms among these compared methods.

Method	**Brain27 B0-I9**				**Brain27 B0-I3**				**Brain27 B15-I3**				**Brain27 B15-I2**			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	39.1	47.2	45.8	-	39.1	47.2	45.8	-	39.1	47.2	45.8	-	39.1	47.2	45.8
Finetune	34.8	9.2	19.3	26.0	30.8	5.0	13.8	21.2	26.0	5.0	13.9	21.1	23.7	3.6	13.2	18.7
EWC	33.2	8.1	17.1	25.0	30.9	5.0	13.9	22.1	26.7	5.3	14.3	22.1	24.8	3.6	13.2	19.5
LwF	37.3	12.2	29.1	29.1	37.0	23.4	40.0	27.0	31.9	14.2	28.6	24.9	29.1	15.2	31.8	20.4
ER	40.7	8.0	11.7	36.2	40.2	4.9	9.1	34.3	37.9	9.7	12.3	35.4	37.5	9.6	11.7	33.7
RS	42.1	9.4	12.6	39.8	41.2	4.5	7.4	33.3	38.3	8.0	11.1	33.9	37.9	5.1	8.7	32.5
AGCN	42.2	29.5	44.5	40.4	42.1	35.4	43.7	34.9	39.3	28.8	**41.7**	37.2	36.3	24.4	36.4	30.9
PRS	41.6	9.3	15.1	38.2	41.7	5.5	8.4	33.5	39.5	8.2	12.2	36.1	37.7	9.4	13.1	33.2
OCDM	41.6	9.7	15.9	37.7	40.6	5.3	7.6	31.6	37.2	4.9	7.1	31.4	37.3	4.4	7.6	32.5
KRT-R	42.5	18.2	30.3	41.1	**44.3**	22.9	32.1	**39.1**	40.4	20.0	33.2	39.1	**39.5**	20.3	33.7	**37.1**
AESL	**44.2**	**32.8**	**44.7**	**42.6**	43.8	**37.1**	**44.0**	36.9	**41.9**	**32.5**	**41.7**	**39.3**	**39.5**	**26.8**	**36.5**	34.8

表 2. Video27 数据集的类别增量结果。AGCN、PRS、OCDM 和 KRT-R 为 MLCIL 算法。表头含义同表 1。

Table 2. Class incremental results on *Video27* dataset. AGCN, PRS, OCDM, and KRT-R are MLCIL algorithms among these compared methods.

Method	**Video27 B0-I9**				**Video27 B0-I3**				**Video27 B15-I3**				**Video27 B15-I2**			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	36.8	46.3	45.4	-	36.8	46.3	45.4	-	36.8	46.3	45.4	-	36.8	46.3	45.4
Finetune	33.8	6.6	13.7	25.1	31.5	4.2	13.0	21.7	26.0	4.3	13.3	21.6	24.3	4.2	13.7	19.1
EWC	35.6	7.5	17.8	27.8	32.9	4.7	13.2	23.6	28.4	4.9	13.9	23.3	26.0	3.9	13.1	19.9
LwF	34.4	6.8	23.3	24.0	38.2	19.9	37.3	24.7	30.0	12.5	33.4	24.2	27.7	15.8	32.7	20.4
ER	42.0	5.1	7.0	39.0	43.0	4.5	4.8	35.4	39.4	8.0	8.3	37.6	37.2	10.1	12.6	34.0
RS	42.8	4.6	6.1	40.1	43.6	4.6	7.8	34.5	39.3	4.2	5.2	37.0	37.2	6.7	9.9	32.0
AGCN	42.1	22.4	39.4	39.2	44.5	34.2	44.5	36.1	39.5	22.7	38.4	37.0	38.0	23.8	36.2	34.0
PRS	42.6	9.5	15.0	40.4	43.0	5.8	9.6	33.4	37.8	8.9	13.4	36.0	37.7	7.4	13.3	33.7
OCDM	43.1	5.5	6.8	40.2	43.8	5.0	7.8	35.0	38.9	4.9	6.6	36.3	37.1	5.2	5.8	32.7
KRT-R	42.9	26.7	35.8	40.1	45.5	26.3	34.7	37.0	**41.5**	**25.0**	35.5	**40.4**	39.5	24.2	34.2	**38.3**
AESL	**44.6**	**23.4**	**39.7**	**41.9**	**47.1**	**35.2**	**45.0**	**37.1**	**41.5**	23.5	**39.2**	38.1	**39.8**	**24.5**	**36.7**	36.1

表 3. Audio28 数据集的类别增量结果。AGCN、PRS、OCDM 和 KRT-R 为 MLCIL 算法。表头含义同表 1。

Table 3. Class incremental results on *Audio28* dataset. AGCN, PRS, OCDM and KRT-R are MLCIL algorithms among these compared methods.

Method	Audio28 B0-I7				Audio28 B0-I4				Audio28 B16-I3				Audio28 B16-I2			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	51.4	61.1	57.1	-	51.4	61.1	57.1	-	51.4	61.1	57.1	-	51.4	61.1	57.1
Finetune	36.4	9.2	14.8	27.3	33.9	5.3	10.0	23.3	29.9	4.4	10.3	22.6	27.6	2.8	8.2	20.2
EWC	37.9	8.3	14.3	29.3	37.1	5.4	10.5	26.6	32.2	4.4	9.7	24.7	28.1	2.8	8.7	22.5
LwF	46.6	37.9	51.7	40.6	45.8	39.9	49.8	37.6	45.0	**32.3**	45.2	40.0	42.3	28.8	41.4	36.5
ER	44.7	8.1	11.4	38.0	45.6	6.5	5.5	35.2	41.3	9.2	13.3	36.8	39.4	10.1	13.6	34.1
RS	43.7	8.1	12.3	36.5	43.6	5.9	9.3	32.0	38.7	7.5	11.7	32.9	38.2	5.8	11.6	31.8
AGCN	47.3	35.3	50.9	41.9	46.6	37.5	51.0	38.6	44.5	29.3	44.6	39.6	41.1	27.5	42.4	34.8
PRS	43.3	9.0	12.8	35.5	44.5	6.8	9.0	34.2	39.2	6.2	8.3	32.9	39.1	8.8	11.4	35.2
OCDM	44.5	8.7	12.0	38.0	43.8	7.5	8.8	31.5	38.2	5.5	9.7	30.1	36.3	3.7	7.9	30.2
KRT-R	46.3	8.2	23.7	41.3	47.3	18.1	33.0	**40.0**	42.6	11.4	27.9	38.9	42.3	13.1	29.2	38.8
AESL	**49.0**	**38.4**	**51.8**	**42.7**	**48.7**	**41.1**	**51.7**	39.8	**47.8**	**32.3**	**48.0**	**42.3**	**45.3**	**30.8**	**45.1**	**39.3**

此外，值得注意的是，基于样本回放的方法，包括 ER、RS、PRS、OCDM 和 KRT-R，效果并不理想，尤其是在 maF1 和 miF1 上。这是因为仅保存当前任务标签，会在后续训练中加剧部分标签问题，说明数据回放并不适合 MLCIL。AGCN 则是很强的基线，在大多数情况下排名第二；本文方法通过有效的标签语义学习，并引入来自情感空间的知识蒸馏，超越 AGCN。

此外，为讨论各对比方法的相对性能，我们采用 Friedman 检验（Demšar, 2006）进行统计检验。对于每个数据集，取四种协议最终 mAP 的平均值用于后续分析。若有 k 个算法与 N 个数据集，则采用算法平均秩 $R_j = \frac{1}{N}\sum_i r_i^j$ 进行 Friedman 检验，其中 r_i^j 为第 j 个算法在第 i 个数据集上的秩。若零假设为所有算法性能相同，那么服从自由度为 $k-1$ 和 $(k-1)(N-1)$ 的 F 分布的 Friedman 统计量为：

$$F_F = \frac{(N-1)\chi_F^2}{N(k-1)-\chi_F^2}. \qquad (16)$$

其中，

$$\chi_F^2 = \frac{12N}{k(k+1)}\left[\sum_{j=1}^{k} R_j^2 - \frac{k(k+1)^2}{4}\right]. \qquad (17)$$

表 4 展示各指标的 Friedman 统计量 F_F 及其相应临界值（对比算法数 $k=9$，数据集数 $N=7$）。在每一个指标上，都能在 0.05 显著性水平拒绝各方法性能相同的零假设。

表 4. 各指标的 Friedman 统计量 F_F，以及 0.05 显著性水平下的临界值。对比算法数 $k=9$，受试者/数据集数 $N=7$。

maF1	miF1	mAP	临界值
37.025	64.000	70.696	2.138

接着进行严格的事后 Nemenyi 检验（Demšar, 2006），用于全部对比方法的两两比较。两个算法秩差的临界差（CD）为：

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}}. \qquad (18)$$

在 0.05 显著性水平下，$q_\alpha = 3.102$。因此，若两个算法平均秩之差大于 CD，就认为其性能显著不同；本实验设置中 $CD = 4.540$。图 5 展示各指标的 CD 图，对比方法的平均秩标在轴上，越小越好。不以水平线相连的方法被认为具有显著性能差异。可以观察到：（1）在 mAP 上，AESL 与其他 MLCIL 方法（OCDM 除外）显著优于 SLCIL 方法。（2）在 miF1 和 maF1 上，无回放方法显著优于基于回放的算法。（3）AESL 与某些 MLCIL 方法之间没有显著差异。这是因为这些方法都优于其他对比方法，Nemenyi 检验未能检出 AESL 在所有评估指标上都始终具有优于其他方法的平均秩。

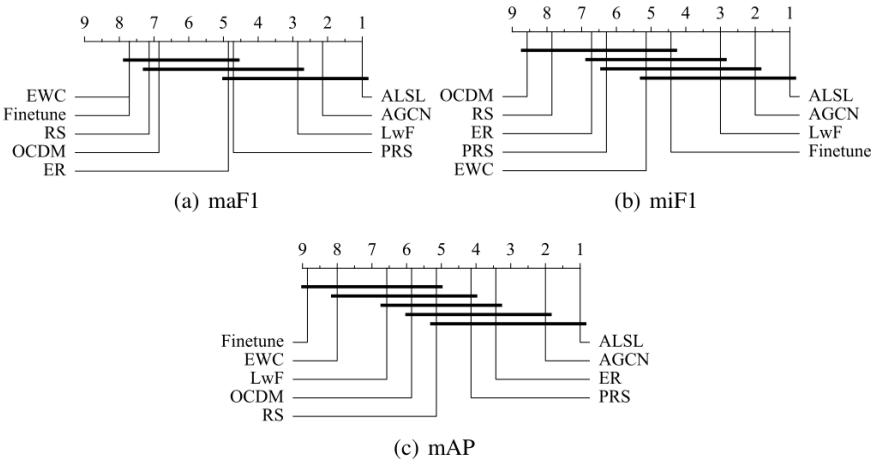


图 5. 对实验中的 7 个数据集和 9 个算法进行 Nemenyi 检验的两两比较。CD 图中彼此不相连的算法被认为存在显著性能差异（0.05 显著性水平下 $CD = 4.540$）。（a）maF1；（b）miF1；（c）mAP。原图将 AESL 标为 ALSL，保留原图标签。

消融研究。为评估 AESL 三个关键组件的作用，我们在 Audio28 数据集的 B0-I7 设置下开展消融实验。设计了七个基线，如表 5 所示：

1. **w/o ESL&LD：** 不使用语义引导特征解耦，直接将特征向量 $\mathbf{z}$ 输入分类器。
2. **w/o ESL&LD, +SE：** 使用先进的 LLaMA 3.1-8B（Dubey et al., 2024）提取情绪类别描述的句子嵌入，并将其用作情绪嵌入。
3. **w/o ESL&LD, +LE：** 为每个新情绪类别分配一个可学习嵌入。
4. **w/o ESL&LD, +AD：** 将逐样本情感维度直接整合为逐类别情绪嵌入。
5. **w/o LD：** 不进行标签消歧，使用原始置信分数 $\mathbf{S}$ 构建邻接矩阵。
6. **w/o RKD：** 移除来自情感空间的知识蒸馏模块。
7. **w/o RKD, +LR：** 以带非线性激活的线性回归器替换 RKD，预测目标情感维度，从而约束 $\mathbf{z}$ 并纳入情感维度。

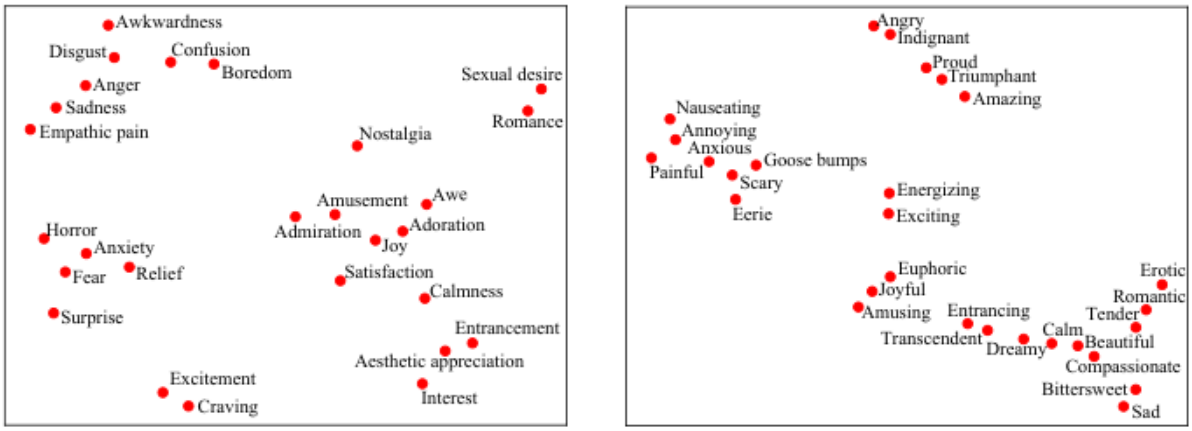
表 5. 各组件的贡献，准确性能由 mAP 衡量。ESL：情绪语义学习；LD：标签消歧；RKD：基于关系的知识蒸馏；Avg. Acc/Last Acc：平均/最终准确性能；Δ：相对于完整 AESL 的变化。+SE、+LE、+AD 在 w/o ESL&LD 上添加，+LR 在 w/o RKD 上添加。

Table 5. The contribution of each component. Accuracy of these models is measured by mAP.

Model	ESL	LD	RKD	Avg. Acc	Δ	Last Acc	Δ
w/o ESL&LD				47.6	-1.4	41.3	-1.4
+SE			✓	45.3	-3.7	40.9	-1.8
+LE				46.8	-2.2	41.9	-0.8
+AD				48.4	-0.6	42.3	-0.4
w/o LD	✓		✓	48.1	-0.9	42.0	-0.7
w/o RKD	✓	✓		48.3	-0.7	42.1	-0.6
+LR				47.0	-2.0	41.8	-0.9
AESL	✓	✓	✓	**49.0**	0.0	**42.7**	0.0

值得注意但并不意外的是，即使借助先进大语言模型提取句子嵌入，将其作为情绪类别标签使用，仍无法达到语义引导特征解耦的性能。这种性能下降说明，AESL 的有效性不仅依赖嵌入质量，还依赖语义引导解耦提供的显式结构对齐。结果表明，AESL 的三个组件对于防止遗忘并提升 MLCIL 模型性能都至关重要。

情绪语义可视化。 情绪语义学习是本文方法的重要模块。图 6 使用 t-SNE（Van der Maaten & Hinton, 2008）对情绪语义学习模块获得的情绪嵌入进行可视化。可以清楚看到，学习到的嵌入保持了有意义的情绪语义拓扑。具体来说，在 Brain27 中，正性情绪主要分布在右下方，负性情绪则分布在左上方。在 Audio28 中，苦乐参半（Bittersweet）恰位于悲伤（Sad）与其他正性情绪之间。这进一步说明了建模标签依赖关系的必要性。



(a) *Brain27* (b) *Audio28*

图 6. AESL 学习到的情绪嵌入的 t-SNE 可视化。（a）Brain27；（b）Audio28。图中全部情绪名称及其中文释义见附录表 6。

增强 ERG 可视化。 图 7(a) 展示 Audio28 数据集上的增强 ERG。我们使用所有任务真值标签统计构建的理想 ERG（oracle ERG）作为上界，并计算皮尔逊相关系数（PCC），衡量增强 ERG 与理想 ERG 的相似性。所提出的方法能够良好重建任务内及任务间的标签关系。此外，引入来自情感维度空间的 RKD 后，增强 ERG 更接近理想 ERG（$r = 0.86$，相比之下未使用 RKD 时 $r = 0.75$）。

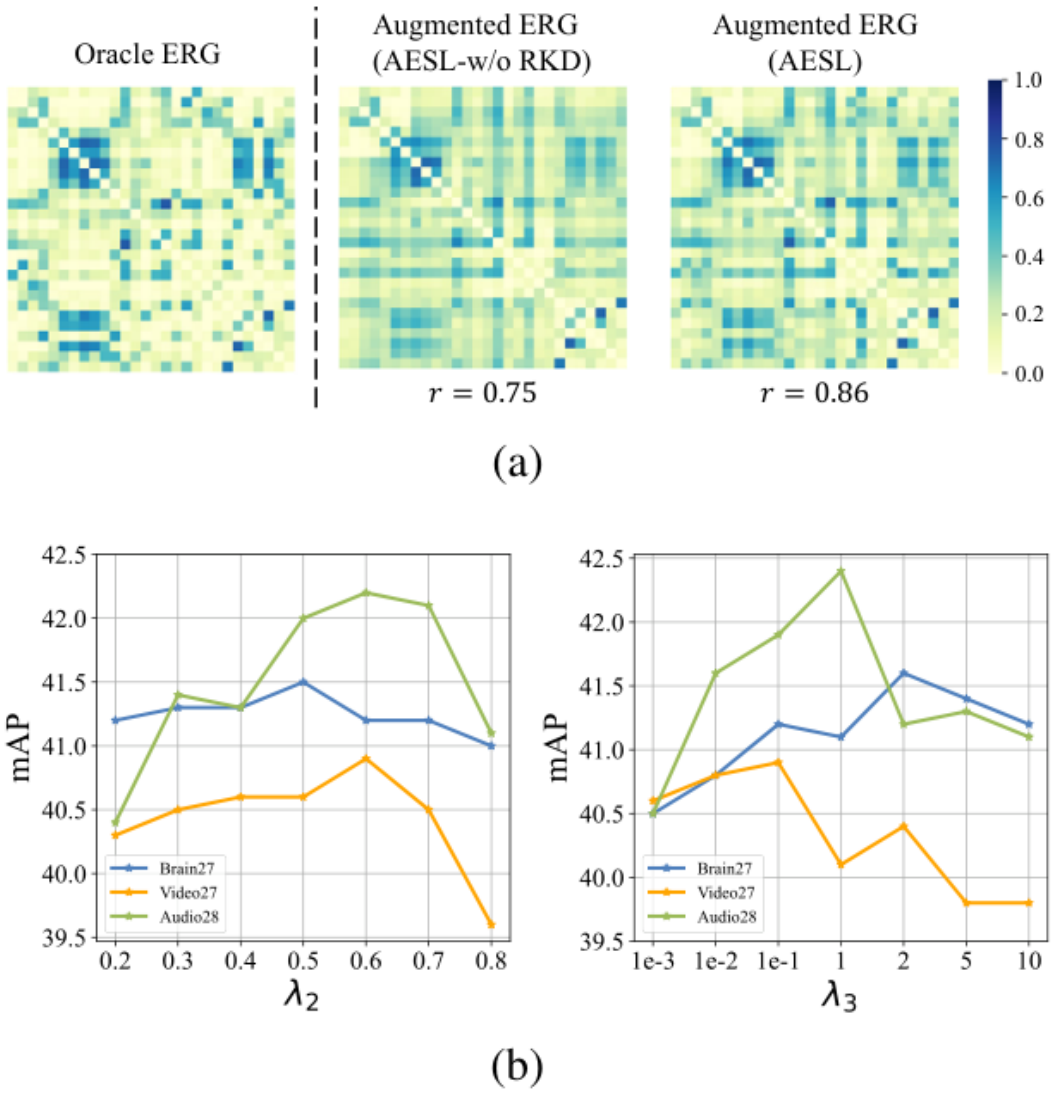


图 7. （a）Audio28 数据集中的增强情绪关系图可视化。Oracle ERG：理想 ERG；Augmented ERG (AESL-w/o RKD)：不使用 RKD 的 AESL 增强 ERG；Augmented ERG (AESL)：完整 AESL 的增强 ERG。（b）随着 λ_2 和 λ_3 变化，以最终 mAP 衡量的 AESL 性能变化。

参数敏感性。 图 7(b) 以三个数据集的 B0-I9 和 B0-I7 协议为例，展示 AESL 性能随正则化参数 λ_2 和 λ_3 的变化，λ_1 固定为 1。当一个参数变化时，另一个固定为合理值。我们发现，由于情感评分存在噪声，过大的 λ_2 会显著降低模型性能；过小则无法起到缓解未来缺失部分标签问题的作用。对于 λ_3，取值过大使模型过分关注图重建，取值过小则无法良好学习标签嵌入，两者都会导致性能下降。

5. 结论

本文提出用于多标签类别增量情绪解码的新型 AESL 框架。具体而言，我们开发带有标签消歧的增强 ERG 生成方法，以处理过去缺失部分标签问题；随后引入来自情感维度空间的知识蒸馏，缓解未来缺失部分标签问题。此外，构建情绪语义学习模块，为后续语义特定特征提取学习不可或缺的标签嵌入。大量实验证明了 AESL 的有效性。

致谢

本研究部分得到国家重点研发计划 2022ZD0116500、国家自然科学基金项目 62206284、北京市自然科学基金项目 L243016，以及北京市科技新星计划项目 20230484460 的支持。

影响声明

本研究的动机在于情感计算在人机交互塑造过程中日益重要的作用。用于情绪识别和合成的深度学习进步具有重要社会影响：改进的情绪感知系统可以增强心理健康支持（例如人工智能辅助治疗）、教育（例如自适应学习系统）以及人机协作（例如具有同理心的聊天机器人）。

然而，该技术具有固有的双重用途风险。我们的模型可能帮助在临床场景中检测痛苦信号，但同样技术也可能被用于不道德的监视或操纵，例如未经同意的情绪画像。情绪模型准确性的局限还引发文化偏差和误解细微情绪状态的担忧，可能在敏感应用中造成有害决策。

我们认为，在严格伦理保障的配合下，负责任的情感计算，尤其是医疗保健与无障碍领域的应用，其收益大于风险。本研究强调，应透明披露模型局限，建立用户同意规程和领域特定的部署指南，以减少滥用。

参考文献

以下保留原文作者、英文题名、出版信息及年份，以便检索；方括号内为题名中文译文。复合词连字符保留，原文可能存在的书目错误不擅自更正。

1. Chen, Z.-M., Wei, X.-S., Wang, P., and Guo, Y. Multi-label image recognition with graph convolutional networks.［利用图卷积网络进行多标签图像识别。］In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 5177-5186, 2019.
2. Chen, Z.-S., Wu, X., Chen, Q.-G., Hu, Y., and Zhang, M.-L. Multi-view partial multi-label learning with graph-based disambiguation.［基于图消歧的多视图部分多标签学习。］In Proceedings of the AAAI Conference on artificial intelligence, volume 34, pp. 3553-3560, 2020.
3. Churamani, N. and Gunes, H. Clifer: Continual learning with imagination for facial expression recognition.［CLIFER：借助想象进行面部表情识别的持续学习。］In 2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020), pp. 322-328. IEEE, 2020.
4. Cowen, A. S. and Keltner, D. Self-report captures 27 distinct categories of emotion bridged by continuous gradients.［自我报告捕捉到由连续梯度连接的 27 种不同情绪类别。］Proceedings of the national academy of sciences, 114(38):E7900-E7909, 2017.
5. Cowen, A. S., Fang, X., Sauter, D., and Keltner, D. What music makes us feel: At least 13 dimensions organize subjective experiences associated with music across different cultures.［音乐让我们有何感受：至少 13 个维度组织了跨文化的音乐相关主观体验。］Proceedings of the National Academy of Sciences, 117(4):1924-1934, 2020.

6. De Lange, M., Aljundi, R., Masana, M., Parisot, S., Jia, X., Leonardis, A., Slabaugh, G., and Tuytelaars, T. A continual learning survey: Defying forgetting in classification tasks.［持续学习综述：对抗分类任务中的遗忘。］IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(7):3366-3385, 2021.
7. Demšar, J. Statistical comparisons of classifiers over multiple data sets.［在多个数据集上对分类器进行统计比较。］The Journal of Machine Learning Research, 7:1-30, 2006.
8. Dong, S., Luo, H., He, Y., Wei, X., Cheng, J., and Gong, Y. Knowledge restore and transfer for multi-label class-incremental learning.［多标签类别增量学习的知识恢复与迁移。］In Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 18711-18720, 2023.
9. Du, K., Lyu, F., Hu, F., Li, L., Feng, W., Xu, F., and Fu, Q. Agcn: augmented graph convolutional network for lifelong multi-label image recognition.［AGCN：用于终身多标签图像识别的增强图卷积网络。］In 2022 IEEE International Conference on Multimedia and Expo (ICME), pp. 01-06. IEEE, 2022.
10. Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Yang, A., Fan, A., et al. The llama 3 herd of models.［Llama 3 模型群。］arXiv preprint arXiv:2407.21783, 2024.
11. Eugenides, J. Middlesex.［《中性》。］Anagrama, 2003.
12. Fu, K., Du, C., Wang, S., and He, H. Multi-view multi-label fine-grained emotion decoding from human brain activity.［从人脑活动中进行多视图多标签细粒度情绪解码。］IEEE Transactions on Neural Networks and Learning Systems, 2022.
13. Glasser, M. F., Coalson, T. S., Robinson, E. C., Hacker, C. D., Harwell, J., Yacoub, E., Ugurbil, K., Andersson, J., Beckmann, C. F., Jenkinson, M., et al. A multi-modal parcellation of human cerebral cortex.［人类大脑皮层的多模态分区。］Nature, 536(7615):171-178, 2016.
14. He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition.［用于图像识别的深度残差学习。］In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778, 2016.
15. Horikawa, T., Cowen, A. S., Keltner, D., and Kamitani, Y. The neural representation of visually evoked emotion is high-dimensional, categorical, and distributed across transmodal brain regions.［视觉诱发情绪的神经表征具有高维性、类别性，并分布于跨模态脑区。］Iscience, 23(5):101060, 2020.
16. Jiménez-Guarneros, Magdiel, Alejo-Eleuterio, and Roberto. A class-incremental learning method based on preserving the learned feature space for eeg-based emotion recognition.［一种保留已学习特征空间的类别增量学习方法，用于基于 EEG 的情绪识别。］Mathematics, 10(4):598, 2022.
17. Kim, C. D., Jeong, J., and Kim, G. Imbalanced continual learning with partitioning reservoir sampling.［利用分区蓄水池采样进行不平衡持续学习。］In Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XIII 16, pp. 411-428. Springer, 2020.

18. Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., et al. Overcoming catastrophic forgetting in neural networks.［克服神经网络中的灾难性遗忘。］Proceedings of the national academy of sciences, 114(13):3521-3526, 2017.
19. Kriegeskorte, N., Mur, M., and Bandettini, P. A. Representational similarity analysis-connecting the branches of systems neuroscience.［表征相似性分析：连接系统神经科学的各分支。］Frontiers in systems neuroscience, pp. 4, 2008.
20. Le, N., Nguyen, K., Tran, Q., Tjiputra, E., Le, B., and Nguyen, A. Uncertainty-aware label distribution learning for facial expression recognition.［用于面部表情识别的不确定性感知标签分布学习。］In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, pp. 6088-6097, 2023.
21. Lee, K., Lee, K., Shin, J., and Lee, H. Overcoming catastrophic forgetting with unlabeled data in the wild.［利用自然环境中的无标签数据克服灾难性遗忘。］In Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 312-321, 2019.
22. Li, S. and Deng, W. Deep facial expression recognition: A survey.［深度面部表情识别综述。］IEEE transactions on affective computing, 13(3):1195-1215, 2020.
23. Li, Z. and Hoiem, D. Learning without forgetting.［无遗忘学习。］IEEE transactions on pattern analysis and machine intelligence, 40(12):2935-2947, 2017.
24. Liang, Y.-S. and Li, W.-J. Optimizing class distribution in memory for multi-label online continual learning.［优化记忆中的类别分布以进行多标签在线持续学习。］arXiv preprint arXiv:2209.11469, 2022.
25. Liu, Y., Feng, W., Sun, J., and Zhang, X. Incremental multi-label learning with dual knowledge distillation.［采用双重知识蒸馏的增量多标签学习。］IEEE Transactions on Neural Networks and Learning Systems, 34(5):2132-2146, 2022.
26. Ma, T.-F., Zheng, W.-L., and Lu, B.-L. Few-shot class-incremental learning for eeg-based emotion recognition.［基于 EEG 的情绪识别中的少样本类别增量学习。］In International Conference on Neural Information Processing, pp. 445-455. Springer, 2022.
27. Masana, M., Liu, X., Twardowski, B., Menta, M., Bagdanov, A. D., and van de Weijer, J. Class-incremental learning: survey and performance evaluation.［类别增量学习：综述与性能评估。］In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, pp. 652-653, 2020.
28. Poria, S., Cambria, E., Bajpai, R., and Hussain, A. A review of affective computing: From unimodal analysis to multimodal fusion.［情感计算综述：从单模态分析到多模态融合。］Information fusion, 37:98-125, 2017.
29. Rebuffi, S.-A., Kolesnikov, A., Sperl, G., and Lampert, C. H. icarl: Incremental classifier and representation learning.［iCaRL：增量分类器与表征学习。］In Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, pp. 2001-2010, 2017.
30. Rolnick, D., Ahuja, A., Schwarz, J., Lillicrap, T., and Wayne, G. Experience replay for continual learning.［用于持续学习的经验回放。］Advances in Neural Information Processing Systems, 32, 2019.

31. Russell, J. A. and Mehrabian, A. Evidence for a three-factor theory of emotions.［情绪三因素理论的证据。］Journal of research in Personality, 11(3):273-294, 1977.
32. Schlosberg, H. Three dimensions of emotion.［情绪的三个维度。］Psychological review, 61(2):81, 1954.
33. Serra, J., Suris, D., Miron, M., and Karatzoglou, A. Overcoming catastrophic forgetting with hard attention to the task.［利用对任务的硬注意力克服灾难性遗忘。］International Conference on Machine Learning, pp. 4548-4557, 2018.
34. Simonyan, K. and Zisserman, A. Very deep convolutional networks for large-scale image recognition.［用于大规模图像识别的超深卷积网络。］arXiv preprint arXiv:1409.1556, 2014.
35. Van der Maaten, L. and Hinton, G. Visualizing data using t-sne.［利用 t-SNE 可视化数据。］Journal of machine learning research, 9(11), 2008.
36. Vitter, J. S. Random sampling with a reservoir.［利用蓄水池进行随机采样。］ACM Transactions on Mathematical Software (TOMS), 11(1):37-57, 1985.
37. Wang, H., Zhang, L., Li, X., and Zhao, G. Adaptive emotion recognition through progressive knowledge distillation.［通过渐进知识蒸馏实现自适应情绪识别。］IEEE Transactions on Affective Computing, 14(2):1012-1024, 2023.
38. Xu, K., Hu, W., Leskovec, J., and Jegelka, S. How powerful are graph neural networks?［图神经网络有多强大？］In Proceedings of the 7th International Conference on Learning Representations, 2019.
39. Yan, S., Xie, J., and He, X. Dynamically expandable representation for class incremental learning.［用于类别增量学习的动态可扩展表征。］In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 3014-3023, 2021.
40. Zhang, K., Liu, F., Liu, M., and Yang, J. Meta-learning for adaptive emotion recognition in dynamic environments.［动态环境中自适应情绪识别的元学习。］In Proceedings of the 30th ACM International Conference on Multimedia, pp. 2167-2175, 2022.
41. Zhang, M.-L. and Zhou, Z.-H. A review on multi-label learning algorithms.［多标签学习算法综述。］IEEE transactions on knowledge and data engineering, 26(8):1819-1837, 2013.
42. Zhang, Z., Wang, H., Luo, X., and Li, Q. Prototype-based multi-label class incremental learning.［基于原型的多标签类别增量学习。］In 2021 IEEE International Conference on Image Processing (ICIP), pp. 2903-2907, 2021.

附录 A. AESL 算法

算法 1. AESL 训练流程。

输入： 训练序列 $\{\mathcal{D}^1, \ldots, \mathcal{D}^B\}$；超参数 $\sigma, \beta, \lambda_1, \lambda_2, \lambda_3$；情感维度特征 $\{\boldsymbol{\tau}^1, \ldots, \boldsymbol{\tau}^B\}$。

1. 对 $b = 1 : B$，执行：
2. 当尚未收敛时，执行：

3. 对每个 $\left(\mathbf{x}^b,\ \mathbf{y}^b\right) \sim \mathcal{D}^b$，执行：
4. 若 $b = 1$：用标签矩阵 $\mathbf{Y}^b$，根据式（1）直接计算 $\mathbf{A}^b$。
5. 否则：
    - 用 $\mathbf{s} = \psi\left(\mathbf{x}^b,\ \mathbf{A}^{b-1};\ \Phi^{b-1}\right)$ 计算软标签矩阵 $\mathbf{S}$，并设置初始标签置信矩阵 $\mathbf{F}^0 = \mathbf{S}$。
    - 计算归一化权重矩阵 $\widehat{\mathbf{P}} = \mathbf{P}\mathbf{D}^{-1}$。$\mathbf{P}_{ij}$ 为 $\mathcal{D}^b$ 中两个实例的相似度。
    - 根据式（3）进行标签传播，得到细化软标签矩阵 $\widehat{\mathbf{S}}$。
    - 根据式（1），直接用标签矩阵 $\mathbf{Y}^b$ 计算 $\mathbf{B}^b$。
    - 根据式（4）和（5），使用 $\widehat{\mathbf{S}}$ 和 $\mathbf{Y}^b$ 计算 $\mathbf{R}^b$ 与 $\mathbf{Q}^b$，然后得到 $\mathbf{A}^b = \begin{bmatrix} \mathbf{A}^{b-1} & \mathbf{R}^b \\ \mathbf{Q}^b & \mathbf{B}^b \end{bmatrix}$。
    - 至此获得第 3.3 节的增强 ERG。
6. 结束条件分支。
7. 使用初始节点特征 $\mathbf{H}_0^b$ 和邻接矩阵 $\mathbf{A}^b$ 构建（增强）ERG $\mathcal{G}^b$。
8. 根据式（6）执行消息传递策略，获得标签语义嵌入 $\mathbf{E}^b$。这实现第 3.4 节的标签语义学习。
9. 使用全连接网络后接 sigmoid 函数，计算重要性向量 $\boldsymbol{\alpha}$。
10. 根据式（8），使用深层潜在特征 $\mathbf{z}$ 与重要性向量 $\boldsymbol{\alpha}$ 计算语义特定特征 $\mathbf{o}$。
11. 根据式（9）计算标签置信分数 $\mathbf{s}$，获得情绪类别 $1, \ldots, \mathcal{C}^b$ 的预测（原算法此处没有基数符号）。这实现第 3.5 节的语义引导特征解耦，得到语义特定特征。
12. 根据式（10）和（11）计算表征相似性矩阵 $\mathbf{M}^b$、$\mathbf{M}^{b-1}$ 和 $\mathbf{M}^{aff}$。这实现第 3.6 节基于情感维度特征的关系知识蒸馏。
13. 使用式（7）、（12）和（13）计算最终损失 $\mathcal{L}$，通过最小化 $\mathcal{L}$ 更新 AESL 模型。
14. 结束样本循环、收敛循环及任务循环。

译注：第 13 步忠实保留原算法的公式引用；正文完整目标函数为式（15），其中还包括式（14）的分类损失。原文没有另附定理或证明。

附录 B. 实验细节

B.1. 数据集细节

Brain27 是视觉诱发情绪脑活动数据集（Horikawa et al., 2020），包含 5 名受试者的血氧水平依赖（BOLD）响应。受试者观看 2196 段视频，同时记录功能磁共振成像（fMRI）数据。数据由 3T Siemens 扫描仪通过多带梯度回波平面成像（EPI）序列采集：TR 为 2000 ms，TE 为 43 ms，翻转角为 80 度，视野为 192×192 mm，体素大小为 $2\times2\times2$ mm，切片数为 76，多带因子为 4。fMRI 数据经过预处理，并对每个视频刺激取平均，因此对一个视频刺激而言，一个体素的脑活动为一个标量。

Video27 是情绪诱发视觉数据集（Cowen & Keltner, 2017），也用于采集 Brain27 的脑活动。它包含 2196 段视频，时长从 0.15 秒到 90 秒不等。图 1 展示了其中部分视频截图。

Audio28 是情绪诱发听觉数据集（Cowen et al., 2020），包含 1841 个无歌词音乐样本。其中 1572 段选自 YouTube，88 段来自 Howard Shore 的《指环王》配乐，181 段来自 Wagner 的《尼伯龙根的指环》组曲。这些音乐片段能够传达强烈感受，时长从 0.73 秒到 7.89 秒不等。

对于情绪类别与情感维度评分，Brain27 和 Video27 的每个实例均由多位评分者针对 27 种情绪类别与 14 个情感维度投票；Audio28 的每段音乐由多位评分者针对 28 种情绪类别和 11 个情感维度评价。情绪类别评分范围为 0 到 1。为构建情绪标签矩阵，Brain27 和 Video27 使用阈值 0.1，Audio28 使用阈值 0.15。前两个数据集与 Audio28 的平均情绪标签数分别为 4.64 和 5.27。情感维度使用九级 Likert 量表评分，并在实验的 RKD 之前进行标准化。

增量学习划分情绪标签时，只按照字母顺序，不施加其他干预。Brain27 和 Video27 的顺序为 Admiration、Adoration、Aesthetic appreciation、Amusement、Anger、Anxiety、Awe、Awkwardness、Boredom、Calmness、Confusion、Craving、Disgust、Empathic pain、Entrancement、Excitement、Fear、Horror、Interest、Joy、Nostalgia、Relief、Romance、Sadness、Satisfaction、Sexual desire、Surprise。Audio28 的顺序为 Amusing、Angry、Annoying、Anxious、Amazing、Beautiful、Bittersweet、Calm、Compassionate、Dreamy、Eerie、Energizing、Entrancing、Erotic、Euphoric、Exciting、Goose bumps、Indignant、Joyful、Nauseating、Painful、Proud、Romantic、Sad、Scary、Tender、Transcendent、Triumphant。27 种和 28 种情绪类别的定义详见表 6。（译注：Audio28 所列顺序中 Amazing 在 Anxious 之后，与严格字母序并不一致；原文列举顺序照录。）

Brain27 和 Video27 使用的情感维度为 Approach（趋近）、Arousal（唤醒度）、Attention（注意）、Certainty（确定性）、Commitment（投入）、Control（控制）、Dominance（支配性）、Effort（努力）、Fairness（公平）、Identity（身份认同）、Obstruction（阻碍）、Safety（安全）、Upswing（向好趋势）和 Valence（效价）。Audio28 使用的维度为 Arousal（唤醒度）、Attention（注意）、Certainty（确定性）、Commitment（投入）、Dominance（支配性）、Enjoyment（享受）、Familiarity（熟悉度）、Identity（身份认同）、Obstruction（阻碍）、Safety（安全）和 Valence（效价）。

表 7 展示实验中三个数据集的特性。统计量包括训练实例数 $|\mathcal{D}_{tr}|$、测试实例数 $|\mathcal{D}_{te}|$、特征数量 $Dim(\mathcal{D})$、构建标签矩阵的阈值 $Th(\mathcal{D})$、可能类别标签数 $L(\mathcal{D})$、情感维度数 $Aff(\mathcal{D})$、标签基数（每个实例平均标签数） $LCard(\mathcal{D})$、标签密度（标签基数除以 $L(\mathcal{D})$） $LDen(\mathcal{D})$ 及模态。对于 Brain27，还展示实验中 ROI 池化前的体素数量 $V(\mathcal{D})$。

B.2. 对比方法

各对比方法的细节如下。

EWC（Kirkpatrick et al., 2017）： 一种单标签类别增量学习算法，通过约束重要参数减少灾难性遗忘，使用 Fisher 信息矩阵计算参数重要性。

LWF（Lee et al., 2019）： 首个将知识蒸馏用于单标签类别增量学习任务的算法。以旧模型作为教师，最小化新旧模型输出概率分布间的 KL 散度。

ER（Lee et al., 2019）： 基于数据回放的单标签类别增量学习算法，采用随机采样策略构建数据缓冲区。

RS（Vitter, 1985）： 基于数据回放的单标签类别增量学习算法，采用蓄水池采样策略构建数据缓冲区。

AGCN（Vitter, 1985）： 基于图卷积神经网络的多标签类别增量学习算法，图邻接矩阵随任务推进不断扩展。

PRS（Kim et al., 2020）： 基于数据回放的多标签类别增量学习算法，改进蓄水池采样策略，使数据缓冲区中各类别样本数尽可能均衡。

OCDM（Liang & Li, 2022）： 基于数据回放的多标签类别增量学习算法，将数据缓冲区的构建与更新定义为待求解的优化问题。

KRT-R（Dong et al., 2023）： 基于知识恢复与迁移（KRT）框架的多标签类别增量学习算法。

译注：此处 ER 和 AGCN 的引用依原文保留，与正文相应的 Rolnick et al.（2019）和 Du et al.（2022）不一致；未据此改变方法内容。

B.3. 特征提取

在 Brain27 上，通过 ROI 池化（见图 8）提取 2880 维特征向量。在 Video27 上，使用预训练 VGG19 模型（Simonyan & Zisserman, 2014）提取单帧视觉物体特征，并在所有帧上取平均，构造 1000 维特征。在 Audio28 上，对每个音频片段计算梅尔频率倒谱系数（MFCC）；随后将同一音频的全部 MFCC 片段输入预训练 ResNet-18 模型（He et al., 2016），对全部片段取平均，得到 512 维特征。

表 6. Brain27、Video28 与 Audio28 的情绪类别定义。（译注：原表标题写 Video28，正文数据集名称为 Video27。）为保证可读性，原表的两组定义分别排为下列两个中文表。

27 种情绪类别

名称（原文与中文）	定义
Admiration 敬佩	对某人的品质或成就产生深深尊重与欣赏的感受。
Adoration 喜爱	对珍爱的人或事物产生深切的爱、奉献或崇敬感。
Aesthetic appreciation 审美欣赏	遇到美或卓越艺术时产生的愉悦与赞赏。
Amusement 逗乐	对滑稽或有趣事物产生的轻松而愉快的反应。
Anger 愤怒	对感知到的伤害、不公或挫折产生的强烈情绪反应。
Anxiety 焦虑	紧张、不安的感受，通常与对不确定结果的恐惧或担忧有关。
Awe 敬畏	对广阔、宏大或超出日常理解之事产生的深刻情绪反应。
Awkwardness 尴尬	在社交笨拙或不确定的情境中产生的不适或难堪感。
Boredom 无聊	因缺少兴趣或投入而产生的厌倦或不满状态。

名称（原文与中文）	定义
Calmness 平静	不受压力或躁动影响的宁静、平和心境。
Confusion 困惑	面对不清楚或出乎预料的事物时产生的迷惑或不确定感。
Craving 渴望	对某种特定事物的强烈欲望或向往，通常指食物或体验。
Disgust 厌恶	强烈的反感或嫌恶，通常由冒犯或令人不快的事物引起。
Empathic pain 共情痛苦	对他人痛苦产生情绪共鸣，进而共同感受到苦楚。
Entrancement 入迷	令人着迷、仿佛被催眠的感受，使人进入深度沉浸的体验。
Excitement 兴奋	对令人振奋或愉快之事产生高度期待或热情的状态。
Fear 恐惧	对感知到的危险或威胁产生的强烈情绪，促发战斗或逃跑反应。
Horror 惊恐	混合震惊或嫌恶的强烈恐惧，通常由可怕或骇人的事物引起。
Interest 兴趣	被吸引人或发人深省的事物激发的好奇与注意。
Joy 喜悦	深刻而振奋人心的幸福或欣喜感。
Nostalgia 怀旧	对过去体验苦乐交织的怀念，常伴随美好回忆。
Relief 释然	压力、痛苦或担忧缓解后产生的轻松与舒缓感。
Romance 浪漫情意	与爱情和亲密联系相关的温柔、深情的情绪。
Sadness 悲伤	沉重而哀伤的感受，通常与失去、失望或共情有关。
Satisfaction 满足	达成目标或愿望后的知足与充实感。
Sexual desire 性欲	身体和情感上对亲密及联结的深切渴望。
Surprise 惊讶	由意外事件或突然领悟引发的突然而出乎意料的情绪。

28 种情绪类别

名称（原文与中文）	定义
Amusing 逗乐的	带来轻松、有趣的感受，常引发微笑和欢笑。
Angry 愤怒的	通常由挫折或不公引发的强烈情绪，带来强烈不悦感。
Annoying 烦恼的	由持续令人困扰或不便之事引发的轻度恼怒或挫败。
Anxious 焦虑的	对不确定结果或未来事件产生的担忧、紧张或不安感。
Amazing 惊叹的	常由非凡或卓越之事引起的惊奇与赞赏。
Beautiful 美好的	与欣赏视觉、听觉或概念上的和谐与吸引力相关的情绪。
Bittersweet 苦乐参半	快乐与悲伤混合的情绪，通常来自怀旧或珍贵回忆。
Calm 平静的	舒缓、平和、宁静且不受扰动的感受。
Compassionate 悲悯的	温暖而富有共情的反应，深切关心他人的痛苦。

名称（原文与中文）	定义
Dreamy 梦幻的	放松而充满幻想的感受，常与逃离现实或幻想感有关。
Eerie 诡异的	带有不安的神秘感，常由奇异或不可思议之事引起。
Energizing 振奋的	动力与活力涌现，使人感到警觉并准备行动。
Entrancing 令人入迷的	引人着迷、使人沉浸的情绪，吸引全部注意力。
Erotic 色情欲感的	深度亲密而感官化的感受，以身体和情感欲望为特征。
Euphoric 欣快的	强烈、令人振奋的喜悦，几乎带有超越性或不真实感。
Exciting 令人兴奋的	对即将发生或正在展开的事物产生生动的期待与热情。
Goose bumps 起鸡皮疙瘩	对强烈情绪的身体反应，常与敬畏、恐惧或敬佩有关。
Indignant 愤慨的	正义的愤怒或怨愤，通常由感知到的不公平待遇引起。
Joyful 喜悦的	纯粹、轻松的快乐，使心情振奋而明朗。
Nauseating 恶心的	强烈的身体不适感，常伴有厌恶或反感。
Painful 痛苦的	由身体或情感上的痛楚引起的强烈且常令人难受的感受。
Proud 自豪的	积极的满足与成就感，常来自对成就的认可。
Romantic 浪漫的	以爱和联结为中心的温柔、深情感受。
Sad 悲伤的	沉重而哀伤的感受，常由失去、失望或共情引起。
Scary 害怕的	感知到威胁或危险后产生的强烈而令人不安的恐惧感。
Tender 温柔的	轻柔、暖心的爱意与关怀。
Transcendent 超越的	超出日常体验的情绪，常带来敬畏或领悟感。
Triumphant 胜利的	克服挑战或取得成功后的胜利和庆祝情绪。

表 7. 实验数据集的特征。Dataset：数据集；Subject：受试者；Modality：模态；Video：视频；Audio：音频。各数学列的完整中文说明见 B.1 节。原表 Video27 的 Aff 列为 11，而 B.1 段落称其使用 14 个情感维度；此处照录原表，不自行统一。

Table 7. The characteristics of the experimental datasets.

Dataset	$\lvert\mathcal{D}_{tr}\rvert$	$\lvert\mathcal{D}_{te}\rvert$	$V(\mathcal{D})$	$Dim(\mathcal{D})$	$Th(\mathcal{D})$	$L(\mathcal{D})$	$Aff(\mathcal{D})$	$LCard(\mathcal{D})$	$LDen(\mathcal{D})$	Modality
Brain27(Subject1)	1800	396	120930	2880	0.10	27	14	4.64	0.17	fMRI
Brain27(Subject2)	1800	396	116260	2880	0.10	27	14	4.64	0.17	fMRI
Brain27(Subject3)	1800	396	102941	2880	0.10	27	14	4.64	0.17	fMRI
Brain27(Subject4)	1800	396	118533	2880	0.10	27	14	4.64	0.17	fMRI
Brain27(Subject5)	1800	396	116699	2880	0.10	27	14	4.64	0.17	fMRI
Video27	1800	396	-	1000	0.10	27	11	4.64	0.17	Video
Audio28	1500	341	-	512	0.15	28	11	5.27	0.19	Audio

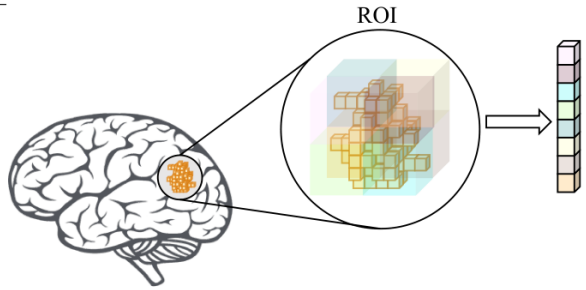


图 8. ROI 池化示意图。每个橙色小立方体表示一个体素。直接使用脑体素信号进行逐体素解码，会引入大量噪声并容易导致过拟合。因此，首先利用 HCP360 模板（Glasser et al., 2016）将全脑划分为多个脑区（ROI），其中包含由 Human Connectome Project 提供的分区方案定义的 360 个皮层区域。为进一步提取各 ROI 的特征，按照坐标将每个 ROI 的体素放入三维体积中，然后把该体积均匀分为 8 个子体积，计算每个子体积内体素的平均脑活动作为该子体积的特征，如图所示。换言之，每个 ROI 得到 8 维特征。最后连接每个半球 360 个 ROI 的特征，得到 2880 维特征。（译注：“每个半球 360 个 ROI”与前述全脑 360 区及 2880 维的关系存在表述歧义，原文措辞保留。）

B.4. 超参数设置

实验中，式（3）的平衡参数 β 设为 0.95，式（15）的 λ_1 设为 1。λ_2 在 $\{0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8\}$ 中搜索，λ_3 在 $\{0.001, 0.01, 0.1, 1, 2, 5, 10\}$ 中搜索。三个数据集的深层潜在表征 $\mathbf{z}$ 维数均设为 64。采用 Adam 优化器训练模型，$\{\beta_1, \beta_2\} = \{0.9, 0.9999\}$。Brain27 和 Video27 的权重衰减设为 0.005、学习率设为 10^{-4}；Audio28 的权重衰减设为 0、学习率设为 10^{-3}。全部实验在一块 NVIDIA TITAN GPU 上开展。

附录 C. 更多对比结果

表 8、9、10 和 11 展示 Brain27 数据集受试者 2、3、4 和 5 的结果。图 9 展示 AESL 与对比方法在这些受试者上的比较曲线。可以观察到与第 4.2 节类似的结论。

表 8. Brain27 数据集受试者 2 的类别增量结果。对比方法中的 AGCN、PRS 和 OCDM 为 MLCIL 算法。全部列及符号与表 1 相同。

Table 8. Class incremental results on subject 2 of *Brain27* dataset. AGCN, PRS and OCDM are MLCIL algorithms among these compared methods.

Method	Brain27 B0-I9				Brain27 B0-I3				Brain27 B15-I3				Brain27 B15-I2			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	34.0	44.3	42.3	-	34.0	44.3	42.3	-	34.0	44.3	42.3	-	34.0	44.3	42.3
Finetune	34.9	8.2	18.5	24.8	31.0	5.0	14.0	21.0	25.8	5.1	14.4	20.0	23.4	3.7	13.3	18.7
EWC	34.3	7.8	18.1	25.2	31.2	5.0	13.7	21.7	26.4	5.0	13.8	20.1	24.1	3.7	13.3	19.4
LwF	38.9	11.4	28.6	29.6	37.0	19.4	37.0	25.9	31.8	15.7	32.5	24.4	29.4	15.4	32.6	21.9
ER	40.4	8.5	13.1	34.9	39.3	3.8	4.8	20.8	37.3	6.9	11.6	34.1	36.3	7.4	11.0	32.7
RS	41.0	7.6	10.8	35.9	40.4	3.7	5.9	28.9	36.4	6.2	10.3	31.4	35.8	4.3	7.8	31.0
AGCN	43.4	28.8	43.1	39.8	43.0	32.4	43.6	33.7	39.0	24.8	39.5	35.2	37.3	24.0	35.5	32.1
PRS	40.4	7.9	14.4	34.4	40.9	3.6	7.8	20.2	37.8	8.4	12.0	34.1	37.2	8.5	11.8	32.5
OCDM	40.0	8.4	12.9	33.4	40.5	4.5	8.1	28.2	36.1	5.9	9.2	30.9	34.7	5.1	8.6	29.4
AESL	**45.4**	**29.8**	**43.2**	**41.4**	**45.5**	**32.5**	**44.2**	**35.3**	**40.2**	**25.5**	**40.1**	**36.4**	**39.3**	**24.8**	**36.4**	**35.0**

表 9. Brain27 数据集受试者 3 的类别增量结果。AGCN、PRS 和 OCDM 为 MLCIL 算法。表头同表 1。

Table 9. Class incremental results on subject 3 of *Brain27* dataset. AGCN, PRS and OCDM are MLCIL algorithms among these compared methods.

Method	Brain27 B0-I9				Brain27 B0-I3				Brain27 B15-I3				Brain27 B15-I2			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	33.6	44.2	42.0	-	33.6	44.2	42.0	-	33.6	44.2	42.0	-	33.6	44.2	42.0
Finetune	33.0	7.7	17.3	25.8	29.4	5.0	14.0	20.5	25.0	5.3	14.0	20.0	23.2	4.1	13.8	19.2
EWC	32.4	7.7	16.7	25.3	29.6	5.2	13.8	19.8	25.5	5.3	14.0	20.0	24.0	4.0	13.6	19.6
LwF	36.4	11.7	28.7	30.3	34.7	21.7	38.3	23.5	30.3	15.4	31.5	23.6	28.2	15.6	31.8	21.3
ER	37.1	7.0	10.2	33.5	36.7	2.4	2.4	30.5	34.6	5.0	8.6	31.9	35.4	6.8	10.9	32.9
RS	38.1	6.5	9.2	35.8	37.7	2.9	5.2	29.0	34.1	5.0	7.7	30.3	33.8	3.6	6.8	30.0
AGCN	40.2	27.6	42.0	38.2	40.1	32.0	42.9	32.7	37.0	27.0	37.1	33.6	34.9	24.1	36.6	30.2
PRS	38.0	7.6	12.0	34.3	38.8	3.6	6.0	29.5	35.5	5.5	7.7	32.7	36.0	4.5	7.3	33.1
OCDM	37.9	8.4	11.7	35.0	38.0	5.4	8.2	30.1	34.4	4.0	6.0	30.3	33.2	3.1	5.3	28.5
AESL	**42.6**	**28.5**	**44.0**	**40.8**	**42.3**	**33.4**	**43.2**	**33.4**	**38.8**	**27.2**	**38.9**	**35.4**	**37.9**	**25.5**	**37.7**	**34.1**

表 10. Brain27 数据集受试者 4 的类别增量结果。AGCN、PRS 和 OCDM 为 MLCIL 算法。表头同表 1。

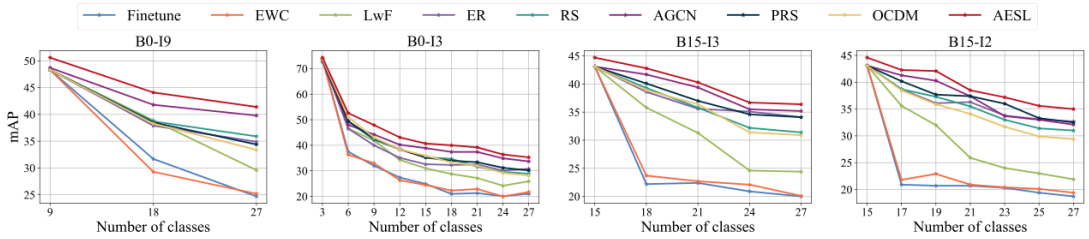
Table 10. Class incremental results on subject 4 of *Brain27* dataset. AGCN, PRS and OCDM are MLCIL algorithms among these compared methods.

Method	Brain27 B0-I9				Brain27 B0-I3				Brain27 B15-I3				Brain27 B15-I2			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	38.3	48.6	45.1	-	38.3	48.6	45.1	-	38.3	48.6	45.1	-	38.3	48.6	45.1
Finetune	36.0	7.9	19.0	25.2	30.9	4.9	13.7	21.1	26.4	4.6	13.4	20.3	23.9	3.7	13.2	18.1
EWC	35.0	7.9	18.5	25.3	31.7	5.1	13.8	22.0	27.2	4.8	13.7	20.4	25.1	3.7	13.2	20.1
LwF	39.6	15.1	33.9	30.8	37.5	20.5	37.5	23.1	33.3	17.2	32.8	25.2	30.9	15.8	33.5	22.7
ER	42.0	10.1	15.6	37.7	41.8	3.9	4.8	34.8	40.1	9.3	11.3	37.0	38.8	9.7	12.4	36.4
RS	42.6	9.0	14.2	38.1	43.5	4.3	7.1	34.4	38.8	7.5	10.8	34.6	37.8	5.4	10.6	33.2
AGCN	43.7	31.8	46.4	40.9	44.1	36.1	44.5	36.3	41.0	30.3	43.7	38.6	39.3	26.6	37.1	35.0
PRS	43.5	10.7	15.9	39.9	44.2	4.0	5.6	32.8	40.2	8.5	11.1	36.1	39.3	9.1	12.2	35.6
OCDM	43.4	11.4	15.1	39.8	43.0	4.9	7.8	31.7	38.2	6.0	5.9	33.4	38.4	5.2	9.4	33.4
AESL	**45.7**	**36.4**	**47.3**	**44.0**	**47.1**	**37.2**	**46.4**	**38.7**	**43.4**	**31.3**	**44.4**	**39.9**	**42.2**	**29.0**	**40.4**	**37.7**

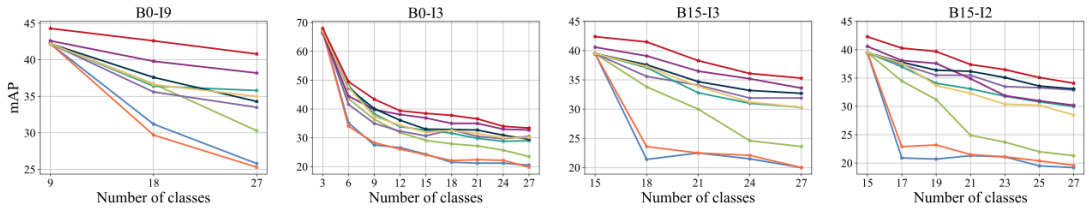
表 11. Brain27 数据集受试者 5 的类别增量结果。AGCN、PRS 和 OCDM 为 MLCIL 算法。表头同表 1。

Table 11. Class incremental results on subject 5 of *Brain27* dataset. AGCN, PRS, OCDM are MLCIL algorithm in these compared methods.

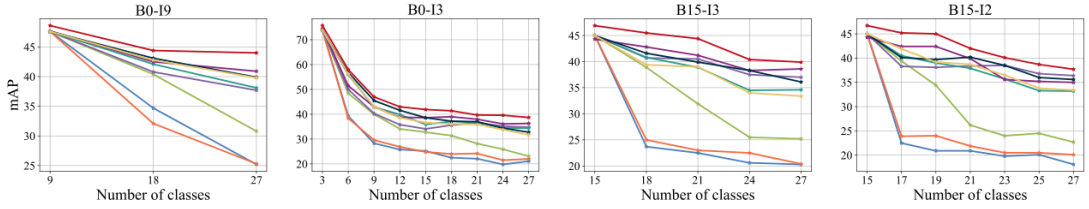
Method	Brain27 B0-I9				Brain27 B0-I3				Brain27 B15-I3				Brain27 B15-I2			
	Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc			Avg. Acc	Last Acc		
	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP	mAP	maF1	miF1	mAP
Upper-bound	-	36.6	46.8	45.0	-	36.6	46.8	45.0	-	36.6	46.8	45.0	-	36.6	46.8	45.0
Finetune	34.7	7.3	17.8	25.4	31.1	5.4	14.3	21.7	25.4	5.2	13.9	18.9	23.4	3.9	13.2	19.2
EWC	34.1	6.7	15.6	25.1	31.0	4.9	13.5	21.9	26.3	5.0	13.7	20.3	24.3	4.0	13.5	20.2
LwF	37.6	12.2	30.3	28.7	35.5	21.0	37.9	25.8	31.2	15.8	31.7	24.6	29.4	14.3	29.0	22.4
ER	40.7	8.8	13.9	35.8	41.7	4.5	7.6	34.0	38.1	6.9	8.9	36.4	36.3	6.9	9.8	32.9
RS	41.4	7.6	11.3	36.9	41.5	4.4	7.6	31.7	37.1	5.7	8.6	33.4	37.3	5.4	9.0	33.0
AGCN	43.8	29.5	44.0	41.4	42.9	32.5	42.5	34.1	38.4	28.7	41.5	35.0	37.3	24.6	37.6	33.1
PRS	41.2	8.9	16.4	37.0	42.4	5.3	8.3	32.0	37.8	6.7	9.0	34.1	38.4	6.5	9.4	34.9
OCDM	41.1	8.3	14.0	35.5	41.3	5.4	8.0	29.7	36.8	4.4	7.9	31.5	34.8	4.6	8.0	30.1
AESL	**46.0**	**32.9**	**45.8**	**44.1**	**45.5**	**35.3**	**45.6**	**35.4**	**40.4**	**29.5**	**44.5**	**37.5**	**39.9**	**29.3**	**40.8**	**36.2**



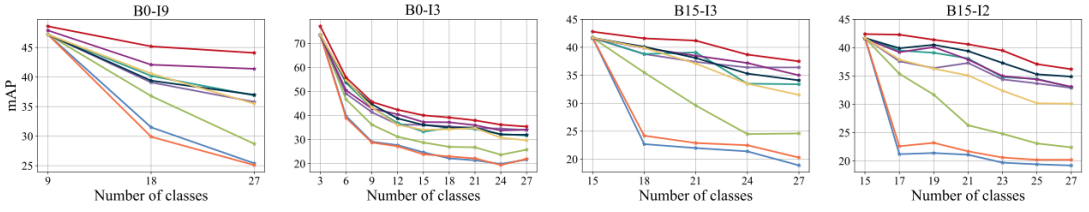
(a) *Brain27*(2)



(b) *Brain27*(3)



(c) *Brain27*(4)



(d) *Brain27*(5)

图 9. 在实验所用数据集的不同协议下，与各 CIL 方法比较的结果（mAP）。子图（a）至（d）分别为 Brain27 受试者 2、3、4、5；横轴 Number of classes 为类别数量，纵轴为 mAP。译注：原图注称“三个数据集”，但实际四行子图均为 Brain27 的不同受试者；原始图及数值全部保留。

附录 D. 局限性

在应用层面，现实场景中的情感人机交互任务不仅需要学习新情绪类别，还需要适应新受试者。因此，有必要进一步考虑来自不同受试者的情绪持续学习，这可以视为领域增量学习。在实验层面，还需进一步探索情绪类别学习顺序，以及每个任务包含的情绪类别数量对实验结果的影响。