# 面向不完整多视图多标签学习的视图-类别交互共享Transformer

**View-Category Interactive Sharing Transformer for Incomplete Multi-View Multi-Label Learning**

Shilong Ou，Zhe Xue，Yawen Li，Meiyu Liang，Yuanqiang Cai，Junjiang Wu
中国，北京邮电大学
{osl, xuezhe, meiyu1210, caiyuanqiang, wujunjiang}@bupt.edu.cn；warmly0716@126.com
通讯作者。

**私人阅读用非官方中文全文译文。** 来源为用户自行上传的10页PDF，原页码27467—27476。本文仅对已提供文档进行翻译，不包含未提供的补充材料。原文的IEEE/CVF等权利声明与来源信息予以保留；未核实允许公开再分发的许可证，本译文不作公开发布。公式及图表采用源文裁图以准确保留符号、数值和编号，图表英文文字在相邻中文图注或图例对照中翻译。

**原文首页声明（译）：** 本CVPR论文是由计算机视觉基金会（Computer Vision Foundation）提供的开放访问版本。除本水印外，它与录用版本相同；会议论文集的最终出版版本可在IEEE Xplore获取。（原始声明保留于随附源文件；“开放访问”不在此被解释为公开再分发许可。）

## 摘要

多视图多标签学习是现实场景中经常遇到的问题，已受到研究者的广泛关注。然而，由于数据采集中的疏漏以及人工标注的不确定性，现实数据往往存在不完整性。遗憾的是，现有大多数多视图多标签学习方法回避了视图和标签缺失的问题。此外，它们常常忽略利用视图与标签之间互补信息的潜力，因而限制了分类能力。为解决这些挑战，我们提出面向不完整多视图多标签学习的视图-类别交互共享Transformer。在该网络中，我们引入一个双层Transformer模块来刻画视图与标签之间的相互作用。此外，为处理视图不完整性，采用一种KNN式缺失视图生成模块。最后，我们引入视图-类别一致性引导的嵌入增强模块，对齐不同视图并提升嵌入的判别能力。这些模块协同整合，有效地对不完整多视图多标签数据进行分类。大量实验验证了我们的方法优于现有最先进方法。

## 1. 引言

数据来源的不断丰富与数据采集技术的进步，使我们能够提取超越单一视角的多种类型特征。由此产生一个值得研究的问题：如何有效整合多视图特征，并从中提取有意义的特征。与此同时，单标签数据往往不足以描述现实场景的复杂性。例如，一张花的图片也可能需要“叶子”或“花园”等标签，这说明多标签能够提供更丰富的类别特征空间，并更准确地保留标签间的关系[8]。鉴于其实际意义，多视图多标签学习成为一个具有重要研究价值的领域。

在多视图学习领域，多视图多标签分类（MVMLC）是一项重大挑战。考虑到视图间的一致性和标签的复杂性，方法必须同时对齐视图，并从整合后的表示中提取多样化特征。近年来，许多研究者朝这一目标取得了进展。其中一项工作引入多视图标签嵌入模型[30]，利用Hilbert-Schmidt独立性准则[4]建立

视图特征空间与类别特征空间之间的联系。与此同时，深度神经网络也已应用于该领域。值得注意的是SIMM神经网络[3]，它利用对抗损失与标签损失识别共享特征，同时实施正则化以捕捉视图特有的细节。

虽然MVMLC吸引了大量研究关注，但通常假设所有视图与标签都是完整的。这一假设并不总与现实场景一致。例如，视频可能缺少音频或文本内容；在社交媒体网络上分享的多媒体数据可能缺乏用户提供的全面标注。这些情况导致现实数据集中普遍存在多视图特征缺失和类别信息不完整的挑战。一些方法尝试通过掩蔽或恢复缺失视图来处理这一问题[9,20,22,25]。尽管这些处理不完整多视图或多标签学习的方法取得了显著成果，但它们往往无法同时解决这两类不完整性。为处理双重不完整多视图多标签学习问题（DIMVMLC），已有若干深度对比网络被提出[10,16]。此外，基于Transformer的不完整多视图多标签学习方法[11]也已提出，表现出对多视图多标签数据集的适应性。

然而，现有大多数双重不完整多视图多标签分类方法忽略了两个关键方面。首先，一些方法虽认识到多个视图间互补信息的重要性，却常低估多视图特征与类别之间的互补性。有效促进视图与类别之间的交互，可以显著增强应对多视图特征和类别信息同时缺失的能力。其次，这些方法经常忽视多视图特征缺失的问题，不考虑补全缺失的多视图特征。这使它们容易受到视图特征不足的影响，从而限制分类性能。

为克服双重不完整多视图多标签学习中的现有挑战，我们提出视图-类别交互共享Transformer（VIST），如图1所示。VIST是一个结构先进的框架，专门用于挖掘多视图与类别的协同作用，并有效生成缺失视图。该方法的双重能力，不仅通过类别的高层语义增强多视图嵌入的有效性，而且利用这些丰富的嵌入显著提高多标签分类精度。这一改进内在地增强了方法的适应能力，尤其是在某些视图与标签缺失的场景中，保证稳健可靠的性能。VIST整合了三个关键组件：视图-类别交互共享Transformer、缺失视图生成，以及视图-类别一致性引导的嵌入增强。视图-类别交互共享Transformer是包含四个Transformer块的紧凑双层网络，促进多视图信息与类别信息的交互，挖掘其互补潜力。缺失视图生成采用KNN式方法，按照每个样本的分布补全缺失视图。视图-类别一致性引导的嵌入增强模块利用对比学习策略强化嵌入的判别能力并提高分类精度。大量实验表明VIST具有优异性能。概括而言，本文的贡献如下：

- 提出一种面向不完整多视图多标签学习的新型视图-类别交互共享Transformer。该方法通过多视图特征与类别信息之间的交互，有效利用视图和类别之间的互补信息，从而有效应对视图与标签不完整所带来的挑战。
- 提出专为不完整多视图多标签学习任务设计的缺失视图生成方法。该方法将KNN策略与多元高斯分布结合，保证对缺失视图进行统计上合理的填补，并使其与对应样本保持协调一致。
- 为增强多视图嵌入的判别能力，开发视图-类别一致性引导的嵌入增强模块。该模块采用对比学习对齐不同视图的嵌入，并利用类别信息引导嵌入学习过程，显著提升所得嵌入的有效性和多标签分类性能。

## 2. 相关工作

针对MVMLC任务，已有许多方法被提出。lrMMC[12]保证公共子空间保持低秩，使其兼容矩阵补全，同时学习组合权重以利用各视图的独特优势。矩阵分解被用于提取不同视图之间的互补数据[27]。尽管具有这些优点，这些模型难以处理存在视图或标签缺失的数据集。为此，MVL-IV[23]利用视图之间的

关系研究不完整多视图学习。iMSF是另一种不完整多视图单标签学习方法，它巧妙地将不完整多视图分类任务拆分为若干完整子任务[26]。然而，MVL-IV与iMSF存在共同不足：它们仅处理视图不完整性。相较之下，MvEL旨在提取上下文与邻域一致性，但只针对标签不完整的场景[29]。

另一方面，对于双重不完整多视图多标签学习任务，iMvWL[14]和NAIML[9]尝试同时处理视图与标签的不完整性。iMvWL将多视图特征和多标签数据对齐到共享子空间，并利用相关性矩阵增强从标签空间到嵌入子空间的投影。NAIML依赖子标签矩阵的低秩假设，巧妙利用子类别之间的相关性来处理这种双重不完整性。近年来，深度学习模型也被用于解决这一问题。DDINet[21]、DICNet[10]和LMVCAT[11]是用于DIMVMLC的深度学习模型。DDINet是第一个包含视图特定解码器网络的深度学习模型，成功保留原始视图的关键信息。DICNet是第一个在实例层面采用对比学习的DIMVMLC深度学习模型，引导模型提取深层跨视图特征。LMVCAT是基于Transformer的双重不完整多视图多标签学习框架，由两个分别针对视图和类别设计的Transformer构成，并在不完整标签上构建图，以引导编码器提取视图特定特征。

# 3. 方法

## 3.1. 问题定义

给定来自 $V$ 个视图的 $n$ 个多视图数据点，可将其表示为一组矩阵 $\{\mathbf{X}_v\}_{v=1}^{V}$，其中 $\mathbf{X}_v \in \mathbb{R}^{n\times d_v}$。这里，$d_v$ 表示第 $v$ 个视图的维数。所有样本的标签矩阵记为 $\mathbf{Y} \in \{0,\ 1\}^{n\times L}$，其中 $L$ 是类别数。$\mathbf{Y}_{i,j} = 1$ 表示第 $i$ 个样本属于类别 $j$；$\mathbf{Y}_{i,j} = 0$ 表示不属于该类别。为描述存在特征缺失的多视图数据，引入缺失视图指示矩阵 $\mathbf{W} \in \{0,\ 1\}^{n\times V}$。$\mathbf{W}_{i,j} = 1$ 表示第 $i$ 个样本的第 $j$ 个视图可用，$\mathbf{W}_{i,j} = 0$ 则表示不可用。类似地，定义缺失标签指示矩阵 $\mathbf{U} \in \{0,\ 1\}^{n\times L}$，其中 $\mathbf{U}_{i,j} = 1$ 表示第 $i$ 个样本的第 $j$ 个类别信息可用，$\mathbf{U}_{i,j} = 0$ 表示相反情况。在数据预处理阶段，视图 $\mathbf{X}_v$ 和标签 $\mathbf{Y}$ 中的所有缺失信息都赋值为0。双重不完整多视图多标签学习任务的目标，是训练能够准确预测每个样本多个类别的模型。下面各节介绍所提出VIST的详细机制。

## 3.2. 视图-类别交互共享Transformer

不同视图包含互补信息，需要通过交互才能有效利用。此外，类别信息体现数据的高层语义，能够增强多视图表示的判别能力。反过来，多视图特征能够弥补因标签不完整而导致的标签信息理解不准确。为此，我们引入视图-类别交互共享Transformer。该新型Transformer旨在增强视图与类别之间的信息交换，从而提升多视图表示的判别能力，并提高多标签分类的精度。

视图-类别交互共享Transformer包含两个关键层。第一层着重提取能够捕捉多个视图与类别间相关性的共享特征。一个必要的前置步骤是对多视图数据 $\mathbf{X}_v \in \mathbb{R}^{n\times d_v}$ 进行嵌入，以统一不同视图的特征维数。对于 $\mathbf{X}_v$ 中的给定样本 $\mathbf{x}_v \in \mathbb{R}^{d_v}$，嵌入向量 $\mathbf{e}_v \in \mathbb{R}^{d_e}$ 可写为 $\mathbf{e}_v = Embedding\left(\mathbf{x}_v\right)$，其中 $d_e$ 为嵌入空间维数，$Embedding(\cdot)$ 是全连接神经网络。随后将嵌入向量堆叠，获得原始多视图嵌入序列 $\mathbf{E} = \left[\mathbf{e}_1,\ \mathbf{e}_2,\ \ldots,\ \mathbf{e}_V\right] \in \mathbb{R}^{V\times d_e}$，进一步作为Transformer的输入向量。注意，对于不完整多视图数据，采用缺失视图生成方法（详见3.3节）生成缺失视图的嵌入，确保 $\mathbf{E}$ 在所有视图上完整。

我们的Transformer结构采用经典Transformer[18]的编码器模块。一个Transformer块记为 $Transformer(\mathbf{\Phi})$，其输入为 $\mathbf{\Phi} \in \mathbb{R}^{t \times d_t}$，其中 $t$ 与 $d_t$ 分别表示token的数量和维数。第一层包含两个Transformer块，记为 $Transformer_{sv}$ 和 $Transformer_{sc}$。通过辨别原始视图间的相关性，$Transformer_{sv}$ 在原始视图之间补充信息，获得多视图嵌入 $\widetilde{\mathbf{E}}$，即原始视图的增强表示，如下所示：

$$\tilde{\mathbf{E}} = Transformer_{sv}(\mathbf{E}) \tag{1}$$

其中 $\widetilde{\mathbf{E}} = \left[\widetilde{\mathbf{e}}_1, \widetilde{\mathbf{e}}_2, \ldots, \widetilde{\mathbf{e}}_V\right] \in \mathbb{R}^{V \times d_e}$。这里引入一个自适应融合层，将多个视图的信息融合为共享视图特征 $\mathbf{s}_v$。融合过程定义如下：

$$\mathbf{s}_v = \sum_{v=1}^{V} \frac{e^{\theta_v^{\epsilon}} \tilde{\mathbf{e}}_v}{\sum_j e^{\theta_j^{\epsilon}}} \tag{2}$$

其中 $\widetilde{\mathbf{e}}_v \in \mathbb{R}^{d_e}$ 是 $\widetilde{\mathbf{E}}$ 的第 $v$ 行，$\theta_v$ 为可学习权重，$\epsilon$ 是调节因子。通过与共享视图特征 $\mathbf{s}_v$ 交互并辨别原始类别之间的相关性，$Transformer_{sc}$ 补充原始类别间的信息，得到类别向量 $\widetilde{\mathbf{C}}$，如下所示：

$$[\tilde{\mathbf{s}}_v, \tilde{\mathbf{C}}] = Transformer_{sc}([\mathbf{s}_v, \mathbf{C}]) \tag{3}$$

其中 $[\cdot, \cdot]$ 表示拼接操作，$\mathbf{C} \in \mathbb{R}^{L \times d_e}$ 表示随机初始化的原始类别向量。随后，将 $Transformer_{sc}$ 的输出特征 $\tilde{\mathbf{s}}_v$ 传递至第二层。

第二层旨在提取高级共享特征：在第一层提取的特征基础上，促进视图信息与类别信息之间的交互融合，从而获得判别性更强的多视图数据表示。这一层包含两个Transformer块，记为 $Transformer_{av}$ 和 $Transformer_{ac}$。$Transformer_{av}$ 通过与共享类别特征 $\mathbf{s}_c$ 交互并辨别视图相关性，补充视图间信息，提取高级多视图嵌入 $\overline{\mathbf{E}}$，即视图的增强表示，表示如下：

$$\mathbf{s}_c = Proj_{cv}(\tilde{\mathbf{s}}_v) \tag{4}$$

$$[\bar{\mathbf{s}}_c, \bar{\mathbf{E}}] = Transformer_{av}([\mathbf{s}_c, \tilde{\mathbf{E}}]) \tag{5}$$

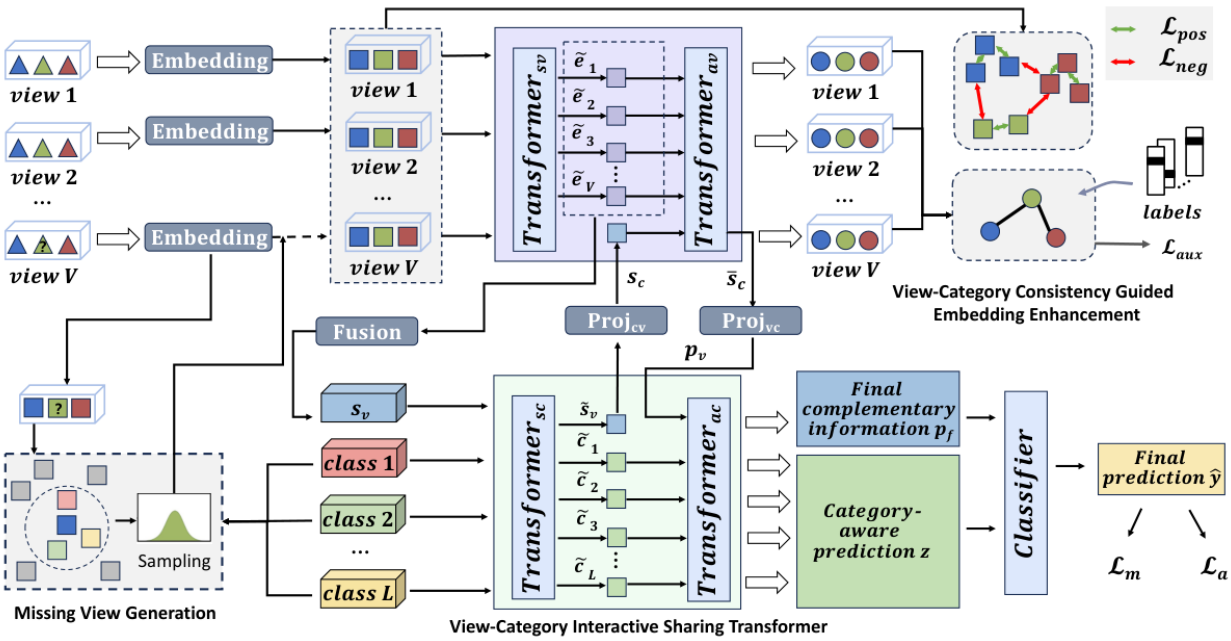



**图1.** VIST方法概览。包括三个模块：视图-类别交互共享Transformer模块、缺失视图生成模块，以及视图-类别一致性引导的嵌入增强模块。不同颜色表示不同样本，不同形状表示不同特征。**图中文字对照：** view＝视图；Embedding＝嵌入；Fusion＝融合；Sampling＝采样；class＝类别；labels＝标签；Missing View Generation＝缺失视图生成；View-Category Interactive Sharing Transformer＝视图-类别交互共享Transformer；View-Category Consistency Guided Embedding Enhancement＝视图-类别一致性引导的嵌入增强；Final complementary information＝最终互补信息；Category-aware prediction＝类别感知预测；Classifier＝分类器；Final prediction＝最终预测。投影层、向量和损失符号保持原样。

其中 $Proj_{cv}(\cdot)$ 是作为投影函数的线性层，将向量从类别特征空间映射到视图特征空间，$\bar{\mathbf{E}} = [\bar{\mathbf{e}}_1, \bar{\mathbf{e}}_2, \ldots, \bar{\mathbf{e}}_V] \in \mathbb{R}^{V \times d_e}$。相应地，$Transformer_{ac}$ 利用高级共享特征 $\mathbf{p}_v$ 并辨别类别相关性，补充类别间的信息并提取高级类别向量 $\bar{\mathbf{C}}$，如下所示：

$$\mathbf{p}_v = Proj_{vc}(\bar{\mathbf{s}}_c) \tag{6}$$

$$[\bar{\mathbf{p}}_v, \bar{\mathbf{C}}] = Transformer_{ac}([\mathbf{p}_v, \tilde{\mathbf{C}}]) \tag{7}$$

其中 $Proj_{vc}(\cdot)$ 是作为投影函数的线性层，将向量从视图特征空间映射到类别特征空间。通过在Transformer块之间传递向量 $\mathbf{s}_v$、$\mathbf{s}_c$ 和 $\mathbf{p}_v$，我们促进视图与类别特征空间之间的信息共享，从而提取更加精细、有效的视图与类别特征。

### 3.3. 缺失视图生成

考虑到数据集中存在视图缺失，一个直观想法是，适当补全这些缺失视图能够增强模型性能。通过3.4节所述的对比学习过程，同一样本的视图之间的距离趋于接近。因此，利用已有视图生成缺失视图是一种合理方案。我们采用类似 $k$ 近邻的方法，利用原始类别向量 $\mathbf{C} = [\mathbf{c}_1, \mathbf{c}_2, \ldots, \mathbf{c}_L]$ 辅助生成缺失视

图。具体而言，对某个样本 $i$，令 $\mathcal{E} = \{v \mid \mathbf{W}_{i,v} = 1\}$ 表示已有视图的索引集合，$\mathcal{M} = \{v \mid \mathbf{W}_{i,v} = 0\}$ 表示缺失视图的索引集合。为利用样本 $i$ 的原始多视图嵌入 $\mathbf{E}$ 补全缺失特征，首先在投影后的类别特征空间中寻找 $k$ 个最近邻。近邻集合 $\mathcal{D}$ 构建如下：

$$\mathcal{D} = \{d | TopK(\sum_{j \in \mathcal{E}} \|\mathbf{e}_j - \mathbf{c}_d\|_2, d \in \{1, 2, 3, \ldots, L\})\} \tag{8}$$

其中 $TopK(\cdot)$ 根据嵌入向量与类别向量之间的最小距离，确定前 $k$ 个类别的索引。随后采用统计方法描述缺失视图的分布。我们假设缺失视图 $\{\mathbf{e}_m\}_{m \in \mathcal{M}}$ 服从多元高斯分布 $\mathcal{N}(\mu, \mathbf{\Sigma})$，均值向量与协方差矩阵表示为：

$$\mu = \frac{\sum_{d \in \mathcal{D}} \mathbf{c}_d}{|\mathcal{D}|} \tag{9}$$

$$\mathbf{\Sigma} = \frac{1}{|\mathcal{D}| - 1} \sum_{d \in \mathcal{D}} (\mathbf{c}_d - \mu)(\mathbf{c}_d - \mu)^T \tag{10}$$

对于缺失视图，从该分布中采样 $|\mathcal{M}|$ 次，用采样结果替换缺失视图。由此可获得不完整多视图数据的完整嵌入。通过重建缺失的多视图数据，该方法进一步提升类别预测性能。

### 3.4. 视图-类别一致性引导的嵌入增强

通过上述视图-类别交互共享Transformer，我们从不同层提取三个多视图嵌入 $\mathbf{E}$、$\widetilde{\mathbf{E}}$ 和 $\overline{\mathbf{E}}$。为获得更好的分类性能，增强这些嵌入的判别能力与有效性十分重要。具体而言，基于视图一致性假设[10,24]，同一样本在不同视图上的嵌入 $\mathbf{E}$ 应当对齐。此外，为提升 $\widetilde{\mathbf{E}}$ 和 $\overline{\mathbf{E}}$ 的判别能力，可以利用多视图数据类别相关性与特征相关性之间的一致性。基于这些因素，我们引入视图-类别一致性引导的嵌入增强。

为学习更有效的嵌入 $\mathbf{E}$，利用对比学习对齐同一样本在不同视图上的嵌入。根据[13,17]，对比学习损失可写为：

$$\begin{aligned} & -\log \frac{e^{sim(x, x^+)}}{e^{sim(x, x^+)} + \sum_{x^- \in \mathcal{F}(x)} e^{sim(x, x^-)}} \\ & \approx -sim(x, x^+) + \log \sum_{x^- \in \mathcal{F}(x)} e^{sim(x, x^-)} \end{aligned} \tag{11}$$

其中 $x$、$x^+$、$x^-$ 分别表示锚点样本、其正样本和负样本。$\mathcal{F}(x)$ 表示负样本对的集合，$sim(\cdot, \cdot)$ 计算两个样本之间的相似度。

显然，我们的目标是最大化相似度 $sim(x,\ x^+)$，同时最小化 $\sum_{x^-\in\mathcal{F}(x)} e^{sim(x,x^-)}$。将 $\mathbf{e}_{i,v}$ 记为第 $i$ 个样本第 $v$ 个视图的嵌入，则 $\mathcal{F}(x)$ 可以改写为 $\mathcal{F}(i,\ v)=\{j,\ w \mid \sum^{L}\mathbf{y}_i\circ\mathbf{u}_i\circ\mathbf{y}_j\circ\mathbf{u}_j=0,\ \mathbf{U}_{j,w}=1\}$，其中 $\circ$ 为Hadamard积，$\mathbf{u}_i$ 是 $\mathbf{U}$ 中第 $i$ 个样本的缺失向量。对于最大化 $e^{sim(x,x^+)}$，采用以下损失函数：

$$\mathcal{L}_{pos}=\sum_{v_1=1}^{V}\sum_{v_2=1,v_2\neq v_1}^{V}\frac{1}{d_e}\|n(\mathbf{e}_{i,v_1})-n(\mathbf{e}_{i,v_2})\|_2^2 \quad (12)$$

其中 $n(\cdot)$ 表示 $L_2$ 归一化函数。为最小化 $\sum_{x^-\in\mathcal{F}(x)} e^{sim(x,x^-)}$，可采用如下损失函数：

$$\mathcal{L}_{neg}=\sum_{v_1=1}^{V}\sum_{j,v_2\in\mathcal{F}(i,v_1)}\frac{-1}{d_e}\|n(\mathbf{e}_{i,v_1})-n(\mathbf{e}_{j,v_2})\|_2^2 \quad (13)$$

为进一步提升 $\widetilde{\mathbf{E}}$ 和 $\overline{\mathbf{E}}$ 的有效性，我们利用类别信息引导这些嵌入的学习过程。如下所示，增强视图特征空间与类别特征空间中数据相关性的一致性：

$$\mathbf{G}_v^1(i,j)=(n(\tilde{\mathbf{e}}_{i,v})(n(\tilde{\mathbf{e}}_{j,v}))^T+1)/2 \quad (14)$$

$$\mathbf{G}_v^2(i,j)=(n(\bar{\mathbf{e}}_{i,v})(n(\bar{\mathbf{e}}_{j,v}))^T+1)/2 \quad (15)$$

$$\mathbf{H}=((\mathbf{Y}\circ\mathbf{U})(\mathbf{Y}\circ\mathbf{U})^T)./(\mathbf{U}\mathbf{U}^T) \quad (16)$$

其中 $\mathbf{G}_v^1$、$\mathbf{G}_v^2$ 和 $\mathbf{H}$ 分别是 $\widetilde{\mathbf{E}}$、$\overline{\mathbf{E}}$ 以及标签的相关性矩阵。$\mathbf{e}_{i,v}$ 和 $\bar{\mathbf{e}}_{i,v}$ 分别表示来自 $\widetilde{\mathbf{E}}$ 与 $\overline{\mathbf{E}}$ 的第 $i$ 个样本第 $v$ 个视图特征。通过交叉熵损失，可对齐视图特征空间与类别特征空间中的数据相关性，从而获得判别性更强的嵌入：

$$\begin{aligned}\mathcal{L}_{aux}=\frac{-1}{2nV}\sum_{v=1}^{V}\sum_{i=1}^{n}\sum_{j\neq i}^{n}(&\mathbf{H}_{i,j}(\log\mathbf{G}_v^1(i,j)+\log\mathbf{G}_v^2(i,j))\\&+(\mathbf{U}_{i,j}-\mathbf{H}_{i,j})(\log(1-\mathbf{G}_v^1(i,j))+\log(1-\mathbf{G}_v^2(i,j))))\end{aligned} \quad (17)$$

考虑上述因素，视图-类别一致性引导的嵌入增强损失可概括为：

$$\mathcal{L}_c=\mathcal{L}_{pos}+\mathcal{L}_{neg}+\alpha\mathcal{L}_{aux} \quad (18)$$

其中 $\alpha$ 为权重参数。通过优化上述损失，学习到的数据嵌入更具判别性，为后续多标签分类奠定坚实基础。

### 3.5. 总体损失函数

为获得多标签分类结果，将 $Transformer_{ac}$ 的输出 $[\overline{\mathbf{p}}_v, \overline{\mathbf{C}}]$ 拆分为 $\overline{\mathbf{p}}_v$ 和 $\overline{\mathbf{C}}$。具体而言，对样本 $i$，$\overline{\mathbf{p}}_v^i$ 通过线性层得到 $\mathbf{p}_f^i \in [0,\ 1]^L$，表示视图与类别之间最终的互补信息。$\overline{\mathbf{C}}^i$ 通过一组类别感知线性层，得到 $\mathbf{z}^i \in [0,\ 1]^L$，表示类别感知预测。在 $\mathbf{p}_f^i$ 的辅助下，得到最终预测 $\hat{\mathbf{y}}^i$：

$$\hat{\mathbf{y}}^i = classifier(\mathbf{p}_f^i + \mathbf{z}^i) \tag{19}$$

其中 $classifier(\cdot)$ 是线性分类器。利用带掩码的交叉熵函数计算多标签分类损失：

$$\mathcal{L}_m = \frac{\sum_{i=1}^{n}\sum_{l=1}^{L}(\mathbf{Y}_{i,l}\log\hat{\mathbf{y}}_l^i + (1-\mathbf{Y}_{i,l})\log(1-\hat{\mathbf{y}}_l^i))\mathbf{U}_{i,l}}{-\sum_{i,l}\mathbf{U}_{i,l}} \tag{20}$$

值得注意的是，类别不平衡是多标签数据的固有特征，会影响多标签预测的泛化性能[15,28]。通常，对于某些类别标签，训练数据中被赋予正标签的实例远少于被赋予负标签的实例。为处理这种类别不平衡问题，引入带掩码的非对称损失函数：

$$\mathbf{L}_l^i = (\max(\hat{\mathbf{y}}_l^i - 0.5, 0))^2 \log(1 - \max(\hat{\mathbf{y}}_l^i - 0.5, 0)) \tag{21}$$

$$\mathcal{L}_a = \frac{\sum_{i=1}^{n}\sum_{l=1}^{L}(\mathbf{Y}_{i,l}\log\hat{\mathbf{y}}_l^i + (1-\mathbf{Y}_{i,l})\mathbf{L}_l^i)\mathbf{U}_{i,l}}{-\sum_{i,l}\mathbf{U}_{i,l}} \tag{22}$$

最终得到模型总体损失函数：

$$\mathcal{L}_o = \mathcal{L}_m + \beta\mathcal{L}_a + \gamma\mathcal{L}_c \tag{23}$$

其中 $\beta$、$\gamma$ 表示不同的权重参数。通过优化 $\mathcal{L}_o$，该方法有效学习不完整多视图数据的嵌入，从而生成准确的多标签分类结果。

## 4. 实验

### 4.1. 实验设置

#### 4.1.1. 数据集

遵循[9,11,14]，我们在五个数据集上评估所提出VIST的性能，包括：

- **Corel5k[1]：** 图像标注与检索研究中常用的标准数据集，包含5000张图像和260种标签。
- **Pascal07[2]：** 又称PASCAL VOC 2007，是著名的视觉对象类别数据集，广泛用于对象识别与分类，包含9963张图像和20种标签。

- **Espgame[19]：** 来自一款由参与者为图像生成标签的在线游戏，包含20770个样本和268种标签。
- **IAPRTC12[5]：** 国际图像标注数据集，包含约20000张图像和290个类别。图像涵盖广泛的主题与场景，每张均附有详细描述文本。
- **Mirflickr[7]：** 包含来自Flickr的25000张图像和38种标签。这些从公共领域选取的图像涵盖多样主题和场景。

采用[6]所述的多视图特征提取方法。这些数据集中的图像经过全面预处理，被转换为六种不同视图：GIST、HSV、HUE、LAB、RGB和SIFT。每种视图都为图像数据提供独特视角，捕捉视觉信息的不同方面。

#### 4.1.2. 实现细节

对于数据集，遵循[14]，对五个数据集进行如下处理以模拟不完整场景：对每个视图随机移除50%的样本，同时保证每个样本至少保留一个视图。在每个类别中，随机将50%的正标签和50%的负标签指定为缺失标签。对于参数设置，全部实验均选择 $d_e = 512$ 、 $\alpha = 0.1$ 、 $\beta = 0.1$ 、 $\gamma = 0.1$ 及 $k = 20$ 。模型在NVIDIA RTX A6000 GPU上使用SGD优化器训练500个epoch，批大小为128。为保证结果可信，重复实验10次，记录结果的均值和方差。

#### 4.1.3. 对比方法

选择十种代表性方法进行比较。其中八种方法——lrMMC、MVL-IV、iMSF、iMvWL、NAIML、DDINet、DICNet和LMVCAT——已在第2节详述。此外，加入GLOCAL[31]，以拓宽评估范围。由于iMvWL和NAIML适用于视图与标签均缺失的数据集，我们必须修改其他方法以保持一致。受[14]和[9]启发，在lrMMC中用可用视图的平均值填入不可用视图。对于MVL-IV和iMSF，将缺失标签视为负标签。GLOCAL对每个视图单独运行，报告其中最优的结果。为保持公平评估，遵循各对比方法论文或代码仓库中推荐的设置。

#### 4.1.4. 评估指标

类似于[11]，采用平均精度（AP）、排序损失（RL）及曲线下面积（AUC）。为便于比较，采用1-RL进行评估。数值越大表示模型性能越好。

### 4.2. 实验结果

表1给出了所有方法在五个数据集上的实验结果，训练样本比例为70%，视图和标签缺失比例均为50%。从表1可见，该方法在大多数指标上具有明显优势。例如，在Corel5k数据集的AP指标上，我们的方法比排名第二的LMVCAT高出3%。此外，DDINet、DICNet和LMVCAT的性能优于前六种方法。这是因为它们专门适用于DIMVMLC问题。此外，它们都是深度学习模型，其更优的结果凸显了深度学习在解决这一特定挑战方面的巨大潜力。

尽管我们的方法主要针对DIMVMLC问题，也在视图与标签完整的场景中评估模型性能。结果见表2。可以看出，模型在这一场景中仍表现出优异性能，说明该方法能够有效应用于MVMLC。

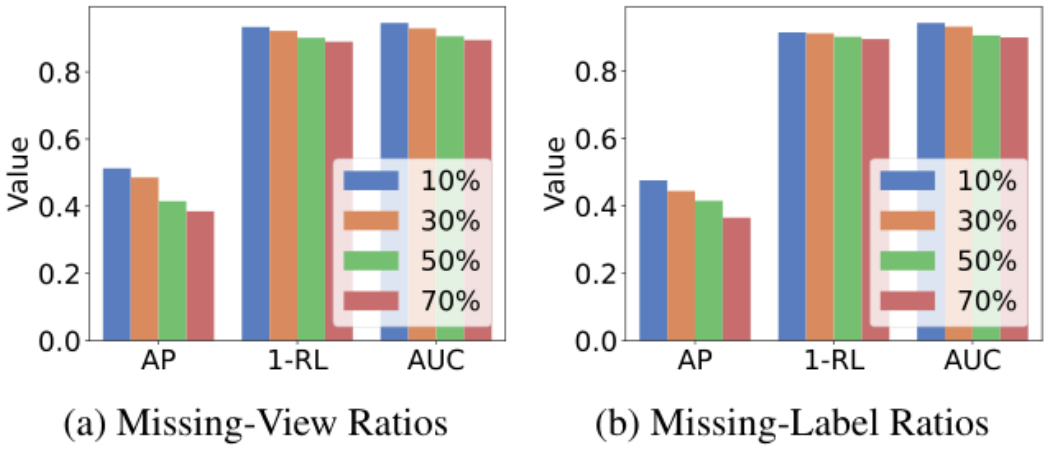
**表1.** 不同方法在五个数据集上的实验结果：70%训练样本，50%缺失实例与缺失标签。最优结果以粗体标出。为简洁起见，后文省略百分号。表头Dataset＝数据集，Metric＝指标；方法名与AP、1-RL、AUC保留原缩写。所有数值及原有“±”记法保留原样。

| Dataset | Metric | lrMMC | MVL-IV | iMSF | GLOCAL | iMvWL | NAIML | DDINet | DICNet | LMVCAT | VIST |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Corel5k | AP | 24.0±0.2 | 24.0±0.1 | 18.9±0.2 | 28.5±0.4 | 28.3±0.7 | 30.9±0.4 | 36.4±0.1 | 38.1±0.4 | 38.4±0.4 | **41.5±0.2** |
| | 1-RL | 76.2±0.2 | 75.6±0.1 | 70.9±0.5 | 80.4±0.3 | 86.5±0.3 | 87.8±0.2 | 87.1±0.0 | 88.2±0.4 | 88.0±0.2 | **90.2±0.2** |
| | AUC | 76.3±0.2 | 76.2±0.1 | 66.3±0.5 | 84.3±0.3 | 86.8±0.3 | 88.1±0.2 | 87.5±0.1 | 88.4±0.4 | 88.3±0.2 | **90.6±0.1** |
| Pascal07 | AP | 42.5±0.3 | 43.3±0.2 | 32.5±0.0 | 49.6±0.4 | 44.1±1.7 | 48.8±0.3 | 53.6±0.2 | 50.5±1.2 | 51.9±0.5 | **53.9±0.3** |
| | 1-RL | 69.8±0.3 | 70.2±0.1 | 56.8±0.0 | 76.7±0.4 | 73.7±0.9 | 78.3±0.1 | 80.7±0.1 | 78.3±0.8 | 81.1±0.4 | **85.6±0.1** |
| | AUC | 72.8±0.2 | 73.0±0.1 | 68.6±0.5 | 62.0±0.1 | 78.6±0.3 | 76.7±1.2 | 82.7±0.0 | 87.6±0.2 | 83.4±0.4 | **88.3±0.2** |
| Espgame | AP | 18.8±0.0 | 18.9±0.0 | 10.8±0.0 | 22.1±0.2 | 24.2±0.3 | 24.6±0.2 | 28.3±0.1 | 29.7±0.2 | 29.4±0.4 | **30.7±0.3** |
| | 1-RL | 77.7±0.1 | 77.8±0.0 | 72.2±0.2 | 78.0±0.4 | 80.7±0.1 | 81.8±0.2 | 81.5±0.0 | 83.2±0.1 | 82.8±0.2 | **84.4±0.0** |
| | AUC | 78.3±0.1 | 78.4±0.1 | 67.4±0.3 | 78.4±0.4 | 81.3±0.2 | 82.4±0.2 | 82.0±0.1 | 83.2±0.1 | 82.8±0.2 | **85.0±0.1** |
| IAPRTC12 | AP | 19.7±0.0 | 19.8±0.0 | 10.1±0.0 | 25.6±0.2 | 23.5±0.4 | 26.1±0.1 | 30.3±0.2 | 32.3±0.1 | 31.7±0.3 | **33.9±0.2** |
| | 1-RL | 80.1±0.0 | 79.9±0.1 | 63.1±0.0 | 82.5±0.2 | 83.3±0.3 | 84.8±0.1 | 85.3±0.1 | 87.3±0.1 | 87.0±0.1 | **88.4±0.2** |
| | AUC | 80.5±0.0 | 80.4±0.1 | 66.5±0.1 | 83.0±0.1 | 83.6±0.2 | 85.0±0.1 | 85.4±0.0 | 87.4±0.1 | 87.2±0.1 | **88.6±0.1** |
| Mirflickr | AP | 44.1±0.1 | 44.9±0.1 | 32.3±0.0 | 53.7±0.2 | 49.5±1.2 | 55.1±0.2 | 59.8±0.2 | 58.9±0.5 | 59.4±0.5 | **60.4±0.3** |
| | 1-RL | 80.5±0.0 | 80.4±0.1 | 66.5±0.1 | 83.2±0.1 | 83.6±0.2 | 85.0±0.1 | 86.3±0.0 | 86.3±0.4 | 86.5±0.3 | **87.9±0.1** |
| | AUC | 80.6±0.1 | 80.7±0.0 | 76.1±0.1 | 82.8±0.1 | 79.4±1.5 | 83.7±0.1 | 85.2±0.1 | 84.9±0.4 | 85.3±0.3 | **86.9±0.1** |

**表2.** 不同方法在五个数据集上的实验结果：70%训练样本，视图和标签完整。最优结果以粗体标出。Dataset＝数据集，Metric＝指标。

| Dataset | Metric | NAIML | DICNet | LMVCAT | VIST |
|---|---|---|---|---|---|
| Corel5k | AP | 32.7 | 50.9 | 52.1 | **55.4** |
| | 1-RL | 89.0 | 92.9 | 92.8 | **93.5** |
| | AUC | 89.3 | 93.1 | 93.0 | **94.2** |
| Pascal07 | AP | 49.6 | 60.8 | 62.9 | **65.5** |
| | 1-RL | 79.5 | 85.9 | 87.8 | **89.4** |
| | AUC | 82.2 | 87.6 | 89.2 | **91.2** |
| Espgame | AP | 25.1 | 39.1 | 38.5 | **40.1** |
| | 1-RL | 82.5 | 87.1 | 87.6 | **87.7** |
| | AUC | 83.0 | 87.4 | 88.0 | **89.6** |
| IAPRTC12 | AP | 26.7 | 41.8 | 43.6 | **45.7** |
| | 1-RL | 82.5 | 91.2 | 91.8 | **92.7** |
| | AUC | 83.0 | 91.1 | 91.8 | **92.0** |
| Mirflickr | AP | 55.5 | 65.9 | 68.4 | **70.4** |
| | 1-RL | 84.7 | 89.5 | 90.5 | **91.3** |
| | AUC | 83.9 | 87.6 | 88.9 | **89.3** |

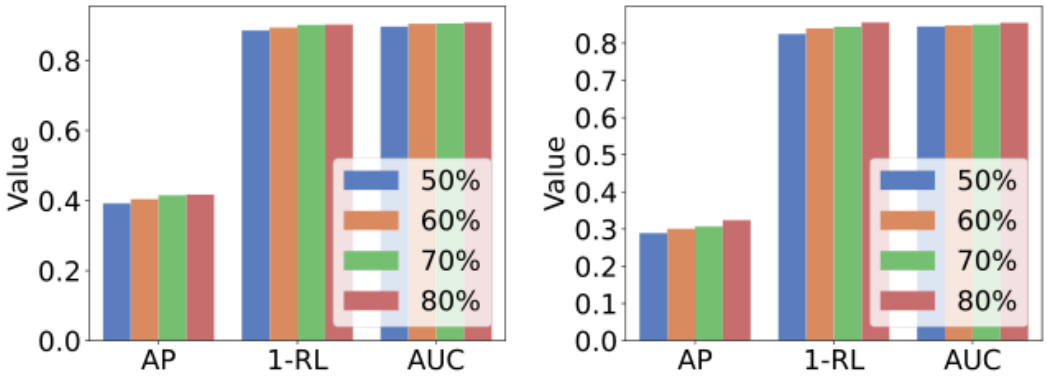
图2展示不同缺失比例下的模型性能。有趣的是，视图不完整与标签不完整都会对模型性能产生不利影响，但后者的影响更明显。此外，尽管进行了视图填补，随着视图缺失比例升高，模型精度仍明显下降。这主要是因为我们依赖已有视图填补缺失视图。缺失视图数量增多时，填补算法趋于退化为随机生成。




(a) Missing-View Ratios (b) Missing-Label Ratios

**图2.** Corel5k数据集上的结果：(a)标签缺失比例为50%时，不同视图缺失比例的结果；(b)视图缺失比例固定为50%时，不同标签缺失比例的结果。Missing-View Ratios＝视图缺失比例；Missing-Label Ratios＝标签缺失比例；Value＝指标值；图例10%、30%、50%、70%为缺失比例。

图3展示不同训练样本比例下的模型性能。虽然该比例对模型的影响并不十分显著，但可以观察到总体趋势：比例增大时，模型性能也相应提高。因此，在实验中选择70%的训练样本比例是合适的。




(a) Corel5k (b) Espgame

**图3.** 在50%视图缺失比例和50%标签缺失比例下，(a)Corel5k和(b)Espgame数据集上不同训练样本比例的结果。Value＝指标值；50%、60%、70%、80%为训练样本比例。

### 4.3. 参数分析

评估模型中的四个超参数，即 $\alpha$ 、 $\beta$ 、 $\gamma$ 和 $k$ 。为评估它们对模型性能的影响，在各自范围内调整数值，并在不同数据集上根据AP指标测试参数组合，设置为50%视图缺失、50%标签缺失和70%训练样本比例。注意， $k$ 与标签数内在相关，因此实际计算使用的 $\widehat{k}$ 应由 $\widehat{k}_j = \frac{k_i}{L_i} L_j$ 决定，其中 $i$ 、 $j$ 分别表示第 $i$ 和第 $j$ 个数据集。根据图4，在Corel5k数据集上， $\beta$ 与 $\gamma$ 分别在[5e-2,5e-1]和[5e-2,1e0]范围内表现较好。这表明 $\beta$ 和 $\gamma$ 不宜过大或过小， $\beta$ 的最优值约为0.1， $\gamma$ 的最优值也应在0.1附近选择。

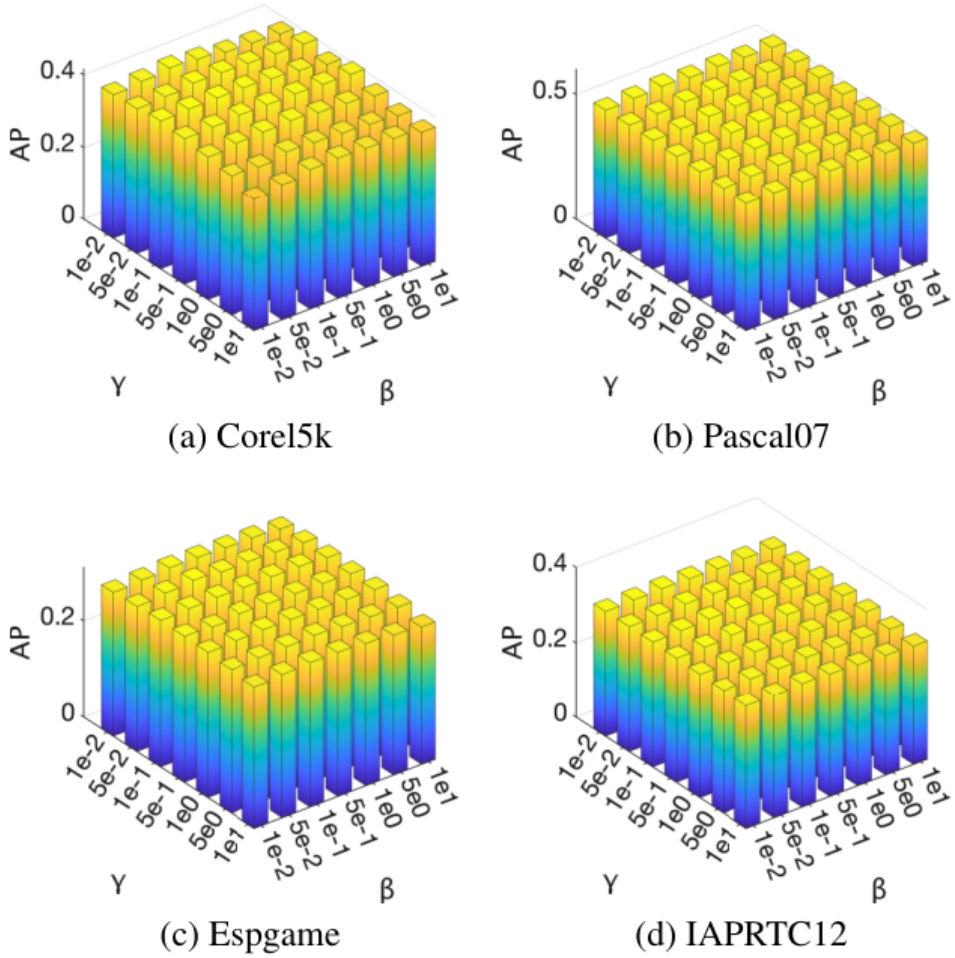
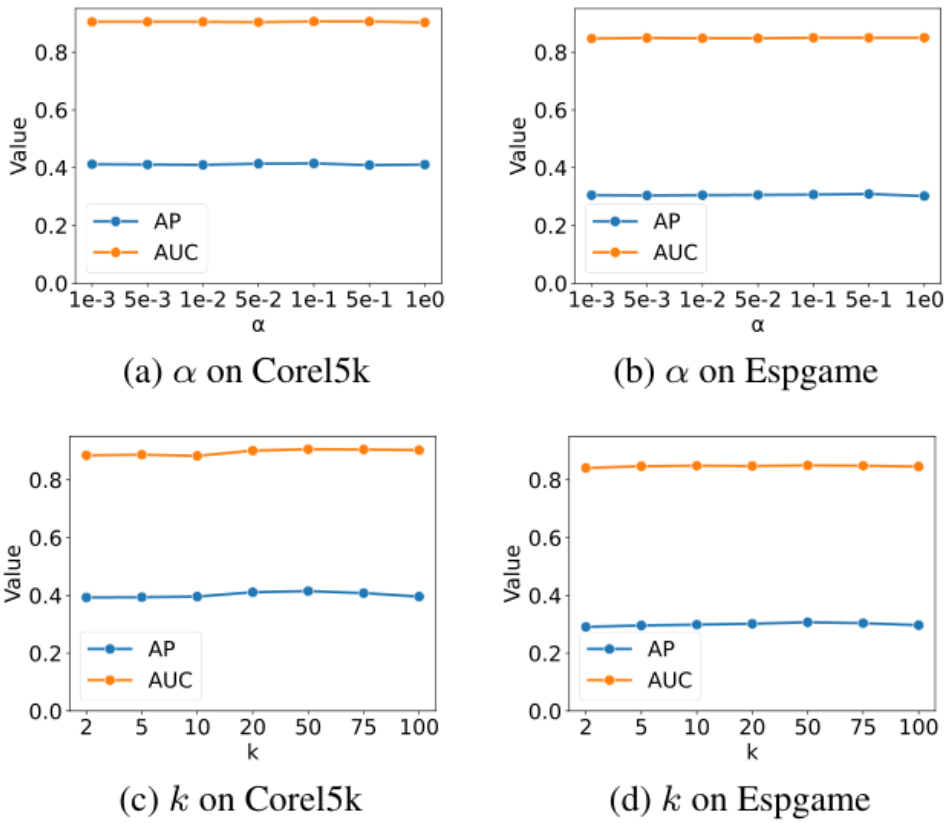



**图4.** 不同数据集上超参数 $\beta$ 与 $\gamma$ 的不同取值组合所产生的结果。 $\alpha$ 和 $k$ 分别设为默认值0.1和20。(a)Corel5k，(b)Pascal07，(c)Espgame，(d)IAPRTC12；纵轴为AP。

对于 $\alpha$ 与 $k$，固定 $\beta = 0.1$ 和 $\gamma = 0.1$，通过测量AP和AUC评估改变 $\alpha$ 和 $k$ 对模型的影响。如图5所示，在Corel5k与Espgame数据集上，AP和AUC均保持在较窄范围内，说明模型对 $\alpha$ 和 $k$ 并不十分敏感。这可能是因为它们作用于深层机制，在一定范围内的变化不会显著影响模型性能。




(a) $\alpha$ on Corel5k (b) $\alpha$ on Espgame

(c) $k$ on Corel5k (d) $k$ on Espgame

**图5.** 不同数据集上超参数 $\alpha$ 和 $k$ 不同取值的结果。 $\beta$ 和 $\gamma$ 分别设为默认值0.1和0.1。(a)Corel5k上的 $\alpha$；(b)Espgame上的 $\alpha$；(c)Corel5k上的 $k$；(d)Espgame上的 $k$。Value＝指标值；图例为AP和AUC。

### 4.4. 消融研究

在消融研究中，我们在三个代表性数据集上评估VIST各模块的性能，结果见表3。可以观察到，视图-类别交互共享Transformer模块对提升模型性能起着关键作用。此外，视图-类别一致性引导的嵌入增强模块能够提升嵌入的判别能力并改善分类性能。缺失视图生成模块也有助于模型的整体有效性。另外，移除 $\mathcal{L}_a$ 后，模型指标明显下降，尤其是AUC。这说明带掩码的非对称损失确实解决了数据不平衡相关的问题。消融研究证明了每个所提模块的有效性与合理性。

**表3.** 三个代表性数据集上的消融实验结果。Vanilla Transformer表示四个标准Transformer的编码器；M1表示基础视图-类别交互共享Transformer模块；M2表示视图-类别一致性引导的嵌入增强模块；M3表示缺失视图生成模块。Method＝方法；w/o $\mathcal{L}_a$ ＝去除 $\mathcal{L}_a$。

| Method | Corel5k | | Espgame | | IAPRTC12 | |
|---|---|---|---|---|---|---|
| | AP | AUC | AP | AUC | AP | AUC |
| Vanilla Transformer | 34.9 | 87.8 | 27.6 | 83.4 | 28.1 | 87.2 |
| $M_1$ | 39.5 | 89.6 | 29.4 | 84.1 | 31.6 | 87.8 |
| $M_1 + M_2$ | 40.4 | 90.1 | 29.6 | 84.7 | 32.7 | 88.3 |
| $M_1 + M_2 + M_3$ | **41.5** | **90.2** | **30.7** | **85.0** | **33.9** | **88.6** |
| *w/o* $\mathcal{L}_a$ | 40.6 | 89.8 | 29.6 | 84.5 | 32.4 | 88.2 |

## 5. 结论

本文提出一种新颖的视图-类别交互共享Transformer VIST，以应对DIMVMLC挑战。该方法利用双层视图-类别Transformer架构，提取视图与标签的深层表示。此外，采用结合多元高斯分布的KNN式方法补全缺失视图。为进一步增强模型有效性，整合视图-类别一致性引导的嵌入增强模块，显著提升嵌入质量与分类精度。全面的实验分析有力地证明，该方法优于现有最先进方法。

### 致谢

本工作得到国家自然科学基金（No.62272058、No.62192784、No.62172056）以及北京市自然科学基金（No.4242027、No.4232025）支持。

## 参考文献

参考文献作者、出版物、年份、卷期页码及原文引用页码保留；文献标题译为中文。末尾数字为原论文的引用页码，而非本译文页码。

[1] P. Duygulu, K. Barnard, J. F. G. de Freitas, and D. A. Forsyth. **将对象识别视为机器翻译：为固定图像词汇学习词典**。 In Computer Vision — ECCV 2002, pages 97–112, Berlin, Heidelberg, 2002. Springer Berlin Heidelberg. 引用页：6。

[2] Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, and Andrew Zisserman. **PASCAL视觉对象类别（VOC）挑战**。 International Journal of Computer Vision, 88:303–338, 2010. 引用页：6。

[3] Zheng Fang and Zhongfei Zhang. **同时结合多视图多标签学习与最大间隔分类**。 In 2012 IEEE 12th International Conference on Data Mining, pages 864–869. IEEE, 2012. 引用页：1。

[4] Arthur Gretton, Olivier Bousquet, Alex Smola, and Bernhard Schölkopf. **利用Hilbert-Schmidt范数衡量统计依赖性**。 In International Conference on Algorithmic Learning Theory, pages 63–77. Springer, 2005. 引用页：1。

[5] Michael Grubinger, Paul Clough, Henning Müller, and Thomas Deselaers. **IAPR TC12基准：视觉信息系统的新评估资源**。 Workshop Ontoimage, 2006. 引用页：6。

[6] Matthieu Guillaumin, Jakob Verbeek, and Cordelia Schmid. **用于图像分类的多模态半监督学习**。 In 2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, pages 902–909. IEEE, 2010. 引用页：6。

[7] Mark J Huiskes and Michael S Lew. **MIR Flickr检索评估**。 In Proceedings of the 1st ACM International Conference on Multimedia Information Retrieval, pages 39–43, 2008. 引用页：6。

[8] Junlong Li, Peipei Li, Xuegang Hu, and Kui Yu. **利用相关信息学习多标签分类的公共特征和标签特定特征**。 Pattern Recognition, 121:108259, 2022. 引用页：1。

[9] Xiang Li and Songcan Chen. **面向非对齐不完整多视图与缺失多标签学习的简洁有效模型**。 IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918–5932, 2022. 引用页：1、2、6。

[10] Chengliang Liu, Jie Wen, Xiaoling Luo, Chao Huang, Zhihao Wu, and Yong Xu. **DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络**。 In Proceedings of the AAAI Conference on Artificial Intelligence, pages 8807–8815, 2023. 引用页：1、2、5。

[11] Chengliang Liu, Jie Wen, Xiaoling Luo, and Yong Xu. **通过标签引导的带掩码视图感知与类别感知Transformer进行不完整多视图多标签学习**。 In Proceedings of the AAAI Conference on Artificial Intelligence, pages 8816–8824, 2023. 引用页：1、2、6。

[12] Meng Liu, Yong Luo, Dacheng Tao, Chao Xu, and Yonggang Wen. **用于多标签图像分类的矩阵补全中的低秩多视图学习**。 In Proceedings of the AAAI Conference on Artificial Intelligence, 2015. 引用页：2。

[13] Lajanugen Logeswaran and Honglak Lee. **用于学习句子表示的高效框架**。 arXiv preprint arXiv:1803.02893, 2018. 引用页：5。

[14] Qiaoyu Tan, Guoxian Yu, Carlotta Domeniconi, Jun Wang, and Zili Zhang. **不完整多视图弱标签学习**。 In Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence, IJCAI-18, pages 2703–2709. International Joint Conferences on Artificial Intelligence Organization, 2018. 引用页：2、6。

[15] Adane Nega Tarekegn, Mario Giacobini, and Krzysztof Michalak. **不平衡多标签分类方法综述**。 Pattern Recognition, 118:107965, 2021. 引用页：5。

[16] Daniel J Trosten, Sigurd Lokse, Robert Jenssen, and Michael Kampffmeyer. **重新审视多视图聚类中的表示对齐**。 In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 1255–1265, 2021. 引用页：1。

[17] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. **利用对比预测编码进行表示学习**。 2019. 引用页：5。

[18] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. **注意力就是你所需要的一切**。 2017. 引用页：3。

[19] Luis von Ahn and Laura Dabbish. **利用计算机游戏标注图像**。 In Proceedings of the SIGCHI Conference on Human Factors in Computing Systems, page 319–326, New York, NY, USA, 2004. Association for Computing Machinery. 引用页：6。

[20] Jie Wen, Zheng Zhang, Lunke Fei, Bob Zhang, Yong Xu, Zhao Zhang, and Jinxing Li. **不完整多视图聚类综述**。 IEEE Transactions on Systems, Man, and Cybernetics: Systems, 53(2):1136–1149, 2022. 引用页：1。

[21] Jie Wen, Chengliang Liu, Shijie Deng, Yicheng Liu, Lunke Fei, Ke Yan, and Yong Xu. **标签不完整与视图缺失条件下的深度双重不完整多视图多标签学习**。 IEEE Transactions on Neural Networks and Learning Systems, 2023. 引用页：2。

[22] Mengyao Xie, Zongbo Han, Changqing Zhang, Yichen Bai, and Qinghua Hu. **为不完整多视图分类探索并利用不确定性**。 In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 19873–19882, 2023. 引用页：1。

[23] Chang Xu, Dacheng Tao, and Chao Xu. **视图不完整条件下的多视图学习**。 IEEE Transactions on Image Processing, 24(12):5812–5825, 2015. 引用页：2。

[24] Jie Xu, Huayi Tang, Yazhou Ren, Liang Peng, Xiaofeng Zhu, and Lifang He. **用于对比多视图聚类的多层级特征学习**。 In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 16051–16060, 2022. 引用页：5。

[25] Nan Xu, Yanqing Guo, Xin Zheng, Qianyu Wang, and Xiangyang Luo. **部分多视图子空间聚类**。 In Proceedings of the 26th ACM International Conference on Multimedia, pages 1794–1801, 2018. 引用页：1。

[26] Lei Yuan, Yalin Wang, Paul M Thompson, Vaibhav A Narayan, Jieping Ye, Alzheimer’s Disease Neuroimaging Initiative, et al. **用于联合分析不完整多种异质神经影像数据的多源特征学习**。 NeuroImage, 61(3):622–632, 2012. 引用页：2。

[27] Changqing Zhang, Ziwei Yu, Qinghua Hu, Pengfei Zhu, Xinwang Liu, and Xiaobo Wang. **潜在语义感知的多视图多标签分类**。 In Proceedings of the AAAI Conference on Artificial Intelligence, 2018. 引用页：2。

[28] Min-Ling Zhang, Yu-Kun Li, Hao Yang, and Xu-Ying Liu. **迈向类别不平衡感知的多标签学习**。 IEEE Transactions on Cybernetics, 52(6):4459–4471, 2022. 引用页：5。

[29] Wei Zhang, Ke Zhang, Pan Gu, and Xiangyang Xue. **面向不完整标注数据的多视图嵌入学习**。 In Twenty-Third International Joint Conference on Artificial Intelligence, 2013. 引用页：2。

[30] Pengfei Zhu, Qi Hu, Qinghua Hu, Changqing Zhang, and Zhizhao Feng. **多视图标签嵌入**。 Pattern Recognition, 84:126–135, 2018. 引用页：1。

[31] Yue Zhu, James T Kwok, and Zhi-Hua Zhou. **利用全局与局部标签相关性进行多标签学习**。 IEEE Transactions on Knowledge and Data Engineering, 30(6):1081–1094, 2017. 引用页：6。