通过扩散引导的冗余去除进行不完整多视图多标签分类

Incomplete Multi-View Multi-Label Classification via Diffusion-Guided Redundancy Removal

第39届 AAAI 人工智能会议（AAAI-25），原文页码 19758–19766。

Shilong Ou[1]，Zhe Xue[1]，Lixiong Qin[1]，Yawen Li[1]，Meiyu Liang[1]，Junjiang Wu[1]，Xuyun Zhang[2]，Amin Beheshti[2]，Yuankai Qi[2]

[1] 北京邮电大学，中国；[2] 麦考瑞大学，澳大利亚。

{osl, xuezhe, lxqin, meiyu1210, wujunjiang}@bupt.edu.cn；{xuyun.zhang, amin.beheshti, yuankai.qi}@mq.edu.au；warmly0716@126.com。

*通讯作者。

Copyright © 2025, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.

译文说明： 本文是用户上传版本全部9页的非官方中文翻译，仅用于用户私有云端交付。版权归原权利人所有，未主张开放许可。公式（1）—（17）、图表及参考文献原始书目信息保留原稿图像，以准确保存字形、数字、粗体、上下标和编号；图表说明与全部正文译为中文，参考文献题名另附中文对照。文中方法名依原文为 DiffSumm，P015_DGRR 仅为归档标识。

摘要

不完整多视图多标签分类旨在部分视图缺失的情况下，准确预测每个样本的标签。由于这种情形在现实场景中广泛存在，该问题已成为受到广泛研究的课题。除视图缺失带来的挑战外，它还面临冗余视图引发的问题：纳入这些视图并不能对性能作出积极贡献。本文首次尝试利用扩散模型解决视图缺失问题，并设计一种识别和去除冗余视图的策略。具体而言，我们训练一个以伪标签为条件的扩散模型，以恢复缺失视图的信息。训练得到的扩散模型能够将训练划分中的数据分布知识传递给数据。冗余识别策略同时考虑视图的附加信息和样本的分类难度，从而自适应地识别和去除冗余视图。我们在五个数据集上进行了广泛实验；在多视图多标签分类任务中，所提方法相比多种最先进方法取得了良好性能。

引言

多视图数据涉及从不同媒介收集数据，在现实世界中无处不在（Zhang et al. 2013b；Wang et al. 2021）。能够表示现实世界复杂关系的多标签数据（Sun et al. 2024）也日益普遍。根据这些数据特点，研究者提出了多视图多标签学习（Fang and Zhang 2012）：在该场景中，数据包含多个视图的

信息，同时属于若干类别。多视图多标签学习吸引了大量研究关注（Liu et al. 2015；Tan et al. 2018；Wang et al. 2022）。其中，多视图多标签分类（MVMLC）是主要研究问题之一。它要求从视图中提取特征并融合这些特征，随后将其映射到标签空间。

在现实场景中，对一个对象或事件的不同视图观测并不完全独立。例如，同一场景的 RGB 和 HSV 视图具有大量相似的结构信息。同时，每个视图都不可避免地含有噪声，因此，更多视图并不意味着更好的性能。我们将这一现象定义为视图冗余现象。因此，识别并去除冗余视图对于取得更好的最终性能十分重要。RMVC（Tao et al. 2018）采用平方 χ^2 距离进行聚类，旨在确保多视图的性能不劣于单视图；DSMVC（Tang and Liu 2022）提出安全添加视图的方法：舍弃那些噪声多于补充信息的新视图，从而减轻增加视图数量所造成的性能下降。这些方法缓解了视图冗余问题，但忽略了各个数据个体之间的差异。

另一方面，MVMLC 在现实数据集中经常遇到视图不完整或标签不完整的问题。例如，传感器损坏可能导致图像的某个视图缺失，社交平台上的多媒体内容也可能未被用户充分标注。为应对视图和标签不完整的挑战，近期的创新包括深度对比网络（Trosten et al. 2021；Liu et al. 2023a）、Transformer（Liu et al. 2023b）以及基于深度图的网络（Li et al. 2024）。这些方法能够有效处理数据集内的不完整多视图多标签数据；然而，它们仍未充分利用数据集中现有视图和标签所蕴含的数据分布知识，因而无法克服不完整性引入的性能限制。

为解决这些问题，我们提出 DiffSumm，这是一种面向多视图多标签分类的冗余驱动扩散模型。具体而言，我们设计视图编码模块，将原始视图转换为用于多标签分类的潜在空间向量，称为摘要向量。随后，我们设计标签引导扩散模块，为包含缺失视图的数据恢复摘要向量。此后，我们设计冗余视图识别策略，利用合成摘要向量及其伪标签识别和去除冗余视图，再利用移除后的版本重新生成新的合成摘要向量和伪标签，以体现合成摘要向量中的数据分布知识。最后，在最终预测模块中，我们融合原始摘要向量和合成摘要向量以获得最终预测。全面的实验验证了所提 DiffSumm 框架的优越性能。概括而言，本文具有以下贡献：

- 据我们所知，这是首项使用扩散模型处理不完整多视图多标签分类问题的工作，能够恢复缺失视图所丢失的信息。
- 我们提出扩散模型辅助的冗余视图识别策略，在样本层面识别并去除冗余视图，从而减少数据噪声、提升模型性能。
- 大量实验表明，与最先进的方法相比，本方法在五个数据集上具有良好性能。

相关工作

不完整多视图多标签分类

针对多视图多标签分类挑战，已有多种策略被提出。LrMMC（Liu et al. 2015）保持低秩公共子空间，与矩阵补全策略相结合，并确定各视图的权重以发挥其独特优势。为了应对视图或标签不完整的数据集带来的困难，MVL-IV（Xu, Tao, and Xu 2015）通过利用视图间关系探索不完整多视图学习。类似地，iMSF 将不完整多视图单标签学习问题划分为多个完整任务来处理（Yuan et al. 2012）。另一方面，MvEL（Zhang et al. 2013a）着重挖掘不完整标签的上下文一致性与邻域一致性，但仅能处理

标签不完整问题。对于视图和标签均不完整的任务，iMvWL（Tan et al. 2018）将多视图和多标签元素整合到统一子空间。与此相对，NAIML（Li and Chen 2022）通过对子标签矩阵和子类别采用低秩框架处理双重不完整性。

深度学习方法也越来越多地应用于这些挑战。DDINet（Wen et al. 2023）引入一种具有视图专用解码器网络的深度学习架构，能够有效保留关键视图信息。DICNet（Liu et al. 2023a）率先在该问题中采用实例级对比学习。基于 Transformer 的 LMVCAT（Liu et al. 2023b）通过结合分别面向视图和标签设计的两个 Transformer，有效解决这一问题。VIST（Ou et al. 2024）通过引入视图—标签交互 Transformer 处理该问题，有效应对数据不完整性，并提升分类性能。

多视图学习中的冗余视图

RMVC（Tao et al. 2018）是多视图聚类领域中保障安全性的开创性工作。类似地，DSMTL（Yue et al. 2021）提出安全多任务模型，其设计目标是在每个任务上的性能至少与相应单任务模型一样好。DSMVC（Tang and Liu 2022）不同于这些方法，其目标是确保引入额外视图时，不会损害原有数据集以及新视图所对应数据的聚类效果。

扩散模型

扩散模型（Sohl-Dickstein et al. 2015；Ho, Jain, and Abbeel 2020）是一类近年来流行的生成模型。为加快去噪过程，DDIM（Song, Meng, and Ermon 2021）引入减少去噪步数的策略。LDM（Rombach et al. 2022）尝试在潜在空间而不是像素空间进行扩散，从而降低训练成本并加快推理。尽管这些方法能够生成高质量样本，但它们不能指定生成内容。GLIDE（Nichol et al. 2022）和 Imagen（Saharia et al. 2022）通过将条件信息直接纳入扩散模型训练，实现无分类器引导（Ho and Salimans 2022）。

方法

我们主要将 DiffSumm 表述为三个模块：视图编码模块、标签引导扩散模块和最终预测模块。训练过程如图1a所示。我们训练视图编码模块，以获得原始摘要向量和伪标签。同时，我们训练标签引导扩散模块，以生成合成摘要向量。最后，使用原始和合成摘要向量共同训练最终预测模块。

随后，在图1b所示的推理阶段，数据首先经过视图编码模块，得到原始摘要向量和伪标签。标签引导扩散模块随后利用这些伪标签生成合成摘要向量。这些向量与根据其他视图组合生成的普通摘要向量和剩余摘要向量共同帮助模型识别并去除冗余视图，进而得到新的视图组合。新的组合再次输入视图编码模块，从而完成该策略循环中的一步。循环结束后，原始和合成摘要向量被输入最终预测模块以得到最终预测。下文将详细介绍该方法。

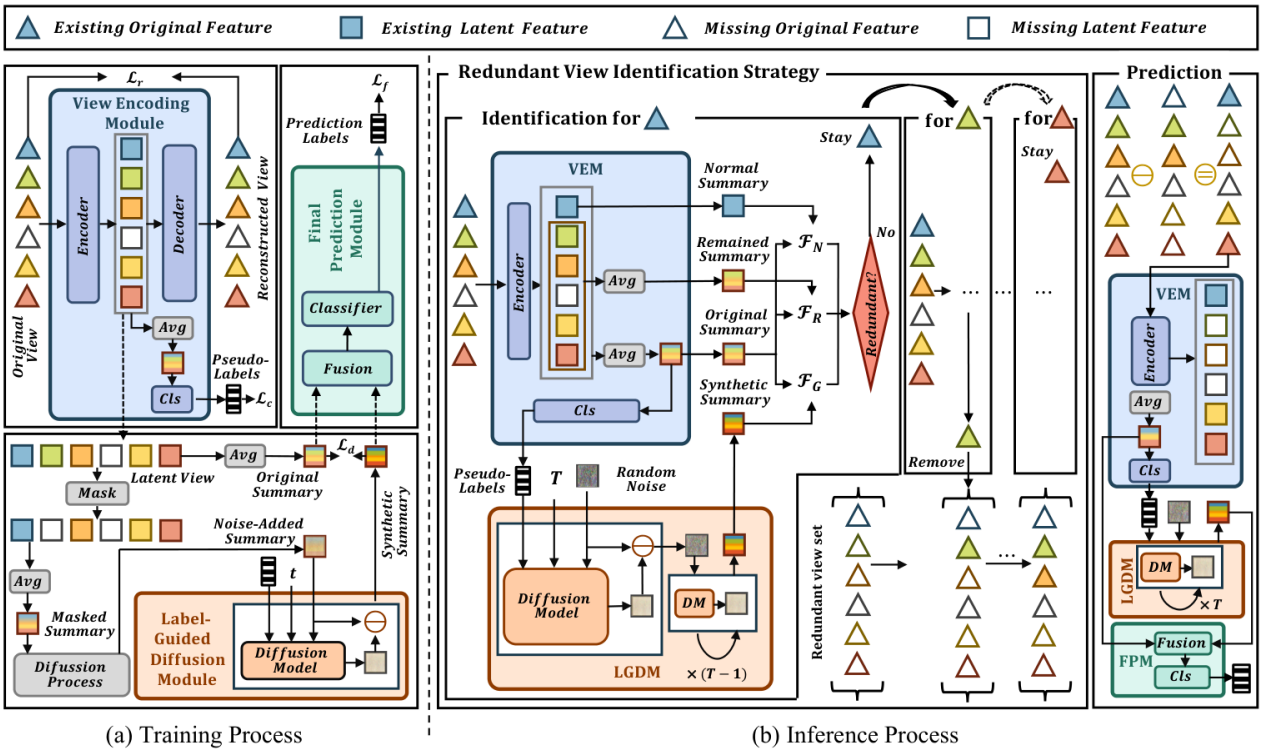


图1： DiffSumm 方法概览。为简洁起见，图中从“摘要向量”中省略了“向量”一词。在推理过程中，模型首先执行冗余视图识别策略，反复利用视图编码模块和标签引导扩散模块，按顺序识别并去除冗余视图。该策略执行后，模型将基于最终视图组合得到的原始和合成摘要向量输入最终预测模块。

图内文字对照： Existing Original Feature：现有原始特征；Existing Latent Feature：现有潜在特征；Missing Original Feature：缺失原始特征；Missing Latent Feature：缺失潜在特征；Training Process：训练过程；Inference Process：推理过程；View Encoding Module（VEM）：视图编码模块；Label-Guided Diffusion Module（LGDM）：标签引导扩散模块；Final Prediction Module（FPM）：最终预测模块；Encoder/Decoder：编码器/解码器；Original View：原始视图；Latent View：潜在视图；Original Summary：原始摘要；Masked Summary：掩码摘要；Noise-added Summary：加噪摘要；Synthetic Summary：合成摘要；Normal Summary：普通摘要；Remained Summary：剩余摘要；Pseudo-labels：伪标签；Prediction Labels：预测标签；Avg：平均；Cls/Classifier：分类器；Fusion：融合；Mask：掩码；Diffusion Process：扩散过程；Diffusion Model（DM）：扩散模型；Random Noise：随机噪声；Redundant View Identification Strategy：冗余视图识别策略；Identification for：针对所示视图的识别；Reconstructed View：重建视图；Redundant?：是否冗余？；No：否；Stay：保留；Remove：去除；Redundant view set：冗余视图集合；Prediction：预测。

预备知识

扩散模型。 扩散模型是一类生成模型，主要包括正向扩散过程和反向去噪过程。正向扩散过程从数据集的分布中采样一个数据点，随后在每一步 $t \in \{1, 2, \ldots, T\}$ 向样本添加方差为 $\beta_t \in (0, 1)$ 的噪声，直至其收敛到标准正态分布 $\mathbf{s}_T \sim \mathcal{N}(0, \mathbf{I})$。即 $q(\mathbf{s}_t \mid \mathbf{s}_{t-1}) = \mathcal{N}\left(\mathbf{s}_t; \sqrt{1-\beta_t}\mathbf{s}_{t-1}, \beta_t\mathbf{I}\right)$。反向去噪过

程利用由 θ 参数化的扩散模型，经过 T 个时间步将采样的 $\mathbf{s}_t$ 恢复到 $\mathbf{s}_0$，可表示为 $p_\theta(\mathbf{s}_{t-1} \mid \mathbf{s}_t) = \mathcal{N}(\mathbf{s}_{t-1};\, \mu_\theta(\mathbf{s}_t,\, t),\, \Sigma_\theta(\mathbf{s}_t,\, t))$。模型通过最大化负对数似然的变分下界进行训练；根据 Ho, Jain, and Abbeel（2020），该训练可简化为下面的损失函数：

$$\mathcal{L}_{simple} = \mathbb{E}_{t,\mathbf{s}_0,\epsilon}[||\epsilon - \epsilon_\theta(\mathbf{s}_t, t)||^2] \qquad (1)$$

其中，ϵ_θ 是对 ϵ 的预测。对于 $\mathbf{s}_t$，可以按以下方式迭代进行去噪：

$$\mathbf{s}_{t-1} = \mu_\theta(\mathbf{s}_t, t) + \sqrt{\Sigma_\theta(\mathbf{s}_t, t)}\mathbf{m}, \;\; \mathbf{m} \sim \mathcal{N}(0, \mathbf{I}) \qquad (2)$$

问题定义。对于来自 V 个不同视图的 n 个样本，用一组矩阵 $\mathcal{X} = \{\mathbf{X}^v\}_{v=1}^V$ 表示，其中 $\mathbf{X}^v \in \mathbb{R}^{n \times d_v}$，$d_v$ 表示第 v 个视图的数据维数。矩阵 $\mathbf{Y} \in \{0,\, 1\}^{n \times L}$ 是所有样本的标签矩阵，L 表示类别总数。$\mathbf{Y}_{i,j} = 1$ 表示第 i 个样本属于第 j 个类别，$\mathbf{Y}_{i,j} = 0$ 则表示不属于。对于某些特征可能缺失的多视图数据，我们采用缺失视图指示矩阵 $\mathbf{W} \in \{0,\, 1\}^{n \times V}$。其中，$\mathbf{W}_{i,j} = 1$ 表示第 i 个样本的第 j 个视图存在，$\mathbf{W}_{i,j} = 0$ 表示该视图缺失。类似地，定义缺失标签指示矩阵 $\mathbf{U} \in \{0,\, 1\}^{n \times L}$，其中 $\mathbf{U}_{i,j} = 1$ 表示第 i 个样本的第 j 类标签可用，$\mathbf{U}_{i,j} = 0$ 则相反。在初始数据处理阶段，视图 $\mathcal{X}$ 或标签 $\mathbf{Y}$ 中的所有缺失值均赋为0。本文目标是开发一个用于不完整多视图多标签分类任务的模型。

模型训练

视图编码模块。原始数据通常包含大量噪声和冗余信息，因此首先需要提取关键信息和潜在特征。与先前的深度学习工作（Wen et al. 2020）类似，我们采用自编码器完成该任务。以某一视图的原始数据 $\mathbf{X}^v$ 为例，它通过该视图专用的编码器 E_v 转换为潜在表示，记作 $\mathbf{Z}^v = E_v(\mathbf{X}^v)$，其中 $\mathbf{Z}^v \in \mathbb{R}^{n \times d_z}$ 为该视图的潜在表示，d_z 为潜在空间维数。相应地，潜在表示随后通过同样为该视图专用的解码器 D_v，用于重建原始视图，表示为 $\widehat{\mathbf{X}}^v = D_v(\mathbf{Z}^v)$，其中 $\widehat{\mathbf{X}}^v$ 为重建视图。由于视图不完整，需要考虑缺失视图指示矩阵 $\mathbf{W}$ 对训练的影响。因此，自编码器使用以下损失函数训练：

$$\mathcal{L}_r = \frac{1}{V}\sum_{v=1}^{V}\left(\frac{1}{d_v}\sum_{i=1}^{n}||\hat{\mathbf{x}}_{i,v} - \mathbf{x}_{i,v}||_2^2 \mathbf{W}_{i,v}\right) \qquad (3)$$

其中，$\mathbf{x}_{i,v}$ 与 $\widehat{\mathbf{x}}_{i,v}$ 分别表示第 i 个样本在第 v 个视图下的原始特征和重建特征。注意，该损失函数计算所有视图的损失，而非单个视图的损失。

在样本层面，要获得原始摘要向量，就必须将来自不同视图的潜在表示融合为统一表示。借鉴此前工作（Chen et al. 2022），我们采用考虑视图缺失情况的平均融合方法，以促进不同视图之间的信息交换：

$$\mathbf{s}_i = F(\mathbf{z}_{i,1}, \mathbf{z}_{i,2}, \ldots, \mathbf{z}_{i,V}, \mathbf{W}) = \frac{\sum_{v=1}^{V} \mathbf{z}_{i,v} \mathbf{W}_{i,v}}{\sum_{v=1}^{V} \mathbf{W}_{i,v}} \quad (4)$$

其中，$\mathbf{z}_{i,v}$ 表示第 i 个样本在第 v 个视图下的潜在表示，$\mathbf{s}_i$ 是第 i 个样本的统一表示，即我们定义的原始摘要向量。为确保原始摘要向量能够准确指导模型完成分类任务，需要训练分类器 C_p，使其能够识别摘要向量中包含的类别信息，该过程表示为 $\mathbf{P} = C_p(\mathbf{S})$。其中，$\mathbf{P} \in \mathbb{R}^{n \times L}$ 是分类器预测，并使用 Sigmoid 激活函数将输出值限制在 $[0, 1]$ 内。$\mathbf{S} = \left[\mathbf{s}_1^{\mathrm{T}} \mathbf{s}_2^{\mathrm{T}} \cdots \mathbf{s}_n^{\mathrm{T}}\right]^{\mathrm{T}} \in \mathbb{R}^{n \times d_z}$ 表示摘要向量的集合矩阵。最后，我们将缺失标签指示矩阵 $\mathbf{U}$ 纳入多标签分类任务中广泛使用的二元交叉熵损失，使模型能够在标签不完整的场景下比较预测与标签：

$$\mathcal{L}_c = -\frac{1}{nL} \sum_{i=1}^{n} \sum_{j=1}^{L} (\mathbf{Y}_{i,j} log(\mathbf{p}_{i,j}) + (1 - \mathbf{Y}_{i,j}) log(1 - \mathbf{p}_{i,j})) \mathbf{U}_{i,j} \quad (5)$$

其中，$\mathbf{p}_{i,j}$ 表示第 i 个样本的第 j 个标签的预测值。

标签引导扩散模块。由于视图不完整，视图编码模块获得的原始摘要向量可能在一定程度上无法充分表示所有视图的结果。因此，我们希望扩散模型作为当前最流行的生成模型，能够提供一些缺失视图的信息。我们的目标是基于伪标签生成全视图的合成摘要向量。对于给定样本 i，其标签集合为 $\mathcal{Y} = \{j \mid \mathbf{Y}_{i,j} = 1\}$。通过摘要向量编码模块中训练好的自编码器，可获得其原始摘要向量 $\mathbf{s} = F(E_1(\mathbf{x}_1), E_2(\mathbf{x}_2), \ldots, E_V(\mathbf{x}_V), \mathbf{W})$；为简洁起见，本节后续省略 i。此外，还可随机掩蔽某些视图，获得掩码摘要向量 $\bar{\mathbf{s}} = F(E_1(\mathbf{x}_1), E_2(\mathbf{x}_2), \ldots, E_V(\mathbf{x}_V), Mask(\mathbf{W}, k_{mask}))$，其中 $Mask(\cdot, \cdot)$ 是按掩码率 k_{mask} 随机掩蔽的函数。

为简化多标签任务，我们依次将 $\mathcal{Y}$ 中的每个标签与掩码摘要向量 $\bar{\mathbf{s}}$ 组合。以 $y \in \mathcal{Y}$ 为条件，将摘要向量 $\bar{\mathbf{s}}$ 视作 $\bar{\mathbf{s}}_0$，通过重参数化操作（Sohl-Dickstein et al. 2015）获得每个时间步 t 的加噪摘要向量 $\bar{\mathbf{s}}_t$：

$$q(\bar{\mathbf{s}}_t | \bar{\mathbf{s}}_0, y) = \mathcal{N}(\bar{\mathbf{s}}_t; \sqrt{\bar{\alpha}_t} \bar{\mathbf{s}}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (6)$$

其中 $\alpha_t = 1 - \beta_t$，$\bar{\alpha}_t = \prod_{i=1}^{t} \alpha_i$。在训练过程中，由 θ 参数化的扩散模型需要在时间步 t 和标签 y 的条件下，预测输入 $\bar{\mathbf{s}}_t$ 的去噪版本。这里，由于 $\bar{\mathbf{s}}$ 通过掩蔽某些视图获得，我们将其视为 $\mathbf{s}$ 的含噪版本：

$$\tilde{\epsilon} = \epsilon + \bar{\mathbf{s}} - \mathbf{s} \quad (7)$$

其中，ϵ 表示从标准高斯分布中采样的噪声。因此，可以将式（1）改写为：

$$\mathcal{L}_d = \mathbb{E}_{t,\mathbf{s},y,\tilde{\epsilon}}[||\tilde{\epsilon} - \epsilon_\theta(\bar{\mathbf{s}}_t, t, y)||^2] \quad (8)$$

最终预测模块。为将得到的原始和合成摘要向量组合为一个统一表示，我们采用自适应加权融合方法。融合向量随后被输入新的分类器 C_f，生成最终预测，过程如下：

$$\mathbf{F} = C_f(l_{ori}\mathbf{s} + l_{syn}\mathbf{s}^d) \quad (9)$$

其中，l_{ori} 与 l_{syn} 为可学习的标量权重，$\mathbf{s}$ 和 $\mathbf{s}^d$ 分别为原始和合成摘要向量，$\mathbf{F} \in \mathbb{R}^{n\times L}$ 表示最终预测。该模块使用与式（5）同形式的损失函数，记作 $\mathcal{L}_f$。

模型推理

冗余视图识别策略。根据视图冗余现象，去除冗余视图会使摘要向量更有判别性。然而，如何识别冗余视图是我们首先关注的问题。为克服这一挑战，我们设计了冗余视图识别策略。

识别冗余视图的一种直观方式，是将当前处理的视图与其他视图分离，并观察该操作对摘要向量的影响。具体而言，对于正在处理的视图 v，我们将其原始视图组合 $\mathbf{W}$ 拆分为单视图组合 $\mathbf{W}_v^o$ 和剩余视图组合 $\mathbf{W}_v^r$：

$$\mathbf{W}_{i,1}^o = 0, \mathbf{W}_{i,2}^o = 0, \ldots, \mathbf{W}_{i,v}^o = 1, \ldots, \mathbf{W}_{i,V}^o = 0 \quad (10)$$

$$\mathbf{W}_{i,1}^r = \mathbf{W}_{i,1}, \ldots, \mathbf{W}_{i,v}^r = 0, \ldots, \mathbf{W}_{i,V}^r = \mathbf{W}_{i,V} \quad (11)$$

注意，我们仅处理存在的视图，因此 $\mathbf{W}_{i,v} \neq 0$。对于第 i 个样本，视图编码模块可以利用这些组合生成不同的摘要向量，即原始摘要向量 $\mathbf{s}_i^a$、普通摘要向量 $\mathbf{s}_{i,v}^o$ 和剩余摘要向量 $\mathbf{s}_{i,v}^r$。后两者分别为：

$$\mathbf{s}_{i,v}^o = F\left(E_1(\mathbf{x}_{i,1}),\ E_2(\mathbf{x}_{i,2}),\ \ldots,\ E_V(\mathbf{x}_{i,V}),\ \mathbf{W}_v^o\right)$$

$$\mathbf{s}_{i,v}^r = F\left(E_1(\mathbf{x}_{i,1}),\ E_2(\mathbf{x}_{i,2}),\ \ldots,\ E_V(\mathbf{x}_{i,V}),\ \mathbf{W}_v^r\right)$$

现在，需要评估这种分离的影响。在视图编码模块中，我们获得伪标签 $\widehat{\mathbf{Y}} \in \mathbb{R}^{n\times L}$ 和分类器 C_p。由于分类器能够识别摘要向量中的类别信息，它是衡量这种影响的最直观工具之一。因此，我们设计了一个新的评价指标，称为保真度分数：

$$\mathcal{F}(\mathbf{s}, \hat{\mathbf{y}}) = precision(C_p(\mathbf{s}), \hat{\mathbf{y}}) \quad (12)$$

其中，$precision(\cdot,\cdot)$ 是多标签分类精确率函数。在一个数据集中，若第 i 个样本的第 v 个视图的普通摘要向量与剩余摘要向量相对于伪标签的保真度分数，都显著高于数据集内的平均分数，就意味着该组合没有引入额外信息，说明原始视图组合可以拆开。

然而，这种考虑忽略了各个样本不同的难度。由于数据集的长尾效应，并非所有标签都以相同频率出现，因此模型对某些标签更容易预测，即使丢失视图结构信息，也能匹配大多数伪标签。标签引导扩散模块生成的合成摘要向量，包含该标签的全视图信息以及随机噪声，因而非常适合用作评估样本难度的参照。对于第 i 个样本第 j 类的伪标签 $\widehat{y} \in \widehat{\mathcal{Y}} = \{j \mid \widehat{y}_j^i = 1\}$，其反向去噪过程可根据式（2）改写为：

$$\mu_\theta(\mathbf{s}, t, \hat{y}) = \frac{1}{\sqrt{\alpha_t}}(\mathbf{s}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(\mathbf{s}_t, t, \hat{y})) \tag{13}$$

$$\mathbf{s}_{t-1} = \mu_\theta(\mathbf{s}, t, \hat{y}) + \sqrt{\Sigma_\theta(\mathbf{s}_t, t)}\mathbf{m}, \quad \mathbf{m} \sim \mathcal{N}(0, \mathbf{I}) \tag{14}$$

我们将 $\widehat{y}$ 引导下生成的 $\mathbf{s}_0$ 定义为 $\mathbf{s}_{\widehat{y}}$，则第 i 个样本的合成摘要向量可按下式计算：

$$\mathbf{s}_i^d = \frac{1}{|\hat{\mathcal{Y}}|}\sum_{\hat{y}\in\hat{\mathcal{Y}}}\mathbf{s}_{\hat{y}} \tag{15}$$

当第 i 个样本的合成摘要向量相对于其伪标签的保真度分数显著低于数据集平均分数时，说明该样本对于模型尤其困难。因此，我们按下式识别冗余视图：

$$\mathcal{R}_v = \{i|(\mathcal{F}(\mathbf{s}_{i,v}^o, \hat{\mathbf{y}}^i) > \mu_o + k_{sig}\sigma_o) \wedge (\mathcal{F}(\mathbf{s}_{i,v}^r, \hat{\mathbf{y}}^i) > \mu_r + k_{sig}\sigma_r) \wedge (\mathcal{F}(\mathbf{s}_i^d, \hat{\mathbf{y}}^i) < \mu_d - k_{sig}\sigma_d)\} \tag{16}$$

其中，(μ_o, σ_o)、(μ_r, σ_r) 和 (μ_d, σ_d) 分别表示普通、剩余与合成摘要向量的保真度分数的均值和方差；k_{sig} 表示方差乘数；$\mathcal{R}_v$ 为视图 v 被判定为冗余的样本索引集合。该模块去除集合 $\mathcal{R}_v$ 中索引对应的样本视图，并用 $\mathbf{s}^r$ 和 $\mathbf{W}_v^r$ 替换 $\mathbf{s}^a$ 与 $\mathbf{W}$。此过程按视图1到视图 V 的顺序持续重复，每完成一轮循环，k_{sig} 增加一个固定值。当 $\mathcal{R}_v$ 变为空集时，循环结束。

最终预测。最后，我们将 $\mathbf{s}_i^a$ 和 $\mathbf{s}_i^d$ 输入最终预测模块，获得最终预测 $\mathbf{f}_i \in \mathbb{R}^L$：

$$\mathbf{f}_i = C_f(l_{ori}\mathbf{s}_i^a + l_{syn}\mathbf{s}_i^d) \tag{17}$$

实验

实验设置

数据集。 我们采用 Tan et al.（2018）建议的方法评估 DiffSumm 的有效性。评估包含以下数据集：Corel 5k（Duygulu et al. 2002）是图像标注与检索领域公认的基准，包含5,000张图像和260个标签。Pascal07（Everingham et al. 2010），也称 PASCAL VOC 2007，是视觉对象分类领域的重要数据集，包含9,963张图像和20个标签。Espgame（von Ahn and Dabbish 2004）源自参与者为图像添加标签的在线游戏，包含20,770张图像和268个标签。IAPRTC12（Grubinger et al. 2006）面向全局图像标注挑战设计，包含约20,000张图像，涵盖290个类别。Mirflickr（Huiskes and Lew 2008）包含25,000张图像与38个标签，具有多样的主题和对象。我们将图像转换为六种不同视图，即 GIST、HSV、HUE、LAB、RGB 和 SIFT，每种视图突出不同的视觉特征，提供对视觉内容的独特理解。

评价指标。 我们使用平均精确率（AP）、排序损失（RL）、汉明损失（HL）及曲线下面积（AUC）进行评估。为简化比较，采用 HL 和 RL 的补值，即 1-HL 和 1-RL。分数越高，性能越好。

实现细节。 模型架构方面，我们采用两个各含四个全连接层的多层感知机，分别作为自编码器的编码器和解码器。对于扩散模型，使用带交叉注意力机制的 UNet（Ronneberger, Fischer, and Brox 2015），与 Rink et al.（2021）中描述的机制类似，共含五个卷积层。为模拟不完整场景，我们随机删除每个数据集中数据的50%视图。在每个类别内，随机将50%的正标签和50%的负标签标记为不可用。所有实验中的掩码率 k_{mask} 均设为0.25。为验证结果的可靠性，每个实验运行10次，并计算结果的均值和方差。

比较方法。 我们将本方法与十种基准方法比较。其中八种方法——lrMMC、MVL-IV、iMSF、iMvWL、NAIML、DDINet、DICNet 和 LMVCAT——已在相关工作部分详细讨论。值得注意的是，iMvWL 和 NAIML 是针对视图和标签不完整场景设计的，因此需要调整其他方法以保证一致性。受 Li and Chen（2022）启发，对于 lrMMC，我们使用可用视图的均值补偿缺失视图。对于 MVL-IV 和 iMSF，假定缺失标签为负标签。此外，我们设计仅以伪标签为条件来引导扩散模型生成合成摘要向量并进行预测的方法，命名为 DiffOnly。我们遵循各方法已发表论文或可用代码库中建议的参数设置，以确保公平比较。

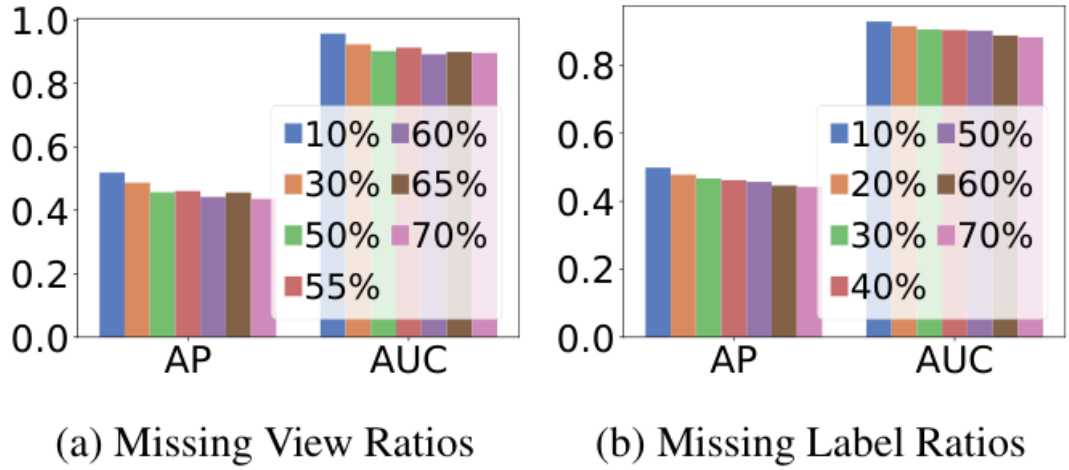
Dataset	Metric	lrMMC	MVL-IV	iMSF	iMvWL	NAIML	DDINet	DICNet	LMVCAT	DiffOnly	DiffSumm
Corel5k	AP	24.0±0.2	24.0±0.1	18.9±0.2	28.3±0.7	30.9±0.4	36.4±0.1	38.1±0.4	*38.4±0.4*	38.2±0.2	**45.7±0.1**
	1-RL	76.2±0.2	75.6±0.1	70.9±0.5	86.5±0.3	87.8±0.2	87.1±0.0	*88.2±0.4*	88.0±0.2	87.8±0.1	**89.3±0.1**
	1-HL	95.4±0.0	95.4±0.0	94.3±0.0	97.8±0.0	*98.7±0.0*	*98.7±0.0*	**98.8±0.0**	98.6±0.0	**98.8±0.0**	**98.8±0.0**
	AUC	76.3±0.2	76.2±0.1	66.3±0.5	86.8±0.3	88.1±0.2	87.5±0.1	*88.4±0.4*	88.3±0.2	88.2±0.2	**90.2±0.1**
Pascal07	AP	42.5±0.3	43.3±0.2	32.5±0.0	44.1±1.7	48.8±0.3	*53.6±0.2*	50.5±1.2	51.9±0.5	50.0±0.2	**56.1±0.1**
	1-RL	69.8±0.3	70.2±0.1	56.8±0.0	73.7±0.9	78.3±0.1	80.7±0.1	78.3±0.8	*81.1±0.4*	78.9±0.5	**84.5±0.1**
	1-HL	88.2±0.0	88.3±0.0	83.6±0.0	88.2±0.0	92.8±0.1	93.2±0.0	92.9±0.1	*99.7±0.0*	*99.7±0.0*	**99.8±0.0**
	AUC	72.8±0.2	73.0±0.1	68.6±0.5	78.6±0.3	76.7±1.2	82.7±0.0	*87.6±0.2*	83.4±0.4	87.4±0.2	**88.6±0.1**
Espgame	AP	18.8±0.0	18.9±0.0	10.8±0.0	24.2±0.3	24.6±0.2	28.3±0.1	29.7±0.2	29.4±0.4	*30.6±0.2*	**36.3±0.2**
	1-RL	77.7±0.1	77.8±0.0	72.2±0.2	80.7±0.1	81.8±0.2	81.5±0.0	83.2±0.1	82.8±0.2	*83.4±0.1*	**87.8±0.1**
	1-HL	97.0±0.0	97.0±0.0	96.4±0.0	97.2±0.0	*98.3±0.0*	*98.3±0.0*	*98.3±0.0*	98.1±0.0	98.2±0.0	**98.6±0.0**
	AUC	78.3±0.1	78.4±0.1	67.4±0.3	81.3±0.2	82.4±0.2	82.0±0.1	*83.2±0.1*	82.8±0.2	82.8±0.1	**84.5±0.1**
IAPRTC12	AP	19.7±0.0	19.8±0.0	10.1±0.0	23.5±0.4	26.1±0.1	30.3±0.2	32.3±0.1	31.7±0.3	*35.2±0.2*	**37.9±0.1**
	1-RL	80.1±0.0	79.9±0.1	63.1±0.0	83.3±0.3	84.8±0.1	85.3±0.1	87.3±0.1	87.0±0.1	*88.2±0.1*	**89.0±0.2**
	1-HL	96.7±0.0	96.7±0.0	96.0±0.0	96.9±0.0	*98.1±0.0*	98.0±0.0	*98.1±0.0*	97.9±0.0	98.0±0.0	**98.2±0.0**
	AUC	80.5±0.0	80.4±0.1	66.5±0.1	83.6±0.2	85.0±0.1	85.4±0.0	*87.4±0.1*	87.2±0.1	87.3±0.1	**88.4±0.1**
Mirflickr	AP	44.1±0.1	44.9±0.1	32.3±0.0	49.5±1.2	55.1±0.2	59.8±0.2	58.9±0.5	59.4±0.5	*60.5±0.4*	**64.6±0.2**
	1-RL	80.5±0.0	80.4±0.1	66.5±0.1	83.6±0.2	85.0±0.1	86.3±0.0	86.3±0.4	*86.5±0.3*	86.4±0.2	**89.2±0.3**
	1-HL	83.9±0.0	83.9±0.0	77.5±0.0	84.0±0.3	88.2±0.1	*88.8±0.0*	88.8±0.2	87.6±0.2	*88.8±0.0*	**89.0±0.1**
	AUC	80.6±0.1	80.7±0.0	76.1±0.1	79.4±1.5	83.7±0.1	85.2±0.1	84.9±0.4	*85.3±0.3*	84.6±0.2	**86.9±0.2**

表1： 各方法在五个数据集上、实例与标签均缺失50%时的结果。最优结果以粗体标记，次优结果以斜体标记。为简洁起见，后续部分省略百分号。表头 Dataset 为“数据集”，Metric 为“指标”；各方法名、指标缩写、数值、误差项与强调格式均原样保留。

实验结果

表1给出了这些方法在所有数据集上的实验结果，训练样本比例为70%，视图与标签的缺失比例均为50%。从表中可以看出，DiffSumm 在所有数据集的所有指标上均优于其他方法。此外，包括 DDINet、DICNet 和 LMVCAT 在内的深度学习模型优于前五种方法，说明深度学习在解决此问题上具有很大潜力。另外，DiffOnly 在一些数据集上取得次优结果，表明合成摘要向量确实为分类器提供了额外的有用信息。

图2展示了模型在不同视图和标签缺失比例下的性能。从图2a可以看到，在某一范围的视图缺失比例内，缺失比例增加并不会导致模型性能下降。这一结果可由我们发现的视图冗余现象解释。该发现还表明，训练过程中掩蔽部分视图有可能增强模型性能。图2b显示，随着标签缺失比例增加，模型性能持续下降，说明更多标签信息有助于模型学习。这可能是因为标签具有明确的类别，噪声不太容易严重扰乱这类信息。

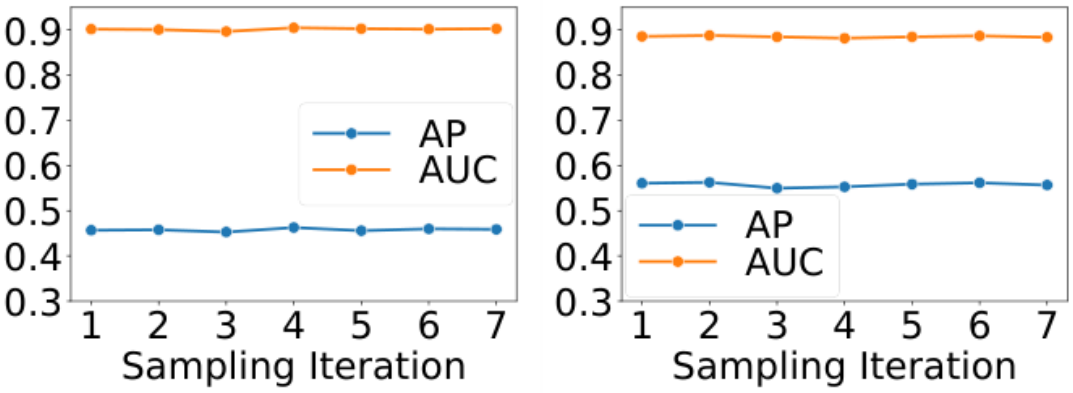


(a) Missing View Ratios (b) Missing Label Ratios

图2： Corel5k 数据集在两种场景下的结果：（a）保持标签缺失比例为50%，改变视图缺失比例；（b）固定视图缺失比例为50%，改变标签缺失比例。Missing View Ratios：视图缺失比例；Missing Label Ratios：标签缺失比例；AP、AUC 为评价指标。图例保留原比例。

参数分析

我们评估模型中的两个超参数：扩散模型采样迭代次数和方差乘数 k_{sig}，结果如图所示。当采用多次扩散模型采样迭代、并对全部采样结果取平均的策略时，可获得图3所示结果。可以观察到，采样迭代次数与模型性能之间似乎不存在直接相关关系。这可能是因为，在有限的采样迭代次数下，扩散模型固有的随机噪声无法在如此小的规模上被有效消除。此外，我们的框架也包含平均操作，在一定程度上可以替代这一过程。



(a) Corel5k (b) Pascal07

图3： 不同数据集上，采用不同采样迭代次数所得的结果。（a）Corel5k；（b）Pascal07。Sampling Iteration：采样迭代次数。图例为 AP、AUC。

针对 k_{sig}，我们设计了多种方法进行评估，即固定值、累加和累乘。固定值方法（F）是在不同轮次中保持相同的 k_{sig} 值；累加方法（CA-x）指每轮将 k_{sig} 增加固定量 x；累乘方法（CM-x）则指每轮将 k_{sig} 乘以固定值 x。实验中，固定值方法在第1—3轮将 k_{sig} 设为1，第4—6轮设为2，超过6轮后设为3；累加实验从1开始，分别在每轮增加0.25、0.5或1；累乘实验从1开始，分别在每轮乘以1.25、1.5或2。

考虑到标签引导扩散模块的生成过程较慢，评估时还需考虑循环结束所需轮数，综合结果见图4。可以观察到，固定值方法取得中等精度，但由于需要根据不同数据集的轮数调整固定值，其实用性有限。累加方法精度较高，但需要更多迭代才能结束循环，因此消耗更多计算资源。累乘方法数值增长迅速，结束循环所需轮数较少，但精度较低。这可能是因为各轮的取值较大，从而漏掉了原本可能识别出的某些冗余视图。综合考虑精度和计算成本，我们最终选择每轮增加0.5作为 k_{sig} 的设置方式。

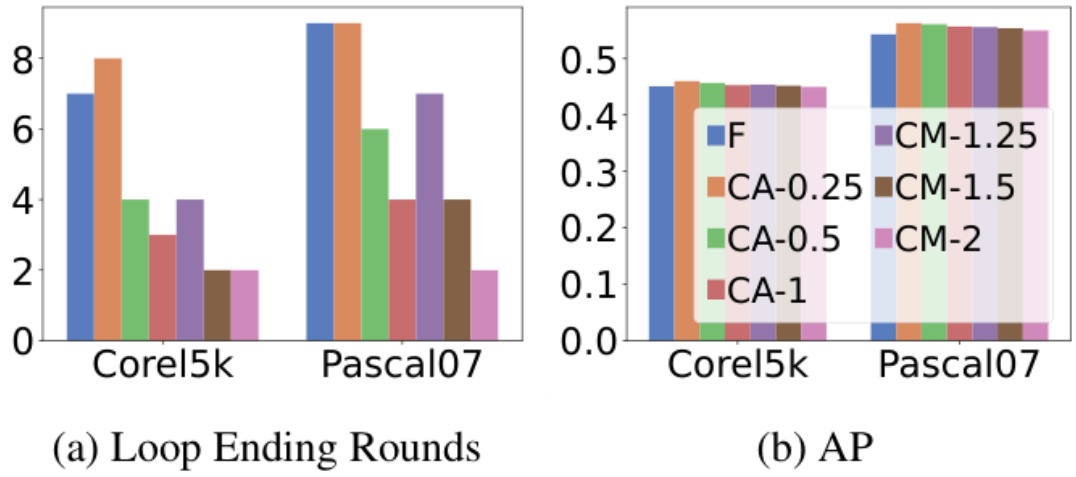


图4： 不同数据集上，使用不同方法确定 k_{sig} 值的结果。（a）Loop Ending Rounds：循环结束轮数；（b）AP。图例：F 为固定值，CA-0.25、CA-0.5、CA-1 为相应增量的累加，CM-1.25、CM-1.5、CM-2 为相应倍数的累乘。

消融研究

针对冗余视图识别，我们设计以下变体。**基于统计规律（SR）**：记录训练期间不同视图组合的性能，据此推导某些组合形成冗余视图的概率；然后在推理时，若出现这样的组合，则按该概率将其识别为冗余并去除。**基于摘要向量相似性（SoSV）**：计算摘要向量之间的余弦相似度，以替代保真度分数，再据此识别冗余视图。**不使用合成摘要向量作为参照（NSSV）**：省略“合成摘要向量与伪标签之间的保真度分数显著低于某一值”这一条件。表2记录了这些变体与本方法的性能。表中，NSSV 的性能最差，验证了我们关于评估样本难度必要性的观点。SoSV 次之，说明保真度分数在一定程度上等同于相似性。然而，保真度分数具有更清晰的语义和更明确的信息，因此优于直接使用相似性。

Method	Corel5k		Espgame		IAPRTC12	
	AP	AUC	AP	AUC	AP	AUC
SR	40.7	89.8	31.9	83.5	34.5	87.1
SoSV	45.0	90.0	35.9	84.4	37.5	88.2
NSSV	37.5	87.6	29.8	83.6	32.2	87.5
DiffSumm	45.7	90.2	36.3	84.5	37.9	88.4

表2： 不同冗余视图识别变体的结果。Method：方法；其余表头为数据集和指标名称。完整数值按原表保留。

随后，我们测试各个模块的有效性，包括视图编码模块（V）、标签引导扩散模块（L）、冗余视图识别策略（R）和最终预测模块（F）。我们在三个数据集上进行测试，结果见表3。可以看出，框架中的每个模块都发挥了重要作用。

Method	Corel5k		Espgame		IAPRTC12	
	AP	AUC	AP	AUC	AP	AUC
V	36.7	87.6	28.6	82.1	30.8	85.2
V+L (DiffOnly)	38.2	88.2	30.6	82.8	35.2	87.3
V+L+R+F (DiffSumm)	45.7	90.2	36.3	84.5	37.9	88.4

表3： 各模块有效性的实验结果。Method：方法；V、L、R、F 的含义如上；V+L 对应 DiffOnly，V+L+R+F 对应 DiffSumm。完整数值按原表保留。

结论

本文探索利用扩散模型辅助解决不完整多视图多标签分类问题与视图冗余现象。我们提出 DiffSumm 框架，其中包含用于获取摘要向量并基于该向量生成伪标签的视图编码模块、用于生成合成摘要向量的标签引导扩散模块，以及用于识别和去除冗余视图的策略。实验证据表明，所提 DiffSumm 能够有效解决该问题，扩散模型也能够高效生成具有判别性的摘要向量。

致谢

本工作得到国家自然科学基金（62422202、62272058、U23A20319、62192784）及北京市自然科学基金（4242027）资助。Xuyun Zhang、Amin Beheshti 和 Yuankai Qi 未获得上述基金资助。

参考文献

下列原稿书目保留全部作者、年份、英文题名、会议或期刊、卷号及页码，随后给出每条文献题名的中文对照。原文第8页顶部左栏含已在上文译出的致谢；第9页仅有末四条参考文献。

Acknowledgments

This work was supported by the National Natural Science Foundation of China (62422202, 62272058, U23A20319, 62192784), and Beijing Natural Science Foundation (4242027). Xuyun Zhang, Amin Beheshti, and Yuankai Qi are not supported by the above mentioned funds.

References

Chen, M.; Liu, T.; Wang, C.; Huang, D.; and Lai, J. 2022. Adaptively-weighted Integral Space for Fast Multiview Clustering. In *MM '22*, 3774–3782.

Duygulu, P.; Barnard, K.; de Freitas, J. F. G.; and Forsyth, D. A. 2002. Object Recognition as Machine Translation: Learning a Lexicon for a Fixed Image Vocabulary. In *ECCV 2002*, volume 2353, 97–112.

Everingham, M.; Gool, L. V.; Williams, C. K. I.; Winn, J. M.; and Zisserman, A. 2010. The Pascal Visual Object Classes (VOC) Challenge. *Int. J. Comput. Vis.*, 88: 303–338.

Fang, Z.; and Zhang, Z. 2012. Simultaneously combining multi-view multi-label learning with maximum margin classification. In *ICDM 2012*, 864–869.

Grubinger, M.; Clough, P.; Müller, H.; and Deselaers, T. 2006. The IAPR TC12 Benchmark: A New Evaluation Resource for Visual Information Systems. *Workshop Ontoimage*.

Ho, J.; Jain, A.; and Abbeel, P. 2020. Denoising Diffusion Probabilistic Models. In *NeurIPS 2020*.

Ho, J.; and Salimans, T. 2022. Classifier-Free Diffusion Guidance. *CoRR*, abs/2207.12598.

Huiskes, M. J.; and Lew, M. S. 2008. The MIR flickr retrieval evaluation. In *ACM SIGMM MIR 2008*, 39–43.

Li, Q.; Luo, T.; Jiang, M.; Liao, J.; and Jiang, Z. 2024. Deep Incomplete Multi-View Network Semi-Supervised Multi-Label Learning with Unbiased Loss. In *MM 2024*, 9048–9056.

Li, X.; and Chen, S. 2022. A Concise Yet Effective Model for Non-Aligned Incomplete Multi-View and Missing Multi-Label Learning. *IEEE TPAMI*, 44: 5918–5932.

Liu, C.; Wen, J.; Luo, X.; Huang, C.; Wu, Z.; and Xu, Y. 2023a. DICNet: Deep Instance-Level Contrastive Network for Double Incomplete Multi-View Multi-Label Classification. In *AAAI 2023*, 8807–8815.

Liu, C.; Wen, J.; Luo, X.; and Xu, Y. 2023b. Incomplete Multi-View Multi-Label Learning via Label-Guided Masked View- and Category-Aware Transformers. In *AAAI 2023*, 8816–8824.

Liu, M.; Luo, Y.; Tao, D.; Xu, C.; and Wen, Y. 2015. Low-Rank Multi-View Learning in Matrix Completion for Multi-Label Image Classification. In *AAAI 2015*, 2778–2784.

Nichol, A. Q.; Dhariwal, P.; Ramesh, A.; Shyam, P.; Mishkin, P.; McGrew, B.; Sutskever, I.; and Chen, M. 2022. GLIDE: Towards Photorealistic Image Generation and Editing with Text-Guided Diffusion Models. In *ICML 2022*, volume 162, 16784–16804.

Ou, S.; Xue, Z.; Li, Y.; Liang, M.; Cai, Y.; and Wu, J. 2024. View-Category Interactive Sharing Transformer for Incomplete Multi-View Multi-Label Learning. In *CVPR 2024*, 27457–27466.

Rink, N. A.; Paszke, A.; Vytiniotis, D.; and Schmid, G. S. 2021. Memory-efficient array redistribution through portable collective communication. *CoRR*, abs/2112.01075.

Rombach, R.; Blattmann, A.; Lorenz, D.; Esser, P.; and Ommer, B. 2022. High-Resolution Image Synthesis with Latent Diffusion Models. In *CVPR 2022*, 10674–10685.

Ronneberger, O.; Fischer, P.; and Brox, T. 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation. In *MICCAI 2015*, volume 9351, 234–241.

Saharia, C.; Chan, W.; Saxena, S.; Li, L.; Whang, J.; Denton, E. L.; Ghasemipour, S. K. S.; Lopes, R. G.; Ayan, B. K.; Salimans, T.; Ho, J.; Fleet, D. J.; and Norouzi, M. 2022. Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding. In *NeurIPS 2022*.

Sohl-Dickstein, J.; Weiss, E. A.; Maheswaranathan, N.; and Ganguli, S. 2015. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. In *ICML 2015*, volume 37, 2256–2265.

Song, J.; Meng, C.; and Ermon, S. 2021. Denoising Diffusion Implicit Models. In *ICLR 2021*.

Sun, Y.; Xu, Q.; Wang, Z.; Yang, Z.; and He, J. 2024. EDGE: Unknown-aware Multi-label Learning by Energy Distribution Gap Expansion. arXiv:2412.07499.

Tan, Q.; Yu, G.; Domeniconi, C.; Wang, J.; and Zhang, Z. 2018. Incomplete Multi-View Weak-Label Learning. In *IJCAI 2018*, 2703–2709.

Tang, H.; and Liu, Y. 2022. Deep Safe Multi-view Clustering: Reducing the Risk of Clustering Performance Degradation Caused by View Increase. In *CVPR 2022*, 202–211.

Tao, H.; Hou, C.; Liu, X.; Liu, T.; Yi, D.; and Zhu, J. 2018. Reliable Multi-View Clustering. In *AAAI-18*, 4123–4130.

Trosten, D. J.; Løkse, S.; Jenssen, R.; and Kampffmeyer, M. 2021. Reconsidering Representation Alignment for Multi-View Clustering. In *CVPR 2021*, 1255–1265.

von Ahn, L.; and Dabbish, L. 2004. Labeling images with a computer game. In *CHI 2004*, 319–326.

Wang, Q.; Ding, Z.; Tao, Z.; Gao, Q.; and Fu, Y. 2021. Generative partial multi-view clustering with adaptive fusion and cycle consistency. *IEEE TIP*, 30: 1771–1783.

Wang, Q.; Tao, Z.; Gao, Q.; and Jiao, L. 2022. Multi-View Subspace Clustering via Structured Multi-Pathway Network. *IEEE TNNLS*.

Wen, J.; Liu, C.; Deng, S.; Liu, Y.; Fei, L.; Yan, K.; and Xu, Y. 2023. Deep Double Incomplete Multi-View Multi-Label Learning With Incomplete Labels and Missing Views. *IEEE TNNLS*.

Wen, J.; Zhang, Z.; Zhang, Z.; Wu, Z.; Fei, L.; Xu, Y.; and Zhang, B. 2020. DIMC-net: Deep Incomplete Multi-view Clustering Network. In *MM '20*, 3753–3761.

Xu, C.; Tao, D.; and Xu, C. 2015. Multi-view learning with incomplete views. *IEEE TIP*, 24: 5812–5825.

Yuan, L.; Wang, Y.; Thompson, P. M.; Narayan, V. A.; and Ye, J. 2012. Multi-source feature learning for joint analysis of incomplete multiple heterogeneous neuroimaging data. *NeuroImage*, 61: 622–632.

Yue, Z.; Ye, F.; Zhang, Y.; Liang, C.; and Tsang, I. W. 2021. Deep Safe Multi-Task Learning. *arXiv preprint arXiv:2111.10601*.

Zhang, W.; Zhang, K.; Gu, P.; and Xue, X. 2013a. Multi-View Embedding Learning for Incompletely Labeled Data. In *IJCAI 2013*, 1910–1916.

Zhang, Y.; Zhang, H.; Nasrabadi, N. M.; and Huang, T. S. 2013b. Multi-metric learning for multi-sensor fusion based classification. *Inf. Fusion*, 14: 431–440.

参考文献题名中文对照（依原文书目顺序）

1. Chen, M.; Liu, T.; Wang, C.; Huang, D.; and Lai, J. 2022. **用于快速多视图聚类的自适应加权整体空间**。MM ’22，3774–3782。
2. Duygulu, P.; Barnard, K.; de Freitas, J. F. G.; and Forsyth, D. A. 2002. **将对象识别视为机器翻译：为固定图像词汇学习词典**。ECCV 2002，卷2353，97–112。
3. Everingham, M.; Gool, L. V.; Williams, C. K. I.; Winn, J. M.; and Zisserman, A. 2010. **Pascal 视觉对象类别（VOC）挑战**。International Journal of Computer Vision，88：303–338。
4. Fang, Z.; and Zhang, Z. 2012. **将多视图多标签学习与最大间隔分类同时结合**。ICDM 2012，864–869。
5. Grubinger, M.; Clough, P.; Müller, H.; and Deselaers, T. 2006. **IAPR TC12 基准：面向视觉信息系统的新评价资源**。Ontoimage 研讨会。
6. Ho, J.; Jain, A.; and Abbeel, P. 2020. **去噪扩散概率模型**。NeurIPS 2020。
7. Ho, J.; and Salimans, T. 2022. **无分类器扩散引导**。CoRR，abs/2207.12598。
8. Huiskes, M. J.; and Lew, M. S. 2008. **MIR flickr 检索评估**。ACM SIGMM MIR 2008，39–43。

9. Li, Q.; Luo, T.; Jiang, M.; Liao, J.; and Jiang, Z. 2024. **采用无偏损失的深度不完整多视图网络半监督多标签学习**。MM 2024，9048–9056。
10. Li, X.; and Chen, S. 2022. **面向非对齐不完整多视图与缺失多标签学习的简洁有效模型**。IEEE TPAMI，44：5918–5932。
11. Liu, C.; Wen, J.; Luo, X.; Huang, C.; Wu, Z.; and Xu, Y. 2023a. **DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络**。AAAI 2023，8807–8815。
12. Liu, C.; Wen, J.; Luo, X.; and Xu, Y. 2023b. **通过标签引导的掩码视图与类别感知 Transformer 进行不完整多视图多标签学习**。AAAI 2023，8816–8824。
13. Liu, M.; Luo, Y.; Tao, D.; Xu, C.; and Wen, Y. 2015. **矩阵补全中的低秩多视图学习用于多标签图像分类**。AAAI 2015，2778–2784。
14. Nichol, A. Q.; Dhariwal, P.; Ramesh, A.; Shyam, P.; Mishkin, P.; McGrew, B.; Sutskever, I.; and Chen, M. 2022. **GLIDE：通过文本引导扩散迈向逼真图像生成与编辑**。ICML 2022，卷 162，16784–16804。
15. Ou, S.; Xue, Z.; Li, Y.; Liang, M.; Cai, Y.; and Wu, J. 2024. **用于不完整多视图多标签学习的视图—类别交互共享 Transformer**。CVPR 2024，27457–27466。
16. Rink, N. A.; Paszke, A.; Vytiniotis, D.; and Schmid, G. S. 2021. **通过可移植集合通信实现内存高效的数组重分布**。CoRR，abs/2112.01075。
17. Rombach, R.; Blattmann, A.; Lorenz, D.; Esser, P.; and Ommer, B. 2022. **利用潜在扩散模型进行高分辨率图像合成**。CVPR 2022，10674–10685。
18. Ronneberger, O.; Fischer, P.; and Brox, T. 2015. **U-Net：用于生物医学图像分割的卷积网络**。MICCAI 2015，卷9351，234–241。
19. Saharia, C.; Chan, W.; Saxena, S.; Li, L.; Whang, J.; Denton, E. L.; Ghasemipour, S. K. S.; Lopes, R. G.; Ayan, B. K.; Salimans, T.; Ho, J.; Fleet, D. J.; and Norouzi, M. 2022. **具有深度语言理解能力的逼真文本到图像扩散模型**。NeurIPS 2022。
20. Sohl-Dickstein, J.; Weiss, E. A.; Maheswaranathan, N.; and Ganguli, S. 2015. **利用非平衡热力学进行深度无监督学习**。ICML 2015，卷37，2256–2265。
21. Song, J.; Meng, C.; and Ermon, S. 2021. **去噪扩散隐式模型**。ICLR 2021。
22. Sun, Y.; Xu, Q.; Wang, Z.; Yang, Z.; and He, J. 2024. **EDGE：通过能量分布间隙扩展实现未知感知多标签学习**。arXiv:2412.07499。
23. Tan, Q.; Yu, G.; Domeniconi, C.; Wang, J.; and Zhang, Z. 2018. **不完整多视图弱标签学习**。IJCAI 2018，2703–2709。
24. Tang, H.; and Liu, Y. 2022. **深度安全多视图聚类：降低视图增加导致的聚类性能退化风险**。CVPR 2022，202–211。
25. Tao, H.; Hou, C.; Liu, X.; Liu, T.; Yi, D.; and Zhu, J. 2018. **可靠多视图聚类**。AAAI-18，4123–4130。
26. Trosten, D. J.; Løkse, S.; Jenssen, R.; and Kampffmeyer, M. 2021. **重新审视多视图聚类中的表示对齐**。CVPR 2021，1255–1265。
27. von Ahn, L.; and Dabbish, L. 2004. **通过计算机游戏标注图像**。CHI 2004，319–326。
28. Wang, Q.; Ding, Z.; Tao, Z.; Gao, Q.; and Fu, Y. 2021. **具有自适应融合和循环一致性的生成式部分多视图聚类**。IEEE TIP，30：1771–1783。
29. Wang, Q.; Tao, Z.; Gao, Q.; and Jiao, L. 2022. **通过结构化多路径网络进行多视图子空间聚类**。IEEE TNNLS。

30. Wen, J.; Liu, C.; Deng, S.; Liu, Y.; Fei, L.; Yan, K.; and Xu, Y. 2023. **具有不完整标签和缺失视图的深度双重不完整多视图多标签学习**。IEEE TNNLS。
31. Wen, J.; Zhang, Z.; Zhang, Z.; Wu, Z.; Fei, L.; Xu, Y.; and Zhang, B. 2020. **DIMC-net：深度不完整多视图聚类网络**。MM ’20，3753–3761。
32. Xu, C.; Tao, D.; and Xu, C. 2015. **具有不完整视图的多视图学习**。IEEE TIP，24：5812–5825。
33. Yuan, L.; Wang, Y.; Thompson, P. M.; Narayan, V. A.; and Ye, J. 2012. **用于联合分析不完整多种异构神经影像数据的多源特征学习**。NeuroImage，61：622–632。
34. Yue, Z.; Ye, F.; Zhang, Y.; Liang, C.; and Tsang, I. W. 2021. **深度安全多任务学习**。arXiv 预印本，arXiv:2111.10601。
35. Zhang, W.; Zhang, K.; Gu, P.; and Xue, X. 2013a. **面向不完整标注数据的多视图嵌入学习**。IJCAI 2013，1910–1916。
36. Zhang, Y.; Zhang, H.; Nasrabadi, N. M.; and Huang, T. S. 2013b. **用于基于多传感器融合分类的多度量学习**。Information Fusion，14：431–440。

译者校对注（非原文内容）

本文忠实保留原稿论述，不替作者修正内部不一致：正文称与“十种基准方法”比较，但表1共列出包含 DiffSumm 的十种方法；原文将 σ 称为“方差”，译文沿用该称呼；表1标题使用“缺失实例”，正文使用“缺失视图”；原文关于固定值策略的概述与按轮数分段取1、2、3的实验细节均保留；交叉注意力处对 Rink et al.（2021）的引用也按原稿保留。数学符号和公式（包括式13中参数写法）以原稿裁图为准，未据推测修改。