# 采用视图特定 Transformer 与增强伪标签的半监督多视图多标签学习

**Semi-Supervised Multi-View Multi-Label Learning with View-Specific Transformer and Enhanced Pseudo-Label**

Quanjiang Li[1]，Tingjin Luo[1]*，Mingdie Jiang[1]，Zhangqi Jiang[1]，Chenping Hou[1]，Feijiang Li[2]

[1] 国防科技大学理学院，中国湖南长沙 410073
[2] 山西大学大数据科学与产业研究院，中国山西太原 030006

liquanjiang@nudt.edu.cn；tingjinluo@hotmail.com；jiangmingdie20@nudt.edu.cn；jiangzq@nudt.edu.cn；hcpnudt@hotmail.com；fjli@sxu.edu.cn

· 通信作者。

第 39 届 AAAI 人工智能会议（AAAI-25），原文第 18430–18438 页。

Copyright © 2025, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.

**私人使用的非官方中文全译**。 来源仅为用户提供的 9 页 PDF；原文公式、图表以原页裁切保留，中文说明紧随其后。本文不主张开放许可，不用于公开发布。原文中的指标名称、公式和交叉引用不一致之处均予保留，并在译者说明中标注。

## 摘要

多视图多标签学习能够以丰富的表达和标注描述对象，因而已成为研究热点。然而，由于人工标注成本高昂且受技术限制，现实数据往往包含大量无标签实例。这一关键问题涉及三个主要挑战：i）如何从可用视图中提取高级语义？ii）如何在有限的已标注空间中构建精细的分类框架？iii）如何提供更多高质量监督信息？为解决这些问题，我们提出采用视图特定 Transformer 与增强伪标签的半监督多视图多标签学习方法，称为 SMVTEP。具体而言，采用生成对抗网络提取信息丰富的共享表示和特定表示，并通过对抗机制与基于信息论的对比学习保证其一致性和独特性。随后，为每个提取出的特征构建特定分类器，并施加实例级流形约束，减小分类器之间的偏差。此外，我们设计一种 Transformer 式融合方法，将置信度分数和类别语义融入自注意力机制，同时捕捉各视图表达能力的不平衡、对特定标签的映射效应以及标签依赖关系。进一步地，在利用 Mixup 进行数据增强之后，采用类别增强伪标签，使无标签样本的标签分布与真实分布对齐，从而提高附加标注的可靠性。最后，大量实验结果验证了 SMVTEP 相对于最先进方法的有效性。

# 引言

多标签学习广泛应用于文本分类（Chang et al. 2020）、图像标注（Sun and Xie 2024）和计算机视觉任务（Jung et al. 2024），因而受到越来越多关注。随着数据来源增加和特征提取方法进步，多视图数据已广泛可用，为全面描述观测目标提供了更多机会（Hu et al. 2023；Guan et al. 2024；Hu et al. 2024a）。例如，自动驾驶汽车整合摄像头、激光雷达和雷达的数据，以增强环境感知和行驶安全性（Xin et al. 2023）。此外，多视图数据包含丰富的观察角度（Hu et al. 2024b），可与多标签结合，表达复杂数据丰富的语义结构（Xiao et al. 2024）。因此，本文聚焦于多视图多标签分类（MvMLC）任务。

传统 MvMLC 方法假定给定数据完整，但这一假设在实践中往往不成立（Zhu et al. 2023）。受技术能力和资源成本限制，获取完全标注的数据并非易事。为处理多视图中的标签不足，MVEL-ILD（Zhang et al. 2013）利用标签相关性获得一致结果，而 DD-IMvMLC（Wen et al. 2023）引入缺失指示矩阵，关注可用标签信息。这些面向不完整数据的 MvMLC 方法主要处理多个标签的部分缺失，利用可用子集推断缺失标签。然而，现实中的多视图数据通常存在完全无标签的实例。例如，在医疗诊断中（Miller and Lowengrub 2022），资源可用性、患者状况多样性和诊断复杂性等因素会使许多记录仍然没有标签，进而可能降低诊断准确性与可靠性。大量视图和标签类别，再加上已标注样本不足，严重妨碍了模型部署对信息的需求，也给 MvMLC 方法带来重大冲击。因此，目前少有方法能够很好地解决这一棘手问题。实际上，解决半监督问题主要涉及利用大量无监督数据并提取充分的监督信息（Sun et al. 2021）。对于 MvMLC，目标是在有限标注空间中，获得与标签语义一致的高级特征表示，建立特征与特定标签之间的细粒度关联，并以最小噪声发掘标签类别之间的内在相关性以及额外标注。

为解决这些问题，我们提出采用视图特定 Transformer 与增强伪标签的半监督多视图多标签学习方法 SMVTEP。SMVTEP 的动机来自以下几个方面。1）多视图学习的重点是在捕获不同视图共享信息的同时，保留每个视图的独有信息（Sun and Wang 2024）。因此，采用生成对抗网络提取清晰且信息丰富的表示。此外，利用对抗机制实现共享特征的一致性，并应用基于信息论的对比学习限制特征交互，保持特定表示的独特性。2）每个视图都无法准确预测全部标签，而是擅长区分某个特定子集（Han et al. 2024）。因此，我们考虑为每个提取出的特征构建特定分类器，并根据特征与多标签预测之间的结构相似性施加流形约束，以减小不同分类器的偏差。3）在结果融合过程中，特征空间和标签空间各自的内在相关性以及映射语义都是关键因素。因此，利用由置信度分数与真实标签语义共同引导的 Transformer，捕捉共享视图和特定视图之间的相对重要性、每个视图对特定子类别的重要性以及标签间依赖关系。4）由于已标注样本稀缺，使用 Mixup 算法进行数据增强，防止模型过拟合。随后分配伪标签，以探索额外的监督信息。然而，多标签中的分布不平衡会使优势标签在伪标签中占据主导，并导致噪声累积（Su and Xu 2024）。为此，采用类别增强伪标签，保证无标签样本中每个类别的标签比例与已标注样本一致，从而使伪标签分布尽可能接近真实分布并提高可靠性。毫无疑问，SMVTEP 不仅能在有限标注环境中提取丰富的特征表示与深层语义关联，还能稳定提供高质量监督信息，因而十分适合多视图半监督多标签问题。我们的贡献概括如下：

- 据我们所知，这是首个以生成对抗网络与 Transformer 的应用为基础、能够处理多视图多标签数据中少量已标注实例的深度分类模型。
- SMVTEP 是统一框架，旨在获得语义不同的高级特征表示，构建具有判别力的分类技术，实现全面的后期融合机制，并提取可靠的监督信息。
- 大量实验结果表明，SMVTEP 持续优于其他方法，并证实其有效性和稳健性。

## 相关工作

### 不完整多视图多标签学习

处理 MvMLC 中的不完整数据最初依赖传统方法。iMVWL（Tan et al. 2018）利用弱标签相关性减轻标签缺失的影响。TM3L（Zhao et al. 2021）将标签矩阵补全与核极限学习机结合。NAIM3L（Li and Chen 2021）通过秩约束，同时利用不同视图之间的一致性及多标签之间的全局和局部结构。然而，这些浅层模型难以捕捉复杂的特征语义和标签相关性。近年来，基于深度学习的方法表现出显著性能。DICNet（Liu et al. 2023a）构建特征提取框架，并引入实例级对比学习以获得一致表示。LMVCAT（Liu et al. 2023b）利用基于 Transformer 的模块聚合特征，并通过标签引导的图约束处理缺失标签；VIST（Ou et al. 2024）则采用视图–类别交互共享 Transformer 和类别一致性引导的嵌入模块来提高判别能力。

### 半监督多标签学习

半监督多标签学习通常分为归纳式和直推式两类。归纳式学习纯粹依赖模型训练预测测试数据。Coins（Zhan and Zhang 2017）采用协同训练，结合特征空间划分与无标签数据上的成对排序，优化多标签分类。SCTML（Li et al. 2024）设计两层堆叠框架，在基础学习器和元学习器中捕捉标签相关性，并融合协同训练和流形假设。直推式学习假设测试数据来自无标签数据，并根据样本相似性传播标签。SSWL（Dong, Li, and Zhou 2018）融合多个模型以优化分类器。MSWL（Zhang et al. 2020）采用流形正则化稀疏模型从无标签数据中学习。ESMC（Akbarnejad and Baghshah 2018）采用由伪实例参数化的稀疏高斯模型，有效利用无标签数据。MGLP（Hu and Miao 2022）采用三支决策方法选择无标签数据，进一步进行标注。

## 方法

本节通过图 1 所示的四个方面阐述 SMVTEP：共享与特定信息提取、一致的视图特定标签学习、自适应标签引导 Transformer 融合，以及类别增强伪标签策略。

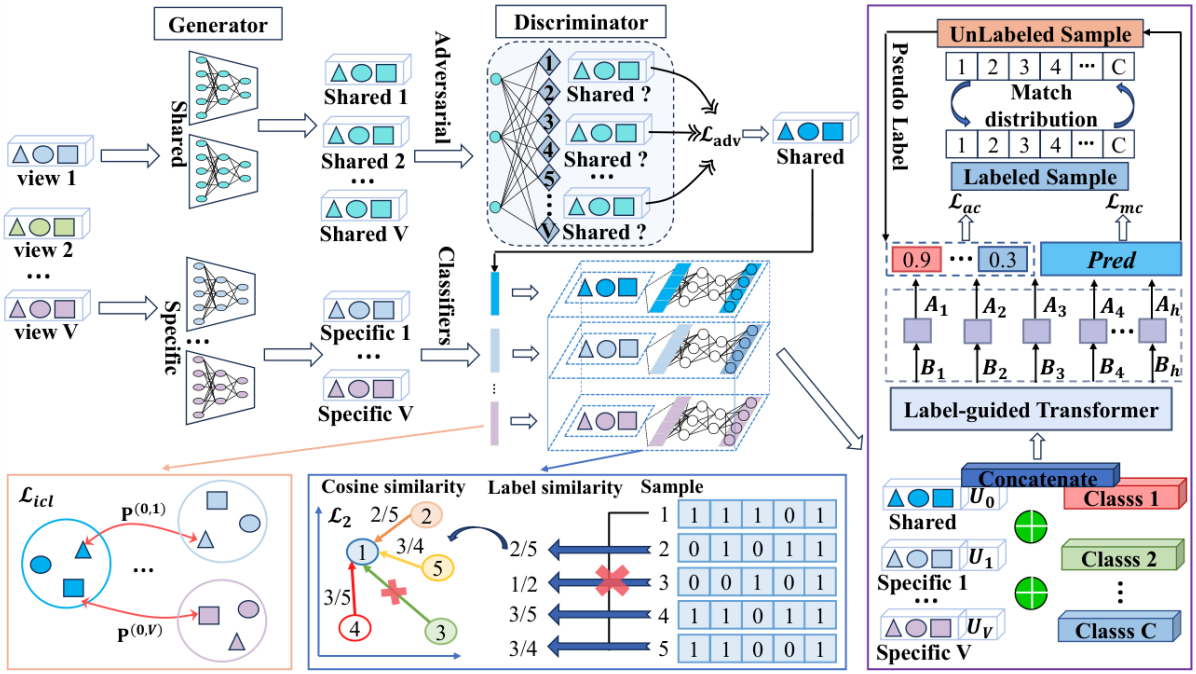



**图 1：** 所提出 SMVTEP 的主要框架。不同形状表示不同样本。图内文字：Generator＝生成器；Discriminator＝判别器；Shared＝共享；Specific＝特定；view＝视图；Adversarial＝对抗；Classifiers＝分类器；UnLabeled Sample＝无标签样本；Labeled Sample＝已标注样本；Pseudo Label＝伪标签；Match distribution＝分布匹配；Pred＝预测；Label-guided Transformer＝标签引导 Transformer；Cosine similarity＝余弦相似度；Label similarity＝标签相似度；Sample＝样本；Concatenate＝拼接；Class＝类别（原图写作 Classs）。所有变量、数值及连接关系保留原图。

## 符号与问题定义

具有 $N$ 个实例和 $V$ 个视图的多视图数据集定义为 $\mathcal{X} = \{\boldsymbol{X}^{(v)}\}_{v=1}^{V}$，其中 $\boldsymbol{X}^{(v)} = \{\boldsymbol{x}_i^{(v)}\}_{i=1}^{N} \in \mathbb{R}^{N \times d_v}$ 是第 $v$ 个视图的 $d_v$ 维特征矩阵。令 $\boldsymbol{Y} \in \{0, 1\}^{N \times C}$ 表示标签矩阵，其中 $C$ 为类别数。此外，$\boldsymbol{Y}_i \in \{0, 1\}^{C}$ 是标签向量；若样本 $i$ 属于类别 $j$，则 $\mathbf{Y}_{i,j} = 1$，否则 $\mathbf{Y}_{i,j} = 0$。已标注实例和无标签实例的数量分别为 $n_l$ 和 $n_u$，满足 $n_l \ll N$ 且 $n_l + n_u = N$。还分别以 $\mathcal{F}$ 和 $\mathcal{R}$ 表示已标注实例与无标签实例的索引空间。

## 共享与特定表示提取

从多视图数据学习具有表达力的表示，对于减少原始数据中的冗余和噪声以及促进信息整合至关重要（Jia et al. 2020）。因此，应充分利用共同语义表示和特定判别表示，以提高信息利用效率。为保证同一样本在多个视图中的底层表示一致，并保持各视图的独有贡献，我们采用生成对抗网络（Wu et al. 2019）学习共享子空间与特定子空间。生成器 $G$ 和 $R$ 用于将共同特征和特定特征提取到相同的 $M$ 维空间，即第 $v$ 个视图对应的表示为 $\mathbf{h}_c^v = G^v(\mathbf{x}^v)$ 和 $\mathbf{h}_s^v = R^v(\mathbf{x}^v)$。判别器 $D$ 是一个 $V$ 类分类器，用于判断生成的共享信息来自哪个原始视图。令 $\mathbf{z}_i^v$ 为指示 $\mathbf{h}_{c,i}^v$ 来源的 $V$ 维独热向量，其中仅第 $v$ 个元素等于 1，其余元素均为 0。记输出为 $\widehat{\mathbf{z}}_i^v = D\left(\mathbf{h}_{c,i}^v\right)$，可利用对抗损失混淆判别器：

$$\mathcal{L}_{adv} = \mathcal{F}\left(-\sum_{i=1}^{N}\sum_{v=1}^{V} \boldsymbol{z}_i^v \log \hat{\boldsymbol{z}}_i^v\right), \tag{1}$$

其中 $\mathcal{F}(\cdot)$ 是单调递减函数，我们设 $\mathcal{F}(x) = e^{-x}$。这样，判别器无法识别共享表示的真实视图，意味着不同视图的共享信息一致。因此，得到共享特征 $\mathbf{h}_c = \frac{1}{V}\sum_{l=1}^{V}\mathbf{h}_c^l$。为尽量减小共享信息与特定信息的重叠，大多数方法（Wu et al. 2019；Jia et al. 2020）采用几何正交约束。然而，不同视图之间的交互无疑比简单的线性几何关系更复杂。这种约束可能在特征提取中留下大量冗余信息。因此，我们采用信息论引导的对比学习（Lin et al. 2022），直接约束二者的互信息，以稳定限制复杂交互。为计算互信息，使用 Softmax 激活函数 $\sigma_s$ 构造分布概率向量 $\widetilde{\mathbf{h}}_{c,i}$ 和 $\widetilde{\mathbf{h}}_{s,i}^v$（Peng et al. 2019）。换言之，$\widetilde{\mathbf{h}}_c$ 和 $\widetilde{\mathbf{h}}_s^v$ 可解释为 $M$ 个类别上的两个离散聚类分配变量。于是，联合概率分布计算如下：

$$\boldsymbol{P}^{(v,c)} = \sum_{i=1}^{N}\left(\widetilde{\boldsymbol{h}}_{s,i}^v\right)^T \widetilde{\boldsymbol{h}}_{c,i}. \tag{2}$$

共享表示和特定表示之间的对比损失定义为 $\ell_{v,c} = I\left(\widetilde{\mathbf{h}}_c; \widetilde{\mathbf{h}}_s^v\right) + \alpha\left(H\left(\widetilde{\mathbf{h}}_c\right) + H\left(\widetilde{\mathbf{h}}_s^v\right)\right)$，其中 $I$ 和 $H$ 分别表示互信息与熵。从该损失可知，更小的 $I\left(\widetilde{\mathbf{h}}_c; \widetilde{\mathbf{h}}_s^v\right)$ 意味着更少的一致性交互，而更小的 $H\left(\widetilde{\mathbf{h}}_c\right)$ 和 $H\left(\widetilde{\mathbf{h}}_s^v\right)$ 表明表示携带更多有效信息且不确定性更低。将边缘概率分布记为 $\mathbf{P}^{(v)}$ 和 $\mathbf{P}^{(c)}$，并枚举各个特定特征，可得以下损失：

$$\mathcal{L}_{icl} = \sum_{v=1}^{V}\sum_{t=1}^{M}\sum_{t'=1}^{M} P_{t,t'}^{(v,c)} \ln\left(\frac{P_{tt'}^{(v,c)}}{\left(P_t^{(v)}\right)^{\alpha+1}\left(P_{t'}^{(c)}\right)^{\alpha+1}}\right), \tag{3}$$

其中，$\mathbf{P}_t^{(v)}$ 和 $\mathbf{P}_{t'}^{(c)}$ 可通过对 $\mathbf{P}^{(v,c)}$ 的第 $t$ 行和第 $t'$ 列求和计算。在实验中，将平衡参数 $\alpha$ 固定为 9。因此，表示提取的最终损失为 $\mathcal{L}_1 = \mathcal{L}_{adv} + \mathcal{L}_{icl}$。

## 一致的视图特定标签学习

由于不同视图具有异质性，并且对特定预测任务的重要性不同（Zhao et al. 2022），我们为每个视图表示独立建立分类器，以识别最相关的多标签子集。为每个特定表示构建分类器 $F_v$（$1 \le v \le V$），共享视图则使用 $F_0$。置信度分数为 $\mathbf{U}^v = F_v\left(\mathbf{h}_s^v\right)$ 和 $\mathbf{U}^0 = F_0\left(\mathbf{h}_c\right)$。令 $\widetilde{\mathbf{U}}^v$（$0 \le v \le V$）表示以 0.5 为阈值得到的预测标签。多标签样本本身具有不均匀的标签分布，这为基于标签相似性细致学习视图特定标签提供了可能（Yin and Zhang 2023）。此外，相似样本应具有相似标签这一流形假设（Wu et al. 2014），对于改进分类至关重要，特别是在特征和标签多样的情况下。因此，在整合视图

特定结果之前，应充分考虑视图与结果之间的结构一致性。由于多标签数据采用二进制编码表示语义且通常保持稀疏，我们利用 Jaccard 距离（Park and Read 2019），从交集与并集的角度度量两个标签集合的相似性。将标签相似度矩阵记为 $\mathbf{T}^v$（$0 \leq v \leq V$），其元素计算如下：

$$T_{i,j}^v = \frac{\langle \widetilde{\boldsymbol{U}}_i^v \cdot \widetilde{\boldsymbol{U}}_j^v \rangle}{\sum_{k=1}^{C} (\widetilde{U}_{i,k}^v + \widetilde{U}_{j,k}^v) - \langle \widetilde{\boldsymbol{U}}_i^v \cdot \widetilde{\boldsymbol{U}}_j^v \rangle}, \tag{4}$$

其中 $\langle \cdot \rangle$ 表示向量点积。令 $\mathbf{h}_c = \mathbf{h}_s^0$，两个视图特征的相似度可以在余弦空间中计算（Yin and Sun 2022）。为了过滤不必要的计算并增强捕捉相似样本的敏感性，我们借鉴基于图的方法（Zhao et al. 2022）的原则，仅考虑邻域 $N_p\left(\mathbf{h}_{s,i}^v\right)$ 内的相似度。对于样本 $i$ 和 $j$，其在提取特征 $\mathbf{h}_s^v$（$0 \leq v \leq V$）中的相似度定义为：

$$\boldsymbol{S}_{i,j}^v = \begin{cases} \left(\frac{\langle \boldsymbol{h}_{s,i}^v \cdot \boldsymbol{h}_{s,j}^v \rangle}{\|\boldsymbol{h}_{s,i}^v\| \|\boldsymbol{h}_{s,j}^v\|} + 1\right)/2, & \text{if } \boldsymbol{h}_{s,j}^v \in N_p\left(\boldsymbol{h}_{s,i}^v\right) \\ 0, & \text{otherwise} \end{cases} \tag{5}$$

式（5）中的 otherwise 表示“其他情况”。为保证相似样本对在标签空间中接近，我们采用具有强判别能力的度量学习（Jia et al. 2020）。以标签相似度为目标、特征相似度为学习对象，可将一致性损失写为：

$$\mathcal{L}_2 = \sum_{v=0}^{V} \sum_{i=1}^{N} \sum_{j \neq i}^{N} T_{i,j}^v S_{i,j}^v + (1 - T_{i,j}^v) \max(0, \text{Margin} - S_{i,j}^v), \tag{6}$$

其中 Margin 用于控制不匹配样本对之间的距离，我们将其设为最大值 1。

## 自适应标签引导 Transformer 融合

现实中，不同视图表示对同一分类任务的重要性不同，同一视图对多标签任务中各个标签的贡献也不同（Zhuge et al. 2023）。我们从 Corel 5k 中选择所有视图和六个相对均衡的标签，采用相同的分类方法进行实验。如图 2 所示，不同视图对同一标签的贡献，以及同一视图对所有标签的贡献，都不是均匀的。此外，应利用多标签相关性探索标签语义的共现，增强模型性能。为在结果融合过程中同时处理这三个因素，我们采用标签引导 Transformer，实现自适应交互感知。将每个类别映射到表示空间，利用自注意力机制实现信息交互。具体而言，将预测置信度作为辅助信息与各表示拼接，即可学习不平衡的表达能力。为补充标签类别的语义信息，在训练前随机初始化 $C$ 个类别令牌 $\{\mathbf{cls}_i \in \mathbb{R}^{M+C}\}_{i=1}^{C}$，并将其添加到输入序列。因此，输入 Transformer 的样本张量构造如下：

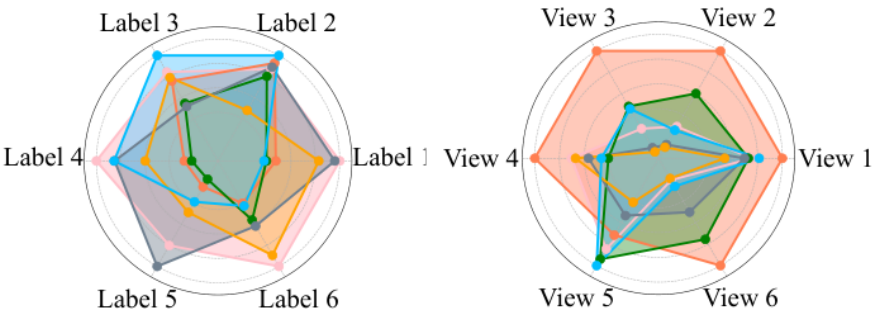



**图 2：** Corel 5k 上，同一标签下不同视图的结果，以及同一视图对不同标签的结果。Label 1–6＝标签 1–6；View 1–6＝视图 1–6。

$$\hat{\boldsymbol{X}}_i = \left\{ \left[ \boldsymbol{U}_i^0 \ \boldsymbol{h}_{c,i} \right], \cdots \left[ \boldsymbol{U}_i^V \ \boldsymbol{h}_{s,i}^V \right], \boldsymbol{cls}_i^1, \cdots, \boldsymbol{cls}_i^C \right\}. \quad (7)$$

对于每个样本嵌入，利用具有 $h$ 个头的投影矩阵 $\{\mathbf{W}_t^q, \mathbf{W}_t^k, \mathbf{W}_t^v\}_{t=1}^h$ 得到其查询、键和值。信息交换后，计算令牌间相关性 $\mathbf{A}_t$ 和输出 $\mathbf{B}_t$：

$$\begin{aligned} \boldsymbol{A}_t &= \text{softmax}\left( \left( \hat{\boldsymbol{X}}_i \boldsymbol{W}_t^q \right) \left( \hat{\boldsymbol{X}}_i \boldsymbol{W}_t^k \right)^T / \sqrt{d_h} \right) \\ \boldsymbol{B}_t &= \boldsymbol{A}_t \left( \hat{\boldsymbol{X}}_i \boldsymbol{W}_t^v \right), \end{aligned} \quad (8)$$

其中 $d_h = (M + C)/h$。图 3 展示了标签引导的多头机制。值得注意的是，将预测标签信息和真实标签信息都纳入自注意力过程，可同时实现特征级、标签级和映射级交互。一方面，自适应调整不同视图表示的重要性，各个视图通过关联全部子类别获得结构联系，使其接近最相关的类别令牌。另一方面，跨类别信息交互隐式促进类别相关性的学习。通过其余 Transformer 层后，输出分为两部分，即从提取表示得到的推断结果 $\{\mathbf{U}^{0*}, \mathbf{U}^{1*}, \ldots, \mathbf{U}^{V*}\}$，以及各类别令牌生成的预测 $\{\mathbf{cls}^{1*}, \mathbf{cls}^{2*}, \ldots, \mathbf{cls}^{C*}\}$。随后，对视图特定结果取平均，得到主要结果 $\mathbf{U}^m = \frac{1}{V+1}\sum_{i=0}^{V} \mathbf{U}^{i*}$，并拼接类别令牌的全部参考分数，得到辅助预测 $\mathbf{U}^c$。为促进多标签分类，采用以下交叉熵损失：

$$\begin{aligned} \mathcal{L}_{bce} = -\frac{1}{n_l C} \sum_{i \in \mathcal{F}} \sum_{j=1}^{C} & Y_{i,j} \log\left(F_{i,j}\right) \\ & + \left(1 - Y_{i,j}\right) \log\left(1 - F_{i,j}\right), \end{aligned} \quad (9)$$

其中 $F_{i,j}$ 为预测值。因此，可以针对 $\mathbf{U}^m$ 和 $\mathbf{U}^c$，依据 $\mathcal{L}_{bce}$ 得到主要分类损失 $\mathcal{L}_{mc}$ 与辅助损失 $\mathcal{L}_{ac}$。最终分类损失为 $\mathcal{L}_3 = \mathcal{L}_{mc} + \mathcal{L}_{ac}$，总训练损失为 $\mathcal{L} = \mathcal{L}_1 + \lambda_1 \mathcal{L}_2 + \lambda_2 \mathcal{L}_3$，其中 $\lambda_1$ 和 $\lambda_2$ 为惩罚系数。

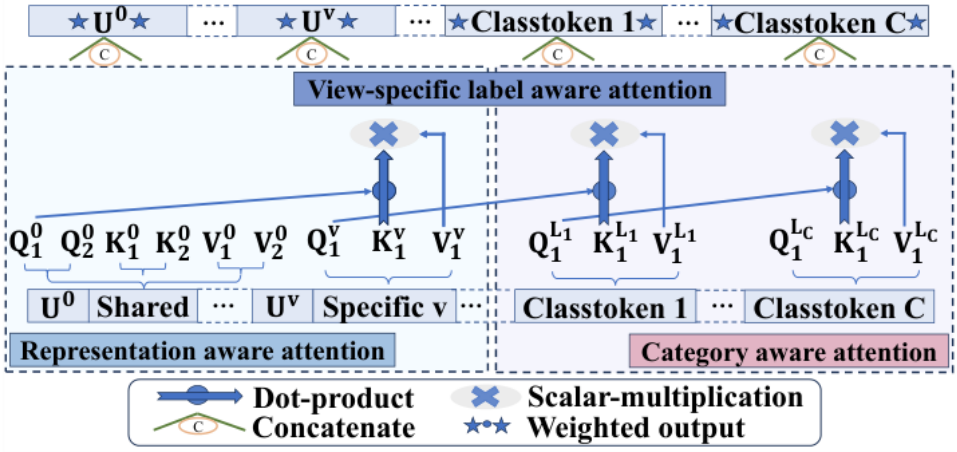



**图 3：** 具有两个头的标签引导自注意力。图内文字：Shared＝共享；Specific v＝特定视图 v；Classtoken＝类别令牌；Representation aware attention＝表示感知注意力；Category aware attention＝类别感知注意力；View-specific label aware attention＝视图特定标签感知注意力；Dot-product＝点积；Scalar-multiplication＝标量乘法；Concatenate＝拼接；Weighted output＝加权输出。

### 类别增强伪标签策略

由于存在大量无标签数据，模型在训练中容易过拟合。数据增强是提高深度学习泛化能力的有力技术（Shorten and Khoshgoftaar 2019）。因此，采用 Mixup 算法（Li, Li, and Yu 2024）对训练样本对进行线性插值，生成新样本，从而降低对单个数据点的依赖并产生正则化作用。对每个样本，将其与另一个随机样本组合，生成新的训练样本：

$$\begin{aligned} \boldsymbol{X}_{\text{new}}^{v} &= \alpha \boldsymbol{X}_{i\in\mathcal{F}}^{v} + (1-\alpha)\boldsymbol{X}_{j\in\mathcal{F},j\neq i}^{v} \\ \boldsymbol{Y}_{\text{new}} &= \operatorname{sgn}\left(\alpha \boldsymbol{Y}_{i\in\mathcal{F}} + (1-\alpha)\boldsymbol{Y}_{j\in\mathcal{F},j\neq i} - 0.5\right), \end{aligned} \tag{10}$$

其中 $\alpha \sim U(0,\ 1)$；当 $x \geq 0$ 时 $sgn(x) = 1$，否则 $sgn(x) = 0$。由于能够为训练提供新的已标注数据，伪标签方法在深度半监督任务中日益受到重视（Jiang and Luo 2024）。由于多标签分布具有长尾特性，错误伪标签的主要来源是对优势标签的过度关注（Meng et al. 2024）。因此，采用类别分布感知伪标签策略，使伪标签紧密对齐真实分布并减少噪声。分别考虑无标签训练样本中的每个类别 $\mathbf{Y}_{:,k}$，可按以下方式获得伪标签：

$$\hat{\boldsymbol{Y}}_{:,k} = \begin{cases} 1 & \text{if } \boldsymbol{U}_{:,k}^{m} \geq \tau(\alpha_k) \\ 0 & \text{if } \boldsymbol{U}_{:,k}^{m} \leq \tau(\beta_k) \\ -1 & \text{otherwise,} \end{cases} \tag{11}$$

其中 $\tau(\alpha_k)$ 和 $\tau(\beta_k)$ 是两个类别感知阈值，$\widehat{\mathbf{Y}_{:,k}} = -1$ 表示该标签将被排除在训练之外（otherwise＝其他情况）。鉴于已标注样本中正标签和负标签的类别比例能够紧密近似真实类别分布（Xie et al. 2024），可通过下式确定 $\tau(\alpha_k)$ 和 $\tau(\beta_k)$：

$$\begin{cases} \sum_{i\in\mathcal{R}} \mathbb{I}\left(U_{i,k}^{m} \geq \tau\left(\alpha_k\right)\right)/n_u = \hat{\gamma}_k \\ \sum_{i\in\mathcal{R}} \mathbb{I}\left(U_{i,k}^{m} \leq \tau\left(\beta_k\right)\right)/n_u = \hat{\rho}_k \end{cases} \tag{12}$$

其中 $\widehat{\gamma_k}$ 和 $\widehat{\rho_k}$ 分别是已标注样本中类别 $k$ 的正标签和负标签比例。为进一步提高伪标签可靠性，可行办法是在分类器训练若干轮后才将其纳入，并丢弃置信度相对较低的伪标签。因此，对任意类别 $k$，选取最可能的、比例分别为 $\eta_1 \cdot \widehat{\gamma_k}$ 和 $\eta_0 \cdot \widehat{\rho_k}$ 的伪标签，其中 $\eta_1$ 和 $\eta_0$ 用于控制置信区间，实验中均固定为 0.8。

## 实验

### 实验设置

**数据集和评价指标**。 遵循 Liu et al.（2023b）和 Zhao et al.（2021），实验选择六个常用多视图多标签数据集，即 Yeast（Guillaumin 2010）、Corel 5k（Duygulu et al. 2002）、VOC 2007（Everingham et al. 2010）、ESP Game（Ahn and Dabbish 2004）、IAPR TC-12（Grubinger et al. 2006）和 MIR FLICKR（Huiskes and Lew 2008）。与 Liu et al.（2023a）类似，采用多标签学习中常用的四项指标作为评价标准，即排序损失（RL）、准确率（ACC）、平均精度（AP）和调整后的曲线下面积（AUC）。为方便性能比较，报告中给出 1-HL 和 1-RL 的值。

**对比方法**。 为验证 SMVTEP 的有效性，将其与八种最先进方法比较，即 iMVWL、TM3L、NAIML、DICNet、DD-IMvMLC、LMVCAT、ESMC 和 SCTML。前六种方法能够处理 MvMLC 的不完整标签，后两种则只能处理单视图半监督多标签问题。因此，ESMC 和 SCTML 在各个视图上分别测试，并报告最佳结果。对比方法的所有参数优先采用其代码或论文推荐的值。

**实现细节**。 每个数据集按 7:1:2 划分为训练集、验证集和测试集。为模拟半监督场景，根据预设的已标注样本比例（LER），从训练集中随机选择 LER% 的实例作为已标注实例。所有结果来自十次独立运行，最终以均值和标准差呈现。模型使用 PyTorch 实现，在一张配备 24 GB 显存的 NVIDIA GeForce RTX 4090 GPU 上运行。

### 实验结果

**性能评价**。 为全面验证 SMVTEP 处理大量无标签样本的能力，我们在无标签样本远多于已标注样本的场景下，将其与八种方法比较。此外，针对标签不足，充分考虑 LER 的取值，采用 {3%, 6%, 9%, 12%, 15%, 18%, 21%} 不同比例。表 1 展示 LER 固定为 6% 时的四项指标，图 4 展示 LER 变化时 AP 的变化。

| DATA | MET | SCTML | ESMC | iMVWL | TM3L | NAIM3L | DICNet | DIMC | LMVCAT | SMVTEP |
|---|---|---|---|---|---|---|---|---|---|---|
| YES | 1-HL | 76.26±1.04 | 57.56±1.19 | 69.10±2.87 | 69.77±0.41 | 64.15±0.25 | 69.76±0.23 | 69.54±2.57 | 75.17±0.89 | **78.07±0.80** |
| | 1-RL | 78.02±0.86 | 73.01±1.26 | 68.93±6.15 | 72.18±2.93 | 64.02±0.29 | 75.76±0.95 | 68.54±4.69 | 76.98±1.19 | **79.80±1.55** |
| | AP | 70.65±1.44 | 63.95±1.94 | 59.90±5.49 | 65.05±2.74 | 56.74±0.60 | 67.51±0.55 | 61.46±4.82 | 69.23±1.10 | **72.95±1.21** |
| | AUC | 79.35±0.56 | 72.19±1.11 | 72.45±5.32 | 74.15±2.76 | 52.06±0.51 | 77.41±0.77 | 71.30±4.09 | 78.18±1.18 | **80.70±1.50** |
| COR | 1-HL | 98.57±0.12 | 71.66±0.65 | 97.71±0.02 | 98.69±0.00 | 91.93±5.52 | 98.69±0.01 | 98.69±0.01 | 98.66±0.01 | **98.70±0.00** |
| | 1-RL | 78.68±0.06 | 60.28±1.27 | 79.08±0.60 | 70.30±0.79 | 61.10±3.34 | 77.82±0.86 | 74.60±1.58 | 81.28±0.48 | **84.80±0.92** |
| | AP | 22.67±2.51 | 11.08±1.53 | 20.19±0.68 | 22.49±0.82 | 14.24±2.67 | 23.21±0.44 | 19.97±1.60 | 26.97±1.09 | **32.52±0.54** |
| | AUC | 79.93±0.25 | 60.27±1.35 | 79.31±0.64 | 77.91±0.27 | 61.50±3.24 | 78.01±0.82 | 74.63±1.78 | 81.45±0.52 | **85.08±0.98** |
| VOC | 1-HL | 92.91±0.30 | 69.01±0.63 | 88.22±0.03 | 92.68±0.05 | 92.11±0.02 | 92.68±0.05 | 92.62±0.06 | 91.81±0.49 | **93.17±0.02** |
| | 1-RL | 71.10±2.60 | 66.21±1.24 | 69.55±0.84 | 75.54±0.29 | 73.21±0.07 | 72.91±0.61 | 68.35±2.12 | 77.70±1.25 | **82.04±1.57** |
| | AP | 45.05±2.41 | 40.24±0.89 | 42.61±0.54 | 48.35±0.50 | 45.17±0.09 | 44.88±0.72 | 42.83±0.50 | 49.35±1.47 | **54.18±1.03** |
| | AUC | 74.69±2.38 | 66.89±1.45 | 71.95±0.36 | 80.37±0.36 | 62.93±0.32 | 75.65±0.65 | 71.95±1.47 | 79.77±1.26 | **83.73±1.48** |
| ESP | 1-HL | 97.34±0.65 | 71.90±0.10 | 97.00±0.00 | 98.24±0.00 | 98.13±0.03 | 98.25±0.01 | 98.24±0.01 | **98.26±0.01** | 98.25±0.01 |
| | 1-RL | 76.66±0.19 | 70.17±0.56 | 76.97±0.17 | 70.22±0.22 | 71.71±0.51 | 78.30±0.17 | 75.45±0.62 | 77.42±0.15 | **81.23±0.50** |
| | AP | 19.70±1.21 | 15.77±0.40 | 18.58±0.12 | 17.85±0.40 | 21.80±0.44 | 22.68±0.24 | 18.88±0.42 | 21.90±0.29 | **27.22±0.63** |
| | AUC | 77.10±0.27 | 70.07±0.53 | 77.54±0.19 | 72.93±0.31 | 71.80±0.44 | 78.50±0.13 | 75.83±0.63 | 77.88±0.11 | **81.64±0.47** |
| IAP | 1-HL | 96.53±1.43 | 71.18±0.15 | 96.73±0.02 | 98.04±0.01 | 79.97±0.04 | 98.04±0.01 | 98.04±0.02 | 98.05±0.01 | **98.06±0.01** |
| | 1-RL | 79.47±0.75 | 70.95±0.45 | 79.19±0.24 | 76.71±0.27 | 61.03±0.09 | 80.36±0.28 | 76.16±1.02 | 79.90±0.17 | **84.31±0.71** |
| | AP | 22.41±3.01 | 16.04±0.35 | 19.63±0.21 | 23.27±0.40 | 12.00±0.10 | 22.72±0.27 | 19.65±0.27 | 22.99±0.44 | **27.76±0.21** |
| | AUC | 80.01±0.42 | 70.80±0.40 | 79.55±0.21 | 79.07±0.34 | 54.83±0.07 | 80.29±0.18 | 76.33±0.97 | 80.28±0.25 | **84.40±0.84** |
| MIR | 1-HL | 87.54±0.11 | 67.14±0.22 | 83.95±0.02 | 87.60±0.03 | 86.53+0.14 | 87.57±0.07 | 87.54±0.07 | 87.69±0.49 | **89.19±0.11** |
| | 1-RL | 83.32±2.37 | 78.86±0.16 | 80.75±0.23 | 78.29±0.33 | 49.58+0.52 | 83.20±0.14 | 79.08±1.27 | 85.15±0.56 | **87.27±0.21** |
| | AP | 51.99±7.19 | 42.81±0.41 | 45.15±0.75 | 50.01±0.55 | 45.30+1.92 | 51.69±0.37 | 45.18±1.18 | 58.19±1.10 | **60.27±0.25** |
| | AUC | 82.94±2.47 | 76.94±0.24 | 80.45±0.12 | 81.11±0.26 | 58.56+0.24 | 81.71±0.17 | 78.01±1.41 | 83.86±0.37 | **85.53±0.28** |

**表 1：** LER 固定为 6% 时，不同方法在六个公开数据集上的 1-HL、1-RL、AP 和 AUC。每行最优结果加粗，次优结果加下划线。DATA＝数据集；MET＝指标；YES＝Yeast，COR＝Corel 5k，VOC＝VOC 2007，ESP＝ESP Game，IAP＝IAPR TC-12，MIR＝MIR FLICKR。算法名、数值、标准差以及原表的 DIMC 列名均原样保留。

对于比较结果，我们有以下观察：1）我们的方法几乎在所有情况下都优于其他比较方法，尤其在最具代表性的 AP 指标上表现突出。2）与半监督方法 ESMC 和 SCTML 相比，SMVTEP 展现出显著优势，例如在 Corel 5k 和 VOC 2007 上 AP 提升超过 50%。此外，我们的方法也优于针对不完整 MvMLC 设计的方法。例如，表 1 表明，即使与 MIR FLICKR 上表现最好的 MvMLC 方法 LMVCAT 相比，SMVTEP 也能可靠地提升性能。总体而言，我们的方法能够有力地同时应对特征和标签类别众多以及标注不足的挑战。3）当 LER 从 3% 增至 21% 时，SMVTEP 仍优于其他八种方法。此外，我们的方法表现稳健，在较低 LER 下持续取得相对理想的结果。例如，在 ESP Game 上 LER=21% 时，SMVTEP 和次优方法 LMVCAT 的 AP 分别为 29.72% 和 27.43%。当 LER=3% 时，SMVTEP 的性能为 25.05%，优于 LMVCAT 的 20.05%，说明我们的方法更适合标注高度缺乏的情形。

**消融研究**。 通过消融实验全面考察 SMVTEP 关键模块的影响。具体而言，分别使用原始视图、对视图特定预测取平均以及直接将分类器结果作为伪标签，评价移除生成对抗网络（S1）、标签引导 Transformer（S2）和伪标签策略（S3）的影响。从表 2 可见，特征语义提取和后期融合有利于提高性能。此外，我们的伪标签策略发挥关键作用，尤其是在较大的数据集上。虽然伪标签中的噪声累积严重妨碍了 Corel 5k 和 VOC 2007 上的分类，我们的方法通过分布对齐有效改善了伪标签质量。

| $S_1$ | $S_2$ | $S_3$ | Yeast | | Corel 5k | | VOC 2007 | |
|---|---|---|---|---|---|---|---|---|
| | | | AP | AUC | AP | AUC | AP | AUC |
| ✗ | ✓ | ✓ | 71.93 | 81.01 | 31.34 | 83.49 | 51.65 | 81.99 |
| ✓ | ✗ | ✓ | 72.05 | 80.91 | 29.97 | 79.45 | 50.77 | 77.02 |
| ✓ | ✓ | ✗ | 71.11 | 80.46 | 20.59 | 77.32 | 43.04 | 72.54 |
| ✓ | ✓ | ✓ | **75.51** | **82.49** | **32.09** | **84.47** | **54.41** | **84.49** |

**表 2：** LER=6% 时在 Yeast、Corel 5k 和 VOC 2007 上的消融研究。“√”和“✗”分别表示使用和不使用相应项目。

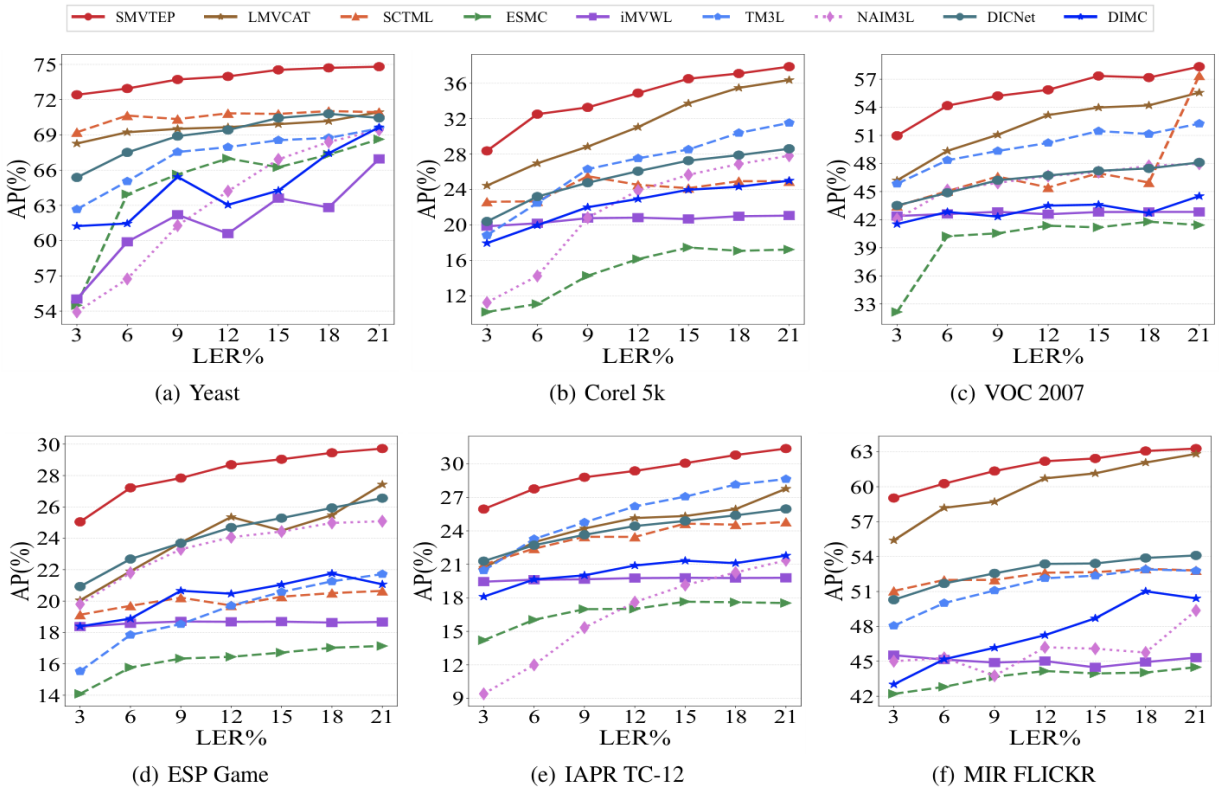
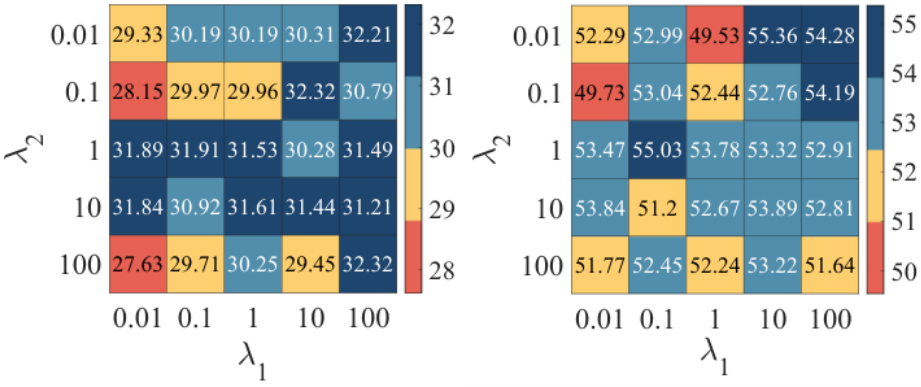


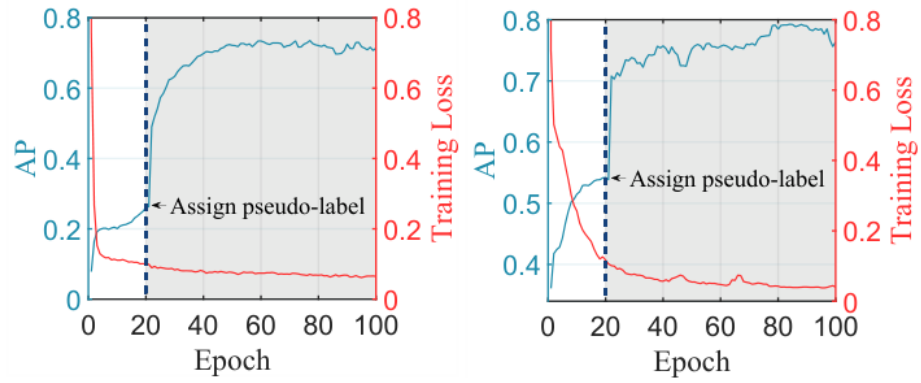

**图 4：** LER 从 3% 变化到 21% 时，六个数据集上的 AP 比较。（a）Yeast；（b）Corel 5k；（c）VOC 2007；（d）ESP Game；（e）IAPR TC-12；（f）MIR FLICKR。横轴 LER%＝已标注样本比例（%），纵轴 AP(%)＝平均精度（%）。图例算法名称及曲线原样保留。

**参数敏感性与收敛性。** 为研究 $\lambda_1$ 和 $\lambda_2$ 的影响，我们在图 6 中给出不同参数组合下的性能。热图表明，当 $\lambda_1$ 接近 100、$\lambda_2$ 接近 0.01 时，性能有所改善，且 SMVTEP 对两个参数都不太敏感。我们还报告训练损失与 AP 值的变化趋势，发现二者几乎同时收敛。此外，加入伪标签后性能显著提高。




(a) Corel 5k (b) VOC 2007

**图 5：** Corel 5k 和 VOC 2007 上权衡参数 $\lambda_1$ 与 $\lambda_2$ 的参数分析。（a）Corel 5k；（b）VOC 2007。




(a) Corel 5k (b) VOC 2007

**图 6：** SMVTEP 在 Corel 5k 和 VOC 2007 上训练期间的收敛情况。（a）Corel 5k；（b）VOC 2007。Epoch＝训练轮次；Training Loss＝训练损失；Assign pseudo-label＝分配伪标签；AP＝平均精度。

## 结论

为解决多样特征和标签下存在大量无标签样本的问题，本文提出一种新的深度半监督学习方法 SMVTEP。SMVTEP 利用生成对抗网络提取语义不同的表示，在流形约束下执行视图特定标签学习，并采用标签引导 Transformer 进行后期融合，以同时探索特征空间和标签空间的内在关系以及映射语义。此外，SMVTEP 将数据增强与类别增强伪标签策略结合，以处理稀疏标注并提取高质量监督信息。最后，大量实验结果证明 SMVTEP 的优越性。未来，我们将进一步处理标签噪声和类别不平衡问题。

## 致谢

本研究获得国家自然科学基金项目（批准号 62376281）、国家杰出青年科学基金项目（批准号 62425607）以及国家自然科学基金重点项目（批准号 62136005）资助。

## 参考文献

下列各条完整保留作者、年份、出处和卷页信息，论文题名译为中文。


1. Ahn, L. V.; and Dabbish, L. 2004. 利用计算机游戏标注图像。载于 SIGCHI Conference on Human Factors in Computing Systems，319–326。
2. Akbarnejad, A. H.; and Baghshah, M. S. 2018. 能处理缺失标签的高效半监督多标签分类器。IEEE Transactions on Knowledge and Data Engineering，31(2): 229–242。
3. Chang, W.-C.; Yu, H.-F.; Zhong, K.; Yang, Y.; and Dhillon, I. S. 2020. 驯服预训练 Transformer，用于极端多标签文本分类。载于 Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining，3163–3171。
4. Dong, H.-C.; Li, Y.-F.; and Zhou, Z.-H. 2018. 从半监督弱标签数据中学习。载于 Proceedings of the AAAI Conference on Artificial Intelligence，第 32 卷，2926–2933。
5. Duygulu, P.; Barnard, K.; de Freitas, J. F.; and Forsyth, D. A. 2002. 将对象识别视为机器翻译：为固定图像词汇学习词典。载于 European Conference on Computer Vision，97–112。
6. Everingham, M.; Van Gool, L.; Williams, C. K.; Winn, J.; and Zisserman, A. 2010. PASCAL 视觉对象类别（VOC）挑战。International Journal of Computer Vision，88: 303–338。
7. Grubinger, M.; Clough, P.; Müller, H.; and Deselaers, T. 2006. IAPR TC-12 基准：视觉信息系统的新评价资源。载于 International Workshop onto Image，第 2 卷，1–11。
8. Guan, R.; Li, Z.; Tu, W.; Wang, J.; Liu, Y.; Li, X.; Tang, C.; and Feng, R. 2024. 基于图卷积网络的高光谱图像对比多视图子空间聚类。IEEE Transactions on Geoscience and Remote Sensing，62: 1–14。
9. Guillaumin, C. 2010. 用于图像分类的多模态半监督学习。载于 IEEE Computer Society Conference on Computer Vision and Pattern Recognition，902–909。
10. Han, X.; Zhou, F.; Ren, Z.; Wang, X.; and You, X. 2024. 用于不完整多视图聚类的视图特定锚点耦合张量二部图学习。Information Sciences，664: 120335。
11. Hu, D.; Dong, Z.; Liang, K.; Yu, H.; Wang, S.; and Liu, X. 2024a. 用于深度单细胞多视图模糊聚类的高阶拓扑。IEEE Transactions on Fuzzy Systems。
12. Hu, D.; Liu, S.; Wang, J.; Zhang, J.; Wang, S.; Hu, X.; Zhu, X.; Tang, C.; and Liu, X. 2024b. 通过实例级和特征级协同插补实现可靠的属性缺失多视图聚类。载于 Proceedings of the 32nd ACM International Conference on Multimedia，1456–1466。
13. Hu, P.; Zhen, L.; Peng, X.; Zhu, H.; Lin, J.; Wang, X.; and Peng, D. 2023. 具有图先验的深度监督多视图学习。IEEE Transactions on Image Processing，33: 123–133。
14. Hu, S.; and Miao, D. 2022. 结合主动学习的基于多粒度标签传播的半监督分类。Expert Systems with Applications，192: 116276。
15. Huiskes, M. J.; and Lew, M. S. 2008. MIR Flickr 检索评价。载于 Proceedings of the 1st ACM International Conference on Multimedia Information Retrieval，39–43。
16. Jia, X.; Jing, X.-Y.; Zhu, X.; Chen, S.; Du, B.; Cai, Z.; He, Z.; and Yue, D. 2020. 半监督多视图深度判别表示学习。IEEE Transactions on Pattern Analysis and Machine Intelligence，43(7): 2496–2509。

17. Jiang, Z.; and Luo, T. 2024. 标签信息不足的深度不完整多视图学习网络。载于 Proceedings of the AAAI Conference on Artificial Intelligence，第 38 卷，12919–12927。
18. Jung, S.; Jeoung, J.; Hong, T.; and Jang, H. 2024. 利用大规模数据集捕捉人员动作与服装信息的视觉多标签检测框架。Building and Environment，257: 111537。
19. Li, J.; Li, G.; and Yu, Y. 2024. 用于半监督领域自适应的域间 Mixup。Pattern Recognition，146: 110023。
20. Li, J.; Zhu, X.; Wang, H.; Zhang, Y.; and Wang, J. 2024. 用于半监督多标签学习的堆叠协同训练。Information Sciences，677。
21. Li, X.; and Chen, S. 2021. 用于非对齐不完整多视图与缺失多标签学习的简洁而有效的模型。IEEE Transactions on Pattern Analysis and Machine Intelligence，44(10): 5918–5932。
22. Lin, Y.; Gou, Y.; Liu, X.; Bai, J.; Lv, J.; and Peng, X. 2022. 用于不完整多视图表示学习的双重对比预测。IEEE Transactions on Pattern Analysis and Machine Intelligence，45(4): 4447–4461。
23. Liu, C.; Wen, J.; Luo, X.; Huang, C.; Wu, Z.; and Xu, Y. 2023a. Dicnet：用于双重不完整多视图多标签分类的深度实例级对比网络。载于 Proceedings of the AAAI Conference on Artificial Intelligence，第 37 卷，8807–8815。
24. Liu, C.; Wen, J.; Luo, X.; and Xu, Y. 2023b. 通过标签引导的掩码视图感知与类别感知 Transformer 进行不完整多视图多标签学习。载于 Proceedings of the AAAI Conference on Artificial Intelligence，第 37 卷，8816–8824。
25. Meng, L.; Zhang, Q.; Yang, R.; and Huang, Y. 2024. 采用动态伪多标签的无监督深度哈希用于图像检索。IEEE Signal Processing Letters，31: 909–913。
26. Miller, H. A.; and Lowengrub, J. 2022. 以患者特定代谢组学数据作为输入的肿瘤生长建模。Annals of Biomedical Engineering，50(3): 314–329。
27. Ou, S.; Xue, Z.; Li, Y.; Liang, M.; Cai, Y.; and Wu, J. 2024. 用于不完整多视图多标签学习的视图–类别交互共享 Transformer。载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，27467–27476。
28. Park, L. A.; and Read, J. 2019. 用于多标签优化与评价的混合度量。载于 Machine Learning and Knowledge Discovery in Databases: European Conference，719–734。Springer。
29. Peng, X.; Zhu, H.; Feng, J.; Shen, C.; Zhang, H.; and Zhou, J. T. 2019. 具有样本分配不变性先验的深度聚类。IEEE Transactions on Neural Networks and Learning Systems，31(11): 4857–4868。
30. Shorten, C.; and Khoshgoftaar, T. M. 2019. 深度学习图像数据增强综述。Journal of Big Data，6(1): 1–48。
31. Su, X.; and Xu, Y. 2024. 结合全局和局部结构的不平衡与缺失多标签数据学习。Information Sciences，120910。
32. Sun, F.; and Xie, M.-K. 2024. 基于课程式消歧的部分多标签图像分类深度模型。Machine Intelligence Research，1–14。
33. Sun, N.; Luo, T.; Zhuge, W.; Tao, H.; Hou, C.; and Hu, D. 2021. 具有标签比例的半监督学习。IEEE Transactions on Knowledge and Data Engineering，35(1): 877–890。
34. Sun, S.; and Wang, B. 2024. 用于多视图学习的解耦表示。Pattern Recognition，151: 110377。

35. Tan, Q.; Yu, G.; Domeniconi, C.; Wang, J.; and Zhang, Z. 2018. 不完整多视图弱标签学习。载于 International Joint Conference on Artificial Intelligence，2703–2709。
36. Wen, J.; Liu, C.; Deng, S.; Liu, Y.; Fei, L.; Yan, K.; and Xu, Y. 2023. 具有不完整标签和缺失视图的深度双重不完整多视图多标签学习。IEEE Transactions on Neural Networks and Learning Systems，35: 11396–11408。
37. Wu, B.; Liu, Z.; Wang, S.; Hu, B.-G.; and Ji, Q. 2014. 具有缺失标签的多标签学习。载于第 22 届 International Conference on Pattern Recognition，1964–1968。
38. Wu, X.; Chen, Q.-G.; Hu, Y.; Wang, D.; Chang, X.; Wang, X.; and Zhang, M.-L. 2019. 采用视图特定信息提取的多视图多标签学习。载于 International Joint Conference on Artificial Intelligence，3884–3890。
39. Xiao, Y.; Chen, J.; Liu, B.; Zhao, L.; Kong, X.; and Hao, Z. 2024. 采用特权信息学习的新型多视图多标签模型。Information Sciences，656: 119911。
40. Xie, M.-K.; Xiao, J.; Liu, H.-Z.; Niu, G.; Sugiyama, M.; and Huang, S.-J. 2024. 用于半监督多标签学习的类别分布感知伪标签。Advances in Neural Information Processing Systems, 36。
41. Xin, B.; Lu, S.; Wang, Q.; Deng, F.; Shi, X.; Cheng, J.; and Kang, Y. 2023. 通过基于多视图建模的混合算法同时调度加工机器和自动导引车。IEEE Transactions on Automation Science and Engineering，21: 4753–4767。
42. Yin, J.; and Sun, S. 2022. 采用余弦相似度的不完整多视图聚类。Pattern Recognition，123: 108371。
43. Yin, J.; and Zhang, W. 2023. 保持双阶流形的多视图多标签学习。Applied Intelligence, 53(12): 14703–14716。
44. Zhan, W.; and Zhang, M.-L. 2017. 采用协同训练的归纳式半监督多标签学习。载于 Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining，1305–1314。
45. Zhang, J.; Li, S.; Jiang, M.; and Tan, K. C. 2020. 基于流形正则化稀疏模型从弱标注数据中学习。IEEE Transactions on Cybernetics，52(5): 3841–3854。
46. Zhang, W.; Zhang, K.; Gu, P.; and Xue, X. 2013. 面向不完全标注数据的多视图嵌入学习。载于 International Joint Conference on Artificial Intelligence，1910–1916。
47. Zhao, D.; Gao, Q.; Lu, Y.; and Sun, D. 2021. 通过子空间学习进行缺失标签的两步多视图多标签学习。Applied Soft Computing，102: 107120。
48. Zhao, D.; Gao, Q.; Lu, Y.; and Sun, D. 2022. 学习视图特定标签并最大化标签–特征依赖关系，用于多视图多标签分类。Applied Soft Computing，124: 109071。
49. Zhu, C.; Liu, Y.; Miao, D.; Dong, Y.; and Pedrycz, W. 2023. 基于视图内、跨视图与一致性视图表示的不完整数据多视图多标签学习。Neurocomputing，557: 126729。
50. Zhuge, W.; Luo, T.; Fan, R.; Tao, H.; Hou, C.; and Yi, D. 2023. 缺失多视图半监督分类。IEEE Transactions on Cybernetics，54(3): 1708–1721。

## 译者说明（非原文内容）

1. 原文实验设置列举 RL、ACC、AP、AUC，但紧接着及表 1 使用 1-HL、1-RL、AP、AUC；此处按原文保留，未自行将 ACC 改为 HL。

2. 原文比较方法段写作 NAIML，相关工作及表格写作 NAIM3L；表格/图例将 DD-IMvMLC 标为 DIMC。各处保留原样。
3. 参数敏感性正文引用“图 6”，但参数热图实际标为图 5，图 6 为收敛曲线。译文保留正文原交叉引用，不悄然修正。
4. 式（2）未显示归一化因子，式（6）的相似度损失形式及式（9）的括号形式均依原页保留。本译文不替原作者修正公式。
5. 参考文献中的作者拼写、年份、卷号和页码依据所供 PDF，不以外部版本替换。未提供的补充材料不在本次翻译范围内。