通过解耦表征与标签语义嵌入实现不完整多视图多标签学习

Incomplete Multi-View Multi-Label Learning via Disentangled Representation and Label Semantic Embedding

Xu Yan[1]，Jun Yin[1]*，Jie Wen[2]
[1] 上海海事大学　[2] 哈尔滨工业大学（深圳）
yanxu@stu.shmtu.edu.cn；junyin@shmtu.edu.cn；jiewen_pr@126.com
*通讯作者

非官方中文全文译文 · 供用户私人阅读

本译文以用户上传的 10 页论文为唯一翻译底本，覆盖摘要、正文第 1-5 节、致谢和全部 42 条参考文献。原图、原表及编号公式以原稿裁切保留，图表说明及图内英文词语提供中文释义，正文与行内数学符号重新排版。原文提及的补充材料第 6.1、6.2 和 7 节不在本次上传文件内，故未补写推导、证明或实验细节。文献末尾的数字保留原文的引用页码，不对应本译文页码。

原稿版本声明（原样保留）

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

声明中译： 这篇 CVPR 论文为计算机视觉基金会（Computer Vision Foundation）提供的开放获取版本。除本水印外，其内容与录用版本相同；会议论文集的最终出版版本可在 IEEE Xplore 获取。原稿的权利与版本声明不因本译文而改变；此处不新增任何开放许可或公开再分发授权。

摘要

在不完整多视图多标签学习场景中，利用不完整的多视图数据，从不同数据源中提取一致性表征和特有表征，并充分利用缺失标签信息，至关重要。然而，以往的大多数方法忽略了视图共享信息与特有信息之间的分离问题。为解决这一问题，本文提出一种在变分自编码器（Variational Autoencoder, VAE）框架下，将视图一致性特征与视图特有特征分离的方法。具体而言，我们首先引入跨视图重构来捕获视图一致性特征，并通过无监督预训练从不同视图中提取共享信息。随后，我们构建解耦模块，通过最小化一致性特征与特有特征之间互信息的变分上界，学习特有特征。最后，我们利用从训练数据中得到的标签相关性先验信息，指导标签语义嵌入分布的学习，聚合相关的语义嵌入，并在语义空间中保持标签相关性的拓扑结构。大量实验表明，我们的模型在多个真实世界数据集上优于现有最先进算法，充分验证了其对视图缺失和标签缺失的强适应能力。

1 引言

近年来，随着数据的多样性和复杂性不断增加，多视图学习作为一种有效的数据处理技术，受到了广泛关注。在图像分类、视频分析和文本挖掘等许多实际应用中，数据往往以多个视图的形式呈现，这使多视图学习方法成为解决复杂问题的有效工具 [28, 35, 36]。过去几年中，许多多视图学习方法都是基于视图完整这一假设提出的 [4, 30, 38]。然而，处理多视图数据时，视图缺失并不少见，这对模型的学习效果构成了挑战 [19, 39]。

与此同时，多标签学习也是一个同样重要的研究领域。与传统的单标签分类任务不同，多标签学习旨在处理实例可能同时属于多个类别的情况。多标签学习的关键在于如何处理标签之间的相关性，这有助于提高分类性能 [12, 42]。由于人工标注过程涉及各种不确定性，多标签数据集往往并不完整。因此，对不完整多标签学习的研究尤为重要。

传统多标签分类依赖从单一视图提取的特征进行分类，导致特征信息不足。利用多视图数据进行多标签分类，可以有效缓解这一问题。目前，许多处理多视图多标签分类（Multi-View Multi-Label Classification，MVMLC）任务的模型已表现出良好性能 [33, 37, 41]。这些模型通常假定数据完整，而目前能够同时处理视图缺失和标签缺失的方法仍然不多。

为处理双重不完整多视图多标签分类（Double Incomplete Multi-View Multi-Label Classification，DIMVMLC）问题，研究者提出了若干基于自编码器的深度学习模型 [22, 23, 31]。然而，用于解耦一致性特征与特有特征的方法仍然很少。SIMM [33] 通过最小化混淆对抗损失和多标签损失识别一致性特征，使用正交约束消除共享信息，并从原始信息中提取特有信息。但是，SIMM 无法应用于数据缺失的情况；强制正交约束只能消除线性相关性，共享特征与特有特征之间仍可能存在非线性关系。这种关系可能难以通过简单的正交约束捕获，从而影响特征的表达能力。MTD [23] 同时学习一致性特征和特有特征，并使用多视图跨通道对比损失将二者分离。同时优化这两个任务可能使优化过程变得复杂：模型需要在两个目标之间权衡，从而增加收敛难度。

为解决上述复杂的双重不完整多视图多标签学习问题，我们提出基于解耦表征与标签语义嵌入的方法（Disentangled Representation and Label Semantic Embedding，DRLS），如图 1 所示。我们的方法包括三个主要部分：（1）最小化各视图一致性特征的近似后验与多视图联合后验之间的 KL 散度，学习多视图一致性特征。（2）最小化一致性特征与特有特征之间互信息的变分上界，学习解耦后的特有特征。（3）利用训练数据中的标签相关性先验信息，并采用图神经网络，对标签语义嵌入的分布进行建模。我们的模型建立在变分自编码器（VAE）框架之上。大量实验证明了 DRLS 的优异性能。本文贡献概括如下：

- 我们提出一种基于解耦表征与标签语义嵌入的新方法，用于解决 DIMVMLC 问题。该方法能够有效利用多视图数据中的一致性信息和特有信息，并通过解耦表征学习模块将二者分离，从而有效完成多标签分类任务。
- 我们引入一种预训练策略：先通过预训练学习视图一致性表征，再最小化一致性特征与特有特征之间互信息的变分上界，以有效分离二者。
- 我们设计一个基于图神经网络的标签语义嵌入学习模块，能够同时聚合相关标签的嵌入，并在语义空间中保持标签相关性的拓扑结构。
- 我们的方法在五个公开数据集上取得领先性能，并且既适用于完整数据，也适用于任意缺失的数据。

2 相关工作

研究者已提出许多 MVMLC 方法。例如，CDMM [40] 基于采用非线性核映射构建的神经网络，建立独立分类器，以确保每个视图学到一致的标签结果。该方法将 Hilbert-Schmidt 独立性准则 [7] 与对不同视图之间差异的探索相结合，以处理视图之间的多样性。MMFA [3] 首先从不同视图中提取公共特征和私有特征，再计算原始特征与公共特征之间的相似度。将该相似度与协同特征矩阵相乘，得到注意力权重矩阵，随后用于多标签预测。

对于 DIMVMLC，iMvWL [27] 使用非负矩阵分解（Nonnegative Matrix Factorization，NMF）学习多个视图的共享子空间，并引入标签信息与局部标签相关性矩阵，以提高子空间的判别能力。NAIML [20] 同时利用多个视图之间的一致性以及标签之间复杂的全局和局部结构，应对可用标签不足的问题。这两种方法都属于浅层机器学习方法，而当前基于深度神经网络的方法在这一领域表现更好，例如 DDINet [31]、DICNet [22] 和 SIP [21]。DDINet 首次使用深度神经网络处理 DIMVMLC。DICNet 利用对比损失学习跨视图共享特征，对齐跨视图实例，并通过多视图融合模块提高特征的判别能力，从而有效处理视图缺失和标签缺失。SIP 模型利用信息瓶颈理论的原理，在保留相关特征的同时减少非共享信息，并通过潜在空间中的原型实例捕获标签之间的关联。

3 方法

3.1 问题定义

给定包含 n 个样本的数据集 $\{x^{(v)}\}_{v=1}^{m}$，每个样本有 m 个视图，其中 $x^{(v)} \in \mathbb{R}^{d_v}$。这里，$d_v$ 表示第 v 个视图的特征维数。标签向量为 $y \in \{0, 1\}^k$，其中 k 表示类别数。若 $y_i = 0$，则该样本不具有第 i 个标签；若 $y_i = 1$，则具有该标签。为处理缺失数据，我们定义集合 $\mathcal{W}$（$|\mathcal{W}| \leq m$），表示某一样本的可观测视图集合；可观测多视图数据定义为 $\{x^{(v)}\}_{v\in\mathcal{W}}$，简记为 $\{x\}$。我们还定义样本的可观测标签集合 $\mathcal{U}$（$|\mathcal{U}| \leq k$）。我们的目标是训练一个模型，预测未见样本的标签。下文的损失函数和目标函数均针对单个样本定义。

3.2 视图一致性特征

在传统多视图学习中，一致性特征往往在没有跨视图交互的情况下分别学习 [33]，因此难以充分捕获不同视图之间的共同语义信息。本节首先介绍如何通过跨视图重构学习多视图一致性特征。

首先，我们定义具有可学习参数 ϕ_v 的 $q_{\phi_v}(c \mid x^{(v)})$，用以近似后验 $p(c \mid x^{(v)})$，其中 c 表示一致性特征。每个视图的一致性特征都应包含所有视图的公共信息。受文献 [2] 启发，我们通过约束每个视图的近似后验与多视图联合后验相似，来学习一致性特征：

$$\min \frac{1}{|\mathcal{W}|} \sum_{v\in\mathcal{W}} \left[D_{KL}(q_{\phi_v}(c \mid x^{(v)}) \| p(c \mid \{x\})) \right] \qquad (1)$$

其中，$D_{KL}(\cdot\|\cdot)$ 表示 KL 散度，$|\mathcal{W}|$ 表示可用视图数，$p(c \mid \{x\})$ 表示多视图联合后验。

从式（1）出发，进一步运用贝叶斯定理分解多视图联合后验分布 $p(c \mid \{x\})$，可以推导出证据下界（Evidence Lower Bound，ELBO）。由于篇幅限制，详细推导见补充材料第 6.1 节。最终结果如下：

$$\begin{aligned}
&\log p(\{x\}) - \frac{1}{|\mathcal{W}|}\sum_{v\in\mathcal{W}}\Big[D_{KL}(q_{\phi_v}(c|x^{(v)})\|p(c|\{x\}))\Big] \\
&= \frac{1}{|\mathcal{W}|}\sum_{v\in\mathcal{W}}\Big[\mathbb{E}_{q_{\phi_v}(c|x^{(v)})}[\log p(\{x\}|c)] \\
&\qquad\qquad - D_{KL}(q_{\phi_v}(c \mid x^{(v)})\|p(c))\Big]
\end{aligned} \tag{2}$$

由此得到证据下界（ELBO）。因此，最大化这个下界，就等价于有效求解式（1）中的最小化问题。

假设给定 c 时，各视图相互条件独立，则可以有效地将数据似然分解为 $p(\{x\} \mid c) = \prod_{i\in\mathcal{W}} p\left(x^{(i)} \mid c\right) \approx \prod_{i\in\mathcal{W}} p_{\theta_i}\left(x^{(i)} \mid c\right)$，其中，具有可学习参数 θ_i 的 $p_{\theta_i}\left(x^{(i)} \mid c\right)$ 用于近似 $p\left(x^{(i)} \mid c\right)$。式（2）的目标涉及从不同视图提取一致性特征。为便于后续分析，我们为各视图的一致性特征引入标识，以区分它们，即 $\{c^{(v)}\}_{v=1}^{m}$。引入这一标识不会改变模型架构。此外，我们引入权衡参数 α [10]，控制重构质量与正则化之间的权衡，得到如下下界：

$$\begin{aligned}
&\mathcal{L}_{consist} = \\
&\frac{1}{|\mathcal{W}|}\sum_{v\in\mathcal{W}}\Big[\mathbb{E}_{q_{\phi_v}(c^{(v)}|x^{(v)})}\Big[\sum_{i\in\mathcal{W}}\log p_{\theta_i}(x^{(i)}|c^{(v)})\Big] \\
&\qquad\qquad - \alpha D_{KL}(q_{\phi_v}(c^{(v)} \mid x^{(v)})\|p(c))\Big]
\end{aligned} \tag{3}$$

这里，$q_{\phi_v}(c^{(v)} \mid x^{(v)})$ 可视为一个编码器，并假设 $q_{\phi_v}(c^{(v)} \mid x^{(v)}) \sim \mathcal{N}\left(\mu_{\phi_v}(x^{(v)}), \sigma_{\phi_v}^2(x^{(v)})I\right)$，其中，$\mu_{\phi_v}(x^{(v)})$ 和 $\sigma_{\phi_v}^2(x^{(v)})$ 分别表示第 v 个视图的均值编码器和方差编码器，I 为单位矩阵。由于采样过程不可微，我们引入重参数化技巧 [16] 获得特征：

$$c^{(v)} = \mu_{\phi_v}(x^{(v)}) + \sigma_{\phi_v}(x^{(v)}) \odot \delta \tag{4}$$

其中，$\delta \sim \mathcal{N}(0, I)$，$\odot$ 表示 Hadamard 积，$c^{(v)} \in \mathbb{R}^{d_e}$，$d_e$ 为特征维数。式（3）中的分布 $p_{\theta_i}\left(x^{(i)} \mid c^{(v)}\right)$ 由一个 MLP 解码器建模，假定 $p_{\theta_i}\left(x^{(i)} \mid c^{(v)}\right) \sim \mathcal{N}\left(\mu_{\theta_i}(c^{(v)}), I\right)$，得到重构特征 $\widehat{x}^{(i,v)} = \mu_{\theta_i}(c^{(v)})$。

对式（3）的简要分析如下：第一项同时表示视图内自重构和跨视图重构。它允许每个视图的 $c^{(v)}$ 重构不同视图的原始数据，有助于 $c^{(v)}$ 捕获共享信息。第二项即 KL 散度，将每个视图的后验 $q_{\phi_v}(c^{(v)} \mid x^{(v)})$ 与共享先验 $p(c) \sim \mathcal{N}(0, I)$ 对齐。这两项共同促使 $c^{(v)}$ 编码视图之间的共享信息。

最后，为得到可用于分类任务、由多个视图共享的融合一致性特征，我们使用专家乘积（Product-of-Expert，PoE）方法 [11] 计算多视图联合后验 $p(c \mid \{x\})$。该方法在视图缺失时直接移除相应参数，因此能够灵活、有效地处理视图缺失。按照文献 [32] 的设置，我们如下计算 $p(c \mid \{x\})$：

$$
\begin{aligned}
p(c|\{x\}) &\propto p(c) \prod_{v \in \mathcal{W}} p(c \mid x^{(v)}) \\
&:= p(c) \prod_{v \in \mathcal{W}} q_{\phi_v}(c^{(v)} \mid x^{(v)})
\end{aligned}
\tag{5}
$$

我们采用相同的重参数化技巧，从 $p(c \mid \{x\})$ 中采样，得到融合后的多视图一致性特征 $\bar{c} \in \mathbb{R}^{d_e}$。

3.3 解耦的视图特有特征

本节引入视图特有特征 $\{s^{(v)}\}_{v=1}^{m}$，用于编码一致性特征之外、每个视图所特有的信息。我们考虑最小化每个视图中一致性特征与特有特征之间的互信息 $I(c^{(v)}; s^{(v)})$，从而尽可能充分地将特有特征与一致性特征解耦。一个自然的思路是先学习一致性特征，再从中解耦特有特征 [15]。因此，我们首先使用 $\mathcal{L}_{consist}$ 进行一定轮数的预训练，轮数取决于数据集规模。第二阶段，我们降低一致性特征编码器 $\{q_{\phi_v}(c^{(v)} \mid x^{(v)})\}_{v=1}^{m}$ 的学习率，使预训练特征在进一步解耦时保持稳定。我们的解耦目标函数如下：

$$
\min \frac{1}{|\mathcal{W}|} \sum_{v \in \mathcal{W}} I(c^{(v)}; s^{(v)}) \tag{6}
$$

我们将 $I(c^{(v)}; s^{(v)})$ 改写如下，更多细节见补充材料第 6.2 节：

$$
I(c^{(v)}; s^{(v)}) = I(x^{(v)}; c^{(v)}) + I(x^{(v)}; s^{(v)}) - I(x^{(v)}; c^{(v)}, s^{(v)}) \tag{7}
$$

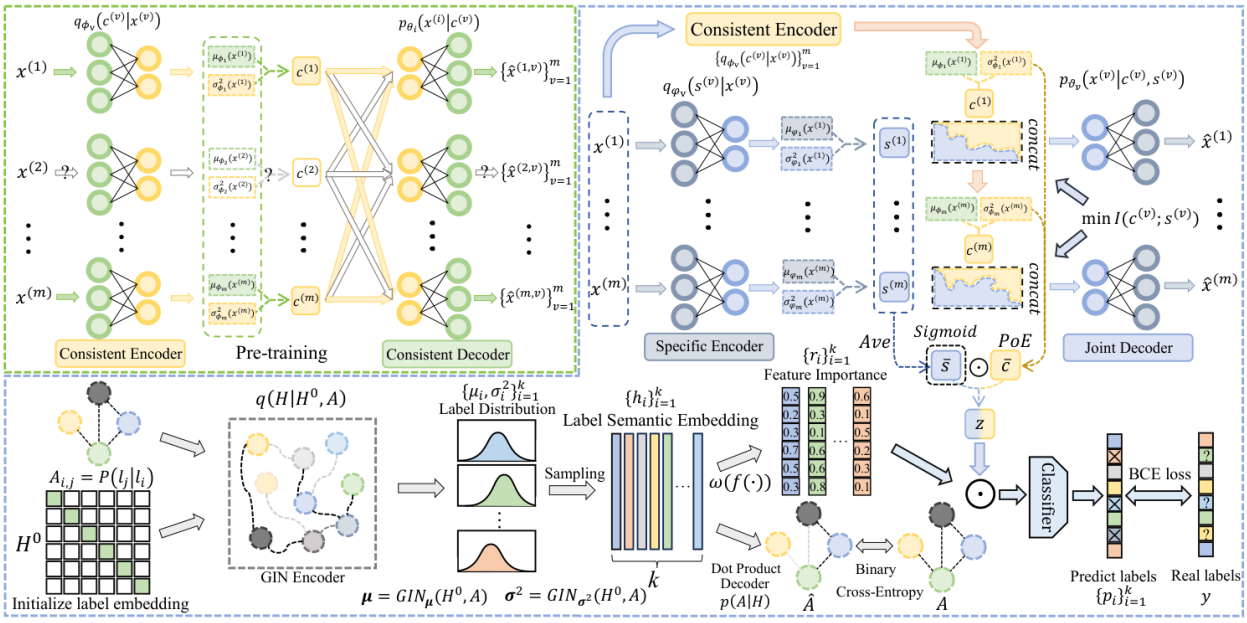


图 1　DRLS 的主要框架。左上角为视图一致性特征学习模块，右上角为解耦的视图特有特征学习模块，下方为标签语义嵌入学习模块。

图内英文释义： Consistent Encoder / Decoder：一致性编码器／解码器；Pre-training：预训练；Specific Encoder：特有特征编码器；Joint Decoder：联合解码器；concat：拼接；Ave：取平均；PoE：专家乘积；Sigmoid：Sigmoid 激活；Initialize label embedding：初始化标签嵌入；GIN Encoder：GIN 编码器；Label Distribution：标签分布；Sampling：采样；Label Semantic Embedding：标签语义嵌入；Feature Importance：特征重要性；Dot Product Decoder：内积解码器；Binary Cross-Entropy / BCE loss：二元交叉熵／损失；Classifier：分类器；Predict labels：预测标签；Real labels：真实标签。

显然，直接优化式（7）具有挑战性。因此，我们引入 $I(x^{(v)}; c^{(v)})$ 和 $I(x^{(v)}; s^{(v)})$ 的变分上界，以及 $I(x^{(v)}; c^{(v)}, s^{(v)})$ 的变分下界 [14]，得到：

$$\begin{aligned} I(c^{(v)}; s^{(v)}) \le\ & D_{KL}(q_{\phi_v}(c^{(v)}|x^{(v)})\|p(c^{(v)})) \\ & + D_{KL}(q_{\varphi_v}(s^{(v)}|x^{(v)})\|p(s^{(v)})) \\ & -\mathbb{E}_{q_{\phi_v}(c^{(v)}|x^{(v)})q_{\varphi_v}(s^{(v)}|x^{(v)})}[\log p_{\vartheta_v}(x^{(v)}|c^{(v)}, s^{(v)})] \end{aligned} \tag{8}$$

可以看到，最小化这一互信息的变分上界，会训练一个解码器 $p_{\vartheta_v}(x^{(v)} \mid c^{(v)}, s^{(v)})$ 和一个特有特征编码器 $q_{\varphi_v}(s^{(v)} \mid x^{(v)})$。这里，我们将 $c^{(v)}$ 与 $s^{(v)}$ 拼接，作为 MLP 解码器 $p_{\vartheta_v}(x^{(v)} \mid c^{(v)}, s^{(v)})$ 的输入，生成重构特征 $\widehat{x}^{(v)}$。与第 3.2 节类似，$q_{\varphi_v}(s^{(v)} \mid x^{(v)}) \sim \mathcal{N}\left(\mu_{\varphi_v}(x^{(v)}), \sigma^2_{\varphi_v}(x^{(v)})I\right)$ 对特有特征的分布进行参数化。特征 $s^{(v)} \in \mathbb{R}^{d_e}$ 通过式（4）所示的重参数化技巧得到。我们假设 $p(c^{(v)})$ 和 $p(s^{(v)})$ 均服从标准高斯分布。最终得到解耦损失：

$$\mathcal{L}_{disent} = \frac{1}{|\mathcal{W}|}\sum_{v\in\mathcal{W}}\big[D_{KL}(q_{\phi_v}(c^{(v)}|x^{(v)})\|p(c^{(v)})) + D_{KL}(q_{\varphi_v}(s^{(v)}|x^{(v)})\|p(s^{(v)})) - \mathbb{E}_{q_{\phi_v}(c^{(v)}|x^{(v)})q_{\varphi_v}(s^{(v)}|x^{(v)})}[\log p_{\vartheta_v}(x^{(v)}|c^{(v)}, s^{(v)})]\big] \tag{9}$$

比较式（3）与式（9）可见，一致性目标函数要求每个一致性特征 $c^{(v)}$ 跨视图重构原始特征；而在解耦损失中，我们仅将一致性特征与特有特征的拼接用于本视图的自重构。我们先预训练了一组编码器 $\{q_{\phi_v}(c^{(v)} \mid x^{(v)})\}_{v=1}^{m}$，然后在第二阶段将 $c^{(v)}$ 与 $s^{(v)}$ 拼接以重构 $x^{(v)}$。由于 $c^{(v)}$ 已经包含了 $x^{(v)}$ 与其他视图之间共享的信息，$s^{(v)}$ 只需编码 $c^{(v)}$ 尚未捕获的互补信息。这一预训练策略使解耦更加高效。我们采用一种简单有效的方法，得到用于后续分类任务的融合多视图特有特征 $\bar{s} \in \mathbb{R}^{d_e}$：

$$\bar{s} = \frac{1}{|\mathcal{W}|}\sum_{v\in\mathcal{W}} s^{(v)} \tag{10}$$

这里，我们没有像第 3.2 节那样使用 PoE 融合特有特征，因为 PoE 更适合合并共享信息。PoE 对不同视图之间的共识较为敏感 [18]。具体而言，如果某一视图的概率分布过于尖锐且存在偏差，联合分布就会产生有偏的均值预测 [1, 18, 26]。考虑到不同视图的特有特征通常存在差异，我们选择简单的平均融合方法，以减轻极端变化并保留总体趋势。

最后，我们融合多视图的一致性信息与特有信息。按照文献 [23] 的方法，我们使用特有特征增强一致性特征：

$$z = \omega(\bar{s}) \odot \bar{c} \tag{11}$$

$z \in \mathbb{R}^{d_e}$ 表示最终的融合表征，$\omega(\cdot)$ 为 sigmoid 激活函数，$\odot$ 表示 Hadamard 积。

3.4 标签语义嵌入

为充分利用不完整的监督信息，我们引入由先验信息引导的标签语义嵌入学习。我们在变分图自编码器（Variational Graph Autoencoder，VGAE）[17] 框架下构建模型，该框架在学习过程中使用变分推断，对标签嵌入的潜在分布进行建模。

首先，我们定义标签之间的关系图 $G = (V, E)$，其中 V 表示节点（类别），E 表示连接节点的边。我们用条件概率对图 G 的邻接矩阵 $A \in \mathbb{R}^{k\times k}$ 建模，具体采用 $P(l_j \mid l_i)$，表示标签 l_i 出现时标签 l_j 出现的概率，其中 l_i 表示第 i 个标签。该概率根据训练集的标签矩阵 $Y \in \mathbb{R}^{n_{train}\times k}$ 计算。由于 $P(l_j \mid l_i)$ 不等于 $P(l_i \mid l_j)$，邻接矩阵 A 是非对称的，这能更准确地反映实际情形。具体计算方式如下：

$$A_{ij} = \begin{cases} P(l_j|l_i) = \frac{C_{ij}}{d_i}, & \text{if } i \neq j \\ 0, & \text{if } i = j \end{cases} \tag{12}$$

其中，$C = Y^\top Y$，$C \in \mathbb{R}^{k\times k}$ 为标签共现矩阵，C_{ij} 为标签 l_i 与 l_j 的共现次数。对于 $i = 1, 2, \ldots, k$，$d_i = \sum_{a=1}^{n_{train}} Y_{ai} = Y_{:i}^\top Y_{:i}$，表示标签 l_i 出现的总次数。需要注意，我们将邻接矩阵 A 的对角线设为 0。

图同构网络（Graph Isomorphism Network，GIN）通过可学习权重和自身节点信息，提供更强的特征聚合能力 [34]。因此，我们使用 GIN 对标签语义嵌入 $H \in \mathbb{R}^{k\times d_e}$ 的后验分布建模：

$$\begin{aligned} q(H|H^0, A) &= \prod_{i=1}^{k} q(h_i|H^0, A), \\ \text{with } q(h_i|H^0, A) &\sim \mathcal{N}(\mu_i, \sigma_i^2 I) \end{aligned} \tag{13}$$

这里，$h_i \in \mathbb{R}^{d_e}$ 为 H 的第 i 行，表示第 i 个标签的语义嵌入；$H^0 \in \mathbb{R}^{k\times k}$ 为单位矩阵，即将标签 i 的嵌入初始化为第 i 个位置为 1 的独热向量。这一做法确保不同标签的初始距离较大，有助于后续学习更好地区分标签之间的语义差异。$\boldsymbol{\mu} = \mathrm{GIN}_{\mu}(H^0, A)$，$\boldsymbol{\mu} \in \mathbb{R}^{k\times d_e}$ 为均值矩阵，其中第 i 行对应第 i 个标签的均值向量 μ_i；类似地，$\boldsymbol{\sigma}^2 = \mathrm{GIN}_{\sigma^2}(H^0, A)$。这里，我们采用三层 GIN，其中一层可定义为：

$$H^{(t+1)} = f^{(t+1)}\left[(1 + \epsilon^{(t+1)})H^{(t)} + AH^{(t)}\right].$$

t 表示当前网络层数，$\epsilon^{(t+1)}$ 表示可学习参数，$f^{(t+1)}$ 表示一个两层全连接网络。$H^{(t+1)} \in \mathbb{R}^{k\times d_{t+1}}$ 表示中间层输出。

随后，我们同样使用重参数化技巧对标签语义嵌入进行采样，公式类似于式（4），即 $h_i = \mu_i + \sigma_i \odot \delta$，$\delta \sim \mathcal{N}(0, I)$。最终得到标签语义嵌入矩阵 H。我们采用简单高效的变量内积作为生成模型：

$$\begin{aligned} p(A|H) &= \prod_{i=1}^{k}\prod_{j=1}^{k} p(A_{ij}|h_i, h_j), \\ \text{with } p(A_{ij}|h_i, h_j) &= \omega(h_i^\top h_j) \end{aligned} \tag{14}$$

其中，$\omega(\cdot)$ 为 sigmoid 激活函数。将标签相关性矩阵作为图的邻接矩阵，使 GIN 能够将语义相关的嵌入聚合到标签语义空间中彼此接近的位置。但是，这无法保证不相关标签被有效地推离。因此，我们引入 VGAE 的生成模型来重构邻接矩阵 A，确保标签语义嵌入在语义空间中有效保留标签相关性的拓扑结构。最终，我们的变分下界为：

$$\mathcal{L}_{le} = \mathbb{E}_{q(H|H^0,A)}[\log p(A|H)] - D_{KL}(q(H|H^0, A)\|p(H)) \tag{15}$$

我们进一步采用高斯先验 $p(H) = \prod_i p(h_i) = \prod_i \mathcal{N}(h_i \mid 0, I)$。我们使用二元交叉熵计算 $\mathcal{L}_{le}$ 的第一项，作为重构损失；并在计算交叉熵损失前，向 A 加上单位矩阵，以免其零对角线强制导致 $\omega(h_i^\top h_i) \approx 0$。

3.5 总体损失函数

最后，我们利用标签语义嵌入进行特征选择，为每个标签选取具有判别性和特异性的特征。首先，通过全连接层 $f(\cdot)$ 将学到的标签语义嵌入 h_i 映射为特征重要性向量 [9]，具体为 $r_i = \omega(f(h_i))$，其中 $r_i \in \mathbb{R}^{d_e}$，$\omega(\cdot)$ 为 sigmoid 激活函数。随后，使用 r_i 选择特征，并将选出的特征输入一个简单神经网络，获得预测：

$$p_i = \omega\left(f_{cls}\left(z \odot r_i\right)\right) \tag{16}$$

其中，$\odot$ 表示 Hadamard 积，f_{cls} 为全连接网络，p_i 为样本被标记为第 i 类的预测概率。我们使用常用的二元交叉熵函数计算多标签分类损失：

$$\mathcal{L}_{BCE} = -\frac{1}{|\mathcal{U}|}\sum_{i\in\mathcal{U}}\left(y_i \log p_i + (1-y_i)\log(1-p_i)\right) \tag{17}$$

其中，y_i 表示真实标签。我们将缺失标签排除在损失计算之外，以过滤其影响。最终损失函数为：

$$\mathcal{L} = \mathcal{L}_{BCE} + \beta\mathcal{L}_{disent} - \gamma\mathcal{L}_{le} \tag{18}$$

其中，β 和 γ 为平衡不同损失项的权衡参数。

4 实验

4.1 数据集

我们根据文献 [21, 23, 31] 的设置，在五个数据集上进行实验，评估所提出模型的性能。这些数据集为 Corel5k [5]、Pascal07 [6]、Espgame [29]、IAPRTC12 [8] 和 Mirflickr [13]。在这五个数据集中，我们使用六种不同的特征，即 DenseHue、DenseSift、GIST、HSV、RGB 和 LAB，维数依次为 100、1000、512、4096、4096 和 4096。更详细的信息见表 1。

Dataset	m	n	k	n/k
Corel5k	6	4999	260	3.396
Pascal07	6	9963	20	1.465
Espgame	6	20770	268	4.686
IAPRTC12	6	19627	291	5.719
Mirflickr	6	25000	38	4.716

表 1　五个多视图多标签数据集的统计信息。m 表示视图数，n 表示样本数，k 表示类别数，n/k 表示每个样本的平均标签数（符号依原文保留）。Dataset：数据集。

4.2 对比方法

实验中，我们选择八种方法与本模型比较：DM2L [24]、CDMM [40]、iMvWL [27]、NAIML [20]、DDINet [31]、DICNet [22]、MTD [23] 和 SIP [21]。需要指出，iMvWL、NAIML、DDINet、DICNet、MTD 和 SIP 都是不完整多视图多标签方法。CDMM 只能处理完整的多视图多标签数据；因此，我们遵循文献 [21] 的设置，对缺失视图使用对应视图中可用实例的均值填补不可用实例。为处理不完整标签，我们将缺失标签视为负标签。DM2L 是一种单视图不完整多标签方法，实验中记录各视图中的最佳结果。

4.3 实现细节

为模拟真实世界的数据缺失，我们按照文献 [27] 和 [21] 的设置生成不完整数据集。对于每个视图，我们随机剔除 50% 的实例，同时确保每个样本至少有一个视图。此外，我们随机删除 50% 的正标签和 50% 的负标签。缺失特征和缺失标签均用零填充。我们使用 70% 的样本进行训练，其余 30% 用于验证和测试。为确保结果稳定，我们将实验重复 10 次，并报告结果的均值和方差。其他细节见补充材料第 7 节。

4.4 评价指标

与一些已有研究 [21, 23, 31] 一致，我们在实验中采用六种常用的多标签分类指标评估模型性能，分别为平均精确率（Average Precision，AP）、受试者工作特征曲线下面积（Area Under the Receiver Operating Characteristic Curve，AUC）、排序损失（Ranking Loss，RL）、汉明损失（Hamming Loss，HL）、单错误率（OneError，OE）和覆盖度（Coverage，Cov）。为更直观地呈现结果，我们以 1-RL、1-HL、1-OE 和 1-Cov 记录最终结果，这些数值越大表示性能越好。

4.5 实验结果

表 2 展示了九种方法在五个公开多视图多标签数据集上的实验结果，包含六个评价指标。表 2 的结果是在视图缺失率为 50%、标签缺失率为 50%、训练样本占 70% 的实验设置下得到的。表中结果表明，在大多数数据集上，我们的方法在各项指标上均优于其他八个竞争方法。例如，在 IAPRTC12 数据集的

AP 指标上，我们的方法比排名第二的 MTD 高 2.4%。具体而言，Ave.R 表示每种方法在六项指标上的平均排名，DRLS 在全部五个数据集上均排名第一，充分证明了我们的方法解决 DIMVMLC 问题的有效性。

表 2　九种方法在五个数据集上的实验结果。 设置为 50% 视图缺失、50% 标签缺失、70% 训练样本。Ave.R 为每种方法在六项指标上的平均排名，右下角的小数字为标准差。Dataset：数据集；Metric：指标。为便于阅读，原表按数据集分为以下三段，后两段重复表头；数值、字体和底色均按原表保留。

Dataset	Metric	DM2L	CDMM	iMvWL	NAIML	DDINet	DICNet	MTD	SIP	DRLS
Corel5k	AP	$0.262_{0.005}$	$0.354_{0.004}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.360_{0.009}$	$0.378_{0.004}$	$0.413_{0.007}$	$0.416_{0.015}$	$0.433_{0.008}$
	1-HL	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$
	1-RL	$0.843_{0.002}$	$0.884_{0.003}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.865_{0.005}$	$0.877_{0.004}$	$0.892_{0.004}$	$0.910_{0.003}$	$0.916_{0.002}$
	AUC	$0.845_{0.002}$	$0.888_{0.003}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.868_{0.005}$	$0.881_{0.003}$	$0.895_{0.004}$	$0.912_{0.003}$	$0.918_{0.002}$
	1-OE	$0.295_{0.014}$	$0.410_{0.007}$	$0.311_{0.015}$	$0.350_{0.009}$	$0.437_{0.012}$	$0.464_{0.012}$	$0.491_{0.010}$	$0.492_{0.018}$	$0.509_{0.019}$
	1-Cov	$0.647_{0.005}$	$0.723_{0.007}$	$0.702_{0.008}$	$0.725_{0.005}$	$0.689_{0.012}$	$0.714_{0.010}$	$0.748_{0.009}$	$0.786_{0.007}$	$0.804_{0.006}$
	Ave.R	8.167	4.833	7.667	5.333	6.000	4.833	2.667	1.833	1.000
Pascal07	AP	$0.471_{0.008}$	$0.508_{0.005}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.532_{0.010}$	$0.502_{0.007}$	$0.550_{0.004}$	$0.550_{0.009}$	$0.567_{0.008}$
	1-HL	$0.928_{0.001}$	$0.931_{0.001}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.932_{0.001}$	$0.930_{0.001}$	$0.932_{0.001}$	$0.931_{0.002}$	$0.934_{0.001}$
	1-RL	$0.761_{0.005}$	$0.812_{0.004}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.808_{0.005}$	$0.781_{0.007}$	$0.830_{0.003}$	$0.825_{0.006}$	$0.843_{0.004}$
	AUC	$0.779_{0.004}$	$0.838_{0.003}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.829_{0.004}$	$0.805_{0.006}$	$0.849_{0.004}$	$0.845_{0.005}$	$0.864_{0.003}$
	1-OE	$0.420_{0.011}$	$0.419_{0.008}$	$0.362_{0.023}$	$0.421_{0.006}$	$0.448_{0.015}$	$0.426_{0.013}$	$0.457_{0.008}$	$0.463_{0.012}$	$0.477_{0.011}$
	1-Cov	$0.692_{0.004}$	$0.759_{0.003}$	$0.677_{0.015}$	$0.727_{0.002}$	$0.757_{0.005}$	$0.728_{0.007}$	$0.783_{0.004}$	$0.777_{0.005}$	$0.798_{0.004}$
	Ave.R	7.667	4.833	9.000	6.500	4.167	6.167	2.167	2.833	1.000

Dataset	Metric	DM2L	CDMM	iMvWL	NAIML	DDINet	DICNet	MTD	SIP	DRLS
Espgame	AP	$0.212_{0.002}$	$0.289_{0.003}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.286_{0.004}$	$0.299_{0.004}$	$0.306_{0.003}$	$0.310_{0.004}$	$0.326_{0.005}$
	1-HL	$0.982_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$
	1-RL	$0.781_{0.001}$	$0.832_{0.001}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.815_{0.003}$	$0.833_{0.003}$	$0.837_{0.001}$	$0.849_{0.002}$	$0.858_{0.002}$
	AUC	$0.785_{0.001}$	$0.836_{0.001}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.819_{0.003}$	$0.837_{0.002}$	$0.842_{0.001}$	$0.853_{0.002}$	$0.862_{0.002}$
	1-OE	$0.294_{0.006}$	$0.396_{0.005}$	$0.343_{0.013}$	$0.339_{0.003}$	$0.427_{0.010}$	$0.437_{0.010}$	$0.448_{0.006}$	$0.451_{0.012}$	$0.473_{0.001}$
	1-Cov	$0.488_{0.003}$	$0.574_{0.004}$	$0.548_{0.004}$	$0.571_{0.003}$	$0.553_{0.005}$	$0.598_{0.006}$	$0.601_{0.004}$	$0.628_{0.004}$	$0.652_{0.003}$
	Ave.R	8.833	4.500	8.000	5.667	5.500	3.500	2.667	1.833	1.000
IAPRTC12	AP	$0.234_{0.003}$	$0.305_{0.004}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.302_{0.005}$	$0.327_{0.005}$	$0.332_{0.002}$	$0.331_{0.007}$	$0.356_{0.006}$
	1-HL	$0.980_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$
	1-RL	$0.823_{0.002}$	$0.862_{0.002}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.853_{0.002}$	$0.872_{0.002}$	$0.875_{0.001}$	$0.887_{0.004}$	$0.896_{0.003}$
	AUC	$0.825_{0.001}$	$0.864_{0.002}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.855_{0.003}$	$0.873_{0.001}$	$0.876_{0.001}$	$0.888_{0.003}$	$0.898_{0.002}$
	1-OE	$0.340_{0.006}$	$0.432_{0.008}$	$0.352_{0.008}$	$0.390_{0.005}$	$0.435_{0.009}$	$0.465_{0.013}$	$0.471_{0.006}$	$0.466_{0.001}$	$0.490_{0.012}$
	1-Cov	$0.529_{0.004}$	$0.597_{0.004}$	$0.564_{0.005}$	$0.592_{0.004}$	$0.594_{0.007}$	$0.648_{0.005}$	$0.649_{0.002}$	$0.679_{0.008}$	$0.707_{0.007}$
	Ave.R	8.333	4.500	8.167	6.667	5.667	4.167	2.333	2.167	1.000

Dataset	Metric	DM2L	CDMM	iMvWL	NAIML	DDINet	DICNet	MTD	SIP	DRLS
Mirflickr	AP	$0.514_{0.006}$	$0.570_{0.002}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.588_{0.003}$	$0.586_{0.005}$	$0.608_{0.004}$	$0.615_{0.004}$	$0.630_{0.005}$
	1-HL	$0.878_{0.001}$	$0.886_{0.001}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.001}$	$0.888_{0.001}$	$0.891_{0.001}$	$0.891_{0.001}$	$0.895_{0.001}$
	1-RL	$0.831_{0.003}$	$0.856_{0.001}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.865_{0.002}$	$0.861_{0.004}$	$0.875_{0.001}$	$0.878_{0.002}$	$0.885_{0.002}$
	AUC	$0.828_{0.003}$	$0.846_{0.001}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.853_{0.002}$	$0.848_{0.004}$	$0.861_{0.002}$	$0.864_{0.002}$	$0.872_{0.003}$
	1-OE	$0.510_{0.008}$	$0.631_{0.004}$	$0.511_{0.022}$	$0.585_{0.003}$	$0.636_{0.008}$	$0.642_{0.006}$	$0.656_{0.004}$	$0.664_{0.006}$	$0.686_{0.009}$
	1-Cov	$0.604_{0.005}$	$0.640_{0.001}$	$0.572_{0.013}$	$0.631_{0.002}$	$0.654_{0.003}$	$0.646_{0.006}$	$0.677_{0.002}$	$0.676_{0.004}$	$0.692_{0.003}$
	Ave.R	8.167	6.000	8.833	7.000	4.167	4.667	2.667	2.167	1.000

此外，进一步分析实验结果可以发现，CDMM、DDINet、DICNet、MTD 和 SIP 在全部五个数据集上都优于其他三种方法。这些方法均为深度学习方法，说明深度学习在解决 DIMVMLC 问题方面具有巨大潜力。

除解决 DIMVMLC 问题外，我们还进一步验证了本方法解决 MVMLC 问题的性能。表 3 展示了四种方法在五个数据集上的实验结果，实验设置为 70% 训练样本、完整视图和完整标签。我们选择了三个有代表性的评价指标。表 3 的结果表明，在这一设置下，我们的模型仍表现出有竞争力的性能，说明本方法能够有效处理 MVMLC 问题。

Dataset	Metric	DICNet	MTD	SIP	DRLS
Corel5k	AP	0.504	0.486	0.520	0.551
	1-RL	0.925	0.921	0.937	0.947
	AUC	0.928	0.924	0.939	0.949
Pascal07	AP	0.609	0.652	0.645	0.655
	1-RL	0.860	0.890	0.887	0.889
	AUC	0.875	0.898	0.899	0.901
Espgame	AP	0.388	0.397	0.356	0.399
	1-RL	0.872	0.880	0.875	0.893
	AUC	0.875	0.883	0.878	0.896
IAPRTC12	AP	0.428	0.441	0.366	0.447
	1-RL	0.910	0.916	0.904	0.926
	AUC	0.911	0.916	0.906	0.927
Mirflickr	AP	0.661	0.682	0.676	0.698
	1-RL	0.897	0.906	0.907	0.915
	AUC	0.879	0.888	0.890	0.898

表 3　四种方法在五个数据集上的实验结果。设置为完整视图、完整标签和 70% 训练样本。Dataset：数据集；Metric：指标。

4.6 参数分析

DRLS 模型有三个需要调整的超参数：α、β 和 γ。为评估模型对这些超参数的敏感性，我们在 Corel5k 和 Pascal07 数据集上进行实验，设置为 50% 视图缺失、50% 标签缺失和 70% 训练样本。

图 2a 和图 2b 展示了不同 β、γ 组合下模型的 AP 值；图 2c 和图 2d 展示了不同 α 取值下的 AP 和 AUC 值。为确保实验有效，其他无关超参数保持固定。根据图 2a 和图 2b，对于 Corel5k 数据集，β 和 γ 分别取 $\left[10^{-3},\ 10^{-1}\right]$ 与 $\left[10^{-5},\ 10^{-3}\right]$ 范围；对于 Pascal07 数据集，β 和 γ 也分别取 $\left[10^{-3},\ 10^{-1}\right]$ 与 $\left[10^{-5},\ 10^{-3}\right]$ 范围。在这些条件下，模型表现良好。关于超参数 α，从图 2c 和图 2d 可以看到，在两个数据集上，AP 和 AUC 的变化都很小，表明模型对 α 不敏感。我们将 α 设置在 $\left[10^{-1},\ 3\times10^{-1}\right]$ 范围内。

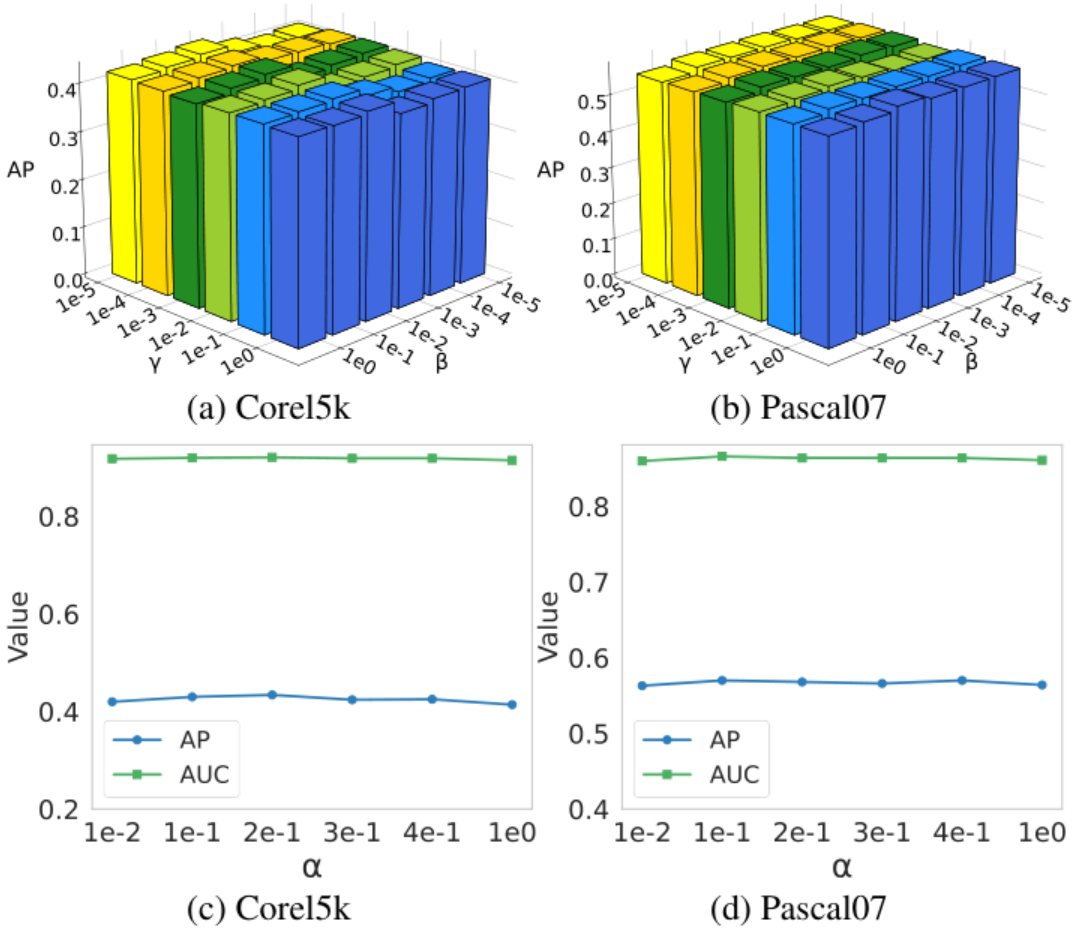


图 2　Corel5k（a）和 Pascal07（b）数据集上不同 β 与 γ 组合对应的 AP 值；Corel5k（c）和 Pascal07（d）数据集上不同 α 值对应的 AP 和 AUC 值。Value：指标值；图中 1e-5 等记法表示相应的十进制科学计数法。

4.7 消融研究

我们的模型由多个模块和目标函数组成。为进一步分析各模块和目标函数的贡献，我们在 Corel5k 和 Pascal07 数据集上进行了系列消融实验，设置为 50% 视图缺失和 50% 标签缺失。

Method	Corel5k			Pascal07		
	AP	1-RL	AUC	AP	1-RL	AUC
A	0.416	0.909	0.912	0.559	0.836	0.858
A+B	0.431	0.913	0.916	0.563	0.840	0.863
DRLS	0.433	0.916	0.918	0.567	0.843	0.864
DRLS w/o $\mathcal{L}_{con.kl}$	0.415	0.908	0.911	0.541	0.823	0.846
DRLS w/o $\mathcal{L}_{disent}$	0.414	0.913	0.916	0.557	0.834	0.857
DRLS w/o $\mathcal{L}_{le}$	0.430	0.913	0.915	0.565	0.842	0.863

表 4　两个数据集上的消融结果。设置为 50% 视图缺失、50% 标签缺失和 70% 训练样本。“w/o”表示“不使用”；“A”表示一致性特征提取模块，“B”表示解耦的特有特征提取模块，DRLS 表示完整模型。$L_{con.kl}$ 表示 $L_{consist}$ 的 KL 散度项。Method：方法。

消融实验结果见表 4。具体而言，我们先测试仅使用一致性特征提取模块的模型性能；然后加入解耦的特有特征提取模块；最后再加入标签语义嵌入学习模块。从这三组实验设置可以看到，每个模块都对模型性能有所贡献。此外，观察表 4 可以发现，解耦的特有特征提取模块对提升模型性能起着关键作用；标签语义嵌入学习模块也有助于增强模型的分类能力。

我们还验证了不同目标函数对模型性能的影响。去除 $\mathcal{L}_{con.kl}$ 或 $\mathcal{L}_{disent}$ 会导致模型性能明显下降。其中，$\mathcal{L}_{con.kl}$ 是预训练阶段使用的目标函数。实验结果表明，$\mathcal{L}_{con.kl}$ 起到正则化作用，能够减少共享特征中的冗余信息。解耦损失 $\mathcal{L}_{disent}$ 负责将一致性特征与特有特征分离，从而提高特有特征的质量。

5 结论

本文提出一种新颖的不完整多视图多标签学习框架。基于多视图数据的一致性与互补性假设，我们构建了使用解耦表征与标签语义嵌入的方法（DRLS）。首先，通过跨视图重构学习视图一致性特征，并通过无监督预训练降低特有特征的解耦难度。接着，通过最小化一致性特征与特有特征之间互信息的变分上界，实现特有特征的解耦学习。同时，我们借助标签相关性先验指导标签语义嵌入学习，以聚合相关语义嵌入，并在语义空间中保持标签相关性的拓扑结构。最后，我们进行了大量实验，证明本方法在处理视图缺失与标签缺失问题上的有效性。

致谢。 本研究得到国家自然科学基金（62476166）和上海市浦江人才计划（22PJD029）的支持。

参考文献

以下保留全部作者、英文题名、来源、卷期、页码、年份及原文引用页码；中文题名为译文补充，便于阅读。第 [40] 与 [41] 条为原文重复条目，按原编号保留。第 [21] 条的年份在原稿中未列出，不予补填。

[1] Ana Lawry Aguila and Andre Altmann. A tutorial on multi-view autoencoders using the multi-view-ae library. 【使用 multi-view-ae 库的多视图自编码器教程】arXiv preprint arXiv:2403.07456, 2024. 原文引用页：4。

[2] Luigi Antelmi, Nicholas Ayache, Philippe Robert, and Marco Lorenzi. Sparse multi-channel variational autoencoder for the joint analysis of heterogeneous data. 【用于异质数据联合分析的稀疏多通道变分自编码器】In International Conference on Machine Learning, pages 302-311. PMLR, 2019. 原文引用页：2。

[3] Yusheng Cheng, Qingyan Li, Yibin Wang, and Weijie Zheng. Multi-view multi-label learning with view feature attention allocation. 【基于视图特征注意力分配的多视图多标签学习】Neurocomputing, 501:857-874, 2022. 原文引用页：2。

[4] Bassoma Diallo, Jie Hu, Tianrui Li, Ghufran Ahmad Khan, Xinyan Liang, and Hongjun Wang. Auto-attention mechanism for multi-view deep embedding clustering. 【用于多视图深度嵌入聚类的自动注意力机制】Pattern Recognition, 143:109764, 2023. 原文引用页：1。

[5] Pinar Duygulu, Kobus Barnard, Joao FG de Freitas, and David A Forsyth. Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary. 【将物体识别视为机器翻译：为固定图像词汇学习词典】In Computer Vision-ECCV 2002: 7th European Conference on Computer Vision Copenhagen, Denmark, May 28-31, 2002 Proceedings, Part IV 7, pages 97-112. Springer, 2002. 原文引用页：6。

[6] Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, and Andrew Zisserman. The pascal visual object classes (voc) challenge. 【PASCAL 视觉物体类别（VOC）挑战】International journal of computer vision, 88:303-338, 2010. 原文引用页：6。

[7] Arthur Gretton, Olivier Bousquet, Alex Smola, and Bernhard Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. 【使用 Hilbert-Schmidt 范数度量统计依赖性】In International conference on algorithmic learning theory, pages 63-77. Springer, 2005. 原文引用页：2。

[8] Michael Grubinger, Paul Clough, Henning Müller, and Thomas Deselaers. The iapr tc-12 benchmark: A new evaluation resource for visual information systems. 【IAPR TC-12 基准：用于视觉信息系统的新评价资源】In International workshop ontoImage, 2006. 原文引用页：6。

[9] Jun-Yi Hang and Min-Ling Zhang. Collaborative learning of label semantics and deep label-specific features for multi-label classification. 【面向多标签分类的标签语义与深层标签特有特征协同学习】IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(12):9860-9871, 2021. 原文引用页：5。

[10] Irina Higgins, Loic Matthey, Arka Pal, Christopher P Burgess, Xavier Glorot, Matthew M Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-vae: Learning basic visual concepts with a constrained variational framework. 【beta-VAE：利用受约束变分框架学习基本视觉概念】ICLR (Poster), 3, 2017. 原文引用页：3。

[11] Geoffrey E Hinton. Training products of experts by minimizing contrastive divergence. 【通过最小化对比散度训练专家乘积模型】Neural computation, 14(8):1771-1800, 2002. 原文引用页：3。

[12] Sheng-Jun Huang and Zhi-Hua Zhou. Multi-label learning by exploiting label correlations locally. 【利用局部标签相关性的多标签学习】In Proceedings of the AAAI Conference on Artificial Intelligence, pages 949-955, 2012. 原文引用页：1。

[13] Mark J Huiskes and Michael S Lew. The mir flickr retrieval evaluation. 【MIR Flickr 检索评价】In Proceedings of the 1st ACM international conference on Multimedia information retrieval, pages 39-43, 2008. 原文引用页：6。

[14] HyeongJoo Hwang, Geon-Hyeong Kim, Seunghoon Hong, and Kee-Eung Kim. Variational interaction information maximization for cross-domain disentanglement. 【用于跨域解耦的变分交互信息最大化】Advances in Neural Information Processing Systems, 33:22479-22491, 2020. 原文引用页：4, 1。

[15] Guanzhou Ke, Bo Wang, Xiaoli Wang, and Shengfeng He. Rethinking multi-view representation learning via distilled disentangling. 【通过蒸馏解耦重新思考多视图表征学习】In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 26774-26783, 2024. 原文引用页：3。

[16] Diederik P Kingma. Auto-encoding variational bayes. 【自编码变分贝叶斯】arXiv preprint arXiv:1312.6114, 2013. 原文引用页：3。

[17] Thomas N Kipf and Max Welling. Variational graph auto-encoders. 【变分图自编码器】arXiv preprint arXiv:1611.07308, 2016. 原文引用页：5。

[18] Ana Lawry Aguila, James Chapman, and Andre Altmann. Multi-modal variational autoencoders for normative modelling across multiple imaging modalities. 【用于跨多种成像模态常模建模（normative modelling）的多模态变分自编码器】In International Conference on Medical Image Computing and Computer-Assisted Intervention, pages 425-434. Springer, 2023. 原文引用页：4。

[19] Haobin Li, Yunfan Li, Mouxing Yang, Peng Hu, Dezhong Peng, and Xi Peng. Incomplete multi-view clustering via prototype-based imputation. 【通过基于原型的插补实现不完整多视图聚类】arXiv preprint arXiv:2301.11045, 2023. 原文引用页：1。

[20] Xiang Li and Songcan Chen. A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning. 【用于非对齐不完整多视图与缺失多标签学习的简洁有效模型】IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918-5932, 2021. 原文引用页：2, 6。

[21] Chengliang Liu, Gehui Xu, Jie Wen, Yabo Liu, Chao Huang, and Yong Xu. Partial multi-view multi-label classification via semantic invariance learning and prototype modeling. 【通过语义不变性学习与原型建模实现部分多视图多标签分类】In Forty-first International Conference on Machine Learning. 原文引用页：2, 6。

[22] Chengliang Liu, Jie Wen, Xiaoling Luo, Chao Huang, Zhihao Wu, and Yong Xu. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. 【DICNet：用于双重不完整多视图多标签分类的深层实例级对比网络】In Proceedings of the AAAI conference on artificial intelligence, pages 8807-8815, 2023. 原文引用页：1, 2, 6。

[23] Chengliang Liu, Jie Wen, Yabo Liu, Chao Huang, Zhihao Wu, Xiaoling Luo, and Yong Xu. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. 【用于不完整多视图弱多标签学习的掩码双通道解耦框架】Advances in Neural Information Processing Systems, 36, 2024. 原文引用页：1, 4, 6。

[24] Zhongchen Ma and Songcan Chen. Expand globally, shrink locally: Discriminant multi-label learning with missing labels. 【全局扩展、局部收缩：标签缺失下的判别式多标签学习】Pattern Recognition, 111:107675, 2021. 原文引用页：6。

[25] William McGill. Multivariate information transmission. 【多变量信息传输】Transactions of the IRE Professional Group on Information Theory, 4(4):93-111, 1954. 原文引用页：1。

[26] Yuge Shi, Brooks Paige, Philip Torr, et al. Variational mixture-of-experts autoencoders for multi-modal deep generative models. 【用于多模态深度生成模型的变分混合专家自编码器】Advances in neural information processing systems, 32, 2019. 原文引用页：4。

[27] Qiaoyu Tan, Guoxian Yu, Carlotta Domeniconi, Jun Wang, and Zili Zhang. Incomplete multi-view weak-label learning. 【不完整多视图弱标签学习】In Ijcai, pages 2703-2709, 2018. 原文引用页：2, 6。

[28] Chang Tang, Zhenglai Li, Jun Wang, Xinwang Liu, Wei Zhang, and En Zhu. Unified one-step multi-view spectral clustering. 【统一的一步多视图谱聚类】IEEE Transactions on Knowledge and Data Engineering, 35(6):6449-6460, 2022. 原文引用页：1。

[29] Luis Von Ahn and Laura Dabbish. Labeling images with a computer game. 【通过计算机游戏标注图像】In Proceedings of the SIGCHI conference on Human factors in computing systems, pages 319-326, 2004. 原文引用页：6。

[30] Xu Wang, Dezhong Peng, Peng Hu, and Yongsheng Sang. Adversarial correlated autoencoder for unsupervised multi-view representation learning. 【用于无监督多视图表征学习的对抗相关自编码器】Knowledge-Based Systems, 168:109-120, 2019. 原文引用页：1。

[31] Jie Wen, Chengliang Liu, Shijie Deng, Yicheng Liu, Lunke Fei, Ke Yan, and Yong Xu. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views. 【标签不完整与视图缺失下的深度双重不完整多视图多标签学习】IEEE transactions on neural networks and learning systems, 2023. 原文引用页：1, 2, 6。

[32] Mike Wu and Noah Goodman. Multimodal generative models for scalable weakly-supervised learning. 【用于可扩展弱监督学习的多模态生成模型】Advances in neural information processing systems, 31, 2018. 原文引用页：3。

[33] Xuan Wu, Qing-Guo Chen, Yao Hu, Dengbao Wang, Xiaodong Chang, Xiaobo Wang, and Min-Ling Zhang. Multi-view multi-label learning with view-specific information extraction. 【具有视图特有信息提取的多视图多标签学习】In IJCAI, pages 3884-3890, 2019. 原文引用页：1, 2。

[34] Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. How powerful are graph neural networks? 【图神经网络究竟有多强大？】arXiv preprint arXiv:1810.00826, 2018. 原文引用页：5。

[35] Xiaoqiang Yan, Shizhe Hu, Yiqiao Mao, Yangdong Ye, and Hui Yu. Deep multi-view learning methods: A review. 【深度多视图学习方法综述】Neurocomputing, 448:106-129, 2021. 原文引用页：1。

[36] Jun Yin and Shiliang Sun. Incomplete multi-view clustering with reconstructed views. 【利用重构视图的不完整多视图聚类】IEEE Transactions on Knowledge and Data Engineering, 35(3):2671-2682, 2021. 原文引用页：1。

[37] Jun Yin and Wentao Zhang. Multi-view multi-label learning with double orders manifold preserving. 【保持双阶流形的多视图多标签学习】Applied Intelligence, 53(12):14703-14716, 2023. 原文引用页：1。

[38] Jun Yin, Shiliang Sun, Lai Wei, and Pei Wang. Discriminatively fuzzy multi-view k-means clustering with local structure preserving. 【保持局部结构的判别式模糊多视图 k-means 聚类】In Proceedings of the AAAI Conference on Artificial Intelligence, pages 16478-16485, 2024. 原文引用页：1。

[39] Honglin Yuan, Shiyun Lai, Xingfeng Li, Jian Dai, Yuan Sun, and Zhenwen Ren. Robust prototype completion for incomplete multi-view clustering. 【用于不完整多视图聚类的鲁棒原型补全】In Proceedings of the 32nd ACM International Conference on Multimedia, pages 10402-10411, 2024. 原文引用页：1。

[40] Dawei Zhao, Qingwei Gao, Yixiang Lu, Dong Sun, and Yusheng Cheng. Consistency and diversity neural network multi-view multi-label learning. 【一致性与多样性神经网络多视图多标签学习】Knowledge-Based Systems, 218:106841, 2021. 原文引用页：2, 6。

[41] Dawei Zhao, Qingwei Gao, Yixiang Lu, Dong Sun, and Yusheng Cheng. Consistency and diversity neural network multi-view multi-label learning. 【一致性与多样性神经网络多视图多标签学习】Knowledge-Based Systems, 218:106841, 2021. 原文引用页：1。

[42] Yue Zhu, James T Kwok, and Zhi-Hua Zhou. Multi-label learning with global and local label correlation. 【结合全局与局部标签相关性的多标签学习】IEEE Transactions on Knowledge and Data Engineering, 30(6):1081-1094, 2017. 原文引用页：1。