面向不完整多视图多标签分类的标签引导表示学习

非官方中文全文译文 | 原文：Label-Guided Representation Learning for Incomplete Multi-View Multi-Label Classification

Yang Li、Quanjiang Li、Tingjin Luo。前两位作者贡献相同。国防科技大学理学院，中国长沙。通信作者：Tingjin Luo，tingjinluo@hotmail.com。

原文刊于第43届国际机器学习大会（ICML），韩国首尔，PMLR 306:67904-67927，2026；版权归作者所有。仓库目录中的“2025”不是论文首页所载年份。本译文依据仓库内与官方版本 SHA-256 相同的24页 PDF 制作。原文与许可：https://proceedings.mlr.press/v306/li26cg.html；https://proceedings.mlr.press/pmlr-license-agreement.html；CC BY 4.0：https://creativecommons.org/licenses/by/4.0/。

翻译及排版属于对原作的改编，非作者审定版本，不表示作者或出版方认可。正文、附录、证明、图表说明及算法全部译为中文；参考文献保留原文。图、表保留原图数据，并附中文图注和术语对照；所有公式编号保留。原稿中的理论推导、数值、图文差异按原样保留，不作未经声明的纠正。

摘要

不完整多视图多标签分类处理视图和标签部分缺失的情形。现有方法仅将标签视为监督信号，忽略了部分标注所蕴含的语义结构。为解决这一问题，我们提出标签引导表示学习（Label-Guided Representation Learning，LGRL），系统地将标签语义作为结构先验信息加以利用。具体而言，我们通过可学习的类别原型构建语义感知混合先验，显式引导跨视图的表示提取。此外，引入类别特定的条件后验，利用这些原型作为贝叶斯专家来支配多视图融合。我们进一步推导出有原则依据的标签驱动信息瓶颈目标，在重构充分性与跨视图一致性之间取得平衡，实现类别条件推理。大量实验结果表明，LGRL 在基准数据集以及体育分析和医学影像应用中均具有有效性。

1. 引言

多视图学习利用异构数据来源中的互补信息，捕获比单视图方法更丰富的语义表示（Pan & Kang, 2021；Yang et al., 2021；Yuan et al., 2025）。多标签分类则同时用多个语义属性刻画对象（Si et al., 2023）。现实应用往往同时具备这两种特征：一篇新闻可以由文本内容、相关图片和用户评论共同描述，同时属于政治、经济、社会等多个类别（Ye et al., 2024；Chen et al., 2024）。这两种范式的融合形成了多视图多标签分类（MvMLC）。实践中，获取完整的多视图多标签数据往往成本过高，或在技术上不可行。传感器故障、隐私约束和标注成本经常造成视图缺失或标签集不完整（Wang et al., 2025；Tan et al., 2018；Luo et al., 2025）。这种双重不完整性带来了重大挑战：视图缺失破坏跨视图依赖关系建模，而部分标签既无法提供充分监督，又掩盖了标签相关结构。因此，不完整多视图多标签分类（iMvMLC）因能处理现实世界中的一般情形而受到越来越多关注。

现有 iMvMLC 方法主要沿三个方向发展。第一类侧重于视图不完整条件下的鲁棒特征提取。早期矩阵分解方法，如 iMVWL（Tan et al., 2018），学习对缺失视图鲁棒的共享子空间；较新的深度方法，如 DICNet（Liu et al., 2023b），使用实例级对比学习增强共识表示。第二类研究多视图融合策略。LMVCAT（Liu et al., 2023c）利用 Transformer 架构实现跨视图聚合；MFD（Xie et al., 2025）将表示分解为视图一致和视图特定成分；SIP（Liu et al., 2024b）从信息瓶颈角度构建融合；URDF（Wen et al., 2026）引入不确定性驱动的动态融合，估计每个样本的特征可靠性，以得到更可靠的视图聚合。第三类探索标签语义建模。NAIM3L（Li & Chen, 2021）结合全局高秩与局部低秩约束捕获标签相关性；CSA（Shao & Xu, 2025）提出增强型对比学习以实现跨视图语义对齐；SSP（Li et al., 2024）使用图约束学习，在特征提取过程中保持样本间语义结构的一致性；TDLSR（Li et al., 2025）构建视图特定的样本拓扑和原型关联图，得到带有理论泛化保证的标签特定表示。

尽管取得了上述进展，现有方法仍未充分利用标签语义，多数方法依然只将标签作为输出层的监督信号。我们从递进的三个层面指出局限。首先，在标签层面，部分标注编码了有意义的共现模式，例如“海滩”会提高“海洋”的可能性，同时降低“山脉”的可能性，但这类标签间语义结构很少被显式建模和利用。其次，在表示层面，现有方法仅通过输出层的分类损失使用标签信息，而潜在表示学习本身与标签无关，导致表示虽然能较好保留输入信息，却缺少与标签关系相匹配的显式语义结构。最后，在融合层面，当前机制将多视图信息聚合为单一共享表示（Wen et al., 2023；Tan et al., 2024；Liu et al., 2024b），隐含地假定所有类别均能同样受益于相同的特征组合。实际上，不同类别往往依赖不同的视图贡献，而与类别无关的融合方式通常不能捕捉这种异质性，从而产生次优表示（Zhang et al., 2024）。

针对这些局限，我们提出标签引导表示学习（LGRL），这是一个系统利用标签语义指导表示提取和多视图融合的统一框架。对于标签引导的表示提取，我们推导标签感知信息瓶颈目标，平衡重构充分性与跨视图一致性，确保所学表示在标签监督引导下保留任务相关信息。为进一步将标签语义编码到潜在空间，我们引入带有可学习类别原型的语义驱动混合先验，通过对比学习鼓励样本靠近正原型、远离负原型，形成能够捕捉标签共现模式的几何结构化潜在空间。对于标签引导的多视图融合，我们引入类别特定的条件后验，使每个原型成为专家乘积（Product-of-Experts，PoE）框架中的精度加权专家。这一设计实现了假设驱动的多标签推理，依据类别特定的语义线索自适应调节视图贡献。最后，我们在六个基准以及 NBA 球员分析、胸部 X 线片筛查等场景中评估 LGRL 的有效性。主要贡献如下。

- 提出 LGRL 统一框架，系统利用标签语义，同时指导 iMvMLC 的表示提取和多视图融合。
- 推导标签感知信息瓶颈目标，并引入可学习类别原型，通过对比对齐在潜在空间中施加语义结构，得到能够捕捉标签共现模式的判别性表示。
- 设计类别特定的条件后验，以原型作为贝叶斯专家，实现基于假设的推理，并针对各类别的语义特征调整融合权重。
- 大量实验表明，在不同缺失比例下，LGRL 持续优于当前先进方法。

2. 方法

如第1节所述，现有 iMvMLC 方法未充分利用部分标注中的语义信息。我们提出 LGRL，将标签语义同时融入表示学习和多视图融合。如图1所示，LGRL 包含三个部分：（1）通过可学习类别原型将标签语义编码到潜在空间几何结构中的语义驱动混合先验；（2）平衡重构充分性和跨视图一致性的任务相关学习目标；（3）以原型作为专家开展基于假设推理的贝叶斯融合机制。

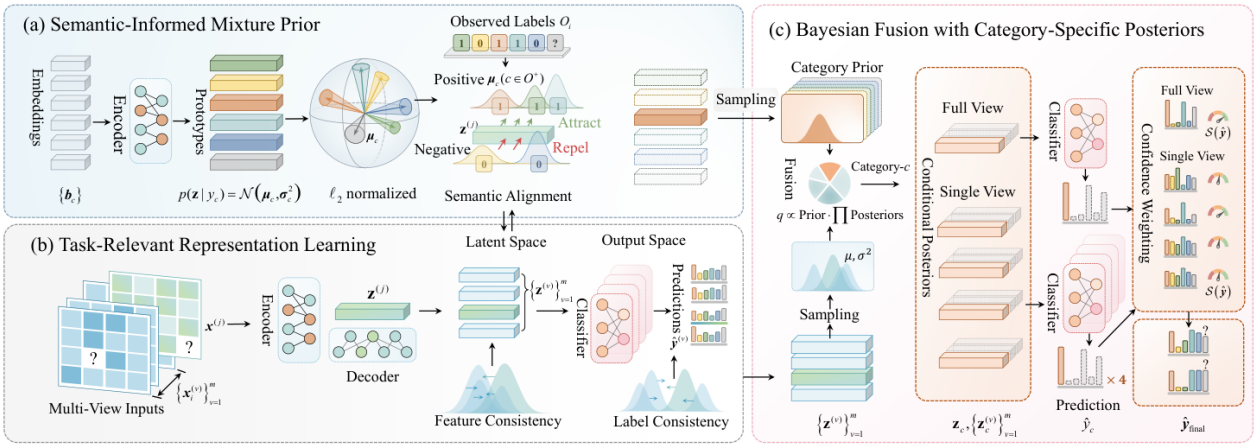


图1. LGRL 概览。（a）语义驱动混合先验通过可学习类别原型编码标签关系。（b）任务相关表示学习在特征层和标签层同时施加一致性。（c）贝叶斯融合将类别先验融入后验计算，完成基于假设的预测。图内术语：Observed Labels=已观测标签；Positive/Negative=正/负；Attract/Repel=吸引/排斥；Embeddings=嵌入；Prototypes=原型；Semantic Alignment=语义对齐；Encoder/Decoder=编码器/解码器；Sampling=采样；Multi-View Inputs=多视图输入；Latent Space/Output Space=潜在空间/输出空间；Classifier=分类器；Feature/Label Consistency=特征/标签一致性；Category Prior=类别先验；View Posteriors=视图后验；Conditional Posteriors=条件后验；Full View/Single View=全视图/单视图；Fusion=融合；Confidence Weighting=置信度加权；Prediction(s)=预测。

2.1. 问题表述

考虑包含 n 个样本的数据集 $\mathcal{D} = \{\left(\{\mathbf{x}_i^{(v)}\}_{v=1}^{m}, \mathbf{y}_i\right)\}_{i=1}^{n}$，其中每个样本 i 对应 m 个视图和一个多标签标注。第 v 个视图表示为 $\mathbf{x}_i^{(v)} \in \mathbb{R}^{d_v}$，标签向量 $\mathbf{y}_i \in \{0, 1\}^C$ 编码其在 C 个类别中的归属。

在实际情形中，视图和标签都存在不完整性。令 $\mathcal{V}_i \subseteq \{1, \ldots, m\}$ 表示样本 i 的可用视图集合。对于标签，令 $\mathcal{O}_i \subseteq \{1, \ldots, C\}$ 表示同时包含正标注和负标注的已观测集合，$\mathcal{U}_i = \{1, \ldots, C\} \backslash \mathcal{O}_i$ 为未观测的补集。给定不完整观测 $\{\left(\{\mathbf{x}_i^{(v)}\}_{v \in \mathcal{V}_i}, \{y_{i,c}\}_{c \in \mathcal{O}_i}\right)\}_{i=1}^{n}$，目标是学习共享表示 $\mathbf{z}_i \in \mathbb{R}^{d_z}$，使其对视图缺失具有鲁棒性，并能够准确预测完整标签向量 $\mathbf{y}_i$。

2.2. 语义驱动混合先验

标准变分框架采用无信息先验 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$，将潜在空间视为没有语义结构。我们认为，即使是部分标签标注也揭示了有价值的结构，包括标签共现模式和类别间关系，这些结构应当为表示的几何形态提供信息。因此，我们构建显式编码此类结构的语义驱动混合先验。

每个类别 $c \in \{1, \ldots, C\}$ 都关联一个专用的可学习原型分布：

$$p(\mathbf{z} \mid y_c = 1) = \mathcal{N}(\boldsymbol{\mu}_c, \operatorname{diag}(\boldsymbol{\sigma}_c^2)). \qquad (1)$$

原型参数由专用标签编码器从可训练类别嵌入 $\{\mathbf{b}_c \in \mathbb{R}^{d_b}\}_{c=1}^{C}$ 生成。每个嵌入 $\mathbf{b}_c$ 初始化为独热向量，经两个独立的两层 MLP 变换，产生 $\boldsymbol{\mu}_c = h_\mu(\mathbf{b}_c)$ 和 $\boldsymbol{\sigma}_c^2 = \mathrm{softplus}(h_\sigma(\mathbf{b}_c))$，其中 $h_\mu, h_\sigma : \mathbb{R}^{d_b} \to \mathbb{R}^{d_z}$。随着训练进行，嵌入通过与已观测标签的联合优化逐渐演变，以捕捉标签相关性。

对于已观测标签为 $\mathcal{O}$ 的样本，通过对比学习将其潜在表示与语义结构对齐。具体而言，正标签对应的类别原型应吸引所学表示，负标签对应的类别原型则应排斥所学表示。对经过 ℓ_2 归一化的表示 $\widetilde{\mathbf{z}} = \mathbf{z}/\parallel \mathbf{z} \parallel$ 和原型 $\widetilde{\boldsymbol{\mu}}_c = \boldsymbol{\mu}_c/\parallel \boldsymbol{\mu}_c \parallel$，语义对齐损失定义为

$$\mathcal{L}_{SA} = -\sum_{c\in\mathcal{O}^+} \log \frac{\exp\left(\widetilde{\mathbf{z}}^\top \widetilde{\boldsymbol{\mu}}_c/\tau\right)}{\sum_{j\in\mathcal{O}} \exp\left(\widetilde{\mathbf{z}}^\top \widetilde{\boldsymbol{\mu}}_j/\tau\right)}. \qquad (2)$$

其中 $\mathcal{O}^+$ 表示 $\mathcal{O}$ 中的正标签，τ 为温度参数。最小化式（2）可组织潜在空间，使标签相似的样本围绕共享原型聚集，而标签不同的样本则被推离。

2.3. 任务相关表示学习

建立结构化先验后，我们通过平衡两个目标来构建学习目标：一是充分性，即保留与重构和分类有关的任务信息；二是一致性，即确保跨视图一致。现有信息瓶颈方法（Liu et al., 2024b）针对共享信息优化一个统一目标；我们则将其分解为特征层和标签层成分，从而独立控制重构质量和分类性能。

在特征层学习中，充分性项 $I(\mathbf{x}^{(v)}; \mathbf{z}^{(v)})$ 保留用于重构的信息，一致性项 $I(\mathbf{x}^{\sim(v)}; \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)})$ 抑制视图特定的伪影。目标为

$$\mathcal{I}_{feat}^{(v)} = I(\mathbf{x}^{(v)}; \mathbf{z}^{(v)}) - \alpha I(\mathbf{x}^{\sim(v)}; \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}). \qquad (3)$$

式中前项为充分性，后项为一致性，$\mathbf{x}^{\sim(v)}$ 表示除视图 v 外的所有视图。

由于特征层学习可能保留低层细节，却丢弃对分类至关重要的语义模式，我们纳入标签信息。充分性项 $I(\mathbf{y}; \mathbf{z}^{(v)})$ 保证预测能力，一致性项 $I(\mathbf{y}; \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)})$ 要求各视图的证据相互一致。标签层信息目标为

$$\mathcal{I}_{label}^{(v)} = I(\mathbf{y}; \mathbf{z}^{(v)}) - \gamma I(\mathbf{y}; \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}). \qquad (4)$$

前项为充分性，后项为一致性；$\mathbf{z}^{\sim(v)}$ 表示除视图 v 外所有视图的潜在表示。统一目标对全部已观测视图求和：

$$\max \sum_{v\in\mathcal{V}} \left[\mathcal{I}_{feat}^{(v)} + \lambda \mathcal{I}_{label}^{(v)}\right], \qquad (5)$$

其中 λ 平衡特征信息与标签信息。

直接优化互信息不可行。因此我们推导变分界，具体包括充分性项的下界和一致性项的上界，完整推导见附录A。对于重构，引入变分解码器 $p_\theta(\mathbf{x}^{(v)} \mid \mathbf{z}^{(v)})$ 可得

$$I(\mathbf{x}^{(v)}; \mathbf{z}^{(v)}) \geq \mathbb{E}_{p(\mathbf{x}^{(v)})} \mathbb{E}_{q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})} \left[\log p_\theta(\mathbf{x}^{(v)} \mid \mathbf{z}^{(v)})\right]. \qquad (6)$$

对于编码器一致性，融合表示 $\mathbf{z}$ 比单独的 $\mathbf{z}^{(v)}$ 汇聚了更多关于其他视图的信息，由此得到上界

$$I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) \le \mathbb{E}_{p(\{\mathbf{x}\})}\Big[D_{KL}\big(q(\mathbf{z} \mid \{\mathbf{x}\}) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big)\Big], \tag{7}$$

其中 $q(\mathbf{z} \mid \{\mathbf{x}\})$ 是通过专家乘积得到的融合后验（第2.4节）。

遵循类似思路，引入分类器 $p_\psi(\mathbf{y} \mid \mathbf{z})$ 可得到标签相关项的界。标签充分性下界为

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)}\big) \ge \mathbb{E}_{p(\mathbf{x}^{(v)})}\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})}\Big[\log p_\psi\big(\mathbf{y} \mid \mathbf{z}^{(v)}\big)\Big]. \tag{8}$$

对于标签一致性，通过比较融合表示与视图特定表示的预测，得到

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) \le \mathbb{E}_{p(\{\mathbf{x}\})}\mathbb{E}_{q(\mathbf{z}\mid\{\mathbf{x}\})}\Big[D_{KL}\big(p_\psi(\mathbf{y} \mid \mathbf{z}) \parallel p_\psi(\mathbf{y} \mid \mathbf{z}^{(v)})\big)\Big]. \tag{9}$$

结合式（6）至（9），将其转为最小化问题，得到特征层损失：

$$\mathcal{L}_{feat}^{(v)} = -\mathbb{E}_{q_\phi(\mathbf{z}\mid\mathbf{x}^{(v)})}\big[\log p_\theta(\mathbf{x}^{(v)} \mid \mathbf{z})\big] + \alpha D_{KL}\big(q(\mathbf{z} \mid \{\mathbf{x}\}) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big). \tag{10}$$

两项分别是重构与编码器一致性。标签层损失为

$$\mathcal{L}_{label}^{(v)} = -\mathbb{E}_{q_\phi(\mathbf{z}\mid\mathbf{x}^{(v)})}\big[\log p_\psi(\mathbf{y} \mid \mathbf{z})\big] + \gamma\mathbb{E}_{q(\mathbf{z}\mid\{\mathbf{x}\})}\Big[D_{KL}\big(p_\psi(\mathbf{y} \mid \mathbf{z}) \parallel p_\psi(\mathbf{y} \mid \mathbf{z}^{(v)})\big)\Big]. \tag{11}$$

两项分别是分类与分类器一致性。任务相关目标将式（10）、（11）在所有可用视图上汇总：

$$\mathcal{L}_{TR} = \sum_{v\in\mathcal{V}}\Big[\mathcal{L}_{feat}^{(v)} + \lambda\mathcal{L}_{label}^{(v)}\Big]. \tag{12}$$

2.4. 具有类别特定后验的贝叶斯融合

LGRL 的一项关键创新，是让类别原型主动参与贝叶斯推断，实现标签引导的多视图融合。虽然混合先验（第2.2节）在表示层捕捉标签共现，但不同类别可能依赖不同的特征组合。例如，检测“纹理”可能更重视边缘模式，而识别“情感”可能更依赖颜色分布。不同于将多视图信息聚合成单一共享表示的方法（Wen et al., 2023；Tan et al., 2024），我们通过类别特定的条件后验将类别语义直接融入融合，实现基于假设的多标签推理。

对于可用视图集合为 $\mathcal{V}$ 的样本，令 $q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)}) = \mathcal{N}\big(\boldsymbol{\mu}^{(v)},\, \mathrm{diag}\big((\boldsymbol{\sigma}^{(v)})^2\big)\big)$ 表示视图 v 的编码器输出。对每个类别 c，条件后验通过专家乘积（PoE）分解为

$$q(\mathbf{z} \mid \{\mathbf{x}\},\, y_c = 1) \propto p(\mathbf{z} \mid y_c = 1)\prod_{v\in\mathcal{V}} q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)}). \tag{13}$$

第一项是类别先验，其余乘积为视图后验。类别先验 $p(\mathbf{z} \mid y_c = 1) = \mathcal{N}\big(\boldsymbol{\mu}_c,\, \mathrm{diag}\big(\boldsymbol{\sigma}_c^2\big)\big)$ 编码类别 c 的预期特征分布，并在融合中充当额外专家。

由于所有成分都是高斯分布，PoE 给出闭式的精度加权参数：

$$\begin{aligned} \tau_c &= \sigma_c^{-2} + \sum_{v\in\mathcal{V}} (\boldsymbol{\sigma}^{(v)})^{-2}, \\ \boldsymbol{\mu}_c^{post} &= \tau_c^{-1}\Big(\sigma_c^{-2}\boldsymbol{\mu}_c + \sum_{v\in\mathcal{V}} (\boldsymbol{\sigma}^{(v)})^{-2}\boldsymbol{\mu}^{(v)}\Big). \end{aligned} \tag{14}$$

其中方差更低（置信度更高）的来源贡献更大。此形式可自然处理视图缺失，因为缺失视图不参与计算即可。

采样 $\mathbf{z}_c \sim \mathcal{N}\left(\boldsymbol{\mu}_c^{post}, \boldsymbol{\tau}_c^{-1}\right)$ 后，通过下式评估假设“ $y_c = 1$ ”：

$$p\left(y_c = 1 \mid \mathbf{z}_c\right) = \sigma\left(f_c\left(\mathbf{z}_c\right)\right), \qquad (15)$$

其中 $f_c(\cdot)$ 是类别特定的分类器。采样得到的 $\mathbf{z}_c$ 将类别 c 的原型纳入先验，使表示偏向与该类别相关的子空间，而分类器评估已观测证据是否支持该假设。

由于各个视图在不同类别上的可靠性可能不同，我们进一步考虑单视图条件后验 $q\left(\mathbf{z} \mid \mathbf{x}^{(v)}, y_c = 1\right) \propto p\left(\mathbf{z} \mid y_c = 1\right) q_\phi\left(\mathbf{z} \mid \mathbf{x}^{(v)}\right)$，总计得到 $1 + |\mathcal{V}|$ 个预测来源。预测通过置信度加权聚合，其中 $S\left(\widehat{\mathbf{y}}\right) = \sum_c \left[\widehat{y}_c^2 + \left(1 - \widehat{y}_c\right)^2\right]$ 偏好明确的预测：

$$\widehat{\mathbf{y}}^{final} = \sum_{k=0}^{|\mathcal{V}|} \frac{\exp\left(S\left(\widehat{\mathbf{y}}^k\right)/\kappa\right)}{\sum_{j=0}^{|\mathcal{V}|} \exp\left(S\left(\widehat{\mathbf{y}}^j\right)/\kappa\right)} \widehat{\mathbf{y}}^k. \qquad (16)$$

其中 $k = 0$ 表示全视图后验， $k \geq 1$ 表示单视图后验， κ 控制权重的尖锐程度。通过在已观测标签上计算二元交叉熵，对聚合预测实施监督：

$$\mathcal{L}_{CE} = -\frac{1}{|\mathcal{O}|} \sum_{c \in \mathcal{O}} \left[y_c \log \widehat{y}_c + \left(1 - y_c\right) \log\left(1 - \widehat{y}_c\right)\right]. \qquad (17)$$

最后，为通过语义先验在表示层、通过置信度加权机制在决策层建立双重鲁棒性，LGRL 的总体目标为

$$\mathcal{L} = \mathcal{L}_{TR} + \beta \mathcal{L}_{SA} + \mathcal{L}_{CE}. \qquad (18)$$

2.5. 网络结构与训练

每个视图 v 配有专用编码器 E_v 和解码器 D_v。编码器将输入 $\mathbf{x}^{(v)} \in \mathbb{R}^{d_v}$ 映射为 $q_\phi(\mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) = \mathcal{N}\left(\boldsymbol{\mu}^{(v)}(\mathbf{x}^{(v)}), \operatorname{diag}\left(\left(\boldsymbol{\sigma}^{(v)}(\mathbf{x}^{(v)})\right)^2\right)\right)$，其中 $\boldsymbol{\mu}^{(v)}, \boldsymbol{\sigma}^{(v)} : \mathbb{R}^{d_v} \to \mathbb{R}^{d_z}$ 为神经网络。采样采用重参数化技巧： $\mathbf{z}^{(v)} = \boldsymbol{\mu}^{(v)}(\mathbf{x}^{(v)}) + \boldsymbol{\sigma}^{(v)}(\mathbf{x}^{(v)}) \odot \boldsymbol{\epsilon}$， $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。

多视图联合后验 $q\left(\mathbf{z} \mid \{\mathbf{x}\}\right)$ 通过 PoE 融合得到，形式为 $\mathcal{N}\left(\boldsymbol{\mu}_{PoE}, \operatorname{diag}\left(\boldsymbol{\sigma}_{PoE}^2\right)\right)$，其中 $\boldsymbol{\sigma}_{PoE}^{-2} = \sum_{v \in \mathcal{V}} \left(\boldsymbol{\sigma}^{(v)}\right)^{-2} + \mathbf{1}$， $\boldsymbol{\mu}_{PoE} = \boldsymbol{\sigma}_{PoE}^2 \sum_{v \in \mathcal{V}} \left(\boldsymbol{\sigma}^{(v)}\right)^{-2} \boldsymbol{\mu}^{(v)}$。只有可用视图参与计算，因此能够自然处理缺失。注意，这一融合采用无信息先验 $\mathcal{N}(\mathbf{0}, \mathbf{I})$，用于一致性项；与之不同，式（13）的原型条件融合用于预测。训练期间，类别原型被采样并联合优化；测试时，使用确定性的原型均值 $\{\boldsymbol{\mu}_c = h_\mu(\mathbf{b}_c)\}_{c=1}^C$ 作为固定语义锚点。算法1总结了 LGRL 的主要流程。

算法1：LGRL 训练流程。

1. 输入：数据集 $\mathcal{D}$，超参数 $\alpha, \beta, \gamma, \lambda, \kappa$。
2. 初始化类别嵌入 $\{\mathbf{b}_c\}_{c=1}^C$。
3. 对每个小批量 $\mathcal{B} \subset \mathcal{D}$：

4. 对每个样本 $i \in \mathcal{B}$：
5. 对每个 $v \in \mathcal{V}_i$：
6. 编码：$\left(\boldsymbol{\mu}^{(v)}, (\boldsymbol{\sigma}^{(v)})^2\right) \leftarrow E_v\left(\mathbf{x}_i^{(v)}\right)$。
7. 通过重参数化采样 $\mathbf{z}_i^{(v)}$。
8. 结束视图循环。
9. 通过 PoE 融合视图，得到 $q\left(\mathbf{z} \mid \{\mathbf{x}_i\}\right)$。
10. 对每个类别 $c = 1, \ldots, C$：
11. 生成原型：$\left(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2\right) \leftarrow \left(h_\mu(\mathbf{b}_c), h_\sigma(\mathbf{b}_c)\right)$。
12. 根据式（13）计算条件后验。
13. 采样 $\mathbf{z}_{i,c}$，并根据式（15）预测 $\widehat{y}_{i,c}$。
14. 结束类别循环。
15. 根据式（16）聚合预测。
16. 结束样本循环。
17. 计算 $\mathcal{L} = \mathcal{L}_{TR} + \beta\mathcal{L}_{SA} + \mathcal{L}_{CE}$。
18. 通过最小化 $\mathcal{L}$ 更新参数。
19. 结束小批量循环。

3. 实验

3.1. 实验设置

数据集与指标。我们在六个广泛使用的多视图多标签数据集上开展实验：Corel5k（Duygulu et al., 2002）、ESPGame（Ahn & Dabbish, 2004）、IAPRTC12（Grubinger et al., 2006）、Mirflickr（Huiskes & Lew, 2008）、Pascal07（Everingham et al., 2010）以及 OBJECT（Hao et al., 2024）。遵循 Liu et al.（2023b）和 Wen et al.（2023），采用六项评价指标：汉明损失（HL）、排序损失（RL）、单错误（OE）、覆盖度（Cov）、平均精度（AP）和曲线下面积（AUC）。为便于比较，报告 1-HL、1-OE、1-Cov 和 1-RL，数值越高表示性能越好。

比较方法。将 LGRL 与九种先进方法比较：AIMNet（Liu et al., 2024a）、DICNet（Liu et al., 2023b）、DIMC（Wen et al., 2023）、iMVWL（Tan et al., 2018）、LMVCAT（Liu et al., 2023c）、MTD（Liu et al., 2023a）、SIP（Liu et al., 2024b）、TDLSR（Li et al., 2025）及 LVSL（Zhao et al., 2022）。其中前八种能够同时处理视图缺失和标签缺失。对于不能处理缺失数据的 LVSL，使用特征均值填补缺失视图，用零填补未知标签。所有基线参数均设置为其推荐值。

实现细节。每个数据集按 7:1:2 划分为训练集、验证集和测试集。为模拟不完整场景，按照部分样本比例（Partial Example Ratio，PER），随机将指定比例的视图实例标记为不可用，同时确保每个样本至少保留一个完整视图。对于标签不完整性，按照标签缺失比例（Label Missing Ratio，LMR）随机去掉正标注和负标注。优化采用 Adam，学习率为 10^{-4}，对比温度 $\tau = 0.1$。其余所有超参数 $\alpha, \gamma, \kappa, \lambda, \beta$ 均固定为1。实验在 NVIDIA RTX 4090（24GB）上运行；PER 与 LMR 均为50%时，结果取10次运行平均；其他配置取5次平均。

3.2. 实验结果与分析

为评估 LGRL 处理缺失视图与标签的有效性，我们在六个数据集的不同稀疏程度下，将其与九种方法进行比较。视图（PER）和标签（LMR）的缺失比例均设置为 {30%，50%，70%，90%}。表1报告 PER=50%、LMR=50% 时的均值、标准差，以及各指标上的平均排名。图2展示 PER 和 LMR 从30% 变至90%时的 AP 变化。

DATA	METRIC	AIMNet	DICNet	DIMC	iMVWL	LMVCAT	LVSL	MTD	SIP	TDLSR	LGRL
COR	1-HL	$0.988_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.986_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$
	1-OE	$0.478_{0.011}$	$0.460_{0.012}$	$0.446_{0.009}$	$0.308_{0.017}$	$0.448_{0.011}$	$0.353_{0.017}$	$0.492_{0.011}$	$0.492_{0.014}$	$0.541_{0.014}$	$0.567_{0.016}$
	1-Cov	$0.766_{0.004}$	$0.726_{0.007}$	$0.709_{0.008}$	$0.701_{0.003}$	$0.720_{0.006}$	$0.720_{0.005}$	$0.754_{0.005}$	$0.780_{0.004}$	$0.801_{0.009}$	$0.810_{0.004}$
	1-RL	$0.900_{0.002}$	$0.881_{0.004}$	$0.874_{0.004}$	$0.864_{0.002}$	$0.876_{0.004}$	$0.879_{0.003}$	$0.893_{0.004}$	$0.908_{0.003}$	$0.917_{0.004}$	$0.923_{0.002}$
	AP	$0.404_{0.005}$	$0.381_{0.006}$	$0.370_{0.005}$	$0.281_{0.005}$	$0.379_{0.006}$	$0.311_{0.005}$	$0.414_{0.006}$	$0.414_{0.006}$	$0.450_{0.006}$	$0.469_{0.006}$
	AUC	$0.903_{0.002}$	$0.883_{0.004}$	$0.877_{0.004}$	$0.867_{0.002}$	$0.879_{0.003}$	$0.882_{0.002}$	$0.895_{0.003}$	$0.910_{0.002}$	$0.919_{0.004}$	$0.925_{0.002}$
	AVE	3.500	5.000	7.000	8.500	6.333	6.500	3.667	2.667	1.833	1.000
ESP	1-HL	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$
	1-OE	$0.442_{0.006}$	$0.440_{0.009}$	$0.431_{0.009}$	$0.343_{0.010}$	$0.431_{0.006}$	$0.365_{0.006}$	$0.452_{0.007}$	$0.450_{0.006}$	$0.477_{0.007}$	$0.511_{0.011}$
	1-Cov	$0.621_{0.003}$	$0.601_{0.003}$	$0.586_{0.004}$	$0.548_{0.004}$	$0.587_{0.003}$	$0.578_{0.002}$	$0.617_{0.004}$	$0.622_{0.004}$	$0.646_{0.004}$	$0.671_{0.004}$
	1-RL	$0.845_{0.002}$	$0.836_{0.002}$	$0.830_{0.002}$	$0.807_{0.002}$	$0.827_{0.002}$	$0.829_{0.001}$	$0.843_{0.002}$	$0.847_{0.002}$	$0.859_{0.002}$	$0.871_{0.002}$
	AP	$0.305_{0.003}$	$0.300_{0.003}$	$0.294_{0.003}$	$0.243_{0.004}$	$0.293_{0.003}$	$0.266_{0.003}$	$0.309_{0.003}$	$0.309_{0.004}$	$0.328_{0.004}$	$0.355_{0.004}$
	AUC	$0.850_{0.001}$	$0.841_{0.002}$	$0.835_{0.002}$	$0.813_{0.002}$	$0.832_{0.001}$	$0.834_{0.001}$	$0.847_{0.002}$	$0.851_{0.002}$	$0.863_{0.002}$	$0.876_{0.002}$
	AVE	3.667	5.000	6.000	8.500	6.833	7.000	3.667	2.833	1.833	1.000
IAP	1-HL	$0.981_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$	$0.981_{0.000}$
	1-OE	$0.457_{0.007}$	$0.464_{0.008}$	$0.454_{0.006}$	$0.351_{0.008}$	$0.433_{0.009}$	$0.377_{0.007}$	$0.479_{0.007}$	$0.459_{0.005}$	$0.491_{0.008}$	$0.522_{0.009}$
	1-Cov	$0.675_{0.004}$	$0.649_{0.005}$	$0.630_{0.005}$	$0.565_{0.004}$	$0.646_{0.004}$	$0.605_{0.004}$	$0.670_{0.004}$	$0.678_{0.003}$	$0.706_{0.005}$	$0.731_{0.004}$
	1-RL	$0.884_{0.001}$	$0.874_{0.002}$	$0.868_{0.002}$	$0.833_{0.002}$	$0.868_{0.002}$	$0.857_{0.002}$	$0.882_{0.002}$	$0.886_{0.001}$	$0.899_{0.002}$	$0.910_{0.001}$
	AP	$0.329_{0.003}$	$0.326_{0.003}$	$0.318_{0.002}$	$0.236_{0.002}$	$0.313_{0.004}$	$0.262_{0.002}$	$0.340_{0.002}$	$0.331_{0.003}$	$0.358_{0.004}$	$0.387_{0.004}$
	AUC	$0.885_{0.001}$	$0.876_{0.002}$	$0.870_{0.001}$	$0.835_{0.001}$	$0.870_{0.002}$	$0.859_{0.001}$	$0.883_{0.002}$	$0.887_{0.001}$	$0.899_{0.002}$	$0.911_{0.001}$
	AVE	4.000	4.833	6.167	8.500	6.500	7.333	3.667	3.167	1.833	1.000
MIR	1-HL	$0.890_{0.001}$	$0.890_{0.001}$	$0.890_{0.001}$	$0.840_{0.004}$	$0.880_{0.004}$	$0.877_{0.001}$	$0.893_{0.001}$	$0.890_{0.001}$	$0.896_{0.001}$	$0.897_{0.001}$
	1-OE	$0.646_{0.009}$	$0.647_{0.010}$	$0.645_{0.008}$	$0.511_{0.016}$	$0.639_{0.009}$	$0.609_{0.007}$	$0.667_{0.006}$	$0.654_{0.007}$	$0.690_{0.009}$	$0.727_{0.003}$
	1-Cov	$0.673_{0.003}$	$0.661_{0.004}$	$0.657_{0.003}$	$0.588_{0.013}$	$0.665_{0.002}$	$0.624_{0.002}$	$0.681_{0.002}$	$0.668_{0.006}$	$0.694_{0.003}$	$0.699_{0.003}$
	1-RL	$0.874_{0.002}$	$0.869_{0.003}$	$0.867_{0.003}$	$0.809_{0.014}$	$0.862_{0.003}$	$0.847_{0.001}$	$0.878_{0.001}$	$0.873_{0.002}$	$0.888_{0.002}$	$0.897_{0.002}$
	AP	$0.599_{0.003}$	$0.595_{0.007}$	$0.592_{0.006}$	$0.494_{0.017}$	$0.589_{0.004}$	$0.548_{0.003}$	$0.614_{0.004}$	$0.603_{0.005}$	$0.631_{0.004}$	$0.653_{0.006}$
	AUC	$0.861_{0.001}$	$0.855_{0.002}$	$0.854_{0.002}$	$0.801_{0.017}$	$0.852_{0.003}$	$0.839_{0.001}$	$0.864_{0.001}$	$0.859_{0.002}$	$0.875_{0.001}$	$0.880_{0.001}$
	AVE	4.500	5.667	6.667	9.500	7.167	8.500	3.000	4.500	2.000	1.000
OBJ	1-HL	$0.948_{0.001}$	$0.948_{0.001}$	$0.947_{0.001}$	$0.899_{0.002}$	$0.940_{0.003}$	$0.935_{0.001}$	$0.949_{0.001}$	$0.948_{0.001}$	$0.953_{0.001}$	$0.951_{0.001}$
	1-OE	$0.619_{0.015}$	$0.601_{0.011}$	$0.594_{0.012}$	$0.465_{0.018}$	$0.604_{0.016}$	$0.450_{0.008}$	$0.627_{0.011}$	$0.626_{0.009}$	$0.685_{0.011}$	$0.704_{0.014}$
	1-Cov	$0.806_{0.006}$	$0.794_{0.006}$	$0.793_{0.006}$	$0.744_{0.008}$	$0.796_{0.008}$	$0.759_{0.006}$	$0.812_{0.006}$	$0.809_{0.006}$	$0.834_{0.007}$	$0.832_{0.007}$
	1-RL	$0.888_{0.005}$	$0.876_{0.004}$	$0.875_{0.004}$	$0.833_{0.006}$	$0.878_{0.006}$	$0.850_{0.004}$	$0.890_{0.005}$	$0.889_{0.004}$	$0.910_{0.004}$	$0.909_{0.004}$
	AP	$0.639_{0.010}$	$0.627_{0.009}$	$0.623_{0.010}$	$0.512_{0.014}$	$0.630_{0.012}$	$0.537_{0.008}$	$0.649_{0.009}$	$0.649_{0.009}$	$0.692_{0.009}$	$0.705_{0.010}$
	AUC	$0.897_{0.004}$	$0.886_{0.004}$	$0.885_{0.004}$	$0.846_{0.006}$	$0.888_{0.006}$	$0.864_{0.004}$	$0.900_{0.005}$	$0.898_{0.004}$	$0.918_{0.004}$	$0.916_{0.004}$
	AVE	4.667	6.333	7.333	9.333	5.833	8.667	3.000	3.833	1.333	1.667
PAS	1-HL	$0.931_{0.001}$	$0.931_{0.000}$	$0.931_{0.001}$	$0.882_{0.004}$	$0.915_{0.005}$	$0.928_{0.001}$	$0.933_{0.001}$	$0.932_{0.001}$	$0.933_{0.001}$	$0.935_{0.001}$
	1-OE	$0.462_{0.009}$	$0.443_{0.007}$	$0.435_{0.010}$	$0.366_{0.039}$	$0.433_{0.017}$	$0.418_{0.008}$	$0.473_{0.008}$	$0.468_{0.008}$	$0.495_{0.013}$	$0.526_{0.013}$
	1-Cov	$0.781_{0.007}$	$0.749_{0.003}$	$0.738_{0.010}$	$0.674_{0.011}$	$0.759_{0.006}$	$0.738_{0.003}$	$0.790_{0.006}$	$0.778_{0.004}$	$0.817_{0.004}$	$0.820_{0.006}$
	1-RL	$0.830_{0.006}$	$0.803_{0.002}$	$0.792_{0.008}$	$0.736_{0.011}$	$0.808_{0.006}$	$0.797_{0.002}$	$0.836_{0.005}$	$0.828_{0.004}$	$0.862_{0.004}$	$0.867_{0.005}$
	AP	$0.548_{0.007}$	$0.517_{0.004}$	$0.510_{0.008}$	$0.438_{0.022}$	$0.524_{0.009}$	$0.486_{0.005}$	$0.562_{0.005}$	$0.552_{0.006}$	$0.590_{0.008}$	$0.607_{0.008}$
	AUC	$0.851_{0.005}$	$0.827_{0.002}$	$0.817_{0.008}$	$0.767_{0.011}$	$0.830_{0.006}$	$0.823_{0.002}$	$0.855_{0.005}$	$0.848_{0.005}$	$0.880_{0.003}$	$0.883_{0.004}$
	AVE	4.333	6.333	7.500	9.333	6.333	7.833	2.833	4.333	2.000	1.000

表1. PER=50%、LMR=50% 时十种方法在六个数据集上的实验结果。“AVE”表示对应方法在全部六项指标上的平均排名。DATA=数据集，METRIC=指标。COR、ESP、IAP、MIR、OBJ、PAS 分别为 Corel5k、ESPGame、IAPRTC12、Mirflickr、OBJECT、Pascal07；方法名称保留不译。各单元格均值及下标标准差按原表保留。

由比较结果可作以下观察：（i）我们的方法在六个数据集几乎所有指标上都表现突出。如表1所示，尽管其他方法的排名有所波动，LGRL 在六个数据集中的五个排名第一，在 OBJECT 上排名第二，证明其处理 iMvMLC 问题的有效性。（ii）SIP、MTD 和 TDLSR 具有竞争力，常进入前三。我们将类别特定先验纳入贝叶斯融合，实现针对每个标签的假设推理，从而优于这些方法。在 Corel5k 上，LGRL 的 AP 为0.469，比第二名 TDLSR（0.450）高4.2%，比 MTD 和 SIP（0.414）高13.3%。在 ESPGame 和 IAPRTC12 上相较 TDLSR 也有类似改进，AP 分别提高8.2%和8.1%。（iii）如图2所示，我们的方

法在广泛的缺失比例下具有较强鲁棒性，尤其适合高度不完整的情形。例如，在 Corel5k 和 ESPGame 上，当 PER 达到90%时，多数基线严重退化，而 LGRL 仍输出稳定结果。表4进一步给出了 PER 和 LMR 均为90%这一极端设置下的详细比较。

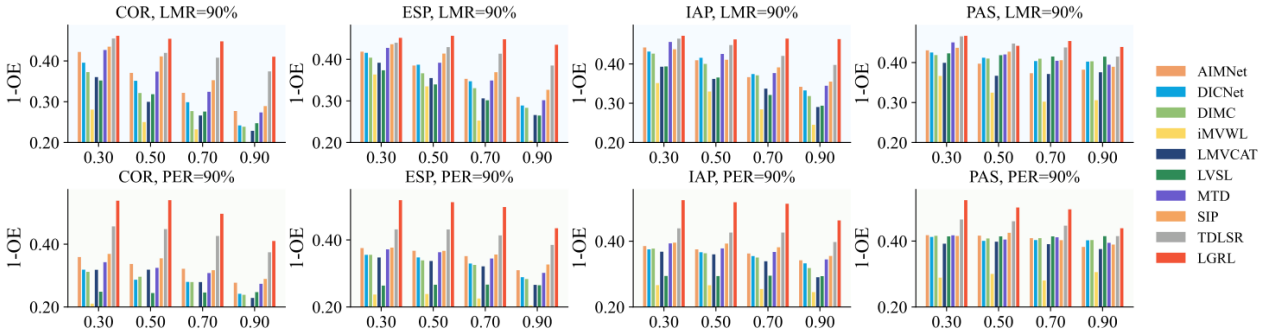


图2. PER 和 LMR 从30%变至90%时，四个数据集上的实验结果。图中横坐标为变化的缺失比例，固定值见各子图标题；纵坐标按原图为 1-OE。译注：正文称其展示 AP，但原图纵轴标为 1-OE；此处保留原稿差异。

3.3. 消融研究

为评估 LGRL 各组成部分的贡献，我们系统地移除语义对齐损失（S1）、任务相关一致性约束（S2）以及类别特定条件后验（S3），开展消融实验。具体而言，移除 S1 即从训练目标中去掉 $\mathcal{L}_{SA}$；移除 S2 即同时去掉编码器与分类器一致性项；移除 S3 即在贝叶斯融合中排除类别原型，将其简化为视图后验上的标准 PoE，不再具有标签引导先验。如表2所示，完整模型始终取得最佳性能，验证了全部三个组成部分的必要性。其中 S3 的影响最明显，证实将类别特定先验纳入融合可实现更有效的假设推理。S2 一致性约束在各数据集上提供稳定改进。S1 语义对齐损失在 Pascal07 和 OBJECT 上带来较明显提升，但对 Corel5k 的影响较小，这可能是因为较大的标签空间增加了表示对齐的难度。

S_1	S_2	S_3	Corel5k				Pascal07				OBJECT				Mirflickr			
			AP	AUC	1-RL	1-OE	AP	AUC	1-RL	1-OE	AP	AUC	1-RL	1-OE	AP	AUC	1-RL	1-OE
✗	✓	✓	0.464	0.922	0.920	0.560	0.586	0.869	0.853	0.502	0.680	0.904	0.897	0.678	0.638	0.871	0.888	0.710
✓	✗	✓	0.455	0.916	0.914	0.548	0.582	0.866	0.850	0.498	0.676	0.901	0.894	0.672	0.633	0.867	0.884	0.703
✓	✓	✗	0.446	0.912	0.910	0.538	0.548	0.842	0.825	0.462	0.635	0.876	0.868	0.632	0.608	0.849	0.865	0.678
✓	✓	✓	**0.469**	**0.925**	**0.923**	**0.567**	**0.607**	**0.883**	**0.867**	**0.526**	**0.705**	**0.916**	**0.909**	**0.704**	**0.653**	**0.880**	**0.897**	**0.727**

表2. PER=50%、LMR=50% 时四个数据集上的消融研究。“√”和“✗”表示是否使用对应模块。S1=语义对齐损失，S2=任务相关一致性约束，S3=类别特定条件后验；数值、方法与指标缩写均按原表保留。

3.4. 参数敏感性与收敛性

分析 LGRL 对超参数 λ 和 β 的敏感性：二者分别平衡特征层与标签层目标，以及控制语义对齐强度。如图3（a-b）所示，当两个参数均处于 $(0.1,\ 1)$ 时，LGRL 性能稳定，体现出对超参数选择的鲁棒性。图3（c-d）展示训练中的收敛行为：LGRL 在前20个训练轮次内迅速收敛，此后保持稳定性能。

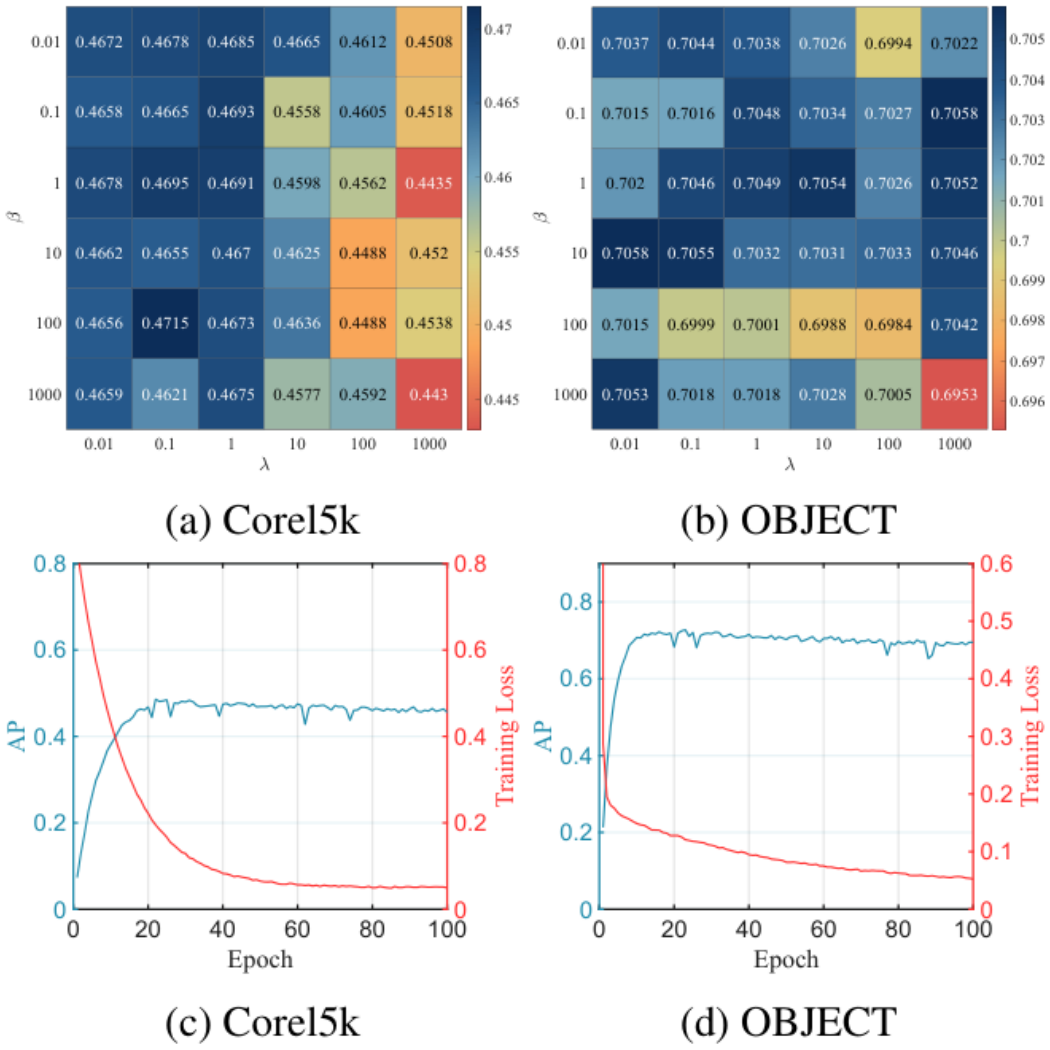


图3. λ、β 的参数敏感性（a-b），以及训练中的收敛行为（c-d）。Epoch=训练轮次，Training Loss=训练损失，AP=平均精度。子图（a）、（c）为 Corel5k，（b）、（d）为 OBJECT。

4. 应用

4.1. NBA 球员潜力预测

评估球员潜力需要整合异构表现统计，同时预测职业发展轨迹、位置角色、获奖可能性等多种属性。在实践中，由于伤病、转会和统计标准不断演变，球员整个职业生涯的数据收集不可避免地存在不完整性。

我们从 Basketball-Reference 构建 NBA 球员数据集，包含2002至2022年间16,992条球员-赛季记录。每个样本汇总六个统计视图：得分、篮板和身体指标、组织进攻、高阶效率指标、球员背景、赛季背景。预测目标包括职业阶段分类（基于职业时间线三等分定义早期、巅峰或后期）、位置识别（PG、SG、SF、PF、C），以及奖项预测（最有价值球员、年度最佳防守球员等）。数据可从 https://www.basketball-reference.com 获取。

我们在 PER 和 LMR 从30%至90%的范围内评估所有方法。如图4（c）所示，LGRL 在这一广泛缺失范围内的平均精度均保持明显优势。此外，图4（e-f）的雷达图表明，我们的方法在 AUC、排序损失等全部六项指标上均有全面改进，在中度（50%）与重度（90%）缺失设置下都表现出较强鲁棒性。

4.2. 胸部 X 线片疾病筛查

胸部 X 线片是初步疾病筛查的重要一线工具。标准胸部成像包括正位和侧位投影，后者可以揭示正位片上被遮挡的病变，例如心后区病变和少量胸腔积液。然而，患者无法移动、床旁便携式成像或基层医疗资源有限等情况，有时使侧位片难以获取。医学影像中的标签不完整也尤为常见，因为全面标注需要投入大量专家精力。

我们从 CheXpert（Irvin et al., 2019）得到数据集，选取31,413项同时包含正位与侧位胸片的检查，将二者作为两个视图。图像转换为 JPEG 格式，通过去掉分类层的预训练 DenseNet-121（Huang et al., 2017）提取视图特定特征，每个视图得到1,024维表示。标签空间包括心脏增大、肺炎、胸腔积液、气胸等14项病理观察。以不同比例模拟视图和标签缺失，以准确反映现实临床情形。

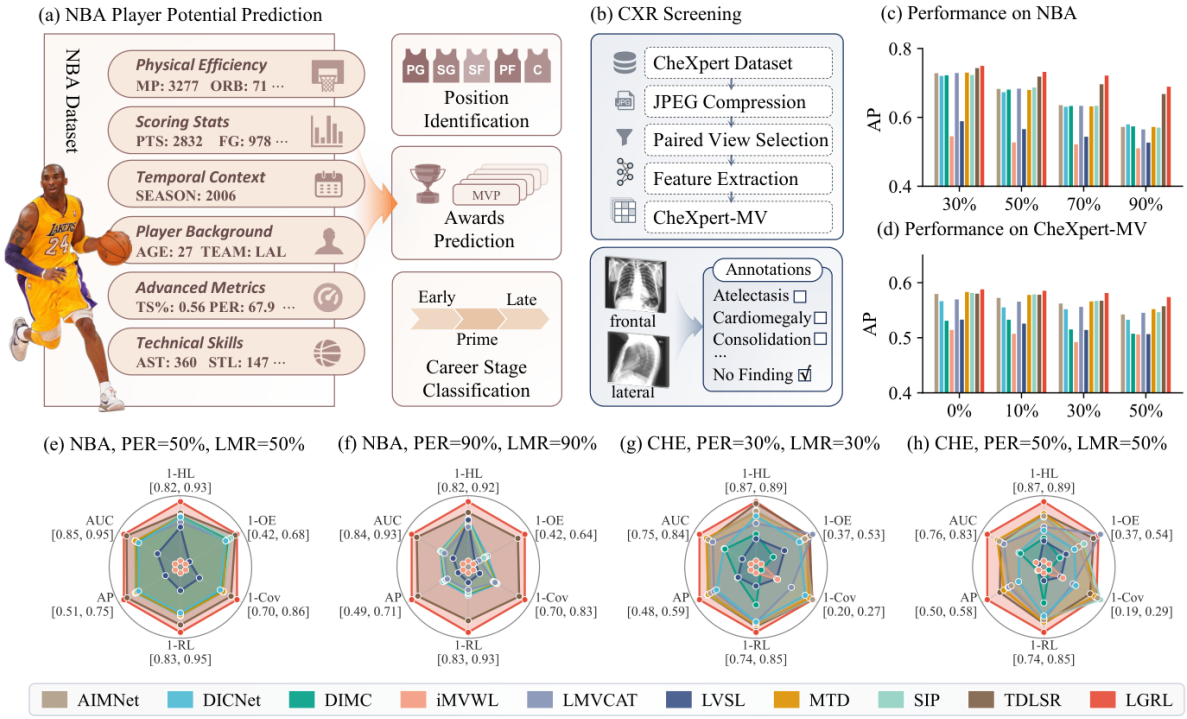


图4. 现实应用和实验性能概览。（a-b）NBA 球员潜力预测和胸片筛查工作流。（c-d）不同缺失比例下的性能（AP）。横坐标为同步变化的 PER 和 LMR，例如30%表示 PER=LMR=30%。（e-h）特定缺失设置下以雷达图全面比较各项指标。图内术语：Position Identification=位置识别；Awards Prediction=奖项预测；Career Stage Classification=职业阶段分类；Early/Prime/Late=早期/巅峰/后期；PG/SG/SF/PF/C=控球后卫/得分后卫/小前锋/大前锋/中锋；Scoring Stats=得分统计；Physical Efficiency=身体效率；Temporal Context=时间背景；Player Background=球员背景；Advanced Metrics=高阶指标；Technical Skills=技术能力；AGE/TEAM/SEASON=年龄/球队/赛季；Frontal/Lateral=正位/侧位；CXR Screening=胸片筛查；JPEG Compression=JPEG 压缩；Paired View Selection=成对视图选择；Feature Extraction=特征提取；Annotations=标注；Atelectasis/No Finding/Cardiomegaly/Consolidation=肺不张/未见异常/心脏增大/肺实变；Performance on=在相

应数据集上的性能。PTS/FG/MP/ORB/TS%/AST/STL=得分/投篮命中数/出场分钟/进攻篮板/真实命中率/助攻/抢断；球员统计中的 PER 指球员效率值，而实验缺失设置中的 PER 指部分样本比例。原图中的球员和胸片示例保留；数据来源说明见正文及参考文献。

图4（d）表明，当同步缺失比例从0%增至50%时，LGRL 始终取得最高 AP。此外，图4（g-h）的雷达图确认 LGRL 的表现均衡，排序和覆盖度指标显著改善，验证其在视图和标签不完整时识别病理表现的有效性。LGRL 的改进表明其具有用于自动初步筛查的潜力，可提供临床提示，帮助放射科医生识别在不完整成像流程下可能被忽略的异常。

5. 结论

本文提出面向不完整多视图多标签分类的标签引导表示学习（LGRL）。LGRL 在整个学习流程中系统利用标签语义：引入可学习类别原型，通过对比对齐在潜在空间施加几何结构；构建任务相关目标，在保证重构和分类的同时施加跨视图一致性；设计类别特定条件后验，实现基于假设的多标签推理。基准数据集及现实应用上的大量实验证明了 LGRL 的优势。不过，目前原型学习随 C 线性增长，对于极大标签空间，原型聚类是自然的扩展方向。我们计划探索更丰富的语义来源，以增强 iMvMLC 的标签语义学习与原型初始化。

致谢

本研究受到国家自然科学基金项目（编号62376281）的部分资助。

影响声明

本文旨在推进面向不完整多视图多标签数据的机器学习。我们展示了其在医学影像（如胸片筛查）中的效用。尽管该方法有助于处理模态缺失，但在高风险临床环境部署前，实践者应仔细评估模型可靠性及潜在偏差。

参考文献（保留英文原文）

Ahn, L. V. and Dabbish, L. Labeling images with a computer game. In SIGCHI Conference on Human Factors in Computing Systems, pp. 319–326, 2004.

Chen, T., Wang, W., Pu, T., Qin, J., Yang, Z., Liu, J., and Lin, L. Dynamic correlation learning and regularization for multi-label confidence calibration. IEEE Transactions on Image Processing, 33:4811–4823, 2024.

Duygulu, P., Barnard, K., de Freitas, J. F. G., and Forsyth, D. A. Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary. In Proceedings of European Conference on Computer Vision, pp. 97–112, 2002.

Everingham, M., Van Gool, L., Williams, C. K., Winn, J., and Zisserman, A. The pascal visual object classes (voc) challenge. International Journal of Computer Vision, 88: 303–338, 2010.

Grubinger, M., Clough, P., Müller, H., and Deselaers, T. The iapr tc-12 benchmark: A new evaluation resource for visual information systems. In International Workshop onto Image, volume 2, pp. 1–11, 2006.

Hao, P., Liu, K., and Gao, W. Anchor-guided global view reconstruction for multi-view multi-label feature selection. Information Sciences, 679:121124, 2024.

Huang, G., Liu, Z., Van Der Maaten, L., and Weinberger, K. Q. Densely connected convolutional networks. In 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2261–2269, 2017. doi: 10.1109/ CVPR.2017.243.

Huiskes, M. J. and Lew, M. S. The mir flickr retrieval evaluation. In Proceedings of ACM International Conference on Multimedia Information Retrieval, pp. 39–43, 2008.

Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Ilcus, S., Chute, C., Marklund, H., Haghgoo, B., Ball, R., Shpanskaya, K., Seekins, J., Mong, D. A., Halabi, S. S., Sandberg, J. K., Jones, R., Larson, D. B., Langlotz, C. P., Patel, B. N., Lungren, M. P., and Ng, A. Y. Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison. Proceedings of the AAAI Conference on Artificial Intelligence, 33(01):590–597, Jul. 2019.

Kingma, D. P. and Welling, M. Auto-encoding variational bayes. In Bengio, Y. and LeCun, Y. (eds.), 2nd International Conference on Learning Representations, 2014.

Li, C., Wu, X., Peng, P., Zhang, Z., and Lu, X. Incomplete multi-view partial multi-label classification via deep semantic structure preservation. 10(6):7661–7679, 2024. ISSN 2198-6053.

Li, Q., Xu, T., Luo, T., Zhong, Y., Li, Y., Zhou, Y., and Hou, C. Theory-driven label-specific representation for incomplete multi-view multi-label learning. In Belgrave, D., Zhang, C., Lin, H., Pascanu, R., Koniusz, P., Ghassemi, M., and Chen, N. (eds.), Advances in Neural Information Processing Systems, volume 38, pp. 121996–122037. Curran Associates, Inc., 2025.

Li, X. and Chen, S. A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918–5932, 2021.

Liu, C., Wen, J., Liu, Y., Huang, C., Wu, Z., Luo, X., and Xu, Y. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. Advances in Neural Information Processing Systems, 36: 32387–32400, 2023a.

Liu, C., Wen, J., Luo, X., Huang, C., Wu, Z., and Xu, Y. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8807–8815, 2023b.

Liu, C., Wen, J., Luo, X., and Xu, Y. Incomplete multi-view multi-label learning via label-guided masked view- and category-aware transformers. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8816–8824, 2023c.

Liu, C., Jia, J., Wen, J., Liu, Y., Luo, X., Huang, C., and Xu, Y. Attention-induced embedding imputation for incomplete multi-view partial multi-label classification. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 13864–13872, 2024a.

Liu, C., Xu, G., Wen, J., Liu, Y., Huang, C., and Xu, Y. Partial multi-view multi-label classification via semantic invariance learning and prototype modeling. In Forty-first International Conference on Machine Learning, 2024b.

Luo, T., Li, Q., Jiang, M., and Hou, C. Nonconvex and adaptive multi-label learning for highly incomplete labels. Knowledge-Based Systems, pp. 114784, 2025.

Pan, E. and Kang, Z. Multi-view contrastive graph clustering. Advances in Neural Information Processing Systems, 34:2148–2159, 2021.

Shao, B. and Xu, Y. Deep consensus semantic aware network for partial multi-view incomplete multi-label classification. 37(4), 2025. ISSN 2213-1248.

Si, C., Jia, Y., Wang, R., Zhang, M.-L., Feng, Y., and Qu, C. Multi-label classification with high-rank and high-order label correlations. IEEE Transactions on Knowledge and Data Engineering, 36(8):4076–4088, 2023.

Tan, Q., Yu, G., Domeniconi, C., Wang, J., and Zhang, Z. Incomplete multi-view weak-label learning. In International Joint Conference on Artificial Intelligence, pp. 2703–2709, 2018.

Tan, X., Zhao, C., Liu, C., Wen, J., and Tang, Z. A two-stage information extraction network for incomplete multi-view multi-label classification. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 15249–15257, 2024.

Wang, Y., Li, Q., Chang, D., Wen, J., Xiao, F., and Zhao, Y. A category-driven contrastive recovery network for double incomplete multi-view multi-label classification. IEEE Transactions on Multimedia, pp. 1–10, 2025.

Wen, J., Liu, C., Deng, S., Liu, Y., Fei, L., Yan, K., and Xu, Y. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views. IEEE Transactions on Neural Networks and Learning Systems, 35(8):11396–11408, 2023.

Wen, J., Long, J., Lu, X., Liu, C., Fang, X., and Xu, Y. Partial multiview incomplete multilabel learning via uncertainty-driven reliable dynamic fusion. IEEE Transactions on Pattern Analysis and Machine Intelligence, 48 (1):236–250, 2026.

Xie, W., Zhao, L., Long, J., Lu, X., and Nie, B. Multi-view factorizing and disentangling: A novel framework for incomplete multi-view multi-label classification. 2025 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), pp. 1914–1923, 2025.

Yang, M., Li, Y., Huang, Z., Liu, Z., Hu, P., and Peng, X. Partially view-aligned representation learning with noise-robust contrastive loss. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 1134–1143, 2021.

Ye, H., Sunderraman, R., and Ji, S. Matchxml: an efficient text-label matching framework for extreme multi-label text classification. IEEE Transactions on Knowledge and Data Engineering, 36:4781–4793, 2024.

Yuan, H., Sun, Y., Zhou, F., Wen, J., Yuan, S., You, X., and Ren, Z. Prototype matching learning for incomplete multi-view clustering. IEEE Transactions on Image Processing, 34:828–841, 2025.

Zhang, X., Wang, R., Chen, S., Jia, Y., and Wang, D. D. Ame-lsift: Attention-aware multi-label ensemble with label subset-specific features. IEEE Transactions on Knowledge and Data Engineering, pp. 7627–7642, 2024.

Zhao, D., Gao, Q., Lu, Y., and Sun, D. Non-aligned multi-view multi-label classification via learning view-specific labels. IEEE Transactions on Multimedia, 25:7235–7247, 2022.

附录 A. 变分界的推导

本附录给出任务相关表示学习目标（第2.3节）所用变分界的严格推导。其理论基础是信息瓶颈原理，旨在平衡两个相互竞争的目标：充分性，即保留任务相关信息；一致性，即抑制视图特定的冗余。

A.1. 问题表述

令 $\mathbf{x}^{(v)} \in \mathbb{R}^{d_v}$ 表示视图 v 的输入，$\mathbf{z}^{(v)} \in \mathbb{R}^{d_z}$ 为相应的视图特定潜在表示，$\mathbf{z}$ 为聚合所有可用视图的融合表示，$\mathbf{x}^{\sim(v)}$ 为除视图 v 之外的所有视图，$\mathbf{z}^{\sim(v)}$ 为除视图 v 之外所有视图的潜在表示，$\mathbf{y} \in \{0, 1\}^C$ 为多标签标注。变分编码器记为 $q_\phi(\mathbf{z}^{(v)} \mid \mathbf{x}^{(v)})$，变分解码器为 $p_\theta(\mathbf{x}^{(v)} \mid \mathbf{z}^{(v)})$，融合后验为 $q(\mathbf{z} \mid \{\mathbf{x}\})$，变分分类器为 $p_\psi(\mathbf{y} \mid \mathbf{z})$。

根据信息瓶颈原理，我们希望学习尽可能保留任务相关信息、同时丢弃视图特定冗余的表示。这被形式化为如下优化问题：

$$\max_{\phi,\theta,\psi} \sum_{v \in \mathcal{V}} \left[\mathcal{J}_{feat}^{(v)} + \lambda \mathcal{J}_{label}^{(v)} \right], \tag{19}$$

其中，特征层与标签层信息目标分别定义为

$$\mathcal{J}_{feat}^{(v)} = I(\mathbf{x}^{(v)}; \mathbf{z}^{(v)}) - \alpha I(\mathbf{x}^{\sim(v)}; \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}), \tag{20}$$

$$\mathcal{J}_{label}^{(v)} = I(\mathbf{y}; \mathbf{z}^{(v)}) - \gamma I(\mathbf{y}; \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}). \tag{21}$$

这一目标分解为四个互信息项：

- **特征充分性** $I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})$：保证对输入的忠实重构。
- **特征一致性** $I(\mathbf{x}^{\sim(v)};\,\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})$：在表示层施加跨视图一致性。
- **标签充分性** $I\big(\mathbf{y};\,\mathbf{z}^{(v)}\big)$：保留用于分类的判别信息。
- **标签一致性** $I\big(\mathbf{y};\,\mathbf{z}^{(v)}\mid\mathbf{z}^{\sim(v)}\big)$：施加跨视图语义一致性。

直接优化这些互信息项不可行。我们利用变分推断得到可处理的界：对需要最大化的充分性项，推导变分下界；对需要最小化的一致性项，推导变分上界。

A.2. 特征充分性

我们希望最大化观测视图与其潜在编码之间的互信息 $I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})$。

命题 A.1. 互信息 $I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})$ 具有如下变分下界：

$$I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})\geq\mathbb{E}_{p(\mathbf{x}^{(v)})}\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})}\big[\log p_\theta(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big]+H(\mathbf{x}^{(v)}),\tag{22}$$

其中 $H(\mathbf{x}^{(v)})$ 表示数据分布的微分熵。

证明。根据互信息定义，

$$I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})=\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\left[\log\frac{p(\mathbf{x}^{(v)},\,\mathbf{z}^{(v)})}{p(\mathbf{x}^{(v)})p(\mathbf{z}^{(v)})}\right].\tag{23}$$

对联合分布使用贝叶斯法则 $p(\mathbf{x}^{(v)},\,\mathbf{z}^{(v)})=p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})p(\mathbf{z}^{(v)})$，可得

$$\begin{aligned}I(\mathbf{x}^{(v)};\,\mathbf{z}^{(v)})&=\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\left[\log\frac{p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})}{p(\mathbf{x}^{(v)})}\right]\\&=\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\big[\log p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big]-\mathbb{E}_{p(\mathbf{x}^{(v)})}\big[\log p(\mathbf{x}^{(v)})\big]\\&=\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\big[\log p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big]+H(\mathbf{x}^{(v)}).\end{aligned}\tag{24}$$

熵项 $H(\mathbf{x}^{(v)})$ 对模型参数而言为常数。我们关注最大化

$$\mathcal{J}_{recon}=\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\big[\log p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big].\tag{25}$$

真实条件似然 $p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})$ 难以处理。引入变分解码器 $p_\theta(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})$，利用 KL 散度的非负性，有

$$\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\big[\log p(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big]\geq\mathbb{E}_{p(\mathbf{x}^{(v)},\mathbf{z}^{(v)})}\big[\log p_\theta(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big].\tag{26}$$

用变分编码器 $q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})$ 替代真实后验 $p(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})$：

$$\mathcal{J}_{recon}\geq\mathbb{E}_{p(\mathbf{x}^{(v)})}\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})}\big[\log p_\theta(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big].\tag{27}$$

由此建立式（6）的下界。对应的**重构损失**为

$$\mathcal{L}_{recon}^{(v)}=-\,\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})}\big[\log p_\theta(\mathbf{x}^{(v)}\mid\mathbf{z}^{(v)})\big].\tag{28}$$

A.3. 特征一致性

我们通过最小化 $I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)})$ 来获得特征一致性。它度量了 $\mathbf{z}^{(v)}$ 在 $\mathbf{x}^{(v)}$ 已捕捉的信息以外，还保留了多少关于其他视图的信息。

命题 A.2. 条件互信息 $I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)})$ 的上界为

$$I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) \le \mathbb{E}_{p(\{\mathbf{x}\})}\Big[D_{KL}\big(q(\mathbf{z} \mid \{\mathbf{x}\}) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big)\Big]. \tag{29}$$

证明。首先建立一个松弛。由于融合表示 $\mathbf{z}$ 聚合了所有视图的信息，它包含的关于 $\mathbf{x}^{\sim(v)}$ 的信息至少与 $\mathbf{z}^{(v)}$ 一样多。根据数据处理不等式，

$$I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) \le I(\mathbf{x}^{\sim(v)};\, \mathbf{z} \mid \mathbf{x}^{(v)}). \tag{30}$$

根据条件互信息的定义，

$$I(\mathbf{x}^{\sim(v)};\, \mathbf{z} \mid \mathbf{x}^{(v)}) = \mathbb{E}_{p(\{\mathbf{x}\},\mathbf{z})}\left[\log \frac{p(\mathbf{x}^{\sim(v)},\, \mathbf{z} \mid \mathbf{x}^{(v)})}{p(\mathbf{x}^{\sim(v)} \mid \mathbf{x}^{(v)})\, p(\mathbf{z} \mid \mathbf{x}^{(v)})}\right]. \tag{31}$$

应用贝叶斯法则 $p(\mathbf{x}^{\sim(v)},\, \mathbf{z} \mid \mathbf{x}^{(v)}) = p\big(\mathbf{z} \mid \{\mathbf{x}\}\big)\, p(\mathbf{x}^{\sim(v)} \mid \mathbf{x}^{(v)})$，代入并化简，得到

$$\begin{aligned} I(\mathbf{x}^{\sim(v)};\, \mathbf{z} \mid \mathbf{x}^{(v)}) &= \mathbb{E}_{p(\{\mathbf{x}\},\mathbf{z})}\left[\log \frac{p\big(\mathbf{z} \mid \{\mathbf{x}\}\big)}{p(\mathbf{z} \mid \mathbf{x}^{(v)})}\right] \\ &= \mathbb{E}_{p(\{\mathbf{x}\})}\big[D_{KL}\big(p\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel p(\mathbf{z} \mid \mathbf{x}^{(v)})\big)\big]. \end{aligned} \tag{32}$$

真实后验难以处理。引入变分近似 $q\big(\mathbf{z} \mid \{\mathbf{x}\}\big)$ 和 $q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})$，作如下分解：

$$\begin{aligned} &D_{KL}\big(p\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel p(\mathbf{z} \mid \mathbf{x}^{(v)})\big) \\ &= \mathbb{E}_{p(\mathbf{z}\mid\{\mathbf{x}\})}\left[\log \frac{p\big(\mathbf{z} \mid \{\mathbf{x}\}\big)}{q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})} + \log \frac{q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})}{p(\mathbf{z} \mid \mathbf{x}^{(v)})}\right] \\ &= D_{KL}\big(p\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big) - D_{KL}\big(p(\mathbf{z} \mid \mathbf{x}^{(v)}) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big). \end{aligned} \tag{33}$$

注意，第二项的期望是在 $p\big(\mathbf{z} \mid \{\mathbf{x}\}\big)$ 下计算，而 KL 散度的定义是在 $p(\mathbf{z} \mid \mathbf{x}^{(v)})$ 下。为了使分析可处理，我们采用视图特定编码器提供足够精确近似这一假设。去掉非正的第二项，得到

$$D_{KL}\big(p\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel p(\mathbf{z} \mid \mathbf{x}^{(v)})\big) \le D_{KL}\big(p\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big). \tag{34}$$

用变分近似 $q\big(\mathbf{z} \mid \{\mathbf{x}\}\big)$ 替代真实融合后验，得到

$$I(\mathbf{x}^{\sim(v)};\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) \le \mathbb{E}_{p(\{\mathbf{x}\})}\Big[D_{KL}\big(q\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big)\Big]. \tag{35}$$

这建立了式（7）的上界。对应的**编码器一致性损失**为

$$\mathcal{L}^{(v)}_{enc-consist} = D_{KL}\big(q\big(\mathbf{z} \mid \{\mathbf{x}\}\big) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\big). \tag{36}$$

对于具有对角协方差的高斯分布 $q\big(\mathbf{z} \mid \{\mathbf{x}\}\big) = \mathcal{N}\big(\boldsymbol{\mu}_{fused},\, \mathrm{diag}\big(\boldsymbol{\sigma}^2_{fused}\big)\big)$ 和 $q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)}) = \mathcal{N}\big(\boldsymbol{\mu}_v,\, \mathrm{diag}\big(\boldsymbol{\sigma}^2_v\big)\big)$，此 KL 散度具有闭式表达：

$$D_{KL} = \frac{1}{2}\sum_{j=1}^{d_z}\left[\log\frac{\sigma_{v,j}^2}{\sigma_{fused,j}^2} + \frac{\sigma_{fused,j}^2 + \left(\mu_{fused,j} - \mu_{v,j}\right)^2}{\sigma_{v,j}^2} - 1\right]. \tag{37}$$

A.4. 标签充分性

我们希望最大化标签与视图特定潜在表示之间的互信息 $I\left(\mathbf{y};\, \mathbf{z}^{(v)}\right)$。

命题 A.3. 互信息 $I\left(\mathbf{y};\, \mathbf{z}^{(v)}\right)$ 具有如下变分下界：

$$I\left(\mathbf{y};\, \mathbf{z}^{(v)}\right) \geq \mathbb{E}_{p\left(\mathbf{x}^{(v)}\right)}\mathbb{E}_{q_\phi\left(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}\right)}\mathbb{E}_{p\left(\mathbf{y}|\mathbf{x}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right] + H\left(\mathbf{y}\right). \tag{38}$$

证明。根据互信息定义，

$$\begin{aligned} I\left(\mathbf{y};\, \mathbf{z}^{(v)}\right) &= \mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log\frac{p\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)}{p\left(\mathbf{y}\right)}\right] \\ &= \mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log p\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right] + H\left(\mathbf{y}\right). \end{aligned} \tag{39}$$

熵 $H\left(\mathbf{y}\right)$ 与模型参数无关。我们关注最大化

$$\mathcal{J}_{cls} = \mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log p\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right]. \tag{40}$$

引入变分分类器 $p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)$，利用 KL 散度的非负性，得到

$$\mathcal{J}_{cls} \geq \mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right]. \tag{41}$$

通过引入 $\mathbf{x}^{(v)}$，在数据分布上展开：

$$\mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right] = \iiint p\left(\mathbf{y},\, \mathbf{z}^{(v)},\, \mathbf{x}^{(v)}\right)\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right) d\mathbf{y}\, d\mathbf{z}^{(v)}\, d\mathbf{x}^{(v)}. \tag{42}$$

在条件独立假设 $p\left(\mathbf{y},\, \mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}\right) = p\left(\mathbf{y} \mid \mathbf{x}^{(v)}\right)p\left(\mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}\right)$ 下，

$$\mathbb{E}_{p\left(\mathbf{y},\mathbf{z}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right] = \mathbb{E}_{p\left(\mathbf{x}^{(v)}\right)}\mathbb{E}_{p\left(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}\right)}\mathbb{E}_{p\left(\mathbf{y}|\mathbf{x}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right]. \tag{43}$$

将真实后验替换为变分编码器：

$$\mathcal{J}_{cls} \geq \mathbb{E}_{p\left(\mathbf{x}^{(v)}\right)}\mathbb{E}_{q_\phi\left(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}\right)}\mathbb{E}_{p\left(\mathbf{y}|\mathbf{x}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right]. \tag{44}$$

这建立了式（8）的下界。对应的**分类损失**为

$$\mathcal{L}_{cls}^{(v)} = -\mathbb{E}_{q_\phi\left(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}\right)}\mathbb{E}_{p\left(\mathbf{y}|\mathbf{x}^{(v)}\right)}\left[\log p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right)\right]. \tag{45}$$

对于部分标签条件下的多标签分类，假设标签之间条件独立，分类器可分解为 $p_\psi\left(\mathbf{y} \mid \mathbf{z}^{(v)}\right) = \prod_{c=1}^{C} p_\psi\left(y_c \mid \mathbf{z}^{(v)}\right)$。在标签已观测的监督设置中，内层期望 $\mathbb{E}_{p\left(\mathbf{y}|\mathbf{x}^{(v)}\right)}$ 退化为在已观测标签集合 $\mathcal{O}_i$ 上的计算，产生二元交叉熵形式：

$$\mathcal{L}_{cls}^{(v)} = -\frac{1}{|\mathcal{O}_i|}\sum_{c\in\mathcal{O}_i}\left[y_c\log\widehat{y}_c^{(v)} + \left(1 - y_c\right)\log\left(1 - \widehat{y}_c^{(v)}\right)\right], \tag{46}$$

其中 $\widehat{y}_c^{(v)} = \sigma\big(f_c(\mathbf{z}^{(v)})\big)$ 表示类别 c 的预测概率。

A.5. 标签一致性

我们希望最小化 $I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big)$。该项度量了给定其他视图表示后，$\mathbf{z}^{(v)}$ 中的冗余标签信息。

命题 A.4. 条件互信息 $I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big)$ 的上界为

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) \le \mathbb{E}_{p(\{\mathbf{x}\})}\mathbb{E}_{q(\mathbf{z}\mid\{\mathbf{x}\})}\Big[D_{KL}\big(p_\psi(\mathbf{y}\mid\mathbf{z}) \,\|\, p_\psi(\mathbf{y}\mid\mathbf{z}^{(v)})\big)\Big]. \tag{47}$$

证明。根据条件互信息定义，

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) = \mathbb{E}_{p(\mathbf{y},\mathbf{z}^{(v)},\mathbf{z}^{\sim(v)})}\left[\log \frac{p\big(\mathbf{y},\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big)}{p\big(\mathbf{y}\mid\mathbf{z}^{\sim(v)}\big)p\big(\mathbf{z}^{(v)}\mid\mathbf{z}^{\sim(v)}\big)}\right]. \tag{48}$$

应用贝叶斯法则 $p\big(\mathbf{y},\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) = p\big(\mathbf{y}\mid\mathbf{z}^{(v)},\, \mathbf{z}^{\sim(v)}\big)p\big(\mathbf{z}^{(v)}\mid\mathbf{z}^{\sim(v)}\big)$，代入并化简，得到

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) = \mathbb{E}_{p(\mathbf{y},\{\mathbf{z}\})}\left[\log \frac{p\big(\mathbf{y}\mid\mathbf{z}^{(v)},\, \mathbf{z}^{\sim(v)}\big)}{p\big(\mathbf{y}\mid\mathbf{z}^{\sim(v)}\big)}\right]. \tag{49}$$

在假设 $p\big(\mathbf{y}\mid\mathbf{z}^{(v)},\, \mathbf{z}^{\sim(v)}\big) = p\big(\mathbf{y}\mid\{\mathbf{z}\}\big)$ 下，

$$\begin{aligned} I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) &= \mathbb{E}_{p(\{\mathbf{z}\})}\big[D_{KL}\big(p(\mathbf{y}\mid\{\mathbf{z}\}) \,\|\, p(\mathbf{y}\mid\mathbf{z}^{\sim(v)})\big)\big] \\ &= \mathbb{E}_{p(\{\mathbf{x}\})}\mathbb{E}_{p(\mathbf{z}\mid\{\mathbf{x}\})}\big[D_{KL}\big(p(\mathbf{y}\mid\{\mathbf{z}\}) \,\|\, p(\mathbf{y}\mid\mathbf{z}^{\sim(v)})\big)\big]. \end{aligned} \tag{50}$$

直接对 $\mathbf{z}^{\sim(v)}$ 计算较为繁琐。我们采用一种对称形式：对于每个视图 v，度量融合表示预测与仅使用视图 v 的预测之间的散度。理由是，若 $p\big(\mathbf{y}\mid\mathbf{z}^{(v)}\big)$ 与 $p\big(\mathbf{y}\mid\{\mathbf{z}\}\big)$ 差异显著，则 $\mathbf{z}^{(v)}$ 携带了与共识不一致的视图特定语义信息。将真实条件分布替换为变分分类器，并采用融合后验 $q\big(\mathbf{z}\mid\{\mathbf{x}\}\big)$，得到

$$I\big(\mathbf{y};\, \mathbf{z}^{(v)} \mid \mathbf{z}^{\sim(v)}\big) \le \mathbb{E}_{p(\{\mathbf{x}\})}\mathbb{E}_{q(\mathbf{z}\mid\{\mathbf{x}\})}\Big[D_{KL}\big(p_\psi(\mathbf{y}\mid\mathbf{z}) \,\|\, p_\psi(\mathbf{y}\mid\mathbf{z}^{(v)})\big)\Big]. \tag{51}$$

这建立了式（9）的上界。对应的**分类器一致性损失**为

$$\mathcal{L}_{cls-consist}^{(v)} = \mathbb{E}_{q(\mathbf{z}\mid\{\mathbf{x}\})}\Big[D_{KL}\big(p_\psi(\mathbf{y}\mid\mathbf{z}) \,\|\, p_\psi(\mathbf{y}\mid\mathbf{z}^{(v)})\big)\Big], \tag{52}$$

其中 $\mathbf{z}$ 从融合后验 $q\big(\mathbf{z}\mid\{\mathbf{x}\}\big)$ 采样，$\mathbf{z}^{(v)}$ 从 $q_\phi(\mathbf{z}^{(v)}\mid\mathbf{x}^{(v)})$ 采样。

对于各类别预测独立的多标签分类，KL 散度可分解为

$$D_{KL}\big(p_\psi(\mathbf{y}\mid\mathbf{z}) \,\|\, p_\psi(\mathbf{y}\mid\mathbf{z}^{(v)})\big) = \sum_{c=1}^{C} D_{KL}\big(p_\psi(y_c\mid\mathbf{z}) \,\|\, p_\psi(y_c\mid\mathbf{z}^{(v)})\big). \tag{53}$$

对于参数为 $\widehat{y}_c = \sigma\big(f_c(\mathbf{z})\big)$ 和 $\widehat{y}_c^{(v)} = \sigma\big(f_c(\mathbf{z}^{(v)})\big)$ 的伯努利分布，

$$D_{KL}\big(p_\psi(y_c\mid\mathbf{z}) \,\|\, p_\psi(y_c\mid\mathbf{z}^{(v)})\big) = \widehat{y}_c \log \frac{\widehat{y}_c}{\widehat{y}_c^{(v)}} + (1-\widehat{y}_c)\log \frac{1-\widehat{y}_c}{1-\widehat{y}_c^{(v)}}. \tag{54}$$

A.6. 小结

结合四个变分界，得到特征层损失（式（10））：

$$\mathcal{L}_{feat}^{(v)} = -\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}|\mathbf{x}^{(v)})}\left[\log p_\theta(\mathbf{x}^{(v)} \mid \mathbf{z}^{(v)})\right] + \alpha D_{KL}\left(q(\mathbf{z} \mid \{\mathbf{x}\}) \parallel q_\phi(\mathbf{z} \mid \mathbf{x}^{(v)})\right), \tag{55}$$

两项分别为重构与编码器一致性；标签层损失（式（11））为

$$\mathcal{L}_{label}^{(v)} = -\mathbb{E}_{q_\phi(\mathbf{z}^{(v)}|\mathbf{x}^{(v)})}\left[\log p_\psi(\mathbf{y} \mid \mathbf{z}^{(v)})\right] + \gamma \mathbb{E}_{q(\mathbf{z}|\{\mathbf{x}\})}\left[D_{KL}\left(p_\psi(\mathbf{y} \mid \mathbf{z}) \parallel p_\psi(\mathbf{y} \mid \mathbf{z}^{(v)})\right)\right]. \tag{56}$$

两项分别为分类与分类器一致性。任务相关表示学习目标在所有可用视图上汇总这些损失（式（12））：

$$\mathcal{L}_{TR} = \sum_{v \in \mathcal{V}} \left[\mathcal{L}_{feat}^{(v)} + \lambda \mathcal{L}_{label}^{(v)}\right], \tag{57}$$

其中 $\mathcal{V}$ 表示当前样本的可用视图集合。完整训练目标（式（18））整合全部组成部分：

$$\mathcal{L} = \mathcal{L}_{TR} + \beta \mathcal{L}_{SA} + \mathcal{L}_{CE}, \tag{58}$$

其中 $\mathcal{L}_{SA}$ 是第2.2节的语义对齐损失，$\mathcal{L}_{CE}$ 是第2.4节的聚合分类损失，$\alpha, \gamma, \lambda, \beta$ 为平衡不同目标的超参数。

值得注意的是，总体目标包含两项与分类有关的损失，但二者承担不同、彼此区分的功能。$\mathcal{L}_{label}^{(v)}$ 内的分类项来自标签充分性原理（第A.4节），对每个独立视图的潜在表示 $\mathbf{z}^{(v)}$ 的预测进行监督，保证每个视图特定编码器独立保留充分的判别信息。相比之下，$\mathcal{L}_{CE}$ 监督的是经置信度加权融合机制（式（16））得到的最终聚合预测 $\widehat{\mathbf{y}}^{final}$，该机制同时包含类别特定条件后验和单独视图的输出。这种双层监督策略确保即使其他视图缺失，单个视图仍保持判别能力，同时使融合机制学会最优地组合异构预测，以提高鲁棒性。

实现。所有期望均采用蒙特卡洛估计近似。外层期望 $\mathbb{E}_{p(\mathbf{x})}[\cdot]$ 通过训练集的经验分布近似，并计算为小批量样本上的平均值。内层期望 $\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\cdot]$ 通过重参数化技巧（Kingma & Welling, 2014）从参数化编码器分布中采样近似：对于高斯编码器 $q_\phi(\mathbf{z}^{(v)} \mid \mathbf{x}^{(v)}) = \mathcal{N}\left(\boldsymbol{\mu}_v, \operatorname{diag}\left(\boldsymbol{\sigma}_v^2\right)\right)$，样本通过 $\mathbf{z}^{(v)} = \boldsymbol{\mu}_v + \boldsymbol{\sigma}_v \odot \boldsymbol{\epsilon}$ 得到，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。标签期望 $\mathbb{E}_{p(\mathbf{y}|\mathbf{x})}[\cdot]$ 根据分类器预测概率分布 $p_\psi(\mathbf{y} \mid \mathbf{z})$ 解析计算，或在监督设置中退化为在已观测标签上的计算。一致性项中使用的融合后验 $q(\mathbf{z} \mid \{\mathbf{x}\})$ 通过第2.5节详述的专家乘积融合得到，将乘积限制在可用视图后验上即可自然适应视图缺失。

附录 B. 实验细节

B.1. 数据集

实验涵盖六个公认基准与两个面向应用的数据集。表3概括其关键统计信息。

基准数据集。我们使用五个标注粒度不同的图像集合：Corel5k（4,999幅图像，260个标签）、ESPGame（20,770幅图像，268个来自众包标注的标签）、IAPRTC12（19,627幅图像，291个语义类别）、Mirflickr（25,000幅社交媒体图像，38个标签）和 Pascal07（9,963幅图像，20个对象类别）。每幅图像通过六个视觉描述子表示，捕捉互补的方面：颜色分布（DenseHue、HSV、RGB、LAB 直方图）、局部模式（DenseSift）、全局结构（GIST）。此外还使用 OBJECT，它是一个多属性识别数据集，包含6,047个实例，由五种形状与纹理特征描述：颜色直方图（CH）、颜色矩（CM）、自相关（CORR）、边缘方向直方图（EDH）和小波纹理（WT）。

NBA 数据集。从 Basketball-Reference 收集球员表现记录，得到2002至2022年间16,992个球员-赛季样本。将统计数据组织成六个主题视图：得分视图捕捉投篮数量和效率；篮板视图反映身体作用与耐久性；组织进攻视图包括传球、防守和控球安全；高阶视图汇总综合效率评级；背景视图编码球员年龄和球队归属；情境视图表示赛季年份与是否参加季后赛。标签空间涵盖三项预测任务：10个奖项指示标签（全明星、最佳阵容、MVP 候选等）、5个位置角色和3个职业阶段（早期、巅峰、后期）。

CheXpert-MV 数据集。为构建有临床动机的多视图基准，我们如下处理 CheXpert 数据库（Irvin et al., 2019）：将原始 DICOM 文件压缩为 JPEG 格式，仅保留包含成对正位-侧位采集的31,413项检查。每个投影作为一个视图，利用 ImageNet 预训练的 DenseNet-121（Huang et al., 2017，去掉最终分类层）获取视觉表示，每个视图产生1,024维嵌入。标注涵盖14项放射学发现：肺不张、心脏增大、肺实变、水肿、心纵隔影增宽、骨折、肺部病灶、肺部阴影、胸腔积液、其他胸膜异常、肺炎、气胸、支持装置、未见异常。

Dataset	Domain	#Inst.	#Views	#Labels	Features (Dim.)
Corel5k	Image	4,999	6	260	DenseHue (100), DenseSift (1000), GIST (512), HSV (4096), RGB (4096), LAB (4096)
ESPGame	Image	20,770	6	268	
IAPRTC12	Image	19,627	6	291	
Mirflickr	Image	25,000	6	38	
Pascal07	Image	9,963	6	20	
OBJECT	Image	6,047	5	31	CH (64), CM (225), CORR (144), EDH (73), WT(128)
NBA	Sports	16,992	6	18	Scoring (20), Rebounding (14), Playmaking (15), Advanced (10), Background (41), Context (22)
CheXpert-MV	Medical	31,413	2	14	Frontal (1024), Lateral (1024)

表3. 数据集统计简要信息。Dataset=数据集；Domain=领域；#Inst.=实例数；#Views=视图数；#Labels=标签数；Features (Dim.)=特征（维数）；Image/Sports/Medical=图像/体育/医疗。特征缩写和维数按原表保留。Scoring/Rebounding/Playmaking/Advanced/Background/Context=得分/篮板/组织进攻/高阶/背景/情境；Frontal/Lateral=正位/侧位。

B.2. 比较方法

我们与九种涵盖矩阵分解、深度学习和信息论方法的代表性方法进行比较。iMVWL（Tan et al., 2018）通过低秩矩阵补全恢复缺失视图。LVSL（Zhao et al., 2022）解耦视图特定与标签特定表示，但不处理缺失。深度方法中，DICNet（Liu et al., 2023b）通过对比目标施加实例级一致性；DIMC（Wen et al., 2023）通过一致性正则化施加跨视图对齐；LMVCAT（Liu et al., 2023c）使用交叉注意力 Transformer 聚合视图。较新的进展包括采用注意力引导插补的 AIMNet（Liu et al.,

2024a）、使用掩码自编码器进行鲁棒重构的 MTD（Liu et al., 2023a），以及优化信息瓶颈目标的 SIP（Liu et al., 2024b）。TDLSR（Li et al., 2025）构建视图特定拓扑和原型关联图，得到标签特定表示，并提供泛化性能的理论分析。

DATA	METRIC	AIMNet	DICNet	DIMC	iMVWL	LMVCAT	LVSL	MTD	SIP	TDLSR	LGRL
COR	1-HL	$0.987_{0.001}$	$0.987_{0.000}$	$0.987_{0.001}$	$0.976_{0.001}$	$0.987_{0.001}$	$0.987_{0.000}$	$0.987_{0.001}$	$0.986_{0.001}$	$0.987_{0.000}$	$0.987_{0.000}$
	1-OE	$0.277_{0.012}$	$0.242_{0.009}$	$0.239_{0.011}$	$0.181_{0.005}$	$0.229_{0.008}$	$0.247_{0.006}$	$0.274_{0.012}$	$0.289_{0.015}$	$0.374_{0.010}$	$0.410_{0.014}$
	1-Cov	$0.605_{0.005}$	$0.515_{0.007}$	$0.518_{0.006}$	$0.524_{0.004}$	$0.600_{0.005}$	$0.608_{0.004}$	$0.573_{0.006}$	$0.601_{0.007}$	$0.692_{0.004}$	$0.731_{0.005}$
	1-RL	$0.823_{0.003}$	$0.774_{0.004}$	$0.772_{0.005}$	$0.762_{0.004}$	$0.817_{0.004}$	$0.823_{0.001}$	$0.809_{0.005}$	$0.821_{0.004}$	$0.866_{0.002}$	$0.887_{0.003}$
	AP	$0.240_{0.004}$	$0.208_{0.005}$	$0.206_{0.004}$	$0.163_{0.004}$	$0.214_{0.001}$	$0.228_{0.004}$	$0.234_{0.005}$	$0.242_{0.006}$	$0.323_{0.004}$	$0.360_{0.005}$
	AUC	$0.826_{0.003}$	$0.776_{0.004}$	$0.774_{0.004}$	$0.766_{0.000}$	$0.820_{0.003}$	$0.827_{0.003}$	$0.811_{0.004}$	$0.823_{0.003}$	$0.869_{0.002}$	$0.889_{0.003}$
	AVE	3.333	6.833	7.333	8.333	5.667	3.667	5.167	3.667	1.833	1.000
ESP	1-HL	$0.982_{0.000}$	$0.982_{0.000}$	$0.982_{0.000}$	$0.969_{0.001}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.982_{0.000}$	$0.982_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$
	1-OE	$0.310_{0.007}$	$0.289_{0.012}$	$0.283_{0.006}$	$0.204_{0.001}$	$0.266_{0.023}$	$0.265_{0.004}$	$0.302_{0.008}$	$0.327_{0.008}$	$0.385_{0.010}$	$0.435_{0.012}$
	1-Cov	$0.508_{0.003}$	$0.464_{0.000}$	$0.456_{0.004}$	$0.421_{0.007}$	$0.468_{0.003}$	$0.489_{0.001}$	$0.492_{0.005}$	$0.500_{0.004}$	$0.576_{0.002}$	$0.589_{0.005}$
	1-RL	$0.792_{0.001}$	$0.773_{0.001}$	$0.769_{0.002}$	$0.729_{0.004}$	$0.771_{0.000}$	$0.783_{0.001}$	$0.786_{0.000}$	$0.785_{0.001}$	$0.825_{0.001}$	$0.835_{0.001}$
	AP	$0.222_{0.003}$	$0.210_{0.002}$	$0.207_{0.003}$	$0.155_{0.004}$	$0.201_{0.006}$	$0.204_{0.001}$	$0.219_{0.004}$	$0.225_{0.002}$	$0.271_{0.003}$	$0.297_{0.005}$
	AUC	$0.797_{0.001}$	$0.777_{0.000}$	$0.772_{0.002}$	$0.733_{0.005}$	$0.775_{0.002}$	$0.787_{0.000}$	$0.790_{0.000}$	$0.790_{0.002}$	$0.830_{0.001}$	$0.840_{0.001}$
	AVE	3.167	5.833	7.000	8.667	6.833	5.833	4.167	3.500	2.000	1.000
IAP	1-HL	$0.980_{0.000}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.966_{0.001}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.980_{0.001}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.980_{0.000}$
	1-OE	$0.342_{0.004}$	$0.330_{0.009}$	$0.318_{0.002}$	$0.245_{0.011}$	$0.290_{0.007}$	$0.294_{0.004}$	$0.344_{0.007}$	$0.355_{0.005}$	$0.397_{0.009}$	$0.463_{0.011}$
	1-Cov	$0.521_{0.002}$	$0.472_{0.004}$	$0.468_{0.002}$	$0.438_{0.009}$	$0.471_{0.005}$	$0.496_{0.002}$	$0.510_{0.006}$	$0.519_{0.003}$	$0.616_{0.001}$	$0.641_{0.005}$
	1-RL	$0.818_{0.003}$	$0.799_{0.004}$	$0.795_{0.002}$	$0.761_{0.005}$	$0.793_{0.003}$	$0.808_{0.002}$	$0.807_{0.001}$	$0.817_{0.003}$	$0.860_{0.001}$	$0.876_{0.002}$
	AP	$0.229_{0.002}$	$0.222_{0.004}$	$0.215_{0.003}$	$0.167_{0.003}$	$0.202_{0.003}$	$0.208_{0.002}$	$0.232_{0.001}$	$0.235_{0.004}$	$0.278_{0.003}$	$0.324_{0.005}$
	AUC	$0.822_{0.002}$	$0.801_{0.003}$	$0.798_{0.002}$	$0.766_{0.005}$	$0.797_{0.001}$	$0.811_{0.001}$	$0.811_{0.001}$	$0.820_{0.002}$	$0.861_{0.001}$	$0.878_{0.002}$
	AVE	3.333	5.500	6.500	8.500	7.333	5.500	4.167	3.167	1.833	1.000
MIR	1-HL	$0.875_{0.001}$	$0.879_{0.001}$	$0.877_{0.002}$	$0.827_{0.004}$	$0.865_{0.004}$	$0.874_{0.001}$	$0.880_{0.001}$	$0.875_{0.002}$	$0.885_{0.002}$	$0.885_{0.002}$
	1-OE	$0.506_{0.023}$	$0.533_{0.005}$	$0.511_{0.005}$	$0.406_{0.023}$	$0.470_{0.020}$	$0.485_{0.004}$	$0.535_{0.008}$	$0.540_{0.009}$	$0.612_{0.006}$	$0.678_{0.008}$
	1-Cov	$0.598_{0.006}$	$0.594_{0.003}$	$0.589_{0.001}$	$0.530_{0.012}$	$0.581_{0.002}$	$0.584_{0.001}$	$0.606_{0.006}$	$0.604_{0.006}$	$0.645_{0.005}$	$0.658_{0.004}$
	1-RL	$0.827_{0.005}$	$0.828_{0.001}$	$0.823_{0.001}$	$0.765_{0.011}$	$0.817_{0.004}$	$0.819_{0.002}$	$0.834_{0.003}$	$0.830_{0.002}$	$0.861_{0.003}$	$0.874_{0.002}$
	AP	$0.494_{0.017}$	$0.512_{0.001}$	$0.501_{0.002}$	$0.415_{0.009}$	$0.485_{0.010}$	$0.482_{0.001}$	$0.519_{0.005}$	$0.519_{0.010}$	$0.575_{0.002}$	$0.609_{0.007}$
	AUC	$0.820_{0.003}$	$0.823_{0.001}$	$0.818_{0.001}$	$0.769_{0.007}$	$0.808_{0.004}$	$0.816_{0.000}$	$0.827_{0.002}$	$0.823_{0.001}$	$0.852_{0.000}$	$0.861_{0.002}$
	AVE	5.667	4.500	5.833	9.333	8.167	7.500	3.000	3.833	1.833	1.000
OBJ	1-HL	$0.937_{0.001}$	$0.938_{0.001}$	$0.938_{0.000}$	$0.882_{0.005}$	$0.927_{0.002}$	$0.934_{0.001}$	$0.938_{0.000}$	$0.937_{0.001}$	$0.946_{0.001}$	$0.944_{0.001}$
	1-OE	$0.468_{0.005}$	$0.453_{0.009}$	$0.439_{0.005}$	$0.335_{0.036}$	$0.405_{0.019}$	$0.364_{0.004}$	$0.474_{0.007}$	$0.485_{0.006}$	$0.603_{0.020}$	$0.654_{0.016}$
	1-Cov	$0.727_{0.009}$	$0.720_{0.008}$	$0.709_{0.010}$	$0.657_{0.023}$	$0.705_{0.017}$	$0.712_{0.002}$	$0.740_{0.007}$	$0.727_{0.006}$	$0.795_{0.003}$	$0.790_{0.008}$
	1-RL	$0.829_{0.003}$	$0.823_{0.006}$	$0.814_{0.008}$	$0.768_{0.012}$	$0.806_{0.011}$	$0.811_{0.001}$	$0.835_{0.003}$	$0.828_{0.004}$	$0.881_{0.002}$	$0.880_{0.005}$
	AP	$0.506_{0.010}$	$0.502_{0.006}$	$0.489_{0.010}$	$0.394_{0.026}$	$0.476_{0.009}$	$0.446_{0.001}$	$0.519_{0.010}$	$0.522_{0.011}$	$0.624_{0.011}$	$0.647_{0.012}$
	AUC	$0.842_{0.003}$	$0.836_{0.005}$	$0.828_{0.008}$	$0.784_{0.012}$	$0.821_{0.011}$	$0.827_{0.001}$	$0.848_{0.003}$	$0.840_{0.004}$	$0.891_{0.001}$	$0.888_{0.005}$
	AVE	4.333	5.333	6.333	9.333	8.000	7.500	3.333	4.000	1.333	1.667
PAS	1-HL	$0.923_{0.003}$	$0.927_{0.001}$	$0.927_{0.001}$	$0.871_{0.003}$	$0.921_{0.003}$	$0.926_{0.000}$	$0.926_{0.001}$	$0.923_{0.000}$	$0.927_{0.003}$	$0.932_{0.001}$
	1-OE	$0.382_{0.023}$	$0.402_{0.002}$	$0.403_{0.002}$	$0.306_{0.037}$	$0.376_{0.021}$	$0.415_{0.001}$	$0.395_{0.011}$	$0.389_{0.011}$	$0.415_{0.016}$	$0.439_{0.015}$
	1-Cov	$0.658_{0.002}$	$0.636_{0.013}$	$0.626_{0.013}$	$0.589_{0.014}$	$0.630_{0.018}$	$0.654_{0.005}$	$0.674_{0.005}$	$0.668_{0.018}$	$0.753_{0.006}$	$0.768_{0.007}$
	1-RL	$0.727_{0.006}$	$0.710_{0.011}$	$0.703_{0.010}$	$0.658_{0.014}$	$0.693_{0.016}$	$0.726_{0.004}$	$0.740_{0.003}$	$0.729_{0.013}$	$0.808_{0.007}$	$0.824_{0.006}$
	AP	$0.440_{0.009}$	$0.440_{0.005}$	$0.434_{0.004}$	$0.368_{0.021}$	$0.430_{0.005}$	$0.444_{0.002}$	$0.447_{0.009}$	$0.449_{0.008}$	$0.504_{0.009}$	$0.524_{0.010}$
	AUC	$0.754_{0.003}$	$0.737_{0.011}$	$0.727_{0.012}$	$0.690_{0.013}$	$0.727_{0.010}$	$0.754_{0.003}$	$0.766_{0.006}$	$0.761_{0.013}$	$0.831_{0.006}$	$0.845_{0.005}$
	AVE	5.333	5.333	6.000	8.667	7.500	4.500	3.500	4.167	2.000	1.000

表4. PER=90%、LMR=90% 时十种方法在六个数据集上的实验结果。“AVE”表示对应方法在全部六项指标上的平均排名。DATA=数据集，METRIC=指标；其余缩写与表1相同。原表的所有均值、下标标准差及排名均予以保留。

B.3. 评价指标

使用六项标准多标签指标评估性能。汉明损失（HL）量化分类错误的实例-标签对所占比例。排序损失（RL）度量顺序颠倒的正负标签对比例。单错误（OE）表示排名最高的预测是否错误。覆盖度（Cov）计算为了覆盖全部真实标签，需要沿排序列表向下走多远，并用标签总数归一化。平均精度（AP）对每个正标签所在排名处的精确率求平均。曲线下面积（AUC）估计一个随机正例排在一个随机负例之前的概率。HL、RL、OE、Cov 越低越好；AP、AUC 越高越好。为统一解释，我们报告 1-HL、1-RL、1-OE 和 1-Cov，使得所有指标都为越高越好。

B.4. 实现细节

数据按 7:1:2 划分为训练、验证和测试集。根据部分样本比例（PER）随机屏蔽视图实例，模拟不完整情形，并约束每个样本至少保留一个已观测视图。标签标注按标签缺失比例（LMR）独立丢弃。各方法使用相同的固定屏蔽模式，以确保公平比较。

优化使用 Adam，学习率为 10^{-4}。对比温度 τ 设为0.1。其他所有超参数，包括编码器一致性权重 α、分类器一致性权重 γ、置信度聚合温度 κ、特征-标签权衡系数 λ 及语义对齐权重 β，均固定为1。实验在 NVIDIA RTX 4090（24GB）上运行；PER=50%、LMR=50% 设置的结果取10次独立运行的平均，其余缺失率组合取5次独立运行平均。

B.5. 结果

参数敏感性。超参数 λ、β 分别控制特征层与标签层目标的权衡，以及语义对齐的影响。我们从 $\{0.01, 0.1, 1, 10, 100\}$ 范围内选择这两个参数开展敏感性分析，并用图5的热图展示其对 AP 的联合影响。结果表明，当 λ 与 β 都落在 $(0.1, 1)$ 范围内时，LGRL 性能相对稳定，说明其对超参数选择的敏感性较低。此外，各数据集最优配置略有不同，表明损失成分之间的平衡可能依赖标签空间大小、视图异质性等数据集特性。

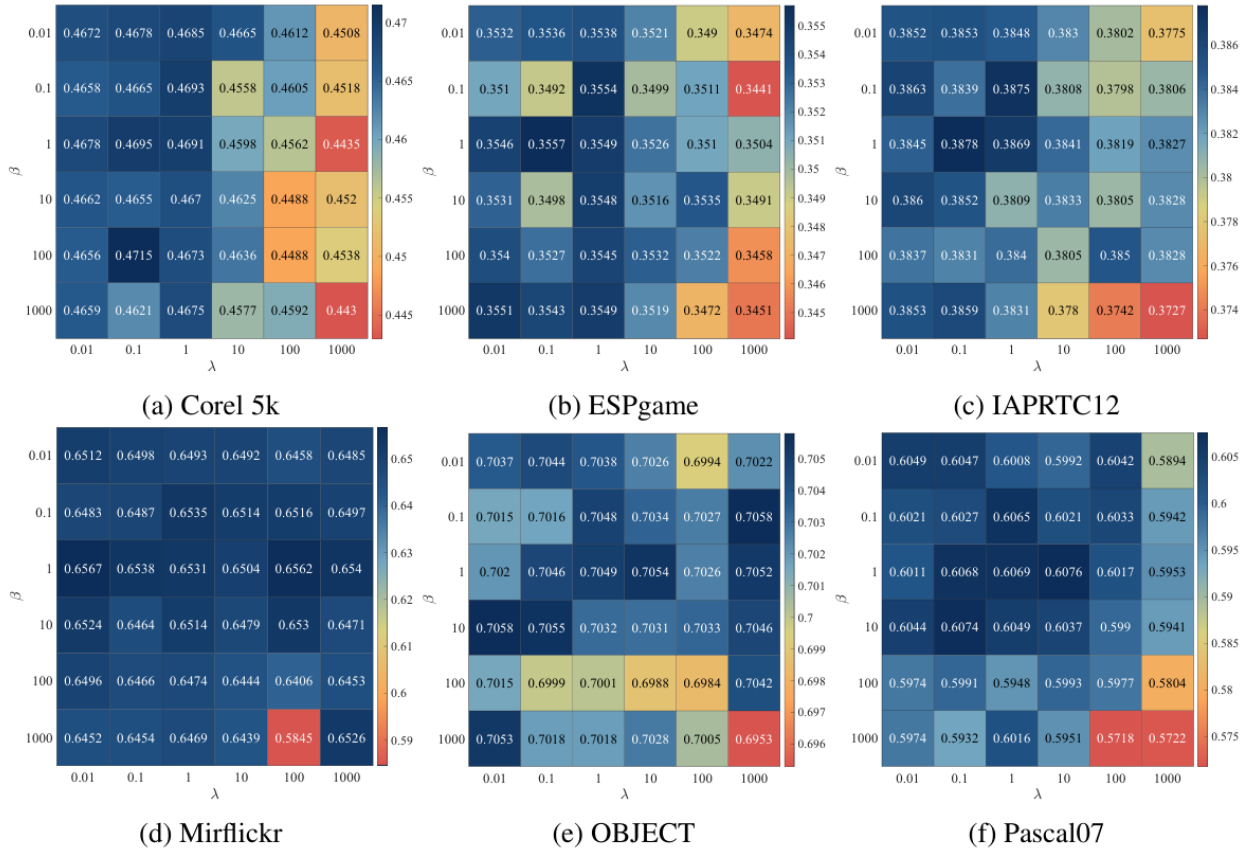


图5. 权衡参数 λ 和 β 的参数分析。（a-f）依次为 Corel5k、ESPGame、IAPRTC12、Mirflickr、OBJECT、Pascal07。热图数字为 AP；坐标数值保留原图。译注：原图坐标包含1000，正文所述搜索集合止于100，二者差异按原稿保留。

复杂度分析。为刻画计算成本，注意原型学习引入 $O(C{\cdot}d_z)$ 个参数，专家乘积融合每个类别需要 $O(|\mathcal{V}|{\cdot}d_z)$ 次操作，置信度加权聚合额外需要 $O((1+|\mathcal{V}|){\cdot}C)$ 次操作。表5比较了各方法的运行时间。由于计算类别特定后验，LGRL 带来适度额外开销，但与现有方法相比仍有竞争力。

Method	Corel5k	Pascal07	Espgame	Mirflickr
iMVWL	513.41	356.28	1822.23	568.46
AIMNet	408.37	247.15	607.02	159.98
DICNet	765.02	489.63	3047.17	1228.27
DIMC	559.77	372.41	995.89	359.66
LMVCAT	1198.72	723.56	3037.25	151.27
MTD	2520.99	1456.82	4080.72	562.55
SIP	1039.93	583.47	1605.16	727.26
TDLSR	2270.64	1327.14	3882.59	520.24
LGRL	1287.35	591.23	1738.42	812.53

表5. 四个数据集上的运行时间比较，单位为秒。Method=方法，其余列为 Corel5k、Pascal07、ESPGame、Mirflickr，原表数值完整保留。

极端不完整情形下的性能。为评估 LGRL 在数据严重稀缺时的鲁棒性，我们在 PER=90%、LMR=90% 下开展实验，代表仅有10%的视图和10%的标签被观测到的极端情形。表4给出了六个基准数据集上的比较结果。尽管设置具有挑战性，LGRL 在六个数据集中的五个取得最佳总体性能，平均排名为1，在 OBJECT 上也保持很强竞争力，仅次于 TDLSR。值得注意的是，极端设置下 LGRL 与竞争方法之间的性能差距更明显。例如，在 Corel5k 上 LGRL 的 AP 为0.360，第二名 TDLSR 为0.323，相对提高 11.5%；相对 SIP（0.242）提高48.8%。其他数据集上也有类似趋势，验证了在监督信号极度稀疏时，标签引导表示学习策略可带来显著收益。

不同缺失比例的影响。为进一步研究不同不完整程度下的性能，我们将 PER 从50%变至90%，同时将 LMR 分别固定在50%、70%、90%。图6、7、8展示上述设置下，十种方法在五个数据集上六项指标的雷达图。此外，图9、10、11、12展示四个数据集上 PER 与 LMR 从30%同步变至90%时的 AP、AUC、1-RL、1-OE 结果。

现实场景应用。图13以雷达图展示不同缺失比例下，十种方法在 NBA 和 CheXpert-MV 数据集上的性能。在 NBA 上，LGRL 在六项指标上始终具有竞争力，随着缺失比例从30%增至90%，优势更加显著。在仅有两个医学影像视图的 CheXpert-MV 上，LGRL 展示了其在不同不完整程度下学习判别表示的有效性。这些结果证实 LGRL 能够良好地泛化至具有不同数据特性的多种现实应用。

附录实验图（完整保留）

以下图中的模型名称、指标缩写和数据集名称保持原样；PER=部分样本比例，LMR=标签缺失比例；方括号为相应坐标轴的数值范围。HL=汉明损失、OE=单错误、Cov=覆盖度、RL=排序损失、AP=平均精度、AUC=曲线下面积。所有数值及图例均保留。



图6. LMR=50% 时，PER 从50%变至90%的十种方法在五个数据集上的实验结果。每行依次对应Corel5k、IAPRTC12、ESPGame、Pascal07、Mirflickr；每行三列的 PER 依次为50%、70%、90%。子图（a-o）顺序与原图一致。



图7. LMR=70% 时，PER 从50%变至90%的十种方法在五个数据集上的实验结果。各行数据集和各列 PER 的含义与图6相同，子图（a-o）顺序不变。

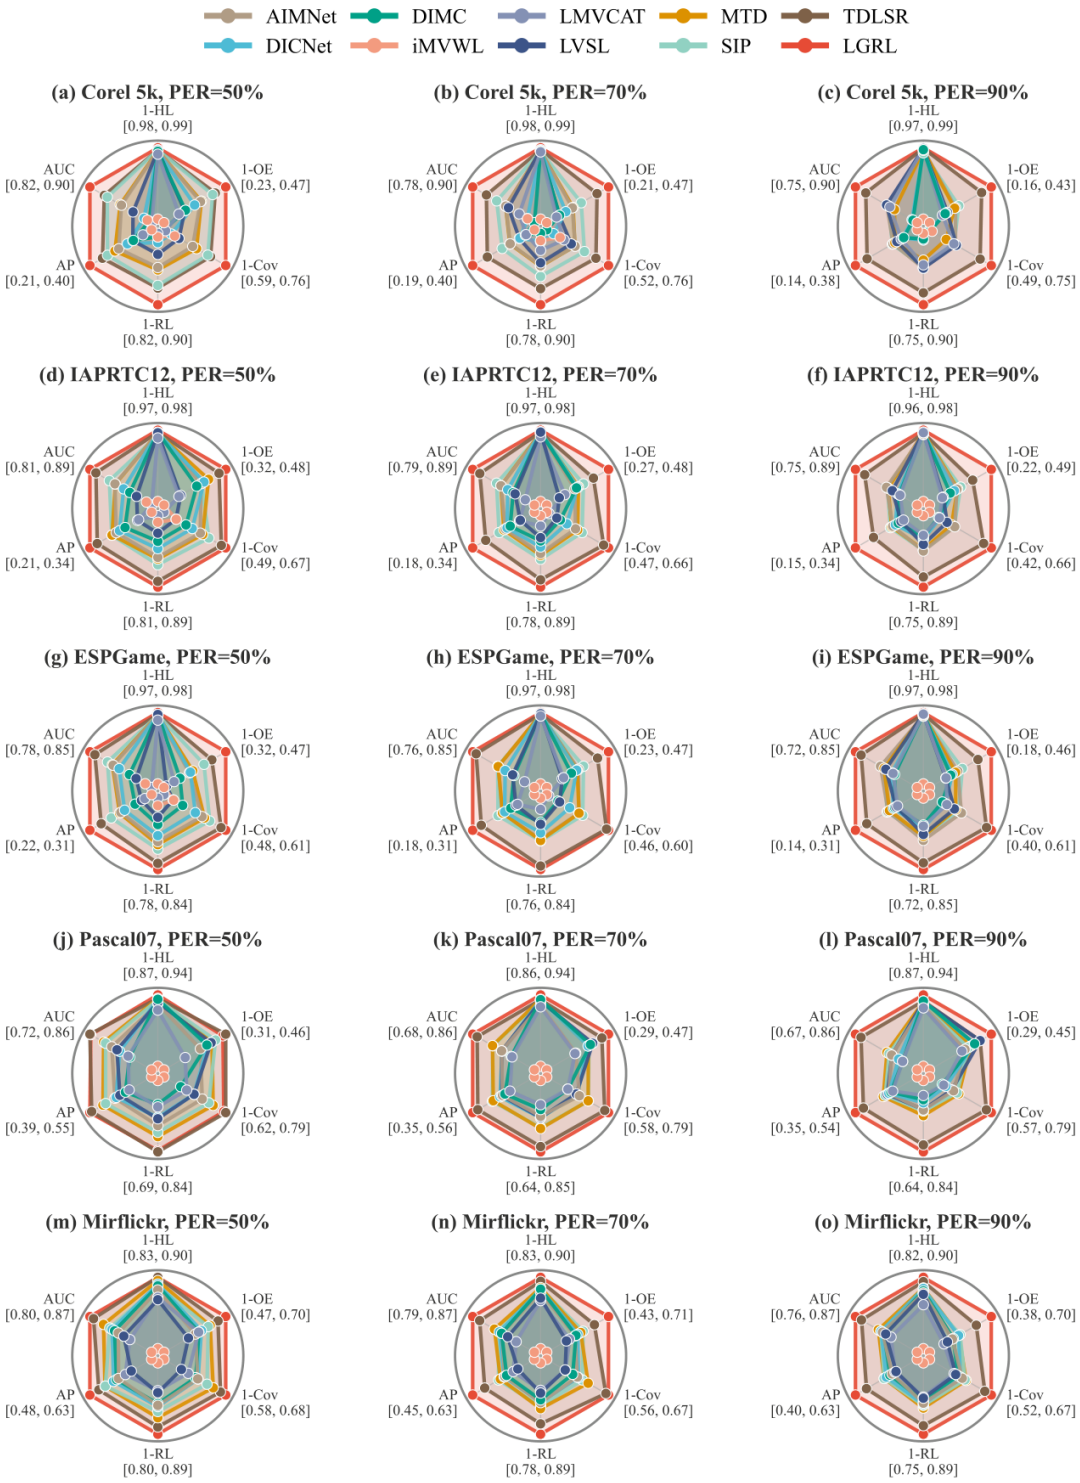


图8. LMR=90% 时，PER 从50%变至90%的十种方法在五个数据集上的实验结果。各行数据集和各列 PER 的含义与图6相同，子图（a-o）顺序不变。

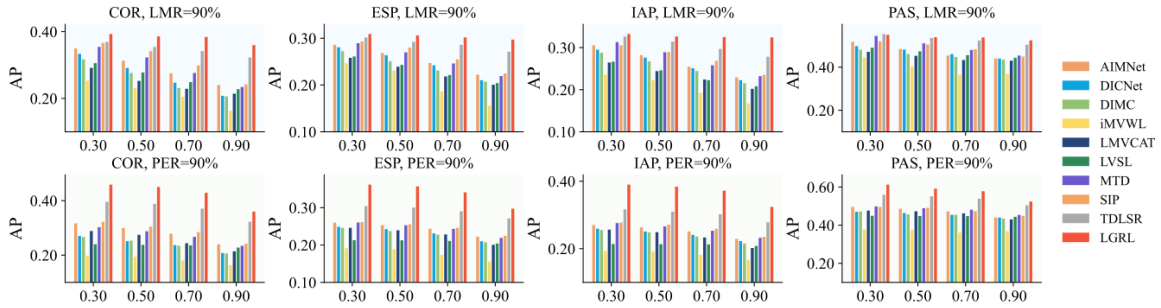


图9. PER 和 LMR 从30%变至90%时，四个数据集上的 AP 结果。COR/ESP/IAP/PAS 分别表示 Corel5k/ESPGame/IAPRTC12/Pascal07。上排固定 LMR=90%，下排固定 PER=90%，横轴为另一项缺失比例。译注：附录正文称“同步变化”，而图中以一项固定、另一项变化的形式呈现；此处保留图文原貌。

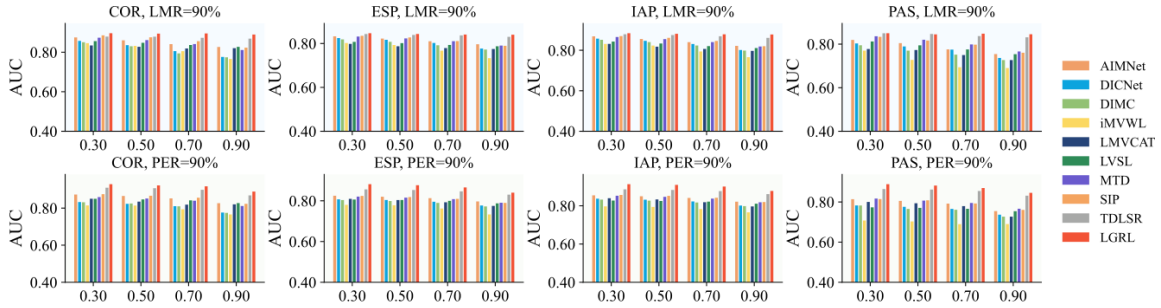


图10. PER 和 LMR 从30%变至90%时，四个数据集上的 AUC 结果。数据集缩写、上下排与横轴含义同图9。

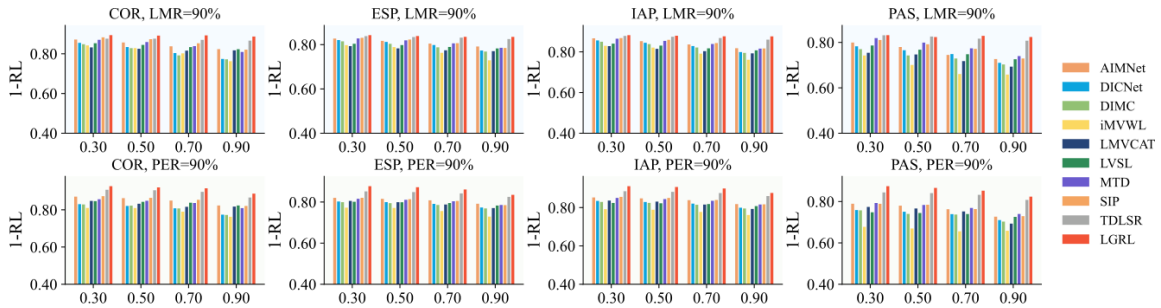


图11. PER 和 LMR 从30%变至90%时，四个数据集上的 1-RL 结果。数据集缩写、上下排与横轴含义同图9。

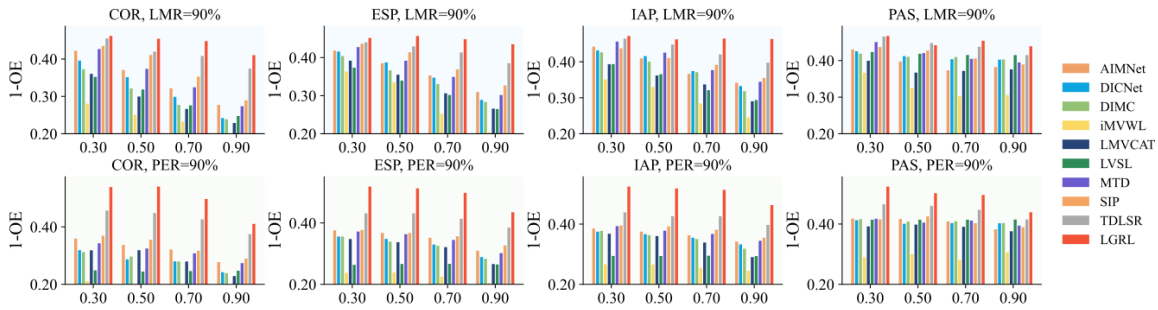


图12. PER 和 LMR 从30%变至90%时，四个数据集上的 1-OE 结果。数据集缩写、上下排与横轴含义同图9。

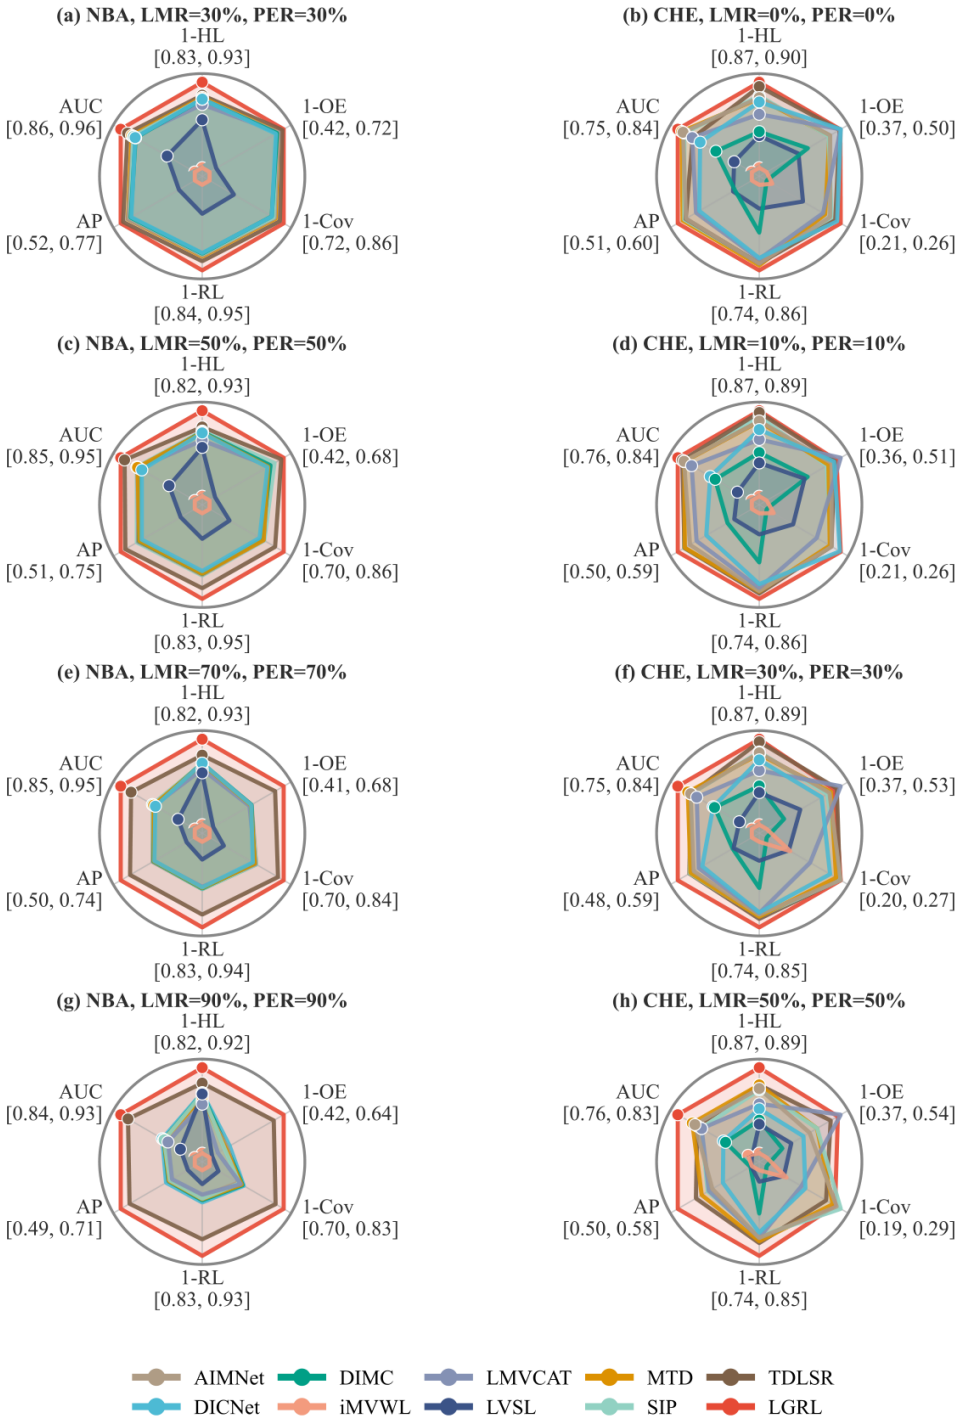


图13. 十种方法在两个应用数据集上的雷达图。左列为 NBA 数据集，LMR 与 PER 从30%同步变至90%；右列为 CheXpert-MV 数据集，LMR 与 PER 从0%同步变至50%。每条轴代表一项评价指标，范围标注在方括号中。左列（a、c、e、g）依次为30%、50%、70%、90%；右列（b、d、f、h）依次为0%、10%、30%、50%。CHE=CheXpert-MV。