面向不完整多视图缺失多标签分类的紧凑语义信息学习

非官方中文全文译文 · COME · ICML 2025

Jie Wen[1]、Yadong Liu[1]、Zhanyan Tang[1]、Yuting He[2]、Yulong Chen[1]、Mu Li[1]、Chengliang Liu[1]

[1] 哈尔滨工业大学（深圳）计算机科学与技术学院，中国深圳 518000。[2] 凯斯西储大学生物医学工程系，美国俄亥俄州克利夫兰 44106。通信作者：Chengliang Liu（liucl1996@163.com）。

原文：Wen, J. et al. Learning Compact Semantic Information for Incomplete Multi-View Missing Multi-Label Classification. Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267:66467–66480, 2025。版权 © 2025 原作者。

原文链接：https://proceedings.mlr.press/v267/wen25c.html 。依据 PMLR 出版协议的 CC BY 4.0 许可翻译、重新排版；许可：https://creativecommons.org/licenses/by/4.0/ 。本译文由 AI 辅助完成，未经原作者审定；改动为中文翻译与版式调整。公式及图表保留原图以确保数字和符号不变，并配中文说明；参考文献保留英文。原文存在的符号或表述差异不擅自修正。

摘要

多视图数据涵盖多特征、多序列、多模态等不同数据形式，能够为下游任务提供丰富的语义信息。不完整多视图缺失多标签学习的内在挑战，是如何有效利用有限的监督和不充分的数据学习具有判别力的表示。从多视图共享信息对于下游任务的充分性出发，我们认为，现有的缺失多视图数据对比学习范式在一致性表示学习方面能力有限，从而成为提取多视图共享信息的瓶颈。为此，我们通过追求跨视图互信息最大化，最小化与任务无关的冗余信息。此外，为缓解标签缺失造成的阻碍，我们提出双分支软伪标签交叉填补策略，以改善分类性能。在多个基准上的大量实验验证了我们的方法的优势，并表明该方法对缺失数据和完整数据均具有很强的兼容性。

1. 引言

多模态学习旨在融合不同模态（如图像、文本、语音等）的数据，以增强模型的理解和决策能力。这一方法已在医学诊断（Qiu et al., 2022; Luo et al., 2023; Lin et al., 2025）、可穿戴设备（Wen et al., 2022; Fang et al., 2024）、情感分析（Soleymani et al., 2017; Zhang et al., 2023）以及多媒体信息检索（Fang et al., 2022）等领域展现出巨大潜力。不仅具有显著差异的多模态数据拥有丰富的表征能力，同一样本的多特征数据同样具有强大的表征能力。基于这类多模态或多特征数据执行机器学习或数据分析任务的学习范式，被统一纳入多视图学习的理论框架（Zhang et al., 2019）。这一框架在下游任务中的成功，很大程度上归功于对多视图一致性语义信息的提取与利用（Hwang et al., 2021; Zeng et al., 2023; Fang et al., 2023）。

传统的单标签分类任务通常假设每个样本对应唯一标签。然而，在现实应用中，几乎所有样本都可能与多个标签相关联。例如，在自动驾驶任务中，相机拍摄的图像可能包含多个实体，并对应若干标签。多标签学习（MLL）任务因其实用意义而受到越来越多关注（Zhou et al., 2012），其目标是为一个未标注样本预测所有可能相关的标签。近年来的大量研究见证了 MLL 在多种实际应用中的显著进展，例如文档分类（Fallah et al., 2023）、情绪识别（Zhang et al., 2021; Ameer et al., 2022）以及图像标注（Chen et al., 2019）。

结合上述两类任务的特点，多视图多标签分类（MVMLC）方法（Wu et al., 2019; Zhang et al., 2020）旨在尽可能利用样本的多视图语义信息，提升多标签分类性能。然而，在现实的数据采集过程中，各种原因引起的失败往往不可避免。例如，医学诊断中常因隐私顾虑或经济因素而缺少诊断报告。此外，人工标注标签可能产生不完整的标记。因此，有必要研究不完整多视图缺失多标签分类（iM3C），即部分视图与部分标签同时缺失的情形。

针对不完整多视图问题，Zhao 等提出 CDMM（Zhao et al., 2021），在探索多视图一致性与多样性的同时，采用集成学习策略获得最终结果。为缓解可用标签信息不足，Zhao 等根据视图空间与标签空间之间的结构一致性提出 LVSL（Zhao et al., 2022）。Li 等从不完整多标签学习的角度出发，利用预测矩阵捕获全局和局部标签结构，以解决标签不完整问题（Ma & Chen, 2021）。上述三种方法对多视图学习或多标签分类领域作出了重要贡献，但无法全面解决 iM3C 问题。因此，Tan 等提出 iMVWL，可以从具有缺失标签的不完整视图中同时学习共享子空间（Tan et al., 2018）。Li 等提出 NAIM3L，构造涉及可用视图和已知标签信息的复合索引矩阵，以减轻其负面影响（Li & Chen, 2021）。近年来，深度学习取得了长足进展（Yang et al., 2023b）。除上述传统方法外，Liu 等在 iM3C 任务中引入深度不完整实例级对比学习，提取多视图特征（Liu et al., 2023）。为进一步利用监督信息，Xie 等对视图级和标签级嵌入施加双图约束，并通过不确定性感知策略生成缺失标签（Xie et al., 2024b）。考虑多视图一致性和多标签分类任务之间的耦合，SIP 方法以数据驱动方式构建标签原型，并通过信息瓶颈进一步提取任务相关信息（Liu et al., 2024）。

这些方法的成功与多视图一致性信息（即共享信息）的提取和学习密切相关。进一步地，我们假设几乎所有与下游分类任务有关的信息都由各视图共享（Federici et al., 2020; Tsai et al., 2020）。尽管现有基于对比学习的方法在提取一致性语义特征方面取得了显著进展，我们观察到，在不完整数据上，对比学习聚合多视图潜在特征的效果仍然有限，表明对比学习处理不完整多视图数据的能力不足。因此，本文提出一种基于混合专家（MoE）框架的互信息增强策略，通过最大化共享表示与原始数据之间的跨视图互信息，压缩跨视图联合表示中的共享信息。此外，缺失多标签数据中弱监督信息不足，也阻碍了多标签分类性能的进一步提升。为此，我们采用双分支软伪标签交叉填补策略，缓解监督信息缺失的负面影响。

总体而言，我们针对 iM3C 任务提出一种新颖的一致性语义表示学习框架，称为 COME。与现有方法相比，贡献如下：

- 提出多视图语义一致性增强策略，以学习紧凑的多视图共享信息，有效缓解不完整对比学习导致的性能下降。
- 与现有工作不同，我们采用双分支协同训练，动态生成软伪标签，用于缺失多标签填补。
- COME 对任意视图与标签不完整情形具有良好适应性。在完整和不完整条件下的大量实验结果，均表明该方法的优越性和鲁棒性。

2. 预备知识与研究动机

2.1. 问题定义

对于 iM3C 任务，定义变量集合 $\{x^{(v)}\}_{v=1}^{m}$ 为具有 m 个观测的任一样本，其中 $x_i^{(v)} \in \mathbb{R}^{d_v}$ 是变量 $x^{(v)}$ 的第 i 个采样，d_v 表示第 v 个视图的维度。定义 $y \in \{0,\ 1\}^c$ 为不完整标签集合，c 为类别数。考虑视图缺失与标签缺失的影响，定义满足 $|V| \leq m$ 的 V 为可用视图集合。具体地，$\{x^{(v)}\}_{v \in V}$（简记为 X^V）表示能够观测到的视图。类似地，定义满足 $|G| \leq c$ 的 G 为已知类别集合。令 n 为样本数。我们的目标是从 X^V 学习多视图联合表示 z，使其包含所有可以用于准确预测相应类别的语义一致性信息。

2.2. 多视图共享表示的充分性

假设每个样本只有两个视图，$z^{(1)},\ z^{(2)}$ 分别为 $x^{(1)},\ x^{(2)}$ 的潜在表示，并引入变量 T 表示分类相关信息。由于我们假设多视图共享表示包含全部任务相关信息，受 Federici et al. (2020) 和 Tsai et al. (2020) 启发，引入如下冗余性假设：

假设 2.1。 $x^{(1)}$ 与 $x^{(2)}$ 共享相同的、足以进行预测的语义信息：$I\left(x^{(1)};\ T\right) = I\left(x^{(2)};\ T\right)$。即如果 $z^{(1)}$ 满足 $I\left(x^{(1)};\ x^{(2)} \mid z^{(1)}\right) = 0$，那么 $z^{(1)}$ 包含预测所需的全部任务相关信息：$I\left(\{x^{(1)},\ x^{(2)}\};\ T\right) = I\left(x^{(1)};\ T\right) = I\left(z^{(1)};\ T\right)$。

在多视图应用中，各视图表示被组合起来，以充分利用共享语义信息。进一步地，我们给出多视图联合表示 z 的语义充分性命题：

命题 2.2。 如果 z 包含视图之间的全部共享信息，那么 z 对预测是充分的。

由命题 2.2，有 $I(z;\ T) = I\left(x^{(1)};\ T\right) = I\left(x^{(2)};\ T\right)$。需要注意，如果 z 包含来自 $x^{(1)}$ 和 $x^{(2)}$ 的全部信息，那么它自然包含下游任务所需的所有信息。然而，在实际应用中，z 中包含的冗余信息会导致性能下降。因此，应尽可能压缩联合表示中的非共享信息，即追求所有视图之间的最小充分共享表示：

定义 2.3（最小充分共享表示）。 联合表示 z 对 $x^{(1)}$ 和 $x^{(2)}$ 是最小且充分的，当且仅当 $I\left(x^{(1)},\ x^{(2)}\right) = I\left(z,\ x^{(1)}\right) = I\left(z,\ x^{(2)}\right)$。

2.3. 不充分的多视图对比学习

经验证据表明，即使训练期间不利用任何下游监督信息，自监督学习（SSL）方法仍能学习到对广泛下游任务具有良好泛化能力的嵌入。例如，SimCLR（Chen et al., 2020）定义对比损失，并使用增强图像作为自监督信号，使训练后的模型能够有效执行多种任务。在以往框架中，自监督信号通常通过数据增强产生，例如词掩码（Devlin, 2018）或图像旋转（Gidaris et al., 2018）。在多视图对比学习中，我们认为，同一样本的不同视图变量应共享语义一致性信息，而不同样本的变量则未必如此（Tian et al., 2020; Pan & Kang, 2021; Liu et al., 2023）。

现有研究已证明，对比学习与视图间互信息最大化存在正相关关系（Tsai et al., 2020; Wang et al., 2022）。即对比学习的目标等价于 $\max I\left(z^{(1)}; z^{(2)}\right)$。根据多视图数据 $\{x^{(1)}, x^{(2)}\}$ 及其潜在表示 $\{z^{(1)}, z^{(2)}\}$，基于数据处理不等式（Thomas & Joy, 2006）和马尔可夫链，有：

$$I\left(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}\right) \geq I\left(\mathbf{z}^{(1)}, \mathbf{x}^{(2)}\right) \geq I\left(\mathbf{z}^{(1)}, \mathbf{z}^{(2)}\right) \qquad (1)$$

当模型容量和训练数据足够充分时，$I\left(x^{(1)}, x^{(2)}\right)$ 与 $I\left(z^{(1)}, z^{(2)}\right)$ 之间的差距会足够小。理想情况下，对比学习能够压缩非共享信息，并最大化表示中共享信息的比例。然而，我们观察到，通过不完整数据上的对比学习学得的共享表示并不充分。如图 1 所示，我们在两个常用多视图多标签数据集 Corel5k 和 Pascal07 上进行实验，展示不充分对比学习造成的性能下降。视图缺失比例设为 50%，缺失实例不参与对比损失中正负样本对的构建。可以观察到，相比完整视图情形，在不完整数据上进行对比学习会导致较差的分类性能。众所周知，对比学习的核心思想是拉近正样本对、推远负样本（Khosla et al., 2020）。视图缺失时，对比学习推远负样本对和拉近正样本对的效果较弱。为解决缺失多视图数据下对比学习不充分的问题，我们提出基于 MoE 的互信息增强框架，通过压缩冗余信息、最大化跨视图互信息，学习多视图数据的最小充分表示。

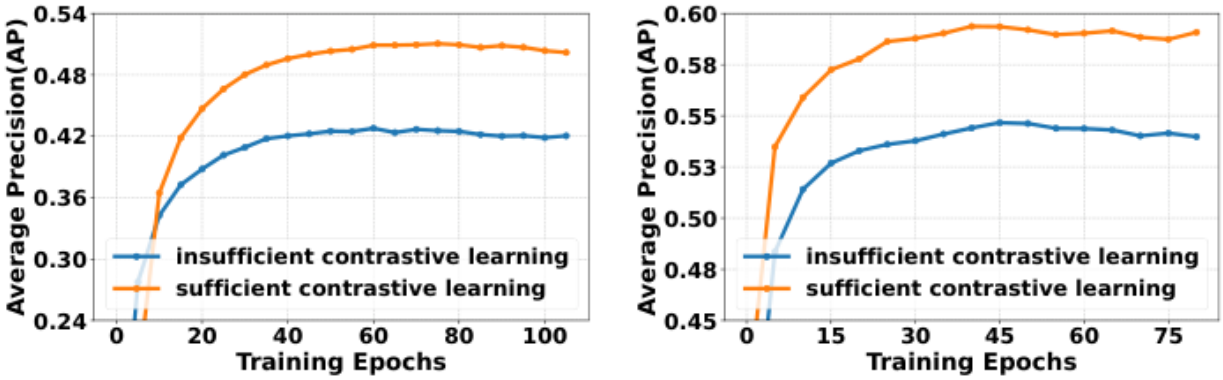


图 1。 在不完整与完整多视图数据条件下，对比损失对 Corel5k（a）和 Pascal07（b）数据集平均精度（AP）的影响。横轴为训练轮数；蓝色为不充分的对比学习，橙色为充分的对比学习。

2.4. 伪标签学习

在 iM3C 任务中，标签也不完整，以往方法在训练过程中利用不完整标签指示量屏蔽缺失部分。为减轻标签缺失的负面影响，受一些 SSL 方法（Lee et al., 2013; Berthelot et al., 2019; Sohn et al., 2020; Xu et al., 2021）启发，一种直观策略是为标签缺失的样本赋予伪标签。伪标签最初用于深度神经网络的半监督训练（Lee et al., 2013）。一些方法（Berthelot et al., 2019; Sohn et al., 2020）结合一致性正则化或熵正则化，改善伪标签质量。常用 SSL 方法 FixMatch（Sohn et al., 2020）选择最可能的标签作为伪标签，称为 Top-1 策略。然而，即使不考虑正确性，这种方法显然也会忽略多个真实标签。在图 2(a) 的 Pascal07 数据集上，上述 Top-1 策略生成的伪标签数少于实际缺失标签数。另一种选择

是取概率最高的 Top-k 个标签，但实践中很难设定 k。如图 2(b) 所示，Pascal07 样本的真实正标签数量不是常数。其他数据集的样本标签数量分布见附录 E。因此，简单的标签生成策略不可避免地会引入假阳性标签或忽略真正的正标签。

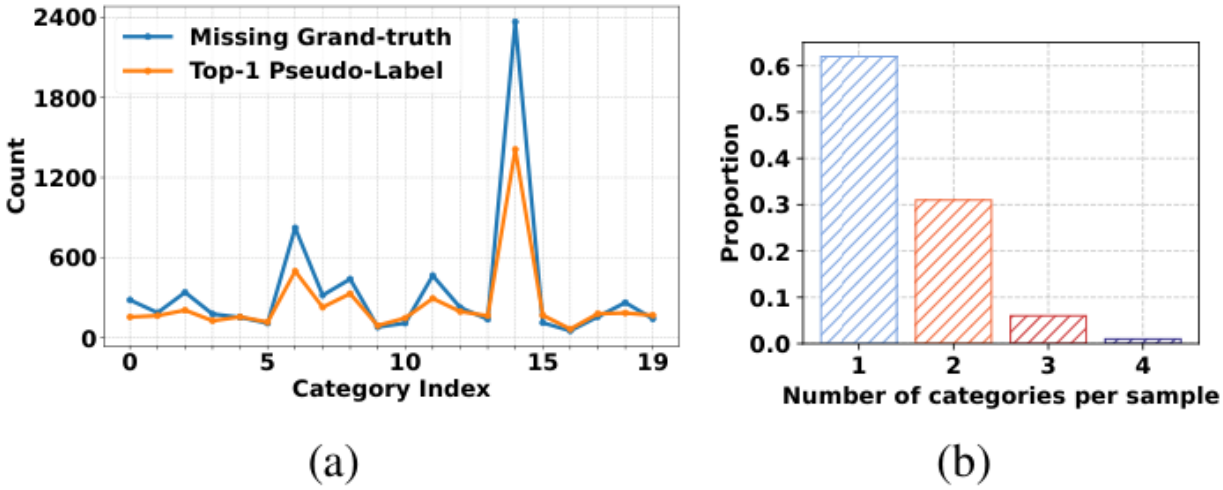


图 2。 （a）Pascal07 数据集上的 Top-1 伪标签与缺失真实标签；横轴为类别索引，纵轴为数量，蓝线表示缺失真实标签，橙线表示 Top-1 伪标签。（b）Pascal07 中各样本的标签数量分布；横轴为每个样本的类别数，纵轴为比例。

此外，考虑不同类别间的类别不平衡差异（Yang et al., 2021; Fang et al., 2025），一些研究提出通过复杂方法生成伪标签，包括类别感知方法（Xie et al., 2024a）、基于类别阈值的方法（Xiao et al., 2024）和基于标签原型的方法（Yang et al., 2023a）。这些方法直接使用生成的硬伪标签训练模型，将其视为真实标签。由于伪标签并非完全准确，使用硬伪标签可能使模型产生偏差，进一步放大错误并导致恶性循环。为解决这一问题，我们提出双分支软伪标签交叉填补策略，减少多标签缺失对多标签分类的阻碍。

3. 方法

本节从三方面介绍我们的方法：不完整多视图对比学习；基于互信息最大化的紧凑共享信息表示学习；双分支软伪标签生成与多标签分类。

3.1. 不完整多视图对比学习

根据第 2 节分析，我们首先建立视图间互信息最大化的优化目标，促进多视图一致性语义表示学习。给定任意两个视图，优化目标为：

$$\max \sum_{v \in \mathcal{V}} \sum_{t \neq v} I\left(\mathbf{z}^{(v)}; \mathbf{z}^{(t)}\right) \tag{2}$$

为实现式（2）的最大化，我们采用 Liu et al. (2023) 提出的不完整多视图对比学习方法，得到如下对比损失：

$$\mathcal{L}_{CTR} = -\sum_{v\in\mathcal{V}}\sum_{t\neq v}\log\frac{\exp(\mathbf{f}(z_i^{(v)}, z_i^{(t)}))}{\exp(\mathbf{f}(z_i^{(v)}, z_i^{(t)})) + \mathbb{S}_{neg}} \tag{3}$$

其中 $S_{neg} = \sum_{r=v,t}\sum_{j=1,j\neq i}^{n}\exp\left(f\left(z_i^{(v)}, z_j^{(r)}\right)\right)$； $z_i^{(v)}$ 表示从 $z^{(v)}$ 的分布中采样，f 是衡量样本对余弦相似度的函数。为此，我们采用视图特定的随机编码器近似分布 $p(z^{(v)} \mid x^{(v)})$。类似于以往工作（Shi et al., 2019; Wen et al., 2020），我们将联合变分后验分解为单模态后验的组合，使用 MoE 建模 $p(z \mid X^V)$，因此有：

$$p(\mathbf{z}|\mathbf{X}^{\mathcal{V}}) = \sum_{v\in\mathcal{V}}\frac{1}{|\mathcal{V}|}p(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}) \tag{4}$$

3.2. 紧凑共享表示学习

回顾第 2.3 节的分析可知，仅通过多视图对比学习优化目标（2），不足以压缩共享信息。此外，还需避免过度压缩破坏信息有效性，即学得的联合表示 z 缺乏足够的预测信息。基于此，我们提出最大化原始数据与联合表示之间的互信息：

$$\max I(\mathbf{X}^{\mathcal{V}}; \mathbf{z}) \tag{5}$$

显然，式（5）要求跨视图联合表示与所有视图的原始数据保持互信息最大化，从而确保跨视图联合表示 z 进一步学习所有可用视图之间的共享信息。

对于式（5）中的互信息 $I(X^V; z)$，可得到如下变分下界：

$$\begin{aligned} & I(\mathbf{X}^{\mathcal{V}}; \mathbf{z}) \\ &= \int\int p(\mathbf{X}^{\mathcal{V}}, \mathbf{z})\log\frac{p(\mathbf{X}^{\mathcal{V}}|\mathbf{z})}{p(\mathbf{X}^{\mathcal{V}})}d\mathbf{X}^{\mathcal{V}}d\mathbf{z} \\ &\geq \mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z})d\mathbf{z}] \end{aligned} \tag{6}$$

其中 $q(X^V \mid z)$ 是为近似 $p(X^V \mid z)$ 而引入的额外分布。随后，基于多视图条件独立假设，条件分布可分解为 $q(X^V \mid z) = \prod_{v\in V} q(x^{(v)} \mid z)$。结合式（4），可将式（5）中的变分下界改写如下：

$$
\begin{aligned}
&\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}\Big[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z})d\mathbf{z}\Big] \\
=&\frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}}\mathbb{E}_{\mathbf{x}^{(v)}\sim p(\mathbf{x}^{(v)})}\Big[\int p(\mathbf{z}|\mathbf{x}^{(v)})\log q(\mathbf{x}^{(v)}|\mathbf{z})d\mathbf{z}\Big] \\
+&\frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}}\sum_{u\in\mathcal{V},u\neq v}\mathbb{E}_{\mathbf{x}^{(v)}\sim p(\mathbf{x}^{(v)})}\Big[\int p(\mathbf{z}|\mathbf{x}^{(v)})\log q(\mathbf{x}^{(u)}|\mathbf{z})d\mathbf{z}\Big]
\end{aligned}
\tag{7}
$$

式（6）和式（7）的完整推导见附录 A。这里使用 $q(x^{(v)} \mid z)$ 近似 $p(x^{(v)} \mid z)$，通过标准差固定为 1 的随机解码器实现。具体地，设 $q(x^{(v)} \mid z) = \mathcal{N}\left(x^{(v)} \mid \mu^{(v)}(z),\, I\right)$，其中 $\mu^{(v)}$ 为均值映射函数。结合高斯分布的性质，优化目标等价为：

$$
\max \mathbb{E}_{p(z|x^{(v)})}\left[\log q(x^{(v)} \mid z)\right] \Leftrightarrow \max\ -\mathbb{E}_{p(z|x^{(v)})}\left[\ \| \ x^{(v)} - \mu^{(v)}(z)\ \|_2^2\right].
$$

因此，很容易得到用于最大化式（7）的重建损失：

$$
\begin{aligned}
\mathcal{L}_{RE} &= \lambda_1 \sum_{v\in\mathcal{V}} \|\mathbf{x}^{(v)} - \mu^{(v)}(\mathbf{z}^{(v)})\|_2^2 + \\
&\quad \lambda_2 \sum_{v\in\mathcal{V}}\sum_{u\in\mathcal{V},u\neq v} \|\mathbf{x}^{(u)} - \mu^{(u)}(\mathbf{z}^{(v)})\|_2^2 \\
&= \lambda_1\mathcal{L}_{RE1} + \lambda_2\mathcal{L}_{RE2}
\end{aligned}
\tag{8}
$$

其中 λ_1 和 λ_2 为权衡系数。随后，将重建损失与对比损失结合，实现最小充分表示学习目标：

$$
\mathcal{L}_{MSR} = \lambda_1\mathcal{L}_{RE1} + \lambda_2\mathcal{L}_{RE2} + \beta\mathcal{L}_{CTR} \tag{9}
$$

其中 β 是对比损失的惩罚系数。

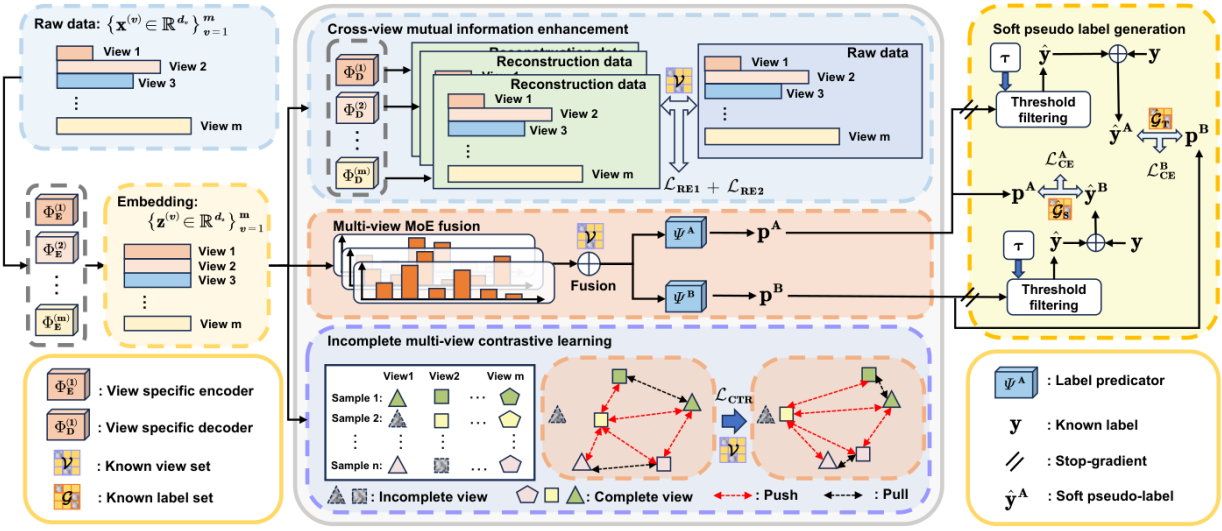


图 3。 COME 的主要框架，由不完整多视图对比学习、多视图互信息增强以及动态软伪标签生成组成。图中文字：Raw data＝原始数据，Embedding＝嵌入，View＝视图，Sample＝样本；Cross-view mutual information enhancement＝跨视图互信息增强，Reconstruction data＝重建数据；Multi-view MoE fusion＝多视图 MoE 融合，Fusion＝融合；Soft pseudo label generation＝软伪标签生成，Threshold filtering＝阈值筛选；View specific encoder/decoder＝视图特定编码器/解码器；Known view/label set＝已知视图/标签集合；Incomplete/Complete view＝不完整/完整视图；Push/Pull＝推远/拉近；Label predictor＝标签预测器；Known label＝已知标签；Stop-gradient＝停止梯度；Soft pseudo-label＝软伪标签。

3.3. 双分支软伪标签生成与多标签分类

以往工作直接将模型生成的伪标签用作下一轮训练的监督信息。然而，我们认为，把当前网络的高置信度预测作为真实标签，对网络的帮助有限。这也可能导致模型对简单样本过拟合，因为模型的性能瓶颈并不在于容易区分的样本分类。此外，这种伪标签使用方式会放大错误伪标签的误导作用，使错误在训练过程中不断累积。为此，我们提出双分支软伪标签交叉填补策略，高效生成可靠的伪标签，进一步提高分类性能。

具体而言，我们首先采用双分支模型生成并利用伪标签，使用两个独立但结构相同的模型 A 和 B，即 $A:\{x^{(v)}\}_{v=1}^{m} \rightarrow z \rightarrow p^{A}$、$B:\{x^{(v)}\}_{v=1}^{m} \rightarrow z \rightarrow p^{B}$，其中 p^{A} 和 p^{B} 分别是模型 A 和 B 预测的逻辑得分。由此构建两个独立预测模型作为两个分支。针对第 2.4 节所述伪标签自生成策略的局限，我们利用外部伪标签改善模型优化。简言之，核心动机是让两个分支相互生成伪标签，用于下一轮迭代。具体地，模型 A 的伪标签生成过程如下：

$$\hat{\mathbf{y}}^{\mathbf{A}} = \begin{cases} \mathbf{None}, & \text{if } \mathbf{c} \notin \mathcal{G} \text{ and } \mathbf{p}_{\mathbf{c}}^{\mathbf{A}} < \tau \\ \mathbf{p}_{\mathbf{c}}^{\mathbf{A}}, & \text{if } \mathbf{c} \notin \mathcal{G} \text{ and } \mathbf{p}_{\mathbf{c}}^{\mathbf{A}} \geq \tau \\ \mathbf{y}_{\mathbf{c}}, & \text{if } \mathbf{c} \in \mathcal{G} \end{cases} \tag{10}$$

其中 $\widehat{y}^A$ 表示模型 A 的伪标签。式中的 None 表示不生成标签：对未知类别，预测分数低于阈值时不填补，达到阈值时保留软预测值；已知类别则保留原标签。还需要将生成的软伪标签纳入已知标签集合，并调整分别对应 $\widehat{y}^A$ 和 $\widehat{y}^B$ 的 G，得到 $\widehat{G}^A$ 和 $\widehat{G}^B$。为增强软伪标签的可靠性，我们建立动态阈值调整策略。训练初期采用更严格的阈值，以确保伪标签质量，尽量降低引入噪声的风险。随着训练推进，逐渐放宽阈值、扩大生成伪标签的范围，在准确性与错误之间取得平衡：

$$\tau = \max(\tau_l, \tau_h - e \times \theta) \tag{11}$$

其中 τ_l 表示阈值范围下界，τ_h 表示初始最大阈值，θ 为阈值衰减率，e 为第 e 个训练轮次。得到两个软伪标签 $\widehat{y}^A$ 和 $\widehat{y}^B$ 后，只需交换它们，作为另一分支下一轮训练的监督信号。模型 A 的交叉熵损失如下：

$$\mathcal{L}_{CE} = \frac{1}{|\hat{\mathcal{G}}^{\mathbf{B}}|} \sum_{j \in \hat{\mathcal{G}}^{\mathbf{B}}} [(1 - \hat{\mathbf{y}}_j^{\mathbf{B}}) \log(1 - \mathbf{p}_j^{\mathbf{A}}) + \hat{\mathbf{y}}_j^{\mathbf{B}} \log \mathbf{p}_j^{\mathbf{A}}] \tag{12}$$

两个分支网络相互生成伪标签；对每个分支而言，该策略帮助其从外部获取额外监督信息。两个分支的训练方式和参数更新策略相同，但彼此独立。由于两分支结构相同，我们直接取模型 A 的预测作为最终结果。最后，将各组件的目标函数相加，得到整体优化目标：

$$\mathcal{L} = \lambda_1 \mathcal{L}_{RE1} + \lambda_2 \mathcal{L}_{RE2} + \beta \mathcal{L}_{CTR} + \mathcal{L}_{CE} \tag{13}$$

其中 λ_1, λ_2, β 为超参数。为便于理解，算法 1 给出模型 A 的训练过程。

算法 1：COME 的训练过程

1. 输入：不完整多视图数据 $\{x^{(v)}\}_{v=1}^m$、已知视图集合 V、不完整多标签 $y \in \{0, 1\}^c$、已知标签集合 G。
2. 输出：模型 A 训练后的参数。
3. 初始化：初始化模型 A 参数，设置超参数 λ_1, λ_2, β 和训练轮数 E。
4. 对 e＝1，...，E，执行：
5. 用编码器计算每个可用视图上的样本潜在表示 $\{z^{(v)}\}_{v=1}^m$。
6. 用解码器重建可用视图。
7. 根据式（9）计算不完整多视图对比损失、视图间重建损失和视图内重建损失，得到 L_{MSR}。
8. 根据式（4）融合样本的多视图表示，得到多视图联合表示 z。
9. 根据式（10）从模型 B 获得 $\widehat{y}^B$，并获得对应的新已知标签集合 $\widehat{G}^B$。
10. 根据式（12）计算模型 A 的分类损失 L_{CE}，并计算总损失 $L = L_{CE} + L_{MSR}$。

11. 使用 L 更新模型 A 的参数。
12. 结束循环。

4. 实验

4.1. 实验设置

数据集。 与以往工作（Tan et al., 2018; Liu et al., 2023）一致，我们在五个多视图多标签数据集上进行实验：Corel5k（Duygulu et al., 2002）、Pascal07（Everingham et al., 2010）、ESPGame（Von Ahn & Dabbish, 2004）、IAPRTC12（Grubinger et al., 2006）和 Mirflickr（Huiskes & Lew, 2008）。每个数据集包含六种不同特征：GIST、HSV、DenseHue、DenseSIFT、RGB、LAB。五个数据集的详细信息以及用于模拟真实情形的数据掩码方案见附录 B。

比较方法。 实验选择八种常用方法与 COME 比较，包括 CDMM（Zhao et al., 2021）、DM2L（Ma & Chen, 2021）、LVSL（Zhao et al., 2022）、iMVWL（Tan et al., 2018）、NAIM3L（Li & Chen, 2021）、DICNet（Liu et al., 2023）、UPDGD-Net（Xie et al., 2024b）和 SIP（Liu et al., 2024）。并非所有方法都能处理不完整视图与标签，因此有必要修改部分方法。我们对不同模型作了相应调整，更多技术细节见附录 C。

评价指标。 为与以往工作保持一致，我们使用六个常用性能指标：平均精度（AP）、汉明损失（HL）、排序损失（RL）、ROC 曲线下面积（AUC）、单错误率（OE）和覆盖度（Cov）。为更清晰地展示结果，使用 1-RL、1-HL、1-OE、1-Cov 作为最终展示结果，使六项指标均为数值越大性能越好。

4.2. 实验结果与分析

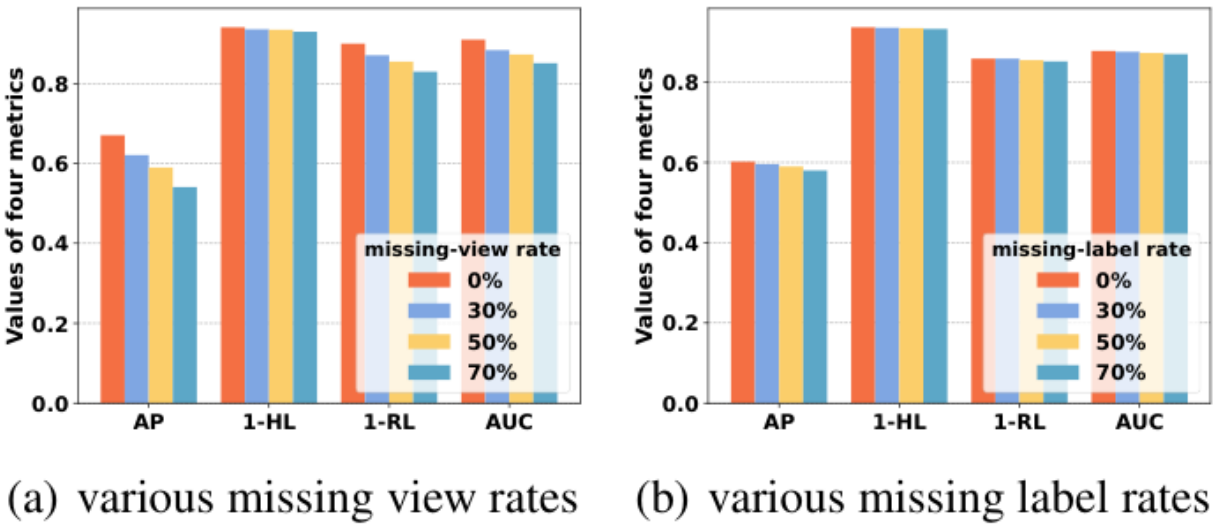
本节将我们的方法与其他八种常用算法在上述五个数据集上比较。视图缺失率和标签缺失率均为 50% 时，六项评价指标的实验结果见表 1。可以得到如下观察：

- 与五个数据集上的其他八种常用方法相比，COME 在所有指标上取得最优性能，充分验证了方法在 iM3C 任务上的有效性。
- 相较于仅考虑单一数据缺失的模型，处理双重缺失问题的模型表现出更好的性能和鲁棒性。这些发现为未来设计 iM3C 模型提供了有价值的见解。

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L	DICNet	UPDGD-Net	SIP	**COME**
Corel5K	AP	$0.354_{0.004}$	$0.262_{0.005}$	$0.342_{0.004}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.381_{0.004}$	$0.413_{0.004}$	$0.418_{0.009}$	$0.432_{0.009}$
	1-HL	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$
	1-RL	$0.884_{0.003}$	$0.843_{0.002}$	$0.881_{0.003}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.882_{0.004}$	$0.903_{0.003}$	$0.911_{0.003}$	$0.917_{0.003}$
	AUC	$0.888_{0.003}$	$0.845_{0.002}$	$0.884_{0.003}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.884_{0.004}$	$0.905_{0.004}$	$0.913_{0.003}$	$0.919_{0.002}$
	1-OE	$0.410_{0.007}$	$0.295_{0.014}$	$0.391_{0.009}$	$0.311_{0.015}$	$0.350_{0.009}$	$0.468_{0.007}$	$0.480_{0.002}$	$0.489_{0.016}$	$0.503_{0.020}$
	1-Cov	$0.723_{0.007}$	$0.647_{0.005}$	$0.718_{0.006}$	$0.702_{0.008}$	$0.725_{0.005}$	$0.727_{0.011}$	$0.777_{0.008}$	$0.787_{0.009}$	$0.804_{0.006}$
Pascal07	AP	$0.508_{0.005}$	$0.471_{0.008}$	$0.504_{0.005}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.505_{0.012}$	$0.552_{0.003}$	$0.555_{0.010}$	$0.590_{0.008}$
	1-HL	$0.931_{0.001}$	$0.928_{0.001}$	$0.930_{0.000}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.929_{0.001}$	$0.933_{0.007}$	$0.931_{0.001}$	$0.935_{0.001}$
	1-RL	$0.812_{0.004}$	$0.761_{0.005}$	$0.806_{0.003}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.783_{0.008}$	$0.832_{0.007}$	$0.830_{0.004}$	$0.855_{0.004}$
	AUC	$0.838_{0.003}$	$0.779_{0.004}$	$0.832_{0.002}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.809_{0.006}$	$0.853_{0.003}$	$0.850_{0.005}$	$0.873_{0.004}$
	1-OE	$0.419_{0.008}$	$0.420_{0.011}$	$0.419_{0.008}$	$0.362_{0.023}$	$0.421_{0.006}$	$0.427_{0.015}$	$0.461_{0.007}$	$0.464_{0.018}$	$0.500_{0.010}$
	1-Cov	$0.759_{0.003}$	$0.692_{0.004}$	$0.751_{0.003}$	$0.677_{0.015}$	$0.727_{0.002}$	$0.731_{0.006}$	$0.785_{0.009}$	$0.783_{0.006}$	$0.805_{0.004}$
ESPGame	AP	$0.289_{0.003}$	$0.212_{0.002}$	$0.285_{0.003}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.297_{0.002}$	$0.312_{0.004}$	$0.311_{0.004}$	$0.319_{0.004}$
	1-HL	$0.983_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$
	1-RL	$0.832_{0.001}$	$0.781_{0.001}$	$0.829_{0.001}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.832_{0.001}$	$0.847_{0.002}$	$0.849_{0.002}$	$0.857_{0.002}$
	AUC	$0.836_{0.001}$	$0.785_{0.001}$	$0.833_{0.002}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.836_{0.001}$	$0.852_{0.002}$	$0.853_{0.002}$	$0.861_{0.002}$
	1-OE	$0.396_{0.005}$	$0.294_{0.006}$	$0.389_{0.004}$	$0.343_{0.013}$	$0.339_{0.003}$	$0.439_{0.007}$	$0.461_{0.010}$	$0.455_{0.007}$	$0.460_{0.010}$
	1-Cov	$0.574_{0.004}$	$0.488_{0.003}$	$0.567_{0.005}$	$0.548_{0.004}$	$0.571_{0.003}$	$0.593_{0.003}$	$0.628_{0.005}$	$0.628_{0.005}$	$0.647_{0.004}$
IAPRTC12	AP	$0.305_{0.004}$	$0.234_{0.003}$	$0.304_{0.004}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.323_{0.001}$	$0.339_{0.003}$	$0.331_{0.006}$	$0.351_{0.005}$
	1-HL	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$
	1-RL	$0.862_{0.002}$	$0.823_{0.002}$	$0.861_{0.002}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.873_{0.001}$	$0.886_{0.002}$	$0.885_{0.003}$	$0.895_{0.003}$
	AUC	$0.864_{0.002}$	$0.825_{0.001}$	$0.863_{0.001}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.874_{0.000}$	$0.888_{0.004}$	$0.886_{0.002}$	$0.896_{0.002}$
	1-OE	$0.432_{0.008}$	$0.340_{0.006}$	$0.429_{0.009}$	$0.352_{0.008}$	$0.390_{0.005}$	$0.468_{0.002}$	$0.463_{0.002}$	$0.463_{0.009}$	$0.486_{0.008}$
	1-Cov	$0.597_{0.004}$	$0.529_{0.004}$	$0.597_{0.004}$	$0.564_{0.005}$	$0.592_{0.004}$	$0.649_{0.001}$	$0.688_{0.007}$	$0.675_{0.007}$	$0.700_{0.006}$
Mirflickr	AP	$0.570_{0.002}$	$0.514_{0.006}$	$0.553_{0.002}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.589_{0.005}$	$0.611_{0.002}$	$0.614_{0.004}$	$0.633_{0.004}$
	1-HL	$0.886_{0.001}$	$0.878_{0.001}$	$0.885_{0.001}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.002}$	$0.891_{0.001}$	$0.891_{0.001}$	$0.895_{0.001}$
	1-RL	$0.856_{0.001}$	$0.831_{0.003}$	$0.856_{0.001}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.863_{0.004}$	$0.875_{0.001}$	$0.877_{0.002}$	$0.888_{0.002}$
	AUC	$0.846_{0.001}$	$0.828_{0.003}$	$0.844_{0.001}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.849_{0.004}$	$0.862_{0.001}$	$0.860_{0.003}$	$0.874_{0.002}$
	1-OE	$0.631_{0.004}$	$0.510_{0.008}$	$0.607_{0.004}$	$0.511_{0.022}$	$0.585_{0.003}$	$0.637_{0.007}$	$0.662_{0.006}$	$0.662_{0.008}$	$0.683_{0.008}$
	1-Cov	$0.640_{0.001}$	$0.604_{0.005}$	$0.636_{0.001}$	$0.572_{0.013}$	$0.631_{0.002}$	$0.652_{0.007}$	$0.681_{0.003}$	$0.678_{0.003}$	$0.694_{0.003}$

表 1。 九种方法在五个数据集上的实验结果，视图缺失率与标签缺失率均为 50%（右下角数字为标准差）。列标题 Data＝数据集，Metric＝指标；所有数据和标准差按原表保留。译注：上段“所有指标”忠实保留原文表述，表中 ESPGame 的 1-OE 显示 UPDGD-Net 为 0.461、COME 为 0.460，存在原文论述与数值的差异。

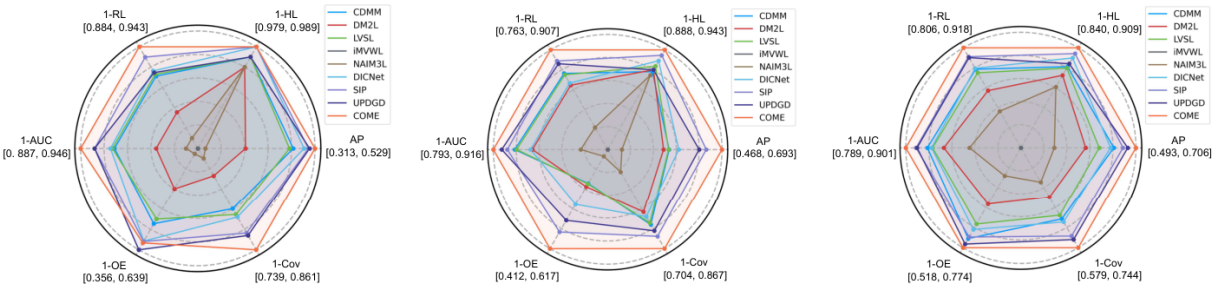
为进一步研究不同视图缺失比例和标签缺失比例对分类性能的影响，我们在 Pascal07 数据集上进行测试，结果见图 4。可以观察到，在相同缺失率下，视图缺失对性能提升的影响比标签缺失更严重。



(a) various missing view rates (b) various missing label rates

图 4。 Pascal07 数据集上四项指标的取值：（a）不同视图缺失率、50% 标签缺失率；（b）50% 视图缺失率、不同标签缺失率。图例中的缺失率依次为 0%、30%、50%、70%；纵轴为四项指标值。

为进一步验证模型适应性，我们在没有任何视图与标签缺失的数据集上进行实验。五个数据集的结果采用雷达图展示，如图 5 所示（其余数据集的更多结果见附录 F）。可以看出，与其他方法（包括为理想完整情形设计的方法）相比，COME 在六项指标上均表现优越。这表明模型具有出色的泛化能力。



(a) Corel5k (b) Pascal07 (c) Mirflickr

图 5。 九种方法在完整 Corel5k、Pascal07 和 Mirflickr 数据集上的实验结果。图中采用六项评价指标，最差结果位于中心，最好结果对应各顶点。图中 AUC 轴沿用原图标注“1-AUC”，未擅自改写。

4.3. 共享信息压缩与信息重建

众所周知，对比学习是一种典型的信息压缩策略，而我们提出的基于 MoE 的互信息增强策略强调保持有效共享信息。即学得的共享信息应仍与原始数据相关，避免信息坍塌。本节通过改变参数 β，研究 $L_{RE1} + L_{RE2}$ 与 L_{CTR} 之间的平衡关系。如图 6 所示，对于 Corel5k 与 Pascal07，β 分别为 0.1 和 1 时，信息压缩与有效信息重建达到平衡，模型取得最优性能。如果继续增大 β，AP 会急剧下降，表明对比学习引起的过度信息压缩，使模型难以为下游预测学习有意义的信息。

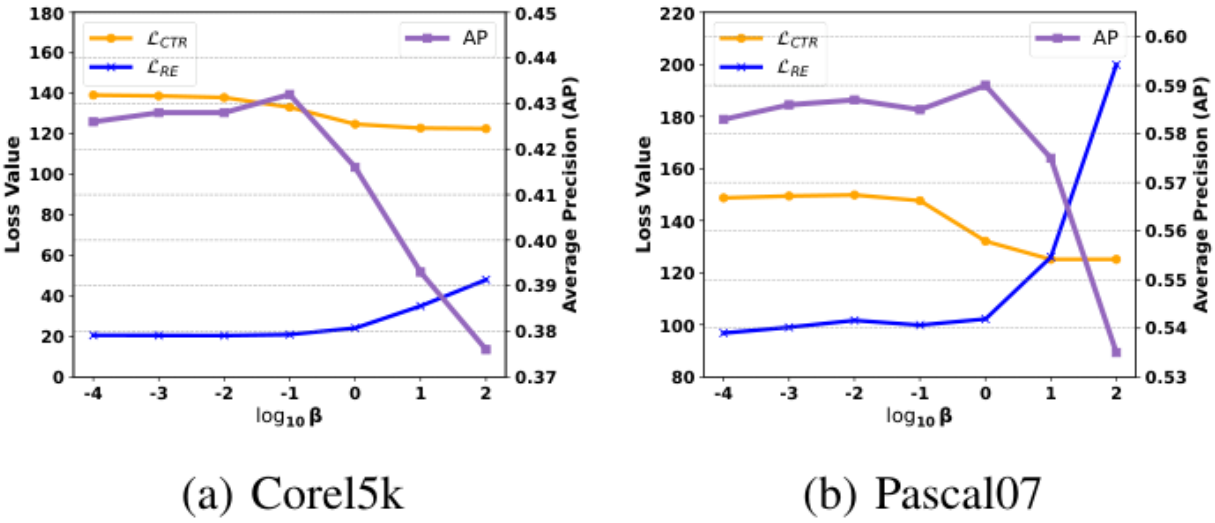


图 6。 信息平衡研究：视图和标签缺失率均为 50% 时，Corel5k、Pascal07 上的 AP 和损失随 β 的变化。横轴为 $\log_{10}\beta$，左纵轴为损失值，右纵轴为平均精度 AP；曲线对应对比损失、重建损失和 AP。

4.4. 消融研究

消融实验在 Corel5k 与 Pascal07 数据集上进行，视图缺失率和标签缺失率均为 50%。目标函数包含两部分：最小充分共享表示学习损失 L_{MSR} 和分类损失 L_{CE}。接下来分解损失，并从三个角度进行消融：考察视图内互信息增强、多视图互信息增强和伪标签的作用。三部分对应损失分别为 L_{RE1}、L_{RE2} 和 L_{CE}。需要指出，不使用伪标签时，模型的监督信息来自原本未缺失的标签。结果见表 2；可以看出 COME 的每个组件都至关重要，均作出积极贡献。尤其是多视图互信息增强模块，对性能提升起着关键作用。

Backbone	$\mathcal{L}_{RE1}$	$\mathcal{L}_{RE2}$	$\mathcal{L}_{CE}$	Corel5k		Pascal07	
				AP	AUC	AP	AUC
✓				0.390	0.883	0.535	0.846
✓	✓			0.399	0.908	0.581	0.868
✓		✓		0.402	0.910	0.562	0.862
✓			✓	0.390	0.903	0.538	0.847
✓	✓	✓		0.427	0.918	0.586	0.872
✓	✓		✓	0.406	0.912	0.584	0.871
✓		✓	✓	0.404	0.910	0.565	0.863
✓	✓	✓	✓	0.432	0.919	0.590	0.873

表 2。 Corel5k 和 Pascal07 数据集上的消融结果。所有数据集均采用 50% 视图缺失、50% 标签缺失和 70% 训练样本。Backbone＝骨干模型，勾号表示启用对应部分；评价指标为 AP 和 AUC。

5. 结论

本文假设各视图共享的一致性语义信息足以用于下游任务。在此基础上，为 iM3C 任务提出名为 COME 的紧凑语义学习框架。研究动机包括两部分：紧凑共享表示学习与软伪标签生成。一方面，通过最大化原始数据与跨视图联合表示之间的互信息，缓解对比学习处理不完整数据的局限，力求学习紧凑的共享表示。另一方面，提出双分支软伪标签交叉填补策略，减轻监督信息缺失的影响。最后，通过大量实验验证了方法的有效性及强大泛化能力。

致谢

本研究部分由深圳市科技计划项目（编号 JCYJ20240813105135047）、广东省基础与应用基础研究基金（编号 2024A1515030213）和国家自然科学基金（编号 62372136）资助。

影响声明

本文介绍的工作旨在推动机器学习领域的发展。我们的工作可能产生多种社会影响，但我们认为没有需要在此特别强调的事项。

参考文献

以下完整保留原文英文参考文献，仅合并换行与断词。

Ameer, I., Sidorov, G., Gomez-Adorno, H., and Nawab, R. M. A. Multi-label emotion classification on code-mixed text: Data and methods. IEEE Access, 10:8779–8789, 2022.

Berthelot, D., Carlini, N., Goodfellow, I., Papernot, N., Oliver, A., and Raffel, C. A. Mixmatch: A holistic approach to semi-supervised learning. Advances in neural information processing systems, 32, 2019.

Chen, T., Kornblith, S., Norouzi, M., and Hinton, G. A simple framework for contrastive learning of visual representations. In International conference on machine learning, pp. 1597–1607. PMLR, 2020.

Chen, Z.-M., Wei, X.-S., Wang, P., and Guo, Y. Multi-label image recognition with graph convolutional networks. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 5177–5186, 2019.

Devlin, J. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.

Duygulu, P., Barnard, K., de Freitas, J. F., and Forsyth, D. A. Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary. In Computer Vision—ECCV 2002: 7th European Conference on Computer Vision Copenhagen, Denmark, May 28–31, 2002 Proceedings, Part IV 7, pp. 97–112. Springer, 2002.

Everingham, M., Van Gool, L., Williams, C. K., Winn, J., and Zisserman, A. The pascal visual object classes (voc) challenge. International journal of computer vision, 88: 303–338, 2010.

Fallah, H., Bruno, E., Bellot, P., and Murisasco, E. Exploiting label dependencies for multi-label document classification using transformers. In Proceedings of the ACM Symposium on Document Engineering 2023, pp. 1–4, 2023.

Fang, C., Sandino, C., Mahasseni, B., Minxha, J., Pouransari, H., Azemi, E., Moin, A., and Zippi, E. Promoting cross-modal representations to improve multimodal foundation models for physiological signals. arXiv preprint arXiv:2410.16424, 2024.

Fang, X., Liu, D., Zhou, P., and Hu, Y. Multi-modal cross-domain alignment network for video moment retrieval. IEEE Transactions on Multimedia, 25:7517–7532, 2022.

Fang, X., Liu, D., Zhou, P., Xu, Z., and Li, R. Hierarchical local-global transformer for temporal sentence grounding. IEEE Transactions on Multimedia, 26:3263–3277, 2023.

Fang, X., Easwaran, A., Genest, B., and Suganthan, P. N. Your data is not perfect: Towards cross-domain out-of-distribution detection in class-imbalanced data. Expert Systems with Applications, 267:126031, 2025.

Federici, M., Dutta, A., Forré, P., Kushman, N., and Akata, Z. Learning robust representations via multi-view information bottleneck. arXiv preprint arXiv:2002.07017, 2020.

Gidaris, S., Singh, P., and Komodakis, N. Unsupervised representation learning by predicting image rotations. arXiv preprint arXiv:1803.07728, 2018.

Grubinger, M., Clough, P., Müller, H., and Deselaers, T. The iapr tc-12 benchmark: A new evaluation resource for visual information systems. In International workshop ontoImage, volume 2, 2006.

Huiskes, M. J. and Lew, M. S. The mir flickr retrieval evaluation. In Proceedings of the 1st ACM international conference on Multimedia information retrieval, pp. 39– 43, 2008.

Hwang, H., Kim, G.-H., Hong, S., and Kim, K.-E. Multiview representation learning via total correlation objective. Advances in Neural Information Processing Systems, 34:12194–12207, 2021.

Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., and Krishnan, D. Supervised contrastive learning. Advances in neural information processing systems, 33:18661–18673, 2020.

Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), Proceedings of the 17th International Conference on Machine Learning (ICML 2000), pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.

Lee, D.-H. et al. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In Workshop on challenges in representation learning, ICML, volume 3, pp. 896. Atlanta, 2013.

Li, X. and Chen, S. A concise yet effective model for nonaligned incomplete multi-view and missing multi-label learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918–5932, 2021.

Lin, Y., Dou, X., Luo, X., Wu, Z., Liu, C., Luo, T., Wen, J., Ling, B. W.-k., Xu, Y., and Wang, W. Multi-view diabetic retinopathy grading via cross-view spatial alignment and adaptive vessel reinforcing. Pattern Recognition, 164: 111487, 2025.

Liu, C., Wen, J., Luo, X., Huang, C., Wu, Z., and Xu, Y. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. In Proceedings of the AAAI conference on artificial intelligence, volume 37, pp. 8807–8815, 2023.

Liu, C., Xu, G., Wen, J., Liu, Y., Huang, C., and Xu, Y. Partial multi-view multi-label classification via semantic invariance learning and prototype modeling. In Forty-first International Conference on Machine Learning, 2024.

Luo, X., Liu, C., Wong, W., Wen, J., Jin, X., and Xu, Y. Mvcinn: multi-view diabetic retinopathy detection using a deep cross-interaction neural network. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8993–9001, 2023.

Ma, Z. and Chen, S. Expand globally, shrink locally: Discriminant multi-label learning with missing labels. Pattern Recognition, 111:107675, 2021.

Pan, E. and Kang, Z. Multi-view contrastive graph clustering. Advances in neural information processing systems, 34:2148–2159, 2021.

Qiu, S., Miller, M. I., Joshi, P. S., Lee, J. C., Xue, C., Ni, Y., Wang, Y., De Anda-Duran, I., Hwang, P. H., Cramer, J. A., et al. Multimodal deep learning for alzheimer’ s disease dementia assessment. Nature communications, 13(1):3404, 2022.

Shi, Y., Paige, B., Torr, P., et al. Variational mixture-of-experts autoencoders for multi-modal deep generative models. Advances in neural information processing systems, 32, 2019.

Sohn, K., Berthelot, D., Carlini, N., Zhang, Z., Zhang, H., Raffel, C. A., Cubuk, E. D., Kurakin, A., and Li, C.-L. Fixmatch: Simplifying semi-supervised learning with consistency and confidence. Advances in neural information processing systems, 33:596–608, 2020.

Soleymani, M., Garcia, D., Jou, B., Schuller, B., Chang, S.-F., and Pantic, M. A survey of multimodal sentiment analysis. Image and Vision Computing, 65:3–14, 2017.

Tan, Q., Yu, G., Domeniconi, C., Wang, J., and Zhang, Z. Incomplete multi-view weak-label learning. In Ijcai, pp. 2703–2709, 2018.

Thomas, M. and Joy, A. T. Elements of information theory. Wiley-Interscience, 2006.

Tian, Y., Krishnan, D., and Isola, P. Contrastive multiview coding. In Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16, pp. 776–794. Springer, 2020.

Tsai, Y.-H. H., Wu, Y., Salakhutdinov, R., and Morency, L.-P. Self-supervised learning from a multi-view perspective. arXiv preprint arXiv:2006.05576, 2020.

Von Ahn, L. and Dabbish, L. Labeling images with a computer game. In Proceedings of the SIGCHI conference on Human factors in computing systems, pp. 319–326, 2004.

Wang, H., Guo, X., Deng, Z.-H., and Lu, Y. Rethinking minimal sufficient representation in contrastive learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 16041–16050, 2022.

Wen, J., Zhang, Z., Zhang, Z., Wu, Z., Fei, L., Xu, Y., and Zhang, B. Dimc-net: Deep incomplete multi-view clustering network. In Proceedings of the 28th ACM international conference on multimedia, pp. 3753–3761, 2020.

Wen, L., Nie, M., Chen, P., Zhao, Y.-n., Shen, J., Wang, C., Xiong, Y., Yin, K., and Sun, L. Wearable multimode sensor with a seamless integrated structure for recognition of different joint motion states with the assistance of a deep learning algorithm. Microsystems & nanoengineering, 8 (1):24, 2022.

Wu, X., Chen, Q.-G., Hu, Y., Wang, D., Chang, X., Wang, X., and Zhang, M.-L. Multi-view multi-label learning with view-specific information extraction. In IJCAI, pp. 3884–3890, 2019.

Xiao, J.-H., Xie, M.-K., Fan, H.-B., Niu, G., Sugiyama, M., and Huang, S.-J. Dual-decoupling learning and metric-adaptive thresholding for semi-supervised multi-label learning. arXiv preprint arXiv:2407.18624, 2024.

Xie, M.-K., Xiao, J., Liu, H.-Z., Niu, G., Sugiyama, M., and Huang, S.-J. Class-distribution-aware pseudo-labeling for semi-supervised multi-label learning. Advances in Neural Information Processing Systems, 36, 2024a.

Xie, W., Lu, X., Liu, Y., Long, J., Zhang, B., Zhao, S., and Wen, J. Uncertainty-aware pseudo-labeling and dual graph driven network for incomplete multi-view multilabel classification. In Proceedings of the 32nd ACM International Conference on Multimedia, pp. 6656–6665, 2024b.

Xu, Y., Shang, L., Ye, J., Qian, Q., Li, Y.-F., Sun, B., Li, H., and Jin, R. Dash: Semi-supervised learning with dynamic thresholding. In International conference on machine learning, pp. 11525–11536. PMLR, 2021.

Yang, W., Zhang, R., Chen, J., Wang, L., and Kim, J. Prototype-guided pseudo labeling for semi-supervised text classification. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 16369–16382, 2023a.

Yang, Z., Xu, Q., Bao, S., Cao, X., and Huang, Q. Learning with multiclass auc: Theory and algorithms. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44 (11):7747–7763, 2021.

Yang, Z., Xu, Q., Bao, S., He, Y., Cao, X., and Huang, Q. Optimizing two-way partial auc with an end-to-end framework. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(8):10228–10246, 2023b. doi: 10.1109/TPAMI.2022.3185311.

Zeng, P., Yang, M., Lu, Y., Zhang, C., Hu, P., and Peng, X. Semantic invariant multi-view clustering with fully incomplete information. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023.

Zhang, C., Liu, Y., and Fu, H. Ae2-nets: Autoencoder in autoencoder networks. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 2577–2585, 2019.

Zhang, D., Ju, X., Zhang, W., Li, J., Li, S., Zhu, Q., and Zhou, G. Multi-modal multi-label emotion recognition with heterogeneous hierarchical message passing. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 35, pp. 14338–14346, 2021.

Zhang, H., Wang, Y., Yin, G., Liu, K., Liu, Y., and Yu, T. Learning language-guided adaptive hyper-modality representation for multimodal sentiment analysis. arXiv preprint arXiv:2310.05804, 2023.

Zhang, Y., Wu, J., Cai, Z., and Philip, S. Y. Multi-view multilabel learning with sparse feature selection for image annotation. IEEE Transactions on Multimedia, 22(11): 2844–2857, 2020.

Zhao, D., Gao, Q., Lu, Y., Sun, D., and Cheng, Y. Consistency and diversity neural network multi-view multi-label learning. Knowledge-Based Systems, 218:106841, 2021.

Zhao, D., Gao, Q., Lu, Y., and Sun, D. Non-aligned multiview multi-label classification via learning view-specific labels. IEEE Transactions on Multimedia, 25:7235–7247, 2022.

Zhou, Z.-H., Zhang, M.-L., Huang, S.-J., and Li, Y.-F. Multiinstance multi-label learning. Artificial Intelligence, 176 (1):2291–2320, 2012.

附录 A. 共享表示学习的完整推导

根据第 3.2 节的分析，我们提出最大化原始数据与联合表示之间的互信息：

$$\max I(\mathbf{X}^{\mathcal{V}};\mathbf{z}) \tag{14}$$

对于式（14）中的互信息 $I(X^V; z)$，可得到如下变分下界：

$$\begin{aligned}
&I(\mathbf{X}^{\mathcal{V}};\mathbf{z})\\
&=\int\int p(\mathbf{X}^{\mathcal{V}},\mathbf{z})\log\frac{p(\mathbf{X}^{\mathcal{V}}|\mathbf{z})}{p(\mathbf{X}^{\mathcal{V}})}d\mathbf{X}^{\mathcal{V}}d\mathbf{z}\\
&\geq\int p(\mathbf{X}^{\mathcal{V}})\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log p(\mathbf{X}^{\mathcal{V}}|\mathbf{z})d\mathbf{X}^{\mathcal{V}}d\mathbf{z}\\
&=\int p(\mathbf{X}^{\mathcal{V}})\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z})d\mathbf{X}^{\mathcal{V}}d\mathbf{z}+\\
&\quad\int p(\mathbf{X}^{\mathcal{V}})\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log\frac{p(\mathbf{X}^{\mathcal{V}}|\mathbf{z})}{q(\mathbf{X}^{\mathcal{V}}|\mathbf{z})}d\mathbf{X}^{\mathcal{V}}d\mathbf{z}\\
&\geq\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}})\log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z})d\mathbf{z}]
\end{aligned} \tag{15}$$

类似于以往工作（Shi et al., 2019），我们将联合变分后验分解为单模态后验的组合，使用混合专家（MoE）建模 $p(z \mid X^V)$，因此有：

$$p(\mathbf{z}|\mathbf{X}^{\mathcal{V}}) = \sum_{v\in\mathcal{V}} \frac{1}{|\mathcal{V}|} p(\mathbf{z}^{(v)}|\mathbf{x}^{(v)}) \tag{16}$$

结合式（16），可将式（15）的变分下界改写如下：

$$\begin{aligned}
&\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}}) \log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z}) d\mathbf{z}] \\
=&\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}}) \log \prod_{v\in\mathcal{V}} q(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{z}] \\
=&\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int (\sum_{v\in\mathcal{V}} \frac{1}{|\mathcal{V}|} p(\mathbf{z}^{(v)}|\mathbf{x}^{(v)})) \log \prod_{v\in\mathcal{V}} q(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{z}] \\
=&\frac{1}{|\mathcal{V}|} \sum_{v\in\mathcal{V}} \mathbb{E}_{\mathbf{x}^{(v)}\sim p(\mathbf{x}^{(v)})}[\int p(\mathbf{z}|\mathbf{x}^{(v)}) \log q(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{z}] \\
+&\frac{1}{|\mathcal{V}|} \sum_{v\in\mathcal{V}} \sum_{u\in\mathcal{V}, u\neq v} \mathbb{E}_{\mathbf{x}^{(v)}\sim p(\mathbf{x}^{(v)})}[\int p(\mathbf{z}|\mathbf{x}^{(v)}) \log q(\mathbf{x}^{(u)}|\mathbf{z}) d\mathbf{z}]
\end{aligned} \tag{17}$$

为更清楚起见，后续推导以两个视图为例。联合后验概率为 $p(z \mid \{x^{(1)}, x^{(2)}\})$，变分下界可改写如下：

$$\begin{aligned}
&\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{X}^{\mathcal{V}}) \log q(\mathbf{X}^{\mathcal{V}}|\mathbf{z}) d\mathbf{z}] \\
&= \frac{1}{2}\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int (p(\mathbf{z}|\mathbf{x}^{(1)}) + (p(\mathbf{z}|\mathbf{x}^{(2)})) \log q(\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}\}|\mathbf{z}) d\mathbf{z}] \\
&= \frac{1}{2}\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int (p(\mathbf{z}|\mathbf{x}^{(1)}) + (p(\mathbf{z}|\mathbf{x}^{(2)})) \log [q(\mathbf{x}^{(1)}|\mathbf{z}) q(\mathbf{x}^{(2)}|\mathbf{z})] d\mathbf{z}] \\
&= \frac{1}{2}\mathbb{E}_{\mathbf{X}^{\mathcal{V}}\sim p(\mathbf{X}^{\mathcal{V}})}[\int p(\mathbf{z}|\mathbf{x}^{(1)}) \log q(\mathbf{x}^{(1)}|\mathbf{z}) d\mathbf{z} + \int p(\mathbf{z}|\mathbf{x}^{(1)}) \log q(\mathbf{x}^{(2)}|\mathbf{z}) d\mathbf{z} \\
&\quad + \int p(\mathbf{z}|\mathbf{x}^{(2)}) \log q(\mathbf{x}^{(1)}|\mathbf{z}) d\mathbf{z} + \int p(\mathbf{z}|\mathbf{x}^{(2)}) \log q(\mathbf{x}^{(2)}|\mathbf{z}) d\mathbf{z}]
\end{aligned} \tag{18}$$

附录 B. 五个数据集的统计信息与数据掩码方案

本节给出实验中使用的五个数据集的详细信息，汇总于表 3。为模拟现实中的视图缺失和部分标签情形，按照以下步骤生成不完整多视图部分多标签数据：（1）视图缺失：每个视图随机掩蔽 50% 样本，同时确保每个样本至少保留一个可用视图。（2）标签缺失：每个类别随机移除 50% 的正标签和负标签。（3）数据集划分：随后从生成的样本中随机选取 70% 作为训练集。

Dataset	# Sample	# Label	# View	# Label/#Sample
Corel5k	4999	260	6	3.40
IAPRTC12	19627	291	6	5.72
ESPGame	20770	268	6	4.69
Pascal07	9963	20	6	1.47
Mirflickr	25000	38	6	4.72

表 3。 实验所用五个多视图多标签数据集的详细信息。各列依次为：数据集、样本数、标签数、视图数、标签数/样本数。Corel5k：4999、260、6、3.40；IAPRTC12：19627、291、6、5.72；ESPGame：20770、268、6、4.69；Pascal07：9963、20、6、1.47；Mirflickr：25000、38、6、4.72。

附录 C. 八种比较方法的统计信息

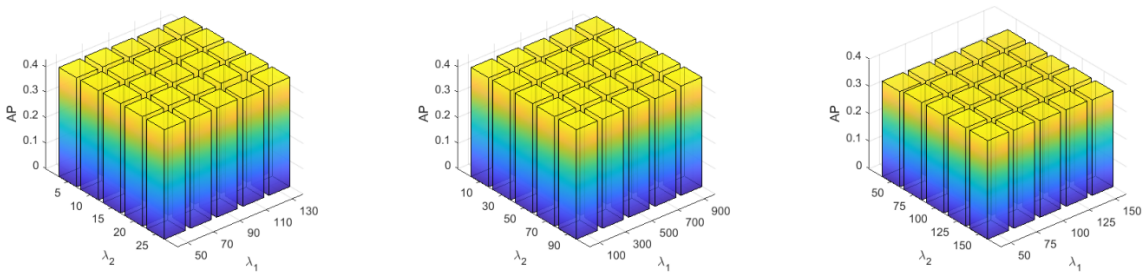
本节给出八种比较方法的详细信息，汇总于表 4。具体地，DM2L 只能处理单视图部分多标签情况，因此记录每个视图的结果并选择最优结果。CDMM 和 LVSL 无法处理视图缺失，因此使用对应视图可用实例的均值填补缺失实例。其余五种方法均可同时处理不完整视图与部分标签。

Method	Sources	Multi-view	Incomplete-view	Missing-label
CDMM	KBS'20	✓	×	×
DM2L	PR'21	×	×	✓
LVSL	TMM'22	✓	×	×
iMVWL	IJCAI'18	✓	✓	✓
NAIM3L	TPAMI'21	✓	✓	✓
DICNet	AAAI'23	✓	✓	✓
UPDGD-Net	ACM MM'24	✓	✓	✓
SIP	ICML'24	✓	✓	✓

表 4。 比较方法的简要汇总及其能力：“Multi-view（多视图）”与“Incomplete-view（不完整视图）”分别表示方法能否处理多视图和不完整多视图情形；“Missing-label（缺失标签）”表示能否处理不完整多标签分类任务。Method＝方法，Sources＝发表来源；勾号表示支持，叉号表示不支持。原表 CDMM 来源为 KBS’20（正文文献年份为 2021），保留原表。

附录 D. 超参数敏感性研究

我们讨论通过两种方式提升所学习表示的性能：增加模态内互信息和模态间互信息。此外，采用两个权衡系数 λ_1 和 λ_2 保持平衡。在不同数据集上，采用 50% 视图缺失、50% 标签缺失和 70% 训练样本，研究这两个超参数的敏感性。如图 7 所示，实验表明，改变 λ_1 和 λ_2 的取值并不会显著影响模型性能，凸显了模型内在的鲁棒性。

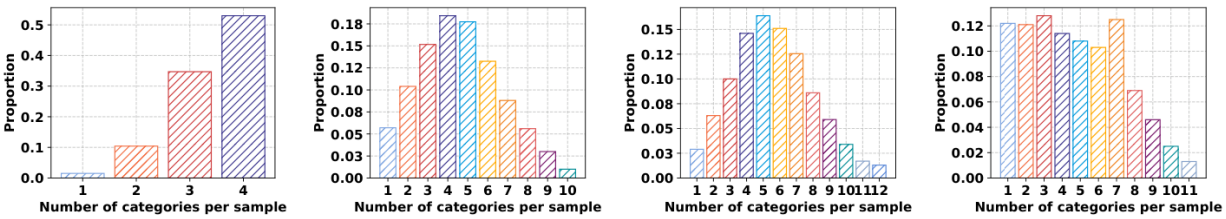


(a) Corel5k (b) Pascal07 (c) IAPRTC12

图 7。 Corel5k 和 Pascal07 数据集上关于 λ_1 与 λ_2 的超参数分析；所有数据集的视图和标签缺失率均设为 50%。译注：原图还包含（c）IAPRTC12，原图注只列出前两者，此处全部保留。

附录 E. 其他数据集的样本标签数量分布

本节展示其他数据集的标签数量分布信息。这进一步表明，每个样本对应的标签数量并不固定，使得 Top-1 或 Top-k 伪标签生成策略难以直接应用。

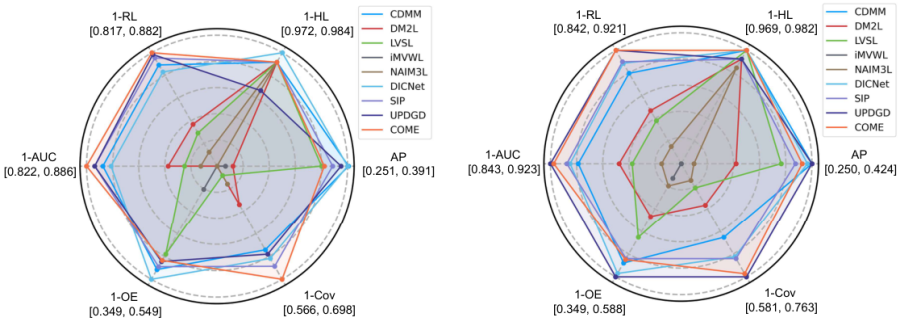


(a) Corel5k (b) ESPGame (c) IAPRTC12 (d) Mirflickr

图 8。 其他四个数据集的样本标签数量分布：（a）Corel5k，（b）ESPGame，（c）IAPRTC12，（d）Mirflickr。横轴为每个样本的类别数，纵轴为比例。

附录 F. 五个完整数据集上的额外实验结果

本节以雷达图的形式给出九种方法在四个不存在任何视图或标签缺失的数据集上的六项指标值，如图 9 所示。



(a) ESPGame　　(b) IAPRTC12

图 9。 其余两个数据集在不存在任何视图或标签缺失时的实验结果：（a）ESPGame，（b）IAPRTC12。按六项评价指标绘制，雷达图中心表示最差结果，顶点表示最好结果。译注：本附录标题的“五个”、正文的“四个”及图注的“两个”均忠实保留原文，图 5 与图 9 合计展示五个数据集。