面向不完整多视图噪声标签学习的带噪声过滤动态多重高阶相关性融合

Dynamic Multiple High-order Correlations Fusion with Noise Filtering for Incomplete Multi-view Noisy-label Learning

Kaixiang Wang*，Xiaojian Ding，Fan Yang
南京财经大学
kxwang@nufe.edu.cn，wjswsl@163.com，nufe_yf@163.com
*通讯作者。

第三十四届国际人工智能联合会议论文集（IJCAI-25），原文第 6316–6324 页。

非官方中文全文译文 · 仅供用户私人阅读

本译文仅依据用户上传的 9 页 PDF 制作，原始文件及来源记录随附。原作者与出版方的权利不变；不声称已获得公开再分发许可。原图、表及公式保留原始内容，图表内英文另附完整中文对照。原文没有独立算法框或附录，不补写未提供的内容。原文中公式及表述的不一致处保留，并在文末作译注。

摘要

多视图多标签数据往往存在特征视图不完整和标签噪声。本文首次同时处理这两项挑战，弥补现有方法的关键缺陷：这些方法对跨视图高阶结构相关性的提取与融合不充分，同时缺乏缓解标签噪声的稳健解决方案。我们提出一种带噪声过滤的动态多重高阶相关性融合方法，专门用于不完整多视图噪声标签学习。受集成学习原理启发，我们利用动态多超图神经网络，有效捕获并整合来自不同视图的样本之间的高阶相关性。基于随机游走理论的创新超图融合技术进一步增强了模型能力，使其能够无缝融合结构信息与特征信息。此外，我们提出紧密嵌入超图神经网络的精细噪声过滤矩阵，以抵消标签噪声的不利影响。考虑到标签噪声会扰乱标签空间中的数据分布，这些过滤矩阵利用特征空间与标签空间之间的分布差异。来自这两个空间的高阶结构信息支撑了噪声过滤矩阵的学习及其有效性。在基准数据集上的实证评估明确表明，我们的方法显著优于当前的先进技术。

1 引言

随着数据模态日益多样，多视图与多标签问题变得越来越突出。例如，社交网络平台中的用户可以通过图像、文本和音频等模态表征，并可能与“交响乐”“贝多芬”“钢琴”和“古典乐派”等多个标签关联。准确分类此类多视图多标签数据，对于全面的数据分析至关重要 [Qian et al., 2014; Zhu et al., 2015]。

研究多视图多标签学习，比单独处理多视图 [Wang et al., 2022] 或多标签 [Liu et al., 2021] 数据更为复杂，因为它需要同时考虑不同数据视图之间的相关性以及多个标签之间错综复杂的依赖关系。面对这种复杂性，研究者越来越关注不完整多视图多标签学习，因为真实世界应用中的数据，在特征表示和标

签标注两方面经常都不完整 [Tan et al., 2018; Li and Chen, 2021; Li et al., 2024; Ou et al., 2024; Liu et al., 2023; Liu et al., 2024]。因此，这一学习框架已成为特别适合解决真实世界实际挑战的框架。

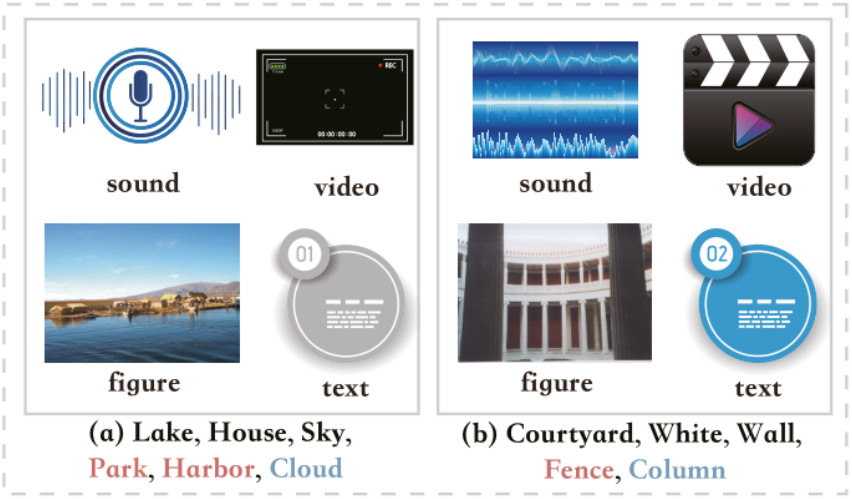


图 1. 含缺失标签和噪声标签的多视图多标签数据集：(a) 模糊对象被随机错标；(b) 相似对象彼此错标。

图内文字对照：sound＝声音；video＝视频；figure＝图像；text＝文本。(a) Lake＝湖泊，House＝房屋，Sky＝天空，Park＝公园，Harbor＝港口，Cloud＝云；(b) Courtyard＝庭院，White＝白色，Wall＝墙，Fence＝围栏，Column＝柱子。颜色及图像中的错误标记均按原图保留。

尽管多视图多标签学习已有显著进展，一个关键问题却经常被忽视：标签噪声。在当今数据驱动的世界中，数据采集、存储和标注错误很常见，尤其对于众包多视图数据，人工失误会引入错误标签，从而产生标签噪声。随着数据集规模扩大，标签噪声的影响更加严重（图 1）。这种噪声通常有两个来源：(1) 模糊对象导致随机错标，例如漏标“云”却错误标注“港口”；(2) 相似对象之间发生混淆，例如把“柱子”误认为“围栏”。标签噪声与标签缺失同时存在，带来了更大挑战。

为应对这些挑战，不完整多视图噪声标签学习成为一种新的学习范式，用于处理真实世界大规模多视图多标签数据中的复杂性，这类数据普遍具有不完整视图和错误标注。为解决这些问题，本文提出新方法：面向不完整多视图噪声标签学习的带噪声过滤动态多重高阶相关性融合（DMHNF）。所提模型解决两项关键挑战：(1) 多个视图之间的结构差异与相关性；(2) 严重妨碍学习性能的标签噪声的检测与缓解。

一方面，在处理跨视图结构相关性差异时，多数现有研究强调融合不同视图中样本的特征与二阶相关性，例如图结构 [Hamilton et al., 2017; Veličković et al., 2017; Defferrard et al., 2016]。然而，对跨视图样本间高阶相关性的探索与整合关注有限。高阶相关性 [Gao et al., 2020] 刻画了每个视图独有的分布特征，当某些视图不完整时尤其重要。在这种情况下，其余视图中的高阶相关性可以提供关键信息，以弥补缺失数据。

另一方面，对于检测和缓解标签噪声的挑战，当前多数多标签学习方法主要利用标签相关性填补缺失标签。但是，这些方法常常没有利用样本间高阶相关性来辅助纠正标签噪声。我们的方法通过在超图网络中引入噪声校正矩阵来弥补这一缺口，从而动态调整和纠正噪声标签。利用特征空间中的高阶相关性，也能细化标签空间，从分布角度实现标签噪声校正。这些整合策略使所提方法兼具高准确性与稳健性。本研究的主要贡献如下。

1. 我们引入不完整多视图噪声标签学习范式，同时处理视图不完整和标签噪声问题。该范式非常适合大规模数据，其中多视图描述往往不完整，标注也经常存在错误。

2. 我们提出一种新的动态多超图融合网络，通过同时融合高阶结构信息和特征信息来增强多视图数据整合。这两类信息被并行利用，相互促进。

3. 我们的方法通过动态超图促进特征空间与标签空间之间的信息交流，利用特征空间中的高阶相关性纠正标签噪声。通过将噪声过滤矩阵与超图神经网络相结合，我们从分布角度减轻标签噪声的不利影响。

2 相关工作

多视图多标签数据在现代数据集中日益常见，但随着数据量增长，保证完整性和标签准确性仍然具有挑战。这使不完整多视图弱标签学习成为机器学习研究的一个重点领域。Tan 等人的 iMVWL 模型开创了这一领域 [Tan et al., 2018]；该模型联合优化不完整视图的共享子空间与弱标签分类器，同时学习局部标签相关性。这一方法处理视图缺失与标签不完整的双重挑战，为后续研究奠定基础。在这些认识的基础上，Li 等人提出了 NAIM3L [Li and Chen, 2021]，一个简洁而有力的模型，用于处理非对齐不完整多视图多标签学习。它利用多视图共识，发掘全局和局部标签结构，通过对齐不同视图中的各个标签，更有效地处理非对齐数据。

鉴于深度学习在该领域的影响，Liu 等人提出 DICNet [Liu et al., 2023]，这是一种面向双重不完整多视图多标签分类的深度实例级对比网络。该模型使用自编码器进行端到端特征提取，并采用对比学习策略，结合多视图加权融合模块，提高分类准确率。最后，Liu 等人提出基于语义不变性和原型建模的方法 SIP [Liu et al., 2024]。该方法运用信息瓶颈理论压缩跨视图表示，以最大化共享信息，从而提高标签预测准确率，同时在潜在空间中对多标签原型建模。尽管取得这些进展，在处理不完整多视图多标签数据中的标签噪声时，仍然存在显著复杂性，表明这一快速发展的研究领域需要进一步创新。

为应对标签噪声与标签缺失共存的复杂情形，已经出现多种方法 [Cui et al., 2020; Zhang et al., 2019; Xie and Huang, 2022]。Chen 等人提出广义噪声多标签分类方法 [Chen et al., 2024]，利用标签嵌入网络捕获特征空间与标签空间之间的复杂相关性。这一创新方法依据标签相关性对噪声预测实施正则化，在标签噪声与标签缺失共存的场景中获得良好结果。由上述分析可见，当标签噪声和标签缺失同时存在时，多视图多标签学习的复杂性会显著增加。因此，模型必须能够整合不同视图中的不完整表示，同时有效处理标签噪声与缺失标签。动态超图网络 [Jiang et al., 2019; Fu et al., 2022; Zhou et al., 2023] 适于发现和利用本文所提出问题中的复杂高阶相关性。本文设计动态多超图神经网络，并辅以标签过滤矩阵，利用样本之间的高阶相关性，有效解决这些关键问题，从而应对这一多方面挑战。

3 所提方法

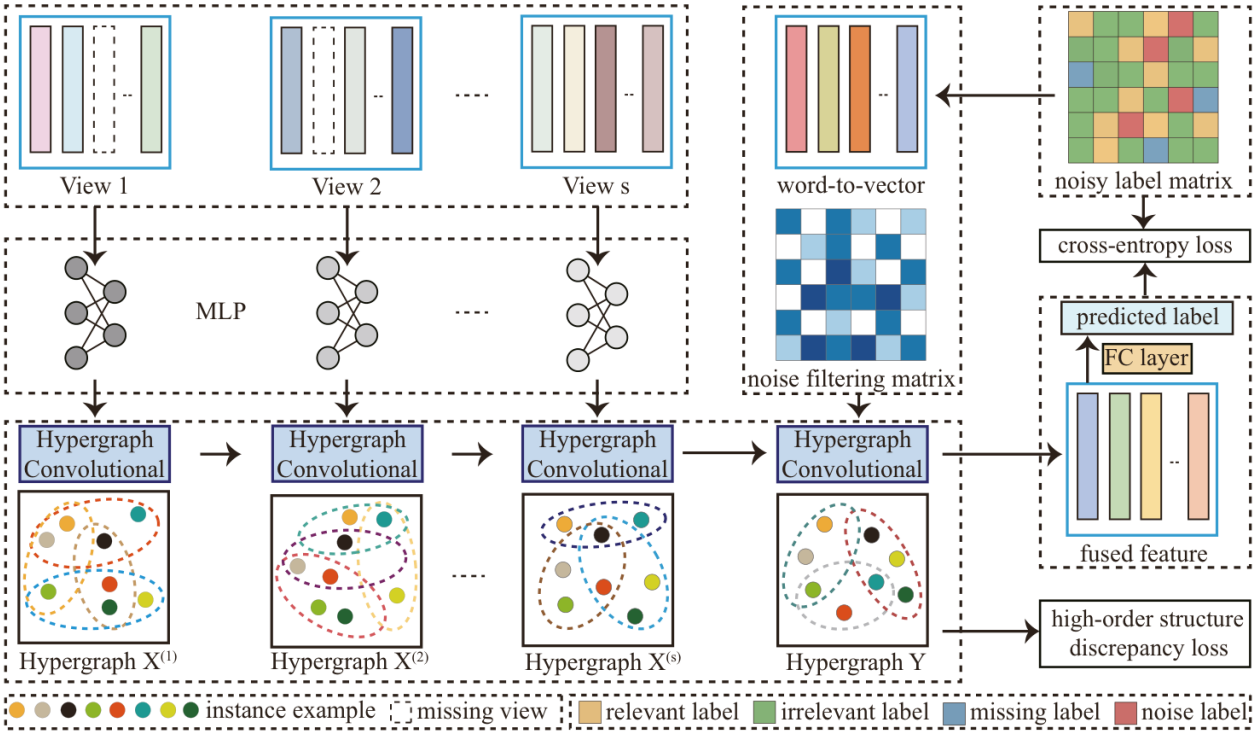


图 2. 所提面向不完整多视图噪声标签学习的带噪声过滤动态多重高阶相关性融合框架，包含两个主要模块：动态多超图神经网络与混合噪声过滤。

图内文字对照：View 1 / View 2 / View s＝视图 1 / 视图 2 / 视图 s；MLP＝多层感知机；Hypergraph Convolutional＝超图卷积；Hypergraph $X^{(1)}$ / $X^{(2)}$ / $X^{(s)}$＝超图 $X^{(1)}$ / $X^{(2)}$ / $X^{(s)}$；word-to-vector＝词向量表示；noise filtering matrix＝噪声过滤矩阵；Hypergraph Y＝超图 Y；noisy label matrix＝噪声标签矩阵；cross-entropy loss＝交叉熵损失；predicted label＝预测标签；FC layer＝全连接层；fused feature＝融合特征；high-order structure discrepancy loss＝高阶结构差异损失；instance example＝实例示例；missing view＝缺失视图；relevant label＝相关标签；irrelevant label＝无关标签；missing label＝缺失标签；noise label＝噪声标签。

数据集记为 $\mathcal{D} = \{\{X^{(q)} \in \mathbb{R}^{m \times d_q}\}_{q=1}^{s}, Y\}$，其中 $X^{(q)} \in \mathbb{R}^{m \times d_q}$ 为第 q 个视图（特征维度为 d_q），$Y \in \{0, 1\}^{m \times n}$ 是标签矩阵，$W \in \{0, 1\}^{m \times s}$ 表示缺失视图，m 和 n 分别表示样本数与标签类别数。目标是学习映射函数 $f : X \to Y$，以准确推断测试实例 $\hat{x}$ 的标签 $\hat{y}$。我们的方法通过两项关键贡献同时处理数据不完整和标签噪声（图 2）。首先，将标签空间视为特殊视图，使用动态多超图神经网络对跨视图高阶相关性建模。该网络有效整合这些相关性，以增强学习。其次，设计两个标签过滤矩阵，细化噪声标签并处理缺失信息。这些矩阵与超图神经网络紧密集成，在利用高阶结构信息的同时缓解标签噪声的不利影响。

3.1 动态多超图神经网络

构建多超图神经网络，首先需要在特征空间与标签空间中构造相应超图。对于特征空间超图，我们采用基于聚类的方法构建超边，进而形成超图。具体而言，对每个视图，依据该视图的数据独立构建一个超图。在这一设置中，每个样本被视为一个顶点，并为每个顶点生成相应的超边 [Zhou et al., 2006]。超

图 $G = (V, E, \omega)$ 由顶点 V、超边 E 和权重 $\omega(e)$ 组成。它由关联矩阵 H 表示，其中当且仅当 $v \in e$ 时，$h(v, e) = 1$。基于 H 计算顶点度 $d(v)$ 与超边度 $\delta(e)$，从而在 G 上进行随机游走，并以有限马尔可夫链对关系建模。按照 [Zhu et al., 2017a] 中的方法，特征空间 $H^{(q)}$ 的超边由下式构建：

$$e_i^{(q)} = \{v_j \mid \theta(x_i, x_j) \geq 0.1\sigma_i^{(q)}\}, \quad i, j = 1, \ldots, m \quad (1)$$

其中 $\theta(x_i, x_j)$ 表示样本 x_i 与 x_j 之间的相似度，$\sigma_i^{(q)}$ 是 x_i 与所有其他样本的平均相似度。对于标签空间超图，我们构建两个超图。在第一个超图中，将标签视为超边，使标签矩阵可以直接表示为超图关联矩阵 $H^l = Y$。在第二个超图中，构建 H^c 以包含标签语义信息，其超边由下式构建：

$$e_i^c = \{v_j \mid \omega(y_i, y_j) \geq 0.1\sigma_i^c\}, \quad i, j = 1, \ldots, m \quad (2)$$

其中 $\omega(y_i, y_j)$ 表示两个标签集合中相应相关标签的词向量表示之间两两距离之和，σ_i^c 是 y_i 与所有其他样本的平均相似度。

这一神经网络主要用于融合数据多个视图的信息，包括数据之间的结构相关性信息和数据的特征信息。因此，融合发生在两个层面：高阶结构信息的融合，以及不同视图特征信息的融合。本研究针对高阶结构信息融合引入动态多超图更新机制。该方法旨在融合先前网络迭代中的超图序列，以生成新超图。需要注意，这里并不依据先前超图序列直接构建新超图，而是先构造新超图的拉普拉斯矩阵，再基于这一拉普拉斯矩阵构建超图神经网络 [Feng et al., 2019]。具体融合过程如下。

我们为每个超图 $(H^{(1)}, \ldots, H^{(s)})$ [Zhou et al., 2006] 关联一个自然随机游走 [Chitra and Raphael, 2019; Carletti et al., 2020]。借助这种关联，可以融合这些超图的转移概率与平稳分布，获得融合超图的拉普拉斯矩阵。令超图 $H^{(1)}$ 与 $H^{(q)}$ 分别表示初始超图结构和第 q 层生成的超图。

令 T 与 Π 分别表示超图随机游走的转移概率矩阵和平稳分布矩阵。T 与 Π 的元素定义如下：

$$t(u, v) = \sum_{e \in E} w(e) \frac{h(u, e)}{d(u)} \frac{h(v, e)}{\delta(e)}, \quad \pi(v) = \frac{d(v)}{vol(V)} \quad (3)$$

$H^{(1)}$ 和 $H^{(q)}$ 的相应矩阵分别记为 T_1, Π_1 和 T_q, Π_q。为进一步阐明融合，多超图割解释如下：

$$\beta_i(u) = \frac{\alpha_i \pi_i(u)}{\sum_{i=1}^{q} \alpha_i \pi_i(u)}, \quad \sum_{i=1}^{q} \alpha_i = 1 \quad (4)$$

$$\alpha_i = (1 - \alpha_1) \frac{cos(\pi_1, \pi_i)}{\sum_{i=1}^{q} cos(\pi_1, \pi_i)}, 2 \leq i \leq q \quad (5)$$

参数 α_i 用于确定融合过程中各超图的相对重要性。平稳分布 π_i 与 π_j 之间的余弦相似度 $\cos\left(\pi_i, \pi_j\right)$ 衡量两个超图的相似程度。特别地，与原始超图更相似的超图被赋予更大的权重，从而改善模型的整体收敛性。

融合后的转移概率与平稳分布定义为：

$$t_q(u,v)=\sum_{i=1}^{q}\beta_i(u)t_i(u,v),\quad \pi_q(v)=\sum_{i=1}^{q}\alpha_i\pi_i(v) \tag{6}$$

值得注意的是，转移概率与平稳分布的构造并不是对各超图作简单线性组合。与超图 $H^{(q)}$ 对应的超图拉普拉斯矩阵记为 $L^{(q)}$。融合超图的拉普拉斯矩阵由下式获得：

$$L^{(q)}=\Pi-\frac{\Pi T+T^{\mathrm{T}}\Pi}{2}=\sum_{i=1}^{q}\alpha_i\Pi_i(I-T_i) \tag{7}$$

随后，按照 [Feng et al., 2019] 的方法，构建超边卷积层 $f(X, W, \Theta)$：

$$Y^{(q)}=\sigma\left((L^{(q)}-I)X^{(q)}\Theta^{q}\right) \tag{8}$$

这里，$X^{(q)}$ 表示第 q 层的超图信号，σ 表示非线性激活函数。得到的 $Y^{(q)}$ 对后续学习起到重要作用。

通过上述步骤，我们已经基于超图完成不同视图之间高阶结构相关性信息的融合。基于上述超图进行多视图信息融合，需要考虑两个关键方面。首先是数据的动态整合，即不断将不同视图的信息引入模型，类似于前述超图融合过程。其次是视图缺失这一挑战，通过利用缺失视图指示矩阵促进数据融合来处理。借助超图相关性与多视图信息，模型有效减轻了缺失视图对性能的不利影响。

这里，$X^{(q)}$ 表示通过卷积神经网络提取的深层特征。基于特征空间信息的超图卷积可表示为：

$$X^{k+1}=\sigma\left((L^{(q)}-I)(W'_{:,q+1}X^{(q+1)})\Theta_f^{k+1}\right)+\alpha_iX^{k} \tag{9}$$

其中 $L^{(q)}$ 是 $\left(H^{(1)}, \ldots, H^{(q-1)}\right)$ 动态融合超图的拉普拉斯矩阵。Θ_f^{k+1} 是网络训练过程中的可学习参数，$\sigma(\cdot)$ 是非线性激活函数。卷积操作后，获得由多视图数据融合的图像特征，这些特征捕获了特征空间中样本的高阶结构信息。

3.2 混合噪声过滤

需要强调的是，我们的方法在数据与模型两个层面都显著不同于传统的不完整多视图多标签方法，关键区别在于标签空间的复杂性。传统的不完整多视图多标签问题只考虑标签空间中的缺失标签，而真实世界应用中，缺失标签与噪声标签往往同时存在（图 3）。

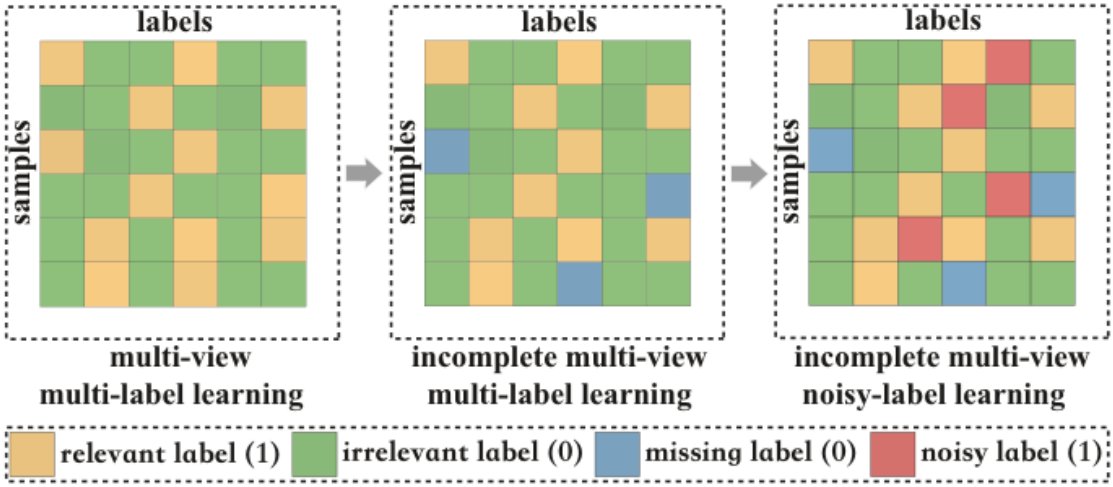


图 3. 多视图噪声标签学习的标签空间。

图内文字对照：labels＝标签；samples＝样本；multi-view multi-label learning＝多视图多标签学习；incomplete multi-view multi-label learning＝不完整多视图多标签学习；incomplete multi-view noisy-label learning＝不完整多视图噪声标签学习；relevant label (1)＝相关标签（1）；irrelevant label (0)＝无关标签（0）；missing label (0)＝缺失标签（0）；noisy label (1)＝噪声标签（1）。

这里假设标签空间中的噪声是多标签噪声，即两个标签之间存在某种转移相关性，并且这一转移独立于样本特征。然而，多标签设置下的标签空间十分复杂，因此我们希望从数据分布角度执行这种变换。这两个噪声校正矩阵在不同标签空间中与各自对应的超图矩阵协同工作，主要用于抵消标签噪声导致的分布变化，确保分类器得到准确训练。

为此，我们构建两个噪声过滤矩阵 T^l 与 T^c。这些矩阵旨在变换特征表示，使其与标签空间对齐，从而实现两者的分布对齐。

$$\begin{aligned}\hat{Y}^{k+1} = \sigma\big(&T^l D_v^{-1/2} H^l W D_e^{-1} (H^l)^\top D_v^{-1/2} (\hat{Y}^k)\Theta_l^k \\ &+ \mu T^c D_v^{-1/2} H^c W D_e^{-1} (H^c)^\top D_v^{-1/2} (\hat{Y}^k)\Theta_c^k\big)\end{aligned} \tag{10}$$

下面，我们讨论标签变换矩阵 T（从 y 转移至 $\widetilde{y}$ 的概率可表示为 $p(\widetilde{y} \mid y)$）如何增强所学多标签分类模型对标签噪声的稳健性，以及如何构建该矩阵。

假设 $y^{i*}=1$ 表示样本 x 真实具有第 i 个标签，而 $\widetilde{y}^{j}=1$ 表示样本 x 在噪声干扰下被标注了第 j 个标签。两者之间的转移可通过标签变换矩阵 $T_{ji}^{*}=p\left(\widetilde{y}^{j}=1 \mid y^{i*}=1\right)$ 实现，其中标签变换矩阵 $T \in \mathbb{R}^{n \times n}$ 是非对称矩阵。假设模型训练的分类器预测真实标签概率为 $\widehat{p}\left(y^{i*}=1 \mid \mathbf{x}, \theta\right)$。借助标签变换矩阵 T，调整模型，使预测分布与噪声数据的标签分布对齐。

$$\hat{p}(\tilde{y}^{j}=1 \mid \mathbf{x}, \theta, T)=\sum_{i} t_{ji} \hat{p}(y^{i*}=1 \mid \mathbf{x}, \theta) \qquad (11)$$

多标签分类模型的训练目标是预测真实准确的标签集合 y^{*}，而非噪声标签集合 $\widetilde{y}$。向模型中加入 T 后，将得到另一个混淆矩阵 $\widetilde{U}$：

$$\tilde{u}_{ij}:=\frac{1}{|S_j|} \sum_{n \in S_j} \hat{p}(\tilde{y}^{i}=1 \mid \mathbf{x}_n, \theta, T) \qquad (12)$$

其中 S_j 是具有标签 $y^{j*}=1$ 的训练样本集合。混淆矩阵表示属于标签 j 的样本被错误分类为标签 i 的概率。因此，若能使 U 成为单位矩阵，就意味着基础模型能够预测训练数据中的真实标签。

根据式（11），可以得到 $\widetilde{U}=TU$。需要指出，在多视图多标签学习中，每个样本携带多个标签，真实的 U 成为单位矩阵的可能性很低。因此，我们仅利用这一思想纠正噪声标签。包含变换矩阵 T 的模型约束混淆矩阵 $\widetilde{U}$，使其与噪声标签的真实分布一致。

$$\tilde{u}_{ik}=\frac{1}{|S_k|} \sum_{n \in S_k} \hat{p}(\tilde{y}^{i} \mid x_n, y_n^{k*}) \rightarrow t_{ik}^{*} \Longrightarrow \tilde{U} \rightarrow T^{*} \quad (13)$$

通过约束 $T=T^{*}$，将迫使 U 收敛到单位矩阵。因此，用加入变换矩阵 T 的模型进行训练，将降低标签误分类概率，增强模型抵抗噪声的稳健性。由上述分析可知，噪声变换矩阵 T 是噪声校正模块的核心。T 可以通过以下两步近似计算：

$$\bar{x}^{i}=\arg \max_{x \in X} \hat{p}(\tilde{y}^{i}=1 \mid x), \quad T_{ij}=\hat{p}(\tilde{y}^{j}=1 \mid \bar{x}^{i}) \quad (14)$$

3.3 总损失函数

为训练整个网络，我们采用交叉熵损失函数，定义如下：

$$L_{ce}=\sum_{i=1}^{m} \sum_{j=1}^{n} y_{ij} \log \left(\hat{y}_{ij}\right)+\left(1-y_{ij}\right) \log \left(1-\hat{y}_{ij}\right) \quad (15)$$

为保证多视图信息融合后特征空间与标签空间的一致性，我们提出如下高阶结构差异损失：

$$L_f(\hat{X}^f, \hat{Y}^{lc}) = \|\hat{X}^f - \hat{Y}^{lc}\|_F^2 \qquad (16)$$

此外，我们利用标准 Kullback-Leibler（KL）散度，衡量经两个噪声校正矩阵处理后的表示之间的对齐程度。这些矩阵来自基于标签空间构建的超图，关注数据的不同方面。

$$L_{kl} = \sum_{i=1}^{m} \mathrm{KL}\left(\hat{y}_{ij}^{l} | 1 \le j \le n, \hat{y}_{ij}^{c} | 1 \le j \le n\right) \qquad (17)$$

综上，所提模型的总损失函数由三个关键部分组成：

$$L = L_{ce} + \beta L_f + \gamma L_{kl} \qquad (18)$$

这些损失项通过对齐特征空间与标签空间来指导训练，提高模型在含噪声、不完整的多视图数据上的分类准确率与稳健性。

4 实验

4.1 数据集与实验设置

我们在五个基准数据集上评估所提 DMHNF：Corel5k [Duygulu et al., 2002]、Pascal07 [Everingham et al., 2010]、ESPGame [Von Ahn and Dabbish, 2004]、IAPRTC12 [Guillaumin et al., 2009] 和 Mirflickr [Huiskes and Lew, 2008]，使用六组特征：GIST、HSV、DenseHue、DenseSift、RGB 和 LAB。评估使用六项指标：排序损失（RL）、平均精确率（AP）、汉明损失（HL）、曲线下面积（AUC）、单错误率（OneError，OE）和覆盖度（Coverage，Cov）。为使比较更清晰，我们采用 1-RL、1-HL、1-OE 和 1-Cov，数值越高表示性能越好。

我们将所提方法与先进的多标签学习方法 GLOCAL [Zhu et al., 2017b]、DM2L [Ma and Chen, 2021]、CDMM [Xie and Huang, 2022]，以及多视图多标签学习方法 LVSL [Zhao et al., 2023]、iMVWL [Tan et al., 2018]、NAIM3L [Li and Chen, 2021]、DICNet [Liu et al., 2023]、SIP [Liu et al., 2024] 进行比较。

我们设计两种实验场景，使用数据集的 70% 进行训练。在第一种场景中，对每个视图随机停用 50% 的实例，同时确保每个样本至少保留一个视图；另外移除正标签和负标签各 50%，模拟部分标签缺失。在第二种场景中，除视图不完整外，还通过随机增加和删除标签引入标签噪声，模拟 20% 的假阳性和 20% 的假阴性，以反映真实的噪声标签空间。

Data	Metric	GLOCAL	CDMM	DM2L	LVSL	iMVWL	NAIM3L	DICNet	SIP	DMHNF
Corel5k	AP	$0.285_{0.004}$	$0.354_{0.004}$	$0.262_{0.005}$	$0.342_{0.004}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.381_{0.004}$	$0.418_{0.009}$	$0.426_{0.004}$
	1-HL	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$	$0.991_{0.000}$
	1-RL	$0.840_{0.003}$	$0.884_{0.003}$	$0.843_{0.002}$	$0.881_{0.003}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.882_{0.004}$	$0.911_{0.003}$	$0.923_{0.004}$
	AUC	$0.843_{0.003}$	$0.888_{0.003}$	$0.845_{0.002}$	$0.884_{0.003}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.884_{0.004}$	$0.913_{0.003}$	$0.927_{0.005}$
	1-OE	$0.327_{0.010}$	$0.410_{0.007}$	$0.295_{0.014}$	$0.391_{0.009}$	$0.311_{0.015}$	$0.350_{0.009}$	$0.468_{0.007}$	$0.489_{0.016}$	$0.497_{0.007}$
	1-Cov	$0.648_{0.006}$	$0.723_{0.007}$	$0.647_{0.005}$	$0.718_{0.006}$	$0.702_{0.008}$	$0.725_{0.005}$	$0.727_{0.011}$	$0.787_{0.009}$	$0.791_{0.011}$
Pascal07	AP	$0.496_{0.004}$	$0.508_{0.005}$	$0.471_{0.008}$	$0.504_{0.005}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.505_{0.012}$	$0.555_{0.010}$	$0.567_{0.008}$
	1-HL	$0.927_{0.000}$	$0.931_{0.001}$	$0.928_{0.001}$	$0.930_{0.000}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.929_{0.001}$	$0.931_{0.001}$	$0.943_{0.001}$
	1-RL	$0.767_{0.004}$	$0.812_{0.004}$	$0.761_{0.005}$	$0.806_{0.003}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.783_{0.008}$	$0.830_{0.004}$	$0.833_{0.008}$
	AUC	$0.786_{0.003}$	$0.838_{0.003}$	$0.779_{0.004}$	$0.832_{0.002}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.809_{0.006}$	$0.850_{0.005}$	$0.869_{0.006}$
	1-OE	$0.443_{0.005}$	$0.419_{0.008}$	$0.420_{0.011}$	$0.419_{0.008}$	$0.362_{0.023}$	$0.421_{0.006}$	$0.427_{0.015}$	$0.464_{0.018}$	$0.487_{0.006}$
	1-Cov	$0.703_{0.004}$	$0.759_{0.003}$	$0.692_{0.004}$	$0.751_{0.003}$	$0.677_{0.015}$	$0.727_{0.002}$	$0.731_{0.006}$	$0.783_{0.006}$	$0.791_{0.003}$
ESPGame	AP	$0.221_{0.002}$	$0.289_{0.003}$	$0.212_{0.002}$	$0.285_{0.003}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.297_{0.002}$	$0.311_{0.004}$	$0.328_{0.006}$
	1-HL	$0.982_{0.000}$	$0.983_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.003}$
	1-RL	$0.780_{0.004}$	$0.832_{0.001}$	$0.781_{0.001}$	$0.829_{0.001}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.832_{0.001}$	$0.849_{0.002}$	$0.867_{0.001}$
	AUC	$0.784_{0.004}$	$0.836_{0.001}$	$0.785_{0.001}$	$0.833_{0.002}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.836_{0.001}$	$0.853_{0.002}$	$0.857_{0.008}$
	1-OE	$0.317_{0.005}$	$0.396_{0.005}$	$0.294_{0.006}$	$0.389_{0.004}$	$0.343_{0.013}$	$0.339_{0.003}$	$0.439_{0.007}$	$0.455_{0.007}$	$0.462_{0.002}$
	1-Cov	$0.496_{0.006}$	$0.574_{0.004}$	$0.488_{0.003}$	$0.567_{0.005}$	$0.548_{0.004}$	$0.571_{0.003}$	$0.593_{0.003}$	$0.628_{0.005}$	$0.637_{0.006}$
IAPRTC12	AP	$0.256_{0.002}$	$0.305_{0.004}$	$0.234_{0.003}$	$0.304_{0.004}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.323_{0.001}$	$0.331_{0.006}$	$0.348_{0.003}$
	1-HL	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.982_{0.001}$
	1-RL	$0.825_{0.002}$	$0.862_{0.002}$	$0.823_{0.002}$	$0.861_{0.002}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.873_{0.001}$	$0.885_{0.003}$	$0.896_{0.000}$
	AUC	$0.830_{0.001}$	$0.864_{0.002}$	$0.825_{0.001}$	$0.863_{0.001}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.874_{0.000}$	$0.886_{0.002}$	$0.897_{0.007}$
	1-OE	$0.378_{0.007}$	$0.432_{0.008}$	$0.340_{0.006}$	$0.429_{0.009}$	$0.352_{0.008}$	$0.390_{0.005}$	$0.468_{0.002}$	$0.463_{0.009}$	$0.464_{0.005}$
	1-Cov	$0.534_{0.003}$	$0.597_{0.004}$	$0.529_{0.004}$	$0.597_{0.004}$	$0.564_{0.005}$	$0.592_{0.004}$	$0.649_{0.001}$	$0.675_{0.007}$	$0.686_{0.004}$
Mirflickr	AP	$0.537_{0.002}$	$0.570_{0.002}$	$0.514_{0.006}$	$0.553_{0.002}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.589_{0.005}$	$0.614_{0.004}$	$0.629_{0.007}$
	1-HL	$0.874_{0.001}$	$0.886_{0.001}$	$0.878_{0.001}$	$0.885_{0.001}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.002}$	$0.891_{0.001}$	$0.896_{0.003}$
	1-RL	$0.832_{0.001}$	$0.856_{0.001}$	$0.831_{0.003}$	$0.856_{0.001}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.863_{0.004}$	$0.877_{0.002}$	$0.879_{0.008}$
	AUC	$0.828_{0.001}$	$0.846_{0.001}$	$0.828_{0.003}$	$0.844_{0.001}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.849_{0.004}$	$0.860_{0.003}$	$0.862_{0.005}$
	1-OE	$0.552_{0.005}$	$0.631_{0.004}$	$0.510_{0.008}$	$0.607_{0.004}$	$0.511_{0.022}$	$0.585_{0.003}$	$0.637_{0.007}$	$0.662_{0.008}$	$0.676_{0.010}$
	1-Cov	$0.605_{0.003}$	$0.640_{0.001}$	$0.604_{0.005}$	$0.636_{0.001}$	$0.572_{0.013}$	$0.631_{0.002}$	$0.652_{0.007}$	$0.678_{0.003}$	$0.685_{0.007}$

表 1. 视图缺失率为 50%、标签缺失率为 50% 的数据集上的定量结果（右下角数字为标准差）。

表头对照：Data＝数据集；Metric＝指标。算法名与数据集名不译；所有数值、右下标标准差及原文加粗格式均保留。指标含义见第 4.1 节。

Data	Metric	GLOCAL	CDMM	DM2L	LVSL	iMVWL	NAIM3L	DICNet	SIP	DMHNF
Corel5k	AP	$0.205_{0.004}$	$0.268_{0.005}$	$0.326_{0.010}$	$0.243_{0.009}$	$0.304_{0.007}$	$0.263_{0.004}$	$0.291_{0.003}$	$0.344_{0.008}$	$0.375_{0.004}$
	1-HL	$0.936_{0.000}$	$0.944_{0.002}$	$0.939_{0.000}$	$0.943_{0.000}$	$0.941_{0.000}$	$0.927_{0.000}$	$0.942_{0.000}$	$0.938_{0.000}$	$0.949_{0.000}$
	1-RL	$0.734_{0.002}$	$0.782_{0.003}$	$0.824_{0.004}$	$0.762_{0.009}$	$0.798_{0.004}$	$0.797_{0.002}$	$0.794_{0.003}$	$0.795_{0.004}$	$0.849_{0.009}$
	AUC	$0.735_{0.006}$	$0.772_{0.010}$	$0.821_{0.003}$	$0.763_{0.002}$	$0.797_{0.004}$	$0.786_{0.002}$	$0.793_{0.005}$	$0.782_{0.002}$	$0.843_{0.003}$
	1-OE	$0.241_{0.017}$	$0.292_{0.009}$	$0.371_{0.018}$	$0.269_{0.011}$	$0.353_{0.013}$	$0.277_{0.016}$	$0.316_{0.012}$	$0.423_{0.007}$	$0.441_{0.018}$
	1-Cov	$0.531_{0.007}$	$0.592_{0.010}$	$0.645_{0.006}$	$0.581_{0.012}$	$0.653_{0.008}$	$0.628_{0.011}$	$0.646_{0.005}$	$0.655_{0.003}$	$0.704_{0.012}$
Pascal07	AP	$0.446_{0.002}$	$0.465_{0.006}$	$0.478_{0.007}$	$0.423_{0.008}$	$0.468_{0.004}$	$0.399_{0.020}$	$0.453_{0.003}$	$0.469_{0.005}$	$0.510_{0.011}$
	1-HL	$0.862_{0.001}$	$0.885_{0.002}$	$0.891_{0.001}$	$0.887_{0.002}$	$0.887_{0.000}$	$0.834_{0.004}$	$0.863_{0.003}$	$0.874_{0.001}$	$0.891_{0.001}$
	1-RL	$0.674_{0.007}$	$0.708_{0.005}$	$0.754_{0.003}$	$0.697_{0.008}$	$0.746_{0.002}$	$0.663_{0.012}$	$0.707_{0.002}$	$0.709_{0.009}$	$0.753_{0.005}$
	AUC	$0.692_{0.008}$	$0.724_{0.002}$	$0.740_{0.003}$	$0.716_{0.004}$	$0.753_{0.001}$	$0.702_{0.020}$	$0.752_{0.003}$	$0.744_{0.002}$	$0.776_{0.004}$
	1-OE	$0.398_{0.009}$	$0.394_{0.004}$	$0.378_{0.010}$	$0.381_{0.009}$	$0.372_{0.007}$	$0.352_{0.019}$	$0.387_{0.005}$	$0.393_{0.017}$	$0.422_{0.012}$
	1-Cov	$0.611_{0.008}$	$0.643_{0.004}$	$0.677_{0.002}$	$0.622_{0.003}$	$0.684_{0.006}$	$0.603_{0.019}$	$0.668_{0.003}$	$0.660_{0.007}$	$0.714_{0.004}$
ESPGame	AP	$0.188_{0.003}$	$0.196_{0.005}$	$0.262_{0.002}$	$0.191_{0.004}$	$0.259_{0.001}$	$0.216_{0.007}$	$0.224_{0.002}$	$0.277_{0.003}$	$0.284_{0.006}$
	1-HL	$0.927_{0.001}$	$0.916_{0.002}$	$0.924_{0.000}$	$0.926_{0.000}$	$0.918_{0.001}$	$0.923_{0.002}$	$0.912_{0.000}$	$0.929_{0.000}$	$0.936_{0.000}$
	1-RL	$0.692_{0.002}$	$0.704_{0.005}$	$0.753_{0.001}$	$0.705_{0.003}$	$0.758_{0.002}$	$0.723_{0.004}$	$0.737_{0.003}$	$0.754_{0.001}$	$0.761_{0.002}$
	AUC	$0.705_{0.003}$	$0.702_{0.002}$	$0.756_{0.003}$	$0.708_{0.001}$	$0.751_{0.004}$	$0.733_{0.003}$	$0.747_{0.002}$	$0.752_{0.001}$	$0.771_{0.002}$
	1-OE	$0.236_{0.021}$	$0.282_{0.004}$	$0.354_{0.002}$	$0.266_{0.006}$	$0.347_{0.004}$	$0.309_{0.013}$	$0.305_{0.005}$	$0.398_{0.009}$	$0.406_{0.007}$
	1-Cov	$0.446_{0.003}$	$0.448_{0.008}$	$0.519_{0.001}$	$0.437_{0.003}$	$0.517_{0.006}$	$0.481_{0.002}$	$0.498_{0.004}$	$0.512_{0.003}$	$0.521_{0.005}$
IAPRTC12	AP	$0.207_{0.005}$	$0.231_{0.001}$	$0.271_{0.004}$	$0.216_{0.002}$	$0.275_{0.006}$	$0.214_{0.003}$	$0.230_{0.000}$	$0.275_{0.010}$	$0.291_{0.007}$
	1-HL	$0.926_{0.000}$	$0.933_{0.001}$	$0.936_{0.000}$	$0.937_{0.002}$	$0.934_{0.002}$	$0.927_{0.001}$	$0.938_{0.003}$	$0.937_{0.000}$	$0.945_{0.001}$
	1-RL	$0.723_{0.002}$	$0.746_{0.006}$	$0.781_{0.001}$	$0.743_{0.003}$	$0.773_{0.005}$	$0.758_{0.002}$	$0.769_{0.000}$	$0.785_{0.003}$	$0.793_{0.001}$
	AUC	$0.724_{0.004}$	$0.748_{0.001}$	$0.782_{0.005}$	$0.744_{0.002}$	$0.785_{0.006}$	$0.750_{0.002}$	$0.774_{0.003}$	$0.783_{0.000}$	$0.806_{0.002}$
	1-OE	$0.271_{0.008}$	$0.340_{0.030}$	$0.396_{0.004}$	$0.307_{0.002}$	$0.381_{0.009}$	$0.316_{0.006}$	$0.357_{0.003}$	$0.405_{0.005}$	$0.411_{0.001}$
	1-Cov	$0.472_{0.004}$	$0.481_{0.005}$	$0.538_{0.003}$	$0.479_{0.002}$	$0.535_{0.010}$	$0.507_{0.004}$	$0.534_{0.007}$	$0.588_{0.003}$	$0.605_{0.005}$
Mirflickr	AP	$0.457_{0.002}$	$0.489_{0.005}$	$0.527_{0.008}$	$0.460_{0.003}$	$0.502_{0.002}$	$0.441_{0.009}$	$0.491_{0.006}$	$0.537_{0.001}$	$0.563_{0.007}$
	1-HL	$0.784_{0.002}$	$0.805_{0.000}$	$0.812_{0.003}$	$0.817_{0.002}$	$0.811_{0.001}$	$0.774_{0.001}$	$0.811_{0.000}$	$0.813_{0.002}$	$0.826_{0.003}$
	1-RL	$0.736_{0.001}$	$0.741_{0.002}$	$0.767_{0.004}$	$0.749_{0.000}$	$0.776_{0.001}$	$0.720_{0.003}$	$0.767_{0.002}$	$0.771_{0.001}$	$0.792_{0.003}$
	AUC	$0.724_{0.002}$	$0.748_{0.003}$	$0.763_{0.001}$	$0.741_{0.004}$	$0.753_{0.002}$	$0.705_{0.001}$	$0.754_{0.002}$	$0.752_{0.003}$	$0.773_{0.004}$
	1-OE	$0.457_{0.007}$	$0.494_{0.006}$	$0.574_{0.008}$	$0.455_{0.003}$	$0.546_{0.002}$	$0.461_{0.005}$	$0.524_{0.004}$	$0.576_{0.001}$	$0.591_{0.006}$
	1-Cov	$0.535_{0.005}$	$0.548_{0.004}$	$0.573_{0.003}$	$0.547_{0.001}$	$0.573_{0.001}$	$0.515_{0.002}$	$0.574_{0.006}$	$0.593_{0.004}$	$0.612_{0.005}$

表 2. 视图缺失率为 40%、噪声标签率为 40% 的数据集上的定量结果（右下角数字为标准差）。

表头对照：Data＝数据集；Metric＝指标。算法名与数据集名不译；所有数值、右下标标准差及原文加粗格式均保留。

4.2 实验结果与分析

表 1 和表 2 给出了不完整多视图数据中，标签缺失与标签含噪声条件下的实验结果。表 3 展示消融研究，图 4 展示视图缺失率与噪声标签率变化时的性能趋势。根据这些结果，我们得出如下结论。

1. 如表 1 和表 2 所示，在所有基准数据集上，我们的方法在处理缺失视图与噪声标签时始终优于现有方法。尤其是，相比先进的多视图多标签学习模型，以及专门处理模态缺失或标签不完整的方法，我们的方法在视图缺失和标签噪声条件下均获得更优性能。这些结果突出了模型的有效性与稳健性。

2. 当标签缺失、标签噪声与视图不完整同时存在时，我们的方法表现出色，优于仅处理缺失标签的方法。这强调了所提方法在复杂设置中的稳健性，尤其是在标签噪声伴随数据缺失时，展现了广泛适用性和更强的实际效用。

3. 分析表 1 和表 2 可见，标签缺失与标签噪声同时存在，比仅有标签缺失更具挑战。尽管表 2 中缺失／噪声标签的比例更低，整体性能却更弱，这证实了我们的方法能够更有效地应对标签缺失和标签噪声的联合挑战。

4. 我们进行了消融实验，结果表明高阶相关性不可或缺。用二阶相关性替代高阶相关性，会削弱其与过滤矩阵的相互作用。没有这些矩阵时，不准确的高阶相关性比二阶相关性更容易降低准确率，突出两者的互补作用。由于标签空间复杂，使用两个过滤矩阵优于只使用一个。仅基于词向量表示构建的超图，其高阶相关性较稀疏。结合两种方式能够提高准确率，改善噪声校正。

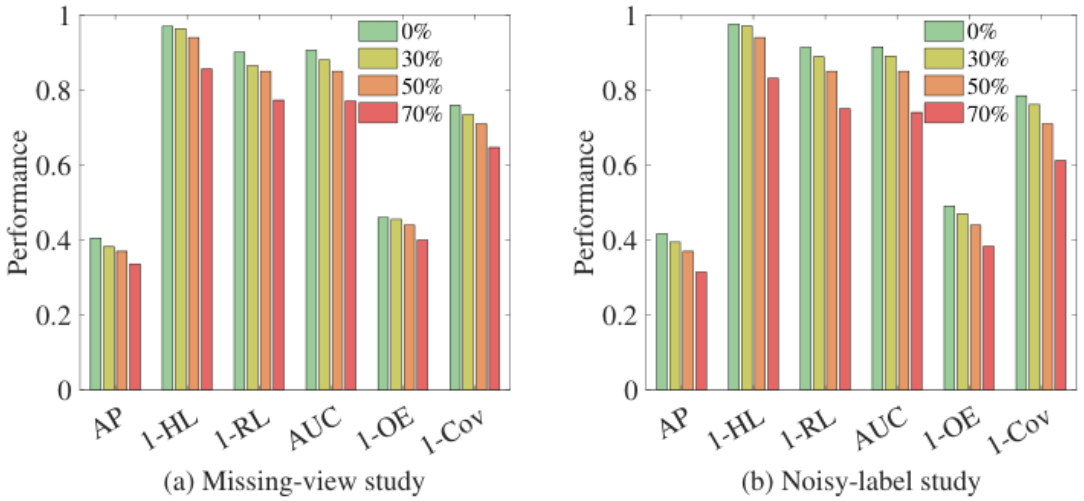


图 4. 视图缺失与标签噪声程度变化时的性能。

图内文字对照：Performance＝性能；(a) Missing-view study＝(a) 视图缺失研究；(b) Noisy-label study＝(b) 噪声标签研究。图例比例为 0%、30%、50%、70%；横轴依次为 AP、1-HL、1-RL、AUC、1-OE、1-Cov。

Method				Corel5k		Pascal07	
Backbone	M-HNN	T^l	T^c	AP	AUC	AP	AUC
✓				0.321	0.818	0.470	0.757
✓	✓			0.363	0.829	0.491	0.767
✓	✓	✓		0.368	0.837	0.498	0.771
✓	✓		✓	0.364	0.836	0.501	0.769
✓	✓	✓	✓	0.375	0.843	0.510	0.776

表 3. 两个数据集在视图缺失率 40%、噪声标签率 40% 下的消融结果。

表头对照：Method＝方法；Backbone＝骨干网络；M-HNN＝多超图神经网络；T^l、T^c 为两个噪声过滤矩阵；Corel5k、Pascal07 为数据集名；AP＝平均精确率，AUC＝曲线下面积。勾号表示采用对应组件。

5 结论

本文提出一种新颖的动态多超图神经网络模型，专门用于解决不完整多视图噪声标签学习的挑战。模型通过捕获样本之间的高阶相关性整合多视图数据，有效利用不同视图中的特征信息与结构信息。为处理标签噪声，我们提出标签噪声过滤矩阵，利用特征空间固有的高阶相关性，校正标签空间中被扰乱的相

关性。大量实验表明，我们的方法不仅在不完整多视图多标签学习场景中表现出色，也能在更具挑战的含噪声标签不完整多视图学习设置下保持稳健性能。这些发现进一步凸显所提模型的有效性、适应性及广泛适用性。

此外，本工作提出一种新的问题表述，紧密反映真实世界多标签学习场景的复杂性，从而为视图不完整和标注含噪声带来的挑战提供有原则且实用的解决方案。我们相信，这些贡献为未来研究奠定了坚实基础，将促进动态多超图方法在不同应用领域中的进一步探索与发展。

致谢

本工作得到中国国家重点研发计划（编号 2022YFB3305504）资助。

参考文献

以下保留原文引用键、作者、刊物／会议、年份、卷期、页码与标识符，文献题名译为中文；不以译名替换原文可检索标识。

[Carletti et al., 2020] Timoteo Carletti, Federico Battiston, Giulia Cencetti, and Duccio Fanelli. 超图上的随机游走（Random walks on hypergraphs）. Physical review E, 101(2):022308, 2020.

[Chen et al., 2024] Jia-Yao Chen, Shao-Yuan Li, Sheng-Jun Huang, Songcan Chen, Lei Wang, and Ming-Kun Xie. Unm：噪声多标签学习的通用方法（Unm: A universal approach for noisy multi-label learning）. IEEE Transactions on Knowledge and Data Engineering, 36:4968–4980, 2024.

[Chitra and Raphael, 2019] Uthsav Chitra and Benjamin Raphael. 具有边依赖顶点权重的超图上的随机游走（Random walks on hypergraphs with edge-dependent vertex weights）. In International Conference on Machine Learning, pages 1172–1181, 2019.

[Cui et al., 2020] Zijun Cui, Yong Zhang, and Qiang Ji. 通过标签关系进行标签错误校正与生成（Label error correction and generation through label relationships）. In AAAI Conference on Artificial Intelligence, pages 3693–3700, 2020.

[Defferrard et al., 2016] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. 具有快速局部化谱滤波的图卷积神经网络（Convolutional neural networks on graphs with fast localized spectral filtering）. In Advances in Neural Information Processing Systems, pages 3844–3852, 2016.

[Duygulu et al., 2002] Pinar Duygulu, Kobus Barnard, Joao FG de Freitas, and David A Forsyth. 将对象识别视为机器翻译：为固定图像词汇表学习词典（Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary）. In European Conference on Computer Vision, pages 97–112, 2002.

[Everingham et al., 2010] Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, and Andrew Zisserman. Pascal 视觉对象类别（VOC）挑战（The pascal visual object classes (voc) challenge）. International Journal of Computer Vision, 88:303–338, 2010.

[Feng et al., 2019] Yifan Feng, Haoxuan You, Zizhao Zhang, Rongrong Ji, and Yue Gao. 超图神经网络（Hypergraph neural networks）. In AAAI Conference on Artificial Intelligence, pages 3558–3565, 2019.

[Fu et al., 2022] Jun Fu, Chen Hou, Wei Zhou, Jiahua Xu, and Zhibo Chen. 用于无参考 360 度图像质量评估的自适应超图卷积网络（Adaptive hypergraph convolutional network for no-reference 360-degree image quality assessment）. In ACM International Conference on Multimedia, pages 961–969, 2022.

[Gao et al., 2020] Yue Gao, Zizhao Zhang, Haojie Lin, Xibin Zhao, Shaoyi Du, and Changqing Zou. 超图学习：方法与实践（Hypergraph learning: Methods and practices）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(5):2548–2566, 2020.

[Guillaumin et al., 2009] Matthieu Guillaumin, Thomas Mensink, Jakob Verbeek, and Cordelia Schmid. Tagprop：图像自动标注最近邻模型中的判别式度量学习（Tagprop: Discriminative metric learning in nearest neighbor models for image auto-annotation）. In International Conference on Computer Vision, pages 309–316, 2009.

[Hamilton et al., 2017] Will Hamilton, Zhitao Ying, and Jure Leskovec. 大规模图上的归纳式表示学习（Inductive representation learning on large graphs）. In Advances in Neural Information Processing Systems, pages 1024–1034, 2017.

[Huiskes and Lew, 2008] Mark J Huiskes and Michael S Lew. MIR Flickr 检索评估（The mir flickr retrieval evaluation）. In ACM International Conference on Multimedia Information Retrieval, pages 39–43, 2008.

[Jiang et al., 2019] Jianwen Jiang, Yuxuan Wei, Yifan Feng, Jingxuan Cao, and Yue Gao. 动态超图神经网络（Dynamic hypergraph neural networks）. In International Joint Conferences on Artificial Intelligence, pages 2635–2641, 2019.

[Li and Chen, 2021] Xiang Li and Songcan Chen. 面向非对齐不完整多视图与缺失多标签学习的简洁有效模型（A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918–5932, 2021.

[Li et al., 2024] Quanjiang Li, Tingjin Luo, Mingdie Jiang, Jiahui Liao, and Zhangqi Jiang. 具有无偏损失的深度不完整多视图网络半监督多标签学习（Deep incomplete multi-view network semi-supervised multi-label learning with unbiased loss）. In ACM International Conference on Multimedia, pages 9048–9056, 2024.

[Liu et al., 2021] Weiwei Liu, Haobo Wang, Xiaobo Shen, and Ivor W Tsang. 多标签学习的新兴趋势（The emerging trends of multi-label learning）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(11):7955–7974, 2021.

[Liu et al., 2023] Chengliang Liu, Jie Wen, Xiaoling Luo, Chao Huang, Zhihao Wu, and Yong Xu. Dicnet：用于双重不完整多视图多标签分类的深度实例级对比网络（Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification）. In AAAI Conference on Artificial Intelligence, pages 8807–8815, 2023.

[Liu et al., 2024] Chengliang Liu, Gehui Xu, Jie Wen, Yabo Liu, Chao Huang, and Yong Xu. 通过语义不变性学习与原型建模实现部分多视图多标签分类（Partial multi-view multi-label classification via semantic invariance learning and prototype modeling）. In International Conference on Machine Learning, pages 32253–32267, 2024.

[Ma and Chen, 2021] Zhongchen Ma and Songcan Chen. 全局扩展、局部收缩：含缺失标签的判别式多标签学习（Expand globally, shrink locally: Discriminant multi-label learning with missing labels）. Pattern Recognition, 111:107675, 2021.

[Ou et al., 2024] Shilong Ou, Zhe Xue, Yawen Li, Meiyu Liang, Yuanqiang Cai, and Junjiang Wu. 用于不完整多视图多标签学习的视图-类别交互共享 Transformer（View-category interactive sharing transformer for incomplete multi-view multi-label learning）. In IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 27467–27476, 2024.

[Qian et al., 2014] Buyue Qian, Xiang Wang, Jieping Ye, and Ian Davidson. 基于重构误差的多标签与多视图学习框架（A reconstruction error based framework for multi-label and multi-view learning）. IEEE Transactions on Knowledge and Data Engineering, 27(3):594–607, 2014.

[Tan et al., 2018] Qiaoyu Tan, Guoxian Yu, Carlotta Domeniconi, Jun Wang, and Zili Zhang. 不完整多视图弱标签学习（Incomplete multi-view weak-label learning）. In International Joint Conference on Artificial Intelligence, pages 2703–2709, 2018.

[Veličković et al., 2017] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lio, and Yoshua Bengio. 图注意力网络（Graph attention networks）. arXiv preprint arXiv:1710.10903, 2017.

[Von Ahn and Dabbish, 2004] Luis Von Ahn and Laura Dabbish. 利用计算机游戏标注图像（Labeling images with a computer game）. In SIGCHI Conference on Human Factors in Computing Systems, pages 319–326, 2004.

[Wang et al., 2022] Qianqian Wang, Zhiqiang Tao, Quanxue Gao, and Licheng Jiao. 通过结构化多路径网络实现多视图子空间聚类（Multi-view subspace clustering via structured multi-pathway network）. IEEE Transactions on Neural Networks and Learning Systems, 35(5):7244–7250, 2022.

[Xie and Huang, 2022] Ming-Kun Xie and Sheng-Jun Huang. Ccmn：具有类别条件多标签噪声的学习通用框架（Ccmn: A general framework for learning with class-conditional multi-label noise）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(1):154–166, 2022.

[Zhang et al., 2019] Changqing Zhang, Ziwei Yu, Huazhu Fu, Pengfei Zhu, Lei Chen, and Qinghua Hu. 面向混合噪声的多标签学习（Hybrid noise-oriented multilabel learning）. IEEE Transactions on Cybernetics, 50(6):2837–2850, 2019.

[Zhao et al., 2023] Dawei Zhao, Qingwei Gao, Yixiang Lu, and Dong Sun. 通过学习视图特定标签进行非对齐多视图多标签分类（Non-aligned multi-view multi-label classification via learning view-specific labels）. IEEE Transactions on Multimedia, 25:7235–7247, 2023.

[Zhou et al., 2006] Dengyong Zhou, Jiayuan Huang, and Bernhard Schölkopf. 超图学习：聚类、分类与嵌入（Learning with hypergraphs: Clustering, classification, and embedding）. In Advances in Neural Information Processing Systems, pages 1601–1608, 2006.

[Zhou et al., 2023] Peng Zhou, Zongqian Wu, Xiangxiang Zeng, Guoqiu Wen, Junbo Ma, and Xiaofeng Zhu. 完全动态超图神经网络（Totally dynamic hypergraph neural network）. In International Joint Conference on Artificial Intelligence, pages 2476–2483, 2023.

[Zhu et al., 2015] Xiaofeng Zhu, Xuelong Li, and Shichao Zhang. 用于图像分类的块行稀疏多视图多标签学习（Block-row sparse multiview multilabel learning for image classification）. IEEE Transactions on Cybernetics, 46(2):450–461, 2015.

[Zhu et al., 2017a] Xiaofeng Zhu, Yonghua Zhu, Shichao Zhang, Rongyao Hu, and Wei He. 用于无监督特征选择的自适应超图学习（Adaptive hypergraph learning for unsupervised feature selection）. In International Joint Conference on Artificial Intelligence, pages 3581–3587, 2017.

[Zhu et al., 2017b] Yue Zhu, James T Kwok, and Zhi-Hua Zhou. 具有全局与局部标签相关性的多标签学习（Multi-label learning with global and local label correlation）. IEEE Transactions on Knowledge and Data Engineering, 30(6):1081–1094, 2017.

译注：原文保留事项

以下为译者核对提示，不属于原文论述，也不改动原公式或实验值。

1. 上传文件名使用“DMHCNF”，但论文正文与实验表格使用“DMHNF”；译文依正文保留 DMHNF。作者第三个邮箱中的下划线已据原稿图像核对为“nufe_yf@163.com”（文本提取器会将其提取为空格）。
2. 式（2）将 $\omega\left(y_i,\ y_j\right)$ 解释为词向量的两两“距离”之和，但同段将 σ_i^c 称为平均“相似度”，且采用大于等于阈值；译文不擅自统一其含义。
3. 式（4）要求权重和为 1；式（5）的分母仍从 $i=1$ 求和，而左侧定义范围为 $2 \le i \le q$。原式及其下标重用均保留，不改写归一化方式。

4. 原文以 W 同时出现在缺失视图指示的定义和超图卷积式中，式（9）还使用 $W'_{:,q+1}$；q、k 和 i 的下标搭配以及各处 $L^{(q)}$ 的描述均照原文保留，未补充原文未给出的维度或定义。
5. 第 3.2 节先说明多标签条件下 U 很难成为单位矩阵，随后又以 $T = T^*$ 推导其收敛到单位矩阵；译文保留这两处表述，不将其升级为额外证明。该节此前定义 T^*_{ji}，式（14）则写为 T_{ij}，索引方向也照原式保留。
6. 式（15）被称为交叉熵损失，但原式前未印负号；式（18）仍以加法组合损失项。两式均保留，不补负号。
7. 第 4.2 节第 1 点的“始终优于”是作者的表述；表格含并列及个别非最优数值，例如表 1 的 IAPRTC12 的 1-OE，以及表 2 的 Pascal07 的 1-RL。译文不篡改文字主张或表值。表 2 的视图缺失率 40% 来自其表题，实验设置段仅明确说明第二种场景的假阳性／假阴性比例。
8. 原文的所有 18 个编号公式、4 张图与3张表均以原稿裁图保留，以免转录改变标量、上下标、转置、希腊字母及书法体。图表英文的中文释义随图表提供。未发现独立的版权声明段落；保留会议归属、作者和原始 PDF，不据此推断公开许可。