# 面向类别不平衡多标签图像分类的分层提示双视图对齐学习

**原题：** Dual-View Alignment Learning with Hierarchical-Prompt for Class-Imbalance Multi-Label Image Classification
**作者：** Sheng Huang、Jiexuan Yan、Beiyan Liu、Bo Liu、Richang Hong
**来源版本：** arXiv:2509.17747v1，2025 年 9 月 22 日，原文 13 页。
**版本链接：** https://arxiv.org/abs/2509.17747v1
**原文 PDF：** https://arxiv.org/pdf/2509.17747v1

## 译本与许可说明

本文件为非官方中文译本，覆盖所提供版本的摘要、正文、19 个编号公式、7 张表、7 幅图的完整图注、85 条参考文献以及 5 位作者的简介；该版本未附独立附录。作者姓名、机构、资助和文献出处均予保留。中文翻译与排版由 AI 辅助完成，未经原作者审定，不表示作者认可本译本。

原文由作者以 **Creative Commons 署名—非商业性使用—相同方式共享 4.0 国际（CC BY-NC-SA 4.0）** 许可发布。本中文翻译及获许可的改编部分同样依该许可提供：须合理署名、链接原作及许可并标明修改；不得用于商业目的；分享改编作品须采用同一许可，不得施加额外法律或技术限制。许可全文：https://creativecommons.org/licenses/by-nc-sa/4.0/。修改包括中文翻译、重排、表格重排、公式重排，以及以下明确标注的图像省略。

**图像范围并非完整复制。** 对权利来源尚未单独确认的照片及照片衍生注意力热图，本译本不推定其已获作者许可覆盖。图 1(a) 的 6 个照片/热图面板与图 2 的输入照片和 4 个照片图块已从派生素材中真正移除，保留灰框与省略标记；相关作者绘制的柱状图、流程线、模块及其他符号保留。图 6、图 7 的全部照片/热图面板和末页 5 张作者肖像不予转载。图 1(b)、图 3、图 4、图 5 完整保留。每处省略均附说明和原文链接。图中英文标签保留，并在相邻文字中提供中文释义。此译本的交付材料不含原文 PDF 或原文整页渲染图。

原文若有文字、引用或数据上的不一致，译文不静默更改研究结论；重要疑点以“译注”明确区分。百分比变化沿用原文表述，表格数据保持原值。

## 摘要

现实世界数据集在多个类别之间往往存在类别不平衡，表现为长尾分布和小样本情形。对于类别不平衡多标签图像分类（Class-Imbalanced Multi-Label Image Classification，CI-MLIC）任务，这一问题尤其棘手，因为数据不平衡和多目标识别构成了显著障碍。为应对这些挑战，我们提出一种新方法，称为分层提示双视图对齐学习（Dual-View Alignment Learning with Hierarchical Prompt，HP-DVAL）。该方法利用视觉语言预训练（vision-language pretrained，VLP）模型的多模态知识，缓解多标签场景中的类别不平衡问题。具体而言，HP-DVAL 采用双视图对齐学习，通过提取互补特征来实现准确的图文对齐，从而迁移 VLP 模型强大的特征表示能力。为使 VLP 模型更好地适应 CI-MLIC

任务，我们引入分层提示调优策略，利用全局提示和局部提示学习任务特定及上下文相关的先验知识。此外，我们在提示调优期间设计语义一致性损失，防止学得的提示偏离 VLP 模型内嵌的通用知识。我们在两个 CI-MLIC 基准 MS-COCO 和 VOC2007 上验证了方法的有效性。大量实验结果表明，本方法优于当前最先进的方法：在长尾多标签图像分类任务上，mAP 分别提高 10.0% 和 5.2%；在多标签小样本图像分类任务上，mAP 分别提高 6.8% 和 2.9%。

**关键词：** 类别不平衡分布；多标签分类；图像分类；双视图对齐学习；分层提示。

## 作者单位与资助

本工作得到国家自然科学基金项目 62176030 和中央高校基本科研业务费项目 2023CDJYGRH-YB18 的部分资助。通讯作者为 Sheng Huang 和 Bo Liu。

Sheng Huang 任职于信息物理社会可信服务计算教育部重点实验室（中国重庆，400044），同时任职于重庆大学大数据与软件学院（中国重庆，400044）。电子邮件：huangsheng@cqu.edu.cn。

Jiexuan Yan 和 Beiyan Liu 任职于重庆大学大数据与软件学院（中国重庆，400044）。电子邮件：jiexuanyan@stu.cqu.edu.cn；beiyanliu@stu.cqu.edu.cn。

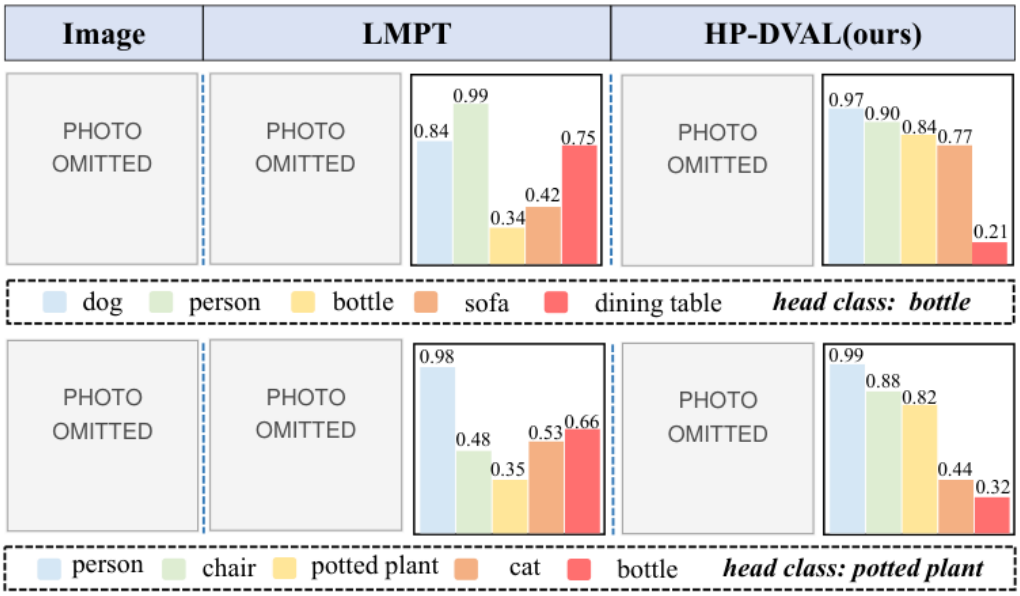
Bo Liu 和 Richang Hong 任职于合肥工业大学计算机与信息学院（中国合肥，230009）。电子邮件：kfliubo@gmail.com；hongrc@hfut.edu.cn。

## I 引言

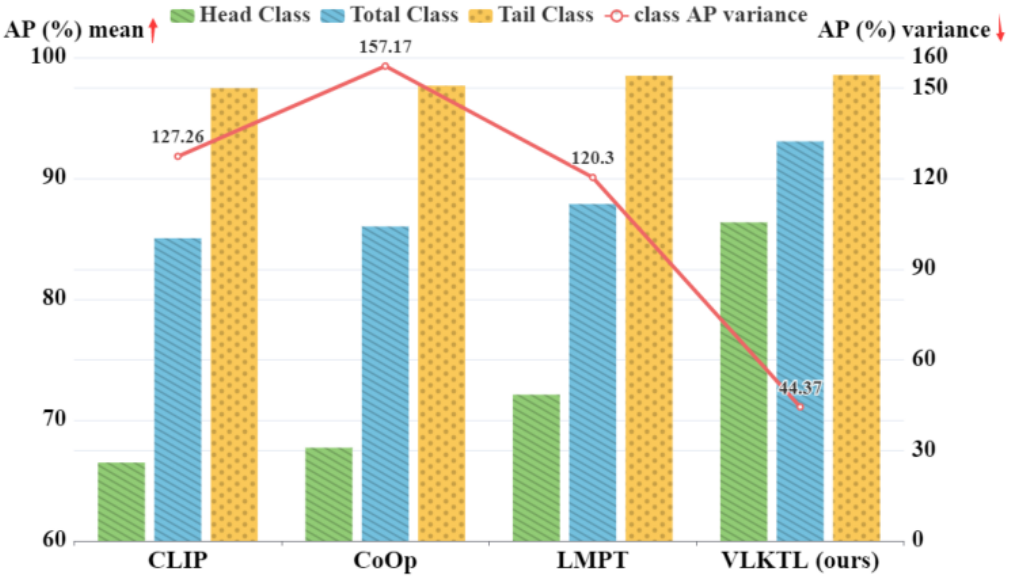
近年来，计算机视觉的发展极大地推动了图像分类的进步 [1]、[2]。这一进步在很大程度上依赖于许多主流的平衡基准（例如 CIFAR [3]、MS COCO [4]），这些基准具有两个关键特点：1）各类别均提供相对均衡且充足的样本；2）每个样本只属于一个类别。然而，在真实应用中，数据分布常呈类别不平衡模式 [5]-[7]。这种不平衡表现为长尾分布和小样本情形 [8]-[11]，深度网络在尾部类别或小样本类别上的表现往往欠佳。同时，与经典的单标签分类不同，实际场景经常涉及带有多个标签的图像 [12]-[14]，从而增加任务的复杂性和难度。为解决这些问题，越来越多的工作聚焦类别不平衡多标签图像分类（CI-MLIC）[15]-[18]。

由于尾部类别或小样本类别的样本相对稀缺，现有 CI-MLIC 方法主要通过各种策略处理样本不平衡，例如对各类别样本数重采样 [20]、[21]，对不同类别的损失重新加权 [16]、[22]、[23]，以及解耦表示学习 [24] 与分类头学习 [25]-[27]。近来，以 CLIP [28] 为代表的视觉语言预训练（VLP）模型展现了学习强大表示的能力，能够有效对齐图像与文本模态。在这些 VLP 模型中，文本模态数据的引入显著增强了跨类别知识迁移能力，减轻了类别不平衡分布在分类阶段的不利影响，从而改善整体性能。目前，这些 VLP 模型已成功适用于多种下游视觉任务，特别是通过提示调优方法 [29]-[31]：这些方法学习任务特定提示，而不是微调整个模型，从而高效迁移 VLP 知识。然而，应用于类别不平衡多标签学习时，现有提示调优方法往往显著偏向尾部类别，以牺牲头部类别性能为代价改善尾部类别 [19]，如图 1 所示。这种现象可以归因于所选尾部类别具有相对简单且易区分的特征，例如 [bus，公共汽车] 和 [horse，马]。相比之下，[bottle，瓶子] 和 [potted plant，盆栽] 等头部类别的目标尺寸较小，且类

内视觉变化较大，使模型难以捕获独特而一致的判别特征。此外，CLIP 的训练数据并未公开，因此 CLIP 在预训练阶段可能已经见过某些尾部类别的样本。这些已有知识降低了下游提示调优中学习这些类别的负担。




(a)




(b)

**图 1。** 在多标签长尾图像分类任务的 VOC-LT 数据集上，与已有提示调优方法的比较。（a）不同方法的可视化结果。LMPT [19] 等提示调优方法在不显著的头部类别（即 [bottle，瓶子] 和 [potted plant，盆栽]）上表现较差，而我们的 HP-DVAL 在所有类别上都取得了更好的性能。（b）不同类别的预测准确率（AP）均值和方差。提示调优方法往往显著偏向尾部类别，而 HP-DVAL 能够均衡地提高从头部到尾部所有类别的识别性能。

**图像省略与标签释义：** 图 1(a) 的两张原始照片和四张照片叠加热图因第三方图像权利未单独确认而省略；作者柱状图与标签保留。PHOTO OMITTED＝照片省略；Image＝图像；ours＝本文方法；head class＝头部类别；dog/person/bottle/sofa/dining table＝狗/人/瓶子/沙发/餐桌；chair/

potted plant/cat＝椅子/盆栽/猫。图 1(b) 中 Head/Total/Tail Class＝头部/全部/尾部类别，class AP variance＝类别 AP 方差。原图横轴将本文方法标为“VLKTL (ours)”，与正文命名不一致，保留原图。被省略面板见原文第 1 页。

此外，这些提示调优方法经常忽视两个关键方面，导致某些类别性能不佳。第一，包含多个目标类别的现实图像，通常需要提取类别特定特征才能准确识别，而类别不平衡的数据分布进一步加剧了特征解耦的难度。当前提示调优方法侧重于从全局角度表示图像，因此难以识别不显著的目标。第二，这些方法依赖通用提示模板（如“a photo of a [category]”，即“一张 [类别] 的照片”）或可学习提示，而没有针对类别不平衡多标签场景进行定制设计，因而提示缺乏图像所需的视觉上下文信息。换言之，这些方法通常假设图像中只存在一个类别；当类别数增加时，图文对齐便变得模糊。因此，这些提示无法准确描述图像内容，造成图像表示与文本表示不匹配，最终导致图文对齐性能不佳。

为解决上述问题，我们提出一种新的图文对齐方法，即面向 CI-MLIC 的分层提示双视图对齐学习（HP-DVAL）。HP-DVAL 从图像和文本两个模态迁移 CLIP 的视觉语言知识。在图像模态上，我们通过知识蒸馏，将 CLIP 泛化良好的视觉表示能力迁移至视觉编码器。为消除多目标引起的特征混合负面影响，我们同时在局部和全局视图中执行图文对齐。此外，在局部视图中只选择相似度最高的前 $k$ 个图像—文本词元对，以确保对齐准确。在文本模态上，我们提出分层提示调优策略，使 CLIP 更好地适应类别不平衡任务。该策略使用一组全局和局部提示来学习分层文本嵌入，潜在地编码任务特定及上下文相关的先验知识。另外，我们在提示调优中引入语义一致性损失，防止可学习提示遗忘 CLIP 内编码的通用知识。通过结合双视图对齐学习与分层提示调优，HP-DVAL 有效迁移 CLIP 的视觉语言知识，以应对 CI-MLIC 任务。

本工作的主要技术贡献如下：

- 我们提出了新的图文对齐方法 HP-DVAL，用于类别不平衡多标签图像分类（CI-MLIC）。HP-DVAL 同时在局部和全局视图进行图文对齐，完成多标签图像分类。双视图对齐缓解多标签学习中的特征混合问题，使模型能够识别不显著目标，从而更好地使 CLIP 适应类别不平衡任务。
- 我们引入分层提示调优策略来支持双视图图文对齐。该策略分别学习全局和局部文本嵌入，挖掘任务特定及上下文相关的先验知识，以促进对齐。此外，在提示调优中纳入语义一致性损失，防止可学习提示遗忘 CLIP 编码的通用知识。
- 我们在 MS-COCO 和 Pascal VOC 两个 CI-MLIC 基准上开展实验。多标签长尾及小样本图像分类任务的大量结果表明，本方法显著优于近期最先进的方法。实验还表明，与其他基于 CLIP 的方法相比，本方法在不同类别上的性能明显更均衡。

## II 相关工作

### A 类别不平衡学习

现实数据往往遵循类别不平衡分布。尾部或小样本类别的样本稀缺，给传统模型带来严峻挑战。应对长尾问题的常见方法包括直接重采样训练样本以平衡类别分布，但这可能导致尾部类别过拟合 [20]、[21]。另一种策略依据训练样本的标签频率重新加权损失，以重新平衡类别之间不均匀的正梯度 [22]、[23]、[33]。然而，这些方法仍会使模型学到有偏特征。对此，有研究 [34] 设计了多样性增强模块，融合所有类别的信息，防止对尾部类别过拟合；与此同时，MLC-NC [35] 从神经坍缩的视角切入，通过缩小类内差异提升模型表示能力。近来，研究者探索迁移学习 [6]、[27]、[36] 及自监督学习 [37]-[39]

等技术来处理长尾分布。鉴于 CLIP 等视觉语言预训练（VLP）模型表现出强大的图文匹配能力，一些策略将其适配至下游长尾学习任务 [40]-[42]。这些基于 VLP 的方法引入额外语言数据以生成辅助置信分数，在类别不平衡数据上微调基于 CLIP 的模型。与这些微调全部参数的方法不同，我们利用 CLIP 强大的表示能力来学习特征提取器，确保对 CI-MLIC 任务的适配既高效又有效。

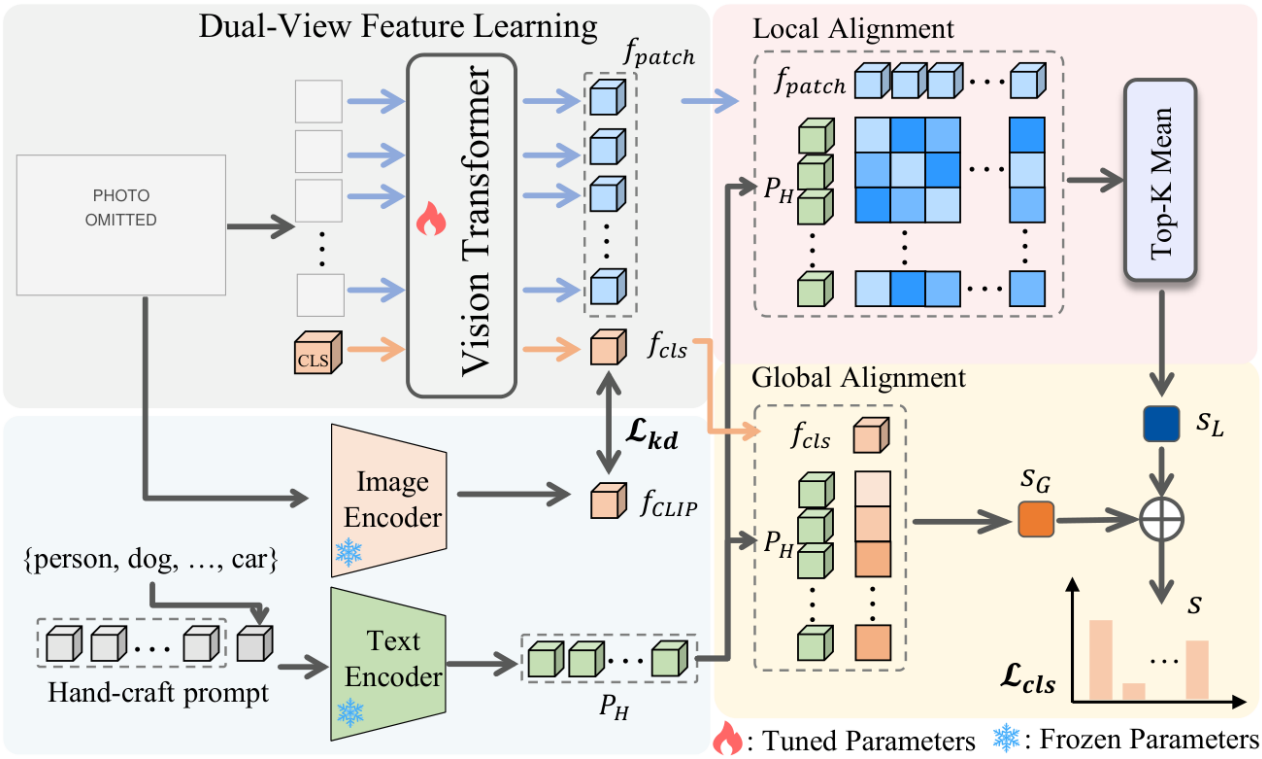



**图 2。** HP-DVAL 的架构采用两阶段训练策略。在双视图对齐学习阶段，我们以 CLIP 图像编码器为教师，利用知识蒸馏 [32] 训练视觉 Transformer。这一阶段包含双视图特征学习，以捕获全局和局部特征。随后，我们从全局和局部两个视图对齐图像嵌入与文本嵌入，并通过加权融合机制整合全局和局部预测。在分层提示调优阶段，我们利用相应的可学习全局和局部提示，挖掘与图像有关的通用上下文和任务特定知识。

**图像省略与标签释义：** 输入样例照片及其 4 个照片图块未转载；空白灰框仅表示省略，不代表模型中的空输入。作者绘制的其余流程结构与箭头保留。Dual-View Feature Learning＝双视图特征学习；Vision Transformer＝视觉 Transformer；Image/Text Encoder＝图像/文本编码器；Hand-craft prompt＝手工提示；Local/Global Alignment＝局部/全局对齐；Top-K Mean＝前 $k$ 项均值；Tuned/Frozen Parameters＝调优/冻结参数。被省略内容见原文第 3 页。

小样本学习是类别不平衡分布背景下的一类独特挑战：它需要在训练样本稀少的条件下预测新类别，因而特别强调预训练分类网络的迁移泛化能力。基于度量学习的方法 [43]-[48] 通常学习一个度量空间，通过测量未标记查询样本与支持样本之间的距离来分类。与此同时，基于元学习的方法 [49]-[53] 采用元学习范式，增强模型对小样本任务的适应能力。近来，CLIP [28] 等 VLP 模型展现出强大的零样本适应能力，已有大量策略将其适配于下游小样本任务 [29]、[30]、[54]、[55]。本文方法可以跨类别迁移 CLIP 泛化良好的视觉表示能力，改善小样本类别的性能。

### B 多标签图像分类

对于多标签图像分类（MLC）任务，早期方案为每个标签分别训练二元分类器 [56]。因此，近期研究通过利用类别语义建模标签间的语义关联来解决 MLC 问题 [57]、[58]。基于 CNN 的方法 [30]、[59]-[61] 使用循环神经网络（RNN）提取对标签依赖敏感的特征，隐式捕获这些依赖关系。随着 Transformer 在各种计算机视觉任务中的兴起，基于 Transformer 的方法 [62]-[65] 利用 Transformer [66] 的核心注意力机制探索标签相关性。然而，这些方法通常设计复杂，可能难以很好地泛化到类别不平衡场景。近年来，VLP 模型已被适配到下游 MLC 任务，以处理小样本和零样本问题 [12]、[67]-[71]。由于忽视了样本分布的不平衡，它们在长尾场景中泛化能力较差。

近年来，多标签场景中的长尾不平衡研究仍相对有限。类似于重新加权策略，文献 [15] 提出分布平衡（distribution-balanced，DB）损失，在二元交叉熵损失基础上减慢负标签的优化速率。基于 DB 损失，文献 [17] 旨在灵活调整训练概率，进一步缩小正负标签之间的概率差距。为使重采样策略适用于多标签场景，文献 [16] 在均匀采样和再平衡采样上采用协同训练，以缓解类别不平衡。此外，有提示调优方法 [19] 将预训练 CLIP 适配到长尾多标签学习。但该方法在提升尾部类别性能的同时，可能部分牺牲头部类别的性能。

另一方面，许多研究者尝试把小样本学习方法迁移到多标签场景。LaSO [72] 是第一个使用深度学习处理多标签小样本图像分类（ML-FSIC）问题的方法。LaSO 对类别级特征执行交集、并集和差集运算，针对监督信息不足采用数据增强策略。KGGR [8] 将图结构扩展到小样本领域，引入图神经网络（GNN）更新共现概率图，并在视觉嵌入与标签嵌入之间加入双线性插值注意力，以有效建模标签依赖。元学习方法 [73] 探索了如何在元训练范式下，将原型网络 [43] 和关系网络 [44] 等经典小样本方法从单标签扩展到多标签设置。这些方法缺乏针对多标签小样本设置的专门设计，因而性能欠佳。为建模稀有类别之间的标签关联，文献 [9] 探索了基于度量的多标签小样本原型网络：利用交叉注意力机制，提取每个标签嵌入对应的视觉原型，并测量每个视觉原型与全局特征之间的距离。然而，这种交叉注意力方法缺乏对原型的有效调整。本文结合双视图对齐学习和分层提示调优，迁移 CLIP 的多模态 [74] 预训练知识，在 CI-MLIC 的头部至尾部类别以及小样本类别识别中均取得更好性能。

## III 方法

**概述**。 本节介绍我们提出的两阶段方法 HP-DVAL。该方法将 CI-MLIC 表述为图文对齐问题，从而加以解决。它能够有效地在类别之间迁移 CLIP 的预训练知识，减轻类别不平衡的不利影响。方法包含两个关键阶段，即双视图对齐学习阶段与分层提示调优阶段。模型优化时，这两个阶段按顺序训练。采用两阶段策略的原因是，同时优化特征提取器和分层提示，会使可学习提示难以收敛。

第一阶段，我们通过知识蒸馏 [32]，从 CLIP 图像编码器训练视觉 Transformer（ViT）[66]，促进图文对齐，如图 2 所示。为应对图像中存在多个类别的情况，我们采用双视图特征学习提取视觉特征，并从全局和局部两个视图引入图文对齐。第二阶段，类似于视觉特征，我们引入两类可训练提示（即全局提示和局部提示），构成用于模型微调的分层提示，如图 3 所示。分层提示经过专门设计，旨在挖掘与图像相关的通用上下文及任务特定知识，使 CLIP 能够生成更准确的文本嵌入，增强图文对齐。此外，我们引入语义一致性损失，防止可学习提示遗忘 CLIP 编码的通用知识。

### A 视觉 Transformer 中的双视图特征学习

本方法采用视觉 Transformer（ViT）[66] 作为提取视觉特征的骨干。在多标签图像分类中，ViT 提取的全局特征往往混合了图像内多个类别的视觉信息。这种混合可能使主要目标主导全局特征，从而抑制对图像中共存的不显著目标的识别。为解决这一问题，我们在 ViT 内采用双视图特征学习，从全局和局部视图提取视觉表示。全局视图捕获图像的综合表示，编码不同类别之间的相关性；局部视图则聚焦细粒度特征，以实现准确的图文对齐。

给定输入图像 $x$，首先将其重塑为展平的二维图块序列 $x_p \in \mathbb{R}^{N\times(P^2\cdot C)}$。这里，$(P,\ P)$ 表示每个图块的分辨率，$N$ 是生成的图块数，$C$ 是通道数。随后，通过线性投影将图块 $x_p$ 映射为图块嵌入 $\bar{x}_p \in \mathbb{R}^{N\times D}$，其中 $D$ 是嵌入维度。ViT 第 $l$ 个块的处理过程为：

$$\begin{aligned} z_0 &= \left[x_{\text{class}};\ \bar{x}_p\right] + E_{\text{pos}}, \\ z'_l &= z_{l-1} + \text{MSA}\left(\text{LN}\left(z_{l-1}\right)\right), \\ z_l &= z'_l + \text{MLP}\left(\text{LN}\left(z'_l\right)\right). \end{aligned} \qquad (1)$$

其中，$x_{\text{class}}$ 为类别词元嵌入，$E_{\text{pos}}$ 为位置嵌入。ViT 经 $L$ 个块后的输出为 $z_L = \left[f_{\text{cls}};\ f_{\text{patch}}\right]$，其中 $f_{\text{cls}}$ 为类别词元特征（全局特征），$f_{\text{patch}} = \left[f_1,\ f_2,\ \ldots,\ f_N\right]$ 为图块词元特征（局部特征）。接着，这些特征通过嵌入层映射到嵌入空间，与 CLIP 文本嵌入对齐。双视图特征嵌入分别记为 $\bar{f}_{\text{cls}}$ 和 $\bar{f}_{\text{patch}} = \left[\bar{f}_1,\ \bar{f}_2,\ \ldots,\ \bar{f}_N\right]$。

### B 蒸馏式双视图图文对齐

与 CLIP 的图像编码器不同，原始 ViT 不具备内在的视觉语言知识迁移能力。因此，我们希望基于 CLIP 的预训练图像编码器进行知识蒸馏 [32]，赋予 ViT 这种能力，促进后续图文对齐。之所以不直接使用 CLIP 图像编码器，是因为 CLIP 在训练时以对比学习进行类别分类，这本质上类似于标准多类分类任务，而非多标签分类任务。因此，CLIP 模型不可避免地对次要类别分配较少注意力。此外，尽管 CLIP 原始图像编码器具有视觉语言对齐能力，其预训练数据对类别不平衡数据集中的长尾类别可能覆盖不足。与仅聚焦文本提示的既有提示调优方法 [29]-[31] 不同，我们通过知识蒸馏 [32] 从 CLIP 图像编码器迁移其稳健知识，增强 ViT 提取的图像嵌入与对应文本嵌入之间的对齐。

具体而言，将 CLIP 图像编码器 $\text{Enc}_I$ 作为教师模型，将 ViT 骨干作为学生模型。提取 CLIP 图像嵌入 $f_{\text{CLIP}}$，并在全局特征 $f_{\text{cls}}$ 上执行蒸馏，因为 $f_{\text{cls}}$ 和 $f_{\text{CLIP}}$ 均对应于 [CLS] 词元。蒸馏损失 $\mathcal{L}_{\text{kd}}$ 通过最小化二者的 $L_1$ 距离定义：

$$\mathcal{L}_{\text{kd}} = \parallel f_{\text{CLIP}} - f_{\text{cls}} \parallel_1, \qquad f_{\text{CLIP}} = \text{Enc}_I(x). \qquad (2)$$

在双视图对齐学习阶段，使用手工模板“a photo of a [CLASS]”（一张 [类别] 的照片）作为输入提示，从文本编码器 $\text{Enc}_T$ 提取文本嵌入。这些固定提示 $T^H = \{t_1^H,\ t_2^H,\ \ldots,\ t_c^H\}$ 为每个类别 $i$ 生成文本嵌入 $P_i^H$：

$$P_i^H = \text{Enc}_T\left(t_i^H\right), \qquad P_i^H \in \mathbb{R}^{1\times D_e}. \qquad (3)$$

其中， $c$ 为类别数， $D_e$ 为文本嵌入维度。在嵌入空间中，我们将文本嵌入 $P^H$ 与双视图图像嵌入 $\bar{f}_{\text{cls}}$ 和 $\bar{f}_{\text{patch}}$ 进行双视图对齐，计算全局及局部预测分数：

$$\begin{aligned} s_i^G &= \langle P_i^H, \bar{f}_{\text{cls}} \rangle, \quad i \in \{1, \ldots, c\}, \\ s_{ij}^L &= \langle P_i^H, \bar{f}_j \rangle, \quad j \in \{1, \ldots, N\}. \end{aligned} \tag{4}$$

其中， $\bar{f}_j$ 为第 $j$ 个图块特征嵌入， $\langle \cdot, \cdot \rangle$ 表示余弦相似度。类别 $i$ 的最终预测分数 $s_i$ 通过加权融合机制整合全局和局部预测：

$$s_i = \alpha s_i^G + (1 - \alpha)\text{TopK}\left(s_{i1}^L, s_{i2}^L, \ldots, s_{iN}^L\right). \tag{5}$$

其中， $\text{TopK}(\cdot)$ 是前 $k$ 项均值池化，即关注最相关的前 $k$ 个局部预测； $\alpha \in [0, 1]$ 为双视图对齐融合的权重因子。采用前 $k$ 项均值池化的核心目的，是选择与文本提示最相关、响应最高的前 $k$ 个图块。这不仅抑制噪声干扰，还使模型聚焦特定类别，从而增强其细粒度匹配能力。

## C 分层提示调优

基于手工模板的固定提示忽略了对应图像所固有的上下文信息，可能为双视图对齐产生次优文本嵌入。因此，类似于以往提示调优方法，我们旨在学习任务特定提示。与 CoOp [30] 使用的单层提示不同，我们提出分层提示调优策略，使用两组可学习提示（全局提示与局部提示），从 CLIP 导出全局和局部文本嵌入，如图 3 所示。全局提示用于编码综合的任务特定先验知识，局部提示则在训练期间聚焦捕获上下文相关的先验知识。

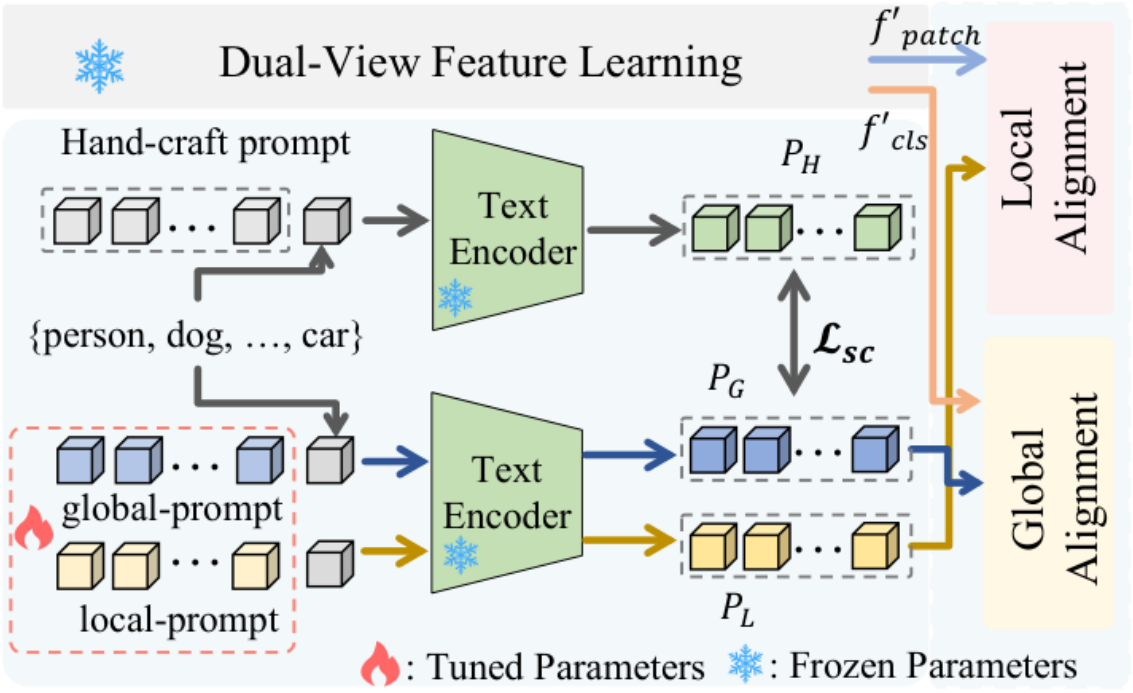



**图 3。** 分层提示调优阶段。我们引入一系列全局和局部提示，编码任务特定及上下文相关的先验知识，同时引入语义一致性损失，使 CLIP 更好地适应 CI-MLIC 任务。

**标签释义：** global-prompt/local-prompt＝全局提示/局部提示；其余英文模块名称同图 2。图中模块及连接按原图保留。

遵循 CoOp [30]，分层提示定义为：

$$\begin{aligned} t_i^G &= [v_1, v_2, \ldots, v_M, w_i], \\ t_i^L &= [v'_1, v'_2, \ldots, v'_M, w_i]. \end{aligned} \tag{6}$$

其中，$v_k$ 和 $v'_k$（$k \in \{1, \ldots, M\}$）为可学习嵌入，与第 $i$ 类的词嵌入 $w_i$ 拼接，构成全局提示 $t_i^G$ 和局部提示 $t_i^L$。这些提示输入 CLIP 文本编码器 $\mathrm{Enc}_T$，生成全局与局部文本嵌入 $P_i^G$ 和 $P_i^L$：

$$\begin{aligned} P_i^G &= \mathrm{Enc}_T\left(t_i^G\right), \quad P_i^G \in \mathbb{R}^{1\times D_e}, \\ P_i^L &= \mathrm{Enc}_T\left(t_i^L\right), \quad P_i^L \in \mathbb{R}^{1\times D_e}. \end{aligned} \tag{7}$$

在分层提示调优阶段，冻结 ViT 参数，从输入图像提取双视图图像嵌入 $\bar{f}'_{\mathrm{cls}}$ 和 $\bar{f}'_{\mathrm{patch}}$。随后，将学得的文本嵌入与双视图图像嵌入对齐，分别计算全局和局部预测分数：

$$\begin{aligned} s_i'^G &= \langle P_i^G, \bar{f}'_{\mathrm{cls}} \rangle, \quad i \in \{1, \ldots, c\}, \\ s_{ij}'^L &= \langle P_i^L, \bar{f}'_j \rangle, \quad j \in \{1, \ldots, N\}. \end{aligned} \tag{8}$$

其中，$\bar{f}'_j$ 为第 $j$ 个图块特征嵌入，$\langle \cdot, \cdot \rangle$ 表示余弦相似度。采用与式（5）相同的加权融合机制得到最终预测分数：

$$s'_i = \alpha s_i'^G + (1-\alpha)\mathrm{TopK}\left(s_{i1}'^L, s_{i2}'^L, \ldots, s_{iN}'^L\right). \tag{9}$$

其中，$\mathrm{TopK}(\cdot)$ 为前 $k$ 项均值池化，即关注最相关的前 $k$ 个局部预测，$\alpha \in [0, 1]$ 是双视图对齐融合的权重因子。

在提示初始化阶段，这两类分层提示具有相似的结构参数，但其学习目标在模型优化过程中显著分化。全局提示特征与全局视觉特征对齐，强调模型的整体性能。然而，全局特征包含多个类别的信息，使模型常常难以有效聚焦某个特定类别。相比之下，局部提示特征与局部视觉特征对齐，聚焦具有高激活响应的图块。虽然这些图块所含信息相对有限，但其内容高度类别特定且显著，从而增强模型进行细粒度匹配的能力。总体而言，全局提示旨在捕获任务特定的全局语义知识，局部提示则用于学习与视角相关上下文相联系的语义知识。

但是，可学习提示容易对稀少样本过拟合，并遗忘 CLIP 中编码的通用知识。为缓解此问题，我们引入语义一致性（semantic consistency，SC）损失，在可学习提示与固定提示之间施加泛化约束。具体而言，SC 损失 $\mathcal{L}_{\mathrm{sc}}$ 通过最小化 $P_H$ 与 $P_G$ 之间的 $L_1$ 距离定义：

$$\mathcal{L}_{\mathrm{sc}} = \| P_H - P_G \|_1. \tag{10}$$

## D 模型优化

给定输入图像 $x_i$，模型预测最终类别概率 $S_i = \{s_i^1, s_i^2, \ldots, s_i^c\}$，其真实标签为 $Y_i = \{y_i^1, y_i^2, \ldots, y_i^c\}$。为处理标签共现和负标签占主导的问题，我们采用分布平衡（DB）损失 [15] 作为分类损失，其定义为：

$$r_i = \tau + \frac{1}{1 + e^{-\beta\left(\frac{1/n_i}{\sum_{i=1}^{c} 1/n_i} - \mu\right)}}. \tag{11}$$

$$\upsilon_i = -\kappa \times -\log\left(\frac{1}{n_i/n} - 1\right). \tag{12}$$

$$\mathcal{L}_{\mathrm{DB}} = \frac{1}{c}\sum_{i=0}^{c} r_i[\ y_i \log\left(1 + e^{-(s_i - \upsilon_i)}\right) + \frac{1}{\lambda}\left(1 - y_i\right)\log\left(1 + e^{\lambda\left(s_i - \upsilon_i\right)}\right)]. \tag{13}$$

其中， $\tau$ 控制权重的整体提升， $\beta$ 和 $\mu$ 控制映射函数的形状。 $r_i$ 为第 $i$ 类的再平衡权重， $\upsilon_i$ 为类别特定偏置， $\kappa$ 和 $\lambda$ 为 DB 损失的缩放因子。为进一步缓解文本提示微调 [29]-[31] 导致的头部类别性能显著下降，我们引入正样本类别加权，旨在为头部类别提供更大的梯度值。修改 DB 损失的正类部分后，最终分类损失定义为：

$$w_i = \frac{n_i/n}{\max\left(n_i/n\right)}. \tag{14}$$

$$\mathcal{L}_{\mathrm{cls}} = \mathcal{L}_{\mathrm{DB}^*} = \frac{1}{c}\sum_{i=0}^{c} r_i[\ y_i \log\left(1 + e^{-w_i\left(s_i - \upsilon_i\right)}\right) + \frac{1}{\lambda}\left(1 - y_i\right)\log\left(1 + e^{\lambda\left(s_i - \upsilon_i\right)}\right)]. \tag{15}$$

其中， $\max(\cdot)$ 表示最大类别权重。

**公式译注：** 式（11）的求和下标和式（13）、（15）的 $i = 0$ 起点按原文保留；式（12）的两个负号亦按原文保留。原文式（13）、（15）的末项对数括号未闭合，本译本仅补齐排版所需的右括号，不改变运算项或符号。原文此处未单独定义 $n_i$ 、 $n$ ，译文不补写为原作者定义。

模型优化时顺序训练两个阶段。在双视图对齐学习阶段，由冻结的文本编码器根据固定提示生成文本嵌入，视觉 Transformer 以分类损失和蒸馏损失为目标进行训练：

$$\mathcal{L}_1 = \mathcal{L}_{\mathrm{cls}} + \mathcal{L}_{\mathrm{kd}}. \tag{16}$$

在分层提示调优阶段，冻结 ViT 参数，仅以分类损失和语义一致性损失为目标微调分层可学习提示：

$$\mathcal{L}_2 = \mathcal{L}_{\mathrm{cls}} + \mathcal{L}_{\mathrm{sc}}. \tag{17}$$

推理时，使用训练好的 ViT 获取图像嵌入，并通过学得的分层提示，从 CLIP 文本编码器生成文本嵌入。然后，分别从全局与局部视图计算图像嵌入和文本嵌入的余弦相似度，通过加权融合机制得到最终分类分数。

# IV 实验与结果

## A 数据集与实验设置

**1）长尾多标签图像分类任务的数据集。** 遵循文献 [15] 的设置，我们在 VOC-LT 和 COCO-LT 两个数据集上进行长尾多标签图像分类实验。这两个数据集分别从广泛使用的多标签图像识别基准 Pascal VOC [75] 和 MS-COCO [4] 中人工采样得到。VOC-LT 根据文献 [15] 的指导，从 Pascal VOC 的 2012 训练—验证集构建。训练集包含 1,142 张图像，标注了 20 个类别。各类别图像数介于 4 至 775 之间。为模拟长尾分布，依据每类训练样本数，将所有类别分为三组：头部类别（超过 100 个样本）、中部类别

（20 至 100 个样本）和尾部类别（少于 20 个样本）。划分后，头部、中部和尾部类别数量比为 6:6:8。我们使用含 4,952 张图像的 VOC 2007 测试集评估模型性能。同样，COCO-LT 通过类似方法从 MS-COCO 2017 数据集构建。其训练集包含 1,909 张图像，标注了 80 个类别；各类别图像数从 6 至 1,128 不等。COCO-LT 中头部、中部、尾部类别数量比设为 22:33:25。性能评估在包含 5,000 张图像的 MS-COCO 2017 测试集上进行。

**2）多标签小样本图像分类任务的数据集。** 对于多标签小样本图像分类任务，主要在 MS-COCO [4] 和 PASCAL VOC 2007 [75] 上开展实验；两者均为广泛使用的多标签图像识别基准。为保证实验结果可比，采用 LaSO [72] 提供的 COCO 小样本划分策略。具体而言，将 80 类划分为 64 个基础类别和 16 个新类别：自行车（bicycle）、船（boat）、停车标志（stop sign）、鸟（bird）、背包（backpack）、飞盘（frisbee）、单板滑雪板（snowboard）、冲浪板（surfboard）、杯子（cup）、叉子（fork）、勺子（spoon）、西兰花（broccoli）、椅子（chair）、键盘（keyboard）、微波炉（microwave）和花瓶（vase）。我们纳入 COCO 2014 训练集和验证集中的图像，$D_{\text{base}}$ 的训练集与 $D_{\text{novel}}$ 的支持集没有重叠。对于 VOC 2007，遵循文献 [9]，将 20 个标签划分为 $C_{\text{base}}$ 的 14 个标签和 $C_{\text{novel}}$ 的 6 个标签，后者为猫（cat）、狗（dog）、盆栽（pottedplant）、绵羊（sheep）、沙发（sofa）和电视监视器（tvmonitor）。与 COCO 一样，采样 10 个任务回合（episodes），支持集中每个新类别仅出现 $K$ 次，其中 $K \in \{1,\ 5\}$。

**3）实现细节。** 使用在 ImageNet-1K 上预训练的 ViT-B/16 作为视觉 Transformer。特征学习的嵌入层由两个线性层组成。对于 VLP 模型，选择图像编码器为 ViT-B/16 的预训练 CLIP。ViT-B/16 的图块投影针对分辨率 $224\times224$ 的图像生成 $14\times14 = 196$ 个图块。前 $k$ 项均值池化的 $k$ 设为 32，双视图对齐权重 $\alpha$ 设为 0.4。对于分层可学习提示，采用共享提示，将每个参数初始化为从 $\mathcal{N}(0,\ 0.02)$ 采样的高斯噪声。在实验中，全局和局部提示的序列长度均为 $M = 4$，因为增加该长度只带来微小提升。DB 损失中的其他超参数与文献 [15] 相同。

第一阶段使用 AdamW [76] 优化器，基础学习率为 $10^{-5}$，权重衰减为 $10^{-4}$。第二阶段，将 AdamW 的基础学习率调整为 $5\times10^{-6}$，用于微调可学习提示。第一阶段以批大小 32 训练 20 个 epoch，第二阶段训练 10 个 epoch。所有实验均在一张 Nvidia RTX-3090 GPU 上进行，模型用 PyTorch 1.12.0 实现。

## B 评估指标

对于长尾多标签图像分类任务，依据训练样本数，将两个数据集中的类别分为头部、中部和尾部三组。具体而言，头部类别的样本数超过 100，中部类别每类有 20 至 100 个样本，尾部类别每类少于 20 个样本。我们使用平均精度均值（mAP）及所有类别预测准确率（AP）的方差（var.）作为评估指标，衡量模型在所有类别上的长尾多标签视觉识别性能。对于多标签小样本图像分类，采用 1-shot 和 5-shot 设置下的 mAP 评估性能。

计算 mAP 时，首先计算每个类别 $c$ 的平均精度（AP）：

$$AP_c = \frac{\sum_{n=1}^{N} \text{Precision}\,(n,\ c)\cdot\text{rel}\,(n,\ c)}{N_c}. \qquad (18)$$

其中， $\text{Precision}(n,\ c)$ 表示检索预测分数排名最高的 $n$ 个样本时类别 $c$ 的精确率； $\text{rel}(n,\ c)$ 为指示函数：若排名第 $n$ 的图像含类别 $c$，则为 1，否则为 0。 $N_c$ 为类别 $c$ 的正样本数。然后计算 mAP：

$$mAP = \frac{1}{C}\sum_{c=1}^{C} AP_c. \qquad (19)$$

其中， $C$ 为类别数量。

## C 实验结果

**1）长尾多标签图像分类结果。** 为验证方法的有效性，我们在长尾多标签图像分类任务上，与此前最先进的方法进行比较。比较方法包括：经验风险最小化（ERM），按类别频率平方根的倒数加权的平滑重新加权（RW），ML-GCN [77]、OLTR [6]、LDAM [23]、类别平衡（CB）Focal [22]、BBN [26]、分布平衡（DB）Focal [15]、ASL [78]、LTML [16]、Stitch-Up [18]、CDRS+AFL [79]、Bilateral-TPS [80]、CAE-Net [81]、PG Loss [17] 和 COMIC [82]。我们也将 HP-DVAL 与 CoOp [30]、CoCoOp [29] 和 LMPT [19] 等既有提示调优方法比较。遵循文献 [15] 的设置，在 VOC-LT 和 COCO-LT 两个长尾数据集上开展实验；二者分别从 VOC 和 MS-COCO 人工采样得到。

表 I 给出长尾多标签图像分类结果。实验表明，我们的方法显著优于既有方法。具体而言，HP-DVAL 在 VOC-LT 和 COCO-LT 上的总体 mAP 分别达到 93.06% 和 76.19%。相较于此前最先进的 LMPT，HP-DVAL 在 VOC-LT 和 COCO-LT 上的总体 mAP 分别提高约 5.18% 和 10.0%。此外，HP-DVAL 在头部、中部和尾部三个类别子集上均表现出色，头部类别的提升尤其明显：原文称，相比 LMPT，在 COCO-LT 和 VOC-LT 上分别提高 14.26% 和 27.16%。**译注：此处原文的数据集顺序与表 I 相反；按表中差值，VOC-LT 为 14.26，COCO-LT 为 27.16。** 与偏向尾部类别的既有提示调优方法相比，本方法在改善尾部性能的同时，显著提升头部类别性能。我们将其归因于先前提示调优方法未能设计考虑长尾分布的任务特定提示，导致提示缺乏必要的图像视觉上下文信息。此外，本方法取得所有类别预测准确率的最小方差，意味着 HP-DVAL 能均衡地提升从头部至尾部所有类别的识别性能。这些结果充分证明，HP-DVAL 能够在长尾多标签学习中同步提升头尾类别性能。

**表 I。** HP-DVAL 与比较方法在两个多标签图像分类数据集长尾设置下的 mAP（%）结果。指标包括总体、头部、中部和尾部类别的 mAP，以及所有类别 AP 的方差（var.）。粗体为最优，下划线为次优；↑ 越高越好，↓ 越低越好。为保证可读性，原表按数据集拆为两部分，数值未改动。CLIP:ViT16 分组以下方法使用该骨干。

**表 I(a) VOC-LT**

| 方法 | 总体 ↑ | 头部 ↑ | 中部 ↑ | 尾部 ↑ | 方差 ↓ |
|---|---|---|---|---|---|
| ERM | 70.86 | 68.91 | 80.20 | 65.31 | 51.72 |
| RW | 74.70 | 67.58 | 82.81 | 73.96 | 47.01 |
| ML-GCN [77] | 68.92 | 70.14 | 76.41 | 62.39 | 46.14 |
| OLTR [6] | 71.02 | 70.31 | 79.80 | 64.95 | 50.02 |
| LDAM [23] | 70.73 | 68.73 | 80.38 | 69.09 | 48.96 |

| 方法 | 总体 ↑ | 头部 ↑ | 中部 ↑ | 尾部 ↑ | 方差 ↓ |
|---|---|---|---|---|---|
| CB Focal [22] | 75.24 | 70.30 | 83.53 | 72.74 | 52.04 |
| BBN [26] | 73.37 | 71.31 | 81.76 | 68.62 | 53.07 |
| DB Focal [15] | 78.94 | 73.22 | 84.18 | 79.30 | 49.06 |
| ASL [78] | 76.40 | 70.70 | 82.26 | 76.29 | 51.11 |
| LTML [16] | 81.44 | 75.68 | 85.53 | 82.69 | 46.42 |
| Stitch-Up [18] | 76.48 | 67.85 | 80.87 | 79.67 | 53.89 |
| CDRS+AFL [79] | 78.96 | 73.35 | 85.03 | 78.63 | 51.62 |
| Bilateral-TPS [80] | 81.58 | 75.88 | 84.11 | 83.95 | 44.65 |
| CAE-Net [81] | 81.61 | 74.00 | 85.35 | 85.28 | 48.28 |
| PG Loss [17] | 80.37 | 73.67 | 83.83 | 82.88 | 50.61 |
| COMIC [82] | 81.53 | 73.10 | 89.18 | 84.53 | 53.73 |
| **CLIP:ViT16** | | | | | |
| 零样本 CLIP | 85.05 | 66.48 | 87.08 | 97.46 | 127.26 |
| CoOp [30] | 86.02 | 67.71 | 88.79 | 97.67 | 157.17 |
| CoCoOp [29] | 84.47 | 64.58 | 87.82 | 96.88 | 182.46 |
| LMPT [19] | 87.88 | 72.10 | 89.26 | 98.49 | 120.30 |
| HP-DVAL（本文） | **93.06** | **86.36** | **92.83** | **98.58** | **44.37** |

### 表 I(b) COCO-LT

| 方法 | 总体 ↑ | 头部 ↑ | 中部 ↑ | 尾部 ↑ | 方差 ↓ |
|---|---|---|---|---|---|
| ERM | 41.27 | 48.48 | 49.06 | 24.25 | 129.84 |
| RW | 42.27 | 48.62 | 45.80 | 32.02 | 59.68 |
| ML-GCN [77] | 44.24 | 44.04 | 48.36 | 38.96 | 55.92 |
| OLTR [6] | 45.83 | 47.45 | 50.63 | 38.05 | 59.51 |
| LDAM [23] | 40.53 | 48.77 | 48.38 | 22.92 | 142.79 |
| CB Focal [22] | 49.06 | 47.91 | 53.01 | 44.85 | 62.49 |
| BBN [26] | 50.00 | 49.79 | 53.99 | 44.91 | 64.86 |
| DB Focal [15] | 53.55 | 51.13 | 57.05 | 51.06 | 58.71 |
| ASL [78] | 50.21 | 49.05 | 53.65 | 46.68 | 59.26 |
| LTML [16] | 56.90 | 54.13 | 60.59 | 54.47 | 61.55 |
| Stitch-Up [18] | 54.14 | 59.80 | 51.53 | 51.27 | 64.20 |
| CDRS+AFL [79] | 55.35 | 52.45 | 59.48 | 52.46 | 62.11 |

| 方法 | 总体 ↑ | 头部 ↑ | 中部 ↑ | 尾部 ↑ | 方差 ↓ |
|---|---|---|---|---|---|
| Bilateral-TPS [80] | 56.38 | 55.93 | 58.26 | 54.29 | 62.92 |
| CAE-Net [81] | 57.64 | 52.37 | 61.18 | 57.63 | 62.97 |
| PG Loss [17] | 54.43 | 51.23 | 57.42 | 53.40 | 56.92 |
| COMIC [82] | 55.08 | 49.21 | 60.08 | 55.36 | 59.77 |
| **CLIP:ViT16** | | | | | |
| 零样本 CLIP | 60.17 | 38.52 | 65.06 | 72.28 | 184.57 |
| CoOp [30] | 60.68 | 41.97 | 63.18 | 73.85 | 153.05 |
| CoCoOp [29] | 61.49 | 39.81 | 64.63 | 76.42 | 202.98 |
| LMPT [19] | 66.19 | 44.89 | 69.80 | 79.08 | 181.95 |
| HP-DVAL（本文） | **76.19** | **72.05** | **75.98** | **79.12** | **54.91** |

**2）多标签小样本图像分类结果。** 对多标签小样本任务，将 HP-DVAL 与此前的小样本方法比较，包括 LaSO [72]、ML-FSL [73]、KGGR [8]、WAGP [9]、BCR [83] 和 LCM [9]。此外，还与只使用文本数据训练、并与 CoOp [30] 集成的基于 CLIP 的方法比较，即 TAI-DPT [68]、CoMC [85] 和 PVP [69]。MS-COCO 和 VOC 2007 上的实验结果见表 II。可以看出，HP-DVAL 大幅优于最先进的小样本方法：在 MS-COCO 的 1-shot、5-shot 设置下，mAP 分别提升 9.3% 和 5.3%；另外两项提升为 27.9% 和 23.7%。**译注：原文此处再次写为 MS-COCO，按表 II 对应 VOC2007；正文将 LCM 引为 [9]，表 II 引为 [84]，均保留原文对应关系。** 我们将性能提升归因于本方法有效增强了 CLIP 的跨类别知识迁移能力。此外，相比基于 CLIP 的方法，HP-DVAL 在两个数据集上仍具有一定性能优势，最大提升为 MS-COCO 的 5-shot 设置下 6.8% mAP。这些结果充分表明，HP-DVAL 能在类别不平衡学习中显著改善小样本类别识别。

**表 II。** 在 VOC2007 和 MS-COCO 上，本文方法与最先进多标签小样本图像分类方法的 mAP（%）比较。粗体为最优，下划线为次优。

| 方法 | VOC 1-shot | VOC 5-shot | COCO 1-shot | COCO 5-shot |
|---|---|---|---|---|
| LaSO [72] | 47.9 | 59.1 | 45.3 | 58.1 |
| ML-FSL [73] | 50.2 | 60.4 | 54.4 | 63.6 |
| KGGR [8] | 49.4 | 61.0 | 52.3 | 63.5 |
| NLC [73] | 53.3 | 60.8 | 56.8 | 64.8 |
| WAGP [9] | 53.3 | 69.3 | 55.7 | 68.2 |
| BCR [83] | 59.8 | 66.7 | 63.7 | 72.2 |
| LCM [84] | 62.9 | 71.7 | 64.2 | 73.9 |
| **CLIP:ViT16** | | | | |
| CoOp [30] | 79.3 | 83.8 | 52.6 | 58.1 |

| 方法 | VOC 1-shot | VOC 5-shot | COCO 1-shot | COCO 5-shot |
|---|---|---|---|---|
| TaI-DPT [68] | 83.2 | 88.2 | 65.8 | 67.6 |
| CoMC [85] | 89.7 | 90.6 | 68.9 | 70.4 |
| PVP [69] | 90.1 | 92.5 | 70.9 | 72.4 |
| HP-DVAL（本文） | **90.8** | **95.4** | **73.5** | **79.2** |

## D 消融研究

**1）多标签分类损失。** 为缓解提示微调引起的头部类别性能显著下降，我们修改原始分布平衡损失的正类部分。本节比较用于优化 HP-DVAL 的多种分类损失，包括二元交叉熵损失（BCE）、多标签软间隔损失（MSL）、类别平衡焦点损失（CB Focal）[22]、非对称损失（ASL）[78]、DB Focal [15] 和本文分类损失（记为 $\mathrm{DB}^*$）。表 III 列出 COCO-LT 上的比较结果。结果表明，在 CI-MLIC 任务中，$\mathrm{DB}^*$ 始终优于其他分类损失。相较原始 DB 损失，$\mathrm{DB}^*$ 显著改善头部类别性能，提高 2.33%。这种优势可归因于其纳入正样本类别加权并处理负标签占主导的问题，而其他损失未充分应对这一关键方面。

**表 III。** HP-DVAL 在 COCO-LT 上使用不同多标签图像分类损失时的 mAP（%）。$\mathrm{DB}^*$ 表示本文分类损失。原表将多标签软间隔损失写为 MLS，正文写为 MSL；此处保留原表缩写。

| 损失函数 | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|
| BCE | 69.58 | 66.71 | 69.46 | 71.59 |
| MLS | 71.85 | 68.33 | 71.53 | 74.46 |
| CB Focal | 72.39 | 68.80 | 72.26 | 74.89 |
| ASL | 74.23 | 69.85 | 73.92 | 77.39 |
| DB Focal | 75.16 | 69.72 | 75.52 | 78.50 |
| DB*（本文） | **76.19** | **72.05** | **75.98** | **79.12** |

为进一步验证本方法的性能提升并非来自 DB 损失本身的优势，我们比较不同方法在 BCE 损失和 DB 损失 [15] 下的实验结果。表 IV 给出 COCO-LT 结果。可以看出，即使不使用 DB 损失，本方法在总体和头部类别 mAP 上仍优于所有已有方法，尤其头部 mAP 提高 21.22%。进一步结合 DB 损失，可以改善尾部类别性能，从而改善整体类别分布的预测。这些结果充分说明，HP-DVAL 并不依赖 DB 损失来同步提升头尾类别性能；DB 损失主要帮助进一步改善尾部类别。

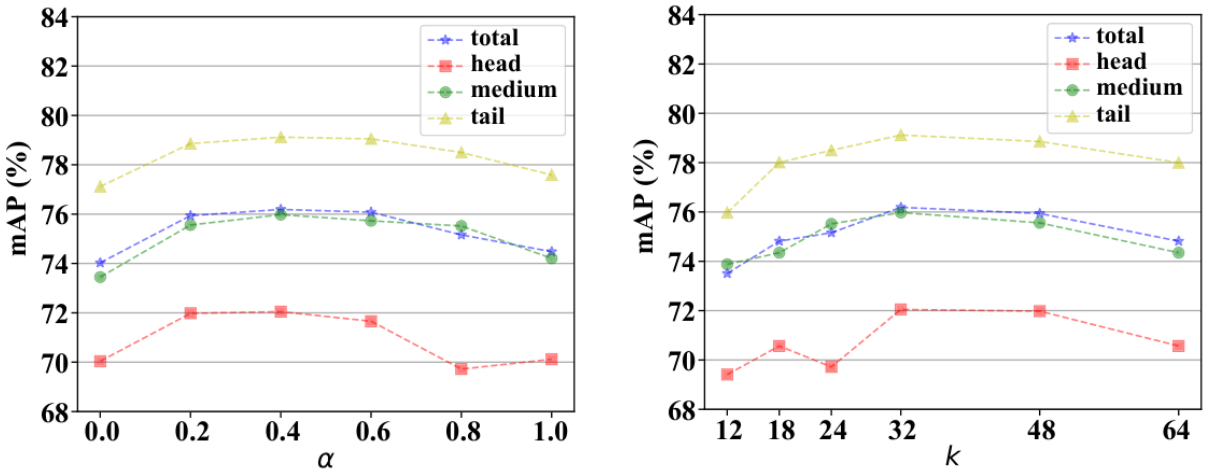
**表 IV。** 不同方法使用 BCE 损失和 DB 损失时，在 COCO-LT 上的 mAP（%）。粗体为最优，下划线为次优。√ 表示使用对应损失，- 为原表未勾选项。

| 方法 | BCE | DB | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|
| BCE | - | - | 49.43 | 48.77 | 53.00 | 45.33 |
| DB Focal | - | - | 53.55 | 51.13 | 57.05 | 51.06 |
| CoOp | √ | - | 55.03 | 39.80 | 57.71 | 64.91 |
| CoOp | - | √ | 60.68 | 41.97 | 63.18 | 73.85 |

| 方法 | BCE | DB | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|
| CoCoOp | √ | - | 58.81 | 45.49 | 61.78 | 66.61 |
| CoCoOp | - | √ | 61.49 | 39.81 | 64.63 | 76.42 |
| LMPT | √ | - | 58.04 | 41.79 | 58.86 | 73.90 |
| LMPT | - | √ | 66.19 | 44.89 | 69.80 | **79.08** |
| HP-DVAL | √ | - | 69.58 | 66.71 | 69.46 | 71.59 |
| HP-DVAL | - | √ | **75.16** | **69.72** | **75.52** | 78.50 |

**译注：** 表 IV 的最优/次优格式依原表保留；原表将 69.46 标为中部列次优，尽管同列存在更大的 69.80。数字未作改动。

**2）超参数敏感性。** 进一步探究双视图对齐权重 $\alpha$ 与前 $k$ 项池化参数 $k$ 对本方法在 COCO-LT 上性能的影响。mAP 结果如图 4 所示。图中可见，当 $\alpha$ 小于 0.4 时，本方法的性能提高。这说明适当地融合局部特征可以增强特征表示能力，进而改善整体性能。对于前 $k$ 项均值池化，$k = 32$ 时达到最高 mAP。分析认为，$k$ 太小时，局部预测分数容易受噪声影响，使结果不稳定；而 $k$ 太大时，由于对过多图块求平均，最相关图块的重要性被稀释，局部预测分数缺乏细粒度信息。因此，设置 $k = 32$ 在这些因素之间取得平衡，获得最佳性能。




(a) Effect of $\alpha$ (b) Effect of $k$

**图 4。** 超参数的影响。COCO-LT 数据集上，不同双视图对齐权重 $\alpha$ 和前 $k$ 项均值池化中的不同 $k$ 对应的 mAP（%）。子图（a）为 $\alpha$ 的影响，子图（b）为 $k$ 的影响；译本将原图上下排列改为左右排列，图内数据未改。图例 total/head/medium/tail 分别表示总体/头部/中部/尾部。

**3）HP-DVAL 组件分析。** 为评估各组件的贡献，我们开展一系列消融实验，结果汇总于表 V。基线采用零样本 CLIP [28]。HP-DVAL 框架包含两个关键阶段：双视图对齐学习（DVAL）和分层提示调优（HPT）。DVAL 利用 CLIP 图像编码器学习具有优秀特征表示能力的 ViT 骨干；HPT 引入分层提示，捕获任务特定和上下文相关的先验知识。加入这两个阶段后，头部、中部和尾部类别均显著改善；在 VOC-LT 和 COCO-LT 上，总体 mAP 分别比基线提高 8.01% 和 16.02%。我们将这些收益归因于两个阶段引导的视觉语言知识迁移：它们有效迁移多模态知识，并利用 CLIP 强大的特征表示能力处理

CI-MLIC。将 HPT 与语义一致性（SC）损失结合可进一步提高 mAP，因为 SC 能有效防止可学习提示遗忘 CLIP 中编码的通用知识。此外，我们比较了联合训练和两阶段顺序训练。分析表明，联合训练削弱了模型对不同优化目标的聚焦能力，导致特征表示混杂和学习混淆。

**表 V**。 HP-DVAL 各组件的消融研究。DVAL＝双视图对齐学习；HPT＝分层提示调优；SC＝语义一致性。最优分数依原表以粗体标出。为便于阅读，按数据集拆分；“两阶段”基线行未启用任何组件。

**表 V(a) VOC-LT**

| 训练方式 | DVAL | HPT | SC | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|---|
| 两阶段基线 | | | | 85.05 | 66.48 | 87.08 | 97.46 |
| 两阶段 | √ | | | 91.59 | 83.84 | 91.59 | 96.42 |
| 两阶段 | √ | √ | | 92.94 | 86.28 | 92.70 | 98.44 |
| 两阶段 | √ | √ | √ | **93.06** | **86.36** | **92.83** | **98.58** |
| 联合 | √ | √ | √ | 90.51 | 93.34 | 92.00 | 94.62 |

**表 V(b) COCO-LT**

| 训练方式 | DVAL | HPT | SC | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|---|
| 两阶段基线 | | | | 60.17 | 38.52 | 65.06 | 72.28 |
| 两阶段 | √ | | | 75.72 | 71.76 | 75.39 | 78.62 |
| 两阶段 | √ | √ | | 76.02 | 71.76 | 75.96 | 78.88 |
| 两阶段 | √ | √ | √ | **76.19** | **72.05** | **75.98** | **79.12** |
| 联合 | √ | √ | √ | 73.36 | 69.45 | 75.04 | 74.25 |

**译注：** 表 V 的 VOC-LT 联合训练行在原文中为总体 90.51、头部 93.34、中部 92.00、尾部 94.62；这些分组值与总体值之间存在明显疑点，且 86.36 仍在原表被加粗。译文不擅自修正数值或改写原表结论。表 V 第二行中部值 91.59 与表 VI 对应行 92.89 也不一致。

**4）分层提示调优的作用**。 为验证分层提示调优的有效性，我们对全局提示和局部提示分别进行消融。表 VI 展示了 VOC-LT 与 COCO-LT 上的长尾多标签图像分类结果。从表中可见，只使用一种可学习提示，无论全局还是局部，都会使性能下降。结合两种提示可以显著提高性能，充分说明了分层提示的优势。

**表 VI**。 HP-DVAL 在 VOC-LT 和 COCO-LT 上的分层提示调优消融分析。未标“√”表示使用固定提示而非可学习提示。

| 数据集 | 全局 | 局部 | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|
| VOC-LT | | √ | 91.36 | 83.09 | 93.78 | 95.76 |
| VOC-LT | √ | | 91.59 | 83.84 | 92.89 | 96.42 |
| VOC-LT | √ | √ | **93.06** | **86.36** | **92.83** | **98.58** |

| 数据集 | 全局 | 局部 | 总体 | 头部 | 中部 | 尾部 |
|---|---|---|---|---|---|---|
| COCO-LT | | √ | 74.03 | 70.04 | 73.45 | 77.12 |
| COCO-LT | √ | | 74.48 | 70.12 | 74.21 | 77.59 |
| COCO-LT | √ | √ | **76.19** | **72.05** | **75.98** | **79.12** |

为进一步验证方法有效性，我们可视化了两类提示在图像定位中的作用。如图 6 所示，当目标突出（如“pizza，比萨”）时，全局和局部提示都能捕获高激活区域。然而，当目标类别不太显著（如“grass，草”）时，局部提示仍能有效突出相应区域。总体而言，两类提示之间的互补交互增强了模型定位特定类别的能力。

**图 6。** 从全局和局部视角，对“pizza（比萨）”与“grass（草）”进行注意力图的比较可视化。

**图像省略说明：** 原图包含两行、三列的 6 个面板（两张原始照片、两张全局注意力热图、两张局部注意力热图）。全部面板都含第三方照片或其衍生图像，权利未单独确认，故不转载；完整图注保留。original/global view/local view＝原图/全局视图/局部视图。原始可视化见原文第 10 页图 6。

**5）提示长度的影响。** 如图 5 所示，我们在 COCO-LT 和 VOC-LT 上比较 HP-DVAL 使用不同提示上下文长度（$M = 2, 4, 8, 16, 32, 64$）时的性能。对于长尾多标签分类，我们学习类别共享提示，因此，当 $M$ 较小（如 2、4）时，HP-DVAL 就能取得良好性能。

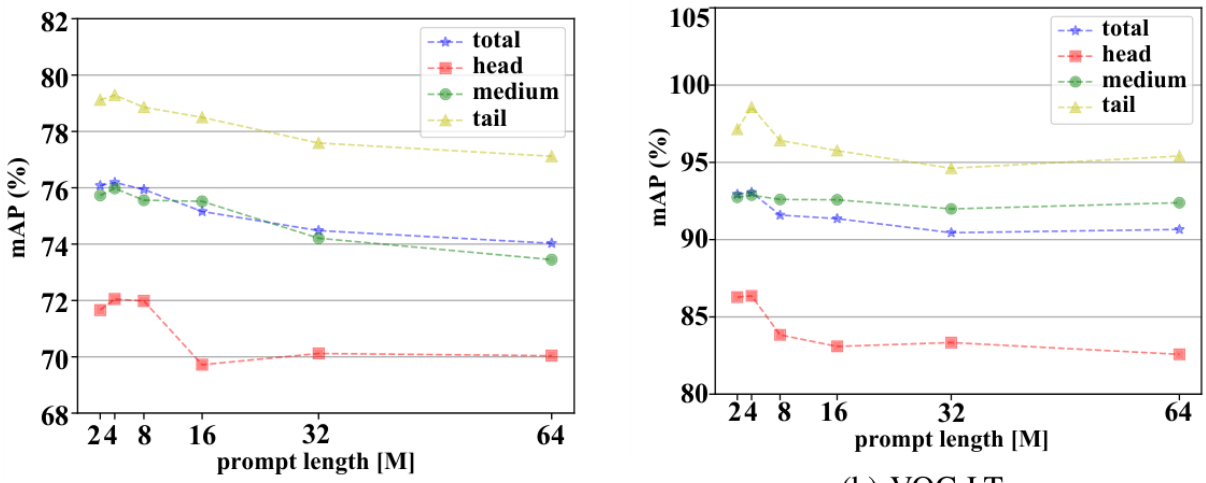



**图 5。** 在 COCO-LT 与 VOC-LT 数据集上，不同提示长度 $M$ 对应的 mAP（%）。两个数据集的长尾多标签分类任务中，HP-DVAL 在 $M$ 较小（例如 2、4）时表现良好。子图（a）为 COCO-LT，子图（b）为 VOC-LT；译本将原图上下排列改为左右排列，图内数据未改。prompt length＝提示长度；其余图例同图 4。

## E 定性分析

为评估已有方法的计算复杂度，表 VII 报告三个指标：模型参数量（以百万为单位，M）、浮点运算量（GFLOPs）和单张图像推理时间（毫秒）。由于局部图块和提示词元引入额外计算，本方法在这些指标上略有增加，但识别性能（mAP）显著提高。复杂度与性能之间的这种有利权衡进一步验证了设计的有效性。

**表 VII**。 各方法在模型参数量（M）、FLOPs（G）和单张图像推理速度（毫秒）方面的计算复杂度比较。

| 方法 | 参数量 M | FLOPs G | 时间 ms | mAP |
|---|---|---|---|---|
| CLIP [28] | 149.62 | 19.55 | 11.73 | 60.17 |
| CoOp [30] | 149.63 | 20.16 | 11.83 | 60.68 |
| CoCoOp [29] | 150.16 | 20.36 | 11.81 | 61.49 |
| HP-DVAL | 150.28 | 20.62 | 14.21 | **76.19** |

为验证方法有效性，我们开展可视化实验。图 7 比较 LMPT 和本方法的注意力图。结果显示，本方法能够更准确地捕获相关区域。例如，在第一列中，LMPT 关注更多无关区域，而本方法准确聚焦 [horse，马] 区域。

**图 7**。 LMPT 与本方法的注意力图可视化比较。LMPT 关注较多无关区域，而本方法能够更准确地捕获相关区域，例如 [horse，马] 所在区域。

**图像省略说明：** 原图含两行（horse＝马、cow＝牛）和三列（original＝原图、LMPT、HP-DVAL）的 6 个照片/热图面板，其照片及照片衍生内容的权利未单独确认，因此全部省略。完整图注保留；见原文第 10 页图 7。

不过，虽然本方法采用语义一致性（SC）损失约束提示、缓解尾部类别过拟合，其核心设计主要是通过全局—局部提示分工来增强特征对齐和细粒度匹配，缺乏专门针对极端类别不平衡的机制。这可能限制其在严重不平衡场景中的性能：局部提示因缺乏足够样本支持，可能无法捕获尾部类别的独特特征，从而损害识别精度。因此，值得进一步研究面向代表性不足类别的差异化提示设计，以及利用生成模型或数据增强丰富训练数据，以缓解样本稀缺、改善泛化能力。

## V 结论

我们提出了一种新的图文对齐方法 HP-DVAL，以处理类别不平衡多标签图像分类。通过结合 VLP 模型知识蒸馏与分层提示调优策略，HP-DVAL 有效迁移预训练视觉语言知识，改善不平衡数据分布下的特征对齐和上下文理解。然而，目前设计缺乏针对极端类别不平衡的专门机制，局部提示可能难以为样本有限的尾部类别学得判别特征。未来，我们将探索面向稀有类别的差异化提示，并利用生成模型或数据增强丰富训练数据，从而改善对代表性不足类别的泛化能力。

## 参考文献

以下保留原文全部 85 条参考文献的编号、作者与出版信息，译出论文标题；文献的期刊/会议名称采用原文缩写以便检索。原文 [35] 仅给出标题，未补造作者、年份或出处；[30] 的作者承接原文 [29]。原文中若存在不完整或重复的著录，依原文保留。

[1] K. He, X. Zhang, S. Ren, and J. Sun, 《用于图像识别的深度残差学习》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2016, 页 770-778.

[2] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, 《重新思考面向计算机视觉的 Inception 架构》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2016, 页 2818-2826.

[3] B. Recht, R. Roelofs, L. Schmidt, and V. Shankar, 《CIFAR-10 分类器能够泛化到 CIFAR-10 吗? 》, 2018, arXiv:1806.00451.

[4] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, 《Microsoft COCO：上下文中的常见物体》, 载于 Proc. Eur. Conf. Comput. Vis., 2014, 页 740-755.

[5] Z. Ji, X. Yu, Y. Yu, Y. Pang, and Z. Zhang, 《用于零样本图像分类的语义引导类别不平衡学习模型》, IEEE Trans. Cybern., 卷 52, 期 7, 页 6543-6554, 2022.

[6] Z. Liu, Z. Miao, X. Zhan, J. Wang, B. Gong, and S. X. Yu, 《开放世界中的大规模长尾识别》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2019, 页 2537-2546.

[7] Y. Zhang, B. Kang, B. Hooi, S. Yan, and J. Feng, 《深度长尾学习综述》, IEEE Trans. Pattern Anal. Mach. Intell., 卷 45, 期 9, 页 10 795-10 816, 2023.

[8] T. Chen, L. Lin, R. Chen, X. Hui, and H. Wu, 《面向通用图像识别的知识引导多标签小样本学习》, IEEE Trans. Pattern Anal. Mach. Intell., 卷 44, 期 3, 页 1371-1384, 2022.

[9] K. Yan, C. Zhang, J. Hou, P. Wang, Z. Bouraoui, S. Jameel, and S. Schockaert, 《通过词向量引导注意力推断多标签小样本图像分类的原型》, 载于 Proc. AAAI Conf. Artif. Intell., 卷 36, 期 3, 6 月 2022, 页 2991-2999.

[10] Y. Wang, M. Hong, L. Huangfu, and S. Huang, 《用于广义零样本识别的数据分布蒸馏生成模型》, 载于 Proc. AAAI Conf. Artif. Intell., 卷 38, 期 6, 2024, 页 5695-5703.

[11] J. Yan, S. Huang, N. Mu, L. Huangfu, and B. Liu, 《用于长尾多标签图像分类的类别提示精化特征学习》, 载于 Proc. 32nd ACM Int. Conf. Multimedia, 2024, 页 2146-2155.

[12] S. He, T. Guo, T. Dai, R. Qiao, X. Shu, B. Ren, and S.-T. Xia, 《通过多模态知识迁移实现开放词汇多标签分类》, 载于 Proc. AAAI Conf. Artif. Intell., 卷 37, 期 1, 6 月 2023, 页 808-816.

[13] X. Zhu, J. Liu, W. Liu, J. Ge, B. Liu, and J. Cao, 《用于多标签图像分类的场景感知标签图学习》, 载于 Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 10 月 2023, 页 1473-1482.

[14] H. Tan, Z. Tan, J. Li, J. Wan, and Z. Lei, 《PVLR：用于多标签图像识别的提示驱动视觉语言表示学习》, 2024, arXiv:2401.17881.

[15] T. Wu, Q. Huang, Z. Liu, Y. Wang, and D. Lin, 《用于长尾数据集多标签分类的分布平衡损失》, 载于 Proc. Eur. Conf. Comput. Vis., Cham, 2020, 页 162-178.

[16] H. Guo and S. Wang, 《在均匀采样与再平衡采样上协同训练以实现长尾多标签视觉识别》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2021, 页 15 089-15 098.

[17] D. Lin, 《用于长尾多标签图像分类的概率引导损失》, 载于 Proc. AAAI Conf. Artif. Intell., 卷 37, 期 2, 2023, 页 1577-1585.

[18] C. Liang, Z. Yang, L. Zhu, and Y. Yang, 《协同学习结合拼接增强，用于有噪声多标签视觉识别》, IEEE Trans. Image Process., 卷 32, 页 2508-2519, 2023.

[19] P. Xia, D. Xu, M. Hu, L. Ju, and Z. Ge, 《LMPT：通过类别特定嵌入损失进行提示调优，用于长尾多标签视觉识别》, 2024, arXiv:2305.04536.

[20] M. Buda, A. Maki, and M. A. Mazurowski, 《卷积神经网络中类别不平衡问题的系统研究》, Neural Networks, 卷 106, 页 249-259, 2018.

[21] J. Byrd and Z. Lipton, 《重要性加权对深度学习有何影响? 》, 载于 Proc. Mach. Learn. Res. (PMLR), 卷 97, 2019, 页 872-881.

[22] Y. Cui, M. Jia, T.-Y. Lin, Y. Song, and S. Belongie, 《基于有效样本数的类别平衡损失》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2019, 页 9268-9277.

[23] K. Cao, C. Wei, A. Gaidon, N. Arechiga, and T. Ma, 《使用标签分布感知间隔损失学习不平衡数据集》, 载于 Proc. Adv. Neural Inf. Process. Syst., 卷 32, 2019.

[24] Z. Ji, Z. Jiao, Q. Wang, Y. Pang, and J. Han, 《通过知识解耦和双重增强对比学习缓解持续学习中的不平衡》, IEEE Trans. Neural Networks Learn. Syst., 卷 36, 期 2, 页 3450-3463, 2025.

[25] B. Kang, S. Xie, M. Rohrbach, Z. Yan, A. Gordo, J. Feng, and Y. Kalantidis, 《解耦表示和分类器以进行长尾识别》, 2020, arXiv:1910.09217.

[26] B. Zhou, Q. Cui, X.-S. Wei, and Z.-M. Chen, 《BBN：具有累积学习的双分支网络，用于长尾视觉识别》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2020, 页 9719-9728.

[27] K. P. Alexandridis, S. Luo, A. Nguyen, J. Deng, and S. Zafeiriou, 《用于长尾图像识别的逆图像频率》, IEEE Trans. Image Process., 卷 32, 页 5721-5736, 2023.

[28] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, 《从自然语言监督中学习可迁移视觉模型》, 载于 Proc. Mach. Learn. Res. (PMLR), 卷 139, 7 月 2021, 页 8748-8763.

[29] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, 《视觉语言模型的条件提示学习》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2022, 页 16 816-16 825.

[30] 同 [29] 作者, 《学习为视觉语言模型构造提示》, Int. J. Comput. Vis., 卷 130, 页 2337-2348, 2022.

[31] L. Qiu, R. Zhang, Z. Guo, Z. Zeng, Z. Guo, Y. Li, and G. Zhang, 《VT-CLIP：通过视觉引导文本增强视觉语言模型》, 2023, arXiv:2112.02399.

[32] X. Xu, M. Li, C. Tao, T. Shen, R. Cheng, J. Li, C. Xu, D. Tao, and T. Zhou, 《大语言模型知识蒸馏综述》, 2024, arXiv:2402.13116.

[33] Y.-X. Wang, D. Ramanan, and M. Hebert, 《学习对尾部建模》, 载于 Proc. Adv. Neural Inf. Process. Syst., 卷 30, 2017.

[34] Z.-M. Chen, Q. Cui, X. Zhang, R. Deng, C. Xia, and S. Lu, 《面向长尾多标签图像识别的梯度均衡与特征多样化》, IEEE Trans. Multimedia, 卷 27, 页 3489-3500, 2025.

[35] 《MLC-NC：从神经坍缩视角研究长尾多标签图像分类》

[36] L. Zhu and Y. Yang, 《用于长尾视觉识别的区域自注意力扩展情景记忆》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2020, 页 4344-4353.

[37] B. Kang, Y. Li, S. Xie, Z. Yuan, and J. Feng, 《探索用于表示学习的平衡特征空间》, 载于 Proc. Int. Conf. Learn. Represent., 2021.

[38] Y. Zhang, B. Hooi, L. Hong, and J. Feng, 《通过测试时自监督聚合多样化专家，实现测试无关的长尾识别》, 2021, arXiv:2107.09249.

[39] H. Pan, Y. Guo, M. Yu, and J. Chen, 《通过对比 CutMix 增强改进长尾识别》, IEEE Trans. Image Process., 卷 33, 页 4215-4230, 2024.

[40] C. Tian, W. Wang, X. Zhu, J. Dai, and Y. Qiao, 《VL-LTR：学习类别级视觉语言表示以进行长尾视觉识别》, 载于 Proc. Eur. Conf. Comput. Vis., Cham, 2022, 页 73-91.

[41] B. Dong, P. Zhou, S. Yan, and W. Zuo, 《LPT：用于图像分类的长尾提示调优》, 载于 Proc. Int. Conf. Learn. Represent., 2023.

[42] J.-X. Shi, T. Wei, Z. Zhou, J.-J. Shao, X.-Y. Han, and Y.-F. Li, 《利用基础模型进行长尾学习：重度微调有害》, 2024, arXiv:2309.10019.

[43] J. Snell, K. Swersky, and R. Zemel, 《用于小样本学习的原型网络》, Proc. Adv. Neural Inf. Process. Syst., 卷 30, 2017.

[44] F. Sung, Y. Yang, L. Zhang, T. Xiang, P. H. Torr, and T. M. Hospedales, 《学习比较：用于小样本学习的关系网络》, 载于 Proc. IEEE Conf. on Comput. Vis. Pattern Recognit.(CVPR), 6 月 2018, 页 1199-1208.

[45] O. Vinyals, C. Blundell, T. Lillicrap, D. Wierstra et al., 《用于单样本学习的匹配网络》, Proc. Adv. Neural Inf. Process. Syst., 卷 29, 2016.

[46] R. Walsh, I. Osman, and M. S. Shehata, 《结合快速领域调整的掩码嵌入建模，用于小样本图像分类》, IEEE Trans. Image Process., 卷 32, 页 4907-4920, 2023.

[47] A.-K. Nguyen Vu, T.-T. Do, N.-D. Nguyen, V.-T. Nguyen, T. D. Ngo, and T. V. Nguyen, 《通过类别层次挖掘进行实例级小样本学习》, IEEE Trans. Image Process., 卷 32, 页 2374-2385, 2023.

[48] X. Yang, D. Kong, N. Wang, and X. Gao, 《结合知识蒸馏的双曲视角，用于跨域小样本学习》, IEEE Trans. Image Process., 卷 34, 页 1921-1933, 2025.

[49] Y. Chen, Z. Liu, H. Xu, T. Darrell, and X. Wang, 《Meta-baseline：探索简单的小样本元学习》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2021, 页 9062-9071.

[50] C. Finn, P. Abbeel, and S. Levine, 《模型无关的元学习，实现深度网络快速适应》, 载于 Proc. Intl. Conf. Mach. Learn. PMLR, 2017, 页 1126-1135.

[51] M. A. Jamal and G.-J. Qi, 《用于小样本学习的任务无关元学习》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2019, 页 11 719-11 727.

[52] B. Li, B. Yang, C. Liu, F. Liu, R. Ji, and Q. Ye, 《超越最大间隔：面向小样本目标检测的类别间隔均衡》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2021, 页 7363-7372.

[53] X. Dong, T. Ouyang, S. Liao, B. Du, and L. Shao, 《基于伪标签的实用半监督元训练，用于小样本学习》, IEEE Trans. Image Process., 卷 33, 页 5663-5675, 2024.

[54] L. Qiu, R. Zhang, Z. Guo, Z. Zeng, Y. Li, and G. Zhang, 《VT-CLIP：通过视觉引导文本增强视觉语言模型》, 2021, arXiv:2112.02399.

[55] S. Xuan, M. Yang, and S. Zhang, 《通过学习知识注入来适配视觉语言模型》, IEEE Trans. Image Process., 卷 33, 页 5798-5809, 2024.

[56] G. Tsoumakas and I. Katakis, 《多标签分类概述》, Int. J. Data Warehouse. Min., 卷 3, 期 3, 页 1-13, 2007.

[57] L. Wang, Y. Liu, H. Di, C. Qin, G. Sun, and Y. Fu, 《用于多标签分类的半监督双关系学习》, IEEE Trans. Image Process., 卷 30, 页 9125-9135, 2021.

[58] T. Chen, W. Wang, T. Pu, J. Qin, Z. Yang, J. Liu, and L. Lin, 《用于多标签置信度校准的动态相关性学习与正则化》, IEEE Trans. Image Process., 卷 33, 页 4811-4823, 2024.

[59] J. Wang, Y. Yang, J. Mao, Z. Huang, C. Huang, and W. Xu, 《CNN-RNN：多标签图像分类的统一框架》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2016, 页 2285-2294.

[60] B.-B. Gao and H.-Y. Zhou, 《学习发现多类别注意力区域以进行多标签图像识别》, IEEE Trans. Image Process., 卷 30, 页 5920-5932, 2021.

[61] J. Zhang, J. Ren, Q. Zhang, J. Liu, and X. Jiang, 《用于多标签图像分类的空间上下文感知目标注意力网络》, IEEE Trans. Image Process., 卷 32, 页 3000-3012, 2023.

[62] J. Lanchantin, T. Wang, V. Ordonez, and Y. Qi, 《基于 Transformer 的通用多标签图像分类》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2021, 页 16 478-16 488.

[63] S. Liu, L. Zhang, X. Yang, H. Su, and J. Zhu, 《Query2Label：一种简单的 Transformer 多标签分类方法》, 2021, arXiv:2107.10834.

[64] H. D. Nguyen, X.-S. Vu, and D.-T. Le, 《用于多标签图像分类的模块化图 Transformer 网络》, 载于 Proc. AAAI Conf. Artif. Intell., 卷 35, 期 10, 5 月 2021, 页 9092-9100.

[65] H. Su, Q. Yang, Y. Ning, Z. Hu, and L. Liu, 《基于 CNN 和 Transformer 的多标签极光图像分类》, IEEE Trans. Image Process., 卷 34, 页 1835-1848, 2025.

[66] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, 《一幅图像相当于 16×16 个词：用于大规模图像识别的 Transformer》, 2021, arXiv:2010.11929.

[67] R. Abdelfattah, Q. Guo, X. Li, X. Wang, and S. Wang, 《CDUL：CLIP 驱动的无监督多标签图像分类学习》, 载于 Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 10 月 2023, 页 1348-1357.

[68] Z. Guo, B. Dong, Z. Ji, J. Bai, Y. Guo, and W. Zuo, 《多标签图像识别提示调优中的以文本为图像》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2023, 页 2808-2817.

[69] X. Wu, Q.-Y. Jiang, Y. Yang, Y.-F. Wu, Q.-G. Chen, and J. Lu, 《TAI++：通过协同学习可迁移提示，以文本为图像进行多标签图像分类》, 2024, arXiv:2405.06926.

[70] H. Tan, Z. Tan, J. Li, A. Liu, J. Wan, and Z. Lei, 《恢复与匹配：通过知识约束最优传输实现开放词汇多标签识别》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 6 月 2025, 页 4650-4660.

[71] Z. Liu, J. Guo, S. Guo, and X. Lu, 《Epsilon：探索全面的视觉语义投影以进行多标签零样本学习》, Proc. AAAI Conf. Artif. Intell., 卷 39, 期 18, 页 19 059-19 067, 4 月 2025.

[72] A. Alfassy, L. Karlinsky, A. Aides, J. Shtok, S. Harary, R. Feris, R. Giryes, and A. M. Bronstein, 《LaSO：用于多标签小样本学习的标签集合运算网络》, 载于 Proc. IEEE Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2019, 页 6548-6557.

[73] C. Simon, P. Koniusz, and M. Harandi, 《用于多标签小样本分类的元学习》, 载于 Proc. IEEE/CVF Winter Conf. Appl. Comput. Vis. (WACV), 1 月 2022, 页 3951-3960.

[74] Y. Zhang, Z. Ji, Y. Pang, J. Han, and X. Li, 《大型多模态模型的模态专家协同适配》, Sci. China Inform. Sci., 卷 67, 期 12, 页 220107, 2024.

[75] M. Everingham, S. A. Eslami, L. Van Gool, C. K. Williams, J. Winn, and A. Zisserman, 《PASCAL 视觉目标类别挑战赛回顾》, Int. J. Comput. Vis., 卷 111, 页 98-136, 2015.

[76] D. P. Kingma and J. Ba, 《Adam：一种随机优化方法》, 2017, arXiv:1412.6980.

[77] Z.-M. Chen, X.-S. Wei, P. Wang, and Y. Guo, 《使用图卷积网络进行多标签图像识别》, 载于 Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.(CVPR), 6 月 2019, 页 5177-5186.

[78] T. Ridnik, E. Ben-Baruch, N. Zamir, A. Noy, I. Friedman, M. Protter, and L. Zelnik-Manor, 《用于多标签分类的非对称损失》, 载于 Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 10 月 2021, 页 82-91.

[79] P. Song, A. Ju, W. Xu, and F. Guo, 《用于长尾多标签分类的自适应加权复制解耦重采样策略》, 载于 IEEE Int. Conf. Pattern Recognit. Artif. Intell. (PRAI), 2023, 页 437-442.

[80] J.-H. Lim, M.-S. Oh, and S.-W. Lee, 《通过处理数据不平衡增强多标签分类的判别能力》, 载于 IEEE Int. Conf. Syst. Man Cybern. (ICSMC), 2023.

[81] J. Chen and S. Li, 《用于不平衡多标签分类的类别感知学习》, 载于 IEEE Int. Conf. Civil Aviation Saf. Inf. Technol. (ICCASIT), 2023, 页 903-907.

[82] W. Zhang, C. Liu, L. Zeng, B. Ooi, S. Tang, and Y. Zhuang, 《在不完美环境中学习：具有长尾分布和部分标签的多标签分类》, 载于 Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 10 月 2023, 页 1423-1432.

[83] Y. An, H. Xue, X. Zhao, N. Xu, P. Fang, and X. Geng, 《利用双向关联进行多标签小样本学习》, IEEE Trans. Neural Networks Learn. Syst., 页 1-13, 2024.

[84] K. Yan, Z. Bouraoui, F. Wei, C. Xu, P. Wang, S. Jameel, and S. Schockaert, 《基于局部特征选择建模多模态交叉交互，用于 ML-FSIC》, 2024, arXiv:2412.13732.

[85] Y. Liu, J. Wen, C. Liu, X. Fang, Z. Li, Y. Xu, and Z. Zhang, 《用于零样本多标签图像识别的语言驱动跨模态分类器》, 载于 Proc. 41th Intl. Conf. Mach. Learn., 2024.

## 作者简介

**肖像省略说明：** 原文第 13 页所列 5 位作者的肖像照片，其摄影作品权利未单独确认，因此不转载。以下完整翻译文字简介，所有任职、论文数量、荣誉等均为原文版本中的表述，不代表经核实的当前状态。肖像及原始简介见原文第 13 页。

**Sheng Huang（IEEE 会员）** 于 2010 年和 2015 年分别在中国重庆的重庆大学获得工学学士和博士学位。2012 至 2014 年，他在美国新泽西州新不伦瑞克的罗格斯大学计算机科学系担任访问博士研究生。现为重庆大学大数据与软件学院教授。他已在 CVPR、AAAI、IEEE Transactions on Image Processing、IEEE Transactions on Information Forensics and Security、IEEE Transactions on Circuits and Systems for Video Technology 等会议和期刊独立或合作发表 30 余篇学术论文。研究兴趣包括计算机视觉、机器学习、图像处理以及人工智能应用。

**Jiexuan Yan** 正在中国重庆的重庆大学攻读大数据与软件工程硕士学位。研究兴趣包括计算机视觉、多标签图像分类以及人工智能应用。

**Beiyan Liu** 正在中国重庆的重庆大学攻读大数据与软件工程硕士学位。研究兴趣包括计算机视觉、多标签图像分类以及人工智能应用。

**Bo Liu** 于 2018 年在新泽西州立罗格斯大学获得计算机科学博士学位。现任中国合肥的合肥工业大学教师。此前分别在 Walmart Global Tech 和京东硅谷研究中心担任 Staff Data Scientist（资深数据科学家）与 Senior Research Scientist（高级研究科学家）。专业领域和研究兴趣涵盖机器学习、计算机视觉以及数据科学。

**Richang Hong（IEEE 高级会员）** 是合肥工业大学教授、博士生导师。现任合肥工业大学计算机与信息学院（人工智能学院）和软件学院院长，同时担任合肥综合性国家科学中心数据空间研究院副院长、安徽省人工智能学会理事长。研究聚焦人工智能相关领域，发表高水平论文 300 余篇，引用超过 20,000 次。他担任国际多媒体建模会议（International Conference on Multimedia Modeling）指导委员会委员，以及 IEEE TBD、IEEE TMM、ACM TOMM 等六种国际期刊编委。他主持多项国家级项目，包括科技部 863 计划、科技部重点研发计划，以及国家自然科学基金优秀青年科学基金和重点项目等。研究成果曾获国家自然科学奖二等奖（2015 年）、安徽省自然科学奖一等奖（2017 年）、安徽省科学技术进步奖一等奖（2020 年）。教学方面，获安徽省教学成果奖一等奖（2022 年）和国家级教学成果奖研究生教育一等奖（2023 年）。2019 年获安徽青年五四奖章，并入选国家领军人才计划。

## 译本校核说明

本译本完整覆盖原文 13 页文字、公式、表格、图注和作者简介；未提供独立附录。为避免将源文疑点改写成新事实，保留并标注了表 V 的数值异常、表 V 与表 VI 的中部类别数据差异、正文个别数据集顺序和参考文献编号的不一致，以及公式排印问题。另需注意：原文引言将 MS COCO 与单标签基准并列描述，但后文又将其作为多标签基准；原文把 COCO 2017 的 5,000 张评估图像称为“测试集”；实现细节使用名称 AdamW，而 [76] 著录标题为 Adam。这些源文表述均未在译文中无说明地改写。

**图像保留与省略汇总：** 图 1(a) 保留统计柱状图和标签，省略 6 个照片/热图面板；图 1(b) 保留；图 2 保留作者流程图，省略 1 张输入照片和 4 个照片图块；图 3、4、5 保留；图 6 的 6 个面板、图 7 的 6 个面板及 5 张作者肖像省略。省略不表示相应实验不存在，仅表示本译本未转载相关图像。原文权威版本及各页定位链接已给出。

本中文改编的署名与许可：Sheng Huang、Jiexuan Yan、Beiyan Liu、Bo Liu、Richang Hong 原作；AI 辅助中文翻译与重新排版。原作及此翻译适用 CC BY-NC-SA 4.0；仅限非商业使用，改编共享须采用相同许可。第三方材料的权利不因上述许可说明而被另行授予。