质量感知与软一致性驱动的表示融合 用于不完整多视图多标签分类

Quality-aware and Soft Consistency Driven Representation Fusion for Incomplete Multi-view Multi-label Classification

Yadong Liu[1]，Waikeung Wong[2]，Yulong Chen[1]，Jie Wen[1]*

[1] 哈尔滨工业大学（深圳）计算机科学与技术学院，中国深圳
[2] 香港理工大学时装及纺织学院

liuyadong221010@163.com；calvinwong@aidlab.hk；chenyulonghit@163.com；jiewen_pr@126.com

* 通讯作者。

第四十届 AAAI 人工智能会议（AAAI-26），原文第 23882–23890 页。

私人阅读译本说明。 本译文以用户上传的 9 页 PDF 为唯一翻译底本，覆盖全部正文、致谢、参考文献、4 幅图、3 张表、15 个编号公式和算法 1。图表与编号公式采用原件裁图，保留全部数值、符号与版式，并附中文图表说明。原文提及的附录 A、B 不在所提供的 PDF 中，本译本不含这些未提供的补充材料，也未推测或补写其内容。原作者版权不变；本译本为非官方、私人使用的中文翻译，不授予公开再分发许可。

原文版权声明：Copyright © 2026, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved.（版权所有，保留所有权利。）

摘要

多视图多标签分类旨在利用多个视图中蕴含的丰富信息实现准确分类。然而，在实际应用中，视图与标签同时缺失往往严重制约其性能。为解决这一问题，本文首先针对传统特征解耦方法中强一致性约束导致表示退化的缺陷，提出一种软一致性约束。该约束不仅能有效对齐共享信息，并尽可能避免压缩有利于分类任务的信息，还能增强高质量表示对其他表示的聚合作用。此外，为解决传统融合策略粒度粗糙的问题，我们设计了一个质量评估网络，以数据驱动的方式实现实例级动态加权融合。在多个基准数据集上开展的大量实验表明，我们的方法在不完整和完整数据场景中都达到了最先进的性能，展现出其鲁棒性与通用性。

引言

信息技术的快速发展，使现实世界的数据越来越多地以多模态和多视图形式呈现（Lu et al. 2024）。例如，患者的医疗记录可能同时包含 CT 扫描和 X 光图像。这些来自不同来源的异质数据，为理解复杂现象提供了互补信息和不同视角。因此，多视图学习已广泛应用于医疗诊断（Lin et al. 2025；Luo et al. 2025）、跨视图检索（Wang et al. 2020, 2023b；Su et al. 2025），以及多视图聚类等无监督任务（Li et al. 2024, 2025）。

然而，将多视图学习理论应用于现实世界时，一个普遍且迫切的挑战是数据不完整（Zhang et al. 2024）。由于数据采集失败、存储限制或隐私顾虑等实际因素，获得的样本常常在一个或多个视图上存在数据缺失。传统多视图方法依赖数据完整的假设，因此在处理不完整数据时，其性能可能大幅下降，甚至完全失效。这严重削弱了此类方法的实用性。因此，如何处理现实世界中更为普遍且更具挑战性的多视图数据缺失问题，正受到越来越多的关注。致力于解决此类问题的研究方向统称为不完整多视图学习（Incomplete Multi-view Learning，IMVL）。

多标签分类（Zhang and Zhou 2013）比单标签分类更具普适性，因为它能够准确建模一个对象同时具有多种属性的现实场景。然而，更广泛的适用性也带来了独特的挑战。例如，用户可能只为一条社交媒体帖子标注其相关标签中的一部分。因此，如何从这种不完整的监督信息中有效学习，已成为该领域的挑战之一。不完整多视图缺失多标签分类（Incomplete Multi-view Missing Multi-label Classification，iM3C）的目标，是在视图与标签双重缺失的挑战下训练模型，并在测试阶段某些视图仍然缺失时，为样本给出准确且稳健的多标签预测。已有研究（Liu et al. 2024a；Xie et al. 2024）观察到，虽然缺失视图和缺失标签都是不完整学习中的挑战，但它们对模型性能的负面影响并不相同。在相同缺失率下，视图信息缺失通常比标签缺失造成更显著的性能下降。鉴于此，本文重点研究如何从不完整多视图数据中尽可能充分地提取并利用潜在的、与任务相关的语义信息，以应对视图缺失带来的严峻挑战。

近年来，该领域一个主流研究方向是学习所有视图共享的一致性表示（Lv et al. 2022；Wang et al. 2023a；Liu et al. 2024c）。其核心思想是，一致性信息在多个视图中被冗余编码。因此，即使某些视图缺失，模型仍可从可用视图中有效重建或推断出这种共享表示，以完成下游任务。然而，这类仅依靠共享信息的策略，其有效性建立在一个较强的假设之上（Tsai et al. 2020）：视图间的共享信息足以满足下游任务的需求。在许多现实场景中，这一假设往往过于乐观。每个视图不仅包含共享信息，还承载大量视图特有的私有信息。而且，这些私有信息可能包含对下游任务至关重要的判别性特征（Liu et al. 2023a）。我们的研究揭示了多视图表示学习中的一种权衡，即一致性与信息丰富性之间存在内在张力。当模型过度追求视图表示之间的一致性时，可能会牺牲信息丰富性。这可能使模型主动抑制或丢弃有助于下游任务的视图特有信息，最终导致表示质量下降。

因此，我们引入软一致性正则化。不同于要求精确对齐的硬约束，我们的方法促进视图间共享信息的一致性，同时保护与任务相关的视图特有私有信息，并增强高质量表示对其他表示的聚合作用。获得各视图的表示后，接下来的挑战在于如何有效融合这些表示。理想的融合策略应在保留任务相关信息与压缩冗余信息之间取得最佳平衡。为解决现有融合策略普遍存在的粒度粗糙、缺乏适应性等问题，我们提出一种质量感知的实例级动态融合方案。与对所有样本一视同仁的传统方法不同，该方案可根据每个样本

独有的信息生成动态融合权重，从而实现更细粒度、更高效的信息整合。我们将这种基于软一致性的质量感知表示学习方法命名为 QUALITY（QUality-Aware representation Learning vIa sofT consistencY）。总而言之，本文的主要贡献如下：

- 提出一种软一致性约束，既能对齐跨视图的共享信息，又能保护与任务相关的私有信息，避免其被过度压缩。
- 设计质量感知融合模块，突破静态、粗粒度方法的局限，根据每个样本独有的质量生成动态、自适应的融合策略。
- 多个数据集上的大量实验结果表明，所提方法不仅在各种不完整数据场景下，而且在完整数据设置下，均优于当前最先进的方法。

问题定义与相关工作

符号说明

为了更好地描述问题与所提方法，我们将原始数据集定义为 $\mathbf{X} = \{\mathbf{x}_i^{(v)} \mid i = 1, \ldots, \mathbf{n};\ v = 1, \ldots, \mathbf{m}\}$，其中包含 $\mathbf{m}$ 个视图和 $\mathbf{n}$ 个样本；$\mathbf{x}_i^{(v)} \in \mathbb{R}^{d_v}$ 表示第 i 个样本的第 v 个视图，d_v 表示其维数。相应地，将标签集定义为 $\mathbf{Y} \in \{0, 1\}^{\mathbf{n}\times\mathbf{c}}$，其中 $\mathbf{c}$ 为类别数。在视图与标签同时缺失这一具有挑战性的设置下，我们将 $\{\mathcal{V}_i\}_{i=1}^{\mathbf{n}}$ 定义为已知视图集合，并将 $\{\mathcal{G}_i\}_{i=1}^{\mathbf{n}}$ 定义为已知标签集合。具体而言，$\mathcal{V}_i$ 表示第 i 个样本能够观测到的视图，$\mathcal{G}_i$ 表示第 i 个样本能够观测到的标签。

不完整多视图学习

当前的不完整多视图学习（IMVL）方法主要分为两类。一类工作侧重于通过已观测视图学习表示，旨在有效提炼并整合已观测视图中的显著判别性特征，以提升下游任务性能。另一类工作以缺失视图补全为中心，首先利用可用视图显式生成缺失数据，然后在补全后的数据集上进行学习。为平衡视图间的一致性与多样性，CDMM 模型（Zhao et al. 2021）使用视图特定的分类器对齐预测，同时利用希尔伯特-施密特独立性准则（Hilbert-Schmidt Independence Criterion，HSIC）保留视图特有信息。基于视图空间与标签空间之间的结构一致性，LVSL 模型（Zhao et al. 2022）同时建模多视图一致性和低秩标签间相关性。随后，在预测阶段利用视图特定的权重捕获互补信息。在生成式方法中，LaSA 模型（Liu et al. 2024b）利用样本固有的图结构，引导缺失视图数据的重建。

标签缺失的多标签学习

与不完整多视图学习高度类似，标签缺失的多标签学习主流方法可以分为两种主要范式。第一种范式是从已知标签中挖掘关联，旨在发现已观测标签集合中的潜在相关性，再利用这些关系推断整个标签空间的状态。第二种范式是基于生成的缺失标签补全，做法更为直接：先主动尝试重建缺失标签，再利用完整补全的标签信息训练模型。考虑到全局信息与局部信息的互补性，DM2L 模型（Ma and Chen 2021）在原始标签空间内同时捕获全局低秩标签结构与局部低秩标签结构，增强标签的可判别性。CAP 模型（Xie et al. 2023）为每个类别学习独特的动态阈值，有效克服了传统伪标签策略在处理多标签相关性和未知标签数量时的局限。

iM3C

尽管已有许多有效方法能够分别处理视图缺失或标签缺失，但它们难以直接应用于视图与标签双重不完整的 iM3C 问题。为解决 iM3C 问题，iMVWL 模型（Tan et al. 2018）在统一框架内联合训练三个主要组成部分：用于视图对齐的共享子空间、用于挖掘标签相关性的局部结构，以及最终分类器。NAIM3L 模型（Li and Chen 2021）的策略是学习一致的多视图表示，以应对视图缺失，同时利用全局和局部标签间结构弥补监督信息的不足。DICNet（Liu et al. 2023b）成功将对比学习应用于 iM3C 问题，通过从双重不完整数据中学习统一而稳健的表示，展示了这一技术方向的巨大潜力。

方法

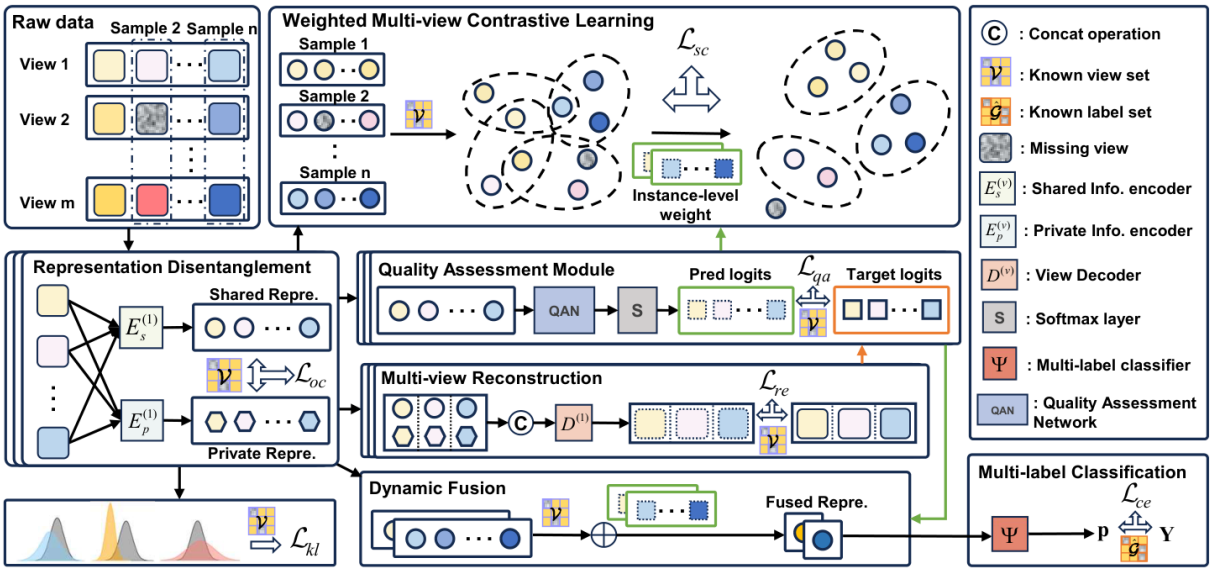


图 1：QUALITY 的主要框架。 本框架的创新包含两个协同模块：质量评估模块和加权软一致性约束模块。其中，质量评估模块为每个视图表示生成动态权重，该权重随后发挥双重作用：既引导实例级加权融合，又调节用于一致性约束的对比损失函数。

图内术语对照：Raw data＝原始数据；View＝视图；Sample＝样本；Weighted Multi-view Contrastive Learning＝加权多视图对比学习；Representation Disentanglement＝表示解耦；Shared/Private Repre.＝共享/私有表示；Quality Assessment Module＝质量评估模块；Pred/Target logits＝预测/目标 logits；Multi-view Reconstruction＝多视图重建；Dynamic Fusion＝动态融合；Instance-level weight＝实例级权重；Fused Repre.＝融合表示；Multi-label Classification＝多标签分类。图例中，C 表示拼接操作，Known view/label set 表示已知视图/标签集合，Missing view 表示缺失视图，$E_s^{(v)}$、$E_p^{(v)}$ 分别表示共享信息编码器与私有信息编码器，$D^{(v)}$ 表示视图解码器，S 表示 Softmax 层，Ψ 表示多标签分类器，QAN 表示质量评估网络。

本节详细介绍所提方法，其包含四个部分：多视图表示解耦、共享软一致性约束、动态实例级融合，以及多标签分类。

多视图表示解耦

虽然多视图数据包含更丰富的信息，但传统融合方法往往因无法有效处理显著的信息冗余而遇到性能瓶颈（Hwang et al. 2021）。一些工作（Liu et al. 2023a；Chen et al. 2023）提出通过特征解耦解决信息冗余，将每个视图的特征分解为视图共享与视图私有两个部分。在决策阶段，模型主要依赖更加稳健的共享特征，并将其与私有特征结合，作出最终判断。基于此，我们设计了一个多视图解耦网络。以第 i 个样本的第 v 个视图为例，原始数据经两个不同的编码器处理，分别提取共享与私有信息，即 $E_s^{(v)}\left(\mathbf{x}_i^{(v)}\right)=\left(\mu_{i,s}^{(v)},\ \sigma_{i,s}^{(v)}\right)$ 和 $E_p^{(v)}\left(\mathbf{x}_i^{(v)}\right)=\left(\mu_{i,p}^{(v)},\ \sigma_{i,p}^{(v)}\right)$，其中 $E_s^{(v)}$ 和 $E_p^{(v)}$ 分别表示共享信息编码器与视图私有信息编码器。共享表示 $\mathbf{z}_{i,s}^{(v)}$ 与私有表示 $\mathbf{z}_{i,p}^{(v)}$ 可分别从高斯分布 $\mathcal{N}\left(\mu_{i,s}^{(v)},\ \left(\sigma_{i,s}^{(v)}\right)^2\right)$ 和 $\mathcal{N}\left(\mu_{i,p}^{(v)},\ \left(\sigma_{i,p}^{(v)}\right)^2\right)$ 中采样。

为确保解耦过程中的信息完整性，我们拼接共享表示和私有表示，并将其输入解码器以重建原始数据。该重建任务的损失函数作为自监督约束，确保解耦出的两个组成部分共同保留原始信息的全部内容：

$$\mathcal{L}_{re}=\frac{1}{\sum_{i=1}^{\mathbf{n}}|\mathcal{V}_i|}\sum_{i=1}^{\mathbf{n}}\sum_{v\in\mathcal{V}_i}||\mathbf{x}_i^{(v)}-\hat{\mathbf{x}}_i^{(v)}||_2^2, \tag{1}$$

其中，$\widehat{\mathbf{x}}_i^{(v)}=D^{(v)}\left(\text{concat}\left(\mathbf{z}_{i,s}^{(v)},\ \mathbf{z}_{i,p}^{(v)}\right)\right)$，$D^{(v)}$ 为第 v 个视图的解码器。此外，我们分别对共享表示与私有表示的后验分布施加正则化，计算它们与标准正态分布之间的 KL 散度损失：

$$\begin{aligned}\mathcal{L}_{kl}=\frac{1}{\sum_{i=1}^{\mathbf{n}}|\mathcal{V}_i|}\sum_{i=1}^{n}\sum_{v\in\mathcal{V}_i}[&D_{KL}\left(q_s^{(v)}(\mathbf{z}_{i,s}^{(v)}|\mathbf{x}_i^{(v)})||p(\mathbf{z}_{i,s}^{(v)})\right)\\&+D_{KL}\left(q_p^{(v)}(\mathbf{z}_{i,p}^{(v)}|\mathbf{x}_i^{(v)})||p(\mathbf{z}_{i,p}^{(v)})\right)],\end{aligned} \tag{2}$$

其中，$q_s^{(v)}\left(\mathbf{z}_{i,s}^{(v)}\mid\mathbf{x}_i^{(v)}\right)$ 和 $q_p^{(v)}\left(\mathbf{z}_{i,p}^{(v)}\mid\mathbf{x}_i^{(v)}\right)$ 由两个编码器预测。进一步地，为确保共享表示与私有表示之间的信息解耦，我们施加正交约束。该约束旨在最小化两种表示之间的线性相关性，从而确保它们从相互独立的维度学习信息：

$$\mathcal{L}_{oc}=\frac{1}{\sum_{i=1}^{\mathbf{n}}|\mathcal{V}_i|}\sum_{i=1}^{\mathbf{n}}\sum_{v\in\mathcal{V}_i}((\mathbf{z}_{i,s}^{(v)})^T\mathbf{z}_{i,p}^{(v)})^2. \tag{3}$$

其中，$\mathbf{z}_{i,s}^{(v)}$ 和 $\mathbf{z}_{i,p}^{(v)}$ 为归一化后的表示。多视图解耦损失如下：

$$\mathcal{L}_{dis}=\alpha\mathcal{L}_{re}+\gamma\mathcal{L}_{kl}+\mathcal{L}_{oc} \tag{4}$$

其中， α 和 γ 为权衡参数。

共享软一致性约束

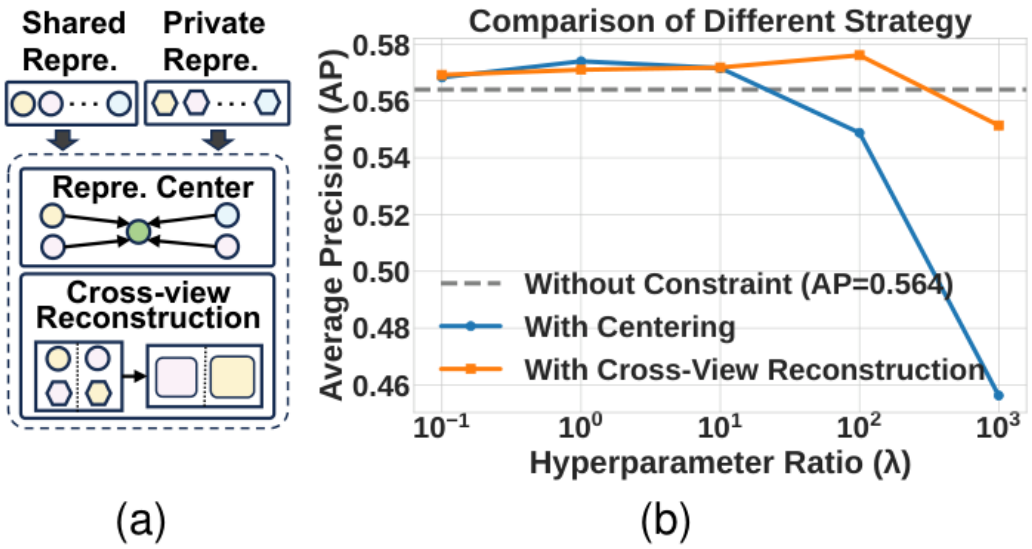


图 2： （a）两种一致性约束方法。（b）在 Pascal07 数据集上，两种约束随超参数变化时的性能。

图内术语对照：Shared/Private Repre.＝共享/私有表示；Repre. Center＝表示中心；Cross-view Reconstruction＝跨视图重建；Comparison of Different Strategy＝不同策略的比较；Average Precision (AP)＝平均精度；Hyperparameter Ratio (λ)＝超参数比值；Without Constraint＝无约束（AP＝0.564）；With Centering＝采用中心化约束；With Cross-View Reconstruction＝采用跨视图重建。

尽管多视图数据描述的是同一对象，但各视图在特征空间、数据分布与噪声特征方面固有的异质性，使直接融合极其困难（Zhang et al. 2024）。一些工作（Zeng et al. 2023；Liu et al. 2024c）基于共享信息假设，即共享的多视图表示足以满足下游任务的需要。因此，在完成特征解耦后，这些方法使用共享表示执行下游任务。基于此，我们探索了两种一致性约束方案以提取共享的多视图表示，如图 2（a）所示：第一种对表示施加中心化约束，第二种通过跨视图重建约束表示一致性。如图 2（b）所示，我们考察了一致性约束的权重。超参数 λ 是平衡一致性约束与重建损失的权衡系数。结果表明，其对性能提升的贡献有限；而且，约束过强时会导致性能下降。

因此，受 Wu et al.（2024）启发，我们利用对比学习施加软一致性约束。它只是拉近同一样本的多视图表示，而不是强迫它们完全一致。这使共享信息得以对齐，同时允许共享表示包含部分有益于下游任务的非共享信息。为考虑不同样本之间视图质量的差异，我们在对比损失函数中引入实例级动态权重 $\widehat{\mathbf{q}}$ 。该权重旨在增强高质量表示对其他表示的聚合作用。下一节将详细说明 $\widehat{\mathbf{q}}$ 的生成方式。对于任意视图对 (k, l)，视图 k 中第 i 个样本与视图 l 中第 j 个样本之间的相似度，由下式计算：

$$\mathbf{s}_{i,j}^{(k,l)} = \frac{\left((\mathbf{z}_{i,s}^{(k)})^T \mathbf{z}_{j,s}^{(l)}\right) \cdot \left(\hat{\mathbf{q}}_{i,s}^{(k)} \cdot \hat{\mathbf{q}}_{j,s}^{(l)}\right)}{\tau}, \qquad (5)$$

其中，τ 为温度参数。对于视图 k 中第 i 个样本，InfoNCE 损失计算如下：

$$\mathcal{L}_i^{(k,l)} = -\mathbf{s}_{i,i}^{(k,l)} + \log\Big(\sum_{j\in\mathcal{V}^{k,l}} \exp(\mathbf{s}_{i,j}^{(k,l)})\Big). \tag{6}$$

对所有可能的视图对计算加权对比损失，并取平均，得到最终的软一致性约束损失；每个损失均在其对应的有效样本子集上计算：

$$\mathcal{L}_{sc} = \frac{\sum_{k=1}^{\mathbf{m}}\sum_{l=k+1}^{\mathbf{m}}\sum_{i\in\mathcal{V}^{k,l}}\mathcal{L}_i^{(k,l)}}{\sum_{k=1}^{\mathbf{m}}\sum_{l=k+1}^{\mathbf{m}}|\mathcal{V}^{k,l}|}, \tag{7}$$

其中，$\mathcal{V}^{k,l}$ 表示视图 k 和视图 l 都可用的样本集合。

动态实例级融合

传统融合方法，例如均值融合或视图级加权，存在一个根本局限：它们隐含地假设每个视图对所有样本的重要性固定不变。然而，在现实场景中，视图的质量与相关性在不同样本之间是动态变化的。因此，这种静态融合策略难以适应真实数据分布，从而限制了模型性能的上限。另一类工作（Liu et al. 2025）通过同时训练一组独立的单视图分类器与质量判别网络，间接评估视图表示的质量。受此启发，我们设计了一种新颖的动态实例级加权融合策略。不同于传统方法的静态粗粒度融合，该策略可根据样本的视图表示质量，为每个样本自适应地生成一组独特的融合权重。以第 i 个样本为例，对于每个视图的共享表示，我们计算其平均对数方差，作为其不确定性的度量 $\{\mathbf{u}_{i,s}^{(v)}\}_{v\in\mathcal{V}}$。然后，将共享表示与不确定性度量拼接，得到增强的特征向量：

$$\hat{\mathbf{z}}_{i,s}^{(v)} = \mathrm{concat}(\mathbf{z}_{i,s}^{(v)}, \mathbf{u}_{i,s}^{(v)}). \tag{8}$$

接下来，将该特征向量输入质量评估网络 f_θ。该网络的输出层使用 Sigmoid 函数，将特征向量映射为质量分数：$\mathbf{q}_{i,s}^{(v)} = f_\theta(\hat{\mathbf{z}}_{i,s}^{(v)})$。其第 v 个视图的归一化质量分数为：

$$\hat{\mathbf{q}}_{i,s}^{(v)} = \frac{\mathbf{q}_{i,s}^{(v)}}{\sum_{v'\in\mathcal{V}_i}\mathbf{q}_{i,s}^{(v')} + \epsilon}, \tag{9}$$

其中，$\epsilon > 0$ 是为保证数值稳定性而加入的小值。随后，我们将生成的质量分数作为权重，对所有视图表示的均值与方差进行加权融合，从而得到统一的、质量感知的融合表示。

$$\hat{\mu}_{i,s} = \sum_{v\in\mathcal{V}_i}\hat{\mathbf{q}}_{i,s}^{(v)}\cdot\mu_{i,s}^{(v)}, \quad (\hat{\sigma}_{i,s})^2 = \sum_{v\in\mathcal{V}_i}(\hat{\mathbf{q}}_{i,s}^{(v)})^2\cdot(\sigma_{i,s}^{(v)})^2. \tag{10}$$

我们为质量评估网络设计了一种训练策略，其核心是以特征的可重建性作为其质量的代理。具体而言，我们最小化网络预测的归一化质量分数 $\widehat{\mathbf{q}}_{i,s}^{(v)}$ 与由重建损失得到的目标分数之间的差异，以此施加约束。该目标分数定义为样本归一化重建损失的负指数函数。对于第 i 个样本的第 v 个视图，我们利用负指数函数将误差转换为目标质量分数：

$$\mathbf{r}_{i,s}^{(v)} = \exp(-||\mathbf{x}_i^{(v)} - \hat{\mathbf{x}}_i^{(v)}||_2^2). \tag{11}$$

然后，对目标质量分数进行归一化，使其总和等于 1：

$$\hat{\mathbf{r}}_{i,s}^{(v)} = \frac{\mathbf{r}_{i,s}^{(v)}}{\sum_{v' \in \mathcal{V}_i} \mathbf{r}_{i,s}^{(v')} + \epsilon}. \tag{12}$$

最后，通过计算质量评估网络给出的质量分数与目标质量分数之间的均方误差，得到最终的质量判别损失：

$$\mathcal{L}_{qa} = \frac{1}{\sum_{i=1}^{\mathbf{n}} |\mathcal{V}_i|} \sum_{i=1}^{n} \sum_{v \in \mathcal{V}_i} ||\hat{\mathbf{q}}_{i,s}^{(v)} - \hat{\mathbf{r}}_{i,s}^{(v)}||_2^2. \tag{13}$$

多标签分类与目标函数

获得融合的多视图分布 $\mathcal{N}\left(\widehat{\mu}_{i,s}, \left(\widehat{\sigma}_{i,s}\right)^2\right)$ 后，我们使用重参数化技巧从中采样，得到可用于下游任务的多视图融合表示 $\bar{\mathbf{z}}$。随后，将融合表示输入多标签分类器，生成最终预测向量 $\mathbf{p}$。多标签分类的交叉熵损失如下：

$$\mathcal{L}_{ce} = -\frac{1}{N} \sum_{i=1}^{\mathbf{n}} \sum_{j \in \mathcal{G}_i} [(1 - \mathbf{y}_{ij}) \log(1 - \mathbf{p}_{ij}) + \mathbf{y}_{ij} \log \mathbf{p}_{ij}]. \tag{14}$$

其中，$N = \sum_{i=1}^{\mathbf{n}} |\mathcal{G}_i|$，$\mathbf{p}_{i,j}$ 与 $\mathbf{y}_{i,j}$ 分别表示第 i 个样本在第 j 类上的预测值与真实标签。最后，模型的总体优化目标由上述模块的损失项组成，具体形式如下：

$$\mathcal{L} = \mathcal{L}_{dis} + \mathcal{L}_{sc} + \beta \mathcal{L}_{qa} + \mathcal{L}_{ce}. \tag{15}$$

其中，β 为平衡因子。算法 1 给出了所提方法的训练过程。

算法 1：模型训练过程

输入： 不完整多视图数据 $\{\{\mathbf{x}_i^{(v)}\}_{v=1}^{\mathbf{m}}\}_{i=1}^{\mathbf{n}}$，已知视图集合 $\{\mathcal{V}_i\}_{i=1}^{\mathbf{n}}$，不完整多标签 $\mathbf{Y}$，已知标签集合 $\{\mathcal{G}_i\}_{i=1}^{\mathbf{n}}$。
初始化： 初始化模型参数，并设置超参数（α、β、γ 及训练轮数 $\mathbf{E}$）。
输出： 训练后的模型参数。

1. 对 $e = 1, \ldots, \mathbf{E}$ 执行以下操作：
2. 使用视图编码器集合 $\{E_s^{(v)}, E_p^{(v)}\}_{v=1}^{\mathbf{m}}$ 对可用视图进行解耦，获得共享表示与私有表示的分布。
3. 根据式（1）计算视图重建损失。
4. 根据式（2）计算各分布的 KL 损失。
5. 对每个视图的共享表示与私有表示，根据式（3）计算正交损失。
6. 根据质量评估网络输出的权重，融合分布参数。
7. 从融合分布中采样表示 $\bar{\mathbf{z}}$，再将 $\bar{\mathbf{z}}$ 输入多标签分类器，得到预测 $\mathbf{p}$。
8. 根据式（7）计算一致性约束损失。
9. 根据式（13）计算质量判别损失。
10. 根据式（14）计算分类损失。
11. 根据式（15）计算总损失 $\mathcal{L}$。
12. 逐批更新模型参数。
13. 结束循环。

实验

实验设置

数据集。 为评估模型性能，并确保与现有最先进方法进行公平比较，我们在本领域常用的五个基准数据集上开展实验，即 Corel5k（Duygulu et al. 2002）、Pascal07（Everingham et al. 2010）、ESPGame（Von Ahn and Dabbish 2004）、IAPRTC12（Grubinger et al. 2006）和 Mirflickr（Huiskes and Lew 2008）。数据集中的每个样本包含六种特征：GIST、HSV、DenseHue、DenseSift、RGB 和 LAB。各数据集的详细信息见附录 A。

不完整多视图缺失多标签数据预处理。 为构建实验所需的不完整多视图和缺失多标签数据集，我们以上述六个标准完整数据集为起点。遵循与现有最先进方法一致的策略（Tan et al. 2018；Li and Chen 2021），我们人为引入视图与标签缺失，以模拟现实世界中数据不完善的场景。具体来说，对于每个视图，按预先定义的掩蔽概率随机掩蔽其数据，但确保每个样本至少保留一个可用视图。同样地，我们随机掩蔽每个样本 50% 的正标签和负标签。每个数据集均随机划分为训练集（70%）、验证集（15%）和测试集（15%）。

译注：上段原文确实写作“six aforementioned standard, complete datasets”（上述六个标准完整数据集），但其前一段仅列出五个数据集，表 1 也包含五个；本译文保留该原文差异，不擅自改动。原文引用的附录 A、B 未随所提供的 9 页 PDF 提供。

比较方法。 在实验比较中，我们共选择九种最先进的方法作为基线。其中包括相关工作部分详细介绍的六种方法：CDMM、LVSL、DM2L、iMVWL、NAIM3L 和 DICNet。此外，还纳入另外三种方法：DIMC（Wen et al. 2023）、MSLPP（Long et al. 2024）和 SIP（Liu et al. 2024c）。这些方法的详细信息见附录 B。对于不能直接应用于 iM3C 问题的基线，我们进行了相应适配，其实现细节见附录 B。

评价指标。 遵循文献中的惯例（Tan et al. 2018；Li and Chen 2021），我们使用六项指标评估模型性能：排序损失（Ranking Loss，RL）、平均精度（Average Precision，AP）、汉明损失（Hamming Loss，HL）、ROC 曲线下面积（Area Under the ROC Curve，AUC）、单错率（One-Error，OE）和覆盖度（Coverage，Cov）。对于 RL、HL、OE 和 Cov，数值越低表示性能越好。为统一评价方向，我们以“1−指标值”的形式报告这些结果。因此，对这六项指标而言，分数越高均表示性能越好。

实验结果与分析

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L	DICNet	DIMC	MSLPP	SIP	QUALITY
Corel5K	AP	$0.354_{0.004}$	$0.262_{0.005}$	$0.342_{0.004}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.381_{0.004}$	$0.353_{0.006}$	$0.413_{0.008}$	$0.418_{0.009}$	$0.434_{0.010}$
	1-HL	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$
	1-RL	$0.884_{0.003}$	$0.843_{0.002}$	$0.881_{0.003}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.882_{0.004}$	$0.867_{0.001}$	$0.901_{0.003}$	$0.911_{0.003}$	$0.913_{0.003}$
	AUC	$0.888_{0.003}$	$0.845_{0.002}$	$0.884_{0.003}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.884_{0.004}$	$0.870_{0.001}$	$0.903_{0.004}$	$0.913_{0.003}$	$0.915_{0.003}$
	1-OE	$0.410_{0.007}$	$0.295_{0.014}$	$0.391_{0.009}$	$0.311_{0.015}$	$0.350_{0.009}$	$0.468_{0.007}$	$0.422_{0.015}$	$0.485_{0.001}$	$0.489_{0.016}$	$0.511_{0.018}$
	1-Cov	$0.723_{0.007}$	$0.647_{0.005}$	$0.718_{0.006}$	$0.702_{0.008}$	$0.725_{0.005}$	$0.727_{0.011}$	$0.684_{0.011}$	$0.766_{0.009}$	$0.787_{0.009}$	$0.795_{0.008}$
Pascal07	AP	$0.508_{0.005}$	$0.471_{0.008}$	$0.504_{0.005}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.505_{0.012}$	$0.532_{0.002}$	$0.544_{0.010}$	$0.555_{0.010}$	$0.590_{0.009}$
	1-HL	$0.931_{0.001}$	$0.928_{0.001}$	$0.930_{0.000}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.929_{0.001}$	$0.931_{0.001}$	$0.932_{0.001}$	$0.931_{0.001}$	$0.934_{0.001}$
	1-RL	$0.812_{0.004}$	$0.761_{0.005}$	$0.806_{0.003}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.783_{0.008}$	$0.813_{0.000}$	$0.819_{0.006}$	$0.830_{0.004}$	$0.852_{0.005}$
	AUC	$0.838_{0.003}$	$0.779_{0.004}$	$0.832_{0.002}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.809_{0.006}$	$0.833_{0.002}$	$0.841_{0.004}$	$0.850_{0.005}$	$0.870_{0.004}$
	1-OE	$0.419_{0.008}$	$0.420_{0.011}$	$0.419_{0.008}$	$0.362_{0.023}$	$0.421_{0.006}$	$0.427_{0.015}$	$0.456_{0.011}$	$0.466_{0.014}$	$0.464_{0.018}$	$0.499_{0.013}$
	1-Cov	$0.759_{0.003}$	$0.692_{0.004}$	$0.751_{0.003}$	$0.677_{0.015}$	$0.727_{0.002}$	$0.731_{0.006}$	$0.769_{0.007}$	$0.771_{0.003}$	$0.783_{0.006}$	$0.808_{0.006}$
ESPGame	AP	$0.289_{0.003}$	$0.212_{0.002}$	$0.285_{0.003}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.297_{0.002}$	$0.287_{0.002}$	$0.310_{0.004}$	$0.311_{0.004}$	$0.318_{0.004}$
	1-HL	$0.983_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$
	1-RL	$0.832_{0.001}$	$0.781_{0.001}$	$0.829_{0.001}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.832_{0.001}$	$0.821_{0.000}$	$0.843_{0.002}$	$0.849_{0.002}$	$0.854_{0.002}$
	AUC	$0.836_{0.001}$	$0.785_{0.001}$	$0.833_{0.002}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.836_{0.001}$	$0.826_{0.000}$	$0.847_{0.002}$	$0.853_{0.002}$	$0.858_{0.002}$
	1-OE	$0.396_{0.005}$	$0.294_{0.006}$	$0.389_{0.004}$	$0.343_{0.013}$	$0.339_{0.003}$	$0.439_{0.007}$	$0.435_{0.009}$	$0.457_{0.012}$	$0.455_{0.007}$	$0.461_{0.008}$
	1-Cov	$0.574_{0.004}$	$0.488_{0.003}$	$0.567_{0.005}$	$0.548_{0.004}$	$0.571_{0.003}$	$0.593_{0.003}$	$0.562_{0.004}$	$0.622_{0.005}$	$0.628_{0.005}$	$0.641_{0.004}$
IAPRTC12	AP	$0.305_{0.004}$	$0.234_{0.003}$	$0.304_{0.004}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.323_{0.001}$	$0.308_{0.001}$	$0.340_{0.005}$	$0.331_{0.006}$	$0.347_{0.004}$
	1-HL	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$
	1-RL	$0.862_{0.002}$	$0.823_{0.002}$	$0.861_{0.002}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.873_{0.001}$	$0.864_{0.000}$	$0.882_{0.002}$	$0.885_{0.003}$	$0.893_{0.002}$
	AUC	$0.864_{0.002}$	$0.825_{0.001}$	$0.863_{0.001}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.874_{0.000}$	$0.864_{0.000}$	$0.883_{0.002}$	$0.886_{0.002}$	$0.894_{0.002}$
	1-OE	$0.432_{0.008}$	$0.340_{0.006}$	$0.429_{0.009}$	$0.352_{0.008}$	$0.390_{0.005}$	$0.468_{0.002}$	$0.431_{0.006}$	$0.474_{0.008}$	$0.463_{0.009}$	$0.481_{0.007}$
	1-Cov	$0.597_{0.004}$	$0.529_{0.004}$	$0.597_{0.004}$	$0.564_{0.005}$	$0.592_{0.004}$	$0.649_{0.001}$	$0.597_{0.004}$	$0.672_{0.006}$	$0.675_{0.007}$	$0.693_{0.006}$
Mirflickr	AP	$0.570_{0.002}$	$0.514_{0.006}$	$0.553_{0.002}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.589_{0.005}$	$0.602_{0.002}$	$0.615_{0.004}$	$0.614_{0.004}$	$0.633_{0.004}$
	1-HL	$0.886_{0.001}$	$0.878_{0.001}$	$0.885_{0.001}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.002}$	$0.888_{0.000}$	$0.892_{0.001}$	$0.891_{0.001}$	$0.895_{0.001}$
	1-RL	$0.856_{0.001}$	$0.831_{0.003}$	$0.856_{0.001}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.863_{0.004}$	$0.865_{0.001}$	$0.879_{0.002}$	$0.877_{0.002}$	$0.886_{0.002}$
	AUC	$0.846_{0.001}$	$0.828_{0.003}$	$0.844_{0.001}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.849_{0.004}$	$0.852_{0.001}$	$0.865_{0.002}$	$0.860_{0.003}$	$0.872_{0.002}$
	1-OE	$0.631_{0.004}$	$0.510_{0.008}$	$0.607_{0.004}$	$0.511_{0.022}$	$0.585_{0.003}$	$0.637_{0.007}$	$0.647_{0.007}$	$0.667_{0.007}$	$0.662_{0.008}$	$0.682_{0.006}$
	1-Cov	$0.640_{0.001}$	$0.604_{0.005}$	$0.636_{0.001}$	$0.572_{0.013}$	$0.631_{0.002}$	$0.652_{0.007}$	$0.661_{0.003}$	$0.679_{0.003}$	$0.678_{0.003}$	$0.695_{0.003}$

表 1： 在五个数据集上，十种方法在视图缺失率 50%、标签缺失率 50% 时的实验结果（右下角数字表示标准差）。Data＝数据集；Metric＝指标；方法名称、各项数值及其标准差均保留原表。

我们在五个公开数据集上，将所提方法与另外九种最先进方法进行了全面的性能比较。表 1 给出了视图缺失率和标签缺失率均为 50% 的实验设置下的比较结果。表中详细列出了所有模型在全部六项评价指标上的性能值。根据表 1 的实验结果，可以得到以下关键观察：

- 全面的实验比较表明，所提方法在五个数据集的各项性能指标上均显著优于另外九种方法。这体现了该方法的先进性，以及解决 iM3C 问题的出色能力。

· 为 iM3C 问题专门设计的模型优于简单适配的方法，说明这是一个需要专门算法解决的独特挑战。

此外，为验证所提方法的通用性，我们进一步在数据完全完整的标准设置下评估其性能。图 3 以雷达图形式展示了本模型与基线方法的多指标比较结果。值得注意的是，即使在完整数据场景下，本方法的性能仍然全面领先。

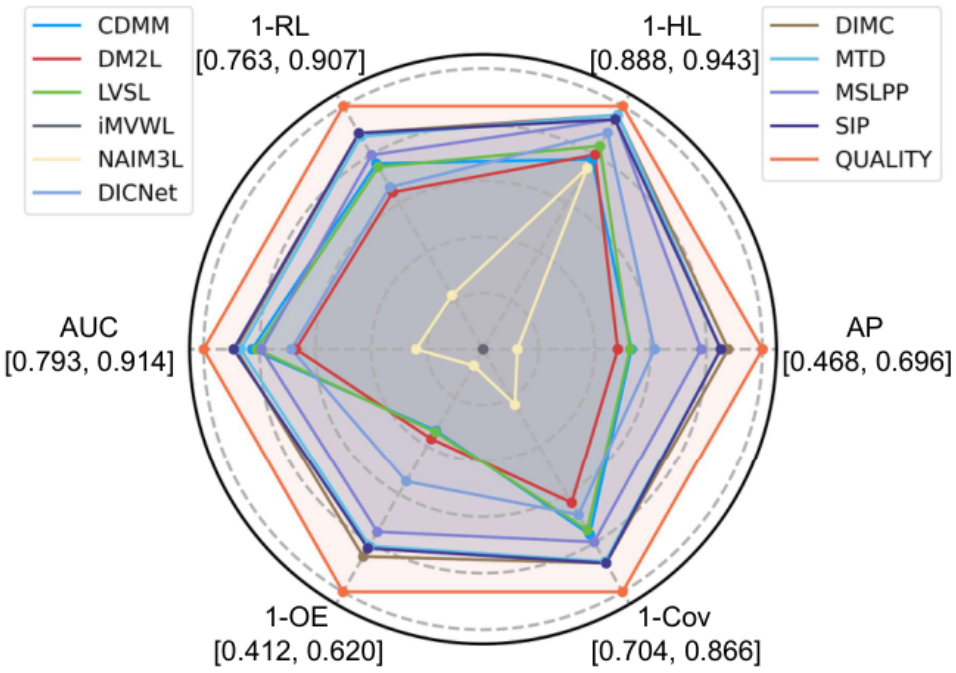


图 3： 九种方法在完整 Pascal07 数据集上的实验结果。在该可视化中，最差结果位于中心。图中的指标缩写和各轴取值范围保留原图。

译注：本图图注原文写作“nine methods”（九种方法）；图例实际包含 QUALITY 及 MTD 等共十一种方法。本译文忠实保留原图与原图注的表述。

质量评估网络研究

本节集中分析一个关键组成部分：质量评估网络。一种更简单的替代方案，是跳过该网络的学习过程，直接将我们的监督代理信号，即重建损失的负指数，作为融合权重。事实上，我们通过实验验证了这一简化方案，结果如表 2 所示。结果证实了质量评估网络的有效性。与采用固定策略将重建损失转换为权重相比，利用专门网络学习这种映射能够产生更加平滑、可靠的质量评估，并最终取得更好的性能。

Strategies	Dataset	AP	1-HL	1-RL	AUC
Pred Fusion	Corel5K	0.434	0.988	0.913	0.915
Direct Fusion	Corel5K	0.426	0.987	0.910	0.912
Pred Fusion	Pascal07	0.590	0.934	0.852	0.870
Direct Fusion	Pascal07	0.581	0.933	0.848	0.866

表 2： 本方法在不同融合策略下的性能。其中，“Pred Fusion”（预测权重融合）使用质量评估网络输出的权重进行融合，而“Direct Fusion”（直接融合）使用归一化的损失负指数进行融合。Strategies＝策略；Dataset＝数据集。

消融研究

为验证模型各组成部分的有效性，我们在 Corel5k 和 Pascal07 数据集上开展了消融研究。除常规的重建损失与分类损失外，模型的创新体现在两个新的关键约束上：共享软一致性约束损失 $\mathcal{L}_{sc}$ 和质量评估损失 $\mathcal{L}_{qa}$。因此，消融研究主要考察这两个约束的有效性。如表 3 所示，消融结果提供了有力证据，表明两项约束都是模型不可或缺且有效的组成部分。此外，正是二者的协同作用带来了最优结果。

Backbone	$\mathcal{L}_{sc}$	$\mathcal{L}_{qa}$	Corel5k		Pascal07	
			AP	AUC	AP	AUC
✓			0.3406	0.8801	0.5544	0.8522
✓	✓		0.3691	0.8906	0.5736	0.8621
✓		✓	0.4057	0.9081	0.5708	0.8605
✓	✓	✓	0.4335	0.9153	0.5901	0.8696

表 3： 在 Corel5K 和 Pascal07 数据集上的消融实验结果；两个数据集均采用 50% 的视图缺失率、50% 的标签缺失率，以及 70% 的训练样本。Backbone＝基础网络；勾选项表示启用相应组成部分。

超参数敏感性研究

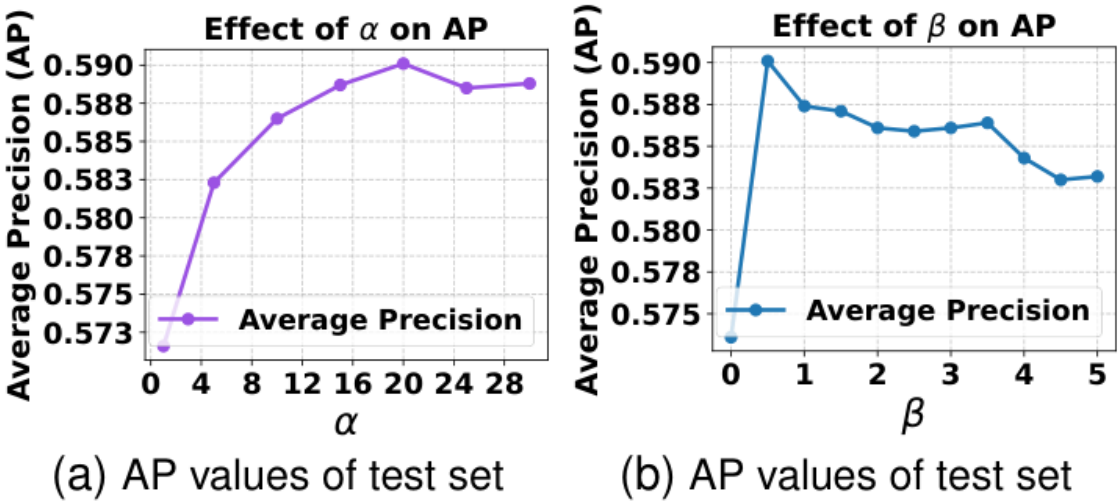


图 4： 在 Pascal07 数据集上对超参数 α 与 β 的分析（视图和标签均缺失 50% 的双重缺失设置）。子图（a）、（b）均显示测试集的 AP 值；Effect of α / β on AP＝α / β 对 AP 的影响；Average Precision＝平均精度。

本节在 Pascal07 数据集上对两个关键超参数进行了敏感性分析。具体而言，图 4（a）描述了 α 在 [1, 30] 范围内变化时模型性能的波动，而图 4（b）相应给出了 β 在 [0, 5] 范围内变化时的结果。实验结果表明，模型具有良好的参数鲁棒性：当超参数 α 与 β 分别处于相对宽泛的 [15, 30] 和 [0.5, 3.5] 范围内时，模型性能保持稳定。对于 γ，我们建议将其设置为 10^{-3}。

结论

本文首先分析了多视图共享表示与私有表示解耦过程中，对共享表示施加强一致性约束所导致的信息损失问题。基于此，我们为 iM3C 任务提出了名为 QUALITY 的框架。一方面，通过加权对比学习带来的软一致性约束，我们不仅对齐共享表示，还增强了高质量表示对其他表示的聚合作用。另一方面，我们设计质量评估网络来评估表示，从而实现实例级动态融合。最后，在多个数据集上开展的大量实验验证了本方法的有效性与鲁棒性。

致谢

本研究部分得到深圳市科技计划项目（资助编号 JCYJ20240813105135047）、广东省基础与应用基础研究基金（资助编号 2024A1515030213）的支持；并部分得到香港特别行政区政府创新科技署 InnoHK 创新香港研发平台旗下人工智能设计研究所（Laboratory for Artificial Intelligence in Design）的支持。

参考文献

以下保留原文作者、年份、英文题名、出版信息与页码，并在各条目中附中文题名；原文未列出的出版信息不作补写。

1. Chen, H.; Qu, C.; Zhang, Y.; Chen, C.; and Jiao, J. 2023. Multi-view self-supervised disentanglement for general image denoising.［面向通用图像去噪的多视图自监督解耦。］In Proceedings of the IEEE/CVF international conference on computer vision, 12281–12291.

2. Duygulu, P.; Barnard, K.; de Freitas, J. F.; and Forsyth, D. A. 2002. Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary.［将对象识别视为机器翻译：为固定图像词汇表学习词典。］In Computer vision—ECCV 2002: 7th European conference on computer vision copenhagen, Denmark, May 28–31, 2002 proceedings, part IV 7, 97–112. Springer.

3. Everingham, M.; Van Gool, L.; Williams, C. K.; Winn, J.; and Zisserman, A. 2010. The pascal visual object classes (voc) challenge.［Pascal 视觉对象类别（VOC）挑战赛。］International journal of computer vision, 88: 303–338.

4. Grubinger, M.; Clough, P.; Müller, H.; and Deselaers, T. 2006. The iapr tc-12 benchmark: A new evaluation resource for visual information systems.［IAPR TC-12 基准：面向视觉信息系统的新评估资源。］In International workshop ontoImage, volume 2.

5. Huiskes, M. J.; and Lew, M. S. 2008. The mir flickr retrieval evaluation.［MIR Flickr 检索评估。］In Proceedings of the 1st ACM international conference on Multimedia information retrieval, 39–43.

6. Hwang, H.; Kim, G.-H.; Hong, S.; and Kim, K.-E. 2021. Multi-view representation learning via total correlation objective.［通过总相关性目标进行多视图表示学习。］Advances in Neural Information Processing Systems, 34: 12194–12207.

7. Li, X.; and Chen, S. 2021. A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning.［用于非对齐不完整多视图与缺失多标签学习的简洁有效模型。］IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10): 5918–5932.

8. Li, X.; Pan, Y. P.; Sun, Y.; Sun, Q.; Sun, Y.; W. Tsang, I.; and Ren, Z. 2025. Incomplete Multi-view Clustering with Paired and Balanced Dynamic Anchor Learning.［通过配对且平衡的动态锚点学习进行不完整多视图聚类。］IEEE Transactions on Multimedia, 7087–7098.

9. Li, X.; Pan, Y. P.; Sun, Y.; Sun, Q. S.; Tsang, I. W.; and Ren, Z. 2024. Fast Unpaired Multi-view Clustering.［快速非配对多视图聚类。］

10. Lin, Y.; Dou, X.; Luo, X.; Wu, Z.; Liu, C.; Luo, T.; Wen, J.; Ling, B. W.-k.; Xu, Y.; and Wang, W. 2025. Multi-view diabetic retinopathy grading via cross-view spatial alignment and adaptive vessel reinforcing.［通过跨视图空间对齐与自适应血管强化进行多视图糖尿病视网膜病变分级。］Pattern Recognition, 164: 111487.

11. Liu, C.; Jia, J.; Wen, J.; Liu, Y.; Luo, X.; Huang, C.; and Xu, Y. 2024a. Attention-induced embedding imputation for incomplete multi-view partial multi-label classification.［用于不完整多视图部分多标签分类的注意力诱导嵌入补全。］In Proceedings of the AAAI conference on artificial intelligence, volume 38, 13864–13872.

12. Liu, C.; Li, R.; Che, H.; Leung, M.-F.; Wu, S.; Yu, Z.; and Wong, H.-S. 2024b. Latent structure-aware view recovery for incomplete multi-view clustering.［用于不完整多视图聚类的潜在结构感知视图恢复。］IEEE transactions on knowledge and data engineering.

13. Liu, C.; Wen, J.; Liu, Y.; Huang, C.; Wu, Z.; Luo, X.; and Xu, Y. 2023a. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning.［用于不完整多视图弱多标签学习的掩蔽双通道解耦框架。］Advances in neural information processing systems, 36: 32387–32400.

14. Liu, C.; Wen, J.; Luo, X.; Huang, C.; Wu, Z.; and Xu, Y. 2023b. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification.［DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络。］In Proceedings of the AAAI conference on artificial intelligence, volume 37, 8807–8815.

15. Liu, C.; Wen, J.; Xu, Y.; Zhang, B.; Nie, L.; and Zhang, M. 2025. Reliable representation learning for incomplete multi-view missing multi-label classification.［用于不完整多视图缺失多标签分类的可靠表示学习。］IEEE Transactions on Pattern Analysis and Machine Intelligence.

16. Liu, C.; Xu, G.; Wen, J.; Liu, Y.; Huang, C.; and Xu, Y. 2024c. Partial multi-view multi-label classification via semantic invariance learning and prototype modeling.［通过语义不变性学习与原型建模进行部分多视图多标签分类。］In Forty-first international conference on machine learning.

17. Long, J.; Zhang, Q.; Lu, X.; Wen, J.; Zhao, L.; and Xie, W. 2024. Multi-scale locality preserving projection for partial multi-view incomplete multi-label learning.［用于部分多视图不完整多标签学习的多尺度局部保持投影。］Neural Networks, 180: 106748.

18. Lu, Y.; Lin, Y.; Yang, M.; Peng, D.; Hu, P.; and Peng, X. 2024. Decoupled contrastive multi-view clustering with high-order random walks.［结合高阶随机游走的解耦对比多视图聚类。］In Proceedings of the AAAI conference on artificial intelligence, volume 38, 14193–14201.

19. Luo, X.; Xu, Q.; Wu, H.; Liu, C.; Lai, Z.; and Shen, L. 2025. Like an Ophthalmologist: Dynamic Selection Driven Multi-View Learning for Diabetic Retinopathy Grading.［像眼科医生一样：用于糖尿病视网膜病变分级的动态选择驱动多视图学习。］In Proceedings of the AAAI Conference on Artificial Intelligence, volume 39, 19224–19232.

20. Lv, Z.; Gao, Q.; Zhang, X.; Li, Q.; and Yang, M. 2022. View-consistency learning for incomplete multiview clustering.［用于不完整多视图聚类的视图一致性学习。］IEEE Transactions on Image Processing, 31: 4790–4802.

21. Ma, Z.; and Chen, S. 2021. Expand globally, shrink locally: Discriminant multi-label learning with missing labels.［全局扩张、局部收缩：标签缺失的判别式多标签学习。］Pattern Recognition, 111: 107675.

22. Su, C.; Zheng, H.; Peng, D.; and Wang, X. 2025. DiCA: Disambiguated Contrastive Alignment for Cross-Modal Retrieval with Partial Labels.［DiCA：用于部分标签跨模态检索的消歧对比对齐。］In Proceedings of the AAAI Conference on Artificial Intelligence, volume 39, 20610–20618.

23. Tan, Q.; Yu, G.; Domeniconi, C.; Wang, J.; and Zhang, Z. 2018. Incomplete multi-view weak-label learning.［不完整多视图弱标签学习。］In Ijcai, 2703–2709.

24. Tsai, Y.-H. H.; Wu, Y.; Salakhutdinov, R.; and Morency, L.-P. 2020. Self-supervised learning from a multi-view perspective.［多视图视角下的自监督学习。］arXiv preprint arXiv:2006.05576.

25. Von Ahn, L.; and Dabbish, L. 2004. Labeling images with a computer game.［利用电脑游戏标注图像。］In Proceedings of the SIGCHI conference on Human factors in computing systems, 319–326.

26. Wang, X.; Hu, P.; Liu, P.; and Peng, D. 2020. Deep semisupervised class-and correlation-collapsed cross-view learning.［深度半监督类别与相关性塌缩的跨视图学习。］IEEE transactions on cybernetics, 52(3): 1588–1601.

27. Wang, X.; Peng, D.; Hu, P.; Gong, Y.; and Chen, Y. 2023a. Cross-domain alignment for zero-shot sketch-based image retrieval.［用于零样本草图图像检索的跨域对齐。］IEEE Transactions on Circuits and Systems for Video Technology, 33(11): 7024–7035.

28. Wang, X.; Peng, D.; Yan, M.; and Hu, P. 2023b. Correspondence-free domain alignment for unsupervised cross-domain image retrieval.［用于无监督跨域图像检索的无对应关系域对齐。］In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, 10200–10208.

29. Wen, J.; Liu, C.; Deng, S.; Liu, Y.; Fei, L.; Yan, K.; and Xu, Y. 2023. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views.［标签不完整和视图缺失条件下的深度双重不完整多视图多标签学习。］IEEE transactions on neural networks and learning systems, 35(8): 11396–11408.

30. Wu, S.; Zheng, Y.; Ren, Y.; He, J.; Pu, X.; Huang, S.; Hao, Z.; and He, L. 2024. Self-weighted contrastive fusion for deep multi-view clustering.［用于深度多视图聚类的自加权对比融合。］IEEE Transactions on Multimedia, 26: 9150–9162.

31. Xie, M.-K.; Xiao, J.; Liu, H.-Z.; Niu, G.; Sugiyama, M.; and Huang, S.-J. 2023. Class-distribution-aware pseudo-labeling for semi-supervised multi-label learning.［用于半监督多标签学习的类别分布感知伪标签方法。］Advances in Neural Information Processing Systems, 36: 25731–25747.

32. Xie, W.; Lu, X.; Liu, Y.; Long, J.; Zhang, B.; Zhao, S.; and Wen, J. 2024. Uncertainty-aware pseudo-labeling and dual graph driven network for incomplete multi-view multi-label classification.［用于不完整多视图多标签分类的不确定性感知伪标签与双图驱动网络。］In Proceedings of the 32nd ACM international conference on multimedia, 6656–6665.

33. Zeng, P.; Yang, M.; Lu, Y.; Zhang, C.; Hu, P.; and Peng, X. 2023. Semantic invariant multi-view clustering with fully incomplete information.［完全不完整信息下的语义不变多视图聚类。］IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(4): 2139–2150.

34. Zhang, M.-L.; and Zhou, Z.-H. 2013. A review on multi-label learning algorithms.［多标签学习算法综述。］IEEE transactions on knowledge and data engineering, 26(8): 1819–1837.

35. Zhang, Q.; Wei, Y.; Han, Z.; Fu, H.; Peng, X.; Deng, C.; Hu, Q.; Xu, C.; Wen, J.; Hu, D.; et al. 2024. Multimodal fusion on low-quality data: A comprehensive survey.［低质量数据上的多模态融合：综合综述。］arXiv preprint arXiv:2404.18947.

36. Zhao, D.; Gao, Q.; Lu, Y.; and Sun, D. 2022. Non-aligned multi-view multi-label classification via learning view-specific labels.［通过学习视图特定标签进行非对齐多视图多标签分类。］IEEE Transactions on Multimedia, 25: 7235–7247.

37. Zhao, D.; Gao, Q.; Lu, Y.; Sun, D.; and Cheng, Y. 2021. Consistency and diversity neural network multi-view multi-label learning.［一致性与多样性神经网络多视图多标签学习。］Knowledge-Based Systems, 218: 106841.