DF²-VB 面向多视图多标签分类的双层模糊融合与视图特定提升

原题： DF²-VB: Dual-level Fuzzy Fusion with View-specific Boosting for Multi-view Multi-label Classification

作者： Yuena Lin[1]、Haichun Cai[2]、Yi Shan[1]、Hao Wei[1]、Yongjian Deng[1]、Zhen Yang[1]、Gengyu Lyu[1],*

[1] 北京工业大学计算机学院，北京
[2] 福州大学计算机与大数据学院，福州
电子邮箱： yuenalin@126.com；fjsmchc@163.com；yi.shan.bjut@gmail.com；haowei@emails.bjut.edu.cn；{yjdeng, yangzhen}@bjut.edu.cn；lyugengyu@gmail.com
* 通信作者。

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

原件页首声明译文： 本 CVPR 论文是由计算机视觉基金会提供的开放获取版本。除本水印外，它与录用版本相同；论文集的最终出版版本可在 IEEE Xplore 获取。原件页码为 33859-33868。

私人阅读译本说明： 本非官方译本依据用户上传的 10 页原始 PDF 制作，仅用于用户请求的私人阅读。原作者及出版方的权利、原有声明和标识均予保留；此处不推定或授予任何公开再分发许可。正文、定理陈述、算法、实验、致谢和 39 条参考文献完整保留。编号公式与图表采用原件高分辨率裁切，图表文字另附中文释义；参考文献保留原始英文书目信息。所供 10 页 PDF 没有附录，也没有给出定理 3.1、3.2 的证明；未见明确引用的补充材料文件或链接，故不补写证明或未提供材料。译者校核说明与原文内容分开标记。

摘要

多视图多标签分类（MVMLC）旨在利用共识信息和互补信息，为样本预测潜在相关的标签。现有 MVMLC 方法通常侧重于特征层融合或决策层融合：前者整合互补特征以得到表达能力更强的表示，后者聚合视图特定预测以更有效地利用标签监督。实际上，仅依赖特征层融合往往不能充分利用标签信息，并限制所学表示的判别能力；而纯粹的决策层融合对视图表示的表达能力关注不足，从而限制了分类性能。

为解决这些局限，我们提出 DF²-VB 双层融合框架。它将特征层融合与决策层融合结合起来，联合利用二者互补的优势，以弥补各自的不足。在特征融合层，模糊动态融合（Fuzzy Dynamic Fusion，FDF）模块将共识特征映射到兼容性更强的模糊特征空间，识别关键特征并抑制冗余特征，进一步融合出表达能力更强的共识表示，并增强决策层融合所需的视图特定预测。在决策融合层，视图特定提升（View-specific Boosting，VB）策略自适应地衡量样本及视图特定预测的重要性，强化监督信息的利用，从而提高特征层融合中的判别能力。FDF 与 VB 形成互补，共同增强模型的表达能力与判别能力，实现可靠预测。在多个公开数据集上的大量实验验证了我们的方法相较于先进 MVMLC 模型的优势。

1 引言

多视图学习旨在统一来自多种异构类型数据的信息，其中每一种类型的数据都被视为一个视图 [12, 25, 26, 30]。多视图多标签分类（MVMLC）是多视图学习中的一项复杂任务，重点在于结合多视图数据的信息，并识别与样本关联的多个可能标签 [4, 13, 15, 20, 38]。例如，在情绪分析 [3] 中，可以利用多种视图数据共同预测潜在的情绪标签，如恐惧、悲伤和愤怒。鉴于这些具有实际意义的应用，MVMLC 已受到越来越多的关注，并成为一个蓬勃发展的研究主题 [10, 19, 31]。

MVMLC 的核心在于从异构视图中挖掘关键信息，并学习能够准确捕获标签语义的特征 [24, 39]。为此，人们提出了两种主流 MVMLC 范式 [24]，即特征层融合和决策层融合。特征层融合方法旨在将多个视图的特征整合到统一的特征空间中 [5, 34]。为了缓解异构视图特征间的冲突，许多方法在特征融合过程中引入视图层加权机制 [8, 22, 28]。尽管这些方法在实践中增强了特征的表达能力，但它们往往未能充分利用监督信息，从而限制了所学特征的判别能力。相比之下，决策层融合方法通过结合多个视图特定分类器的预测，直接与监督信息交互，以提高可靠性 [27]。虽然这类方法表现出更强的预测能力，但它们通常对提升特征表达能力、进而支持预测关注不足。

总体而言，两种范式都暴露出固有局限：特征层融合没有充分利用具有判别性的监督指导，而决策层融合依赖于表达能力较弱的特征。幸运的是，两种范式的优势能够抵消彼此的局限：特征层融合可以通过缓解视图间的不一致冲突来生成表达能力更强的表示，而决策层融合能够通过有效利用监督信息来提高表示的判别能力。

受此启发，我们提出新模型 DF^2-VB，将两层融合统一起来，在弥补不足的同时形成具有较强表达能力和判别能力的表示。首先，DF^2-VB 为每个视图配备一对共识编码器和互补编码器，分别提取共识表示与互补表示。随后，在特征层融合阶段，提出模糊动态融合（FDF）模块，将不同视图的共识表示映射到兼容性更强的模糊表示空间。不同于采用视图层加权的传统方法，FDF 利用隶属函数识别并保留信息丰富的特征，同时抑制冗余特征，得到表达能力较强的融合共识表示。然后，将其注入互补表示，以增强决策层融合中的视图特定预测。最后，在决策层融合中，我们将多标签分类任务分解为多个简化的二分类子问题，并设计视图特定提升（VB）策略，评估样本和预测的重要性，使具有不同学习难度的数据能够参与协同决策，并进一步利用监督信息来强化特征层融合阶段表示的判别能力。通过结合 FDF 与 VB，DF^2-VB 有效弥补两种融合方式的不足，实现更加可靠的预测。

我们的贡献概括如下：

- 提出新颖的统一双层融合模型 DF^2-VB，联合优化特征层融合与决策层融合，以抵消二者的不足，实现可靠预测。
- 设计模糊动态融合以学习自适应的特征层权重，并提出视图特定提升以动态衡量样本和分类器的重要性，从而有效学习表达能力较强的表示并利用监督信息。
- 在六个公开基准上的实验表明，DF^2-VB 持续取得领先性能，并提高了所生成表示的表达能力与判别能力。

2 相关工作

2.1 多视图多标签学习

多视图多标签学习（MVML）通过同时处理多个异构视图和多个相关标签，对多视图学习进行了扩展 [16, 38, 39]。现有 MVML 方法可以分为两大类：基于特征层融合的方法 [7, 29] 和基于决策层融合的方法 [3, 6, 39]。特征层融合方法注重从多个视图学习统一且信息丰富的表示。SIMM [29] 联合提取共享信息与视图特定信息，并将其整合为融合表示，用于最终预测。E2FS [7] 联合进行视图间融合与特征增强，以加强特征选择，实现有效的 MVMLC。尽管这些方法提高了表示的表达能力，但它们通常未能充分利用监督信息，因而限制了判别能力。

相比之下，决策层融合方法结合视图特定预测，以实现可靠分类。ML-BVAE [3] 采用专家乘积机制，在推断网络中整合多个分类器的决策，从而同时预测多种情绪状态。I2VSLC [6] 通过在视图特定标签矩阵之间建立层次关系，探索视图间的标签相关性。尽管已经取得成功，现有 MVMLC 方法往往只关注特征层融合或决策层融合中的一种。这种分离使它们无法利用两种范式的互补优势，也促使我们开发一个统一框架，联合利用特征层融合与决策层融合的优点，实现更有效的多视图多标签分类。

2.2 模糊集理论

模糊集理论通过引入隶属度概念，扩展了经典的清晰集理论，从而能够更细致地刻画一个元素是否属于某个集合 [32]。定义在论域 $\mathbb{U}$ 上的模糊集 $\mathcal{A}$ 由隶属函数 $f_{\mathcal{A}}(a)$ 表示，该函数将每个元素 $a \in \mathbb{U}$ 映射到区间 $[0,\ 1]$ 内的实数。这里，$\mathbb{U}$ 表示针对某个特定问题所考虑的全部元素组成的集合，而 $f_{\mathcal{A}}(a)$ 量化了 a 属于模糊集 $\mathcal{A}$ 的程度 [37]。模糊集理论为不确定性建模提供了灵活框架。然而，适当隶属函数的设计往往依赖具体领域，并且需要先验知识。形式化定义如下。

定义： 函数 $f_{\mathcal{A}} : \mathbb{U} \to \mathbb{L} \subseteq \mathbb{R}$ 称为隶属函数。

定义： 包含论域 $\mathbb{U}$ 与隶属函数 $f_{\mathcal{A}}$ 的二元组 $\mathcal{A} = \left(\mathbb{U},\ f_{\mathcal{A}}\right)$ 称为模糊集。

根据上述定义，当 $\mathbb{L} = [0,\ 1]$ 时，$\mathcal{A}$ 是一个模糊集。当隶属函数依据 a 是否属于 $\mathcal{A}$，只取 0 和 1 两个值，即 $\mathbb{L} = \{0,\ 1\}$ 时，$\mathcal{A}$ 退化为清晰集。

3 所提出的方法

符号约定。 本文将特征空间定义为 $\mathcal{X} = \mathbb{R}^{d_1} \times \mathbb{R}^{d_2} \times \cdots \times \mathbb{R}^{d_V}$，其中 V 为视图数，第 v 个视图特征的维数为 d_v。给定含 N 个样本的数据集 $\mathcal{D} = \{\left(X_i,\ \boldsymbol{y}_i\right)\}_{i=1}^{N}$，我们用 $X_i = \left[\boldsymbol{x}_i^1,\ \boldsymbol{x}_i^2,\ \cdots,\ \boldsymbol{x}_i^V\right]$ 表示由 V 个视图特征组成的每个样本，以 $\boldsymbol{y}_i = \left[\boldsymbol{y}_{i,1},\ \boldsymbol{y}_{i,2},\ \cdots,\ \boldsymbol{y}_{i,L}\right]$ 表示 X_i 的真实标签，其中 L 为类别数。$\boldsymbol{y}_{i,j} = 1$（$1 \le j \le L$）表示样本 X_i 被标注为标签 j，否则 $\boldsymbol{y}_{i,j} = 0$。所提出的 DF²-VB 旨在整合不同视图的多样特征，构建一个强大的多标签分类器，为未见样本分配预测标签。

3.1 概述

一般的 MVMLC 方法联合利用共识表示与互补表示来训练多标签分类器。然而，直接结合二者具有挑战性：保持视图间相似性的共识表示只能产生判别性较弱的预测，而互补表示包含异构信息，往往会干扰特征融合并限制表示的表达能力。鉴于此，DF²-VB 探索了一种有效策略，包括特征提取与解耦过程、特征层融合过程以及决策层融合过程。

在特征层融合过程中，通过解耦损失 $\mathcal{L}_{de}$，将每个视图特征分解为共识表示与视图特定的互补表示。在特征层融合过程中，我们提出模糊动态融合（FDF）模块，将共识表示映射到兼容性更强的模糊表示空间。在该空间中衡量特征的重要性，识别关键特征并抑制冗余特征，将它们融合为统一的综合共识表示 $\widehat{\boldsymbol{C}}$。在决策层融合阶段，将融合后的综合共识表示注入每个互补表示，得到最终的视图特定表示 $\{\mathcal{H}^v\}_{v=1}^V$，以其为输入生成视图特定预测 $\{\widetilde{\boldsymbol{O}}^v\}_{v=1}^V$。为了进一步细化预测，我们将每个视图特定分类器分解为多个原子分类器。随后引入视图特定提升（VB）策略，对原子分类器和训练样本均进行自适应加权，从而增强跨视图协同预测，并提高表示的判别能力。框架如图 1 所示。

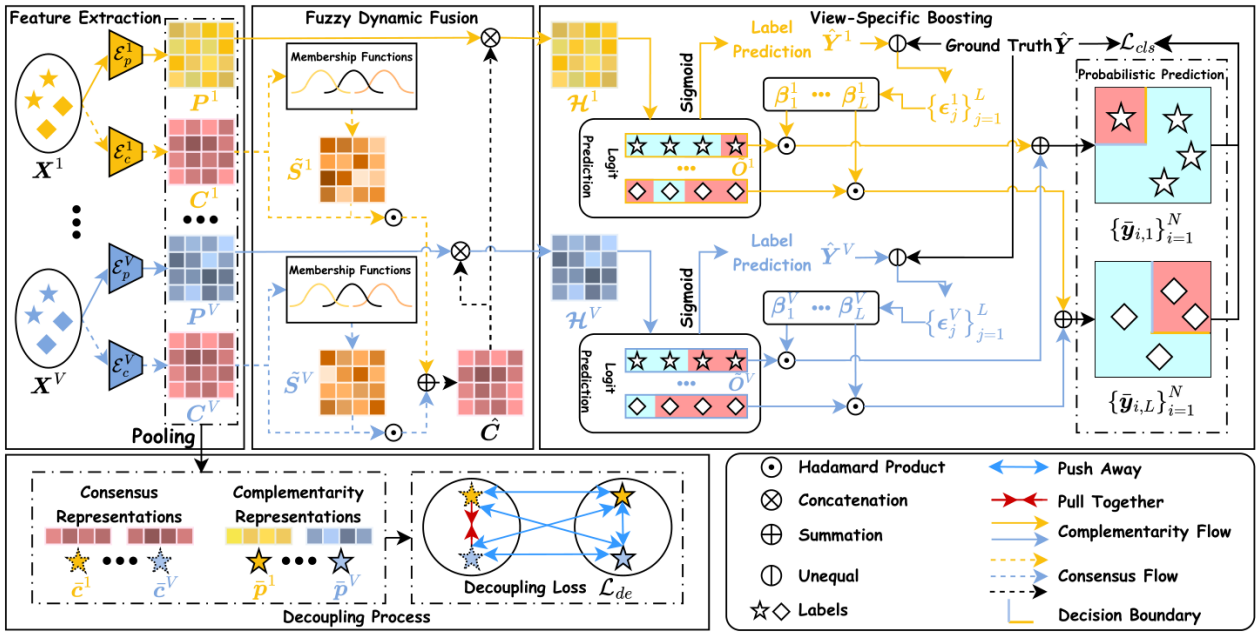


图 1： DF²-VB 的框架，由三个过程组成：（1）特征提取与解耦过程，将每个视图数据分解为相互独立的共识表示与互补表示；（2）特征层融合过程，其中模糊动态融合模块衡量特征重要性，以融合出综合共识表示；（3）决策层融合过程，其中视图特定提升策略衡量每个原子分类器的重要性，以构建可靠的决策边界。

图内文字释义： Feature Extraction＝特征提取；Fuzzy Dynamic Fusion＝模糊动态融合；View-Specific Boosting＝视图特定提升；Membership Functions＝隶属函数；Pooling＝池化；Consensus Representations＝共识表示；Complementarity Representations＝互补表示；Decoupling Process/Loss＝解耦过程/损失；Logit Prediction＝logit 预测；Label Prediction＝标签预测；Ground Truth＝真实标签；Probabilistic Prediction＝概率预测；Hadamard Product＝哈达玛积；Concatenation＝拼接；Summation＝求和；Unequal＝不等；Push Away/Pull Together＝推远/拉近；Complementarity Flow/Consensus Flow＝互补信息流/共识信息流；Labels＝标签；Decision Boundary＝决策边界。Sigmoid 为 S 形激活函数。

3.2 共识与互补信息提取

已有研究表明，共识与互补信息的结合有利于提高 MVMLC 模型的性能 [11, 29]。沿用先前工作，我们为每个视图数据引入独立编码器来提取对应信息，从具有不同维数的各类视图数据中提取共识表示与互补表示。这一过程定义为：

$$\boldsymbol{C}^v = \mathcal{E}_c^v(\boldsymbol{X}^v), \quad \boldsymbol{P}^v = \mathcal{E}_p^v(\boldsymbol{X}^v), \tag{1}$$

其中，$\boldsymbol{X}^v$ 是第 v 个视图的特征矩阵。$\mathcal{E}_c^v$ 与 $\mathcal{E}_p^v$ 为两个编码器，分别从第 v 个视图特征 $\boldsymbol{X}^v$ 中提取关键共识表示 $\boldsymbol{C}^v$ 和互补表示 $\boldsymbol{P}^v$。

由于视图特定互补表示具有固有异构性，容易造成视图冲突，而共识表示应在所有视图特征间保持相似性，因此分别融合二者比直接将二者一起融合更为适当。为此，我们将互补表示与共识表示解耦，打破它们之间的相互依赖，以促进后续双层融合过程。解耦损失定义为：

$$\mathcal{L}_{de} = -\frac{1}{V}\sum_{v=1}^{V}\log\frac{\ell_1^v}{\ell_1^v + \ell_2^v + \ell_3^v}, \tag{2}$$

其中：

$$\begin{cases} \ell_1^v = \sum_u e^{\vartheta(\bar{\boldsymbol{c}}^v, \bar{\boldsymbol{c}}^u)/\tau_{ind}} \\ \ell_2^v = \sum_u e^{\vartheta(\bar{\boldsymbol{c}}^v, \bar{\boldsymbol{p}}^u)/\tau_{ind}} \\ \ell_3^v = \sum_u e^{\vartheta(\bar{\boldsymbol{p}}^v, \bar{\boldsymbol{p}}^u)/\tau_{ind}} \\ \bar{\boldsymbol{c}}^v = \frac{1}{N}\sum_{i=1}^{N}\boldsymbol{c}_i^v \\ \bar{\boldsymbol{p}}^v = \frac{1}{N}\sum_{i=1}^{N}\boldsymbol{p}_i^v \end{cases}. \tag{3}$$

这里，$\vartheta(\cdot,\cdot)$ 定义为余弦相似度，τ_{ind} 为温度系数，$\boldsymbol{c}_i^v$ 为共识表示矩阵 $\boldsymbol{C}^v$ 的第 i 行，$\boldsymbol{p}_i^v$ 为互补表示矩阵 $\boldsymbol{P}^v$ 的第 i 行。与通常通过实例级损失实现解耦的方法 [17, 18] 不同，我们利用均值池化，得到用于解耦过程的汇总共识表示 $\bar{\boldsymbol{c}}^v$ 与汇总互补表示 $\bar{\boldsymbol{p}}^v$，从而将复杂度由 $\mathcal{O}(V^2N^2)$ 降至 $\mathcal{O}(V^2)$。

定理 3.1。对于 $v, u \in \{1, \cdots, V\}$，$\mathcal{L}_{de}$ 能够增大 $I(\boldsymbol{C}^v; \boldsymbol{C}^u)$ 的下界，同时减小 $I(\boldsymbol{C}^v; \boldsymbol{P}^u)$ 与 $I(\boldsymbol{P}^v; \boldsymbol{P}^u)$ 的下界。

这一定理意味着，式（2）增强共识表示之间的统计依赖，同时抑制共识表示与互补表示之间的统计依赖，以及互补表示之间的统计依赖。

3.3 模糊动态融合

多数基于特征层融合的方法通过为不同视图分配特定权重来实现特征融合 [23]。虽然这些方法在一定程度上缓解了视图特征之间的冲突，但它们忽略了对特征元素层面重要性与冗余性的处理，未能进一步促进融合。因此，我们提出模糊动态融合（FDF）策略，通过自适应衡量特征元素的重要性来解决上述问题。

FDF 利用模糊逻辑 [32, 33]，将所有共识表示变换到模糊表示空间。相较于通常的特征空间，模糊表示空间可以被视为更一般化的特征空间 [35]，因而在组合异构视图特征时具有更好的兼容性。为实现这一变换，我们引入 K 个高斯隶属函数 [9, 36]，丰富共识表示的语义信息：

$$\boldsymbol{s}_{i,j,k}^{v}=\exp\left\{-\frac{\left(\boldsymbol{c}_{i,j}^{v}-\boldsymbol{m}_{j,k}\right)^{2}}{2\boldsymbol{\delta}_{j,k}^{2}}\right\},k=1,2,\cdots,K,\quad(4)$$

其中，$\boldsymbol{c}_{i,j}^{v}$ 是 $\boldsymbol{c}_{i}^{v}$ 的第 j 个特征元素。$\boldsymbol{m}_{j,k}$ 与 $\boldsymbol{\delta}_{j,k}$ 分别为第 k 个高斯隶属函数的可学习均值和标准差。$\boldsymbol{s}_{i,j,k}^{v}$ 是衡量 $\boldsymbol{c}_{i}^{v}$ 与第 k 个模糊表示空间匹配程度的隶属度，并被视为特征重要性。显然，这种特征重要性是从更细粒度的逐元素视角生成的。借助可学习的隶属函数，特征重要性能够自适应调整，在保留关键信息的同时抑制无意义信息。与分配视图权重的方法相比，它能更好地评估特征元素的重要性与冗余性。

在 K 个隶属度中，我们通过最大池化算子选出最终隶属度：

$$\tilde{\boldsymbol{s}}_{i,j}^{v}=\max_{k}\{\boldsymbol{s}_{i,j,k}^{v}\},k=1,2,\cdots,K.\qquad(5)$$

该隶属度对应于信息最丰富的共识特征元素，进一步提高表示的表达能力并促进融合过程。得到共识表示的权重后，将它们融合为综合共识表示：

$$\hat{\boldsymbol{C}}=Norm\left(\sum_{v=1}^{V}\tilde{\boldsymbol{S}}^{v}\odot\boldsymbol{C}^{v}\right),\qquad(6)$$

其中，$\widetilde{\boldsymbol{S}}^{v}$ 是隶属度矩阵，其元素由式（5）得到；$\odot$ 表示哈达玛积，$Norm(\cdot)$ 为归一化算子。

定理 3.2。与一般的视图层加权方法相比，特征层加权策略 FDF 能够产生更小的 Rademacher 复杂度 [1]。

更小的 Rademacher 复杂度对应更好的泛化能力，这说明了 FDF 相对于主流视图层加权方法的优势。

3.4 视图特定提升

视图特定的互补表示是实现可靠预测的关键内容，但它们往往包含异构性，妨碍特征顺利融合。鉴于此，我们在决策层融合阶段组合所有视图的互补信息。然而，仅有视图特定互补信息不足以指导准确预测，因为不可或缺的共识信息已经从视图特征中剥离。为了补全支持基分类器预测的有益信息，我们将视图特定互补表示与综合共识表示合并，作为每个视图的最终表示：

$$\boldsymbol{\mathcal{H}}^{v}=\hat{\boldsymbol{C}}\|\boldsymbol{P}^{v},\qquad(7)$$

其中，$\|$ 为拼接算子，$\boldsymbol{P}^{v}$ 为第 v 个视图的互补表示，$\boldsymbol{\mathcal{H}}^{v}$ 为第 v 个视图的最终表示。

由于单个视图的表示蕴含与标签有关的特定知识，探索视图表示与标签之间相应的激活关系十分重要。为揭示细致的激活关系，我们将多标签分类问题分解为多个细粒度的二分类子问题。相应地，每个视图特定的多标签基分类器的预测，被拆分为原子分类器的预测：

$$\begin{aligned} \tilde{\boldsymbol{o}}_i^v &= g^v(\boldsymbol{\mathcal{H}}_i^v) = [\tilde{\boldsymbol{o}}_{i,1}^v, \tilde{\boldsymbol{o}}_{i,2}^v, \cdots, \tilde{\boldsymbol{o}}_{i,L}^v], \\ \tilde{\boldsymbol{y}}_{i,j}^v &= \sigma(\tilde{\boldsymbol{o}}_{i,j}^v), \end{aligned} \tag{8}$$

其中，$g^v(\cdot)$ 为第 v 个视图的视图特定基分类器，$\boldsymbol{\mathcal{H}}_i^v$ 为第 v 个视图中第 i 个样本的最终表示，$\sigma(\cdot)$ 为 Sigmoid 函数。$\tilde{\boldsymbol{o}}_{i,j}^v$ 是第 v 个视图中预测第 j 个标签的原子分类器的 logit 值；$\tilde{\boldsymbol{y}}_{i,j}^v \in (0, 1)$ 为该原子分类器的置信度预测。

在决策层融合阶段，我们引入视图特定提升（VB）策略，充分融合各个原子分类器的优势，构建强分类器。VB 的关键是确定样本和原子分类器的重要性，这促使我们在一个小批次 B 中，按如下方式计算每个原子分类器的错误率：

$$\begin{aligned} \boldsymbol{\epsilon}_{j,t}^v &= \frac{\sum_i \boldsymbol{\omega}_{i,t} \cdot \mathbb{I}(\hat{\boldsymbol{y}}_{i,j}^v \neq \boldsymbol{y}_{i,j})}{\sum_i \boldsymbol{\omega}_{i,t}}, \\ \hat{\boldsymbol{y}}_{i,j}^v &= \mathbb{I}(\tilde{\boldsymbol{y}}_{i,j}^v > \zeta), \end{aligned} \tag{9}$$

其中，$\boldsymbol{\omega}_{i,t}$ 是第 t 次提升迭代中第 i 个样本的权重，$\boldsymbol{\omega}_{i,0}$ 初始化为 $1/|B|$。$\mathbb{I}(\cdot)$ 为指示函数，用来统计小批次 B 中的错误预测，ζ 为阈值。$\hat{\boldsymbol{y}}_{i,j}^v \in \{0, 1\}$ 为第 v 个视图特征的第 j 个原子分类器的标签预测。$\boldsymbol{\epsilon}_{j,t}^v$ 为利用 $\boldsymbol{\mathcal{H}}^v$ 预测第 j 个标签的原子分类器的错误率。

获得错误率之后，原子分类器识别表示与标签之间激活关系的能力就变得清楚，也就是说，标签与视图表示之间的对应关系得以识别。原子分类器的重要性根据错误率按下述规则控制：

$$\begin{aligned} \boldsymbol{\beta}_{j,t+1}^v &= \begin{cases} \frac{1}{2}\log\frac{1-\boldsymbol{\epsilon}_{j,t}^v+\eta}{\boldsymbol{\epsilon}_{j,t}^v+\eta}, & \boldsymbol{\epsilon}_{j,t}^v < 0.5 \\ 0, & \boldsymbol{\epsilon}_{j,t}^v \geq 0.5 \end{cases}, \\ \tilde{\boldsymbol{\beta}}_{j,t+1}^v &= \frac{\exp\left(\boldsymbol{\beta}_{j,t+1}^v\right)}{\sum_u \exp\left(\boldsymbol{\beta}_{j,t+1}^u\right)}, \end{aligned} \tag{10}$$

其中，$\boldsymbol{\beta}_{j,t+1}^v$ 是在第 t 次提升迭代中，利用 $\boldsymbol{\mathcal{H}}^v$ 预测第 j 个标签的原子分类器更新后的权重；η 为避免数值溢出而设置的一个小值。当某个原子分类器无法提供可靠预测时，即 $\boldsymbol{\epsilon}_{j,t}^v \geq 0.5$，构造强分类器时将降低它的权重，否则很容易损害最终预测。更新原子分类器的权重之后，各样本相对于各原子分类器的分类难度就变得清晰。我们按如下更新规则调整样本权重：为难以分类的样本分配较高权重，为容易分类的样本分配较低权重，具体如下式：

$$\boldsymbol{\omega}_{i,t+1} = \frac{\boldsymbol{\omega}_{i,t} \cdot \exp\left(-\boldsymbol{\beta}_{j,t+1}^v \boldsymbol{y}_{i,j} \hat{\boldsymbol{y}}_{i,j}^v\right)}{\sum_i \boldsymbol{\omega}_{i,t}}. \tag{11}$$

最后，聚合所有视图的 logit 值，得到第 j 个标签的概率预测 $\bar{\boldsymbol{y}}_{i,j}$：

$$\bar{\boldsymbol{y}}_{i,j} = \sigma\left(\sum_{v} \tilde{\boldsymbol{\beta}}_{j,T}^{v} \cdot \tilde{\boldsymbol{o}}_{i,j}^{v}\right), \tag{12}$$

其中， T 为提升迭代的总次数。为了训练联合分类器，我们采用二元交叉熵作为多标签分类损失：

$$\mathcal{L}_{cls} = -\sum_{i=1}^{N}\sum_{j=1}^{L}\left[\boldsymbol{y}_{i,j}\log\bar{\boldsymbol{y}}_{i,j} + (1-\boldsymbol{y}_{i,j})\log(1-\bar{\boldsymbol{y}}_{i,j})\right]. \tag{13}$$

总损失函数为：

$$\mathcal{L} = \mathcal{L}_{cls} + \alpha\mathcal{L}_{de}, \tag{14}$$

其中， α 为惩罚系数。推断时，各原子分类器的权重已经确定，利用式（12）得到最终预测。DF²-VB 训练算法的细节列于算法 1。

算法 1 所提出的 DF²-VB 的训练过程

输入： MVML 数据集 $\mathcal{D} = \{(X_i, \boldsymbol{y}_i)\}_{i=1}^{N}$、惩罚系数 α、训练轮数 E。

输出： 多标签分类模型 DF²-VB。

对训练轮次 $e \le E$ 循环：
    // 特征提取阶段
    对视图编号 $v \le V$ 循环：
        通过式（1）提取共识表示 $\boldsymbol{C}^v$ 与互补表示 $\boldsymbol{P}^v$；
    结束视图循环。
    利用式（2）对共识表示与互补表示解耦。
    // 特征层融合阶段
    对视图编号 $v \le V$ 循环：
        通过式（5）计算隶属度，作为特征层权重 $\widetilde{\boldsymbol{S}}^v$。
    结束视图循环。
    通过式（6）得到综合共识表示 $\widehat{\boldsymbol{C}}$。
    // 决策层融合阶段
    对视图编号 $v \le V$ 循环：
        通过式（7）得到视图表示 $\mathcal{H}^v$；
    结束视图循环。
    对提升迭代 $t \le T$ 循环：
        通过式（9）计算所有原子分类器的错误率；
        通过式（10）更新原子分类器的权重；
        通过式（11）更新样本权重。
    结束提升循环。
    通过式（12）计算模型预测；
    通过损失式（14）更新模型参数。
结束训练轮次循环。

算法 1 原文排版保留：

Algorithm 1 Training procedure of proposed DF^2-VB.

Input: MVML dataset $\mathcal{D} = \{(X_i, \boldsymbol{y}_i)\}_{i=1}^{N}$, the penalty coefficient α, number of epochs E.
Output: The multi-label classification model DF^2-VB.
Process:

for Training epoch $e \leq E$ **do**
  // Feature Extraction Phase
  for View number $v \leq V$ **do**
    Extract consensus representation $\boldsymbol{C}^v$ and complementarity representation $\boldsymbol{P}^v$ via Eq. (1);
  end for
  Decouple consensus and complementarity representations with Eq. (2).
  // Feature-level Fusion Phase
  for View number $v \leq V$ **do**
    Calculate membership degrees as feature-level weights $\tilde{\boldsymbol{S}}^v$ via Eq. (5).
  end for
  Obtain the comprehensive consensus representation $\hat{\boldsymbol{C}}$ via Eq. (6).
  // Decision-level Fusion Phase
  for View number $v \leq V$ **do**
    Obtain the view representation $\boldsymbol{\mathcal{H}}^v$ via Eq. (7);
  end for
  for Boosting iteration $t \leq T$ **do**
    Calculate error rates for all the atom classifiers via Eq. (9);
    Update weights for atom classifiers via Eq. (10);
    Update sample weights via Eq. (11).
  end for
  Calculate model predictions via Eq. (12);
  Update model parameters through the loss Eq. (14).
end for

4 实验

4.1 实验设置

我们使用 6 个公开的多视图多标签数据集评估模型性能，包括 Emotions、Scene、Yeast、Corel5k、Pascal 和 Espgame。为了公平比较，采用 6 个先进基线模型，包括 FIMAN [27]、D-VSM [14]、DIMC [26]、ML-BVAE [3]、VAMS [24] 和 TMvML [39]，并引入广泛使用的平均精度（Average Precision，AP）、单错误（One Error，OE）、排序损失（Ranking Loss，RL）、覆盖度（Coverage，Cov）和微平均 F1（Micro F1，MiF1）作为指标。这些指标的详细定义见文献 [21]。

4.2 多标签分类

本节开展多标签分类任务，比较所提出的 DF²-VB 与其他先进基线之间的性能差距。为获得可靠结果，在每个数据集上进行五折交叉验证，表 1 报告各指标的均值和标准差。根据 210 个实验结果，我们得到以下观察。

（1）在各项指标的大多数情况下，所提出的 DF²-VB 优于其他基线模型。具体而言，DF²-VB 在所有情况下均优于 ML-BVAE、FIMAN、TMvML 和 VAMS，并分别在 93.3% 和 90.0% 的情况下优于 DIMC 和 D-VSM。这些比较结果有力地说明 DF²-VB 是一种很有前景的 MVMLC 模型。

（2）与 FIMAN、DIMC 等特征层融合方法相比，DF²-VB 在所有数据集的大多数指标上展现出优势。这些方法只关注特征层融合，由于未能充分利用监督信息的优势，模型性能的进一步提升受到限制。相较之下，DF²-VB 利用监督信息强化模型预测，取得了明显更好的性能，尤其体现在 MiF1 指标上。

（3）与 ML-BVAE、TMvML 等决策层融合方法相比，DF²-VB 在所有评价指标上都取得显著提升。这些方法没有认识到从所有视图构建富有表达力的表示的必要性。相比之下，DF²-VB 通过自适应的特征层权重融合视图特征，对特征元素的重要性评分，从而学习表达能力更强的表示，以进行准确预测。

表 1： DF²-VB 与比较模型的性能比较，最佳性能用粗体表示。OE、RL 和 Cov 越低越好；AP 和 MiF1 越高越好。为便于阅读，下列六个数据集分别展示；每个数据集上下两组原始裁切均重复“数据集”和“指标”列，上组为 FIMAN、D-VSM、DIMC，下组为 ML-BVAE、VAMS、TMvML、DF²-VB。数据与粗体均保持原样。

表 1（续组 1）：**Emotions**

Datasets	Metrics	FIMAN	D-VSM	DIMC
Emotions	OE ↓	0.258±0.042	0.214±0.046	0.303±0.032
	RL ↓	0.161±0.026	0.137±0.015	0.183±0.019
	Cov ↓	7.796±0.189	1.624±0.038	1.873±0.037
	AP ↑	0.806±0.027	0.835±0.027	0.782±0.021
	MiF1 ↑	0.671±0.014	0.700±0.034	0.482±0.010

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Emotions	OE ↓	0.568±0.029	0.235±0.027	0.319±0.046	**0.206±0.024**
	RL ↓	0.423±0.035	0.144±0.013	0.184±0.019	**0.123±0.009**
	Cov ↓	3.163±0.242	1.659±0.055	1.914±0.066	**1.589±0.077**
	AP ↑	0.572±0.022	0.826±0.012	0.774±0.023	**0.840±0.012**
	MiF1 ↑	0.107±0.091	0.692±0.015	0.635±0.033	**0.724±0.025**

表 1（续组 2）：**Yeast**

Datasets	Metrics	FIMAN	D-VSM	DIMC
Yeast	OE ↓	0.257±0.013	**0.215±0.010**	0.248±0.009
	RL ↓	0.187±0.005	0.172±0.003	0.180±0.005
	Cov ↓	6.673±0.074	6.562±0.133	6.538±0.094
	AP ↑	0.740±0.007	0.760±0.005	0.738±0.006
	MiF1 ↑	0.111±0.008	0.655±0.008	0.468±0.003

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Yeast	OE ↓	0.253±0.012	0.222±0.008	0.250±0.010	0.220±0.018
	RL ↓	0.204±0.007	0.168±0.004	0.180±0.006	**0.158±0.006**
	Cov ↓	6.706±0.094	6.376±0.096	6.509±0.099	**6.154±0.092**
	AP ↑	0.712±0.007	0.763±0.009	0.745±0.007	**0.778±0.011**
	MiF1 ↑	0.479±0.008	0.656±0.012	0.577±0.007	**0.683±0.010**

表 1（续组 3）：Scene

Datasets	Metrics	FIMAN	D-VSM	DIMC
Scene	OE ↓	0.280±0.018	0.189±0.016	0.263±0.009
	RL ↓	0.107±0.006	**0.058±0.007**	0.086±0.004
	Cov ↓	0.628±0.020	0.372±0.051	0.516±0.024
	AP ↑	0.827±0.010	0.890±0.011	0.844±0.004
	MiF1 ↑	0.616±0.008	0.777±0.015	0.308±0.002

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Scene	OE ↓	0.464±0.032	0.198±0.014	0.207±0.011	**0.183±0.007**
	RL ↓	0.171±0.017	0.070±0.010	0.078±0.015	**0.058±0.002**
	Cov ↓	0.942±0.090	0.434±0.058	0.459±0.070	**0.370±0.013**
	AP ↑	0.717±0.023	0.878±0.014	0.795±0.004	**0.893±0.003**
	MiF1 ↑	0.304±0.095	0.748±0.016	0.713±0.023	**0.779±0.010**

表 1（续组 4）：Corel5k

Datasets	Metrics	FIMAN	D-VSM	DIMC
Corel5k	OE ↓	0.489±0.017	0.410±0.018	0.613±0.019
	RL ↓	0.085±0.000	0.084±0.004	0.114±0.003
	Cov ↓	53.94±0.790	53.21±1.947	70.80±2.256
	AP ↑	0.430±0.007	0.475±0.008	0.333±0.008
	MiF1 ↑	0.361±0.009	0.399±0.004	0.029±0.000

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Corel5k	OE ↓	0.626±0.019	0.432±0.016	0.575±0.014	**0.363±0.019**
	RL ↓	0.188±0.008	0.082±0.004	0.152±0.002	**0.068±0.004**
	Cov ↓	108.7±4.792	53.20±2.218	84.87±3.437	**42.65±2.184**
	AP ↑	0.286±0.000	0.452±0.009	0.369±0.006	**0.540±0.014**
	MiF1 ↑	0.025±0.001	0.372±0.005	0.414±0.008	**0.437±0.014**

表 1（续组 5）：Pascal

Datasets	Metrics	FIMAN	D-VSM	DIMC
Pascal	OE ↓	0.313±0.011	0.274±0.008	0.438±0.011
	RL ↓	0.118±0.003	0.077±0.001	**0.063±0.002**
	Cov ↓	3.486±0.081	2.342±0.044	**1.908±0.065**
	AP ↑	0.721±0.003	0.767±0.003	0.695±0.008
	MiF1 ↑	0.008±0.002	0.636±0.004	0.136±0.001

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Pascal	OE ↓	0.426±0.007	0.283±0.006	0.283±0.010	**0.269±0.012**
	RL ↓	0.106±0.001	0.101±0.002	0.111±0.006	0.066±0.004
	Cov ↓	2.966±0.028	2.231±0.038	2.482±0.022	2.094±0.096
	AP ↑	0.659±0.002	0.759±0.008	0.706±0.006	**0.784±0.009**
	MiF1 ↑	0.385±0.031	0.426±0.026	0.394±0.014	**0.648±0.011**

表 1（续组 6）：Espgame

Datasets	Metrics	FIMAN	D-VSM	DIMC
Espgame	OE ↓	0.628±0.004	**0.464±0.010**	0.615±0.013
	RL ↓	0.154±0.002	0.133±0.003	0.141±0.000
	Cov ↓	102.8±1.183	86.75±1.634	92.21±0.113
	AP ↑	0.284±0.002	0.364±0.003	0.273±0.001
	MiF1 ↑	0.242±0.002	0.332±0.003	0.034±0.000

Datasets	Metrics	ML-BVAE	VAMS	TMvML	DF^2-VB
Espgame	OE ↓	0.615±0.010	0.470±0.011	0.690±0.023	**0.464±0.004**
	RL ↓	0.211±0.002	0.144±0.002	0.217±0.014	**0.123±0.001**
	Cov ↓	136.5±1.681	89.91±1.816	133.4±7.478	**82.39±0.751**
	AP ↑	0.257±0.001	0.266±0.002	0.223±0.012	**0.375±0.002**
	MiF1 ↑	0.008±0.002	0.320±0.000	0.022±0.001	**0.348±0.003**

此外，我们采用广泛使用的统计检验，即 Friedman 检验 [2]，比较和分析所有参评方法的相对性能。如表 2 所示，关于所有比较算法之间性能“可区分”的原假设，在 0.05 显著性水平上被拒绝。进一步地，我们采用事后 Bonferroni-Dunn 检验 [2]，比较各算法的相对性能。图 2 给出了各评价指标的临界差异（CD）图，每种算法的平均排名标记在坐标轴上。根据图 2，可以观察到 DF^2-VB 在所有指标上具有最佳性能。

Metrics	τ_F	Critical Difference Value
Ranking Loss	19.2056	
Coverage	13.9304	4.7233
Average Precision	38.4038	Methods: 7, Datasets: 6
Micro-F1	29.2012	

表 2： 各评价指标的 Friedman 统计量 τ_F（显著性水平为 0.05）。表内 Metrics＝指标；Critical Difference Value＝临界差异值；Methods＝方法数量（7）；Datasets＝数据集数量（6）。四项指标依次为排序损失、覆盖度、平均精度和微平均 F1。

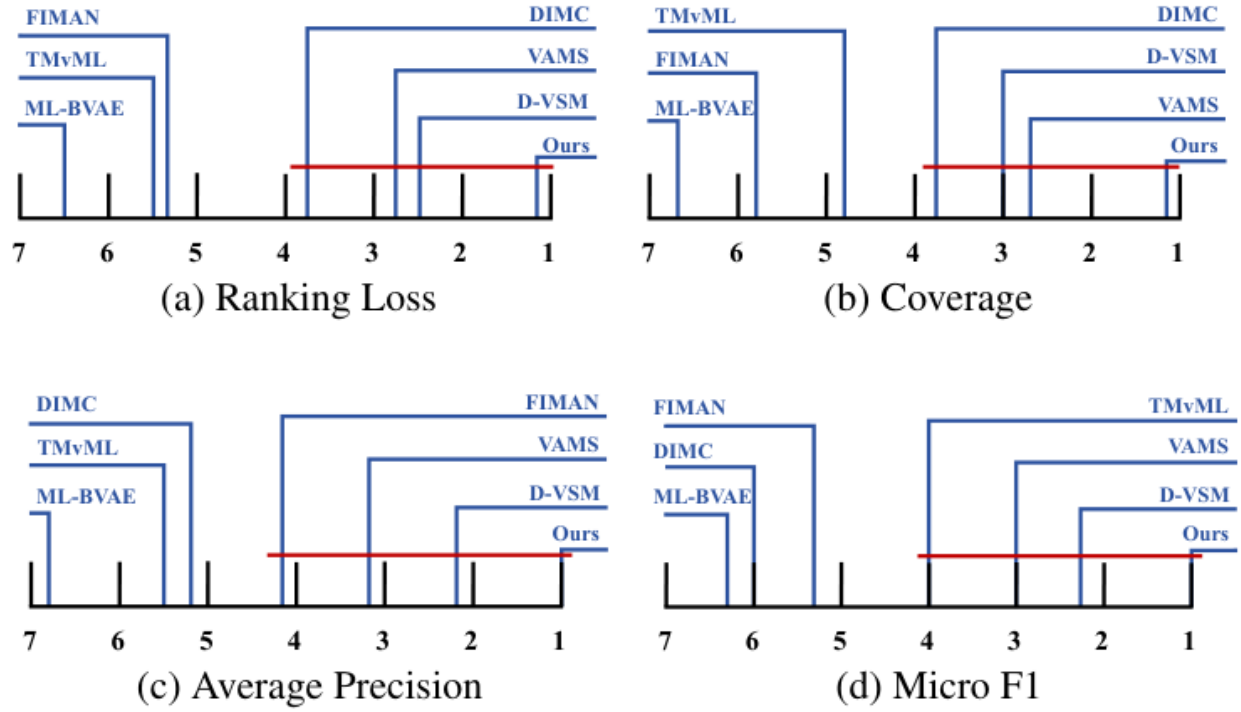


图 2： 所提出模型与所有其他比较算法的 Bonferroni-Dunn 检验结果（在 0.05 显著性水平下，CD＝3.290）。未与 DF²-VB 相连的算法显著劣于 DF²-VB。四个子图为：（a）排序损失；（b）覆盖度；（c）平均精度；（d）微平均 F1。Ours 表示本文方法。原图按前两个与后两个子图分为上下两行，顺序不变。

综上，所提出的 DF²-VB 将特征层融合与决策层融合结合起来，获得具有表达能力和判别能力的表示，相较于现有 MVMLC 方法持续表现出最佳性能。

4.3 消融研究

在消融研究中，我们将 DF²-VB 与四个退化变体进行比较，以评估每个组件的有效性：（1）去掉 FDF 和 VB 的 DF²-VB，即直接使用所有视图共识表示的平均值进行预测的模型；（2）去掉 VB 的 DF²-VB，即使用 FDF 得到的综合共识表示 $\widehat{C}$ 进行预测的模型；（3）去掉 FDF 的 DF²-VB，即使用平均共识表示并结合 VB 进行预测的模型；（4）去掉 DL 的 DF²-VB，即不包含解耦损失的模型。

DF²-VB 与其他变体的比较结果见表 3。结果表明，每个组件都有助于提高模型性能，体现了所有组件的作用。此外，不含 VB 的模型总体上弱于不含 FDF 的模型；原文据此认为，特征层融合比决策层融合更为关键。最后，我们发现所提出的 DF²-VB 在各变体中表现最佳，说明特征层融合与决策层融合互利互补。两种融合方式之间的这种互补性有力地支持了我们的研究动机。

Emotions	Average Precision	One Error	Ranking Loss	Coverage	Micro-F1
W/o FDF & VB	0.828 ± 0.017	0.238 ± 0.023	0.135 ± 0.016	1.644 ± 0.096	0.595 ± 0.012
W/o VB	0.829 ± 0.011	0.231 ± 0.021	0.133 ± 0.009	1.633 ± 0.057	0.633 ± 0.011
W/o FDF	0.834 ± 0.014	0.221 ± 0.028	0.131 ± 0.013	1.626 ± 0.090	0.716 ± 0.014
W/o DL	0.838 ± 0.012	0.209 ± 0.022	**0.123 ± 0.012**	1.599 ± 0.072	0.722 ± 0.015
DF^2-VB	**0.840 ± 0.012**	**0.206 ± 0.024**	**0.123 ± 0.009**	**1.589 ± 0.077**	**0.724 ± 0.025**
Scene	Average Precision	One Error	Ranking Loss	Coverage	Micro-F1
W/o FDW & VB	0.884 ± 0.008	0.194 ± 0.012	0.069 ± 0.008	0.430 ± 0.046	0.767 ± 0.011
W/o VB	0.888 ± 0.006	0.188 ± 0.011	0.064 ± 0.004	0.406 ± 0.027	0.774 ± 0.009
W/o FDF	0.890 ± 0.004	0.190 ± 0.007	0.060 ± 0.004	0.384 ± 0.027	0.775 ± 0.011
W/o DL	0.892 ± 0.009	0.186 ± 0.015	0.059 ± 0.006	0.374 ± 0.031	0.776 ± 0.010
DF^2-VB	**0.893 ± 0.003**	**0.183 ± 0.007**	**0.058 ± 0.002**	**0.370 ± 0.013**	**0.779 ± 0.010**

表 3： DF²-VB 与四种变体的消融比较。上半部分为 Emotions，下半部分为 Scene。Average Precision＝平均精度；One Error＝单错误；Ranking Loss＝排序损失；Coverage＝覆盖度；Micro-F1＝微平均 F1。W/o 表示去掉相应组件，DL 表示解耦损失。Scene 第一行的“W/o FDW & VB”按原表保留。

4.4 敏感性分析

在敏感性分析中，我们探索模型性能与两个关键超参数之间的关系，即高斯隶属函数的数量 K 和惩罚系数 α。图 3 展示了不同的超参数设置及相应模型性能。可以观察到，这两个超参数都会影响模型性能。随着超参数增大，模型性能起初逐渐提升，随后下降。在我们的实验中，对于 Scene 和 Corel5K 数据集，K 的最优值分别为 $\{2,\ 2\}$，α 的最优值分别为 $\{0.001,\ 0.0015\}$。

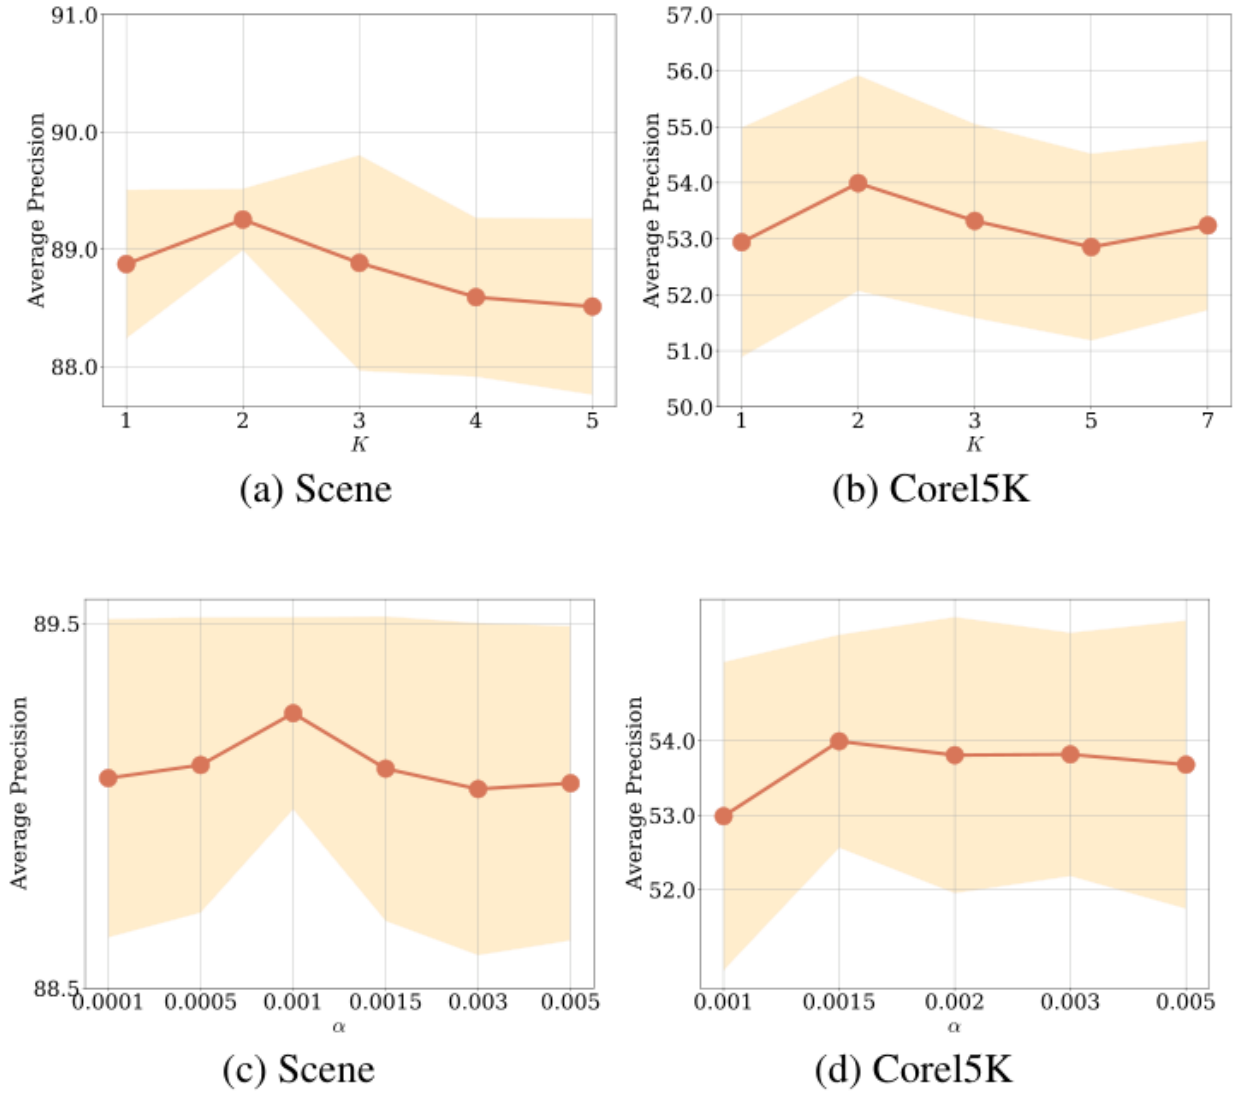


图 3： 关于 K 与 α 的超参数敏感性分析。（a）Scene 上的 K；（b）Corel5K 上的 K；（c）Scene 上的 α；（d）Corel5K 上的 α。纵轴 Average Precision 表示平均精度。原图按前两个与后两个子图分为上下两行，顺序不变。

4.5 收敛性分析

我们在四个数据集上对所提出方法进行收敛性分析，包括 Scene、Corel5K、Pascal 和 Espgame。图 4 展示了训练期间损失值的变化。可以观察到，在各数据集上，损失值起初下降，随后趋于稳定。这一现象从经验上说明 DF²-VB 在训练过程中收敛。

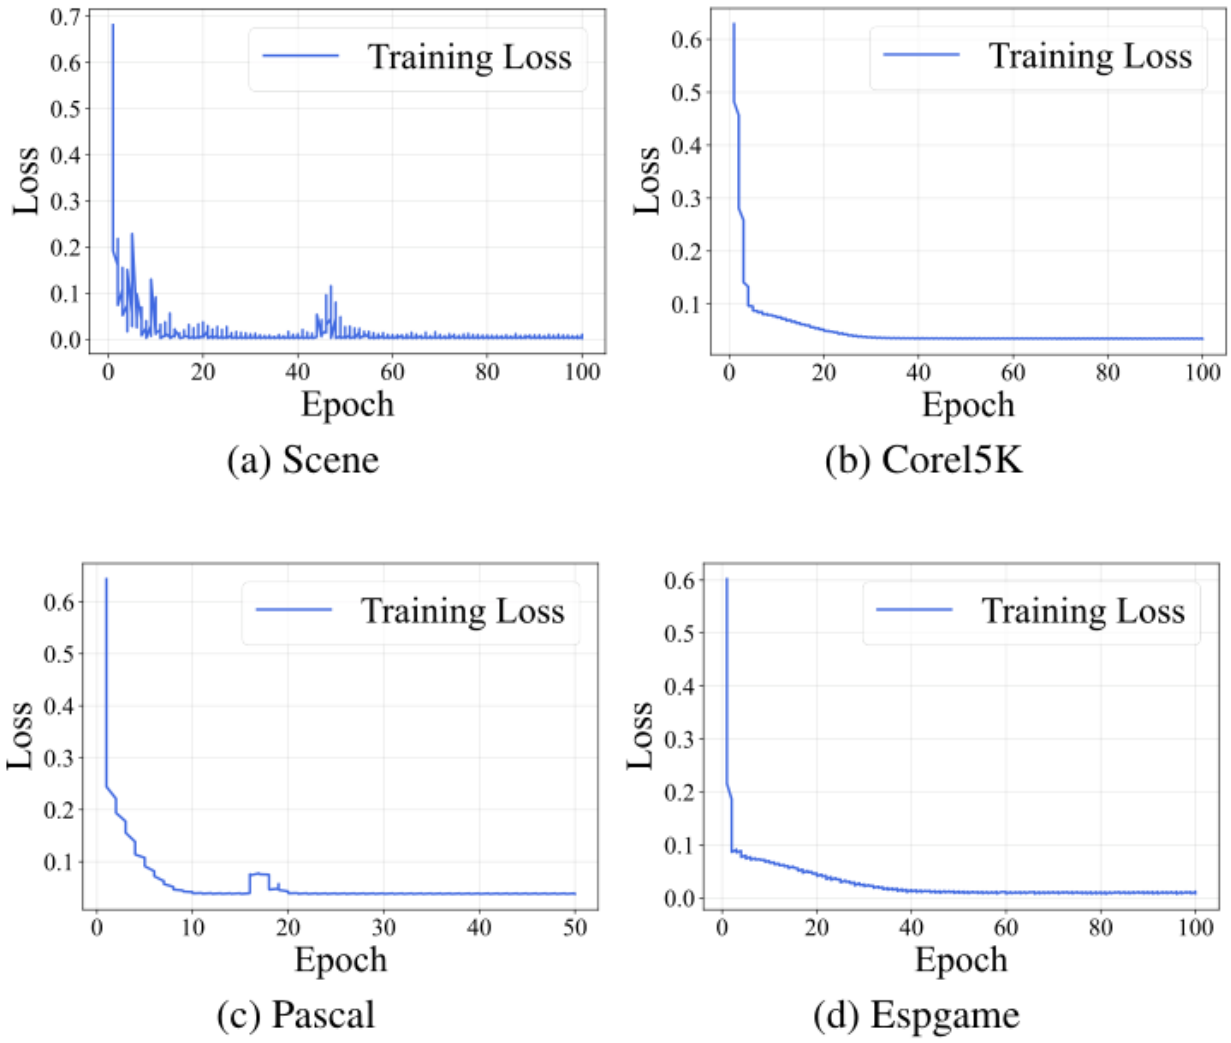


图 4： 不同数据集上的损失函数收敛情况。（a）Scene；（b）Corel5K；（c）Pascal；（d）Espgame。Training Loss＝训练损失；Loss＝损失；Epoch＝训练轮次。原图按前两个与后两个子图分为上下两行，顺序不变。

5 结论

本文提出 DF²-VB，一种统一的双层融合 MVMLC 模型。它联合利用特征层融合与决策层融合的互补优势，以弥补各自的不足，即判别能力受限以及表示表达能力不足。通过联合引入 FDF 增强特征层兼容性、引入 VB 强化决策层协作，DF²-VB 有效利用异构视图数据中的共识信息与互补信息，提高模型性能。在多个数据集上的大量实验表明，DF²-VB 持续优于先进方法，证实了双层融合设计的成功。

致谢

本研究得到中国国家自然科学基金（编号 62306020）、北京市科学技术协会青年人才托举工程（编号 BYESS2024199）、北京市自然科学基金（编号 L244009）、中央引导地方科技发展资金（编号 2024ZY0124）以及国家重点研发计划（编号 2023YFB3107100）的支持。第一作者获得中国教育部国家留学基金管理委员会（CSC）以及中国科协青年科技人才培育工程博士生专项计划的资助。

译者校核说明

以下说明不属于原文研究结论，不改动原始公式或实验数据。

- 第 4.2 节原文使用“null hypothesis of distinguishable performance”这一表述。本译文保留其“性能可区分的原假设被拒绝”的字面意思；该用语与常见 Friedman 检验的原假设表述存在差异，不将其静默改写为另一命题。
- 第 4.3 节原文先称“去掉 VB 的模型通常弱于去掉 FDF 的模型”，随后认为“特征层融合更关键”。这两句的推论方向存在疑问，本译文照录，并以“原文据此认为”标明，而不擅自修改作者结论。
- 表 3 的 Scene 部分将第一种变体写作“W/o FDW & VB”，正文使用“FDF”。原始表格裁切保留 FDW 字样，不自行改表。第 3.1 节连续两次出现“特征层融合过程”，亦按原文保留。
- 原文式（11）的权重更新符号和归一化分母均按原件保留；译本不根据算法惯例改写。定理 3.1、3.2 只翻译所提供的陈述与解释，不补写证明。

参考文献

以下保留原文的完整书目信息与编号，便于检索；每项末尾的数字为原文引用所在页码，而非本译本页码。

[1] Peter L Bartlett and Shahar Mendelson. Rademacher and gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3(Nov):463-482, 2002. 4

[2] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7(Jan):1-30, 2006. 7

[3] Kaicheng Fu, Changde Du, Shengpei Wang, and Huiguang He. Multi-view multi-label fine-grained emotion decoding from human brain activity. *IEEE Transactions on Neural Networks and Learning Systems*, 35(7):9026-9040, 2024. 1, 2, 6

[4] Wanfu Gao, Pingting Hao, Yang Wu, and Ping Zhang. A unified low-order information-theoretic feature selection framework for multi-label learning. *Pattern Recognition*, 134:109111, 2023. 1

[5] Zongbo Han, Fan Yang, Junzhou Huang, Changqing Zhang, and Jianhua Yao. Multimodal dynamics: Dynamical fusion for trustworthy multimodal classification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20707-20717, 2022. 1

[6] Pingting Hao, Weiping Ding, Wanfu Gao, and Jialong He. Exploring view-specific label relationships for multi-view multi-label feature selection. *Information Sciences*, 681:121215, 2024. 2

[7] Pingting Hao, Wanfu Gao, and Liang Hu. Embedded feature fusion for multi-view multi-label feature selection. *Pattern Recognition*, 157:110888, 2025. 2

[8] Shizhe Hu, Zhengzheng Lou, and Yangdong Ye. View-wise versus cluster-wise weight: Which is better for multi-view clustering? *IEEE Transactions on Image Processing*, 31:58-71, 2021. 1

[9] Andong Li, Zhaohong Deng, Wei Zhang, Zhiyong Xiao, Kup-Sze Choi, Yueying Liu, Shudong Hu, and Shitong Wang. Multi-view transfer representation learning with tsk fuzzy system for eeg epilepsy detection. *IEEE Transactions on Fuzzy Systems*, 32(1):38-52, 2024. 4

[10] Quanjiang Li, Tingjin Luo, and Jiahui Liao. Theory-inspired deep multi-view multi-label learning with incomplete views and noisy labels. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20706-20715, 2025. 1

[11] Chengliang Liu, Jie Wen, Yabo Liu, Chao Huang, Zhihao Wu, Xiaoling Luo, and Yong Xu. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. *Advances in Neural Information Processing Systems*, pages 32387-32400, 2023. 3

[12] Chengliang Liu, Jie Wen, Xiaoling Luo, Chao Huang, Zhihao Wu, and Yong Xu. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. In *Proceedings of the AAAI conference on artificial intelligence*, pages 8807-8815, 2023. 1

[13] Wei Liu, Jiazheng Yuan, Gengyu Lyu, and Songhe Feng. Label driven latent subspace learning for multi-view multi-label classification. *Applied Intelligence*, 53(4):3850-3863, 2023. 1

[14] Gengyu Lyu, Xiang Deng, Yanan Wu, and Songhe Feng. Beyond shared subspace: A view-specific fusion for multi-view multi-label learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 7647-7654, 2022. 6

[15] Gengyu Lyu, Songhe Feng, Yi Jin, Tao Wang, Congyan Lang, and Yidong Li. Prior knowledge regularized self-representation model for partial multilabel learning. *IEEE Transactions on Cybernetics*, 53(3):1618-1628, 2023. 1

[16] Gengyu Lyu, Zhen Yang, Xiang Deng, and Songhe Feng. L-vsm: Label-driven view-specific fusion for multiview multilabel classification. *IEEE Transactions on Neural Networks and Learning Systems*, 36(4):6569-6583, 2025. 2

[17] Yujie Mo, Yajie Lei, Jialie Shen, Xiaoshuang Shi, Heng Tao Shen, and Xiaofeng Zhu. Disentangled multiplex graph representation learning. In *International Conference on Machine Learning*, pages 24983-25005, 2023. 3

[18] Yujie Mo, Zongqian Wu, Yuhuan Chen, Xiaoshuang Shi, Heng Tao Shen, and Xiaofeng Zhu. Multiplex graph representation learning via common and private information mining. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 9217-9225, 2023. 3

[19] Shilong Ou, Zhe Xue, Yawen Li, Meiyu Liang, Yuanqiang Cai, and Junjiang Wu. View-category interactive sharing transformer for incomplete multi-view multi-label learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 27467-27476, 2024. 1

[20] Lijuan Sun, Songhe Feng, Gengyu Lyu, Hua Zhang, and Guojun Dai. Partial multi-label learning with noisy side information. *Knowledge and Information Systems*, 63(2):541-564, 2021. 1

[21] Shiliang Sun and Daoming Zong. Lcbm: a multi-view probabilistic model for multi-label classification. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(8):2682-2696, 2021. 6

[22] Qianqian Wang, Zhengming Ding, Zhiqiang Tao, Quanxue Gao, and Yun Fu. Generative partial multi-view clustering with adaptive fusion and cycle consistency. *IEEE Transactions on Image Processing*, 30:1771-1783, 2021. 1

[23] Qianqian Wang, Zhiqiang Tao, Wei Xia, Quanxue Gao, Xiaochun Cao, and Licheng Jiao. Adversarial multiview clustering networks with adaptive fusion. *IEEE Transactions on Neural Networks and Learning Systems*, 34(10):7635-7647, 2023. 3

[24] Hao Wei, Yongjian Deng, Qiuru Hai, Yuena Lin, Zhen Yang, and Gengyu Lyu. Multi-view multi-label classification via view-label matching selection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 21456-21464, 2025. 1, 6

[25] Jie Wen, Chengliang Liu, Gehui Xu, Zhihao Wu, Chao Huang, Lunke Fei, and Yong Xu. Highly confident local structure based consensus graph learning for incomplete multi-view clustering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15712-15721, 2023. 1

[26] Jie Wen, Chengliang Liu, Shijie Deng, Yicheng Liu, Lunke Fei, Ke Yan, and Yong Xu. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views. *IEEE Transactions on Neural Networks and Learning Systems*, 35(8):11396-11408, 2024. 1, 6

[27] Jing-Han Wu, Xuan Wu, Qing-Guo Chen, Yao Hu, and Min-Ling Zhang. Feature-induced manifold disambiguation for multi-view partial multi-label learning. In *Proceedings of ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 557-565, 2020. 1, 6

[28] Song Wu, Yan Zheng, Yazhou Ren, Jing He, Xiaorong Pu, Shudong Huang, Zhifeng Hao, and Lifang He. Self-weighted contrastive fusion for deep multi-view clustering. *IEEE Transactions on Multimedia*, 26:9150-9162, 2024. 1

[29] Xuan Wu, Qing-Guo Chen, Yao Hu, Dengbao Wang, Xiaodong Chang, Xiaobo Wang, and Min-Ling Zhang. Multi-view multi-label learning with view-specific information extraction. In *International Joint Conference on Artificial Intelligence*, pages 3884-3890, 2019. 2, 3

[30] HaiMing Xu, Qianqian Wang, Boyue Wang, and Quanxue Gao. Deep fair multi-view clustering with attention kan. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5061-5070, 2025. 1

[31] Xu Yan, Jun Yin, and Jie Wen. Incomplete multi-view multi-label learning via disentangled representation and label semantic embedding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 30722-30731, 2025. 1

[32] Lotfi Asker Zadeh. Fuzzy sets. *Information and Control*, 8(3):338-353, 1965. 2, 4

[33] Lotfi Asker Zadeh. Fuzzy sets as a basis for a theory of possibility. *Fuzzy Sets and Systems*, 1(1):3-28, 1978. 4

[34] Changqing Zhang, Ziwei Yu, Qinghua Hu, Pengfei Zhu, Xinwang Liu, and Xiaobo Wang. Latent semantic aware multi-view multi-label classification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 4414-4421, 2018. 1

[35] Chun-Yang Zhang, Yue-Na Lin, CL Philip Chen, Hong-Yu Yao, Hai-Chun Cai, and Wu-Peng Fang. Fuzzy representation learning on graph. *IEEE Transactions on Fuzzy Systems*, 31(10):3358-3370, 2023. 4

[36] Wei Zhang, Zhaohong Deng, Te Zhang, Kup-Sze Choi, and Shitong Wang. Multi-view fuzzy representation learning with rules based model. *IEEE Transactions on Knowledge and Data Engineering*, 36(2):736-749, 2024. 4

[37] Vitalii Zhelezniak, Aleksandar Savkov, April Shen, Francesco Moramarco, Jack Flann, and Nils Y Hammerla. Don't settle for average, go for the max: Fuzzy sets and max-pooled word vectors. In *International Conference on Learning Representations*, pages 1-17, 2019. 2

[38] Qiyu Zhong, Gengyu Lyu, and Zhen Yang. Align while fusion: A generalized nonaligned multiview multilabel classification method. *IEEE Transactions on Neural Networks and Learning Systems*, 36(4):7627-7636, 2025. 1, 2

[39] Qiyu Zhong, Yi Shan, Haobo Wang, Zhen Yang, and Gengyu Lyu. Tensorized multi-view multi-label classification via laplace tensor rank. In *International Conference on Machine Learning*, pages 1-15, 2025. 1, 2, 6