基于共享码本与融合教师自蒸馏的不完整多视图多标签分类

非官方中文全文译文 · 仅供用户私人阅读

原题：Incomplete Multi-View Multi-Label Classification via Shared Codebook and Fused-Teacher Self-Distillation

作者：Xu Yan[1]，Jun Yin[1]*，Shiliang Sun[2]*，Minghua Wan[1]
[1] 上海海事大学信息工程学院
[2] 上海交通大学自动化与感知学院
yanxu@stu.shmtu.edu.cn；{junyin,mhwan}@shmtu.edu.cn；shiliangsun@gmail.com
* 通讯作者。

原稿标识：**Preprint（预印本）**；arXiv:2604.04170v1 [cs.CV]，2026 年 4 月 5 日。译文依据用户上传的完整 15 页 PDF，覆盖正文、图表、算法、参考文献及附录 A.1—A.4；不包含未提供的补充材料。
原作的著作权及其他权利不因本译文而改变；本文件不宣称开放许可，也不代表公开发布授权。数学式及原图表采用原稿裁图以保留字形、编号、数值与排版，图表中的英文说明另附中文对照。原文的符号与可能存在的不一致不作静默修改。

摘要

尽管多视图多标签学习已得到广泛研究，但对于视图与标签均不完整的双重缺失情形，研究仍相当不足。现有方法主要依赖对比学习或信息瓶颈理论，在视图缺失条件下学习一致表征；然而，仅通过损失进行对齐而缺少显式结构约束，限制了其捕获稳定且具有判别力的共享语义的能力。为解决这一问题，我们引入一种结构更明确的一致表征学习机制：利用多视图共享码本和跨视图重构学习离散一致表征，使不同视图自然地在有限的共享码本嵌入中对齐，并减少特征冗余。在决策层面，我们设计了一种权重估计方法，评估各视图保留标签相关性结构的能力，并据此分配权重，以提高融合预测的质量。此外，我们引入融合教师自蒸馏框架，由融合预测指导各视图专属分类器的训练，将全局知识反馈至单视图分支，从而增强模型在标签缺失条件下的泛化能力。我们在五个基准数据集上，与先进方法进行了广泛的对比实验，充分验证了所提方法的有效性。代码地址：https://github.com/xuy11/SCSD。

1 引言

多视图数据在现实世界中十分常见（Zhao et al., 2017）：单个样本通常由不同模态或不同特征提取方法产生的多种表征描述，例如图像的 RGB/HSV/GIST 特征、视频的音视频同步信息、推荐系统中的内容/行为/社交视图，以及生物信息学中的多组学数据（Yan et al., 2021）。多视图学习旨在利用视图之间的一致性和互补性，提高表征质量以及分类等下游任务的性能。它已经成为众多实际应用中的一项基础技术（Yu et al., 2025）。

类似地，许多任务天然属于多标签设定：单个样本通常对应多个标签，例如图像分类与多主题文本分类（Hang & Zhang, 2021）。多标签分类能够利用标签相关性来提升预测性能（Chen et al., 2019）。如果能有效建模并利用这些相关性，不仅可以缓解标签稀疏性的负面影响，还能提高有限标注条件下的预测准确性和鲁棒性。

然而，在实际应用中，多视图数据完整且所有多标签标注均可观测这一理想假设很少成立（Wen et al., 2023）。一方面，不完整多视图数据非常常见（Yin & Sun, 2021）。在多视图数据采集过程中，传感器故障、遮挡或跨域限制（例如隐私与授权约束），常导致部分视图在训练或推理时不可用。另一方面，多标签缺失也普遍存在（Chen et al., 2020）。这主要源于细粒度标注的高成本以及标注人员注意力有限，因而有些样本只能观测到部分标签。简单地将缺失标签视为负例，会进一步加剧类别不平衡，并引入偏差（Ridnik et al., 2021）。

更具挑战性的情形是，多视图与多标签数据同时缺失，形成双重缺失情境（Liu et al., 2023b）。首先，多视图缺失会影响跨视图一致性与互补性的学习，增加表征学习的不确定性。其次，多标签缺失会损害标签相关性的建模和监督信号的完整性。当两类缺失同时发生时，仅针对其中一类缺失设计的方法往往无法奏效（Tan et al., 2018）。

针对这一挑战，系统研究不完整多视图多标签分类（Incomplete Multi-View Multi-Label Classification，IMVMLC）问题具有重要的实践与理论价值。本研究主要关注现有的两个技术方向。第一个方向是多视图一致表征学习。代表性工作包括基于对比学习的 DICNet（Liu et al., 2023b），它通过在不同视图之间构建正样本对来约束表征一致性；以及遵循信息瓶颈原理的 SIP（Liu et al., 2024c），它在保留有效特征的同时最小化非共享信息，以最大化共享信息。第二个方向是多视图融合策略，包括早期融合、中间融合和后期融合。不同的代表性方法探索了不同的融合范式。例如，AIMNet（Liu et al., 2024a）采用平均融合，得到鲁棒但相对“平滑”的预测。LMVCAT（Liu et al., 2023c）引入可学习权重，自适应分配各视图特征的贡献，从而提升判别能力。RANK（Liu et al., 2025）使用视图质量感知子网络，显式利用多视图互补性，使分类网络能够学习可靠的跨视图融合表征。

不过，这些方法存在一定局限。在学习多视图一致表征时，它们通常依赖基于损失的约束（例如对比学习），或依赖最小化视图间非共享信息的正则化技术。当视图缺失时，这些策略容易导致表征不足或过度正则化，从而限制模型的泛化能力。此外，大多数现有融合策略忽略了标签相关性隐含的结构信息，而许多基于可学习权重或质量判别器的融合方法又会增加额外训练成本。

为解决上述问题，我们提出基于共享码本与融合教师自蒸馏的不完整多视图多标签分类方法（SCSD），如图 1 所示。首先，在一致表征方面，我们引入共享码本与跨视图重构机制。共享离散码本捕获跨视图的共同语义，而跨视图重构进一步增强离散表征的一致性。有限的多视图共享码本嵌入减少了特征冗余，并增强表征的泛化能力。其次，在决策融合方面，我们设计了面向标签相关性的融合策略。该策略通过估计各视图预测保留原始标签相关性结构的能力，为各视图分配不同权重，从而减小低质量视图的影响。最后，在训练范式方面，我们采用融合教师自蒸馏：将融合预测作为教师信号，指导各视图专属分类器的学习。这样，跨视图整合的全局知识被反馈到单视图分支，提高训练与推理过程中的一致性、鲁棒性和泛化能力。本文的主要贡献如下：

- 提出一种基于共享码本与融合教师自蒸馏的新型不完整多视图多标签分类框架。该框架能够处理任意缺失情形，在多个数据集上取得领先性能，超过多种先进方法。

- 提出通过多视图共享码本学习离散一致表征，将连续特征量化到有限的码本嵌入集合中。这一设计产生更紧凑的表征，有效减少冗余信息。同时，不同视图的特征能够自然地在这一共享码本嵌入空间中对齐，从而增强多视图表征的一致性。
- 提出一种加权融合方法，根据各视图的预测保留标签相关性结构的能力分配权重。该方法不依赖额外的外部网络或可学习权重，充分利用监督信号本身蕴含的结构信息。
- 引入用于多视图预测的融合教师自蒸馏框架，通过自蒸馏损失将所有视图的知识反馈到每个视图分支，从而提升模型泛化能力。

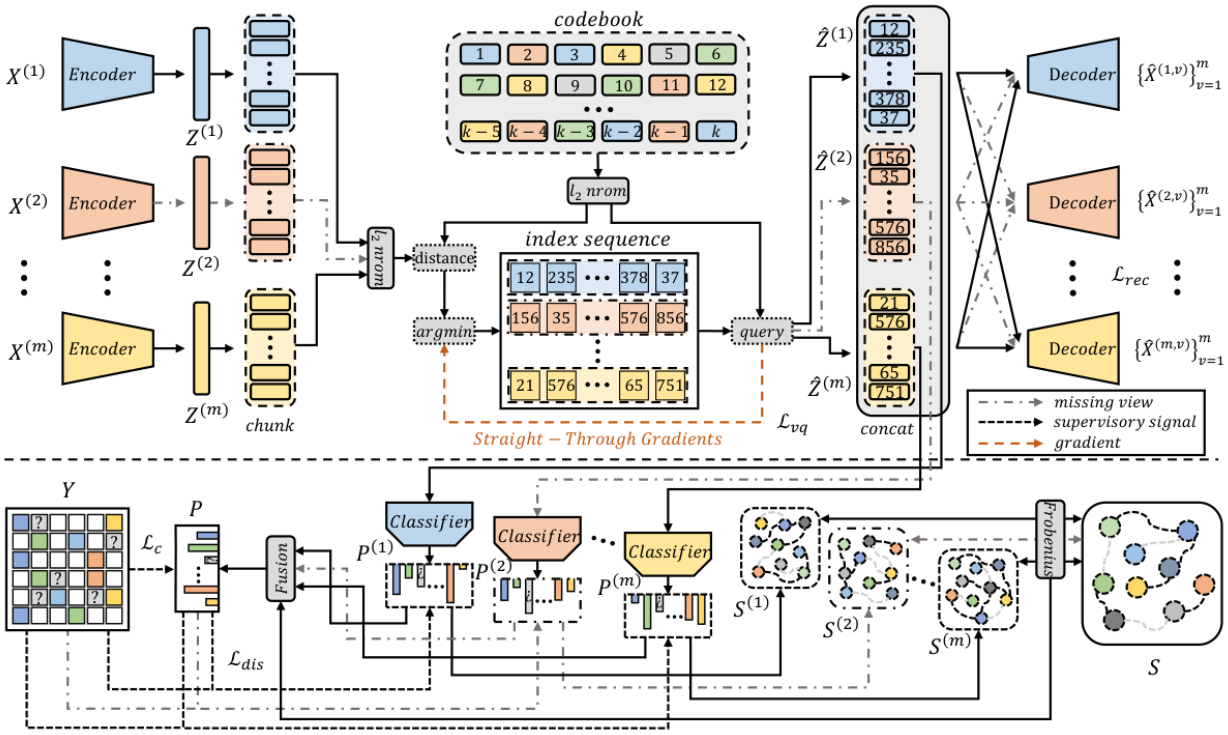


图 1： SCSD 的总体框架。上半部分是多视图一致离散表征学习框架，下半部分是多视图预测融合与自蒸馏框架。图内文字：Encoder＝编码器；Decoder＝解码器；Classifier＝分类器；Frobenius＝Frobenius 范数；chunk＝分块；query＝查询；codebook＝码本；ℓ_2 norm＝ℓ_2 归一化；distance＝距离；index sequence＝索引序列；argmin＝取使目标最小的索引；concat＝拼接；Straight-Through Gradient＝直通梯度；Fusion＝融合；missing view＝缺失视图；supervised signal＝监督信号；gradient＝梯度。数学变量、索引及损失符号保持原样。

2 方法

2.1 问题定义

本节定义问题并介绍符号。考虑一个多视图数据集 $\{X^{(v)}\}_{v=1}^{m}$，其中 m 表示视图数，$X^{(v)} \in \mathbb{R}^{n\times d_v}$，$d_v$ 表示第 v 个视图的原始特征维度，n 表示样本数。定义包含 c 个类别的标签矩阵 $Y \in \{0,1\}^{n\times c}$，其中 $Y_{i,j}=1$ 表示第 i 个样本具有第 j 个标签，$Y_{i,j}=0$ 表示第 i 个样本未被赋予第 j 个标签。为处理视图缺失，引入缺失视图指示矩阵 $\mathcal{W} \in \{0,1\}^{n\times m}$；$\mathcal{W}_{i,j}=1$ 表示第 i 个样本的第 j 个视图可观测，否则 $\mathcal{W}_{i,j}=0$。类似地，引入缺失标签指示矩阵 $\mathcal{G} \in \{0,1\}^{n\times c}$；$\mathcal{G}_{i,j}=1$

表示样本 i 的第 j 个标签可观测，否则 $\mathcal{G}_{i,j} = 0$。缺失视图与标签均用零填充。我们的目标是在视图与标签均不完整的条件下训练多标签分类模型。本文中，$X_{i,j}$、$X_{i,:}$ 和 $X_{:,j}$ 分别表示矩阵 X 的元素、第 i 行和第 j 列。

2.2 一致离散表征学习

本节分三个部分，说明如何通过共享码本与跨视图重构来学习多视图一致离散表征。

编码。由于多视图数据中不同视图的原始维度 d_v 不同，我们首先使用各视图专属的 MLP 编码器，将原始数据映射到统一的 d_e 维空间。形式上，$\{Z^{(v)} = E^{(v)}(X^{(v)})\}_{v=1}^{m}$，其中 $Z^{(v)} \in \mathbb{R}^{n \times d_e}$ 表示第 v 个视图的连续特征，$E^{(v)}$ 表示该视图的 MLP 编码器。

量化。随后，我们通过向量量化（Van Den Oord et al., 2017）将 $Z^{(v)}$ 离散化，把一个视图的每个样本 $Z_{i,:}^{(v)}$ 映射为一个词元序列，即离散编码序列。首先定义可学习的共享码本 $\mathcal{V} = \{e_i\}_{i=1}^{k} \in \mathbb{R}^{k \times d_c}$，其中包含 k 个编码，每个编码的维度为 d_c。我们采用分组量化方法（Baevski et al., 2019），首先将 $Z_{i,:}^{(v)}$ 划分为 g 个片段。为清楚起见，以第 v 个视图的第 i 个样本为例，可得 $\widetilde{Z}_{i,:}^{(v)} = \left[z_1, z_2, \ldots, z_g\right]^{\top} \in \mathbb{R}^{g \times (d_e/g)}$，其中 $z_t \in \mathbb{R}^{d_c}$ 表示第 t 个特征片段，且 $d_c = d_e/g$。通过最近邻查找，为每个 z_t 分配最近的码本嵌入：

$$t^* = \arg\min_j \left\| \ell_2(z_t) - \ell_2(e_j) \right\|_2^2, \quad j = 1, \ldots, k, \tag{1}$$

由此得到第 t 个特征片段 z_t 的最优量化索引 t^*，并记 $\widehat{z}_t = e_{t^*}$，其中 $\ell_2(\cdot)$ 表示码本查找所用的 ℓ_2 归一化（Yu et al., 2021）。经此量化，原始连续特征 $Z_{i,:}^{(v)}$ 被映射为整数索引序列 $\left[1^*, 2^*, \ldots, g^*\right] \in \{1, \ldots, k\}^g$，每个索引 t^* 对应一个码本嵌入。最后，按照这些索引检索码本嵌入并将其拼接，得到量化后的离散表征 $\widehat{Z}_{i,:}^{(v)} = \left[\widehat{z}_1; \widehat{z}_2; \ldots; \widehat{z}_g\right] \in \mathbb{R}^{d_e}$，其中 $[\cdot;\cdot]$ 表示拼接操作。其余所有非缺失多视图特征 $Z^{(v)}$ 都经过相同的量化过程，得到各自的离散表征 $\widehat{Z}^{(v)}$。

重构与损失函数。对于每个视图，构建视图专属的 MLP 解码器，从离散表征 $\widehat{Z}^{(v)}$ 重构原始视图 $X^{(v)}$，这些解码器记为 $\{D^{(v)}\}_{v=1}^{m}$。为更好地学习多视图一致表征，我们引入跨视图重构：每个视图的表征都由不同视图的解码器解码，以重构原始特征，即 $\{\widehat{X}^{(j,v)} = D^{(j)}(\widehat{Z}^{(v)})\}_{v=1}^{m}$，$j = 1, \ldots, m$；其中 $\widehat{X}^{(j,v)}$ 表示利用视图 v 的表征重构的视图 j 原始特征。重构损失定义为：

$$\mathcal{L}_{rec} = \frac{1}{\sum_{i=1}^{n}\sum_{j=1}^{m}\sum_{v=1}^{m} \mathcal{W}_{i,j}\,\mathcal{W}_{i,v}} \sum_{i=1}^{n}\sum_{j=1}^{m}\sum_{v=1}^{m} \left\| \hat{X}_{i,:}^{(j,v)} - X_{i,:}^{(j)} \right\|_2^2 \mathcal{W}_{i,j}\,\mathcal{W}_{i,v} \tag{2}$$

我们使用基于均方误差（MSE）的重构损失，缺失视图指示矩阵 $\mathcal{W}$ 用于屏蔽不可用视图。仅当视图 v 与视图 j 均可用时，才计算重构损失，从而减少缺失视图对模型的影响。由于式（1）的最近邻搜索不可微，我们遵循 Van Den Oord et al.（2017），采用直通梯度估计器：$z_t = \mathrm{sg}\left[z_t - \widehat{z}_t\right] + \widehat{z}_t$，将梯度直接从解码器输入复制至编码器输出。码本学习目标定义为：

$$\underbrace{\mathcal{L}_{vq}^{(i,v)}}_{\text{sample } i,\ \text{view } v} = \sum_{t=1}^{g} \Big(\|\mathrm{sg}[\ell_2(z_t)] - \ell_2(\hat{z}_t)\|_2^2 + \|\ell_2(z_t) - \mathrm{sg}[\ell_2(\hat{z}_t)]\|_2^2 \Big), \tag{3}$$

式（3）下括号的说明为“样本 i，视图 v”。其中 $\mathrm{sg}[\cdot]$ 表示停止梯度操作，即 $\mathrm{sg}[z] \equiv z$ 且 $\frac{d}{dz}\mathrm{sg}[z] \equiv 0$。第一项促使码本嵌入接近编码器输出，第二项确保编码器输出被拉向某个码本嵌入。我们在所有非缺失样本上计算损失：

$$\mathcal{L}_{vq} = \frac{1}{\sum_{i=1}^{n}\sum_{v=1}^{m} \mathcal{W}_{i,v}} \sum_{i=1}^{n}\sum_{v=1}^{m} \mathcal{W}_{i,v}\mathcal{L}_{vq}^{(i,v)}.$$

这一部分的多视图一致离散表征学习由 m 个编码器、一个量化器和 m 个解码器组成。我们使用同一个共享码本，将连续特征 $\{Z^{(v)}\}_{v=1}^{m}$ 量化为离散表征 $\{\widehat{Z}^{(v)}\}_{v=1}^{m}$。通过共享码本量化，不同视图的特征被映射到有限的码本嵌入集合中，这不仅减少了冗余，还使跨视图共同信息能够在离散空间中得到一致表达。此外，跨视图重构损失进一步增强了多视图一致表征的学习，降低了对额外对齐损失的需求。

2.3 分类与多视图决策融合

本节介绍如何基于第 2.2 节学得的视图一致离散表征 $\{\widehat{Z}^{(v)}\}_{v=1}^{m}$ 进行多标签分类。

分类。首先为每个视图构建多标签分类器 $F_{cls}^{(v)}(\cdot)$，它由一个全连接层组成，将 $\widehat{Z}^{(v)}$ 映射至标签空间。形式上，$\{P^{(v)} = \sigma\big(F_{cls}^{(v)}(\widehat{Z}^{(v)})\big) \in \mathbb{R}^{n\times c}\}_{v=1}^{m}$，其中 $\sigma(\cdot)$ 表示 sigmoid 激活函数。

融合。现有多视图特征融合和决策层融合方法主要包括平均融合、可学习权重融合、不确定性感知融合，以及基于质量判别器的融合。我们提出利用标签相关性来指导视图预测质量的评估，再为每个视图预测分配定量权重。由于充分利用多标签监督信号和标签相关性，我们的方法更适合多视图预测融合。

具体而言，首先遵循 Hang & Zhang（2021）和 Chen et al.（2019）的方法，利用条件概率矩阵计算标签相关性矩阵，其形式为：

$$S_{i,j} = \frac{\sum_{r=1}^{n} Y_{r,i}Y_{r,j}}{\sum_{r=1}^{n} Y_{r,i}Y_{r,i} + \varepsilon} = \frac{Y_{:,i}^{\top}Y_{:,j}}{Y_{:,i}^{\top}Y_{:,i} + \varepsilon} \tag{4}$$

其中，$S_{i,j}$ 表示标签 i 出现时标签 j 出现的概率，ε 表示一个很小的标量。标签矩阵 Y 来自训练集，最终得到标签相关性矩阵 $S \in \mathbb{R}^{c\times c}$。接着，以同样方式计算每个视图预测 $\widehat{P}_{r,:}^{(v)} = \mathcal{W}_{r,v}P_{r,:}^{(v)}$ 的标签相关性矩阵：

$$S_{i,j}^{(v)} = \frac{\sum_{r=1}^{n_h} \hat{P}_{r,i}^{(v)}\hat{P}_{r,j}^{(v)}}{\sum_{r=1}^{n_h} \hat{P}_{r,i}^{(v)}\hat{P}_{r,i}^{(v)} + \varepsilon} = \frac{(\hat{P}_{:,i}^{(v)})^{\top}\hat{P}_{:,j}^{(v)}}{(\hat{P}_{:,i}^{(v)})^{\top}\hat{P}_{:,i}^{(v)} + \varepsilon} \tag{5}$$

其中 n_h 表示第 h 个训练步骤的批量大小。通过上述公式，得到各视图的标签相关性矩阵 $\{S^{(v)}\}_{v=1}^{m} \in \mathbb{R}^{c\times c}$，这些矩阵由当前批次中可用视图的预测计算而来。随后，计算 $S^{(v)}$ 与 S 之差的 Frobenius 范数，衡量第 v 个视图保留标签相关性结构的能力，并将其作为预测质量指标。在计算差异之前，先对两个矩阵作对称化和逐行归一化，得到 $\widehat{S}^{(v)}$ 与 $\widehat{S}$。预测质量分数和视图权重定义为：

$$q^{(v)} = -\|\hat{S}^{(v)} - \hat{S}\|_F, \quad w_i^{(v)} = \frac{\exp\left(q^{(v)}/\tau\right)\cdot \mathcal{W}_{i,v}}{\sum_{u=1}^{m}\exp\left(q^{(u)}/\tau\right)\cdot \mathcal{W}_{i,u}}, \tag{6}$$

第二项表示带温度参数 τ 的 softmax 归一化，由此得到所有视图的权重 $\{w_i^{(v)}\}_{v=1}^{m}$，$i = 1, \ldots, n$。这种方法不仅依赖单个视图的预测，还显式利用全局标签相关性结构 S。因此，权重分配会优先考虑与全局标签依赖模式一致的视图，并减小噪声视图对融合结果的影响。每个批次中的 $S^{(v)}$ 都根据当前预测更新，因此权重能够自适应地反映不同训练阶段和不同批次中各视图的相对质量，而非保持固定。

$$P_{i,:} = \sum_{v=1}^{m} w_i^{(v)} P_{i,:}^{(v)}. \tag{7}$$

最后，通过加权融合得到融合预测 $P \in \mathbb{R}^{n\times c}$。使用二元交叉熵损失，使融合预测 P 与真实标签 Y 对齐：

$$\mathcal{L}_c = \mathcal{L}_{bce}(P,Y) = -\frac{1}{\sum_{i=1}^{n}\sum_{j=1}^{c}\mathcal{G}_{i,j}}\sum_{i=1}^{n}\sum_{j=1}^{c}\Big(Y_{i,j}\log(P_{i,j}) + (1-Y_{i,j})\log(1-P_{i,j})\Big)\mathcal{G}_{i,j}, \tag{8}$$

其中缺失标签指示矩阵 $\mathcal{G}$ 用于屏蔽缺失标签对模型的影响。

2.4 基于自蒸馏的预测增强

获得融合预测 P 后，我们通过自蒸馏框架（Zhang et al., 2021）进一步增强模型的预测能力。具体地，将多视图融合预测 P 作为教师，将每个单视图预测 $P^{(v)}$ 作为学生，由教师预测指导每个学生的学习。自蒸馏损失定义为：

$$\mathcal{L}_{\text{dis}} = \frac{1}{\sum_{i=1}^{n}\sum_{v=1}^{m}\mathcal{W}_{i,v}}\sum_{i=1}^{n}\sum_{v=1}^{m}\Big[\lambda\,\mathcal{D}_{KL}\big(\text{sg}[P_{i,:}]\,\|\,P_{i,:}^{(v)}\big) + (1-\lambda)\,\mathcal{L}_{bce}\big(P_{i,:}^{(v)}, Y_{i,:}\big)\Big]\mathcal{W}_{i,v} \tag{9}$$

其中 $\lambda \in [0, 1]$ 表示模仿参数，$\text{sg}[\cdot]$ 为第 2.2 节定义的停止梯度操作，$\mathcal{D}_{KL}$ 表示 Kullback–Leibler（KL）散度，$\mathcal{L}_{bce}$ 是每个视图预测 $P^{(v)}$ 的监督损失，与式（8）类似。传统蒸馏最小化教师与学生概率之间的 KL 散度，假定各类别概率之和为一。然而，该假设在多标签学习中不成立。为此，我们采用多标签 logit 蒸馏（MLD）损失（Yang et al., 2023）：遵循一对其余策略，将任务分解为多个二分类问题，并最小化每个问题中教师和学生的概率差异，从而实现有效的多标签学习蒸馏。

该自蒸馏框架将多视图融合预测作为教师，汇集所有视图的信息，提供全面且可靠的监督信号。各视图专属分类器作为学生，从教师输出中学习，既能够捕获融合预测中的全局知识，也保留自身视图特有的特征。因此，该框架提高了训练和推理期间的一致性、鲁棒性及泛化能力。

2.5 总体损失函数

最后，将式（2）、式（3）、式（8）与式（9）结合，得到模型的总体优化目标：

$$\mathcal{L} = \mathcal{L}_c + \mathcal{L}_{dis} + \alpha\mathcal{L}_{rec} + \mathcal{L}_{vq}, \tag{10}$$

其中 α 是平衡不同优化目标影响的权衡系数。总体目标函数从预测准确性、融合自蒸馏、重构质量以及表征量化等方面共同促进优化过程。

复杂度分析。首先定义 d_{max} 为网络中间层中的最大神经元数。四个损失函数 $\mathcal{L}_c$、$\mathcal{L}_{dis}$、$\mathcal{L}_{rec}$ 和 $\mathcal{L}_{vq}$ 的计算复杂度依次为 $O(nc)$、$O(nmc)$、$O(nm^2)$ 和 $O(nmg)$。编码—解码阶段的时间复杂度为 $O(nm^2d_{max}^2)$，量化过程的时间复杂度为 $O(nmgk)$。因此，总体时间复杂度为 $O(nm^2d_{max}^2 + nmgk + nc + nmc + nm^2 + nmg)$。总之，SCSD 的整体计算成本主要由多视图编码—解码过程决定。总体复杂度随样本规模 n 线性增长，框架在多视图场景中具有良好的可扩展性。

3 实验

3.1 数据集与评价指标

数据集。遵循多项 IMVMLC 研究的实验设定，全面评估所提模型的性能（Liu et al., 2024b；Yan et al., 2025）。我们在五个多视图多标签数据集上开展实验：Corel5k（Duygulu et al., 2002）、Pascal07（Everingham et al., 2010）、Espgame（Von Ahn & Dabbish, 2004）、Iaprtc12（Grubinger et al., 2006）和 Mirflickr（Huiskes & Lew, 2008）。表 1 提供了数据集的更多细节。我们使用六种不同类型的特征作为六个视图：DenseSift（1000）、DenseHue（100）、GIST（512）、RGB（4096）、LAB（4096）和 HSV（4096），括号中的数字表示特征维度。

Dataset	c	c/n	n	m
Corel5k	260	3.396	4999	6
Pascal07	20	1.465	9963	6
Espgame	268	4.686	20770	6
Iaprtc12	291	5.719	19627	6
Mirflickr	38	4.716	25000	6

表 1： 各数据集的汇总统计。c 表示类别数，c/n 表示每个样本的平均正标签数，n 表示样本数，m 表示视图数。Dataset＝数据集。保留原表对 c/n 的记法与说明。

评价指标。遵循以往工作（Liu et al., 2023b；2024c），使用六种常用多标签分类指标评价本模型与所有基线方法：平均精确率（Average Precision，AP）、汉明损失（Hamming Loss，HL）、适配曲线下面积（Adapted Area Under Curve，AUC）、排序损失（Ranking Loss，RL）、首位错误（OneError，OE）和覆盖度（Coverage，Cov）。对于其中四项指标，在图表中记录 $1-\mathrm{HL}$、$1-\mathrm{RL}$、$1-\mathrm{OE}$ 和 $1-\mathrm{Cov}$。这样，六项评价指标均遵循同一约定：数值越大，性能越好。

Dataset	Metric	iMvWL	NAIM3L	DDINet	DICNet	MTD	SIP	RANK	DRLS	SCSD
	Sources	IJCAI'18	TPAMI'22	TNNLS'23	AAAI'23	NeurIPS'23	ICML'24	TPAMI'25	CVPR'25	—
Corel5k	AP	$0.283_{0.008}$	$0.309_{0.004}$	$0.360_{0.009}$	$0.378_{0.004}$	$0.413_{0.007}$	$0.416_{0.015}$	$0.425_{0.009}$	$\underline{0.433}_{0.008}$	$\mathbf{0.447}_{0.010}$
	1-HL	$0.978_{0.000}$	$\underline{0.987}_{0.000}$	$\underline{0.987}_{0.000}$	$\underline{0.987}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$
	1-RL	$0.865_{0.005}$	$0.878_{0.002}$	$0.865_{0.005}$	$0.877_{0.004}$	$0.892_{0.004}$	$0.910_{0.003}$	$0.913_{0.003}$	$\underline{0.916}_{0.002}$	$\mathbf{0.920}_{0.002}$
	AUC	$0.868_{0.005}$	$0.881_{0.002}$	$0.868_{0.005}$	$0.881_{0.003}$	$0.895_{0.004}$	$0.912_{0.003}$	$0.915_{0.003}$	$\underline{0.918}_{0.002}$	$\mathbf{0.923}_{0.003}$
	1-OE	$0.311_{0.015}$	$0.350_{0.009}$	$0.437_{0.012}$	$0.464_{0.012}$	$0.491_{0.010}$	$0.492_{0.018}$	$0.490_{0.014}$	$\underline{0.509}_{0.019}$	$\mathbf{0.526}_{0.018}$
	1-Cov	$0.702_{0.008}$	$0.725_{0.005}$	$0.689_{0.012}$	$0.714_{0.010}$	$0.748_{0.009}$	$0.786_{0.007}$	$0.798_{0.005}$	$\underline{0.804}_{0.006}$	$\mathbf{0.811}_{0.006}$
	Ave.R	8.500	6.667	7.500	6.333	4.167	3.333	3.000	$\underline{1.833}$	**1.000**
Pascal07	AP	$0.437_{0.018}$	$0.488_{0.003}$	$0.532_{0.010}$	$0.502_{0.007}$	$0.550_{0.004}$	$0.550_{0.009}$	$0.554_{0.009}$	$\underline{0.567}_{0.008}$	$\mathbf{0.578}_{0.009}$
	1-HL	$0.882_{0.004}$	$0.928_{0.001}$	$\underline{0.932}_{0.001}$	$0.930_{0.001}$	$\underline{0.932}_{0.001}$	$0.931_{0.002}$	$\underline{0.932}_{0.001}$	$\mathbf{0.934}_{0.001}$	$\mathbf{0.934}_{0.001}$
	1-RL	$0.736_{0.015}$	$0.783_{0.001}$	$0.808_{0.005}$	$0.781_{0.007}$	$0.830_{0.003}$	$0.825_{0.006}$	$0.826_{0.004}$	$\underline{0.843}_{0.004}$	$\mathbf{0.846}_{0.005}$
	AUC	$0.767_{0.015}$	$0.811_{0.001}$	$0.829_{0.004}$	$0.805_{0.006}$	$0.849_{0.004}$	$0.845_{0.005}$	$0.848_{0.005}$	$\underline{0.864}_{0.003}$	$\mathbf{0.866}_{0.004}$
	1-OE	$0.362_{0.023}$	$0.421_{0.006}$	$0.448_{0.015}$	$0.426_{0.013}$	$0.457_{0.008}$	$0.463_{0.012}$	$0.465_{0.015}$	$\underline{0.477}_{0.011}$	$\mathbf{0.489}_{0.011}$
	1-Cov	$0.677_{0.015}$	$0.727_{0.002}$	$0.757_{0.005}$	$0.728_{0.007}$	$0.783_{0.004}$	$0.777_{0.005}$	$0.779_{0.005}$	$\underline{0.798}_{0.004}$	$\mathbf{0.801}_{0.005}$
	Ave.R	8.833	7.500	5.333	7.167	3.500	4.833	3.500	$\underline{1.833}$	**1.000**
Espgame	AP	$0.244_{0.005}$	$0.246_{0.002}$	$0.286_{0.004}$	$0.299_{0.004}$	$0.306_{0.003}$	$0.310_{0.004}$	$0.314_{0.004}$	$\underline{0.326}_{0.005}$	$\mathbf{0.345}_{0.004}$
	1-HL	$\underline{0.972}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$
	1-RL	$0.808_{0.002}$	$0.818_{0.002}$	$0.815_{0.003}$	$0.833_{0.003}$	$0.837_{0.001}$	$0.849_{0.002}$	$0.849_{0.002}$	$\underline{0.858}_{0.002}$	$\mathbf{0.863}_{0.002}$
	AUC	$0.813_{0.002}$	$0.824_{0.002}$	$0.819_{0.003}$	$0.837_{0.002}$	$0.842_{0.001}$	$0.853_{0.002}$	$0.853_{0.002}$	$\underline{0.862}_{0.002}$	$\mathbf{0.867}_{0.002}$
	1-OE	$0.343_{0.013}$	$0.339_{0.003}$	$0.427_{0.010}$	$0.437_{0.010}$	$0.448_{0.006}$	$0.451_{0.012}$	$0.460_{0.010}$	$\underline{0.473}_{0.001}$	$\mathbf{0.491}_{0.010}$
	1-Cov	$0.548_{0.004}$	$0.571_{0.003}$	$0.553_{0.005}$	$0.598_{0.006}$	$0.601_{0.004}$	$0.628_{0.004}$	$0.632_{0.005}$	$\underline{0.652}_{0.003}$	$\mathbf{0.657}_{0.004}$
	Ave.R	8.833	6.500	6.500	5.167	4.333	3.167	2.667	$\underline{1.833}$	**1.000**
Iaprtc12	AP	$0.237_{0.003}$	$0.261_{0.001}$	$0.302_{0.005}$	$0.327_{0.005}$	$0.332_{0.002}$	$0.331_{0.007}$	$0.347_{0.004}$	$\underline{0.356}_{0.006}$	$\mathbf{0.385}_{0.005}$
	1-HL	$0.969_{0.000}$	$\underline{0.980}_{0.000}$	$\underline{0.980}_{0.000}$	$\underline{0.980}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$
	1-RL	$0.833_{0.002}$	$0.848_{0.001}$	$0.853_{0.002}$	$0.872_{0.002}$	$0.875_{0.001}$	$0.887_{0.004}$	$0.888_{0.002}$	$\underline{0.896}_{0.003}$	$\mathbf{0.903}_{0.002}$
	AUC	$0.835_{0.001}$	$0.850_{0.001}$	$0.855_{0.003}$	$0.873_{0.001}$	$0.876_{0.001}$	$0.888_{0.003}$	$0.889_{0.002}$	$\underline{0.898}_{0.002}$	$\mathbf{0.905}_{0.002}$
	1-OE	$0.352_{0.008}$	$0.390_{0.005}$	$0.435_{0.009}$	$0.465_{0.013}$	$0.471_{0.006}$	$0.466_{0.001}$	$0.486_{0.012}$	$\underline{0.490}_{0.012}$	$\mathbf{0.514}_{0.008}$
	1-Cov	$0.564_{0.005}$	$0.592_{0.004}$	$0.594_{0.007}$	$0.648_{0.005}$	$0.649_{0.002}$	$0.679_{0.008}$	$0.686_{0.006}$	$\underline{0.707}_{0.007}$	$\mathbf{0.721}_{0.005}$
	Ave.R	9.000	7.667	6.833	6.000	4.000	3.833	2.667	$\underline{1.833}$	**1.000**
Mirflickr	AP	$0.490_{0.012}$	$0.551_{0.002}$	$0.588_{0.003}$	$0.586_{0.005}$	$0.608_{0.004}$	$0.615_{0.004}$	$0.606_{0.006}$	$\underline{0.630}_{0.005}$	$\mathbf{0.634}_{0.005}$
	1-HL	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.001}$	$0.888_{0.001}$	$\underline{0.891}_{0.001}$	$\underline{0.891}_{0.001}$	$\underline{0.891}_{0.001}$	$\mathbf{0.895}_{0.001}$	$\mathbf{0.895}_{0.001}$
	1-RL	$0.803_{0.008}$	$0.844_{0.001}$	$0.865_{0.002}$	$0.861_{0.004}$	$0.875_{0.001}$	$0.878_{0.002}$	$0.874_{0.002}$	$\underline{0.885}_{0.002}$	$\mathbf{0.888}_{0.002}$
	AUC	$0.787_{0.012}$	$0.837_{0.001}$	$0.853_{0.002}$	$0.848_{0.004}$	$0.861_{0.002}$	$0.864_{0.002}$	$0.860_{0.003}$	$\underline{0.872}_{0.003}$	$\mathbf{0.873}_{0.002}$
	1-OE	$0.511_{0.022}$	$0.585_{0.003}$	$0.636_{0.008}$	$0.642_{0.006}$	$0.656_{0.004}$	$\underline{0.664}_{0.006}$	$0.654_{0.009}$	$\mathbf{0.686}_{0.009}$	$\mathbf{0.686}_{0.006}$
	1-Cov	$0.572_{0.013}$	$0.631_{0.002}$	$0.654_{0.003}$	$0.646_{0.006}$	$0.677_{0.002}$	$0.676_{0.004}$	$0.673_{0.004}$	$\underline{0.692}_{0.003}$	$\mathbf{0.695}_{0.004}$
	Ave.R	9.000	8.000	6.167	6.500	3.667	3.167	4.667	$\underline{1.667}$	**1.000**

表 2：视图缺失率 50%、标签缺失率 50%、训练数据占比 70% 时的结果。表中列出均值及标准差（右下角）。Ave.R 表示各指标的平均排名。粗体表示最佳结果，下划线表示次佳结果。表头 Dataset＝数据集；Metric＝指标；Sources＝出处；AP＝平均精确率；HL＝汉明损失；RL＝排序损失；AUC＝适配曲线下面积；OE＝首位错误；Cov＝覆盖度。各方法名、会议期刊出处、数值、标准差及强调格式均保留原样。

3.2 对比方法

为更全面地评价所提方法的有效性，我们选取八种专门针对双重缺失问题设计的不完整多视图多标签学习方法，作为对比实验中的基线，从而更全面地评价模型处理双重缺失情形的能力。具体方法包括 iMvWL（Tan et al., 2018）、NAIM3L（Li & Chen, 2021）、DDINet（Wen et al., 2023）、DICNet（Liu et al., 2023b）、MTD（Liu et al., 2024b）、SIP（Liu et al., 2024c）、RANK（Liu et al., 2025）和 DRLS（Yan et al., 2025）；相关说明已在第 1 节引言与附录 A.1 相关工作中给出。

3.3 实现细节

为模拟现实场景中多视图与多标签数据的随机缺失，遵循已有研究生成缺失数据（Tan et al., 2018; Liu et al., 2024c）。具体而言，对于多视图数据，随机丢弃 50% 的视图，同时确保每个样本至少保留一个可用视图。对于多标签数据，随机丢弃 50% 的正标签和负标签，并用零填充缺失视图与标签。数据集按 70% 用于训练、30% 用于验证和测试进行划分。所提 SCSD 模型采用 PyTorch 实现，在配备 RTX 4090 GPU 和 i9-13900K CPU 的 Ubuntu 操作系统上进行实验。学习率设为 0.001，使用 AdamW 优化器，权重衰减为 0.001，批量大小为 128。码本通过 k-means 初始化，码本大小 k 设为 2048，码本嵌入维度 d_c 设为 4。

3.4 实验结果

表 2 在五个公开多视图多标签数据集上比较了八种先进方法，视图和标签缺失率均设为 50%。可以看到，所提 SCSD 模型优于所有基线，尤其是在 Espgame 和 Iaprtc12 的 AP 指标上，相较次佳方法 DRLS，SCSD 分别提升 5.83% 和 8.15%。Espgame 和 Iaprtc12 的标签空间更加复杂，带来了更高的学习难度。在这些更具挑战性的标签结构下仍取得显著提升，表明 SCSD 在复杂多标签关系建模和跨视图一致性学习方面具有更强能力。与通过对比损失学习多视图一致特征的 DICNet，以及基于信息瓶颈原理抑制非共享信息、获得一致表征的 SIP 相比，所提 SCSD 在五个数据集上的 AP 平均分别提升 14.94% 和 8.65%。这些结果清楚表明了 SCSD 在多视图一致表征学习方面的优势。该对比实验充分验证了 SCSD 在双重缺失情形下进行多标签分类的有效性。

此外，还在视图完整且标签完整的条件下开展对比实验，如图 2 所示。可以看到，SCSD 在五个数据集的大多数指标上取得最佳性能，有力地说明了其通用性。在视图与标签均完整时，SCSD 仍能在大多数指标上获得最佳或接近最佳的性能。这说明基于多视图共享码本的一致表征学习机制本身具有较强表征能力，其有效性并不限于信息缺失的情形。

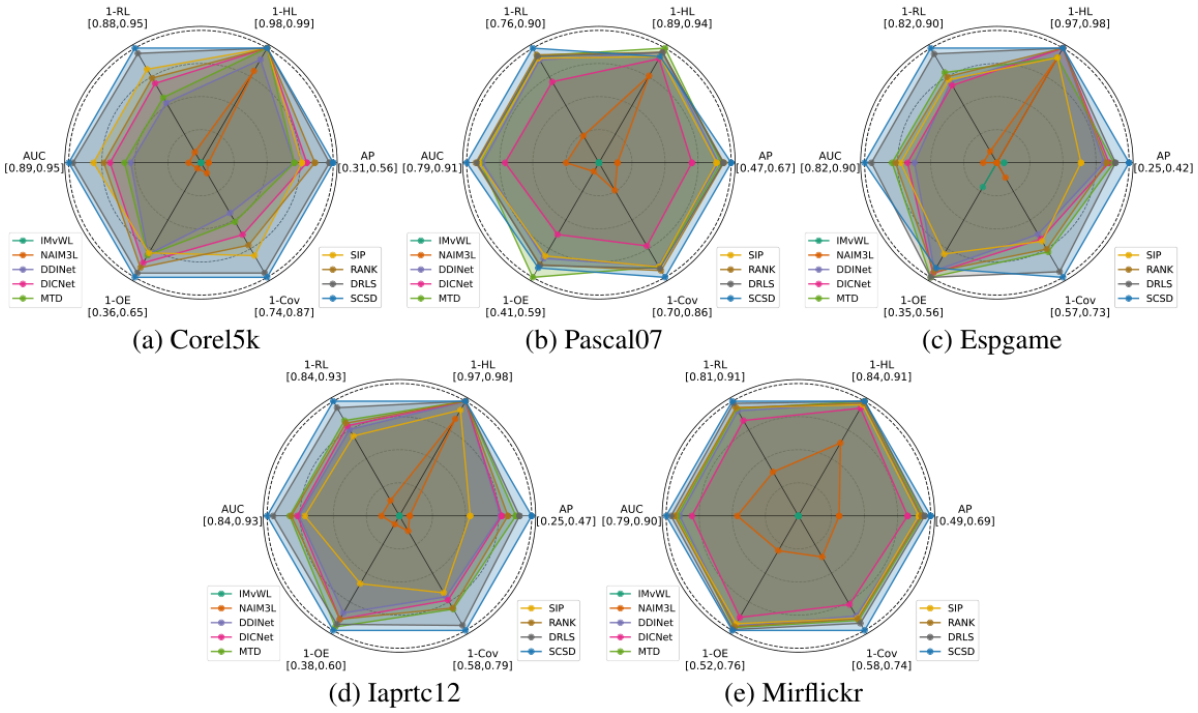


图 2：雷达图基于视图完整、标签完整且训练数据占比 70% 的实验结果，涵盖九种方法、五个数据集和六项指标。每幅图的中心表示最差结果，顶点表示最佳结果。子图依次为（a）Corel5k、（b）Pascal07、（c）Espgame、（d）Iaprtc12 和（e）Mirflickr。图例保留各方法名称；指标缩写的中文见第 3.1 节；方括号表示对应轴的取值范围。

3.5 参数分析

模型包含三个超参数：$\mathcal{L}_{rec}$ 中的 α、$\mathcal{L}_{dis}$ 中的 λ，以及决策融合中 softmax 的温度参数 τ。图 3 给出了 SCSD 的参数敏感性结果。图 3a 和图 3b 展示了不同 α、λ 组合下，SCSD 在 Corel5k 和 Pascal07 上的 AP 指标。可以观察到，在 Corel5k 上，当 $\alpha = 1e{-}2$ 或 $\alpha = 2e1$ 这类极端值时，SCSD 性能出现波动；而在 Pascal07 上，性能相对稳定。对于 Corel5k，当 $\alpha \in [1e{-}2,\ 1e0]$ 且 $\lambda \in [1e{-}2,\ 2e{-}1]$ 时得到最佳结果；对于 Pascal07，当 $\alpha \in [5e0,\ 2e1]$ 且 $\lambda \in [1e{-}2,\ 2e{-}1]$ 时性能较好。图 3c 和图 3d 展示了 τ 对模型的影响，左侧纵轴为 AP，右侧纵轴为 AUC。所提方法对温度参数 τ 的变化不敏感。在 Corel5k 上，$\tau \in [5e{-}1,\ 5e0]$ 时获得最佳结果；在 Pascal07 上，$\tau \in [1e{-}1,\ 5e{-}1]$ 时性能最好。

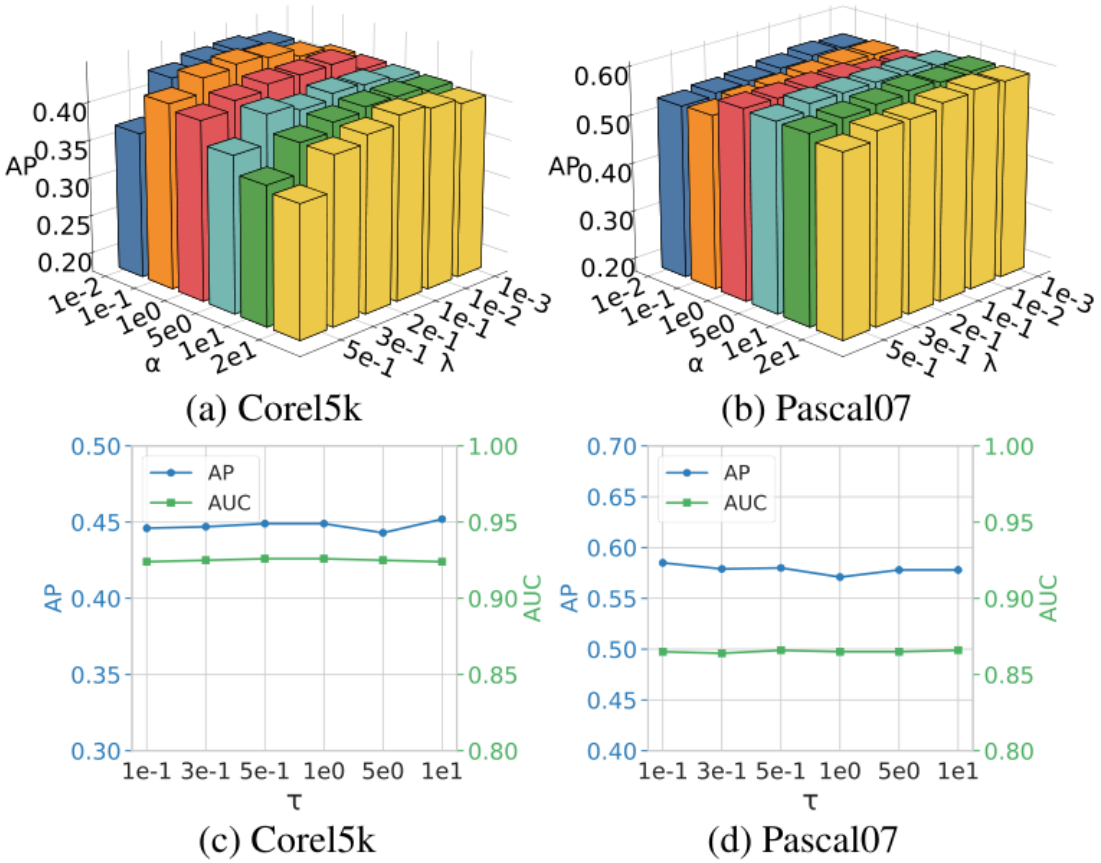


图 3： 在视图缺失率 50%、标签缺失率 50%、训练数据占比 70% 的条件下，对 SCSD 进行参数敏感性分析。子图（a）、（c）为 Corel5k，（b）、（d）为 Pascal07；AP＝平均精确率，AUC＝适配曲线下面积；其余坐标轴为参数 α、λ 和 τ。

3.6 消融研究

表 3 给出 SCSD 的消融研究，中间灰色背景突出显示 SCSD 完整版本。上半部分移除了不同的损失函数。其中，$\mathcal{L}_{dis_KL}$ 表示 $\mathcal{L}_{dis}$ 的第一项，用于鼓励学生模仿融合教师的输出。可以观察到，移除任一损失函数都会导致 SCSD 性能下降。表格下半部分移除了某些结构设计。第 5 行的“w/o VQ”表示不使用向量量化，而直接采用编码器输出的连续特征 $\{Z^{(v)}\}_{v=1}^{m}$。可以看到性能明显下降，这是因为多视图共享码本设计能够更好地支持一致表征学习。第 6 行的“w/o cross view rec”表示移除跨视图重构，改用标准单视图重构进行训练，同样造成一定程度的性能退化。最后一行“w/o S fusion”表示移除所提出的加权融合策略，替换为简单的掩码平均融合策略：

$$P_{i,:} = \Big(\sum_{v=1}^{m} P_{i,:}^{(v)} \mathcal{W}_{i,v}\Big) / \sum_{v=1}^{m} \mathcal{W}_{i,v}.$$

可以观察到性能下降，尤其是在 Pascal07 数据集上。这是因为 Pascal07 具有 20 个标签，能够提供更可靠的标签相关性矩阵 S，使我们的融合策略能够更好地识别不同视图预测的质量。总体而言，我们发现多视图共享码本和自蒸馏对 SCSD 性能的贡献最为显著。

Method	Corel5k			Pascal07		
	AP	1-RL	AUC	AP	1-RL	AUC
SCSD w/o $\mathcal{L}_{dis}$	0.376	0.882	0.884	0.560	0.834	0.855
SCSD w/o $\mathcal{L}_{dis_KL}$	0.411	0.906	0.909	<u>0.572</u>	0.843	<u>0.864</u>
SCSD w/o $\mathcal{L}_{rec}$	0.439	0.916	0.919	0.560	0.839	0.860
SCSD	**0.447**	**0.920**	**0.923**	**0.578**	**0.846**	**0.866**
SCSD w/o VQ	0.430	0.914	0.916	0.565	0.841	0.860
SCSD w/o cross_view_rec	0.442	0.918	0.921	0.553	0.837	0.859
SCSD w/o S_fusion	<u>0.445</u>	<u>0.919</u>	<u>0.922</u>	0.570	<u>0.844</u>	<u>0.864</u>

表 3：视图缺失率 50%、标签缺失率 50%、训练数据占比 70% 时，两个数据集上的消融结果。“w/o”表示“不使用”。粗体表示最佳结果，下划线表示次佳结果。Method＝方法；w/o VQ＝不使用向量量化；w/o cross view rec＝不使用跨视图重构；w/o S fusion＝不使用基于 S 的融合；其他“w/o”行表示移除其后所列损失项。指标中文见第 3.1 节。

4 结论

本文提出了一种新的不完整多视图多标签分类方法。首先，使用多视图共享码本学习跨视图一致的离散表征，并通过跨视图重构机制进一步增强不同视图表征的一致性。随后，评估各视图预测保留标签相关性结构的能力，据此分配不同权重，并通过加权融合得到融合预测。最后，以融合预测为教师，指导各视图预测的学习，通过自蒸馏损失将所有视图的知识反馈到每个视图专属分支，从而提升模型的泛化能力。广泛实验表明，SCSD 方法能够有效解决双重缺失条件下的多视图多标签分类问题。

局限性。尽管该方法在不完整多视图多标签学习任务中取得了较强性能，但仍有若干局限，可能影响它在更广泛场景中的适用性。首先，引入多视图共享码本带来额外的内存和计算开销。内存开销主要来自码本嵌入的存储和更新，计算成本主要来自量化时输入特征与码本嵌入之间距离矩阵的计算。此外，SCSD 的量化模块假设不同视图的表征能够在共享潜在空间中对齐。当视图缺失率很高时，可用于对齐的跨视图信息大幅减少，可能削弱共享码本机制的泛化能力。

可复现性声明

本文所有实验均在五个公开多视图多标签数据集上完成，确保未使用任何私有或专有数据。训练过程的伪代码见附录 A.2。SCSD 源代码已在 GitHub 上提供。

致谢

本工作得到国家自然科学基金资助（项目编号 62476166 和 62576206）。

参考文献

以下保留作者、出版物专名、卷期、页码、年份与 DOI，论文题名译为中文；出版物中文释义在括号内给出。原稿中的年份及书目信息照录，不根据外部资料改写。

1. Alexei Baevski, Steffen Schneider, Michael Auli. **vq-wav2vec：离散语音表征的自监督学习**。arXiv 预印本 arXiv:1910.05453，2019。

2. Ze-Sen Chen, Xuan Wu, Qing-Guo Chen, Yao Hu, Min-Ling Zhang. **利用基于图的消歧进行多视图偏多标签学习**。Proceedings of the AAAI Conference on Artificial Intelligence（AAAI 人工智能会议论文集），第 34 卷，第 3553–3560 页，2020。

3. Zhao-Min Chen, Xiu-Shen Wei, Peng Wang, Yanwen Guo. **利用图卷积网络进行多标签图像识别**。Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition（IEEE/CVF 计算机视觉与模式识别会议论文集），第 5177–5186 页，2019。

4. Pinar Duygulu, Kobus Barnard, Joao FG de Freitas, David A Forsyth. **将目标识别视为机器翻译：为固定的图像词汇学习词典**。Computer Vision—ECCV 2002: 7th European Conference on Computer Vision Copenhagen, Denmark, May 28–31, 2002 Proceedings, Part IV 7（《计算机视觉——ECCV 2002》：第七届欧洲计算机视觉会议，丹麦哥本哈根，2002 年 5 月 28–31 日，论文集第四部分 7），第 97–112 页。Springer，2002。

5. Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn, Andrew Zisserman. **PASCAL 视觉目标类别（VOC）挑战赛**。International Journal of Computer Vision（《国际计算机视觉期刊》），88:303–338，2010。

6. Michael Grubinger, Paul Clough, Henning Müller, Thomas Deselaers. **IAPR TC-12 基准：面向视觉信息系统的新评估资源**。International Workshop ontoImage（ontoImage 国际研讨会），第 2 卷，2006。

7. Jun-Yi Hang, Min-Ling Zhang. **面向多标签分类的标签语义与深度标签专属特征协同学习**。IEEE Transactions on Pattern Analysis and Machine Intelligence（《IEEE 模式分析与机器智能汇刊》），44(12):9860–9871，2021。

8. Mark J Huiskes, Michael S Lew. **MIR Flickr 检索评估**。Proceedings of the 1st ACM International Conference on Multimedia Information Retrieval（第一届 ACM 多媒体信息检索国际会议论文集），第 39–43 页，2008。

9. Xiang Li, Songcan Chen. **面向非对齐不完整多视图与缺失多标签学习的简洁有效模型**。IEEE Transactions on Pattern Analysis and Machine Intelligence（《IEEE 模式分析与机器智能汇刊》），44(10):5918–5932，2021。

10. Bo Liu, Weibin Li, Yanshan Xiao, Xiaodong Chen, Laiwang Liu, Changdong Liu, Kai Wang, Peng Sun. **利用高阶标签相关性的多视图多标签学习**。Information Sciences（《信息科学》），624:165–184，2023a。

11. Chengliang Liu, Jie Wen, Xiaoling Luo, Chao Huang, Zhihao Wu, Yong Xu. **DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络**。Proceedings of the AAAI Conference on Artificial Intelligence（AAAI 人工智能会议论文集），第 37 卷，第 8807–8815 页，2023b。

12. Chengliang Liu, Jie Wen, Xiaoling Luo, Yong Xu. **通过标签引导的掩码视图与类别感知 Transformer 进行不完整多视图多标签学习**。Proceedings of the AAAI Conference on Artificial Intelligence（AAAI 人工智能会议论文集），第 37 卷，第 8816–8824 页，2023c。

13. Chengliang Liu, Jinlong Jia, Jie Wen, Yabo Liu, Xiaoling Luo, Chao Huang, Yong Xu. **面向不完整多视图偏多标签分类的注意力诱导嵌入补全**。Proceedings of the AAAI Conference on Artificial Intelligence（AAAI 人工智能会议论文集），第 38 卷，第 13864–13872 页，2024a。

14. Chengliang Liu, Jie Wen, Yabo Liu, Chao Huang, Zhihao Wu, Xiaoling Luo, Yong Xu. **用于不完整多视图弱多标签学习的掩码双通道解耦框架**。Advances in Neural Information Processing Systems（《神经信息处理系统进展》），36，2024b。

15. Chengliang Liu, Gehui Xu, Jie Wen, Yabo Liu, Chao Huang, Yong Xu. **通过语义不变性学习与原型建模进行部分多视图多标签分类**。Forty-first International Conference on Machine Learning（第四十一届国际机器学习会议），2024c。

16. Chengliang Liu, Jie Wen, Yong Xu, Bob Zhang, Liqiang Nie, Min Zhang. **面向不完整多视图缺失多标签分类的可靠表征学习**。IEEE Transactions on Pattern Analysis and Machine Intelligence（《IEEE 模式分析与机器智能汇刊》），47(6):4940–4956，2025。doi: 10.1109/TPAMI.2025.3546356。

17. Gengyu Lyu, Xiang Deng, Yanan Wu, Songhe Feng. **超越共享子空间：用于多视图多标签学习的视图专属融合**。Proceedings of the AAAI Conference on Artificial Intelligence（AAAI 人工智能会议论文集），第 36 卷，第 7647–7654 页，2022。

18. Tal Ridnik, Emanuel Ben-Baruch, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter, Lihi Zelnik-Manor. **用于多标签分类的非对称损失**。Proceedings of the IEEE/CVF International Conference on Computer Vision（IEEE/CVF 国际计算机视觉会议论文集），第 82–91 页，2021。

19. Qiaoyu Tan, Guoxian Yu, Carlotta Domeniconi, Jun Wang, Zili Zhang. **不完整多视图弱标签学习**。IJCAI（国际人工智能联合会议），第 2703–2709 页，2018。

20. Aaron Van Den Oord, Oriol Vinyals 等. **神经离散表征学习**。Advances in Neural Information Processing Systems（《神经信息处理系统进展》），30，2017。

21. Luis Von Ahn, Laura Dabbish. **利用电脑游戏标注图像**。Proceedings of the SIGCHI Conference on Human Factors in Computing Systems（SIGCHI 计算系统人因会议论文集），第 319–326 页，2004。

22. Jie Wen, Chengliang Liu, Shijie Deng, Yicheng Liu, Lunke Fei, Ke Yan, Yong Xu. **标签不完整且视图缺失条件下的深度双重不完整多视图多标签学习**。IEEE Transactions on Neural Networks and Learning Systems（《IEEE 神经网络与学习系统汇刊》），2023。

23. Xuan Wu, Qing-Guo Chen, Yao Hu, Dengbao Wang, Xiaodong Chang, Xiaobo Wang, Min-Ling Zhang. **利用视图专属信息提取进行多视图多标签学习**。IJCAI（国际人工智能联合会议），第 3884–3890 页，2019。

24. Xiaoqiang Yan, Shizhe Hu, Yiqiao Mao, Yangdong Ye, Hui Yu. **深度多视图学习方法综述**。Neurocomputing（《神经计算》），448:106–129，2021。

25. Xu Yan, Jun Yin, Jie Wen. **通过解耦表征与标签语义嵌入进行不完整多视图多标签学习**。Proceedings of the Computer Vision and Pattern Recognition Conference（计算机视觉与模式识别会议论文集），第 30722–30731 页，2025。

26. Penghui Yang, Ming-Kun Xie, Chen-Chen Zong, Lei Feng, Gang Niu, Masashi Sugiyama, Sheng-Jun Huang. **多标签知识蒸馏**。Proceedings of the IEEE/CVF International Conference on Computer Vision（IEEE/CVF 国际计算机视觉会议论文集），第 17271–17280 页，2023。

27. Jun Yin, Shiliang Sun. **利用重构视图进行不完整多视图聚类**。IEEE Transactions on Knowledge and Data Engineering（《IEEE 知识与数据工程汇刊》），35(3):2671–2682, 2021。

28. Jiahui Yu, Xin Li, Jing Yu Koh, Han Zhang, Ruoming Pang, James Qin, Alexander Ku, Yuanzhong Xu, Jason Baldridge, Yonghui Wu. **利用改进 VQGAN 进行向量量化图像建模**。arXiv 预印本 arXiv:2110.04627，2021。

29. Zhiwen Yu, Ziyang Dong, Chenchen Yu, Kaixiang Yang, Ziwei Fan, CL Philip Chen. **多视图学习综述**。Frontiers of Computer Science（《计算机科学前沿》），19(7):197334, 2025。

30. Linfeng Zhang, Chenglong Bao, Kaisheng Ma. **自蒸馏：迈向高效而紧凑的神经网络**。IEEE Transactions on Pattern Analysis and Machine Intelligence（《IEEE 模式分析与机器智能汇刊》），44(8):4388–4403，2021。

31. Dawei Zhao, Qingwei Gao, Yixiang Lu, Dong Sun, Yusheng Cheng. **一致性与多样性神经网络多视图多标签学习**。Knowledge-Based Systems（《基于知识的系统》），218:106841, 2021。

32. Jing Zhao, Xijiong Xie, Xin Xu, Shiliang Sun. **多视图学习概述：最新进展与新挑战**。Information Fusion（《信息融合》），38:43–54，2017。

附录 A

A.1 相关工作

多视图多标签学习。在视图和标签完整的条件下，已有多种代表性方法。SIMM（Wu et al., 2019）联合优化混淆对抗损失与多标签损失，以利用共享信息，同时在共享子空间上施加正交约束，保留具有判别力的特征。为显式处理视图一致性与多样性，CDMM（Zhao et al., 2021）利用独立分类器建模视图一致性，引入 Hilbert–Schmidt 独立性准则捕获多样性，并引入标签相关性和视图贡献因子提升性能。从基于图的角度看，D-VSM（Lyu et al., 2022）利用深度 GCN 对视图特征编码，并在统一图中整合跨视图关系。此外，ELSMML（Liu et al., 2023a）着重建模标签依赖，利用高阶策略构建标签相关性矩阵，结合降维提取潜在语义特征，引入流形正则化保留结构信息，并利用加速优化算法训练分类器。

不完整多视图多标签学习。为处理视图与标签缺失，研究者提出了多种不完整多视图多标签学习方法。iMvWL（Tan et al., 2018）在共享子空间中同时学习跨视图关系与弱标签信息，并捕获局部标签相关性、学习相应预测器。为解决不完整设定下标签不足和视图未对齐的问题，NAIM3L（Li & Chen, 2021）通过一致性约束与标签结构建模缓解标签不足，并在公共标签空间中联合建模全局和局部结构。从网络架构角度看，DDINet（Wen et al., 2023）包含特征提取、加权融合、分类和解码模块，能够在双重缺失情境下有效整合可用数据与标签。MTD（Liu et al., 2024b）引入掩码机制，提出掩码双通道解耦框架，将表征分为共享与私有通道，并通过对比损失和图正则化增强特征学习。此外，DRLS（Yan et al., 2025）聚焦表征解耦，通过跨视图重构提取共享特征，利用互信息约束学习视图专属特征，并利用标签相关性引导语义嵌入，以保留拓扑结构。

A.2 算法

SCSD 模型的训练过程见算法 1。

算法 1：SCSD 的训练过程（逐行中文对照）

输入：不完整多视图数据 $\{X^{(v)}\}_{v=1}^{m}$，不完整标签矩阵 Y，缺失视图指示矩阵 $\mathcal{W}$，缺失标签指示矩阵 $\mathcal{G}$，超参数 α、λ 和 τ，训练轮数 H。

输出：预测 P。

1. 初始化模型参数。使用式（4）计算标签相关性矩阵 S。令 `codebook_initialized = False`。
2. 对 $h = 1$ 到 H 执行以下循环。
3. 通过编码器提取多视图连续特征 $\{Z^{(v)} = E^{(v)}\big(X^{(v)}\big)\}_{v=1}^{m}$。
4. 将非缺失特征 $\{Z^{(v)}\}_{v=1}^{m}$ 划分为特征片段：
   $\{\widetilde{Z}_{i,:}^{(v)} = \left[z_1,\ z_2,\ \ldots,\ z_g\right]^{\top} \in \mathbb{R}^{g\times(d_e/g)} \mid i = 1,\ \ldots,\ n,\ \ v = 1,\ \ldots,\ m,\ \ \mathcal{W}_{i,v} \neq 0\}$。
5. 若 `codebook_initialized` 为假，则执行第 6—7 行。
6. 使用当前批次内所有可用视图特征 $\{\widetilde{Z}_{i,:}^{(v)}\}$ 进行 k-means 聚类，以初始化码本嵌入。
7. 令 `codebook_initialized = True`。

8. 对每个 z_t 使用式（1）找到最近的码本嵌入 e_{t^*}，并将它们拼接，得到离散特征 $\{\widehat{Z}^{(v)}\}_{v=1}^{m}$。

9. 通过解码器获得跨视图重构结果：$\{\widehat{X}^{(j,v)} = D^{(j)}(\widehat{Z}^{(v)})\}_{v=1}^{m}$，$j = 1, \ldots, m$。

10. 通过分类器获得各视图的预测：$\{P^{(v)} = \sigma\left(F_{cls}^{(v)}(\widehat{Z}^{(v)})\right)\}_{v=1}^{m}$。

11. 根据式（5）、（6）、（7）计算权重，得到融合多视图预测 P。

12. 根据式（10）计算总体损失 $\mathcal{L}$，并更新参数。

Algorithm 1: The training process of SCSD

Input: Incomplete multi-view data $\{X^{(v)}\}_{v=1}^{m}$, incomplete label matrix Y, missing-view indicator matrix $\mathcal{W}$, missing-label indicator matrix $\mathcal{G}$, hyperparameters α, λ, and τ, and training epochs H.

Output: Prediction P.

Initialize the model parameters. Use Eq 4 to compute the label correlation matrix S. Set $codebook_initialized$ = False.

for $h = 1$ **to** H **do**

  Extract multi-view continuous features $\{Z^{(v)} = E^{(v)}(X^{(v)})\}_{v=1}^{m}$ through the encoders.

  Split the non-missing features $\{Z^{(v)}\}_{v=1}^{m}$ into feature segments $\{\tilde{Z}_{i,:}^{(v)} = [\, z_1, z_2, \ldots, z_g \,]^{\top} \in \mathbb{R}^{g \times (d_e/g)} \mid i = 1, \ldots, n,\ v = 1, \ldots, m,\ \mathcal{W}_{i,v} \neq 0\}$.

  if *not* $codebook_initialized$ **then**

    Use all available view features $\{\tilde{Z}_{i,:}^{(v)}\}$ within the current batch to perform k-means clustering for initializing the codebook embeddings.

    $codebook_initialized = \text{True}$

  Use Eq 1 to find the nearest codebook embedding e_{t^*} for each z_t, and concatenate them to obtain the discrete features $\{\hat{Z}^{(v)}\}_{v=1}^{m}$.

  Obtain the cross-view reconstruction results through the decoders: $\{\hat{X}^{(j,v)} = D^{(j)}(\hat{Z}^{(v)})\}_{v=1}^{m}, j = 1, \ldots, m$.

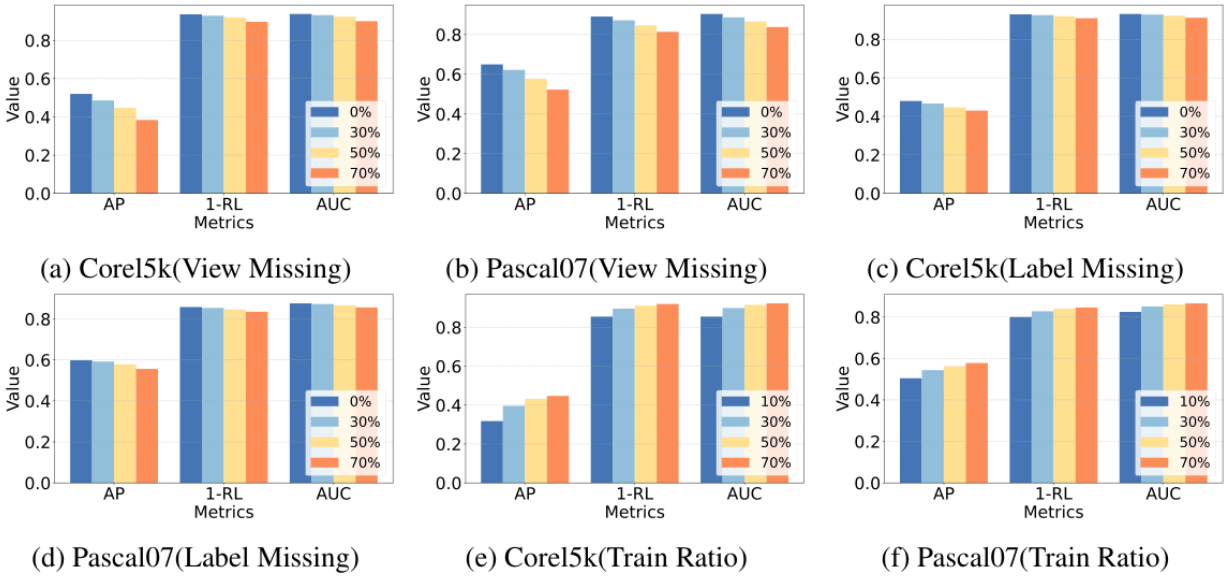
  Obtain the predictions of each view through the classifiers: $\{P^{(v)} = \sigma(F_{cls}^{(v)}(\hat{Z}^{(v)}))\}_{v=1}^{m}$.

  Compute the weights according to Eq 5, 6, 7 and obtain the fused multi-view prediction P.

  Compute the overall loss $\mathcal{L}$ according to Eq 10 and update the parameters.

算法原稿对照：Input＝输入；Output＝输出；Initialize＝初始化；for...do＝循环执行；if...then＝如果……则；Extract＝提取；Split＝划分；Use＝使用；Obtain＝得到；Compute＝计算；update the parameters＝更新参数。上方逐行译文覆盖原算法全部文字；此裁图用于精确保留公式、编号及控制流缩进。

A.3 补充实验结果



(a) Corel5k(View Missing) (b) Pascal07(View Missing) (c) Corel5k(Label Missing)

(d) Pascal07(Label Missing) (e) Corel5k(Train Ratio) (f) Pascal07(Train Ratio)

图 4： SCSD 模型在不同视图缺失率、不同标签缺失率与不同训练集占比下的实验结果，展示两个数据集和三项评价指标。图内 Value＝数值；Metrics＝指标；View Missing＝视图缺失；Label Missing＝标签缺失；Train Ratio＝训练集占比。子图（a）、（b）分别为 Corel5k、Pascal07 的视图缺失实验；（c）、（d）分别为两者的标签缺失实验；（e）、（f）分别为两者的训练集占比实验。AP、1-RL、AUC 的中文含义见第 3.1 节。各图例百分比原样保留。

缺失率与训练样本比例分析。图 4a 和图 4b 展示标签缺失率固定为 50% 时，SCSD 在不同视图缺失率下的结果。图 4c 和图 4d 展示视图缺失率固定为 50% 时，不同标签缺失率下的结果。随着视图缺失率或标签缺失率逐渐增加，模型性能也会下降。不过，即使缺失率达到 70%，我们的模型仍能保持相对稳定的性能。此外，增大视图缺失率对模型的影响比增大标签缺失率更大。这是因为模型依赖学得的多视图一致表征，而随着视图缺失率增加，表征学习质量会降低。图 4e 和图 4f 展示了视图缺失率 50%、标签缺失率 50% 时，SCSD 在不同训练集占比下的结果。随着训练集占比增大，模型性能也随之提升。即使在训练数据仅占 10% 的极端情况下，我们的模型仍取得令人满意的结果。

补充参数分析。在图 5a 和图 5b 中，我们还使用不同规模的码本大小 k 和码本嵌入维度 d_c 重新训练并评价模型，以系统分析多视图共享码本对表征能力及最终性能的影响。实验结果表明，在一定范围内适当增大码本可以提高模型性能，但过大的码本会带来更高计算成本，而收益逐渐减小。同时，较小的嵌入维度能够稳定量化过程，提高码本利用率，从而获得更好的模型性能。

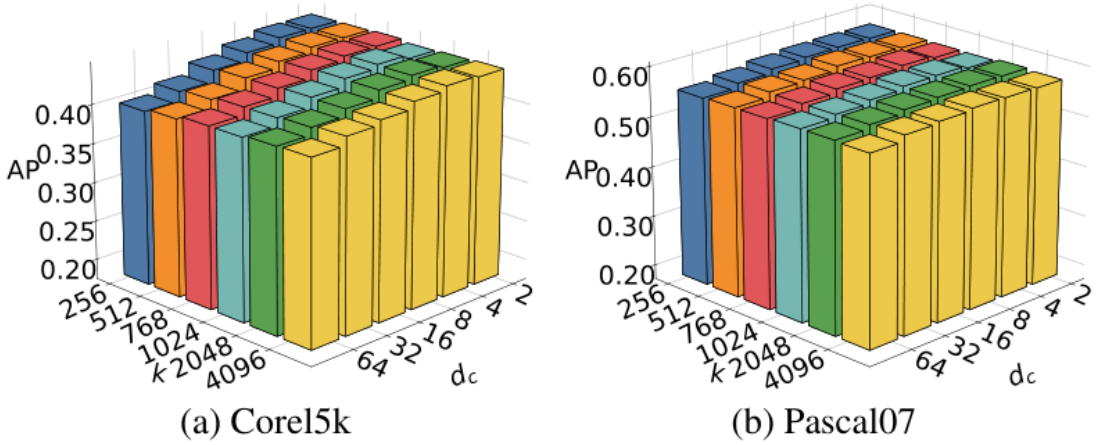


图 5： 视图缺失率 50%、标签缺失率 50%、训练数据占比 70% 时，SCSD 的补充参数敏感性分析。（a）Corel5k；（b）Pascal07。AP＝平均精确率；k ＝码本大小；d_c ＝码本嵌入维度。

码本利用率分析。图 6 展示了 SCSD 模型训练过程中在验证集上的码本利用率变化。本实验通过统计前向传播期间实际被选中的码本嵌入数，再除以码本总大小，计算利用率；未分配给任何输入特征的码本嵌入被视为不活跃。该方式直观反映了模型在量化阶段覆盖码本原型的程度，并体现模型的效率。我们仅展示 10 个训练轮次，因为此后所有数据集都保持 100% 的码本利用率，直至训练结束。从图中可以看到，SCSD 在所有数据集上仅需几轮就能达到 100% 的码本利用率，并在后续训练中持续稳定保持。这说明 SCSD 能够充分激活共享码本中的所有嵌入单元，避免码本坍塌问题，即只有极少数码本嵌入被频繁使用，而大多数向量闲置、未激活，导致表征能力不足和信息利用率低。换言之，SCSD 的共享码本设计不仅保留了多视图数据丰富的表征能力，还能通过有限数量的码本嵌入有效抑制冗余特征，从而增强学得表征的泛化能力。

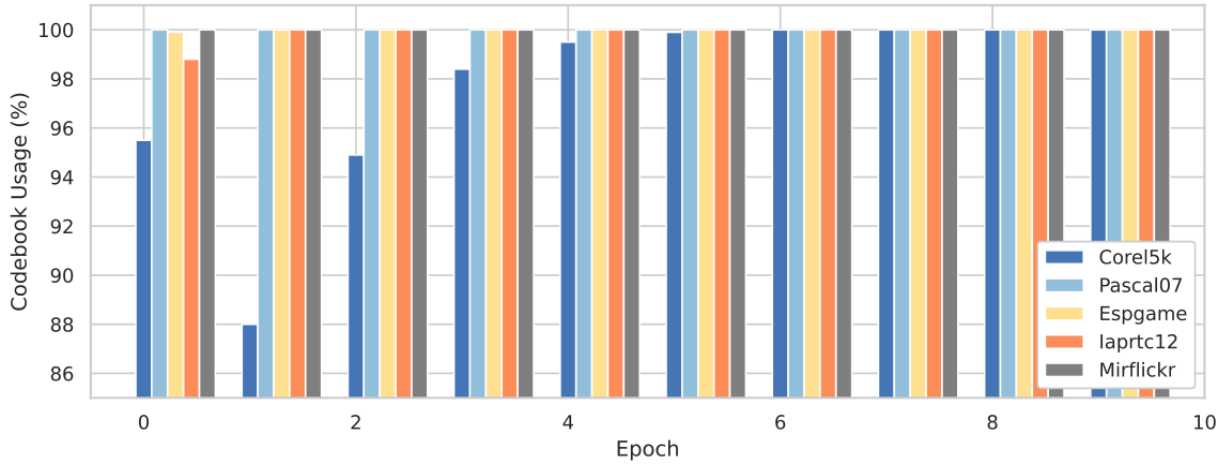


图 6： 在视图缺失率 50%、标签缺失率 50%、训练数据占比 70% 的训练设定下，报告 SCSD 在全部五个数据集上的码本利用率。Codebook Usage (%)＝码本利用率（%）；Epoch＝训练轮次；图例中的五个数据集名称保留原样。

A.4 大语言模型使用声明

本文使用大语言模型润色了引言部分。