面向不完整多视图部分多标签分类的可靠跨视图邻域关系迁移与高阶语义结构挖掘

ReCHSM 原文完整中文译文

原题：Reliable cross-view neighborhood relation transfer and high-order semantic structure mining for incomplete multi-view partial multi-label classification

作者：Jiayan Li[1] · Zhixian Jiang[1] · Wenbin Bu[1] · Nisuo Du[2] · Xiaohuan Lu[1]

[1] 贵州大学大数据与信息工程学院，中国贵阳。
[2] 贵州大学贵州省大数据实验室，中国贵阳。

通讯作者：Nisuo Du，nsdu@gzu.edu.cn；Xiaohuan Lu，xhlu3@gzu.edu.cn。
作者电子邮箱：Jiayan Li，jiayanli720@gmail.com；Zhixian Jiang，jjjzxx1027@gmail.com；Wenbin Bu，wenbinbu2005@gmail.com。

期刊：Journal of King Saud University Computer and Information Sciences (2026) 38:843。
DOI：https://doi.org/10.1007/s44443-026-01262-9。
稿件类型：研究论文。收稿：2026 年 4 月 30 日；录用：2026 年 8 月 15 日。
在线发表：2026 年 9 月 3 日。
© The Author(s) 2026。版权归原作者所有。

译文范围与使用说明。 本译文依据用户上传文件中的 19 页论文原件制作，完整覆盖题名、摘要、正文第 1 至第 5 节、22 个编号公式、算法 1、6 幅图、8 张表、作者声明与全部参考文献；不是摘要或节译。原图、原表和编号公式采用原件高清裁图，保留原有数字、符号、上下标、字体强调与图中标注，并在相邻中文文字中解释其含义。参考文献保留作者、原题、刊物及 DOI，并附题名中译。原件提及在线补充材料 S1、S2、表 S1 和表 S2，但上传文件不含这些材料，因此本译文不声称包含它们。

本文件是应上传者要求生成的非官方私人参考译本，不表示原作者、期刊或出版方认可。原文的 CC BY-NC-ND 4.0（署名—非商业性使用—禁止演绎）声明完整保留于文末；上传来源不意味着取得公开传播译文或其他演绎材料的许可。文中个别原始表述、数值或数学边界条件的未说明之处按原文保留，文末列出译者核对说明。

摘要

多视图多标签分类能够从多个角度刻画复杂的现实数据，因而受到越来越多的关注。然而，视图与标签同时缺失往往造成特征信息不完整和数据分布不确定，阻碍判别性语义的提取。为解决这一问题，我们提出一个统一框架，称为可靠跨视图邻域关系迁移与高阶语义结构挖掘（Reliable Cross-View Neighborhood Relation Transfer and High-Order Semantic Structure Mining，ReCHSM）。具体而言，我们设计了一种可靠跨视图补全机制，将已观测视图中的邻域关系迁移过来，以重构缺失视图。为减轻跨视图异质性引起的错误迁移，该机制评估候选邻居的可靠性，并采用轻量级非线性网络对重构特征进行细化。为进一步从补全后的表示中提取结构信息，我们引入一种基于随机游走的策略，传播修复后的局部邻域，以捕捉高阶语义依赖。此外，考虑到各视图提供的判别信息不同，而且补全视图的质量可能存在差异，我们开发了一个由标签语义一致性驱动的模块，用于评估视图质量并自适应地分配融合权重。在五个公开数据集上的大量实验表明，ReCHSM 有效且具有竞争力。

关键词： 不完整多视图部分多标签分类；视图补全；高阶语义结构挖掘；视图质量评估。

1 引言

随着现代数据采集技术的发展，样本越来越多地由多个互补视图表示。例如，一个网页可以通过页面内容和锚文本来刻画（Zhao et al. 2017），而一个人可以通过人脸、指纹、签名和虹膜信息来描述（He et al. 2023）。多视图学习融合这些互补信息，以提高表示质量（Fang et al. 2022；Hu et al. 2022；Zhu et al. 2022, 2020）。与此同时，多标签分类（MLC）为每个样本赋予多个语义标签：例如，自然场景图像可能包含“天空”“树”和“云”，而一篇文档可能涉及“政治”“经济”和“体育”（Liu et al. 2022）。将这两种范式结合便得到多视图多标签分类（MvMLC），这一方向日益受到关注。

现有 MvMLC 方法以不同方式利用跨视图互补性和标签依赖。LCBM（Sun and Zong 2021）在视图共享的潜在子空间中，通过条件伯努利混合建模标签依赖，并采用高斯混合变分自编码器进行近似推断。LSA-MML（Zhang et al. 2018）则通过矩阵分解学习共享表示，并利用 HSIC 在核空间中对齐视图特定的潜在基。邻近的多模态与多视图领域近期研究也强调异质表示对齐、自适应信息融合和关系依赖建模（Chang et al. 2026；Jiang et al. 2025, 2026a；Zheng et al. 2026）。这些进展表明，有效的多视图学习应同时考虑跨视图差异、视图贡献不均等以及复杂的结构关系。

然而，大多数现有 MvMLC 方法假定所有视图和标签都完整可用。在现实应用中，完整的多视图观测和标签监督通常难以获得（Liu et al. 2024；Zeng et al. 2024）。传感器故障、视角遮挡、传输异常和数据损坏都可能造成视图缺失（Li et al. 2024；Zhao et al. 2017）。同时，人工标注中的不确定性和人为错误可能导致标签缺失（Li et al. 2024）。这两种不完整性催生了不完整多视图部分多标签分类（IMvPMLC）任务。

现有 IMvPMLC 方法从不同角度应对双重不完整性。早期方法包括 iMvWL（Tan et al. 2018）和 NAIM3L（Li and Chen 2022），主要依赖共享子空间学习、缺失指示量及标签结构正则化。较新的深度模型分别采用 DICNet 中的实例级对比对齐（Liu et al. 2023c）、LMVCAT 中基于 Transformer 的视图—类别交互（Liu et al. 2023d）、MSLPP 中的多尺度局部性保持（Long et al. 2024）、

RANK 中标签驱动的图学习与样本级质量判别（Liu et al. 2025），以及 DSPNF 中的双空间结构约束与不确定性感知融合（Jiang et al. 2026b）。尽管有效，这些方法主要在表示学习与融合期间抑制、绕过或补偿不可用视图，而非显式修复其局部邻域结构。

恢复驱动的方法通过推断不可用视图提供了另一种解决思路。LOGIC（Zheng et al. 2025）在信息论框架下从共同潜在表示生成缺失视图，而关系迁移方法利用可观测源视图中保留的邻域关系来推断目标视图（Wang et al. 2023）。然而，潜在生成可能并不显式保持目标视图的局部几何；当异质视图提供的邻域证据不一致时，直接关系迁移也可能引入不可靠候选。此外，从不完整或粗略恢复的表示构建的图约束，可能将失真的局部关系传播为高阶依赖。

为解决这些局限，我们提出 ReCHSM，用于视图与标签同时缺失时的分类。ReCHSM 遵循从可靠性感知补全到结构学习的过程。首先通过跨视图邻域关系迁移、基于可靠性的候选选择、加权聚合与非线性细化，重构每个缺失视图。随后由补全后的表示构建关系图，并应用多步随机游走传播以捕捉高阶语义依赖。最后，基于标签语义一致性的辅助机制估计样本级视图质量，在融合期间自适应地降低语义不一致视图的贡献。

总体而言，本文的主要贡献如下。

- 我们开发了一种可靠性感知跨视图补全机制，将候选在不同源视图中的出现频次与累积几何距离相结合，用于邻居选择和加权重构。轻量级非线性网络进一步细化重构特征。
- 我们提出一种补全引导的高阶结构学习策略，从补全后的视图表示构建关系图，并通过多步随机游走传播扩展修复后的局部邻域。
- 我们引入一种标签语义一致性引导的样本级融合机制，强调那些成对关系能够更好保持已观测标签所刻画语义的视图。五个基准数据集上的大量实验进一步证明了该方法的有效性和竞争力。

2 相关工作

2.1 多视图多标签分类

MvMLC 将多视图学习与多标签分类结合，面临双重挑战：既要处理不同视图产生的异质表示，又要处理多个相关语义标签。为应对这些挑战，研究者开发了多种 MvMLC 方法。其中，Liu 等提出 lrMMC（Liu et al. 2015），在矩阵补全框架中嵌入多视图学习能力。它首先将全部可用视图投影到低秩空间，以提取统一的低维表示，然后通过学习视图组合权重来捕捉不同视图的互补性。Zhu 等进一步提出 MVLE（Zhu et al. 2018），通过最大化特征空间、潜在空间与标签空间之间的相关性，学习具有预测能力的潜在空间；该方法还引入 Hilbert–Schmidt 独立性准则（HSIC），以平衡视图间的多样性与一致性。Huang 等进一步提出 VLSF（Huang et al. 2019），联合学习视图—标签特定表示和视图贡献权重，从而考虑不同视图贡献的不均等及标签特定的特征关联。

随着深度学习不断发展，Zhao 等开发了 CDMM（Zhao et al. 2021b）。该方法利用统一神经网络框架，通过为每个视图构建独立分类器，同时整合多视图一致性和多样性。它鼓励各视图给出一致的标签预测，并进一步引入基于 HSIC 的多样性建模、标签相关性因子和视图贡献因子。为处理非对齐场景，Zhao 等又提出 LVSL（Zhao et al. 2023），显式学习视图特定标签，并将特征空间的拉普拉斯图正则

化与低秩标签相关性建模相结合，以保持原始几何结构并更好地捕捉标签依赖。Liu 等随后提出 ELSMML（Liu et al. 2023a）。该方法将多视图学习纳入一个包含降维和流形正则化的更广泛框架，以识别标签中的高层潜在语义信息。

除面向特定任务的 MvMLC 研究外，邻近的多模态与多视图领域近期也进一步研究了表示对齐、自适应融合和关系依赖建模。Jiang 等在表示学习之前采用模态对齐预处理，减小异质模态间的分布差异（Jiang et al. 2025）。Chang 等保留相对独立的模态特定学习分支，并执行自适应后期融合，以减少直接聚合异质特征造成的干扰（Chang et al. 2026）。从关系建模角度，Jiang 等将知识图谱与图注意力网络相结合，以捕捉多模态实体间显式的语义依赖（Jiang et al. 2026a）。此外，Zheng 等提出 STANCE，将视图特定自表示矩阵张量化，以捕捉高阶视图间相关性，并采用样本级注意力进行自适应多视图融合（Zheng et al. 2026）。这些研究说明处理跨视图异质性、视图贡献不均等和复杂结构依赖的重要性。不过，它们主要聚焦完整多模态数据或无监督多视图聚类，并未直接处理 IMvPMLC 所考虑的视图与语义标签同时缺失问题。

2.2 不完整多视图多标签分类

在 MvMLC 中，视图和标签同时缺失会降低多视图数据的语义完整性，增加分布不确定性，并造成监督稀疏。因此，特征学习和分类变得更加困难。为缓解这一问题，Zhao 等提出 TM3L（Zhao et al. 2021a），采用两阶段学习策略，在共享低维子空间中联合建模多视图特征，并进一步结合标签矩阵补全，以减轻双重不完整性造成的不利影响。Deng 等进一步提出 MVIML-TAR（Deng et al. 2026），引入 Tucker 分解进行共享潜在标签学习，以刻画不完整多视图数据中的跨视图一致性和潜在语义关联。

随着深度学习发展，表示学习框架在不完整设置下取得了显著进展。DICNet（Liu et al. 2023c）使用缺失感知的实例级对比学习，对齐各视图可用表示，并在重构、对比学习和融合期间利用缺失指示量排除无效实例。MTD（Liu et al. 2023b）将视图级表示分解为共享与视图特定分量，并把跨通道对比学习与随机片段掩蔽相结合。MSLPP（Long et al. 2024）在原始空间和潜在空间中保持多尺度局部结构，同时通过缺失视图掩蔽策略降低不可用视图的影响。RANK（Liu et al. 2025）进一步引入标签驱动的图嵌入，以及由视图特定分类性能监督的样本级质量判别器。DSPNF（Jiang et al. 2026b）联合施加标签空间约束和基于随机游走的高阶结构约束，并采用由预测性能与不确定性驱动的质量监督，实现自适应融合。最近的 SCECD-Net（Jiang et al. 2025）增强标签语义与视图表示的一致性，同时建模样本级视图贡献，以减少预测期间低质量视图的干扰。

另一条研究路线显式重构或生成缺失视图信息，而非仅仅屏蔽不可用观测。例如，Zheng 等提出 LOGIC（Zheng et al. 2025），通过信息论生成模型统一完整与不完整多视图聚类。它依据全面性、共识性和可压缩性原则解释缺失视图恢复，并从共同潜在表示生成缺失视图。跨视图关系迁移方法提供了不同的恢复路线：将源视图中可用的邻域关系迁移到缺失目标视图（Wang et al. 2023）。然而，基于潜在生成的方法不显式保证保持目标视图的局部几何结构，而当异质源视图提供的邻域证据不一致时，直接关系迁移可能引入不可靠邻居。

总体上，现有 IMvPMLC 方法主要通过掩蔽、结构正则化或质量感知融合来缓解缺失视图的影响，而恢复驱动的方法通过潜在生成或直接关系迁移重构缺失信息。不过，前者不显式修复目标视图缺失所破坏的局部拓扑，后者则可能在跨视图异质性下引入不可靠关系。因此，ReCHSM 聚焦可靠性感知的拓扑重构，并将修复后的表示作为后续高阶语义传播的基础，同时以基于标签语义一致性的加权作为辅助融合机制。

3 所提出的方法

本节首先形式化 IMvPMLC 任务，然后介绍 ReCHSM 的整体框架，最后详细说明各模块。

3.1 问题表述

令 $\mathcal{X} = \{X^{(v)} \in \mathbb{R}^{n\times d_v}\}_{v=1}^{m}$ 表示包含 n 个样本和 m 个视图的原始多视图数据集，其中 $X^{(v)}$ 和 d_v 分别是第 v 个视图的特征矩阵与维度。给定对应 ℓ 个类别的标签矩阵 $Y \in \{0,1\}^{n\times\ell}$，若样本 i 属于类别 j，则令 $Y_{i,j}=1$，否则为 0。为建模视图与标签缺失，我们引入指示矩阵 $W \in \{0,1\}^{n\times m}$ 和 $G \in \{0,1\}^{n\times\ell}$。这里，$W_{i,v}=1$ 表示样本 i 的第 v 个视图可用，而 $G_{i,j}=1$ 表示其第 j 个标签已被观测。在这一设置下，我们的目标是开发一个分类模型，准确预测每个样本的完整标签集合。主要符号汇总于表 1。为简化记号，公式使用 n 个样本；实现时，成对关系矩阵在每个小批次内部构建，大小为 $b\times b$，其中 b 是小批次大小。

表 1 主要符号（保留原表）。

Notation	Description	Notation	Description
n, m, ℓ	Numbers of samples, views, and categories.	k	Number of nearest neighbors.
$X^{(v)}, d_v$	Original data matrix of the v-th view ($\mathbb{R}^{n\times d_v}$) and its feature dimension d_v.	$\hat{X}^{(v)}$	Completed data matrix of the v-th view ($\mathbb{R}^{n\times d_v}$).
Y	Ground-truth label matrix ($\{0,1\}^{n\times\ell}$).	W, G	Missing-view and missing-label indicator matrices, respectively ($W \in \{0,1\}^{n\times m}$, $G \in \{0,1\}^{n\times\ell}$).
$\mathcal{I}_v$	Index set of samples whose v-th view is observed.	$D^{(v)}$	Euclidean distance matrix of the v-th view ($\mathbb{R}^{n\times n}$).
$\mathcal{V}_{\text{obs}}^{(i)}$	Set of observable source views for sample i.	$\mathcal{P}_{i,u}$	Candidate neighbor set of sample i retrieved from source view u.
$\widetilde{\mathcal{P}}_{i,u}^{(v)}$	Transferred candidate neighbor set after removing neighbors missing in the target view.	$\mathcal{N}_{i,v}$	Final reliable neighbor set of sample i in target view v.
$R_{i,j}^{(v)}$	Neighborhood reliability score of candidate neighbor j for reconstructing sample i in target view v.	$Z^{(v)}, d_e$	Embedding feature matrix of the completed v-th view ($\mathbb{R}^{n\times d_e}$) and the unified embedding dimension d_e.
Z^f	Fused feature representation of all views ($\mathbb{R}^{n\times d_e}$).	$T^{(v)}$	Transition probability matrix of the v-th view ($\mathbb{R}^{n\times n}$).
$\Psi^{(v)}$	High-order semantic structure matrix of the v-th view ($\mathbb{R}^{n\times n}$).	L	Label similarity matrix in the label space ($\mathbb{R}^{n\times n}$).
$S^{(v)}$	Feature similarity matrix induced by the v-th view ($[0,1]^{n\times n}$).	B	Predicted view-quality distribution ($[0,1]^{n\times m}$).
E	Trustworthy view-quality distribution ($[0,1]^{n\times m}$).	P	Final multi-label prediction matrix ($[0,1]^{n\times\ell}$).
$\mathbb{I}(\cdot), \|\cdot\|_2$	Indicator function and ℓ_2 norm.	$\odot$	Hadamard product.

表 1 中文释义。

符号	含义
$n,\ m,\ \ell$	样本数、视图数和类别数。

符号	含义
k	最近邻数量。
$X^{(v)},\ d_v$	第 v 个视图的原始数据矩阵（$\mathbb{R}^{n\times d_v}$）及其特征维度。
$\widehat{X}^{(v)}$	第 v 个视图补全后的数据矩阵（$\mathbb{R}^{n\times d_v}$）。
Y	真实标签矩阵（$\{0,\ 1\}^{n\times \ell}$）。
$W,\ G$	分别为缺失视图与缺失标签指示矩阵，$W \in \{0,\ 1\}^{n\times m}$，$G \in \{0,\ 1\}^{n\times \ell}$。
$\mathcal{I}_v$	第 v 个视图已被观测的样本索引集合。
$D^{(v)}$	第 v 个视图的欧氏距离矩阵（$\mathbb{R}^{n\times n}$）。
$\mathcal{V}_{\text{obs}}^{(i)}$	样本 i 的可观测源视图集合。
$\mathcal{P}_{i,u}$	从源视图 u 检索得到的样本 i 的候选邻居集合。
$\widetilde{\mathcal{P}}_{i,u}^{(v)}$	剔除目标视图缺失的邻居之后得到的迁移候选邻居集合。
$\mathcal{N}_{i,v}$	目标视图 v 中样本 i 的最终可靠邻居集合。
$R_{i,j}^{(v)}$	在目标视图 v 中重构样本 i 时，候选邻居 j 的邻域可靠性分数。
$Z^{(v)},\ d_e$	补全后的第 v 个视图的嵌入特征矩阵（$\mathbb{R}^{n\times d_e}$）与统一嵌入维度。
Z^f	所有视图融合后的特征表示（$\mathbb{R}^{n\times d_e}$）。
$T^{(v)}$	第 v 个视图的转移概率矩阵（$\mathbb{R}^{n\times n}$）。
$\Psi^{(v)}$	第 v 个视图的高阶语义结构矩阵（$\mathbb{R}^{n\times n}$）。
L	标签空间中的标签相似度矩阵（$\mathbb{R}^{n\times n}$）。
$S^{(v)}$	第 v 个视图诱导的特征相似度矩阵（$[0,\ 1]^{n\times n}$）。
B	预测的视图质量分布（$[0,\ 1]^{n\times m}$）。
E	可信视图质量分布（$[0,\ 1]^{n\times m}$）。
P	最终多标签预测矩阵（$[0,\ 1]^{n\times \ell}$）。
$\mathbb{I}(\cdot),\ \|\cdot\|_2$	指示函数与 ℓ_2 范数。
$\odot$	Hadamard 乘积。

3.2 整体框架

图 1 展示了 ReCHSM 的整体框架。给定不完整多视图数据，可靠跨视图补全模块首先重构缺失视图，生成补全特征 $\{\widehat{X}^{(v)}\}_{v=1}^{m}$。每个视图特定编码器 $\mathrm{En}^{(v)}$ 再将其补全特征矩阵映射到统一潜在空间，得到嵌入 $\{Z^{(v)}\}_{v=1}^{m}$。基于这些嵌入，ReCHSM 通过两条并行分支进行处理。高阶语义结构挖掘分支把修复后的局部关系扩展为多跳语义依赖，并通过 $\mathcal{L}_{\mathrm{struct}}$ 引导表示学习。与此同时，基于标签语义一致性的视图质量评估分支，在 $\mathcal{L}_{\mathrm{qual}}$ 的监督下估计样本特定的视图权重 B。最后，样本特定权重 B 将各视图特定嵌入自适应融合为 Z^{f}，分类器再将 Z^{f} 映射为多标签预测矩阵 P。因此，视图补全提供可靠输入，高阶结构挖掘改善所学表示，而视图质量评估控制它们在最终融合中的贡献。

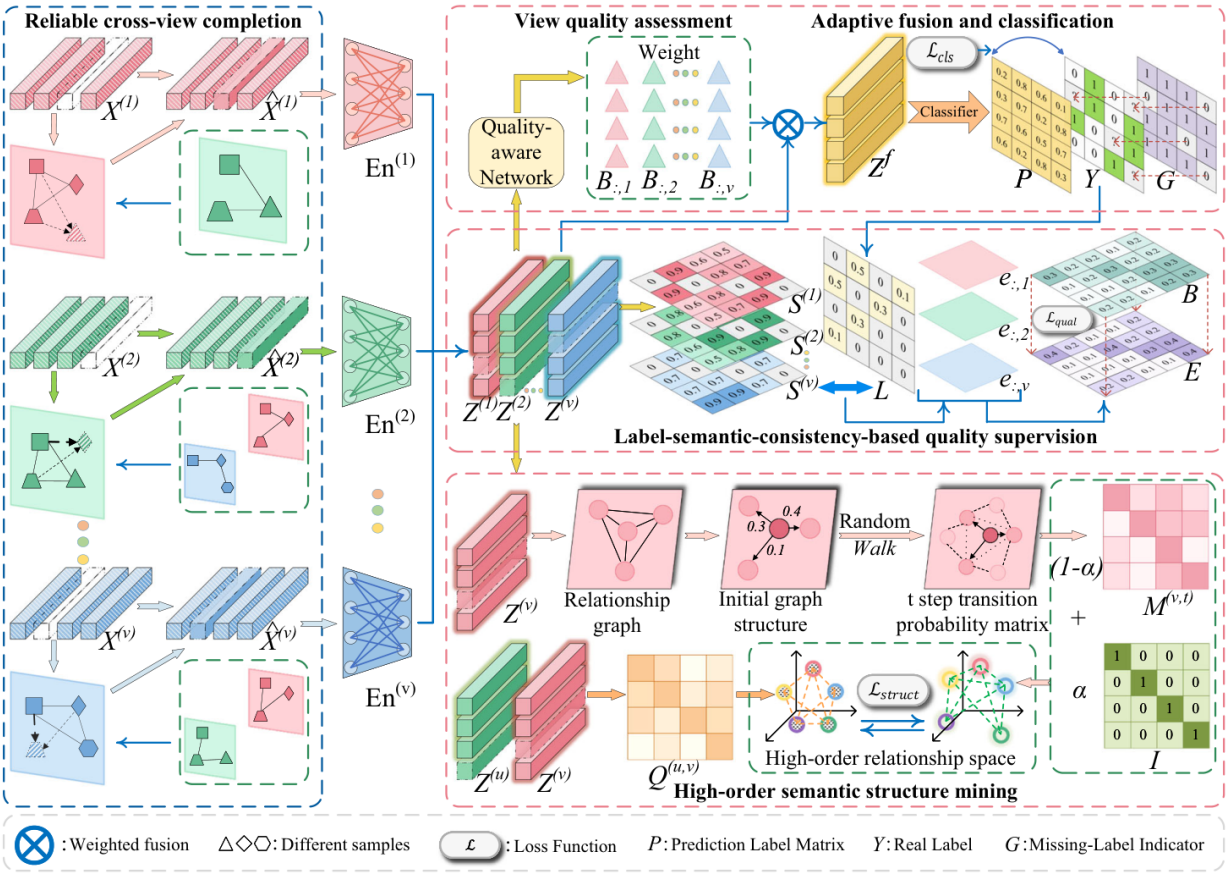


图 1 ReCHSM 整体框架。 首先重构不完整视图并映射为视图特定嵌入；随后并行进行高阶语义结构挖掘与基于标签语义一致性的视图质量评估，分别改善表示学习并估计样本级视图权重；最后使用所学权重完成自适应多视图融合与多标签分类。不同颜色和形状分别表示不同视图和不同样本。

图中文字译释：Reliable cross-view completion＝可靠跨视图补全；View quality assessment＝视图质量评估；Adaptive fusion and classification＝自适应融合与分类；Quality-aware Network＝质量感知网络；Weight＝权重；Classifier＝分类器；Label-semantic-consistency-based quality supervision＝基于标签语义一致性的质量监督；Relationship graph＝关系图；Initial graph structure＝初始图结构；Random Walk＝随机游走；t step transition probability matrix＝t 步转移概率矩阵；High-order relationship space＝高阶关系空间；High-order semantic structure

mining＝高阶语义结构挖掘；Weighted fusion＝加权融合；Different samples＝不同样本；Loss Function＝损失函数；Prediction Label Matrix＝预测标签矩阵；Real Label＝真实标签；Missing-Label Indicator＝缺失标签指示量。

3.3 通过可靠跨视图邻域关系迁移进行视图补全

不完整多视图数据的内在挑战在于，视图缺失既降低样本表示的完整性，又破坏下游表示学习所需的局部邻域拓扑。直接丢弃不完整样本会浪费其可观测视图中保留的信息，还可能引入样本选择偏差；零填充则会产生人为特征模式，扭曲样本间距离。因此，在表示学习之前适当重构缺失视图，对于保持特征信息和局部几何结构都很重要。CRTC（Wang et al. 2023）引入的跨视图关系迁移策略，通过将可观测源视图中保留的邻域关系迁移到缺失目标视图，提供了一种拓扑感知的解决方案。然而，由于跨视图异质性，不同源视图可能提供不一致的邻域证据，直接迁移它们的最近邻可能引入不可靠候选。因此，我们将这一策略适配到 IMvPMLC 场景：在重构前筛选迁移候选，并通过非线性细化抑制残余重构噪声。整体流程见图 2，具体形式如下。

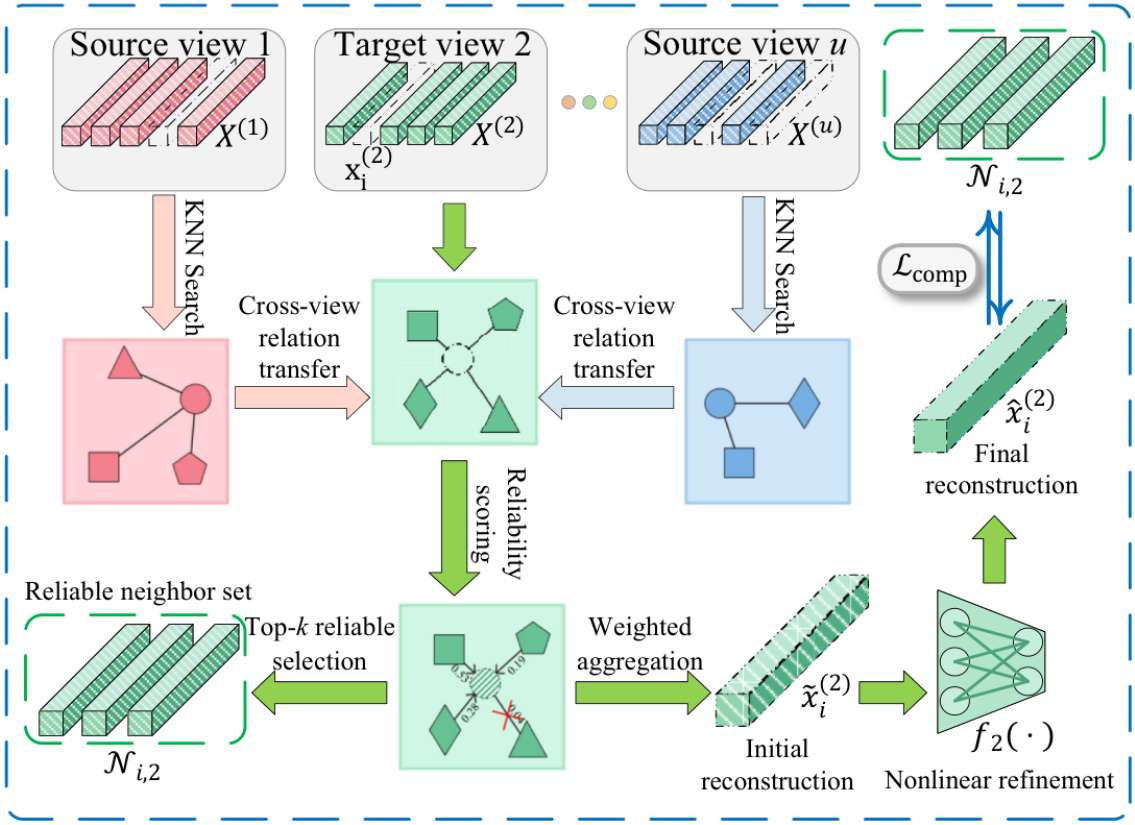


图 2 视图 2 中缺失样本 i 的可靠跨视图补全过程。 将可观测源视图中识别出的邻域关系迁移到目标视图，通过可靠性评分及 top-k 选择剔除不可靠候选。随后聚合保留的邻居得到初始重构，再使用非线性网络进一步细化。补全模块使用 $\mathcal{L}_{\text{comp}}$ 预训练。

图中文字译释：Source view 1 / u＝源视图 1 / u；Target view 2＝目标视图 2；KNN Search＝K 近邻搜索；Cross-view relation transfer＝跨视图关系迁移；Reliability scoring＝可靠性评分；Top-k reliable selection＝选择 top-k 个可靠邻居；Reliable neighbor set＝可靠邻居集合；Weighted aggregation＝加权聚合；Initial reconstruction＝初始重构；Nonlinear refinement＝非线性细化；Final reconstruction＝最终重构。

首先，我们使用欧氏距离衡量样本相似性，以识别邻居。对每个视图，我们在已观测样本集合 $\mathcal{I}_v = \{i \mid W_{i,v} = 1\}$ 上计算欧氏距离矩阵 $D^{(v)} \in \mathbb{R}^{n\times n}$。该矩阵的元素定义为：

$$D_{i,j}^{(v)} = \begin{cases} \|x_i^{(v)} - x_j^{(v)}\|_2, & \text{if } i,\, j \in \mathcal{I}_v, \\ +\infty, & \text{otherwise.} \end{cases} \tag{1}$$

式（1）中的两个条件依次为：若 $i,\ j \in \mathcal{I}_v$；否则。

接下来，我们把源视图的邻域关系迁移到目标视图，以指导补全过程。对于在目标视图 v 中缺失的样本 i，根据各自的距离矩阵 $D^{(u)}$，从每个可观测源视图 $u \in \mathcal{V}_{\text{obs}}^{(i)} = \{u \mid W_{i,u} = 1\}$ 中检索其 top-k 最近邻，构成候选邻居集合 $\mathcal{P}_{i,u} = \{j_1,\ \ldots,\ j_k\}$。$\mathcal{P}_{i,u}$ 中的某些候选也可能在目标视图 v 中缺失，不能直接用于重构。因此，我们将这些候选移除，得到迁移候选邻居集合 $\widetilde{\mathcal{P}}_{i,u}^{(v)}$，其中 $\left|\widetilde{\mathcal{P}}_{i,u}^{(v)}\right| \le k$。为衡量候选 j 的可靠性，定义其在可观测源视图中的出现频次 $c_{i,j}^{(v)}$ 和累积距离 $\Delta_{i,j}^{(v)}$ 如下：

$$\begin{aligned} c_{i,j}^{(v)} &= \sum_{u\in\mathcal{V}_{\text{obs}}^{(i)}} \mathbb{I}\left(j \in \widetilde{\mathcal{P}}_{i,u}^{(v)}\right), \\ \Delta_{i,j}^{(v)} &= \sum_{u\in\mathcal{V}_{\text{obs}}^{(i)}} \mathbb{I}\left(j \in \widetilde{\mathcal{P}}_{i,u}^{(v)}\right) D_{i,j}^{(u)}. \end{aligned} \tag{2}$$

其中，$\mathbb{I}(\cdot)$ 表示指示函数。

为考虑跨视图异质性，我们联合使用跨视图出现一致性和几何接近程度来评估候选可靠性。候选 j 的平均源视图距离为 $\Delta_{i,j}^{(v)}/c_{i,j}^{(v)}$。因此，我们将可靠性定义为出现频次除以这一平均距离：

$$R_{i,j}^{(v)} = \frac{c_{i,j}^{(v)}}{\Delta_{i,j}^{(v)}/c_{i,j}^{(v)}} = \frac{\left(c_{i,j}^{(v)}\right)^2}{\Delta_{i,j}^{(v)}}. \tag{3}$$

根据邻域可靠性分数，从所有迁移候选邻居集合 $\widetilde{\mathcal{P}}_{i,u}^{(v)}$ 的并集中选出 top-k 候选，构成目标邻居集合 $\mathcal{N}_{i,v}$：

$$\mathcal{N}_{i,v} = \text{TopK}_{j\in\bigcup_{u\in\mathcal{V}_{\text{obs}}^{(i)}} \widetilde{\mathcal{P}}_{i,u}^{(v)}} \left(R_{i,j}^{(v)}\right). \tag{4}$$

若有效候选不足 k 个，则保留所有可用候选。若不存在有效候选，则不引入人为邻居，而将零初始化特征传给后续非线性细化网络。随后，利用基于可靠性的权重聚合这些邻居，获得缺失特征 $x_i^{(v)}$ 的初始重构：

$$\begin{aligned}\omega_{i,j} &= \frac{\exp\left(R_{i,j}^{(v)}\right)}{\sum_{k\in\mathcal{N}_{i,v}}\exp\left(R_{i,k}^{(v)}\right)},\\ \tilde{x}_i^{(v)} &= \sum_{j\in\mathcal{N}_{i,v}}\omega_{i,j}x_j^{(v)}.\end{aligned} \tag{5}$$

其中，$\omega_{i,j}$ 表示邻居 j 的贡献权重。

线性加权重构可能无法充分捕捉高维特征空间中的非线性语义。因此，我们采用基于轻量级多层感知机的细化网络 $f_v(\cdot)$，对初步补全的特征进一步细化。最终补全特征 $\widehat{x}_i^{(v)}$ 定义为：

$$\hat{x}_i^{(v)} = \begin{cases} x_i^{(v)}, & \text{if } W_{i,v}=1,\\ f_v(\tilde{x}_i^{(v)}), & \text{if } W_{i,v}=0. \end{cases} \tag{6}$$

式（6）的两种情况分别对应 $W_{i,v}=1$ 与 $W_{i,v}=0$。

为鼓励补全特征保持接近其可靠邻居所构成的局部子空间，我们定义基于均方误差的补全损失。具体而言，该损失衡量每个补全特征与其选定可靠邻居之间的差异：

$$\mathcal{L}_{\text{comp}} = \frac{1}{N_{\text{miss}}}\sum_{v=1}^{m}\sum_{i:W_{i,v}=0}\frac{1}{\max\{1,|\mathcal{N}_{i,v}|\}}\sum_{j\in\mathcal{N}_{i,v}}\left\|\hat{x}_i^{(v)}-x_j^{(v)}\right\|_2^2 \tag{7}$$

其中，$N_{\text{miss}}=\sum_{v=1}^{m}|\{i\mid W_{i,v}=0\}|$ 是所有视图中缺失样本的总数。当 $\mathcal{N}_{i,v}=\varnothing$ 时，相应的内层损失项定义为零。

跨视图补全后，我们为每个视图 v 得到一个补全特征矩阵 $\widehat{X}^{(v)}\in\mathbb{R}^{n\times d_v}$。为将异质视图特征转换到共享潜在表示空间，进一步使用视图特定编码器 $\mathrm{En}^{(v)}(\cdot)$ 生成嵌入特征矩阵：

$$Z^{(v)} = \mathrm{En}^{(v)}\left(\hat{X}^{(v)}\right) \tag{8}$$

其中，$Z^{(v)}\in\mathbb{R}^{n\times d_e}$，$d_e$ 表示统一嵌入维度。实现时，每个 $\mathrm{En}^{(v)}(\cdot)$ 都是视图特定的多层感知机，由带有批归一化和 ReLU 激活的堆叠全连接块构成；在中间层应用 Dropout。

3.4 基于随机游走的高阶语义结构挖掘

第 3.3 节中的补全模块重构缺失视图，并修复局部邻域拓扑。然而，恢复出的这些关系主要描述直接连接样本之间的一阶接近性。此类成对关系可能不足以刻画复杂潜在结构，因为并非直接邻居的样本，仍可能通过共享邻域或多跳连接路径在语义上相关。因此，利用高阶邻域信息对于揭示更深层的样本间依

赖，以及引导更具判别力的表示学习十分重要。基于这一认识，我们引入基于随机游走的高阶语义结构挖掘模块。该模块以补全后的视图特定嵌入为输入，通过多步转移传播修复后的局部关系，把一阶邻域转换为更广泛的高阶语义依赖。随后，将得到的高阶结构用作表示学习的结构监督，具体如下。

基于第 v 个视图的嵌入特征 $Z^{(v)}$，首先利用高斯核构建转移概率矩阵 $T^{(v)}$：

$$T_{i,j}^{(v)} = \frac{\exp\left(-\frac{\|\tilde{z}_i^{(v)} - \tilde{z}_j^{(v)}\|_2^2}{2\sigma^2}\right)}{\sum_{k=1}^{n} \exp\left(-\frac{\|\tilde{z}_i^{(v)} - \tilde{z}_k^{(v)}\|_2^2}{2\sigma^2}\right)} \tag{9}$$

其中，$\tilde{z}_i^{(v)} = z_i^{(v)} / \| z_i^{(v)} \|_2$，而 $z_i^{(v)}$ 为 $Z^{(v)}$ 中样本 i 的嵌入。核带宽 σ 设为 0.1。$T^{(v)} \in \mathbb{R}^{n\times n}$ 的第 i 行表示从样本 i 到所有样本的一步转移概率分布。

随后，为进一步捕捉多跳邻域关系，我们执行 t 步随机游走传播：

$$\begin{cases} M^{(v,1)} = T^{(v)}, \\ M^{(v,t)} = M^{(v,t-1)} T^{(v)} = \left(T^{(v)}\right)^t, \quad t \geq 2. \end{cases} \tag{10}$$

其中，$M_{i,j}^{(v,t)}$ 表示从样本 i 到样本 j 的 t 步转移强度。步数 t 控制传播深度：增大 t 可捕捉更广泛的多跳关系，但过大的取值可能导致过度扩散。为平衡局部与全局信息，我们将 $M^{(v,t)}$ 与单位矩阵 $I \in \mathbb{R}^{n\times n}$ 融合，得到最终高阶语义结构矩阵 $\Psi^{(v)}$：

$$\Psi^{(v)} = \alpha I + (1-\alpha) M^{(v,t)} \tag{11}$$

其中，α 是样本特定身份信息与传播后高阶关系之间的平衡系数。适中的 α 有助于在利用多跳结构信息的同时保留样本区分能力。根据第 4.3 节的敏感性结果，我们设定 $t = 15$、$\alpha = 0.5$。

最后，将挖掘出的高阶关联作为跨视图表示学习的结构监督。对于第 u 和第 v 个视图，跨视图相似度分布 $Q^{(u,v)} \in \mathbb{R}^{n\times n}$ 按下式计算：

$$Q_{i,j}^{(u,v)} = \frac{\exp\left(\langle \tilde{z}_i^{(u)}, \tilde{z}_j^{(v)} \rangle / \tau\right)}{\sum_{k=1}^{n} \exp\left(\langle \tilde{z}_i^{(u)}, \tilde{z}_k^{(v)} \rangle / \tau\right)} \tag{12}$$

其中，$\langle \tilde{z}_i^{(u)}, \tilde{z}_j^{(v)} \rangle$ 表示两个经过 ℓ_2 归一化的嵌入之间的内积，对应于余弦相似度；τ 是温度超参数，设为 0.2。结构约束损失定义为：

$$\mathcal{L}_{\text{struct}} = -\frac{1}{mn^2} \sum_{u,v=1}^{m} \sum_{i,j=1}^{n} \Big[\Psi_{i,j}^{(v)} \log Q_{i,j}^{(u,v)} + \left(1 - \Psi_{i,j}^{(v)}\right) \log\left(1 - Q_{i,j}^{(u,v)}\right) \Big]. \tag{13}$$

3.5 基于标签语义一致性的视图质量评估

尽管前述模块重构了缺失视图，并增强了所学表示的结构语义，但由于跨视图异质性及残余补全误差，不同视图的可靠性仍可能因样本而异。对所有视图一视同仁，或为每个视图分配固定权重，都无法充分捕捉这种样本特定的质量变化，并可能使不够可靠的表示干扰最终融合（Liu et al. 2025）。因此，有必要在样本层面评估视图质量，并自适应地调节各视图的贡献。为使这种评估与下游多标签任务直接相关，我们依据标签语义一致性评估视图可靠性。具体而言，如果一个视图的表示诱导的样本间关系，与已观测标签所刻画的语义结构更加一致，则认为该视图对相应样本更加可靠。基于这一原则，我们构建可信质量分布作为监督信号，并学习样本级自适应视图权重，用于后续融合。

具体而言，我们沿视图维度堆叠嵌入特征 $\{Z^{(v)}\}_{v=1}^{m}$，形成 $C \in \mathbb{R}^{n\times m\times d_e}$，其中 $C_i = \left[z_i^{(1)}, z_i^{(2)}, \ldots, z_i^{(m)}\right]^{\top} \in \mathbb{R}^{m\times d_e}$ 包含样本 i 的所有视图特定嵌入。质量感知网络 g_ϕ 采用由线性层、ReLU 激活和 Dropout 组成的三层感知机实现，将 C 映射为预测视图质量分布 $B \in [0,\ 1]^{n\times m}$：

$$B = \mathrm{softmax}\left(g_\phi(C)\right) \tag{14}$$

其中，softmax 操作沿视图维度施加。

随后，为指导质量感知网络 g_ϕ 的训练，我们进一步通过衡量标签诱导语义结构与视图诱导相似度之间的一致性，构建监督信号。为此，首先定义标签相似度矩阵如下：

$$L = \frac{(Y \odot G)(Y \odot G)^{\top}}{GG^{\top}} \tag{15}$$

其中，$\odot$ 表示 Hadamard 乘积，除法按元素进行。矩阵 $GG^{\top}$ 记录每对样本共同观测到的标签数量，并用于归一化 L；L 表示已观测标签空间中的成对语义相似度。

接着，我们使用余弦相似度刻画嵌入特征之间的关系：

$$S_{i,j}^{(v)} = \frac{1 + \cos(z_i^{(v)}, z_j^{(v)})}{2} \tag{16}$$

其中，$z_i^{(v)}$ 为第 v 个视图中样本 i 的嵌入，$S^{(v)} \in [0,\ 1]^{n\times n}$ 为对应的特征相似度矩阵。这里，$\cos\left(x,\ y\right) = x^{\top}y/\left(\ \|\ x\ \|_{\ 2}\ \|\ y\ \|_{\ 2}\right)$。变换 $(1 + \cos(\cdot,\ \cdot))/2$ 将余弦相似度从 $[\ -1,\ 1]$ 映射到 $[0,\ 1]$，使其与 L 相容。

为量化各视图对已观测标签所揭示语义结构的保持程度，我们衡量由标签得到的相似度与由特征得到的相似度之间的差异。对于视图 v 中样本 i，语义一致性分数定义为：

$$e_{i,v} = \frac{1}{n-1}\sum_{j=1,j\neq i}^{n}\left(L_{i,j} - S_{i,j}^{(v)}\right)^2 \tag{17}$$

$e_{i,v}$ 越小，表示视图 v 诱导的相似度结构与样本 i 的已观测标签语义越一致。因此，该视图对这个样本被认为更可靠。然后，在各视图之间对一致性分数归一化，构建可信视图质量分布 $E \in [0,\ 1]^{n\times m}$：

$$E_{i,v} = \frac{\exp(-e_{i,v})}{\sum_{k=1}^{m} \exp(-e_{i,k})} \tag{18}$$

这样，归一化过程为语义一致性更高的视图赋予更大的 E 值，使 E 能作为监督质量预测的可信目标分布。

最后，通过以下质量评估损失，将预测质量分布 $B \in [0,\ 1]^{n\times m}$ 与可靠分布 $E \in [0,\ 1]^{n\times m}$ 对齐：

$$\mathcal{L}_{\text{qual}} = \frac{1}{n} \sum_{i=1}^{n} \sum_{v=1}^{m} E_{i,v} \log \frac{E_{i,v}}{B_{i,v}} \tag{19}$$

此外，我们在该模块中采用梯度隔离机制。具体而言，阻断由下游融合与分类传播的梯度对质量感知网络的更新，仅通过 $\mathcal{L}_{\text{qual}}$ 优化该网络。这样的设计使该网络能够在标签语义一致性监督下专注于样本级视图可靠性，而不受分类目标干扰。

3.6 质量感知的自适应融合与分类

在高阶结构分支改善视图特定表示、质量评估分支估计其样本级可靠性之后，预测质量分布 B 对嵌入 $\{Z^{(v)}\}_{v=1}^{m}$ 进行自适应聚合。估计质量较高的视图对融合表示贡献更大，而不够可靠的视图贡献更小：

$$Z^{f} = \sum_{v=1}^{m} B_{:,v} \odot Z^{(v)} \tag{20}$$

其中，$B_{:,v}$ 表示所学习的第 v 个视图的样本级质量权重向量，$\odot$ 表示沿特征维度广播的逐元素乘法。

随后，分类器 $h(\cdot)$ 将统一特征表示 Z^{f} 映射为最终多标签预测矩阵 $P \in [0,\ 1]^{n\times \ell}$。实现时，$h(\cdot)$ 由一个 LeakyReLU 激活、两层 MLP 和末端 Sigmoid 激活函数构成。为衡量预测与真实标签之间的差异，我们采用二元交叉熵损失：

$$\begin{aligned}\mathcal{L}_{\text{cls}} = -\frac{1}{n\ell} \sum_{i=1}^{n} \sum_{j=1}^{\ell} G_{i,j} \Big[& Y_{i,j} \log(P_{i,j}) \\ & + (1 - Y_{i,j}) \log(1 - P_{i,j}) \Big]\end{aligned} \tag{21}$$

3.7 总损失与模型训练

我们采用两阶段策略优化 ReCHSM。在预训练期间，通过最小化式（7）的 $\mathcal{L}_{\text{comp}}$，对补全网络 $\{f_v\}_{v=1}^{m}$ 优化 $T_{\text{pre}} = 50$ 个训练轮次。然后冻结这些网络的参数，在主训练阶段提供稳定的补全特征。所有补全网络仅在训练子集上预训练。

在主训练阶段，总损失 $\mathcal{L}_{\text{total}}$ 被写为式（21）的分类损失 $\mathcal{L}_{\text{cls}}$、式（13）的高阶语义结构损失 $\mathcal{L}_{\text{struct}}$ 和式（19）的视图质量评估损失 $\mathcal{L}_{\text{qual}}$ 的加权组合：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{cls}} + \beta\mathcal{L}_{\text{struct}} + \gamma\mathcal{L}_{\text{qual}}, \tag{22}$$

其中，β 和 γ 为惩罚系数。在前 $T_{\text{warm}} = 20$ 个训练轮次中，将 $\Psi^{(v)}$ 设为单位矩阵，因此 $\mathcal{L}_{\text{struct}}$ 主要鼓励同一样本在不同视图中的嵌入保持接近。这一预热过程在引入高阶结构之前稳定表示空间。随后，将 $\Psi^{(v)}$ 替换为基于随机游走的高阶语义结构矩阵。算法 1 概括了 ReCHSM 的完整训练过程。

算法 1 ReCHSM 的训练过程。

输入： 多视图数据 $\{X^{(v)}\}_{v=1}^{m}$、缺失标签指示矩阵 G、缺失视图指示矩阵 W 和真实标签矩阵 Y。

初始化： 随机初始化细化网络 $\{f_v\}_{v=1}^{m}$、视图特定编码器 $\{\text{En}^{(v)}\}_{v=1}^{m}$、质量感知网络 g_ϕ 与分类器 h；设置超参数 $\alpha, \beta, \gamma, k, t, \sigma, \tau$、预训练轮数 T_{pre}、预热轮数 T_{warm} 和主训练轮数 T_{main}。

阶段 1：补全模块预训练。对 $r = 1, \ldots, T_{\text{pre}}$ 重复：

1. 对目标视图 v 中每个缺失样本，依据式（2）至式（4）识别可靠迁移邻居 $\mathcal{N}_{i,v}$。
2. 用式（5）的加权聚合重构初始缺失特征 $\widetilde{x}_i^{(v)}$，并按照式（6）用 $f_v(\cdot)$ 对其细化。
3. 通过最小化式（7）的 $\mathcal{L}_{\text{comp}}$，更新 $\{f_v\}_{v=1}^{m}$ 的可学习参数。

循环结束。冻结补全模块的可学习参数。

阶段 2：冻结补全模块后的主训练。对 $r = 1, \ldots, T_{\text{main}}$ 重复：

1. 使用冻结的补全模块恢复缺失视图，得到 $\widehat{X}^{(v)}$，并依据式（8）生成视图特定嵌入 $\{Z^{(v)}\}_{v=1}^{m}$。
2. 若 $r \le T_{\text{warm}}$，则对所有视图令 $\Psi^{(v)} = I$；否则使用式（9）至式（11）通过随机游走构建 $\Psi^{(v)}$。
3. 使用式（14）预测样本级视图质量分布 B，并使用式（15）至式（18）推导可信分布 E。
4. 使用式（20）将多视图嵌入融合为 Z^f，得到预测 P，并计算 $\mathcal{L}_{\text{qual}}$、$\mathcal{L}_{\text{struct}}$ 和 $\mathcal{L}_{\text{cls}}$。
5. 通过最小化 $\mathcal{L}_{\text{total}}$ 更新 $\{\text{En}^{(v)}\}_{v=1}^{m}$、$g_\phi$ 和 h。

循环结束。**输出：** 训练完成的 ReCHSM 模型。

算法 1 原文对照。

Algorithm 1 Training procedure of ReCHSM.

Input: Multi-view data $\{X^{(v)}\}_{v=1}^{m}$, missing-label indicator matrix G, missing-view indicator matrix W, and ground-truth label matrix Y.

Initialization: Randomly initialize refinement networks $\{f_v\}_{v=1}^{m}$, view-specific encoders $\{\mathrm{En}^{(v)}\}_{v=1}^{m}$, quality-aware network g_ϕ, and classifier h; set hyperparameters α, β, γ, k, t, σ, τ, pre-training epochs T_{pre}, warm-up epochs T_{warm}, and main training epochs T_{main}.
Stage 1: Pre-training of completion module
for $r = 1$ **to** T_{pre} **do**
1. For each missing sample in target view v, identify reliable transferred neighbors $\mathcal{N}_{i,v}$ according to (2)–(4).
2. Reconstruct the initial missing features $\tilde{x}_i^{(v)}$ by weighted aggregation using (5), and refine them by $f_v(\cdot)$ according to (6).
3. Update the learnable parameters of $\{f_v\}_{v=1}^{m}$ by minimizing $\mathcal{L}_{\mathrm{comp}}$ in (7).
end for
Freeze the learnable parameters of the completion module.
Stage 2: Main training with frozen completion module
for $r = 1$ **to** T_{main} **do**
1. Recover missing views using the frozen completion module to obtain $\hat{X}^{(v)}$, and generate view-specific embeddings $\{Z^{(v)}\}_{v=1}^{m}$ according to (8).
2. **if** $r \le T_{\mathrm{warm}}$ **then** set $\Psi^{(v)} = I$ for all views; **else** construct $\Psi^{(v)}$ via random walk using (9)–(11).
3. Predict the sample-level view quality distribution B using (14), and derive the trustworthy distribution E using (15)–(18).
4. Fuse the multi-view embeddings into Z^f using (20), obtain predictions P, and compute $\mathcal{L}_{\mathrm{qual}}$, $\mathcal{L}_{\mathrm{struct}}$, and $\mathcal{L}_{\mathrm{cls}}$.
5. Update $\{\mathrm{En}^{(v)}\}_{v=1}^{m}$, g_ϕ, and h by minimizing $\mathcal{L}_{\mathrm{total}}$.
end for

Output: Trained ReCHSM model.

4 实验

4.1 实验设置

4.1.1 数据集

遵循该领域先前研究广泛采用的实验设置（Jiang et al. 2026b；Li and Chen 2022；Liu et al. 2023c；Long et al. 2024），我们在五个广泛用于 MvMLC 的基准数据集上评估 ReCHSM，即 Corel5k、ESPGame、Pascal07、Mirflickr 和 IAPRTC12。这些数据集涵盖自然场景、物体语义和社交媒体图像等不同语义场景。每个数据集都提供 HSV、GIST、Hue、LAB、RGB 和 SIFT 六种异质视图特征，从颜色、纹理和空间布局等不同角度描述样本。表 2 报告了这些数据集的简要统计信息。更详细的情况如下。

1. **Corel5k（Duygulu et al. 2002）：** 包含 4,999 幅图像，覆盖 260 个类别。每幅图像通常具有 1 至 5 个标签，表明标签具有显著稀疏性。
2. **Pascal07（Everingham et al. 2010）：** 包含 9,963 幅图像和 20 个物体类别，通常用于物体检测与识别。
3. **ESPGame（von Ahn and Dabbish 2004）：** 采集自在线协作游戏，包含 20,770 幅图像和 268 个标签。每幅图像有 1 至 15 个描述性标签。

4. **IAPRTC12（Escalante et al. 2010）：** 这个大规模数据集包含 19,627 幅高质量自然场景图像，覆盖 291 个类别。标签从图像说明或描述中提取。每个样本最多可有 23 个标签，显示出较高语义复杂性。
5. **Mirflickr（Huiskes and Lew 2008）：** 包含来自 Flickr 的 25,000 幅图像，内容包括人物、动物和风景。我们采用 38 个核心语义标签，这些标签代表社交摄影的典型分布。

表 2 基准数据集统计。 Avg. Labels 表示每个样本的平均语义标签数量。列标题依次为：数据集、样本数、视图数、标签数、平均标签数。

Dataset	Samples	Views	Labels	Avg. Labels
Corel5k	4,999	6	260	3.40
Pascal07	9,963	6	20	1.47
ESPGame	20,770	6	268	4.69
IAPRTC12	19,627	6	291	5.72
Mirflickr	25,000	6	38	4.72

4.1.2 双重不完整性的构建

为验证 ReCHSM，我们遵循先前研究的方案（Jiang et al. 2026b；Li and Chen 2022；Liu et al. 2023c；Long et al. 2024），构建视图和标签都不完整的数据集。具体而言，随机移除各视图中 50% 的观测，同时确保每个样本至少保留一个已观测视图。通过在所有类别中随机隐藏 50% 的标签来模拟标签不完整。随后将所得数据划分为训练集（70%）、验证集（15%）和测试集（15%）。尽管所有子集的特征矩阵均保持不完整，我们为验证集和测试集保留完整真实标签，以支持严格评估。

4.1.3 对比方法

为确定 ReCHSM 在 IMvPMLC 任务上的能力，我们将其与九个已有模型对比：DSPNF（Jiang et al. 2026b）、NAIM3L（Li and Chen 2022）、DICNet（Liu et al. 2023c）、RANK（Liu et al. 2025）、MSLPP（Long et al. 2024）、iMvWL（Tan et al. 2018）、C2AE（Yeh et al. 2017）、CDMM（Zhao et al. 2021b）和 LVSL（Zhao et al. 2023）。在这些基线中，DSPNF、NAIM3L、DICNet、RANK、MSLPP、iMvWL、LVSL 和 CDMM 是与本文任务密切相关的代表性 MvMLC 或 IMvPMLC 方法。C2AE 是经典的基于深度自编码器的多标签分类模型，主要面向单视图场景，通过联合学习特征表示和标签嵌入来改善预测性能。表 3 汇总了各对比方法的特征。

某些基线并不原生支持 IMvPMLC 任务。对于单视图基线 C2AE，我们分别评估每个视图，并取所有视图中的最好结果用于比较。对于无法直接处理缺失视图的 C2AE、CDMM 和 LVSL，我们用从已观测视图计算得到的平均表示替代不可用视图特征。对于无法直接处理缺失标签的 LVSL 和 CDMM，我们把未观测标签条目填为零。

表 3 对比方法概览。 Multi-view 表示方法是否为多视图学习构建；Missing-view 和 Missing-label 分别表示能否处理视图不完整与标签不完整。其余列标题 Method＝方法，Source＝来源；勾号表示支持，叉号表示不支持。来源年份按原表保留。

Method	Source	Multi-view	Missing-view	Missing-label
C2AE	AAAI'17	✗	✗	✓
CDMM	KBS'20	✓	✗	✗
LVSL	TMM'22	✓	✗	✗
iMvWL	IJCAI'18	✓	✓	✓
NAIM3L	TPAMI'22	✓	✓	✓
DICNet	AAAI'23	✓	✓	✓
MSLPP	Neural Netw'24	✓	✓	✓
RANK	TPAMI'25	✓	✓	✓
DSPNF	ICONIP'25	✓	✓	✓

4.1.4 评估指标

遵循 Jiang et al.（2026b）、Li and Chen（2022）、Liu et al.（2023c）和 Long et al.（2024）的方法，我们依靠四项基本指标评估性能：排序损失（Ranking Loss，RL）、平均精确率（Average Precision，AP）、汉明损失（Hamming Loss，HL）和经适配的曲线下面积（Area Under the Curve，AUC）。为保持“数值越大表示性能越好”的单调评估尺度，我们以 $1-\mathrm{HL}$ 和 $1-\mathrm{RL}$ 替代原始损失值。同样，在完整数据评估中引入单一错误率（One-error，OE）和覆盖度（Coverage，Cov）的互补形式，即 $1-\mathrm{OE}$ 和 $1-\mathrm{Cov}$。这一标准化使比较更加直观，因为所报告分数的任何提高都对应模型能力的提升。

4.1.5 实现细节

ReCHSM 使用 Python 和 PyTorch 实现。主训练阶段采用 SGD，批量大小为 128，动量为 0.9。Pascal07 的学习率设为 0.005，IAPRTC12 设为 0.5，其余数据集设为 0.9；补全模块在所有数据集上均使用固定学习率 0.001。主要性能实验在配备 Intel Core i5-12450H 处理器、16 GB 内存和 NVIDIA GeForce RTX 4050 Laptop GPU 的工作站上进行。第 4.5 节的效率实验在另一台配备 AMD Ryzen 9 7945HX 处理器、32 GB 内存和 NVIDIA GeForce RTX 4060 Laptop GPU 的工作站上进行。效率对比中的所有方法均在同一 RTX 4060 平台上评估。

4.2 实验结果与分析

为全面评估 ReCHSM，我们考虑四种主要设置。首先，在双重不完整设置下，将 ReCHSM 与九个具有竞争力的基线比较；这是本文研究的主要任务，结果见表 4。其次，为进一步厘清每种不完整性对性能的影响，我们评估两种单侧不完整场景：视图完整但标签缺失 50%，以及视图缺失 50% 但标签完整；结果见表 5。第三，我们进一步探索 ReCHSM 在不同缺失率下的内在稳定性，结果见图 3。最后，将评估扩展到两个完整数据集，进一步验证 ReCHSM 的泛化能力，如图 4 所示。根据上述实验结果，可以得出以下主要观察。

- 表 4 表明，ReCHSM 在五个数据集的全部四项主要指标上都取得最优或并列最优结果。尤其是，其在 Pascal07 上的 AP 达到 0.583，在 Corel5k 上达到 0.449，分别比相应次优结果高出

2.8 和 1.9 个百分点。这些结果说明，它在双重不完整条件下能够有效学习具有判别力的多标签表示。

- 如表 5 所示，在两种单侧不完整设置下，ReCHSM 在几乎所有数据集和指标上都取得最优或并列最优结果。这表明 ReCHSM 在双重与单侧不完整条件下都有效。此外，大多数方法在标签缺失时的表现优于视图缺失时，说明视图缺失通过直接减少表示学习可用的特征信息而造成更严重的性能退化。这一发现支持专门进行视图恢复的必要性。
- 如图 3 所示，任一缺失率增加都会降低性能，但整体下降仍较为温和。ReCHSM 对视图缺失比对标签缺失更敏感，与表 5 一致。这进一步确认了保持和恢复视图信息的重要性。
- 如图 4 所示，ReCHSM 在大多数评估指标上仍取得优越或高度有竞争力的表现。这说明所提框架并不局限于不完整数据场景。在完整数据条件下，后续语义建模和自适应融合机制依然有效，使模型在完整数据集上保持较强判别能力。
- 通过对匹配的数据集、指标和基线进行分析比较，ReCHSM 在双重不完整条件下呈现最大的总体优势。在数据集层面，双重不完整和视图缺失设置下的增益在 Pascal07 上最显著，而标签缺失设置下的增益在 Corel5k 上最显著。这一模式表明，ReCHSM 有利于具有互补异质视图及稀疏高维标签空间的数据集。
- 作为额外的鲁棒性检查，我们在四种非随机缺失机制下评估了 ReCHSM，包括视图特定缺失率、块状视图缺失、标签依赖缺失和仅观测一个视图的设置。ReCHSM 在 Corel5k 和 Pascal07 上取得最优或并列最优结果。详细方案、完整定量结果和分析见补充材料第 S2 节及表 S2。

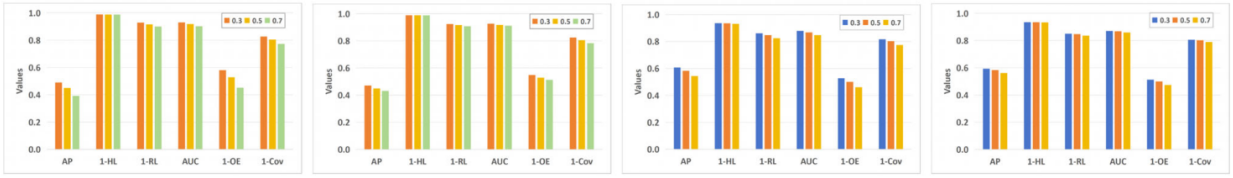
表 4 在视图缺失 50%、标签缺失 50%、训练样本占 70% 的条件下，十种方法在五个数据集上的实验结果。 DATA＝数据集；METRIC＝指标；OURS＝本文方法。所有箭头均表示越高越好。粗体为各项比较中的最优结果，下划线为次优结果。为便于阅读，原始横向大表分成上下两部分，重复左侧的数据集与指标列；所有数值及其下标均保留。

DATA	METRIC	C2AE	iMvWL	NAIM3L	LVSL	CDMM
Corel5k	AP↑	$0.227_{0.008}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.342_{0.004}$	$0.354_{0.004}$
	1-HL↑	$0.980_{0.002}$	$0.978_{0.000}$	$\underline{0.987}_{0.000}$	$\underline{0.987}_{0.000}$	$\underline{0.987}_{0.000}$
	1-RL↑	$0.804_{0.010}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.881_{0.003}$	$0.884_{0.003}$
	AUC↑	$0.806_{0.010}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.884_{0.003}$	$0.888_{0.002}$
Pascal07	AP↑	$0.485_{0.008}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.504_{0.005}$	$0.508_{0.005}$
	1-HL↑	$0.908_{0.002}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.930_{0.000}$	$0.931_{0.001}$
	1-RL↑	$0.745_{0.009}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.806_{0.003}$	$0.812_{0.004}$
	AUC↑	$0.765_{0.010}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.832_{0.002}$	$0.838_{0.003}$
ESPGame	AP↑	$0.202_{0.006}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.285_{0.003}$	$0.289_{0.003}$
	1-HL↑	$0.971_{0.002}$	$\underline{0.972}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$
	1-RL↑	$0.772_{0.006}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.829_{0.001}$	$0.832_{0.001}$
	AUC↑	$0.777_{0.006}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.833_{0.002}$	$0.836_{0.001}$
IAPRTC12	AP↑	$0.224_{0.007}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.304_{0.004}$	$0.305_{0.004}$
	1-HL↑	$0.965_{0.002}$	$0.969_{0.000}$	$\underline{0.980}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$
	1-RL↑	$0.806_{0.005}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.861_{0.002}$	$0.862_{0.002}$
	AUC↑	$0.807_{0.005}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.863_{0.001}$	$0.864_{0.002}$
Mirflickr	AP↑	$0.505_{0.008}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.553_{0.002}$	$0.570_{0.002}$
	1-HL↑	$0.853_{0.004}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.885_{0.001}$	$0.886_{0.001}$
	1-RL↑	$0.821_{0.003}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.856_{0.001}$	$0.856_{0.001}$
	AUC↑	$0.810_{0.004}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.844_{0.001}$	$0.846_{0.001}$

DATA	METRIC	DICNet	MSLPP	RANK	DSPNF	OURS
Corel5k	AP↑	$0.381_{0.004}$	$0.413_{0.008}$	$0.427_{0.006}$	$\underline{0.430}_{0.007}$	$\mathbf{0.449}_{0.008}$
	1-HL↑	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$
	1-RL↑	$0.882_{0.004}$	$0.901_{0.003}$	$\underline{0.9130.002}$	$0.904_{0.006}$	$\mathbf{0.916}_{0.003}$
	AUC↑	$0.884_{0.004}$	$0.903_{0.004}$	$\underline{0.916}_{0.003}$	$0.907_{0.006}$	$\mathbf{0.918}_{0.003}$
Pascal07	AP↑	$0.505_{0.012}$	$0.544_{0.010}$	$\underline{0.555}_{0.010}$	$0.553_{0.007}$	$\mathbf{0.583}_{0.010}$
	1-HL↑	$0.929_{0.001}$	$0.932_{0.001}$	$\underline{0.933}_{0.001}$	$\underline{0.933}_{0.001}$	$\mathbf{0.935}_{0.001}$
	1-RL↑	$0.783_{0.008}$	$0.819_{0.006}$	$\underline{0.830}_{0.008}$	$0.829_{0.004}$	$\mathbf{0.847}_{0.005}$
	AUC↑	$0.809_{0.006}$	$0.841_{0.004}$	$\underline{0.851}_{0.006}$	$0.849_{0.004}$	$\mathbf{0.868}_{0.004}$
ESPGame	AP↑	$0.297_{0.002}$	$0.310_{0.004}$	$0.314_{0.004}$	$\underline{0.321}_{0.005}$	$\mathbf{0.331}_{0.005}$
	1-HL↑	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$
	1-RL↑	$0.832_{0.001}$	$0.843_{0.002}$	$0.848_{0.002}$	$\underline{0.851}_{0.002}$	$\mathbf{0.860}_{0.002}$
	AUC↑	$0.836_{0.001}$	$0.847_{0.002}$	$0.853_{0.002}$	$\underline{0.855}_{0.002}$	$\mathbf{0.863}_{0.002}$
IAPRTC12	AP↑	$0.323_{0.001}$	$0.340_{0.005}$	$0.346_{0.004}$	$\underline{0.355}_{0.005}$	$\mathbf{0.362}_{0.005}$
	1-HL↑	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$
	1-RL↑	$0.873_{0.001}$	$0.882_{0.002}$	$0.888_{0.002}$	$\underline{0.892}_{0.003}$	$\mathbf{0.898}_{0.002}$
	AUC↑	$0.874_{0.000}$	$0.883_{0.002}$	$0.889_{0.002}$	$\underline{0.893}_{0.003}$	$\mathbf{0.899}_{0.001}$
Mirflickr	AP↑	$0.589_{0.005}$	$\underline{0.615}_{0.004}$	$0.602_{0.007}$	$0.611_{0.006}$	$\mathbf{0.626}_{0.003}$
	1-HL↑	$0.888_{0.002}$	$\underline{0.892}_{0.001}$	$0.890_{0.001}$	$\underline{0.892}_{0.001}$	$\mathbf{0.893}_{0.001}$
	1-RL↑	$0.863_{0.004}$	$\underline{0.879}_{0.002}$	$0.875_{0.003}$	$0.876_{0.003}$	$\mathbf{0.883}_{0.002}$
	AUC↑	$0.849_{0.004}$	$\underline{0.865}_{0.002}$	$0.860_{0.003}$	$0.863_{0.003}$	$\mathbf{0.869}_{0.002}$

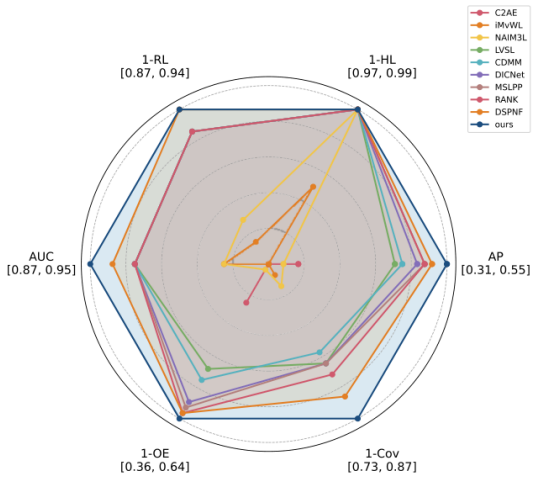
表 5 视图完整但标签缺失 50%，以及视图缺失 50% 但标签完整时的结果。 左侧列组为“视图完整、标签缺失 50%”，右侧列组为“视图缺失 50%、标签完整”。DATA＝数据集；METRIC＝指标；OURS＝本文方法。粗体为最优结果，下划线为次优结果。

DATA	METRIC	Complete views and 50% missing labels				50% missing views and complete labels			
		iMvWL	NAIM3L	MSLPP	OURS	iMvWL	NAIM3L	MSLPP	OURS
Corel5k	AP↑	$0.308_{0.006}$	$0.319_{0.004}$	$\underline{0.443}_{0.009}$	$\mathbf{0.503}_{0.010}$	$0.289_{0.009}$	$0.317_{0.003}$	$\underline{0.443}_{0.011}$	$\mathbf{0.482}_{0.007}$
	1-HL↑	$0.979_{0.000}$	$0.987_{0.000}$	$\underline{0.988}_{0.000}$	$\mathbf{0.989}_{0.000}$	$0.979_{0.000}$	$\underline{0.987}_{0.000}$	$\mathbf{0.988}_{0.000}$	$\mathbf{0.988}_{0.000}$
	1-RL↑	$0.880_{0.003}$	$0.886_{0.003}$	$\underline{0.912}_{0.004}$	$\mathbf{0.933}_{0.004}$	$0.870_{0.003}$	$0.885_{0.003}$	$\underline{0.912}_{0.003}$	$\mathbf{0.926}_{0.004}$
	AUC↑	$0.883_{0.003}$	$0.888_{0.003}$	$\underline{0.914}_{0.004}$	$\mathbf{0.935}_{0.003}$	$0.873_{0.003}$	$0.888_{0.002}$	$\underline{0.914}_{0.003}$	$\mathbf{0.929}_{0.004}$
Pascal07	AP↑	$0.470_{0.006}$	$0.493_{0.003}$	$\underline{0.611}_{0.009}$	$\mathbf{0.627}_{0.009}$	$0.435_{0.009}$	$0.493_{0.002}$	$\underline{0.565}_{0.011}$	$\mathbf{0.601}_{0.009}$
	1-HL↑	$0.888_{0.001}$	$0.929_{0.001}$	$\underline{0.937}_{0.001}$	$\mathbf{0.939}_{0.001}$	$0.882_{0.003}$	$0.929_{0.001}$	$\underline{0.934}_{0.001}$	$\mathbf{0.936}_{0.001}$
	1-RL↑	$0.763_{0.006}$	$0.790_{0.002}$	$\underline{0.864}_{0.005}$	$\mathbf{0.873}_{0.004}$	$0.737_{0.005}$	$0.791_{0.001}$	$\underline{0.835}_{0.007}$	$\mathbf{0.856}_{0.005}$
	AUC↑	$0.792_{0.006}$	$0.818_{0.001}$	$\underline{0.879}_{0.005}$	$\mathbf{0.890}_{0.004}$	$0.768_{0.006}$	$0.818_{0.001}$	$\underline{0.855}_{0.006}$	$\mathbf{0.875}_{0.005}$
ESPGame	AP↑	$0.258_{0.003}$	$0.249_{0.002}$	$\mathbf{0.366}_{0.002}$	$\underline{0.365}_{0.006}$	$0.245_{0.004}$	$0.249_{0.002}$	$\underline{0.329}_{0.005}$	$\mathbf{0.342}_{0.004}$
	1-HL↑	$\underline{0.972}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\underline{0.972}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$	$\mathbf{0.983}_{0.000}$
	1-RL↑	$0.815_{0.002}$	$0.822_{0.001}$	$\underline{0.866}_{0.001}$	$\mathbf{0.877}_{0.003}$	$0.810_{0.002}$	$0.822_{0.002}$	$\underline{0.854}_{0.002}$	$\mathbf{0.863}_{0.002}$
	AUC↑	$0.820_{0.002}$	$0.827_{0.001}$	$\underline{0.870}_{0.002}$	$\mathbf{0.880}_{0.003}$	$0.816_{0.002}$	$0.828_{0.002}$	$\underline{0.857}_{0.002}$	$\mathbf{0.866}_{0.002}$
IAPRTC12	AP↑	$0.250_{0.002}$	$0.265_{0.001}$	$\underline{0.408}_{0.004}$	$\mathbf{0.429}_{0.005}$	$0.234_{0.005}$	$0.265_{0.001}$	$\underline{0.360}_{0.004}$	$\mathbf{0.380}_{0.003}$
	1-HL↑	$0.969_{0.000}$	$\underline{0.981}_{0.000}$	$\mathbf{0.982}_{0.000}$	$\mathbf{0.982}_{0.000}$	$\underline{0.968}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$	$\mathbf{0.981}_{0.000}$
	1-RL↑	$0.841_{0.002}$	$0.851_{0.001}$	$\underline{0.907}_{0.002}$	$\mathbf{0.919}_{0.001}$	$0.832_{0.003}$	$0.851_{0.001}$	$\underline{0.891}_{0.002}$	$\mathbf{0.902}_{0.002}$
	AUC↑	$0.842_{0.002}$	$0.853_{0.001}$	$\underline{0.907}_{0.002}$	$\mathbf{0.920}_{0.001}$	$0.835_{0.002}$	$0.853_{0.001}$	$\underline{0.892}_{0.002}$	$\mathbf{0.902}_{0.002}$
Mirflickr	AP↑	$0.502_{0.020}$	$0.554_{0.001}$	$\underline{0.668}_{0.004}$	$\mathbf{0.691}_{0.004}$	$0.490_{0.010}$	$0.553_{0.002}$	$\underline{0.625}_{0.004}$	$\mathbf{0.627}_{0.004}$
	1-HL↑	$0.843_{0.006}$	$0.882_{0.001}$	$\underline{0.902}_{0.001}$	$\mathbf{0.907}_{0.001}$	$0.863_{0.002}$	$0.882_{0.001}$	$\underline{0.894}_{0.001}$	$\mathbf{0.895}_{0.001}$
	1-RL↑	$0.812_{0.020}$	$0.846_{0.001}$	$\underline{0.902}_{0.002}$	$\mathbf{0.911}_{0.002}$	$0.806_{0.007}$	$0.846_{0.001}$	$\underline{0.883}_{0.002}$	$\mathbf{0.885}_{0.002}$
	AUC↑	$0.795_{0.030}$	$0.839_{0.001}$	$\underline{0.885}_{0.002}$	$\mathbf{0.894}_{0.002}$	$0.797_{0.012}$	$0.838_{0.001}$	$\underline{0.869}_{0.002}$	$\mathbf{0.870}_{0.002}$

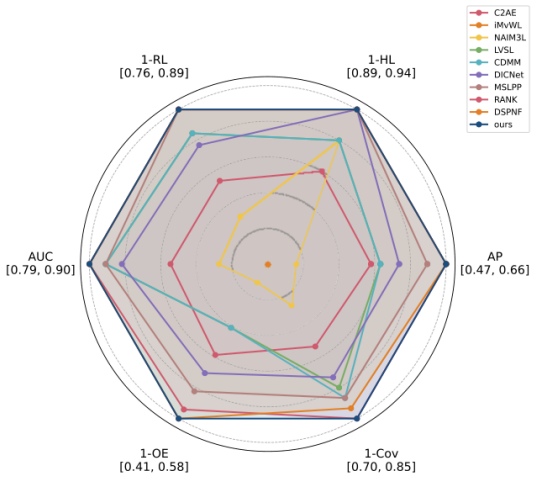


(a) Varying views (Corel5k) (b) Varying labels (Corel5k) (c) Varying views (Pascal07) (d) Varying labels (Pascal07)

图 3 ReCHSM 在不同缺失率下的鲁棒性。 （a）和（c）表示固定标签缺失率为 50% 时改变视图缺失率的影响；（b）和（d）表示固定视图缺失率为 50% 时改变标签缺失率的影响。所有指标均按“越高越好”的形式展示。子图分别为：（a）改变视图缺失率（Corel5k）；（b）改变标签缺失率（Corel5k）；（c）改变视图缺失率（Pascal07）；（d）改变标签缺失率（Pascal07）。图例 0.3、0.5、0.7 对应相应缺失率。纵轴 Values＝指标值。



(a) Corel5k



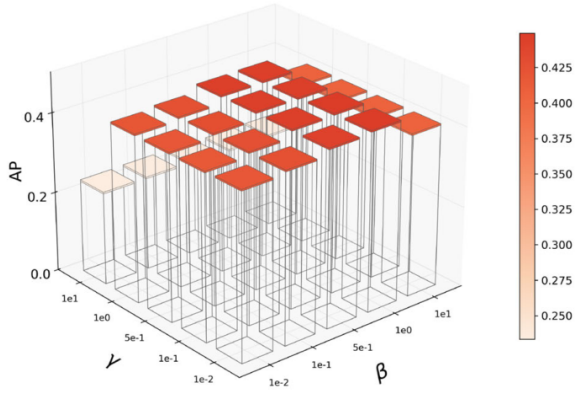
(b) Pascal07

图 4 十种方法在两个完整观测数据集上的性能比较。 对每张雷达图，数据点从中心（最差结果）移向外边界（最优结果）表示性能改善。（a）Corel5k；（b）Pascal07。图例中的 ours 表示本文方法；各轴沿用原始评估指标与范围。

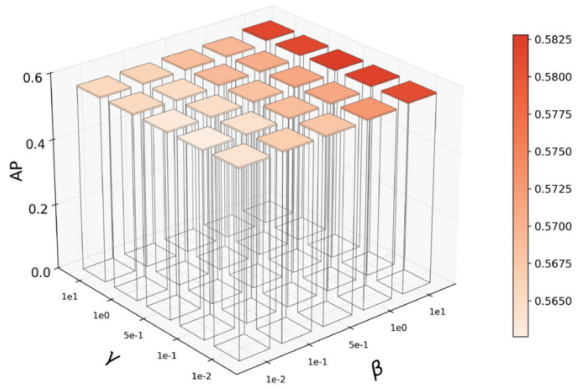
4.3 参数研究

为研究 ReCHSM 对主要超参数的敏感性，我们围绕惩罚系数 β 和 γ、最近邻数量 k、随机游走步数 t 与平衡系数 α 进行参数研究。这些分析在 Corel5k 和 Pascal07 上开展，条件为视图缺失 50%、标签缺失 50% 和训练比例 70%。

关于 β 和 γ： 两个参数均从 {1e-2, 1e-1, 5e-1, 1e0, 1e1} 中选取，结果分别见图 5a 和图 5b。结果表明，ReCHSM 对大多数测试组合相对稳定。然而，将 γ 设为 1e1 会使 Corel5k 上的性能显著下降。这意味着过大的 γ 可能过分强调对应损失项，破坏总体目标的平衡。因此，我们在这一极端区域之外选取参数值。



(a) Corel5k (β and γ)

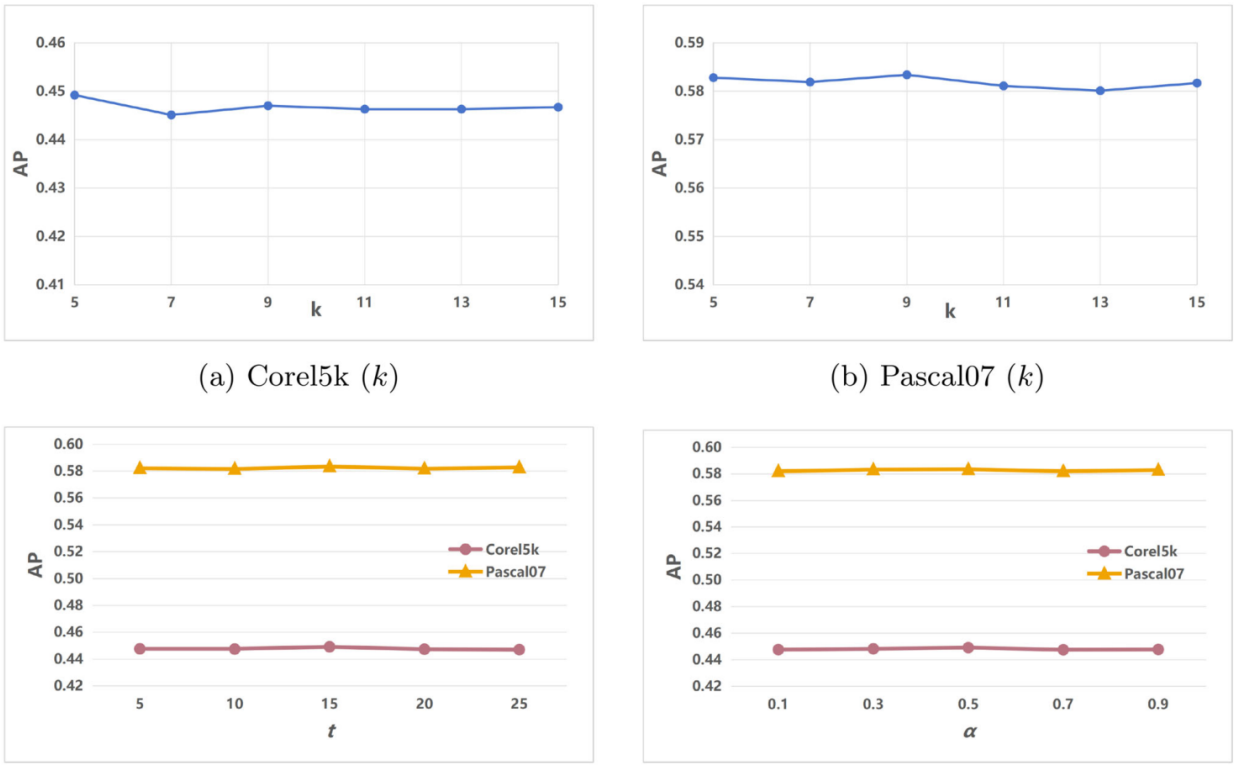


(b) Pascal07 (β and γ)

图 5 在 Corel5k 与 Pascal07 数据集上对 β 和 γ 的超参数研究。 （a）Corel5k（β 与 γ）；（b）Pascal07（β 与 γ）；竖轴为 AP。

关于 k： 参数 k 决定初始候选邻域。如图 6a 和图 6b 所示，k 从 5 变化到 15 时 ReCHSM 保持稳定。Corel5k 上在 $k = 5$ 时取得最优 AP，Pascal07 上在 $k = 9$ 时取得最优 AP；后续实验采用这些取值。较低的敏感性可归因于候选检索之后基于可靠性的筛选和非线性细化。

关于 t 和 α： 我们令 t 在 $\{5, 10, 15, 20, 25\}$ 中变化，α 在 $\{0.1, 0.3, 0.5, 0.7, 0.9\}$ 中变化，结果见图 6c 和图 6d。对于 t，最高 AP 在 $t = 15$ 时取得，表明该值提供了适宜传播深度。对于 α，最高 AP 在 $\alpha = 0.5$ 时取得。这个中间取值在身份保持和结构传播之间提供了适宜平衡。此外，各测试值之间性能变化有限，表明 ReCHSM 总体上对 t 与 α 的适度变化具有鲁棒性。



(a) Corel5k (k)　(b) Pascal07 (k)

(c) Corel5k and Pascal07 (t)　(d) Corel5k and Pascal07 (α)

图 6 ReCHSM 在 Corel5k 与 Pascal07 数据集上对 k、t 和 α 的敏感性。（a）Corel5k（k）；（b）Pascal07（k）；（c）Corel5k 与 Pascal07（t）；（d）Corel5k 与 Pascal07（α）。所有子图的纵轴为 AP。

4.4 消融研究

我们在视图和标签均缺失 50% 的条件下评估 ReCHSM 各模块的贡献。完整 ReCHSM 集成四个关键模块及其相应损失函数：分类骨干（$\mathcal{L}_{\text{cls}}$）、带有 $\mathcal{L}_{\text{comp}}$ 的视图补全模块（Comp.）、高阶语义结构挖掘（$\mathcal{L}_{\text{struct}}$），以及基于标签语义一致性的视图质量评估（$\mathcal{L}_{\text{qual}}$）。只使用 $\mathcal{L}_{\text{cls}}$ 训练的模型作为基线（Backbone）。表 6 报告了 Corel5k 与 Pascal07 上的定量结果。我们还将视图缺失率提高到 70%，同时保持标签缺失 50% 和训练比例 70%，以测试严重视图不完整情形。表 7 比较了完整模型与不含补全的变体。

表 6 双重不完整设置下，各组件在 Corel5k 与 Pascal07 上的性能。 Comp. 表示视图补全模块，$\mathcal{L}_{\text{comp}}$ 为该模块的损失函数。Method＝方法；Loss Functions＝损失函数；Backbone＝骨干基线；w/o Comp.＝无补全模块；Comp.＝有补全模块；勾号表示使用相应损失。粗体表示最优性能。

Method	Loss Functions				Corel5k				Pascal07			
	$\mathcal{L}_{\text{cls}}$	$\mathcal{L}_{\text{comp}}$	$\mathcal{L}_{\text{struct}}$	$\mathcal{L}_{\text{qual}}$	AP↑	1-HL↑	1-RL↑	AUC↑	AP↑	1-HL↑	1-RL↑	AUC↑
Backbone	✓				0.392	0.988	0.889	0.892	0.552	0.932	0.826	0.849
w/o Comp.	✓		✓		0.428	0.988	0.908	0.910	0.567	0.933	0.839	0.861
	✓			✓	0.392	0.987	0.892	0.895	0.553	0.932	0.827	0.850
	✓		✓	✓	0.428	0.988	0.908	0.910	0.566	0.934	0.839	0.860
Comp.	✓	✓			0.420	0.988	0.903	0.906	0.564	0.933	0.836	0.856
	✓	✓	✓		0.447	0.988	0.916	**0.919**	0.579	0.935	0.846	0.867
	✓	✓		✓	0.415	0.988	0.899	0.902	0.566	0.933	0.837	0.856
	✓	✓	✓	✓	**0.449**	**0.988**	**0.916**	0.918	**0.583**	**0.935**	**0.847**	**0.868**

表 7 在视图缺失 70%、标签缺失 50%、训练样本占 70% 的条件下，Corel5k 与 Pascal07 上的视图补全模块消融结果。 Method＝方法；w/o Comp.＝无补全模块；Full model＝完整模型。

Method	Corel5k				Pascal07			
	AP↑	1-HL↑	1-RL↑	AUC↑	AP↑	1-HL↑	1-RL↑	AUC↑
w/o Comp.	0.365	0.987	0.885	0.888	0.525	0.930	0.809	0.835
Full model	0.392	0.987	0.900	0.902	0.543	0.931	0.824	0.847

- **可靠跨视图邻域关系迁移补全的有效性。** 相比 Backbone，引入 Comp. 后，Corel5k 上的 AP 从 0.392 提高到 0.420，Pascal07 上从 0.552 提高到 0.564，分别提高 2.8 和 1.2 个百分点。这证实补全策略能够恢复对下游分类有用的缺失视图信息。
- **视图补全与高阶语义结构挖掘的协同作用。** 在 Corel5k 上，将 Comp. 与 $\mathcal{L}_{\text{struct}}$ 相结合得到 AP 0.447，比 Backbone 高 5.5 个百分点，也高于单独使用 Comp.（0.420）或 $\mathcal{L}_{\text{struct}}$（0.428）的结果。Pascal07 呈现相同趋势。这些结果确认，高阶结构挖掘将修复后的局部关系扩展为更广泛的语义依赖，与视图补全形成互补。
- **视图质量评估模块的作用。** 该模块单独使用时的表现接近 Backbone，说明其独立贡献有限。当在补全和高阶结构挖掘之上加入该模块时，Corel5k 的 AP 从 0.447 提高至 0.449，Pascal07 从 0.579 提高至 0.583，其他指标则保持有竞争力。因此，$\mathcal{L}_{\text{qual}}$ 主要在表示完整性和结构一致性得到改善后提供辅助监督。
- **严重视图不完整条件下视图补全的鲁棒性。** 如表 7 所示，完整模型在两个数据集上均持续优于不含视图补全的变体。这表明，即便大多数视图不可用，补全模块仍能提供有用信息，证实所提补全策略在严重视图不完整条件下的鲁棒性。

为进一步检验补全机制的行为，补充材料第 S1 节和表 S1 提供了 Corel5k 与 Pascal07 上关于候选可用性、累积距离分布、重构权重集中程度和有效邻居数量的额外事后诊断。

4.5 复杂度分析

我们从时间复杂度与空间复杂度两个方面分析 ReCHSM 的计算需求。主要计算成本来自可靠跨视图补全、视图特定表示学习、高阶语义结构挖掘和损失计算。令 D_v 表示与第 v 个视图相关的隐藏层中最大神经元数量，b 表示批量大小。

对于可靠跨视图补全，在所有视图上构建成对欧氏距离矩阵需要 $O\left(mb^2d_{\max}\right)$，其中 m 为视图数，$d_{\max}=\max_v d_v$ 为最大输入维度。基于排序的 KNN 检索在最坏情况下需要 $O\left(mb^2\log b\right)$。考虑到一个样本可能有多个缺失目标视图，跨视图关系迁移、可靠性评分和候选选择需要 $O\left(bm^2k\log\left(mk\right)\right)$，其中 k 为选定邻居数。非线性细化网络和视图特定编码器采用全连接层，复杂度为 $O\left(b\sum_{v=1}^{m}D_v^2\right)$。在补全预训练期间，计算 $\mathcal{L}_{\text{comp}}$ 需要 $O\left(bmkd_{\max}\right)$；当 $k\le b$ 时，它被成对距离构建的成本支配，因此不会改变补全阶段的渐近复杂度。

对于高阶语义结构挖掘，构建各视图的亲和矩阵需要 $O\left(mb^2d_e\right)$，其中 d_e 为嵌入维度。通过稠密矩阵求幂计算 t 步转移矩阵需要 $O\left(mb^3\log t\right)$，其中 t 为随机游走步数。结构约束计算所有有序视图对的相似度矩阵，需要 $O\left(m^2b^2d_e\right)$。基于标签语义一致性的质量评估需要 $O\left(b^2\ell+mb^2d_e+bmd_e^2\right)$，其中 ℓ 为标签数。

合并同阶项并省略被支配的低阶操作后，每次主训练迭代的总体时间复杂度为：

$$O\Big(mb^3\log t+b^2\left[m\left(d_{\max}+\log b\right)+m^2d_e+\ell\right]+b\left[m^2k\log\left(mk\right)+\sum_{v=1}^{m}D_v^2+md_e^2\right]\Big).$$

三次项来自稠密矩阵求幂，是关于批量大小的最高阶操作。在预热阶段，由于高阶结构矩阵初始化为单位矩阵，这一项被省略。

空间复杂度主要由模型参数、样本关系矩阵和中间特征表示决定。模型参数需要 $O\left(N_\theta^{\text{all}}\right)$ 存储空间，其中 N_θ^{all} 同时包括可训练参数和冻结参数。批次级距离、转移、高阶结构、标签相似度和跨视图相似度矩阵至多需要 $O\left(m^2b^2\right)$ 空间。稠密矩阵求幂涉及的中间矩阵需要 $O\left(mb^2\log t\right)$，而距离计算所用临时成对差分张量需要 $O\left(b^2d_{\max}\right)$。缓存的邻居特征、补全特征、视图特定嵌入和预测需要 $O\left(b\left[mkd_{\max}+md_{\max}+md_e+\ell\right]\right)$。

合并同阶项后，总体空间复杂度为：

$$O\Big(N_\theta^{\text{all}}+b^2\left[m^2+m\log t+d_{\max}\right]+b\left[m\left(k+1\right)d_{\max}+md_e+\ell\right]\Big).$$

因此，主要内存成本随批量大小呈二次增长，而通过小批次处理控制对样本总数的依赖。

为评估实际效率，我们在相同平台、数据划分、缺失掩码、批量大小和主训练轮次下，在 Corel5k 与 Mirflickr 上比较 ReCHSM 与 DICNet、RANK 和 DSPNF。如表 8 所示，由于包含 50 个补全预训练轮次，ReCHSM 需要更多训练和推理时间。然而，在两个数据集上，它以最少的参数和最低的 GPU 峰值显存占用获得了更优的分类性能。

表 8 在视图缺失 50%、标签缺失 50%、训练样本占 70% 的条件下，Corel5k 与 Mirflickr 上的时间成本、GPU 峰值显存和参数分析。 Dataset＝数据集；Measure＝测量项；Method＝方法；Training (s)＝训练（秒）；Inference (s)＝推理（秒）；Peak GPU memory (MB)＝GPU 峰值显存（MB）；Parameters (M)＝参数量（百万）；Completion (s)＝补全（秒）；Random walk (s)＝随机游走（秒）。横线按原表保留。

Dataset	Measure \ Method	DICNet	DSPNF	RANK	ReCHSM
Corel5k	Training (s)	511.70	520.92	540.62	1799.07
	Inference (s)	0.17	0.30	0.27	1.28
	Peak GPU memory (MB)	2208.00	1822.00	3992.00	1374.00
	Parameters (M)	111.14	99.05	191.78	75.96
	Completion (s)	–	–	–	1242.14
	Random walk (s)	–	–	–	10.14
Mirflickr	Training (s)	1090.49	924.49	2787.07	7960.01
	Inference (s)	0.43	0.61	0.70	7.33
	Peak GPU memory (MB)	2626.00	2182.00	16738.00	1574.00
	Parameters (M)	131.12	116.95	191.66	86.72
	Completion (s)	–	–	–	6522.44
	Random walk (s)	–	–	–	55.04

5 结论

本文针对 IMvPMLC 提出了 ReCHSM，即可靠跨视图邻域关系迁移与高阶语义结构挖掘框架。该框架结合三个关键组成部分。首先，我们开发了一种基于可靠跨视图邻域关系迁移的补全机制。该机制通过可靠邻域评分，将现有视图间可靠的实例关系迁移到缺失视图，并进一步使用轻量级 MLP 非线性细化网络处理初始重构数据，从而获得鲁棒的重构视图。其次，我们引入基于随机游走的高阶语义结构挖掘策略，将修复后的局部关系传播为信息更丰富的全局拓扑依赖，以指导编码器提取更加紧凑且更具判别力的高层语义特征。最后，考虑到所学语义信息应服务于最终标签分类，我们设计了基于标签语义一致性的视图质量评估模块，学习样本级自适应融合权重，从而有效聚合多视图信息。

大量结果表明，在双重不完整、单侧不完整和完整数据设置下，ReCHSM 始终优于现有方法或保持竞争力。进一步的消融实验验证了各组件的不可或缺性，尤其突出可靠视图补全与高阶语义结构建模之间强烈的互补性。

补充信息与声明

补充信息。 在线版本包含补充材料，地址为 https://doi.org/10.1007/s44443-026-01262-9。〔译者说明：这是原文所给链接；本次上传的 19 页文件不含该外部补充材料，本译文不包含未提供的 S1、S2、表 S1 或表 S2。〕

作者贡献。 Jiayan Li：概念构思、方法设计、软件、形式分析、初稿撰写。Zhixian Jiang：方法设计、指导监督、审阅与编辑。Wenbin Bu：可视化、验证、实验协助、审阅与编辑。Nisuo Du：指导监督、经费获取、审阅与编辑。Xiaohuan Lu：指导监督、审阅与编辑。所有作者均阅读并批准了最终稿件。

资助。 本工作得到以下项目支持：贵州大学专项（特岗）科研基金（自然科学）“基于多模态强化学习与知识注入的通用推理大模型研究”（编号 GuiDaLingJunHz-[2025] 01）；国家重点项目“教育大数据驱动的个性化学习关键技术及示范应用”（2023YFC3341200）；国家自然科学基金“侦查文书分析中的证据链构建研究”（62166006）。本工作还得到以下项目的部分支持：贵州省科技支撑计划“分布式科技资源空间优化配置关键核心技术”（黔科合支撑 [2023] 一般 093）和“知识与数据驱动的水库大坝健康智能诊断关键技术研究”（黔科合支撑 [2023] 一般 251）；贵州省重大科技专项（[2024]014）；贵州大学人才基金（2018 第 48 号）。〔项目中文名称据原文英文译出，编号保留。〕

数据可用性。 本研究使用的数据集均为公开可用的基准数据集。支持本研究发现的数据可在提出合理请求后从通讯作者处获取。

声明。

伦理批准： 不适用。

利益冲突： 作者声明不存在利益冲突。

开放获取。 本文依据知识共享署名—非商业性使用—禁止演绎 4.0 国际许可协议（Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License）授权。该许可允许在任何媒介或格式中进行非商业性使用、共享、分发和复制，前提是适当注明原作者和来源，提供知识共享许可协议的链接，并说明是否修改了获许可材料。**本许可不允许共享由本文或其部分内容产生的改编材料**。 除非材料的署名说明另有规定，本文中的图像或其他第三方材料均包含在文章的知识共享许可范围内。如果某项材料未包含在该许可范围内，且拟进行的使用未获得法律规定允许或超出允许范围，则必须直接获得版权持有者许可。许可协议全文见 http://creativecommons.org/licenses/by-nc-nd/4.0/。

原文许可声明保留。

Open Access This article is licensed under a Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License, which permits any non-commercial use, sharing, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if you modified the licensed material. You do not have permission under this licence to share adapted material derived from this article or parts of it. The images or other third party material in this article are included in the article's Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article's Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit http://creativecommons.org/licenses/by-nc-nd/4.0/.

参考文献

以下按原文顺序保留全部 41 条文献。英文题名、作者、出版信息和 DOI 依据原文保留；“题名中译”为本译文所加，不替换原始检索信息。

1. Chang CY, Jiang WD, Chang IH et al (2026). Not only detection but also explain: An interpretable multimodal system for anomaly detection. IEEE Trans Emerg Topics Comput Intell 10(2):1863–1877. https://doi.org/10.1109/TETCI.2026.3654456。题名中译：不仅检测，还要解释：用于异常检测的可解释多模态系统。

2. Deng T, Zhang Z, Jia Q et al (2026). Tucker decomposition guided shared latent label learning for multi-view incomplete multi-label classification. Information Fusion 126:103673. https://doi.org/10.1016/j.inffus.2025.103673。题名中译：Tucker 分解引导的共享潜在标签学习，用于多视图不完整多标签分类。

3. Duygulu P, Barnard K, de Freitas JF et al (2002). Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary. In: Computer Vision – ECCV 2002, Lecture Notes in Computer Science, vol 2353. Springer, Berlin, Heidelberg, pp 97–112. https://doi.org/10.1007/3-540-47979-1_7。题名中译：将物体识别视为机器翻译：为固定图像词汇表学习词典。

4. Escalante HJ, Hernández CA, Gonzalez JA et al (2010). The segmented and annotated IAPR TC-12 benchmark. Computer Vision and Image Understanding 114(4):419–428. https://doi.org/10.1016/j.cviu.2009.03.008, special issue on Image and Video Retrieval Evaluation（图像与视频检索评估专刊）。题名中译：经过分割和标注的 IAPR TC-12 基准。

5. Everingham M, Van Gool L, Williams CK et al (2010). The PASCAL visual object classes (VOC) challenge. Int J Comput Vision 88(2):303–338. https://doi.org/10.1007/s11263-009-0275-4。题名中译：PASCAL 视觉物体类别（VOC）挑战。

6. Fang X, Hu Y, Zhou P et al (2022). ANIMC: A soft approach for autoweighted noisy and incomplete multiview clustering. IEEE Trans Artif Intell 3(2):192–206. https://doi.org/10.1109/TAI.2021.3116546。题名中译：ANIMC：用于自动加权含噪与不完整多视图聚类的软方法。

7. He ZF, Zhang CH, Liu B et al (2023). Label recovery and label correlation co-learning for multi-view multi-label classification with incomplete labels. Appl Intell 53(8):9444–9462. https://doi.org/10.1007/s10489-022-03945-y。题名中译：面向标签不完整的多视图多标签分类的标签恢复与标签相关性协同学习。

8. Hu S, Shi Z, Ye Y (2022). DMIB: Dual-correlated multivariate information bottleneck for multiview clustering. IEEE Trans Cybernet 52(6):4260–4274. https://doi.org/10.1109/TCYB.2020.3025636。题名中译：DMIB：用于多视图聚类的双重相关多变量信息瓶颈。

9. Huang J, Qu X, Li G et al (2019). Multi-view multi-label learning with view-label-specific features. IEEE Access 7:100979–100992. https://doi.org/10.1109/ACCESS.2019.2930468。题名中译：具有视图—标签特定特征的多视图多标签学习。

10. Huiskes MJ, Lew MS (2008). The MIR Flickr retrieval evaluation. In: Proceedings of the 1st ACM International Conference on Multimedia Information Retrieval. Association for Computing Machinery, New York, NY, USA, pp 39–43. https://doi.org/10.1145/1460096.1460104。题名中译：MIR Flickr 检索评估。

11. Jiang WD, Chang CY, Su MY et al (2025). Toward interpretable multimodal violence detection with knowledge distillation and modality-aligned preprocessing. IEEE Trans Syst Man Cybernet Syst 55(9):6215–6228. https://doi.org/10.1109/TSMC.2025.3576390。题名中译：借助知识蒸馏与模态对齐预处理实现可解释多模态暴力检测。

12. Jiang Y, Zhao L, Jiang Z et al (2025). Semantic consistency enhancement and contribution-driven network for partial multi-view incomplete multi-label classification. J King Saud Univ Comput Inf Sci 37(4):53. https://doi.org/10.1007/s44443-025-00066-7。题名中译：面向部分多视图不完整多标签分类的语义一致性增强与贡献驱动网络。

13. Jiang WD, Chin YT, Yang YT et al (2026a). Detection, retrieval, and explanation unified: A violence detection system based on knowledge graphs and GAT. IEEE Trans Syst Man Cybernet Syst 56(4):2827–2841. https://doi.org/10.1109/TSMC.2026.3653874。题名中译：统一检测、检索与解释：基于知识图谱与 GAT 的暴力检测系统。

14. Jiang Z, Jiang Y, Li C, et al (2026b). Dual-space structure preservation with non-homogeneous fusion for incomplete multi-view multi-label classification. In: Neural Information Processing. ICONIP 2025, Communications in Computer and Information Science, vol 2754. Springer, Singapore, pp 582–597. https://doi.org/10.1007/978-981-95-4091-4_40。题名中译：面向不完整多视图多标签分类的非同质融合双空间结构保持。

15. Li X, Chen S (2022). A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning. IEEE Trans Pattern Anal Mach Intell 44(10):5918–5932. https://doi.org/10.1109/TPAMI.2021.3086895。题名中译：用于非对齐不完整多视图与缺失多标签学习的简洁有效模型。

16. Li C, Wu X, Peng P et al (2024). Incomplete multi-view partial multi-label classification via deep semantic structure preservation. Complex Intell Syst 10(6):7661–7679. https://doi.org/10.1007/s40747-024-01562-5。题名中译：通过深层语义结构保持实现不完整多视图部分多标签分类。

17. Liu M, Luo Y, Tao D, et al (2015). Low-rank multi-view learning in matrix completion for multi-label image classification. In: Proceedings of the AAAI conference on artificial intelligence, pp 2778–2784. https://doi.org/10.1609/aaai.v29i1.9547。题名中译：面向多标签图像分类的矩阵补全中的低秩多视图学习。

18. Liu W, Wang H, Shen X et al (2022). The emerging trends of multi-label learning. IEEE Trans Pattern Anal Mach Intell 44(11):7955–7974. https://doi.org/10.1109/TPAMI.2021.3119334。题名中译：多标签学习的新兴趋势。

19. Liu B, Li W, Xiao Y et al (2023a). Multi-view multi-label learning with high-order label correlation. Inf Sci 624:165–184. https://doi.org/10.1016/j.ins.2022.12.072。题名中译：具有高阶标签相关性的多视图多标签学习。

20. Liu C, Wen J, Liu Y et al (2023b). Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. In: Advances in Neural Information Processing Systems, vol 36. Curran Associates, Inc., Red Hook, NY, USA, pp 32387–32400. https://doi.org/10.5555/3666122.3667528。题名中译：用于不完整多视图弱多标签学习的掩蔽双通道解耦框架。

21. Liu C, Wen J, Luo X, et al (2023c). DICNet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. In: Proceedings of the AAAI conference on artificial intelligence, pp 8807–8815. https://doi.org/10.1609/aaai.v37i7.26059。题名中译：DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络。

22. Liu C, Wen J, Luo X et al (2023d). Incomplete multi-view multi-label learning via label-guided masked view-and category-aware transformers. In: Proceedings of the AAAI conference on artificial intelligence, pp 8816–8824. https://doi.org/10.1609/aaai.v37i7.26060。题名中译：通过标签引导的掩蔽式视图与类别感知 Transformer 进行不完整多视图多标签学习。

23. Liu H, Ma Y, Yan M et al (2024). DIDA: Disambiguated domain alignment for cross-domain retrieval with partial labels. In: Proceedings of the AAAI conference on artificial intelligence, pp 3612–3620. https://doi.org/10.1609/aaai.v38i4.28150。题名中译：DIDA：面向部分标签跨域检索的消歧域对齐。

24. Liu C, Wen J, Xu Y et al (2025). Reliable representation learning for incomplete multi-view missing multi-label classification. IEEE Trans Pattern Anal Mach Intell 47(6):4940–4956. https://doi.org/10.1109/TPAMI.2025.3546356。题名中译：面向不完整多视图缺失多标签分类的可靠表示学习。

25. Long J, Zhang Q, Lu X et al (2024). Multi-scale locality preserving projection for partial multi-view incomplete multi-label learning. Neural Netw 180:106748. https://doi.org/10.1016/j.neunet.2024.106748。题名中译：面向部分多视图不完整多标签学习的多尺度局部保持投影。

26. Sun S, Zong D (2021). LCBM: A multi-view probabilistic model for multi-label classification. IEEE Trans Pattern Anal Mach Intell 43(8):2682–2696. https://doi.org/10.1109/TPAMI.2020.2974203。题名中译：LCBM：用于多标签分类的多视图概率模型。

27. Tan Q, Yu G, Domeniconi C (2018). Incomplete multi-view weak-label learning. In: Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI-18). International Joint Conferences on Artificial Intelligence Organization. Stockholm, Sweden, pp 2703–2709. https://doi.org/10.24963/ijcai.2018/375。题名中译：不完整多视图弱标签学习。

28. von Ahn L, Dabbish L (2004). Labeling images with a computer game. In: Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. Association for Computing Machinery, New York, NY, USA, pp 319–326. https://doi.org/10.1145/985692.985733。题名中译：通过计算机游戏标注图像。

29. Wang Y, Chang D, Fu Z et al (2023). Incomplete multiview clustering via cross-view relation transfer. IEEE Trans Circuits Syst Video Technol 33(1):367–378. https://doi.org/10.1109/TCSVT.2022.3201822。题名中译：通过跨视图关系迁移进行不完整多视图聚类。

30. Yeh CK, Wu WC, Ko WJ et al (2017). Learning deep latent space for multi-label classification. In: Proceedings of the 31st AAAI Conference on Artificial Intelligence, vol 31. AAAI Press, San Francisco, California, USA, pp 2838–2844. https://doi.org/10.1609/aaai.v31i1.10769。题名中译：学习用于多标签分类的深层潜在空间。

31. Zeng P, Yang M, Lu Y et al (2024). Semantic invariant multi-view clustering with fully incomplete information. IEEE Trans Pattern Anal Mach Intell 46(4):2139–2150. https://doi.org/10.1109/TPAMI.2023.3332967。题名中译：完全不完整信息下的语义不变多视图聚类。

32. Zhang C, Yu Z, Hu Q et al (2018). Latent semantic aware multi-view multi-label classification. In: Proceedings of the AAAI conference on artificial intelligence, pp 4414–4421. https://doi.org/10.1609/aaai.v32i1.11722。题名中译：潜在语义感知的多视图多标签分类。

33. Zhao J, Xie X, Xu X et al (2017). Multi-view learning overview: Recent progress and new challenges. Information Fusion 38:43–54. https://doi.org/10.1016/j.inffus.2017.02.007。题名中译：多视图学习综述：近期进展与新挑战。

34. Zhao D, Gao Q, Lu Y et al (2021a). Two-step multi-view and multi-label learning with missing label via subspace learning. Appl Soft Comput 102:107120. https://doi.org/10.1016/j.asoc.2021.107120。题名中译：通过子空间学习进行标签缺失条件下的两步多视图多标签学习。

35. Zhao D, Gao Q, Lu Y et al (2021b). Consistency and diversity neural network multi-view multi-label learning. Knowl-Based Syst 218:106841. https://doi.org/10.1016/j.knosys.2021.106841。题名中译：一致性与多样性神经网络多视图多标签学习。

36. Zhao D, Gao Q, Lu Y et al (2023). Non-aligned multi-view multi-label classification via learning view-specific labels. IEEE Trans Multimedia 25:7235–7247. https://doi.org/10.1109/TMM.2022.3219650。题名中译：通过学习视图特定标签进行非对齐多视图多标签分类。

37. Zheng Y, Zhou G, Huang H et al (2025). Unifying complete and incomplete multi-view clustering through an information-theoretic generative model. Neural Netw 182:106901. https://doi.org/10.1016/j.neunet.2024.106901。题名中译：通过信息论生成模型统一完整与不完整多视图聚类。

38. Zheng Y, Huang H, Luo Y et al (2026). Multi-view subspace tensorization with attentive clustering embedding. Neural Netw 196:108344. https://doi.org/10.1016/j.neunet.2025.108344。题名中译：具有注意力聚类嵌入的多视图子空间张量化。

39. Zhu P, Hu Q, Hu Q et al (2018). Multi-view label embedding. Pattern Recogn 84:126–135. https://doi.org/10.1016/j.patcog.2018.07.009。题名中译：多视图标签嵌入。

40. Zhu C, Miao D, Wang Z et al (2020). Global and local multi-view multi-label learning. Neurocomputing 371:67–77. https://doi.org/10.1016/j.neucom.2019.09.009。题名中译：全局与局部多视图多标签学习。

41. Zhu Y, Ma J, Yuan C et al (2022). Interpretable learning based dynamic graph convolutional networks for Alzheimer’s disease analysis. Information Fusion 77:53–61. https://doi.org/10.1016/j.inffus.2021.07.013。题名中译：用于阿尔茨海默病分析的基于可解释学习的动态图卷积网络。

出版者说明。 Springer Nature 对已发表地图中的司法管辖区主张和机构隶属关系保持中立。

译者核对说明

以下仅说明原文中保留的边界与记号，不属于作者新增结论，也不对论文作未经证实的修正。

1. 本译文的“部分多标签”遵循原题 partial multi-label。正文实验中对应的是标签条目缺失；未将其改写为另一个“候选标签集合中包含错误标签”的任务设定。
2. 所有编号公式均以原件裁图保留：距离范数在式（1）中不平方，而高斯核中的距离在式（9）中平方；式（3）的可靠性为出现频次的平方除以累积距离；式（13）的分母原文是 mn^2，其视图求和为 $u,\ v=1,\ \ldots,\ m$，未擅改成 m^2n^2；式（21）仍以 $n\ell$ 归一化，而不是以已观测标签数量归一化。
3. 原文说明了无候选邻居时传入零初始化特征、邻居集合为空时相应内层补全损失取零。原文未进一步给出式（3）中累积距离为零、式（7）中 $N_{\text{miss}}=0$、式（9）归一化嵌入的范数为零、式（15）中共同已观测标签数为零，或式（17）中 $n=1$ 时的数值处理规则。本译文不自行补入平滑常数、掩蔽或其他实现约定。
4. 表 3 中 CDMM 的来源写为 KBS’20，LVSL 写为 TMM’22；相应参考文献的年份分别为 2021b 和 2023。本译文按各自原始位置保留，没有统一改年。原文中的两项 Jiang et al. 2025 引用均保持原样，未额外分配年份后缀。
5. 表 4 与表 5 中小号下标数值、最优粗体与次优下划线均直接保留原表。原文表注没有明确解释这些小号下标的统计含义，译文不擅自添加“标准差”等断言。表 6 中完整模型 Corel5k AUC 为 0.918，而仅补全加结构项的对应值为 0.919；数值与原始加粗均原样保留。
6. 算法 1 的步骤 5 按原文翻译为通过总损失更新相关网络；第 3.5 节同时明确描述质量网络的梯度隔离，仅由质量损失优化。两处表述均完整保留。复杂度部分也按原文保留小批次分析、稠密矩阵求幂与冻结补全模块后的计算项。
7. 补充材料第 S1、S2 节及表 S1、S2 不在本次上传原件之中。本译文保留正文对其的引用及其缺件事实，没有替代性摘要、推造补充结果或擅自延伸来源范围。