利用生物医学与语言知识增强的多标签分类从全切片图像预测基因突变

Predicting Genetic Mutation from Whole Slide Images via Biomedical-Linguistic Knowledge Enhanced Multi-label Classification

Gexin Huang、Chenfei Wu、Mingjie Li、Xiaojun Chang（IEEE 高级会员）、Ling Chen（IEEE 高级会员）、Ying Sun、Shen Zhao（通信作者）、Xiaodan Liang、Liang Lin（IEEE Fellow）。

版本与许可：本译文对应 arXiv:2406.02990v1，2024年6月5日提交的16页预印本，不是仓库条目 P054 后来的期刊最终版。原文：https://arxiv.org/abs/2406.02990v1 。arXiv 为此版本标示 CC BY-NC-SA 4.0（https://creativecommons.org/licenses/by-nc-sa/4.0/）。本非官方中文翻译及排版改编按同一许可提供，须署名、非商业使用并以相同方式共享，不表示作者认可本译文。原 PDF 使用 IEEE 期刊模板，页脚还含“0000–0000/00$00.00 © 2021 IEEE”模板文字；本译本的版本与许可识别以对应 arXiv 记录为依据，不据模板认定正式发表。

内容范围：完整正文、8幅图的图注、3张表、55条参考文献及9位作者简介。图3(a1)含来自 GeneCards 的较长第三方说明摘录，本译本不复制该图块及其逐字引文，改以中文概述说明；其余图块保留。作者肖像不转载。数字、公式与原文中存在的不一致不作隐蔽修正，必要处加译注。作者任职与简介均按2024年原稿翻译，不代表当前情况。本译本用于论文阅读，不构成临床建议。

摘要

从全切片图像预测基因突变对于癌症诊断不可或缺。然而，现有研究训练多个二分类模型，面临两项挑战：(a) 训练多个二分类器效率低，而且不可避免地会产生类别不平衡问题；(b) 忽略基因之间的生物学关系，限制了预测性能。为解决这些问题，我们设计了生物学知识增强的病理基因组多标签 Transformer（Biological-knowledge enhanced PathGenomic multi-label Transformer, BPGT）。

BPGT 首先建立新的基因编码器，通过两个专门模块构造基因先验：(a) 基因图，其节点特征由基因的语言描述和癌症表型组成，边依据基因通路关联与突变一致性建模；(b) 知识关联模块，利用基于 Transformer 的图表示学习，将语言与生物医学知识融合到基因先验中，捕获不同基因突变之间的内在关系。随后，BPGT 设计标签解码器，通过两个模块完成突变预测：(a) 模态融合模块，将基因先验与全切片图像中的关键区域融合，获得逐基因突变 logits；(b) 对比式多标签损失，强调不同突变状态之间的内在比较，以增强判别能力。在癌症基因组图谱（TCGA）基准上的充分实验表明，BPGT 优于当时的先进方法。

索引词：组织病理学；基因突变；知识图谱；Transformer；多标签学习。

作者单位与资助：G. Huang 任职于加拿大温哥华不列颠哥伦比亚大学。C. Wu 和 Y. Sun 任职于中山大学肿瘤防治中心，中国广州510060。M. Li 任职于斯坦福大学放射肿瘤学部门。L. Chen 和 X. Chang 任职于悉尼科技大学澳大利亚人工智能研究所。S. Zhao 和 X. Liang 任职于中山大学智能工程学院，中国广州510006。L. Lin 任职于中山大学计算机学院，中国广州510006。X. Chang 和 X. Liang 同时任职于穆罕默德·本·扎耶德人工智能大学（MBZUAI）计算机视觉系。

邮箱依原稿次序：gexinml@gmail.com；wucf@sysucc.org.cn；lmj695@stanford.edu；xiaojun.chang@uts.edu.au；Ling.Chen@uts.edu.au；sunying@sysucc.org.cn；z-s-06@163.com；xdliang328@gmail.com；linliang@ieee.org。通信作者为 Shen Zhao。本研究获国家自然科学基金62101607、国家重点研发计划政府间国际科技创新合作重点专项2022YFE0112500，以及中国博士后科学基金2022TQ0389支持。

1 引言

从全切片图像（whole slide images，WSIs）预测基因突变，即依据输入 WSI 的组织病理信息找出全部发生突变的基因，有望推动癌症诊断[1]、预后[2,3]、生存预测[4]和治疗[5]等临床流程。某些基因的突变与癌症进展存在内在联系[6]，因此突变预测具有重要临床意义。近年来，研究者揭示了基因突变与癌组织病理信息之间的联系[7]，支持直接从 WSI 预测基因突变的可行性。虽然基因检测也可用于这一目的，但直接从 WSI 预测显著更经济、便捷[8]。因此，这是临床和人工智能研究的重要方向。

然而，这一任务具有挑战性。一方面，基因突变发生在分子层面，它与 WSI 可见组织病理信息之间的关系不易辨认；另一方面，不同基因突变间的生物学关系也很复杂。例如：(1) WSI 通常很大，往往达到十亿像素级，但其中哪些细微区域与特定基因的突变有关，即使专业病理学家也可能难以辨识，因为相关的细胞和组织结构非常细微复杂[9]。计算模型要探索巨幅 WSI 关键区域与特定基因突变之间的潜在联系，可能更加困难。(2) 不同基因的突变在分子层面可能存在微妙关联[10]。一个患者同时发生多个基因突变，而不只是单个基因突变，是常见现象[11]。计算机视觉算法难以捕获这些分子层面的生物学关系及共突变现象。因此，从 WSI 预测基因突变，本质上是一个输入复杂、类别标签易混淆的多标签分类任务。

现有研究主要把该任务分解为逐个基因的突变状态二分类，见图1(a)。这种做法忽略不同基因突变之间的内在生物关系，可能导致效率和准确性不足[12,13]。它们还可能忽略基因标签的语言信息以及生物医学知识提供的指导，影响深度学习从 WSI 预测突变的效果[14]。详细分析如下。

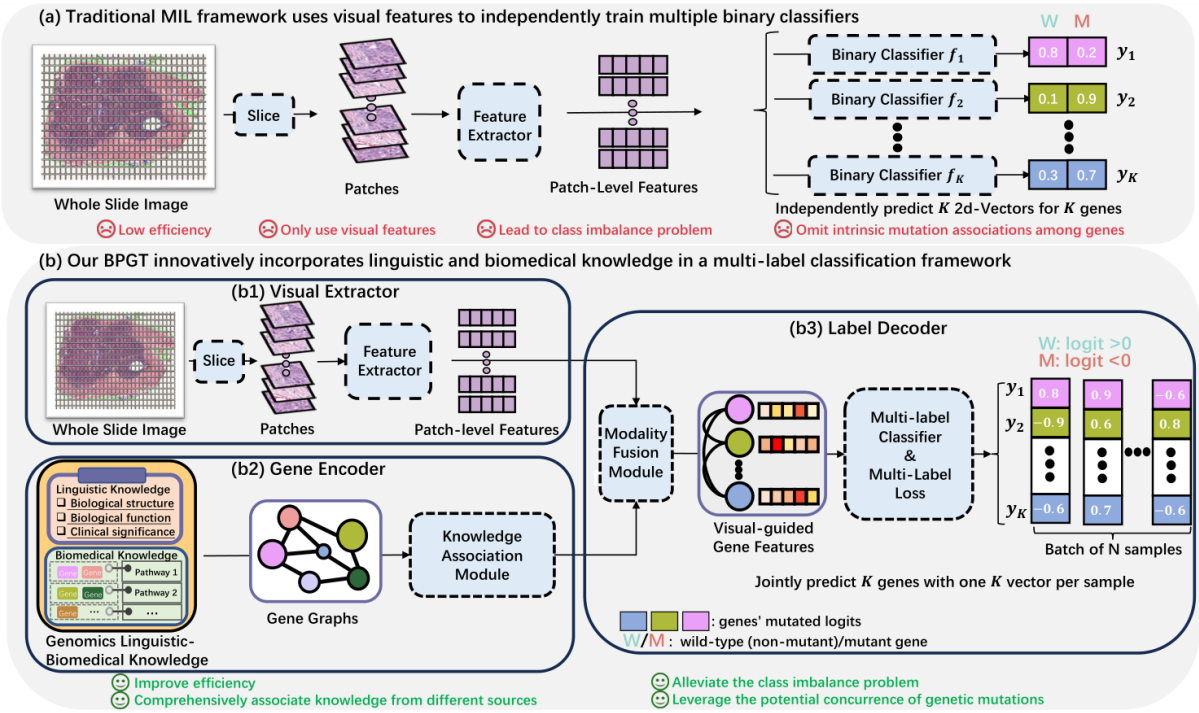


图1 BPGT 与现有 MIL 框架的流程比较。MIL 框架(a)仅用视觉特征，针对每个基因分别预测一个表示突变状态的二维向量。BPGT(b)则在多标签分类范式中综合关联语言知识、生物医学知识等不同来源信息，提高效率、缓解类别不平衡、充分利用潜在共突变关系，并增强特征判别性。图内关键词：Whole Slide Image＝全切片图像；Patches＝图块；Feature Extractor＝特征提取器；Visual Extractor＝视觉提取器；Gene Encoder＝基因编码器；Label Decoder＝标签解码器；Linguistic/Biomedical Knowledge＝语言/生物医学知识；W/M＝野生型（未突变）/突变型。原图的 logit 正负标记与第2.3.1节预测约定有不一致，均保留原稿信息，不据此改变正文。

1.1 相关工作

1.1.1 用于WSI基因突变预测的多示例学习范式

基于多示例学习（MIL）的方法可用于预测基因突变，但直接采用逐基因二分类范式，可能忽略基因突变的内在关系以及非视觉模态信息。MIL 首先把 WSI 切分为多个图块，再选取代表性图块并提取图块级特征，最后聚合成切片级特征以完成病理诊断任务。MIL 已在癌症诊断、分子表型预测和生存预测等多种 WSI 任务中证明有效[15–17]，也已用于基因突变预测。

例如，Fu 等[2]采用基于迁移学习的 MIL 方法：先用预训练 InceptionNet 提取可迁移的图块级特征，再依次聚合这些特征，训练新的突变分类器。Kather 等[9]先用 ResNet-50 编码器提取图块特征，再用三层多层感知机（MLP）及平均池化聚合，最后为每个基因独立训练一个二分类器。Qu 等[18]先通过 ResNet-101 提取图块特征，然后借助人工专家及 K-means 算法选取含肿瘤的图块；随后利用自注意力层聚合特征，学习切片级表示以预测突变。Chen 等[15,16]把图块特征分成多个簇，各自训练分类器，再选择分类器中的最佳分数计算切片级预测。Saldanha 等[19]先提取图块特征，再经注意力层聚合，以给突变打分。

尽管这些工作取得了不可忽视的成果，它们都将任务分解为逐基因独立训练二分类器，判断该基因是否突变；每个分类器输出一个二维向量，见图1(a)。若采用多标签分类，更好地利用突变关系与多模态知识，其准确性和效率还有提升空间。

1.1.2 医学图像中的知识图谱

知识图谱通过节点和边在语义上连接知识，有潜力建模不同基因突变之间的关系，从而改进 WSI 突变预测[20]。近期方法主要把包含目标组织或病灶的图像、WSI 图块视为节点，把空间距离、特征相似度等关系视为边，重点在于获取更好的节点表示及交互。

例如，Chan 等[21]先检测 WSI 图块中的细胞核，并将其划分为预定义类型，如肿瘤性或非肿瘤性。随后，对每种细胞核类型，以图块特征为节点、特征相似度为边构图；再用语义一致性池化联合聚合这些图，得到用于癌症分类等下游任务的 WSI 级特征。Li 等[22]先提取图块中的疾病相关特征作为节点，再根据空间距离通过 K 近邻（KNN）建立层次图，最终用加权池化聚合各层次图的节点预测来分类癌症。Mao 等[23]采用 GCN，把每张 X 光图像作为节点，并将身份、年龄、性别和视角四类图像关系编码为边；GCN 所得全局图像表示用于识别14种疾病。Yu 等[24]提取胸部 X 光图像特征作为节点，以欧氏距离编码边，再经 GCN 聚合得到所有图像的全局表示，将每张图像分为正常或肺炎。

这些方法可能迁移到基因突变预测，通过考虑突变关系来改进 MIL。但其知识图谱主要依赖视觉特征，没有充分利用标签背后的语言和生物医学信息等有价值的知识，因而可能限制突变预测能力。

1.1.3 讨论与动机

通过在多标签分类框架内更好地利用多模态信息，现有方法可以进一步改进。直接使用现有 MIL 范式和/或知识图谱可能存在以下问题。

- 待分类基因可能很多，逐基因二分类就需要训练大量分类器，导致参数多、MIL 效率低[25]。更重要的是，对每个基因，未突变的负样本远多于突变的正样本，分类器因而倾向输出阴性，这不利于后续诊断分析。
- 独立二分类忽略了基因组数据中有价值的内在关系。不同基因在分子层面可能相关，存在潜在共突变。忽略这一点，可能导致次优性能，尤其是对训练数据不足但可由关联基因推断状态的稀有基因[12,13]。
- 即使把基因而不是 WSI 图块[26,27]视作节点来做多标签分类，现有知识图谱方法[28]也可能忽略基因的重要语言与生物医学知识。直接迁移这些方法，可能缺乏综合基因先验的指导，难以准确定位巨幅 WSI 中与突变相关的区域，继而损害预测表现。

因此，突变预测需要一个能够综合利用 WSI 图像、基因标签语言知识以及不同基因生物医学关系的多标签分类框架。同时，还应增强特征判别性，以正确找出所有突变基因。

1.2 方法概述

据此，我们提出 BPGT，以多标签分类方式从 WSI 预测基因突变。图1(b)中，BPGT 先像已有方法一样提取视觉特征(b1)。不同之处在于，它基于 GNN 和 Transformer 设计新的基因编码器（GE，b2），将生物医学知识与语言知识整合成基因先验；再设计新的标签解码器（LD，b3），综合融合视觉特征与基因先验，并构造对比式多标签损失。

1. **基因编码器**整合生物医学与语言知识，以增强预测。它首先建立基因图（GG），结合 GeneCards 中的语言知识，如描述基因突变特征及癌症发病相关特征的文字，以及癌症表型、通路关联、突变一致性等生物医学知识，形成对基因的综合描述。随后设计知识关联模块（KAM），通过 Transformer 图表示学习，将两类知识融合成基因先验，捕获不同基因突变之间的内在关系。

2. **标签解码器**把基因先验与视觉特征融合，使语言知识、生物医学关系与 WSI 特征相联系。它首先采用基于 Transformer 的模态融合模块（MFM），引导 BPGT 聚焦与突变最相关的 WSI 区域。随后为每张 WSI 进行多标签分类，输出表示多个基因突变概率的向量。原稿此处称其为 N 维向量、对应 N 个基因；后文统一使用 K 表示基因数。LD 还设计对比式多标签损失，通过强调类别间比较，更好地区分突变和未突变基因，避免为各基因分别训练分类器，并提高预测性能。

本文主要贡献如下。

- 据我们所知，BPGT 是首个用于基因突变预测、综合整合 WSI 视觉特征、基因语言知识和生物医学知识的多标签分类框架，避免了既有 MIL 方法的局限。
- 提出基因编码器，以 Transformer 图表示学习整合标签语言知识与生物医学知识，构造全面描述基因生物特征的先验。
- 设计标签解码器融合视觉特征与基因先验，综合多模态知识，探索巨幅 WSI 特征与基因先验的关系；同时构造对比式多标签损失以提升预测。

我们在具有挑战性的大规模 WSI 数据集 TCGA 上进行了全面评估。实验表明，BPGT 改善了突变预测，优于当时先进的二分类模型；各设计模块均有益。BPGT 为研究突变相关癌症发生、靶向治疗和预后奠定基础。

2 BPGT

BPGT 是紧密集成的多标签分类框架，可直接从输入 WSI 预测所有突变基因。它包含视觉提取器、基因编码器和标签解码器；后两者是本文新设计的模块，利用综合基因生物先验增强分类准确性。整体流程如下。

视觉提取器（VE，图2(a)）把输入 WSI（记为 X）切成大量图块，提取图块级组织病理特征 F。同时，基于图的 GE（图2(b)）构建基因图（b1）：将语言知识编码为初始节点特征 G，将生物医学知识编码为边权和节点权重。随后，KAM（b2）聚合两类知识，得到考虑基因间突变相关性的先验 P。视觉特征 F 和基因先验 P 再被送入 LD（图2(c)）；MFM（c1）融合两者，引导分类器关注与突变相关的关键区域。最终预测 logits y 由切片级突变标签 y^* 通过对比式多标签损失（c2）监督，更好地区分突变与未突变基因。

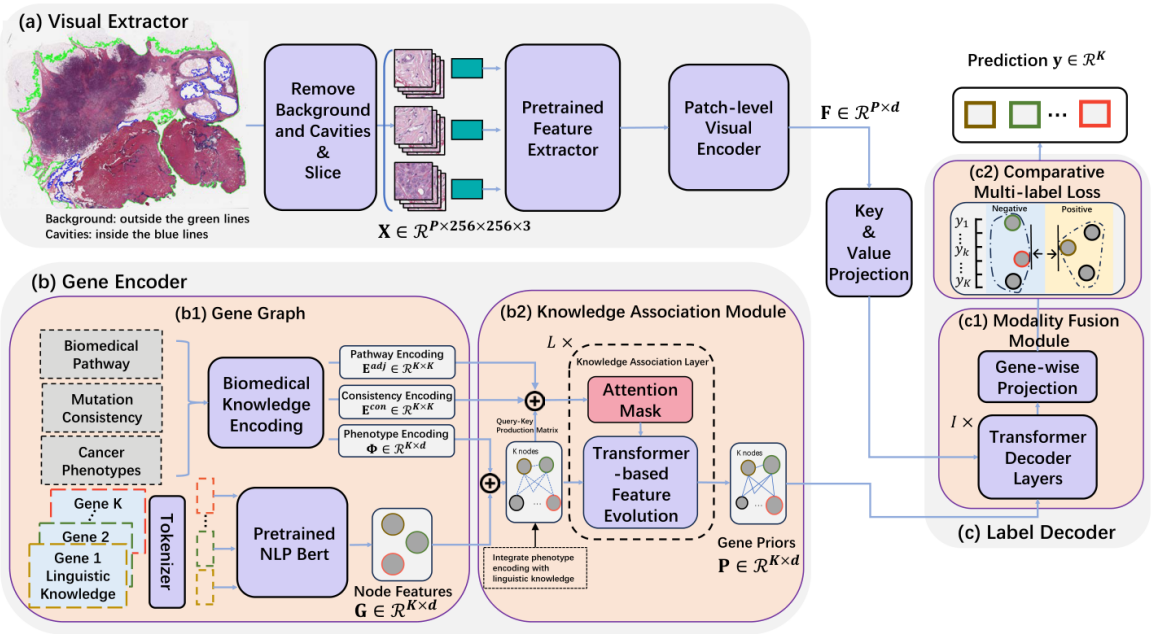


图2 BPGT 总体架构：(a)视觉提取器；(b)基因编码器；(c)标签解码器。(b1)基因图和(b2)知识关联模块分别在第2.2.1和2.2.2节详述。图内注释：绿色轮廓外为背景，蓝色轮廓内为空腔；Phenotype/Pathway/Consistency Encoding＝表型/通路/一致性编码；Gene Priors＝基因先验；Query-Key Production Matrix＝查询–键乘积矩阵；Gene-wise Projection＝逐基因投影；Comparative Multi-label Loss＝对比式多标签损失。原图将图块数写为 P，正文使用 N；图像标签保留原样。

2.1 视觉提取器

BPGT 首先通过 VE 有效提取巨幅 WSI 的图块级语义特征。依照常用预处理流程[29]，VE 将输入 WSI 分割成不重叠图块。同时用 OTSU 算法确定背景区域，即图2(a)中的白色区域，删除位于绿色轮廓外、含背景的图块，以减少计算。再用分割算法删除含空腔的图块，即蓝色轮廓内部分。这样，整图被切分为多个包含苏木精–伊红（H&E）染色组织的图块，大小均为 $L\times L$，记为 $X = x_1, \ldots, x_N \in \mathbb{R}^{N\times L\times L\times 3}$，其中 x_i 表示第 i 个图块。

随后，以预训练特征提取器 DINO[30]提取粗粒度图块特征，展平后送入图块级视觉编码器，输出用于切片级下游任务的细粒度视觉特征 $F \in \mathbb{R}^{N\times d}$。为验证 BPGT 能适用于不同视觉编码器，选取以下先进编码器。

- **GeneHe-VE[18]**：提取粗粒度特征后，先用粗略 K-means 分类选择含癌组织的图块，再用经典 Transformer[31]中的缩放点积多头自注意力，使图块间信息交互，获得细粒度特征 F。
- **DeepHis-VE[9]**：主流程与 GeneHe-VE 相同，但从 X 中随机选500个图块，不要求一定包含肿瘤；仅用三层 MLP 提取各图块细粒度特征，作为 F。
- **Attention-VE（Att-VE）[32]**：主流程相似，但不筛选图块。它将所有图块的粗粒度特征送入多头自注意力层[33]，为每个图块计算分数，再按分数加权进行图块间特征交互，计算 F。
- **Transformer-VE（Trans-VE）[34]**：类似 Att-VE，先将所有图块的粗粒度特征送入 CNN，获得位置编码，将其与图块特征拼接后送入视觉 Transformer（ViT）[35]，计算图块间注意力并进行特征交互；交互后特征即 F。

- **核注意力 Transformer（KAT）[36]**：同样用 ViT 注意力进行交互，但另计算编码图块空间距离的掩码矩阵，在图块特征交互时与值矩阵相乘，从而以空间距离引导交互，提取细粒度 F。
- **层次图像金字塔 Transformer（HIPT）[37]**：先重新组织粗粒度图块特征，使之与更大图块的空间排列对齐。例如，将一组 16×16 个、来自 256×256 图块的特征拼接为一个 4096×4096 图块的新特征。再将重排后的特征送入另一个 DINO，进行图块间交互，输出细粒度 F。

2.2 基因编码器

GE 通过构造基因图 GG（图2(b1)）及 KAM（图2(b2)）整合标签中的语言和生物医学知识，建立基因先验 P，帮助探索不同基因突变之间的关系。

2.2.1 基因图

GG 将基因语言知识编码为初始节点特征，即初始基因特征 G；同时利用基因的生物医学知识建立边权和节点权重。

语言知识编码。 初始特征 G 旨在编码每个基因背后的语言知识，以捕捉标签独有信息。语言知识来自 GeneCards[1]，包括突变特征、生物功能、临床意义等文字说明。例如，TP53 的说明涉及其编码的抑癌蛋白、与多种人类癌症的关联，以及旁系同源基因 TP73。这说明 TP53 的突变会增加癌症易感性；TP53 可能与 TP73、TP63 等抑癌基因共享生物功能，却可能与 KRAS、EGFR 等促癌基因具有相反功能。

把这些语言知识纳入初始节点特征，可以综合捕捉每个基因的独特性和与其他基因的语言关联，有助于掌握不同基因突变之间，以及突变与癌症发生之间的关系。相比之下，仅用独热向量表示基因，可能在图学习中造成过平滑[38]；而且这种初始化不包含基因语言信息，会削弱后续图表示学习。

我们采用字节对编码（BPE）[39]，把 GeneCards 文本分解为子词 token。token 可保留 TP53、TP73 等基因名称和 tumor-suppressor 等生物功能概念。再将其送入预训练 BERT 模型，提取 G 作为初始节点特征。所用 BERT 已在相关生物语料上预训练，因此能捕捉基因内在的语义差异和关联。例如 Bio-BERT[40]使用包含基因名、功能和关系的大规模生物文本语料训练，其特征可以反映语言知识中的语义独特性和相关性。

[1] https://www.genecards.org 。本段对所引第三方基因说明作概述，不逐字重现其较长引文。

生物医学知识编码。 在计算节点（基因）的初始特征 G 后，GE 通过三种编码纳入标签内在生物医学知识：(1)表型编码 Φ，编码癌症类型，利用基因–癌症关系辅助预测；(2)通路编码 E^{adj}，编码不同基因的生物医学功能，从功能角度考虑突变关系；(3)一致性编码 E^{con}，从数据角度编码共突变频率。这些特征反映突变关系等内在知识，供第2.2.2节知识关联层构建反映基因依赖的先验。

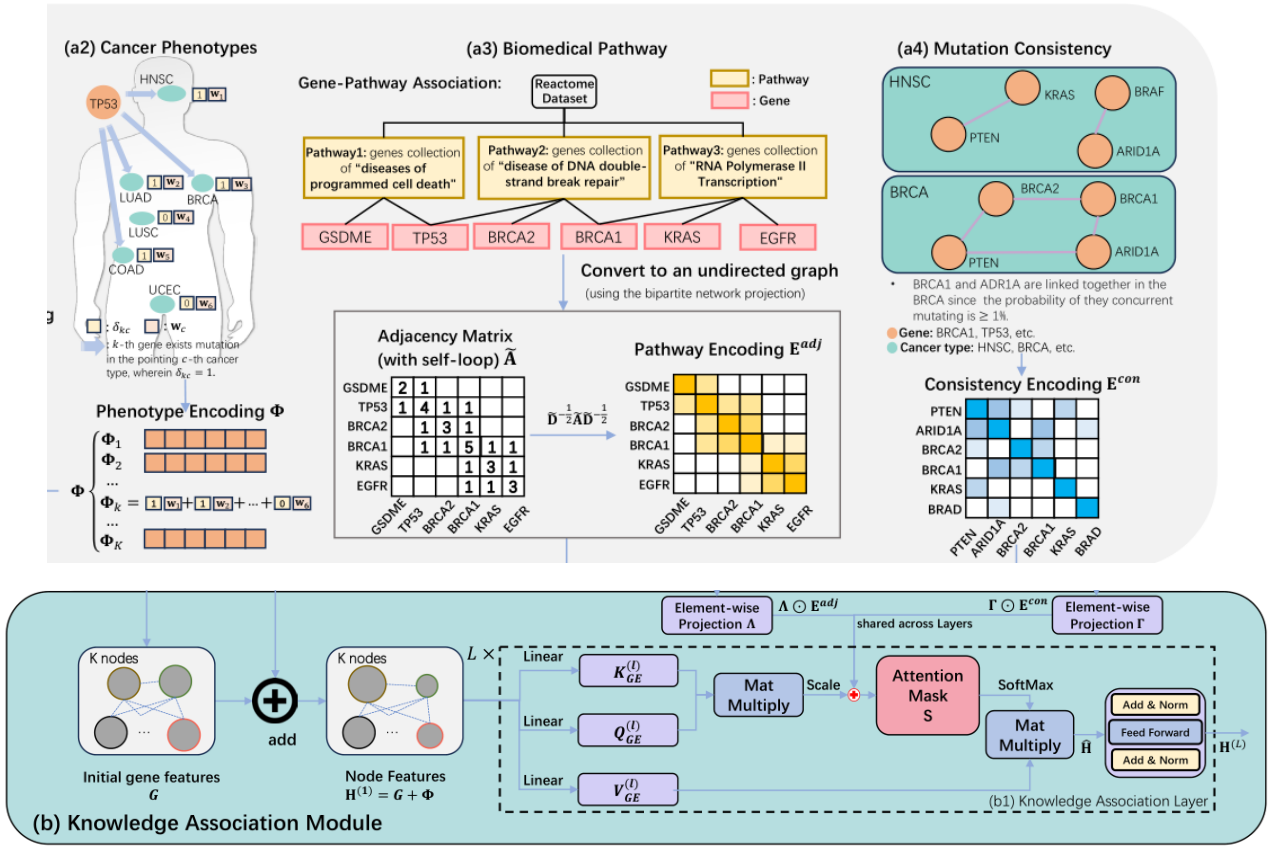


图3 基因编码器将语言和生物医学知识聚合为基因先验，含基因图 GG(a)及知识关联模块 KAM(b)。原图(a1)通过 BPE 和生物医学 BERT 编码 GeneCards 语言知识，得到初始基因特征；该图块因含第三方文本摘录未转载，机制已在正文解释。上图保留(a2)表型编码、(a3)通路编码及(a4)一致性编码：它们分别利用基因–癌症关联、生物功能关联、以及数据驱动共突变频率。下图保留 KAM：节点特征融合语言与表型编码，边权融合通路与一致性编码，以 Transformer 图表示学习综合四类知识。图内关键词：shared across Layers＝跨层共享；Element-wise Projection＝逐元素投影；Mat Multiply＝矩阵乘法；Add & Norm＝残差相加与归一化；Feed Forward＝前馈网络。

表型编码。 它利用基因–癌症关系，将突变与癌症的关联引入节点特征，提高判别性。不同癌症可能与不同基因突变有关。直观地说，如果统计显示某基因在多种癌症中突变，那么该基因在肿瘤 WSI 中更可能发生突变。因此，表型编码考虑潜在基因–癌症关系，向节点特征加入表示这种统计信息的偏置。例如，图3(a2)中 TP53 突变见于乳腺癌 BRCA、肺癌 LUAD、结肠癌 COAD、头颈癌 HNSC 等，因此把这些癌症的可学习特征加入 TP53 表型编码。

形式化地，表型矩阵 $\Phi \in \mathbb{R}^{K\times d}$， K 为基因数， d 为节点特征维数，与 G 相同。第 k 行 ϕ_k 表示第 k 个基因的表型编码：

$$\phi_k = \sum_{c}^{C} \delta_{kc} w_c. \qquad (1)$$

δ_{kc} 表示第 k 个基因突变是否与第 c 类癌症发生相关，相关为1，否则为0；它根据人类癌症经验突变模式[41]确定。向量 w_c 是代表第 c 类癌症的可学习参数，作用类似 Transformer 中的可学习位置嵌入[42]。因此， ϕ_k 聚合所有与该基因突变有关的癌症特征。

通路编码。 生物医学通路是功能相关基因的集合[43]。通路编码利用基因内在功能关系，以边连接 GG 中的相关基因，提高符合这些关系的共突变预测概率。首先从 Reactome[44]提取基因–通路关系，建立由通路到基因的两层树状结构，见图3(a3)。两层分别为通路集合（黄色框）和基因集合（红色框）。两集合之间的连接表示功能关系；例如“DNA双链断裂修复疾病”通路包含 BRCA1、BRCA2、TP53，表示这些功能相关基因的突变可能导致该疾病。

然后采用二部网络投影[45]，将其转为无向图：以基因集合为节点，将它们与另一集合的共享连接转为边。例如，TP53 成为一个节点；其通路连接转化为边。GSDME、BRCA2、BRCA1 通过通路1或2与 TP53 关联，故图3(a3)对应的 $\widetilde{A}_{21}/\widetilde{A}_{12}$、 $\widetilde{A}_{23}/\widetilde{A}_{32}$、 $\widetilde{A}_{24}/\widetilde{A}_{42}$ 的权重各增加1。

转化后图中的边由含自环的邻接矩阵 $\widetilde{A} \in \mathbb{R}^{K\times K}$ 表示:

$$\widetilde{A}_{ij} = \begin{cases} \max\limits_{j\in\{1,\ldots,K\}\setminus\{i\}} n_{ij} + 1, & i = j, \\ n_{ij}, & i \neq j. \end{cases} \tag{2}$$

其中 n_{ji} 表示同时连接基因 i 和 j 的通路数，反映功能相似性。图3(a3)中的第2和第4个基因 TP53 与 BRCA1 共享通路2，因此 $\widetilde{A}_{24} = \widetilde{A}_{42} = 1$。随后，按经典 GCN[46]方式归一化:

$$E^{\mathrm{adj}} = \widetilde{D}^{-1/2}\widetilde{A}\,\widetilde{D}^{-1/2}, \qquad \widetilde{D}_{ii} = \sum_j \widetilde{A}_{ij},$$

$\widetilde{D}$ 为对角矩阵。这样， E^{adj} 从生物功能角度体现突变关系。

一致性编码。 除生物功能外，还可从统计数据角度考虑突变关系。一致性编码量化数据集中的共突变频率，同样作为 GG 的边，目的与通路编码相同。对每种癌症，计算任意两个基因在该癌症 WSI 中共突变的概率；若超过1%，则认为其突变在统计上相关。形式为

$$E^{\mathrm{con}}_{ij} = \begin{cases} 1, & i = j, \\ \dfrac{1}{N}\displaystyle\sum_{c}^{C} \zeta_{ijc} N_c, & i \neq j. \end{cases} \tag{3}$$

N 是训练集 WSI 总数， N_c 是第 c 类癌症的 WSI 数。 ζ_{ijc} 为二元变量：当基因 i, j 在该类癌症中的共突变概率至少为1%时取1。由于大量基因中的共突变总体较少，1%已是相对较高阈值。跨癌症类型的加权平均按其样本规模纳入全部肿瘤 WSI。

我们还尝试按实际共突变概率确定 E^{con}_{ij}，而不是超过1%就置1，但未获得显著提升。这可能是训练集和测试集共突变概率分布不同所引入的偏差所致。相比之下，采用这种“截断”设置的矩阵可能更好地捕捉统计共突变关系。原稿前述阈值先写“超过1%”，变量定义写“至少1%”，本译文保留这一表述差异。

2.2.2 知识关联模块

KAM（图3(b)）利用生物医学编码，通过 Transformer 图表示学习有效更新 GG 节点特征，为每个基因构造同时编码语言知识和生物医学关系的先验 P，捕捉突变依赖，增强多标签分类。

具体而言，KAM 受 Transformer 编码器层[31]启发，构造注意力掩码并用注意力机制学习图表示。首先将表型编码加到初始基因特征：

$$H^{(1)} = G + \Phi. \qquad (4)$$

这将每个基因的语言知识与相关癌症特征整合，更好反映其内在特征。然后，将 $H^{(1)}$ 送入多个知识关联层（KAL），把通路和一致性编码作为特征更新的偏置。以第 l 层为例，通过查询–键乘积建立掩码：

$$S^{(l)} = \frac{Q_{\mathrm{GE}}^{(l)}\left(K_{\mathrm{GE}}^{(l)}\right)^{\top}}{\sqrt{d}} + \Gamma \odot E^{\mathrm{con}} + \Lambda \odot E^{\mathrm{adj}}. \qquad (5)$$

其中 $Q_{\mathrm{GE}}^{(l)} = H^{(l)}W_Q^{(l)}$，$K_{\mathrm{GE}}^{(l)} = H^{(l)}W_K^{(l)}$；下标 GE 表示基因图编码器中的矩阵。$H^{(l)}$ 是本层输入，$W_Q^{(l)}, W_K^{(l)}$ 为可学习矩阵。Γ, Λ 也是可学习矩阵，并在所有 KAL 层间共享。随后按标准自注意力更新节点：

$$\widehat{H}^{(l+1)} = \mathrm{softmax}\left(S^{(l)}\right)V_{\mathrm{GE}}^{(l)}, \qquad (6)$$

其中 $V_{\mathrm{GE}}^{(l)} = H^{(l)}W_V^{(l)}$，$W_V^{(l)}$ 为可训练矩阵。再像经典 Transformer[31]一样，将 $\widehat{H}^{(l+1)}$ 依次送入 Add & Norm、由 MLP 实现的前馈层和另一 Add & Norm，得到本层输出 $H^{(l+1)}$。经过 L 个 KAL，KAM 输出所有基因的先验 P。

这些先验综合考虑与突变相关的语言、生物医学关系。查询–键乘积体现语言知识与基因–癌症表型关联等内在特征；加入 E^{con} 和 E^{adj} 偏置，则纳入由通路和一致性推得的共突变关系。这样，节点聚合综合了多种基因先验，有益于多标签分类中基因间突变关系的捕捉。

2.3 标签解码器

LD 的模态融合模块包含顺序连接的 Transformer 解码器层及逐标签投影层，将基因先验与巨幅 WSI 特征联系起来，引导关注关键区域；然后以对比式多标签损失进行突变分类，更好找出全部突变基因。

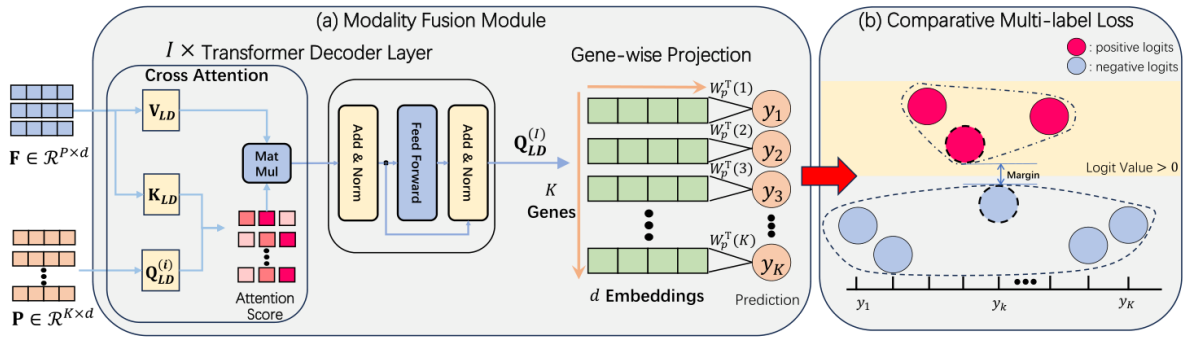


图4 LD 将基因先验 P 与视觉特征 F 整合，使 P 引导多标签分类。(a)MFM 经 Transformer 解码器的交叉注意力获得嵌入 $Q_{\mathrm{LD}}^{(I)}$；逐基因投影把每行与一个独有的可学习列向量相乘，得到对应基因的 logit。(b)多标签损失扩大最难正、负 logits 之间的间隔（红蓝虚线圆），提高判别性；图中以 logit 大于0或不大于0判定正负预测。图内 Margin＝间隔，Cross Attention＝交叉注意力，Embeddings ＝嵌入。

2.3.1 模态融合模块

MFM 包含多个 Transformer 解码器层和逐基因投影层。每层将视觉提取器的细粒度图块特征 F 投影为键和值： $K_{\mathrm{LD}} = FM_K$ 、 $V_{\mathrm{LD}} = FM_V$ ，它们在不同解码器层间共享。GE 输出的先验 P 作为第一层查询矩阵 $Q_{\mathrm{LD}}^{(1)}$ 。第 i 层的交叉注意力输出为

$$\widehat{Q}_{\mathrm{LD}}^{(i+1)} = \mathrm{LN}\left(\mathrm{softmax}\left(\frac{Q_{\mathrm{LD}}^{(i)} K_{\mathrm{LD}}^{\top}}{\sqrt{d}}\right) V_{\mathrm{LD}} + Q_{\mathrm{LD}}^{(i)}\right). \qquad (7)$$

d 是 $\widehat{Q}_{\mathrm{LD}}^{(i)}$ 的列维数，LN 表示层归一化。式(7)通过交叉注意力融合 WSI 特征与基因先验。随后利用跳跃连接及前馈层 FFN 得到解码层输出：

$$Q_{\mathrm{LD}}^{(i+1)} = \mathrm{LN}\left(\mathrm{FFN}\left(\widehat{Q}_{\mathrm{LD}}^{(i+1)}\right) + \widehat{Q}_{\mathrm{LD}}^{(i+1)}\right).$$

各层迭代更新查询：第一层使用 $Q_{\mathrm{LD}}^{(1)}$ ，后续层使用上一层输出。原稿将最后第 I 层输出记为 $Q_{\mathrm{LD}}^{(I)} \in \mathbb{R}^{K\times d}$ 。接着，以逐基因投影预测全部 K 个基因的最终 logits：使用 K 个 $d\times 1$ 可学习向量，将 $Q_{\mathrm{LD}}^{(I)}$ 的每行（一个基因的特征）与一个向量相乘，得到表示该基因突变分数的标量。不同基因对应不同向量，每个向量只负责一个基因的状态。

这样得到 $y \in \mathbb{R}^K$ ，用于第2.3.2节损失计算。最终对 y 应用 sigmoid，得到0到1之间的突变概率向量；给定阈值 β ，如0.5，某元素大于阈值则预测该基因突变，否则预测未突变。

2.3.2 对比式多标签损失

该损失旨在更好地区分所有突变（正）基因与未突变（负）基因。一张 WSI 中可能不止一个基因突变，因此不能直接使用经典单标签分类的 softmax 交叉熵，因为后者每个样本只允许一个正类。这也是常见 MIL 方法为每个基因独立训练二分类器的原因。但如引言所述，该策略需要数百个独立分类器，具有两项缺陷：(1)逐基因预测时，未突变样本通常远多于突变样本，产生不平衡；(2)各类独立计算，忽略类别间相对比较。相比之下，softmax 损失既不引入该形式的不平衡，又内含类别比较[47]。

因此，对比式多标签损失借鉴 softmax 的比较能力，在多标签范式中区分所有突变与未突变基因；还引入间隔，以增强最难正类（真实突变但正类中预测分数最低）与最难负类（反之）的区分：

$$\mathcal{L} = \text{softplus}\left[\log \sum_{n \in \mathcal{N}} e^{y_n} + T \log \sum_{p \in \mathcal{P}} e^{-y_p/T}\right]. \qquad (8)$$

$\text{softplus}(z) = \log(1 + \exp z)$；$\mathcal{N}$ 和 $\mathcal{P}$ 分别表示真实标签 y^* 中未突变的负类与突变的正类。y_n, y_p 是相应预测 logits，两个求和分别对全部负类与正类的指数 logits 求和。T 控制最难正、负 logits 之间间隔的尺度。

译注：原稿这一说明句把 y_n, y_p 对应的“正/负”词序颠倒，且第二个求和的下标曾写成 $n \in \mathcal{P}$；上式及集合定义本身已明确含义，这里按公式解释并披露文字不一致。

式(8)通过 softmax 式的类别比较增强判别性：用全部正 logits 中最难的那个替代单标签 softmax 中的唯一正 logit，并额外引入间隔。log-sum-exp 类似最大值算子，因此第一项寻找预测 logit 最大的负类，第二项寻找预测 logit 最小的正类，即最难负类和正类。损失促使最小正 logit 高于最大负 logit，并具有受超参数 $T > 0$ 控制的间隔，从而提高正负区分能力。另外，它比较不同基因的突变概率，而非独立比较某个基因的突变/未突变概率，因此也可缓解 MIL 中的不平衡问题。

3 实验

3.1 实验设置

3.1.1 数据准备与实现细节

我们在具有挑战性的 TCGA 数据集[48]上评估 BPGT 的基因突变预测表现。挑战在于：(1)WSI 尺寸巨大，宽高通常各为5万至90万像素，且仅有患者级突变标签，难以定位相关区域；(2)TCGA 综合多种癌症的基因组突变信息，每张 WSI 可能有多个突变基因。因此选用它评估模型识别不同癌症相关突变的能力。

为保证癌症与突变的统计意义，选择发病率最高的9种癌症，并按[18]选择每种癌症中突变频率超过1%的基因，构成3,800张 WSI、30个基因的数据集。采用标准五折交叉验证划分训练集和测试集。

BPGT 使用 Python 3.6.5 和 PyTorch 实现，采用 Adam 优化器，学习率 10^{-4}；其余超参数按[49]设置为 $\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$。所有可训练参数以 Xavier 初始化，训练250轮。使用 L2 正则化，权重为 10^{-5}。第3.1.2节所有评估指标均取五折交叉验证结果的平均。

3.1.2 评价指标

为评估各基因的预测，按[9,15,16,18]使用逐类 F1 与逐类 AUC，每类对应一个基因；还使用所有基因的整体 F1 和整体 AUC，综合评价多标签性能。

逐类和整体 AUC。 逐类 AUC 评价各基因突变分类的灵敏度和特异度，是受试者工作特征（ROC）曲线下的面积。ROC 描述不同阈值 β 下真阳性率 TPR 与假阳性率 FPR 的关系； β 是区分突变/未突变的截断值：

$$\mathrm{TPR}(\beta) = \frac{\mathrm{TP}(\beta)}{\mathrm{TP}(\beta) + \mathrm{FN}(\beta)}, \qquad \mathrm{FPR}(\beta) = \frac{\mathrm{FP}(\beta)}{\mathrm{FP}(\beta) + \mathrm{TN}(\beta)}.$$

TP、TN、FP、FN 分别为给定阈值下的真阳性、真阴性、假阳性和假阴性数。把不同阈值对应的 TPR、FPR 看成二维点，即得到 ROC 曲线，其下面积即 AUC。整体 AUC 是所有基因逐类 AUC 的平均。

逐类和整体 F1。 这些指标评价特定阈值下的多标签分类表现，如[50]推荐的0.5。第 i 类的 F1 为

$$F1_i = \frac{2P_iR_i}{P_i + R_i}, \qquad P_i = \frac{TP_i}{TP_i + FP_i}, \qquad R_i = \frac{TP_i}{TP_i + FN_i},$$

P_i, R_i 分别为逐类精确率和召回率。整体精确率、召回率、F1（OP、OR、OF1）定义为

$$OP = \frac{\sum_i TP_i}{\sum_i P_i}, \qquad OR = \frac{\sum_i TP_i}{\sum_i P_i^*}, \qquad OF1 = \frac{2OP \cdot OR}{OP + OR},$$

其中这里的 $P_i = TP_i + FP_i$、 $P_i^* = TP_i + FN_i$。译注：原稿在此复用 P_i 符号，上一个公式表示精确率，本公式表示预测正例数，须按上下文区分。

3.2 整体基因突变预测表现

表1表明，BPGT 在不同视觉提取骨干上均获得较高性能，体现其通用性。每行表示第2.1节不同 VE 骨干的结果，每列给出某基因的 AUC 和 F1，最后两列是跨基因整体性能。例如，Trans-VE 对 TP53 达到74.5% AUC、69.6% F1；Att-VE 和 HIPT 也在各基因获得较高值，正文举例为 TP53 的72.3% AUC、64.9% F1，以及 PTEN 的73.3% AUC、69.1% F1。不同 VE 下整体 OF1 也较高，验证了 BPGT 对不同骨干的有效性。

译注：上一段两组举例沿用原稿正文。原表1的 Att-VE/TP53 F1 是64.4%，不是64.9%；73.3%/69.1% 列在 HIPT/TP53，而非 PTEN。原表数据如下保留，不将文字与表格偷偷改成一致。

表1 不同视觉提取骨干下的 BPGT 突变预测性能。“-VE”表示把参考方法的视觉提取器与本文 GE、LD 组合。表内数值为百分比；基因名括号中的比例沿用原稿。为便于阅读，将原始宽表按基因重排，数值、标准差及方法对应关系不变。

骨干	TP53 (38%) AUC / F1	PIK3CA (22%) AUC / F1
GeneHe-VE[18]	71.6±6.2 / 63.1±4.6	57.2±8.3 / 50.7±5.1
DeepHis-VE[9]	72.2±6.4 / 63.9±4.8	65.8±9.3 / 56.2±5.9
Att-VE[32]	72.3±5.9 / 64.4±3.6	63.7±6.3 / 53.0±5.7
Trans-VE[34]	74.5±5.7 / 69.6±3.6	62.9±6.6 / 55.3±4.3
KAT[36]	72.7±5.3 / 68.3±4.0	66.1±5.8 / 58.9±4.9
HIPT[37]	73.3±6.1 / 69.1±3.7	66.8±6.4 / 60.1±4.7

骨干	PTEN (14%) AUC / F1	KRAS (11%) AUC / F1
GeneHe-VE[18]	66.6±9.7 / 58.7±5.7	65.2±9.2 / 50.4±6.1
DeepHis-VE[9]	72.5±10.7 / 61.5±6.5	77.6±11.3 / 69.1±7.4
Att-VE[32]	62.8±7.7 / 52.7±6.1	72.5±10.3 / 51.1±6.7
Trans-VE[34]	68.3±7.1 / 56.5±5.1	74.5±8.0 / 51.5±6.1
KAT[36]	78.1±6.3 / 73.0±4.7	77.6±7.6 / 53.6±6.3
HIPT[37]	71.2±6.1 / 67.2±5.1	80.9±8.3 / 60.4±7.0

骨干	ARID1A (9%) AUC / F1	EGFR (5%) AUC / F1
GeneHe-VE[18]	57.7±12.7 / 44.2±7.1	57.0±13.9 / 33.9±9.3
DeepHis-VE[9]	69.8±9.8 / 56.8±8.7	70.0±18.1 / 49.1±10.7
Att-VE[32]	52.0±13.9 / 43.7±7.7	73.3±12.3 / 56.1±9.0
Trans-VE[34]	66.9±9.1 / 52.7±7.3	60.4±11.8 / 43.4±9.3
KAT[36]	56.2±12.5 / 48.3±8.1	71.9±14.9 / 48.8±10.5
HIPT[37]	70.8±13.9 / 63.3±9.3	62.6±10.1 / 46.0±10.8

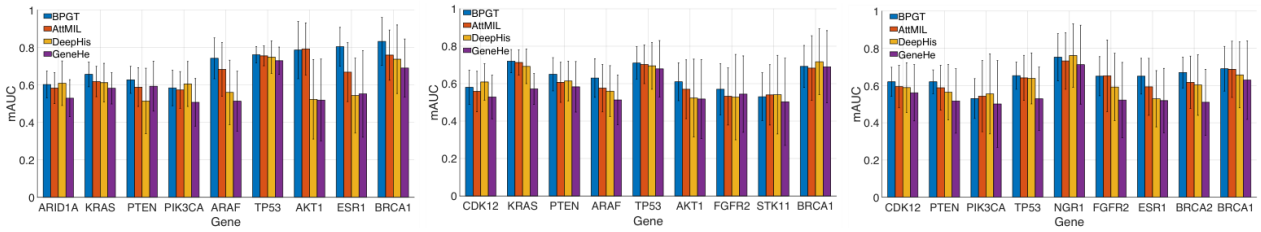
骨干	FGFR2 (3%) AUC / F1	整体 OAUC / OF1
GeneHe-VE[18]	55.3±14.1 / 30.1±11.7	55.2±8.1 / 31.2±0.8
DeepHis-VE[9]	61.2±18.3 / 41.4±12.3	55.4±8.8 / 31.9±0.8
Att-VE[32]	66.9±14.5 / 45.3±11.0	61.2±4.6 / 34.3±0.6
Trans-VE[34]	62.6±12.9 / 41.9±10.9	63.8±4.4 / 36.3±0.5
KAT[36]	57.0±15.8 / 36.3±13.4	60.3±3.3 / 36.1±0.5
HIPT[37]	67.5±11.9 / 44.2±12.9	64.8±5.2 / 36.0±0.5

3.3 与先进方法的比较

为说明竞争力，我们与逐基因二分类方法 GeneHe[18]、DeepHis[9]和 AttMIL[19]比较。注意，“GeneHe”“DeepHis”不同于表1中加“-VE”的骨干：前者直接采用[18,9,19]的方法，为每个关键基因独立训练分类器；后者只取这些方法的视觉提取器，与 BPGT 的 GE、LD 结合，对所有基因做多标签分类。

图5比较不同癌症关键基因的分类：图5(a)、(b)、(c)分别为乳腺癌 BRCA、子宫内膜癌 UCEC、头颈鳞癌 HNSC，以平均 AUC 衡量。BPGT 对几乎所有列出的基因均取得更高平均 AUC。例如 ARID1A 为 60.2%，高于 GeneHe 的52.9%；AKT1 为78.6%，高于 GeneHe 的51.9%，其他基因也呈类似趋势。

BPGT 的 mAUC 标准差也通常低于对比方法，表现更稳定。例如 CDK12 分类中，BPGT 标准差为 0.078，明显低于 AttMIL 的0.114、DeepHis 的0.133、GeneHe 的0.151。TP53、NGR1、FGFR2、ESR1、BRCA2、BRCA1 等也体现领先表现，说明其稳健预测能力及改进 MIL 突变预测的潜力。



(a) Performance Comparison on BRCA. (b) Performance Comparison on UCEC. (c) Performance Comparison on HNSC.

图5 BPGT 与先进方法的比较。不同颜色柱表示各模型在五折交叉验证中、对不同癌症的各基因所获平均 AUC。(a)BRCA；(b)UCEC；(c)HNSC。原图注将 BPGT 拼为 BOGT，本译注说明该排印差异；模型和数据保留原样。纵轴 mAUC，横轴 Gene＝基因。

讨论。 BPGT 的优势来自 GE 创新地结合生物医学和语言知识。两类知识的丰富语境可能带来更稳健、临床相关性更强的预测。KAM 通过 Transformer 图表示学习捕捉突变内在关系，相比不采用综合知识的方法可能具有更精细的理解。最后，对比式多标签损失既改善正负基因区分，又避免对比方法逐基因二分类形式下的不平衡问题。这些构成本文框架相对于类似工作的优势。

3.4 消融研究

3.4.1 基因编码器的影响

语言与生物医学知识的有效性。 首先用 Trans-VE 评估 GG 中两类编码。图6(a)显示，结合全部三类生物医学知识的 BPGT（All）F1 最好，为36.31%，表明联合纳入三类编码有利。图6(b)评估不同 BERT 文本编码，Bio-BERT 的 F1 最高，为36.3%，是所测试策略中最有效者。无论使用哪一种文本编码来获取语言知识，结果均超过不使用语言知识的消融版本。

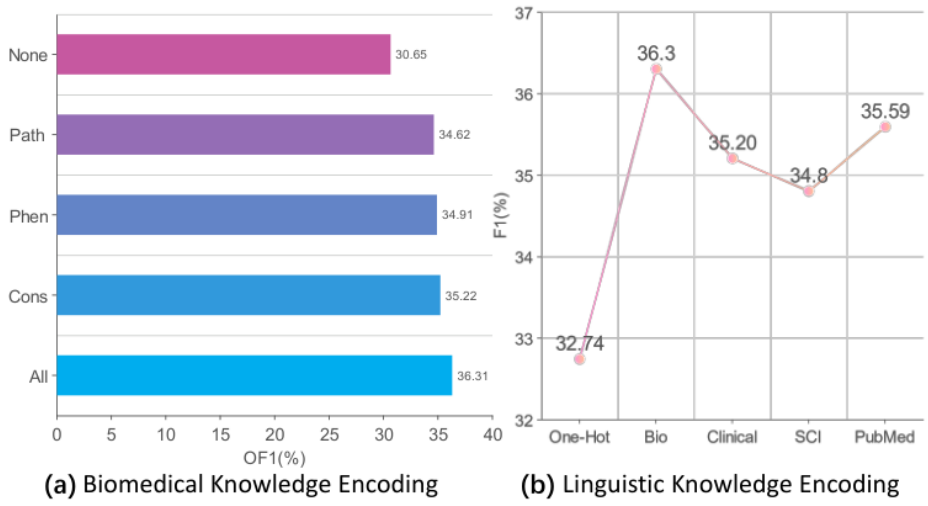


图6 不同知识编码的比较。(a)不使用生物医学编码，以及分别使用通路、表型、一致性编码和全部编码的表现；(b)不同语言编码：独热编码（初始节点为独热标签，不含语言知识）、Bio-BERT[40]、Clinical-BERT[53]、SCI-BERT[54]、PubMed-BERT[55]。指标为整体 F1。图内 None＝无；Path＝通路；Phe＝表型；Cons＝一致性；All＝全部。

KAM 的有效性。 我们比较不进行知识关联（仅以初始 G 为先验，表2第一行）和使用 GCN[46]、Graph Transformer[51]、MCAT[52]等图聚合模块的版本。表2表明，关联语言和生物医学等多模态知识有益，KAM 在所有视觉骨干上优于其他关联方式。不关联知识一行最低，说明关联的重要性。以 Trans-VE 为例，KAM 为36.3%±0.5，而次优 Graph Transformer 为32.7%±0.7。

多数比较具有统计显著性，† 表示 Student t 检验 $p < 0.005$ 。在 GeneHe-VE、DeepHis-VE 等少数情况中，KAM 增益不那么显著，虽然平均 OF1 仍更高。原因可能是这两种编码器仅用部分图块，视觉信息不足，限制基因先验作用；充分利用所有 WSI 图块时，KAM 优势更明显。总体上，KAM 的 Transformer 图表示学习式多模态知识关联优于消融版本。

表2 KAM 与不同图聚合模块的消融比较。数值为整体 F1（%）的均值±标准误；† 表示与 KAM 比较具有统计显著性（$p < 0.005$ ）。

方法	GeneHe-VE	DeepHis-VE	Att-VE
无 KAM	25.3±1.5 †	24.8±0.8 †	25.9±1.0 †
GCN[46]	30.6±0.8	30.1±0.8 †	29.6±0.7 †
Graph Transformer[51]	31.0±0.9	31.6±1.0	30.3±0.8 †
MCAT[52]	30.8±0.8	30.7±0.8 †	31.6±0.6 †
KAM（本文）	31.2±0.8	31.9±0.8	34.3±0.6

方法	Trans-VE	KAT	HIPT
无 KAM	27.3±1.2†	27.1±1.2†	28.3±0.9†
GCN[46]	32.3±0.6†	32.9±0.5†	34.1±0.5†
Graph Transformer[51]	32.7±0.7†	34.7±0.6†	35.4±0.6†
MCAT[52]	32.5±0.5†	33.2±0.5†	34.4±0.7†
KAM（本文）	36.3±0.5	36.4±0.5	36.0±0.5

译注：原表1中 KAT 的 OF1 为36.1±0.5，原表2中 KAM/KAT 为36.4±0.5；两处数值分别照录，不推断哪一处应更正。

讨论。 语言和生物医学知识提供互补基因信息，提高特征判别性并改善突变预测。图7用 t-SNE 将不同知识构成的先验投到二维，右上数值是相应模型的 OF1。仅独热编码、不含两类知识时（a）为27.93%；仅语言知识 LK（b）为30.65%；仅生物医学知识 BK（c）为32.74%；两者结合（d）最高，为36.31%。

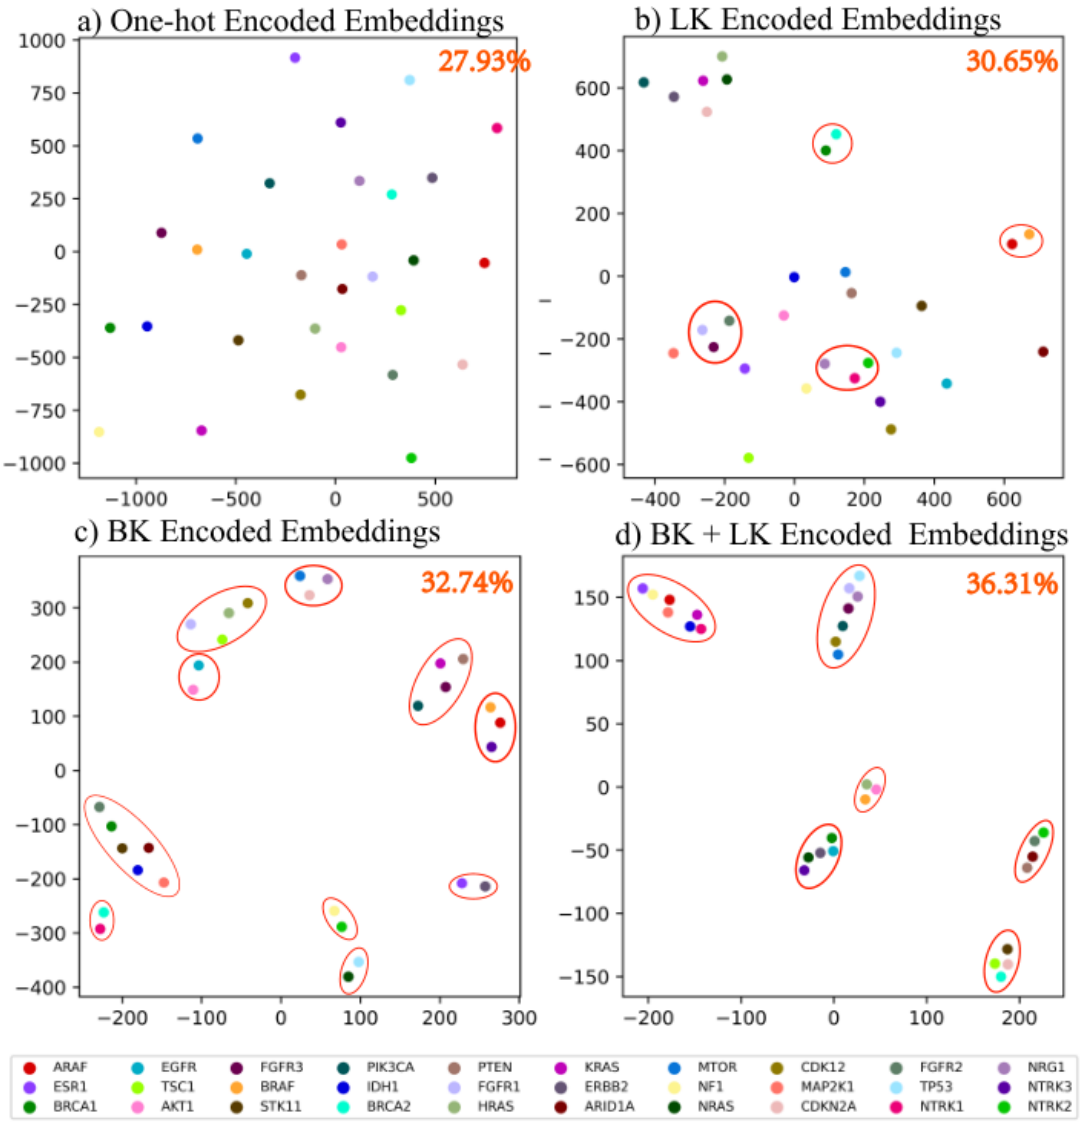


图7 基因先验中语言与生物医学知识的效果可视化。t-SNE 将先验投影到二维。(a)独热；(b)LK；(c)BK；(d)BK+LK。随着引入更多知识，OF1 提高，功能相近的基因如 AKT1、BRAF、HRAS 更倾向聚集。原图注写作 ATK1，正文写作 AKT1；此处说明差异。

比较图7(a)、(b)，引入 LK 可能捕捉基因功能、交互和调控，使语言上有关联的基因靠近，无关基因分开。例如，BRCA1、BRCA2 因共享“BRC”命名成分而聚类；ARAF、BRAF 分别具有“A-Raf Proto-Oncogene”“B-Raf Proto-Oncogene”等相近命名，也聚在一起。比较(a)、(c)，BK 则引入生物医学研究中的基因–疾病关联、通路参与等经验信息，提升 OF1。例如 ESR1、ERBB2 突变都与乳腺癌密切相关，并参与“癌症中的 PI3K/AKT 信号”“RNA聚合酶II转录”“受体酪氨酸激酶信号”等多个通路。

与(b)、(c)相比，协同结合 BK 与 LK 的(d)聚类更显著，OF1 最高。例如原稿指出，AKT1、BRAF、HRAS 的摘要分别涉及蛋白激酶B、B-Raf激酶、GTPase HRas，语言上相近；它们在功能上也都参与“生长因子受体和第二信使介导的信号转导疾病”“致癌 MAPK 信号”“高激酶活性 BRAF 突变体信号”等通路。这说明两类知识结合可能提供更全面的基因表征，使功能相关基因聚集，提高下游特征判别性，改善突变预测及 OF1。

3.4.2 标签解码器的影响

针对 LD，分别消融 MFM 和对比式多标签损失，结果见表3。

表3 标签解码器组件的消融，视觉骨干为 Trans-VE[34]。结果为五折交叉验证均值±标准差。

架构	参数量	OF1（%）
无模态融合模块	2,507,258	28.33±1.80
无多标签损失	2,902,970	23.37±0.59
BPGT	2,902,970	36.38±0.53

MFM 的有效性。 这一消融直接通过矩阵操作融合特征，替代 MFM，再调整为 $K\times1$ 输出 logits。MFM 将 OF1 从28.33%提升到36.38%，标准差从1.80%降到0.53%。它带来约8个百分点提升，却没有显著增加网络总参数量，显示在 Transformer 框架中聚合视觉和文本信息的优势。下文会说明，MFM 有助于捕捉注意力图中的关键区域，利用最有信息的视觉特征预测突变。

对比式多标签损失的有效性。 将该损失替换为二元交叉熵（BCE），保持学习率和训练策略一致。表3显示，采用对比式损失，OF1 从23.37%升到36.38%，标准差从0.59%降到0.53%，不改变模型容量，却获得13.01个百分点增益，说明它的关键作用。BCE 对每个基因独立比较正负 logits，而本文损失利用 softmax 内在的跨基因比较。这一差异使其自然缓解 BCE 形式下的不平衡，增强 BPGT 正负类判别能力。

巨幅WSI的注意力图。 我们可视化 LD 最后交叉注意力层，展示基因先验如何引导模型关注关键视觉特征。LD 能综合 GE 提取的多模态信息，聚焦巨幅 WSI 中与突变相关的区域。图示还表明，基因先验能捕捉不同形态特征：图8(a)用红框标记不同癌症肿瘤区域；图8(b)高注意力区与之高度一致，尽管 BPGT 并不知道这些红框。这说明模型自动关注了肿瘤组织，LD 帮助识别了突变与肿瘤区域的潜在关系。

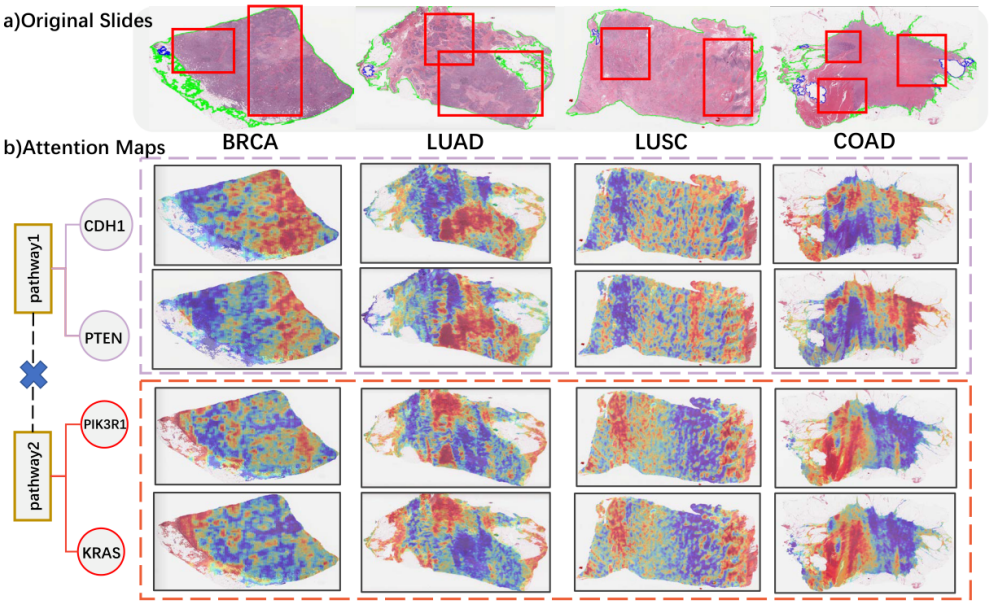


图8 注意力可视化显示，功能相关基因会突出巨幅 WSI 中相似区域。(a)不同癌症患者的原始切片，红框为肿瘤；(b)两个通路中的四个基因。原图注称 CDH1、PTEN 属于通路1，PIK3CA、KRAS 属于通路2。相同通路基因关注区域高度相似，且与(a)肿瘤区对齐，支持 LD 利用先验寻找突变相关区域。原图中基因标签写 PIK3R1，图注与正文写 PIK3CA；本译本保留原图并明确该差异。图内 Original Slides＝原始切片，Attention Maps＝注意力图。

进一步看功能相关、即同通路基因，它们关注相似区域；不相关、不同通路基因则关注不同区域。例如图8(b)第一列中，通路1的 CDH1、PTEN 关注相同 WSI 区域，而与通路2的 PIK3CA、KRAS 所强调区域有明显区别。这表明 LD 利用功能关联等先验，找到了与突变高度相关的视觉特征。

讨论。 两项设计使 BPGT 获得更高性能，而不过度增加参数。MFM 仅增加约14%参数，对比式损失不改变参数数目，却分别带来8.05和13.01个百分点 OF1 提升。这说明它们能够有效融合生物先验与视觉特征，并提高突变/未突变基因的判别能力。LD 中视觉特征与先验的融合，还促使注意力图与肿瘤区域对齐，使视觉特征连接到底层遗传信息。这些观察提示，BPGT 有潜力识别基因突变与组织病理特征间的潜在关系。

4 结论

据我们所知，BPGT 首次设计多标签分类范式用于基因突变预测。GE 通过新型 Transformer 图表示学习，表明标签内生物医学与语言知识的结合有助于探索基因间突变关系。LD 采用 Transformer 模态融合和对比式多标签损失，表明巨幅 WSI 与遗传信息之间的潜在关系有益于预测，而引入类别比较可更好区分突变与未突变基因。

实验显示，各项设计能综合提升预测表现，并优于当时先进模型。这项工作可能是充分利用基因组学内在知识、改进患者病理图像突变预测的重要一步。代码实现地址：https://github.com/gexinh/BPGT.git 。

参考文献

保留原稿作者、题名与出版信息，另附中文题名，便于检索。

[1] M. Y. Lu, T. Y. Chen, D. F. Williamson, M. Zhao, M. Shady, J. Lipkova, and F. Mahmood, “Ai-based pathology predicts origins for cancers of unknown primary,” Nature, vol. 594, no. 7861, pp. 106–110, 2021.
中文题名：基于人工智能的病理分析预测原发部位不明癌症的起源。

[2] Y. Fu, A. W. Jung, R. V. Torne, S. Gonzalez, H. Vöhringer, A. Shmatko, L. R. Yates, M. Jimenez-Linan, L. Moore, and M. Gerstung, “Pan-cancer computational histopathology reveals mutations, tumor composition and prognosis,” Nature Cancer, vol. 1, no. 8, pp. 800–810, 2020.
中文题名：泛癌计算组织病理揭示突变、肿瘤组成和预后。

[3] Z. Ning, Z. Zhao, Q. Feng, W. Chen, Q. Xiao, and Y. Zhang, “Mutual-assistance learning for standalone mono-modality survival analysis of human cancers,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 6, pp. 7577–7594, 2023.
中文题名：面向人类癌症独立单模态生存分析的互助学习。

[4] D. Di, C. Zou, Y. Feng, H. Zhou, R. Ji, Q. Dai, and Y. Gao, “Generating hypergraph-based high-order representations of whole-slide histopathological images for survival prediction,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 5, pp. 5800–5815, 2023.
中文题名：基于超图生成全切片组织病理图像高阶表示用于生存预测。

[5] J. N. Kather, A. T. Pearson, N. Halama, D. Jäger, J. Krause, S. H. Loosen, A. Marx, P. Boor, F. Tacke, U. P. Neumann et al., “Deep learning can predict microsatellite instability directly from histology in gastrointestinal cancer,” Nature medicine, vol. 25, no. 7, pp. 1054–1056, 2019.
中文题名：深度学习可直接由胃肠道癌组织学预测微卫星不稳定性。

[6] F. Martínez-Jiménez, F. Muiños, I. Sentís, J. Deu-Pons, I. Reyes-Salazar, C. Arnedo-Pac, L. Mularoni, O. Pich, J. Bonet, H. Kranas et al., “A compendium of mutational cancer driver genes,” Nature Reviews Cancer, vol. 20, no. 10, pp. 555–572, 2020.
中文题名：突变性癌症驱动基因汇编。

[7] J. Shia, N. Schultz, D. Kuk, E. Vakiani, S. Middha, N. H. Segal, J. F. Hechtman, M. F. Berger, Z. K. Stadler, M. R. Weiser et al., “Morphological characterization of colorectal cancers in the cancer genome atlas reveals distinct morphology–molecular associations: clinical and biological implications,” Modern Pathology, vol. 30, no. 4, pp. 599–609, 2017.
中文题名：TCGA结直肠癌的形态学分析揭示不同形态–分子关联及临床生物学意义。

[8] J. Mateo, L. Steuten, P. Aftimos, F. André, M. Davies, E. Garralda, J. Geissler, D. Husereau, I. Martinez-Lopez, N. Normanno et al., “Delivering precision oncology to patients with cancer,” Nature Medicine, vol. 28, no. 4, pp. 658–665, 2022.
中文题名：将精准肿瘤学服务提供给癌症患者。

[9] J. N. Kather, L. R. Heij, H. I. Grabsch, C. Loeffler, A. Echle, H. S. Muti, J. Krause, J. M. Niehues, K. A. Sommer, P. Bankhead et al., “Pan-cancer image-based detection of clinically actionable genetic alterations,” Nature Cancer, vol. 1, no. 8, pp. 789–799, 2020.
中文题名：基于泛癌图像检测具有临床可操作性的基因改变。

[10] K. Chan and D. A. Gordenin, “Clusters of multiple mutations: incidence and molecular mechanisms,” Annual Review of Genetics, vol. 49, pp. 243–267, 2015.
中文题名：多重突变簇的发生与分子机制。

[11] Z. R. Chalmers, C. F. Connelly, D. Fabrizio, L. Gay, S. M. Ali, R. Ennis, A. Schrock, B. Campbell, A. Shlien, J. Chmielecki et al., “Analysis of 100,000 human cancer genomes reveals the landscape of tumor mutational burden,” Genome Medicine, vol. 9, pp. 1–14, 2017.
中文题名：十万人类癌症基因组分析揭示肿瘤突变负荷图景。

[12] L. Schneider, S. Laiouar-Pedari, S. Kuntz, E. Krieghoff-Henning, A. Hekler, J. N. Kather, T. Gaiser, S. Froehling, and T. J. Brinker, “Integration of deep learning-based image analysis and genomic data in cancer pathology: A systematic review,” European Journal of Cancer, vol. 160, pp. 80–91, 2022.
中文题名：癌症病理中深度学习图像分析与基因组数据整合的系统综述。

[13] G. Karlebach and R. Shamir, “Modelling and analysis of gene regulatory networks,” Nature Reviews Molecular Cell Biology, vol. 9, no. 10, pp. 770–780, 2008.
中文题名：基因调控网络的建模与分析。

[14] S. K. Mohamed, A. Nounu, and V. Nováček, “Biological applications of knowledge graph embedding models,” Briefings in Bioinformatics, vol. 22, no. 2, pp. 1679–1693, 2021.
中文题名：知识图谱嵌入模型的生物学应用。

[15] B. Guo, X. Li, M. Yang, H. Zhang, and X. S. Xu, “A robust and lightweight deep attention multiple instance learning algorithm for predicting genetic alterations,” Computerized Medical Imaging and Graphics, vol. 105, p. 102189, 2023.
中文题名：用于预测基因改变的稳健轻量级深度注意力多示例学习算法。

[16] Z. Chen, X. Li, M. Yang, H. Zhang, and X. S. Xu, “Optimization of deep learning models for the prediction of gene mutations using unsupervised clustering,” The Journal of Pathology: Clinical Research, vol. 9, no. 1, pp. 3–17, 2023.
中文题名：利用无监督聚类优化基因突变预测深度学习模型。

[17] S. Li, Y. Zhao, J. Zhang, T. Yu, J. Zhang, and Y. Gao, “Highorder correlation-guided slide-level histology retrieval with selfsupervised hashing,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 9, pp. 11 008–11 023, 2023.
中文题名：高阶相关性引导的自监督哈希切片级组织学检索。

[18] H. Qu, M. Zhou, Z. Yan, H. Wang, V. K. Rustgi, S. Zhang, O. Gevaert, and D. N. Metaxas, “Genetic mutation and biological pathway prediction based on whole slide images in breast carcinoma using deep learning,” NPJ Precision Oncology, vol. 5, no. 1, pp. 1–11, 2021.
中文题名：利用深度学习基于乳腺癌全切片图像预测基因突变和生物通路。

[19] O. L. Saldanha, C. M. Loeffler, J. M. Niehues, M. van Treeck, T. P. Seraphin, K. J. Hewitt, D. Cifci, G. P. Veldhuizen, S. Ramesh, A. T. Pearson et al., “Self-supervised attention-based deep learning for pan-cancer mutation prediction from histopathology,” NPJ Precision Oncology, vol. 7, no. 1, p. 35, 2023.
中文题名：自监督注意力深度学习用于组织病理泛癌突变预测。

[20] M. Ali, M. Berrendorf, C. T. Hoyt, L. Vermue, M. Galkin, S. Sharifzadeh, A. Fischer, V. Tresp, and J. Lehmann, “Bringing light into the dark: A large-scale evaluation of knowledge graph embedding models under a unified framework,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 12, pp. 8825–8845, 2022.
中文题名：照亮黑暗：统一框架下知识图谱嵌入模型的大规模评估。

[21] T. H. Chan, F. J. Cendra, L. Ma, G. Yin, and L. Yu, “Histopathology whole slide image analysis with heterogeneous graph representation learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 15 661–15 670.
中文题名：利用异构图表示学习分析组织病理全切片图像。

[22] Y. Li, Y. Shen, J. Zhang, S. Song, Z. Li, J. Ke, and D. Shen, “A hierarchical graph v-net with semi-supervised pre-training for histological image based breast cancer classification,” IEEE Transactions on Medical Imaging, vol. 42, no. 12, pp. 3907–3918, 2023.
中文题名：具有半监督预训练的层次图V网络用于组织学乳腺癌分类。

[23] C. Mao, L. Yao, and Y. Luo, “Imagegcn: Multi-relational image graph convolutional networks for disease identification with chest x-rays,” IEEE Transactions on Medical Imaging, vol. 41, no. 8, pp. 1990–2003, 2022.
中文题名：ImageGCN：用于胸片疾病识别的多关系图像图卷积网络。

[24] X. Yu, S.-H. Wang, and Y.-D. Zhang, “Cgnet: A graph-knowledge embedded convolutional neural network for detection of pneumonia,” Information Processing & Management, vol. 58, no. 1, p. 102411, 2021.
中文题名：CGNet：嵌入图知识的卷积网络用于肺炎检测。

[25] D. Cifci, S. Foersch, and J. N. Kather, “Artificial intelligence to identify genetic alterations in conventional histopathology,” The Journal of Pathology, vol. 257, no. 4, pp. 430–444, 2022.
中文题名：利用人工智能在常规组织病理中识别基因改变。

[26] Y. Zhao, F. Yang, Y. Fang, H. Liu, N. Zhou, J. Zhang, J. Sun, S. Yang, B. Menze, X. Fan et al., "Predicting lymph node metastasis using histopathological images based on multiple instance learning with deep graph convolution," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 4837–4846.
中文题名：基于深度图卷积多示例学习利用组织病理图像预测淋巴结转移。

[27] K. Ding, Q. Liu, E. Lee, M. Zhou, A. Lu, and S. Zhang, "Featureenhanced graph networks for genetic mutational prediction using histopathological images in colon cancer," in International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2020, pp. 294–304.
中文题名：用于结肠癌组织病理图像突变预测的特征增强图网络。

[28] M. Li, P.-Y. Huang, X. Chang, J. Hu, Y. Yang, and A. Hauptmann, "Video pivoting unsupervised multi-modal machine translation," IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.
中文题名：以视频为枢纽的无监督多模态机器翻译。

[29] M. Y. Lu, D. F. Williamson, T. Y. Chen, R. J. Chen, M. Barbieri, and F. Mahmood, "Data-efficient and weakly supervised computational pathology on whole-slide images," Nature Biomedical Engineering, vol. 5, no. 6, pp. 555–570, 2021.
中文题名：全切片图像上数据高效的弱监督计算病理学。

[30] R. J. Chen and R. G. Krishnan, "Self-supervised vision transformers learn visual concepts in histopathology," Learning Meaningful Representations of Life, NeurIPS, 2022.
中文题名：自监督视觉Transformer学习组织病理视觉概念。

[31] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," Advances in Neural Information Processing Systems, vol. 30, 2017.
中文题名：注意力就是你所需要的。

[32] M. Ilse, J. Tomczak, and M. Welling, "Attention-based deep multiple instance learning," in International Conference on Machine Learning, 2018, pp. 2127–2136.
中文题名：基于注意力的深度多示例学习。

[33] H. Zhang, I. Goodfellow, D. Metaxas, and A. Odena, "Selfattention generative adversarial networks," in International Conference on Machine Learning. PMLR, 2019, pp. 7354–7363.
中文题名：自注意力生成对抗网络。

[34] Z. Shao, H. Bian, Y. Chen, Y. Wang, J. Zhang, X. Ji et al., "Transmil: Transformer based correlated multiple instance learning for whole slide image classification," Advances in Neural Information Processing Systems, vol. 34, pp. 2136–2147, 2021.
中文题名：TransMIL：用于全切片分类的Transformer相关多示例学习。

[35] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly et al., “An image is worth 16x16 words: Transformers for image recognition at scale,” in International Conference on Learning Representations, 2020.
中文题名：一幅图像胜过16×16个词：规模化图像识别的Transformer。

[36] Y. Zheng, J. Li, J. Shi, F. Xie, and Z. Jiang, “Kernel attention transformer for histopathology whole slide image classification,” in International Conference on Medical Image Computing and ComputerAssisted Intervention, 2022, pp. 283–292.
中文题名：用于组织病理全切片分类的核注意力Transformer。

[37] R. J. Chen, C. Chen, Y. Li, T. Y. Chen, A. D. Trister, R. G. Krishnan, and F. Mahmood, “Scaling vision transformers to gigapixel images via hierarchical self-supervised learning,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 16 144–16 155.
中文题名：通过层次自监督学习将视觉Transformer扩展到十亿像素图像。

[38] Y. Zheng, S. Pan, V. Lee, Y. Zheng, and P. S. Yu, “Rethinking and scaling up graph contrastive learning: An extremely efficient approach with group discrimination,” Advances in Neural Information Processing Systems, vol. 35, pp. 10 809–10 820, 2022.
中文题名：重新思考并扩展图对比学习：基于分组判别的极高效方法。

[39] Y. Shibata, T. Kida, S. Fukamachi, M. Takeda, A. Shinohara, T. Shinohara, and S. Arikawa, “Byte pair encoding: A text compression scheme that accelerates pattern matching,” 1999.
中文题名：字节对编码：加速模式匹配的文本压缩方案。

[40] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C. H. So, and J. Kang, “Biobert: a pre-trained biomedical language representation model for biomedical text mining,” Bioinformatics, vol. 36, no. 4, pp. 1234– 1240, 2020.
中文题名：BioBERT：用于生物医学文本挖掘的预训练语言表示模型。

[41] L. B. Alexandrov, J. Kim, N. J. Haradhvala, M. N. Huang, A. W. Tian Ng, Y. Wu, A. Boot, K. R. Covington, D. A. Gordenin, E. N. Bergstrom et al., “The repertoire of mutational signatures in human cancer,” Nature, vol. 578, no. 7793, pp. 94–101, 2020.
中文题名：人类癌症突变特征谱。

[42] N. Parmar, A. Vaswani, J. Uszkoreit, L. Kaiser, N. Shazeer, A. Ku, and D. Tran, “Image transformer,” in International Conference on Machine Learning, 2018, pp. 4055–4064.
中文题名：图像Transformer。

[43] V. K. Ramanan, L. Shen, J. H. Moore, and A. J. Saykin, “Pathway analysis of genomic data: concepts, methods, and prospects for future development,” TRENDS in Genetics, vol. 28, no. 7, pp. 323– 332, 2012.
中文题名：基因组数据的通路分析：概念、方法与发展前景。

[44] M. Gillespie, B. Jassal, R. Stephan, M. Milacic, K. Rothfels, A. SenffRibeiro, J. Griss, C. Sevilla, L. Matthews, C. Gong et al., “The reactome pathway knowledgebase 2022,” Nucleic Acids Research, vol. 50, no. D1, pp. D687–D692, 2022.
中文题名：Reactome通路知识库2022。

[45] T. Zhou, J. Ren, M. Medo, and Y.-C. Zhang, “Bipartite network projection and personal recommendation,” Physical Review E, vol. 76, no. 4, p. 046115, 2007.
中文题名：二部网络投影与个性化推荐。

[46] T. N. Kipf and M. Welling, “Semi-supervised classification with graph convolutional networks,” in International Conference on Learning Representations, 2017.
中文题名：利用图卷积网络进行半监督分类。

[47] Y. Sun, C. Cheng, Y. Zhang, C. Zhang, L. Zheng, Z. Wang, and Y. Wei, “Circle loss: A unified perspective of pair similarity optimization,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 6398–6407.
中文题名：Circle Loss：成对相似度优化的统一视角。

[48] C. Kandoth, M. D. McLellan, F. Vandin, K. Ye, B. Niu, C. Lu, M. Xie, Q. Zhang, J. F. McMichael, M. A. Wyczalkowski et al., “Mutational landscape and significance across 12 major cancer types,” Nature, vol. 502, no. 7471, pp. 333–339, 2013.
中文题名：十二种主要癌症的突变图景及意义。

[49] Z. Zhang, “Improved adam optimizer for deep neural networks,” in 2018 IEEE/ACM 26th International Symposium on Quality of Service (IWQoS). Ieee, 2018, pp. 1–2.
中文题名：面向深度神经网络的改进Adam优化器。

[50] F. Zhu, H. Li, W. Ouyang, N. Yu, and X. Wang, “Learning spatial regularization with image-level supervisions for multi-label image classification,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017, pp. 5513–5522.
中文题名：利用图像级监督学习多标签图像分类的空间正则化。

[51] V. P. Dwivedi and X. Bresson, “A generalization of transformer networks to graphs,” in the Association for the Advancement of Artificial Intelligence, 2020.
中文题名：Transformer网络向图的推广。

[52] R. J. Chen, M. Y. Lu, W.-H. Weng, T. Y. Chen, D. F. Williamson, T. Manz, M. Shady, and F. Mahmood, “Multimodal co-attention transformer for survival prediction in gigapixel whole slide images,” in Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, pp. 4015–4025.
中文题名：用于巨幅全切片图像生存预测的多模态协同注意力Transformer。

[53] E. Alsentzer, J. R. Murphy, W. Boag, W.-H. Weng, D. Jin, T. Naumann, and M. McDermott, “Publicly available clinical BERT embeddings,” in Proceedings of the Clinical Natural Language Processing Workshop, 2019, pp. 72–78.
中文题名：公开可用的临床BERT嵌入。

[54] I. Beltagy, K. Lo, and A. Cohan, “SciBERT: A pretrained language model for scientific text,” in Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2019, pp. 3615–3620.
中文题名：SciBERT：面向科学文本的预训练语言模型。

[55] Y. Peng, S. Yan, and Z. Lu, “Transfer learning in biomedical natural language processing: An evaluation of bert and elmo on ten benchmarking datasets,” in Proceedings of the Biomedical Natural Language Processing Workshop, 2019.
中文题名：生物医学自然语言处理中的迁移学习：在十个基准集上评估BERT和ELMo。

作者简介

以下均为2024年原稿中的作者简介，未据此核实当前任职；肖像未转载。

Gexin Huang 是不列颠哥伦比亚大学电气与计算机工程系博士生，曾任中山大学研究助理。2021年获华南理工大学模式识别与智能系统硕士学位。研究兴趣包括医学影像分析、图表示学习和贝叶斯深度学习。

Chenfei Wu 是中山大学肿瘤防治中心放射肿瘤科医师，获该中心医学博士学位，专长为头颈癌和胸部肿瘤的诊疗。研究主要关注医学人工智能和机器学习在放疗与肿瘤学中的应用。

Mingjie Li 是斯坦福大学放射肿瘤学部门博士后研究员，2023年获悉尼科技大学博士学位。研究兴趣包括机器学习、医学人工智能、计算机视觉，尤其是医学视觉与语言对齐。

Shen Zhao 于2015年获清华大学博士学位，研究医学图像分析中的深度学习方法，包括目标检测/分割、度量学习、深度主动轮廓，以及视觉和语言信息在医学影像诊断中的结合。

Xiaojun Chang（IEEE 高级会员）是悉尼科技大学澳大利亚人工智能研究所教授。此前任澳大利亚 RMIT 大学计算技术学院副教授。主要研究从非受控或监控视频中利用多种信号进行自动内容分析，并在多项国际竞赛取得领先成绩。

Ling Chen 是悉尼科技大学澳大利亚人工智能研究所教授，博士毕业于新加坡南洋理工大学。研究领域为机器学习与数据挖掘，近期关注复杂结构数据异常检测、各类数据的哈希与表示学习，以及基于文本的交互系统中的强化学习。

Ying Sun 是中山大学肿瘤防治中心放射肿瘤学教授、副院长。主要研究鼻咽癌个体化与精准治疗，尤其是人工智能辅助放疗、大数据驱动风险分层，以及开发预后和预测标志物的转化研究。

Xiaodan Liang 是中山大学副教授，曾在卡内基梅隆大学担任项目科学家，与 Eric Xing 教授合作。2016年获中山大学博士学位。已在图神经网络、深度推理、结构预测、目标检测等领域发表80余篇前沿论文，发表于本领域重要期刊会议，Google引用超过6000次。曾任 ICCV 2019、CVPR 2020领域主席

和 CVPR 2021教程主席；主持 CVPR 2019“迈向因果、可解释与通用医学视觉诊断”研讨会，以及 ACM MM 2018“像素级理解的结构化深度学习”教程。获 ACM 中国及 CCF 优秀博士学位论文奖，以及阿里巴巴达摩院青橙奖。原稿将 ACM China 拼作 ACM Chine。

Liang Lin 是中山大学教授，2016至2018年任商汤集团执行研发总监及杰出科学家，负责前沿技术产品转化。在重要学术期刊会议发表或共同发表200余篇论文，担任 IEEE Transactions on Human-Machine Systems、IET Computer Vision 编委，以及 CVPR、ICCV、IJCAI 等会议领域主席。所获荣誉包括吴文俊人工智能奖、2019年 ICCV 最佳论文提名、2018年 Pattern Recognition 年度最佳论文、2017年 IEEE ICME 最佳论文钻石奖、2012年 Google Faculty Award。他是 IET Fellow。原稿标题作者行另列其为 IEEE Fellow，按各处原文保留。