自适应且具备数据韧性的多模态层次多标签图书体裁识别

Adaptive Data-Resilient Multi-Modal Hierarchical Multi-Label Book Genre Identification

作者： Utsav Kumar Nareti、Soumi Chattopadhyay、Prolay Mallick、Suraj Kumar、Chandranath Adak、Ayush Vikas Daga、Adarsh Wase、Arjab Roy

U. K. Nareti 和 C. Adak 任职于印度理工学院巴特那分校计算机科学与工程系；S. Chattopadhyay、P. Mallick 和 S. Kumar 任职于印度理工学院印多尔分校计算机科学与工程系；A. V. Daga 任职于印度 SVNIT；A. Wase 任职于印度理工学院印多尔分校和印度管理学院印多尔分校；A. Roy 任职于印度信息技术学院古瓦哈提分校人文与社会科学系。通讯作者：C. Adak、S. Chattopadhyay。

来源、许可与译制说明。 本文为非官方中文翻译，依据 arXiv:2505.03839v2，原文日期为2025年10月18日；主文原稿10页，已核对与提供的论文PDF完全一致。主文以 Creative Commons Attribution 4.0 International 许可发布；作者署名和来源保留。译制改动包括中文翻译、单栏重排、表格拆分和公式重排；不代表原作者认可此译文。译制日期：2026年10月26日。

第三方素材边界。 论文许可不应被视为对第三方书封、封面文字摘录和出版简介的额外授权。本译本省略图1的书封及引述简介、图2左侧的第三方输入示例、表IV的书封及引述简介；保留完整作者图注、分析、书目事实和实验结果。图2保留可分离的算法图，图3–5保留作者绘制的统计图。各处列明省略内容并链接原文，未声称所有图像均已复现。补充文件的来源及许可范围另见文末说明。

摘要

识别细粒度图书体裁对于通过高效发现、个性化推荐和提升读者参与度来改善用户体验至关重要。同时，它为出版商和营销人员提供了有关消费者偏好与新兴市场趋势的宝贵洞见。传统体裁分类方法主要依赖文本评论或内容分析，而纳入书封、图书简介和元数据等额外模态，可以提供更丰富的上下文线索。然而，多模态系统的效果往往受到各模态中不完整、含噪或缺失数据的阻碍。为解决这一问题，我们提出 IMAGINE（Intelligent Multi-modal Adaptive Genre Identification NEtwork，智能多模态自适应体裁识别网络），这一框架旨在利用多模态数据，同时对信息缺失或不可靠的情况保持稳健。IMAGINE 学习模态特定的特征表示，并在推理时自适应地优先利用可用信息源中信息量最大的来源。它进一步采用以人工整理的图书体裁分类体系为基础的层次分类策略，以捕捉体裁间关系，并支持反映现实文学多样性的多标签赋值。IMAGINE 的一大优势是其适应能力：即使文本或图像等某一模态不可用，它仍能维持较高的预测性能。我们还整理了一个大规模层次数据集，将图书体裁组织为多个粒度层级，从而能够进行更全面的评估。实验结果表明，IMAGINE 在多种设置下优于强基线，并在特定模态数据不完整的情形下取得显著提升。

关键词： 层次分类；多标签分类；多模态分类；自适应学习。

I 引言

在数字媒体领域，准确的图书体裁分类是有效推荐的核心，能够提升文学平台上的用户体验和参与度。它使读者能够发现符合个人偏好的图书，并为出版商和营销人员提供消费者行为、内容策展和定向营销方面的洞见。通过细化分类，基于体裁的推荐丰富了用户交互，并支持图书生产、推广和发行中的明智决策[1]。电子书与数字阅读的兴起进一步改变了出版业，使通过 Goodreads 和 Amazon Kindle 等平台面向全球发行成为可能[2]。

这种扩展虽然提高了可获取性，也带来了浏览海量数字图书馆的挑战，使人工分类难以实施，并凸显了自动体裁识别的必要性。Goodreads 通过用户自建书架来解决这一问题，但这种方式依赖不可靠的评论，在没有评论时无法奏效，而且经常产生不规范的标签，例如有声书、纸质书等图书形式标签，或相互冲突的标签，例如虚构与非虚构。此外，它缺少层次结构，限制了在宽泛与细粒度体裁间的组织能力。

图1：内容不一致的示例。 (a) 信息不足的简介；(b) 不相关的简介；(c) 封面提供的视觉线索极少。

> **素材省略说明：** 图1(a)–(c)的第三方书封与引述简介未复制。书目事实分别为：(a)作者 Norman Bridwell，出版社 Scholastic；(b)作者 Francine Pascal，出版社 Bantam Books；(c)作者 C. S. Lewis，出版社 MacMillan。原始面板见版本固定的原文第1页。

尽管自动图书体裁分类很重要，它仍未得到充分研究。既有研究主要依赖描述[3]、[4]或封面图像[5]、[6]等单一模态。一些多模态方法将元数据与封面图像结合[7]、[8]，但准确率通常较低，并忽视了对细致体裁关系至关重要的层次结构。如图1所示，图书可能只有极简描述、稀疏元数据，或缺乏有效信息的封面。这些局限凸显了建立全面多模态框架的必要性：整合封面图像、简介与元数据来实现结构化体裁识别，进而增强推荐系统和用户体验。

既有工作[9]的另一不足是依赖不一致的用户评论或标签。为克服这一问题，我们构建了一个多模态数据集，汇集封面图像、简介、元数据和通过 OCR 提取的封面文字等可靠来源。不同于完全依赖众包标签的数据集，我们的数据集采用经专家核验的标注，并将其组织为层次分类体系，以实现精确分类。为缓解类别不平衡，我们采用包含数据增强与选择性重采样的两阶段预处理策略。

在此基础上，我们提出 IMAGINE，一种用于层次多标签体裁分类的自适应多模态框架。主要贡献如下。

(i) 将图书体裁识别表述为层次多模态问题。 与电影体裁相比，图书体裁分类的研究相对不足。既有工作依赖单一模态，例如封面图像、标题、简介或评论，或仅采用有限的模态组合，如封面图像与标题。据我们所知，我们首次将图书体裁分类表述为层次任务：第1层区分虚构与非虚构，第2层执行细粒度多标签分类。

(ii) IMAGINE：一种自适应且具备数据韧性的多模态框架。 我们提出的新框架有四项方法创新：(a)用于由粗到细多标签体裁识别的两层层次结构；(b)跨多种输入捕捉更丰富上下文的全面多模态融合；(c)在含噪或缺失数据下自适应地优先选择信息量最大模态的选择性门控机制；(d)缓解偏斜标签分布、提高欠代表体裁稳健性的不平衡感知损失函数。

(iii) 新数据集与基准评估。 我们构建了包含11302个图书样本的数据集，涵盖封面图像、简介、元数据，以及经专家核验的层次多标签体裁标注。在该数据集上，我们开展广泛实验，将 IMAGINE 与先进的单模态、多模态、层次模型及大规模模型进行比较。包括消融研究和逐体裁评估在内的详细分析表明，IMAGINE 在准确性与适应能力方面始终优于基线，为结构化、可靠的图书体裁分类建立了新的基准。

本文组织如下：第II节回顾相关工作，第III–IV节介绍问题与 IMAGINE 架构，第V节报告实验，第VI节总结全文，补充文件提供数据集细节、挑战、增强策略和定性结果。

II 相关工作

本文主要关注利用多模态数据识别多标签图书体裁。既有研究考察了单独或组合使用多种模态的方式；表I概述这些研究，下面作简要总结。

视觉。 封面图像是图书的视觉表征，其中包括视觉场景、标题、字体风格和插图等元素，都可为图书体裁提供有意义的线索。文献[10]利用 CNN 分析图书封面图像，将其分为30种体裁。类似地，文献[5]使用多种基于 CNN 的架构，依据封面图像分为32种体裁。文献[6]也使用 CNN 将图书分为14种体裁。

文本。 图书中的文本数据，包括简介、标题、元数据和用户生成评论，为体裁识别提供了丰富信息。文献[3]采用朴素贝叶斯和 Doc2Vec 分析简介以进行体裁分类。文献[9]采用带 LSTM 的 RNN 将图书评论归入不同体裁，文献[1]则用带 GRU 的 RNN 分析简介。文献[4]中的 CNN 纳入预训练通用句子编码器 USE，处理图书内容以预测体裁。文献[11]用 BERT 对西班牙语图书简介分类。文献[12]对孟加拉语图书简介采用带注意力的 CNN-LSTM。文献[13]利用葡萄牙语用户评论以及 TF-IDF/LSA 特征进行体裁识别。

表I：图书体裁识别相关工作概览。 为便于中文阅读，按模态分组。体裁/标签数均保留原值；“否”对应原表的 χ，“是”对应 √；℘表示数据集未公开提供。

模态与方法	输入	架构或技术	体裁/标签数	数据集	多标签
视觉 [10]	封面图像	AlexNet	30	Amazon	否
视觉 [5]	封面图像	CNN	32	Amazon	否
视觉 [6]	封面图像	CNN	14	GoodReads（℘）	否
文本 [3]	简介	朴素贝叶斯、Doc2Vec	14	GoodReads（℘）	否
文本 [1]	简介、评论、评分	RNN + GRU	31	Book-Crossing（℘）	否
文本 [9]	评论	RNN + LSTM	28	Book-Crossing（℘）、Amazon	是
文本 [4]	图书内容	USE、CNN	8	GoodReads（℘）	否
文本 [12]	简介	CNN、LSTM、注意力	8	Bangla Book Dataset（℘）	是

模态与方法	输入	架构或技术	体裁/标签数	数据集	多标签
文本 [11]	简介	BERT	26	Spanish Book Dataset（℘）	否
文本 [13]	评论	TF-IDF、随机森林	24	Portuguese Books（℘）	否
多模态 [16]	封面图像、书名	CNN、NLP、SVM	5	OpenLibrary.org（℘）	否
多模态 [14]	封面图像、封面文字	USE、ResNet50	30	BookCover30（℘）	否
多模态 [15]	封面图像、书名	Xception、GloVe	5	Amazon（℘）	否
多模态 [7]	封面图像、书名、元数据	SE-ResNeXt-101、EXAN	28	BookCover28、Arabic Book Cover（℘）	否
多模态 [8]	封面图像、书名	Inception-v3、朴素贝叶斯	30	Amazon	否

多模态。 封面图像、简介、评论和元数据等多种模态常被组合以提高图书体裁预测准确率。文献[14]提出一个多模态模型，用 ResNet-50 处理封面图像、用 USE 处理封面文字，进行体裁分类。类似地，文献[15]使用 XceptionNet 从封面图像提取特征，并从标题提取 GloVe 嵌入，再输入多项逻辑回归模型。文献[7]提出采用改进 SE-ResNeXt 的多模态注意力融合框架，处理封面图像、书名和元数据。文献[8]分别采用 Inception-v3 和朴素贝叶斯，从封面图像和封面文字提取特征，再利用早期与晚期融合技术提高体裁分类效果。

本工作的定位。 现有图书体裁识别文献仍然有限，大多数研究仅关注视觉或文本输入。少量工作探索了结合封面图像与文本的多模态数据，但尚无工作在统一框架中系统利用所有关键图书模态，即封面、封面文字、元数据和简介。此外，既有研究很少处理多标签分类的挑战或图书体裁的层次性质。

相比之下，IMAGINE 是首个使用全面多模态数据进行层次多标签图书体裁分类的此类方法。它引入选择性门控模块，动态选择信息量最大的模态，使其对缺失或不完整输入保持稳健。此外，IMAGINE 提供逐体裁性能洞见与深入的误预测分析，这些方面在既有研究中大多被忽视。这些贡献使 IMAGINE 成为多模态层次体裁分类的一项重要进展。

III 问题表述

我们将层次图书体裁分类问题定义如下。令 $\mathcal{B} = \{\mathcal{B}_1, \ldots, \mathcal{B}_n\}$ 为包含 n 本图书的集合，其中每本图书表示为 $\mathcal{B}_i = (\mathcal{I}_i, \mathcal{T}_i, \mathcal{M}_i)$， $\mathcal{I}_i$ 表示封面图像， $\mathcal{T}_i$ 表示简介， $\mathcal{M}_i$ 表示结构化元数据。体裁按层次组织：

$$L_1 = \{0, 1\}, \qquad L_f = \{\gamma_1, \ldots, \gamma_{m_1}\}, \qquad L_{nf} = \{\lambda_1, \ldots, \lambda_{m_2}\}.$$

其中， “0”对应虚构， “1”对应非虚构。 $\gamma_i \in L_f$ 表示虚构类对应的一个体裁， $\lambda_i \in L_{nf}$ 表示非虚构类对应的一个体裁。每本图书 $\mathcal{B}_i$ 关联一个标签：

$$y_i = \left(y_1^i,\ y_2^i\right), \qquad y_1^i \in L_1,$$

$$y_2^i \subseteq \begin{cases} L_f, & \text{if } \ y_1^i = 0 \text{ (fiction)}, \\ L_{nf}, & \text{if } \ y_1^i = 1 \text{ (non-fiction)}. \end{cases}$$

因此，第1层是二分类任务，即虚构与非虚构；第2层是在所选分支内的条件多标签分类任务。目标是学习函数

$$f : \left(\mathcal{I}_i,\ \mathcal{T}_i,\ \mathcal{M}_i\right) \mapsto \left(y_1^i,\ y_2^i\right),$$

利用多模态输入预测未见图书的层次体裁，同时对含噪或缺失模态保持稳健。

IV 解决方案架构

本节介绍我们提出的层次多模态图书体裁预测框架 IMAGINE（图2）。IMAGINE 使用四种输入来源：封面图像、OCR提取的封面文字、简介和元数据，例如作者、出版社。这些信息通过三条可选处理路径处理：视觉路径 ψ_V 、文本路径 ψ_T 和多模态融合路径 ψ_M 。

IMAGINE 的核心是选择性门控模块 Φ_S ，它评估输入的可用性与可靠性，然后激活最合适的路径。不同于始终结合所有模态的传统多模态融合方法， Φ_S 每次只选择一条路径，从而在部分模态缺失或含噪时同时保证效率与稳健性。无论选择哪条路径，都遵循两阶段层次分类流程：(a)第1层：共享分类器 Φ_B 汇总全部特征，以确定一本书属于虚构还是非虚构；(b)第2层：以 Φ_B 的决策为条件，路径特定模块将分类细化为细粒度体裁。

具体而言，视觉路径 ψ_V 在 Φ_B 后接 Φ_V ，将封面图像特征与 Φ_B 的潜在表示 g_l 整合。文本路径 ψ_T 在 Φ_B 后接 Φ_T ，将简介与 g_l 一同处理。多模态路径 ψ_M 在 Φ_B 后接 Φ_M ，将封面图像和简介特征与 g_l 融合。

每个第2层模块 Φ_i （ $i \in \{V,\ T,\ M\}$ ）都包含两个并行分类器：用于虚构子体裁的 Φ_i^F 和用于非虚构子体裁的 Φ_i^N 。 Φ_B 的第1层预测激活相应分类器，从而实现类别感知的细粒度体裁识别。以下小节详细介绍各模块架构。

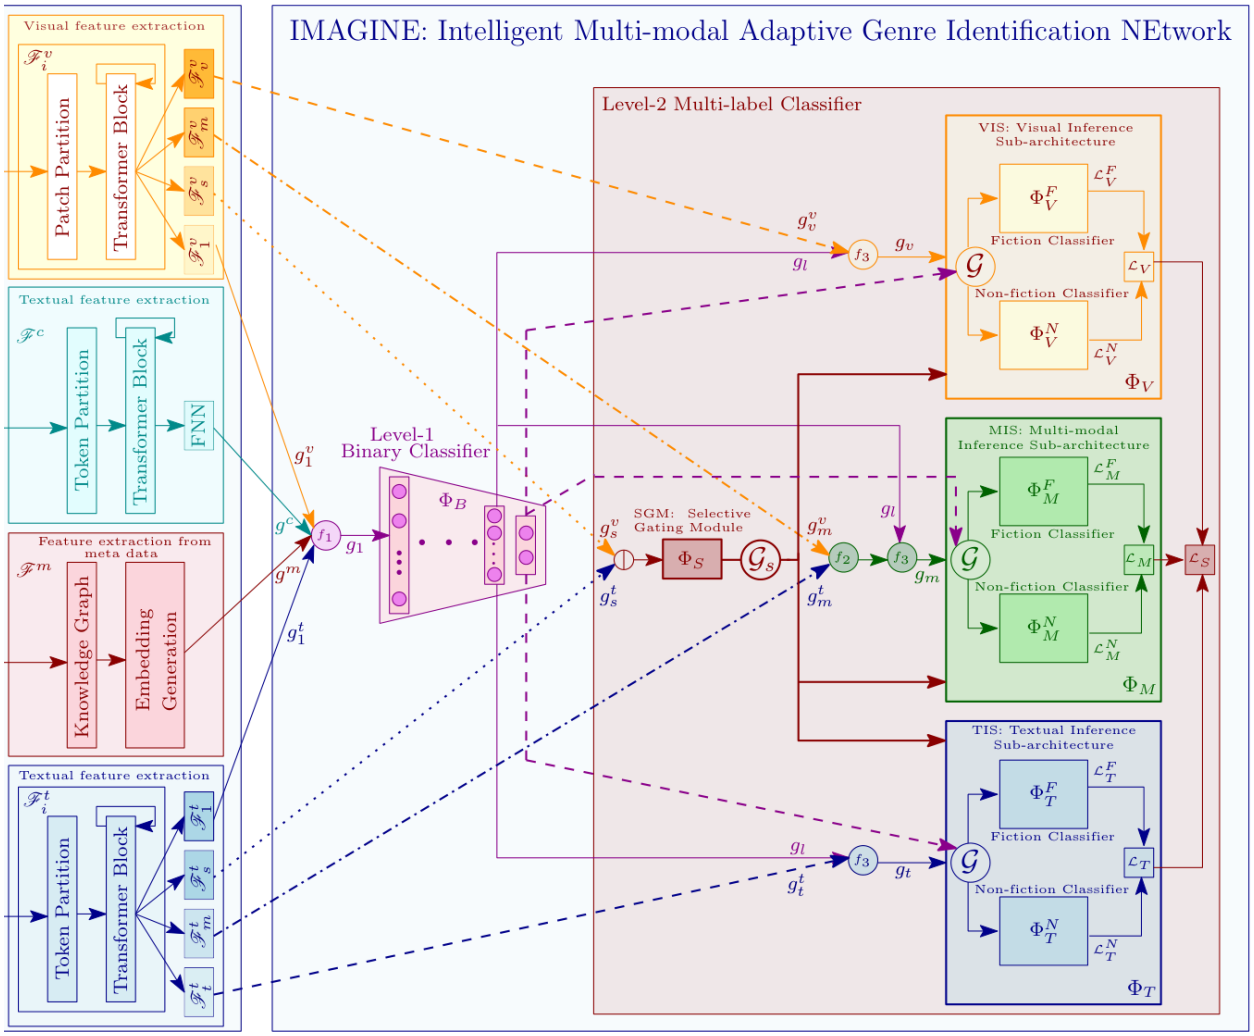


图2：用于层次图书体裁预测的 IMAGINE 框架概览。 图中保留作者绘制的特征提取器和算法主体。Visual/Textual feature extraction分别为视觉/文本特征提取；Patch/Token Partition分别为图像块/词元划分；Transformer Block为Transformer块；Knowledge Graph为知识图谱；Embedding Generation为嵌入生成；FNN为前馈神经网络；Fiction/Non-fiction Classifier分别为虚构/非虚构分类器；Level-1 Binary Classifier为第1层二分类器，Level-2 Multi-label Classifier为第2层多标签分类器。VIS、TIS、MIS和SGM的含义见本节。

> **裁剪说明：** 左侧输入示例包含第三方《Harry Potter and the Cursed Child》封面、OCR文字与引述简介，故未复制；被裁去的事实性元数据示例为作者 J. K. Rowling、出版社 Little, Brown、年份2016。保留区域从特征提取模块开始，因此最左侧输入连线不完整；算法节点及右侧分类路径保留。完整原图见原文第4页。

A SGM 选择性门控模块 Φ_S

IMAGINE 的顶层模块记为 Φ_S，充当选择性门控机制，根据每本图书输入的可靠性与完整性，动态将其路由到最合适的视觉 ψ_V、文本 ψ_T 或多模态 ψ_M 路径。这一设计使 IMAGINE 在含噪、不完整或模态特定的条件下保持稳健。Φ_S 对拼接后的特征嵌入进行操作：来自封面图像的视觉特征 g_s^v 和来自简介的文本特征 g_s^t。它采用深度前馈神经网络实现，生成三条路径上的概率分布 $\widehat{Y} \in \mathbb{R}^3$。门控函数 $\mathcal{G}_s$ 通过选择置信度最大的路径，将此分布转换为独热路由决策：

$$\mathcal{G}_s(\widehat{Y}) = \mathbf{e}_{\{\underset{j}{\operatorname{argmax}}\widehat{Y}_j\}}, \qquad j \in \{V,\ T,\ M\}. \tag{1}$$

其中， $\mathbf{e}_i$ 表示所选路径对应的独热向量。因此，在训练与推理中都只激活一条路径，以促进各模态特定分支的专门化。

Φ_S 的训练由交叉熵损失 $\mathcal{L}_S$ 引导，鼓励稳健且具有上下文感知能力的路由。此外， Φ_S 使用基于经验的监督：将每个训练实例分配给此前产生最准确预测的路径。这种反馈驱动的适应方式确保门控机制随实证性能共同演化，从而实现更可靠、准确的多标签体裁分类。

B MIS 多模态推理子架构 ψ_M

MIS 采用两层层次结构：第1层二分类器 Φ_B 和第2层多标签分类器 Φ_M。两层通过门控连接， Φ_B 确定宽泛类别，即虚构或非虚构，并激活相应第2层分支进行细粒度分类。

1）第1层二分类器 Φ_B。 IMAGINE 的第一阶段是统一应用于所有路径 ψ_V、 ψ_T 和 ψ_M 的共享二分类器 Φ_B，其任务是区分虚构与非虚构。为此， Φ_B 汇总多种模态的特征：从封面图像提取的视觉特征 g_1^v，来自简介的文本特征 g_1^t 和封面文字特征 g^c，以及作者或出版社信息等元数据特征 g^m。这些特征融合为联合表示：

$$g_1 = f_1(g_1^v,\ g_1^t,\ g^c,\ g^m),$$

其中， f_1 表示融合函数。实证结果表明，简单拼接始终优于线性投影、自注意力和交叉注意力等更复杂方案，因此全文采用拼接。

聚合特征 g_1 被输入以前馈神经网络实现的 Φ_B，使用二元交叉熵 BCE 优化，并产生概率向量 $\widehat{y}_1$。门控函数 $\mathcal{G}$ 将 $\widehat{y}_1$ 转为独热路由决策，选择第2层分类的虚构或非虚构分支。与选择信息量最大模态路径的顶层选择性门控模块 Φ_S 不同， $\mathcal{G}$ 根据 Φ_B 的预测控制第2层内部的分支激活。

2）第2层多标签分类器 Φ_M。 以第1层输出为条件，第二阶段 Φ_M 通过多标签分类，将预测细化为细粒度体裁。它包含两个并行分类器：用于虚构子体裁的 Φ_M^F 和用于非虚构子体裁的 Φ_M^N。激活的分支由 $\mathcal{G}(\widehat{y}_1)$ 确定。每个分类器都通过组合视觉封面特征 g_m^v、文本简介特征 g_m^t 和来自 Φ_B 的潜在表示 g_l，整合多模态信息。融合方式为：

$$g_m = f_3(f_2(g_m^v,\ g_m^t),\ g_l),$$

其中， f_2 合并模态特定特征， f_3 融入第1层上下文。在此，拼接也被证明最有效。

Φ_M^F 和 Φ_M^N 均采用前馈神经网络实现，最后一层应用 sigmoid 激活，生成多标签概率估计 $\widehat{y}_2$。当某体裁概率超过经验阈值时，将其赋给图书。训练使用专为多标签不平衡设计的非对称损失函数 ASL[17]。对每个样本 i，虚构与非虚构损失分别为：

$$\mathcal{L}_M^{F(i)} = \frac{1}{m_1}\sum_{j=1}^{m_1}\left(\mathcal{L}_{MF}^{ij+} + \mathcal{L}_{MF}^{ij-}\right); \qquad \mathcal{L}_M^{N(i)} = \frac{1}{m_2}\sum_{j=1}^{m_2}\left(\mathcal{L}_{MN}^{ij+} + \mathcal{L}_{MN}^{ij-}\right). \tag{2}$$

这里， m_1 和 m_2 分别表示虚构与非虚构体裁数。正项强调置信度不足的真实标签：

$$\mathcal{L}_{MF}^{ij+} = y_2^{ij}\left(1-\widehat{y}_2^{ij}\right)^{\gamma^+}\log\left(\widehat{y}_2^{ij}+\epsilon_0\right),$$

负项则通过截断来惩罚置信度过高的无关标签：

$$\mathcal{L}_{MF}^{ij-} = \left(1-y_2^{ij}\right)P_\epsilon\left(\widehat{y}_2^{ij}\right)^{\gamma^-}\log\left(1-P_\epsilon\left(\widehat{y}_2^{ij}\right)\right).$$

其中，y_2^{ij} 和 $\widehat{y}_2^{ij}$ 分别为真实值与预测值，且

$$P_\epsilon\left(\widehat{y}_2^{ij}\right) = \max\left(\widehat{y}_2^{ij}-\epsilon,\ 0\right).$$

超参数 γ^+、γ^-、ϵ 和 ϵ_0 分别控制对困难正样本的关注、对负样本的抑制、截断阈值以及数值稳定性。$\mathcal{L}_{MN}^{ij+}$ 和 $\mathcal{L}_{MN}^{ij-}$ 可类似计算。

这种层次表述保证了分支特定且对标签敏感的学习。通过结合 Φ_B 的类别级路由与 ASL 驱动的多标签细化，Φ_M 在类别不平衡下实现稳健的细粒度体裁识别。

C VIS 视觉推理子架构 ψ_V

VIS 是 IMAGINE 的另一条关键路径，其层次结构与 MIS 相同。它由共享的第1层二分类器 Φ_B 和第2层多标签视觉分类器 Φ_V 组成，两者通过依据 Φ_B 预测路由信息的门控机制连接。不同于整合多种来源的多模态路径，视觉路径仅处理封面图像特征，并与来自 Φ_B 的潜在表示 g_l 结合。纳入 g_l 可注入虚构与非虚构决策中的上下文知识，改善视觉域内的体裁预测。损失函数 $\mathcal{L}_V^{F(i)}$ 和 $\mathcal{L}_V^{N(i)}$ 采用与 $\mathcal{L}_M^{F(i)}$ 和 $\mathcal{L}_M^{N(i)}$ 相同的非对称形式，但针对视觉路径调整。

D TIS 文本推理子架构 ψ_T

TIS 构成 IMAGINE 的文本路径，采用与 MIS 和 VIS 相同的层次结构。它由共享的第1层二分类器 Φ_B 和第2层多标签文本分类器 Φ_T 组成，两者通过由 Φ_B 输出引导的门控机制连接。如前所述，Φ_B 由所有路径共享，用于判断图书属于虚构还是非虚构类别。在此输出的条件下，Φ_T 专门负责文本模态内的细粒度分类。Φ_T 中的每个分类器都将简介特征与来自 Φ_B 的潜在表示 g_l 一同处理。

在这条路径中，g_l 作为来自第1层决策的条件信号，将文本表示与虚构或非虚构上下文对齐，从而实现更具区分力的体裁预测。纳入 g_l 提供了来自虚构与非虚构决策的上下文线索，从而改善文本域内的细粒度体裁分类。路径特定损失 $\mathcal{L}_T^{F(i)}$ 和 $\mathcal{L}_T^{N(i)}$ 遵循 $\mathcal{L}_M^{F(i)}$ 和 $\mathcal{L}_M^{N(i)}$ 的非对称损失形式，但针对文本特征进行调整。

E 总体损失函数

IMAGINE 损失联合监督第1层二分类，即虚构与非虚构，以及跨模态的第2层多标签体裁预测。其设计实施选择性梯度传播，确保每个训练实例只更新相关分支和模态。形式化地，定义模态级门控函数为：

$$\delta^{(i)} = \mathcal{G}_s\left(\widehat{Y}^i\right) = \left[\delta_M^{(i)},\ \delta_V^{(i)},\ \delta_T^{(i)}\right]^\top, \qquad \delta_M^{(i)}+\delta_V^{(i)}+\delta_T^{(i)} = 1,$$

即每个样本恰好激活多模态、视觉或文本中的一条路径。第2层损失定义为：

$$\begin{aligned}\mathcal{L}_F^{2(i)} &= \delta_M^{(i)}\mathcal{L}_M^{F(i)} + \delta_V^{(i)}\mathcal{L}_V^{F(i)} + \delta_T^{(i)}\mathcal{L}_T^{F(i)},\\ \mathcal{L}_N^{2(i)} &= \delta_M^{(i)}\mathcal{L}_M^{N(i)} + \delta_V^{(i)}\mathcal{L}_V^{N(i)} + \delta_T^{(i)}\mathcal{L}_T^{N(i)}.\end{aligned} \tag{3}$$

第1层监督由 BCE 损失给出：

$$\mathcal{L}^{1(i)} = \mathrm{BCE}\left(y_1^i,\ \widehat{y}_1^i\right). \tag{4}$$

总体训练目标汇总第1层与第2层监督：

$$\mathcal{L} = \frac{1}{n}\sum_{i=1}^{n}\left[\mathcal{L}^{1(i)} + y_1^i\mathcal{G}\left(\widehat{y}_1^i\right)\mathcal{L}_F^{2(i)} + \left(1-y_1^i\right)\left(1-\mathcal{G}\left(\widehat{y}_1^i\right)\right)\mathcal{L}_N^{2(i)}\right]. \tag{5}$$

其中，$\mathcal{G}(\cdot)$ 是由 Φ_B 控制的类别级门控函数，即虚构与非虚构，y_1^i 为第1层真实标签。该形式引入两种互补的选择机制：(i)类别级门控 $\mathcal{G}$ 将监督路由到正确分支，防止跨分支干扰；(ii)模态级门控 $\mathcal{G}_s$ 对每个实例恰好激活一条模态路径，避免较弱信号带来的含噪更新，并鼓励专门化。

训练期间，门控模块 Φ_S 通过基于经验的路由标签接受监督，以学习具有上下文感知能力的决策。推理时采用硬独热门控。类别级与模态级的层次路由共同保证了稳健、上下文敏感的预测，并使预测同时符合体裁分类体系和输入的多模态性质。

> **公式核对注：** 以上公式按原文保留。原文第III节定义虚构为0、非虚构为1，但式(5)对 $\mathcal{L}_F^{2(i)}$ 与 $\mathcal{L}_N^{2(i)}$ 的标签系数写法与此定义存在表面不一致；原文式(2)及其正负损失项也未显式写出通常损失定义中的整体负号。本译文不擅自修正原式。

F 特征提取器

下面讨论 IMAGINE 中负责多模态特征提取的模块。这些模块对于从不同模态提取相关信息至关重要。

1）从封面图像提取视觉特征。 IMAGINE 采用 Swin Transformer[18] 作为图书封面特征提取的视觉骨干，原因在于其效率以及捕捉细粒度和层次模式的能力。不同于采用全局自注意力的 ViT[19]，Swin Transformer 引入不重叠窗口和移位窗口方案，在保留全局上下文的同时，以较低成本实现跨窗口交互。

输入图像被嵌入为 d_v 维图像块词元，经过包含图像块合并的层次 Swin Transformer 块，得到最终特征向量 g_v。该共享表示通过任务特定前馈网络 $\mathcal{F}_1^v$、$\mathcal{F}_s^v$、$\mathcal{F}_v^v$ 和 $\mathcal{F}_m^v$ 分别适配 Φ_B、Φ_S、Φ_V 和 Φ_M，产生 g_1^v、g_s^v、g_v^v 和 g_m^v，从而实现参数共享与任务特定专门化。我们先在数据集的一个子集上微调 Swin-B 变体，再用其权重初始化端到端 IMAGINE 训练，以改善收敛与下游性能。

2）从简介提取文本特征。 对于文本特征，我们采用 XLNet-Base Transformer[20]，原因是其基于排列的目标、相对位置编码和片段递归共同提供了更丰富的双向上下文与长序列建模能力。XLNet 先在领域特定语料上微调，再在 IMAGINE 内部进行端到端训练。每段简介编码为 d_t 维向量 g_t，通过 $\mathcal{F}_1^t$、$\mathcal{F}_s^t$、$\mathcal{F}_m^t$ 和 $\mathcal{F}_t^t$，分别转换为供 Φ_B、Φ_S、Φ_M 和 Φ_T 使用的任务特定表示 g_1^t、g_s^t、g_m^t 和 g_t^t。

3）从封面文字提取文本特征。 我们也使用微调后的 XLNet-Base[20]，从通过 OCR[21] 获取的图书封面文字中提取文本特征。与简介特征提取器类似，封面文字编码为 d_c 维表示 g_c。该表示通过专用前馈网络 $\mathcal{F}^c$，得到 $g^c = \mathcal{F}^c(g_c)$，仅由第1层分类器 Φ_B 使用。考虑到封面文字在大多数情况下信息有限且通常含噪，我们不将该模态纳入第2层模块或 SGM。

4）元数据特征提取器。 我们设计元数据特征提取器 $\mathcal{F}^m$，从训练元数据构建知识图谱，节点表示四类实体的字段值：作者、出版社、第1层体裁（粗粒度）与第2层体裁（细粒度）。图谱根据共现模式编码六类有向关系：（作者，出版社）、（作者，第1层体裁）、（作者，第2层体裁）、（出版社，第1层体裁）、（出版社，第2层体裁）和（第1层体裁，第2层体裁）。这些具有语义意义的边捕捉结构关系，使有效的多关系表示学习成为可能。

为嵌入这些异构实体，我们采用 TransD[22]，这是一种基于平移的模型，将实体与关系投影到关系特定空间。TransD 通过以更少参数动态建模实体与关系的交互，改进了 TransE 和 TransR 等先前模型[22]，并减少稀疏图中的过拟合。训练后，TransD 生成作为元数据特征的实体嵌入。

对于样本 M_i，我们提取并聚合其关联作者与出版社的嵌入，例如通过平均池化，构成元数据向量 $g^m \in \mathbb{R}^{d_m}$。若训练中未出现相关实体，g^m 默认取零向量。由于元数据覆盖稀疏，向量 g^m 仅用于第1层分类器 Φ_B，不用于第2层细化或 SGM 等后续模块。我们在观测三元组与合成三元组上使用基于间隔的排序损失[22]训练 $\mathcal{F}^m$，以保证稳健且具有区分力的表示。

G IMAGINE 的训练策略

IMAGINE 分两个顺序阶段训练，以同时保证模态特定分类器的可靠专门化，以及选择性门控机制的有效学习。第一阶段，从原训练数据集 $\mathcal{D}_{train}$ 构建可靠子集 $\mathcal{D}'$。从 $\mathcal{D}'$ 创建三个过滤子集：$\mathcal{D}_1$ 排除视觉存在困难的样本，用于训练视觉分类器 Φ_V；$\mathcal{D}_2$ 排除文本存在困难的样本，用于训练文本分类器 Φ_T；$\mathcal{D}_3$ 排除视觉或文本任一方面存在困难的所有样本，用于训练多模态分类器 Φ_M。最初，使用 $\mathcal{D}'$ 训练 Φ_B；随后分别在 $\mathcal{D}_1$、$\mathcal{D}_2$、$\mathcal{D}_3$ 上训练 Φ_V、Φ_T、Φ_M，此阶段冻结 Φ_B。

这些分类器在各自高置信度子集上训练完成后，我们准备训练选择性 SGM 模块 Φ_S 的数据集。将 $\mathcal{D}'$ 中每个样本输入三个分类器 ψ_M、ψ_V、ψ_T，找出产生最准确预测者。随后创建代表最佳分类器的独热目标向量，各维对应 ψ_M、ψ_V、ψ_T，将相应索引设为1，其余设为0。若所有分类器均无法对某样本作出正确预测，则将其排除出该训练集。随后用这些数据训练 Φ_S，使其学会对每个实例选择最可靠的分类器。

第二阶段使用完整训练数据集 $\mathcal{D}_{train}$ 对 IMAGINE 联合训练。最初，更新 Φ_B、Φ_V、Φ_T 和 Φ_M，同时为 SGM 模块收集样本。在预定义的训练轮数后，切换为用收集的样本更新 Φ_S。在 SGM 模块和分类器之间交替更新，使 Φ_S 能持续适应分类器不断变化的性能，确保将每个输入稳健、动态地路由到最合适的模态特定分支。

V 实验与讨论

本节通过一组全面实验评估 IMAGINE 的性能。实验使用 PyTorch 2.1.0，在配备16核 Intel(R) Xeon(R) W-1270 处理器、128 GB RAM 和24 GB NVIDIA RTX A5000 GPU 的系统上进行。

A 使用的数据集

本研究的主要目标是分析图书的多模态数据，并识别其关联的多标签体裁。据我们所知，目前不存在公开可用的多模态层次图书体裁数据集，因此我们整理了一个包含11302个图书样本的全面数据集，其中虚构图书6704本、非虚构图书4598本，每本带有1至6个体裁标签。数据集包含封面、简介、元数据（作者、出版社）和多标签体裁。

表II：数据集按层次体裁统计的样本数。 “—”对应原表中不适用的类别。

类别ID	体裁标签	虚构	非虚构
1	动物、野生动物与宠物	590	235
2	艺术与摄影	1188	606
3	商业与金钱	42	256
4	儿童图书	1714	298
5	漫画与图像作品	364	96
6	计算机与技术	27	92
7	食谱、食物与葡萄酒	72	223
8	手工、爱好与家居	40	61
9	环境与植物	92	337
10	家庭、育儿与人际关系	208	257
11	时尚与生活方式	732	204
12	健康、健身与饮食	32	320
13	历史	1677	1619
14	人文	537	1555
15	幽默与娱乐	972	376
16	文学	2615	670
17	悬疑、惊悚、悬念、恐怖与冒险	2043	404
18	医学	70	165
19	元文本	35	88
20	神话、宗教与灵性	890	748
21	报刊与媒体	138	167
22	参考书与语言	97	1003
23	爱情	1445	80
24	科学与数学	419	712
25	自助与励志	72	630
26	体育与户外	183	157

类别ID	体裁标签	虚构	非虚构
27	青少年与青年	1712	170
28	旅行	92	393
29	科幻与奇幻	2715	—
30	传记与回忆录	—	1256

表II给出了虚构与非虚构类别中体裁标签的详细信息及分布统计。多数样本关联多个体裁，导致计数重叠，并形成显著的类别不平衡。例如，科幻与奇幻、历史等体裁非常常见，而计算机与技术、手工、爱好与家居等体裁代表不足。为缓解这一不平衡，我们采用数据增强技术，显著改善了分布。然而，由于数据集具有多标签性质，且多数类与少数类经常在同一样本中共现，仍无法达到完全平衡。数据集创建、模态特定挑战、统计特征以及包括数据增强在内的数据预处理细节在附录A中讨论。

为缓解数据不平衡，同时确保各体裁按比例得到表示，数据集按8:1:1的比例划分为训练集 $\mathcal{D}_{train}$ 、验证集 $\mathcal{D}_{val}$ 和测试集 $\mathcal{D}_{test}$ 。

B 评估指标

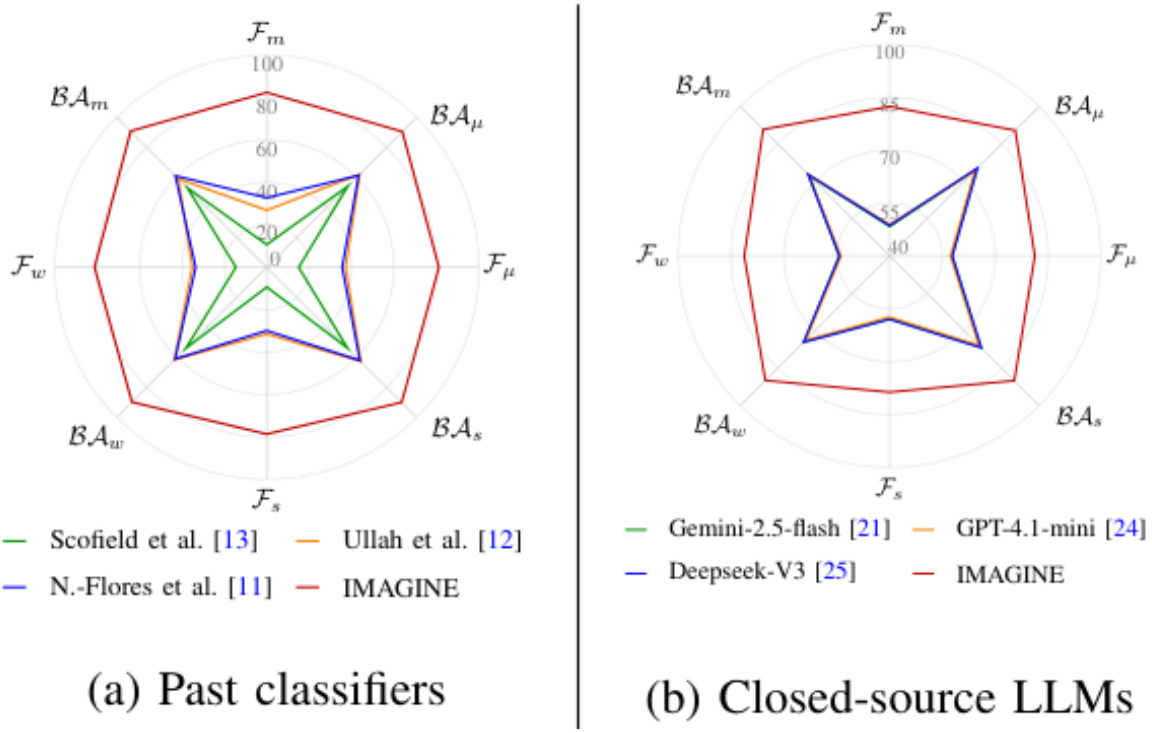
为评估模型在 $\mathcal{D}_{test}$ 上的表现，我们报告第1层（二分类）的 F1分数 $\mathcal{F}$ 和准确率 $\mathcal{A}$ ，均以百分比表示。对于第2层多标签分类，我们报告 F1分数和平衡准确率的微平均 $\mathcal{F}_{\mu}$, $\mathcal{BA}_{\mu}$ 、宏平均 $\mathcal{F}_{m}$, $\mathcal{BA}_{m}$ 、加权平均 $\mathcal{F}_{w}$, $\mathcal{BA}_{w}$ 和基于样本的 $\mathcal{F}_{s}$, $\mathcal{BA}_{s}$ 。此外，使用汉明损失 $\mathcal{HL}$ 捕捉逐标签的不匹配。

这些不同指标提供互补视角：微平均强调高频类别，宏平均平等对待所有类别，加权平均考虑类别频率，基于样本的指标则反映逐实例性能；对于类别不平衡的多标签任务，这些视角至关重要[23]。

C 与基线的比较分析

据我们所知，几乎没有既有工作使用同时利用封面图像、OCR提取的封面文字、简介和元数据的全面多模态数据集来处理层次图书体裁分类。现有图书推荐或体裁预测方法要么是单模态，要么将体裁层次扁平化，限制了实际应用能力。为进行公平比较，在适配基线时，我们将分类体系扁平化为58个类别，即29个虚构类加29个非虚构类。

图3：IMAGINE 与基线(a)–(e)的性能比较。 (a)既有分类器；(b)闭源大语言模型；(c)开源大语言模型；(d)开源视觉语言模型；(e)层次分类器。图中指标符号含义见第V-B节，模型名称及参考文献编号保留原标注。 为提高图例可读性，原横排五面板按(a)–(b)、(c)–(d)、(e)分组放大排列。



(a) Past classifiers

(b) Closed-source LLMs

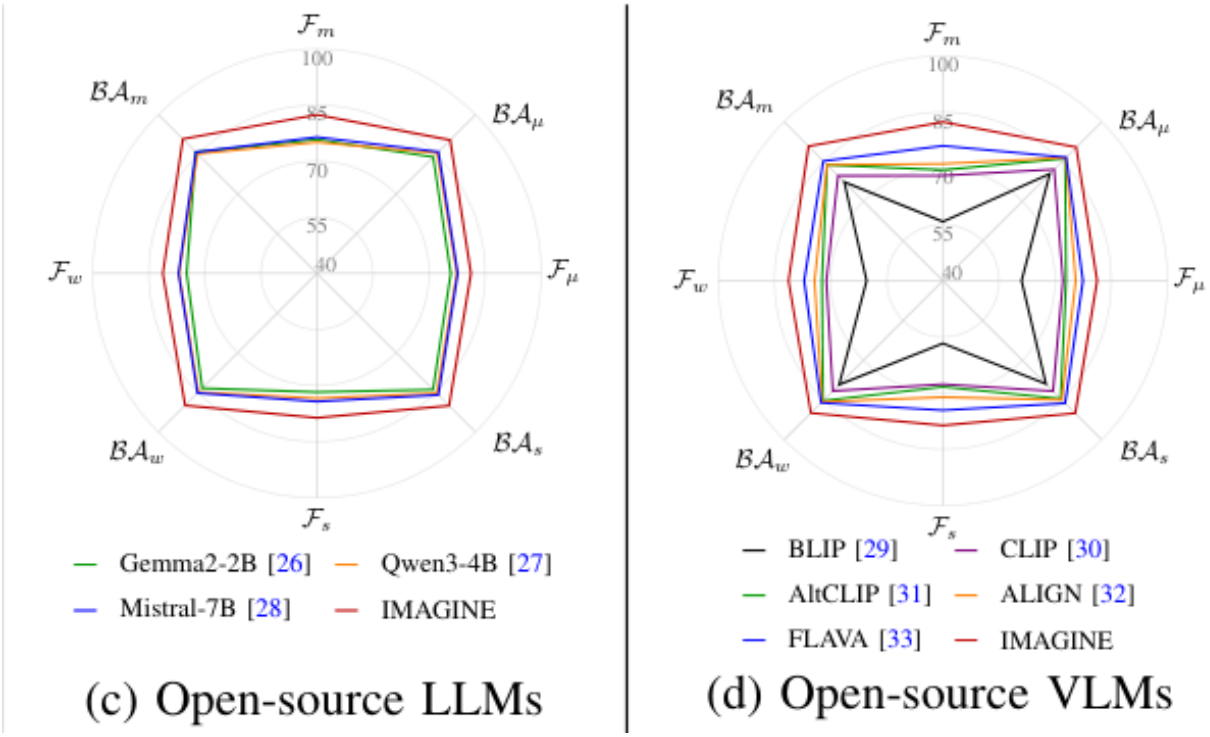


图3续：(c)开源大语言模型；(d)开源视觉语言模型。

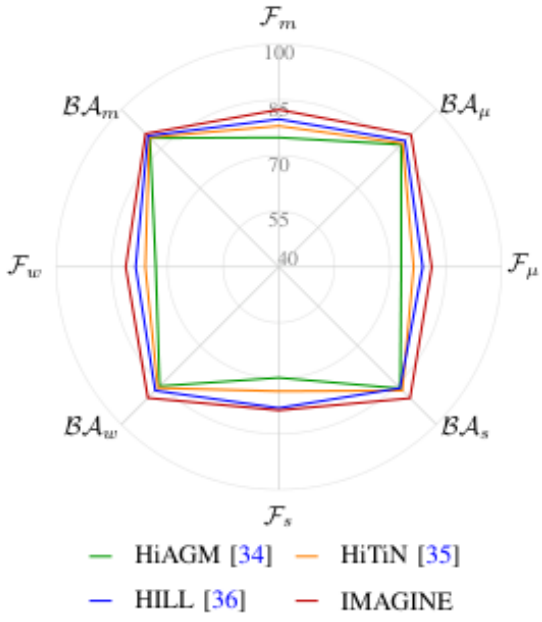


图3续：(e)层次分类器。

(i) 既有图书体裁分类器。 我们采用 Scofield 等人[13]、Ullah 等人[12]和 N.-Flores 等人[11]的架构，并在我们的数据集上进行评估，以保证公平比较。文献[13]基于简介的方法仅取得中等性能；文献[12]带注意力的 CNN-BiLSTM 有所改善，但难以进行跨模态推理；文献[11]基于 RoBERTa 的分类器虽然更强，却未能捕捉标签依赖关系，且仍对领域偏移敏感。如图3(a)所示，IMAGINE 始终优于这些既有方法，凸显了其多模态整合、选择性门控和层次分类体系对稳健图书体裁分类的有效性。

(ii) 闭源大语言模型。 与 Gemini-2.5 Flash[21]、GPT-4.1 Mini[24]和 Deepseek-V3[25]相比，IMAGINE 始终取得更高性能（图3(b)）。这表明，结合层次监督的领域特定架构可以超越通用大语言模型。

(iii) 开源大语言模型。 面对 Gemma2-2B[26]、Qwen3-4B[27]和 Mistral-7B[28]，IMAGINE 再次在各项指标上领先（图3(c)），说明任务特定的选择性融合相较通用预训练架构具有优势。

(iv) 开源视觉语言模型。 我们采用 BLIP[29]、CLIP[30]、AltCLIP[31]、ALIGN[32]和 FLAVA[33]同时利用封面图像和简介，但这些模型针对对齐任务而非结构化分类进行优化。IMAGINE 超过了所有这些视觉语言模型（图3(d)），显示出层次路由和多模态专门化的有效性。

(v) 层次分类器。 HiAGM[34]、HiTiN[35]和 HILL[36]等方法显式利用层次结构，但工作于单模态文本设置。虽然它们优于扁平分类器，却缺乏多模态适应能力。IMAGINE 优于这些分类器（图3(e)），表明它能够通过多模态监督捕捉更深层的标签依赖与语义关系。

在所有类别中，IMAGINE 通过结合层次设计、自适应模态门控与多模态融合，均优于基线，在图书体裁分类中取得先进性能。

D 模态消融研究

本小节通过评估 IMAGINE 的不同消融版本，分析每种模态对体裁预测的贡献：(a) UM_v：仅使用从封面图像提取的视觉模态的单模态版本；(b) UM_d：仅依赖从简介获取的文本模态的单模态版本；(c) MM_{vd}：仅包含封面图像和简介的多模态消融版本；(d) MM_{vdc}：考虑封面图像、简介和封面文字的多模态消融版本；(e) MM_{vdm}：包含封面图像、简介和元数据的多模态消融版本；(f) ψ_M：整合封面图像、简介、封面文字和元数据的多模态消融版本。 ψ_M 与 IMAGINE 的关键区别在于：IMAGINE 在单模态视觉或文本模型与完整多模态模型之间动态选择，而 ψ_M 严格依赖多模态数据，不具备这种选择性适应。

表III：模态与模块消融研究。 原表拆为三个子表；↑表示越大越好，↓表示越小越好。为避免横向挤压，第2层子表转置为指标按行、模型按列。UMv、UMd、MMvd、MMvdc、MMvdm、ψM、MMF 分别对应 UM_v、UM_d、MM_{vd}、MM_{vdc}、MM_{vdm}、ψ_M、MM_F。

表III(a) 第1层。

模态研究	模型	F ↑	A ↑
视觉	UMv	87.32	86.22
文本	UMd	96.43	96.06
多模态	MMvd	96.89	96.62
多模态	MMvdc	98.21	98.04
多模态	MMvdm	96.92	96.63
多模态	ψM	98.51	98.36
扁平结构	MMF	—	—
完整框架	IMAGINE	98.51	98.36

表III(b) 第2层 虚构。

指标	UMv	UMd	MMvd	MMvdc	MMvdm	ψM	MMF	IMAGINE
Fμ ↑	68.31	71.98	74.87	76.33	76.01	76.65	64.28	79.32
BAμ ↑	79.88	84.15	86.26	87.12	86.98	87.47	80.47	88.76
Fm ↑	68.08	70.41	75.57	77.26	77.69	78.15	62.38	80.52
BAm ↑	79.46	82.42	85.90	87.20	87.32	87.87	78.53	89.16
Fw ↑	67.80	70.53	74.85	76.26	75.98	76.62	62.64	79.43
BAw ↑	77.95	81.46	83.91	85.01	84.63	85.22	77.91	87.23
Fs ↑	63.43	69.91	72.39	73.91	73.72	74.27	62.12	77.19
BAs ↑	78.96	83.97	85.73	86.59	86.45	86.88	80.34	88.16
HL ↓	0.0670	0.0632	0.0592	0.0557	0.0566	0.0553	0.0799	0.0485

表III(c) 第2层 非虚构。

指标	UMv	UMd	MMvd	MMvdc	MMvdm	ψM	MMF	IMAGINE
Fμ ↑	60.83	73.63	77.29	76.77	77.15	78.46	72.30	83.74
BAμ ↑	75.94	84.09	86.44	86.09	86.33	87.00	82.78	91.06
Fm ↑	58.71	73.48	77.98	77.63	78.37	79.39	69.11	84.27
BAm ↑	74.13	84.41	85.96	85.52	86.28	86.74	81.25	90.92
Fw ↑	60.33	72.12	77.19	76.75	77.10	78.40	70.51	83.71
BAw ↑	74.24	83.30	85.14	84.78	85.14	85.83	81.37	90.22
Fs ↑	53.57	71.19	72.38	71.47	71.94	73.23	71.11	80.43
BAs ↑	74.37	84.09	85.46	85.01	85.19	85.90	83.91	90.53
HL ↓	0.0776	0.0572	0.0483	0.0494	0.0486	0.0457	0.0629	0.0358

表III列出 IMAGINE 及其各种消融版本的性能，强调纳入多种模态并根据其信息量进行选择性利用的重要性。由表III可以观察到以下现象。

(i) 单模态与多模态表示的影响（UM_v/UM_d 对比 MM_{vd}）。 值得注意的是，UM_d 在第1层与第2层分类的所有评估指标上均始终优于 UM_v，说明简介文本比封面图像提供了信息量更大的图书体裁识别特征。此外，MM_{vd} 在全部评估指标上均明显优于 UM_v 和 UM_d，表明多模态特征包含比单独来自简介或封面图像的单模态特征更丰富的体裁相关信息。

(ii) IMAGINE 中多模态的影响。 值得注意的是，MM_{vdc} 和 MM_{vdm} 在大多数情况下优于 MM_{vd}，说明纳入元数据或封面文字均可增强特征表示并改善体裁识别。此外，ψ_M 在所有指标上优于 MM_{vdc} 和 MM_{vdm}，体现了封面图像、简介、封面文字与元数据的各自贡献。这种改善来自多种模态的整合，使提取到的特征更丰富、信息量更大。

(iii) 层次架构相较扁平架构的影响。 我们将层次多模态架构 ψ_M 与 MM_F 比较，后者使用全部模态，但将分类体系视为58个独立类别，即29个虚构类加29个非虚构类。ψ_M 始终优于 MM_F，说明显式建模层次标签依赖有助于分类。

(iv) IMAGINE 与其消融版本的比较。 IMAGINE 表现出更优性能，在所有评估指标上超过全部消融版本。关键原因之一是其第2层分类中的选择机制，使其能够根据可用模态，即封面图像和简介的信息量，动态选择最有效的分类器。

表IV：模态消融的定性分析。 原表的5幅第三方书封和5段引述简介均未复制；下列完整保留书目事实、真实体裁和全部模型预测。原面板见原文第8页。星号按原表保留，表示预测体裁集合与真实体裁集合完全一致；不为原表其他相同集合补加星号。

表IV(a)。 ISBN 9780394929132；书名 Great Day for Up（书名直译：向上的美好一天）；作者 Dr. Seuss；出版社 Random House Books for Young Readers。引述简介与书封省略。

项目	类别与体裁集合
真实体裁	虚构，{艺术与摄影，儿童图书，幽默与娱乐，文学，科幻与奇幻}
UMv	虚构，{艺术与摄影，儿童图书}
UMd	虚构，{艺术与摄影，儿童图书，幽默与娱乐，文学，科幻与奇幻}*
MMvd	虚构，{艺术与摄影，儿童图书，幽默与娱乐}
IMAGINE	虚构，{艺术与摄影，儿童图书，幽默与娱乐，文学，科幻与奇幻}*

表IV(b)。 ISBN 9780553243581；书名 When Love Dies（书名直译：当爱消逝）；作者 Francine Pascal、Kate William；出版社 Bantam Books。引述简介与书封省略。

项目	类别与体裁集合
真实体裁	虚构，{儿童图书，家庭、育儿与人际关系，文学，爱情，青少年与青年}
UMv	虚构，{儿童图书，家庭、育儿与人际关系，文学，爱情，青少年与青年}
UMd	虚构，{艺术与摄影，幽默与娱乐，文学}
MMvd	虚构，{艺术与摄影，儿童图书，家庭、育儿与人际关系，文学，爱情，青少年与青年}
IMAGINE	虚构，{儿童图书，家庭、育儿与人际关系，文学，爱情，青少年与青年}

表IV(c)。 ISBN 9780307001504；书名 The Cat That Climbed the Christmas Tree（书名直译：爬上圣诞树的猫）；作者 Susanne Santoro Whayne、Christopher Santoro；出版社 Western Publishing Company Inc。引述简介与书封省略。

项目	类别与体裁集合
真实体裁	虚构，{动物、野生动物与宠物，艺术与摄影，儿童图书，神话、宗教与灵性}
UMv	虚构，{动物、野生动物与宠物，艺术与摄影，儿童图书}
UMd	虚构，{动物、野生动物与宠物，儿童图书，神话、宗教与灵性}
MMvd	虚构，{动物、野生动物与宠物，艺术与摄影，儿童图书，神话、宗教与灵性}
IMAGINE	虚构，{动物、野生动物与宠物，艺术与摄影，儿童图书，神话、宗教与灵性}

表IV(d)。 ISBN 9781568655802；书名 Bimbos & Zombies: Bimbos of the Death Sun / Zombies of the Gene Pool（书名直译：美女与僵尸：死亡太阳下的美女／基因库中的僵尸）；作者 Sharyn McCrumb；出版社 GuildAmerica Books。引述简介与书封省略。

项目	类别与体裁集合
真实体裁	虚构，{幽默与娱乐，悬疑、惊悚、悬念、恐怖与冒险，科幻与奇幻}
UMv	虚构，{历史，悬疑、惊悚、悬念、恐怖与冒险，爱情}
UMd	非虚构，{}
MMvd	虚构，{悬疑、惊悚、悬念、恐怖与冒险}
IMAGINE	虚构，{幽默与娱乐，悬疑、惊悚、悬念、恐怖与冒险，科幻与奇幻}

表IV(e)。 ISBN 9780060186869；书名 The Blessing of the Animals: True Stories of Ginny, the Dog Who Rescues Cats（书名直译：动物的祝福：救猫的狗金妮的真实故事）；作者 Philip González；出版社 HarperCollins。引述简介与书封省略。

项目	类别与体裁集合
真实体裁	非虚构，{动物、野生动物与宠物，传记与回忆录}
UMv	非虚构，{动物、野生动物与宠物，环境与植物，科学与数学}
UMd	非虚构，{动物、野生动物与宠物}
MMvd	非虚构，{动物、野生动物与宠物}
IMAGINE	非虚构，{动物、野生动物与宠物，传记与回忆录}

表IV突出显示了 IMAGINE 所用不同模态的重要性，以及根据跨模态信息量自适应选择模型的意义。原表列出多个示例，包括封面图像、简介（较长时用“……”截断）、顶部的元数据，以及真实体裁标签和 UM_v、UM_d、MM_{vd}、IMAGINE 的预测。

表IV(a)中，封面图像传达的信息有限，而简介信息丰富。类似地，表IV(b)中，封面图像更相关，但简介缺乏有用细节。 MM_{vd} 难以准确预测所有体裁，而 IMAGINE 正确识别了它们，这可能归功于其在单模态与多模态模型之间进行选择性适应的能力。表IV(c)中，封面图像和简介都为识别至少部分体裁提供了有用信息。在此， MM_{vd} 正确预测了体裁，IMAGINE 也取得了同样良好的表现。值得注意的是，即使某一模态，即封面图像或简介，缺乏足够信息，IMAGINE 仍始终优于 UM_v、UM_d 和 MM_{vd}。这表明 IMAGINE 具有稳健性：能够有效利用跨模态互补特征，并根据可用模态的信息量自适应选择模型。表IV(d)–(e)进一步强调了封面文字与元数据的重要性。在这些案例中，只有 IMAGINE 成功预测体裁，显示出其整合从多样、可靠数字内容中提取的特征，以准确分类体裁的更强能力。

E 不同融合策略的影响

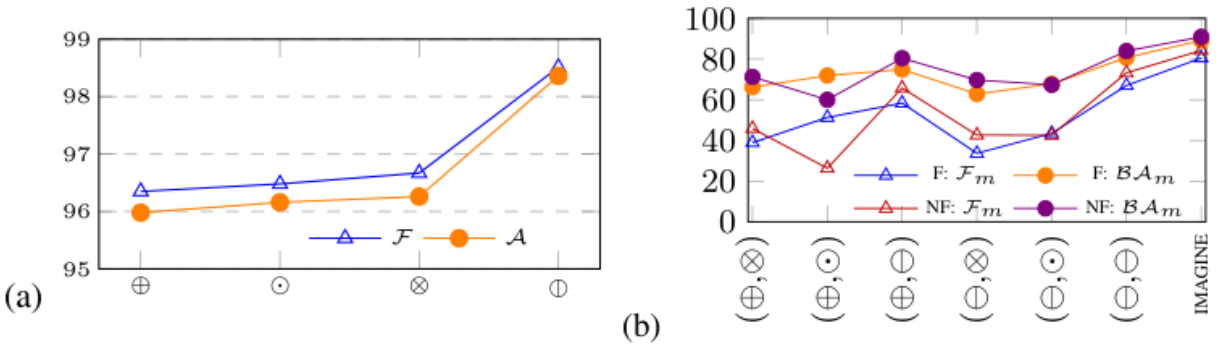
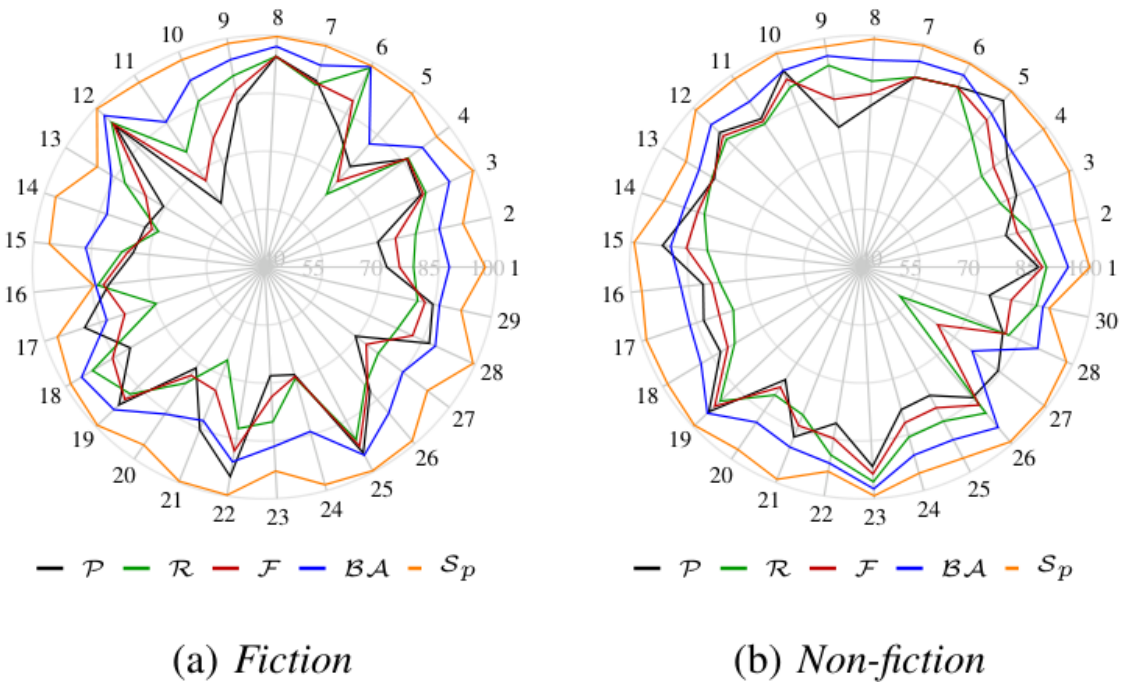


图4：融合函数 f_1、f_2 和 f_3 的影响。 (a)第1层 f_1；(b)第2层 f_2, f_3。$\oplus$：加法；$\odot$：自注意力；$\otimes$：交叉注意力；$\textcircled{\scriptsize ||}$：拼接。F：虚构；NF：非虚构。

图4考察不同融合策略对体裁识别性能的影响，展示了 ψ_M 采用 f_1、f_2、f_3 中不同融合策略时的性能。图4(a)、(b)表明，拼接 $\textcircled{\scriptsize ||}$ 在第1层和第2层分类中始终取得最高性能，优于加法 $\oplus$、自注意力 $\odot$ 和交叉注意力 $\otimes$。值得注意的是，自注意力与交叉注意力导致模型性能显著下降，说明它们在此情境中并不有效。

F 逐体裁分析

图5展示了各体裁的精确率 $\mathcal{P}$、召回率 $\mathcal{R}$、F1分数 $\mathcal{F}$、平衡准确率 $\mathcal{BA}$ 和特异度 Sp，以下分析重点讨论 $\mathcal{F}$。虚构类（ID 1–29）的平均 $\mathcal{F} = 80.52$，中位数为81.18，标准差为7.87，表明方差较高，即体裁间波动大于非虚构类。表现最佳的虚构体裁包括手工、爱好与家居（ID 8，$\mathcal{F} = 94.64$）、健康、健身与饮食（ID 12，$\mathcal{F} = 93.88$）、自助与励志（ID 25，$\mathcal{F} = 92.47$）、元文本（ID 19，$\mathcal{F} = 89.77$），以及食谱、食物与葡萄酒（ID 7，$\mathcal{F} = 89.57$），反映出多模态线索，即封面图像与简介，与层次监督之间具有较强一致性。相比之下，表现较弱的虚构体裁，如时尚与生活方式（ID 11，$\mathcal{F} = 67.07$）、漫画与图像作品（ID 5，$\mathcal{F} = 69.17$）、科学与数学（ID 24，$\mathcal{F} = 69.39$）、人文（ID 14，$\mathcal{F} = 70.70$）和青少年与青年（ID 27，$\mathcal{F} = 73.04$），受到数据稀疏和叶层级更高语义混淆性的影响。



(a) *Fiction* (b) *Non-fiction*

图5：逐体裁性能分析。 (a)虚构；(b)非虚构。类别编号对应表II；P、R、F、BA、Sp分别为精确率、召回率、F1分数、平衡准确率与特异度。

非虚构类（ID 1–28、30）的平均 $\mathcal{F} = 84.27$，中位数84.72，标准差5.82，表现出更强的一致性。领先体裁包括爱情（ID 23，$\mathcal{F} = 93.62$）、计算机与技术（ID 6，$\mathcal{F} = 92.86$）、元文本（ID 19，$\mathcal{F} = 92.39$）、家庭、育儿与人际关系（ID 10，$\mathcal{F} = 92.39$）以及食谱、食物与葡萄酒（ID 7，$\mathcal{F} = 91.07$），它们受益于丰富的文本与视觉对应关系。同时，低资源或小众体裁，如青少年与青年（ID 27，$\mathcal{F} = 64.66$）、神话、宗教与灵性（ID 20，$\mathcal{F} = 77.52$）、悬疑、惊悚、悬念、恐怖与冒险（ID 17，$\mathcal{F} = 78.86$）、文学（ID 16，$\mathcal{F} = 79.03$）和传记与回忆录（ID 30，$\mathcal{F} = 79.59$），因样本有限而得分较低。

总体而言，IMAGINE 利用层次监督与多模态门控，在大多数体裁，尤其是非虚构体裁上获得较高且稳定的 $\mathcal{F}$；而规模较小、代表不足的体裁上性能下降，则强调了增强或重加权策略的必要性。虚构类的峰值更大但低谷更深、非虚构类提升更稳定，这种不对称反映了表II所体现的标签频率与语义歧义的共同影响。

附录B给出使用不同特征提取器的框架分析，附录C提供更多定性结果。总体而言，结果显示 IMAGINE 始终优于多模态基线与单模态模型，凸显其使用多模态输入进行层次多标签体裁分类的有效性。

VI 结论

本文提出 IMAGINE，一种用于层次图书体裁分类的新型多模态框架，将图书封面、简介和元数据整合起来，以获得稳健、准确的预测。通过利用两层层次结构，IMAGINE 有效处理了多标签依赖和数据不平衡。实验显示它相较先进方法具有明显优势。本研究强调了多模态整合与结构化体裁层次在改善图书推荐和内容组织方面的价值。未来工作将聚焦于扩展到更细的子体裁，并在维持性能的同时支持更深的层次结构。

参考文献

以下保留作者、年份、出版信息和标识符，并将题名译为中文；作者缩写、“等”及原文书目信息均依原文。未以外部资料静默修正原文条目。

[1] Y. Ng 等。“基于深度学习模型与元数据的个性化图书推荐”。WISE，2019，162–178页。

[2] S. Lee 等。“使用机器学习方法，书封能帮助预测畅销书吗？” Telematics and Inform.，第78卷，文章101948，2023。

[3] A. Sobkowicz 等。“通过封面读书：使用简短描述检测图书体裁”。ICMMI，2017，439–448页。

[4] M. Khalifa 等。“利用预训练句子嵌入和可读性分数预测图书成功”。HICSS 2022，1–8页。

[5] A. Lucieri 等。“图书封面分类深度学习模型的基准评估”。SN Computer Science，第1卷，2020年4月。

[6] P. Buczkowski 等。“面向图书封面分类的深度学习方法”。ICPRAM 2018，2018，309–316页。

[7] A. Rasheed 等。“利用改进的多模态网络进行基于封面的多图书体裁识别”。IJDAR，第26卷第1期，65–88页，2023。

[8] R. Jayaram 等。“依据封面对图书按体裁分类”。IJEAT，第9卷，530–535页，2020年6月。

[9] M. Saraswat 等。“利用RNN体裁分类进行图书推荐”。IJIT，第14卷第7期，3751–3756页，2022。

[10] B. K. Iwana 等。“以封面评判一本书”。arXiv:1610.09204，2016。

[11] J. A. Nolazco-Flores 等。“西班牙语图书的体裁分类”。IEEE Access，第11卷，132878–132892页，2023。

[12] M. S. Ullah 等。“孟加拉语图书语境分类：一种多标签方法”。ICCIT，2023，1–5页。

[13] C. Scofield 等。“基于葡萄牙语文学评论的图书体裁分类”。PROPOR，2022，188–197页。

[14] C. Kundu 等。“基于封面的图书体裁分类深度多模态网络”。arXiv:2011.07658，2020。

[15] G. R. Biradar 等。“使用图书封面与标题的图书体裁分类”。ICISGT 2019，2019，72–723页。

[16] H. Chiang 等。“通过封面与标题进行图书体裁分类”。Computer science: class report（计算机科学课程报告），2015。

[17] T. Ridnik 等。“用于多标签分类的非对称损失”。ICCV，2021，82–91页。

[18] Z. Liu 等。“Swin Transformer：使用移位窗口的层次视觉Transformer”。ICCV，2021，10012–10022页。

[19] A. Dosovitskiy 等。“一幅图像价值16×16个词：用于大规模图像识别的Transformer”。ICLR，2021。

[20] Z. Yang 等。“XLNet：用于语言理解的广义自回归预训练”。NeurIPS，2019。

[21] G. Team 等。“Gemini：一族能力强大的多模态模型”。arXiv:2312.11805，2023。

[22] G. Ji 等。“通过动态映射矩阵进行知识图谱嵌入”。ACL-IJCNLP，2015，687–696页。

[23] M.-L. Zhang 等。“多标签学习算法综述”。IEEE TKDE，第26卷第8期，1819–1837页，2014。

[24] OpenAI 等。“GPT-4技术报告”。2024。

[25] A. Liu 等。“Deepseek-v3技术报告”。arXiv:2412.19437，2024。

[26] G. Team 等。“Gemma 2：以实用规模改进开放语言模型”。arXiv:2408.00118，2024。

[27] A. Yang 等。“Qwen3技术报告”。arXiv:2505.09388，2025。

[28] A. Q. Jiang 等。“Mistral 7B”。arXiv:2310.06825，2023。

[29] J. Li 等。“BLIP：面向统一视觉语言理解与生成的自举式语言图像预训练”。ICML，2022，12888–12900页。

[30] A. Radford 等。“从自然语言监督中学习可迁移视觉模型”。ICML，2021，8748–8763页。

[31] Z. Chen 等。“AltCLIP：改变CLIP的语言编码器以扩展语言能力”。ACL，2023，8666–8682页。

[32] C. Jia 等。“利用含噪文本监督扩展视觉及视觉语言表示学习”。ICML，2021，4904–4916页。

[33] A. Singh 等。“Flava：基础语言与视觉对齐模型”。CVPR，2022，15638–15650页。

[34] J. Zhou 等。“用于层次文本分类的层次感知全局模型”。ACL，2020，1106–1117页。

[35] H. Zhu 等。“HiTIN：用于层次文本分类的层次感知树同构网络”。ACL，2023，7809–7821页。

[36] H. Zhu、J. Wu 等。“HILL：用于层次文本分类的层次感知信息无损对比学习”。NAACL，2024，4731–4745页。

补充附录 原文说明

附录A、B、C见 作者的 IMAGINE 仓库。

译者范围说明： 上句为原文第10页的完整补充附录指引。10页 arXiv 主文未包含附录A–C正文。作者仓库另列 Supp_Appendix_A_B_C.pdf、Supp_Data_Samples.pdf、Supp_Dataset_Challenge.pdf 和 Supp_Genre_Misprediction.pdf；这些独立补充文件未因仓库公开可读或主文采用CC BY而被自动视为具有相同改编许可。本次仅交付已核验许可的主文全译；已查阅官方v2源码包的文件清单：包内含被主文件注释排除的旧版附录TeX，但没有上述4份独立补充PDF，且旧稿章节组织与独立A–C补充文件不同，未建立逐文件许可匹配。独立补充文件未翻译、未再分发。主文所有附录引用均保留，以免混淆本译本的覆盖范围。