当语义一致编码遇上视图—标签异质性建模：面向不完整多视图多标签学习的统一框架

作者： Chengliang Liu、Bo Li、Bob Zhang、Yanghao Zhou、Jie Wen、Wenwu Wang
论文编号： arXiv:2609.07525v1（2026-09-07）
原文： arXiv 页面 · PDF
代码： justsmart/V2L

> **私人阅读译本说明：** 本译文以用户上传的 17 页 PDF 为校核依据，非官方译文。原论文著作权及原有标识归原权利人；公开再分发许可尚未核实，不声明任何 CC 许可，不用于公开仓库发布。正文、推导、算法、实验、作者信息及参考文献均保留；公式与图表采用原页裁切以保持符号字形、编号与数据。图表中的英文标签在相邻说明中释义，参考文献保留英文。所提供原文没有附录；本译本不包含未提供的补充材料。

摘要

不完整多视图多标签学习既要从部分观测的视图中稳健地聚合语义信息，也要利用与标签相关的视图特有证据。现有方法通常侧重于共享表示学习或决策层融合。前者有助于抵御视图缺失，但往往会把标签判别所需的视图特有线索压缩到单一潜在表示中；后者可以保留各视图的判别能力，却通常依赖固定或全局学习的融合权重，因而忽略了不同样本、不同标签之间的差异。

为解决这些问题，本文提出用于不完整多视图多标签分类的统一框架 V2L。在表示学习方面，V2L 通过一种感知扰动的编码机制，从不完整视图中构造语义一致的变分后验，为学习提供稳定的共享语义基础。在决策方面，V2L 引入主动式视图—标签相关性建模，估计每个样本、每个标签对应的视图贡献，使每个标签的预测都能自适应地选择有用的视图特有证据。从模型架构角度看，这两种策略通过混合融合架构整合在统一框架中，同时满足跨视图语义一致性与表示互补性的要求。

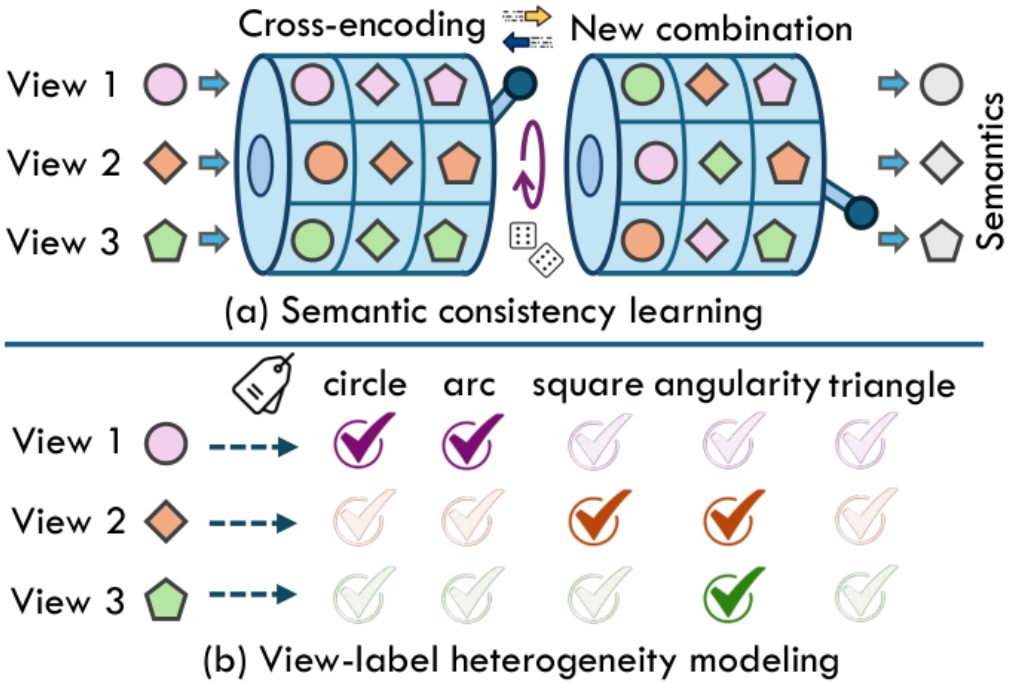
在五个基准数据集上的不完整与完整设置实验表明，V2L 均取得领先表现。代码见：https://github.com/justsmart/V2L。

关键词： 不完整多视图多标签分类；语义一致变分编码；视图—标签相关性建模。

1 引言

多视图多标签学习旨在从描述同一目标的异构观测中预测多个语义标签 [1, 2, 3]。在图像理解、多媒体检索、医学分析和多模态内容推理等应用中，不同视图往往刻画对象的互补属性，而表达对象丰富语义又需要多个标签，因此这类学习越来越重要 [4, 5]。在这些场景中，有效学习既取决于对跨视图互补性的利用，也取决于对标签相关语义的建模。

然而，实际的多视图多标签数据很少能够被完整观测 [6]。视图缺失可能由采集失败、成本限制、隐私约束或遮挡引起；标签缺失则常见于标注稀疏或人工遗漏 [7, 8, 9]。因此，不完整多视图多标签分类必须同时处理输入侧的部分观测和输出侧的不完整监督。与完整数据设置相比，这种双重不完整使学习问题困难得多：模型必须从受损证据中推断可靠语义，同时避免对噪声大或信息较弱的视图过拟合 [10, 11]。



图内标签：View=视图；Cross-encoding=交叉编码；New combination=新组合；Semantics=语义；circle/arc/square/angularity/triangle=圆/弧/正方形/棱角/三角形。

图1： 两个核心动机的示意图。(a) 来自不同来源的跨视图编码应保持语义一致；(b) 不同视图在描述同一标签时天然存在差异。

从多视图表示学习的角度看，一个基本问题是如何在观测不完整时学习共同语义表示。多数现有不完整多视图多标签分类（iM3C）方法遵循以表示为中心的思路，通过共享表示学习、一致性正则化、信息瓶颈目标或变分潜变量建模来构造公共潜在表示，再在其上使用多标签分类器 [12, 13, 14, 15]。共享表示能够汇聚不同视图中观测到的、与目标相关的语义，因此有助于减轻视图缺失的影响 [16, 17]。但这种设计也隐含一个假设：只要得到足够好的公共表示，就能依据同一份融合证据预测所有标签。对于多标签任务而言，这一假设往往过于严格。

在多标签预测中，不同语义标签可能依赖不同的证据来源。例如，在多种眼病诊断中，由 RGB 图像得到的视图通常更适合检测糖尿病视网膜病变的多种典型可见病灶；而描述光学相干断层扫描（OCT）图像的视图则更有助于识别糖尿病性黄斑水肿。即使是同一个标签，其最可靠的视图也可能因噪声、遮挡或观测缺失而随样本变化；现有多标签融合方法通常忽略了这一点 [3, 18, 19]。因此，本文认为视图与标签之间的关系并非全局固定，而是依赖具体样本且具有标签特异性。本文将这一现象称为**视图—标签异质性**，如图1(b)所示。

这些观察表明，需要通过两种互补机制来解决该问题。第一种机制从不完整观测中学习稳健的共享语义空间；第二种机制显式评估每个可用视图对每个标签预测的贡献，避免标签特有的互补证据被全局融合压制。基于此，本文提出统一框架 V2L，将语义一致性学习与视图—标签异质性建模结合起来。具体而言，本文提出源扰动不变编码方案，以便在不完整观测下保留与任务相关的信息，并增强跨视图语义一致性，如图1(a)所示。值得注意的是，执行扰动对齐时，本文追求的是最大程度的多样性。在决策侧，本文设计主动式视图—标签相关性评估策略，评估样本级、标签感知的视图贡献，以实现自适应预测融合。这样，中层语义融合与后期决策融合被整合起来，而非作为彼此孤立的替代方案。

由此得到的框架建立了一条连贯路径，从多视图分布一致性建模过渡到自适应的、具备标签感知能力的决策聚合。它保留共享潜在表示学习的优势，同时避免所有标签都必须依赖单一融合表示或静态视图权重的局限。因此，该方法为不完整多视图多标签分类提供了统一解决方案，同时增强语义丰富性、跨视图一致性和标签敏感的预测适应能力。

本文的主要贡献如下：

- 从表示—决策的视角重新审视不完整多视图多标签分类，并指出视图—标签异质性是仅依赖表示层语义融合时的一项关键局限。
- 提出用于 iM3C 的混合框架 **V2L**，联合建模共同语义一致性与视图—标签异质性，从而在统一范式下连接表示层融合与决策层融合。
- 提出源扰动不变编码机制，在视图缺失与标签不完整同时存在时保留与任务相关的共享信息，并实现稳健的跨视图语义一致性。
- 提出主动式视图—标签异质性建模策略，刻画样本特定且具备标签感知能力的视图贡献，实现超越静态或全局可学习加权方案的自适应预测融合。

2 相关工作

2.1 多视图学习

多视图学习旨在联合利用同一个样本的多种表示；这些视图可以来自不同特征提取器、模态或数据来源 [1, 20, 21]。利用视图间的共享信息和互补信息，通常可以比单视图学习得到更稳健、更具判别性的表示。在无监督场景中，多视图聚类是最具代表性的研究方向之一。早期有影响力的工作主要通过协同训练或协同正则化来约束跨视图一致性 [22]。此后，多核方法和基于图的方法展现出整合异构视图的能力 [23, 24]；对于具有潜在低秩结构的高维数据，基于子空间的方法尤其有效 [25]。近期的图方法进一步通过张量化自适应共识图学习探索高阶跨视图相关性 [26]；锚图传播则被用于提升不完整多视图观测下的聚类可扩展性 [27]。近期深度变分多视图学习方法表现突出，同时也提供了坚实的理论基础 [28, 29, 14]。

另一个重要方向是不完整多视图学习，即训练或推理过程中可能缺失一个或多个视图 [30, 31]。为减轻观测缺失的影响，现有方法主要采用两种策略：视图补全或跳过缺失视图 [1]。例如，Liu 等人 [3] 根据样本间近邻图的聚合，在潜在空间中填补缺失视图；Lin 等人 [32] 采用对比学习追求一致特征，并通过跨视图预测恢复缺失视图。视图补全方法不可避免地增加计算复杂度，也有引入冗余噪声的风险。另一类方法则利用先验缺失信息，在前向和反向传播过程中屏蔽缺失视图 [33, 34]。

2.2 多标签分类

多标签分类旨在为每个样本分配多个语义标签，已广泛应用于视觉识别、推荐、医学诊断和文本理解。与单标签分类相比，其核心挑战不仅是提取判别特征，还包括刻画标签之间复杂的依赖结构 [5, 3]。近期研究已超越早期的问题转换策略 [35]，越来越多地关注更现实、稳健的设置，例如弱监督标签发现 [36]、单正例标注 [37] 和预测可靠性 [38]。例如，Li 等人 [39] 提出极弱监督下的开放世界多标签文本分类框架：标签空间并非预先完全给定，而是必须从原始文档中逐步发现。近期研究也越来越重视多标签预测器的可信性。Chen 等人 [40] 提出多标签置信度校准任务，并通过动态相关性学习提高多标签识别中置信度估计的可靠性。

然而，大多数多标签分类方法是在单视图或特征完全观测的条件下开发的。即使有多个模态或视图，许多方法仍强调全局特征融合，对不同标签可能依赖不同证据来源这一事实关注有限 [18, 41]。在多视图场景中，这一局限更加明显，因为某些标签天然更容易由特定视图解释。因此，对于本文研究的问题，仅建模标签相关性或仅增强最终分类器并不足够；还需要一种具备标签感知能力的机制，能够以样本为单位评估哪个视图对哪个标签贡献更大。

2.3 不完整多视图缺失多标签分类

不完整多视图缺失多标签分类（iM3C）处于不完整多视图学习与不完整多标签学习的交叉领域。其目标是在视图缺失与标签不完整同时存在时实现可靠的多标签预测 [10, 11, 4]。早期方法只针对单一缺失设置，因此难以同时处理视图与标签的双重缺失，例如 GLOCAL [42]、C2AE [43] 和 CDMM [44]。已知最早的 iM3C 工作是 IMvML [33]，它采用矩阵分解将多视图数据对齐到公共潜在空间。近期由于深度表示学习具有强大的特征提取能力，更多方法转向这一范式，例如 DICNet [45] 和 AIMNet [3]。这些研究奠定了 iM3C 的基本学习范式，并表明结合多视图互补性与弱标签监督能够带来显著收益。

然而，现有 iM3C 方法仍有两项与本文动机直接相关的局限。第一，许多方法优先构建稳健的共享表示，但对于如何在观测不完整时以语义充分的方式保留与任务相关的信息，处理有限。第二，现有方法忽略了视图与多个标签之间的依赖关系，简单地把 iM3C 视为表示学习与多标签分类的堆叠任务。这割裂了多个视图与多个标签之间的内在联系。换言之，现有方法未能充分阐明多视图语义一致性学习与标签判别之间的关系。

3 预备知识

3.1 问题定义与符号

令 $\{\mathbf{x}^{(v)}\}_{v=1}^{m}$ 表示从不同视图描述同一对象的 m 个随机变量，其中 $\mathbf{x}^{(v)} \in \mathbb{R}^{d_v}$；令 $\mathbf{y} \in \{0,\ 1\}^{c}$ 表示相应的多标签随机变量。分别用 $\mathcal{M} = \{1,\ 2,\ \ldots,\ m\}$ 和 $\mathcal{C} = \{1,\ 2,\ \ldots,\ c\}$ 表示完整的视图索引集合与标签索引集合。包含 n 个观测（样本）的数据集记为

$$\mathcal{D} = \{\left(\{x_i^{(v)}\}_{v=1}^{m},\ y_i\right)\}_{i=1}^{n},$$

其中 $x_i^{(v)}$ 和 y_i 分别是随机变量 $\mathbf{x}^{(v)}$ 与 $\mathbf{y}$ 的一次采样。

在不完整设置下，每个样本并非所有视图和标签都可观测。对于第 i 个样本，记 $\mathcal{V}_i \subseteq \mathcal{M}$ 为可用视图集合（不指代特定样本时也记作 $\mathcal{V}$），记 $\mathcal{G}_i \subseteq \mathcal{C}$ 为已观测标签集合。为便于形式化表示，再定义两个索引矩阵 $\mathbf{W} \in \mathbb{R}^{n\times m}$ 和 $\mathbf{R} \in \mathbb{R}^{n\times c}$，分别标记视图或标签是否可用：

$$\mathbf{W}_{i,v} = \begin{cases} 1, & \text{if } v \in \mathcal{V}_i \\ 0, & \text{otherwise} \end{cases}, \mathbf{R}_{i,j} = \begin{cases} 1, & \text{if } j \in \mathcal{G}_i \\ 0, & \text{otherwise} \end{cases}. \qquad (1)$$

式（1）中 if 表示“若”，otherwise 表示“其他情况”。

两种表示等价，即

$\mathcal{V}_i = \{v \in \mathcal{M} \mid \mathbf{W}_{i,v} = 1\}, \qquad \mathcal{G}_i = \{j \in \mathcal{C} \mid \mathbf{R}_{i,j} = 1\}.$

因此，不完整多视图多标签分类的目标是学习一个预测器，将不完整的多视图观测映射到完整标签空间：

$$f : \{x_i^{(v)}\}_{v\in\mathcal{V}_i} \mapsto y_i \in [0,1]^c, \qquad (2)$$

从而在视图与标签同时不完整时准确推断语义标签。

3.2 多视图数据中的任务相关共同语义

尽管不同视图来自异构来源或特征提取器，它们描述的仍是同一个底层样本。因此，多视图观测应当共享一部分反映目标共同属性的语义信息。这些共同语义信息构成在不完整观测下学习统一多视图表示的基础。

为形式化这一想法，本文引入概念性潜变量 $\mathbf{s}$，表示多个视图共享的共同语义信息。对于每个视图 $\mathbf{x}^{(v)}$，$\mathbf{s}$ 表示相应观测所支持的语义因素。由此得到如下假设。

假设 3.1（任务相关共同语义）。对于描述同一样本的多视图观测，存在一个各视图共享、且与标签变量 $\mathbf{y}$ 相关的潜在语义变量 $\mathbf{s}$。形式上，对每个视图 $v \in \mathcal{M}$，

$$I(\mathbf{x}^{(v)}; \mathbf{s}) > 0, \qquad I(\mathbf{s}; \mathbf{y}) > 0. \qquad (3)$$

这里的 $\mathbf{s}$ 仅用于描述多视图数据中的共同语义因素，并非模型中显式实现的额外潜变量。在这一假设下，理想的多视图表示 $\mathbf{z}$ 应保留 $\mathbf{s}$ 所携带的信息。这引出以下命题。

命题 3.2。如果多视图表示 $\mathbf{z}$ 保留了多个视图共享的共同语义信息 $\mathbf{s}$，那么 $\mathbf{z}$ 可以作为观测视图的共同语义表示。

3.3 多视图信息瓶颈框架

原则上，恰当构造的跨视图表示 $\mathbf{z}$ 可以捕获下游预测所需的信息。然而，原始多视图观测往往包含大量与目标无关的视图特有变化。因此，朴素融合可能会把这些无关因素引入 $\mathbf{z}$，产生冗余信息，遮蔽共享的任务相关信号，并降低 $\mathbf{z}$ 对 $\mathbf{y}$ 的可预测性 [46, 14]。这促使我们采用强调共享语义、抑制视图特有无关信息的学习策略，从而在现实条件下更好地保留 $\mathbf{z}$ 的充分性。

根据数据处理不等式，马尔可夫链

$\{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}} \rightarrow \mathbf{z} \rightarrow \mathbf{y}$

蕴含 $\{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}}$、 $\mathbf{z}$ 和 $\mathbf{y}$ 之间存在如下互信息关系：

$$I(\mathbf{z};\mathbf{y}) \leq I(\{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}};\mathbf{y}). \tag{4}$$

因此，如果编码过程没有丢失任何有助于预测 $\mathbf{y}$ 的信息，那么 $\mathbf{z}$ 对 $\mathbf{y}$ 是充分的 [47]，即

$$I(\mathbf{z};\mathbf{y}) = I(\{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}};\mathbf{y}). \tag{5}$$

不过，仅有充分性还不够，因为冗余表示仍可能保留大量视图特有的干扰信息。根据信息瓶颈原理，理想表示既要充分，也要紧凑，因此有

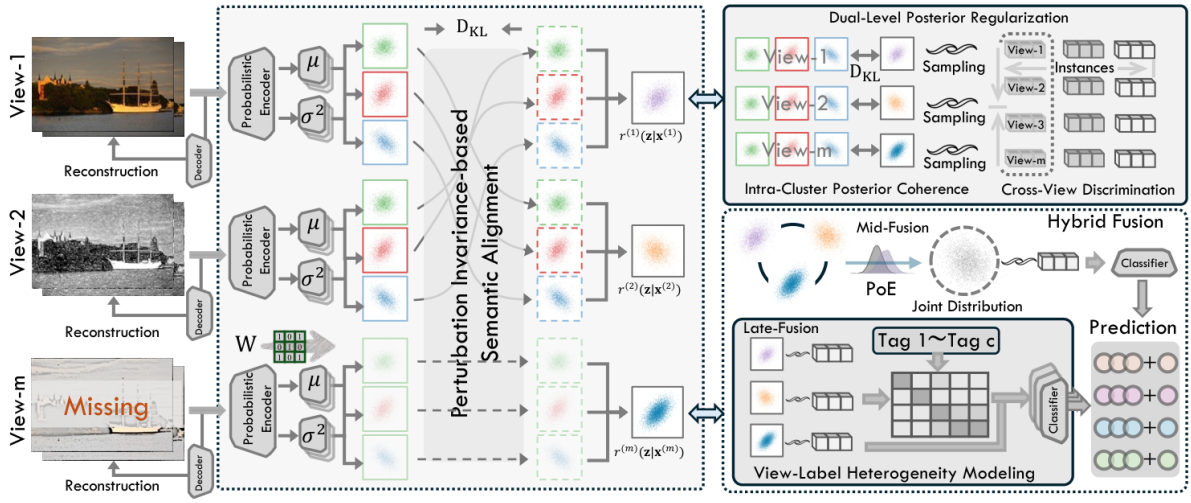
$$\min I(\{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}};\mathbf{z}) - I(\mathbf{z};\mathbf{y}). \tag{6}$$

这是多视图学习条件下信息瓶颈理论的自然形式。第一项可理解为信息编码的压缩过程；第二项则表示增强潜在编码与任务之间的相关性。

需要指出的是，上述充分性假设并非万无一失。尽管我们期望不同视图在语义上对目标保持一致，但从信息角度看，基于这种理想假设构建的模型可能忽略视图特有信息。因此，本文除了运用多视图信息瓶颈理论追求视图间语义一致性，还提出对视图—标签异质性进行建模，以补充视图特有线索。

4 方法

本节首先给出基于信息论的总体目标，然后介绍用于优化该目标的四个组成部分：源扰动不变编码、双层后验正则化、主动式视图—标签相关性建模和多标签分类。整体框架见图2。



图内标签：Probabilistic Encoder=概率编码器；Decoder=解码器；Reconstruction=重建；Missing=缺失；Perturbation Invariance-based Semantic Alignment=基于扰动不变性的语义对齐；Dual-Level Posterior Regularization=双层后验正则化；Intra-Cluster Posterior Coherence=

簇内后验一致性；Cross-View Discrimination=跨视图判别；Sampling=采样；Instances=实例；Classifier=分类器；Mid-/Late-/Hybrid Fusion=中层/后期/混合融合；Prediction=预测；Joint Distribution=联合分布；Tag=标签。

图2： V2L 的总体架构。模型以多视图变分编码器为主体。通过交换分布簇中的对应元素并保持分布不变，实现跨视图语义一致性；每个标签的决策依赖不同视图，共同形成多视图混合融合结构。引入缺失索引矩阵，防止不可用视图和标签参与训练。

4.1 总体目标

我们从以下观察出发：不完整多视图学习本质上是在观测缺失条件下提取共享语义的问题。令 $\mathbf{x}^{(u)}$ 与 $\mathbf{x}^{(v)}$ 表示两个已观测视图，且 $u \neq v$；令 $\mathbf{z}$ 表示联合多视图表示。为刻画 $\mathbf{z}$ 在何种条件下足以支持下游预测，考虑互信息分解：

$$\begin{aligned} I(\mathbf{x}^{(u)}; \mathbf{x}^{(v)}, \mathbf{z}) &= I(\mathbf{x}^{(u)}; \mathbf{z} \mid \mathbf{x}^{(v)}) + I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)}) \\ &= I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)} \mid \mathbf{z}) + I(\mathbf{z}; \mathbf{x}^{(u)}), \end{aligned} \tag{7}$$

从而得到

$$I(\mathbf{x}^{(u)}; \mathbf{z} \mid \mathbf{x}^{(v)}) = \underbrace{I(\mathbf{z}; \mathbf{x}^{(u)}) - I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)})}_{\text{minimality gap}} + \underbrace{I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)} \mid \mathbf{z})}_{\text{consistency gap}}. \tag{8}$$

式（8）中 minimality gap 为“最小性差距”，consistency gap 为“一致性差距”。

这一分解揭示了多视图表示学习的两个理想条件。第一，如果 $\mathbf{z}$ 包含视图间共享的全部信息，那么在给定 $\mathbf{z}$ 后，各视图之间的剩余依赖应消失，即 $I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)} \mid \mathbf{z}) = 0$。第二，如果 $\mathbf{z}$ 只包含共享信息，那么它与每个视图的互信息应与视图间共享部分相匹配，即 $I(\mathbf{z}; \mathbf{x}^{(u)}) - I(\mathbf{x}^{(v)}; \mathbf{x}^{(u)}) = 0$。在这两个条件下，条件互信息 $I(\mathbf{x}^{(u)}; \mathbf{z} \mid \mathbf{x}^{(v)})$ 为零；这就形式化了关于跨视图共同语义的最小充分性概念。

推论 4.1。对任意一对视图 $u \neq v$，假设 $\mathbf{z}$ 是保留 $\mathbf{x}^{(u)}$ 与 $\mathbf{x}^{(v)}$ 之间任务相关共同语义的最小表示。那么在给定 $\mathbf{x}^{(v)}$ 后，$\mathbf{x}^{(u)}$ 不再为 $\mathbf{z}$ 提供额外信息，即
$I(\mathbf{x}^{(u)}; \mathbf{z} \mid \mathbf{x}^{(v)}) = 0.$

该推论为表示学习目标提供了原则：理想的潜在表示应保留每个视图中的有效信息，同时抑制其他视图不支持的视图私有冗余。因此，结合该推论与信息瓶颈设计原则，可得表示学习目标：

$$\max \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} I(\mathbf{z}; \mathbf{x}^{(v)}), \text{ s.t. } \frac{1}{|\mathcal{V}|} \sum_{u,v \in \mathcal{V}}^{u \neq v} I(\mathbf{x}^{(u)}; \mathbf{z} \mid \mathbf{x}^{(v)}) = 0. \tag{9}$$

引入拉格朗日乘子 $\beta \geq 0$，得到

$$\max \frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}} I\big(\mathbf{z};\mathbf{x}^{(v)}\big) - \beta\cdot\frac{1}{|\mathcal{V}|}\sum_{u,v\in\mathcal{V}}^{u\neq v} I\big(\mathbf{x}^{(u)};\mathbf{z}\mid\mathbf{x}^{(v)}\big). \quad (10)$$

该目标刻画了框架中的表示部分：保留各视图中的有效信息，同时约束跨视图语义一致性。然而，对于不完整多视图多标签分类，该目标仍不完整，因为它没有显式考虑与任务相关的标签信息。为使学习到的表示能够用于多标签分类，我们进一步最大化共同潜在表示 $\mathbf{z}$ 与目标标签 $\mathbf{y}$ 之间的互信息，得到总体目标：

$$\begin{aligned}\max \frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}} I(\mathbf{z};\mathbf{x}^{(v)}) - \beta\cdot\frac{1}{|\mathcal{V}|}\sum_{u,v\in\mathcal{V}}^{u\neq v} I(\mathbf{x}^{(u)};\mathbf{z}\mid\mathbf{x}^{(v)}) \\ +\lambda I(\mathbf{z};\mathbf{y}),\end{aligned} \quad (11)$$

其中 $\lambda \geq 0$ 用于平衡表示一致性与任务相关性。

4.2 源扰动不变的跨视图编码

给出总体目标后，接下来要为其中的表示部分构造可处理的变分形式。理想潜在表示需同时满足两项要求：第一，每个潜在分量都应保留其对应视图所携带的信息；第二，当不同视图描述相同的底层语义时，相应的潜在后验应在不同视图间保持一致。这两项要求自然引出带有跨视图后验正则化的变分编码方案。

与现有变分框架只使用单个概率编码器（例如多层感知机 MLP）直接建模特定分布、近似 $p(\mathbf{z}\mid\mathbf{x}^{(v)})\approx r^{(v)}(\mathbf{z}\mid\mathbf{x}^{(v)})$ 不同，本文采用一组概率编码器，将每个视图的源数据映射到所有视图的潜在空间。对于每个可用源视图 $\mathbf{x}^{(v)}$，采用一组跨视图编码器，构造一簇以源视图为锚点的分布提议：

$$\{r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})\}_{l\in\mathcal{M}}, \quad (12)$$

其中 $r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})$ 表示共享潜变量 $\mathbf{z}$ 上的高斯后验提议，由来自第 v 个源视图、面向第 l 个目标视图的编码器头生成。所有提议后验都定义在同一共享潜在空间中。索引 l 表示面向目标视图的提议头，而非一个独立的潜变量。这些提议是由同一已观测视图诱导出的多个潜在投影，因此可以从不同跨视图角度考察 $\mathbf{x}^{(v)}$ 携带的信息，而不只依赖单一编码路径。

给定由 $\mathbf{x}^{(v)}$ 导出的提议簇后，我们将其汇总为单个视图特定后验 $r^{(v)}(\mathbf{z}\mid\mathbf{x}^{(v)})$：

$$r^{(v)}(\mathbf{z}|\mathbf{x}^{(v)}) = \mathcal{A}(\{r^{v\to l}(\mathbf{z}|\mathbf{x}^{(v)})\}_{l\in\mathcal{M}}) := \mathcal{N}(\boldsymbol{\mu}^{(v)},\boldsymbol{\Sigma}^{(v)}), \quad (13)$$

其中 $\mathcal{A}(\cdot)$ 表示对提议簇执行精度加权的高斯聚合，参数 $\boldsymbol{\mu}^{(v)}$ 与 $\boldsymbol{\Sigma}^{(v)}$ 为

$$\begin{aligned}\boldsymbol{\Sigma}^{(v)} &= (\mathbf{I} + \sum_{l\in\mathcal{M}} (\boldsymbol{\Sigma}^{v\to l})^{-1})^{-1},\\ \boldsymbol{\mu}^{(v)} &= \boldsymbol{\Sigma}^{(v)}(\sum_{l\in\mathcal{M}} (\boldsymbol{\Sigma}^{v\to l})^{-1}\boldsymbol{\mu}^{v\to l}),\end{aligned} \tag{14}$$

这里 $r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)}):=\mathcal{N}\left(\boldsymbol{\mu}^{v\to l},\,\boldsymbol{\Sigma}^{v\to l}\right)$，而 $\mathbf{I}$ 对应标准高斯先验。该精度加权高斯聚合会给方差较小的提议更大权重，从而抑制不确定的投影，保留更可靠的语义线索。这样，$r^{(v)}(\mathbf{z}\mid\mathbf{x}^{(v)})$ 就成为与视图 v 相关的汇总后验专家。这种“分歧—聚合”流程（$v\to\mathcal{M}\to v$）为扰动一致性对齐奠定了基础。

4.2.1 跨视图语义一致性的变分实现

回到式（11）中的前两项，我们先为保留视图有效信息推导可处理的目标。对于每个可用视图 $v\in\mathcal{V}$，互信息 $I(\mathbf{z};\mathbf{x}^{(v)})$ 衡量潜在后验保留了多少关于源观测的信息。根据互信息定义：

$$\begin{aligned}&I(\mathbf{x}^{(v)};\mathbf{z})\\ &=\iint p(\mathbf{x}^{(v)},\mathbf{z})\log\frac{p(\mathbf{x}^{(v)}|\mathbf{z})}{p(\mathbf{x}^{(v)})}\,d\mathbf{x}^{(v)}d\mathbf{z}\\ &=\iint p(\mathbf{x}^{(v)},\mathbf{z})\log p(\mathbf{x}^{(v)}|\mathbf{z})\,d\mathbf{x}^{(v)}d\mathbf{z}+H(\mathbf{x}^{(v)}).\end{aligned} \tag{15}$$

由于 $H(\mathbf{x}^{(v)})\geq 0$，最大化 $I(\mathbf{x}^{(v)};\mathbf{z})$ 可以通过最大化由 $\mathbf{z}$ 重建 $\mathbf{x}^{(v)}$ 的条件对数似然来给出下界。引入变分解码器 $q^{(v)}(\mathbf{x}^{(v)}\mid\mathbf{z})$，可得

$$I(\mathbf{x}^{(v)};\mathbf{z})\geq\mathbb{E}_{p(\mathbf{x}^{(v)})}\mathbb{E}_{r^{(v)}(\mathbf{z}|\mathbf{x}^{(v)})}\left[\log q^{(v)}(\mathbf{x}^{(v)}\mid\mathbf{z})\right]. \tag{16}$$

式（16）表明重建目标可自然地作为总体目标第一项的变分替代量。直观而言，该项可防止潜变量被过度压缩，并保留每个观测视图中的信息。

对于总体目标的第二项，考虑在给定 $\mathbf{x}^{(v)}$ 时 $\mathbf{x}^{(u)}$ 与 $\mathbf{z}$ 之间的条件互信息，其中 $u\neq v$：

$$\begin{aligned}&I(\mathbf{x}^{(u)};\mathbf{z}\mid\mathbf{x}^{(v)})\\ &=\iiint p(\mathbf{x}^{(u)},\mathbf{x}^{(v)},\mathbf{z})\log\frac{p(\mathbf{z}\mid\mathbf{x}^{(u)},\mathbf{x}^{(v)})}{p(\mathbf{z}\mid\mathbf{x}^{(v)})}\,d\mathbf{x}^{(u)}d\mathbf{x}^{(v)}d\mathbf{z}\\ &=\mathbb{E}_{p(\mathbf{x}^{(u)},\mathbf{x}^{(v)})}\left[D_{\mathrm{KL}}\left(p(\mathbf{z}\mid\mathbf{x}^{(u)},\mathbf{x}^{(v)})\|p(\mathbf{z}\mid\mathbf{x}^{(v)})\right)\right].\end{aligned} \tag{17}$$

这一表达式说明，降低 $I(\mathbf{x}^{(u)};\mathbf{z}\mid\mathbf{x}^{(v)})$，相当于让同时以两个视图为条件的后验接近仅以视图 v 为条件的后验。由于精确的条件互信息涉及不可处理的后验 $p(\mathbf{z}\mid\mathbf{x}^{(u)},\mathbf{x}^{(v)})$ 和 $p(\mathbf{z}\mid\mathbf{x}^{(v)})$，无法直接计算。因此，本文引入受条件互信息（CMI）启发的后验一致性替代项：

$$\mathcal{S}_{\mathrm{CMI}}^{(u,v)} = \sum_{l\in\mathcal{M}} D_{\mathrm{KL}}\Big(r^{u\to l}(\mathbf{z}\mid\mathbf{x}^{(u)}) \,\Big\|\, r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})\Big). \tag{18}$$

式（18）中的提议来自不同源视图，但对应同一个面向目标的提议头 l。最小化它们之间的差异，会促使面向目标的语义后验不受源视图变化的影响，与理想的零 CMI 条件一致。需要强调，$\mathcal{S}_{\mathrm{CMI}}^{(u,v)}$ 是可优化的一致性替代项，并非条件互信息的精确估计量或变分界。

依据式（16）的重建下界和式（18）中 CMI 启发的后验一致性替代项，本文用以下信息瓶颈损失 $\mathcal{L}_{\mathrm{ib}}$ 实例化表示学习目标：

$$\mathcal{L}_{\mathrm{ib}} = \mathcal{L}_{\mathrm{re}} + \beta\,\mathcal{L}_{\mathrm{consis}}, \tag{19}$$

其中

$$\mathcal{L}_{\mathrm{re}} = -\frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}} \mathbb{E}_{r^{(v)}(\mathbf{z}|\mathbf{x}^{(v)})}\big[\log q^{(v)}(\mathbf{x}^{(v)}\mid\mathbf{z})\big], \tag{20}$$

且

$$\mathcal{L}_{\mathrm{consis}} = \frac{1}{|\mathcal{V}|}\sum_{u,v\in\mathcal{V}}^{u\neq v}\sum_{l\in\mathcal{M}} D_{\mathrm{KL}}\big(r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)}) \,\|\, r^{u\to l}(\mathbf{z}\mid\mathbf{x}^{(u)})\big). \tag{21}$$

$\mathcal{L}_{\mathrm{re}}$ 保留视图有效信息并防止过度压缩；$\mathcal{L}_{\mathrm{consis}}$ 则促使每个目标视图对应的潜在后验能够由不同观测视图一致地诱导得到。二者结合，为不完整多视图观测下的最小充分性提供了可操作的实现。

4.2.2 源扰动不变性建模

尽管式（21）中的一致性正则项 $\mathcal{L}_{\mathrm{consis}}$ 直接鼓励跨视图语义一致性，但枚举所有有序视图对会带来不必要的计算负担，也可能使对齐过程过于僵硬。为获得更具可扩展性和稳健性的机制，本文进一步提出一种扰动不变策略：对以源视图为锚点的后验簇执行随机交换，而不是逐对迭代。

对于给定的可用源视图 v，它会产生语义提议簇
$\{r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})\}_{l\in\mathcal{M}}$.
将该潜在提议簇记作 $\mathcal{C}^{(v)}$：

$$\mathcal{C}^{(v)} = \{r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})\}_{l\in\mathcal{M}}. \tag{22}$$

每个簇都可以视作由一个观测视图诱导、并投影到所有目标潜在子空间的结构化语义描述。如果不同视图编码了相同的底层语义，那么即使扰动源视图关联，簇中对应元素的分布也应保持一致。

基于这一想法，对于每个样本，在可用视图集合 $\mathcal{V}$ 上随机生成扰动映射 $\pi:\mathcal{V}\to\mathcal{V}$，其中 $\pi(v)\neq v$。随后，将第 l 个提议原来的源视图关联替换为其对应项，形成扰动后的簇：

$$\widetilde{\mathcal{C}}^{(v)}=\{r^{\pi(v)\to l}(\mathbf{z}\mid\mathbf{x}^{(\pi(v))})\}_{l\in\mathcal{M}}. \tag{23}$$

根据前文提出的最小充分性原则，如果不同观测视图在与目标相关的层面上语义一致，那么置换源视图身份不应改变面向目标的潜在语义。由此得到以下推论。

推论 4.2（源扰动不变性）。如果两个视图在目标相关信息方面语义等价，那么交换它们作为源视图的角色不会改变诱导出的提议簇，即 $\mathcal{C}^{(v)}$ 与 $\widetilde{\mathcal{C}}^{(v)}$ 在目标维度的分布上等价。因此，对任意 $l\in\mathcal{M}$，有

$$D_{\mathrm{KL}}\big(r^{v\to l}(\mathbf{z}\mid\mathbf{x}^{(v)})\;\|\;r^{\pi(v)\to l}(\mathbf{z}\mid\mathbf{x}^{(\pi(v))})\big)=0.$$

此外，交换方案旨在促进不同目标间的多样性。对于固定源视图 v，分配给不同目标的交换源不能重复：

$$\pi_l(v)\neq\pi_{l'}(v),\qquad\forall\, l\neq l',\quad l,l'\in\mathcal{M}, \tag{24}$$

其中 $\pi_l(v)$ 和 $\pi'_l(v)$ 分别表示第 l 个与第 l' 个随机映射。（译注：此处正文按原文写作 $\pi'_l(v)$，而式（24）使用 $\pi_{l'}(v)$；两处符号不一致，均予保留。）等价地，

$$|\{\pi_l(v):l\in\mathcal{M}\}|=|\mathcal{M}|.$$

因此，面向不同目标的提议会与语义一致但彼此不同的源锚点进行匹配，从而避免不同目标反复对比同一个交换视图，并丰富簇级语义对齐的监督信号。

综上，本文不再穷举匹配所有有序视图对，而是通过约束原始簇与其置换版本之间的差异来改写 $\mathcal{L}_{\text{consis}}$：

$$\mathcal{L}_{\text{consis}}=\frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}}\sum_{l\in\mathcal{M}}D_{\mathrm{KL}}\big(r^{v\to l}(\mathbf{z}|\mathbf{x}^{(v)})\|r^{\pi(v)\to l}(\mathbf{z}|\mathbf{x}^{(\pi(v))})\big). \tag{25}$$

需要强调，所提出的感知扰动一致性损失并不假设所有视图在原始输入层面完全相同，只要求其潜在语义提议在目标相关层面保持一致。因此，模型仍可通过重建路径保留适度的视图特有信息，同时由感知扰动一致性正则化抑制视图私有变化。这一点在不完整观测下尤为重要，因为直接施加硬对齐可能会放大低质量视图或部分缺失视图中的噪声。相比之下，本文的扰动一致性建模以更柔和、更高效的方式促进视图间语义凝聚，同时保留实际多视图多标签预测所需的灵活性。

4.3 双层后验正则化

源扰动不变编码促使以源视图为锚点的语义提议在分布上保持一致，但它没有显式约束每个提议簇内部的后验一致性，也没有显式约束同一样本不同观测视图之间的实例级可区分性。为进一步稳定潜在语义学习，本文引入双层后验正则化方案，包括簇内后验一致性正则化和跨视图实例级后验判别。

簇内后验一致性。 对给定的观测视图 $v \in \mathcal{V}$，源锚定提议簇 $\{r^{v\to l}(\mathbf{z} \mid \mathbf{x}^{(v)})\}_{l\in\mathcal{M}}$ 包含由同一源观测诱导出的多个潜在提议。为减少提议簇中的视图特定漂移，本文促使每个源诱导提议与相应的视图特定后验 $r^{(v)}(\mathbf{z} \mid \mathbf{x}^{(v)})$ 对齐：

$$\mathcal{L}_{\text{intra}} = \frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}}\sum_{l\in\mathcal{M}} D_{\text{KL}}\big(r^{v\to l}(\mathbf{z} \mid \mathbf{x}^{(v)}) \,\|\, r^{(v)}(\mathbf{z} \mid \mathbf{x}^{(v)})\big). \quad (26)$$

跨视图后验判别。 同一样本在不同观测视图下的表示经语义编码后应保持接近，同时不同样本的表示仍应可区分。为此，本文通过实例感知的跨视图判别目标对视图级后验均值进行正则化。

令 $\boldsymbol{\mu}_i^{(v)} \in \mathbb{R}^d$ 表示第 i 个样本在视图 v 下对应的后验均值，令 $\widetilde{\boldsymbol{\mu}}_i^{(v)} = f_{l_2}(\boldsymbol{\mu}_i^{(v)})$ 表示其经过 l_2 归一化后的形式。对于分别来自视图 v 和 u 的样本 i 与 j，定义

$$s_{i,j}^{(v,u)} = \frac{\langle \widetilde{\boldsymbol{\mu}}_i^{(v)}, \widetilde{\boldsymbol{\mu}}_j^{(u)} \rangle}{\tau},$$

其中 $\tau > 0$ 为温度参数。于是，跨视图后验判别损失写为

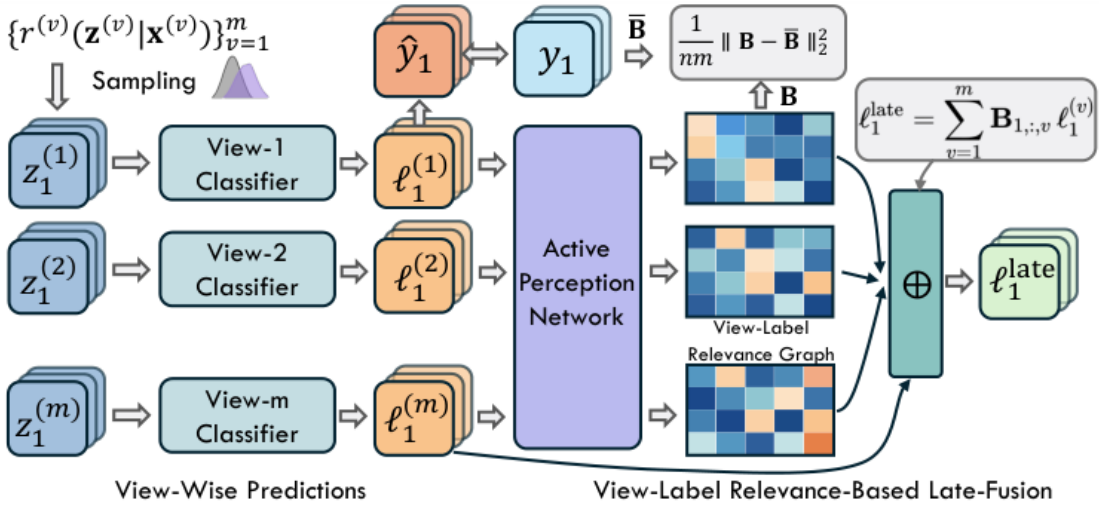
$$\mathcal{L}_{\text{cross}} = -\frac{1}{n}\sum_{i=1}^{n}\sum_{v,u=1}^{m} \mathbf{W}_{i,v}\mathbf{W}_{i,u} \log \frac{\exp\big(s_{i,i}^{(v,u)}\big)}{\sum_{j=1}^{n}\exp\big(s_{i,j}^{(v,u)}\big)\mathbf{W}_{j,u}}. \quad (27)$$

式（27）实现一种对比式后验正则化：同一实例不同视图下的后验被视作正样本，不同实例下的后验则作为负样本。这既鼓励跨视图语义一致性，也保留实例级可区分性。

总体而言，后验正则化损失为

$$\mathcal{L}_{\text{post}} = \sigma\mathcal{L}_{\text{intra}} + \gamma\mathcal{L}_{\text{cross}}.$$

它从两个方面补充扰动不变性正则化：$\mathcal{L}_{\text{intra}}$ 提高同一源视图生成的目标特定语义提议之间的一致性；$\mathcal{L}_{\text{cross}}$ 则增强不同观测视图之间的实例级可区分性。σ 与 γ 为权衡系数。



图内标签：View-Wise Predictions=逐视图预测；Active Perception Network=主动感知网络；View-Label Relevance Graph=视图—标签相关性图；View-Label Relevance-Based Late-Fusion=基于视图—标签相关性的后期融合。

图3： 视图—标签异质性建模示意图。主动感知网络为每个实例、每个视图提供标签感知的相关性分数，用于各视图的 logit。

4.4 主动式视图—标签相关性建模

前述表示学习目标主要针对共享语义充分性。但回到总体目标，最后一项要求学习到的表示尽可能包含关于目标标签的信息。常见做法是最大化 $I(\mathbf{z};\mathbf{y})$ 的一个变分下界；在实践中，这相当于最小化真实标签与模型预测之间的二元交叉熵（BCE）。然而，如果这一项只通过基于融合表示的单一预测器来实现，优化过程就会主要奖励全局共享语义，而可能忽略两个重要问题：(1) 不同视图如何贡献于最终预测？(2) 如何区分不同标签？前者体现了探索多视图互补性的需要；后者强调从上游表示学习过渡到下游多标签分类的重要性。

为处理这两个问题，本节提出视图—标签异质性建模策略，其动机是：在样本层面，不同视图对不同标签的贡献并不相同。

定义 4.3（视图—标签异质性）。对样本 i，令 $s_{i,j}^{(v)}$ 表示视图 v 对标签 j 的预测效用。如果存在标签 $j_1 \neq j_2$ 或样本 $i_1 \neq i_2$，使得
$s_{i,j_1}^{(v)} \neq s_{i,j_2}^{(v)}$ ？ $s_{i_1,j}^{(v)} \neq s_{i_2,j}^{(v)}$,
则多视图多标签数据呈现视图—标签异质性。

该定义意味着，与某个标签相关的视图对另一个标签可能毫无信息，而且相关性还会随样本而变。因此，我们不能只把多个视图的联合表示映射到标签空间，而应建模特定视图与特定标签之间的相关性。要以细粒度建模视图—标签异质性，仅依赖中层多视图融合显然不够。因此，本文在将多视图联合特征映射到标签预测的同时引入决策层融合，形成结合中层表示融合与后期决策融合的混合多视图融合框架。

对于中层表示融合，给定视图特定近似分布 $r^{(v)}(\mathbf{z} \mid \mathbf{x}^{(v)})$，通过对所有可用视图的视图特定后验执行 PoE（专家乘积）操作，构造联合近似后验：

$$r(\mathbf{z}|\mathbf{x}^{\mathcal{V}}) := p(\mathbf{z}) \prod_{v\in\mathcal{V}} r^{(v)}(\mathbf{z}|\mathbf{x}^{(v)}), \tag{28}$$

其中 $\mathbf{x}^{\mathcal{V}} = \{\mathbf{x}^{(v)}\}_{v\in\mathcal{V}}$，为方便起见，$p(\mathbf{z})$ 设为标准高斯分布。实际实现中，中层融合分支所用的联合潜在表示从 $z_i \sim r(\mathbf{z} \mid \mathbf{x}^{\mathcal{V}})$ 采样；可用视图 $v \in \mathcal{V}$ 对应的潜在表示从 $z_i^{(v)} \sim r^{(v)}(\mathbf{z} \mid \mathbf{x}^{(v)})$ 采样。z_i 与 $z_i^{(v)}$ 均通过重参数化技巧获得。联合表示通常用于产生中层语义预测 $\hat{y}_i^{\text{mid}}$：

$$\ell_i^{\text{mid}} = g(z_i), \qquad \hat{y}_i^{\text{mid}} = f_{sig}(\ell_i^{\text{mid}}), \tag{29}$$

其中 $g(\cdot)$ 表示共享分类器，ℓ_i^{mid} 是中层融合的 logit 分数，f_{sig} 表示 Sigmoid 激活函数。该分支主要传递由源扰动不变编码保留的共享语义证据。

同时，对于后期决策融合，每个视图特定表示都映射到各自的决策分支：

$$\ell_i^{(v)} = g^{(v)}(z_i^{(v)}), \qquad \hat{y}_i^{(v)} = f_{sig}(\ell_i^{(v)}), \quad v \in \mathcal{M}, \tag{30}$$

其中 $\ell_i^{(v)}$、$g^{(v)}$ 和 $\hat{y}_i^{(v)}$ 分别表示视图 v 对应的 logit、分类器和预测。

给定这些视图特定 logit $\{\ell_i^{(v)}\}_{v\in\mathcal{M}}$，现有融合策略显然不足，因为视图贡献同时取决于标签和样本。因此，将各视图、各实例的 logit 堆叠为张量

$$\mathbf{L} = \left[\ell_i^{(1)}, \ldots, \ell_i^{(m)}\right]_{i=1}^{n}, \qquad \mathbf{L} \in \mathbb{R}^{n\times c\times m}.$$

对于第 j 个标签，将对应的 logit $\mathbf{L}_{i,j,:}$ 输入主动感知网络 $f_{\text{act}}(\cdot)$，以估计各视图与该标签的相关性。所得相关性图 $\mathbf{B} \in \mathbb{R}^{n\times c\times m}$ 定义为

$$\mathbf{B}_{i,j,v} = \frac{\exp\left(f_{act}(\mathbf{L}_{i,j,v})\right)\mathbf{W}_{i,v}}{\sum_{u=1}^{m}\exp\left(f_{act}(\mathbf{L}_{i,j,u})\right)\mathbf{W}_{i,u}}, \tag{31}$$

其中归一化过程会排除不可用视图。需要指出，本文的视图—标签异质性感知方法，既不同于静态后期融合，也不同于为同一视图中的所有样本赋予相同权重的视图级动态策略。

基于相关性图，后期融合决策分支以标签感知的方式聚合逐视图 logit：

$$\ell_i^{\text{late}} = \sum_{v=1}^{m} \mathbf{B}_{i,:,v}\,\ell_i^{(v)}. \tag{32}$$

然后，在同一 logit 空间中组合中层语义 logit 与后期决策 logit，得到最终预测：

$$\hat{y}_i = f_{sig}\left(\ell_i^{\text{mid}} + \ell_i^{\text{late}}\right). \tag{33}$$

这样，中层分支提供语义稳定的共享证据，后期分支则保留各视图对特定标签的互补贡献。

接下来的问题是：如何确保主动感知网络 $f_{\text{act}}(\cdot)$ 的输出有效？直观而言，一个视图对某标签的预测效用应直接反映在它的预测表现上。因此，本文建立一种自引导监督机制：依据变分框架自身建模分布的质量判别结果，对主动感知网络进行监督。

令 $\mathbf{E}$ 表示逐视图预测误差张量，其元素计算为

$$\mathbf{E}_{i,j,v} = -\left[y_{i,j}\log\hat{y}_{i,j}^{(v)} + (1-y_{i,j})\log(1-\hat{y}_{i,j}^{(v)})\right]. \tag{34}$$

将误差转换为目标相关性权重：

$$\bar{\mathbf{B}}_{i,j,v} = \frac{\exp(-\mathbf{E}_{i,j,v})\,\mathbf{W}_{i,v}}{\sum_{u=1}^{m}\exp(-\mathbf{E}_{i,j,u})\,\mathbf{W}_{i,u}}, \tag{35}$$

从而使预测误差较小的视图获得较大的目标相关性。相应的相关性正则化项为

$$\mathcal{L}_{\text{rele}} = \frac{1}{n}\sum_{i=1}^{n}\frac{1}{|\mathcal{G}_i||\mathcal{V}_i|}\sum_{j=1}^{c}\mathbf{R}_{i,j}\sum_{v=1}^{m}\mathbf{W}_{i,v}(\mathbf{B}_{i,j,v}-\bar{\mathbf{B}}_{i,j,v})^2. \tag{36}$$

值得注意的是，为避免干扰主要变分框架，误差 $\mathbf{E}$ 和目标 $\bar{\mathbf{B}}$ 只用于监督主动感知器的学习，从而保证训练稳定性和推理过程的独立性。

4.5 多标签分类与总体损失

根据问题定义中的标签索引矩阵 $\mathbf{R}$，第 i 个样本只有 $\mathcal{G}_i$ 中的标签参与监督学习。因此，最终多标签分类损失只针对已观测标签和混合预测 $\widehat{y_i}$ 定义。此外，由于自适应决策分支建立在逐视图预测之上，每个单视图分类器也应具备足够的预测能力。引入视图索引矩阵 $\mathbf{W}$，总体多标签分类损失 $\mathcal{L}_{\text{cls}}$ 定义为

$$\begin{aligned}\mathcal{L}_{\text{cls}} = -\frac{1}{n}\sum_{i=1}^{n}\frac{1}{|\mathcal{G}_i|}\sum_{j=1}^{c}\mathbf{R}_{i,j}\big[&(y_{i,j}\log\hat{y}_{i,j}+(1-y_{i,j})\log(1-\hat{y}_{i,j}))\\ &+\frac{1}{|\mathcal{V}_i|}\sum_{v=1}^{m}\mathbf{W}_{i,v}(y_{i,j}\log\hat{y}_{i,j}^{(v)}+(1-y_{i,j})\log(1-\hat{y}_{i,j}^{(v)}))\big].\end{aligned} \tag{37}$$

结合信息瓶颈损失 $\mathcal{L}_{\text{ib}}$、后验正则化损失 $\mathcal{L}_{\text{post}}$、视图—标签相关性损失 $\mathcal{L}_{\text{rele}}$ 和分类损失 $\mathcal{L}_{\text{cls}}$，总体训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \mathcal{L}_{\text{rele}} + \mathcal{L}_{\text{ib}} + \mathcal{L}_{\text{post}}. \tag{38}$$

其中 $\mathcal{L}_{\text{ib}} = \mathcal{L}_{\text{re}} + \beta\mathcal{L}_{\text{consis}}$，且 $\mathcal{L}_{\text{post}} = \sigma\mathcal{L}_{\text{intra}} + \gamma\mathcal{L}_{\text{cross}}$，包含三个权衡系数。在该总体训练目标中，前两项实现对 $I(\mathbf{z};\mathbf{y})$ 的预测性估计，剩余各项则促进跨视图语义一致性。这样，预测目标与表示目标便在统一框架内共同优化。

为更清楚地概括上述组成部分，V2L 的总体训练流程如算法1所示。整个框架可以理解为每次迭代中紧密耦合的两个阶段：首先，模型从不完整多视图观测中学习语义充分且一致的潜在表示；其次，依据学到的视图—标签相关性图执行标签感知的决策融合，并通过最小化统一目标更新全部参数。

Algorithm 1 Training Procedure of V2L

Input: Incomplete multi-view data $\mathcal{D} = \{(\{\mathbf{x}^{(v)}\}_{v=1}^{m}, \mathbf{y})\}$, view index matrix $\mathbf{W}$, label index matrix $\mathbf{R}$, training epochs T, learning rate, and trade-off coefficients β, σ, and γ.
Output: The parameters of encoders, decoders, classifiers, and active perception network.
for $t = 1, \ldots, T$ **do**
    Compute source-anchored proposal cluster $\{r^{v\to u}(\mathbf{z} \mid \mathbf{x}^{(v)})\}_{u\in\mathcal{M}}$ for each available view.
    Aggregate proposal clusters by Eq. (13) to obtain view-specific posteriors $\{r^{(v)}(\mathbf{z} \mid \mathbf{x}^{(v)})\}_{v\in\mathcal{V}}$.
    Construct the common posterior $r(\mathbf{z} \mid \mathbf{x}^{\mathcal{V}})$ by Eq. (28) and sample latent variables $\mathbf{z}$.
    Reconstruct each observed view by decoders $q^{(v)}(\mathbf{x}^{(v)} \mid \mathbf{z})$ and compute $\mathcal{L}_{\mathrm{re}}$.
    Perform source-perturbation invariance matching and compute $\mathcal{L}_{\mathrm{consis}}$, $\mathcal{L}_{\mathrm{intra}}$, and $\mathcal{L}_{\mathrm{cross}}$.
    Sample view-specific representation $z_i^{(v)}$ and joint representation z_i from $r^{(v)}(\mathbf{z} \mid \mathbf{x}^{\mathcal{V}})$ and $r(\mathbf{z} \mid \mathbf{x}^{\mathcal{V}})$, respectively.
    Obtain the mid-level prediction $\hat{y}_i^{\mathrm{mid}}$ by Eq. (29) and the view-specific predictions $\{\hat{y}_i^{(v)}\}_{v=1}^{m}$ by Eq. (30) for each sample i.
    Build the logit tensor $\mathbf{L}$, infer the view-label relevance graph $\mathbf{B}$ by Eq. (31), and obtain the late-fusion logits by Eq. (32).
    Compute the final prediction $\hat{y}_i$ by Eq. (33), the target relevance graph $\bar{\mathbf{B}}$ by Eq. (35), and the relevance loss $\mathcal{L}_{\mathrm{rele}}$.
    Compute the information bottleneck loss $\mathcal{L}_{\mathrm{ib}}$ and the posterior regularization loss $\mathcal{L}_{\mathrm{post}} = \sigma\mathcal{L}_{\mathrm{intra}} + \gamma\mathcal{L}_{\mathrm{cross}}$.
    Compute the classification loss $\mathcal{L}_{\mathrm{cls}}$ on observed labels and total objective $\mathcal{L}$ by Eq. (38).
    Update all network parameters by back-propagation with respect to $\mathcal{L}$.
end for
Return the trained V2L model for inference.

算法1：V2L 训练流程（逐项中文译文）

输入： 不完整多视图数据 $\mathcal{D}=\{\left(\{\mathbf{x}^{(v)}\}_{v=1}^{m},\mathbf{y}\right)\}$，视图索引矩阵 $\mathbf{W}$，标签索引矩阵 $\mathbf{R}$，训练轮数 T、学习率，以及权衡系数 β,σ,γ。
输出： 编码器、解码器、分类器和主动感知网络的参数。

对 $t=1,\ldots,T$，执行：

1. 对每个可用视图计算源锚定提议簇 $\{r^{v\to u}(\mathbf{z}\mid\mathbf{x}^{(v)})\}_{u\in\mathcal{M}}$。
2. 按式（13）精度加权聚合提议簇，得到视图特定后验 $\{r^{(v)}(\mathbf{z}\mid\mathbf{x}^{(v)})\}_{v\in\mathcal{V}}$。
3. 按式（28）构造共同后验 $r\left(\mathbf{z}\mid\mathbf{x}^{\mathcal{V}}\right)$ 并采样潜变量 $\mathbf{z}$。
4. 用解码器 $q^{(v)}(\mathbf{x}^{(v)}\mid\mathbf{z})$ 重建每个观测视图，并计算 $\mathcal{L}_{\text{re}}$。
5. 执行源扰动不变性匹配，计算 $\mathcal{L}_{\text{consis}}$、$\mathcal{L}_{\text{intra}}$ 和 $\mathcal{L}_{\text{cross}}$。
6. 分别从 $r^{(v)}\left(\mathbf{z}\mid\mathbf{x}^{\mathcal{V}}\right)$ 和 $r\left(\mathbf{z}\mid\mathbf{x}^{\mathcal{V}}\right)$ 采样视图特定表示 $z_i^{(v)}$ 和联合表示 z_i。（原文此处将视图特定表示的条件写作 $r^{(v)}\left(\mathbf{z}\mid\mathbf{x}^{\mathcal{V}}\right)$，与前文定义 $r^{(v)}(\mathbf{z}\mid\mathbf{x}^{(v)})$ 不一致，译文保留这一处原文表述。）
7. 根据式（29）获得中层预测 $\widehat{y}_i^{\text{mid}}$ 及根据式（30）获得每个样本的逐视图预测 $\{\widehat{y}_i^{(v)}\}_{v=1}^{m}$。
8. 构建 logit 张量 $\mathbf{L}$，按式（31）推断视图—标签相关性图 $\mathbf{B}$，并按式（32）得到后期融合 logit。
9. 按式（33）计算最终预测 $\widehat{y}_i$、按式（35）计算目标相关性图 $\overline{\mathbf{B}}$ 和相关性损失 $\mathcal{L}_{\text{rele}}$。
10. 计算信息瓶颈损失 $\mathcal{L}_{\text{ib}}$ 和后验正则化损失 $\mathcal{L}_{\text{post}}=\sigma\mathcal{L}_{\text{intra}}+\gamma\mathcal{L}_{\text{cross}}$。
11. 在已观测标签上计算分类损失 $\mathcal{L}_{\text{cls}}$，并按式（38）计算总体目标 $\mathcal{L}$。
12. 根据 $\mathcal{L}$ 反向传播，更新所有网络参数。

返回训练完成、用于推理的 V2L 模型。

4.6 复杂度分析

令 b 表示小批次大小，C_{enc} 和 C_{dec} 分别表示一个概率编码器和一个解码器的计算开销。每个可用源视图由 m 个面向目标的编码器头处理，因此提议生成需要 $\mathcal{O}\left(b|\mathcal{V}|mC_{\text{enc}}\right)$ 次运算。重建项和后验对齐项分别需要 $\mathcal{O}\left(b|\mathcal{V}|C_{\text{dec}}\right)$ 与 $\mathcal{O}(b|\mathcal{V}|md)$；批次级跨视图判别项的最坏情况复杂度为 $\mathcal{O}\left(b^2|\mathcal{V}|^2d\right)$。PoE 融合、多标签分类和主动视图—标签融合分别引入 $\mathcal{O}(b|\mathcal{V}|d)$、$\mathcal{O}(b(|\mathcal{V}|+1)dc)$ 和 $\mathcal{O}(b|\mathcal{V}|c)$ 的开销。因此，主要额外计算成本来自训练期间的提议生成和跨视图后验判别。

4.7 讨论：共同语义与视图—标签相关性

问题1：语义共识假设是否与视图互补性相矛盾?

不矛盾。任务相关共同语义假设是在表示学习层面提出的。它促使模型从不完整视图中推断出的潜在表示保留多个视图共同支持、且与标签空间相关的语义信息，从而为跨视图对齐提供稳定基础。这并不意味着不同视图对所有标签贡献相同，也不排除标签特定的互补证据。

在决策层面，V2L 为每个可用视图保留独立的后验样本 $z_i^{(v)}$、分类器 $g^{(v)}$ 和 logit 向量 $\ell_i^{(v)}$。这些视图特定分支允许共享后验未能完整表示的标签判别证据通过后期融合参与预测。随后，相关性图 $\mathbf{B}$ 为每个样本、每个标签分别确定各可用视图的贡献。因此，V2L 所说的视图互补性，是保留并自适应利用有用的预测差异，而不是鼓励视图之间任意分歧。

问题2：为什么建模样本级、标签级的视图相关性，而不使用全局视图权重?

全局视图加权假设每个视图的贡献在不同标签和样本间固定不变；对于不完整多视图多标签学习而言，这一假设过于严格。真实场景中的视图重要性可能同时随目标标签和输入样本变化。此外，仅依赖融合表示可能会压制对某些标签有用的细粒度视图特有线索。通过估计样本级、标签级的视图相关性，模型可以显式捕获这种异质依赖，并自适应聚合视图特定预测，从而同时利用稳健的共享语义融合和灵活的标签特定互补融合。

5 实验

5.1 实验设置

数据集

遵循近期 iM3C 研究 [10, 45, 3]，本文在五个常用多视图多标签基准上评估所提方法：Corel5k [48]、Pascal07 [49]、ESPGame [50]、IAPRTC12 [51] 和 MIRFLICKR [52]。所有数据集中的每个样本均由六种视觉视图表示：GIST、HSV、DenseHue、DenseSIFT、RGB 和 LAB。为保证公平比较，采用现有 iM3C 文献中的特征设置与基准划分。数据集的详细统计信息见表1。

表1：五个多视图多标签数据集的详细统计信息。 表头依次为数据集、样本数、标签数、视图数与每样本平均标签数。

Database	# Sample	# Label	# View	# Label/#Sample
Corel5k	4999	260	6	3.40
Pascal07	9963	20	6	1.47
ESPGame	20770	268	6	4.69
IAPRTC12	19627	291	6	5.72
MIRFLICKR	25000	38	6	4.72

- **Corel5k** 是常用的图像标注与多标签分类基准，包含 4,999 张图像和 260 个语义标签。每张图像通常对应 1 至 5 个标签。
- **Pascal07** 源自 PASCAL VOC 2007 基准，包含 9,963 张图像和 20 个对象类别，是评估视觉识别方法最常用的数据集之一。
- **ESPGame** 包含从在线图像标注游戏中收集的 20,770 张图像，并标注了 268 个标签。每张图像平均包含 4.69 个语义标签。
- **IAPRTC12** 是大型图像标注与检索基准，包含 19,627 张图像和 291 个类别。每张图像最多可关联 23 个标签。

- **MIRFLICKR** 包含从 Flickr 收集的 25,000 张图像和 38 个语义类别，为多标签视觉理解提供了较丰富的用户生成标注。

不完整数据的构造

为模拟不完整多视图、缺失多标签设置，本文遵循以往 iM3C 研究采用的标准协议 [33, 10, 45, 14]。具体而言，对每个数据集，在每个视图上随机移除一定比例的样本，同时确保每个样本至少保留一个可用视图。此外，对每个样本随机屏蔽一定比例的正、负标签，并将其视为未知。除非另有说明，视图缺失率和标签缺失率均设为 50%。

构造不完整数据集后，按 70%、15% 和 15% 的比例随机划分训练集、验证集与测试集。训练时依据相应索引矩阵，只使用已观测视图和已知标签；测试时输入不完整视图，但使用完整真实标签进行评估。

对比方法

为评估 V2L，本文将其与三个相关类别中的代表性方法比较：完整多视图多标签方法 CDMM [44] 和 LVSL [41]；不完整多标签学习方法 DM2L [7]；以及专门针对 iM3C 的方法 iMVWL [33]、NAIM3L [10]、DICNet [45]、DIMC [53]、MSLPP [54]、SIP [14] 和 QARF [55]。对于原本并非针对视图与标签同时不完整而设计的方法，本文遵循既有研究 [41, 10] 的标准适配协议：用相应的平均特征填补缺失视图，并在监督损失中排除未观测标签。为保证比较公平，使用已发布代码，并依据推荐设置调节超参数。

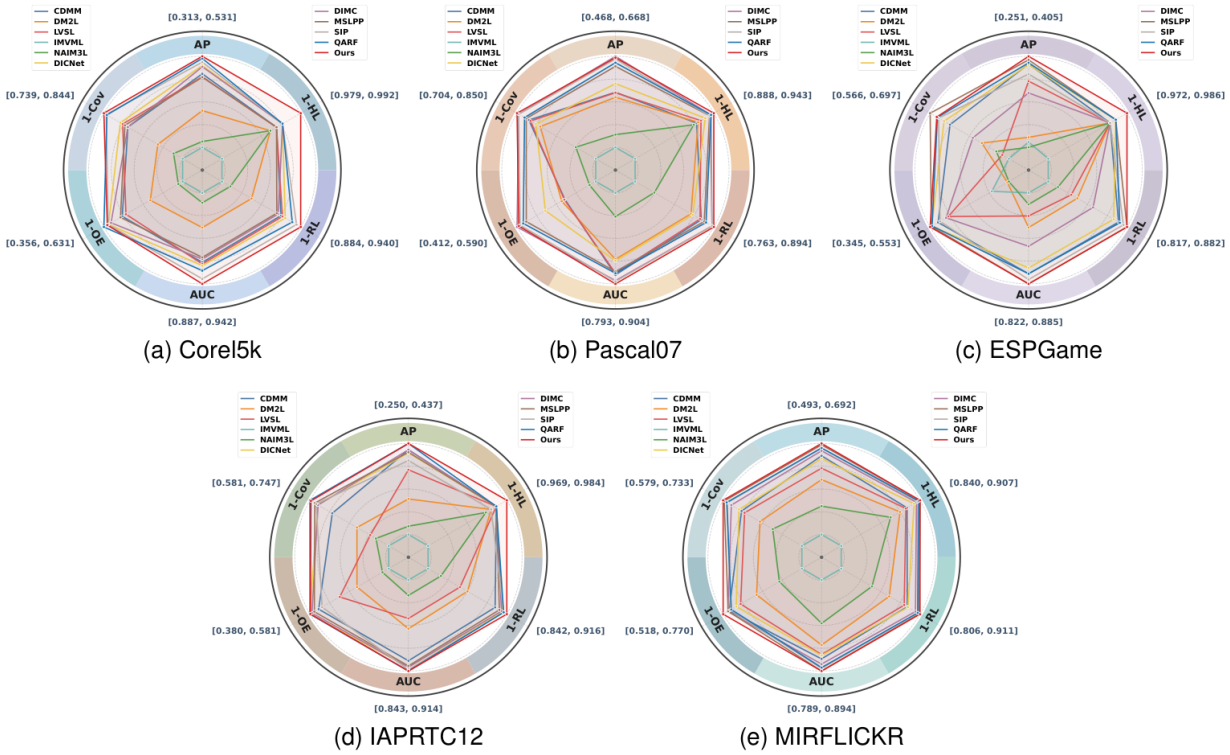
评价指标

为与既有工作保持一致，本文报告六种标准多标签指标：平均精度（AP）、汉明损失（HL）、排序损失（RL）、ROC 曲线下面积（AUC）、单错误率（OE）和覆盖率（Cov）。为使所有指标的方向一致，除 AP 和 AUC 外，报告 $1-\mathrm{HL}$、$1-\mathrm{RL}$、$1-\mathrm{OE}$ 和 $1-\mathrm{Cov}$，因此所有指标均为数值越大越好。遵循多标签评估中的常用协议，最终结果报告 10 折的均值与标准差。

实现细节

V2L 使用 PyTorch 实现。除非另行说明，潜在维度设为 512，批次大小设为 128，并使用学习率为 1×10^{-3} 的 Adam 优化器。总训练轮数为 100；前 10 轮用于预热，之后才启用视图—标签相关性监督项。权衡系数根据训练候选范围在验证集上选择。

5.2 实验结果与分析



(a) Corel5k (b) Pascal07 (c) ESPGame

(d) IAPRTC12 (e) MIRFLICKR

图内 Ours 指本文方法；各指标缩写见评价指标小节。

图4： 五个完整数据集（无视图或标签缺失）上 11 种方法的实验结果。雷达图中心表示最差结果，顶点表示六项指标上的最佳结果。 >



(a) MIRFLICKR (b) Pascal07

图内标签：missing rate=缺失率；missing views=视图缺失；missing labels=标签缺失。

图5： MIRFLICKR 与 Pascal07 在不同缺失率下的实验结果。分别固定视图或标签缺失率为 0.5，再将另一项缺失率设为 0、0.3、0.5 和 0.7。

不完整设置下的实验

首先报告标准双重不完整设置下的主要比较结果，其中视图缺失率和标签缺失率均固定为 50%。定量结果见表2。V2L 的优势并不局限于单一评价指标。AP 和 AUC 的提升表明，学习到的表示能够可靠地对标签进行整体排序；$1-\mathrm{OE}$ 和 $1-\mathrm{Cov}$ 的提升则说明自适应决策分支有助于更准确地识别置信度最高的标签。这与 V2L 的设计相符：语义编码分支在视图缺失时稳定潜在空间，而视图—标签相关性分支利用视图特有证据细化逐标签决策。

这些结果验证了框架中两个核心组成部分的有效性。源扰动不变编码从不完整观测中保留与任务相关的共享语义，直接有益于 AP 和 AUC 等整体指标；主动式视图—标签相关性建模则执行样本级、标签感知的预测融合，进一步提升 $1-\mathrm{RL}$、$1-\mathrm{OE}$ 和 $1-\mathrm{Cov}$ 等排序相关指标。与主要侧重共享潜在表示学习或全局后期融合的现有方法相比，V2L 更好地结合了跨视图语义一致性与标签敏感的决策聚合，从而在 iM3C 设置下得到更可靠的预测。

表2：视图缺失率和标签缺失率均为 50% 时，11 种方法在五个数据集上的实验结果。 标准差标于各数值右下角；最佳结果以粗体标出。为便于阅读，按数据集分为五组，每组将方法列分为上下两段并重复数据集与指标列；没有删减数据。

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L
Corel5k	AP ↑	0.354$_{0.004}$	0.262$_{0.005}$	0.342$_{0.004}$	0.283$_{0.008}$	0.309$_{0.004}$
	1-HL ↑	0.987$_{0.000}$	0.987$_{0.000}$	0.987$_{0.000}$	0.978$_{0.000}$	0.987$_{0.000}$
	1-RL ↑	0.884$_{0.003}$	0.843$_{0.002}$	0.881$_{0.003}$	0.865$_{0.005}$	0.878$_{0.002}$
	AUC ↑	0.888$_{0.003}$	0.845$_{0.002}$	0.884$_{0.003}$	0.868$_{0.005}$	0.881$_{0.002}$
	1-OE ↑	0.410$_{0.007}$	0.295$_{0.014}$	0.391$_{0.009}$	0.311$_{0.015}$	0.350$_{0.009}$
	1-Cov ↑	0.723$_{0.007}$	0.647$_{0.005}$	0.718$_{0.006}$	0.702$_{0.008}$	0.725$_{0.005}$

Data	Metric	DICNet	DIMC	MSLPP	SIP	QARF	**Ours**
Corel5k	AP ↑	0.381$_{0.004}$	0.353$_{0.006}$	0.413$_{0.008}$	0.418$_{0.009}$	0.411$_{0.008}$	**0.426**$_{0.011}$
	1-HL ↑	0.988$_{0.000}$	0.987$_{0.000}$	0.988$_{0.000}$	0.988$_{0.000}$	0.988$_{0.000}$	**0.988**$_{0.000}$
	1-RL ↑	0.882$_{0.004}$	0.867$_{0.001}$	0.901$_{0.003}$	0.911$_{0.003}$	0.900$_{0.004}$	**0.915**$_{0.003}$
	AUC ↑	0.884$_{0.004}$	0.870$_{0.001}$	0.903$_{0.004}$	0.913$_{0.003}$	0.902$_{0.004}$	**0.916**$_{0.003}$
	1-OE ↑	0.468$_{0.007}$	0.422$_{0.015}$	0.485$_{0.010}$	0.489$_{0.016}$	0.492$_{0.013}$	**0.494**$_{0.013}$
	1-Cov ↑	0.727$_{0.011}$	0.684$_{0.011}$	0.766$_{0.009}$	0.787$_{0.009}$	0.761$_{0.009}$	**0.793**$_{0.008}$

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L
Pascal07	AP ↑	0.508$_{0.005}$	0.471$_{0.008}$	0.504$_{0.005}$	0.437$_{0.018}$	0.488$_{0.003}$
	1-HL ↑	0.931$_{0.001}$	0.928$_{0.001}$	0.930$_{0.000}$	0.882$_{0.004}$	0.928$_{0.001}$
	1-RL ↑	0.812$_{0.004}$	0.761$_{0.005}$	0.806$_{0.003}$	0.736$_{0.015}$	0.783$_{0.001}$
	AUC ↑	0.838$_{0.003}$	0.779$_{0.004}$	0.832$_{0.002}$	0.767$_{0.015}$	0.811$_{0.001}$
	1-OE ↑	0.419$_{0.008}$	0.420$_{0.011}$	0.419$_{0.008}$	0.362$_{0.023}$	0.421$_{0.006}$
	1-Cov ↑	0.759$_{0.003}$	0.692$_{0.004}$	0.751$_{0.003}$	0.677$_{0.015}$	0.727$_{0.002}$

Data	Metric	DICNet	DIMC	MSLPP	SIP	QARF	**Ours**
Pascal07	AP ↑	0.505$_{0.012}$	0.532$_{0.002}$	0.544$_{0.010}$	0.555$_{0.010}$	0.556$_{0.007}$	**0.562**$_{0.008}$
	1-HL ↑	0.929$_{0.001}$	0.931$_{0.001}$	0.932$_{0.001}$	0.931$_{0.001}$	0.931$_{0.001}$	**0.934**$_{0.001}$
	1-RL ↑	0.783$_{0.008}$	0.813$_{0.000}$	0.819$_{0.006}$	0.830$_{0.004}$	0.828$_{0.004}$	**0.836**$_{0.004}$
	AUC ↑	0.809$_{0.006}$	0.833$_{0.002}$	0.841$_{0.004}$	0.850$_{0.005}$	0.847$_{0.004}$	**0.858**$_{0.003}$
	1-OE ↑	0.427$_{0.015}$	0.456$_{0.011}$	0.466$_{0.014}$	0.464$_{0.018}$	0.471$_{0.011}$	**0.473**$_{0.010}$
	1-Cov ↑	0.731$_{0.006}$	0.769$_{0.007}$	0.771$_{0.003}$	0.783$_{0.006}$	0.780$_{0.005}$	**0.793**$_{0.004}$

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L
ESPGame	AP ↑	0.289$_{0.003}$	0.212$_{0.002}$	0.285$_{0.003}$	0.244$_{0.005}$	0.246$_{0.002}$
	1-HL ↑	0.983$_{0.000}$	0.982$_{0.000}$	0.983$_{0.000}$	0.972$_{0.000}$	0.983$_{0.000}$
	1-RL ↑	0.832$_{0.001}$	0.781$_{0.001}$	0.829$_{0.001}$	0.808$_{0.002}$	0.818$_{0.002}$
	AUC ↑	0.836$_{0.001}$	0.785$_{0.001}$	0.833$_{0.002}$	0.813$_{0.002}$	0.824$_{0.002}$
	1-OE ↑	0.396$_{0.005}$	0.294$_{0.006}$	0.389$_{0.004}$	0.343$_{0.013}$	0.339$_{0.003}$
	1-Cov ↑	0.574$_{0.004}$	0.488$_{0.003}$	0.567$_{0.005}$	0.548$_{0.004}$	0.571$_{0.003}$

Data	Metric	DICNet	DIMC	MSLPP	SIP	QARF	**Ours**
ESPGame	AP ↑	0.297$_{0.002}$	0.287$_{0.002}$	0.310$_{0.004}$	0.311$_{0.004}$	0.307$_{0.004}$	**0.321**$_{0.005}$
	1-HL ↑	0.983$_{0.000}$	0.983$_{0.000}$	0.983$_{0.000}$	0.983$_{0.000}$	0.983$_{0.000}$	**0.983**$_{0.000}$
	1-RL ↑	0.832$_{0.001}$	0.821$_{0.000}$	0.843$_{0.002}$	0.849$_{0.002}$	0.842$_{0.001}$	**0.853**$_{0.002}$
	AUC ↑	0.836$_{0.001}$	0.826$_{0.000}$	0.847$_{0.002}$	0.853$_{0.002}$	0.846$_{0.001}$	**0.857**$_{0.002}$
	1-OE ↑	0.439$_{0.007}$	0.435$_{0.009}$	0.457$_{0.012}$	0.455$_{0.007}$	0.448$_{0.009}$	**0.467**$_{0.011}$
	1-Cov ↑	0.593$_{0.003}$	0.562$_{0.004}$	0.622$_{0.005}$	0.628$_{0.005}$	**0.651**$_{0.004}$	0.638$_{0.005}$

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L
IAPRTC12	AP ↑	0.305$_{0.004}$	0.234$_{0.003}$	0.304$_{0.004}$	0.237$_{0.003}$	0.261$_{0.001}$
	1-HL ↑	0.981$_{0.000}$	0.980$_{0.000}$	0.981$_{0.000}$	0.969$_{0.000}$	0.980$_{0.000}$
	1-RL ↑	0.862$_{0.002}$	0.823$_{0.002}$	0.861$_{0.002}$	0.833$_{0.002}$	0.848$_{0.001}$
	AUC ↑	0.864$_{0.002}$	0.825$_{0.001}$	0.863$_{0.001}$	0.835$_{0.001}$	0.850$_{0.001}$
	1-OE ↑	0.432$_{0.008}$	0.340$_{0.006}$	0.429$_{0.009}$	0.352$_{0.008}$	0.390$_{0.005}$
	1-Cov ↑	0.597$_{0.004}$	0.529$_{0.004}$	0.597$_{0.004}$	0.564$_{0.005}$	0.592$_{0.004}$

Data	Metric	DICNet	DIMC	MSLPP	SIP	QARF	**Ours**
IAPRTC12	AP ↑	0.323$_{0.001}$	0.308$_{0.001}$	0.340$_{0.005}$	0.331$_{0.006}$	0.338$_{0.004}$	**0.349**$_{0.005}$
	1-HL ↑	0.981$_{0.000}$	0.980$_{0.000}$	0.981$_{0.000}$	0.980$_{0.000}$	0.981$_{0.000}$	**0.981**$_{0.000}$
	1-RL ↑	0.873$_{0.001}$	0.864$_{0.000}$	0.882$_{0.002}$	0.885$_{0.003}$	0.882$_{0.002}$	**0.893**$_{0.002}$
	AUC ↑	0.874$_{0.000}$	0.864$_{0.000}$	0.883$_{0.002}$	0.886$_{0.002}$	0.883$_{0.002}$	**0.893**$_{0.002}$
	1-OE ↑	0.468$_{0.002}$	0.431$_{0.006}$	0.474$_{0.008}$	0.463$_{0.009}$	0.471$_{0.011}$	**0.482**$_{0.001}$
	1-Cov ↑	0.649$_{0.001}$	0.597$_{0.004}$	0.672$_{0.006}$	0.675$_{0.007}$	0.668$_{0.005}$	**0.694**$_{0.006}$

Data	Metric	CDMM	DM2L	LVSL	iMVWL	NAIM3L
MIRFLICKR	AP ↑	0.570$_{0.002}$	0.514$_{0.006}$	0.553$_{0.002}$	0.490$_{0.012}$	0.551$_{0.002}$
	1-HL ↑	0.886$_{0.001}$	0.878$_{0.001}$	0.885$_{0.001}$	0.839$_{0.002}$	0.882$_{0.001}$
	1-RL ↑	0.856$_{0.001}$	0.831$_{0.003}$	0.856$_{0.001}$	0.803$_{0.008}$	0.844$_{0.001}$
	AUC ↑	0.846$_{0.001}$	0.828$_{0.003}$	0.844$_{0.001}$	0.787$_{0.012}$	0.837$_{0.001}$
	1-OE ↑	0.631$_{0.004}$	0.510$_{0.008}$	0.607$_{0.004}$	0.511$_{0.022}$	0.585$_{0.003}$
	1-Cov ↑	0.640$_{0.001}$	0.604$_{0.005}$	0.636$_{0.001}$	0.572$_{0.013}$	0.631$_{0.002}$

Data	Metric	DICNet	DIMC	MSLPP	SIP	QARF	**Ours**
MIRFLICKR	AP ↑	0.589$_{0.005}$	0.602$_{0.002}$	0.615$_{0.004}$	0.614$_{0.004}$	0.616$_{0.004}$	**0.621**$_{0.003}$
	1-HL ↑	0.888$_{0.002}$	0.888$_{0.000}$	0.892$_{0.001}$	0.891$_{0.001}$	0.892$_{0.001}$	**0.895**$_{0.001}$
	1-RL ↑	0.863$_{0.004}$	0.865$_{0.001}$	0.879$_{0.002}$	0.877$_{0.002}$	0.880$_{0.003}$	**0.881**$_{0.003}$
	AUC ↑	0.849$_{0.004}$	0.852$_{0.001}$	0.865$_{0.002}$	0.860$_{0.003}$	0.866$_{0.002}$	**0.872**$_{0.002}$
	1-OE ↑	0.637$_{0.007}$	0.647$_{0.007}$	0.667$_{0.007}$	0.662$_{0.008}$	0.662$_{0.008}$	**0.673**$_{0.007}$
	1-Cov ↑	0.652$_{0.007}$	0.661$_{0.003}$	0.679$_{0.003}$	0.678$_{0.003}$	0.683$_{0.003}$	**0.683**$_{0.003}$

完整数据及不同缺失率下的实验

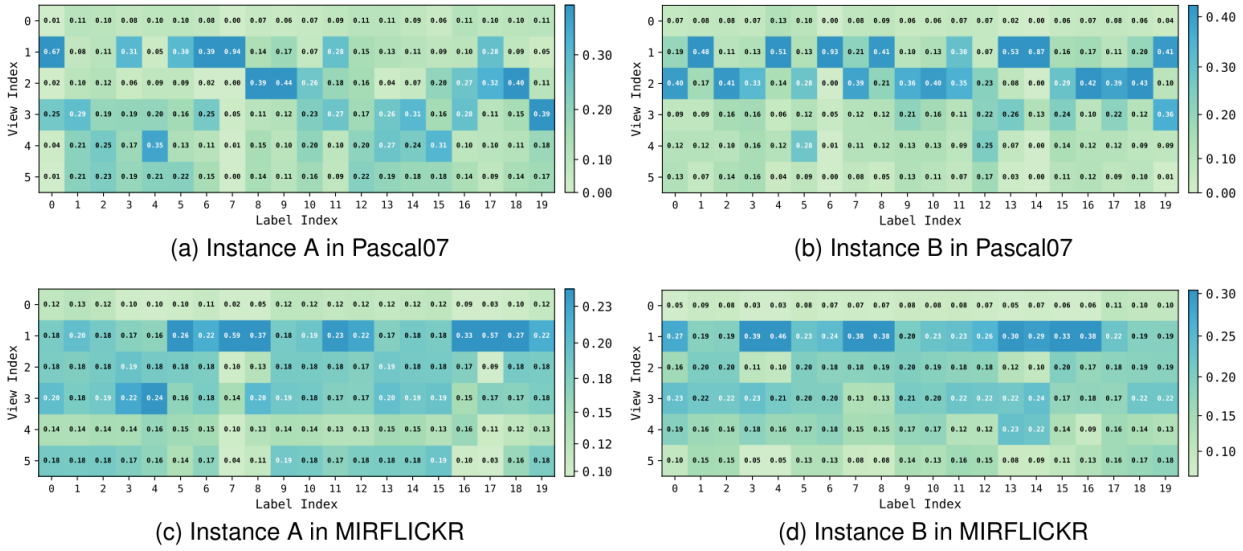
为进一步考察 V2L 的优势是否只出现在不完整场景，本文还在视图与标签均无缺失的完整观测设置下评估所有方法。图4中的雷达图显示，在不同数据集和评价指标上，V2L 仍处于表现最好的方法之列。这说明该模型的优势并非仅来自专门处理缺失数据；学习到的共享表示与自适应视图—标签融合策略也能很好地推广到理想的完整数据情形。因此，V2L 是统一的多视图多标签学习器，而非只针对输入受损场景的方法。

此外，为考察不同缺失模式的影响，本文在图5中展示了不同视图缺失率和标签缺失率下的结果。具体而言，固定一项缺失率为 50%，将另一项从 0 调整到 0.7。随着任一类缺失增加，性能都明显下降，这符合直觉：观测缺失和监督缺失都会减少可用的判别信息。同时，提高视图缺失率造成的性能下降通常

比提高标签缺失率更明显。这表明，尽管监督不完整会造成损害，观测视图的减少更直接地削弱了跨视图语义聚合，并减少了用于标签预测的互补证据。总体而言，V2L 在较宽范围的缺失条件下都保持了良好表现，且性能下降较为平稳，而非突然崩塌。

5.3 视图—标签异质性研究

为验证视图—标签异质性建模策略的有效性，本文在图6中可视化了所提主动感知网络预测的视图—标签相关性图。具体而言，本文在完整的 Pascal07 和 MIRFLICKR 数据集上进行实验，并分别从每个数据集中随机选取两个样本进行案例分析。对每个样本，绘制其六个视图与前 20 个标签之间相关性的热图。这些可视化提供了一种直接检验模型是否确实学习到样本级、标签感知的视图贡献，而非依赖静态视图融合的方式。



图内标签：View Index=视图索引；Label Index=标签索引；Instance A/B=样本 A/B。图注关于 Pascal07 仅显示前20个标签的说明按原文保留。

图6： 视图—标签异质性建模示例。可视化 Pascal07 与 MIRFLICKR 数据集中各两个随机样本的视图—标签相关性图热图；受篇幅限制，Pascal07 仅显示前 20 个标签。

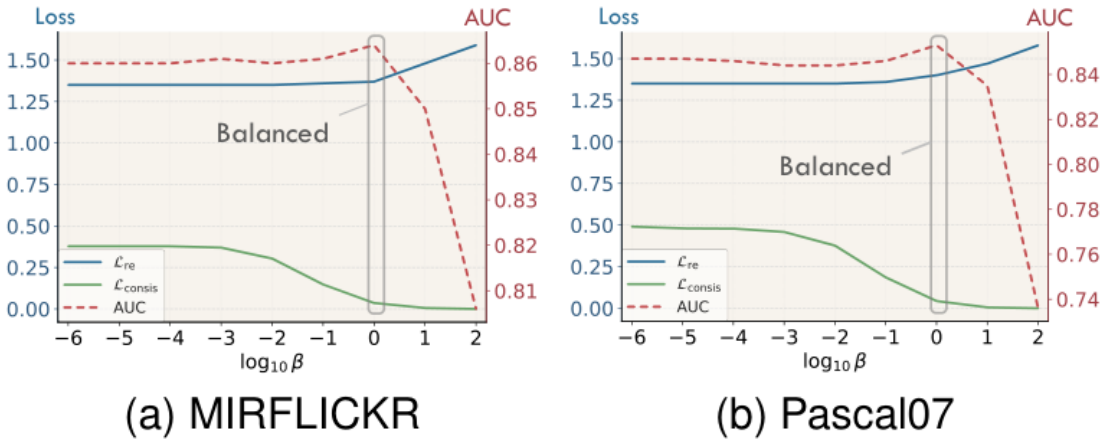
图6展示了三点观察结果。(1) 即使在同一数据集中，不同样本的热图也明显不同，说明视图贡献模式取决于样本，而非全局固定。这支持了逐样本动态评估视图相关性的动机。(2) 对任一给定样本，不同标签对六个视图呈现出显著不同的依赖关系。换言之，同一视图对不同标签预测的贡献会变化。这直接说明了建模视图—标签异质性的必要性，而不能为所有标签指定相同融合权重。(3) 从整体视图来看，各视图间也存在明显不均衡。例如，在两个数据集中，视图0的判别能力相对较弱，而其他一些视图的贡献明显更强。与 MIRFLICKR 相比，Pascal07 中这种不均衡更加突出，强视图与弱视图的区别更明显。这些观察进一步说明组合式预测策略的必要性：中层融合捕捉共享语义，后期融合则针对每个标签自适应地重新加权视图特有证据。因此，可视化结果不仅验证了视图—标签异质性的存在，也说明逐样本、标签感知的后融合机制对于有效的多视图多标签预测十分重要。

某些视图相关性较低，可能是因为特征的判别性与信息冗余存在差异。例如，视图0对应 GIST，主要捕捉全局空间结构；对于面向对象与标签的任务，它可能不如局部外观、颜色或纹理特征信息丰富。此外，$\mathbf{B}_{i,j,v}$ 衡量的是可用视图之间归一化后的相对贡献，而非绝对效用。因此，如果某个视图的证据不够可靠，或与更强视图的证据冗余，它可能获得较低权重，但这不意味着它完全没有信息。

5.4 信息瓶颈设计研究

本小节进一步分析式（11）总体目标中的自监督表示学习部分，即由信息瓶颈损失 $\mathcal{L}_{\text{ib}}$ 实例化的前两项。回顾式（19），$\mathcal{L}_{\text{ib}} = \mathcal{L}_{\text{re}} + \beta\mathcal{L}_{\text{consis}}$：$\mathcal{L}_{\text{re}}$ 鼓励每个视图特定潜变量保留重建所需的有效信息；$\mathcal{L}_{\text{consis}}$ 则抑制视图私有冗余并促进跨视图语义一致性。因此，关键问题是如何选择权衡系数 β，使学习到的表示既充分含有信息，又保持紧凑。

为研究这种平衡，本文改变 β，并在 MIRFLICKR 和 Pascal07 上可视化 $\mathcal{L}_{\text{re}}$、$\mathcal{L}_{\text{consis}}$ 与 AUC 的相应变化，如图7所示。可以观察到明显的权衡：当 β 太小时，重建项主导优化，模型倾向于保留更多视图特定细节。虽然这会使 $\mathcal{L}_{\text{re}}$ 较低，但一致性正则不足以充分去除视图间非共享信息，因此最终 AUC 不够理想。相反，当 β 过大时，模型会过度强调语义压缩，并激进地最小化 $\mathcal{L}_{\text{consis}}$。这导致 $\mathcal{L}_{\text{re}}$ 明显升高，说明部分有助于重建的视图有效信息被丢弃，预测性能也随之下降。



图内标签：Loss=损失；Balanced=平衡。

图7： 信息平衡参数 β 对重建损失 $\mathcal{L}_{\text{re}}$、一致性损失 $\mathcal{L}_{\text{consis}}$ 和 AUC 的影响。

当 β 取中间范围时，两个目标达到较好的平衡，结果最佳（图7中最佳 $\beta = 10^0$）。此时模型既不会过拟合视图特有冗余，也不会过度压缩潜在表示，能够为潜在编码保留足够的有效信息，同时在视图间施加充分的语义一致性约束。这些观察验证了信息瓶颈设计的有效性并非单独来自重建或一致性，而是来自二者的协同作用。换言之，$\mathcal{L}_{\text{ib}}$ 的两项确实发挥互补作用，共同编码语义对齐且信息充分的表示，以支持下游多标签预测。

5.5 消融研究

为评估 V2L 中各损失项的贡献，本文在视图缺失率和标签缺失率均为 50% 的条件下，在 Corel5k 与 Pascal07 上进行损失函数消融实验。具体而言，分别单独或组合移除后验正则化损失 $\mathcal{L}_{\text{post}}$、信息瓶颈损失 $\mathcal{L}_{\text{ib}}$ 和相关性正则化 $\mathcal{L}_{\text{rele}}$，结果见表3。可以得到以下观察：完整模型在两个数据集的所有指标上均取得最佳结果，说明三种损失互为补充而非相互冗余；移除任一损失都会造成明显性能下降，验证了表示对齐、语义压缩和视图—标签相关性学习均有助于最终预测质量。其中，移除 $\mathcal{L}_{\text{ib}}$ 在大多数情况下造成的退化最明显，尤其是 AP、AUC 和 $1-\text{Cov}$，表明自监督信息瓶颈设计为学习判别性强且语义充分的潜在表示提供了最基础的支持；同时移除多项损失会导致性能进一步下降；三种辅助损失全部移除时结果最差，这进一步说明了联合优化这些组成部分的必要性。

表3： 在 Corel5k 和 Pascal07 上、视图与标签缺失率均为 50% 时，针对损失函数的消融结果。“w/ o”表示不含相应损失。

Method	Corel5k					
	AP	1-HL	1-RL	AUC	1-OE	1-Cov
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{ib}}$ $\mathcal{L}_{\text{rele}}$	0.352	0.986	0.864	0.867	0.428	0.702
V2L w/o $\mathcal{L}_{\text{ib}}$ $\mathcal{L}_{\text{rele}}$	0.374	0.987	0.891	0.893	0.441	0.752
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{rele}}$	0.390	0.986	0.898	0.900	0.464	0.762
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{ib}}$	0.371	0.987	0.865	0.867	0.463	0.700
V2L w/o $\mathcal{L}_{\text{rele}}$	0.404	0.987	0.906	0.908	0.481	0.779
V2L w/o $\mathcal{L}_{\text{post}}$	0.401	0.987	0.901	0.903	0.479	0.769
V2L w/o $\mathcal{L}_{\text{ib}}$	0.395	0.987	0.894	0.896	0.473	0.756
V2L	0.426	0.988	0.915	0.916	0.494	0.793

Method	Pascal07					
	AP	1-HL	1-RL	AUC	1-OE	1-Cov
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{ib}}$ $\mathcal{L}_{\text{rele}}$	0.527	0.926	0.815	0.835	0.426	0.767
V2L w/o $\mathcal{L}_{\text{ib}}$ $\mathcal{L}_{\text{rele}}$	0.534	0.929	0.824	0.844	0.427	0.777
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{rele}}$	0.541	0.928	0.827	0.845	0.444	0.780
V2L w/o $\mathcal{L}_{\text{post}}$ $\mathcal{L}_{\text{ib}}$	0.526	0.926	0.813	0.833	0.426	0.763
V2L w/o $\mathcal{L}_{\text{rele}}$	0.546	0.930	0.833	0.852	0.443	0.787
V2L w/o $\mathcal{L}_{\text{post}}$	0.546	0.929	0.828	0.846	0.448	0.782
V2L w/o $\mathcal{L}_{\text{ib}}$	0.539	0.929	0.823	0.842	0.439	0.776
V2L	0.562	0.934	0.836	0.858	0.473	0.793

除损失函数外，本文还研究了主动式后融合策略和先验缺失索引指导的作用，结果见表4。具体而言，将所提的样本级、标签感知融合替换为静态融合（“V2L 静态融合”：所有可用视图在后期融合中权重相同）或被动融合（“V2L 被动融合”：所有可用视图由一组可学习的视图级参数赋权），都会使两个数据集的整体表现下降。可以看到，这些简化变体在 AP、AUC 和 $1-\text{OE}$ 等代表性指标上表现不及完整 V2L，说明固定或全局可学习的视图权重不足以捕捉 iM3C 中复杂的视图—标签异质性。相比之下，基于主动感知的融合能够在样本级自适应调整不同视图的贡献，从而实现更有针对性的融合。

此外，本文完全移除后期融合策略，仅保留中层融合与分类器（即表示层融合版本，发表于文献 [56]，称为“V2L 无后期融合”）。实验结果表明，如果各分支的决策没有得到适当平衡，混合融合也可能因决策冲突而得到更差结果。

移除缺失视图索引矩阵 $\mathbf{W}$ 或缺失标签索引矩阵 $\mathbf{R}$ 也会导致模型性能下降，证实了在学习过程中显式纳入缺失先验信息的必要性。特别是屏蔽缺失视图信息后，两个数据集的整体性能下降更加明显，说明可靠地识别可用视图对于语义聚合和自适应决策融合都很重要。这些结果进一步说明，V2L 的优势既来自更强的信息中心学习目标，也来自更恰当的融合机制和显式的缺失感知建模。

表内 w/ static fusion=使用静态融合；w/ passive fusion=使用被动融合；w/o late fusion=不含后期融合；w/o perm. consist.=不含置换一致性；w/o view index=不含视图索引；w/o label index=不含标签索引。

表4： 在 Corel5k 和 Pascal07 上、视图与标签缺失率均为 50% 时，融合策略与缺失索引指导的消融结果。

Method	Corel5k					
	AP	1-HL	1-RL	AUC	1-OE	1-Cov
V2L w/ static fusion	0.416	0.987	0.905	0.908	0.498	0.783
V2L w/ passive fusion	0.412	0.987	0.907	0.910	0.484	0.782
V2L w/o late fusion	0.421	0.988	0.910	0.913	0.493	0.790
V2L w/o perm. consist.	0.405	0.987	0.906	0.908	0.486	0.788
V2L w/o view index	0.398	0.987	0.900	0.903	0.480	0.769
V2L w/o label index	0.403	0.987	0.906	0.909	0.468	0.781
V2L	0.426	0.988	0.915	0.916	0.494	0.793

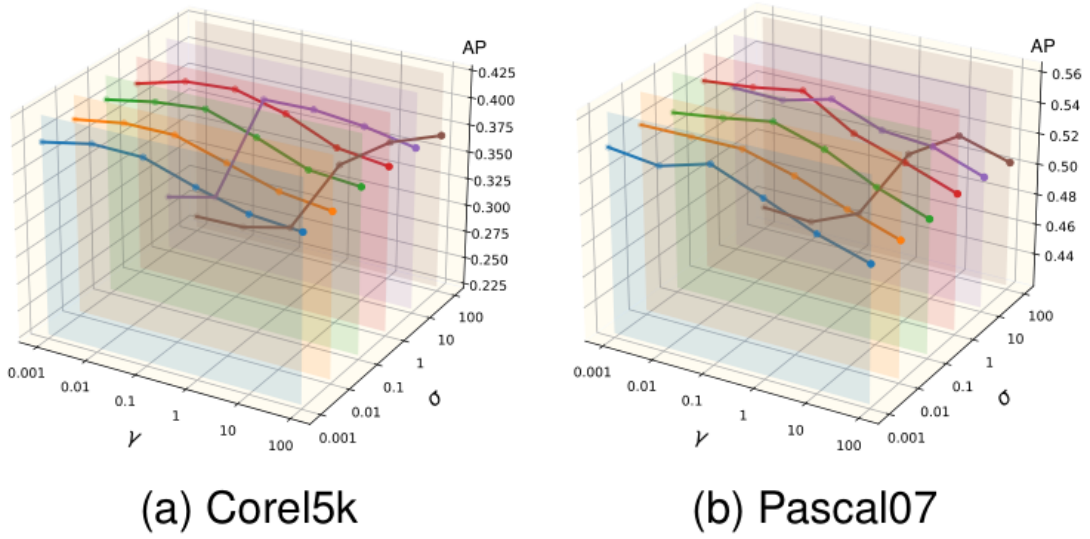
Method	Pascal07					
	AP	1-HL	1-RL	AUC	1-OE	1-Cov
V2L w/ static fusion	0.551	0.931	0.831	0.853	0.450	0.788
V2L w/ passive fusion	0.550	0.929	0.831	0.854	0.448	0.790
V2L w/o late fusion	0.559	0.934	0.834	0.857	0.471	0.790
V2L w/o perm. consist.	0.554	0.933	0.826	0.852	0.462	0.783
V2L w/o view index	0.540	0.930	0.825	0.847	0.450	0.779
V2L w/o label index	0.532	0.928	0.833	0.853	0.435	0.789
V2L	0.562	0.934	0.836	0.858	0.473	0.793

5.6 超参数分析

本小节进一步分析总体优化中的两个权衡系数 γ 和 σ 的敏感性。图8报告了不同参数组合下，Corel5k 与 Pascal07 上的性能变化。总体而言，两个数据集呈现出一致趋势：当两个系数处于适中范围时，V2L 相对稳定；任一参数过大都会导致性能明显下降。

具体而言，当 γ 太小时，跨视图后验正则化不足，潜在表示不能充分利用不完整视图间的共享语义。因此，模型倾向于保留更多视图特定干扰，最终预测质量不理想。相反，当 γ 太大时，正则约束过强，会压制视图—标签异质性建模所需的视图特定判别线索。σ 也呈现类似现象：较小或适中的 σ 有助于保持信息瓶颈正则化的效果；σ 过大则造成明显性能下降，尤其在 Corel5k 上，σ 增至 10 或 100 时更为突出。

根据图8，当 γ 约为 $10^{-2} \sim 10^{-1}$、σ 约为 $10^{-1} \sim 10^{0}$ 时，通常可以取得较好的结果。在这一范围内，模型能够达到较有利的平衡，并在各数据集上保持较强表现。



两幅子图分别对应 Corel5k 与 Pascal07，纵轴为 AP。

图8： 在视图和标签缺失率均为 50% 时，Corel5k 与 Pascal07 上 γ 和 σ 的超参数敏感性分析。

5.7 时间开销研究

本文在 Corel5k 上使用相同数据划分评估所有方法的计算开销，其中 70% 样本用于训练。由于模型训练时间对收敛准则高度敏感，所有方法均采用各自默认的收敛设置。对于单视图方法，记录所有视图训练时间之和，以及单个视图的推理时间。对于 DICNet、SIP 和 PCVE，训练阶段均运行 100 轮。如表5所示，V2L 的训练耗时为 507.13 秒。由于提议编码器、后验正则化和混合融合架构带来开销，这一时间高于若干较简单的基线，但仍低于 DM2L 和 MSLPP。

V2L 的推理只需 0.03 秒，因为重建解码器和后验正则化项仅在训练阶段使用。资源方面，V2L 包含 7,337.7 万个可训练参数，峰值 GPU 显存占用为 1,803.68 MB。其参数量少于 DICNet、DIMC、MSLPP 和 QARF，显存占用则低于 DICNet 和 DIMC。总体而言，V2L 引入了适中、可控的训练开销，同时保持了高效推理。由于这些指标与传统优化型方法并不直接可比，参数量和 GPU 显存只对神经网络方法报告。

表内 Training time=训练时间；Inference time=推理时间；Parameters=参数量；Peak GPU memory=峰值 GPU 显存；Method=方法；Metric=指标；Ours=本文方法。

表5： Corel5k 上使用 70% 训练样本时的运行时间、参数量和峰值 GPU 显存。运行时间单位为秒，参数量单位为百万，显存单位为 MB。

Metric \ Method	CDMM	DM2L	LVSL	iMVWL
Training time (s)	16.02	713.37	63.73	165.82
Inference time (s)	1.73	0.04	0.64	0.02
Parameters (M)	–	–	–	–
Peak GPU memory (MB)	–	–	–	–

Metric \ Method	NAIM3L	DICNet	DIMC	MSLPP	SIP	QARF	V2L
Training time (s)	143.63	313.89	141.85	4889.84	336.11	134.03	507.13
Inference time (s)	0.01	0.05	0.04	0.05	0.01	0.02	0.03
Parameters (M)	–	187.232	111.142	82.897	34.824	81.265	73.377
Peak GPU memory (MB)	–	2895.40	2172.65	1295.59	1031.64	1271.72	1803.68

6 结论

本文提出了用于不完整多视图多标签分类的统一框架 V2L。从多视图表示学习的角度看，本文认为，不完整观测下的可靠预测应建立在语义一致的表示学习基础之上。为此，本文设计源扰动不变编码方案，在保留与任务相关的共享信息的同时抑制视图特有冗余，使学习到的潜在表示在不同视图间兼具信息性与一致性。

从视图—标签异质性建模的角度看，本文进一步指出，仅有共享语义不足以支持多标签预测，因为不同标签可能以依赖样本的方式依赖不同视图。因此，本文引入主动式视图—标签相关性建模策略，以刻画具备标签感知能力、样本特定的视图互补性，超越静态融合。最终，这两种策略通过混合融合架构整合起来，在统一模型中结合中层语义融合与后期自适应决策融合。前者为不完整多视图表示学习提供稳定的共享语义证据，后者则保留用于标签预测的互补视图特有线索。基准数据集上的大量实验和分析验证了该设计能够同时获得更好的预测性能和可解释的视图—标签相关性模式。

该策略还可以扩展到其他不完整多视图或多模态任务：源扰动不变编码可提供稳健的共享表示，主动相关性机制则可建模不同信息来源对目标的依赖贡献 [57, 58, 59]。未来的重要方向包括将 V2L 扩展到多模态诊断、多传感器识别和多媒体理解等任务，并为其设计适合具体任务的相关性监督和预测目标。

参考文献

文中引文已与原 PDF 的参考文献编号对应。以下 59 条参考文献保留英文著录信息。

1. J. Wen, Z. Zhang, L. Fei, B. Zhang, Y. Xu, Z. Zhang, and J. Li, “A survey on incomplete multiview clustering,” IEEE Transactions on Systems, Man, and Cybernetics: Systems, vol. 53, no. 2, pp. 1136–1149, 2022.
2. Z.-B. Yu and M.-L. Zhang, “Multi-label classification with label-specific feature generation: A wrapped approach,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 9, pp. 5199–5210, 2021.
3. C. Liu, J. Jia, J. Wen, Y. Liu, X. Luo, C. Huang, and Y. Xu, “Attention-induced embedding imputation for incomplete multi-view partial multi-label classification,” in Proceedings of the AAAI conference on artificial intelligence, vol. 38, no. 12, 2024, pp. 13 864–13 872.

4. C. Liu, J. Wen, Y. Xu, B. Zhang, L. Nie, and M. Zhang, "Reliable representation learning for incomplete multi-view missing multi-label classification," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 47, no. 6, pp. 4940–4956, 2025.
5. J. Li, P. Li, X. Hu, and K. Yu, "Learning common and label-specific features for multi-label classification with correlation information," Pattern Recognition, vol. 121, p. 108259, 2022.
6. C. Zhang, X. Zhu, Z. Wang, Y. Zhong, W. Sheng, W. Ding, and B. Jiang, "Discriminative multi-view fusion via adaptive regression," IEEE Transactions on Emerging Topics in Computational Intelligence, vol. 8, no. 6, pp. 3821–3833, 2024.
7. Z. Ma and S. Chen, "Expand globally, shrink locally: Discriminant multi-label learning with missing labels," Pattern Recognition, vol. 111, p. 107675, 2021.
8. P. Zhou, R. Li, Z. Ling, L. Du, and X. Liu, "Fair clustering ensemble with equal cluster capacity," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 47, no. 3, pp. 1729–1746, 2024.
9. B. Jiang, C. Zhang, X. Liang, P. Zhou, J. Yang, X. Wu, J. Guan, W. Ding, and W. Sheng, "Collaborative similarity fusion and consistency recovery for incomplete multi-view clustering," in Proceedings of the AAAI conference on artificial intelligence, vol. 39, no. 17, 2025, pp. 17 617–17 625.
10. X. Li and S. Chen, "A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 10, pp. 5918–5932, 2022.
11. X. Zhang, R. Abdelfattah, Y. Song, and X. Wang, "An effective approach for multi-label classification with missing labels," in 2022 IEEE 24th Int Conf on High Performance Computing & Communications; 8th Int Conf on Data Science & Systems; 20th Int Conf on Smart City; 8th Int Conf on Dependability in Sensor, Cloud & Big Data Systems & Application (HPCC/DSS/SmartCity/DependSys). IEEE, 2022, pp. 1713–1720.
12. S. Wang, Z. Chen, S. Du, and Z. Lin, "Learning deep sparse regularizers with applications to multi-view clustering and semi-supervised classification," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 9, pp. 5042–5055, 2021.
13. Z. Han, C. Zhang, H. Fu, and J. T. Zhou, "Trusted multi-view classification with dynamic evidential fusion," IEEE transactions on pattern analysis and machine intelligence, vol. 45, no. 2, pp. 2551–2566, 2022.
14. C. Liu, G. Xu, J. Wen, Y. Liu, C. Huang, and Y. Xu, "Partial multi-view multi-label classification via semantic invariance learning and prototype modeling," in Proceedings of the 41st International Conference on Machine Learning, vol. 235. PMLR, 21–27 Jul 2024, pp. 32 253–32 267. [Online]. Available: https://proceedings.mlr.press/v235/liu24bv.html
15. J. Wen, Y. Liu, Z. Tang, Y. He, Y. Chen, M. Li, and C. Liu, "Learning compact semantic information for incomplete multi-view missing multi-label classification," in Forty-second International Conference on Machine Learning, 2025.

16. Y. Wang, F. Zhang, and B. Jiang, “Robust multi-view clustering via quadratic matrix factorization with manifold learning,” IEEE Transactions on Image Processing, 2026.
17. Y. Liu, C. Liu, J. Wen, L. Shen, B. Zhang, and Y. Xu, “Learning compact semantic information and reliable pseudo-labels for incomplete multi-view multi-label classification,” IEEE Transactions on Pattern Analysis and Machine Intelligence, 2026.
18. S. Black and R. Souvenir, “Multi-view classification using hybrid fusion and mutual distillation,” in Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2024, pp. 270–280.
19. Y. Gan, Y. You, J. Huang, S. Xiang, C. Tang, W. Hu, and S. An, “Multi-view clustering via multi-stage fusion,” IEEE Transactions on Multimedia, vol. 27, pp. 4571–4583, 2025.
20. H. Zhao, W. Chen, and P. Zhou, “Active deep multi-view clustering,” in Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, 2024, pp. 5554–5562.
21. P. Zhou, B. Hu, D. Yan, and L. Du, “Clustering ensemble via diffusion on adaptive multiplex,” IEEE Transactions on Knowledge and Data Engineering, vol. 36, no. 4, pp. 1463–1474, 2023.
22. A. Kumar, P. Rai, and H. Daume, “Co-regularized multi-view spectral clustering,” Advances in neural information processing systems, vol. 24, 2011.
23. X. Yang, H. Che, M.-F. Leung, C. Liu, and S. Wen, “Auto-weighted multi-view deep non-negative matrix factorization with multi-kernel learning,” IEEE Transactions on Signal and Information Processing over Networks, vol. 11, pp. 23–34, 2024.
24. H. Wang, Y. Yang, and B. Liu, “Gmc: Graph-based multi-view clustering,” IEEE Transactions on Knowledge and Data Engineering, vol. 32, no. 6, pp. 1116–1129, 2019.
25. Y. Chen, X. Xiao, C. Peng, G. Lu, and Y. Zhou, “Low-rank tensor graph learning for multi-view subspace clustering,” IEEE Transactions on Circuits and Systems for Video Technology, vol. 32, no. 1, pp. 92–104, 2021.
26. W. Guo, H. Che, and M.-F. Leung, “Tensor-based adaptive consensus graph learning for multi-view clustering,” IEEE Transactions on Consumer Electronics, vol. 70, no. 2, pp. 4767–4784, 2024.
27. X. Pu, H. Che, D. Ouyang, and S. Zhao, “Conquering missing views: Scalable incomplete multi-view clustering with anchor graph propagation,” IEEE Transactions on Multimedia, 2026.
28. X. Tian, Z. Zhang, C. Wang, W. Zhang, Y. Qu, L. Ma, Z. Wu, Y. Xie, and D. Tao, “Variational distillation for multi-view learning,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 46, no. 7, pp. 4551–4566, 2024.
29. D. Khattar, J. S. Goud, M. Gupta, and V. Varma, “Mvae: Multimodal variational autoencoder for fake news detection,” in The world wide web conference, 2019, pp. 2915–2921.
30. X. Ding, L. Zhao, X. Li, and X. Zhu, “Incomplete multi-view clustering via hierarchical semantic alignment and cooperative completion,” Advances in Neural Information Processing Systems, vol. 38, pp. 52 175–52 195, 2026.

31. G. Jiang, H. Hou, Y. Liu, J. Peng, and H. Wang, "Reliable feature imputation with cross-view relation transfer for deep incomplete multi-view classification," IEEE Transactions on Circuits and Systems for Video Technology, 2026.
32. Y. Lin, Y. Gou, Z. Liu, B. Li, J. Lv, and X. Peng, "Completer: Incomplete multi-view clustering via contrastive prediction," in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021, pp. 11 174–11 183.
33. Q. Tan, G. Yu, C. Domeniconi, and et al., "Incomplete multi-view weak-label learning," in Ijcai, 2018, pp. 2703–2709.
34. M. Xie, Z. Han, C. Zhang, Y. Bai, and Q. Hu, "Exploring and exploiting uncertainty for incomplete multi-view classification," in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023, pp. 19 873–19 882.
35. E. A. Cherman, M. C. Monard, and J. Metz, "Multi-label problem transformation methods: a case study," CLEI Electronic Journal, vol. 14, no. 1, pp. 4–4, 2011.
36. Y. Kim, J. M. Kim, Z. Akata, and J. Lee, "Large loss matters in weakly supervised multi-label classification," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 14 156–14 165.
37. N. Xu, C. Qiao, J. Lv, X. Geng, and M.-L. Zhang, "One positive label is sufficient: Single-positive multi-label learning with label enhancement," Advances in Neural Information Processing Systems, vol. 35, pp. 21 765–21 776, 2022.
38. Y. Gong, Q. Wu, M. Zhou, and C. Chen, "A diversity and reliability-enhanced synthetic minority oversampling technique for multi-label learning," Information Sciences, vol. 690, p. 121579, 2025.
39. X. Li, J. Jiang, R. Dharmani, J. Srinivasa, G. Liu, and J. Shang, "Open-world multi-label text classification with extremely weak supervision," in Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, 2024, pp. 15 084–15 096.
40. T. Chen, W. Wang, T. Pu, J. Qin, Z. Yang, J. Liu, and L. Lin, "Dynamic correlation learning and regularization for multi-label confidence calibration," IEEE Transactions on Image Processing, vol. 33, pp. 4811–4823, 2024.
41. D. Zhao, Q. Gao, Y. Lu, and D. Sun, "Non-aligned multi-view multi-label classification via learning view-specific labels," IEEE Transactions on Multimedia, 2022.
42. Y. Zhu, J. T. Kwok, and Z.-H. Zhou, "Multi-label learning with global and local label correlation," IEEE Transactions on Knowledge and Data Engineering, vol. 30, no. 6, pp. 1081–1094, 2017.
43. C.-K. Yeh, W.-C. Wu, W.-J. Ko, and Y.-C. F. Wang, "Learning deep latent space for multi-label classification," in AAAI Conference on Artificial Intelligence, vol. 31, no. 1, 2017.
44. D. Zhao, Q. Gao, Y. Lu, D. Sun, and Y. Cheng, "Consistency and diversity neural network multi-view multi-label learning," Knowledge-Based Systems, vol. 218, p. 106841, 2021.
45. C. Liu, J. Wen, X. Luo, C. Huang, Z. Wu, and Y. Xu, "Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification," in

Proceedings of the AAAI Conference on Artificial Intelligence, vol. 37, no. 7, 2023, pp. 8807–8815.
46. M. Federici, A. Dutta, P. Forré, N. Kushman, and Z. Akata, "Learning robust representations via multi-view information bottleneck," in International Conference on Learning Representations. OpenReview. net, 2020.
47. A. Achille and S. Soatto, "Emergence of invariance and disentanglement in deep representations," Journal of Machine Learning Research, vol. 19, no. 50, pp. 1–34, 2018.
48. P. Duygulu, K. Barnard, J. F. de Freitas, and D. A. Forsyth, "Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary," in European Conference on Computer Vision, 2002, pp. 97–112.
49. M. Everingham, L. Van Gool, C. K. Williams, J. Winn, and A. Zisserman, "The pascal visual object classes (voc) challenge," International journal of computer vision, vol. 88, pp. 303–308, 2009.
50. L. Von Ahn and L. Dabbish, "Labeling images with a computer game," in SIGCHI conference on Human factors in computing systems, 2004, pp. 319–326.
51. M. Henning, D. Thomas et al., "The iapr benchmark: Anew evaluation resource for visual information systems," in International Conference on Language Resources and Evaluation, 2006, pp. 1–11.
52. M. J. Huiskes and M. S. Lew, "The mir flickr retrieval evaluation," in ACM international conference on Multimedia information retrieval, 2008, pp. 39–43.
53. J. Wen, C. Liu, S. Deng, Y. Liu, L. Fei, K. Yan, and Y. Xu, "Deep double incomplete multi-view multi-label learning with incomplete labels and missing views," IEEE transactions on neural networks and learning systems, 2023.
54. J. Long, Q. Zhang, X. Lu, J. Wen, L. Zhao, and W. Xie, "Multi-scale locality preserving projection for partial multi-view incomplete multi-label learning," Neural Networks, vol. 180, p. 106748, 2024.
55. X. Lu, J. Long, H. Zhang, W. Xie, L. Zhao, Y. Ye, and J. Wen, "Partial multi-view incomplete multi-label learning network with quality-aware representation fusion," IEEE Transactions on Circuits and Systems for Video Technology, 2025.
56. C. Liu, B. Li, B. Zhang, X. Luo, Y. Liu, and J. Wen, "Permutation-consistent variational encoding for incomplete multi-view multi-label classification," in The Fourteenth International Conference on Learning Representations, 2026, pp. 1–18.
57. Y. Li, M. Yang, and Z. Zhang, "A survey of multi-view representation learning," IEEE transactions on knowledge and data engineering, vol. 31, no. 10, pp. 1863–1883, 2018.
58. X. Yan, J. Yin, and J. Wen, "Incomplete multi-view multi-label learning via disentangled representation and label semantic embedding," in Proceedings of the Computer Vision and Pattern Recognition Conference, 2025, pp. 30 722–30 731.
59. J. Yin, R. Cai, and S. Sun, "Clustering result re-guided incomplete multi-view spectral clustering," Information Fusion, p. 104360, 2026.

作者单位、资助与作者简介

作者单位与通信信息（据原文）：

- Chengliang Liu、Bo Li：澳门大学人工智能系 PAMI 研究组，澳门。电子邮箱：liucl1996@163.com；bo_li_mail@163.com。
- Bob Zhang：澳门大学人工智能系 PAMI 研究组，以及人工智能与脑科学研究所通用人工智能中心，澳门。电子邮箱：bobzhang@um.edu.mo。
- Yanghao Zhou：北京理工大学计算机科学与技术学院，北京 100811。电子邮箱：zhouyh77@bit.edu.cn。
- Jie Wen：哈尔滨工业大学（深圳）计算机科学与技术学院，深圳 518055。电子邮箱：jiewen_pr@126.com。
- Wenwu Wang：英国萨里大学计算机科学与电子工程学院，英国吉尔福德 GU2 7XH。电子邮箱：w.wang@surrey.ac.uk。
- **通信作者：** Bob Zhang 与 Jie Wen。

资助信息： 本研究获得澳门大学（MYRG-GRG2024-00205-FST）、澳门特别行政区科学技术发展基金（FDCT）（0028/2023/RIA1）、广东省科学技术协会青年科技人才培育计划（SKXRC2026408）以及广东省基础与应用基础研究基金（2024A1515030213）的资助。

作者简介

- **Chengliang Liu：** 2024 年获中国深圳哈尔滨工业大学计算机科学博士学位（Ph.D.），2020 年获中国武汉华中科技大学计算机科学理学硕士学位（M.S.），2018 年获中国长春吉林大学计算机科学理学学士学位（B.S.）。目前在澳门的澳门大学从事博士后研究。他担任 Pattern Recognition 副编辑、Information Fusion 客座编辑，并担任 IJCAI 与 AAAI 的 SPC。研究兴趣包括机器学习和计算机视觉，尤其是多模态学习。他曾获 AAAI 2023 杰出论文奖，并获 CSIG 博士论文激励计划提名奖及哈尔滨工业大学优秀博士论文奖。个人主页：https://justsmart.github.io。
- **Bo Li：** 2021 年获北京信息科技大学机器人工程工学学士学位（B.Eng.），2024 年获北京工业大学电子信息工学硕士学位（M.Eng.），目前在澳门大学攻读计算机科学博士学位。研究方向处于生物医学人工智能与智能体系统交叉领域，包括生物医学图像分析、基于图像表型的药物发现、虚拟细胞和生物医学知识检索。
- **Bob Zhang：** IEEE 高级会员。2006 年获加拿大安大略省多伦多约克大学计算机科学文学学士学位（B.A.），2007 年获加拿大魁北克省蒙特利尔康考迪亚大学信息系统安全应用科学硕士学位（M.A.Sc.），2011 年获加拿大安大略省滑铁卢市滑铁卢大学电气与计算机工程博士学位（Ph.D.）。目前任澳门的澳门大学人工智能系副教授及副系主任。研究兴趣包括生物特征识别、模式识别和图像处理。他是 IEEE SMC 学会技术委员会委员，并担任 IEEE TIP、IEEE TSMC: Systems、IEEE TNNLS、IEEE OJ-CS 和 Artificial Intelligence Review 的副编辑。
- **Yanghao Zhou：** IEEE 学生会员。2018 年获中国吉林大学学士学位，2020 年获谢菲尔德大学硕士学位，目前在中国北京理工大学计算机科学与技术学院攻读博士学位。研究兴趣包括鲁棒多模态学习及其应用、多模态大语言模型和 AIGC。

- **Jie Wen：** IEEE 高级会员。2019 年获哈尔滨工业大学（深圳）计算机科学与技术博士学位，目前任该校计算机科学与技术学院教授。研究兴趣包括图像与视频增强、模式识别和机器学习。他已在 TNNLS、TIP、TCYB、NeurIPS、ICML、CVPR、AAAI、IJCAI、ACM MM 等期刊与会议发表或合作发表 100 余篇论文。他担任 IEEE Transactions on Pattern Analysis and Machine Intelligence、IEEE Transactions on Image Processing、IEEE Transactions on Information Forensics and Security、Pattern Recognition 和 International Journal of Image and Graphics 的副编辑，担任 Information Fusion 的领域编辑，并任 CAAI Transactions on Intelligence Technology 青年编委。他还曾担任 NeurIPS、ICLR、ACM MM 和 ICML 的领域主席，以及 AAAI 和 IJCAI 的 SPC。
- **Wenwu Wang：** IEEE Fellow，生于中国安徽。1997、2000 和 2002 年分别获中国哈尔滨工程大学自动化专业理学学士（B.Sc.）、工程硕士（M.E.）和博士（Ph.D.）学位。此后曾在伦敦国王学院、卡迪夫大学、Tao Group Ltd.（现 Antix Labs Ltd.）和 Creative Labs 工作；2007 年 5 月加入英国萨里大学，目前任信号处理与机器学习教授、计算机科学与电子工程学院外部合作副院长，并任萨里以人为中心人工智能研究院首席 AI Fellow。研究兴趣包括信号处理、机器学习与感知、人工智能和统计异常检测，已合著相关论文 400 余篇。曾获 Meta 杰出教师奖（2026）、音频工程学会最佳技术论文奖（2025）、IEEE 信号处理学会青年作者最佳论文奖（2022）、DCASE 评审奖（2020、2023、2024）、DCASE 可复现系统奖（2019、2020）及 LVA/ICA 最佳学生论文奖（2018）。他曾在 30 余场国际会议和研讨会上担任主题或全体会议报告人。

作者肖像（保留原图）

Chengliang Liu	Bo Li	Bob Zhang
		

Yanghao Zhou	Jie Wen	Wenwu Wang
		