蒸馏的统计学视角

A Statistical Perspective on Distillation · 非官方中文全文译文

Aditya Krishna Menon、Ankit Singh Rawat、Sashank J. Reddi、Seungyeon Kim、Sanjiv Kumar

Google Research，纽约。通讯作者：Aditya Krishna Menon（adityakmenon@google.com）。

原文发表于第38届国际机器学习大会（ICML），PMLR 139:7632–7642，2021。© 2021 原作者。原文及官方补充材料：PMLR论文页面。按 CC BY 4.0 制作中文翻译这一改编版本；未获作者审校或认可。译文包含11页主文（含参考文献）及8页官方补充材料。图表保留原图，并提供中文图注；参考文献保留作者、刊物等检索信息并翻译题名。与原文相比的改动为翻译、重新排版与明确标注的译者注。

排版记号说明. 原文的 Iverson 双方括号在译文中统一排为 $\mathbf{1}\{A\}$（A 为条件），条件成立时为1，否则为0；这仅是等价记号替换。向量粗体依原文保留，标量与带类别下标的分量不擅自加粗。

摘要

知识蒸馏是一种改善“学生”模型的技术：将其独热训练标签替换为从“教师”模型获得的标签分布。尽管取得了广泛成功，若干基本问题——例如，蒸馏为何有帮助？更准确的教师为何未必能更好地蒸馏？——尚未得到充分的形式化研究。本文提出蒸馏的统计学视角，以阐明这些问题。我们的核心观察是，提供真实类别概率的“贝叶斯教师”能够降低学生目标的方差，从而改善性能。随后，我们建立偏差—方差权衡，量化近似贝叶斯类别概率的教师的效用。这为怎样的教师才算“好”提供了形式化标准，即其概率估计的质量。最后，我们说明这一统计学视角如何促成蒸馏在二分排序与多类检索中的新应用。

1 引言

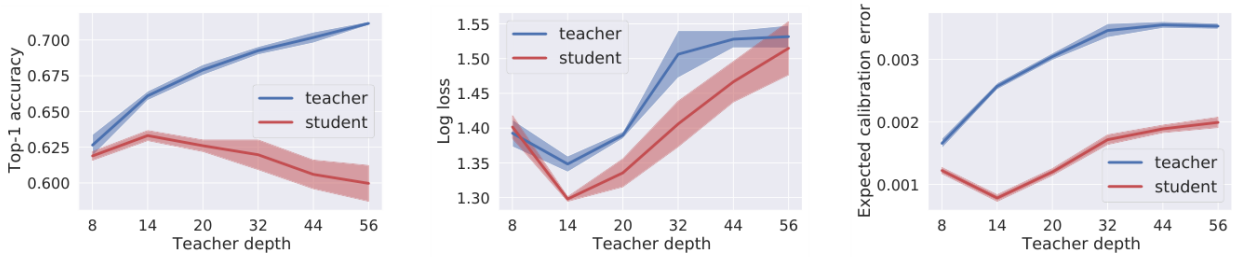
蒸馏是利用“教师”模型改善“学生”模型性能的过程（Bucilă 等，2006；Ba 与 Caruana，2014；Hinton 等，2015）。最简单的形式是训练学生拟合教师给出的软标签分布，而非独热训练标签。尽管最初被设计为模型压缩手段，蒸馏也成功改善了与教师采用相同架构的学生（Rusu 等，2016；Furlanello 等，2018），并获得了更广泛的应用（Papernot 等，2016；Yim 等，2017；Liu 等，2019）。

鉴于其实证成功，自然会问：蒸馏为什么有帮助？回答这一问题必须面对许多令人困惑的实证现象，例如，提高教师准确率可能损害蒸馏性能（Müller 等，2019）。Hinton 等（2015）提出的一种广受接受的直觉是：对于样本 (x, y)，教师的软标签通过赋予“错误”标签 $y' \neq y$ 的权重，提供了“暗知识”。但使用软标签而非独热标签究竟有何形式化的统计收益？什么才是“理想”的软标签集合？虽然多项研究考察了蒸馏的不同方面（Lopez-Paz 等，2016；Phuong 与 Lampert，2019；Mobahi 等，2020；Ji 与 Zhu，2020；Zhang 与 Sabuncu，2020；Zhou 等，2021；Hsu 等，2021；参见第2.2节），这些问题仍缺乏精确答案。

本文提出蒸馏的统计学视角，解释蒸馏为何能改善性能，阐明“暗知识”的统计价值，并形式化界定“好”教师。关键观察是：提供真实（贝叶斯）类别概率的教师，可以降低学生目标的方差，从而改善性能。此外，可靠近似这些概率的教师——仅仅准确并不足够——存在一种偏差—方差权衡，可以量化它们如何改善泛化。除了提供概念性见解，这一视角还促成蒸馏在二分排序、多类检索等问题中的新应用。

概括而言，我们的贡献如下。

1. 提出蒸馏的统计学观点，证明学生的期望损失本身就用贝叶斯类别概率平滑标签（第3节），进而量化用这些概率替换独热标签的收益。这给出了对“暗知识”的统计解释：对于样本 (x, y)，“错误”标签 $y' \neq y$ 的逻辑值（logit）编码了底层类别分布的信息。这帮助学生最小化对真实泛化误差更好的近似，从而改善性能。
2. 量化提供贝叶斯概率近似的教师的偏差—方差权衡（第4节）。由此得到评估教师是否“好”的具体标准：概率估计的质量，例如用对数损失来估计。这未必对应更准确的教师；见图1。
3. 说明这一统计学视角如何促成新的实际应用，例如二分排序和多类检索问题（第5节）。



(a) Top-1 accuracy. (b) Log-loss. (c) Expected calibration error.

图1. 更好的测试集类别概率估计通常产生更好的学生，与我们的偏差—方差界（命题3）一致。在 CIFAR-100 上，训练不同深度的 ResNet 教师，并蒸馏到固定深度8的 ResNet 学生。图1(a)显示，随深度增加，教师测试集准确率越来越高。然而，深度超过14后，教师的测试集概率估计对贝叶斯类别概率 $\mathbf{p}^*(x)$ 的近似逐渐变差：教师测试集对数损失和校准误差（Guo 等，2017）这两个概率估计质量指标均开始增大（图1(b)、(c)）。直观上，深度14在教师预测的偏差与方差之间达到最佳平衡。与命题3一致，概率估计最好的深度14教师产生了最准确的学生（图1(a)）。更多细节见第4.3节，形式化偏差—方差权衡见第4.1节。子图：(a) Top-1准确率；(b) 对数损失；(c) 期望校准误差。横轴均为教师深度。

我们在受控合成数据集与真实数据集上，针对线性模型、神经网络和决策树验证了这些发现。这说明了统计学视角更广泛的一点：蒸馏可以被理解为一种基本工具，其效用不限于神经网络。

更广泛地说，我们对教师蒸馏效用的简单度量——概率估计质量，可用测试集对数损失、平方损失或校准误差来估计——为理解各种实证结果提供了一种方式。例如，温度缩放可视为改善教师的概率校准（参见第4.2节）；而仅准确却给出低质量概率估计的教师，可能蒸馏得很差（图1、3）。

2 背景与记号

2.1 多类分类

在多类分类中，给定训练样本 $S \doteq \{(x_n, y_n)\}_{n=1}^{N} \sim \mathbb{P}^N$，其中 $\mathbb{P}$ 是定义在实例空间 $\mathcal{X}$ 和标签空间 $\mathcal{Y} = [L] \doteq \{1, 2, \ldots, L\}$ 上的分布。目标是学习风险最小的预测器 $\mathbf{f} : \mathcal{X} \to \mathbb{R}^L$：

$$R(\mathbf{f}) \doteq \mathbb{E}_{(x,y)\sim\mathbb{P}}\big[\ell\big(y, \mathbf{f}(x)\big)\big]. \qquad (1)$$

这里，$\ell\big(y, \mathbf{f}(x)\big)$ 是真实标签为 $y \in [L]$ 时预测 $\mathbf{f}(x) \in \mathbb{R}^L$ 的损失。一个典型例子是 softmax 交叉熵，即带 softmax 激活的对数损失：

$$\ell\big(y, \mathbf{f}(x)\big) = -f_y(x) + \log\Big[\sum_{y' \in [L]} e^{f_{y'}(x)}\Big]. \qquad (2)$$

可以通过经验风险近似 $R(\mathbf{f})$：

$$\widehat{R}(\mathbf{f}; S) \doteq \frac{1}{N}\sum_{n\in[N]} \mathbf{e}_{y_n}^{\top}\ell\big(\mathbf{f}(x_n)\big), \qquad (3)$$

其中 $\mathbf{e}_y \in \{0, 1\}^L$ 为标签 $y \in [L]$ 的独热编码，$\ell(\mathbf{f}(x)) \doteq (\ell(1, \mathbf{f}(x)), \ldots, \ell(L, \mathbf{f}(x))) \in \mathbb{R}_+^L$ 是所有可能标签的损失向量。

2.2 知识蒸馏

蒸馏利用“教师”模型改善“学生”模型。经典做法是匹配两模型的逻辑值（Bucilă 等，2006）。我们采用 Hinton 等（2015）的推广形式，先计算教师的类别概率估计 $\mathbf{p}^t(x) \doteq \big[p^t\big(y \mid x\big)\big]_{y\in[L]}$，其中 $p^t\big(y \mid x\big)$ 估计 x 被分为 y 的可能性。学生使用这些概率，将经验风险(3)替换为蒸馏风险：

$$\widetilde{R}(\mathbf{f}; S) = \frac{1}{N}\sum_{n\in[N]} \mathbf{p}^t(x_n)^{\top}\ell\big(\mathbf{f}(x_n)\big). \qquad (4)$$

这样，标签的独热编码被教师的标签分布所替代。构造(4)只要求 $\mathbf{p}^t$ 是有效标签分布。对通过最小化 softmax 交叉熵训练的神经网络教师，$\mathbf{p}^t$ 可以取温度缩放后教师逻辑值的 softmax（Hinton 等，2015，式2）。逻辑值匹配是这一方法的特例（Hinton 等，2015）。也有人研究了这一设置的扩展，例如匹配中间层（Romero 等，2015；Zagoruyko 与 Komodakis，2017；Kim 等，2018；Jain 等，2020）。

2.3 蒸馏为什么有帮助?

尽管蒸馏的实证价值已被广泛接受，对其原因却少有共识。Hinton 等（2015）将成功归因于教师对样本 (x, y) 的“错误”标签 $y' \neq y$ 所分配概率中编码的“暗知识”。这可能通过给样本赋予不同权重而帮助学生（Furlanello 等，2018；Tang 等，2020）。不过，对这一直觉的形式化有限。一个优雅的例外是 Lopez-Paz 等（2016）：假设软标签加速学习，则蒸馏有帮助；但该结果没有确立软标签何时及为何能够加速学习。

已有研究针对特定模型类，探索蒸馏对学生模型优化的影响（Phuong 与 Lampert，2019；Rahbar 等，2020；Ji 与 Zhu，2020）。蒸馏也可被看作学生模型上一种依赖数据的正则化（Dong 等，2019；Yuan 等，2020）；Mobahi 等（2020）及 Zhang 与 Sabuncu（2020）在自蒸馏（教师与学生架构相同）情形中阐明了这一点。Foster 等（2019）给出了受约束、须学习接近教师模型的学生的泛化界。这些工作既未说明“理想”教师的构成，也未量化对理想教师的近似如何影响泛化。

近期，Zhou 等（2021）提出了与第4节分析精神相近的偏差—方差视角。但他们没有量化使用贝叶斯概率的降方差收益（参见引理1），没有形式化说明这些收益如何迁移到近似贝叶斯概率（参见命题4），也没有提供利用该视角的更广泛蒸馏价值实例（参见第5节与附录B）。

3 蒸馏：类别概率视角

现在提出统计学视角，解释蒸馏为何能帮助泛化。核心有两个观察：(i) 我们试图最小化的风险(1)本身就使用类别概率 $\mathbb{P}(y \mid x)$ 平滑标签；(ii) 与独热标签 $\mathbf{e}_y$ 相比，这样的平滑得到方差更低的目标。

3.1 贝叶斯最明智：蒸馏类别概率

首先观察：预测器 $\mathbf{f} : \mathcal{X} \to \mathbb{R}^L$ 的总体风险是

$$R(\mathbf{f}) = \mathbb{E}_x \mathbb{E}_{y|x}\left[\ell\left(y, \mathbf{f}(x)\right)\right] = \mathbb{E}_x\left[\mathbf{p}^*(x)^\top \ell\left(\mathbf{f}(x)\right)\right], \qquad (5)$$

其中 $\mathbf{p}^*(x) \doteq \left[\mathbb{P}(y \mid x)\right]_{y \in [L]}$ 为标签上的贝叶斯类别概率分布。直观上，$\mathbb{P}(y \mid x)$ 表示 y 对 x 的适合程度：若 $\mathbf{p}^*(x)$ 并未集中在单一标签上，标签间就存在固有混淆。风险先抽取 $x \sim \mathbb{P}(x)$，再以 $\mathbb{P}(y \mid x)$ 为权重，对所有 $y \in [L]$ 的损失取平均。

给定 $(x_n, y_n) \sim \mathbb{P}$，经验风险(3)用仅支持一个标签的独热向量 $\mathbf{e}_{y_n}$ 近似 $\mathbf{p}^*(x_n)$。虽然前者是后者的无偏估计，但其粒度显著降低。相比之下，考虑样本 $S \sim \mathbb{P}^N$ 上的贝叶斯蒸馏风险：

$$\widehat{R}_*(\mathbf{f}; S) \doteq \frac{1}{N}\sum_{n=1}^{N} \mathbf{p}^*(x_n)^\top \ell\left(\mathbf{f}(x_n)\right). \qquad (6)$$

这是使用贝叶斯教师的蒸馏目标（参见(4)）；该教师提供真实类别概率。最小化(6)的学生并非拟合单个标签实现 $y_n \sim \text{Discrete}\left(\mathbf{p}^*(x_n)\right)$，而是按各自可能性考虑所有其他标签实现。当 ℓ 为(2)的对数损失时，(6)是 $\mathbf{p}^*$ 与 $\text{softmax}\left(\mathbf{f}(x_n)\right)$ 之间的 KL 散度加上一个常数。

标准经验风险(3)与贝叶斯蒸馏风险(6)，都是总体风险(1)的无偏估计。不过直观上，最小化(6)的学生应当更好泛化。下面将这一直觉精确化。

引理1. 用 $\mathbb{V}$ 表示随机变量的方差。对任意固定预测器 $\mathbf{f} : \mathcal{X} \to \mathbb{R}^L$，

$$\mathbb{V}_{S \sim \mathbb{P}^N}[\widehat{R}_*(\mathbf{f}; S)] \le \mathbb{V}_{S \sim \mathbb{P}^N}[\widehat{R}(\mathbf{f}; S)],$$

等号成立当且仅当对所有 $x \in \mathcal{X}$，损失值 $\ell(\mathbf{f}(x))$ 在 $\mathbf{p}^*(x)$ 的支撑集上恒定，即

$$(\forall\, x \in \mathcal{X})(\forall\, y, y' \in \text{supp}(\mathbf{p}^*(x))) \quad \ell\left(y, \mathbf{f}(x)\right) = \ell\left(y', \mathbf{f}(x)\right).$$

引理1的证明. 根据定义，

$$\begin{aligned}\text{LHS} &= \frac{1}{N}\mathbb{V}\left[\mathbf{p}^*(x)^\top \ell(\mathbf{f}(x))\right] \\ &= \frac{1}{N}\mathbb{V}\left[\mathbb{E}_{y|x}\ell\left(y,\ \mathbf{f}(x)\right)\right] \\ &= \frac{1}{N}\mathbb{E}_x\left[\mathbb{E}_{y|x}\ell\left(y,\ \mathbf{f}(x)\right)\right]^2 - \frac{1}{N}\left[\mathbb{E}_x\mathbb{E}_{y|x}\ell\left(y,\ \mathbf{f}(x)\right)\right]^2,\end{aligned}$$

$$\begin{aligned}\text{RHS} &= \frac{1}{N}\mathbb{V}\left[\ell\left(y,\ \mathbf{f}(x)\right)\right] \\ &= \frac{1}{N}\mathbb{E}_x\mathbb{E}_{y|x}\left[\ell\left(y,\ \mathbf{f}(x)\right)^2\right] - \frac{1}{N}\left[\mathbb{E}_x\mathbb{E}_{y|x}\ell\left(y,\ \mathbf{f}(x)\right)\right]^2.\end{aligned}$$

因为两者均无偏，原文指出两式的第二项均为 $R(\mathbf{f})^2$。对固定 $x \in \mathcal{X}$，向随机变量 $Z(x) \doteq \ell\left(y,\ \mathbf{f}(x)\right)$ 应用 Jensen 不等式便得结果。等号成立当且仅当每个 $Z(x)$ 恒定，即 ℓ 在 $\operatorname{supp}\left(\mathbf{p}^*(x)\right)$ 上恒定。

译者注（保留原文问题）. 上述两行实际写出的第二项带有 $1/N$，因此为 $R(\mathbf{f})^2/N$；原文文字写作 $R(\mathbf{f})^2$。此外，方差等号条件通常应理解为关于 x 的分布“几乎处处”成立，原文写为“所有 x”。不改动原结论陈述。

方差相等的条件很直观：当对所有 x，$\mathbf{f}$ 没有区分能力（各标签损失相同），或者标签本质上确定（$\mathbf{p}^*(x)$ 集中在单一标签），两风险显然一致。但对具有区分能力的预测器和不确定标签，贝叶斯蒸馏风险的方差可能低得多。

降方差的回报是更好的泛化：与使用独热标签相比，最小化(6)的学生更好地最小化总体风险(1)。利用 Maurer 与 Pontil（2009），可以量化贝叶斯蒸馏损失的经验方差如何影响泛化。

命题2. 取任意有界损失 ℓ。固定预测器 $\mathbf{f} : \mathcal{X} \to \mathbb{R}^L$ 的假设类 $\mathcal{F}$，其诱导函数类 $\mathcal{H}^* \subset [0,\ 1]^{\mathcal{X}}$ 包含函数 $h(x) \doteq \mathbf{p}^*(x)^\top \ell(\mathbf{f}(x))$。设 $\mathcal{H}^*$ 的一致覆盖数为 $\mathcal{N}_\infty$。则对任意 $\delta \in (0,\ 1)$，关于 $S \sim \mathbb{P}^N$，以至少 $1 - \delta$ 的概率有

$$R(\mathbf{f}) \le \widehat{R}_*(\mathbf{f};\ S) + O\left(\sqrt{\frac{\mathbb{V}_N^*(\mathbf{f})}{N}}\sqrt{\log\frac{M_N^*}{\delta}} + \frac{\log\left(M_N^*/\delta\right)}{N}\right),$$

其中 $M_N^* \doteq \mathcal{N}_\infty\left(1/N,\ \mathcal{H}^*,\ 2N\right)$，$\mathbb{V}_N^*(\mathbf{f})$ 是 $\{\mathbf{p}^*(x_n)^\top \ell\left(\mathbf{f}\left(x_n\right)\right)\}_{n=1}^N$ 的经验方差。

脚注1. 损失有界这一假设是标准假设（Boucheron 等，2005，定理4.1），实际中可通过某种正则化（例如权重衰减）施加。

命题2的证明. 这是 Maurer 与 Pontil（2009，定理6）的直接推论；该定理是 Bennett 不等式（Bennett，1962）的一致收敛版本。

相比之下，使用独热标签的标准经验风险所能获得的界，依赖独热损失值的方差（Maurer 与 Pontil，2009，定理6）。结合引理1，贝叶斯蒸馏经验风险产生较低的方差惩罚。因此，随样本量 N 增加，贝叶斯蒸馏风险的泛化界具有更有利的收敛速率。若需考虑教师欠拟合与过拟合的更精细分析，参见基于本文早期版本的 Dao 等（2021）。

概括而言，学生理想情况下应获得底层类别概率 $\mathbf{p}^*(x)$，而非单次实现 $y \sim \text{Discrete}(\mathbf{p}^*(x))$：这些概率使学生目标具有更低方差，从而帮助泛化。这给出“暗知识”价值的统计学解释：对于“贝叶斯教师” $\mathbf{p}^*$，样本 (x, y) 的其他标签 $y' \neq y$ 上的逻辑值，提供了贝叶斯类别概率的信息。

3.2 示例：贝叶斯教师的价值

在已知贝叶斯 $\mathbf{p}^*(x)$ 的受控环境中，我们展示用此“贝叶斯教师”蒸馏有利于学习。生成二分类训练样本 $S = \{(x_n, y_n)\}_{n=1}^N$，分布 $\mathbb{P}$ 的类条件分布为10维各向同性高斯，均值为 $\pm(0.25, 0.25, \ldots, 0.25)$。可显式计算 $\mathbf{p}^*(x) = (\mathbb{P}(y=0 \mid x), \mathbb{P}(y=1 \mid x))$，其中 $\mathbb{P}(y=1 \mid x) = \sigma\left((\theta^*)^\top x\right)$，$\theta^* \doteq (0.5, 0.5, \ldots, 0.5)$，$\sigma$ 为 sigmoid 函数。

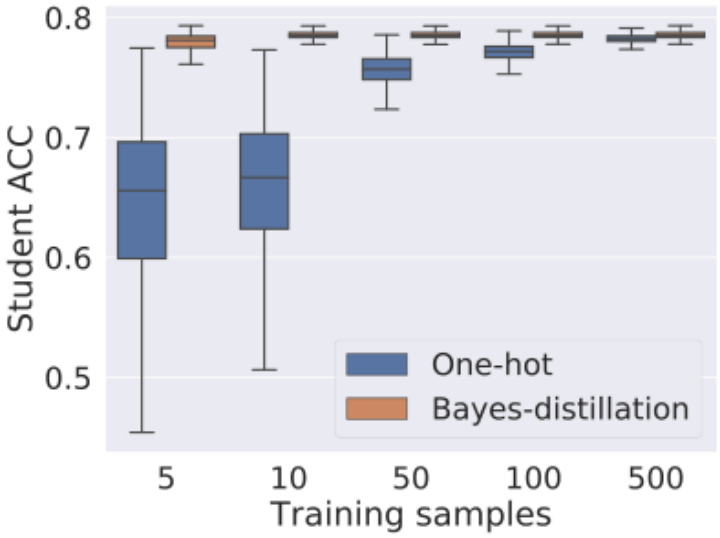


图2. 从“贝叶斯教师”蒸馏有助泛化。在已知贝叶斯概率 $\mathbf{p}^*$ 的合成问题上学习线性学生模型。与独热标签训练相比，用这些概率蒸馏显著提高准确率，小样本情况下尤其如此。

比较在 S 上训练的标准逻辑回归与按(6)使用 $\mathbf{p}^*(x_n)$ 的贝叶斯蒸馏逻辑回归。图2比较不同训练集大小 N：每个 N 做100次独立试验，并在 10^4 个样本的测试集上测量准确率。当 N 较小时，贝叶斯蒸馏相对独热训练有明显收益，与其保证更低方差的理论一致（引理1）。两方法都随 N 增大而改善，但独热编码收益更大。因此，贝叶斯蒸馏的降方差作用能够补偿学生样本较少的不足。更多实验见附录C.3。

4 从不完美教师蒸馏

上一节说明理想化的“贝叶斯教师”如何帮助学生。现在研究更现实的情形：使用从数据中学习到、不完美的“近似贝叶斯教师”。

4.1 蒸馏的偏差—方差界

首先观察到，教师预测器 $\mathbf{p}^t$ 通常是真实 $\mathbf{p}^*$ 的不完美估计。例如，最小化 softmax 交叉熵的教师，实际上在最小化 $\mathbb{E}\left[\mathrm{KL}\left(\mathbf{p}^*(x)\|\mathbf{p}^t(x)\right)\right]$。当然，实际中教师不太可能学得 $\mathbf{p}^t = \mathbf{p}^*$：模型类可能不足以表示真实 $\mathbf{p}^*$；即便能够表示，也可能由于统计问题（例如过拟合）与优化问题（例如非凸性），无法从有限样本完美学得它。

这样的不完美估计仍能改善泛化吗？为回答，我们建立蒸馏的偏差—方差权衡。具体而言，蒸馏风险 $\widetilde{R}(\mathbf{f};\, S)$（(4)）与总体风险 $R(\mathbf{f})$（(5)）的差异，取决于教师在均方误差（MSE）意义下估计贝叶斯类别概率分布 $\mathbf{p}^*$ 的好坏。而这又允许对教师估计作经典的偏差—方差分解。以下为简化起见，假设学生与教师在分开的样本上训练。

命题3. 取任意有界损失 ℓ。设教师模型 $\mathbf{p}^t$ 对应(4)中的蒸馏经验风险。对任意预测器 $\mathbf{f} : \mathcal{X} \to \mathbb{R}^L$，

$$\mathbb{E}\left[\left(\widetilde{R}(\mathbf{f};\, S) - R(\mathbf{f})\right)^2\right] \le \frac{1}{N}\mathbb{V}\left[\mathbf{p}^t(x)^\top \ell(\mathbf{f}(x))\right] + O\Big(\mathbb{E}\left[\left\|\mathbf{p}^t(x) - \mathbf{p}^*(x)\right\|_2\right]\Big)^2. \tag{7}$$

命题3的证明. 令 $\Delta \doteq \widetilde{R}(\mathbf{f};\, S) - R(\mathbf{f})$。则

$$\mathbb{E}\left[\left(\widetilde{R}(\mathbf{f};\, S) - R(\mathbf{f})\right)^2\right] = \mathbb{E}\left[\Delta^2\right] = \mathbb{V}[\Delta] + \mathbb{E}[\Delta]^2.$$

注意

$$\begin{aligned}
\mathbb{E}[\Delta] &= \mathbb{E}_x\left[\left(\mathbf{p}^t(x) - \mathbf{p}^*(x)\right)^\top \ell(\mathbf{f}(x))\right] \\
&\le \mathbb{E}_x\left[\left\|\mathbf{p}^t(x) - \mathbf{p}^*(x)\right\|_2 \left\|\ell(\mathbf{f}(x))\right\|_2\right] \\
&\le \mathbb{E}_x\left[\left\|\mathbf{p}^t(x) - \mathbf{p}^*(x)\right\|_2 c \left\|\ell(\mathbf{f}(x))\right\|_\infty\right] \\
&\le c\,\mathbb{E}_x\left[\left\|\mathbf{p}^t(x) - \mathbf{p}^*(x)\right\|_2\right],
\end{aligned}$$

其中第二行来自 Cauchy–Schwarz 不等式，第三行来自带常数 c 的范数等价。由于 $R(\mathbf{f})$ 为常数，$\mathbb{V}[\Delta] = \mathbb{V}\left[\widetilde{R}(\mathbf{f};\, S)\right] = N^{-1}\mathbb{V}\left[\mathbf{p}^t(x)^\top \ell(\mathbf{f}(x))\right]$，于是得到(7)。

译者注. 原证明展示的是 $\mathbb{E}[\Delta]$ 的单侧界；用于平方时可对其绝对值应用同一 Cauchy–Schwarz 界。原文最后一行把有界损失的上界吸收到常数中。

展开命题3可知，蒸馏风险的保真度取决于两个因素：随机实例的期望损失变动有多大；教师估计 $\mathbf{p}^t$ 在 MSE 意义下多好地近似真实 $\mathbf{p}^*$。当 N 很大时，后者占主导，并具有经典偏差—方差权衡。由附录 A.2，可把(7)写为

$$\begin{aligned}
\mathbb{E}\left[\left(\widetilde{R}(\mathbf{f};\, S) - R(\mathbf{f})\right)^2\right] \;\le\; & \frac{1}{N}\mathbb{V}\left[\mathbf{p}^t(x)^\top \ell(\mathbf{f}(x))\right] \\
& + O\Big(\left\|\mathbb{E}\left[\mathbf{p}^t(x)\right] - \mathbf{p}^*(x)\right\|_2^2 + \mathbb{V}\left[\mathbf{p}^t(x)\right]\Big).
\end{aligned} \tag{8}$$

最后两项体现经典现象：提高教师复杂度可减小偏差（更好近似 $\mathbf{p}^*$），代价却是更高方差（预测更不稳定）。妥善平衡这些量，得到相对于 $\mathbf{p}^*$ 的 MSE 较低的教师。命题3表明，这样的教师带来更好的学生泛化误差界。实际上，由上一节可推出

$$R(\mathbf{f}) \leq \widetilde{R}(\mathbf{f}; S) + \mathcal{C}(\mathcal{F}, N) + O\left(\mathbb{E}\|\mathbf{p}^t(x) - \mathbf{p}^*(x)\|_2\right). \qquad (9)$$

其中 $\mathcal{C}$ 为命题2中假设类 $\mathcal{F}$ 的惩罚项。直观上，不完美教师引入额外惩罚，其大小依赖预测在平方误差意义下距离贝叶斯概率多远。形式化陈述及与已有界的比较见附录A的命题4。

4.2 讨论与启示

我们提出的统计学视角基于两点：“贝叶斯教师”可以降低学生目标的方差；近似贝叶斯概率的教师提供偏差—方差权衡。结果易由这一视角导出，但其对蒸馏的启示和概念性见解较为微妙，值得讨论。

怎样的教师才“好”？ 上述分析具体说明了如何评价教师软标签的质量：它们应是“好”的概率估计，即相对于贝叶斯概率 $\mathbf{p}^*$ 的平方误差较低。命题3确立，这时得到的学生能更好泛化。

有三点限定。首先，实际中不可能精确评估到 $\mathbf{p}^*$ 的平方误差，因为后者通常未知；但可在留出集上估计教师概率质量，例如计算相对于独热标签的对数损失、平方损失或校准误差（Guo 等，2017）。尽管这些估计必然不完美，仍能检测差的教师概率。

其次，命题3可能较松，且不是下界。完整的蒸馏理论还需要给出必要条件。然而，这些界的定性趋势仍可在实际中成立。例如，图1（亦见第4.3节）显示，增加 ResNet 深度可能提高准确率，却降低概率估计质量。

第三，以近似贝叶斯概率 $\mathbf{p}^*$ 为中心，意味着教师预测主要应反映偶然不确定性，而非认知不确定性（Senge 等，2014；Hüllermeier 与 Waegeman，2021）。

更准确的教师为何可能蒸馏得更差? 一种奇特的实证现象是，更准确的教师可能产生更差的学生（Müller 等，2019）。统计学视角提供一种解释：好的概率建模有助学生泛化，但尽管给出好概率的模型也会准确，准确模型却未必给出好概率（Devroye 等，1996，第6.7节）。事实上，深度网络虽准确，却经常给出过度自信、校准不佳的预测（Guo 等，2017；Rothfuss 等，2019）。

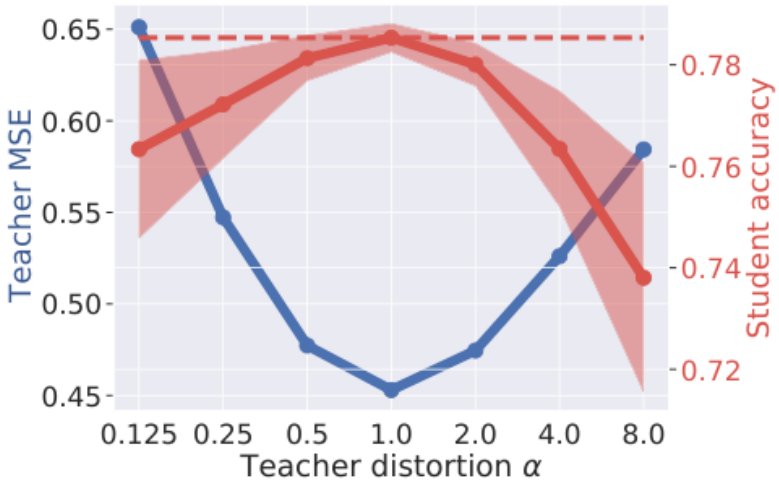


图3. 教师准确率不足以预测蒸馏性能。在合成问题上构造由 α 参数化的一族教师，它们准确率相同（红虚线），但概率估计质量不同（蓝线），质量用相对贝叶斯 $\mathbf{p}^*$ 的 MSE 测量。将各教师蒸馏到线性学生，得到明显不同的准确率（红实线）；概率估计最佳的教师（$\alpha = 1.0$）表现最好。横轴：教师失真参数 α；纵轴：教师MSE与学生准确率。

温度缩放为何有帮助? 温度缩放（Hinton 等，2015）是常用技巧，通过 $p^t(y \mid x) \propto \exp\left(f_y^t(x)/T\right)$、$T > 0$ 平滑过度自信的教师逻辑值 $\mathbf{f}^t(x)$。与统计学观点一致，这样的缩放能让学生的目标更接近真实标签分布 $\mathbf{p}^*$（从而帮助泛化），而不仅仅传递最准确的标签。

偏差换方差：模型复杂度。 根据(8)，为了获得更紧的学生泛化界，可以偏好偏差更高的教师（$\mathbf{p}^t$ 对 $\mathbf{p}^*$ 的近似更差），只要其方差更低（$\mathbf{p}^t$ 随样本变化更小）。例如，调节教师复杂度即可得到这样的权衡。

对于神经网络，近期研究挑战了传统观念（Geman 等，1992）：提高模型复杂度（例如增加网络宽度或深度）就意味着更高方差（Neal 等，2018；Yang 等，2020）。命题3并未假设或施加特定的偏差—方差权衡，而是说明给定权衡如何影响学生泛化。特别地，它表明同时实现低偏差、低方差的模型应该能很好地蒸馏。

偏差换方差：标签平滑。 标签平滑（Szegedy 等，2016）将学生标签与均匀预测混合，即对 $\alpha \in (0, 1]$ 使用 $\mathbf{p}^t(x) = (1-\alpha)\mathbf{e}_y + (\alpha/L)\mathbf{1}$。从建模 $\mathbf{p}^*(x)$ 的角度，相对于直接使用观察标签，这引入偏差，但因 $(1-\alpha)$ 缩放而降低方差。只要偏差不太大，平滑便能帮助泛化。近期工作还研究了平滑如何降低优化过程的方差（Xu 等，2020）。

关于训练样本复用。 我们的分析要求教师与学生使用不同训练样本。这适用于教师给大型未标注样本池打标签的常见情况（Radosavovic 等，2018；Yalniz 等，2019）。近期，Dao 等（2021）展示了如何通过更细致的“交叉拟合”过程，让教师与学生使用相同训练样本。它减少教师概率估计过拟合的风险，代价是计算成本略微增加。

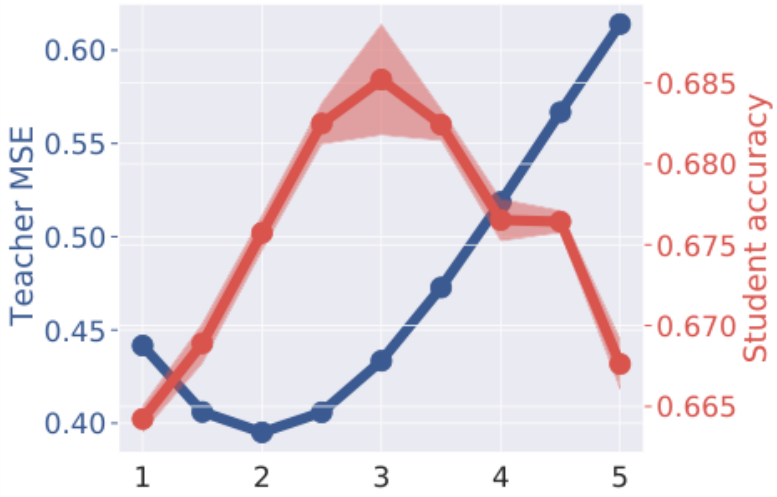


图4. 适当的温度缩放可以改善教师概率质量。在 CIFAR-100 上从 ResNet-32 蒸馏到 ResNet-14；温度 T 过高或过低时，教师分布分别过平或过尖，因而不能很好反映真实 $\mathbf{p}^*$。调节 T 可改善由测试集平方损失测得的教师概率质量。这一变化也跟踪学生准确率，尤其在两个极端，与我们的观点一致。

4.3 示例：教师概率的价值

通过受控合成问题与真实问题上的实证结果，采用线性模型、神经网络和决策树，说明上述论点。这些结果强调，对蒸馏进行统计推理并不限于深度神经网络。

教师准确率并不充分（图3）。 首先展示教师准确率并不总能转化为好的学生性能。对第3.2节贝叶斯概率为 $\mathbf{p}^*$ 的高斯数据，构造教师概率 $\bar{\mathbf{p}}(x) = \Psi_\alpha(\mathbf{p}^*(x))$。改变 α 不影响准确率，但使 $\mathbf{p}^*$ 更集中，从而降低其概率质量（如 MSE）。具体地，令 $\Psi_\alpha(u) = \frac{1}{2} + \frac{1}{2}(2u-1)^\alpha \mathrm{sgn}(2u-1)$，其中 $\alpha \in \{2^{-3}, 2^{-2}, \ldots, 2^3\}$（图见附录C.2）。

译者注. 此处以及补充材料的函数原式未在 $2u-1$ 外加绝对值；当 $u < 1/2$、α 非整数时，实值幂存在定义问题。图示所表达的是保持排序的实值变换，但本译文保留原式，不默改为绝对值版本。

图3证实，虽然所有 α 的教师准确率相同，$\alpha \neq 1$ 时学生准确率却系统性受损。此外，学生准确率紧随由 $\|\bar{\mathbf{p}} - \mathbf{p}^*\|_2^2$ 衡量的教师概率估计质量。这与我们的分析一致。

温度缩放与概率质量（图4）。 验证温度缩放改善教师概率质量，并跟踪蒸馏学生性能。在 CIFAR-100 上从 ResNet-32 蒸馏到 ResNet-14，采用 $T \in \{1.0, 1.5, 2.0, \ldots, 5.0\}$。对每个 T，测量教师概率相对独热标签的测试集 MSE，以及学生模型准确率。与可访问 $\mathbf{p}^*$ 的合成环境不同，前者必然只是教师真实概率质量的估计。

图4显示，随 T 改变，教师概率 MSE 平滑变化，最佳温度为 $T^* = 2$。学生最佳准确率在略高温度 $T^* = 3$ 达到——这反映出我们给出的是学生风险的上界——但超过此点后，概率质量退化，学生准确率也迅速下降，与我们的观点一致。

偏差换方差：决策树（图5）。 在不同教师间选择时，可偏好偏差较高、即概率估计较差但方差较低的教师。我们在受控合成问题上训练一系列复杂度递增的教师。数据的边缘分布 $\mathbb{P}(x)$ 在 $[0,\ 1]^2$ 上均匀，而 $\mathbb{P}(y = 1 \mid x)$ 呈“棋盘”模式，正负样本散布在交替方格内；图示见附录C.1。

考虑深度 $d \in \{4,\ 5,\ 6,\ 7,\ 8\}$ 的决策树教师。增大 d 减少偏差、增加方差，因为更深的树可更好近似 $\mathbf{p}^*$，但更复杂。固定 d 时，在训练样本 S（$N = 5000$）上训练教师，将其预测蒸馏到深度4的学生树，并在100次试验中计算测试集教师 MSE 与学生 AUC-ROC。

图5显示，教师在 $d = 6$ 时对 $\mathbf{p}^*$ 达到最佳 MSE 近似。与分析一致，该教师产生的学生泛化最好。$d > 6$ 时教师偏差更低、方差更高；偏差更高的 $d = 6$ 教师在 MSE 上取得更好的权衡。另一问题上的附加结果见附录C.4。

偏差换方差：ResNet（图1）。 图1在 CIFAR-100 上训练不同深度的 ResNet 教师，并蒸馏至深度固定为8的学生。概率更好（MSE意义下）的教师通常产生更好的学生。虽然随教师深度增加，准确率持续提高，但准确率提高并不对应 MSE 改善。已有工作发现学生与教师大小不匹配也会影响蒸馏（Cho 与 Hariharan，2019；Mirzadeh 等，2020）。为减轻此类混杂因素，在附录图10中将图1扩展至深度14、20的学生，发现深度8的一般趋势仍然成立。

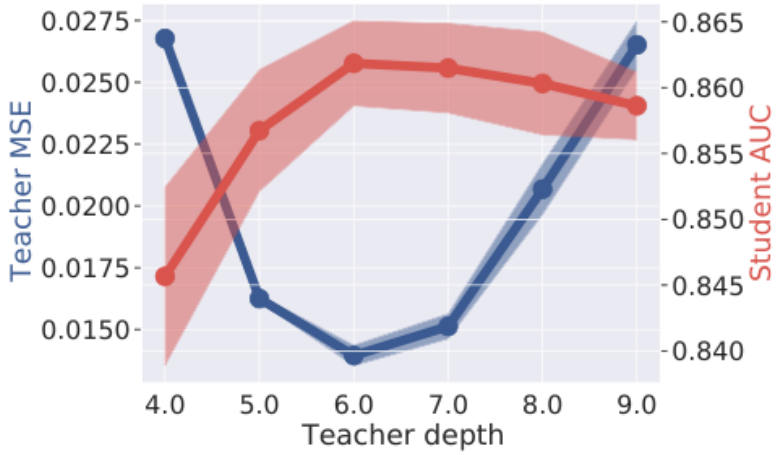


图5. 受控环境中的偏差—方差权衡：可以偏好偏差更高、即概率估计相对较差但方差更低的教师。合成问题上，不同深度的决策树教师蒸馏到深度4的学生。增加教师深度减小偏差，代价是增大方差。最佳教师深度 $d = 6$ 平衡两项，最小化教师 MSE。根据我们的分析，教师 MSE 紧随学生性能。横轴为教师深度；纵轴为教师MSE和学生AUC。

5 统计学视角的应用

统计学观点已经在概念上解释蒸馏如何改善分类。现在展示一种潜在实际收益：以简单、通用的方式，将蒸馏应用到分类之外的场景。具体而言，将目标写为贝叶斯类别概率的函数，就能导出基于教师输出的经验估计。这与朴素地应用蒸馏有所不同，下面举例说明。

5.1 二分排序的蒸馏

给定 $\mathcal{X}\times\{\pm 1\}$ 上的分布 $\mathbb{P}$，二分排序问题（Agarwal 与 Niyogi，2009）旨在学习评分器 $f:\mathcal{X}\to\mathbb{R}$，使成对不一致最小：

$$\mathrm{PD}(f) \doteq \mathbb{E}_{x|y=+1}\mathbb{E}_{x'|y=-1}\mathbf{1}\{f(x) < f(x')\},$$

即随机正样本得分低于随机负样本的概率。这等于1减去 f 的 ROC 曲线下面积（Agarwal 等，2005），衡量 f 区分正负样本的能力。给定训练样本 $S=\{(x_n,\, y_n)\}_{n=1}^{N}\sim\mathbb{P}^N$，PD 的经验估计为

$$\widehat{\mathrm{PD}}(f) \propto \sum_{i\in S_+}\sum_{j\in S_-}\mathbf{1}\{f(x_i) < f(x_j)\}, \qquad (10)$$

其中 $S_+,\, S_-$ 是正、负样本子集。直观上，考虑正负标签样本对，评估其得分差。

在蒸馏情形，给定强教师，可构造原始风险更紧的近似。由于 $\mathbb{P}(x \mid y)\propto\mathbb{P}(y \mid x)\mathbb{P}(x)$，可写为

$$\mathrm{PD}(f) \propto \mathbb{E}_{x\sim\mu}\mathbb{E}_{x'\sim\mu}\left[p^*(x)\left(1-p^*(x')\right)\mathbf{1}\{f(x) < f(x')\}\right],$$

其中 μ 为实例边缘分布，$p^*(x)\doteq\mathbb{P}(y=+1 \mid x)$。如上一节所述，用教师概率 p^t 替换 p^*，得到蒸馏二分风险：

$$\widehat{\mathrm{PD}}(f) \propto \sum_{i\in S,\, j\in S\setminus\{i\}} p^t(x_i)\left(1-p^t(x_j)\right)\mathbf{1}\{f(x_i) < f(x_j)\}.$$

注意，这里考虑所有样本对，而不是像(10)那样分为“正”“负”组。此外，每一项都使用教师概率平滑两次，而分类中标准做法只用一次（参见(4)）。下文也会出现这一点。

5.2 多类检索的蒸馏

给定 $\mathcal{X}\times[L]$ 上的分布 $\mathbb{P}$，多类检索问题（Lapin 等，2018；Reddi 等，2019）旨在学习预测器 $\mathbf{f}:\mathcal{X}\to\mathbb{R}^L$，使对样本 $(x,\, y)$，$\mathbf{f}(x)\in\mathbb{R}^L$ 排名前列的标签包含真实标签 y。常用损失之一是二元解耦损失族（Reddi 等，2019）：

$$\ell(y,\, \mathbf{f}(x)) = \phi\left(f_y(x)\right) + \sum_{y'\neq y}\phi\left(-f_{y'}(x)\right), \qquad (11)$$

其中 $\phi:\mathbb{R}\to\mathbb{R}_+$ 是二分类间隔损失，例如铰链损失 $\phi(z)=[1-z]_+$。第一项鼓励“正”标签 y 得高分，第二项鼓励“负”标签 $y'\neq y$ 得低分。固定 $x\in\mathcal{X}$ 时，对抽取的 y 取期望损失：

$$\begin{aligned}\mathbf{p}^*(x)^\top\ell(\mathbf{f}(x)) &= \mathbf{p}^*(x)^\top\left(\phi(\mathbf{f}(x))-\phi(-\mathbf{f}(x))\right)+\mathbf{1}^\top\phi(-\mathbf{f}(x))\\ &= \mathbf{p}^*(x)^\top\phi(\mathbf{f}(x))+\left(\mathbf{1}-\mathbf{p}^*(x)\right)^\top\phi(-\mathbf{f}(x))\\ &= \sum_{y\in[L]}\mathbb{P}(y \mid x)\phi\left(f_y(x)\right) \qquad (12)\\ &\quad+\sum_{y'\in[L]}\left(1-\mathbb{P}(y' \mid x)\right)\phi\left(-f_{y'}(x)\right).\end{aligned}$$

这里 $\mathbf{1} \in \mathbb{R}^L$ 为全1向量，$\mathbf{p}^*(x)$ 仍为 $\mathbb{P}(y \mid x)$ 的向量。相比(11)，第一项像标准蒸馏一样，将所有标签 $y \in [L]$ 视为“平滑正例”。有趣的是，第二项将所有标签 $y' \in [L]$ 视为“平滑负例”，其权重随 $\mathbb{P}(y' \mid x)$ 改变。原文直观解释是：损失更关注那些可能是 x 的其他合理解释的负例 y'。

译者注. 原文最后一句与式(12)的权重方向存在张力：$\mathbb{P}(y' \mid x)$ 越高，负项系数 $1 - \mathbb{P}(y' \mid x)$ 越小。本译文保留这一原文解释，未将其改写为相反含义。

按统计学视角，在有限样本 $S = \{(x_n, y_n)\}_{n=1}^N$ 上，可用教师估计 $\mathbf{p}^t$ 替换这些贝叶斯概率：

$$
\begin{aligned}
\widetilde{R}(\mathbf{f}; S) &= \frac{1}{N} \sum_{n \in [N]} \sum_{y \in [L]} p^t(y \mid x_n) \big[\phi\big(f_y(x_n)\big) + z(x_n) \big], \\
z(x_n) &\doteq \sum_{y' \in [L]} \alpha_{y'}(x_n) \phi\big(-f_{y'}(x_n)\big), \\
\alpha_{y'}(x_n) &\doteq 1 - p^t(y' \mid x_n).
\end{aligned}
\tag{13}
$$

与标准分类类似，对正负标签采用这种差异加权，可以得到期望损失的低方差估计。可扩展到常用的 softmax 交叉熵（参见(2)）：

$$
\ell\big(y, \mathbf{f}(x)\big) = -f_y(x) + \log\Big[\sum_{y' \in [L]} e^{f_{y'}(x)} \Big].
$$

内部求和可视为惩罚“负”标签 $y' \neq y$ 的高得分。受(12)启发，差异化加权负例，得到：

$$
\begin{aligned}
\widetilde{R}(\mathbf{f}; S) &= \frac{1}{N} \sum_{n \in [N]} \sum_{y \in [L]} p^t(y \mid x_n) \big[-f_y(x_n) + z(x_n) \big], \\
z(x_n) &\doteq \log\Big(\sum_{y' \in [L]} \alpha_{y'}(x_n) e^{f_{y'}(x_n)} \Big), \\
\alpha_{y'}(x_n) &\doteq 1 - \mathbf{1}\{y' \neq y_n\} p^t(y' \mid x_n).
\end{aligned}
\tag{14}
$$

与(13)不同，这里 $\alpha_{y_n}(x_n) = 1$。原文指出，这一选择保证 $\ell\big(y, \mathbf{f}(x)\big)$ 非负，因为损失可视为加权 softmax 分布下的对数损失。

译者注. 式(14)的权重按观察标签 y_n 定义，而外层求和遍历 y；原文接着用任意候选标签 y 解释非负性。此处存在索引不一致，不能仅凭所印公式推出所有求和项都非负。本译文保留 y_n 及原解释。

再次强调，这里使用教师两次：第一次为标准蒸馏，平滑正标签；第二次是新的用途，平滑负标签。相比标准损失，对每个候选标签 y，计算损失时都给负标签 $y' \neq y$ 施加依赖实例及标签的权重。因此称其为**负例感知蒸馏**。

实证上，以“未归一化”的教师概率而非直接用 $\mathbf{p}^t$ 加权负例，表现更好。具体可用 $1 - \sigma\big(a\, s^t_{y'}(x)\big)$，其中 $s^t_{y'}(x)$ 是教师逻辑值，σ 为 sigmoid，$a > 0$ 是可调缩放参数。相比使用 $\mathbf{p}^t$，这允许多个 y' 同时具有高（或低）权重。在一个给定 $x \in \mathcal{X}$ 可有多个相关标签的检索场景中，这很有用。

5.3 实证示例

二分排序公式的实证分析放在附录C.6。这里在多类检索基准 AMAZONCAT-13K 与 AMAZONCAT-670K（McAuley 与 Leskovec，2013；Bhatia 等，2015）上评估负例感知蒸馏目标。

采用含一个宽度512的（线性）隐藏层的前馈“教师”模型，以最小化 softmax 交叉熵训练。“学生”在 AMAZONCAT-13K 上隐藏层宽度8，在 AMAZONCAT-670K 上宽度64，因为后者标签多得多。

比较学生使用独热标签、教师逻辑值（蒸馏）、以及按(14)在 softmax 中额外平滑负例的教师逻辑值三种训练方式。目的是确认负例感知蒸馏的核心思想——除正例外，也用教师平滑负例——可以改善标准蒸馏。

	AMAZONCAT-13K			AMAZONCAT-670K		
Method	**P@1**	**P@3**	**P@5**	**P@1**	**P@3**	**P@5**
Teacher	0.8495	0.7412	0.6109	0.3983	0.3598	0.3298
Student	0.7913	0.6156	0.4774	0.3307	0.3004	0.2753
Student + SD	0.8131	0.6363	0.4918	0.3461	0.3151	**0.2892**
Student + NAD	**0.8560**	**0.7148**	**0.5715**	**0.3480**	**0.3161**	0.2865

表1. 多类检索任务上，负例感知蒸馏（NAD）、标准蒸馏（SD）与学生基线的 Precision@k。NAD 改善这两种方法。左侧数据集 AMAZONCAT-13K，右侧 AMAZONCAT-670K；各组列为 P@1、P@3、P@5；行依次为教师、学生、学生+SD、学生+NAD。数字及原表强调方式见保留表图。

以 $k \in \{1,\ 3,\ 5\}$ 的 precision@k 比较所有方法，对多次运行取平均。表1总结结果：蒸馏相对学生基线带来小而一致的提升，负例感知蒸馏进一步改善，尤其在 $k = 1,\ 3$ 时，确认差异化加权负例的价值。在 AMAZONCAT-13K 上收益显著，甚至超过教师模型。最后，这里使用（负例感知）蒸馏仍遵循前几节的原则：例如，对教师做温度缩放改善概率校准，而该变化与学生性能一致；见附录C.7。

5.4 讨论与启示

以上两个例子说明统计学视角如何促成蒸馏在多类分类之外的应用。每种应用的关键是用贝叶斯类别概率表示真实期望损失。所得目标以不同于经典蒸馏的方式使用教师，例如同时加权正负标签。

更广泛地，对具有复杂目标的其他问题也可采用类似过程；附录B提供更多例子，包括对标签噪声的鲁棒性。

6 结束语

我们的蒸馏统计学视角建立在简单观察上：用贝叶斯类别概率蒸馏，可以更好地估计总体风险。这在概念上解释了蒸馏为何有帮助，并提供一种简单、有原则的方式，将蒸馏用于分类之外的场景。

未来有多个值得研究的方向。例如，把我们的分析与蒸馏其他作用的研究（如对优化的影响，Phuong 与 Lampert，2019）结合起来会很有意义。更细粒度的偏差与方差概念也值得研究，例如 Zhou 等（2021）中的“正则化样本”概念。

参考文献

以下保留原文全部书目信息，题名附中文译名；未补充原文未列出的 DOI 或链接。

- Agarwal, S. 与 Niyogi, P. 排序算法基于算法稳定性的泛化界（Generalization bounds for ranking algorithms via algorithmic stability）. J. Mach. Learn. Res., 10:441–474, June 2009. ISSN 1532-4435.
- Agarwal, S., Graepel, T., Herbrich, R., Har-Peled, S., 与 Roth, D. ROC曲线下面积的泛化界（Generalization bounds for the area under the roc curve）. Journal of Machine Learning Research, 6(14):393–425, 2005.
- Ba, J. 与 Caruana, R. 深度网络真的需要很深吗？（Do deep nets really need to be deep?）. 载 Ghahramani, Z., Welling, M., Cortes, C., Lawrence, N. D., 与 Weinberger, K. Q.（编）, Advances in Neural Information Processing Systems 27, pp. 2654–2662. Curran Associates, Inc., 2014.
- Bennett, G. 独立随机变量之和的概率不等式（Probability inequalities for the sum of independent random variables）. Journal of the American Statistical Association, 57(297):33–45, 1962.
- Bhatia, K., Jain, H., Kar, P., Varma, M., 与 Jain, P. 用于极端多标签分类的稀疏局部嵌入（Sparse local embeddings for extreme multi-label classification）. Advances in Neural Information Processing Systems, pp. 730–738, 2015.
- Boucheron, S., Bousquet, O., 与 Lugosi, G. 分类理论：若干近期进展综述（Theory of classification: a survey of some recent advances）. ESAIM: Probability and Statistics, 2005.
- Bucilă, C., Caruana, R., 与 Niculescu-Mizil, A. 模型压缩（Model compression）. Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD ’06, pp. 535–541, New York, NY, USA, 2006. ACM.
- Cho, J. H. 与 Hariharan, B. 论知识蒸馏的有效性（On the efficacy of knowledge distillation）. 2019 IEEE/CVF International Conference on Computer Vision (ICCV), pp. 4793–4801, 2019.
- Dao, T., Kamath, G. M., Syrgkanis, V., 与 Mackey, L. 作为半参数推断的知识蒸馏（Knowledge distillation as semiparametric inference）. International Conference on Learning Representations, 2021.
- Devroye, L., Györfi, L., 与 Lugosi, G. 模式识别的概率理论（A Probabilistic Theory of Pattern Recognition）. Stochastic Modelling and Applied Probability, volume 31. Springer, 1996. ISBN 978-1-4612-0711-5.
- Dong, B., Hou, J., Lu, Y., 与 Zhang, Z. 蒸馏约等于提前停止？利用各向异性信息检索从过参数化神经网络中获取暗知识（Distillation ≈ early stopping? harvesting dark knowledge

utilizing anisotropic information retrieval for overparameterized neural network），2019.

- Duchi, J., Hashimoto, T., 与 Namkoong, H. 潜在协变量混合的分布鲁棒损失（Distributionally robust losses for latent covariate mixtures）, 2020.
- Foster, D. J., Greenberg, S., Kale, S., Luo, H., Mohri, M., 与 Sridharan, K. 假设集稳定性与泛化（Hypothesis set stability and generalization）. Advances in Neural Information Processing Systems 32, pp. 6726–6736. Curran Associates, Inc., 2019.
- Furlanello, T., Lipton, Z. C., Tschannen, M., Itti, L., 与 Anandkumar, A. 再生神经网络（Born-again neural networks）. Proceedings of the 35th International Conference on Machine Learning, ICML 2018, pp. 1602–1611, 2018.
- Geman, S., Bienenstock, E., 与 Doursat, R. 神经网络与偏差/方差困境（Neural networks and the bias/variance dilemma）. Neural Computation, 4(1):1–58, 1992.
- Guo, C., Pleiss, G., Sun, Y., 与 Weinberger, K. Q. 论现代神经网络的校准（On calibration of modern neural networks）. Proceedings of the 34th International Conference on Machine Learning, pp. 1321–1330, 2017.
- Hinton, G. E., Vinyals, O., 与 Dean, J. 蒸馏神经网络中的知识（Distilling the knowledge in a neural network）. CoRR, abs/1503.02531, 2015.
- Hsu, D., Ji, Z., Telgarsky, M., 与 Wang, L. 通过蒸馏获得泛化界（Generalization bounds via distillation）. International Conference on Learning Representations, 2021.
- Hüllermeier, E. 与 Waegeman, W. 机器学习中的偶然与认知不确定性：概念与方法导论（Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods）. Machine Learning, 110(3):457–506, 2021.
- Jain, H., Gidaris, S., Komodakis, N., Pérez, P., 与 Cord, M. Quest：用于知识迁移的量化嵌入空间（Quest: Quantized embedding space for transferring knowledge）. 载 Vedaldi, A., Bischof, H., Brox, T., 与 Frahm, J.-M.（编）, Computer Vision – ECCV 2020, pp. 173–189, Cham, 2020. Springer International Publishing.
- Ji, G. 与 Zhu, Z. 宽神经网络中的知识蒸馏：风险界、数据效率及不完美教师（Knowledge distillation in wide neural networks: Risk bound, data efficiency and imperfect teacher）. 载 Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., 与 Lin, H.（编）, Advances in Neural Information Processing Systems, 2020.
- Kim, J., Park, S., 与 Kwak, N. 复述复杂网络：通过因子迁移压缩网络（Paraphrasing complex network: Network compression via factor transfer）. Proceedings of the 32nd International Conference on Neural Information Processing Systems, NIPS’18, pp. 2765–2774, Red Hook, NY, USA, 2018. Curran Associates Inc.
- Lapin, M., Hein, M., 与 Schiele, B. 多类、top-k及多标签分类损失函数的分析与优化（Analysis and optimization of loss functions for multiclass, top-k, and multilabel classification）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 40(7):1533–1554, July 2018.
- Liu, Y., Jia, X., Tan, M., Vemulapalli, R., Zhu, Y., Green, B., 与 Wang, X. 搜索以蒸馏：珍珠无处不在，唯缺发现的眼睛（Search to distill: Pearls are everywhere but not the eyes）, 2019.

· Lopes, R. G., Fenu, S., 与 Starner, T. 深度神经网络的无数据知识蒸馏（Data-free knowledge distillation for deep neural networks）. CoRR, abs/1710.07535, 2017.
· Lopez-Paz, D., Schölkopf, B., Bottou, L., 与 Vapnik, V. 统一蒸馏与特权信息（Unifying distillation and privileged information）. International Conference on Learning Representations (ICLR), November 2016.
· Lukasik, M., Bhojanapalli, S., Menon, A. K., 与 Kumar, S. 标签平滑能减轻标签噪声吗?（Does label smoothing mitigate label noise?）, 2020.
· Maurer, A. 与 Pontil, M. 经验Bernstein界与样本方差惩罚（Empirical bernstein bounds and sample-variance penalization）. COLT 2009 - The 22nd Conference on Learning Theory, Montreal, Quebec, Canada, June 18–21, 2009, 2009.
· McAuley, J. 与 Leskovec, J. 隐因子与隐主题：借助评论文本理解评分维度（Hidden factors and hidden topics: Understanding rating dimensions with review text）. Proceedings of the 7th ACM Conference on Recommender Systems, RecSys ’13, pp. 165–172, New York, NY, USA, 2013. Association for Computing Machinery. ISBN 9781450324090.
· Mirzadeh, S.-I., Farajtabar, M., Li, A., 与 Ghasemzadeh, H. 通过助教改进知识蒸馏：弥合学生与教师之间的差距（Improved knowledge distillation via teacher assistant: Bridging the gap between student and teacher）. AAAI, 2020.
· Mobahi, H., Farajtabar, M., 与 Bartlett, P. L. 自蒸馏放大希尔伯特空间中的正则化（Self-distillation amplifies regularization in hilbert space）. 载 Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., 与 Lin, H.（编）, Advances in Neural Information Processing Systems 33, 2020.
· Müller, R., Kornblith, S., 与 Hinton, G. E. 标签平滑何时有帮助? （When does label smoothing help?）. Advances in Neural Information Processing Systems 32, pp. 4696–4705, 2019.
· Natarajan, N., Dhillon, I. S., Ravikumar, P. D., 与 Tewari, A. 用噪声标签学习（Learning with noisy labels）. Advances in Neural Information Processing Systems (NIPS), pp. 1196–1204, 2013.
· Nayak, G. K., Mopuri, K. R., Shaj, V., Babu, R. V., 与 Chakraborty, A. 深度网络中的零样本知识蒸馏（Zero-shot knowledge distillation in deep networks）. CoRR, abs/1905.08114, 2019.
· Neal, B., Mittal, S., Baratin, A., Tantia, V., Scicluna, M., Lacoste-Julien, S., 与 Mitliagkas, I. 神经网络偏差—方差权衡的现代观点（A modern take on the bias-variance tradeoff in neural networks）. CoRR, abs/1810.08591, 2018. URL http://arxiv.org/abs/1810.08591.
· Papernot, N., McDaniel, P. D., Wu, X., Jha, S., 与 Swami, A. 将蒸馏作为防御深度神经网络对抗扰动的方法（Distillation as a defense to adversarial perturbations against deep neural networks）. IEEE Symposium on Security and Privacy, SP 2016, San Jose, CA, USA, May 22–26, 2016, pp. 582–597, 2016.
· Phuong, M. 与 Lampert, C. 迈向理解知识蒸馏（Towards understanding knowledge distillation）. Proceedings of the 36th International Conference on Machine Learning, pp. 5142–5151, 2019.

- Radosavovic, I., Dollár, P., Girshick, R. B., Gkioxari, G., 与 He, K. 数据蒸馏：迈向全监督学习（Data distillation: Towards omni-supervised learning）. 2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, June 18–22, 2018, pp. 4119–4128, 2018.
- Rahbar, A., Panahi, A., Bhattacharyya, C., Dubhashi, D., 与 Chehreghani, M. H. 论知识蒸馏出乎寻常的有效性：核机制下的分析（On the unreasonable effectiveness of knowledge distillation: Analysis in the kernel regime）, 2020.
- Reddi, S. J., Kale, S., Yu, F., Holtmann-Rice, D., Chen, J., 与 Kumar, S. 大输出空间学习中的随机负例挖掘（Stochastic negative mining for learning with large output spaces）. Proceedings of Machine Learning Research, volume 89, pp. 1940–1949. PMLR, 16–18 Apr 2019.
- Romero, A., Ballas, N., Kahou, S. E., Chassang, A., Gatta, C., 与 Bengio, Y. Fitnets：给纤细深度网络的提示（Fitnets: Hints for thin deep nets）. 载 Bengio, Y. 与 LeCun, Y.（编）, 3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7–9, 2015, Conference Track Proceedings, 2015.
- Rothfuss, J., Ferreira, F., Boehm, S., Walther, S., Ulrich, M., Asfour, T., 与 Krause, A. 条件密度估计的噪声正则化（Noise regularization for conditional density estimation）, 2019.
- Rudin, C. P-Norm Push：一种聚焦列表顶端的简单凸排序算法（The P-Norm Push: A simple convex ranking algorithm that concentrates at the top of the list）. Journal of Machine Learning Research, 10:2233–2271, Oct 2009.
- Rusu, A. A., Colmenarejo, S. G., Gülçehre, Ç., Desjardins, G., Kirkpatrick, J., Pascanu, R., Mnih, V., Kavukcuoglu, K., 与 Hadsell, R. 策略蒸馏（Policy distillation）. 4th International Conference on Learning Representations, ICLR 2016, 2016.
- Scott, C., Blanchard, G., 与 Handy, G. 非对称标签噪声下的分类：一致性与最大去噪（Classification with asymmetric label noise: consistency and maximal denoising）. Conference on Learning Theory (COLT), pp. 489–511, 2013.
- Senge, R., Bösner, S., Dembczyński, K., Haasenritter, J., Hirsch, O., Donner-Banzhoff, N., 与 Hüllermeier, E. 可靠分类：学习区分偶然不确定性与认知不确定性的分类器（Reliable classification: Learning classifiers that distinguish aleatoric and epistemic uncertainty）. Information Sciences, 255:16–29, 2014. ISSN 0020-0255.
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., 与 Wojna, Z. 重新思考用于计算机视觉的Inception架构（Rethinking the inception architecture for computer vision）. 2016 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2016, Las Vegas, NV, USA, June 27–30, 2016, pp. 2818–2826, 2016.
- Tang, J., Shivanna, R., Zhao, Z., Lin, D., Singh, A., Chi, E. H., 与 Jain, S. 理解并改进知识蒸馏（Understanding and improving knowledge distillation）. CoRR, abs/2002.03532, 2020.
- Xu, Y., Xu, Y., Qian, Q., Li, H., 与 Jin, R. 迈向理解标签平滑（Towards understanding label smoothing）. CoRR, abs/2006.11653, 2020.

· Yalniz, I. Z., Jégou, H., Chen, K., Paluri, M., 与 Mahajan, D. 用于图像分类的十亿规模半监督学习（Billion-scale semi-supervised learning for image classification）. CoRR, abs/1905.00546, 2019. URL http://arxiv.org/abs/1905.00546.
· Yang, Z., Yu, Y., You, C., Steinhardt, J., 与 Ma, Y. 重新思考神经网络泛化中的偏差—方差权衡（Rethinking bias-variance trade-off for generalization of neural networks）. 载 III, H. D. 与 Singh, A.（编）, Proceedings of the 37th International Conference on Machine Learning, volume 119 of Proceedings of Machine Learning Research, pp. 10767–10777. PMLR, 13–18 Jul 2020.
· Yim, J., Joo, D., Bae, J., 与 Kim, J. 来自知识蒸馏的礼物：快速优化、网络最小化与迁移学习（A gift from knowledge distillation: Fast optimization, network minimization and transfer learning）. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 7130–7138, July 2017.
· Yuan, L., Tay, F. E. H., Li, G., Wang, T., 与 Feng, J. 通过标签平滑正则化重新审视知识蒸馏（Revisiting knowledge distillation via label smoothing regularization）. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 3902–3910. IEEE, 2020.
· Zagoruyko, S. 与 Komodakis, N. 更关注注意力：通过注意力迁移提高卷积神经网络性能（Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer）. 5th International Conference on Learning Representations, ICLR 2017. OpenReview.net, 2017.
· Zhang, Z. 与 Sabuncu, M. R. 作为实例特定标签平滑的自蒸馏（Self-distillation as instance-specific label smoothing）. 载 Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., 与 Lin, H.（编）, Advances in Neural Information Processing Systems, 2020.
· Zhou, H., Song, L., Chen, J., Zhou, Y., Wang, G., Yuan, J., 与 Zhang, Q. 重新思考知识蒸馏的软标签：偏差—方差权衡视角（Rethinking soft labels for knowledge distillation: A bias–variance tradeoff perspective）. International Conference on Learning Representations, 2021.

官方补充材料：《蒸馏的统计学视角》

A 理论：讨论与附加结果

A.1 与已有界的比较

命题3的界与先前工作不能直接比较。例如，Phuong 与 Lampert（2019）界定的是学生与教师不一致的概率，而不是泛化误差。Foster 等（2019）假设学生受约束而接近教师，而不是使用软标签训练。与后者不同，我们假设教师在独立于学生的样本上训练；教师与学生复用样本这一更困难的情形，是有趣的未来研究课题。

A.2 式(8)中论断的证明

由 Jensen 不等式与方差定义可知，

$$\begin{aligned}\left(\mathbb{E}_x\left[\left\|\mathbf{p}^t(x)-\mathbf{p}^*(x)\right\|_2\right]\right)^2 &\le \mathbb{E}_x\left[\left\|\mathbf{p}^t(x)-\mathbf{p}^*(x)\right\|_2^2\right]\\ &= \left\|\mathbb{E}\left[\mathbf{p}^t(x)\right]-\mathbf{p}^*(x)\right\|_2^2+\mathbb{V}\left[\mathbf{p}^t(x)\right].\end{aligned}$$

因此进一步得到

$$R(\mathbf{f}) \le \frac{1}{N}\mathbb{V}\left[\mathbf{p}^t(x)^{\mathsf{T}}\ell(\mathbf{f}(x))\right]+c^2\left(\left\|\mathbb{E}\left[\mathbf{p}^t(x)\right]-\mathbf{p}^*(x)\right\|_2^2+\mathbb{V}\left[\mathbf{p}^t(x)\right]\right). \tag{15}$$

译者注（原文记号问题）. 式(15)左端原印为 $R(\mathbf{f})$，并非正文式(8)的 $\mathbb{E}\left[\left(\widetilde{R}(\mathbf{f};S)-R(\mathbf{f})\right)^2\right]$。本译文保留原印式。该段同时混用了对 x 的期望与教师训练随机性上的偏差—方差分解；若严格解释通常需要给定 x 并明确教师随机性，再对 x 积分，原文未展开这些限定。

A.3 附加结果

现在说明如何将命题3转为学生性能的泛化界，对应贝叶斯教师情形中的命题2。

命题4. 取任意有界损失 ℓ。固定预测器 $\mathbf{f}:\mathcal{X}\to\mathbb{R}^L$ 的假设类 $\mathcal{F}$，其诱导函数类 $\mathcal{H}\subset[0,1]^{\mathcal{X}}$ 包含 $h(x)\doteq\mathbf{p}^t(x)^{\mathsf{T}}\ell(\mathbf{f}(x))$。设 $\mathcal{H}$ 的一致覆盖数为 $\mathcal{N}_\infty$。对任意 $\delta\in(0,1)$，关于 $S\sim\mathbb{P}^N$，以至少 $1-\delta$ 的概率有

$$R(\mathbf{f}) \le \widetilde{R}(\mathbf{f};S)+O\left(\sqrt{\widetilde{\mathbb{V}}_N(\mathbf{f})\frac{\log\left(M_N/\delta\right)}{N}}+\frac{\log\left(M_N/\delta\right)}{N}\right)+O\left(\mathbb{E}\left\|\mathbf{p}^t(x)-\mathbf{p}^*(x)\right\|_2\right),$$

其中 $M_N\doteq\mathcal{N}_\infty(1/N,\mathcal{H},2N)$，$\widetilde{\mathbb{V}}_N(\mathbf{f})$ 为损失值的经验方差。

命题4的证明. 令 $\widetilde{R}(\mathbf{f})=\mathbb{E}\left[\widetilde{R}(\mathbf{f};S)\right]$，$\Delta\doteq\widetilde{R}(\mathbf{f};S)-R(\mathbf{f})$。依照命题2的证明，以概率 $1-\delta$ 有

$$\widetilde{R}(\mathbf{f}) \le \widetilde{R}(\mathbf{f};S)+O\left(\sqrt{\widetilde{\mathbb{V}}_N(\mathbf{f})\frac{\log\left(M_N/\delta\right)}{N}}+\frac{\log\left(M_N/\delta\right)}{N}\right), \tag{16}$$

其中 $M_N\doteq\mathcal{N}_\infty(1/N,\mathcal{H},2N)$，$\widetilde{\mathbb{V}}_N(\mathbf{f})$ 为损失值的经验方差。另外，

$$\begin{aligned}\left|\widetilde{R}(\mathbf{f})-R(\mathbf{f})\right| &= \left|\mathbb{E}\left[\widetilde{R}(\mathbf{f};S)\right]-\mathbb{E}\left[\widehat{R}_*(\mathbf{f};S)\right]\right|\\ &\le \mathbb{E}\left[\left\|\mathbf{p}^t(x)-\mathbf{p}^*(x)\right\|_2\left\|\ell(\mathbf{f}(x))\right\|_2\right].\end{aligned}$$

所以，对某个常数 $C>0$，有

$$R(\mathbf{f}) \le \widetilde{R}(\mathbf{f})+C\,\mathbb{E}\left[\left\|\mathbf{p}^t(x)-\mathbf{p}^*(x)\right\|_2\right]. \tag{17}$$

结合(16)与(17)即得结论。

B 统计框架的更多应用

上述统计框架为理解和使用蒸馏提供简单而通用的方式：对于复杂使用贝叶斯类别概率的总体目标，可以导出基于教师模型输出的经验版本。本节介绍若干其他潜在应用。

B.1 对标签噪声的鲁棒性

统计学视角提供了理解标签噪声下蒸馏可行性的方式。给定来自受类条件标签噪声影响的分布 $\overline{\mathbb{P}}$ 的样本（Scott 等，2013；Natarajan 等，2013），即对于噪声转移矩阵 $\mathbf{T}$，有 $\overline{\mathbb{P}}(y \mid x) = \mathbf{T}_{y,:}\mathbb{P}(\cdot \mid x)$。一类常见的损失校正技术用损失 $\mathbf{T}^{-1}\ell$ 学习。这可以解释为经由 $\mathbb{P}(\cdot \mid x) = \mathbf{T}^{-1}\overline{\mathbb{P}}(y \mid x)$ 构造 $\mathbb{P}(y \mid x)$ 的代入估计。

给定在噪声数据上训练的教师——因而估计带噪的 $\overline{\mathbb{P}}(y \mid x)$ ——我们便可以计算 $\mathbf{T}^{-1}\overline{\mathbb{P}}(y \mid x)$ 的更紧估计，并用它加权损失。Lukasik 等（2020）最近确实探索了这样的过程，但动机纯粹来自实证。统计框架提供了论证该过程的依据。

译者注. 原文在矩阵乘法 $\mathbf{T}^{-1}\overline{\mathbb{P}}(y \mid x)$ 中以单个 y 记号表示所需概率向量；这里保留其记号，维度上应结合前文的全类别概率向量理解。

B.2 使用推升损失的排序

受第5.1节二分排序问题启发，考虑 $\mathcal{X} \times [L]$ 上的多类分类。可采用二分排序损失的上下文化版本：

$$R(\mathbf{f}) = \mathbb{E}_x \mathbb{E}_{y \sim P_+(x)} \mathbb{E}_{y' \sim P_-(x)} \mathbf{1}\{f_y(x) < f_{y'}(x)\},$$

其中 $P_+, P_- \in \Delta_L$ 分别为“正”“负”标签上的分布。正例自然选择 $P_+ = \mathbb{P}(y \mid x)$；负例可选 $P_- \propto C - \mathbb{P}(y' \mid x)$，$C = \max_{y''} \mathbb{P}(y'' \mid x)$，使 $\mathbb{P}(\cdot)$ 下概率最低的标签最可能为负。风险可改写为

$$R(\mathbf{f}) = \mathbb{E}_x \Big[\sum_{y, y'} \mathbb{P}(y \mid x) \big(C - \mathbb{P}(y' \mid x)\big) \mathbf{1}\{f_y(x) < f_{y'}(x)\} \Big].$$

如前，可用教师估计替换 $\mathbb{P}(\cdot \mid x)$。

可进一步使用推升损失（push loss；Rudin，2009）：对递增函数 $g : \mathbb{R} \to \mathbb{R}$，定义

$$R_{\text{push}}(\mathbf{f}) = \mathbb{E}_x \mathbb{E}_{y \sim P_+(x)} g\Big(\mathbb{E}_{y' \sim P_-(x)} \mathbf{1}\{f_y(x) < f_{y'}(x)\} \Big),$$

从而更强地惩罚假负例。例如，当 $g(z) = z^p$、$p \to +\infty$，得到 Rudin（2009）的 p 范数推升损失的上下文对应形式：

$$R_{\text{push}}(\mathbf{f}) = \mathbb{E}_x \mathbb{E}_{y \sim P_+(x)} \max_{y' \in \operatorname{supp}(P_-(x))} \mathbf{1}\{f_y(x) < f_{y'}(x)\},$$

其中内层量可理解为得分最高的负样本的排名。如前，可写为

$$R_{\text{push}}(\mathbf{f}) = \mathbb{E}_x \Big[\sum_{y} \mathbb{P}(y \mid x) g\Big(\sum_{y'} \big(C - \mathbb{P}(y' \mid x)\big) \mathbf{1}\{f_y(x) < f_{y'}(x)\} \Big) \Big].$$

例如 $g(z) = \log(1 + z)$ 时，用指数替代函数替换指示函数，得到

$$\overline{R}_{\text{push}}(\mathbf{f}) = \mathbb{E}_x \Big[\sum_{y} \mathbb{P}(y \mid x) \log\Big(1 + \sum_{y'} \big(C - \mathbb{P}(y' \mid x)\big) e^{f_{y'}(x) - f_y(x)} \Big) \Big],$$

与负例感知蒸馏目标(14)相似。

译者注（保留原文公式）. 从 $P_- \propto C - \mathbb{P}(y' \mid x)$ 改写为求和时，原式省略了归一化因子，且使用等号；C 依赖 x 时，该因子不一定是全局常数。此外，仅令 $g(z) = z^p$ 后取 $p \to \infty$，一般不能直接得到所印的最大值式；原文没有给出范数根或其他极限限定。此处完整保留原文推导，不暗中修正。

B.3 对协变量偏移的鲁棒性

协变量偏移指测试分布的实例边缘分布不同于训练时观察到的边缘分布。防范该问题的一种方式是采用分布鲁棒优化目标，例如

$$R_{\mathrm{dro}}(\mathbf{f}) = \sup_{\mu' \in B(\mu, \epsilon)} \mathbb{E}_{x \sim \mu'} \mathbb{E}_{y|x} \ell\big(y,\, \mathbf{f}(x)\big),$$

其中 μ 为观察到的训练实例分布，$B(\cdot,\, \epsilon)$ 为大小 ϵ 的适当球。Duchi 等（2020）指出，当 B 为 CVaR 球时，

$$R_{\mathrm{dro}}(\mathbf{f}) = \inf_{\lambda} \left[\frac{1}{\epsilon} \mathbb{E}_{x \sim \mu} \Big(\mathbb{E}_{y|x} \ell\big(y,\, \mathbf{f}(x)\big) - \lambda \Big)_+ + \lambda \right].$$

直观上，只保留期望损失超过阈值 λ^* 的样本，而阈值依赖于分布。

通常给定样本 $S = \{(x_n,\, y_n)\}_{n=1}^N \sim \mathbb{P}^N$，无法可靠估计 $\mathbb{E}_{y|x}\big[\ell\big(y,\, \mathbf{f}(x)\big)\big]$，因为对给定 x 往往只有一次观测。这促使 Duchi 等（2020）构造了 $R_{\mathrm{dro}}(\mathbf{f})$ 的另一种界。但在蒸馏环境中，可以用教师模型的得分估计条件期望损失。这给出显著更简单的近似最小化 R_{dro} 的方法，不过代价是偏差增加。

C 附加实验

本节补充正文实验，展示以下内容：

1. 可视化用来说明决策树偏差—方差权衡的棋盘数据（C.1）。
2. 可视化失真函数 Ψ_α，展示教师准确率可能与学生泛化完全不一致（C.2）。
3. 底层问题的噪声越强，贝叶斯教师蒸馏越有用（C.3）。
4. 显式扭曲贝叶斯类别概率函数，可以展示偏差—方差权衡（C.4）。
5. 不同深度的 ResNet 可以展示偏差—方差权衡（C.5）。
6. 蒸馏二分排序目标可优于标准独热训练（C.6）。
7. 在合成高斯数据及 AMAZONCAT-13K 数据上，对教师概率做温度缩放可以改善其校准与学生性能。

C.1 棋盘数据

图6显示第4节使用的棋盘数据。样本的边缘分布在 $[0,\, 1]^2$ 上均匀。类别概率函数选为

$$\mathbb{P}(y = +1 \mid x) = \sum_{i=0}^{(B+1)/2} \sum_{j=0}^{(B+1)/2} \sigma\big(40 s_{2i,2j}(x)\big) + \sum_{i=1}^{(B-1)/2} \sum_{j=1}^{(B-1)/2} \sigma\big(40 s_{2i,2j}(x)\big)\sigma\big(40 s_{2i+1,2j+1}(x)\big),$$

$$s_{i,j}(x) = \frac{1}{2B} - \|x - \mu_{i,j}\|_\infty,$$

其中有 B^2 个等间距正方形，质心为 $\mu_{i,j}$， $B = 3$。

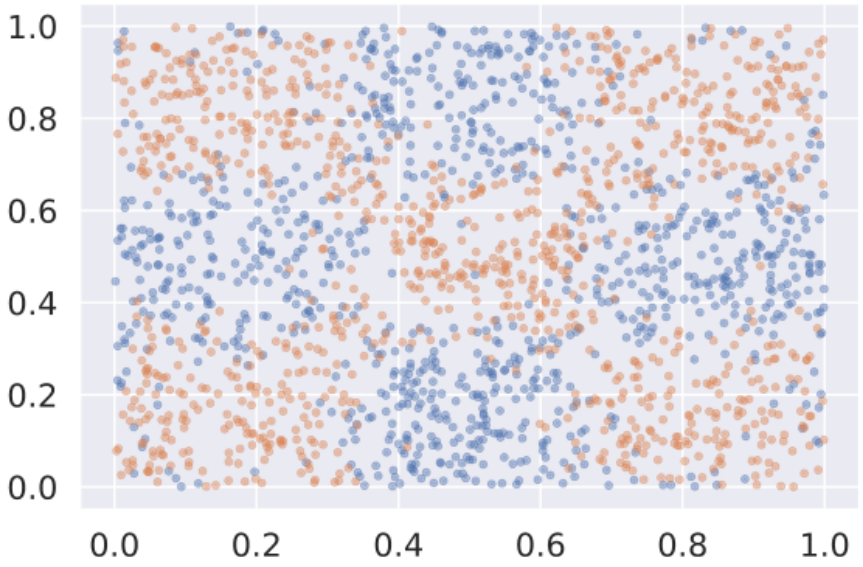


图6. 用于决策树实验的棋盘数据。

C.2 教师概率失真函数

图7绘制对教师概率应用失真函数 Ψ_α 的结果。当 $\alpha = 1$ 时，得到标准 sigmoid 函数。当 $\alpha \gg 1$，概率高度集中在0.5附近，几乎不提供信息，使学生学习问题噪声显著增加、更加困难。当 $\alpha \ll 1$，概率过度集中于两端，近似于直接使用原始标签训练。

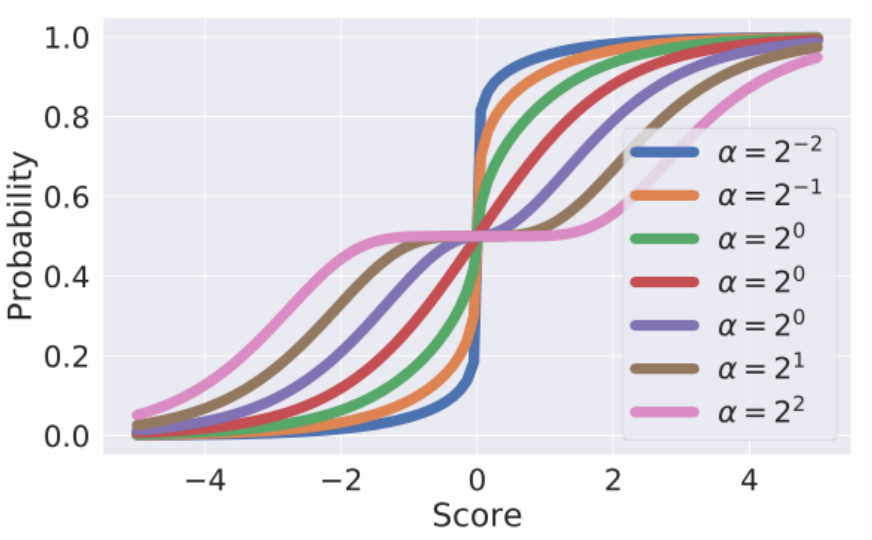


图7. 调参参数 α 增大时，教师概率 $\bar{p}(x) = \Psi_\alpha(\mathbf{p}^*(x))$ 越来越偏离贝叶斯概率 $\mathbf{p}^*(x)$。纵轴：概率；横轴：得分。保留原图图例，包括原图重复显示的 $\alpha = 2^0$ 条目。

C.3 贝叶斯蒸馏对不可分问题很有价值

图8继续探索第3.1节的高斯环境，取样本数 $N = 100$。现在改变高斯均值之间的距离 r。r 较小时，两分布更接近，分类更困难。同时，相比贝叶斯类别概率，较小的 r 使独热标签具有更高方差。因此，在此环境下蒸馏相对独热编码的收益更大，与低方差贝叶斯蒸馏风险有助泛化的保证一致（命题2）。

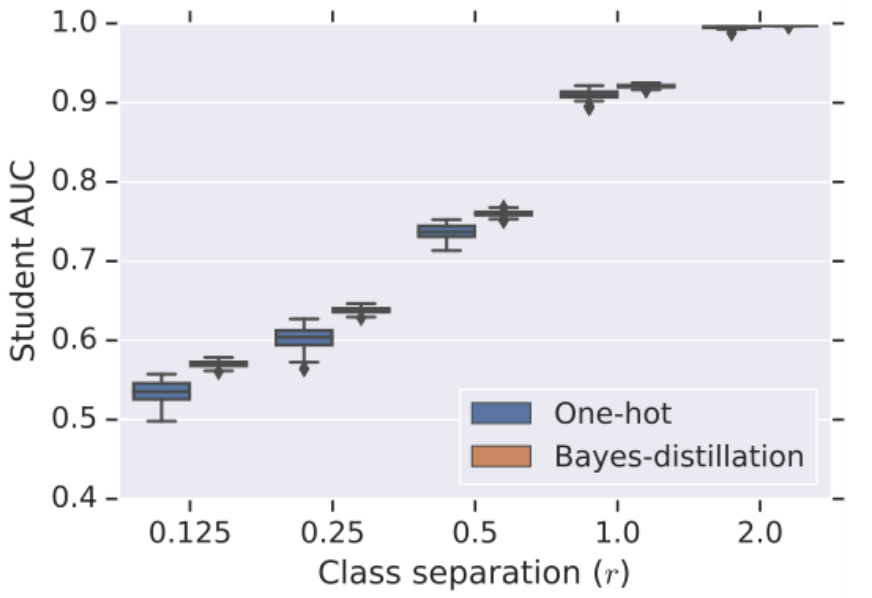


图8. 在由高斯类条件分布组成的合成数据集上，比较蒸馏与独热编码，均值为 $r(+1, +1)$ 和 $r(-1, 1)$。改变 r 以改变类别间的分离程度。随着 r 变小，两方法性能均下降，但此时蒸馏相对独热编码的收益更大。横轴：类别分离度 r；纵轴：学生AUC；图例：独热、贝叶斯蒸馏。

译者注. 图8图注第二个均值在原文确为 $r(-1,\,1)$，本译文保留；未擅自改为两个分量均为负的形式。正文交叉引用第3.1节亦依原文保留，具体合成实验介绍在第3.2节。

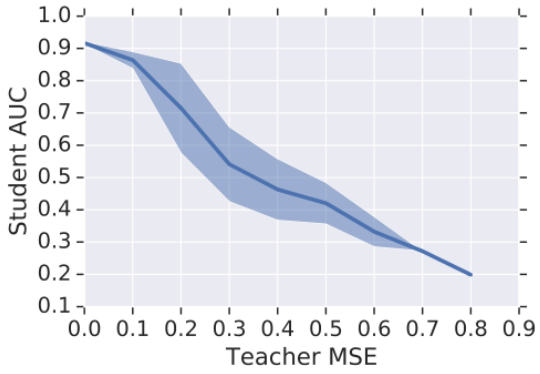
C.4 偏差—方差权衡：另一种失真

下面以另一种方式扭曲贝叶斯概率，验证偏差—方差权衡。继续使用第3.2节的合成高斯数据，考虑教师族

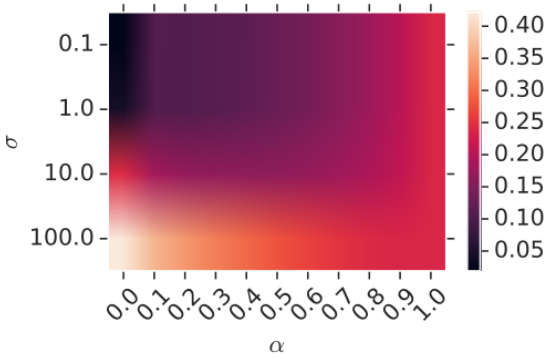
$$\mathbf{p}^t(x) = (1-\alpha)\Psi\left(\left(\theta^*\right)^\top x + \sigma^2\epsilon\right) + \frac{\alpha}{2}, \qquad (18)$$

其中 $\Psi(z) \doteq (1+e^{-z})^{-1}$ 为 sigmoid，$\alpha \in [0,\,1]$、$\sigma > 0$，$\epsilon \sim \mathcal{N}(0,\,1)$ 是独立高斯噪声。增大 α 在教师对 $\mathbf{p}^*(x)$ 的估计中引入偏差；增大 σ 则在重新抽样时引入教师方差。两者共同控制教师均方误差 $\mathbb{E}\left[\|\mathbf{p}^*(x) - \mathbf{p}^t(x)\|_2^2\right]$；命题3表明它界定总体风险与蒸馏经验风险的差距。

对每个教师，计算其 MSE 及相应蒸馏学生的测试集 AUC。图9(a)展示教师 MSE 与学生 AUC 的关系：与理论一致，对 $\mathbf{p}^*$ 更准确的估计产生更好的学生。图9(b)展示教师 MSE 如何依赖 σ 与 α，表明多个参数对能达到相似 MSE。如前，教师可以用偏差换方差来获得较低 MSE。



(a) Relationship between teacher's MSE against true class-probability and student's test set AUC. In keeping with the theory, teachers which better approximate $\mathbf{p}^*$ yield better students.

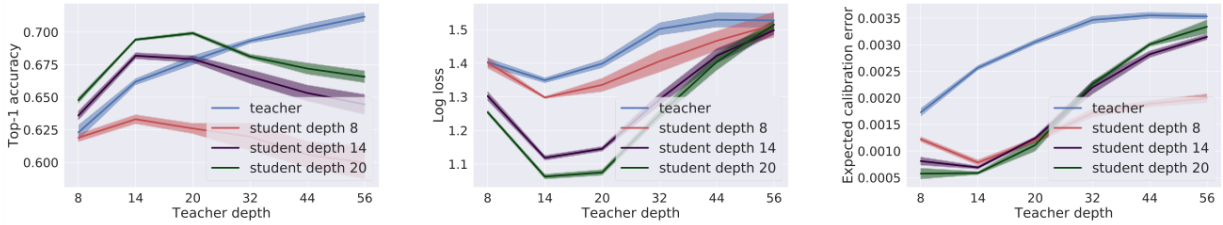


(b) Relationship between teacher's bias and variance, and corresponding MSE against true class-probability. The teacher can achieve a given MSE through multiple possible bias-variance combinations.

图9. 高斯数据上的偏差—方差权衡。(a) 教师相对真实类别概率的 MSE 与学生测试集 AUC 的关系。与理论一致，更好近似 $\mathbf{p}^*$ 的教师产生更好的学生。(b) 教师偏差、方差与相对真实类别概率的 MSE 的关系。多个偏差—方差组合可以达到相同 MSE。

C.5 偏差换方差：ResNet

回顾图1：在 CIFAR-100 上训练不同深度的 ResNet 教师，蒸馏到固定深度8的学生。概率更好（MSE 意义下）的教师通常产生更好的学生。教师深度增加、准确率持续提高，却不对应 MSE 改善。先前工作发现学生与教师大小不匹配也会影响蒸馏（Cho 与 Hariharan，2019；Mirzadeh 等，2020）。为减轻这些混杂因素，图10将图1扩展至深度14、20的学生，发现深度8的一般趋势仍成立。



(a) Top-1 accuracy. (b) Log-loss. (c) Expected calibration error.

图10. CIFAR-100 上的偏差—方差权衡：概率估计更好的教师通常产生更好的学生。结果扩展图1，纳入不同深度的学生。(a) Top-1准确率；(b) 对数损失；(c) 期望校准误差。横轴：教师深度。各曲线：教师，学生深度8、14、20。

C.6 二分排序的蒸馏

回顾二分排序问题的蒸馏目标（第5.1节）：给定 $S = \{(x_n, y_n)\}_{n=1}^{N}$， $y_n \in \{\pm 1\}$，对教师模型 p^t，构造

$$\widehat{\mathrm{PD}}(f) \propto \sum_{i \in S,\, j \in S \setminus \{i\}} p^t(x_i)\big(1 - p^t(x_j)\big)\mathbf{1}\{f(x_i) < f(x_j)\}.$$

它与标准二分排序目标形成对照，后者实际上对应“独热”教师 $p^t(x_n) = (y_n + 1)/2$。

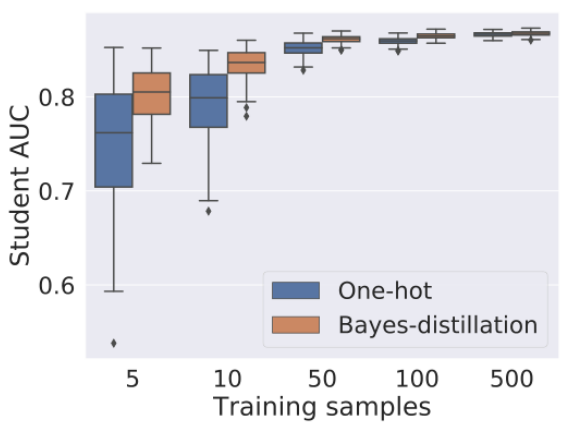
与分类情形一样，用蒸馏目标学习可以显著提升学生性能。考虑与第3.2节相同的合成高斯问题，比较“独热”与“贝叶斯教师”训练。后者使用真实 $\mathbf{p}^*(x) = \big(\mathbb{P}(y = -1 \mid x), \mathbb{P}(y = +1 \mid x)\big)$ 给出的概率。为便于基于梯度的优化，用凸替代函数 $\phi(z) = \log(1 + e^{-z})$ 替换指示函数：

$$\widehat{\mathrm{PD}}(f) \propto \sum_{i \in S,\, j \in S \setminus \{i\}} p^t(x_i)\big(1 - p^t(x_j)\big)\phi\big(f(x_i) - f(x_j)\big).$$

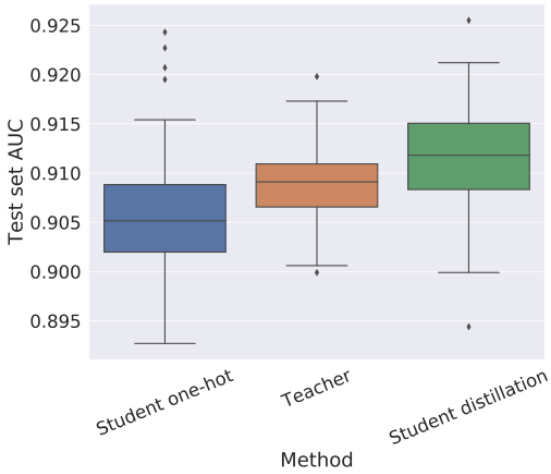
图11(a)比较学生在测试样本上的 ROC 曲线下面积（AUC）。在小样本环境中，贝叶斯教师蒸馏显著提升性能。

为进一步评估真实环境下的有效性，考虑 Fashion MNIST。该数据本为多类数据，但仅保留 T-Shirt（T恤）与 Shirt（衬衫）标签的样本，构造适用于二分排序的二值版本。训练 LeNet-5 教师，将其蒸馏到同为 LeNet-5 架构、但所有滤波器尺寸减半的学生；Lopes 等（2017）及 Nayak 等（2019）考虑过此设置。蒸馏时不直接使用教师原始预测 $\mathbf{p}^t(x)$，而采用常见技巧，用 $(1 - \alpha)\mathbf{e}_y + \alpha\mathbf{p}^t(x)$ 将其与训练标签混合；依照 Nayak 等（2019），取 $\alpha = 0.7$。这可理解为减轻目标标签的偏差。

图11(b)比较教师、独热标签训练的学生及蒸馏学生的测试集 AUC，展示100次独立试验结果。蒸馏显著优于独热训练，实际上有时还能超过教师性能。



(a) Synthetic dataset comprising Gaussian class-conditionals. Here, we employ the "Bayes teacher", which uses the true $\mathbf{p}^*$ to train the student, which is a linear model.



(b) Fashion MNIST dataset, binarised to classify T-Shirt versus Shirt. Here, we use a LeNet-5 teacher, which is distilled to a LeNet-5 student with all filter sizes reduced by half.

图11. 二分排序版本的蒸馏与独热编码比较。以学生 ROC 曲线下面积（AUC）衡量，蒸馏目标显著改善独热训练。(a) 高斯类条件分布构成的合成数据集。使用真实 $\mathbf{p}^*$ 的"贝叶斯教师"训练线性学生模型；横轴为训练样本数。(b) 二值化为区分 T-Shirt 与 Shirt 的 Fashion MNIST。使用 LeNet-5 教师，将其蒸馏到所有滤波器尺寸减半的 LeNet-5 学生。横轴方法依次为独热学生、教师、蒸馏学生；纵轴为测试集AUC。

C.7 温度缩放与教师校准

研究温度缩放对学生性能与教师概率质量的影响。图12在 AMAZONCAT-13K 上研究这一问题。从左至右提高温度，使模型向学生生成不那么自信的标签。学生性能与教师对数损失高度负相关；后者是贝叶斯标签概率与教师预测之间距离的代理指标。

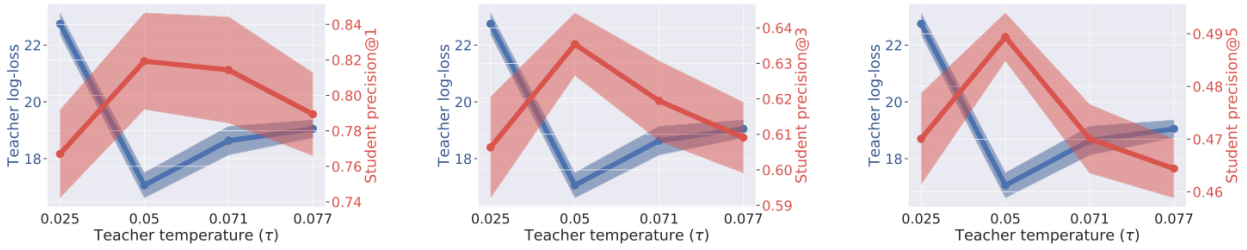


图12. 温度缩放与准确性：AMAZONCAT-13K 数据。三个面板横轴均为教师温度 τ，左纵轴为教师对数损失，右纵轴依次为学生 precision@1、precision@3、precision@5。

进一步验证发现，第3.1节合成高斯数据上也有类似趋势。取贝叶斯 $\mathbf{p}^* = \sigma\left(\left(\theta^*\right)^{\mathsf{T}} x\right)$，在 sigmoid 内应用温度缩放。显然，不缩放应获得最佳学生性能，因为这时提供的是贝叶斯概率。图13确认了这一点，并表明温度改变时，所得教师的对数损失和 MSE 所衡量的校准都会显著受损。这进一步印证教师概率质量对蒸馏性能的重要作用。

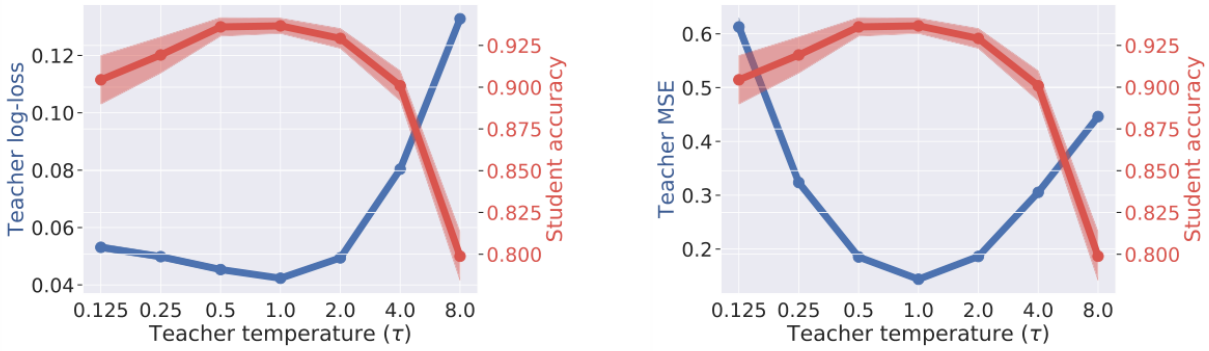


图13. 温度缩放与准确性：高斯数据。横轴为教师温度 τ；左面板比较教师对数损失与学生准确率，右面板比较教师MSE与学生准确率。