多标签性能度量的统一视角

A Unified View of Multi-Label Performance Measures

Xi-Zhu Wu、Zhi-Hua Zhou
南京大学计算机软件新技术国家重点实验室，中国南京 210023。通讯作者：Zhi-Hua Zhou，zhouzh@lamda.nju.edu.cn。

原文：第 34 届国际机器学习会议（ICML），澳大利亚悉尼，PMLR 70:3780–3788，2017。版权归原作者。官方来源：https://proceedings.mlr.press/v70/wu17a.html 。

非官方中文全文译文。 本译文依据 PMLR 的 CC BY 4.0 出版许可制作，保留作者署名、来源、公式、图表与参考文献。翻译和重新排版是对原作的修改，未经原作者审定。许可说明：https://proceedings.mlr.press/pmlr-license-agreement.html 。图中英文标识保留，中文说明随图提供。参考文献保留原文以便检索。补充材料另列于文末，不与正文混淆。

阅读说明。 下文忠实保留原文的定理、证明及结论，不代表已独立证明其正确性。原文个别公式和文字存在不一致，译者用明确标注的“译注”指出，没有悄悄修正原文论断。

摘要

多标签分类研究每个实例同时关联多个类别标签的问题。由于多标签分类的评价比单标签情形更加复杂，研究者提出了多种性能度量。人们注意到，同一种算法在不同度量上的表现往往不同。因此，理解哪些算法在哪些度量上表现良好，以及原因何在，十分重要。本文提出一个统一的间隔视角，重新考察多标签分类中的十一种性能度量。具体而言，我们定义标签维间隔和实例维间隔，并证明，通过最大化这些间隔，相应的不同性能度量将得到优化。基于所定义的间隔，我们设计了一种称为 LIMO 的最大间隔方法，实验结果验证了我们的理论发现。

1 引言

多标签分类旨在为同时具有多个标签的对象构建分类模型，这是现实应用中常见的一种学习范式。在文本分类中，一篇文档可能关联科学、娱乐、新闻等多个主题（Schapire & Singer, 2000）；在图像分类中，一幅图像可以同时具有田野和山脉标签（Boutell et al., 2004）；在音乐信息检索中，一段音乐可以同时表达古典、钢琴、激情等多种信息（Turnbull et al., 2008）。

在传统监督分类中，学习系统的泛化性能通常用准确率评价；如果不同错误分类的代价不同，则用 F 度量评价。与单标签分类相比，多标签分类的性能评价更加复杂，因为每个实例可同时关联多个标签。例如，以下两种情形中哪一种错误更严重，很难判断：一个实例有三个错误标签，或者三个实例各有一个错误标签。因此，研究者提出了一系列关注不同方面的性能度量，如汉明损失、排序损失、首位错误率、覆盖度、平均精度（Schapire & Singer, 2000），以及 micro-F1 和 macro-F1（Tsoumakas et al., 2011）。

多标签学习算法在不同度量上通常表现不同，但关于多标签性能度量的研究仍然不多。Dembczynski et al. (2010) 说明汉明损失和子集 0/1 损失不能同时得到优化。Gao & Zhou (2013) 提出研究多标签学习中替代损失的贝叶斯一致性；他们证明，没有凸替代损失与排序损失一致，并给出了确定性情形下与汉明损失一致的替代损失函数。关于 F 度量已有不少研究，大多聚焦单标签任务，并将多标签学习作为应用。例如，Ye et al. (2012) 对使用决策理论方法（DTA）和经验效用最大化方法（EUM）优化 F 度量给出了依据并建立联系。随后，Waegeman et al. (2014) 从 DTA 角度研究推断算法的 F 度量最优性。Koyejo et al. (2015) 则研究了 EUM 最优的多标签分类器。这些理论研究带来了许多认识，但仍缺少对各种多标签性能度量之间关系的统一理解。此外，一些在评价中被广泛使用的性能度量（Zhang & Wu, 2015）尚未得到理论研究。

本文尝试揭示不同度量共享的性质，为多标签性能评价建立统一理解。我们从间隔视角重新考察十一种常用多标签性能度量，包括汉明损失、排序损失、首位错误率、覆盖度、平均精度，以及采用宏平均、微平均和实例平均的 F 度量与 AUC。具体而言，我们提出标签维间隔和实例维间隔的概念，在此基础上定义多标签分类器相应的有效性，并以有效性为桥梁连接不同性能度量。我们的理论结果表明，最大化实例维间隔将优化 macro-AUC、macro-F1 和汉明损失；最大化标签维间隔则将优化除 micro-AUC 外的另外八种性能度量。受理论发现启发，我们设计 LIMO（Label-wise and Instance-wise Margins Optimization，标签维与实例维间隔优化）方法，同时最大化这两种间隔。实验验证了理论发现，也表明，通过同一方法的不同参数设置，可以灵活地优化不同度量。

本文其余部分安排如下：第 2 节介绍符号以及十一种多标签性能度量的定义。第 3 节提出标签维间隔和实例维间隔，并给出理论结果。第 4 节介绍 LIMO 方法。第 5 节报告实验结果。最后，第 6 节总结全文并指出若干未来研究问题。

2 预备知识

2.1 符号

设 $x_i \in \mathbb{R}^{d\times 1}$ 为实值实例向量，$y_i \in \{0,1\}^{l\times 1}$ 为 x_i 的标签向量，m 为训练样本数。因此，y_{ij}（$i \in \{1,\ldots,m\}$、$j \in \{1,\ldots,l\}$）表示第 i 个实例的第 j 个标签；$y_{ij}=1$ 或 0 分别表示该标签相关或不相关。实例矩阵为 $X \in \mathbb{R}^{m\times d}$，标签矩阵为 $Y \in \{0,1\}^{m\times l}$。多标签分类器 $H:\mathbb{R}^d \to \{0,1\}^l$ 包含 l 个模型，每个标签对应一个模型，因此 $H=\{h_1,\ldots,h_l\}$，$h_j(x_i)$ 表示对 y_{ij} 的预测。此外，$F:\mathbb{R}^d \to \mathbb{R}^l$ 为多标签预测器，其预测值可视为相关性的置信度。同样，F 可以分解为 $\{f_1,\ldots,f_l\}$，其中 $f_j(x_i)$ 表示 y_{ij} 的预测值。

通过阈值函数，可以从 F 导出 H。例如，$h_j(x_i)=\left[\left[f_j(x_i)>t(x_i)\right]\right]$ 使用基于实例 x_i 的阈值函数，在预测值高于阈值时输出 1。若谓词 π 成立，$[[\pi]]$ 返回 1，否则返回 0。

为简化表达，用 $Y_{i\cdot}$ 表示标签矩阵的第 i 行向量，用 $Y_{\cdot j}$ 表示第 j 列向量。进一步，$Y_{i\cdot}^{+}$（或 $Y_{i\cdot}^{-}$）表示 $Y_{i\cdot}$ 中相关（或不相关）标签的索引集合。形式化地，$Y_{i\cdot}^{+}=\{j \mid y_{ij}=1\}$，$Y_{i\cdot}^{-}=\{j \mid y_{ij}=0\}$。对标签矩阵第 j 列，$Y_{\cdot j}^{+}=\{i \mid y_{ij}=1\}$ 表示第 j 个标签的正实例索引集合，$Y_{\cdot j}^{-}=\{i \mid y_{ij}=0\}$ 同样表示负实例集合。用 $|\cdot|$ 表示集合的基数，因此 x_i 的相关标签数为 $\left|Y_{i\cdot}^{+}\right|$。

2.2 多标签性能度量

表 1 汇总了以往研究常用的十一种多标签性能度量。前五种度量，即汉明损失、排序损失、首位错误率、覆盖度和平均精度，见于 Schapire & Singer (2000) 及大量后续工作，如 Huang et al. (2012)、Zhang & Wu (2015)。后六种度量通过不同平均策略，将 F 度量和 AUC（ROC 曲线下面积）扩展到多标签分类。这些 F 度量既广泛用于算法评价（Liu & Tsang, 2015），也用于理论分析（Koyejo et al., 2015）。AUC 则见于 Lampert (2011)、Pham et al. (2015)、Zhang & Wu (2015) 等算法评价工作。

部分度量定义在分类器 H 上，关注二元分类性能；另一部分度量定义在预测器 F 上，通常衡量预测器的排序性能。我们注意到，当 F 为常值函数时，一些排序度量的定义并不完善。例如，如果 F 对所有标签都输出 1，则 one-error $(F) = 0$ 、coverage $(F) = 0$ ，各类 AUC 都等于 1，而这些分别是最优值。多标签学习领域往往隐含假设，连续实值预测能够诱导全序，这在实际情形中很常见。本文仍沿用既有工作的惯例，假设连续预测中不存在并列，从而规避这一缺陷。

表 1 十一种多标签性能度量。 以下为原表公式图，保留公式的集合下标和原文比较符号；中文释义随后逐项给出。

Measure	Formulation	Note
Hamming loss	$hloss(H) = \frac{1}{ml}\sum_{i=1}^{m}\sum_{j=1}^{l}[\![h_{ij} \neq y_{ij}]\!]$	The fraction of misclassified labels
ranking loss	$rloss(F) = \frac{1}{m}\sum_{i=1}^{m}\frac{\lvert\mathcal{S}_{\text{rank}}^{i}\rvert}{\lvert Y_{i\cdot}^{+}\rvert\lvert Y_{i\cdot}^{-}\rvert}$ $\mathcal{S}_{\text{rank}}^{i} = \{(u,v)\lvert f_u(\boldsymbol{x}_i) \leq f_v(\boldsymbol{x}_i), (u,v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-}\}$	The average fraction of reversely ordered label pairs of each instance.
one-error	$one\text{-}error(F) = \frac{1}{m}\sum_{i=1}^{m}[\![\arg\max F(\boldsymbol{x}_i) \notin Y_{i\cdot}^{+}]\!]$	The fraction of instances whose most confident label is irrelevant.
coverage	$coverage(F) = \frac{1}{m}\sum_{i=1}^{m}[\![\max_{j\in Y_{i\cdot}^{+}} rank_F(\boldsymbol{x}_i,j) - 1]\!]$	The number of more labels on average should include to cover all relevant labels
average precision	$avgprec(F) = \frac{1}{m}\sum_{i=1}^{m}\frac{1}{\lvert Y_{i\cdot}^{+}\rvert}\sum_{j\in Y_{i\cdot}^{+}}\frac{\lvert\mathcal{S}_{\text{precision}}^{ij}\rvert}{rank_F(\boldsymbol{x}_i,j)}$ $\mathcal{S}_{\text{precision}}^{ij} = \{k \in Y_{i\cdot}^{+}\lvert rank_F(\boldsymbol{x}_i,k) \leq rank_F(\boldsymbol{x}_i,j)\}$	The average fraction of relevant labels ranked higher than one other relevant label.
macro-F1	$macro\text{-}F1(H) = \frac{1}{l}\sum_{j=1}^{l}\frac{2\sum_{i=1}^{m} y_{ij}h_{ij}}{\sum_{i=1}^{m} y_{ij} + \sum_{i=1}^{m} h_{ij}}$	F-measure averaging on each label.
instance-F1	$instance\text{-}F1(H) = \frac{1}{m}\sum_{i=1}^{m}\frac{2\sum_{j=1}^{l} y_{ij}h_{ij}}{\sum_{j=1}^{l} y_{ij} + \sum_{j=1}^{l} h_{ij}}$	F-measure averaging on each instance.
micro-F1	$micro\text{-}F1(H) = \frac{2\sum_{j=1}^{l}\sum_{i=1}^{m} y_{ij}h_{ij}}{\sum_{j=1}^{l}\sum_{i=1}^{m} y_{ij} + \sum_{j=1}^{l}\sum_{i=1}^{m} h_{ij}}$	F-measure averaging on the prediction matrix.
macro-AUC	$macro\text{-}AUC(F) = \frac{1}{l}\sum_{j=1}^{l}\frac{\lvert\mathcal{S}_{\text{macro}}^{j}\rvert}{\lvert Y_{\cdot j}^{+}\rvert\lvert Y_{\cdot j}^{-}\rvert}$ $\mathcal{S}_{\text{macro}}^{j} = \{(a,b) \in Y_{\cdot j}^{+} \times Y_{\cdot j}^{-}\lvert f_j(\boldsymbol{x}_a) \geq f_j(\boldsymbol{x}_b)\}$	AUC averaging on each label. $\mathcal{S}_{\text{macro}}$ is the set of correctly ordered instance pairs on each label.
instance-AUC	$instance\text{-}AUC(F) = \frac{1}{m}\sum_{i=1}^{m}\frac{\lvert\mathcal{S}_{\text{instance}}^{i}\rvert}{\lvert Y_{i\cdot}^{+}\rvert\lvert Y_{i\cdot}^{-}\rvert}$ $\mathcal{S}_{\text{instance}}^{i} = \{(u,v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-}\lvert f_u(\boldsymbol{x}_i) \geq f_v(\boldsymbol{x}_i)\}$	AUC averaging on each instance. $\mathcal{S}_{\text{instance}}$ is the set of correctly ordered label pairs on each instance.
micro-AUC	$micro\text{-}AUC(F) = \frac{\lvert\mathcal{S}_{\text{micro}}\rvert}{(\sum_{i=1}^{m}\lvert Y_{i\cdot}^{+}\rvert)\cdot(\sum_{i=1}^{m}\lvert Y_{i\cdot}^{-}\rvert)}$ $\mathcal{S}_{\text{micro}} = \{(a,b,i,j)\lvert(a,b) \in Y_{\cdot i}^{+} \times Y_{\cdot j}^{-},\ f_i(\boldsymbol{x}_a) \geq f_j(\boldsymbol{x}_b)\}$	AUC averaging on prediction matrix. $\mathcal{S}_{\text{micro}}$ is the set of correct quadruples.

1. **汉明损失（Hamming loss）**：所有实例—标签单元中被错误分类的比例，$\text{hloss}(H) = \frac{1}{ml}\sum_{i=1}^{m}\sum_{j=1}^{l}\left[\left[h_{ij} \neq y_{ij}\right]\right]$。
2. **排序损失（ranking loss）**：每个实例中逆序的相关—不相关标签对所占比例的平均。逆序集合为 $S_{\text{rank}}^{i} = \{(u, v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-} \mid f_u(x_i) \leq f_v(x_i)\}$。
3. **首位错误率（one-error）**：置信度最高的标签实际上不相关的实例比例。
4. **覆盖度（coverage）**：为包含全部相关标签，平均需要覆盖到的最大排名减 1。
5. **平均精度（average precision）**：对每个相关标签，计算排名不低于它的标签中相关标签所占的比例，再对相关标签和实例依次平均。
6. **macro-F1**：分别在每个标签上计算 F1，然后对标签平均。
7. **instance-F1**：分别在每个实例上计算 F1，然后对实例平均。
8. **micro-F1**：将整个预测矩阵的计数合并后计算 F1。
9. **macro-AUC**：各标签 AUC 的平均；S_{macro}^{j} 为标签 j 上正确排序的正—负实例对集合。
10. **instance-AUC**：各实例 AUC 的平均；S_{instance}^{i} 为实例 i 上正确排序的相关—不相关标签对集合。

11. **micro-AUC**：在整个预测矩阵上计算 AUC； S_{micro} 为正确排序的四元组集合。它比较的是任意正标签单元与任意负标签单元，不局限于同一行或同一列。

3 理论结果

我们定义标签维间隔和实例维间隔这两个新概念。

定义 1。 给定多标签预测器 $F : \mathbb{R}^d \to \mathbb{R}^l$、 $F = \{f_1, \ldots, f_l\}$ 及训练集 (X, Y)，实例 x_i 上的标签维间隔定义为

$$\gamma_i^{\text{label}} = \min_{u,v} \{f_u(x_i) - f_v(x_i) \mid (u, v) \in Y_{i\cdot}^+ \times Y_{i\cdot}^-\}.$$

其中 $Y_{i\cdot}^+ \times Y_{i\cdot}^-$ 是实例 i 的全部（相关，不相关）标签索引对集合。

定义 2。 给定上述预测器及训练集，标签 $Y_{\cdot j}$ 上的实例维间隔定义为

$$\gamma_j^{\text{inst}} = \min_{a,b} \{f_j(x_a) - f_j(x_b) \mid (a, b) \in Y_{\cdot j}^+ \times Y_{\cdot j}^-\}.$$

其中 $Y_{\cdot j}^+ \times Y_{\cdot j}^-$ 是标签 j 的全部（正，负）实例索引对集合。

标签维间隔和实例维间隔描述了 F 的判别能力。标签维间隔越大，就越容易区分某实例的相关和不相关标签；实例维间隔越大， F 就越容易区分某一标签的正实例和负实例。因此，我们希望最大化标签维／实例维间隔，以获得更好的性能。

尽管我们希望最大化这两种间隔，但就性能度量而言，目标可以放宽。我们定义预测器可能具备的三种性质：标签维有效、实例维有效和双重有效。

定义 3。 如果 F 在数据集 $D = (X, Y)$ 上的所有标签维间隔都为正，则称预测器 F 在 D 上标签维有效。

定义 4。 如果 F 在 D 上的所有实例维间隔都为正，则称其在 D 上实例维有效。

定义 5。 如果 F 在 D 上的所有标签维间隔和实例维间隔都为正，则称其在 D 上双重有效。

粗略地说，标签维有效表示 F 能准确区分每个实例的相关和不相关标签；实例维有效表示 F 能准确区分每个标签的正实例和负实例。双重有效的 F 自然具有最强的区分能力。

下面两小节利用有效性分析不同性能度量，第 3.3 节汇总分析结果。

3.1 排序性能度量

根据下述定理，若干多标签性能度量可以在给定数据集上达到经验最优。

定理 1。 如果多标签预测器 F 在 D 上标签维有效，则该数据集上的排序损失、首位错误率、覆盖度、平均精度和 instance-AUC 均达到最优。

证明。（a）排序损失：根据标签维有效的定义，对每一对 $(u, v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-}$，都有 $f_u(x_i) > f_v(x_i)$。因此，表 1 中的逆序集合 S_{rank}^{i} 为空，基数为零，所有逆序集合的基数之和也为零，即 $\text{rloss}(F) = 0$。排序损失达到最优。

（b）首位错误率：对标签维有效的 F，由于实例 x_i 上的标签维间隔为正，有

$$\max_{u \in Y_{i\cdot}^{+}} f_u(x_i) > \max_{v \in Y_{i\cdot}^{-}} f_v(x_i).$$

因此，对任意 x_i，$\text{argmax}\, F(x_i) \in Y_{i\cdot}^{+}$。于是每个实例均有 $\left[\left[\text{argmax}\, F(x_i) \notin Y_{i\cdot}^{+}\right]\right] = 0$，从而 $\text{one-error}(F) = 0$，达到最优。

（c）覆盖度：当 F 标签维有效时，相关标签的最大排名小于不相关标签的最小排名，即

$$\max_{u \in Y_{i\cdot}^{+}} \text{rank}_F(x_i, u) < \min_{v \in Y_{i\cdot}^{-}} \text{rank}_F(x_i, v), \qquad (1)$$

$$\max_{u \in Y_{i\cdot}^{+}} \text{rank}_F(x_i, u) = \left|Y_{i\cdot}^{+}\right|.$$

因此覆盖度为

$$\text{coverage}(F) = \frac{1}{m} \sum_{i=1}^{m} \left(\left|Y_{i\cdot}^{+}\right| - 1\right),$$

这就是覆盖度的最优值。

（d）平均精度：设 j 是实例 i 的一个相关标签。由式（1）得

$$\text{rank}_F(x_i, j) = \left|\{k \in Y_{i\cdot}^{+} \mid \text{rank}_F(x_i, k) \le \text{rank}_F(x_i, j)\}\right|.$$

右侧正是 $S_{\text{precision}}^{ij}$ 的基数，因此 $\text{avgprec}(F) = 1$，即平均精度达到最优。

（e）instance-AUC：由标签维有效性，对实例 x_i 有

$$f_u(x_i) > f_v(x_i), \qquad \forall\ (u, v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-}.$$

所以实例 i 上正确排序的预测值对数为

$$\left|\{(u, v) \in Y_{i\cdot}^{+} \times Y_{i\cdot}^{-} \mid f_u(x_i) \ge f_v(x_i)\}\right| = \left|Y_{i\cdot}^{+}\right|\left|Y_{i\cdot}^{-}\right|.$$

于是 $\text{instance-AUC}(F) = 1$，达到最优。证毕。

类似于 instance-AUC 的证明，可得 macro-AUC 的结果。

定理 2。如果多标签预测器 F 在 D 上实例维有效，则 macro-AUC 达到最优。

证明。由实例维有效性，对标签向量 $Y_{\cdot j}$ 有

$$f_j(x_a) > f_j(x_b), \qquad \forall\ (a, b) \in Y_{\cdot j}^{+} \times Y_{\cdot j}^{-}.$$

因此标签 j 上正确排序的预测值对数为

$$\left|\{(a,\ b) \in Y_{\cdot j}^{+} \times Y_{\cdot j}^{-} \mid f_j(x_a) \geq f_j(x_b)\}\right| = \left|Y_{\cdot j}^{+}\right|\left|Y_{\cdot j}^{-}\right|.$$

于是 macro-AUC $(F) = 1$，达到最优。证毕。

micro-AUC 将标签矩阵作为整体看待，单有实例维有效或标签维有效的 F 不能保证将其优化。双重有效的 F 则更强。下面证明关于 micro-AUC 的结果。

定理 3（原文表述）。如果多标签预测器 F 在 D 上双重有效，则当实例数增长时，micro-AUC 将达到最优。

证明（保留原文推导）。首先证明关于随机变量 $A_i,\ B,\ C$ 的一个结果。如果 n 个随机变量 $A_1,\ A_2,\ \ldots,\ A_n$ 来自均匀分布 $U(0,\ 1)$，对任意常数 a，至少存在一个 A_i 小于 a 的事件概率为

$$\Pr\left[\exists\ A_i,\ \ A_i \leq a\right] = 1 - (1-a)^n.$$

另一随机变量 B 在 $\left(0,\ \min\{A_i\}\right)$ 上均匀分布，随机变量 $C \sim U(0,\ 1)$ 大于 B 的概率为

$$\Pr[C > B] \geq \Pr\left[(C \geq a) \wedge \left(\exists\ A_i,\ A_i \leq a\right)\right]$$

$$= \left(1 - \frac{a}{2}\right)[1 - (1-a)^n]. \qquad (2)$$

对任意小的 a，可选择足够大的 n 使式（2）接近 1。

给定标签矩阵 $Y \in \{0,\ 1\}^{m \times l}$ 及其预测矩阵 $F \in (0,\ 1)^{m \times l}$，由于预测器双重有效，预测矩阵满足

$$F_{ij} > F_{iu} \quad ? \quad Y_{ij} = 1 \wedge Y_{iu} = 0,$$

$$F_{ij} > F_{vj} \quad ? \quad Y_{ij} = 1 \wedge Y_{vj} = 0.$$

为使 F 中的值位于 $(0,\ 1)$，进一步假设：当 $Y_{ij} = 1$ 时，$F_{ij} \sim U(0,\ 1)$。

若 $Y_{ij} = 0$，那么对于 $Y_{iu} = 1$ 的 F_{iu} 及 $Y_{vj} = 1$ 的 F_{vj}，F_{ij} 都应小于它们。定义最小值

$$b = \min\left\{\min_{v}\{F_{vj} \mid Y_{vj} = 1\},\ \min_{u}\{F_{iu} \mid Y_{iu} = 1\}\right\}.$$

然后令 F_{ij} 来自 $U(0,\ b)$，并选择一个小常数 $a > b$。根据式（2），随机四元组 $(i,\ j,\ u,\ v)$ 构成正确 micro 配对的概率为

$$P_{\text{micro}} = \Pr\left[F_{ij} > F_{uv} \mid Y_{ij} = 1,\ Y_{uv} = 0\right]$$

$$\geq \left(1 - \frac{a}{2}\right)[1 - (1-a)^n], \qquad n = \frac{k}{ml}(m + l - 2).$$

在实际情形中，标签数量与实例数成正比：$k \propto m$。假设 $k = pm$，其中 p 为小于 l 的常数。原文接着写道

$$\lim_{m \to \infty} n = \lim_{m \to \infty} \frac{p}{l}(m + l - 2) = \infty,$$

$$\lim_{m\to\infty}\frac{|S_{\text{micro}}|}{\left|\left(\sum_{i=1}^{m}|Y_i^+|\right)\cdot\left(\sum_{i=1}^{m}|Y_i^-|\right)\right|}=\lim_{m\to\infty}P_{\text{micro}}=1.$$

因此，当实例数增长时，micro-AUC 将达到最优。证毕。

译注。 定理 3 的证明额外引入了预测值的均匀分布构造，因此不应把该证明直接解释成“任意双重有效的预测矩阵都具有这一渐近性质”。原文式（2）的事件概率与其后 $1-a/2$ 因子也存在需要核对之处。以上忠实保留原式，不以翻译替代数学勘误。原文在此使用 k，其语境是正标签单元的数量，而非前文以 l 表示的标签类别数。

通过上述分析，我们可以得出：标签维有效的 F 可以优化排序损失、首位错误率、覆盖度、平均精度、instance-AUC、micro-AUC，而实例维有效的 F 可以优化 macro-AUC。对于 micro-AUC，双重有效的 F 可以随着实例数增加将其优化。

译注。 上段第一句按原文保留，其中将 micro-AUC 列入标签维有效的可优化度量，与前面的讨论及表 2 不一致；表 2 将其归于双重有效。

3.2 分类性能度量

如第 2.2 节所述，一些度量评价的是分类器 H，而不是预测器 F。阈值化或二值化有许多策略（Fan & Lin, 2007；Fürnkranz et al., 2008；Read et al., 2011）。为简化讨论，我们关注两种主要策略：按实例设阈值，以及按标签设阈值。

标签维有效的 F 可以配备基于每个实例的阈值函数 $t(x_i)$，并通过 $h_j(x_i)=\left[\left[f_j(x_i)>t(x_i)\right]\right]$ 构造 H。但对实例维有效的 F 使用 $t(x_i)$ 并不合理，因为不同标签上的预测值未必可比较。总之，应为不同有效性的 F 使用合适的阈值函数：标签维有效时，对每个实例使用 $t(x_i)$；实例维有效时，对每个标签使用 t_j。对双重有效的 F，使用 $t(x_i)$ 或 t_j 都合理。

为形式化分析分类性能度量，我们定义阈值误差。

定义 6。 给定一个降序实值序列 $x_1, x_2, \ldots, x_k$，其最优切分数为 c^*，其中 $c^*\in\mathbb{N}$ 且 $1\le c^*\le k$。对实值阈值 $t\in(x_k-1,\ x_1+1)$，阈值误差为

$$\epsilon=\left|\operatorname{argmin}_i\left(x_i\right)-c^*\right|,\qquad ??\ \ x_i>t.$$

直观上，阈值误差 ϵ 统计：当正确答案为切分数 c^* 时，阈值在一个降序序列上错分了多少项。基于阈值误差，我们给出以下分类性能度量定理。

定理 4（保留原文等式）。 对标签维有效的 F，若阈值函数对每个实例 i 至多产生 ϵ_i 个错误，则 micro-F1、instance-F1 和汉明损失满足

$$\text{micro-F1}(H)=\text{instance-F1}(H)$$

$$\ge\frac{1}{m}\sum_{i=1}^{m}\min\left\{\frac{2\left(|Y_i^+|-\epsilon_i\right)}{2|Y_i^+|-\epsilon_i},\ \frac{2|Y_i^+|}{2|Y_i^+|+\epsilon_i}\right\},$$

$$\mathrm{hloss}(H) \leq \frac{1}{ml}\sum_{i=1}^{m}\epsilon_i.$$

上述定理的主要思想是：给定阈值误差和相关标签数，可以计算最差可能的列联表与完美列联表之间的差距。由于 F 度量基于列联表计算，便可推导相应下界。定理 4 的详细证明见附录 A.1。

译注。 macro、micro 和 instance 是不同聚合方式。原文这里以及附录将 micro-F1 与 instance-F1 写成恒等式，但按表 1 的一般定义，两者并不普遍相等；此处保留作者原述，使用该下界时应重新核对其适用条件。

类似于定理 4，可以证明标签维有效的 F 的结果：

定理 5。 对实例维有效的 F，若阈值函数对每个标签 j 至多产生 ϵ_j 个错误，则 macro-F1 和汉明损失满足

$$\text{macro-F1}(H) \geq \frac{1}{l}\sum_{j=1}^{l}\min\left\{\frac{2\left(|Y_{\cdot j}^{+}| - \epsilon_j\right)}{2|Y_{\cdot j}^{+}| - \epsilon_j}, \frac{2|Y_{\cdot j}^{+}|}{2|Y_{\cdot j}^{+}| + \epsilon_j}\right\},$$

$$\mathrm{hloss}(H) \leq \frac{1}{ml}\sum_{j=1}^{l}\epsilon_j.$$

定理 5 的详细证明见附录 A.2。

译注。 引出定理 5 的句子使用了“标签维有效”，而定理本身及证明针对“实例维有效”。上文保留这一原文用词差异。

由上述分析可知，标签维有效的 F 可以优化 instance-F1 和 micro-F1；实例维有效的 F 可以优化 macro-F1。两种有效性的 F 都可以优化汉明损失。双重有效的 F 同时拥有这两类性质，因此在使用适当阈值时，可以优化以上全部性能度量。

3.3 汇总

表 2 汇总了第 3.1 和 3.2 节的理论结果。每一行给出一种多标签性能度量的结果。注意，双重有效是标签维有效和实例维有效的特殊情形，所以只要某种度量可由标签维有效或实例维有效预测器优化，它也可以由双重有效预测器优化。

表 2 不同有效性的多标签预测器所优化的性能度量。 勾号表示原文证明该单元格中的预测器能优化相应度量；叉号表示不一定；实心／空心圆分别表示计算需要／不需要阈值化。

Measure	x-effective F			Threshold
	label-wise	inst-wise	double	
ranking loss	✓	✗	✓	○
avg. precision	✓	✗	✓	○
one-error	✓	✗	✓	○
coverage	✓	✗	✓	○
instance-AUC	✓	✗	✓	○
macro-AUC	✗	✓	✓	○
micro-AUC	✗	✗	✓	○
macro-F1	✗	✓	✓	●
instance-F1	✓	✗	✓	●
micro-F1	✓	✗	✓	●
Hamming loss	✓	✓	✓	●

根据分析，可以预期通过优化不同间隔，会在不同性能度量上得到怎样的结果。例如，若最大化每个标签的实例维间隔，就会在 macro-AUC 上取得良好表现，但排序损失、覆盖度及表中实例维列标叉的其他度量可能较差。如果只最大化标签维间隔而忽视实例维间隔，则可能在平均精度上表现好，却在 macro-F1 上表现差，例如 Elisseeff & Weston (2002)。同时最大化标签维和实例维间隔，以得到双重有效的 F，预计是最好的选择。

4 LIMO 方法

以上分析表明，最大化不同间隔会优化不同度量。如果可能，双重有效的 F 更可取，因为它同时享有最大化标签维间隔和实例维间隔的好处。因此，我们提出 LIMO 方法。LIMO 用同一个方法同时优化两种间隔，也可通过参数设置退化为分别优化其中一种间隔。

4.1 形式化描述

设 F 为线性预测器，即 $F(X) = W^{\top}X$，其中 $W = [w_1, w_2, ..., w_l]$。我们提出以下优化形式：

$$
\begin{aligned}
\underset{\boldsymbol{W},\xi}{\arg\min}\ & \sum_{i=1}^{l}||\boldsymbol{w}_i||^2+\lambda_1\sum_{i=1}^{m}\sum_{(u,v)}\xi_i^{uv}+\lambda_2\sum_{j=1}^{l}\sum_{(a,b)}\xi_{ab}^{j} \\
\text{s.t. } & \boldsymbol{w}_u^\top\boldsymbol{x}_i-\boldsymbol{w}_v^\top\boldsymbol{x}_i>1-\xi_i^{uv},\ \ \xi_i^{uv}\geq 0, \\
& \quad \text{for } i=1,\cdots,m \text{ and } (u,v)\in Y_{i\cdot}^{+}\times Y_{i\cdot}^{-}\ , \\
& \boldsymbol{w}_j^\top\boldsymbol{x}_a-\boldsymbol{w}_j^\top\boldsymbol{x}_b>1-\xi_{ab}^{j},\ \ \xi_{ab}^{j}\geq 0, \\
& \quad \text{for } j=1,\cdots,l \text{ and } (a,b)\in Y_{\cdot j}^{+}\times Y_{\cdot j}^{-}\ .
\end{aligned}
\tag{3}
$$

公式释义（译者补充）。式（3）的目标为：各标签权向量的平方范数之和，加上以 λ_1 加权的标签维松弛变量总和，再加上以 λ_2 加权的实例维松弛变量总和。第一组约束要求每个实例的相关—不相关标签对的间隔严格大于 $1-\xi_i^{uv}$；第二组约束要求每个标签的正—负实例对的间隔严格大于 $1-\xi_{ab}^{j}$。所有松弛变量非负。

这里 ξ_i^{uv} 和 ξ_{ab}^{j} 为松弛变量，λ_1, λ_2 为权衡参数。当两个参数都为正时，同时考虑标签维与实例维间隔。若令 $\lambda_1=0$（或 $\lambda_2=0$），则只考虑实例维（或标签维）间隔。本文将只考虑实例维（或标签维）间隔的方法称为 LIMO-inst（或 LIMO-label）；LIMO 则同时考虑两种间隔。

译注。原文前面定义 $X\in\mathbb{R}^{m\times d}$，此处却写 $F(X)=W^{\mathsf{T}}X$。按此前矩阵朝向，常用的批量预测写法应为 XW；单个列向量实例的预测则为 $W^{\mathsf{T}}x_i$。这里保留原文表达，并提示这一维度约定差异。

算法 1 LIMO。下图保留原算法的更新公式和索引；其输入、步骤、输出的中文翻译见后文。

Algorithm 1 LIMO

Input:

Data matrix $\boldsymbol{X} \in \mathbb{R}^{m \times d}$, label matrix $\boldsymbol{Y} \in \{0,1\}^{m \times l}$, step size η, trade-off parameters λ_1, λ_2, and the maximium iteration number T.

Procedure:

Initialize $\boldsymbol{W}^0$ with $N(0, 1/\sqrt{d})$ random values.
Compute the weight vector $\boldsymbol{c}^{inst}$ of each instance, $\boldsymbol{c}_i^{inst} = |Y_{i\cdot}^+||Y_{i\cdot}^-| / \sum_{i=1}^m |Y_{i\cdot}^+||Y_{i\cdot}^-|$.
Compute the weight vector $\boldsymbol{c}^{label}$ of each label, $\boldsymbol{c}_j^{label} = |Y_{\cdot j}^+||Y_{\cdot j}^-| / \sum_{j=1}^l |Y_{\cdot j}^+||Y_{\cdot j}^-|$.
for $t = 1, 2, \cdots, T$ **do**
    Random sample an instance $\boldsymbol{x}_i^t$ using weight $\boldsymbol{c}^{inst}$,
    Random sample a positive label y_{iu} and a negative label y_{iv} of instance $\boldsymbol{x}_i^t$.
    if $1 - \boldsymbol{w}_u^\top \boldsymbol{x}_i^t + \boldsymbol{w}_v^\top \boldsymbol{x}_i^t > 0$ **then**
        $\boldsymbol{w}_u^t = \boldsymbol{w}_u^{t-1} - \eta(-\lambda_1 \boldsymbol{x}_i^t + \boldsymbol{w}_u^{t-1})$.
        $\boldsymbol{w}_v^t = \boldsymbol{w}_v^{t-1} - \eta(\lambda_1 \boldsymbol{x}_i^t + \boldsymbol{w}_v^{t-1})$.
    end if
    Random sample index j of label using weight $\boldsymbol{c}^{label}$.
    Random sample a positive instance $\boldsymbol{x}_a^t$ and a negative instance $\boldsymbol{x}_b^t$ on label j.
    if $1 - \boldsymbol{w}_j^\top \boldsymbol{x}_a^t + \boldsymbol{w}_j^\top \boldsymbol{x}_b^t > 0$ **then**
        $\boldsymbol{w}_j^t = \boldsymbol{w}_j^{t-1} - \eta(\lambda_2(\boldsymbol{x}_b^t - \boldsymbol{x}_a^t) + \boldsymbol{w}_j^{t-1})$.
    end if
end for
$\boldsymbol{W} = \frac{1}{T} \sum_{t=1}^T \boldsymbol{W}^t$.

Output:

Multi-label linear model $\boldsymbol{W}$.

输入： 数据矩阵 $X \in \mathbb{R}^{m \times d}$，标签矩阵 $Y \in \{0, 1\}^{m \times l}$，步长 η，权衡参数 λ_1, λ_2，最大迭代次数 T。

过程（沿用原算法步骤编号）：

第 1 步。 使用来自 $N\left(0,\ 1/\sqrt{d}\right)$ 的随机值初始化 W^{0}。

第 2 步。 计算每个实例的权重向量 c^{inst}，其中 $c_i^{\text{inst}} = \left|Y_{i\cdot}^{+}\right|\left|Y_{i\cdot}^{-}\right| / \sum_{i=1}^{m}\left|Y_{i\cdot}^{+}\right|\left|Y_{i\cdot}^{-}\right|$。

第 3 步。 计算每个标签的权重向量 c^{label}，其中 $c_j^{\text{label}} = \left|Y_{\cdot j}^{+}\right|\left|Y_{\cdot j}^{-}\right| / \sum_{j=1}^{l}\left|Y_{\cdot j}^{+}\right|\left|Y_{\cdot j}^{-}\right|$。

第 4 步。 对 $t = 1,\ 2,\ \ldots,\ T$ 开始迭代。

第 5 步。 按 c^{inst} 加权随机抽取实例 x_i^t。

第 6 步。 随机抽取该实例的一个正标签 y_{iu} 和一个负标签 y_{iv}。

第 7 步。 若 $1 - w_u^{\mathsf{T}} x_i^t + w_v^{\mathsf{T}} x_i^t > 0$，则执行第 8、9 步。

第 8 步。 更新 $w_u^t = w_u^{t-1} - \eta\left(-\lambda_1 x_i^t + w_u^{t-1}\right)$。

第 9 步。 更新 $w_v^t = w_v^{t-1} - \eta\left(\lambda_1 x_i^t + w_v^{t-1}\right)$。

第 10 步。 结束上述条件分支。

第 11 步。 按 c^{label} 加权随机抽取标签索引 j。

第 12 步。 在标签 j 上随机抽取一个正实例 x_a^t 和一个负实例 x_b^t。

第 13 步。 若 $1 - w_j^{\mathsf{T}} x_a^t + w_j^{\mathsf{T}} x_b^t > 0$，则执行第 14 步。

第 14 步。 更新 $w_j^t = w_j^{t-1} - \eta(\lambda_2\left(x_b^t - x_a^t\right) + w_j^{t-1})$。

第 15 步。 结束上述条件分支。

第 16 步。 结束迭代循环。

第 17 步。 令 $W = \frac{1}{T}\sum_{t=1}^{T} W^{t}$。

输出： 多标签线性模型 W。

4.2 算法

由于约束和松弛变量数量庞大，式（3）难以直接求解。对包含 m 个实例、l 个标签的训练集，约束数为 $O\left(m^2 l + m l^2\right)$，在实际应用中可能超过内存限制。

为解决计算问题，我们采用固定步长的随机梯度下降（SGD）求解式（3），并采用 Shalev-Shwartz & Ben-David（2014，第 14.3 章）的默认平均技术。SGD 的关键是找到一个随机向量，使其在每次迭代中的期望等于梯度方向。我们随机抽取两类三元组，用它们计算正确方向。在每次迭代 t，抽取三元

组 $(x_i^t,\ y_{iu},\ y_{iv})$，其中 y_{iu} 相关、y_{iv} 不相关；同时抽取三元组 $(j,\ x_a^t,\ x_b^t)$，其中 x_a^t 与 x_b^t 分别是标签 j 上的正实例和负实例。随后用这两类三元组计算 SGD 的随机梯度向量。详细算法见算法 1，随机向量为梯度方向无偏估计的证明见附录 A.3。

训练结束后，使用线性模型预测训练数据上的连续置信度值，再通过优化某个具体分类度量来选择最佳阈值。

5 实验

我们在合成数据和基准数据上对 LIMO 进行了实验。注意，本文的主要目的，是从间隔优化角度研究多标签性能度量。因此，实验目标是验证理论发现，而不是宣称 LIMO 优于其他方法，尽管它确实表现出很强的竞争力。

5.1 合成数据

我们在具有 4 个标签的合成数据上进行实验。从 $(-1,\ +1)^2$ 的正方形中随机生成 2,000 个数据点，并按图 1 分配标签。保留 50% 的数据用于测试。合成数据旨在模拟典型现实情况：共现标签的数量有所变化，各标签对应的区域不同，而且线性学习器无法完美分离这些数据。

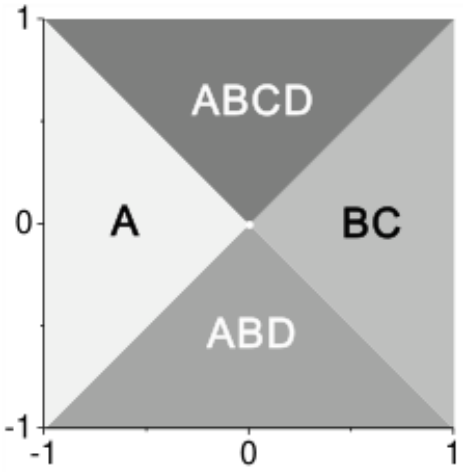


图 1。 输入空间包含四个区域，分别分配标签集合 $\{A,\ B,\ C,\ D\}$ 的不同子集。中心点坐标为 $(0,\ 0)$。

为展示间隔与性能度量之间的关系，我们将权衡参数 λ_1 或 λ_2 设为零，使 LIMO 退化为仅考虑一种间隔。LIMO-inst 令 $\lambda_1 = 0$，LIMO-label 令 $\lambda_2 = 0$，另一个参数设为 100；LIMO 则令 $\lambda_1 = \lambda_2 = 100$。实验重复十次并报告平均结果。由于覆盖度的取值范围不是 $[0,\ 1]$，且一些度量越大越好、另一些越小越好，我们将所有性能值重新缩放为相对值以便可视化：最好结果缩放为 1，最差结果缩放为 0。图 2 给出相对结果，右侧列出原始最差性能值。

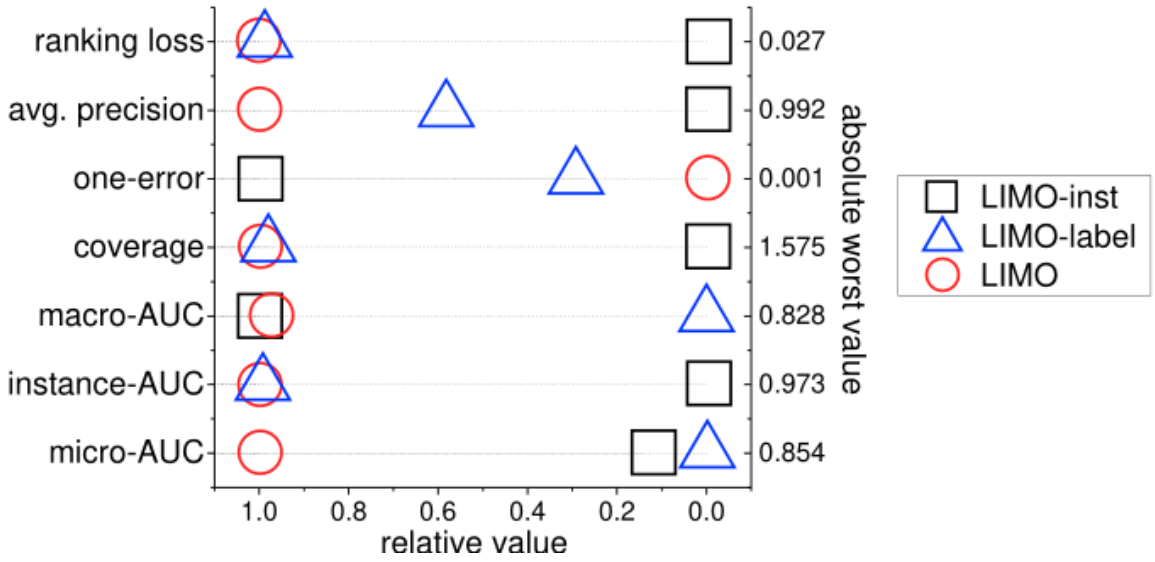


图 2。 排序度量上的相对性能汇总，越靠左性能越好。右侧的原始最差值依次为：排序损失 0.027、平均精度 0.992、首位错误率 0.001、覆盖度 1.575、macro-AUC 0.828、instance-AUC 0.973、micro-AUC 0.854。

图 2 的结果支持表 2 的理论发现。例如，micro-AUC 被认为可由双重有效的 F 优化，而其他两类有效性不保证这一点，因此 LIMO（红色圆点）取得最好的相对值。对于已证明可由标签维间隔优化的排序损失、平均精度、覆盖度和 instance-AUC，LIMO-label 优于 LIMO-inst；对于 macro-AUC，则是 LIMO-inst 更好。对于首位错误率，三个 LIMO 版本都表现极好，绝对值均小于 0.001，这可能是其相对值不符合预期的原因。

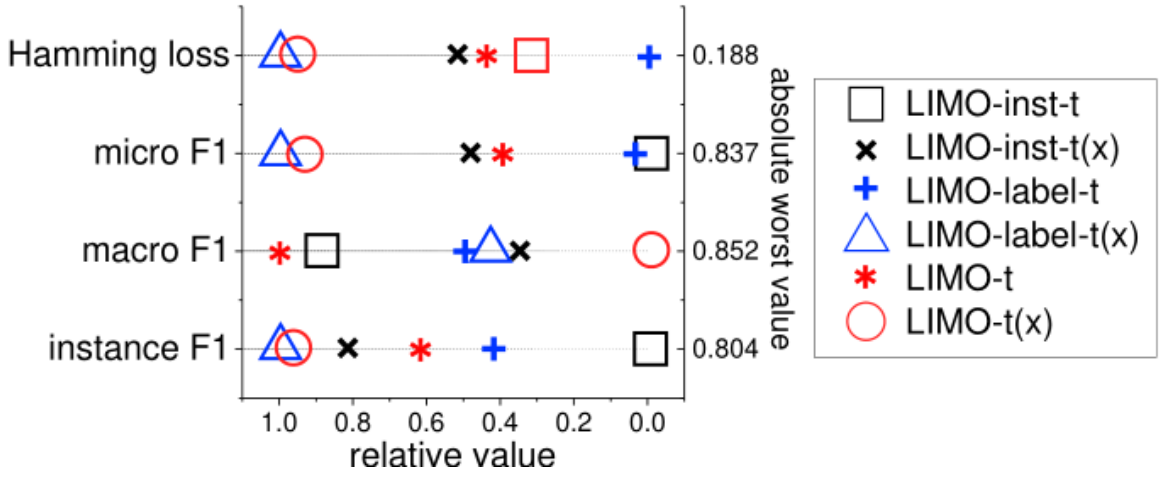


图 3。 分类度量上的相对性能汇总，越靠左越好。原始最差值依次为：汉明损失 0.188、micro-F1 0.837、macro-F1 0.852、instance-F1 0.804。图例中的 $-t$ 表示按标签设阈值，$-t(x)$ 表示按实例设阈值。

图 3 展示分类方面的相对性能。我们使用第 3.2 节讨论的两种阈值策略：为每个实例或每个标签设置阈值函数，图例分别记为 $-t(x)$ 或 $-t$。阈值从训练数据估计。图中结果准确体现了理论结论：配备 $t(x)$ 的 LIMO-label 能优化 instance-F1 和 micro-F1；配备 t 的 LIMO-inst 能优化 macro-F1。同时考虑标签维与实例维间隔的 LIMO，在四种分类度量上都表现良好。

5.2 基准数据

我们在十一种多标签性能度量上开展实验，以进一步说明：正如理论分析揭示的那样，优化标签维间隔或实例维间隔会得到不同结果。

实验采用五个多标签基准数据集。选择它们是因为它们分别来自不同领域：（i）音乐数据集 CAL500；（ii）电子邮件数据集 enron；（iii）临床文本数据集 medical；（iv）图像数据集 corel5k；（v）标签标注数据集 bibtex。每个数据集随机划分为 70% 训练集和 30% 测试集。实验重复十次，报告平均结果。数据集来源：http://mulan.sourceforge.net/datasets-mlc.html 。

由于我们的方法优化一个线性模型，为公平比较，提供了三种原文所称的线性方法：二元关联法 Binary Relevance（BR）（Zhang & Zhou, 2014）、ML-kNN（Zhang & Zhou, 2007）和 GFM（Waegeman et al., 2014）。与合成数据实验相同，将 LIMO（$\lambda_1 = \lambda_2 = 1$）退化为 LIMO-inst（$\lambda_1 = 0, \lambda_2 = 1$）和 LIMO-label（$\lambda_1 = 1, \lambda_2 = 0$）。SGD 步长设为 0.01。BR 使用 $C = 1$ 的 L2 正则化 SVM（Chang & Lin, 2011）作为基学习器。ML-kNN 和 GFM 的近邻数为 10。分类度量采用第 3.2 节讨论的适当阈值。

各对比方法分别使用其作者推荐的默认参数。一方面，我们相信作者推荐的参数设置具有合理性；另一方面，面对十一种性能度量，很难说哪种参数设置整体更好。

由于某些度量越高越好，某些越低越好，为更清楚地展示结果，我们计算每种方法在某个度量上的跨数据集平均排名。例如，考察 LIMO 的排序损失时，先计算它在各个数据集上的排名：LIMO 在 CAL500、enron、bibtex 上排第 1，在 medical、corel5k 上排第 2。因此，其排序损失平均排名为 $(1 + 1 + 1 + 2 + 2)/5 = 1.4$。图 4 展示平均排名。受篇幅所限，用于计算排名的详细结果见附录 B.2。

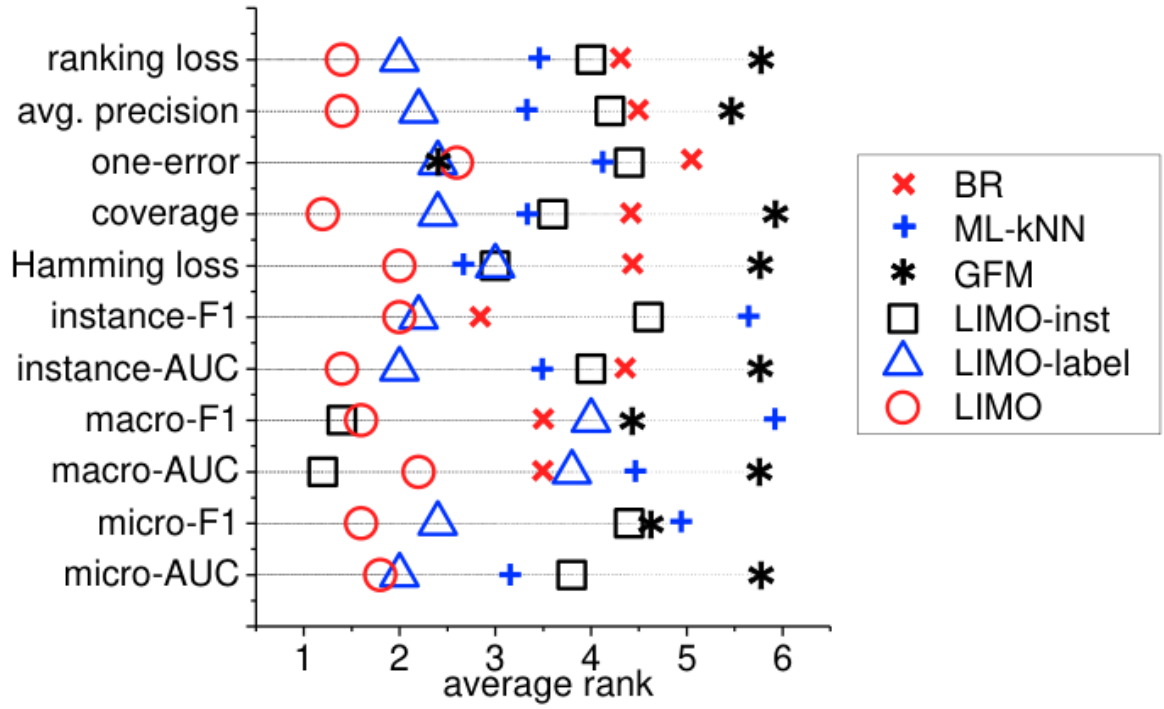


图 4。 基准数据上的平均排名，数值越小越好。

图 4 的结果与理论发现一致。LIMO-inst（方形）在 macro-F1 和 macro-AUC 上表现良好，而 LIMO-label（三角形）在其他性能度量上表现良好。LIMO（圆形）几乎在每种度量上都排名靠前。

合成数据和基准数据上的实验支持理论分析。尽管不同性能度量关注不同方面，它们也具有共同性质，本文将其形式化为标签维间隔和实例维间隔。在实践中，建议对特定间隔赋予更高权重（ λ_1/λ_2 ），以优化所需的性能度量。采用非线性预测器的 LIMO 可能表现更好，但这需要一种新的优化算法。

6 结论

本文为多种多标签性能度量建立了统一视角。基于提出的标签维／实例维间隔概念，我们证明，一些性能度量可由标签维有效分类器优化，另一些则可由实例维有效分类器优化。受理论发现启发，我们设计 LIMO 方法，通过不同参数设置，可以使其倾向标签维或实例维有效。

我们的工作揭示了不同多标签性能度量子集之间存在的共同性质。这解释了为何有些度量在实验中看起来冗余，也提示：未来经验研究不应随机挑选一组评价度量，而应采用性质不同的度量，例如同时使用可由标签维有效预测器优化的度量和可由实例维有效预测器优化的度量，这样更具信息量。未来值得研究，当两种间隔尚未达到最优时，这些性能度量的渐近性质。间隔视角也为设计新的多标签算法提供了启发。

致谢

本研究获得国家自然科学基金（61333014）、973 计划（2014CB340501）及新型软件技术与产业化协同创新中心支持。作者感谢审稿人的有益意见，并感谢 Sheng-Jun Huang、Xiu-Shen Wei 和 Miao Xu 阅读论文初稿。

参考文献

为便于按题名和出版信息检索，以下完整保留原文书目信息。

- Boutell, Matthew R., Luo, Jiebo, Shen, Xipeng, and Brown, Christopher M. Learning multi-label scene classification. Pattern Recognition, 37(9):1757–1771, 2004.
- Chang, Chih-Chung and Lin, Chih-Jen. LIBSVM: A library for support vector machines. ACM Trans. Intelligent Systems and Technology, 2(3):27:1–27:27, 2011.
- Dembczynski, Krzysztof, Waegeman, Willem, Cheng, Weiwei, and Hüllermeier, Eyke. Regret analysis for performance metrics in multi-label classification: the case of hamming and subset zero-one loss. In ECML/PKDD, pp. 280–295, 2010.
- Elisseeff, André and Weston, Jason. A kernel method for multi-labelled classification. In NIPS, pp. 681–687, 2002.
- Fan, Rong-En and Lin, Chih-Jen. A study on threshold selection for multi-label classification. National Taiwan University, Technical Report, pp. 1–23, 2007.
- Fürnkranz, Johannes, Hüllermeier, Eyke, Mencía, Eneldo Loza, and Brinker, Klaus. Multilabel classification via calibrated label ranking. Machine Learning, 73(2):133–153, 2008.

- Gao, Wei and Zhou, Zhi-Hua. On the consistency of multi-label learning. Artificial Intelligence, 199:22–44, 2013.
- Huang, Sheng-Jun, Yu, Yang, and Zhou, Zhi-Hua. Multi-label hypothesis reuse. In ACM SIGKDD, pp. 525–533, 2012.
- Koyejo, Oluwasanmi, Natarajan, Nagarajan, Ravikumar, Pradeep, and Dhillon, Inderjit S. Consistent multilabel classification. In NIPS, pp. 3321–3329, 2015.
- Lampert, Christoph H. Maximum margin multi-label structured prediction. In NIPS, pp. 289–297, 2011.
- Liu, Weiwei and Tsang, Ivor W. On the optimality of classifier chain for multi-label classification. In NIPS, pp. 712–720, 2015.
- Pham, Anh T., Raich, Raviv, Fern, Xiaoli Z., and Arriaga, Jesús Pérez. Multi-instance multi-label learning in the presence of novel class instances. In ICML, pp. 2427–2435, 2015.
- Read, Jesse, Pfahringer, Bernhard, Holmes, Geoff, and Frank, Eibe. Classifier chains for multi-label classification. Machine Learning, 85(3):333–359, 2011.
- Schapire, Robert E and Singer, Yoram. Boostexter: A boosting-based system for text categorization. Machine Learning, 39(2):135–168, 2000.
- Shalev-Shwartz, Shai and Ben-David, Shai. Understanding Machine Learning: From Theory to Algorithms. Cambridge University Press, 2014.
- Tsoumakas, Grigorios, Katakis, Ioannis, and Vlahavas, Ioannis P. Random k-labelsets for multilabel classification. IEEE Trans. Knowledge and Data Engineering, 23(7):1079–1089, 2011.
- Turnbull, Douglas, Barrington, Luke, Torres, David A., and Lanckriet, Gert R. G. Semantic annotation and retrieval of music and sound effects. IEEE Trans. Audio, Speech & Language Processing, 16(2):467–476, 2008.
- Waegeman, Willem, Dembczynski, Krzysztof, Jachnik, Arkadiusz, Cheng, Weiwei, and Hüllermeier, Eyke. On the bayes-optimality of F-measure maximizers. Journal of Machine Learning Research, 15(1):3333–3388, 2014.
- Ye, Nan, Chai, Kian Ming Adam, Lee, Wee Sun, and Chieu, Hai Leong. Optimizing F-measure: A tale of two approaches. In ICML, 2012.
- Zhang, Min-Ling and Wu, Lei. LIFT: Multi-label learning with label-specific features. IEEE Trans. Pattern Analysis and Machine Intelligence, 37(1):107–120, 2015.
- Zhang, Min-Ling and Zhou, Zhi-Hua. ML-KNN: A lazy learning approach to multi-label learning. Pattern Recognition, 40(7):2038–2048, 2007.
- Zhang, Min-Ling and Zhou, Zhi-Hua. A review on multi-label learning algorithms. IEEE Trans. Knowledge and Data Engineering, 26(8):1819–1837, 2014.

官方补充材料译文

对应 Supplementary material for A Unified View of Multi-Label Performance Measures，来源：https://proceedings.mlr.press/v70/wu17a/wu17a-supp.pdf 。附录公式编号独立于正文。

附录 A 证明

本节给出正文理论结果的详细证明。

A.1 定理 4 的证明

由于 F 标签维有效，它对特定实例 x_i 的预测值排序正确。因此，阈值误差 ϵ_i 可以以下两种方式之一出现。

1. 将 ϵ_i 个正标签预测为负标签。

此时，该实例的真阳性数 TP_i 变为 $\left|Y_{i\cdot}^{+}\right| - \epsilon_i$，假阳性数 FP_i 为零，假阴性数 FN_i 变为 ϵ_i。

精确率和召回率为

$$\mathrm{Prec}_i = \frac{TP_i}{TP_i + FP_i} = 1, \qquad \mathrm{Rec}_i = \frac{TP_i}{TP_i + FN_i} = \frac{\left|Y_{i\cdot}^{+}\right| - \epsilon_i}{\left|Y_{i\cdot}^{+}\right|}.$$

相应的 F 度量为

$$F\text{-measure}_i = \frac{2\mathrm{Prec}_i\mathrm{Rec}_i}{\mathrm{Prec}_i + \mathrm{Rec}_i} = \frac{2\left(\left|Y_{i\cdot}^{+}\right| - \epsilon_i\right)}{2\left|Y_{i\cdot}^{+}\right| - \epsilon_i}.$$

2. 将 ϵ_i 个负标签预测为正标签。

此时，真阳性数 TP_i 仍为 $\left|Y_{i\cdot}^{+}\right|$，假阳性数 $FP_i = \epsilon_i$，假阴性数 FN_i 为零。

精确率和召回率为

$$\mathrm{Prec}_i = \frac{TP_i}{TP_i + FP_i} = \frac{\left|Y_{i\cdot}^{+}\right|}{\left|Y_{i\cdot}^{+}\right| + \epsilon_i}, \qquad \mathrm{Rec}_i = \frac{TP_i}{TP_i + FN_i} = 1.$$

相应的 F 度量为

$$F\text{-measure}_i = \frac{2\mathrm{Prec}_i\mathrm{Rec}_i}{\mathrm{Prec}_i + \mathrm{Rec}_i} = \frac{2\left|Y_{i\cdot}^{+}\right|}{2\left|Y_{i\cdot}^{+}\right| + \epsilon_i}.$$

instance-F1 的下界由每个实例 F 度量的最小值求和并平均得到，因此

$$\text{instance-F1}\,(H) \geq \frac{1}{m}\sum_{i=1}^{m} \min\left\{\frac{2\left(\left|Y_{i\cdot}^{+}\right| - \epsilon_i\right)}{2\left|Y_{i\cdot}^{+}\right| - \epsilon_i}, \frac{2\left|Y_{i\cdot}^{+}\right|}{2\left|Y_{i\cdot}^{+}\right| + \epsilon_i}\right\}.$$

在所有实例独立同分布抽取的假设下，micro-F1 等于 instance-F1。定理 4 得证。

译注。 最后一句是原文论断；独立同分布本身并不保证“先按实例计算比值再平均”与“先合并计数再计算比值”相等，不能忽略正文译注所提示的聚合差异。

A.2 定理 5 的证明

由于 F 实例维有效，它对特定标签 $Y_{\cdot j}$ 的预测值排序正确。因此，阈值误差 ϵ_j 可以以下两种方式之一出现。

1. 将 ϵ_j 个正实例预测为负实例。

此时，该标签上的真阳性数 TP_j 变为 $\left|Y_{\cdot j}^{+}\right| - \epsilon_j$，假阳性数 FP_j 为零，假阴性数 FN_j 变为 ϵ_j。

精确率与召回率为

$$\mathrm{Prec}_j = \frac{TP_j}{TP_j + FP_j} = 1, \qquad \mathrm{Rec}_j = \frac{TP_j}{TP_j + FN_j} = \frac{\left|Y_{\cdot j}^{+}\right| - \epsilon_j}{\left|Y_{\cdot j}^{+}\right|}.$$

相应的 F 度量为

$$F\text{-measure}_j = \frac{2\mathrm{Prec}_j\mathrm{Rec}_j}{\mathrm{Prec}_j + \mathrm{Rec}_j} = \frac{2\left(\left|Y_{\cdot j}^{+}\right| - \epsilon_j\right)}{2\left|Y_{\cdot j}^{+}\right| - \epsilon_j}.$$

译注。 原文该行最后一项下标印作 $Y_{j\cdot}^{+}$，与本节按标签列计算的上下文不符；这里明确统一为 $Y_{\cdot j}^{+}$，未改变其数学意图。

2. 将 ϵ_j 个负实例预测为正实例。

此时，真阳性数 TP_j 仍为 $\left|Y_{\cdot j}^{+}\right|$，假阳性数 $FP_j = \epsilon_j$，假阴性数 FN_j 为零。

精确率与召回率为

$$\mathrm{Prec}_j = \frac{TP_j}{TP_j + FP_j} = \frac{\left|Y_{\cdot j}^{+}\right|}{\left|Y_{\cdot j}^{+}\right| + \epsilon_j}, \qquad \mathrm{Rec}_j = \frac{TP_j}{TP_j + FN_j} = 1.$$

相应的 F 度量为

$$F\text{-measure}_j = \frac{2\mathrm{Prec}_j\mathrm{Rec}_j}{\mathrm{Prec}_j + \mathrm{Rec}_j} = \frac{2\left|Y_{\cdot j}^{+}\right|}{2\left|Y_{\cdot j}^{+}\right| + \epsilon_j}.$$

macro-F1 的下界由每个标签 F 度量的最小值求和并平均得到，因此

$$\text{macro-F1}\,(H) \geq \frac{1}{l}\sum_{j=1}^{l} \min\left\{\frac{2\left(\left|Y_{\cdot j}^{+}\right| - \epsilon_j\right)}{2\left|Y_{\cdot j}^{+}\right| - \epsilon_j}, \frac{2\left|Y_{\cdot j}^{+}\right|}{2\left|Y_{\cdot j}^{+}\right| + \epsilon_j}\right\}.$$

定理 5 得证。

A.3 LIMO 算法的证明

定理 A.3.1。 在算法 1 的每次迭代（第 5 至 15 步）中，模型更新方向是下述目标函数梯度的无偏估计：

$$
\begin{aligned}
\arg\min_{\boldsymbol{W},\xi} & \sum_{i=1}^{l}||\boldsymbol{w}_i||^2+\lambda_1\sum_{i=1}^{m}\sum_{(u,v)}\xi_i^{uv}+\lambda_2\sum_{j=1}^{l}\sum_{(a,b)}\xi_{ab}^{j} \\
\text{s.t. } & \boldsymbol{w}_u^\top\boldsymbol{x}_i-\boldsymbol{w}_v^\top\boldsymbol{x}_i>1-\xi_i^{uv},\ \ \xi_i^{uv}\geq 0, \\
& \quad \text{for } i=1,\cdots,m \text{ and } (u,v)\in Y_{i\cdot}^{+}\times Y_{i\cdot}^{-}\ , \\
& \boldsymbol{w}_j^\top\boldsymbol{x}_a-\boldsymbol{w}_j^\top\boldsymbol{x}_b>1-\xi_{ab}^{j},\ \ \xi_{ab}^{j}\geq 0, \\
& \quad \text{for } j=1,\cdots,l \text{ and } (a,b)\in Y_{\cdot j}^{+}\times Y_{\cdot j}^{-}\ .
\end{aligned}
\tag{3}
$$

这里的目标及约束与正文式（3）相同，在补充材料中编号为式（1）。

证明。设式（1）中的函数为 $f(W)$。由于 W 可以分解为 $[w_1, w_2, ..., w_l]$，考虑某个特定 w_k 的偏梯度：

$$
\begin{aligned}
\frac{\partial f(\boldsymbol{W})}{\partial \boldsymbol{w}_k} =& 2\boldsymbol{w}_k+\lambda_1\phi_1+\lambda_2\phi_2=2\boldsymbol{w}_k \\
&+\lambda_1\sum_{i=1}^{m}\Big\{[\![k\in Y_{i\cdot}^{-}]\!]\boldsymbol{x}_i\sum_{j\in Y_{i\cdot}^{+}}[\![1-(\boldsymbol{w}_j-\boldsymbol{w}_k)^\top\boldsymbol{x}_i>0]\!] \\
&\qquad -[\![k\in Y_{i\cdot}^{+}]\!]\boldsymbol{x}_i\sum_{j\in Y_{i\cdot}^{-}}[\![1-(\boldsymbol{w}_k-\boldsymbol{w}_j)^\top\boldsymbol{x}_i>0]\!]\Big\} \\
&+\lambda_2\sum_{a\in Y_{\cdot k}^{+}}\sum_{b\in Y_{\cdot k}^{-}}(\boldsymbol{x}_b-\boldsymbol{x}_a)[\![1-\boldsymbol{w}_k^\top(\boldsymbol{x}_a-\boldsymbol{x}_b)>0]\!]
\end{aligned}
\tag{2}
$$

第二项 $\lambda_1\phi_1$ 是标签维间隔关于 w_k 的梯度，第三项 $\lambda_2\phi_2$ 是实例维间隔关于 w_k 的梯度。

假设在第 5、6 步选中了 (x_i, y_{ik}, y_{ij})，则第 8 或第 9 步按以下公式计算方向：

$$
\begin{aligned}
g^{label}(\boldsymbol{x}_i,y_{ik},y_{ij}) =& [\![k\in Y_{i\cdot}^{-}]\!]\lambda_1\boldsymbol{x}_i[\![1-(w_k-w_j)^\top\boldsymbol{x}_i>0]\!] \\
&-[\![k\in Y_{i\cdot}^{+}]\!]\lambda_1\boldsymbol{x}_i[\![1-(w_j-w_k)^\top\boldsymbol{x}_i>0]\!]+\boldsymbol{w}_k
\end{aligned}
$$

然后计算期望：

$$E_{\boldsymbol{x}_i}\left[E_{y_{ij}}[g^{label}(\boldsymbol{x}_i, y_{ik}, y_{ij})]\right] = \frac{1}{C}E_{\boldsymbol{x}_i}\Bigg[\lambda_1 \boldsymbol{x}_i \sum_{j\in Y_i^+} [\![1-(w_k-w_j)^\top \boldsymbol{x}_i > 0]\!] - \lambda_1 \boldsymbol{x}_i \sum_{j\in Y_i^-} [\![1-(w_j-w_k)^\top \boldsymbol{x}_i > 0]\!] + \frac{1}{D}\boldsymbol{w}_k\Bigg] = \frac{1}{C'}\lambda_1\phi_1 + \frac{1}{D'}\boldsymbol{w}_k$$

其中 C' 和 D' 为常数。类似地，可以证明第 11 至第 15 步中方向的期望为

$$\mathbb{E}_{x_a,x_b}\left[g^{\text{inst}}(y_k,\ x_a,\ x_b)\right] = \frac{1}{C''}\lambda_2\phi_2 + \frac{1}{D''}w_k.$$

由于期望的线性性，并把常数吸收到 λ_1 和 λ_2 中，可以对梯度 $\partial f(W)/\partial w_k$ 作无偏估计。也就是说，该算法更新方向是式（1）梯度的无偏估计。证毕。

附录 B 详细实验结果

本节提供详细实验结果。合成数据结果见 B.1 节，基准数据结果见 B.2 节。

B.1 合成数据的详细实验结果

本节给出合成数据实验的详细结果。

表 B.1。 排序度量实验的原始绝对值和重新缩放的值。每一组中左列为绝对值，右列为缩放后的相对值。度量依次为排序损失、平均精度、首位错误率、覆盖度、macro-AUC、instance-AUC、micro-AUC。

measure	LIMO-inst		LIMO		LIMO	
ranking loss	0.027	0.00	0.015	0.99	0.015	1.00
avg. precision	0.992	0.00	0.992	0.58	0.992	1.00
one-error	0.000	1.00	0.001	0.28	0.001	0.00
coverage	1.576	0.00	1.557	0.97	1.556	1.00
macro-AUC	0.842	1.00	0.828	0.00	0.842	0.98
instance-AUC	0.973	0.00	0.985	0.99	0.985	1.00
micro-AUC	0.861	0.14	0.854	0.00	0.903	1.00

译注。 原表的后两个方法表头均印为 LIMO；结合正文实验设计，中间一组应与 LIMO-label 对应。这里保留原表，不擅自修改数据。

表 B.2。 分类度量实验的原始绝对值和重新缩放的值。每组左列为绝对值，右列为缩放后的相对值。四行依次为汉明损失、micro-F1、macro-F1、instance-F1；t 与 $t(x)$ 分别表示按标签和按实例设阈值。

measure	LIMO-inst-t		LIMO-inst-t(x)		LIMO-label-t		LIMO-label-t(x)		LIMO-t		LIMO-t(x)	
Hamming loss	0.172	0.28	0.160	0.48	0.188	0.00	0.131	1.00	0.163	0.43	0.134	0.94
micro-F1	0.837	0.00	0.860	0.43	0.840	0.06	0.890	1.00	0.858	0.40	0.885	0.92
macro-F1	0.869	0.87	0.857	0.25	0.861	0.46	0.859	0.35	0.872	1.00	0.852	0.00
instance-F1	0.804	0.00	0.883	0.79	0.835	0.32	0.904	1.00	0.858	0.54	0.900	0.96

B.2 基准数据的详细实验结果

正文图 4 的排名结果由表 B.3 计算得到。原表过大，因此原补充材料将其旋转后放在下一页。本译文将其按数据集分块展示，保留全部原始数值。

表 B.3。 十一种多标签性能度量上的实验结果。向下箭头表示越小越好，向上箭头表示越大越好。结果表示为“均值 ± 标准差（排名）”，排名越小性能越好。各块中的算法依次为 BR、ML-kNN、GFM、LIMO-inst、LIMO-label、LIMO。列指标依次为汉明损失、排序损失、平均精度、首位错误率、覆盖度、instance-F1、instance-AUC、macro-F1、macro-AUC、micro-F1、micro-AUC。

CAL500。

Dataset	Algorithm	hamming loss↓	ranking loss↓	avg. precision↑	one-error↓	coverage↓
CAL500	BR	.145±.003(5)	.216±.005(4)	.470±.008(4)	.212±.025(5)	143.025±2.319(4)
	ML-kNN	.139±.003(3)	.184±.005(3)	.491±.007(3)	.106±.023(3)	129.789±2.426(2)
	GFM	.200±.002(6)	.522±.007(5)	.337±.004(5)	.000±.000(1)	166.481±0.906(6)
	LIMO-inst	.143±.004(4)	.545±.015(6)	.147±.004(6)	.971±.022(6)	162.652±1.539(5)
	LIMO-label	.138±.002(2)	.180±.004(2)	.499±.008(2)	.105±.023(2)	129.993±2.491(3)
	LIMO	.137±.025(1)	.178±.004(1)	.501±.008(1)	.122±.035(4)	129.323±2.672(1)

Dataset	Algorithm	instance-F1↑	instance-AUC↑	macro-F1↑	macro-AUC↑	micro-F1↑	micro-AUC ↑
CAL500	BR	.354±.009(5)	.784±.005(4)	.097±.006(5)	.544±.012(2)	.357±.011(5)	.779±.006(4)
	ML-kNN	.321±.010(6)	.816±.005(3)	.053±.002(6)	.523±.009(3)	.318±.010(6)	.813±.004(3)
	GFM	.454±.006(3)	.662±.006(5)	.183±.005(3)	.518±.013(5)	.457±.006(3)	.661±.006(5)
	LIMO-inst	.386±.010(4)	.455±.015(6)	.302±.008(1)	.566±.011(1)	.389±.010(4)	.458±.014(6)
	LIMO-label	.473±.004(2)	.820±.004(2)	.126±.003(4)	.510±.011(6)	.477±.004(2)	.815±.004(2)
	LIMO	.475±.006(1)	.822±.004(1)	.288±.006(2)	.523±.011(4)	.479±.006(1)	.816±.004(1)

medical。

Dataset	Algorithm	hamming loss↓	ranking loss↓	avg. precision↑	one-error↓	coverage↓
medical	BR	.011±.001(1)	.073±.041(5)	.416±.100(6)	.804±.029(6)	3.697±1.752(5)
	ML-kNN	.016±.001(5)	.048±.008(4)	.788±.017(4)	.266±.025(5)	3.034±0.411(4)
	GFM	.025±.002(6)	.287±.026(6)	.692±.025(5)	.217±.025(3)	6.581±0.714(6)
	LIMO-inst	.015±.001(4)	.017±.005(1)	.881±.018(2)	.170±.028(2)	1.248±0.279(1)
	LIMO-label	.014±.001(3)	.032±.006(3)	.829±.018(3)	.217±.026(4)	2.237±0.378(3)
	LIMO	.013±.001(2)	.019±.006(2)	.893±.017(1)	.147±.027(1)	1.423±0.350(2)

Dataset	Algorithm	instance-F1↑	instance-AUC↑	macro-F1↑	macro-AUC↑	micro-F1↑	micro-AUC ↑
medical	BR	.766±.022(1)	.927±.040(5)	.384±.040(3)	.877±.038(3)	.792±.020(1)	.910±.039(5)
	ML-kNN	.564±.033(5)	.953±.007(4)	.190±.015(6)	.797±.029(5)	.654±.028(4)	.949±.008(4)
	GFM	.636±.025(4)	.882±.013(6)	.216±.018(4)	.650±.027(6)	.605±.027(5)	.875±.014(6)
	LIMO-inst	.444±.090(6)	.983±.005(1)	.448±.024(2)	.901±.032(1)	.439±.087(6)	.979±.005(1)
	LIMO-label	.641±.030(3)	.968±.006(3)	.207±.012(5)	.859±.035(4)	.702±.020(3)	.960±.007(3)
	LIMO	.706±.019(2)	.981±.006(2)	.464±.024(1)	.896±.029(2)	.757±.012(2)	.977±.006(2)

enron。

Dataset	Algorithm	hamming loss↓	ranking loss↓	avg. precision↑	one-error↓	coverage↓
enron	BR	.070±.003(6)	.136±.010(4)	.539±.086(4)	.533±.263(6)	16.834±0.669(4)
	ML-kNN	.053±.001(3)	.096±.004(3)	.624±.014(3)	.310±.022(4)	13.615±0.423(3)
	GFM	.069±.003(5)	.554±.027(6)	.399±.021(6)	.246±.041(2)	31.645±0.764(6)
	LIMO-inst	.054±.001(4)	.205±.008(5)	.520±.008(5)	.344±.013(5)	23.679±0.804(5)
	LIMO-label	.049±.001(2)	.085±.003(2)	.672±.010(2)	.233±.017(1)	12.324±0.444(2)
	LIMO	.049±.001(1)	.083±.003(1)	.672±.010(1)	.253±.022(3)	11.880±0.255(1)

Dataset	Algorithm	instance-F1↑	instance-AUC↑	macro-F1↑	macro-AUC↑	micro-F1↑	micro-AUC ↑
enron	BR	.482±.009(3)	.866±.010(4)	.187±.015(3)	.631±.025(5)	.473±.008(3)	.814±.008(4)
	ML-kNN	.409±.022(5)	.904±.004(3)	.083±.008(6)	.633±.022(4)	.461±.017(4)	.898±.003(1)
	GFM	.428±.022(4)	.669±.014(6)	.118±.012(5)	.553±.015(6)	.437±.016(5)	.654±.011(6)
	LIMO-inst	.404±.053(6)	.796±.008(5)	.310±.018(1)	.717±.015(1)	.414±.056(6)	.810±.006(5)
	LIMO-label	.565±.011(1)	.916±.003(2)	.137±.005(4)	.644±.019(3)	.591±.008(2)	.897±.003(2)
	LIMO	.562±.010(2)	.918±.003(1)	.278±.017(2)	.663±.021(2)	.596±.006(1)	.896±.004(3)

corel5k。

Dataset	Algorithm	hamming loss↓	ranking loss↓	avg. precision↑	one-error↓	coverage↓
corel5k	BR	.014±.000(5)	.280±.010(5)	.077±.013(6)	.962±.004(6)	207.643±3.477(5)
	ML-kNN	.009±.000(1)	.135±.002(3)	.245±.004(2)	.736±.009(3)	114.727±1.658(3)
	GFM	.021±.001(6)	.803±.012(6)	.100±.005(5)	.516±.030(1)	320.449±2.173(6)
	LIMO-inst	.010±.000(2)	.275±.004(4)	.105±.004(4)	.897±.006(5)	172.120±2.183(4)
	LIMO-label	.011±.000(4)	.112±.003(1)	.289±.006(1)	.710±.010(2)	99.629±2.136(2)
	LIMO	.011±.000(3)	.116±.003(2)	.227±.005(3)	.791±.008(4)	94.253±2.109(1)

Dataset	Algorithm	instance-F1↑	instance-AUC↑	macro-F1↑	macro-AUC↑	micro-F1↑	micro-AUC ↑
corel5k	BR	.139±.005(4)	.720±.010(5)	.044±.003(4)	.605±.004(4)	.158±.006(3)	.706±.009(5)
	ML-kNN	.017±.002(6)	.865±.002(3)	.009±.001(6)	.540±.007(5)	.027±.003(6)	.866±.002(3)
	GFM	.150±.008(3)	.416±.012(6)	.029±.002(5)	.516±.006(6)	.146±.011(4)	.411±.013(6)
	LIMO-inst	.058±.003(5)	.725±.004(4)	.118±.003(1)	.706±.006(1)	.057±.002(5)	.725±.004(4)
	LIMO-label	.214±.004(1)	.888±.003(1)	.050±.002(3)	.658±.006(3)	.236±.004(1)	.882±.002(1)
	LIMO	.152±.005(2)	.884±.003(2)	.117±.004(2)	.692±.007(2)	.177±.005(2)	.881±.003(2)

bibtex。

Dataset	Algorithm	hamming loss↓	ranking loss↓	avg. precision↑	one-error↓	coverage↓
bibtex	BR	.016±.001(5)	.114±.007(3)	.528±.012(2)	.428±.014(2)	32.758±1.929(4)
	ML-kNN	.014±.000(2)	.218±.004(5)	.339±.006(5)	.599±.007(6)	56.259±1.260(5)
	GFM	.037±.000(6)	.707±.003(6)	.210±.004(6)	.492±.010(5)	85.281±0.701(6)
	LIMO-inst	.014±.000(1)	.120±.003(4)	.494±.008(4)	.469±.016(4)	32.403±0.640(3)
	LIMO-label	.014±.000(4)	.071±.002(2)	.527±.008(3)	.433±.013(3)	20.425±0.422(2)
	LIMO	.014±.000(3)	.058±.001(1)	.570±.004(1)	.390±.008(1)	17.447±0.357(1)

Dataset	Algorithm	instance-F1↑	instance-AUC↑	macro-F1↑	macro-AUC↑	micro-F1↑	micro-AUC ↑
bibtex	BR	.399±.009(1)	.886±.007(3)	.318±.016(3)	.866±.007(4)	.419±.012(3)	.869±.007(4)
	ML-kNN	.160±.007(6)	.782±.004(5)	.066±.006(6)	.661±.007(5)	.211±.007(5)	.776±.005(5)
	GFM	.223±.008(5)	.618±.003(6)	.130±.007(5)	.575±.003(6)	.185±.007(6)	.626±.003(6)
	LIMO-inst	.392±.005(2)	.880±.003(4)	.323±.005(2)	.921±.002(2)	.438±.006(1)	.877±.003(3)
	LIMO-label	.386±.007(4)	.929±.002(2)	.232±.004(4)	.911±.002(3)	.405±.007(4)	.917±.002(2)
	LIMO	.390±.007(3)	.942±.001(1)	.326±.006(1)	.924±.002(1)	.435±.004(2)	.938±.002(1)