通过分布匹配实现校准：可训练的核校准度量

记号说明。 原文双线体数字 1 表示指示函数；为稳定显示，本译文可编辑公式中用粗体数字 1 表示同一指示函数，原式裁图仍保留原字形，语义不变。

非官方中文全文译文 · arXiv:2310.20211v1（2023 年 10 月 31 日）

Charles Marx、Sofian Zalouk、Stefano Ermon（斯坦福大学）。Charles Marx 与 Sofian Zalouk 贡献相同。联系邮箱：ctmarx@cs.stanford.edu、szalouk@stanford.edu、ermon@cs.stanford.edu。

原文：Calibration by Distribution Matching: Trainable Kernel Calibration Metrics。第 37 届神经信息处理系统大会（NeurIPS 2023）。版本来源：https://arxiv.org/abs/2310.20211v1 。

许可与改动说明：原文及本中文翻译均采用 **Creative Commons 署名—非商业性使用—相同方式共享 4.0 国际许可（CC BY-NC-SA 4.0）**，https://creativecommons.org/licenses/by-nc-sa/4.0/ 。本译文仅可依该许可用于非商业目的；发布改编内容须采用相同许可，并保留署名、来源、许可与改动说明。此处不授予商业使用权。改动包括中文翻译、重排版及中文图表说明；原始公式、图与数据表采用原版裁图保留符号和数值。翻译由 AI 辅助完成，不代表作者认可。原版 PDF 与 TeX 源文件另存于 source/，未修改仓库原论文。原文个别疑似笔误不作静默订正，相关说明见文末。

摘要

校准要求预测概率与经验频率一致，从而确保概率预测能够有意义地刻画不确定性。然而，许多现有校准方法专门用于事后再校准，这可能降低预测的尖锐性。基于可以将校准视为分布匹配任务这一认识，我们提出基于核的校准度量，统一并推广分类与回归中的常见校准形式。这些度量具有可微的样本估计，因而便于把校准目标纳入经验风险最小化。此外，我们提供直观机制，按决策任务定制校准度量，并促使损失估计准确、决策无遗憾。实证评估表明，在一系列回归与分类任务中，将这些度量用作正则项能够改善校准、尖锐性和决策表现，优于仅依赖事后再校准的方法。

1 引言

概率预测是刻画目标结果不确定性的重要工具。实践中通常无法恢复精确的结果分布 [51]，因而会产生过度自信的预测 [15]。校准为预测提供统计保证，使预测概率与事件的真实发生概率一致。例如，假设天气预报给出明天下雨的概率为 80%。良好校准的预测意味着，在给出这种预测的日期中，平均有 80% 的日子下雨。通过恰当地量化不确定性，即使无法精确恢复结果分布，校准仍使决策者能够高效分配资源、降低风险。

分类 [8,21,35] 与回归 [42,23,53] 中已有许多校准形式，用于确保不确定性估计与真实频率相匹配。从方法角度看，实施校准的文献较为分散：许多算法专门针对某一种校准形式 [39,29,52,10,17]，或仅为事后校准而设计 [27,23]。尽管事后方法能够有效实现校准，却经常降低预测器的预测能力，即尖锐性 [26]。这促使我们寻找通用度量，以便在训练期间实施多种校准形式。本文提出统一框架，将已有校准

概念表示为分布匹配约束。我们使用最大均值差异（Maximum Mean Discrepancy，MMD）实施分布匹配，得到适用于梯度优化的失校准无偏估计。我们将这些度量作为正则项，与恰当评分规则一同优化，从而在保持尖锐性的同时促进校准。

将校准表述为分布匹配 [38]，使我们能够利用 MMD [14] 得到适用于梯度优化的失校准无偏估计。这种方法的优势在于，可以通过改变 MMD 度量中的核来表达已有校准度量。此外，也可以表达专门针对下游决策任务的新校准概念，从而优先处理影响决策的错误 [52]。

本文贡献如下：

- 提出基于分布匹配的框架，统一多种校准概念。
- 提供可微训练目标，在监督学习的经验风险最小化中促进多种常用校准形式。将这些度量作为可与恰当评分规则共同优化的正则项，便能在不降低尖锐性的情况下促进校准。
- 展示如何定义与实施针对特定下游决策问题的新校准度量。成功优化这些度量后，决策者可以在无标签数据上准确估计决策损失。
- 在 10 个表格预测任务（5 个回归、5 个分类）上进行实证研究，发现相较现有再校准方法，以这些度量作正则项可以改善校准、尖锐性和决策。

2 相关工作

校准。 本文建立在校准预测文献 [31,8,9,13] 的基础上。近年来，分类 [5,25,24,32,35,33,10,17,28,36,27]、回归 [23,42,53,39,51] 及其他领域 [47,22] 中提出了许多校准形式。实施校准的算法往往针对特定形式设计。例如，为校准二分类中的置信水平，研究者对有效估计期望校准误差（ECE）投入了大量关注 [19,44,4,15,35]。本文旨在补充这些工作，提供可以用作训练目标的通用校准度量。这些方法可以与事后校准配合：在模型训练期间鼓励校准，训练完成后再修正剩余失校准。

决策校准。 近期一条值得关注的研究路线致力于为下游决策问题校准预测 [39,52]。Zhao 等 [52] 表明，当可能动作的集合有限时，可以实现决策校准。我们展示了借助决策问题的低维充分统计量将这一结果扩展到无限动作空间的情形。Zhao 等 [52] 使用线性分类器近似最坏情形决策问题来计算校准；我们则使用 MMD 目标的核均值嵌入形式，因此只需调整核，就能方便地针对受限损失函数集合进行校准。

基于核的校准度量。 针对 ECE 直方图分箱产生的问题，近期研究使用核来定义平滑校准度量。Zhang 等 [50] 和 Popordanoska 等 [37] 使用核密度估计来估计分类场景中的校准。相较之下，本文适用于回归，并采用分布匹配视角。Widmann 等 [47] 与 Kumar 等 [26] 的工作最接近本文，也提出了基于 MMD 的校准度量。我们与 Widmann 等 [46] 的区别在于，重点关注可训练性与优化、同已有校准形式的联系以及决策应用。Kumar 等 [26] 的方法可视为本文方法应用于多分类最高标签校准的特例（见表 1）。我们扩展了基于 MMD 的校准度量文献，展示了如何通过改变 MMD 目标中的核，表达并优化 11 种已有校准形式（见表 1、2）。

3 校准即分布匹配

考虑回归场景：给定特征向量 $x \in \mathcal{X} = \mathbb{R}^d$，预测标签 $y \in \mathcal{Y} \subset \mathbb{R}$。我们获得 n 个独立同分布样本 $(x_1, y_1), \ldots, (x_n, y_n)$，它们服从定义在 $\mathcal{X} \times \mathcal{Y}$ 上的某个真实但未知的累积分布函数（cdf）P。小写 p 表示存在时的概率密度函数（pdf）或概率质量函数（pmf）。我们用下标表示边缘与条件分布，因此 $P_{Y|x}(\cdot)$ 是给定 $X = x$ 时 Y 的条件 cdf，$p_Y(\cdot)$ 是 Y 的边缘 pdf。当输入 X 随机时，记 $P_{Y|X}$ 为取值为 cdf 的随机变量；在事件 $X = x$ 上，它取值为 $P_{Y|x}$。

表 1。将常见校准形式表述为分布匹配，其中 P 为真实分布，Q 为预测。在给定条件变量时，预测变量与目标变量同分布，即实现校准。$\delta^*_\ell(Q_{Y|X})$ 表示 $Q_{Y|X}$ 下的贝叶斯最优动作，y_0 是 $\mathcal{Y}$ 中的固定标签，$\alpha \in [0, 1]$ 是阈值，$\phi(X)$ 是特征映射。更多细节见附录 A。

Calibration Objective	Forecast Variable	Target Variable	Conditioning Variable
Quantile Calibration [23]	$Q_{Y\|X}(Y)$	$P_{Y\|X}(Y)$	$-$
Threshold Calibration [39]	$Q_{Y\|X}(Y)$	$P_{Y\|X}(Y)$	$\mathbb{1}\{Q_{Y\|X}(y_0) \le \alpha\}$
Marginal Calibration [12]	$\widehat{Y}$	Y	$-$
Decision Calibration [52]	$\widehat{Y}$	Y	$\delta^*_\ell(Q_{Y\|X})$
Group Calibration [36]	$\widehat{Y}$	Y	$\mathrm{Group}(X)$
Distribution Calibration [42]	$\widehat{Y}$	Y	$Q_{Y\|X}$
Individual Calibration [51]	$\widehat{Y}$	Y	X
Local Calibration [27]	$\widehat{Y}$	Y	$\phi(X)$

表内列名依次为：校准目标、预测变量、目标变量、条件变量。各行依次为：分位数校准 [23]、阈值校准 [39]、边缘校准 [12]、决策校准 [52]、群体校准 [36]、分布校准 [42]、个体校准 [51]、局部校准 [27]。Group(X) 表示 X 所属群体；“—”表示无条件变量。数学符号按原表保留。

目标是学习预测器 Q，给定特征向量 x 后，预测 y 上的 cdf $Q_{Y|x}(\cdot)$。将预测条件 pdf 与特征边缘 pdf 结合，预测器隐式定义 $\mathcal{X} \times \mathcal{Y}$ 上的联合分布，即 $q(x, y) = p_X(x) q_{Y|x}(y)$。在 $\mathcal{X} \times \mathcal{Y}$ 的适当区域上对 $q(x, y)$ 积分，即定义预测器的联合 cdf $Q(x, y)$。类似于 $(X, Y) \sim P$ 是真实分布的样本，我们把来自 Q 的样本记作 $(X, \widehat{Y}) \sim Q$，其中 $X \sim P_X$，$\widehat{Y}$ 是从预测中抽出的标签，$(\widehat{Y} \mid X = x) \sim Q_{Y|x}$。

理想预测器精确恢复真实概率，即 $Q = P$。然而，实践中每个特征向量 x 往往只被观察一次，因此无法达到完美预测 [51]。校准转而要求预测平均而言准确，由此得到严格弱于完美预测的可处理任务。每种校准形式要求预测遵循某条特定概率规律。例如，当 Y 是二元变量时，分布校准规定：对预测 $q_{Y|x}(Y = 1) = c$ 的样本，应以频率 c 观察到 $Y = 1$。在回归中，分位数校准 [23] 规定，y 应以频率 c 超过预测的每个分位数 $c \in [0, 1]$。校准还可在数据子群内实施（群体校准 [36]）、在输入空间的平滑邻域内实施（局部校准 [27]），甚至通过随机化在单个特征向量上实施（个体校准 [51]）。

校准可表述为条件分布匹配问题，要求真实分布关联的某些变量与预测中的对应变量匹配。

引理 3.1（非正式）。分位数校准等价于 $Q_{Y|X}(Y)$ 与 $P_{Y|X}(Y)$ 的分布匹配。分布校准等价于给定 $Q_{Y|X}$ 时 $\widehat{Y}$ 与 Y 的分布匹配。个体校准等价于给定 X 时 $\widehat{Y}$ 与 Y 的分布匹配。

选择进行分布匹配的随机变量，决定了所恢复的校准形式。表 1 展示如何将许多常见校准形式表述为分布匹配；附录 A 给出这些对应关系的更多细节。第 4 节说明如何用基于核的校准度量表达和估计这些形式，第 5 节展示如何针对下游决策问题定制度量，第 6 节则将这些度量用作正则项，研究其对校准、尖锐性和决策的实证影响。

4 将校准度量用作可训练正则项

本节提出利用分布匹配实施校准的框架。我们使用积分概率度量量化校准，这类度量具有基于数据的无偏估计，并适合梯度优化。由此可以将校准与标准训练目标共同优化，在不降低尖锐性的情况下实现校准。已有研究表明，共同优化校准和尖锐性优于仅在事后实施校准 [26]。

积分概率度量（IPM）通过一族见证函数，灵活量化两个分布间的差异 [30]。由于需要进行条件分布匹配，我们考虑同时以标签 Y 和条件变量 Z 为输入的见证函数；Z 在 P 与 Q 下具有相同分布。

$$D(\mathcal{F}, P, Q) = \sup_{f \in \mathcal{F}} \left| \mathbb{E}_P \left[f(Y, Z) \right] - \mathbb{E}_Q \left[f(\widehat{Y}, Z) \right] \right|. \tag{1}$$

见证函数族 $\mathcal{F}$ 与条件变量 Z 的不同选择度量不同的校准概念。类似于 Widmann 等 [47]，我们关注 $\mathcal{F}$ 为再生核希尔伯特空间（RKHS）$\mathcal{H}$ 单位球的情形，此时 IPM 对应最大均值差异 [14]，记为 $\mathrm{MMD}(\mathcal{F}, P, Q)$。MMD 既可以通过典范特征映射 $\phi(y, z) \in \mathcal{H}$ 表达，也可以通过 $\mathcal{H}$ 的再生核 $k\big((y, z), (\widehat{y}, z')\big) = \langle \phi(y, z), \phi(\widehat{y}, z') \rangle_{\mathcal{H}}$ 表达：

$$\begin{aligned} \mathrm{MMD}^2(\mathcal{F}, P, Q) &= \left\| \mathbb{E}_P \left[\phi(Y, Z) \right] - \mathbb{E}_Q \left[\phi(\widehat{Y}, Z) \right] \right\|_{\mathcal{H}}^2 \\ &= \mathbb{E}_P \left[k((Y, Z), (Y', Z')) \right] + \mathbb{E}_Q \left[k((\widehat{Y}, Z), (\widehat{Y}', Z')) \right] - 2\mathbb{E}_P \mathbb{E}_Q \left[k((Y, Z), (\widehat{Y}', Z')) \right] \end{aligned} \tag{2}$$

给定含 n 个独立同分布样本对 $(x_i, y_i) \sim P$ 的数据集 D，可生成预测标签 $\widehat{y}_i \sim Q_{Y|x_i}$。根据表 1 的表达式，从 (x_i, y_i) 计算条件变量 z_i。代入式 MMD 估计量无偏，形式为 [14]：

$$\widehat{\mathrm{MMD}}^2(\mathcal{F}, D, Q) = \frac{1}{n(n-1)} \sum_{i=1}^{n} \sum_{j \neq i}^{n} h_{ij}, \tag{3}$$

其中 h_{ij} 是一个单样本 U 统计量：

$$h_{ij} := k((y_i, z_i), (y_j, z_j)) + k((\widehat{y}_i, z_i), (\widehat{y}_j, z_j)) - k((y_i, z_i), (\widehat{y}_j, z_j) - k((y_j, z_j), (\widehat{y}_i, z_i))$$

将抽取 $\widehat{y}_i \sim Q_{Y|x_i}$ 所引入的模拟随机性边缘化，可以减小估计量方差。这既可以解析完成，也可以通过对每个样本多次重抽预测标签进行经验估计。我们发现，在实践中对模拟随机性进行经验边缘化可以提高训练稳定性。完整训练目标结合恰当评分规则（本文使用负对数似然）与 MMD 估计，以促进校

准。训练时，将数据集 D 分成批次 $D_b \subset \{1, \ldots, n\}$，批次必须足够大，使批次上的 MMD 估计具有足够低的方差，提供有效监督（实践中大小为 64 已足够）。给定一族预测模型 $\{Q_\theta : \theta \in \Theta\}$（例如神经网络），在每批数据上优化：

$$\min_{\theta \in \Theta} \sum_{i \in D_b} -\log q_{Y|x_i;\theta}(y_i) + \lambda \cdot \widehat{\mathrm{MMD}}^2(\mathcal{F}, D_b, Q_\theta) \tag{4}$$

为了对式（4）中的 MMD 估计关于 θ 求导，要求核 k 可微，且抽样结果可表示为模型参数的可微函数（例如使用重参数化技巧）。对于不支持精确可微抽样的参数化，可以使用可微松弛（例如，若 Q_θ 是混合分布，可用 Gumbel-Softmax 近似）。原则上，可以用蒙特卡洛强化学习技术（如 REINFORCE [48]）优化 MMD 目标，完全消除对可微抽样的需求，但这超出本文范围。注意，训练时进行校准正则化并不提供校准保证，除非能够保证目标在样本外也被优化。在这个意义上，正则化与事后校准互为补充：正则化缓解校准和尖锐性之间的权衡，而事后方法可提供有限样本校准保证（如 [45,29]）。因此，我们建议联合使用正则化与事后校准（见表 3）。

核的选择。当核 k 是通用核时，MMD 为零当且仅当给定 Z 后 Y 与 $\widehat{Y}$ 同分布 [14]。将 $\mathcal{Y} \times \mathcal{Z}$ 上的核分解为两个通用核的逐点乘积（分别定义于 $\mathcal{Y}$ 与 $\mathcal{Z}$），仍可保持通用性 [43]。

引理 4.1。设 $k\big((y, z), (y', z')\big) = k_y(y, y')k_z(z, z')$，其中 k_y 与 k_z 分别是空间 $\mathcal{Y}$ 与 $\mathcal{Z}$ 上的通用核。在温和条件下，k 是 $\mathcal{Y} \times \mathcal{Z}$ 上的通用核。

证明见 [43，定理 4]。实验中，我们考虑 $\mathcal{Y} \times \mathcal{Z}$ 上的通用 RBF 核，因为它满足引理 4.1 所需的温和条件。为实施决策校准，我们也考虑故意不具有通用性的核 k_Y，它只度量 P 与 Q 之间同决策有关的差异（见第 5 节）。此外，为度量分位数校准与阈值校准，需要匹配概率积分变换 $P_{Y|X}(Y)$ 与 $Q_{Y|X}(Y)$ 的分布，而不是 Y 与 $\widehat{Y}$ 的分布。因此，我们将 k_Y 替换为概率积分变换值域 $[0, 1]$ 上的通用核。

4.1 分类的校准度量

到目前为止，我们关注回归场景中的校准度量估计。下面说明该框架如何应用于分类。

在分类场景中，给定特征向量 $x \in \mathcal{X} = \mathbb{R}^d$，预测标签 $y \in \mathcal{Y} = \{1, \ldots, m\}$。与之前一样，获得来自 $\mathcal{X} \times \mathcal{Y}$ 上某个未知分布 P 的 n 个独立同分布样本 $(x_1, y_1), \ldots, (x_n, y_n)$。目标是学习预测器 Q，给定特征向量 x，预测标签空间 $\mathcal{Y}$ 上的概率质量函数 $q_{Y|x}(\cdot)$。

表 2。 对类别为 $\mathcal{Y} = \{1, ..., m\}$ 的分类问题，将常用校准形式表达为分布匹配。 $q_{Y|X}(\cdot)$ 为预测 pmf。给定条件变量后，预测变量与目标变量同分布，即预测器得到校准。对于最高标签校准，使用 $Y^*:=\text{argmax}_{y\in\mathcal{Y}} q_{Y|X}(y)$，它因 X 而随机。边缘校准条件表达 m 个分布匹配约束，每个 $y \in \mathcal{Y}$ 对应一个约束。

Calibration Objective	Forecast Variable	Target Variable	Conditioning Variable
Canonical Calibration [44, Eq 1]	$\widehat{Y}$	Y	$q_{Y\|X}$
Top-label Calibration [44, Eq 2]	$\mathbb{1}\{\widehat{Y} = Y^*\}$	$\mathbb{1}\{Y = Y^*\}$	$q_{Y\|X}(Y^*)$
Marginal Calibration [44, Eq 3]	$\mathbb{1}\{\widehat{Y} = y\}$	$\mathbb{1}\{Y = y\}$	$q_{Y\|X}(y), \forall y \in \mathcal{Y}$

列名依次为校准目标、预测变量、目标变量、条件变量。三行分别为典范校准 [44，式 1]、最高标签校准 [44，式 2]、边缘校准 [44，式 3]；全部指示函数、条件变量及“对所有 $y \in \mathcal{Y}$”的量词按原表保留。

表 2 将分类中常用概念（典范、最高标签、边缘校准）表示为分布匹配。分类中校准与分布匹配的更多细节见附录 A.2。我们使用式（3）中的同一无偏代入式 MMD 估计量。在分类中，计算 MMD 估计时，可以解析边缘化预测所产生的随机性。完成边缘化后，单样本 U 统计量为：

$$h_{ij} = k((y_i, z_i), (y_j, z_j)) + \sum_{y\in\mathcal{Y}} \sum_{y'\in\mathcal{Y}} q_i(y) q_j(y') k((y, z_i), (y', z_j)) - 2 \sum_{y\in\mathcal{Y}} q_i(y) k((y, z_i), (y_j, z_j)),$$

其中条件变量 z_i 从 (x_i, y_i) 计算，细节见表 2。这里 $q_i(y) = q_{Y|x_i}(y)$ 是给定特征 x_i 时标签 $Y = y$ 的预测概率。当预测变量与目标变量还依赖 Y 之外的变量（例如最高标签校准中的 Y^* 依赖 $q_{Y|X}$）时，将这些变量作为核的额外输入。采用该 U 统计量的代入式 MMD 估计量关于预测标签概率可微，并且可在 $O(n^2m^2)$ 时间内计算。

5 校准与决策

校准最具实际用途的结果之一，是为下游决策提供保证 [52]。通用核原则上保证分布匹配，但某些情况下需要大量样本。如果事先了解决策问题，则可以设计仅对决策相关错误敏感的校准度量。本节展示如何设计此类度量，并说明它们能够使我们：（1）准确评估下游动作的损失；（2）选择在某种意义上最优的动作。

首先引入一般决策问题。对每个样本，决策者选择动作 $a \in \mathcal{A}$，并承受取决于结果的损失 $\ell(a, y)$。具体而言，给定信息 z（例如预测），决策策略 $\delta : \mathcal{Z} \to \mathcal{A}$ 分配动作 $\delta(z)$。所有这类策略的集合记为 $\Delta(\mathcal{Z})$。标签分布 P_Y 下的贝叶斯最优策略记为 $\delta^*_\ell(P_Y):=\text{argmin}_{a\in\mathcal{A}} \mathbb{E}_P[\ell(a, Y)]$。决策校准 [52] 提供两项重要保证：

$$\mathbb{E}_Q\left[\ell(a, \widehat{Y}) \mid Z = z\right] = \mathbb{E}_P\left[\ell(a, Y) \mid Z = z\right], \quad \forall a \in \mathcal{A}, z \in \mathcal{Z} \qquad \text{(loss estimation)}$$
$$\mathbb{E}_P\left[\ell(\delta^*_\ell(Q_{Y|x}), Y) \mid Z = z\right] \le \mathbb{E}_P\left[\ell(\delta(z), Y) \mid Z = z\right], \quad \forall z \in \mathcal{Z}, \delta \in \Delta(\mathcal{Z}) \qquad \text{(no regret)}$$

上式两行分别为“损失估计”与“无遗憾”。损失估计表示，每个动作在真实分布下和预测下的期望损失相等，因此可以在无标签数据上估计损失。无遗憾表示，预测给出的贝叶斯最优动作 $\delta_\ell^*\left(Q_{Y|X}\right)$ 的期望损失，不大于仅依赖 z 的任意策略 $\delta \in \Delta(\mathcal{Z})$ 的期望损失。若选择 $z = Q_{Y|X}$，即以预测为条件，那么仅能获得预测的决策者，就有动机把预测当作正确分布来行动。我们还考虑事先不知道损失函数的情形。例如，供应商发布服务大量用户的基础模型时，不同用户很可能拥有不同损失函数。因此，我们也展示能对损失族 $\mathcal{L}$ 中所有损失函数 ℓ 实现准确损失估计与无遗憾的情形。

决策校准的一般方法。下面描述使用基于核的度量来度量决策校准的方法。对每个动作 $a \in \mathcal{A}$ 与损失 $\ell \in \mathcal{L}$，希望度量 P 与 Q 下损失 $\ell(a, Y)$ 期望的差异。为此，定义计算所有动作损失的特征映射 $\phi(y) = \left(\ell(a, y)\right)_{a\in\mathcal{A},\ell\in\mathcal{L}}$。它分别为 P 与 Q 赋予均值嵌入 $\mu_P = \mathbb{E}_P\left[(\ell(a, Y))_{a\in\mathcal{A},\ell\in\mathcal{L}}\right]$ 和 $\mu_Q = \mathbb{E}_Q\left[(\ell(a, \widehat{Y}))_{a\in\mathcal{A},\ell\in\mathcal{L}}\right]$。令 $\mathcal{F}$ 为此特征映射所对应希尔伯特空间的单位球，MMD 的均值嵌入形式给出

$$\mathrm{MMD}(\mathcal{F}, P, Q)^2 = \| \mu_P - \mu_Q \|_2^2 = \sum_{a\in\mathcal{A}}\sum_{\ell\in\mathcal{L}} \left(\mathbb{E}_P\left[\ell(a, Y) - \mathbb{E}_Q[\ell(a, \widehat{Y})]\right]\right)^2.$$

当 $\mathcal{A}$ 或 $\mathcal{L}$ 无限时，对应求和换成积分。该度量衡量在真实分布与预测下，每个动作是否具有相同的边缘期望损失。因此，准确损失估计只在边缘意义上有保证，无遗憾结果也只是相对于对所有样本选择同一动作的常数决策函数而言。

接下来将决策校准结果细化，使其在给定变量 Z 后成立。y 上的核为 $k_y(y, y') = \langle\phi(y), \phi(y')\rangle$。通过定义 $k\left((y, z), (y', z')\right) = k_y(y, y')k_z(z, z')$，将该核提升至 $\mathcal{Y}\times\mathcal{Z}$，其中 k_z 是通用核。对应的 MMD 度量衡量以 Z 为条件的决策校准。若取 $Z = Q_{Y|X}$，无遗憾保证意味着：在所有仅依赖预测的策略中，将预测视为正确分布来行动是最优决策策略。

当 $\mathcal{A}$ 或 $\mathcal{L}$ 无限时，上述特征映射为无限维。然而，应用核技巧有时仍能有效估计 MMD。即便如此，实践中优化 MMD 仍可能困难，尤其是在条件变量 Z 表达能力很强时。我们建议将该度量用作正则项，在训练中鼓励决策校准，并在需要时仍然进行事后再校准。下面给出两个具体例子，一个动作空间无限，另一个损失函数集合无限。

例 1（点估计决策）。考虑回归问题：决策者选择点估计 $a \in \mathbb{R}$，承受平方损失 $\ell(a, y) = (a - y)^2$。动作 a 的期望损失是 $\mathbb{E}_P\left[(a - Y)^2\right] = \left(a - \mathbb{E}_P[Y]\right)^2 + \mathbb{E}_P\left[Y^2\right] - \mathbb{E}_P[Y]^2$。可见，该期望损失仅通过前两阶矩 $\mathbb{E}_P[Y]$ 和 $\mathbb{E}_P\left[Y^2\right]$ 依赖 Y。取表示 $\phi(y) = (y, y^2)$，对应核为 $k(y, y') = \langle(y, y^2), (y', y'^2)\rangle$。由 MMD 的均值嵌入形式可得，原文写为 $\mathrm{MMD}(\mathcal{F}, P, Q) = \| \mu_P - \mu_Q \|^2 = \left(\mathbb{E}[Y] - \mathbb{E}_Q[\widehat{Y}]\right)^2 + \left(\mathbb{E}_P\left[Y^2\right] - \mathbb{E}_Q\left[\widehat{Y}^2\right]\right)^2$。因此，当且仅当每个动作 a 在真实分布与预测下的期望损失相同，该度量为零。

MMD 度量鼓励预测准确反映每个动作的边缘损失。然而，通常我们希望知道给定某个预测时的最优动作，而不仅仅是边缘最优动作。此时可以选择条件变量来细化保证。令 $Z = Q_{Y|X}$，并选核 $k\left((y, z), (y', z')\right) = k_y(y, y')k_z(z, z')$，其中 k_y 与上文相同，k_z 为通用核。该核的 MMD 为零，当且仅当几乎处处成立：$\mathbb{E}_P\left[Y \mid Q_{Y|X}\right] = \mathbb{E}_Q\left[\widehat{Y} \mid Q_{Y|X}\right]$，且 $\mathbb{E}_P\left[Y^2 \mid Q_{Y|X}\right] = \mathbb{E}_Q\left[\widehat{Y}^2 \mid Q_{Y|X}\right]$。预测建议的贝叶斯最优动作，在仅依赖预测的决策策略中最优：

$$\mathbb{E}_P\left[\ell\left(\delta^*(Q_{Y|X}), Y\right)\right] \le \mathbb{E}_P\left[\ell\left(\delta(Q_{Y|X}), Y\right)\right], \quad \forall \delta \in \Delta(Q_{Y|X}) \tag{5}$$

换言之，决策者有动机像预测完全正确那样行动。

例 2（阈值决策）。 上例的动作空间无限，损失函数只有一个。这里考虑动作空间很小、但损失函数集合无限的问题。该情形适用于向多个决策者提供模型的供应商，每个决策者可能具有不同损失函数。例如，设患者某项血液指标为 $Y \in [0, T]$，其中 $T > 0$；决策任务是判断 Y 是否超过表示临床试验入选资格的阈值 $t \in [0, T]$。形式上，决策者选择 $a \in \{\pm 1\}$，以最小化损失 $\ell_t(a, y) = \mathbf{1}\{a \neq \operatorname{sign}(y - t)\}$。目标是同时针对所有阈值 $t \in [0, T]$ 校准预测，即 $\mathcal{L} = \{\ell_t : t \in [0, T]\}$。此时选择特征映射 $\phi(y) = \left(\mathbf{1}\{y \ge t\}\right)_{t\in[0,T]}$。对应核为 $k(y, y') = \langle \phi(y), \phi(y') \rangle = \min\{y, y'\}$。原文将均值嵌入写作 $\mathbb{E}_P[\phi(Y)] = P_Y$ 和 $\mathbb{E}_Q[\phi(\widehat{Y})] = Q_Y$，即 Y 和 Y_Q 的边缘 cdf。于是 MMD 度量衡量 $\| P_Y - Q_Y \|_2^2 = \int_{t=0}^{T} \left(P_Y(t) - Q_Y(t)\right)^2 dt$，它恰在 $P_Y = Q_Y$ 时为零。当 $\mathrm{MMD}(\mathcal{F}, P, Q) = 0$ 时，对所有 $\ell \in \mathcal{L}$，每个动作 a 在真实分布和预测下的期望损失相同。与上例类似，可通过为条件变量加入通用核，实现条件决策校准。

讨论。 Zhao 等 [52] 与 Sahoo 等 [39] 已研究决策与校准的联系。这里将 Zhao 等 [52] 的结果扩展到无限动作空间，并进一步使决策保证依赖任意条件变量。例 2 将我们的方法联系到阈值校准 [39] 这一特例。重要的是，本框架提供了在训练期间优化决策校准的策略。

6 实验

实验的主要目标是：（1）将本文方法与其他可训练校准度量及标准事后再校准方法比较；（2）研究为特定决策任务定制 MMD 核的影响；（3）研究可训练校准度量是否能改善数据局部邻域内的校准。复现实验的代码见 https://github.com/kernel-calibration/kernel-calibration/ 。

6.1 数据集

我们考虑标准基准数据集及与决策任务有关的数据集。每个数据集随机分配 70% 用于训练、10% 用于验证、20% 用于测试。

回归数据集。 使用 4 个表格型 UCI 数据集：SUPERCONDUCTIVITY（超导性）[16]、CRIME（犯罪）[34]、BLOG（博客）[6]、FB-COMMENT（脸书评论）[41]，以及医疗支出面板调查数据集 MEDICAL-EXPENDITURE [7]。它们是不确定性量化文献中的常见基准 [23,39]。特征数 d 从 53 到 280；各数据集的样本总数 n 与特征数 d 见表 3。

分类数据集。 使用 5 个表格型 UCI 数据集：BREAST-CANCER（乳腺癌）[49]、HEART-DISEASE（心脏病）[18]、ONLINE-SHOPPERS（网络购物者）[40]、DRY-BEAN（干豆）[1]、ADULT（成年人）[2]。标签类别数 m 从 2 到 7，特征数 d 从 16 到 104；各数据集的 n, d, m 见表 4。

作物产量数据集。 引入 CROP-YIELD 数据集，任务是依据美国不同县的天气数据预测每年小麦产量。使用 NOAA 数据库记录每年的天气汇总统计量（温度、降水、制冷／采暖度日），用 NASS 数据库记录年度小麦产量。数据覆盖 1990—2007 年；保留 1995 年数据用于可视化，其余数据用于训练。用该数据集评估相对于经纬度坐标的局部校准。

6.2 实验设置与基线

模型。 用含 3 个全连接层的前馈神经网络表示模型不确定性。分类中，模型输出全部 m 类的 logits。回归中，模型输出预测均值 $\mu(Y)$ 和方差 $\sigma^2(Y)$，用于参数化高斯概率分布。这样可方便地计算逆 cdf $Q_{Y|X}^{-1}$ 并实施可微抽样，从而能在多种设置中测试校准度量。模型超参数调优细节见附录 B。

训练目标。 回归中考虑负对数似然 NLL，以及将可训练校准度量作为正则项的 NLL + MMD。对于 MMD，选择条件变量 $Z = X$，匹配 $(X, \widehat{Y})$ 与 (X, Y) 的分布，以实施一种个体校准（表 1）。具体而言，优化一个核按随机变量对分解的 MMD 目标：$k\big((x, y), (x', y')\big) = k_X(x, x')k_Y(y, y')$。$k_X$ 和 k_Y 的形式因实验而异。分类中，考虑交叉熵（XE）损失，以及三种可训练校准正则项：MMCE [26]、KDE [37]、MMD（本文）。

基线。 回归中，将本文方法与用 NLL 训练的未校准预测器，以及采用保序回归的事后再校准 [23] 比较。分类中，与用 XE 损失训练的未校准预测器比较，并与两种可训练校准度量 MMCE [26] 和 KDE [37] 比较。将所有方法与标准事后再校准方法温度缩放 [15] 对比。分类与回归均在验证集上训练事后再校准方法，随后在留出的测试集上评估。

表 3。 5 个回归数据集上的模型性能比较。模型使用 NLL 与 NLL + MMD（本文）两种目标训练。给出每种训练程序在测试集上的指标，包括是否施加在验证集上拟合的事后分位数校准 [23] 两种情况。n 为样本数，d 为特征数。

Dataset	Training Objective	NLL ↓	Quantile Cal. ↓	Decision Cal. ↓
CRIME $n = 1992$ $d = 102$	NLL	-0.716 ± 0.007	0.220 ± 0.004	0.151 ± 0.009
	+ Post-hoc	-0.387 ± 0.012	0.154 ± 0.003	0.089 ± 0.005
	NLL + MMD (*Ours*)	**-0.778 ± 0.008**	0.164 ± 0.004	0.042 ± 0.011
	+ Post-hoc	-0.660 ± 0.014	**0.105 ± 0.004**	**0.041 ± 0.005**
BLOG $n = 52397$ $d = 280$	NLL	0.997 ± 0.040	0.402 ± 0.006	4.087 ± 0.004
	+ Post-hoc	**0.624 ± 0.021**	0.053 ± 0.001	4.090 ± 0.001
	NLL + MMD (*Ours*)	0.957 ± 0.008	0.302 ± 0.002	**4.051 ± 0.002**
	+ Post-hoc	0.945 ± 0.007	**0.042 ± 0.001**	4.067 ± 0.001
MEDICAL-EXPENDITURE $n = 33005$ $d = 107$	NLL	1.535 ± 0.000	0.078 ± 0.001	0.476 ± 0.002
	+ Post-hoc	1.808 ± 0.002	0.059 ± 0.001	0.472 ± 0.002
	NLL + MMD (*Ours*)	**1.532 ± 0.000**	0.059 ± 0.001	0.438 ± 0.002
	+ Post-hoc	1.780 ± 0.001	**0.045 ± 0.000**	**0.431 ± 0.001**
SUPERCONDUCTIVITY $n = 21264$ $d = 81$	NLL	3.375 ± 0.008	0.062 ± 0.003	0.211 ± 0.003
	+ Post-hoc	3.707 ± 0.007	0.066 ± 0.001	0.202 ± 0.003
	NLL + MMD (*Ours*)	**3.269 ± 0.012**	**0.042 ± 0.003**	**0.182 ± 0.003**
	+ Post-hoc	3.643 ± 0.010	0.050 ± 0.002	0.186 ± 0.003
FB-COMMENT $n = 40949$ $d = 53$	NLL	0.634 ± 0.016	0.334 ± 0.004	3.151 ± 0.003
	+ Post-hoc	0.734 ± 0.015	0.063 ± 0.001	3.151 ± 0.002
	NLL + MMD (*Ours*)	**0.605 ± 0.004**	0.258 ± 0.003	**3.131 ± 0.003**
	+ Post-hoc	0.639 ± 0.005	**0.054 ± 0.001**	3.138 ± 0.002

表内列名：数据集、训练目标、NLL（↓）、分位数校准误差（↓）、决策校准误差（↓）。Ours=本文方法；+ Post-hoc=再加事后校准。各数据集名称对应上文中文名称；所有数值、标准误与向下箭头保持原样。

指标。 回归预测性能采用负对数似然、分位数校准误差（QCE）[23] 和决策校准误差（见第 6.3 节）评估。分类中，计算准确率、期望校准误差（校准）以及预测的平均香农熵（尖锐性）。还报告核校准误差（KCE），其定义为 $\mathcal{X} \times \mathcal{Y}$ 上 RBF 核对应的 MMD 目标。各指标均在留出测试集上计算。全部实验使用 50 个随机种子重复，报告每个指标的均值和标准误。

表 4。 5 个表格分类任务的实验结果：比较 MMCE 正则化 [26]、KDE 正则化 [37]、MMD 正则化（本文）和标准交叉熵（XE）损失，不进行事后再校准。 n, d, m 分别为样本数、特征数、类别数。

Dataset	Training Objective	Accuracy ↑	ECE ↓	Entropy ↓	KCE ↓
BREAST-CANCER	XE	95.372 ± 0.160	0.194 ± 0.003	0.453 ± 0.004	6.781 ± 0.601
$n = 569$	XE + MMCE	94.770 ± 0.147	0.060 ± 0.001	0.076 ± 0.002	0.392 ± 0.086
$d = 30$	XE + ECE KDE	94.351 ± 0.163	0.062 ± 0.001	0.065 ± 0.001	0.225 ± 0.083
$m = 2$	XE + MMD (*Ours*)	**95.789 ± 0.060**	**0.052 ± 0.000**	**0.006 ± 0.000**	**0.014 ± 0.000**
HEART-DISEASE	XE	55.904 ± 0.196	0.373 ± 0.003	1.512 ± 0.007	0.581 ± 0.016
$n = 921$	XE + MMCE	60.787 ± 0.208	0.267 ± 0.002	0.947 ± 0.003	0.097 ± 0.002
$d = 23$	XE + ECE KDE	50.036 ± 2.801	0.304 ± 0.012	1.392 ± 0.016	0.450 ± 0.050
$m = 5$	XE + MMD (*Ours*)	**61.516 ± 0.255**	**0.261 ± 0.003**	**0.945 ± 0.006**	**0.077 ± 0.002**
ONLINE-SHOPPERS	XE	89.816 ± 0.037	0.129 ± 0.001	0.221 ± 0.003	0.022 ± 0.001
$n = 12330$	XE + MMCE	89.933 ± 0.036	0.128 ± 0.001	0.220 ± 0.002	-0.019 ± 0.001
$d = 28$	XE + ECE KDE	**90.019 ± 0.034**	**0.127 ± 0.000**	0.225 ± 0.002	-0.022 ± 0.001
$m = 2$	XE + MMD (*Ours*)	89.976 ± 0.031	**0.127 ± 0.001**	**0.218 ± 0.002**	**-0.026 ± 0.000**
DRY-BEAN	XE	92.071 ± 0.025	0.113 ± 0.000	0.264 ± 0.001	0.061 ± 0.002
$n = 13612$	XE + MMCE	92.772 ± 0.035	0.099 ± 0.000	0.224 ± 0.002	0.048 ± 0.004
$d = 16$	XE + ECE KDE	92.760 ± 0.037	0.097 ± 0.000	0.232 ± 0.001	0.041 ± 0.003
$m = 7$	XE + MMD (*Ours*)	**92.894 ± 0.035**	**0.089 ± 0.000**	**0.174 ± 0.002**	**0.040 ± 0.004**
ADULT	XE	84.528 ± 0.040	0.186 ± 0.000	0.320 ± 0.002	-0.014 ± 0.002
$n = 32561$	XE + MMCE	84.203 ± 0.042	0.191 ± 0.000	0.340 ± 0.002	-0.015 ± 0.002
$d = 104$	XE + ECE KDE	84.187 ± 0.045	**0.178 ± 0.001**	0.414 ± 0.002	**-0.020 ± 0.003**
$m = 2$	XE + MMD (*Ours*)	**84.565 ± 0.035**	**0.178 ± 0.001**	**0.315 ± 0.002**	-0.018 ± 0.001

列名：数据集、训练目标、准确率（↑）、ECE（↓）、熵（↓）、KCE（↓）。Ours=本文；XE + ECE KDE=交叉熵加基于 KDE 的 ECE 正则项。其余缩写、数据集标识和数值按原表保留。

结果。 回归和分类结果分别见表 3、4。回归中，我们的 NLL + MMD 目标在所有数据集上的 QCE 均优于 NLL 目标，同时测试集 NLL 相当或更好。在多数数据集上，本文方法还减小了事后校准引起的尖锐性损失。重要的是，我们还观察到事后校准与本文方法互补：事后方法可保证留出数据上的校准，校准正则化则减轻尖锐性损失。分类中，相对于所测试的校准正则化基线，本文方法改善了准确率、ECE 和熵。事后校准后总体上仍存在这些趋势：大多数数据集上，本文方法的校准和准确率更好（见表 5）。

计算需求。 相对于不加正则化的 NLL 目标，采用 MMD 正则化后，5 个回归数据集的每轮平均实际耗时为原来的 1.2 倍，5 个分类数据集则为 1.3 倍。

6.3 实验：决策校准

可训练校准度量的关键优势之一，是能灵活实施多种校准概念。为研究本文方法改善决策校准的效果，考虑一个决策任务：选择动作 $a \in \{\pm 1\}$，损失 $\ell(a, y) = \mathbf{1}\{a \neq \operatorname{sign}(y - c)\}$ 仅取决于标签 y 是否超过阈值 $c \in \mathbb{R}$。给定真实分布 P 与预测器 $Q_{Y|X}$，决策校准误差定义为

$$\mathrm{DCE}^2(P, Q) = \sum_{a \in \mathcal{A}} \| \mathbb{E}_P[\ell(Y, a)] - \mathbb{E}_X \mathbb{E}_{\widehat{Y} \sim Q_{Y|X}}[\ell(\widehat{Y}, a)] \|_2^2.$$

MMD 目标。 为优化决策校准，定制核 k_X, k_Y 以反映决策问题。具体而言，选择惩罚落在阈值 c 错误一侧的预测标签的核：若 $\text{sign}(y-c) = \text{sign}(y'-c)$，则 $k_Y(y, y') = +1$，否则为 -1。为允许梯度优化，将其松弛为可微核 $k_Y(y, y') = \tanh(y-c)\tanh(y'-c)$。原文随后指出，同侧时该核约为 $+1$，否则约为 -1。为促进所有特征上的决策校准，令 k_X 为 RBF 核。

结果。 表 3 表明，针对决策问题定制的 MMD 训练目标在所有数据集上实现最佳决策校准。附录 B.3 的额外结果表明，使用针对决策问题定制的 MMD 核（即 tanh 核），能够改善所有数据集的决策校准分数。

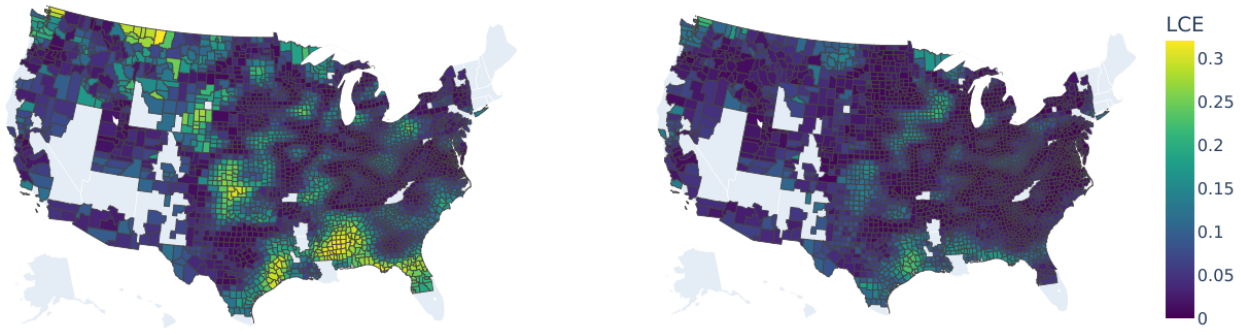
6.4 实验：局部校准

设置。 为直观说明所提度量如何促进特征局部邻域内的校准，我们在 CROP-YIELD 回归数据集上研究位置对预测可靠性的影响。针对地理空间邻域的局部校准，定制核 k_X, k_Y。具体而言，选择从完整输入向量 x 中提取地理特征（纬度、经度）的 $\phi(x)$。然后定义 $k_X(x, x') = k_{\text{RBF}}(\phi(x), \phi(x'))$ 和 $k_Y(y, y') = k_{\text{RBF}}(y, y')$。

指标。 扩展此前局部校准工作 [27]，给定 cdf 预测器 $Q_{Y|X}$、特征嵌入 $\phi(\cdot)$ 与核 k，定义回归的局部校准误差（LCE）：

$$\text{LCE}(x;\, c) = \frac{\sum_i \mathbf{1}\{y_i \le Q^{-1}_{Y|x_i}(c)\}\, k(\phi(x),\, \phi(x_i))}{\sum_i k(\phi(x),\, \phi(x_i))} - c.$$

总 LCE 为 $\text{LCE}_{\text{total}}(x) = \frac{1}{B}\sum_{i=1}^{B} \text{LCE}(x;\, c_i)^2$，其中 $c_i = i/B$。直观而言，LCE 度量由 $\phi(\cdot)$ 决定的局部区域中的 QCE。图 1 展示 $B = 20$ 的结果。



(a) NLL　　(b) Ours (NLL + MMD)

图 1。 对基于气候与地理数据预测年度小麦产量的预测器，可视化其局部校准误差。标准 NLL 目标（左）得到的预测器在局部地理邻域内失校准，较亮区域显示这一现象。基于核的校准目标（右）改善了局部邻域内的校准。图中文字：(a) NLL；(b) 本文（NLL + MMD）；色标 LCE=局部校准误差。

7 结论

本文提出一类灵活的可训练校准度量，基于利用 MMD 进行分布匹配。这些方法能与现有事后校准方法有效结合，在保持尖锐性的同时获得较强的校准保证。

局限性。 优化 MMD 要求来自预测的样本关于模型参数可微。这限制了适用的预测器族，但 Gumbel-softmax 等可微松弛能够缓解这一问题。此外，由于计算和数据限制，实践中常无法仅靠正则化达到零校准误差。为缓解这一限制，建议将校准正则项与事后校准方法配合使用。最后，MMD 的尺度对所选核敏感（例如 RBF 核的带宽），因此很难仅根据 MMD 从绝对意义上理解模型的校准程度。

8 致谢

CM 获得 NSF GRFP 支持。本研究部分获得 NSF（#1651565）、ARO（W911NF-21-1-0125）、ONR（N00014-23-1-2159）及 CZ Biohub 支持。

参考文献

为便于检索，作者、刊物／会议名称、卷页、DOI 与原文题名完整保留；每条另给出中文题名。

[1] Dry Bean Dataset. UCI Machine Learning Repository, 2020. DOI: https://doi.org/10.24432/C50S4B.

中文题名：干豆数据集。

[2] Barry Becker and Ronny Kohavi. Adult. UCI Machine Learning Repository, 1996. DOI: https://doi.org/10.24432/C5XW20.

中文题名：成年人数据集。

[3] James Bergstra, Rémi Bardenet, Yoshua Bengio, and Balázs Kégl. Algorithms for hyperparameter optimization. Advances in neural information processing systems, 24, 2011.

中文题名：超参数优化算法。

[4] Ondrej Bohdal, Yongxin Yang, and Timothy Hospedales. Meta-calibration: Learning of model calibration using differentiable expected calibration error. arXiv preprint arXiv:2106.09613, 2021.

中文题名：元校准：使用可微期望校准误差学习模型校准。

[5] Jochen Bröcker. Reliability, sufficiency, and the decomposition of proper scores. Quarterly Journal of the Royal Meteorological Society: A journal of the atmospheric sciences, applied meteorology and physical oceanography, 135(643):1512–1519, 2009.

中文题名：可靠性、充分性与恰当评分的分解。

[6] Krisztian Buza. Feedback prediction for blogs. In Data analysis, machine learning and knowledge discovery, pages 145–152. Springer, 2014.

中文题名：博客反馈预测。

[7] Joel W Cohen, Steven B Cohen, and Jessica S Banthin. The medical expenditure panel survey: a national information resource to support healthcare cost research and inform policy and practice. Medical care, pages S44–S50, 2009.

中文题名：医疗支出面板调查：支持医疗成本研究并为政策和实践提供信息的全国性信息资源。

[8] A Philip Dawid. The well-calibrated bayesian. Journal of the American Statistical Association, 77(379):605–610, 1982.

中文题名：良好校准的贝叶斯主义者。

[9] Morris H DeGroot and Stephen E Fienberg. The comparison and evaluation of forecasters. Journal of the Royal Statistical Society: Series D (The Statistician), 32(1-2):12–22, 1983.

中文题名：预测器的比较与评估。

[10] Cynthia Dwork, Michael P Kim, Omer Reingold, Guy N Rothblum, and Gal Yona. Outcome indistinguishability. In Proceedings of the 53rd Annual ACM SIGACT Symposium on Theory of Computing, pages 1095–1108, 2021.

中文题名：结果不可区分性。

[11] Tilmann Gneiting and Matthias Katzfuss. Probabilistic forecasting. Annual Review of Statistics and Its Application, 1:125–151, 2014.

中文题名：概率预测。

[12] Tilmann Gneiting and Roopesh Ranjan. Combining predictive distributions. Electronic Journal of Statistics, 7:1747–1782, 2013.

中文题名：组合预测分布。

[13] Tilmann Gneiting, Fadoua Balabdaoui, and Adrian E Raftery. Probabilistic forecasts, calibration and sharpness. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 69 (2):243–268, 2007.

中文题名：概率预测、校准与尖锐性。

[14] Arthur Gretton, Karsten M Borgwardt, Malte J Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. The Journal of Machine Learning Research, 13(1):723–773, 2012.

中文题名：核双样本检验。

[15] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q Weinberger. On calibration of modern neural networks. In International Conference on Machine Learning, pages 1321–1330. PMLR, 2017.

中文题名：现代神经网络的校准。

[16] Kam Hamidieh. Superconductivty Data. UCI Machine Learning Repository, 2018. DOI: https://doi.org/10.24432/C53P47.

中文题名：超导性数据。

[17] Ursula Hébert-Johnson, Michael Kim, Omer Reingold, and Guy Rothblum. Multicalibration: Calibration for the (computationally-identifiable) masses. In International Conference on Machine Learning, pages 1939–1948. PMLR, 2018.

中文题名：多重校准：为可计算识别的群体进行校准。

[18] Andras Janosi, William Steinbrunn, Matthias Pfisterer, and Robert Detrano. Heart Disease. UCI Machine Learning Repository, 1988. DOI: https://doi.org/10.24432/C52P4X.

中文题名：心脏病数据集。

[19] Archit Karandikar, Nicholas Cain, Dustin Tran, Balaji Lakshminarayanan, Jonathon Shlens, Michael C Mozer, and Becca Roelofs. Soft calibration objectives for neural networks. Advances in Neural Information Processing Systems, 34:29768–29779, 2021.

中文题名：神经网络的软校准目标。

[20] Jon Kleinberg, Sendhil Mullainathan, and Manish Raghavan. Inherent trade-offs in the fair determination of risk scores. arXiv preprint arXiv:1609.05807, 2016.

中文题名：风险评分公平确定中的内在权衡。

[21] Volodymyr Kuleshov and Stefano Ermon. Estimating uncertainty online against an adversary. In Thirty-First AAAI Conference on Artificial Intelligence, 2017.

中文题名：在线对抗不确定性估计。

[22] Volodymyr Kuleshov and Percy S Liang. Calibrated structured prediction. Advances in Neural Information Processing Systems, 28, 2015.

中文题名：校准的结构化预测。

[23] Volodymyr Kuleshov, Nathan Fenner, and Stefano Ermon. Accurate uncertainties for deep learning using calibrated regression. In International conference on machine learning, pages 2796–2804. PMLR, 2018.

中文题名：使用校准回归获得深度学习的准确不确定性。

[24] Meelis Kull and Peter Flach. Novel decompositions of proper scoring rules for classification: Score adjustment as precursor to calibration. In Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2015, Porto, Portugal, September 7-11, 2015, Proceedings, Part I 15, pages 68–85. Springer, 2015.

中文题名：分类恰当评分规则的新分解：作为校准前导步骤的评分调整。

[25] Meelis Kull, Telmo Silva Filho, and Peter Flach. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. In Artificial Intelligence and Statistics, pages 623–631. PMLR, 2017.

中文题名：Beta 校准：有理论基础且易于实现的二分类逻辑校准改进。

[26] Aviral Kumar, Sunita Sarawagi, and Ujjwal Jain. Trainable calibration measures for neural networks from kernel mean embeddings. In International Conference on Machine Learning, pages 2805–2814. PMLR, 2018.

中文题名：基于核均值嵌入的神经网络可训练校准度量。

[27] Rachel Luo, Aadyot Bhatnagar, Yu Bai, Shengjia Zhao, Huan Wang, Caiming Xiong, Silvio Savarese, Stefano Ermon, Edward Schmerling, and Marco Pavone. Local calibration: metrics and recalibration. In Uncertainty in Artificial Intelligence, pages 1286–1295. PMLR, 2022.

中文题名：局部校准：度量与再校准。

[28] Valery Manokhin. Multi-class probabilistic classification using inductive and cross venn–abers predictors. In Conformal and Probabilistic Prediction and Applications, pages 228–240. PMLR, 2017.

中文题名：使用归纳式和交叉 Venn–Abers 预测器进行多类概率分类。

[29] Charles Marx, Shengjia Zhao, Willie Neiswanger, and Stefano Ermon. Modular conformal calibration. In International Conference on Machine Learning, pages 15180–15195. PMLR, 2022.

中文题名：模块化共形校准。

[30] Alfred Müller. Integral probability metrics and their generating classes of functions. Advances in applied probability, 29(2):429–443, 1997.

中文题名：积分概率度量及其生成函数类。

[31] Allan H Murphy and Robert L Winkler. Reliability of subjective probability forecasts of precipitation and temperature. Journal of the Royal Statistical Society Series C: Applied Statistics, 26(1):41–47, 1977.

中文题名：降水与温度主观概率预测的可靠性。

[32] Mahdi Pakdaman Naeini, Gregory Cooper, and Milos Hauskrecht. Obtaining well calibrated probabilities using bayesian binning. In Proceedings of the AAAI conference on artificial intelligence, volume 29, 2015.

中文题名：使用贝叶斯分箱获得良好校准的概率。

[33] Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In Proceedings of the 22nd international conference on Machine learning, pages 625–632, 2005.

中文题名：利用监督学习预测良好的概率。

[34] United States. Bureau of the Census et al. Census of Population and Housing, 1990 [United States]: Summary Tape File 3A, Record Sequence Example File. 1992.

中文题名：1990 年美国人口与住房普查：汇总磁带文件 3A，记录序列示例文件。

[35] John Platt et al. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. Advances in large margin classifiers, 10(3):61–74, 1999.

中文题名：支持向量机的概率输出及其与正则化似然方法的比较。

[36] Geoff Pleiss, Manish Raghavan, Felix Wu, Jon Kleinberg, and Kilian Q Weinberger. On fairness and calibration. Advances in neural information processing systems, 30, 2017.

中文题名：公平性与校准。

[37] Teodora Popordanoska, Raphael Sayer, and Matthew Blaschko. A consistent and differentiable lp canonical calibration error estimator. Advances in Neural Information Processing Systems, 35:7933–7946, 2022.

中文题名：一致且可微的 lp 典范校准误差估计量。

[38] Mihaela Rosca, Balaji Lakshminarayanan, and Shakir Mohamed. Distribution matching in variational inference. arXiv preprint arXiv:1802.06847, 2018.

中文题名：变分推断中的分布匹配。

[39] Roshni Sahoo, Shengjia Zhao, Alyssa Chen, and Stefano Ermon. Reliable decisions with threshold calibration. Advances in Neural Information Processing Systems, 34, 2021.

中文题名：借助阈值校准实现可靠决策。

[40] C. Sakar and Yomi Kastro. Online Shoppers Purchasing Intention Dataset. UCI Machine Learning Repository, 2018. DOI: https://doi.org/10.24432/C5F88Q.

中文题名：网络购物者购买意向数据集。

[41] Kamaljot Singh, Ranjeet Kaur Sandhu, and Dinesh Kumar. Comment volume prediction using neural networks and decision trees. In IEEE UKSim-AMSS 17th International Conference on Computer Modelling and Simulation, UKSim2015 (UKSim2015), 2015.

中文题名：使用神经网络与决策树预测评论量。

[42] Hao Song, Tom Diethe, Meelis Kull, and Peter Flach. Distribution calibration for regression. In International Conference on Machine Learning, pages 5897–5906. PMLR, 2019.

中文题名：回归的分布校准。

[43] Zoltán Szabó and Bharath K Sriperumbudur. Characteristic and universal tensor product kernels. J. Mach. Learn. Res., 18(233):1–29, 2017.

中文题名：特征性与通用张量积核。

[44] Juozas Vaicenavicius, David Widmann, Carl Andersson, Fredrik Lindsten, Jacob Roll, and Thomas Schön. Evaluating model calibration in classification. In The 22nd International Conference on Artificial Intelligence and Statistics, pages 3459–3467. PMLR, 2019.

中文题名：评估分类中的模型校准。

[45] Vladimir Vovk, Ivan Petej, Paolo Toccaceli, Alexander Gammerman, Ernst Ahlberg, and Lars Carlsson. Conformal calibrators. In Conformal and probabilistic prediction and applications, pages 84–99. PMLR, 2020.

中文题名：共形校准器。

[46] David Widmann, Fredrik Lindsten, and Dave Zachariah. Calibration tests in multi-class classification: A unifying framework. Advances in Neural Information Processing Systems, 32, 2019.

中文题名：多类分类中的校准检验：统一框架。

[47] David Widmann, Fredrik Lindsten, and Dave Zachariah. Calibration tests beyond classification. arXiv preprint arXiv:2210.13355, 2022.

中文题名：超越分类的校准检验。

[48] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. Machine learning, 8:229–256, 1992.

中文题名：用于联结主义强化学习的简单统计梯度跟随算法。

[49] William Wolberg, Olvi Mangasarian, Nick Street, and W. Street. Breast Cancer Wisconsin (Diagnostic). UCI Machine Learning Repository, 1995. DOI: https://doi.org/10.24432/C5DW2B.

中文题名：威斯康星乳腺癌（诊断）数据集。

[50] Yunfeng Zhang, Q Vera Liao, and Rachel KE Bellamy. Effect of confidence and explanation on accuracy and trust calibration in ai-assisted decision making. In Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency, pages 295–305, 2020.

中文题名：置信度与解释对 AI 辅助决策中准确率和信任校准的影响。

[51] Shengjia Zhao, Tengyu Ma, and Stefano Ermon. Individual calibration with randomized forecasting. In International Conference on Machine Learning, pages 11387–11397. PMLR, 2020.

中文题名：采用随机化预测的个体校准。

[52] Shengjia Zhao, Michael Kim, Roshni Sahoo, Tengyu Ma, and Stefano Ermon. Calibrating predictions to decisions: A novel approach to multi-class calibration. Advances in Neural Information Processing Systems, 34, 2021.

中文题名：将预测校准到决策：多类校准的新方法。

[53] Johanna F Ziegel and Tilmann Gneiting. Copula calibration. 2014.

中文题名：Copula 校准。

附录 A 将常见校准形式表达为分布匹配

A.1 回归中的校准

这里展示如何将表 1 中的校准形式表述为条件分布匹配。注意，其中许多形式在分类中同样合理（例如边缘、群体与决策校准）。

分位数校准。 设 Y 为连续随机变量。当下式成立时，预测器是分位数校准的：

$$\mathbb{P}\left(Q_{Y|X}(Y) \leq t\right) = t, \quad \forall t \in [0,1]. \tag{6}$$

这等价于 $Q_{Y|X}(Y)$ 在区间 $[0,\ 1]$ 上服从均匀分布。对于连续随机变量，概率积分变换 $P_{Y|X}(Y)$ 在 $[0,\ 1]$ 上均匀分布。因此分位数校准可写为 $Q_{Y|X}(Y) \triangleq P_{Y|X}(Y)$，其中 $\triangleq$ 表示同分布。

阈值校准。 设 Y 是连续随机变量。若对所有 $t \in [0,\ 1]$、$c \in [0,\ 1]$ 和 $y \in \mathcal{Y}$，均有 $\mathbb{P}\left(Q_{Y|X}(Y) \leq t \mid Q_{Y|X}(y) \leq c\right) = t$，则预测器满足阈值校准 [39]。这表示在事件 $Q_{Y|X}(y) \leq c$ 的条件下，$Q_{Y|X}(Y)$ 均匀分布。注意 $P_{Y|X}(Y)$ 也均匀分布，因此该约束等价于：

$$Q_{Y|X}(Y) \triangleq P_{Y|X}(Y) \mid \mathbb{1}\left\{Q_{Y|X}(y) \leq c\right\}, \quad \forall c \in [0,1], y \in \mathcal{Y} \tag{7}$$

边缘校准。 若对所有 $y \in \mathcal{Y}$ 均有 $\mathbb{E}\left[Q_{Y|X}(y)\right] = P_Y(y)$，则预测器满足边缘校准 [11]。 $\widehat{Y}$ 的分布由 $(\widehat{Y} \mid X = x) \sim Q_{Y|x}$ 定义，故其边缘分布为 $\widehat{Y} \sim \mathbb{E}\left[Q_{Y|X}\right]$。因此，边缘校准表示 $\widehat{Y}$ 与 Y 具有相同边缘 cdf，等价于 $\widehat{Y} \triangleq Y$。

决策校准。 Zhao 等 [52] 为多类分类引入 $\mathcal{L}^K$ 决策校准的概念，其中 $\mathcal{Y} = \{0, 1\}^C$ 表示 C 个类别的独热向量集合。

定义 A.1（ $\mathcal{L}^K$ 决策校准，Zhao 等 [52]）。 令 $\mathcal{L}^K = \{\ell : \mathcal{Y} \times \mathcal{A} \to \mathbb{R}, |\mathcal{A}| = K\}$ 为具有 K 个动作的所有损失函数的集合。如果对所有 $\ell \in \mathcal{L}^K$ 和 $\delta \in \Delta_{\mathcal{L}^K}$，均有

$$\mathbb{E}_X \mathbb{E}_{\widehat{Y} \sim Q_{Y|X}}[\ell(\widehat{Y}, \delta(Q_{Y|X}))] = \mathbb{E}_X \mathbb{E}_{Y \sim P_{Y|X}}[\ell(Y, \delta(Q_{Y|X}))] \tag{8}$$

则称预测 $Q_{Y|X}$ 相对于 $P_{Y|X}$ 满足 $\mathcal{L}^K$ 决策校准。其中 $\Delta_{\mathcal{L}^K}$ 是具有 K 个动作的损失函数的所有贝叶斯决策规则集合。

他们证明， $\mathcal{L}^K$ 决策校准可等价表示为：对所有 $\delta \in \Delta_{\mathcal{L}^K}$，要求 $\mathbb{E}\left[(\widehat{Y} - Y)\mathbf{1}\{\delta\left(Q_{Y|X}\right) = a\}\right] = 0$。可将其改写为

$$\mathbb{E}[\widehat{Y} | \delta(Q_{Y|X}) = a] = \mathbb{E}[Y | \delta(Q_{Y|X}) = a], \quad \forall \delta \in \Delta_{\mathcal{L}^K}, a \in \mathcal{A} \tag{9}$$

注意，由于 Y 采用独热表示， $\mathbb{E}\left[Y \mid \delta\left(Q_{Y|X}\right) = a\right]$ 给出了 $\left(Y \mid \delta\left(Q_{Y|X}\right) = a\right)$ 的条件分布。因此，等价地要求

$$\left(\widehat{Y} \triangleq Y\right) \mid \delta(Q_{Y|X}), \quad \forall \delta \in \Delta_{\mathcal{L}^K} \tag{10}$$

其中 $\triangleq$ 表示同分布。

群体校准。 群体校准 [20] 指预测对每个子群（例如按性别或年龄定义的群体）均满足边缘校准。可写作 $\widehat{Y} \triangleq Y \mid \text{Group}(X)$，其中 Group(X) 是表示特征向量 X 所属子群的变量。

分布校准。 若对所有可能预测 Q_0 与标签 $y \in \mathcal{Y}$，均有 $\mathbb{P}\left(Y \leq y \mid Q_{Y|X} = Q_0\right) = Q_0(y)$，则预测器满足分布校准 [42]。原文将这等价地写作：对所有 $y \in \mathcal{Y}$， $P_{Y|X}(y) \mid Q_{Y|X} = Q_{Y|X}(y)$。由于 cdf 在所有 $y \in \mathcal{Y}$ 处取值相同，随机变量 Y 与 $\widehat{Y}$ 具有相同分布，即 $\widehat{Y} \triangleq Y \mid Q_{Y|X}$。

个体校准。 设 Y 是实值连续随机变量。个体校准 [51] 表示：对所有 $t \in [0, 1]$ 和 $x \in \mathcal{X}$，均有 $\mathbb{P}\left(Q_{Y|x}(Y) \leq t\right) = t$。令 $U \sim \text{Unif}(0, 1)$，则可写为如下连续四步：

$$Q_{Y|X}(Y) \triangleq P_{Y|X}(Y) \mid X \tag{11}$$

$$Q^{-1}_{Y|X}(Q_{Y|X}(Y)) \triangleq Q^{-1}_{Y|X}(P_{Y|X}(Y)) \mid X \tag{12}$$

$$Y \triangleq Q^{-1}_{Y|X}(U) \mid X \tag{13}$$

$$Y \triangleq \widehat{Y} \mid X \tag{14}$$

局部校准。 如果在特征空间的任一邻域内， $Q_{Y|X}$ 和 $P_{Y|X}$ 平均而言相同，则预测器满足局部校准 [27]。特征空间的相似度由核 $k(x, x')$ 定义。在回归中，分位数局部校准表示：

$$\frac{\mathbb{E}[\mathbb{1}\left\{Q_{Y|X}(Y) \leq t\right\} k(X,x)]}{\mathbb{E}[k(X,x)]} = t, \quad \forall t \in [0,1], x \in \mathcal{X}. \tag{15}$$

等价地可以写为

$$\mathbb{E}[\mathbb{1}\left\{Q_{Y|X}(Y) \leq t\right\} k(X,x)] = \mathbb{E}[\mathbb{1}\left\{P_{Y|X}(Y) \leq t\right\} k(X,x)], \quad \forall t \in [0,1], x \in \mathcal{X} \tag{16}$$

或者用典范特征映射表示为

$$\mathbb{E}[\mathbb{1}\left\{Q_{Y|X}(Y) \leq t\right\} \langle \phi(X), \phi(x) \rangle] = \mathbb{E}[\mathbb{1}\left\{P_{Y|X}(Y) \leq t\right\} \langle \phi(X), \phi(x) \rangle], \quad \forall t \in [0,1], x \in \mathcal{X}. \tag{17}$$

因此，只需使 $\mathbb{E}\left[Q_{Y|X}\right]$ 与 $\mathbb{E}\left[P_{Y|X}\right]$ 在给定特征映射 $\phi(X)$ 后具有相同分布。可简写为

$$Y \triangleq \widehat{Y} \mid \phi(X) \tag{18}$$

A.2 分类中的校准

这里将分类文献中的三种常用校准形式，即典范、最高标签与边缘校准 [44，式（1—3）]，表达为分布匹配约束。本节中，Y 始终是取值于 $\mathcal{Y} = \{1, 2, \ldots, m\}$ 的离散随机变量，$q_{Y|X}$ 是给定特征 $X = x$ 后预测的概率质量函数。

典范校准。若对所有 $y \in \mathcal{Y}$，均有 $\mathbb{P}\left(Y = y \mid q_{Y|X}\right) = q_{Y|X}(y)$，则预测器满足典范校准。这表示，给定 $q_{Y|X}$ 后，标签在预测与真实分布下服从同一分布。换言之，$Y \triangleq \widehat{Y} \mid q_{Y|X}$。

最高标签校准。若 $\mathbb{P}\left(Y = Y^* \mid q_{Y|X}\left(Y^*\right)\right) = q_{Y|X}\left(Y^*\right)$，则预测器满足最高标签校准，其中 $Y^* := \operatorname{argmax}_{y \in \mathcal{Y}} q_{Y|X}(y)$ 是预测分布的众数。可用指示变量将该式改写为

$$\mathbb{E}\left[\mathbb{1}\left\{Y = Y^*\right\} \mid q_{Y|X}(Y^*)\right] = \mathbb{E}\left[\mathbb{1}\{\widehat{Y} = Y^*\} \mid q_{Y|X}(Y^*)\right]$$

指示变量的期望相等，当且仅当其分布相等。因此最高标签校准等价于 $\mathbf{1}\{Y = Y^*\} \triangleq \mathbf{1}\{\widehat{Y} = Y^*\} \mid q_{Y|X}\left(Y^*\right)$。

边缘校准。若对所有 $y \in \mathcal{Y}$，均有 $\mathbb{P}\left(Y = y \mid q_{Y|X}(y)\right) = q_{Y|X}(y)$，则预测器满足边缘校准。与最高标签校准类似，可写成

$$\mathbb{E}\left[\mathbb{1}\left\{Y = y\right\} \mid q_{Y|X}(y)\right] = \mathbb{E}\left[\mathbb{1}\{\widehat{Y} = y\} \mid q_{Y|X}(y)\right]$$

指示变量的期望相等，当且仅当其分布相等。因此边缘校准可写为 $\mathbf{1}\{Y = y\} \triangleq \mathbf{1}\{\widehat{Y} = y\} \mid q_{Y|X}(y)$，对所有 $y \in \mathcal{Y}$ 成立。

附录 B 实验设置与额外结果

B.1 可复现性

为了复现本文实验与结果，以下给出超参数调优及计算资源需求的细节。

超参数搜索。 使用 TPES [3] 进行超参数优化。所有实验均改变以下参数：

- 层宽在 32 至 512 之间。
- RBF 核带宽在 0.001 至 200 之间。
- 批次大小在 16 至 512 之间，分别测试使用和不使用批归一化。
- 学习率在 10^{-7} 至 10^{-1} 之间。
- 损失混合权重 λ（如 NLL + $\lambda\cdot$ MMD、XE + $\lambda\cdot$ MMD）在 0.1 至 1000 之间。

对每个数据集，为回归目标集合 {NLL，NLL + MMD} 和分类目标集合 {XE，XE + MMCE，XE + KDE，XE + MMD} 中的每个训练目标测试 100 种超参数配置。每次运行中，若验证损失连续超过 50 轮未改善，则提前停止。回归中根据验证 NLL 选择最佳运行；分类中根据验证准确率选择最佳运行，并用验证 ECE 打破平局。对每种模型和数据集，将最佳模型用 50 个随机种子重新运行，收集标准误与统计显著性信息。为反映不同种子之间的变动，表 3、4、5 报告均值的标准误。

核带宽。 采用上述超参数优化，为每个数据集选择训练用 RBF 核带宽。对于表 4、5 中每个数据集，报告的 KDE 指标使用留出验证集选择的带宽，并进行缩放，使跨数据集的误差量级可比（因为将核乘以正标量保持核的性质）。

基线。 分类中，将本文方法与两种先进的可训练校准方法 MMCE [26] 和 KDE [37] 比较。对 MMCE，遵循作者官方实现的相同实验设置，用留出验证集选择混合权重 λ 和拉普拉斯核带宽。对 KDE，使用 ECE KDE 估计量计算 L_1 典范校准，按 Popordanoska 等 [37] 的式（9）计算。遵循作者官方实现的设置，通过留一似然（LOO MLE）选择核带宽，通过留出验证集选择损失混合权重 λ。

计算需求。 所有实验均在一台 CPU 机器上完成：Intel(R) Xeon(R) Gold 6342 CPU @ 2.80GHz，每项实验使用 8 核。CPU 上单模型训练依数据集大小需要 5—15 分钟，采用该配置约 24 小时可完成一次完整超参数扫描。

为加速训练，还使用一块 11GB NVIDIA GeForce GTX 1080 Ti 进行了部分实验。GPU 上单模型训练依数据集大小需要 2—5 分钟，超参数扫描约需 10 小时。

美国农业数据集。 引入新的 CROP-YIELD 数据集，用美国不同县的地理气象数据预测每年小麦产量。NOAA 数据库包含美国数千个气象站的天气数据。对每个县，将每年的天气序列归纳为每月若干汇总统计量（平均／最高／最低温度、降水、制冷／采暖度日）。为研究气候变化与位置如何影响作物产量，将 NASS 数据集中的产量数据与 NOAA 数据库的气象站匹配，学习从天气数据预测产量的函数。具体考虑美国各县 1990—2007 年的小麦产量。由于 1995 年产量数据最不稀疏，保留该年数据用于可视化，其余数据用于训练预测器。

B.2 额外实验结果

表 5。 分类任务性能：比较 MMCE 正则化 [26]、KDE 正则化 [37]、MMD 正则化（本文）及标准交叉熵（XE）损失。全部方法均使用温度缩放进行事后再校准。 n, d, m 分别为数据集样本数、特征数及类别数。

Dataset	Training Objective **with Temp. Scaling**	Accuracy ↑	ECE ↓	Entropy ↓	KCE ↓
BREAST-CANCER	XE	95.372 ± 0.160	0.105 ± 0.031	0.056 ± 0.007	0.028 ± 0.005
$n = 569$	XE + MMCE	94.770 ± 0.147	**0.052 ± 0.001**	0.011 ± 0.001	**0.019 ± 0.000**
$d = 30$	XE + ECE KDE	94.351 ± 0.163	0.074 ± 0.018	0.010 ± 0.001	0.022 ± 0.003
$m = 2$	XE + MMD (*Ours*)	**95.789 ± 0.060**	**0.052 ± 0.000**	**0.004 ± 0.000**	**0.019 ± 0.000**
HEART-DISEASE	XE	55.904 ± 0.196	0.325 ± 0.003	1.116 ± 0.008	0.077 ± 0.000
$n = 921$	XE + MMCE	60.787 ± 0.208	0.262 ± 0.002	0.927 ± 0.004	0.067 ± 0.000
$d = 23$	XE + ECE KDE	50.036 ± 2.801	0.276 ± 0.011	1.192 ± 0.033	0.082 ± 0.002
$m = 5$	XE + MMD (*Ours*)	**61.516 ± 0.255**	**0.252 ± 0.003**	**0.860 ± 0.003**	**0.066 ± 0.000**
ONLINE-SHOPPERS	XE	89.816 ± 0.037	0.130 ± 0.000	0.227 ± 0.001	**0.050 ± 0.000**
$n = 12330$	XE + MMCE	89.933 ± 0.036	0.128 ± 0.000	0.220 ± 0.000	0.051 ± 0.000
$d = 28$	XE + ECE KDE	**90.019 ± 0.034**	0.125 ± 0.000	0.216 ± 0.001	**0.050 ± 0.000**
$m = 2$	XE + MMD (*Ours*)	89.976 ± 0.031	**0.126 ± 0.000**	**0.214 ± 0.001**	**0.050 ± 0.000**
DRY-BEAN	XE	92.071 ± 0.025	0.102 ± 0.000	0.206 ± 0.001	**0.011 ± 0.000**
$n = 13612$	XE + MMCE	92.772 ± 0.035	0.092 ± 0.000	0.188 ± 0.001	**0.011 ± 0.000**
$d = 16$	XE + ECE KDE	92.760 ± 0.037	0.091 ± 0.000	0.190 ± 0.000	**0.011 ± 0.000**
$m = 7$	XE + MMD (*Ours*)	**92.894 ± 0.035**	**0.086 ± 0.000**	**0.187 ± 0.001**	**0.011 ± 0.000**
ADULT	XE	84.528 ± 0.040	0.188 ± 0.000	**0.330 ± 0.000**	0.022 ± 0.000
$n = 32561$	XE + MMCE	84.203 ± 0.042	0.190 ± 0.000	0.335 ± 0.000	0.022 ± 0.000
$d = 104$	XE + ECE KDE	84.187 ± 0.045	0.177 ± 0.001	0.338 ± 0.001	0.023 ± 0.000
$m = 2$	XE + MMD (*Ours*)	**84.565 ± 0.035**	**0.174 ± 0.000**	0.334 ± 0.000	**0.020 ± 0.000**

列名：数据集、带温度缩放的训练目标、准确率（↑）、ECE（↓）、熵（↓）、KCE（↓）。Ours=本文；各数据集中文名称与缩写含义同表 4。全部数值与标准误按原表保留。

表 6。 回归任务中性能随每次预测用于代入式 MMD 估计的模拟样本数的变化。所有其他超参数固定，包括训练步数。增加样本数能够更好地估计 MMD 目标，通常改善性能，但会增加计算量。

	CRIME			BLOG			MEDICAL-EXPENDITURE		
# Samples	NLL	QCE	DCE	NLL	QCE	DCE	NLL	QCE	DCE
1	-0.703	0.198	0.088	0.952	0.379	4.171	1.546	0.071	0.448
2	-0.755	0.188	0.133	0.959	0.444	4.228	1.535	0.07	0.427
5	-0.72	0.154	0.043	0.96	0.395	4.09	1.539	0.071	**0.419**
10	-0.777	0.154	0.06	0.85	0.416	4.077	1.54	0.072	0.459
20	-0.772	0.157	0.054	0.835	0.415	4.031	1.538	**0.063**	0.431
50	-0.779	**0.150**	**0.041**	0.847	0.432	4.016	**1.531**	0.065	0.447
100	-0.781	0.153	0.043	**0.829**	0.386	**3.978**	1.536	0.064	0.449
200	**-0.782**	0.151	0.043	**0.829**	**0.373**	**3.978**	1.535	0.064	0.442

	SUPERCONDUCTIVITY			FB-COMMENT		
# Samples	NLL	QCE	DCE	NLL	QCE	DCE
1	3.369	0.053	0.182	0.637	0.268	3.15
2	3.35	0.062	0.197	0.477	0.294	3.14
5	3.311	0.038	0.216	**0.409**	0.276	3.146
10	3.333	0.036	0.208	0.59	0.278	**3.102**
20	3.298	0.055	0.262	0.569	0.258	3.119
50	3.345	0.041	0.208	0.479	**0.223**	3.14
100	3.318	0.036	**0.181**	0.469	0.23	3.149
200	**3.291**	**0.034**	0.182	0.458	0.231	3.137

表中 # Samples=样本数；NLL=负对数似然；QCE=分位数校准误差；DCE=决策校准误差。上半表数据集为犯罪、博客、医疗支出，下半表为超导性、脸书评论。表内全部数值保留。

B.3 实验：决策校准

为示例说明可训练校准度量如何改善特定决策问题的校准，考虑一个常见现实决策问题：需要采取动作，其效用只取决于标签 y 大于还是小于特定阈值 c。具体而言，对动作 $a \in \{-1, +1\}$ 与标签 $y \in \mathcal{Y}$，决策损失 $\ell : \mathcal{A} \times \mathcal{Y} \to \mathbb{R}$ 定义为 $\ell(a, y) = \mathbf{1}\{a \neq \operatorname{sign}(y - c)\}$。

设置。 为实现决策校准，定制核 k_X, k_Y 以紧密对应决策问题。具体而言，使用对阈值 c 错误一侧的预测标签施加惩罚的核：$k_Y(y, y') = \tanh(y - c)\tanh(y' - c)$。原文指出，同侧时 $k_Y(y, y') \approx +1$，否则约为 -1。因此，校准度量为模型提供与决策问题高度一致的训练反馈。为鼓励所有特征上的决策校准，将 k_X 设为通用 RBF 核。

作为本实验的一部分，研究针对决策问题定制 MMD 核，是否比对 k_X, k_Y 均使用通用 RBF 核更能改善决策校准。

指标。 为评估方法效果，在全部回归数据集上计算标准决策校准误差 DCE，定义为

$$\mathrm{DCE}^2 = \sum_{a \in \mathcal{A}} \left\| \mathbb{E}_P[\ell(Y, a)] - \mathbb{E}_X \mathbb{E}_{\widehat{Y} \sim Q_{Y|X}}[\ell(\widehat{Y}, a)] \right\|_2^2, \tag{19}$$

其中 P 是 $\mathcal{X} \times \mathcal{Y}$ 上的真实分布，$Q_{Y|X}$ 为预测器。

额外结果：核的选择。 给出两组结果。第一组见表 7，比较以本文 NLL + MMD 目标训练的模型：一个采用为决策问题定制的 k_Y（tanh），另一个使用通用 RBF 核。如第 6.3 节所述，使用 tanh 核在所有数据集上明显实现更好的决策校准，同时尖锐性（即 NLL）几乎没有降低。这说明，通过使核紧密对应决策问题，可以利用可训练校准度量改善决策校准。

第二组结果见图 2，进一步展示模型训练期间可训练校准度量与决策校准的关系。使核紧密对应决策问题后，可观察到决策校准在整个训练过程中被优化。相反，与决策问题无关的目标（即 NLL，或使用 RBF 核的 MMD）带来明显更差的决策校准，训练中几乎没有改善。留出验证集上也有相同趋势，如图 3 所示。

Dataset	**Kernel** (k_Y)	NLL ↓	Decision Cal. ↓
CRIME	RBF	**-0.778 ± 0.008**	0.042 ± 0.011
$(n = 1992, d = 102)$	tanh	-0.657 ± 0.010	**0.027 ± 0.006**
BLOG	RBF	0.957 ± 0.008	4.051 ± 0.002
$(n = 52397, d = 280)$	tanh	**0.934 ± 0.007**	**3.052 ± 0.001**
MEDICAL-EXPENDITURE	RBF	**1.530 ± 0.000**	0.447 ± 0.002
$(n = 33005, d = 107)$	tanh	1.532 ± 0.000	**0.438 ± 0.002**
SUPERCONDUCTIVITY	RBF	**3.269 ± 0.012**	0.182 ± 0.003
$(n = 21264, d = 81)$	tanh	3.311 ± 0.009	**0.127 ± 0.003**
FB-COMMENT	RBF	0.605 ± 0.004	3.131 ± 0.003
$(n = 40949, d = 53)$	tanh	**0.598 ± 0.003**	**2.342 ± 0.003**

表 7。 使用本文训练目标 NLL + MMD、但在 MMD 中对 k_Y 采用不同核时的模型性能比较。RBF 是常用通用核，tanh 则专门匹配决策任务以实现决策校准。所有指标在测试集上报告。表内列名：数据集、核 k_Y、NLL（↓）、决策校准误差（↓）。数据集、数值、标准误均保留。

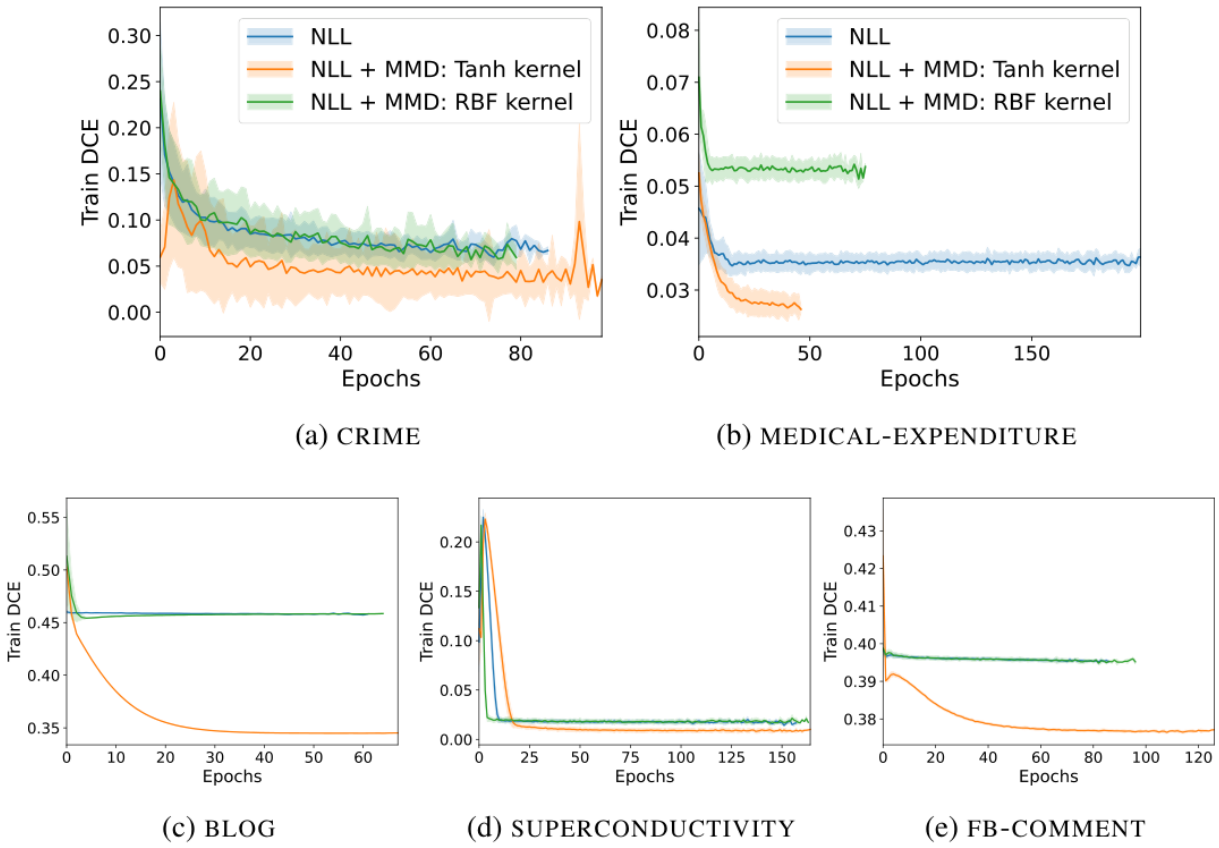


图 2。 高斯预测器使用不同目标训练时，在整个训练过程中对训练数据评估的决策校准误差（DCE）。本文方法通过为具体决策问题定制核，在所有数据集上获得优于基线的 DCE。使用本文方法时，DCE 在整个训练期间持续改善。误差条表示 50 次随机试验计算的标准差。图例：NLL；NLL + MMD：Tanh 核；NLL + MMD：RBF 核。横轴 Epochs=训练轮数；纵轴 Train DCE=训练集决策校准误差。子图 (a) 犯罪、(b) 医疗支出、(c) 博客、(d) 超导性、(e) 脸书评论。

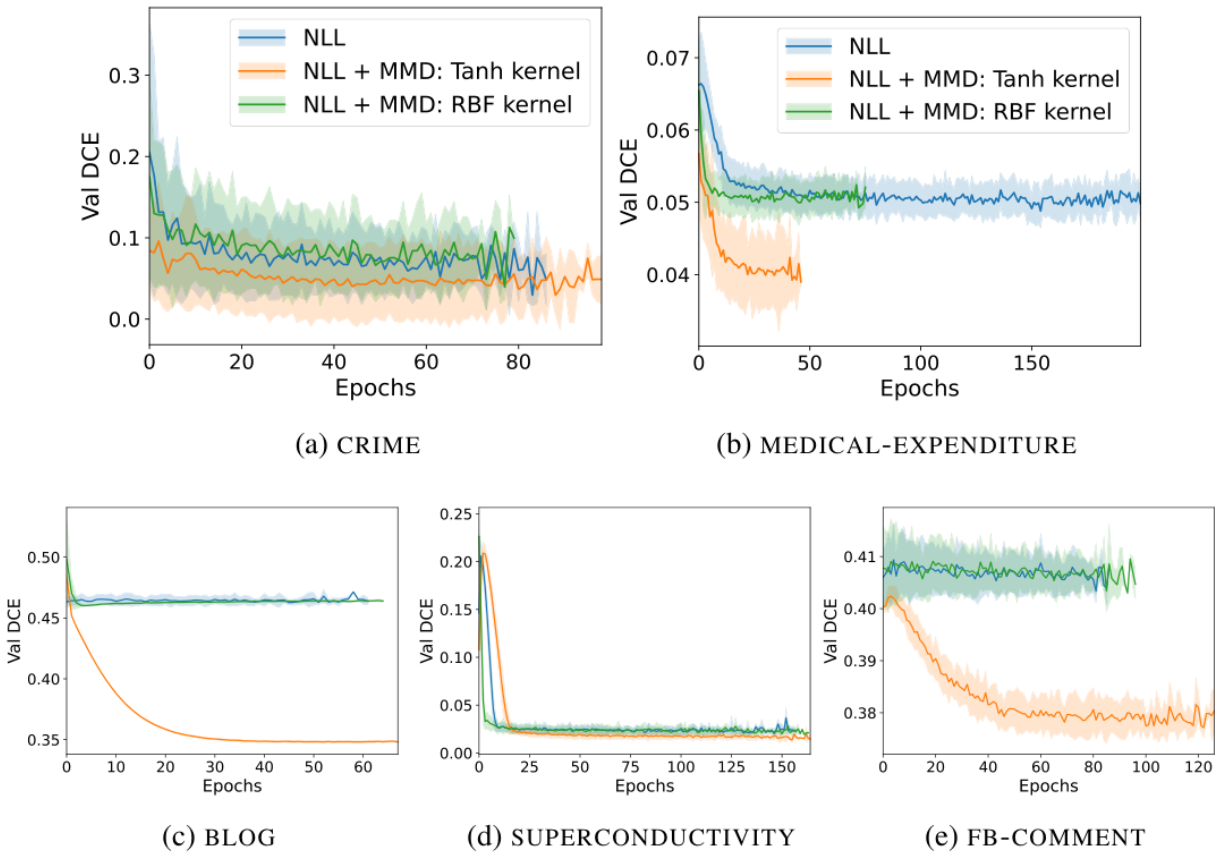


图 3。 在整个训练过程中对留出的验证数据评估的决策校准误差（DCE）。本文方法通过针对特定决策问题定制核，在所有数据集上获得优于基线的 DCE。误差条表示 50 次随机试验计算的标准差。图例与子图数据集对应关系同图 2；横轴 Epochs=训练轮数，纵轴 Val DCE=验证集决策校准误差。

译者说明：版本、保真与原文疑点

本译文覆盖所存 arXiv v1 PDF 的全部 19 页：摘要、正文 1—8 节、53 条参考文献、附录 A.1—A.2 和 B.1—B.3、7 张表、3 幅图、编号公式（1）—（19）及非编号公式。公式裁图保留原版字形、上下标、帽号、括号及编号，避免重排引入含义变化；数据表原值与正负号完整保留，并附完整中文表头／术语对照。书目原文保留用于检索，另译全部题名。

以下为原文自身存在的疑点，并非译文新增结论：第 3 节以“超过分位数的频率为 c”表述分位数校准，而附录式（6）采用 cdf 方向；第 5 节例 1 的 MMD 是否平方的记号与式（2）不一致；例 2 的指示函数 $\mathbf{1}\{y \geq t\}$ 的均值通常对应生存函数而非 cdf，但两个分布之差的平方积分仍相同；第 6.3 节与附录 B.3 关于 tanh 核的原文条件把第二个 y' 误写成 y，正文译为“同侧”以说明其语义，并在此披露；DCE 公式使用 $\ell(Y, a)$ 的参数次序，而前文定义为 $\ell(a, y)$，原编号公式按版面保留。第 5 节原文例 2 将二元动作称为“阈值”，译文以“选择 a”避免改变数学定义。原文表 3 与表 7 的个别结果和正文对核选择的叙述不完全一致，均保留原样，不代作者修订。