用于增强多模态学习的分类器引导梯度调制

非官方中文全文译文 · P114 / CGGM

原题：Classifier-guided Gradient Modulation for Enhanced Multimodal Learning

作者：Zirun Guo[1,2]、Tao Jin[1] †、Jingyuan Chen[1]、Zhou Zhao[1,2]。[1]浙江大学；[2]上海人工智能实验室。电子邮件：zrguo.cs@gmail.com。†通讯作者。

原文会议标识：第38届神经信息处理系统会议（NeurIPS 2024）。本译文严格以 **arXiv:2411.01409v1，2024年11月3日** 为底本，不以仓库中未另行核实许可的会议版为底本。来源：https://arxiv.org/abs/2411.01409v1 。原作许可：CC BY 4.0。中文翻译与重新排版属于改编；图表及附录矩阵公式裁自该许可版本，保留原始数值与标记，另附中文说明。本中文改编同样按 CC BY 4.0 提供。译文非作者官方版本，不代表作者认可。原文的主张、符号与可能的不一致均予保留；译者说明明确标出。

摘要

近年来，多模态学习发展迅速。然而，在多模态训练过程中，模型往往只依赖能够使其学得更快的一种模态，因而对其他模态利用不足。现有用于平衡训练过程的方法，总是在损失函数、优化器和模态数量方面存在一定限制，而且只考虑调制梯度的幅值，忽略了梯度方向。为解决这些问题，本文提出一种通过**分类器引导梯度调制（Classifier-Guided Gradient Modulation，CGGM）**来平衡多模态学习的新方法，同时考虑梯度的幅值和方向。我们在 UPMC-Food 101、CMU-MOSI、IEMOCAP 和 BraTS 2021 四个多模态数据集上开展了大量实验，涵盖分类、回归和分割任务。结果表明，CGGM 始终优于所有基线及其他最先进的方法，证明了其有效性和通用性。代码见 https://github.com/zrguo/CGGM 。

1 引言

人类通过视觉、触觉和声音等多模态方式感知世界。这些多模态特征能够提供全面信息，帮助我们理解和探索环境。近年来，多模态学习在视觉问答[2]、多模态情感分析[18]和多模态检索[26,13]等领域取得了巨大成功。

尽管近年来多模态学习取得了显著进展，但训练过程中对不同模态信息利用不足仍然是一项挑战。在理论方面，例如 Wu 等人[25]提出了贪婪学习者假设：多模态模型会学会依赖某个能让其学习更快的输入模态，并且不再继续学习利用其他模态。Huang 等人[12]发现，在联合训练期间，多种模态会相互竞争，一些模态会在竞争中失败。在实验方面，某些多模态数据集上，仅用一种模态训练与使用全部模态训练之间的准确率提升很小[18,21]。这些理论分析和实验结果表明，多模态学习在充分利用和整合不同模态信息方面效率不高。

为处理这一问题，近期研究[25,17,15,8,28,9]考察了多模态学习的训练过程，并提出梯度调制策略，以便在某些情况下更好地整合不同模态信息并平衡训练过程。然而，由于一些限制，这些方法都不易直接应用。例如，Wu 等人[25]、Peng 等人[17]、Li 等人[15]和 Hua 等人[11]提出了针对分类任务、基于交

叉熵损失的平衡方法。对于回归任务或其他任务，我们无法使用这些策略。此外，多数方法只能处理仅有两种模态的情况。例如，Wu 等人[25]提出的条件学习速度，在模态超过两种时难以计算和使用。这些方法无法用于模态更多的情况。此外，多数方法只考虑调制梯度幅值，忽略梯度方向。

基于以上观察，本文提出通过分类器引导梯度调制（CGGM）平衡多模态学习的新方法。在 CGGM 中，我们考虑更一般的情况，不限制任务类型、优化器、模态数量等。此外，我们同时考虑梯度幅值和方向，以充分促进多模态学习的训练过程。具体来说，我们加入分类器，评估各模态的利用率并获得单模态梯度。然后，利用该利用率自适应地调制编码器梯度幅值，并使用单模态梯度引导模型朝更好的方向优化。

我们在 UPMC-Food 101[23]、CMU-MOSI[27]、IEMOCAP[3]和 BraTS 2021[1]四个多模态数据集上开展大量实验。UPMC-Food 101 和 IEMOCAP 属于分类任务，CMU-MOSI 属于回归任务，BraTS 2021 属于分割任务。CGGM 优于全部基线及其他最先进方法，证明了其有效性与普适性。概括而言，我们的贡献如下：

- 提出 CGGM，同时考虑梯度的幅值和方向，以平衡多模态学习。
- CGGM 能够容易地应用于多种多模态任务和网络，不限制任务类型、优化器、模态数量等，体现了其通用性。
- 所提出的 CGGM 在包括分类、回归、分割在内的各种任务上带来一致提升。大量实验表明，CGGM 优于其他最先进的方法，证明了其有效性。

2 相关工作

多模态学习。 多模态学习的一项主要挑战，是如何有效利用和整合不同模态的信息，使其相互补充。按融合策略划分，主要有三类多模态融合策略：早期融合、中间融合和晚期融合。在早期融合方法[16,24]中，不同模态的原始数据在输入模型之前，通过拼接或其他方式在输入层面合并。中间融合方法[14]在模型架构内的不同中间处理阶段合并各模态数据。晚期融合方法[2,18]通过独立模型分别处理各模态数据，再在较晚阶段合并。总体而言，晚期融合是多模态学习中占主导地位的方法。主要原因[14]是，多年来各单模态分支的架构经过精心设计，已能在各模态上达到最先进性能。因此，我们可以利用这些预训练模型[5,6]取得更好的结果。所以，本文方法以晚期融合为基础。

这些融合策略能有效整合不同模态的信息，但在利用不同模态信息实现互补方面的提升有限。换言之，它们无法处理模态竞争[12]或不平衡多模态学习。当占主导地位的模态缺失[10]或遭到破坏时，性能会显著下降。与这些融合策略不同，我们的方法旨在相对充分地利用每种模态的信息，并解决多模态学习不平衡问题。

平衡多模态学习。 无法高效地充分利用和整合多模态信息，是多模态学习领域的一大挑战。一些研究[18,21]指出，仅用一种模态训练与使用全部模态训练之间的准确率提升很小。Wang 等人[22]表明，使用多种模态的多模态模型甚至可能不如仅使用一种模态的模型。为平衡多模态学习过程、充分利用不同模态，研究者提出了一系列平衡多模态学习方法[25,17,15,8,28,9,7,11]。Wu 等人[25]提出条件学习速度，以刻画模态之间的相对学习速度并平衡学习过程。Peng 等人[17]提出梯度调制策略，通过监测各模态对学习目标贡献的差异，自适应地控制每种模态的优化。最近，Fan 等人[8]提出原型式模态再平衡策略，为不同模态引入不同学习策略。Li 等人[15]提出自适应梯度调制方法，可提升采用不同融合策略的多模态模型性能。Hua 等人[11]利用与历史模型竞争的协调正则项，动态调整学习目标。

然而，这些既有研究都存在一定限制，只能用于特定情况。例如，Wu 等人[25]基于中间融合策略提出条件学习速度，因而难以用于模态超过两种或网络不采用中间融合的情况。Peng 等人[17]、Fan 等人[8]、Fu 等人[9]、Li 等人[15]和 Hua 等人[11]提出的平衡策略，主要针对分类任务，以交叉熵损失函数为假设。特别地，Peng 等人[17]使用 SGD 优化器。与这些方法不同，我们考虑更一般的情况，不对模态数量、优化器、损失函数等作限制。此外，多数现有方法仅考虑梯度幅值，忽略梯度方向；而我们同时考虑两者。

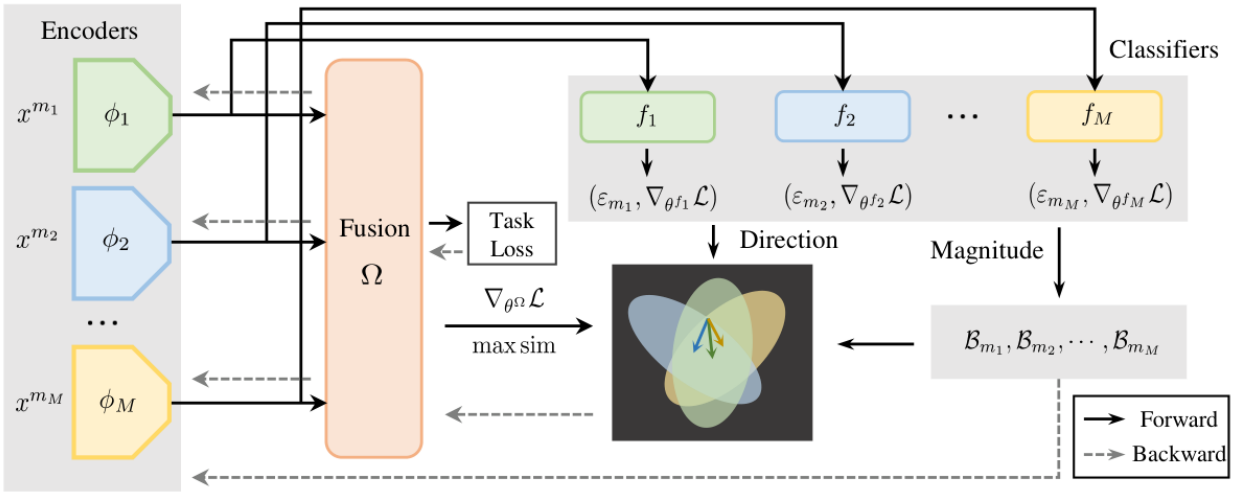


图1：CGGM 的整体架构。 训练阶段引入分类器，计算单模态梯度的方向及评价指标；推理阶段丢弃分类器。图中 Encoders＝编码器；Classifiers＝分类器；Fusion＝融合；Task Loss＝任务损失；Direction＝方向；Magnitude＝幅值；Forward＝前向传播；Backward＝反向传播。

3 所提出的方法

3.1 问题设置

假设有 M 种模态，记为 $m_1, m_2, \ldots, m_M$。多模态数据集记为 $D = \{(x_i, y_i)\}_{i=1}^{N}$，其中 N 是数据集中的数据数量，$x_i = \left(x_i^{m_1}, x_i^{m_2}, \ldots, x_i^{m_M}\right)$。我们考虑多模态模型中最常见的结构（图1）：先将不同模态的输入送入模态专属编码器，再将全部模态的表示输入融合模块。将模态 m_i 的编码器记为 ϕ_i，其中 $i = 1, 2, \ldots, M$，融合模块记为 Ω。

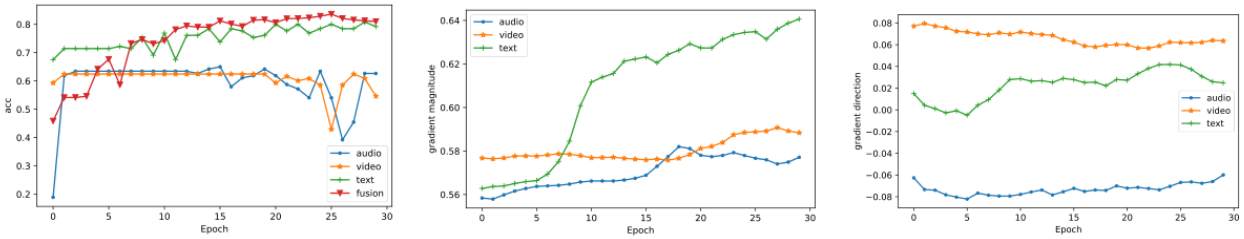
前向传播时，首先将特征输入编码器：

$$h_i = \phi_i(x^{m_i}) \qquad (1)$$

其中 h_i 是模态 m_i 的表示。获得全部模态表示后，应用融合模块：

$$\widehat{y} = \mathcal{F}\left(\Omega\left(\left[h_1, h_2, \ldots, h_M\right]\right)\right) \qquad (2)$$

其中 $\widehat{y}$ 为预测，$[\ldots]$ 为拼接操作，$\mathcal{F}(\cdot)$ 为预测答案的预测头。$\Omega(\cdot)$ 融合多模态表示，并输出融合特征作为预测标记。



(a) (b) (c)

图2： (a) 各模态与融合结果的准确率；(b) 各模态的梯度幅值，以梯度向量的欧几里得范数表示；(c) 各模态与其融合结果之间的梯度方向，以两个梯度向量之间的余弦相似度表示。全部结果均来自 CMU-MOSI。图例 audio＝音频，video＝视频，text＝文本，fusion＝融合；Epoch＝训练轮次，acc＝准确率，gradient magnitude＝梯度幅值，gradient direction＝梯度方向。

3.2 梯度分析

为引入 CGGM，我们先分析梯度更新过程。将损失函数记为 $L(\theta)=\frac{1}{N}\sum_{i=1}^{N}\ell\left(\widehat{y}_{\theta}^{i},\ y^{i}\right)$，其中 θ 表示网络参数，$\widehat{y}_{\theta}^{i}$ 为预测，y^{i} 为真实值。为简便起见，下文用 $\widehat{y}^{i}$ 表示预测。与先前仅考虑交叉熵损失的方法[17,8,11]不同，我们的 L 可以是交叉熵损失、L1 损失或其他任意损失函数。采用梯度下降（GD）优化方法，融合模块 Ω 与编码器 ϕ_i 的参数可更新为：

$$\theta_{t+1}^{\Omega}=\theta_{t}^{\Omega}-\alpha\nabla_{\theta^{\Omega}}L\left(\theta_{t}^{\Omega}\right)=\theta_{t}^{\Omega}-\frac{\alpha}{N}\sum_{n=1}^{N}\left[\frac{\partial\mathcal{F}}{\partial\Omega}\right]^{\mathrm{T}}\frac{\partial\ell\left(\widehat{y}^{n},\ y^{n}\right)}{\partial\mathcal{F}}\qquad(3)$$

$$\theta_{t+1}^{\phi_i}=\theta_{t}^{\phi_i}-\alpha\nabla_{\theta^{\phi_i}}L\left(\theta_{t}^{\phi_i}\right)=\theta_{t}^{\phi_i}-\frac{\alpha}{N}\sum_{n=1}^{N}\left[\frac{\partial\mathcal{F}}{\partial\Omega}\frac{\partial\Omega}{\partial\phi_i}\right]^{\mathrm{T}}\frac{\partial\ell\left(\widehat{y}^{n},\ y^{n}\right)}{\partial\mathcal{F}}\qquad(4)$$

其中 α 为学习率，N 为批大小，t 为迭代次数。根据反向传播中求梯度所用的链式法则，ϕ_i 的更新会影响 Ω 的更新，反之亦然。由图2(a)、2(b)可见，训练过程中主导模态的梯度与准确率会增加，而另外两种模态保持稳定。特别是文本模态的梯度幅值在训练中增加很快。这说明主导模态编码器的更新速度远快于其他编码器，使 $\partial\Omega/\partial\phi$ 大得多。先前研究[8,17,25]也能验证这一现象。此外，图2(c)展示了各模态与融合结果之间的梯度方向。可以看到，音频模态与多模态融合之间的相似度小于0，表明它们朝相反方向优化，从而妨碍多模态分支的梯度更新。与此同时，文本模态与多模态融合之间的相似度不断增加，表明优化方向朝向主导模态。随着优化推进，主导模态编码器能够给出相对准确的预测，使融合模块 Ω 仅依赖这一模态（如上所述，在幅值和方向两方面都是如此），令其他编码器优化不足。

3.3 分类器引导梯度调制

3.3.1 梯度幅值调制

如第3.2节所讨论，主导模态的梯度幅值在训练中快速增加，而其他模态保持稳定，因而优化不足。为平衡训练过程，使融合模块能够同时受益于所有编码器，我们提出分类器引导梯度调制。具体来说，使用模态专属分类器对式(1)中的 h_i 作出预测。这一过程可写成：

$$\widehat{y}_{m_i}=f_i(h_i)\qquad(5)$$

其中 f_i 是模态 m_i 的分类器，$\widehat{y}_{m_i}$ 是仅使用模态 m_i 的预测。对于分类和回归任务，分类器 f_i 由1至2层多头自注意力（MSA）[20]和一个全连接层组成；对于分割任务，f_i 是一个轻量解码器。h_i 输入融合模块 Ω 后，会变成更高层次的表示。因此，我们使用若干 MSA 层，使 h_i 与融合模块输出更加一致。

对特定任务，存在准确率、平均绝对误差等评价指标。这里选择其中一个指标（如分类任务用准确率，回归任务用平均绝对误差），记为 ε。每次训练迭代，都可以从分类器取得预测。将这些预测记为 $\widehat{y}^i = \left(\widehat{y}^i_{m_1}, \widehat{y}^i_{m_2}, \ldots, \widehat{y}^i_{m_M}\right)$，其中 i 是当前迭代。进一步，用 $\widehat{y}^i$ 评价任务，得到评价指标 $\varepsilon^i = \left(\varepsilon^i_{m_1}, \varepsilon^i_{m_2}, \ldots, \varepsilon^i_{m_M}\right)$。这里，用相邻两次 ε 的差表示每次迭代各模态的改进：

$$\begin{aligned}\Delta\varepsilon^{t+1} &= \varepsilon^{t+1} - \varepsilon^t = \left(\Delta\varepsilon^{t+1}_{m_1}, \Delta\varepsilon^{t+1}_{m_2}, \ldots, \Delta\varepsilon^{t+1}_{m_M}\right) \\ &= \left(\varepsilon^{t+1}_{m_1} - \varepsilon^t_{m_1}, \varepsilon^{t+1}_{m_2} - \varepsilon^t_{m_2}, \ldots, \varepsilon^{t+1}_{m_M} - \varepsilon^t_{m_M}\right).\end{aligned} \tag{6}$$

其中 $t = 0, 1, 2, \ldots, T$，T 是训练总迭代次数。特别地，ε^0 初始化为0。在一些多模态数据集中，仅使用一种模态就能取得较好结果，因此不能直接用 ε 衡量不同模态的利用率。所以，用 ε 之差表示每次迭代的相对改进是合理的。接着，将第 t 次迭代中模态 m_i 的梯度幅值平衡项定义如下：

$$B^t_{m_i} = \rho \frac{\sum_{k=1,k\neq i}^{M} \Delta\varepsilon^t_{m_k}}{\sum_{k=1}^{M} \Delta\varepsilon^t_{m_k}} \tag{7}$$

其中 ρ 是缩放超参数，M 是模态数量。由式(7)容易看出，当仅使用模态 m_i 的模型性能提升很快（即 $\Delta\varepsilon^t_{m_i}$ 大）时，$B^t_{m_i}$ 会小。同理，当模态 m_i 为模型带来的改进相对有限（即 $\Delta\varepsilon^t_{m_i}$ 小）时，$B^t_{m_i}$ 会大。因此，$B^t_{m_i}$ 能够衡量这些模态的相对利用率，我们可用它调制编码器 ϕ_i 的梯度幅值。式(4)于是可改写为：

$$\begin{aligned}\theta^{\phi_i}_{t+1} &= \theta^{\phi_i}_t - \alpha B^{t+1}_{m_i} \nabla_{\theta^{\phi_i}} L\left(\theta^{\phi_i}_t\right) \\ &= \theta^{\phi_i}_t - \alpha\rho \frac{\sum_{k=1,k\neq i}^{M} \Delta\varepsilon^{t+1}_{m_k}}{\sum_{k=1}^{M} \Delta\varepsilon^{t+1}_{m_k}} \nabla_{\theta^{\phi_i}} L\left(\theta^{\phi_i}_t\right).\end{aligned} \tag{8}$$

由式(2)可知，最终预测与 h_i 密切相关。因此，调制对应编码器 ϕ_i 的梯度后，会影响 Ω 的输入，进而帮助融合模块 Ω 的优化。

3.3.2 梯度方向调制

正如 Wu 等人[25]发现的，当模型只依赖一种模态就能表现良好时，它便不会继续学习使用其他模态。如第3.2节讨论，这意味着该模态主导模型更新。既有工作[25,17,15]主要通过关注梯度幅值调制来处理这一问题。然而，我们在第3.2节发现，模型正朝着主导模态的方向优化。因此，本小节介绍一种可调制梯度方向、从而平衡训练过程的方法。

总体而言，当模型仅依靠一种模态预测时，我们希望平衡模型的优化方向。因此，我们提出，强制模型梯度方向尽可能接近仅使用单一模态的模型梯度方向的加权平均。我们以式(7)中的 $B_{m_i}^t$ 为权重项。这能保证当模型倾向于朝主导模态优化时， $B_{m_i}^t$ 帮助模型使用其他模态的信息。此外， $B_{m_i}^t$ 在训练中变化，因而该项能够动态调整，以平衡优化方向。具体来说，在训练中可将一种模态输入模型，把其他模态替换为0或其他固定值而将其丢弃，以计算这一模态的梯度。通过这种方法，可计算所有模态的单模态梯度。然后，只需使模型梯度方向尽可能接近这些单模态梯度方向的加权平均。然而，这种方法在训练中非常复杂，因为每次迭代都要丢弃模态以计算单模态梯度，随着模态数量增加，会变得耗时。

因此，我们提出使用分类器 f_i 的梯度代表单模态梯度。后面将证明两者相似（第4.4节和图4）。这里以回归任务梯度为例：输出维数为1，因此梯度是一个 n 维向量。对于梯度为矩阵的分类任务或其他任务，详见附录A。具体来说，分类器 f_i 的梯度可计算为：

$$\nabla_{\theta^{f_i}} L\left(\theta^{f_i}\right) = \frac{\partial L\left(\theta^{f_i}\right)}{\partial f_i} = \left[\frac{\partial L\left(\theta^{f_i}\right)}{\partial \theta_1^{f_i}}, \frac{\partial L\left(\theta^{f_i}\right)}{\partial \theta_2^{f_i}}, \ldots, \frac{\partial L\left(\theta^{f_i}\right)}{\partial \theta_n^{f_i}}\right]^{\mathrm{T}} \tag{9}$$

其中 θ^{f_i} 表示 f_i 的参数。不同于式(3)、(4)中下标 t 表示迭代的 $\theta_t^{f_i}$，这里的 $\theta_n^{f_i}$ 表示 θ^{f_i} 中的一个变量。类似地，融合模块分类器 $\mathcal{F}$ 的梯度为：

$$\nabla_{\theta^{\mathcal{F}}} L\left(\theta^{\mathcal{F}}\right) = \frac{\partial L\left(\theta^{\mathcal{F}}\right)}{\partial \mathcal{F}} = \left[\frac{\partial L\left(\theta^{\mathcal{F}}\right)}{\partial \theta_1^{\mathcal{F}}}, \frac{\partial L\left(\theta^{\mathcal{F}}\right)}{\partial \theta_2^{\mathcal{F}}}, \ldots, \frac{\partial L\left(\theta^{\mathcal{F}}\right)}{\partial \theta_n^{\mathcal{F}}}\right]^{\mathrm{T}} \tag{10}$$

我们将 $\nabla_{\theta^{f_i}} L$ （$i = 1, 2, \ldots, M$）视作单模态梯度，将 $\nabla_{\theta^{\mathcal{F}}} L$ 视作融合梯度。如前所述，希望后者尽可能接近前者的加权平均方向。令 $\mathrm{sim}(u, v) = u^{\mathrm{T}} v / (\| u \| \| v \|)$，表示经 ℓ_2 归一化的 u 和 v 的点积（即余弦相似度）。通过最大化其余弦相似度，可以让融合模块梯度方向尽可能接近这些单模态梯度方向的加权平均：

$$\max \sum_{i=1}^{M} B_{m_i}^t \mathrm{sim}\left(\nabla_{\theta^{\mathcal{F}}} L, \nabla_{\theta^{f_i}} L\right) \tag{11}$$

其中 t 为当前迭代。将式(11)改写为损失项：

$$L_{gm}^t = \frac{1}{M} \sum_{i=1}^{M} \left[\left|B_{m_i}^t\right| - B_{m_i}^t \mathrm{sim}\left(\nabla_{\theta_t^{\mathcal{F}}} L, \nabla_{\theta_t^{f_i}} L\right)\right] \tag{12}$$

余弦相似度在−1与1之间。向损失项加入 $\left|B_{m_i}^t\right|$，可以保证 L_{gm} 始终为正。如前所述，当模态 m_i 的改进有限时， $B_{m_i}^t$ 较大。因此， L_{gm}^t 中的对应项会较大，使优化方向朝向模态 m_i，从而平衡学习过程。

总体损失函数于是可写为：

$$L^t = L_{task} + \lambda L_{gm}^t \tag{13}$$

其中 L_{task} 为任务损失函数（如交叉熵损失、L1 损失）， λ 用于权衡两个损失项。算法1给出了完整方法。

算法1：分类器引导梯度调制

1. **输入：** 训练数据集 $D = \{(x_i, y_i)\}_{i=1}^{N}$、迭代次数 T、模态数量 M、模型 $F = (\phi_i, \Omega, \mathcal{F})$、分类器 f_i 及超参数。
2. **初始化：** $\varepsilon_p \leftarrow 0$， $\varepsilon_n \leftarrow$ 空列表， $L_{gm} \leftarrow 0$，分类器梯度列表 L_g。
3. 对 $t = 1$ 至 T 循环:
4. 从 D 中采样得到 D_t。
5. 按式(1)前向传播，得到表示 $h = (h_1, h_2, \ldots, h_M)$。
6. 对 $i = 1$ 至 M 循环:
7. 使用 h_i，按式(5)作出预测。
8. 计算 $\varepsilon_{m_i}^t$，将其追加到 ε_n。
9. 将 $\nabla_{\theta^{f_i}} L\left(\theta^{f_i}\right)$ 追加到 L_g。
10. 结束内层循环。
11. $\Delta\varepsilon^t = \varepsilon_n - \varepsilon_p$。
12. 按式(7)计算 $B_{m_i}^t$， $i = 1, 2, \ldots, M$。
13. 计算损失 $L = L_{task} + \lambda L_{gm}$ 并反向传播。
14. 按式(12)计算 L_{gm}^t。
15. $\varepsilon_p \leftarrow \varepsilon_n$， $L_{gm} \leftarrow L_{gm}^t$， $\varepsilon_n \leftarrow$ 空列表。
16. 按式(3)、(8)更新参数。
17. 结束外层循环。

> 译者说明：上述算法保留原文计算顺序，未擅自重排第13—15行。原文称式(12)“始终为正”，这里忠实保留措辞；数学上该构造保证非负，可为零。式(7)分母为零的处理方式及误差类指标的符号变换，原文此处未说明。

4 实验

4.1 数据集和评价指标

我们采用 UPMC-Food 101[23]、CMU-MOSI[27]、IEMOCAP[3]和 BraTS 2021[1]四个多模态数据集。表1展示了四者的区别。

表1：所用四个数据集的区别。

数据集	任务类型	模态数量
UPMC-Food 101	分类	2
CMU-MOSI	回归	3
IEMOCAP	分类	3
BraTS 2021	分割	4

UPMC-Food 101[23] 是食物分类数据集，包含约100,000份食谱，共101个食物类别。每个条目由一张图像和文本信息表示。我们用准确率和 F1 分数评价模型性能。

CMU-MOSI[27] 是常用的多模态（音频、文本、视频）情感分析数据集。每段视频经人工标注获得从强烈负面到强烈正面的情感分数（−3至+3）。遵循先前工作[18,10]，我们使用二分类准确率（ACC-2）、F1分数、七分类准确率（ACC-7）、平均绝对误差（MAE）及皮尔逊相关系数（Corr）评价模型性能。

IEMOCAP[3] 是多模态情绪识别数据集，包含十名演员在五次双人对话中的录像。遵循先前工作[18,24,10]，选择四种情绪（快乐、愤怒、悲伤、中性）进行情绪识别。用准确率和 F1 分数评价模型性能。

BraTS 2021[1] 是三维多模态脑肿瘤分割数据集，有 flair、t1ce、t1 和 t2 四种模态。输入图像大小为 $240 \times 240 \times 155$。标注合并为三个嵌套子区域：全肿瘤（WT）、肿瘤核心（TC）、增强肿瘤（ET）。使用这三个嵌套子区域的 Dice 分数及其平均值评价性能。

Method	Acc	F1
Text only	84.77	84.72
Image only	68.24	68.23
Baseline	90.32	90.30
G-Blending [22]	90.42	90.38
Greedy [25]	91.21	91.20
OGE [17]	91.08	91.08
AGM [15]	91.49	91.48
PMR [8]	92.01	91.98
UMT [7]	91.82	91.82
UME [7]	90.69	90.68
QMF [28]	<u>92.87</u>	<u>92.85</u>
ReconBoost [11]	92.52	92.51
CGGM	**92.94**	**92.90**

表2：UPMC-Food 101 数据集上的定量结果。 粗体表示最佳结果，下划线表示次佳结果。Method＝方法；Acc＝准确率；Text only＝仅文本；Image only＝仅图像；Baseline＝基线。其余为方法名称。原表写作“OGE [17]”，正文写作“OGM [17]”，此处保留原表，不作静默更正。

Method	WT	TC	ET	Avg.
flair only	70.42	51.41	45.27	55.70
t1 only	50.73	36.13	38.77	41.88
t2 only	64.82	42.17	34.62	47.20
t1ce only	56.61	53.83	53.14	54.53
Baseline	74.03	67.08	66.53	69.21
MRD	74.02	68.04	67.28	69.78
MSLR	74.47	69.98	67.20	70.55
UMT [7]	74.15	67.69	66.80	69.55
UME [7]	74.65	68.74	67.58	70.32
QMF [28]	75.11	<u>70.78</u>	68.94	71.61
ReconBoost [11]	<u>75.21</u>	70.18	<u>70.01</u>	<u>71.80</u>
CGGM	**76.94**	**72.75**	**72.14**	**73.94**

表3：BraTS 2021 上的结果。 WT、TC、ET 分别表示全肿瘤、肿瘤核心、增强肿瘤的 Dice 分数。Avg.＝平均值；“某模态 only”表示仅使用该模态；Baseline＝基线。

Method	CMU-MOSI					IEMOCAP	
	Acc-2	Acc-7	F1	MAE	Corr	Acc	F1
Text only	76.83	28.24	76.80	1.016	0.664	65.35	64.30
Audio only	64.12	23.04	66.96	1.451	0.510	52.18	50.14
Video only	62.00	21.65	66.18	1.441	0.499	54.55	53.97
Baseline	81.23	29.26	81.23	0.952	0.710	70.74	69.53
MRD	80.78	31.44	80.75	0.975	0.688	71.81	71.08
MSLR	81.22	31.00	81.19	0.950	0.704	71.99	70.96
AGM [15]	-	-	-	-	-	72.35	71.94
UMT [7]	<u>81.78</u>	<u>31.98</u>	<u>81.77</u>	<u>0.942</u>	<u>0.712</u>	70.75	69.81
UME [7]	80.83	30.94	80.78	0.969	0.701	71.53	70.94
QMF [28]	-	-	-	-	-	72.08	71.64
ReconBoost [11]	-	-	-	-	-	<u>73.14</u>	<u>72.71</u>
CGGM	**82.84**	**33.73**	**82.74**	**0.915**	**0.717**	**75.38**	**74.97**

表4：CMU-MOSI 和 IEMOCAP 数据集上的定量结果。 粗体表示最佳结果，下划线表示次佳结果。Text/Audio/Video only 分别表示仅文本、仅音频、仅视频；Baseline＝基线。Acc-2＝二分类准确率，Acc-7＝七分类准确率，MAE＝平均绝对误差，Corr＝皮尔逊相关系数，Acc＝准确率。“-”保留原文未给出结果的标记。

4.2 实现细节

输入。 对于 UPMC-Food 101，我们使用提取后的特征作为输入。具体来说，用预训练 bert-base-uncased 模型[5]提取文本特征，用 ImageNet 上预训练的 ViT[6]提取图像特征。对于 CMU-MOSI 和 IEMOCAP，遵循 Guo 等人[10]提取声学、视觉和文本特征。对于 BraTS 2021，使用预处理后的原始图像作为输入。

骨干网络。 对于 UPMC-Food 101、CMU-MOSI 和 IEMOCAP，采用 Transformer 编码器[20]作为模态编码器及融合模块。对于 BraTS 2021，使用 DeepLab v3+[4]作为编码器，若干卷积层作为融合模块。

训练细节。 对于 UPMC-Food 101 和 BraTS 2021 中的图像，我们实施随机裁剪、随机翻转、颜色抖动、添加噪声等数据增强策略。为节省内存，从三维图像中随机切出一张图像，将 BraTS 2021 视为二维分割任务。CMU-MOSI 使用 L1 损失；UPMC-Food 101 和 IEMOCAP 使用交叉熵损失；BraTS 2021 使用软 Dice 损失与交叉熵损失的组合。此外，CMU-MOSI 使用 Adam 优化器，UPMC-Food 101 和 IEMOCAP 使用 AdamW 优化器，BraTS 2021 使用 SGD 优化器。其他超参数在附录B中详细描述。

4.3 主要结果

与最先进方法的比较。 为证明所提方法的有效性，我们将 CGGM 与其他方法比较。在四个数据集上，将 CGGM 与仅用一种模态训练的模型、多模态联合训练（Baseline）、模态随机丢弃（MRD）和模态专属学习率（MSLR）方法比较。此外，还与 G-Blending[22]、Greedy[25]、OGM[17]、AGM[15]、PMR[8]、UMT[7]、UME[7]、QMF[28]和 ReconBoost[11]等最先进方法比较。表2、3、4展示 CGGM 及对比方法的结果。与基线相比，CGGM 显著提升模型性能，证明了所提方法的有效性。此外，CGGM 同时考虑梯度幅值和方向，因而在四个数据集上始终优于其他梯度调制方法。最重要的是，CGGM 能容易地应用于分类、回归、分割等各类任务，并取得良好性能。同时，CGGM 不限制优化器、损失函数和模态数量。

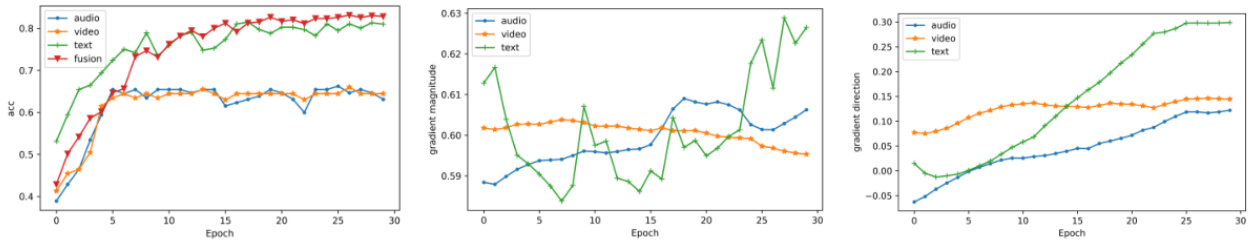


图3： 使用 CGGM 训练时，(a) 性能、(b) 梯度幅值、(c) 方向的变化。结果来自 CMU-MOSI。图例与坐标词汇同图2。

CGGM 的有效性。 图3可视化了使用 CGGM 训练时准确率、梯度幅值及方向的变化。与图2(a)相比，图3(a)中文本模态的准确率在使用 CGGM 后并未快速增加，说明 CGGM 在优化过程中约束了主导模态。此外，所有模态及融合的准确率均有提升，表明 CGGM 有效。在图2(b)中，主导模态始终具有最大的梯度，而在图3(b)中，文本模态梯度幅值最初下降，表明 CGGM 减缓了其优化，同时加快其他模

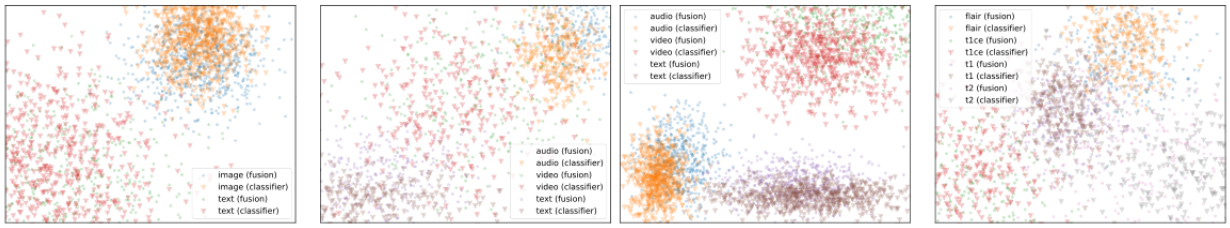
态的优化，帮助每种模态充分学习，从而提升多模态性能。在梯度方向方面，图2中音频模态与融合之间的相似度在训练期间始终小于0，说明单模态与多模态的优化方向相反，从而妨碍优化过程。图3中，多模态方向与所有模态一致，说明多模态分支有效利用了单模态信息。

4.4 分类器性能和梯度方向

unimodal training			multimodal training			CGGM		
audio	video	text	f_1	f_2	f_3	f_1	f_2	f_3
52.18	54.55	65.35	50.59	53.04	67.15	54.95	56.77	67.39

表5：IEMOCAP 上的准确率。 f_1、f_2、f_3 分别表示音频、视频、文本分类器。单模态训练中分别训练三个独立模型。unimodal training＝单模态训练；multimodal training＝多模态训练；audio/video/text＝音频/视频/文本。

分类器性能。 表5展示不同情况下分类器的准确率。单模态训练可被视为充分利用单模态信息的基线。与单模态训练相比，多模态训练中 f_1 和 f_2 的准确率略有下降，而 f_3 略有提升。这表明多模态训练未能充分利用音频和视频信息，即两者优化不足。f_3 的提升说明文本模态已被充分利用，并从另外两种模态学到一些信息。相比之下，CGGM 中三个分类器的准确率都提高了。这表明，在平衡过程中，融合能够充分利用所有模态信息，从而在反向传播中使三个模态的编码器融合其他模态的信息。因此，三个分类器的准确率相应提升。这也验证了 CGGM 的有效性。



(a) UPMC-Food 101　(b) CMU-MOSI　(c) IEMOCAP　(d) BraTS 2021

图4：分类器梯度和单模态梯度的 t-SNE 可视化。 每个点表示一个数据批次的梯度向量或矩阵。四个面板分别为 UPMC-Food 101、CMU-MOSI、IEMOCAP、BraTS 2021。图例中的 fusion 表示融合模块所得梯度，classifier 表示分类器所得梯度；image/text/audio/video＝图像/文本/音频/视频，flair、t1ce、t1、t2 为原模态名称。

分类器梯度方向。 第3.3.2节提出用分类器梯度代表单模态梯度。本小节可视化两者。具体来说，对每个数据批次，先将其输入模型得到表示 h_i，再送入分类器 f_i，得到分类器梯度。随后仅将一种模态的 h_i 输入融合模块 Ω，得到单模态梯度。用 t-SNE[19]可视化这些梯度向量。图4给出四个数据集上的可视化结果。图中，对每个模态，单模态梯度向量与对应分类器的梯度向量非常接近，表明使用分类器梯度代表单模态梯度是有意义的。

4.5 消融研究

梯度幅值和方向。 为分别衡量梯度幅值调制与方向调制的贡献，表6给出 IEMOCAP 上的消融结果。与第一行基线相比，调制梯度幅值比调制梯度方向带来更多模型性能提升。与表4中的 CGGM 性能相比，同时调制梯度幅值和方向进一步增强了模型性能。

Model	Acc	F1
Baseline	70.74	69.53
CGGM ($\rho = 1.0, \lambda = 0$)	72.35	71.56
CGGM ($\rho = \text{None}, \lambda = 0.1$)	72.41	72.07
CGGM ($\rho = 1.0, \lambda = 0.1$)	73.74	73.18

表6：调制梯度幅值和梯度方向的收益。 Model＝模型；Acc＝准确率；Baseline＝基线；$\rho = \text{None}$ 保留原文“无幅值调制”设定标记。

> 译者说明：上一段“幅值调制比方向调制带来更多提升”忠实保留原文说法；但表6的方向单独调制行（72.41、72.07）高于幅值单独调制行（72.35、71.56），两者不一致。没有改写原结论或改动数值。

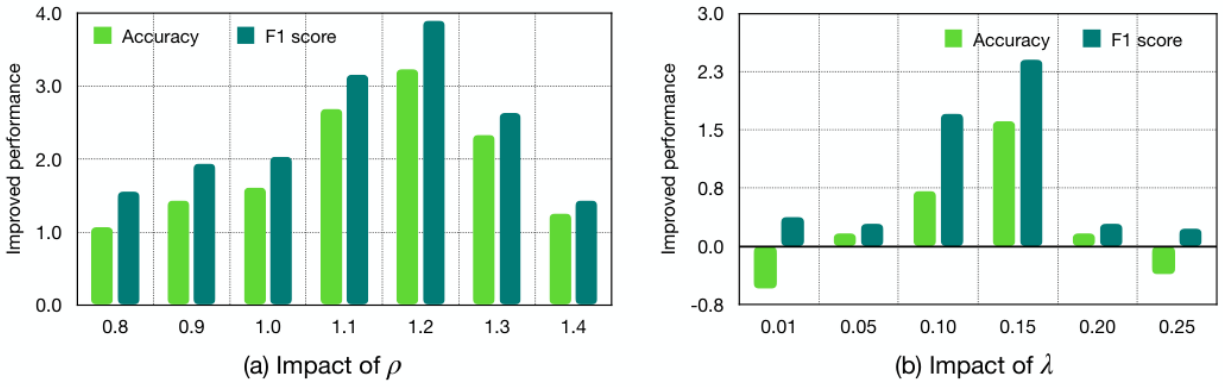


图5： 相对于联合训练基线，采用不同 ρ 和 λ 时的性能提升。(a) ρ 的影响；(b) λ 的影响。Improved performance＝性能提升；Accuracy＝准确率；F1 score＝F1分数。

缩放超参数 ρ。 为探索缩放超参数 ρ 对模型性能的影响，选择七个不同值，并在图5(a)给出 IEMOCAP 上的结果。我们发现，准确率随 ρ 增加而提升，在 $\rho = 1.2$ 时达到最高，此后随 ρ 增加而下降。与基线相比，无论 ρ 取多大，调制梯度幅值都带来一致提升。直观上，ρ 越大，对梯度的修改越大。因此，表中结果说明，需要谨慎选择 ρ，以避免修改过大或过小。

损失权衡 λ。 λ 衡量调制梯度方向的强度。选择六个不同值，图5(b)展示 IEMOCAP 上的结果。如图所示，λ 为0.01或0.25时，准确率会略有下降。λ 过小时，调制不充分，可能影响优化过程；λ 过大时，调制较强，会影响任务损失，从而使优化偏离任务。

5 结论

本文提出 CGGM，一种平衡多模态训练过程的新策略。与现有梯度调制方法相比，CGGM 不限制损失函数、优化器、模态数量等。此外，在分类器引导下，我们同时考虑梯度幅值和方向。大量实验与消融研究充分证明了 CGGM 的有效性和普适性。然而，CGGM 也存在局限：它需要借助额外分类器实现梯度调制。尽管这些分类器是轻量的，仍会带来更多计算资源消耗。我们把这一具有挑战性的问题留待未来研究。

致谢

本研究获得国家重点研发计划（项目编号 No.2022ZD0162000）支持。

参考文献

以下完整保留28条参考文献的作者、原题及出版信息，便于检索；每条另给出题名中文译文。原文大小写、条目信息及异常页码不作推断修订。

[1] Ujjwal Baid, Satyam Ghodasara, Suyash Mohan, Michel Bilello, Evan Calabrese, Errol Colak, Keyvan Farahani, Jayashree Kalpathy-Cramer, Felipe C Kitamura, Sarthak Pati, et al. The rsna-asnr-miccai brats 2021 benchmark on brain tumor segmentation and radiogenomic classification. arXiv preprint arXiv:2107.02314, 2021.

题名译文：RSNA-ASNR-MICCAI BraTS 2021 脑肿瘤分割与影像基因组分类基准。

[2] Hedi Ben-Younes, Rémi Cadene, Matthieu Cord, and Nicolas Thome. Mutan: Multimodal tucker fusion for visual question answering. In Proceedings of the IEEE international conference on computer vision, pages 2612–2620, 2017.

题名译文：MUTAN：用于视觉问答的多模态 Tucker 融合。

[3] Carlos Busso, Murtaza Bulut, Chi-Chun Lee, Ebrahim (Abe) Kazemzadeh, Emily Mower Provost, Samuel Kim, Jeannette N. Chang, Sungbok Lee, and Shrikanth S. Narayanan. Iemocap: interactive emotional dyadic motion capture database. Language Resources and Evaluation, 42: 335–359, 2008.

题名译文：IEMOCAP：交互式情绪双人动作捕捉数据库。

[4] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In Proceedings of the European conference on computer vision (ECCV), pages 801–818, 2018.

题名译文：用于语义图像分割的空洞可分离卷积编码器—解码器。

[5] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.

题名译文：BERT：用于语言理解的深度双向 Transformer 预训练。

[6] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020.

题名译文：一张图像相当于16×16个词：用于大规模图像识别的 Transformer。

[7] Chenzhuang Du, Jiaye Teng, Tingle Li, Yichen Liu, Tianyuan Yuan, Yue Wang, Yang Yuan, and Hang Zhao. On uni-modal feature learning in supervised multi-modal learning. In International Conference on Machine Learning, pages 8632–8656. PMLR, 2023.

题名译文：论监督式多模态学习中的单模态特征学习。

[8] Yunfeng Fan, Wenchao Xu, Haozhao Wang, Junxiao Wang, and Song Guo. Pmr: Prototypical modal rebalance for multimodal learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 20029–20038, 2023.

题名译文：PMR：用于多模态学习的原型式模态再平衡。

[9] Jie Fu, Junyu Gao, Bing-Kun Bao, and Changsheng Xu. Multimodal imbalance-aware gradient modulation for weakly-supervised audio-visual video parsing. IEEE Transactions on Circuits and Systems for Video Technology, 2023.

题名译文：用于弱监督视听视频解析的多模态不平衡感知梯度调制。

[10] Zirun Guo, Tao Jin, and Zhou Zhao. Multimodal prompt learning with missing modalities for sentiment analysis and emotion recognition. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 1726–1736, 2024.

题名译文：缺失模态条件下用于情感分析和情绪识别的多模态提示学习。

[11] Cong Hua, Qianqian Xu, Shilong Bao, Zhiyong Yang, and Qingming Huang. Reconboost: Boosting can achieve modality reconcilement. In The Forty-first International Conference on Machine Learning, 2024.

题名译文：ReconBoost：提升法可以实现模态协调。

[12] Yu Huang, Junyang Lin, Chang Zhou, Hongxia Yang, and Longbo Huang. Modality competition: What makes joint training of multi-modal network fail in deep learning? (provably). In International Conference on Machine Learning, pages 9226–9259. PMLR, 2022.

题名译文：模态竞争：深度学习中是什么导致多模态网络联合训练失败？（可证明）。

[13] Tao Jin, Weicai Yan, Ye Wang, Sihang Cai, Shuaiqifan, and Zhou Zhao. Calibrating prompt from history for continual vision-language retrieval and grounding. In ACM Multimedia 2024, 2024.

题名译文：从历史中校准提示以实现持续视觉—语言检索与定位。

[14] Hamid Reza Vaezi Joze, Amirreza Shaban, Michael L Iuzzolino, and Kazuhito Koishida. Mmtm: Multimodal transfer module for cnn fusion. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 13289–13299, 2020.

题名译文：MMTM：用于CNN融合的多模态迁移模块。

[15] Hong Li, Xingyu Li, Pengbo Hu, Yinuo Lei, Chunxiao Li, and Yi Zhou. Boosting multi-modal model performance with adaptive gradient modulation. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 22214–22224, 2023.

题名译文：通过自适应梯度调制提升多模态模型性能。

[16] Paul Pu Liang, Ziyin Liu, AmirAli Bagher Zadeh, and Louis-Philippe Morency. Multimodal language analysis with recurrent multistage fusion. In Ellen Riloff, David Chiang, Julia Hockenmaier, and Jun’ichi Tsujii, editors, Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, pages 150–161, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1014. URL https://aclanthology.org/D18-1014.

题名译文：采用循环多阶段融合的多模态语言分析。

[17] Xiaokang Peng, Yake Wei, Andong Deng, Dong Wang, and Di Hu. Balanced multimodal learning via on-the-fly gradient modulation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 8238–8247, 2022.

题名译文：通过即时梯度调制实现平衡多模态学习。

[18] Yao-Hung Hubert Tsai, Shaojie Bai, Paul Pu Liang, J. Zico Kolter, Louis-Philippe Morency, and Ruslan Salakhutdinov. Multimodal transformer for unaligned multimodal language sequences. In Anna Korhonen, David Traum, and Lluís Màrquez, editors, Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 6558–6569, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1656. URL https://aclanthology.org/P19-1656.

题名译文：用于未对齐多模态语言序列的多模态 Transformer。

[19] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. Journal of Machine Learning Research, 9(86):2579–2605, 2008.

题名译文：使用t-SNE进行数据可视化。

[20] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. Advances in neural information processing systems, 30, 2017.

题名译文：注意力就是你所需要的全部。

[21] Valentin Vielzeuf, Alexis Lechervy, Stéphane Pateux, and Frédéric Jurie. Centralnet: a multi-layer approach for multimodal fusion. In Proceedings of the European Conference on Computer Vision (ECCV) Workshops, pages 0–0, 2018.

题名译文：CentralNet：用于多模态融合的多层方法。

[22] Weiyao Wang, Du Tran, and Matt Feiszli. What makes training multi-modal classification networks hard? In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 12695–12705, 2020.

题名译文：是什么使多模态分类网络难以训练?

[23] Xin Wang, Devinder Kumar, Nicolas Thome, Matthieu Cord, and Frédéric Precioso. Recipe recognition with large multimodal food dataset. In 2015 IEEE International Conference on Multimedia Expo Workshops (ICMEW), pages 1–6, 2015. doi: 10.1109/ICMEW.2015.7169757.

题名译文：利用大型多模态食物数据集识别食谱。

[24] Yansen Wang, Ying Shen, Zhun Liu, Paul Pu Liang, Amir Zadeh, and Louis-Philippe Morency. Words can shift: Dynamically adjusting word representations using nonverbal behaviors. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 33, pages 7216–7223, 2019.

题名译文：词语可以移动：使用非言语行为动态调整词表示。

[25] Nan Wu, Stanislaw Jastrzebski, Kyunghyun Cho, and Krzysztof J Geras. Characterizing and overcoming the greedy nature of learning in multi-modal deep neural networks. In International Conference on Machine Learning, pages 24043–24055. PMLR, 2022.

题名译文：刻画并克服多模态深度神经网络学习的贪婪性。

[26] Weicai Yan, Ye Wang, Wang Lin, Zirun Guo, Zhou Zhao, and Tao Jin. Low-rank prompt interaction for continual vision-language retrieval. In ACM Multimedia 2024, 2024.

题名译文：用于持续视觉—语言检索的低秩提示交互。

[27] Amir Zadeh, Rowan Zellers, Eli Pincus, and Louis-Philippe Morency. Multimodal sentiment intensity analysis in videos: Facial gestures and verbal messages. IEEE Intelligent Systems, 31 (6):82–88, 2016. doi: 10.1109/MIS.2016.94.

题名译文：视频中的多模态情感强度分析：面部姿态与语言信息。

[28] Qingyang Zhang, Haitao Wu, Changqing Zhang, Qinghua Hu, Huazhu Fu, Joey Tianyi Zhou, and Xi Peng. Provable dynamic fusion for low-quality multimodal data. In International conference on machine learning, pages 41753–41769. PMLR, 2023.

题名译文：面向低质量多模态数据的可证明动态融合。

附录A 梯度方向调制细节

对于分类任务，分类器 f_i 输出不止一个值。例如，对于 UPMC-Food 101 数据集， f_i 为每条数据输出101个值。因此，可以定义 $f_i = \left(f_i^{(1)}, f_i^{(2)}, ..., f_i^{(m)}\right)$，其中 m 是输出数量。分类器 f_i 的梯度计算如下：

$$\nabla_{\theta^{f_i}} \mathcal{L}(\theta^{f_i}) = \frac{\partial \mathcal{L}(\theta^{f_i})}{\partial f_i} = \begin{bmatrix} \frac{\partial \mathcal{L}(\theta^{f_i^{(1)}})}{\partial \theta_1^{f_i}} & \frac{\partial \mathcal{L}(\theta^{f_i^{(2)}})}{\partial \theta_1^{f_i}} & \cdots & \frac{\partial \mathcal{L}(\theta^{f_i^{(m)}})}{\partial \theta_1^{f_i}} \\ \frac{\partial \mathcal{L}(\theta^{f_i^{(1)}})}{\partial \theta_2^{f_i}} & \frac{\partial \mathcal{L}(\theta^{f_i^{(2)}})}{\partial \theta_2^{f_i}} & \cdots & \frac{\partial \mathcal{L}(\theta^{f_i^{(m)}})}{\partial \theta_2^{f_i}} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial \mathcal{L}(\theta^{f_i^{(1)}})}{\partial \theta_n^{f_i}} & \frac{\partial \mathcal{L}(\theta^{f_i^{(2)}})}{\partial \theta_n^{f_i}} & \cdots & \frac{\partial \mathcal{L}(\theta^{f_i^{(m)}})}{\partial \theta_n^{f_i}} \end{bmatrix} \tag{14}$$

类似地，融合模块分类器的梯度计算如下：

$$\nabla_{\theta^{\mathcal{F}}} \mathcal{L}(\theta^{\mathcal{F}}) = \frac{\partial \mathcal{L}(\theta^{\mathcal{F}})}{\partial \mathcal{F}} = \begin{bmatrix} \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(1)}})}{\partial \theta_1^{\mathcal{F}}} & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(2)}})}{\partial \theta_1^{\mathcal{F}}} & \cdots & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(m)}})}{\partial \theta_1^{\mathcal{F}}} \\ \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(1)}})}{\partial \theta_2^{\mathcal{F}}} & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(2)}})}{\partial \theta_2^{\mathcal{F}}} & \cdots & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(m)}})}{\partial \theta_2^{\mathcal{F}}} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(1)}})}{\partial \theta_n^{\mathcal{F}}} & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(2)}})}{\partial \theta_n^{\mathcal{F}}} & \cdots & \frac{\partial \mathcal{L}(\theta^{\mathcal{F}^{(m)}})}{\partial \theta_n^{\mathcal{F}}} \end{bmatrix} \tag{15}$$

为计算这两项之间的余弦相似度，我们将它们展平为向量，然后用式(12)计算 L_{gm}。

附录B 实现细节

Hyperparameters	UMPC-Food 101	CMU-MOSI	IEMOCAP	BraTS 2021
batch size	128	64	32	64
optimizer	AdamW	Adam	AdamW	SGD
base lr	1e-3	1e-3	1e-3	1e-2
classifier lr	5e-4	5e-4	5e-4	6e-3
weight decay	3e-3	-	-	3e-4
gradient clip	0.8	0.8	0.8	-
scheduler	StepLR	StepLR	StepLR	CosineLR
ρ	1.3	1.3	1.3	1.2
λ	0.15	0.20	0.15	0.10
warm-up epoch	-	-	-	10
epoch	80	30	30	150

表7：四个数据集的主要超参数。 Hyperparameters＝超参数；batch size＝批大小；optimizer＝优化器；base lr＝基础学习率；classifier lr＝分类器学习率；weight decay＝权重衰减；gradient clip＝梯度裁剪；scheduler＝学习率调度器；warm-up epoch＝预热轮数；epoch＝训练轮数。AdamW、Adam、SGD、StepLR、CosineLR 及 ρ、λ 保留原名。原表将 UPMC 写为 UMPC，此处保留表内原拼写。

表7列出四个数据集的主要超参数。除表中超参数外，还有一些任务专属超参数。

对 BraTS 2021，起始学习率设为 4×10^{-4}，经预热轮次升至 10^{-2}，最终学习率为 10^{-3}。此外，损失函数使用软 Dice 损失与交叉熵损失的组合，可表示为 $L_{task} = L_{Dice} + \lambda_1 L_{CE}$。将 λ_1 设为1。特别地，我们使用加权交叉熵损失函数，背景、标签1、标签2、标签3的权重分别为0.2、0.3、0.25、0.25。

附录C 更多消融研究

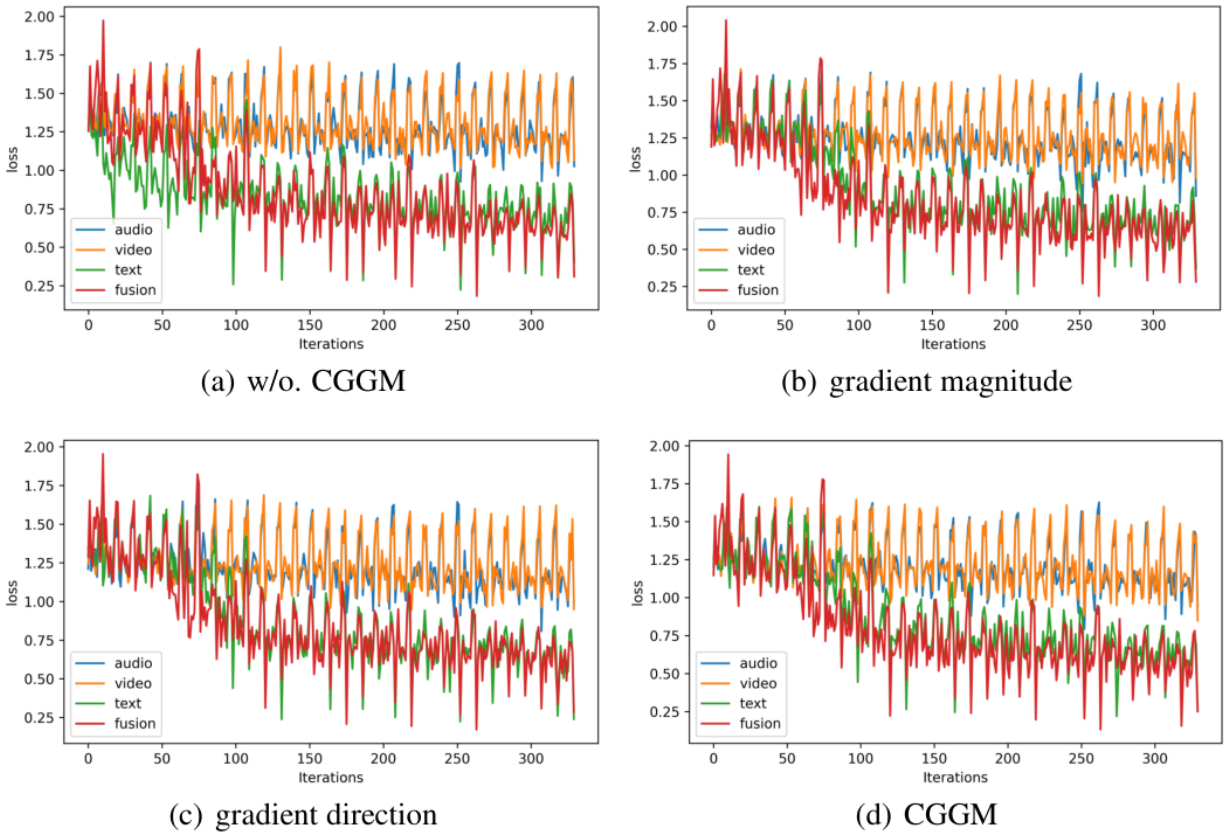


图6：训练过程中的损失变化。 (a) 不使用 CGGM；(b) 梯度幅值；(c) 梯度方向；(d) CGGM。图中 loss＝损失；iterations＝迭代次数；audio/video/text/fusion＝音频/视频/文本/融合。

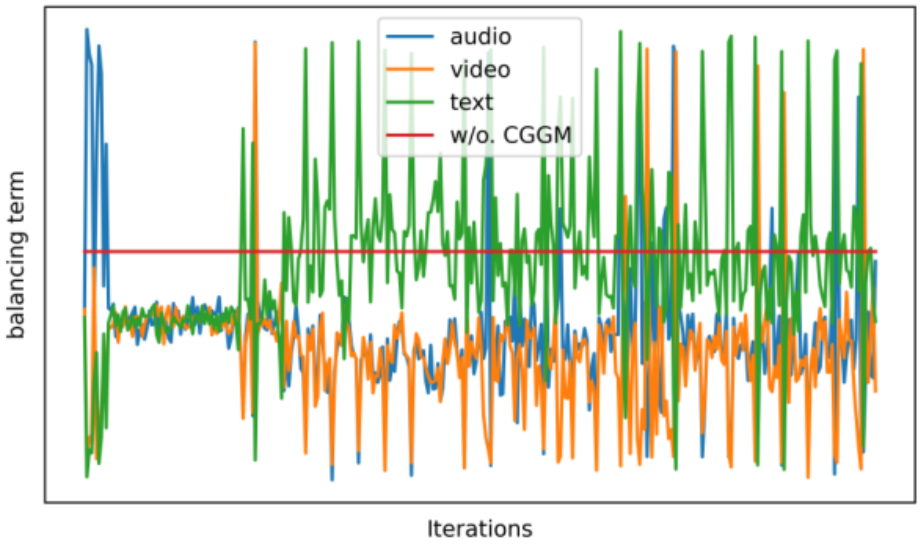


图7：训练过程中平衡项的变化。 balancing term＝平衡项；iterations＝迭代次数；audio/video/text＝音频/视频/文本；w/o. CGGM＝不使用 CGGM。

CGGM 的更多可视化。 图6进一步可视化损失变化。由图可观察到，(b)—(d)中使用 CGGM 的主导模态损失，下降速度远慢于图6(a)。此外，(b)—(d)中所有模态的损失都小于(a)，表明 CGGM 有效。除损失变化外，图7还可视化了训练过程中平衡项的变化。当数值高于红线时，该模态得到促进；低于红线时，该模态被抑制。最初若干次迭代中，主导模态受到抑制，保证其他模态充分优化。在优化期间，三种模态的平衡项上下波动，确保每种模态充分优化。

分类器额外的计算资源。 额外分类器在训练中需要更多计算资源。不过，在推理时会丢弃分类器，因此它们不影响推理阶段。表8报告了额外分类器增加的内存开销（MB）。由表可见，增加的计算开销很低。主要有两个原因：(1) 分类器或解码器是轻量的，参数很少；(2) 分类器仅用梯度更新自身，反向传播时不向模态编码器传递梯度。因此无需为每个参数保存梯度，从而降低内存开销。

Setting	Food101	MOSI	IEMOCAP	BraTS
With classifiers	+8MB	+8MB	+8MB	+24MB

表8：分类器额外的 GPU 内存开销（MB）。 Setting＝设置；With classifiers＝使用分类器。Food101、MOSI、IEMOCAP、BraTS 四列分别增加8、8、8、24 MB。

版本与完整性说明（译者附记，不属于原论文）。 本译文包括所选15页 arXiv v1 中的摘要、正文第1—5节、致谢、28条参考文献、附录A—C、算法1、公式(1)—(15)、图1—7及表1—8。该版本没有单列定理或证明章节。表1以中文重排，其余表格保留原表图像，并翻译标题、表头及必要词汇。图形保留原始数据与标签，并提供中文图注和词汇对照。式(14)、(15)以高分辨率裁图保留矩阵。未将图表数据替换为摘要。该版本与仓库会议版的逐字等同性未验证，故不声称它是会议版的翻译。附录B、表7与图5讨论的超参数位置各按原文保留，未合并为新的推荐值。