通过变分 Copula 建模实现跨模态对齐

非官方中文全文译文 · P117

Feng Wu*，Tsai Hor Chan*，Fuying Wang，Guosheng Yin，Lequan Yu

香港大学计算与数据科学学院，中国香港。*共同第一作者。通讯作者：Lequan Yu（lqyu@hku.hk）。

原文：Cross-Modal Alignment via Variational Copula Modelling。第 42 届国际机器学习大会，温哥华，加拿大；PMLR 267:67128-67146，2025。版权所有 © 2025 作者。

原文及出处：https://proceedings.mlr.press/v267/wu25d.html 。本中文译文依据 CC BY 4.0 制作，属于翻译与重新排版的改编，未经原作者审阅或认可。正文及附录完整翻译；图、表和复杂推导保留原版图像以保障数值与符号忠实性，另附中文图题、表题及标签说明。参考文献保留作者和出版信息，并提供中文题名。原文中可能存在的公式或数据不一致不作静默修正。

摘要

现实应用中常见多种数据模态，例如医疗保健中的电子健康记录、医学图像和临床笔记。因此，必须发展多模态学习方法，汇聚多个模态中的各种信息。主要挑战在于如何恰当地将不同模态的表示对齐、融合为联合分布。现有方法主要依赖拼接或 Kronecker 积，过度简化了模态之间的交互结构，说明有必要建模更复杂的交互。此外，具有高阶交互的潜在表示联合分布尚未得到充分探索。Copula（联结函数）是一种强大的统计结构，可用于建模变量之间的交互，因为它自然地连接多个变量的联合分布与边缘分布。我们提出一种新颖的 Copula 驱动多模态学习框架，着重学习不同模态的联合分布，以捕获它们之间的复杂交互。核心思想是将 Copula 模型解释为高效对齐各模态边缘分布的工具。通过为每个模态假设高斯混合分布，并为联合分布假设 Copula 模型，我们的模型也能为缺失模态生成准确表示。在公开 MIMIC 数据集上的大量实验证明，本模型优于其他竞争方法。代码：https://github.com/HKU-MedAI/CMCM 。

1. 引言

多模态学习旨在汇集多个模态的信息，为下游任务生成有意义的表示。这一方向已在视觉-语言模型（Fu 等，2023；El Banani 等，2023）、音频-视觉应用（Chen 等，2023；Mo 与 Tian，2023；Huang 等，2023）、图像-视频模型（Girdhar 等，2023；Gan 等，2023）及医疗应用（Wu 等，2024a；Hayat 等，2022）中得到广泛探索。例如，多模态学习已用于临床预测（Zhang 等，2023；Wu 等，2024a）、报告生成（Song 等，2022；Cao 等，2023）及临床试验中心选择（Theodorou 等，2024）等医疗任务。现有融合策略可分为早期融合、联合融合和晚期融合（Huang 等，2020）。联合融合最为流行，其核心是建模输入模态表示之间的交互（Hayat 等，2022）。由此产生的融合嵌入编码了模态间的结构性交互，从而能针对每个模态进行准确预测。

然而，由于不同模态的异质性，例如电子健康记录（EHR）、医学图像和医学报告，恰当地对齐它们的分布仍是一项挑战。现有对齐策略主要依赖拼接或 Kronecker 积，过度简化了不同模态之间的交互。近期工作（Salzmann 等，2022）强调对边缘分布作简单概率假设，却忽视了对模态联合分布的统计假设的探索。这可能产生有偏的融合表示，限制下游任务的性能，以及多模态模型的泛化性和鲁棒性。因此，仍然需要一种能更恰当地对齐模态分布、建模其潜在复杂交互的方法。

Copula 模型在变量交互建模中取得了巨大成功，因为它构建了联合分布与边缘分布之间的桥梁（Cherubini，2004）。但深度学习领域对它的研究较少，原因是多数现有方法高度依赖采样，例如 MCMC（Silva 与 Gramacy，2009）；这些方法速度较慢，难以扩展到现代深度学习场景（Smith 与 Loaiza-Maya，2023）。尽管近期一些研究尝试通过随机变分推断将 Copula 引入深度学习模型（Smith 与 Loaiza-Maya，2023），其在多模态学习中的潜力仍未被充分探索。

此外，现有多模态学习方法大多假设所有模态都存在。现实中，部分观测的某些模态可能因各种原因缺失，例如医疗中因临床或行政因素，某些患者没有医学图像或报告；这给多模态学习带来重大挑战。现有解决方案要么丢弃这些观测，要么用简单数值插补，例如零或其他观测的均值。然而，这些方法忽略了模态的边缘分布，往往误导联合分布的学习。因此，恰当学习边缘分布同样必要，才能为模态缺失的观测生成无偏的潜在表示。

针对上述挑战，我们提出一种新颖的 Copula 驱动多模态学习框架，称为 CM^2（通过变分 Copula 建模实现跨模态对齐），从概率角度处理联合融合范式。贡献如下：

1. 首次将 Copula 建模引入多模态学习，在 Sklar 定理保证下，将 Copula 解释为有效的分布对齐工具。
2. 对各模态的边缘分布采用高斯混合模型，更灵活地建模不同模态的高维特征分布。
3. 采用随机变分推断优化 Copula 模型，使其能够扩展到大规模数据集。
4. 将学得的边缘分布作为数据生成器，准确插补缺失观测。
5. 真实多模态 MIMIC 数据集上的实证结果显示良好性能；消融分析进一步证实了 Copula 在模态对齐中的有效性及面对潜在变化的鲁棒性。

2. 相关工作

多模态表示学习。 多模态表示学习旨在有效整合不同模态的信息，以准确预测下游任务。早期工作（Hayat 等，2022；Ding 等，2022；Trong 等，2020）关注晚期融合，例如使用拼接或 Kronecker 积合并单模态表示。然而，这些方法过度简化了模态交互，通常导致有偏的融合表示。因此，为实现更有效的多模态学习，需要将模态的结构性交互编码进融合表示。近期，模态交互建模日益受到关注。Liang 等（2024）提出信息分解框架，定义并量化模态之间不同类型的交互。基于 Transformer 的方法通过建模跨模态词元，极大推动了该方向（Zhang 等，2023；Theodorou 等，2024）。但使用 Transformer 匹配对应关系会引入很高的计算复杂度，因而需要更加高效的表示对齐方法。

Copula 深度学习。 Copula 是建模变量间交互或相关性的有前景工具，连接着联合分布与边缘分布。由于能够建模复杂交互，它已广泛用于金融风险管理（Hofert，2021；Rodriguez，2007）、信号处理及医疗保健（Zeng 与 Wang，2022）。传统 Copula 模型依赖似然的闭式解，并用基于采样的方法估计 Copula 参数，例如 MCMC（Silva 与 Gramacy，2009）。但这些算法的时间复杂度很高，不太适用于高维数据。随着深度学习兴起，已有工作将 Copula 模型融入深度学习框架（Tagasovska 等，

2019；Smith 等，2020）。为应对固有的高维性，研究者采用变分推断求解高维 Copula 模型（Tran 等，2015；Smith 与 Loaiza-Maya，2023）。例如，Tagasovska 等（2019）将 Copula 引入变分自编码器，构建深度生成模型。不过，它在多模态学习中的潜力仍未充分开发。

缺失数据下的学习。 传统多模态学习假定所有模态都可用，但实际中可能缺失部分观测，例如临床数据中的医学图像或报告。晚期融合是常见处理策略，通过汇聚可用模态的预测（Yoo 等，2019）或潜在空间表示（Theodorou 等，2024）处理缺失模态。这虽有效，却把各模态视为独立对象，缺少模态交互。一些研究提取跨模态共享信息用于下游任务（Deldari 等，2023；Yao 等，2024），但面对 EHR 和 CXR 等异质模态尤其具有挑战。在随机缺失（MAR）假设下，插补成为处理缺失数据的常用方法。一些方法假设缺失模态服从某种分布，使用该分布的均值或众数填补缺失值（Ma 等，2021）；另一些则通过深度学习模型在潜在特征空间中插补缺失模态表示，试图通过建模关系（Zhang 等，2022；Wu 等，2024b），或为缺失数据生成全局表示（Hayat 等，2022）来保持性能。尽管这些方法取得了成功，其分布假设或学得的关系可能不准确，从而引入偏差。因此，需要概率假设来保证所学习边缘分布的无偏性。

3. 方法

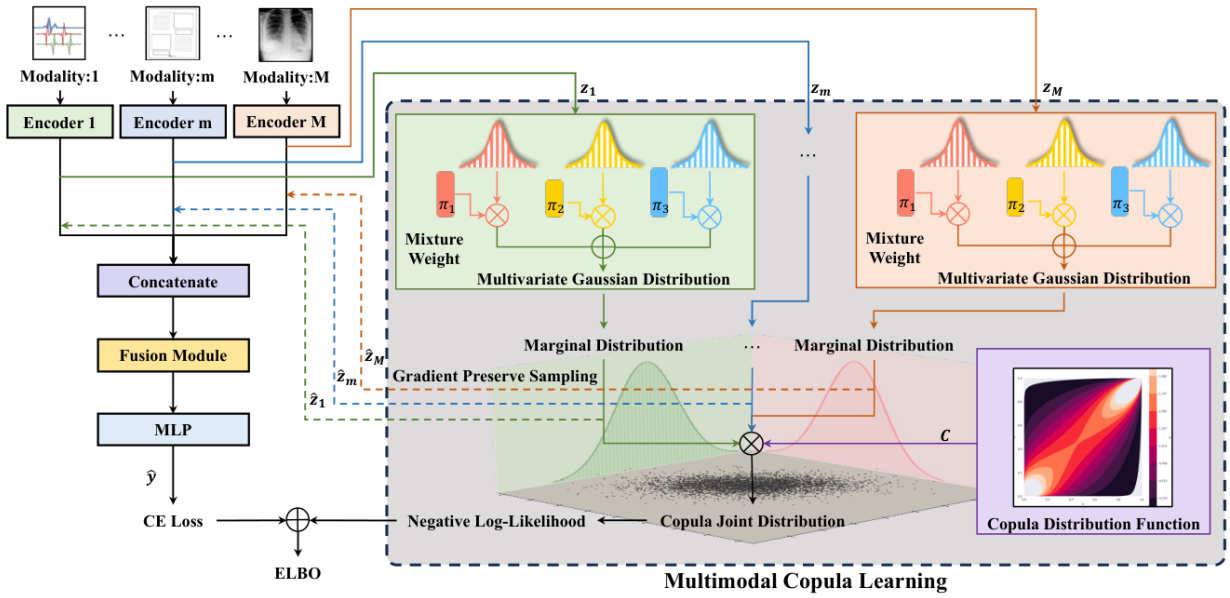


图 1. 所提出 CM^2 框架概览。对于具有 M 个模态的数据集，通过 Encoder_m 提取模态专属嵌入 $\mathbf{z}_m$，并计算其高斯混合模型（GMM）。随后建模边缘分布，使用 Copula 族 C 估计联合分布。如果模态 m 缺失，则从它的 GMM 采样 $\widehat{\mathbf{z}}_m$。拼接后的嵌入 $\mathbf{z}$ 通过双层 LSTM 融合模块和 MLP 分类器，预测 $\widehat{\mathbf{y}}$。将任务特定损失（如交叉熵）与联合分布的负对数似然汇总，即得到用于反向传播的 ELBO。图中标签：Modality=模态，Encoder=编码器，Concatenate=拼接，Fusion Module=融合模块，Mixture Weight=混合权重，Multivariate Gaussian Distribution=多元高斯分布，Marginal Distribution=边缘分布，Gradient Preserve Sampling=保梯度采样，Copula Joint Distribution=Copula 联合分布，Copula Distribution Function=Copula 分布函数，Negative Log-Likelihood=负对数似然，CE Loss=交叉熵损失，Multimodal Copula Learning=多模态 Copula 学习。

3.1. 预备知识

Copula。 M 元函数 $C(u_1, \ldots, c_M)$，其中所有 $u_m \in [0, 1]$，当且仅当它定义了随机向量 $(U_1, \ldots, U_M)$ 的有效联合累积分布函数（CDF），且每个 U_m 都在单位区间上服从均匀分布时，称其为 Copula。以二元 Gumbel Copula 为例，给定第一、第二模态的 CDF 值 u, v，二元分布为

$$C(u, v; \alpha) = \exp\{-\left[(-\log u)^{\alpha} + (-\log v)^{\alpha}\right]^{1/\alpha}\}.$$

其 Copula 密度为

$$c(u, v; \alpha) = \frac{1}{uv}(-\log v)^{\alpha-1}(-\log u)^{\alpha-1} C(u, v; \alpha) \times \left[g(u, v; \alpha)\right]^{2(1-\alpha)/\alpha}\left[(\alpha - 1)\left[g(u, v; \alpha)\right]^{-1/\alpha} + 1\right],$$

其中 $g(u, v; \alpha) = (-\log u)^{\alpha} + (-\log v)^{\alpha}$。不同 Copula 族的影响将在消融分析中讨论，各族及其分布、密度函数详见附录 C。

多模态学习。 给定多模态训练集 $\mathcal{D}_{tr} = \{(\boldsymbol{x}_1^{(i)}, \ldots, \boldsymbol{x}_M^{(i)}, y^{(i)})\}_{i=1}^{n}$，其中 $\boldsymbol{x}_m^{(i)}$ 是第 m 个模态的第 i 个观测， $y^{(i)}$ 为对应标签。目标是训练参数为 Θ 的多模态模型 $\mathcal{M}_{\Theta}(\cdot)$，使其在下游任务中达到最优性能。

3.2. Copula 多模态学习

图 1 展示所提出的 Copula 驱动多模态学习框架。给定多模态数据，我们提取各模态专属嵌入，并计算其 GMM。随后建模边缘密度，并使用 Copula 族 C 估计联合分布。若模态 m 缺失，则从其 GMM 生成特征嵌入。拼接的嵌入 $\mathbf{z}$ 通过融合模块和 MLP 分类器进行预测。证据下界（ELBO）结合了 Copula 对数似然和任务特定损失。

高斯混合假设。 GMM 是机器学习中建模高维分布行为的常用技术（Song 等，2024；Bai 等，2022；Ni 等，2021）。为生成更灵活的特征分布，假设第 m 个模态的特征分布服从包含 K 个分量的多元 GMM：

$$f_m(\mathbf{z}_m) = \sum_{k=1}^{K} \pi_{mk} \mathcal{N}(\boldsymbol{\mu}_{mk}, \boldsymbol{\Sigma}_{mk}). \qquad (1)$$

其中 π_{mk} 是混合权重， $\boldsymbol{\mu}_{mk}$ 和 $\boldsymbol{\Sigma}_{mk}$ 分别是第 m 个模态第 k 个混合分量的均值向量和协方差矩阵。令 $\boldsymbol{\mu} = \{\boldsymbol{\mu}_{mk} : m \in [M], k \in [K]\}$， $\boldsymbol{\Sigma} = \{\boldsymbol{\Sigma}_{mk} : m \in [M], k \in [K]\}$。不失一般性，我们用带 softmax 输出层的多层感知机（MLP）预测 π_{mk}，采用重参数化技巧（Nalisnick，2018；Tran 等，2022），假定 $\boldsymbol{\Sigma}_{mk}$ 为对角矩阵。进一步令 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 可通过梯度反向传播训练。使用 Marmin 等（2015）的近似计算多元高斯分布的 CDF。通过混合模型，可建模每个模态更广泛的分布，提升灵活性和鲁棒性。

多元 Copula。 使用多元 Copula，模态的联合分布函数为

$$F_{\mathbf{z}_1, \ldots, \mathbf{z}_M}(\mathbf{z}) = C(F_1(\mathbf{z}_1), \ldots, F_M(\mathbf{z}_M)),$$

其中右侧为 M 维 Copula 分布函数， $F_m(\mathbf{z}_m)$ 为第 m 个模态的边缘 CDF，即式（1）所定义 GMM 的 CDF。

3.3. 随机变分推断

为使 CM^2 能够扩展到现代深度学习场景，我们采用随机变分推断优化所提出的 Copula 模型，并将 Copula 参数 α 设为可训练。算法 1 给出整体流程。

算法 1. 所提方法的采样算法。

1. 输入：参数为 Θ 的多模态模型 $\mathcal{M}_\Theta(\cdot)$。
2. 输入：Copula 参数 α。
3. 输入：GMM 均值和协方差 $\{(\boldsymbol{\mu}_{mk}, \boldsymbol{\Sigma}_{mk}) \mid m = 1, \ldots, M;\ k = 1, \ldots, K\}$。
4. 输入：训练集 $\mathcal{D}_{tr} = \{(\mathbf{x}_1^{(i)}, \ldots, \mathbf{x}_M^{(i)}, y^{(i)})\}_{i=1}^n$。
5. 输出：训练好的 f_Θ（原文输出栏记号）。
6. 对 $\mathcal{D}_{tr}$ 中每个 $(\mathbf{x}_1^{(i)}, \ldots, \mathbf{x}_M^{(i)}, \mathbf{y}^{(i)})$：
   - 计算 $\widehat{y}^{(i)} = \mathcal{M}_\Theta(\mathbf{x}_1^{(i)}, \ldots, \mathbf{x}_M^{(i)})$。
   - 用 $\widehat{y}^{(i)}$ 和 $y^{(i)}$ 计算任务特定损失 $\mathcal{L}_{obj}$。
   - 计算 $\mathrm{KL}(q\|\pi)$，继而计算 ELBO。
   - 对 ELBO 反向传播以更新 Θ, α。
7. 循环结束，返回训练好的 $\mathcal{M}_\Theta$。

变分族。 使用变分后验 q 近似联合分布的真实后验。训练时优化的 Copula 模型变分族为

$$q(\mathbf{z}) = \Big[\prod_{m=1}^{M} q_m(\mathbf{z}_m)\Big] c\big(Q_1(\mathbf{z}_1), \ldots, Q_M(\mathbf{z}_M)\big),$$

其中 $q_m(\mathbf{z}_m)$ 是第 m 个模态 GMM 的变分后验密度， $Q_m(\mathbf{z}_m)$ 为对应 CDF。

证据下界（ELBO）。 联合目标可写为负对数似然的相反数（原文措辞及符号保留）：

$$\begin{aligned}\mathrm{ELBO} = &-\lambda_{cop}\sum_{i=1}^{n}\Big(\log c\Big(Q_1\big(\mathbf{z}_1^{(i)}\big), \ldots, Q_M\big(\mathbf{z}_M^{(i)}\big)\Big)\\ &-\sum_{m=1}^{M}\log f_m\big(\mathbf{z}_m^{(i)}\big)\Big) + \mathcal{L}_{obj},\end{aligned}$$

其中 $f_m(\mathbf{z}_m^{(i)})$ 是模态 m 的边缘密度， $c\big(Q_1(\mathbf{z}_1^{(i)}), \ldots, Q_M(\mathbf{z}_M^{(i)})\big)$ 是 Copula 密度； λ_{cop} 为 Copula 正则化参数， $\mathcal{L}_{obj}$ 为任务特定损失，如交叉熵。基于 ELBO 计算梯度并反向传播：对 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 更新以学习各模态边缘分布；对 α 更新以学习模态交互；对模型参数 Θ 更新以学习嵌入、融合和分类层。

3.4. 处理缺失模态

得益于概率化设计，本框架还可为缺失模态生成伪表示。不失一般性，假设模态随机缺失（MAR），并遵循先前工作（Tran 等，2017；Ma 等，2021；Zhang 等，2022；Wang 等，2023），在潜在空间插补其特征。我们考虑标签完整、仅观测缺失的情形。每个模态学得的 GMM 可作为数据生成模型，通过从该模态 GMM 采样生成特征嵌入，即 $\mathbf{z}_m^{(i)} \sim F_m$。随后将所生成特征作为分类层输入，获得预测。

通过学习 Copula 参数 α，各模态边缘分布包含其他模态的信息及交互信息。因此，生成的特征表示 $\mathbf{z}_m^{(i)}$ 能更好地反映联合分布的特性，改善表示质量和下游任务性能。

3.5. Sklar 定理提供的理论保证

利用 Sklar 定理说明联合分布的唯一性。

定理 3.1（Sklar 定理；Sklar，1959）。设 $F(x_1, \ldots, x_M)$ 是 $(X_1, \ldots, X_M)$ 的 M 元 CDF，第 m 个变量的边缘 CDF 为 $F_m(x_m)$，$m = 1, \ldots, M$。

（1） 存在 M 维 Copula，使得对所有 $x_m \in \mathbb{R}$，

$$C(F_1(x_1), \ldots, F_M(x_M)) = F(x_1, \ldots, x_M). \qquad (2)$$

（2） 反之，给定任意 Copula C 和一元 CDF $F_1, \ldots, F_M$，C 是 $(X_1, \ldots, X_M)$ 的有效联合 CDF。若 F 连续，式（2）中的 C 唯一。

上述定理为构造边缘分布相同、依赖结构不同的联合分布奠定基础；也可以反过来固定依赖结构、改变各模态的行为（Tagasovska 等，2019）。因此可以分别更新边缘分布与 Copula 参数。此外，我们为各模态假设 GMM，而 GMM 按定义连续，故 Copula C 的唯一性得到保证，模型的可辨识性也可增强。

4. 实验

4.1. 数据集与实验设置

数据集。使用大规模真实 EHR 数据集 MIMIC-III（Johnson 等，2016）、MIMIC-IV（Johnson 等，2023）和 MIMIC-CXR（Johnson 等，2019）评估 CM²。MIMIC-III、MIMIC-IV 是公开数据集，包含贝斯以色列女执事医疗中心（BIDMC）重症监护室（ICU）或急诊患者的真实 EHR，包括数值时间序列和临床笔记。MIMIC-CXR 包含 BIDMC 收集的胸部 X 光（CXR）图像及放射学报告，其部分患者与 MIMIC-IV 匹配。

遵循 Hayat 等（2022），使用 MIMIC-IV 与 MIMIC-CXR 进行多模态实验，同时扩展至 MIMIC-III。由于 MIMIC-III 没有 CXR 图像，我们用临床笔记替代。表 1 总结真实数据集及训练/验证/测试划分。从 MIMIC-IV 提取 25,071 次具有 EHR 的 ICU 住院，其中 5,931 次匹配 CXR 图像和报告；从

MIMIC-III 提取 21,139 次具有 EHR 的 ICU 住院，其中 5,273 次匹配临床笔记。为评估跨模态对齐性能，进行完全匹配的双模态和三模态实验；另在部分匹配数据集上评估缺失模态下的鲁棒性。更多细节见附录 A.1。

表 1. 训练、验证、测试集的样本数。表头：Datasets=数据集，Train=训练，Valid=验证，Test=测试，Total=总数；Complete Datasets=完整数据集，Matched Datasets=匹配数据集。

Datasets	Train	Valid	Test	Total
		Complete Datasets		
MIMIC-III	14,681	3,222	3,236	21,139
MIMIC-III NOTE	3,652	815	806	5,273
MIMIC-IV	18,064	2,035	4,972	25,071
MIMIC-CXR	344,529	9,497	23,069	377,095
		Matched Datasets		
MIMIC-III ∣ NOTE	3,652	815	806	5,273
MIMIC-IV ∣ CXR	4,287	465	1,179	5,931
MIMIC-IV ∣ CXR ∣ REPORT	4,287	465	1,179	5,931

任务与评估指标。遵循临床预测任务惯例（Hayat 等，2022；Zhang 等，2022；Wu 等，2024b；Wang 等，2024），聚焦两项任务：（1）院内死亡率（IHM）预测，即患者是否会在住院期间死亡；（2）再入院（READM）预测，即出院后 30 天内是否再次入院。使用精确率-召回率曲线下面积（AUPR）与受试者工作特征曲线下面积（AUROC）评估。报告基于 1,000 次 bootstrap 重采样的对应 95% 置信区间。

骨干编码器。遵循 Hayat 等（2022），CXR 图像采用 ResNet34（He 等，2016）；时间序列采用双层堆叠 LSTM（Graves 与 Graves，2012）；临床笔记和放射学报告采用 TinyBERT（Jiao 等，2019）。投影层将模态嵌入映射到相同潜在空间。

4.2. 比较方法

与以下基线比较：（1）MMTM（Joze 等，2020）是促进模态信息交换的灵活插件模块，训练和测试时用零填充缺失 CXR 与临床笔记。（2）DAFT（Pölsterl 等，2021）用于在 CNN 模型中交换表格数据与图像模态的信息，同样在训练、测试中用零矩阵替代缺失 CXR 与临床笔记。（3）Unified（Hayat 等，2021）动态整合辅助模态，通过统一分类器组合所有表示，本身可处理缺失数据，并利用全部可用的模态专属信息。（4）MedFUSE（Hayat 等，2022）基于 LSTM 融合图像或语言编码器与 EHR 编码器的特征，通过学习缺失 CXR 或笔记的全局表示处理缺失。（5）DrFuse（Yao 等，2024）使用解耦表示学习，即使一个模态缺失，也能在 EHR 与图像模态之间建立共享表示。

4.3. 实验结果

表 2. MIMIC-III 和 MIMIC-IV 在模态完全匹配情形下的 AUROC、AUPR 及 95% 置信区间。最佳结果加粗。Datasets=数据集，Models=模型，IHM=院内死亡，READM=再入院，↑表示越大越好。

Datasets	Models	IHM		READM	
		AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
MIMIC-III	MMTM (Joze et al., 2020)	0.776 (0.728,0.819)	0.347 (0.268,0.447)	0.716 (0.670,0.762)	0.341 (0.277,0.419)
	DAFT (Pölsterl et al., 2021)	0.792 (0.746,0.839)	0.388 (0.299,0.484)	0.701 (0.653,0.746)	0.325 (0.262,0.403)
	Unified (Hayat et al., 2021)	0.827 (0.782,0.868)	0.466 (0.371,0.569)	0.714 (0.662,0.759)	0.423 (0.344,0.504)
	MedFuse (Hayat et al., 2022)	0.826 (0.781,0.866)	0.430 (0.340,0.537)	0.725 (0.676,0.774)	0.414 (0.338,0.502)
	DrFuse (Yao et al., 2024)	0.835 (0.793,0.874)	0.511 (0.417,0.607)	0.749 (0.699,0.795)	0.441 (0.356,0.527)
	CM^2	**0.854** (0.820,0.861)	**0.513** (0.460,0.557)	**0.754** (0.731,0.774)	**0.445** (0.403,0.487)
MIMIC-IV	MMTM (Joze et al., 2020)	0.802 (0.770,0.835)	0.429 (0.362,0.513)	0.713 (0.677,0.750)	0.420 (0.362,0.489)
	DAFT (Pölsterl et al., 2021)	0.815 (0.782,0.844)	0.454 (0.387,0.538)	0.729 (0.692,0.766)	0.433 (0.378,0.499)
	Unified (Hayat et al., 2021)	0.808 (0.778,0.840)	0.429 (0.367,0.512)	0.719 (0.680,0.756)	0.450 (0.390,0.513)
	MedFuse (Hayat et al., 2022)	0.813 (0.777,0.844)	0.448 (0.380,0.528)	0.725 (0.690,0.762)	0.438 (0.379,0.508)
	DrFuse (Yao et al., 2024)	0.818 (0.784,0.850)	0.460 (0.391,0.540)	0.726 (0.689,0.760)	0.430 (0.370,0.495)
	CM^2	**0.827** (0.790,0.859)	**0.492** (0.423,0.566)	**0.737** (0.704,0.773)	**0.466** (0.404,0.529)

表 3. MIMIC-III 和 MIMIC-IV 在模态部分匹配（即存在缺失模态）情形下的 AUROC、AUPR 及 95% 置信区间。最佳结果加粗，表头含义同表 2。

Datasets	Models	IHM		READM	
		AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
MIMIC-III	MMTM (Joze et al., 2020)	0.846 (0.825,0.865)	0.450 (0.399,0.509)	0.742 (0.716,0.766)	0.413 (0.371,0.455)
	DAFT (Pölsterl et al., 2021)	0.854 (0.836,0.873)	0.495 (0.440,0.552)	0.748 (0.724,0.772)	0.429 (0.386,0.473)
	Unified (Hayat et al., 2021)	0.849 (0.829,0.868)	0.491 (0.436,0.542)	0.751 (0.728,0.772)	0.427 (0.383,0.467)
	MedFuse (Hayat et al., 2022)	0.850 (0.830,0.868)	0.480 (0.426,0.533)	0.753 (0.730,0.775)	0.437 (0.396,0.480)
	DrFuse (Yao et al., 2024)	0.839 (0.817,0.861)	0.474 (0.422,0.531)	0.749 (0.727,0.770)	0.411 (0.371,0.455)
	CM^2	**0.856** (0.833,0.877)	**0.510** (0.463,0.566)	**0.754** (0.708,0.795)	**0.445** (0.358,0.523)
MIMIC-IV	MMTM (Joze et al., 2020)	0.855 (0.840,0.869)	0.519 (0.477,0.561)	0.765 (0.747,0.783)	0.465 (0.430,0.501)
	DAFT (Pölsterl et al., 2021)	0.857 (0.841,0.870)	0.526 (0.487,0.565)	0.765 (0.747,0.782)	0.476 (0.442,0.510)
	Unified (Hayat et al., 2021)	0.854 (0.839,0.870)	0.505 (0.463,0.545)	0.759 (0.742,0.776)	0.470 (0.436,0.503)
	MedFuse (Hayat et al., 2022)	0.855 (0.840,0.870)	0.500 (0.458,0.541)	0.762 (0.744,0.778)	0.465 (0.430,0.501)
	DrFuse (Yao et al., 2024)	0.857 (0.841,0.872)	0.518 (0.479,0.562)	0.768 (0.749,0.784)	0.485 (0.451,0.520)
	CM^2	**0.858** (0.844,0.872)	**0.527** (0.490,0.568)	**0.771** (0.752,0.788)	**0.486** (0.452,0.518)

定量结果。 表 2 给出完全匹配情形的结果。CM^2 在全部情形下均优于五种基线。特别是 IHM 任务中，在 MIMIC-III 的 AUROC 上超过最佳基线 1.9%，在 MIMIC-IV 的 AUPR 上超过 3.2%。这些结果说明 CM^2 有效捕获模态交互，提高临床预测中多模态学习任务的性能。

表 3 给出部分匹配情形的结果。CM^2 在所有情形中均优于基线；在 MIMIC-III 上表现最佳，IHM 任务的 AUPR 超过最佳基线 1.5%，READM 任务的 AUPR 超过 0.8%。这说明 CM^2 能有效学习模态联合分布，在模态缺失时生成鲁棒且无偏的表示。

此外，部分匹配数据集上的性能优于匹配数据集，可能因为前者观测更多，突出说明了在缺失模态下开展多模态学习的重要性。最后，在部分匹配设置中，MIMIC-IV 的表现优于 MIMIC-III，可能因为前者观测更多。MIMIC-IV 的模态异质性也可能更强，导致完全匹配设置下两个数据集的性能差异。

定性分析。 我们可视化不同 Copula 族的密度，以考察如何捕获模态交互。图 2 分别展示 Gumbel、Gaussian、Frank 族学得的密度。Gumbel 更关注模态之间的正依赖，而 Gaussian 对尾部依赖的建模权重较低。Frank 具有尾部对称性，既能建模正依赖，也能建模负依赖，因此可覆盖更多依赖结构，

可能是建模复杂交互的更灵活选择。我们进一步通过不同训练轮次的密度图说明 CM^2 如何学习交互，详见附录 D。还研究了相关性随训练轮次的学习过程。图 3 给出估计的 α 及对应相关性 $(\alpha-1)/\alpha$ 的变化。模型逐渐学得正相关，相关性约收敛于 0.601。这表明通过将梯度反向传播至 Copula 参数 α，模型可在训练中学习模态间交互。

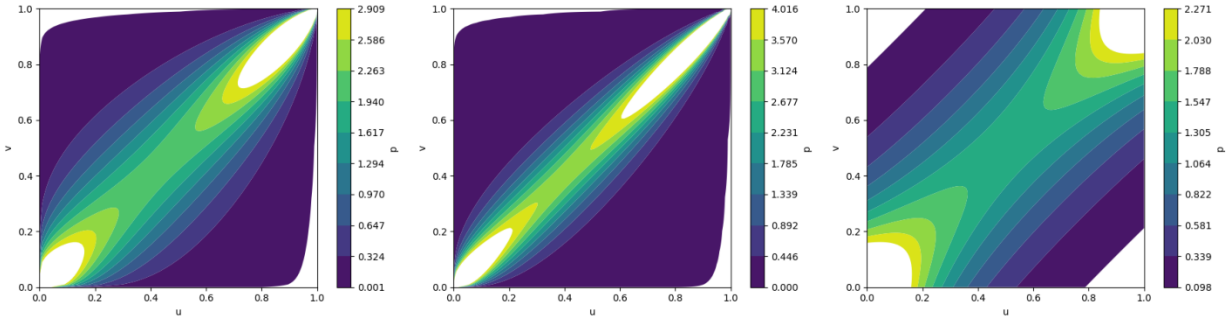


图 2. 拟合的 Copula 密度，展示模型捕获的相互关系。左：Gumbel；中：Gaussian；右：Frank。

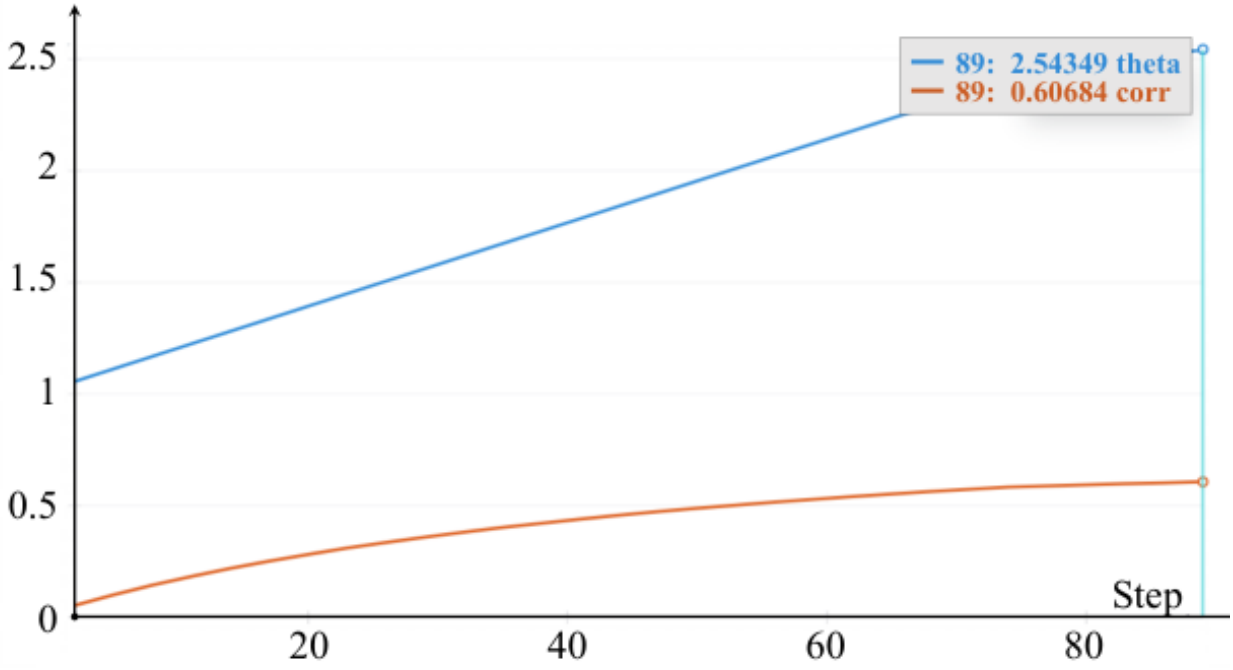


图 3. Gumbel Copula 模型学得的 α 与相关性 $\text{Corr} = (\alpha-1)/\alpha$ 的对比。Step=训练步，theta=参数 α，corr=相关性。

4.4. 消融分析

Copula 对齐的有效性。 表 4 研究对齐损失的影响。Copula 对齐损失表现最佳，优于常用的余弦相似性对齐与 KL 散度对齐。

表 4. 不同对齐损失函数在 MIMIC-IV 上的 AUROC 和 AUPR 消融。Alignment loss=对齐损失；Cosine=余弦，KL=KL 散度。

Alignment loss	IHM		READM	
	AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
Cosine	0.820	0.470	0.726	0.445
KL	0.826	0.489	0.731	0.446
Copula	0.827	0.492	0.737	0.466

设计模块的贡献消融。 为进一步评估 CM^2，分别移除 Copula 对齐、保梯度采样（GPS）及融合模块。表 5 显示，移除 Copula 对齐后性能显著下降，强调在融合模态特征前建模 Copula 联合分布的重要性。多数情况下，移除融合模块也显著降低性能，说明它对捕获模态交互很重要。此外，移除 GPS 后性能略降，表明其能有效为模态缺失的观测生成无偏表示。

表 5. 所提方法各组件（Copula 对齐、保梯度采样 GPS、融合模块）在 MIMIC-IV 上的影响。w/o=不使用，Matched=是否完全匹配；√为是，×为否。

Models	Matched	IHM		READM	
		AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
w/o copula	×	0.855	0.506	0.753	0.459
w/o GPS	×	0.858	0.521	0.763	0.473
w/o fusion	×	0.860	0.531	0.762	0.476
CM^2	×	0.858	0.527	0.771	0.486
w/o copula	✓	0.809	0.434	0.717	0.424
w/o fusion	✓	0.811	0.446	0.720	0.424
CM^2	✓	0.827	0.492	0.737	0.466

不同 Copula 族的消融。 我们比较缺失模态与 Copula 族的不同设置。准确性高度依赖所假设的族（Zeng 与 Wang，2022）。考察了一组常用 Copula 族，结果见表 6。整体上方法对族的选择较鲁棒，但不同任务中表现最佳的族不同。这表明不同任务强调不同特征，例如死亡预测中的极端值，而选择合适的 Copula 族可捕获这些特征。

表 6. 不同 Copula 族及缺失模态对 MIMIC-IV 结果的影响。Matched 含义同表 5，Gaussian=高斯。

Matched	Copula	IHM		READM	
		AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
×	Gumbel	0.858	0.527	0.772	0.485
✓	Gumbel	0.825	0.488	0.735	0.463
×	Frank	0.858	0.527	0.771	0.486
✓	Frank	0.827	0.492	0.737	0.466
×	Gaussian	0.859	0.527	0.771	0.485
✓	Gaussian	0.827	0.488	0.736	0.458

扩展到更多模态。 进一步研究加入更多辅助模态的影响，将全部基线扩展至三模态设置。表 7 给出 EHR 时间序列、CXR 图像和放射学报告三模态下的 MIMIC-IV 结果。CM^2 在两项任务上持续优于基线并取得最佳性能。值得注意的是，基线相对双模态设置性能下降，表明随着对齐复杂度增加，加入更多模态更具挑战。尽管如此，CM^2 仍保持较强性能，体现了多模态对齐的鲁棒性和有效性。

表 7. MIMIC-IV 上使用三个模态（EHR 时间序列、CXR 图像和 CXR 报告）的 AUROC、AUPR 及 95% 置信区间。表头同表 2。

Models	IHM		READM	
	AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
MMTM (Joze et al., 2020)	$0.777_{(0.739,0.813)}$	$0.370_{(0.312,0.443)}$	$0.689_{(0.650,0.723)}$	$0.401_{(0.347,0.463)}$
DAFT (Pölsterl et al., 2021)	$0.788_{(0.754,0.821)}$	$0.397_{(0.331,0.471)}$	$0.706_{(0.670,0.742)}$	$0.403_{(0.346,0.464)}$
Unified (Hayat et al., 2021)	$0.795_{(0.761,0.827)}$	$0.420_{(0.351,0.497)}$	$0.715_{(0.679,0.749)}$	$0.430_{(0.376,0.495)}$
MedFuse (Hayat et al., 2022)	$0.801_{(0.767,0.836)}$	$0.427_{(0.367,0.511)}$	$0.713_{(0.675,0.749)}$	$0.419_{(0.356,0.487)}$
DrFuse (Yao et al., 2024)	$0.808_{(0.773,0.839)}$	$0.451_{(0.376,0.524)}$	$0.728_{(0.691,0.761)}$	$0.433_{(0.370,0.495)}$
CM^2	$\mathbf{0.824}_{(0.793,0.856)}$	$\mathbf{0.471}_{(0.399,0.554)}$	$\mathbf{0.730}_{(0.694,0.764)}$	$\mathbf{0.444}_{(0.385,0.509)}$

5. 结论

我们将 Copula 建模引入多模态表示学习。Copula 可有效建模不同模态的交互，并通过从所学边缘分布采样插补缺失模态。实证评估在完全匹配与部分匹配数据集上验证了多模态学习任务的预测性能。消融表明，所提 Copula 模型在不同族上始终表现令人满意，因而可成为有前景的模态对齐工具。该思想还可扩展到需要有效融合或分布对齐的工作，包括领域自适应、多特征学习和多视图学习。

局限与未来工作。 用神经网络学习 Copula 参数 α 可能不充分，因为联合对数似然未必凸。因此，未来发展 Copula 多模态学习时，需要其他更新算法（例如偏似然），以确保各损失凸，从而应用梯度下降。虽然本文选择医疗数据集展示有效性，本方法也可扩展到其他多模态数据集。

致谢。 感谢程序主席、领域主席及审稿人的诸多建设性建议，显著改善了本文。本工作部分受香港研究资助局（17308321、27206123、C5055-24G、T45-401/22-N）、Patrick SC Poon 捐赠基金、香港创新及科技基金（ITS/273/22、ITS/274/22）、国家自然科学基金（62201483）及广东省自然科学基金（2024A1515011875）资助。

影响声明

本工作旨在推动机器学习领域的发展。它可潜在扩展到需要有效融合或分布对齐的领域，包括领域自适应、多特征学习和多视图学习。

参考文献

以下保留原文作者、刊物、年份、页码及标识；中文题名置于方括号，便于检索时对应原文。

Bai, J., Kong, S., and Gomes, C. P. Gaussian mixture variational autoencoder with contrastive learning for multi-label classification. [用于多标签分类、结合对比学习的高斯混合变分自编码器。] In International Conference on Machine Learning, pp. 1383-1398. PMLR, 2022.

Cao, Y., Cui, L., Zhang, L., Yu, F., Li, Z., and Xu, Y. Mmtn: multi-modal memory transformer network for image-report consistent medical report generation. [MMTN：用于图像-报告一致医学报告生成的多模态记忆 Transformer 网络。] In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 277-285, 2023.

Chen, J., Zhang, R., Lian, D., Yang, J., Zeng, Z., and Shi, J. iquery: Instruments as queries for audio-visual sound separation. [iQuery：以乐器为查询的音频-视觉声音分离。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 14675-14686, 2023.

Cherubini, U. Copula methods in finance. [金融中的 Copula 方法。] John Wiley & Sons google schola, 2:949-956, 2004.

Deldari, S., Spathis, D., Malekzadeh, M., Kawsar, F., Salim, F., and Mathur, A. Latent masking for multimodal self-supervised learning in health timeseries. [用于健康时间序列多模态自监督学习的潜在掩码。] arXiv preprint arXiv:2307.16847, 2023.

Ding, N., Tian, S.-w., and Yu, L. A multimodal fusion method for sarcasm detection based on late fusion. [基于晚期融合的讽刺检测多模态融合方法。] Multimedia Tools and Applications, 81(6):8597-8616, 2022.

Dosovitskiy, A. An image is worth 16x16 words: Transformers for image recognition at scale. [一张图像值 16×16 个词：面向大规模图像识别的 Transformer。] arXiv preprint arXiv:2010.11929, 2020.

El Banani, M., Desai, K., and Johnson, J. Learning visual representations via language-guided sampling. [通过语言引导采样学习视觉表示。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 19208-19220, 2023.

Fu, Z., Mao, Z., Song, Y., and Zhang, Y. Learning semantic relationship among instances for image-text matching. [为图像-文本匹配学习实例间语义关系。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 15159-15168, 2023.

Gan, T., Wang, Q., Dong, X., Ren, X., Nie, L., and Guo, Q. Cnvid-3.5 m: Build, filter, and pre-train the large-scale public chinese video-text dataset. [Cnvid-3.5 m：构建、过滤并预训练大规模公开中文视频-文本数据集。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 14815-14824, 2023.

Girdhar, R., El-Nouby, A., Singh, M., Alwala, K. V., Joulin, A., and Misra, I. Omnimae: Single model masked pre-training on images and videos. [OmniMAE：图像与视频的单模型掩码预训练。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10406-10417, 2023.

Graves, A. and Graves, A. Long short-term memory. [长短期记忆。] Supervised sequence labelling with recurrent neural networks, pp. 37-45, 2012.

Harutyunyan, H., Khachatrian, H., Kale, D. C., Ver Steeg, G., and Galstyan, A. Multitask learning and benchmarking with clinical time series data. [临床时间序列数据的多任务学习与基准评测。] Scientific Data, 6(1):96, 2019.

Hayat, N., Geras, K. J., and Shamout, F. E. Towards dynamic multi-modal phenotyping using chest radiographs and physiological data. [利用胸部 X 光和生理数据实现动态多模态表型分析。] arXiv preprint arXiv:2111.02710, 2021.

Hayat, N., Geras, K. J., and Shamout, F. E. Medfuse: Multi-modal fusion with clinical time-series data and chest x-ray images. [MedFuse：临床时间序列数据与胸部 X 光图像的多模态融合。] In Machine Learning for Healthcare Conference, pp. 479-503. PMLR, 2022.

He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. [用于图像识别的深度残差学习。] In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770-778, 2016.

Hofert, M. Right-truncated archimedean and related copulas. [右截断阿基米德及相关 Copula。] Insurance: Mathematics and Economics, 99:79-91, 2021.

Huang, C., Tian, Y., Kumar, A., and Xu, C. Egocentric audio-visual object localization. [第一视角音频-视觉目标定位。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 22910-22921, 2023.

Huang, S.-C., Pareek, A., Seyyedi, S., Banerjee, I., and Lungren, M. P. Fusion of medical imaging and electronic health records using deep learning: a systematic review and implementation guidelines. [使用深度学习融合医学影像与电子健康记录：系统综述和实施指南。] NPJ Digital Medicine, 3(1):136, 2020.

Jiao, X., Yin, Y., Shang, L., Jiang, X., Chen, X., Li, L., Wang, F., and Liu, Q. Tinybert: Distilling bert for natural language understanding. [TinyBERT：为自然语言理解蒸馏 BERT。] arXiv preprint arXiv:1909.10351, 2019.

Johnson, A. E., Pollard, T. J., Shen, L., Lehman, L.-w. H., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Anthony Celi, L., and Mark, R. G. Mimic-iii, a freely accessible critical care database. [MIMIC-III：可自由访问的重症监护数据库。] Scientific Data, 3(1):1-9, 2016.

Johnson, A. E., Pollard, T. J., Berkowitz, S. J., Greenbaum, N. R., Lungren, M. P., Deng, C.-y., Mark, R. G., and Horng, S. Mimic-cxr, a de-identified publicly available database of chest radiographs with free-text reports. [MIMIC-CXR：去标识化、公开可用且带自由文本报告的胸部 X 光数据库。] Scientific Data, 6(1):317, 2019.

Johnson, A. E., Bulgarelli, L., Shen, L., Gayles, A., Shammout, A., Horng, S., Pollard, T. J., Hao, S., Moody, B., Gow, B., et al. Mimic-iv, a freely accessible electronic health record dataset. [MIMIC-IV：可自由访问的电子健康记录数据集。] Scientific Data, 10(1):1, 2023.

Joze, H. R. V., Shaban, A., Iuzzolino, M. L., and Koishida, K. Mmtm: Multimodal transfer module for cnn fusion. [MMTM：用于 CNN 融合的多模态迁移模块。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 13289-13299, 2020.

Khader, F., Müller-Franzes, G., Wang, T., Han, T., Tayebi Arasteh, S., Haarburger, C., Stegmaier, J., Bressem, K., Kuhl, C., Nebelung, S., et al. Multimodal deep learning for integrating chest radiographs and clinical parameters: a case for transformers. [整合胸部 X 光和临床参数的多模态深度学习：Transformer 的应用。] Radiology, 309(1):e230806, 2023.

Liang, P. P., Cheng, Y., Fan, X., Ling, C. K., Nie, S., Chen, R., Deng, Z., Allen, N., Auerbach, R., Mahmood, F., et al. Quantifying & modeling multimodal interactions: An information decomposition framework. [量化与建模多模态交互：信息分解框架。] Advances in Neural Information Processing Systems, 36, 2024.

Ma, M., Ren, J., Zhao, L., Tulyakov, S., Wu, C., and Peng, X. Smil: Multimodal learning with severely missing modality. [SMIL：模态严重缺失下的多模态学习。] In Proceedings of the AAAI Conference on Artificial Intelligence, volume 35, pp. 2302-2310, 2021.

Marmin, S., Chevalier, C., and Ginsbourger, D. Differentiating the multipoint expected improvement for optimal batch design. [对多点期望改进求导以实现最优批量设计。] In International Workshop on Machine Learning, Optimization and Big Data, pp. 37-48. Springer, 2015.

Mo, S. and Tian, Y. Audio-visual grouping network for sound localization from mixtures. [用于混合声音定位的音频-视觉分组网络。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10565-10574, 2023.

Nalisnick, E. T. On priors for Bayesian neural networks. [论贝叶斯神经网络的先验。] University of California, Irvine, 2018.

Ni, J., Cheng, W., Chen, Z., Asakura, T., Soma, T., Kato, S., and Chen, H. Superclass-conditional gaussian mixture model for learning fine-grained embeddings. [用于学习细粒度嵌入的超类条件高斯混合模型。] In International Conference on Learning Representations, 2021.

Pölsterl, S., Wolf, T. N., and Wachinger, C. Combining 3d image and tabular data via the dynamic affine feature map transform. [通过动态仿射特征图变换结合三维图像与表格数据。] In Medical Image Computing and Computer Assisted Intervention-MICCAI 2021: 24th International Conference, Strasbourg, France, September 27-October 1, 2021, Proceedings, Part V 24, pp. 688-698. Springer, 2021.

Rodriguez, J. C. Measuring financial contagion: A copula approach. [衡量金融传染：Copula 方法。] Journal of Empirical Finance, 14(3):401-423, 2007.

Salzmann, T., Pavone, M., and Ryll, M. Motron: Multi-modal probabilistic human motion forecasting. [Motron：多模态概率人体运动预测。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 6457-6466, 2022.

Silva, R. and Gramacy, R. Mcmc methods for bayesian mixtures of copulas. [用于贝叶斯 Copula 混合的 MCMC 方法。] In Artificial Intelligence and Statistics, pp. 512-519. PMLR, 2009.

Sklar, M. Fonctions de répartition à n dimensions et leurs marges. [n 维分布函数及其边缘分布。] In Annales de l'ISUP, volume 8, pp. 229-231, 1959.

Smith, M. S. and Loaiza-Maya, R. Implicit copula variational inference. [隐式 Copula 变分推断。] Journal of Computational and Graphical Statistics, 32(3):769-781, 2023.

Smith, M. S., Loaiza-Maya, R., and Nott, D. J. High-dimensional copula variational approximation through transformation. [通过变换进行高维 Copula 变分近似。] Journal of Computational and Graphical Statistics, 29(4):729-743, 2020.

Song, A. H., Chen, R. J., Ding, T., Williamson, D. F., Jaume, G., and Mahmood, F. Morphological prototyping for unsupervised slide representation learning in computational pathology. [计算病理学中用于无监督切片表示学习的形态原型构建。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 11566-11578, 2024.

Song, X., Zhang, X., Ji, J., Liu, Y., and Wei, P. Cross-modal contrastive attention model for medical report generation. [用于医学报告生成的跨模态对比注意力模型。] In Proceedings of the 29th International Conference on Computational Linguistics, pp. 2388-2397, 2022.

Tagasovska, N., Ackerer, D., and Vatter, T. Copulas as high-dimensional generative models: Vine copula autoencoders. [作为高维生成模型的 Copula：Vine Copula 自编码器。] Advances in Neural Information Processing Systems, 32, 2019.

Theodorou, B., Glass, L., Xiao, C., and Sun, J. Framm: Fair ranking with missing modalities for clinical trial site selection. [FRAMM：临床试验中心选择中模态缺失下的公平排序。] Patterns, 5(3), 2024.

Tran, B.-H., Rossi, S., Milios, D., and Filippone, M. All you need is a good functional prior for bayesian deep learning. [贝叶斯深度学习只需要一个良好的函数先验。] Journal of Machine Learning Research, 23(74):1-56, 2022.

Tran, D., Blei, D., and Airoldi, E. M. Copula variational inference. [Copula 变分推断。] Advances in Neural Information Processing Systems, 28, 2015.

Tran, L., Liu, X., Zhou, J., and Jin, R. Missing modalities imputation via cascaded residual autoencoder. [通过级联残差自编码器插补缺失模态。] In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 1405-1414, 2017.

Trong, V. H., Gwang-hyun, Y., Vu, D. T., and Jin-young, K. Late fusion of multimodal deep neural networks for weeds classification. [用于杂草分类的多模态深度神经网络晚期融合。] Computers and Electronics in Agriculture, 175:105506, 2020.

Vaswani, A. Attention is all you need. [注意力就是你所需要的。] Advances in Neural Information Processing Systems, 2017.

Wang, H., Chen, Y., Ma, C., Avery, J., Hull, L., and Carneiro, G. Multi-modal learning with missing modality via shared-specific feature modelling. [通过共享-专有特征建模进行缺失模态下的多模态学习。] In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 15878-15887, 2023.

Wang, Y., Pillai, M., Zhao, Y., Curtin, C., and Hernandez-Boussard, T. Fairehr-clp: Towards fairness-aware clinical predictions with contrastive learning in multimodal electronic health records. [FairEHR-CLP：通过多模态电子健康记录中的对比学习实现公平性感知的临床预测。] arXiv preprint arXiv:2402.00955, 2024.

Wu, Z., Dadu, A., Tustison, N., Avants, B., Nalls, M., Sun, J., and Faghri, F. Multimodal patient representation learning with missing modalities and labels. [模态和标签缺失下的多模态患者表示学习。] In The Twelfth International Conference on Learning Representations, 2024a.

Wu, Z., Dadu, A., Tustison, N., Avants, B., Nalls, M., Sun, J., and Faghri, F. Multimodal patient representation learning with missing modalities and labels. [模态和标签缺失下的多模态患者表示学习。] In The Twelfth International Conference on Learning Representations, 2024b.

Yao, W., Yin, K., Cheung, W. K., Liu, J., and Qin, J. Drfuse: Learning disentangled representation for clinical multi-modal fusion with missing modality and modal inconsistency. [DrFuse：为模态缺失与模态不一致下的临床多模态融合学习解耦表示。] In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 16416-16424, 2024.

Yoo, Y., Tang, L. Y., Li, D. K., Metz, L., Kolind, S., Traboulsee, A. L., and Tam, R. C. Deep learning of brain lesion patterns and user-defined clinical and mri features for predicting conversion to multiple sclerosis from clinically isolated syndrome. [对脑病变模式及用户定义的临床、MRI 特征进行深度学习，预测临床孤立综合征向多发性硬化的转化。] Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization, 7(3):250-259, 2019.

Zeng, Z. and Wang, T. Neural copula: A unified framework for estimating generic high-dimensional copula functions. [神经 Copula：估计通用高维 Copula 函数的统一框架。] arXiv preprint arXiv:2205.15031, 2022.

Zhang, C., Chu, X., Ma, L., Zhu, Y., Wang, Y., Wang, J., and Zhao, J. M3care: Learning with missing modalities in multimodal healthcare data. [M3Care：多模态医疗数据中模态缺失下的学习。] In Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 2418-2428, 2022.

Zhang, X., Li, S., Chen, Z., Yan, X., and Petzold, L. R. Improving medical predictions by irregular multimodal electronic health records modeling. [通过不规则多模态电子健康记录建模改善医学预测。] In International Conference on Machine Learning, pp. 41300-41313. PMLR, 2023.

附录

概览

本附录首先在 A.1 介绍数据集详情，在 A.2 介绍实验任务。随后 B 节介绍多元高斯分布，C 节介绍常见 Copula 族。D 节讨论 Copula 模型随训练轮次学习交互的含义。最后，E.1 提供实验实现和超参数的更多细节，E.2 介绍基线设置。

A. 数据集和任务的补充信息

A.1. 数据集

表 8 总结实验使用的数据集。

MIMIC-III。 包含 46,520 次 ICU 住院，每次有 17 个临床变量。遵循 Harutyunyan 等（2019），按 70:15:15 划分训练、验证和测试集。

MIMIC-IV。 包含 21,139 次 ICU 住院，同样有 17 个临床变量。遵循 Hayat 等（2022），按 70:10:20 划分训练、验证和测试集。

对于两个数据集，提取 ICU 常规监测的 17 个临床变量，包括 5 个分类变量及 12 个连续变量。遵循 Hayat 等（2022），两个任务均在入 ICU 后最初 48 小时内每两小时采样一次。这使临床时间序列每个时间步形成大小为 76 的向量表示。

MIMIC-CXR。 包含 377,110 张胸部 X 光图像，其中 5,931 张与 MIMIC-IV 的 ICU 住院关联。划分为 4,287 个训练样本、465 个验证样本及 1,179 个测试样本。遵循 Hayat 等（2022），取最后一次前后位投照的胸部 X 光，对图像做变换并调整为 224×224 像素。

该数据集也包含非结构化文本形式的放射学报告。我们选择这些报告作为辅助模态，研究 CM^2 对更多模态的对齐效果；由于报告不含死亡信息，可以避免潜在过拟合和捷径。将非结构化报告分为四部分：诊断印象（Impression）、影像所见（Findings）、末段（Last paragraph）和对比（Comparison）。

MIMIC-III NOTE。 包含 5,273 份与 MIMIC-III ICU 住院关联的临床笔记，划分为 3,652 个训练样本、815 个验证样本和 806 个测试样本。遵循 Zhang 等（2023），选择预测时间之前最后五份笔记；不足五份时，将该次住院的笔记视为缺失。原本匹配的 ICU 住院约 15,000 次，我们随机抽取其中三分之一形成训练、验证和测试集，使笔记规模与 MIMIC-IV 的 CXR 大致相当。

放射学报告各部分和临床笔记的最大长度均为 512 词，进行词级分词，并用预训练 TinyBERT（Jiao 等，2019）嵌入成 312 维向量。脚注 1：https://huggingface.co/huawei-noah/TinyBERT_General_4L_312D 。

A.2. 任务

院内死亡（IHM）预测。 预测患者是否在住院期间死亡。表 8 显示，MIMIC-III 共 2,795 个阳性样本，其中 736 个匹配临床笔记；MIMIC-IV 有 3,153 个阳性样本，其中 890 个匹配 CXR。

再入院（READM）预测。 预测患者是否在出院后 30 天内再次入院。该任务将再次入院者和住院期间死亡者均视为阳性。表 8 显示，MIMIC-III 有 3,987 个阳性样本，其中 998 个匹配临床笔记；MIMIC-IV 有 4,603 个阳性样本，其中 1,262 个匹配 CXR。

表 8. 训练/验证/测试集的样本数。Datasets=数据集，Tasks=任务，Train=训练，Valid=验证，Test=测试，Pos.=阳性样本，Total=总数；Complete Datasets=完整数据集，Matched Datasets=匹配数据集。

Datasets	Tasks	Train	Valid	Test	Pos.	Total
			Complete Datasets			
MIMIC-III	IHM	14681	3222	3236	2795	21139
MIMIC-III	READM	14681	3222	3236	3987	21139
MIMIC-III NOTE	–	3652	815	806	–	5,273
MIMIC-IV	IHM	18064	2035	4972	3153	25071
MIMIC-IV	READM	18064	2035	4972	4603	25071
MIMIC-CXR	–	344529	9497	23069	–	377,095
			Matched Datasets			
MIMIC-III ∣ NOTE	IHM	3652	815	806	736	5273
MIMIC-III ∣ NOTE	READM	3652	815	806	998	5273
MIMIC-IV ∣ CXR	IHM	4287	465	1179	890	5931
MIMIC-IV ∣ CXR	READM	4287	465	1179	1262	5931
MIMIC-IV ∣ CXR ∣ REPORT	IHM	4287	465	1179	890	5931
MIMIC-IV ∣ CXR ∣ REPORT	READM	4287	465	1179	1262	5931

译者注：本节原文的部分总样本数与表 1、表 8 不一致，本译文忠实保留，未擅自修正。

B. 多元高斯分布

多元高斯分布定义为

$$p(\mathbf{z};\, \boldsymbol{\mu},\, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{ -\frac{1}{2}(\mathbf{z}-\boldsymbol{\mu})^{\top}\boldsymbol{\Sigma}^{-1}(\mathbf{z}-\boldsymbol{\mu})\right\},$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^p$ 是 p 维均值向量，$\boldsymbol{\Sigma} \in \mathbb{R}^{p\times p}$ 是协方差矩阵。两个多元正态分布 $\mathcal{N}(\boldsymbol{\mu}_1,\, \Sigma_1)$、$\mathcal{N}(\boldsymbol{\mu}_2,\, \Sigma_2)$ 的 KL 散度为

$$\begin{aligned}\mathrm{KL}(\mathcal{N}(\boldsymbol{\mu}_1,\, \boldsymbol{\Sigma}_1)\|\mathcal{N}(\boldsymbol{\mu}_2,\, \boldsymbol{\Sigma}_2)) = \frac{1}{2}\Big[&\log\frac{|\boldsymbol{\Sigma}_2|}{|\boldsymbol{\Sigma}_1|} - p + \mathrm{tr}\{\boldsymbol{\Sigma}_2^{-1}\boldsymbol{\Sigma}_1\} \\ &+ (\boldsymbol{\mu}_2-\boldsymbol{\mu}_1)^{\top}\boldsymbol{\Sigma}_2^{-1}(\boldsymbol{\mu}_2-\boldsymbol{\mu}_1)\Big].\end{aligned}$$

C. 常见 Copula 族

下面给出常见 Copula 族的分布、密度函数及必要推导。不失一般性，考虑二元 Copula 族。

阿基米德 Copula。可通过生成函数 $\varphi : [0,\, 1] \to [0,\, \infty]$ 方便地构造一类 Copula。该函数严格递减且凸，并满足 $\varphi(0) = \infty,\, \varphi(1) = 0$。于是可构造

$$C(u_1,\, u_2,\, \ldots,\, u_d) = \varphi^{[-1]}\Big(\sum_{i=1}^{d}\varphi(u_i)\Big).$$

当数据集含有不止一个模态时，阿基米德 Copula 可生成 Copula 密度。

C.1. Copula 分布函数

Clayton Copula：

$$C(u,\, v;\, \alpha) = \left[\max\{u^{-\alpha} + v^{-\alpha} - 1,\, 0\}\right]^{-1/\alpha}.$$

Frank Copula：

$$C(u,\, v;\, \alpha) = -\frac{1}{\alpha}\log\left[1 - \frac{(1-e^{\alpha u})(1-e^{\alpha v}))}{1-e^{-\alpha}}\right],$$

其中 $\alpha \in \mathbb{R}\backslash\{0\}$。译者注：指数正负号及多余右括号按原文保留。

Gumbel Copula：

$$C(u,\, v;\, \alpha) = \exp\{-\left[(-\log u)^{\alpha} + (-\log v)^{\alpha}\right]^{1/\alpha}\}.$$

Gaussian Copula：

$$C(u,\, v;\, \rho) = \Phi_2\left[\Phi^{-1}(u),\, \Phi^{-1}(v);\, \rho\right],$$

其中 Φ 为标准高斯分布的 CDF，Φ_2 为二元高斯分布。

Student t Copula：

$$C(u,\ v;\ \rho,\ \nu) = T_{2,\nu}\left[T_{\nu}^{-1}(u),\ T_{\nu}^{-1}(v);\ \rho\right], \qquad v > 0;\ \ |\rho| < 1,$$

其中 T_{ν}^{-1} 为自由度 ν 的 Student t 分布 CDF 的逆函数，$T_{2,\nu}$ 为自由度 ν 的二元 t 分布。条件中的 v 按原文保留。

C.2. Copula 密度函数

Clayton Copula：

$$c(u,\ v) = (1+\alpha)(uv)^{-1-\alpha}(-1+u^{-\alpha}+v^{-\alpha})^{-2-1/\alpha},$$

其中 $\alpha \in (-1,\ \infty)$。

Frank Copula：

$$c(u,\ v) = \frac{-\alpha e^{-\alpha(u+v)}(e^{-\alpha}-1)}{\left(e^{-\alpha}-e^{-\alpha u}-e^{-\alpha v}+e^{-\alpha(u+v)}\right)^2},$$

其中 $\alpha \in (-\infty,\ \infty),\ \alpha \neq 0$。

Gumbel Copula。 完整二元密度推导如下。为准确保留每一步的导数、上下标及括号，直接保留原式：

$$
\begin{aligned}
c(u,v) =& \frac{\partial}{\partial u}\frac{\partial}{\partial v}C(u,v) \\
=& \frac{\partial}{\partial u}\frac{\partial}{\partial v}\exp\{-\left[(-\log u)^{\alpha}+(-\log v)^{\alpha}\right]^{1/\alpha}\} \\
:=& \frac{\partial}{\partial u}\frac{\partial}{\partial v}\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\} \\
=& \frac{\partial}{\partial u}-\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\left(\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\right)\frac{\partial}{\partial v}g(u,v;\alpha) \\
=& \frac{\partial}{\partial u}\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\left(\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\right)\alpha(-\log v)^{\alpha-1}\frac{1}{v} \\
=& \frac{\alpha}{v}(-\log v)^{\alpha-1}\Bigg[\left(\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\right)\frac{\partial}{\partial u}\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\} \\
&\qquad +\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\frac{\partial}{\partial u}\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\Bigg] \\
=& \frac{\alpha}{v}(-\log v)^{\alpha-1}\Bigg[-\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\left(\frac{1}{\alpha}\left[g(u,v;\alpha)\right]^{\frac{1-\alpha}{\alpha}}\right)\frac{\partial}{\partial u}g(u,v;\alpha) \\
&\qquad +\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\frac{1-\alpha}{\alpha^2}\left[g(u,v;\alpha)\right]^{\frac{1-2\alpha}{\alpha}}\frac{\partial}{\partial u}g(u,v;\alpha)\Bigg] \\
=& \frac{\alpha}{v}(-\log v)^{\alpha-1}\frac{\partial}{\partial u}g(u,v;\alpha)\exp\{-\left[g(u,v;\alpha)\right]^{1/\alpha}\}\Bigg[\frac{1}{\alpha^2}\left[g(u,v;\alpha)\right]^{\frac{2(1-\alpha)}{\alpha}} \\
&\qquad +\frac{\alpha-1}{\alpha^2}\left[g(u,v;\alpha)\right]^{\frac{1-2\alpha}{\alpha}}\Bigg] \\
=& \frac{1}{uv}(-\log v)^{\alpha-1}(-\log u)^{\alpha-1}C(u,v)\left[(\alpha-1)\left[g(u,v;\alpha)\right]^{\frac{1-2\alpha}{\alpha}}+\left[g(u,v;\alpha)\right]^{\frac{2(1-\alpha)}{\alpha}}\right] \\
=& \frac{1}{uv}(-\log v)^{\alpha-1}(-\log u)^{\alpha-1}C(u,v)\left[g(u,v;\alpha)\right]^{\frac{2(1-\alpha)}{\alpha}}\left[(\alpha-1)\left[g(u,v;\alpha)\right]^{-\frac{1}{\alpha}}+1\right].
\end{aligned}
$$

三元 Gumbel Copula 密度的闭式表达计算如下：

$$
\begin{aligned}
c(u,v,w) =& \frac{\partial}{\partial u}\frac{\partial}{\partial v}\frac{\partial}{\partial w}C(u,v,w) \\
=& \frac{\partial}{\partial u}\frac{\partial}{\partial v}\frac{\partial}{\partial w}\exp\{-\left[(-\log u)^{\alpha}+(-\log v)^{\alpha}+(-\log w)^{\alpha}\right]^{1/\alpha}\} \\
:=& \frac{\partial}{\partial u}\frac{\partial}{\partial v}\frac{\partial}{\partial w}\exp\{-\left(h(u,v,w;\alpha)\right)^{\alpha}\} \\
=& \frac{1}{uvw}(-\log(u))^{\alpha-1}(-\log(v))^{\alpha-1}(-\log(w))^{\alpha-1}C(u,v,w) \\
&\cdot\Bigg(\alpha^6\left(h(u,v,w;\alpha)\right)^{3\alpha-3}-(\alpha-1)\alpha^5\left(h(u,v,w;\alpha)\right)^{2\alpha-3}-2\alpha^5(\alpha-1)\left(h(u,v,w;\alpha)\right)^{2\alpha-3} \\
&+(\alpha-2)(\alpha-1)\alpha^4\left(h(u,v,w;\alpha)\right)^{\alpha-3}\Bigg).
\end{aligned}
$$

对于 $M>3$，可由阿基米德 Copula 生成该恒等式；这种情形在多模态学习中较少见：

$$
c(\mathbf{u}) = \varphi^{(d)}(t(\mathbf{u}))\prod_{j=1}^{d}\left(\varphi^{-1}\right)'\left(u_j\right),
$$

其中 Gumbel Copula 的 $\varphi(t;\alpha)=\left(\log t\right)^{\alpha}$，$\left(\varphi^{-1}\right)'$ 是 φ 的逆函数的一阶导数。

Gaussian Copula。 二元情形为

$$c(u,\ v;\ \rho) = \frac{1}{\sqrt{1-\rho}} \exp\left(- \frac{(a^2+b^2)\rho^2 - 2ab\rho}{2(1-\rho^2)} \right),$$

其中 $a = \sqrt{2}\,\mathrm{erf}^{-1}(2u-1)$， $b = \sqrt{2}\,\mathrm{erf}^{-1}(2v-1)$。多元情形具有下列矩阵形式：

$$c(\mathbf{u};\ \mathbf{\Sigma}) = (2\pi)^{M/2}|\mathbf{\Sigma}|^{-1/2} \frac{\exp\{ -\zeta^{\mathsf{T}}\mathbf{\Sigma}^{-1}\zeta/2\}}{\prod_{m=1}^{M}(2\pi)^{-1/2}\exp\left(-\zeta_m^2/2\right)},$$

其中 $\mathbf{\Sigma}$ 为协方差矩阵， $\zeta = \left(\Phi^{-1}(u_1),\ \ldots,\ \Phi^{-1}(u_M)\right)^{\mathsf{T}}$， $\zeta = [\zeta_1,\ \ldots,\ \zeta_M]$。译者注：二元公式中的 $\sqrt{1-\rho}$ 及多元式的系数均按原文保留。

Student t Copula：

$$\frac{\Gamma(v/2)\Gamma(v/2+1)(1+(t_v^{-2}(u)+t_v^{-2}(v)-2\rho t_v^{-1}(u)t_v^{-1}(v))/(v(1-\rho^2))^{-(v+2)/2})}{\sqrt{1-\rho^2}\Gamma((v+1)/2)^2(1+t_v^{-2}(u)/v)^{-(v+1)/2}(1+t_v^{-2}(v)/v)^{-(v+1)/2}},$$

其中 v 是自由度， Γ 是伽马函数，且

$$t_v(x) = \int_{-\infty}^{x} \frac{\Gamma\left((v+1)/2\right)dt}{\sqrt{v\pi}\,\Gamma(v/2)\left(1+v^{-1}t^2\right)^{(v+1)/2}}.$$

D. Copula 如何学习交互

我们展示 Copula 模型如何随训练轮次学习交互，并讨论其含义。

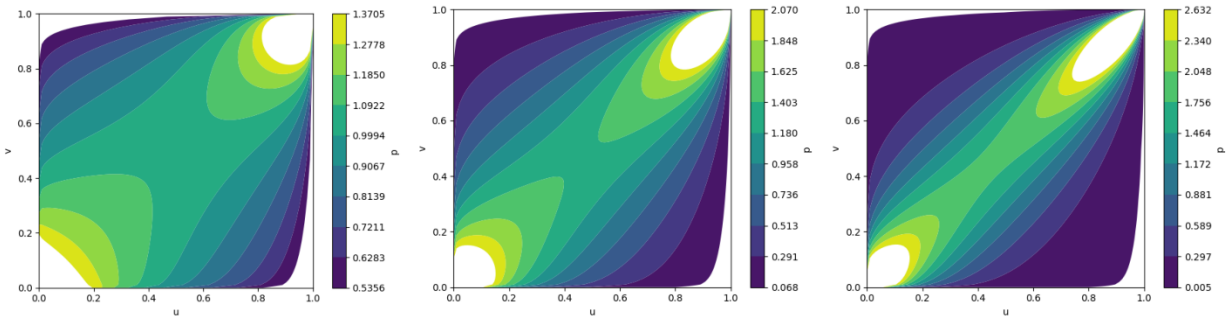


图 4. Gumbel 族在第 5、50、100 个训练轮次的 Copula 密度图，依次从左至右。

图 4 展示上述三个训练轮次的密度，以 Gumbel 族为例。可以观察到，Copula 密度逐渐演化为正相关模式；负相关情形，例如 $u > 0.5,\ v < 0.5$ 或 $u < 0.5,\ v > 0.5$，仍被考虑，但所分配的权重正在减小。

E. 基线方法和实现细节补充

E.1. 实现细节和超参数

所有模型在训练集上训练 100 个轮次，以 AUROC 为监测指标，根据验证集选择最佳模型，最终报告测试集结果。使用 Adam 优化器；若验证 AUROC 连续 15 个轮次未改善，则提前停止以防过拟合。全部实验在单张 RTX-3090 GPU 上进行。MIMIC-IV 与 CXR 的批大小设为 32；MIMIC-III 与 NOTE 的批大小为 16，但 DrFuse 为 8。使用验证集进行网格搜索调参，报告测试集最佳结果。搜索空间包括：

- Dropout 比例：$\{0,\ 0.1,\ 0.2,\ 0.3\}$。
- 学习率：$\{1\times10^{-4},\ 5\times10^{-5},\ 1\times10^{-5}\}$。
- 高斯混合分量数 K：$\{1,\ 2,\ 3,\ 4,\ 5,\ 6\}$。
- 温度：$\{0.001,\ 0.005,\ 0.01,\ 0.05,\ 0.08\}$。
- 正则化参数 λ_{cop}：$\{1\times10^{-5},\ 5\times10^{-6},\ 1\times10^{-6}\}$。

CM^2 使用 Python 3.11 和 PyTorch 1.9 实现。遵循 MedFuse（Hayat 等，2022），CXR 骨干为 ResNet34（He 等，2016），时间序列编码器为双层 LSTM（Graves 与 Graves，2012），临床笔记编码器为预训练 TinyBERT（Jiao 等，2019；脚注 2）。通过投影层将模态嵌入映射到同一潜在空间。双层 LSTM 作为融合模块组合模态嵌入，具有一个线性层和 sigmoid 激活的 MLP 作为分类器。

E.2. 基线方法的补充设置

将 CM^2 与以下基线比较：

- **MMTM（Joze 等，2020）**：可用灵活插件架构利用模态间信息。由于假设完整模态，训练、测试时以全零补偿缺失 CXR 和临床笔记；对于笔记，用 TinyBERT 替换 ResNet34 编码器。
- **DAFT（Pölsterl 等，2021）**：可插入 CNN，在表格数据与图像间交换信息。同样在训练、测试时以全零矩阵替代缺失 CXR 和临床笔记，并用 TinyBERT 嵌入笔记。
- **Unified（Hayat 等，2021）**：动态整合辅助数据模态，学习各模态表示，并通过统一分类器融合。其内在支持缺失，能利用全部可用的模态专属数据。也用 TinyBERT 嵌入临床笔记。
- **MedFuse（Hayat 等，2022）**：用基于 LSTM 的融合结合图像（或语言）编码器和 EHR 编码器特征。通过学习缺失 CXR 或笔记的全局表示处理缺失。我们随机初始化时间序列、临床笔记和 CXR 图像编码器。
- **DrFuse（Yao 等，2024）**：用解耦表示学习，在一个模态缺失时仍能学习 EHR 与图像共享表示。使用 ResNet50 图像编码器和 Transformer EHR 编码器；对临床笔记，将 ResNet50 换为 TinyBERT。

DrFuse 的实现遵循原论文（Yao 等，2024；脚注 3），使用相同超参数。直接采用 Hayat 等（2022；脚注 4）提供的 MMTM、DAFT、Unified、MedFuse 实现，超参数均为其默认值。将这五种方法扩展到包括 EHR 时间序列、CXR 图像、放射学报告的三模态设置。

脚注 2：https://huggingface.co/huawei-noah/TinyBERT_General_4L_312D 。

脚注 3：https://github.com/dorothy-yao/drfuse 。

脚注 4：https://github.com/nyuad-cai/MedFuse 。

F. 补充实验结果

其他基线。 将 CM^2 与另外两种医疗基线 LSMT（Khader 等，2023）和 Interleaved（Zhang 等，2023）比较，结果见表 9。

表 9. MIMIC-IV 上其他基线的结果。全部报告 AUROC、AUPR 及 95% 置信区间，最佳结果加粗。Totally Matched=完全匹配，Partially Matched=部分匹配；其余表头同表 2。

Models	IHM		READM	
	AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
	Totally Matched			
LSMT (Khader et al., 2023)	$0.803_{(0.769,0.837)}$	$0.444_{(0.370,0.519)}$	$0.701_{(0.662,0.737)}$	$0.421_{(0.356,0.490)}$
Interleaved (Zhang et al., 2023)	$0.800_{(0.764,0.834)}$	$0.440_{(0.374,0.523)}$	$0.702_{(0.664,0.741)}$	$0.421_{(0.360,0.487)}$
CM^2	$\mathbf{0.827}_{(0.790,0.859)}$	$\mathbf{0.492}_{(0.423,0.566)}$	$\mathbf{0.737}_{(0.704,0.773)}$	$\mathbf{0.466}_{(0.404,0.529)}$
	Partially Matched			
LSMT (Khader et al., 2023)	$0.854_{(0.838,0.870)}$	$0.508_{(0.466,0.551)}$	$0.764_{(0.746,0.781)}$	$0.473_{(0.436,0.509)}$
Interleaved (Zhang et al., 2023)	$0.856_{(0.840,0.871)}$	$0.508_{(0.466,0.550)}$	$0.758_{(0.740,0.775)}$	$0.473_{(0.441,0.506)}$
CM^2	$\mathbf{0.858}_{(0.844,0.872)}$	$\mathbf{0.527}_{(0.490,0.568)}$	$\mathbf{0.771}_{(0.752,0.788)}$	$\mathbf{0.486}_{(0.452,0.518)}$

- **LSMT（Khader 等，2023）** 是面向多模态医疗场景的 Transformer 模型。
- **Interleaved（Zhang 等，2023）** 处理医疗多模态数据的不规则性，并用跨模态注意力融合不同模态表示。

骨干编码器的影响。 我们进一步探索时间序列和 CXR 图像骨干编码器的有效性，开展补充实验评估各模态不同编码器架构的影响。具体以 Transformer（Vaswani，2017）和 ViT（Dosovitskiy，2020）分别替代时间序列、CXR 图像编码器，结果见表 10。本方法在不同骨干上持续优于竞争基线，体现鲁棒性和有效性。此外，不同骨干间更稳定，说明对其选择不太敏感。Transformer 总体优于 LSTM，尤其对于 MMTM、LSMT、Interleaved。ResNet 略优于 ViT，但差别不显著，说明骨干选择对时间序列数据的影响更大。

表 10. MIMIC-IV 在模态完全匹配时，不同骨干编码器和其他基线的结果。全部报告 AUROC、AUPR 及 95% 置信区间，最佳结果加粗。Backbone=骨干，TS=时间序列，IMG=图像；其余表头同表 2。

Models	Backbone TS	Backbone IMG	IHM AUROC (↑)	IHM AUPR (↑)	READM AUROC (↑)	READM AUPR (↑)
MMTM (Joze et al., 2020)	LSTM	ResNet	0.802 (0.770,0.835)	0.429 (0.362,0.513)	0.713 (0.677,0.750)	0.420 (0.362,0.489)
DAFT (Pölsterl et al., 2021)			0.815 (0.782,0.844)	0.454 (0.387,0.538)	0.729 (0.692,0.766)	0.433 (0.378,0.499)
Unified (Hayat et al., 2021)			0.808 (0.778,0.840)	0.429 (0.367,0.512)	0.719 (0.680,0.756)	0.450 (0.390,0.513)
MedFuse (Hayat et al., 2022)			0.813 (0.777,0.844)	0.448 (0.380,0.528)	0.725 (0.690,0.762)	0.438 (0.379,0.508)
DrFuse (Yao et al., 2024)			0.814 (0.780,0.844)	0.450 (0.384,0.536)	0.723 (0.687,0.756)	0.422 (0.367,0.486)
LSMT (Khader et al., 2023)			0.803 (0.769,0.837)	0.444 (0.374,0.523)	0.701 (0.662,0.737)	0.421 (0.356,0.490)
Interleaved (Zhang et al., 2023)			0.800 (0.764,0.834)	0.440 (0.370,0.519)	0.702 (0.664,0.741)	0.421 (0.360,0.487)
CM^2			**0.827** (0.790,0.859)	**0.492** (0.423,0.566)	**0.737** (0.704,0.773)	**0.466** (0.404,0.529)
MMTM (Joze et al., 2020)	LSTM	ViT	0.805 (0.768,0.837)	0.446 (0.377,0.524)	0.712 (0.676,0.749)	0.422 (0.360,0.491)
DAFT (Pölsterl et al., 2021)			0.808 (0.775,0.840)	0.438 (0.365,0.521)	0.714 (0.678,0.753)	0.423 (0.369,0.490)
Unified (Hayat et al., 2021)			0.803 (0.768,0.835)	0.431 (0.365,0.515)	0.707 (0.667,0.743)	0.416 (0.360,0.482)
MedFuse (Hayat et al., 2022)			0.805 (0.771,0.837)	0.439 (0.371,0.524)	0.715 (0.677,0.753)	0.424 (0.370,0.492)
DrFuse (Yao et al., 2024)			0.806 (0.772,0.838)	0.446 (0.379,0.526)	0.716 (0.677,0.748)	0.421 (0.364,0.489)
LSMT (Khader et al., 2023)			0.801 (0.767,0.836)	0.441 (0.374,0.527)	0.703 (0.662,0.739)	0.410 (0.358,0.475)
Interleaved (Zhang et al., 2023)			0.802 (0.766,0.833)	0.434 (0.364,0.509)	0.710 (0.673,0.747)	0.435 (0.372,0.502)
CM^2			**0.826** (0.790,0.856)	**0.490** (0.421,0.563)	**0.736** (0.697,0.771)	**0.452** (0.394,0.522)
MMTM (Joze et al., 2020)	Transformer	ResNet	0.813 (0.780,0.846)	0.452 (0.383,0.540)	0.735 (0.699,0.770)	0.448 (0.388,0.515)
DAFT (Pölsterl et al., 2021)			0.814 (0.782,0.845)	0.437 (0.373,0.522)	0.730 (0.694,0.766)	0.430 (0.372,0.493)
Unified (Hayat et al., 2021)			0.812 (0.776,0.845)	0.453 (0.385,0.533)	0.719 (0.681,0.754)	0.426 (0.365,0.488)
MedFuse (Hayat et al., 2022)			0.815 (0.782,0.846)	0.441 (0.373,0.520)	0.728 (0.692,0.762)	0.442 (0.381,0.505)
DrFuse (Yao et al., 2024)			0.818 (0.784,0.850)	0.460 (0.391,0.540)	0.726 (0.689,0.760)	0.430 (0.370,0.495)
LSMT (Khader et al., 2023)			0.817 (0.785,0.848)	0.452 (0.386,0.535)	0.722 (0.688,0.758)	0.431 (0.376,0.494)
Interleaved (Zhang et al., 2023)			0.821 (0.791,0.851)	0.459 (0.389,0.539)	0.721 (0.683,0.757)	0.429 (0.367,0.497)
CM^2			**0.823** (0.788,0.855)	**0.488** (0.421,0.560)	**0.740** (0.699,0.771)	**0.470** (0.382,0.510)
MMTM (Joze et al., 2020)	Transformer	ViT	0.813 (0.778,0.846)	0.462 (0.396,0.545)	0.723 (0.686,0.761)	0.435 (0.380,0.505)
DAFT (Pölsterl et al., 2021)			0.803 (0.768,0.836)	0.432 (0.363,0.510)	0.719 (0.682,0.758)	0.421 (0.367,0.486)
Unified (Hayat et al., 2021)			0.812 (0.778,0.845)	0.463 (0.396,0.546)	0.719 (0.680,0.753)	0.412 (0.353,0.474)
MedFuse (Hayat et al., 2022)			0.818 (0.786,0.849)	0.461 (0.393,0.542)	0.721 (0.684,0.759)	0.431 (0.371,0.493)
DrFuse (Yao et al., 2024)			0.814 (0.780,0.845)	0.436 (0.369,0.516)	0.717 (0.680,0.755)	0.416 (0.359,0.480)
LSMT (Khader et al., 2023)			0.815 (0.784,0.847)	0.453 (0.389,0.535)	0.714 (0.675,0.751)	0.424 (0.365,0.492)
Interleaved (Zhang et al., 2023)			0.818 (0.786,0.849)	0.453 (0.380,0.531)	0.717 (0.679,0.753)	0.433 (0.371,0.498)
CM^2			**0.826** (0.790,0.855)	**0.489** (0.422,0.560)	**0.737** (0.700,0.772)	**0.465** (0.394,0.517)

混合分量数 K 的影响。 按统计建模惯例，K 设得较小以避免过度设定。常见选择为 2 至 3，使混合分布在避免过度设定的同时达到最佳灵活程度。图 5 评估 CM^2 随 K 变化的性能，结果较为鲁棒。

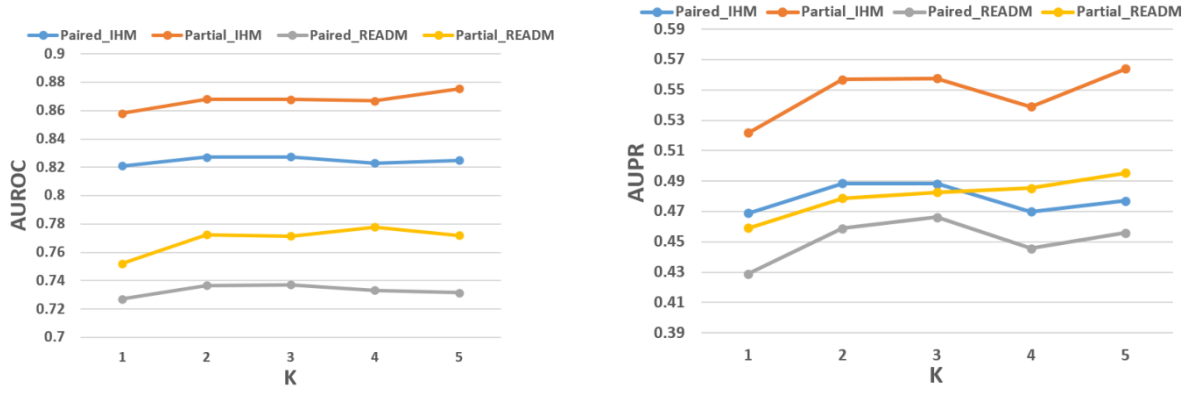


图 5. CM^2 在 MIMIC-IV 上的结果：左为 AUROC，右为 AUPR。$K = 1$ 时，模型退化为多元高斯分布。Paired=匹配，Partial=部分匹配；IHM=院内死亡，READM=再入院。

统计检验。 表 11 给出 CM^2 相对各基线的 AUROC、AUPR 双样本 bootstrap t 检验的 p 值。总体而言，相对于竞争基线的改善在 5% 显著性水平下具有统计显著性，验证了本方法的有效性。

表 11. CM^2 与基线方法比较的 AUROC、AUPR 双样本 bootstrap t 检验 p 值。多数检验在 5% 显著性水平下显著。表头同表 2。

Models	IHM		READM	
	AUROC (↑)	AUPR (↑)	AUROC (↑)	AUPR (↑)
MMTM (Joze et al., 2020)	2.02e-06	3.55e-180	4.40e-100	5.36e-291
DAFT (Pölsterl et al., 2021)	0.1122	1.53e-132	9.37e-78	2.95e-240
Unified (Hayat et al., 2021)	4.55e-08	5.71e-240	4.80e-73	2.81e-139
MedFuse (Hayat et al., 2022)	7.73e-07	5.66e-129	1.11e-92	3.69e-173
DrFuse (Yao et al., 2024)	0.1447	4.28e-99	6.05e-67	6.25e-250