C^2MOE 面向不完整多模态情感学习的一致性与互补性引导混合专家框架

非官方中文全文译文 · P119

原题：C^2MOE: Consistency and Complementarity-guided Mixture of Experts for Incomplete Multimodal Emotion Learning

作者与机构

- Yuntao Shou：中南林业科技大学，中国湖南；shouyuntao@stu.xjtu.edu.cn。
- Tao Meng*：中南林业科技大学，中国湖南；mengtao@hnu.edu.cn。
- Wei Ai：中南林业科技大学，中国湖南；aiwei@hnu.edu.cn。
- Keqin Li：纽约州立大学，New Paltz，New York 12561，美国；原文另列“中国西安”；lik@newpaltz.edu。

* 通讯作者。

来源、许可与改编说明。 本译文完整翻译所核验的 10 页原稿 arXiv:2608.04013v1，原始 PDF。作者依 CC BY 4.0 授权原文。本译文是中文翻译与重新排版的改编，未经原作者审阅或认可；保留全部正文、公式、5 幅图、3 张表和 63 条参考文献。图表采用原稿高清裁图，中文图表题与英文标签释义另列；表 1、表 2 为提升可读性拆为上下两组，并重复左侧索引列，原数值不变。参考文献保留完整检索信息并增列中文题名。

原稿状态说明。 官方来源与 PDF 侧边印记均写有“22 Apr 2026”，但标识符为“2608.04013v1”；此处照录，不推定修正日期。原稿含未填完的 ACM 模板：参考格式写“2018”，页眉写“Conference’17, July 2017, Washington, DC, USA”，DOI 为占位符。以下均作为原稿内容保留，不视为已核实的正式会议发表信息。原稿公式编号的重复、倒序以及显著的文字/数值不一致亦保留，并以“译者注”明确区分。

摘要

对话中的多模态情感识别（Multimodal Emotion Recognition in Conversations，MERC）近年来的发展凸显了它对完整多模态输入的依赖。然而，现实数据常因传输错误或用户行为而出现模态缺失，严重降低模型性能。现有方法通过跨模态一致性学习增强鲁棒性，却在很大程度上忽略了模态互补性，从而导致有偏重建。为解决这一局限，我们提出 C^2MOE，一种面向不完整多模态情感学习的新型一致性与互补性引导的混合专家框架。该方法在具有明确原理依据的信息论框架中统一了表示学习与缺失模态插补。具体而言，通过交互感知专家，将多模态知识分解为一致性成分与互补性成分。通过最大化跨模态可预测性捕获一致性，通过最大化模态间条件熵保留互补性。在这一分解基础上，C^2MOE 引入双分支预测机制，在模态缺失时实现稳健插补。一致性分支通过最小化不确定性，使插补特征与联合分布

对齐；互补性分支则通过熵最大化利用模态独有的线索。最后，C²MOE 使用可学习的重加权模块，动态为每位专家的输出分配重要性分数，实现用于插补的稳健、自适应融合。在多个 MERC 基准上的大量实验表明，C²MOE 在各种模态缺失设置下均持续优于最先进方法，验证了其鲁棒性与泛化能力。

CCS 概念。 计算方法 → 语篇、对话与语用；非负矩阵分解。计算理论 → 固定参数可处理性。

关键词。 多模态情感识别；特征融合；混合专家；不完整多模态学习。

ACM 参考格式（原稿模板内容）。 Yuntao Shou, Tao Meng, Wei Ai, and Keqin Li. 2018. C²MOE: Consistency and Complementarity-guided Mixture of Experts for Incomplete Multimodal Emotion Learning. 载于 Proceedings of ACM Conference (Conference’17). ACM, New York, NY, USA, 10 pages. 原稿 DOI 占位文字：https://doi.org/XXXXXXX.XXXXXXX 。

1 引言

对话多模态情感识别（MERC）的核心目标，是整合异质模态以提高情感分析的准确性与鲁棒性 [15, 18, 38, 39, 43, 45, 50, 55]。近期研究重点在于学习具有判别性的跨模态表示，并开发有效的融合策略 [7, 12, 26, 27, 30, 34, 36, 41, 44]。然而，现实场景中经常发生模态缺失，严重降低模型性能与鲁棒性 [52]。因此，设计能抵御模态不完整性的 MERC 模型已成为重要研究挑战 [23, 36, 39, 41, 47, 54, 59, 60]。

对于不完整多模态条件下的 MERC，一种常见解决方案是利用编码器-解码器框架，从已观测模态恢复缺失模态。编码器根据可用表示估计缺失模态，解码器则在原始特征空间重建它。例如，Zhao 等 [61] 将自编码器与循环一致性相结合，以减少失真和噪声；Lian 等 [19] 将多模态特征建模为图节点，并通过图神经网络传播信息，从而补全缺失模态。然而，这些方法对恢复机制的可解释性有限。为此，信息论方法 [21, 22] 通过最大化模态间互信息增强跨模态一致性，从而改善模态缺失条件下的性能。尽管如此，这些方法忽略了互补性对多模态学习的影响。

不过，同时建模模态间一致性与互补性面临一个根本挑战：这两个目标本质上彼此冲突。提升一致性需要最小化条件熵 $H\left(\mathbf{Z}^i \mid \mathbf{Z}^j\right)$，以减小跨模态不确定性；增强互补性则依赖最大化同一个量，以保留模态特有信息。针对这一问题，我们提出一致性与互补性引导的混合专家框架（C²MOE），通过专门化专家与自适应路由解耦这两个目标。C²MOE 在混合专家架构中使用两位专家。一致性专家最大化互信息 $I\left(\mathbf{Z}^1, \mathbf{Z}^2\right)$ 并最小化条件熵，使恢复数据与真实分布对齐。互补性专家执行相反的优化，以保留模态独有特征并增强重建鲁棒性。动态门控网络根据模态可用性和语义上下文，将每个输入分配给合适的专家；协调模块则将专家输出融合成统一表示，在一致性与互补性之间取得平衡。总体贡献如下：

- 据我们所知，这是首次尝试从信息论角度，将一致性语义信息与互补性语义信息整合进统一的混合专家（MOE）框架，以缓解数据缺失问题。
- 为解决一致性与互补性的内在冲突，我们提出 C²MOE 模型，通过专门化专家与自适应路由解耦两个目标。C²MOE 动态为每个输入选择最合适的专家，实现互不干扰的针对性学习。
- 在多个数据集上开展大量实验，证明所提出的 C²MOE 在不完整多模态对话情感识别中优于最先进方法。

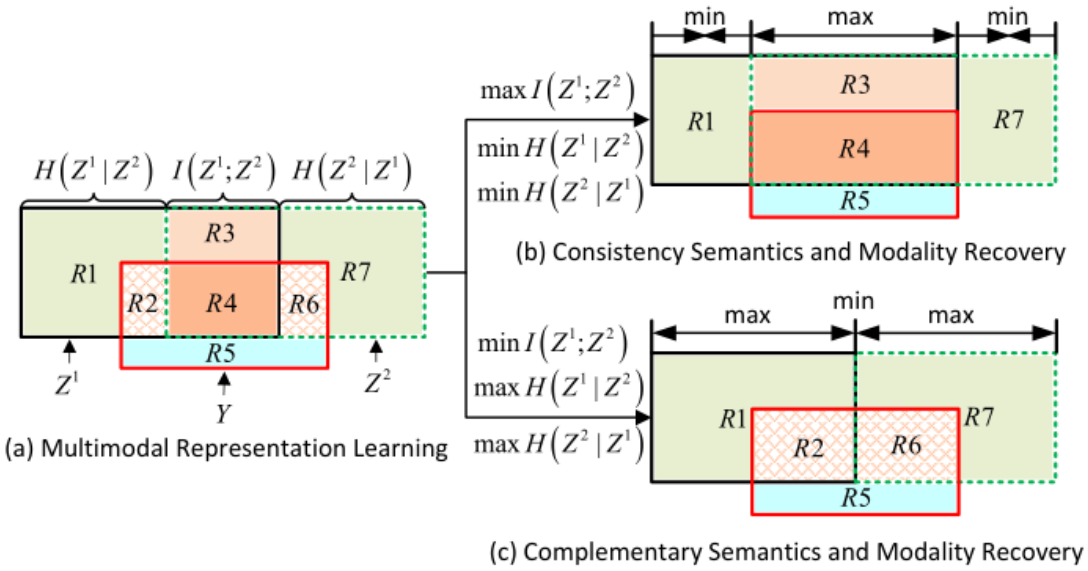


图 1。 从信息论角度给出的基本观察与理论认识。（a）黑色实线矩形表示完整模态特征 $Z^1 = R_1 \cup R_2 \cup R_3 \cup R_4$，绿色虚线矩形表示不完整模态特征 $Z^2 = R_3 \cup R_4 \cup R_6 \cup R_7$，红色实线矩形表示任务相关特征 $Y = R_2 \cup R_4 \cup R_5 \cup R_6$。其中，$R_1$ 和 R_7 为模态特有但与任务无关的区域；R_2 和 R_6 为模态特有且与任务相关的（互补）区域；R_3 和 R_4 为共享的（一致）区域，其中 R_3 与任务无关，R_4 与任务相关；R_5 为与任务相关但未知的区域。（b）最大化一致的任务相关语义，需要扩大 R_4，同时抑制 R_1 和 R_7。（c）相反，最大化互补的任务相关语义，需要缩小 R_4 并扩大 R_2 和 R_6。

图中标签：Multimodal Representation Learning = 多模态表示学习；Consistency Semantics and Modality Recovery = 一致性语义与模态恢复；Complementary Semantics and Modality Recovery = 互补语义与模态恢复；max/min = 最大化/最小化。

2 相关工作

2.1 不完整模态学习

不完整多模态学习旨在解决现实场景中的模态缺失问题；在这些场景下，数据采集限制或环境因素往往导致只能获得部分观测 [4, 8, 14, 16, 32, 33, 61, 63]。现有方法主要分为两类：共享子空间学习与模态恢复。共享子空间方法通过学习共同的低维表示来对齐模态，并最大化跨模态相关性 [1, 2, 29, 35, 51, 58]。然而，过分强调相关性，可能忽略对下游任务至关重要的模态特有判别线索。相比之下，模态恢复方法显式地从已观测模态重建缺失模态。这既包括填零 [6, 58] 或均值插补 [2] 等简单启发式方法，也包括利用强大表示模型的深度生成策略。尤其是循环一致的跨模态重建 [29, 61]、级联残差自编码器 [49] 和基于图的方法 [19]，已展现出捕获复杂模态间依赖、实现有效恢复的潜力。

2.2 对比学习

作为一种高效的无监督学习模型，对比学习（CL）在特征学习中取得了显著成果 [22, 37, 40, 42, 46]。其核心思想是构造一个特征空间，将相似数据映射到彼此接近的位置，同时将不同数据点推到较远的位置 [3], [5], [9], [17], [48]。近期研究揭示了对比学习成功的一个关键因素：互信息最大化。例如，

MoCo [10] 通过优化对比学习损失，最大化查询特征与对应键特征之间的相似度，同时最小化查询特征与其他无关键特征之间的相似度。CPC [28] 尝试最大化真实未来信息与当前上下文之间的相似度，同时最小化当前上下文与负样本之间的相似度。MoCo 与 CPC 都通过最小化 InfoNCE 损失来最大化互信息；该损失可视为用于最大化互信息的一个下界。

3 问题定义

在多模态学习中，将具有 M 个异质模态的样本记为 $\left(X^1, X^2, \ldots, X^M\right)$，其中 X^m 对应第 m 个模态的输入。在现实应用中，由于数据采集过程中的传感器噪声、传输错误或行为差异，部分模态可能缺失。为形式化描述这种不完整设置，引入可观测性指示变量 $\lambda^m \in \{0, 1\}$，其中 $\lambda^m = 1$ 表示模态 m 可用，$\lambda^m = 0$ 表示它缺失。由此得到已观测模态集合 $I^{\text{obs}} = \{m \mid \lambda^m = 1\}$ 和缺失模态集合 $I^{\text{miss}} = \{m \mid \lambda^m = 0\}$。我们的目标是利用 I^{obs} 中的信息，推断并重建 I^{miss} 中各模态的表示，从而减轻数据不完整的负面影响，为下游任务构建更加连贯、信息更丰富且便于融合的多模态表示。

4 所提出的方法

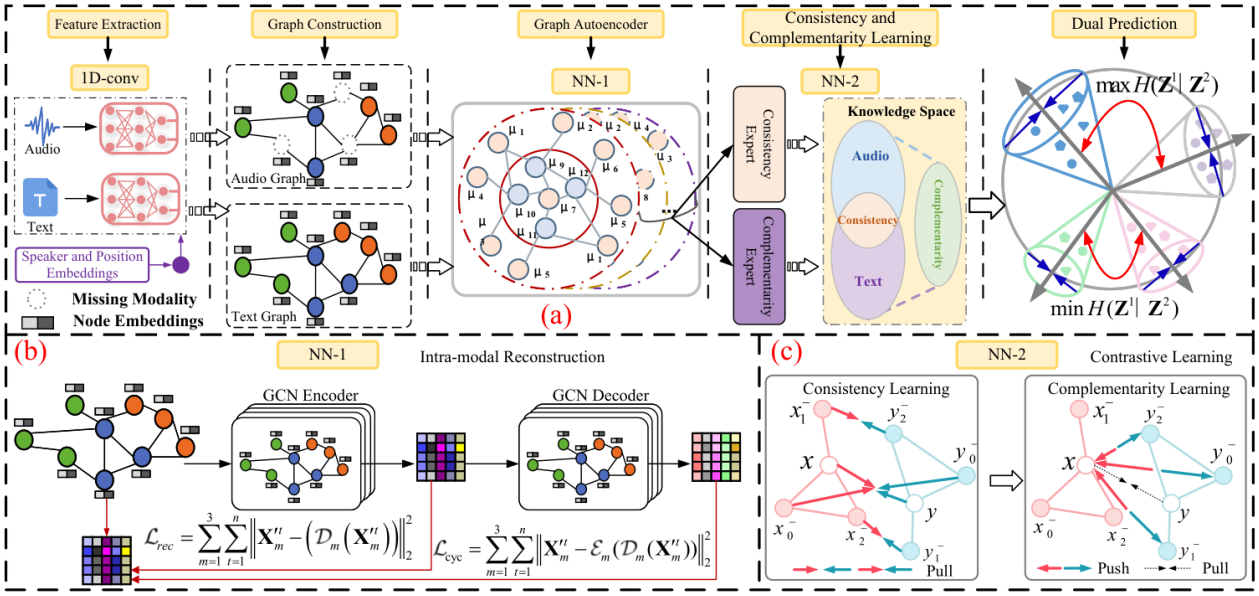


图 2。 所提出 C²MOE 框架的整体架构。模型首先通过一维卷积，结合说话人嵌入与位置嵌入提取多模态特征。NN-1 执行模态内重建，以保留模态特有信息，实现稳定恢复。NN-2 在信息论空间中引入一致性专家与互补性专家，将多模态知识解耦为共享成分与模态独有成分。一致性专家增强跨模态可预测性，互补性专家则最大化条件熵以保留模态特有线索。在这两位专家的基础上，C²MOE 形成双分支预测机制，在模态缺失时实现稳健插补。（b）NN-1：模态内重建。（c）NN-2：一致性与互补性对比学习。

图中标签：Feature Extraction = 特征提取；Graph Construction = 图构建；Graph Autoencoder = 图自编码器；Consistency and Complementarity Learning = 一致性与互补性学习；Dual Prediction = 双重预测；Audio/Text = 音频/文本；Speaker and Position Embeddings = 说话人和位置嵌入；Missing Modality = 缺失模态；Node Embeddings = 节点嵌入；Audio Graph/Text Graph = 音频图/文本图；GCN Encoder/Decoder = 图卷积网络编码器/解码器；Knowledge Space =

知识空间；Consistency/Complementarity Expert = 一致性/互补性专家；Intra-modal Reconstruction = 模态内重建；Contrastive Learning = 对比学习；Pull/Push = 拉近/推远。图内原有箭头、数学标签与结构均保持不变。

4.1 模态编码器

文本、音频和视频的原始特征在维度和尺度上差异显著，直接将它们用于缺失模态恢复，会造成分布不匹配并阻碍语义对齐。为缓解这一问题，并将所有单模态表示映射到统一的特征空间，我们采用一个一维卷积神经网络（1D-CNN）层 [25]，执行如下跨模态特征投影与对齐：

$$\mathbf{X}^{m\prime} = \mathrm{Conv1D}(\mathbf{X}^{m}, l^{m}) \in \mathbb{R}^{N\times d}, \quad m \in \{t, a, v\}. \tag{1}$$

其中，l^{m} 表示第 m 个模态对应的一维卷积核大小，N 表示整个对话序列中的句子总数，d 表示共享潜在空间的维度。

为使模型感知话语顺序并增强上下文建模能力，我们向卷积处理后的序列加入位置嵌入：

$$\mathrm{PE}_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad \mathrm{PE}_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right). \tag{2}$$

其中，pos 表示序列索引，维度 i 表示特征维度的索引。

我们将位置嵌入加入卷积序列，以增强模型捕获时间顺序与位置依赖的能力：

$$\mathbf{X}^{m\prime} = \mathbf{X}^{m\prime} + \mathrm{PE}. \tag{3}$$

4.2 模态内重建

传统多模态学习依赖多个模态的协同作用，但当某些模态缺失时，单个模态的学习能力就变得尤为重要。模态内重建使每个模态都能独立学习有效的特征表示，确保即便其他模态缺失，模型性能也不会显著下降。具体而言，对于每个模态，我们采用图自编码器（GAE）[13] 学习其潜在表示 $\mathbf{Z}^{m}$，以有效捕获模态内的结构信息与特征分布。首先，最小化原始数据 $\mathbf{X}^{m\prime}$ 与重建数据 $\mathbf{Z}^{m}$ 之间的差异，确保学得的潜在表示能够保留该模态的核心信息：

$$\mathcal{L}_{rec} = \sum_{m=1}^{3}\sum_{t=1}^{n} \parallel \mathbf{X}_{t}^{m\prime} - \left(\mathcal{D}^{m}\left(\mathbf{X}_{t}^{m\prime}\right)\right) \parallel_{2}^{2}. \tag{4}$$

其中，$\mathbf{X}_{t}^{m\prime}$ 是 $\mathbf{X}^{m\prime}$ 的第 t 个样本，$\mathcal{D}^{m}$ 是第 m 个模态的图编码器。为确保编码后的潜在特征 Z_{m} 与原始数据 $\mathbf{X}'_{m}$ 之间的语义一致性，我们引入如下的一致性损失：

$$\mathcal{L}_{cyc} = \sum_{m=1}^{3}\sum_{t=1}^{n} \parallel \mathbf{X}_{t}^{m\prime} - \mathcal{E}^{m}\left(\mathcal{D}^{m}\left(\mathbf{X}_{t}^{m\prime}\right)\right) \parallel_{2}^{2}. \tag{5}$$

其中，$\mathcal{E}^{m}$ 是第 m 个模态的图解码器。因此，第 m 个模态第 t 个样本的潜在表示为：

$$\mathbf{Z}^{m} = \mathcal{D}^{m}\left(\mathbf{X}_{t}^{m\prime}\right). \tag{6}$$

4.3 一致性与互补性引导的混合专家

为增强多模态表示学习的鲁棒性与泛化能力，我们提出一致性与互补性引导的混合专家（C²MoE）框架，将模态交互显式分解为一致性成分与互补性成分。该框架包含两位专门化专家：一致性对比专家负责捕获语义对齐、模态不变的模式；互补性对比专家则用于探索多样化、模态特有的信号。共享路由网络通过预测软门控权重，动态地将每个输入对分配给合适的专家，实现灵活、随数据自适应的专家协作。下面详细介绍 C²MoE 框架。

混合专家的信息论基础。 从信息论角度看，多模态学习既需要捕获跨模态一致性，也需要捕获模态特有的互补性。为建模一致性，我们最大化模态间互信息，促使模态共享且可预测的成分对齐。为建模互补性，我们最大化条件熵，从而保留无法从其他模态推断出的模态独有信号。形式化地，这对应于最大化：

$$\max_{\mathcal{H}_c} I\left(\mathbf{Z}^i; \mathbf{Z}^j\right) \quad \text{and} \quad \max_{\mathcal{H}_s} H\left(\mathbf{Z}^i \mid \mathbf{Z}^j\right). \tag{7}$$

其中， $\mathcal{H}_c$ 和 $\mathcal{H}_s$ 分别为一致性专家与互补性专家。关键在于，我们通过双专家 MoE 架构实现这些目标：

$$\mathbf{Z}^m = \sum_{k=1}^{K} \alpha_k^m \cdot \mathcal{H}_k(\mathbf{Z}^m). \tag{8}$$

其中， $\mathcal{H}_k$ 为第 K 位专家， α_k^m 为路由权重。关键创新是，每位专家专门负责一致性或互补性，路由机制动态选择合适的专家。

一致性对比专家。 为显式建模跨模态共享语义模式，我们设计了一致性对比专家。该专家通过最大化模态表示之间的统计依赖，专门捕获跨模态一致性。给定样本 i 的两个模态潜在表示 $\left(\mathbf{Z}_i^1, \mathbf{Z}_i^2\right)$，路由网络产生软分配向量 $\mathbf{g}_i = \left[g_i^C, g_i^R\right]$，其中 g_i^C 是一致性专家的门控权重， g_i^R 是互补性专家的门控权重。在该分支中，两个模态都经过共享专家函数 $f_C(\cdot)$：

$$\widetilde{\mathbf{Z}}_i^1 = f_C\left(\mathbf{Z}_i^1\right), \qquad \widetilde{\mathbf{Z}}_i^2 = f_C\left(\mathbf{Z}_i^2\right). \tag{9}$$

为促进一致结构的学习，我们引入基于互信息（MI）最大化的一致性对比损失：

$$\mathcal{L}_{cl} = -\sum_{i=1}^{n} I\left(\widetilde{\mathbf{Z}}_i^1; \widetilde{\mathbf{Z}}_i^2\right) + \alpha\left(H\left(\widetilde{\mathbf{Z}}_i^1\right) + H\left(\widetilde{\mathbf{Z}}_i^2\right)\right). \tag{10}$$

其中， $I(\cdot;\cdot)$ 表示互信息， $H(\cdot)$ 是用于防止专家坍塌的熵正则项。为计算互信息，我们估计两个模态离散化特征或软分配特征的联合分布 [21]。具体而言，构造共激活矩阵 $\mathbf{P} \in \mathbb{R}^{D \times D}$：

$$\mathbf{P} = \frac{1}{m} \sum_{i=1}^{m} \widetilde{\mathbf{Z}}_i^1 \left(\widetilde{\mathbf{Z}}_i^2\right)^{\top}. \tag{10}$$

其中， D 表示用于估计特征分布的离散化区间数或潜在维度数。边缘分布通过对 $\mathbf{P}$ 的行、列求和得到。最终的离散互信息目标写为：

$$\mathcal{L}_{cl} = -\sum_{d=1}^{D} \sum_{d'=1}^{D} P_{dd'} \log\left(\frac{P_{dd'}}{P_d \cdot P_{d'}}\right). \tag{11}$$

该目标鼓励最大化模态间的统计一致性。通过与路由联合训练，一致性专家专注于捕获跨模态共享结构，互补性专家则关注模态特有信息。

一致性专家预测。为在所提出的双专家 MoE 框架中推断模态一致的表示，我们设计了一致性专家预测机制，从具有一致性的对应模态估计缺失或不完整模态。这使一致性对比专家能够通过条件生成建模进行语义重建。形式化地，给定成对的模态表示 $\left(\mathbf{Z}_i^1,\ \mathbf{Z}_i^2\right)$，目标是最小化条件熵 $H\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)$，使 $\mathbf{Z}_i^1$ 能由 $\mathbf{Z}_i^2$ 确定性地推断出来：

$$H\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right) = -\mathbb{E}_{p\left(\mathbf{Z}_i^1,\mathbf{Z}_i^2\right)}\left[\log p\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)\right]. \qquad (12)$$

由于直接计算真实后验 $p\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)$ 不可行，我们引入由神经网络参数化的变分近似 $Q\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)$。最大化条件似然得到以下变分下界：

$$\begin{aligned}&\mathbb{E}_{p\left(\mathbf{Z}_i^1,\mathbf{Z}_i^2\right)}\left[\log p\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)\right] \\ &\quad \geq \mathbb{E}_{p\left(\mathbf{Z}_i^1,\mathbf{Z}_i^2\right)}\left[\log Q\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)\right] \qquad (12) \\ &\qquad -\mathcal{D}_{\mathrm{KL}}\left(Q\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right) \parallel p\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right)\right).\end{aligned}$$

为便于实际优化，我们假设变分分布为高斯分布：

$$Q\left(\mathbf{Z}_i^1 \mid \mathbf{Z}_i^2\right) = \mathcal{N}\left(G^{(C)}\left(\mathbf{Z}_i^2\right),\ \sigma^2 I\right).$$

其中，$G^{(C)}(\cdot)$ 表示一致性预测网络，$\sigma^2 I$ 表示预测不确定性。在高斯假设下，最大化该下界等价于最小化重建损失：

$$\mathcal{L}'_{cl} = \mathbb{E}_{p\left(\mathbf{Z}_i^1,\mathbf{Z}_i^2\right)} \left\| \mathbf{Z}_i^1 - G^{(C)}\left(\mathbf{Z}_i^2\right) \right\|_2^2. \qquad (14)$$

训练完成后，可用它直接推断缺失模态表示：

$$\widetilde{\mathbf{Z}}_i^1 = G^{(C)}\left(\mathbf{Z}_i^2\right). \qquad (15)$$

互补性对比专家。一致性专家侧重于模态不变的共享语义，而现实多模态数据往往具有丰富的、各模态特有的互补信息。为建模这种模态特有的多样性，我们引入互补性对比专家，用于捕获跨模态之间不重叠但在语义上协调的表示。令 $\mathbf{Z}_i^1$ 和 $\mathbf{Z}_i^2$ 表示样本 i 的两个模态表示。这些特征经过共享专家函数 $f_R(\cdot)$，得到互补表示：

$$\widehat{\mathbf{Z}}_i^1 = f_R\left(\mathbf{Z}_i^1\right), \quad \widehat{\mathbf{Z}}_i^2 = f_R\left(\mathbf{Z}_i^2\right). \qquad (13)$$

为增强跨模态互补性，我们设计一种损失，通过最大化熵并惩罚互信息，鼓励每个模态保留丰富信息，同时减少冗余：

$$\mathcal{L}_p = -\sum_{i=1}^{n}\left[H\left(\widehat{\mathbf{Z}}_i^1\right) + H\left(\widehat{\mathbf{Z}}_i^2\right)\right] + \beta \cdot I\left(\widehat{\mathbf{Z}}_i^1;\ \widehat{\mathbf{Z}}_i^2\right). \qquad (14)$$

其中，$\beta > 0$ 是平衡两项的超参数。为在离散空间估计互信息，计算联合共激活矩阵：

$$\mathbf{P}^{\mathrm{comp}} = \frac{1}{m}\sum_{i=1}^{m}\widehat{\mathbf{Z}}_i^1\left(\widehat{\mathbf{Z}}_i^2\right)^{\top}. \qquad (15)$$

边缘分布 $P_d^{(1)}$ 与 $P_{d'}^{(2)}$ 分别由行求和与列求和计算得到。于是，熵和互信息项可估计为：

$$\mathcal{L}_p = -\sum_{d=1}^{D}\left[H\left(P_d^{(1)}\right)+H\left(P_d^{(2)}\right)\right] +\beta\sum_{d=1}^{D}\sum_{d'=1}^{D}P_{dd'}^{\text{comp}}\log\left(\frac{P_{dd'}^{p}}{P_d^{(1)}\cdot P_{d'}^{(2)}}\right). \tag{16}$$

互补性专家预测。为重建语义相关但不重叠的缺失模态特有信息，我们引入互补性专家预测机制。与面向共享语义的一致性预测不同，该模块着重捕获各模态独有的多样化信号。与一致性专家预测相反，其训练目标简化为最大化真实值与预测互补特征之间的期望重建误差。

$$\mathcal{L}'_p = -\mathbb{E}_{p(\widetilde{\mathbf{z}}_i,\mathbf{z}_i^j)}\left\|\widetilde{\mathbf{Z}}_i-\mathcal{E}^{(j)}\left(\mathbf{Z}_i^j\right)\right\|_2^2. \tag{17}$$

训练完成后，互补特征可估计为：

$$\widetilde{\mathbf{Z}}_i=\mathcal{E}^{(j)}\left(\mathbf{Z}_i^j\right)=\mathcal{E}^{(j)}\left(\mathcal{D}^{(j)}\left(X^j\right)\right). \tag{18}$$

其中，$\mathcal{D}^{(j)}$ 是模态 j 的编码器。

路由感知的专家整合。为在预测过程中自适应地平衡共享语义与模态特有语义，我们引入一个路由网络，根据已观测模态表示的特征，动态融合一致性专家与互补性专家的输出。给定已观测模态 j 的输入特征 $\mathbf{Z}_i^j$，路由网络生成软分配向量 $\mathbf{g}_i=\left[g_i^C,\,g_i^R\right]$，其中 $g_i^C,\,g_i^R\in[0,\,1]$ 且 $g_i^C+g_i^R=1$。这些权重通过如下 softmax 门控机制计算：

$$\mathbf{g}_i=\text{softmax}\left(\mathbf{W}\cdot\mathbf{Z}_i^j+\mathbf{b}\right). \tag{19}$$

其中，$\mathbf{W}$ 和 $\mathbf{b}$ 为可学习参数。权重 g_i^C 与 g_i^R 分别表示一致性预测和互补性预测的重要程度。最终预测表示由如下加权融合给出：

$$\mathbf{Z}_i^{\text{pred}}=g_i^C\cdot\bar{\mathbf{Z}}_i+g_i^R\cdot\widetilde{\mathbf{Z}}_i. \tag{20}$$

其中，$\bar{\mathbf{Z}}_i=G^{(C)}\left(\mathbf{Z}_i^j\right)$ 为一致性预测，$\widetilde{\mathbf{Z}}_i=\mathcal{E}^{(j)}\left(\mathbf{Z}_i^j\right)$ 为互补性预测。

译者注（公式忠实性）。原稿先后重复使用编号 (10)、(12)、(14)、(15)，且在 (15) 后出现 (13)，本译文保持其编号顺序。式 (8) 后原文写作“第 K 位专家”；式 (16) 的对数分子原文为 $P_{dd'}^{p}$，而外部系数写作 $P_{dd'}^{\text{comp}}$；式 (17) 的负号与最大化重建误差的文字均按原稿保留。此处不将这些记号或目标改写为推测中的“正确”形式。

4.4 目标函数

为在双专家框架中联合优化一致性与互补性，我们定义一个复合目标，整合两位专家的对比部分和预测部分。总损失为：

$$\mathcal{L}_{\text{total}}=\lambda_1\left(\mathcal{L}_{cl}+\cdot\mathcal{L}'_{cl}\right)+\lambda_2\left(\mathcal{L}_p+\cdot\mathcal{L}'_p\right)+\mathcal{L}_{rec}+\mathcal{L}_{cyc}. \tag{21}$$

其中， λ_1, λ_2 是用于平衡四个目标相对重要性的超参数。

译者注。 式 (21) 中两个“ $+\cdot$ ”均原样保留；原稿未在点号前列出额外系数。

5 实验

5.1 语料描述

为验证 C^{2}MOE 在不同对话场景中的有效性，我们在两个基准数据集 CMU-MOSI [56] 和 CMU-MOSEI [57] 上进行了大量实验。CMU-MOSI 数据集包含来自社交媒体平台的视频评论，涵盖广泛的话题与情感表达。每个视频片段包含音频、视频和文本数据。CMU-MOSEI 数据集包含大量来自 YouTube 的视频评论。CMU-MOSI 和 CMU-MOSEI 的情感强度标注范围均为 -3（非常负面）至 +3（非常正面），0 表示中性情感。遵循先前工作 [20, 24]，我们使用以下指标评估 MERC 性能：七分类准确率（ACC7）、二分类准确率（ACC2）及 F1 分数。

5.2 实现细节

我们评估不同模态不完整程度下的模型性能。缺失率 η 定义为 $\eta = 1 - \frac{\sum_{i=1}^{L} m_i}{L \times M}$ ，其中 m_i 表示第 i 个样本的可用模态数， L 为样本数， M 为模态总数。对于每个样本，根据 η 随机遮蔽模态，同时确保至少保留一个模态（ $1 \leq m_i \leq M$ ），从而有上界 $\eta \leq \frac{M-1}{M}$ 。当 $M = 3$ 时，我们遵循先前工作 [19]，以 0.1 为步长，将 η 从 0.0 变化至 0.7。为进行公平比较，训练、验证和测试使用相同的缺失率。

对于每条话语，使用预训练模型提取声学、词汇和视觉特征。具体来说，使用 wav2vec-large [31] 提取 512 维声学特征，使用 MA-Net [62] 提取 1024 维面部特征，使用 DeBERTa [11] 提取 1024 维词汇特征。全部实验在 NVIDIA RTX 4090 GPU 上使用 PyTorch 实现，批量大小为 16。采用提前停止，模型最多训练 60 个轮次直至收敛。

译者注。 原稿给出的上界在 $M = 3$ 时为 $2/3$ ，但同时报告了缺失率 0.7 的实验。本译文保留这两处表述和原表，不推定额外的采样或舍入规则。

5.3 基线

为评估所提出 C^{2}MOE 的性能，我们将其与最先进的不完整多模态学习方法比较，包括 MCTN [29]、MMIN [61]、GCNet [19]、DiCMoR [52]、IMDer [53] 和 GSDNet [46]。

表 1。 不同方法在 CMU-MOSI 和 CMU-MOSEI 数据集不同模态缺失条件下的性能。每个单元格依次报告 ACC2/F1/ACC7。粗体表示最佳性能。

Datasets	Available	MCTN	MMIN	GCNet
CMU-MOSI	$\{l\}$	79.1/79.2/41.0	83.8/83.8/41.6	83.7/83.6/42.3
	$\{v\}$	55.0/54.4/16.3	57.0/54.0/15.5	56.1/55.7/16.9
	$\{a\}$	56.1/54.5/16.5	55.3/51.5/15.5	56.1/54.5/16.6
	$\{l,v\}$	81.1/81.2/42.1	83.8/83.9/42.0	84.3/84.2/43.4
	$\{l,a\}$	81.0/81.0/43.2	84.0/84.0/42.3	84.5/84.4/43.4
	$\{v,a\}$	57.5/57.4/16.8	60.4/58.5/19.5	62.0/61.9/17.2
	$\{l,v,a\}$	81.4/81.5/43.4	84.6/84.4/44.8	85.2/85.1/44.9
	Average	70.2/69.9/31.3	72.7/71.4/31.6	73.1/72.8/32.1
CMU-MOSEI	$\{l\}$	82.6/82.8/50.2	82.3/82.4/51.4	83.0/83.2/51.2
	$\{v\}$	62.6/57.1/41.6	59.3/60.0/40.7	61.9/61.6/41.7
	$\{a\}$	62.7/54.5/41.4	58.9/59.5/40.4	60.2/60.3/41.1
	$\{l,v\}$	83.2/83.2/50.4	83.8/83.4/51.2	84.3/84.4/51.1
	$\{l,a\}$	83.5/83.3/50.7	83.7/83.3/52.0	84.3/84.4/51.3
	$\{v,a\}$	63.7/62.7/42.1	63.5/61.9/41.8	64.1/57.2/42.0
	$\{l,v,a\}$	84.2/84.2/51.2	84.3/84.2/52.4	85.2/85.1/51.5
	Average	74.6/72.5/46.8	73.7/73.5/47.1	74.7/73.7/47.1

Datasets	Available	DiCMoR	IMDer	GSDNet	C^{2}MOE (Ours)
CMU-MOSI	$\{l\}$	84.5/84.4/44.3	84.8/84.7/44.8	86.4/86.6/45.7	**87.3/87.7/48.0**
	$\{v\}$	62.2/60.2/20.9	61.3/60.8/22.2	64.1/63.7/25.3	**65.3/64.5/26.1**
	$\{a\}$	62.2/60.2/20.9	62.0/62.2/22.0	64.4/64.1/24.6	**65.6/65.5/26.4**
	$\{l,v\}$	85.5/85.4/45.2	85.5/85.4/45.3	86.5/86.4/46.7	**87.6/87.9/47.4**
	$\{l,a\}$	85.5/85.5/44.6	85.4/85.3/45.0	86.7/86.6/46.8	**88.0/87.8/47.6**
	$\{v,a\}$	64.0/63.5/21.9	63.6/63.4/23.8	65.2/64.8/24.9	**66.7/65.5/25.2**
	$\{l,v,a\}$	85.7/85.6/45.3	85.7/85.6/45.3	87.7/87.3/46.8	**88.5/88.8/47.4**
	Average	75.4/75.1/34.7	75.5/75.3/35.5	77.3/77.1/37.3	**78.4/78.2/38.3**
CMU-MOSEI	$\{l\}$	84.2/84.3/52.4	84.5/84.5/52.5	86.6/86.1/55.3	**87.3/87.1/56.7**
	$\{v\}$	63.6/63.6/42.0	63.9/63.6/42.6	65.1/65.7/44.9	**66.8/66.6/45.7**
	$\{a\}$	62.9/60.4/41.4	63.8/60.6/41.7	64.6/64.2/43.1	**66.4/65.5/44.4**
	$\{l,v\}$	84.9/84.9/53.0	85.0/85.0/53.1	87.3/87.0/56.2	**88.8/88.3/57.1**
	$\{l,a\}$	85.0/84.9/52.7	85.1/85.1/53.1	86.2/86.4/55.5	**87.4/87.7/56.2**
	$\{v,a\}$	65.2/64.4/42.4	64.9/63.5/42.8	66.7/66.3/45.2	**67.9/66.7/46.0**
	$\{l,v,a\}$	85.1/85.1/53.4	85.1/85.1/53.4	87.3/87.2/54.9	**88.6/88.1/56.5**
	Average	75.8/75.4/48.2	76.0/75.3/48.5	77.7/77.6/50.7	**79.0/78.6/51.8**

标签：Datasets = 数据集；Available = 可用模态；Average = 平均值；Ours = 本文方法。 l, v, a 分别表示语言/文本、视觉和音频。为放大数值，原表模型列拆为上下两组，重复数据集与可用模态列；两组共同构成完整表 1。

表 2。 不同方法在 CMU-MOSI 和 CMU-MOSEI 数据集不同缺失率下的性能。每个单元格依次报告 ACC2/F1/ACC7。粗体表示最佳性能。

Datasets	Missing Rate	MCTN	MMIN	GCNet
CMU-MOSI	0.0	81.4/81.5/43.4	84.6/84.4/44.8	85.2/85.1/44.9
	0.1	78.4/78.5/39.8	81.8/81.8/41.2	82.3/82.3/42.1
	0.2	75.6/75.7/38.5	79.0/79.1/38.9	79.4/79.5/40.0
	0.3	71.3/71.2/35.5	76.1/76.2/36.9	77.2/77.2/38.2
	0.4	68.0/67.6/32.9	71.7/71.6/34.9	74.3/74.4/36.6
	0.5	65.4/64.8/31.2	67.2/66.5/32.2	70.0/69.8/33.9
	0.6	63.8/62.5/29.7	64.9/64.0/29.1	67.7/66.7/29.8
	0.7	61.2/59.0/27.5	62.8/61.0/28.4	65.7/65.4/28.1
	Average	70.6/70.1/34.8	73.5/73.1/35.8	75.2/75.1/36.7
CMU-MOSEI	0.0	84.2/84.2/51.2	84.3/84.2/52.4	85.2/85.1/51.5
	0.1	81.8/81.6/49.8	81.9/81.3/50.6	82.3/82.1/51.2
	0.2	79.0/78.7/48.6	79.8/78.8/49.6	80.3/79.9/50.2
	0.3	76.9/76.2/47.4	77.2/75.5/48.1	77.5/76.8/49.2
	0.4	74.3/74.1/45.6	75.2/72.6/47.5	76.0/74.9/48.0
	0.5	73.6/72.6/45.1	73.9/70.7/46.7	74.9/73.2/46.7
	0.6	73.2/71.1/43.8	73.2/70.3/45.6	74.1/72.1/45.1
	0.7	72.7/70.5/43.6	73.1/69.5/44.8	73.2/70.4/44.5
	Average	77.0/76.1/46.9	77.3/75.4/48.2	77.9/76.8/48.3

Datasets	Missing Rate	DiCMoR	IMDer	GSDNet	C^2MOE (Ours)
CMU-MOSI	0.0	85.7/85.6/45.3	85.7/85.6/45.3	87.7/87.3/46.8	**88.5/88.8/47.4**
	0.1	83.9/83.9/43.6	84.9/84.8/44.8	87.1/86.5/46.2	**88.4/88.0/47.8**
	0.2	83.9/83.9/43.6	83.5/83.4/44.3	86.4/86.1/45.2	**87.1/87.5/46.5**
	0.3	80.4/80.2/40.6	81.2/81.0/42.5	85.2/85.0/44.3	**86.7/86.1/45.8**
	0.4	77.9/77.7/37.6	78.6/78.5/39.7	83.3/82.9/42.1	**85.2/84.7/43.7**
	0.5	76.7/76.4/36.4	76.2/75.9/37.9	81.2/81.1/40.6	**82.4/82.4/41.5**
	0.6	73.3/73.0/32.7	74.7/74.0/35.8	80.1/79.7/38.7	**81.7/81.3/39.2**
	0.7	71.1/70.8/30.0	71.9/71.2/33.4	77.6/77.3/35.6	**78.3/78.5/36.3**
	Average	78.9/78.7/38.5	79.6/79.3/40.5	83.6/83.2/42.3	**84.8/84.7/43.5**
CMU-MOSEI	0.0	78.9/78.7/38.5	85.1/85.1/53.4	87.3/87.2/54.9	**88.6/88.1/55.5**
	0.1	78.9/78.7/38.5	84.8/84.6/53.1	86.7/86.5/54.2	**87.9/87.7/55.6**
	0.2	81.8/81.5/51.4	82.7/82.4/52.0	85.3/85.1/53.5	**86.2/86.1/54.3**
	0.3	79.8/79.3/50.3	81.3/80.7/51.3	83.3/83.0/52.2	**84.8/84.6/53.8**
	0.4	78.7/77.4/48.8	79.3/78.1/50.0	81.4/81.2/51.4	**83.2/82.5/53.2**
	0.5	77.7/75.8/47.7	79.0/77.4/49.2	80.5/80.1/50.7	**81.3/81.6/51.4**
	0.6	77.7/75.8/47.7	78.0/75.5/48.5	79.4/79.1/49.4	**80.7/80.3/50.6**
	0.7	75.4/72.2/46.2	77.3/74.6/47.6	78.2/78.1/48.6	**79.5/79.3/49.7**
	Average	79.9/78.6/49.6	80.9/79.8/50.6	82.8/82.5/51.9	**84.0/83.8/53.0**

标签：Missing Rate = 缺失率；其余标签同表 1。原表模型列拆为上下两组，并重复左侧索引列；所有数值照录，包括 CMU-MOSEI 中 DiCMoR 的原有重复值，以及 C^2MOE 在缺失率 0.0 时与表 1 不同的 ACC7 数值。

6 结果与讨论

6.1 不同缺失模态下的性能

表 1 列出了在 CMU-MOSI 和 CMU-MOSEI 数据集上，不同缺失模态与随机缺失率条件下的定量结果，展示了各方法在模态缺失时的性能。C^{2}MOE 在两个数据集上都取得了最佳结果，验证了它在处理模态缺失问题方面的优势。C^{2}MOE 的优越性能可能归因于它能够同时利用多模态数据的一致性语义信息与互补性语义信息。这不仅有助于确保恢复数据与原始数据的一致性，也为恢复数据提供了额外补充信息，增强了模型在模态缺失时的鲁棒性。

6.2 不同缺失率下的性能

表 2 列出了 CMU-MOSI 和 CMU-MOSEI 数据集上随机缺失率的定量结果，展示各方法在不同缺失率下的性能。与其他 MERC 方法相比，随着模态缺失率增加，C^{2}MOE 的性能退化有所减轻，说明它能有效应对模态缺失带来的挑战，并在高缺失率条件下保持较高的识别性能。事实上，对于多数基于恢复的模型，性能通常会随模态缺失率增加而显著下降。C^{2}MOE 通过更好地利用模态间的一致性和互补性，显著减缓了性能退化。

6.3 消融研究

表 3 给出了消融研究，考察 C^{2}MOE 框架内不同损失成分的影响。仅使用一致性对比损失 $\mathcal{L}_{cl}$ 时，模型就已取得较强的基线性能，验证了该损失在捕获模态不变语义表示、促进跨模态语义对齐方面的有效性。相比之下，仅使用互补性对比损失 $\mathcal{L}_{comp}$ 会导致性能略有下降。这表明，如果缺少足够的一致性约束而只强调多样性，可能会引入语义噪声，阻碍稳定的表示学习。此外，仅使用 $\mathcal{L}_{cl}$, 和 $\mathcal{L}_{comp}$, 进行预测训练，会显著降低性能，说明缺乏显式语义对齐的重建或预测目标，不足以支持稳健的多模态理解。值得注意的是，联合优化全部四项损失时取得了最佳性能。这表明对比目标与预测目标具有互补作用：对比损失施加语义结构约束，预测损失则增强表示的完整性。这些结果明确验证了在 C^{2}MOE 路由机制下联合建模一致性与互补性的有效性。

$\mathcal{L}_{cl}$	$\mathcal{L}_p$	$\mathcal{L}'_{cl}$	$\mathcal{L}'_p$	CMU-MOSI			CMU-MOSEI		
				ACC_2	F1	ACC_7	ACC_2	F1	ACC_7
✓	✓			81.4	81.0	41.2	81.1	80.8	50.5
		✓	✓	78.6	78.2	39.4	78.3	77.7	48.2
✓		✓		74.7	72.0	33.6	72.1	71.4	42.3
	✓		✓	75.8	75.3	34.1	73.0	72.6	45.4
✓	✓	✓	✓	**84.8**	**84.7**	**43.5**	**84.0**	**83.8**	**53.0**

表 3。 C^{2}MOE 在随机缺失率平均结果上的消融研究。各单元格报告 ACC2/F1/ACC7。粗体表示最佳性能。勾号表示启用相应损失项。

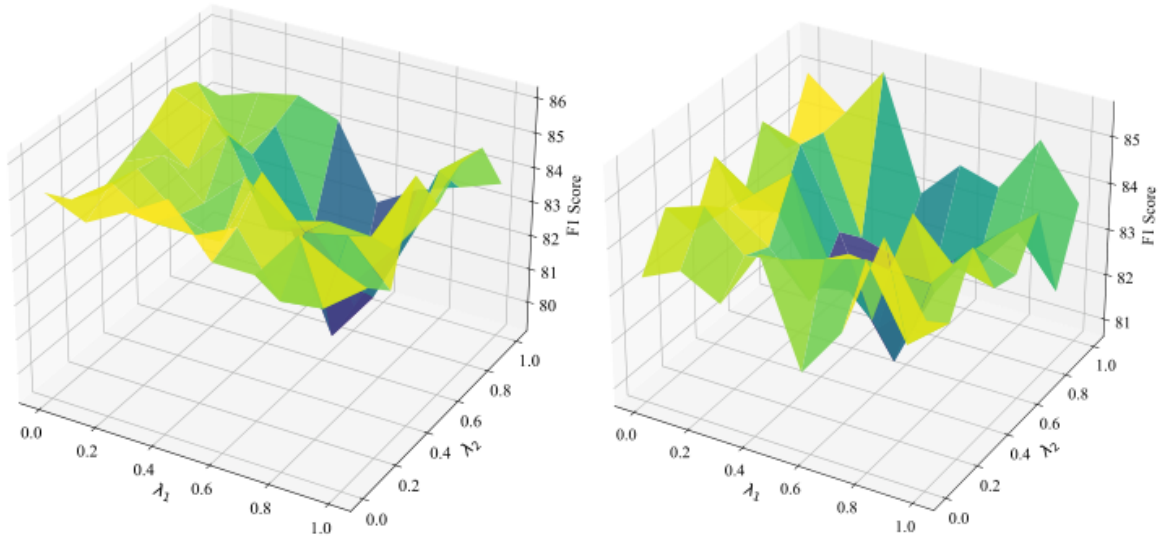
译者注。 本节原文使用 $\mathcal{L}_{comp}$、$\mathcal{L}_{comp'}$ 等记号，前文与表 3 则使用 $\mathcal{L}_{p}$、$\mathcal{L}'_{p}$。此外，正文描述“仅使用”单个对比损失，但表 3 的前四行各有两项损失被勾选。本译文保留原叙述和原表，不据此补造新的消融结果。

6.4 超参数敏感性分析

图 ?? 展示了所提出模型在 CMU-MOSI 和 CMU-MOSEI 数据集上，不同 λ_1 和 λ_2 设置下的 F1 分数；这两个参数分别控制一致性对比损失和互补性对比损失的相对权重。如图所示，两个超参数在适中的范围内变化时，模型性能稳定，说明 C^{2}MOE 对精确的超参数调节并不过分敏感。值得注意的是，在 $\lambda_1 \in [0.6, 0.8]$、$\lambda_2 \in [0.3, 0.5]$ 时出现了明显的性能峰值，表明一致性与互补性之间的适当平衡，对取得最优性能至关重要。

当任一超参数设置得极低或极高时，模型性能都会明显下降。这表明，对一致性的强调不足，可能削弱跨模态语义对齐；对一致性的强调过度，则可能抑制有用的互补信息。同样，对互补损失赋予过大的权重可能引入语义噪声，而强调不足则可能限制模型利用模态特有线索的能力。总体而言，这些结果凸显了联合建模一致性和互补性、学习平衡且稳健的多模态表示的重要性。

译者注。 “图 ??” 是原稿未解析的交叉引用，按原文保留。下方的图 3 及其编号、图题均来自原稿，不将原文的问号悄然替换为推断出的图号。



(a) CMU-MOSI　　(b) CMU-MOSEI

图 3。 所提出模型在两个基准数据集上，超参数 λ_1 和 λ_2 变化时的 F1 分数表现。（a）CMU-MOSI；（b）CMU-MOSEI。F1 Score = F1 分数；两个水平轴为 λ_1 与 λ_2。

6.5 嵌入空间可视化

图 4 使用 t-SNE，对 CMU-MOSEI 数据集在固定模态缺失设置下，恢复数据与原始数据的特征分布进行可视化。如图所示，C^{2}MOE 生成的分布与原始数据分布最接近，表明该方法在恢复过程中能更有效地保留缺失模态内在的结构和语义特征。恢复特征不仅在全局上与原始分布良好重合，也保持了连贯的局部邻域结构。

相比之下，其他基于恢复的方法出现明显的分布偏移，具有显著偏差和碎片化簇，尤其在与原始数据重合较弱的局部区域更为明显。这些差异表明，这类方法难以保持细粒度语义一致性，从而导致特征表示失真。总体而言，该可视化直观地表明，C^{2}MOE 能更好地捕获全局分布一致性与局部语义结构，进而实现更忠实、更稳健的模态恢复。

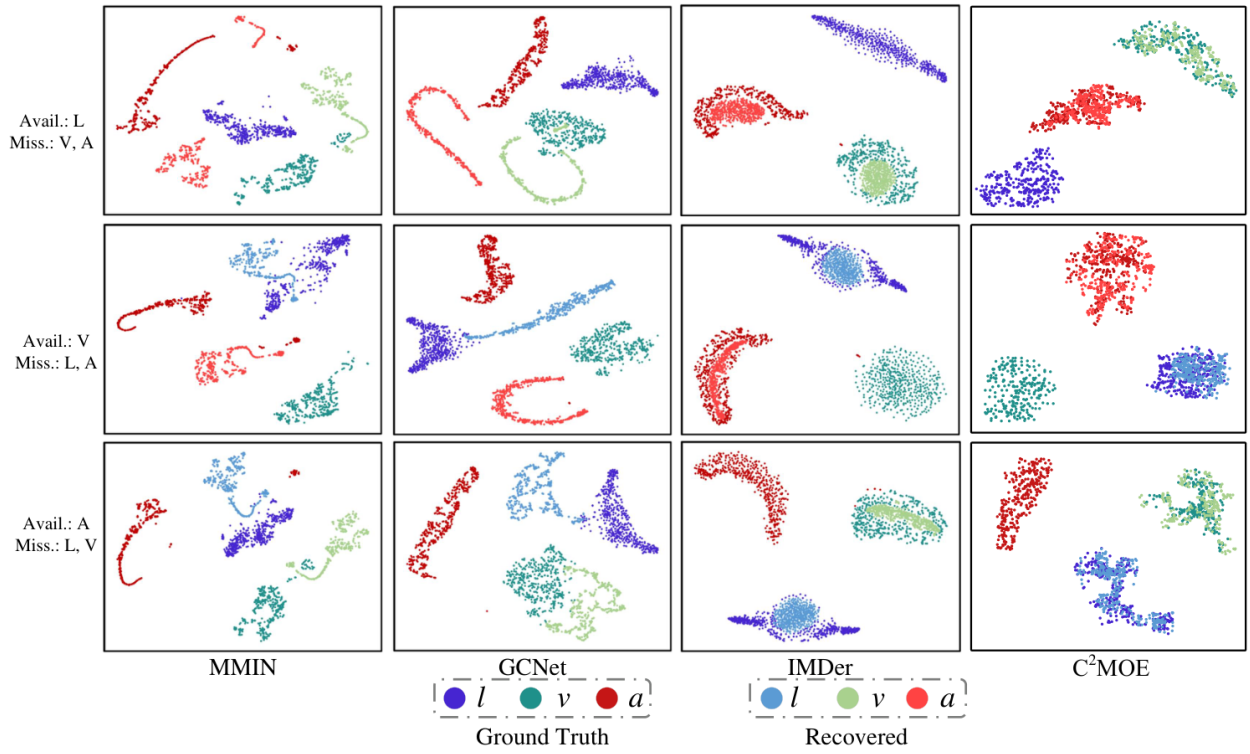


图 4。 恢复模态的可视化。Avail. 表示可用模态；Miss. 表示缺失模态。三行分别为：仅 L 可用、缺失 V 与 A；仅 V 可用、缺失 L 与 A；仅 A 可用、缺失 L 与 V。四列依次为 MMIN、GCNet、IMDer 和 C^{2}MOE。Ground Truth = 真实值；Recovered = 恢复值； l, v, a 分别表示语言/文本、视觉与音频。

6.6 插补性能

图 5 报告了不同方法在不同缺失率下的补全性能。在 CMU-MOSI 和 CMU-MOSEI 的所有缺失率设置下，C^{2}MOE 始终优于基线，尤其在高缺失率时提升更为显著。这些结果凸显了分布一致性与跨模态互补性在补全中的关键作用，而多数基线未充分利用二者。通过分别为一致性和互补性联合执行互信息最大化与最小化，C^{2}MOE 不仅能恢复缺失模态，还能更好地保留原始结构与语义属性，特别是在严重缺失条件下。

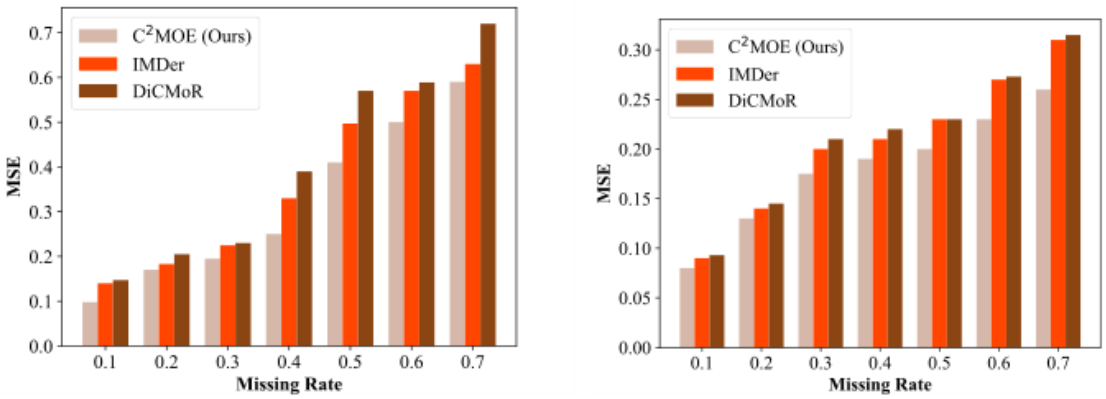


图 5。 不同缺失率下的插补性能比较，展示各方法处理不同缺失率时的插补效果。（a）CMU-MOSI；（b）CMU-MOSEI。MSE = 均方误差；Missing Rate = 缺失率；C²MOE (Ours) = C²MOE（本文方法）；其余图例为 IMDer、DiCMoR。原图题使用 interpolation，正文则使用 imputation/completion；此处按本文任务语境统一译作“插补/补全”，不改变其数值或曲线。

7 结论

本研究解决了对话多模态情感识别中的一个核心障碍：现实场景下模态缺失导致的严重性能下降。我们提出 C²MOE，一种一致性与互补性引导的混合专家框架，在统一的信息论表述下，将多模态表示显式解耦为一致性成分与互补性成分。双分支插补机制将通过不确定性最小化实现的一致性对齐，与通过熵最大化实现的互补性利用结合起来，在保留模态独有线索的同时实现连贯重建。此外，可学习的重加权模块自适应地融合专家输出，提高了异质缺失模式下的灵活性，并增强鲁棒性。在多个 MERC 基准上的大量实验表明，C²MOE 在多种模态缺失场景下持续优于最先进方法，具有更高的准确性与稳定性。

参考文献

以下完整保留原稿的 63 条文献及原有作者、年份、发表载体、卷期、页码和标识信息；在英文题名后附中文译名，便于检索与阅读。原稿未列出的信息不补造。

[1] Wei Ai, Yilong Tan, Yuntao Shou, Tao Meng, Haowen Chen, Zhixiong He, and Keqin Li. 2026. The paradigm shift: A comprehensive survey on large vision language models for multimodal fake news detection. Computer Science Review 60 (2026), 100893. **中文题名：** 范式转变：用于多模态虚假新闻检测的大型视觉语言模型综合综述。

[2] Galen Andrew, Raman Arora, Jeff Bilmes, and Karen Livescu. 2013. Deep canonical correlation analysis. In International conference on machine learning. PMLR, 1247–1255. **中文题名：** 深度典型相关分析。

[3] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. 2020. A simple framework for contrastive learning of visual representations. In International conference on machine learning. PMLR, 1597–1607. **中文题名：** 视觉表示对比学习的简单框架。

[4] Yijing Dai, Yingjian Li, Jinxing Li, and Guangming Lu. 2025. Hierarchical Multi-Criteria Representation Fusion for Robust Incomplete Multimodal Sentiment Analysis. IEEE Transactions on Affective Computing (2025). **中文题名：** 面向稳健不完整多模态情感分析的层次化多准则表示融合。

[5] Cheng Deng, Zhaojia Chen, Xianglong Liu, Xinbo Gao, and Dacheng Tao. 2018. Triplet-based deep hashing network for cross-modal retrieval. IEEE Transactions on Image Processing 27, 8 (2018), 3893–3903. **中文题名：** 用于跨模态检索的基于三元组的深度哈希网络。

[6] Yuanyue Deng, Jintang Bian, Shisong Wu, Jianhuang Lai, and Xiaohua Xie. 2025. Multiplex graph aggregation and feature refinement for unsupervised incomplete multimodal emotion recognition. Information Fusion 114 (2025), 102711. **中文题名：** 面向无监督不完整多模态情感识别的多重图聚合与特征精炼。

[7] Yi Ding, Neethu Robinson, Chengxuan Tong, Qiuhao Zeng, and Cuntai Guan. 2023. LGGNet: Learning from local-global-graph representations for brain–computer interface. IEEE Transactions on Neural Networks and Learning Systems (2023). **中文题名：** LGGNet：面向脑机接口的局部-全局-图表示学习。

[8] Shengcai Duan, Le Wu, Aiping Liu, and Xun Chen. 2023. Alignment-enhanced interactive fusion model for complete and incomplete multimodal hand gesture recognition. IEEE Transactions on Neural Systems and Rehabilitation Engineering 31 (2023), 4661–4671. **中文题名：** 用于完整与不完整多模态手势识别的对齐增强交互融合模型。

[9] Raia Hadsell, Sumit Chopra, and Yann LeCun. 2006. Dimensionality reduction by learning an invariant mapping. In 2006 IEEE computer society conference on computer vision and pattern recognition (CVPR’06), Vol. 2. IEEE, 1735–1742. **中文题名：** 通过学习不变映射进行降维。

[10] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. 2020. Momentum contrast for unsupervised visual representation learning. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 9729–9738. **中文题名：** 用于无监督视觉表示学习的动量对比。

[11] Pengcheng He, Xiaodong Liu, Jianfeng Gao, and Weizhu Chen. [n.d.]. DEBERTA: DECODING-ENHANCED BERT WITH DISENTANGLED ATTENTION. In International Conference on Learning Representations. **中文题名：** DEBERTA：采用解耦注意力的解码增强BERT。

[12] Zhangfeng Hu, Wenming Zheng, Yuan Zong, Mengting Wei, Xingxun Jiang, and Mengxin Shi. 2024. A novel decoupled prototype completion network for incomplete multimodal emotion recognition. In 2024 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 1–6. **中文题名：** 用于不完整多模态情感识别的新型解耦原型补全网络。

[13] Thomas N Kipf and Max Welling. 2016. Variational Graph Auto-Encoders. NIPS Workshop on Bayesian Deep Learning (2016). **中文题名：** 变分图自编码器。

[14] Jian Lang, Zhangtao Cheng, Ting Zhong, and Fan Zhou. 2025. Retrieval-augmented dynamic prompt tuning for incomplete multimodal learning. In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 39. 18035–18043. **中文题名：** 用于不完整多模态学习的检索增强动态提示调优。

[15] Mingcheng Li, Dingkang Yang, Yang Liu, Shunli Wang, Jiawei Chen, Shuaibing Wang, Jinjie Wei, Yue Jiang, Qingyao Xu, Xiaolu Hou, et al. 2024. Toward robust incomplete multimodal sentiment analysis via hierarchical representation learning. Advances in Neural Information Processing Systems 37 (2024), 28515–28536. **中文题名：** 通过层次化表示学习实现稳健的不完整多模态情感分析。

[16] Mingcheng Li, Dingkang Yang, Xiao Zhao, Shuaibing Wang, Yan Wang, Kun Yang, Mingyang Sun, Dongliang Kou, Ziyun Qian, and Lihua Zhang. 2024. Correlation-decoupled knowledge distillation for multimodal sentiment analysis with incomplete modalities. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 12458–12468. **中文题名：** 面向模态不完整的多模态情感分析的相关性解耦知识蒸馏。

[17] Yunfan Li, Peng Hu, Zitao Liu, Dezhong Peng, Joey Tianyi Zhou, and Xi Peng. 2021. Contrastive clustering. In Proceedings of the AAAI conference on artificial intelligence, Vol. 35. 8547–8555. **中文题名：** 对比聚类。

[18] Yong Li, Yuanzhi Wang, and Zhen Cui. 2023. Decoupled multimodal distilling for emotion recognition. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 6631–6640. **中文题名：** 用于情感识别的解耦多模态蒸馏。

[19] Zheng Lian, Lan Chen, Licai Sun, Bin Liu, and Jianhua Tao. 2023. GCNet: Graph completion network for incomplete multimodal learning in conversation. IEEE Transactions on pattern analysis and machine intelligence 45, 7 (2023), 8419–8432. **中文题名：** GCNet：用于对话中不完整多模态学习的图补全网络。

[20] Tao Liang, Guosheng Lin, Lei Feng, Yan Zhang, and Fengmao Lv. 2021. Attention is not enough: Mitigating the distribution discrepancy in asynchronous multi-modal sequence fusion. In Proceedings of the IEEE/CVF International Conference on Computer Vision. 8148–8156. **中文题名：** 仅有注意力还不够：缓解异步多模态序列融合中的分布差异。

[21] Yijie Lin, Yuanbiao Gou, Xiaotian Liu, Jinfeng Bai, Jiancheng Lv, and Xi Peng. 2022. Dual contrastive prediction for incomplete multi-view representation learning. IEEE Transactions on Pattern Analysis and Machine Intelligence 45, 4 (2022), 4447–4461. **中文题名：** 用于不完整多视图表示学习的双重对比预测。

[22] Yijie Lin, Yuanbiao Gou, Zitao Liu, Boyun Li, Jiancheng Lv, and Xi Peng. 2021. COMPLETER: Incomplete multi-view clustering via contrastive prediction. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 11174–11183. **中文题名：** COMPLETER：通过对比预测实现不完整多视图聚类。

[23] Rui Liu, Haolin Zuo, Zheng Lian, Björn W Schuller, and Haizhou Li. 2024. Contrastive learning based modality-invariant feature acquisition for robust multimodal emotion recognition with missing modalities. IEEE Transactions on Affective Computing 15, 4 (2024), 1856–1873. **中文题名：** 基于对比学习获取模态不变特征，以实现模态缺失时的稳健多模态情感识别。

[24] Fengmao Lv, Xiang Chen, Yanyong Huang, Lixin Duan, and Guosheng Lin. 2021. Progressive Modality Reinforcement for Human Multimodal Emotion Recognition From Unaligned Multimodal Sequences. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2554–2562. **中文题名：** 从未对齐多模态序列识别人类多模态情感的渐进式模态增强。

[25] Hui Ma, Jian Wang, Hongfei Lin, Bo Zhang, Yijia Zhang, and Bo Xu. 2023. A Transformer-Based Model With Self-Distillation for Multimodal Emotion Recognition in Conversations. IEEE Transactions on Multimedia (2023), 1–13. **中文题名：** 具有自蒸馏机制的基于 Transformer 的对话多模态情感识别模型。

[26] Tao Meng, Yuntao Shou, Wei Ai, Jiayi Du, Haiyan Liu, and Keqin Li. 2024. A multi-message passing framework based on heterogeneous graphs in conversational emotion recognition. Neurocomputing 569 (2024), 127109. **中文题名：** 对话情感识别中基于异质图的多消息传递框架。

[27] Tao Meng, Yuntao Shou, Wei Ai, Nan Yin, and Keqin Li. 2024. Deep imbalanced learning for multimodal emotion recognition in conversations. IEEE Transactions on Artificial Intelligence 5, 12 (2024), 6472–6487. **中文题名：** 用于对话多模态情感识别的深度不平衡学习。

[28] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. 2018. Representation learning with contrastive predictive coding. CoRR (2018). **中文题名：** 利用对比预测编码进行表示学习。

[29] Hai Pham, Paul Pu Liang, Thomas Manzini, Louis-Philippe Morency, and Barnabás Póczos. 2019. Found in translation: Learning robust joint representations by cyclic translations between modalities. In Proceedings of the AAAI conference on artificial intelligence, Vol. 33. 6892–6899. **中文题名：** 在转换中发现：通过模态间循环转换学习稳健联合表示。

[30] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. 2021. Zero-shot text-to-image generation. In International Conference on Machine Learning. Pmlr, 8821–8831. **中文题名：** 零样本文本到图像生成。

[31] Steffen Schneider, Alexei Baevski, Ronan Collobert, and Michael Auli. 2019. wav2vec: Unsupervised pre-training for speech recognition. In Proceedings of the Interspeech. 3465–3469. **中文题名：** wav2vec：用于语音识别的无监督预训练。

[32] Yuntao Shou, Wei Ai, Jiayi Du, Tao Meng, Haiyan Liu, and Nan Yin. 2024. Efficient long-distance latent relation-aware graph neural network for multi-modal emotion recognition in conversations. arXiv preprint arXiv:2407.00119 (2024). **中文题名：** 用于对话多模态情感识别的高效长距离潜在关系感知图神经网络。

[33] Yuntao Shou, Wei Ai, Tao Meng, and Keqin Li. 2026. Graph diffusion models: A comprehensive survey of methods and applications. Computer Science Review 59 (2026), 100854. **中文题名：** 图扩散模型：方法与应用综合综述。

[34] Yuntao Shou, Xiangyong Cao, Huan Liu, and Deyu Meng. 2025. Masked contrastive graph representation learning for age estimation. Pattern Recognition 158 (2025), 110974. **中文题名：** 用于年龄估计的掩码对比图表示学习。

[35] Yuntao Shou, Xiangyong Cao, and Deyu Meng. 2025. Spegcl: Self-supervised graph spectrum contrastive learning without positive samples. IEEE Transactions on Neural Networks and Learning Systems (2025). **中文题名：** Spegcl：无需正样本的自监督图谱对比学习。

[36] Yuntao Shou, Xiangyong Cao, Peiqiang Yan, Qiao Hui, Qian Zhao, and Deyu Meng. 2025. Graph domain adaptation with dual-branch encoder and two-level alignment for whole slide image-based survival prediction. In Proceedings of the IEEE/CVF International Conference on Computer Vision. 19925–19935. **中文题名：** 用于基于全切片图像的生存预测的双分支编码器与双层对齐图域适应。

[37] Yuntao Shou, Haozhi Lan, and Xiangyong Cao. 2025. Contrastive graph representation learning with adversarial cross-view reconstruction and information bottleneck. Neural Networks 184 (2025), 107094. **中文题名：** 具有对抗性跨视图重建和信息瓶颈的对比图表示学习。

[38] Yuntao Shou, Huan Liu, Xiangyong Cao, Deyu Meng, and Bo Dong. 2024. A low-rank matching attention based cross-modal feature fusion method for conversational emotion recognition. IEEE Transactions on Affective Computing 16, 2 (2024), 1177–1189. **中文题名：** 用于对话情感识别的基于低秩匹配注意力的跨模态特征融合方法。

[39] Yuntao Shou, Tao Meng, Wei Ai, Fangze Fu, Nan Yin, and Keqin Li. 2026. A comprehensive survey on multi-modal conversational emotion recognition with deep learning. ACM Transactions on Information Systems 44, 2 (2026), 1–48. **中文题名：** 基于深度学习的多模态对话情感识别综合综述。

[40] Yuntao Shou, Tao Meng, Wei Ai, and Keqin Li. 2025. Dynamic graph neural ODE network for multi-modal emotion recognition in conversation. In Proceedings of the 31st International Conference on Computational Linguistics. 256–268. **中文题名：** 用于对话多模态情感识别的动态图神经常微分方程网络。

[41] Yuntao Shou, Tao Meng, Wei Ai, and Keqin Li. 2025. Multimodal large language models meet multimodal emotion recognition and reasoning: A survey. arXiv preprint arXiv:2509.24322 (2025). **中文题名：** 多模态大语言模型遇上多模态情感识别与推理：综述。

[42] Yuntao Shou, Tao Meng, Wei Ai, and Keqin Li. 2025. Revisiting multi-modal emotion learning with broad state space models and probability-guidance fusion. In Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Springer, 509–525. **中文题名：** 利用宽状态空间模型与概率引导融合重新审视多模态情感学习。

[43] Yuntao Shou, Tao Meng, Wei Ai, Sihan Yang, and Keqin Li. 2022. Conversational emotion recognition studies based on graph convolutional neural networks and a dependent syntactic analysis. Neurocomputing 501 (2022), 629–639. **中文题名：** 基于图卷积神经网络和依存句法分析的对话情感识别研究。

[44] Yuntao Shou, Tao Meng, Wei Ai, Nan Yin, and Keqin Li. 2025. CILF-CIAE: CLIP-driven Image–Language Fusion for Correcting Inverse Age Estimation. Neural Networks (2025), 108518. **中文题名：** CILF-CIAE：CLIP 驱动的图像-语言融合，用于纠正反向年龄估计。

[45] Yuntao Shou, Tao Meng, Wei Ai, Fuchen Zhang, Nan Yin, and Keqin Li. 2024. Adversarial alignment and graph fusion via information bottleneck for multimodal emotion recognition in conversations. Information Fusion 112 (2024), 102590. **中文题名：** 通过信息瓶颈实现对抗对齐与图融合，用于对话多模态情感识别。

[46] Yuntao Shou, Jun Yao, Tao Meng, Wei Ai, Cen Chen, and Keqin Li. 2025. GSDNet: Revisiting Incomplete Multimodality-Diffusion Emotion Recognition from the Perspective of Graph Spectrum. In Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence, IJCAI-25. International Joint Conferences on Artificial Intelligence Organization. 6182–6190. **中文题名：** GSDNet：从图谱角度重新审视不完整多模态扩散情感识别。

[47] Yuntao Shou, Jun Zhou, Tao Meng, Wei Ai, and Keqin Li. 2026. Dual-branch Graph Domain Adaptation for Cross-scenario Multi-modal Emotion Recognition. arXiv preprint arXiv:2603.26840 (2026). **中文题名：** 用于跨场景多模态情感识别的双分支图域适应。

[48] Yonglong Tian, Dilip Krishnan, and Phillip Isola. 2020. Contrastive multiview coding. In Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16. Springer, 776–794. **中文题名：** 对比多视图编码。

[49] Luan Tran, Xiaoming Liu, Jiayu Zhou, and Rong Jin. 2017. Missing modalities imputation via cascaded residual autoencoder. In Proceedings of the IEEE conference on computer vision and pattern recognition. 1405–1414. **中文题名：** 通过级联残差自编码器进行缺失模态插补。

[50] Yao-Hung Hubert Tsai, Shaojie Bai, Paul Pu Liang, J Zico Kolter, Louis-Philippe Morency, and Ruslan Salakhutdinov. 2019. Multimodal Transformer for Unaligned Multimodal Language Sequences. In Proceedings of the 57th Conference of the Association for Computational Linguistics. 6558–6569. **中文题名：** 用于未对齐多模态语言序列的多模态 Transformer。

[51] Weiran Wang, Raman Arora, Karen Livescu, and Jeff Bilmes. 2015. On deep multi-view representation learning. In International conference on machine learning. PMLR, 1083–1092. **中文题名：** 论深度多视图表示学习。

[52] Yuanzhi Wang, Zhen Cui, and Yong Li. 2023. Distribution-consistent modal recovering for incomplete multimodal learning. In Proceedings of the IEEE/CVF International Conference on Computer Vision. 22025–22034. **中文题名：** 用于不完整多模态学习的分布一致模态恢复。

[53] Yuanzhi Wang, Yong Li, and Zhen Cui. 2023. Incomplete multimodality-diffused emotion recognition. Advances in Neural Information Processing Systems 36 (2023), 17117–17128. **中文题名：** 不完整多模态扩散情感识别。

[54] Yuanzhi Wang, Yong Li, and Zhen Cui. 2024. Incomplete multimodality-diffused emotion recognition. Advances in Neural Information Processing Systems 36 (2024). **中文题名：** 不完整多模态扩散情感识别。

[55] Wenxin Xu, Hexin Jiang, and Xuefeng Liang. 2024. Leveraging Knowledge of Modality Experts for Incomplete Multimodal Learning. In Proceedings of the 32nd ACM International Conference on Multimedia. 438–446. **中文题名：** 利用模态专家知识进行不完整多模态学习。

[56] Amir Zadeh, Rowan Zellers, Eli Pincus, and Louis-Philippe Morency. 2016. Multi-modal sentiment intensity analysis in videos: Facial gestures and verbal messages. IEEE Intelligent Systems 31, 6 (2016), 82–88. **中文题名：** 视频中的多模态情感强度分析：面部姿态与言语信息。

[57] AmirAli Bagher Zadeh, Paul Pu Liang, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. 2018. Multimodal language analysis in the wild: Cmu-mosei dataset and interpretable dynamic fusion graph. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2236–2246. **中文题名：** 自然场景中的多模态语言分析：CMU-MOSEI 数据集与可解释动态融合图。

[58] Changqing Zhang, Yajie Cui, Zongbo Han, Joey Tianyi Zhou, Huazhu Fu, and Qinghua Hu. 2020. Deep partial multi-view learning. IEEE transactions on pattern analysis and machine intelligence 44, 5 (2020), 2402–2415. **中文题名：** 深度部分多视图学习。

[59] Haoyu Zhang, Wenbin Wang, and Tianshu Yu. 2024. Towards robust multi-modal sentiment analysis with incomplete data. Advances in Neural Information Processing Systems 37 (2024), 55943–55974. **中文题名：** 面向不完整数据的稳健多模态情感分析。

[60] Yunhua Zhang, Hazel Doughty, and Cees Snoek. 2024. Learning unseen modality interaction. Advances in Neural Information Processing Systems 36 (2024). **中文题名：** 学习未见过的模态交互。

[61] Jinming Zhao, Ruichen Li, and Qin Jin. 2021. Missing modality imagination network for emotion recognition with uncertain missing modalities. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2608–2618. **中文题名：** 面向不确定模态缺失情感识别的缺失模态想象网络。

[62] Zengqun Zhao, Qingshan Liu, and Shanmin Wang. 2021. Learning deep global multi-scale and local attention features for facial expression recognition in the wild. IEEE Transactions on Image Processing 30 (2021), 6544–6556. **中文题名：** 学习深度全局多尺度与局部注意力特征，以实现自然场景中的面部表情识别。

[63] Aoqiang Zhu, Min Hu, Xiaohua Wang, Jiaoyun Yang, Yiming Tang, and Ning An. 2025. Proxy-Driven Robust Multimodal Sentiment Analysis with Incomplete Data. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 22123–22138. **中文题名：** 代理驱动的面向不完整数据的稳健多模态情感分析。