含缺失数据的深度学习

Deep learning with missing data

Tianyi Ma[1]、Tengyao Wang[2]、Richard J. Samworth[1]
[1] 剑桥大学统计实验室
[2] 伦敦政治经济学院统计系

非官方中文全文译文 · arXiv:2504.15388v3 · 原文版本日期：2026 年 7 月 1 日

本译文根据作者原文制作，保留论文正文、附录 A–I、证明、参考文献与数学记号。原文和作者署名见 arXiv 版本页面；原文 PDF。原文依据 Creative Commons Attribution 4.0 International（CC BY 4.0） 许可发布；本中文翻译及新增说明也依该许可提供。译制：OpenAI 助手，2026 年 10 月 26 日。本译文未经作者审定，不代表作者背书。

改动及图像说明： 英文叙述、图注和文献题名译为中文，重新排版；公式保留原记号，复杂陈列公式采用原文高清裁切以避免转录误差；原图中的英文标签保留，并在中文图注中解释。保留原文图 1–5、7–13 共 12 幅。**图 6 的 MNIST 样例图像因未独立核实数据集图像的许可而不收入本译文**，其完整图注及相关论述照译，并提供原文定位链接；未制作或插入替代图像。原始文件未作修改。

摘要

针对协变量存在缺失的多元非参数回归问题，我们提出模式嵌入神经网络（Pattern Embedded Neural Networks，PENN）；它可以与任何现有插补技术结合使用。除在插补后数据上训练一个神经网络外，PENN 还将观测指示向量送入第二个神经网络，以得到紧凑表示。随后，第三个神经网络将两者的输出结合，生成最终预测。我们的主要理论结果采用如下假设：观测模式可以划分为若干单元，在每个单元上，贝叶斯回归函数具有相似行为，并属于一个复合 Hölder 函数类。该结果给出对任意缺失机制都成立的有限样本超额风险界；结合一个相应的极小极大下界，它表明，在典型情形下，PENN 估计量达到了如同事先知道划分单元时的极小极大收敛速率，仅相差样本量的一个多对数因子。在模拟、半合成及真实数据上的数值实验确认，PENN 估计量相对于不使用模式嵌入的标准神经网络始终有所改进，而且改进往往十分显著。复现实验的代码及方法使用教程均已公开。

关键词： 深度学习；缺失数据；非参数回归。

1 引言

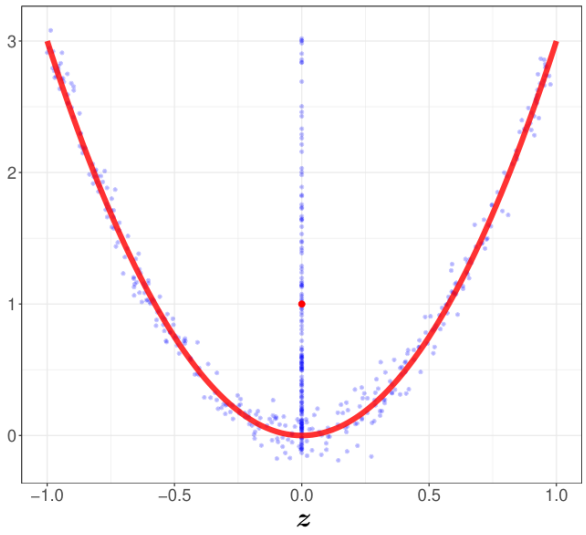
过去十余年间，深度神经网络在多个应用领域的学习任务中取得了惊人的实证成功，包括图像分类（Krizhevsky, Sutskever and Hinton, 2012；He et al., 2016）、蛋白质折叠（Jumper et al., 2021）、自然语言处理（Vaswani et al., 2017；Devlin et al., 2019）以及许多其他领域。尽管其复杂性最初使人倾向于把它们视为黑箱，近期理论确实为其出色实践表现的来源提供了认识（Jacot, Gabriel and Hongler, 2018；Schmidt-Hieber, 2020；Kohler and Langer, 2021；Mei and Montanari, 2022；Suh and Cheng, 2024）。

上述研究都考虑所涉大规模数据集被完整观测的情形。然而，如 Zhu, Wang and Samworth（2022）所论述，缺失数据在高维学习问题中的作用日益显著；现在已有新方法处理若干涉及缺失数据的当代统计难题，包括稀疏线性回归（Loh and Wainwright, 2012；Chandrasekher, Alaoui and Montanari, 2020）、主成分分析（Elsener and van de Geer, 2019；Zhu, Wang and Samworth, 2022）、分类（Cai and Zhang, 2019；Sell, Berrett and Cannings, 2024）以及变点估计（Follain, Wang and Samworth, 2022）。其中大部分论文研究最简单、理想化的数据与缺失指示变量相互独立的情形，即完全随机缺失（Missing Completely At Random，MCAR）。事实上，现已认识到，对更一般的、具有依赖性的缺失机制，如果不作额外假设，甚至一致的均值估计都可能无法实现（Ma et al., 2026+）。

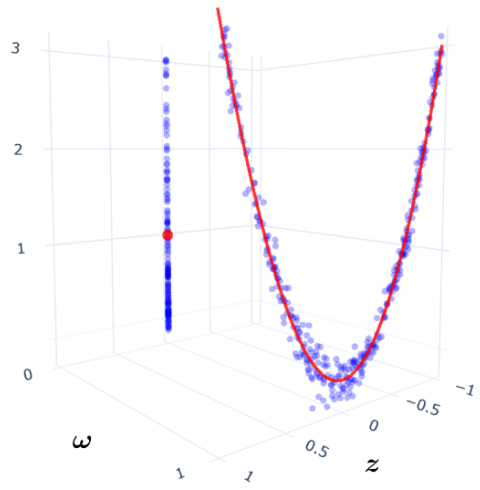
本文旨在研究协变量中含缺失值的监督深度学习问题；我们不依赖 MCAR 假设，也不对缺失机制作任何其他限制。受深度学习众多应用的启发，我们关注预测（即对一个新协变量向量处的响应作出预报），而非估计（即学习模型的底层参数）。我们在方法上的主要贡献，是将（观测）模式嵌入的思想引入神经网络框架。也就是说，除了在原始协变量上训练一个神经网络（缺失值可用任意现有技术插补）外，我们还将观测指示向量——称为**揭示向量**（revelation vectors）——送入另一个神经网络，获得概括其中信息的紧凑表示。随后训练第三个神经网络，把前两个网络结合起来生成最终预测。

图 1 展示了本方法的优势，其中样本量 $n = 1,000$、维度 $d = 1$ 的训练数据由下文第 2.1 节例 1 的模型生成。原始协变量 $(\boldsymbol{X}_i)_{i=1}^n$ 含有缺失，我们根据相应揭示向量 $(\boldsymbol{\Omega}_i)_{i=1}^n$ 进行零（均值）插补，得到插补后协变量 $(\boldsymbol{Z}_i)_{i=1}^n$。结合响应 $(Y_i)_{i=1}^n$，即得到训练数据 $(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i, Y_i)_{i=1}^n$，其中对 $i = 1, \ldots, n$，$Y_i \mid \boldsymbol{X}_i \sim N\left(3\boldsymbol{X}_i^2, 0.1^2\right)$ 且相互独立。插补之后，标准做法是在 $(\boldsymbol{Z}_i, Y_i)_{i=1}^n$ 上训练模型（见图 1(a)）；它在一个大小为 500 的独立测试集上的拟合值见图 1(c)。相比之下，我们的方法在图 1(b) 所示的增广数据 $(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i, Y_i)_{i=1}^n$ 上训练神经网络，得到明显更准确的测试预测，如图 1(d) 所示。这里的关键是：图 1(c) 中未纳入揭示向量 $(\boldsymbol{\Omega}_i)_{i=1}^n$，使原点附近的输出受到破坏；原点恰是 $\boldsymbol{z} \mapsto \mathbb{E}(Y_1 \mid \boldsymbol{Z}_1 = \boldsymbol{z})$ 的一个不连续点。而图 1(d) 纳入额外协变量后纠正了这一问题。

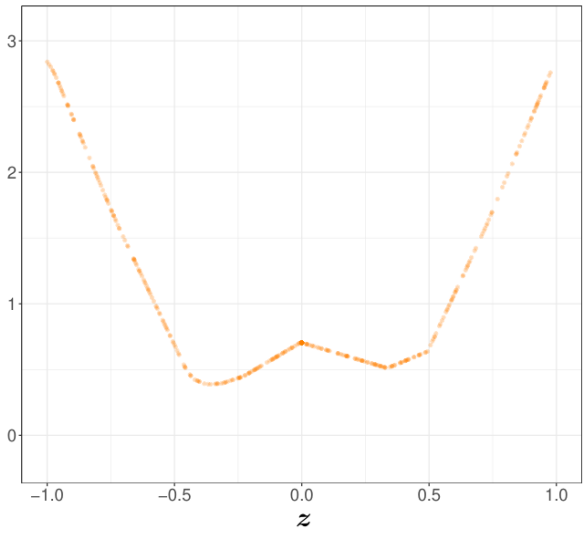
另一方面，如第 2.3 节图 2 所示，当 d 较大时，简单地把揭示向量作为额外协变量加入，甚至可能比完全省略 $(\boldsymbol{\Omega}_i)_{i=1}^n$ 的效果更差。此外，第 2.3 节还指出，揭示向量的预测价值未必与其欧氏几何结构相吻合。因此，关键挑战是恰当地压缩揭示向量中的信息，同时尽可能保留其预测内容。



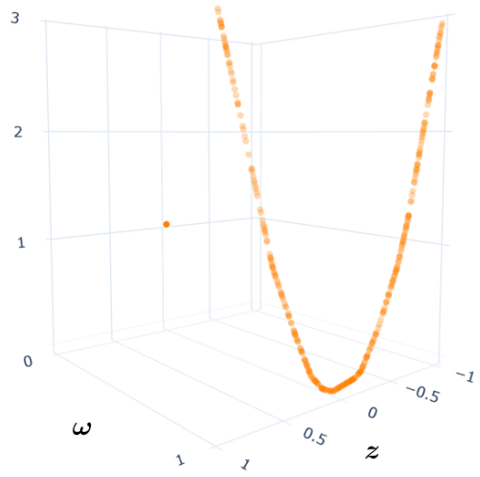
(a) Test data (blue) and Bayes regression function $z \mapsto \mathbb{E}(Y_1 \mid \boldsymbol{Z}_1 = z)$ (red).



(b) Test data (blue) and Bayes regression function $(z, \omega) \mapsto \mathbb{E}(Y_1 \mid \boldsymbol{Z}_1 = z, \boldsymbol{\Omega}_1 = \omega)$ (red).



(c) Output of the neural network trained without the revelation vectors.



(d) Output of the neural network trained with the revelation vectors.

图 1: 例 1 的示意，以及未使用和使用揭示向量训练的神经网络输出。(a) 测试数据（蓝色）及贝叶斯回归函数 $z \mapsto \mathbb{E}\left(Y_1 \mid \boldsymbol{Z}_1 = z\right)$（红色）；(b) 测试数据（蓝色）及贝叶斯回归函数 $(z, \omega) \mapsto \mathbb{E}\left(Y_1 \mid \boldsymbol{Z}_1 = z, \boldsymbol{\Omega}_1 = \omega\right)$（红色）；(c) 不含揭示向量的神经网络输出；(d) 含揭示向量的神经网络输出。

在更正式地描述问题设定并介绍 ReLU 神经网络背景之后，第 2 节提出模式嵌入神经网络（PENN）。它可以用标准经验风险最小化算法拟合，例如 Python 的 PyTorch 中实现的 Adam 或 AdamW（Kingma and Ba, 2015；Loshchilov and Hutter, 2019），从而得到贝叶斯回归函数 $f^\star$ 的估计量 $\widehat{f}$，其中 $f^\star(z, \omega) := \mathbb{E}\left(Y_1 \mid \boldsymbol{Z}_1 = z, \boldsymbol{\Omega}_1 = \omega\right)$。

第 3 节研究程序的理论性质。首先给出一般的预言机不等式（命题 1）：在响应满足次高斯条件时，估计量的超额风险由优化误差、逼近误差和估计误差之和控制，后两项反映神经网络类复杂度的偏差—方差权衡。主要结果（第 3.2 节定理 2）将这一一般设定具体化，给出更加显式的超额风险界。特别地，由于可能有 2^d 种观测模式，我们对贝叶斯回归函数 $f^\star$ 引入一个新条件，以刻画这样的观念：全部可能观测模式可划分为若干集合，而在每个集合上，$f^\star$ 作为协变量的函数具有相似行为。进一步要求，在每个划分单元上，$f^\star$ 属于一个复合 Hölder 光滑性类。由此可知，除样本量的多对数因子外，逼近误差与估计误差之和由各划分单元估计速率的加权平均以及一个反映划分复杂度、通常可以忽略的额外项控制。定理 3 的极小极大下界与这一结果相配套，确认定理 2 中不同单元估计速率的加权平均是最优的。所有证明均置于附录。

第 4 节通过数值研究考察 PENN 估计量的表现。模拟设定同时考虑 MCAR 和非随机缺失（Missing Not At Random，MNAR），以及三种常用插补技术：逐列均值插补、MissForest 插补（Stekhoven and Bühlmann, 2012）和链式方程多重插补（Multiple Imputation by Chained Equations, MICE；van Buuren and Groothuis-Oudshoorn, 2011）。结果呈现出一致的模式：与相应的不含模式嵌入的神经网络估计量相比，PENN 能够改善性能，有时改善非常显著。我们还与直接处理缺失的其他机器学习方法——XGBoost（Chen and Guestrin, 2016）和随机森林（Breiman, 2001）——比较，也观察到类似改善。除纯模拟数据外，我们还以相同插补方法研究两个半合成数据集和一个真实数据集。前两者的完整真实数据分别是手写数字（额外纳入视觉 Transformer，Dosovitskiy et al., 2021）与计算机断层扫描（CT）切片相对位置，因此可用已知机制人为加入 MCAR 或 MNAR 缺失。后者的信用评分真实数据则原本就存在缺失。将数据划分为训练、验证和测试集后，模式嵌入方法仍表现出一致改善。本节全部实验的复现 Python 代码与使用教程见 作者代码仓库。

1.1 相关文献

理解和解释深度学习令人印象深刻的实证表现，是当前统计学与机器学习的一项重要研究主题。一条研究路线在假定经验风险能够得到足够充分最小化的前提下，从逼近论与经验过程理论的角度给出显式收敛速率。例如，神经网络关于样本量的极小极大最优性已在非参数回归（Bauer and Kohler, 2019；Imaizumi and Fukumizu, 2019；Schmidt-Hieber, 2020；Kohler and Langer, 2021；Jiao et al., 2023；Bhattacharya, Fan and Mukherjee, 2024；Fan and Gu, 2024）、分类（Bos and Schmidt-Hieber, 2022；Zhang, Shi and Zhou, 2024）、部分线性 Cox 模型（Zhong, Mueller and Wang, 2022）和密度估计（Bos and Schmidt-Hieber, 2024）中得到研究。特别地，现已知道，在复合 Hölder 假设下，神经网络能够利用非参数回归中的低维结构（Schmidt-Hieber, 2020；Kohler and Langer, 2021）。上述研究中的多数界，其前置系数对协变量维数或回归函数所依赖的变量数呈指数依赖；Jiao et al.（2023）利用 Lu et al.（2021）的逼近方案，给出仅以多项式方式依赖维数的上界，而 Imaizumi and Fukumizu（2019）允许回归函数存在不连续性。其他方向则关注理解神经网络训练动力学，例如神经切线核（Jacot, Gabriel and Hongler, 2018；Du et al., 2019；Arora et al., 2019）、张量程序（Yang and Hu, 2021；Littwin and Yang, 2023）和均值场极限（Chizat and Bach, 2018；Mei, Montanari and Nguyen, 2018；Mei and Montanari, 2022；Suzuki, Wu and Nitanda, 2023）。最近，Transformer 的上下文学习能力还被用于构建表格数据基础模型（Hollmann et al., 2025）；上下文非参数回归的理论结果可见 Kim, Nakamaki and Suzuki（2024）、Ma, Wang and Samworth（2025）、Ching et al.（2026）等。

拟合神经网络时，将离散或结构化数据嵌入潜在空间是一种有吸引力的方法。特别地，类别嵌入把词或用户标识符等离散对象映射为与预测任务共同学习的连续表示（Mikolov et al., 2013；Guo and Berkhahn, 2016）。与之相关，在无监督任务中，自编码器借助中间层较窄的“瓶颈结构”学习紧凑潜在表示，以捕捉高维数据的本质结构（Hinton and Salakhutdinov, 2006；Vincent et al., 2008）。从这一角度看，我们的方法为观测模式这一最多具有 2^d 个水平的类别变量学习低维嵌入；模式间的相似性从数据推断，而非预先指定。不同于经典自编码器，在我们的监督学习任务中，这个嵌入只为预测而优化，并不要求重建缺失模式本身。

缺失数据数十年来一直是统计学的活跃课题，如今重新受到重视，主要有两方面原因。首先，如前所述，大型数据集中的缺失值无处不在；与其他形式的数据损坏不同，许多统计学习算法只有在缺失得到恰当处理后才能应用。其次，与此相关，现代数据的复杂性要求新的缺失模型和带有适当性能保证的新推断方法（Berrett and Samworth, 2023；Ma et al., 2026+）。人们早已认识到，MCAR 假设对许多实际应用并不现实。另一方面，现代数据生成机制往往只有通过高维或无限维参数空间才能得到充分描述。在这种情形下，随机缺失（Missing At Random，MAR）等模型以采用极大似然拟合的低维参数模型正确为前提，可能并不合适。

对于协变量缺失的回归问题，一种广泛使用的通用策略是“先插补再回归”：先插补缺失数据，再把插补后数据视为完整数据来训练回归算法。MCAR 或 MAR 假设下已有许多插补算法，例如 MissForest（Stekhoven and Bühlmann, 2012）、MICE（van Buuren and Groothuis-Oudshoorn, 2011），以及基于深度学习和生成模型的方法（Li, Jiang and Marlin, 2019；Mattei and Frellsen, 2019；Nazabal et al., 2020；Zhang et al., 2025）。如果存在普适一致估计量，那么在某些仍允许 MNAR 的条件下，随着样本量趋于无穷，先插补再回归方法对新协变量向量的超额风险会渐近趋于零（Le Morvan et al., 2021；Josse et al., 2024）。但是，在这种情形下，贝叶斯回归函数即给定插补后协变量向量的响应条件期望，可能不连续且难以学习（Le Morvan et al., 2021）。

Efromovich（2011）研究了 MAR 缺失下的一元非参数回归正交级数方法。含缺失数据回归的其他策略包括：在相关坐标中用一个表示缺失值的特殊点增广协变量空间；这一策略可用于回归树，以及 XGBoost 和随机森林等其他非正交等变方法。Twala, Jones and Hand（2008）提出将观测模式作为协变量纳入回归树；Śmieja et al.（2018）用估计期望值替换神经网络第一隐藏层的神经元以处理缺失；Le Morvan et al.（2021）则使用神经网络同时训练插补算法与回归算法。对图像数据，MisGAN（Li, Jiang and Marlin, 2019）插补缺失像素，而视觉 Transformer（ViT）借助基于图块的表示与注意力机制可自然处理遮挡（Dosovitskiy et al., 2021；Bao et al., 2022；He et al., 2022）。不过，据我们所知，本文是首个为含缺失数据的多元非参数回归提供极小极大最优性保证的研究。

1.2 记号

最后介绍贯穿全文的记号。对 $n \in \mathbb{N}$，定义 $[n] := \{1, \ldots, n\}$；对 $a, b \in \mathbb{R}$，令 $a \wedge b := \min\{a, b\}$、$a \vee b := \max\{a, b\}$。对 $\boldsymbol{a}, \boldsymbol{b} \in \mathbb{R}^d$，$\boldsymbol{a} \odot \boldsymbol{b} \in \mathbb{R}^d$ 表示 Hadamard 积，即逐坐标乘积。对 $q \in [1, \infty)$ 与 $\boldsymbol{v} = (v_1, \ldots, v_d)^\top \in \mathbb{R}^d$，记 $\| \boldsymbol{v} \|_q := \left(\sum_{j=1}^d |v_j|^q \right)^{1/q}$，并记 $\| \boldsymbol{v} \|_0 := \sum_{j=1}^d \mathbf{1}_{\{v_j \neq 0\}}$、$\| \boldsymbol{v} \|_\infty := \max_{j \in [d]} |v_j|$。全一向量为 $\mathbf{1}_d := (1, \ldots, 1)^\top \in \mathbb{R}^d$。若 $(\mathcal{X}, \mathcal{A}, \mu)$ 是测度空间且 $f : \mathcal{X} \to \mathbb{R}$ 可测，则定义 $\| f \|_{L^q(\mu)} := \left(\int_{\mathcal{X}} |f|^q \, d\mu \right)^{1/q}$，并记

$\| f \|_{\infty}:=\sup_{x\in\mathcal{X}}|f(\boldsymbol{x})|$。对函数类 $\mathcal{F}$ 与 $\mathcal{G}$，定义 $\mathcal{F}\circ\mathcal{G}:=\{f\circ g: f\in\mathcal{F},\, g\in\mathcal{G}\}$；对 $B\geq 0$，定义截断算子 $T_B:\mathbb{R}\to[-B,\, B]$ 为 $T_B(y):=(-B)\vee y\wedge B$。若 $\mathcal{S}_1,\, \ldots,\, \mathcal{S}_K$ 是非空集合 $\mathcal{S}$ 的两两不交非空子集，且并集等于 $\mathcal{S}$，则称 $\{\mathcal{S}_1,\, \ldots,\, \mathcal{S}_K\}$ 为 $\mathcal{S}$ 的一个划分。实随机变量 X 的次高斯范数为 $\| X \|_{\psi_2}:=\inf\{t>0:\exp\left(X^2/t^2\right)\leq 2\}$；次指数范数为 $\| X \|_{\psi_1}:=\inf\{t>0:\exp\left(|X|/t\right)\leq 2\}$。【译注：原文此处两个范数定义的指数前均未排印期望符号，本译文按原样保留。】对正数序列 (a_n)、(b_n)，若存在通用常数 $C>0$，使所有 $n\in\mathbb{N}$ 都满足 $a_n\leq Cb_n$，则记 $a_n\lesssim b_n$；若还满足 $b_n\lesssim a_n$，则记 $a_n\asymp b_n$。

2 问题设定与方法

2.1 问题设定

设 $\left(\boldsymbol{X}_i,\, \boldsymbol{\Omega}_i,\, Y_i\right)_{i=0}^{n}$ 是取值于 $\mathbb{R}^d\times\{0,\, 1\}^d\times\mathbb{R}$ 的独立同分布随机向量。每个三元组依次表示完整协变量向量、揭示向量及响应，令 $\mathcal{S}:=\{\boldsymbol{\omega}:\mathbb{P}\left(\boldsymbol{\Omega}_0=\boldsymbol{\omega}\right)>0\}$ 为可能的观测模式集合。在缺失数据情境中，我们通常无法观测 $\left(\boldsymbol{X}_i\right)_{i=0}^{n}$，而只能获得取值于扩展空间 $\mathbb{R}_{\star}^{d}:=\left(\mathbb{R}\cup\{\star\}\right)^d$ 的部分观测协变量向量 $\left(\widetilde{\boldsymbol{X}}_i\right)_{i=0}^{n}$，其中 $\star$ 表示缺失值。[1] 因此，$\widetilde{\boldsymbol{X}_i}$ 与 $\boldsymbol{X}_i$ 一致，唯有 $\boldsymbol{\Omega}_i$ 为零的分量会被替换为 $\star$。强调一点：我们不假定协变量 $\boldsymbol{X}_i$ 与揭示向量 $\boldsymbol{\Omega}_i$ 相互独立，而且允许 $\widetilde{\boldsymbol{X}_i}$ 的分量为 MNAR。令 $\mathrm{Imp}:\mathbb{R}_{\star}^{d}\to\mathbb{R}^d$ 为可能随机化的插补算法，其中构造 Imp 时的任何随机性均与 $\left(\boldsymbol{X}_i,\, \boldsymbol{\Omega}_i,\, Y_i\right)_{i=0}^{n}$ 独立；对 $i\in\{0,\, 1,\, \ldots,\, n\}$ 令 $\boldsymbol{Z}_i:=\mathrm{Imp}\left(\widetilde{\boldsymbol{X}_i}\right)$。例如，Imp 可以是零（或均值）插补，也可以是在独立数据集上训练的其他基于回归的插补算法。[2] 我们观测训练数据 $\left(\boldsymbol{Z}_i,\, \boldsymbol{\Omega}_i,\, Y_i\right)_{i=1}^{n}$，目标是给定测试点 $\left(\boldsymbol{Z}_0,\, \boldsymbol{\Omega}_0\right)$ 预测 Y_0。

用 $\mathcal{G}$ 表示所有可能预测函数构成的集合，即从 $\mathbb{R}^d\times\mathcal{S}$ 到 $\mathbb{R}$ 的 Borel 可测函数集合。$\widetilde{f}\in\mathcal{G}$ 的泛化误差定义为

$$
\begin{aligned}
R(\widetilde{f}) &:= \mathbb{E}_{(\boldsymbol{Z}_0,\boldsymbol{\Omega}_0,Y_0)}\left\{\left(\widetilde{f}(\boldsymbol{Z}_0,\boldsymbol{\Omega}_0)-Y_0\right)^2\right\} \\
&= \int_{\mathbb{R}^d\times\mathcal{S}\times\mathbb{R}}\left(\widetilde{f}(\boldsymbol{z},\boldsymbol{\omega})-y\right)^2\,\mathrm{d}\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0,Y_0}(\boldsymbol{z},\boldsymbol{\omega},y),
\end{aligned}
$$

其中 $\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0,Y_0}$ 表示 $\left(\boldsymbol{Z}_0,\, \boldsymbol{\Omega}_0,\, Y_0\right)$ 的分布。注意，若 $\widetilde{f}$ 是依赖于 $\left(\boldsymbol{Z}_i,\, \boldsymbol{\Omega}_i,\, Y_i\right)_{i=1}^{n}$ 的估计量，则 $R\left(\widetilde{f}\right)$ 是随机的，因为期望只对 $\left(\boldsymbol{Z}_0,\, \boldsymbol{\Omega}_0,\, Y_0\right)$ 的分布取。贝叶斯回归函数 $f^{\star}:\mathbb{R}^d\times\mathcal{S}\to\mathbb{R}$ 定义为

$$
f^{\star}(\boldsymbol{z},\,\boldsymbol{\omega}):=\mathbb{E}\left(Y_0\mid\boldsymbol{Z}_0=\boldsymbol{z},\,\boldsymbol{\Omega}_0=\boldsymbol{\omega}\right).
$$

该函数满足 $R\left(f^{\star}\right)=\inf_{f\in\mathcal{G}}R(f)$，因此可能依赖所采用的插补算法，尽管 $R\left(f^{\star}\right)$ 并不依赖它。对估计量 $\widetilde{f}$，我们用超额风险 $\mathbb{E}\{R\left(\widetilde{f}\right)\}-R\left(f^{\star}\right)$ 衡量其表现。最后，$\widetilde{f}$ 的经验风险定义为

$$\widehat{R}_n(\widetilde{f}) := \frac{1}{n}\sum_{i=1}^{n}\big(\widetilde{f}(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i) - Y_i\big)^2.$$

例 1。设 $\boldsymbol{X}_0 = (X_{0,1}, \ldots, X_{0,d})^\top \sim \mathrm{Unif}[-1, 1]^d$，$Y_0 = 3X_{0,1}^2 + \varepsilon_0$，其中 $\varepsilon_0 \sim N(0, 0.01)$ 且 $\varepsilon_0 \perp\!\!\!\perp \boldsymbol{X}_0$。假定 $\boldsymbol{\Omega}_0 = (\Omega_{0,1}, \ldots, \Omega_{0,d})^\top \perp\!\!\!\perp (\boldsymbol{X}_0, \varepsilon_0)$，并且 $\Omega_{0,1}, \ldots, \Omega_{0,d} \overset{\mathrm{iid}}{\sim} \mathrm{Ber}(0.7)$，即每个坐标以概率 0.3 独立缺失的 MCAR 情形。令 $\widetilde{\boldsymbol{X}_0}$ 为与 $\boldsymbol{X}_0$ 对应的部分观测协变量向量，令 $\mathrm{Imp}: \mathbb{R}_\star^d \to \mathbb{R}^d$ 为将 $\star$ 替换为零的零插补算法（在本例中等同于均值插补），故 $\boldsymbol{Z}_0 := \mathrm{Imp}(\widetilde{\boldsymbol{X}_0}) = \boldsymbol{X}_0 \odot \boldsymbol{\Omega}_0$。对 $\boldsymbol{z} = (z_1, \ldots, z_d)^\top \in [-1, 1]^d$ 与 $\boldsymbol{\omega} = (\omega_1, \ldots, \omega_d)^\top \in \{0, 1\}^d$，贝叶斯回归函数可写为

$$f^\star(\boldsymbol{z}, \boldsymbol{\omega}) = \begin{cases} 3z_1^2 & \text{if } \omega_1 = 1 \\ 1 & \text{if } \omega_1 = 0. \end{cases}$$

其中两个分支分别对应 $\omega_1 = 1$ 与 $\omega_1 = 0$。

2.2 ReLU 神经网络

本节正式定义使用 ReLU 激活函数 σ 的神经网络类，其中对 $a \in \mathbb{R}$，$\sigma(a) := a \vee 0$。对向量 $\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in \mathbb{R}^d$，定义

$$\boldsymbol{\sigma}(\boldsymbol{x}) := (\sigma(x_1), \ldots, \sigma(x_d))^\top \in [0, \infty)^d,$$

不过，在不同使用情形中允许 d 改变，不再专门说明。给定 $L \in \mathbb{N}$ 与 $\boldsymbol{p} = (p_0, p_1, \ldots, p_{L+1}) \in \mathbb{N}^{L+2}$，具有结构 $(L, \boldsymbol{p})$ 的神经网络集合定义为

$$\mathcal{F}(L, \boldsymbol{p}) := \Big\{ \boldsymbol{f}: \mathbb{R}^{p_0} \to \mathbb{R}^{p_{L+1}} : \boldsymbol{f}(\cdot) = \boldsymbol{A}_{L+1} \circ \boldsymbol{\sigma} \circ \boldsymbol{A}_L \circ \boldsymbol{\sigma} \circ \cdots \circ \boldsymbol{A}_2 \circ \boldsymbol{\sigma} \circ \boldsymbol{A}_1(\cdot), \text{ where } \boldsymbol{A}_\ell(\boldsymbol{v}) = \boldsymbol{W}_\ell \boldsymbol{v} + \boldsymbol{b}_\ell, \boldsymbol{W}_\ell \in \mathbb{R}^{p_\ell \times p_{\ell-1}} \text{ and } \boldsymbol{b}_\ell \in \mathbb{R}^{p_\ell} \ \forall \ell \in [L+1] \Big\}. \quad (1)$$

式中，L 为隐藏层数（或网络深度），$p_1, \ldots, p_L$ 为隐藏层宽度，p_0 为输入维数，p_{L+1} 为输出维数，$\boldsymbol{W}_1, \ldots, \boldsymbol{W}_{L+1}$ 为权重矩阵，$\boldsymbol{b}_1, \ldots, \boldsymbol{b}_{L+1}$ 为偏置向量。对具有权重矩阵 $(\boldsymbol{W}_\ell)_{\ell=1}^{L+1}$ 和偏置向量 $(\boldsymbol{b}_\ell)_{\ell=1}^{L+1}$ 的 $\boldsymbol{f} \in \mathcal{F}(L, \boldsymbol{p})$，定义 $\boldsymbol{\Theta}(\boldsymbol{f})$ 为由神经网络 $\boldsymbol{f}$ 的全部参数组成的向量，即 $\boldsymbol{\Theta}(\boldsymbol{f}) := (\mathrm{vec}(\boldsymbol{W}_1)^\top, \boldsymbol{b}_1^\top, \ldots, \mathrm{vec}(\boldsymbol{W}_{L+1})^\top, \boldsymbol{b}_{L+1}^\top)^\top \in \mathbb{R}^V$，其中 $V := \sum_{\ell=1}^{L+1} p_\ell(p_{\ell-1} + 1)$ 为参数总数。给定 $s \in \mathbb{N}$，定义

$$\mathcal{F}(L, \boldsymbol{p}, s) := \{\boldsymbol{f} \in \mathcal{F}(L, \boldsymbol{p}) : \| \boldsymbol{\Theta}(\boldsymbol{f}) \|_0 \le s\}$$

为结构 $(L, \boldsymbol{p})$、稀疏度 s 的神经网络集合。注意，对所有 $s \ge V$，有 $\mathcal{F}(L, \boldsymbol{p}, s) = \mathcal{F}(L, \boldsymbol{p})$。

2.3 模式嵌入神经网络估计量

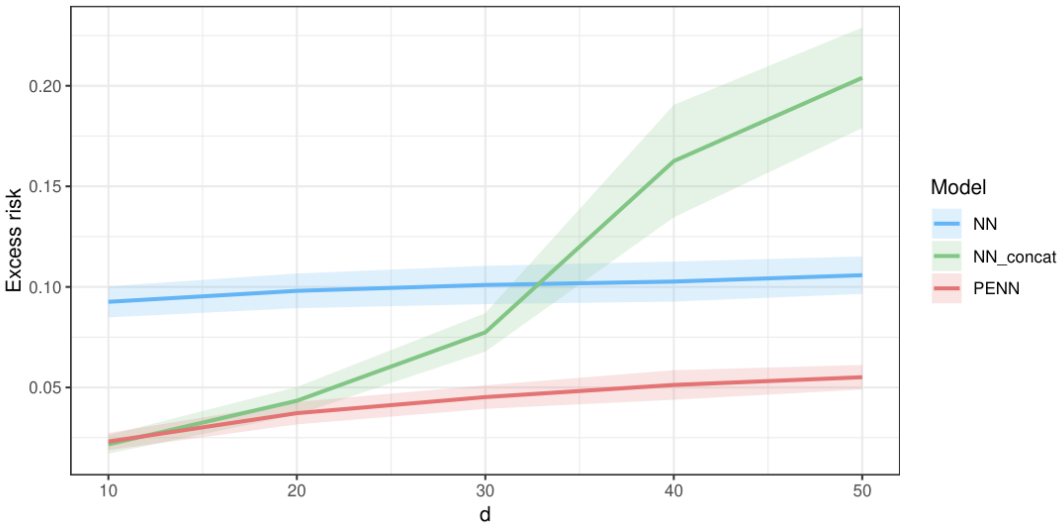
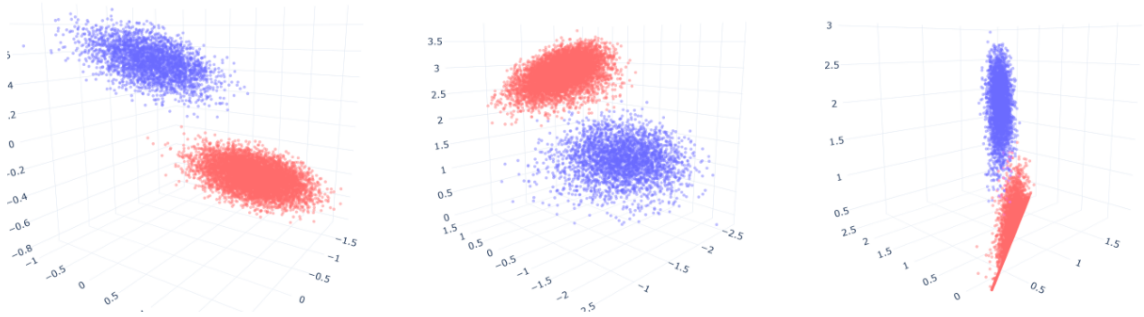


图 2： 例 1 在 $d \in \{10, 20, \ldots, 50\}$、$n = 1000$ 时的超额风险。NN（蓝色）是将 Y_i 对 $\boldsymbol{Z}_i$ 回归的神经网络；NN_concat（绿色）是直接将 Y_i 对 $(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i)$ 回归的神经网络；PENN（红色）是我们的模式嵌入神经网络（$m = 3$）。阴影区域为根据 100 次重复实验得到的真实超额风险的 90% 置信区间。横轴为维数 d，纵轴为超额风险，Model 表示模型。

我们希望使用神经网络将 $(Y_i)_{i=1}^n$ 对 $(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i)_{i=1}^n$ 回归以估计 $f^\star$，同时在相似观测模式之间共享统计信息。若简单地将拼接向量 $(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i)_{i=1}^n$ 作为协变量训练神经网络，在维数 d 较大时会出现显著过拟合（见图 2）；其超额风险甚至可能比忽略揭示向量、仅将 $(Y_i)_{i=1}^n$ 对 $(\boldsymbol{Z}_i)_{i=1}^n$ 回归还大。主要问题在于，观测模式数 $|\mathcal{S}|$ 可随 d 指数增长，以至于每个数据点都可能具有独特的观测模式，而朴素训练无法在相似观测模式间共享信息。此外，尽管揭示向量 $\boldsymbol{\Omega}_i \in \{0, 1\}^d$ 可能承载很有用的预测信息，超立方体 $\{0, 1\}^d$ 的原始欧氏几何结构却可能与问题的预测结构很不一致。例如，在例 1 中，两个除第一个坐标外其余坐标都不同的揭示向量产生完全相同的回归函数，尽管两者的欧氏距离 $\sqrt{d-1}$ 已接近最大值。因此，直接将揭示向量作为协变量，迫使模型适应一个几乎相当于噪声的额外几何结构。

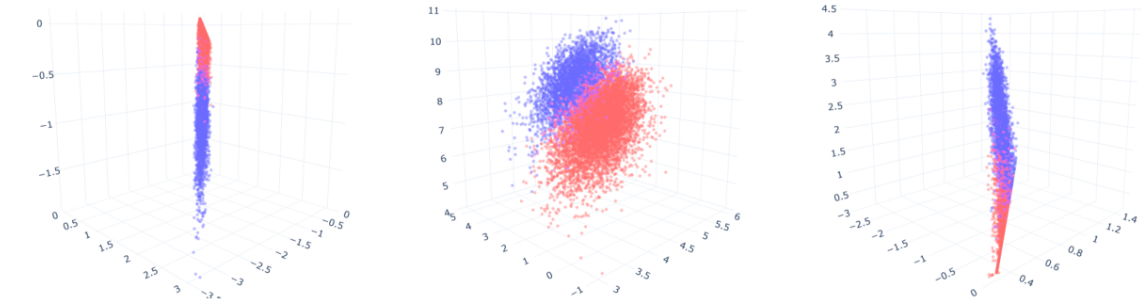
为解决上述问题，我们希望学习一个把揭示向量映射到低维欧氏空间的嵌入，使几何上的接近对应于预测行为的相似（见图 3）。这种嵌入使模型能够在相关缺失模式之间共享统计信息，从而改善对稀有模式的泛化。图 3 展示例 1 中所学习揭示向量嵌入的预测价值，特别是：嵌入中更好的分离对应更低的超额风险。自然地，维数较高时，各簇更易重叠，反映出问题难度增加；尽管如此，即使 $d = 100$，学习到的三维嵌入仍提供相当多的预测信息。该嵌入为一个神经网络，将 d 维揭示向量映射到 $\mathbb{R}^m$，其中嵌入维数 $m \le d$（图中 $m = 3$）。另一方面，插补后协变量 $\boldsymbol{Z}_1, \ldots, \boldsymbol{Z}_n$ 也可受益于非线性特征映射；随后将两组变换后的变量输入另一个灵活的回归模型，以捕捉适当的交互作用。我们同样把这些非线性函数取为神经网络，因为它们便于建模和拟合。



(a) $d = 40$, excess risk 0.0289.

(b) $d = 40$, excess risk 0.0523.

(c) $d = 40$, excess risk 0.0680.



(d) $d = 100$, excess risk 0.0421.

(e) $d = 100$, excess risk 0.0866.

(f) $d = 100$, excess risk 0.1074.

图 3： 在例 1 的 $d \in \{40, 100\}$、$n = 1000$ 设定下，从六个训练后的 PENN 估计量提取的观测模式三维嵌入可视化。蓝点、红点分别对应第一个坐标为零、为一的模式。子图标注给出维数及相应 PENN 在测试数据上的超额风险：(a) $d = 40$，0.0289；(b) $d = 40$，0.0523；(c) $d = 40$，0.0680；(d) $d = 100$，0.0421；(e) $d = 100$，0.0866；(f) $d = 100$，0.1074。

因此，我们的模式嵌入神经网络（PENN）具有 $(z, \omega) \mapsto f_3(f_1(z), f_2(\omega))$ 的形式，其中 $r \in \{1, 2, 3\}$ 时 f_r 都是神经网络。这里，f_1 表示插补后协变量的特征映射，f_2 表示揭示向量的模式嵌入，f_3 将学习到的协变量特征和模式嵌入结合起来。

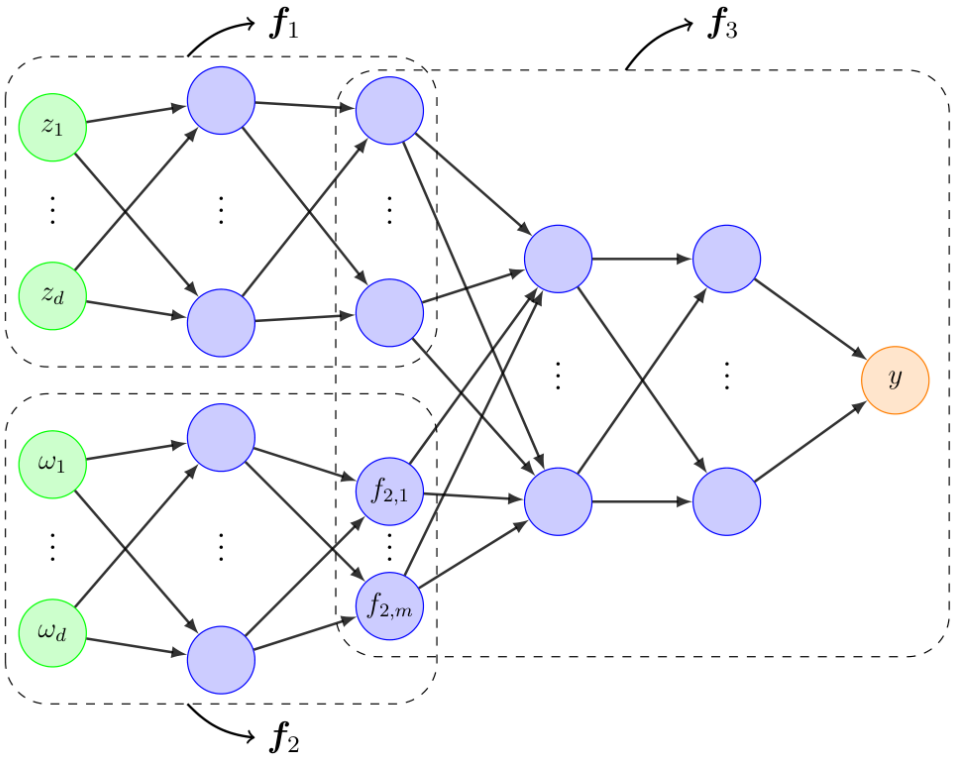


图 4： 模式嵌入神经网络类 $\mathcal{F}_{\mathrm{PENN}}\left((L_r,\ \boldsymbol{p}_r)_{r=1}^{3},\ s\right)$ 的示意。上支路 $\boldsymbol{f}_1$ 处理插补后协变量，下支路 $\boldsymbol{f}_2$ 把揭示向量压缩为 m 维，$\boldsymbol{f}_3$ 输出预测 y。

更精确地，对 $r \in \{1,\ 2,\ 3\}$，令 $L_r \in \mathbb{N}$，假定 $\boldsymbol{p}_r = \left(p_{r,0},\ \ldots,\ p_{r,L_r+1}\right) \in \mathbb{N}^{L_r+2}$ 满足 $p_{3,0} = p_{1,L_1+1} + p_{2,L_2+1}$，并令 $s \in \mathbb{N}$；记 $p_{\mathrm{in}} := p_{1,0} + p_{2,0}$、$p_{\mathrm{out}} := p_{3,L_3+1}$，则模式嵌入神经网络类定义为

$$\mathcal{F}_{\mathrm{PENN}}\left((L_r, \boldsymbol{p}_r)_{r=1}^{3}, s\right) := \Big\{ \boldsymbol{f} : \mathbb{R}^{p_{\mathrm{in}}} \to \mathbb{R}^{p_{\mathrm{out}}} : \boldsymbol{f}(\cdot,\cdot\cdot) = \boldsymbol{f}_3\big(\boldsymbol{f}_1(\cdot), \boldsymbol{f}_2(\cdot\cdot)\big), \\ \text{where } \boldsymbol{f}_r \in \mathcal{F}(L_r, \boldsymbol{p}_r) \text{ for } r \in \{1,2,3\} \text{ and } \sum_{r=1}^{3} \|\boldsymbol{\Theta}(\boldsymbol{f}_r)\|_0 \le s \Big\}. \quad (2)$$

其中 $\boldsymbol{f}_r \in \mathcal{F}\left(L_r,\ \boldsymbol{p}_r\right)$，$r \in \{1,\ 2,\ 3\}$，且三个子网络的非零参数总数不超过 s。图 4 给出 PENN 示意。在第 2.1 节设定中，我们寻找在式 (2) 定义的合适 PENN 类上最小化经验风险 $\widehat{R}_n(f)$ 的估计量 $\widehat{f}$。为此，PENN 被实现为一个统一神经网络（使用 PyTorch 等标准软件；Paszke et al., 2019），并通过梯度方法训练。不过，这一优化问题是非凸的，因此第 3 节理论允许存在残余优化误差。在应用中，取 $p_{1,0} = p_{2,0} = d$、$p_{2,L_2+1} = m$、$p_{3,L_3+1} = 1$。

3 理论结果

本节理论的主要目标，是为第 2.3 节提出的 PENN 方法提供性能保证。总体策略首先将估计量超额风险分解为优化误差、逼近误差、估计误差三项之和，见下文命题 1。该分解相当一般：除不要求数据生成机制与缺失机制的依赖结构满足任何条件外，我们也不对贝叶斯回归函数 $f^{\star}$ 的形式作假设，并考虑

任意神经网络估计量。不过，这种一般性使逼近误差项不够显式，它只反映神经网络类中的元素能够将 $f^\star$ 逼近到什么程度。因此，我们进一步引入能够在不同观测模式间共享信息的自然假设以及光滑性条件，给出逼近误差的显式形式。这样，在主要结果（定理 2）中，可以选择 PENN 估计量的结构来平衡逼近误差和估计误差，得到不对缺失机制形式作任何假设的有限样本超额风险界。相应的极小极大下界（定理 3）说明，除样本量的多对数因子外，PENN 估计量是最优的。

3.1 预言机不等式

沿用上述策略，令 $L \in \mathbb{N}$、$\boldsymbol{p} = (p_0, \ldots, p_{L+1})^\top \in \mathbb{N}^{L+2}$，其中 $p_0 = 2d$、$p_{L+1} = 1$。所谓 $\mathcal{F} \subseteq \mathcal{F}(L, \boldsymbol{p}, s)$ 中的神经网络估计量，是一个联合可测函数 $\widetilde{f} : \mathbb{R}^d \times \mathcal{S} \times \left(\mathbb{R}^d \times \mathcal{S} \times \mathbb{R}\right)^n \to \mathbb{R}$，并且对每个 $\mathcal{D} := (\boldsymbol{z}_i, \boldsymbol{\omega}_i, y_i)_{i=1}^n \in \left(\mathbb{R}^d \times \mathcal{S} \times \mathbb{R}\right)^n$，函数 $\widetilde{f}(\cdot, \cdot; \mathcal{D}) \in \mathcal{F}$。当上下文已明确数据时，通常省略 $\widetilde{f}$ 的最后一个参数。

命题 1。在第 2.1 节设定中，假定对某个 $\xi \geq 1$ 有 $\| Y_0 \|_{\psi_2} \leq \xi$。设 $\widetilde{f}$ 是基于数据 $\mathcal{D} := (\boldsymbol{Z}_i, \boldsymbol{\Omega}_i, Y_i)_{i=1}^n$ 的、属于 $\mathcal{F} \subseteq \mathcal{F}(L, \boldsymbol{p}, s)$ 的神经网络估计量，令 $B_n := \xi\sqrt{2\log n}$。则存在通用常数 $C > 0$，使得对 $n \geq 2$，

$$\mathbb{E}\left\{R(T_{B_n}\widetilde{f})\right\} - R(f^\star) \leq 2\mathbb{E}\left\{\widehat{R}_n(\widetilde{f}) - \inf_{f \in \mathcal{F}} \widehat{R}_n(f)\right\} + 2\inf_{f \in \mathcal{F}} \mathbb{E}\left\{\left(f(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0) - f^\star(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)\right)^2\right\} + \frac{C\xi^4 \log(e\xi) \log^3 n \cdot \left(sL \log(es) + s \log(ed)\right)}{n}.$$

作为对命题 1 中 $\| Y_0 \|_{\psi_2}$ 上界的简单说明，若 $Y_0 = f^0(\boldsymbol{X}_0) + \varepsilon_0$，其中 $\| f^0 \|_\infty \leq \xi_1$、$\| \varepsilon_0 \|_{\psi_2} \leq \xi_2$，则 $\| Y_0 \|_{\psi_2} \leq \xi_1/\sqrt{\log 2} + \xi_2$。命题 1 的超额风险上界是三项之和：第一项为优化误差，第二项为逼近误差，最后一项为反映函数类 $\mathcal{F}$ 复杂度的估计误差。若 $\widetilde{f}$ 是经验风险最小化解，优化误差项消失。重要的是，我们不坚持要求 $f^\star \in \mathcal{F}$，尽管若其成立，就可令逼近误差项为零。除多对数因子外，估计误差项的阶为 sL/n。一般而言，逼近与估计误差之间存在类似偏差—方差的权衡：更复杂的 $\mathcal{F}$ 具有更小逼近误差，但代价是估计误差项中的 s、L 更大。完整观测数据情形下与命题 1 相关的结果包括 Schmidt-Hieber（2020）和 Kohler and Langer（2021）；前者额外假定参数空间与输入空间有界，后者研究完全稠密神经网络。我们证明的关键是命题 4 给出的 $\mathcal{F}(L, \boldsymbol{p}, s)$ 类的 Vapnik–Chervonenkis 维数及覆盖数的新界，它使我们能够消除已有研究对协变量及神经网络参数有界性的限制。

3.2 分段光滑性假设下的极小极大速率

原则上，当 $\boldsymbol{\omega}$ 遍历 $\mathcal{S}$ 时，函数 $\boldsymbol{z} \mapsto f^\star(\boldsymbol{z}, \boldsymbol{\omega})$ 可以任意不同；命题 1 确实没有限制这些函数随 $\boldsymbol{\omega}$ 变化的差异。因此，在最坏情形下，可能要学习 $|\mathcal{S}| = 2^d$ 个不同回归函数！幸运的是，在许多情形中，假设某些不同观测模式对应相似的贝叶斯回归函数是合理的，这将为理论带来很大优势。

假设 1。假定 $\boldsymbol{Z}_0$ 的每个坐标为次指数，Y_0 为次高斯，即存在 $\xi_1, \xi_2 > 0$，使对所有 $j \in [d]$，$\| Z_{0,j} \|_{\psi_1} \le \xi_1$，且 $\| Y_0 \|_{\psi_2} \le \xi_2$。进一步假定存在 $K \le |\mathcal{S}|$、$\mathcal{S}$ 的划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 以及函数 $f^{\mathcal{S}_1}, \ldots, f^{\mathcal{S}_K} : \mathbb{R}^d \to \mathbb{R}$，使得[3]

$$f^\star(\boldsymbol{z}, \boldsymbol{\omega}) = \sum_{k=1}^{K} f^{\mathcal{S}_k}(\boldsymbol{z}) \mathbb{1}_{\{\boldsymbol{\omega} \in \mathcal{S}_k\}} \tag{3}$$

对全部 $\boldsymbol{z} \in \mathbb{R}^d$、$\boldsymbol{\omega} \in \mathcal{S}$ 都成立。对 $k \in [K]$，记 $\pi_k := \mathbb{P}(\boldsymbol{\Omega}_0 \in \mathcal{S}_k)$，$n_k := n\pi_k$ 为第 k 个单元的有效样本量。

$\boldsymbol{Z}_0$ 的尾部条件允许协变量无界，这与非参数回归文献中的许多工作不同。当然，任何贝叶斯回归函数 $f^\star$ 总能以 $K = |\mathcal{S}|$ 满足式 (3)。不过，K 可能远小于 $|\mathcal{S}|$；例如，例 1 中 $|\mathcal{S}| = 2^d$ 而 $K = 2$，因为可取 $\mathcal{S}_1 = \{\boldsymbol{\omega} \in \{0, 1\}^d : \omega_1 = 1\}$、$\mathcal{S}_2 = \{\boldsymbol{\omega} \in \{0, 1\}^d : \omega_1 = 0\}$。这种情况下，可在揭示向量落于同一划分单元的数据之间共享信息。实际上，假设 1 可以弱化为仅要求式 (3) 近似成立，见下文定理 2 后的讨论。

给定 $\mathcal{S}$ 的任意划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$，都存在一个贝叶斯回归函数 $f^\star$，使它以该划分满足假设 1，见引理 15。除了单元数 K，还可通过能够将同一单元的观测模式聚在一起的函数类（例如神经网络）的复杂度，来衡量该划分的复杂度。为此，我们引入 $\mathcal{S}$ 的划分可分离性概念。

定义 1。给定从 $\mathbb{R}^d$ 到 $\mathbb{R}^m$ 的函数类 $\mathcal{F}$，若存在 $\boldsymbol{f} \in \mathcal{F}$、$\boldsymbol{v}_1, \ldots, \boldsymbol{v}_K \in \mathbb{R}^m$ 及 $\epsilon > 0$，使

(i) 对所有 $k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$，有 $\| \boldsymbol{f}(\boldsymbol{\omega}) - \boldsymbol{v}_k \|_\infty \le \epsilon/2$；**(ii)** 对所有 $k \ne k'$，有 $\| \boldsymbol{v}_k - \boldsymbol{v}_{k'} \|_\infty \ge 2\epsilon$，

则称 $\mathcal{S} \subseteq \{0, 1\}^d$ 的划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 是 $\mathcal{F}$-**可分离的**。此时称该划分被 $\boldsymbol{f}$ 分离。

因此，若 $\boldsymbol{f}$ 在每个 $\mathcal{S}_k$ 上的变化尺度，相对于不同划分单元之间的变化很小，则 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 被 $\boldsymbol{f}$ 分离。命题 5 保证，对适当的 $\boldsymbol{p}$，任意划分都具有 $\mathcal{F}(2, \boldsymbol{p})$-可分离性。而且，若该划分由少数坐标（该命题 (a)）或少数半空间（该命题 (b)）确定，则可用参数更少的神经网络类分离该划分。

现在引入对式 (3) 中每个 $f^{\mathcal{S}_k}$ 施加的光滑性假设。使用偏导数的多重指标记号较为方便：对于 $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_d)^\top \in \mathbb{N}_0^d$，以及定义在 $\mathbb{R}^d$ 子集上的 $\| \boldsymbol{\alpha} \|_1$ 次可微实值函数 f，设 $\partial^{\boldsymbol{\alpha}} f := \partial^{\alpha_1} \cdots \partial^{\alpha_d} f$。对 $\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in \mathbb{R}^d$，还记 $\boldsymbol{x}^{\boldsymbol{\alpha}} := \prod_{j=1}^{d} x_j^{\alpha_j}$。

定义 2。对 $\beta, \gamma > 0$、$d \in \mathbb{N}$、$t \in [d] \cup \{0\}$ 及 $D \subseteq \mathbb{R}^d$，记 $\beta_0 := \lceil \beta \rceil - 1$，将仅依赖 t 个变量的 (β, γ)-Hölder 函数类[4]定义为

$$\mathcal{H}_t^\beta(D, \gamma) := \Bigg\{ f : D \to \mathbb{R} : f \text{ depends only on } t \text{ variables, } f \text{ is } \beta_0\text{-times differentiable,} \\ \max_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 \le \beta_0} \|\partial^{\boldsymbol{\alpha}} f\|_\infty \le \gamma, \max_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 = \beta_0} \sup_{\boldsymbol{x} \ne \boldsymbol{y} \in D} \frac{|\partial^{\boldsymbol{\alpha}} f(\boldsymbol{x}) - \partial^{\boldsymbol{\alpha}} f(\boldsymbol{y})|}{\|\boldsymbol{x} - \boldsymbol{y}\|_2^{\beta - \beta_0}} \le \gamma \Bigg\}.$$

即 $f : D \to \mathbb{R}$ 只依赖 t 个变量、β_0 次可微，并满足图示导数上界与 Hölder 条件。另记 $\mathcal{H}_t^{\beta}\left(D,\, \mathbb{R}^{d'},\, \gamma\right)$ 为向量值函数 $\boldsymbol{g} : D \to \mathbb{R}^{d'}$ 的集合，其中每个分量函数都属于 $\mathcal{H}_t^{\beta}(D,\, \gamma)$。

假定函数 $f^{\mathcal{S}_k}$ 是若干向量值函数的复合，而这些函数的对应分量属于上述 Hölder 类。下文定义 3 将标准 Hölder 光滑性推广为复合函数类；这种定义已广泛用于深度学习理论分析（如 Schmidt-Hieber, 2020；Kohler and Langer, 2021；Fan and Gu, 2024）。

定义 3。设 $q \in \mathbb{N}$，$\boldsymbol{d} = (d_r)_{r=1}^{q+1} \in \mathbb{N}^{q+1}$，其中 $d_1 = d$、$d_{q+1} = 1$；$\boldsymbol{t} = (t_r)_{r=1}^{q} \in \mathbb{N}_0^{q}$，且对每个 $r \in [q]$ 有 $t_r \in [d_r] \cup \{0\}$；$\boldsymbol{\beta} = (\beta_r)_{r=1}^{q} \in (0,\, \infty)^q$、$\boldsymbol{\gamma} = (\gamma_r)_{r=1}^{q} \in (0,\, \infty)^q$。定义 $\mathcal{H}_{\mathrm{comp}}(q,\, \boldsymbol{d},\, \boldsymbol{t},\, \boldsymbol{\beta},\, \boldsymbol{\gamma})$ 为具有下列形式的函数 $f : \mathbb{R}^d \to \mathbb{R}$ 构成的类：

$$f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_1,$$

其中对所有 $r \in [q]$，$\boldsymbol{g}_r \in \mathcal{H}_{t_r}^{\beta_r}\left(\mathbb{R}^{d_r},\, \mathbb{R}^{d_{r+1}},\, \gamma_r\right)$。[5]

例如，若 f 具有单指标结构，即对某个 $a \in \mathbb{R}^d$、$g_2 \in \mathcal{H}_1^{\beta}(\mathbb{R},\, \gamma)$ 有 $f(x) = g_2\left(a^{\top} x\right)$，则 f 属于一个复合 Hölder 类，其中 $g_1 : x \mapsto a^{\top} x$ 是依赖全部 d 个变量的线性函数（无限光滑），g_2 是 $\mathbb{R}$ 上的 β-Hölder 函数。

给定 $f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_1 \in \mathcal{H}_{\mathrm{comp}}(q,\, \boldsymbol{d},\, \boldsymbol{t},\, \boldsymbol{\beta},\, \boldsymbol{\gamma})$ 和 $r \in [q]$，$\boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_r$ 的 Hölder 光滑度为

$$\bar{\beta}_r := \beta_r \prod_{\ell=r+1}^{q} (\beta_\ell \wedge 1).$$

由此得到下一定义。

定义 4。$f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_1 \in \mathcal{H}_{\mathrm{comp}}(q,\, \boldsymbol{d},\, \boldsymbol{t},\, \boldsymbol{\beta},\, \boldsymbol{\gamma})$ 的**临界复合指标**为[6]

$$r_\star := \mathrm{sargmax}_{r \in [q]} \frac{t_r}{\bar{\beta}_r}.$$

f 的**有效光滑度**与**有效维数**分别为 $\bar{\beta}_\star := \bar{\beta}_{r_\star}$、$t_\star := t_{r_\star}$。

必须注意，有效光滑度与有效维数由最坏的比值决定，而不是例如分别取各自最坏的情况。回到定义 3 后的单指标例子，尽管 f 依赖全部 d 个协变量，却有 $\bar{\beta}_\star = \beta$、$t_\star = 1$。下文定理 2 将表明，其复合结构带来的较小有效维数，使我们能够获得避开维数灾难的收敛速率。

假设 2。对每个 $k \in [K]$，假定 $f^{\mathcal{S}_k} \in \mathcal{H}_{\mathrm{comp}}\left(q_k,\, \boldsymbol{d}^{(k)},\, \boldsymbol{t}^{(k)},\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right)$。

分别用 $r_\star^{(k)}$、$\bar{\beta}_\star^{(k)}$、$t_\star^{(k)}$ 表示 $f^{\mathcal{S}_k}$ 的临界复合指标、有效光滑度与有效维数。现在可以陈述主要结果。

定理 2。假设 1、2 成立。进一步假定对某个 $L_2 \in \mathbb{N}$、$\boldsymbol{p}_2 \in \mathbb{N}^{L_2+2}$ 和 $s_2 \in \mathbb{N}$，划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 是 $\mathcal{F}(L_2, \boldsymbol{p}_2, s_2)$-可分离的，并令 $B_n := \xi_2\sqrt{2\log n}$。则存在 $L_1, L_3 \in \mathbb{N}$、$\boldsymbol{p}_1 \in \mathbb{N}^{L_1+2}$、$\boldsymbol{p}_3 \in \mathbb{N}^{L_3+2}$ 和 $s \in \mathbb{N}$，使记

$$\mathcal{F} := \mathcal{F}_{\mathrm{PENN}}\Big(\big(L_r, \boldsymbol{p}_r\big)_{r=1}^{3}, s\Big),$$

并令 $\widehat{f}$ 为基于数据 $\mathcal{D} := \big(\boldsymbol{Z}_i, \boldsymbol{\Omega}_i, Y_i\big)_{i=1}^{n}$ 的任意 $\mathcal{F}$ 中神经网络估计量时，对 $n \geq 2$ 有

$$\mathbb{E}\big\{R(T_{B_n}\widehat{f})\big\} - R(f^\star) \leq C\left\{\sum_{k=1}^{K} \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} + \frac{s_2 \log s_2}{n}\right\} \cdot (\log n)^{2\max_{k\in[K]}\bar{\beta}_1^{(k)}\vee 6} + 2\mathbb{E}\Big\{\widehat{R}_n(\widehat{f}) - \inf_{f\in\mathcal{F}} \widehat{R}_n(f)\Big\},$$

其中 $C > 0$ 不依赖 n、$(\pi_k)_{k=1}^{K}$ 或 s_2。

为理解定理 2 的核心含义，先假定能够精确计算经验风险最小化解，因而优化误差 $\mathbb{E}\{\widehat{R}_n(\widehat{f}) - \inf_{f\in\mathcal{F}}\widehat{R}_n(f)\}$ 为零。此时，截断 PENN 估计量的超额风险由两个可解释项之和控制。除样本量的多对数因子外，第一项就是假设 1 中划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 已知时，估计贝叶斯回归函数的极小极大速率。它是各 $k \in [K]$ 上估计 $f^{\mathcal{S}_k}$ 的极小极大速率的加权平均，每个单元的有效样本量为 n_k、有效光滑度为 $\bar{\beta}_\star^{(k)}$、有效维数为 $t_\star^{(k)}$，见下文定理 3。这种加权平均形式的一个优点是，对固定 n，第 k 项满足

$$\pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} = \pi_k^{t_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} n^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} \to 0 \quad \text{as } \pi_k \to 0,$$

因此，很少观测到的缺失模式对超额风险的影响可以忽略。定理 2 上界中的第二项，是由于 $\mathcal{F}(L_2, \boldsymbol{p}_2, s_2)$-可分离划分 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 未知而产生的额外误差。例如，若划分由少数坐标或少数半空间定义，可预期第二项被第一项支配。特别地，这发生在命题 5(a) 中 $|\mathcal{S}_g| \lesssim \sum_{k=1}^{K} n_k^{t_\star^{(k)}/(2\bar{\beta}_\star^{(k)}+t_\star^{(k)})}$ 的情形，也发生在命题 5(b) 中 $K\sum_{k=1}^{K} P_k \lesssim \sum_{k=1}^{K} n_k^{t_\star^{(k)}/(2\bar{\beta}_\star^{(k)}+t_\star^{(k)})}$ 的情形。定理 2 同时覆盖经验风险最小化解未被精确计算的情况，此时会产生额外优化误差。

下面刻画定理 2 成立所需参数 $L_1, L_3, \boldsymbol{p}_1, \boldsymbol{p}_3, s$ 关于 $n_1, \ldots, n_K$ 的阶。记 $\boldsymbol{p}_1 = \big(d, p_{1,\star}, \ldots, p_{1,\star}, p_{1,L_1+1}\big)^{\mathsf{T}} \in \mathbb{N}^{L_1+2}$、$\boldsymbol{p}_3 = \big(d, p_{3,\star}, \ldots, p_{3,\star}, 1\big)^{\mathsf{T}} \in \mathbb{N}^{L_3+2}$。由证明可见，只需取 L_1, L_3 为相对于样本量的常数阶，并满足

$$p_{1,*} \asymp \sum_{k=1}^{K} n_k^{t_*^{(k)}/(4\bar{\beta}_*^{(k)}+2t_*^{(k)})} \log n, \quad p_{3,*} \asymp \sum_{k=1}^{K} n_k^{t_*^{(k)}/\{(L_3-3)(2\bar{\beta}_*^{(k)}+t_*^{(k)})\}},$$

$$s \asymp s_2 + \sum_{k=1}^{K} n_k^{t_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} \log^2 n.$$

此外，由附录 A 的 (P1) 以及命题 1 的界不依赖隐藏层宽度这一事实，可以增大 $p_{1,\star}$ 与 $p_{3,\star}$ 而不影响定理 2 的界。这意味着定理 2 适用于具有适当稀疏度的过参数化神经网络。

从证明还可看出，定理 2 中的 $C > 0$ 可取为关于 d, $\boldsymbol{d}^{(k)}$, $\boldsymbol{t}^{(k)}$ 的多项式在 $k \in [K]$ 上的最大值；多项式次数仅依赖 $\boldsymbol{\beta}^{(k)}$，系数仅依赖 p_{2,L_2+1}, L_1, L_2, L_3, ξ_1, ξ_2, d, $\boldsymbol{\beta}^{(k)}$, $\boldsymbol{\gamma}^{(k)}$。特别地，若对全部 $k \in [K]$、$r \in [q_k]$，有 $\pi_k = 1/K$、$\beta_r^{(k)} = \beta \geq 1$、$t_r^{(k)} = t$，则上界中的第一项简化为 $(K/n)^{2\beta/(2\beta+t)}$，仅相差一个不依赖 K 的 n 的多对数因子。证明的最后一个启示是，假设 1 可以弱化，不要求同一 $\mathcal{S}_k$ 中不同元素的贝叶斯回归函数完全相同；事实上，只需对 $\boldsymbol{z} \in \mathbb{R}^d$、$k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$ 假定

$$\left|f^{\star}(\boldsymbol{z}, \boldsymbol{\omega}) - f^{\mathcal{S}_k}(\boldsymbol{z})\right| \lesssim n_k^{-\bar{\beta}_{\star}^{(k)}/(2\bar{\beta}_{\star}^{(k)}+t_{\star}^{(k)})}.$$

值得强调定理 2 相对于完整观测数据已有工作（如 Schmidt-Hieber, 2020；Kohler and Langer, 2021）的新颖之处。一个关键挑战是建立合适模型，使不同缺失模式之间能够共享信息。由于可能总共有 2^d 种不同缺失模式，这一点至关重要，且通过假设 1 得以实现。同样，定义 1 中刻画贝叶斯回归函数单元划分复杂度的 $\mathcal{F}$ -可分离性条件也是新的。证明定理 2 的主要挑战，是对估计与逼近误差进行精细平衡，以得到界中的 $\sum_{k=1}^{K} \pi_k n_k^{-2\bar{\beta}_{\star}^{(k)}/(2\bar{\beta}_{\star}^{(k)}+t_{\star}^{(k)})}$ 项；无缺失时并不出现这一项。

下面以一个对应的极小极大下界补充定理 2 的上界，采用假设 1、2 及定义 4 的记号。此外，对 $k \in [K]$，定义 $\mathcal{J}^{(k)} := \{j \in [d] : \omega_j = 1,\ \forall\, \boldsymbol{\omega} \in \mathcal{S}_k\}$，并令 $d_{\star}^{(k)} := d_{r_{\star}^{(k)}}^{(k)}$、$\gamma_{\star}^{(k)} := \gamma_{r_{\star}^{(k)}}^{(k)}$。

定理 3。令 $\mathcal{P}$ 为 $(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0, Y_0)$ 的所有如下分布构成的集合：$\boldsymbol{Z}_0 = \mathrm{Imp}(\widetilde{\boldsymbol{X}}_0)$，其中 $\widetilde{\boldsymbol{X}}_0$ 表示部分观测协变量向量，而 $(\boldsymbol{X}_0, \boldsymbol{\Omega}_0, Y_0)$ 满足假设 1、2 且 $\xi_1, \xi_2 \geq 1$。进一步假定存在 $j_{\star} \in [d]$，使对所有 $k \in [K]$，

$$t_*^{(k)} \leq \min\left\{d_1^{(k)}, \ldots, d_*^{(k)}\right\} \wedge \left|\mathcal{J}^{(k)} \setminus \{j_*\}\right| \wedge \gamma_*^{(k)}$$

对 $P \in \mathcal{P}$，令 $f^{\star} \equiv f_P^{\star} := \mathbb{E}_P(Y_0 \mid \boldsymbol{Z}_0, \boldsymbol{\Omega}_0)$，并令 $\widehat{\mathcal{F}}$ 为基于大小为 n 的样本的所有 $f^{\star}$ 估计量的集合，即从 $\mathbb{R}^d \times \mathcal{S} \times \left(\mathbb{R}^d \times \mathcal{S} \times \mathbb{R}\right)^n$ 到 $\mathbb{R}$ 的 Borel 可测函数集合。那么存在仅依赖 ξ_2 和 $\left(\bar{\beta}_{\star}^{(k)}, t_{\star}^{(k)}\right)_{k=1}^{K}$ 的 $c > 0$，使对所有 $n \in \mathbb{N}$，

$$\inf_{\widehat{f} \in \widehat{\mathcal{F}}} \sup_{P \in \mathcal{P}} \mathbb{E}_{P^{\otimes n}}\left\{R(\widehat{f}) - R(f^{\star})\right\} \geq c \sum_{k=1}^{K} \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})}$$

定理 3 表明，定理 2 上界的主要项，即第一个估计误差项，关于 n 和 $\pi_1, \ldots, \pi_K$ 达到极小极大最优，仅相差 n 的多对数因子。

4 模拟实验

本节研究模式嵌入神经网络（PENN）估计量在模拟、半合成和真实数据上的实证表现。由于 PENN 可与任何插补技术结合，我们考虑逐列均值插补（MI）、MissForest 插补（MF；Stekhoven and Bühlmann, 2012），以及链式方程多重插补（MICE；van Buuren and Groothuis-Oudshoorn, 2011）的 Python 实现，即 scikit-learn（Pedregosa et al., 2011）中的 IterativeImputer（II）。对每种插补法，都将 PENN 与不把揭示向量作为协变量的标准神经网络比较。还比较 XGBoost（Chen and Guestrin, 2016）和随机森林（Breiman, 2001）；这是两种常用的树算法，通过为含缺失的观测学习默认分裂方向，直接处理缺失值。

所有数值实验中，我们都把数据分为训练、验证、测试集。先在训练数据上运行随机优化方法 AdamW（Loshchilov and Hutter, 2019）10 轮，再保留绝对值最大的比例为 $\lambda \in \{0.1,\ 0.2,\ 0.4,\ 0.8\}$ 的权重以及全部偏置向量，得到稀疏网络。遵循 Liu et al.（2019）的建议，在剪枝后使用 PyTorch 函数 `torch.nn.init.kaiming_uniform_` 随机重新初始化非零参数，再以 AdamW 重新训练稀疏模型。采用早停（Prechelt, 2002）：对于每个 λ，一旦连续 10 轮中验证损失的下降未达到 0.001，就终止训练。随后选取使验证集平均损失最小的调参值 λ，最终报告选定估计量在测试集上的表现。对 XGBoost，依据验证集表现从 $\{3,\ 6,\ 9,\ 12\}$ 中选择 `max_depth`；对随机森林，从 $\{\lceil 0.1d \rceil,\ \lceil 0.2d \rceil,\ \lceil 0.4d \rceil,\ \lceil 0.8d \rceil\}$ 中调节 `max_features`；其他调参采用默认设置。需要指出，虽然理论要求用于插补的数据与训练数据独立，但在模拟中，我们在整个数据集（训练、验证和测试集）上训练插补算法，然后插补缺失项。

模拟中，对训练样本量 n、协变量维数 d 的数据集，定义 $w_1 := \lceil \sqrt{n} \rceil$、$w_2 := \lceil w_1/5 \rceil$，嵌入维数 $m := \lceil \sqrt{d} \rceil \wedge \lceil w_1/20 \rceil$。随后：

- PENN 使用 $\mathcal{F}_{\text{PENN}}\left((L_r,\ \boldsymbol{p}_r)_{r=1}^{3},\ s \right)$，其中 $L_1 = 3$、$\boldsymbol{p}_1 = (d,\ w_1,\ w_1,\ w_1,\ w_1)$，$L_2 = 2$、$\boldsymbol{p}_2 = (d,\ w_2,\ w_2,\ m)$，$L_3 = 3$、$\boldsymbol{p}_3 = (w_1 + m,\ w_1,\ w_1,\ w_1,\ 1)$。
- NN 使用 $\mathcal{F}\left(6,\ (d,\ w_1,\ w_1,\ w_1,\ w_1,\ w_1,\ w_1,\ 1),\ s\right)$。

由 (P2)，上述 PENN 类不计嵌入函数 $\boldsymbol{f}_2$ 时总共有六个隐藏层，见式 (2) 和图 4。因此，与它比较的是一个具有六个同样宽度隐藏层的标准神经网络。稀疏度 s 按前述方法选择。

4.1 模拟数据

每个模拟数据实验均取 $d = 20$，训练集大小 $n = 10,\ 000$，因此 $m = 4$；验证集和测试集大小各为 5,000。数据生成机制如下。

模型 1： $\boldsymbol{X}_0 \sim \text{Unif}[-1,\ 1]^d$，$Y_0 = \exp\left(X_{0,1} + X_{0,2}\right) + 4X_{0,3}^2 + \varepsilon_0$，$\varepsilon_0 \sim N(0,\ 0.25)$，$\varepsilon_0 \perp\!\!\!\perp \boldsymbol{X}_0$，$\boldsymbol{\Omega}_0 \perp\!\!\!\perp \left(\boldsymbol{X}_0,\ \varepsilon_0\right)$，且对 $j \in [d]$，$\Omega_{0,j} \overset{\text{iid}}{\sim} \text{Ber}(0.7)$。

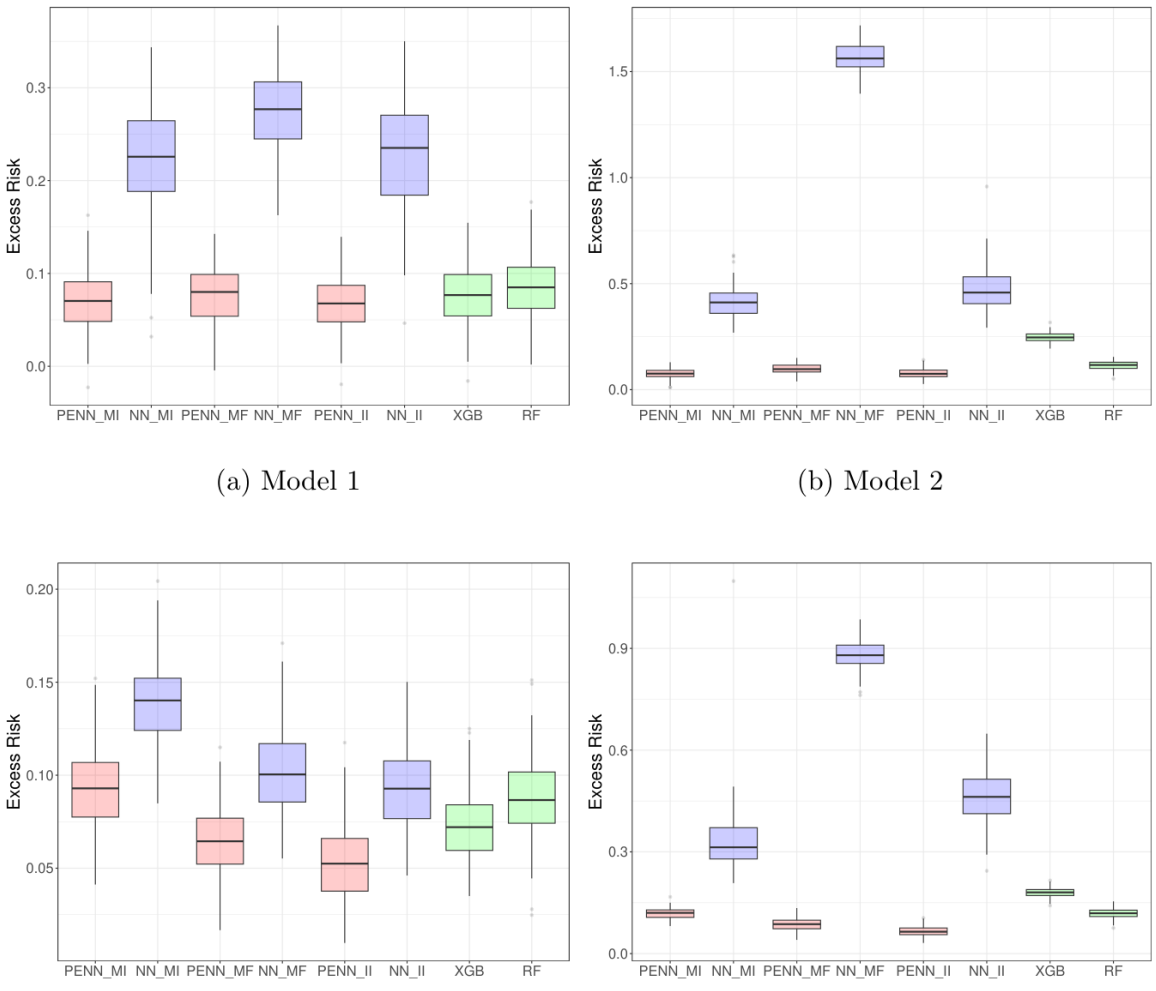
模型 2： $\boldsymbol{X}_0 \sim \text{Unif}[-1,\ 1]^d$，$Y_0 = 2\sin\left(2X_{0,1} + 2X_{0,2} + 2X_{0,3}\right) + 2X_{0,3} + \varepsilon_0$，$\varepsilon_0 \sim N(0,\ 0.25)$，$\varepsilon_0 \perp\!\!\!\perp \boldsymbol{X}_0$。对 $j \notin \{2,\ 3\}$，$\Omega_{0,j} \overset{\text{iid}}{\sim} \text{Ber}(0.7)$ 且与 $\boldsymbol{X}_0$ 独立；对 $j \in \{2,\ 3\}$，$\Omega_{0,j} = \mathbf{1}_{\{X_{0,j} \le 0.4\}}$。

模型 3： 与模型 1 相同，但改为 $X_{0,1} = \sqrt{X_{0,4} + 1} - 0.7 + \text{Unif}[-0.3, 0.3]$，$X_{0,3} = 0.7X_{0,5} + \text{Unif}[-0.3, 0.3]$。

模型 4： 与模型 2 相同，但改为 $X_{0,1} = \sqrt{X_{0,4} + 1} - 0.7 + \text{Unif}[-0.3, 0.3]$，$X_{0,3} = 0.7X_{0,5} + \text{Unif}[-0.3, 0.3]$。

因此，模型 1、3 为 MCAR，模型 2、4 为 MNAR。模型 1、2 中协变量的不同坐标相互独立；模型 3、4 中则在 $X_{0,1}$ 与 $X_{0,4}$ 之间、$X_{0,3}$ 与 $X_{0,5}$ 之间引入正相关。每种情况下，真实回归函数都只依赖 $\boldsymbol{X}_0$ 的前三个分量，这便于通过蒙特卡洛积分计算贝叶斯风险。

100 次重复模拟的结果见图 5。四个模型中，对每一种插补技术，PENN 都提升了普通 NN 的表现，且提升往往很显著。特别地，它能在很大程度上弥补模型 2、4 中 NN_MF 格外差的表现。从某种程度看，对普通神经网络估计量更有效的插补技术，也倾向于产生更好的 PENN 估计量。XGBoost 与随机森林在模型 1 上具有竞争力，但在其他三个模型上表现较弱。附录 I 还提供学习到的模式嵌入可视化。



(a) Model 1　　(b) Model 2

(c) Model 3　　(d) Model 4

图 5： 模拟数据模型 1–4 的超额风险估计。PENN 估计量为红色，普通神经网络（NN）为蓝色，XGBoost（XGB）与随机森林（RF）为绿色。横轴下划线后的缩写表示所用插补技术；MI 为均值插补，MF 为 MissForest，II 为 IterativeImputer。纵轴 Excess Risk 为超额风险，子图 (a)–(d) 依次为模型 1–4。

4.2 半合成数据

本小节考虑两个半合成数据集，即取两个无缺失的真实数据集，按下述两种指定机制人为加入缺失。这一做法的优点，是能够在真实数据上研究不同缺失类型的影响。

CT 相对位置数据集： 来自 OpenML 的计算机断层扫描（CT）相对位置数据集是完整数据，$d = 384$，总样本量为 53,500。响应变量为 CT 切片在人体纵轴上的相对位置，协变量描述骨结构的位置及空气包容区域的位置。这里仍考虑各坐标观测概率均为 0.7 的 MCAR 缺失。MNAR 情形中，X_{ij} 被观测的概率为 $\mathrm{sigmoid}\left(-2X_{ij} + 4\bar{X}_i + 1\right)$，其中 $\mathrm{sigmoid}(x) := 1/(1+e^{-x})$、$\bar{X}_i := d^{-1}\sum_{k=1}^{d} X_{ik}$。

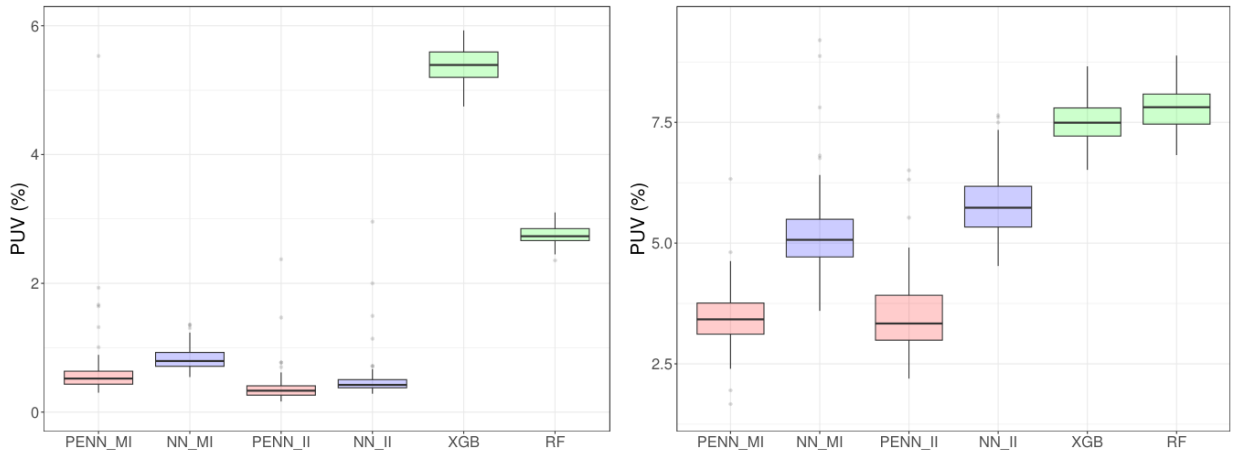
MNIST 数据集： PyTorch 中的 MNIST 数据集（LeCun, Cortes and Burges, 1998）包含 70,000 张数字 0–9 的手写灰度图，每张表示为 28×28 像素网格。我们把灰度归一化到 $[0, 1]$，目标是根据图像预测标签。为体现相邻像素的缺失可能相关，把每张图像均匀划分为 49 个 4×4 像素块。MCAR 设定下，每个块以概率 0.5 独立被观测；MNAR 设定下，对每个 $\ell \in \{0, \ldots, 9\}$，从 $[0.2, 0.8]^{49}$ 中均匀抽取随机向量 $\boldsymbol{p}_\ell = \left(p_{\ell,1}, \ldots, p_{\ell,49}\right)^\top$，并对 $j \in [49]$ 独立生成 $\Omega_{i,j} \sim \mathrm{Ber}\left(p_{\ell_i,j}\right)$，其中 ℓ_i 是第 i 个观测的标签。也就是说，MNAR 情形下缺失概率随标签变化，但所有观测整体的期望缺失概率均为 0.5。对 MNIST 仅使用均值插补，因为 MissForest 与 MICE 不太适合图像数据。图 6 展示 MNIST 前 16 张图像在 MCAR 和 MNAR 缺失下的样子。

图 6： MNIST 数据集中带有 MCAR 和 MNAR 缺失的前 16 张图像（均值插补后），各子图上方标注真实标签。(a) MCAR 缺失；(b) MNAR 缺失。

> **译制说明：本处未收入图 6 位图。** 该图包含 MNIST 数据集样例，图像自身的许可尚未独立核实，因此仅保留完整中文图注与上下文。查看原图请见 原文 PDF 第 21 页图 6。此省略不涉及论文其余 12 幅图。

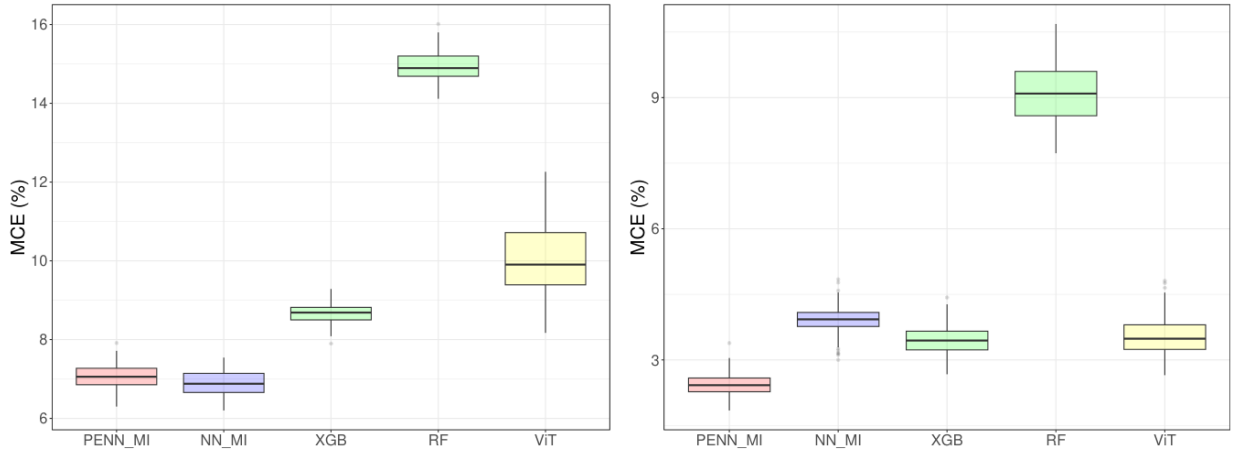
在图像分类任务中，卷积神经网络取得了巨大成功（Zhang et al., 1988；LeCun et al., 1998；Krizhevsky, Sutskever and Hinton, 2012）；相关介绍还可参见 Fan, Ma and Zhong（2020，第 3.1 节）。因此，对 MNIST，把 PENN 定义式 (2) 中 $\boldsymbol{f}_1$ 的前两个隐藏层，以及 NN 的前两个隐藏层，分别替换为二维卷积层、ReLU 激活层和最大池化层的复合。模拟所用含卷积层 PENN 与 NN 的详细结构见 作者代码仓库。我们仍把 PENN 与删除嵌入函数、其余结构相同的神经网络比较，并与 XGBoost、随机森林比较。另外，对 MNIST 纳入视觉 Transformer（ViT；Dosovitskiy et al., 2021）作为基准，[7] 因为 ViT 可通过降低缺失或遮挡图块的注意力权重，直接应用于带有缺失或遮挡图块的图像。MNIST 分类任务的训练使用交叉熵损失，即相应多项分布的负对数似然。

两个数据集各进行 100 次重复；每次引入缺失后，按 8:1:1 的样本量比例随机划分训练、验证与测试集。回归任务以未解释方差比例（PUV）衡量算法性能，即测试集均方预测误差与同一测试集响应样本方差之比。分类任务则以测试集误分类率（MCE）衡量性能。两个数据集结果分别见图 7、8。MCAR 缺失时，PENN 总体表现至少不逊于普通 NN；MNAR 缺失时，则有显著改善。PENN 相对于 XGBoost、随机森林及 ViT 也有很大改进。



(a) MCAR missingness (b) MNAR missingness

图 7： CT 相对位置数据集在不同缺失机制下的未解释方差比例（PUV，百分比）。(a) MCAR；(b) MNAR。



(a) MCAR missingness (b) MNAR missingness

图 8： MNIST 数据集在不同缺失机制下的误分类率（MCE，百分比）。(a) MCAR；(b) MNAR。

4.3 真实数据

最后考虑一个本身已包含缺失值的真实数据集。

信用评分预测数据集： 来自 Kaggle 的信用评分预测数据集具有 $d = 304$、总样本量 100,000。感兴趣的响应为信用等级，在现有数据中量化为 300–839 之间的正整数。41 列存在缺失，这些列的观测概率见图 9 左图。

同样进行 30 次重复，每次按 8:1:1 随机划分训练、验证和测试集。信用评分数据的 PUV 见图 9 右图。PENN 相对于普通 NN、XGBoost 和随机森林的改善再次十分明显。

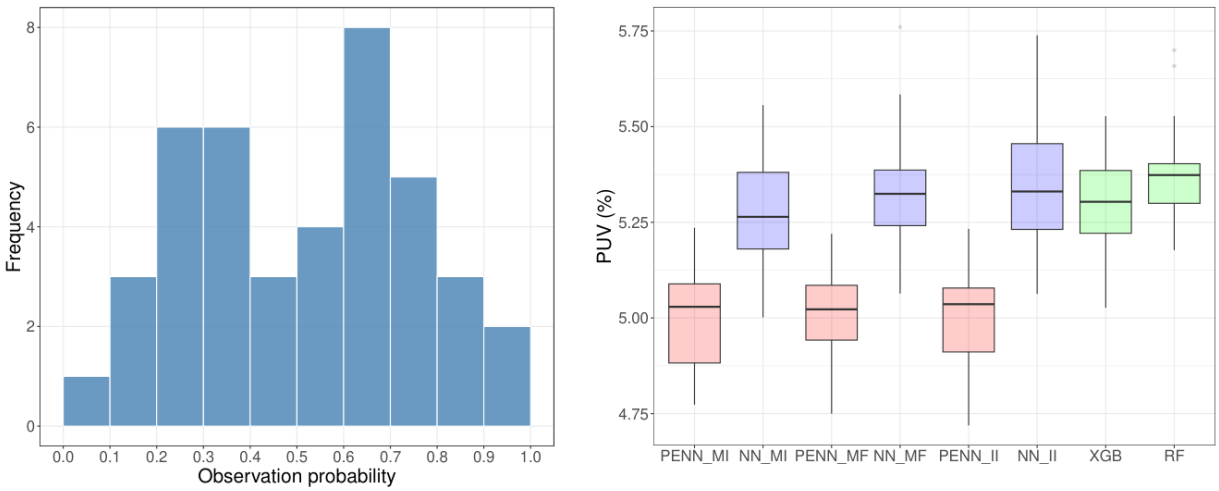


图 9： 左：含缺失列的观测概率直方图；横轴为观测概率（Observation probability），纵轴为频数（Frequency）。右：信用评分预测数据集的未解释方差比例（PUV，百分比）。

5 讨论

本文提出模式嵌入神经网络（PENN），作为协变量缺失的非参数回归的一种新型深度学习结构。图 1 所示的例 1 表明，函数 $\boldsymbol{z} \mapsto \mathbb{E}(\boldsymbol{Y} \mid \boldsymbol{Z} = \boldsymbol{z})$ 可能由于不同观测模式而出现不连续，因此这个例子的一个主要信息是：建模时应纳入揭示向量。

另一方面，图 2 表明，只是简单地把揭示向量作为额外协变量加入——使输入空间维数加倍——甚至可能损害预测性能。因此，PENN 的主要方法贡献，是通过将揭示向量嵌入一个较低维空间，有效压缩其中的信息。该方法的一项优点是可与任意现有插补技术结合使用。

我们为 PENN 的使用提供理论支持：给出其超额风险的有限样本上界，且不对数据生成机制与缺失机制的关系作任何假设。假设 1 将贝叶斯回归函数划分为不同单元，使不同观测模式之间可以共享统计信息；定理 2、3 的主要结论是，PENN 通常能达到如同预先知道这些划分单元时的极小极大收敛速率，仅相差样本量的多对数因子。

理论结果由合成、半合成和真实数据上的数值实验补充，实验确认了 PENN 带来的实际性能提升。

致谢

TM 与 RJS 的研究得到 RJS 的欧洲研究理事会高级研究资助项目 101019498 支持。

参考文献

以下保留原文的完整英文书目信息，并逐条附中文题名译注，以便检索核对。

1. Arora, S., Du, S. S., Hu, W., Li, Z., Salakhutdinov, R. R. and Wang, R. (2019) On exact computation with an infinitely wide neural net. Advances in Neural Information Processing Systems, 32.
   题名中译： 无限宽神经网络的精确计算。

2. Bao, H., Dong, L., Piao, S. and Wei, F. (2022) BEiT: BERT Pre-Training of Image Transformers. In International Conference on Learning Representations.
题名中译： BEiT 图像 Transformer 的 BERT 预训练。

3. Bartlett, P. L., Harvey, N., Liaw, C. and Mehrabian, A. (2019) Nearly-tight VC-dimension and pseudodimension bounds for piecewise linear neural networks. Journal of Machine Learning Research, 20, 1–17.
题名中译： 分段线性神经网络近乎紧致的 VC 维数与伪维数界。

4. Bauer, B. and Kohler, M. (2019) On deep learning as a remedy for the curse of dimensionality in nonparametric regression. Annals of Statistics, 47, 2261–2285.
题名中译： 用深度学习缓解非参数回归中的维数灾难。

5. Berrett, T. B. and Samworth, R. J. (2023) Optimal nonparametric testing of Missing Completely At Random, and its connections to compatibility. Annals of Statistics, 51, 2170–2193.
题名中译： 完全随机缺失的最优非参数检验及其与相容性的联系。

6. Bhattacharya, S., Fan, J. and Mukherjee, D. (2024) Deep neural networks for nonparametric interaction models with diverging dimension. Annals of Statistics, 52, 2738–2766.
题名中译： 维数发散的非参数交互模型的深度神经网络。

7. Bos, T. and Schmidt-Hieber, J. (2022) Convergence rates of deep ReLU networks for multiclass classification. Electronic Journal of Statistics, 16, 2724–2773.
题名中译： 深度 ReLU 网络在多类分类中的收敛速率。

8. Bos, T. and Schmidt-Hieber, J. (2024) A supervised deep learning method for nonparametric density estimation. Electronic Journal of Statistics, 18, 5601–5658.
题名中译： 用于非参数密度估计的监督深度学习方法。

9. Breiman, L. (2001) Random forests. Machine Learning, 45, 5–32.
题名中译： 随机森林。

10. Cai, T. T. and Zhang, L. (2019) High dimensional linear discriminant analysis: optimality, adaptive algorithm and missing data. Journal of the Royal Statistical Society, Series B: Statistical Methodology, 81, 675–705.
题名中译： 高维线性判别分析 最优性 自适应算法与缺失数据。

11. Chandrasekher, K. A., Alaoui, A. E. and Montanari, A. (2020) Imputation for high-dimensional linear regression. arXiv preprint arXiv:2001.09180.
题名中译： 高维线性回归中的插补。

12. Chen, T. and Guestrin, C. (2016) XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.
题名中译： XGBoost 可扩展的树提升系统。

13. Ching, M., Popescu, I., Smith, N., Ma, T., Underwood, W. G. and Samworth, R. J. (2026) Efficient and minimax-optimal in-context nonparametric regression with transformers. International Conference on Machine Learning, to appear.
题名中译： 使用 Transformer 的高效且极小极大最优的上下文非参数回归。

14. Chizat, L. and Bach, F. (2018) On the global convergence of gradient descent for over-parameterized models using optimal transport. Advances in Neural Information Processing Systems, 31.
题名中译： 利用最优输运研究过参数化模型梯度下降的全局收敛。

15. Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K. (2019) Bert: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of the 2019 Conference of the North American chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (long and short papers), 4171–4186.
题名中译： BERT 用于语言理解的深层双向 Transformer 预训练。

16. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J. and Houlsby, N. (2021) An image is worth 16x16 words: Transformers for image recognition at scale. In International Conference on Learning Representations.
题名中译： 一张图像等于 16×16 个词 面向大规模图像识别的 Transformer。

17. Du, S. S., Zhai, X., Poczos, B. and Singh, A. (2019) Gradient descent provably optimizes over-parameterized neural networks. In International Conference on Learning Representations.
题名中译： 梯度下降可证明地优化过参数化神经网络。

18. Efromovich, S. (2011) Nonparametric regression with predictors missing at random. Journal of the American Statistical Association, 106, 306–319.
题名中译： 预测变量随机缺失的非参数回归。

19. Elsener, A. and van de Geer, S. (2019) Sparse spectral estimation with missing and corrupted measurements. Stat, 8, e229.
题名中译： 含缺失及损坏测量的稀疏谱估计。

20. Fan, J. and Gu, Y. (2024) Factor augmented sparse throughput deep ReLU neural networks for high dimensional regression. Journal of the American Statistical Association, 119, 2680–2694.
题名中译： 用于高维回归的因子增广稀疏直通深度 ReLU 神经网络。

21. Fan, J., Ma, C. and Zhong, Y. (2020) A selective overview of deep learning. Statistical Science, 36, 264–290.
题名中译： 深度学习的选择性概述。

22. Follain, B., Wang, T. and Samworth, R. J. (2022) High-dimensional changepoint estimation with heterogeneous missingness. Journal of the Royal Statistical Society Series B: Statistical Methodology, 84, 1023–1055.
题名中译： 异质缺失下的高维变点估计。

23. Guo, C. and Berkhahn, F. (2016) Entity embeddings of categorical variables. arXiv preprint arXiv:1604.06737.
题名中译： 类别变量的实体嵌入。

24. Györfi, L., Kohler, M., Krzyzak, A. and Walk, H. (2006) A Distribution-free Theory of Nonparametric Regression. Springer Science & Business Media.
题名中译： 非参数回归的分布无关理论。

25. He, K., Chen, X., Xie, S., Li, Y., Dollár, P. and Girshick, R. (2022) Masked autoencoders are scalable vision learners. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 16000–16009.
题名中译： 掩码自编码器是可扩展的视觉学习器。

26. He, K., Zhang, X., Ren, S. and Sun, J. (2016) Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 770–778.
题名中译： 用于图像识别的深度残差学习。

27. Hinton, G. E. and Salakhutdinov, R. R. (2006) Reducing the dimensionality of data with neural networks. Science, 313, 504–507.
题名中译： 用神经网络降低数据维数。

28. Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T. and Hutter, F. (2025) Accurate predictions on small data with a tabular foundation model. Nature, 637, 319–326.
题名中译： 利用表格基础模型在小数据上作出准确预测。

29. Imaizumi, M. and Fukumizu, K. (2019) Deep neural networks learn non-smooth functions effectively. In The 22nd International Conference on Artificial Intelligence and Statistics, 869–878, PMLR.
题名中译： 深度神经网络有效学习非光滑函数。

30. Jacot, A., Gabriel, F. and Hongler, C. (2018) Neural tangent kernel: Convergence and generalization in neural networks. Advances in Neural Information Processing Systems, 31.
题名中译： 神经切线核 神经网络的收敛与泛化。

31. Jiao, Y., Shen, G., Lin, Y. and Huang, J. (2023) Deep nonparametric regression on approximate manifolds: Nonasymptotic error bounds with polynomial prefactors. Annals of Statistics, 51, 691–716.
题名中译： 近似流形上的深度非参数回归 具有多项式前置系数的非渐近误差界。

32. Josse, J., Chen, J. M., Prost, N., Varoquaux, G. and Scornet, E. (2024) On the consistency of supervised learning with missing values. Statistical Papers, 65, 5447–5479.
题名中译： 含缺失值监督学习的一致性。

33. Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Žídek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., Back, T., Petersen, S., Reiman, D., Clancy, E., Zielinski, M., Steinegger, M., Pacholska, M., Berghammer, T., Bodenstein, S., Silver, D., Vinyals, O., Senior, A. W., Kavukcuoglu, K., Kohli, P. and Hassabis, D. (2021) Highly accurate protein structure prediction with AlphaFold. Nature, 596, 583–589.
题名中译： AlphaFold 实现高精度蛋白质结构预测。

34. Kim, J., Nakamaki, T. and Suzuki, T. (2024) Transformers are minimax optimal nonparametric in-context learners. Advances in Neural Information Processing Systems, 37, 106667–106713.
题名中译： Transformer 是极小极大最优的非参数上下文学习器。

35. Kingma, D. P. and Ba, J. (2015) Adam: A method for stochastic optimization. In International Conference on Learning Representations.
题名中译： Adam 一种随机优化方法。

36. Kohler, M. and Langer, S. (2021) On the rate of convergence of fully connected deep neural network regression estimates. Annals of Statistics, 49, 2231–2249.
题名中译： 全连接深度神经网络回归估计的收敛速率。

37. Krizhevsky, A., Sutskever, I. and Hinton, G. E. (2012) Imagenet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25.
题名中译： 使用深度卷积神经网络的 ImageNet 分类。

38. Le Morvan, M., Josse, J., Scornet, E. and Varoquaux, G. (2021) What's a good imputation to predict with missing values? Advances in Neural Information Processing Systems, 34, 11530–11540.
题名中译： 利用缺失值进行预测时 什么是好的插补。

39. LeCun, Y., Bottou, L., Bengio, Y. and Haffner, P. (1998) Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86, 2278–2324.
题名中译： 应用于文档识别的基于梯度的学习。

40. LeCun, Y., Cortes, C. and Burges, C. J. C. (1998) The MNIST database of handwritten digits. https://yann.lecun.com/exdb/mnist/.
题名中译： MNIST 手写数字数据库。

41. Li, S. C.-X., Jiang, B. and Marlin, B. (2019) MisGAN: Learning from incomplete data with generative adversarial networks. In International Conference on Learning Representations.
题名中译： MisGAN 用生成对抗网络从不完整数据中学习。

42. Littwin, E. and Yang, G. (2023) Adaptive optimization in the ∞-width limit. In The Eleventh International Conference on Learning Representations.
题名中译： 无限宽极限中的自适应优化。

43. Liu, Z., Sun, M., Zhou, T., Huang, G. and Darrell, T. (2019) Rethinking the value of network pruning. In International Conference on Learning Representations.
题名中译： 重新思考网络剪枝的价值。

44. Loh, P.-L. and Wainwright, M. J. (2012) High-dimensional regression with noisy and missing data: provable guarantees with nonconvexity. Annals of Statistics, 40, 1637–1664.
题名中译： 含噪声和缺失数据的高维回归 非凸性下的可证明保证。

45. Loshchilov, I. and Hutter, F. (2019) Decoupled weight decay regularization. In International Conference on Learning Representations.
题名中译： 解耦的权重衰减正则化。

46. Lu, J., Shen, Z., Yang, H. and Zhang, S. (2021) Deep network approximation for smooth functions. SIAM Journal on Mathematical Analysis, 53, 5465–5506.
题名中译： 光滑函数的深层网络逼近。

47. Ma, T., Verchand, K. A., Berrett, T. B., Wang, T. and Samworth, R. J. (2026+) Estimation beyond Missing (Completely) at Random. Annals of Statistics (to appear).
题名中译： 超越（完全）随机缺失的估计。

48. Ma, T., Wang, T. and Samworth, R. J. (2025) Optimal in-context adaptivity and distributional robustness of Transformers. arXiv preprint arXiv:2510.23254.
题名中译： Transformer 的最优上下文自适应性与分布鲁棒性。

49. Mattei, P.-A. and Frellsen, J. (2019) MIWAE: Deep generative modelling and imputation of incomplete data sets. In International Conference on Machine Learning, 4413–4423, PMLR.
题名中译： MIWAE 不完整数据集的深度生成建模与插补。

50. Mei, S. and Montanari, A. (2022) The generalization error of random features regression: Precise asymptotics and the double descent curve. Communications on Pure and Applied Mathematics, 75, 667–766.
题名中译： 随机特征回归的泛化误差 精确渐近与双下降曲线。

51. Mei, S., Montanari, A. and Nguyen, P.-M. (2018) A mean field view of the landscape of two-layer neural networks. Proceedings of the National Academy of Sciences, 115, E7665–E7671.
题名中译： 双层神经网络损失景观的均值场观点。

52. Mikolov, T., Chen, K., Corrado, G. and Dean, J. (2013) Efficient estimation of word representations in vector space. arXiv preprint arXiv:1301.3781.
题名中译： 向量空间中词表示的高效估计。

53. Nazabal, A., Olmos, P. M., Ghahramani, Z. and Valera, I. (2020) Handling incomplete heterogeneous data using VAEs. Pattern Recognition, 107, 107501.
题名中译： 使用变分自编码器处理不完整异质数据。

54. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J. and Chintala, S. (2019) Pytorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.
题名中译： PyTorch 命令式高性能深度学习库。

55. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. and Duchesnay, E. (2011) Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
题名中译： Scikit-learn Python 中的机器学习。

56. Prechelt, L. (2002) Early stopping – but when? In Neural Networks: Tricks of the Trade (Orr, G. B. and Müller, K.-R., eds.), 55–69, Springer.
题名中译： 早停 但应何时停止。

57. Royden, H. L. and Fitzpatrick, P. (2010) Real Analysis. Printice-Hall Inc, Boston.
题名中译： 实分析。

58. Samworth, R. J. and Shah, R. D. (2026+) Modern Statistical Methods and Theory. Cambridge University Press, Cambridge.
题名中译： 现代统计方法与理论。

59. Schmidt-Hieber, J. (2020) Nonparametric regression using deep neural networks with ReLU activation function. Annals of Statistics, 48, 1875–1897.
题名中译： 使用 ReLU 激活深度神经网络的非参数回归。

60. Sell, T., Berrett, T. B. and Cannings, T. I. (2024) Nonparametric classification with missing data. Annals of Statistics, 52, 1178–1200.
题名中译： 含缺失数据的非参数分类。

61. Shen, Z., Yang, H. and Zhang, S. (2019) Nonlinear approximation via compositions. Neural Networks, 119, 74–84.
题名中译： 通过复合进行非线性逼近。

62. Śmieja, M., Struski, Ł., Tabor, J., Zieliński, B. and Spurek, P. (2018) Processing of missing data by neural networks. Advances in Neural Information Processing Systems, 31.
题名中译： 使用神经网络处理缺失数据。

63. Stekhoven, D. J. and Bühlmann, P. (2012) MissForest—non-parametric missing value imputation for mixed-type data. Bioinformatics, 28, 112–118.
题名中译： MissForest 混合类型数据的非参数缺失值插补。

64. Suh, N. and Cheng, G. (2024) A survey on statistical theory of deep learning: Approximation, training dynamics, and generative models. Annual Review of Statistics and Its Application, 12, 177–207.
题名中译： 深度学习统计理论综述 逼近 训练动力学与生成模型。

65. Suzuki, T., Wu, D. and Nitanda, A. (2023) Convergence of mean-field langevin dynamics: time-space discretization, stochastic gradient, and variance reduction. Advances in Neural Information Processing Systems, 36, 15545–15577.
题名中译： 均值场 Langevin 动力学的收敛 时空离散化 随机梯度与方差缩减。

66. Twala, B. E., Jones, M. and Hand, D. J. (2008) Good methods for coping with missing data in decision trees. Pattern Recognition Letters, 29, 950–956.
题名中译： 决策树中处理缺失数据的有效方法。

67. van Buuren, S. and Groothuis-Oudshoorn, K. (2011) mice: Multivariate imputation by chained equations in R. Journal of Statistical Software, 45, 1–67.
题名中译： mice R 中的链式方程多元插补。

68. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. and Polosukhin, I. (2017) Attention is all you need. Advances in Neural Information Processing Systems, 30.
题名中译： 注意力就是你所需要的全部。

69. Vincent, P., Larochelle, H., Bengio, Y. and Manzagol, P.-A. (2008) Extracting and composing robust features with denoising autoencoders. In Proceedings of the 25th International Conference on Machine Learning, 1096–1103.
题名中译： 用去噪自编码器提取和组合鲁棒特征。

70. Yang, G. and Hu, E. J. (2021) Tensor Programs IV: Feature Learning in Infinite-Width Neural Networks. In International Conference on Machine Learning, PMLR.
题名中译： 张量程序 IV 无限宽神经网络中的特征学习。

71. Zhang, H., Fang, L., Wu, Q. and Yu, P. S. (2025) DiffPuter: An EM-driven diffusion model for missing data imputation. In The Thirteenth International Conference on Learning Representations.
题名中译： DiffPuter 用于缺失数据插补的 EM 驱动扩散模型。

72. Zhang, W., Tanida, J., Itoh, K. and Ichioka, Y. (1988) Shift-invariant pattern recognition neural network and its optical architecture. In Proceedings of annual conference of the Japan Society of Applied Physics, vol. 564, Montreal, CA.
题名中译： 平移不变模式识别神经网络及其光学结构。

73. Zhang, Z., Shi, L. and Zhou, D.-X. (2024) Classification with deep neural networks and logistic loss. Journal of Machine Learning Research, 25, 1–117.
题名中译： 使用深度神经网络和逻辑损失的分类。

74. Zhong, Q., Mueller, J. and Wang, J.-L. (2022) Deep learning for the partially linear Cox model. Annals of Statistics, 50, 1348–1375.
题名中译： 部分线性 Cox 模型的深度学习。

75. Zhu, Z., Wang, T. and Samworth, R. J. (2022) High-dimensional principal component analysis with heterogeneous missingness. Journal of the Royal Statistical Society Series B: Statistical Methodology, 84, 2000–2031.
题名中译： 异质缺失下的高维主成分分析。

附录 A 神经网络的一些性质

我们概述与神经网络相关的若干基本运算。

(P1) 神经网络扩宽： 令 $L \in \mathbb{N}$，$\boldsymbol{p}_1, \boldsymbol{p}_2 \in \mathbb{N}^{L+2}$ 满足逐坐标 $\boldsymbol{p}_1 \le \boldsymbol{p}_2$，且 $s \in \mathbb{N}$。由定义，$\mathcal{F}(L, \boldsymbol{p}_1, s) \subseteq \mathcal{F}(L, \boldsymbol{p}_2, s)$。

(P2) 神经网络复合： $\boldsymbol{p}_1 = (p_{1,0}, \ldots, p_{1,L_1+1})^\top \in \mathbb{N}^{L_1+2}$、$\boldsymbol{p}_2 = (p_{2,0}, \ldots, p_{2,L_2+1})^\top \in \mathbb{N}^{L_2+2}$ 满足 $p_{1,L_1+1} = p_{2,0}$。令 $\boldsymbol{f}_1 \in \mathcal{F}(L_1, \boldsymbol{p}_1)$、$\boldsymbol{f}_2 \in \mathcal{F}(L_2, \boldsymbol{p}_2)$（若 $\boldsymbol{f}_1$ 或 $\boldsymbol{f}_2$ 为仿射函数，则令相应的 L_1 或 L_2 为零）。那么

$$\boldsymbol{f}_2 \circ \boldsymbol{f}_1 \in \mathcal{F}(L_1 + L_2, \boldsymbol{p}_3), \qquad \boldsymbol{p}_3 := (p_{1,0}, \ldots, p_{1,L_1}, p_{2,1}, \ldots, p_{2,L_2+1}) \in \mathbb{N}^{L_1+L_2+2}.$$

为说明这一点，设

$$\boldsymbol{f}_1(\cdot) = \boldsymbol{A}^{(1)}_{L_1+1} \circ \boldsymbol{\sigma} \circ \boldsymbol{A}^{(1)}_{L_1} \circ \boldsymbol{\sigma} \circ \cdots \circ \boldsymbol{A}^{(1)}_{2} \circ \boldsymbol{\sigma} \circ \boldsymbol{A}^{(1)}_{1}(\cdot),$$

$$\boldsymbol{f}_2(\cdot) = \boldsymbol{A}^{(2)}_{L_2+1} \circ \boldsymbol{\sigma} \circ \boldsymbol{A}^{(2)}_{L_2} \circ \boldsymbol{\sigma} \circ \cdots \circ \boldsymbol{A}^{(2)}_{2} \circ \boldsymbol{\sigma} \circ \boldsymbol{A}^{(2)}_{1}(\cdot).$$

于是

$$\boldsymbol{f}_2 \circ \boldsymbol{f}_1(\cdot) = \boldsymbol{A}^{(2)}_{L_2+1} \circ \boldsymbol{\sigma} \circ \cdots \circ \boldsymbol{A}^{(2)}_2 \circ \boldsymbol{\sigma} \circ \left(\boldsymbol{A}^{(2)}_1 \circ \boldsymbol{A}^{(1)}_{L_1+1}\right) \circ \boldsymbol{\sigma} \circ \cdots \circ \boldsymbol{A}^{(1)}_2 \circ \boldsymbol{\sigma} \circ \boldsymbol{A}^{(1)}_1(\cdot)$$

注意 $\boldsymbol{A}^{(2)}_1 \circ \boldsymbol{A}^{(1)}_{L_1+1} : \mathbb{R}^{p_{1,L_1}} \to \mathbb{R}^{p_{2,1}}$ 为仿射函数。

(P3) 神经网络补层： 令 $L_1, L_2 \in \mathbb{N}$ 且 $L_1 < L_2$，令 $\boldsymbol{p}_1 = \left(p_{1,0}, \ldots, p_{1,L_1+1}\right)^\top \in \mathbb{N}^{L_1+2}$、$\boldsymbol{p}_2 = \left(\boldsymbol{p}_1, 2p_{1,L_1+1}, \ldots, 2p_{1,L_1+1}\right)^\top \in \mathbb{N}^{L_2+2}$，且 $s \in \mathbb{N}$。那么 $\mathcal{F}\left(L_1, \boldsymbol{p}_1, s\right) \subseteq \mathcal{F}\left(L_2, \boldsymbol{p}_2, 2s + 2p_{1,L_1+1}\left(L_2 - L_1\right)\right)$。为说明这一点，定义 $\boldsymbol{\phi} \in \mathcal{F}\left(1, \left(p_{1,L_1+1}, 2p_{1,L_1+1}, p_{1,L_1+1}\right)\right)$ 为：对 $\boldsymbol{y} \in \mathbb{R}^{p_{1,L_1+1}}$，$\boldsymbol{\phi}(\boldsymbol{y}) := \boldsymbol{\sigma}(\boldsymbol{y}) - \boldsymbol{\sigma}(-\boldsymbol{y})$，故 $\boldsymbol{\phi}(\boldsymbol{y}) = \boldsymbol{y}$。令 $\boldsymbol{f}_1 \in \mathcal{F}\left(L_1, \boldsymbol{p}_1, s\right)$，定义 $\boldsymbol{f}_2 := \boldsymbol{\phi} \circ \cdots \circ \boldsymbol{\phi} \circ \boldsymbol{f}_1$，其中 $\boldsymbol{\phi}$ 应用 $L_2 - L_1$ 次。于是对所有 $\boldsymbol{x} \in \mathbb{R}^{p_{1,0}}$，$\boldsymbol{f}_1(\boldsymbol{x}) = \boldsymbol{f}_2(\boldsymbol{x})$；由 (P2) 及参数计数，$\boldsymbol{f}_2 \in \mathcal{F}\left(L_2, \boldsymbol{p}_2, 2s + 2p_{1,L_1+1}\left(L_2 - L_1\right)\right)$。

(P4) 神经网络并行化： 令 $N, L \in \mathbb{N}$，且对 $i \in [N]$，$\boldsymbol{f}_i \in \mathcal{F}\left(L, \boldsymbol{p}_i, s_i\right)$，其中 $\boldsymbol{p}_i = \left(d, p_{i,1}, \ldots, p_{i,L+1}\right)^\top \in \mathbb{N}^{L+2}$、$s_i \in \mathbb{N}$。记 $\boldsymbol{f}(\cdot) = \left(\boldsymbol{f}_1(\cdot)^\top, \ldots, \boldsymbol{f}_N(\cdot)^\top\right)^\top$，由定义有

$$\boldsymbol{f} \in \mathcal{F}\left(L, \left(d, \sum_{i=1}^N p_{i,1}, \ldots, \sum_{i=1}^N p_{i,L+1}\right), \sum_{i=1}^N s_i\right).$$

附录 B 稀疏神经网络的覆盖数界

命题 1 中关于稀疏神经网络估计量超额风险的预言机不等式，依赖于本节推导的相关函数类覆盖数界。事实上，证明通过该类的伪维数界展开，而伪维数又与 Vapnik–Chervonenkis（VC）维数有关，因此先定义所需概念。

定义 5。 令 $\mathcal{H}$ 为从 $\mathcal{X} \subseteq \mathbb{R}^d$ 到 $\{0, 1\}$ 的函数集合。对 $m \in \mathbb{N}$，**打散系数**定义为

$$\operatorname{shat}(\mathcal{H}, m) := \max_{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_m \in \mathcal{X}} \left|\left\{\left(h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_m)\right) : h \in \mathcal{H}\right\}\right|.$$

$\mathcal{H}$ 的 **VC 维数**定义为

$$\operatorname{VCdim}(\mathcal{H}) := \sup\{m \in \mathbb{N} : \operatorname{shat}(\mathcal{H}, m) = 2^m\}.$$

定义符号函数 $\operatorname{sgn} : \mathbb{R} \to \{0, 1\}$ 为 $\operatorname{sgn}(x) := \mathbf{1}_{\{x>0\}}$。[8] 若 $\mathcal{F}$ 为实值函数类，则定义 $\operatorname{sgn} \circ \mathcal{F} := \{\operatorname{sgn} \circ f : f \in \mathcal{F}\}$。

定义 6。 令 $\mathcal{F}$ 为从 $\mathcal{X} \subseteq \mathbb{R}^d$ 到 $\mathbb{R}$ 的函数集合。$\mathcal{F}$ 的**伪维数**定义为

$$\operatorname{Pdim}(\mathcal{F}) := \operatorname{VCdim}\left(\left\{(\boldsymbol{x}, y) \mapsto \operatorname{sgn}\left(f(\boldsymbol{x}) - y\right) : f \in \mathcal{F}\right\}\right).$$

对 $\epsilon > 0$，若函数集合 $g_1, \ldots, g_N : \mathcal{X} \to \mathbb{R}$ 满足：每个 $f \in \mathcal{F}$ 都存在 $j = j(f) \in [N]$，使 $\| f - g_j \|_{L^q(\mu)} \le \epsilon$，则称它是 $\mathcal{F}$ 关于 $\| \cdot \|_{L^q(\mu)}$ 的一个 ϵ-覆盖。$\mathcal{F}$ 关于该范数的 ϵ-**覆盖数**记为 $\mathcal{N}\big(\epsilon, \mathcal{F}, \| \cdot \|_{L^q(\mu)}\big)$，定义为最小 ϵ-覆盖的基数（若不存在有限覆盖，则覆盖数为 ∞）。

下面命题给出 $\mathcal{F}(L, \boldsymbol{p}, s)$ 类的 VC 维数与覆盖数上界。证明基于 Bartlett et al.（2019，定理 7），该结果给出 $\mathcal{F}(L, \boldsymbol{p})$ 类的 VC 维数上界。另需指出，Schmidt-Hieber（2020，引理 5）等已得到 $\{f \in \mathcal{F}(L, \boldsymbol{p}, s) : \| \Theta(\boldsymbol{f}) \|_\infty \le 1\}$ 类的覆盖数上界；但这些结果并不蕴含其 VC 维数上界，也无法推广至 $\mathcal{F}(L, \boldsymbol{p}, s)$ 类。

命题 4。设 $L \in \mathbb{N}$，$\boldsymbol{p} = (p_0, \ldots, p_{L+1})^\top \in \mathbb{N}^{L+2}$ 且 $p_{L+1} = 1$，令 $V := \sum_{\ell=1}^{L+1} p_\ell (p_{\ell-1} + 1)$，$s \in [V]$。

(a) 有

$$\begin{aligned} \mathrm{VCdim}\big(\mathrm{sgn} \circ \mathcal{F}(L, \boldsymbol{p}, s)\big) &\le \mathrm{Pdim}\big(\mathcal{F}(L, \boldsymbol{p}, s)\big) \\ &\le 6s(L+1)\log_2(3s) + 2s\log_2(2p_0) \\ &\lesssim sL\log(es) + s\log(ep_0). \end{aligned}$$

(b) 对 $q \in [1, \infty)$、$B > 0$、$\epsilon \in (0, B/2)$ 及 $\mathbb{R}^d$ 上任意概率测度 μ，有

$$\begin{aligned} \log \mathcal{N}\big(\epsilon, T_B \circ \mathcal{F}(L, \boldsymbol{p}, s), \| \cdot \|_{L_q(\mu)}\big) &\le 2q \cdot \mathrm{Pdim}\big(\mathcal{F}(L, \boldsymbol{p}, s)\big) \log(10B/\epsilon) \\ &\lesssim q\big\{sL\log(es) + s\log(ep_0)\big\}\log(B/\epsilon). \end{aligned}$$

由 Bartlett et al.（2019，定理 3），存在通用常数 $C_3 > 0$，使当 $s \ge C_3 L \ge C_3^2$ 时，存在 $\boldsymbol{p}' = (p'_0, \ldots, p'_{L+1})^\top \in \mathbb{N}^{L+2}$，满足 $V' := \sum_{\ell=1}^{L+1} p'_\ell (p'_{\ell-1} + 1) \le s$，并且对某个通用常数 $c_4 > 0$ 有 $\mathrm{VCdim}\big(\mathrm{sgn} \circ \mathcal{F}(L, \boldsymbol{p}')\big) \ge c_4 sL\log(s/L)$。由 (P1)，对所有逐坐标满足 $\boldsymbol{p} \ge \boldsymbol{p}'$ 的 $\boldsymbol{p} \in \mathbb{N}^{L+2}$，有 $\mathcal{F}(L, \boldsymbol{p}') \subseteq \mathcal{F}(L, \boldsymbol{p}, s)$，因此同一下界也适用于 $\mathrm{VCdim}\big(\mathrm{sgn} \circ \mathcal{F}(L, \boldsymbol{p}, s)\big)$。所以在上述关于 s, L 的条件下，若 $\boldsymbol{p}$ 足够大，命题 4(a) 的上界除 n 的一个对数因子外是紧致的。

证明。(a) 首先注意

$$\begin{aligned} \mathrm{Pdim}\big(\mathcal{F}(L, \boldsymbol{p}, s)\big) &= \mathrm{VCdim}\big(\big\{(\boldsymbol{x}, y) \mapsto \mathrm{sgn}\big(f(\boldsymbol{x}) - y\big) : f \in \mathcal{F}(L, \boldsymbol{p}, s)\big\}\big) \\ &\ge \mathrm{VCdim}\big(\big\{\boldsymbol{x} \mapsto \mathrm{sgn}\big(f(\boldsymbol{x})\big) : f \in \mathcal{F}(L, \boldsymbol{p}, s)\big\}\big) \\ &= \mathrm{VCdim}\big(\mathrm{sgn} \circ \mathcal{F}(L, \boldsymbol{p}, s)\big). \end{aligned}$$

记 $\widetilde{\boldsymbol{p}} := (p_0, p_1 \wedge s, \ldots, p_L \wedge s, p_{L+1})^\top$。由 Schmidt-Hieber（2020，式 (19)），$\mathcal{F}(L, \boldsymbol{p}, s) = \mathcal{F}(L, \widetilde{\boldsymbol{p}}, s)$。定义从 $\mathbb{R}^{p_0} \times \mathbb{R}$ 到 $\mathbb{R}$ 的函数类 $\mathcal{H} := \{(\boldsymbol{x}, y) \mapsto \mathrm{sgn}\big(f(\boldsymbol{x}) - y\big) : f \in \mathcal{F}(L, \widetilde{\boldsymbol{p}}, s), \gamma \in \mathbb{R}\}$。则 $\mathrm{Pdim}\big(\mathcal{F}(L, \boldsymbol{p}, s)\big) = \mathrm{VCdim}(\mathcal{H})$，故只需为 $m := \mathrm{VCdim}(\mathcal{H})$ 给出上界。若 $m < s$，由于命题右

端至少为 s，结论 (a) 即成立。因此不失一般性可假定 $m \geq s$。设 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_m, y_m) \in \mathbb{R}^{p_0} \times \mathbb{R}$ 被 $\mathcal{H}$ 打散。令 $\widetilde{V} := \sum_{\ell=1}^{L+1} \widetilde{p}_\ell (\widetilde{p}_{\ell-1} + 1)$ 为 $\mathcal{F}(L, \widetilde{\boldsymbol{p}}, s)$ 中神经网络的参数总数。对 $\boldsymbol{x} \in \mathbb{R}^{p_0}$ 与 $\theta \in \{\theta' \in \mathbb{R}^{\widetilde{V}} : \| \theta' \|_0 \leq s\} =: B_0^{\widetilde{V}}(s)$，若 $f \in \mathcal{F}(L, \widetilde{\boldsymbol{p}}, s)$ 满足 $\Theta(f) = \theta$，则令 $g(\boldsymbol{x}, \theta) := f(\boldsymbol{x})$。也就是说，$g(\cdot, \theta)$ 是参数向量为 θ 的神经网络，故 $\mathcal{F}(L, \widetilde{\boldsymbol{p}}, s) = \{g(\cdot, \theta) : \theta \in B_0^{\widetilde{V}}(s)\}$。将 $B_0^{\widetilde{V}}(s)$ 划分为 $B_1, \ldots, B_{\binom{\widetilde{V}}{s}}$，每个 B_i 中的元素都支撑在同一个大小为 s 的集合上。由 m 的定义，

$$
\begin{aligned}
2^m &= \left| \left\{ \left(\operatorname{sgn}\big(g(\boldsymbol{x}_1, \boldsymbol{\theta}) - y_1\big), \ldots, \operatorname{sgn}\big(g(\boldsymbol{x}_m, \boldsymbol{\theta}) - y_m\big) \right)^\top : \boldsymbol{\theta} \in \mathbb{B}_0^{\widetilde{V}}(s) \right\} \right| \\
&\leq \sum_{i=1}^{\binom{\widetilde{V}}{s}} \left| \left\{ \left(\operatorname{sgn}\big(g(\boldsymbol{x}_1, \boldsymbol{\theta}) - y_1\big), \ldots, \operatorname{sgn}\big(g(\boldsymbol{x}_m, \boldsymbol{\theta}) - y_m\big) \right)^\top : \boldsymbol{\theta} \in B_i \right\} \right| =: \sum_{i=1}^{\binom{\widetilde{V}}{s}} K_i. \qquad (4)
\end{aligned}
$$

我们将证明 $K_1, \ldots, K_{\binom{\widetilde{V}}{s}}$ 的上界，从而导出 m 的上界。为此，不失一般性只对 K_1 求上界。对 $\ell \in [L+1]$、$\boldsymbol{x} \in \mathbb{R}^{p_0}$、$\theta \in B_1$，定义 $\boldsymbol{g}^{(\ell)}(\boldsymbol{x}, \theta) := \boldsymbol{A}_\ell \circ \sigma \circ \cdots \circ \sigma \circ \boldsymbol{A}_1(\boldsymbol{x})$，其中 $\boldsymbol{A}_1, \ldots, \boldsymbol{A}_{L+1}$ 按式 (1) 类似定义（但将各 p_ℓ 替换为 $\widetilde{p}_\ell$），权重矩阵与偏置向量取自 θ 的相应分量。对 $\ell \in [L+1]$、$u \in [\widetilde{p}_\ell]$，令 $g_u^{(\ell)}$ 为 $\boldsymbol{g}^{(\ell)}$ 的第 u 个坐标函数；令 $\mathcal{U}_\ell := \{u \in [\widetilde{p}_\ell] : g_u^{(\ell)}(\cdot, \theta) \neq 0 \text{ for some } \theta \in B_1\}$ 为第 ℓ 层活跃神经元的坐标集合（其中要求存在某个 $\theta \in B_1$ 使该坐标函数不为零），并令 $k_\ell := |\mathcal{U}_\ell|$。若某个 $\ell \in [L+1]$ 有 $k_\ell = 0$，则对所有 $\theta \in B_1$，$g(\cdot, \theta) = 0$，故 $K_1 = 1$。现假定所有 $\ell \in [L+1]$ 都有 $k_\ell \geq 1$。我们构造 B_1 的有限划分序列 $\mathcal{P}_1, \ldots, \mathcal{P}_{L+1}$，每一个都细化前一个，并满足：

(i) $N_\ell := |\mathcal{P}_\ell|$ 满足 $N_1 = 1$，且对 $\ell \in [L]$，

$$
\frac{N_{\ell+1}}{N_\ell} \leq 2 \left(\frac{2em\ell k_\ell}{s} \right)^s =: \phi_\ell.
$$

(ii) 对每个 $j \in [m]$、$\ell \in [L+1]$、$P_\ell \in \mathcal{P}_\ell$，映射 $\theta \mapsto \boldsymbol{g}^{(\ell)}(\boldsymbol{x}_j, \theta)$ 在 P_ℓ 上是次数至多为 ℓ 的多项式。

先定义 $\mathcal{P}_1 := \{B_1\}$。由式 (1) 中 $\boldsymbol{A}_1$ 的定义，$\theta \mapsto \boldsymbol{g}^{(1)}(\boldsymbol{x}_j, \theta) = \boldsymbol{A}_1(\boldsymbol{x}_j)$ 在 B_1 上是线性的。现假定已对某个 $\ell \in [L]$ 构造出满足 (i)、(ii) 的 $\mathcal{P}_1, \ldots, \mathcal{P}_\ell$。由归纳假设，$\mathcal{P}_\ell = \{P_{\ell,1}, \ldots, P_{\ell,N_\ell}\}$ 具有如下性质：对每个 $r \in [N_\ell]$、$j \in [m]$、$u \in \mathcal{U}_\ell$，映射 $\theta \mapsto g_u^{(\ell)}(\boldsymbol{x}_j, \theta)$ 在 $P_{\ell,r}$ 上是次数至多为 ℓ、依赖 θ 的至多 s 个坐标的多项式。对固定的 $r \in [N_\ell]$，由 Bartlett et al.（2019，引理 17）及 $m \geq s$，有

$$
\begin{aligned}
&\left| \left\{ \left(\operatorname{sgn}\big(g_u^{(\ell)}(\boldsymbol{x}_j, \boldsymbol{\theta})\big) : u \in [\widetilde{p}_\ell],\, j \in [m] \right) : \boldsymbol{\theta} \in P_{\ell,r} \right\} \right| \\
&\qquad = \left| \left\{ \left(\operatorname{sgn}\big(g_u^{(\ell)}(\boldsymbol{x}_j, \boldsymbol{\theta})\big) : u \in \mathcal{U}_\ell,\, j \in [m] \right) : \boldsymbol{\theta} \in P_{\ell,r} \right\} \right| \leq \phi_\ell.
\end{aligned}
$$

因此，对每个 $r \in [N_\ell]$，可将 $P_{\ell,r}$ 划分为区域 $R_{r,1}, \ldots, R_{r,\phi_\ell}$，使对每个 $t \in [\phi_\ell]$，映射 $\theta \mapsto \big(\operatorname{sgn}\big(g_u^{(\ell)}(\boldsymbol{x}_j, \theta)\big) : u \in [\widetilde{p}_\ell],\ j \in [m]\big)$ 在 $R_{r,t}$ 上为常数。再定义 $\mathcal{P}_{\ell+1} := \{R_{r,t} : r \in [N_\ell],\ t \in [\phi_\ell]\}$。根据构造，$\mathcal{P}_{\ell+1}$ 满足性质 (i)。此外，记 $\boldsymbol{\xi}_{\boldsymbol{x}_j,\theta} := \big(\operatorname{sgn}\big(g_u^{(\ell)}(\boldsymbol{x}_j, \theta)\big) : u \in [\widetilde{p}_\ell]\big)^\top \in \{0, 1\}^{\widetilde{p}_\ell}$，则

$$\boldsymbol{g}^{(\ell+1)}(\boldsymbol{x}_j, \boldsymbol{\theta}) = \boldsymbol{A}_{\ell+1} \circ \boldsymbol{\sigma} \circ \boldsymbol{g}^{(\ell)}(\boldsymbol{x}_j, \boldsymbol{\theta}) = \boldsymbol{A}_{\ell+1}\big(\operatorname{diag}(\boldsymbol{\xi}_{\boldsymbol{x}_j,\boldsymbol{\theta}})\boldsymbol{g}^{(\ell)}(\boldsymbol{x}_j, \boldsymbol{\theta})\big).$$

对每个 $j \in [m]$、$r \in [N_\ell]$、$t \in [\phi_\ell]$，当 $\theta \in R_{r,t}$ 时，符号向量 $\boldsymbol{\xi}_{\boldsymbol{x}_j,\theta}$ 恒定，因此 $\theta \mapsto \boldsymbol{g}^{(\ell+1)}\big(\boldsymbol{x}_j, \theta\big)$ 在 $R_{r,t}$ 上是次数至多为 $\ell + 1$ 的多项式。这验证了 $\ell + 1$ 的性质 (ii)，完成归纳。

接着，由性质 (ii)，对每个 $j \in [m]$、$P_L \in \mathcal{P}_L$，映射 $\theta \mapsto g\big(\boldsymbol{x}_j, \theta\big) - y_j = \boldsymbol{g}^{(L+1)}\big(\boldsymbol{x}_j, \theta\big) - y_j$ 在 P_L 上是次数至多为 L、至多依赖 θ 的 s 个坐标的多项式。因此再次由 Bartlett et al.（2019，引理 17），

$$\Big|\Big\{\Big(\operatorname{sgn}\big(g(\boldsymbol{x}_1, \boldsymbol{\theta}) - y_1\big), \ldots, \operatorname{sgn}\big(g(\boldsymbol{x}_m, \boldsymbol{\theta}) - y_m\big)\Big)^\top : \boldsymbol{\theta} \in P_L\Big\}\Big| \le 2\left(\frac{2emL}{s}\right)^s. \tag{5}$$

由性质 (i) 还有

$$|\mathcal{P}_L| \le 2^L \prod_{\ell=1}^{L}\left(\frac{2em\ell k_\ell}{s}\right)^s. \tag{6}$$

结合式 (5)、(6)，得

$$\begin{aligned} K_1 &\le 2^{L+1}\left(\frac{2emL}{s}\right)^s \prod_{\ell=1}^{L}\left(\frac{2em\ell k_\ell}{s}\right)^s = 2^{L+1}\left(\frac{2em}{s}\right)^{s(L+1)}\left(\prod_{\ell=1}^{L}\ell k_\ell\right)^s \\ &\le 2^{L+1}\left(\frac{2em}{s}\right)^{s(L+1)}\left(\frac{1}{L}\sum_{\ell=1}^{L}\ell k_\ell\right)^{sL} \le 2^{L+1}(2em)^{s(L+1)}, \end{aligned}$$

其中第二个不等式使用算术—几何平均不等式，最后一个界利用 $\sum_{\ell=1}^{L} k_\ell \le s$。于是由式 (4) 推得

$$2^m \le \binom{\widetilde{V}}{s} \cdot 2^{L+1}(2em)^{s(L+1)} \le \big(4em\widetilde{V}^{1/(L+1)}\big)^{s(L+1)}.$$

由引理 12，由于 $4e\widetilde{V}^{1/(L+1)} \ge 4$，有

$$\begin{aligned} m &\le 2s(L+1)\log_2\big(4es(L+1)\widetilde{V}^{1/(L+1)}\big) \\ &\le 2s(L+1)\log_2\big(8es^3(2p_0)^{1/(L+1)}\big) \le 6s(L+1)\log_2(3s) + 2s\log_2(2p_0), \end{aligned}$$

第二个不等式成立，是因为根据所有 $\ell \in [L+1]$ 上 $k_\ell \geq 1$ 的假设，有 $L+1 \leq s$，且

$$\widetilde{V} \leq (L-1)s(s+1) + (p_0+1)s + s + 1 \leq 2(L+1)s^2 + p_0 s \leq 2p_0(2s)^{L+1}.$$

(b) 若 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_m, y_m) \in \mathbb{R}^{p_0} \times \mathbb{R}$ 被 $\{(\boldsymbol{x}, y) \mapsto \operatorname{sgn}\big(T_B f(\boldsymbol{x}) - y\big) : f \in \mathcal{F}\big(L, \boldsymbol{p}, s\big)\}$ 打散，则对所有 $j \in [m]$ 必有 $y_j \in [-B, B)$。因此这些点也被 $\{(\boldsymbol{x}, y) \mapsto \operatorname{sgn}\big(f(\boldsymbol{x}) - y\big) : f \in \mathcal{F}\big(L, \boldsymbol{p}, s\big)\}$ 打散，故 $\operatorname{Pdim}\big(T_B \circ \mathcal{F}\big(L, \boldsymbol{p}, s\big)\big) \leq \operatorname{Pdim}\big(\mathcal{F}\big(L, \boldsymbol{p}, s\big)\big)$。由 Györfi et al.（2006，定理 9.4），由于 $\operatorname{Pdim}\big(T_B \circ \mathcal{F}\big(L, \boldsymbol{p}, s\big)\big) \geq 2$，有

$$\begin{aligned}\mathcal{N}\big(\epsilon, T_B \circ \mathcal{F}(L, \boldsymbol{p}, s), \|\cdot\|_{L_q(\mu)}\big) &\leq 3\left\{\frac{2e(2B)^q}{\epsilon^q}\log\left(\frac{3e(2B)^q}{\epsilon^q}\right)\right\}^{\operatorname{Pdim}(T_B \circ \mathcal{F}(L,\boldsymbol{p},s))} \\ &\leq \left(\frac{10B}{\epsilon}\right)^{2q \cdot \operatorname{Pdim}(\mathcal{F}(L,\boldsymbol{p},s))}.\end{aligned}$$

取对数并应用 (a)，即得所需结果。

附录 C 命题 1 的证明

命题 1 的证明。 对 $i = 0, 1, \ldots, n$，令 $\widetilde{\boldsymbol{Z}}_i := (\boldsymbol{Z}_i, \boldsymbol{\Omega}_i)$、$f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) := \mathbb{E}\big(T_{B_n} Y_i \mid \widetilde{\boldsymbol{Z}}_i\big)$。则

$$\begin{aligned}\mathbb{E}\big\{R(T_{B_n}\widetilde{f}) - R(f^\star)\big\} &= \mathbb{E}\big\{\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_0) - Y_0\big)^2 - \big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2\big\} \\ &\quad + \mathbb{E}\big\{\big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 - \big(f^\star(\widetilde{\boldsymbol{Z}}_0) - Y_0\big)^2\big\} \\ &\quad + \mathbb{E}\Bigg[\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 \\ &\qquad - \frac{2}{n}\sum_{i=1}^n\Big\{\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2\Big\}\Bigg] \\ &\quad + \mathbb{E}\Bigg[\frac{2}{n}\sum_{i=1}^n\Big\{\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2 - \big(f^\star(\widetilde{\boldsymbol{Z}}_i) - Y_i\big)^2\Big\}\Bigg] \\ &\quad + \mathbb{E}\Bigg[\frac{2}{n}\sum_{i=1}^n\Big\{\big(f^\star(\widetilde{\boldsymbol{Z}}_i) - Y_i\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2\Big\}\Bigg] \\ &=: E_1 + E_2 + E_3 + E_4 + E_5.\end{aligned}$$

控制 E_1： 由引理 13，

$$E_1 \leq \mathbb{E}\big\{Y_0^2 - (T_{B_n}Y_0)^2\big\} + 2B_n\mathbb{E}\big\{|Y_0 - T_{B_n}Y_0|\big\} \leq \frac{5\xi^2}{n}. \tag{7}$$

控制 $E_2 + E_5$： 注意 $E_5 = -2E_2$，因此由引理 13，

$$
\begin{aligned}
E_2 + E_5 &= \mathbb{E}\big\{\big(f^\star(\widetilde{\boldsymbol{Z}}_0) - Y_0\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2\big\} \\
&= \mathbb{E}\big\{\big(f^\star(\widetilde{\boldsymbol{Z}}_0)\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0)\big)^2\big\} + \mathbb{E}\big\{Y_0^2 - (T_{B_n}Y_0)^2\big\} \\
&\qquad - 2\mathbb{E}\big\{f^\star(\widetilde{\boldsymbol{Z}}_0)\cdot Y_0 - f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0)\cdot T_{B_n}Y_0\big\} \le \frac{13\xi^2}{n}. \quad (8)
\end{aligned}
$$

控制 E_3： 对 $(\boldsymbol{u}_1, \boldsymbol{v}_1), \ldots, (\boldsymbol{u}_n, \boldsymbol{v}_n) \in \mathbb{R}^d \times \mathbb{R}^d$，令 P_n 为它们的经验测度，并令

$$
\mathcal{N}_{1,n} := \sup_{(\boldsymbol{u}_i,\boldsymbol{v}_i)_{i=1}^n \in (\mathbb{R}^d\times\mathbb{R}^d)^n} \mathcal{N}\big((80B_n n)^{-1},\, T_{B_n}\circ\mathcal{F},\, \|\cdot\|_{L_1(\mathbb{P}_n)}\big).
$$

取 $\delta := 24\cdot 214 B_n^4 \log\big(14\mathcal{N}_{1,n}\big)/n \ge 1/n$，有

$$
\begin{aligned}
E_3 &= \mathbb{E}\Bigg[\mathbb{E}\Big\{\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 \;\Big|\; \mathcal{D}\Big\} \\
&\qquad - \frac{2}{n}\sum_{i=1}^n\Big\{\big(T_{B_n}\widetilde{f}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2\Big\}\Bigg] \\
&\le \mathbb{E}\Bigg(\sup_{g\in T_{B_n}\circ\mathcal{F}(L,\boldsymbol{p},s)}\Bigg[\mathbb{E}\Big\{\big(g(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2\Big\} \\
&\qquad - \frac{2}{n}\sum_{i=1}^n\Big\{\big(g(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2\Big\}\Bigg]\Bigg) \\
&\le \delta + \int_\delta^\infty \mathbb{P}\Bigg(\sup_{g\in T_{B_n}\circ\mathcal{F}(L,\boldsymbol{p},s)}\Big[\mathbb{E}\big\{\big(g(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_0) - T_{B_n}Y_0\big)^2\big\} \\
&\qquad - \frac{2}{n}\sum_{i=1}^n\big\{\big(g(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2 - \big(f^\star_{B_n}(\widetilde{\boldsymbol{Z}}_i) - T_{B_n}Y_i\big)^2\big\}\Big] > t\Bigg)\,\mathrm{d}t \\
&\overset{(i)}{\le} \delta + 14\mathcal{N}_{1,n}\int_\delta^\infty \exp\Big(-\frac{nt}{24\cdot 214B_n^4}\Big)\,\mathrm{d}t \\
&= \delta + 14\mathcal{N}_{1,n}\cdot\frac{24\cdot 214B_n^4}{n}\exp\Big(-\frac{n\delta}{24\cdot 214B_n^4}\Big) \\
&\le \frac{24\cdot 214B_n^4\log(14\mathcal{N}_{1,n})}{n} + \frac{24\cdot 214B_n^4}{n} \\
&\overset{(ii)}{\lesssim} \frac{\xi^4\log(e\xi)\log^3 n\cdot\big(sL\log(es) + s\log(ed)\big)}{n}, \qquad (9)
\end{aligned}
$$

其中 (i) 使用 Györfi et al.（2006，定理 11.4），并在该定理中取 $\epsilon = 1/2$、$\alpha = \beta = t/2$；(ii) 使用命题 4(b)。

控制 E_4： $\mathcal{F}$ 中函数由欧氏空间的子集 A 参数化，即可写作 $\mathcal{F} = \{f_\theta : \theta \in A\}$。由于 A 具有可数稠密子集 $\widetilde{A}$（如 Royden and Fitzpatrick, 2010，命题 9.26），而映射 $\theta \mapsto \widehat{R}_n(f_\theta)$ 连续，所以 $\inf_{\theta\in A}\widehat{R}_n(f_\theta) = \inf_{\theta\in\widetilde{A}}\widehat{R}_n(f_\theta)$。因此 $\inf_{f\in\mathcal{F}}\widehat{R}_n(f)$ 可测，且

$$
\begin{aligned}
E_4 &\le \mathbb{E}\left[\frac{2}{n}\sum_{i=1}^{n}\left\{\left(\widetilde{f}(\widetilde{\boldsymbol{Z}}_i)-Y_i\right)^2-\left(f^\star(\widetilde{\boldsymbol{Z}}_i)-Y_i\right)^2\right\}\right] \\
&= 2\mathbb{E}\left\{\widehat{R}_n(\widetilde{f})-\inf_{f\in\mathcal{F}}\widehat{R}_n(f)\right\}+2\mathbb{E}\left\{\inf_{f\in\mathcal{F}}\widehat{R}_n(f)-\widehat{R}_n(f^\star)\right\} \\
&\le 2\mathbb{E}\left\{\widehat{R}_n(\widetilde{f})-\inf_{f\in\mathcal{F}}\widehat{R}_n(f)\right\}+2\inf_{f\in\mathcal{F}}\mathbb{E}\left\{\widehat{R}_n(f)-\widehat{R}_n(f^\star)\right\} \\
&= 2\mathbb{E}\left\{\widehat{R}_n(\widetilde{f})-\inf_{f\in\mathcal{F}}\widehat{R}_n(f)\right\}+2\inf_{f\in\mathcal{F}}\mathbb{E}\left\{\left(f(\widetilde{\boldsymbol{Z}}_0)-Y_0\right)^2-\left(f^\star(\widetilde{\boldsymbol{Z}}_0)-Y_0\right)^2\right\} \\
&= 2\mathbb{E}\left\{\widehat{R}_n(\widetilde{f})-\inf_{f\in\mathcal{F}}\widehat{R}_n(f)\right\}+2\inf_{f\in\mathcal{F}}\mathbb{E}\left\{\left(f(\widetilde{\boldsymbol{Z}}_0)-f^\star(\widetilde{\boldsymbol{Z}}_0)\right)^2\right\}. \qquad (10)
\end{aligned}
$$

结合式 (7)、(8)、(9)、(10)，得到最终结果。

附录 D 集合 $\mathcal{S}$ 的划分的可分离性

命题 5。设 $\mathcal{S}\subseteq\{0,1\}^d$ 且 $|\mathcal{S}|\ge 2$，令 $K\in\{2,\ldots,|\mathcal{S}|\}$，$\{\mathcal{S}_1,\ldots,\mathcal{S}_K\}$ 为 $\mathcal{S}$ 的划分。

(a) 假定存在 $\mathcal{J}\subseteq[d]$，使只要 $\boldsymbol{\omega}_{\mathcal{J}}=\boldsymbol{\omega}'_{\mathcal{J}}$，$\boldsymbol{\omega},\boldsymbol{\omega}'\in\mathcal{S}$ 就属于同一个划分单元。令 $\mathcal{S}_{\mathcal{J}}:=\{\boldsymbol{\omega}_{\mathcal{J}}:\boldsymbol{\omega}\in\mathcal{S}\}\subseteq\{0,1\}^{|\mathcal{J}|}$。定义 $p_\star:=2\lceil|\mathcal{S}_{\mathcal{J}}|^{1/2}\rceil$、$\boldsymbol{p}:=(d,p_\star,p_\star,1)^\top\in\mathbb{N}^4$。则 $\{\mathcal{S}_1,\ldots,\mathcal{S}_K\}$ 为 $\mathcal{F}(2,\boldsymbol{p})$-可分离。特别地，若 $\mathcal{S}_1,\ldots,\mathcal{S}_K$ 是 $\mathcal{S}$ 的任意划分，可取 $\mathcal{J}=[d]$。

(b) 假定对每个 $k\in[K]$，存在 $P_k\in\mathbb{N}$、$\left(\boldsymbol{v}_\ell^{(k)},b_\ell^{(k)}\right)_{\ell\in[P_k]}\in\left(\mathbb{R}^d\times\mathbb{R}\right)^{P_k}$，使 $\mathcal{S}_k=\{\boldsymbol{\omega}\in\mathcal{S}:\boldsymbol{\omega}^\top\boldsymbol{v}_\ell^{(k)}\le b_\ell^{(k)},\ \forall\,\ell\in[P_k]\}$。定义 $\boldsymbol{p}:=\left(d,2\sum_{k=1}^K P_k,K,1\right)^\top\in\mathbb{N}^4$。则 $\{\mathcal{S}_1,\ldots,\mathcal{S}_K\}$ 为 $\mathcal{F}(2,\boldsymbol{p})$-可分离。

证明。(a) 令 $J:=|\mathcal{J}|$。不失一般性假定 $\mathcal{J}=[J]$，并令 $\mathcal{S}_{\mathcal{J}}=\{\boldsymbol{u}_1,\ldots,\boldsymbol{u}_{|\mathcal{S}_{\mathcal{J}}|}\}\subseteq\{0,1\}^J$。对 $i\in[|\mathcal{S}_{\mathcal{J}}|]$，定义 $x_i:=\sum_{j=1}^J 2^{j-1}u_{ij}\in\mathbb{N}_0$，其中 u_{ij} 为 $\boldsymbol{u}_i$ 的第 j 个坐标。进一步定义 $y_i:=k/K$，其中 $k\in[K]$ 满足存在 $\boldsymbol{\omega}\in\mathcal{S}_k$ 使 $\boldsymbol{\omega}_{\mathcal{J}}=\boldsymbol{u}_i$；根据假设，这个 k 唯一确定。由 Shen, Yang and Zhang（2019，引理 2.2）及 (P1)，存在 $f_1\in\mathcal{F}(2,(1,p_\star,p_\star,1))$，使对所有 $i\in[|\mathcal{S}_{\mathcal{J}}|]$，$f_1(x_i)=y_i$。因此由 (P2)，存在 $f\in\mathcal{F}(2,\boldsymbol{p})$，使对 $\boldsymbol{v}=(v_1,\ldots,v_d)^\top\in\mathbb{R}^d$，

$$
f(\boldsymbol{v})=f_1\Big(\sum_{j=1}^J 2^{j-1}v_j\Big).
$$

对任何 $k\in[K]$、$\boldsymbol{\omega}=(\omega_1,\ldots,\omega_d)^\top\in\mathcal{S}_k$，存在 $i\in[|\mathcal{S}_{\mathcal{J}}|]$ 使 $\boldsymbol{\omega}_{\mathcal{J}}=\boldsymbol{u}_i$，故

$$
f(\boldsymbol{\omega})=f_1\left(\sum_{j=1}^J 2^{j-1}\omega_j\right)=f_1\left(\sum_{j=1}^J 2^{j-1}u_{ij}\right)=f_1(x_i)=\frac{k}{K}.
$$

【译注：原文第 37 页此处将指标范围排印为 $i \in |\mathcal{S}_g|$，未带方括号；本译文按同一证明前文的指标范围补为 $i \in [|\mathcal{S}_g|]$。】

所以 $\mathcal{S}_1, \ldots, \mathcal{S}_K$ 在 $\epsilon = 1/(2K)$ 时具有 $\mathcal{F}(2, \boldsymbol{p})$-可分离性。

(b) 首先定义

$$\epsilon := \min_{k\in[K]} \min_{\boldsymbol{\omega}\in\mathcal{S}\setminus\mathcal{S}_k} \max_{\ell\in[P_k]} \left(\boldsymbol{\omega}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)}\right).$$

对每个 $k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}\setminus\mathcal{S}_k$，根据假设有 $\max_{\ell\in[P_k]}\left(\boldsymbol{\omega}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)}\right) > 0$，故 $\epsilon > 0$。对 $k \in [K]$、$\ell \in [P_k]$，定义 $\phi^{(k,\ell)} \in \mathcal{F}(1, (d, 2, 1))$，对 $\boldsymbol{x} \in \mathbb{R}^d$ 令

$$\phi_{(k,\ell)}(\boldsymbol{x}) := \sigma\left(-\frac{\boldsymbol{x}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)}}{\epsilon} + 1\right) - \sigma\left(-\frac{\boldsymbol{x}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)}}{\epsilon}\right)$$

若 $\boldsymbol{x}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)} \le 0$，则 $\phi^{(k,\ell)}(\boldsymbol{x}) = 1$；若 $\boldsymbol{x}^\top \boldsymbol{v}_\ell^{(k)} - b_\ell^{(k)} \ge \epsilon$，则 $\phi^{(k,\ell)}(\boldsymbol{x}) = 0$。由 (P4)，函数 $\boldsymbol{\phi} : \mathbb{R}^d \to \mathbb{R}^{\sum_{k=1}^K P_k}$，定义为 $\boldsymbol{\phi}(\boldsymbol{x}) := \left(\phi^{(k,\ell)}(\boldsymbol{x})\right)_{k\in[K],\ell\in[P_k]}$，属于 $\mathcal{F}\left(1, \left(d, 2\sum_{k=1}^K P_k, \sum_{k=1}^K P_k\right)\right)$。对 $k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$，有 $\sum_{\ell=1}^{P_k} \phi^{(k,\ell)}(\boldsymbol{\omega}) = P_k$；对所有 $k' \ne k$，有 $\sum_{\ell'=1}^{P_{k'}} \phi^{(k',\ell')}(\boldsymbol{\omega}) \le P_{k'} - 1$，因为存在 $\ell^\star \in [P_{k'}]$，使 $\boldsymbol{\omega}^\top \boldsymbol{v}_{\ell^\star}^{(k')} - b_{\ell^\star}^{(k')} \ge \epsilon$。接着定义 $\psi \in \mathcal{F}\left(1, \left(\sum_{k=1}^K P_k, K, 1\right)\right)$，对 $\boldsymbol{u} = \left(u_{k,\ell}\right)_{k\in[K],\ell\in[P_k]} \in \mathbb{R}^{\sum_{k=1}^K P_k}$，令

$$\psi(\boldsymbol{u}) := \sum_{k=1}^K k \cdot \sigma\left(\sum_{\ell=1}^{P_k} u_{k,\ell} - P_k + 1\right)$$

则对 $k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$，有 $\psi\left(\boldsymbol{\phi}(\boldsymbol{\omega})\right) = k$。最后，由 (P2)，$\psi \circ \boldsymbol{\phi} \in \mathcal{F}(2, \boldsymbol{p})$，所以 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 具有 $\mathcal{F}(2, \boldsymbol{p})$-可分离性。

附录 E 神经网络的逼近理论

下面的引理沿用 Lu et al.（2021，定理 2.2）和 Jiao et al.（2023，定理 3.3）的论证，仅作非常细微的修改。

引理 6。设 $\beta, \gamma > 0$、$\beta_0 := \lceil\beta\rceil - 1$、$d \in \mathbb{N}$，且 $g \in \mathcal{H}_d^\beta\left([0,1]^d, \gamma\right)$。对任意 $M, N \in \mathbb{N}$，令 R、L、p_* 以及 $\boldsymbol{p}$ 如下：

$$R := \lfloor N^{1/d}\rfloor^2 \lfloor M^{2/d}\rfloor, \quad L := 12(\beta_0+1)^2(M+2)\lceil\log_2(4M)\rceil,$$
$$p_* := 30(\beta_0+1)^2 d^{\beta_0+1}(N+1)\lceil\log_2(8N)\rceil \quad \textit{and} \quad \boldsymbol{p} := (d, p_*, \ldots, p_*, 1)^\top \in \mathbb{N}^{L+2}.$$

对 $\delta > 0$，令

$$\Gamma\big([0,1]^d, R, \delta\big) \coloneqq \bigcup_{j=1}^{d}\left\{\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in [0,1]^d : x_j \in \bigcup_{r=1}^{R-1}\left(\frac{r}{R} - \delta,\ \frac{r}{R}\right)\right\}.$$

那么，对任意 $\delta \in (0,\ 1/(3R)]$，存在 $f \in \mathcal{F}\big(L,\ \boldsymbol{p}\big)$，使得对所有 $\boldsymbol{x} \in \mathbb{R}^d$ 都有 $|f(\boldsymbol{x})| \le \gamma$，且对所有 $\boldsymbol{x} \in [0,\ 1]^d \backslash \Gamma\Big([0,\ 1]^d,\ R,\ \delta\Big)$ 都有

$$|f(\boldsymbol{x}) - g(\boldsymbol{x})| \le 9\gamma(\beta_0 + 3)^2 8^\beta d^{\beta_0 + \beta/2}(NM)^{-2\beta/d},$$

证明。步骤 1（离散化）： 由 Lu et al.（2021，命题 4.3），存在 $\phi_1 \in \mathcal{F}\big(4M + 5,\ \big(1,\ p_{*1},\ \ldots,\ p_{*1},\ 1\big)\big)$，其中 $p_{*1} \coloneqq 4\lfloor N^{1/d} \rfloor + 3$，使得对 $r \in \{0,\ 1,\ \ldots,\ R-1\}$，若 x 位于下式给定的区间，则 $\phi_1(x) = r/R$：

$$\phi_1(x) = \frac{r}{R} \quad \text{if } x \in \left[\frac{r}{R},\ \frac{r+1}{R} - \delta \cdot \mathbb{1}_{\{r \le R-2\}}\right] \text{ for } r \in \{0, 1, \ldots, R-1\}.$$

对 $\boldsymbol{v} = \big(v_1,\ \ldots,\ v_d\big)^\top \in \{0,\ 1,\ \ldots,\ R-1\}^d$，定义 $Q_{\boldsymbol{v}}$ 如下，其中所列坐标条件须对所有 $j \in [d]$ 成立：

$$Q_{\boldsymbol{v}} \coloneqq \left\{\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in [0,1]^d : x_j \in \left[\frac{v_j}{R},\ \frac{v_j + 1}{R} - \delta \cdot \mathbb{1}_{\{v_j \le R-2\}}\right] \text{ for all } j \in [d]\right\},$$

于是 $[0,\ 1]^d \backslash \Gamma\Big([0,\ 1]^d,\ R,\ \delta\Big) = \bigcup_{\boldsymbol{v} \in \{0,\ldots,R-1\}^d} Q_{\boldsymbol{v}}$。由性质 (P4)，函数 $\boldsymbol{\phi}_{\mathrm{dsc}} : \mathbb{R}^d \to \mathbb{R}^d$ 属于 $\mathcal{F}\big(4M + 5,\ \big(d,\ dp_{*1},\ \ldots,\ dp_{*1},\ d\big)\big)$，这里对 $\boldsymbol{x} = \big(x_1,\ \ldots,\ x_d\big)^\top$，定义 $\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x}) \coloneqq \big(\phi_1\big(x_1\big),\ \ldots,\ \phi_1\big(x_d\big)\big)^\top$。因此，对所有 $\boldsymbol{x} \in Q_{\boldsymbol{v}}$、$\boldsymbol{v} \in \{0,\ 1,\ \ldots,\ R-1\}^d$，都有

$$\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x}) = \left(\frac{v_1}{R}, \ldots, \frac{v_d}{R}\right)^\top \quad \text{for all } \boldsymbol{x} \in Q_{\boldsymbol{v}},\ \boldsymbol{v} \in \{0, 1, \ldots, R-1\}^d.$$

步骤 2（Taylor 系数的逼近）： 由 $\phi_2(\boldsymbol{x}) \coloneqq \sum_{j=1}^{d} R^j \phi_1\big(x_j\big)$ 给出的函数 $\phi_2 : \mathbb{R}^d \to \mathbb{R}$，是 $\boldsymbol{\phi}_{\mathrm{dsc}}$ 与沿向量 $\big(R,\ R^2,\ \ldots,\ R^d\big)^\top$ 的投影的复合，因此由 (P2)，$\phi_2 \in \mathcal{F}\big(4M + 5,\ \big(d,\ dp_{*1},\ \ldots,\ dp_{*1},\ 1\big)\big)$。此外，对所有 $\boldsymbol{v} \in \{0,\ 1,\ \ldots,\ R-1\}^d$ 和 $\boldsymbol{x} \in Q_{\boldsymbol{v}}$，有

$$\phi_2(\boldsymbol{x}) = \sum_{j=1}^{d} R^{j-1} v_j =: I_{\boldsymbol{v}} \in \{0, 1, \ldots, R^d - 1\}. \tag{11}$$

对满足 $\|\boldsymbol{\alpha}\|_1 \le \beta_0$ 的每个 $\boldsymbol{\alpha} \in \mathbb{N}_0^d$，当 $\boldsymbol{x} \in [0,\,1]^d$ 时，有 $\big(\partial^{\boldsymbol{\alpha}} g(\boldsymbol{x}) + \gamma\big)/\big(2\gamma\big) \in [0,\,1]$。因此，由于 $R^d \le N^2 M^2$，且 $\boldsymbol{v} \mapsto I_{\boldsymbol{v}}$ 是双射，根据 Lu et al.（2021，命题 4.4），存在 $\psi_{\boldsymbol{\alpha}}^{\circ} \in \mathcal{F}\Big(5(M+2)\lceil \log_2(4M)\rceil,\ \big(1,\ p_{*2},\ \ldots,\ p_{*2},\ 1\big)\Big)$，其中 $p_{*2} := 16\big(\beta_0+1\big)(N+1)\lceil \log_2(8N)\rceil$，使得对所有 $\boldsymbol{v} \in \{0,\,1,\,\ldots,\,R-1\}^d$，都有

$$\left|\psi_{\boldsymbol{\alpha}}^{\circ}(I_{\boldsymbol{v}}) - \frac{\partial^{\boldsymbol{\alpha}} g(\boldsymbol{v}/R) + \gamma}{2\gamma}\right| \le (NM)^{-2(\beta_0+1)} \quad \text{for all } \boldsymbol{v} \in \{0,1,\ldots,R-1\}^d. \tag{12}$$

现在，

$$dp_{*1} \vee p_{*2} \le 16d(\beta_0+1)(N+1)\lceil \log_2(8N)\rceil =: p_{*3}$$

并且

$$4M + 5 + 5(M+2)\lceil \log_2(4M)\rceil \le 7(M+2)\lceil \log_2(4M)\rceil =: L_0$$

因此，由性质 (P1)、(P2) 和 (P3)，存在 $\psi_{\boldsymbol{\alpha}} \in \mathcal{F}\big(L_0,\ \big(d,\ p_{*3},\ \ldots,\ p_{*3},\ 1\big)\big)$，使得对所有 $\boldsymbol{x} \in [0,\,1]^d$，有 $\psi_{\boldsymbol{\alpha}}(\boldsymbol{x}) = 2\psi_{\boldsymbol{\alpha}}^{\circ}\big(\phi_2(\boldsymbol{x})\big) - 1 \in [-1,\,1]$。由式 (11) 和 (12)，可知对所有 $\boldsymbol{v} \in \{0,\,1,\,\ldots,\,R-1\}^d$ 和 $\boldsymbol{x} \in Q_{\boldsymbol{v}}$，有

$$\left|\psi_{\boldsymbol{\alpha}}(\boldsymbol{x}) - \frac{1}{\gamma} \cdot \partial^{\boldsymbol{\alpha}} g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\right| \le 2(NM)^{-2(\beta_0+1)}. \tag{13}$$

步骤 3（局部 Taylor 展开）： 由 Lu et al.（2021，引理 4.2），存在 $\phi_{\times} \in \mathcal{F}\big(2\big(\beta_0+1\big)(M+1),\ \big(1,\ 9(N+1)+1,\ \ldots,\ 9(N+1)+1,\ 1\big)\big)$，使得对所有 $x,\,y \in [-1,\,1.1]$，有

$$|\phi_{\times}(x,y) - xy| \le 27(N+1)^{-2(\beta_0+1)(M+1)}. \tag{14}$$

此外，由 Lu et al.（2021，命题 4.1），对满足 $\|\boldsymbol{\alpha}\|_1 \le \beta_0$ 的 $\boldsymbol{\alpha} \in \mathbb{N}_0^d$，存在 $\mathrm{Poly}_{\boldsymbol{\alpha}} \in \mathcal{F}\Big(7\big(\beta_0+1\big)^2 M,\ \big(d,\ 9(N+1)+\beta_0,\ \ldots,\ 9(N+1)+\beta_0,\ 1\big)\Big)$，使得对所有 $\boldsymbol{x} \in [0,\,1]^d$，都有

$$|\mathrm{Poly}_{\boldsymbol{\alpha}}(\boldsymbol{x}) - \boldsymbol{x}^{\boldsymbol{\alpha}}| \le 9(\beta_0+1)(N+1)^{-7(\beta_0+1)M}, \tag{15}$$

而且，由于 $9\big(\beta_0+1\big)(N+1)^{-7(\beta_0+1)M} \le 9\big(\beta_0+1\big)2^{-7(\beta_0+1)} < 0.1$，对所有 $\boldsymbol{x} \in [0,\,1]^d$ 都有 $\mathrm{Poly}_{\boldsymbol{\alpha}}(\boldsymbol{x}) \in [-1,\,1.1]$。现定义 $f^{\circ} : [0,\,1]^d \to \mathbb{R}$ 为

$$f^{\circ}(\boldsymbol{x}) := \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 \le \beta_0} \frac{\gamma}{\boldsymbol{\alpha}!} \cdot \phi_{\times}\Big(\psi_{\boldsymbol{\alpha}}(\boldsymbol{x}),\ \mathrm{Poly}_{\boldsymbol{\alpha}}\big(\boldsymbol{x} - \boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\Big).$$

由于 $\left|\{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\ \|\boldsymbol{\alpha}\|_1\le\beta_0\}\right|=\binom{d+\beta_0}{\beta_0}\le(\beta_0+1)d^{\beta_0}$，由性质 (P1) 至 (P4)，有 $f^\circ\in\mathcal{F}\big(L-1,\ \boldsymbol{p}^\circ\big)$，其中 $\boldsymbol{p}^\circ:=\big(d,\ p_*,\ \ldots,\ p_*,\ 1\big)^{\mathsf{T}}\in\mathbb{N}^{L+1}$。此外，对 $\boldsymbol{v}\in\{0,\ \ldots,\ R-1\}^d$ 和 $\boldsymbol{x}\in Q_{\boldsymbol{v}}$，有

$$
\begin{aligned}
&\left|f^\circ(\boldsymbol{x})-\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\partial^{\boldsymbol{\alpha}}g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)}{\boldsymbol{\alpha}!}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)^{\boldsymbol{\alpha}}\right|\\
&\le\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\gamma}{\boldsymbol{\alpha}!}\cdot\left|\phi_\times\Big(\psi_{\boldsymbol{\alpha}}(\boldsymbol{x}),\,\mathrm{Poly}_{\boldsymbol{\alpha}}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\Big)-\psi_{\boldsymbol{\alpha}}(\boldsymbol{x})\cdot\mathrm{Poly}_{\boldsymbol{\alpha}}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\right|\\
&\quad+\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\gamma}{\boldsymbol{\alpha}!}\cdot\left|\psi_{\boldsymbol{\alpha}}(\boldsymbol{x})-\frac{1}{\gamma}\cdot\partial^{\boldsymbol{\alpha}}g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\right|\cdot\mathrm{Poly}_{\boldsymbol{\alpha}}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)\\
&\quad+\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\partial^{\boldsymbol{\alpha}}g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)}{\boldsymbol{\alpha}!}\Big|\mathrm{Poly}_{\boldsymbol{\alpha}}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)-\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)^{\boldsymbol{\alpha}}\Big|\\
&\le\gamma(\beta_0+1)d^{\beta_0}\big\{27(N+1)^{-2(\beta_0+1)(M+1)}+3(NM)^{-2(\beta_0+1)}+9(\beta_0+1)(N+1)^{-7(\beta_0+1)M}\big\}\\
&\le\gamma(\beta_0+1)(9\beta_0+39)d^{\beta_0}(NM)^{-2(\beta_0+1)},
\end{aligned}
\tag{16}
$$

其中第二个不等式由式 (14)、(13) 和 (15) 得到。因此可知，对 $\boldsymbol{v}\in\{0,\ \ldots,\ R-1\}^d$ 和 $\boldsymbol{x}\in Q_{\boldsymbol{v}}$，有

$$
\begin{aligned}
|f^\circ(\boldsymbol{x})-g(\boldsymbol{x})|&\le\left|f^\circ(\boldsymbol{x})-\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\partial^{\boldsymbol{\alpha}}g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)}{\boldsymbol{\alpha}!}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)^{\boldsymbol{\alpha}}\right|\\
&\quad+\left|g(\boldsymbol{x})-\sum_{\boldsymbol{\alpha}\in\mathbb{N}_0^d:\|\boldsymbol{\alpha}\|_1\le\beta_0}\frac{\partial^{\boldsymbol{\alpha}}g\big(\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)}{\boldsymbol{\alpha}!}\big(\boldsymbol{x}-\boldsymbol{\phi}_{\mathrm{dsc}}(\boldsymbol{x})\big)^{\boldsymbol{\alpha}}\right|\\
&\le\gamma(\beta_0+1)(9\beta_0+39)d^{\beta_0}(NM)^{-2(\beta_0+1)}+\gamma d^{\beta_0}(\sqrt{d}/R)^{\beta}\\
&\le\gamma(\beta_0+1)(9\beta_0+39)d^{\beta_0}(NM)^{-2(\beta_0+1)}+\gamma d^{\beta_0+\beta/2}8^{\beta}(NM)^{-2\beta/d}\\
&\le 9\gamma(\beta_0+3)^2 8^{\beta}d^{\beta_0+\beta/2}(NM)^{-2\beta/d},
\end{aligned}
$$

其中第二个不等式由式 (16) 和引理 14 得到，第三个不等式则来自 $R\ge\frac{1}{8}(NM)^{2/d}$。最后，定义 $f:\mathbb{R}^d\to\big[-\gamma,\ \gamma\big]$ 为

$$
f(\boldsymbol{x}):=\sigma\big(f^\circ(\boldsymbol{x})+\gamma\big)-\sigma\big(f^\circ(\boldsymbol{x})-\gamma\big)-\gamma=T_\gamma f^\circ(\boldsymbol{x}).
$$

由 (P1) 和 (P2)，有 $f\in\mathcal{F}\big(L,\ \boldsymbol{p}\big)$。此外，由于对所有 $\boldsymbol{x}\in[0,\ 1]^d$ 都有 $g(\boldsymbol{x})\in\big[-\gamma,\ \gamma\big]$，对 $\boldsymbol{v}\in\{0,\ \ldots,\ R-1\}^d$ 和 $\boldsymbol{x}\in Q_{\boldsymbol{v}}$，有 $|f(\boldsymbol{x})-g(\boldsymbol{x})|\le|f^\circ(\boldsymbol{x})-g(\boldsymbol{x})|\le 9\gamma\big(\beta_0+3\big)^2 8^{\beta}d^{\beta_0+\beta/2}(NM)^{-2\beta/d}$。□

下一个引理量化了如下逼近程度：对于定义在有界超立方体上、仅依赖部分变量的 Hölder 函数，在沿每个坐标方向剔除有限个条带后，神经网络可以将它逼近到何种程度。

引理 7。设 $-\infty<a<c<\infty$、$\beta,\ \gamma>0$、$\beta_0:=\lceil\beta\rceil-1$、$d\in\mathbb{N}$、$t\in[d]\cup\{0\}$，且 $g\in\mathcal{H}_t^{\beta}\Big([a,\ c]^d,\ \gamma\Big)$。对任意 $M,\ N\in\mathbb{N}$，令 R、L、p_* 以及 $\boldsymbol{p}$ 如下：

$$R \coloneqq \lfloor N^{1/t} \rfloor^2 \lfloor M^{2/t} \rfloor, \quad L \coloneqq 12(\beta_0+1)^2(M+2)\lceil \log_2(4M) \rceil,$$
$$p_* \coloneqq 30(\beta_0+1)^2 t^{\beta_0+1}(N+1)\lceil \log_2(8N) \rceil \vee 1 \quad and \quad \boldsymbol{p} \coloneqq (d, p_*, \ldots, p_*, 1)^\top \in \mathbb{N}^{L+2}.$$

那么，对任意 $\delta \in (0,\ 1/(3R)]$，存在 $f \in \mathcal{F}\big(L,\ \boldsymbol{p}\big)$，使得对所有 $\boldsymbol{x} \in \mathbb{R}^d$ 都有 $|f(\boldsymbol{x})| \le \gamma \vee (c-a)^{\beta_0}\gamma$，且对所有 $\boldsymbol{x} \in [a,\ c]^d \backslash \Gamma\Big([a,\ c]^d,\ R,\ \delta\Big)$ 都有

$$|f(\boldsymbol{x}) - g(\boldsymbol{x})| \le 9\big(1 \vee (c-a)^{\beta_0}\big)\gamma(\beta_0+3)^2 8^\beta t^{\beta_0+\beta/2}(NM)^{-2\beta/t},$$

其中，当 $t \in [d]$ 时，

$$\Gamma\big([a,c]^d, R, \delta\big) \coloneqq \bigcup_{j=1}^{d}\left\{\boldsymbol{x} = (x_1,\ldots,x_d)^\top \in [a,c]^d : \frac{x_j - a}{c-a} \in \bigcup_{r=1}^{R-1}\left(\frac{r}{R} - \delta,\ \frac{r}{R}\right)\right\}$$

当 $t = 0$ 时，则令 $\Gamma\Big([a,\ c]^d,\ R,\ \delta\Big) \coloneqq \varnothing$。

证明。在 $t = 0$ 的情形中，函数 g 是常数，因而属于 $\mathcal{F}\big(L,\ \boldsymbol{p}\big)$，逼近误差为零。下面考虑 $t = d$ 的情形。定义 $h : [0,\ 1]^d \to \mathbb{R}$ 为

$$h(\boldsymbol{x}) \coloneqq g\big(a\mathbf{1}_d + (c-a)\boldsymbol{x}\big),$$

则 $h \in \mathcal{H}_d^\beta\Big([0,\ 1]^d,\ \gamma \vee (c-a)^{\beta_0}\gamma\Big)$。由引理 6，存在 $f^\circ \in \mathcal{F}\big(L,\ \boldsymbol{p}\big)$，使得对所有 $\boldsymbol{x} \in \mathbb{R}^d$，都有 $|f^\circ(\boldsymbol{x})| \le \gamma \vee (c-a)^{\beta_0}\gamma$，而且对所有 $\boldsymbol{x} \in [0,\ 1]^d \backslash \Gamma\Big([0,\ 1]^d,\ R,\ \delta\Big)$，都有

$$|f^\circ(\boldsymbol{x}) - h(\boldsymbol{x})| \le 9\big(\gamma \vee (c-a)^{\beta_0}\gamma\big)(\beta_0+3)^2 8^\beta t^{\beta_0+\beta/2}(NM)^{-2\beta/t} \tag{17}$$

由 (P2)，存在 $f \in \mathcal{F}\big(L,\ \boldsymbol{p}\big)$，使得

$$f(\boldsymbol{x}) = f^\circ\left(\frac{\boldsymbol{x} - a\mathbf{1}_d}{c-a}\right),$$

且对所有 $\boldsymbol{x} \in \mathbb{R}^d$ 都有 $|f(\boldsymbol{x})| \le \gamma \vee (c-a)^{\beta_0}\gamma$。因此，由式 (17)，对所有 $\boldsymbol{x} \in [a,\ c]^d \backslash \Gamma\Big([a,\ c]^d,\ R,\ \delta\Big)$，都有

$$|f(\boldsymbol{x}) - g(\boldsymbol{x})| \le 9\big(\gamma \vee (c-a)^{\beta_0}\gamma\big)(\beta_0+3)^2 8^\beta t^{\beta_0+\beta/2}(NM)^{-2\beta/t}$$

这就证明了 $t = d$ 时的结论。

现在假定 $t \in [d-1]$。不失一般性，假设 g 仅依赖 $[t]$ 中的坐标。定义 $g^{[t]} : [a,\ c]^t \to \mathbb{R}$ 为 $g^{[t]}(\boldsymbol{y}) \coloneqq g\big(\boldsymbol{y},\ \mathbf{0}_{d-t}\big)$，于是 $g^{[t]} \in \mathcal{H}_t^\beta\Big([a,\ c]^t,\ \gamma\Big)$。那么，由 $t = d$ 的情形，存在 $f^{[t]} \in \mathcal{F}\big(L,\ \boldsymbol{p}^{[t]}\big)$，其中 $\boldsymbol{p}^{[t]} \coloneqq \big(t,\ p_*,\ \ldots,\ p_*,\ 1\big)^\top \in \mathbb{N}^{L+2}$，使得对所有 $\boldsymbol{y} \in \mathbb{R}^t$，都有 $\big|f^{[t]}(\boldsymbol{y})\big| \le \gamma \vee (c-a)^{\beta_0}\gamma$，且对所有 $\boldsymbol{y} \in [a,\ c]^t \backslash \Gamma\Big([a,\ c]^t,\ R,\ \delta\Big)$，都有

$$\left|f^{[t]}(\boldsymbol{y})-g^{[t]}(\boldsymbol{y})\right| \leq 9\left(\gamma \vee (c-a)^{\beta_0}\gamma\right)(\beta_0+3)^2 8^{\beta} t^{\beta_0+\beta/2}(NM)^{-2\beta/t}$$

由 (P2)，可令 $f(\boldsymbol{x}) := f^{[t]}(\boldsymbol{M}\boldsymbol{x})$ 来定义 $f \in \mathcal{F}(L, \boldsymbol{p})$，其中 $\boldsymbol{M} := (\boldsymbol{I}_t \ \ \boldsymbol{0}) \in \mathbb{R}^{t\times d}$，而 f 满足引理陈述中的要求。□

由假设 2，对每个 $k \in [K]$，存在 $\boldsymbol{g}_1^{(k)}, \ldots, \boldsymbol{g}_{q_k}^{(k)}$，使得

$$\begin{aligned}\boldsymbol{g}_r^{(k)} &= \left(g_{r,1}^{(k)}, \ldots, g_{r,d_{r+1}^{(k)}}^{(k)}\right)^\top : \mathbb{R}^{d_r^{(k)}} \to \mathbb{R}^{d_{r+1}^{(k)}},\\ g_{r,j}^{(k)} &\in \mathcal{H}_{t_r^{(k)}}^{\beta_r^{(k)}}\left(\mathbb{R}^{d_r^{(k)}}, \gamma_r^{(k)}\right) \text{ for all } r \in [q_k], j \in [d_{r+1}^{(k)}],\end{aligned}$$

其中第二行的条件对所有 $r \in [q_k]$、$j \in \left[d_{r+1}^{(k)}\right]$ 成立，并且对所有 $\boldsymbol{z} \in \mathbb{R}^d$，

$f^{\mathcal{S}_k}(\boldsymbol{z}) = \boldsymbol{g}_{q_k}^{(k)} \circ \boldsymbol{g}_{q_k-1}^{(k)} \circ \cdots \circ \boldsymbol{g}_1^{(k)}(\boldsymbol{z})$.

现在，对 $k \in [K]$，定义如下端点；第二行定义适用于 $r \in \{2, \ldots, q_k+1\}$：

$$\begin{aligned}a_1^{(k)} &:= -\xi_1 \log(2dn), \quad c_1^{(k)} := \xi_1 \log(2dn)\\ \text{and } a_r^{(k)} &:= -\gamma_{r-1}^{(k)}, \quad c_r^{(k)} := \gamma_{r-1}^{(k)} \quad \text{for } r \in \{2, \ldots, q_k+1\}.\end{aligned} \tag{18}$$

对 $r \in \{2, \ldots, q_k+1\}$，由这些函数的 Hölder 性质，对于所有 $\boldsymbol{z} \in \mathbb{R}^{d_{r-1}^{(k)}}$，有 $\boldsymbol{g}_{r-1}^{(k)}(\boldsymbol{z}) \in \left[a_r^{(k)}, c_r^{(k)}\right]^{d_r^{(k)}}$。因此，对于 $r \in \{2, \ldots, q_k\}$，只需将 $\boldsymbol{g}_r^{(k)}$ 的定义域限制为 $\left[a_r^{(k)}, c_r^{(k)}\right]^{d_r^{(k)}}$。于是，假设 2 给出：对所有 $\boldsymbol{z} \in \left[a_1^{(k)}, c_1^{(k)}\right]^d = \left[-\xi_1\log(2dn), \xi_1\log(2dn)\right]^d$，有

$f^{\mathcal{S}_k}(\boldsymbol{z}) = \boldsymbol{g}_{q_k}^{(k)} \circ \boldsymbol{g}_{q_k-1}^{(k)} \cdots \circ \boldsymbol{g}_1^{(k)}(\boldsymbol{z})$,

其中下列函数的定义域和值域如第一行所示，且第二行的 Hölder 类条件对所有 $r \in [q_k]$、$j \in \left[d_{r+1}^{(k)}\right]$ 成立：

$$\begin{aligned}\boldsymbol{g}_r^{(k)} &= \left(g_{r,1}^{(k)}, \ldots, g_{r,d_{i+1}^{(k)}}^{(k)}\right)^\top : [a_r^{(k)}, c_r^{(k)}]^{d_r^{(k)}} \to [a_{r+1}^{(k)}, c_{r+1}^{(k)}]^{d_{r+1}^{(k)}}, \text{ and}\\ g_{r,j}^{(k)} &\in \mathcal{H}_{t_r^{(k)}}^{\beta_r^{(k)}}\left([a_r^{(k)}, c_r^{(k)}]^{d_r^{(k)}}, \gamma_r^{(k)}\right) \text{ for all } r \in [q_k], j \in [d_{r+1}^{(k)}].\end{aligned} \tag{19}$$

我们将 $f^{\mathcal{S}_k}$ 的定义域限制在 $\left[-\xi_1\log(2dn), \xi_1\log(2dn)\right]^d$ 上，是因为由假设 1，$\boldsymbol{Z}_0$ 的每个坐标都具有次指数尾部，所以对所有 $j \in [d]$，都有 $\mathbb{P}\left(|Z_{0,j}| \geq \xi_1\log(2dn)\right) \leq 1/(dn)$。因此，由并集界，

$$\mathbb{P}\left\{\boldsymbol{Z}_0 \notin \left[-\xi_1 \log(2dn), \xi_1 \log(2dn)\right]^d\right\} \leq \frac{1}{n}, \tag{20}$$

故只需在 $\left[-\xi_1\log(2dn), \xi_1\log(2dn)\right]^d$ 上逼近 $f^{\mathcal{S}_k}$。为此，我们首先逼近定义 $f^{\mathcal{S}_k}$ 的复合中的每个函数。最后，回顾对 $k \in [K]$ 和 $r \in [q_k]$ 的定义：

$$\bar{\beta}_r^{(k)} := \beta_r^{(k)} \prod_{\ell=r+1}^{q_k} (\beta_\ell^{(k)} \wedge 1).$$

还定义 $r_*^{(k)}:=\text{sargmax}_{r\in[q_k]} t_r^{(k)}/\bar{\beta}_r^{(k)}$，并令 $\bar{\beta}_*^{(k)}:=\bar{\beta}_{r_*^{(k)}}^{(k)}$、$\beta_*^{(k)}:=\beta_{r_*^{(k)}}^{(k)}$、$t_*^{(k)}:=t_{r_*^{(k)}}^{(k)}$ 以及 $\gamma_*^{(k)}:=\gamma_{r_*^{(k)}}^{(k)}$。

引理 8。假定假设 1 和 2 成立。沿用式 (18) 和 (19) 中的记号，对 $M, N \in \mathbb{N}$ 和 $k \in [K]$，令 $L^{(k)}$、$p_*^{(k)}$ 以及 $\boldsymbol{p}_r^{(k)}$ 如下；最后一行适用于 $r \in [q_k]$：

$$\begin{aligned} L^{(k)} &:= \max_{r\in[q_k]} 12\lceil\beta_r^{(k)}\rceil^2(M+2)\lceil\log_2(4M)\rceil, \\ p_*^{(k)} &:= \max_{r\in[q_k]}\left\{30d_{r+1}^{(k)}\lceil\beta_r^{(k)}\rceil^2(t_r^{(k)})^{\lceil\beta_r^{(k)}\rceil}(N+1)\lceil\log_2(8N)\rceil \vee 2d_{r+1}^{(k)}\right\} \text{ and} \\ \boldsymbol{p}_r^{(k)} &:= (d_r^{(k)}, p_*^{(k)}, \ldots, p_*^{(k)}, d_{r+1}^{(k)})^\top \in \mathbb{N}^{L^{(k)}+2} \text{ for } r \in [q_k]. \end{aligned}$$

对每个 $k \in [K]$、$r \in [q_k]$ 和 $n \in \mathbb{N}$，存在 $\boldsymbol{f}_r^{(k)} \in \mathcal{F}\left(L^{(k)}, \boldsymbol{p}_r^{(k)}\right)$ 和 $E_r^{(k)} \subseteq \left[a_r^{(k)}, c_r^{(k)}\right]^{d_r^{(k)}}$，满足：

(i) 对所有 $\boldsymbol{x} \in \mathbb{R}^{d_r^{(k)}}$，有 $\| \boldsymbol{f}_r^{(k)}(\boldsymbol{x}) \|_\infty \le \gamma_r^{(k)} \vee \left(c_r^{(k)} - a_r^{(k)}\right)^{\lceil\beta_r^{(k)}\rceil-1}\gamma_r^{(k)}$；并且对所有 $\boldsymbol{x} \in \left[a_r^{(k)}, c_r^{(k)}\right]^{d_r^{(k)}} \backslash E_r^{(k)}$，有

$$\begin{aligned} &\left\|\boldsymbol{f}_r^{(k)}(\boldsymbol{x}) - \boldsymbol{g}_r^{(k)}(\boldsymbol{x})\right\|_\infty \\ &\le 9\left(1 \vee (c_r^{(k)} - a_r^{(k)})^{\lceil\beta_r^{(k)}\rceil-1}\right)\gamma_r^{(k)}(\lceil\beta_r^{(k)}\rceil+2)^2 8^{\beta_r^{(k)}}(t_r^{(k)})^{\lceil\beta_r^{(k)}\rceil-1+\beta_r^{(k)}/2}(NM)^{-2\beta_r^{(k)}/t_r^{(k)}}, \end{aligned}$$

(ii) $\mu_{Z_0}\left(E_1^{(k)}\right) \le 1/\left(Knq_k\right)$，且对所有 $r \in \{2, \ldots, q_k\}$，有 $\mu_{Z_0}\left(\left(\boldsymbol{F}_{r-1}^{(k)}\right)^{-1}\left(E_r^{(k)}\right)\right) \le 1/\left(Knq_k\right)$，其中 $\boldsymbol{F}_r^{(k)}:=\boldsymbol{f}_r^{(k)} \circ \cdots \circ \boldsymbol{f}_1^{(k)}$。

证明。固定 $k \in [K]$，我们以归纳法构造 $\left(\boldsymbol{f}_r^{(k)}, E_r^{(k)}\right)_{r=1}^{q_k}$。对 $r \in [q_k]$，令 $R_r^{(k)}:=\lfloor N^{1/t_r^{(k)}}\rfloor^2\lfloor M^{2/t_r^{(k)}}\rfloor$。令 $\delta_{\max}:=1/\left(3\max_{r\in[q_k]}R_r^{(k)}\right)$。由引理 7、(P1)、(P3) 和 (P4)，对任意 $\delta \in (0, \delta_{\max}]$，存在 $\boldsymbol{f}_{1,\delta}^{(k)} \in \mathcal{F}\left(L^{(k)}, \boldsymbol{p}_1^{(k)}\right)$，使得对所有 $\boldsymbol{x} \in \mathbb{R}^{d_1^{(k)}}$，都有 $\| \boldsymbol{f}_{1,\delta}^{(k)}(\boldsymbol{x}) \|_\infty \le \left(1 \vee \left(c_1^{(k)} - a_1^{(k)}\right)^{\lceil\beta_1^{(k)}\rceil-1}\right)\gamma_1^{(k)}$，且对所有 $\boldsymbol{x} \in \left[a_1^{(k)}, c_1^{(k)}\right]^{d_1^{(k)}} \backslash E_{1,\delta}^{(k)}$，都有

$$\begin{aligned} &\left\|\boldsymbol{f}_{1,\delta}^{(k)}(\boldsymbol{x}) - \boldsymbol{g}_1^{(k)}(\boldsymbol{x})\right\|_\infty \\ &\le 9\left(1 \vee (c_1^{(k)} - a_1^{(k)})^{\lceil\beta_1^{(k)}\rceil-1}\right)\gamma_1^{(k)}(\lceil\beta_1^{(k)}\rceil+2)^2 8^{\beta_1^{(k)}}(t_1^{(k)})^{\lceil\beta_1^{(k)}\rceil-1+\beta_1^{(k)}/2}(NM)^{-2\beta_1^{(k)}/t_1^{(k)}}, \end{aligned}$$

其中 $E_{1,\delta}^{(k)}:=\Gamma\left(\left[a_1^{(k)},\, c_1^{(k)}\right]^{d_1^{(k)}},\, R_1^{(k)},\, \delta\right)$，其定义见引理 7。再注意到，集合族 $\left(E_{1,\delta}^{(k)}\right)_{\delta\in(0,\delta_{\max}]}$ 是嵌套的，且交集为空。因此，存在 $\delta^*\in(0,\,\delta_{\max}]$，使得 $\mu_{Z_0}\left(E_{1,\delta^*}^{(k)}\right)\le 1/\left(Knq_k\right)$。令 $\boldsymbol{f}_1^{(k)}:=\boldsymbol{f}_{1,\delta^*}^{(k)}$、$E_1^{(k)}:=E_{1,\delta^*}^{(k)}$，则 $\boldsymbol{f}_1^{(k)}$ 和 $E_1^{(k)}$ 满足条件 (i) 和 (ii)。

现在假定，对某个 $r\in\{2,\,\ldots,\,q_k\}$，已经构造出满足条件 (i) 和 (ii) 的 $\boldsymbol{f}_1^{(k)},\,\ldots,\,\boldsymbol{f}_{r-1}^{(k)}$ 以及 $E_1^{(k)},\,\ldots,\,E_{r-1}^{(k)}$。应用与上面相同的论证来构造 $\boldsymbol{f}_r^{(k)}$ 和 $E_r^{(k)}$。由引理 7、(P1)、(P3) 和 (P4)，对任意 $\delta\in(0,\,\delta_{\max}]$，存在 $\boldsymbol{f}_{r,\delta}^{(k)}\in\mathcal{F}\left(L^{(k)},\,\boldsymbol{p}_r^{(k)}\right)$，使得对所有 $\boldsymbol{x}\in\mathbb{R}^{d_r^{(k)}}$，都有 $\|\boldsymbol{f}_{r,\delta}^{(k)}(\boldsymbol{x})\|_\infty\le\left(1\vee\left(c_r^{(k)}-a_r^{(k)}\right)^{\lceil\beta_r^{(k)}\rceil-1}\right)\gamma_r^{(k)}$，并且满足下面的不等式（原文跨页续接）：

$$\left\|\boldsymbol{f}_{r,\delta}^{(k)}(\boldsymbol{x})-\boldsymbol{g}_r^{(k)}(\boldsymbol{x})\right\|_\infty$$

$$\le 9\left(1\vee\left(c_r^{(k)}-a_r^{(k)}\right)^{\lceil\beta_r^{(k)}\rceil-1}\right)\gamma_r^{(k)}\left(\lceil\beta_r^{(k)}\rceil+2\right)^2 8^{\beta_r^{(k)}}\left(t_r^{(k)}\right)^{\lceil\beta_r^{(k)}\rceil-1+\beta_r^{(k)}/2}(NM)^{-2\beta_r^{(k)}/t_r^{(k)}},$$

该式对所有 $\boldsymbol{x}\in\left[a_r^{(k)},\,c_r^{(k)}\right]^{d_r^{(k)}}\backslash E_{r,\delta}^{(k)}$ 成立，其中 $E_{r,\delta}^{(k)}:=\Gamma\left(\left[a_r^{(k)},\,c_r^{(k)}\right]^{d_r^{(k)}},\,R_r^{(k)},\,\delta\right)$。同样，由于集合族 $\left(\left(\boldsymbol{F}_{r-1}^{(k)}\right)^{-1}\left(E_{r,\delta}^{(k)}\right)\right)_{\delta\in(0,\delta_{\max}]}$ 是嵌套的，且交集为空，存在 $\delta^*\in(0,\,\delta_{\max}]$，使得 $\mu_{Z_0}\left(\left(\boldsymbol{F}_{r-1}^{(k)}\right)^{-1}\left(E_{r,\delta^*}^{(k)}\right)\right)\le 1/\left(Knq_k\right)$。令 $\boldsymbol{f}_r^{(k)}:=\boldsymbol{f}_{r,\delta^*}^{(k)}$、$E_r^{(k)}:=E_{r,\delta^*}^{(k)}$，则 $\boldsymbol{f}_r^{(k)}$ 和 $E_r^{(k)}$ 满足条件 (i) 和 (ii)。□

现在，在剔除某些条带之后，我们已经能够在一个超立方体上，用神经网络逼近贝叶斯回归函数的每一片。

引理 9。假定假设 1 和 2 成立，并令 $n\ge 2$。对 $M,\,N\in\mathbb{N}$ 和 $k\in[K]$，令 $L^{(k)}$ 以及 $p_*^{(k)}$ 如下:

$$L^{(k)}:=\max_{r\in[q_k]}12\lceil\beta_r^{(k)}\rceil^2(M+2)\lceil\log_2(4M)\rceil\ \ and$$
$$p_*^{(k)}:=\max_{r\in[q_k]}\left\{30d_{r+1}^{(k)}\lceil\beta_r^{(k)}\rceil^2\left(t_r^{(k)}\right)^{\lceil\beta_r^{(k)}\rceil}(N+1)\lceil\log_2(8N)\rceil\vee 2d_{r+1}^{(k)}\right\}.$$

对每个 $k\in[K]$，存在 $E^{(k)}\subseteq\left[-\xi_1\log(2dn),\,\xi_1\log(2dn)\right]^d$ 和 $f^{(k)}\in\mathcal{F}\left(q_kL^{(k)},\,\boldsymbol{p}^{(k)}\right)$，其中 $\boldsymbol{p}^{(k)}:=\left(d,\,p_*^{(k)},\,\ldots,\,p_*^{(k)},\,1\right)\in\mathbb{N}^{q_kL^{(k)}+2}$，使得 $\mu_{Z_0}\left(E^{(k)}\right)\le 1/(Kn)$，对所有 $\boldsymbol{z}\in\mathbb{R}^d$ 有 $\left|f^{(k)}(\boldsymbol{z})\right|\le\gamma_{q_k}^{(k)}\vee\left(2\gamma_{q_k-1}^{(k)}\right)^{\lceil\beta_{q_k}^{(k)}\rceil-1}\gamma_{q_k}^{(k)}$，而且对所有 $\boldsymbol{z}\in\left[-\xi_1\log(2dn),\,\xi_1\log(2dn)\right]^d\backslash E^{(k)}$ 有

$$\left|f^{(k)}(\boldsymbol{z})-f^{\mathcal{S}_k}(\boldsymbol{z})\right|\le C_1(\xi_1,\boldsymbol{t}^{(k)},\boldsymbol{\beta}^{(k)},\boldsymbol{\gamma}^{(k)})\cdot\log^{\bar{\beta}_1^{(k)}}(2dn)\sum_{r=1}^{q_k}\frac{1}{(NM)^{2\bar{\beta}_r^{(k)}/t_r^{(k)}}}$$

其中 $C_1\left(\xi_1,\, \boldsymbol{t}^{(k)},\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right) > 0$ 仅依赖于 $\left(\xi_1,\, \boldsymbol{t}^{(k)},\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right)$，并且对某些 $A\left(\xi_1,\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right),\, B\left(\boldsymbol{\beta}^{(k)}\right) > 0$，有 $C_1\left(\xi_1,\, \boldsymbol{t}^{(k)},\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right) \le A\left(\xi_1,\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right) \| \boldsymbol{t}^{(k)} \|_{\infty}^{B(\boldsymbol{\beta}^{(k)})}$。

证明。使用式 (18) 和 (19) 中的记号。固定 $k \in [K]$，令 $\left(\boldsymbol{f}_r^{(k)}\right)_{r=1}^{q_k}$ 和 $\left(E_r^{(k)}\right)_{r=1}^{q_k}$ 如引理 8 中所定义。由 (P2)，函数 $f^{(k)} := \boldsymbol{f}_{q_k}^{(k)} \circ \cdots \circ \boldsymbol{f}_1^{(k)}$ 属于 $\mathcal{F}\left(q_k L^{(k)},\, \boldsymbol{p}^{(k)}\right)$。对 $r \in \left[q_k\right]$，回顾引理 8 中 $\boldsymbol{F}_r^{(k)}$ 的定义，并令 $\boldsymbol{G}_r^{(k)} := \boldsymbol{g}_r^{(k)} \circ \cdots \circ \boldsymbol{g}_1^{(k)}$。定义 $E^{(k)} := \bigcup_{r \in [q_k]} \left(\boldsymbol{F}_{r-1}^{(k)}\right)^{-1}\left(E_r^{(k)}\right)$，其中 $\boldsymbol{F}_0^{(k)}$ 为恒等函数。由引理 8 和并集界，$\mu_{\boldsymbol{Z}_0}\left(E^{(k)}\right) \le 1/(Kn)$。对 $\boldsymbol{f} : \mathbb{R}^d \to \mathbb{R}^m$ 和 $D \subseteq \mathbb{R}^d$，定义 $\| \boldsymbol{f} \|_{L^\infty(D)} := \sup_{\boldsymbol{x} \in D} \| \boldsymbol{f}(\boldsymbol{x}) \|_\infty$。对 $r \in \left[q_k\right]$，令 $D_r^{(k)} := \left[a_r^{(k)},\, c_r^{(k)}\right]^{d_r^{(k)}} \backslash E_r^{(k)}$，并令 $D^{(k)} := \left[-\xi_1 \log(2dn),\, \xi_1 \log(2dn)\right]^d \backslash E^{(k)}$。那么，对 $r \in \{2,\, \ldots,\, q_k\}$，

$$
\begin{aligned}
\left\| \boldsymbol{F}_r^{(k)} - \boldsymbol{G}_r^{(k)} \right\|_{L^\infty(D^{(k)})} &\le \left\| \boldsymbol{f}_r^{(k)} \circ \boldsymbol{f}_{r-1}^{(k)} \circ \cdots \circ \boldsymbol{f}_1^{(k)} - \boldsymbol{g}_r^{(k)} \circ \boldsymbol{f}_{r-1}^{(k)} \circ \cdots \circ \boldsymbol{f}_1^{(k)} \right\|_{L^\infty(D^{(k)})} \\
&\quad + \left\| \boldsymbol{g}_r^{(k)} \circ \boldsymbol{f}_{r-1}^{(k)} \circ \cdots \circ \boldsymbol{f}_1^{(k)} - \boldsymbol{g}_r^{(k)} \circ \boldsymbol{g}_{r-1}^{(k)} \circ \cdots \circ \boldsymbol{g}_1^{(k)} \right\|_{L^\infty(D^{(k)})} \\
&\le \left\| \boldsymbol{f}_r^{(k)} - \boldsymbol{g}_r^{(k)} \right\|_{L^\infty(\boldsymbol{F}_{r-1}^{(k)}(D^{(k)}))} + \gamma_r^{(k)} \left\{ \left(t_r^{(k)}\right)^{1/2} \left\| \boldsymbol{F}_{r-1}^{(k)} - \boldsymbol{G}_{r-1}^{(k)} \right\|_{L^\infty(D^{(k)})} \right\}^{\beta_r^{(k)} \wedge 1} \\
&\le \left\| \boldsymbol{f}_r^{(k)} - \boldsymbol{g}_r^{(k)} \right\|_{L^\infty(D_r^{(k)})} + \gamma_r^{(k)} \left(t_r^{(k)}\right)^{(\beta_r^{(k)} \wedge 1)/2} \left\| \boldsymbol{F}_{r-1}^{(k)} - \boldsymbol{G}_{r-1}^{(k)} \right\|_{L^\infty(D^{(k)})}^{\beta_r^{(k)} \wedge 1}, \qquad (21)
\end{aligned}
$$

其中第二个不等式成立，是因为 $\boldsymbol{g}_r^{(k)}$ 的每个坐标函数都属于类 $\mathcal{H}_{t_r^{(k)}}^{\beta_r^{(k)}}\left(\left[a_r^{(k)},\, c_r^{(k)}\right]^{d_r^{(k)}},\, \gamma_r^{(k)}\right)$。因此，

$$
\begin{aligned}
\left\| f^{(k)} - f^{\mathcal{S}_k} \right\|_{L^\infty(D^{(k)})} &= \left\| \boldsymbol{F}_{q_k}^{(k)} - \boldsymbol{G}_{q_k}^{(k)} \right\|_{L^\infty(D^{(k)})} \\
&\le \sum_{r=1}^{q_k} \left\{ \prod_{j=r+1}^{q_k} (\gamma_j^{(k)})^{\bar{\beta}_j^{(k)}/\beta_j^{(k)}} \left(t_j^{(k)}\right)^{\bar{\beta}_{j-1}^{(k)}/(2\beta_{j-1}^{(k)})} \right\} \left\| \boldsymbol{f}_r^{(k)} - \boldsymbol{g}_r^{(k)} \right\|_{L^\infty(D_r^{(k)})}^{\bar{\beta}_r^{(k)}/\beta_r^{(k)}} \\
&\le \sum_{r=1}^{q_k} \left\{ \prod_{j=r+1}^{q_k} (\gamma_j^{(k)})^{\bar{\beta}_j^{(k)}/\beta_j^{(k)}} \left(t_j^{(k)}\right)^{\bar{\beta}_{j-1}^{(k)}/(2\beta_{j-1}^{(k)})} \right\} \left\{ 9\left(1 \vee (c_r^{(k)} - a_r^{(k)})^{\lceil \beta_r^{(k)} \rceil - 1}\right) \gamma_r^{(k)} \right. \\
&\qquad \left. \times (\lceil \beta_r^{(k)} \rceil + 2)^2 8^{\beta_r^{(k)}} (t_r^{(k)})^{\lceil \beta_r^{(k)} \rceil - 1 + \beta_r^{(k)}/2} \right\}^{\bar{\beta}_r^{(k)}/\beta_r^{(k)}} (NM)^{-2\bar{\beta}_r^{(k)}/t_r^{(k)}} \\
&\le C_1(\xi_1, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}) \cdot \log^{\bar{\beta}_1^{(k)}}(2dn) \sum_{r=1}^{q_k} \frac{1}{(NM)^{2\bar{\beta}_r^{(k)}/t_r^{(k)}}},
\end{aligned}
$$

其中 $C_1\left(\xi_1,\, \boldsymbol{t}^{(k)},\, \boldsymbol{\beta}^{(k)},\, \boldsymbol{\gamma}^{(k)}\right)$ 具有引理陈述中声称的性质。这里，第一个不等式通过迭代应用式 (21)，并利用对于 $a,\, b \ge 0$、$t \in [0,\, 1]$ 有 $(a+b)^t \le a^t + b^t$ 这一事实而得到；第二个不等式由引理 8 得到；第三个不等式则通过代入式 (18) 中 $\left(a_r^{(k)},\, c_r^{(k)}\right)_{r=1}^{q_k}$ 的定义得到。此外，由引理 8，有 $\| f^{(k)} \|_{L^\infty(\mathbb{R}^d)} \le \| \boldsymbol{f}_{q_k}^{(k)} \|_{L^\infty(\mathbb{R}^d)} \le \gamma_{q_k}^{(k)} \vee \left(2\gamma_{q_k-1}^{(k)}\right)^{\lceil \beta_{q_k}^{(k)} \rceil - 1} \gamma_{q_k}^{(k)}$。□

下面的引理用于证明后面的引理 11。引理 11 量化了：基于一个将 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 分离的函数 $\boldsymbol{f}_2$，我们可以利用神经网络将坐标提取到何种程度。

引理 10。对任意 $B > 0$ 和 $N, L \in \mathbb{N}$，存在 $\phi \in \mathcal{F}(L, (2, 9N+1, \ldots, 9N+1, 1))$，使得对所有 $x \in [-B, B]$，都有 $\phi(x, 0) = 0$，并且

$$|\phi(x, 1) - x| \leq \frac{12B}{N^L}.$$

证明。由 Lu et al.（2021，引理 5.2），存在 $\phi_1 \in \mathcal{F}(L, (2, 9N, \ldots, 9N, 1))$，使得对所有 $a, b \in [0, 1]$ 都有 $|\phi_1(a, b) - ab| \leq 6N^{-L}$。此外，由 Lu et al.（2021，式 (5.2)），函数 ϕ_1 定义为 $\phi_1(a, b) = 2\big(\psi((a+b)/2) - \psi(a/2) - \psi(b/2)\big)$，其中 ψ 是 Lu et al.（2021，引理 5.1）构造的神经网络，满足 $\psi(0) = 0$。因此，对所有 $a \in [0, 1]$，都有 $\phi_1(a, 0) = 0$。由 (P2) 和 (P4)，存在 $\phi \in \mathcal{F}(L, (2, 9N+1, \ldots, 9N+1, 1))$，使得对所有 $\big(x, y\big) \in \mathbb{R} \times [0, \infty)$，都有 $\phi\big(x, y\big) = 2B\phi_1\big((x+B)/(2B), y\big) - By$。此外，对所有 $x \in [-B, B]$，都有 $\phi(x, 0) = 2B\phi_1((x+B)/(2B), 0) = 0$，并且

$$|\phi(x,1) - x| = 2B\left|\phi_1\left(\frac{x+B}{2B}, 1\right) - \frac{x+B}{2B}\right| \leq \frac{12B}{N^L},$$

即得所需结论。□

引理 11。假定 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 被 $\boldsymbol{f}_2 \in \mathcal{F}\big(L_2, \boldsymbol{p}_2\big)$ 分离。令 $m := p_{2,L_2+1}$，且 $B > 0$。对任意 $M, N_1, \ldots, N_K \in \mathbb{N}$，令 s、p_* 以及 $\boldsymbol{p}$ 如下：

$$s := (13m+7)K + (2M+2)\sum_{k=1}^{K}(9N_k+1)^2 + 7,$$

$$p_* := (4m+1)K \vee \sum_{k=1}^{K}(9N_k+1) \quad \textit{and} \quad \boldsymbol{p} := (K+m, p_*, \ldots, p_*, 1) \in \mathbb{N}^{M+5}.$$

那么，存在 $f_3 \in \mathcal{F}\big(M+3, \boldsymbol{p}, s\big)$，使得对所有 $(\boldsymbol{u}, \boldsymbol{v}) \in \mathbb{R}^K \times \mathbb{R}^m$，都有 $|f_3(\boldsymbol{u}, \boldsymbol{v})| \leq B$，且对所有 $\boldsymbol{u} = \big(u_1, \ldots, u_K\big)^\top \in [-B, B]^K$、$k \in [K]$ 和 $\boldsymbol{\omega} \in \mathcal{S}_k$，都有

$$\big|f_3\big(\boldsymbol{u}, \boldsymbol{f}_2(\boldsymbol{\omega})\big) - u_k\big| \leq \frac{12B}{N_k^M}.$$

证明。假定 $\{\mathcal{S}_1, \ldots, \mathcal{S}_K\}$ 与 $\boldsymbol{f}_2 \in \mathcal{F}\big(L_2, \boldsymbol{p}_2\big)$ 对某个 $\epsilon > 0$ 和 $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_K \in \mathbb{R}^m$ 满足定义 1。对 $a \in \mathbb{R}$，定义 $h_a : \mathbb{R} \to [0, 1]$ 为

$$h_a(x) := \sigma\left(\frac{2x - 2a + 2\epsilon}{\epsilon}\right) - \sigma\left(\frac{2x - 2a + \epsilon}{\epsilon}\right) - \sigma\left(\frac{2x - 2a - \epsilon}{\epsilon}\right) + \sigma\left(\frac{2x - 2a - 2\epsilon}{\epsilon}\right).$$

那么 $h_a \in \mathcal{F}(1,\ (1,\ 4,\ 1),\ 12)$，对所有 $x \in [a-\epsilon/2,\ a+\epsilon/2]$ 都有 $h_a(x)=1$，且对所有 $x \in (-\infty,\ a-\epsilon] \cup [a+\epsilon,\ \infty)$ 都有 $h_a(x)=0$。进一步，对 $k \in [K]$，记 $\boldsymbol{v}_k = (v_{k,1},\ \ldots,\ v_{k,m})^\top \in \mathbb{R}^m$，并定义 $g_k \in \mathcal{F}(2,\ (m,\ 4m,\ 1,\ 1),\ 13m+2)$ 为

$$g_k(\boldsymbol{x}) := \sigma\left(\sum_{j=1}^{m} h_{v_{k,j}}(x_j) - m + 1\right).$$

那么，对 $\boldsymbol{\omega} \in \mathcal{S}_k$，有 $g_k\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big) = \sigma(m-m+1) = 1$；对 $\boldsymbol{\omega} \notin \mathcal{S}_k$，有 $\sum_{j=1}^{m} h_{v_{k,j}}\big(f_{2,j}(\boldsymbol{\omega})\big) \le m-1$，因而 $g_k\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big) = 0$。由引理 10，对 $k \in [K]$，存在 $\phi_k \in \mathcal{F}\big(M,\ (2,\ 9N_k+1,\ \ldots,\ 9N_k+1,\ 1)\big)$，使得对所有 $x \in [-B,\ B]$，都有 $\phi_k(x,\ 0) = 0$ 且 $|\phi_k(x,\ 1) - x| \le 12BN_k^{-M}$。进一步，由 (P1)、(P2) 和 (P4)，存在 $f_3^\circ \in \mathcal{F}\big(M+2,\ (K+m,\ p_*,\ \ldots,\ p_*,\ 1),\ s-7\big)$，使得对所有 $\boldsymbol{u} \in [-B,\ B]^K$ 和 $v \in \mathbb{R}^m$，都有 $f_3^\circ(\boldsymbol{u},\ \boldsymbol{v}) = \sum_{k=1}^{K} \phi_k(u_k,\ g_k(\boldsymbol{v}))$。此外，对 $\boldsymbol{\omega} \in \mathcal{S}_k$ 和 $\boldsymbol{u} = (u_1,\ \ldots,\ u_K)^\top \in [-B,\ B]^K$，有

$$\begin{aligned}
\big|f_3^\circ\big(\boldsymbol{u},\ \boldsymbol{f}_2(\boldsymbol{\omega})\big) - u_k\big| &= \left|\sum_{\ell=1}^{K}\Big\{\phi_k\Big(u_\ell,\ g_\ell\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big)\Big) - u_\ell g_\ell\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big)\Big\}\right| \\
&\le \sum_{\ell=1}^{K}\left|\phi_k\Big(u_\ell,\ g_\ell\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big)\Big) - u_\ell g_\ell\big(\boldsymbol{f}_2(\boldsymbol{\omega})\big)\right| \\
&= |\phi_k(u_k,\ 1) - u_k| + \sum_{\ell \ne k} |\phi_\ell(u_\ell,\ 0) - 0| \le \frac{12B}{N_k^M}.
\end{aligned}$$

最后，定义 $f_3 : \mathbb{R}^{K+m} \to [-B,\ B]$ 为

$$f_3 := \sigma\big(f_3^\circ + B\big) - \sigma\big(f_3^\circ - B\big) - B = T_B f_3^\circ.$$

由 (P1) 和 (P2)，有 $f_3 \in \mathcal{F}\big(M+3,\ \boldsymbol{p},\ s\big)$，而且由于 $u_k \in [-B,\ B]$，可知对所有 $\boldsymbol{u} = (u_1,\ \ldots,\ u_K)^\top \in [-B,\ B]^K$、$k \in [K]$ 和 $\boldsymbol{\omega} \in \mathcal{S}_k$，都有 $|f_3\big(\boldsymbol{u},\ \boldsymbol{f}_2(\boldsymbol{\omega})\big) - u_k| \le |f_3^\circ\big(\boldsymbol{u},\ \boldsymbol{f}_2(\boldsymbol{\omega})\big) - u_k|$。□

附录 F 定理 2 的证明

定理 2 的证明。 对任意 $M_1 \in \mathbb{N}$，令

$$L_1 := \max_{k \in [K],\, r \in [q_k]} 12 q_k \lceil \beta_r^{(k)} \rceil^2 (M_1+2) \lceil \log_2(4M_1) \rceil \in \mathbb{N}$$

并对 $k \in [K]$，令

$$N_1^{(k)} := \lceil M_1^{-1} n_k^{t_*^{(k)}/(4\bar{\beta}_*^{(k)}+2t_*^{(k)})} \rceil,$$
$$p_{1,*}^{(k)} := \max_{r\in[q_k]} \Big\{ 30 d_{r+1}^{(k)} \lceil \beta_r^{(k)} \rceil^2 (t_r^{(k)})^{\lceil \beta_r^{(k)} \rceil} (N_1^{(k)}+1) \lceil \log_2(8N_1^{(k)}) \rceil \vee 2d_{r+1}^{(k)} \Big\},$$
$$\boldsymbol{p}_1^{(k)} := (d, p_{1,*}^{(k)}, \ldots, p_{1,*}^{(k)}, 1) \in \mathbb{N}^{L_1+2}.$$

由引理 9 和 (P3)，对 $k \in [K]$ 可找到 $E^{(k)} \subseteq \big[-\xi_1 \log(2dn),\ \xi_1 \log(2dn)\big]^d$ 以及 $f_1^{(k)} \in \mathcal{F}\big(L_1,\ \boldsymbol{p}_1^{(k)}\big)$，使 $\mu_{\boldsymbol{Z}_0}\big(E^{(k)}\big) \le 1/(Kn)$，对所有 $\boldsymbol{z} \in \mathbb{R}^d$ 有

$$|f_1^{(k)}(\boldsymbol{z})| \le \max_{k\in[K]} \big\{ \gamma_{q_k}^{(k)} \vee (2\gamma_{q_k-1}^{(k)})^{\lceil \beta_{q_k}^{(k)} \rceil - 1} \gamma_{q_k}^{(k)} \big\} =: B$$

并对所有 $\boldsymbol{z} \in \big[-\xi_1 \log(2dn),\ \xi_1 \log(2dn)\big]^d \backslash E^{(k)}$ 有

$$\begin{aligned} \big|f_1^{(k)}(\boldsymbol{z}) - f^{\mathcal{S}_k}(\boldsymbol{z})\big| &\le C_1(\xi_1, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}) \cdot \log^{\bar{\beta}_1^{(k)}}(2dn) \cdot q_k \cdot n_k^{-\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} \\ &\le C_2(\xi_1, d, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}) \cdot \log^{\bar{\beta}_1^{(k)}}(n) \cdot n_k^{-\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} \end{aligned} \tag{22}$$

此外，每个 $f_1^{(k)}$ 具有 $V_1^{(k)} := (d+L_1+1)p_{1,\star}^{(k)} + (L_1-1)\big(p_{1,\star}^{(k)}\big)^2 + 1$ 个参数。因此，由 (P4)，函数 $\boldsymbol{f}_1 := \big(f_1^{(1)},\ \ldots,\ f_1^{(K)}\big)^{\mathsf{T}} : \mathbb{R}^d \to [-B,\ B]^K$ 属于 $\mathcal{F}\big(L_1,\ \boldsymbol{p}_1,\ s_1\big)$，其中 $\boldsymbol{p}_1 := \Big(d,\ \sum_{k=1}^K p_{1,\star}^{(k)},\ \ldots,\ \sum_{k=1}^K p_{1,\star}^{(k)},\ K\Big) \in \mathbb{N}^{L_1+2}$，$s_1 := \sum_{k=1}^K V_1^{(k)}$。

根据假设，存在 $\boldsymbol{f}_2 \in \mathcal{F}\big(L_2,\ \boldsymbol{p}_2,\ s_2\big)$，使 $\{\mathcal{S}_1,\ \ldots,\ \mathcal{S}_K\}$ 被 $\boldsymbol{f}_2$ 分离。对任意 $M_3 \in \mathbb{N}$，令 $m := p_{2,L_2+1}$，并令

$$L_3 := \left\lceil 2M_3 \max_{k\in[K]} \frac{\bar{\beta}_*^{(k)}}{t_*^{(k)}} \right\rceil + 3, \quad N_{3,k} := \left\lceil n_k^{\bar{\beta}_*^{(k)}/\{(L_3-3)(2\bar{\beta}_*^{(k)}+t_*^{(k)})\}} \right\rceil \text{ for } k \in [K],$$
$$p_{3,*} := (4m+1)K \vee \sum_{k=1}^K (9N_{3,k}+1), \quad \boldsymbol{p}_3 := \big(K+m,\ p_{3,*},\ \ldots,\ p_{3,*},\ 1\big) \in \mathbb{N}^{L_3+2} \text{ and}$$
$$s_3 := (13m+7)K + (2M_3+2)\sum_{k=1}^K (9N_{3,k}+1)^2 + 7.$$

由引理 11，存在 $f_3 \in \mathcal{F}\big(L_3,\ \boldsymbol{p}_3,\ s\big)$，使对所有 $(\boldsymbol{u},\ \boldsymbol{v}) \in \mathbb{R}^K \times \mathbb{R}^m$ 都有 $|f_3(\boldsymbol{u},\ \boldsymbol{v})| \le B$，且对所有 $\boldsymbol{z} \in \mathbb{R}^d$、$k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$，有

$$\big|f_3\big(\boldsymbol{f}_1(\boldsymbol{z}), \boldsymbol{f}_2(\boldsymbol{\omega})\big) - f_1^{(k)}(\boldsymbol{z})\big| \le 12B \cdot n_k^{-\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})}. \tag{23}$$

再注意，对 $k \in [K]$，

$$N_{3,k} \le 2n_k^{t_*^{(k)}/(4\bar{\beta}_*^{((k)}+2t_*^{(k)})}.$$

因此

$$s_3 \le C_3(m, M_3) \sum_{k=1}^{K} n_k^{t_*^{(k)}/(2\bar{\beta}_*^{((k)}+t_*^{(k)})}.$$

现定义 $\bar{f} \in \mathcal{F}$ 为 $\bar{f}(\boldsymbol{z}, \boldsymbol{\omega}) := f_3\big(\boldsymbol{f}_1(\boldsymbol{z}), \boldsymbol{f}_2(\boldsymbol{\omega})\big)$，使对所有 $\boldsymbol{z} \in \mathbb{R}^d$、$\boldsymbol{\omega} \in \mathcal{S}$，$\big|\bar{f}(\boldsymbol{z}, \boldsymbol{\omega})\big| \le B$。令 $D := \big[-\xi_1 \log(2dn), \xi_1 \log(2dn)\big]^d \backslash \big(\bigcup_{k\in[K]} E^{(k)}\big)$；由引理 9 和式 (20)，有

$$\mathbb{P}(\boldsymbol{Z}_0 \notin D) \le \mathbb{P}\big(\boldsymbol{Z}_0 \notin \big[-\xi_1 \log(2dn), \xi_1 \log(2dn)\big]^d\big) + \sum_{k=1}^{K} \mathbb{P}(\boldsymbol{Z}_0 \in E^{(k)}) \le \frac{2}{n}. \tag{24}$$

由式 (22)、(23)，对所有 $\boldsymbol{z} \in D$、$k \in [K]$、$\boldsymbol{\omega} \in \mathcal{S}_k$，有

$$\begin{aligned}\big|\bar{f}(\boldsymbol{z}, \boldsymbol{\omega}) - f^\star(\boldsymbol{z}, \boldsymbol{\omega})\big| &\le \big|f_3\big(\boldsymbol{f}_1(\boldsymbol{z}), \boldsymbol{f}_2(\boldsymbol{\omega})\big) - f_1^{(k)}(\boldsymbol{z})\big| + \big|f_1^{(k)}(\boldsymbol{z}) - f^{\mathcal{S}_k}(\boldsymbol{z})\big| \\ &\le \big\{C_2(\xi_1, d, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}) + 12B\big\} \cdot \log^{\bar{\beta}_1^{(k)}}(n) \cdot n_k^{-\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})}. \end{aligned} \tag{25}$$

故存在仅依赖 ξ_1, d, m 以及 $\big(\boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}\big)_{k=1}^{K}$ 的 $C_4 > 0$，使

$$\begin{aligned}&\inf_{f\in\mathcal{F}} \mathbb{E}\Big\{\big(f(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0) - f^\star(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)\big)^2\Big\} \\ &\qquad \le \mathbb{E}\Big\{\big(\bar{f}(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0) - f^\star(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)\big)^2 \mathbb{1}_{\{\boldsymbol{Z}_0\in D\}}\Big\} + \frac{8B^2}{n} \\ &\qquad = \sum_{k=1}^{K} \pi_k \mathbb{E}\Big\{\big(\bar{f}(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0) - f^\star(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)\big)^2 \mathbb{1}_{\{\boldsymbol{Z}_0\in D\}} \;\big|\; \boldsymbol{\Omega}_0 \in \mathcal{S}_k\Big\} + \frac{8B^2}{n} \\ &\qquad \le \sum_{k=1}^{K} \pi_k \sup_{\boldsymbol{z}\in D, \boldsymbol{\omega}\in\mathcal{S}_k} \big\{\bar{f}(\boldsymbol{z}, \boldsymbol{\omega}) - f^\star(\boldsymbol{z}, \boldsymbol{\omega})\big\}^2 + \frac{8B^2}{n} \\ &\qquad \le C_4 (\log n)^{2\max_{k\in[K]} \bar{\beta}_1^{(k)}} \cdot \sum_{k=1}^{K} \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})}, \end{aligned} \tag{26}$$

其中第一个不等式由式 (24) 以及对全部 $\boldsymbol{z} \in \mathbb{R}^d$、$\boldsymbol{\omega} \in \mathcal{S}$ 有 $\big|\bar{f}(\boldsymbol{z}, \boldsymbol{\omega}) - f^\star(\boldsymbol{z}, \boldsymbol{\omega})\big| \le 2B$ 推出；最后一个不等式由式 (25) 得到。令 $L_0 := L_3 + \big(L_1 \vee L_2\big)$，

$\boldsymbol{p}_0 := \big(2d, 2 \| \boldsymbol{p}_1 \|_\infty + 2 \| \boldsymbol{p}_2 \|_\infty, \ldots, 2 \| \boldsymbol{p}_1 \|_\infty + 2 \| \boldsymbol{p}_2 \|_\infty, \boldsymbol{p}_3\big) \in \mathbb{N}^{L_0+2}$，

$s_0 := 2\big(s_1 + s_2 + s_3\big) + 2(K \vee m)|L_1 - L_2|$。由 (P1)–(P4)，有 $\mathcal{F} \subseteq \mathcal{F}\big(L_0, \boldsymbol{p}_0, s_0\big)$。此外，

$$\frac{s_0 L_0 \log(es_0) + s_0 \log(ed)}{n} \le C_5 \log^3 n \cdot \frac{\sum_{k=1}^{K} n_k^{t_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} + s_2 \log s_2}{n}$$
$$= C_5 \log^3 n \cdot \left\{ \sum_{k=1}^{K} \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)}+t_*^{(k)})} + \frac{s_2 \log s_2}{n} \right\}, \qquad (27)$$

其中 $C_5 > 0$ 仅依赖 m, L_2, M_1, M_3, d 及 $\left(\boldsymbol{d}^{(k)}, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}\right)_{k=1}^{K}$。结合式 (26)、(27) 应用命题 1，即得最终结果。

附录 G 定理 3 的证明

定理 3 的证明。 不失一般性，可假定 $j_\star = d$。再定义 $\beta_\star^{(k)} := \beta_{r_\star^{(k)}}^{(k)}$。令 $\boldsymbol{X}_0$ 在 $[0,\,1]^d$ 上均匀分布，因此对 $j \in [d]$，$\| X_{0,j} \|_{\psi_1} \le 0.8 \le \xi_1$。对 $k \in [K-1]$，令 $A_k := [\sum_{\ell=1}^{k-1} \pi_\ell,\, \sum_{\ell=1}^{k} \pi_\ell)$，并令 $A_K := \left[\sum_{\ell=1}^{K-1} \pi_\ell,\, 1\right]$。给定 $f^{(1)}, \ldots, f^{(K)} : [0,\,1]^d \to [0,\,1/2]$，定义 $g_{(f^{(1)},\ldots,f^{(K)})} : [0,\,1]^d \to [0,\,1/2]$ 为 $g_{(f^{(1)},\ldots,f^{(K)})}(\boldsymbol{x}) := \sum_{k=1}^{K} \mathbf{1}_{\{x_d \in A_k\}} f^{(k)}(\boldsymbol{x})$，其中 $\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in [0,\,1]^d$。进一步，令 $P_{(f^{(1)},\ldots,f^{(K)})}$ 为 $(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0, Y_0)$ 的分布，其中当 $X_{0,d} \in A_k$ 时，$\boldsymbol{\Omega}_0 \mid \boldsymbol{X}_0 \sim \mathrm{Unif}(\mathcal{S}_k)$；$\boldsymbol{Z}_0 = \mathrm{Imp}(\widetilde{\boldsymbol{X}}_0)$（$\widetilde{\boldsymbol{X}}_0$ 是 $\boldsymbol{X}_0$ 的部分观测版本）；$Y_0 = g_{(f^{(1)},\ldots,f^{(K)})}(\boldsymbol{X}_0) + \varepsilon_0$，其中 $\varepsilon_0 \sim N(0,\, \xi_2^2/25)$ 与 $(\boldsymbol{X}_0, \boldsymbol{\Omega}_0)$ 独立。因此

$$\|Y_0\|_{\psi_2} \le \|g_{(f^{(1)},\ldots,f^{(K)})}(\boldsymbol{X}_0)\|_{\psi_2} + \|\varepsilon_0\|_{\psi_2} \le \frac{1}{2\sqrt{\log 2}} + \sqrt{\frac{8}{75}}\xi_2 \le \xi_2.$$

另外，注意当 $\boldsymbol{\omega} \in \mathcal{S}_k$ 时必有 $X_{0,d} \in A_k$，故 $g_{(f^{(1)},\ldots,f^{(K)})}(\boldsymbol{X}_0) = f^{(k)}(\boldsymbol{X}_0)$。于是，若对每个 $k \in [K]$，$f^{(k)}$ 仅依赖于 $\widetilde{\mathcal{J}}^{(k)} := \mathcal{J}^{(k)} \backslash \{d\}$ 中的坐标，则当 $\boldsymbol{\omega} \in \mathcal{S}_k$ 时，

$$f^\star(\boldsymbol{z}, \boldsymbol{\omega}) = \mathbb{E}(\boldsymbol{Y}_0 \mid \boldsymbol{Z}_0 = \boldsymbol{z}, \boldsymbol{\Omega}_0 = \boldsymbol{\omega}) = \mathbb{E}\left(g_{(f^{(1)},\ldots,f^{(K)})}(\boldsymbol{X}_0) \mid \boldsymbol{Z}_0 = \boldsymbol{z}, \boldsymbol{\Omega}_0 = \boldsymbol{\omega}\right)$$
$$= \mathbb{E}\left(f^{(k)}(\boldsymbol{X}_0) \mid \boldsymbol{Z}_0 = \boldsymbol{z}, \boldsymbol{\Omega}_0 = \boldsymbol{\omega}\right) = f^{(k)}(\boldsymbol{z}).$$

因而一般有 $f^\star(\boldsymbol{z}, \boldsymbol{\omega}) = \sum_{k=1}^{K} f^{(k)}(\boldsymbol{z}) \mathbf{1}_{\{\boldsymbol{\omega} \in \mathcal{S}_k\}}$。对 $k \in [K]$，令 $\mathcal{F}^{(k)}$ 为 $\mathcal{H}_{\mathrm{comp}}\left(q_k, \boldsymbol{d}^{(k)}, \boldsymbol{t}^{(k)}, \boldsymbol{\beta}^{(k)}, \boldsymbol{\gamma}^{(k)}\right)$ 中取值于 $[0,\,1/2]$ 且仅依赖 $\widetilde{\mathcal{J}}^{(k)}$ 中坐标的函数集合。

现已证明：若对所有 $k \in [K]$，$f^{(k)} \in \mathcal{F}^{(k)}$，则 $P_{(f^{(1)},\ldots,f^{(K)})} \in \mathcal{P}$。令 $\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0}$ 表示 $(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0, Y_0) \sim P_{(f^{(1)},\ldots,f^{(K)})} \in \mathcal{P}$ 时 $(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)$ 的联合分布；对 $k \in [K]$、$f^{(k)} \in \mathcal{F}^{(k)}$，令 $P_{f^{(k)}} := P_{(0,\ldots,0,f^{(k)},0,\ldots,0)}$。则

$$\inf_{\widehat{f}\in\widehat{\mathcal{F}}}\sup_{P\in\mathcal{P}}\mathbb{E}_{P^{\otimes n}}\big\{R(\widehat{f})-R(f^\star)\big\}\geq\inf_{\widehat{f}\in\widehat{\mathcal{F}}}\sup_{\substack{f^{(1)},\ldots,f^{(K)}:\\ f^{(\ell)}\in\mathcal{F}^{(\ell)}\,\forall\ell\in[K]}}\mathbb{E}_{P^{\otimes n}_{(f^{(1)},\ldots,f^{(K)})}}\big\{\|\widehat{f}-f^\star\|^2_{L_2(\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0})}\big\}$$

$$=\inf_{\widehat{f}\in\widehat{\mathcal{F}}}\sup_{\substack{f^{(1)},\ldots,f^{(K)}:\\ f^{(\ell)}\in\mathcal{F}^{(\ell)}\,\forall\ell\in[K]}}\sum_{k=1}^{K}\mathbb{E}_{P^{\otimes n}_{(f^{(1)},\ldots,f^{(K)})}}\int_{[0,1]^d\times\mathcal{S}}\big\{\widehat{f}(\boldsymbol{z},\boldsymbol{\omega})-f^{(k)}(\boldsymbol{z})\big\}^2\mathbb{1}_{\{\boldsymbol{\omega}\in\mathcal{S}_k\}}\,\mathrm{d}\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0}(\boldsymbol{z},\boldsymbol{\omega})$$

$$\geq\sum_{k=1}^{K}\inf_{\widehat{f}\in\widehat{\mathcal{F}}}\sup_{\substack{f^{(1)},\ldots,f^{(K)}:\\ f^{(\ell)}\in\mathcal{F}^{(\ell)}\,\forall\ell\in[K]}}\mathbb{E}_{P^{\otimes n}_{(f^{(1)},\ldots,f^{(K)})}}\int_{[0,1]^d\times\mathcal{S}}\big\{\widehat{f}(\boldsymbol{z},\boldsymbol{\omega})-f^{(k)}(\boldsymbol{z})\big\}^2\mathbb{1}_{\{\boldsymbol{\omega}\in\mathcal{S}_k\}}\,\mathrm{d}\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0}(\boldsymbol{z},\boldsymbol{\omega})$$

$$\geq\sum_{k=1}^{K}\inf_{\widehat{f}\in\widehat{\mathcal{F}}}\sup_{f^{(k)}\in\mathcal{F}^{(k)}}\mathbb{E}_{P^{\otimes n}_{f^{(k)}}}\int_{[0,1]^d\times\mathcal{S}}\big\{\widehat{f}(\boldsymbol{z},\boldsymbol{\omega})-f^{(k)}(\boldsymbol{z})\big\}^2\mathbb{1}_{\{\boldsymbol{\omega}\in\mathcal{S}_k\}}\,\mathrm{d}\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0}(\boldsymbol{z},\boldsymbol{\omega}).\tag{28}$$

现固定 $k\in[K]$，并对所有 $\ell\neq k$ 取 $f^{(\ell)}=0$。由于任何 $f^{(k)}\in\mathcal{F}^{(k)}$ 仅依赖 $\widetilde{\mathcal{J}}^{(k)}$ 中坐标，存在 $\widetilde{f}^{(k)}:[0,\,1]^{|\widetilde{\mathcal{J}}^{(k)}|}\to[0,\,1/2]$，使对所有 $\boldsymbol{x}=(x_1,\,\ldots,\,x_d)^\top\in[0,\,1]^d$，$f^{(k)}(\boldsymbol{x})=\widetilde{f}^{(k)}\big(\boldsymbol{x}_{\widetilde{\mathcal{J}}^{(k)}}\big)$，其中 $\boldsymbol{x}_{\widetilde{\mathcal{J}}^{(k)}}:=\big(x_j\big)_{j\in\widetilde{\mathcal{J}}^{(k)}}\in[0,\,1]^{|\widetilde{\mathcal{J}}^{(k)}|}$。因此，对平方可积 $f:[0,\,1]^m\to\mathbb{R}$、$m\in\mathbb{N}$ 记 $\|f\|_{L^2}:=\Big(\int_{\boldsymbol{x}\in[0,1]^m}f(\boldsymbol{x})^2\,d\boldsymbol{x}\Big)^{1/2}$，则对 $f_1^{(k)},\,f_2^{(k)}\in\mathcal{F}^{(k)}$，可推出

$$\int_{[0,1]^d\times\mathcal{S}}\big\{f_1^{(k)}(\boldsymbol{z})-f_2^{(k)}(\boldsymbol{z})\big\}^2\mathbb{1}_{\{\boldsymbol{\omega}\in\mathcal{S}_k\}}\,\mathrm{d}\mu_{\boldsymbol{Z}_0,\boldsymbol{\Omega}_0}(\boldsymbol{z},\boldsymbol{\omega})=\mathbb{E}\Big[\big\{f_1^{(k)}(\boldsymbol{Z}_0)-f_2^{(k)}(\boldsymbol{Z}_0)\big\}^2\mathbb{1}_{\{\boldsymbol{\Omega}_0\in\mathcal{S}_k\}}\Big]$$

$$\begin{aligned}&=\mathbb{E}\Big[\big\{\widetilde{f}_1^{(k)}(\boldsymbol{X}_{0,\widetilde{\mathcal{J}}^{(k)}})-\widetilde{f}_2^{(k)}(\boldsymbol{X}_{0,\widetilde{\mathcal{J}}^{(k)}})\big\}^2\mathbb{1}_{\{X_{0,d}\in A_k\}}\Big]\\&=\pi_k\mathbb{E}\Big[\big\{\widetilde{f}_1^{(k)}(\boldsymbol{X}_{0,\widetilde{\mathcal{J}}^{(k)}})-\widetilde{f}_2^{(k)}(\boldsymbol{X}_{0,\widetilde{\mathcal{J}}^{(k)}})\big\}^2\,\Big|\,X_{0,d}\in A_k\Big]\\&=\pi_k\big\|f_1^{(k)}-f_2^{(k)}\big\|_{L_2}^2.\end{aligned}\tag{29}$$

接着，用与 Schmidt-Hieber（2020，定理 3）类似的构造证明下界。定义 $R:=\lfloor\lambda n_k^{1/(2\bar{\beta}_\star^{(k)}+t_\star^{(k)})}\rfloor\in\mathbb{N}$，其中 $\lambda\geq16$ 稍后选择；令 $\rho:=1/R$、$\mathcal{U}:=\{0,\,\rho,\,2\rho,\,\ldots,\,(R-1)\rho\}^{t_\star^{(k)}}$。定义 $h:\mathbb{R}\to[0,\,1]$ 为 $h(x):=c_1e^{-1/\{x(1-x)\}}\mathbf{1}_{\{x\in(0,1)\}}$，其中 $c_1>0$ 只依赖 $\beta_\star^{(k)}$，并选取到使 $h\in\mathcal{H}_1^{\beta_\star^{(k)}}(\mathbb{R},\,1)$。再不失一般性假定 $\widetilde{\mathcal{J}}^{(k)}=\{1,\,\ldots,\,\big|\widetilde{\mathcal{J}}^{(k)}\big|\}$。对 $\boldsymbol{u}=\big(u_1,\,\ldots,\,u_{t_\star^{(k)}}\big)^\top\in\mathcal{U}$，定义 $\psi_{\boldsymbol{u}}:[0,\,1]^{t_\star^{(k)}}\to[0,\,1]$ 为

$$\psi_{\boldsymbol{u}}(x_1,\ldots,x_{t_*^{(k)}}):=\rho^{\beta_*^{(k)}}\prod_{j=1}^{t_*^{(k)}}h\left(\frac{x_j-u_j}{\rho}\right).$$

对满足 $\|\boldsymbol{\alpha}\|_1\leq\lceil\beta_\star^{(k)}\rceil-1$ 的 $\boldsymbol{\alpha}\in\mathbb{N}_0^d$，由于 $h\in\mathcal{H}_1^{\beta_\star^{(k)}}(\mathbb{R},\,1)$，有 $\|\partial^{\boldsymbol{\alpha}}\psi_{\boldsymbol{u}}\|_\infty\leq1$。此外，对满足 $\|\boldsymbol{\alpha}\|_1=\lceil\beta_\star^{(k)}\rceil-1$ 的 $\boldsymbol{\alpha}\in\mathbb{N}_0^d$，及所有 $\boldsymbol{x},\,\boldsymbol{y}\in[0,\,1)^{t_\star^{(k)}}$，有

$$
\begin{aligned}
\frac{|\partial^{\boldsymbol{\alpha}}\psi_{\boldsymbol{u}}(\boldsymbol{x})-\partial^{\boldsymbol{\alpha}}\psi_{\boldsymbol{u}}(\boldsymbol{y})|}{\|\boldsymbol{x}-\boldsymbol{y}\|_2^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}} &= \rho^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}\frac{\left|\prod_{j=1}^{t_*^{(k)}}h^{(\alpha_j)}\left(\frac{x_j-u_j}{\rho}\right)-\prod_{j=1}^{t_*^{(k)}}h^{(\alpha_j)}\left(\frac{y_j-u_j}{\rho}\right)\right|}{\|\boldsymbol{x}-\boldsymbol{y}\|_2^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}} \\
&\le \frac{\rho^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}}{\|\boldsymbol{x}-\boldsymbol{y}\|_2^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}}\sum_{\ell=1}^{t_*^{(k)}}\left|\prod_{j=\ell}^{t_*^{(k)}}h^{(\alpha_j)}\left(\frac{x_j-u_j}{\rho}\right)\prod_{j=1}^{\ell-1}h^{(\alpha_j)}\left(\frac{y_j-u_j}{\rho}\right)\right. \\
&\qquad \left.-\prod_{j=\ell+1}^{t_*^{(k)}}h^{(\alpha_j)}\left(\frac{x_j-u_j}{\rho}\right)\prod_{j=1}^{\ell}h^{(\alpha_j)}\left(\frac{y_j-u_j}{\rho}\right)\right| \\
&\le \sum_{\ell=1}^{t_*^{(k)}}\frac{\left|h^{(\alpha_\ell)}\left(\frac{x_\ell-u_\ell}{\rho}\right)-h^{(\alpha_\ell)}\left(\frac{y_\ell-u_\ell}{\rho}\right)\right|}{|(x_\ell-y_\ell)/\rho|^{\beta_*^{(k)}+1-\lceil\beta_*^{(k)}\rceil}} \le t_*^{(k)},
\end{aligned}
$$

其中第一个不等式来自三角不等式，第二、第三个来自 $h\in\mathcal{H}_1^{\beta_\star^{(k)}}(\mathbb{R},\,1)$。由此证明 $\psi_{\boldsymbol{u}}\in\mathcal{H}_{t_\star^{(k)}}^{\beta_\star^{(k)}}\left([0,\,1]^{t_\star^{(k)}},\,t_\star^{(k)}\right)$。对 $\boldsymbol{v}=\left(v_{\boldsymbol{u}}\right)_{\boldsymbol{u}\in\mathcal{U}}\in\{0,\,1\}^{|\mathcal{U}|}$，定义 $\phi_{\boldsymbol{v}}:[0,\,1]^{t_\star^{(k)}}\to[0,\,1]$ 为

$$
\phi_{\boldsymbol{v}}:=\sum_{\boldsymbol{u}\in\mathcal{U}}v_{\boldsymbol{u}}\psi_{\boldsymbol{u}}.
$$

由于 $\boldsymbol{u}\neq\boldsymbol{u}'$ 时 $\psi_{\boldsymbol{u}}$ 与 $\psi_{\boldsymbol{u}'}$ 的支撑不相交，有 $\phi_{\boldsymbol{v}}\in\mathcal{H}_{t_\star^{(k)}}^{\beta_\star^{(k)}}\left([0,\,1]^{t_\star^{(k)}},\,t_\star^{(k)}\right)$。

对 $r<r_\star^{(k)}$，若 $d_{r+1}^{(k)}\le d_r^{(k)}$，则定义 $\boldsymbol{g}_r^{(k)}:[0,\,1]^{d_r^{(k)}}\to[0,\,1]^{d_{r+1}^{(k)}}$ 为 $\boldsymbol{g}_r^{(k)}(\boldsymbol{x}):=\left(x_1,\,\ldots,\,x_{d_{r+1}^{(k)}}\right)^{\mathsf{T}}$；否则定义为 $\boldsymbol{g}_r^{(k)}(\boldsymbol{x}):=(\boldsymbol{x},\,0,\,\ldots,\,0)^{\mathsf{T}}$。对 $r>r_\star^{(k)}$，定义 $\boldsymbol{g}_r^{(k)}:[0,\,1]^{d_r^{(k)}}\to[0,\,1]^{d_{r+1}^{(k)}}$ 为 $\boldsymbol{g}_r^{(k)}(\boldsymbol{x}):=\left(x_1^{\beta_r^{(k)}\wedge1},\,0,\,\ldots,\,0\right)^{\mathsf{T}}$。对 $\boldsymbol{v}\in\{0,\,1\}^{|\mathcal{U}|}$，定义 $\boldsymbol{g}_{r_\star^{(k)},\boldsymbol{v}}^{(k)}:[0,\,1]^{d_{r_\star^{(k)}}^{(k)}}\to[0,\,1]^{d_{r_\star^{(k)}+1}^{(k)}}$ 为 $\boldsymbol{g}_{r_\star^{(k)},\boldsymbol{v}}^{(k)}(\boldsymbol{x}):=\left(\phi_{\boldsymbol{v}}\left(x_1,\,\ldots,\,x_{t_\star^{(k)}}\right),\,0,\,\ldots,\,0\right)^{\mathsf{T}}$。

于是对 $r\in[q_k]\backslash\{r_\star^{(k)}\}$，$\boldsymbol{g}_r^{(k)}$ 的每个分量都属于 $\mathcal{H}_{t_r^{(k)}}^{\beta_r^{(k)}}\left([0,\,1]^{d_r^{(k)}},\,\gamma_r^{(k)}\right)$；对 $\boldsymbol{v}\in\{0,\,1\}^{|\mathcal{U}|}$，$\boldsymbol{g}_{r_\star^{(k)},\boldsymbol{v}}^{(k)}$ 的每个分量属于 $\mathcal{H}_{t_\star^{(k)}}^{\beta_\star^{(k)}}\left([0,\,1]^{d_{r_\star^{(k)}}^{(k)}},\,\gamma_\star^{(k)}\right)$。令 $B:=\prod_{r=r_\star^{(k)}+1}^{q_k}\left(\beta_r^{(k)}\wedge1\right)=\bar{\beta}_\star^{(k)}/\beta_\star^{(k)}$。对 $\boldsymbol{v}=\left(v_{\boldsymbol{u}}\right)_{\boldsymbol{u}\in\mathcal{U}}\in\{0,\,1\}^{|\mathcal{U}|}$，定义 $f_{\boldsymbol{v}}^{(k)}:[0,\,1]^d\to[0,\,1/2]$ 为

$$
\begin{aligned}
f_{\boldsymbol{v}}^{(k)}(\boldsymbol{x}) &:= \frac{1}{2}\boldsymbol{g}_{q_k}^{(k)}\circ\cdots\circ\boldsymbol{g}_{r_*^{(k)}+1}^{(k)}\circ\boldsymbol{g}_{r_*^{(k)},\boldsymbol{v}}^{(k)}\circ\boldsymbol{g}_{r_*^{(k)}-1}^{(k)}\circ\cdots\circ\boldsymbol{g}_1^{(k)}(\boldsymbol{x}) \\
&= \frac{1}{2}\phi_{\boldsymbol{v}}(\boldsymbol{x})^B=\frac{1}{2}\sum_{\boldsymbol{u}\in\mathcal{U}}v_{\boldsymbol{u}}\psi_{\boldsymbol{u}}\left(x_1,\ldots,x_{t_*^{(k)}}\right)^B,
\end{aligned}
$$

根据构造，它满足 $f_{\boldsymbol{v}}^{(k)}\in\mathcal{F}^{(k)}$。对 $\boldsymbol{u}\in\mathcal{U}$，有 $\|\psi_{\boldsymbol{u}}^B\|_{L^2}^2=\rho^{2\bar{\beta}_\star^{(k)}+t_\star^{(k)}}\|h^B\|_{L^2}^{2t_\star^{(k)}}$。因此，对 $\boldsymbol{v},\,\boldsymbol{v}'\in\{0,\,1\}^{|\mathcal{U}|}$，

$$\|f_{\boldsymbol{v}}^{(k)} - f_{\boldsymbol{v}'}^{(k)}\|_{L_2}^2 = \frac{1}{4}\|\boldsymbol{v} - \boldsymbol{v}'\|_1 \cdot \rho^{2\bar{\beta}_*^{(k)} + t_*^{(k)}} \|h^B\|_{L_2}^{2t_*^{(k)}}. \tag{30}$$

由 Gilbert–Varshamov 引理（Samworth and Shah, 2026+，习题 8.9），存在 $\mathcal{V} \subseteq \{0,\,1\}^{|\mathcal{U}|}$，使 $|\mathcal{V}| \geq e^{|\mathcal{U}|/8}$，且对所有不同的 $\boldsymbol{v},\,\boldsymbol{v}' \in \mathcal{V}$，有 $\|\boldsymbol{v} - \boldsymbol{v}'\|_1 > |\mathcal{U}|/4$。因此，对这样的 $\boldsymbol{v},\,\boldsymbol{v}'$，由式 (29)、(30) 有

$$\begin{aligned}\int_{[0,1]^d \times \mathcal{S}} \left\{f_{\boldsymbol{v}}^{(k)}(\boldsymbol{z}) - f_{\boldsymbol{v}'}^{(k)}(\boldsymbol{z})\right\}^2 \mathbb{1}_{\{\boldsymbol{\omega} \in \mathcal{S}_k\}} \,\mathrm{d}\mu_{\boldsymbol{Z}_0, \boldsymbol{\Omega}_0}(\boldsymbol{z}, \boldsymbol{\omega}) &= \pi_k \|f_{\boldsymbol{v}}^{(k)} - f_{\boldsymbol{v}'}^{(k)}\|_{L_2}^2 \\ &> \frac{\pi_k}{4} \cdot \frac{\rho^{-t_*^{(k)}}}{4} \cdot \rho^{2\bar{\beta}_*^{(k)} + t_*^{(k)}} \|h^B\|_{L_2}^{2t_*^{(k)}} \geq \frac{\|h^B\|_{L_2}^{2t_*^{(k)}}}{16\lambda^{2\bar{\beta}_*^{(k)}}} \cdot \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)} + t_*^{(k)})}. \end{aligned} \tag{31}$$

此外，取 $\lambda := 2\left(100 \,\|\, h^B \,\|\, _{L^2}^{2t_\star^{(k)}}/\xi_2^2\right)^{1/(2\bar{\beta}_\star^{(k)} + t_\star^{(k)})} \vee 16$，则

$$\begin{aligned}\mathrm{KL}\left(P_{f_{\boldsymbol{v}}^{(k)}}^{\otimes n}, P_{f_{\boldsymbol{v}'}^{(k)}}^{\otimes n}\right) &= n\mathrm{KL}\left(P_{f_{\boldsymbol{v}}^{(k)}}, P_{f_{\boldsymbol{v}'}^{(k)}}\right) \\ &= \frac{25n}{2\xi_2^2} \cdot \int_{[0,1]^d \times \mathcal{S}} \left\{f_{\boldsymbol{v}}^{(k)}(\boldsymbol{z}) - f_{\boldsymbol{v}'}^{(k)}(\boldsymbol{z})\right\}^2 \mathbb{1}_{\{\boldsymbol{\omega} \in \mathcal{S}_k\}} \,\mathrm{d}\mu_{\boldsymbol{Z}_0, \boldsymbol{\Omega}_0}(\boldsymbol{z}, \boldsymbol{\omega}) \\ &= \frac{25n\pi_k}{2\xi_2^2} \|f_{\boldsymbol{v}}^{(k)} - f_{\boldsymbol{v}'}^{(k)}\|_{L_2}^2 \leq \frac{25\|h^B\|_{L_2}^{2t_*^{(k)}}}{8\xi_2^2} \cdot n_k \rho^{2\bar{\beta}_*^{(k)}} \\ &\leq \frac{1}{32\rho^{t_*^{(k)}}} \leq \frac{\log(|\mathcal{V}|)}{4}. \end{aligned} \tag{32}$$

结合式 (31)、(32) 应用 Fano 引理（Samworth and Shah, 2026+，推论 8.12），可知存在仅依赖 $\left(\xi_2,\, \bar{\beta}_\star^{(k)},\, t_\star^{(k)}\right)$ 的 $c^{(k)} > 0$，使

$$\begin{aligned}\inf_{\widehat{f} \in \widehat{\mathcal{F}}} \sup_{f^{(k)} \in \mathcal{F}^{(k)}} \mathbb{E}_{P_{f^{(k)}}^{\otimes n}} \int_{[0,1]^d \times \mathcal{S}} \left\{\widehat{f}(\boldsymbol{z}, \boldsymbol{\omega}) - f^{(k)}(\boldsymbol{z})\right\}^2 \mathbb{1}_{\{\boldsymbol{\omega} \in \mathcal{S}_k\}} \,\mathrm{d}\mu_{\boldsymbol{Z}_0, \boldsymbol{\Omega}_0}(\boldsymbol{z}, \boldsymbol{\omega}) \\ \geq c^{(k)} \pi_k n_k^{-2\bar{\beta}_*^{(k)}/(2\bar{\beta}_*^{(k)} + t_*^{(k)})}. \end{aligned} \tag{33}$$

由式 (28)、(33) 得到最终结果。

附录 H 辅助引理

引理 12。对 $c \geq 4$、$d \geq 1$，若 $m \geq 0$ 满足 $2^m \leq (cm)^d$，则 $m \leq 2d\log_2(cd)$。

证明。先考虑 $d = 1$。$x \geq 0$ 满足 $2^x \leq cx$ 当且仅当 $f(x) := x - \log_2 x - \log_2 c \leq 0$。由于 $x \geq \log_2 e$ 时 $f'(x) \geq 0$，任何满足 $f(m_0) > 0$ 的 $m_0 \geq \log_2 e$ 都是 m 的上界。但取 $m_0 = 2\log_2 c$ 时，对所有 $c \geq 4$，

$$f(m_0) = \log_2 c - \log_2\log_2 c - 1 \geq 0.$$

因此 $m \leq m_0$，如所需。对一般 $d \geq 1$，定义 $y{:=}m/d$，有 $2^y \leq cdy$，所以由 $d = 1$ 的情形可得结论。

引理 13。令 Y 为随机变量，对某个 $\xi > 0$ 满足 $\| Y \|_{\psi_2} \leq \xi$。令 Z 为取值于可测空间 $\mathcal{Z}$ 的随机变量。记 $B_n{:=}\xi\sqrt{2\log n}$，则

$$\mathbb{E}\{|Y - T_{B_n}Y|\} \leq \frac{\sqrt{\pi}\xi}{n^2}, \quad \mathbb{E}\{Y^2 - (T_{B_n}Y)^2\} \leq \frac{2\xi^2}{n^2}$$

以及

$$\mathbb{E}\Big\{\big(\mathbb{E}(Y \mid Z)\big)^2 - \big(\mathbb{E}(T_{B_n}Y \mid Z)\big)^2\Big\} \leq \frac{4\xi^2}{n}, \ \Big|\mathbb{E}\Big\{\mathbb{E}(Y \mid Z)Y - \mathbb{E}(T_{B_n}Y \mid Z)\cdot T_{B_n}Y\Big\}\Big| \leq \frac{4\xi^2}{n}.$$

证明。由 Markov 不等式，对全部 $t \geq 0$，

$$\mathbb{P}(|Y| \geq t) \leq \mathbb{E}\big(e^{|Y|^2/\xi^2}\big)e^{-t^2/\xi^2} \leq 2e^{-t^2/\xi^2}.$$

对于第一个不等式，

$$\begin{aligned}\mathbb{E}\{|Y - T_{B_n}Y|\} &= \int_0^\infty \mathbb{P}(|Y - T_{B_n}Y| \geq t)\,\mathrm{d}t \\ &\leq \int_0^\infty \mathbb{P}(|Y| \geq B_n + t)\,\mathrm{d}t \\ &\leq 2\int_0^\infty e^{-(B_n^2+t^2)/\xi^2}\,\mathrm{d}t = \frac{2}{n^2}\int_0^\infty e^{-t^2/\xi^2}\,\mathrm{d}t = \frac{\sqrt{\pi}\xi}{n^2}.\end{aligned}$$

对于第二个不等式，

$$\begin{aligned}\mathbb{E}\big\{Y^2 - (T_{B_n}Y)^2\big\} &= \int_0^\infty \mathbb{P}\big(Y^2 - (T_{B_n}Y)^2 \geq t\big)\,\mathrm{d}t \\ &\leq \int_0^\infty \mathbb{P}\big(Y^2 \geq B_n^2 + t\big)\,\mathrm{d}t \leq 2\int_0^\infty e^{-(B_n^2+t)/\xi^2}\,\mathrm{d}t = \frac{2\xi^2}{n^2}.\end{aligned}$$

对于第三个不等式，由 Cauchy–Schwarz 不等式，

$$\begin{aligned}&\mathbb{E}\Big\{\big(\mathbb{E}(Y \mid Z)\big)^2 - \big(\mathbb{E}(T_{B_n}Y \mid Z)\big)^2\Big\} \\ &\quad= \mathbb{E}\Big\{\big(\mathbb{E}(Y \mid Z) - \mathbb{E}(T_{B_n}Y \mid Z)\big)\cdot\big(\mathbb{E}(Y \mid Z) + \mathbb{E}(T_{B_n}Y \mid Z)\big)\Big\} \\ &\quad\leq \sqrt{\mathbb{E}\Big\{\big(\mathbb{E}(Y - T_{B_n}Y \mid Z)\big)^2\Big\}\cdot\mathbb{E}\Big\{2\big(\mathbb{E}(Y \mid Z)\big)^2 + 2\big(\mathbb{E}(T_{B_n}Y \mid Z)\big)^2\Big\}}. \qquad (34)\end{aligned}$$

此外，由条件 Jensen 不等式，

$$\mathbb{E}\Big\{\big(\mathbb{E}(Y-T_{B_n}Y\mid Z)\big)^2\Big\}\le\mathbb{E}\Big\{\mathbb{E}\big((Y-T_{B_n}Y)^2\mid Z\big)\Big\}\le\mathbb{E}\big\{Y^2-(T_{B_n}Y)^2\big\}\le\frac{2\xi^2}{n^2},\quad(35)$$

并且

$$\begin{aligned}\mathbb{E}\Big\{2\big(\mathbb{E}(Y\mid Z)\big)^2+2\big(\mathbb{E}(T_{B_n}Y\mid Z)\big)^2\Big\}&\le\mathbb{E}\Big\{2\mathbb{E}(Y^2\mid Z)+2\mathbb{E}\big((T_{B_n}Y)^2\mid Z\big)\Big\}\\&\le 4\mathbb{E}(Y^2)=4\int_0^\infty\mathbb{P}(Y^2\ge t)\,\mathrm{d}t\le 8\int_0^\infty e^{-t/\xi^2}\,\mathrm{d}t=8\xi^2.\quad(36)\end{aligned}$$

结合式 (34)、(35)、(36)，即得第三个不等式。

最后，对于第四个不等式，再次使用 Cauchy–Schwarz 不等式，有

$$\begin{aligned}&\Big|\mathbb{E}\Big\{\mathbb{E}(Y\mid Z)Y-\mathbb{E}(T_{B_n}Y\mid Z)\cdot T_{B_n}Y\Big\}\Big|\\&\quad\le\Big|\mathbb{E}\Big\{\mathbb{E}(Y\mid Z)(Y-T_{B_n}Y)\Big\}\Big|+\Big|\mathbb{E}\Big\{\big(\mathbb{E}(Y\mid Z)-\mathbb{E}(T_{B_n}Y\mid Z)\big)\cdot T_{B_n}Y\Big\}\Big|\\&\quad\le\sqrt{\mathbb{E}\big\{\big(\mathbb{E}(Y\mid Z)\big)^2\big\}\cdot\mathbb{E}\big\{(Y-T_{B_n}Y)^2\big\}}+B_n\mathbb{E}\big\{\big|\mathbb{E}(Y-T_{B_n}Y\mid Z)\big|\big\}.\quad(37)\end{aligned}$$

由式 (36)，

$$\mathbb{E}\big\{\big(\mathbb{E}(Y\mid Z)\big)^2\big\}\le\mathbb{E}(Y^2)\le 2\xi^2,\quad(38)$$

且

$$\mathbb{E}\big\{(Y-T_{B_n}Y)^2\big\}\le\mathbb{E}\big\{Y^2-(T_{B_n}Y)^2\big\}\le\frac{2\xi^2}{n^2}.\quad(39)$$

最后，

$$\mathbb{E}\big\{\big|\mathbb{E}(Y-T_{B_n}Y\mid Z)\big|\big\}\le\mathbb{E}\big(|Y-T_{B_n}Y|\big)\le\frac{\sqrt{\pi}\xi}{n^2}.\quad(40)$$

结合式 (37)、(38)、(39)、(40) 得到

$$\Big|\mathbb{E}\Big\{\mathbb{E}(Y\mid Z)Y-\mathbb{E}(T_{B_n}Y\mid Z)\cdot T_{B_n}Y\Big\}\Big|\le\frac{4\xi^2}{n},$$

即为所需。

引理 14。 令 $\beta,\ \gamma > 0$、 $\beta_0 := \lceil \beta \rceil - 1$、 $d \in \mathbb{N}$，且 $g \in \mathcal{H}_d^{\beta}\left([0,\ 1]^d,\ \gamma\right)$。则对全部 $\boldsymbol{x},\ \boldsymbol{y} \in [0,\ 1]^d$，

$$\left| g(\boldsymbol{y}) - \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 \le \beta_0} \frac{\partial^{\boldsymbol{\alpha}} g(\boldsymbol{x})}{\boldsymbol{\alpha}!} (\boldsymbol{y} - \boldsymbol{x})^{\boldsymbol{\alpha}} \right| \le \gamma d^{\beta_0} \|\boldsymbol{y} - \boldsymbol{x}\|_2^{\beta}$$

证明。 令 $\boldsymbol{u} := \boldsymbol{y} - \boldsymbol{x}$。根据 Taylor 定理，存在 $\theta \in (0,\ 1)$，使

$$g(\boldsymbol{y}) = \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 \le \beta_0 - 1} \frac{\partial^{\boldsymbol{\alpha}} g(\boldsymbol{x})}{\boldsymbol{\alpha}!} \boldsymbol{u}^{\boldsymbol{\alpha}} + \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 = \beta_0} \frac{\partial^{\boldsymbol{\alpha}} g(\boldsymbol{x} + \theta \boldsymbol{u})}{\boldsymbol{\alpha}!} \boldsymbol{u}^{\boldsymbol{\alpha}}.$$

于是

$$\begin{aligned} \left| g(\boldsymbol{y}) - \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 \le \beta_0} \frac{\partial^{\boldsymbol{\alpha}} g(\boldsymbol{x})}{\boldsymbol{\alpha}!} \boldsymbol{u}^{\boldsymbol{\alpha}} \right| &\le \sum_{\boldsymbol{\alpha} \in \mathbb{N}_0^d : \|\boldsymbol{\alpha}\|_1 = \beta_0} \left| \partial^{\boldsymbol{\alpha}} g(\boldsymbol{x} + \theta \boldsymbol{u}) - \partial^{\boldsymbol{\alpha}} g(\boldsymbol{x}) \right| \boldsymbol{u}^{\boldsymbol{\alpha}} \\ &\le d^{\beta_0} \gamma \|\boldsymbol{u}\|_2^{\beta - \beta_0} \cdot \|\boldsymbol{u}\|_2^{\beta_0} \end{aligned}$$

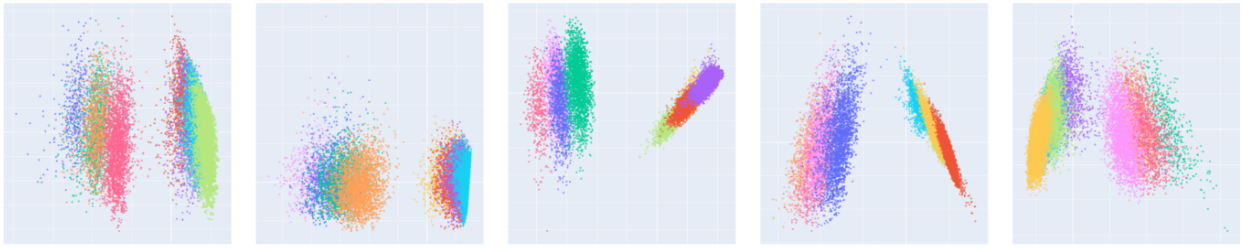
最后一个不等式利用以下事实： $\left| \{ \boldsymbol{\alpha} \in \mathbb{N}_0^d :\ \| \boldsymbol{\alpha} \|_1 = \beta_0 \} \right| = \binom{d + \beta_0 - 1}{\beta_0} \le d^{\beta_0}$，
$g \in \mathcal{H}_d^{\beta}\left([0,\ 1]^d,\ \gamma\right)$，以及 $\boldsymbol{u}^{\boldsymbol{\alpha}} = \prod_{j=1}^{d} u_j^{\alpha_j} \le \| \boldsymbol{u} \|_{\infty}^{\beta_0} \le \| \boldsymbol{u} \|_2^{\beta_0}$。

引理 15。 给定 $\mathcal{S}$ 的任意划分 $\{\mathcal{S}_1,\ \ldots,\ \mathcal{S}_K\}$，存在满足假设 1 的贝叶斯回归函数 $f^{\star}$。

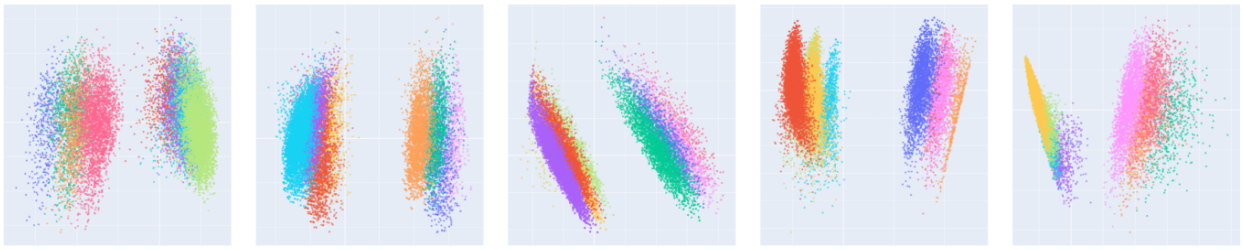
证明。 事实上，令 $\boldsymbol{X} = (X_1,\ \ldots,\ X_d)^{\top} \sim \mathrm{Unif}[0,\ 1]^d$，并令 $Y = \sum_{k=1}^{K} \mathbf{1}_{\{X_1 \ge (k-1)/K\}} + \varepsilon$，其中 $\varepsilon \sim N(0,\ 1)$ 与 $\boldsymbol{X}$ 独立。进一步定义 $\boldsymbol{\Omega}$：当 $X_1 \in [\,(k-1)/K,\ k/K)$ 时，$\boldsymbol{\Omega} \mid \boldsymbol{X} \sim \mathrm{Unif}\left(\mathcal{S}_k\right)$。于是只要 $\omega \in \mathcal{S}_k$，就对所有 $\boldsymbol{z} \in [0,\ 1]^d$ 有 $f^{\star}(\boldsymbol{z},\ \omega) = k$。

附录 I 合成数据中学习到的模式嵌入可视化

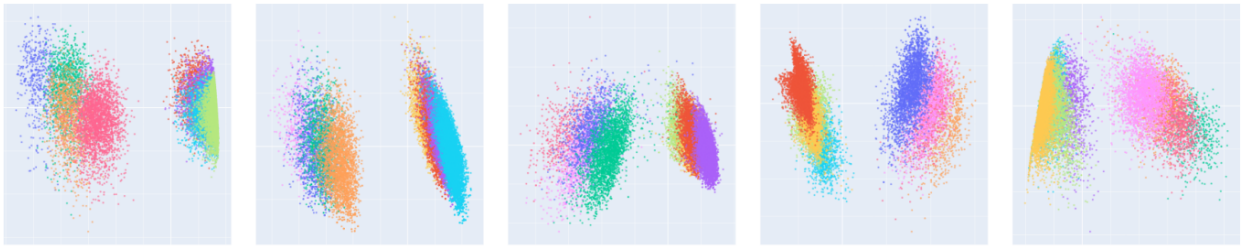
图 10–13 展示第 4.1 节模型 1–4 合成数据例子中学习到的嵌入。原始嵌入为四维，因此用前两个主成分进行可视化。图中不同颜色的聚类结构进一步说明：揭示向量的嵌入确实包含与预测性能相关的信息。有时，如图 11，各簇几乎不相交；另一些情形，如图 10，至少在投影到前两个主成分之后，各簇之间可能存在不可忽略的重叠。



(a) Model 1 MI

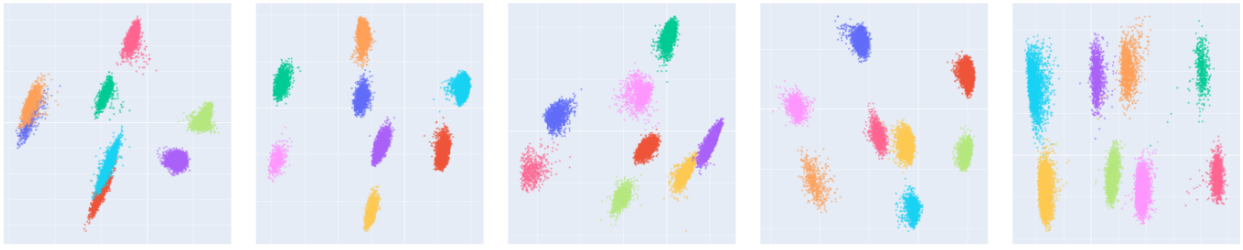


(b) Model 1 MF

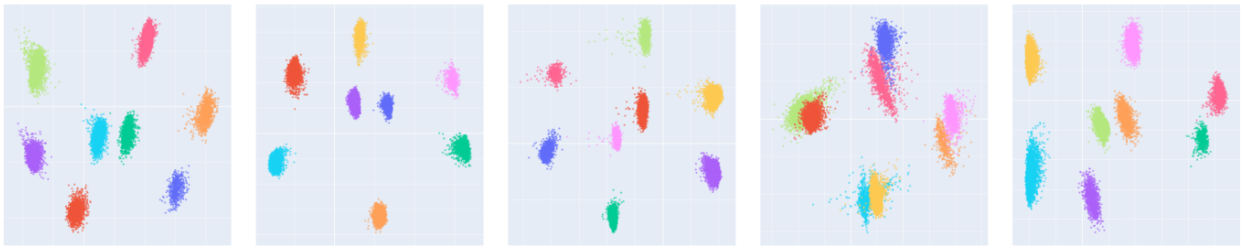


(c) Model 1 II

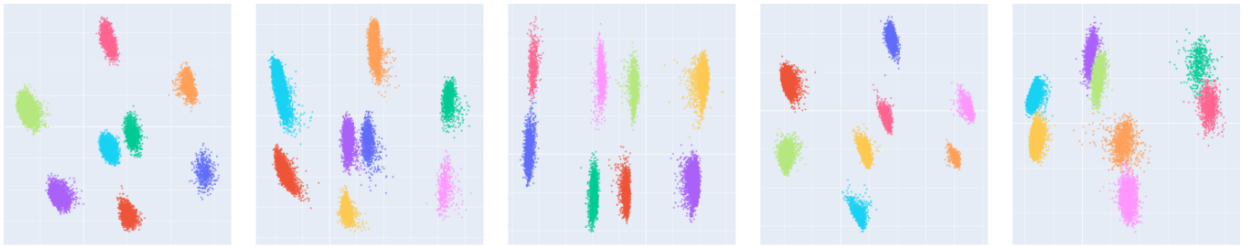
图 10： 模型 1 的五次不同合成数据实现、三种不同插补方法下学习到的嵌入可视化。上排 (a) 为均值插补（MI），中排 (b) 为 MissForest（MF），下排 (c) 为 Iterative Imputer（II）。贝叶斯回归函数划分含八个不同单元（由 ω_1, ω_2, ω_3 决定），以不同颜色绘制。



(a) Model 2 MI



(b) Model 2 MF

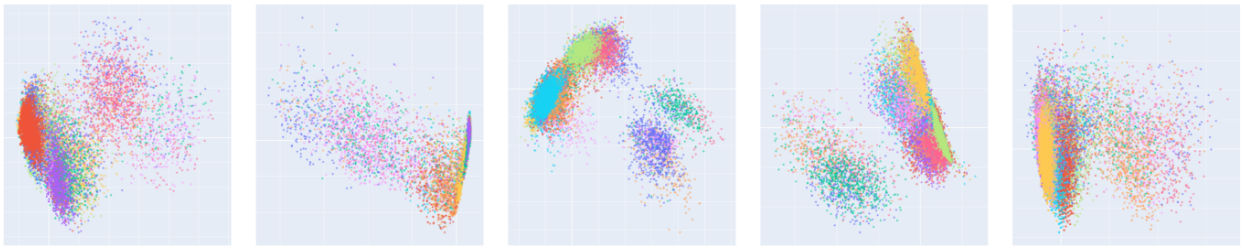


(c) Model 2 II

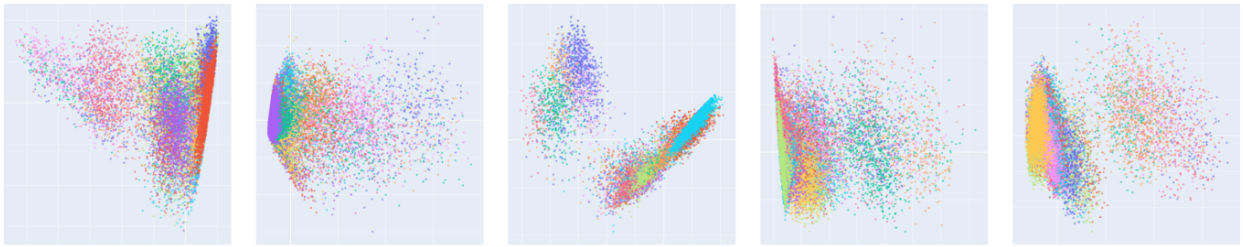
图 11： 模型 2 的五次不同合成数据实现、三种不同插补方法下学习到的嵌入可视化。上排 (a) 为均值插补（MI），中排 (b) 为 MissForest（MF），下排 (c) 为 Iterative Imputer（II）。贝叶斯回归函数划分含八个不同单元（由 ω_1, ω_2, ω_3 决定），以不同颜色绘制。



(a) Model 3 MI

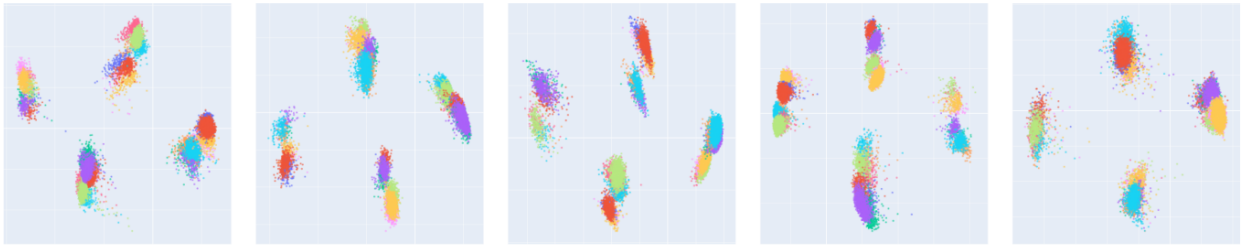


(b) Model 3 MF

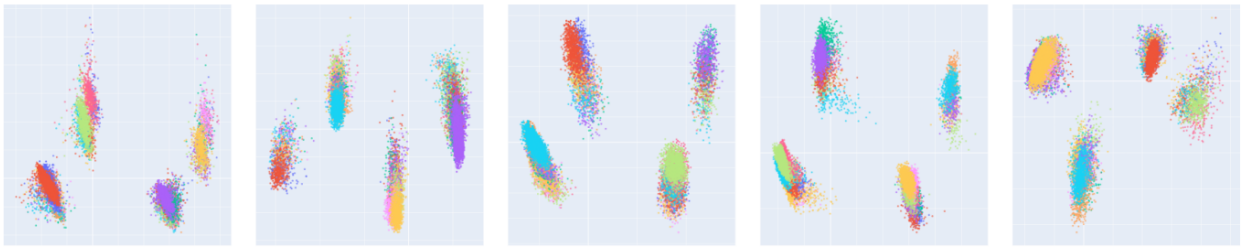


(c) Model 3 II

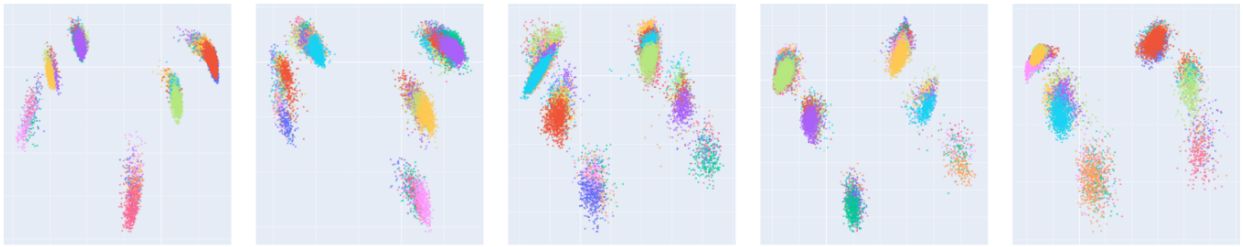
图 12： 模型 3 的五次不同合成数据实现、三种不同插补方法下学习到的嵌入可视化。上排 (a) 为均值插补（MI），中排 (b) 为 MissForest（MF），下排 (c) 为 Iterative Imputer（II）。贝叶斯回归函数划分含 32 个不同单元（由 $\omega_1, \ldots, \omega_5$ 决定），以不同颜色绘制。



(a) Model 4 MI



(b) Model 4 MF



(c) Model 4 II

图 13： 模型 4 的五次不同合成数据实现、三种不同插补方法下学习到的嵌入可视化。上排 (a) 为均值插补（MI），中排 (b) 为 MissForest（MF），下排 (c) 为 Iterative Imputer（II）。贝叶斯回归函数划分含 32 个不同单元（由 $\omega_1, \ldots, \omega_5$ 决定），以不同颜色绘制。

注释

1. 形式上，该集合配备 Ma et al.（2026+，第 2.1 节）所述的自然拓扑与 σ -代数。↩

2. 这一假设是为理论上的便利而作。在实践中（也包括第 4 节模拟），神经网络与插补算法会在同一数据集上训练。↩

3. 更形式化地，$f^\star$ 仅在 $(\boldsymbol{Z}_0, \boldsymbol{\Omega}_0)$ 分布的零测集之外定义，所以我们要求存在一个 $f^\star$ 的版本，使假设 1 的陈述成立。↩

4. 对 $D \subseteq \mathbb{R}^d$、$f : D \to \mathbb{R}$，若存在 $\mathcal{J} \subseteq [d]$、$|\mathcal{J}| = t$，使对所有满足 $\boldsymbol{x}_{\mathcal{J}} = \boldsymbol{y}_{\mathcal{J}}$ 的 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$，都有 $f(\boldsymbol{x}) = f(\boldsymbol{y})$，则称 f 仅依赖 t 个变量；$\boldsymbol{x}_{\mathcal{J}}, \boldsymbol{y}_{\mathcal{J}} \in \mathbb{R}^t$ 分别是 $\boldsymbol{x}, \boldsymbol{y}$ 由 $\mathcal{J}$ 中指标选出的子向量。$\mathcal{J} = \varnothing$ 时，这意味着 f 是常数函数。↩

5. 尽管 $\boldsymbol{g}_q$ 是实值函数，为方便起见，原文仍以粗体字母表示它。↩

6. 此处 sargmax 表示 argmax 集合中的最小元素。↩

7. 我们使用 该 GitHub 仓库 中的实现。↩

8. 这并非符号函数的标准定义，但神经网络文献中也有采用（如 Bartlett et al., 2019），并且便于本文使用。↩