更多模态总能带来帮助吗

从几何视角看缺失模态鲁棒性

非官方中文全文译文

原题：Do More Modalities Always Help? A Geometric Perspective on Missing-Modality Robustness

作者：Songyuan Sui[1]、Zhen Tan[2]、Mohan Zhang[3]、Rana Muhammad Shahroz Khan[3]、Xia Hu[1]、Tianlong Chen[3]

[1] 莱斯大学；[2] 史蒂文斯理工学院；[3] 北卡罗来纳大学教堂山分校。联系邮箱：Songyuan.Sui@rice.edu。

版本与许可：本译文以 2026 年 10 月 3 日提交的 arXiv:2610.04792v1 为唯一来源。官方 PDF 与用户云端仓库原件逐字节一致，SHA-256：`81b274abfcf2dcb3a44a451160ac3235cb46e78fa07336a5fd614eb8836ba328`。原作根据 Creative Commons Attribution 4.0 International（CC BY 4.0） 授权；本中文改编亦按 CC BY 4.0 提供。原作者保留署名；翻译不代表原作者审阅或认可。译制：ChatGPT，2026 年 10 月 26 日。

改动说明：正文、附录、证明、图表说明及参考文献题名译为中文；专名、层名称、参考文献的原始书目信息保留以便检索。4 幅图、25 张表及主要公式使用原 PDF 高清裁切，保留原始数据、符号与排版；中文图表说明和表头词汇说明随文提供。页面重新编排，章节、图表与公式编号对应原文，文内“我们”均指原作者。原件未修改。四幅图均经逐幅视觉审查，未发现第三方图像或独立权利排除标记。

摘要

模态缺失始终是多模态学习中的长期挑战。现有方法通常通过模态恢复或自适应策略处理这一问题，却忽视了多模态训练过程中形成、并在之后损害鲁棒性的模型内部跨模态依赖。我们系统刻画一种违反直觉的部署期失效模式：使用完整模态训练的模型，在推理时缺失一种模态的情况下，性能可能不如单模态模型。这一模式出现在多种架构中，包括融合模型、CLIP 式双塔模型和视觉语言模型。我们表明，这种退化与主参数子空间中学到的跨模态依赖密切相关。多模态训练会诱导这些子空间发生结构化旋转，尤其是在跨模态交互层中。这些旋转与模态缺失输入下任务对齐间隔的缩小、以及更大的任务感知表征损害相关。我们提出测地线遗忘（Geodesic Unlearning，GU），这是一种轻量参数编辑方法，利用 Grassmann 流形的子空间几何进行结构化子空间校正，以改善缺失模态鲁棒性。它沿测地线路径将主输入子空间旋转到单模态参考的方向。我们证明，在固定的子空间距离预算内，该校正使到参考的距离最小。跨架构、跨数据集实验表明，GU 在保持完整模态准确性的同时改善了模态缺失推理性能，并优于强缺失模态鲁棒性基线。这些发现支持从几何角度理解部署期模态缺失退化，并表明局部子空间编辑是实用的鲁棒性校正途径。

1 引言

多模态学习已在语言、视觉和医疗领域取得强劲表现 [66, 8, 44]。大语言模型（LLM）也支持超出纯文本的推理与解释，例如视觉、时间序列和关系数据库 [8, 46, 18, 45]。在联合训练的多模态模型中，结合互补信号通常能比相应的单模态模型获得更好的性能 [21]。然而，这一优势未必能迁移至部署阶段：传感器故障、数据采集不完整、隐私限制或系统约束都可能导致某种模态不可用 [58]。关于不平衡多模态学习的已有研究表明，联合训练可能使模态特定表征得不到充分优化 [37]。我们研究一种不同的部署期表现：当推理时一种模态完全缺失，使用完整模态训练的模型可能不如仅以可用模态训练的模型。这种情形常见于设备或传感器可用性不同的异构部署环境 [35, 40, 13]。

在多种架构中，我们观察到反复出现的性能排序：完整模态推理最好，单模态训练次之，而完整模态训练后以缺失模态推理最差。这意味着模态缺失退化不只是输入信息缺失所致，也与多模态训练所塑造的内部跨模态依赖有关。

我们从几何角度刻画这一退化。在参数层面，多模态模型表现出结构化的主子空间旋转；我们用匹配的多模态与单模态输入子空间之间的主夹角偏移来衡量，尤其关注跨模态交互层。旋转幅度与模态缺失差距高度相关。在表征层面，缺失模态推理下，最终误分类样本在中间多模态交互阶段表现出比正确分类样本更大的任务感知损害（负的有符号任务间隔），且这一差距会延续至分类器。这些局部参数空间与表征空间特征，促使我们超越恢复式或自适应方法，实施有针对性的参数级校正。

受上述发现启发，我们将缺失模态鲁棒性表述为一种特殊的机器遗忘问题：在输入缺失时减弱有害的跨模态依赖，同时保留有用的多模态功能。我们提出测地线遗忘（GU），一种轻量的训练后编辑方法。给定多模态模型及匹配的单模态参考，GU 以夹角-损害准则选出一个目标层进行编辑。它将选中的主子空间视作 Grassmann 流形上的一个点，沿测地线路径将其输入侧基旋转至单模态参考方向，并在保留主系数、输出因子与残差的情况下重构该层。理论分析确立了此校正在固定子空间距离预算下的几何最优性，并表明该路径使所有主夹角按比例推进。

在融合模型、CLIP 式双塔架构、视觉语言模型（VLM）和多个数据集上的实验进一步表明，GU 能提升模态缺失任务性能，同时基本保持完整模态准确性。与多模态专用方法、通用训练和适应基线以及参数编辑对照的比较，支持 GU 有利的鲁棒性-保持性权衡；当有害依赖集中于可编辑的交互层时，增益最强。

综上，我们的贡献如下：

- 在三大类多模态架构上，系统刻画了推理时一种模态完全不可用所造成的部署期退化。
- 提供退化的几何解释，并以参数和表征层面的证据说明：退化与跨模态交互层中的主子空间旋转和任务感知表征损害高度相关。
- 提出测地线遗忘：一种轻量、具有理论依据的 Grassmann 子空间编辑方法，可跨模型改善缺失模态鲁棒性，同时保留多模态效用。

2 相关工作

模态缺失仍然是多模态学习的挑战 [43, 68, 58]。现有方法通过恢复不可用信息，或改善模型对可用模态的利用来应对这一挑战。恢复式方法在数据层面 [63, 22, 49, 54, 69] 或表征层面 [35, 53, 74, 47, 12, 51] 插补缺失输入，依赖于跨模态相关性与重构质量。自适应方法通过灵活架构 [61, 50, 65]、参数适应 [19, 73] 或训练-推理策略 [52, 64, 20, 60, 57, 9] 适应缺失输入。作为补充，OGM-GE [37]、AGM [30]、DnR [56] 和 MCR [27] 等模态平衡方法，在联合训练期间调节各模态的相对学习贡献。我们关注的是部署时一种模态完全缺失后仍保留在模型中的有害参数依赖。我们诊断其与任务相关的主子空间几何，并在已经训练的模型中进行校正，提供一种可补充训练期鲁棒性目标的模型侧方法。

对神经网络的几何理解已从表征和参数两个角度得到研究。在表征层面，已有工作揭示了结构化的特征几何，包括单纯形类别结构 [36]、模型之间的表征相似性 [29]，以及与泛化和鲁棒性相关的基于间隔的几何 [11, 34]。在参数层面，近期研究表明模型参数和梯度往往集中在低维子空间，推动了低秩适应及基于子空间的优化 [19, 72, 41]。更近期的 Grassmann 流形方法刻画这些子空间的演化，并利用测地线路径实现保持结构的更新 [10, 17, 39]。我们的工作将这些几何视角与缺失模态鲁棒性相联系，表明多模态训练会诱导主参数子空间中的结构化旋转，而这些旋转与缺失输入下的任务感知表征损害相关。

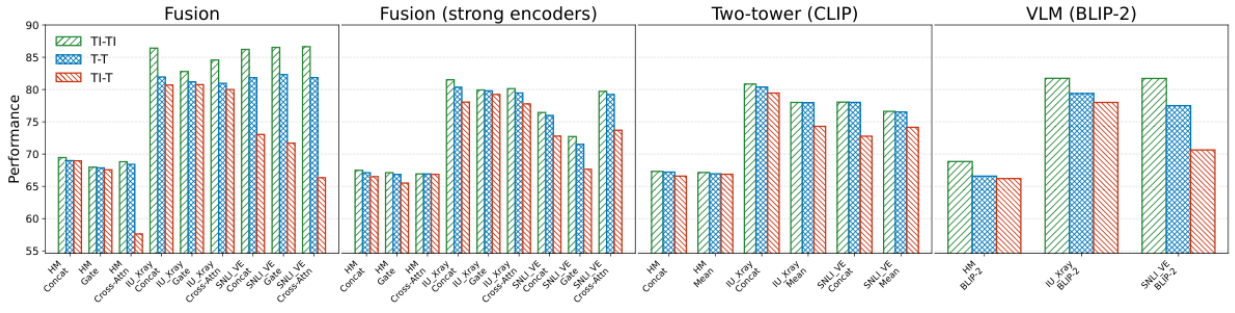


图 1 跨架构和数据集的模态缺失退化。报告 TI-TI、T-T 和 TI-T 设置的 F1 分数。27 种设置中有 26 种呈现 TI-TI > T-T > TI-T，揭示了一种反复出现的部署期模态缺失退化模式。图中 Performance 为性能，Fusion 为融合模型，strong encoders 为强编码器，Two-tower 为双塔，VLM 为视觉语言模型。

机器遗忘（MU）最初由隐私领域提出，旨在不进行完全重训练的情况下移除特定训练数据的影响 [4, 3]。现有方法包括数据侧干预 [67, 48]、训练期更新 [5, 25]、解码期控制 [14, 38] 和免训练参数编辑 [24, 2]。在隐私之外，MU 也被用于改善持续学习 [55]、领域适应 [1] 和领域泛化 [70] 等场景中的模型行为。我们发现多模态训练会在输入缺失时诱导有害跨模态依赖，因此重新利用 MU 来选择性削弱这些依赖，同时保留有用的多模态能力。据我们所知，本工作首次将缺失模态鲁棒性表述为遗忘问题，并通过几何参数编辑加以解决。

3 问题设置与预备知识

3.1 部署期模态缺失设置

考虑定义在模态集合 $\mathcal{M} = \{1, \ldots, M\}$ 上的多模态学习问题，每种模态 $m \in \mathcal{M}$ 对应输入空间 $\mathcal{X}_m$。完整模态输入空间为 $\mathcal{X}_{\text{full}} = \prod_{m \in \mathcal{M}} \mathcal{X}_m$，完整输入记为 $x = (x_1, \ldots, x_M)$。我们研究部署期模态缺失设置：模型以完整模态输入训练，却在推理时一种或多种模态不可用的情况下接受评估。引入

空符号 $\perp$，定义 $\mathcal{X}_{\text{miss}} = \prod_{m \in \mathcal{M}} (\mathcal{X}_m \cup \{\perp\})$。若部署时模态 m 缺失，相应输入为 $x_{-m} = (x_1, \ldots, x_{m-1}, \perp, x_{m+1}, \ldots, x_M)$。实践中，$\perp$ 可实现为掩码词元、置零特征流或学习得到的空嵌入。我们重点关注具有实际重要性的单一模态缺失情况。对于文本-图像等双模态系统，在模态缺失评估中，每个测试样本的同一种模态均完全缺失，而另一模态仍然可用。

3.2 评估协议与模态缺失差距

我们用双模态文本-图像模型实例化这一设置，以 T 表示文本、I 表示图像。考虑三种训练-测试方式：TI-TI 用文本+图像训练和测试；T-T 仅用文本训练和测试；TI-T 用文本+图像训练，却仅用文本测试。除非另有说明，我们研究缺失图像评估，即文本仍然可用，图像在推理时被移除。我们定义模态缺失差距 $\Delta_{\text{miss}} = \text{Perf}(\text{TI-TI}) - \text{Perf}(\text{TI-T})$，以及单模态鲁棒性差距 $\Delta_{\text{uni}} = \text{Perf}(\text{T-T}) - \text{Perf}(\text{TI-T})$。其中 $\text{Perf}(\cdot)$ 表示任务指标，在主要实验中为 F1 分数。前者衡量部署时移除图像模态后的性能损失；后者衡量模态缺失的多模态模型落后于文本专用模型的程度。

表 1 分析采用的代表性模型家族。覆盖显式融合架构、对齐的双塔编码器和 VLM 等不同多模态集成机制。表头 Model Family / Backbone(s) / Variants 分别为模型家族 / 骨干网络 / 变体；Concat 为拼接，Gate 为门控，Cross-Attention 为交叉注意力，Mean Pooling 为均值池化，Late Concat 为后期拼接，Classifier Head 为分类头。

Model Family	Backbone(s)	Variants
Fusion	RoBERTa [33] + ResNet50 [28]	Concat, Gate, Cross-Attention
Fusion (strong encoders)	Qwen [62] + OpenCLIP [23]	Concat, Gate, Cross-Attention
Two-tower	OpenCLIP	Mean Pooling, Late Concat
VLM	BLIP-2 [31]	Classifier Head

3.3 参数子空间几何

为研究多模态训练如何改变层参数，我们分析所选权重矩阵的主奇异子空间。对于层权重矩阵 $W \in \mathbb{R}^{d_o \times d_i}$，设其奇异值分解（SVD）为 $W = U\Sigma V^\top$。使用前 k 个奇异向量 $U_k = [u_1, \ldots, u_k]$ 与 $V_k = [v_1, \ldots, v_k]$，分别定义主输出子空间和主输入子空间。右奇异向量 V_k 确定该层读取的主导输入方向，U_k 则确定对应输出方向。由于任意正交矩阵 $Q \in \mathbb{R}^{k \times k}$ 都使 V_k 与 $V_k Q$ 张成同一子空间，与基无关的对象就是 $S = \text{span}(V_k) \in \text{Gr}(k, d_i)$；输出子空间类似地定义在 $\text{Gr}(k, d_o)$ 上。给定多模态模型 W_{TI} 和单模态参考模型 W_{T}，我们比较对应的输入和输出子空间，用主夹角、子空间重叠和 Frobenius 距离等标准度量，量化多模态训练如何改变参数几何。

4 模态缺失退化的实证分析

4.1 分析范围 架构与基准

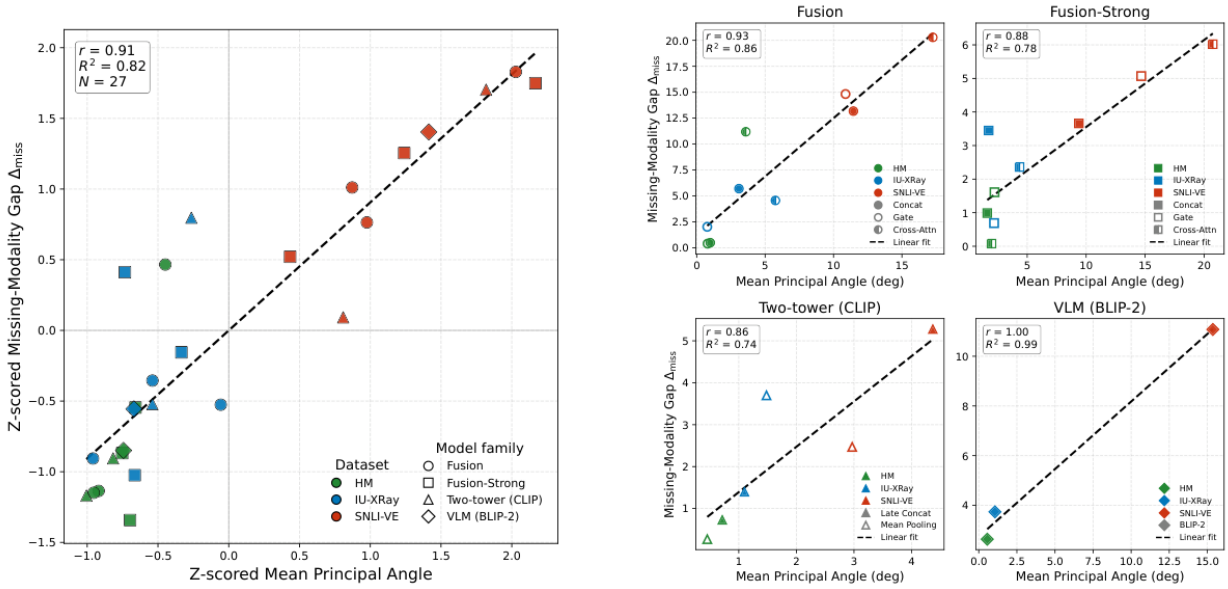
如表 1 所示，分析覆盖三个代表性多模态架构家族：融合模型、双塔双编码器模型和视觉语言模型。这一划分遵循近期按架构组织方式和融合策略对多模态系统分类的综述 [71, 16, 32]。所选系统在编码、对齐和融合模态的方式上存在差异，使我们能够检验部署期模态缺失退化是依赖于某一特定架构，还是更普遍地出现。所有分析均采用第 3.2 节定义的部署期缺失图像设置。数据集细节、评估指标和实现协议见第 6 节。

4.2 RQ1 模态缺失退化是否跨架构一致

观察 1 在不同架构和数据集上，完整模态推理的表现最好，而模态缺失推理通常不如单模态训练。

关于不平衡多模态学习的先前研究已表明，联合多模态训练可能导致模态特定表征优化不足 [37]。我们考察一个不同的部署期问题：用完整模态训练的模型，在推理时一种模态完全不可用后，是否依然鲁棒。图 1 在表 1 的 27 个架构-数据集组合上比较第 3.2 节的三种方式。27 个设置中的 26 个满足 $\text{Perf}(\text{TI-TI}) > \text{Perf}(\text{T-T}) > \text{Perf}(\text{TI-T})$；全部 27 个设置均满足 $\text{Perf}(\text{T-T}) > \text{Perf}(\text{TI-T})$。完整数值结果见附录 C.1。

在这 27 个设置中，模态缺失差距平均为 4.74 个 F1 点，但范围从 0.08 到 20.29。一般而言，与门控融合或均值池化双编码器等跨模态耦合较弱的架构相比，交叉注意力融合等具有更显式跨模态交互的架构，往往具有更大的模态缺失差距。这表明退化不仅是移除输入信息的后果，也与多模态训练期间形成的内部跨模态依赖有关。这些依赖可从参数子空间角度分析。



(a) Normalized correlation across model families.

(b) Raw correlation within each architecture.

图 2 主子空间旋转与模态缺失退化相关。（a）家族内 z 分数标准化揭示总体正相关；（b）家族内原始测量无需标准化便显示一致的正相关。横轴为平均主夹角（a 为 z 分数，b 为角度），纵轴为模态缺失差距（a 为 z 分数）；Linear fit 为线性拟合。

4.3 RQ2 参数几何是否反映退化

观察 2 跨模态交互层中更大的主子空间旋转，与更大的模态缺失差距呈现强正相关。

我们检验第 4.2 节的退化是否在参数空间中具有可测量的特征。针对每个候选层，使用第 3.3 节定义的主奇异子空间，将 TI 训练模型与仅文本参考进行比较。以平均主夹角 $\bar{\theta} = k^{-1}\sum_{i=1}^{k}\theta_i$ 衡量二者的差异，其中 $\theta_i = \arccos\sigma_i\left(V_{\text{TI},k}^{\top}V_{\text{T},k}\right)$，$\sigma_i(\cdot)$ 表示第 i 个奇异值。

图 2 显示，交互层子空间旋转强烈反映模态缺失退化。为消除尺度差异而在家族内进行 z 分数标准化后，图 2(a) 显示全部 27 个架构-数据集设置中，平均主夹角与模态缺失差距高度正相关（$r = 0.91$，$R^2 = 0.82$）。图 2(b) 中，家族内原始测量也呈现相同关系，包括融合模型（$r = 0.93$，$R^2 = 0.86$）、强编码器融合模型（$r = 0.88$，$R^2 = 0.78$）和 CLIP 式双塔模型（$r = 0.86$，$R^2 = 0.74$）。BLIP-2 的趋势也为正，但因为仅含三个点，应将其作为描述性结果理解。在 SNLI-VE 上，Fusion Cross-Attention 的差距为 20.29 个 F1 点，`attn_v_from_t_in_proj` 的输入/输出平均主夹角为 16.00°/16.57°，而最终分类器处为 1.95°/0.00°（附录 C.2）。

这些结果表明存在强正相关，而且并非完全由标准化造成。结果也意味着多模态训练诱导的参数变化并不均匀，最有信息量的几何变化集中在跨模态交互层。因此，主夹角偏移为模态缺失失效提供了几何特征。这种相关性的强度和一致性，促使我们将交互层子空间作为鲁棒性校正的局部目标。

4.4 RQ3 表征损害集中在哪里

观察 3 最终错误样本相对于最终正确样本的任务感知损害，始终体现在多模态交互的中间阶段，并经常延续至分类器附近。

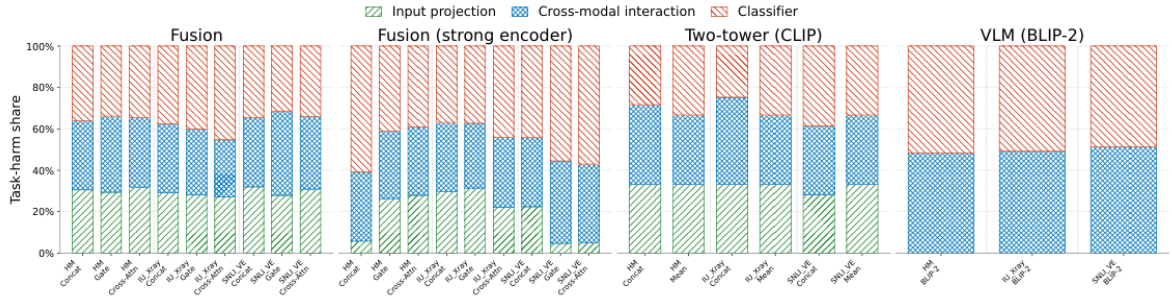


图 3 任务感知表征损害的阶段分布。最终错误样本与最终正确样本之间的损害差距出现在跨模态交互阶段，并经常延续至分类器附近。Task-harm share 为任务损害占比，Input projection 为输入投影，Cross-modal interaction 为跨模态交互，Classifier 为分类器。

接下来，我们定位由模态缺失输入诱导的任务相关表征变化。对于本文的二分类任务，在每个被探测阶段使用质心-间隔诊断。令 μ_+ 和 μ_- 为由该阶段表征计算的类别质心，任务方向为 $d = \mu_+ - \mu_-$，中点为 $c = (\mu_+ + \mu_-)/2$。对表征 $h(x)$ 及标签 $y \in \{+1, -1\}$，定义有符号任务间隔 $m(x) = y \cdot (h(x) - c)^{\top} \hat{d}$，其中 $\hat{d} = d / \| d \|_2$；定义 $\mathrm{Harm}(x) = -m(x)$。错误集 $\mathcal{E}$ 和正确集 $\mathcal{C}$ 根据模态缺失评估下的最终预测来确定。随后以同一划分探测中间表征，计算 $\Delta_{\mathrm{harm}} = \mathbb{E}_{x \in \mathcal{E}}[\mathrm{Harm}(x)] - \mathbb{E}_{x \in \mathcal{C}}[\mathrm{Harm}(x)]$。

图 3 总结最终错误与最终正确样本损害差距的阶段分布。柱状图在各数据集和模型设置内部归一化，因此体现的是差距集中在哪里，而非绝对大小。最终错误样本在分类器附近表现出更大损害，但这种差距在最终决策层之前的跨模态交互阶段就已明显。各设置中，这些阶段占据损害差距的相当大比例，与第 4.3 节中最强子空间旋转也发生在跨模态交互层的发现一致。因此，在若干设置中，分类器阶段的损害更适合解释为上游效应向下游的延续，而非仅存在于分类器的效应。详细逐层结果见附录 C.3。

第 4.2 至 4.4 节共同为方法设计提供了实证基础：退化广泛存在，与交互层子空间旋转高度相关，并伴随着集中在多模态交互阶段周围的任务感知表征变化。因此，我们将识别出的交互层子空间作为鲁棒性校正的局部目标。

5 测地线遗忘

5.1 概述

第 4 节将跨模态交互层识别为局部目标。这些层的主子空间旋转反映模态缺失退化，其表征也表现出任务感知损害。给定训练好的多模态模型及匹配的单模态参考，我们提出测地线遗忘（GU），对选出的一个层执行轻量训练后校正。GU 用夹角-损害准则选择目标层，沿 Grassmann 测地线将主输入侧子空间旋转至对应单模态子空间方向，并在保留主系数、输出因子和残差结构的情况下重构层。这在输入缺失时选择性减弱有害跨模态依赖，同时保留有用的多模态功能。同一子空间编辑流程适用于融合模型、CLIP 式双塔模型及 BLIP-2 模型，只需按架构改变目标层，从而实现统一的训练后校正。

5.2 目标层选择

对于每个模型，GU 从第 4 节分析的交互层及其附近的投影/分类器层中选择一个目标层。对每个候选层 ℓ，令 θ_ℓ 为 TI 模型与 T 参考的前 k 维输入子空间之间的平均主夹角，$\Delta_{\mathrm{harm},\ell}$ 为模态缺失评估下在该层测量的最终错误与最终正确样本损害差距。我们在开发集上按下式对各层排序：

$$s_\ell = z(\theta_\ell) + z(\Delta_{\mathrm{harm},\ell}), \tag{1}$$

其中 $z(\cdot)$ 表示在同一模型的候选层之间进行 z 分数标准化。编辑 s_ℓ 最大的层；测试集只用于最终评估。

5.3 子空间重新对齐与重构

给定所选多模态层权重 $W_{\mathrm{TI}} \in \mathbb{R}^{d_o \times d_i}$，其 SVD 为 $W_{\mathrm{TI}} = U_{\mathrm{TI}}\Sigma_{\mathrm{TI}}V_{\mathrm{TI}}^\top$，我们将其分解为前 k 阶主分量与残差：

$$W_{\mathrm{TI}} = U_{\mathrm{TI},k}\Sigma_{\mathrm{TI},k}V_{\mathrm{TI},k}^\top + R_{\mathrm{TI}}, \qquad R_{\mathrm{TI}} = W_{\mathrm{TI}} - U_{\mathrm{TI},k}\Sigma_{\mathrm{TI},k}V_{\mathrm{TI},k}^\top. \tag{2}$$

诊断将任务相关偏差定位在主输入子空间中，因此 GU 编辑这一方向。令 $V_{\mathrm{T},k}$ 为匹配单模态参考中对应前 k 维输入子空间的正交归一基。GU 计算编辑后子空间的正交归一基：

$$V(\eta) = \mathrm{Geodesic}(V_{\mathrm{TI},k}, V_{\mathrm{T},k}; \eta), \qquad \eta \in [0,1], \tag{3}$$

其中 η 控制编辑强度：$\eta = 0$ 使多模态子空间保持不变，$\eta = 1$ 则沿测地线路径到达单模态参考端点。显式测地线构造见附录 D.1。编辑后的参数重构为：

$$W' = R_{\mathrm{TI}} + U_{\mathrm{TI},k}\Sigma_{\mathrm{TI},k}V(\eta)^\top. \tag{4}$$

这一重构保留 TI 输出因子 $U_{\mathrm{TI},k}$、主系数 $\Sigma_{\mathrm{TI},k}$ 和残差 R_{TI}，而直接权重插值也会改变这些分量。

几何依据。令 $S_{\mathrm{TI}} = \mathrm{span}\left(V_{\mathrm{TI},k}\right)$、$S_{\mathrm{T}} = \mathrm{span}\left(V_{\mathrm{T},k}\right)$、$S_\eta = \mathrm{span}\left(V\left(\eta\right)\right)$。以 d 表示 Grassmann 测地距离，即主夹角向量的 ℓ_2 范数，并令 $D = d\left(S_{\mathrm{TI}}, S_{\mathrm{T}}\right)$。对于满足 $d\left(S_{\mathrm{TI}}, S\right) \le \eta D$ 的任意候选子空间 S，最短测地线给出：

$$d(S_{\mathrm{TI}}, S_\eta) = \eta D, \qquad d(S_\eta, S_{\mathrm{T}}) = (1-\eta)D \le d(S, S_{\mathrm{T}}). \tag{5}$$

因此，在同样的子空间距离预算内，GU 到达的子空间与参考的距离不会大于任何其他编辑得到的子空间。它使每个主夹角推进其自身的 η 比例，而对齐基的线性插值随后再正交归一化，通常会产生依赖夹角的推进幅度。附录 D.2 提供证明及与线性路径的比较。目标层选择和编辑策略的受控比较见附录 F.5。

6 实验

6.1 实验设置

数据集与指标。我们在三个多模态基准上评估 GU：用于社交多模态分类的 Hateful Memes [26]、用于视觉蕴涵的 SNLI-VE [59]、用于医疗视觉语言预测的 IU-XRay [6]。这三个基准均在部署期模态缺失设置下表述为二分类任务。为考虑潜在类别不平衡，主要指标采用 F1。更多数据集信息见附录 E.1。附录 F.6 进一步在多项选择 VQA 基准 A-OKVQA [42] 上评估 GU。

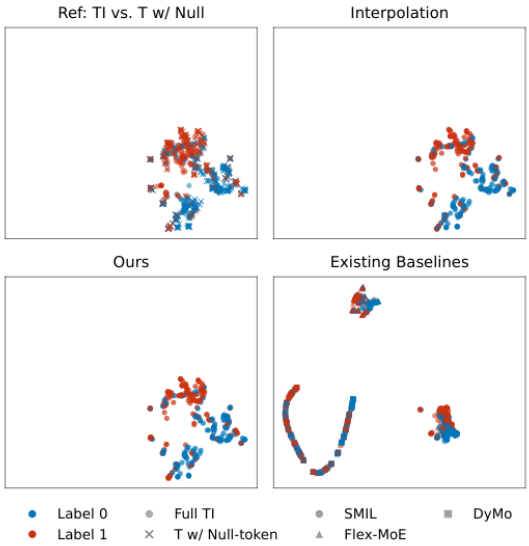
模型家族。采用表 1 总结的模型家族。对每个数据集和模型家族，训练使用文本与图像输入的完整多模态模型，记为 TI 模型。采用相同的整体参数化训练匹配的 T 参考，在训练和推理时均以空输入替代图像分支。这实现了 T-T 方式，同时保持层形状对齐，以便子空间比较与编辑。

基线。比较涵盖三组方法。多模态专用方法包括统一融合设置下的 SMIL [35]、Flex-MoE [65] 和 DyMo [9]，以及在这一设置之外、兼容架构上的 MoRA [73] 和 OGM-GE [37]。通用训练和适应基线包括训练后 LoRA [19] 与 Dual CE；Dual CE 联合监督完整输入路径和缺失图像路径。参数编辑对照包括遵循参数空间编辑思想 [24] 的层插值（Weight），以及对齐子空间线性插值（Linear）。这些对照隔离了被编辑对象和插值路径的影响。附录 E.2 详述其定义、架构覆盖和协议；附录 F.4 与 F.5 提供更多比较。

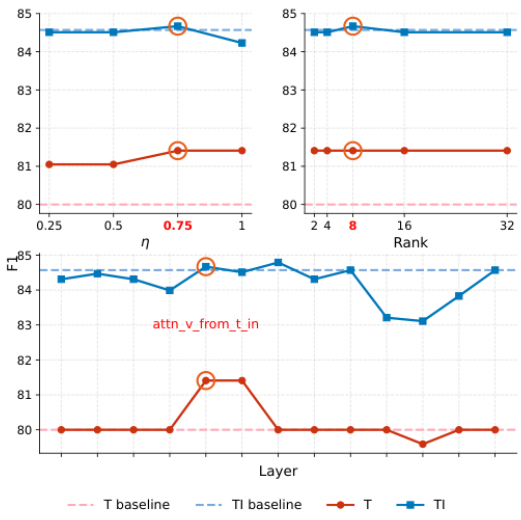
实现。GU 在训练完成后应用。与缺失模态基线的主要比较采用统一的 RoBERTa-ResNet50 交叉注意力融合设置。跨家族鲁棒性与保持性评估中，GU 和层插值应用于表 1 的所有模型家族。我们同时评估缺失图像恢复能力和完整模态保持性。基线协议与实现细节见附录 E.2 和 E.4。

表 2 主要缺失图像性能（TI-T，F1 越高越好）。数值为三次运行均值。下划线和粗体分别表示次优及最优结果；括号内为相对次优结果的增益。Dataset 为数据集，Null-token 为空词元，Interpolation 为插值，GU (Ours) 为本文 GU。

Dataset	Null-token	SMIL	Flex-MoE	DyMo	Interpolation	**GU (Ours)**
HM	57.63	56.60	47.58	48.82	<u>58.50</u>	**60.88** (+2.38)
IU-XRay	80.00	79.21	71.02	79.19	<u>80.14</u>	**81.41** (+1.27)
SNLI-VE	66.35	<u>72.20</u>	70.74	61.30	67.29	**74.41** (+2.21)



(a) UMAP of fusion-layer representations.



(b) Ablations of η, rank, and target layer.

图 4 表征结构与消融分析。（a）在 SNLI-VE 上，GU 与层插值保留了相似的 UMAP 整体布局；（b）在 IU-XRay 上，目标层选择对鲁棒性恢复的影响最大。Label 为标签，Full TI 为完整 TI，T w/ Null-token 为带空词元的仅文本输入，Existing Baselines 为已有基线；Rank 为秩，Layer 为层，T baseline / TI baseline 为对应基线。

6.2 部署期模态缺失设置的主要结果

性能。表 2 报告 TI-T 设置下三次独立运行的平均 F1，此时推理阶段图像模态完全缺失。相应样本标准差及补充的十随机种子配对显著性检验见附录 F.1。GU 在全部三个数据集上的平均 F1 均为所比较方法中最高，相比各数据集最强基线，在 Hateful Memes、IU-XRay、SNLI-VE 上分别提高 +2.38、+1.27、+2.21。这些一致增益仅通过训练后编辑一个选定层获得。因此，GU 的优势来自直接处理第 4 节所识别的失效模式：局部参数子空间中的有害跨模态依赖。

结果也说明，为何这一部署设置对数据侧恢复和自适应融合方法具有挑战性。许多缺失模态方法面向拥有更多可用模态、仅在样本层面部分缺失的设置，在这些设置中，剩余模态仍能提供足够跨模态信息来完成恢复、路由或自适应融合。而本文系统为双模态，两种模态之一完全不可用，只剩文本信息。在这一更严格条件下，基线的有效性不够一致：SMIL 和 Flex-MoE 在 SNLI-VE 上具有竞争力，但不能在各数据集上稳定优于空词元基线，DyMo 则显著退化。相比之下，GU 从模型侧入手，校正与有害多模态依赖相关的参数子空间，而不是尝试重构不可用模态。这解释了为何简单的空词元路径在 Hateful Memes 与 IU-XRay 上仍有竞争力，而 GU 能通过有针对性的参数空间校正进一步改善它。

表 3 SNLI-VE 上家族级鲁棒性-保持性权衡。 ΔT 和 ΔTI 分别表示 TI-T、TI-TI 相对于原 TI 模型的变化。Family 为家族，#Var 为变体数量，Interp. 为层插值，str. 为强编码器。

Family	#Var	TI-T		TI-TI		ΔT		ΔTI	
		Interp.	**GU**	Interp.	**GU**	Interp.	**GU**	Interp.	**GU**
Fusion	3	71.34	**73.86**	86.33	**86.37**	0.98	**3.49**	−0.13	**−0.09**
Fusion (str.)	3	72.34	**73.06**	75.16	**75.95**	0.96	**1.69**	−1.13	**−0.34**
CLIP	2	74.50	**74.68**	76.13	**76.70**	1.04	**1.22**	−1.21	**−0.64**
VLM	1	70.65	**70.65**	81.72	**81.73**	0.01	**0.01**	0.00	**+0.01**

表征层面的证据。图 4(a) 用 UMAP 可视化 SNLI-VE 上融合层表征。GU 与层插值具有相似的整体布局，与其单层编辑的有限范围相符。附录 F.2 的定量分析显示，两种编辑均与原 TI-T 表征保持高度相似，而 GU 取得更大的错误样本间隔增益、纠正更多错误，仅带来少量退化增加。结合其 TI-T F1，这些结果支持一种有针对性的任务相关校正，同时大幅保留表征结构。

总体上，主要结果显示在图像完全缺失的推理下，性能增益一致；GU 在全部三个数据集上均位列表 2 方法之首。其优势在于校正模型内部学到的有害依赖，而不是在剩余跨模态信息不足时依赖数据侧模态恢复或自适应路由。更多基线比较见附录 F.4。

6.3 跨模型家族的鲁棒性与保持性权衡

关键问题是，改善缺失模态鲁棒性是否会牺牲完整模态能力。表 3 通过比较各模型家族的 TI-T 与 TI-TI 性能考察这一权衡。GU 改善各家族的 TI-T 性能，同时使 TI-TI 性能几乎不变，说明编辑后的模型并未坍缩为纯文本解。与层插值相比，GU 通常带来更大的 TI-T 增益和更小的 TI-TI 退化，意味着子空间级编辑比直接参数混合更能保持有用的多模态结构。完整的逐变体结果见附录 F.3。

增益幅度随架构而变。GU 对融合模型最有效，因为跨模态依赖相对集中于显式融合层；对于相关依赖可能更分散的 CLIP 式和 BLIP 架构，增益较小。因此，最好将 GU 视为一种局部鲁棒性校正方法。当有害依赖集中于所选层时，它对鲁棒性-保持性权衡的改善最大。

6.4 成本分析

除性能外，我们也评估 GU 的计算成本和部署效率。在相同软硬件环境和评估协议下，用 Fusion Cross-Attention、CLIP Mean Pooling 和 BLIP-2，在 SNLI-VE 上比较 GU、训练后 LoRA 与 Dual CE。LoRA 从与 GU 相同的 TI 检查点出发，以秩 8 适应同一目标层；以缺失图像输入训练 4 轮，学习率为 10^{-4}，在开发集选择最佳检查点。Dual CE 则通过完整输入与缺失图像联合监督从头重训练。

GU 只需在部署前进行一次编辑，不对 TI 检查点作梯度更新。如表 4 所示，该阶段耗时 230-858 秒，比训练后 LoRA 减少 57%-88% 实际用时。相对原 TI 模型，所得模型不引入额外参数或前向 FLOPs。推理只使用编辑后的检查点，无需保留单模态参考。完整离线成本比较从已有 TI 检查点开始，不计该检查点原有训练成本。GU 总成本包括匹配参考训练与编辑，Dual CE 则包括完整重训练成本。GU 的两个阶段顺序运行，因此总时长为二者之和，峰值显存取两者峰值的较大者。即使计入参考训练，GU 在三个架构上仍比 Dual CE 节省 7%-22% 实际用时和 16%-62% 峰值 GPU 显存。

表 4 SNLI-VE 上的离线成本与鲁棒性-保持性权衡。计入参考训练后，GU 仍比 Dual CE 使用更少时间和峰值 GPU 显存。Architecture 为架构，Method / Phase 为方法/阶段，Wall-clock (s) 为实际用时（秒），Peak Mem. (GiB) 为峰值显存，T Reference 为 T 参考训练，GU Edit 为 GU 编辑，GU (Total) 为总成本；CA 为交叉注意力，MP 为均值池化。

Architecture	Method / Phase	Wall-clock (s)	Peak Mem. (GiB)	ΔT	ΔTI
Fusion CA	Post-hoc LoRA	1812.30	2.090	+6.02	-1.62
	Dual CE	2592.03	13.954	+13.57	-0.94
	T Reference	1849.09	5.241	–	–
	GU Edit	297.19	1.744	–	–
	GU (Total)	2146.28	5.241	+8.06	-0.11
CLIP MP	Post-hoc LoRA	1910.39	4.423	+1.03	-3.66
	Dual CE	2580.61	3.684	+2.16	-1.40
	T Reference	1773.52	3.099	–	–
	GU Edit	230.17	3.104	–	–
	GU (Total)	2003.69	3.104	+1.43	-0.97
BLIP-2	Post-hoc LoRA	2000.73	16.930	+0.26	-0.68
	Dual CE	3079.53	32.857	+4.41	-0.53
	T Reference	1993.90	24.957	–	–
	GU Edit	857.83	16.126	–	–
	GU (Total)	2851.73	24.957	+0.01	+0.01

表 4 也给出了相对原 TI 模型的 ΔT 和 ΔTI。GU 兼具比 Dual CE 更低的总成本和更好的完整模态保持性。在 Fusion 与 CLIP 上，它比 LoRA 的 TI-T 增益更大、TI-TI 损失更小，但参考训练使其总离线时间更长；在 BLIP-2 上，单层编辑主要保留原性能。总体而言，GU 提供高效的训练后鲁棒性校正，离线成本低、没有额外推理开销，且完整模态保持性强。

6.5 消融研究

我们消融 GU 的三个关键因素：测地线系数 η、子空间秩 k 和目标层。如图 4(b) 所示，GU 在一定范围的 η、k 下相对稳定，目标层则更具决定性。将 η 从 0.25 调至 1.0，仅导致缺失模态性能和完整模态保持性中等幅度变化；将秩从 2 调至 32，TI-T 性能相近，TI-TI 只有小幅波动。因此，我们依据开发集上的 TI-T 改善与 TI-TI 保持之间的权衡选择超参数。

编辑大多数层只能带来有限收益，而将 GU 应用于所选跨模态交互层 `attn_v_from_t_in`，在维持强 TI-TI 性能的同时产生最大的 TI-T 改善。这与第 4 节子空间旋转和表征损害集中在跨模态交互阶段的发现一致。该结果进一步支持模态缺失退化具有局部性，表明一次选择得当的 Grassmann 子空间编辑，无需广泛修改模型即可恢复鲁棒性。

7 结论

我们系统刻画了一种部署期失效模式：推理时一种模态缺失，完整模态多模态模型的表现可能不如单模态模型。我们表明，这种退化与跨模态交互层的主子空间旋转及任务感知表征损害高度相关。受这些发现启发，我们提出测地线遗忘：一种轻量训练后方法，将选定主子空间看作 Grassmann 流形上的一

点，使其向单模态参考旋转，并在固定子空间距离预算下以可证明的最优方式推进对齐。跨模型家族实验展示了有利的鲁棒性-保持性权衡，多项选择 VQA 与缺失文本评估也提供进一步支持。总体而言，理论和实证结果支持从几何视角理解模态缺失问题，并表明局部子空间编辑是一种实用校正策略。

参考文献

下列 74 项保留原始作者、英文题名、出版信息和链接，并附中文题名译注，以兼顾全文中文阅读与原文检索。出版信息依原文记录，不另行修订。

[1] 遗忘更多以学习更多 用于半监督和无监督领域适应的领域特定特征遗忘。

Hritam Basak and Zhaozheng Yin. Forget more to learn more: Domain-specific feature unlearning for semi-supervised and unsupervised domain adaptation. In European Conference on Computer Vision, pages 130–148. Springer, 2024.

[2] CURE 通过扩散模型中的正交表征编辑进行概念遗忘。

Shristi Das Biswas, Arani Roy, and Kaushik Roy. Cure: Concept unlearning via orthogonal representation editing in diffusion models. In The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.

[3] 机器遗忘。

Lucas Bourtoule, Varun Chandrasekaran, Christopher A Choquette-Choo, Hengrui Jia, Adelin Travers, Baiwu Zhang, David Lie, and Nicolas Papernot. Machine unlearning. In 2021 IEEE symposium on security and privacy (SP), pages 141–159. IEEE, 2021.

[4] 通过机器遗忘使系统学会忘记。

Yinzhi Cao and Junfeng Yang. Towards making systems forget with machine unlearning. In 2015 IEEE Symposium on Security and Privacy, pages 463–480, 2015. doi: 10.1109/SP.2015.35.

[5] 分数遗忘蒸馏 一种用于扩散模型机器遗忘的快速无数据方法。

Tianqi Chen, Shujian Zhang, and Mingyuan Zhou. Score forgetting distillation: A swift, data-free method for machine unlearning in diffusion models. In The Thirteenth International Conference on Learning Representations, 2025. URL https://openreview.net/forum?id=gjwhDHeAsz.

[6] 为分发和检索准备放射检查数据集。

Dina Demner-Fushman, Marc D Kohli, Marc B Rosenman, Sonya E Shooshan, Laritza Rodriguez, Sameer Antani, George R Thoma, and Clement J McDonald. Preparing a collection of radiology examinations for distribution and retrieval. Journal of the American Medical Informatics Association, 23(2):304–310, 2016.

[7] e-SNLI-VE 具有自然语言解释的纠正视觉文本蕴涵。

Virginie Do, Oana-Maria Camburu, Zeynep Akata, and Thomas Lukasiewicz. e-snli-ve: Corrected visual-textual entailment with natural language explanations, 2021. URL https://arxiv.org/abs/2004.03744.

[8] Insight-V 探索多模态大语言模型的长链视觉推理。

Yuhao Dong, Zuyan Liu, Hai-Long Sun, Jingkang Yang, Winston Hu, Yongming Rao, and Ziwei Liu. Insight-v: Exploring long-chain visual reasoning with multimodal large language models. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 9062–9072, 2025.

[9] 用于不完整多模态分类的推理期动态模态选择。

Siyi Du, Xinzhe Luo, Declan O’ regan, and Chen Qin. Inference-time dynamic modality selection for incomplete multimodal classification. In The Fourteenth International Conference on Learning Representations, 2026. URL https://openreview.net/forum?id=PWhDUWRVhM.

[10] 带正交约束算法的几何。

Alan Edelman, Tomás A Arias, and Steven T Smith. The geometry of algorithms with orthogonality constraints. SIAM journal on Matrix Analysis and Applications, 20(2):303–353, 1998.

[11] 用于分类的大间隔深度网络。

Gamaleldin Elsayed, Dilip Krishnan, Hossein Mobahi, Kevin Regan, and Samy Bengio. Large margin deep networks for classification. Advances in neural information processing systems, 31, 2018.

[12] 通过 VAE 循环置换实现深度不完整多视图学习。

Xin Gao and Jian Pu. Deep incomplete multi-view learning via cyclic permutation of VAEs. In The Thirteenth International Conference on Learning Representations, 2025. URL https://openreview.net/forum?id=s4MwstmB8o.

[13] 学习关联 完全缺失模态下的多模态推理。

Jack Geraghty, Andrew Hines, and Fatemeh Golpayegani. Learning to associate: Multimodal inference with fully missing modalities. ACM Transactions on Intelligent Systems and Technology, 16(5):1–48, 2025.

[14] CPR 用于版权保护的检索增强生成。

Aditya Golatkar, Alessandro Achille, Luca Zancato, Yu-Xiang Wang, Ashwin Swaminathan, and Stefano Soatto. Cpr: Retrieval augmented generation for copyright protection. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 12374–12384, 2024.

[15] 自然语言推理数据中的标注伪迹。

Suchin Gururangan, Swabha Swayamdipta, Omer Levy, Roy Schwartz, Samuel R. Bowman, and Noah A. Smith. Annotation artifacts in natural language inference data. In Marilyn Walker, Heng Ji, and Amanda Stent, editors, Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers), pages 107–112, New Orleans, Louisiana, June 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-2017. URL https://aclanthology.org/N18-2017/.

[16] 多模态融合与视觉语言模型 面向机器人视觉的综述。

Xiaofeng Han, Shunpeng Chen, Zenghuang Fu, Zhe Feng, Lue Fan, Dong An, Changwei Wang, Li Guo, Weiliang Meng, Xiaopeng Zhang, et al. Multimodal fusion and vision-language models: A survey for robot vision. Information Fusion, page 103652, 2025.

[17] 基于部分信息的在线鲁棒子空间跟踪。

Jun He, Laura Balzano, and John Lui. Online robust subspace tracking from partial information. arXiv preprint arXiv:1109.3827, 2011.

[18] 利用视觉语言模型检测时间序列异常。

Zelin He, Sarah Alnegheimish, and Matthew Reimherr. Harnessing vision-language models for time series anomaly detection. In Proceedings of the Fortieth AAAI Conference on Artificial Intelligence and Thirty-Eighth Conference on Innovative Applications of Artificial Intelligence and Sixteenth Symposium on Educational Advances in Artificial Intelligence, AAAI’26/IAAI’26/EAAI’26. AAAI Press, 2026. ISBN 978-1-57735-906-7. doi: 10.1609/aaai.v40i26.39319. URL https://doi.org/10.1609/aaai.v40i26.39319.

[19] LoRA 大语言模型的低秩适应。

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021. URL https://arxiv.org/abs/2106.09685.

[20] 缺失模态视觉识别的深度相关提示。

Lianyu Hu, Tongkai Shi, Wei Feng, Fanhua Shang, and Liang Wan. Deep correlated prompting for visual recognition with missing modalities. Advances in Neural Information Processing Systems, 37:67446–67466, 2024.

[21] 是什么使多模态学习优于单模态学习 一个可证明的解释。

Yu Huang, Chenzhuang Du, Zihui Xue, Xuanyao Chen, Hang Zhao, and Longbo Huang. What makes multi-modal learning better than single (provably). Advances in Neural Information Processing Systems, 34:10944–10956, 2021.

[22] 面向低功耗可穿戴设备时间序列机器学习的传感器感知数据插补。

Dina Hussein, Taha Belkhouja, Ganapati Bhat, and Jana Doppa. Sensor-aware data imputation for time-series machine learning on low-power wearable devices. ACM Transactions on Design Automation of Electronic Systems, 30(1):1–27, 2024.

[23] OpenCLIP。

Gabriel Ilharco, Mitchell Wortsman, Nicholas Carlini, Rohan Taori, Achal Dave, Vaishaal Shankar, Hongseok Namkoong, John Miller, Hannaneh Hajishirzi, Ali Farhadi, et al. Openclip. Zenodo, 2021.

[24] 用任务算术编辑模型。

Gabriel Ilharco, Marco Tulio Ribeiro, Mitchell Wortsman, Ludwig Schmidt, Hannaneh Hajishirzi, and Ali Farhadi. Editing models with task arithmetic. In The Eleventh International Conference on Learning Representations, 2023. URL https://openreview.net/forum?id=6t0Kwf8-jrj.

[25] 视觉语言模型的近似领域遗忘。

Kodai Kawamura, Yuta Goto, Rintaro Yanagi, Hirokatsu Kataoka, and Go Irie. Approximate domain unlearning for vision-language models. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, and N. Chen, editors, Advances in Neural Information Processing Systems, volume 38, Main Conference, pages 21805–21833. Curran Associates, Inc., 2025. doi: 10.52202/085713-0736. URL https://proceedings.neurips.cc/paper_files/paper/2025/file/1f6af963e891e7efa229c24a1607fa7f-Paper-Conference.pdf.

[26] Hateful Memes 挑战 检测多模态模因中的仇恨言论。

Douwe Kiela, Hamed Firooz, Aravind Mohan, Vedanuj Goswami, Amanpreet Singh, Pratik Ringshia, and Davide Testuggine. The hateful memes challenge: Detecting hate speech in multimodal memes. Advances in neural information processing systems, 33:2611–2624, 2020.

[27] 通过博弈论正则化平衡多模态训练。

Konstantinos Kontras, Thomas Strypsteen, Christos Chatzichristos, Paul Liang, Matthew Blaschko, and Maarten De Vos. Balancing multimodal training through game-theoretic regularization. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, and N. Chen, editors, Advances in Neural Information Processing Systems, volume 38, Main Conference, pages 167953–167982. Curran Associates, Inc., 2025. doi: 10.52202/085713-5600. URL https://proceedings.neurips.cc/paper_files/paper/2025/file/f5784de266e45bd09333721b0a602b61-Paper-Conference.pdf.

[28] ResNet 50。

Brett Koonce. Resnet 50. In Convolutional neural networks with swift for tensorflow: image recognition and dataset categorization, pages 63–72. Springer, 2021.

[29] 重新审视神经网络表征的相似性。

Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In International conference on machine learning, pages 3519–3529. PMLR, 2019.

[30] 通过自适应梯度调制提升多模态模型性能。

Hong Li, Xingyu Li, Pengbo Hu, Yinuo Lei, Chunxiao Li, and Yi Zhou. Boosting multi-modal model performance with adaptive gradient modulation. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pages 22214–22224, October 2023.

[31] BLIP-2 利用冻结图像编码器和大语言模型引导语言图像预训练。

Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In International conference on machine learning, pages 19730–19742. PMLR, 2023.

[32] 多模态对齐与融合综述。

Songtao Li and Hao Tang. Multimodal alignment and fusion: A survey. International Journal of Computer Vision, 134(3):1–31, 2026. doi: 10.1007/s11263-025-02667-1.

[33] RoBERTa 一种稳健优化的 BERT 预训练方法。

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692, 2019.

[34] 利用间隔分布改善深度神经网络泛化。

Shen-Huan Lyu, Lu Wang, and Zhi-Hua Zhou. Improving generalization of deep neural networks by leveraging margin distribution. Neural Networks, 151:48–60, 2022.

[35] SMIL 模态严重缺失的多模态学习。

Mengmeng Ma, Jian Ren, Long Zhao, Sergey Tulyakov, Cathy Wu, and Xi Peng. Smil: Multimodal learning with severely missing modality. In Proceedings of the AAAI conference on artificial intelligence, volume 35, pages 2302–2310, 2021.

[36] 深度学习训练末期神经坍缩现象的普遍性。

Vardan Papyan, XY Han, and David L Donoho. Prevalence of neural collapse during the terminal phase of deep learning training. Proceedings of the National Academy of Sciences, 117 (40):24652–24663, 2020.

[37] 通过即时梯度调制实现平衡多模态学习。

Xiaokang Peng, Yake Wei, Andong Deng, Dong Wang, and Di Hu. Balanced multimodal learning via on-the-fly gradient modulation. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 8238–8247, 2022.

[38] TokenSwap 一种扰乱大语言模型记忆序列的轻量方法。

Parjanya Prajakta Prashant, Kaustubh Ponkshe, and Babak Salimi. Tokenswap: A lightweight method to disrupt memorized sequences in llms. In The Thirty-ninth Annual Conference on Neural Information Processing Systems, 2025.

[39] SubTrack++ 面向可扩展大语言模型训练的梯度子空间跟踪。

Sahar Rajabi, Nayeema Nonta, and Sirisha Rambhatla. Subtrack++ : Gradient subspace tracking for scalable llm training. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, and N. Chen, editors, Advances in Neural Information Processing Systems, volume 38, Main Conference, pages 31584–31613. Curran Associates, Inc., 2025. doi: 10.52202/085713-1060. URL https://proceedings.neurips.cc/paper_files/paper/2025/file/2d62cb71e87ae340e3ab0e874befcbc2-Paper-Conference.pdf.

[40] 通过参数高效适应实现缺失模态下的鲁棒多模态学习。

Md Kaykobad Reza, Ashley Prater-Bennette, and M Salman Asif. Robust multimodal learning with missing modalities via parameter-efficient adaptation. IEEE transactions on pattern analysis and machine intelligence, 47(2):742–754, 2024.

[41] LDAdam 基于低维梯度统计的自适应优化。

Thomas Robert, Mher Safaryan, Ionut-Vlad Modoranu, and Dan Alistarh. LDAdam: Adaptive optimization from low-dimensional gradient statistics. In The Thirteenth International Conference on Learning Representations, 2025. URL https://openreview.net/forum?id=Zkp1GuHerF.

[42] A-OKVQA 使用世界知识进行视觉问答的基准。

Dustin Schwenk, Apoorv Khandelwal, Christopher Clark, Kenneth Marino, and Roozbeh Mottaghi. A-okvqa: A benchmark for visual question answering using world knowledge. In European conference on computer vision, pages 146–162. Springer, 2022.

[43] 用于情绪识别的多模态方法综述。

Nicu Sebe, Ira Cohen, Theo Gevers, and Thomas S Huang. Multimodal approaches for emotion recognition: a survey. In Internet Imaging VI, volume 5670, pages 56–67. SPIE, 2005.

[44] 面向医疗应用的集成多模态人工智能框架。

Luis R Soenksen, Yu Ma, Cynthia Zeng, Leonard Boussioux, Kimberly Villalobos Carballo, Liangyuan Na, Holly M Wiberg, Michael L Li, Ignacio Fuentes, and Dimitris Bertsimas. Integrated multimodal artificial intelligence framework for healthcare applications. NPJ digital medicine, 5(1):149, 2022.

[45] Chain-of-Query 通过多智能体协作释放大语言模型在 SQL 辅助表格理解中的能力。

Songyuan Sui, Hongyi Liu, Serena Liu, Li Li, Soo-Hyun Choi, Rui Chen, and Xia Hu. Chain-of-query: Unleashing the power of LLMs in SQL-aided table understanding via multi-agent collaboration. In Kentaro Inui, Sakriani Sakti, Haofen Wang, Derek F. Wong, Pushpak Bhattacharyya, Biplab Banerjee, Asif Ekbal, Tanmoy Chakraborty, and Dhirendra Pratap Singh, editors, Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics, pages 957–986, Mumbai, India, December 2025. The Asian Federation of Natural Language Processing and The Association for Computational Linguistics. ISBN 979-8-89176-298-5. doi: 10.18653/v1/2025.ijcnlp-long.53. URL https://aclanthology.org/2025.ijcnlp-long.53/.

[46] ECLAD 面向预测性维护中可解释异常检测的边云协同智能体框架。

Songyuan Sui, Zhanqi Deng, Yamin Zhuang, Serena Liu, Leisheng Yu, Alfredo Costilla Reyes, and Xia Hu. Eclad: An edge-cloud collaborative agentic framework for interpretable anomaly detection in predictive maintenance. In Companion Proceedings of the ACM Web Conference 2026, WWW Companion ’26, pages 164–167, New York, NY, USA, 2026. Association for Computing Machinery. ISBN 9798400723087. doi: 10.1145/3774905.3793127. URL https://doi.org/10.1145/3774905.3793127.

[47] RedCore 面向缺失率不平衡的模态缺失问题的相对优势感知跨模态表征学习。

Jun Sun, Xinxin Zhang, Shoukang Han, Yu-Ping Ruan, and Taihao Li. Redcore: Relative advantage aware cross-modal representation learning for missing modalities with imbalanced missing rates. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pages 15173–15182, 2024.

[48] UnSeg 一个通用不可学习样本生成器足以对抗所有图像分割。

Ye Sun, Hao Zhang, Tiehua Zhang, Xingjun Ma, and Yu-Gang Jiang. Unseg: One universal unlearnable example generator is enough against all image segmentation. Advances in Neural Information Processing Systems, 37:79168–79193, 2024.

[49] 不确定模态缺失下基于相似模态补全的多模态情感分析。

Yuhang Sun, Zhizhong Liu, Quan Z Sheng, Dianhui Chu, Jian Yu, and Hongxiang Sun. Similar modality completion-based multimodal sentiment analysis under uncertain missing modalities. Information Fusion, 110:102454, 2024.

[50] ViperGPT 通过 Python 执行实现视觉推理。

Dídac Surís, Sachit Menon, and Carl Vondrick. Vipergpt: Visual inference via python execution for reasoning. In Proceedings of the IEEE/CVF international conference on computer vision, pages 11888–11898, 2023.

[51] 结合模型形式适应与非缺失特征监督的迭代缺失数据插补。

Hao Wang, Zhengnan Li, Zhichao Chen, Xu Chen, Shuting He, Guangyi Liu, Haoxuan Li, and Zhouchen Lin. Iterative missing data imputation with model form adaptation and non-missing feature supervision. In The thirty-ninth annual conference on neural information processing systems, 2025.

[52] 通过共享与特有特征建模实现缺失模态多模态学习。

Hu Wang, Yuanhong Chen, Congbo Ma, Jodie Avery, Louise Hull, and Gustavo Carneiro. Multimodal learning with missing modality via shared-specific feature modelling. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 15878–15887, 2023.

[53] 面向缺失模态多模态学习的可学习跨模态知识蒸馏。

Hu Wang, Congbo Ma, Jianpeng Zhang, Yuan Zhang, Jodie Avery, Louise Hull, and Gustavo Carneiro. Learnable cross-modal knowledge distillation for multi-modal learning with missing modality. In International Conference on Medical Image Computing and Computer-Assisted Intervention, pages 216–226. Springer, 2023.

[54] 不完整多模态扩散情绪识别。

Yuanzhi Wang, Yong Li, and Zhen Cui. Incomplete multimodality-diffused emotion recognition. Advances in Neural Information Processing Systems, 36:17117–17128, 2023.

[55] 持续学习的统一通用框架。

Zhenyi Wang, Yan Li, Li Shen, and Heng Huang. A unified and general framework for continual learning. In The Twelfth International Conference on Learning Representations, 2024. URL https://openreview.net/forum?id=BE5aK0ETbp.

[56] 面向平衡多模态学习的诊断与重新学习。

Yake Wei, Siwei Li, Ruoxuan Feng, and Di Hu. Diagnosing and re-learning for balanced multimodal learning. In European Conference on Computer Vision, pages 71–86. Springer, 2024.

[57] SiMO 可单模态运行的多模态协同感知。

Jiageng Wen, Shengjie Zhao, Bing Li, Jiafeng Huang, Kenan Ye, and Hao Deng. SiMO: Single-modality-operable multimodal collaborative perception. In The Fourteenth International Conference on Learning Representations, 2026. URL https://openreview.net/forum?id=h0iRgjTmVs.

[58] 缺失模态下的深度多模态学习综述。

Renjie Wu, Hu Wang, Hsiang-Ting Chen, and Gustavo Carneiro. Deep multimodal learning with missing modality: A survey. arXiv preprint arXiv:2409.07825, 2024.

[59] 视觉蕴涵 细粒度图像理解的新任务。

Ning Xie, Farley Lai, Derek Doran, and Asim Kadav. Visual entailment: A novel task for fine-grained image understanding. arXiv preprint arXiv:1901.06706, 2019.

[60] 用于不完整多模态生存预测的蒸馏提示学习。

Yingxue Xu, Fengtao Zhou, Chenyu Zhao, Yihui Wang, Can Yang, and Hao Chen. Distilled prompt learning for incomplete multimodal survival prediction. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 5102–5111, 2025.

[61] 动态多模态融合。

Zihui Xue and Radu Marculescu. Dynamic multimodal fusion. In 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), pages 2575–2584. IEEE, 2023.

[62] Qwen2.5 技术报告。

An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tianyi Tang, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, and Zihan Qiu. Qwen2.5 technical report, 2025. URL https://arxiv.org/abs/2412.15115.

[63] 通过模态混合与深度监督实现脑疾病诊断多模态连接组的不完整学习。

Yanwu Yang, Hairui Chen, Zhikai Chang, Yang Xiang, Chenfei Ye, and Ting Ma. Incomplete learning of multi-modal connectome for brain disorder diagnosis via modal-mixup and deep supervision. In Medical Imaging With Deep Learning, pages 1006–1018. PMLR, 2024.

[64] DrFuse 面向模态缺失与模态不一致的临床多模态融合解耦表征学习。

Wenfang Yao, Kejing Yin, William K Cheung, Jia Liu, and Jing Qin. Drfuse: Learning disentangled representation for clinical multi-modal fusion with missing modality and modal inconsistency. In Proceedings of the AAAI conference on artificial intelligence, volume 38, pages 16416–16424, 2024.

[65] Flex-MoE 通过灵活专家混合建模任意模态组合。

Sukwon Yun, Inyoung Choi, Jie Peng, Yangfan Wu, Jingxuan Bao, Qiyiwen Zhang, Jiayi Xin, Qi Long, and Tianlong Chen. Flex-moe: Modeling arbitrary modality combination via the flexible mixture-of-experts. Advances in Neural Information Processing Systems, 37: 98782–98805, 2024.

[66] 学习语言引导的自适应超模态表征用于多模态情感分析。

Haoyu Zhang, Yu Wang, Guanghao Yin, Kejun Liu, Yuanyuan Liu, and Tianshu Yu. Learning language-guided adaptive hyper-modality representation for multimodal sentiment analysis. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, pages 756–767, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.49. URL https://aclanthology.org/2023.emnlp-main.49/.

[67] 不可学习簇 迈向标签无关的不可学习样本。

Jiaming Zhang, Xingjun Ma, Qi Yi, Jitao Sang, Yu-Gang Jiang, Yaowei Wang, and Changsheng Xu. Unlearnable clusters: Towards label-agnostic unlearnable examples. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 3984–3993, 2023.

[68] 从超声蒸馏缺失模态知识以使用磁共振图像诊断子宫内膜异位症。

Yuan Zhang, Hu Wang, David Butler, Minh-Son To, Jodie Avery, M Louise Hull, and Gustavo Carneiro. Distilling missing modality knowledge from ultrasound for endometriosis diagnosis with magnetic resonance images. In 2023 IEEE 20th International Symposium on Biomedical Imaging (ISBI), pages 1–5. IEEE, 2023.

[69] 用于缺失模态插补的统一多模态图像合成。

Yue Zhang, Chengtao Peng, Qiuli Wang, Dan Song, Kaiyan Li, and S Kevin Zhou. Unified multi-modal image synthesis for missing modality imputation. IEEE Transactions on Medical Imaging, 44(1):4–18, 2024.

[70] 训练期间的遗忘 面向领域泛化的领域特定梯度上升。

Di Zhao, Jingfeng Zhang, Hongsheng Hu, Philippe Fournier-Viger, Gillian Dobbie, and Yun Sing Koh. Unlearning during training: Domain-specific gradient ascent for domain generalization. In The Fourteenth International Conference on Learning Representations, 2026. URL https://openreview.net/forum?id=9ufS5Jl0O0.

[71] 深度多模态数据融合。

Fei Zhao, Chengcui Zhang, and Baocheng Geng. Deep multimodal data fusion. ACM computing surveys, 56(9):1–36, 2024.

[72] GaLore 通过梯度低秩投影实现显存高效的大语言模型训练。

Jiawei Zhao, Zhenyu Zhang, Beidi Chen, Zhangyang Wang, Anima Anandkumar, and Yuandong Tian. Galore: memory-efficient llm training by gradient low-rank projection. In Proceedings of the 41st International Conference on Machine Learning, pages 61121–61143, 2024.

[73] MoRA 用于视觉识别的缺失模态低秩适应。

Shu Zhao, Nilesh Ahuja, Tan Yu, Tianyi Shen, and Vijaykrishnan Narayanan. MoRA: Missing modality low-rank adaptation for visual recognition. In The Fourteenth International Conference on Learning Representations, 2026. URL https://openreview.net/forum?id=ZgQnIPG4uV.

[74] 从任意模态学习用于语义分割的模态无关表征。

Xu Zheng, Yuanhuiyi Lyu, and Lin Wang. Learning modality-agnostic representation for semantic segmentation from any modalities. In European Conference on Computer Vision, pages 146–165. Springer, 2024.

附录目录

以下页码沿用英文原版，便于核对；中文译文已重新分页。

- A 局限性（原第 18 页）
- B 更广泛影响（原第 18 页）
- C 实证分析补充材料（原第 18 页）：C.1 模态缺失退化的更多结果；C.2 参数子空间旋转的更多结果；C.3 模态缺失下表征损害的更多结果（均始于原第 18 页）
- D 方法细节（原第 21 页）：D.1 Grassmann 测地线构造；D.2 几何依据与路径比较（原第 21 页）；D.3 实现说明（原第 22 页）
- E 实验设置补充材料（原第 22 页）：E.1 数据集；E.2 基线（原第 22 页）；E.3 计算资源；E.4 实现（原第 24 页）
- F 补充实验结果（原第 26 页）：F.1 性能稳定性分析；F.2 表征层面证据的更多细节（原第 26 页）；F.3 鲁棒性-保持性权衡的更多结果；F.4 更多基线比较（原第 27 页）；F.5 几何校正的受控干预（原第 30 页）；F.6 向多项选择 VQA 泛化；F.7 缺失文本输入下的补充评估（原第 31 页）

A 局限性

尽管本工作对于揭示并处理多模态学习中模态缺失退化的结构性原因具有重要意义，仍有一些局限值得注意。首先，评估限于分类任务，包括多项选择视觉问答。将 GU 扩展到自由形式的多模态生成，是未来工作的重要方向。其次，已有研究对 Hateful Memes 中的渲染文字和 SNLI-VE 中假设侧伪迹提出担忧。我们通过有针对性的预处理和补充对照处理受影响基准上的这些问题。在不含这些特定伪迹的更多数据集上进行的进一步评估，也复现了退化和 GU 的改善，确认二者都不以这些伪迹的存在为前提。最后，虽然覆盖了不同领域的融合模型、双塔模型与 VLM，但受资源限制，未在规模显著更大的模型上开展大规模实验。

B 更广泛影响

本工作改善了多模态模型对模态缺失输入的鲁棒性；在输入可能因传感器故障、隐私限制或部署约束而不完整的现实场景中，这一点很重要。这种改进可能有益于医疗决策支持、多模态内容理解等应用。然而，鲁棒性提升也可能鼓励人们在仍会出现错误预测的场景中部署模型。此外，鲁棒性不能消除训练数据已有的偏差。

C 实证分析补充材料

C.1 模态缺失退化的更多结果

正文使用汇总柱状图概括模态缺失退化。表 5 给出不同模型变体和数据集在完整模态评估（TI-TI）、单模态文本评估（T-T）以及部署期缺失图像评估（TI-T）下的完整 F1 分数。结果为三次独立运行的均值 ± 样本标准差。IX 和 SV 分别表示 IU-XRay 与 SNLI-VE。

所报告的平均分数支持第 4.2 节的趋势：27 个设置中有 26 个满足 TI-TI > T-T > TI-T，所有 27 个都满足 T-T > TI-T。唯一非严格的情况是 HM 上的强编码器 Fusion Cross-Attention，其中 TI-TI = T-T = 66.93 > TI-T = 66.85。这种效应在显式跨模态交互模型中尤其明显，例如 SNLI-VE 上的交叉注意力融合，其模态缺失差距属于最大的一类。这些结果支持如下观点：部署期模态缺失退化不仅与输入信息缺失有关，还与多模态训练中形成的跨模态依赖有关。

表 5 三种训练-测试方式下的 F1 性能。在不同模型家族和数据集上，TI-T 均不如 T-T。Family 为家族，Dataset 为数据集，Variant 为变体，Δ_{miss} 为模态缺失差距。

Family	Dataset	Variant	TI-TI	T-T	TI-T	Δ_{miss}
Fusion	HM	Concat	69.46 ± 0.32	68.99 ± 0.25	68.96 ± 0.44	0.50 ± 0.14
	HM	Gate	67.98 ± 0.28	67.86 ± 0.23	67.57 ± 0.38	0.41 ± 0.12
	HM	Cross-Attn	68.82 ± 0.48	68.41 ± 0.40	57.63 ± 0.88	11.19 ± 0.45
	IX	Concat	86.41 ± 0.22	81.94 ± 0.18	80.70 ± 0.38	5.71 ± 0.18
	IX	Gate	82.79 ± 0.20	81.18 ± 0.17	80.76 ± 0.33	2.03 ± 0.15
	IX	Cross-Attn	84.57 ± 0.28	80.97 ± 0.23	80.00 ± 0.47	4.57 ± 0.22
	SV	Concat	86.22 ± 0.07	81.84 ± 0.05	73.04 ± 0.24	13.18 ± 0.18
	SV	Gate	86.53 ± 0.08	82.31 ± 0.06	71.70 ± 0.29	14.83 ± 0.22
	SV	Cross-Attn	86.64 ± 0.10	81.85 ± 0.08	66.35 ± 0.38	20.29 ± 0.30
Fusion (strong)	HM	Concat	67.49 ± 0.30	67.12 ± 0.24	66.50 ± 0.46	0.99 ± 0.18
	HM	Gate	67.12 ± 0.34	66.85 ± 0.27	65.51 ± 0.53	1.61 ± 0.22
	HM	Cross-Attn	66.93 ± 0.22	66.93 ± 0.18	66.85 ± 0.24	0.08 ± 0.03
	IX	Concat	81.51 ± 0.21	80.35 ± 0.16	78.06 ± 0.36	3.45 ± 0.17
	IX	Gate	79.93 ± 0.18	79.79 ± 0.14	79.24 ± 0.25	0.69 ± 0.08
	IX	Cross-Attn	80.14 ± 0.24	79.46 ± 0.19	77.78 ± 0.38	2.36 ± 0.16
	SV	Concat	76.44 ± 0.06	75.99 ± 0.05	72.78 ± 0.19	3.66 ± 0.14
	SV	Gate	72.72 ± 0.07	71.51 ± 0.06	67.65 ± 0.24	5.07 ± 0.18
	SV	Cross-Attn	79.71 ± 0.08	79.23 ± 0.07	73.69 ± 0.27	6.02 ± 0.20
CLIP	HM	Late Concat	67.31 ± 0.27	67.21 ± 0.22	66.58 ± 0.41	0.73 ± 0.16
	HM	Mean Pooling	67.14 ± 0.20	66.95 ± 0.17	66.87 ± 0.24	0.27 ± 0.05
	IX	Late Concat	80.85 ± 0.19	80.40 ± 0.15	79.45 ± 0.29	1.40 ± 0.12
	IX	Mean Pooling	78.00 ± 0.20	77.97 ± 0.16	74.30 ± 0.38	3.70 ± 0.20
	SV	Late Concat	78.05 ± 0.06	78.01 ± 0.05	72.77 ± 0.21	5.28 ± 0.16
	SV	Mean Pooling	76.62 ± 0.06	76.52 ± 0.05	74.15 ± 0.18	2.47 ± 0.13
VLM (BLIP-2)	HM	BLIP-2	68.85 ± 0.38	66.58 ± 0.31	66.21 ± 0.59	2.64 ± 0.24
	IX	BLIP-2	81.74 ± 0.26	79.38 ± 0.22	78.00 ± 0.46	3.74 ± 0.23
	SV	BLIP-2	81.72 ± 0.18	77.51 ± 0.07	70.64 ± 0.70	11.08 ± 0.66

C.2 参数子空间旋转的更多结果

为补充正文对交互层几何的分析，我们提供 SNLI-VE 上融合模型的逐层比较。表 7 报告各 TI 层与匹配 T 参考之间的输入/输出子空间重叠、平均主夹角和 Frobenius 距离。

各层的子空间变化不均匀。投影层和跨模态交互层通常比分类器层具有更大的主夹角偏移和更低的子空间重叠。交叉注意力模块在输入侧和输出侧均有较大夹角变化，与正文中交互层几何最能反映模态缺失差距的发现一致。相比之下，最终分类器的重叠接近完美，输出侧夹角接近零，说明主要的参数空间变化发生在最终预测层之前。

这些结果支持将交互层子空间旋转用作模态缺失退化的结构性诊断，以及选择局部 GU 编辑目标的准则。

C.3 模态缺失下表征损害的更多结果

正文在阶段层面总结任务感知表征损害。表 6 给出缺失图像评估下 SNLI-VE 融合模型的逐层结果，报告错误-正确样本损害差距 Δ_{harm} 与违反率差距 Δ_{viol}。更大的差距表示错误样本比正确样本占据更不符合任务的区域。

各层的表征损害不均匀。损害信号在多模态交互阶段附近变得明显，并经常持续至分类器输入处。这补充了表 7 的参数子空间分析。图像投影层可能有较大的子空间旋转，但由于图像模态不可用，其在缺失图像评估下的损害分数为零。相反，跨模态交互层同时表现出显著子空间旋转和非平凡的表征损害。这些结果促使我们在选择目标层时同时使用参数子空间旋转和任务感知损害，而不只依据主夹角。

总之，这些发现支持正文的解释：在模态缺失输入下，交互层几何伴随着与任务相关的表征变化。

表 6 SNLI-VE 上融合模型的逐层任务感知表征损害。损害差距出现在跨模态交互阶段，并经常延续至分类器附近。Variant 为变体，Layer 为层，Δ_{harm} 和 Δ_{viol} 分别为损害差距与违反率差距；层标识保留原样。

Variant	Layer	Δ_{harm}	Δ_{viol}
Concat	text_proj_out	0.5187	0.6170
	image_proj_out	0.0000	0.0000
	fusion_mlp0_concat_input	0.5187	0.6170
	fusion_mlp3_output	0.5617	0.7308
	head_last_linear_input	0.5617	0.7308
Gate	text_proj_out	0.3881	0.5735
	image_proj_out	0.0000	0.0000
	fusion_mlp0_concat_input	0.3881	0.5735
	fusion_mlp3_h_base	0.2373	0.5992
	gate_mlp0_gate	0.1066	0.5617
	fusion_pre_ln	0.2996	0.6127
	fusion_output	0.2996	0.6113
	head_last_linear_input	0.2996	0.6113
Cross-Attn	text_proj_out	0.4585	0.4339
	image_proj_out	0.0000	0.0000
	attn_t_from_v_in_proj_to_text_pooled	0.4134	0.4464
	attn_t_from_v_out_proj_to_text_pooled	0.4134	0.4464
	attn_v_from_t_in_proj_to_image_pooled	0.3673	0.4557
	attn_v_from_t_out_proj_to_image_pooled	0.3673	0.4557
	ffn_t_0_to_text_pooled	0.4134	0.4464
	ffn_t_3_to_text_pooled	0.4134	0.4464
	ffn_v_0_to_image_pooled	0.3673	0.4557
	ffn_v_3_to_image_pooled	0.3673	0.4557
	combine_mlp0_concat_input	0.3896	0.4420
	combine_mlp3_output	0.4445	0.5868
	head_last_linear_input	0.4445	0.5868

表 7 SNLI-VE 上融合模型的逐层参数子空间旋转。投影层和跨模态交互层通常比最终分类器旋转更大。Overlap (In / Out) 为输入/输出重叠，Mean Angle (In / Out) 为输入/输出平均夹角，Fro. Dist. 为 Frobenius 距离。

Variant	Layer	Overlap (In / Out)	Mean Angle (In / Out)	Fro. Dist.
Concat	text_proj	0.9666 / 0.9666	8.3333 / 8.3150	1.4884
	image_proj	0.8368 / 0.8409	19.2640 / 18.7282	2.5745
	fusion_mlp0	0.9307 / 0.9314	11.4472 / 11.3110	1.8050
	fusion_mlp3	0.9578 / 0.9573	4.2398 / 4.2895	1.3692
	head_last_linear	0.9991 / 1.0000	1.7072 / 0.0000	0.0511
Gate	text_proj	0.9715 / 0.9714	7.7292 / 7.7325	1.4133
	image_proj	0.8615 / 0.8656	17.8397 / 17.2876	2.4042
	fusion_mlp0	0.9129 / 0.9126	12.3658 / 12.2981	1.8239
	fusion_mlp3	0.9249 / 0.9254	8.3895 / 8.2923	1.4560
	gate_mlp0	0.9408 / 0.9425	10.8734 / 10.5926	2.0828
	head_last_linear	0.9994 / 1.0000	1.3227 / 0.0000	0.0367
Cross-Attn	text_proj	0.9656 / 0.9658	8.1285 / 8.0749	1.4191
	image_proj	0.8777 / 0.8818	16.1052 / 15.5300	2.3401
	attn_t_from_v_in_proj	0.9152 / 0.9127	13.3996 / 13.8179	2.3295
	attn_t_from_v_out_proj	0.8701 / 0.8666	17.2543 / 17.6767	1.4386
	attn_v_from_t_in_proj	0.8845 / 0.8796	16.0031 / 16.5666	2.4871
	attn_v_from_t_out_proj	0.9315 / 0.9312	10.2142 / 10.2819	0.9027
	ffn_t_0	0.9873 / 0.9870	5.2286 / 5.3021	1.1664
	ffn_t_3	0.9862 / 0.9860	5.0457 / 5.0703	1.0904
	ffn_v_0	0.9771 / 0.9767	6.4555 / 6.4909	1.2853
	ffn_v_3	0.9881 / 0.9882	4.6682 / 4.6642	1.0396
	combine_mlp0	0.9638 / 0.9642	8.4807 / 8.4070	1.5600
	combine_mlp3	0.9471 / 0.9464	5.3530 / 5.4254	1.0109
	head_last_linear	0.9988 / 1.0000	1.9483 / 0.0000	0.0501

D 方法细节

D.1 Grassmann 测地线构造

直观而言，这一构造将多模态与单模态子空间的主方向配对，并把每个多模态方向旋转到其对应参考方向。单个编辑强度为每一对方向指定相同的角度校正比例。随后将所得基表为原始 TI 坐标，以便用保留的输出因子、主系数和残差进行重构。本节给出式（3）使用的显式 Grassmann 测地线。令 $V_{\mathrm{TI},k},\ V_{\mathrm{T},k} \in \mathbb{R}^{d_i \times k}$ 分别为多模态模型和匹配单模态参考的前 k 维输入子空间的正交归一基。先对其子空间重叠计算紧致 SVD：

$$V_{\mathrm{TI},k}^{\top} V_{\mathrm{T},k} = P \cos(\Theta) Q^{\top}, \tag{6}$$

其中 Θ 的对角元素 $\theta_i \in [0,\ \pi/2]$ 是两个子空间之间的主夹角。然后构造对齐的主基：

$$A = V_{\mathrm{TI},k} P, \qquad B = V_{\mathrm{T},k} Q. \tag{7}$$

测地线方向计算为：

$$Y = (B - A\cos\Theta)(\sin\Theta)^{\dagger}, \tag{8}$$

其中 $(\cdot)^{\dagger}$ 表示 Moore-Penrose 伪逆。对于 $\theta_i = 0$，公共方向不变，Y 对应列为零。主坐标下的测地线基及其在原 TI 奇异向量坐标中的表达为：

$$\widetilde{V}(\eta) = A\cos(\eta\Theta) + Y\sin(\eta\Theta), \qquad V(\eta) = \widetilde{V}(\eta)P^{\top}, \quad \eta \in [0,1]. \tag{9}$$

这里 $\widetilde{V}(0) = A$，$\widetilde{V}(1) = B$。乘以 $P^{\top}$ 保持子空间和正交归一性，同时使基表达在重构使用的 TI 坐标中。因此，$V(0) = V_{\mathrm{TI},k}$，$V(1) = V_{\mathrm{T},k}QP^{\top}$，路径从原始 TI 基出发，终止于参考子空间。

D.2 几何依据与路径比较

被编辑的对象。前 k 维右奇异子空间指定该层读取的主导输入方向。第 4.3 与 4.4 节通过参数偏差和任务感知表征损害，论证了以这一方向为目标的理由。其 Grassmann 表示将张成同一子空间的所有正交归一基视为同一个对象。GU 保留原输出因子 $U_{\mathrm{TI},k}$、主系数 $\Sigma_{\mathrm{TI},k}$ 与残差 R_{TI}；直接权重插值则同时改变这些分量。

编辑预算最优性。几何问题是：在限制编辑后的子空间偏离原始多模态子空间程度的同时，它能多接近参考？编辑预算规定了允许的偏离。最短路径将全部预算用于对齐：每移动一个单位，到参考的剩余距离就减少一个单位。

令 $S_{\mathrm{TI}} = \mathrm{span}\left(V_{\mathrm{TI},k}\right)$，$S_{\mathrm{T}} = \mathrm{span}\left(V_{\mathrm{T},k}\right)$。采用标准 Grassmann 测地距离 [10]：

$$d(S_1, S_2) = \left(\sum_{i=1}^{k} \theta_i(S_1, S_2)^2\right)^{1/2}, \qquad D = d(S_{\mathrm{TI}}, S_{\mathrm{T}}). \tag{10}$$

这一距离定义编辑预算；第 4.3 节的平均主夹角只是诊断汇总。式（9）的子空间路径可内蕴地写为：

$$S_\eta = \mathrm{Exp}_{S_{\mathrm{TI}}}\left(\eta\ \mathrm{Log}_{S_{\mathrm{TI}}}(S_{\mathrm{T}})\right), \qquad 0 \le \eta \le 1, \tag{11}$$

其中 Log 表示最小化对数映射；当它不唯一时，固定一个最小化分支。每个主方向推进 $\eta\theta_i$，到参考还剩 $(1-\eta)\theta_i$。因此 $d\left(S_{\mathrm{TI}},\, S_\eta\right) = \eta D$，$d\left(S_\eta,\, S_{\mathrm{T}}\right) = (1-\eta)D$。对满足 $d\left(S_{\mathrm{TI}},\, S\right) \le \eta D$ 的任意候选 S，三角不等式给出：

$$d(S, S_{\mathrm{T}}) \ge D - d(S_{\mathrm{TI}}, S) \ge (1-\eta)D. \tag{12}$$

测地线点 S_η 达到该下界，从而证明式（5）。因此，在固定子空间距离预算内，GU 朝匹配参考取得尽可能大的进展。这一最优性针对几何路径，并不声称任务性能最优。

与对齐线性插值比较。使用相同的主基 $A,\, B$，考虑外在路径：

$$L(\eta) = \mathrm{polar}\left((1-\eta)A + \eta B\right), \tag{13}$$

其中 $\mathrm{polar}\,(X) = X\left(X^{\top}X\right)^{-1/2}$ 为正交归一极分解因子。以 $a_i,\, b_i,\, y_i$ 表示 $A,\, B,\, Y$ 的对应列。由于 $b_i = \cos\theta_i\, a_i + \sin\theta_i\, y_i$，第 i 个插值列为：

$$\ell_i(\eta) = \frac{(1-\eta+\eta\cos\theta_i)a_i + \eta\sin\theta_i\, y_i}{\sqrt{(1-\eta+\eta\cos\theta_i)^2 + \eta^2\sin^2\theta_i}}. \tag{14}$$

未归一化的列两两正交，因此极分解步骤分别对各列归一化。其在对应主平面中相对 a_i 的位移为：

$$\phi_i(\eta) = \operatorname{atan2}(\eta\sin\theta_i,\, 1-\eta+\eta\cos\theta_i)\,. \tag{15}$$

一般而言，$\phi_i(\eta) \neq \eta\theta_i$。区别在于插值系数的含义：以同一系数混合全部对齐基向量，一般不会让它们各自推进相同的夹角比例。GU 使 η 在各方向具有一致几何含义，以恒定测地速度让每个主夹角按比例推进。进行权重重构时，对应线性路径的基为 $L(\eta)P^\top$，与 GU 使用相同 TI 坐标。

D.3 实现说明

在实现中，先将 $V_{\mathrm{TI},k}^\top V_{\mathrm{T},k}$ 的奇异值截断到 $[-1,\,1]$，再应用 arccos 计算主夹角。对于接近零的夹角，使用一个小数值常数稳定 $(\sin\Theta)^\dagger$ 的相应元素。算出 $V(\eta)$ 后，用正文式（4）重构编辑层：

$$W' = R_{\mathrm{TI}} + U_{\mathrm{TI},k}\Sigma_{\mathrm{TI},k}V(\eta)^\top. \tag{16}$$

式（9）的转换保证 $\eta = 0$ 时 $W' = W_{\mathrm{TI}}$。所有其他层保持不变。

E 实验设置补充材料

E.1 数据集

表 8 实验使用的数据集划分统计。Split 为划分，Train / Dev / Test 分别为训练集 / 开发集 / 测试集。

Split	Hateful Memes	SNLI-VE	IU-XRay
Train	8,500	353,482	2,928
Dev	500	11,898	366
Test	1,000	11,937	366

主要实验采用三个文本-图像多模态基准：Hateful Memes [26]、SNLI-VE [59] 和 IU-XRay [6]。Hateful Memes 是社交多模态分类基准，需要联合推理模因图像及相关文本。SNLI-VE 是视觉蕴涵基准，将图像与文本假设配对。IU-XRay 是由胸部 X 光图像和放射报告构建的医疗视觉语言数据集。为保持一致，将三者均表述为二分类任务。SNLI-VE 原本含蕴涵、矛盾、中立三类，我们移除中立样本。这在保持跨数据集统一二分类协议的同时，也减轻了已有文献记录的中立类标注问题的影响 [15, 7]。表 8 总结所用数据划分。使用开发集选择超参数，在留出测试集报告最终结果。

E.2 基线

为了组织实验，我们将比较方法分为多模态专用方法、通用训练和适应基线、参数编辑对照。此分组反映各方法在评估中的角色与适用性，并非对已有工作作互斥分类。覆盖范围遵循方法的架构要求：SMIL、Flex-MoE、DyMo 在匹配融合骨干下比较，其他兼容架构的方法则把评估扩展到更多模型家族。

E.2.1 多模态专用方法

SMIL、Flex-MoE 与 DyMo。在全部三个主数据集上，以统一的 RoBERTa-ResNet50 交叉注意力融合骨干评估 SMIL [35]、Flex-MoE [65] 和 DyMo [9]。这一选择遵循它们公开实现的结构假设。SMIL 将贝叶斯元学习与缺失模态特征重构结合，需要选择重构目标和辅助网络插入点。Flex-MoE 使用缺失模态库、专家和专用路由器；DyMo 使用恢复模态候选与推理期模态选择。将这些方法扩展到 CLIP 式或 BLIP-2 模型是可行的，但需要针对各方法修改重构目标、原生融合或 Q-Former 组件、或路由与恢复模块。此类重新设计会改变架构、参数预算和优化流程，为匹配骨干比较引入额外设计选择。当前设置提供共同骨干和训练协议，同时保留各方法的辅助组件。

SMIL、Flex-MoE、DyMo 均使用原论文发布的官方代码库，未指定的设置与默认配置保持一致。为公平比较，所有模型采用相同训练轮数：Hateful Memes 为 10 轮，IU-XRay 为 10 轮，SNLI-VE 为 4 轮。同时，将这些基线的主学习率与统一交叉注意力融合设置匹配。唯一例外是 SMIL 内循环学习率，遵循官方实现设为 1.0×10^{-3} 。

MoRA 与 OGM-GE。MoRA [73] 在三个主数据集的 CLIP Late Concat 与 Mean Pooling 上提供缺失模态适应基线。其模态特定及共享低秩更新耦合成对文本与视觉编码器权重；将此形式应用于 Fusion Concat 需要新的插入点和针对融合的共享规则。OGM-GE [37] 在相同数据集的 Fusion Concat 及两个 CLIP 变体上提供训练期模态平衡基线。CLIP Mean Pooling 允许把完整 logit 精确分解为文本和图像贡献。对于非线性 Late Concat，通过原生单模态前向路径估计模态置信度，同时保留原发表方法的差异度、梯度调制及泛化增强规则。结果见附录 F.4.1。

SiMO [57] 采用专门的协同感知架构和分阶段训练。将其迁移到我们的设置将替换所评估的骨干和训练流程，而不是提供匹配骨干比较。

E.2.2 通用训练和适应基线

Dual CE。在 SNLI-VE 上，使用共享分类器联合监督完整输入路径和缺失图像路径，从头重训练 Fusion Cross-Attention、CLIP Mean Pooling 与 BLIP-2：

$$\mathcal{L}_{\text{Dual CE}} = \mathcal{L}_{\text{TI}} + 0.5\,\mathcal{L}_{\text{T}}.$$

两项均采用带 logits 的二元交叉熵，分别以完整文本-图像输入、以及图像被空输入替代的输入求值。Dual CE+GU 将 GU 应用于所得检查点，以检验局部编辑是否能够补充联合监督。比较见附录 F.4.2。

LoRA。在 SNLI-VE 的同三个架构上比较时，训练后 LoRA [19] 从与 GU 相同的 TI 检查点出发，以缺失图像输入适应相同目标层。采用秩 8、学习率 10^{-4}，训练 4 轮，并在开发集选择最佳检查点。性能与计算成本见第 6.4 节。

E.2.3 参数编辑对照

Weight（层插值）。对每个架构变体，层插值与测地线遗忘使用相同目标层，见表 14。给定所选多模态参数矩阵 W_{TI} 和对应单模态参考参数矩阵 W_{T}，层插值将编辑后的参数构造为：

$$W' = (1-\alpha)W_{\text{TI}} + \alpha W_{\text{T}}.$$

在全部数据集和模型上固定 $\alpha = 0.5$。此基线直接混合参数值，而 GU 只编辑选中的 Grassmann 子空间，同时保留残差参数结构。

Linear（子空间插值）。在三个主数据集的 Fusion Cross-Attention 对照中，Linear 对对齐主基进行插值，并应用式（13）定义的极分解回缩（polar retraction）。它与 GU 使用相同目标层、匹配检查点及参考、秩 $k = 8$ 和系数 $\eta = 0.75$，通过附录 D.2 的重构坐标保留原 TI 输出因子、主系数和残差。这些对照隔离了被编辑对象和子空间路径的影响，结果见附录 F.5。

E.3 计算资源

所有实验均可在一张显存 80GB 的 NVIDIA A100 GPU 上运行，包括训练多模态与单模态参考模型、运行测地线遗忘和层插值、评估缺失模态基线。测地线遗忘本身作为训练后单层参数编辑应用，与模型训练相比增加的计算开销可忽略。

E.4 实现

E.4.1 骨干配置

表 1 的模型家族使用以下骨干配置。基础融合模型使用 RoBERTa 和 ResNet50，强融合设置使用 Qwen2.5-3B 与 OpenCLIP ViT-bigG-14。CLIP 式双塔模型采用 OpenCLIP ViT-L-14，VLM 实验采用带分类头的 BLIP-2。每个 TI 模型均对应一个架构与预训练参数化相同的单模态参考。GU 要求各层在维度和语义上对应；不满足这种对应的参考需要额外对齐映射。

E.4.2 超参数

在三个二分类基准上，标准 TI 训练使用共享分类器，以完整文本-图像输入计算带 logits 的二元交叉熵。Dual CE 按附录 E.2 所述增加缺失图像监督。

对所有使用测地线遗忘的模型，底层多模态模型训练的权重衰减为 1.0×10^{-2}，在开发集选择最佳检查点。最大训练轮数：Hateful Memes 为 10，IU-XRay 为 10，SNLI-VE 为 4。表 10-13 总结各模型家族 TI 模式的学习率。“-”表示相应配置没有该模块。基础融合模型不使用模块特定学习率，对所有可训练参数（包括解冻的编码器骨干）统一使用全局学习率 3.0×10^{-5}。

E.4.3 干预细节

测地线遗忘的测地线系数 $\eta = 0.75$ 与子空间秩 $k = 8$ 在开发集上选定，并在所有数据集和模型家族中固定。每个架构变体的候选层取自第 4 节分析的交互层及附近投影/分类器层。目标层在开发集上根据式（1）的夹角-损害分数选择，该分数结合 TI 模型与 T 参考之间的主夹角偏移，以及缺失模态评估下的任务感知损害差距。若任务感知损害在功能阶段级而非单层级测量，则为该阶段内全部候选层赋予同一阶段损害分数。测试集从不用于目标层选择。表 14 列出每个架构变体所选目标层。

表 9 缺失模态基线的学习率。未指定的超参数遵循官方代码库默认值。SMIL Outer / Inner 分别为外循环 / 内循环。

Dataset	**GU**	SMIL Outer	SMIL Inner	Flex-MoE	DyMo
Hateful Memes	3.0×10^{-5}	3.0×10^{-5}	1.0×10^{-3}	3.0×10^{-5}	3.0×10^{-5}
SNLI-VE	3.0×10^{-5}	3.0×10^{-5}	1.0×10^{-3}	3.0×10^{-5}	3.0×10^{-5}
IU-XRay	3.0×10^{-5}	3.0×10^{-5}	1.0×10^{-3}	3.0×10^{-5}	3.0×10^{-5}

表 10 基础融合模型学习率。所有可训练参数采用一个全局学习率。Concat / Cross-Attention / Gate 分别为拼接 / 交叉注意力 / 门控。

Dataset	Concat	Cross-Attention	Gate
Hateful Memes	3.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
SNLI-VE	3.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
IU-XRay	3.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}

表 11 强编码器融合模型的模块级学习率。Text/Image 同时指 `text_encoder.proj` 和 `image_encoder.proj`；Bottleneck/Head 同时指瓶颈与分类头两个模块，Fusion 为融合模块。

Dataset	Variant	Text/Image	Fusion	Bottleneck/Head
Hateful Memes	Concat	2.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
	Cross-Attention	2.0×10^{-5}	2.0×10^{-5}	3.0×10^{-5}
	Gate	1.0×10^{-5}	2.0×10^{-5}	2.0×10^{-5}
SNLI-VE	Concat	2.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
	Cross-Attention	1.0×10^{-5}	1.0×10^{-5}	1.0×10^{-5}
	Gate	2.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
IU-XRay	Concat	2.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
	Cross-Attention	2.0×10^{-5}	2.0×10^{-5}	3.0×10^{-5}
	Gate	1.0×10^{-5}	2.0×10^{-5}	2.0×10^{-5}

表 12 CLIP 式双塔模型的模块级学习率。Text/Image 同时指两个投影模块；Bottleneck/Head 同时指两个模块。

Dataset	Variant	Text/Image	Fusion	Bottleneck/Head
Hateful Memes	Late Concat	1.0×10^{-5}	1.0×10^{-5}	1.0×10^{-5}
	Mean Pooling	1.0×10^{-5}	–	1.0×10^{-5}
SNLI-VE	Late Concat	1.0×10^{-5}	1.0×10^{-5}	1.0×10^{-5}
	Mean Pooling	1.0×10^{-5}	–	1.0×10^{-5}
IU-XRay	Late Concat	1.0×10^{-5}	1.0×10^{-5}	1.0×10^{-5}
	Mean Pooling	1.0×10^{-5}	–	1.0×10^{-5}

表 13 基于 BLIP-2 的 VLM 模型的模块级学习率。Q-Former 同时指 `vlm_encoder.qformer_embeddings` 与 `vlm_encoder.backbone.qformer`；Projection（投影）同时指 `vlm_encoder.backbone.language_projection` 与 `vlm_encoder.proj`；Bottleneck / Head 分别为瓶颈 / 分类头。

Dataset	Q-Former	Projection	Bottleneck	Head
Hateful Memes	5.0×10^{-6}	5.0×10^{-6}	2.0×10^{-5}	2.0×10^{-5}
SNLI-VE	1.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}
IU-XRay	1.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}	3.0×10^{-5}

表 14 测地线遗忘编辑的目标层。所有配置均使用 $\eta = 0.75$ 和 $k = 8$。Model Family / Variant / Target Layer 分别为模型家族 / 变体 / 目标层；层标识保留原样。

Model Family	Variant	Target Layer
Fusion / Fusion (strong)	Concat	`fusion_mlp0`
Fusion / Fusion (strong)	Gate	`gate_mlp0`
Fusion / Fusion (strong)	Cross-Attention	`attn_v_from_t_in_proj`
Two-tower	Late Concat	`fusion_mlp0`
Two-tower	Mean Pooling	`text_proj`
VLM	BLIP-2 Classifier Head	`qformer_crossattn0_out`

F 补充实验结果

F.1 性能稳定性分析

F.1.1 三次运行的均值与标准差

表 15 和表 16 分别补充表 2 与表 3，报告三次独立运行的均值 ± 样本标准差。对家族级结果，先在各随机种子内对变体取平均，再对三个种子级均值计算均值和样本标准差。因此，所得标准差在与正文均值相同的聚合层级上描述跨运行变异。

三次运行结果中，GU 在表 15 全部三个数据集上仍有最高的平均 TI-T F1。表 16 的家族级结果进一步表明，在所评估家族中，GU 的平均缺失模态恢复和完整模态保持性与插值持平或优于插值。

表 15 表 2 的补充结果。报告三次独立运行的均值 ± 样本标准差。下划线和粗体分别表示平均结果的次优和最优。Method 为方法。

Method	HM	IU-XRay	SNLI-VE
Null-token	57.63 ± 0.88	80.00 ± 0.47	66.35 ± 0.38
SMIL	56.60 ± 0.74	79.21 ± 0.68	$\underline{72.20} \pm 0.52$
Flex-MoE	47.58 ± 1.38	71.02 ± 0.82	70.74 ± 0.64
DyMo	48.82 ± 0.93	79.19 ± 0.77	61.30 ± 0.70
Interpolation	$\underline{58.50} \pm 0.91$	$\underline{80.14} \pm 0.49$	67.29 ± 0.61
GU (Ours)	$\mathbf{60.88} \pm 0.73$	$\mathbf{81.41} \pm 0.63$	$\mathbf{74.41} \pm 0.77$

表 16 SNLI-VE 上表 3 的补充鲁棒性-保持性结果。结果为三次独立运行的均值 ± 样本标准差。Metric 为指标，Method 为方法，str. 为强编码器。

Metric	Method	Fusion	Fusion (str.)	CLIP	VLM
TI-T	Interp.	71.34 ± 0.46	72.34 ± 0.38	74.50 ± 0.44	70.65 ± 0.79
	GU	$\mathbf{73.86} \pm 0.56$	$\mathbf{73.06} \pm 0.43$	$\mathbf{74.68} \pm 0.52$	$\mathbf{70.65} \pm 0.68$
TI-TI	Interp.	86.33 ± 0.18	75.16 ± 0.37	76.13 ± 0.38	81.72 ± 0.30
	GU	$\mathbf{86.37} \pm 0.14$	$\mathbf{75.95} \pm 0.31$	$\mathbf{76.70} \pm 0.31$	$\mathbf{81.73} \pm 0.18$
ΔT	Interp.	0.98 ± 0.30	0.96 ± 0.22	1.04 ± 0.35	0.01 ± 0.10
	GU	$\mathbf{3.49} \pm 0.26$	$\mathbf{1.69} \pm 0.20$	$\mathbf{1.22} \pm 0.33$	$\mathbf{0.01} \pm 0.04$
ΔTI	Interp.	-0.13 ± 0.11	-1.13 ± 0.31	-1.21 ± 0.34	0.00 ± 0.13
	GU	$\mathbf{-0.09} \pm 0.06$	$\mathbf{-0.34} \pm 0.24$	$\mathbf{-0.64} \pm 0.25$	$\mathbf{+0.01} \pm 0.04$

F.1.2 十随机种子配对显著性检验

进一步用十个匹配随机种子验证表 2 的增益。对每个数据集，将 GU 与空词元基线以及该表最强竞争方法比较：HM、IU-XRay 为插值，SNLI-VE 为 SMIL。报告配对的 GU 减基线 F1 差值（$\Delta F1$），形式为均值 ± 样本标准差。统计显著性通过双侧精确配对符号翻转检验评估，并对全部六项比较作 Holm 校正。

如表 17 所示，六项比较在 Holm 校正后仍全部显著（$p < 0.05$）。对每个数据集最强竞争方法，GU 在全部 30 次配对运行中获胜，在 HM、IU-XRay、SNLI-VE 上分别平均增加 +2.41、+1.34、+2.21 F1。这些结果为上文单独报告的三次运行主要结果提供额外统计支持。

表 17 GU 相对 Null 及表 2 最强竞争方法的十种子配对检验。六项比较在 Holm 校正后仍显著。Comparison 为比较，10-seed paired $\Delta F1$ 为十种子配对 F1 差值，GU wins 为 GU 获胜次数，Raw p / Holm p 为原始 / Holm 校正后的 p 值。

Dataset	Comparison	10-seed paired ΔF1	GU wins	Raw p	Holm p
HM	GU−Null	$+3.19 \pm 1.14$	9/10	0.003906	0.011719
HM	GU−Interp.	$+2.41 \pm 0.77$	10/10	0.001953	0.011719
IX	GU−Null	$+1.51 \pm 1.71$	9/10	0.033203	0.033203
IX	GU−Interp.	$+1.34 \pm 0.45$	10/10	0.001953	0.011719
SV	GU−Null	$+8.09 \pm 0.22$	10/10	0.001953	0.011719
SV	GU−SMIL	$+2.21 \pm 0.68$	10/10	0.001953	0.011719

F.2 表征层面证据的更多细节

使用 SNLI-VE Fusion Cross-Attention 模型，量化图 4(a) 背后的表征相似性与功能变化。表 18 使用相同缺失图像测试输入（TI-T），报告三次独立运行的均值 ± 样本标准差。线性 CKA 衡量每个编辑模型与原多模态模型在同一 TI-T 条件下融合层表征的相似度。错误样本间隔增益相对原 TI-T 模型测量。纠正率和退化率分别表示原本错误预测在编辑后被纠正的比例，以及原本正确预测在编辑后变错的比例。

两种编辑均保留总体表征结构：插值的线性 CKA 为 0.988，GU 为 0.991，与图 4(a) 中相似的 UMAP 布局一致。尽管整体相似，GU 带来显著更大的任务级变化：其错误样本间隔增益为 +0.30，而插值为 +0.06；GU 纠正原错误的 34.0%，插值为 11.8%；退化率仅多 0.6 个百分点（5.1% 对 4.5%）。相应地，GU 的 TI-T F1 达到 74.41，而插值为 67.29。这些结果显示，GU 保留整体表征结构，同时通过有针对性的改变改善任务相关间隔、纠正显著更多错误。

表 18 图 4(a) 在 SNLI-VE Fusion Cross-Attention 上的定量分析。两种编辑均保留较高表征相似性，而 GU 获得更大的任务级改善。CKA to orig. 为相对原模型的 CKA，Error-margin gain 为错误样本间隔增益，Corr./regr. rate (%) 为纠正率/退化率（%），Orig. TI-T 为原 TI-T 模型。

Method	TI-T	CKA to orig.	Error-margin gain	Corr./regr. rate (%)
Orig. TI-T	66.35 ± 0.38	1.000	0	0/0
Interp.	67.29 ± 0.61	0.988 ± 0.001	$+0.06 \pm 0.01$	11.8 ± 0.6 / 4.5 ± 0.2
GU (Ours)	74.41 ± 0.77	0.991 ± 0.001	$+0.30 \pm 0.02$	34.0 ± 1.3 / 5.1 ± 0.3

F.3 鲁棒性与保持性权衡的更多结果

正文报告 SNLI-VE 上鲁棒性恢复与完整模态保持性的家族级平均结果。表 19 给出完整逐变体结果，形式为三次独立运行的均值 ± 样本标准差。对每个模型变体，TI-T、TI-TI 分别表示编辑后的缺失模态和完整模态性能，ΔT 、 ΔTI 则度量它们相对原 TI 模型的变化。

跨变体看，GU 通常比层插值带来更大的 TI-T 增益，同时 TI-TI 变化更小或相当。这种区别在交叉注意力融合中最明显：GU 显著改善缺失模态鲁棒性，而完整模态退化有限。CLIP 式和 BLIP-2 架构的增益较小，与其更分散的跨模态交互一致。总体而言，逐变体结果强化了第 6.3 节报告的家族级鲁棒性-保持性模式。

表 19 SNLI-VE 上逐变体鲁棒性-保持性结果。相比插值，GU 通常恢复能力更强，且完整模态保持性相当或更好。Family / Variant / Target Layer / Method 分别为家族 / 变体 / 目标层 / 方法。

Family	Variant	Target Layer	Method	TI-T	TI-TI	ΔT	ΔTI
Fusion	Concat	fusion_mlp0	Interp.	74.86 ± .68	86.10 ± .16	1.82 ± .48	−0.12 ± .10
	Concat	fusion_mlp0	**GU**	**75.11** ± .56	**86.14** ± .12	**2.07** ± .32	**−0.08** ± .05
	Gate	gate_mlp0	Interp.	71.88 ± .47	86.40 ± .18	0.18 ± .24	−0.13 ± .11
	Gate	gate_mlp0	**GU**	**72.05** ± .35	**86.44** ± .12	**0.35** ± .07	**−0.09** ± .04
	Cross-Attn	attn_v←t_in	Interp.	67.29 ± .61	86.50 ± .24	0.94 ± .29	−0.14 ± .15
	Cross-Attn	attn_v←t_in	**GU**	**74.41** ± .77	**86.53** ± .17	**8.06** ± .40	**−0.11** ± .08
Fusion (strong)	Concat	fusion_mlp0	Interp.	72.93 ± .33	76.62 ± .18	0.15 ± .16	0.18 ± .13
	Concat	fusion_mlp0	**GU**	**73.06** ± .24	**76.74** ± .12	**0.28** ± .05	**0.30** ± .07
	Gate	gate_mlp0	Interp.	70.13 ± .52	73.09 ± .23	2.48 ± .34	0.37 ± .17
	Gate	gate_mlp0	**GU**	**71.99** ± .70	**73.30** ± .16	**4.34** ± .46	**0.58** ± .09
	Cross-Attn	attn_v←t_in	Interp.	73.95 ± .48	75.76 ± .82	0.26 ± .24	−3.95 ± .75
	Cross-Attn	attn_v←t_in	**GU**	**74.13** ± .35	**77.81** ± .65	**0.44** ± .09	**−1.90** ± .57
Two-tower	Late Concat	fusion_mlp0	Interp.	73.72 ± .42	77.61 ± .22	0.95 ± .24	−0.44 ± .17
	Late Concat	fusion_mlp0	**GU**	**73.78** ± .51	**77.74** ± .15	**1.01** ± .30	**−0.31** ± .09
	Mean Pooling	text_proj1	Interp.	75.28 ± .67	74.65 ± .59	1.13 ± .52	−1.97 ± .55
	Mean Pooling	text_proj1	**GU**	**75.58** ± .53	**75.65** ± .46	**1.43** ± .35	**−0.97** ± .41
VLM	BLIP-2	q_crossattn0_o	Interp.	70.65 ± .79	81.72 ± .30	0.01 ± .10	0.00 ± .13
	BLIP-2	q_crossattn0_o	**GU**	**70.65** ± .68	**81.73** ± .18	**0.01** ± .04	**0.01** ± .04

F.4 更多基线比较

F.4.1 MoRA 与 OGM-GE

进一步将 GU 与两个架构兼容基线比较。MoRA [73] 是参数高效的缺失模态适应方法，在 CLIP Late Concat 和 Mean Pooling 上评估。其形式在成对文本与视觉编码器权重之间，耦合模态特定和共享的低秩更新。若应用到 Fusion Concat，需要新的插入点以及融合专用共享规则，因此保留其匹配的双编码器参数化。

OGM-GE [37] 是训练期模态平衡方法，在 Fusion Concat 及两个 CLIP 变体上评估。CLIP Mean Pooling 允许完整 logit 精确分解为模态贡献。对非线性 Late Concat，保留原发表方法中的差异度、梯度调制和泛化增强规则，同时用原生单模态前向路径估计模态置信度。

表 20 报告 TI-T / TI-TI，形式为三次独立运行的均值 ± 样本标准差。ΔTI 行表示 GU 相对 Null-token 的平均 TI-TI 变化。GU 在全部九个设置中均取得最高平均 TI-T，包括全部六个 CLIP 设置。在六项 CLIP 比较中，相对 MoRA、OGM-GE 的平均优势分别为 4.42 与 5.04 F1。在 IU-XRay 和 SNLI-VE 上，相对 Null-token 的恢复更大。HM Fusion Concat 原始模态缺失差距只有 0.50 F1，进一步恢复空间较小。

在全部九个设置中，GU 平均改善 TI-T 0.94 F1，而 TI-TI 仅改变 -0.41 F1；最大 TI-TI 损失是 IU-XRay Fusion Concat 的 1.08 F1。MoRA 与 OGM-GE 并不能稳定改善缺失图像性能，而 GU 在超出原融合模型比较范围的两个 CLIP 变体中依然有效。

表 20 与 MoRA、OGM-GE 的跨架构比较。GU 在全部九个评估设置中取得最高平均 TI-T。表内数值为 TI-T / TI-TI F1。 ΔTI 表示 GU 相对 Null-token 的平均 TI-TI 变化（GU 减 Null-token）。

Method	Fusion Concat	CLIP Late Concat	CLIP Mean Pooling
Hateful Memes			
Null-token	68.96 ± 0.44 / 69.46 ± 0.32	66.58 ± 0.41 / 67.31 ± 0.27	66.87 ± 0.24 / 67.14 ± 0.20
MoRA	– / –	65.64 ± 0.28 / 65.39 ± 0.83	60.45 ± 6.17 / 64.98 ± 0.87
OGM-GE	66.71 ± 0.56 / 67.07 ± 0.78	66.07 ± 0.47 / 65.85 ± 0.41	64.51 ± 0.66 / 65.68 ± 1.10
GU	69.01 ± 0.24 / 69.32 ± 0.30	67.03 ± 0.17 / 67.26 ± 0.31	66.96 ± 0.34 / 67.09 ± 0.22
GU ΔTI	−0.14	−0.05	−0.05
IU-XRay			
Null-token	80.70 ± 0.38 / 86.41 ± 0.22	79.45 ± 0.29 / 80.85 ± 0.19	74.30 ± 0.38 / 78.00 ± 0.20
MoRA	– / –	73.87 ± 1.91 / 78.14 ± 0.26	70.55 ± 2.06 / 75.13 ± 0.45
OGM-GE	72.62 ± 3.87 / 77.53 ± 2.25	75.04 ± 0.48 / 75.51 ± 1.02	67.54 ± 0.89 / 71.36 ± 0.33
GU	81.69 ± 0.72 / 85.33 ± 0.80	80.16 ± 0.24 / 80.57 ± 0.31	75.98 ± 0.61 / 77.28 ± 0.36
GU ΔTI	−1.08	−0.28	−0.72
SNLI-VE			
Null-token	73.04 ± 0.24 / 86.22 ± 0.07	72.77 ± 0.21 / 78.05 ± 0.06	74.15 ± 0.18 / 76.62 ± 0.06
MoRA	– / –	70.28 ± 0.99 / 75.06 ± 0.19	72.21 ± 0.12 / 72.17 ± 0.04
OGM-GE	67.26 ± 0.33 / 83.91 ± 0.24	68.10 ± 2.14 / 71.07 ± 0.10	68.00 ± 0.54 / 70.30 ± 0.21
GU	75.11 ± 0.56 / 86.14 ± 0.12	73.78 ± 0.51 / 77.74 ± 0.15	75.58 ± 0.53 / 75.65 ± 0.46
GU ΔTI	−0.08	−0.31	−0.97

F.4.2 LoRA 与 Dual CE

在 SNLI-VE 上，使用 Fusion Cross-Attention（Fusion CA）、CLIP Mean Pooling（CLIP MP）与 BLIP-2 比较 GU、训练后 LoRA 和 Dual CE。表 21 报告缺失图像（TI-T）和完整模态（TI-TI）评估性能。

与 LoRA 比较。LoRA 从与 GU 相同的已训练 TI 检查点出发，以秩 8 适应同一目标层。使用缺失图像输入、学习率 10^{-4} 训练 4 轮，在开发集选择最佳检查点。GU 则利用匹配单模态参考做一次闭式编辑，不再对 TI 检查点进行梯度更新。

在 Fusion CA 和 CLIP MP 上，GU 的平均 TI-T 与 TI-TI 均高于 LoRA。在 BLIP-2 上，LoRA 的 TI-T 恢复略大，但会降低 TI-TI；GU 则使两个指标基本不变。在三个架构上取平均，相对 Null-token，LoRA 提高 TI-T 2.44 F1，TI-TI 变化为 -1.99 F1；GU 提高 TI-T 3.17 F1，TI-TI 仅变化 -0.36 F1。因此，GU 平均多恢复 0.73 F1 的缺失图像性能，并少造成 1.63 F1 的完整模态退化。结果表明，GU 比匹配层 LoRA 适应具有更好的平均跨架构鲁棒性-保持性权衡，将比较扩展到层插值与融合设置之外。

与 Dual CE 比较。Dual CE 对每个架构从头重训练，使用共享分类器联合监督完整输入和缺失图像路径，辅助项权重为 0.5。Dual CE+GU 将 GU 应用于所得 Dual CE 检查点。Dual CE 是强重训练基线，相对 Null-token，在 Fusion CA、CLIP MP、BLIP-2 上分别提高 TI-T 13.57、2.16、4.41 F1；对应 TI-TI 变化分别为 -0.94、-1.40、-0.53 F1。而 GU 在三个架构上都保留了更高完整模态性能。

在 Fusion 设置中，两种方法互补：Dual CE 后应用 GU，使 TI-TI 从 85.70 升至 86.51，同时 TI-T 从 79.92 略升至 80.09。在 CLIP 和 BLIP-2 上，组合没有额外恢复收益。总体而言，Dual CE 倾向于通过重训练取得更强缺失图像恢复，而 GU 提供完整模态保持性更强的训练后校正。GU、LoRA、Dual CE 的计算成本比较见表 4。

表 21 在 SNLI-VE 上与训练后 LoRA 和 Dual CE 的比较。表内 F1 为三次独立运行的均值 ± 样本标准差。

Architecture	Method	TI-T	TI-TI
Fusion CA	Null-token	66.35 ± 0.38	86.64 ± 0.10
	LoRA	72.37 ± 0.25	85.02 ± 0.35
	Dual CE	79.92 ± 0.23	85.70 ± 0.22
	GU	74.41 ± 0.77	86.53 ± 0.17
	Dual CE+GU	80.09 ± 0.30	86.51 ± 0.19
CLIP MP	Null-token	74.15 ± 0.18	76.62 ± 0.06
	LoRA	75.18 ± 0.07	72.96 ± 0.64
	Dual CE	76.31 ± 0.13	75.22 ± 0.08
	GU	75.58 ± 0.53	75.65 ± 0.46
	Dual CE+GU	75.46 ± 0.61	75.45 ± 0.78
BLIP-2	Null-token	70.64 ± 0.70	81.72 ± 0.18
	LoRA	70.90 ± 0.86	81.04 ± 0.23
	Dual CE	75.05 ± 0.13	81.19 ± 0.16
	GU	70.65 ± 0.68	81.73 ± 0.18
	Dual CE+GU	75.05 ± 0.17	81.04 ± 0.49

F.5 几何校正的受控干预

我们考察 GU 背后的两项设计选择：在哪里编辑，以及如何编辑。这些受控比较将第 4 节的诊断与附录 D.2 的几何依据连接起来。

F.5.1 目标层选择

使用图 4(b) 的 IU-XRay Fusion Cross-Attention 逐层扫描，在固定检查点与编辑协议的前提下，比较仅夹角、仅损害、以及夹角-损害联合选择。仅夹角与仅损害分别依据主子空间偏移、任务感知损害对候选层排序；联合规则使用式（1）的开发集分数。表 22 报告三次独立运行的均值 ± 样本标准差。ΔT 和 ΔTI 分别表示 TI-T、TI-TI 相对原 TI 模型的变化。

联合规则产生最大的 TI-T 增益（+1.41 F1）和最小的 TI-TI 损失（-0.13 F1）。仅夹角与仅损害选择带来的增益较小，分别为 +0.34 和 +0.72，TI-TI 变化分别为 -0.61 与 -0.36。因此，结合几何偏移和任务感知损害，比单独使用任一信号更能识别有效校正目标。

表 22 IU-XRay Fusion Cross-Attention 的目标层选择。夹角-损害联合选择提供最强恢复和保持性。Angle only / Harm only / Angle+harm 分别为仅夹角 / 仅损害 / 夹角与损害；Selected layer 为所选层。

	Angle only	Harm only	**Angle+harm**
Selected layer	`attn_t_from_v_out_proj`	`text_proj`	`attn_v_from_t_in_proj`
TI-T	80.34 ± 0.66	80.72 ± 0.40	$\mathbf{81.41} \pm 0.63$
TI-TI	83.96 ± 0.37	84.21 ± 0.32	$\mathbf{84.44} \pm 0.28$
ΔT	$+0.34$	$+0.72$	$\mathbf{+1.41}$
ΔTI	-0.61	-0.36	$\mathbf{-0.13}$

F.5.2 编辑策略比较

接下来在三个数据集的 Fusion Cross-Attention 上比较三种编辑策略。所有方法均使用匹配的 TI/T 检查点、同一目标层和参考、相同评估协议。Weight 以固定 $\alpha = 0.5$ 在完整所选权重矩阵与参考之间插值，因此同时改变输入方向、输出因子、尺度和残差。Linear 与 GU 则编辑对齐主输入子空间，保留原 TI 输出因子、主系数和残差。Linear 采用式（13）的极分解回缩插值，GU 沿 Grassmann 测地线行进。二者均使用 $k = 8$ 和 $\eta = 0.75$。表 23 报告三次独立运行的 TI-T / TI-TI F1 均值 ± 样本标准差。

GU 在三个设置中的平均 TI-T 与 TI-TI 均最高。在 HM、IU-XRay 上，相比 Weight 与 Linear，GU 同时改善缺失图像恢复和完整模态保持性。在 SNLI-VE 上，GU 的 TI-T F1 为 74.41，而 Weight 为 67.29，Linear 为 66.84，同时 TI-TI 性能相当。尤其是与 Linear 的比较隔离了插值路径：即使目标子空间、秩、系数和保留分量都相同，测地线仍能实现显著更强的恢复。

这些对照共同支持 GU 的两项关键设计：结合几何偏移与任务感知损害选择目标，并沿 Grassmann 测地线校正所选主输入子空间。

表 23 Fusion Cross-Attention 上编辑策略的受控比较。GU 在全部三个数据集上取得最高平均 TI-T 和 TI-TI。表内数值为 TI-T / TI-TI F1。Weight 为权重插值，Linear 为对齐子空间线性插值。

Dataset	Weight	Linear	**GU (Ours)**
HM	58.50 ± 0.91 / 66.52 ± 0.33	58.07 ± 1.03 / 66.62 ± 0.21	$\mathbf{60.88} \pm 0.73$ / $\mathbf{67.55} \pm 0.26$
IX	80.14 ± 0.49 / 82.67 ± 0.56	79.83 ± 0.75 / 82.39 ± 0.36	$\mathbf{81.41} \pm 0.63$ / $\mathbf{84.44} \pm 0.28$
SV	67.29 ± 0.61 / 86.50 ± 0.24	66.84 ± 1.29 / 86.50 ± 0.07	$\mathbf{74.41} \pm 0.77$ / $\mathbf{86.53} \pm 0.17$

F.6 向多项选择 VQA 泛化

为将评估扩展到二分类之外，我们在 A-OKVQA [42] 多项选择 VQA 基准上评估 GU。采用附录 E.4.1 的强编码器交叉注意力融合配置，编码器为 Qwen2.5-3B 和 OpenCLIP ViT-bigG-14，并遵循官方数据划分。

表 24 报告十次独立运行的准确率均值 ± 样本标准差。TI-T、TI-TI 分别表示缺失图像与完整模态评估；T 参考的 T-T 准确率列在 TI-T 栏。Shuffle-I 在完整输入推理中用打乱配对的图像评估原 TI 模型。粗体表示 Interpolation、LoRA、GU 三者中的最佳结果。

A-OKVQA 上仍存在 TI-TI > T-T > TI-T 的排序（50.79 > 47.17 > 38.94）。打乱图像使完整输入准确率由 50.79% 降为 39.85%，确认图像信息对完整输入预测有重要贡献。

GU 将 TI-T 准确率提高 2.13 个百分点，并在三种干预中达到最高 TI-TI 准确率，相对原 TI 模型损失 3.39 个百分点。其 TI-TI 准确率分别比 Interpolation、LoRA 高 4.19、2.39 个百分点。LoRA 的 TI-T 恢复更大（+4.58），但 TI-TI 损失也更大（-5.78）。这些结果将 GU 的恢复-保持行为从二分类扩展到多项选择 VQA。

表 24 A-OKVQA 十次运行的多项选择准确率（%）。在所评估干预中，GU 提供最强完整模态保持性。粗体标出 Interpolation、LoRA、GU 中的最佳结果。Acc. 为准确率，T Refer. 为文本参考，Orig. TI 为原 TI 模型，Shuffle-I 为打乱图像。

Method	TI-T Acc.	TI-TI Acc.
T Refer. (T-T)	47.17 ± 0.31	–
Shuffle-I	–	39.85 ± 1.97
Orig. TI	38.94 ± 1.92	50.79 ± 0.71
Interp.	39.80 ± 1.21	43.21 ± 1.44
LoRA	$\mathbf{43.52} \pm 0.60$	45.01 ± 1.72
GU (Ours)	41.07 ± 1.79	$\mathbf{47.40} \pm 1.19$

F.7 缺失文本输入下的补充评估

进一步在 HM、IU-XRay、SNLI-VE 上，使用 Fusion Cross-Attention 评估缺失文本输入下的 GU。这里 TI-I 表示在没有文本时评估 TI 训练模型，I-I 表示匹配的仅图像参考。GU 和层插值均以该仅图像模型作为参考。表 25 报告三次独立运行的 F1 均值 ± 样本标准差。

全部三个数据集均满足 TI-TI > I-I > TI-I，与第 4.2 节的缺失图像模式相呼应。GU 在 HM、IU-XRay、SNLI-VE 上分别改善 TI-I 1.02、0.84、2.13 F1，而 TI-TI 仅变化 -0.17、+0.07、+0.03 F1。

GU 的平均 TI-I 也高于匹配层插值，并且在三个数据集上都更接近原 TI-TI 性能。虽然编辑后的 TI-I 仍低于匹配 I-I 参考，GU 却稳定缩小了这一差距。这些结果展示了 GU 跨缺失方向的泛化能力：当与部署时可用模态配对时，同一校正原则能一致改善缺失图像和缺失文本输入的鲁棒性。

表 25 Fusion Cross-Attention 的缺失文本评估。GU 在三个数据集上均改善 TI-I，同时大体保持完整模态性能。Eval. 为评估方式，I Refer. 为仅图像参考。

Method	Eval.	HM	IU-XRay	SNLI-VE
Orig. TI	TI-TI	68.82 ± 0.48	84.57 ± 0.28	86.64 ± 0.10
I Refer.	I-I	66.58 ± 0.15	75.32 ± 0.41	68.74 ± 0.00
Orig. TI	TI-I	63.32 ± 0.88	73.58 ± 0.85	64.48 ± 0.97
Interp.	TI-I	64.10 ± 0.24	73.70 ± 0.76	65.87 ± 0.46
Interp.	TI-TI	68.30 ± 0.28	84.39 ± 0.36	86.01 ± 0.15
GU (Ours)	TI-I	64.34 ± 0.20	74.42 ± 0.22	66.61 ± 0.27
GU (Ours)	TI-TI	68.65 ± 0.23	84.64 ± 0.48	86.67 ± 0.15