面向多标签置信度校准的动态相关性学习与正则化

Dynamic Correlation Learning and Regularization for Multi-Label Confidence Calibration

Tianshui Chen，Weihang Wang，Tao Pu，Jinghui Qin，Zhijing Yang，Jie Liu，Liang Lin（IEEE Fellow）

非官方中文全文译文 · 原文版本 arXiv:2407.06844v1 · 2024 年 7 月 9 日

原文及版本来源：arXiv:2407.06844v1。原文采用 Creative Commons Attribution 4.0 International（CC BY 4.0）许可。原作者及著作权归属如上；本中文翻译、重新排版和标注由 AI 助手制作，属于非官方改编，不表示原作者认可。译文文字按 CC BY 4.0 提供，原作者图表和公式保留原有署名及许可。本版完整翻译所提供 13 页版本的正文、图表说明、算法、55 条参考文献及 7 段作者简介；该版本不含附录。

图像处理说明：图 1、图 5 仅保留可分离的作者预测分数面板；图 2 保留不含照片的架构、特征和相关性面板。示例照片、照片衍生热图及作者肖像的单独权利未获核实，因此不予复制；各处明确说明省略内容，并链接原文。图 3、图 4、表 I-VI、式（1）-（17）及算法 1 采用原文清晰裁切，保留原始数值与数学排印，另配中文说明。此版不宣称完整保留所有原图；未将原始完整 PDF 或源文整页渲染图作为译文配套发布。

摘要

现代视觉识别模型依赖复杂的深度神经网络和独热目标监督，往往表现出过度自信，产生不可靠的置信度分数，因此需要进行校准。现有置信度校准技术主要针对单标签场景，对于更实用、更具普适性的多标签场景则缺少关注。本文提出多标签置信度校准（Multi-Label Confidence Calibration，MLCC）任务，旨在为多标签场景提供经过良好校准的置信度分数。不同于单标签图像，多标签图像包含多个物体，容易导致语义混淆，进一步降低置信度分数的可靠性。现有基于标签平滑的单标签校准方法没有考虑类别相关性，而这种相关性对于解决语义混淆至关重要，因此这些方法的性能并不理想。为克服上述局限，我们提出动态相关性学习与正则化（Dynamic Correlation Learning and Regularization，DCLR）算法，利用多粒度语义相关性，更好地对语义混淆进行建模，从而实现自适应正则化。DCLR 学习各类别特有的动态实例级和原型级相似度，并利用这些相似度度量不同类别之间的语义相关性。在此基础上，我们构造自适应标签向量，为相关性强的类别赋予更高的值，从而实现更有效的正则化。我们建立了一个评测基准，重新实现了若干先进的置信度校准算法，并将它们应用于领先的多标签识别（MLR）模型，以进行公平比较。大量实验表明，在多标签场景中提供可靠置信度分数方面，DCLR 的表现优于现有方法。

关键词：多标签图像识别；置信度校准；过度自信；可信人工智能。

作者单位与通信信息。Tianshui Chen、Weihang Wang、Jinghui Qin 和 Zhijing Yang 任职于广东工业大学（电子邮箱：tianshuichen@gmail.com、wwkml994@gmail.com、scape1989@gmail.com、yzhj@gdut.edu.cn）。Tao Pu 和 Liang Lin 任职于中山大学（电子邮箱：putao537@gmail.com、linliang@ieee.org）。Jie Liu 任职于北方工业大学（电子邮箱：liujxxxy@126.com）。通信作者为 Jinghui Qin。

资助说明。本研究获得国家自然科学基金（NSFC，项目编号 62206060、62206314）、广州市基础与应用基础研究基金（项目编号 SL2022A04J01626、2022A1515011835），以及广州市科技计划项目（项目编号 2024A04J4388）的部分资助。

I 引言

建立在复杂深度神经网络 [1]、[2] 之上的现代视觉识别模型，往往会对训练数据过拟合，不可避免地陷入预测分数过度自信且不可靠的困境 [3]-[5]。这一问题严重阻碍了它们在自动驾驶 [6]、[7] 和医学诊断 [8]、[9] 等高风险场景中的应用。为解决这一问题，人们开展了大量置信度校准研究 [3]、[10]、[11]，旨在提供更准确、可靠的预测置信度分数，使其准确反映预测正确的概率。尽管这些工作取得了显著进展，但它们主要集中在每幅图像仅关联一个类别的单标签设置。然而，现实世界中的图像往往包含多个类别的物体 [12]-[14]，已有工作难以应用于这种更贴近实际的多标签场景。我们的工作面向多标签置信度校准（MLCC）任务，旨在将校准技术扩展到这些更复杂、更实用的场景并加以改进。

现有多标签识别（MLR）模型 [15]、[16] 主要将各类别的独热目标标签用作监督，忽略其他类别的信息。因此，这些模型容易不加区分地为预测赋予过高的置信度，最终形成严重的过度自信问题。此外，这些模型学习整体特征 [16]、[17] 或类别特定特征 [15] 来进行预测。但是，由于一幅图像中分布着多个语义物体，这些特征往往同时捕获多个语义物体的信息，导致显著的语义混淆，并进一步加剧过度自信问题。在图 1 的第一个示例中，现有模型由于“花瓶”和“盆栽”外观相似而将其混淆，为不存在的“盆栽”赋予过度自信的分数。同样，图中并不存在类似“手机”和“书”的物体，但模型仍错误地为这两个类别赋予很高的置信度。传统置信度校准算法 [3]、[10] 通常采用标签平滑机制 [10]，从目标类别中重新分配一个较小的值，以相等且独立的方式分配给所有非目标类别，从而对每个类别进行平滑。然而，这些算法未考虑能够捕获语义混淆并实现自适应正则化的类别相关性，因此在 MLCC 场景中的表现并不理想。

图 1　当前先进 MLR 模型在使用和不使用 DCLR 校准时的两个预测分数示例。图像中实际存在的类别以粗体标出。

	handbag	**vase**	potted plant	cell phone
SSGRL	35.89%	69.83%	98.55%	71.88%
SSGRL+Ours	94.09%	91.32%	22.29%	30.48%
MLGCN	2.35%	3.93%	76.29%	87.57%
MLGCN+Ours	89.92%	89.76%	2.80%	3.93%
CTran	36.22%	1.97%	87.29%	48.90%
CTran+Ours	97.58%	93.78%	37.07%	4.19%

	handbag	**dining table**	cell phone	book
SSGRL	63.80%	28.73%	95.28%	72.99%
SSGRL+Ours	94.30%	89.28%	18.31%	20.80%
MLGCN	42.20%	31.26%	87.10%	86.37%
MLGCN+Ours	95.29%	93.50%	15.76%	17.64%
CTran	48.43%	30.26%	93.22%	81.51%
CTran+Ours	98.32%	96.29%	18.70%	19.95%

译注：上、下两组预测分数均取自原图，仅省略各组左侧的示例照片。上组列名依次为手提包、花瓶、盆栽、手机；下组为手提包、餐桌、手机、书。Ours 表示本文方法。照片与完整图像请参阅原文第 1 页图 1；照片权利尚未单独核实。

本研究提出动态相关性学习与正则化（DCLR）算法，专门用于学习和整合类别相关性，对多标签图像中的语义混淆建模，从而实现更有效的自适应正则化。我们采用类别特定对比学习模块，为给定图像的每个类别学习独立的特征表示及其特征相似度。该方法使我们能够利用实例级特征相似度对类别相关性建模，为关联紧密的类别赋予较高值，为关联较弱的类别赋予较低值，由此形成用于自适应正则化的软标签向量。为进一步增强模型，我们为每个类别学习原型表示，并计算原型与特征之间的相似度，建立更稳健的类别相关性。随后，以同样方式利用这些相关性构造另一个软标签向量。两个软标签向量的结合包含多样而稳健的类别相关性，可以无缝集成到任何现有多标签识别方法 [15]、[16]、[18] 中，以即插即用的方式实现有效校准。如图 1 所示，将 DCLR 算法加入现有模型后，能够获得明显更好地校准的分数。

目前尚无 MLCC 评测基准，这严重阻碍了该任务的发展。本研究进一步建立统一评测基准，用于公平比较 MLCC 方法并推动该领域研究。具体而言，我们首先重新实现传统标签平滑 [10] 和若干领先的置信度校准算法 [11]、[19]-[21]，并使其适应 MLCC 任务。为进行公平、全面的比较，我们将这些算法及所提出的 DCLR 算法应用于三个具有代表性的 MLR 模型：分别学习类别特定特征和整体特征用于分类的 SSGRL [15] 与 ML-GCN [16]，以及使用更先进 Transformer 网络的 C-Tran [18]。我们使用自适应校准误差（ACE）[22]、期望校准误差（ECE）[23]、最大校准误差（MCE）[20] 和可靠性图 [24] 等传统指标进行性能评估。

本研究的贡献可概括为四点。第一，我们将置信度校准从单标签识别扩展到更实用、更重要的多标签场景，并对 MLCC 任务进行深入分析。第二，我们提出新的动态相关性学习与正则化算法，学习类别相关性以建模语义混淆，并整合这些相关性来正则化 MLR 模型的训练，以即插即用的方式解决过度自信

问题。第三，我们构建公平、全面的 MLCC 评测基准，能够有效评估各个性能良好算法的实际作用，促进该领域研究。最后，我们遵循统一基准开展大量实验，验证所提算法的有效性。该统一基准包含所有重新实现算法及所提 DCLR 算法的代码和训练模型，可在以下地址获得：https://github.com/wkml/MLCC-DCLR。

II 相关工作

我们从多标签图像识别和置信度校准两条主要研究路线回顾相关文献。

A 多标签图像识别

近年来，多标签图像识别（MLR）受到了学术界的广泛关注，代表性工作包括 [13]、[15]、[18]、[25]-[30]。对 MLR 的高度关注凸显了其相较于单标签任务的实用性和优势。早期 MLR 工作通过识别包含更具判别力的物体及其部件的局部区域，学习更强的特征表示。这些工作或者侧重于物体候选区域 [12]、[31]，或者使用视觉注意力机制 [32]-[34]。作为一项开创性工作，Wei 等人 [12] 使用现成算法提取数千个物体候选区域，并聚合这些区域的预测分数，得到最终的 MLR 结果。尽管取得了显著进展，这些算法只考虑视觉特征，而未考虑标签相关性。实际上，多标签图像天然存在较强的标签相关性，这些相关性可以作为额外知识来正则化 MLR 模型的训练。此前的工作，如 [34]、[35]，引入循环神经网络（RNN）或长短期记忆网络（LSTM）学习上下文化特征表示，从而隐式捕获这些相关性。受图传播网络 [36]、[37] 启发，近期工作 [15]、[16] 提出使用结构化图表示显式建模标签相关性，显著改善了 MLR 性能。例如，Chen 等人 [15] 首先学习类别特定特征，再利用标签共现相关性将这些特征关联起来，并引入图神经网络沿图传播信息，学习上下文化特征。得益于更强大的 Transformer 网络 [2]、[38]、[39]，更近期的工作进一步引入 Transformer 网络 [18]、[40]，学习更具判别力的特征或更好地捕获标签相关性，进而获得更好的 MLR 性能。

B 置信度校准

多分类问题中的置信度校准长期以来已得到广泛研究。置信度校准旨在使分类器正确量化逐实例预测所对应的不确定性或置信度。已有许多方法 [3]、[10]、[11]、[19]-[21]、[41]-[44] 用于纠正模型置信度。标签平滑（LS）[10] 被提出作为模型校准的一项基础技术，用来防止网络过度自信。焦点损失（FL）[41] 最初旨在将训练集中于一组稀疏的困难样本，并避免大量简单负样本在训练中淹没检测器。在后续研究 [3] 中，人们发现它也能作为模型校准方法。随后，带样本依赖调度的焦点损失（FLSD）[3] 作为改进型焦点损失被提出，可以自动选择用于模型校准的超参数。预测置信度与准确率之差（DCA）[11] 是一种基于期望校准误差的校准方法，通过将预测置信度与准确率之差加入辅助损失来纠正置信度。最大均值校准误差（MMCE）[42] 是基于再生核希尔伯特空间（RKHS）核的校准度量：在完全校准时该度量达到最小值，其有限样本估计具有一致性和较快的收敛速度。多类别置信度与准确率差异（MDCA）[20] 是一种新的辅助损失函数，用于帮助模型实现相应的 MDCA。基于间隔的标签平滑（MbLS）[21] 从统一的约束优化角度理解现有先进校准损失，然后在 logit 距离上施加可控间隔，得到基于不等式约束、简单而灵活的推广。动态加权平衡损失（DWBL）[19] 则采用基于类别平衡动态加权损失的类别再平衡策略来调整模型置信度。它根据类别频率和真实类别的预测概率为不同类别赋权，从而缓解深度学习中的类别分布不平衡问题。根据预测分数自动调整权重，使模型能够适应难度不同的实例，实现模型校准。

尽管上述方法在多分类任务的置信度校准方面取得了显著进展，但尚未在多标签识别设置下得到探索。在本研究中，我们将这些方法扩展到多标签识别任务，以验证其有效性，并将它们作为基线纳入评测基准，以便公平比较。此外，这些方法没有考虑能够有效捕获语义混淆的类别相关性，因而在 MLCC 场景中的表现并不理想。为解决这一问题，我们提出新的置信度校准方法 DCLR，学习类别相关性来建模多标签图像中的语义混淆，并整合这些相关性，实现自适应且更有效的校准。

III 动态相关性学习与正则化

MLR 关注多类别分类问题中的样本标签预测，其中每个样本可能属于不止一个类别。给定训练集 $D = \{(\mathbf{x}^n, \mathbf{y}^n)\}_{n=1}^N$ 和 C 个物体类别，MLR 模型旨在预测给定图像实际包含的一个或多个物体类别。其中，N 为样本总数，$\mathbf{x}^n \in \mathbb{R}^{H\times W\times 3}$ 表示 D 中的第 n 幅图像，$\mathbf{y}^n = \{y_1^n, \ldots, y_C^n\} \in \{1, 0\}^C$ 为多热编码标签向量。现有大多数方法将真实多热标签向量作为监督信号，利用二元交叉熵损失优化模型以实现这一目标。真实多热标签向量由不同类别的多个硬标签组成，每个分量为 0 或 1。虽然这些硬标签可以定义图像所属的类别，但用这些硬标签优化模型往往会使模型过度自信，导致输出分布不可信，难以与预测正确性的准确概率对应 [4]、[21]。

为缓解神经网络的过度自信问题，标签平滑（LS）[10]、[21] 作为一种输出分布正则化形式和成熟的单标签置信度校准方法，经常用于增强鲁棒性、改善多类别识别问题。标签平滑通过对均匀分布与硬标签进行加权平均，将硬标签转换为软标签，其形式如下：

$$\tilde{y}_c^i = \begin{cases} 1-\alpha, & y_c^i = 1 \\ \dfrac{\alpha}{C-1}, & y_c^i = 0 \end{cases} \tag{1}$$

已有研究表明，这种方法能够隐式校准所学习的模型：它防止模型将全部概率质量分配给单一类别，同时使真实类别与其他类别的 logit 保持合理距离 [21]、[45]。直观地说，标签平滑正则化也可以类似地扩展到多标签识别问题，其形式为：

$$\tilde{y}_c^i = \begin{cases} 1-\alpha, & y_c^i = 1 \\ \dfrac{\alpha M}{C-M}, & y_c^i = 0 \end{cases} \tag{2}$$

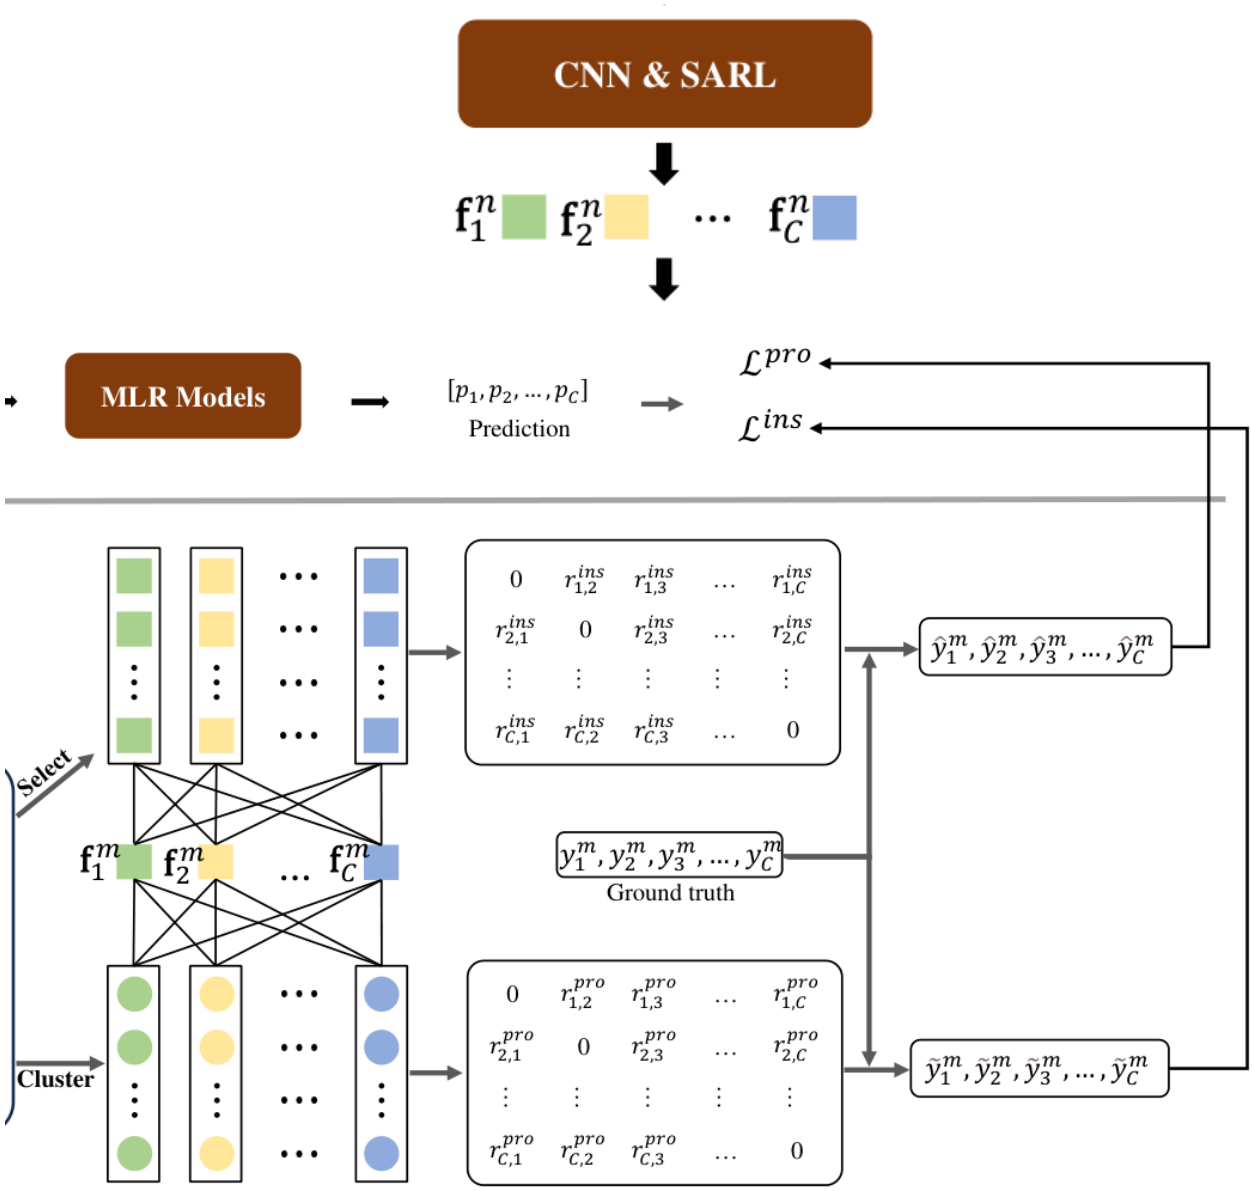
其中，$M \le C$ 是样本 $\mathbf{x}^i$ 的类别数，$\alpha \ge 0$ 是输出分布正则化的超参数。如果 $M = 1$，式（2）就等于式（1）。如果令 $\alpha = 0$，式（2）就等于原始标签。此外，如果 α 过大，模型将无法预测真实标签。

现有标签平滑算法将惩罚项 α 均匀分配给所有负类别。但是，这些算法忽略了相似物体类别之间的语义混淆和相关性，而这种现象在多标签图像中天然存在。因此，它们无法有效约束与正类别存在强相关的负类别。这些高度相关的类别仍然彼此混淆，使 MLR 场景中的校准性能不理想。

在本研究中，我们提出一个直接而有说服力的假设：与正类别相似度高的负类别应受到更大的惩罚，其他负类别则应受到较小的惩罚。为此，我们引入动态相关性学习与正则化（DCLR）算法，学习类别相关性以有效建模多标签图像中的语义混淆，并利用这些相关性为 MLR 模型构建自适应、高效的正则

化。图 2 展示了 DCLR 算法及其与现有 MLR 模型的集成方式。DCLR 基于类别特定对比学习模块，为每个类别学习语义感知特征表示。随后，算法同时探索实例到实例和实例到原型的相似度，以建模类别相关性，并据此计算软化标签向量。接着，这些向量用于监督现有 MLR 模型。通过这种自适应正则化，DCLR 有效地惩罚高度相关的类别，从而更准确地解决语义混淆。

图 2　所提 DCLR 算法及其与 MLR 模型集成的总体示意图。首先，输入图像经骨干网络及 SARL 模块处理，提取类别特定特征。随后，我们计算所提取特征与所选实例样本特征之间，以及所提取特征与原型表示之间的相似度，从而得到实例级和原型级相关性矩阵，有效建模语义混淆。最后，根据相应的相关性矩阵和真实标签，计算实例级和原型级软化标签向量。这些软化标签向量用于 MLR 模型训练。



译注：上方保留 CNN 与 SARL 特征提取模块，下方保留原图右侧架构、特征、原型和相关性矩阵。原图左上输入照片及左下正样本照片衍生热图未复制，两个保留区域的相对位置因此调整。MLR Models：MLR 模型；Prediction：预测；Select：选择；Cluster：聚类；Ground truth：真实标签；Positive samples：正样本。完整原图见原文第 4 页图 2。

A 类别特定对比学习

为准确衡量类别相关性，需要为每个类别学习满足两项关键标准的语义感知特征。首先，类别 c 的特征向量应主要包含该类别特有的语义信息，尽可能减小其他类别信息的影响。其次，相关类别的特征应具有较高相似度，不相关类别的特征则应具有明显较低的相似度。为实现这一目标，我们引入类别特定对比学习（CSFL）模块。该模块融入类别语义，以指导捕获特定语义信息，并通过分类损失与对比损失的组合进行训练。它不仅增强对相关语义内容的关注，还确保依据类别相关性对特征进行有效区分和对齐，从而满足上述两项标准。

给定输入图像 I^m，我们首先使用标准骨干网络（例如 ResNet101 [1]），再接入先前工作 [15] 中的语义嵌入注意力机制，提取类别特定特征向量，简称 CNN&SARL。其形式表示为：

$$\{\mathbf{f}_1^m, \mathbf{f}_2^m, \cdots, \mathbf{f}_C^m\} = \phi(I^m). \tag{3}$$

为确保所学特征满足两项关键标准，我们引入分类损失与对比损失的组合。

辅助分类损失。为确保特征向量 $\mathbf{f}_c^m$ 能够有效包含与其类别有关的语义信息，我们使用分类器仅根据相应特征向量 $\mathbf{f}_c^m$ 来预测特定类别 c。对所有学习到的特征向量执行这一过程，得到概率分布 $\widehat{\mathbf{p}}^m = \{\widehat{p}_1^m, \widehat{p}_2^m, \ldots, \widehat{p}_C^m\}$。随后，我们使用软化标签向量 $\widetilde{\mathbf{y}}^m = \{\widetilde{y}_1^m, \widetilde{y}_2^m, \ldots, \widetilde{y}_C^m\}$ 和 $\widehat{\mathbf{y}}^m = \{\widehat{y}_1^m, \widehat{y}_2^m, \ldots, \widehat{y}_C^m\}$ 来定义分类损失（这些向量将在 III-B 和 III-C 节详细说明）：

$$\mathcal{L}_{acl} = \eta \sum_{m=1}^{N} (\ell(\hat{\mathbf{p}}^m, \hat{\mathbf{y}}^m) + \ell(\hat{\mathbf{p}}^m, \tilde{\mathbf{y}}^m)) \tag{4}$$

其中：

$$\ell(\mathbf{p}, \mathbf{y}) = \sum_{c=1}^{C} (y_c \log(p_c) + (1 - y_c) \log(1 - p_c)) \tag{5}$$

这里令 $\eta = 0.5$，使其量级与常用的传统交叉熵分类损失相一致。

类别特定对比损失。我们考虑的另一个标准是：相关类别中的特征应表现出较高相似度，而不相关类别的特征应表现出较低相似度。但是，由于缺少详细描述这些类别相似性的精确标注，无法获得用于学习此类相关性的准确监督信号。本研究引入类别特定对比损失，利用现有标签标注学习这些相关性。对于任意两幅图像和给定类别，如果两幅图像都包含该类别，则使相应特征接近；否则使其远离。由于不同图像中同一类别的物体通常具有相似视觉特征 [46]，这种方法可以有效学习不同类别之间的视觉相关性。

形式上，给定两幅图像 m、n 和类别 c，我们通过余弦距离计算它们的相似度：

$$s_c^{m,n} = \text{cosine}(\mathbf{f}_c^m, \mathbf{f}_c^n) = \frac{\mathbf{f}_c^m \cdot \mathbf{f}_c^n}{||\mathbf{f}_c^m|| \cdot ||\mathbf{f}_c^n||}. \tag{6}$$

如果图像 m 和 n 都包含类别 c，则期望 $s_c^{m,n}$ 较高，否则较低。为此，我们将类别特定对比损失表示为：

$$\mathcal{L}_c = \sum_{m=1}^{N} \sum_{c=1}^{C} \sum_{n} \ell_c^{m,n}, \tag{7}$$

其中：

$$\ell_c^{m,n} = \begin{cases} 1 - s_c^{m,n} & y_c^i = 1, y_c^j = 1 \\ 1 + s_c^{m,n} & otherwise. \end{cases} \tag{8}$$

因此，类别特定对比学习（CSCL）模块的最终损失定义为：

$$\mathcal{L}_{cscl} = \mathcal{L}_{acl} + \mathcal{L}_c \tag{9}$$

训练算法。算法 1 给出了 CSCL 的完整训练算法。如前所述，每个训练步骤的第 4-6 行负责生成实例级和原型级软标签。然后，第 7-9 行计算辅助分类损失 $\mathcal{L}_{acl}$、类别特定对比损失 $\mathcal{L}_c$ 及最终损失 $\mathcal{L}_{cscl}$。训练过程在数据集上持续迭代，直至收敛。CSCL 训练完成后，即可用于生成软标签，指导各种 MLR 模型的训练。

算法 1　类别特定对比学习（CSCL）的训练过程

Algorithm 1 Training Procedure of Category-Specific Contrastive Learning (CSCL)

Input: Training image dataset $\mathcal{D}$;
Output: well-trained CNN&SARL module ϕ;

1: initialize CNN&SARL module ϕ;
2: **repeat**
3: **for all** $I^m \in \mathcal{D}$ **do**
4: $\{\mathbf{f}_1^m, \mathbf{f}_2^m, \cdots, \mathbf{f}_C^m\} = \phi(I^m)$
5: obtain instance-level soft label vector $\hat{\mathbf{y}}^m$ according to Equation (13)
6: obtain prototype-level soft label vector $\tilde{\mathbf{y}}^m$ according to Equation (15)
7: compute $\mathcal{L}_{acl}$ according to Equation (4)
8: compute $\mathcal{L}_c$ according to Equation (7)
9: $\mathcal{L}_{cscl} = \mathcal{L}_{acl} + \mathcal{L}_c$
10: update the model parameters of ϕ by minimizing $\mathcal{L}_{cscl}$
11: **end for**
12: **until** ϕ convergence
13: **return** the CNN&SARL module ϕ

算法 1 中文逐行说明。输入：训练图像数据集 D；输出：训练好的 CNN&SARL 模块 ϕ。

1. 初始化 CNN&SARL 模块 ϕ。
2. 重复以下步骤。
3. 对所有 $I^m \in D$ 执行：
4. 计算 $\{\mathbf{f}_1^m, \mathbf{f}_2^m, \ldots, \mathbf{f}_C^m\} = \phi(I^m)$。
5. 根据式（13）获得实例级软标签向量 $\widehat{\mathbf{y}}^m$。
6. 根据式（15）获得原型级软标签向量 $\widetilde{\mathbf{y}}^m$。
7. 根据式（4）计算 $\mathcal{L}_{acl}$。
8. 根据式（7）计算 $\mathcal{L}_c$。
9. 令 $\mathcal{L}_{cscl} = \mathcal{L}_{acl} + \mathcal{L}_c$。
10. 通过最小化 $\mathcal{L}_{cscl}$ 更新 ϕ 的模型参数。
11. 结束 for 循环。
12. 直至 ϕ 收敛。
13. 返回 CNN&SARL 模块 ϕ。

B 实例级相关性感知正则化

获得类别特定特征向量后，我们可以通过类别特定特征相似度，计算不同类别之间的相关性，构成 $\mathbf{R}^{ins}$。该矩阵第 i 行、第 j 列的元素 r_{ij}^{ins} 表示类别 i 与 j 的相关性。随后，利用该矩阵导出软标签向量，用于训练 MLR 模型。

给定图像 m 和类别 c，为计算 c 与 c' 的相关性，我们首先检索具有正标签 c' 的图像子集。相关值可按下式计算：

$$r_{cc'}^{ins} = \sum_{t=1}^{T} \text{cosine}(\mathbf{f}_c^m, \mathbf{f}_{c'}^{n_t}) \tag{10}$$

其中，T 为检索到的图像数量。对于每幅图像 m，我们计算所有类别 c 和 c' 之间的相关值，得到相关性矩阵 $\mathbf{R}_m^{ins}$。

为消除惩罚项中标签自身的影响，需要屏蔽相关性矩阵的对角线，实现方式如下：

$$r_{cc'}^{ins} = \begin{cases} -\infty, & c = c' \\ r_{cc'}^{ins}, & otherwise. \end{cases} \tag{11}$$

接着，使用 softmax 函数对所有类别之间的相似度分数归一化：

$$r_{cc'}^{ins} = \frac{\exp(r_{cc'}^{ins})}{\sum_k \exp(r_{ck}^{ins})}. \tag{12}$$

最后，根据实例级相关性矩阵 $\mathbf{R}_m^{ins}$ 得到软标签向量：

$$\hat{y}_c^m = \begin{cases} 1-\alpha, & y_c^m = 1 \\ \sum_{k=1}^{C} \alpha r_{kc}^{ins} y_k^m, & y_c^m = 0 \end{cases} \tag{13}$$

对所有类别重复这一过程，得到实例级软标签向量 $\widehat{\mathbf{y}}^m = \{\widehat{y}_1^m, \widehat{y}_2^m, \ldots, \widehat{y}_C^m\}$。

C 原型级相关性感知正则化

尽管上述实例级相关性感知正则化可以作为改进的标签平滑方法，但它只捕获相对局部的类间相关性，因为对于每个输入图像，仅采样部分图像来计算类别特定相关性。为了将全局类间相关性纳入框架，为模型校准构建更加稳健的平滑标签，我们进一步引入能够表示类别全局特征的类别原型，从全局层面对类别特定相关性建模。

为实现原型级相关性感知正则化，对于每个类别 c，我们首先从所有将 c 标记为其标签之一的图像中，提取全部实例级特征。然后使用 K 均值算法 [47] 将实例级特征聚类为 K 个原型级特征 $\{\mathbf{p}_c^1, \mathbf{p}_c^2, \ldots, \mathbf{p}_c^K\}$。这里令 $K = 10$，因为属于任一类别 c 的图像都存在视觉变化。例如，不同图像中属于同一类别的物体可能具有不同外观。因此，我们聚类得到多个原型级特征，以涵盖任一类别 c 的视觉变化。

给定图像 m 和类别 c，我们以相同方式计算相关值，其形式为：

$$r_{cc'}^{pro} = \sum_{k=1}^{K} \text{cosine}(\mathbf{f}_c^m, \mathbf{p}_c^k). \tag{14}$$

类似地，我们根据式（14）计算所有类别 c 和 c' 的相关值，再将对角线赋值为 $-\infty$，并使用 softmax 函数归一化，得到原型级相关性矩阵 $\mathbf{R}_m^{pro}$。随后，利用该矩阵得到软标签向量：

$$\tilde{y}_c^m = \begin{cases} 1-\alpha, & y_c^m = 1 \\ \sum_{k=1}^{C} \alpha r_{kc}^{pro} y_k^m, & y_c^m = 0 \end{cases} \tag{15}$$

最终得到原型级软标签向量 $\widetilde{\mathbf{y}}^m = \{\widetilde{y}_1^m, \widetilde{y}_2^m, \ldots, \widetilde{y}_C^m\}$。

D 对现有 MLR 模型进行正则化

DCLR 算法训练完成后，可以用来生成软化标签向量，代替传统独热标签向量。这些软化向量随后用于监督 MLR 模型训练。给定输入图像 n，将其送入 MLR 模型，预测概率分布 $\mathbf{p}^n = \{p_1^n, p_2^n, \ldots, p_C^n\}$；同时将其送入 DCLR 模型，得到软化标签向量，即 $\mathbf{p}_{ins}^n = \{y_{ins,1}^n, y_{ins,2}^n, \ldots, y_{ins,C}^n\}$ 和 $\mathbf{p}_{pro}^n = \{y_{pro,1}^n, y_{pro,2}^n, \ldots, y_{pro,C}^n\}$。分类损失函数定义为：

$$\mathcal{L}_{cls} = \eta(\mathcal{L}^{ins} + \mathcal{L}^{pro}) \tag{16}$$

其中：

$$\begin{aligned} \mathcal{L}^{ins} &= \sum_{m=1}^{N} (\ell(\mathbf{p}^m, \hat{\mathbf{y}}_m) \\ \mathcal{L}^{pro} &= \sum_{m=1}^{N} (\ell(\mathbf{p}^m, \tilde{\mathbf{y}}_m) \end{aligned} \tag{17}$$

在上述形式中，$\ell(\mathbf{p}, \mathbf{y})$ 按式（5）定义，η 始终设为 0.5。

为解决现有 MLR 模型 [15]、[16]、[18] 的过度自信问题，我们以式（16）定义的分类损失替代基于独热标签向量的传统交叉熵损失。除替换分类损失外，网络细节、训练流程等其他所有方面均与原始工作保持一致。

译注：原文在缩写和部分数学记号上存在不一致，本版不擅自改写原式。例如本节前文使用 CSFL，后文及算法使用 CSCL；式（5）按原文未添加负号；式（8）的标签索引为 i, j；式（14）右侧原型下标印为 c；式（17）的括号也保留原貌。所有编号公式均为原文裁切，可直接核对。公式中的 cosine 表示余弦相似度，log 表示对数，exp 表示指数函数，otherwise 表示其他情况。

IV 统一评测基准

本节介绍构建统一多标签置信度校准（MLCC）评测基准所选择的多标签图像识别方法、对比算法和数据集。随后介绍该基准用于公平比较的统一评测协议。

A 所选多标签图像识别方法

大多数校准算法是在不同基线上实现的，或面向不同场景，因而难以进行公平评估。为在多标签图像识别任务中公平评估校准算法，我们选择 SSGRL [15]、ML-GCN [16] 和 C-Tran [18] 三种多标签识别方法作为骨干。下面简要介绍这些方法。

- **SSGRL [15]：**这是一个包含两个关键模块的语义特定图表示学习框架。第一个关键模块为语义解耦模块，通过融入类别语义来指导语义特定表示学习。另一个模块为语义交互模块，以统计标签共现关系构建的图关联这些语义特定表示，并通过图传播机制探索它们之间的交互。
- **ML-GCN [16]：**这是一个基于图卷积网络（GCN）的多标签分类模型，用于捕获和探索图像中通常共同出现的物体之间的标签依赖关系。它在物体标签上构建有向图，并通过可学习的 GCN 将标签图映射为一组相互依赖的物体分类器，再将这些分类器应用于另一子网络提取的图像描述符。此外，该方法还采用新的重加权方案，构造有效的标签相关性矩阵，以指导可学习 GCN 的优化。
- **C-Tran [18]：**C-Tran 是一个通用的多标签图像分类框架，利用 Transformer [38] 探索视觉特征与标签之间的复杂依赖关系。其核心为一个 Transformer 编码器，训练目标是在给定一组被

掩蔽的输入标签和来自 CNN 的视觉特征时，预测一组目标标签。此外，该方法还提出新的标签掩蔽训练目标，使用三元编码方案，将训练期间的标签状态表示为正、负或未知。

我们选择这三种多标签图像识别方法作为骨干，是因为它们分别代表不同主流多标签图像识别方法的特征。SSGRL 是使用类别特定特征的多标签图像识别方法，而 ML-GCN 对整体特征建模以进行分类。C-Tran [18] 则是由 Transformer 这一新型基础模型驱动的多标签图像识别模型。

B 对比算法

为公平评估，我们选择若干经典算法，并在所选骨干上重新实现。下面简要概述各对比算法。

- **NLL**。负对数似然损失（NLL）适用于训练多类别分类问题。由于多标签视觉识别是一类特殊的多类别分类任务，因此我们将其作为基线之一。
- **LS [10]**。标签平滑（LS）能够防止网络过度自信，是模型校准的一项基础技术。此外，本研究也旨在对其进行改进。
- **FL [41]**。焦点损失（FL）最初使训练聚焦于一组稀疏的困难样本，避免大量简单负样本在训练中淹没检测器。后续研究 [3] 发现，它也可用于模型校准。因此，我们将其作为对比基线之一。
- **FLSD [3]**。带样本依赖调度的焦点损失（FLSD）是改进型焦点损失，能够自动选择模型校准的超参数。
- **DCA [11]**。预测置信度与准确率之差（DCA）是一种基于期望校准误差的模型校准方法，将预测置信度与准确率之差加入辅助损失。
- **MMCE [42]**。最大均值校准误差（MMCE）是基于 RKHS 核的校准度量。它能够与负似然损失一起高效训练，无需复杂的超参数调节。MMCE 在完全校准时达到最小值，其有限样本估计具有一致性和较快的收敛速度。
- **MDCA [20]**。多类别置信度与准确率差异（MDCA）是一种新的辅助损失函数，用于帮助模型实现相应的 MDCA。
- **MbLS [21]**。基于间隔的标签平滑（MbLS）[21] 的作者首先从统一的约束优化角度解释现有先进校准损失，然后通过对 logit 距离施加可控间隔，提出基于不等式约束、简单而灵活的推广。
- **DWBL [19]**。动态加权平衡损失（DWBL）是一种基于类别平衡动态加权损失的类别再平衡策略，用来缓解深度学习中的类别分布不平衡问题。它根据类别频率和真实类别的预测概率，为不同类别赋予权重。根据预测分数自动调整权重，使模型能够适应难度不同的实例，从而实现模型校准。

C 数据集

与许多先前多标签识别工作 [15]、[50] 一样，我们采用两个著名的公开数据集 MS-COCO [48] 和 Visual Genome [49] 作为基准数据集，以便公平、一致地比较不同算法。虽然 Pascal VOC 2007 [51] 也广泛用于各种多标签识别工作的基准评测，但我们未将其纳入基准数据集，因为它只有 20 个常见类别，可能不存在过度自信问题。

MS-COCO [48] 最初面向物体检测和分割任务。近年来，由于具有细粒度物体标注，它也被直接用于评估多标签图像识别。该数据集共有 122,218 幅图像，包含 80 个常见类别。这些图像划分为 82,081 幅图像组成的训练集和 40,137 幅图像组成的验证集。需要注意的是，测试集的真实标注目前不可用。因此，本文报告的所有模型均在训练集上训练，并在验证集上评估。

Visual Genome [49] 包含 108,249 幅图像，具有密集的物体、属性和关系标注。这些图像来自 YFCC100M [52] 与 MS-COCO [48] 的交集，涵盖 80,138 个类别。在 Visual Genome 中，每幅图像平均包含 35 个物体。因此，Visual Genome 是衡量多标签识别任务性能及模型校准效果的良好测试平台。由于大多数类别的样本极少，我们只考虑出现最频繁的 500 个类别，随机选择 10,000 幅图像作为测试集，其余 98,249 幅图像作为训练集。

D 评估指标

我们的多标签置信度校准框架同时追求准确性与校准性。为评估准确性，我们遵循以往工作 [31]、[53]，采用所有类别上的平均精度均值（mAP）。对于校准性，我们采用若干广泛使用的指标，包括期望校准误差（ECE）[23]、自适应 ECE（ACE）[54] 和最大校准误差（MCE）[20]。ECE 度量期望准确率与期望置信度之间的差异。ACE 使用自适应方案来度量准确率与置信度之间的差异，该方案调整分箱区间，使每个箱内包含相同数量的预测。MCE 度量平均置信度与准确率之间的最大差异。

V 实验

本节首先介绍实现细节，再报告和分析本文方法及各个基线的实验结果。此外，我们开展消融研究，验证算法中各组成部分的作用。最后，展示 DCLR 在下游应用中的通用性。

A 实现细节

我们采用包含 101 层的卷积神经网络 ResNet-101 [1]，作为 DCLR 提取特征的骨干网络。为获得更好的泛化能力，首先使用预训练权重初始化骨干网络，再用下游任务的数据进行微调。我们使用 Adam [55] 优化器训练 DCLR 模型 20 个轮次。初始学习率、beta1 和 beta2 分别设为 10^{-5} 、0.999 和 0.9。在第 10 个轮次将学习率降低为原来的十分之一。对于 MLR 模型训练，我们遵循 SSGRL [15]、ML-GCN [16] 和 C-Tran [18] 原始工作的训练设置。

B DCLR 与各基线的比较

在这部分，我们在公平评测基准下全面评估重新实现的算法及所提 DCLR 算法的性能，以进行充分、公平的比较。如表 I 所示，所提 DCLR 算法在三个模型 [15]、[16]、[18] 的 ACE、ECE 和 MCE 指标上均优于所有参与比较的领先校准算法。这种优势在 MS-COCO [48] 和 Visual Genome [49] 两个数据集上一致存在。值得注意的是，这些改进并未损害衡量分类性能的重要指标 mAP。

表 I　DCLR 和各基线在三个不同 MLC 模型、两个常用基准上的性能。最佳和次佳结果分别突出显示并加下划线。

Datasets	Method	SSGRL [15]				ML-GCN [16]				C-Tran [18]			
		mAP	ACE	ECE	MCE	mAP	ACE	ECE	MCE	mAP	ACE	ECE	MCE
MS-COCO	NLL	84.0	3.692	4.108	154.069	83.0	4.143	5.072	232.622	83.5	2.414	3.675	154.668
	LS [10]	83.9	2.104	1.741	69.516	83.5	1.436	2.165	55.906	83.8	1.146	1.866	55.621
	FL [41]	84.0	3.049	4.734	81.670	83.0	4.011	5.007	65.005	83.6	2.012	3.023	130.523
	FLSD [3]	84.1	3.546	3.858	133.999	82.9	4.196	4.967	48.713	83.7	1.915	2.775	100.296
	DCA [11]	84.1	3.376	3.636	127.368	82.8	3.931	4.131	120.012	83.7	2.180	3.891	130.962
	MMCE [42]	84.1	1.575	2.951	130.991	82.8	3.523	3.840	121.866	83.7	2.111	2.874	109.911
	MDCA [20]	84.1	3.449	3.834	148.859	82.9	3.880	4.067	125.018	83.7	1.942	3.668	125.107
	MbLS [21]	83.3	2.304	2.188	96.764	83.3	2.923	2.954	67.812	83.9	1.808	2.582	108.604
	DWBL [19]	84.0	3.181	4.345	79.217	81.3	9.726	11.170	115.477	83.6	2.195	2.519	102.985
	Ours	84.0	**1.459**	**1.503**	**59.018**	83.5	**1.037**	**1.427**	**26.411**	83.8	**0.862**	**1.489**	**51.854**

Datasets	Method	SSGRL [15]				ML-GCN [16]				C-Tran [18]			
		mAP	ACE	ECE	MCE	mAP	ACE	ECE	MCE	mAP	ACE	ECE	MCE
Visual Genome	NLL	51.4	5.053	5.199	52.272	48.6	4.804	4.811	200.376	51.6	4.338	4.678	44.497
	LS [10]	51.4	4.400	3.721	35.902	48.7	3.643	3.892	108.051	51.6	2.985	2.673	33.170
	FL [41]	51.4	4.814	4.914	42.745	48.7	3.794	3.907	187.978	51.8	4.012	3.918	39.124
	FLSD [3]	51.5	4.541	4.874	40.798	48.7	3.587	3.876	189.701	51.8	2.981	3.513	40.325
	DCA [11]	51.6	4.565	4.820	51.406	48.7	4.518	4.866	178.643	51.6	3.824	4.198	39.908
	MMCE [42]	51.5	4.560	4.851	46.015	48.6	4.015	4.598	158.092	51.7	4.032	4.070	44.307
	MDCA [20]	51.4	4.786	5.054	52.529	48.6	4.076	4.879	150.159	51.7	4.205	4.273	45.286
	MbLS [21]	51.6	4.741	3.907	45.676	48.7	3.987	4.675	149.802	51.7	2.964	4.329	57.031
	DWBL [19]	51.5	4.494	3.974	37.851	48.6	4.498	4.523	149.800	51.6	3.415	3.298	36.267
	Ours	51.4	**3.548**	**2.887**	**33.248**	48.8	**3.580**	**3.752**	**72.487**	51.6	**2.608**	**2.480**	**28.286**

表头中文：Datasets 为数据集，Method 为方法；mAP 为平均精度均值，ACE 为自适应校准误差，ECE 为期望校准误差，MCE 为最大校准误差；Ours 为本文方法。为方便阅读，原表按数据集拆为两部分，并重复原始表头；所有模型、方法、数值和原始强调样式均予保留。

结果见表 I。对 MS-COCO 数据集的详细分析表明，在大多数场景中，现有置信度校准算法均能显著改善 ACE、ECE 和 MCE 指标。我们新提出的 DCLR 算法在所有这些指标上都优于现有方案，表现出显著改进。具体而言，SSGRL 模型的 ACE、ECE、MCE 分别为 1.459、1.503、59.018；ML-GCN 分别为 1.037、1.427、26.411；C-Tran 分别为 0.862、1.489、51.854。相较于表现次佳的 LS 算法，SSGRL 的 ACE、ECE、MCE 分别相对降低 30.7%、13.7%、15.1%；ML-GCN 分别降低 27.8%、34.1%、52.8%；C-Tran 分别降低 24.8%、20.2%、6.8%。这些结果有力地表明 DCLR 算法具有更优性能。

Visual Genome 数据集上也出现了类似现象。加入 DCLR 算法后，ACE、ECE 和 MCE 显著降低。对于 SSGRL，指标由 4.400、3.721、35.902 改善为 3.548、2.887、33.248。对于 ML-GCN，指标由 3.643、3.892、108.051 变为 3.580、3.752、72.487。此外，C-Tran 的指标由 2.964、2.673、33.170 降为 2.608、2.480、28.286。这些结果进一步证实 DCLR 算法能够有效提升校准性能。

为进行更全面的评估，我们还提供可靠性图，以图形方式呈现统计预测置信度与实际准确率之间的差异。曲线越接近对角线，校准性能越好。图 3 展示了 SSGRL、ML-GCN 和 C-Tran 模型在不校准、采用现有校准算法和采用所提 DCLR 校准算法时的可靠性图。未经校准的模型明显偏离对角线并位于其下方，表明存在严重的过度自信问题。现有校准方法能够适度改善模型与对角线的对齐程度。相比之下，经 DCLR 算法校准的模型几乎与对角线完美对齐，表明其校准状态接近理想情况。

图 3　MS-COCO 数据集上，SSGRL、ML-GCN 和 C-Tran 模型不使用校准、使用现有对比算法以及使用所提 DCLR 算法时的可靠性图。结果按模型依次排列：第一行为 SSGRL，第二行为 ML-GCN，最后一行为 C-Tran。

原图依照上述行顺序拆分放大；每个模型的前五列依次为 NLL、LS、FL、FLSD、DCA，后五列为 MMCE、MDCA、MbLS、DWBL、Ours。各图横轴 Confidence 为置信度，纵轴 Accuracy 为准确率。

图 3 第一行　SSGRL，前五列与后五列

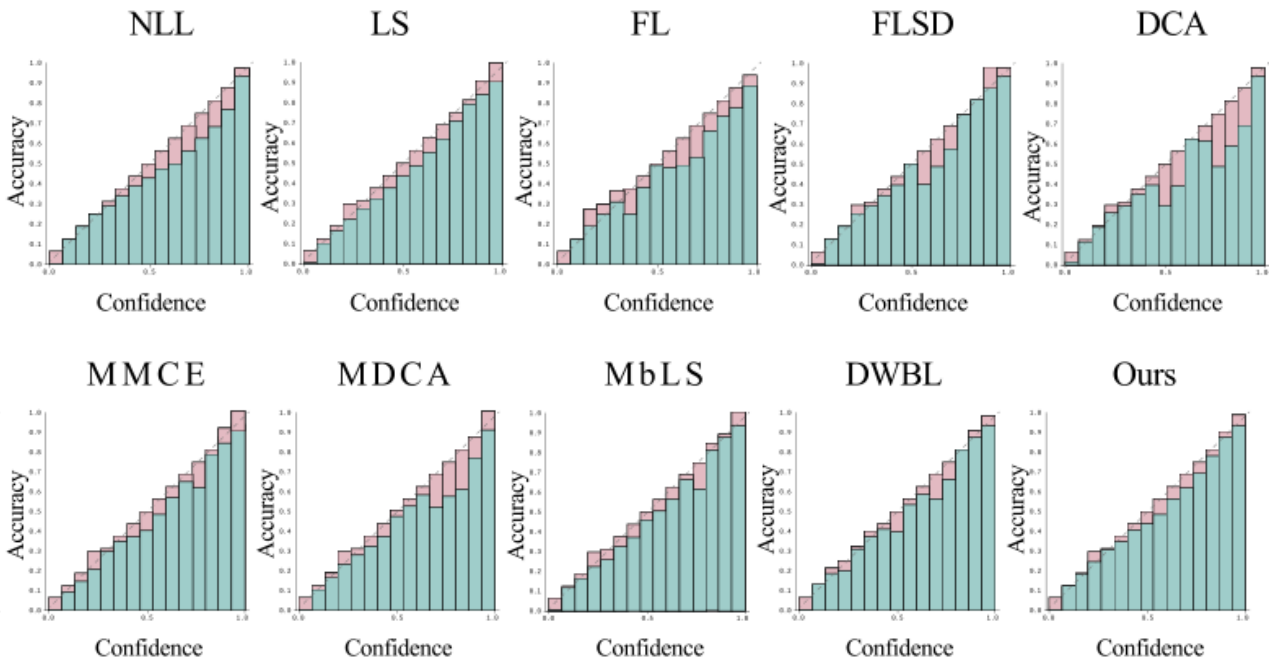


图 3 第二行　ML-GCN，前五列与后五列

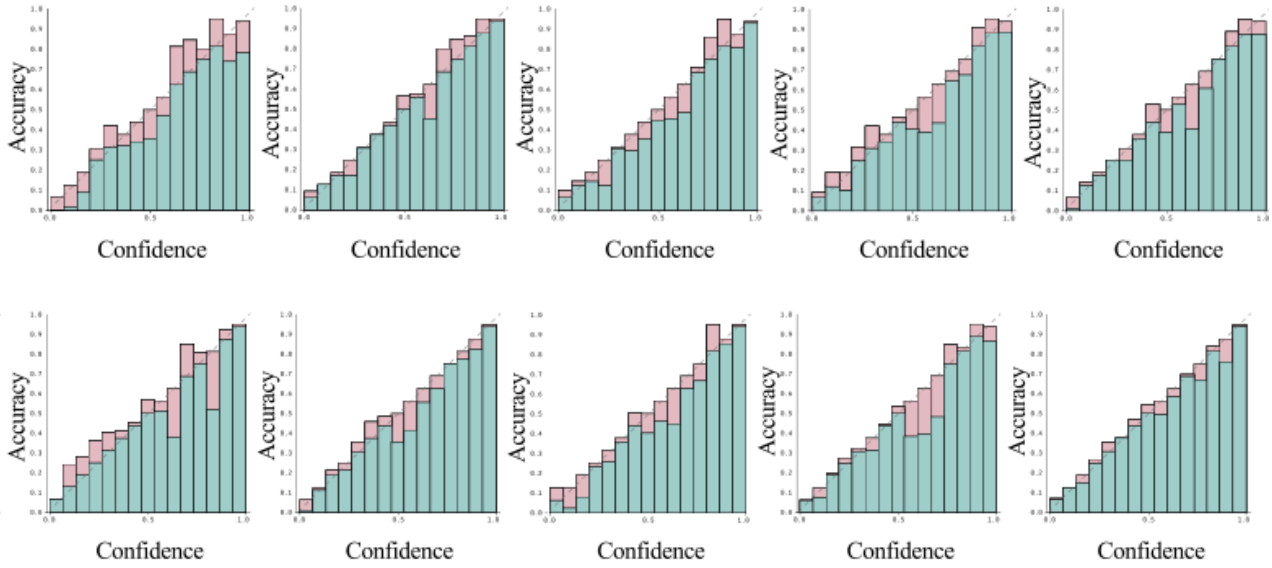
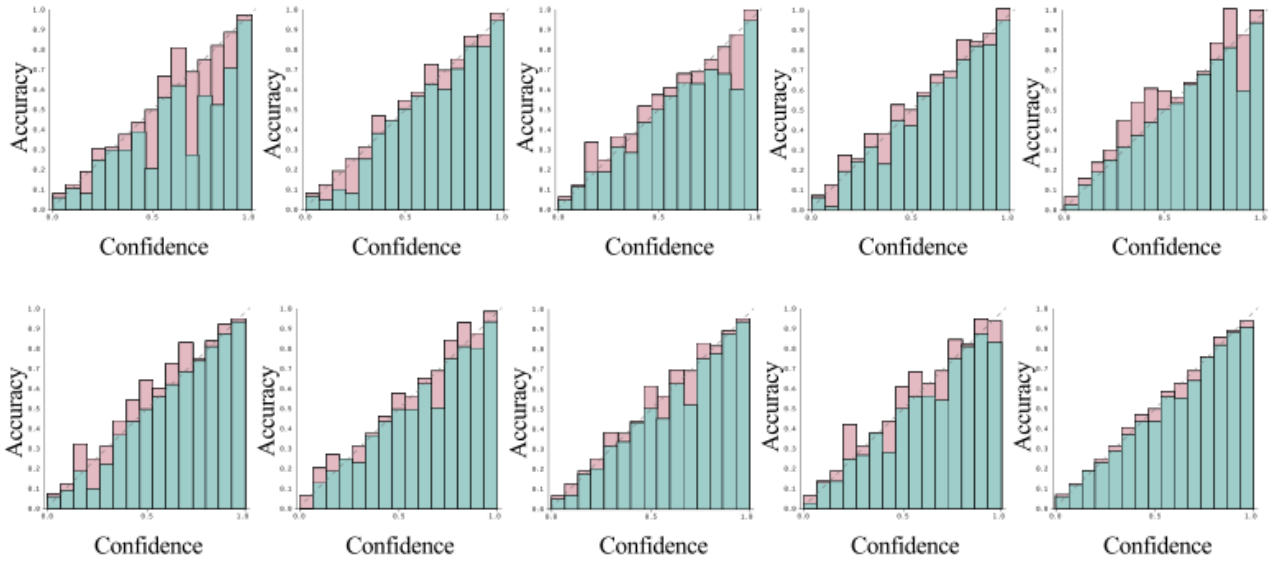


图 3 第三行　C-Tran，前五列与后五列



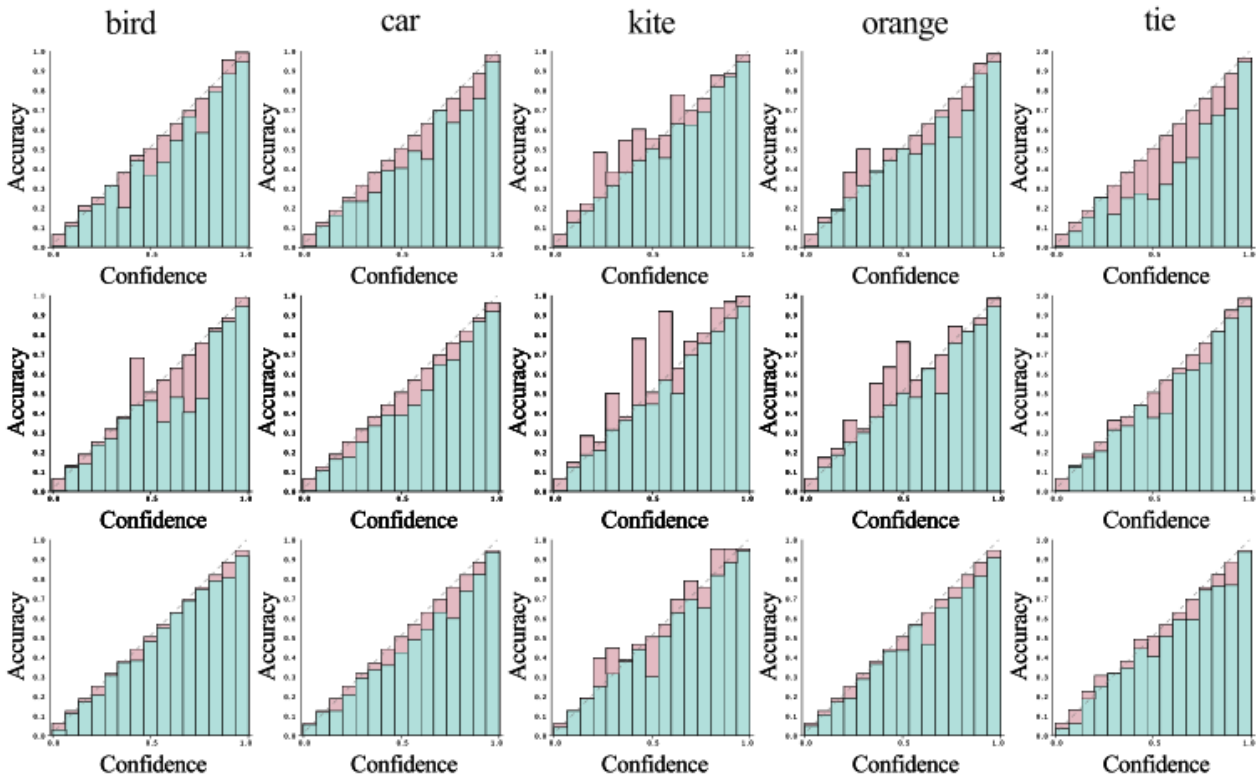
置信度校准算法不应牺牲分类性能，而分类性能是多标签识别（MLR）任务的重要方面。因此，我们进一步报告了 MLR 评估中最常用的 mAP 指标。如表 I 所示，在不同模型和数据集上，所提 DCLR 和大多数现有算法均获得了与未校准模型相当、具有竞争力的 mAP 分数。值得注意的是，传统 LS 优于大多数现有算法。这种性能差异可能是因为大多数现有算法主要为单标签场景设计，在对应的多标签场景中表现较差。相比之下，简单直接的标签平滑正则化具有更强的跨场景适应性，因此性能更好。

C 消融研究

为深入分析 DCLR 算法以及各关键模块的实际贡献，我们进一步开展大量消融实验。这里的所有实验均在 MS-COCO 数据集上，以 SSGRL 为基线进行。

1）DCLR 分析。本研究的关键技术贡献是 DCLR 算法，它融入类别相关性以有效解决语义歧义，进而增强正则化。我们通过与未经校准的模型（NLL）以及使用 LS 算法校准的模型进行比较，展示其有效性。如表 I 所示，相较于 NLL 模型和经 LS 校准的模型，DCLR 算法均显著提升性能。图 3 的可靠性图也反映了这一改进。为进行更充分的比较，我们还在图 4 中给出类别特定的可靠性图，从 MS-COCO 中选择五个类别进行简洁展示。DCLR 算法显著缩小统计预测置信度与实际准确率之间的差距，说明其分数校准得更加准确。

图 4　不采用校准算法、采用 LS 和所提 DCLR 算法时各类别的可靠性图。各算法结果依次排列：第一行为未校准结果，第二行为 LS 结果，最后一行为 DCLR 结果。评估在 MS-COCO 数据集上使用 SSGRL 模型进行。



图中五列分别为鸟（bird）、汽车（car）、风筝（kite）、橙子（orange）、领带（tie）；横轴为置信度，纵轴为准确率。

这些评估从整体上证明了所提 DCLR 算法的有效性。实际上，该算法同时包含实例级与原型级相关性感知正则化。下面我们进一步深入分析这两个模块。

2）CSCL、ILCAR 和 PLCAR 的作用。为研究类别特定对比学习（CSCL）、实例级相关性感知正则化（ILCAR）与原型级相关性感知正则化（PLCAR）的作用，我们在 MS-COCO 数据集上使用 SSGRL 模型，通过启用或禁用这些组件开展消融研究。实验结果见表 II。可以观察到，三个不同组件都能帮助模型获得更好的校准效果。具体而言，比较 Ours DCLR 与 Ours DCLR w/o $\mathcal{L}_c$，可见 CSCL 分别使 ACE、ECE 和 MCE 降低 0.439、0.144 和 9.57。同样，比较 Ours DCLR 与 Ours DCLR w/o $\mathcal{L}^{pro}$，可见 PLCRA 分别使 ACE、ECE 和 MCE 降低 0.33、0.117 和 5.01；比较 Ours DCLR 与 Ours DCLR w/o $\mathcal{L}^{ins}$，可见 ILCRA 分别使 ACE、ECE 和 MCE 降低 0.342、0.09 和 8.275。这些结果说明三个组件均能有效改善模型置信度。此外，当三个组件同时使用时，模型获得最佳校准性能，表明 DCLR 的有效性。

表 II　CSCL、ILCAR 和 PLCAR 对 SSGRL 模型的影响。

	mAP	ACE	ECE	MCE
Ours DCLR w/o $\mathcal{L}_c$	84.1	1.897	1.647	68.588
Ours DCLR w/o $\mathcal{L}^{ins}$	84.0	1.801	1.593	67.293
Ours DCLR w/o $\mathcal{L}^{pro}$	83.9	1.789	1.620	64.028
Ours DCLR	84.0	1.459	1.503	59.018

表中 w/o 表示不使用相应损失，Ours DCLR 表示本文完整 DCLR。原文混用 ILCAR/ILCRA 及 PLCAR/PLCRA 缩写，本译文保留其对应关系；本段的 0.439 按原文保留，表中 1.897 与 1.459 的算术差为 0.438。

3）超参数 α 分析。超参数 α 用于输出分布正则化。为衡量其对性能的影响并设定合适的值，我们在 MS-COCO 上使用 SSGRL 骨干开展消融研究，将其分别设为 0.02、0.03、0.05、0.1。实验结果见表 III。结果表明，不同 α 设置在各项指标上都能获得有竞争力的性能，而 $\alpha = 0.05$ 时取得最佳且达到先进水平的性能。因此，所有实验均选择 0.05 作为超参数 α 的默认值。

表 III　在 SSGRL 骨干上，DCLR 方法采用不同 α 设置时的 mAP、ACE、ECE 和 MCE。

	mAP	ACE	ECE	MCE
0.02	84.1	1.697	1.863	85.927
0.03	84.1	1.602	1.795	80.687
0.05	84.0	1.459	1.503	59.018
0.1	83.9	1.923	2.072	89.258

4）ILCRA 分析。ILCAR 用于学习实例级相关性，帮助构建能够建模语义混淆的软标签向量。为评估其有效性，我们仅使用 ILCAR（记为 Ours ILCRA）开展实验，并与标签平滑（LS）基线比较。表 IV 的实验结果表明，即使仅使用 ILCRA，也能提升校准性能。与 LS 基线相比，ILCRA 分别使 ACE、ECE 和 MCE 降低 0.315、0.121 和 5.488。

表 IV　LS 基线、Ours ILCRA w/o Lc 与 Ours ILCRA 的 mAP、ACE、ECE 和 MCE。

	mAP	ACE	ECE	MCE
LS	83.9	2.104	1.741	69.516
Ours ILCAR w/o $\mathcal{L}_{acl}$	83.9	2.124	1.748	70.846
Ours ILCAR w/o $\mathcal{L}_c$	83.9	1.831	1.658	66.291
Ours ILCAR	83.9	1.789	1.620	64.028

表内还列出不使用辅助分类损失 $\mathcal{L}_{acl}$ 的变体；标题按原文完整翻译，表内原始行与数值均保留。

辅助分类损失和对比损失有助于更好地学习类别信息及类别间相关性，从而构建更有效的正则化。这里，我们将 Ours ILCRA 与分别去掉这两项损失的两个修改基线（记为 Ours ILCRA w/o $\mathcal{L}_{acl}$ 和 Ours ILCRA w/o $\mathcal{L}_c$）比较，以验证它们的贡献。如表 IV 所示，去掉任一损失都会使 ACE、ECE 和 MCE 明显下降。我们观察到，移除辅助分类损失后的性能甚至劣于 LS 基线。这可能是因为模型无法保证学

到的特征包含对应类别的特定信息，从而妨碍其准确学习相关性、构建合理伪标签的能力。相反，即使不使用对比损失，我们的模型仍优于 LS 基线，ACE 和 ECE 分别降低 0.273 和 0.083。这一发现表明，类别特定特征中本身存在捕获语义类别相关性的相似性，无需重新训练也可改善校准结果。

译注：上一段“ACE、ECE 和 MCE 明显下降”是原文的表述；表 IV 显示移除损失后这些误差数值增大、校准性能下降。本译文保留原文文字并提示这一不一致，不据此改动表中数据。

5）PLCRA 分析。PLCRA 旨在学习更加稳健的原型级相关性，以构建软标签向量。这里，我们同样仅使用 PLCRA（记为 Ours PLCRA），并与 LS 基线比较，以评估其贡献。如表 V 所示，该方法也获得更好的校准性能，ACE、ECE 和 MCE 分别降低 0.303、0.148 和 2.223。

表 V　LS 基线、Ours PLCRA w/o Lc 与 Ours PLCRA 的 mAP、ACE、ECE 和 MCE。

	mAP	ACE	ECE	MCE
LS	83.9	2.104	1.741	69.516
Ours PLCRA w/o $\mathcal{L}_{acl}$	84.0	2.146	1.790	70.571
Ours PLCRA w/o $\mathcal{L}_{c}$	84.0	1.895	1.697	69.081
Ours PLCRA	84.0	1.801	1.593	67.293

表内还保留不使用辅助分类损失 $\mathcal{L}_{acl}$ 的变体。

对比损失有助于学习更加紧凑的表示，从而获得更加稳健的原型与实例相似度。在这部分，我们设计了不使用对比损失的新基线（记为 Ours PLCRA w/o $\mathcal{L}_{c}$），并将其与 Ours PLCRA 比较。如表 V 所示，去掉对比损失会使三项指标上的性能显著下降。值得注意的是，与 LS 基线相比，Ours PLCRA w/o $\mathcal{L}_{c}$ 仍能获得总体更好的校准性能，再次证明无需重新训练就已存在内在类别相关性。同样，移除辅助分类损失（即 Ours PLCRA w/o $\mathcal{L}_{acl}$）会使性能同时劣于我们的 PLCRA 和 LS 基线。

原型级特征的数量 K 也是影响性能的关键因素。为研究其贡献，我们在 SSGRL 上使用 DCLR，以不同 K 值开展实验，分别将 K 设为 5、10、20。结果见表 VI。可以看到，虽然不同 K 的所有模型都能取得有竞争力的结果，但合适的 K 对置信度校准依然重要，因为不同图像具有不同的视觉变化，合适的 K 能够在表示这些变化时实现更好的权衡。根据实验结果，我们选择 10 作为 K 的默认值。

表 VI　在 SSGRL 骨干上，DCLR 方法采用不同数量 K 的原型级特征时的 mAP、ACE、ECE 和 MCE。

K	mAP	ACE	ECE	MCE
5	83.9	1.582	1.736	70.689
10	84.0	1.459	1.503	59.018
20	83.8	1.768	2.052	92.741

D 定性比较

为展示 DCLR 如何校准预测置信度，我们在图 5 中给出若干来自 MS-COCO 数据集的可视化示例，展示不同 MLR 模型和不同校准方法的类别预测置信度。

图 5　来自 MS-COCO 数据集的可视化示例。这些示例说明 DCLR 如何校准置信度以获得更好的预测。

图 5（a）预测分数　人、瓶子、椅子、冰箱

	person	bottle	chair	refrigerator
SSGRL	99.95%	67.30%	87.20%	87.90%
SSGRL+LS	95.89%	90.01%	30.20%	71.29%
SSGRL+Ours	97.59%	95.81%	22.13%	30.72%
MLGCN	99.87%	26.11%	86.09%	79.98%
MLGCN+LS	89.09%	50.30%	33.50%	70.01%
MLGCN+Ours	98.76%	89.28%	30.58%	7.78%
CTran	99.98%	74.12%	90.12%	92.16%
CTran+LS	96.49%	80.01%	90.01%	78.59%
CTran+Ours	97.45%	94.09%	26.45%	22.45%

图 5（b）预测分数　风筝、人、冲浪板、船

	kite	person	surfboard	boat
SSGRL	99.97%	94.91%	69.98%	90.57%
SSGRL+LS	97.54%	82.58%	42.31%	92.38%
SSGRL+Ours	98.58%	30.56%	12.31%	30.39%
MLGCN	12.32%	55.44%	70.13%	68.45%
MLGCN+LS	50.47%	60.49%	36.70%	60.74%
MLGCN+Ours	94.26%	20.48%	15.47%	20.80%
CTran	99.99%	99.66%	33.39%	91.25%
CTran+LS	97.39%	53.91%	20.45%	70.27%
CTran+Ours	98.87%	20.59%	10.21%	9.80%

图 5（c）预测分数　三明治、杯子、瓶子、碗

	sandwich	cup	bottle	bowl
SSGRL	99.41%	82.13%	50.60%	95.17%
SSGRL+LS	95.45%	90.87%	36.69%	70.96%
SSGRL+Ours	96.74%	99.89%	20.54%	40.87%
MLGCN	8.44%	37.14%	89.78%	97.65%
MLGCN+LS	94.69%	90.59%	80.58%	91.45%
MLGCN+Ours	98.64%	99.06%	13.51%	41.33%
CTran	97.95%	39.30%	75.52%	96.44%
CTran+LS	91.59%	95.16%	60.26%	20.69%
CTran+Ours	98.38%	97.08%	8.25%	19.75%

图 5（d）预测分数　沙发、花瓶、电视、瓶子

	couch	vase	tv	bottle
SSGRL	99.24%	34.44%	75.85%	62.59%
SSGRL+LS	95.49%	47.09%	67.72%	40.21%
SSGRL+Ours	97.37%	80.68%	20.49%	35.33%
MLGCN	98.28%	10.45%	70.28%	82.36%
MLGCN+LS	89.59%	52.64%	20.56%	29.57%
MLGCN+Ours	96.52%	92.48%	6.72%	4.29%
CTran	99.85%	48.28%	97.53%	62.00%
CTran+LS	96.22%	59.97%	51.73%	10.59%
CTran+Ours	97.55%	89.92%	40.48%	6.97%

译注：以上四个面板完整保留作者的类别与分数表，不复制各面板左侧示例照片。照片与完整布局见原文第 11 页图 5；照片单独权利未获核实。

从可视化示例（a）、（b）、（c）、（d）可以得出，DCLR 的置信度分数预测优于原始 MLR 模型及使用标签平滑（LS）增强的版本，因为 DCLR 能为正确类别预测相当高的置信度，为错误类别预测较低的置信度，从而表现出更清晰的判别边界。例如，在示例（a）中，SSGRL、MLGCN 和 CTran 由于预测置信度较低，未能预测出“瓶子”。经标签平滑（LS）校准后，只有 SSGRL 能正确预测“瓶子”，而 MLGCN 和 CTran 对“瓶子”的预测置信度仍然较低。得益于所提出的 DCLR，SSGRL、MLGCN 和 CTran 三个模型都能正确预测“瓶子”，并且其置信度高于错误类别。在其他示例中也可以得到类似观察和结果。这些结果进一步说明，DCLR 能够更好地校准预测置信度，因此对多标签置信度校准有效。

VI 结论

总之，本研究解决了多标签场景中普遍存在的过度自信问题，而现有单标签校准算法在很大程度上忽略了这一挑战。我们提出新的动态相关性学习与正则化（DCLR）算法，利用多粒度语义相关性，对多标签图像特有的语义混淆建模，从而获得经过良好校准的置信度分数。DCLR 利用动态实例级和原型级相似度，构造自适应标签向量，实现更有效的正则化。此外，我们建立了全面的基准，填补此前 MLCC 评测中的空白。该基准重新实现并调整了若干先进置信度校准算法，使其适用于 MLCC 任务；还将这些算法及所提 DCLR 集成到三个有代表性的 MLR 模型中，在两个广泛使用的数据集上进行性能比较。

未来，MLCC 有两个尤为重要且有意义的研究方向。第一，我们目前仅考虑类别间的两两相关性，这是一种局部相关性。如果考虑全部类别，并从整体角度引入相关性，以更好地学习相关信息、获得更优正则化，将具有重要价值。第二，许多场景的标签是有限的，例如部分标签多标签识别和少样本多标签识别。MLCC 可以提供更可靠的标签，帮助有效检索标签，从而显著提升这些实际任务的性能。

参考文献

以下保留原文编号、作者、刊物与出版信息，论文题名译为中文。会议及期刊专名保留原文以便检索；出版年份、卷期、页码均依所提供版本，不擅自校订。

[1] K. He，X. Zhang，S. Ren，J. Sun. 《用于图像识别的深度残差学习》. 载于 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition，2016，页 770-778。

[2] A. Dosovitskiy，L. Beyer，A. Kolesnikov，D. Weissenborn，X. Zhai，T. Unterthiner，M. Dehghani，M. Minderer，G. Heigold，S. Gelly 等. 《一幅图像相当于 16×16 个词：用于大规模图像识别的 Transformer》. 载于 International Conference on Learning Representations，2020。

[3] J. Mukhoti，V. Kulharia，A. Sanyal，S. Golodetz，P. Torr，P. Dokania. 《利用焦点损失校准深度神经网络》. Advances in Neural Information Processing Systems，卷 33，页 15288-15299，2020。

[4] C. Guo，G. Pleiss，Y. Sun，K. Q. Weinberger. 《论现代神经网络的校准》. 载于 International Conference on Machine Learning. PMLR，2017，页 1321-1330。

[5] Z. Lu，S. He，D. Li，Y.-Z. Song，T. Xiang. 《广义少样本语义分割的预测校准》. IEEE Transactions on Image Processing，2023。

[6] S. Grigorescu，B. Trasnea，T. Cocias，G. Macesanu. 《自动驾驶深度学习技术综述》. Journal of Field Robotics，卷 37，期 3，页 362-386，2020。

[7] J. Janai，F. Güney，A. Behl，A. Geiger 等. 《自动驾驶车辆的计算机视觉：问题、数据集与研究现状》. Foundations and Trends® in Computer Graphics and Vision，卷 12，期 1-3，页 1-308，2020。

[8] X. Jiang，M. Osl，J. Kim，L. Ohno-Machado. 《校准预测模型估计以支持个性化医疗》. Journal of the American Medical Informatics Association，卷 19，期 2，页 263-274，2012。

[9] R. Caruana，Y. Lou，J. Gehrke，P. Koch，M. Sturm，N. Elhadad. 《医疗保健中的可理解模型：预测肺炎风险和出院后 30 天内再入院》. 载于 Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining，2015，页 1721-1730。

[10] R. Müller，S. Kornblith，G. E. Hinton. 《标签平滑何时有帮助？》. Advances in Neural Information Processing Systems，卷 32，2019。

[11] G. Liang，Y. Zhang，X. Wang，N. Jacobs. 《面向医学影像分类神经网络的改进可训练校准方法》. arXiv 预印本 arXiv:2009.04057，2020。

[12] Y. Wei，W. Xia，M. Lin，J. Huang，B. Ni，J. Dong，Y. Zhao，S. Yan. 《HCP：用于多标签图像分类的灵活 CNN 框架》. IEEE Transactions on Pattern Analysis and Machine Intelligence，卷 38，期 9，页 1901-1907，2016。

[13] Z.-M. Chen，Q. Cui，B. Zhao，R. Song，X. Zhang，O. Yoshie. 《SST：用于多标签图像识别的空间和语义 Transformer》. IEEE Transactions on Image Processing，卷 31，页 2570-2583，2022。

[14] J. Zhang，J. Ren，Q. Zhang，J. Liu，X. Jiang. 《用于多标签图像分类的空间上下文感知物体注意力网络》. IEEE Transactions on Image Processing，2023。

[15] T. Chen，M. Xu，X. Hui，H. Wu，L. Lin. 《面向多标签图像识别的语义特定图表示学习》. 载于 Proceedings of the IEEE/CVF International Conference on Computer Vision，2019，页 522-531。

[16] Z.-M. Chen，X.-S. Wei，P. Wang，Y. Guo. 《利用图卷积网络进行多标签图像识别》. 载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，2019，页 5177-5186。

[17] J. Ye，J. He，X. Peng，W. Wu，Y. Qiao. 《用于多标签图像识别的注意力驱动动态图卷积网络》. 载于 Computer Vision-ECCV 2020：第 16 届欧洲会议，英国格拉斯哥，2020 年 8 月 23-28 日，论文集第 XXI 部分 16. Springer，2020，页 649-665。

[18] J. Lanchantin，T. Wang，V. Ordonez，Y. Qi. 《使用 Transformer 的通用多标签图像分类》. 载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，2021，页 16478-16488。

[19] K. R. M. Fernando，C. P. Tsokos. 《动态加权平衡损失：深度神经网络的类别不平衡学习与置信度校准》. IEEE Transactions on Neural Networks and Learning Systems，卷 33，期 7，页 2940-2951，2021。

[20] R. Hebbalaguppe，J. Prakash，N. Madan，C. Arora. 《及时一针省九针：用于改善神经网络校准的训练时正则化损失》. 载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，2022，页 16081-16090。

[21] B. Liu，I. Ben Ayed，A. Galdran，J. Dolz. 《关键在间隔：用于网络校准的基于间隔的标签平滑》. 载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，2022，页 80-88。

[22] K. Nguyen，B. O'Connor. 《自然语言处理模型的后验校准与探索性分析》. arXiv 预印本 arXiv:1508.05154，2015。

[23] M. P. Naeini，G. Cooper，M. Hauskrecht. 《使用贝叶斯分箱获得良好校准的概率》. 载于 Proceedings of the AAAI Conference on Artificial Intelligence，卷 29，期 1，2015。

[24] M. H. DeGroot，S. E. Fienberg. 《预测者的比较与评价》. Journal of the Royal Statistical Society: Series D (The Statistician)，卷 32，期 1-2，页 12-22，1983。

[25] T. Chen，T. Pu，L. Liu，Y. Shi，Z. Yang，L. Lin. 《用于部分标签多标签识别的异构语义迁移》. International Journal of Computer Vision，2024。

[26] L. Nie，T. Chen，Z. Wang，W. Kang，L. Lin. 《使用注意力 Transformer 定位器模块的多标签图像识别》. Multimedia Tools and Applications，卷 81，期 6，页 7917-7940，2022。

[27] T. Chen，L. Lin，R. Chen，X. Hui，H. Wu. 《面向通用图像识别的知识引导多标签少样本学习》. IEEE Transactions on Pattern Analysis and Machine Intelligence，卷 44，期 3，页 1371-1384，2022。

[28] Z. Peng，Y. Luo，T. Chen，K. Xu，S. Huang. 《用于序列置信度校准的感知与语义感知正则化》. 载于 Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition，2023，页 10658-10668。

[29] T. Pu，T. Chen，H. Wu，Y. Shi，Z. Yang，L. Lin. 《用于部分标签多标签图像识别的双视角语义感知表示混合》. Expert Systems with Applications，卷 249，文章号 123526，2024。

[30] Z.-M. Chen，Q. Cui，X.-S. Wei，X. Jin，Y. Guo. 《面向多标签图像识别的标签线索解耦、嵌入与排序》. IEEE Transactions on Multimedia，卷 23，页 1827-1840，2020。

[31] H. Yang，J. Tianyi Zhou，Y. Zhang，B.-B. Gao，J. Wu，J. Cai. 《利用边界框标注进行多标签物体识别》. 载于 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition，2016，页 280-288。

[32] J. Ba，V. Mnih，K. Kavukcuoglu. 《使用视觉注意力进行多物体识别》. arXiv 预印本 arXiv:1412.7755，2014。

[33] T. Chen，Z. Wang，G. Li，L. Lin. 《用于多标签图像识别的循环注意力强化学习》. 载于 Proceedings of AAAI Conference on Artificial Intelligence，2018，页 6730-6737。

[34] Z. Wang，T. Chen，G. Li，R. Xu，L. Lin. 《通过循环发现注意力区域进行多标签图像识别》. 载于 Proceedings of IEEE International Conference on Computer Vision（ICCV），2017，页 464-472。

[35] J. Wang，Y. Yang，J. Mao，Z. Huang，C. Huang，W. Xu. 《CNN-RNN：多标签图像分类的统一框架》. 载于 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition，2016，页 2285-2294。

[36] Y. Li，D. Tarlow，M. Brockschmidt，R. S. Zemel. 《门控图序列神经网络》. 载于 International Conference on Learning Representations，2016。

[37] T. Chen，T. Pu，H. Wu，Y. Xie，L. Liu，L. Lin. 《跨域面部表情识别：统一评测基准与对抗图学习》. IEEE Transactions on Pattern Analysis and Machine Intelligence，卷 44，期 12，页 9887-9903，2021。

[38] A. Vaswani，N. Shazeer，N. Parmar，J. Uszkoreit，L. Jones，A. N. Gomez，Ł. Kaiser，I. Polosukhin. 《注意力就是你所需要的一切》. Advances in Neural Information Processing Systems，卷 30，2017。

[39] Z. Zhao，Y. Qiang，F. Yang，X. Hou，J. Zhao，K. Song. 《基于双流视觉 Transformer 的中医处方构建多标签识别》. Computers in Biology and Medicine，卷 170，文章号 107920，2024。

[40] H. D. Nguyen，X.-S. Vu，D.-T. Le. 《用于多标签图像分类的模块化图 Transformer 网络》. 载于 Proceedings of the AAAI Conference on Artificial Intelligence，卷 35，期 10，2021，页 9092-9100。

[41] T.-Y. Lin，P. Goyal，R. Girshick，K. He，P. Dollár．《用于密集物体检测的焦点损失》．载于 Proceedings of the IEEE International Conference on Computer Vision，2017，页 2980-2988。

[42] A. Kumar，S. Sarawagi，U. Jain．《基于核均值嵌入的神经网络可训练校准度量》．载于 International Conference on Machine Learning．PMLR，2018，页 2805-2814。

[43] Q. Shi，M. Ye，W. Huang，W. Ruan，B. Du．《视觉意图理解中的标签感知校准与关系保持》．IEEE Transactions on Image Processing，2024。

[44] Y. An，H. Xue，X. Zhao，N. Xu，P. Fang，X. Geng．《利用双向相关性进行多标签少样本学习》．IEEE Transactions on Neural Networks and Learning Systems，2024。

[45] G. Pereyra，G. Tucker，J. Chorowski，L. Kaiser，G. Hinton．《通过惩罚高置信度输出分布来正则化神经网络》．2017。

[46] T. Chen，T. Pu，H. Wu，Y. Xie，L. Lin．《用于部分标签多标签识别的结构化语义迁移》．载于 Proceedings of the AAAI Conference on Artificial Intelligence，卷 36，期 1，2022，页 339-346。

[47] J. A. Hartigan，M. A. Wong．《算法 AS 136：一种 K 均值聚类算法》．Journal of the Royal Statistical Society, Series C (Applied Statistics)，卷 28，期 1，页 100-108，1979。

[48] T.-Y. Lin，M. Maire，S. Belongie，J. Hays，P. Perona，D. Ramanan，P. Dollár，C. L. Zitnick．《Microsoft COCO：上下文中的常见物体》．载于 Computer Vision-ECCV 2014：第 13 届欧洲会议，瑞士苏黎世，2014 年 9 月 6-12 日，论文集第 V 部分 13．Springer，2014，页 740-755。

[49] R. Krishna，Y. Zhu，O. Groth，J. Johnson，K. Hata，J. Kravitz，S. Chen，Y. Kalantidis，L.-J. Li，D. A. Shamma 等．《Visual Genome：利用众包密集图像标注连接语言与视觉》．International Journal of Computer Vision，卷 123，页 32-73，2017。

[50] F. Zhu，H. Li，W. Ouyang，N. Yu，X. Wang．《利用图像级监督学习空间正则化以进行多标签图像分类》．载于 Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition，2017，页 5513-5522。

[51] M. Everingham，L. Van Gool，C. K. Williams，J. Winn，A. Zisserman．《Pascal 视觉物体类别（VOC）挑战》．International Journal of Computer Vision，卷 88，期 2，页 303-338，2010。

[52] B. Thomee，D. A. Shamma，G. Friedland，B. Elizalde，K. Ni，D. Poland，D. Borth，L.-J. Li．《YFCC100M：多媒体研究中的新数据》．Communications of the ACM，卷 59，期 2，页 64-73，2016。

[53] Y. Wei，W. Xia，M. Lin，J. Huang，B. Ni，J. Dong，Y. Zhao，S. Yan．《HCP：用于多标签图像分类的灵活 CNN 框架》．IEEE Transactions on Pattern Analysis and Machine Intelligence，卷 38，期 9，页 1901-1907，2015。

[54] J. Nixon，M. W. Dusenberry，L. Zhang，G. Jerfel，D. Tran. 《衡量深度学习中的校准》. 载于 CVPR Workshops，卷 2，期 7，2019。

[55] D. P. Kingma，J. Ba. 《Adam：一种随机优化方法》. arXiv 预印本 arXiv:1412.6980，2014。

作者简介

以下为原文第 13 页作者简介的完整中文翻译，履历和“目前”等时间表述均对应原文 2024 年版本，并非对现职的更新。原页 7 张作者肖像的单独权利未获核实，本版省略肖像；原始版面参见原文第 13 页。

Tianshui Chen

Tianshui Chen 于 2018 年在中国广州中山大学数据科学与计算机学院获得计算机科学博士学位。在获得博士学位之前，他于 2013 年在信息科学与技术学院获得工学学士学位。目前，他是广东工业大学副教授。他当前的研究兴趣包括计算机视觉和机器学习。他独立或合作撰写了 40 余篇发表于顶级学术期刊和会议的论文，包括 T-PAMI、T-NNLS、T-IP、T-MM、CVPR、ICCV、AAAI、IJCAI、ACM MM 等。他担任过众多学术期刊和会议的审稿人，并获得 2017 年 IEEE ICME 最佳论文钻石奖。

Weihang Wang

Weihang Wang 是广东工业大学计算机科学专业本科生。他将于 2024 年赴复旦大学攻读计算机科学博士学位。他的研究兴趣是机器学习，尤其是计算机视觉和大语言模型。

Tao Pu

Tao Pu 于 2020 年在中国广州中山大学计算机科学与工程学院获得工学学士学位，目前正在该校攻读计算机科学博士学位。他独立或合作撰写了约 10 篇发表于顶级学术期刊和会议的论文，包括 T-PAMI、AAAI、ACM MM 等。

Jinghui Qin

Jinghui Qin 是中国广州广东工业大学讲师。他分别于 2012 年和 2014 年在中国广州中山大学软件学院获得理学学士和工程硕士学位，并于 2020 年在中国广州中山大学数据科学与计算机学院获得博士学位。2020 年至 2022 年间，他在中国广州中山大学从事博士后研究。他担任 IEEE Transactions on Neural Networks and Learning Systems、IEEE Transactions on Broadcasting、Neurocomputing、Computer Vision and Image Understanding、Bioinformatics 等期刊的审稿人。他的研究兴趣包括自然语言处理、机器学习和计算机视觉。

Zhijing Yang

Zhijing Yang 分别于 2003 年和 2008 年在中国广州中山大学数学与计算科学领域获得理学学士和博士学位。2009 年 7 月至 12 月，他在英国布拉德福德大学计算、信息学与媒体学院任访问学者；2011 年 1 月至 2013 年 1 月，在英国林肯大学工程学院任研究员。目前，他是中国广东工业大学信息工程学院教授、副院长。他已发表 80 余篇经过同行评审的期刊和会议论文，包括 IEEE T-CSVT、T-MM、T-GRS、PR 等。他的研究兴趣包括机器学习和模式识别。

Jie Liu

Jie Liu 目前是中国北京北方工业大学信息学院教授、博士生导师。1999 年至 2021 年，他在首都师范大学工作；目前兼任首都师范大学博士生导师和硕士生导师。他于 2009 年在北京理工大学获得计算机应用技术博士学位。他担任中国语言智能研究中心副主任、中国人工智能学会理事、中国人工智能学会语言智能专委会秘书长。他获得 2019 年吴文俊人工智能科学技术进步一等奖、2017 年北京市科学技术进步二等奖，以及 2023 年北京市发明专利奖二等奖。他是中国科技部“科技创新 2030”重大项目负责人。主要研究兴趣为自然语言处理和人工智能。

Liang Lin

Liang Lin（IEEE Fellow）是中山大学正教授。2008 年至 2010 年，他在加利福尼亚大学洛杉矶分校从事博士后研究。2016 年至 2018 年，他领导商汤科技研发团队，在计算机视觉、数据分析与挖掘以及智能机器人系统领域开发前沿且可交付的解决方案。他独立或合作撰写了 100 余篇顶级学术期刊和会议论文，例如在 TPAMI 和 IJCV 发表 15 篇论文，在 CVPR、ICCV、NIPS 和 IJCAI 发表 60 余篇论文。他担任过 IEEE Transactions on Human-Machine Systems、The Visual Computer 和 Neurocomputing 的副编辑，并担任 CVPR、ICME、ACCV、ICMR 等多个会议的领域主席或分会主席。他获得 2018 年 Pattern Recognition（Elsevier）年度最佳论文奖、2017 年 IEEE ICME 最佳论文钻石奖、2010 年 ACM NPAR 最佳论文亚军奖、2012 年 Google Faculty Award、2014 年 IEEE ICME 最佳学生论文奖，以及 2014 年香港学者奖。他是 IEEE、IAPR 和 IET 会士。