探索和利用不确定性进行不完整多视图分类

Exploring and Exploiting Uncertainty for Incomplete Multi-View Classification

作者： Mengyao Xie*、Zongbo Han*、Changqing Zhang †、Yichen Bai、Qinghua Hu
单位： 天津大学智能与计算学部
联系邮箱： zhangchangqing@tju.edu.cn
* 同等贡献。 † 通讯作者。

版本及来源： arXiv:2304.05165v1，2023 年 4 月 11 日，论文版本页，原文 PDF。

授权与译文说明： 原作采用 Creative Commons Attribution 4.0 International（CC BY 4.0） 许可。本文为依据上述 10 页版本制作的非官方中文全文译文，由 ChatGPT 翻译和重新排版，不代表原作者认可。原作署名及出处予以保留；改动包括正文、标题、图表说明和参考文献题名的中文翻译，以及单栏重排。原始图 1–4、表 1 的全部数据和编号公式 1–9 以原文裁图保留，图内英文另附中文释义；表 1 按数据集分为五部分并重复表头。参考文献保留作者、英文题名和书目信息，并附中文题名。未修改原始 PDF，未添加原文不存在的附录。译文中的明确“译注”不属于原作。译文日期：2026 年 10 月 26 日。

摘要

真实应用中广泛存在任意视图缺失的情况，因此，对不完整多视图数据进行分类不可避免。尽管已有研究取得了很大进展，但由于缺失视图天然具有较高的不确定性，现有不完整多视图方法仍难以得到可信的预测。首先，缺失视图具有高度不确定性，因此只提供一个确定性插补结果并不合理。其次，插补数据本身的质量也具有高度不确定性。为探索和利用这种不确定性，我们提出不确定性诱导的不完整多视图数据分类模型（Uncertainty-induced Incomplete Multi-View Data Classification，UIMC），在一个稳定、可靠的框架下对不完整多视图数据进行分类。我们构造一个分布并多次采样，以刻画缺失视图的不确定性，再依据采样质量自适应地利用这些结果。由此，所提方法实现了更可感知的插补和更可控的融合。具体而言，我们以可用视图为条件，用一个分布对每个缺失数据建模，从而引入不确定性。随后，采用基于证据的融合策略，保证对插补视图进行可信整合。我们在多个基准数据集上开展了大量实验，所提方法在性能和可信性两方面均达到了当前先进水平。

1 引言

从多个互补视图中学习，有望得到泛化能力更强的模型。受益于深度学习的能力，多视图学习在聚类 [1–3]、分类 [4,5] 和表示学习 [6,7] 中，相对于单视图范式进一步展现出显著优势。然而，真实世界的数据通常并不完整。例如，在医疗领域，病情相同的患者可能选择不同的医学检查，从而产生不完整或未对齐的多视图数据；类似地，汽车中的传感器有时会发生故障，因而只能收集到部分信息。由于缺失问题具有很高的不确定性，灵活、可信地利用不完整多视图数据仍然极具挑战。

针对不完整多视图分类（Incomplete Multi-View Classification，IMVC）任务，已有大量研究，大致可分为两条主要路线。一类方法 [8,9] 不进行插补，只使用可用视图完成分类。另一类方法 [10–13] 则基于自编码器 [14,15]、生成对抗网络（GAN）[16] 等深度学习方法重建缺失数据，再利用插补后的完整数据进行分类。

虽然现有 IMVC 方法已经取得显著进展，但仍有以下局限：（1）简单忽略缺失视图的方法，由于难以探索视图之间的相关性，通常效果不佳，在高缺失率条件下尤其如此；（2）基于深度学习插补缺失数据的方法缺乏可解释性，而确定性的插补方式无法刻画缺失所带来的不确定性，导致分类不稳定；（3）能够处理复杂缺失模式下多视图数据的 IMVC 方法很少，尤其对于具有两个以上视图的数据，这使得这些方法缺乏灵活性。

针对上述局限，我们提出一种简单而有效、稳定且灵活的不完整多视图分类模型。首先，所提模型不是插补一个确定值，而是为每个缺失视图插补一个分布，以刻画其不确定性。近期研究 [17,18] 已充分认识到，必须刻画单视图数据中缺失数据的不确定性。其次，我们从上述分布中进行多次采样，每次采样结果均与已观测视图结合，构成多个补全后的多视图样本。采样数据的质量具有高度不确定性，因此，无论在单视图层面还是多视图融合层面，我们都依据其质量进行自适应整合。对于单视图，低质量采样数据往往具有较大的不确定性，不应影响其他视图的学习。因此，我们为每个视图构建一个基于证据的分类器，获得包含主观概率和不确定性质量的意见。在多视图融合时，依据 DS 规则整合多个视图的意见，从而保证能够可信地利用任意质量的视图。本工作的主要贡献总结如下。

- 我们提出一种用于不完整多视图数据分类的探索与利用策略，通过刻画缺失数据的不确定性，提高利用插补数据的有效性与可信性。据我们所知，所提 UIMC 是首个在不完整多视图分类中明确引入不确定性的工作。
- 为充分利用高质量插补数据并减弱低质量插补视图的影响，我们从两个方面对插补数据赋权，避免其对单视图和多视图融合产生负面影响。不确定性感知的训练与融合，显著保障了整合不确定插补数据时的有效性和可靠性。
- 我们针对具有多种特征或模态的数据开展分类实验，并采用多种指标评估结果，验证了所提 UIMC 在上述任务中优于现有方法，而且能够提供可靠的不确定性，具有可信性。

2 相关工作

2.1 不完整多视图学习

按照处理缺失视图的方式，不完整多视图学习大体可分为两条主要路线。具体而言，现有工作主要关注忽略缺失视图，或基于深度学习方法补全缺失视图。**不进行插补的方法**。 这类方法只使用已有视图，在聚类 [19–21] 和分类 [8,9] 中，直接为所有视图学习共同的潜在子空间或表示。**生成式方法**。 这类方法利用已有视图插补缺失视图，再使用重建的完整数据开展下游任务 [10,11,22–28]。具体来说，最常见的方式之一，是在部分多视图数据上应用变分自编码器结构，以重建缺失视图 [10,11,22]。生成对抗网络也被用于生成缺失视图 [26–28]。此外，还有一些基于核 CCA [23]、谱图 [24] 和信息论 [25] 获得插补结果的方法。与上述算法相比，我们的方法得到的是多个插补结果，而不是单次插补，并且会动态评估插补质量。因此，可以更可靠地执行下游分类任务。

2.2 不确定性估计

我们方法的关键之一，是探索并利用缺失数据中的不确定性。为实现高质量的不确定性估计，已有许多方法被提出 [29–31]。深度学习中的不确定性通常可分为偶然不确定性和认知不确定性 [32–34]。偶然不确定性是指由数据引起的不确定性，衡量数据的固有噪声。偶然不确定性还可分为同方差不确定性和异方差不确定性：前者随不同任务变化，通常用于估计多任务学习中的不确定性 [35,36]；后者随输入变化，在输入空间包含可变噪声时很有用 [37,38]。另一方面，认知不确定性指模型训练不充分引起的

不确定性，在理论上可以消除。可以使用具有不同参数的模型，对同一个不确定观测进行预测来估计这种不确定性；预测结果的不稳定性正反映了认知不确定性 [32,39]。在本工作中，我们采用主观逻辑 [40] 和 Dempster–Shafer 理论 [41]，估计插补结果的偶然不确定性，以构建可信、可靠的多视图分类网络。

3 方法

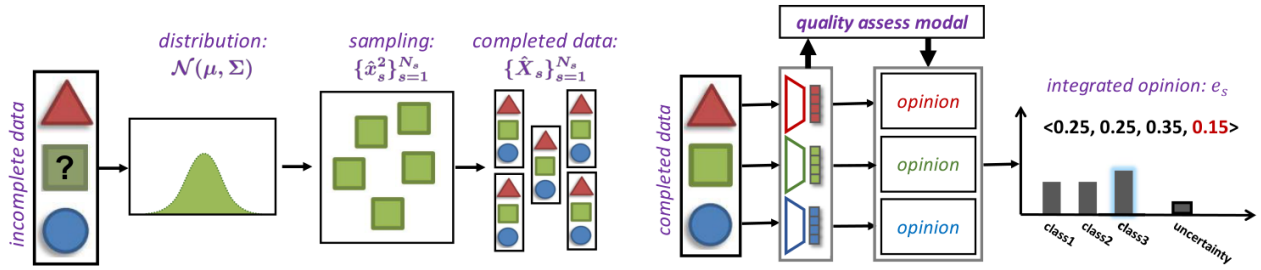
所提方法的核心目标，是探索并利用不完整多视图数据的不确定性，同时提高模型的有效性和可信性。我们先在第 3.1 节介绍不完整多视图分类的背景；随后在第 3.2 节介绍如何刻画插补视图的不确定性，在第 3.3 节介绍如何利用插补不确定性并整合不确定决策；最后在第 3.4 节说明如何利用多重插补得到分类预测。

3.1 背景

给定具有 V 个视图的 N 个训练输入 $\{\mathbb{X}_n\}_{n=1}^N$，其中 $\mathbb{X} = \{\mathbf{x}^v\}_{v=1}^V$，以及对应的类别标签 $\{\mathbf{y}_n\}_{n=1}^N$，多视图分类旨在利用互补的多视图数据，构建输入与标签之间的映射。在本文中，我们关注定义 3.1 所给出的不完整多视图分类任务。

定义 3.1 不完整多视图分类。形式上，一个完整的多视图样本由 V 个视图 $\mathbb{X} = \{\mathbf{x}^v\}_{v=1}^V$ 及其对应的类别标签 $\mathbf{y}$ 构成。不完整的多视图观测 $\bar{\mathbb{X}}$ 是完整多视图观测的一个子集，即 $\bar{\mathbb{X}} \subseteq \mathbb{X}$，其中包含任意可能的 $\bar{V}$ 个视图，且 $1 \leq \bar{V} \leq V$。给定含有 N 个样本的不完整多视图训练数据集 $\{\bar{\mathbb{X}}_n, \mathbf{y}_n\}_{n=1}^N$，不完整多视图分类旨在学习不完整多视图观测 $\bar{\mathbb{X}}$ 与对应类别标签 $\mathbf{y}$ 之间的映射。

解决不完整多视图分类问题主要有两条路线，即插补缺失视图与忽略缺失视图。具体而言，基于插补的方法 [10–13] 根据已观测数据补全缺失视图，但基本忽视了不可信插补会损害下游任务这一点。相比之下，忽略缺失视图的方法 [8,9] 只使用可用视图训练分类模型，通常缺少对不同视图间相关性的探索。所提方法旨在通过探索和利用缺失视图的不确定性，学习更可信的模型。



(a) Stage 1: Completion for missing view

(b) Stage 2: Evidential fusion for completed data

图 1 所提 UIMC 的示意图。为清晰起见，图 1a 采用缺失一个视图的三视图数据作为示例。UIMC 的整体过程包括两个阶段。在阶段 1，我们依据非参数化的最近邻策略，以多元高斯分布 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 刻画缺失视图的潜在不确定性。随后，从缺失视图的分布中采样 N_s 次，即可得到 N_s 个完整实例 $\{\widehat{\mathbb{X}}_s\}_{s=1}^{N_s}$。在阶段 2，对于实例 $\widehat{\mathbb{X}}_s$，我们通过证据分类利用每个视图的不确定性，以缓解低质量插补带来的负面影响。随后，采用定义 3.2 中介绍的 Dempster 合成规则整合多个视图的主观意见，使模型能够可信地利用插补数据。

图内文字对照：incomplete data＝不完整数据；distribution＝分布；sampling＝采样；completed data＝补全数据；quality assess modal＝质量评估模块；opinion＝意见；integrated opinion＝整合意见；class 1/2/3＝类别 1/2/3；uncertainty＝不确定性。（a）阶段 1：补全缺失视图；（b）阶段 2：对补全数据进行证据融合。图中数值和符号保留原貌。

3.2 插补缺失视图

给定一个不完整多视图数据实例 $\bar{\mathbb{X}}$，我们考虑依据其已观测视图合理插补缺失视图，从而可能改善下游分类模型。

刻画缺失视图的不确定性。 大多数现有不完整多视图分类方法 [10–13] 采用单次插补来填补缺失视图。形式上，它们通常构建从不完整多视图数据实例 $\bar{\mathbb{X}}$ 到完整数据的确定性映射，即 $f:\bar{\mathbb{X}}\to\mathbb{X}$。单次插补忽略了插补数据具有高度不确定性的本质，不可信的插补可能对下游分类任务产生负面影响。在属性缺失的单视图分类任务中，这一现象也已得到充分认识 [18,42]。我们不采用确定性映射插补缺失视图，而是依据基于最近邻的非参数化策略，用分布刻画缺失视图的潜在不确定性。

构造最近邻集合。 不失一般性，考虑一个第 m 个视图缺失的不完整多视图训练实例 $\bar{\mathbb{X}}$，及其对应的标签 $\mathbf{y}$。我们的目标是利用其他第 m 个视图可用的训练样本中的信息，插补缺失视图 $\mathbf{x}^m$。受经典分类算法 k 最近邻 [43] 启发，我们采用非参数化方法，通过探索 $\bar{\mathbb{X}}$ 的邻居来构造缺失视图 $\mathbf{x}^m$ 的分布。具体而言，对于第 v 个视图（$v\neq m$），给定可用观测 $\mathbf{x}^v\in\bar{\mathbb{X}}$，我们通过以下方式，在其他具有相同标签的样本中寻找其 k 个最近邻，进而构造邻居集合。首先，计算 $\mathbf{x}^v$ 与 $\mathbf{x}_n^v$ 之间的距离来构造距离集合 $\mathbb{D}^v$；其中，$\mathbf{x}_n^v$ 是第 m 个视图可用且满足 $\mathbf{y}=\mathbf{y}_n$ 的样本的第 v 个视图数据：

$$\mathbb{D}^v=\left\{-\left\|\mathbf{x}^v-\mathbf{x}_n^v\right\|^2 \mid \mathbf{x}_n^v,\mathbf{x}_n^m \textit{ are available and } \mathbf{y}=\mathbf{y}_n\right\}. \tag{1}$$

式（1）中的 “are available and” 表示“均可用，且”。随后，可以通过下式得到最近邻索引集合 $\mathbb{I}^v$：

$$\mathbb{I}^v=\left\{i \mid -\left\|\mathbf{x}^v-\mathbf{x}_i^v\right\|^2\in \operatorname{topk}\left(\mathbb{D}^v\right)\right\}, \tag{2}$$

其中，$\operatorname{topk}(\cdot)$ 是根据距离集合 $\mathbb{D}^v$ 从训练集中选择 k 个最近邻的算子。注意，在测试阶段，缺失视图 $\mathbf{x}^m$ 的插补，是通过从训练集中选择最近邻实现的，与标签无关。

利用统计信息插补。 给定最近邻索引集合 $\mathbb{I}=\{\mathbb{I}^v\}_{v\neq m}$，我们利用其邻居集合 $\{\mathbf{x}_i^m\}_{i\in\mathbb{I}}$，以统计方式刻画缺失视图 $\mathbf{x}^m$ 的分布。形式上，我们假设缺失视图 $\mathbf{x}^m$ 服从多元高斯分布 $\mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$，其中，$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 分别为根据邻居集合计算的均值向量和协方差矩阵：

$$\boldsymbol{\mu}=\frac{\sum_{i\in\mathbb{I}}\mathbf{x}_i^m}{|\mathbb{I}|},\boldsymbol{\Sigma}=\frac{1}{|\mathbb{I}|-1}\sum_{i\in\mathbb{I}}(\mathbf{x}_i^m-\boldsymbol{\mu})(\mathbf{x}_i^m-\boldsymbol{\mu})^T. \tag{3}$$

随后，可以从多元高斯分布 $\mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$ 中进行多次采样，插补 $\mathbf{x}^m$。更具体地说，给定一个不完整训练实例 $\bar{\mathbb{X}}$，通过 N_s 次采样，可以得到 N_s 个完整训练实例 $\{\widehat{\mathbb{X}}_s\}_{s=1}^{N_s}$。插补框架见图 1a。

3.3 对插补后的多视图样本分类

得到插补后的多视图训练数据集 $\{\{\widehat{\mathbb{X}}_{n,s}\}_{n=1}^{N}\}_{s=1}^{N_s}$ 后，我们考虑利用插补样本的不确定性，缓解低质量插补造成的负面影响。由于插补中存在固有噪声，插补后的多视图数据通常具有高度不确定性。因此，我们先基于证据多视图学习框架估计不同视图的不确定性，再进行基于不确定性的决策融合。整体框架如图 1b 所示。

不同于传统分类算法，证据分类 [44,45] 定义了一个获取主观意见 $S = \{\{b_k\}_{k=1}^{K}, u\}$ 的理论框架，其中包含主观概率（信念质量）$\{b_k\}_{k=1}^{K} \geq 0$ 和总体不确定性质量 $u \geq 0$； K 表示类别数，并且 $\sum_{k=1}^{K} b_k + u = 1$。主观意见与一个参数为 $\boldsymbol{\alpha} = [\alpha_1, \ldots, \alpha_K]$ 的 Dirichlet 分布相关联。具体而言，可以很容易地由对应 Dirichlet 分布的参数推导出信念质量 $b_k = (\alpha_k - 1)/\alpha_0$，其中 $\alpha_0 = \sum_{k=1}^{K} \alpha_k$ 是 Dirichlet 强度。

为获取每个视图 $\widehat{\mathbf{x}}^v \in \widehat{\mathbb{X}}$ 的 Dirichlet 分布参数，我们构建证据神经网络：将传统神经网络分类器的 softmax 层替换为 softplus 等激活函数，使其正值输出可被视为证据向量 $\mathbf{e}^v = [e_1^v, \ldots, e_K^v]$。随后，通过 $\alpha_k^v = e_k^v + 1$ 得到视图 $\widehat{\mathbf{x}}^v$ 对应的 Dirichlet 分布 $Dir(\mathbf{p}^v \mid \boldsymbol{\alpha}^v)$ 的参数。在变分框架下，证据分类损失函数 $\mathcal{L}^v$ 由分类损失 $\mathcal{L}_c^v$ 与正则项 $\mathcal{L}_r^v$ 组成 [46]。更具体地说，分类目标函数可视为：在 $Dir(\mathbf{p}^v \mid \boldsymbol{\alpha}^v)$ 所确定的单纯形上，对传统交叉熵损失进行积分。具体得到：

$$\mathcal{L}_c^v(\boldsymbol{\alpha}^v \mid \mathbf{x}^v) = \sum_{k=1}^{K} y_k \left(\psi\left(\alpha_0^v\right) - \psi\left(\alpha_k^v\right)\right), \qquad (4)$$

其中， y_k 是采用独热向量表示的 $\mathbf{y}$ 的第 k 个元素， $\psi(\cdot)$ 为 digamma 函数。为得到合理的 Dirichlet 分布，我们使用下式为 Dirichlet 分布加入先验，作为正则项：

$$\mathcal{L}_r^v(\boldsymbol{\alpha}^v \mid \mathbf{x}^v) = D_{KL}\left[Dir(\boldsymbol{p}^v \mid \tilde{\boldsymbol{\alpha}}^v) \| Dir(\boldsymbol{p}^v \mid [1, \cdots, 1])\right], \qquad (5)$$

其中， $\tilde{\boldsymbol{\alpha}}^v = \mathbf{y} + (1 - \mathbf{y}) \odot \boldsymbol{\alpha}^v$，即将与标签对应的 α_k 替换为 1 后的 Dirichlet 分布参数。 $Dir(\mathbf{p}^v \mid [1, \ldots, 1])$ 是均匀 Dirichlet 分布。因此，每个视图的总体损失函数可写为：

$$\mathcal{L}^v(\boldsymbol{\alpha}^v \mid \mathbf{x}^v) = \mathcal{L}_c^v(\boldsymbol{\alpha}^v \mid \mathbf{x}^v) + \lambda \mathcal{L}_r^v(\boldsymbol{\alpha}^v \mid \mathbf{x}^v), \qquad (6)$$

其中， λ 是退火系数，在训练期间从 0 逐渐变为 1，以控制约束强度。通过最小化 $\mathcal{L}^v$，可以得到 Dirichlet 分布 $Dir(\mathbf{p}^v \mid \boldsymbol{\alpha}^v)$。随后，可由 $b_k^v = (\alpha_k^v - 1)/\alpha_0$ 和 $u^v = 1 - \sum_{k=1}^{K} b_k^v$ 推导出对应的主观意见。

现在，我们考虑根据不确定性整合不同视图的主观意见。Dempster–Shafer 理论允许整合来自不同来源的主观意见，产生更全面的意见 [47]。具体而言，两个不同视图的 Dempster 合成规则见定义 3.2。由此，可以推导出整合后的多视图主观意见 $S^m = S^1 \oplus S^2 \oplus \cdots \oplus S^V = \{\{b_k^m\}_{k=1}^{K}, u^m\}$。通过 $\alpha_k^m = b_k^m \times \alpha_0^m + 1$，得到整合后的多视图 Dirichlet 分布 $Dir(\mathbf{p}^m \mid \boldsymbol{\alpha}^m)$ 的对应参数。

定义 3.2 Dempster 合成规则。 整合后的主观意见 $S = \{\{b_k\}_{k=1}^K, u\}$，可以由两个主观意见 $S^1 = \{\{b_k^1\}_{k=1}^K, u^1\}$ 和 $S^2 = \{\{b_k^2\}_{k=1}^K, u^2\}$，通过 $S = S^1 \oplus S^2$ 得到。具体可写为:

$$b_k = \frac{1}{1-C}\left(b_k^1 b_k^2 + b_k^1 u^2 + b_k^2 u^1\right), u = \frac{1}{1-C} u^1 u^2, \tag{7}$$

其中 $C = \sum_{i \neq j} b_i^1 b_j^2$。

为同时获得可靠的单视图 Dirichlet 分布和整合后的 Dirichlet 分布，我们采用多任务策略。具体而言，分类阶段的最终损失函数由单视图和多视图损失构成:

$$\mathcal{L} = \sum_{n=1}^{N} \sum_{s=1}^{N_s} \left\{ \mathcal{L}^m(\boldsymbol{\alpha}^m) + \sum_{v=1}^{V} \mathcal{L}^v(\boldsymbol{\alpha}^v \mid \mathbf{x}_{n,s}^v) \right\}, \tag{8}$$

其中:

$$\begin{aligned} \mathcal{L}^m(\boldsymbol{\alpha}^m) = & \sum_{k=1}^{K} y_k \left(\psi\left(\alpha_0^m\right) - \psi\left(\alpha_k^m\right)\right) \\ & + \lambda D_{KL}\left[Dir(\boldsymbol{p}^m \mid \tilde{\boldsymbol{\alpha}}^m) \| Dir(\boldsymbol{p}^m \mid [1, \cdots, 1])\right]. \end{aligned} \tag{9}$$

UIMC 的伪代码见算法 1。

算法 1 UIMC 的训练过程

输入： 不完整多视图训练集 $\{\bar{\mathbb{X}}_n, \mathbf{y}_n\}_{n=1}^N$。

初始化： 初始化 UIMC 的参数。

1. **对于** $n = 1 : N$：
   - 根据式（3）构造分布 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，从中采样 N_s 次，插补缺失视图 $\mathbf{x}_n^m$。
2. **结束循环**。
3. **当尚未收敛时：**
   - **对于** $v = 1 : V$：
     - 通过深度神经网络（DNN）得到证据 $\mathbf{e}_n^v$；
     - 得到 $\boldsymbol{\alpha}_n^v = \mathbf{e}_n^v + 1$ 以及 $S_n^v = \{\{b_{n,k}^v\}_{k=1}^K, u_n^v\}$。
   - **结束视图循环**。
   - 通过定义 3.2，得到 $\boldsymbol{\alpha}_n = [\alpha_{n,1}, \ldots, \alpha_{n,K}]$ 以及 $S_n = \{\{b_{n,k}\}_{k=1}^K, u_n\}$。
   - 计算式（8）中的总体损失 $\mathcal{L}$；
   - 使用优化算法更新参数。
4. **结束循环**。

输出： 模型参数。

3.4 利用多重插补进行预测

在测试阶段，对于每个不完整样本，我们可以得到 N_s 个插补后的多视图样本 $\{\widehat{\mathbb{X}}_s\}_{s=1}^{N_s}$。随后，对于每个样本，我们采用投票策略，依据其 N_s 个插补结果得到分类预测。具体而言，给定 N_s 个插补后的测试实例 $\{\widehat{\mathbb{X}}_s\}_{s=1}^{N_s}$，可以得到 N_s 个标签预测 $\{\widehat{\mathbf{y}}_s\}_{s=1}^{N_s}$。多视图测试实例 $\widehat{\mathbb{X}}$ 的最终预测标签，就是 $\{\widehat{\mathbf{y}}_s\}_{s=1}^{N_s}$ 中出现次数最多的元素。

4 实验

在本节中，我们在多个多视图数据集上，以不同缺失率 $\eta = \frac{\sum_{v=1}^{V} M^v}{V \times N}$ 开展大量实验，以回答以下问题；其中 M^v 表示缺少第 v 个视图的观测数量。

- **Q1 有效性（I）：** 所提 UIMC 是否优于其他方法?
- **Q2 有效性（II）：** 不同方法插补得到的完整多视图数据质量如何?
- **Q3 消融研究（I）：** 多重插补策略是否确实优于单次插补策略?
- **Q4 消融研究（II）：** 不确定性引导的分类和融合策略是否有助于提高性能?
- **Q5 稳定性：** 所提方法在采样操作下的稳定性如何?

4.1 数据集与比较方法

为验证 UIMC 的有效性，我们在五个数据集上开展实验。**YaleB** [48] 是一个包含 10 个类别的三视图数据集，每个类别有 65 张人脸图像。**ROSMAP** [49] 是一个包含两个类别的三视图数据集：阿尔茨海默病（AD）患者类别有 182 个样本，正常对照（NC）类别有 169 个样本。**Handwritten** [50] 是一个六视图数据集，包含从数字“0”到“9”的 10 个类别，每个类别有 200 个样本。**BRCA** [49] 是一个用于乳腺浸润性癌（BRCA）亚型分类的三视图数据集，包含 5 个类别，每个类别的样本数量在 46 至 436 之间。**Scene15** [51] 是一个用于场景分类的三视图数据集，包含 15 个类别，每个类别的样本数量在 210 至 410 之间。

我们将所提 UIMC 与以下方法比较。

1. **Mean-Imputation（均值插补）**：直接利用第 m 个视图上所有可用观测的均值，插补缺失视图 $\mathbf{x}^m$。
2. **GCCA** [52]：将典型相关分析（CCA）[53] 扩展到具有两个以上视图的数据。
3. **TCCA** [54]：通过最大化多个视图的典型相关性，得到所有视图共享的公共子空间。
4. **MVAE** [10]：将变分自编码器扩展到多视图数据，并采用专家乘积策略获得公共潜在子空间。
5. **MIWAE** [11]：将重要性加权自编码器扩展到多视图数据，以插补缺失数据。
6. **CPM-Nets** [9]：直接利用可用数据学习所有视图的联合潜在表示，并将该潜在表示映射为分类预测。
7. **DeepIMV** [8]：应用信息瓶颈（IB）框架，利用可用数据获得边缘表示和联合表示，并构建视图特定预测器与多视图预测器，以获得分类预测。

4.2 实验结果

下面，我们给出详细的实证结果，以研究上述关键问题，验证模型的有效性和可信性。

Q1 有效性（I）。 我们在不同缺失率 $\eta = [0, 0.1, 0.2, 0.3, 0.4, 0.5]$ 下，将本算法与当前先进的不完整多视图分类方法比较。遵循已有工作 [55]，我们采用分类准确率作为评估指标。对于 Mean-Imputation 方法，先用相应均值插补缺失视图，再依据补全后的多视图数据训练分类器。对于 GCCA、TCCA 等多视图学习方法，先用相应均值插补缺失视图，再训练 GCCA/TCCA，获得所有视图的联合拼接表示；最后，依据该多视图表示训练分类器。对于 MVAE、MIWAE 等不完整多视图生成式方法，我们采用先插补、后分类的策略：具体而言，先训练 MVAE/MIWAE，得到插补后的多视图数据，再基于插补结果，分别在单视图数据和多视图数据上训练分类器。对于 CPM-Nets、DeepIMV 等可以直接处理不完整多视图数据的分类方法，则不插补缺失视图，直接在不完整数据上训练分类器。所有方法均采用相同的网络架构，比较结果见表 1。

表 1 在五个数据集上，缺失率为 $\eta = [0, 0.1, 0.2, 0.3, 0.4, 0.5]$ 时的分类准确率比较（均值 ± 标准差）。

表头对照：Datasets＝数据集；Methods＝方法；Missing rates＝缺失率。方法名 Mean-Imputation＝均值插补，Ours＝本文方法；其余方法保留缩写。以下按原表顺序列出五个数据集的全部行和全部六个缺失率列；粗体和数值均保留原文。

表 1a YaleB

Datasets	Methods	Missing rates					
		$\eta = 0$	$\eta = 0.1$	$\eta = 0.2$	$\eta = 0.3$	$\eta = 0.4$	$\eta = 0.5$
YaleB	Mean-Imputation	**1.0000 ± 0.00**	0.9923 ± 0.00	0.9769 ± 0.01	0.9769 ± 0.01	0.9692 ± 0.01	0.9615 ± 0.01
	GCCA	0.9692 ± 0.00	0.9385 ± 0.01	0.9077 ± 0.02	0.8615 ± 0.03	0.8385 ± 0.02	0.8231 ± 0.02
	TCCA	0.9846 ± 0.00	0.9625 ± 0.00	0.9492 ± 0.01	0.90.77 ± 0.01	0.8846 ± 0.02	0.8615 ± 0.01
	MVAE	**1.0000 ± 0.00**	0.9969 ± 0.00	0.9861 ± 0.00	0.9831 ± 0.01	0.9692 ± 0.02	0.9599 ± 0.01
	MIWAE	**1.0000 ± 0.00**	0.9923 ± 0.00	0.9923 ± 0.01	0.9903 ± 0.01	0.9846 ± 0.01	0.9692 ± 0.03
	CPM-Nets	0.9915 ± 0.02	0.9862 ± 0.01	0.9800 ± 0.01	0.9700 ± 0.02	0.9469 ± 0.01	0.9100 ± 0.02
	DeepIMV	**1.0000 ± 0.00**	0.9846 ± 0.03	0.9231 ± 0.02	0.9154 ± 0.08	0.8923 ± 0.02	0.8718 ± 0.06
	Ours	**1.0000 ± 0.00**	**1.0000 ± 0.00**	**0.9981 ± 0.00**	**0.9962 ± 0.01**	**0.9847 ± 0.01**	**0.9769 ± 0.01**

译注：原表 YaleB 数据集的 TCCA 方法在 η=0.3 处印为“0.90.77 ± 0.01”。此处保留原图，不推测或擅自改正该数值。

表 1b ROSMAP

Datasets	Methods	Missing rates					
		$\eta = 0$	$\eta = 0.1$	$\eta = 0.2$	$\eta = 0.3$	$\eta = 0.4$	$\eta = 0.5$
ROSMAP	Mean-Imputation	0.7429 ± 0.03	0.6809 ± 0.01	0.6714 ± 0.02	0.6571 ± 0.07	0.6429 ± 0.02	0.6072 ± 0.05
	GCCA	0.6953 ± 0.03	0.6571 ± 0.02	0.6429 ± 0.04	0.6143 ± 0.03	0.5714 ± 0.06	0.5429 ± 0.06
	TCCA	0.7143 ± 0.03	0.7072 ± 0.01	0.6857 ± 0.05	0.6500 ± 0.05	0.6286 ± 0.03	0.6036 ± 0.06
	MVAE	0.7429 ± 0.02	0.7286 ± 0.05	0.7143 ± 0.05	0.6786 ± 0.03	0.6786 ± 0.06	0.6524 ± 0.06
	MIWAE	0.7429 ± 0.03	0.7286 ± 0.02	0.6714 ± 0.05	0.6571 ± 0.03	0.6571 ± 0.05	0.6357 ± 0.08
	CPM-Nets	0.7840 ± 0.05	0.7517 ± 0.04	0.7394 ± 0.06	0.7183 ± 0.04	0.6901 ± 0.08	0.6409 ± 0.08
	DeepIMV	0.7607 ± 0.03	0.7429 ± 0.01	0.7143 ± 0.05	0.6643 ± 0.05	0.6524 ± 0.06	0.6250 ± 0.06
	Ours	**0.8714 ± 0.00**	**0.8429 ± 0.03**	**0.7714 ± 0.05**	**0.7464 ± 0.03**	**0.7214 ± 0.03**	**0.7143 ± 0.02**

表 1c Handwritten

Datasets	Methods	Missing rates $\eta=0$	$\eta=0.1$	$\eta=0.2$	$\eta=0.3$	$\eta=0.4$	$\eta=0.5$
Handwritten	Mean-Imputation	0.9800 ± 0.00	0.9750 ± 0.00	0.9700 ± 0.01	0.9700 ± 0.01	0.9500 ± 0.01	0.9100 ± 0.01
	GCCA	0.9500 ± 0.01	0.9350 ± 0.02	0.9100 ± 0.01	0.8875 ± 0.02	0.8425 ± 0.02	0.8200 ± 0.03
	TCCA	0.9725 ± 0.00	0.9650 ± 0.00	0.9575 ± 0.02	0.9350 ± 0.01	0.9200 ± 0.01	0.9100 ± 0.02
	MVAE	0.9800 ± 0.00	0.9750 ± 0.01	0.9700 ± 0.00	0.9650 ± 0.01	0.9575 ± 0.01	0.9500 ± 0.01
	MIWAE	0.9800 ± 0.00	0.9800 ± 0.00	0.9725 ± 0.00	0.9650 ± 0.00	0.9475 ± 0.01	0.9375 ± 0.02
	CPM-Nets	0.9550 ± 0.01	0.9475 ± 0.01	0.9375 ± 0.01	0.9300 ± 0.02	0.9225 ± 0.01	0.9125 ± 0.01
	DeepIMV	$\mathbf{0.9908 \pm 0.04}$	$\mathbf{0.9883 \pm 0.02}$	$\mathbf{0.9850 \pm 0.04}$	0.9750 ± 0.02	0.9625 ± 0.04	0.9450 ± 0.06
	Ours	0.9825 ± 0.00	0.9800 ± 0.00	0.9800 ± 0.00	$\mathbf{0.9775 \pm 0.00}$	$\mathbf{0.9700 \pm 0.01}$	$\mathbf{0.9600 \pm 0.01}$

表 1d BRCA

Datasets	Methods	Missing rates $\eta=0$	$\eta=0.1$	$\eta=0.2$	$\eta=0.3$	$\eta=0.4$	$\eta=0.5$
BRCA	Mean-Imputation	0.7885 ± 0.02	0.7143 ± 0.03	0.7000 ± 0.04	0.6571 ± 0.02	0.6429 ± 0.03	0.6286 ± 0.02
	GCCA	0.7371 ± 0.03	0.7143 ± 0.03	0.6971 ± 0.04	0.6762 ± 0.02	0.6514 ± 0.03	0.6381 ± 0.04
	TCCA	0.7543 ± 0.02	0.7314 ± 0.03	0.7238 ± 0.04	0.7129 ± 0.03	0.6857 ± 0.04	0.6743 ± 0.03
	MVAE	0.7885 ± 0.03	0.7691 ± 0.02	0.7347 ± 0.01	0.6968 ± 0.03	0.6633 ± 0.05	0.6388 ± 0.03
	MIWAE	0.7885 ± 0.02	0.7352 ± 0.03	0.7314 ± 0.03	0.7105 ± 0.02	0.7029 ± 0.02	0.6857 ± 0.04
	CPM-Nets	0.7388 ± 0.02	0.7317 ± 0.04	0.7107 ± 0.08	0.7233 ± 0.04	0.6980 ± 0.05	0.6788 ± 0.03
	DeepIMV	0.7686 ± 0.03	0.7614 ± 0.02	0.7457 ± 0.02	0.7414 ± 0.02	0.7400 ± 0.02	0.6714 ± 0.04
	Ours	$\mathbf{0.8286 \pm 0.01}$	$\mathbf{0.7943 \pm 0.01}$	$\mathbf{0.7771 \pm 0.01}$	$\mathbf{0.7657 \pm 0.02}$	$\mathbf{0.7543 \pm 0.02}$	$\mathbf{0.7429 \pm 0.02}$

表 1e Scene15

Datasets	Methods	Missing rates $\eta=0$	$\eta=0.1$	$\eta=0.2$	$\eta=0.3$	$\eta=0.4$	$\eta=0.5$
Scene15	Mean-Imputation	0.7681 ± 0.02	0.6912 ± 0.01	0.6477 ± 0.01	0.6098 ± 0.01	0.5864 ± 0.02	0.5106 ± 0.02
	GCCA	0.6611 ± 0.02	0.6511 ± 0.01	0.6176 ± 0.01	0.5708 ± 0.01	0.5385 ± 0.02	0.5006 ± 0.02
	TCCA	0.6878 ± 0.02	0.6644 ± 0.01	0.6566 ± 0.01	0.6187 ± 0.01	0.5741 ± 0.01	0.5563 ± 0.02
	MVAE	0.7681 ± 0.00	0.7346 ± 0.01	0.7157 ± 0.01	0.6689 ± 0.01	0.6444 ± 0.01	0.6098 ± 0.01
	MIWAE	0.7681 ± 0.03	0.7179 ± 0.01	0.6990 ± 0.01	0.6566 ± 0.01	0.6265 ± 0.02	0.5875 ± 0.02
	CPM-Nets	0.6990 ± 0.02	0.6566 ± 0.02	0.6388 ± 0.00	0.6265 ± 0.01	0.5903 ± 0.01	0.5708 ± 0.01
	DeepIMV	0.7124 ± 0.00	0.6934 ± 0.02	0.6656 ± 0.01	0.6410 ± 0.00	0.5853 ± 0.02	0.5719 ± 0.01
	Ours	$\mathbf{0.7770 \pm 0.00}$	$\mathbf{0.7581 \pm 0.01}$	$\mathbf{0.7347 \pm 0.00}$	$\mathbf{0.6990 \pm 0.01}$	$\mathbf{0.6689 \pm 0.01}$	$\mathbf{0.6254 \pm 0.02}$

从实验结果可以观察到：（1）UIMC 在完整多视图数据（$\eta = 0$）上取得了具有竞争力的性能。（2）当 $\eta \neq 0$ 时，UIMC 在大多数数据集上优于所有比较方法，尤其在任务较难时。例如，在 ROSMAP 上，从 $\eta = 0.1$ 到 $\eta = 0.5$，所提方法的性能显著优于其他方法。（3）在较高缺失率下，UIMC 取得最高分类准确率，验证了其对不完整多视图数据的强鲁棒性。例如，在 BRCA 上，从 $\eta = 0.3$ 到 $\eta = 0.5$，本文方法的准确率仅下降 2.28%，而其他方法下降 7%。

Q2 有效性（II）。我们在 Handwritten 上，以 $\eta = 0.5$ 开展实验，对插补后的完整多视图数据进行可视化。具体而言，根据可用视图确定分布，并从中采样 $N_s = 30$ 次，得到插补后的完整数据。如图 2 所示，由于 UIMC 探索了不同视图之间的相关性，不同类别之间的间隔更加清晰。虽然我们的插补策略可能引入噪声，模型仍取得了最佳性能。

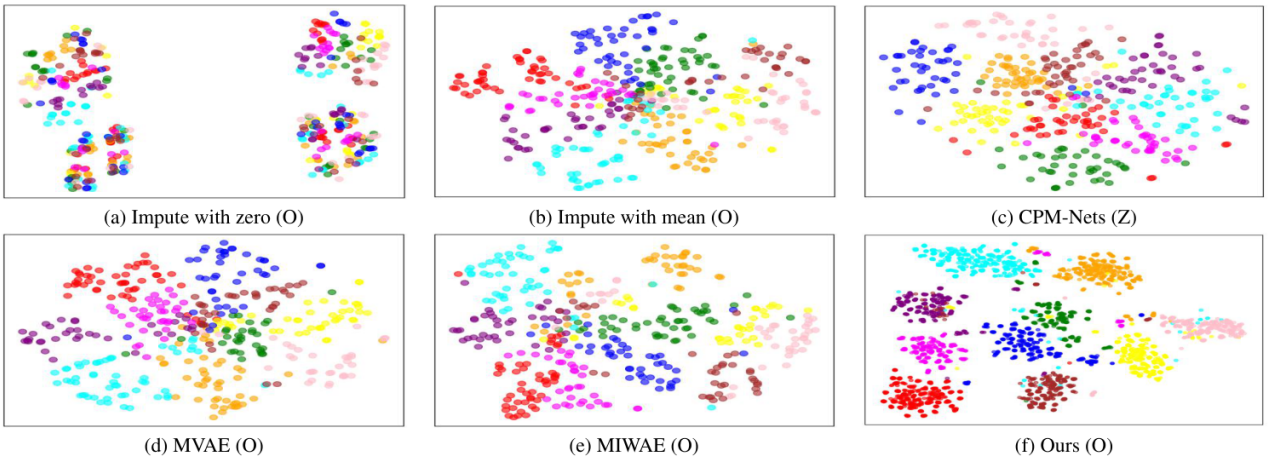


图 2 缺失率为 $\eta = 0.5$ 时，插补后的完整数据（Handwritten）的可视化，其中多个视图进行了拼接。 “O”和“Z”分别表示原始数据（及插补视图）的拼接结果，以及由多个可用视图学习得到的公共潜在表示。子图依次为：（a）零值插补（O）；（b）均值插补（O）；（c）CPM-Nets（Z）；（d）MVAE（O）；（e）MIWAE（O）；（f）本文方法（O）。

Q3 消融研究（I）。 为说明有必要进行多次采样来插补缺失视图，而不是采用确定性插补，我们开展消融实验，将多次采样与朴素的确定性插补比较。如图 3 所示，名为 single-imputation（单次插补）的方法，被设计为使用邻居的均值插补缺失视图。UIMC 的优越表现，从实验上验证了多重插补策略能够取得比单次插补更好的性能。

Q4 消融研究（II）。 我们开展消融实验，研究利用不确定性引导多视图融合和分类的作用。具体而言，我们将本方法与名为 Naive-IMVC 的朴素版本比较；后者忽略了插补引入的不确定性。更具体地说，Naive-IMVC 与 UIMC 的关键区别在于：Naive-IMVC 分别在每个单视图以及整合后的多视图数据上训练分类器，并用交叉熵损失 $\mathcal{L}_{ce} = -\sum_{k=1}^{K} y_k \log(p_k)$ 优化，其中 p_k 是类别 k 的预测概率；而 UIMC 采用不确定性引导的多视图融合与分类策略。如图 3 所示，我们在 Handwritten、YaleB 和 Scene15 上，以 $\eta = [0, 0.1, 0.2, 0.3, 0.4, 0.5]$ 比较 UIMC 与 Naive-IMVC。UIMC 的分类准确率优于 Naive-IMVC，表明本方法能够利用插补不确定性，更高效、可信地进行预测。

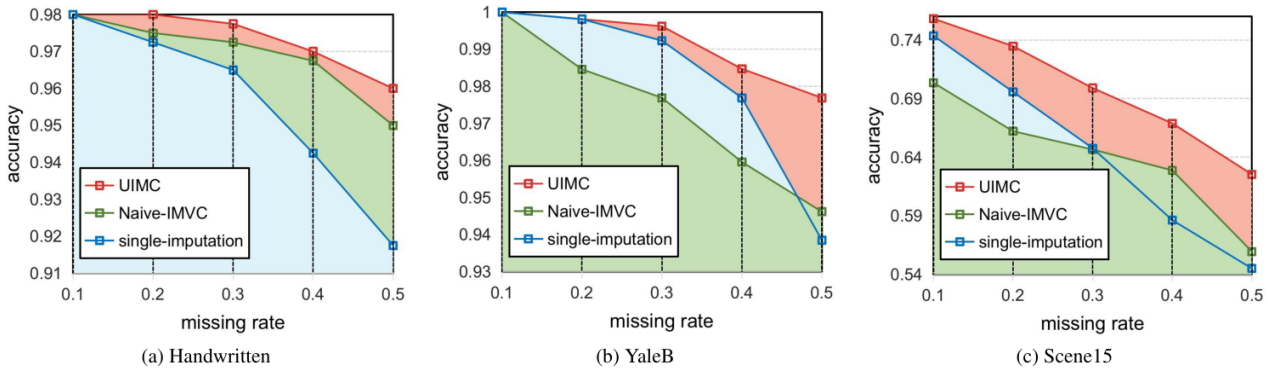
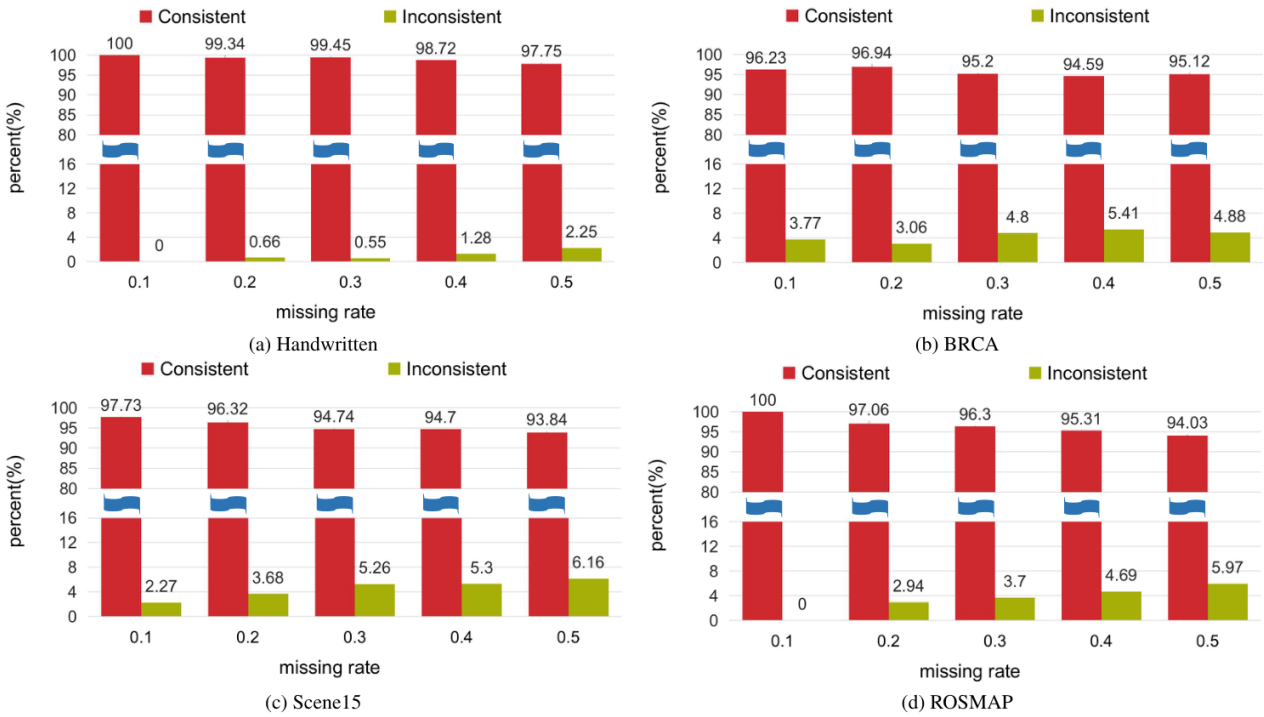


图 3 UIMC、single-imputation 和 Naive-IMVC 在三个数据集上、$\eta = [0, 0.1, 0.2, 0.3, 0.4, 0.5]$ 时的分类性能。 子图为：（a）Handwritten；（b）YaleB；（c）Scene15。图内 accuracy＝准确率；missing rate＝缺失率；single-imputation＝单次插补。图注和横坐标均按原文保留。

Q5 稳定性。 我们从估计出的多元高斯分布中进行多次采样，以插补缺失视图。由于采样过程包含随机性，每次采样操作会产生不同的完整数据，因而对应的分类预测也可能不同。为获得稳定、鲁棒的预测，我们的方法采用投票策略得到最终分类，可以减轻采样操作所带来的不确定性的负面影响。为研究采样过程造成的预测变化，我们固定不完整多视图数据的缺失模式，即固定每个样本缺失的视图，再进行 $N_i = 10$ 次采样，得到 10 组不同的完整多视图数据。随后，使用一个预训练分类模型，对这 10 个插补后的多视图数据集进行测试，得到 10 组预测结果。我们在 ROSMAP、BRCA、Handwritten 和 Scene15 上进行该实验，它们的类别数分别为 2、5、10 和 15。如图 4 所示，“Inconsistent”的比例相对较小，说明模型的预测相当稳定；其中，“Consistent”和“Inconsistent”分别表示 10 次测试得到相同预测和不同预测的情况。



(a) Handwritten (b) BRCA (c) Scene15 (d) ROSMAP

图 4 在四个数据集上，以 $\eta = [0, 0.1, 0.2, 0.3, 0.4, 0.5]$ 评估 UIMC 的稳定性。 子图为：（a）Handwritten；（b）BRCA；（c）Scene15；（d）ROSMAP。图内 Consistent＝一致；Inconsistent＝不一致；percent (%)＝百分比（%）；missing rate＝缺失率。图中的断轴和所有百分比数值按原样保留。

5 结论

在本工作中，我们提出一种新颖的不完整多视图分类框架，名为不确定性诱导的不完整多视图数据分类（UIMC）。它能够有效地探索和利用插补产生的不确定性，兼顾有效性与可信性。具体而言，UIMC 在插补缺失视图时重点考虑插补质量。由于 UIMC 从缺失视图的估计分布中进行多次采样，不可避免地会引入不确定性。我们采用证据分类器刻画视图特定的不确定性，并进一步利用 Dempster 合成规则，融合多个（插补）视图的不确定意见。我们开展了大量实验，实验结果充分验证了所提 UIMC 的有效性和稳定性。

本工作的局限在于，插补分布在多视图融合和分类之前便已确定。因此，未来工作将重点研究联合学习缺失视图的参数化分布与多视图分类器，使这两个组成部分能够相互促进。另一个有趣方向，是通过理论分析说明为缺失视图引入不确定性的必要性。

致谢

本工作得到国家自然科学基金（61976151）的部分资助。作者感谢本研究所使用的 MindSpore、CANN（Compute Architecture for Neural Networks，神经网络计算架构）以及 Ascend AI Processor（昇腾 AI 处理器）提供的支持。我们还希望在 MindSpore 上使用 UIMC；MindSpore 是一种新的深度学习计算框架。这些问题留待未来工作解决。

参考文献

以下保留原文的编号、作者顺序、英文题名和书目信息，并附中文题名；每条末尾的“原文引用页”对应英文原作中的回引页码，不是本译文页码。原作的书目拼写、重复条目及未给出的信息不作推断性修订。

[1] Zhiqiang Tao, Hongfu Liu, Sheng Li, Zhengming Ding, and Yun Fu. **From ensemble clustering to multi-view clustering**（从集成聚类到多视图聚类）. In Proceedings of the International Joint Conference on Artificial Intelligence, 2017. 原文引用页：1。

[2] Handong Zhao, Zhengming Ding, and Yun Fu. **Multi-view clustering via deep matrix factorization**（基于深度矩阵分解的多视图聚类）. In Proceedings of the AAAI Conference on Artificial Intelligence, 2017. 原文引用页：1。

[3] Hong Tao, Chenping Hou, Xinwang Liu, Tongliang Liu, Dongyun Yi, and Jubo Zhu. **Reliable multi-view clustering**（可靠的多视图聚类）. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 32, 2018. 原文引用页：1。

[4] Chunjie Zhang, Jian Cheng, and Qi Tian. **Multi-view image classification with visual, semantic and view consistency**（结合视觉一致性、语义一致性和视图一致性的多视图图像分类）. IEEE Transactions on Image Processing, 29:617–627, 2019. 原文引用页：1。

[5] Jinglin Xu, Wenbin Li, Xinwang Liu, Dingwen Zhang, Ji Liu, and Junwei Han. **Deep embedded complementary and interactive information for multi-view classification**（用于多视图分类的深度嵌入式互补与交互信息）. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 34, pages 6494–6501, 2020. 原文引用页：1。

[6] Yingming Li, Ming Yang, and Zhongfei Zhang. **A survey of multi-view representation learning**（多视图表示学习综述）. IEEE Transactions on Knowledge and Data Engineering, 31(10):1863–1883, 2018. 原文引用页：1。

[7] Ruihuang Li, Changqing Zhang, Qinghua Hu, Pengfei Zhu, and Zheng Wang. **Flexible multi-view representation learning for subspace clustering**（用于子空间聚类的灵活多视图表示学习）. In Proceedings of the International Joint Conference on Artificial Intelligence, pages 2916–2922, 2019. 原文引用页：1。

[8] Changhee Lee and Mihaela van der Schaar. **A variational information bottleneck approach to multi-omics data integration**（一种用于多组学数据整合的变分信息瓶颈方法）. In The 24th International Conference on Artificial Intelligence and Statistics, 2021. 原文引用页：1、2、3、5。

[9] Changqing Zhang, Zongbo Han, Yajie Cui, Huazhu Fu, Joey Tianyi Zhou, and Qinghua Hu. **Cpm-nets: Cross partial multi-view networks**（CPM-Nets：交叉部分多视图网络）. In Advances in Neural Information Processing Systems, pages 557–567, 2019. 原文引用页：1、2、3、5。

[10] Mike Wu and Noah D. Goodman. **Multimodal generative models for scalable weakly-supervised learning**（用于可扩展弱监督学习的多模态生成模型）. In Advances in Neural Information Processing Systems, pages 5580–5590, 2018. 原文引用页：1、2、3、5。

[11] Pierre-Alexandre Mattei and Jes Frellsen. **Miwae: Deep generative modelling and imputation of incomplete data sets**（MIWAE：不完整数据集的深度生成建模与插补）. In International Conference on Machine Learning, pages 4413–4423, 2019. 原文引用页：1、2、3、5。

[12] Kim-Han Thung, Pew-Thian Yap, and Dinggang Shen. **Joint robust imputation and classification for early dementia detection using incomplete multi-modality data**（面向使用不完整多模态数据进行早期痴呆检测的联合鲁棒插补与分类）. In International Workshop on PRedictive Intelligence In MEdicine, pages 51–59, 2018. 原文引用页：1、3。

[13] Lei Cai, Zhengyang Wang, Hongyang Gao, Dinggang Shen, and Shuiwang Ji. **Deep adversarial learning for multi-modality missing data completion**（用于多模态缺失数据补全的深度对抗学习）. In Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pages 1158–1166, 2018. 原文引用页：1、3。

[14] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio. **Contractive auto-encoders: Explicit invariance during feature extraction**（收缩自编码器：特征提取过程中的显式不变性）. In Proceedings of the 28th International Conference on Machine Learning, 2011. 原文引用页：1。

[15] Diederik P. Kingma and Max Welling. **Auto-encoding variational bayes**（自编码变分贝叶斯）. In International Conference on Learning Representations, 2014. 原文引用页：1。

[16] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Y. Bengio. **Generative adversarial nets**（生成对抗网络）. In Advances in Neural Information Processing Systems, 2014. 原文引用页：1。

[17] Niels Ipsen, Pierre-Alexandre Mattei, and Jes Frellsen. **How to deal with missing data in supervised deep learning?**（如何处理监督深度学习中的缺失数据？）. In The Tenth International Conference on Learning Representations, 2020. 原文引用页：1。

[18] Alma B Pedersen, Ellen M Mikkelsen, Deirdre Cronin-Fenton, Nickolaj R Kristensen, Tra My Pham, Lars Pedersen, and Irene Petersen. **Missing data and multiple imputation in clinical epidemiological research**（临床流行病学研究中的缺失数据与多重插补）. Clinical Epidemiology, 9:157, 2017. 原文引用页：1、3。

[19] Linlin Zong, Xianchao Zhang, Xinyue Liu, and Hong Yu. **Multi-view clustering on data with partial instances and clusters**（针对实例和簇不完整数据的多视图聚类）. Neural Networks, 129:19–30, 2020. 原文引用页：2。

[20] Shao-Yuan Li, Yuan Jiang, and Zhi-Hua Zhou. **Partial multi-view clustering**（部分多视图聚类）. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 28, 2014. 原文引用页：2。

[21] Handong Zhao, Hongfu Liu, and Yun Fu. **Incomplete multimodal visual data grouping**（不完整多模态视觉数据分组）. In Proceedings of the International Joint Conference on Artificial Intelligence, pages 2392–2398, 2016. 原文引用页：2。

[22] HyeongJoo Hwang, Geon-Hyeong Kim, Seunghoon Hong, and Kee-Eung Kim. **Multi-view representation learning via total correlation objective**（基于总相关性目标的多视图表示学习）. In Advances in Neural Information Processing Systems, volume 34, pages 12194–12207, 2021. 原文引用页：2。

[23] Piyush Rai, Anusua Trivedi, Hal Daumé III, and Scott L DuVall. **Multiview clustering with incomplete views**（视图不完整情况下的多视图聚类）. In Proceedings of the NIPS Workshop on Machine Learning for Social Computing, 2010. 原文引用页：2。

[24] Hang Gao, Yuxing Peng, and Songlei Jian. **Incomplete multi-view clustering**（不完整多视图聚类）. In International Conference on Intelligent Information Processing, pages 245–255, 2016. 原文引用页：2。

[25] Yijie Lin, Yuanbiao Gou, Zitao Liu, Boyun Li, Jiancheng Lv, and Xi Peng. **Completer: Incomplete multi-view clustering via contrastive prediction**（Completer：通过对比预测进行不完整多视图聚类）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 11174–11183, 2021. 原文引用页：2。

[26] Changqing Zhang, Yajie Cui, Zongbo Han, Joey Tianyi Zhou, Huazhu Fu, and Qinghua Hu. **Deep partial multi-view learning**（深度部分多视图学习）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(5):2402–2415, 2022. 原文引用页：2。

[27] Cai Xu, Ziyu Guan, Wei Zhao, Hongchang Wu, Yunfei Niu, and Beilei Ling. **Adversarial incomplete multi-view clustering**（对抗式不完整多视图聚类）. Pages 3933–3939. Proceedings of the International Joint Conference on Artificial Intelligence, 2019. 原文引用页：2。

[28] Qianqian Wang, Zhengming Ding, Zhiqiang Tao, Quanxue Gao, and Yun Fu. **Partial multi-view clustering via consistent gan**（基于一致性 GAN 的部分多视图聚类）. In IEEE International Conference on Data Mining, pages 1290–1295, 2018. 原文引用页：2。

[29] Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. **Simple and scalable predictive uncertainty estimation using deep ensembles**（使用深度集成进行简单且可扩展的预测不确定性估计）. Volume 30, 2017. 原文引用页：2。

[30] Andrey Malinin and Mark Gales. **Predictive uncertainty estimation via prior networks**（通过先验网络进行预测不确定性估计）. Volume 31, 2018. 原文引用页：2。

[31] Joost Van Amersfoort, Lewis Smith, Yee Whye Teh, and Yarin Gal. **Uncertainty estimation using a single deep deterministic neural network**（使用单个深度确定性神经网络进行不确定性估计）. In International Conference on Machine Learning, pages 9690–9700, 2020. 原文引用页：2。

[32] Alex Kendall and Yarin Gal. **What uncertainties do we need in bayesian deep learning for computer vision?**（面向计算机视觉的贝叶斯深度学习需要哪些不确定性？）. Volume 30, 2017. 原文引用页：2。

[33] Durga Rao Karanki, S Rahman, Vinh N Dang, and O Zerkak. **Epistemic and aleatory uncertainties in integrated deterministic and probabilistic safety assessment: Tradeoff between accuracy and accident simulations**（综合确定性与概率安全评估中的认知不确定性和偶然不确定性：准确性与事故模拟之间的权衡）. Reliability Engineering & System Safety, 162:91–102, 2017. 原文引用页：2。

[34] Jon C Helton, Jay D Johnson, William L Oberkampf, and Cedric J Sallaberry. **Representation of analysis results involving aleatory and epistemic uncertainty**（涉及偶然不确定性和认知不确定性的分析结果表示）. International Journal of General Systems, 39(6):605–646, 2010. 原文引用页：2。

[35] Rafael Peres da Silva, Chayaporn Suphavilai, and Niranjan Nagarajan. **Task uncertainty loss reduce negative transfer in asymmetric multi-task feature learning (student abstract)**（任务不确定性损失减少非对称多任务特征学习中的负迁移：学生摘要）. In Proceedings of the AAAI Conference on Artificial Intelligence, pages 15867–15868, 2021. 原文引用页：2。

[36] Alex Kendall, Yarin Gal, and Roberto Cipolla. **Multi-task learning using uncertainty to weigh losses for scene geometry and semantics**（利用不确定性对场景几何与语义损失加权的多任务学习）. In Conference on Computer Vision and Pattern Recognition, pages 7482–7491, 2018. 原文引用页：2。

[37] Bindya Venkatesh and Jayaraman J Thiagarajan. **Heteroscedastic calibration of uncertainty estimators in deep learning**（深度学习中不确定性估计器的异方差校准）. The Computing Research Repository, 2019. 原文引用页：2。

[38] Murat Seckin Ayhan and Philipp Berens. **Test-time data augmentation for estimation of heteroscedastic aleatoric uncertainty in deep neural networks**（用于估计深度神经网络中异方差偶然不确定性的测试时数据增强）. In International Conference on Medical Imaging with Deep Learning, 2018. 原文引用页：2。

[39] Jakob Gawlikowski, Cedrique Rovile Njieutcheu Tassi, Mohsin Ali, Jongseok Lee, Matthias Humt, Jianxiang Feng, Anna Kruspe, Rudolph Triebel, Peter Jung, Ribana Roscher, et al. **A survey of uncertainty in deep neural networks**（深度神经网络中的不确定性综述）. The Computing Research Repository, 2021. 原文引用页：2。

[40] Audun Jøsang. **A logic for uncertain probabilities**（一种针对不确定概率的逻辑）. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, 9(03):279–311, 2001. 原文引用页：2。

[41] Arthur P Dempster. **A generalization of bayesian inference**（贝叶斯推断的一种推广）. Journal of the Royal Statistical Society: Series B (Methodological), 30(2):205–232, 1968. 原文引用页：2。

[42] Marine Le Morvan, Julie Josse, Erwan Scornet, and Gael Varoquaux. **What's a good imputation to predict with missing values?**（使用缺失值进行预测时，什么才是好的插补？）. In Advances in Neural Information Processing Systems, volume 34, pages 11530–11540, 2021. 原文引用页：3。

[43] Thomas Cover and Peter Hart. **Nearest neighbor pattern classification**（最近邻模式分类）. IEEE Transactions on Information Theory, 13(1):21–27, 1967. 原文引用页：3。

[44] Murat Sensoy, Lance M. Kaplan, and Melih Kandemir. **Evidential deep learning to quantify classification uncertainty**（用于量化分类不确定性的证据深度学习）. Advances in Neural Information Processing Systems, 31:3183–3193, 2018. 原文引用页：4。

[45] Audun Jøsang. **Subjective Logic - A Formalism for Reasoning Under Uncertainty**（主观逻辑：不确定性推理的一种形式体系）. Artificial Intelligence: Foundations, Theory, and Algorithms. 2016. 原文引用页：4。

[46] Zongbo Han, Changqing Zhang, Huazhu Fu, and Joey Tianyi Zhou. **Trusted multi-view classification with dynamic evidential fusion**（基于动态证据融合的可信多视图分类）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022. 原文引用页：4。

[47] Arthur P Dempster. **A generalization of bayesian inference**（贝叶斯推断的一种推广）. Journal of the Royal Statistical Society: Series B (Methodological), 30(2):205–232, 1968. 原文引用页：4。

[48] Athinodoros S. Georghiades, Peter N. Belhumeur, and David J. Kriegman. **From few to many: Illumination cone models for face recognition under variable lighting and pose**（从少到多：用于可变光照与姿态下人脸识别的光照锥模型）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 23(6):643–660, 2001. 原文引用页：5。

[49] Tongxin Wang, Wei Shao, Zhi Huang, Haixu Tang, Jie Zhang, Zhengming Ding, and Kun Huang. **Moronet: multi-omics integration via graph convolutional networks for biomedical data classification**（Moronet：通过图卷积网络进行多组学整合，用于生物医学数据分类）. bioRxiv, 2020. 原文引用页：5。

[50] Simon Perkins and James Theiler. **Online feature selection using grafting**（使用嫁接方法进行在线特征选择）. In Proceedings of the 20th International Conference on Machine Learning, pages 592–599, 2003. 原文引用页：5。

[51] Pietro Perona FeiFei Li. **A bayesian hierarchical model for learning natural scene categories**（用于学习自然场景类别的贝叶斯层次模型）. In IEEE Computer Society Conference on Computer Vision and Pattern Recgnition, 2005. 原文引用页：5。

[52] Jon R Kettenring. **Canonical analysis of several sets of variables**（多组变量的典型分析）. Biometrika, 58(3):433–451, 1971. 原文引用页：5。

[53] Harold Hotelling. **Relations between two sets of variates**（两组变量之间的关系）. Biometrika, 28:321–377, 1935. 原文引用页：5。

[54] Yong Luo, Dacheng Tao, Kotagiri Ramamohanarao, Chao Xu, and Yonggang Wen. **Tensor canonical correlation analysis for multi-view dimension reduction**（用于多视图降维的张量典型相关分析）. IEEE Transactions on Knowledge and Data Engineering, 27(11):3111–3124, 2015. 原文引用页：5。

[55] Junhyun Nam, Hyuntak Cha, Sungsoo Ahn, Jaeho Lee, and Jinwoo Shin. **Learning from failure: De-biasing classifier from biased classifier**（从失败中学习：利用有偏分类器消除分类器偏差）. In Advances in Neural Information Processing Systems, volume 33, pages 20673–20684, 2020. 原文引用页：5。