用于稀疏交互工作者众包聚合的稀疏秩一矩阵补全梯度下降法

Gradient Descent for Sparse Rank-One Matrix Completion for Crowd-Sourced Aggregation of Sparsely Interacting Workers

Yao Ma[1]、Alex Olshevsky[2]、Venkatesh Saligrama[2]、Csaba Szepesvari[3]

[1] 美国波士顿大学系统工程部；[2] 美国波士顿大学电气与计算机工程系；[3] 加拿大阿尔伯塔大学计算科学系。作者按字母顺序排列。通讯作者：Venkatesh Saligrama，srv@bu.edu。

原载：第 35 届国际机器学习会议（ICML），瑞典斯德哥尔摩，PMLR 80:3335-3344，2018。版权 © 2018 原作者。官方页面：https://proceedings.mlr.press/v80/ma18b.html 。

非官方中文全文译文，含官方六页补充材料。 本译文依据 PMLR 出版协议的 CC BY 4.0 许可制作；翻译、符号排版及版面为修改内容，未经原作者审定。许可：https://creativecommons.org/licenses/by/4.0/ 。原文图形保留，图中英文配有中文说明；参考文献保留原始书目信息以便检索。正文和补充材料中的原有疑点不作无声修正，必要时以译注区分。向量、矩阵以粗体区分标量，集合与损失依语义排版。

摘要

我们研究单硬币 Dawid-Skene 众包模型中的工作者技能估计。在实践中，由于工作者的可用性任意且不可控制，任务分配稀疏而不规则，技能估计具有挑战性。我们把技能估计表述为秩一相关矩阵补全问题，已观测分量对应工作者之间观测到的标签相关性。我们证明，当且仅当采样矩阵（已观测分量）不可约且非周期时，相关矩阵可以成功恢复，技能可以识别。随后提出高效的梯度下降方案，并证明在此类采样矩阵下，技能估计收敛到所需的全局最优解。我们的证明是原创的；考虑到一般加权秩一矩阵分解问题也具有 NP 难度，这一结果令人意外。接着，我们利用采样矩阵的无符号拉普拉斯矩阵谱性质，导出含噪情形的样本复杂度界。所提方案在多个真实数据集上达到先进水平。

1 引言

本文研究众包中的标签估计。我们的工作基于 Dawid & Skene（1979）的单硬币模型：输入是一个稀疏填充的 $W \times T$ 工作者-任务标签矩阵。每名工作者具有自身未知的技能，每项任务具有自身未知的标签。矩阵收集工作者对各项任务提供的随机标签。工作者的技能水平，是其标签与任意任务未知真实标签相符的概率经缩放后的数值。观测标签彼此独立。

给定工作者技能水平，重建未知标签的最优方法（Nitzan & Paroush, 1981；Shapley & Grofman, 1984）是加权多数投票：每个工作者的标签权重等于其技能对应的对数优势比。实践中的群体往往高度异质，既有高技能工作者，也有负技能工作者。降低无技能工作者的权重、提高有技能工作者的权重，

会显著影响性能。由于技能未知，我们沿用既有工作（如 Dalvi et al., 2013；Berend & Kontorovich, 2014；Szepesvári, 2015；Bonald & Combes, 2016），采用两步方法：先估计技能，再用最优加权法恢复标签。

稀疏且不规则的分配。 工作者的可用性任意且不受控制，导致任务分配稀疏且不规则，使技能估计变得困难（Karger et al., 2013；Dalvi et al., 2013）。另一个微妙问题是工作者交互缺乏多样性：一名工作者在所有任务中，往往只与有限的一小部分其他工作者分组合作。[1]

我们的贡献。 （i）将技能估计表述为加权最小二乘秩一问题，以权重补偿实际应用中矩估计精度的差异；（ii）提出用投影梯度下降最小化所得目标；（iii）提供理论依据：给出权重矩阵的自然且温和的条件，证明即使目标非凸且权重稀疏，梯度下降仍能求得真实矩矩阵的秩一分解；（iv）在合成数据与标准基准数据上给出实验支持。数值实验中，由于大多数数据集是多分类的（标签超过两个取值），我们还基本遵循 Karger et al.（2013；2014）给出一种简单的多分类推广，并发现其实际效果良好。

技术创新。 我们导出秩一矩阵补全的基本结果：当且仅当采样矩阵不可约且非周期时，未观测条目可被恢复。加权低秩分解甚至在秩一情形也是 NP 难的（Gillis & Glineur, 2011），因此我们的梯度下降收敛结果尤其令人意外。表面上的矛盾可以解释：我们同时约束数据（秩一）与权重矩阵（不可约且非周期）。证明利用二部图的组合性质，具有独立研究价值。相比之下，现有低秩矩阵补全结果要求对权重矩阵作较强假设：权重通常为二元值（条目存在或缺失），并要求非相干性或随机权重矩阵（如 Ge et al., 2016）。

[1] 基准数据体现了这一情况：Web 数据集有 177 名工作者，每项任务 3 至 20 人；每名工作者平均只与约 2.7 名其他工作者交互，而交互人数的标准差为 15。RTE 有 164 名工作者，每项任务平均仅 10 人，每名工作者与不足 2.5 名其他工作者交互，而交互度标准差为 20。

2 相关工作

判别式方法。 与我们的两步法不同，一些工作使用判别式标签预测。这些方法（Li & Yu, 2014；Tian & Zhu, 2015）直接通过纳入工作者可靠性的各种聚合规则识别真实标签。

技能估计。 如前所述，我们研究单硬币模型下的技能估计。已有方法基于最大似然/最大后验（ML/MAP）估计、矩匹配，或两者结合。从 Dawid & Skene（1979）开始，人们提出多个版本的 EM 算法实现 ML/MAP。其变体与扩展在多种问题上得到检验，包括 Hui & Walter（1980）、Smyth et al.（1995）、Albert & Dodd（2004）、Raykar et al.（2010）和 Liu et al.（2012）。近期工作研究了 EM 及变体的性能保证（Gao & Zhou, 2013；Zhang et al., 2014；Gao et al., 2016）。另一常见方向是在技能、标签或分配上增加先验，利用信念传播、均值场和变分等贝叶斯方法处理额外信息（Raykar et al., 2010；Karger et al., 2011；Liu et al., 2012；Karger et al., 2013；2014）。矩匹配也得到广泛应用（Ghosh et al., 2011；Dalvi et al., 2013；Zhang et al., 2014；Gao et al., 2016；Bonald & Combes, 2016；Zhang et al., 2016）。除了采用特设方法的 Bonald & Combes（2016），这些算法使用矩阵或张量分解。[2]

理论上，保证最大化似然/后验的 ML/MAP 是适应不规则任务分配的理想方法。但是据我们所知，除非用基于矩匹配的谱方法初始化，目前尚无算法被证明能够找到其目标的令人满意的近似最大化解（Zhang et al., 2016）。同时，采用谱算法乃至一般代数算法的矩匹配法也隐含假设分配规则。

Ghosh et al.（2011）的方法使用未归一化统计量，关键依赖分配规则性，因而不应期待它适用于不规则数据。其他纯代数谱方法隐含地把估计矩阵和张量中的所有条目视为同样精确，而不规则分配时事实远非如此。必须显式处理精度不等的数据，这在低秩分解领域早已得到认识，可追溯至 Gabriel & Zamir（1979）。从该工作开始，标准建议是将低秩估计改写为加权最小二乘（如 Gabriel & Zamir, 1979；Srebro & Jaakkola, 2003），本文也采用这一建议。

Dalvi et al.（2013）虽然也使用加权最小二乘目标，但这是数据归一化的结果，而不是为修正数据精度差异而主动选择。他们也没有直接最小化所得目标，而是使用两个同样涉及未加权谱方法的启发式方案。因此，我们的目标是使谱方法适用于实践中常见的不规则工作者-任务数据。

矩阵分解/补全。 与推荐系统中的一般矩阵分解问题（Koren et al., 2009）不同，我们主要关心方形对称矩阵的秩一估计。现有对称方阵补全结果（Ge et al., 2016）更一般，但要求非相干性和随机采样等较强假设。

[2] Ghosh et al.（2011）开创了矩阵分解方法，但他们直接估计标签，因而与此处讨论的相关性较小。

符号和约定。 实数集记为 $\mathbb{R}$，不含零的自然数集记为 $\mathbb{N}$。对于 $k \in \mathbb{N}$，$[k] = \{1, \ldots, k\}$。空和定义为零。$\mathbb{P}$ 表示随机变量所在测度空间上的概率测度，$\mathbb{E}$ 表示相应期望。对于 $p \in [1, \infty]$，$\| \mathbf{v} \|_p$ 表示向量的 p 范数；$\| \cdot \|$ 表示 2 范数，$\| \cdot \|_F$ 表示 Frobenius 范数。集合 S 的基数为 $|S|$。实向量 $\mathbf{x}$ 的 $|\mathbf{x}|$ 是分量为 $|x_i|$ 的向量。正文省略的新结果证明见附录。

3 问题设定

考虑二元众包任务：一组工作者为大量项目提供二元标签。固定正整数 $W \in \mathbb{N}$ 表示工作者人数。问题实例 $\theta = (\mathbf{s}, A, \mathbf{g})$ 由技能向量 $\mathbf{s} = (s_1, \ldots, s_W) \in [-1, 1]^W$、工作者-任务分配集合 $A \subset [W] \times \mathbb{N}$ 及真实标签向量 $\mathbf{g} \in \{\pm 1\}^{\mathbb{N}}$ 给出。

若某个 $T \in \mathbb{N}$ 满足 $A \subset [W] \times [T]$，则称 θ 是有 T 项任务的有限实例，否则称无限实例。允许无限任务是为了讨论渐近可识别性。Θ_W 表示全部实例的集合。

定义 1（交互图）。 设 A 是工作者-任务分配集合。其工作者交互图 $G = G_A = ([W], E)$ 的顶点集为 $[W]$；当存在 $t \in \mathbb{N}$ 使 $(i, t), (j, t) \in A$ 时，工作者 i, j 相连，即 $(i, j) \in E$。

众包标签恢复问题是：给定取值为 ± 1 的观测随机变量集合 $(Y_{w,t})_{(w,t) \in A}$，恢复真实标签 $(g_t)_t$。这里 $Y_{w,t} = Z_{w,t} g_t$，而 $(Z_{w,t})_{(w,t) \in A}$ 相互独立且满足 $\mathbb{E}[Z_{w,t}] = s_w$。

分配集合 A 上的确定性推断方法，接收观测 $(Y_{w,t})_{(w,t) \in A}$，返回 A 中每项任务的实值得分；得分的符号给出标签估计。形式上，$\gamma : \{\pm 1\}^A \to \mathbb{R}^{\mathbb{N}}$；给定 $\mathbf{Y} \in \{\pm 1\}^A$，$\gamma_t(\mathbf{Y})$ 是 $\gamma(\mathbf{Y})$ 的第 t 个分量，表示任务 t 的推断得分。推断方法面向有限分配集合。为了处理无限分配集合，定义推断方案为方法的无限序列 $\gamma^{(1)}, \gamma^{(2)}, \ldots$，其中相应方法用于 $A \cap ([W] \times [T])$。

需要时，以 $\mathbb{P}_\theta$ 的下标表示概率分布对实例的依赖，相应期望为 $\mathbb{E}_\theta$。推断方案 $\gamma = (\gamma^{(1)}, \gamma^{(2)}, \ldots)$ 在实例 θ 前 T 项任务上的平均损失为

$$L_T(\gamma;\,\theta) = \frac{1}{T}\mathbb{E}_\theta\Big[\sum_{t=1}^{T} \mathbb{I}\{\gamma_t^{(T)}(\mathbf{Y})g_t \le 0\}\Big].$$

已知技能向量 $\mathbf{s} \in [-1,\,1]^W$ 时，分配集 A 的最优推断方案记为 $\gamma^*_{\mathbf{s},A}$。下一节给出其简单显式形式。推断方案在实例 $\theta \in \Theta$ 上的平均遗憾，是相对于最优方案的超额损失：

$$R_T(\gamma;\,\theta) = L_T(\gamma;\,\theta) - L_T\big(\gamma^*_{\mathbf{s},A};\,\theta\big).$$

定义 2（一致性和可学习性）。 若对任意 $\theta \in \Theta \subset \Theta_W$，都有 $\operatorname{limsup}_{T\to\infty} R_T(\gamma) = 0$，则称该推断方案对实例集 Θ 渐近一致。若存在一致推断方案，则称 Θ 渐近可学习。

3.1 两步插入式方法

我们先估计技能，再通过插入式分类器预测真实标签。其动机来自以技能估计误差刻画准确性的已有结果。为便于说明，回顾其中若干结果。

定义由参数向量 $\alpha \in (-1,\,1)^W$ 参数化的对数优势比加权多数投票：

$$\gamma_{t,\alpha}(\mathbf{Y}) = \sum_{i:(i,t)\in A} \upsilon(\alpha_i) Y_{i,t}, \qquad \upsilon(\alpha) = \log\frac{1+\alpha}{1-\alpha}.$$

Nitzan & Paroush（1981）证明，最优决策规则 $\gamma^*_{\mathbf{s},A}$ 对每个 $t \in \mathbb{N}$ 都单独最小化误差概率 $\mathbb{P}\big(\gamma_{t,\mathbf{s}}(\mathbf{Y})g_t \le 0\big)$，其形式正是上式取 $\boldsymbol{\alpha} = \mathbf{s}$，权重 $\upsilon_i^* = \upsilon(s_i)$。

已知技能时，Berend & Kontorovich（2014）利用所谓委员会势能给出了误差上界与渐近匹配的下界。技能仅近似已知时，Szepesvári（2015）及 Berend & Kontorovich（2014）也给出了类似结果。

引理 1。 对任意 $\epsilon > 0$，估计权重 $\widehat{\upsilon}_i = \upsilon(\widehat{s}_i)$ 的损失满足

$$\frac{1}{T}\mathbb{E}_\theta\Big[\sum_{t=1}^{T} \mathbb{I}\{\gamma_{t,\widehat{\mathbf{s}}}(\mathbf{Y})g_t \le 0\}\Big] \le \frac{1}{T}\mathbb{E}_\theta\Big[\sum_{t=1}^{T} \mathbb{I}\{\gamma^*(\mathbf{Y})g_t \le \epsilon\}\Big] + \mathbb{P}_\theta\Big(\,\|\,\mathbf{v}^* - \widehat{\mathbf{v}}\,\|_{\,1} \ge \epsilon\Big).$$

误差 $\|\,\mathbf{v}^* - \widehat{\mathbf{v}}\,\|_{\,1}$ 可由技能估计的乘性差异来界定（见 Berend & Kontorovich, 2014）。

引理 2。 假设 $\frac{1+\widehat{s}_i}{1+s_i},\ \frac{1-\widehat{s}_i}{1-s_i} \in \big[1-\delta_i,\ 1+\delta_i\big]$，则 $|\upsilon(s_i) - \upsilon(\widehat{s}_i)| \le 2|\delta_i|$。

这些结果表明，具有技能估计精度保证的插入式估计器，也能给出真实标签预测错误概率的界。这就是技能估计问题的动机。

4 加权最小二乘估计

本节针对不规则任务分配提出渐近一致的技能估计器。不规则不仅指每项任务只有部分工作者提供标签，更重要的是交互图并非团，而且工作者共同处理任务的次数差异很大。

回顾实例 $\theta = (\mathbf{s},\ A,\ \mathbf{g})$ 的学习数据是稀疏矩阵 $(Y_{i,t})_{(i,t)\in A}$，其元素为独立二元随机变量，满足 $Y_{i,t} = g_t Z_{i,t}$ 和 $s_i = \mathbb{E}(Z_{i,t})$。定义矩阵 $\mathbf{N} \in \mathbb{N}^{W\times W}$，其中 $i \neq j$ 时，条目为工作者 $i,\ j$ 共同标注任务的次数：

$$N_{ij} = |\{t \in \mathbb{N} : (i,\ t),\ (j,\ t) \in A\}|.$$

并令 $N_{ii} = 0$。交互图 $G = ([W],\ E)$ 中 $(i,\ j) \in E$ 当且仅当 $N_{ij} > 0$。若 A 无限，N_{ij} 可以为无穷。此时定义 $N_{ij}(T) = |\{t \in [T] : (i,\ t),\ (j,\ t) \in A\}|$（$i \neq j$），且 $N_{ii}(T) = 0$。

设实例有限。当 $(i,\ t),\ (j,\ t) \in A$ 时，由 $g_t^2 = 1$ 和独立性假设，$\mathbb{E}\left[Y_{i,t}Y_{j,t}\right] = s_i s_j$。因此用下式估计技能：

$$\tilde{\mathbf{s}} = \operatorname*{argmin}_{\mathbf{x}\in[-1,+1]^W} \frac{1}{2} \sum_{(i,t),(j,t)\in A} \left(Y_{i,t}Y_{j,t} - x_i x_j\right)^2. \qquad (1)$$

某名工作者的技能估计所受约束项数，与其合作对象数量同向变化。这在直觉上合理：工作者与他人共同工作的次数越多，我们获得的技能信息就应越多。

该目标还有一个很有用的等价形式，也是算法和分析的基础。定义 $C_{ij} = s_i s_j$，并令

$$\widetilde{C}_{ij} = \frac{1}{N_{ij}} \sum_{(i,t),(j,t)\in A} Y_{i,t}Y_{j,t}. \qquad (2)$$

引理 3。定义 $\mathcal{L} : [-1,\ 1]^W \to [0,\ \infty)$：

$$\mathcal{L}(\mathbf{x}) = \frac{1}{2} \sum_{(i,j)\in E} N_{ij}\left(\widetilde{C}_{ij} - x_i x_j\right)^2.$$

式（1）等价于 $\operatorname{argmin}_{\mathbf{x}\in[-1,+1]^W}\mathcal{L}(\mathbf{x})$。基于简单代数的证明见附录 A；证明实际表明，两个目标仅差一个常数。

此目标可以视为 Gabriel & Zamir（1979）最先提出的加权低秩目标：用 $\mathbf{x}\mathbf{x}^\top$ 近似 $\widetilde{\mathbf{C}}$，第 $(i,\ j)$ 项误差按 N_{ij} 加权。这种加权合理，因为 $\widetilde{C}_{ij}$ 的方差为 $1/N_{ij}$；最小二乘理论提示，合并异方差（方差不等）数据时，各项应按数据方差的倒数加权。由于 $N_{ii} = 0$，权重矩阵一般可能满秩，此时一般加权秩一优化为 NP 难问题（Gillis & Glineur, 2011）。不过，数据的特殊结构可能绕开该难度：一方面，数据增加时，$\widetilde{\mathbf{C}}$ 本身接近秩一；另一方面，我们对权重矩阵施加自然且为可识别性所必需的约束。该约束实质上要求：以 $N_{ij} = \infty$ 为连边条件的极限交互图不可约且非二部。

译注（记号规范化）。原文在独立性论证处写作 $\mathbb{E}\left[Y_{i,t},\ Y_{j,t}\right]$，使用逗号而非乘号；结合式（1）和（2）的乘积相关性，此处译为 $\mathbb{E}\left[Y_{i,t}Y_{j,t}\right]$。原文又称单个条目 $\widetilde{C}_{ij}$ “接近秩一”；秩是矩阵的属性，故此处将其规范表述为矩阵 $\widetilde{\mathbf{C}}$ 接近秩一。这两处是译者根据上下文作的记号澄清，不是原文逐字记号。

4.1 插入式投影梯度下降

为求解加权最小二乘目标，我们提出投影梯度下降（PGD，参见第 4 节）。每一步依次沿损失 $\mathcal{L}$ 的负梯度更新技能：

$$\tilde{s}_i^{t+1} = s_i^t + \gamma \sum_{(i,j)\in E} N_{ij}\left(\widehat{C}_{ij} - s_i^t s_j^t\right)s_j^t, \qquad s_i^{t+1} = \mathcal{P}\left(\tilde{s}_i^{t+1}\right).$$

其中投影 $\mathcal{P}:\mathbb{R}\to\left[-1+\tau/\sqrt{N_i},\ +1-\tau/\sqrt{N_i}\right]$ 将输入截断到该区间；$\gamma>0$ 是步长，$N_i=|\{t:(i,t)\in A\}|$ 是工作者 i 标注的任务数，$\tau>0$ 是调节参数。

投影旨在远离超立方体边界，因为对数优势比在那里变化很快。接近 1 的技能会对插入式规则产生压倒性影响，而估计不确定性以 $\mathrm{const}\times e^{-\tau^2}$ 的概率按 $\tau/\sqrt{N_i}$ 缩放，因此将参数限制在适当缩小的超立方体内，对精度影响很小。原则上可以调整参数，但本文取 $\tau=1$。

技能向量只能识别到整体符号。为破除对称性，本文假定真实技能满足 $\sum_i s_i>0$。算法最后在必要时反转估计向量符号，确保总技能为正。

算法 1：插入式投影梯度方案

输入：$\mathbf{N}$、$\mathbf{Y}=(Y_{i,t})_{(i,t)\in A}$、$\eta,\tau>0$。

1. 初始化 $x_i\sim U[-1,1]$，$N_i=\sum_j N_{ij}$。
2. 对所有 $N_{ij}>0$，计算 $\widetilde{C}_{ij}\leftarrow N_{ij}^{-1}\sum_{(i,t),(j,t)\in A}Y_{i,t}Y_{j,t}$。
3. 重复以下循环，直到 $\mathbf{x}$ 收敛。对 $i=1,\dots,W$：

$$x_i \leftarrow x_i + \eta\sum_{j\in[W]} N_{ij}\widetilde{C}_{ij}x_j - \eta\sum_{j\in[W]} N_{ij}x_i x_j^2;$$
$$x_i \leftarrow \min\{x_i,\ 1-\tau/\sqrt{N_i}\}, \qquad x_i \leftarrow \max\{x_i,\ -1+\tau/\sqrt{N_i}\}.$$

1. $\hat{\mathbf{s}}\leftarrow \mathrm{sgn}\left(\sum_{i\in[W]}x_i\right)\mathbf{x}$。
2. 对 $t=1,\dots,T$，$\widehat{Y}_t\leftarrow\sum_{i\in[W]}Y_{i,t}\log\frac{1+\hat{s}_i}{1-\hat{s}_i}$。
3. 返回 $\left(\widehat{Y}_t\right)_{t\in[T]}$。

译注。 本文保留正文与算法中 N_i 的两种定义；原文算法输出的是投票得分，标签由其符号给出。原文对矩阵 $\mathbf{N}$ 的自然数取值描述与零对角约定并存，未在此改写。

5 理论结果

本节推导理论结果，说明任务分配所诱导交互图必须具有何种基本结构，才能在数据缺失时保证可学习性；随后分析 PGD 收敛性质。

5.1 可学习性

在保持交互图固定时，可用不同方式使任务数趋向无穷。

情形 A。 固定 $G = ([W], E)$，考虑满足最小共享任务数 $T_{\min}(T) = \min_{(i,j)\in E} N_{ij}(T) \to \infty$ 的分配集合。此时，可学习性是交互图的性质。

情形 B。 从无限分配集合 A 出发，定义 $G_A^{\infty} = ([W], E)$，仅当 $N_{ij} = \infty$ 时连边。即依据工作者交互有限次还是无限次定义连接性。

我们采用第二种稍更一般的方法：它允许某些工作者只交互有限次，第一种则不允许。因此，固定分配集 A，考虑共享此分配的实例集合 Θ。为表达对任务真实标签完全无知，结果针对“真值完备”实例集合：任意 $\theta = (\mathbf{s}, A, \mathbf{g}) \in \Theta$ 都要求 $\Theta_{\mathbf{s},A} \subset \Theta$，其中 $\Theta_{\mathbf{s},A} = \{(\mathbf{s}, A, \mathbf{g}) : \mathbf{g} \in \{-1, +1\}^{\mathbb{N}}\}$。

推断问题具有固有对称性：实例 $(\mathbf{s}, A, \mathbf{g})$ 与 $(-\mathbf{s}, A, -\mathbf{g})$ 对观测 $\mathbf{Y}$ 赋予相同似然。因此，若不排除这些对称解，实例集合就不可学习。为表达相关条件，定义 $S(\Theta) = \{\mathbf{s} \in [-1, 1]^W : (\mathbf{s}, A, \mathbf{g}) \in \Theta\}$。对技能向量，令 $P(\mathbf{s}) = \{i \in [W] : s_i > 0\}$ 为正技能工作者集合，并令 $\mathcal{P}(\mathbf{s}) = \{P(\mathbf{s}), P(-\mathbf{s})\}$ 表示正、负技能工作者的不完全划分；零技能工作者不在其中。若存在 $\mathbf{s} \in [-1, 1]^W$ 和 $\alpha > 1$ 满足 $\times_{i\in[W]}\{\alpha s_i, s_i/\alpha\} \subset S(\Theta)$，则称 Θ 是丰富的。

定理 1（可学习性刻画）。 固定无限分配集合 A，假定 $G = G_A^{\infty}$ 连通。则定义在 A 上的丰富、真值完备实例集 $\Theta \subset \Theta_A$ 可学习，当且仅当：

（i）对任意 $\mathbf{s}, \mathbf{s}' \in S(\Theta)$，若 $|\mathbf{s}| = |\mathbf{s}'|$ 且 $\mathcal{P}(\mathbf{s}) = \mathcal{P}(\mathbf{s}')$，则 $\mathbf{s} = \mathbf{s}'$；

（ii）图非二部，即含有奇环。

丰富性确保技能存在足够歧义。条件（i）要求由 $|\mathbf{s}|$ 及哪些分量同号、哪些为零这一信息唯一确定 $\mathbf{s}$。例如，若限制 Θ 只包含分量和为正的技能向量，则满足此条件；本文后文采用该条件。

定理的正向论证依赖以下结果。

引理 4。 对任意 $\mathbf{g} \in \{\pm 1\}$、$\mathbf{s} \in [-1, 1]^W$，以及极限交互图 G_A^{∞} 连通且非二部的分配集，都存在估计 $|\mathbf{s}|$ 与 $\mathcal{P}(\mathbf{s})$ 的方法。

反向蕴含来自下述结果。

引理 5。 假定 G 中所有环长度均为偶数，则存在 $\mathbf{s}, \mathbf{s}' \in [-1, 1]^W$，$\mathbf{s} \notin \{-\mathbf{s}', \mathbf{s}'\}$，使 $C_{ij} = s_i s_j = s_i' s_j'$。

有限任务可学习性。 顺便指出，渐近可学习性是基本要求；若不满足，就不可能获得合理的有限时间结果。

5.2 PGD 算法的收敛性

上一节表明，可学习性要求极限交互图 G_A^{∞} 连通且非二部。现在证明这些假设下，PGD 在含噪与无噪两种情形收敛到唯一极小值。无噪是指引理 3 的损失中，对 $(i, j) \in E$ 置 $\widetilde{C}_{ij} = C_{ij} = s_i s_j$。奇环条件与连通性一起等价于交互计数矩阵 $\mathbf{N}$ 不可约且非周期。我们证明此时损失具有唯一极小值，且 PGD 恢复技能向量。

定理 2。 当所有 $s_i > 0$，且在正正交象限初始化时，第 4 节 PGD 算法在定理 1 条件（i）、（ii）下，于无噪情形收敛到全局极小值。此外，在相同条件下，对任意 C_{ij}，可通过后处理步骤唯一恢复技能向量。

证明分析损失 $\mathcal{L}$ 的临界点，具体检验是否存在 $\mathbf{x} \neq \mathbf{s}$，使每个 $i = 1, \ldots, W$ 都满足

$$\sum_{j=1}^{W} N_{ij}\left(x_i x_j - s_i s_j\right)x_j = 0. \qquad (3)$$

我们论证，当交互矩阵 $\mathbf{N} = \left[N_{ij}\right]$ 不可约且非周期时，满足方程的两个点只有 $\mathbf{x} = \mathbf{s}$ 和 $\mathbf{x} = -\mathbf{s}$；再利用先验 $\sum_i s_i > 0$ 排除错误平衡点。图 1 说明证明的关键思想。无噪定理对交互限制很少：不限制每人任务数、总任务数，也不要求同步分配。实际上，每项任务可以仅涉及两名工作者，PGD 仍收敛到技能向量。

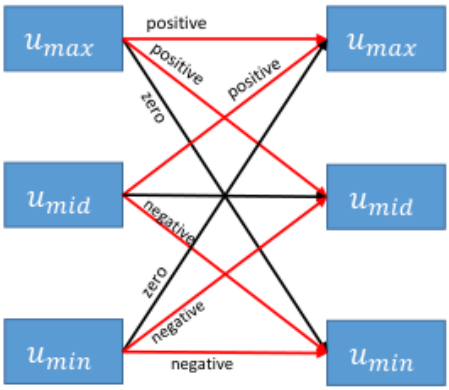


图 1：定理 2 证明示意。 PGD 平衡点对应 $\sum_j \widetilde{N_{ij}}\left(u_i u_j - 1\right) = 0$，其中 $u_i = x_i/s_i$，$\widetilde{N_{ij}} = N_{ij}s_i s_j$；在 $s_i > 0$ 时该矩阵不可约且非周期。将顶点分为三组：（i）$u_i = u_{\max} = \max_i x_i/s_i$；（ii）$u_i = u_{\min} = \min_i x_i/s_i$；（iii）其他顶点，并考虑 $u_{\max}u_{\min} = 1$。从顶点 j 到 k 的边标注为 $u_j u_k - 1$ 的符号。证明指出，正边（positive，$u_j u_k > 1$）与负边（negative，$u_j u_k < 1$）相应的 $\widetilde{N_{jk}}$ 必须为零，从而仅留下黑边构成的二部图，产生矛盾。图中 mid 表示中间组。

接下来推广到含噪情形。首先，渐近一致性是定理 2 的直接推论。

推论 1。 若权重为 $\rho_{ij} = \lim_{T\to\infty} N_{ij}(T)/T > 0$ 的极限交互图不可约且非周期，则技能估计渐近一致。证明由 $\widetilde{C_{ij}} \to C_{ij}$ 得到。

含噪观测。 令 $\widetilde{C_{ij}} \neq C_{ij}$，并以 $W \times W$ 矩阵 $\mathbf{\Delta} = \left[\Delta_{ij}\right]$ 满足 $C_{ij} = \widetilde{C_{ij}} + \Delta_{ij}$。利用局部强凸性，以 $\mathbf{\Delta}$ 界定技能估计误差。考虑带扰动的 PGD 平衡点：

$$\sum_{j=1}^{W} N_{ij}\left(x_i x_j - s_i s_j + \Delta_{ij}\right)x_j = 0,$$

$$\Rightarrow \quad \sum_{j=1}^{W} N_{ij}\left(x_i x_j - s_i s_j\right)x_j = \sum_{j=1}^{W} N_{ij}\Delta_{ij}x_j. \qquad (4)$$

令 f 表示 $\widetilde{C}_{ij}=s_is_j$ 时的无噪目标 $\mathcal{L}$。最后等式左侧是 $\nabla f(\mathbf{x})$。所以，若 $\mathbf{x}$ 是 $\mathcal{L}$ 的驻点且远离零，则其 ∇f 很小。因为 $\mathbf{s}$ 是 f 的极小点，$\nabla f(\mathbf{s})=0$。若 f 在 $\mathbf{s}$ 邻域强凸，则至少在扰动足够小时，$\mathbf{x}$ 接近 $\mathbf{s}$。为证明强凸性，写为 $\nabla^2 f(\mathbf{x})=\mathbf{D_s}\mathbf{P}(\mathbf{x}/\mathbf{s})\mathbf{D_s}$，其中原文给出 $P_{ii}(\mathbf{x})=\sum_j 2N_{ij}x_i^2$，$P_{ij}(\mathbf{x})=4N_{ij}x_ix_j-2N_{ij}$（$i\neq j$）。$\mathbf{P}(\mathbf{1})$ 为所谓无符号拉普拉斯矩阵，因而正定（Desai & Rao, 1994，命题 2.1）。再利用连续性完成论证，得到以下定理，详证见附录。

定理 3。 假设交互矩阵满足定理 2 的条件。则每个 $\epsilon\in(0,\,1)$ 都存在常数 $c_\epsilon>0$，使任意 $\mathbf{\Delta}\in\mathbb{R}^{W\times W}$、$\mathbf{x}\in\mathbb{R}^W$，若 $\|\,\mathbf{\Delta}\,\|\le c_\epsilon$，$\mathbf{x}$ 为式（4）的解，且 $\min_i|x_i|\ge\epsilon$、$\max_i|x_i|\le 1$，则

$$\|\,\mathbf{x}-\mathbf{s}\,\|\;\le\;\frac{\|\,\mathbf{N}\,\|_F\,\|\,\mathbf{\Delta}\,\|}{s_{\min}^2\sigma_{\min}(\mathbf{P}(\mathbf{1}))},\qquad s_{\min}=\min_i|s_i|.$$

分子 $\|\,\mathbf{N}\,\|_F$ 与分母中 $\mathbf{P}(\mathbf{1})$ 的最小特征值 $\sigma_{\min}(\mathbf{P}(\mathbf{1}))$ 都随任务数线性缩放。定理说明，小扰动下驻点解误差与 $\|\,\mathbf{\Delta}\,\|_2$ 成比例，比例常数由最小技能的平方倒数和该最小特征值决定。后者刻画带权图距“二部图”的程度（Desai & Rao, 1994）。

有限任务界。 可直接应用该结果得到有限任务刻画。考虑连通非二部交互图，定义最小共享任务数 $T_{\min}=\min_{(i,j)\in E}N_{ij}$，最大度 $d_{\max}$，度数总和 D。标准 Hoeffding 界给出，以大于 $1-\delta$ 的概率，

$$\max_{(i,j)\in E}|C_{ij}-\widehat{C}_{ij}|\le\frac{\log(D/\delta)}{\sqrt{N_{\min}}}.$$

令扰动为 $C_{ij}-\widehat{C}_{ij}$，应用 Gershgorin 圆盘定理，以大于 $1-\delta$ 的概率有 $\|\,\mathbf{\Delta}\,\|\le d_{\max}\log(D/\delta)/\sqrt{N_{\min}}$。代入定理 3 得到同概率下

$$\|\,\mathbf{x}-\mathbf{s}\,\|\;\le\;\frac{d_{\max}\log(D/\delta)\,\|\,\mathbf{N}\,\|_F}{s_{\min}^2\sigma_{\min}(\mathbf{P}(\mathbf{1}))\sqrt{T_{\min}}}.$$

译注（保留原文差异）。 式（4）的移项符号按原文保留，首行若按通常代数移项，右侧应出现负号；其范数界不受整体符号影响。正文 Hessian 对角项写作 x_i^2，附录 D 写作 x_k^2。原文在有限任务界中混用 $N_{\min}$ 与 $T_{\min}$。这些差异未静默改正；上述收敛与唯一性叙述为原文主张。

6 实验结果

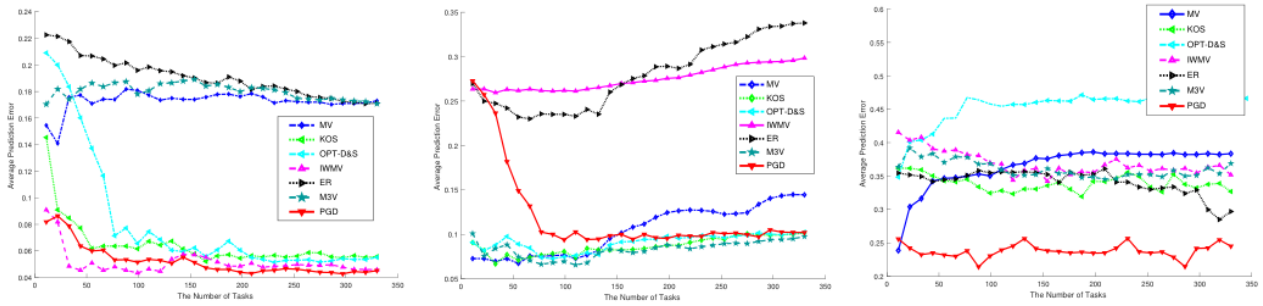
合成实验。 我们考察不同图类型、标签噪声水平、图规模、技能分布和权重函数。图规模、技能分布和权重的结果见补充材料；这里描述图类型与噪声实验。

图类型的影响。 考虑三个含 11 个顶点（工作者）的不可约非二部图：团（G_1）、增加奇环的星形图（G_2）和环（G_3）。它们用于展示稀疏性影响（团中交互稠密，而星形图/环的工作者交互少于 3）和图类型差异（环与星形图）。这些图满足定理 1 条件（ii）。

噪声鲁棒性。 增加任务数会降低相关矩阵误差，由此改变噪声水平。任务随机分配到二元类别 ±1，总任务数从 11 到 330。技能在 0.8 与 -0.3 之间的均匀网格上随机分配。[3]

我们比较平均预测误差 $PE = T^{-1}\sum_{t=1,..,T}\mathbb{1}\{\widehat{Y}_t \neq g_t\}$，对手包括多数投票 MV、KOS（Karger et al., 2013）、Opt-D&S（Zhang et al., 2014）、ER（Dalvi et al., 2013）、IWMV（Li & Yu, 2014）及 M3V（Tian & Zhu, 2015）。KOS 基于信念传播；Opt-D&S 用谱方法初始化 EM；ER 是其原论文中效果较好的谱方法；IWMV 是 EM 风格算法。每个算法在每个数据集上运行 15 次取平均，结果见图 2。随着任务增多，PGD 平均预测误差下降，明显对缺失数据、稀疏性及图类型稳健。性能接近 PGD 的 OPT-DS 在环等稀疏图上显著下降，可归因于其张量方法要求每项任务至少有 3 名工作者标注（Zhang et al., 2014）。

[3] 这样选择是为满足定理 1 条件（i），即总技能为正；平均技能约为 0.25。



(a) Clique. (b) Star graph with 3-cycle. (c) Ring.

图 2：三种图上的预测性能比较。（a）团（Clique）；（b）含三环的星形图（Star graph with 3-cycle）；（c）环（Ring）。**译者说明：** 横轴为任务数，纵轴为平均预测误差。**原图注续：** 为清楚展示，仅绘均值。团在 11 项任务时，MV、KOS、OPT-D&S、PGD、ER、IWMV、M3V 的标准差依次为 0.09、0.10、0.14、0.14、0.19、0.09、0.09；330 项任务时依次为 0.02、0.01、0.017、0.014、0.012、0.013、0.018。星形图在 11 项任务时，相同顺序的标准差为 0.09、0.13、0.13、0.06、0.13、0.09、0.07；330 项任务时为 0.016、0.015、0.013、0.012、0.04、0.03、0.013。环在 11 项任务时为 0.096、0.05、0.08、0.1、0.11、0.09、0.08；330 项任务时为 0.017、0.05、0.02、0.043、0.05、0.086、0.05。标准差随任务数增多而下降。

基准数据实验。 我们将 PGD 与先进算法比较，各算法在 RTE1（Snow et al.）、Temp（Snow et al.）、Dogs（Deng et al., 2009）和 WebSearch（Zhou et al., 2012）上运行，按惯例报告真实标签与恢复标签的错误率。表 1 汇总数据；RTE1 和 Temp 是二元标签，可直接应用本算法。

多分类数据。 对 Dogs 和 Web，假设类别独立模型决定工作者翻转真值的概率，对每类采用一对其余策略。对类别 $k \in \mathcal{K}$ 计算条件技能得分

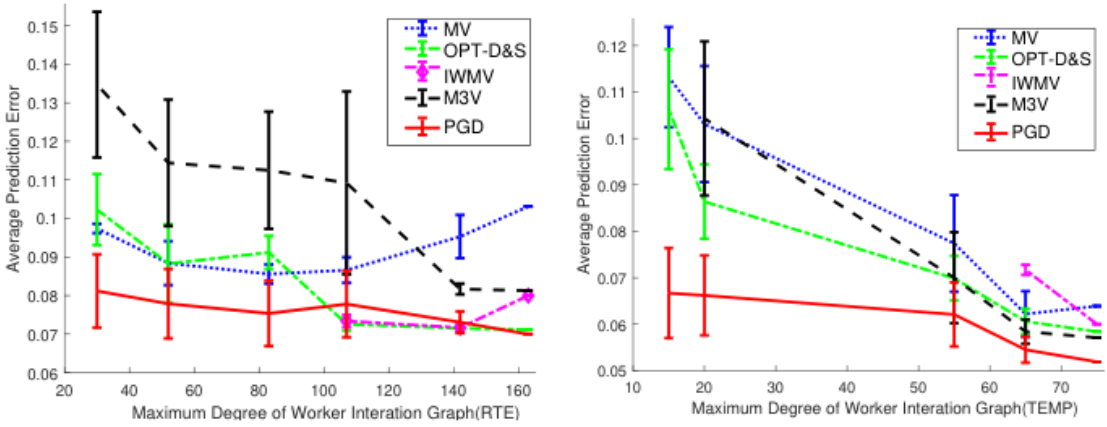
$$\text{score}(k) = \sum_{(i,t)\in A} \log\frac{1+s_i}{1-s_i}\,\mathbb{1}\big(Y_{i,t} = k\big),$$

其中 $\mathbb{1}(\cdot)$ 为取 ± 1 的指示函数，以最大得分对应类别为预测。还考虑密切相关的方法（Li & Yu, 2014；另见补充材料）：翻转后的真实标签随机分配到其他类别之一。由于混淆矩阵由单一技能参数刻画，该情形的技能和标签估计是本方案的直接推广。表 1 报告这两种设定中的较好结果；PGD 一致优于先进算法。

表 1：基准数据及不同方法预测错误率。

数据集	任务数	工作者	实例数	类别数	稀疏水平
RTE1	800	164	8000	2	0.0610
Temp	462	76	4620	2	0.1316
Dogs	807	109	8070	4	0.0917
Web	2665	177	15567	5	0.0033

数据	PGD	MV	Opt-D&S	KOS	ER	IWMV	M3W
RTE1	0.07	0.1031	0.0712	0.3975	0.14	0.08	0.0813
Temp	0.0512	0.0639	0.0584	0.0628	0.052	0.06	0.0606
Dogs	0.1660	0.1958	0.1689	0.3172	0.18	0.19	0.1822
Web	0.1485	0.2693	0.1586	0.4293	0.22	0.22	0.1847



(a) RTE1. (b) TEMP.

图 3：图稀疏化的影响。 （a）RTE1；（b）TEMP。**译者说明：** 横轴为工作者交互图最大度，纵轴为平均预测误差；曲线为 MV、OPT-D&S、IWMV、M3V 和 PGD。

图稀疏化影响。 在二分类基准上，我们考虑每项任务由更少工作者标注的情形。二分类任务与理论一致，实验突显稀疏分配下先进算法的表现。用随机稀疏化模拟这一效应：先按交互图顶点度排序，再从最高度顶点开始随机删除边，对其他顶点继续，直到得到目标最大度。为保持对称性，也对称删除相接工作者的对应边。这还会隐式删除一些任务，例如仅有两名工作者标注的任务。稀疏化越强，可训练任务越少。对不同目标最大度，运行 PGD 和其他算法各 50 次蒙特卡洛试验，平均错误率见图 3。IWMV 表现差是因为其依赖的多数投票已不可靠。PGD 对交互稀疏化出乎意料地稳健，相比其他方案平缓退化，说明它能利用工作者间稀疏交互，对准确预测所需技能得到较稳健的估计。

时间复杂度。 我们还比较时间复杂度。与其他迭代法相比，PGD 所需迭代较少，每次迭代随工作者数 W 与交互图最大度 $D_{\max}$ 线性缩放，其中 $D_{\max} \le W$。表 2 汇总复杂度。[4]

表 2：不同方法每次迭代的时间复杂度。

算法	PGD	IWMV	M3W
复杂度	$O(D_{\max}W)$	$O(TW)$	$O(W^2T)$

[4] 省略 Opt-D&S、KOS、ER；这些算法使用谱分解，时间复杂度较高。表中 M3W 与正文 M3V 的名称差异按原文保留。

7 结论

我们提出基于加权秩一近似的新矩匹配方法，并提出梯度算法估计众包工作者技能。与既有工作不同，权重用于校正工作者间一致性测量精度的离散程度；在谁与谁共同处理任务不可控的真实问题中，这种差异很常见。结果用谱图论量显式刻画可识别性与收敛率，揭示交互图对技能估计的重要性。本文的一般问题与间歇及主动传感器通信下的状态估计相关（Saligrama & Castanon, 2006；Hanawal et al., 2017），我们计划在未来探索。

致谢

本工作受 Venkatesh Saligrama 教授项目支持：NSF CCF:1320566、CNS:1330008、CCF:1527618，以及 ONR N00014-18-1-2257。

参考文献

以下保留原文书目信息、作者、年份、题名、页码与 DOI；英文题名不替换，以确保检索准确。

Albert, P. S. and Dodd, L. E. A cautionary note on the robustness of latent class models for estimating diagnostic error without a gold standard. Biometrics, 60(2):427-435, 2004.

Berend, D. and Kontorovich, A. Consistency of weighted majority votes. In NIPS, pp. 3446-3454, 2014.

Bonald, T. and Combes, R. Crowdsourcing: Low complexity, minimax optimal algorithms. arXiv preprint arXiv 1606.00226, 2016.

Dalvi, N., Dasgupta, A., Kumar, R., and Rastogi, V. Aggregating crowdsourced binary ratings. In WWW, pp. 285-294, 2013.

Dawid, A. P. and Skene, A. M. Maximum likelihood estimation of observer error-rates using the EM algorithm. Applied Statistics, 28(1):20-28, 1979.

Deng, J., Dong, W., Socher, R., Li, L.-j., Li, K., and Fei-fei, L. Imagenet: A large-scale hierarchical image database. In In CVPR, 2009.

Desai, M. and Rao, V. A characterization of the smallest eigenvalue of a graph. J. Graph Theory, 1994.

Gabriel, K. R. and Zamir, S. Lower rank approximation of matrices by least squares with any choice of weights. Technometrics, 21(4):489-498, November 1979. ISSN 0040-1706. doi: 10.1080/00401706.1979.10489819.

Gao, C. and Zhou, D. Minimax optimal convergence rates for estimating ground truth from crowdsourced labels. arXiv preprint arXiv:1310.5764, 2013.

Gao, C., Lu, Y., and Zhou, D. Exact exponent in optimal rates for crowdsourcing. In ICML, pp. 603-611, 2016.

Ge, R., Lee, J. D., and Ma, T. Matrix completion has no spurious local minimum. In Lee, D. D., Sugiyama, M., Luxburg, U. V., Guyon, I., and Garnett, R. (eds.), Advances in Neural Information Processing Systems 29, pp. 2973-2981. Curran Associates, Inc., 2016.

Ghosh, A., Kale, S., and McAfee, P. Who moderates the moderators? crowdsourcing abuse detection in user-generated content. In Proc. of the 12th ACM conference on Electronic commerce, pp. 167-176, 2011.

Gillis, N. and Glineur, F. Low-rank matrix approximation with weights or missing data is NP-hard. SIAM J. Matrix Analysis Applications, 32(4):1149-1165, 2011.

Hanawal, M. K., Szepesvári, C., and Saligrama, V. Unsupervised sequential sensor acquisition. In Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, AISTATS 2017, 20-22 April 2017, Fort Lauderdale, FL, USA, pp. 803-811, 2017.

Hui, S. L. and Walter, S. D. Estimating the error rates of diagnostic tests. Biometrics, pp. 167-171, 1980.

Karger, D., Oh, S., and Shah, D. Efficient crowdsourcing for multi-class labeling. In SIGMETRICS, pp. 81-92, 2013.

Karger, D., Oh, S., and Shah, D. Budget-optimal task allocation for reliable crowdsourcing systems. Operations Research, 62(1):1-24, 2014.

Karger, D. R., Oh, S., and Shah, D. Iterative learning for reliable crowdsourcing systems. In NIPS, pp. 1953-1961, 2011.

Koren, Y., Bell, R., and Volinsky, C. Matrix factorization techniques for recommender systems. Computer, 2009.

Li, H. and Yu, B. Error rate bounds and iterative weighted majority voting for crowdsourcing. 11 2014.

Liu, Q., Peng, J., and Ihler, A. T. Variational inference for crowdsourcing. In NIPS, pp. 692-700, 2012.

Nesterov, Y. Introductory Lectures on Convex Optimization. Kluwer Academic Publishers, 2004.

Nitzan, S. and Paroush, J. The characterization of decisive weighted majority rules. Economics Letters, 7(2):119-124, 1981.

Raykar, V. C., Yu, S., Zhao, L. H., Valadez, G. H., Florin, C., Bogoni, L., and Moy, L. Learning from crowds. Journal of Machine Learning Research, 11:1297-1322, 2010.

Saligrama, V. and Castanon, D. A. Reliable distributed estimation with intermittent communications. In Proceedings of the 45th IEEE Conference on Decision and Control, Dec 2006.

Shapley, L. and Grofman, B. Optimizing group judgmental accuracy in the presence of interdependencies. Public Choice, 43(3):329-343, January 1984. ISSN 0048-5829, 1573-7101. doi: 10.1007/BF00118940.

Smyth, P., Fayyad, U., Burl, M., Perona, P., and Baldi, P. Inferring ground truth from subjective labelling of venus images. In NIPS, volume 7, pp. 1085-1092, 1995.

Snow, R., O’ Connor, B., Jurafsky, D., and Ng, A. Y. Cheap and fast—but is it good?: Evaluating non-expert annotations for natural language tasks. In Proceedings of the Conference on Empirical Methods in Natural Language Processing, EMNLP ’ 08, pp. 254-263, Stroudsburg, PA, USA. Association for Computational Linguistics.

Srebro, N. and Jaakkola, T. Weighted low-rank approximations. In Proceedings of the 20th International Conference on Machine Learning (ICML-03), pp. 720-727, 2003.

Szepesvári, D. A statistical analysis of the aggregation of crowdsourced labels. Master’ s thesis, University of Waterloo, 2015.

Tian, T. and Zhu, J. Max-margin majority voting for learning from crowds. In Cortes, C., Lawrence, N. D., Lee, D. D., Sugiyama, M., and Garnett, R. (eds.), Advances in Neural Information Processing Systems 28, pp. 1621-1629. Curran Associates, Inc., 2015.

Zhang, Y., Chen, X., Zhou, D., and Jordan, M. Spectral methods meet EM: A provably optimal algorithm for crowdsourcing. In NIPS, pp. 1260-1268, 2014.

Zhang, Y., Chen, X., Zhou, D., and Jordan, M. I. Spectral methods meet EM: A provably optimal algorithm for crowdsourcing. The Journal of Machine Learning Research, 17(1):3537-3580, 2016.

Zhou, D., Basu, S., Mao, Y., and Platt, J. Learning from the wisdom of crowds by minimax entropy. In NIPS, pp. 2195-2203, 2012.

官方补充材料：附录

来源：https://proceedings.mlr.press/v80/ma18b/ma18b-supp.pdf 。以下为独立六页补充材料全文，保持其 A-E 节、引理及公式编号。

A 引理 3 的证明

回顾 θ 是有限实例。对于每个满足 $N_{ij} > 0$ 的 $(i,\ j)$，有

$$\begin{aligned}&\frac{1}{N_{ij}} \sum_{t:(i,t),(j,t)\in A} \left(Y_{i,t}Y_{j,t} - x_i x_j\right)^2 = \frac{1}{N_{ij}} \sum_{t:(i,t),(j,t)\in A} \left(1 - 2Y_{i,t}Y_{j,t}x_i x_j + x_i^2 x_j^2\right) \\ &= 1 - 2\widetilde{C}_{ij}x_i x_j + x_i^2 x_j^2 = \widetilde{C}_{ij}^{\,2} - 2\widetilde{C}_{ij}x_i x_j + x_i^2 x_j^2 + 1 - \widetilde{C}_{ij}^{\,2} \\ &= \left(\widetilde{C}_{ij} - x_i x_j\right)^2 + 1 - \widetilde{C}_{ij}^{\,2}.\end{aligned}$$

因此，

$$\frac{1}{2} \sum_{(i,t),(j,t)\in A} \left(Y_{i,t}Y_{j,t} - x_i x_j\right)^2 = \frac{1}{2} \sum_{i,j\in[W]} N_{ij}\left(\widetilde{C}_{ij} - x_i x_j\right)^2 + \sum_{i,j\in[W]} N_{ij}\left(1 - \widetilde{C}_{ij}^{\,2}\right).$$

由于 $\sum_{i,j\in[W]} N_{ij}\left(1 - \widetilde{C}_{ij}^{\,2}\right)$ 是常数，式（1）等价于 $\operatorname{argmin}_{\mathbf{x}\in[-1,+1]^W} \mathcal{L}(\mathbf{x})$ 。

译注。 原文最后一式常数项未带 $1/2$，本译文保留；这一常数因子不影响最小化解。

B 定理 1 的证明

证明直接来自引理 4 和引理 5。下面证明它们。

引理 4 的证明。 取图 $G = ([W],\ E)$ 中任意相连工作者 $i,\ j$，令 $t \in \mathbb{N}$ 满足 $(i,\ t),\ (j,\ t) \in A$ 。由假设，$Y_{i,t}Y_{j,t} = g_t^2 Z_{i,t}Z_{j,t} = Z_{i,t}Z_{j,t}$ 。由大数定律，

$$C_{ij} := \lim_{T\to\infty} \frac{1}{T} \sum_{(i,t),(j,t)\in A,\ t\le T} Z_{i,t}Z_{j,t} = \mathbb{E}\left[Z_i Z_j\right] = \mathbb{E}\left[Z_i\right]\mathbb{E}\left[Z_j\right] = s_i s_j,$$

其中 $(Z_i)_i \sim \prod_{i=1}^{W} \mathrm{Rad}(s_i)$ 。注意 $C_{ij} = C_{ji}$；当 $(i,\ j) \notin E$ 时定义 $C_{ij} = 0$ 。

不失一般性，假设工作者 $1,\ 2,\ \ldots,\ 2k+1$ 在图中形成环，即 $(1,\ 2),\ \ldots,\ (2k,\ 2k+1),\ (2k+1,\ 1) \in E$ 。则

$$\begin{aligned}s_1 &= C_{1,2k+1}s_{2k+1}^{-1} = C_{1,2k+1}C_{2k+1,2k}^{-1}s_{2k} \\ &= C_{1,2k+1}C_{2k+1,2k}^{-1}C_{2k,2k-1}s_{2k-1}^{-1} = \cdots = C_{1,2k+1}C_{2k+1,2k}^{-1}C_{2k,2k-1}\cdots C_{2,1}s_1^{-1},\end{aligned}$$

即

$$|s_1| = \sqrt{C_{1,2k+1}C_{2k+1,2k}^{-1}C_{2k,2k-1}\cdots C_{2,1}},$$

这里假设 $C_{2,3},\, C_{4,5},\, \dots,\, C_{2k,2k+1} \neq 0$。由于图连通，对任意工作者 i，从工作者 1 到它都存在路径。若路径顶点依次为 $1,\, 2,\, \dots,\, \ell$，则

$$
\begin{aligned}
|s_{\ell}| &= |C_{\ell,\ell-1}|\,\left|s_{\ell-1}^{-1}\right| = |C_{\ell,\ell-1}|\,\left|C_{\ell-1,\ell-2}^{-1}\right|\,|s_{\ell-2}| \\
&= \cdots = |C_{\ell,\ell-1}|\,\left|C_{\ell-1,\ell-2}^{-1}\right|\cdots\left|C_{2,1}^{(-1)^{\ell}}\right|\,|s_1|^{(-1)^{\ell+1}}.
\end{aligned}
$$

还需证明可恢复 $\mathcal{P}(\mathbf{s})$。令 $i,\, j \in [W]$ 为不同工作者，$\pi \subset E$ 是从 i 到 j 的路径，则无论如何选择 π，都有

$$
\prod_{(u,v)\in E} \operatorname{sgn}\left(C_{u,v}\right) = \prod_{(u,v)\in E} \operatorname{sgn}\left(s_u\right)\operatorname{sgn}\left(s_v\right) = \operatorname{sgn}\left(s_i\right)\operatorname{sgn}\left(s_j\right).
$$

若连接 $i,\, j$ 的某条路径 π 满足该符号乘积为 $+1$，则把两者分到同一组。图连通使分组至多两组，所得“划分”必与 $\mathcal{P}(\mathbf{s})$ 相同。

引理 5 的证明。取丰富性定义中的 $\mathbf{s},\, \alpha$，构造另外两个技能向量 $\mathbf{s}',\, \mathbf{s}''$。置 $s_1' = \alpha s_1$、$s_1'' = s_1/\alpha$。如果从工作者 1 到 i 的某条路径长度为偶数，就置 $s_i' = \alpha s_i$、$s_i'' = s_i/\alpha$；否则置 $s_i' = s_i/\alpha$、$s_i'' = \alpha s_i$。由于图连通，从 1 可到达全部工作者。若存在多条路径，它们必有相同奇偶性，否则图会含奇环。沿任意边 $(i,\, j) \in E$，$\mathbf{s}$ 和 $\mathbf{s}'$ 给出相同乘积 $s_i s_j$。按假设两者都在 Θ 中，结论得证。

定理 1 的反向证明。使用逆否命题。先假设（i）不成立，证明不可学习。可取不同技能向量 $\mathbf{s},\, \mathbf{s}' \in S(\Theta)$，满足 $|\mathbf{s}| = |\mathbf{s}'|$ 且 $\mathcal{P}(\mathbf{s}) = \mathcal{P}(\mathbf{s}')$，从而 $\mathbf{s} = -\mathbf{s}'$。任取 $\mathbf{g} \in \{\pm 1\}^{W}$，实例 $(\mathbf{s},\, A,\, \mathbf{g})$ 和 $(-\mathbf{s},\, A,\, -\mathbf{g})$ 导致观测标签的相同联合分布。因此任何推断方案都不能区分它们，必在其中一个实例上承受线性遗憾。若（ii）不成立，引理 5 给出不同且不互为正负的技能向量 $\mathbf{s},\, \mathbf{s}'$，它们同样对任意数据给出相同似然，于是任何方案也必在其中一个实例上承受线性遗憾。

译注。原文这里的大数定律分母写为 T 而非共同任务数；路径乘积的下标写为 E 而非 π；证明使用了非零相关性假设，并在标签维数上写作 W。均按原文记录，不将这些论证差异伪装成译者已经修复的结论。

C 定理 2 的证明

给定交互矩阵 $\mathbf{N}$，它非负、不可约、非周期、整数值、对称且零对角；另有 $\mathbf{s} \in \mathbb{R}^{W}$。需要论证不存在 $\mathbf{x} \notin \{\pm \mathbf{s}\}$ 使所有 $i = 1,\, \dots,\, W$ 满足

$$
\sum_{j=1}^{W} N_{ij}\left(x_i x_j - s_i s_j\right) x_j = 0. \tag{5}
$$

先引入符号。$\mathbf{D}_{\mathbf{x}}$ 表示以向量 $\mathbf{x}$ 为对角的对角矩阵；$\operatorname{diag}[\mathbf{A}]$ 表示将矩阵 $\mathbf{A}$ 对角元素堆叠为向量（这是不常见的记法）。称非负、不可约、非周期、对称且零对角的矩阵为“可容许”。

假定 $\mathbf{x}$ 满足（5）。先假定其分量均非零，零分量情形稍后处理。再作简化假设 $\mathbf{s}>0$，且寻找 $\mathbf{x}>0$。若 $\mathbf{s}$ 有负分量，总能通过 $|\mathbf{x}|$ 恢复 $|\mathbf{s}|$。假设 $s_i>0$ 时，利用图非二部的假设，可以确定 $\mathbf{s}$ 其余符号并得到一个解 $\mathbf{x}$；类似地，假设 $s_i<0$ 则得到另一个解 $-\mathbf{x}$。因为只考虑总和为正的技能向量，最优解必须是 $\{\pm\mathbf{x}\}$ 中总和为正的那个。

我们将论证，给定 $\mathbf{s}>0$，不可能找到 $\mathbf{x}>0$、$\mathbf{x}\neq\mathbf{s}$ 和可容许矩阵，使（5）成立。将第 i 个方程乘 x_i，首先可重写为

$$\operatorname{diag}\left[\mathbf{D_x N D_x}\left(\mathbf{x}\mathbf{x}^{\top}-\mathbf{s}\mathbf{s}^{\top}\right)\right]=\mathbf{0}. \qquad (6)$$

因此只需证明，不存在 $\mathbf{x}>0$、$\mathbf{x}\neq\mathbf{s}$ 和可容许 $\mathbf{F}$，使

$$\operatorname{diag}\left[\mathbf{F}\left(\mathbf{x}\mathbf{x}^{\top}-\mathbf{s}\mathbf{s}^{\top}\right)\right]=\mathbf{0}.$$

$\mathbf{x}>0$ 意味着所有 $x_i>0$，没有零分量。之所以能去掉 $\mathbf{D_x}$，是因为 $\mathbf{N}$ 可容许当且仅当 $\mathbf{D_x N D_x}$ 可容许。

由于 $x_ix_j-s_is_j=s_i\left(\frac{x_ix_j}{s_is_j}-1\right)s_j$，定义 $u_i=x_i/s_i$，于是 $\mathbf{u}>0$ 且

$$\mathbf{x}\mathbf{x}^{\top}-\mathbf{s}\mathbf{s}^{\top}=\mathbf{D_s}\left(\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}\right)\mathbf{D_s}.$$

因此需要证明，不可能找到 $\mathbf{u}>0$、$\mathbf{u}\neq\mathbf{1}$ 和可容许 $\mathbf{F}$，使

$$\operatorname{diag}\left[\mathbf{D_s F D_s}\left(\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}\right)\mathbf{D_s}\right]=\mathbf{0}.$$

由于 $\mathbf{s}>0$，只需证明不存在 $\mathbf{u}>0$、$\mathbf{u}\neq\mathbf{1}$ 和可容许 $\mathbf{Z}$，使

$$\operatorname{diag}\left[\mathbf{Z}\left(\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}\right)\right]=\mathbf{0}. \qquad (7)$$

不失一般性，重新排列指标，设 $u_1\le u_2\le\cdots\le u_W$。有三种可能：（1）$u_1u_W>1$；（2）$u_1u_W=1$；（3）$u_1u_W<1$。

逐一证明不存在满足（7）的适当 $\mathbf{u}$。情形 1 下，$\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}$ 的末列条目 u_iu_W-1 全部严格为正。由 $\left[\mathbf{Z}\left(\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}\right)\right]_{WW}=0$，$\mathbf{Z}$ 最后一行必为零，与不可约性矛盾。类似地，情形 3 下，第一列条目 u_1u_i-1 为负；由乘积的 $(1,1)$ 元素为零可知 $\mathbf{Z}$ 第一行必为零，也不可能。

只剩情形 2。考虑任意 $\mathbf{u}>0$、$\mathbf{u}\neq\mathbf{1}$。可假定 $u_1<u_W$，因为排除与全一向量成比例的解显然。将 $\{1,\ldots,W\}$ 分三块：第一块为所有 $u_j=u_1$ 的指标，第三块为所有 $u_j=u_W$ 的指标，其余放入第二块。第二块可能为空，例如每个条目都等于 u_1 或 u_W。

这样分块的优点是，矩阵具有符号结构

$$\mathbf{u}\mathbf{u}^{\top}-\mathbf{1}\mathbf{1}^{\top}=\begin{pmatrix}-&-&0\\-&*&+\\0&+&+\end{pmatrix},$$

其中负号表示严格负子矩阵，正号表示严格正子矩阵，星号表示任意符号。严格负性来自 $u_1<u_W$。对应地分块 $\mathbf{Z}$，得到

$$\operatorname{diag}\left[\begin{pmatrix}\mathbf{Z}_{11}&\mathbf{Z}_{12}&\mathbf{Z}_{13}\\ \mathbf{Z}_{21}&\mathbf{Z}_{22}&\mathbf{Z}_{23}\\ \mathbf{Z}_{31}&\mathbf{Z}_{32}&\mathbf{Z}_{33}\end{pmatrix}\begin{pmatrix}-&-&0\\ -&*&+\\ 0&+&+\end{pmatrix}\right]=\mathbf{0}.$$

考虑乘积的 $(1,\,1)$ 对角块，并利用 $\mathbf{Z}\succeq 0$，得到 $\mathbf{Z}_{11}=\mathbf{Z}_{12}=\mathbf{0}$；考虑 $(3,\,3)$ 块，得到 $\mathbf{Z}_{32}=\mathbf{Z}_{33}=\mathbf{0}$。由对称性，还有 $\mathbf{Z}_{21}=\mathbf{0}$ 与 $\mathbf{Z}_{33}=\mathbf{0}$（此处按原文重复）。于是容易得到矛盾：若中间块非空，矩阵可约；若第二块为空，矩阵具有偶数周期。至此完成 $\mathbf{x}$ 分量均非零情形的证明。

最后，$\mathbf{x}$ 含零分量时，可将驻点作为不稳定点排除。Hessian $\mathbf{P}(\mathbf{x})$ 的矩阵形式为 $\mathbf{D_s}\mathbf{P}(\mathbf{x}/\mathbf{s})\mathbf{D_s}$，其中除法逐分量进行，$\mathbf{P}$ 的定义见正文。$\mathbf{P}(\mathbf{x})$ 正（半）定当且仅当 $\mathbf{P}(\mathbf{x}/\mathbf{s})$ 正（半）定。由 $\mathbf{P}$ 的形式，只要 $\mathbf{x}$ 有零分量，$\mathbf{P}(\mathbf{x}/\mathbf{s})$ 就不是半正定。注意随机初始化的梯度算法不会收敛到非局部极小点，证明完成。

D 定理 3 的证明

固定 $\mathbf{s}\in[-1,\,1]^{W}$。令其无噪目标为

$$f(\mathbf{x})=\sum_{i<j}N_{ij}\big(x_ix_j-s_is_j\big)^2. \tag{8}$$

以 $\mathbf{P_s}(\mathbf{x})=\nabla^2 f(\mathbf{x})$ 表示 Hessian。直接计算得

$$\frac{\partial f}{\partial x_i}(\mathbf{x})=\sum_{k=1}^{W}2N_{ik}\big(x_ix_k-s_is_k\big)x_k,$$
$$(\mathbf{P_s}(\mathbf{x}))_{ii}=\frac{\partial^2 f}{\partial x_i^2}(\mathbf{x})=\sum_{k=1}^{W}2N_{ik}x_k^2,$$
$$(\mathbf{P_s}(\mathbf{x}))_{ij}=\frac{\partial^2 f}{\partial x_i\partial x_j}(\mathbf{x})=4N_{ij}x_ix_j-2s_is_jN_{ij},\qquad i\neq j.$$

因此，$\nabla^2 f(\mathbf{x})=\mathbf{D_s}\mathbf{P_1}(\mathbf{x}/\mathbf{s})\mathbf{D_s}$。正文省略下标 $\mathbf{1}$，将 $\mathbf{P_1}(\mathbf{u})$ 记为 $\mathbf{P}(\mathbf{u})$，这里沿用。回顾 $s_{\min}=\min_i|s_i|$。由 $\mathbf{P}=\mathbf{P_1}$ 连续，立即知道 f 在 $\mathbf{s}$ 足够小的邻域强凸。

引理 6。 存在正数 δ，使 f 限制在以下集合时强凸：

$$\mathcal{B}_\delta=\{\mathbf{x}\in[-1,\,1]^{W}:\ \|\,\mathbf{x}/\mathbf{s}-\mathbf{1}\,\|_{\infty}\le\delta\}.$$

特别地，任意 $\mathbf{x}\in\mathcal{B}_\delta$ 满足

$$\lambda_{\min}\big(\nabla^2 f(\mathbf{x})\big)\ge s_{\min}^2\mu,\qquad \mu=\lambda_{\min}(\mathbf{P}(\mathbf{1}))/2.$$

由 Desai & Rao（1994）命题 2.1，$\mu>0$。

证明。 显然 $\lambda_{\min}\big(\nabla^2 f(\mathbf{x})\big)\ge s_{\min}^2\lambda_{\min}(\mathbf{P}(\mathbf{x}/\mathbf{s}))$。特别地，$\lambda_{\min}\big(\nabla^2 f(\mathbf{s})\big)\ge 2s_{\min}^2\mu$。$\mathbf{P_s}$ 及其最小特征值函数连续，结论即得。

立即得到以下推论。

推论 2。 对任意 $\mathbf{x}\in\mathcal{B}_\delta$，其中 δ 如前引理，

$$\| \mathbf{x}-\mathbf{s} \| \le \frac{\| \nabla f(\mathbf{x}) \|_2}{s_{\min}^2 \mu}.$$

证明。 $\mathbf{x}=\mathbf{s}$ 时显然。否则假定 $\mathbf{x} \in \mathcal{B}_\delta$ 且不等于 $\mathbf{s}$。由于两者均在该集合，且 f 在其上为 $s_{\min}^2\mu$ -强凸（见 Nesterov, 2004，定理 2.1.9），

$$\big(\nabla f(\mathbf{x})-\nabla f(\mathbf{s})\big)^\top(\mathbf{x}-\mathbf{s}) \ge s_{\min}^2\mu \| \mathbf{x}-\mathbf{s} \|^2.$$

利用 $\nabla f(\mathbf{s})=\mathbf{0}$ 和 Cauchy-Schwarz 不等式，得到

$$\| \nabla f(\mathbf{x}) \| \ \| \mathbf{x}-\mathbf{s} \| \ge s_{\min}^2\mu \| \mathbf{x}-\mathbf{s} \|^2.$$

两边除以 $\| \mathbf{x}-\mathbf{s} \|$ 即得结论。

现在考虑满足 $\nabla \mathcal{L}(\mathbf{x})=\mathbf{0}$，且对某个 $\epsilon>0$ 有 $\min_i |x_i| \ge \epsilon$ 的 $\mathbf{x}$。用 $|\mathbf{\Delta}|$ 表示逐元素绝对值矩阵。利用 $N_{ij} \ge 0$、任意方阵都满足的 $\| \operatorname{diag}[\mathbf{A}] \|^2 = \sum_i A_{ii}^2 \le \| \mathbf{A} \|_F^2$，以及 $\max_i |x_i| \le 1$，结合（4）得到

$$\| \operatorname{diag}\left[\mathbf{N}\mathbf{D}_\mathbf{x}\left(\mathbf{x}\mathbf{x}^\top-\mathbf{s}\mathbf{s}^\top\right)\right] \| = \| \operatorname{diag}\left[\mathbf{N}\mathbf{D}_\mathbf{x}\mathbf{\Delta}\right] \| \le \| \mathbf{N}|\mathbf{\Delta}| \|_F \le \| \mathbf{N} \|_F \| \mathbf{\Delta} \|_F. \tag{9}$$

令

$$\pi(\mathbf{N}) = \inf\{ \| \operatorname{diag}\left[\mathbf{N}\mathbf{D}_\mathbf{y}\left(\mathbf{y}\mathbf{y}^\top-\mathbf{s}\mathbf{s}^\top\right)\right] \| : \mathbf{y} \notin \mathcal{B}_\delta, \ \min_i |y_i| \ge \epsilon\}.$$

称正整数值、不可约且非二部的 $\mathbf{N}$ 可容许，并以 $\mathcal{N}$ 表示这些矩阵组成的集合。当 $\| \mathbf{\Delta} \|_F \le c := \inf_{\mathbf{N}\in\mathcal{N}} \pi(\mathbf{N}) / \| \mathbf{N} \|_F$ 时，$\mathbf{x} \in \mathcal{B}_\delta$。注意 $c>0$。

于是由推论 2、（4）和（9），

$$\| \mathbf{x}-\mathbf{s} \| \le \frac{\| \nabla f(\mathbf{x}) \|}{s_{\min}^2\mu} \le \frac{\| \operatorname{diag}\left[\mathbf{N}\mathbf{D}_\mathbf{x}\mathbf{\Delta}\right] \|}{s_{\min}^2\mu} \le \frac{\| \mathbf{N} \|_F \| \mathbf{\Delta} \|_F}{s_{\min}^2\mu},$$

证明完成。

E 额外实验与细节

E.1 多分类

对 Dogs 和 Web 两个多分类数据集，采用两种不同方法。第一种对每类 $k \in \mathcal{K}$ 使用一对其余策略，假设类别独立模型决定工作者翻转真值的概率。第二种用齐次 Dawid-Skene 模型代替单硬币模型，为每名工作者构建仅有一个参数的混淆矩阵。具体而言，对每名工作者，混淆矩阵对角元素相同，每行非对角元素也相同。把标签表示为相应类别列上为 1 的向量后，通过 PGD 最小化加权最小二乘目标

$$\frac{1}{2}\sum_{(i,j)\in E} N_{ij}\left[\widetilde{C}_{ij} - |\mathcal{K}|x_i x_j - (|\mathcal{K}|-2)x_i - (|\mathcal{K}|-2)x_j\right]^2,$$

其中

$$\widetilde{C}_{ij} = \frac{4(|\mathcal{K}| - 1)}{T} \sum_{t=1}^{T} \langle \mathbf{Y}_{i,t},\ \mathbf{Y}_{j,t} \rangle - |\mathcal{K}|.$$

对不同数据集选取最适合的模型。为预测标签，对每类计算条件技能得分 $\text{score}(k) = \sum_{(i,t)\in A} \log \frac{1+s_i}{1-s_i} \mathbb{1}\left(Y_{i,t} = k\right)$，其中指示函数取 ± 1；以最大得分类别作为标签。

E.2 不同技能分布实验

对 $T = 300$ 项任务随机分配二元类别，选取五组参数。表 3 给出 10 次独立运行的平均错误率。$\alpha = 5, \beta = 1$ 对应可靠工作者，预测误差较小；$\alpha = 2, \beta = 2$ 和 $\alpha = 0.5, \alpha = 0.5$ 时，因为 $\sum_{i\in[W]} s_i$ 不再为正，预测几乎随机，验证了理论。$\alpha = 2, \beta = 5$ 和 $\alpha = 5, \beta = 1$ 也出现类似情况，因为相对于技能和为正的假设，技能全部翻转。

译注。 上段最后两组参数及重复的 α 均按原文保留；与表 3 的描述存在不一致，不应据此理解为译文主动更改实验配置。

表 3：不同技能分布下的平均预测误差。

工作者类型	α	β	贝叶斯误差	预测误差（固定噪声）
对抗者与能手	0.5	0.5	0.0036 ± 0.0014	0.5990 ± 0.4860
不对称，更多正技能	5	1	0.0038 ± 0.0014	0.0041 ± 0.0013
不对称，更多负技能	2	5	0.0314 ± 0.0062	0.9667 ± 0.0067
能手（Hammer）	2	2	0.0615 ± 0.0083	0.4162 ± 0.4273
随机作答者（Spammer）	1	3	0.0129 ± 0.0034	0.9864 ± 0.0041

E.3 图规模

我们关注图规模如何影响 PGD 性能。图规模与工作者人数相关。目标是说明固定噪声量下，PGD 预测精度不随图增大而下降。再次考虑增加长度 3 奇环的星形工作者交互图，通过向星形图添加顶点增大规模。技能 $\mathbf{s}$ 在 0.8 和 -0.3 之间均匀选取。为固定噪声水平，对所有 $(i,\ j) \in E$ 定义 $C_{ij} = s_i s_j + \xi_{ij}$，其中 ξ_{ij} 从 $[-0.2,\ 0.2]$ 随机选取。相对于通常预期的相关性估计精度，这一噪声相当大。重复运行 PGD 50 次，不同规模的平均错误率见表 4。相对于贝叶斯误差，预测误差对图规模不敏感。

表 4：不同图规模的平均预测误差。

工作者数	21	51	71	91
贝叶斯误差	0.0425 ± 0.0042	0.0622 ± 0.0040	0.0634 ± 0.0033	0.0574 ± 0.0030
预测误差（固定噪声）	0.0425 ± 0.0042	0.0641 ± 0.0126	0.0662 ± 0.0072	0.0618 ± 0.0063

E.4 权重函数

由定理 2 的证明容易看出，PGD 对任意非负权重都收敛到全局最优。目标使用式（3）的计数权重，但还有其他选择。Dalvi et al.（2013）建议 $B\left(N_{ij}\right) = N_{ij}^2$，而我们用 N_{ij}；还可以采用二元权重。针对不同任务分配，对每个权重函数在 $T = 300$ 项任务上运行 PGD 10 次。若所有 N_{ij} 相同，这些选择结果相同。我们考虑：（a）大多数任务分给随机作答者；（b）大多数任务分给正技能工作者。表 5 比较预测误差。二次权重在此表现很差，因为它容易忽略正技能工作者。另一方面，不加权时不能准确估计随机作答者，因此也不是好选择。

表 5：不同加权方式的预测误差。

被分配最多任务的工作者类型	$\left[N_{ij} > 0\right]$	$B\left(N_{ij}\right) = N_{ij}$	$B\left(N_{ij}\right) = N_{ij}^2$
随机作答者	0.33 ± 0.03	0.33 ± 0.03	0.55 ± 0.17
正技能工作者	0.17 ± 0.06	0.09 ± 0.02	0.09 ± 0.02