整合而非收集：数据洪流时代的统计匹配

非官方中文全文译文

Riccardo D’Alberto · Meri Raggi

《Statistical Papers》65（2024）：2135–2163。DOI：10.1007/s00362-023-01468-3。

收稿：2022年1月12日；修订：2023年6月28日；在线发表：2023年9月19日。© 作者，2023。

作者单位：意大利博洛尼亚大学“P. Fortunati”统计科学系，Via Delle Belle Arti 41，40126 Bologna，BO，Italy。通讯作者：Riccardo D’Alberto，riccardo.dalberto@unibo.it；Meri Raggi，meri.raggi@unibo.it。

许可与译者说明。 原文依据 Creative Commons Attribution 4.0 International（CC BY 4.0）许可发布，许可地址：https://creativecommons.org/licenses/by/4.0/ 。本译文为中文翻译改编，非作者或出版者审定版本。原文链接：https://link.springer.com/article/10.1007/s00362-023-01468-3 。数学符号及图形按原文保留；参考文献保留原始书目信息以便检索。翻译不代表原作者认可。原文中潜在的排版或论述问题不擅自改写。

摘要

统计匹配正逐渐成为一种直接的数据整合方法。这种重要性和关注度不断提高的方法，有助于应对数据短缺带来的尚未解决的挑战，以及当前数据洪流时代出现的多种机遇。本文对该方法从早期起源到最新发展的历程进行全面综述，同时考察最重要的应用。本文讨论统计匹配与其他整合方法之间的联系，分析为何一种已有50年历史的方法，直到最近才被置于一个一致但仍不完整的框架之下。我们在不同的数据特征和样本代表性框架下比较统计匹配的优势与不足，并提出未来研究思路；贯穿始终的关注点是不确定性，即统计匹配试图回答的核心问题。

关键词： 数据整合；数据融合；插补；记录链接；热卡技术。

数学主题分类： 62D10 · 62G86 · 62P20 · 62P25。

1 引言

时间限制和预算约束，是促使官方统计（OS）以及不同学科研究人员重新思考传统数据收集方式的两个重要驱动因素。例如，通过全国人口普查收集数据的做法正逐渐被放弃；与此同时，数据整合的新场景不断出现，为官方统计、研究人员、政策制定者和公众提供新的解决方案。

过去20年间大数据的大量产生，促使人们形成这样一种认识：信息可以通过无数种途径获得。移动设备、应用程序、社交媒体和物联网共同强化了这一观念：不再需要规划数据收集，只需要通过建模来利用已有信息（Iaccarino，2019）。然而，原始数据仍带来尚待解决的质量问题、隐私诉求和安全原因造成的限制、数据所有权问题，以及组织、技术与治理问题。

从数据收集向数据整合的渐进转变已经开始，尤其体现在官方统计领域。官方统计正在制定策略，持续更新现有数据来源，例如整合一手和二手数据，汇集行政登记、网络数据、项目调查、卫星数据和地理数据。因此，数据整合代表着未来数据生产与共享过程的发展方向。现有路径包括：（1）传统来源与行政数据；（2）传统来源与大数据；（3）微观与宏观层面的数据（UNECE，2017）。这些不同策略具有共同目标：在极其广泛的研究领域中汇集多来源的有价值信息，提高满足并妥善回应用户需求的能力（Pentland，2019）。

整合最初分别收集于两个或更多数据源的信息，可以采用不同方法。其中重要的方法包括记录链接（RL）、多重插补（MI）和统计匹配（SM）。

记录链接包括精确链接和概率链接（Christen，2012）。当需要整合指向同一总体的两个或更多不同数据源时，精确记录链接允许依据共同标识符，将同时存在于两个数据集中的单位合并。如果一个数据集中的某条记录，在共同标识符上的取值与另一个数据集中的某些记录完全相同，精确记录链接便将这些记录合并。这是整合不同来源（如行政数据）的最简单情形。然而，当（1）两个或更多来源收集的单位集合至少部分重叠，（2）不存在或无法使用唯一标识符，并且（3）共同变量可以充当“伪标识符”，但可能误报或随时间变化时（Fellegi和Sunter，1969），概率记录链接就成为整合过程的主角。因此，在无法使用或缺乏精确标识符时，概率记录链接识别不同数据集中对应同一单位的记录。

多重插补处理变量的缺失值，在个体层面分两步进行。首先创建少量完整数据集，并利用插补模型填补缺失值；其次在每个完整数据集中计算估计值，最后将其合并（Rubin，1987）。当需要为一个部分观测的数据集逐条记录“补全”时，可以利用插补模型的样本，从给定已观测变量条件下缺失变量的未知条件分布中随机生成该变量取值的估计替代值（Murray，2018）。多重插补通常仅利用一个数据集完成记录中的缺失内容（Denk和Hackl，2003）；“粗略地说，缺失数据被插补不止一次……这些插补建立在某些分布假设之上”（Rässler，2002，第5页）。

本文聚焦统计匹配，下文将详细描述其方法。简要而言，当操作环境具有以下特征时，统计匹配能够整合两个或更多来源中的信息：（1）不同来源收集了共同变量集合 $\mathbf{x}$，以及分别观测的两个变量集合 $\mathbf{y}$ 和 $\mathbf{z}$；（2）各数据集中观测的单位集合可能互不相交（D’Orazio等，2006b）。记录链接处理“相同”的单位，统计匹配则处理尽可能“相似”的单位（Judson，2005）。统计匹配与记录链接／多重插补的主要差别，在于最终整合目标。记录链接评估数据集之间的覆盖重叠或重复记录，可用于增加或删除记录，从而可能扩充某一来源的数据。统计匹配的整合重点与多重插补稍有不同，后者超越了通常的双数据库情形（Judson，2005）。记录链接和多重插补都不处理统计匹配潜在的最广泛目标：根据两个或更多数据源建立一个合成的完整数据集。该数据集称为“合成”，因为它并非来自直接观察或收集，而是人为构建；称为“完整”，因为它最终汇集了在任一来源中收集的全部变量。此外，记录链接和多重插补都不像统计匹配那样考察整合结果背后的不确定性。[1]

统计匹配也能更加灵活地服务于数据融合目标（Rässler，2002），尤其适用于如下缺失结构：仅利用对 $\mathbf{x}$ 的了解，就需要获取联合分布函数 $f(\mathbf{x}, \mathbf{y}, \mathbf{z})$ 的知识，或者将缺失变量从一个来源转移到另一个来源。在这种情况下，随机变量 $\mathbf{y}$ 只在一个数据集中观测，$\mathbf{z}$ 只在另一个数据集中观测，而 $\mathbf{x}$ 在所有可用数据集中均被观测；下文称其为“匹配”变量。

如今，统计匹配与记录链接／多重插补之间正在出现富有成效的结合，用以应对大数据整合带来的挑战；这一领域必须考虑非概率样本。Bethlehem（2016）通过讨论大规模插补，指出了匹配不同样本时存在的主要实践问题；Rao（2021）则全面综述了概率抽样方法，也关注能够从非概率样本获得有效推断的模型。

Rässler（2002）与D’Orazio等（2006b）两部专著对统计匹配作了系统论述。本文对统计匹配乃至更广泛的数据整合文献的贡献有两个方面。第一，回顾最新发展，讨论识别、量化及处理数据整合不确定性的主要发现。第二，讨论覆盖从最早发展到最新发表论文的全部历程。本文既讨论方法特点，也讨论其优势与不足；考察抽样框架对数据整合的影响，并且不忽略真实数据应用。目的在于为一般读者和有深入兴趣的读者提供一幅有用的路线图，帮助他们完整理解该方法的各种应用形态。

为便于读者理解统计匹配在完整、共享理论框架下的复杂发展与成果，表1列出了构成该领域研究基础的关键贡献。这些研究与其他引文均列于参考文献。表中按照20世纪70年代至今的十年阶段，并结合方法发展的主要主题，对重要贡献作了结构化梳理，旨在帮助读者更清晰地理解统计匹配的演变，并高效聚焦其主要特征。

表1 统计匹配：从起源到确立，对研究现状的结构化梳理

时期	阶段与主要议题	主要贡献
20世纪70年代	仍被称为“合并”的统计匹配：最初探索、三元正态分布、 $\mathbf{x}$ 的解释力	Okner（1972，1974），Ruggles和Ruggles（1974），Kadane（1978）
20世纪80年代	方法的兴起：类别型 $\mathbf{x}$ 、多元正态分布、替代方法比较、官方统计实践	Rodgers（1984），Walter（1984），Gavin（1985），Barry（1988），Singh等（1989），Cohen（1991）
20世纪90年代	转折点：对条件独立假设的批评、替代路径比较、抽样权重	Rubin（1986），Singh等（1993），Renssen（1998）
21世纪00年代	走向统一：明确的符号体系、形式化方法	Rässler（2002，2004），D’Orazio等（2006）
21世纪10年代	不确定性及其延伸：相容性、不确定性的定义／估计、误差度量、独立样本	Conti等（2008），Vantaggi（2008），Conti等（2016），Conti等（2019），Marella和Pfeffermann（2019）
21世纪20年代	大数据与非概率样本：即将到来的整合	Chen等（2020），Kim等（2020），Castro-Martín等（2022）

本文结构如下。第2节简要介绍方法，强调关键特征，并提出统计匹配的两个主要目标（微观和宏观）。第3节回顾起源时期的“合并”方法，讨论早期方案忽略的形式化统一需求。第4节考察非参数和贝叶斯方法，讨论匹配噪声量化、不确定性定义与估计的解决方案。第5节依据最新方案分析统计匹配中的不确定性，特别关注非代表性样本与大数据问题。第6节给出结论及未来发展的若干思考。附录A概述最重要的统计匹配应用和软件解决方案。

2 方法概述

图1 两个数据集（A和B）的统计匹配问题中可用的数据。 图中共同观测区域对应匹配变量，另外两个区域对应仅在各自来源观测的变量。

$$
\begin{bmatrix}
y_{11}^{\mathrm{A}} & \cdots & y_{1m}^{\mathrm{A}} & \cdots & y_{1M}^{\mathrm{A}} & x_{11}^{\mathrm{A}} & \cdots & x_{1l}^{\mathrm{A}} & \cdots & x_{1L}^{\mathrm{A}} & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\
\vdots & \ddots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & & & & & & & & \\
y_{i1}^{\mathrm{A}} & \cdots & y_{im}^{\mathrm{A}} & \cdots & y_{iM}^{\mathrm{A}} & x_{i1}^{\mathrm{A}} & \cdots & x_{il}^{\mathrm{A}} & \cdots & x_{iL}^{\mathrm{A}} & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\
\vdots & \ddots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & & & & & & & & \\
y_{n_{\mathrm{A}}1}^{\mathrm{A}} & \cdots & y_{n_{\mathrm{A}}m}^{\mathrm{A}} & \cdots & y_{n_{\mathrm{A}}M}^{\mathrm{A}} & x_{n_{\mathrm{A}}1}^{\mathrm{A}} & \cdots & x_{n_{\mathrm{A}}l}^{\mathrm{A}} & \cdots & x_{n_{\mathrm{A}}L}^{\mathrm{A}} & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots
\end{bmatrix}
$$

$$
\begin{bmatrix}
\cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & x_{11}^{\mathrm{B}} & \cdots & x_{1l}^{\mathrm{B}} & \cdots & x_{1L}^{\mathrm{B}} & z_{11}^{\mathrm{B}} & \cdots & z_{1p}^{\mathrm{B}} & \cdots & z_{1P}^{\mathrm{B}} \\
 & & & & & & & & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\
\cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & x_{j1}^{\mathrm{A}} & \cdots & x_{jl}^{\mathrm{A}} & \cdots & x_{jL}^{\mathrm{B}} & z_{j1}^{\mathrm{B}} & \cdots & z_{jp}^{\mathrm{B}} & \cdots & z_{jP}^{\mathrm{B}} \\
 & & & & & & & & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\
\cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & x_{n_{\mathrm{B}}1}^{\mathrm{A}} & \cdots & x_{n_{\mathrm{B}}l}^{\mathrm{B}} & \cdots & x_{n_{\mathrm{B}}L}^{\mathrm{B}} & z_{n_{\mathrm{B}}1}^{\mathrm{B}} & \cdots & z_{n_{\mathrm{B}}p}^{\mathrm{R}} & \cdots & z_{n_{\mathrm{B}}P}^{\mathrm{B}}
\end{bmatrix}
$$

为简单起见，考虑两个数据集 A 和 B。令 A 为“受体”数据集，B 为“供体”数据集，观测数分别为 n_A 和 n_B。令 $\mathbf{x}$ 为在 A、B 中均观测的随机变量； $\mathbf{y}$ 为仅在 A 中观测的随机变量； $\mathbf{z}$ 为仅在 B 中观测的随机变量。它们对应于 A、B 中的第 i、第 j 个观测，其中 $i = 1, ..., n_A$， $j = 1, ..., n_B$。观测变量及数据集的原文符号、维度如下：

$$\mathbf{x} = \{X_1, ..., X_l, ..., X_L\}, \qquad \underset{n_A \times M}{\mathbf{y}} = \{Y_1^{\mathrm{A}}, ..., Y_m^{\mathrm{A}}, ..., Y_M^{\mathrm{A}}\},$$

$$\underset{n_B \times P}{\mathbf{z}} = \{Z_1^{\mathrm{B}}, ..., Z_p^{\mathrm{B}}, ..., Z_P^{\mathrm{B}}\}.$$

$$\mathrm{A} = \left\{ \underset{n_A \times L}{\mathbf{x}^{\mathrm{A}}}, \underset{n_A \times M}{\mathbf{y}^{\mathrm{A}}} \right\}, \qquad \mathrm{B} = \left\{ \underset{n_B \times L}{\mathbf{x}^{\mathrm{B}}}, \underset{n_B \times P}{\mathbf{z}^{\mathrm{B}}} \right\}.$$

即： $\mathbf{x}$ 的各列在 A 和 B 中均收集，对应向量维度分别为 n_A 和 n_B； $\mathbf{y}$ 的各列只在 A 中收集，向量维度为 n_A； $\mathbf{z}$ 的各列只在 B 中收集，向量维度为 n_B。全部可用信息如图1所示。

统计匹配通过微观和宏观两种路径汇集不同来源的信息（D’Orazio等，2006b）。为便于说明，假设 $l = 1$、 $m = 1$、 $p = 1$，即 X、Y、Z 均为单变量连续变量。令 $\mathcal{F}$ 为分布族，其中每个 $f(X, Y, Z; \theta) \in \mathcal{F}$ 由参数向量 $\theta \in \Theta$ 定义；宏观统计匹配旨在估计联合分布函数 $f(X, Y, Z)$。微观统计匹配则旨在根据 A、B 生成合成的完整数据集。前一目标较为直接，后一目标需要进一步解释。令 S_d 为从随机变量 $\mathbf{z}$ 中选择的任意一个包含 d 个目标变量的子集，其中 $d = 1, ..., P$。微观统计匹配的目标，是把 S_d 从 B 插补到 A，从而生成名为 C 的合成完整数据集；其符号和维度为：

$$\mathrm{C} = \left\{ \underset{n_A \times L}{\mathbf{x}^{\mathrm{A}}}, \underset{n_A \times M}{\mathbf{y}^{\mathrm{A}}}, \underset{n_A \times S_d}{\mathbf{z}^{\mathrm{A}}} \right\}.$$

最一般的统计匹配框架作出以下假设：

A.1. A、B 收集了同一目标总体的两个代表性样本的信息（D’Orazio等，2006b）。

A.2. 图1中不同的样本 A、B 可视为一个统一样本 $A \cup B$，包含从 $f(X, Y, Z)$ 获得的 $n_A + n_B$ 个独立同分布观测（D’Orazio等，2006b）。

A.3. 根据来自 $f(X, Y, Z)$ 的 $n_A + n_B$ 个单位组成的总样本 $A \cup B$，可推导一个合成的完整数据集，其中缺失信息结构是完全随机缺失（MCAR）或随机缺失（MAR）（Rubin，1987；Rässler，2002，2004）。

与 $f(X, Y, Z)$ 有关的关键估计问题，往往借助条件独立假设（CIA）导出的可识别模型来处理。简言之，完整信息集由 $A \cup B$ 样本定义，X、Y、Z 是独立且服从正态分布的随机变量。统计匹配通常显式或隐式采用条件独立假设，通过似然函数因子分解，将上述估计难题拆解为较小的估计问题（Anderson，1957）。最初的解决方案限于三元正态分布，后来扩展至多元分布。Rubin（1974）证明联合分布可分解如下：

$$f(\mathbf{x}, \mathbf{y}, \mathbf{z}; \theta) = f(\mathbf{x}; \theta_{\mathbf{x}}) \cdot f(\mathbf{y} \mid \mathbf{x}; \theta_{\mathbf{y}|\mathbf{x}}) \cdot f(\mathbf{z} \mid \mathbf{x}; \theta_{\mathbf{z}|\mathbf{x}}).$$

换言之，条件独立假设允许使用 $A \cup B$ 计算 $\theta_{\mathbf{x}}$ 的极大似然估计，并分别利用 A 和 B 计算 $\theta_{\mathbf{y}|\mathbf{x}}$ 与 $\theta_{\mathbf{z}|\mathbf{x}}$ 的极大似然估计。

3 统一性在哪里？

3.1 统计匹配还只是“合并”的时期

统计匹配中的关键估计问题及若干解决思路，在20世纪50年代已为人所知。然而，直到电子计算机可用，最早的合并／匹配应用才得以传播：“对微观经济层面社会问题的兴趣日益提高，加上技术发展提供的机会，推动了对细分社会经济和人口信息的需求”（Okner，1972，第325页）。“1966年合并文件”是这一方向的早期粗略尝试。它将美国住户的1967年经济机会调查与1966年税务文件整合起来（Okner，1972），以回应缺乏一致且全面的住户数据的问题。作者旨在满足关于美国个人收入分布，以及按典型人口特征交叉分类的官方统计需求。他利用匹配变量 $\mathbf{x}$（工资、薪金收入、农业收入等）[2]，按主要和次要收入来源以及一致性得分建立等价类体系。这些体系用于给单位赋予“分数”，进而匹配单位，生成在个体特征之外还记录具体收入构成的新文件。

Sims（1972a，b）批评这种方法，因为它仅隐式假定条件独立，而实际上需要更明确的理论框架。关于结果的“质量”和有效性，论述很少；对于原调查可能存在的少报或未报告，以及评价这些问题所需的调整，也几乎未加讨论。Alter（1974）略有推进：将1970年加拿大消费者财务调查与1970年家庭支出调查整合后，提出用交叉表评估匹配后变量的一致性。然而，他也强调：“X–Y–Z问题仍未解决……因为无法仅从已知的 X 与 Y、X 与 Z 的分布推断 X、Y、Z 的联合分布”（Alter，1974，第374页）。

这些工作还忽略了其他挑战：它们隐式假定向量 $\mathbf{x}$ 在 A 与 B 中的定义完全相同，但实际上匹配变量可能受到类型、大小和发生频率各不相同的误差影响。[3] 此外，也未考虑一些特殊却并不少见的情况（如社会科学中）：$\mathbf{x}$ 为复合变量，或 $\mathbf{z}$、$\mathbf{y}$ 为复合变量。[4]

另一个重要的遗留问题，是选择匹配变量的依据。通常， $\mathbf{x}$ 的选择由数据驱动，并以 R^2 的解释力为导向。在回归插补中，用决定系数评估 (X,Y) 或 (X,Z) 关系的强度，从而评估条件独立假设的有效性，是直接的做法。但如果目标不是赋予均值，而是重现原数据中的取值分布、转移复杂的信息集合，就会遇到额外挑战。Ruggles和Ruggles（1974）认识到这一点，并明确指出：为匹配而进行的整合，不必预先确定某个特定函数关系。那么，如何最有效地选择匹配变量？他们提出，利用 A、B 之间全部 $\mathbf{x}$ 变量构造 L 维交叉表，在其中进行匹配；落入同一单元格的单位随机配对。X 变量区间的质量，即在某个特定 X 区间内 Y、Z 分布保持不变的保证，通过对 Y 和／或 Z 分布进行卡方检验来评估。如果发现显著差异，则计算一个相关性度量来估计分布差异程度。值得注意的是，对 $\mathbf{x}$ “质量”的讨论也包含了对最终合成完整数据集整体优良性和可靠性的考虑。

上述方案有一个共同根源：隐式采用一种伪距离，它建立在 A、B 共同变量 $\mathbf{x}$ 的分层嵌套交叉表单元格之上。通过不断将这些变量划分为更窄的区间，可以对单位标记、重新标记，然后对标签排序，从而挑选待匹配单位。这种伪距离类似于多元回归分析中赋予各匹配变量 X 的权重；其中 $\mathbf{x}$ 为回归变量，$\mathbf{y}$ 、 $\mathbf{z}$ 为因变量。

虽然这些实现常被含混地称作“链接”“融合”“拼接”等（Rässler，2002），其提出的统计匹配方法已经采用了不同于记录链接的方法框架。直到Kadane（1978），才出现第一个在类似第2节所述框架中提出的明确匹配方案。该文考虑正态分布变量三元组 (X,Y,Z)，指出联合正态假设意味着所有 (X,Y)、(X,Z) 回归都是线性的，而这在真实世界数据中往往不成立。因此，作为“绕过问题的办法”（Kadane，1978，第424页），作者建议仅在 X 空间中逐个局部区域采用该假设，并分别估计协方差，但无法观测的 σ_{YZ} 除外。能够获取 σ_{YZ} 信息的特殊情形，包括已经完美匹配的粗略样本，从中可知某些 σ_{YZ} 元素；另一选择则是条件独立假设。

然而，由于不能根据现有数据一致估计 σ_{YZ}，作者建议为其指定一个特定值，目的在于得到某个预期结果，例如某项税率表期望筹集的税额。对 σ_{YZ} 的分布作假设，再从中取值，最终可用特定值出现的概率对结果加权；也就是对 σ_{YZ} 进行抽样。此方法的缺点是：正态假设越不可靠，方法的一致性越弱。此外，方案没有考虑如何验证最终整合结果。

3.2 方法的兴起：国家机构的应用

Rodgers（1984）首次明确指出统计匹配缺乏理论基础与经验依据：匹配数据所产生的任何发现，其有效性在很大程度上取决于事先对匹配变量作出的假设，因此都值得质疑。然而，这些假设无法检验，所以必须检查其可能不成立时的后果。他由此首次尝试建立统一的统计匹配符号体系，引入距离函数和供体类别两个基本概念。距离函数定义为来自不同数据集的两个观测，在 X（如年龄）取值上的绝对差。例如，一个一般的基本距离为 $|x_i - x_j|$， $i = 1, \ldots, n_A$， $j = 1, \ldots, n_B$。[5] 供体类别是观测的同质子组，可限制单位配对的范围，例如按男性和女性分组。现有数据涵盖供体与受体的全部 $n_B^{n_A}$ 种组合；令 $X^\star$ 为离散化变量，其类别 $X_f^\star$（ $f = 1, \ldots, F$ ）标识供体类别，便可将潜在供体—受体配对数限制为 $\left(n_{B,X_f^\star}\right)^{n_{A,X_f^\star}}$。

Rodgers（1984）还从统计匹配的用途出发，提出一种新的整合视角：考察对统计匹配数据进行分析后所得结论的有效性。该有效性高度依赖变量关系基本假设的准确程度。单独的 A、B 并不包含 $\mathbf{y}$ 、 $\mathbf{z}$ 之间关系的信息，而统计匹配仅反映匹配过程中显式或隐式作出的假设，因此最终匹配数据集是“分析这些关系的一种有风险的基础”（Rodgers，1984，第96页）。作者考察不同场景中的模拟和经验应

用，检验条件独立假设的有效性，讨论根据可用变量集合，应在何时、以何种程度信任匹配程序。具体分析：（1）无约束和有约束匹配；（2）距离函数应包含哪些匹配变量；（3）完成匹配所需输入数据集的最小规模。

只有当分析者为整合目的对这些关系作出的或隐含的假设足够稳健时，整合数据集才能为涉及 $\mathbf{x}$、$\mathbf{y}$、$\mathbf{z}$ 关系的分析提供价值。例如，假设需要估计下列线性模型：

$$\mathbf{z} = \mathbf{x}_{L-1}\cdot\boldsymbol{\beta} + \mathbf{y}\cdot\boldsymbol{\lambda} + \epsilon.$$

等式左侧为内生结果变量，右侧同时包含内生和外生解释变量，以及非零参数向量和随机误差。[6] Klevmarken（1982）指出，能否估计该线性模型的参数，取决于对模型中每一个 Y，距离函数所使用的随机变量 $\mathbf{x}$ 中，是否至少有一个不属于 $\mathbf{x}_{L-1}$。简言之，设 $\mathbf{x}$、$\mathbf{y}$、$\mathbf{z}$ 均包含于以下系统；原文的参数矩阵、扰动矩阵和约化形式为：

$$\mathbf{x}\cdot\boldsymbol{B} + \mathbf{y}\cdot\boldsymbol{\Lambda} + \mathbf{z}\cdot\boldsymbol{\Gamma} = \mathbf{U}, \qquad E(\mathbf{U}) = \mathbf{0},$$

$$\mathbf{y} = \mathbf{x}\cdot\boldsymbol{\pi} + \mathbf{V}.$$

其中随机扰动矩阵 $\mathbf{U}$ 的期望为零，$\mathbf{y}$ 和 $\mathbf{z}$ 为内生变量，$\mathbf{x}$ 为外生变量。该系统显然包含前面的方程，另一个组成部分是以 $\boldsymbol{\pi}$ 和 $\mathbf{V}$ 为相应子矩阵的约化形式。利用数据集（样本）A 可以估计 $\boldsymbol{\pi}$，再依据观测到的匹配变量预测 $\widehat{\mathbf{y}}^{\mathrm{B}}$。此外，利用样本 B 可估计相应结果方程，并改写为矩阵形式；普通最小二乘估计如下：

$$\mathbf{z}^{\mathrm{B}} = \mathbf{x}_{L-1}^{\mathrm{B}}\cdot\boldsymbol{\beta} + \widehat{\mathbf{y}}^{\mathrm{B}}\cdot\boldsymbol{\lambda} + \epsilon = \mathbf{M}^{\mathrm{B}}\cdot\boldsymbol{\delta} + \epsilon,$$

$$\mathbf{M}^{\mathrm{B}} = \left(\mathbf{x}_{L-1}^{\mathrm{B}} \mid \widehat{\mathbf{y}}^{\mathrm{B}}\right), \qquad \boldsymbol{\delta} = (\boldsymbol{\beta} \mid \boldsymbol{\lambda}), \qquad \widehat{\boldsymbol{\delta}} = (\mathbf{M}'\mathbf{M})^{-1}\mathbf{M}'\mathbf{z}.$$

只要所需逆矩阵存在，就可以估计参数。然而，这个逆矩阵的秩不能超过 $\mathbf{x}$ 的变量数；这意味着，从结果方程中排除的匹配变量，至少要与纳入其中的 $\mathbf{y}$ 变量一样多。

在匹配质量评估方面，Walter（1984）仅针对类别匹配，研究了让给定样本的所有单位都找到匹配所需的抽样工作量。作者利用马尔可夫链，推导为所选匹配变量各类别完成匹配配额所需样本量的精确分布的前两阶矩，从而考察匹配难度与样本量、匹配类别数、类别概率及配额分布的关系。其方法假定第一个总体的样本已给定，对第二个总体重复抽样，直到第一个样本中所有单位均找到匹配。Walter（1984）证明：（1）匹配类别数固定时，大样本比小样本更容易匹配；（2）所需平均样本量随匹配类别数增加而增加；（3）类别抽样概率与配额成比例时，匹配更容易。

后一情形常发生于匹配变量分布相似且混杂因素较弱时。此外，如果类别概率与配额远不成比例，预计需要大量过度抽样。因此，问题转为：样本 A、B 的匹配变量必须达到何种最优相似程度，才能更容易匹配且不损失精度？在这一背景下，此前被忽略的连续型 $\mathbf{x}$ 情形显现出来。20世纪80年代在这个方向没有进一步发展，多数贡献聚焦真实数据应用，其中美国和加拿大国家部门及联邦机构走在前列（例如Radner等，1980；Rodgers和DeVol，1981；Gavin，1985；Armstrong，1989，及其中引文）。

尽管存在这些空白，80年代的实践贡献仍然为推进整个框架发挥了根本作用。此时统计匹配开始被视为一种有别于记录链接的“文件合并技术”。例如Barry（1988）指出，记录链接是一种“精确匹配”方法，强调其建立在能够链接不同来源实体的伪标识符之上；统计匹配则处理相似、但不一定“相同”的单位。统计匹配的主要目标被表述为：“如果来自两个来源的两个单位被识别为最佳匹配或最相似单

位，则将一个来源中某个体的数据，与另一来源中不同观测的数据整合”（Gavin，1985，第183页）。换言之，统计匹配不同于记录链接，因为用于统计匹配的两个文件中的单位集合可能完全不相交，或者仅有少量未知重叠（Singh等，1988，第672页）。这些认识揭示了统计匹配对数据整合的价值，尤其是在隐私限制存在时。随着数据隐私关注及相关讨论增多，例如删除唯一标识符导致的信息逐步短缺，使跨来源记录链接更加复杂，也推动了新整合方案的普及。

为完善框架，Singh等（1988）和Armstrong（1989）分析了替代方法，主要是对数线性模型插补。其创新在于，在由 $f\left(X^{\star}, Y^{\star}, Z^{\star}\right)$ 表示的类别框架中估计待插补的条件分布：星号变量为类别协变量，联合分布 $f(\cdot)$ 为概率质量函数。核心思想是将涉及 $f(X, Y, Z)$ 的经典问题转换为类别变量问题。适当选择 (X,Y,Z) 空间的类别划分后，首先利用 $f\left(Z^{\star} \mid X^{\star}\right)$ 在插补类别 $\left(X^{\star}, Z^{\star}\right)$ 内将 Z 插补到某个 $Z^{\star}$ 类别；然后在该类别内选取 Z 的一个值。主要优点是，在与 $f(X, Y, Z)$ “近似相同”的类别框架中，可以较容易控制对条件独立假设的违反。由此可取得适合作为预测变量的 X 子集，并形成最优插补类别；最优性由根据类别划分粗细定义的不稳定性度量来判断。

当整合服务于微观模拟模型，且需要发生概率很低的特定信息时，这种方案尤为重要。例如高收入观测、频繁的回答误差以及／或者信息细节不足。用统计匹配插补为微观模拟提供数据，可以：（1）降低数据整合所需计算量；（2）通过精细控制转换后的类别框架，避免或减轻 X、Y、Z 非线性关系带来的潜在弊端，以防这些关系使整合数据分析产生偏差（Cohen，1991）。

3.3 方法论终于到来

“政策分析者和规划人员经常使用的微观模拟数据库，由多个通过统计匹配合并的数据文件构成”（Singh等，1993，第59页）。对回归型、距离型和对数线性型三种替代“技术”模拟结果的讨论，大大加快了该方法的发展。Singh等（1993）的经验结果表明，基于距离的统计匹配，即第4节将详细讨论的热卡技术，表现优于基于回归的方法。相反，如果有辅助信息，因而能通过类别约束放宽条件独立假设，则应优先采用对数线性方法。Schulte Nordholt（1998）比较了荷兰数据的模拟与真实应用，得出类似结论。值得指出的是，除Renssen（1998）外，这可以被视为第一个使用欧洲国家（荷兰）数据的统计匹配应用；更早的20世纪80年代末至90年代初德国、法国“数据融合”尝试在附录A讨论。

新千年开始时，诸如“统计匹配被实践者广泛使用，但并不总是有充分的理论支撑”（Moriarity和Scheuren，2001，第407页），以及“世界各地使用数据融合、数据合并或数据匹配、大规模插补、微观模拟建模和文件拼接等同义名称描述统计匹配……对恰当且清晰命名的讨论仍在延续”（Rässler，2002，第2页）的评论，显示了方法形式化亟需更强统一性。普遍认识是：统计匹配广泛用于实践，尤其是官方统计（Moriarity和Scheuren，2003）。Rässler（2002，第44页）也指出，描述传统方法和技术的大量文献是工作论文、技术报告或内部报告。

Rässler（2002）与D’Orazio等（2006b）两项主要工作回应了建立更坚实理论基础的需求。它们为统计匹配提供了统一理论框架，讨论条件独立假设的主要影响与辅助信息的使用（D’Orazio等，2006b），并比较多种替代方案，特别关注贝叶斯解决方案（Rässler，2002）。Rässler（2003）进一步发展了后者，改造并实现Rubin（1987）的框架，采用一种非迭代贝叶斯方法替代其回归模型。

此后，关键挑战成为寻找条件独立假设的可靠替代。如果把统计匹配视为无回答问题，其核心思想就涉及基本的“识别问题”：即使缺失机制可忽略，非联合观测变量之间的关联仍不可识别，因此不能通过似然估计。于是，要么有关于 $f(X, Y, Z)$ 的额外信息，要么研究者必须进行多次插补，必要时依据

有信息先验。在这一背景下，Rässler（2004）提出按统计匹配可达到的四个有效性层次理解识别问题：第1层，保持个体值；第2层，保持联合分布；第3层，保持相关结构；第4层，保持边际分布。通常，第4层是统计匹配能够广泛控制的层次。如果无法从现有数据估计条件关联，即给定 A、B 共同变量时未联合观测变量间的关联，仍可估计 Y、Z 无条件关联的可容许值。具体而言，根据匹配变量的解释能力，可以估计较窄或较宽的可容许值范围（Rässler，2004）。

4 非参数与贝叶斯方法

过去20年间，非参数统计匹配受到广泛关注，原因在于：（1）它充分利用“活的”、实际观测的信息（D’Orazio等，2006b）；（2）它减少对联合分布族 $f(X, Y, Z)$ 参数作假设所产生的模型设定错误偏差（Conti等，2017b）；（3）它降低参数统计匹配所需的计算量（D’Orazio，2015）。尽管非参数技术不需要“假设”，仍须注意，其应用涉及：（1）选择距离函数；（2）是否以及如何建立供体类别；（3）选择供体的抽样机制。

非参数统计匹配带来的方法进步，与“匹配噪声”的概念、定义、量化及其在整合过程中的作用有关。起点是：匹配得到的联合分布 $f(X, Y, Z)$，可能并不等于“真实”但不可观测的分布。因此，“插补数据集并非真实数据集，从中得出的统计结论值得质疑”（Marella等，2008，第1593页）。只要两个分布不同，就存在匹配噪声；研究者应尽量减少它。

设两个数据集分别只含 $\mathbf{x}^{\mathrm{A}}$，以及含 $\mathbf{x}^{\mathrm{B}}$ 和 $\mathbf{z}^{\mathrm{B}}$，目标是生成包含 $\mathbf{x}^{\mathrm{A}}$、$\mathbf{z}^{\mathrm{A}}$ 的合成完整数据集。原文矩阵维度为：

$$\mathrm{A} = \{\underset{n_A \times L}{\mathbf{x}^{\mathrm{A}}}\}, \qquad \mathrm{B} = \{\underset{n_B \times L}{\mathbf{x}^{\mathrm{B}}}, \underset{n_B \times P}{\mathbf{z}^{\mathrm{B}}}\}, \qquad \mathrm{C} = \{\underset{n_A \times L}{\mathbf{x}^{\mathrm{A}}}, \underset{n_A \times S_d}{\mathbf{z}^{\mathrm{A}}}\}.$$

Marella等（2008）指出，生成数据集服从以下分布：

$$f\left(\mathbf{x}^{\mathrm{A}}, \mathbf{z}^{\mathrm{A}}\right) = \int f\left(\mathbf{x}_{\widetilde{j}}^{\mathrm{B}} \mid \mathbf{x}^{\mathrm{A}}\right) f\left(\mathbf{z}^{\mathrm{A}} \mid \mathbf{x}_{\widetilde{j}}^{\mathrm{B}}\right) d\mathbf{x}_{\widetilde{j}}^{\mathrm{B}}.$$

其中 $\mathbf{x}_{\widetilde{j}}^{\mathrm{B}}$ 为与受体单位匹配的供体单位的观测随机变量，即与第 i 个受体匹配的第 $\widetilde{j}$ 个供体；$\mathbf{z}^{\mathrm{A}}$ 为依据匹配单位对插补到受体中的随机变量。因此，匹配噪声由供体分布 $f\left(\mathbf{x}_{\widetilde{j}}^{\mathrm{B}} \mid \mathbf{x}^{\mathrm{A}}\right)$，以及配对供体中所观测到的待插补变量取值共同构成。

Conti等（2008）比较不同非参数插补策略在最小化匹配噪声方面的表现：热卡技术、k近邻（kNN）以及局部线性回归，后者并不强制要求总体回归函数为线性。此前，作者专门研究k近邻方法（Marella等，2008），评估固定供体数和可变供体数插补的匹配噪声。固定供体数时，包含距离型和随机热卡技术的插补程序类别，假设为单位 $i \in \mathrm{A}$ 提供的 k 个供体，就是 B 中 $\mathbf{x}_i$ 的 k 个最近邻，$i = 1, \ldots, n_A$。令 d 为如下欧氏距离，D 为正定矩阵：

$$d\left(\mathbf{x}_i^{\mathrm{A}}, \mathbf{x}_j^{\mathrm{B}}\right) = \left[\left(\mathbf{x}_j^{\mathrm{B}} - \mathbf{x}_i^{\mathrm{A}}\right)' \mathbf{D} \left(\mathbf{x}_j^{\mathrm{B}} - \mathbf{x}_i^{\mathrm{A}}\right)\right]^{1/2}.$$

$\mathbf{x}_i^{\mathrm{A}}$ 的 k 个最近邻，是 B 中按距离 d 最接近它的 $k \geq 1$ 个观测，即 $\mathbf{x}_{j(i)}^{\mathrm{B}} = \left(\mathbf{x}_{j_1(i)}^{\mathrm{B}}, \ldots, \mathbf{x}_{j_k(i)}^{\mathrm{B}}\right)$。当供体数固定时，某些供体可能稀疏，k近邻方法却将离 $\mathbf{x}_i^{\mathrm{A}}$ 很远的观测视为对 $\mathbf{z}_i^{\mathrm{A}}$ 同样有信息。作者建议，让最优 k 随 $\mathbf{x}_i^{\mathrm{A}}$ 变化，使每个受体匹配不同数量的供体。实现方法是固定一个阈值，将满足 $d\left(\mathbf{x}_i^{\mathrm{A}}, \mathbf{x}_j^{\mathrm{B}}\right)$ 小于阈值的观测选为近邻。

Marella等（2008）的模拟结果支持使用较大的供体数据集、可变供体数 k，并可用残差调整均值插补。为评估数据生成模型与插补生成模型的接近程度，Conti等（2008）在模拟研究中构造了一个基于Kolmogorov–Smirnov距离的差异度量。结果显示，固定 k 时k近邻表现最差，且低估变异性，因为 $f\left(\mathbf{z}^{\mathrm{A}} \mid \mathbf{x}_j^{\mathrm{B}}\right) d\mathbf{x}_j^{\mathrm{B}}$ 集中于 $\mathbf{z} \mid \mathbf{x}$ 的期望。此外，作者建议：当变量之间存在复杂函数关系时，优先采用局部线性回归估计量。

如同非参数统计匹配，Rässler（2002）的方案也标志着传统方法适当“替代方案”的转折。作者将统计匹配嵌入多重插补，通过贝叶斯推断转移信息，再用频率学派方式验证结果，从而创新了方法框架。她的起点是整合两个或更多来源，为最终用户提供公共使用文件。此类文件的特点是匹配后的数据会交给他人，而且通常是官方统计体系之外的人。因此，文件用户或数据分析者往往不是实施插补的人。这提出了一个经典插补挑战，而作者认为它不能通过加权、校准或EM算法解决（Rässler，2002）。如果不对从未联合观测的变量作出明确假设，就不能使用观测数据似然或EM算法处理统计匹配。由于某些参数不可估计，即现有数据无法确定底层模型，统计匹配便面临识别问题：可能有多种可行关联描述未联合观测变量的联合分布。

Rässler（2002）处理的识别问题，其核心可表述如下。给 n 个个体提问，n_0 人拒答。目标变量 W 取值0或1，p 是 $n_1 = n - n_0$ 个回答者中观测到 W=1 的比例。估计 $P(W=1)$ 时，常直接使用 p，这就意味着未观测结果与已观测结果具有相同分布。但若只将 p 视作 $P(W=1 \mid R=1)$ 的良好估计，其中 R=1 表示 W 被观测，R=0 表示个体拒答，则：

$$P(W=1) = P(W=1, R=1) + P(W=1, R=0)$$

$$= P(W=1 \mid R=1)P(R=1) + P(W=1 \mid R=0)P(R=0).$$

显然，$P(W=1 \mid R=0)$ 未知；以 p 估计 $P(W=1)$，实际上假定前者也由 p 估计。然而，已知的仅是 $P(W=1 \mid R=0) \in [0, 1]$。因此，可利用以下上、下界：

$$P(W=1) \leq P(W=1 \mid R=1)P(R=1) + P(R=0),$$

$$P(W=1) \geq P(W=1 \mid R=1)P(R=1).$$

分别用 n_1/n 与 n_0/n 估计 $P(R=1)$、$P(R=0)$，得到边界估计：

$$p\frac{n_1}{n} \leq \widehat{P}(W=1) \leq p\frac{n_1}{n} + \frac{n_0}{n}.$$

Rässler（2002）进一步发展这一“识别”概念，利用多重插补估计无条件关联的上下界。

提出的解决方案建立在贝叶斯推断和数据增广算法之上。给定未知参数向量 $\theta \in \Theta$，指定观测数据的概率模型；再把 θ 视为具有某种先验分布的随机变量，用给定现有数据的后验分布总结关于它的推断。Rässler（2002）证明，联合分布的似然同时接受观测数据与先验的贡献。此外，数据未被观测

时，先验预测分布并不以先前观测为条件。于是，通过先验信息和多重插补程序替代识别问题；采用有信息先验的多重插补技术，克服条件独立假设的限制。对条件关联设置不同先验，可以显示无条件关联对这些设置的敏感性，以及共同变量在决定无条件关联时所发挥的作用。

Rässler（2003）通过统计匹配的非迭代贝叶斯方法（NIBAS），进一步扩展Rässler（2002）的初步框架。该方法不对 $\mathbf{x}$ 作分布假设，只要求匹配变量能够充当线性回归模型的预测矩阵。统计匹配特有的缺失结构，使得可以定义数据模型与先验分布，并据此推导观测数据后验。利用多重插补程序，将先验信息用于缺失数据插补，再由插补数据估计上下界，获得无条件关联参数的取值范围；这个范围可作为统计匹配的质量度量。

针对可识别性问题的贝叶斯解决方案，对方法发展至关重要，因为它明确指出：如果两个变量并非联合观测，或者更确切地说从不联合观测，则无法通过似然推断估计相关条件关联参数。相比之下，多年来提出和使用的最近邻方案常有一个缺点：即使没有假定条件独立，它也会在事实上产生条件独立。为克服这一问题及其影响，NIBAS 至少假定 Y、Z 各自服从一元正态分布，并假定 $f\left(\mathbf{y},\ \mathbf{z} \mid \mathbf{x}\right)$ 为多元正态分布。然后，NIBAS 假定 A、B 一般线性模型的回归参数与协方差矩阵 $\mathbf{\Sigma}_{\mathbf{y},\mathbf{z}|\mathbf{x}}$ 独立；结合适当的无信息先验，可以推导观测数据后验分布和条件预测分布。从后者可随机抽取参数，并获得插补的 $\mathbf{y}$、$\mathbf{z}$。

为评估匹配变量 $\mathbf{x}$ 的预测能力，Rässler（2004）通过模拟证明贝叶斯方法具有明显优势：回归插补对真实总体相关性的估计并非无偏，甚至不是渐近无偏；贝叶斯统计匹配却可保留条件相关性的先验取值，优于其他方法。这表明，如果有辅助数据且必须利用先验信息，作者提出的贝叶斯多重插补程序是可用的最佳选择。

5 不确定性：老问题，新挑战

5.1 约束问题

21世纪最初五年，解决统计匹配识别问题的“第三条道路”开始兴起。[7] 此前，通常通过对 (Y,Z) 作特定建模，或利用关于 $f(Y,\ Z)$ 的辅助信息来处理。新方法被称为“不确定性分析”“部分识别”或“上下概率研究”。这些方法共同深化了如下认识：统计匹配至少在宏观层面的主要目标，应是估计不可识别参数的潜在取值范围，并使其与可估计参数相一致（Di Zio和Vantaggi，2017）。换言之，重点应是借助共同变量，降低从未联合观测变量关联参数的不确定性。

D’Orazio等（2006a）指出，即使完全知道 $f(X,\ Y)$ 与 $f(X,\ Z)$，也不能就 $f(X,\ Y,\ Z)$ 得出结论，因为只有当两个二元分布之间存在确定性关系时，才能预测联合分布。考虑20世纪70年代常用的 X、Y、Z 交叉表方法，令 $\left(X^{\star},\ Y^{\star},\ Z^{\star}\right)$ 为类别数分别为 F、G、H 的三元组，则表中单元格可定义为：

$$\iota = \{\left(f,\ g,\ h\right) : f = 1,\ \ldots,\ F;\ \ g = 1,\ \ldots,\ G;\ \ h = 1,\ \ldots,\ H\}.$$

未知的联合分布 $f\left(X^{\star},\ Y^{\star},\ Z^{\star}\right)$ 是多项分布，由 $\theta_{fgh} = P\left(X = f,\ Y = g,\ Z = h\right)$ 定义，$f = 1,\ \ldots,\ F$，$g = 1,\ \ldots,\ G$，$h = 1,\ \ldots,\ H$。因此，真实但未知的参数向量 θ^{*}_{fgh} 决定该分布。D’Orazio等（2006a）指出，这个向量完全不确定，但如果完全知道 $\left(X^{\star},\ Y^{\star}\right)$、$\left(X^{\star},\ Z^{\star}\right)$ 的边际

分布，就能对它施加限制。参数 θ^{*}_{fgh} 位于由上下限界定的区间中，其全部可能值决定一个由所有 θ^{*}_{fgh} 的频数构成的密度函数。利用 $\widehat{\theta}_{fg.}$、$\widehat{\theta}_{f.h}$ 的极大似然估计，可以证明，适当约束有助于从 Θ 中排除不合逻辑的取值。

Conti等（2013）从生态推断角度出发，以总体计数给出边际的列联表为起点，估计有序类别变量的联合分布 $f\left(X^{\star}, Y^{\star}, Z^{\star}\right)$。如果表中的行、列计数来自不同样本 A、B，则问题纯粹是估计联合分布函数，即宏观统计匹配。提出的方案是估计 $\left(X^{\star}, Y^{\star}, Z^{\star}\right)$ 的可能分布类，并识别估计模型的不确定性度量。通过单元格计数的上下界定义不确定性，必要时利用结构零约束限制条件及无条件不确定性。在目标随机变量为类别变量时，这种参数约束经常使用，即对某些 (f,g,h) 定义 $\theta_{fgh} = 0$（Agresti, 2013）。结构零出现在：（1）(f,g,h) 中至少一对类别不相容；或者（2）每一对类别均合理，但三元组不相容。

此约束对整合很有用，因为它可能将似然脊缩减为唯一分布。具体而言，若目标是把 Θ 限制在闭且凸的子空间 $\Omega \subset \Theta$ 内，则需要找到使似然函数 $L(\theta \mid A \cup B)$ 最大的 $\theta \in \Omega$ 集合。原文关于参数子集与无约束似然脊交集的表示如下：

$$\Omega \cap \mathcal{P}_{\widehat{\theta}_{x}\widehat{\theta}_{y|x}\widehat{\theta}_{z|x}} \neq \varnothing,$$

$$\Omega \cap \mathcal{P}_{\widehat{\theta}_{x}\widehat{\theta}_{y|x}\widehat{\theta}_{z|x}} = \widehat{\theta}.$$

这里考察子空间与无约束似然脊有非空交集的情形。结构零可以提供如此充分的信息，使交集退化为唯一的 $\widehat{\theta}$。例如，对每个 $X = f$，$f = 1, \ldots, F$，定义 $(G-1)(H-1)$ 个独立结构零约束，就足以获得唯一极大似然估计。Conti等（2013）的模拟结果显示，不确定性的下降与给定 $X^{\star}$ 时 $Y^{\star}$、$Z^{\star}$ 条件分布支撑集的缩减成正比。此外，不确定性高度依赖结构零约束的信息量。

利用所谓Fréchet界（或“不确定性类”），可以估计 $\left(X^{\star}, Y^{\star}, Z^{\star}\right)$ 的可能分布类（D’Orazio等, 2017）。这里变量是类别型；下文将讨论Conti等（2017b）对连续 Y、Z 和离散 X 的处理。这些界确定用于定义 $(Z \mid X)$、$(Y \mid X)$ 边际分布的待估参数的合理上下界。具体而言，给定来自 A 的 $\widehat{\theta}_{y|x}$、来自 B 的 $\widehat{\theta}_{z|x}$ 和来自 $A \cup B$ 的 $\widehat{\theta}_{x}$，(Y,Z) 列联表单元格频率 θ_{yz} 可通过下列类别获得：

$$\max\{0; \hat{\theta}_{y|x} + \hat{\theta}_{z|x} - 1\} \leq \hat{\theta}_{yz|x} \leq \min\{\hat{\theta}_{y|x}; \hat{\theta}_{z|x}\}. \qquad (1)$$

这个不确定性类既能评估统计匹配的不确定性，也能验证整个整合过程。Rässler（2002）提出，在多元正态情形下评估不可识别参数对应类别的长度，最终定义条件独立假设下估计的可靠性度量。结果表明，如果不确定性类较短，不同模型的参数估计与条件独立假设下的估计差异很小。此外，Rässler（2002）定义不确定性度量为：

$$\frac{1}{K}\sum_{k}\left(\widehat{\theta}^{(U)}_{k} - \widehat{\theta}^{(L)}_{k}\right).$$

其中 θ_{k}（$k = 1, \ldots, K$）为 (X,Y,Z) 参数模型中的不可识别参数，$\widehat{\theta}^{(U)}_{k}$、$\widehat{\theta}^{(L)}_{k}$ 是相应不确定性类的估计上下界。

Conti等（2017b）进一步发展这一思路，在特定非参数情境中提出不确定性度量并研究其性质。参数角度下，不确定性可由不可识别参数估计值的范围来量化；非参数角度下，这种度量则与 (Y,Z) 的“内在”关联有关。以Fréchet界为起点，可用适当泛函度量不确定性类的长度。令 $dF(x,\ y,\ z) = dQ(x)\,dS(y,\ z \mid x)$ 为三个随机变量 (X,Y,Z) 的联合分布函数，其中 Q(x) 是 X 的边际分布函数，$S(y,\ z \mid x)$ 是给定 X 时 (Y,Z) 的分布函数。X 是离散匹配变量，Y、Z 连续。在给定 X 的条件下，可取得与一元分布函数 $G(y \mid x)$、$H(z \mid x)$ 相容的全部 $S(y,\ z \mid x)$ 的可能模型集合，即Fréchet类。

令上下界分别为：

$$L\left[G(y \mid x),\ H(z \mid x)\right] = \max\left[H(z \mid x) + G(y \mid x) - 1,\ 0\right],$$

$$U\left[G(y \mid x),\ H(z \mid x)\right] = \min\left[H(z \mid x),\ G(y \mid x)\right].$$

这与式（1）类似。对每个 (y,z)，考虑不等式 $L\left[G(y \mid x),\ H(z \mid x)\right] \le S(y,\ z \mid x) \le U\left[G(y \mid x),\ H(z \mid x)\right]$。若这两个不等式成立，且 L、U 是边际为 $G(y \mid x)$、$H(z \mid x)$ 的联合分布函数，则这两个分布的Fréchet类定义为：

$$\mathcal{S} = \{S(y,z|x) : \mathrm{L}\left[G(y|x),\ H(z|x)\right] \le S(y,z|x) \le \mathrm{U}\left[G(y|x),\ H(z|x)\right]\}. \quad (2)$$

因此，分布函数集合 $\mathcal{S}$ 定义非参数统计匹配框架中的不确定性类。对 X 的分布取期望，可定义无条件Fréchet类：

$$\mathcal{S} = \{S(y,z) : E\left[\mathrm{L}\left(G(y|x),\ H(z|x)\right)\right] \le S(y,z) \le E\left[\mathrm{U}\left(G(y|x),\ H(z|x)\right)\right]\}. \quad (3)$$

显然，式（3）中的不确定性类并未利用 A、B 中共同观测的变量。由于 X 的每个类别在 A、B 中都被观测，可将式（1）改写为以下形式，得到Fréchet类估计量：

$$\left\{\max\left[\hat{H}_{n_\mathrm{B}}(z|x) + \hat{G}_{n_\mathrm{A}}(y|x) - 1,\ 0\right],\ \min\left[\hat{H}_{n_\mathrm{B}}(z|x),\ \hat{G}_{n_\mathrm{A}}(y|x)\right]\right\}. \quad (4)$$

此外，无条件Fréchet界的估计为：

$$\left\{\sum_x \hat{p}(x)\max\left[\hat{H}_{n_\mathrm{B}}(z|x) + \hat{G}_{n_\mathrm{A}}(y|x) - 1,\ 0\right],\ \sum_x \hat{p}(x)\min\left[\hat{H}_{n_\mathrm{B}}(z|x),\ \hat{G}_{n_\mathrm{A}}(y|x)\right]\right\}, \quad (5)$$

其中 $\widehat{p}(x) = \left(n_{A,x} + n_{B,x}\right)/\left(n_A + n_B\right)$ 估计 $P(X = x)$。[8]

Conti等（2017b）为式（4）中的Fréchet类估计量构造置信区域，再利用Kolmogorov–Smirnov（KS）统计量，建立 $G(y \mid x)$ 和 $H(z \mid x)$ 的置信带，分别为：

$$\mathcal{G}_{n_{\mathrm{A}},x} = \left(\hat{G}_{n_{\mathrm{A}}}(y|x) - \frac{k_\alpha}{\sqrt{n_{\mathrm{A},x}}},\ \hat{G}_{n_{\mathrm{A}}}(y|x) + \frac{k_\alpha}{\sqrt{n_{\mathrm{A},x}}}; y \in \mathbb{R} \right),$$
$$\mathcal{H}_{n_{\mathrm{B}},x} = \left(\hat{H}_{n_{\mathrm{B}}}(z|x) - \frac{k_\alpha}{\sqrt{n_{\mathrm{B},x}}},\ \hat{H}_{n_{\mathrm{B}}}(z|x) + \frac{k_\alpha}{\sqrt{n_{\mathrm{B},x}}}; z \in \mathbb{R} \right), \tag{6}$$

其中 k_α 为KS分布的 $1-\alpha$ 分位数。定义：

$$\underline{\hat{S}}(y,z|x) = \max\left\{ \hat{H}_{n_{\mathrm{B}}}(z|x) - \frac{k_\alpha}{\sqrt{n_{\mathrm{B},x}}} + \hat{G}_{n_{\mathrm{A}}}(y|x) - \frac{k_\alpha}{\sqrt{n_{\mathrm{A},x}}} - 1,\ 0 \right\},$$
$$\overline{\hat{S}}(y,z|x) = \min\left\{ \hat{H}_{n_{\mathrm{B}}}(z|x) + \frac{k_\alpha}{\sqrt{n_{\mathrm{B},x}}},\ \hat{G}_{n_{\mathrm{A}}}(y|x) + \frac{k_\alpha}{\sqrt{n_{\mathrm{A},x}}} \right\}, \tag{7}$$

可得到Fréchet类的置信区域：

$$\mathcal{S}_n^x = \{S(y,\ z \mid x) : \underline{\widehat{S}}\,(y,\ z \mid x) \le S(y,\ z \mid x) \le \overline{\widehat{S}}\,(y,\ z \mid x)\}.$$

逐点不确定性由区间 $\{L[G(y \mid x),\ H(z \mid x)],\ U[G(y \mid x),\ H(z \mid x)]\}$ 的长度 U−L 给出。由于每个三元组 x、y、z 都有一个度量，Conti等（2017b）进一步将逐点度量汇总为单一平均长度。他们在 $\mathbb{R}^3$ 上定义权函数 T(x,y,z)，并计算：

$$\int_{\mathbb{R}^3} \{U[G(y \mid x),\ H(z \mid x)] - L[G(y \mid x),\ H(z \mid x)]\}\, dT(x,\ y,\ z).$$

取 $dT(x,\ y,\ z) = dQ(x)\, d[G(y \mid x),\ H(z \mid x)]$，整体度量为：

$$\int_{\mathbb{R}} \left\{ \int_{\mathbb{R}^2} \{\mathrm{U}[G(y|x),\ H(z|x)] - \mathrm{L}[G(y|x),\ H(z|x)]\}\, d[G(y|x),\ H(z|x)] \right\} dQ(x).$$

这一度量的主要发现是：不存在外部辅助信息时，内在不确定性既不依赖支撑集，也不依赖 $f(Y,\ Z)$ 的边际分布，即 $G(y \mid x)$、$H(z \mid x)$。Conti等（2017b）证明，不论样本数据如何，最大不确定性均为1/6。相反，存在辅助信息时，可通过施加逻辑约束降低不确定性。

在真实数据应用中，对参数集合中不合逻辑的情形设定边界具有现实意义。至少有两类可靠情形：某些信息的存在值得怀疑，或者某些信息具有不等式特征。例如，8岁雇员显然属于第一种情况；第二种情况可考虑“拥有文凭的临时工”的概率高于“无学位经理”的概率。既然“逻辑约束自然产生于应用”（Vantaggi，2008，第710页），就必须妥善处理。Vantaggi（2008）改造de Finetti（1974）的概率理论，提出利用相容的条件概率结合不同来源的数据，而不必对 (X,Y,Z) 的关系作强假设。此外，还可纳入逻辑约束；即使不存在这些约束、必须假定条件独立，作者也证明条件评估仍可保持相容。对于同一总体、相同抽样方案的情形，迄今Vantaggi（2008）是唯一利用相容条件概率整合数据的方案，既考虑两个来源，也考虑多个来源。

Vantaggi（2008）提出基于极大似然估计减少不相容性的框架；Brozzi等（2012）则进一步提出基于距离最小化的方案。其特定调整对需要去除不相容性的参数子域进行加权定位，性能优于Vantaggi（2008）最初的相容性评估。

Di Zio和Vantaggi（2017）针对匹配变量被误分类时的部分识别问题，研究了一个特殊议题。他们忽略估计量抽样变异对识别区域的影响，评估不同误分类场景。对于类别变量，通过相容概率的上下界，描述部分可识别区域，即扩展从不同来源信息获得的条件概率的概率类。当共同变量仅在两个待匹配数据集中的一个被误报时，作者证明：对误分类机制作假设，可以提高分布的潜在相容性。换言之，可借助关于匹配变量误分类的假设，细化可识别区域。

Conti等（2016，2017a）在分层抽样设计下考察整合不确定性对合成完整数据集质量的影响。第一项研究提出匹配引入“误差”的具体度量，估计未联合观测变量的分布函数及相应误差，并给出误差上界。如果能识别给定或不给定匹配变量条件下 (X,Y,Z) 的可能分布类，其大小便定义不确定性度量。作者证明，这个受约束Fréchet类中的可容许分布，与所选匹配分布之间的差异，基本上就是匹配程序的误差。该误差可利用迭代比例拟合估计，给出从该类中选择一个分布时可能产生的最大误差，也就是抽取真实但未知 $f(X,\ Y,\ Z)$ 的一个替代分布所产生的最大误差。

5.2 抽样框架与大数据

以上讨论的不同整合方法，主要考虑概率样本。然而，由于（1）无回答率不断上升；（2）实际数据收集成本；（3）大数据提供的潜力，数据质量与所需资源之间的权衡促使人们探索其他机会，例如非概率样本。后者目前代表着数据整合最有潜力的解决方案（Lohr和Raghunathan，2017）。重要例子包括网络调查、社交媒体数据、手机记录和网络爬虫软件数据。Rivers（2007）针对网络调查，提出最近邻大规模插补：在非概率样本（如网络面板）上训练给定 X 的 Y 预测模型，再用其预测概率样本的 $f(Y \mid X)$，后者是从总体框中抽取的常规随机样本。

这一思路旨在解决概率调查中的无回答问题。从覆盖目标总体且包含辅助变量的抽样框中选出的个体，无须直接回答问卷；相反，为他们分配面板中具有相似特征的替代者，面板同样包含上述辅助变量，并由这些替代者填写问卷。Bethlehem（2016）进一步研究这类“样本匹配”，考察其最有效运行的条件。作者指出，此插补方法取决于辅助变量完全解释参与行为的能力；这种能力越强，无回答偏差消除得越充分。

另一个方案是，将非概率样本的“回答倾向”估计为协变量 $\mathbf{x}$ 的函数，再据此为非概率数据加权。Castro-Martín等（2022）改造Lee（2006）的方法，通过考虑“若采用概率抽样设计，该样本会是什么样”的假想情景，估计个体参与非概率样本的倾向。作者提出的训练方法有助于降低选择偏差，在预测中“赋予更可能出现在总体中的个体更大的重要性”（Castro-Martín等，2022，第17页）。仍有若干局限：需要在不同数据集、更多场景中检验结果的可重复性，可以纳入其他预测算法，并须进一步发展理论性质。

一个重要挑战是：结合不同来源的大数据，例如纳入大型调查数据时，前景良好的匹配型插补本质上仍建立在随机缺失假设之上。例如，Chen等（2020a）在对非概率样本选择机制作参数模型假设的基础上提出权重调整，Chen等（2020b）进一步将其扩展至非参数框架。Kim等（2021）则超越随机缺失假设，提出一种大数据抽样机制，允许在协变量调整后仍考虑样本之间的系统差异。然后使用概率样本估计缺失数据，纠正大数据的覆盖不足偏差；这里，大数据被视为有限总体的一个不完整抽样框。

6 结论（以及更广阔的世界）

最近，统计匹配在官方统计领域重新受到关注，既因为大数据的作用，也因为数据提供者越来越需要尽快生产更详细、更精准的信息（de Waal，2015）。如果缺失信息部分存在于单一数据集中，可用多重插补；如果不同文件中观测单位的唯一标识符缺失或误报，可用概率记录链接，而这些文件本身不应不完整。与两者密切相关的统计匹配，则可以处理在两个或更多数据集中从未联合观测的变量。在数据收集和信息共享的潜在来源、工具越来越多的世界中，这一特点有助于应对许多实践挑战。

Gessendorfer等（2018）提出一个缩小记录链接与统计匹配差距的重要方案：当专项调查等来源中的某些个体不同意链接，导致其行政数据无法与调查信息汇集时，以统计匹配补充记录链接。在这种特殊缺失背景下，为拒绝授权链接的个体提供变量取值，从而整合原本无法整合的信息。然而，作者强调，在链接观测之前对拒绝同意者进行匹配，会得到互相矛盾的结果，提示潜在问题可能比直接忽略缺少授权还严重。

针对高维问题，Ahfock等（2016）处理多元 $(\mathbf{x}, \mathbf{y}, \mathbf{z})$，旨在识别联合分布 $f(\mathbf{x}, \mathbf{y}, \mathbf{z})$ 的参数。他们建议从参数识别集合抽取取值，以抽样值范围度量部分识别参数的不确定性，这些参数需要联合观测 $\mathbf{y}$、$\mathbf{z}$。方案采用基于Gibbs抽样的方法，为部分指定的协方差矩阵估计一组正定补全。对于涉及多元正态、偏正态和正态混合模型的真实数据问题，这是一种可推广的解决途径。通过将模拟与真实数据结果同贝叶斯方法比较，Ahfock等（2016）证明，在获得接近真实观测相关性的估计方面，其频率学派抽样方法显著优于贝叶斯方法。此外，该方法灵活，计算速度突出。

除了大数据可能发挥的作用，统计匹配近期发展还涉及多种理论挑战。参数统计匹配已得到广泛分析，而非参数统计匹配仍留下若干问题，例如距离型热卡技术应采用何种最优距离函数、供体类别的“大小”，以及这些因素在多大程度上影响合成完整数据集的方差估计。

另一个悬而未决的问题，是调查权重及构建不同数据集所用的抽样设计。Marella和Pfeffermann（2019）最近提出结合不同样本信息的方案，在信息性抽样设计下，将统计匹配结果的不确定性，与在“盲目”条件独立假设下、即忽略信息性抽样机制时产生的不确定性比较。模拟证明，忽略样本选择过程及其影响，会损害对 X、Y、Z 的预测。因此，生成的合成完整数据集不同于底层总体分布 $f(X, Y, Z)$，从而产生偏差；即使忽略选择效应的估计可能具有较小方差，情况仍然如此。

Conti等（2019）强调，统计匹配应用并不十分普遍，是因为数据由不同复杂调查设计获得，妨碍信息的直接协调。然而，如果生态推断已经能够从汇总数据得出个体层面结论，统计匹配也可借助作为某种“分组”的匹配变量，重新导向推断。由于两个领域尚未共享解决方案，作者建议探索这一可能。此外，未来发展可针对其不确定性度量中隐含的不完整性：该方案虽很适合捕捉“数据集的不确定性”，却在某种程度上未能度量“匹配质量”。衡量统计匹配质量的指标，可能是重要研究方向。

在匹配过程中纳入抽样权重，以及更广义地考虑待整合样本的特征，尤其重要，因为只有另两项工作讨论过这些挑战：Rubin（1986）和Renssen（1998）。前者建议根据 $A \cup B$ 超样本中的单位计算新权重，但实践适用性很有限，因为不知道 A 中单位在 B 的抽样设计下的纳入概率。后者建议依据共同信息，对不同样本 A、B 的实际权重进行校准，从而获得与 (Y,X)、(X,Z) 边际相容的分布。不过，D’Orazio（2009）证明，两种方案的结果十分相似。

实践中，未来最主要的改进涉及辅助信息。为了从整合数据获得足够准确的统计量，应最有效地使用哪类辅助变量？额外来源中的哪类信息对整合更有帮助：总体总量知识，还是现有变量之间的关系知识？此外，是否值得反复开展专项调查，以获取不同数据源中部分目标变量的信息？当现实中不存在完整形式的数据时，又如何评估整合数据推断的质量？换言之，当我们自己就是实施整合的用户时，如何评估质量？这些问题要求进一步开展模拟研究，考察不同参数设定与依赖结构对插补表现的影响。同时，应开展真实数据应用，为匹配数据集建立直接明了的数据质量标准。

作者贡献、经费与开放获取

作者贡献。 本文主要基于RD在MR指导下完成的博士论文。概念构思：RD、MR；文献检索：RD；数据分析：RD；初稿撰写：RD；审阅与编辑：RD；修订：RD。

经费。 博洛尼亚大学在CRUI-CARE协议框架下提供开放获取经费。

开放获取。 本文依据知识共享署名4.0国际许可发布。只要适当注明原作者及来源、提供许可链接并说明是否作出修改，就允许以任何媒介或形式使用、共享、改编、分发与复制。除非材料署名另有说明，文中的图片或其他第三方材料包含于该许可。如果材料不在该许可范围内，而预期使用不被法律允许或超出允许范围，则须直接向权利人获取许可。许可全文：http://creativecommons.org/licenses/by/4.0/ 。

附录A 应用与软件

本附录聚焦具有以下关键特征的统计匹配贡献：（1）主要是方法的实践应用；（2）经验示例；或（3）基于真实世界数据的技术报告。

A.1 20世纪70年代至90年代的应用

从70年代初至90年代末，存在两大“数据整合学派”：以Okner（1972）为早期代表的北美学派（见第3.1节）和欧洲学派。后者在统计匹配研究史中较少为人所知，至少可分为法国、德国、英国三个学派，不同作者主要在营销研究中应用匹配方法。

在美国和加拿大，统计匹配主要用于整合官方统计、国家部门及联邦机构的行政登记和一手数据。

- Budd（1971）通过匹配不同来源，整合用于估计收入规模分布的微观数据文件。主要目标是纠正或补充美国现期人口调查原有的收入估计。背景：美国商务部商业经济办公室。
- Okner（1972）整合1967年美国经济机会调查与1966年美国税务文件的微观数据。背景：美国经济机会办公室。
- Alter（1974）整合1970年加拿大消费者财务调查与1970年家庭支出调查。背景：加拿大统计局支出司。
- Ruggles和Ruggles（1974）给出1970年美国公共使用样本与社会保障纵向雇主—雇员数据文件整合的经验示例。
- Radner等（1980）讨论多个经验示例，以评估美国政府部门、研究机构和官方统计产生的不同数据源的整合。
- Gavin（1985）整合收入与教育调查和1976年全国健康访谈调查。背景：美国卫生与公众服务部。

- Armstrong（1989）整合消费者财务调查与加拿大税务局税务数据。背景：加拿大统计局企业调查方法司。

欧洲的统计匹配在法国、德国、英国大体独立发展，但都属于媒体营销研究。公共机构与私人研究机构一方面整合电视与其他媒体数据，另一方面整合媒体数据与购买信息。

- 据我们所知，Bergonier等（1967）首次将匹配技术用于媒体营销分析。
- Rässler（2002，第46–47页及其中引文）列出若干德国70年代的经验示例：德国媒体分析协会与Wendt事务所开展并整合了杂志阅读、广播收听和电视观看年度调查。
- Wiegand（1986）整合不同特征和媒体排期指标，将广播媒体信息转移到平面媒体调查。
- Antoine和Santini（1987）在“媒体—市场计划”中整合多种媒体调查，如电影观众调查和读者自填调查。
- Baker等（1989）和O’Brien（1991）整合英国目标群体指数（TGI）与广播受众研究委员会（BARB）的数据。
- Roberts（1994）整合BARB与英国大型市场追踪面板AGB Superpanel的数据。
- Adamek（1994）给出利用TGI和BARB数据分析整合技术表现的经验示例。
- Darkow（1996）整合电视观看行为专项调查与其他媒体数据。
- Kamakura和Wedel（1997）将拉丁美洲多分支银行客户满意度调查与内部记录整合。

A.2 21世纪00年代至今的应用

过去20年，统计匹配在多个研究领域应用，但都采用共同、一致、统一的理论框架。

- Sutherland等（2002）整合英国家庭支出调查与英国家庭资源调查，用于财政政策模拟。
- Denk和Hackl（2003）在欧盟资助的“企业绩效竞争力和财政影响指标体系开发”（DIECOFIS）项目中，给出收入和纳税申报不同来源的整合示例。
- Abello和Phillips（2004）整合全国健康调查与住户支出调查。背景：澳大利亚统计局方法咨询委员会。
- Ballin等（2009）整合农场会计数据网络（FADN）与农场结构调查（FSS）。背景：意大利国家统计局。
- Agafitei和Leulescu（2013）讨论两个经验示例：（1）将欧盟收入与生活状况统计同欧洲生活质量调查匹配，整合生活质量数据；（2）将欧盟收入与生活状况统计同劳动力调查匹配，整合劳动与工资数据。背景：欧盟委员会欧洲统计局。
- Gutman等（2013）将美国医疗保险和医疗补助服务中心数据与Visual Statistics死亡率数据匹配，整合微观数据文件，用于估计和预测医疗费用及生命末期支出。
- Roesch和Lips（2013）整合瑞士农业经营单位的FSS与FADN数据。
- D’Orazio和Catanese（2016）将农业经营单位经济成果年度调查与FADN结合，估计意大利农业经营单位的能源生产表现。背景：联合国粮农组织经济与社会发展部。
- D’Alberto等（2018）结合意大利FADN数据与欧盟第七框架计划资助项目的调查，用于农业政策影响评估。

A.3 软件

- Rässler（2003）：非迭代贝叶斯插补（NIBAS）算法，S-PLUS 2000（MathSoft, Inc.）。

- Alpman（2016）：统计匹配命令 `smpc` 和 `smmatch`，Stata 14（StataCorp, LLC.）。
- D’Orazio（2020）：`StatMatch`软件包，R（R Foundation for Statistical Computing）。

参考文献

以下完整保留原文书目信息，便于准确检索；题名及出版信息不作意译。

Abello R, Phillips B (2004) Statistical matching of the HES and NHS: an exploration of issues in the use of unconstrained and constrained approaches in creating a basefile for a microsimulation model of the pharmaceutical benefits scheme. ABS Technical Working Paper. Technical report. pp 1–44

Adamek JC (1994) Fusion: combining data from separate sources. Market Mag Manag Appl 6:48–50

Agafitei M, Leulescu A (2013) Statistical matching: a model based approach for data integration. Eurostat methodologies and working papers. Technical report. pp 1–100

Agresti A (2013) Categorical data analysis. Wiley, London

Ahfock D, Pyne S, Lee SX, McLachlan GJ (2016) Partial identification in the statistical matching problem. Comput Stat Data Anal 104:79–90. https://doi.org/10.1016/j.csda.2016.06.005

Alpman A (2016) Implementing Rubin’s alternative multiple-imputation method for statistical matching in Stata. Stata J 16:717–739. https://doi.org/10.1177/1536867X1601600311

Alter HE (1974) Creation of a synthetic data set by linking records of the Canadian Survey of Consumer Finances with the Family Expenditure Survey. Ann Econ Soc Meas 3:373–394

Anderson TW (1957) Maximum likelihood estimates for a multivariate normal distribution when some observations are missing. J Am Stat Assoc 52:200–203. https://doi.org/10.2307/2280845

Antoine J, Santini G (1987) Fusion techniques: alternative to single-source methods. Eur Res 15:178–187

Armstrong J (1989) An evaluation of statistical matching methods. Business Survey Methods Division— statistics Canada. Technical report, 1–48

Baker K, Harris P, O’Brien J (1989) Data fusion: an appraisal and experimental evaluation. J Market Res Soc 31:153–212

Ballin M, D’Orazio M, Di Zio M, Scanu M, Torelli N (2009) Statistical matching of two surveys with a common subset. Università di Trieste Working papers. Technical report. pp 1–12

Barry JT (1988) An investigation of statistical matching. J Appl Stat 15:275–283. https://doi.org/10.1080/02664768800000038

Bergonier H, Boucharenc L, Irrmann P (1967) Une nouvelle methode d’ analyse globale des resultats d’ une enquete etablissement de typologies. Rev Française de Market 25:31–41

Bethlehem J (2016) Solving the nonresponse problem with sample matching? Soc Sci Comput Rev 34:59–77

Brozzi A, Capotorti A, Vantaggi B (2012) Incoherence correction strategies in statistical matching. Int J Approx Reason 53:1124–1136. https://doi.org/10.1016/j.ijar.2012.06.009

Budd EC (1971) The creation of a microdata file for estimating the size distribution of income. Rev Income Wealth 11:317–334. https://doi.org/10.1111/j.1475-4991.1971.tb00785.x

Castro-Martín L, Rueda MM, Ferri-García R (2022) Combining statistical matching and propensity score adjustment for inference from non-probability surveys. J Comput Appl Math 404:3414. https://doi.org/10.1016/j.cam.2021.113414

Chen Y, Li P, Wu C (2020a) Doubly robust inference with non-probability survey samples. J Am Stat Assoc 115:2011–2021. https://doi.org/10.1080/01621459.2019.1677241

Chen S, Yang S, Kim JW (2020b) Nonparametric mass imputation for data integration. J Surv Stat Methodol. https://doi.org/10.1093/jssam/smaa036

Christen P (2012) Data matching: concepts and techniques for record linkage, entity resolution, and duplicate detection. Springer, Berlin

Chung CK, Cheng PE (1995) Nonparametric regression estimation with missing data. J Stat Plan Inference 48:85–99. https://doi.org/10.1016/0378-3758(94)00151-K

Cohen ML (1991) Statistical matching and microsimulation models. In: Citro CF, Hanushek EA (eds) Improving information for social policy decisions—the uses of microsimulation modeling: Volume II, technical papers. The National Academies Press, Washington DC, pp 62–88

Conti PL, Marella D, Scanu M (2008) Evaluation of matching noise for imputation techniques based on nonparametric local linear regression estimators. Comput Stat Data Anal 53:354–365. https://doi.org/10.1016/j.csda.2008.07.041

Conti PL, Marella D, Scanu M (2013) Uncertainty analysis for statistical matching of ordered categorical variables. Commun Stat-Theor Methods 68:311–325. https://doi.org/10.1016/j.csda.2013.07.004

Conti PL, Marella D, Scanu M (2016) Statistical matching analysis for complex survey data with applications. J Am Stat Assoc 111:1715–1725. https://doi.org/10.1080/01621459.2015.1112803

Conti PL, Marella D, Neri A (2017a) Statistical matching and uncertainty analysis in combining household income and expenditure data. Stat Methods Appl 26:485–505. https://doi.org/10.1007/s10260-016-0374-7

Conti PL, Marella D, Scanu M (2017b) How far from identifiability? A systematic overview of the statistical matching problem in a non parametric framework. Commun Stat-Theor Methods 46:967–994. https://doi.org/10.1080/03610926.2015.1010005

Conti PL, Marella D, Scanu M (2019) An overview on uncertainty and estimation in statistical matching. In: Zhang L-C, Chambers RL (eds) Analysis of integrated data. CRC Press, Boca Raton, pp 73–96

D'Alberto R, Zavalloni M, Raggi M, Viaggi D (2018) AES impact evaluation with integrated farm data: combining statistical matching and propensity score matching. Sustainability 10:1–24. https://doi.org/10.3390/su10114320

D'Orazio M (2009) Uncertainty intervals for nonidentifiable parameters in statistical matching. In: Proceedings of the 57th Session of the International Statistical Institute, Durban (South Africa), August 2009

D'Orazio M (2015) Statistical matching and imputation of survey data with StatMatch. Italian National Institute of Statistics—ISTAT. Technical report. pp 1–35

D'Orazio M (2020) Statistical matching and imputation of survey data with StatMatch. R package version 1.4.0. https://cran.r-project.org/package=StatMatch

D'Orazio M, Catanese E (2016) Evaluating revenues and economic growth for farms producing renewable energies: an investigation based on integration of FSS and EOAH 2013 survey data. In: Proceedings of the Seventh International Conference on Agricultural Statistics. pp 1–8

D'Orazio M, Di Zio M, Scanu M (2006a) Statistical matching for categorical data: displaying uncertainty and using logical constraints. J Off Stat 22:137–157

D'Orazio M, Di Zio M, Scanu M (2006b) Statistical matching: theory and practice. Wiley, Hoboken

D'Orazio M, Di Zio M, Scanu M (2017) The use of uncertainty to choose matching variables in statistical matching. Int J Approx Reason 90:433–440. https://doi.org/10.1016/j.ijar.2017.08.015

Darkow M (1996) Compatible or not? Results of a single source field experiment within a TV audience research panel. Market Res Today 24:150–161

de Finetti B (1974) Theory of probability. Wiley, London

de Waal T (2015) Statistical matching: experimental results and future research questions. Statistics Netherlands. Technical report. pp 1–33

Denk M, Hackl P (2003) Data integration and record matching: an Austrian contribution to research in official statistics. Austrian J Stat 32:305. https://doi.org/10.17713/ajs.v32i4.464

Di Zio M, Vantaggi B (2017) Partial identification in statistical matching with misclassification. Int J Approx Reason 82:227–241. https://doi.org/10.1016/j.ijar.2016.12.015

Dunn HL (1946) Record linkage. Am J Public Health 36:1412–1416

Fellegi IP, Sunter AB (1969) A theory for record linkage. J Am Stat Assoc 64:1183–1210

Gavin NI (1985) An application of statistical matching with the survey of income and education and the 1976 Health Interview Survey. Health Serv Res 20:183–198

Gessendorfer J, Beste J, Drechsler J, Sakshaug JW (2018) Statistical matching as a supplement to record linkage: a valuable method to tackle nonconsent bias? J Off Stat 34:909–933. https://doi.org/10.2478/JOS-2018-0045

Grace J (2006) Composite variables and their uses. In: Grace J (ed) Structural equation modeling and natural systems. Cambridge University Press, Cambridge, pp 143–180

Gutman R, Afendulis CC, Zaslavsky AM (2013) A Bayesian procedure for file linking to analyze end-of-life medical costs. J Am Stat Assoc 108:34–47. https://doi.org/10.1080/01621459.2012.726889

Harron K, Goldstein H, Dibben C (2016) Methodological developments in data linkage. Wiley, Chichester

Iaccarino G (2019) Metrics and methods for uncertainty quantification, presentation to the new techniques and technologies for statistics (NTTS – 2019), Brussels, 11–15 March 2019. https://ec.europa.eu/eurostat/cros/system/files/iaccarino_ntts2019.pdf

Judson DH (2005) Computerized record linkage and statistical matching. In: Kempf-Leonard K (ed) Encyclopedia of social measurement, vol 2. Elsevier, Amsterdam, pp 439–447

Kadane JB (1978) Some statistical problems in merging data files. Compendium of Tax Research—U.S. Department of the Treasury. Technical report. pp 159–171

Kamakura WA, Wedel M (1997) Statistical data fusion for cross-tabulation. J Market Res 34:485–498

Kim JW, Tam S-M (2021) Data integration by combining Big Data and survey sample data for finite population inference. Int Stat Rev 89:382–401. https://doi.org/10.1111/insr.12434

Klevmarken NA (1982) Missing variables and two-stage least squares estimation from more than one data set. In: Proceedings of the American Statistical Association—business and economic statistics section. pp 156–161

Lee S (2006) Propensity score adjustment as a weighting scheme for volunteer panel web surveys. J Off Stat 22:329–349

Lohr SL, Raghunathan TE (2017) Combining survey data with other data sources. Stat Sci 32:293–312

Manski CF (1995) Identification problems in the social sciences. Harvard University Press, Cambridge

Mardia KV, Kent JT, Bibby JM (1980) Multivariate analysis (probability and mathematical statistics). Academic Press, London

Marella D, Pfeffermann D (2019) Matching information from two independent informative samples. J Stat Plan Inference 203:70–81. https://doi.org/10.1016/j.jspi.2019.03.001

Marella D, Scanu M, Conti PL (2008) On the matching noise of some nonparametric imputation procedures. Stat Probab Lett 78:1593–1600. https://doi.org/10.1016/j.spl.2008.01.020

Moriarity C, Scheuren F (2001) Statistical matching: a paradigm for assessing the uncertainty in the procedure. J Off Stat 17:407–422

Moriarity C, Scheuren F (2003) A note on Rubin’s statistical matching using file concatenation with adjusted weights and multiple imputations. J Bus Econ Stat 21:65–73

Murray JS (2018) Multiple imputation: a review of practical and theoretical findings. Stat Sci 2:142–159. https://doi.org/10.1214/18-STS644

Newcombe HB, Kennedy J, Axford S, James A (1959) Automatic linkage of vital records. Science 130:954– 959

Nielsen SF (2001) Nonparametric conditional mean imputation. J Stat Plan Inference 99:129–150. https://doi.org/10.1016/S0378-3758(01)00087-8

O’Brien S (1991) The role of data fusion in actionable media targeting in the 1990’s. Market Res Today 19:15–22

Okner BA (1972) Constructing a new data base from existing microdata sets: the 1966 merge file. Ann Econ Soc Meas 1:325–342

Pentland S (2019) Better decisions with data, presentation to the new techniques and technologies for statistics (NTTS—2019), Brussels, 11–15 March 2019. https://ec.europa.eu/eurostat/cros/system/files/pentland_ntts_2019.pdf

Radner DB, Allen R, Gonzalez ME, Jabine TB, Muller HJ (1980) Report on exact and statistical matching techniques. Statistical policy paper 5—U.S. Department of Commerce. Technical report. pp 1–58

Rao JNK (2021) On making valid inferences by integrating data from surveys and other sources. Sankhya 83:242–272

Rässler S (2002) Statistical matching: a frequentist theory, practical applications, and alternative bayesian approaches. Springer, New York

Rässler S (2003) A non-iterative Bayesian approach to statistical matching. Stat Neerl 57:58–74. https://doi.org/10.20378/irbo-55154

Rässler S (2004) Data fusion: identification problems, validity, and multiple imputation. Austrian J Stat 33:1538

Renssen RH (1998) Use of statistical matching techniques in calibration estimation. Surv Methodol 24:171– 183

Rivers D (2007) Sampling for web surveys. In: Proceedings of the American Statistical Association—Joint statistical meetings, Salt Lake City. pp 1–26

Roberts A (1994) Media exposure and consumer purchasing: an improved data fusion technique. Market Res Today 22:150–172

Rodgers WL (1984) An evaluation of statistical matching. J Bus Econ Stat 2:91–102. https://doi.org/10.2307/1391358

Rodgers WL, DeVol E (1981) An evaluation of statistical matching. In: Proceedings of the American Statistical Association—section on survey research methods. pp 128–132

Roesch A, Lips M (2013) Sampling design for two combined samples of the Farm Accountancy Data Network (FADN). J Agric Biol Environ Stat 18:178–203. https://doi.org/10.1007/s13253-013-0130-5

Rubin RD (1974) Characterizing the estimation of parameters in incomplete-data problems. J Am Stat Assoc 69:467–474. https://doi.org/10.2307/2285680

Rubin RD (1976) Inference and missing data. Biometrika 63:581–592. https://doi.org/10.1093/biomet/63.3.581

Rubin RD (1986) Statistical matching using file concatenation with adjusted weights and multiple imputations. J Bus Econ Stat 4:87–94. https://doi.org/10.2307/1391390

Rubin DB (1987) Multiple imputation for nonresponse in surveys. Wiley, New York

Ruggles R, Ruggles N (1974) A strategy for merging and matching microdata sets. Ann Econ Soc Meas 3:353–371

Schulte Nordholt E (1998) Imputation: methods, simulation experiments and practical examples. Int Stat Rev 66:157–180. https://doi.org/10.2307/1403488

Sims CA (1972a) Comments. Ann Econ Soc Meas 1:343–345

Sims CA (1972b) Rejoinder. Ann Econ Soc Meas 1:355–357

Singh AC, Armstrong JB, Lemaitre GE (1988) Statistical matching using log-linear imputation. In: Proceedings of the American Statistical Association—section on survey research methods. pp 672–677

Singh AC, Mantel HJ, Kinack MD, Rowe G (1993) Statistical matching: use of auxiliary information as an alternative to the conditional independence assumption. Surv Methodol 19:59–79

Sutherland H, Taylor R, Gomulka J (2002) Combining household income and expenditure data in policy simulations. Rev Income Wealth 48:517–536. https://doi.org/10.1016/10.1111/1475-4991.00066

United Nations Economic Commission for Europe (UNECE) (2017) A guide to data integration for official statistics, technical report of the data integration project—version 1.0. High Level Group for the Modernisation of Official Statistics (HLG-MOS)

Vantaggi B (2008) Statistical matching of multiple sources: a look through coherence. Int J Approx Reason 49:701–711. https://doi.org/10.1016/j.ijar.2008.07.005

Walter SD (1984) Required sample size for categorical matching. J Am Stat Assoc 79:662–667

Wiegand J (1986) Combining different media surveys: the German partnership model and fusion experiments. J Market Res Soc 28:189–208

出版者声明。 Springer Nature对已发表地图及机构隶属关系中涉及的管辖权主张保持中立。

---

1. 在不重叠数据集上采用多重插补时，关键问题是无法估计全部相关模型参数，因为只度量了抽样方差和插补方差。因此，多重插补未考虑模型不确定性。↩

2. 同时使用直接观测和计算得到的匹配变量。后者的例子是总营业收入或财产收入，通过相应组成部分（应税股息、利息、储蓄等）的绝对金额加总获得。↩

3. 当确实出现这些差异时，采用的解决办法仅为人工修订，如Okner（1972）。↩

4. 复合变量由两个或更多在概念或统计意义上高度相关的变量或测量构成。通常采用量表、评分或类别变量来构建（Grace，2006）。整合复合变量可能改变其与潜在结果变量的关系强度、改变统计功效、过度或不足地压缩信息，并造成解释复合变量与目标结果关系的困难。但这类变量也有潜在优点，例如可以利用在 A 中观测到的、对从 B 插补的变量的代理变量信息。↩

5. 篇幅所限，一般距离函数必须满足的性质参见Mardia等（1980）。↩

6. 即所有匹配变量 $X_1, \ldots, X_l, \ldots, X_{L-1}$ 均纳入模型，只排除一个。↩

7. 第4节根据Manski（1995）和Rässler（2002）的定义阐述了该问题。↩

8. $n_{A,x}$ 与 $n_{B,x}$ 分别定义为 $n_{A,x} = \sum_{i=1}^{n_A} I\left(X_i = x\right)$ 和 $n_{B,x} = \sum_{i=1}^{n_B} I\left(X_i = x\right)$。$I(x \in D)$ 是集合 D 的指示函数，$x \in D$ 时为1，否则为0。↩