带缺失标签的大规模多标签学习

非官方中文全文译文

Hsiang-Fu Yu（德克萨斯大学奥斯汀分校计算机科学系，ROFUYU@CS.UTEXAS.EDU）；Prateek Jain（微软印度研究院，班加罗尔，PRAJAIN@MICROSOFT.COM）；Purushottam Kar（微软印度研究院，班加罗尔，T-PURKAR@MICROSOFT.COM）；Inderjit S. Dhillon（德克萨斯大学奥斯汀分校计算机科学系，INDERJIT@CS.UTEXAS.EDU）。

原文：Large-scale Multi-label Learning with Missing Labels，第31届国际机器学习大会（北京，2014），PMLR 32(1):593–601。作者保留版权 © 2014。官方来源：https://proceedings.mlr.press/v32/yu14.html 。官方补充材料：https://proceedings.mlr.press/v32/yu14-supp.pdf 。根据 PMLR 出版协议（https://proceedings.mlr.press/pmlr-license-agreement.html）的 CC BY 4.0（https://creativecommons.org/licenses/by/4.0/）进行中文翻译、重排和图表裁切。本译文由 AI 在 dot 云端工作区制作，未经作者或出版方审定；不暗示其认可。公式、图表数据与参考文献保留原文含义；疑似原文错误以译注标明，不作无声修正。正文及补充材料图表均未发现单独第三方版权或排除授权的署名行。

摘要

多标签分类问题近年来受到广泛关注。然而，现有方法未能充分解决两个关键挑战：（a）扩展到具有大量标签（例如数百万个）的任务；（b）处理标签缺失的数据。本文在通用经验风险最小化（ERM）框架下研究多标签问题，直接处理这两项挑战。我们的框架虽然简单，却意外地涵盖了若干近期基于标签压缩的方法：这些方法均可作为本方法的特例导出。为优化 ERM 问题，我们利用特定损失函数（如平方损失）的结构获得高效算法。进一步地，我们证明即使标签缺失，该学习框架也具有超额风险界。所给界是紧的，表明促进低秩的迹范数正则化比不感知秩的 Frobenius 范数正则化具有更好的泛化性能。最后，我们在多种基准数据集上给出广泛实验，表明本方法明显优于现有标签压缩方法，并可扩展到包含超过20万个标签的 Wikipedia 等超大数据集。

1 引言

大规模多标签分类是一项重要学习问题，在图像/视频标注（Carneiro et al., 2007; Wang et al., 2009）和查询/关键词推荐（Agrawal et al., 2013）等现实任务中有多种应用。其目标是为给定数据点 $x \in \mathbb{R}^d$ 预测标签向量 $y \in \{0, 1\}^L$。结构化输出学习领域已广泛研究此问题，通常假设标签数较少，因此主要关注标签间相关性的建模及其在标签向量预测中的利用（Hariharan et al., 2010）。

受多项实际应用驱动，近期研究的关注点已大幅转向另一端，即标签数极多的情形。关键挑战是设计能实时预测、内存占用小的可扩展算法。此时，将每个标签视为独立二分类问题的一对其余或二元关联（BR）等简单方法表现很差。以许多应用中常见的 10^4 个标签、10^6 个特征的问题为例，这些方法的内存占用约为100 GB，而且预测缓慢。

近期多项工作采用“标签空间降维”处理标签数量激增问题。其核心是通过随机投影或基于典型相关分析（CCA）的投影降低标签空间维度（Chen & Lin, 2012; Hsu et al., 2009; Tai & Lin, 2012; Kapoor et al., 2012）。随后在低维标签空间预测，再投影回高维空间恢复原标签。特别是 Chen & Lin（2012）提出了一种高效算法，通过带正交约束的类 CCA 方法同时压缩标签空间和特征空间。但该方法较僵硬，不能处理多标签问题固有的若干重要问题，详见第2.1节。

本文采取更直接的途径：学习低秩线性模型 $Z \in \mathbb{R}^{d \times L}$，使 $y^{\text{pred}} = Z^T x$。我们将其置于标准 ERM 框架，允许使用多种损失函数和关于 Z 的正则项。此框架统一了若干既有降维方法。尤其当选择平方 L_2 损失时，所提形式有闭式解；令人意外的是，Chen & Lin（2012）的条件主标签空间变换（CPLST）可作为特例导出。框架的灵活性又允许使用其他损失和正则项，以防止过拟合并提高可扩展性。

此外，我们可将问题扩展到缺失标签；相反，大多数降维形式（包括 CPLST）不能容纳缺失标签。能够在标签缺失时学习至关重要，因为多数现实应用都无法期望通过人工或自动标注准确获得一个数据点的所有标签。例如图像标注人员只标出显著标签，往往遗漏图中若干对象。类似地，Wikipedia 等在线集合中的文章会被赋予类别，但标注者通常只标记自己知道的类别。标签中还可能有相当多的噪声。

为求解该形式产生的低秩线性模型，我们使用常见的交替最小化算法；尽管秩约束非凸，它仍工作良好。针对一般损失和迹范数正则化，我们利用问题中的细微结构设计快速共轭梯度方法。针对平方 L_2 损失与迹范数正则化的特例，进一步利用损失结构获得更高效、可扩展的算法。与直接计算相比，算法加速 $O(\bar{d})$ 倍，其中 $\bar{d}$ 是每个实例的平均非零特征数。

理论上，在标签均匀随机被观测的假设下，我们对带缺失标签的迹范数正则化 ERM 形式进行超额风险分析。由于标签缺失，现有结果不能直接推出我们的证明，必须进行涉及随机矩阵理论的细致分析。结果显示，一般情况下，促进低秩的迹范数正则化并不比学习满秩矩阵（如使用 Frobenius 范数正则化）给出更好的界；但对若干有意义的数据分布，迹范数正则化确实给出明显更好的界。具体而言，对于各向同性分布，迹范数方法的超额风险为 $O\left(1/\sqrt{nL}\right)$，而满秩学习只能保证 $O\left(1/\sqrt{n}\right)$，其中 n 是训练点数。

最后，我们在多种基准数据集上全面评估本方法，特别与近期三种标签压缩方法 CPLST（Chen & Lin, 2012）、Bayesian-CS（Kapoor et al., 2012）及 WSABIE（Weston et al., 2010）比较。几乎所有数据集上，无论标签缺失与否，本方法均明显更好。我们还将方法用于近期整理的 Wikipedia 数据集（Agrawal et al., 2013），其中有881,805个训练样本和213,707个标签，以说明可扩展性。结果不仅表明本方法在这类大规模问题上具有合理准确率，也表明训练时间比若干既有方法少几个数量级。

相关工作。 将每个标签作为独立二分类任务的 BR 通常在多标签学习上相当准确。但标签很多时，模型规模和预测时间增加，使其不可行。近期方法或降低标签维度，如压缩感知（Hsu et al., 2009）、PLST（Tai & Lin, 2012）、CPLST（Chen & Lin, 2012）和 Bayesian CS（Kapoor et al., 2012）；或降低特征维度，如 Sun et al.（2011）；或两者兼顾，如 WSABIE（Weston et al., 2010）。这些技术大多绑定特定损失（例如 CPLST、BCS 仅适用平方 L_2 损失，WSABIE 使用加权近似排序损失），和/或不能处理缺失标签。

本框架将多标签分类建模为带低秩约束的一般 ERM 问题，不仅概括标签与特征降维，还支持多种损失函数，并允许严格分析泛化误差。我们说明，框架不仅将已证明相当准确的 CPLST 作为特例恢复出来，而且通过正则化、其他损失函数以及对缺失标签的支持等显著增强它。

论文结构。 第2节研究一般低秩 ERM 框架；第3节提出高效算法；第4节分析迹范数正则化下的泛化性能；第5节给出实验；第6节总结。

2 问题形式化

本节提出多标签分类的一般 ERM 风格框架。每个训练点包含特征向量 $x_i \in \mathbb{R}^d$ 和含 L 个标签的向量 $y_i \in \{0, 1\}^L$。对任意 $j \in [L]$， $y_i^j = 1$ 表示该标签“存在”或“开启”， $y_i^j = 0$ 表示“缺席”或“关闭”。本文主要关注二分类，但方法易于扩展到 $y_i^j \in \{1, 2, \ldots, C\}$ 的多类情形。〔译注：原文此处将第 j 个标签写作第 l 个，符号不一致。〕

标签预测参数化为 $f(x; Z) = Z^T x$，其中 $Z \in \mathbb{R}^{d \times L}$。虽采用线性参数化，结果也容易推广到非线性核。损失 $\ell\big(y, f(x; Z)\big) \in \mathbb{R}$ 衡量真实标签与预测的偏差。我们假定其可分解：

$$\ell\big(y, f(x; Z)\big) = \sum_{j=1}^{L} \ell\big(y^j, f^j(x; Z)\big).$$

本框架的动机是：尽管多标签问题标签很多，但通常存在显著相关性，建模所需的有效参数数目远小于 dL。为刻画此直觉，我们限制 Z 只学习少量“潜在”因子，使其为低秩矩阵；这既控制过拟合，也带来计算优势。

给定 n 个训练点，训练集为 (X, Y)，其中 $X = \big[x_1, \ldots, x_n\big]^T$， $Y = \big[y_1, y_2, \ldots, y_n\big]^T$。使用损失 ℓ，通过标准 ERM 学习：

$$\widehat{Z} = \operatorname*{argmin}_Z J(Z) = \sum_{i=1}^{n} \sum_{j=1}^{L} \ell\big(Y_{ij}, f^j(x_i; Z)\big) + \lambda r(Z), \qquad \text{s.t. } \operatorname{rank}(Z) \le k. \tag{1}$$

其中 $r : \mathbb{R}^{d \times L} \to \mathbb{R}$ 为正则项。存在缺失标签时，只在已知标签上计算损失：

$$\widehat{Z} = \operatorname*{argmin}_Z J_\Omega(Z) = \sum_{(i,j) \in \Omega} \ell\big(Y_{ij}, f^j(x_i; Z)\big) + \lambda r(Z), \qquad \text{s.t. } \operatorname{rank}(Z) \le k. \tag{2}$$

$\Omega \subseteq [n] \times [L]$ 为已知标签索引集。我们采用标准缺失值设定：每个标签可能开启、关闭（$Y_{ij} = 1$ 或 0），或缺失（$Y_{ij} = ?$）。其他一些工作采用另一设定：只有正标签已知且记为1，负标签与缺失标签都记为0（Agrawal et al., 2013; Bucak et al., 2011）。

由于非凸秩约束，该形式一般是 NP 难的；不过对凸损失仍可使用标准交替最小化。对于 L_2 损失特例，我们还可推导完整标签情形（1）的闭式解，并展示与若干已有方法的联系。

需要指出，尽管 ERM 是熟知的标准框架，但现有大标签数方法多以较为临时性的方式提出。我们可证明 CPLST 等已有方法实际上是通用 ERM 框架的特例（见下一节）。此框架还帮助研究泛化误差界，并识别方法有望成功的条件（第4节）。

2.1 特例：平方 L_2 损失

本节考察（1）、（2）在 $\ell\big(y,\ f(x;\ Z)\big) = \ \| \ y - f(x;\ Z) \ \|_2^2$ 时的情形。无缺失标签时，（1）可通过 SVD 得到最优解；此外，选取适当的 $r(Z)$ 与 λ，其解恰与 CPLST 相同。先说明无正则化形式的闭式解。

断言1。若 $\ell\big(y,\ f(x;\ Z)\big) = \ \| \ y - Z^T x \ \|_2^2$ 且 $\lambda = 0$，则

$$V_X \Sigma_X^{-1} M_k = \arg\min_{Z:\mathrm{rank}\,(Z)\le k} \ \| \ Y - XZ \ \|_F^2. \qquad (3)$$

这里 $X = U_X \Sigma_X V_X^T$ 是 X 的薄 SVD，M_k 是 $M \equiv U_X^T Y$ 的秩 k 截断 SVD。证明见附录A。下面说明这恰是 Chen & Lin（2012）的 CPLST 形式所得解。

断言2。（3）的解等价于 $Z^{\mathrm{CPLST}} = W_{\mathrm{CPLST}} H_{\mathrm{CPLST}}^T$，即 CPLST 的闭式解。

证明见附录A。Chen & Lin（2012）是以较为临时性的方式，通过放松 Hamming 损失问题并舍弃 CCA 中约束导出方法。上述结果表明同一模型可更有原则地推导，这也有助于有原则地扩展到其他设定，并给出超额风险界：

- 实验证明，d 大时 CPLST 往往严重过拟合；适当设置 λ 即可处理该问题。
- CPLST 的闭式解需要对完全观测的 Y 做 SVD，无法直接处理缺失标签；本框架无需修改即可处理。
- CPLST 绑定 L_2 损失；本框架容易使用其他损失，尽管优化可能更难。

多元回归低秩解与 PCA/SVD 的联系在文献中早已存在（Izenman, 1975; Breiman & Friedman, 1997）。但这些结果主要在各类噪声模型下的随机设定中导出，而我们的结果适用于经验设定；经典结果也很少强调大规模实现。

3 算法

本节以交替最小化优化（1）、（2）。已知 Z 的秩很小、为 k 时，以 dL 个元素表示它效率低，特别是在 $d,\ L$ 很大时。因此考虑 $Z = WH^T$，其中 $W \in \mathbb{R}^{d\times k}$、$H \in \mathbb{R}^{L\times k}$。进一步假设 $r(Z)$ 可分解为 $r_1(W) + r_2(H)$。下文使用迹范数正则化 $r(Z) = \ \| \ Z \ \|_{\mathrm{tr}}$，其分解为 $\| \ Z \ \|_{\mathrm{tr}} = \frac{1}{2}\Big(\ \| \ W \ \|_F^2 + \ \| \ H \ \|_F^2\Big)$。〔译注：该等式须理解为对满足 $Z = WH^T$ 的分解取最小值后的变分表示，并非任意分解均成立；原文直接写为等式。〕于是带秩约束的 $\min_Z J_\Omega(Z)$ 等价于对 $W,\ H$ 最小化：

$$J_\Omega(W,\ H) = \sum_{(i,j)\in\Omega} \ell\Big(Y_{ij},\ x_i^T W h_j\Big) + \frac{\lambda}{2}\Big(\ \| \ W \ \|_F^2 + \ \| \ H \ \|_F^2\Big). \qquad (4)$$

h_j^T 为 H 第 j 行。固定 $W,\ H$ 任一者，$J_\Omega(W,\ H)$ 即为凸函数，因此可应用适于此性质的标准交替最小化。对于一般损失，适当初始化后生成序列：

$$H^{(t)} \leftarrow \operatorname*{argmin}_H J_\Omega\Big(W^{(t-1)},\ H\Big), \qquad W^{(t)} \leftarrow \operatorname*{argmin}_W J_\Omega\Big(W,\ H^{(t)}\Big).$$

对凸损失，若这两个子问题的最小值点均唯一定义，则 $\left(W^{(t)},\, H^{(t)}\right)$ 保证收敛到驻点（Bertsekas, 1999，命题2.7.1）。实际上，在第3.2节讨论的平方损失且 Y 完全观测情形，若 $\lambda = 0$ 或 X 正交，我们可证明它收敛至（4）的全局最小值。

固定 W 后，更新 H 很容易，因为各行可独立更新：

$$h_j \leftarrow \operatorname*{argmin}_{h\in\mathbb{R}^k} \sum_{i:(i,j)\in\Omega} \ell\left(Y_{ij},\, x_i^T W h\right) + \frac{\lambda}{2} \parallel h \parallel_2^2. \qquad (5)$$

一般 k 很小，故求解容易。依损失选择，（5）实质为含 k 个变量、$|\{i:(i,\,j)\in\Omega\}|$ 个实例的线性分类或回归。固定 H 后，因左乘 X 使变量相互混合，更新 W 更复杂。令 $\widetilde{x}_{ij} = h_j \otimes x_i$（原文称 $\otimes$ 为外积；在此向量化恒等式中按 Kronecker 积使用）。可证明更新 W 等价于含 $|\Omega|$ 个数据点 $\{\left(Y_{ij},\, \widetilde{x}_{ij}\right) : (i,\, j)\in\Omega\}$ 的正则化线性分类/回归。若 $W^* = \operatorname{argmin}_W J_\Omega(W,\, H)$，并记 $w^* = \operatorname{vec}\left(W^*\right)$，则 $w^* = \operatorname{argmin}_{w\in\mathbb{R}^{dk}} g(w)$，其中

$$g(w) \equiv \sum_{(i,j)\in\Omega} \ell\left(Y_{ij},\, w^T\widetilde{x}_{ij}\right) + \frac{\lambda}{2} \parallel w \parallel_2^2. \qquad (6)$$

以平方损失为例，这等价于 dk 个变量的正则化最小二乘。d 很大（如一百万）时，闭式解需对 $dk\times dk$ 矩阵求逆，几乎不可行。因此高效更新 W 是交替最小化的主要挑战。

当 dk 和 $|\Omega|$ 都很大时，共轭梯度（CG）等迭代法更适合求解（6）：更新便宜，少数迭代便可得到良好近似。若 $\{\widetilde{x}_{ij}\}$ 可用，LIBLINEAR（Fan et al., 2008）等线性分类/回归软件即可处理。此类方法主要计算梯度 $\nabla g(w)$ 或 Hessian 与向量乘积 $\nabla^2 g(w)s$。令 $\widetilde{X} = \left[\cdots \widetilde{x}_{ij} \cdots\right]_{(i,j)\in\Omega}^T$，$\bar{d} = \sum_{i=1}^n \parallel x_i \parallel_0 / n$，一般需至少 $\operatorname{nnz}\left(\widetilde{X}\right) = O(|\Omega|\bar{d}k)$ 的计算时间。

但下文将利用 $\widetilde{X}$ 结构，将两项操作都降至 $O((|\Omega| + \operatorname{nnz}(X) + d + L)k)$ 时间，因此 CG 等方法可加速 $O(\bar{d})$ 倍。附录B给出平方损失下求解（6）的详细 CG 程序。由此交替最小化足以高效处理大规模问题。

3.1 一般损失函数的快速操作

假设一般损失 $\ell(a,\, b)$ 二次可微，其中 $a,\, b$ 为标量。记 $\ell'(a,\, b) = \partial\ell(a,\, b)/\partial b$，$\ell''(a,\, b) = \partial^2\ell(a,\, b)/\partial b^2$。梯度和 Hessian 为

$$\nabla g(w) = \sum_{(i,j)\in\Omega} \ell'\left(Y_{ij},\, w^T\widetilde{x}_{ij}\right)\widetilde{x}_{ij} + \lambda w, \qquad (7)$$

$$\nabla^2 g(w) = \sum_{(i,j)\in\Omega} \ell''\left(Y_{ij},\, w^T\widetilde{x}_{ij}\right)\widetilde{x}_{ij}\widetilde{x}_{ij}^T + \lambda I. \qquad (8)$$

由（7）、（8）直接计算梯度及 Hessian-向量乘积至少需 $O(|\Omega|\bar{d}k)$ 时间。下面给出更快程序。

梯度计算。注意 $\widetilde{x}_{ij} = h_j \otimes x_i = \operatorname{vec}\left(x_i h_j^T\right)$。因此

$$\sum_{(i,j)\in\Omega} \ell'\left(Y_{ij},\ w^T\widetilde{x}_{ij}\right)x_i h_j^T = X^T D H,$$

其中 D 稀疏，$D_{ij} = \ell'\left(Y_{ij},\ w^T\widetilde{x}_{ij}\right)$，$(i,\ j) \in \Omega$。于是

$$\nabla g(w) = \mathrm{vec}\left(X^T D H\right) + \lambda w. \qquad (9)$$

假设 $\ell'(a,\ b)$ 可在常数时间计算（平方 L_2、logistic 等多数损失满足），则梯度计算耗时 $O((\mathrm{nnz}(X) + |\Omega| + d)k)$。算法1给出细节。

Hessian-向量乘积。代入 $\widetilde{x}_{ij} = h_j \otimes x_i$，得到

$$\nabla^2 g(w)s = \sum_{(i,j)\in\Omega} \ell''_{ij}\left(\left(h_j h_j^T\right) \otimes \left(x_i x_i^T\right)\right)s + \lambda s,$$

其中 $\ell''_{ij} = \ell''\left(Y_{ij},\ w^T\widetilde{x}_{ij}\right)$。令 $S \in \mathbb{R}^{d\times k}$ 满足 $s = \mathrm{vec}(S)$。利用 $\left(B^T \otimes A\right)\mathrm{vec}(X) = \mathrm{vec}(AXB)$，有 $\left(\left(h_j h_j^T\right) \otimes \left(x_i x_i^T\right)\right)s = \mathrm{vec}\left(x_i x_i^T S h_j h_j^T\right)$。故

$$\begin{aligned}\sum_{ij} \ell''_{ij} x_i x_i^T S h_j h_j^T &= \sum_{i=1}^{n} x_i\Big(\sum_{j:(i,j)\in\Omega} \ell''_{ij}\left(S^T x_i\right)^T h_j h_j^T\Big) \\ &= \sum_{i=1}^{n} x_i\Big(\sum_{j:(i,j)\in\Omega} U_{ij} h_j^T\Big) = X^T U H.\end{aligned}$$

这里 U 稀疏，$U_{ij} = \ell''_{ij}\left(S^T x_i\right)^T h_j$，$(i,\ j) \in \Omega$。所以

$$\nabla^2 g(w)s = \mathrm{vec}\left(X^T U H\right) + \lambda s. \qquad (10)$$

算法1根据（10），在 $O((\mathrm{nnz}(X) + |\Omega| + d)k)$ 时间计算 Hessian-向量乘积。

算法1：带缺失标签的一般损失。原算法保留如下，随后给出逐步中文说明。

Algorithm 1 General Loss with Missing Labels

To compute $\nabla g(\boldsymbol{w})$:

1. $A \leftarrow XW$, where $\boldsymbol{vec}(W) = \boldsymbol{w}$.
2. $D_{ij} \leftarrow \ell'(Y_{ij}, \boldsymbol{a}_i^T \boldsymbol{h}_j),\ \forall (i,j) \in \Omega$.
3. **Return**: $\boldsymbol{vec}\left(X^T(DH)\right) + \lambda \boldsymbol{w}$

To compute: $\nabla^2 g(\boldsymbol{w})\boldsymbol{s}$

1. $A \leftarrow XW$, where $\boldsymbol{vec}(W) = \boldsymbol{w}$.
2. $B \leftarrow XS$, where $\boldsymbol{vec}(S) = \boldsymbol{s}$.
3. $U_{ij} \leftarrow \ell''(Y_{ij}, \boldsymbol{a}_i^T \boldsymbol{h}_j)\boldsymbol{b}_i^T \boldsymbol{h}_j,\ \forall (i,j) \in \Omega$.
4. **Return**: $\boldsymbol{vec}\left(X^T(UH)\right) + \lambda \boldsymbol{s}$.

计算 $\nabla g(w)$：（1） $A \leftarrow XW$，其中 $\mathrm{vec}(W) = w$；（2）对所有 $(i,\ j) \in \Omega$，$D_{ij} \leftarrow \ell'\left(Y_{ij},\ a_i^T h_j\right)$；（3）返回 $\mathrm{vec}\left(X^T(DH)\right) + \lambda w$。计算 $\nabla^2 g(w)s$：（1） $A \leftarrow XW$；（2） $B \leftarrow XS$，其中 $\mathrm{vec}(S) = s$；（3） $U_{ij} \leftarrow \ell''\left(Y_{ij},\ a_i^T h_j\right) b_i^T h_j$；（4）返回 $\mathrm{vec}\left(X^T(UH)\right) + \lambda s$。

损失函数。附录B.1给出平方、logistic、平方 hinge 三种常见损失的 ℓ' 、 ℓ''。因此，平方损失可用 CG 求解（6），其他两种可用 TRON（Lin et al., 2008）。

3.2 完整标签平方损失的快速操作

标签完全观测时，大规模高效求解（1）仍有挑战。（3）的闭式解不理想有两个原因：其一，需要对 X 与 $U_X^T Y$ 做 SVD， X 秩大时不可行；其二，没有正则化，可能过拟合。CPLST 也因缺少正则化和需计算 X 伪逆而存在类似问题。 Y 完全观测时，面向一般损失与缺失标签的算法1也不够可扩展，因为 $|\Omega| = nL$，每步需 $O(nLk + \mathrm{nnz}(X)k)$，当 $n,\ L$ 都大时难以承受。

一般损失的 $O(nLk)$ 成本似乎不可避免，但对 L_2 损失，我们提出使每步代价只依赖 $\mathrm{nnz}(Y)$ 而非 $|\Omega|$ 的程序。多数真实多标签问题有 $\mathrm{nnz}(Y) \ll nL = |\Omega|$，故即使 $|\Omega| = nL$，平方损失下也可高效交替最小化。

使用平方损失且 Y 完全观测时，（9）中 $D = XWH^T - Y$， $\mathrm{vec}(W) = w$。于是

$$\nabla g(w) = \mathrm{vec}\left(X^T XWH^T H - X^T YH\right) + \lambda w. \qquad (11)$$

同样，（10）中 $U = XSH^T$，从而

$$\nabla^2 g(w)s = \mathrm{vec}\left(X^T XSH^T H\right) + \lambda s. \qquad (12)$$

仔细选择矩阵乘法次序，算法2只需 $O\left(nk + k^2\right)$ 额外空间，并在 $O\left((\mathrm{nnz}(Y) + \mathrm{nnz}(X))k + (n + L)k^2\right)$ 时间高效计算两项操作。

算法2：完整标签的平方损失。

Algorithm 2 Squared Loss with Full Labels

To compute $\nabla g(\boldsymbol{w})$:

1. $A \leftarrow XW$, where $\boldsymbol{vec}(W) = \boldsymbol{w}$.
2. $B \leftarrow YH$.
3. $M \leftarrow H^T H$.
4. **Return**: $\boldsymbol{vec}\left(X^T(AM - B)\right) + \lambda \boldsymbol{w}$

To compute: $\nabla^2 g(\boldsymbol{w})\boldsymbol{s}$

1. $A \leftarrow XS$, where $\boldsymbol{vec}(S) = \boldsymbol{s}$.
2. $M \leftarrow H^T H$.
3. **Return**: $\boldsymbol{vec}\left(X^T(AM)\right) + \lambda \boldsymbol{s}$

计算 $\nabla g(w)$：（1） $A \leftarrow XW$， $\mathrm{vec}(W) = w$；（2） $B \leftarrow YH$；（3） $M \leftarrow H^T H$；（4）返回 $\mathrm{vec}\left(X^T(AM - B)\right) + \lambda w$。计算 $\nabla^2 g(w)s$：（1） $A \leftarrow XS$， $\mathrm{vec}(S) = s$；（2） $M \leftarrow H^T H$；（3）返回 $\mathrm{vec}\left(X^T(AM)\right) + \lambda s$。

关于并行化。两个算法均以矩阵乘法为关键子程序。因此使用高度优化的并行 BLAS 库（如 ATLAS、Intel MKL），即可无需额外工作地利用并行矩阵运算加速。附录E图3表明，随核心数增加，两种算法确实获得显著加速。

关于核扩展。给定核 $K(\cdot, \cdot)$，令 $f^j \in \mathcal{H}_K$ 为（2）经验损失的极小化函数。由表示定理（如 Schölkopf et al., 2001）， f^j 可表示为 $f^j\left(\cdot; z_j\right) = \sum_{t=1}^{n} z_{jt} K\left(\cdot, x_t\right)$，其中 $z_j \in \mathbb{R}^n$。定义 $k(x) = \left[\cdots, K\left(x, x_t\right), \cdots\right]^T$，则 $f(x; Z) = Z^T k(x)$， Z 为第 j 列为 z_j 的 $n \times L$ 矩阵。仍可施加（4）中相同迹范数正则化和低秩约束。于是 $Z = WH^T$， $f^j\left(x_i, z_j\right) = k^T\left(x_i\right) W h_j$。若 K 是训练集核 Gram 矩阵， K_i 为其第 i 列，（4）中损失可替换为 $\ell\left(Y_{ij}, K_i^T W h_j\right)$。因此交替最小化也可求解核扩展后的（1）、（2）。

4 泛化误差界

本节分析迹范数正则化模型的超额风险界，说明它相对于 BR 和 Frobenius 范数正则化的优势。由于标签缺失，标准结果不适用，必须更细致地分析。

多标签学习模型由数据与标签空间 $\mathcal{X} \times \{0, 1\}^L$ 上的分布 $\mathcal{D}$（ $\mathcal{X} \subseteq \mathbb{R}^d$），以及决定标签缺失模式的分布刻画。我们获得从 $\mathcal{D}$ 独立同分布抽样的 n 个训练点 $\left(x_1, y_1\right), \ldots, \left(x_n, y_n\right)$，其中 y_i 为真实标签向量，但只能在 s 个随机位置观测它。具体而言，位置 $l_i^1, \ldots, l_i^s \in [L]$ 从 $[L]$ 均匀选取，且选择与 $\left(x_i, y_i\right)$ 独立。

给定训练数据，在受约束预测器集合上进行 ERM：

$$\widehat{Z} = \arg\inf_{r(Z) \le \lambda} \widehat{\mathcal{L}}(Z), \qquad \widehat{\mathcal{L}}(Z) = \frac{1}{n} \sum_{i=1}^{n} \sum_{j=1}^{s} \ell\left(y_i^{l_i^j}, f^{l_i^j}(x_i; Z)\right).$$

$\widehat{\mathcal{L}}$ 为经验风险。虽然式（2）使用带秩约束的正则化形式，为简化，这里仅分析不带秩约束的正则化版本。由于带秩约束的矩阵类别比迹范数受约束类别更小，若能精确求解 ERM，实际泛化性能可以预期优于此处所示。目标是证明 $\widehat{Z}$ 有良好泛化性质，即

$$\mathcal{L}(\widehat{Z}) \le \inf_{r(Z) \le \lambda} \mathcal{L}(Z) + \epsilon, \qquad \mathcal{L}(Z) := \mathbb{E}_{x,y,l}\left[\ell\left(y^l, f^l(x; Z)\right)\right].$$

定理3。在 n 个训练点上，用 $\widehat{Z} = \mathrm{arginf}_{\|Z\|_{\mathrm{tr}} \le \lambda} \widehat{\mathcal{L}}(Z)$ 学习预测器，则至少以概率 $1 - \delta$，

$$\mathcal{L}(\widehat{Z}) \le \inf_{\|Z\|_{\mathrm{tr}} \le \lambda} \mathcal{L}(Z) + O\left(s\lambda\sqrt{\frac{1}{n}}\right) + O\left(s\sqrt{\frac{\log(1/\delta)}{n}}\right),$$

其中不失一般性假定 $\mathbb{E}\left[\ \| x \|_2^2\right] \le 1$。

证明见附录C。有趣的是，通过一致收敛界得到的分析是紧的，一般不能改进；紧性论证见附录D.1。但 Frobenius 范数正则化也可给出相同超额风险界，因此该结果尚未显示迹范数优势。尽管如此，对一类一般的 $(x,\ y)$ 分布仍可取得改进界。

定理4。数据分布满足：（1）协方差矩阵 $\mathsf{X} = \mathbb{E}_{x\sim\mathcal{D}}\left[xx^T\right]$ 的最大奇异值为 $\| \mathsf{X} \|_2 = \sigma_1$；（2）$\mathrm{tr}(\mathsf{X}) = \Sigma$；（3）$\mathcal{X}$ 上的分布次高斯，即存在 $\eta > 0$，对所有 $v \in \mathbb{R}^d$，$\mathbb{E}\left[\exp\left(x^T v\right)\right] \le \exp\left(\| v \|_2^2 \eta^2/2 \right)$。则至少以概率 $1-\delta$，

$$\mathcal{L}(\widehat{Z}) \le \inf_{\|Z\|_{\mathrm{tr}}\le\lambda} \mathcal{L}(Z) + O\left(s\lambda\sqrt{\frac{d\left(\eta^2+\sigma_1\right)}{nL\Sigma}} + s\sqrt{\frac{\log(1/\delta)}{n}} \right).$$

特别地，若数据点从标准正态分布产生，则

$$\mathcal{L}(\widehat{Z}) \le \inf_{\|Z\|_{\mathrm{tr}}\le\lambda} \mathcal{L}(Z) + O\left(s\lambda\sqrt{\frac{1}{nL}} \right) + O\left(s\sqrt{\frac{\log(1/\delta)}{n}} \right).$$

证明见附录C。由于特征向量与缺失标签之间复杂的相互作用，证明既不能由已有矩阵预测器学习技术（如 Kakade et al., 2012）直接推出，也不能由迹范数矩阵补全结果（Shamir & Shalev-Shwartz, 2011）直接推出。我们改为使用新形式的 Rademacher 平均，需要随机矩阵理论工具来控制它。结果甚至可处理标签非均匀采样（见附录C定理6）。

支撑在紧集上的任意分布都容易以有限的 σ_1, η 满足数据分布假设。但对某些分布，这使迹范数具有更好的界。即使这些分布下，Frobenius 正则化也不能获得优于 $\lambda/\sqrt{n}$ 量级的超额误差界（证明见附录D.2），而迹范数可给出更优的 $\lambda/\sqrt{nL}$。例如 $\lambda = O\left(\sqrt{L}\right)$ 时，对比尤为鲜明：迹范数给出 $O\left(1/\sqrt{n}\right)$，Frobenius 则恶化至 $O\left(\sqrt{L/n}\right)$。因此迹范数似乎更适于利用各向同性分布。

直觉如下：标签观测非常稀疏，如 $s = O(1)$ 时，每个标签只在 $O(n/L)$ 个训练点上被观测。此时，取 $\lambda = \sqrt{L}$ 的 Frobenius 正则化实质允许为每个标签 $l \in [L]$ 学习独立的 $z_l \in \mathbb{R}^d$。这些预测器各自只有 $O(n/L)$ 个训练点，性能因此受损。

相反，若为所有标签训练同一个预测器，即对某个 $z \in \mathbb{R}^d$ 有 $Z = z\mathbf{1}^T$，它便能观测 $O(n)$ 个点，泛化性更好。该预测器也满足 $\| z\mathbf{1}^T \|_{\mathrm{tr}} \le \sqrt{L}$。这提示迹范数比 Frobenius 更能捕获跨标签依赖，尤其在标签缺失时。

尽管如此，两种正则化会在学习框架中引入不同偏差。研究它们的偏差-方差权衡是有趣的方向。不过存在标签相关性时，我们预期两种形式具有类似偏差。

〔译注：原文经验风险对每样本的 s 项求和，而总体风险写为单个随机标签的期望；此处照录该归一化约定，没有自行补入 $1/s$。定理的损失有界性和 Lipschitz 条件在补充证明中使用，应结合附录阅读。〕

5 实验结果

下面从准确率和稳定性评估所提算法，展示其相对其他方法的优势。

数据集。 使用多种基准数据，包括四个标准集（bibtex、delicious、eurlex、nus-wide）、两个 $d \gg L$ 的集（autofood、compphys），以及基于 Wikipedia 的超大规模集（约一百万页面、20万标签）。详情见表1。全部实验在32核 Intel 机器上完成。

			Training set			Test set		
Dataset	d	L	n	$\bar{d}$	$\bar{L}$	n	$\bar{d}$	$\bar{L}$
bibtex	1,836	159	4,880	68.74	2.40	2,515	68.50	2.40
autofood	9,382	162	155	143.92	15.80	38	143.71	13.71
compphys	33,284	208	161	792.78	9.80	40	899.02	11.83
delicious	500	983	12,920	18.17	19.03	3,185	18.80	19.00
eurlex	5,000	3,993	17,413	236.69	5.30	1,935	240.96	5.32
nus-wide	1,134	1,000	161,789	862.70	5.78	107,859	862.94	5.79
wiki	366,932	213,707	881,805	146.78	7.06	10,000	147.78	7.08

表1：数据统计。 d, L 分别为特征数、标签数； $\bar{d}$, $\bar{L}$ 分别为每实例平均非零特征数与正标签数。Training set / Test set 为训练集/测试集， n 为样本数。表内数值保持原版。

比较方法。 下列为包括本方法在内的对比方法。没有纳入 CS（Hsu et al., 2009）和 PLST（Tai & Lin, 2012），因为 Chen & Lin（2012）、Kapoor et al.（2012）已表明它们不及 CPLST 和 BCS。

1. **LEML**（用于多标签学习的低秩经验风险最小化）：本方法。平方损失使用结合算法1、2的 CG；logistic 和平方 hinge 使用结合算法1的 TRON（Lin et al., 2008）。
2. **CPLST**：Chen & Lin（2012）的方法，使用作者代码。
3. **BCS**：Kapoor et al.（2012）的方法，使用作者代码。
4. **BR**：采用多种损失的二元关联。
5. **WSABIE**：没有公开代码，因此自行实现，并按作者建议（Weston, 2013）针对每个数据集手工调节学习率和间隔。

评估标准。 使用 top- K 准确率（少数最高预测的表现）、Hamming 损失（整体分类表现）、平均 AUC（排序表现）三种指标。细节见附录E.1。

5.1 完整标签结果

数据分为两组：所有方法均可处理的小数据集（bibtex、autofood、compphys、delicious），以及只有 LEML 与 WSABIE 能扩展到的大数据集（eurlex、nus-wide、wiki）。

小数据集。 先比较基于降维的方法在不同降维比例下的表现。图1报告平方 L_2 损失下 LEML、CPLST、BCS 结果，并列 BR 供参考。LEML 在所有比例下均持续优于其他方法。随后以平方、logistic、 L_2 -hinge 三种替代损失下的 LEML 与近似优化加权近似排序损失的 WSABIE 比较。表2显示，虽每个数据集最好的损失不同，LEML 始终优于或可比于 WSABIE。

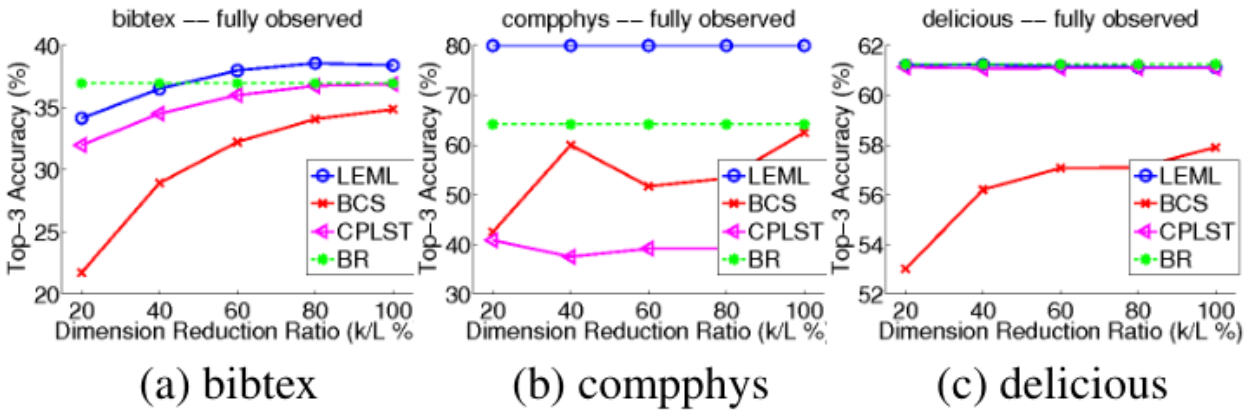


图1： 完全观测 Y 时，改变降维比例比较不同降维方法。（a）bibtex；（b）compphys；（c）delicious。横轴 Dimensional Reduction Ratio：降维比例（%）；纵轴 Top-3 Accuracy：前三准确率（%）；曲线名称为 LEML、BCS、CPLST、BR。

		Top-3 Accuracy				Average AUC			
		LEML			WSABIE	LEML			WSABIE
	k/L	SQ	LR	SH		SQ	LR	SH	
bibtex	20%	**34.16**	25.65	27.37	28.77	0.8910	0.8677	0.8541	**0.9055**
	40%	**36.53**	28.20	24.81	30.05	0.9015	0.8809	0.8467	**0.9092**
	60%	**38.00**	28.68	23.26	31.11	0.9040	0.8861	0.8505	**0.9089**
autofood	20%	**81.58**	80.70	**81.58**	66.67	0.9565	**0.9598**	0.9424	0.8779
	40%	76.32	**80.70**	78.95	70.18	0.9277	**0.9590**	0.9485	0.8806
	60%	70.18	80.70	**81.58**	60.53	0.8815	**0.9582**	0.9513	0.8518
compphys	20%	**80.00**	**80.00**	**80.00**	49.17	0.9163	0.9223	**0.9274**	0.8212
	40%	**80.00**	78.33	79.17	39.17	**0.9199**	0.9157	0.9191	0.8066
	60%	**80.00**	**80.00**	**80.00**	49.17	**0.9179**	0.9143	0.9098	0.8040
delicious	20%	**61.20**	53.68	57.27	42.87	0.8854	0.8588	**0.8894**	0.8561
	40%	**61.23**	49.13	52.95	42.05	0.8827	0.8534	**0.8868**	0.8553
	60%	**61.15**	46.76	49.58	42.22	0.8814	0.8517	**0.8852**	0.8523

表2： 小数据集上不同损失的 LEML 与 WSABIE 对比。SQ：平方损失；LR：logistic 回归损失；SH：平方 hinge 损失。Top-3 Accuracy：前三准确率；Average AUC：平均 AUC。

结合图1、表2与附录E.3，还可观察到：（1）即使维度大幅缩减，LEML 也可达到与 BR 相当的准确率；（2）在 bibtex 与 compphys 上，LEML 甚至优于 BR，这是低秩 Z 能捕获标签关系的设计优势，使其比 BR 更好利用标签信息并获得更高准确率；（3）在 autofood、compphys 上，CPLST 似乎过拟合，性能明显下降。相反，在形式中引入正则化的 LEML 在所有数据集上持续表现良好。

大数据集。 表3比较三个大数据集上的 LEML 与 WSABIE。完整标签情形使用算法2实现平方 L_2 损失的 LEML。此处不用 Hamming 损失，因为不清楚如何将 WSABIE 给出的排序转为0/1编码。LEML 报告五轮交替迭代后的时间与准确率。WSABIE 以手工调好的参数在每个数据集上运行约两天，报告平均 AUC 最高那一轮的时间与结果。

		LEML				WSABIE			
dataset	k	time (s)	top-1	top-3	AUC	time (s)	top-1	top-3	AUC
eurlex	250	**175**	**51.99**	**39.79**	**0.9425**	373	33.13	25.01	0.8648
	500	**487**	**56.90**	**44.20**	**0.9456**	777	31.58	24.00	0.8651
nus-wide	50	**574**	**20.71**	**15.96**	**0.7741**	4,705	14.58	11.37	0.7658
	100	**1,097**	**20.76**	**16.00**	**0.7718**	6,880	12.46	10.21	0.7597
wiki	250	**9,932**	**19.56**	14.43	**0.9086**	79,086	18.91	**14.65**	0.9020
	500	**18,072**	**22.83**	**17.30**	**0.9374**	139,290	19.20	15.66	0.9058

表3： 大数据集上 LEML 与 WSABIE 比较。time (s)：耗时（秒）；top-1 / top-3：第一/前三准确率；k：降维后的秩。

在 eurlex、nus-wide 上，LEML 在所有标准上明显更好。wiki 上，$k = 250$ 时二者接近，增至500后 LEML 再次胜出。训练时间差异同样显著：LEML 不到6小时即在 wiki 达到0.9374 AUC，WSABIE 则需约1.6天才能达到0.9058。具体而言，WSABIE 第一轮约7,000秒，第二轮16,000秒，第三轮36,000秒，以至仅5轮便耗去近两天。其采样方案（Weston et al., 2010）使此现象符合预期，但 L 增大时问题更严重。设计适于大 L 的更好采样方案留作后续研究。图2a进一步展示 nus-wide 上的时间差距。总体结果清楚表明 LEML 的可扩展性与效率。

5.2 缺失标签结果

比较 LEML、BCS、BR。带缺失标签的 BR 为每个标签，仅在已观测实例上学习 L_2 正则化二分类器/回归器，因此对应（2）配合 Frobenius 正则化的极小化模型。表4报告20%元素可见（缺失率80%）、使用平方损失训练的结果。LEML 与 BCS 均取 $k = 0.4L$。原文称结果显示“LEML 在三项标准上均优于 BCS 和 LEML”。〔译注：此处原文第二个 LEML 显然与比较对象及表4不一致，疑应为 BR；保留原句并明确标注，不默改。〕

	Top-3 Accuracy			Hamming loss			Average AUC		
	LEML	BCS	BR	LEML	BCS	BR	LEML	BCS	BR
bibtex	**28.50**	23.84	25.78	**0.0136**	0.2496	0.0193	**0.8332**	0.7871	0.8087
autofood	**67.54**	35.09	62.28	**0.0671**	0.2445	0.0760	**0.8634**	0.6322	0.8178
compphys	**65.00**	35.83	31.67	**0.0518**	0.2569	0.0566	**0.7964**	0.6442	0.7459

表4： Y 中20%元素被观测、$k = 0.4L$ 时不同降维方法比较。Top-3 Accuracy：前三准确率；Hamming loss：Hamming 损失；Average AUC：平均 AUC。

bibtex 上还在图2b给出不同观测比例结果，在图2c给出不同降维比例结果。LEML 明显优于其他方法，印证第4节关于促进低秩正则化具有更好泛化性能的理论。其他损失、观测比例和降维比例的更多结果见附录E.4。

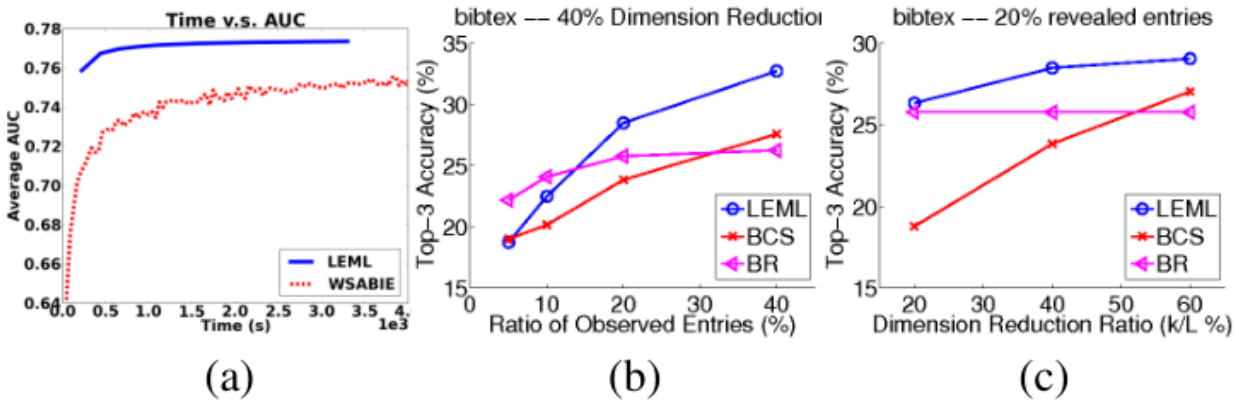


图2： （a）nus-wide 上运行时间；（b）bibtex 上不同标签观测比例；（c）bibtex 上不同降维比例。（a）横轴 Running time (s)：运行时间（秒），纵轴 Average AUC：平均 AUC；（b）横轴 Ratio of Observed Entries (%)：已观测元素比例；（c）横轴 Dimensional Reduction Ratio (%)：降维比例；后两图纵轴 Top-3 Accuracy：前三准确率。图例保留方法缩写。

6 结论

本文在标准 ERM 框架下研究带缺失标签的多标签学习，以秩约束和正则项建模来提高可扩展性与效率。为求解所得非凸问题，提出交替最小化方法，关键在于利用损失结构实现扩展。我们证明框架具有超额风险界，表明相对于 BR 等既有方法，本方法泛化性能更好，实验也予以确认。实验还表明，该技术比其他大规模多标签分类器效率高得多，并优于现有标签压缩方法。今后希望将 LEML 扩展至排序损失等不可分解损失，并研究保证本问题交替最小化收敛到全局最优的条件。另一个开放问题是：是否能不走本文所用的一致收敛路线，从而改进风险界。

致谢

感谢一位审稿人指出降秩回归文献中的经典结果。本研究由 NSF 项目 CCF-1117055 资助。

参考文献（保留原文）

References

Agrawal, Rahul, Gupta, Archit, Prabhu, Yashoteja, and Varma, Manik. Multi-label learning with millions of labels: Recommending advertiser bid phrases for web pages. In *Proceedings of the International World Wide Web Conference*, 2013.

Bertsekas, Dimitri P. *Nonlinear Programming*. Athena Scientific, Belmont, MA 02178-9998, second edition, 1999.

Breiman, Leo and Friedman, Jerome H. Predicting Multivariate Responses in Multiple Linear Regression. *Journal of the Royal Stat. Soc.: Series B*, 59(1):3–54, 1997.

Bucak, Serhat Selcuk, Mallapragada, Pavan Kumar, Jin, Rong, and Jain, Anil K. Efficient multi-label ranking for multi-class learning: Application to object recognition. In *Proceedings of IEEE International Conference on Computer Vision*, 2009.

Bucak, Serhat Selcuk, Jin, Rong, and Jain, Anil K. Multi-label learning with incomplete class assignments. In *Proceedings of IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2011.

Carneiro, Gustavo, Chan, Antoni B., Moreno, Pedro J., and Vasconcelos, Nuno. Supervised learning of semantic classes for image annotation and retrieval. *IEEE Trans. Pattern Anal. Mach. Intell.*, 29(3):394–410, 2007.

Chen, Yao-Nan and Lin, Hsuan-Tien. Feature-aware label space dimension reduction for multi-label classification. In Bartlett, P., Pereira, F.C.N., Burges, C.J.C., Bottou, L., and Weinberger, K.Q. (eds.), *Advances in Neural Information Processing Systems 25*, pp. 1538–1546, 2012.

Fan, Rong-En, Chang, Kai-Wei, Hsieh, Cho-Jui, Wang, Xiang-Rui, and Lin, Chih-Jen. LIBLINEAR: A library for large linear classification. *Journal of Machine Learning Research*, 9:1871–1874, 2008.

Hariharan, Bharath, Zelnik-Manor, Lihi, Vishwanathan, S. V. N., and Varma, Manik. Large scale max-margin multi-label classification with priors. In *Proceedings of the International Conference on Machine Learning*, June 2010.

Hsu, Daniel, Kakade, Sham, Langford, John, and Zhang, Tong. Multi-label prediction via compressed sensing. In Bengio, Y., Schuurmans, D., Lafferty, J., Williams, C. K. I., and Culotta, A. (eds.), *Advances in Neural Information Processing Systems 22*, pp. 772–780, 2009.

Izenman, Alan Julian. Reduced-Rank Regression for the Multivariate Linear Model. *Journal of Multivariate Analysis*, 5:248–264, 1975.

Kakade, Sham M., Sridharan, Karthik, and Tewari, Ambuj. On the Complexity of Linear Prediction: Risk Bounds, Margin Bounds, and Regularization. In Koller, Daphne, Schuurmans, Dale, Bengio, Yoshua, and Bottou, Léon (eds.), *Advances in Neural Information Processing Systems 21*, 2008.

Kakade, Sham M., Shalev-Shwartz, Shai, and Tewari, Ambuj. Regularization Techniques for Learning with Matrices. *Journal of Machine Learning Research*, 13:1865–1890, 2012.

Kapoor, Ashish, Viswanathan, Raajay, and Jain, Prateek. Multilabel classification using bayesian compressed sensing. In Bartlett, P., Pereira, F.C.N., Burges, C.J.C., Bottou, L., and Weinberger, K.Q. (eds.), *Advances in Neural Information Processing Systems 25*, pp. 2654–2662, 2012.

Ledoux, Michel and Talagrand, Michel. *Probability in Banach Spaces: Isoperimetry and Processes*. Springer, 2002.

Lin, Chih-Jen, Weng, Ruby C., and Keerthi, S. Sathiya. Trust region Newton method for large-scale logistic regression. *Journal of Machine Learning Research*, 9:627–650, 2008.

Schölkopf, Bernhard, Herbrich, Ralf, and Smola, Alex J. A Generalized Representer Theorem. In *14th Annual Conference on Computational Learning Theory*, pp. 416–426, 2001.

Shamir, Ohad and Shalev-Shwartz, Shai. Collaborative Filtering with the Trace Norm: Learning, Bounding, and Transducing. In *24th Annual Conference on Learning Theory*, 2011.

Sun, Liang, Ji, Shuiwang, and Ye, Jieping. Canonical correlation analysis for multi-label classification: A least squares formulation, extensions and analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(1):194–200, 2011.

Tai, Farbound and Lin, Hsuan-Tien. Multi-label classification with principal label space transformation. *Neural Computation*, 24(9):2508–2542, 2012.

Vershynin, Roman. *Introduction to the non-asymptotic analysis of random matrices*, chapter 5 of Compressed Sensing, Theory and Applications, pp. 210–268. Cambridge University Press, 2012.

Wang, Changhu, Yan, Shuicheng, Zhang, Lei, and Zhang, Hong-Jiang. Multi-Label Sparse Coding for Automatic Image Annotation. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2009.

Weston, Jason. Personal Communication, 2013.

Weston, Jason, Bengio, Samy, and Usunier, Nicolas. Large scale image annotation: learning to rank with joint word-image embeddings. *Mach. Learn.*, 81(1):21–35, October 2010.

官方补充材料：完整中文译文

本部分对应 PMLR 官方补充文件《Large-scale Multi-label Learning with Missing Labels》，共 19 页，作者 Hsiang-Fu Yu、Prateek Jain、Purushottam Kar、Inderjit S. Dhillon；原始发表：ICML 2014，PMLR 32(1):593–601。官方来源：https://proceedings.mlr.press/v32/yu14.html ，补充文件：https://proceedings.mlr.press/v32/yu14-supp.pdf 。版权归原作者所有；按 PMLR 出版协议（https://proceedings.mlr.press/pmlr-license-agreement.html ）的 CC BY 4.0（https://creativecommons.org/licenses/by/4.0/ ）授权制作非官方中文翻译。译者为 OpenAI ChatGPT；翻译、重新排版和中文说明均属改编，原作者未审核或认可本译文。公式长推导、图和表采用原文件精确裁切，以避免改变数学符号或数据；英文表头、图轴和图例的中文释义随文列出。未发现补充材料图 3 或表 5–15 中另列的第三方版权例外。原文中可疑符号或笔误在相应位置单独说明，不作无提示更改。

A. 无正则化、使用平方 L2 损失的 LEML 可还原 CPLST

断言 1。若 $\ell\big(y,\, f(x;\, Z)\big) = \parallel y - Z^T x \parallel_2^2$ 且 $\lambda = 0$，则

$$V_X \Sigma_X^{-1} M_k = \operatorname{argmin}_{Z:\operatorname{rank}(Z)\le k} \parallel Y - XZ \parallel_F^2,$$

其中 $X = U_X \Sigma_X V_X^T$ 为 X 的薄奇异值分解，M_k 为 $M \equiv U_X^T Y$ 的秩 k 截断 SVD。

断言 1 的证明。设 $X = U_X \Sigma_X V_X^T$ 为 X 的薄 SVD，M_k 为 $U_X^T Y$ 的秩 k 截断 SVD 近似。有

$$\begin{aligned}
\arg\min_{Z:\operatorname{rank}(Z)\le k} \|Y - XZ\|_F &= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|(U_X U_X^\top)(Y - XZ) + (I - U_X U_X^\top)(Y - XZ)\|_F \\
&= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|(U_X U_X^\top)(Y - XZ) + (I - U_X U_X^\top)(Y - XZ)\|_F^2 \\
&= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|U_X U_X^\top (Y - XZ)\|_F^2 + \|(I - U_X U_X^\top)(Y - XZ)\|_F^2 \\
&= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|U_X^\top (Y - XZ)\|_F^2 \\
&= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|U_X^\top (Y - XZ)\|_F \\
&= \arg\min_{Z:\operatorname{rank}(Z)\le k} \|U_X^\top Y - \Sigma_X V_X^\top Z\|_F \\
&= V_X \Sigma_X^{-1} M_k .
\end{aligned}$$

第二步和第五步来自平方函数在非负数上递增这一事实。第三个等式由勾股定理得到，因为 $U_X U_X^T$ 是正交投影。由于 $U_X^T U_X = I_r$，其中 r 为 X 的秩，故 $U_X U_X^T X = X$，于是 $\big(I - U_X U_X^T\big)(Y - XZ) = \big(I - U_X U_X^T\big) Y$。最后这个量不依赖变量 Z，可以从优化目标中去掉，得到第四个等式。同理，由 $U_X^T X = I_r \Sigma_X V_X^T = \Sigma_X V_X^T$，得到第六个等式。〔译注：原文将第二、第五步称为 “inequalities”（不等式），但显示的推导均为等式。〕

对于最后一个等式，首先注意，按 M_k 的定义，$\operatorname{rank}\left(V_X\Sigma_X^{-1}M_k\right) \le \operatorname{rank}\left(M_k\right) \le k$，所以 $Z = V_X\Sigma_X^{-1}M_k$ 是可行解。其次，对任意可行 Z'，因为 $\operatorname{rank}\left(\Sigma_X V_X^T Z'\right) \le \operatorname{rank}\left(Z'\right) \le k$，再由 M_k 的定义可知 $\| U_X^T Y - \Sigma_X V_X^T Z' \|_F \ge \| U_X^T Y - M_k \|_F$。由 $V_X^T V_X = I_r$，有 $\Sigma_X V_X^T\left(V_X\Sigma_X^{-1}M_k\right) = M_k$，结论成立。

断言 2。式 (3) 的解等价于 $Z^{\text{CPLST}} = W_{\text{CPLST}}H_{\text{CPLST}}^T$，即 CPLST 方案的闭式解：

$$
\begin{aligned}
(W_{CPLST}, H_{CPLST}) = \underset{\substack{W\in\mathbb{R}^{d\times k}\\ H\in\mathbb{R}^{L\times k}}}{\arg\min} & \|XW - YH\|_F^2 + \|Y - YHH^T\|_F^2, \\
s.t. \quad & H^T H = I_k.
\end{aligned} \tag{13}
$$

断言 2 的证明。令 $U_k[A]\Sigma_k[A]V_k[A]$ 表示矩阵 A 的秩 k 截断 SVD 近似。Chen & Lin (2012) 证明，式 (13) 的闭式解为

$$
H_C = V_k\left[Y^T X X^\dagger Y\right], \qquad W_C = X^\dagger Y H_C,
$$

其中 $X^\dagger$ 为 X 的伪逆。由 $X^\dagger = V_X\Sigma_X^{-1}U_X^T$ 得 $Y^T X X^\dagger Y = Y^T U_X U_X^T Y = M^T M$，以及 $V_k\left[Y^T X X^\dagger Y\right] = V_k[M]$。因此有

$$
\begin{aligned}
Z^{CPLST} &= W_C H_C^T \\
&= X^\dagger Y H_C H_C^T \\
&= V_X^T\Sigma_X^{-1}U_X^T Y V_k[M]V_k[M]^T \\
&= V_X^T\Sigma_X^{-1}M V_k[M]V_k[M]^T \\
&= V_X^T\Sigma_X^{-1}M_k
\end{aligned}
$$

〔译注：以上裁切忠实保留原文。原文把 SVD 写为 $U_k[A]\Sigma_k[A]V_k[A]$，未在最后一项标转置；末尾推导又三次写成 $V_X^T\Sigma_X^{-1}$，与前面伪逆定义及断言 1 的 $V_X\Sigma_X^{-1}$ 不一致，维度也通常不匹配。此处标明而不暗改。〕

B. 算法细节

B.1. 各种损失的导数计算

注意，表 5 的逻辑损失和 L2 铰链损失假定 Y_{ij} 取 -1，$+1$，而不是 $\{0, 1\}$。虽然 L2 铰链损失并非二次可微，仍可使用 $\partial\ell(a, b)/\partial b$ 的次微分，令 TRON 求解式 (6)。

表 5。 不同损失函数的 $\ell'(a,\ b)$ 与 $\ell''(a,\ b)$ 的计算。行名依次为平方损失、逻辑损失、L2 铰链损失；列依次为损失、一阶导数、二阶导数。

	$\ell(a,b)$	$\frac{\partial}{\partial b}\ell(a,b)$	$\frac{\partial^2}{\partial b^2}\ell(a,b)$
Squared loss	$\frac{1}{2}(a-b)^2$	$b-a$	1
Logistic loss	$\log\left(1+e^{-ab}\right)$	$\frac{-a}{1+e^{-ab}}$	$\frac{-a^2e^{-ab}}{(1+e^{-ab})^2}$
L_2-hinge loss	$(\max(0,1-ab))^2$	$-2a\max(0,1-ab)$	$2\cdot\mathcal{I}[ab<1]$

〔译注：原表逻辑损失的导数存在明显疑点：对 $\log\left(1+e^{-ab}\right)$，关于 b 的一阶导数应为 $-a/\left(1+e^{ab}\right)$，二阶导数应为 $a^2e^{-ab}/\left(1+e^{-ab}\right)^2$；原表却给出不同的一阶分母和负号的二阶导数。裁切保留原表，不建议照抄该行实现。〕

B.2. 平方损失的共轭梯度法

算法 3 给出了使用平方损失时求解式 (6) 的详细共轭梯度过程。注意，由于平方损失使式 (6) 成为二次问题，$\nabla^2 g(w)$ 不随 w 改变。

算法 3：用平方损失求解式 (6) 的共轭梯度法。

- 设置初始值 w_0，$r_0 = -\nabla g(w_0)$，$d_0 = r_0$。
- 对 $t = 0,\ 1,\ 2,\ \ldots$：
  - 如果 $\| r_t \|$ 足够小，则终止并返回 w_t。
  - $\alpha_t = \left(r_t^T r_t\right)/\left(d_t^T \nabla^2 g(w_0) d_t\right)$。
  - $w_{t+1} = w_t + \alpha_t d_t$。
  - $r_{t+1} = r_t - \alpha_t \nabla^2 g(w_0) d_t$。
  - $\beta_t = \left(r_{t+1}^T r_{t+1}\right)/\left(r_t^T r_t\right)$。
  - $d_{t+1} = r_{t+1} + \beta_t d_t$。

C. 迹范数有界预测器的分析

本节证明定理 3 和定理 4。证明通过建立经验损失的一致收敛型界展开。更准确地说，对于迹范数正则化和 Frobenius 范数正则化，我们都将证明，以高概率有

$$\mathcal{L}(\widehat{Z}) \le \widehat{\mathcal{L}}(\widehat{Z}) + \epsilon.$$

设 $Z^* \in \operatorname{argmin}_{r(Z)\le\lambda}\mathcal{L}(Z)$，类似分析还可证明，以高概率有

$$\widehat{\mathcal{L}}\left(Z^*\right) \le \mathcal{L}\left(Z^*\right) + \epsilon.$$

结合这两式及 $\widehat{Z}$ 是经验风险最小化器这一事实，即 $\widehat{\mathcal{L}}(\widehat{Z}) \le \widehat{\mathcal{L}}\left(Z^*\right)$，可得所述结论：

$$\mathcal{L}(\widehat{Z}) \le \mathcal{L}\left(Z^*\right) + 2\epsilon.$$

因此，以下只专注于证明上述一致收敛界。将正则化预测器类记为 $\mathcal{Z} = \{Z \in \mathbb{R}^{d\times L} : r(Z) \le \lambda\}$，其中 $r(Z) = \| Z \|_{\mathrm{tr}}$ 或 $r(Z) = \| Z \|_F$。对于预测器在某个标签 $l \in [L]$ 上的损失，采用简写 $\ell\left(y_i^l,\, Z_l,\, x\right) := \ell\left(y_i^l,\, f^l(x;\, Z)\right)$，其中 Z_l 表示 Z 的第 l 列。

分析分为以下步骤:

1. 第一步：应用 McDiarmid 不等式，将学习到的预测器的超额风险，以高概率归约为对预测器类 $\mathcal{Z}$ 中经验风险与总体风险之偏差上确界的期望进行控制。
2. 第二步：用一个 Rademacher 平均项控制上述上确界的期望。
3. 第三步：把 Rademacher 平均项的估计归约为一个稍后定义的随机矩阵的谱范数估计。
4. 第四步：利用随机矩阵理论工具控制该谱范数。

以下各小节给出每一步的细节。

C.1. 第一步：以偏差上确界的期望控制超额风险

先分析 $s = 1$，稍后说明如何推广到 $s > 1$。此时收到 n 个训练点 $\left(x_i,\, y_i\right)$，对每个训练点 x_i，只看到某个随机标签 $l_i \in [L]$ 的值，即 $y_i^{l_i}$ 的真实值。因此，对任意 $Z \in \mathcal{Z}$，观测训练损失为

$$\widehat{\mathcal{L}}\,(Z) = \frac{1}{n}\sum_{i=1}^{n} \ell\left(y_i^{l_i},\, Z_{l_i},\, x_i\right).$$

总体风险泛函为

$$\mathcal{L}\,(Z) = \mathbb{E}_{(x,y,l)}\left[\ell_l\left(y^l,\, f^l(x;\, Z)\right)\right] = \mathbb{E}_{(x,y,l)}\left[\ell_l\left(y^l,\, Z_l,\, x\right)\right].$$

后续分析即使在标签非均匀采样时也成立，总体风险的定义已纳入这一点。若标签服从均匀分布，上述定义化为

$$\mathcal{L}\,(Z) = \mathbb{E}_{(x,y,l)}\left[\ell_l\left(y^l,\, Z_l,\, x\right)\right] = \mathbb{E}_{(\widetilde{x}_i,\widetilde{y}_i,\tilde{l}_i)}\left[\frac{1}{n}\sum_{i=1}^{n} \ell\left(\widetilde{y}_i^{\tilde{l}_i},\, Z_{\tilde{l}_i},\, \widetilde{x}_i\right)\right].$$

据此分析超额风险，即观测训练损失 $\widehat{\mathcal{L}}\,(\widehat{Z})$ 与总体风险 $\mathcal{L}\,(\widehat{Z})$ 的差:

$$\begin{aligned}
\mathcal{L}(\hat{Z}) - \hat{\mathcal{L}}(\hat{Z}) \;&\le\; \sup_{Z\in\mathcal{Z}} \left\{\mathcal{L}(Z) - \hat{\mathcal{L}}(Z)\right\} \\
&=\; \underbrace{\sup_{Z\in\mathcal{Z}} \left\{ \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i,\tilde{l}_i)} \left[\!\!\left[\frac{1}{n}\sum_{i=1}^{n} \ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i) \right]\!\!\right] - \frac{1}{n}\sum_{i=1}^{n} \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\}}_{g((\boldsymbol{x}_1,\boldsymbol{y}_1,l_1),\ldots,(\boldsymbol{x}_n,\boldsymbol{y}_n,l_n))}
\end{aligned}$$

由于所有逐标签损失函数均有界，对任意一个 $\left(x_i,\, y_i\right)$ 或任意一个 l_i 作任意改变，都至多使 $g\left(\left(x_1,\, y_1,\, l_1\right),\, \ldots,\, \left(x_n,\, y_n,\, l_n\right)\right)$ 改变 $O(1/n)$。因此，应用 McDiarmid 不等式，以至少 $1 - \delta$ 的概率有

$$\mathcal{L}(\hat{Z}) - \hat{\mathcal{L}}(\hat{Z}) \leq \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} [\![g((\boldsymbol{x}_1,\boldsymbol{y}_1,l_1),\ldots,(\boldsymbol{x}_n,\boldsymbol{y}_n,l_n))]\!] + \mathcal{O}\left(\sqrt{\frac{\log\frac{1}{\delta}}{n}}\right)$$

于是，计算经验风险与总体风险之偏差上确界的期望，即可控制学习到的预测器的超额风险。

C.2. 第二步：以 Rademacher 平均控制偏差上确界的期望

现在分析该期望。有以下完整推导:

$$\begin{aligned}
&\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} [\![g((\boldsymbol{x}_1,\boldsymbol{y}_1,l_1),\ldots,(\boldsymbol{x}_n,\boldsymbol{y}_n,l_n))]\!] \\
= &\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i,\tilde{l}_i)} \left[\!\!\left[\frac{1}{n}\sum_{i=1}^n \ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i) \right]\!\!\right] - \frac{1}{n}\sum_{i=1}^n \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
\leq &\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i,\tilde{l}_i)} \left[\!\!\left[\frac{1}{n}\sum_{i=1}^n \ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i) \right]\!\!\right] - \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] \right\} \right]\!\!\right] \\
&+ \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] - \frac{1}{n}\sum_{i=1}^n \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
= &\mathop{\mathbb{E}}_{l_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i,\tilde{l}_i)} \left[\!\!\left[\frac{1}{n}\sum_{i=1}^n \ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i) \right]\!\!\right] - \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] \right\} \right]\!\!\right] \\
&+ \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] - \frac{1}{n}\sum_{i=1}^n \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
\leq &\mathop{\mathbb{E}}_{(l_i,\tilde{l}_i)} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i)]\!] - \frac{1}{n}\sum_{i=1}^n \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] \right\} \right]\!\!\right] \\
&+ \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i) - \frac{1}{n}\sum_{i=1}^n \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
= &\mathop{\mathbb{E}}_{(l_i,\tilde{l}_i),\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \left(\mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{\tilde{l}_i}, Z_{\tilde{l}_i}, \tilde{\boldsymbol{x}}_i)]\!] - \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] \right) \right\} \right]\!\!\right] \\
&+ \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i),\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \left(\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i) - \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right) \right\} \right]\!\!\right] \\
\leq &2 \mathop{\mathbb{E}}_{l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i)} [\![\ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i)]\!] \right\} \right]\!\!\right] + 2 \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
\leq &2 \mathop{\mathbb{E}}_{(\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{y}}_i),l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \ell(\tilde{\boldsymbol{y}}_i^{l_i}, Z_{l_i}, \tilde{\boldsymbol{x}}_i) \right\} \right]\!\!\right] + 2 \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \\
\leq &4 \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \frac{1}{n}\sum_{i=1}^n \epsilon_i \ell(\boldsymbol{y}_i^{l_i}, Z_{l_i}, \boldsymbol{x}_i) \right\} \right]\!\!\right] \leq \frac{4C}{n} \mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i),l_i,\epsilon_i} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \left\{ \sum_{i=1}^n \epsilon_i \langle Z_{l_i}, x_i \rangle \right\} \right]\!\!\right] \\
= &\frac{4C}{n} \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}} \left[\!\!\left[\sup_{Z\in\mathcal{Z}} \langle Z, X^{\mathbf{l}}_{\boldsymbol{\epsilon}} \rangle \right]\!\!\right],
\end{aligned}$$

其中，对任意 $x_1, \ldots, x_n \in \mathcal{X}$、$\mathbf{l} \in [L]^n$ 和 $\boldsymbol{\epsilon} \in \{-1, +1\}^n$，定义

$$X_\epsilon^{\mathbf{l}} := \Big[\sum_{i\in I_1}\epsilon_i x_i \quad \sum_{i\in I_2}\epsilon_i x_i \quad \cdots \quad \sum_{i\in I_L}\epsilon_i x_i\Big],$$

且对每个 $l \in [L]$，令 $I_l := \{i : l_i = l\}$。倒数第二个不等式使用了 Rademacher 平均的收缩不等式（见 Ledoux & Talagrand, 2002，定理 4.12 的证明）。上述分析也允许每个标签拥有各自不同的损失函数，只要它们都有界且均为 C-Lipschitz。对于任意矩阵预测器类 $\mathcal{Z}$，定义其 Rademacher 复杂度为

$$\mathcal{R}_n(\mathcal{Z}) := \frac{1}{n}\mathbb{E}_{X,\mathbf{l},\epsilon}\left[\sup_{Z\in\mathcal{Z}}\langle Z,\ X_\epsilon^{\mathbf{l}}\rangle\right].$$

因而已经证明，以高概率有

$$\mathcal{L}(\widehat{Z}) - \widehat{\mathcal{L}}(\widehat{Z}) \le 4C\mathcal{R}_n(\mathcal{Z}) + O\left(\sqrt{\frac{\log(1/\delta)}{n}}\right).$$

现在说明，该分析也适用于每个训练点观测 s 个标签值的情况。即对每个 x_i，观测标签 $l_i^1, \ldots, l_i^s$ 的值。经验损失为

$$\widehat{\mathcal{L}}(Z) = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{s}\ell\left(y_i^{l_i^j},\ Z_{l_i^j},\ x_i\right).$$

改变任意一个 x_i 至多造成 $O(s/n)$ 的扰动，而改变任意一个 l_i^j 至多造成 $O(1/n)$ 的扰动。因此扰动平方和以 $2s^2/n$ 为界。应用 McDiarmid 不等式，可用下列偏差上确界的期望加上 $O\left(s\sqrt{\log(1/\delta)/n}\right)$ 来控制超额风险：

$$\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i,l_i^j)}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\left\{s\mathop{\mathbb{E}}_{(x,y,l)}\left[\!\!\left[\ell_l(\boldsymbol{y}^l, Z_l, \boldsymbol{x})\right]\!\!\right] - \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{s}\ell(\boldsymbol{y}_i^{l_i^j}, Z_{l_i^j}, \boldsymbol{x}_i)\right\}\right]\!\!\right]$$

该期望的分析如下：

$$\begin{aligned}
&\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i,l_i^j)}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\left\{s\mathop{\mathbb{E}}_{(\boldsymbol{x},\boldsymbol{y},l)}\left[\!\!\left[\ell_l(\boldsymbol{y}^l, Z_l, \boldsymbol{x})\right]\!\!\right] - \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{s}\ell(\boldsymbol{y}_i^{l_i^j}, Z_{l_i^j}, \boldsymbol{x}_i)\right\}\right]\!\!\right] \\
= &\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i,l_i^j)}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\left\{\sum_{j=1}^{s}\left(\mathop{\mathbb{E}}_{(\boldsymbol{x},\boldsymbol{y},l)}\left[\!\!\left[\ell_l(\boldsymbol{y}^l, Z_l, \boldsymbol{x})\right]\!\!\right] - \frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{y}_i^{l_i^j}, Z_{l_i^j}, \boldsymbol{x}_i)\right)\right\}\right]\!\!\right] \\
\le &\sum_{j=1}^{s}\mathop{\mathbb{E}}_{(\boldsymbol{x}_i,\boldsymbol{y}_i,l_i^j)}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\left\{\mathop{\mathbb{E}}_{(\boldsymbol{x},\boldsymbol{y},l)}\left[\!\!\left[\ell_l(\boldsymbol{y}^l, Z_l, \boldsymbol{x})\right]\!\!\right] - \frac{1}{n}\sum_{i=1}^{n}\ell(\boldsymbol{y}_i^{l_i^j}, Z_{l_i^j}, \boldsymbol{x}_i)\right\}\right]\!\!\right] \\
\le &\sum_{j=1}^{s}\frac{4C}{n}\mathop{\mathbb{E}}_{X,\mathbf{l}^j,\boldsymbol{\epsilon}}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\langle Z, X_{\boldsymbol{\epsilon}}^{\mathbf{l}^j}\rangle\right]\!\!\right] = \frac{4Cs}{n}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\!\!\left[\sup_{Z\in\mathcal{Z}}\langle Z, X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\rangle\right]\!\!\right] = 4Cs\mathcal{R}_n(\mathcal{Z})
\end{aligned}$$

所以只需证明每个点观测一个标签时的界。顺带指出，$s = 1$ 的情形类似多任务学习；但通常研究多任务学习时使用的学习模型不同，而且大多采用与我们不同的组正则化。

C.3. 第三步：估计 Rademacher 平均

现在控制下式，其中 $X_{\epsilon}^{\mathbf{l}}$ 定义如前：

$$\mathcal{R}_n(\mathcal{Z}) = \frac{1}{n}\mathbb{E}_{X,\mathbf{l},\epsilon}\left[\sup_{Z\in\mathcal{Z}}\langle Z,\ X_{\epsilon}^{\mathbf{l}}\rangle\right].$$

控制此类 Rademacher 平均项的常见方法，是使用鞅技术（Kakade et al., 2008）或凸分析工具（Kakade et al., 2012），并分解 Rademacher 平均项。但这样的分解在本文情形下会得到次优结果。我们的方法改为先应用 Hölder 不等式，再利用随机矩阵理论控制某个随机矩阵的谱范数。

为简化记号，对任意 $l \in [L]$，令 $V_l = \sum_{i\in I_l}\epsilon_i x_i$，且 $V := X_{\epsilon}^{\mathbf{l}} = \begin{bmatrix} V_1 & V_2 & \cdots & V_L \end{bmatrix}$。同时，令 $n_l = |I_l|$ 表示观测到第 l 个标签值的训练点数，即 $n_l = \sum_{i=1}^{n}\mathbf{1}_{l_i=l}$。

C.3.1. 与分布无关的界

应用 Hölder 不等式，得

$$\frac{1}{n}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sup_{Z\in\mathcal{Z}}\langle Z, X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\rangle\right] \le \frac{1}{n}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sup_{Z\in\mathcal{Z}}\|Z\|_{\mathrm{tr}}\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_F\right] \le \frac{1}{n}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\lambda\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2\right] \le \frac{\lambda}{n}\sqrt{\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2\right]}$$

随后可直接推得：

$$\begin{aligned}
\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2\right] &\le \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_F^2\right] = \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sum_{l=1}^{L}\|V_l\|_2^2\right] = \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sum_{l=1}^{L}\left\|\sum_{i\in I_l}\epsilon_i\boldsymbol{x}_i\right\|_2^2\right] \\
&= \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sum_{l=1}^{L}\sum_{i\in I_l}\|\boldsymbol{x}_i\|_2^2 + \sum_{i\neq j\in I_l}\epsilon_i\epsilon_j\langle\boldsymbol{x}_i,\boldsymbol{x}_j\rangle\right] \\
&\le \mathop{\mathbb{E}}_{\mathbf{l}}\left[\sum_{l=1}^{L} n_l\mathbb{E}\left[\|\boldsymbol{x}\|_2^2\right]\right] \le \mathop{\mathbb{E}}_{\mathbf{l}}\left[\sum_{l=1}^{L} n_l\right] = n
\end{aligned}$$

其中不失一般性假定 $\mathbb{E}_{x\sim\mathcal{D}}\|x\|_2^2 \le 1$。这证明了

$$\mathcal{R}_n(\mathcal{Z}) \le \frac{\lambda}{\sqrt{n}},$$

从而得到定理 3。若 $\mathcal{Z}$ 以 Frobenius 范数正则化，同样的分析仍成立，因为可以转而应用 Frobenius 范数对应的 Hölder 不等式，得到相同的 Rademacher 平均界。

〔译注：此处原文 Hölder 推导中间一项印为 $\|Z\|_{\mathrm{tr}}\|X_{\epsilon}^{\mathbf{l}}\|_F$，下一步却换为谱范数；按迹范数与谱范数的对偶关系，该中间项通常应是谱范数。裁切保留原排印。〕

C.3.2. 迹范数正则化的更紧界

上述分析没有利用 $X_\epsilon^{\mathbf{l}}$ 的最大奇异值可能远小于 Frobenius 范数这一事实。但确有一些分布，使迹范数正则化具有优于 Frobenius 范数正则化的性能保证。为更清晰地表述界，对 $\mathcal{X}$ 上的数据分布 $\mathcal{D}$（更准确地说，是其边缘分布）进行更细致的建模。设 $\mathsf{X}:=\mathbb{E}\left[xx^T\right]$，假定分布满足：

1. X 的最大奇异值为 $\|\mathsf{X}\|_2=\sigma_1$。
2. $\mathrm{tr}(\mathsf{X})=\Sigma$。
3. $\mathcal{X}$ 上的分布为次高斯分布，即存在 $\eta>0$，使所有 $v\in\mathbb{R}^d$ 都满足

$$\mathbb{E}\left[\exp\left(x^Tv\right)\right]\le\exp\left(\|v\|_2^2\eta^2/2\right).$$

为与前面的结果一致，将 x 归一化，使其期望平方范数为 1。因为 $\mathbb{E}\|x\|_2^2=\mathrm{tr}(\mathsf{X})=\Sigma$，所需的 Rademacher 平均界写为

$$\mathcal{R}_n(\mathcal{Z})\le\frac{1}{n\sqrt{\Sigma}}\mathbb{E}_{X,\mathbf{l},\epsilon}\left[\sup_{Z\in\mathcal{Z}}\langle Z,\,X_\epsilon^{\mathbf{l}}\rangle\right].$$

此时可应用 Hölder 不等式：

$$\frac{1}{n\sqrt{\Sigma}}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sup_{Z\in\mathcal{Z}}\langle Z,X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\rangle\right]\le\frac{1}{n\sqrt{\Sigma}}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\sup_{Z\in\mathcal{Z}}\|Z\|_{\mathrm{tr}}\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2\right]\le\frac{1}{n\sqrt{\Sigma}}\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\lambda\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2\right]\le\frac{\lambda}{n\sqrt{\Sigma}}\sqrt{\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2\right]}$$

因此，只需控制 $\mathbb{E}_{X,\mathbf{l},\epsilon}\|X_\epsilon^{\mathbf{l}}\|_2^2$。由于关注的是谱范数，例如训练点从（近）各向同性分布中采样时，预期能得到更好的保证。而 Frobenius 范数正则化在这些情况下无法获益，因为它涉及该矩阵的 Frobenius 范数（如前一小节所示），无法利用谱范数远小于 Frobenius 范数这一事实。

C.4. 第四步：计算随机矩阵的谱范数

为控制 $\mathbb{E}_{X,\mathbf{l},\epsilon}\|X_\epsilon^{\mathbf{l}}\|_2^2$，先作一些简化，归一化稍后处理。对每个 $l\in[L]$，令观测到标签 l 值的概率为 $p_l\in(0,1]$，且 $\sum_l p_l=1$；令 $P=\max_{l\in[L]}p_l$，$p=\min_{l\in[L]}p_l$。令事件 $\mathcal{E}_{\max}$ 表示对所有 $l\in[L]$ 均有 $n_l\le 2Pn$，即每个标签至多在 $2Pn$ 个训练点上被观测。下面说明这是高概率事件。〔译注：原文最小概率定义末项写为 p_t，这里明确标记为下标笔误，译文使用上下文一致的 p_l。〕

引理 1。对任意 $\delta>0$，若 $n\ge\left(1/\left(2p^2\right)\right)\log(L/\delta)$，则以概率 $1-\delta$，有

$$\mathbb{P}\left[\mathcal{E}_{\max}\right]\ge 1-\delta.$$

证明。对任意 $l\in[L]$，对布尔随机变量应用 Chernoff 界可知，以至少 $1-\exp\left(-2np_l^2\right)$ 的概率，$n_l\le 2p_ln\le 2Pn$。取并合界，再使用 $p_l\ge p$，即完成证明。〔译注：引理原文在概率下界外又加“以概率 $1-\delta$”，此处忠实保留其表述。〕

以 $\mathcal{E}_{\max}$ 为条件，可通过各列的次高斯范数界，控制 $X_\epsilon^{\mathbf{l}}$ 的谱范数。下面说明，这个条件化不影响 Rademacher 平均计算。简单计算得 $\mathbb{E}_{X,\epsilon}\left[\|X_\epsilon^{\mathbf{l}}\|_2^2\mid\mathbf{l}\right]\le n\Sigma$。若 $n>\left(1/\left(2p^2\right)\right)\log(L\Sigma/\left[Pd\left(\eta^2+\sigma_1\right)\right])$，则 $\mathbb{P}\left[\neg\mathcal{E}_{\max}\right]<Pd\left(\eta^2+\sigma_1\right)/\Sigma$。于是有

$$
\begin{aligned}
\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2\right] &= \mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \mathcal{E}_{\max}\right]\mathbb{P}\left[\mathcal{E}_{\min}\right] + \mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \neg\mathcal{E}_{\min}\right]\left(1-\mathbb{P}\left[\mathcal{E}_{\max}\right]\right) \\
&= \mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \mathcal{E}_{\max}\right](1-\delta) + \mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \neg\mathcal{E}_{\max}\right]\delta \\
&\leq \mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \mathcal{E}_{\max}\right] + n\Sigma\left(\frac{Pd(\eta^2+\sigma_1)}{\Sigma}\right) \\
&\leq \mathcal{O}\left(\mathop{\mathbb{E}}_{X,\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2 \middle| \mathcal{E}_{\max}\right]\right)
\end{aligned}
$$

最后一步基于后面的计算将表明 $\mathbb{E}_{X,\boldsymbol{\epsilon}}\left[\| X_{\boldsymbol{\epsilon}}^{\mathbf{l}} \|_2^2 \mid \mathcal{E}_{\max}\right] = O\left(nPd\left(\eta^2+\sigma_1\right)\right)$。因此只需控制 $\mathbb{E}_{X,\boldsymbol{\epsilon}}\left[\| X_{\boldsymbol{\epsilon}}^{\mathbf{l}} \|_2^2 \mid \mathcal{E}_{\max}\right] = \mathbb{E}_{X,\boldsymbol{\epsilon}}\left[\| V \|_2^2 \mid \mathcal{E}_{\max}\right]$。为简洁，以下略去条件项。〔译注：原推导第一行混用了未定义的 $\mathcal{E}_{\min}$ 和 $\mathcal{E}_{\max}$，图中原样保留；其末步以 O 上界吸收附加项的论证也不够严谨，本译文未作补证。〕

令 $A_l = V_l/c$，其中 $c = \eta\sqrt{2Pn}$，并令 $A = \left[A_1\, A_2 \cdots A_L\right]$。于是

$$
\mathbb{E}_{X,\mathbf{l},\boldsymbol{\epsilon}} \| X_{\boldsymbol{\epsilon}}^{\mathbf{l}} \|_2^2 = c^2 \mathbb{E}_{X,\mathbf{l},\boldsymbol{\epsilon}} \| A \|_2^2 .
$$

先控制列向量 A_l 的次高斯范数。对任意 $v \in \mathbb{R}^d$，有

$$
\begin{aligned}
\mathbb{E}\left[\exp\left(A_l^\top \boldsymbol{v}\right)\right] &= \mathbb{E}\left[\exp\left(\frac{1}{c}\sum_{i\in I_l}\epsilon_i\langle \boldsymbol{x}_i, \boldsymbol{v}\rangle\right)\right] \\
&= \left(\mathbb{E}\left[\exp\left(\langle \boldsymbol{x}, \frac{1}{c}\epsilon\boldsymbol{v}\rangle\right)\right]\right)^{n_l} \\
&\leq \left(\exp\left(\left\|\frac{1}{c}\epsilon\boldsymbol{v}\right\|_2^2 \eta^2/2\right)\right)^{n_l} \\
&= \exp\left(\frac{n_l}{2\eta^2 P\cdot n}\|\boldsymbol{v}\|_2^2\,\eta^2/2\right) \\
&\leq \exp\left(\|\boldsymbol{v}\|_2^2/2\right)
\end{aligned}
$$

第二步利用了 $i \neq j$ 时 x_i, x_j 及 ϵ_i, ϵ_j 的独立性；第三步使用了 x 的次高斯性质；第四步使用事件 $\mathcal{E}_{\max}$ 成立这一事实。这表明 A_l 的次高斯范数有界，即 $\| A_l \|_{\psi_2} \leq 1$。

接下来控制 $\mathbb{E}_{X,\boldsymbol{\epsilon}} \| A \|_2^2 = \mathbb{E}_{X,\boldsymbol{\epsilon}} \| A^T \|_2^2$。证明先应用 Bernstein 型不等式，再使用覆盖数论证，最后用累积分布函数控制期望。前两部分沿用 Vershynin (2012) 定理 5.39 的证明思路。对任意固定 $v \in S^{d-1}$（d 维单位范数向量集合），有

$$\|A\boldsymbol{v}\|_2^2 = \sum_{l=1}^{L} \langle A_l, \boldsymbol{v}\rangle^2 =: \sum_{l=1}^{L} Z_l^2$$

〔译注：按前述 A 的列定义，A 为 $d\times L$；上式原文写 $\| Av \|_2^2$，维度上应考虑 $\| A^T v \|_2^2$。下文相同记号沿原文保留。〕

给定 $\mathbf{1}$ 后，若 $t \neq t'$，则 $I_t \cap I_{t'} = \varnothing$，所以 Z_t, $Z_{t'}$ 条件独立。这使我们能够应用下面的 Bernstein 型不等式。

定理 5（Vershynin, 2012，推论 5.17）。 设 $X_1, \ldots, X_N$ 是相互独立、中心化的次指数随机变量，其次指数范数有界，即存在 $B > 0$ 使所有 i 均有 $\| X_i \|_{\psi_1} \le B$。则存在绝对常数 $c_1 > 0$，使任意 $\epsilon > 0$ 都满足

$$\mathbb{P}\Big[\sum_{i=1}^{N} X_i \ge \epsilon N\Big] \le \exp\left(- c_1 \min\left\{ \frac{\epsilon^2}{B^2},\ \frac{\epsilon}{B} \right\} N \right).$$

为了应用此结果，先控制随机变量 Z_l^2 的期望：

$$\mathbb{E}\left[\!\left[Z_l^2 \right]\!\right] = \mathbb{E}\left[\!\left[\langle A_l, \boldsymbol{v}\rangle^2 \right]\!\right] = \mathbb{E}\left[\!\left[\left(\frac{1}{c} \sum_{i\in I_l} \epsilon_i \langle \boldsymbol{x}_i, \boldsymbol{v}\rangle \right)^2 \right]\!\right] = \frac{n_l}{c^2} \mathbb{E}\left[\!\left[\langle \boldsymbol{x}, \boldsymbol{v}\rangle^2 \right]\!\right] \le \frac{n_l \sigma_1}{c^2} \le \frac{\sigma_1}{\eta^2}$$

第四个不等式来自 $\mathsf{X} = \mathbb{E}\left[xx^T\right]$ 的最大奇异值 σ_1 的定义，最后一个不等式来自事件 $\mathcal{E}_{\max}$。上述计算给出 Z_l^2 的期望界，用于将其中心化。由于已经建立 $\| A_l \|_{\psi_2} \le 1$，自动有 $\| Z_l \|_{\psi_2} \le 1$。利用随机变量的次指数范数与次高斯范数之间的标准不等式（例如 Vershynin, 2012，引理 5.14），还有

$$\| Z_l^2 - \mathbb{E}Z_l^2 \|_{\psi_1} \le 2 \| Z_l^2 \|_{\psi_1} \le 4 \| Z_l \|_{\psi_2}^2 \le 4.$$

将定理 5 应用于 $X_l = Z_l^2 - \mathbb{E}Z_l^2$，得

$$\mathbb{P}\left[\sum_{l=1}^{L} Z_l^2 - \frac{L\sigma_1}{\eta^2} \ge \epsilon L \right] \le \exp\big(- c_1 L \min\{\epsilon^2, \epsilon\} \big),$$

其中 $c_1 > 0$ 为绝对常数。因此，对于固定 $v \in S^{d-1}$，以至少 $1 - \exp\big(- c_1 L \min\{\epsilon^2, \epsilon\}\big)$ 的概率有

$$\| Av \|_2^2 \le \big(\sigma_1/\eta^2 + \epsilon \big) L.$$

在 S^{d-1} 的一个 $1/4$-网 $\mathcal{N}_{1/4}$（其大小至多 9^d）上取并合界，原文称以“至多”$1 - 9^d \exp\big(- c_1 L \min\{\epsilon^2, \epsilon\}\big)$ 的概率，上述不等式对网中所有向量成立。〔译注：由并合界应得到“至少”，这里明确指出原文用词错误。〕这意味着矩阵 A 的谱范数也有界（见 Vershynin, 2012，引理 5.4）：

$$\| A \|_2^2 \le 2\big(\sigma_1/\eta^2 + \epsilon \big) L.$$

令 $\epsilon = c_2 d/L + \epsilon'/L$，其中 $c_2 = \max\{1, \ln 9/c_1\}$，并假定 $d \geq L$。由于 $c_2 \geq 1$，有 $\epsilon \geq 1$，因此 $\min\{\epsilon, \epsilon^2\} = \epsilon$。以至少 $1 - \exp(-c_1\epsilon')$ 的概率，有

$$\| A \|_2^2 \leq 2\left(L\sigma_1/\eta^2 + c_2 d + \epsilon'\right).$$

考虑随机变量 $Y = \| A \|_2^2/2 - L\sigma_1/\eta^2 - c_2 d$，则 $\mathbb{P}[Y > \epsilon] \leq \exp(-c_1\epsilon)$。于是

$$\mathbb{E}Y = \int_0^\infty \mathbb{P}[Y > \epsilon]\, d\epsilon \leq \int_0^\infty \exp(-c_1\epsilon)\, d\epsilon = 1/c_1.$$

〔译注：以上尾积分等式通常适用于非负随机变量；此处定义的 Y 未保证非负。将等式替换为上界仍足以推出后续上界，原等式在此保留并注明。〕

从而

$$\mathbb{E} \| A \|_2^2 \leq 2\left(L\sigma_1/\eta^2 + c_2 d + 1/c_1\right),$$

因此

$$\mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\left\|X_{\boldsymbol{\epsilon}}^{\mathbf{l}}\right\|_2^2\right] = c^2 \cdot \mathop{\mathbb{E}}_{X,\mathbf{l},\boldsymbol{\epsilon}}\left[\|A\|_2^2\right] \leq 4\eta^2 P \cdot n\left(L\frac{\sigma_1}{\eta^2} + c_2 d + \frac{1}{c_1}\right) \leq \mathcal{O}\left(n\eta^2 P\left(d + L\frac{\sigma_1}{\eta^2}\right)\right) \leq \mathcal{O}\left(nPd(\eta^2 + \sigma_1)\right)$$

最后一步在 $d \geq L$ 时成立。因此，存在绝对常数 c_3，使 Rademacher 平均满足

$$\mathcal{R}_n(\mathcal{Z}) \leq \frac{\lambda}{n\sqrt{\Sigma}}\sqrt{\mathbb{E}_{X,\mathbf{l},\boldsymbol{\epsilon}} \| X_{\boldsymbol{\epsilon}}^{\mathbf{l}} \|_2^2} \leq c_3\lambda\sqrt{\frac{Pd\left(\eta^2 + \sigma_1\right)}{n\Sigma}}.$$

据此可得如下结论。

定理 6。假定在 n 个训练点上，使用迹范数正则化形式 $\widehat{Z} = \operatorname{arginf}_{\|Z\|_{\mathrm{tr}} \leq \lambda} \widehat{\mathcal{L}}(Z)$ 学习预测器。进一步假定，对每个 $l \in [L]$，观测到标签 l 值的概率为 p_l，令 $P = \max_{l \in [L]} p_l$。则以至少 $1 - \delta$ 的概率，有

$$\mathcal{L}(\hat{Z}) \leq \inf_{\|Z\|_{\mathrm{tr}} \leq \lambda} \mathcal{L}(Z) + \mathcal{O}\left(s\lambda\sqrt{\frac{dP(\eta^2 + \sigma_1)}{n\Sigma}}\right) + \mathcal{O}\left(s\sqrt{\frac{\log\frac{1}{\delta}}{n}}\right),$$

其中 η, σ_1, Σ 由数据分布定义，同前。〔译注：原定理风险界右侧印成 $\operatorname{arginf}\mathcal{L}(Z)$，其返回预测器而非风险数值，与左侧类型不匹配；通常应为 $\inf\mathcal{L}(Z)$。原图保留该笔误。另外，上述证明显式使用的样本量及 $d \geq L$ 条件没有在此定理陈述中再次列出。〕

实质上，这表明：若某个标签被过于频繁地观测，例如 $P = \Omega(1)$，迹范数正则化就没有收益，因为这类似标签完全观测的情形。若标签分布接近均匀，即 $P = O(1/L)$，上述计算则给出

$$\mathcal{R}_n(\mathcal{Z}) \leq c_3\lambda\sqrt{\frac{d\left(\eta^2 + \sigma_1\right)}{nL\Sigma}},$$

并相应控制超额风险，这证明了定理 4 的第一部分。

若数据分布接近各向同性，即 $\Sigma \gg \sigma_1$，该结果给出更优的界。例如，数据点来自标准正态分布时，$\sigma_1 = 1$、$\Sigma = d$、$\eta = 1$，于是

$$\mathcal{R}_n(\mathcal{Z}) \le c_3 \lambda \sqrt{\frac{2}{nL}},$$

得到定理 4 的第二部分。

D. 基于一致收敛的证明所能达到的下界

本节说明，定理 3 和定理 4 的分析本质上是紧的。具体来说，对每一种情形，都构造一个数据分布，使经验损失与总体风险的偏差，在相差常数因子的意义下，等于上述结果预测的量级。下面分两个小节陈述下界。

D.1. 迹范数正则化的下界

本节说明，对一般分布，定理 3 是紧的。回顾定理 3：使用迹范数正则化学习到的预测器 $\widehat{Z}$，以常数概率（即 $\delta = \Omega(1)$）满足

$$\mathcal{L}(\widehat{Z}) \le \widehat{\mathcal{L}}(\widehat{Z}) + O\left(\lambda \sqrt{\frac{1}{n}}\right),$$

其中为简便且不失一般性，假设 $s = 1$。下面通过下界说明该结果是紧的。

命题 7。 存在一个数据-标签分布和一个损失函数，使按 $\widehat{Z} = \operatorname{arginf}_{\|Z\|_{\mathrm{tr}} \le \lambda} \widehat{\mathcal{L}}(Z)$ 学得的经验风险最小化器，以常数概率具有以下总体风险下界：

$$\mathcal{L}(\widehat{Z}) \ge \widehat{\mathcal{L}}(\widehat{Z}) + \Omega\left(\lambda \sqrt{\frac{1}{n}}\right).$$

这便确立了紧性。证明将考虑非各向同性分布；因为对于各向同性分布，定理 4 已说明确实可以取得更紧的上界。为简便且不失一般性，只对 $\lambda = 1$ 证明。令 $\mu \in \mathbb{R}^d$ 是固定单位向量，考虑数据分布

$$x_i = \zeta_i \mu,$$

其中 ζ_i 是独立 Rademacher 变量；标签分布取简单形式

$$y_i = \mathbf{1},$$

其中 $\mathbf{1} \in \mathbb{R}^L$ 为全 1 向量。该数据分布满足 $\mathbb{E} \| x \|_2^2 = 1$，所以满足定理 3 的假设。当且仅当第 i 个训练点的标签 l 被观测到时，令 $\omega_i^l = 1$。对任意 i，有 $\sum_{l=1}^{L} \omega_i^l = 1$；对任意 $l \in [L]$，$\omega_i^l = 1$ 的概率为 $1/L$。考虑损失函数

$$\ell\left(y^l,\ f^l(x;\ Z)\right) = \langle Z_l,\ y^l x \rangle.$$

令

$$\widehat{Z} = \arg \inf_{\|Z\|_{\mathrm{tr}} \le 1} \widehat{\mathcal{L}}(Z) = \arg \inf_{\|Z\|_{\mathrm{tr}} \le 1} \frac{1}{n} \langle Z,\ \mu v^T \rangle,$$

其中

$$v = \left[\sum_{i=1}^{n} \zeta_i \omega_i^1 \quad \sum_{i=1}^{n} \zeta_i \omega_i^2 \quad \cdots \quad \sum_{i=1}^{n} \zeta_i \omega_i^L\right].$$

显然，因为 x 的分布中心化且 ℓ 为线性损失，$\mathcal{L}(\widehat{Z}) = 0$。由 Hölder 不等式还有

$$\widehat{Z} = -\frac{\mu v^T}{\| v \|_2}.$$

因 $\| \mu \|_2 = 1$，得到 $\widehat{\mathcal{L}}(\widehat{Z}) = -(1/n) \| v \|_2$。以下引理表明，以常数概率 $\| v \|_2 \geq \sqrt{n/2}$，所以 $\mathcal{L}(\widehat{Z}) \geq \widehat{\mathcal{L}}(\widehat{Z}) + \Omega\left(\sqrt{1/n}\right)$，从而证明下界。

引理 2。 以至少 $3/4$ 的概率，$\| v \|_2^2 \geq n/2$。

证明。 有

$$\begin{aligned} \|\mathbf{v}\|_2^2 &= \sum_{l=1}^{L} \left(\sum_{i=1}^{n} \zeta_i \omega_i^l\right)^2 = \sum_{l=1}^{L} \sum_{i=1}^{n} \omega_i^l + \sum_{l=1}^{L} \sum_{i \neq j} \zeta_i \omega_i^l \zeta_j \omega_j^l \\ &= n + \sum_{i \neq j} \zeta_i \zeta_j \langle \boldsymbol{\omega}_i, \boldsymbol{\omega}_j \rangle = n + W, \end{aligned}$$

其中 $\omega_i = \left[\omega_i^1, \omega_i^2, \ldots, \omega_i^L\right]$。显然 $\mathbb{E}W = 0$；下面的计算还表明 $\mathbb{E}W^2 \leq 2n^2/L$。应用切比雪夫不等式，当 $L > 32$ 时，以至少 $3/4$ 的概率，$|W| \leq n/2$，因此 $\| v \|_2^2 \geq n/2$。下面估计 W 的方差：

$$\begin{aligned} \mathbb{E}\left[\!\left[W^2\right]\!\right] &= \mathbb{E}\left[\!\left[\sum_{i_1 \neq j_1, i_2 \neq j_2} \zeta_{i_1} \zeta_{j_1} \langle \boldsymbol{\omega}_{i_1}, \boldsymbol{\omega}_{j_1} \rangle \zeta_{i_2} \zeta_{j_2} \langle \boldsymbol{\omega}_{i_2}, \boldsymbol{\omega}_{j_2} \rangle\right]\!\right] \\ &= 2\mathbb{E}\left[\!\left[\sum_{i \neq j} \langle \boldsymbol{\omega}_i, \boldsymbol{\omega}_j \rangle^2\right]\!\right] = 2n(n-1)\mathbb{E}\left[\!\left[\langle \boldsymbol{\omega}_1, \boldsymbol{\omega}_2 \rangle\right]\!\right] \leq \frac{2n^2}{L}, \end{aligned}$$

这里使用了 $\langle \omega_i, \omega_j \rangle^2 = \langle \omega_i, \omega_j \rangle$，因为内积只能取 0 或 1；也使用了 $\mathbb{E}\langle \omega_1, \omega_2 \rangle = 1/L$，即 x_1 和 x_2 上观测到同一个标签的概率。〔译注：原文在介绍方差估计时写成“Z 的方差”，随后公式实际计算的是 W；此外引理陈述未列出证明中使用的 $L > 32$ 条件。〕

D.2. Frobenius 范数正则化的下界

本节证明，即使对各向同性分布，Frobenius 范数正则化也不能给出迹范数正则化所能提供的 $O\left(1/\sqrt{nL}\right)$ 型界。

命题 8。 存在一个各向同性的次高斯数据分布和一个损失函数，使按 $\widehat{Z} = \operatorname{arginf}_{\|Z\|_F \le \lambda} \widehat{\mathcal{L}}(Z)$ 学得的经验风险最小化器，以常数概率具有总体风险下界

$$\mathcal{L}(\widehat{Z}) \ge \widehat{\mathcal{L}}(\widehat{Z}) + \Omega\left(\lambda\sqrt{\frac{1}{n}}\right),$$

而在同一分布上，按 $\widehat{Z} = \operatorname{arginf}_{\|Z\|_{\mathrm{tr}} \le \lambda} \widehat{\mathcal{L}}(Z)$ 学得的经验风险最小化器，以至少 $1-\delta$ 的概率满足

$$\mathcal{L}(\widehat{Z}) \le \widehat{\mathcal{L}}(\widehat{Z}) + O\left(\lambda\sqrt{\frac{1}{nL}}\right) + O\left(\sqrt{\frac{\log(1/\delta)}{n}}\right).$$

仍对 $\lambda = 1$ 证明。保留附录 D.1 的标签分布和损失函数，也继续用 ω_i^l 表示标签观测模式；但现在用 Rademacher 向量定义数据分布，即向量 x 的每个坐标都由下述分布生成：

$$r \sim \tfrac{1}{2}\left(\mathbf{1}_{\{r=1\}} + \mathbf{1}_{\{r=-1\}}\right).$$

于是采样

$$x_i = \frac{1}{\sqrt{d}}\left[r_i^1,\ r_i^2,\ \ldots,\ r_i^d\right],$$

各坐标独立。下面验证此分布满足定理 4 的假设。$\mathbb{E}\left[xx^T\right] = (1/d)I$，其中 I 为 $d \times d$ 单位矩阵，因此 $\sigma_1 = 1/d$、$\Sigma = 1$。对任意 $v \in \mathbb{R}^d$ 还有

$$\begin{aligned}
\mathbb{E}\left[\!\left[\exp\left(\boldsymbol{x}^\top \boldsymbol{v}\right)\right]\!\right] &= \mathbb{E}\left[\!\left[\exp\left(\sum_{j=1}^{d} \boldsymbol{x}^j \boldsymbol{v}^j\right)\right]\!\right] = \prod_{j=1}^{d} \mathbb{E}\left[\!\left[\exp\left(\boldsymbol{x}^j \boldsymbol{v}^j\right)\right]\!\right] \\
&= \prod_{j=1}^{d} \frac{1}{2}\left(\exp\left(\frac{1}{\sqrt{d}}\boldsymbol{v}^j\right) + \exp\left(-\frac{1}{\sqrt{d}}\boldsymbol{v}^j\right)\right) \\
&= \prod_{j=1}^{d} \cosh\left(\frac{1}{\sqrt{d}}\boldsymbol{v}^j\right) \le \prod_{j=1}^{d} \exp\left(\frac{1}{d}(\boldsymbol{v}^j)^2\right) \\
&= \exp\left(\sum_{j=1}^{d} \frac{1}{d}(\boldsymbol{v}^j)^2\right) = \exp\left(\frac{1}{d}\|\boldsymbol{v}\|_2^2\right),
\end{aligned}$$

第二个等式使用了 x 各坐标的独立性。因此 $\eta^2 = 2/d$，该分布满足定理 4 的全部前提。若采用迹范数正则化，应用定理 4 可得超额误差

$$O\left(\sqrt{\frac{d(\eta^2+\sigma_1)}{nL\Sigma}}\right) = O\left(\sqrt{\frac{d(2/d+1/d)}{nL\cdot 1}}\right) = O\left(\sqrt{\frac{1}{nL}}\right).$$

但以下计算表明，Frobenius 范数正则化无法保证优于 $O\left(\sqrt{1/n}\right)$ 的超额风险。假设确实使用 Frobenius 范数正则化，则

$$\widehat{Z} = \arg\inf_{\|Z\|_F \le 1} \widehat{\mathcal{L}}(Z) = \arg\inf_{\|Z\|_F \le 1} \frac{1}{n}\langle Z, X\rangle,$$

其中矩阵 X 定义为

$$X = \left[\sum_{i=1}^{L} \omega_i^1 \boldsymbol{x}_i \ \sum_{i=1}^{L} \omega_i^2 \boldsymbol{x}_i \ \ldots \ \sum_{i=1}^{L} \omega_i^L \boldsymbol{x}_i\right].$$

〔译注：此处矩阵定义的三个求和上限均印为 L，但下文范数展开及训练样本索引使用 n；应视为疑似求和上限笔误，裁切保留原式。〕

同前，数据分布中心化且损失函数线性，所以 $\mathcal{L}(\widehat{Z}) = 0$。类似应用 Hölder 不等式，可得

$$\widehat{Z} = -\frac{X}{\| X \|_F},$$

因此 $\widehat{\mathcal{L}}(\widehat{Z}) = -(1/n)\| X \|_F$。以下引理表明，以常数概率 $\| X \|_F \ge \sqrt{n/2}$，这意味着 $\mathcal{L}(\widehat{Z}) \ge \widehat{\mathcal{L}}(\widehat{Z}) + \Omega\left(\sqrt{1/n}\right)$，证明即使对各向同性分布，Frobenius 范数正则化也不能给出 $O\left(1/\sqrt{nL}\right)$ 型界。

引理 3。 以至少 $3/4$ 的概率，有 $\| X \|_F^2 \ge n/2$。

证明。 有

$$\begin{aligned}
\|X\|_F^2 &= \sum_{l=1}^{L}\left\|\sum_{i=1}^{n}\omega_i^l \boldsymbol{x}_i\right\|_2^2 = \sum_{l=1}^{L}\sum_{i=1}^{n}\omega_i^l \|\boldsymbol{x}_i\|_2^2 + \sum_{l=1}^{L}\sum_{i\ne j}\omega_i^l\omega_j^l\langle \boldsymbol{x}_i, \boldsymbol{x}_j\rangle \\
&= \sum_{i=1}^{n}\|\boldsymbol{x}_i\|_2^2 + \sum_{i\ne j}\langle \boldsymbol{x}_i, \boldsymbol{x}_j\rangle\langle \boldsymbol{\omega}_i, \boldsymbol{\omega}_j\rangle = n + W
\end{aligned}$$

其中同前，$\omega_i = \left[\omega_i^1, \omega_i^2, \ldots, \omega_i^L\right]$。接下来证明 $|W| \le n/2$，从而确立结论。显然 $\mathbb{E}W = 0$，且以下计算表明 $\mathbb{E}W^2 \le 2n^2/(Ld)$。应用切比雪夫不等式，当 $Ld > 32$ 时，以至少 $3/4$ 的概率有 $|W| \le n/2$，故 $\| X \|_F^2 \ge n/2$。W 的方差估计如下：

$$\begin{aligned}
\mathbb{E}\left[\!\left[W^2\right]\!\right] &= \mathbb{E}\left[\!\left[\sum_{i_1\ne j_1, i_2\ne j_2}\langle \boldsymbol{x}_{i_1}, \boldsymbol{x}_{j_1}\rangle\langle \boldsymbol{\omega}_{i_1}, \boldsymbol{\omega}_{j_1}\rangle\langle \boldsymbol{x}_{i_2}, \boldsymbol{x}_{j_2}\rangle\langle \boldsymbol{\omega}_{i_2}, \boldsymbol{\omega}_{j_2}\rangle\right]\!\right] \\
&= 2\mathbb{E}\left[\!\left[\sum_{i\ne j}\langle \boldsymbol{x}_i, \boldsymbol{x}_j\rangle^2\langle \boldsymbol{\omega}_i, \boldsymbol{\omega}_j\rangle^2\right]\!\right] = 2n(n-1)\mathbb{E}\left[\!\left[\langle \boldsymbol{x}_1, \boldsymbol{x}_2\rangle^2\langle \boldsymbol{\omega}_1, \boldsymbol{\omega}_2\rangle\right]\!\right] \\
&= 2n(n-1)\mathbb{E}\left[\!\left[\langle \boldsymbol{x}_1, \boldsymbol{x}_2\rangle^2\right]\!\right]\mathbb{E}\left[\!\left[\langle \boldsymbol{\omega}_1, \boldsymbol{\omega}_2\rangle\right]\!\right] \le \frac{2n^2}{Ld},
\end{aligned}$$

此处利用了数据点与标签模式独立采样这一事实。〔译注：引理陈述没有列出证明中使用的 $Ld > 32$ 条件。〕

E. 更多实验结果

E.1. 评价标准

给定测试集 $\{(x_i, y_i) : i = 1, \ldots, n\}$，使用以下三个标准评价实值预测器 $f(x) : \mathbb{R}^d \to \mathbb{R}$ 的性能。〔译注：原文此处将输出空间写为 $\mathbb{R}$；全文的多标签预测器实际输出一个标签得分向量，以下按原文说明其逐标签分量。〕

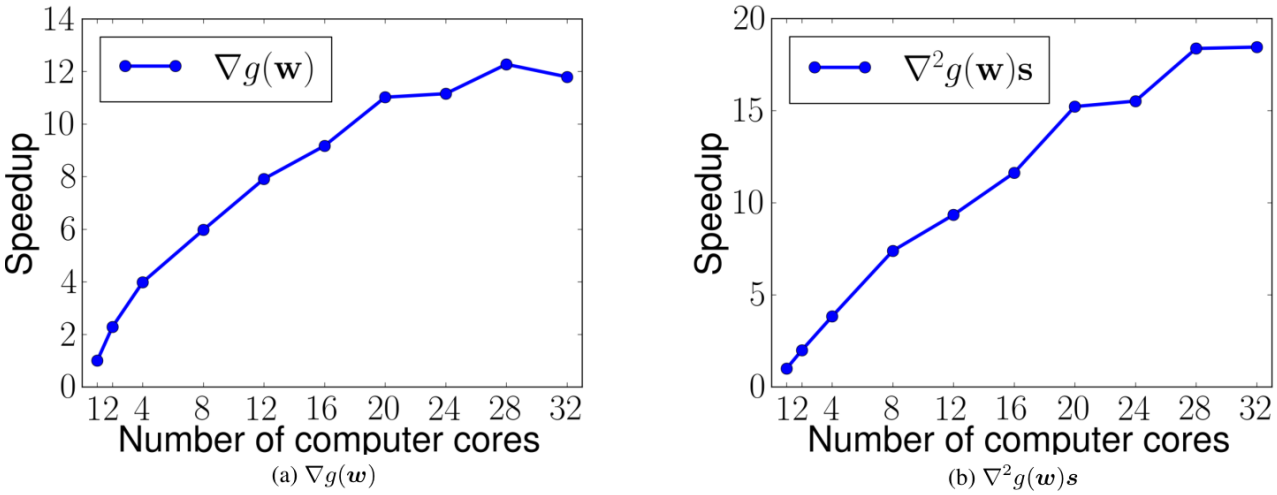
- **Top-K 准确率：** 对每个实例，选出决策值最大的 K 个标签作为预测。报告所有实例的平均准确率，作为 Top-K 准确率。
- **汉明损失：** 对每个实例 x 与标签下标 j 的组合，将决策值 $f^j(x)$ 舍入为 0 或 1：

$$\text{Hamming Loss} = \frac{1}{nL}\sum_{i=1}^{n}\sum_{j=1}^{L}\mathbf{1}\left[\text{round}\left(f^j(x)\right) \neq y^j\right].$$

〔译注：公式原文的 x, y 未附样本下标 i，此处保留其记法。〕

- **平均 AUC：** 遵循 Bucak et al. (2009)，为每个实例计算 ROC 曲线下面积，并报告所有测试实例的平均 AUC。

E.2. 多核计算带来的加速结果



(a) $\nabla g(\boldsymbol{w})$ (b) $\nabla^2 g(\boldsymbol{w})\boldsymbol{s}$

图 3。 本文提出的快速梯度计算和 Hessian-向量乘法的加速结果。(a) $\nabla g(w)$；(b) $\nabla^2 g(w)s$。两图横轴 Number of computer cores 为计算核心数，纵轴 Speedup 为加速比。曲线图例分别对应梯度计算与 Hessian-向量乘法。

E.3. 完整标签下的详细结果

- 表 6 给出标签完全观测时的 Top-1 准确率。
- 表 7 给出标签完全观测时的 Top-3 准确率。

· 表 8 给出标签完全观测时的 Top-5 准确率。

· 表 9 给出标签完全观测时的汉明损失。

· 表 10 给出标签完全观测时的平均 AUC。

表 6。 标签矩阵 Y 完全观测、采用不同秩时，降维方法的 Top-1 准确率比较。SQ 表示平方损失；LR 表示逻辑损失；SH 表示平方铰链损失；WAR 表示加权近似排名损失。 k/L 为秩相对标签数的比例。方法及数据集名称沿用原文。

		Top-1 Accuracy					
		LEML			BCS	CPLST	WSABIE
	k/L	SQ	LR	SH	SQ	SQ	WAR
bibtex	20%	**58.33**	46.20	46.52	41.43	55.55	48.51
	40%	**60.99**	50.78	40.68	54.63	58.73	52.37
	60%	**61.99**	51.37	39.24	57.53	60.36	51.45
	80%	**63.38**	52.64	39.96	59.76	62.31	53.04
	100%	**63.94**	53.76	38.41	60.24	63.02	53.24
autofood	20%	86.84	84.21	**89.47**	68.42	52.63	47.37
	40%	**92.11**	89.47	**92.11**	28.95	55.26	86.84
	60%	73.68	**89.47**	86.84	71.05	52.63	65.79
	80%	**94.74**	89.47	89.47	81.58	57.89	78.95
	100%	81.58	**89.47**	86.84	84.21	57.89	60.53
compphys	20%	92.50	87.50	**97.50**	70.00	52.50	65.00
	40%	**95.00**	92.50	**95.00**	65.00	50.00	47.50
	60%	**95.00**	92.50	**95.00**	72.50	47.50	70.00
	80%	95.00	87.50	**97.50**	75.00	50.00	45.00
	100%	95.00	**97.50**	**97.50**	67.50	50.00	52.50
delicious	20%	**67.16**	57.39	61.07	59.50	66.53	48.35
	40%	**66.66**	51.62	56.20	61.16	66.25	47.25
	60%	**66.28**	50.96	51.59	63.08	66.22	47.38
	80%	**66.25**	51.55	49.11	62.10	66.22	45.59
	100%	**66.28**	50.83	46.53	63.45	66.22	46.25

表 7。 标签矩阵 Y 完全观测、采用不同秩时，降维方法的 Top-3 准确率比较。SQ、LR、SH、WAR 及 k/L 的含义同表 6。

		Top-3 Accuracy					
			LEML		BCS	CPLST	WSABIE
	k/L	SQ	LR	SH	SQ	SQ	WAR
bibtex	20%	**34.16**	25.65	27.37	21.74	31.99	28.77
	40%	**36.53**	28.20	24.81	28.95	34.53	30.05
	60%	**38.00**	28.68	23.26	32.25	36.01	31.11
	80%	**38.58**	29.42	23.04	34.09	36.75	31.21
	100%	**38.41**	30.25	22.36	34.87	36.91	31.24
autofood	20%	**81.58**	80.70	**81.58**	53.51	42.98	66.67
	40%	76.32	**80.70**	78.95	50.88	42.11	70.18
	60%	70.18	80.70	**81.58**	64.91	41.23	60.53
	80%	80.70	80.70	**85.09**	73.68	42.98	72.81
	100%	75.44	80.70	**82.46**	65.79	42.98	64.04
compphys	20%	**80.00**	**80.00**	**80.00**	42.50	40.83	49.17
	40%	**80.00**	78.33	79.17	60.00	37.50	39.17
	60%	**80.00**	**80.00**	**80.00**	51.67	39.17	49.17
	80%	80.00	78.33	**80.83**	53.33	39.17	52.50
	100%	80.00	79.17	**81.67**	62.50	39.17	56.67
delicious	20%	**61.20**	53.68	57.27	53.01	61.13	42.87
	40%	**61.23**	49.13	52.95	56.20	61.08	42.05
	60%	**61.15**	46.76	49.58	57.07	61.09	42.22
	80%	**61.13**	48.06	47.34	57.09	61.09	42.01
	100%	**61.12**	46.11	45.92	57.91	61.09	41.34

表 8。 标签矩阵 Y 完全观测、采用不同秩时，降维方法的 Top-5 准确率比较。缩写同表 6。

		Top-5 Accuracy					
		LEML			BCS	CPLST	WSABIE
	k/L	SQ	LR	SH	SQ	SQ	WAR
bibtex	20%	**24.49**	19.24	20.33	15.39	23.11	21.92
	40%	**26.84**	20.61	18.54	19.95	24.96	22.47
	60%	**27.66**	20.99	17.61	22.43	26.07	23.33
	80%	**28.20**	21.48	17.46	24.07	26.47	23.44
	100%	**28.01**	22.03	16.83	24.48	26.47	23.44
autofood	20%	**81.05**	80.00	75.79	44.21	36.84	66.32
	40%	73.68	**78.42**	76.84	51.05	36.32	66.84
	60%	69.47	**78.95**	78.42	57.37	36.32	60.53
	80%	74.74	78.95	**80.53**	68.95	36.84	66.84
	100%	72.63	78.42	**83.16**	62.11	36.84	61.58
compphys	20%	72.00	**73.50**	72.50	32.50	37.50	46.00
	40%	73.00	74.00	**74.50**	54.50	35.50	41.00
	60%	73.00	**74.00**	**74.00**	43.50	34.50	44.00
	80%	73.00	73.00	**74.00**	47.50	36.00	46.50
	100%	72.50	72.50	**73.00**	54.50	36.00	49.50
delicious	20%	**56.46**	49.46	52.94	47.91	56.30	39.79
	40%	**56.39**	45.66	49.54	51.61	56.28	39.27
	60%	**56.28**	43.22	46.93	52.85	56.23	38.97
	80%	**56.27**	44.03	45.43	52.92	56.23	39.27
	100%	**56.27**	42.11	44.24	53.28	56.23	38.41

表 9。 标签矩阵 Y 完全观测、采用不同秩时，降维方法的汉明损失比较。缩写同表 6。

		Hamming Loss				
			LEML		BCS	CPLST
	k/L	SQ	LR	SH	SQ	SQ
bibtex	20%	**0.0126**	0.0211	0.0231	0.0150	**0.0127**
	40%	**0.0124**	0.0240	0.0285	0.0140	0.0126
	60%	**0.0123**	0.0233	0.0320	0.0132	0.0126
	80%	**0.0123**	0.0242	0.0343	0.0130	0.0125
	100%	**0.0122**	0.0236	0.0375	0.0129	0.0125
autofood	20%	**0.0547**	0.0621	0.0588	0.0846	0.0996
	40%	0.0590	0.0608	**0.0578**	0.0846	0.0975
	60%	0.0593	0.0611	**0.0586**	0.0838	0.0945
	80%	0.0572	0.0611	**0.0569**	1.0000	0.0944
	100%	0.0603	0.0617	**0.0586**	1.0000	0.0944
compphys	20%	0.0457	0.0470	**0.0456**	0.0569	0.0530
	40%	**0.0454**	0.0466	0.0456	0.0569	0.0526
	60%	**0.0454**	0.0469	0.0460	0.0569	0.0530
	80%	0.0464	0.0484	**0.0456**	0.0569	0.0755
	100%	0.0453	0.0469	**0.0450**	0.0569	0.0755
delicious	20%	**0.0181**	0.0196	0.0187	0.0189	**0.0182**
	40%	**0.0181**	0.0221	0.0198	0.0186	**0.0182**
	60%	**0.0182**	0.0239	0.0207	0.0187	**0.0182**
	80%	**0.0182**	0.0253	0.0212	0.0186	**0.0182**
	100%	**0.0182**	0.0260	0.0216	0.0186	**0.0182**

表 10。 标签矩阵 Y 完全观测、采用不同秩时，降维方法的平均 AUC 比较。缩写同表 6。

		Average AUC					
			LEML		BCS	CPLST	WSABIE
	k/L	SQ	LR	SH	SQ	SQ	WAR
bibtex	20%	0.8910	0.8677	0.8541	0.7875	0.8657	**0.9055**
	40%	0.9015	0.8809	0.8467	0.8263	0.8802	**0.9092**
	60%	0.9040	0.8861	0.8505	0.8468	0.8854	**0.9089**
	80%	0.9035	0.8875	0.8491	0.8560	0.8882	**0.9164**
	100%	0.9024	0.8915	0.8419	0.8614	0.8878	**0.9182**
autofood	20%	0.9565	**0.9598**	0.9424	0.7599	0.7599	0.8779
	40%	0.9277	**0.9590**	0.9485	0.7994	0.7501	0.8806
	60%	0.8815	**0.9582**	0.9513	0.8282	0.7552	0.8518
	80%	0.9280	**0.9588**	0.9573	0.8611	0.7538	0.8520
	100%	0.9361	**0.9581**	0.9561	0.8718	0.7539	0.8471
compphys	20%	0.9163	0.9223	**0.9274**	0.6972	0.7692	0.8212
	40%	**0.9199**	0.9157	0.9191	0.7881	0.7742	0.8066
	60%	**0.9179**	0.9143	0.9098	0.7705	0.7705	0.8040
	80%	0.9187	0.9003	**0.9220**	0.7820	0.7806	0.7742
	100%	**0.9205**	0.9040	0.8977	0.7884	0.7804	0.7951
delicious	20%	0.8854	0.8588	**0.8894**	0.7308	0.8833	0.8561
	40%	0.8827	0.8534	**0.8868**	0.7635	0.8814	0.8553
	60%	0.8814	0.8517	**0.8852**	0.7842	0.8834	0.8523
	80%	0.8814	0.8468	**0.8845**	0.7941	0.8834	0.8558
	100%	0.8814	0.8404	**0.8836**	0.8000	0.8834	0.8557

E.4. 缺失标签下的详细结果

- 表 11 给出不同缺失比例和降维比例下的 Top-1 准确率。
- 表 12 给出不同缺失比例和降维比例下的 Top-3 准确率。
- 表 13 给出不同缺失比例和降维比例下的 Top-5 准确率。
- 表 14 给出不同缺失比例和降维比例下的汉明损失。
- 表 15 给出不同缺失比例和降维比例下的平均 AUC。

以下各表统一释义：dataset 为数据集； k/L 为秩与标签数之比； $|\Omega|/(nL)$ 为已观测标签条目的比例（而非缺失比例）；Squared 为平方损失；Logsitic 为原表拼写，指 Logistic（逻辑损失）；Squared Hinge 为平方铰链损失。LEML、BCS、BR 为方法名。表中加粗、所有数值及数据集分组均按原版保留。

表 11。 Y 含缺失标签时的比较：Top-1 准确率。

dataset	$\frac{k}{L}$	$\frac{\lvert\Omega\rvert}{nL}$	Top-1 Accuracy						
			Squared			Logsitic		Squared Hinge	
			LEML	BCS	BR	LEML	BR	LEML	BR
bibtex	20%	5%	30.30	30.22	**42.90**	41.51	**46.68**	30.42	**44.97**
		10%	39.84	33.56	**44.53**	41.99	**51.09**	33.44	**48.55**
		20%	**48.35**	40.12	46.08	43.06	**55.94**	37.22	**52.84**
		40%	**52.37**	41.79	43.82	42.27	**58.57**	40.24	**55.39**
	40%	5%	34.35	39.17	**42.90**	43.42	**46.68**	31.13	**44.97**
		10%	42.11	39.96	**44.53**	46.00	**51.09**	29.03	**48.55**
		20%	**51.97**	45.49	46.08	47.40	**55.94**	32.05	**52.84**
		40%	**56.38**	50.10	43.82	49.70	**58.57**	38.17	**55.39**
	60%	5%	36.58	41.87	**42.90**	43.54	**46.68**	42.54	**44.97**
		10%	**45.53**	45.13	44.53	39.36	**51.09**	31.37	**48.55**
		20%	**53.52**	49.54	46.08	46.12	**55.94**	33.28	**52.84**
		40%	**57.18**	54.19	43.82	48.83	**58.57**	32.13	**55.39**
autofood	20%	5%	**7.89**	0.00	**7.89**	**7.89**	**7.89**	**7.89**	**7.89**
		10%	44.74	2.63	**50.00**	**55.26**	44.74	**50.00**	**50.00**
		20%	**63.16**	0.00	57.89	**73.68**	47.37	**68.42**	57.89
		40%	60.53	15.79	**78.95**	**81.58**	68.42	**86.84**	78.95
	40%	5%	**10.53**	**10.53**	7.89	**7.89**	**7.89**	**13.16**	7.89
		10%	**57.89**	7.89	50.00	**60.53**	44.74	**55.26**	50.00
		20%	**76.32**	31.58	57.89	**78.95**	47.37	**76.32**	57.89
		40%	60.53	5.26	**78.95**	**84.21**	68.42	**84.21**	78.95
	60%	5%	7.89	**10.53**	7.89	**7.89**	**7.89**	**7.89**	**7.89**
		10%	**57.89**	23.68	50.00	**57.89**	44.74	**55.26**	50.00
		20%	**73.68**	57.89	57.89	**78.95**	47.37	**76.32**	57.89
		40%	63.16	36.84	**78.95**	**81.58**	68.42	**89.47**	78.95
compphys	20%	5%	**62.50**	35.00	42.50	**45.00**	**45.00**	**67.50**	42.50
		10%	**75.00**	10.00	52.50	**67.50**	52.50	**55.00**	52.50
		20%	**72.50**	7.50	52.50	**72.50**	52.50	**70.00**	52.50
		40%	**87.50**	5.00	52.50	**77.50**	52.50	**80.00**	52.50
	40%	5%	**65.00**	60.00	42.50	**45.00**	**45.00**	**65.00**	42.50
		10%	**70.00**	17.50	52.50	**65.00**	52.50	**72.50**	52.50
		20%	**72.50**	52.50	52.50	**70.00**	52.50	**75.00**	52.50
		40%	**80.00**	42.50	52.50	**80.00**	52.50	**80.00**	52.50
	60%	5%	**67.50**	52.50	42.50	**45.00**	**45.00**	**65.00**	42.50
		10%	**70.00**	52.50	52.50	**67.50**	52.50	**67.50**	52.50
		20%	**77.50**	52.50	52.50	**80.00**	52.50	**80.00**	52.50
		40%	**82.50**	52.50	52.50	**80.00**	52.50	**80.00**	52.50

表 12。 Y 含缺失标签时的比较：Top-3 准确率。

dataset	$\frac{k}{L}$	$\frac{\|\Omega\|}{nL}$	Top-3 Accuracy						
			Squared			Logsitic		Squared Hinge	
			LEML	BCS	BR	LEML	BR	LEML	BR
bibtex	20%	5%	16.06	14.29	**22.19**	21.74	**24.47**	16.10	**23.29**
		10%	20.95	16.29	**24.10**	22.88	**28.43**	17.64	**26.69**
		20%	**26.34**	18.78	25.78	23.21	**31.92**	21.06	**29.56**
		40%	**30.17**	21.55	26.26	23.61	**34.50**	23.05	**31.99**
	40%	5%	18.73	18.99	**22.19**	22.84	**24.47**	17.03	**23.29**
		10%	22.49	20.16	**24.10**	25.18	**28.43**	16.62	**26.69**
		20%	**28.50**	23.84	25.78	25.79	**31.92**	18.97	**29.56**
		40%	**32.74**	27.58	26.26	27.18	**34.50**	21.18	**31.99**
	60%	5%	18.81	21.09	**22.19**	22.62	**24.47**	22.48	**23.29**
		10%	23.96	24.06	**24.10**	19.84	**28.43**	17.28	**26.69**
		20%	**29.07**	27.05	25.78	25.13	**31.92**	19.14	**29.56**
		40%	**33.55**	31.13	26.26	27.66	**34.50**	19.46	**31.99**
autofood	20%	5%	**30.70**	11.40	19.30	**29.82**	17.54	**38.60**	19.30
		10%	**52.63**	5.26	33.33	**50.88**	23.68	**57.02**	33.33
		20%	59.65	10.53	**62.28**	**70.18**	53.51	**66.67**	61.40
		40%	57.89	20.18	**71.93**	**76.32**	63.16	**75.44**	71.93
	40%	5%	**26.32**	15.79	19.30	**29.82**	17.54	**31.58**	19.30
		10%	**59.65**	12.28	33.33	**51.75**	23.68	**53.51**	33.33
		20%	**67.54**	35.09	62.28	**71.05**	53.51	**64.04**	61.40
		40%	55.26	33.33	**71.93**	**78.07**	63.16	**77.19**	71.93
	60%	5%	**25.44**	8.77	19.30	**28.95**	17.54	**22.81**	19.30
		10%	**52.63**	35.09	33.33	**50.00**	23.68	**61.40**	33.33
		20%	**68.42**	35.09	62.28	**73.68**	53.51	**71.05**	61.40
		40%	57.02	23.68	**71.93**	**75.44**	63.16	**74.56**	71.93
compphys	20%	5%	**46.67**	32.50	28.33	**40.00**	28.33	**40.00**	28.33
		10%	**53.33**	9.17	37.50	**59.17**	29.17	**40.83**	37.50
		20%	**62.50**	10.83	31.67	**60.83**	28.33	**61.67**	31.67
		40%	**69.17**	26.67	43.33	**73.33**	33.33	**70.83**	43.33
	40%	5%	**45.83**	27.50	28.33	**37.50**	28.33	**41.67**	28.33
		10%	**57.50**	20.83	37.50	**60.00**	29.17	**55.83**	37.50
		20%	**65.00**	35.83	31.67	**60.00**	28.33	**61.67**	31.67
		40%	**68.33**	32.50	43.33	**70.83**	33.33	**73.33**	43.33
	60%	5%	**45.00**	30.83	28.33	**35.83**	28.33	**45.00**	28.33
		10%	**59.17**	26.67	37.50	**61.67**	29.17	**56.67**	37.50
		20%	**65.00**	29.17	31.67	**60.83**	28.33	**64.17**	31.67
		40%	**71.67**	30.00	43.33	**65.83**	33.33	**70.83**	43.33

表 13。 Y 含缺失标签时的比较：Top-5 准确率。

dataset	$\frac{k}{L}$	$\frac{\|\Omega\|}{nL}$	Top-5 Accuracy						
			Squared			Logsitic		Squared Hinge	
			LEML	BCS	BR	LEML	BR	LEML	BR
bibtex	20%	5%	11.71	10.32	**16.14**	16.34	**17.74**	12.07	**17.32**
		10%	15.42	11.55	**17.77**	16.91	**20.80**	13.11	**19.65**
		20%	**19.51**	13.26	18.81	17.07	**23.95**	15.52	**22.12**
		40%	**22.05**	15.32	19.13	17.55	**25.57**	17.57	**23.30**
	40%	5%	13.53	13.25	**16.14**	17.02	**17.74**	12.70	**17.32**
		10%	16.25	14.30	**17.77**	18.78	**20.80**	12.24	**19.65**
		20%	**20.56**	17.36	18.81	19.05	**23.95**	14.46	**22.12**
		40%	**23.75**	19.73	19.13	19.67	**25.57**	15.86	**23.30**
	60%	5%	13.61	14.78	**16.14**	16.62	**17.74**	16.56	**17.32**
		10%	16.99	17.31	**17.77**	14.41	**20.80**	12.91	**19.65**
		20%	**21.10**	19.51	18.81	18.23	**23.95**	14.17	**22.12**
		40%	**24.50**	22.31	19.13	20.38	**25.57**	14.95	**23.30**
autofood	20%	5%	**35.26**	8.42	25.26	**34.21**	21.58	**36.84**	25.26
		10%	**46.84**	6.84	35.79	**51.05**	32.11	**48.95**	35.79
		20%	50.53	10.53	**57.89**	**66.84**	52.11	**60.53**	57.89
		40%	52.11	16.84	**68.42**	**73.16**	56.32	**72.11**	68.42
	40%	5%	**32.11**	17.89	25.26	**31.58**	21.58	**30.00**	25.26
		10%	**49.47**	10.00	35.79	**50.53**	32.11	**45.26**	35.79
		20%	**64.74**	32.11	57.89	**66.32**	52.11	**60.53**	57.89
		40%	50.53	28.95	**68.42**	**73.16**	56.32	**74.74**	68.42
	60%	5%	**31.58**	17.37	25.26	**31.05**	21.58	**30.00**	25.26
		10%	**50.53**	31.58	35.79	**52.63**	32.11	**53.68**	35.79
		20%	**64.74**	28.95	57.89	**68.42**	52.11	**67.89**	57.89
		40%	58.95	20.00	**68.42**	**71.58**	56.32	**69.47**	68.42
compphys	20%	5%	**34.50**	23.00	25.00	**28.50**	26.00	**34.50**	25.00
		10%	**50.50**	13.50	28.50	**51.50**	24.00	**41.50**	29.00
		20%	**52.00**	11.50	36.50	**55.00**	30.00	**53.00**	36.50
		40%	**60.50**	24.00	38.00	**64.50**	31.00	**64.00**	38.50
	40%	5%	**34.50**	22.00	25.00	**29.50**	26.00	**33.50**	25.00
		10%	**53.50**	29.00	28.50	**51.50**	24.00	**46.00**	29.00
		20%	**56.50**	31.00	36.50	**55.50**	30.00	**52.50**	36.50
		40%	**59.50**	26.00	38.00	**61.50**	31.00	**62.50**	38.50
	60%	5%	**36.00**	22.00	25.00	**27.50**	26.00	**33.50**	25.00
		10%	**53.00**	24.50	28.50	**50.50**	24.00	**50.50**	29.00
		20%	**56.50**	29.00	36.50	**54.00**	30.00	**55.50**	36.50
		40%	**61.00**	32.00	38.00	**61.50**	31.00	**63.50**	38.50

表 14。 Y 含缺失标签时的比较：汉明损失。

dataset	$\frac{k}{L}$	$\frac{\lvert\Omega\rvert}{nL}$	Hamming Loss						
				Squared		Logsitic		Squared Hinge	
			LEML	BCS	BR	LEML	BR	LEML	BR
bibtex	20%	5%	0.0158	0.1480	**0.0144**	0.0143	**0.0138**	0.0180	**0.0137**
		10%	**0.0146**	0.1360	0.0156	0.0144	**0.0134**	0.0187	**0.0135**
		20%	**0.0136**	0.1179	0.0193	0.0156	**0.0132**	0.0210	**0.0136**
		40%	**0.0131**	0.0994	0.0251	0.0174	**0.0128**	0.0242	**0.0141**
	40%	5%	0.0152	0.2837	**0.0144**	0.0141	**0.0138**	0.0175	**0.0137**
		10%	**0.0149**	0.2716	0.0156	0.0141	**0.0134**	0.0211	**0.0135**
		20%	**0.0136**	0.2496	0.0193	0.0150	**0.0132**	0.0226	**0.0136**
		40%	**0.0128**	0.2271	0.0251	0.0160	**0.0128**	0.0269	**0.0141**
	60%	5%	0.0154	0.4082	**0.0144**	0.0145	**0.0138**	0.0154	**0.0137**
		10%	**0.0147**	0.3978	0.0156	0.0163	**0.0134**	0.0215	**0.0135**
		20%	**0.0138**	0.3726	0.0193	0.0157	**0.0132**	0.0252	**0.0136**
		40%	**0.0129**	0.3638	0.0251	0.0172	**0.0128**	0.0312	**0.0141**
autofood	20%	5%	**0.0924**	0.1727	0.0942	**0.0918**	0.0991	**0.0884**	0.0942
		10%	**0.0807**	0.1449	0.0837	**0.0832**	0.0854	**0.0811**	0.0837
		20%	**0.0750**	0.1436	0.0760	**0.0686**	0.0843	**0.0697**	0.0760
		40%	0.0780	0.1399	**0.0752**	**0.0655**	0.0838	**0.0629**	0.0750
	40%	5%	**0.0919**	0.2887	0.0942	**0.0919**	0.0991	**0.0941**	0.0942
		10%	**0.0801**	0.2264	0.0837	**0.0812**	0.0854	**0.0814**	0.0837
		20%	**0.0671**	0.2445	0.0760	**0.0681**	0.0843	**0.0697**	0.0760
		40%	0.0903	0.2042	**0.0752**	**0.0647**	0.0838	**0.0648**	0.0750
	60%	5%	**0.0932**	0.4189	0.0942	**0.0921**	0.0991	**0.0937**	0.0942
		10%	0.0840	0.4144	**0.0837**	**0.0817**	0.0854	**0.0817**	0.0837
		20%	**0.0689**	0.3596	0.0760	**0.0676**	0.0843	**0.0692**	0.0760
		40%	**0.0724**	0.3384	0.0752	**0.0650**	0.0838	**0.0645**	0.0750
compphys	20%	5%	**0.0555**	0.1391	0.0556	**0.0554**	0.0555	0.0567	**0.0556**
		10%	**0.0536**	0.1446	0.0565	**0.0542**	0.0569	**0.0554**	0.0565
		20%	**0.0524**	0.1431	0.0566	**0.0518**	0.0566	**0.0518**	0.0566
		40%	**0.0484**	0.1048	0.0543	**0.0489**	0.0561	**0.0488**	0.0543
	40%	5%	0.0567	0.2924	**0.0556**	**0.0555**	**0.0555**	0.0566	**0.0556**
		10%	**0.0532**	0.2532	0.0565	**0.0535**	0.0569	**0.0532**	0.0565
		20%	**0.0518**	0.2569	0.0566	**0.0513**	0.0566	**0.0518**	0.0566
		40%	**0.0505**	0.1766	0.0543	**0.0495**	0.0561	**0.0484**	0.0543
	60%	5%	0.0558	0.4394	**0.0556**	0.0556	**0.0555**	**0.0555**	0.0556
		10%	**0.0532**	0.4148	0.0565	**0.0532**	0.0569	**0.0544**	0.0565
		20%	**0.0516**	0.3797	0.0566	**0.0519**	0.0566	**0.0517**	0.0566
		40%	**0.0486**	0.3563	0.0543	**0.0495**	0.0561	**0.0480**	0.0543

表 15。 Y 含缺失标签时的比较：平均 AUC。

dataset	$\frac{k}{L}$	$\frac{\lvert\Omega\rvert}{nL}$	Average AUC						
				Squared		Logsitic		Squared Hinge	
			LEML	BCS	BR	LEML	BR	LEML	BR
bibtex	20%	5%	0.7115	0.6529	**0.7789**	0.8066	**0.8123**	0.7363	**0.7998**
		10%	0.7665	0.6756	**0.7954**	0.8208	**0.8561**	0.7371	**0.8210**
		20%	**0.8269**	0.7111	0.8087	0.8205	**0.8941**	0.7859	**0.8378**
		40%	**0.8674**	0.7375	0.8104	0.8347	**0.9153**	0.8167	**0.8530**
	40%	5%	0.7379	0.7182	**0.7789**	**0.8164**	0.8123	0.7396	**0.7998**
		10%	0.7730	0.7353	**0.7954**	0.8370	**0.8561**	0.7351	**0.8210**
		20%	**0.8332**	0.7817	0.8087	0.8392	**0.8941**	0.7813	**0.8378**
		40%	**0.8724**	0.8097	0.8104	0.8639	**0.9153**	0.8038	**0.8530**
	60%	5%	0.7376	0.7445	**0.7789**	**0.8132**	0.8123	**0.8051**	0.7998
		10%	0.7778	0.7831	**0.7954**	0.7639	**0.8561**	0.7444	**0.8210**
		20%	**0.8367**	0.8264	0.8087	0.8251	**0.8941**	0.7755	**0.8378**
		40%	**0.8753**	0.8504	0.8104	0.8716	**0.9153**	0.7899	**0.8530**
autofood	20%	5%	**0.7170**	0.5198	0.6451	**0.7070**	0.6356	**0.7235**	0.6450
		10%	**0.8083**	0.5578	0.7576	**0.8194**	0.7259	**0.8131**	0.7576
		20%	0.8043	0.5804	**0.8178**	**0.8797**	0.7712	**0.8665**	0.8178
		40%	0.8007	0.5807	**0.8860**	**0.9317**	0.8087	**0.9237**	0.8857
	40%	5%	**0.7129**	0.6299	0.6451	**0.7029**	0.6356	**0.7157**	0.6450
		10%	**0.8218**	0.6517	0.7576	**0.8198**	0.7259	**0.8175**	0.7576
		20%	**0.8634**	0.6322	0.8178	**0.8796**	0.7712	**0.8644**	0.8178
		40%	0.8131	0.6848	**0.8860**	**0.9319**	0.8087	**0.9260**	0.8857
	60%	5%	**0.7175**	0.6013	0.6451	**0.7045**	0.6356	**0.7128**	0.6450
		10%	**0.8206**	0.6316	0.7576	**0.8196**	0.7259	**0.8213**	0.7576
		20%	**0.8725**	0.6758	0.8178	**0.8800**	0.7712	**0.8781**	0.8178
		40%	0.8141	0.6351	**0.8860**	**0.9315**	0.8087	**0.9255**	0.8857
compphys	20%	5%	**0.6486**	0.5727	0.6457	**0.6479**	0.6424	**0.6488**	0.6457
		10%	**0.7478**	0.5691	0.7235	**0.7473**	0.7147	**0.7556**	0.7235
		20%	**0.7908**	0.5729	0.7459	**0.7921**	0.7297	**0.8101**	0.7459
		40%	**0.8172**	0.6788	0.7728	**0.8416**	0.7413	**0.8718**	0.7730
	40%	5%	**0.6474**	0.6049	0.6457	**0.6478**	0.6424	**0.6480**	0.6457
		10%	**0.7509**	0.6295	0.7235	**0.7481**	0.7147	**0.7437**	0.7235
		20%	**0.7964**	0.6442	0.7459	**0.7913**	0.7297	**0.7849**	0.7459
		40%	**0.8192**	0.6651	0.7728	**0.8371**	0.7413	**0.8561**	0.7730
	60%	5%	0.6443	0.6089	**0.6457**	**0.6468**	0.6424	**0.6601**	0.6457
		10%	**0.7504**	0.6505	0.7235	**0.7489**	0.7147	**0.7421**	0.7235
		20%	**0.7991**	0.6687	0.7459	**0.7854**	0.7297	**0.8064**	0.7459
		40%	**0.8269**	0.7240	0.7728	**0.8378**	0.7413	**0.8659**	0.7730

〔译注：补充表 15 的 bibtex、$k/L = 40\%$、观测率 20%、平方损失 BCS 的 AUC 印为 0.7817；主文表 4 同一设置印为 0.7871。两处原始数据不一致，均予保留，不替作者选择更正值。补充材料没有独立参考文献表，所引文献见主文参考文献。〕