鞅一致的自监督学习

Martingale-Consistent Self-Supervised Learning

Moritz Gögl[1]　Hanwen Xing[1]　Christopher Yau[1,2]

[1] 牛津大学　[2] 英国健康数据研究所（Health Data Research UK）

联系邮箱：moritz.gogl@keble.ox.ac.uk

非官方完整中文译文｜arXiv:2605.11846v1｜原文日期 2026 年 5 月 12 日｜预印本

译文与许可说明

原作者为 Moritz Gögl、Hanwen Xing 和 Christopher Yau。原文：版本说明及许可；原始 PDF。原文采用 Creative Commons Attribution 4.0 International（CC BY 4.0） 许可。本译文由 AI 助手制作，亦按 CC BY 4.0 提供；未获作者审定，不代表作者或机构背书。

本文件将正文、致谢、参考文献及附录 A–F 译为中文，重新排版；保留公式、符号、引文编号及表格数值。图表按原 PDF 裁切保留，图内英文及原表内容不改写，中文图注、表注和术语对照随附。**图 4A 含第三方 CIFAR 示例照片，其再分发权限尚未确立，因此本译文只保留图 4B；图 4 的完整图注与相关正文仍译出。**查看图 4A 请访问上述原始 PDF 第 9 页。本译文没有以替代图片冒充原图；其余六幅图完整保留。除上述翻译、重排、可读性放大及图 4A 省略外，未有意改动原文论述；原文结论与局限按原意保留。原始 PDF 保持不变。

摘要

自监督学习（SSL）经常部署在信息不断变化的情境下，例如历史变短、特征缺失或图像仅部分可见。在这些情境中，粗视图与精细视图的预测应当协调一致：在信息细化之前，粗视图预测应与细化后预期获得的预测均值相同。鞅将这一协调性原则形式化，但标准 SSL 目标并不强制满足它。与使各视图彼此靠近的不变性目标不同，鞅一致性只约束精细预测的期望，允许预测随着信息显露而更新，同时避免系统性漂移。我们提出一个鞅一致的 SSL 框架来弥补这一缺口，提供实用的预测空间与潜在空间变体，以及基于随机细化的无偏双样本蒙特卡洛估计器。我们在部分观测条件下，使用合成与真实的时间序列、表格和图像基准，在半自监督及完全无标签两种设置中评估该方法。在这些实验中，本框架改善了部分观测下的鲁棒性与校准，使信息显露时的表示更加稳定。

1 引言

自监督学习（SSL）已成为从无标签数据中学习可复用表示的标准方法 [23, 6, 10, 13]。然而，尽管人们已从互信息最大化、潜变量建模和掩码条件预测等概率视角研究 SSL，现有 SSL 目标通常并不把所学预测器视为一个由嵌套信息集索引、协调一致的条件期望族。实际中，学习到的预测器常常需要在多种信

息集下接受查询：这些信息集对应较短或较长的历史、较粗或较细的上下文、延迟或缺失的特征，或者不同的数据获取预算。于是，人们期望同一个模型在信息被揭示、保留不予提供或进一步细化时，都能协调一致地行动。

示例。假设一个模型预测患者未来 24 小时内是否会发生脓毒症（$Y \in \{0, 1\}$）。输入 x 由临床测量组成，包括体温、心率、血压、白细胞计数和乳酸水平。不同信息集对应诊疗过程中数据可用性的不同阶段。例如，可以有三个嵌套观测集：(i) $\mathcal{F}_1$：仅生命体征；(ii) $\mathcal{F}_2$：生命体征加常规化验；(iii) $\mathcal{F}_M$：全部可用测量，满足 $\mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \mathcal{F}_M$。预测器 g 可能仅依据生命体征估计脓毒症风险为 $g\left(x_{\mathcal{F}_1}\right) = 0.30$，并在化验结果可用后修正该估计。在尚未观测到化验结果之前，我们合理地期望：给定当前可用信息时，精细预测的条件期望等于粗预测：

$$\mathbb{E}\left[g\left(x_{\mathcal{F}_2}\right) \mid x_{\mathcal{F}_1}\right] = g\left(x_{\mathcal{F}_1}\right).$$

这就是鞅性质。

直观地说，对某一患者，化验结果到达后精细预测可能显著上升或下降。但在尚未看到这些结果时，模型不应系统性地预期自身未来预测向上或向下漂移。如果条件期望反而等于 $0.45 \neq 0.30$，则模型其实已经隐含地在粗信息阶段低估了风险。

本文将 SSL 中对这一鞅性质的强制满足称为鞅一致性 [25]。标准 SSL 目标并不强制满足这种一致性 [6, 10, 13]，因此可能学习出在各个视图上表现良好、但在嵌套信息集之间总体不一致的预测器。我们建立信息变化条件下的 SSL 概率视角：预测器构成一个由信息结构索引的条件期望族，并在训练中强制信息细化之间的协调性。

贡献。我们的贡献有三方面：(1) 指出鞅一致性是将 SSL 看作条件期望族时一个具有定义性、却尚缺失的结构性质：标准 SSL 在多个条件集上使用单个预测器，却不强制满足有效条件期望算子所需的一致性关系；我们将该性质引入为训练准则；(2) 提供实用训练方案，即预测空间和潜在空间的鞅惩罚与无偏双样本蒙特卡洛估计器，无需针对模态重新设计即可填补这一缺口；(3) 在时间、表格和图像基准的半自监督与完全自监督设置中，证明弥补该缺口能改善部分观测下的下游鲁棒性、概率校准及表示稳定性。

2 相关工作

跨目标与模态的 SSL。SSL 已沿着若干主要目标族发展。在视觉领域，SimCLR [6]、BYOL [10] 等对比与自举方法通过对齐增强视图学习表示，而 MAE 等掩码重建方法通过预测被遮蔽内容，从不完整输入中学习 [13]。在时间序列领域，TS2Vec [28] 使用分层对比学习，Ti-MAE [16] 与 SimMTM [9] 则采用掩码建模目标。在表格学习中，VIME [27]、SCARF [3] 和 SubTab [22] 分别通过基于扰动的前置任务、对比学习以及特征子集视图来适配自监督。

跨视图一致性。许多 SSL 方法依赖多个视图之间的一致，但通常借助不变性或表示对齐。SimCLR [6] 和 BYOL [10] 鼓励各增强视图的表示相似，VICReg [4] 则通过不变性、方差和协方差正则化显式实现这一点。掩码建模方法也通过重建来耦合视图 [13, 16, 9]。这些约束要求视图彼此相似，却不约束信息

细化时预测如何更新。相比之下，鞅一致性强制一个有方向性的恒等式：粗预测等于精细预测的期望；这是条件期望族的定义关系。它补充而非取代现有 SSL 目标：正如实验将显示的，在 SimCLR 和 BYOL 上叠加该约束能够相较于原始目标改善下游鲁棒性，说明它捕捉到了这些目标未加约束的结构。

3 自监督学习中的条件协调性

3.1 问题设置

设 $(X_t)_{t=1}^{T}$ 是联合分布为 $p(x_{1:T})$ 的随机过程。我们旨在学习部分历史的表示，使其能在任意条件结构下有效预测未来变量。令 $\mathcal{F}$ 表示某个观测视图（例如经掩码或子采样的历史）中可获得的信息。对于目标随机变量 $Y = h(X_{t+1:t+k})$，给定 $\mathcal{F}$ 的贝叶斯最优预测器为条件期望 $m_{\mathcal{F}} := \mathbb{E}[Y \mid \mathcal{F}]$。

条件期望的一个基本性质是鞅性质：对于任何 $\mathcal{F}_1 \subseteq \mathcal{F}_2$，

$$\mathbb{E}\left[m_{\mathcal{F}_2} \mid \mathcal{F}_1\right] = m_{\mathcal{F}_1}. \qquad (1)$$

图 1 展示了这一性质。它表示：对 $\mathcal{F}_1$ 中尚未观测的信息取平均，精细视图的预测就还原为仅依据 $\mathcal{F}_1$ 的预测。直观而言，在观测到任何额外信息之前，我们对细化后预测变化的期望应保持不变。遵循这一原则的预测器称为鞅一致的预测器。

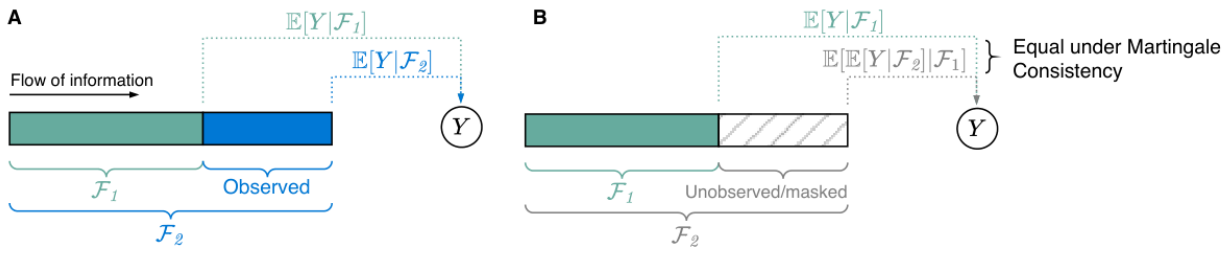


图 1　鞅性质示意图。(A) 根据可用信息更新对目标 Y 的预测。(B) 鞅性质表示，在没有进一步信息的条件下对 Y 的条件期望，应与仅依据已观测信息得到的期望一致。当这一点对所有嵌套对 $(\mathcal{F}_1, \mathcal{F}_2)$ 都成立时，就实现了一致性。图内：Flow of information＝信息流；Observed＝已观测；Unobserved/masked＝未观测／被掩码；Equal under Martingale Consistency＝在鞅一致性下相等。

3.2 在自监督中的应用

标准 SSL 方法可解释为在某个特定条件结构下学习预测器 [6, 10, 13]。令 Y 表示与 X 相关联的目标随机变量，它既可由外部提供，也可从 X 本身导出。每个训练目标都近似如下形式的条件期望：

$$g_\phi(x_{\mathcal{F}}) \approx \mathbb{E}[Y \mid \mathcal{F}], \qquad (2)$$

其中，$\mathcal{F}$ 由作用于 X 的掩码方案、子采样规则或因果历史诱导。

然而，训练后，同一预测器 g_ϕ 通常会用于许多部分观测模式 $x_{\mathcal{F}}$。这隐含地将 g_ϕ 视为由 $\mathcal{F}$ 索引的条件预测器族。但标准 SSL 目标独立训练每种条件，并不强制嵌套信息集之间协调一致。即使训练让模型接触了掩码或部分信息模式的某个分布，学习问题仍按观测视图分解，在不同视图下作出的预测并未被显式耦合。我们提出直接把鞅恒等式作为训练目标施加。

从表示学习角度看，这是一种结构归纳偏置：通过惩罚不同掩码、子采样方案或时间尺度之间的不协调，鼓励模型学习在信息边缘化下保持稳定的表示，提高观测模式变化时的鲁棒性。

3.3 鞅一致性目标

现在形式化本方法的鞅一致性目标。令 $P(\mathcal{F})$ 表示由掩码、子采样或历史选择规则诱导的信息模式分布。每次抽取 $\mathcal{F} \sim P$ 对应一个部分观测 $x_{\mathcal{F}}$。于是，我们可以学习预测器

$$g_\phi(x_{\mathcal{F}}) \approx \mathbb{E}[Y \mid \mathcal{F}], \qquad (3)$$

其参数为 ϕ，通常实现为共享编码器之上的神经网络预测头。

预测项。我们包含标准的自监督预测损失

$$\mathcal{L}_{\text{pred}} = \mathbb{E}\left[\ell\left(g_\phi(X_{\mathcal{F}}),\, Y\right)\right], \qquad (4)$$

其中 ℓ 是均方误差或负对数似然。在纯自监督设置中，通常令 $Y = t(X)$，其中 t 是合适的目标映射。

鞅一致性项。为强制不同条件之间的协调性，我们采样嵌套信息集 $\mathcal{F}_1 \subseteq \mathcal{F}_2$（如粗、细掩码），并惩罚偏离鞅恒等式的程度：

$$\mathcal{L}_{\text{mart}} = \mathbb{E}_{\mathcal{F}_1 \subseteq \mathcal{F}_2}\Big[\, \| \, g_\phi(x_{\mathcal{F}_1}) - \mathbb{E}\left[g_\phi(x_{\mathcal{F}_2}) \mid x_{\mathcal{F}_1}\right] \| \,^2\Big]. \qquad (5)$$

完整目标为 $\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda \mathcal{L}_{\text{mart}}$。不过，单独的 $\mathcal{L}_{\text{mart}}$ 并不能确定有用的预测器。例如，任何与掩码无关的常数预测器 $g_\phi(x_{\mathcal{F}}) \equiv c$ 都满足

$$g_\phi(x_{\mathcal{F}_1}) - \mathbb{E}\left[g_\phi(x_{\mathcal{F}_2}) \mid x_{\mathcal{F}_1}\right] = c - c = 0, \qquad (6)$$

因而即使没有信息量，也会得到零鞅惩罚。更一般地，对任意常向量 c，将 g_ϕ 替换为 $g_\phi + c$ 不改变 $\mathcal{L}_{\text{mart}}$。因此，$\mathcal{L}_{\text{mart}}$ 必须与将编码器锚定到有意义目标上的预测目标结合。附录 B.4 以闭式形式刻画了这一归纳偏置：增大 λ 会逐步恢复最优的粗视图预测器。

与标准一致性正则化及不变性学习的区别。传统对称视图对齐或一致性目标鼓励不同视图的预测或表示直接相似，例如 $g(x_{\mathcal{F}_1}) \approx g(x_{\mathcal{F}_2})$，从而抑制依赖视图的变化。相反，鞅一致性只约束精细预测的条件期望，即 $g(x_{\mathcal{F}_1}) \approx \mathbb{E}\left[g(x_{\mathcal{F}_2}) \mid x_{\mathcal{F}_1}\right]$；它允许随着额外信息显露，单个精细预测发生显著变化，同时避免期望中的系统性漂移。因此，该目标保留对信息敏感的更新，而不是强制跨视图不变性。

3.4 近似条件期望

为了使鞅目标切实可用，必须近似条件期望 $\mathbb{E}\left[g_\phi(x_{\mathcal{F}_2}) \mid x_{\mathcal{F}_1}\right]$。一种自然策略是从一个在条件上与 $x_{\mathcal{F}_1}$ 一致的细化机制中独立采样，再利用这些样本构建蒙特卡洛估计器。但在 $\mathcal{L}_{\text{mart}}$ 内用有限样本平均替代该条件期望，会因蒙特卡洛方差而引入偏差。我们提出无偏的双样本蒙特卡洛估计器：给定 $x_{\mathcal{F}_1}$，抽取两个条件独立的细化结果 $x_{\mathcal{F}_2}^{(a)}$ 与 $x_{\mathcal{F}_2}^{(b)}$，定义 $u := g_\phi(x_{\mathcal{F}_1})$、$v_a := g_\phi(x_{\mathcal{F}_2}^{(a)})$、$v_b := g_\phi(x_{\mathcal{F}_2}^{(b)})$，并令

$$\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}} = (u - v_a)^{\top}(u - v_b). \qquad (7)$$

由于两个样本相互独立，且期望均为 $\mathbb{E}\left[g_\phi\left(x_{\mathcal{F}_2}\right) \mid x_{\mathcal{F}_1}\right]$，给定 $x_{\mathcal{F}_1}$ 取条件期望可得

$$\mathbb{E}\left[\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}} \mid x_{\mathcal{F}_1}\right] = \| g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[g_\phi\left(x_{\mathcal{F}_2}\right) \mid x_{\mathcal{F}_1}\right] \|^2. \qquad (8)$$

进一步对 $x_{\mathcal{F}_1}$ 取期望即可恢复 $\mathcal{L}_{\mathrm{mart}}$，所以 $\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}}$ 是 $\mathcal{L}_{\mathrm{mart}}$ 的无偏估计器，而不是另一种目标（证明见附录 B.1）。尽管它的方差比大样本蒙特卡洛平均更高，但每个分支仅抽取一个样本时仍保持无偏。

3.5 潜在空间的鞅一致性

在图像、视频或长序列等高维设置中，直接在观测空间强制鞅一致性可能不切实际。自监督模型通过编码器将部分观测映射到低维潜在表示，因此在这一层面施加一致性很自然。形式上，令编码器 f_θ 将部分观测 $x_{\mathcal{F}}$ 映射到潜在表示 $z_{\mathcal{F}} = f_\theta\left(x_{\mathcal{F}}\right)$。这一表示保留了输入视图信息的粗化版本。我们考虑 $g_\phi\left(z_{\mathcal{F}}\right) \approx \mathbb{E}\left[Y \mid z_{\mathcal{F}}\right]$ 形式的预测器，并在潜在表示层面强制嵌套条件 $\mathcal{F}_1 \subseteq \mathcal{F}_2$ 之间的鞅一致性：$\mathbb{E}\left[g_\phi\left(z_{\mathcal{F}_2}\right) \mid z_{\mathcal{F}_1}\right] = g_\phi\left(z_{\mathcal{F}_1}\right)$。我们将其作为式 (1) 在潜在空间中的替代；当 $z_{\mathcal{F}_1}$ 生成 $\mathcal{F}_1$ 时，它与总体鞅恒等式严格一致。这强制的是相对于编码器所保留信息的协调性，而不是相对于完整观测空间的协调性。所报告实验通过随机补全，以及 EMA 变体中精细路径的目标网络，实现潜在空间约束。因此，潜在空间鞅一致性是理想观测空间约束的可扩展替代。其保证相对于编码器而言：仅对潜在空间保留的信息强制一致性，而非原始输入中的全部信息。这种权衡在现代自监督和掩码自编码架构中很常见 [13, 2, 10]。

4 鞅一致 SSL 框架的具体实现

现在将第 3 节的框架转化为具体训练方案。该框架只要求一个嵌套对 $\mathcal{F}_1 \subseteq \mathcal{F}_2$，其中 $\mathcal{F}_2$ 可以是 $\mathcal{F}_1$ 的任何细化。不过，在后续实验中，我们不失一般性地采用缺失情形下最自然的选择：$\mathcal{F}_2 = x$ 是完整输入，即信息最丰富的训练视图；$\mathcal{F}_1 = x_{\mathrm{obs}}$ 是被掩码的部分视图：

$$x_{\mathcal{F}_1} := x_{\mathrm{obs}} := x \odot M, \qquad x_{\mathcal{F}_2} := x. \qquad (9)$$

图 2 展示这一架构在右删失时间序列数据上的形式。共享编码器 f_θ 与预测头 g_ϕ 应用于完整输入，产生基本预测损失 $\mathcal{L}_{\mathrm{pred}}$；在半自监督设置中它是分类损失，在无标签设置中则可以是重建损失。

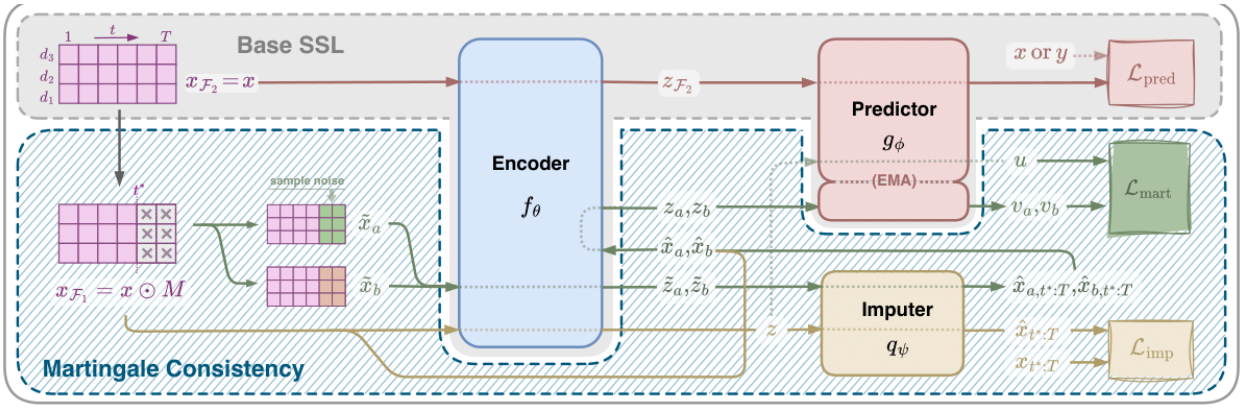


图 2　鞅一致 SSL 的基础模型架构，以右删失时间序列设置为例。预测分支使用完全观测输入 $x_{\mathcal{F}_2} = x$；鞅分支从 $x_{\mathcal{F}_1} = x_{\text{obs}} = x \odot M$ 出发，经 q_ψ 形成两个插补细化结果 $\widehat{x}_a, \widehat{x}_b$，并在预测或潜在空间中实现鞅估计器 $\widehat{\mathcal{L}}^{\text{2MC}}_{\text{mart}}$；$\mathcal{L}_{\text{imp}}$ 仅作用于被移除的条目。图内：Base SSL＝基础 SSL；Encoder＝编码器；Predictor＝预测器；Imputer＝插补器；sample noise＝采样噪声；Martingale Consistency＝鞅一致性。

插补器。应用式 (8) 需要从 $p\left(x_{\mathcal{F}_2} \mid x_{\mathcal{F}_1}\right)$（给定部分视图时完整输入的条件分布）抽取两个样本。一般而言，该分布未知，所以我们引入插补器 q_ψ：这是一个学习得到的随机补全网络，通过给定 $x_{\mathcal{F}_1}$ 填充未观测坐标来近似 $p\left(x_{\mathcal{F}_2} \mid x_{\mathcal{F}_1}\right)$。它通过仅作用于被移除条目的辅助损失 $\mathcal{L}_{\text{imp}}$ 训练，使其训练信号与预测目标保持分离。给定 $x_{\mathcal{F}_1}$，从 q_ψ 独立抽样两次得到随机补全 $\widehat{x}_a$ 和 $\widehat{x}_b$：各自将 x 的已观测条目与缺失坐标上独立插补的样本合并，提供式 (8) 所需的近似条件独立细化。

预测空间和潜在空间变体。记 $z = f_\theta\left(x_{\mathcal{F}_1}\right)$、$z_a = f_\theta\left(\widehat{x}_a\right)$、$z_b = f_\theta\left(\widehat{x}_b\right)$。预测空间变体将 $u = g_\phi(z)$ 作为粗预测，将 $v_a = g_\phi(z_a)$、$v_b = g_\phi(z_b)$ 作为两个精细预测代入，得到估计器 $\widehat{\mathcal{L}}^{\text{2MC}}_{\text{mart,pred}}$。潜在空间变体则直接使用这些表示：

$$\widehat{\mathcal{L}}^{\text{2MC}}_{\text{mart,lat}} = (z - z_a)^\top (z - z_b), \qquad (10)$$

其中 z 是粗潜在表示，z_a, z_b 是两个精细表示。这通过基于插补器的细化，将第 3 节的潜在空间替代具体化。

EMA 目标网络。两个变体都可以扩展为指数移动平均（EMA）形式：使用编码器或预测头的缓慢更新副本计算精细目标（v_a, v_b 或 z_a, z_b）。每一步后，其参数通过 $\theta_{\text{EMA}} \leftarrow \tau\theta_{\text{EMA}} + (1-\tau)\theta$ 跟踪主网络，以防止同一网络同时决定粗预测及其优化所要匹配的精细目标时出现移动目标不稳定性。

组合训练目标为

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{pred}} + \lambda_{\text{imp}}\mathcal{L}_{\text{imp}} + \lambda_{\text{mart}}\mathcal{L}_{\text{mart}}, \qquad (11)$$

其中，根据变体，$\mathcal{L}_{\text{mart}}$ 由 $\widehat{\mathcal{L}}^{\text{2MC}}_{\text{mart,pred}}$ 或 $\widehat{\mathcal{L}}^{\text{2MC}}_{\text{mart,lat}}$ 实现。$\mathcal{L}_{\text{imp}}$ 属于基于插补的细化机制，而非抽象鞅目标本身：它训练 q_ψ 产生实现双样本估计器的随机补全。完整实现细节见附录 F。

5 实验

5.1 概述

我们评估鞅一致 SSL 框架，检验在已观测信息量变化时，强制条件协调性是否带来更可靠的表示。下游鲁棒性通过不同观测完整度下的探针准确率衡量。

实验沿两个主要维度组织。首先，区分半自监督设置与完全自监督设置：前者以类别标签定义预测项，后者的主要训练信号基于重建，即不使用标签。其次，我们跨多种模态评估方法：先考察时间序列数据，右删失为鞅提供了最清楚的具体图景，因为观测到更长前缀直接对应信息的细化。然后转向更复杂的时间缺失模式，以及表格和图像数据中的特征显露；它们实现同样的嵌套信息关系 $\mathcal{F}_1 \subseteq \mathcal{F}_2$，而不要求严格的序列解释。这说明该框架不局限于时间数据，也可扩展到信息不断演变或仅部分可用的其他模态。最后，附录 D 报告在 TCGA 多组学生存研究中的补充应用。

5.2 基线与模型消融

相对于图 2 的基础 SSL 架构，最简单的基线只保留编码器和预测器，以 $\lambda_{\text{mart}} = \lambda_{\text{imp}} = 0$ 优化底层 SSL 目标（Base）。还考虑非鞅插补基线（Base + imputation），其中包含插补模块及其辅助损失（$\lambda_{\text{imp}} > 0$），但令 $\lambda_{\text{mart}} = 0$。鞅扩展共有第 4 节导出的四种变体：Base + mart. 在预测空间施加鞅惩罚；Base + mart. (EMA) 使用相同预测空间惩罚，但通过预测头的 EMA 副本计算精细目标；Base + mart. (latent) 在潜在空间施加鞅惩罚；Base + mart. (latent, EMA) 将潜在空间正则化与全模型 EMA 目标（编码器和预测头）结合。在完全自监督的静态设置中，还纳入 SimCLR [6] 与 BYOL [10] 的定制表格适配版本；这两个自监督目标最初为图像开发，SimCLR 使用对比目标，BYOL 使用自举目标（表格适配细节见附录 F.6）。我们为它们分别增添潜在空间鞅一致性项，在主目标之外强制跨条件协调性。

5.3 基准族与数据集

实证研究结合三个主要基准族。

时间序列基准。首先研究右删失缺失下的模拟时间序列（T-SIM-RC），其中每个序列只有一个前缀可观测。然后研究结构化时间模拟（T-SIM），其条目可按更丰富的时间模式在不同时间点缺失；最后考察真实时间序列数据集：UCI HAR（HAR）[1]、Traffic（TRAF）[8]、Stock（STK）、Character Trajectories（CT）[24] 和 Spoken Arabic Digits（SAD）[19]。

静态表格基准。还研究模拟静态数据（S-SIM）以及真实表格数据集：Adult（AD）[5]、Bank Marketing（BM）[18]、Credit-g（CG）[14] 和 Phoneme（PH）[11]。这里，部分观测作用于特征而非时间。

图像基准。为了检验同样的条件协调性思想在高维视觉设置中是否仍成立，我们也在中心偏置的块掩码下评估 CIFAR-10 [15] 和 STL-10 [7]；粗视图仅显露图像的一部分。

除右删失时间序列和图像基准之外，训练掩码从在留出的先验拟合划分上推断的先验中抽取，而非直接从目标评估过程采样。这使 SSL 训练与最终留出测试评估分离，同时让模型接触现实的部分观测模式。每个训练批次内，定制训练掩码在 $[0.05,\ 1.0]$ 内随机化已观测信息比例，确保模型在轻度和严重部分观测下均接受训练。附录 E 汇总数据集，附录 E.4 与 F.3 详细说明部分观测过程及其训练时近似。

5.4 结果

主要标量汇总指标是完整度（已观测信息比例） $c \in \{0.05,\ 0.2,\ 0.4,\ 0.6,\ 0.8\}$ 上的平均下游探针准确率。

时间序列基准。表 1 显示鞅正则化在时间序列基准上带来一致的收益。在半自监督设置中，七个数据集上的最佳平均下游准确率均由某个鞅变体取得，相对于 Base，T-SIM-RC（+30.9%）、CT（+155.6%）与 SAD（+37.8%）的相对提升最大。非鞅插补基线有时略有帮助，在 STK 上与最佳鞅变体持平。在完全自监督时间序列设置中，鞅正则化在全部七个数据集上取得最佳结果，T-SIM-RC（+14.6%）、TRAF（+12.6%）和 SAD（+17.3%）上的提升尤其明显。总体上，时间序列实验支持这一结论：强制跨信息协调性可提高历史减少时的鲁棒性。

表 1　时间序列基准上的下游准确率。每个数据集报告完整度 0.05 至 0.8 上的平均下游准确率，数值是五次运行的均值 ± 均值标准误（SEM）。

	T-SIM-RC	T-SIM	HAR	TRAF	STK	CT	SAD
Semi-self-supervised							
Base	$0.320_{\pm 6.5e^{-3}}$	$0.266_{\pm 1.0e^{-2}}$	$0.867_{\pm 4.4e^{-3}}$	$0.859_{\pm 5.5e^{-3}}$	$0.564_{\pm 1.2e^{-2}}$	$0.153_{\pm 1.8e^{-2}}$	$0.291_{\pm 8.4e^{-3}}$
Base (with imputation)	$0.333_{\pm 5.5e^{-3}}$	$0.267_{\pm 1.0e^{-2}}$	$0.867_{\pm 4.2e^{-3}}$	$0.851_{\pm 5.7e^{-3}}$	$\mathbf{0.582}_{\pm 4.7e^{-3}}$	$0.156_{\pm 1.3e^{-2}}$	$0.291_{\pm 9.4e^{-3}}$
Base + mart.	$\mathbf{0.419}_{\pm 2.5e^{-3}}$	$\mathbf{0.315}_{\pm 6.5e^{-3}}$	$0.883_{\pm 2.2e^{-3}}$	$0.824_{\pm 3.0e^{-2}}$	$0.581_{\pm 5.2e^{-3}}$	$0.344_{\pm 1.1e^{-2}}$	$0.387_{\pm 8.6e^{-3}}$
Base + mart. (EMA)	$0.375_{\pm 1.0e^{-2}}$	$0.313_{\pm 3.5e^{-3}}$	$\mathbf{0.888}_{\pm 2.7e^{-3}}$	$\mathbf{0.905}_{\pm 9.7e^{-3}}$	$0.570_{\pm 1.2e^{-2}}$	$\mathbf{0.391}_{\pm 9.9e^{-3}}$	$\mathbf{0.401}_{\pm 2.8e^{-3}}$
Base + mart. (latent)	$0.414_{\pm 2.1e^{-3}}$	$0.312_{\pm 4.1e^{-4}}$	$0.887_{\pm 3.5e^{-3}}$	$0.836_{\pm 2.7e^{-2}}$	$0.581_{\pm 7.9e^{-3}}$	$0.268_{\pm 7.8e^{-3}}$	$0.359_{\pm 4.8e^{-3}}$
Base + mart. (latent, EMA)	$0.399_{\pm 7.5e^{-3}}$	$0.294_{\pm 5.3e^{-3}}$	$0.886_{\pm 1.6e^{-3}}$	$0.849_{\pm 2.5e^{-2}}$	$\mathbf{0.582}_{\pm 4.0e^{-3}}$	$0.296_{\pm 8.2e^{-3}}$	$0.314_{\pm 5.9e^{-3}}$
Rel. gain (vs Base)	+30.9%	+18.4%	+2.4%	+5.4%	+3.2%	+155.6%	+37.8%
Fully self-supervised							
Base	$0.356_{\pm 8.4e^{-3}}$	$0.288_{\pm 3.0e^{-3}}$	$0.751_{\pm 7.6e^{-3}}$	$0.555_{\pm 1.2e^{-2}}$	$0.636_{\pm 7.9e^{-3}}$	$0.137_{\pm 1.2e^{-2}}$	$0.295_{\pm 5.5e^{-3}}$
Base (with imputation)	$0.362_{\pm 8.1e^{-3}}$	$0.291_{\pm 2.8e^{-3}}$	$0.752_{\pm 7.3e^{-3}}$	$0.552_{\pm 1.1e^{-2}}$	$0.637_{\pm 6.3e^{-3}}$	$0.135_{\pm 1.2e^{-2}}$	$0.283_{\pm 6.1e^{-3}}$
Base + mart.	$0.406_{\pm 3.2e^{-3}}$	$0.307_{\pm 1.2e^{-3}}$	$0.753_{\pm 7.3e^{-3}}$	$\mathbf{0.625}_{\pm 6.1e^{-3}}$	$0.637_{\pm 8.5e^{-3}}$	$0.133_{\pm 1.1e^{-2}}$	$0.283_{\pm 6.6e^{-3}}$
Base + mart. (EMA)	$0.404_{\pm 2.5e^{-4}}$	$0.308_{\pm 6.2e^{-4}}$	$0.752_{\pm 7.8e^{-3}}$	$0.604_{\pm 2.1e^{-2}}$	$0.648_{\pm 0}$	$\mathbf{0.175}_{\pm 9.6e^{-3}}$	$0.249_{\pm 1.2e^{-2}}$
Base + mart. (latent)	$0.406_{\pm 9.4e^{-4}}$	$0.307_{\pm 5.8e^{-4}}$	$0.746_{\pm 7.3e^{-3}}$	$0.584_{\pm 9.7e^{-3}}$	$0.636_{\pm 6.9e^{-3}}$	$0.137_{\pm 1.3e^{-2}}$	$0.305_{\pm 3.4e^{-3}}$
Base + mart. (latent, EMA)	$\mathbf{0.408}_{\pm 2.3e^{-3}}$	$\mathbf{0.310}_{\pm 2.5e^{-5}}$	$\mathbf{0.754}_{\pm 7.0e^{-3}}$	$0.556_{\pm 8.9e^{-3}}$	$\mathbf{0.650}_{\pm 1.4e^{-2}}$	$0.139_{\pm 1.3e^{-2}}$	$\mathbf{0.346}_{\pm 6.6e^{-3}}$
Rel. gain (vs Base)	+14.6%	+7.6%	+0.4%	+12.6%	+2.2%	+27.7%	+17.3%

表内术语：Semi-self-supervised＝半自监督；Fully self-supervised＝完全自监督；Base＝基础模型；with imputation＝含插补；mart.＝鞅正则化；latent＝潜在空间；EMA＝指数移动平均；Rel. gain (vs Base)＝相对基础模型的提升。原表的全部数值、强调标记及比较顺序均予保留。

静态表格基准。表 2 汇总特征级缺失下的五个静态表格基准。在半自监督部分，每个数据集的最高平均准确率均由某个鞅变体取得，相对 Base 最大的提升出现在 S-SIM（+34.1%）和 BM（+10.0%）。在完全自监督部分，Base + martingale 变体在全部五个数据集上优于纯 Base；相对提升较半自监督设置小，但全部为正。对于表格 SimCLR 和 BYOL，鞅正则化相对于原始目标改善下游准确率，表明附加约束捕捉了 SimCLR 和 BYOL 未捕捉的信息。仅插补训练在某些数据集上的预测表现仍具有竞争力，但可能产生较大的鞅一致性违背（图 3）。

表 2　静态表格基准上的下游准确率。每个数据集报告完整度 0.05 至 0.8 上的平均下游准确率，数值是五次运行的均值 ± SEM。

	S-SIM	AD	BM	CG	PH
			Semi-self-supervised		
Base	$0.328_{\pm 5.4e^{-3}}$	$0.786_{\pm 1.5e^{-2}}$	$0.814_{\pm 3.4e^{-2}}$	$0.701_{\pm 8.4e^{-3}}$	$0.735_{\pm 6.2e^{-3}}$
Base (with imputation)	$0.368_{\pm 9.9e^{-3}}$	$0.784_{\pm 1.7e^{-2}}$	$0.823_{\pm 3.4e^{-2}}$	$0.690_{\pm 9.9e^{-3}}$	$0.746_{\pm 2.1e^{-3}}$
Base + mart.	$0.423_{\pm 4.4e^{-3}}$	$\mathbf{0.810}_{\pm 7.2e^{-4}}$	$\mathbf{0.895}_{\pm 2.5e^{-4}}$	$0.716_{\pm 8.1e^{-3}}$	$0.752_{\pm 1.9e^{-3}}$
Base + mart. (EMA)	$0.432_{\pm 3.3e^{-3}}$	$0.809_{\pm 6.6e^{-4}}$	$0.894_{\pm 1.8e^{-4}}$	$0.692_{\pm 8.3e^{-3}}$	$0.753_{\pm 2.2e^{-3}}$
Base + mart. (latent)	$0.431_{\pm 3.3e^{-3}}$	$0.807_{\pm 4.6e^{-4}}$	$0.891_{\pm 4.3e^{-4}}$	$0.720_{\pm 6.9e^{-3}}$	$\mathbf{0.755}_{\pm 2.1e^{-3}}$
Base + mart. (latent, EMA)	$\mathbf{0.440}_{\pm 2.0e^{-3}}$	$0.790_{\pm 1.7e^{-2}}$	$0.892_{\pm 1.7e^{-3}}$	$\mathbf{0.724}_{\pm 5.3e^{-3}}$	$0.749_{\pm 4.1e^{-3}}$
Rel. gain (vs Base)	+34.1%	+3.1%	+10.0%	+3.3%	+2.7%
			Fully self-supervised		
Base	$0.411_{\pm 1.9e^{-3}}$	$0.787_{\pm 8.2e^{-4}}$	$0.888_{\pm 6.0e^{-4}}$	$0.724_{\pm 8.8e^{-4}}$	$0.720_{\pm 1.5e^{-3}}$
Base (with imputation)	$0.410_{\pm 3.0e^{-3}}$	$0.789_{\pm 7.3e^{-4}}$	$0.887_{\pm 9.8e^{-4}}$	$0.721_{\pm 1.9e^{-3}}$	$0.733_{\pm 2.6e^{-3}}$
Base + mart.	$0.410_{\pm 3.5e^{-3}}$	$\mathbf{0.799}_{\pm 7.3e^{-4}}$	$\mathbf{0.889}_{\pm 1.7e^{-4}}$	$\mathbf{0.725}_{\pm 1.1e^{-3}}$	$\mathbf{0.734}_{\pm 2.5e^{-3}}$
Base + mart. (EMA)	$0.413_{\pm 1.1e^{-3}}$	$0.796_{\pm 9.9e^{-4}}$	$0.888_{\pm 3.3e^{-4}}$	$\mathbf{0.725}_{\pm 1.1e^{-3}}$	$0.733_{\pm 2.2e^{-3}}$
Base + mart. (latent)	$0.421_{\pm 4.4e^{-3}}$	$0.797_{\pm 9.9e^{-4}}$	$\mathbf{0.889}_{\pm 1.6e^{-4}}$	$0.722_{\pm 3.0e^{-3}}$	$0.725_{\pm 2.5e^{-3}}$
Base + mart. (latent, EMA)	$\mathbf{0.432}_{\pm 1.4e^{-3}}$	$0.797_{\pm 2.5e^{-4}}$	$0.886_{\pm 3.1e^{-4}}$	$0.723_{\pm 0}$	$0.720_{\pm 9.7e^{-4}}$
Rel. gain (vs Base)	+5.1%	+1.5%	+0.1%	+0.1%	+1.9%
SimCLR	$0.390_{\pm 8.5e^{-3}}$	$0.785_{\pm 1.8e^{-3}}$	$0.884_{\pm 3.0e^{-4}}$	$0.622_{\pm 4.9e^{-2}}$	$0.716_{\pm 3.9e^{-3}}$
SimCLR (imputation only)	$\mathbf{0.414}_{\pm 2.4e^{-3}}$	$0.794_{\pm 1.9e^{-3}}$	$\mathbf{0.885}_{\pm 5.4e^{-4}}$	$0.691_{\pm 2.4e^{-3}}$	$\mathbf{0.724}_{\pm 3.4e^{-3}}$
SimCLR + mart. (latent)	$\mathbf{0.414}_{\pm 3.2e^{-3}}$	$\mathbf{0.800}_{\pm 6.0e^{-4}}$	$0.884_{\pm 5.5e^{-4}}$	$\mathbf{0.720}_{\pm 2.7e^{-4}}$	$0.713_{\pm 2.6e^{-3}}$
Rel. gain (vs vanilla SimCLR)	+6.2%	+1.9%	+0.0%	+15.8%	-0.4%
BYOL	$0.296_{\pm 1.7e^{-2}}$	$0.660_{\pm 4.4e^{-2}}$	$0.723_{\pm 5.6e^{-2}}$	$0.661_{\pm 3.5e^{-2}}$	$0.665_{\pm 2.2e^{-2}}$
BYOL (imputation only)	$0.393_{\pm 9.2e^{-3}}$	$0.795_{\pm 2.4e^{-3}}$	$0.865_{\pm 5.7e^{-3}}$	$0.694_{\pm 1.9e^{-3}}$	$\mathbf{0.746}_{\pm 2.4e^{-3}}$
BYOL + mart. (latent)	$\mathbf{0.411}_{\pm 3.0e^{-3}}$	$\mathbf{0.798}_{\pm 8.6e^{-4}}$	$\mathbf{0.883}_{\pm 5.0e^{-5}}$	$\mathbf{0.719}_{\pm 4.6e^{-3}}$	$0.734_{\pm 1.8e^{-3}}$
Rel. gain (vs vanilla BYOL)	+38.9%	+20.9%	+22.1%	+8.8%	+10.4%

表内术语同表 1；imputation only＝仅插补；Rel. gain (vs vanilla SimCLR/BYOL)＝相对于原始 SimCLR／BYOL 的提升。

鲁棒性曲线与鞅违背。图 3 以模拟基准的鲁棒性曲线，以及随完整度变化的预测空间与潜在空间鞅违背，对表格作出补充。对每个完整度水平 c，我们定义

$$\widehat{V}_{\text{pred}}(c) := \frac{1}{Nd_g}\sum_{i=1}^{N}\left\| u_i(c) - \frac{1}{K}\sum_{k=1}^{K} v_i^{(k)}(c)\right\|_2^2,$$

$$\widehat{V}_{\text{lat}}(c) := \frac{1}{Nd_z}\sum_{i=1}^{N}(z_i(c) - z_i^{(a)}(c))^{\top}(z_i(c) - z_i^{(b)}(c)).$$

其中 $u_i(c)$ 是粗视图预测，$v_i^{(k)}(c)$ 是精细预测，$z_i^{(a)}(c), z_i^{(b)}(c)$ 是两个独立细化的潜在表示。在模拟数据上，可以将预测空间违背直接与已知数据生成过程所诱导的真实条件期望（以蒙特卡洛采样近似）比较；潜在空间中不存在类似的总体量，而是将插补器产生的两个独立随机补全输入编码器，再测量表示不匹配来估计违背。曲线表明，收益始终集中在低完整度区间，恰好是信息细化下的预测协调性最关键之处；鞅目标也常常降低两个空间中的违背。这是合理的，因为编码器与预测头相互耦合：对输出正则化可以稳定表示，对表示正则化则可以传递到下游预测。预测空间正则化更直接作用于任务输出，潜在空间正则化更直接作用于下游探针所使用的表示几何，但在所报告基准中，没有任何一种始终最优。此外，控制完整度增加的一般影响后，较低鞅违背与较好下游鲁棒性仍有系统关联，表现为负的 Spearman 相关；附录 B.3 给出理论解释。

信息变化下的校准。图 3B 展示时间半自监督基准的校准诊断。可用信息减少时，任时遗憾（相对于完整信息的准确率损失）、期望校准误差（ECE）和负对数似然（NLL）通常都会恶化，但 Base 的恶化程度远大于鞅一致训练。在 $c \in \{0.05,\ 0.2,\ 0.4,\ 0.6,\ 0.8\}$ 上，Base 的平均任时遗憾约为 0.39，而 Base + mart. (latent) 约为 0.02。在部分观测下，Base 的平均 ECE 约为 0.26，而 Base + mart. (latent) 约为 0.04；相对于完整视图，平均 NLL 增量分别约为 1.09 和 0.09。这支持条件期望族视角：训练时强制跨视图协调性，会改善部分观测下的校准。

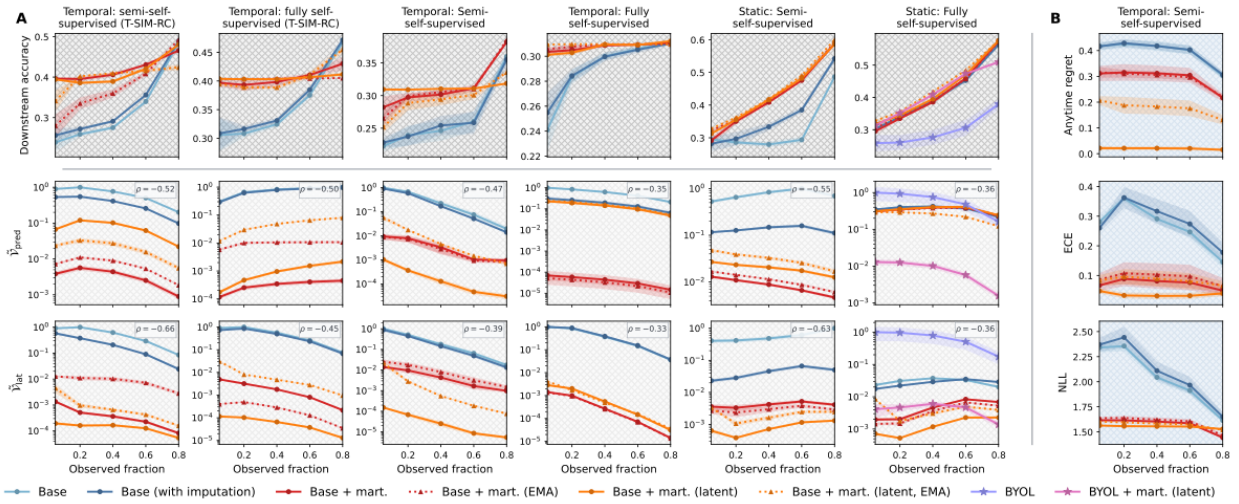


图 3。(A) 模拟基准在缺失情况下的鲁棒性。各行展示下游探针准确率、预测空间违背、潜在空间违背与完整度的关系；违背按列归一化。插图显示经过完整度调整后的下游准确率与对数违背之间的 Spearman 关联。(B) 右删失半自监督设置的校准诊断：任时遗憾（相对完整信息的准确率损失）、ECE 和 NLL。图内：Temporal＝时间序列；Static＝静态；Downstream accuracy＝下游准确率；Observed fraction＝观测比例；Anytime regret＝任时遗憾；其余模型名同表 1。下列分区为同一原图的放大裁切，便于阅读，不增加新结果。

图 3A 放大 前三列 时间序列结果（原图裁切，图例见全图）

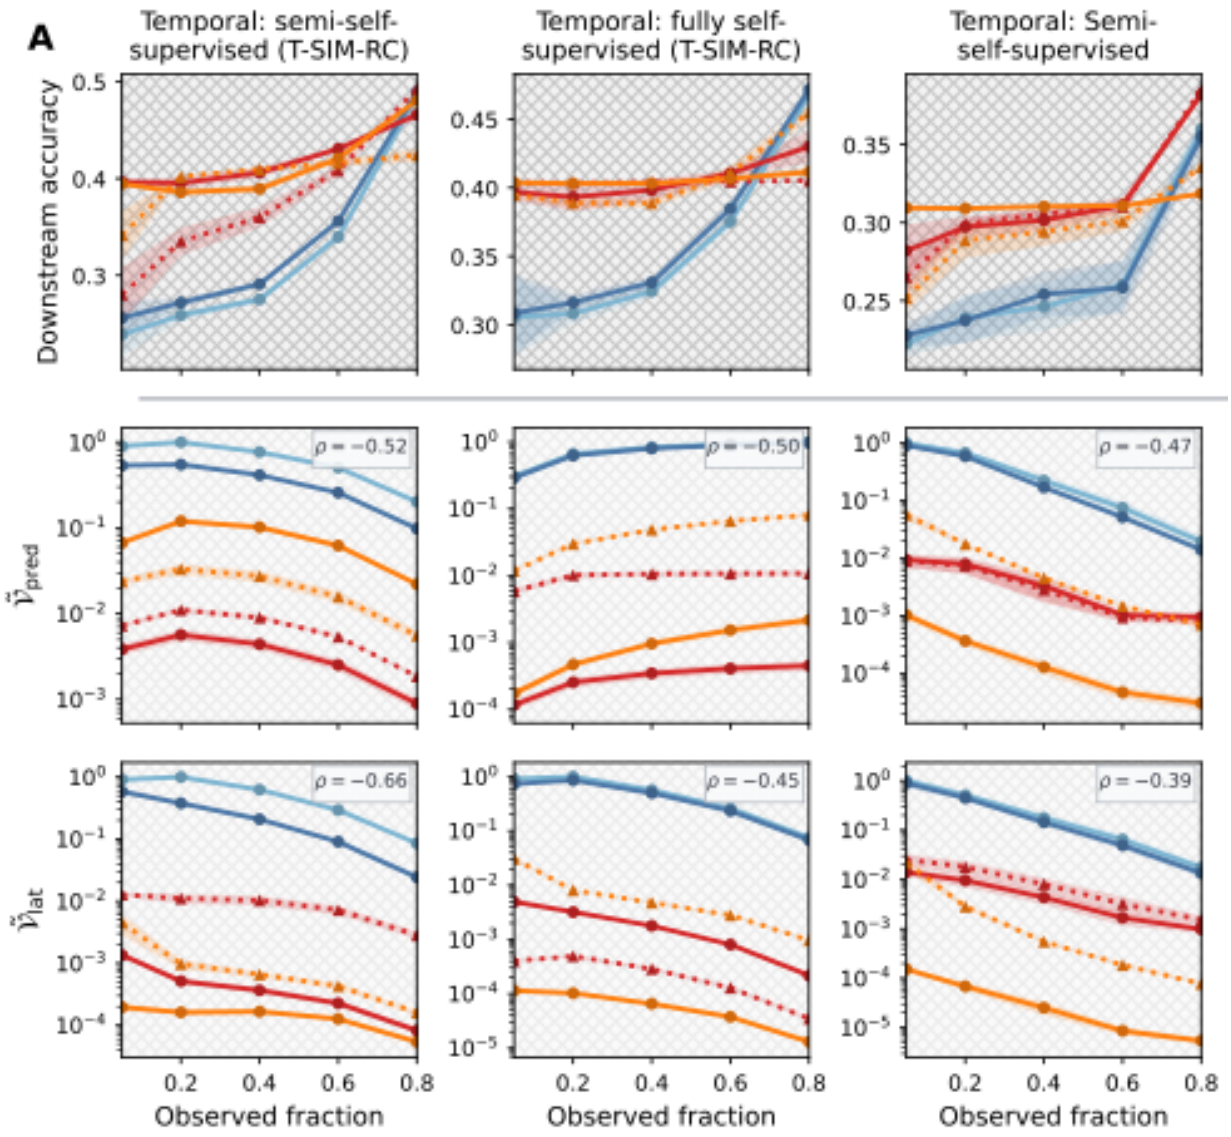


图 3A 放大 后三列 时间序列与静态结果（原图裁切，图例见全图）

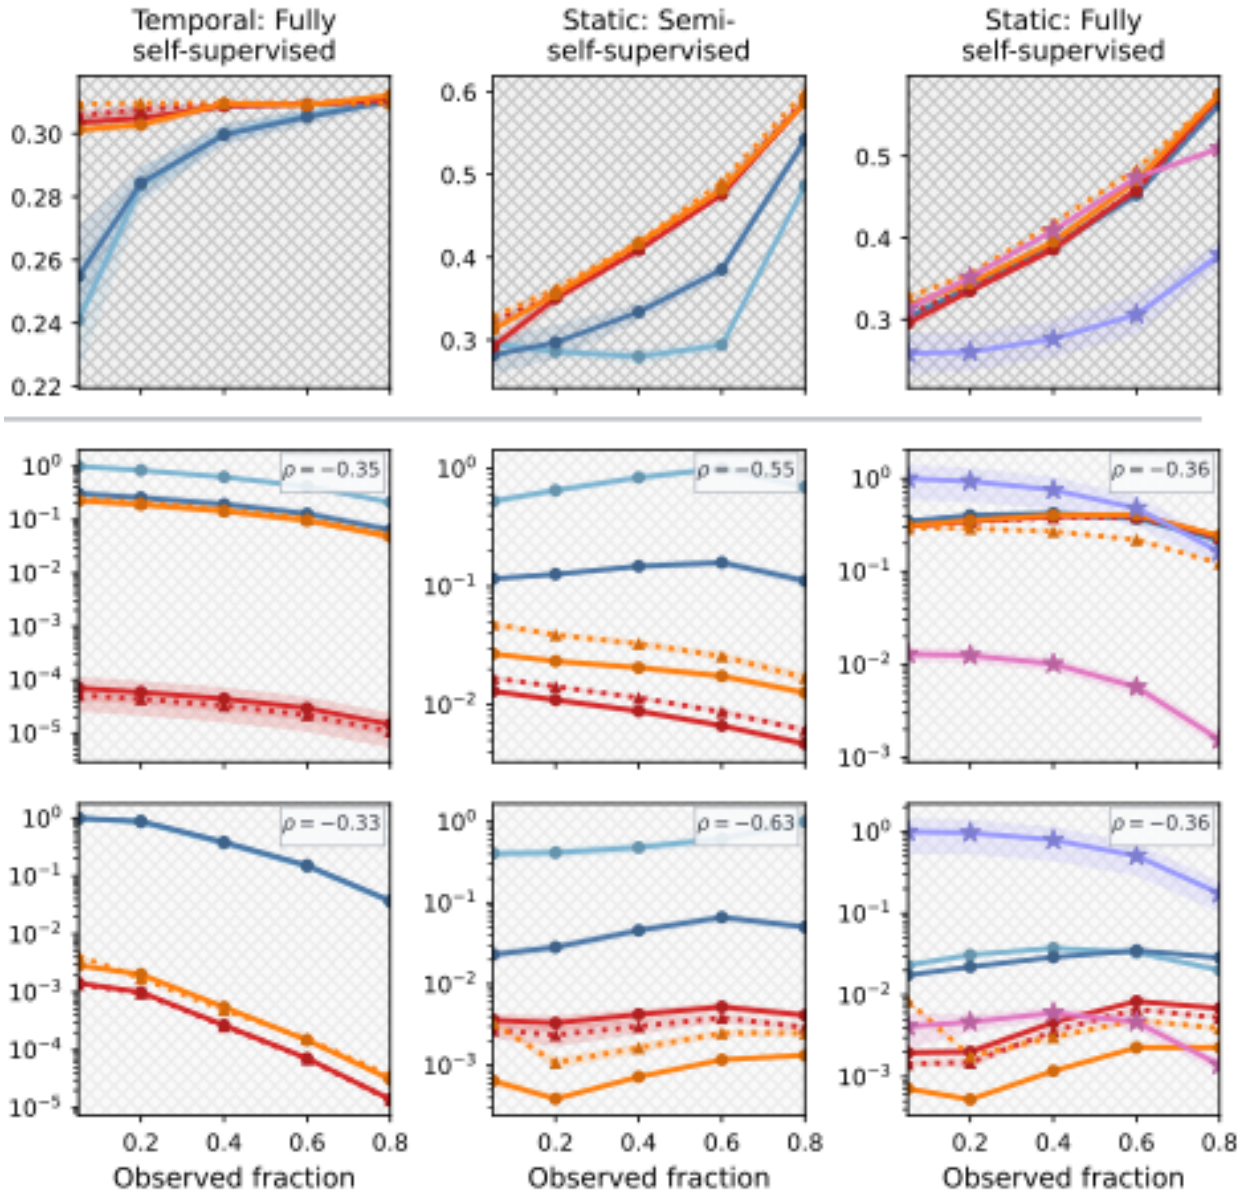
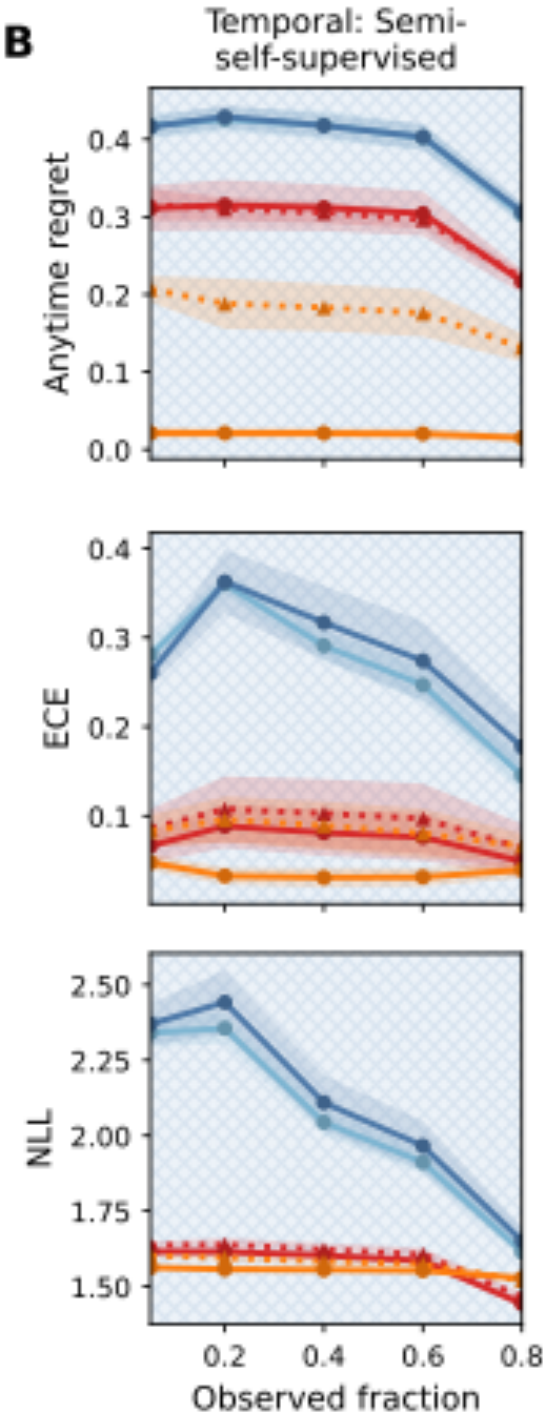
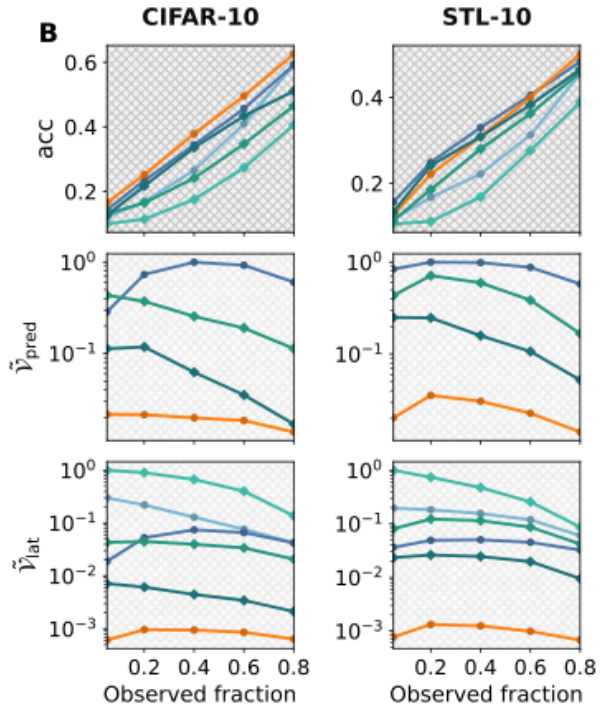


图 3B 放大 校准诊断（原图裁切，图例见全图）





	CIFAR-10	STL-10
Semi-self-supervised		
Base	0.311	0.255
Base (with imp.)	0.353	**0.324**
Base + mart. (latent)	**0.383**	0.311
Rel. gain (vs Base)	+23.2%	+22.0%
Fully self-supervised		
SimCLR	0.213	0.210
SimCLR (with imp.)	0.269	0.280
SimCLR+mart. (latent)	**0.324**	**0.306**
Rel. gain (vs SimCLR)	+52.1%	+45.7%



图 4　完整原图图注的中文翻译。(A) 采用中心偏置掩码的 CIFAR-10 部分观测可视化。(B) CIFAR-10 和 STL-10 上，各方法的平均下游准确率，以及归一化后的预测空间、潜在空间鞅违背曲线，并附所报告平均准确率的简表。**译者说明：本译文仅呈现 B 面板；A 面板的第三方 CIFAR 示例照片因再分发权限未确立而省略。原始 A 面板见原文第 9 页**。图内：acc＝准确率；pred／lat＝预测／潜在空间违背；Observed fraction＝观测比例；Semi-self-supervised＝半自监督；Fully self-supervised＝完全自监督；Rel. gain＝相对提升；模型名同表 1。

图像基准。图 4 将部分观测设置扩展到中心偏置块掩码下的 CIFAR-10 与 STL-10。在 CIFAR-10 的半自监督图像设置中，潜在鞅正则化将平均下游准确率从 0.311 提高到 0.383（较基础模型提升 23.2%，较含插补的基础模型提升 8.5%），同时降低预测空间与潜在空间的鞅违背。CIFAR-10 SimCLR 也出现相同模式：鞅变体将平均准确率从 0.213 提高到 0.324（较 SimCLR 提升 52.1%，较含插补的 SimCLR 提升 20.4%），并降低两种违背。在 STL-10 中，半自监督鞅变体相对基础模型将准确率从 0.255 提高到 0.311（+22.0%），不过非鞅插补基线达到 0.324。对于 STL-10 SimCLR，鞅正则化将平均准确率从 0.210 提高到 0.306（较 SimCLR 提升 45.7%，较含插补的 SimCLR 提升 9.3%），并降低两个空间的违背。这表明协调性约束在更高维的视觉设置中仍有作用。附录 C 提供包括敏感性分析在内的补充实验结果。

6 讨论

本研究将鞅一致性引入为部分信息条件下自监督学习的协调性约束。所提目标不强制跨视图不变性，而是强制信息细化下期望上的一致，允许预测随新信息揭示而更新，同时避免系统性漂移。这为部署在不同掩码模式、上下文长度或观测条件下的 SSL 模型提供了概率视角。

实证上，鞅正则化在时间序列、表格和图像基准上持续改善部分观测下的鲁棒性及校准，其中也包括基于对比和自举的目标。收益在低信息条件下最强，因为嵌套信息集之间的协调更新在此最为关键。此外，改进经常伴随鞅违背减少，说明细化下的协调性捕捉到标准 SSL 目标中缺失的一种有用结构先验。

本框架通过预测空间或潜在空间惩罚，以及基于随机细化的无偏双样本估计器，可简洁地整合进现有 SSL 流程。同时仍存在若干局限：该方法依赖于用来近似条件期望的细化机制质量；鞅目标与架构、模型规模之间的相互作用值得进一步研究。更高效或自适应的细化分布构建策略，也可能提高大规模设置下的可扩展性。

一个尤其有前景的方向是基础模型预训练：同一个模型通常在不同上下文长度、掩码模式或不完整观测下接受查询。因此，这些系统被隐含地要求在信息变化时产生协调更新，但现有目标并不显式强制这一性质。我们认为，鞅一致性是填补这一缺口的有原则的方法。

致谢

MG 获 EPSRC 健康数据科学博士培养中心（EP/S02428X/1）资助。CY 获 UKRI 图灵人工智能加速研究员项目（EP/V023233/2）资助。附录所展示的结果部分基于 TCGA 研究网络生成的数据：TCGA。

参考文献

以下保留作者、来源、卷期页码、标识符及原文链接，并将文献题名译为中文；原英文题名同时保留，便于检索。原文大小写、作者署名或书目信息中的不规则之处不擅自校正。

[1] D. Anguita, A. Ghio, L. Oneto, X. Parra, J. Reyes. 用于智能手机人体活动识别的公共领域数据集（A public domain dataset for human activity recognition using smartphones）. Proceedings of the 21th International European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning, 437–442, Bruges, 2013. ISBN 978-2-87419-081-0. 链接.

[2] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, Nicolas Ballas. 利用联合嵌入预测架构从图像进行自监督学习（Self-supervised learning from images with a joint-embedding predictive architecture）. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 15619–15629. IEEE, 2023. DOI: 10.1109/cvpr52729.2023.01499. 链接.

[3] Dara Bahri, Heinrich Jiang, Yi Tay, Donald Metzler. SCARF：使用随机特征扰动的自监督对比学习（Scarf: Self-supervised contrastive learning using random feature corruption）. International Conference on Learning Representations, 2022. 链接.

[4] Adrien Bardes, Jean Ponce, Yann LeCun. VICReg：用于自监督学习的方差、不变性和协方差正则化（VICReg: Variance-invariance-covariance regularization for self-supervised learning）. International Conference on Learning Representations, 2022. 链接.

[5] Barry Becker, Ronny Kohavi. Adult（成人数据集）, 1996. 链接.

[6] Ting Chen, Simon Kornblith, Mohammad Norouzi, Geoffrey Hinton. 视觉表示对比学习的简单框架（A simple framework for contrastive learning of visual representations）. 载 Hal Daumé III, Aarti Singh（编）, Proceedings of the 37th International Conference on Machine Learning, Proceedings of Machine Learning Research 119:1597–1607. PMLR, 2020 年 7 月 13–18 日。

[7] Adam Coates, Andrew Ng, Honglak Lee. 无监督特征学习中的单层网络分析（An analysis of single-layer networks in unsupervised feature learning）. 载 Geoffrey Gordon, David Dunson, Miroslav Dudík（编）, Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, Proceedings of Machine Learning Research 15:215–223, Fort Lauderdale, FL, USA, 2011 年 4 月 11–13 日. PMLR. 链接.

[8] Marco Cuturi. 快速全局对齐核（Fast global alignment kernels）. 载 Lise Getoor, Tobias Scheffer（编）, Proceedings of the 28th International Conference on Machine Learning (ICML-11), ICML ’11, 929–936, New York, NY, USA, 2011 年 6 月. ACM. ISBN 978-1-4503-0619-5.

[9] Jiaxiang Dong, Haixu Wu, Haoran Zhang, Li Zhang, Jianmin Wang, Mingsheng Long. SimMTM：掩码时间序列建模的简单预训练框架（Simmtm: A simple pre-training framework for masked time-series modeling）. 载 A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, S. Levine（编）, Advances in Neural Information Processing Systems 36:29996–30025. Curran Associates, Inc., 2023. 链接.

[10] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Guo, Mohammad Gheshlaghi Azar, Bilal Piot, koray kavukcuoglu, Remi Munos, Michal Valko. 自举你自己的潜在表示：自监督学习的新方法（Bootstrap your own latent - a new approach to self-supervised learning）. 载 H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, H. Lin（编）, Advances in Neural Information Processing Systems 33:21271–21284. Curran Associates, Inc., 2020. 链接.

[11] Trevor Hastie, Andreas Buja, Robert Tibshirani. 惩罚判别分析（Penalized discriminant analysis）. The Annals of Statistics, 23(1), 1995 年 2 月. ISSN 0090-5364. DOI: 10.1214/aos/1176324456. 链接.

[12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. 用于图像识别的深度残差学习（Deep residual learning for image recognition）. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778. IEEE, 2016. DOI: 10.1109/cvpr.2016.90. 链接.

[13] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollar, Ross Girshick. 掩码自编码器是可扩展的视觉学习器（Masked autoencoders are scalable vision learners）. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 15979–15988. IEEE, 2022. DOI: 10.1109/cvpr52688.2022.01553. 链接.

[14] Hans Hofmann. Statlog（德国信用数据）（Statlog (german credit data)）, 1994. 链接.

[15] Alex Krizhevsky, Geoffrey Hinton. 从微小图像中学习多层特征（Learning multiple layers of features from tiny images）. Technical Report 0, University of Toronto, Toronto, Ontario, 2009. 链接.

[16] Zhe Li, Zhongwen Rao, Lujia Pan, Pengyun Wang, Zenglin Xu. Ti-MAE：自监督掩码时间序列自编码器（Ti-mae: Self-supervised masked time series autoencoders）, 2023. 链接.

[17] Ilya Loshchilov, Frank Hutter. 解耦权重衰减正则化（Decoupled weight decay regularization）. International Conference on Learning Representations, 2019. 链接.

[18] Sérgio Moro, Paulo Cortez, Paulo Rita. 预测银行电话营销成功率的数据驱动方法（A data-driven approach to predict the success of bank telemarketing）. Decision Support Systems, 62:22–31, 2014. ISSN 0167-9236. DOI: 10.1016/j.dss.2014.03.001. 链接.

[19] Nacereddine Hammami Mouldi Bedda. 阿拉伯语口语数字（Spoken arabic digit）, 2008. 链接.

[20] Aaron van den Oord, Yazhe Li, Oriol Vinyals. 利用对比预测编码进行表示学习（Representation learning with contrastive predictive coding）, 2018. 链接.

[21] Sebastian Pölsterl. scikit-survival：基于 scikit-learn 构建的事件发生时间分析库（scikit-survival: A library for time-to-event analysis built on top of scikit-learn）. Journal of Machine Learning Research, 21(212):1–6, 2020. 链接.

[22] Talip Ucar, Ehsan Hajiramezanali, Lindsay Edwards. SubTab：通过表格数据特征子集进行自监督表示学习（Subtab: Subsetting features of tabular data for self-supervised representation learning）. 载 M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, J. Wortman Vaughan（编）, Advances in Neural Information Processing Systems 34:18853–18865. Curran Associates, Inc., 2021. 链接.

[23] Tobias Uelwer, Jan Robine, Stefan Sylvius Wagner, Marc Höftmann, Eric Upschulte, Sebastian Konietzny, Maike Behrendt, Stefan Harmeling. 视觉表示学习的自监督方法综述（A survey on self-supervised methods for visual representation learning）. Machine Learning, 114(4), 2025 年 3 月. ISSN 1573-0565. DOI: 10.1007/s10994-024-06708-7. 链接.

[24] Ben H. Williams, Marc Toussaint, Amos J. Storkey. 从自然手写数据中提取运动基元（Extracting motion primitives from natural handwriting data）. 载 Stefanos Kollias, Andreas Stafylopatis, Włodzisław Duch, Erkki Oja（编）, Artificial Neural Networks – ICANN 2006, 634–643, Berlin, Heidelberg, 2006. Springer Berlin Heidelberg. ISBN 978-3-540-38873-9.

[25] David Williams. 鞅概率论（Probability with Martingales）. Cambridge University Press, 1991.

[26] Hanwen Xing, Christopher Yau. MIND：使用邻域感知分布进行多模态整合（Mind: Multimodal integration with neighbourhood-aware distributions）. 2025. DOI: 10.1101/2025.09.15.676314. 链接.

[27] Jinsung Yoon, Yao Zhang, James Jordon, Mihaela van der Schaar. VIME：将自监督与半监督学习的成功扩展到表格领域（Vime: Extending the success of self- and semi-supervised learning to tabular domain）. 载 H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, H. Lin（编）, Advances in Neural Information Processing Systems 33:11033–11043. Curran Associates, Inc., 2020. 链接.

[28] Zhihan Yue, Yujing Wang, Juanyong Duan, Tianmeng Yang, Congrui Huang, Yunhai Tong, Bixiong Xu. TS2Vec：迈向通用时间序列表示（Ts2vec: Towards universal representation of time series）. Proceedings of the AAAI Conference on Artificial Intelligence, 36(8):8980–8987, 2022. ISSN 2159-5399. DOI: 10.1609/aaai.v36i8.20881. 链接.

附录

A 影响声明

本文引入一种训练自监督模型的框架，使模型在信息逐步揭示时产生协调一致的预测。通过提高部分观测下的鲁棒性与校准，本研究有望支持在数据逐渐或不均匀到达的情境下实现更可靠的下游应用，包括临床风险评估、流式分析和预算约束的数据获取。尽管所得预测能够为这些领域的决策提供信息，但它们应当补充而不是替代专家判断、常规不确定性量化，以及针对部署中具体数据生成过程的验证。从这一意义上说，伦理考量包括透明披露该方法已在哪些缺失条件下得到验证，因为更强的基准鲁棒性可能促使人们将其用于与训练时有本质差异的部署缺失模式。在随机化部分观测条件下训练的一个优点是降低对任何单一观测模式的敏感性，从而在异质数据收集环境中获得更好的泛化。然而，与所有针对部分信息条件的方法一样，仍须谨慎确保不同人群公平获益，因为现实数据中的缺失很少均匀分布，而且可能与敏感属性相关。本研究主要旨在改善自监督表示的协调性性质，尚无可预见的直接社会危害。

B 理论补充

B.1 双样本鞅损失估计器无偏性的证明

我们证明，双样本蒙特卡洛估计器 $\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}}$ 是条件平方误差 $\| u - \mathbb{E}\left[g_\phi\left(X_{\mathcal{F}_2}\right) \mid x_{\mathcal{F}_1}\right] \|^2$ 的无偏估计器。

证明。固定 $x_{\mathcal{F}_1}$，记 $\mu := \mathbb{E}\left[g_\phi\left(X_{\mathcal{F}_2}\right) \mid x_{\mathcal{F}_1}\right]$。假设给定 $x_{\mathcal{F}_1}$ 时，v_a 与 v_b 条件独立地抽取，且所有向量均有有限二阶矩。展开 $(u - v_a)^\top (u - v_b)$，得到 $\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}} = u^\top u - u^\top v_b - v_a^\top u + v_a^\top v_b$。给定 $x_{\mathcal{F}_1}$ 取条件期望，并利用线性性、条件独立性以及 $\mathbb{E}\left[v_a \mid x_{\mathcal{F}_1}\right] = \mathbb{E}\left[v_b \mid x_{\mathcal{F}_1}\right] = \mu$，可得

$$
\begin{aligned}
\mathbb{E}\left[\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart}} \mid x_{\mathcal{F}_1}\right] &= u^\top u - u^\top \mathbb{E}\left[v_b \mid x_{\mathcal{F}_1}\right] \\
&\quad - \mathbb{E}\left[v_a \mid x_{\mathcal{F}_1}\right]^\top u + \mathbb{E}\left[v_a^\top v_b \mid x_{\mathcal{F}_1}\right] \\
&= \| u \|^2 - u^\top \mu - \mu^\top u + \mathbb{E}\left[v_a \mid x_{\mathcal{F}_1}\right]^\top \mathbb{E}\left[v_b \mid x_{\mathcal{F}_1}\right] \\
&= \| u \|^2 - 2u^\top \mu + \| \mu \|^2 \\
&= \| u - \mu \|^2 .
\end{aligned}
$$

B.2 推广到非嵌套信息集

所报告实验并未使用非嵌套训练。在全部所报告实验中，粗视图仅部分可观测，而精细视图始终是完整输入，因此整个实证流程始终嵌套。这是信息逐步揭示类基准最自然的设置，也是所有训练与评估流程采用的设置。

不过，同样的协调性视角提示了一种超越嵌套信息结构的自然扩展。如果 $\mathcal{F}_1$ 和 $\mathcal{F}_2$ 之间没有包含顺序，但有部分重叠，则定义

$$\mathcal{F}_\cap := \mathcal{F}_1 \cap \mathcal{F}_2. \qquad (12)$$

记

$$m_{\mathcal{F}} := \mathbb{E}[Y \mid \mathcal{F}], \qquad (13)$$

相应的总体一致性关系为

$$\mathbb{E}\left[m_{\mathcal{F}_1} \mid \mathcal{F}_\cap\right] = \mathbb{E}\left[m_{\mathcal{F}_2} \mid \mathcal{F}_\cap\right]. \qquad (14)$$

根据塔式性质，两边都等于 $\mathbb{E}\left[Y \mid \mathcal{F}_\cap\right]$（因为 $\mathcal{F}_\cap \subseteq \mathcal{F}_i$），所以该恒等式在总体层面成立。这对任意训练后的预测器并不成立，因此它可以在非嵌套情况下充当正则项。当视图嵌套时，$\mathcal{F}_\cap = \mathcal{F}_1$，于是退化为通常的鞅恒等式。

这一扩展最适合具有重叠但不可比较视图的设置，例如异质特征子集或部分重叠的时间窗口。它与本文部分观测实验的相关性较低，因为这些基准明确将问题表述为从部分视图细化到完整观测。

B.3 鞅违背下的超额风险界

以下结果将第 5 节报告的经验关联形式化：粗粒度的超额风险可分解为鞅违背和细粒度误差，从而为较低违背为何关联于更好鲁棒性提供理论解释。

命题 1（超额风险分解）。设 $\mathcal{F}_1 \subseteq \mathcal{F}_2$，$g_\phi$ 是任意具有有限二阶矩的预测器。定义细粒度超额风险

$$R\left(\mathcal{F}_2;\, g_\phi\right) := \mathbb{E}\left[\, \| \, g_\phi\left(x_{\mathcal{F}_2}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_2\right] \| \, ^2\right]$$

以及鞅违背

$$V\left(g_\phi\right) := \mathbb{E}\left[\, \| \, g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[g_\phi\left(x_{\mathcal{F}_2}\right) \mid \mathcal{F}_1\right] \| \, ^2\right].$$

则

$$\mathbb{E}\left[\, \| \, g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_1\right] \| \, ^2\right] \le 2V\left(g_\phi\right) + 2R\left(\mathcal{F}_2;\, g_\phi\right). \qquad (15)$$

证明。根据塔式性质，$\mathbb{E}\left[\mathbb{E}\left[Y \mid \mathcal{F}_2\right] \mid \mathcal{F}_1\right] = \mathbb{E}\left[Y \mid \mathcal{F}_1\right]$。作如下分解：

$$g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_1\right] = \underbrace{\left(g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[g_\phi\left(x_{\mathcal{F}_2}\right) \mid \mathcal{F}_1\right]\right)}_{A} + \underbrace{\mathbb{E}\left[g_\phi\left(x_{\mathcal{F}_2}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_2\right] \mid \mathcal{F}_1\right]}_{B}.$$

应用 $\| a+b \|^2 \le 2\| a \|^2 + 2\| b \|^2$ 并取期望，有 $\mathbb{E}\left[\| A \|^2 \right] = V\left(g_\phi\right)$。对于 B 项，由 Jensen 不等式，$\| B \|^2 \le \mathbb{E}\left[\| g_\phi\left(x_{\mathcal{F}_2}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_2\right] \|^2 \mid \mathcal{F}_1 \right]$；再根据塔式性质，它的期望等于 $R\left(\mathcal{F}_2;\, g_\phi\right)$。

当模型很好地拟合精细视图（$R\left(\mathcal{F}_2;\, g_\phi\right)$ 较小）时，降低 $V\left(g_\phi\right)$ 是改善粗粒度准确率的关键途径。在极限情形 $R\left(\mathcal{F}_2;\, g_\phi\right) = 0$ 下，该界简化为 $\mathbb{E}\left[\| g_\phi\left(x_{\mathcal{F}_1}\right) - \mathbb{E}\left[Y \mid \mathcal{F}_1\right] \|^2 \right] \le 2V\left(g_\phi\right)$。

B.4 线性高斯闭式解

为了给出归纳偏置的几何直觉，我们在线性高斯设置下刻画联合目标的最小化解。

设置。设 $X = \left(X_1^\top,\, X_2^\top\right)^\top \sim \mathcal{N}(0,\, \Sigma)$，其中

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, \qquad Y = w_1^\top X_1 + w_2^\top X_2 + \varepsilon,$$

$\varepsilon \sim \mathcal{N}\left(0,\, \sigma^2\right)$ 且独立。粗视图观测 X_1，精细视图观测完整的 X。对作用于已观测分量的线性预测器 $g_\beta(x) = \beta_1^\top x_1 + \beta_2^\top x_2$，鞅损失简化为 $\mathcal{L}_{\text{mart}}\left(\beta\right) = \beta_2^\top C \beta_2$，其中 $C{:=}\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12} \succcurlyeq 0$。

命题 2（线性高斯最小化解）。令 $\Sigma_{2|1}{:=}\Sigma_{22} - C$。$\mathcal{L}_{\text{pred}}\left(\beta\right) + \lambda \mathcal{L}_{\text{mart}}\left(\beta\right)$ 的唯一最小化解为

$$\begin{aligned} \beta_2^*(\lambda) &= \left(\Sigma_{2|1} + \lambda C\right)^{-1} \Sigma_{2|1} w_2, \\ \beta_1^*(\lambda) &= w_1 + \Sigma_{11}^{-1}\Sigma_{12}\left(w_2 - \beta_2^*(\lambda)\right). \end{aligned} \tag{16}$$

证明。预测损失为 $\left(\beta - w\right)^\top \Sigma \left(\beta - w\right) + \sigma^2$。令 $\nabla_{\beta_1} = 0$，得到 $\beta_1^* = w_1 - \Sigma_{11}^{-1}\Sigma_{12}\left(\beta_2^* - w_2\right)$。代入 $\nabla_{\beta_2} = 0$：交叉项 $2\Sigma_{21}\left(\beta_1^* - w_1\right)$ 变成 $-2\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}\left(\beta_2^* - w_2\right) = -2C\left(\beta_2^* - w_2\right)$，余下

$$-2C\left(\beta_2^* - w_2\right) + 2\Sigma_{22}\left(\beta_2^* - w_2\right) + 2\lambda C \beta_2^* = 0.$$

使用 $\Sigma_{22} - C = \Sigma_{2|1}$，得到 $\left(\Sigma_{2|1} + \lambda C\right)\beta_2^* = \Sigma_{2|1} w_2$。

在 $\lambda = 0$ 时，$\beta^*(0) = w$（普通最小二乘，OLS）。当 $\lambda \to \infty$ 时，$\beta_2^* \to 0$，且 $\beta_1^* \to w_1 + \Sigma_{11}^{-1}\Sigma_{12} w_2$，这恰好是最优粗预测器 $\mathbb{E}\left[Y \mid X_1\right]$ 的系数。对于有限 λ，鞅正则化沿与 X_1 相关性最高的方向（由 C 的特征结构刻画）收缩 β_2^*，并相应调整 β_1^* 作补偿，逐步恢复粗粒度的最优条件期望。

C 补充实验与结果

C.1 Lambda 敏感性研究

为研究超参数敏感性，我们在静态表格基准的 S-SIM 数据集上，分别在半自监督和完全自监督设置中考察 $\left(\lambda_{\text{imp}},\, \lambda_{\text{mart}}\right)$ 的敏感性。结果汇总于图 5。

两种设置中，下游准确率最高的区域总体相似：集中在适度的插补权重（完全自监督设置中 $\lambda_{\text{imp}} \approx 0.1-1$，半自监督设置中约为 $\lambda_{\text{imp}} \approx 10$）及适度的鞅权重（$\lambda_{\text{mart}} \approx 1-10$）附近。很小的 λ_{imp} 在两种设置中都相对不利；而在 λ_{mart} 较小时，较大的 λ_{imp} 能部分起到补偿作用。

鞅违背面板中的主导趋势沿 λ_{mart} 方向出现：增大 λ_{mart} 会降低预测和潜在空间的违背，在整个扫描范围中通常可下降多个数量级。λ_{imp} 的作用取决于 λ_{mart}，而非其自身呈单调影响。在较低 λ_{mart} 下，中等 λ_{imp}（常在 1 附近）时违背往往最高；而在较高 λ_{mart} 下，更广的 λ_{imp} 范围内违背都很低。对预测空间鞅正则化，较高 λ_{imp} 与强鞅正则化结合还往往进一步降低预测空间违背，这与补全质量提高带来更协调的精细预测相吻合。

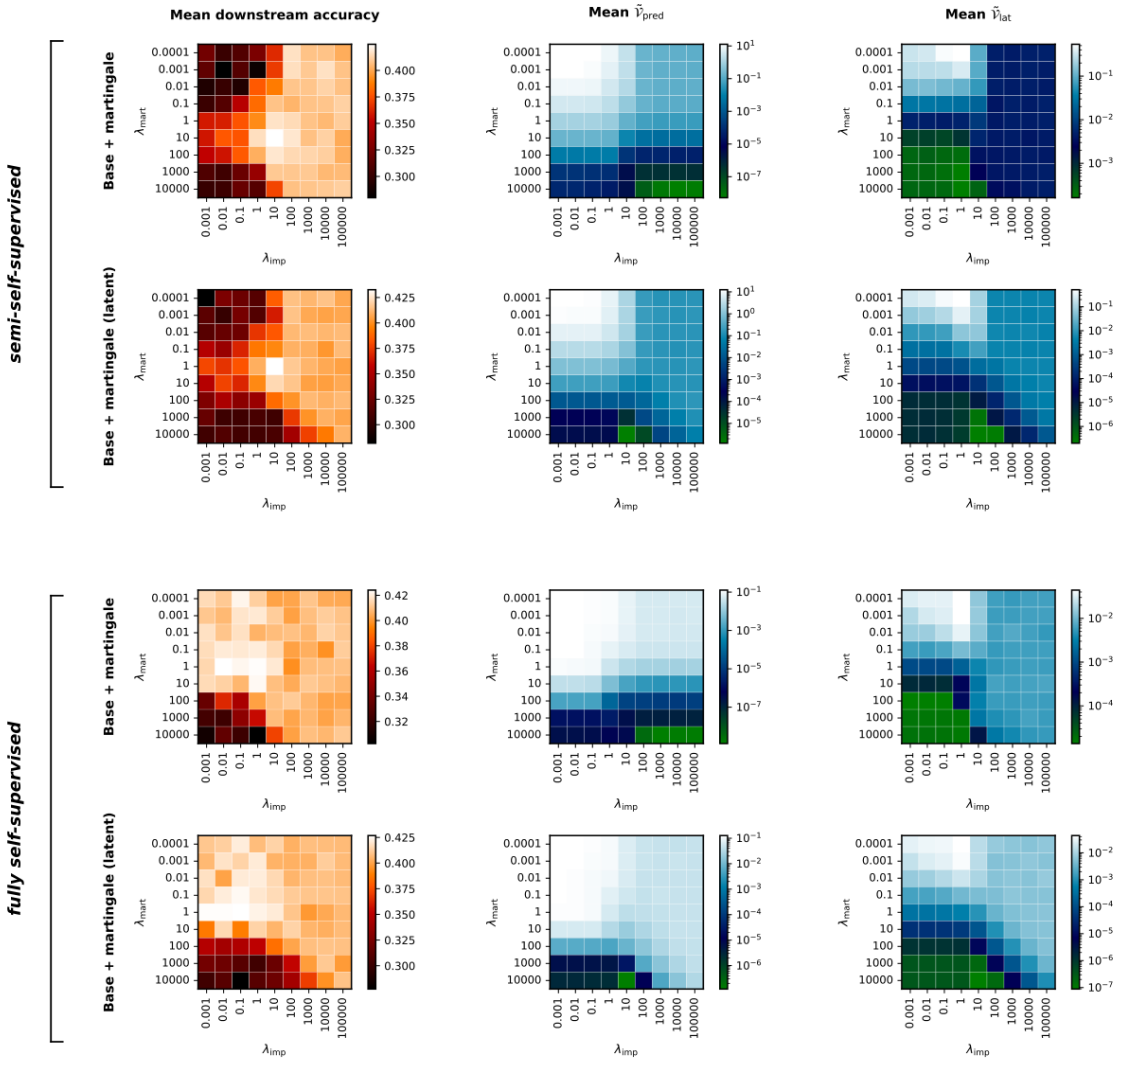


图 5　S-SIM 上的 Lambda 敏感性研究。上半部分：半自监督设置。下半部分：完全自监督设置。每部分各行汇总在预测空间和潜在空间进行鞅正则化的基础 SSL 模型；各列展示平均下游准确率、平均预测空间鞅违背、平均潜在空间鞅违背。数值在三次运行及完整度水平 $c \in \{0.8, 0.6, 0.4, 0.2, 0.05\}$ 上取平均。图内：Mean downstream accuracy＝平均下游准确率；Mean pred／Mean lat＝平均预测／潜在空间违背；semi-self-supervised＝半自监督；fully self-supervised＝完全自监督；Base + martingale (latent)＝基础模型加潜在空间鞅正则化。

C.2 冻结模型下鞅估计器的偏差诊断

我们将鞅惩罚的两个有限样本估计器与大 K 蒙特卡洛参考比较。对于冻结模型 g_ϕ、粗视图 $x_{\mathcal{F}_1}$ 及 $u := g_\phi(x_{\mathcal{F}_1})$，理想鞅平方误差为 $L := \| u - \mu \|_2^2$，其中 $\mu := \mathbb{E}\left[g_\phi(x_{\mathcal{F}_2}) \mid x_{\mathcal{F}_1}\right]$。我们以 $K = 128$ 的蒙特卡洛平均 $\widehat{\mu}$ 近似 μ，并设 $L_{\text{ref}} := \| u - \widehat{\mu} \|_2^2$。两个候选估计器分别是朴素单样本代入估计器

$$\widehat{L}_{\text{single}} := \| u - v_a \|_2^2, \tag{17}$$

以及双独立样本构造

$$\widehat{L}_{\text{two}} := (u - v_a)^\top (u - v_b), \tag{18}$$

其中 v_a, v_b 是条件独立的细化样本。在 S-SIM 上训练两个模型族，各使用一种估计器；再用各自原生估计器评估冻结模型。诊断值为在测试批次上平均的 $|\widehat{L} - L_{\text{ref}}|$。对两种训练设置以及两种细化机制——学习得到的插补器、模拟数据生成过程（DGP）的真实条件采样器——重复这一过程（图 6）。

在两种细化机制下，双样本估计器都比朴素代入估计器更贴近参考，且低完整度时差距最大。单样本估计器有大小为 $\mathrm{Var}\left(v_a \mid x_{\mathcal{F}_1}\right)$ 的向上偏差，该偏差随完整度降低而增大；双样本构造消除了这一偏差。因此，较小的差异 $|\widehat{L} - L_{\text{ref}}|$ 反映的是偏差减少，而不是方差减少。

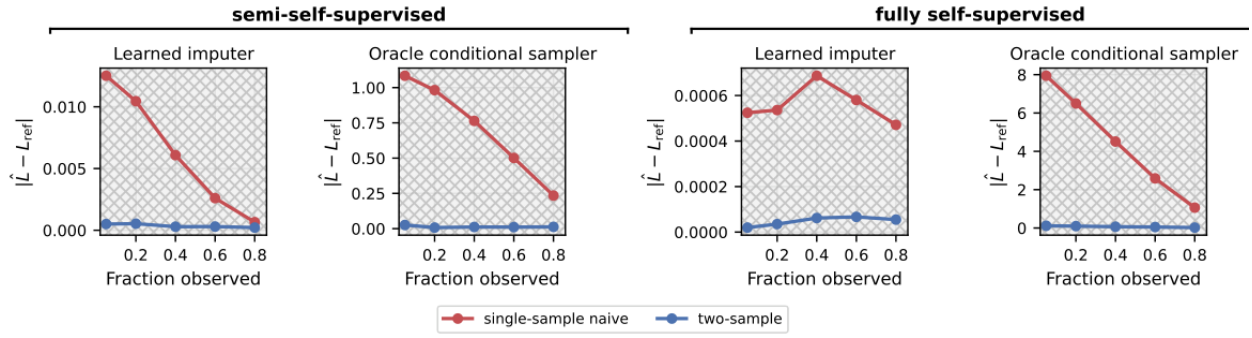


图 6　冻结模型下鞅估计器的偏差诊断。结果针对 S-SIM 数据集的静态表格基准，在五次运行上取平均。横轴是粗视图中的已观测比例；纵轴是有限样本鞅误差估计器 $\widehat{L}$（朴素单样本与双样本）与 $K = 128$ 蒙特卡洛参考 L_{ref} 的绝对差异 $|\widehat{L} - L_{\text{ref}}|$。面板按训练设置（半自监督与完全自监督）和细化采样机制（学习得到的插补器与真实条件采样器）划分。图内：Learned imputer＝学习得到的插补器；Oracle conditional sampler＝真实条件采样器；Fraction observed＝观测比例；single-sample naive＝朴素单样本；two-sample＝双样本。

C.3 计算开销

图 7 表明，运行时间、GPU 峰值内存和参数量的开销增幅通常都很小。参数增长尤其有限，这与附加插补组件的精简实现相一致。多数比较中，运行时间和内存仅略有增加，说明附加正则化在实践中仍然轻量。

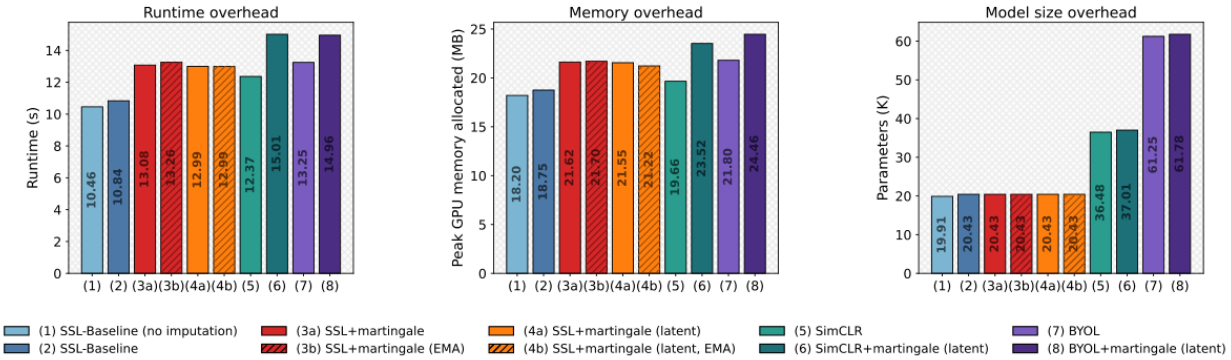


图 7　各方法的计算开销比较。从左至右，各面板报告运行时间、GPU 内存分配峰值及总参数量。图内：Runtime overhead＝运行时间开销；Memory overhead＝内存开销；Model size overhead＝模型规模开销；Runtime (s)＝运行时间（秒）；Peak GPU memory allocated (MB)＝GPU 已分配内存峰值（MB）；Parameters (K)＝参数量（千）。方法编号：(1) 无插补的 SSL 基线；(2) SSL 基线；(3a) SSL 加鞅正则化；(3b) SSL 加鞅正则化（EMA）；(4a) SSL 加潜在空间鞅正则化；(4b) SSL 加潜在空间鞅正则化（EMA）；(5) SimCLR；(6) SimCLR 加潜在空间鞅正则化；(7) BYOL；(8) BYOL 加潜在空间鞅正则化。

D TCGA 多组学生存基准

我们还在具有固有缺失的生物医学设置中检验鞅一致性正则化。该基准使用癌症基因组图谱（TCGA）的各癌种队列，以多个组学模态表示患者，包括 RNA 表达、DNA 甲基化、拷贝数变异、反相蛋白阵列（RPPA），以及可用时的 miRNA。不同于正文中的受控缺失实验，TCGA 患者并非完全观测，通常只测量了因患者而异的一部分模态。因此，我们将此实验作为补充压力测试：评估时使用的缺失模式是队列原有的模态可用性，而非人工模拟的测试掩码。

基础模型为 MIND [26]，它是一个多模态变分自编码器，将部分观测的多组学资料整合为共享的患者级表示。针对每个癌种，我们训练一个 MIND 模型，提取后验均值患者嵌入，并将这些嵌入连同年龄、性别协变量一起用于拟合 Coxnet 生存模型 [21]。以五折交叉验证的 C 指数衡量表现。报告每个癌种和变体在三个随机种子重复实验上的平均结果。

这一设置改变了精细信息集的解释。在主实验中，精细视图 $\mathcal{F}_2$ 是完全观测的输入；对于 TCGA，大多数患者并没有完全观测的多模态资料。因此，定义 $\mathcal{F}_2 = \mathcal{F}_{\mathcal{M}_i}$ 为患者的最大可用视图，其中 $\mathcal{M}_i$ 是患者 i 的已观测模态集。训练时，对 $|\mathcal{M}_i| = n_i \geq 2$ 的患者，先采样 $k_i \sim \mathrm{Uniform}\{1, \ldots, n_i - 1\}$，再均匀采样大小为 k_i 的子集 $\mathcal{M}_i' \subset \mathcal{M}_i$，得到嵌套粗视图 $\mathcal{F}_{\mathcal{M}_i'} \subset \mathcal{F}_{\mathcal{M}_i}$。仅有一个可用模态的患者参与基础 MIND 目标，但从鞅归约中排除，因为严格粗化项在此退化。因此，该实验考察：对原本已部分观测的真实数据进一步粗化时，鞅正则化能否改善表示学习。

我们训练六个模型：MIND；MIND (with imputation)，使用辅助插补损失但不使用鞅项；以及四个采用预测或潜在空间损失、具有或不具有 EMA 目标的鞅正则化变体。MIND 的模态专属编码器与解码器提供形成两个独立随机细化结果的插补机制。设置 $\lambda_{\mathrm{imp}} = \lambda_{\mathrm{mart}} = 1$，EMA 变体采用衰减系数 0.999。

结果。表 3 报告相对 MIND 的胜出情况：对每种方法，最后一行统计 17 个队列中 C 指数严格高于 MIND 的数量。MIND (with imputation) 在 6 个队列中胜出；四个鞅变体在 8–13 个队列中胜出，其中预测空间 EMA 最多（13），其次为预测空间（12）、潜在空间 EMA（12），以及不含 EMA 的潜在空间（8）。

总体上，TCGA 研究在不同条件下支持了与主基准相同的定性结论。在这里，鞅一致性不是将模拟的部分视图细化为完全观测样本，而是正则化患者已观测模态的进一步粗化子集与其自身最大可用多模态资料之间的协调性。这些胜出比例表明，鞅正则化在固有缺失下往往有帮助；变体之间的差异则强调，最佳鞅空间与目标网络的选择可能依赖具体应用。

表 3　TCGA 多组学生存基准。条目为根据 MIND 患者嵌入计算的五折 Coxnet C 指数，报告三个训练种子上的均值 ± SEM。最后一行统计相对 MIND 的队列胜出数（C 指数严格更高）。

Cancer	MIND	MIND (with imputation)	MIND + mart.	MIND + mart. (EMA)	MIND + mart. (latent)	MIND + mart. (latent, EMA)
BLCA	0.6185±.0039	0.6213±.0035	**0.6247**±.0048	0.6233±.0048	0.6121±.0047	0.5872±.0025
BRCA	0.6409±.0077	**0.6507**±.0050	0.6358±.0053	0.6448±.0050	0.6407±.0017	0.6149±.0033
CESC	0.6191±.0101	0.5654±.0053	0.6138±.0242	0.5966±.0079	0.6119±.0056	**0.6447**±.0098
COAD	0.5188±.0066	0.5376±.0192	0.5441±.0210	0.4913±.0047	0.5351±.0109	**0.5739**±.0013
COADREAD	0.5780±.0092	0.5590±.0128	0.5837±.0116	0.5855±.0054	0.5732±.0035	**0.6146**±.0026
GBM	0.6426±.0045	0.6449±.0037	0.6533±.0014	0.6501±.0023	**0.6564**±.0031	0.6541±.0020
HNSC	0.6263±.0062	0.6240±.0002	0.6009±.0018	0.6039±.0048	0.6160±.0012	**0.6324**±.0011
KIRC	0.7102±.0031	0.7097±.0029	**0.7199**±.0026	0.7167±.0017	0.7028±.0007	0.7065±.0012
LGG	0.8422±.0026	0.8394±.0016	0.8476±.0004	**0.8494**±.0011	0.8488±.0010	0.8472±.0027
LIHC	0.6063±.0109	0.6043±.0115	**0.6401**±.0011	0.6236±.0025	0.6352±.0071	0.6100±.0243
LUAD	0.6045±.0043	0.5905±.0056	0.5834±.0031	**0.6102**±.0153	0.5965±.0036	0.5529±.0015
LUSC	0.5253±.0088	0.5397±.0100	0.5414±.0076	0.5386±.0042	0.5398±.0067	**0.5467**±.0025
OV	0.5983±.0079	0.5966±.0048	0.5809±.0051	0.5941±.0040	0.5977±.0033	**0.5994**±.0007
SKCM	0.6461±.0032	0.6364±.0028	0.6522±.0011	0.6631±.0003	**0.6641**±.0013	0.5994±.0028
STAD	0.5619±.0093	0.5635±.0116	0.5749±.0090	**0.5788**±.0057	0.5785±.0031	0.5730±.0019
THCA	0.9336±.0054	0.9326±.0067	0.9438±.0008	**0.9515**±.0018	0.9303±.0022	0.9479±.0028
UCEC	0.6281±.0086	0.6259±.0065	0.6483±.0108	**0.6509**±.0121	0.6413±.0034	0.6491±.0038
Wins / 17	–	6	12	13	8	12

表内：Cancer＝癌种；MIND (with imputation)＝含插补的 MIND；mart.＝鞅正则化；latent＝潜在空间；EMA＝指数移动平均；Wins / 17＝17 个队列中的胜出数量。癌种缩写及全部数值保留原样。

E 数据说明

E.1 模拟数据

合成时间序列数据（右删失 T-SIM-RC）。右删失基准从一个带有有界非线性的因果线性动力系统生成合成多变量时间序列：

$$\begin{aligned} X_0 &\sim \mathcal{N}(0,\ \Sigma_0), \\ X_t &= AX_{t-1} + \varepsilon_t + \alpha\tanh\big(AX_{t-1} + \varepsilon_t\big), \qquad t = 1,\ \ldots,\ T, \end{aligned} \tag{19}$$

其中 $\varepsilon_t \sim \mathcal{N}(0,\ \sigma^2 I_D)$ 独立同分布， $A \in \mathbb{R}^{D\times D}$ 是稳定的下三角转移矩阵， Σ_0 是线性部分的平稳协方差。所报告设置使用 $T = 16$ 、 $D = 16$ 、噪声尺度 $\sigma = 0.2$ 、非线性强度 $\alpha = 0.2$ 及五个类别，标签定义为 $y = \operatorname{argmax}_{k\in\{1,\ldots,5\}}(W_{\mathrm{RC}}u)_k$ ，其中 u 是最后 $W = 5$ 个时间步的加权组合， W_{RC} 是将该汇总向量映射为五个 logit 的固定线性映射。这一构造将标签信息集中在序列末端，因此右删失会首先移除最有预测力的时间步。

合成时间序列数据（T-SIM）。结构化时间基准采用另一种非马尔可夫生成器，每个时间步具有独立的潜因子：

$$\begin{aligned} z_t &\sim \mathcal{N}(0,\ I_k), \\ X_t &= B_t z_t + \varepsilon_t + \alpha\tanh(B_t z_t + \varepsilon_t), \qquad t = 1,\ \ldots,\ T, \end{aligned} \tag{20}$$

其中 $B_t \in \mathbb{R}^{D\times k}$ 是按时间索引的投影， $\varepsilon_t \sim \mathcal{N}(0,\ \sigma^2 I_D)$ ，潜在维数 $k = 8$ 。所报告设置使用 $T = 16$ 、 $D = 32$ 、噪声尺度 $\sigma = 0.2$ 、非线性强度 $\alpha = 0.2$ 和五个类别。标签使用时间索引 $\{8,\ 9,\ 10,\ 15\}$ 上的帧：逐坐标平均这四帧形成 D 维汇总，逐坐标对汇总应用 $\tanh$ ，再用模拟种子确定的固定掩码将除 $|S| = 5$ 个特征维度之外的其余维度置零（使标签信息只由这些坐标提供）；对于固定随机矩阵 $W_{\mathrm{ST}} \in \mathbb{R}^{5\times D}$ 和掩码汇总 $\widetilde{x} \in \mathbb{R}^D$ ，令 $y = \operatorname{argmax}_{k\in\{1,\ldots,5\}}(W_{\mathrm{ST}}\widetilde{x})_k$ 。

合成静态表格数据集（S-SIM）。S-SIM 是实验所用的合成静态表格数据集。每个样本是一个特征向量，通过特征掩码诱导部分观测。数据生成使用一个共享标准正态因子 g ，以及与固定预测性坐标子集 S 对应的独立标准正态配对因子 $\left(f_j\right)_{j=1}^{|S|}$ 。每个预测性坐标以固定仿射系数加载到 $\left(g,\ f_j\right)$ 上，并包含高斯噪声；至多 $|S|$ 个额外代理坐标加载到同样的因子上（因此当 S 被掩码时，预测信息仍可部分恢复）；其余所有坐标均为独立高斯噪声。随后加入尺度为 σ 的加性高斯测量噪声，以及强度为 α 的有界非线性，所用 $(\sigma,\ \alpha)$ 与 T-SIM-RC、T-SIM 相同。标签由 S 上的线性多类别得分定义：$y = \operatorname{argmax}_{k\in\{1,\ldots,K\}}(Wx)_k$ ，其中类别权重矩阵 $W \in \mathbb{R}^{K\times D}$ 仅在 S 上有支撑。所报告设置使用 $D = 16$ 、 $K = 5$ 、 $|S| = 5$ 。

E.2 真实数据与图像数据

真实时间序列数据集为 UCI HAR（HAR）[1]、Traffic（TRAF）（PEMS-SF）[8]、Stock（STK）[1]、Character Trajectories（CT）[24] 和 Spoken Arabic Digits（SAD）[19]。这些多变量序列分类问题在序列长度、维度和领域方面差异显著。股票基准由固定一组美国大盘股的每日 OHLCV 历史构建，使用数据集构建时可获得的约两年数据。随后，对各股票代码的序列标准化，以步幅 32 提取长度为 128 的滑动窗口，并赋予表示下一次收盘价是否上涨的二元标签。

[1] 股票历史通过 Yahoo Finance 市场数据的 yfinance 软件包 下载。

静态数据集为 Adult（AD）[5]、Bank Marketing（BM）[18]、Credit-g（CG）[14] 和 Phoneme（PH）[11]。这些表格分类任务用于检验：当嵌套信息由特征显露而非时间延续诱导时，同样的鞅一致性思路是否仍有意义。图像基准为 CIFAR-10 [15] 和 STL-10 [7]，均作为块掩码下的 32×32 彩色图像分类问题；粗视图仅显露部分图像块，精细视图则是完整图像。

E.3 数据集汇总

表 4 汇总实验所用模拟、真实和图像基准。模拟基准中，T-SIM-RC 使用 3000／3000 的训练／测试划分；T-SIM 和 S-SIM 使用 3000 个训练样本、500 个留出的掩码先验拟合样本及 3000 个测试样本。真实时间序列与静态表格数据集使用 60%／10%／30% 的训练／掩码先验拟合／测试划分。CIFAR-10 和 STL-10 使用 70%／30% 的训练／测试划分，不另外保留掩码先验拟合分区；图像实验将 STL-10 图像从 96×96 缩放为 32×32 。

表 4　基准数据集汇总。

Dataset	Samples	Classes	Features	Cat./Cont.	Domain
Time-series benchmarks					
T-SIM-RC	6000	5	16	0 / 16	Synthetic time series
T-SIM	6500	5	32	0 / 32	Synthetic time series
UCI HAR (HAR)	10299	6	9	0 / 9	Activity sensing
Traffic (TRAF)	440	2	963	0 / 963	Transportation
Stock (STK)	180	2	5	0 / 5	Finance
Character Trajectories (CT)	2858	20	3	0 / 3	Handwriting
Spoken Arabic Digits (SAD)	8800	10	13	0 / 13	Speech
Static tabular benchmarks					
S-SIM	6500	5	16	0 / 16	Synthetic tabular
Adult (AD)	48842	2	14	8 / 6	Demographics
Bank Marketing (BM)	45211	2	16	10 / 6	Marketing
Credit-g (CG)	1000	2	20	13 / 7	Finance
Phoneme (PH)	5404	2	5	0 / 5	Speech
Image benchmarks					
CIFAR-10	60000	10	32×32×3	–	Natural images
STL-10	13000	10	32×32×3	–	Natural images

表头：Dataset＝数据集；Samples＝样本数；Classes＝类别数；Features＝特征数；Cat./Cont.＝类别型／连续型特征数；Domain＝领域。分组：Time-series benchmarks＝时间序列基准；Static tabular benchmarks＝静态表格基准；Image benchmarks＝图像基准。领域依次为：合成时间序列、合成时间序列、活动感知、交通运输、金融、手写、语音、合成表格、人口统计、营销、金融、语音、自然图像、自然图像。

E.4 部分观测协议

在所有基准中，均在各基准特有的部分观测过程下，以已观测信息水平 $c \in \{0.05,\ 0.2,\ 0.4,\ 0.6,\ 0.8\}$ 评估下游鲁棒性。评估时部分观测模式的来源随基准族不同：右删失时间序列和图像基准使用预定义方案，而非右删失时间序列和静态表格基准使用结构化过程。全部基准中，部分观测都与任务相关结构耦合，使精细视图系统性地包含更多下游任务信息；这恰好是鞅一致性最有益的条件（命题 1）。

时间序列基准（右删失）。该基准通过在已观测前缀之后右删失时间轴获得部分观测视图。记 $L \in \{0,\ \ldots,\ T\}$ 为观测前缀长度，则掩码为

$$M_{t,d} = \mathbf{1}\{t \le L\}, \qquad t = 1,\ \ldots,\ T,\ \ d = 1,\ \ldots,\ D. \tag{21}$$

完整输入充当精细目标视图。这一构造直接对应通过增加历史长度来细化信息的解释。在 T-SIM-RC 中，标签信息依构造集中在序列末尾，因此右删失会优先移除最有预测力的时间步，使跨视图协调性对下游鲁棒性尤其重要。

时间序列基准（非右删失）。非右删失时间序列基准通过结构化时间过程生成缺失。对样本 i 和时间索引 t，使用低秩逻辑模型

$$\Pr\big(M_{i,t}=1\big)=\sigma(b_t+s_i+z_i^{\top}\ell_t-\beta q_t+\delta(c)), \qquad (22)$$

其中 q_t 是时间重要性曲线（T-SIM 中由合成构造导出，为标签相关时间步上的二元指示；真实时间序列数据集中，则在 SSL 训练划分上估计），$z_i\sim\mathcal{N}\big(0,\,I_r\big)$ 是样本级潜因子，$s_i\sim\mathcal{N}\big(0,\,\tau^2\big)$ 是严重程度项，$\delta(c)$ 是选定的标量平移，使期望观测比例与目标完整度 c 一致。负项 $-\beta q_t$ 将缺失与时间重要性显式耦合，使在目标过程中更有预测力的时间步也更可能缺失。所报告设置使用秩 $r=3$、基础 logit 尺度 0.04、相关载荷尺度 0.05、重要性强度 $\beta=5.0$、严重程度标准差 $\tau=0.12$。

静态表格基准。静态表格基准采用相同参数化，只将时间索引 t 替换为特征索引 j：

$$\Pr\big(M_{i,j}=1\big)=\sigma(b_j+s_i+z_i^{\top}\ell_j-\beta q_j+\delta(c)). \qquad (23)$$

这里，q_j 是特征重要性曲线（S-SIM 中由合成构造导出，真实静态表格数据集中在训练划分上估计），$z_i,\,s_i,\,\delta(c)$ 的作用同上。所报告设置仍使用秩 3、基础尺度 0.04、相关尺度 0.05、重要性强度 5.0 和严重程度标准差 0.12。

图像基准。图像基准在规则块网格上通过块掩码诱导部分观测。令 $P_{i,p}\in\{0,\,1\}$ 表示图像 i、块索引 p 的块级观测掩码，满足

$$\frac{1}{n_{\text{patch}}}\sum_{p=1}^{n_{\text{patch}}}P_{i,p}\approx c, \qquad (24)$$

其中 c 为目标观测比例。在所报告 CIFAR-10 和 STL-10 实验中，采用中心偏置掩码方案：采样被丢弃的正方形块区域，其概率按下式向图像中心加权：

$$w_p\propto\exp\Big(-\gamma\widetilde{d}_p^{\,2}\Big), \qquad \gamma=3.0, \qquad (25)$$

其中 $\widetilde{d}_p^{\,2}$ 是块 p 到图像中心的平方距离，已用块网格上的最大平方距离归一化。将块掩码展开到像素上便得到图像级掩码，精细目标视图始终为完整图像。

F 模型实现细节

F.1 模型架构与目标族

在全部所报告实验中，训练从完整输入 X 出发，采样掩码 M 构造粗视图。对时间和表格基准，X 为 $\mathbb{R}^{T\times D}$ 中的数组，静态表格数据作为 $T=1$ 的特例处理；粗输入为 $X\odot M$，其中 $M\in\{0,\,1\}^{T\times D}$。对图像基准，$X\in\mathbb{R}^{C\times H\times W}$，$M$ 是直接作用于图像的采样块掩码。在所有情况下，鞅分支使用的精细视图都是完整输入。基础实现由编码器 f_θ、预测头 g_ϕ 以及可选插补模块 q_ψ

组成。对于时间和表格数据，f_θ 是作用于经掩码序列或特征输入的掩码感知编码器。对于图像，f_θ 是作用于掩码图像的视觉编码器；所报告 CIFAR-10 和 STL-10 实验中，半自监督与 SimCLR 模型均使用 ResNet-18 [12] 主干。一般地，记粗表示与精细表示为

$$z_{\mathcal{F}_1} := f_\theta(X \odot M), \qquad z_{\mathcal{F}_2} := f_\theta(X), \tag{26}$$

其中，时间和表格模型采用掩码感知编码器实现；图像则在调用编码器前，将掩码作用于像素。

基础框架。核心基准族使用两类目标。基于重建的设置中，预测头从编码器表示预测完整输入，重建项在完整输入上评估：

$$\mathcal{L}_{\text{pred}}^{\text{rec}} := \frac{1}{|\Omega|} \parallel g_\phi^{\text{rec}}\left(z_{\mathcal{F}_2}\right) - X \parallel_2^2, \tag{27}$$

其中 $|\Omega|$ 表示输入坐标或像素的数量。半自监督设置中，预测头将表示映射到类别 logit，分类项为完整输入上的交叉熵：

$$\mathcal{L}_{\text{pred}}^{\text{cls}} := -\log \frac{\exp\left(g_\phi^{\text{cls}}\left(z_{\mathcal{F}_2}\right)_Y\right)}{\sum_{k=1}^{K} \exp\left(g_\phi^{\text{cls}}\left(z_{\mathcal{F}_2}\right)_k\right)}. \tag{28}$$

因此，在基础框架中，这些预测项在完整样本上计算，而掩码视图通过插补与鞅一致性项进入。所报告时间序列和静态表格实验中，半自监督模型采用监督分类，完全自监督基础模型采用重建目标。时间序列和静态表格分类的预测头作用于编码器表示的掩码均值池化结果；图像分类则作用于图像编码器的直接输出。重建时，预测头作用于未池化编码器输出，以便逐坐标或逐像素预测完整输入。

F.2 插补模块

除这些预测或表示学习项外，基于鞅的模型还可使用插补模块 q_ψ，从粗视图表示预测输入的缺失部分。对时间和表格数据，这指原序列／特征域中的缺失坐标；对图像，这指掩码图像中的缺失像素。记 $X_{\text{imp}} = q_\psi\left(z_{\mathcal{F}_1}\right)$，则插补损失为

$$\mathcal{L}_{\text{imp}}(\theta, \psi; X, M) := \frac{\sum_j \left(1 - M_j\right)\left(\left(X_{\text{imp}}\right)_j - X_j\right)^2}{\sum_j \left(1 - M_j\right) + \varepsilon}, \tag{29}$$

其中索引 j 遍历坐标或像素，$\varepsilon > 0$ 防止除零。已观测条目直接从输入复制，因此插补器只在真正缺失的分量上训练。所报告实验中，该模块有两个作用：为损失贡献显式插补项；为鞅正则项生成随机补全。

F.3 SSL 模型训练期间的掩码方案

所有所报告实验的训练均是嵌套的：模型接收完整输入，但有意采样粗掩码以构造部分信息分支，精细分支仍为完整输入。粗视图完整度逐批次在 $[0.05, 1.0]$ 中随机化，涵盖严重和轻微掩码情况。

对结构化时间和静态表格基准，训练掩码不直接从评估时过程抽取。相反，我们在 SSL 训练划分上估计特征或时间步重要性得分，在留出的先验拟合分区上以完整度 0.5 生成校准掩码，从这些观测掩码拟合掩码先验，再在训练时从该先验采样粗视图掩码。这在不重复使用评估样本的前提下近似部署时的缺失。右删失时间和图像基准的掩码则直接从预定义掩码族抽取：T-SIM-RC 使用右删失前缀，图像设置使用中心偏置块掩码。

F.4 所报告实验中的鞅一致性目标

全部所报告实验中，$x_{\mathcal{F}_2} = x$ 为完整观测，$x_{\mathcal{F}_1} = x \odot M$ 为粗视图。式 (8) 所需两个条件独立细化结果由基于随机插补器的补全产生，即将插补的缺失条目与已观测坐标合并。对时间序列和表格实验，记 $r \in \{a, b\}$，有

$$\begin{aligned} \widetilde{x}_r &:= x_{\mathcal{F}_1} + \xi_r \odot (1 - M), \\ \widetilde{z}_r &:= f_\theta(\widetilde{x}_r), \\ \widehat{x}_r &:= x \odot M + q_\psi(\widetilde{z}_r) \odot (1 - M), \end{aligned} \tag{30}$$

其中 ξ_a, ξ_b 是独立抽取的高斯噪声。图像实验则将 $x_{\mathcal{F}_1}$ 的带噪编码器表示输入插补器。

预测空间变体。记传给预测头的表示为 $z = f_\theta(x_{\mathcal{F}_1})$、$z_a = f_\theta(\widehat{x}_a)$、$z_b = f_\theta(\widehat{x}_b)$，把粗、精细预测 $u = g_\phi(z)$、$v_a = g_\phi(z_a)$、$v_b = g_\phi(z_b)$ 代入式 (8)，得到 $\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart,pred}}$。

潜在空间变体。潜在空间变体在鞅项中跳过预测头，将式 (8) 直接应用于相同的粗、精细表示，得到 $\widehat{\mathcal{L}}^{\mathrm{2MC}}_{\mathrm{mart,lat}} := (z - z_a)^\top (z - z_b)$。SimCLR 与 BYOL 变体只使用这一潜在空间构造。

F.5 训练调度与优化

总体训练损失形式为

$$\mathcal{L}_{\mathrm{total}} = \mathcal{L}_{\mathrm{pred}} + \lambda_{\mathrm{imp}} \mathcal{L}_{\mathrm{imp}} + \lambda^{\mathrm{eff}}_{\mathrm{mart}} \mathcal{L}_{\mathrm{mart}}, \tag{31}$$

其中，根据模型变体，$\mathcal{L}_{\mathrm{mart}}$ 为预测空间或潜在空间鞅惩罚。有效鞅权重遵循预热—渐增调度：

$$\lambda^{\mathrm{eff}}_{\mathrm{mart}}(s) = \lambda_{\mathrm{mart}} \cdot \gamma(s), \tag{32}$$

其中 $\gamma(s)$ 在预热阶段为 0，之后在渐增区间线性增加到 1，此后维持为 1。这一调度用于减少早期优化不稳定性。

F.6 训练与模型超参数

时间序列与静态表格实验。我们通过网格搜索选择 λ_{imp} 与 λ_{mart}，搜索范围为 $\lambda_{\mathrm{imp}} \in \{10^{-4}, 10^{-3}, \ldots, 10^{3}\}$ 与 $\lambda_{\mathrm{mart}} \in \{10^{-4}, 10^{-3}, \ldots, 10^{4}\}$。对每一对 $(\lambda_{\mathrm{imp}}, \lambda_{\mathrm{mart}})$，在完整训练划分上训练各 SSL 模型的鞅一致变体；为给该参数对评分，在 80% 的训练数据上拟合线性探针，在余下 20% 上验证；保留在完整度 $c \in \{0.8, 0.6, 0.4, 0.2, 0.05\}$ 上平均验证准确率最高的参数对。Base + imputation 模型复用相应鞅模型族选出的 λ_{imp}。

其余设置在所报告模型和数据集中共享。学习率为 10^{-3}，权重衰减为 10^{-4}；每次运行训练 500 步，批大小 256。编码器是一个作用于每个时间索引完整特征向量的单个 MLP，层宽为 128–64–32，使用 GELU 激活及 0.1 的 dropout；表示为对已观测位置取掩码均值得到的 32 维向量。在半自监督设置中，使用单个线性映射，从池化的 32 维表示读出类别 logit。在完全自监督（重建）和插补目标中，使用跨时间共享的线性读出，每个都是从隐藏特征到输入特征维度的单个映射。

鞅正则化的训练粗视图在每个批次从 $[0.05,\ 1.0]$ 采样已观测信息比例。鞅项采用 100 步预热、400 步线性渐增；基于 EMA 的变体使用衰减系数 0.97（潜在鞅使用完整目标 EMA，预测空间鞅仅使用预测头 EMA）。两次随机细化采用尺度为 0.25 的高斯补全噪声。在表格 SimCLR 和 BYOL 运行中，对比及自举目标由两个独立采样的部分视图计算，这些视图使用与鞅正则化相同的已拟合掩码机制获得。SimCLR 的投影 MLP 为 $32 \to 128 \to 64$，温度 0.1；BYOL 另外加入预测器 MLP $64 \to 256 \to 64$，目标衰减系数 0.99。下游探针使用线性头，训练 10 个探针轮次，学习率 10^{-2}、权重衰减 0、批大小 1000；探针在完整观测嵌入上训练，在 $c \in \{0.8,\ 0.6,\ 0.4,\ 0.2,\ 0.05\}$ 上测试。SSL 预训练与线性探针训练均使用 AdamW 优化器 [17]。

图像实验。图像实验的编码器为从头训练的 ResNet-18 [12]：使用直至全局平均池化的标准卷积堆栈，去掉原本将池化特征向量映射到 1000 类 ImageNet 头类别 logit 的最后线性层，因此表示为池化后得到的 512 维向量。CIFAR-10 使用原生 32×32 分辨率，STL-10 从 96×96 缩放为 32×32。SSL 预训练批大小为 256，共 50 个轮次，学习率 10^{-3}、权重衰减 10^{-4}。掩码使用 4×4 块，中心偏置 3.0，结果在完整度 $c \in \{0.8,\ 0.6,\ 0.4,\ 0.2,\ 0.05\}$ 上报告。

半自监督模型族中，Base 模型在编码器特征上使用线性分类器；Base + imputation 增加 MLP 插补器，$\lambda_{\text{imp}} = 1$；潜在鞅变体使用相同插补器，$\lambda_{\text{imp}} = 1$、$\lambda_{\text{mart}} = 0.01$，鞅项预热 5 个轮次、线性渐增 12 个轮次，鞅裁剪值为 100。插补器将 512 维潜在向量映射为完整的 $3\times32\times32$ 像素，细化噪声尺度为 0.05。

SimCLR 使用标准完整图像增强：尺度为 $[0.2,\ 1.0]$ 的随机缩放裁剪、概率 0.5 的水平翻转、概率 0.2 的灰度化；投影头为 $512 \to 512 \to 128$，温度为 0.2 [20, 6]。SimCLR + imputation 使用 $\lambda_{\text{imp}} = 1$；SimCLR + imputation + latent martingale 使用 $\lambda_{\text{imp}} = 1$、$\lambda_{\text{mart}} = 1$，采用相同的预热、渐增和鞅裁剪设置。下游探针在未掩码特征上使用线性头训练 25 个轮次，学习率 10^{-2}、权重衰减 10^{-4}、批大小 1024。

全部实验均在共享集群上执行，每项任务使用一块 NVIDIA A100 GPU（40–80 GB 显存），主机内存范围为 20–90 GB。我们的测量显示，静态表格实验单次训练运行耗时为数秒量级，图像实验约为一小时。