掩码条件共形预测：适用于所有缺失数据机制的有效不确定性

非官方中文全文译文

Jiarong Fan · Juhyun Park · Thi Phuong Thuy Vo · Nicolas Brunel

作者单位：Jiarong Fan：巴黎萨克雷大学 Evry，LaMME；Juhyun Park、Thi Phuong Thuy Vo：ENSIIE、LaMME，巴黎萨克雷大学 Evry；Nicolas Brunel：ENSIIE、LaMME，巴黎萨克雷大学 Evry，以及 Capgemini Invent France。

原文：Mask-Conditional Conformal Prediction: Valid Uncertainty For All Missing Data Mechanisms，第29届人工智能与统计国际会议（AISTATS 2026），摩洛哥丹吉尔，PMLR 300:3034–3042。版权 © 2026 原作者。官方论文页面。原文及本译文采用 CC BY 4.0；翻译、重新排版和中文图表说明属于改编，不代表作者认可。正文、参考文献及随附补充材料均纳入译文；公式和图表部分保留原始图像以维护符号与数值保真。

摘要

共形预测（CP）提供了一套有原则的不确定性量化框架，但面对缺失协变量时，它无法保证掩码条件覆盖率。为了处理各种缺失模式造成的异质性，掩码条件有效（MCV）覆盖已成为比边际覆盖更理想的性质。本文提出“预插补—施加掩码—再校正”框架，将分割式 CP 扩展到缺失值情形，以提供有效覆盖。我们证明，该方法能在一般缺失数据机制下保证边际覆盖和掩码条件有效性。方法的关键组成部分是重新加权的共形预测程序：对校准数据集进行分布型插补（多重插补）之后，该程序对预测集加以校正，使本方法兼容标准插补流程。我们推导了两种算法，并证明它们同时实现边际有效性和 MCV。我们在合成数据集和真实数据集上进行了评估。相对于标准 MCV 方法，本方法在保持目标保证的同时，显著缩小了预测区间宽度。

1 引言

不确定性估计对于将机器学习模型部署到金融、医疗保健和自主系统等现实应用至关重要。量化不确定性的常用办法是构造预测集，例如回归中的区间或分类中的标签集合。预测集的主要目标是以较高概率（例如90%）包含样本点的真实标签。

为了获得有效预测集，共形预测（CP）已成为一种广泛采用的框架（Vovk et al., 2005）。CP 提供了与模型无关、无分布假设的办法，可为任何机器学习模型构造预测集（Angelopoulos et al., 2023）。给定测试点随机变量 $(X, Y) \in \mathcal{X} \times \mathcal{Y}$，其中 X 包含 d 个特征，对任意 $i \in \{1, \ldots, d\}$，有 $X_i \in \mathcal{X}_i$，而每个 $\mathcal{X}_i$ 通常是 $\mathbb{R}$ 或离散空间；再给定误覆盖率 α，CP 的目标是创建集合 $\widehat{C}_\alpha(X)$，使其以概率 $1 - \alpha$ 包含 Y。分割式 CP（Papadopoulos et al., 2002）是最常用的 CP 技术之一，通过利用校准数据集评估模型的不确定性来实现这一目标。

尽管 CP 似乎非常适合仅对数据生成过程作可交换性假设（弱于独立同分布假设）的应用，但在存在扰动（例如噪声标签或缺失数据）时，它无法提供保证（Einbinder et al., 2024; Zaffran et al., 2023, 2024; Feldman and Romano, 2024; Sesia et al., 2024; Zhou et al., 2025）。

特别地，为保证缺失数据下的覆盖率，考虑缺失模式或掩码至关重要。用向量 $M \in \{0, 1\}^d$ 表示掩码，其中 $M_i = 1$ 表示特征 X_i 缺失。[1] 缺失数据会严重降低模型性能，长期以来一直是机器学习与统计学的研究对象（Emmanuel et al., 2021; Ren et al., 2023）。为评估并纠正这一问题，较新的研究重点是对缺失数据进行插补，并最终选取最好的插补算法以提高预测可靠性，例如“先插补再回归”程序（Le Morvan et al., 2021; Bertsimas et al., 2024; Lobo et al., 2025）。已有研究表明，缺失值也会影响包括 CP 在内的不确定性量化（Zaffran et al., 2023; Feldman and Romano, 2024）。

Zaffran et al. (2023) 引入了掩码条件有效性（MCV，见定义2.1）概念，强调缺失性会造成数据异质性，使基本分割式 CP 集合出现覆盖不足。若用 P 表示 (X, Y, M) 的联合分布，则 MCV 对应于针对每个模式 $m \in \{0, 1\}^d$ 的组别控制：$P\left(Y \in \widehat{C}_\alpha \mid M = m\right) \geq 1 - \alpha$。通过数据增强方法 CP-MDA-Exact 和 CP-MDA-Nested（Zaffran et al., 2023）修改校准数据集的处理方式，可以实现这一性质。然而，该方法局限于 MCAR，而且往往较为保守：CP-MDA-Exact 需要大量数据；CP-MDA-Nested 则在极端情况下产生很大的预测集，例如 Zaffran et al. (2023) 图12中缺失值比例为40%的数据。

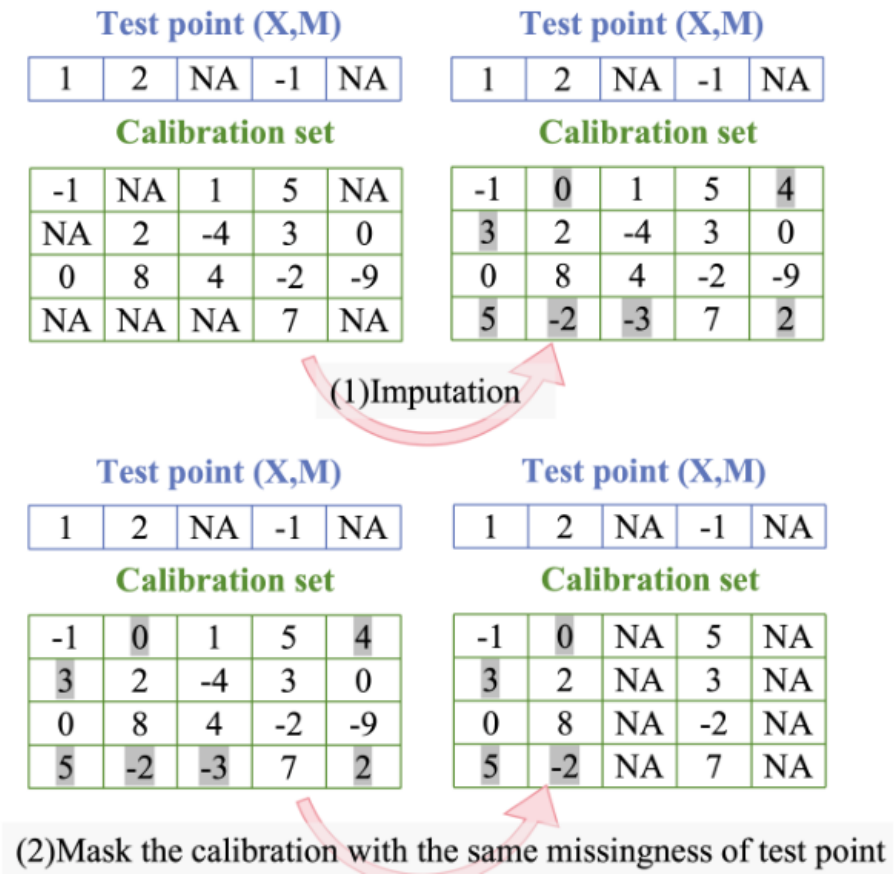


图1： 预插补示意图。先插补校准数据，再使用测试点的掩码 M 对其施加掩码，使两者具有相同模式。这样，分割式 CP 就能给出以 M 为条件的预测集。但仍存在分布偏移。不同于 CP-MDA，本方法利用全部可用校准数据，而不修改测试点。图内词语：calibration data 为校准数据，test point 为测试点，imputation 为插补，mask 为掩码。

由于偶然不确定性随 M 显著变化（Zaffran et al., 2023），MCV 是本文的研究重点：在实践中，保证这一关键性质，才能重新获得风险可控且有用的预测集。为弥补已有方法的不足，我们提出新的“预插补—施加掩码—再校正”框架。该框架建立在通常先插补、再使用分割式 CP 等常规不确定性量化工具的标准做法之上。关键在于，（仅仅）插补并不能纠正不同缺失模式引起的异质性；为控制误覆盖率，我们建议在应用分割式 CP 之前按照缺失模式对齐，如图1所示。然而，正如第4.4节实验所示，由于不完美插补引入分布偏移，这种做法无法保证 MCV。我们将加权 CP（Tibshirani et al., 2019）推广到缺失数据，并引入两种基于似然的校正机制，以解决这一问题，保证在更符合实际的 MAR 和 MNAR 条件下也能获得有效区间（Kang, 2013）。

贡献。我们提出“预插补—施加掩码—再校正”框架，其中包括两种新的校正方法：掩码条件加权 CP，以及接受—拒绝校正（ARC）CP，用于应对分布偏移和在协变量缺失的数据集中构造有效预测集的挑战。ARC-CP 是一种新的实现方式，它使用密度比权重对一个子集进行重采样，从而显式地解决分布偏移的重新加权问题。

这两种方法同时保证 MV 和 MCV，并显著缩小相对于已有方法的预测区间宽度；严格的理论分析和合成及真实数据集上的广泛实验证明了这一点。所提方法无需对缺失机制作任何假设即可保证 MCV；据我们所知，以前尚未达到这一点。

我们还分析了不准确的似然比估计器对 MCV 的影响，建立了误覆盖的下界，并通过实证表明其影响仍然有限且可控。由于本方法只需要对校准数据集插补一次，不需要插补测试观测，因此可以平滑地集成到大量数据处理流程中，同时保持保证，并且容易在实践中使用。

2 背景

缺失数据记号。给定三元随机变量 $Z{:=}(X,\ M,\ Y) \in \mathcal{X}\times\{0,\ 1\}^d\times\mathcal{Y} \sim P$，令 $\mathcal{X}_{\mathrm{NA}} = \prod_{j=1}^{d}\left(\mathcal{X}_j\cup\{\mathrm{NA}\}\right)$。定义掩码算子 $\mathrm{mask} : \mathcal{X}_{\mathrm{NA}}\times\{0,\ 1\}^d \to \mathcal{X}$：

$$\mathrm{mask}(x,\ m){:=}(1-m)\odot x + m\odot\mathrm{NA}. \qquad (1)$$

其中 $\odot$ 表示逐元素乘积。在不会引起歧义时，使用 $\widetilde{X}$ 表示 $\mathrm{mask}(X,\ M)$，以简化记号。

用 $\mathrm{obs}(M)$ 表示已观测协变量的索引集，用 $\mathrm{mis}(M)$ 表示缺失协变量的索引集。例如，若 $m = [0,\ 1,\ 0]$，则 $\mathrm{obs}(m) = \{1,\ 3\}$，且 $X_{\mathrm{obs}(m)} = \left[X_1,\ X_3\right]$。

按照 Rubin (1976)，回顾缺失机制的标准分类：当 $P(M = m \mid X,\ Y) = P(M = m)$ 时为完全随机缺失（MCAR）；当 $P(M = m \mid X,\ Y) = P\left(M = m \mid X_{\mathrm{obs}(M)}\right)$ 时为随机缺失（MAR）；既非 MAR 也非 MCAR 时为非随机缺失（MNAR）。

在缺失协变量上建立模型时，可以采用插补，也可以不采用。近期研究表明，对于几乎所有确定性插补函数 $\Phi \in \{\Phi : \mathcal{X}_{\mathrm{NA}} \to \mathcal{X} \mid \Phi\left(\widetilde{X}_{\mathrm{obs}(M)}\right) = X_{\mathrm{obs}(M)}\}$，配合一致学习器的“先插补再回归”程序是贝叶斯一致的（Le Morvan et al., 2021）。当然，插补并非总是必需。梯度提升树等树模型本来就能处理带有缺失值的协变量。为简化记号，我们用 $\widehat{f}$ 表示定义在 $\mathcal{X}_{\mathrm{NA}}$ 上的任何可能模型。

加权分割式 CP。CP 的一种流行形式是分割式 CP（Papadopoulos et al., 2002）。给定在 t 个训练数据 $\{(\widetilde{X}^i_{\mathrm{tr}}, Y^i_{\mathrm{tr}})\}_{i=1}^t$ 上预先拟合的模型 $\widehat{f}$，以及留出的校准数据集 $\{\widetilde{Z}^i := (\widetilde{X}^i, Y^i)\}_{i=1}^n$，在所有校准点上计算非一致性分数 $s : \mathcal{X}_{\mathrm{NA}} \times \mathcal{Y} \to \mathbb{R}$。在实践中，$s$ 由 $\widehat{f}$ 导出，可以直接在部分观测输入上计算，也可先应用插补策略后计算。用 $Q_\beta(F)$ 表示分布 F 的 β 水平分位数，即对 $T \sim F$，$Q_\beta(T) = \inf\{z : P\{T \le z\} \ge \beta\}$。令 $F_n := \{\sum_{i=1}^n \delta_{s(\widetilde{Z}^i)} + \delta_{+\infty}\}/(n+1)$ 为 n 个分数的经验分布，其中额外的 $\delta_{+\infty}$ 是 CP 中保证有限样本覆盖的标准约定。对任何测试点 $\widetilde{X}^{n+1} \in \mathcal{X}_{\mathrm{NA}}$，分割式 CP 预测集定义为

$$\widehat{C}_\alpha\left(\widetilde{X}^{n+1}\right) := \{y \mid s\left(\widetilde{X}^{n+1}, y\right) \le Q_{1-\alpha}(F_n)\}. \qquad (2)$$

只要 $\{\widetilde{Z}^i\}_{i=1}^{n+1}$ 可交换，该预测集就以至少 $1-\alpha$ 的概率包含 Y^{n+1}（Angelopoulos and Bates, 2021）。

然而，若这些点不可交换（如图1），则分割式 CP 无覆盖保证。Tibshirani et al. (2019) 将 CP 扩展到协变量偏移下的不可交换数据，考虑使用测试集与校准集之间的密度比对数据重新加权。其他不可交换情形包括重复抽样（Sesia et al., 2023）、时间序列（Gibbs and Candès, 2024; Zaffran et al., 2022）以及标签偏移（Si et al., 2023; Podkopaev and Ramdas, 2021）。近期，Prinster et al. (2024) 在顺序的、由反馈引发的协变量偏移下，将共形预测推广到超出可交换性范围的任意数据分布。虽然这大幅扩展了加权 CP 的适用范围，但依赖对数据生成分布（可能用图分解）的了解；在缺失数据和插补机制下，这种信息很少可得。

边际有效性（MV）与掩码条件有效性（MCV）。下文假设随机变量对 $(\widetilde{X}, Y)$ 有 $t+n+1$ 个独立同分布实现，划分为大小为 t 的训练集 Train、大小为 n 的校准集，以及一个测试点。令 $\mathrm{Cal} = \{\widetilde{Z}^i\}_{i=1}^n$ 表示校准集。任务是给定 Train、Cal 和 $\widetilde{X}^{n+1}$，为 Y^{n+1} 构造预测集。面对缺失值，我们特别关注定义2.1中的性质。

定义2.1。若产生区间 $\widehat{C}_\alpha\left(\widetilde{X}^{n+1}\right)$ 的方法满足

$$P\left(Y^{n+1} \in \widehat{C}_\alpha\left(\widetilde{X}^{n+1}\right)\right) \ge 1-\alpha,$$

则称其在水平 α 上具有 MV；若对任何满足 $P(M=m)>0$ 的 $m \in \{0,1\}^d$ 均有

$$P\left(Y^{n+1} \in \widehat{C}_\alpha\left(\widetilde{X}^{n+1}\right) \mid M^{n+1} = m\right) \ge 1-\alpha,$$

则称其在水平 α 上具有 MCV。

缺失值下的不确定性量化问题近期受到越来越多关注。总体上出现了两类不同方法。第一，Liang et al. (2024)、Gui et al. (2023) 和 Shao and Zhang (2023) 通过矩阵补全处理这一问题，提出了针对矩阵数据的新型 CP 策略，并具有强理论保证。然而，他们的假设（例如条目按伯努利分布独立缺失、即 MCAR 的随机观测模型）在典型监督学习设置中可能不成立。此外，Shao and Zhang (2023) 强调，矩阵预测与矩阵插补是本质上不同的问题：前者假定行与列均具有某种结构（如低秩或可交换性）；后

者处理固定协变量和响应，其特征通常不可交换。第二，启发本文的 Zaffran et al. (2023, 2024) 在带缺失数据增强的共形预测（CP-MDA）框架中引入两种数据增强技术（CP-MDA-Exact 和 CP-MDA-Nested），并提出更灵活的推广 CP-MDA-Nested $\star$。算法1回顾其主要算法。

在 MCAR 下，CP-MDA-Nested $\star$ 已被证明在水平 2α 上具有 MCV（Zaffran et al., 2024）。当

$$\widetilde{\mathrm{Id}}_{\mathrm{Cal}} = \{k \in \{1, \ldots, n\} : \sum_{j=1}^{d} M_j^k = \sum_{j=1}^{d} M_j^k M_j^{n+1}\}$$

时，该方法是 CP-MDA-Exact；当 $\widetilde{\mathrm{Id}}_{\mathrm{Cal}} = \{1, \ldots, n\}$ 时，则为 CP-MDA-Nested。然而，对于 CP-MDA-Exact，由于只选取比测试点缺失值更少的校准点，小校准集可能没有足够点数，这在小样本情形下不可行。另一方面，CP-MDA-Nested 通过增加额外缺失值来扩展掩码、修改测试点，这不可避免地增加保守性并产生更大的预测区间。允许更灵活目标缺失模式的 CP-MDA-Nested $\star$ 是两者的折中，但如何选择最优 $\widetilde{\mathrm{ID}}_{\mathrm{Cal}}$ 仍是问题。

算法1：CP-MDA-Nested $\star$（Zaffran et al., 2024）

输入：$\mathrm{Cal} = \{\left(\widetilde{X}^k, Y^k\right)\}_{k=1}^{n}$、非一致性分数函数 $s(\cdot, \cdot)$、显著性水平 α、测试点 $\widetilde{X}^{n+1}$、任意子抽样校准索引集 $\widetilde{\mathrm{Id}}_{\mathrm{Cal}} \subseteq \{1, \ldots, n\}$。输出：$\widehat{C}_{n,\alpha}^{\text{MDA-Nested}^\star}\left(\widetilde{X}^{n+1}\right)$。

步骤1：对每个 $k \in \widetilde{\mathrm{Id}}_{\mathrm{Cal}}$，设 $\bar{M}^k = \left[\max\left(M_i^k, M_i^{n+1}\right), \ i = 1, \ldots, d\right]$。

步骤2：按下式构造集合（原式保留）：

$$2:\ \widehat{C}_{n,\alpha}^{\text{Nested}^\star}(\widetilde{X}^{n+1}(M^{n+1})) := \Big\{y : (1-\alpha)(1+\#\widetilde{Id}_{\texttt{Cal}}) > \sum_{k \in \widetilde{Id}_{\texttt{Cal}}} \mathbf{1}\Big[s(\widetilde{X}^k(\bar{M}^k), Y^k) < s(\widetilde{X}^{n+1}(\bar{M}^k), y)\Big]\Big\}$$

与加权 CP 及偏移校正的关系。除了矩阵补全和 CP-MDA 方法，本研究还与利用重要性加权学习校正分布偏移的更广泛研究有关，例如 Bickel et al. (2009) 和 Zhou et al. (2023)。以往工作主要聚焦于改进协变量偏移下的重要性权重估计，而本文重点不同：研究如何将此类估计器集成到共形预测中，以在缺失数据机制下保持掩码条件覆盖。因此，主要创新是适配缺失性的“预插补—施加掩码—再校正”框架；我们强调插补的作用及其对校准有效性的影响。此外，还评估了不准确估计器的后果，量化不良估计如何影响预测集的误覆盖率。

3 方法

3.1 校准数据集的预插补

如图1所示，预插补确保可以应用分割式 CP。由于校准集中响应 Y 已观测到，自然可以利用它插补，以改善缺失协变量的重构。因此，我们考虑可能更一般的插补：同时利用 $X_{\text{obs}(M)}$ 和 Y，而不是只依赖 $X_{\text{obs}(M)}$ 的标准办法。后一种情形也在本文结果的覆盖范围内，但实验发现更一般的做法能提供更好的插补。本研究的关键是使用分布式（或多重）插补；此类插补（例如 MICE）已被证明具有良好结果和理想性质（Näf et al., 2024）。

因此，我们只考虑校准数据集的分布型插补策略。形式上，从部分观测数据 $\left(\widetilde{X},\ Y\right)$ 出发，得到完整版本 $(\widehat{X},\ Y)$，其中 $\widehat{X} \mid \left(\widetilde{X},\ Y\right)$ 的分布是支撑于 $\mathcal{X}$ 的某个分布。用 Q 表示 $\widehat{Z}:=(\widehat{X},\ Y)$ 的联合分布。对每个校准点应用该程序，构造插补后的校准数据集 $\{\widehat{Z}^i:=\left(\widehat{X}^i,\ Y^i\right)\}_{i=1}^{n}$，以及插补后的测试点 $\widehat{Z}^{n+1}:=\left(\widehat{X}^{n+1},\ Y^{n+1}\right)$。注意，$\widehat{X}^i$ 是 $\widetilde{X}^i$ 的插补值，故 $\widehat{X}^i_{\text{obs}(M^i)} = X^i_{\text{obs}(M^i)}$。实践中经常使用此类插补，例如 Scikit-learn 中的贝叶斯线性岭回归（Pedregosa et al., 2011）。形式定义见附录A。例如，若用贝叶斯岭回归插补，则

$$\widehat{X}_{\text{mis}(M)} \mid \left(\widetilde{X},\ Y\right) \sim \mathcal{N}(\widehat{\mu}\left(\widetilde{X},\ Y\right),\ \widehat{\Sigma}\left(\widetilde{X},\ Y\right)),$$

其中包括估计的条件均值 $\widehat{\mu}\left(\widetilde{X},\ Y\right)$ 和协方差矩阵 $\widehat{\Sigma}\left(\widetilde{X},\ Y\right)$。

全文采用下列假设。为简化记号，我们略微滥用记法：对索引集 I（例如 $I = \text{obs}(m)$），定义 $Z_I^i:=\left(X_I^i,\ Y^i\right)$、$\widehat{Z}_I^i:=\left(\widehat{X}_I^i,\ Y^i\right)$、$\widetilde{Z}_I^i:=\left(\widetilde{X}_I^i,\ Y^i\right)$。

假设1。

- （A1）校准与测试数据 $\{\widetilde{Z}^i\}_{i=1}^{n+1}$ 独立同分布。
- （A2）插补器在训练集上训练，并以同样方式应用于所有点；因此插补后的数据集 $\{\widehat{Z}^i\}_{i=1}^{n+1}$ 也独立同分布。
- （A3）预测模型仅在训练集上拟合。

这些假设在 CP 文献中是标准假设，实践中通常满足。

注1。根据假设1，全部插补点独立同分布。因此，在插补后的校准与测试数据集上使用分割式 CP 得到的任何预测集都具有 MV，因为插补保持可交换性。该结果推广了 Zaffran et al. (2023) 中仅适用于确定性插补的引理3.2。我们进一步证明，对于分布型插补，“先插补再分割式 CP”也能保证边际有效性。

对任意掩码 $m \in \{0,\ 1\}^d$，记 $\mathcal{X}_{\text{obs}(m)}:=\prod_{i\in\text{obs}(m)}\mathcal{X}_i$。对任意可测子集 $A \subseteq \mathcal{X}_{\text{obs}(m)}\times\mathcal{Y}$，定义 $Q_m(A):=Q\left(\widehat{Z}_{\text{obs}(m)} \in A\right)$，并定义原始条件测度 $P_m(A):=P\left(Z_{\text{obs}(m)} \in A \mid M = m\right)$。预插补后，条件于 M^{n+1}，校准点满足 $\widehat{Z}^i_{\text{obs}(M^{n+1})} \sim Q_{M^{n+1}}$，$i = 1,\ \ldots,\ n$，而测试点服从真实分布 $Z^{n+1}_{\text{obs}(M^{n+1})} \sim P_{M^{n+1}}$。一般地，$Q_{M^{n+1}} \neq P_{M^{n+1}}$，导致掩码条件分布偏移。这种差异限制了分割式 CP 的直接应用。

下面引入命题1，初步揭示插补对掩码条件覆盖的影响。

命题1。在假设1下，如果对测试点 $\widetilde{X}^{n+1}$ 应用分割式 CP，并使用已施加掩码的校准数据集 $\{\text{mask}\left(\widehat{X}^i,\ M^{n+1}\right),\ Y^i\}_{i=1}^n$，那么对几乎所有满足 $P(M = m) > 0$ 的 $m \in \{0,\ 1\}^d$，式（2）定义的相应预测集 $\widehat{C}_\alpha$ 满足：

$$P(Y^{n+1} \in \hat{C}_\alpha(\widetilde{X}^{n+1})|M^{n+1} = m) \geq 1 - \alpha - \left(d_{TV}(P,Q) + \mathbb{E}_P\left[\left|\frac{dP(X,Y|M=m)}{dP(X,Y)} - 1\right|\right]\right)$$

此外，若 P 为 MCAR，则：

$$P(Y^{n+1} \in \hat{C}_\alpha(X^{n+1})|M^{n+1} = m) \geq 1-\alpha-d_{TV}(P,Q)$$

证明见C.1节。该界将掩码条件误覆盖分解为两个组成部分：不完美插补所引起的误差，以及依赖掩码的抽样所造成的内在分布偏移。第一个结果表明，在 MAR 或 MNAR 下，当 $P\left(X,\ Y \mid M = M^{n+1}\right) \neq P(X,\ Y)$ 时，即使插补完美（即 $P = Q$），也未必能保证有效覆盖。第二个结果突出说明，预插补质量对于保证 MCAR 下的有效覆盖至关重要。虽然我们的下界可能较松，但结果表面上与 Le Morvan et al. (2021) 的结论相矛盾；后者聚焦于一致性和渐近贝叶斯最优性，认为“插补对回归任务并不重要”。以往结果属于一阶性质，而本方法强调预插补对不确定性和 MCV 等二阶性质的显著影响。附录A对预插补质量作了详细讨论。

3.2 掩码条件分布偏移下的加权共形预测

为解决插补造成的分布偏移，引入假设2。

假设2。$(X,\ Y) \sim P$ 的联合分布相对于 $(\widehat{X},\ Y) \sim Q$ 绝对连续，记 $\omega(x,\ y):=\frac{dP}{dQ}(x,\ y)$。

这一假设在许多常见场景下成立。例如，若缺失协变量连续分布，并采用分布型插补方法（如 MICE），那么插补后的分布相对于原始分布绝对连续。若缺失协变量是离散的或含有质量点，只要插补为这些相同的点赋予非零概率质量，条件仍然成立。实践中很容易确保这一性质，例如使用分布型插补器，或仅给插补值加一个很小的高斯扰动，从而保证插补后的分布覆盖原始分布的整个支撑集。

在假设2下，对任何满足 $P(M=m)>0$ 的掩码 $m\in\{0,1\}^d$，条件分布 P_m 相对于 Q_m 绝对连续，其似然比为 $\omega_m(x_{\mathrm{obs}(m)},y):=\frac{dP_m}{dQ_m}(x_{\mathrm{obs}(m)},y)$，并约定若 $Q_m=0$ 则 $\omega_m=0$。对所有 $i\in\{1,\ldots,n\}$，记 $\omega_m^i:=\omega_m\left(\widehat{X}^i_{\mathrm{obs}(m)},Y^i\right)$；定义权重函数 $W_m^i:\mathcal{X}_{\mathrm{obs}(m)}\times\mathcal{Y}\to\mathbb{R}$：

$$W_m^i(x_{\mathrm{obs}(m)},y):=\frac{\omega_m^i}{\sum_{j=1}^n\omega_m^j+\omega_m(x_{\mathrm{obs}(m)},y)},$$

以及

$$W_m^{n+1}(x_{\mathrm{obs}(m)},y):=\frac{\omega_m(x_{\mathrm{obs}(m)},y)}{\sum_{j=1}^n\omega_m^j+\omega_m(x_{\mathrm{obs}(m)},y)}.$$

对任意非一致性分数 $s:\mathcal{X}_{\mathrm{NA}}\times\mathcal{Y}\to\mathbb{R}$，在同一定义域上定义先插补再施加掩码的校准点分数：$S_m^i:=s\left(\mathrm{mask}\left(\widehat{X}^i,m\right),Y^i\right)$。

定理1。在假设1和2下，条件于 $M^{n+1}=m$，定义加权分割式 CP 区间：

$$\widehat{C}_\alpha^W(\widetilde{X}^{n+1})=\{y:s(\widetilde{X}^{n+1},y)\le\mathcal{Q}_{1-\alpha}(\sum_{i=1}^n W_m^i(\widetilde{X}^{n+1}_{\mathrm{obs}(m)},y)\delta_{S_m^i}+W_m^{n+1}(\widetilde{X}^{n+1}_{\mathrm{obs}(m)},y)\delta_{+\infty})\}\tag{3}$$

则对于任意缺失机制（MCAR、MAR 或 MNAR）：

$$P\left(Y^{n+1}\in\widehat{C}_\alpha^W\left(\widetilde{X}^{n+1}\right)\mid M^{n+1}=m\right)\ge1-\alpha.$$

证明见C.2节。定理1的关键认识是：当插补引入掩码条件分布偏移时，似然比 ω_m 调整分位数并确保有效覆盖。Tibshirani et al. (2019) 仅处理具有显式预测区间的协变量偏移，而本文方法需要式（3）中每个校准点的权重依赖于 y。正式的算法3见附录C；关于实现及运行时间，我们在附录B讨论实践策略。当只知道 $\omega_m(x_{\mathrm{obs}(m)},y)$ 到一个乘法常数时，定理1的结论和算法仍然适用。然而，其计算代价仍然较高，因此下面提出更高效的算法。

3.3 掩码条件分布偏移下的 ARC 共形预测

一般而言，期望预插补至少具备一定重构原始分布的能力，从而缩小插补数据（提议分布 Q_m）与完整分布（目标分布 P_m）之间的差距。因此，这一场景非常适合从 Q_m 中抽取观测，通过接受—拒绝（AR）方法以 P_m 为目标。假设 ω_m^i 由常数 $K>0$ 所界定。AR 的思想是从 $\{\widehat{Z}^i\}_{i=1}^n$ 中均匀随机抽取一个子集。具体而言，对每个点，抽样 $U^i\sim\mathcal{U}(0,1)$，当且仅当 $U^i<\omega_m^i\left(\widehat{X}^i_{\mathrm{obs}(m)},Y^i\right)/K$ 时保

留该点。正式的算法4见附录C。算法4输出被接受的 $\{(\widehat{X}^j,\ Y^j)\}_{j\in I_{\mathrm{AR}}}$，对其施加掩码 m，形成新校准数据集 $\widetilde{\mathrm{Cal}}_m=\{(\mathrm{mask}(\widehat{X}^j,\ m),\ Y^j)\}_{j\in I_{\mathrm{AR}}}$。定理2表明 $\widetilde{\mathrm{Cal}}_{M^{n+1}}$ 服从分布 $P_{M^{n+1}}$，因此可使用标准分割式 CP 校准，在测试点 $\widetilde{X}^{n+1}$ 上获得 MCV 预测集。

定理2。对任意 $m\in\{0,\ 1\}^d$，假设 ω_m^i 由常数 $K>0$ 所界定。通过算法4选出的索引 I_{AR} 生成 $\widetilde{\mathrm{Cal}}_m$。则：（a） $\widetilde{\mathrm{Cal}}_m$ 中的点是来自 P_m 的独立同分布样本；（b）分割预测集 $\widehat{C}_\alpha^{\mathrm{AR}}$（见算法4）满足

$$P\left(Y^{n+1}\in\widehat{C}_\alpha^{\mathrm{AR}}\left(\widetilde{X}^{n+1}\right)\mid M^{n+1}=m\right)\geq 1-\alpha.$$

证明及详细 ARC-CP 算法见C.3节。从理论上讲，若假设2被违反，似然比可能无法良好定义或不有界，从而影响本方法的有效性。当某些可观测点无法通过插补生成时，就会出现这种情形（讨论见附录A）；这凸显了可靠插补的重要性，也说明相近且具有相同支撑集的分布有助于确保较高接受率。

3.4 似然比 ω_m 的估计

类似于 Tibshirani et al. (2019)，我们提出算法2，用于训练似然比 ω_m 的估计器。这里概述其有效性证明。其思想是：随机生成的数据 $\widetilde{x}$ 若不含任何插补值（即 $(X_{\mathrm{obs}(m)},\ Y)\sim P_m$），则标为“1”；若含插补值（即 $(X_{\mathrm{obs}(m)},\ Y)\sim Q_m$），则标为“0”。训练一个二元分类器，用 $\widehat{p}(\widetilde{x},\ y)$ 估计概率 $P\left(C=1\mid\widetilde{X}=\widetilde{x},\ Y=y\right)$。由贝叶斯定理，得到

$$\frac{P\left(C=1\mid\widetilde{X}=\widetilde{x},\ Y=y\right)}{P\left(C=0\mid\widetilde{X}=\widetilde{x},\ Y=y\right)}=\beta\frac{dP_m}{dQ_m}\left(x_{\mathrm{obs}(m)},\ y\right),$$

其中常数 $\beta=P(C=1)/P(C=0)$。ω_m 的估计只使用校准数据集，不依赖测试值 $(x,\ y)$。

算法2：似然比估计

输入：从插补后集合 $(\widehat{X},\ M,\ Y)$ 抽取的点 $\{(x^i,\ m^i,\ y^i)\}_{i=1}^t$；随机掩码数 $q\in\mathbb{N}^\star$。输出：$\omega_m(x_{\mathrm{obs}(m)},\ y)$ 的估计器。

1. 对每个 $(x^i,\ m^i,\ y^i)$，生成 q 个随机掩码 $\{\widetilde{m}_j^i\}_{j=1}^q$。
2. 对所有 $i,\ j$ 计算 $c_j^i=1\{m^i=\widetilde{m}_j^i\}$，构造数据集 $\{(x^i,\ \widetilde{m}_j^i,\ y^i,\ c_j^i)\}$。
3. 训练概率分类器 $\widehat{p}$（例如基于直方图的 GBDT），由 $(\mathrm{mask}(\widetilde{x}^i,\ \widetilde{m}_j^i),\ y^i)$ 预测 c_j^i。
4. $\widehat{\omega}_m:=\widehat{p}(\widetilde{x}(m),\ y)/(1-\widehat{p}(\widetilde{x}(m),\ y))$ 估计 ω_m。

3.5 比率估计对覆盖率的影响

估计器的准确性可能影响加权 CP 的覆盖率，例如在高维等难以估计的情形下。因此，下面对可能的误覆盖进行理论分析，并在附录D补充实证研究以求完整。

令 $\widehat{\omega}_m(\cdot)$ 为密度比估计器，定义 $\widetilde{\omega}_m(\cdot):=\widehat{\omega}_m(\cdot)/\mathbb{E}_Q\left[\widehat{\omega}_m\left(\widehat{X}_{\mathrm{obs}(m)},\, Y\right)\right]$。若记 $d\widetilde{P}_m:=\widetilde{\omega}_m\left(\widehat{X}_{\mathrm{obs}(m)},\, Y\right) dQ_m$，则在假设2下，$\widetilde{P}_m$ 是良好定义的概率测度。

命题2。在假设2下，对任意掩码 m，若在式（3）中使用估计似然比 $\widehat{\omega}$，将结果记为 $\widehat{C}_\alpha^{\widehat{W}}$，则有

$$P\left(Y^{n+1} \in \widehat{\widetilde{C}}_\alpha^{\widehat{W}}\left(\widetilde{X}^{n+1}\right) \mid M^{n+1}=m\right) \qquad (4)$$
$$\geq (1-\alpha) - d_{TV}\left(\tilde{P}_m, P_m\right).$$

为了衡量损失，下面提出一个可以实现的覆盖率下界。

命题3。假设有一个额外数据集 $\{\left(\breve{X}^k,\, \breve{Y}^k,\, \breve{M}^k\right)\}_{k=1}^J$，其中各点独立同分布于 P。使用算法5生成两个数据集 $\{Z_P^i\}_{i=1}^{l_1} \sim P_m$ 和 $\{Z_{\widetilde{P}}^i\}_{i=1}^{l_2} \sim \widetilde{P}_m$，并令 $l=\min\left(l_1,\, l_2\right)$。通过添加标签 C，构造平衡分类样本 $\mathcal{Z}_c:=\{\left(Z_P^i,\, 1\right)\}_{i=1}^l \cup \{\left(Z_{\widetilde{P}}^i,\, 0\right)\}_{i=1}^l$。令 $\widehat{g}_m \in \operatorname{argmin}_{g\in\mathcal{G}_m} \widehat{\mathcal{R}_\gamma}\left(g_m\right)$ 为在 $\mathcal{Z}_c$ 上相对于0–1损失 γ 的、定义在 $\mathcal{G}_m$ 上的经验风险最小化器（见附录C.5），并用 $\widehat{\mathcal{R}_\gamma}(\cdot)$ 表示在 $\mathcal{Z}_c$ 上的经验风险。在正则性假设3至7下，对任意 $\epsilon>0$，以至少

$$1-\exp\left(-\frac{\epsilon^2}{2l\beta_l^2}\right)-\exp\left(-\frac{\epsilon^2 l}{2}\right)$$

的概率有：

$$P\left(Y^{n+1} \in \hat{\widetilde{C}}_\alpha^{\widetilde{W}}\left(\tilde{X}^{n+1}\right) \mid M^{n+1}=m\right)$$
$$>1-\alpha-\left(1-2\,\hat{R}_\gamma\left(\hat{g}_m\right)\right)-\epsilon-K\sqrt{\frac{V_{\mathcal{G}_m}}{l}}, \qquad (5)$$

其中 $\beta_l,\, V_{\mathcal{G}},\, K$ 定义于附录C.5。

证明见附录C.6。对于不完美的似然比估计器，命题3给出可估计的覆盖率下界，其关键可解释项是 $\frac{1}{2}-\widehat{\mathcal{R}_\gamma}\left(\widehat{g}_m\right)$。直观上，若估计器近乎准确，则判别器 $\widehat{g}_m$ 无法区分 P_m 与 $\widetilde{P}_m$，因而 $\widehat{\mathcal{R}_\gamma}\left(\widehat{g}_m\right)\approx\frac{1}{2}$。反之，若估计器很差，$\widehat{g}_m$ 很容易区分二者，使 $\widehat{\mathcal{R}_\gamma}\left(\widehat{g}_m\right)\approx 0$，从而削弱覆盖保证。注意，这要求为每个掩码 m 估计一个 g_m，看起来可能代价较高。然而，第4节证实：即使采用近似估计器，本方法在多种缺失设置下也能达到接近名义水平的覆盖率，验证其实践稳健性。

4 实验

数值研究的主要目标是：（1）验证所提方法在缺失场景下的 MCV 性质；（2）与 CP-MDA 方法比较区间宽度和覆盖性能；（3）展示分布偏移校正的必要性与实用性；（4）研究不完美似然比估计器的影响，评估其误覆盖。

为简便起见，考虑 $\mathcal{X} = \mathbb{R}^d$、$\mathcal{Y} = \mathbb{R}$。采用共形化分位数回归方法（Romano et al., 2019）定义的非一致性分数 s。具体而言，模型 $\widehat{f}$ 由迭代岭插补和一对分位数回归森林模型 $\left(\widehat{f}_{\text{low}}, \widehat{f}_{\text{high}}\right)$（Meinshausen and Ridgeway, 2006）组成，二者均在独立训练集上学习。因此定义 $s(\widetilde{x}, y) = \max\left(\widehat{f}_{\text{low}}(\widetilde{x}) - y, y - \widehat{f}_{\text{high}}(\widetilde{x})\right)$。用迭代贝叶斯岭回归（Scikit-learn 中令 `sample_posterior=True` 的 MICE）对校准集预插补。目标 $1 - \alpha$ 固定为90%，似然比 ω_m 使用基于直方图的梯度提升分类树估计。

我们报告合成数据及真实 UCI 数据集在 MCAR、MAR 和 MNAR 下的结果。[2] 按相应机制生成缺失值。对每项任务生成不同数据集并重复实验，为每个掩码的平均覆盖率和区间宽度计算置信区间。全部结果表明，本方法在保证 MCV 的同时显著减小预测区间宽度。

4.1 合成数据集实验

遵循 Zaffran et al. (2023, 2024) 生成合成数据集，因为可以推导预测区间的预言机长度并进行比较。数据满足 $Y = \beta^T X + \varepsilon$，$\beta \in \mathbb{R}^d$，其中 $d = 10$，$X \sim \mathcal{N}(\mu, \Sigma)$，$\mu = (1, \ldots, 1)^T$，$\Sigma = \rho(1, \ldots, 1)^T(1, \ldots, 1) + (1 - \rho)I_d$，$\rho = 0.8$。高斯噪声 $\varepsilon \sim \mathcal{N}(0, 1) \perp\!\!\!\perp (X, M)$，且 $\beta = (1, 2, -1, 3, -0.5, -1, 0.3, 1.7, 0.4, -0.3)^T$。为更清晰展示方法差异，使用较高的逐特征缺失概率50%。附录E还报告20%缺失率的结果，提供另一视角。预言机区间宽度定义为已知 X_M 时 MCV 区间的最小宽度，使用 Zaffran et al. (2023) 命题4.1计算。实验使用500个训练数据和100个校准数据。对1023类缺失模式（$2^{10} - 1$，不含全部缺失模式），每类生成100个测试数据。分别用每组评估对应缺失模式的覆盖率与区间宽度。每项实验重复500次。

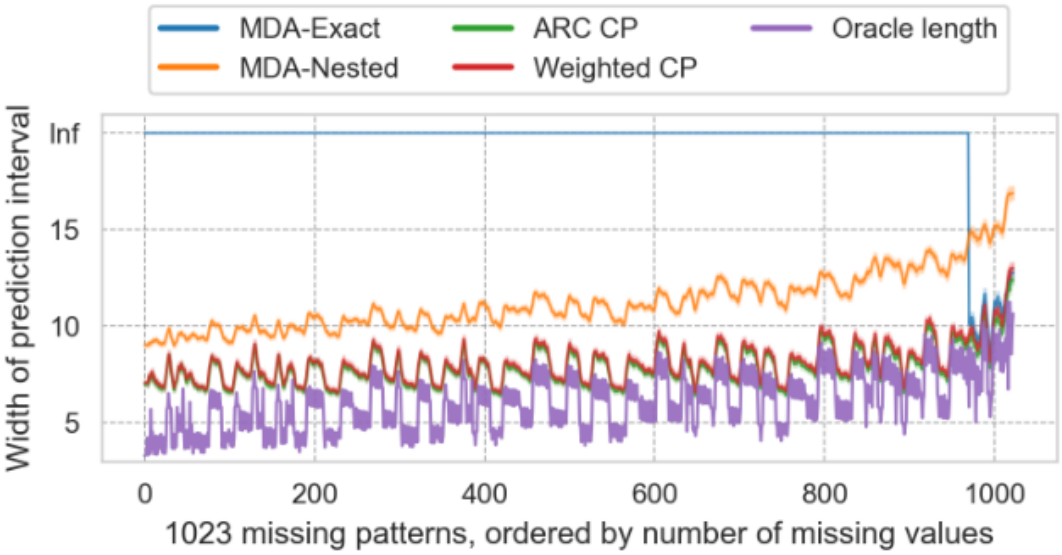


图2： MCAR 合成数据集：1023个掩码的预测区间宽度（均值及95%置信区间）。横轴为按缺失值数量排序的1023种缺失模式，纵轴为预测区间宽度；Oracle length 为预言机长度，Weighted CP 为加权 CP，ARC CP 为接受—拒绝校正CP，MDA-Exact 与 MDA-Nested 为对比方法名称。

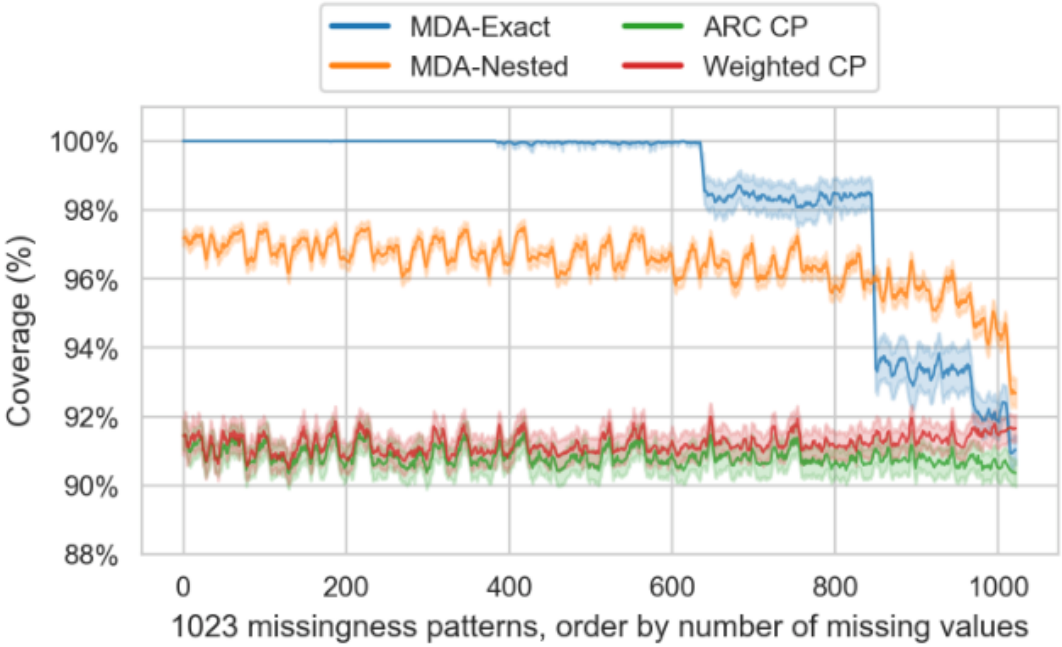


图3： MCAR 合成数据集：1023个掩码的预测覆盖率（均值及95%置信区间）。横轴为按缺失值数量排序的1023种缺失模式，纵轴为覆盖率（%）；目标水平为90%，图例译法同图2。

图2与图3按缺失模式比较本文方法与 CP-MDA 方法。为清晰起见，对曲线使用宽度为5的窗口平滑。未平滑曲线见附录A，两者得出相同结论。结果对所有缺失模式均验证了定理1和2确立的理论 MCV 保证。本方法显著减小预测区间宽度。相较之下，MDA-Exact 对某些缺失模式无法生成有信息量的预测集，而 MDA-Nested 更保守。总体而言，相对于 MDA-Nested，本文方法将预测宽度平均减小了30%。[3]

我们还使用 Schouten et al. (2018) 和 Zaffran et al. (2024) 的方法，在同一合成数据集上生成 MAR 与 MNAR（自掩码）机制。前5个协变量 $\{X_1, X_2, X_3, X_4, X_5\}$ 可能缺失，总缺失概率为20%。在 MAR 下，M 是函数 $h_{\mathrm{MAR}}(X_6, \ldots, X_{10})$；在 MNAR 下，则为 $h_{\mathrm{MNAR}}(X_1, \ldots, X_5)$。表1报告31种缺失模式的最坏情形覆盖率的95%置信区间。为每种模式生成点时必须谨慎，因为在 MAR 或 MNAR 下，$(X, Y) \mid M = m$ 没有显式形式。我们重复100次实验。两种机制下本文方法均具有 MCV，其中 ARC CP 提供最短预测区间。

表1：31个掩码上的最坏情形覆盖率（95%置信区间）及平均预测区间宽度。各单元格为“覆盖率 / 宽度”。

机制	MDA-Exact	MDA-Nested	Weighted CP	ARC CP
MAR	87.8–89.7% / 5.84	87.9–89.8% / 5.67	89.0–91.2% / 5.79	88.3–90.2% / 5.64
MNAR	87.8–89.8% / 5.74	87.8–89.8% / 5.64	89.1–91.0% / 5.79	88.5–90.3% / 5.60

朴素插补基线。还在合成数据集上评估了两种朴素策略。第一种常见方法是插补全部协变量，并在完全插补后的数据上应用标准分割式 CP。该方法的边际覆盖率达到90.6%，但违反掩码条件有效性：在 $2^{10} = 1024$ 个掩码中，超过100个掩码的条件覆盖率低于90%，最坏情形覆盖率降至61.8%。第二种策略训练分位数回归模型（采用 pinball 损失的 HistGradientBoostingRegressor），直接计算预测区间。尽管其平均区间较短（长度约为3.17），最坏情形掩码条件覆盖率却仅为71.2%。这些基线表明，朴素的插补型方法可能实现边际平均覆盖，却无法适应不同缺失模式间的异质性，对某些掩码覆盖不足。

4.2 高维数据（$d = 100$）

进一步考虑第4.1节相同数据集的100维版本。确切的 β 见E.7节。由于共有 2^{100} 个可能掩码，只均匀随机抽取1000个掩码，并为每个掩码生成100个测试点以估计其掩码条件覆盖率。

对每个掩码 m，计算预言机90%区间长度 $L_{\mathrm{oracle}}(m)$，即在真实数据生成模型下达到90%覆盖的最短可能区间。用 $L_{\mathrm{oracle}}(m)$ 作为难度指标，按这种“预言机难度”将掩码分为10个区间。对每个分组报告平均掩码条件覆盖率和平均区间长度，见表2。

表2： 100维合成设置：按预言机区间长度 $L_{\text{oracle}}(m)$ 分组的平均掩码条件覆盖率与区间长度。覆盖率和长度结果对1000个掩码取平均，共重复50次。cov 表示覆盖率，len 表示长度，WCP 表示加权 CP，Nested 表示 MDA-Nested。

Bin of $L_{\text{oracle}}(m)$	ARC-CP cov	ARC-CP len	WCP cov	WCP len	Nested cov	Nested len
$[17.74, 20.39]$	0.911	27.92	0.884	27.14	0.926	29.58
$[20.39, 21.16]$	0.910	27.99	0.885	27.20	0.927	29.76
$[21.16, 21.57]$	0.910	28.04	0.885	27.16	0.928	29.90
$[21.57, 22.02]$	0.911	28.08	0.881	27.08	0.927	29.91
$[22.02, 22.40]$	0.911	28.20	0.882	27.17	0.928	30.04
$[22.40, 22.77]$	0.911	28.14	0.884	27.21	0.927	30.17
$[22.77, 23.14]$	0.910	28.17	0.884	27.33	0.927	30.20
$[23.14, 23.64]$	0.911	28.28	0.883	27.36	0.926	30.35
$[23.64, 24.27]$	0.910	28.25	0.883	27.27	0.928	30.53
$[24.27, 26.73]$	0.910	28.37	0.882	27.42	0.928	30.87

在全部预言机难度分组中，ARC-CP 的覆盖率约为91%，平均区间长度为27.9至28.4，且从不产生无限区间；MDA-Exact 则总因样本有限而失败。总体而言，在这一100维情形中，ARC-CP 在覆盖率、效率和运行时间之间取得了有利平衡。

4.3 真实数据集实验

来自 UCI 数据库的 Concrete 数据（Yeh, 1998，CC BY 4.0 许可）： 目标是利用8个特征预测抗压强度。选取630个训练数据和100个校准数据。在 MCAR 下，以50%的逐特征缺失率，为每个掩码生成100个测试数据，共产生255种模式（$2^8 - 1$）。全部四种方法在全部缺失模式下均达到90%覆盖率。[4] 相比 MDA-Nested，ARC CP 将平均宽度减小12%，加权 CP 减小10%。

在 MAR 下，前4个特征可能缺失，缺失率依赖其他4个特征，总缺失率为20%。本文方法具有 MCV，各方法最坏情形覆盖率为：MDA-Exact $89.1\% \pm 1.64\%$，MDA-Nested $90.8\% \pm 1.43\%$，ARC CP $90.1\% \pm 1.63\%$，加权 CP $90.6\% \pm 1.42\%$。ARC CP 产生最窄的平均区间，相比 MDA-Nested 将宽度减小7.5%（见表6）。附录E.2还提供三个维度更高的真实数据集。它们均显示本文方法具有有效覆盖。

4.4 权重校正的消融研究

为展示校正方法的有效性，在相同合成数据上进行不使用校正的实验：即先预插补校准集，再施加测试点的掩码，而忽略分布偏移。详细实验见E.3节。结果表明，三种方法的区间宽度非常相近（图8和9）；但不校正时，最坏掩码条件覆盖率约为89%，说明若没有适当的权重或接受操作进行校正，分布偏移就会导致覆盖不足。这证实了缺失数据下应用 CP 时校正的必要性。

4.5 不完美估计器的影响

准确估计似然比从来都不是简单的事。通过合成案例研究（见附录D），显式评估似然比估计器质量对覆盖率的影响。在真实密度比已知的高斯生成模型中，我们表明：（i）不准确估计器可能导致覆盖不足或覆盖过度；（ii）经验覆盖率与估计器质量（例如其与真实比率的皮尔逊相关系数）高度相关。值得注意的是，当相关系数超过0.3时，覆盖率接近目标 $1-\alpha$。这些结果说明，可能不需要精确的密度比数值；重要的是保持似然的相对排序。对估计噪声的这种容忍使该方法在实践中具有稳健性。

5 结论与未来工作

本文处理了在缺失值情况下构造预测集，同时保持 MV 和 MCV 的挑战。我们引入两种新策略：掩码条件加权 CP 和 ARC CP，它们克服了现有方法在包括 MCAR、MAR 和 MNAR 在内的一般缺失机制下的关键局限。具体而言，通过利用广义分布型插补和加权 CP，解决了 CP-MDA-Nested 的保守性以及 CP-MDA-Exact 不切实际的样本量要求。

合成和真实数据集上的广泛实验展示了方法有效性。与已有方法相比，本文方法在保持所需有效性性质的同时，显著减小了预测集宽度。尤其是 ARC 方法在计算效率和预测信息量之间取得了有竞争力的平衡。在分布偏移情形下，相比传统加权 CP，它将计算时间减少90%（见E.1节），因而有望成为替代候选方法。

总之，我们针对缺失数据下的共形预测提出名为“预插补—施加掩码—再校正”的新框架，以及在一般缺失机制下保证 MCV 的两种校正方法。未来工作包括：在似然比估计误差或违反假设2时推导更紧的稳健性界，以及开发适用于高维或不完美插补的自适应策略。

致谢

感谢匿名审稿人富有洞见的意见和建议，帮助改进了本文。本项目获得欧盟“地平线欧洲”研究与创新计划 Marie Skłodowska-Curie COFUND 资助协议第101127936号（DeMythif.AI）的资助。本研究还获得 DATAIA 融合研究所的支持，该研究所是由巴黎萨克雷大学实施的“未来投资计划”（Programme d’Investissement d’Avenir，ANR-17-CONV-0003）的一部分。

参考文献

Anastasios N Angelopoulos 和 Stephen Bates. 共形预测与无分布不确定性量化入门（A gentle introduction to conformal prediction and distribution-free uncertainty quantification）. arXiv 预印本 arXiv:2107.07511, 2021.

Anastasios N Angelopoulos, Stephen Bates 等. 共形预测：简明入门（Conformal prediction: A gentle introduction）. Foundations and Trends® in Machine Learning, 16(4):494–591, 2023.

Rina Foygel Barber, Emmanuel J Candes, Aaditya Ramdas 和 Ryan J Tibshirani. 超越可交换性的共形预测（Conformal prediction beyond exchangeability）. The Annals of Statistics, 51(2):816–845, 2023.

Dimitris Bertsimas, Arthur Delarue 和 Jean Pauphilet. 用于含缺失数据预测的简单插补规则：理论保证与经验性能（Simple imputation rules for prediction with missing data: Theoretical guarantees vs. empirical performance）. Transactions on Machine Learning Research, 2024.

Steffen Bickel, Michael Brückner 和 Tobias Scheffer. 协变量偏移下的判别学习（Discriminative learning under covariate shift）. Journal of Machine Learning Research, 10(9), 2009.

Olivier Bousquet 和 André Elisseeff. 稳定性与泛化（Stability and generalization）. Journal of machine learning research, 2(Mar):499–526, 2002.

Tianyu Du, Luca Melis 和 Ting Wang. Remasker：利用掩码自编码进行表格数据插补（Remasker: Imputing tabular data with masked autoencoding）. arXiv 预印本 arXiv:2309.13793, 2023.

Bat-Sheva Einbinder, Shai Feldman, Stephen Bates, Anastasios N Angelopoulos, Asaf Gendler 和 Yaniv Romano. 共形预测对标签噪声的鲁棒性（Label noise robustness of conformal prediction）. Journal of Machine Learning Research, 25(328):1–66, 2024.

Tlamelo Emmanuel, Thabiso Maupong, Dimane Mpoeleng, Thabo Semong, Banyatsang Mphago 和 Oteng Tabona. 机器学习中的缺失数据综述（A survey on missing data in machine learning）. Journal of Big data, 8:1–37, 2021.

Hadi Fanaee-T. 共享单车（Bike Sharing）. UCI Machine Learning Repository, 2013. DOI: https://doi.org/10.24432/C5W894.

Shai Feldman 和 Yaniv Romano. 利用特权信息的鲁棒共形预测（Robust conformal prediction using privileged information）. arXiv 预印本 arXiv:2406.05405, 2024.

Vincent Fortuin, Dmitry Baranchuk, Gunnar Rätsch 和 Stephan Mandt. Gp-vae：深度概率时间序列插补（Gp-vae: Deep probabilistic time series imputation）. 载 International conference on artificial intelligence and statistics, 第1651–1661页. PMLR, 2020.

Isaac Gibbs 和 Emmanuel J Candès. 任意分布偏移下用于在线预测的共形推断（Conformal inference for online prediction with arbitrary distribution shifts）. Journal of Machine Learning Research, 25(162):1–36, 2024.

Yu Gui, Rina Barber 和 Cong Ma. 共形化矩阵补全（Conformalized matrix completion）. Advances in Neural Information Processing Systems, 36:4820–4844, 2023.

Daniel Jarrett, Bogdan C Cebere, Tennison Liu, Alicia Curth 和 Mihaela van der Schaar. Hyperimpute：具有自动模型选择的广义迭代插补（Hyperimpute: Generalized iterative imputation with automatic model selection）. 载 International Conference on Machine Learning, 第9916–9937页. PMLR, 2022.

Hyun Kang. 缺失数据的预防与处理（The prevention and handling of the missing data）. Korean journal of anesthesiology, 64(5):402–406, 2013.

Marine Le Morvan, Julie Josse, Erwan Scornet 和 Gaël Varoquaux. 含缺失值预测中的好插补是什么？（What’sa good imputation to predict with missing values?）. Advances in Neural Information Processing Systems, 34:11530–11540, 2021.

Ziyi Liang, Tianmin Xie, Xin Tong 和 Matteo Sesia. 用于矩阵补全的结构化共形推断及其在群组推荐系统中的应用（Structured conformal inference for matrix completion with applications to group recommender systems）. arXiv 预印本 arXiv:2404.17561, 2024.

Jingchen Liu, Andrew Gelman, Jennifer Hill, Yu-Sung Su 和 Jonathan Kropko. 论迭代插补的平稳分布（On the stationary distribution of iterative imputations）. Biometrika, 101(1):155–173, 2014.

Angel David Reyero Lobo, Alexis Ayme, Claire Boyer 和 Erwan Scornet. 含缺失数据的线性分类入门（A primer on linear classification with missing data）. 载 The 28th International Conference on Artificial Intelligence and Statistics, 2025.

Chao Ma, Sebastian Tschiatschek, Richard Turner, José Miguel Hernández-Lobato 和 Cheng Zhang. Vaem：异质混合类型数据的深度生成模型（Vaem: a deep generative model for heterogeneous mixed type data）. Advances in Neural Information Processing Systems, 33:11237–11247, 2020.

Pascal Massart 和 Élodie Nédélec. 统计学习的风险界（Risk bounds for statistical learning）. The Annals of Statistics, 34(5), 2006年10月. ISSN 0090-5364. doi: 10.1214/009053606000000786.

Pierre-Alexandre Mattei 和 Jes Frellsen. Miwae：不完整数据集的深度生成建模与插补（Miwae: Deep generative modelling and imputation of incomplete data sets）. 载 International conference on machine learning, 第4413–4423页. PMLR, 2019.

Colin McDiarmid 等. 关于有界差分方法（On the method of bounded differences）. Surveys in combinatorics, 141(1):148–188, 1989.

Nicolai Meinshausen 和 Greg Ridgeway. 分位数回归森林（Quantile regression forests）. Journal of machine learning research, 7(6), 2006.

Jeffrey Näf, Erwan Scornet 和 Julie Josse. MAR 缺失机制下，什么是好的插补？（What is a good imputation under mar missingness?）. arXiv 预印本 arXiv:2403.19196, 2024.

Alfredo Nazabal, Pablo M Olmos, Zoubin Ghahramani 和 Isabel Valera. 使用 VAE 处理不完整的异质数据（Handling incomplete heterogeneous data using vaes）. Pattern Recognition, 107:107501, 2020.

Harris Papadopoulos, Kostas Proedrou, Volodya Vovk 和 Alex Gammerman. 用于回归的归纳置信机器（Inductive confidence machines for regression）. 载 Machine learning: ECML 2002: 13th European conference on machine learning Helsinki, Finland, August 19–23, 2002 proceedings 13, 第345–356页. Springer, 2002.

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg 等. Scikit-learn：Python 中的机器学习（Scikit-learn: Machine learning in python）. the Journal of machine Learning research, 12:2825–2830, 2011.

Aleksandr Podkopaev 和 Aaditya Ramdas. 标签偏移下分类任务的无分布不确定性量化（Distribution-free uncertainty quantification for classification under label shift）. 载 Uncertainty in artificial intelligence, 第844–853页. PMLR, 2021.

Drew Prinster, Samuel Don Stanton, Anqi Liu 和 Suchi Saria. 任何数据分布都存在共形有效性保证（以及如何找到这些保证）（Conformal validity guarantees exist for any data distribution (and how to find them)）. 载 Forty-first International Conference on Machine Learning, 2024.

Michael Redmond 和 Alok Baveja. 支持警察部门间合作式信息共享的数据驱动软件工具（A data-driven software tool for enabling cooperative information sharing among police departments）. European Journal of Operational Research, 141(3):660–678, 2002.

Lijuan Ren, Tao Wang, Aicha Sekhari Seklouli, Haiqing Zhang 和 Abdelaziz Bouras. 缺失值的主要挑战与方法综述（A review on missing values for main challenges and methods）. Information Systems, 第102268页, 2023.

Yaniv Romano, Evan Patterson 和 Emmanuel Candes. 共形化分位数回归（Conformalized quantile regression）. Advances in neural information processing systems, 32, 2019.

Donald B Rubin. 推断与缺失数据（Inference and missing data）. Biometrika, 63(3):581–592, 1976.

Donald B Rubin. 十八年多之后的多重插补（Multiple imputation after 18+ years）. Journal of the American statistical Association, 91(434):473–489, 1996.

Rianne Margaretha Schouten, Peter Lugtig 和 Gerko Vink. 为模拟生成缺失值：一种多变量删失过程（Generating missing values for simulation purposes: a multivariate amputation procedure）. Journal of Statistical Computation and Simulation, 88(15):2909–2930, 2018.

Matteo Sesia, Stefano Favaro 和 Edgar Dobriban. 使用离散草图数据的共形频率估计，并为不同查询提供覆盖保证（Conformal frequency estimation using discrete sketched data with coverage for distinct queries）. Journal of Machine Learning Research, 24(348):1–80, 2023.

Matteo Sesia, YX Rachel Wang 和 Xin Tong. 含噪声标签的自适应共形分类（Adaptive conformal classification with noisy labels）. Journal of the Royal Statistical Society Series B: Statistical Methodology, 第qkae114页, 2024.

Meijia Shao 和 Yuan Zhang. 任意缺失模式下的无分布矩阵预测（Distribution-free matrix prediction under arbitrary missing pattern）. arXiv 预印本 arXiv:2305.11640, 2023.

Wenwen Si, Sangdon Park, Insup Lee, Edgar Dobriban 和 Osbert Bastani. 标签偏移下的 PAC 预测集（Pac prediction sets under label shift）. arXiv 预印本 arXiv:2310.12964, 2023.

Jake A Soloff, Rina Foygel Barber 和 Rebecca Willett. Bagging 提供无需假设的稳定性（Bagging provides assumption-free stability）. Journal of Machine Learning Research, 25(131):1–35, 2024.

Daniel J Stekhoven 和 Peter Bühlmann. Missforest：混合类型数据的非参数缺失值插补（Missforest—non-parametric missing value imputation for mixed-type data）. Bioinformatics, 28(1):112–118, 2012.

Ryan J Tibshirani, Rina Foygel Barber, Emmanuel Candes 和 Aaditya Ramdas. 协变量偏移下的共形预测（Conformal prediction under covariate shift）. Advances in neural information processing systems, 32, 2019.

Aad W Van Der Vaart 和 Jon A Wellner. 弱收敛（Weak convergence）. 载 Weak convergence and empirical processes: with applications to statistics, 第16–28页. Springer, 1996.

Vladimir Vapnik. 统计学习理论的本质（The nature of statistical learning theory）. Springer science & business media, 2013.

Vladimir Vovk, Alexander Gammerman 和 Glenn Shafer. 随机世界中的算法学习（Algorithmic learning in a random world）, 第29卷. Springer, 2005.

I-Cheng Yeh. 混凝土抗压强度（Concrete Compressive Strength）. UCI Machine Learning Repository, 1998. DOI: https://doi.org/10.24432/C5PK67.

Jinsung Yoon, James Jordon 和 Mihaela Schaar. Gain：使用生成对抗网络进行缺失数据插补（Gain: Missing data imputation using generative adversarial nets）. 载 International conference on machine learning, 第5689–5698页. PMLR, 2018.

Seongwook Yoon 和 Sanghoon Sull. Gamin：用于高度缺失数据的生成对抗多重插补网络（Gamin: Generative adversarial multiple imputation network for highly missing data）. 载 Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 第8456–8464页, 2020.

Margaux Zaffran, Olivier Féron, Yannig Goude, Julie Josse 和 Aymeric Dieuleveut. 时间序列的自适应共形预测（Adaptive conformal predictions for time series）. 载 International Conference on Machine Learning, 第25834–25866页. PMLR, 2022.

Margaux Zaffran, Aymeric Dieuleveut, Julie Josse 和 Yaniv Romano. 含缺失值的共形预测（Conformal prediction with missing values）. 载 International Conference on Machine Learning, 第40578–40604页. PMLR, 2023.

Margaux Zaffran, Julie Josse, Yaniv Romano 和 Aymeric Dieuleveut. 含缺失协变量的预测不确定性量化（Predictive uncertainty quantification with missing covariates）, 2024.

Helen Zhou, Sivaraman Balakrishnan 和 Zachary Lipton. 缺失机制偏移下的域适应（Domain adaptation under missingness shift）. 载 International Conference on Artificial Intelligence and Statistics, 第9577–9606页. PMLR, 2023.

Xiaofan Zhou, Baiting Chen, Yu Gui 和 Lu Cheng. 共形预测：数据视角（Conformal prediction: A data perspective）. ACM Computing Surveys, 2025.

Jian Zhu 和 Trivellore E Raghunathan. 序贯回归多重插补算法的收敛性质（Convergence properties of a sequential regression multiple imputation algorithm）. Journal of the American Statistical Association, 110(511):1112–1124, 2015.

核查清单

1. 对于所提出的所有模型与算法，请核查是否包含：
    - 1. 对数学设定、假设、算法和／或模型的清晰描述。[是]
    - 1. 对各算法的性质及复杂度（时间、空间、样本量）的分析。[是] 见表3。
    - 1. （可选）匿名化源代码，并说明包括外部库在内的所有依赖项。[是] 我们将随补充材料一同上传。
2. 对于任何理论主张，请核查是否包含：
    - 1. 所有理论结果的完整假设集合。[是]
    - 1. 所有理论结果的完整证明。[是]
    - 1. 对所有假设的清晰解释。[是]
3. 对于呈现实验结果的所有图表，请核查是否包含：
    - 1. 复现主要实验结果所需的代码、数据和说明（放在补充材料中或提供 URL）。[是]
    - 1. 所有训练细节（例如，数据划分、超参数及其选择方式）。[是]
    - 1. 对具体度量或统计量以及误差条的清晰定义（例如，多次运行实验后，相对于随机种子的变化）。[是]
    - 1. 对所用计算基础设施的描述（例如，GPU 类型、内部集群或云服务提供商）。[是]
4. 如果使用已有资源（例如，代码、数据、模型），或整理／发布新资源，请核查是否包含：
    - 1. 若使用已有资源，对其创建者的引用。[是]
    - 1. 资源的许可信息（若适用）。[是]
    - 1. 将新资源放在补充材料中或以 URL 形式提供（若适用）。[是]
    - 1. 有关数据提供者／整理者同意的信息。[不适用]
    - 1. 对敏感内容的讨论（若适用），例如个人身份识别信息或冒犯性内容。[不适用]
5. 如果使用了众包或开展了以人为受试对象的研究，请核查是否包含：
    - 1. 向参与者提供的完整说明文本和屏幕截图。[不适用]
    - 1. 对参与者潜在风险的描述，以及机构审查委员会（IRB）批准的链接（若适用）。[不适用]
    - 1. 支付给参与者的估计时薪以及参与者报酬的总支出。[不适用]

补充材料

A 关于校准数据集预插补质量的讨论

在我们的工作中，只有校准数据集需要插补。对于在训练数据上训练得到的基模型 $\widehat{f} : \mathcal{X}_{\mathrm{NA}} \to \mathcal{Y}$，它可以隐式包含插补（例如，$\widehat{f}$ 可以是神经网络 $f_{\mathrm{NN}} : \mathcal{X} \to \mathcal{Y}$ 与插补函数 φ 的复合，即 $\widehat{f} = f_{\mathrm{NN}} \circ \varphi$），也可以只是一个不进行插补的树模型。因此，我们的方法可以与任意基模型 $\widehat{f}$ 集成。

然而，我们方法中的一个关键步骤是对校准数据集进行预插补。本节讨论校准数据集预插补质量对于不确定性量化的重要性。我们首先回顾先进的缺失值插补方法，然后说明采用分布型插补的理由。最后，我们通过实验比较确定性插补方法与分布型插补方法的性能。

插补方法大致可以分为三类（Jarrett 等，2022）：**(1) 简单值插补**：均值插补、中位数插补等方法使用具有代表性的数值填补缺失数据，而不重构原始数据分布。**(2) 迭代插补**（Liu 等，2014；Zhu 和 Raghunathan，2015）：例如 MICE（Rubin，1996）、Missforest（Stekhoven 和 Bühlmann，2012）等。在这些方法中，每个特征的条件分布都根据其余所有特征来估计，并使用这些单变量模型，以轮流更新的方式插补缺失值，直到收敛。近期，Näf 等（2024）利用分布随机森林（DRF）逼近条件分布的能力，提出了 mice-Distributional Random Forest（DRF），并指出，在 MAR 条件下，使用分布型插补函数而非确定性插补非常重要；这是他们提出的“好的插补候选方法”应满足的三项标准之一。所有这些方法都需要为每个变量预先定义函数形式。**(3) 深度生成模型**：例如基于 GAN 的插补（Yoon 等，2018；Yoon 和 Sull，2020），或基于 VAE 的插补（Du 等，2023；Nazabal 等，2020；Ma 等，2020；Mattei 和 Frellsen，2019；Fortuin 等，2020）。这些方法可以利用深度函数逼近器带来的更强学习能力和更高学习效率，并通过参数摊销来捕捉协变量之间的相关性（Jarrett 等，2022）。尽管功能强大，这些方法通常需要大型数据集，而且计算代价可能很高。

但是，对于 X 中存在缺失值的 $X - Y$ 型数据集，传统插补仅被构造为一个以 $X_{\mathrm{obs}(M)}$ 为输入、预测缺失部分 $X_{\mathrm{mis}(M)}$ 的函数，这限制了插补在更一般场景中的潜力。在这一定义下，对于“先插补、后回归”的任务，Le Morvan 等（2021）已经证明了“插补并不重要”：其含义是，对于几乎所有插补函数，通用学习器都能达到贝叶斯最优。然而，对于不确定性量化与覆盖保证，这还不够，因此我们提出更广义的插补定义，将其扩展为分布型插补和广义分布型插补。我们将说明，如果采用广义分布型插补，一个好的插补器可以帮助预测区间达到目标覆盖率。

在正文中，我们没有正式定义插补函数，而只是使用 $(\widetilde{X}, Y)$ 表示插补后的点。在本部分，我们形式化定义以下三种插补函数，并使用 φ 表示插补函数，使得 $\widetilde{X} \overset{d}{=} \varphi\left(\widetilde{X}\right)$ 或 $\widetilde{X} \overset{d}{=} \varphi\left(\widetilde{X}, Y\right)$，具体取决于 φ 是否以 Y 为输入。

定义 A.1（确定性插补函数（Dt））。如果 $\varphi_{Dt} : \mathcal{X}_{\mathrm{NA}} \to \mathcal{X}$ 对所有 $x \in \mathcal{X},\ m \in \{0, 1\}^d$ 满足

$$\varphi_{Dt}(\mathrm{mask}(x, m))_{\mathrm{obs}(m)} = x_{\mathrm{obs}(m)},$$

则称其为确定性插补函数。

定义 A.2（分布型插补函数（Ds））。 设 $\mathcal{Z}(\mathcal{X})$ 表示取值于 $\mathcal{X}$ 的随机变量空间。如果函数 $\varphi_{Ds} : \mathcal{X}_{\mathrm{NA}} \to \mathcal{Z}(\mathcal{X})$ 对所有 $x \in \mathcal{X},\ m \in \{0,\ 1\}^d$ 满足

$$P(\varphi_{Ds}(\mathrm{mask}\,(x,\ m))_{\mathrm{obs}\,(m)} = x_{\mathrm{obs}\,(m)}) = 1,$$

则称其为分布型插补函数。

随后，协变量的缺失部分 $X_{\mathrm{mis}\,(M)}$ 由 $\varphi_{Ds}(X)_{\mathrm{mis}\,(M)}$ 插补。

译注：此处原文的输入写作 X，没有波浪号；按原文保留。

分布型插补函数可以看作多重插补（MI）（Rubin，1996）的第一步；多重插补会融合多个估计。

定义 A.3（广义分布型插补函数（GDs））。 如果函数 $\varphi_{GDs} : \mathcal{X}_{\mathrm{NA}} \times \mathcal{Y} \to \mathcal{Z}(\mathcal{X})$ 对所有 $x \in \mathcal{X},\ m \in \{0,\ 1\}^d,\ y \in \mathcal{Y}$ 满足

$$P(\varphi_{GDs}\big(\mathrm{mask}\,(x,\ m),\ y\big)_{\mathrm{obs}\,(m)} = x_{\mathrm{obs}\,(m)}) = 1,$$

则称其为广义分布型插补函数。

随后，协变量的缺失部分 $X_{\mathrm{mis}\,(M)}$ 由 $\varphi_{GDs}\big(\widetilde{X}\,(M),\ Y\big)_{\mathrm{mis}\,(M)}$ 插补。

这里，我们给出一个额外实验，比较确定性插补和分布型插补在合成数据集（第4.1节）上的效果。为模拟**确定性插补**，我们在迭代贝叶斯岭回归插补中关闭后验采样，从而得到固定的插补值。

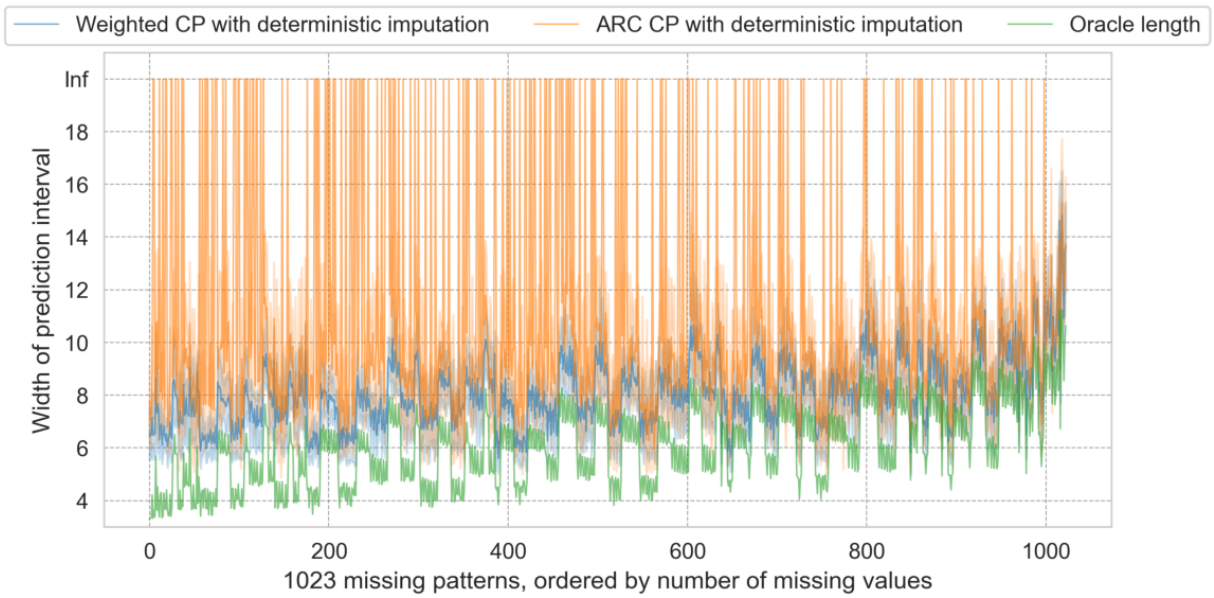


图4： 合成数据集：采用确定性插补时，针对1023种缺失模式的预测区间宽度均值及99%置信区间。图中蓝色为“采用确定性插补的 Weighted CP”，橙色为“采用确定性插补的 ARC CP”，绿色为“Oracle 长度”；纵轴为“预测区间宽度”，其中 Inf 表示无穷大；横轴为“1023种缺失模式，按缺失值数量排序”。

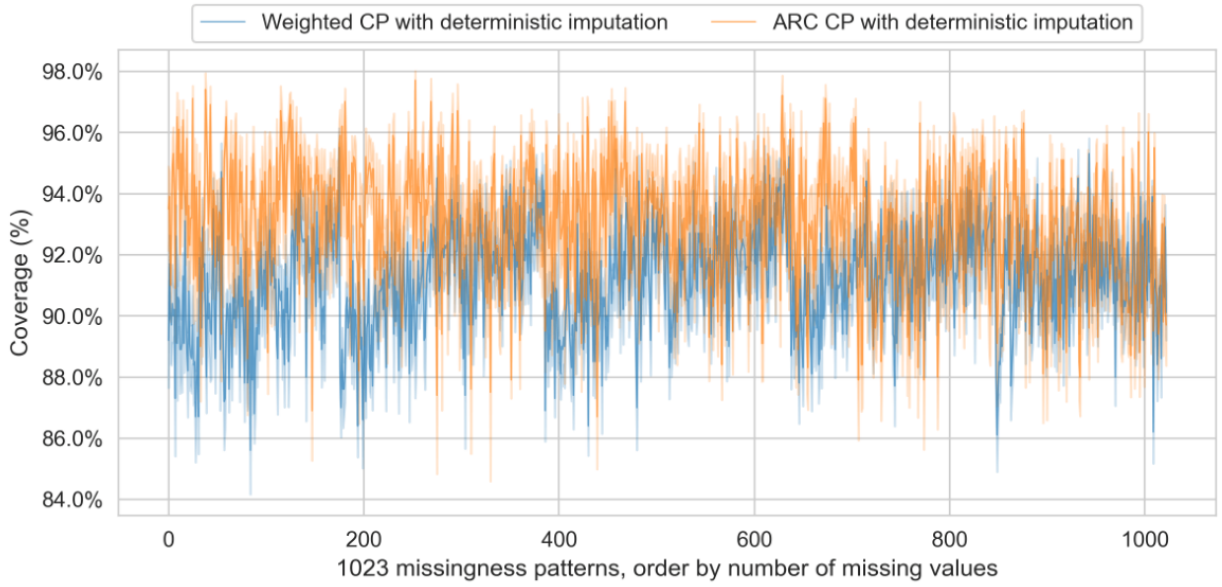


图5： 合成数据集：采用确定性插补时，针对1023种缺失模式的预测覆盖率均值及99%置信区间。图中蓝色为“采用确定性插补的 Weighted CP”，橙色为“采用确定性插补的 ARC CP”；纵轴为“覆盖率（%）”，横轴为“1023种缺失模式，按缺失值数量排序”。

与图2和图3相比，我们从图4和图5观察到：如果使用确定性插补替代分布型插补，同时保持其他条件不变，结果可能不够理想。这一结果符合我们的预期：若使用确定性函数插补缺失值，所得插补分布将缺乏连续性，违反假设2中的绝对连续性假设，从而可能导致两个问题：

1. 对于 **Weighted CP**：若某一点的似然比 ω_m 很大，例如 $\omega_m\left(x_m^j,\, y^j\right) \approx \infty$，则根据定理1的定义，很可能有 $p_m^j = 1$。因此，按式（3）计算加权分位数时，加权分位数将等于 s_m^j。换言之，只要有一个似然比极大，权重就很容易受到该极端值影响，从而扭曲加权分位数。这种扭曲可能造成分位数计算不准确，并在许多实际场景中无法保证 MCV。
2. 对于 **ARC CP**：若不满足绝对连续性条件，意味着似然比无界（即 $K \to \infty$），则大多数点很可能会在接受-拒绝步骤中被拒绝。这将导致校准数据集中的样本数不足，从而可能使某些缺失模式下的预测区间具有无穷宽度。

这些结果表明，插补质量在我们的框架中发挥着至关重要的作用。如果插补质量较差，或采用纯粹的确定性插补，则所得方法无论在理论上还是实践中都会向 CP-MDA-Exact 退化，因为插补后的校准数据不再提供超出已观测部分的额外分布信息。相反，校准良好的分布型插补使我们的方法能够利用校准数据中更丰富的信息，有效校正掩码引起的分布偏移，并获得更窄且具有有效覆盖保证的预测区间。因此，预插补步骤不仅是一种预处理选择，更是决定我们不确定性量化框架效率与鲁棒性的关键组成部分。

A.1 绝对连续性的充分条件

本节给出一个简单的充分条件，以确保在分布型插补下，假设2中的绝对连续性假设成立。

命题4（分布型插补下绝对连续性的充分条件）。令 P_m 为 $\left(X_{\mathrm{obs}(m)},\ Y\right) \mid M = m$ 的真实分布，令 Q_m 为第3.1节所定义的插补后数据对 $\left(\widehat{X}_{\mathrm{obs}(m)},\ Y\right)$ 的分布。假设 P_m 和 Q_m 相对于 $\mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y}$ 上的共同支配测度 μ（连续分量使用 Lebesgue 测度，离散分量使用计数测度）分别存在密度 p_m 和 q_m，即 $P_m = p_m \cdot \mu$ 且 $Q_m = q_m \cdot \mu$。那么，P_m 关于 Q_m 绝对连续，当且仅当

$$\forall\ \left(x_{\mathrm{obs}},\ y\right) \text{ such that } p_m\left(x_{\mathrm{obs}},\ y\right) > 0, \qquad q_m\left(x_{\mathrm{obs}},\ y\right) > 0. \qquad (\star)$$

条件（$\star$）意味着 P_m 的支撑包含于 Q_m 的支撑。特别地，以下每种情形都满足（$\star$）：

- **连续情形**。P_m 具有一个支撑在 $\mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y}$ 某个子集上的密度，且没有点质量；插补机制诱导出的密度 q_m 在同一支撑上严格为正（例如，基于高斯或贝叶斯回归的 MICE，其连续支撑覆盖整个定义域）。
- **离散情形**。P_m 是离散分布，支撑在有限或可数的原子集合上。此时，只要插补分布对每个此类原子都赋予非零概率，（$\star$）就成立。
- **混合情形**。P_m 同时具有连续部分和原子，而插补分布在连续支撑上具有正密度，并对所有原子赋予非零质量。

在上述三种情形中，似然比

$$\omega_m(z) = \frac{dP_m}{dQ_m}(z)$$

在 P_m 支撑中的所有 z 处都有良好定义。

> 译注：命题4的原文将密度条件与似然比的定义均写成逐点陈述，此处忠实保留。严格的测度论表述通常应按相应测度的“几乎处处”理解；原文未加这一限定。

因此，假设 $P_m \ll Q_m$ 与分布型插补器的选择有关。对于 MAR/MNAR 情形，缺失本身不会直接破坏 P_m 与 Q_m 之间的绝对连续性。在实践中，MAR/MNAR 使条件分布更难估计，这可能增大似然比 ω_m，从而增大 P_m 与 Q_m 之间的散度。然而，当所有协变量在 $\mathcal{X}$ 上连续时，大多数现代分布型插补方法都会使 $P_m \ll Q_m$ 成立；一个典型情形是使用 MICE 且 Q_m 为高斯分布。

此外，正如我们在附录 A 末尾（图4和图5）强调的那样，确定性插补器（例如均值插补）可能违反这一条件，导致我们的方法失效；而简单的分布型插补器（例如 MICE）则能产生稳定的结果。

B Weighted CP 的实现细节

正如正文所讨论的，一般形式的加权 CP 在推断过程中涉及测试标签 y，这给高效实现带来了挑战。不过，如表3所示，加权 CP 方法仍然可以在实践中成功实现。我们提出了一系列优化，显著降低计算负担，使其成为可行的选择。这些优化如下。

B.1 搜索区间边界

通常可以合理地假设，式（3）定义的预测集是一个区间 $\left[B_l,\ B_u\right]$；否则，该预测集也包含于这样一个区间中。借助这一假设，我们只需搜索预测区间的下界与上界，而无须在整个 $\mathcal{Y}$ 上执行完整的网格搜索，从而降低计算成本。

B.2 粗网格搜索

为进一步加速搜索，我们引入步长 h，并将搜索网格定义为：

$$\mathcal{G} = \{y_{\min},\ y_{\min} + h,\ y_{\min} + 2h,\ \ldots,\ y_{\max}\}.$$

随后，将估计的边界定义为：

$$\widehat{B}_l = \min\left\{y \in \mathcal{G} \mid y \notin \widehat{C}_\alpha(x),\ \ y + h \in \widehat{C}_\alpha(x)\right\},$$

$$\widehat{B}_h = \max\left\{y \in \mathcal{G} \mid y \in \widehat{C}_\alpha(x),\ \ y + h \notin \widehat{C}_\alpha(x)\right\}.$$

这种粗离散化确保所得区间最多带来 $2h$ 的保守性，同时保持有效性。

> 译注：原文 B.1 使用 B_u 表示上界，但 B.2、B.3 改用 $\widehat{B}_h$，此处保留该记号差异。原文 B.2 的上界公式返回仍属于预测集的网格点 y，而非 $y + h$，却随后声称保持有效性；译文按原式与原论述保留，未擅自修正。

B.3 预定义搜索范围

我们将搜索范围限制在一个依赖于数据的区间内，以避免不必要的计算。具体定义如下：

$$y_{\min} = \min\left\{y \mid s(\widetilde{x},\ y) \le \max_{i=1,\ldots,n} S_m^i\right\}, \qquad y_{\max} = \max\left\{y \mid s(\widetilde{x},\ y) \le \max_{i=1,\ldots,n} S_m^i\right\}.$$

随后，在 $[y_{\min},\ y_{\max}]$ 内执行搜索。为保持理论上的有效性，我们采用以下规则：

$$\widehat{B}_l = -\infty \quad \text{if} \quad y_{\min} \in \widehat{C}_\alpha^W(\widetilde{x}), \qquad \widehat{B}_h = \infty \quad \text{if} \quad y_{\max} \in \widehat{C}_\alpha^W(\widetilde{x}).$$

以上技术都能使加权 CP 更高效，并在理论上保持有效，尽管会引入 $2h$ 的保守性。虽然由于 AR-Corrected 方法速度快、灵活性强，我们在实际部署中主要推荐它，但加权 CP 方法依然有价值。特别是，加权 CP 避免了 AR 校正过程中子采样引入的额外方差，因此在重视方差的场景中更加稳定。

附录 C 证明

假设 P, Q 以及对任意 $m \in \{0,\ 1\}^d$ 的 P_m, Q_m 均具有相对于共同控制测度 μ 的密度。分别将这些密度记为 p, q, p_m, q_m。

C.1 命题 1 的证明

回顾 $Q_{M^{n+1}}$ 和 $P_{M^{n+1}}$ 的定义：前者是具有缺失模式 M^{n+1} 的插补校准数据的分布，后者是在给定 M^{n+1} 条件下测试点的分布。在 $M^{n+1} = m$ 条件下直接对这两个分布应用分割式 CP，根据 Barber 等（2023）的定理 2，对于所有满足 $P(M = m) > 0$ 的 $m \in \{0,\ 1\}^d$，有：

$$P(Y^{n+1} \in \hat{C}_\alpha(\widetilde{X}^{n+1}) \mid M^{n+1} = m) \ge 1 - \alpha - 2d_{TV}(Q_m, P_m) \tag{6}$$

对于全变差距离项，有：

$$
\begin{aligned}
&2d_{TV}(Q_m, P_m) \\
&= 2 \times \frac{1}{2} \int_{\mathcal{X}^{\mathrm{obs}(m)} \times \mathcal{Y}} \left| p_m(x_{\mathrm{obs}(m)}, y) - q_m(x_{\mathrm{obs}(m)}, y) \right| d(x_{\mathrm{obs}(m)}, y) \\
&= \int_{\mathcal{X}^{\mathrm{obs}(m)} \times \mathcal{Y}} \left| \int_{\mathcal{X}^{\mathrm{mis}(m)}} p(x, y | M = m) dx_{\mathrm{mis}(m)} - \int_{\mathcal{X}^{\mathrm{mis}(m)}} q(x, y) dx_{\mathrm{mis}(m)} \right| d(x_{\mathrm{obs}(m)}, y) \\
&= \int_{\mathcal{X}^{\mathrm{obs}(m)} \times \mathcal{Y}} \left| \int_{\mathcal{X}^{\mathrm{mis}(m)}} \left\{ p(x, y | M = m) - p(x, y) + p(x, y) - q(x, y) \right\} dx_{\mathrm{mis}(m)} \right| d(x_{\mathrm{obs}(m)}, y) \\
&\leq \int_{\mathcal{X}^{\mathrm{obs}(m)} \times \mathcal{Y}} \int_{\mathcal{X}^{\mathrm{mis}(m)}} \left| p(x, y | M = m) - p(x, y) + q(x, y) - q(x, y) \right| dx_{\mathrm{mis}(m)} d(x_{\mathrm{obs}(m)}, y) \\
&\leq \int_{\mathcal{X}^{\mathrm{obs}(m)} \times \mathcal{Y}} \int_{\mathcal{X}^{\mathrm{mis}(m)}} \left\{ |p(x, y | M = m) - p(x, y)| + |p(x, y) - q(x, y)| \right\} dx_{\mathrm{mis}(m)} d(x_{\mathrm{obs}(m)}, y) \\
&= \int_{\mathcal{X} \times \mathcal{Y}} \left\{ |p(x, y | M = m) - p(x, y)| + |p(x, y) - q(x, y)| \right\} d(x, y) \\
&= d_{TV}(P, Q) + \int_{\mathcal{X} \times \mathcal{Y}} \left| \frac{dP(x, y \mid M = m)}{dP(x, y)} - 1 \right| dP(x, y) d(x, y) \\
&= d_{TV}(P, Q) + \mathbb{E}_P \left[\left| \frac{dP(X, Y | M = m)}{dP(X, Y)} - 1 \right| \right]
\end{aligned}
$$

对于 MCAR 情形，注意 $p(X,\ Y \mid M) = p(X,\ Y)$；因此，最后一个等式中的第二项为零。

C.2 定理 1 的证明

对于任意 $m \in \{0,\ 1\}^d$，考虑给定 $M^{n+1} = m$ 条件下的所有事件。根据 Q_m 的定义以及 $M^{n+1} \perp \{\left(\widehat{X}^i_{\mathrm{obs}(M^{n+1})},\ Y^i\right)\}_{i=1}^n$，先插补后施加掩码的校准点满足 $\left(\{\left(\widehat{X}^i_{\mathrm{obs}(M^{n+1})},\ Y^i\right)\}_{i=1}^n \mid M^{n+1} = m\right) \sim Q_m$，测试点满足 $\left(\left(X^{n+1}_{\mathrm{obs}(M^{n+1})},\ Y^{n+1}\right) \mid M^{n+1} = m\right) \sim P_m$。

回顾 P_m 和 Q_m 是定义在 $\#\mathrm{obs}(m)$ 维空间上的概率。现在考虑 d 维数据集 $\left(\{\mathrm{mask}\left(\widehat{X}^i,\ M^{n+1}\right),\ Y^i\}_{i=1}^n \mid M^{n+1} = m\right)$，将其分布记为 $Q_m^\star$；考虑测试点 $\left(\left(\widetilde{X}^{n+1},\ Y^{n+1}\right) \mid M^{n+1} = m\right)$，将其分布记为 $P_m^\star$。[5] 假设 $Q_m^\star$ 和 $P_m^\star$ 受测度 μ 控制，其密度分别为 $q_m^\star$ 和 $p_m^\star$。根据掩码算子的定义，容易验证：

$$
\begin{aligned}
p_m^\star(x, y) &= p_m(x_{\mathrm{obs}(m)}, y) \mathbb{1}_{x_{\mathrm{mis}}(m) = NA} \\
q_m^\star(x, y) &= q_m(x_{\mathrm{obs}(m)}, y) \mathbb{1}_{x_{\mathrm{mis}}(m) = NA}
\end{aligned}
$$

应用 Tibshirani 等（2019）的引理 2 及假设 2，可知全部 $n+1$ 个点具有加权可交换性，权重函数为：对 $i = 1,\ \ldots,\ n$，$\omega_i = 1$；并且 $\omega_{n+1} = p_m^\star / q_m^\star = p_m / q_m = dP_m / dQ_m$。

应用 Tibshirani 等（2019）的定理 2，立即得到：在 $M^{n+1} = m$ 条件下，预测集 $\widehat{C}_\alpha^W\left(\widetilde{X}^{n+1}\right)$ 恰好就是加权版本，因此

$$P\left(Y^{n+1} \in \widehat{C}_\alpha^W\left(\widetilde{X}^{n+1}\right) \mid M^{n+1} = m\right) \geq 1 - \alpha.$$

正式算法概括在算法 3 中。

算法 3：校准集预插补的加权 CP

输入： 校准集 $\text{Cal} = \{\left(\widetilde{X}^k, Y^k\right)\}_{k=1}^n$、广义分布型插补 φ、预测模型 $\widehat{f}$、非一致性评分函数 $s_{\widehat{f}}(\widetilde{x}, y)$、针对 $\omega_m(x_{\text{obs}(m)}, y)$ 的似然估计函数 $\widehat{\omega}_m(\text{mask}(x, m), y)$、显著性水平 α、测试点 $\widetilde{X}^{n+1}$。插补函数 φ 和预测模型 $\widehat{f}$ 在独立训练集上训练。

输出： 预测集 $\widehat{C}_\alpha^W\left(\widetilde{X}^{n+1}\right)$。

1. 对 $k \in \{1, \ldots, n\}$ 循环：
2. $\left(\widetilde{X}^k, Y^k\right) = \left(\varphi\left(\widetilde{X}^k, Y^k\right), Y^k\right)$。// 对 Cal 预插补。
3. $\left(\widehat{X}^k, Y^k\right) = \left(\text{mask}\left(X^k, M^{n+1}\right), Y^k\right)$。// 为每个数据点加入缺失模式 M^{n+1}。
4. $\omega^k = \widehat{\omega}_m\left(\text{mask}\left(\widehat{X}^k, M^{n+1}\right), Y^k\right)$。// 计算权重。
5. 结束循环。
6. 按定理 1 定义 $W^i(x_{\text{obs}(M^{n+1})}, y)$ 和 $W^{n+1}(x_{\text{obs}(M^{n+1})}, y)$。
7. 计算预测集的加权版本：

$$\widehat{C}_\alpha^W(\widetilde{X}^{n+1}) := \left\{y : s_{\hat{f}}(\widetilde{X}^{n+1}, y)\right.$$
$$\left. \leq \mathcal{Q}_{1-\alpha}\left(\sum_{i=1}^n W^i(X^i_{\text{obs}(M^{n+1})}, y)\delta_{s_{\hat{f}}(\widetilde{X}^i, Y^i)} + W^{n+1}(X^{n+1}_{\text{obs}(M^{n+1})}, y)\delta_\infty\right)\right\}. \tag{7}$$

C.3 定理 2 的证明

在进行证明之前，先澄清定理 2 中关于每个校准样本的重要性权重 ω_m^i 由常数 $K > 0$ 上界控制的假设。事实上，这等价于假设似然比函数 $\omega_m(x_{\text{obs}(m)}, y) := P_m(x_{\text{obs}(m)}, y)/Q_m(x_{\text{obs}(m)}, y)$ 对所有 $(x_{\text{obs}(m)}, y)$ 一致有界。

证明。 1. 对于第一点，由于所有数据在 X 的索引 $\text{mis}(m)$ 处均为缺失值 NA，我们只需证明所有点在 X 的索引 $\text{obs}(m)$ 及 Y 上具有相同边缘分布，并且相互独立。

为了证明它们同分布，只需证明 $\left(\widehat{X}^i_{\text{obs}(m)}, Y^i\right)$ 在 $U \leq \omega_m^i/K$ 条件下的条件分布确实与 P_m 相同。也就是说，以累积分布函数表示，我们希望证明

$$P\left(\hat{X}_{\text{obs}(m)} \leq x, Y \leq y \mid U \leq \frac{\beta}{K}\frac{dP_m}{dQ_m}(\hat{X}_{\text{obs}(m)}, Y)\right) = P(X_{\text{obs}(m)} \leq x, Y \leq y \mid M = m), \tag{8}$$

其中 β 是未知归一化常数，使 $\omega_m^i = \beta\, dP_m/dQ_m$。令事件 $B = \{U \le (\beta/K)(dP_m/dQ_m)(\widehat{X}_{\mathrm{obs}(m)}, Y)\}$， $A = \{\widehat{X}_{\mathrm{obs}(m)} \le x, Y \le y\}$。首先，根据均匀分布的定义有

$$P(B \mid \hat{X}_{\mathrm{obs}(m)} = x, Y = y) = \frac{\beta}{K}\frac{dP_m(x,y)}{dQ_m(x,y)},$$

还有:

$$\begin{aligned} P(B) &= \int_{\mathcal{X}_{\mathrm{obs}(m)}\times\mathcal{Y}} P(B \mid \hat{X}_{\mathrm{obs}(m)} = x, Y = y) dQ_m(\hat{X}_{\mathrm{obs}(m)} = x, Y = y) \\ &= \int_{\mathcal{X}_{\mathrm{obs}(m)}\times\mathcal{Y}} \frac{\beta}{K}\frac{dP_m(x,y)}{dQ_m(x,y)} dQ_m(x,y) \\ &= \frac{\beta}{K}, \end{aligned}$$

$$Q_m(B \mid A) = \frac{\int_A \mathbb{P}_{\mathrm{U}\sim\mathrm{Uniform}}\left(U \le \frac{\beta}{K}\,\omega_m(z) \mid z\right) dQ_m(z)}{Q_m(A)} \tag{9}$$

$$= \frac{\int_A \frac{\beta}{K}\,\omega_m(z)\, dQ_m(z)}{Q_m(A)} \tag{10}$$

$$= \frac{\beta}{K\, Q_m(A)} \int_A dP_m \tag{11}$$

$$= \frac{\beta\, P_m(A)}{K\, Q_m(A)}. \tag{12}$$

根据贝叶斯公式:

$$
\begin{aligned}
P(B|A) &= \frac{P(B,A)}{P(A)} \\
&= \frac{P(U \le \frac{\beta}{K}\frac{dP_m}{dQ_m}(\hat{X}_{\mathrm{obs}(m)}, Y), \hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)}{P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)} \\
&= \int_{-\infty}^{(x,y)} \frac{P(U \le \frac{\beta}{K}\frac{dP_m(w_x,w_y)}{dQ_m(w_x,w_y)} \mid w_x \le x, w_y \le y)}{P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)} dQ_m(w_x, w_y)) \\
&= \frac{1}{P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y \mid M = m)} \int_{-\infty}^{(x,y)} \frac{\beta}{K}\frac{dP_m(w_x,w_y)}{dQ_m(w_x,w_y)} dQ_m(w_x, w_y) \\
&= \frac{\beta}{K \cdot P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)} \int_{-\infty}^{(x,y)} dP_m(w_x, w_y) \\
&= \frac{\beta \cdot P(X_{\mathrm{obs}(m)} \le x, Y \le y \mid M = m)}{K \cdot P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)}.
\end{aligned}
$$

注意 $P\big(\widehat{X}_{\mathrm{obs}(m)} \le x,\ Y \le y \mid U \le (\beta/K)(dP_m/dQ_m)(\widehat{X}_{\mathrm{obs}(m)},\ Y)\big) = P(A \mid B)$，因此

$$
\begin{aligned}
P(A|B) &= P(B|A)\frac{P(A)}{P(B)} \\
&= \frac{\beta \cdot P(X_{\mathrm{obs}(m)} \le x, Y \le y \mid M = m)}{K \cdot P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)} \cdot \frac{P(\hat{X}_{\mathrm{obs}(m)} \le x, Y \le y)}{\beta/K} \\
&= P(X_{\mathrm{obs}(m)} \le x, Y \le y \mid M = m),
\end{aligned}
$$

这就是目标式（8）。对插补后的校准数据应用接受-拒绝方法，所得数据点服从与 $\big(X_{\mathrm{obs}(m)},\ Y\big)$ 相同的分布。

此外，根据定义，$\big(\widehat{X}^i,\ Y^i\big) \cup \big(X^{n+1},\ Y^{n+1}\big)$ 中各点彼此独立，而且 $U \perp\!\!\!\perp \big(X^k,\ Y^k\big)_{k=1}^{n+1}$，因此 $\widetilde{\mathrm{Cal}}_m$ 中所有数据点与 $\big(X_{\mathrm{obs}(m)}^{n+1},\ Y^{n+1}\big)$ 相互独立。由此得出所有数据点独立同分布。

1. 如前所证，给定 $M = m$ 时，$\widetilde{\mathrm{Cal}}_m$ 中所有数据点与 $\big(X_{\mathrm{obs}(m)}^{n+1},\ Y^{n+1}\big)$ 独立同分布，满足共形预测的条件（可交换性），因而任何目标覆盖率为 $1-\alpha$ 的边缘有效方法均有：

$$
P\big(Y^{n+1} \in \widehat{C}_\alpha^{AR}\big(\mathrm{mask}\big(X^{n+1},\ m\big)\big) \mid M^{n+1} = m\big) \ge 1 - \alpha.
$$

算法 4：校准集预插补的接受-拒绝校正 CP

输入：校准集 $\mathrm{Cal} = \{\big(\widetilde{X}^i,\ Y^i\big)\}_{i=1}^n$、广义分布型插补 φ、预测模型 $\widehat{f}$、非一致性评分函数 $s_{\widehat{f}}\big(\widetilde{x},\ y\big)$、针对 $\omega_m\big(x_{\mathrm{obs}(m)},\ y\big)$ 的似然估计函数 $\widehat{\omega}_m\big(\mathrm{mask}(x,\ m),\ y\big)$ 及其最大值 $\omega_{\max}$、显著性水平 α、测试点 $\widetilde{X}^{n+1}$。插补函数 φ 与预测模型 $\widehat{f}$ 均在独立训练集上训练。

输出： 预测集 $\widehat{C}_{\alpha}^{AR}\left(\widetilde{X}^{n+1}\right)$。

1. $I_{AR}=\{\}$。
2. 对 $k\in\{1,\ ...,\ n\}$ 循环：
3. 对校准点进行预插补，得到 $\left(\varphi\left(\widetilde{X}^{k},\ Y^{k}\right),\ Y^{k}\right)$。
4. 采样 $U^{k}\sim\mathcal{U}(0,\ 1)$。
5. 计算 $q^{k}=\widehat{\omega}_{m}\left(\text{mask}\left(\varphi\left(\widetilde{X}^{k},\ Y^{k}\right),\ M^{n+1}\right),\ Y^{k}\right)/\omega_{\max}$。
6. 如果 $U^{k}<q^{k}$，则：
7. $I_{AR}=I_{AR}\cup\{k\}$。
8. $\widehat{X}^{k}=\varphi\left(\widetilde{X}^{k},\ Y^{k}\right)$。
9. 结束条件判断。
10. 结束循环。
11. $\widetilde{\text{Cal}}=\{\left(\widehat{X}^{i},\ Y^{i}\right)\}_{i\in I_{AR}}$。// 接受 $|I_{AR}|$ 个点，使得 $\{\left(\widehat{X}^{i},\ Y^{i}\right)\}_{i\in I_{AR}}\subseteq\{\left(\varphi\left(\widetilde{X}^{i},\ Y^{i}\right),\ Y^{i}\right)\}_{i=1}^{n}$。
12. 更新后的数据集为 $\widetilde{\text{Cal}}_{M^{n+1}}=\{\left(\text{mask}\left(\widehat{X}^{i},\ M^{n+1}\right),\ Y^{i}\right)\}_{i\in I_{AR}}$。// 使用测试点的缺失模式 M^{n+1} 掩蔽 $\widetilde{\text{Cal}}$。
13. 对所有 $i\in I_{AR}$，记 $\widehat{S}^{i}_{M^{n+1}}=s_{\hat{f}}\left(\text{mask}\left(\widetilde{X}^{i},\ M^{n+1}\right),\ Y^{i}\right)$。
14. 计算 AR 校正的预测集：

$$\widehat{C}_{\alpha}^{AR}(\widetilde{X}^{n+1}):=\left\{y\in\mathcal{Y}:s_{\hat{f}}(\widetilde{X}^{n+1},y)\leq\mathcal{Q}_{1-\alpha}\left(\sum_{i\in\mathcal{I}_{AR}}\delta_{\hat{S}^{i}_{M^{n+1}}}+\delta_{\infty}\right)\right\}. \tag{13}$$

引理 1（贝叶斯分类风险与全变差距离）。设 $(\Omega,\ \mathcal{F})$ 为可测空间，$\mathbb{P},\ \mathbb{Q}$ 是其上的两个概率测度。假设存在同时控制两者的 σ 有限测度 μ，相应密度记为 $p=d\mathbb{P}/d\mu$ 和 $q=d\mathbb{Q}/d\mu$。

在 $\Omega\times\{0,\ 1\}$ 上定义联合分布 Π：

$$\Pi(dx,\ dc)=\tfrac{1}{2}\mathbb{P}(dx)\delta_{1}(dc)+\tfrac{1}{2}\mathbb{Q}(dx)\delta_{0}(dc),$$

其中 δ_{c} 表示集中在 c 处的狄拉克测度。于是 X 的边缘分布为 $D:=\tfrac{1}{2}(\mathbb{P}+\mathbb{Q})$。

对于任意可测分类器 $c:\Omega\to\{0,\ 1\}$，将（0-1）分类风险定义为 $R(c):=P_{(X,C)\sim\Pi}[c(X)\neq C]$，贝叶斯最优风险为 $R^{\star}:=\inf_{c}R(c)$。则有：

$$R^{\star}=\tfrac{1}{2}-\tfrac{1}{2}d_{\text{TV}}(\mathbb{P},\ \mathbb{Q}),$$

其中

$$d_{\text{TV}}(\mathbb{P},\ \mathbb{Q}):=\tfrac{1}{2}\int_{\Omega}|p(x)-q(x)|\,d\mu(x).$$

证明。给定样本 x 时，该样本来自 $\mathbb{P}$（即 $C=1$）的后验概率定义为

$$\eta(x) := P(C = 1 \mid X = x) = \frac{\frac{1}{2}p(x)}{\frac{1}{2}p(x) + \frac{1}{2}q(x)} = \frac{p(x)}{p(x) + q(x)}.$$

联合分布 Π 下 X 的边缘分布是

$$D(dx) = \tfrac{1}{2}(\mathbb{P} + \mathbb{Q})(dx) = \tfrac{1}{2}\big(p(x) + q(x)\big)\, d\mu(x).$$

贝叶斯最优分类器为 $c^\star(x) = \mathbf{1}\{\eta(x) > 1/2\}$，相应贝叶斯分类风险为

$$R\big(c^\star\big) = P_{(X,C)\sim\Pi}\big[c^\star(X) \neq C\big] = \mathbb{E}_{X\sim D}\big[\min\big(\eta(X),\, 1 - \eta(X)\big)\big].$$

代入 $\eta(x)$ 的定义，得到

$$\min\left(\frac{p(x)}{p(x) + q(x)},\, \frac{q(x)}{p(x) + q(x)}\right) = \frac{\min\{p(x),\, q(x)\}}{p(x) + q(x)}.$$

因此，

$$\mathcal{R}(\mathsf{c}^\star) = \int_\Omega \tfrac{1}{2}(p(x) + q(x))\frac{\min\{p(x), q(x)\}}{p(x) + q(x)}\, d\mu(x) = \tfrac{1}{2}\int_\Omega \min\{p(x), q(x)\}\, d\mu(x).$$

最后，回顾全变差距离满足

$$d_{\mathrm{TV}}(\mathbb{P}, \mathbb{Q}) = \tfrac{1}{2}\int_\Omega |p(x) - q(x)|\, d\mu(x) = 1 - \int_\Omega \min\{p(x), q(x)\}\, d\mu(x),$$

从而得到 $R\big(c^\star\big) = \frac{1}{2} - \frac{1}{2}d_{\mathrm{TV}}(\mathbb{P},\, \mathbb{Q})$。

C.4 命题 2 的证明

固定一个 $m \in \{0,\, 1\}^d$，令 $\left(X^{\widetilde{\omega}}_{\mathrm{obs}(m)},\, Y^{\widetilde{\omega}}\right)$ 为服从 $d\widetilde{P}_m := \widetilde{\omega}_m\big(\widehat{X}_{\mathrm{obs}(m)},\, Y\big) \cdot dQ_m$ 的随机向量。该新分布通过相对于 Q_m 的 Radon-Nikodym 导数、使用归一化加权函数 $\widetilde{\omega}_m$ 得到，因而定义良好。为方便起见，定义 $X^{\widetilde{\omega}}_{\mathrm{mis}(m)} := \mathrm{NA}$。

由于 $\widehat{C}^{\widehat{W}}_\alpha$ 是在校准数据集 Q_m 上使用校正权重 $\widetilde{\omega}_m$ 构造的，这意味着重加权校准分布等于 $\left(X^{\widetilde{\omega}}_{\mathrm{obs}(m)},\, Y^{\widetilde{\omega}}\right)$ 的分布。根据构造，若使用同一加权 CP 方法为 $X^{\widetilde{\omega}}$ 计算预测区间，则具有精确有效的覆盖率：

$$P(Y^{\tilde{\omega}} \in \widehat{C}^{\widehat{W}}_\alpha(X^{\tilde{\omega}})) \geq 1 - \alpha. \tag{14}$$

此外，注意根据似然比 ω_m 的定义，真实 $\big(X_{\mathrm{obs}(m)},\, Y\big)$ 服从分布 $P_m = \omega_m\big(\widehat{X}_{\mathrm{obs}(m)},\, Y\big) \cdot Q_m$。用 A 表示在 $M^{n+1} = m$ 条件下 Y 落入预测区间 $\widehat{C}^{W}_\alpha\big(\widetilde{X}\big)$ 的事件。根据全变差距离的基本性质，有

$$
\begin{aligned}
&\left|P\left(Y^{n+1} \in \widehat{C}_{\alpha}^{\widehat{W}}\left(\widetilde{X}^{n+1}\right) \mid M^{n+1}=m\right)-P\left(Y^{\tilde{\omega}} \in \widehat{C}_{\alpha}^{\widehat{W}}\left(X^{\tilde{\omega}}\right) \mid M^{n+1}=m\right)\right| \\
=&\left|P_{\left(X_{\mathrm{obs}(m)}, Y\right) \sim P_m}(A)-P_{\left(X_{\mathrm{obs}(m)}, Y\right) \sim \tilde{\omega}_m\left(\hat{X}_{\mathrm{obs}(m)}, Y\right) \cdot d Q_m}(A)\right| \\
=&\left|P_{\left(X_{\mathrm{obs}(m)}, Y\right) \sim P_m}(A)-P_{\left(X_{\mathrm{obs}(m)}, Y\right) \sim \tilde{P}_m}(A)\right| \\
\leq& d_{TV}\left(P_m, \tilde{P}_m\right)
\end{aligned}
$$

将式（14）与上述结果结合，即得到命题 2 的结论。

C.5 正则性假设

记号。固定掩码 m。P_m 和 $\widetilde{P}_m$ 是 $\mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y}$ 上的概率测度。在 $\left(\mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y}\right) \times\{0,\ 1\}$ 上引入平衡混合分布：

$$
\Pi_m=\tfrac{1}{2}\left(P_m \times \delta_1\right)+\tfrac{1}{2}\left(\widetilde{P}_m \times \delta_0\right),
$$

其中 δ_c 表示 $c \in\{0,\ 1\}$ 处的狄拉克质量。令 $\mathcal{G} \subset\left\{g:\left(\mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y}\right) \rightarrow\{0,\ 1\}\right\}$ 为假设类。定义 0-1 损失

$$
\gamma\left(g,\ \left(x_{\mathrm{obs}(m)},\ y\right),\ c\right)=\mathbf{1}\left\{g\left(x_{\mathrm{obs}(m)},\ y\right) \neq c\right\} \in[0,\ 1],
$$

其风险为

$$
R_\gamma(g):=\mathbb{E}_{\left(\left(X_{\mathrm{obs}(m)}, Y\right), C\right) \sim \Pi_m}\left[\gamma\left(g,\ \left(X_{\mathrm{obs}(m)},\ Y\right),\ C\right)\right],
$$

贝叶斯风险为 $R_\gamma^{\star}:=\inf_g R_\gamma(g)$。由引理 1，$R_\gamma^{\star}=\frac{1}{2}-\frac{1}{2} d_{\mathrm{TV}}\left(P_m,\ \widetilde{P}_m\right)$。

我们将分类器 g_m 的搜索限制在假设类 $\mathcal{G}_m$ 中，通过最小化上述 0-1 损失的经验值获得分类器。

假设 3（$\mathcal{G}_m$ 的可分性）。存在可数集合 $\mathcal{G}' \subset \mathcal{G}_m$，使得对每个 $g \in \mathcal{G}_m$，存在序列 $\left(g_k\right) \subset \mathcal{G}'$，满足对所有 $\left(\left(x_{\mathrm{obs}(m)},\ y\right),\ c\right)$，$\gamma\left(g_k,\ \left(x_{\mathrm{obs}(m)},\ y\right),\ c\right) \rightarrow \gamma\left(g,\ \left(x_{\mathrm{obs}(m)},\ y\right),\ c\right)$。

假设 4（VC 类）。令 $\mathcal{A}_{\mathcal{G}_m}:=\left\{\left\{\left(x_{\mathrm{obs}(m)},\ y\right): g_m\left(x_{\mathrm{obs}(m)},\ y\right)=1\right\}: g_m \in \mathcal{G}_m\right\}$ 为 $\mathcal{G}_m$ 诱导的决策集合族。假设 $\mathcal{A}_{\mathcal{G}_m}$ 是有限维数 $V \geq 1$ 的 VC 类。

假设 5（$\mathcal{G}_m$ 上的 ERM）。给定来自 Π_m 的 l 个独立同分布样本，令 $\widehat{g}_m \in \operatorname{argmin}_{g \in \mathcal{G}_m} \widehat{R}_\gamma(g)$ 为 γ 在 $\mathcal{G}$ 上的经验风险最小化器。

假设 6。存在 $g_m^{\star} \in \mathcal{G}_m$，使得 $R_\gamma\left(g_m^{\star}\right)=R_\gamma^{\star}$。

假设 7（训练算法的一致 β 稳定性）。令 $\widetilde{Z}=\left(Z^1,\ \ldots,\ Z^l\right) \in \mathcal{Z}^l$，其中 $Z^i=\left(X_{\mathrm{obs}(m)}^i,\ Y^i,\ C_i\right)$ 独立同分布于 Π_m。令 T 是输出分类器 $\widehat{g}_m=T\left(\widetilde{Z}\right) \in \mathcal{G}_m$ 的学习算法。对于 $i \in\{1,\ \ldots,\ l\}$，将 Z^i 替换为独立副本 $Z' \sim \Pi_m$，定义数据集 $\widetilde{Z}^{(i)}$，即 $\widetilde{Z}^{(i)}=\left(Z^1,\ \ldots,\ Z^{i-1},\ Z',\ Z^{i+1},\ \ldots,\ Z^l\right)$。如果存在 $\beta_l \geq 0$，使得对所有 $i \in\{1,\ \ldots,\ l\}$ 及所有 $z=\left(x_{\mathrm{obs}(m)},\ y,\ c\right) \in \mathcal{X}_{\mathrm{obs}(m)} \times \mathcal{Y} \times\{0,\ 1\}$，

$$\left|\gamma\left(T\left(\widetilde{Z}\right),\, z\right) - \gamma\left(T\left(\widetilde{Z}^{(i)}\right),\, z\right)\right| \le \beta_l$$

相对于 $\widetilde{Z},\, Z'$ 的联合分布 Π_m^{l+1} 几乎必然成立，则称算法 T 是（关于损失 γ）一致 β_l 稳定的。

这些假设受到经典统计学习理论（Massart and Nédélec，2006；Van Der Vaart and Wellner，1996；Vapnik，2013）以及算法性质和稳定性方面研究进展（Bousquet and Elisseeff，2002；Soloff 等，2024）的启发。例如，核方法、正则化逻辑回归和权重有界的神经网络满足可分性与有限 VC 维数假设。随机森林或梯度提升树等基于树的集成，在树的数量和深度有界时也满足这些假设。假设 7（一致 β_l 稳定性）对于零一损失平凡成立。推广见 Bousquet and Elisseeff（2002）及 Soloff 等（2024）。

C.6 命题 3 的证明

（1）假设有另一个大小为 l 的数据集，记为 $Z_c := \{\left(\widetilde{X}^i,\, \widetilde{Y}^i,\, \widetilde{C}^i\right)\}_{i=1}^{l}$，以及似然比估计量 $\widehat{\omega}_m$。目标是估计 $d_{\mathrm{TV}}\left(P_m,\, \widetilde{\omega}_m\left(\widehat{X}_{\mathrm{obs}(m)},\, Y\right)\cdot Q_m\right)$。

由于 $\widetilde{\omega}_m$ 是归一化后的似然比估计量，$\widetilde{P}_m := \widetilde{\omega}_m\left(\widehat{X}_{\mathrm{obs}(m)},\, Y\right)\cdot Q_m$ 定义了一个有效概率分布。

在假设 3 和 4 下，由 Massart and Nédélec（2006）的推论 3，有

$$\mathbb{E}_{Z_c}\left[R_\gamma\left(\widehat{g}_m\right)\right] - R_\gamma^\star \le K\sqrt{\frac{V_{\mathcal{G}}}{l}},$$

其中 K 是与样本量及分布无关的普适常数，$V_{\mathcal{G}}$ 是假设 4 中假设类 $\mathcal{G}$ 的 VC 维数。

算法 5：通过接受-拒绝采样构造来自 P_m 和 $\widetilde{P}_m$ 的数据集

假设给定 J 个独立同分布样本 $\{\left(\widetilde{X}^i,\, \widetilde{Y}^i,\, \widetilde{M}^i\right)\}_{i=1}^{J}$。首先应用与正文相同的预插补函数，得到按构造服从分布 Q 的完全观测数据集。

然后对每个数据点应用固定掩码 m，产生掩蔽样本 $\{\left(\widetilde{\widetilde{X}}^i,\, \widetilde{Y}^i\right)\}_{i=1}^{J} := \{\left(\mathrm{mask}\left(\widetilde{X}^i,\, m\right),\, \widetilde{Y}^i\right)\}_{i=1}^{J}$，其服从分布 Q_m。

为了从通过似然比 $\widetilde{\omega}_m$ 定义的分布 $d\widetilde{P}_m := \widetilde{\omega}_m\, dQ_m$ 生成独立同分布样本，我们采用提议分布为 Q_m 的接受-拒绝方案：

1. 从数据集中选择候选点 $Z^i = \left(\widetilde{\widetilde{X}}^i,\, \widetilde{Y}^i\right)$，并独立采样 $U \sim \mathrm{Unif}\,(0,\, 1)$。
2. 如果 $U \le \widetilde{\omega}_m\left(Z^i\right)/\widetilde{K}$，则接受 Z^i，其中 $\widetilde{K} \ge \sup_z \widetilde{\omega}_m(z)$。

每个被接受的点都是来自 $\widetilde{P}_m$ 的精确样本，重复这一过程得到来自 $\widetilde{P}_m$、大小为 l_2 的独立同分布数据集。

为了构造来自 P_m 的数据集，从原始样本集合 $\{\left(\widetilde{X}^i, \widetilde{Y}^i, \widetilde{M}^i\right)\}_{i=1}^{J}$ 中选出所有满足 $\widetilde{M}^i = m$ 的样本。根据定义，这些点服从 P_m。

此过程产生两个独立数据集，分别由来自 P_m 和 $\widetilde{P}_m$ 的独立同分布样本构成。

（2）考虑预测区间 $\widehat{C}_\alpha^W$ 的构造，它与数据集 Z_c 独立。因此可应用命题 2，得到

$$P\left(Y^{n+1} \in \hat{C}_\alpha^W(\widetilde{X}^{n+1}) \mid M^{n+1} = m\right) - (1-\alpha) \geq -d_{TV}(P_m, \tilde{P}_m) \tag{15}$$

$$= -(1 - 2R_\gamma^\star)\,, \tag{16}$$

其中最后一个等式由引理 1 得到。由于 $\widehat{C}_\alpha^W$ 的构造独立于 Z_c，式（15）的右侧可以改写为

$$\begin{aligned} &P(Y^{n+1} \in \hat{C}_\alpha^W(\widetilde{X}^{n+1}) \mid M^{n+1} = m) - (1-\alpha) \qquad (17)\\ &\geq -\left(1 - 2\,R_\gamma^\star\right) = -1 + 2\,R_\gamma^\star \\ &\geq -1 + 2\mathbb{E}_{Z_c}[R_\gamma(\hat{g}_m)] - K\sqrt{\frac{V_{\mathcal{G}_m}}{l}}\,, \end{aligned}$$

其中 $K > 0$ 是普适常数，可以吸收诸如 2 这样的绝对数值常数。在假设 7 下，可应用 McDiarmid 不等式（McDiarmid 等，1989）得到如下界：对于任意 $\epsilon > 0$，

$$P_{Z_c}(R_\gamma(\widehat{g}_m) - \mathbb{E}_{Z_c}\left[R_\gamma(\widehat{g}_m)\right] \geq \epsilon) \leq \exp\left(-\frac{2\epsilon^2}{l\beta_l^2}\right).$$

由于所有风险均以 0 和 1 为界，应用 Hoeffding 不等式得到

$$P_{Z_c}\left(\widehat{R}_\gamma(\widehat{g}_m) - R_\gamma(\widehat{g}_m) \geq \epsilon\right) \leq \exp\left(-\frac{2\epsilon^2 l^2}{l}\right).$$

将 ϵ 替换为 $\epsilon/2$，有

$$P_{Z_c}(|\hat{R}_\gamma(\hat{g}_m) - \mathbb{E}_{Z_c}[R_\gamma(\hat{g}_m)]| \leq \epsilon) > 1 - \exp(-\frac{\epsilon^2}{2l\beta_l^2}) - \exp(-\frac{\epsilon^2 l}{2}). \tag{18}$$

代入式（17）即得到所需结论。

附录 D 估计量质量对覆盖率的影响

本节研究密度比估计质量对加权共形预测的掩码条件覆盖率的实际影响。分析基于真实密度比可进行解析计算的合成数据。

D.1 合成数据生成

考虑与第 4 节相同的合成设置。令 $X \in \mathbb{R}^d$ 为 d 维高斯随机变量，Y 为带加性高斯噪声的线性响应：

$$X \sim \mathcal{N}(\mu_X, \Sigma_X),$$
$$Y \mid X = \beta^\top X + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2).$$

联合分布 (X, Y) 是高斯分布，其均值和协方差为：

$$\mu_{XY} = \begin{bmatrix} \mu_X \\ \beta^\top \mu_X \end{bmatrix},$$
$$\Sigma_{XY} = \begin{bmatrix} \Sigma_X & \Sigma_X \beta \\ \beta^\top \Sigma_X & \beta^\top \Sigma_X \beta + \sigma^2 \end{bmatrix}.$$

以概率 0.5 独立随机掩蔽每个特征 X_j，模拟完全随机缺失（MCAR）。令 $M \in \{0, 1\}^d$ 为缺失指示变量。

根据高斯条件分布，对每种缺失模式 $M = m$，给定观测协变量及 Y 时缺失协变量的条件分布为

$$X_{\text{mis}} \mid X_{\text{obs}}, Y \sim \mathcal{N}\left(\mu_{\text{mis}|\text{obs},Y}, \Sigma_{\text{mis}|\text{obs},Y}\right),$$

其中：

$$\mu_{\text{mis}|\text{obs},Y} = \mu_{\text{mis}} + \Sigma_{\text{mis},[X_{\text{obs}},Y]} \Sigma^{-1}_{[X_{\text{obs}},Y]} \left(\begin{bmatrix} X_{\text{obs}} & Y \end{bmatrix} - \mu_{[X_{\text{obs}},Y]} \right),$$
$$\Sigma_{\text{mis}|\text{obs},Y} = \Sigma_{\text{mis,mis}} - \Sigma_{\text{mis},[X_{\text{obs}},Y]} \Sigma^{-1}_{[X_{\text{obs}},Y]} \Sigma_{[X_{\text{obs}},Y],\text{mis}}.$$

D.2 扰动插补策略

为了模拟插补中的估计噪声，对条件分布进行扰动：

$$\varphi(\tilde{x}, y)_{\text{mis}} \sim \mathcal{N}\left(\tilde{\mu}_{\text{mis}}, \tilde{\Sigma}_{\text{mis}}\right),$$

其中：

$$\tilde{\mu}_{\text{mis}} = \alpha \cdot \mu_{\text{mis}|\text{obs},Y} + \Delta, \qquad \tilde{\Sigma}_{\text{mis}} = \Sigma_{\text{mis}|\text{obs},Y} + \tau I,$$

这里 $\alpha > 0$，$\Delta \in \mathbb{R}^{|\text{mis}|}$ 是偏差项，$\tau > 0$ 为方差膨胀。

如正文所述，加权共形预测的关键要素是似然比：

$$\omega_m(x_{\text{obs}},\, y) = \frac{dP_m(x_{\text{obs}},\, y)}{dQ_m(x_{\text{obs}},\, y)},$$

其中 P_m 是 $(X,\, Y) \mid M = m$ 的真实掩码条件分布，Q_m 则是由插补校准数据诱导的分布。在这一设置中，两者都可计算：P_m 是原始高斯分布，而 Q_m 是来自扰动插补的混合高斯分布。在我们的扰动插补策略下，各项均可处理。

D.3 实证评估

在固定掩码 $m = [1,\, 1,\, 1,\, 0,\, 0]$ 下进行受控模拟，其中 $d = 5$、$\mu_X = 1_d$，协方差 $\Sigma_X = \rho 1_d 1_d^{\mathsf{T}} + (1-\rho)I$，$\rho = 0.8$。生成 500 个训练样本、200 个校准样本和 100 个测试样本。扰动设置为 $\Delta = 0.5$、$\alpha = 1.5$、$\tau = 0.2$。目标覆盖率为 90%。随后评估以下情况：

1. 无校正：由分布偏移导致失覆盖。
2. 预言校正：使用精确的 ω_m。
3. 估计校正：使用算法 2 学习 ω_m 的估计量 $\widehat{\omega}_m$。
4. 扰动估计：向 $\widehat{\omega}_m$ 施加受控噪声，检验对不同质量密度估计量的稳健性（详见 D.4 节）。

每种设置重复 100 次，以计算覆盖率统计量及其对估计量质量的敏感性。发现如下：

- 未校正 CP 因测试/校准分布偏移而低估覆盖率（86%）。
- 预言校正 CP 达到接近完美的覆盖率（89%-90%）。
- 使用算法 2 估计权重达到所需覆盖率，但表现出保守性（覆盖率为 93%）。
- 随着估计权重与真实权重之间的相关性下降，估计量劣化导致系统性的覆盖不足（详见 D.4 节）。

D.4 密度比估计中受控扰动的影响

为了通过实证检验本方法在不完美密度比估计下的稳健性，我们引入受控扰动。这补充了正文讨论的理论和实证发现，也回应了关于本方法对密度比质量敏感性的关切。

向估计密度比注入噪声。实现中，使用算法 2（基于直方图的梯度提升分类器）估计密度比。为模拟不同水平的估计质量，向估计密度比的对数中加入高斯噪声：

$$\log\widetilde{\omega}_m = \log\widehat{\omega}_m + \epsilon, \qquad \epsilon \sim \mathcal{N}(0,\, \sigma^2),$$

再取指数，得到带噪声的 $\widetilde{\omega}_m$。这确保扰动具有乘性，并现实地刻画比值空间中的偏离。

实证评估。在 100 次重复中的每次实验里，对密度比估计量施加扰动，利用校准数据上真实与估计密度比值之间的 Pearson 相关系数，评估密度比估计量的质量。随后测量加权 CP 方法得到的掩码条件覆盖率。因此，每次重复都对应不同质量的密度比估计量（以 Pearson 相关性衡量）及其关联覆盖率。图 6 绘出相关性与经验覆盖率的散点图。我们观察到很强的正向关系：当相关性超过 0.3 时，覆盖率稳定在 90% 的名义水平附近，表明该方法对中等程度的估计误差具有稳健性。

D.5 理论失覆盖界的评估

目标是通过实证验证命题 3 的有效性：由不完美密度比估计引起的失覆盖，可由数据估计出的量给出上界。具体来说，使用包含 500 个独立同分布样本的辅助数据集构造分布 P_m 和 $\widetilde{P}_m$，训练分类器 $\widehat{g}_m$ 以区分二者，并评估所得分类错误是否构成所观测失覆盖的有效上界。根据 C.6 节，有：

$$P(Y \in \widehat{C}_\alpha^{\widetilde{W}}(\tilde{X}) \mid M = m) - 90\% \geq -(1 - 2\widehat{\mathcal{R}}(\hat{g}_m)).$$
$$\leftrightarrow 90\% - P(Y \in \widehat{C}_\alpha^{\widetilde{W}}(\tilde{X}) \mid M = m) \leq (1 - 2\widehat{\mathcal{R}}(\hat{g}_m)).$$

每次重复实验均可计算失覆盖：

失覆盖 = 90% − 真实覆盖率。

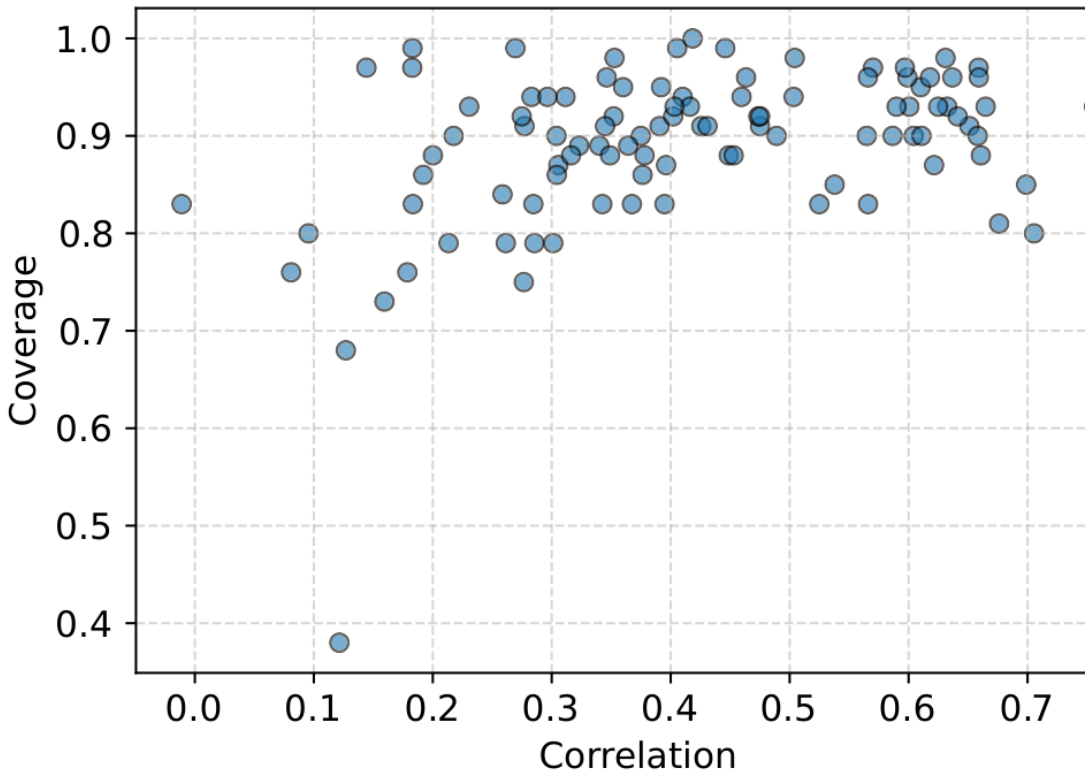


图 6： 覆盖率与估计密度比、真实密度比之间相关性的关系。每个点代表一次实验。较高相关性产生接近名义水平的覆盖率。图中 Coverage 为覆盖率，Correlation 为相关性。

还可使用额外数据集，计算区分 P_m 和 $\widetilde{P}_m$ 的分类器的经验误差 $\widehat{R}(\widehat{g}_m)$，以及经验失覆盖量 $1 - 2\widehat{R}(\widehat{g}_m)$。理想情况下，应观察到全部失覆盖均受 $1 - 2\widehat{R}(\widehat{g}_m)$ 控制。图 7 比较经验失覆盖与理论界 $1 - 2\widehat{R}(\widehat{g}_m)$。大多数观测失覆盖值位于红色直线 $y = x$ 下方，验证了该界的有效性。

这些发现共同表明，本方法在实证上对不完美的密度比估计具有稳健性，而且可在实践中推导和验证失覆盖的理论界。

附录 E 详细实验

E.1 运行时间比较

在相同数据集上比较全部四种方法的运行时间，即每种缺失模式有 100 个点。所有实验均在同一服务器上运行，CPU 为 Intel XeonGold 6252 @ 2.10GHz。表 3 给出四种方法在两个数据集上的运行时间。我们提出的 AR 校正方法运行时间与 MDA-Exact 相当，远快于 MDA-Nested 和加权 CP。这符合预期，因为 MDA-Nested 要以不同方式修改测试点与校准点，而加权方法需要采用类似“网格搜索”的方法评估预测区间，不能显式求解。因此，我们提出的基于接受-拒绝的方法可成为替代加权共形预测的良好候选，尤其是在加权 CP 区间没有简单显式形式时。

表 3：四种方法的运行时间比较。

方法	合成数据集	混凝土数据集
MDA-Exact	17034 秒	2031 秒
MDA-Nested	510932 秒	43225 秒
Weighted CP	228638 秒	37983 秒
ARC CP	21320 秒	4766 秒

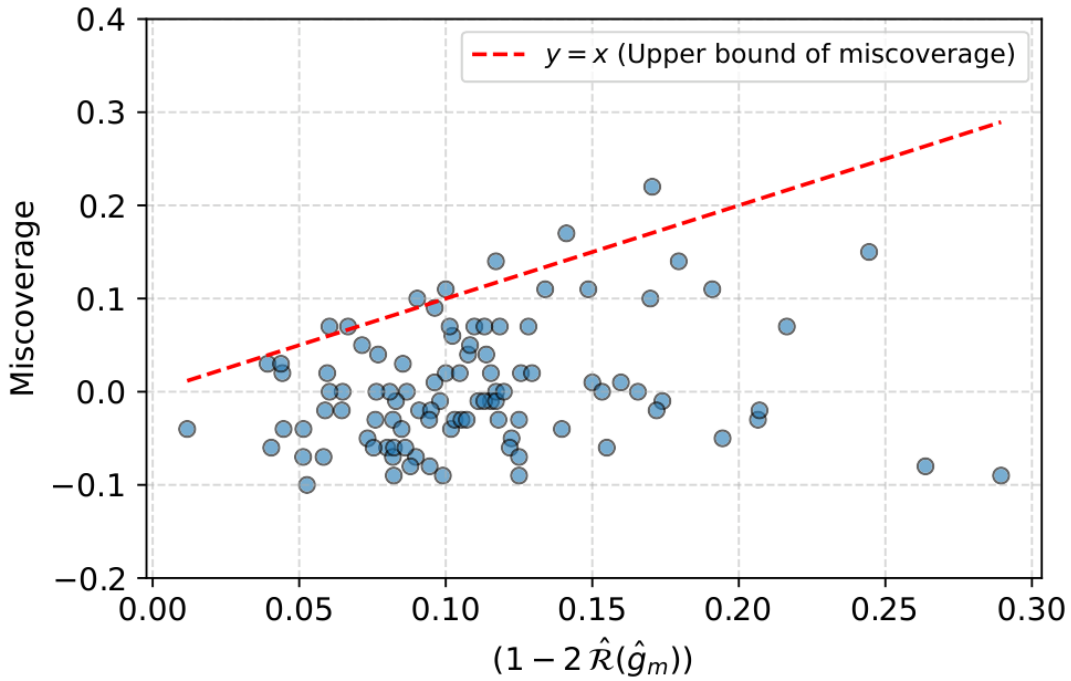


图 7：失覆盖与估计界的关系。位于 $y = x$ 下方的点确认该界的保守性。Miscoverage 表示失覆盖；图例中的 Upper bound of miscoverage 表示失覆盖上界。

E.2 另一个真实数据集

UCI 仓库的共享单车数据集（Fanaee-T，2013）。目标值是每小时租借自行车的总数。共有 4 个连续协变量和 12 个离散协变量。选取 5000 个训练数据和 100 个校准数据。在 MCAR 机制下，每个特征的缺失率为 50%，为每种缺失模式另生成 100 个测试数据。由于有 4 个连续协变量，共存在 15 种（$2^4 - 1$）缺失模式。

表 4：不同方法在共享单车数据集上的比较。列出 15 种不同缺失模式的平均覆盖率和区间宽度。

方法	平均覆盖率	平均宽度
MDA-Exact	92.9 ± 0.7	∞
MDA-Nested	91.8 ± 0.5	336.3 ± 2.3
Weighted CP	91.9 ± 0.6	306.4 ± 2.2
ARC CP	93.0 ± 0.6	309.9 ± 3.1

结果见表 4，可以观察到相似结论：MDA-Exact 对某些掩码可能无法工作，从而使区间平均宽度为无穷大；MDA-Nested 高估不确定性；而我们的方法在保持掩码条件有效性的同时，提供宽度更短的预测集。

MEPS19 数据集。MEPS19 数据集是指由美国医疗保健研究与质量局（AHRQ）开展的 2019 年医疗支出小组调查。[6] 这是针对美国家庭和个人的大规模全国代表性调查，收集医疗服务利用、支出、保险覆盖及健康状况的详细信息。数据集包含连续和分类协变量：在我们的设置中，使用 5 个连续协变量和 134 个离散协变量。

分析中的目标变量 `UTILIZATION_reg` 是医疗服务利用的综合指标，由描述医疗服务使用频率和强度的 MEPS 变量推导而来。由于目标值范围很广，使用加权共形预测（Weighted CP）在计算上面临挑战，因为它需要在可能结果的稠密网格上评估一致性评分。因此，重点比较 MDA-Exact、MDA-Nested 和我们的 ARC-CP 方法。

随机选取 1000 个训练样本及 500 个校准样本。5 个连续协变量按照完全随机缺失（MCAR）机制产生缺失。重复实验 50 次，估计平均覆盖率及其相应置信区间。表 5 的结果表明，所有方法均达到所需覆盖率，而 ARC-CP 方法产生最短平均区间长度。

表 5：不同方法在共享单车数据集上的比较。列出 32 种不同缺失模式的最坏情形覆盖率和区间宽度。

方法	覆盖率	区间宽度
MDA-Exact	94.03 - 95.01	33.0
MDA-Nested	94.29 - 95.15	34.1
ARC CP	94.04 - 95.04	32.08

Communities and Crime 数据集。为进一步探索高维表现，增加了 Communities and Crime 数据集（Redmond and Baveja，2002）上的实验，这是一个包含 122 个实值特征的回归任务。允许全部特征缺失，因此有 2^{122} 种可能掩码，并随机抽取 1000 种掩码，分别评估掩码条件覆盖率。对于 ARC-

CP，这 1000 种掩码中的最坏掩码条件覆盖率为 87.8%；仅有 49 种掩码的覆盖率低于 90%（介于 87.8% 和 90% 之间），表明即使在这种富有挑战性的高维真实数据设置中，ARC-CP 仍然稳健且合理接近目标。MDA-Exact 始终给出无穷区间，而 Nested 和 Weighted CP 无法在合理时间（一周）内完成。

E.3 校正的必要性

为了说明本校正方法能有效保证 MCV，在第 4.4 节数据集上分别进行应用和不应用校正方法的实验。图 8 和图 9 比较是否采用校正方法时各缺失模式的覆盖率与区间宽度。不使用校正时，最坏掩码条件覆盖率为 89.1%，表明若没有合适的权重/接受机制来调整原始校准集，分布偏移会导致真实标签的覆盖不足。

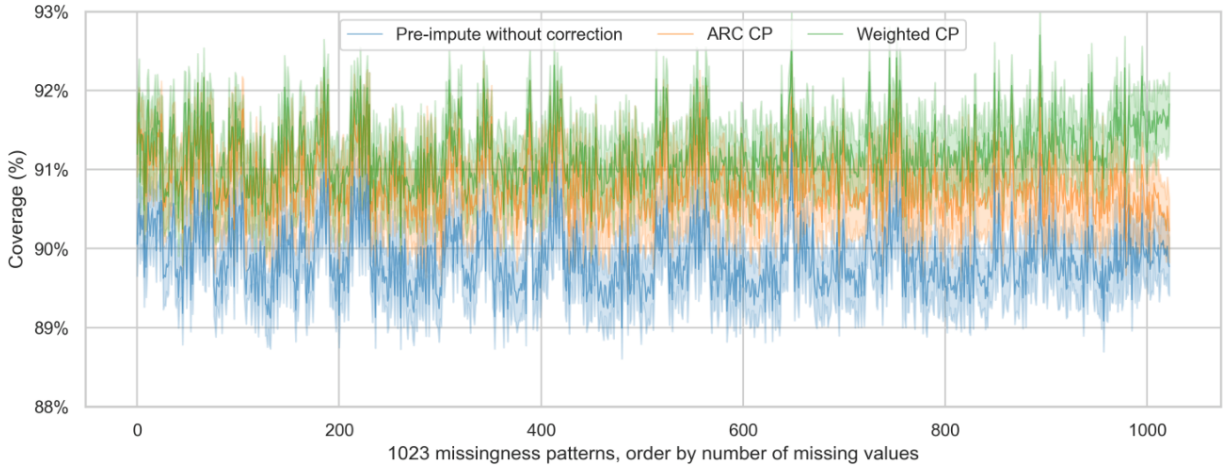


图 8：合成数据集：在 1023 种缺失模式下，比较采用和不采用所提出校正方法时的预测覆盖率（均值及 99% 置信区间）。

图 8–16 中共同使用的图内文字译释：Coverage (%) 为覆盖率（%）；Width of prediction interval 为预测区间宽度；missingness patterns, ordered by number of missing values 为按缺失值数量排序的缺失模式；Pre-impute without correction 为不加校正的预插补；Oracle length 为预言区间长度；Inf 为无穷；MDA-Exact、MDA-Nested、ARC CP、Weighted CP 为文中方法名称（分别对应精确 MDA、嵌套 MDA、接受-拒绝校正 CP 和加权 CP）。

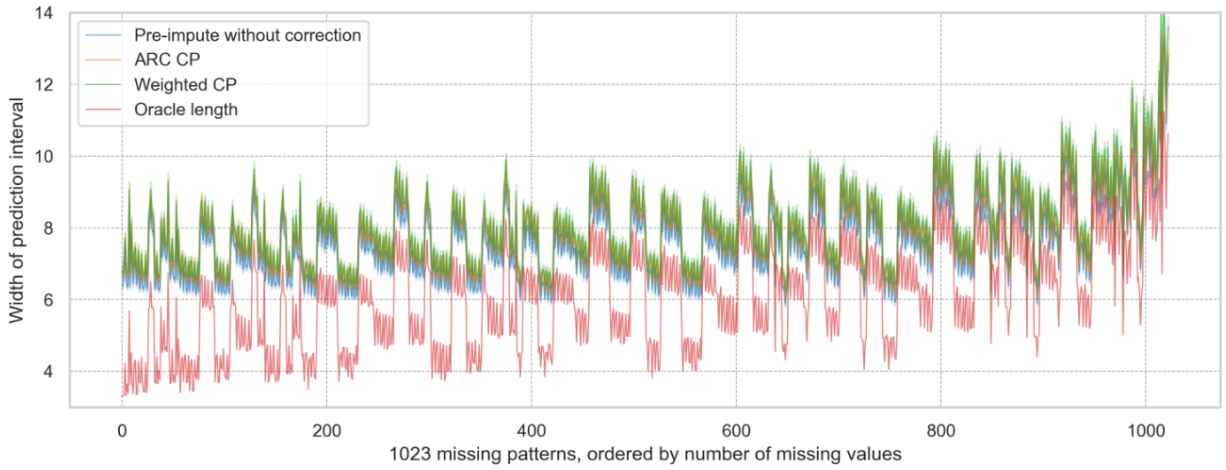


图 9：合成数据集：在 1023 种缺失模式下，比较采用和不采用所提出校正方法时的预测区间宽度（均值及 99% 置信区间）。

E.4 混凝土数据集实验

图 10 给出混凝土数据集按缺失模式划分的覆盖率。

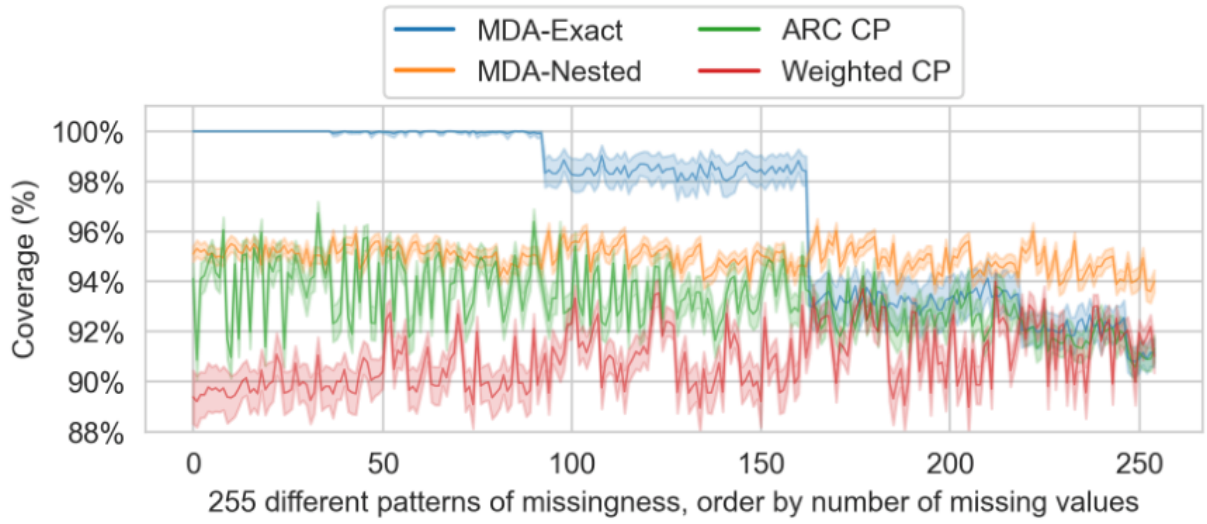


图 10：混凝土数据集：255 种缺失模式下预测覆盖率的均值及 99% 置信区间。

对于 MAR 设置，四种方法按缺失模式划分的最坏情形覆盖率和边缘预测区间宽度见表 6。

表 6：有 4 个可能 MAR 缺失协变量的混凝土数据集，15 种掩码上的最坏情形覆盖率（95% CI）和平均预测区间宽度。

机制	MDA-Exact	MDA-Nested	Weighted CP	ARC CP
MAR	89.1% ± 1.64% / 29.1	90.8% ± 1.43% / 31.4	89.1% ± 1.91% / 29.8	90.6% ± 1.42% / 28.9

对于自掩蔽 MNAR 设置，通常很难为每种模式生成足够多测试点，因此允许 2 个协变量缺失。四种方法按缺失模式划分的最坏情形覆盖率与边缘预测区间宽度见表 7。

表 7：有 4 个可能缺失协变量的混凝土数据集，15 种掩码上的最坏情形覆盖率（95% CI）和平均预测区间宽度。

机制	MDA-Exact	MDA-Nested	Weighted CP	ARC CP
MNAR	89.0% ± 1.78% / 30.1	88.7% ± 1.76% / 30.4	90.0% ± 1.67% / 30.8	89.0% ± 1.83% / 30.1

E.5 其他设置下合成实验的补充

E.5.1 更少的缺失值

考虑同一合成数据集设置，但缺失率由 50% 改为 20%。如前所述，当数据集存在大量缺失值，而希望对几乎没有缺失值的测试点实现 MCV 时，MDA-Exact 可能因校准数据集中样本点不足而给出无信息预测区间。不过，当缺失值较少时，这种方法应能较好工作。图 11 和图 12 比较 MDA-Exact、MDA-Nested 以及我们的方法。观察到 MDA-Exact 给出无信息预测集的可能性减小，但当测试点缺失值较少时，MDA-Exact 和 Nested 均表现出缺失条件覆盖过度。我们的方法对所有缺失模式的覆盖率表现得更稳定。对所有缺失模式，AR 校正方法的平均预测区间宽度较 MDA-Nested 减少 10.7%。



图 11：缺失率为 20% 的合成数据集：1023 种缺失模式下预测区间宽度的均值与 99% 置信区间，比较是否使用校正方法。

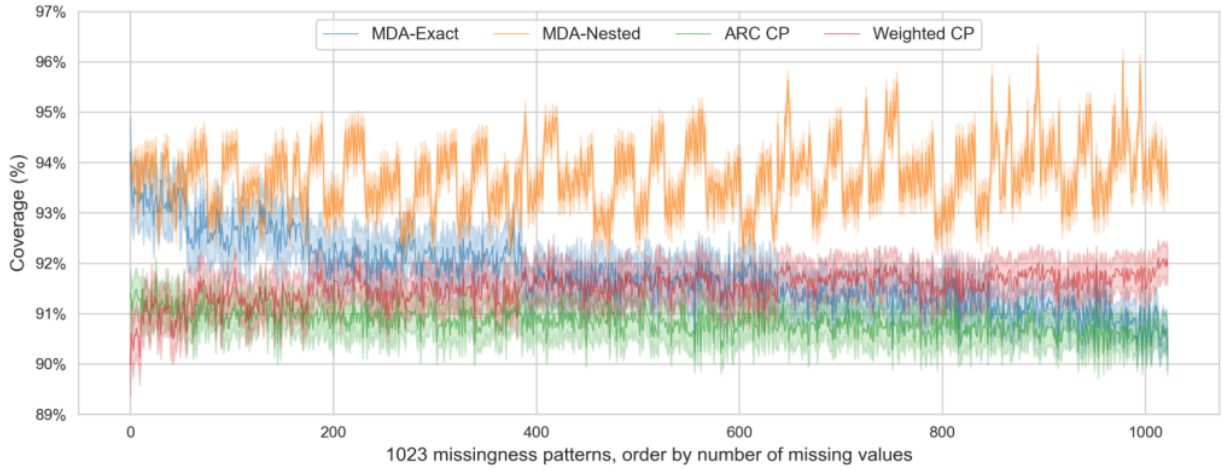


图 12：缺失率为 20% 的合成数据集：1023 种缺失模式下预测覆盖率的均值与 99% 置信区间，比较是否使用校正方法。

E.5.2 特征独立（$\rho = 0$）的合成数据集

与 Zaffran 等（2024）类似，在特征独立（$\rho = 0$）的数据集上开展另一项实验，此时插补无法优于各特征的边缘期望。缺失率仍保持为 20%。相应结果见图 13 和图 14。观察到类似结论：对所有缺失模式，AR 校正方法的平均预测区间宽度较 MDA-Nested 减少 8.9%。



图 13：缺失率为 20%、特征独立的合成数据集：1023 种缺失模式下预测区间宽度的均值与 99% 置信区间，比较是否使用校正方法。

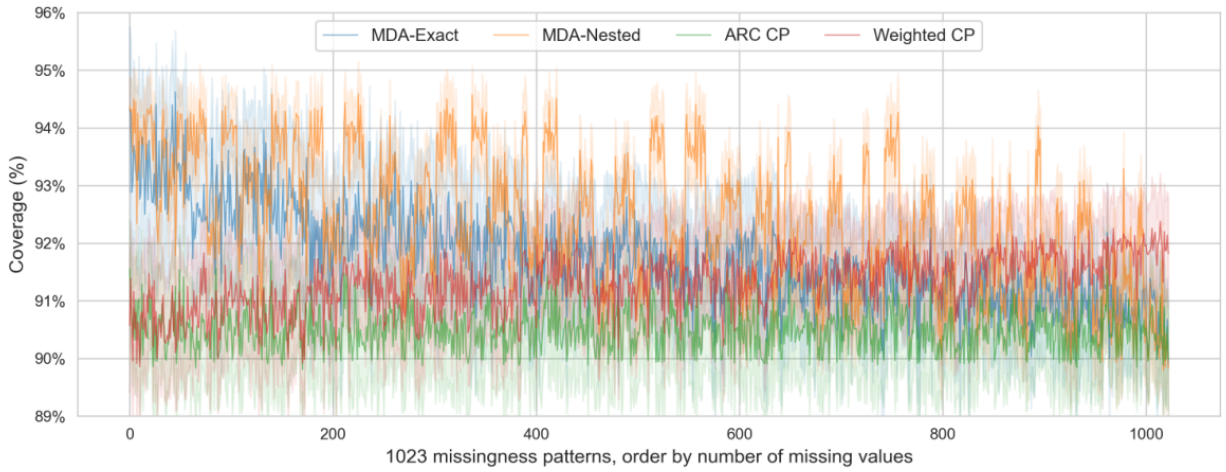


图 14：缺失率为 20%、特征独立的合成数据集：1023 种缺失模式下预测覆盖率的均值与 99% 置信区间，比较是否使用校正方法。

E.6 图 2 和图 3 的未平滑结果

第 4 节实验中的未平滑结果见图 15 和图 16。

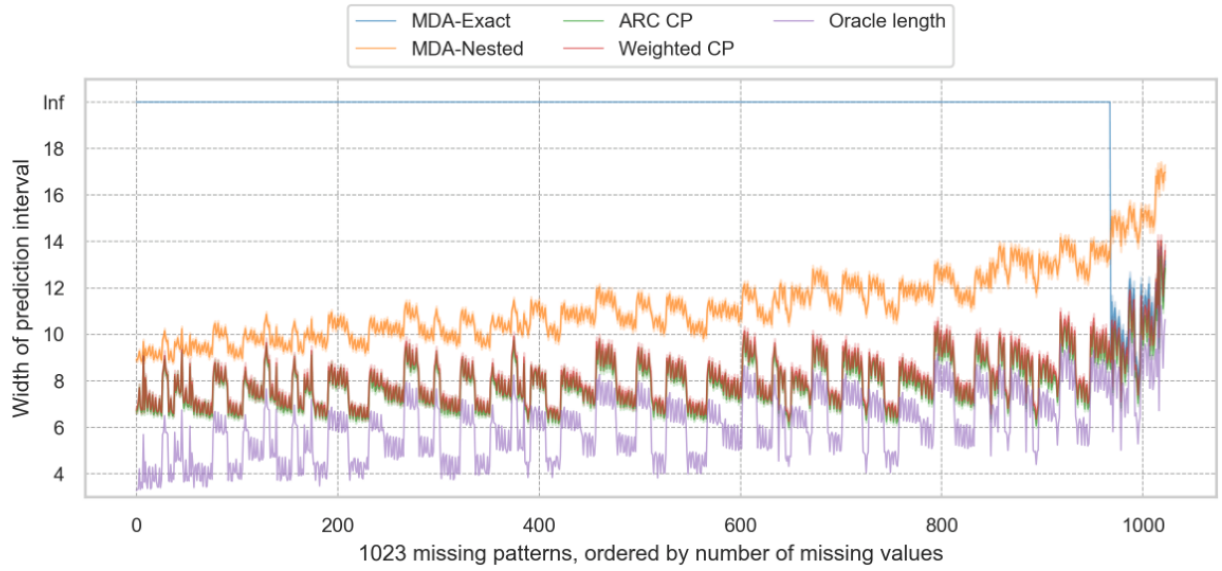


图 15：合成数据集：1023 种缺失模式下预测宽度均值和 99% 置信区间的未平滑结果。

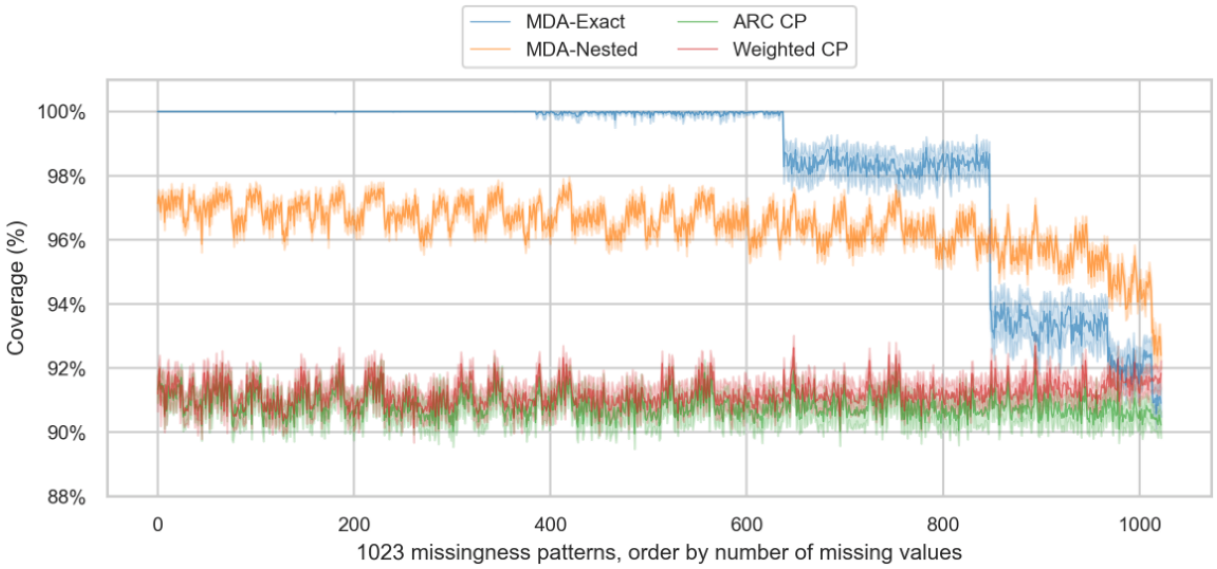


图 16：合成数据集：1023 种缺失模式下预测覆盖率均值和 99% 置信区间的未平滑结果。

E.7 100 维合成实验的系数向量 β

在第 4.2 节的 100 维合成实验中，将线性模型系数固定为 $\beta =$ （1, 2, -1, 3, -0.5, -1, 0.3, 1.7, 0.4, -0.3, -2.84, 0.91, 2.77, -0.68, 1.53, -1.94, 0.44, -2.21, 2.05, -0.17, -1.46, 0.23, 1.88, -2.63, 2.41, -0.82, 0.71, -1.12, 2.58, -0.49, -2.05, 1.37, -0.94, 2.63, -1.59, 0.52, -2.77, 1.96, -0.08, 2.24, -1.23, 0.35, 2.49, -2.36, 1.14, -0.71, 2.81, -1.76, 0.62, -2.48, 1.79, -0.27, 2.92, -1.65, 0.84, -2.58, 2.18, -0.41, 1.25, -2.93, 2.67, -0.56, 1.48, -2.12, 0.19, 2.32, -1.88, 0.77, -2.69, 2.55, -0.63, 1.61, -2.44, 0.58, 2.86, -1.31, 0.05, -2.29, 1.92, -0.14, 2.37, -1.57, 0.49, 2.99, -2.72, 1.08, -0.35, 2.14, -1.99, 0.66, -2.11, 0.88, -1.45, 2.63, -0.72, 1.57, -2.33, 0.12, 2.48, -1.08），与公开代码所示一致。

译者核对说明

本译文覆盖原PDF全部32页，正文、致谢、参考文献、检查清单与附录A–E均完整保留。英文图内标签由相邻中文图注译释；复杂推导和部分表格保留原始高清裁剪，以免改变数学符号、推导步骤或数值。

原文的记号和论证疑点未擅自修正：

- 式（1）将掩码算子的值域写为 $\mathcal{X}$，而算子包含NA；按原文保留。
- 假设2要求 $P \ll Q$，其后举例段落却用相反方向的绝对连续性作说明；照原文翻译，不替作者补强假设。
- 第3.4节称似然比估计仅使用校准集，但算法2输入以上标 t 编号；原记号保留。
- 命题1的MCAR专式使用 X^{n+1}，其一般式用 $\widetilde{X}^{n+1}$；保留原始公式。
- C.1证明中的密度 p/q 书写及全变差距离系数存在疑点；原始完整推导裁剪保留，不作隐性修正。
- 附录A的确定性插补输入、命题4逐点密度/导数表述，以及附录B的 B_u/B_h 切换与上端点 y，均按原文保留；具体译注紧随对应段落。

- 表5相关正文说MEPS19，而表题写Bike sharing；表7正文说2个协变量，表题写4个协变量/15种掩码；均保留原文并说明。
- 正文第4.3节中 ARC CP 与加权CP的最坏覆盖率分别写为 $90.1\% \pm 1.63\%$ 与 $90.6\% \pm 1.42\%$，与表6中两列的数值不一致；正文与表格均照原文保留，不擅自对调或订正。
- 正文第4.3节的“三个附加数据集”后原文用“Both”；译文用“它们”衔接，数量仍为三个。

数学字体核对依据：源PDF中一般变量（包括向量 X, Y, M, β, μ）使用CMMI普通数学斜体，Σ 采用CMR；本文未因其向量/矩阵语义擅加粗。集合与风险等花体符号按CMSY字形还原；附录引理1的分布 $\mathbb{P}$, $\mathbb{Q}$ 依据MSBM字体使用黑板粗体，与概率运算符 P 区分。源字体逐跨度证据保存在 `source/font_evidence.json`。

---

1. 本文对向量 V 使用下标 V_i 表示其第 i 个元素。↩

2. 代码见 https://github.com/jrfan/Mask-Conditional-Conformal-Prediction 。↩

3. 通过对全部1023种缺失模式的区间宽度取平均来比较区间宽度。↩

4. 按缺失模式划分的覆盖率结果详见附录E图10。↩

5. 或者，等价地考虑分布 $\mathrm{mask}\left(X^{n+1}, M^{n+1}\right) \mid M^{n+1} = m$，因为 $\widetilde{X}^{n+1} = \mathrm{mask}\left(X^{n+1}, M^{n+1}\right)$。↩

6. https://meps.ahrq.gov/data_stats/download_data_files.jsp↩