警惕差距 多模态主动学习陷阱评估框架

Mind the Gap: A Framework for Assessing Pitfalls in Multimodal Active Learning

作者： Dustin Eisenhardt[1,2,3]（通讯作者），Yunhee Jeong[6]，Florian Buettner[1,2,3,4,5]

Dustin Eisenhardt：ORCID 0009-0007-6777-9038；Yunhee Jeong：ORCID 0000-0002-1150-7734；Florian Buettner：ORCID 0000-0001-5587-6761。

1. 德国癌症研究中心（DKFZ），德国海德堡。
2. 德国癌症联盟（DKTK）法兰克福／美因茨合作站点，由 DKFZ 与 UCT Frankfurt-Marburg 合作设立，德国美因河畔法兰克福。
3. 法兰克福歌德大学信息学研究所，德国美因河畔法兰克福。
4. 法兰克福歌德大学医学系，德国美因河畔法兰克福。
5. 法兰克福癌症研究所（FCI），德国美因河畔法兰克福。
6. 拜耳股份公司作物科学事业部，德国美因河畔法兰克福。

通讯邮箱：dustin.eisenhardt@dkfz-heidelberg.de

版本与许可说明

本文件为 **arXiv:2603.29677v1（2026 年 3 月 31 日）** 的非官方中文全文译文，涵盖摘要、正文、第 A 与 B 附录、致谢及全部 32 条参考文献。原著作者为 Dustin Eisenhardt、Yunhee Jeong 和 Florian Buettner。

版本页面：https://arxiv.org/abs/2603.29677v1
版本 PDF：https://arxiv.org/pdf/2603.29677v1
原文与本中文翻译改编的许可：**知识共享署名-相同方式共享 4.0 国际许可（CC BY-SA 4.0）**，https://creativecommons.org/licenses/by-sa/4.0/；法律文本：https://creativecommons.org/licenses/by-sa/4.0/legalcode。

中文翻译与排版由 OpenAI ChatGPT 于 2026 年 10 月制作；未获原作者审校，不表示原作者认可。改动为英文文字的中文翻译、重新分页排版、中文图表说明与明确标识的译者注；公式、实验图和数据表保留原版裁切，未改动数据、曲线、符号或原有加粗／斜体。参考文献保留原始书目信息，并附中文题名。图表中的英文标签由中文说明解释。

本翻译改编亦依 **CC BY-SA 4.0** 提供：再分发须保留适当署名、原文及许可链接并注明修改；进一步改编的贡献须按相同许可发布，不得增加妨碍许可所允许使用的法律或技术限制。本文件只在授权的云端工作区制作，不改变原始论文文件。

从官方版本链接下载的 PDF 与仓库原件的 SHA-256 完全一致：`e831288a781ce695a1131c964f1a27fe8ad305f7b7323c32b839428efea851aa`。11 幅图均已逐幅检查；图 1 为合成样例，图 2–11 为实验图，未发现单独的第三方署名或排除许可声明。原文若存在公式、术语或设置上的不一致，本译文保留并在相应位置注记，不擅自改正。

摘要

多模态学习使神经网络能够整合来自异构来源的信息，但在这一场景中，主动学习面临独有的挑战，包括模态缺失、模态学习难度的差异，以及不同的交互结构。这些问题在单模态情形中并不存在。尽管单模态场景下主动学习策略的行为已经得到充分刻画，人们对于这些多模态条件下的行为仍缺乏理解。

我们提出一个新的多模态主动学习基准评测框架，利用合成数据集将这些陷阱分离出来，从而在不受混杂噪声影响的情况下进行系统评估。我们使用该框架比较单模态与多模态查询策略，并在两个真实世界数据集上验证所得发现。

结果表明，模型总是形成不平衡的表征，主要依赖某一个模态而忽视其他模态。现有查询方法无法缓解这一效应，多模态策略也未能稳定优于单模态策略。这些发现揭示了现有主动学习方法的局限性，强调了设计具有模态感知能力、明确针对这些陷阱的查询策略的必要性。代码与基准资源将公开发布。

关键词： 多模态学习；主动学习。

1 引言

训练现代神经网络需要大规模的标注数据集。当模型必须处理来自图像、文本、表格特征或时间序列信号等多个来源的输入时，标注负担会进一步增加，因为每个样本可能需要在多个模态上进行标注。这对于生物医学应用尤其困难，因为标注只能由领域专家以高昂成本完成。主动学习（active learning，AL）旨在通过选择信息量最大的样本进行标注来降低这些成本。模型首先在小规模标注数据集上训练，随后与查询策略配合，迭代选择新的待标注样本，直到达到令人满意的性能。

尽管单模态场景中的 AL 已被广泛研究，人们对它在多模态学习中的行为仍了解不足。多模态模型面临若干挑战，可能妨碍其充分利用所有可用模态中的信息。本文识别出三种此类挑战，将其称为“陷阱”，并评估它们对 AL 的影响。首先，训练或推断期间可能发生模态缺失。其次，当某个模态包含的信号比另一个模态更容易学习时，会出现模态不平衡。第三，模态的有用性取决于其交互结构，即信息是在模态之间共享、仅为某个模态独有，还是具有互补性、必须同时使用两个模态才能正确预测。

这些陷阱可以相互作用并扭曲 AL 方法的行为。例如，如果一个模态更容易学习，模型可能主要依赖它，导致其余模态的表征贫乏。由此，所学表征失衡，模型严重依赖单一模态。这引出了一个问题：在存在此类不平衡时，现有查询策略是否仍能识别有信息量的样本？

为研究这一问题，我们提出一个系统评测多模态 AL 的框架，使研究者能够对多模态场景下 AL 方法的性能作出有意义的判断。该框架包括一组合成数据集，能够隔离上述陷阱并有针对性地分析其影响。通过控制模态缺失、难度和交互结构，框架能够排除真实数据集中常见的混杂噪声，进行系统评估。此外，我们在选定的真实世界数据集上验证研究发现。使用该框架，我们对单模态与多模态 AL 查询方法进行了广泛的实证比较。

实验表明，所有陷阱都会强烈影响学习行为。特别是，我们始终观察到，网络主要依赖某一个模态而在很大程度上忽略另一个模态。现有查询方法无法缓解这一现象。此外，在我们的实验中，多模态查询策略并未稳定优于相应的单模态策略。这些结果揭示了当前 AL 方法应用于多模态场景时的重要局限。

我们的贡献如下：

- 识别并形式化了多模态 AL 的三个关键陷阱：模态缺失、模态不平衡，以及不同的模态交互结构。
- 提出具有可控合成数据集的基准评测框架，系统地隔离每一种陷阱，从而有针对性地分析其对多模态 AL 性能的影响。
- 提供首个全面的多模态 AL 基准，在合成与真实世界数据集上比较单模态和多模态查询策略，表明现有方法未能解决所识别的陷阱。

2 相关工作

2.1 主动学习

AL 旨在尽量减少训练高性能模型所需的标注样本数。以少量已标注样本预算和一个大规模未标注数据池为起点，AL 迭代选择信息量最大的样本，交由标注者（oracle）标注，并加入标注集。

在 AL 中，待标注样本由查询方法决定。查询策略可分为三类：基于不确定性、基于多样性，以及混合方法。基于不确定性的方法假设，高不确定性样本会为训练带来新的知识。Entropy 获取熵最高的样本，BALD [5] 根据互信息选择样本。KCG [23] 是基于多样性的方法，通过在分类器表征空间中求解 K-Center 问题，尽可能覆盖数据集。混合方法结合不确定性采样与多样性采样。例如，BADGE [1] 在分类器的梯度空间中使用 K-Means++ 初始化寻找聚类中心。

已有多个 AL 基准 [19,29,12] 揭示了单模态查询方法的重要失效模式。例如，在适当控制实验条件后，许多策略无法优于随机采样 [19]。但这些基准均未考虑多模态数据特有的挑战，例如模态不平衡或模态缺失。据我们所知，尚不存在多模态 AL 基准。

2.2 多模态主动学习

在多模态 AL 中，样本包含多个模态的输入。BMMAL [24] 和 GRACE [18] 是基于 BADGE 的多模态查询方法。BMMAL 根据各模态的贡献引入权重，以实现模态平衡的样本选择。GRACE 使用信息性、代表性和易学性得分来指导样本选择，并在 AL 周期中调整这些得分。

文献 [15] 和 [21] 通过修改网络架构，学习选择有信息量的样本；文献 [25] 则对齐不同模态的表征，并查询单模态距离最小的样本。文献 [7,32,9] 提出了针对特定领域或任务的查询方法：[7] 为野生动物监测使用融入领域知识的度量，[32] 专门为视觉语言模型的目标检测设计查询方法，[9] 利用外部大语言模型对样本排序。

2.3 多模态学习

多模态学习旨在整合异构来源的信息，以提高预测性能。

模态缺失是真实世界多模态系统中普遍存在的挑战：在模型生命周期的任何阶段，传感器故障、隐私限制或数据采集异常都可能导致模态缺失 [30]。现有方法通过从可用模态组合或生成缺失模态来处理这一问题，或者采用鲁棒表征学习，在输入不完整时维持可靠预测 [30]。

多模态学习的一个核心挑战是模态不平衡。由于神经网络的简单性偏置，多模态模型往往依赖最容易学习的模态，使其他模态即使在收敛后也训练不足 [3,11]。已经提出的补救方法包括动态平衡模态贡献的梯度调制策略 [31]，以及模态随机丢弃（modality dropout）[20]：后者在训练中随机丢弃模态，以在学习跨模态相关性的同时保留各模态特有的表征。

除了冗余信息共享外，模态还可以以更丰富的方式交互：信息可能仅为单个模态独有，也可能具有协同性，即只有把两个模态结合起来才会变得有用 [4]。

3 主动学习中的多模态陷阱

本节介绍多模态陷阱，并解释它们如何对多模态 AL 构成独特挑战。为清楚起见，我们在双模态场景中描述这些陷阱；它们可以直接推广到更多模态。

P1 模态缺失

通常无法保证每个样本都包含所有模态。相反，在模型生命周期的任何阶段，都可能出现模态不完整的样本。即使某些样本存在模态缺失，训练和推断也必须正常运行。这一陷阱会随着神经网络生命周期阶段的不同而产生不同后果。

P1.1 训练期间的模态缺失： 可能使更频繁缺失的模态学习不充分。

P1.2 推断期间的模态缺失： 使神经网络无法访问这些模态中的信息。

与 AL 的关系： 查询方法必须选择适当样本，使神经网络能够充分学习所有模态。应平衡模态缺失情况，避免形成只包含单一模态的标注集。

P2 模态不平衡

神经网络倾向于利用最简单的学习路径完成任务，这可能使模型忽略更具挑战性的模态，无法有效从中学习。不同模态的复杂度不同，也就是说，某些模态在本质上比其他模态更容易学习。因此，已有观察发现，多模态神经网络过度依赖单一模态进行预测，而忽略其余模态 [3]。我们把更容易的模态称为“强”模态。这种不平衡会导致弱模态的表征学习不足，不仅降低其单独使用时的性能，也降低联合多模态性能。

与 AL 的关系： 查询方法不应强化模态不平衡。样本获取应推动联合模态性能的提高。不过，模态不平衡要求查询方法也选择那些专门有助于改善弱模态的样本。

P3 模态交互

与任务相关的信息可以以不同方式分布在各模态中 [4]。

P3.1 共享信息： 信息可能在模态间共享，使每个模态都包含正确分类目标变量所需的全部信息。

P3.2 独有信息： 相反，信息也可能仅为某个模态独有，即只有包含这一模态才能解决任务。

P3.3 互补信息： 模态中的信息可能互补。在这种情况下，只有汇总两个模态中的信息才能解决任务。

与 AL 的关系： 样本的信息量必然与信息从输入模态流入的方式有关。无论模态交互属于何种类型，查询方法都应能够可靠地估计样本信息量。

陷阱共现

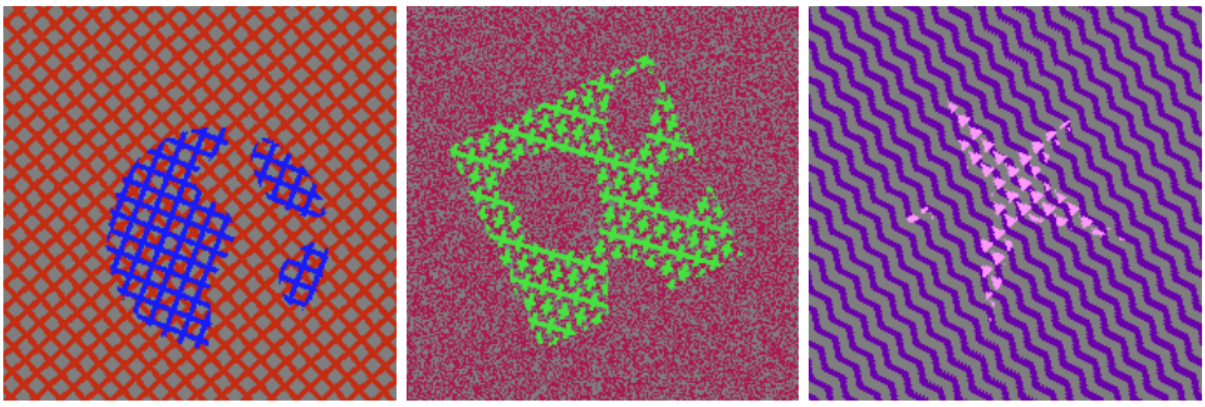
这些陷阱并不互斥；在实践中，它们会共同出现。例如，在皮肤病灶分类中，模型可能结合皮肤镜照片和从活检切片得到的组织病理图像。组织病理图像具有细致的细胞信息，因此通常是较强的模态（P2）。但其可用性取决于诊断阶段：皮肤镜图像在筛查时即可获取，而组织病理图像只有在活检之后才能获取（P1）。一些信息在两种模态间共享，例如病灶是否异常；另一些信息则只有组织病理学才能提供，例如具体的病灶亚型（P3）。因此，当仅有皮肤镜图像时，分类器可能难以准确预测。这说明模态不平衡和模态缺失如何共同降低性能。

4 多模态主动学习框架

本节解释基准的设计。我们首先介绍用于构建实验的合成数据集，随后介绍为评估上述陷阱而设计的实验，以及真实世界数据集。

4.1 QuintFeatures 数据集

为严格评估方法，我们开发了一个新的合成数据集，称为 QuintFeatures。它受 Trifeatures [10] 启发，但通过增加特征维度和额外的数据增强进行了扩展。QuintFeatures 以可控方式组合三种不同的视觉特征类型，即形状、颜色和纹理，生成逼真的图像。具体而言，我们随机采样前景形状、颜色和纹理，以及背景颜色和纹理，生成多样化的数据集，以测试不同条件下的性能。形状、颜色和纹理各有十种不同的取值。为提高数据集难度，我们还加入两种增强：首先使用 Perlin 噪声擦除前景物体的一部分；其次，在仍然保持不同取值清晰可辨的前提下，对颜色进行随机化。图 1 展示了若干示例。



(a) Blue Circle with Grid texture on Red Grid texture

(b) Green Square with Pulses texture on Purple Noise texture

(c) Pink Star with Triangles texture on Purple Zigzags texture

图 1　QuintFeatures 数据集示例。（a）红色网格纹理背景上的蓝色网格纹理圆形；（b）紫色噪声纹理背景上的绿色脉冲纹理正方形；（c）紫色锯齿纹理背景上的粉色三角形纹理星形。原始图像及子图英文标注保留。

4.2 陷阱覆盖情况

本节解释框架如何覆盖陷阱 P1–P3，并介绍四个用于系统评估的实验。

P1.1（Missing）： 为评估训练期间的缺失，我们构建称为 Missing 的数据集，包含两个以不同概率缺失的输入模态。实验目标是预测目标变量，同时不忽视缺失更频繁的第一个模态。每个模态均从 QuintFeatures 数据集（第 4.1 节）采样。目标任务是预测图像前景的形状。采样保证两个模态中的形状一致，代表信息完全共享，而其他特征随机化。为模拟这一陷阱，我们将第一个模态的缺失概率设为 90%，第二个模态设为 10%。如果在任何一步两个模态都将缺失，则随机选择其中一个保留。

P2 与 P3.1（Share）： 我们建立称为 Share 的场景：两个模态都包含解决目标任务所需的全部信息，但复杂度不同。目标是考察，在存在更易学习模态的情况下，模型能否学会利用较弱的模态。由于 QuintFeatures 中各特征的复杂度相近，我们改为将 CIFAR-10 [16] 与 MNIST [17] 分别视为两个模态，构建一个合成双模态数据集。为确保信息共享，将 CIFAR-10 中的每个类别恰好映射到 MNIST 中的一个类别。

P3.2（Unique）： 在称为 Unique 的实验中，我们评估某些信息仅对一个模态可用的情形。目标是在尽量提高每个模态性能的同时，预测共享特征与独有特征的“幂集”（power-set）。因此，我们构建包含两个输入模态的数据集，每个模态同样从 QuintFeatures（第 4.1 节）采样。目标任务是预测形状与第一个模态纹理这两种特征的“幂集”。采样保证两个模态的形状一致。由于第二个模态无法访问第一个模态所呈现的纹理信息，因此其能够达到的最高准确率为 10%。

P3.3（Synergy）： 在称为 Synergy 的实验中，我们考察模态间信息互补的情形，也就是只有两个模态都存在时，信息才对预测有用。目标是评估模型与查询策略能否利用模态间的协同作用，最大化联合预测性能。我们使用 QuintFeatures（第 4.1 节）构建双模态数据集，其中目标任务是预测第一个模态纹理与第二个模态形状的“幂集”中的类别。

> **译者注（原文术语）：** 上述两处任务定义均使用 “power-set”。本文据此保留“幂集”表述；按实验中两个各有十种取值的特征及 100 类任务语境，它似乎指特征取值组合，但此处不将原文自行改写为“笛卡尔积”。

P1.2： 我们在所有实验中穷举评估各种模态缺失组合（第 6 节）。例如，对于两个模态 A 和 B，模型在测试集上评估三次：一次仅保留 A，一次仅保留 B，一次同时保留两个模态。这样，我们就测试了模型在推断时所有可能的模态缺失情形下的能力。

4.3 真实世界数据集

为评估研究发现的泛化性，我们采用两个真实世界数据集，它们对应 Share 场景，但具有不同种类的模态。这些数据集用于验证框架，检验合成数据中识别出的陷阱以及观察到的查询方法性能是否也适用于实际场景。

Food101。 UPMC Food101 [28] 是一个大型多模态分类数据集，约有 100,000 个样本，涵盖 101 个食品类别。每个样本包含一份食谱的文本和该食谱网页上的一张图像。由于数据集是自动收集的，样本可能包含误导信息。例如，标记为“汉堡”的样本可能包含汉堡成品图像（食品）、汉堡肉饼图像（配料），或炖菜等无关内容（噪声）。

MIMIC-IV。 MIMIC-IV [6,14,13,8] 是一个大型电子健康记录数据库。我们使用其中的血液化验（bloodlabs）和心电图（ECG），对患者的一年死亡结局进行分类，即判断患者是否在入院后一年内死亡。更多信息见第 A.1 节。

5 实验设置

下面介绍实验设置，用于评估第 3 节所述陷阱下的多模态 AL。

模型架构。 所有实验均使用一种简单架构，由单模态编码器和融合层组成。融合层组合单模态特征，生成多模态潜在空间。在多模态特征上施加一个线性层，对输入进行分类。更多架构细节见第 A.2 节。

超参数选择。 我们采用文献 [19] 的超参数选择方法。使用固定的训练方案，指定训练轮数、批大小、优化器和学习率调度器（第 A.3 节）。在 AL 周期开始时，利用初始预算和验证集优化学习率、权重衰减与数据增强。最终超参数见第 A.3 节。

主动学习设置。 为模拟多种条件，我们在每个数据集上评估不同的标注规模，具体为“低标注量”“中标注量”和“高标注量”三种设置。这些设置影响初始预算、验证集和每次获取样本的大小。详细信息见第 A.4 节。

查询方法。 按照文献 [19]，我们纳入五种单模态查询方法（BADGE、BALD、Entropy、KCG、Random），以及两种多模态查询方法（BMMAL、GRACE）。其他多模态方法被排除，原因如下：[15,21,25] 需要修改训练流程，或改变架构 [15,21]，或增加损失项 [25]；而本文关注无需修改模型和训练过程的独立查询方法。[7,32,9] 面向特定应用领域或任务，因而与我们不针对特定领域的分类设置不兼容。

模态随机丢弃。 多模态数据上的实际 AL 应用往往会采用策略缓解常见多模态陷阱。为模拟这种应用，我们引入 Modality Dropout（ModDrop）[20]。ModDrop 在训练期间随机丢弃单个模态，旨在学习跨模态相关性的同时，保留各模态特有表征的独特性。所有合成实验均分别在使用和不使用 ModDrop 的条件下开展。对于真实世界实验，我们用第 A.3 节的超参数进行了预实验，发现 ModDrop 对 Food101 和 MIMIC 有益，因此对这两个数据集使用 ModDrop。

评估。 对每个评估的数据集，我们使用学习曲线下面积（Area Under the Learning Curve，AULC）报告性能。该指标汇总每次 AL 迭代后所得最佳模型的平衡测试准确率：

$$\mathrm{AULC} = \sum_{i=0}^{N-1} \frac{1}{2} \frac{\mathrm{ACC}(i+1) - \mathrm{ACC}(i)}{i+1-i}, \mathrm{ACC}(0) = 0$$

其中，ACC(i) 表示总共 N 次迭代中第 i 次 AL 迭代的平衡测试准确率。AULC 的取值范围为 [0, N]。

> **译者注（保留原公式）：** 上图忠实保留原文第 9 页的公式，其中分子为 ACC(i+1) − ACC(i)，分母为 i+1 − i。该写法与通常的学习曲线面积定义及文中所述范围／表中数值存在不一致；本译文不将减号改为加号，也不推测实验代码实际采用的计算方法。

我们在三种标注规模下报告所有查询方法的这一指标。此外，为评估这些陷阱，我们穷举评估模型在所有可能模态缺失组合下的性能（第 4.2 节）。每种设置、每种查询方法的结果都来自三次实验：改变随机种子与训练／验证划分，测试集则在各次运行中保持不变。

6 系统评估

下面对第 3 节所介绍陷阱下的多模态 AL 进行系统评估。首先单独评估每个陷阱对模型性能的影响（第 6.1 节），随后在合成数据上比较单模态与多模态查询方法（第 6.2 节），并在真实世界数据集上验证发现（第 6.3 节）。所有结果的详细图示见附录 B。

6.1 陷阱的影响

本节研究第 4.2 节所提出实验对多模态神经网络学习性能的影响。表 1 给出合成数据集高标注量设置下 Random 查询方法的 AULC。我们还比较采用 ModDrop（第 5 节）的影响。下文按陷阱逐项讨论结果。

表 1　合成数据上的 Random 查询方法。 高标注量设置下 Random 方法的 AULC，分别对每种模态组合评估。上标“+”表示为便于比较，将仅具有部分预测信息的模态得分乘以 10。Dataset＝数据集；ModDrop 中 Yes／No＝使用／不使用；Modality A／B＝模态 A／B；Both＝同时使用两个模态；Rare／Frequent＝罕见／常见模态；Full／Partial＝完整／部分信息。

Dataset	**ModDrop**	**AULC**		
		Modality A	Both	Modality B
Missing		Rare	Both	Frequent
	Yes	1.01 ± 0.08	7.94 ± 0.10	7.95 ± 0.11
	No	0.97 ± 0.05	7.94 ± 0.13	7.96 ± 0.13
Share		CIFAR-10	Both	MNIST
	Yes	5.10 ± 0.11	8.91 ± 0.01	8.81 ± 0.02
	No	4.23 ± 0.24	8.91 ± 0.01	8.82 ± 0.02
Unique		Full	Both	Partial^{+}
	Yes	8.45 ± 0.07	8.62 ± 0.09	6.40 ± 0.96
	No	8.45 ± 0.10	8.51 ± 0.06	1.76 ± 1.43
Synergy		Partial A^{+}	Both	Partial B^{+}
	Yes	8.86 ± 0.17	2.49 ± 1.54	2.54 ± 1.58
	No	8.88 ± 0.09	6.55 ± 1.19	6.60 ± 1.22

P1.1（Missing）。 仅在罕见模态上评估得到的 AULC 显著低于常见模态。联合 AULC 接近仅使用常见模态时的结果。使用 ModDrop 未带来实质性差异。

P2 与 P3.1（Share）。 仅在 CIFAR-10 上评估的 AULC 远低于仅在 MNIST 上评估的结果。联合 AULC 接近仅使用 MNIST 时的结果。在这里，ModDrop 提高了弱模态性能，而不影响强模态。不过，弱模态与强模态之间仍存在显著性能差距。

P3.2（Unique）。 拥有全部任务相关信息的模态明显优于仅有部分信息的模态。联合 AULC 与具有完整信息的模态接近。在这种情况下，ModDrop 显著改善了仅有部分任务信息时获得的 AULC。另一个模态不受影响，两者之间仍有性能差距。

P3.3（Synergy）。 模型在模态 A 上表现最好，其得分明显高于使用模态 B 时的得分。与前面的情形不同，联合 AULC 接近弱模态的性能。在这里，ModDrop 损害了整体性能，使得分显著下降。

小结。 在四种实验设置中，模态不平衡始终出现：无论信息结构如何，模型都会不成比例地依赖一个模态。除了 Synergy 设置外，ModDrop 都能缓解这种不平衡；在 Synergy 中，它反而有害，大幅降低联合性能。根据这些结果，在接下来对合成数据集的评估中，除 Synergy 外均使用 ModDrop。

6.2 合成数据上的查询方法比较

在研究多模态陷阱的影响后，我们进一步在合成设置中考察单模态与多模态查询方法（表 2）。具体而言，我们研究它们对所提陷阱的易受影响程度，并评估相对性能。以下逐一讨论各个陷阱。

P1.1（Missing）。 KCG、Entropy 和 BALD 在罕见模态设置下明显优于其他方法。不过，KCG 的优势不稳定。Entropy 的整体表现最好，在中标注量设置下排名第二，在高标注量设置下排名第一。

P2 与 P3.1（Share）。 在 Share 设置下，没有任何方法能可靠提高弱模态性能。Random 的表现与任何专门设计的策略同样好。

P3.2（Unique）。 对于只含部分信息的模态，在低标注量与中标注量设置中出现了差异，GRACE 与 KCG 表现最好。高标注量设置中，所有方法的得分趋于相近，Random 在比较中领先。

P3.3（Synergy）。 各查询方法表现相近，KCG 在低标注量和中标注量设置下排名第一，BADGE 在高标注量设置下领先。这说明不同策略的相对优势取决于标注预算。没有任何方法能够持续且显著地优于竞争方法。

小结。 上述分析表明，除了 P1.1 外，我们提出的陷阱导致的不平衡（第 6.1 节）基本未被现有查询方法解决。此外，没有单个查询方法在所有设置和标注规模下都稳定优于其他方法。为提供总体视角，表 3 给出弱模态评估的排名总和。整体而言，KCG 在低标注量和中标注量设置下取得最佳总体排名，但这一优势在高标注量设置中消失，此时 BALD 排名第一。这种不稳定性进一步凸显了多模态 AL 缺乏可靠策略的问题。

表 2　合成数据上的查询方法比较（上半：Missing 与 Share）。 各标注规模下，每种查询方法在合成数据集上的 AULC。分别报告每种模态组合；最优数值加粗，弱模态用斜体。Dataset＝数据集；Regime＝标注规模，Low／Mid／High＝低／中／高标注量；Metric＝评估项；AULC per Query Method＝各查询方法的 AULC。原表按数据集分成两部分，第二部分重复原表头，未改变任何数据。

Dataset	Regime	Metric	AULC per Query Method						
			BADGE	BALD	BMMAL	Entropy	GRACE	KCG	Random
Missing	Low	*Rare*	1.05	1.07	1.13	**1.19**	1.10	**1.19**	0.97
		Both	**1.13**	1.02	1.06	1.12	1.02	1.22	0.96
		Frequent	1.08	0.91	0.96	0.94	0.91	**1.10**	0.92
	Mid	*Rare*	1.50	2.33	2.46	3.49	2.91	**4.99**	1.01
		Both	5.77	5.25	5.63	5.01	5.22	**6.09**	5.51
		Frequent	**5.71**	4.98	5.43	4.26	4.85	5.00	5.52
	High	*Rare*	1.13	3.79	2.19	**5.45**	2.20	1.03	1.01
		Both	8.02	7.90	8.02	**8.06**	7.96	7.96	7.94
		Frequent	**8.03**	7.69	7.95	7.49	7.86	7.97	7.95
Share	Low	*CIFAR-10*	**3.66**	3.52	**3.66**	3.24	3.45	3.53	**3.66**
		Both	**8.42**	8.32	8.41	7.99	8.36	8.30	**8.42**
		MNIST	**8.51**	8.46	8.49	8.19	8.48	8.45	8.49
	Mid	*CIFAR-10*	4.62	4.59	4.72	4.41	4.47	4.65	**4.76**
		Both	8.85	8.86	**8.87**	8.64	8.81	8.80	8.86
		MNIST	8.78	8.78	**8.80**	8.54	8.74	8.73	8.77
	High	*CIFAR-10*	4.91	4.94	5.08	4.78	4.80	5.00	**5.10**
		Both	8.91	8.92	**8.93**	8.85	8.90	8.91	8.91
		MNIST	8.83	**8.84**	**8.84**	8.75	8.81	8.83	8.81

表 2（续）　Unique 与 Synergy。 Full＝完整信息；Partial＝部分信息；Partial A／B＝部分信息模态 A／B；Both＝两个模态联合。方法名称与原文一致。

Dataset Regime		Metric	AULC per Query Method						
			BADGE	BALD	BMMAL	Entropy	GRACE	KCG	Random
Unique	Low	Full	**4.75**	4.58	4.63	3.95	4.41	4.21	4.74
		Both	**4.80**	4.61	4.76	4.14	4.66	4.29	4.76
		Partial	2.33	2.20	2.96	3.66	**3.75**	2.74	1.94
	Mid	Full	**6.48**	6.38	6.41	6.29	6.23	6.17	6.43
		Both	**6.56**	6.49	6.46	6.38	6.38	6.39	6.52
		Partial	2.53	2.86	2.55	2.73	3.61	**3.99**	2.87
	High	Full	**8.47**	8.44	8.43	8.40	8.45	8.44	8.45
		Both	**8.64**	8.62	8.60	8.56	8.62	8.59	8.62
		Partial	6.26	6.26	5.98	5.85	6.22	5.86	**6.40**
Synergy	Low	Partial A	6.11	6.21	6.13	5.90	6.08	6.00	**6.22**
		Both	3.69	3.30	3.70	2.99	3.85	**4.06**	3.72
		Partial B	4.59	4.01	4.34	3.64	4.47	4.95	**4.61**
	Mid	Partial A	**7.89**	7.84	7.84	7.76	7.74	7.87	7.81
		Both	5.42	4.85	5.68	5.54	5.40	**5.91**	5.53
		Partial B	5.42	5.30	6.29	6.06	5.84	**6.42**	5.90
	High	Partial A	8.91	8.89	8.89	8.86	**8.92**	8.91	8.88
		Both	**7.89**	7.76	7.50	7.04	7.85	7.35	6.55
		Partial B	**7.90**	7.79	7.55	7.09	7.89	7.40	6.60

表 3　合成数据上的查询方法排名汇总。 为比较查询方法，将每种查询方法在所有数据集上获得的名次相加。排名总和反映总体性能，越小越好。最优数值加粗。Label Regime＝标注规模；Query Method＝查询方法。

Label Regime	Query Method						
	BADGE	*BALD*	*BMMAL*	*Entropy*	*GRACE*	*KCG*	*Random*
Low	16	22	14	17	15	**11**	17
Mid	22	21	14	17	17	**6**	15
High	14	**11**	15	21	15	20	16

6.3 真实世界数据上的查询方法比较

下面验证合成数据上观察到的模式能否推广到真实世界多模态数据集。

Food101。 Food101 呈现出与 Share 设置类似的不平衡问题：图像模态的表现明显落后，联合评估性能则随较强模态变化。在查询方法中，BALD 在不同标注规模下表现较好，在低标注量和中标注量设置中获得最高的联合 AULC。不过，在高标注量设置中，BMMAL 领先，而多模态方法 GRACE 的联合得分最低。没有任何方法能可靠改善弱模态（图像）的性能。

MIMIC。 在 MIMIC-IV 上，血液化验是较强模态，在所有标注规模下都明显优于心电图。联合 AULC 紧随仅使用血液化验的性能，再次确认了模态不平衡模式。值得注意的是，在大多数设置下，Random 与所有查询方法具有竞争力，甚至更好，这与合成实验的发现一致。

小结。 总体而言，真实世界结果佐证了合成实验的发现：模态不平衡持续存在，现有查询方法无法缓解，多模态策略相对于单模态基线没有稳定优势。

局限性。 我们的框架聚焦双模态场景。尽管所识别的陷阱在概念上可以推广，增加模态后，其相互作用可能更加复杂。此外，所有实验均使用后期融合架构；早期融合或交叉注意力等其他融合策略可能与这些陷阱产生不同交互，改变查询方法的相对性能。将这一基准扩展到更丰富的架构及两个以上模态，是未来工作的自然方向。

表 4　真实世界数据上的查询方法比较。 各标注规模下，每种查询方法在真实世界数据集上的 AULC。分别报告每种模态组合；最优数值加粗，弱模态用斜体。Image＝图像；Text＝文本；ECG＝心电图；Bloodlabs＝血液化验；Both＝两个模态联合；Low／Mid／High＝低／中／高标注量。

Dataset Regime		Metric	AULC per Query Method						
			BADGE	BALD	BMMAL	Entropy	GRACE	KCG	Random
Food101	Low	*Image*	0.98	0.90	0.94	0.83	0.83	0.88	0.97
		Both	2.42	3.45	3.38	3.42	3.44	3.05	2.54
		Text	1.80	2.96	2.86	3.01	3.01	2.50	1.90
	Mid	*Image*	0.96	0.92	0.93	0.78	0.94	0.93	1.04
		Both	3.42	4.47	3.22	3.70	3.14	3.43	3.23
		Text	2.88	4.12	2.67	3.30	2.57	2.90	2.68
	High	*Image*	0.57	0.50	0.62	0.56	0.68	0.67	0.60
		Both	2.10	2.16	2.72	2.47	1.72	2.41	2.45
		Text	1.88	1.99	2.55	2.29	1.23	2.17	2.23
MIMIC	Low	*ECG*	4.60	4.61	4.62	4.60	4.63	4.64	**4.73**
		Both	6.51	**6.52**	6.51	6.49	6.43	6.42	6.51
		Bloodlabs	**6.55**	**6.55**	6.52	6.53	6.44	6.03	6.54
	Mid	*ECG*	4.71	4.87	4.74	4.67	4.82	4.62	**5.03**
		Both	6.55	**6.59**	6.55	6.57	6.45	6.49	6.58
		Bloodlabs	6.54	**6.61**	6.54	6.56	6.40	6.27	**6.61**
	High	*ECG*	4.85	5.13	4.87	4.74	4.76	4.76	**5.23**
		Both	6.62	6.66	**6.67**	6.61	6.56	6.61	**6.67**
		Bloodlabs	6.59	6.65	6.64	6.59	6.53	6.52	**6.66**

7 结论

本文提出了一个可控基准，用于评估多模态场景中的 AL 方法。通过精心设计的合成数据集，框架隔离了三个关键陷阱：模态缺失、模态不平衡和不同的模态交互结构。我们还在真实世界数据上验证了研究发现。

实验揭示了一个一致模式：多模态模型主要依赖某一个模态，形成不平衡表征；当较弱模态携带任务相关信息时，这会降低性能。这一现象出现在所有陷阱设置中，而且我们评估的所有查询策略都未能缓解。尽管部分方法，尤其是 KCG 和 BALD，在总体比较中表现较好，其优势却无法在不同设置下保持一致。在我们的实验中，多模态查询策略相对于单模态策略并没有明显优势。

这些发现指出了一项根本局限：当前 AL 查询策略在实践中不感知模态，即使设计之初已经考虑多模态数据也是如此。我们认为，有效的多模态 AL 需要在样本获取过程中显式监测并纠正模态不平衡的查询方法。所提出的基准为开发和评估这类方法提供了可控基础。

致谢

感谢 Thomas Wolf（拜耳股份公司）发起拜耳股份公司与德国癌症研究中心（DKFZ）之间的合作，并提供宝贵意见。本工作部分获得拜耳股份公司生命科学合作项目“Embrace Uncertainty”的资助。

参考文献

以下保留全部原始书目条目的作者、英文题名、出处、年份与原有链接，并提供中文题名以便阅读。会议、期刊、机构和模型名称保留其通用原名；不补写原文缺失的书目字段。

1. Ash, J.T., Zhang, C., Krishnamurthy, A., Langford, J., Agarwal, A.: **基于多样且不确定的梯度下界的深度批量主动学习**。Deep Batch Active Learning by Diverse, Uncertain Gradient Lower Bounds. In: ICLR (Apr 2020).

2. Cubuk, E.D., Zoph, B., Shlens, J., Le, Q.V.: **RandAugment：缩减搜索空间的实用自动数据增强**。Randaugment: Practical automated data augmentation with a reduced search space. In: CVPRW. pp. 3008–3017. IEEE, Seattle, WA, USA (Jun 2020). https://doi.org/10.1109/CVPRW50498.2020.00359

3. Du, C., Teng, J., Li, T., Liu, Y., Wang, Y., Yuan, Y., Zhao, H.: **模态惰性：人人有责便无人负责**。Modality Laziness: Everybody’s Business is Nobody’s Business (Oct 2021).

4. Dufumier, B., Castillo-Navarro, J., Tuia, D., Thiran, J.P.: **多模态对比学习应当对齐什么**。What to align in multimodal contrastive learning? (Mar 2025). https://doi.org/10.48550/arXiv.2409.07402

5. Gal, Y., Islam, R., Ghahramani, Z.: **面向图像数据的深度贝叶斯主动学习**。Deep Bayesian Active Learning with Image Data. In: ICML. pp. 1183–1192. PMLR (Jul 2017).

6. Goldberger, A.L., Amaral, L.A., Glass, L., Hausdorff, J.M., Ivanov, P.C., Mark, R.G., Mietus, J.E., Moody, G.B., Peng, C.K., Stanley, H.E.: **PhysioBank、PhysioToolkit 和 PhysioNet：面向复杂生理信号的新型研究资源的组成部分**。PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation 101(23), E215–220 (Jun 2000). https://doi.org/10.1161/01.cir.101.23.e215

7. Gordon, L., Behari, N., Collier, S., Bondi-Kelly, E., Killian, J.A., Ressijac, C., Boucher, P., Davies, A., Tambe, M.: **无需直接寻找犀牛而发现犀牛：利用南非犀牛栖息地多模态影像的主动学习**。Find Rhinos without Finding Rhinos: Active Learning with Multimodal Imagery of South African Rhino Habitats. In: IJCAI. pp. 5977–5985 (Aug 2023). https://doi.org/10.24963/ijcai.2023/663

8. Gow, B., Pollard, T., Nathanson, L.A., Johnson, A., Moody, B., Fernandes, C., Greenbaum, N., Waks, J.W., Eslami, P., Carbonati, T., Chaudhari, A., Herbst, E., Moukheiber, D., Berkowitz, S., Mark, R., Horng, S.: **MIMIC-IV-ECG：诊断心电图匹配子集 v1.1**。MIMIC-IV-ECG: Diagnostic electrocardiogram matched subset v1.1. PhysioNet (Sep 2023). https://doi.org/10.13026/4nqg-sb35

9. Hassan, S., Chung, H.Y., Tan, X.Z., Alikhani, M.: **面向具身智能体、结合主动学习的连贯性驱动多模态安全对话**。Coherence-Driven Multimodal Safety Dialogue with Active Learning for Embodied Agents (Feb 2025). https://doi.org/10.48550/arXiv.2410.14141

10. Hermann, K., Lampinen, A.: **什么塑造了特征表征：探索数据集、架构和训练**。What shapes feature representations? Exploring datasets, architectures, and training. In: NeurIPS. vol. 33, pp. 9995–10006. Curran Associates, Inc. (2020).

11. Huang, Y., Lin, J., Zhou, C., Yang, H., Huang, L.: **模态竞争：深度学习中是什么使多模态网络联合训练失败（可证明分析）**。Modality Competition: What Makes Joint Training of Multi-modal Network Fail in Deep Learning? (Provably). In: ICML. pp. 9226–9259. PMLR (Jun 2022).

12. Ji, Y., Kaestner, D., Wirth, O., Wressnegger, C.: **随机性是万恶之源：更可靠地评估深度主动学习**。Randomness Is the Root of All Evil: More Reliable Evaluation of Deep Active Learning. In: WACV. pp. 3943–3952 (2023).

13. Johnson, A., Bulgarelli, L., Pollard, T., Horng, S., Celi, L.A., Mark, R.: **MIMIC-IV v2.2**。MIMIC-IV v2.2. PhysioNet (Jan 2023). https://doi.org/10.13026/6mm1-ek67

14. Johnson, A.E.W., Bulgarelli, L., Shen, L., Gayles, A., Shammout, A., Horng, S., Pollard, T.J., Hao, S., Moody, B., Gow, B., Lehman, L.w.H., Celi, L.A., Mark, R.G.: **MIMIC-IV：可自由访问的电子健康记录数据集**。MIMIC-IV, a freely accessible electronic health record dataset. Scientific Data 10(1), 1 (Jan 2023). https://doi.org/10.1038/s41597-022-01899-x

15. Khanal, B., Bhattarai, B., Khanal, B., Stoyanov, D., Linte, C.A.: **M-VAAL：面向下游医学图像分析任务的多模态变分对抗主动学习**。M-VAAL: Multimodal Variational Adversarial Active Learning for Downstream Medical Image Analysis Tasks. In: Waiter, G., Lambrou, T., Leontidis, G., Oren, N., Morris, T., Gordon, S. (eds.) Medical Image Understanding and Analysis. pp. 48–63. Springer Nature Switzerland, Cham (2024). https://doi.org/10.1007/978-3-031-48593-0_4

16. Krizhevsky, A.: **从微小图像中学习多层特征**。Learning Multiple Layers of Features from Tiny Images.

17. LeCun, Yann: **MNIST 手写数字数据库**。The mnist database of handwritten digits. http://yann.lecun.com/exdb/mnist/ (1998).

18. Li, X., Ye, W., Zhang, Y., Sun, X.: **GRACE：面向多模态情感分析、结合课程增强的基于梯度的主动学习**。GRACE: GRadient-based Active Learning with Curriculum Enhancement for Multimodal Sentiment Analysis. In: ACM MM. pp. 5702–5711. MM ’ 24, Association for Computing Machinery, New York, NY, USA (Oct 2024).

19. Lüth, C., Bungert, T., Klein, L., Jaeger, P.: **避开主动学习评估的陷阱：用于有意义性能评估的系统框架**。Navigating the Pitfalls of Active Learning Evaluation: A Systematic Framework for Meaningful Performance Assessment. NeurIPS 36, 9789–9836 (Dec 2023).

20. Neverova, N., Wolf, C., Taylor, G., Nebout, F.: **ModDrop：自适应多模态手势识别**。ModDrop: Adaptive Multi-Modal Gesture Recognition. IEEE Trans. Pattern Anal. Mach. Intell. 38(8), 1692–1706 (Aug 2016). https://doi.org/10.1109/TPAMI.2015.2461544

21. Rudovic, O., Zhang, M., Schuller, B., Picard, R.: **从人类数据中进行多模态主动学习：一种深度强化学习方法**。Multi-modal Active Learning From Human Data: A Deep Reinforcement Learning Approach. In: ICMI. pp. 6–15. ICMI ’ 19, Association for Computing Machinery, New York, NY, USA (Oct 2019). https://doi.org/10.1145/3340555.3353742

22. Saporta, A., Puli, A., Goldstein, M., Ranganath, R.: **使用 Symile 进行对比：面向不限数量模态的简单、模型无关表征学习**。Contrasting with Symile: Simple Model-Agnostic Representation Learning for Unlimited Modalities. NeurIPS 37, 56919–56957 (Dec 2024). https://doi.org/10.52202/079017-1814

23. Sener, O., Savarese, S.: **卷积神经网络的主动学习：核心集方法**。Active Learning for Convolutional Neural Networks: A Core-Set Approach (Jun 2018). https://doi.org/10.48550/arXiv.1708.00489

24. Shen, M., Huang, Y., Yin, J., Zou, H., Rajan, D., See, S.: **迈向多模态分类的平衡主动学习**。Towards Balanced Active Learning for Multimodal Classification. In: ACM MM. pp. 3434–3445 (Oct 2023). https://doi.org/10.1145/3581783.3612463

25. Shen, M., Wei, Y., Yin, J.T., Rajan, D., Hu, D., See, S.: **增强多模态冷启动主动学习的模态表征与对齐**。Enhancing Modality Representation and Alignment for Multimodal Cold-start Active Learning. In: MMAsia. pp. 1–8. MMAsia ’ 24, Association for Computing Machinery, New York, NY, USA (Dec 2024). https://doi.org/10.1145/3696409.3700225

26. Tan, M., Le, Q.V.: **EfficientNet：重新思考卷积神经网络的模型缩放**。EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks (Sep 2020). https://doi.org/10.48550/arXiv.1905.11946

27. Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M.: **MiniLM：面向预训练 Transformer 任务无关压缩的深度自注意力蒸馏**。MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers (Apr 2020). https://doi.org/10.48550/arXiv.2002.10957

28. Wang, X., Kumar, D., Thome, N., Cord, M., Precioso, F.: **利用大型多模态食品数据集进行食谱识别**。Recipe recognition with large multimodal food dataset. In: ICMEW. pp. 1–6 (Jun 2015). https://doi.org/10.1109/ICMEW.2015.7169757

29. Werner, T., Burchert, J., Stubbemann, M., Schmidt-Thieme, L.: **主动学习的跨领域基准**。A Cross-Domain Benchmark for Active Learning. NeurIPS 37, 62875–62911 (Dec 2024). https://doi.org/10.52202/079017-2009

30. Wu, R., Wang, H., Chen, H.T., Carneiro, G.: **存在模态缺失的深度多模态学习综述**。Deep Multimodal Learning with Missing Modality: A Survey. TMLR (Oct 2025).

31. Zhang, Q., Wei, Y., Han, Z., Fu, H., Peng, X., Deng, C., Hu, Q., Xu, C., Wen, J., Hu, D., Zhang, C.: **低质量数据上的多模态融合综合综述**。Multimodal Fusion on Low-quality Data: A Comprehensive Survey (Nov 2024). https://doi.org/10.48550/arXiv.2404.18947

32. Zhang, Z., Yuan, X., Ma, W., Lin, J., Yang, L., Guo, M., Zhao, X.: **利用大型多模态模型进行开放集目标检测的主动学习**。Active Learning for Open-Set Object Detection with Large Multimodal Model. In: ICRCV. pp. 93–98 (Sep 2024). https://doi.org/10.1109/ICRCV62709.2024.10758564

附录 A 实验细节

A.1 MIMIC 数据集

为构建数据集，我们收集所有入院记录，并获取入院前 24 小时至入院后 24 小时内的血液化验与心电图。由于一些患者多次住院，同一患者会出现在多个样本中。我们在训练／测试划分中考虑这一点，随机选取 30,000 名受试者用于测试。

血液化验包含血液中各种物质的测量。由于并非每次都测量所有物质，我们遵循文献 [22]，仅选择最常见的 50 项测量，分别为：红细胞压积（Hematocrit）、血小板计数（Platelet Count）、肌酐（Creatinine）、钾（Potassium）、血红蛋白（Hemoglobin）、白细胞（White Blood Cells）、平均红细胞血红蛋白浓度（MCHC）、红细胞（Red Blood Cells）、平均红细胞体积（MCV）、平均红细胞血红蛋白量（MCH）、红细胞分布宽度（RDW）、尿素氮（Urea Nitrogen）、钠（Sodium）、氯（Chloride）、碳酸氢盐（Bicarbonate）、阴离子间隙（Anion Gap）、葡萄糖（Glucose）、镁（Magnesium）、总钙（Calcium Total）、磷酸盐（Phosphate）、国际标准化比值 INR(PT)、凝血酶原时间（PT）、部分凝血活酶时间（PTT）、嗜碱性粒细胞（Basophils）、中性粒细胞（Neutrophils）、单核细胞（Monocytes）、嗜酸性粒细胞（Eosinophils）、淋巴细胞（Lymphocytes）、红细胞分布宽度标准差（RDW-SD）、H、L、I、丙氨酸氨基转移酶（ALT）、天冬氨酸氨基转移酶（AST）、乳酸（Lactate）、碱性磷酸酶（Alkaline Phosphatase）、总胆红素（Bilirubin Total）、pH、白蛋白（Albumin）、碱剩余（Base Excess）、氧分压（pO2）、计算总二氧化碳（Calculated Total CO2）、二氧化碳分压（pCO2）、中性粒细胞绝对计数（Absolute Neutrophil Count）、嗜酸性粒细胞绝对计数（Absolute Eosinophil Count）、单核细胞绝对计数（Absolute Monocyte Count）、嗜碱性粒细胞绝对计数（Absolute Basophil Count）、淋巴细胞绝对计数（Absolute Lymphocyte Count）、肌酸激酶（CK）、未成熟粒细胞（Immature Granulocytes）。即使在这些项目中，也并非每个时间点都会测量所有物质。对于血液化验，我们采用分位数缩放和中位数插补。

对于心电图，我们过滤空心电图和包含 NaN 值的记录，并将心电图重新缩放至 [-1, 1]。

> **译者注（原文措辞）：** 原文关于重复住院的句子为 “some patients are admitted to the hospital times”，缺少修饰次数的词；根据紧接着“这些患者出现在多个样本中”的说明译为“多次住院”。原文 AST 英文名称写作 “Asparate Aminotransferase”，中文按其括号缩写译出；H、L、I 原样保留，不推测其含义。

A.2 模型架构

实验采用带有单模态编码器的简单架构。所有单模态潜在表征均经过非线性投影层，形成等长特征向量。随后使用 Transformer 编码器融合这些向量，并传递给线性分类器。

对于图像模态，我们使用 EfficientNetB0 [26] 架构。在 Share 实验中，调整第一层卷积以接受单通道输入。对于 Food101 的文本输入，我们采用 MiniLM [27] 架构[7]。对于 MIMIC-IV，血液化验输入一个两层 MLP；心电图使用一维版本的 EfficientNetB0 处理。在 MIMIC 中，我们还在投影层采用 dropout。[7] 模型地址：https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2

A.3 训练设置

本节详细说明模型训练超参数的选择。对每个实验，训练轮数、批大小、优化器与学习率调度器均预先选定。所有实验均采用随机梯度下降、余弦退火学习率调度器，以及十个预热训练轮次。

学习率、权重衰减和数据增强通过网格搜索选择。学习率候选值为 [0.1, 0.01, 0.001]，权重衰减候选值为 [5e−3, 5e−4]，数据增强候选项为 [Basic, RandAugMC]。Basic 结合随机水平翻转和随机裁剪；RandAug 则按照文献 [2]，额外施加多种强增强。

数据增强仅作用于图像模态。如果一个数据集以两个图像模态作为输入，则两个模态均应用增强。其他类型的模态不进行增强。

表 5 列出实验使用的训练设置。对于 MIMIC，我们还采用类别平衡采样。

表 5　训练设置。 表中给出第 A.3 节所述超参数搜索的结果。星号（*）表示列出的设置适用于所有标注规模。Dataset＝数据集；Label Regime＝标注规模；Epochs＝训练轮数；Batch Size＝批大小；Learning Rate＝学习率；Weight Decay＝权重衰减；Augment.＝增强；None＝无增强。

Dataset	Label Regime	Epochs	Batch Size	Learning Rate	Weight Decay	Augment.
Missing	*	60	128	0.1	5e-4	RandAug
Share	*	200	1024	0.1	5e-3	RandAug
Unique	*	60	128	0.1	5e-4	Basic
Synergy	*	60	128	0.1	5e-4	Basic
Food101	*	60	128	0.1	5e-4	RandAug
MIMIC	Low	60	256	0.01	5e-5	None
	Mid			0.01	5e-4	None
	High			0.001	5e-5	None

译者注（原文设置差异）： 正文列出的权重衰减候选值为 [5e−3, 5e−4]，但表 5 的 MIMIC 低标注量／高标注量设置使用 5e−5；原文还在候选项中写 “RandAugMC”，而表中写 “RandAug”。译文保留这些不同写法与数值，不推断其等价性或更正搜索范围。

A.4 主动学习设置

表 6　主动学习设置。 Dataset＝数据集；Label Regime＝标注规模；Initial Budget＝初始预算；Validation Size＝验证集大小；Acquisition Size＝每次获取样本数；Iterations＝迭代次数；Low／Mid／High＝低／中／高标注量。

Dataset	Label Regime	Initial Budget	Validation Size	Acquisition Size	Iterations
Missing Share	Low	50	250	50	10
	Mid	250	1250	250	10
	High	1000	5000	1000	10
Unique Synergy MIMIC	Low	500	2500	500	10
	Mid	1000	5000	1000	10
	High	5000	5000	5000	10
Food101	Low	505	2525	505	10
	Mid	1010	5050	1010	10
	High	5050	5050	5050	5

按照文献 [19]，我们研究不同的标注规模，以验证查询方法在多种条件下均能工作。这些标注规模涵盖不同初始预算、验证集大小、每次获取样本数及迭代次数。我们遵循其经验规则：低标注量设置的初始预算和每次获取样本数取 5 × C，中标注量取 25 × C，高标注量取 100 × C，其中 C 表示类别数。

MIMIC 是这一规则的例外。它是一个非常大的数据集，而任务是二分类。若按该经验规则选择，相对于数据集规模而言，预算和查询量都会非常小。因此，我们采用 Unique 和 Synergy 设置中的数值。

迭代次数设为十次。唯一例外是 Food101 的高标注量设置：为使最终迭代的样本量低于完整数据集的一半，我们仅进行五次迭代。

> **译者注（原文预算规则差异）：** 上述 5C／25C／100C 规则与表 6 中 Unique、Synergy 和 Food101 的部分中／高标注量数值不完全一致。正文规则、例外说明与表内数值均按原文保留，未重新计算或替换。

附录 B 详细结果

图表标签对照。 Regime 或 Label Regime＝标注规模；Low／Mid／High＝低／中／高标注量；QM 或 Query Method＝查询方法；AULC＝学习曲线下面积；Test Balanced Accuracy＝平衡测试准确率；Number of Samples＝样本数；Both＝两个模态联合；Rare／Frequent＝罕见／常见模态；Full／Partial＝完整／部分信息；Partial A／B＝部分信息模态 A／B；Image／Text＝图像／文本；ECG＝心电图；Bloodlab 或 Bloodlabs＝血液化验；KCenterGreedy＝正文简称 KCG 的查询方法。图中的 k 表示千。图表中的英文标签、精确数值、误差、颜色、符号与字体均保留原版；中文图题和图注在相邻处完整给出。

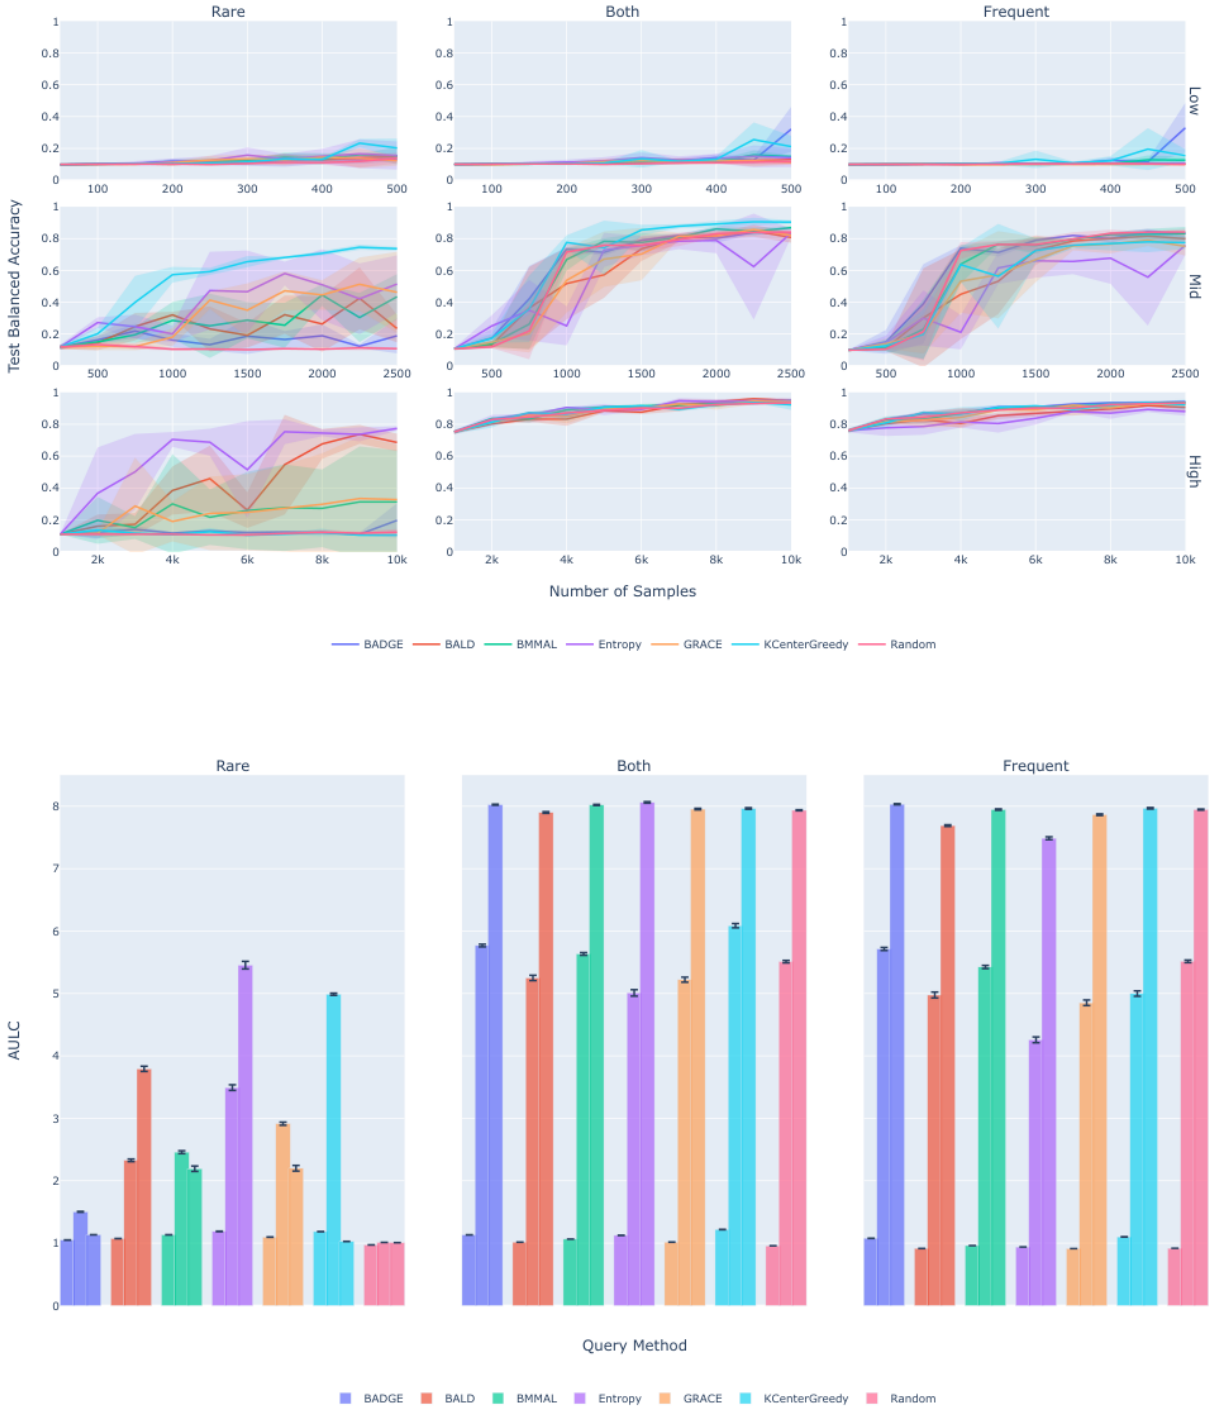
附录表中 A、B 分别表示第一、第二模态；对于 Missing，对应罕见与常见模态；对于 Unique，对应完整与部分信息模态；对于 Synergy，对应部分信息模态 A 与 B。这些表与正文在缩放口径／标签说明上未处处重复说明，译文不据此修改数值。

B.1 Missing

表 7　使用 ModDrop 时 Missing 的结果。 展示所有查询方法在 Missing 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	Rare	Both	Frequent
Low	BADGE	1.05 ± 0.16	1.13 ± 0.17	1.08 ± 0.13
	BALD	1.07 ± 0.10	1.02 ± 0.06	0.91 ± 0.02
	BMMAL	1.13 ± 0.15	1.06 ± 0.09	0.96 ± 0.06
	Entropy	1.19 ± 0.33	1.12 ± 0.24	0.94 ± 0.05
	GRACE	1.10 ± 0.19	1.02 ± 0.13	0.91 ± 0.02
	KCenterGreedy	1.19 ± 0.14	1.22 ± 0.24	1.10 ± 0.26
	Random	0.97 ± 0.11	0.96 ± 0.06	0.92 ± 0.03
Mid	BADGE	1.50 ± 0.46	5.77 ± 0.36	5.71 ± 0.43
	BALD	2.33 ± 0.91	5.25 ± 0.82	4.98 ± 0.96
	BMMAL	2.46 ± 0.93	5.63 ± 0.39	5.43 ± 0.47
	Entropy	3.49 ± 1.28	5.01 ± 1.03	4.26 ± 1.11
	GRACE	2.91 ± 0.84	5.22 ± 0.77	4.85 ± 0.92
	KCenterGreedy	4.99 ± 0.36	6.09 ± 0.56	5.00 ± 0.86
	Random	1.01 ± 0.07	5.51 ± 0.36	5.52 ± 0.38
High	BADGE	1.13 ± 0.13	8.02 ± 0.10	8.03 ± 0.10
	BALD	3.79 ± 1.11	7.90 ± 0.16	7.69 ± 0.18
	BMMAL	2.19 ± 1.98	8.02 ± 0.12	7.95 ± 0.13
	Entropy	5.45 ± 1.11	8.06 ± 0.15	7.49 ± 0.31
	GRACE	2.20 ± 2.07	7.96 ± 0.15	7.86 ± 0.17
	KCenterGreedy	1.03 ± 0.12	7.96 ± 0.15	7.97 ± 0.15
	Random	1.01 ± 0.08	7.94 ± 0.10	7.95 ± 0.11

图 2　使用 ModDrop 时 Missing 的结果。

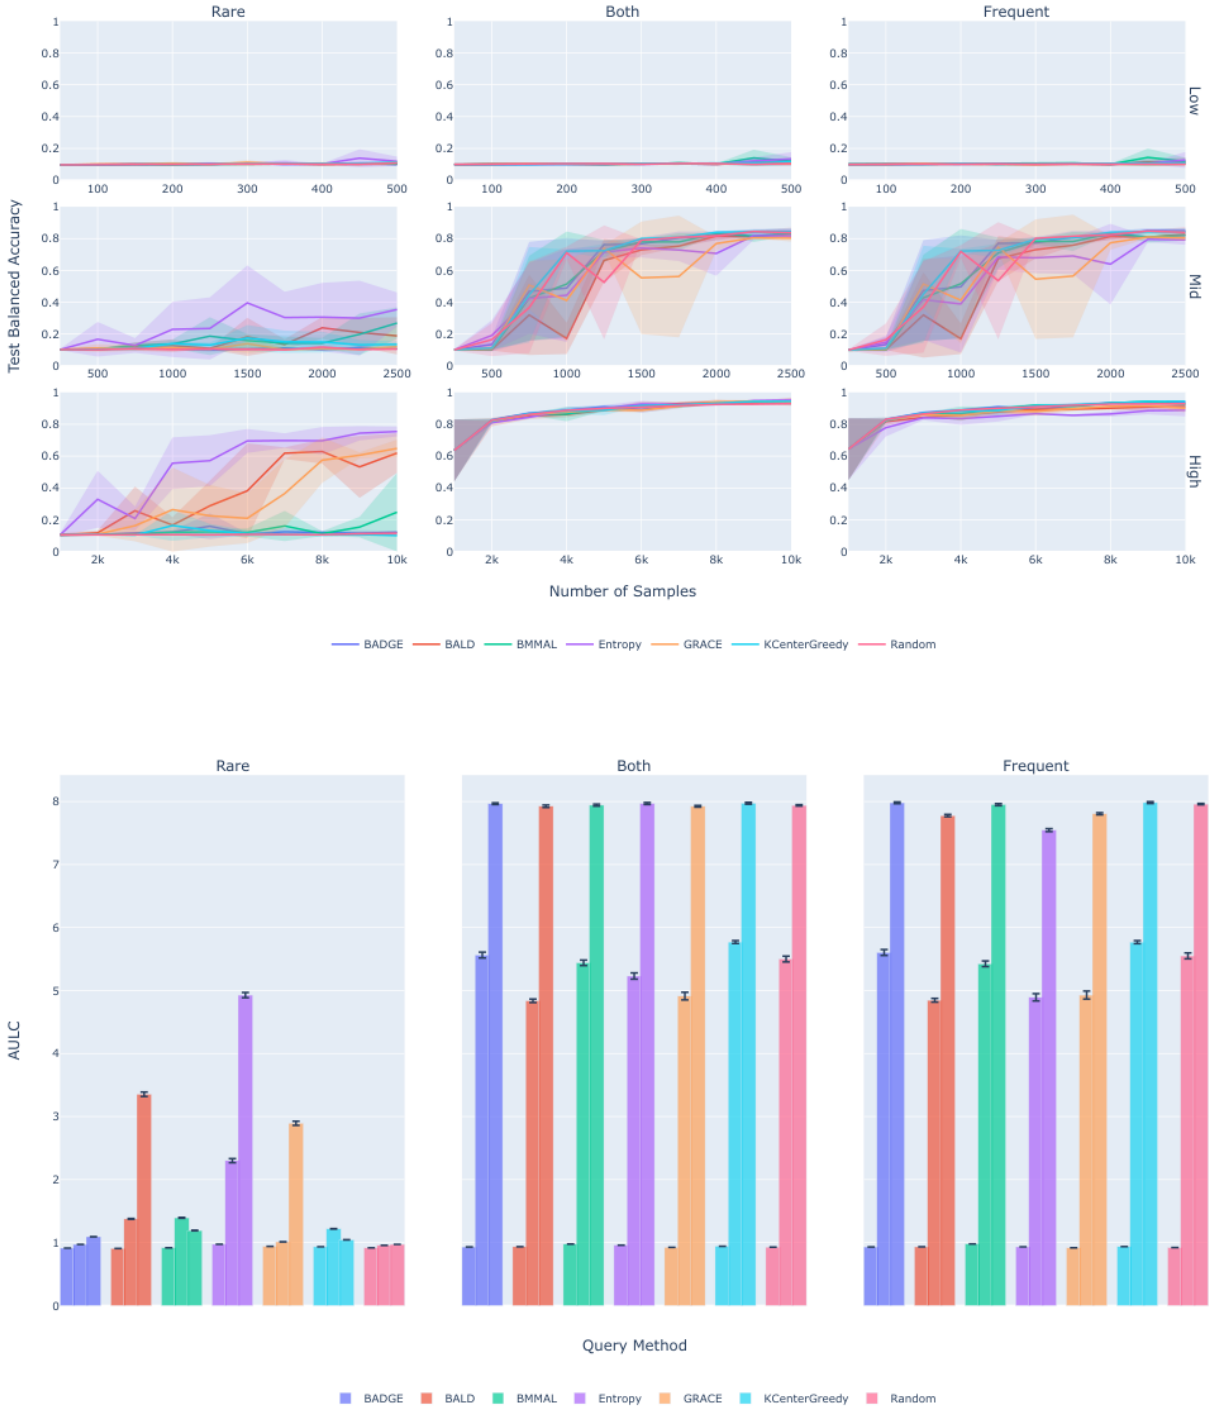


展示所有查询方法在 Missing 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

表 8　不使用 ModDrop 时 Missing 的结果。 展示所有查询方法在 Missing 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	A	Both	B
Low	BADGE	0.91 ± 0.04	0.93 ± 0.05	0.93 ± 0.05
	BALD	0.91 ± 0.03	0.93 ± 0.05	0.93 ± 0.05
	BMMAL	0.92 ± 0.02	0.98 ± 0.10	0.98 ± 0.10
	Entropy	0.97 ± 0.11	0.96 ± 0.07	0.93 ± 0.05
	GRACE	0.94 ± 0.05	0.92 ± 0.03	0.92 ± 0.02
	KCenterGreedy	0.93 ± 0.03	0.94 ± 0.03	0.94 ± 0.03
	Random	0.92 ± 0.03	0.93 ± 0.04	0.92 ± 0.05
Mid	BADGE	0.97 ± 0.05	5.56 ± 0.83	5.60 ± 0.84
	BALD	1.38 ± 0.45	4.84 ± 0.57	4.85 ± 0.60
	BMMAL	1.39 ± 0.47	5.44 ± 0.79	5.42 ± 0.85
	Entropy	2.30 ± 1.43	5.23 ± 0.95	4.89 ± 1.18
	GRACE	1.01 ± 0.15	4.91 ± 1.24	4.93 ± 1.29
	KCenterGreedy	1.22 ± 0.31	5.77 ± 0.40	5.77 ± 0.42
	Random	0.96 ± 0.04	5.50 ± 0.84	5.55 ± 0.85
High	BADGE	1.09 ± 0.17	7.97 ± 0.17	7.98 ± 0.17
	BALD	3.35 ± 1.05	7.93 ± 0.25	7.78 ± 0.24
	BMMAL	1.19 ± 0.36	7.94 ± 0.20	7.95 ± 0.21
	Entropy	4.93 ± 0.85	7.97 ± 0.20	7.55 ± 0.31
	GRACE	2.89 ± 1.13	7.92 ± 0.18	7.81 ± 0.22
	KCenterGreedy	1.04 ± 0.20	7.97 ± 0.19	7.98 ± 0.19
	Random	0.97 ± 0.05	7.94 ± 0.13	7.96 ± 0.13

图 3　不使用 ModDrop 时 Missing 的结果。



展示所有查询方法在 Missing 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

B.2 Share

表 9　使用 ModDrop 时 Share 的结果。 展示所有查询方法在 Share 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	CIFAR-10	Both	MNIST
Low	BADGE	3.66 ± 0.12	8.42 ± 0.06	8.51 ± 0.07
	BALD	3.52 ± 0.16	8.32 ± 0.11	8.46 ± 0.12
	BMMAL	3.66 ± 0.24	8.41 ± 0.09	8.49 ± 0.07
	Entropy	3.24 ± 0.18	7.99 ± 0.24	8.19 ± 0.24
	GRACE	3.45 ± 0.23	8.36 ± 0.13	8.48 ± 0.09
	KCenterGreedy	3.53 ± 0.22	8.30 ± 0.13	8.45 ± 0.12
	Random	3.66 ± 0.14	8.42 ± 0.08	8.49 ± 0.06
Mid	BADGE	4.62 ± 0.10	8.85 ± 0.03	8.78 ± 0.03
	BALD	4.59 ± 0.10	8.86 ± 0.02	8.78 ± 0.03
	BMMAL	4.72 ± 0.10	8.87 ± 0.02	8.80 ± 0.02
	Entropy	4.41 ± 0.19	8.64 ± 0.14	8.54 ± 0.14
	GRACE	4.47 ± 0.13	8.81 ± 0.05	8.74 ± 0.05
	KCenterGreedy	4.65 ± 0.20	8.80 ± 0.03	8.73 ± 0.03
	Random	4.76 ± 0.13	8.86 ± 0.02	8.77 ± 0.02
High	BADGE	4.91 ± 0.12	8.91 ± 0.02	8.83 ± 0.03
	BALD	4.94 ± 0.15	8.92 ± 0.01	8.84 ± 0.01
	BMMAL	5.08 ± 0.12	8.93 ± 0.01	8.84 ± 0.02
	Entropy	4.78 ± 0.15	8.85 ± 0.06	8.75 ± 0.08
	GRACE	4.80 ± 0.20	8.90 ± 0.03	8.81 ± 0.03
	KCenterGreedy	5.00 ± 0.18	8.91 ± 0.02	8.83 ± 0.02
	Random	5.10 ± 0.11	8.91 ± 0.01	8.81 ± 0.02

图 4　使用 ModDrop 时 Share 的结果。



展示所有查询方法在 Share 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

表 10　不使用 ModDrop 时 Share 的结果。 展示所有查询方法在 Share 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	CIFAR-10	Both	MNIST
Low	BADGE	3.35 ± 0.13	8.38 ± 0.09	8.44 ± 0.09
	BALD	3.12 ± 0.17	8.20 ± 0.22	8.30 ± 0.19
	BMMAL	3.39 ± 0.14	8.40 ± 0.08	8.45 ± 0.07
	Entropy	2.89 ± 0.21	7.84 ± 0.27	7.88 ± 0.38
	GRACE	3.11 ± 0.22	8.19 ± 0.16	8.31 ± 0.16
	KCenterGreedy	3.34 ± 0.13	8.16 ± 0.16	8.28 ± 0.17
	Random	3.32 ± 0.18	8.36 ± 0.08	8.38 ± 0.09
Mid	BADGE	3.99 ± 0.20	8.86 ± 0.02	8.78 ± 0.02
	BALD	3.93 ± 0.16	8.87 ± 0.01	8.78 ± 0.02
	BMMAL	3.99 ± 0.15	8.88 ± 0.01	8.80 ± 0.02
	Entropy	3.80 ± 0.38	8.73 ± 0.10	8.54 ± 0.14
	GRACE	3.79 ± 0.20	8.84 ± 0.03	8.75 ± 0.06
	KCenterGreedy	4.34 ± 0.23	8.85 ± 0.03	8.76 ± 0.03
	Random	4.13 ± 0.26	8.86 ± 0.01	8.77 ± 0.02
High	BADGE	4.27 ± 0.23	8.93 ± 0.01	8.83 ± 0.02
	BALD	4.16 ± 0.27	8.92 ± 0.01	8.84 ± 0.02
	BMMAL	4.35 ± 0.21	8.93 ± 0.01	8.85 ± 0.02
	Entropy	4.15 ± 0.22	8.89 ± 0.02	8.76 ± 0.06
	GRACE	4.15 ± 0.20	8.92 ± 0.01	8.82 ± 0.03
	KCenterGreedy	4.46 ± 0.23	8.92 ± 0.01	8.83 ± 0.02
	Random	4.23 ± 0.24	8.91 ± 0.01	8.82 ± 0.02

图 5　不使用 ModDrop 时 Share 的结果。



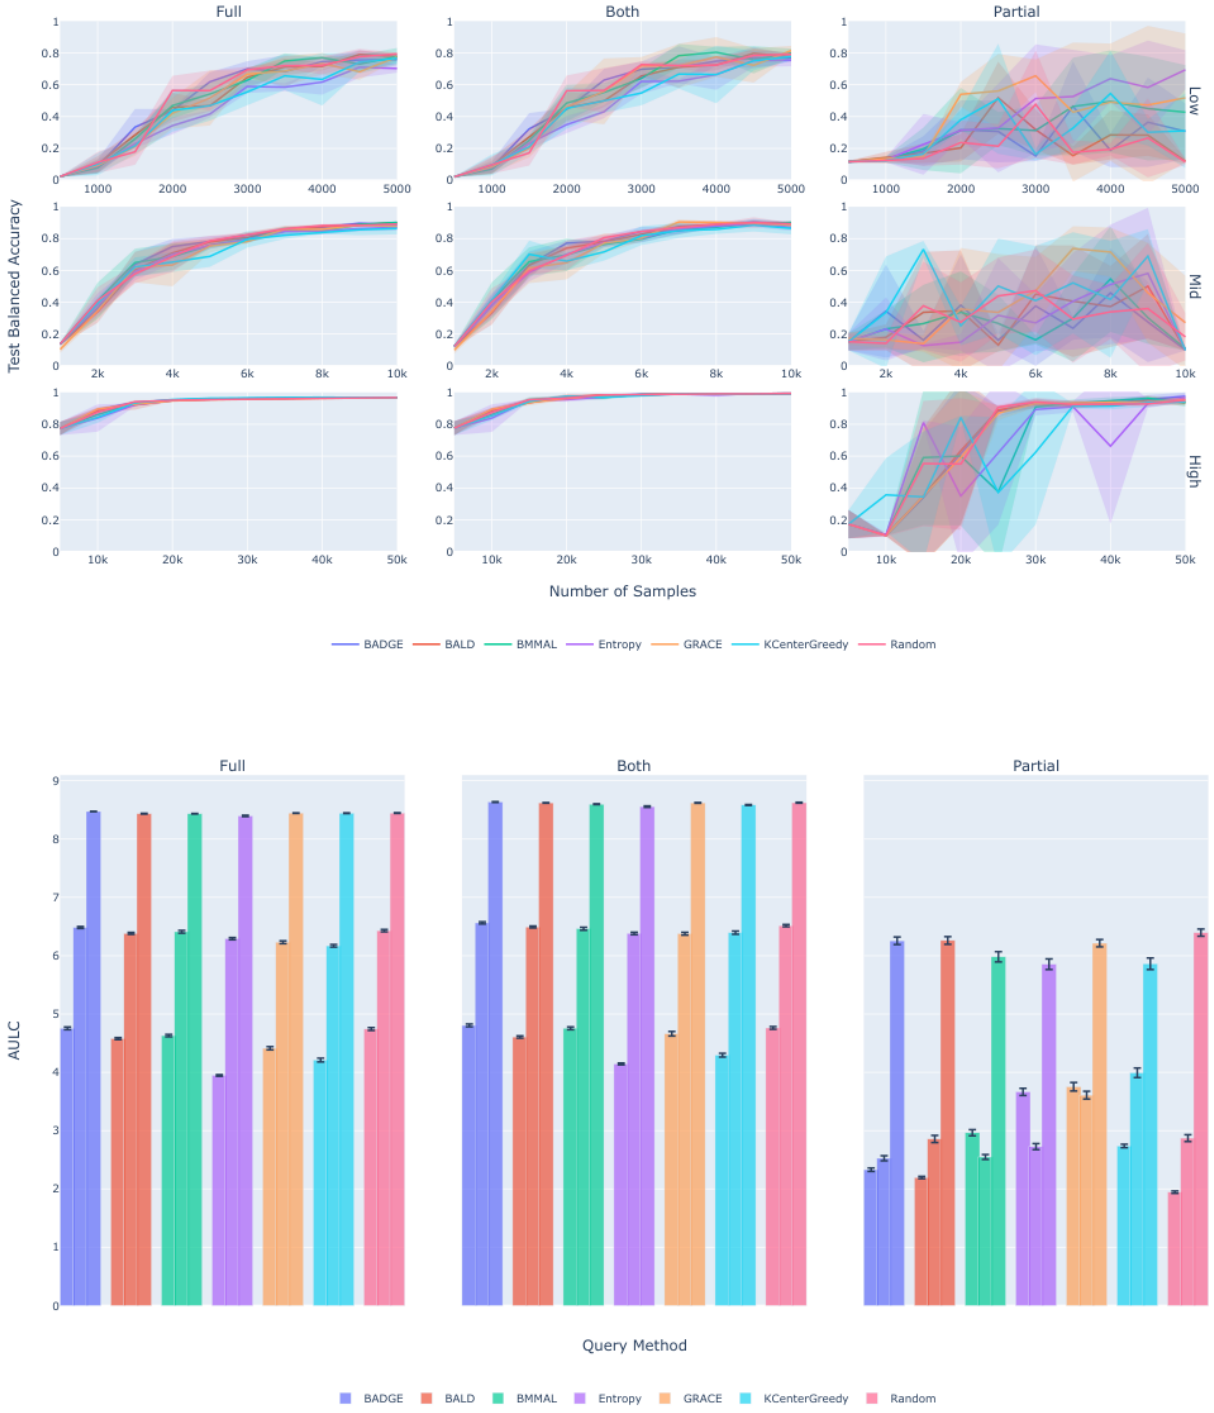
展示所有查询方法在 Share 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

B.3 Unique

表 11　使用 ModDrop 时 Unique 的结果。 展示所有查询方法在 Unique 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	A	Both	B
Low	BADGE	4.75 ± 0.48	4.80 ± 0.50	2.33 ± 1.27
	BALD	4.58 ± 0.39	4.61 ± 0.43	2.20 ± 0.89
	BMMAL	4.63 ± 0.43	4.76 ± 0.51	2.96 ± 1.78
	Entropy	3.95 ± 0.36	4.14 ± 0.40	3.66 ± 1.67
	GRACE	4.41 ± 0.61	4.66 ± 0.83	3.75 ± 1.95
	KCenterGreedy	4.21 ± 0.76	4.29 ± 0.74	2.74 ± 1.09
	Random	4.74 ± 0.51	4.76 ± 0.50	1.94 ± 1.04
Mid	BADGE	6.48 ± 0.26	6.56 ± 0.29	2.53 ± 1.72
	BALD	6.38 ± 0.26	6.49 ± 0.26	2.86 ± 2.15
	BMMAL	6.41 ± 0.38	6.46 ± 0.40	2.55 ± 1.63
	Entropy	6.29 ± 0.29	6.38 ± 0.33	2.73 ± 1.92
	GRACE	6.23 ± 0.38	6.38 ± 0.37	3.61 ± 1.84
	KCenterGreedy	6.17 ± 0.37	6.39 ± 0.43	3.99 ± 2.05
	Random	6.43 ± 0.32	6.52 ± 0.30	2.87 ± 2.03
High	BADGE	8.47 ± 0.05	8.64 ± 0.07	6.26 ± 1.04
	BALD	8.44 ± 0.07	8.62 ± 0.06	6.26 ± 1.06
	BMMAL	8.43 ± 0.05	8.60 ± 0.08	5.98 ± 1.47
	Entropy	8.40 ± 0.13	8.56 ± 0.15	5.85 ± 1.55
	GRACE	8.45 ± 0.05	8.62 ± 0.07	6.22 ± 1.01
	KCenterGreedy	8.44 ± 0.07	8.59 ± 0.09	5.86 ± 1.69
	Random	8.45 ± 0.07	8.62 ± 0.09	6.40 ± 0.96

图 6　使用 ModDrop 时 Unique 的结果。



展示所有查询方法在 Unique 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

表 12　不使用 ModDrop 时 Unique 的结果。 展示所有查询方法在 Unique 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	A	Both	B
Low	BADGE	4.76 ± 0.39	4.81 ± 0.38	1.07 ± 0.25
	BALD	4.68 ± 0.46	4.68 ± 0.46	0.95 ± 0.08
	BMMAL	4.56 ± 0.56	4.54 ± 0.56	0.94 ± 0.07
	Entropy	4.36 ± 0.48	4.40 ± 0.58	1.11 ± 0.35
	GRACE	4.35 ± 0.51	4.33 ± 0.51	0.94 ± 0.04
	KCenterGreedy	3.94 ± 0.59	4.20 ± 0.62	1.59 ± 0.92
	Random	4.75 ± 0.36	4.73 ± 0.37	0.92 ± 0.03
Mid	BADGE	6.70 ± 0.23	6.70 ± 0.23	0.91 ± 0.04
	BALD	6.63 ± 0.24	6.74 ± 0.23	1.28 ± 0.67
	BMMAL	6.41 ± 0.37	6.41 ± 0.37	0.91 ± 0.05
	Entropy	6.57 ± 0.36	6.63 ± 0.30	1.09 ± 0.37
	GRACE	6.43 ± 0.34	6.42 ± 0.33	0.92 ± 0.05
	KCenterGreedy	6.38 ± 0.40	6.58 ± 0.30	1.61 ± 1.17
	Random	6.71 ± 0.27	6.70 ± 0.26	0.90 ± 0.03
High	BADGE	8.50 ± 0.05	8.54 ± 0.04	1.73 ± 1.11
	BALD	8.46 ± 0.12	8.54 ± 0.07	1.89 ± 1.71
	BMMAL	8.51 ± 0.07	8.54 ± 0.06	1.59 ± 1.20
	Entropy	8.47 ± 0.05	8.48 ± 0.05	1.22 ± 0.53
	GRACE	8.46 ± 0.07	8.51 ± 0.06	1.74 ± 1.13
	KCenterGreedy	8.45 ± 0.00	8.53 ± 0.00	2.39 ± 0.00
	Random	8.45 ± 0.10	8.51 ± 0.06	1.76 ± 1.43

图 7　不使用 ModDrop 时 Unique 的结果。



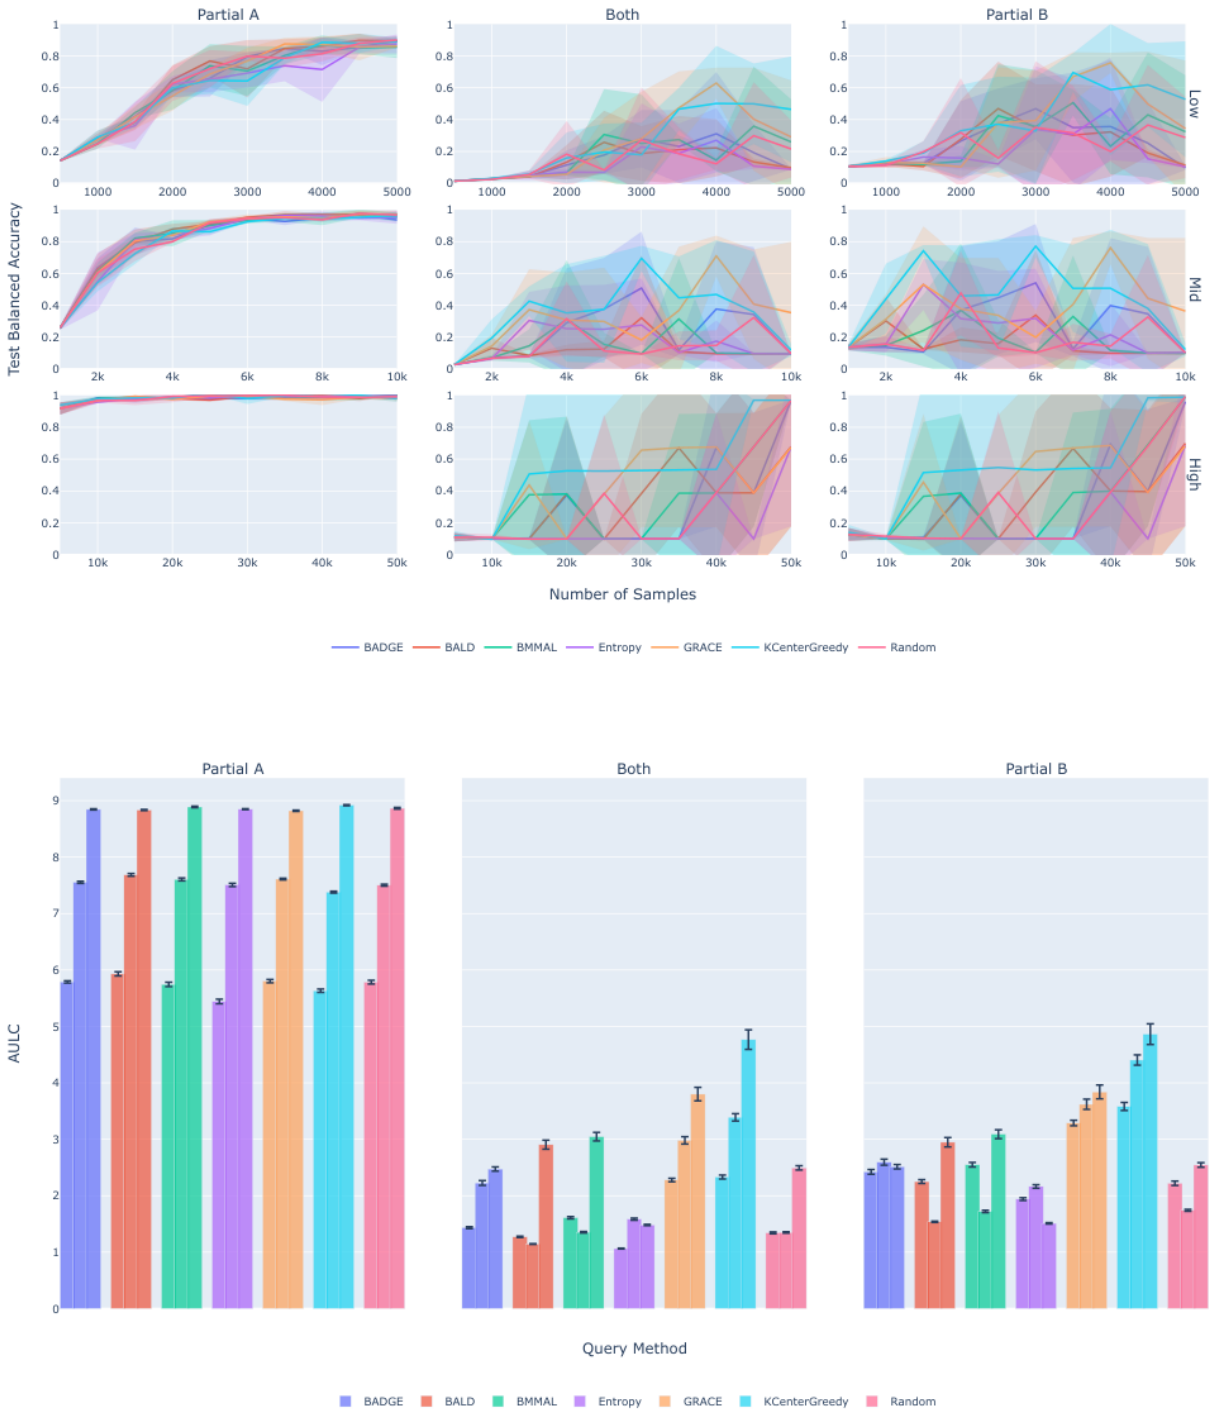
展示所有查询方法在 Unique 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

B.4 Synergy

表 13　使用 ModDrop 时 Synergy 的结果。 展示所有查询方法在 Synergy 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	A	Both	B
Low	BADGE	5.79 ± 0.35	1.43 ± 1.19	2.42 ± 1.73
	BALD	5.93 ± 0.62	1.27 ± 0.91	2.25 ± 1.49
	BMMAL	5.74 ± 0.67	1.61 ± 1.22	2.55 ± 1.57
	Entropy	5.44 ± 0.75	1.06 ± 0.74	1.94 ± 1.26
	GRACE	5.80 ± 0.51	2.28 ± 1.34	3.29 ± 1.48
	KCenterGreedy	5.63 ± 0.52	2.33 ± 1.48	3.58 ± 1.99
	Random	5.78 ± 0.56	1.34 ± 1.19	2.22 ± 1.76
Mid	BADGE	7.55 ± 0.25	2.23 ± 1.93	2.59 ± 2.07
	BALD	7.68 ± 0.32	1.14 ± 0.57	1.54 ± 0.76
	BMMAL	7.60 ± 0.34	1.35 ± 0.96	1.72 ± 1.24
	Entropy	7.51 ± 0.38	1.58 ± 1.18	2.16 ± 1.44
	GRACE	7.61 ± 0.20	2.98 ± 2.20	3.62 ± 2.51
	KCenterGreedy	7.38 ± 0.22	3.39 ± 1.93	4.40 ± 2.07
	Random	7.50 ± 0.23	1.35 ± 0.88	1.74 ± 0.99
High	BADGE	8.84 ± 0.12	2.47 ± 1.50	2.51 ± 1.55
	BALD	8.83 ± 0.11	2.90 ± 2.75	2.95 ± 2.81
	BMMAL	8.89 ± 0.15	3.05 ± 2.47	3.09 ± 2.52
	Entropy	8.85 ± 0.10	1.48 ± 0.78	1.51 ± 0.80
	GRACE	8.82 ± 0.13	3.80 ± 3.14	3.84 ± 3.18
	KCenterGreedy	8.92 ± 0.11	4.77 ± 3.64	4.86 ± 3.76
	Random	8.86 ± 0.17	2.49 ± 1.54	2.54 ± 1.58

图 8　使用 ModDrop 时 Synergy 的结果。



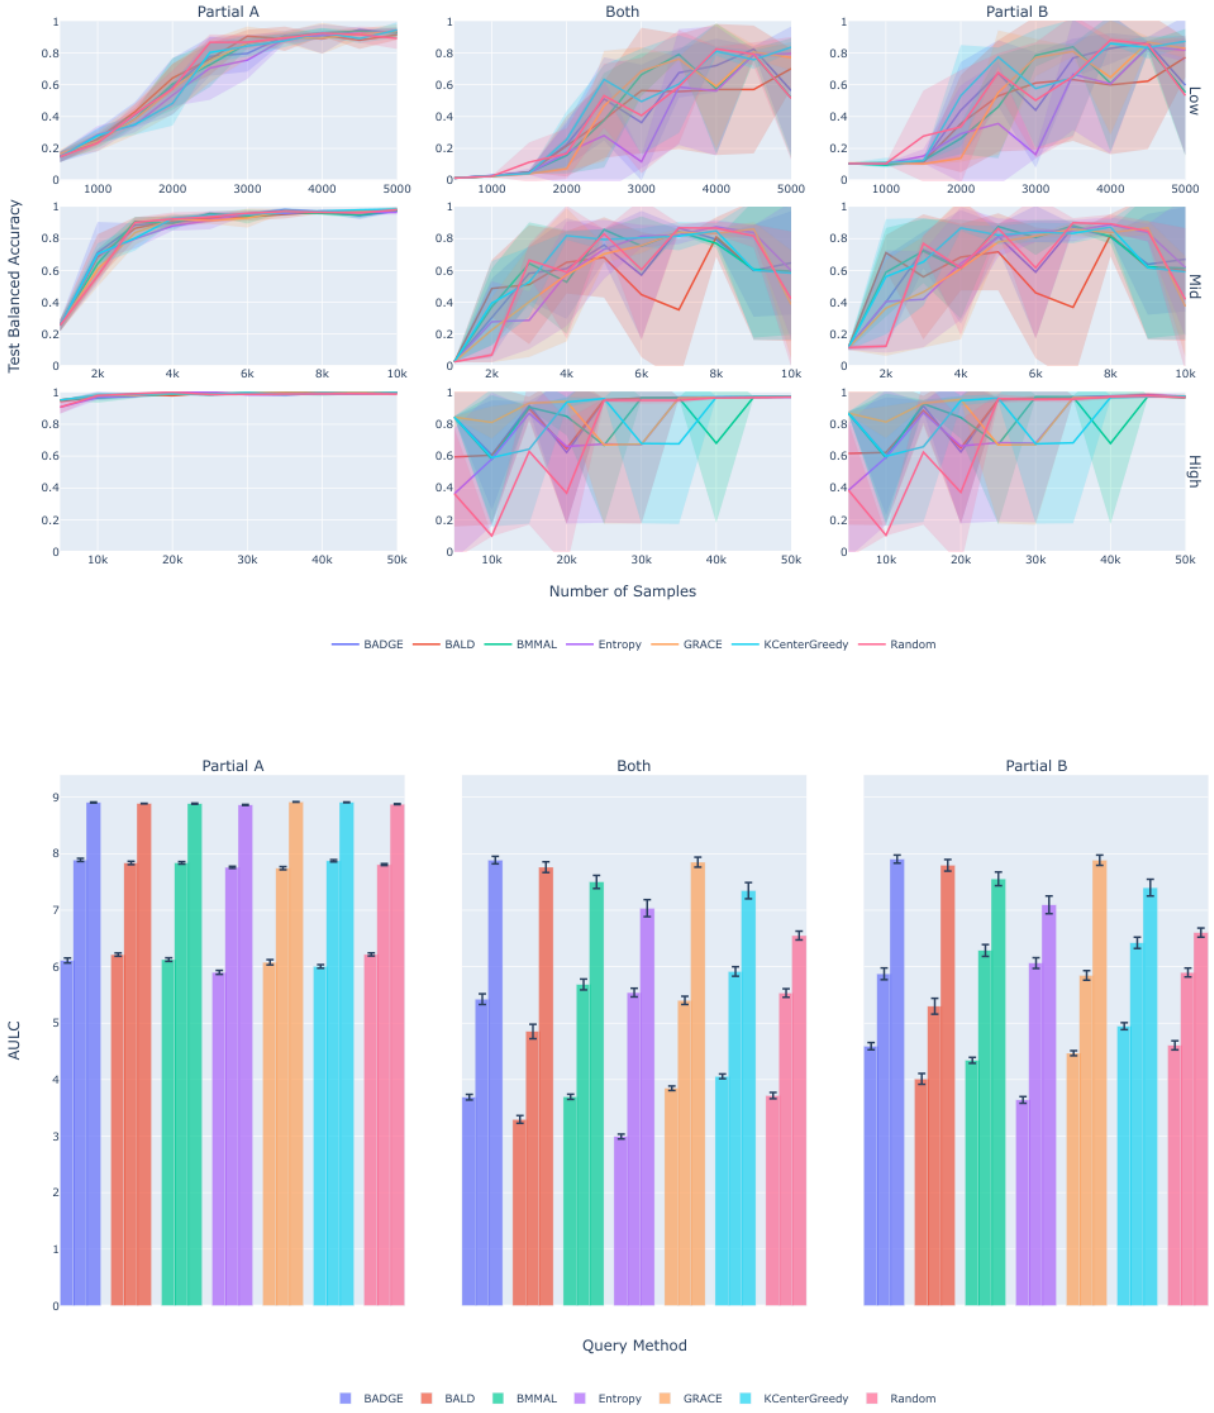
展示所有查询方法在 Synergy 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

表 14　不使用 ModDrop 时 Synergy 的结果。 展示所有查询方法在 Synergy 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	A	Both	B
Low	BADGE	6.11 ± 0.72	3.69 ± 1.33	4.59 ± 1.38
	BALD	6.21 ± 0.46	3.30 ± 2.07	4.01 ± 2.40
	BMMAL	6.13 ± 0.51	3.70 ± 1.23	4.34 ± 1.20
	Entropy	5.90 ± 0.59	2.99 ± 1.41	3.64 ± 1.62
	GRACE	6.08 ± 0.76	3.85 ± 1.02	4.47 ± 0.99
	KCenterGreedy	6.00 ± 0.51	4.06 ± 1.02	4.95 ± 1.25
	Random	6.22 ± 0.43	3.72 ± 1.49	4.61 ± 1.74
Mid	BADGE	7.89 ± 0.35	5.42 ± 1.74	5.87 ± 1.77
	BALD	7.84 ± 0.36	4.85 ± 2.62	5.30 ± 2.65
	BMMAL	7.84 ± 0.27	5.68 ± 1.68	6.29 ± 1.67
	Entropy	7.76 ± 0.24	5.54 ± 1.38	6.06 ± 1.56
	GRACE	7.74 ± 0.35	5.40 ± 1.34	5.84 ± 1.44
	KCenterGreedy	7.87 ± 0.25	5.91 ± 1.42	6.42 ± 1.56
	Random	7.81 ± 0.21	5.53 ± 1.36	5.90 ± 1.34
High	BADGE	8.91 ± 0.10	7.89 ± 0.85	7.90 ± 0.91
	BALD	8.89 ± 0.04	7.76 ± 1.22	7.79 ± 1.32
	BMMAL	8.89 ± 0.10	7.50 ± 1.54	7.55 ± 1.60
	Entropy	8.86 ± 0.09	7.04 ± 2.14	7.09 ± 2.21
	GRACE	8.92 ± 0.05	7.85 ± 1.13	7.89 ± 1.16
	KCenterGreedy	8.91 ± 0.07	7.35 ± 1.95	7.40 ± 2.00
	Random	8.88 ± 0.09	6.55 ± 1.19	6.60 ± 1.22

译者注（原文表间差异）： 对于 Synergy、中标注量、BADGE、部分信息模态 B，正文表 2 给出 5.42，附录表 14 给出 5.87 ± 1.77。此处保留原表各自数值，不自行判定哪一项正确。

图 9　不使用 ModDrop 时 Synergy 的结果。



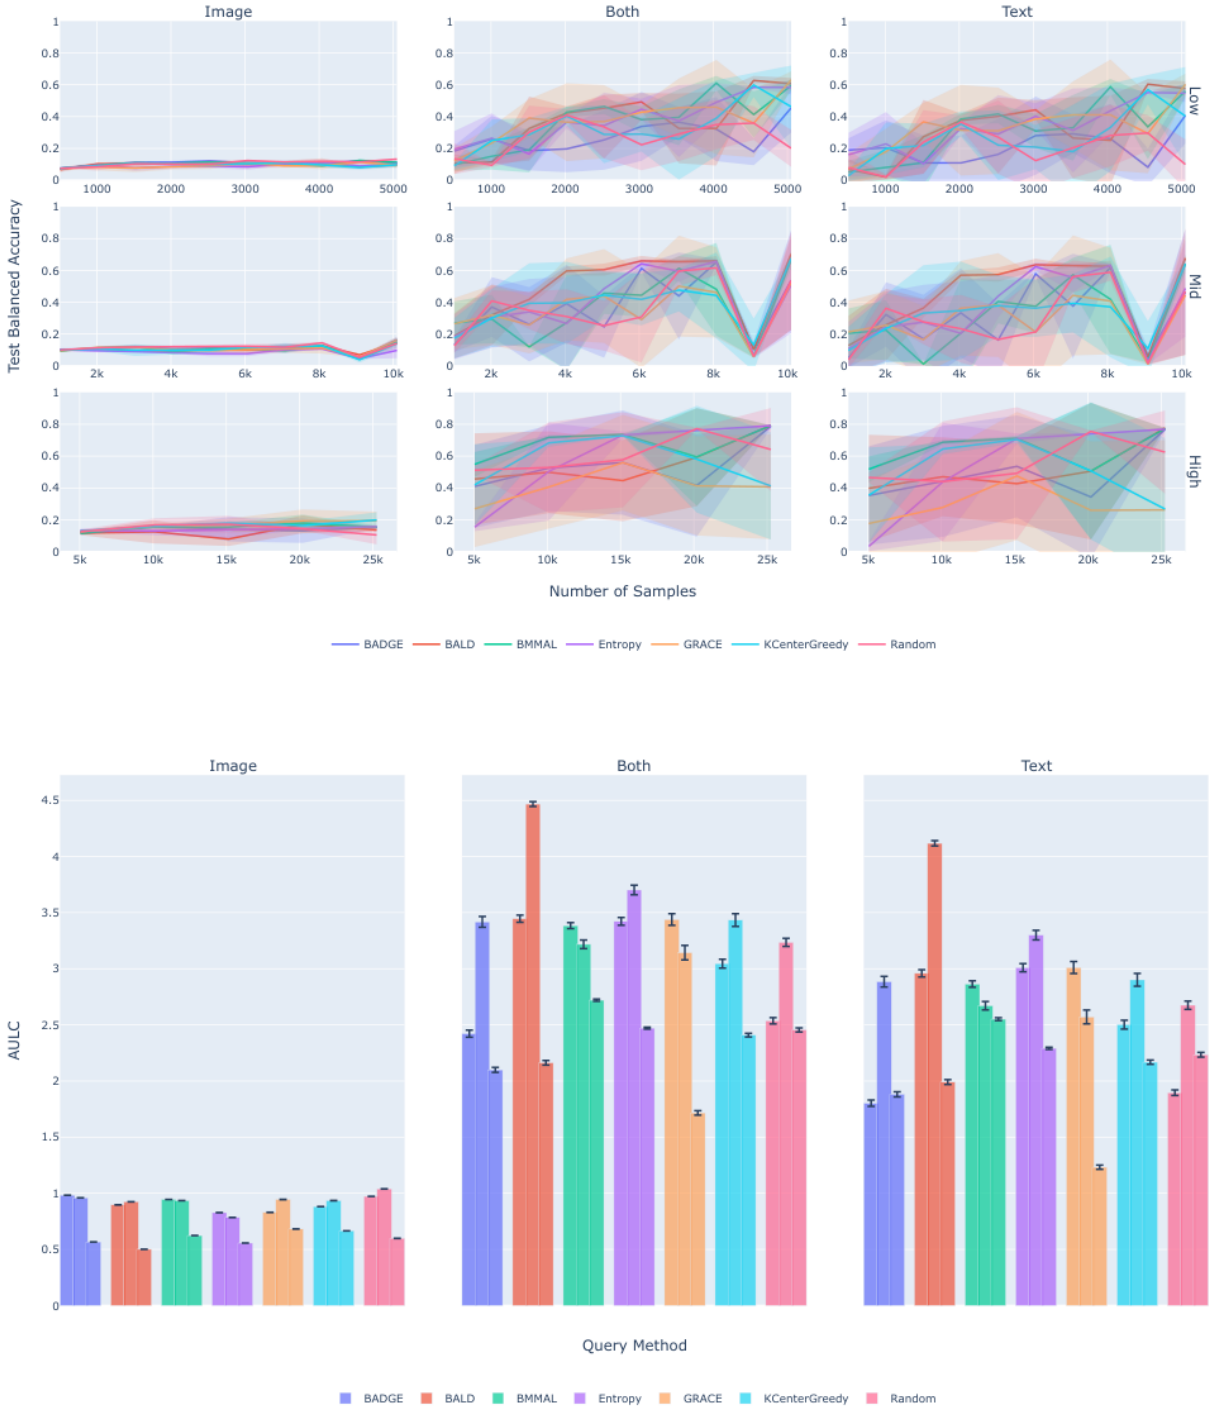
展示所有查询方法在 Synergy 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

B.5 Food101

表 15　使用 ModDrop 时 Food101 的结果。 展示所有查询方法在 Food101 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	Image	Both	Text
Low	BADGE	0.98 ± 0.08	2.42 ± 1.30	1.80 ± 1.56
	BALD	0.90 ± 0.14	3.45 ± 0.93	2.96 ± 1.10
	BMMAL	0.94 ± 0.07	3.38 ± 0.79	2.86 ± 1.00
	Entropy	0.83 ± 0.11	3.42 ± 1.00	3.01 ± 1.21
	GRACE	0.83 ± 0.14	3.44 ± 1.51	3.01 ± 1.77
	KCenterGreedy	0.88 ± 0.09	3.05 ± 1.30	2.50 ± 1.57
	Random	0.97 ± 0.08	2.54 ± 1.11	1.90 ± 1.30
Mid	BADGE	0.96 ± 0.10	3.42 ± 1.40	2.88 ± 1.64
	BALD	0.92 ± 0.09	4.47 ± 0.48	4.12 ± 0.58
	BMMAL	0.93 ± 0.09	3.22 ± 1.19	2.67 ± 1.40
	Entropy	0.78 ± 0.10	3.70 ± 1.16	3.30 ± 1.30
	GRACE	0.94 ± 0.16	3.14 ± 2.06	2.57 ± 2.40
	KCenterGreedy	0.93 ± 0.16	3.43 ± 1.65	2.90 ± 1.96
	Random	1.04 ± 0.10	3.23 ± 1.12	2.68 ± 1.38
High	BADGE	0.57 ± 0.17	2.10 ± 1.06	1.88 ± 1.21
	BALD	0.50 ± 0.19	2.16 ± 0.96	1.99 ± 1.10
	BMMAL	0.62 ± 0.10	2.72 ± 0.36	2.55 ± 0.50
	Entropy	0.56 ± 0.10	2.47 ± 0.35	2.29 ± 0.42
	GRACE	0.68 ± 0.16	1.72 ± 1.16	1.23 ± 1.54
	KCenterGreedy	0.67 ± 0.08	2.41 ± 0.66	2.17 ± 0.86
	Random	0.60 ± 0.14	2.45 ± 0.73	2.23 ± 0.94

图 10　使用 ModDrop 时 Food101 的结果。



展示所有查询方法在 Food101 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。

B.6 MIMIC

表 16　使用 ModDrop 时 MIMIC 的结果。 展示所有查询方法在 MIMIC 数据集上的 AULC ± 标准差。越高越好。

Regime	QM	ECG	Both	Bloodlabs
Low	BADGE	4.60 ± 0.18	6.51 ± 0.10	6.55 ± 0.08
	BALD	4.61 ± 0.17	6.52 ± 0.08	6.55 ± 0.07
	BMMAL	4.62 ± 0.17	6.51 ± 0.10	6.52 ± 0.10
	Entropy	4.60 ± 0.19	6.49 ± 0.08	6.53 ± 0.08
	GRACE	4.63 ± 0.18	6.43 ± 0.16	6.44 ± 0.16
	KCenterGreedy	4.64 ± 0.16	6.42 ± 0.11	6.03 ± 0.38
	Random	4.73 ± 0.28	6.51 ± 0.08	6.54 ± 0.08
Mid	BADGE	4.71 ± 0.20	6.55 ± 0.08	6.54 ± 0.09
	BALD	4.87 ± 0.28	6.59 ± 0.08	6.61 ± 0.06
	BMMAL	4.74 ± 0.27	6.55 ± 0.07	6.54 ± 0.09
	Entropy	4.67 ± 0.20	6.57 ± 0.11	6.56 ± 0.13
	GRACE	4.82 ± 0.26	6.45 ± 0.09	6.40 ± 0.20
	KCenterGreedy	4.62 ± 0.07	6.49 ± 0.06	6.27 ± 0.14
	Random	5.03 ± 0.19	6.58 ± 0.06	6.61 ± 0.05
High	BADGE	4.85 ± 0.26	6.62 ± 0.08	6.59 ± 0.08
	BALD	5.13 ± 0.18	6.66 ± 0.06	6.65 ± 0.06
	BMMAL	4.87 ± 0.22	6.67 ± 0.05	6.64 ± 0.06
	Entropy	4.74 ± 0.17	6.61 ± 0.07	6.59 ± 0.07
	GRACE	4.76 ± 0.23	6.56 ± 0.10	6.53 ± 0.09
	KCenterGreedy	4.76 ± 0.05	6.61 ± 0.03	6.52 ± 0.04
	Random	5.23 ± 0.09	6.67 ± 0.06	6.66 ± 0.06

图 11　使用 ModDrop 时 MIMIC 的结果。



展示所有查询方法在 MIMIC 数据集上的测试结果。上部：主动学习实验过程中平衡测试准确率的变化，标准差以较浅阴影表示。下部：使用 AULC 汇总上方曲线，柱上标出标准差。对于每种查询方法与每个模态，从左到右的三根柱分别表示低、中、高标注量设置。两个子图中，数值越高都表示性能越好。