MMPareto：利用无害的单模态辅助促进多模态学习

非官方中文全文译文｜原文：Yake Wei[1]、Di Hu[12]，ICML 2024，PMLR 235:52559–52572。

作者单位：[1]中国人民大学高瓴人工智能学院，中国北京；[2]大数据管理与分析方法北京市重点实验室，中国北京。通讯作者：Di Hu，dihu@ruc.edu.cn。

原文发表于第 41 届国际机器学习大会论文集，奥地利维也纳，2024。版权 © 2024 原作者。原文链接：https://proceedings.mlr.press/v235/wei24d.html 。依据 PMLR 出版协议的 CC BY 4.0 许可制作本中文翻译（https://creativecommons.org/licenses/by/4.0/）。本译文为翻译与重新排版的改编，不代表原作者或出版方认可。原图、原表保留以精确呈现数据，图表标题及文字释义译为中文；专名和参考文献著录保留以便检索。源文件 SHA-256：`e571649b6e1245dd2175be90545002180bf67ddd2b871318da17cc9f67cb0bfd`。

摘要

具有针对性单模态学习目标的多模态学习方法，在缓解多模态学习不平衡问题方面表现出优越效果。然而，本文发现了此前被忽视的多模态与单模态学习目标之间的梯度冲突，这种冲突可能误导单模态编码器的优化。为有效减少冲突，我们考察多模态损失与单模态损失之间的差异：较易学习的多模态损失，其梯度幅值及协方差均小于单模态损失。利用这一性质，我们分析多模态场景下的帕累托融合，并提出 MMPareto 算法。该算法能够保证最终梯度的方向对所有学习目标都是共同的下降方向，同时增强幅值以改善泛化，从而提供无害的单模态辅助。最后，跨多种模态类型以及具有密集跨模态交互的框架的实验，表明我们的方法性能优越且可扩展。我们的方法也有望促进任务难度存在明显差异的多任务场景，体现出理想的可扩展性。源代码与数据集见 https://github.com/GeWu-Lab/MMPareto_ICML2024 。

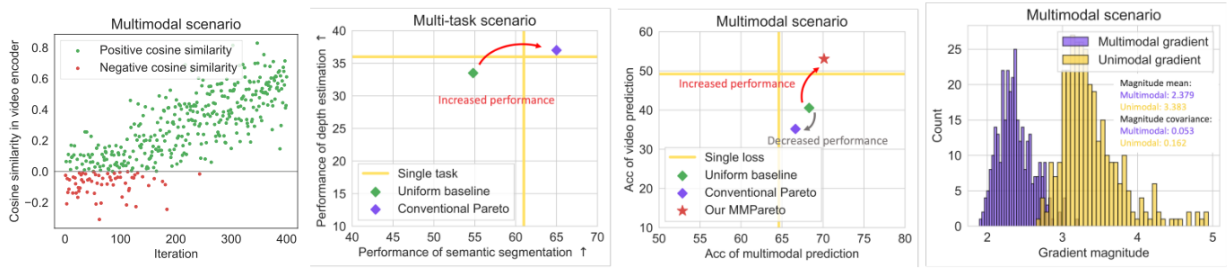
1. 引言

人们沉浸于包括视觉、听觉和触觉在内的多种感知之中，这催生了多模态学习（Baltrušaitis 等，2018；Lin 等，2023）以及视听学习（Wei 等，2022）。尽管许多多模态方法已经展现出有效性，Peng 等（2022）指出了多模态学习不平衡问题：多数多模态模型不能很好地联合利用全部模态，对各模态的利用不均衡。该问题近期受到广泛关注（Zhang 等，2024）。研究者提出了若干方法，通过额外模块（Wang 等，2020）或模态特定训练策略（Peng 等，2022；Wu 等，2022；Wei 等，2024）改善学习较差模态的训练。这些方法通常有一个共同思路，即有针对性地改善单模态训练。其中，类多任务方法在多模态联合学习目标之外直接添加单模态学习目标，在缓解此类不平衡问题方面展现出卓越效果（Wang 等，2020；Du 等，2023；Fan 等，2023）。

然而，在有效性能背后，我们观察到这一广泛使用的类多任务场景中，模型优化存在此前被忽视、可能限制模型能力的风险。凡事均有两面性。单模态学习目标无疑能有效增强相应模态的学习；与此同时，单模态编码器参数的优化同时受到多模态联合学习目标和其自身单模态学习目标的影响。这意味着需要同时最小化两个学习目标，但通常并不存在一组能够满足这一要求的参数。因此，这些多模态和单模态

学习目标在优化过程中可能发生冲突。图 1a 以广泛使用的 Kinetics Sounds 数据集上的视频编码器为例。负余弦相似度表明，多模态与单模态梯度的方向在优化期间确实存在冲突。尤其在训练早期，这些冲突可能显著损害模型能力（Liu 等，2020）。因此，主要的多模态学习可能受到干扰。

要避免优化冲突，必须妥善融合两个梯度，使单模态梯度不妨碍、而是辅助主要的多模态训练。这一需求自然契合帕累托方法（Sener & Koltun，2018）的思想：寻找有益于所有目标的最陡下降方向，并最终收敛到目标之间的折中状态。图 1b 展示了具有代表性的多任务场景之一，即 Cityscapes（Cordts 等，2016）数据集上的语义分割与深度估计任务，帕累托方法在平衡这两项任务的学习目标方面取得了理想进展。因此，人们预期它也能在这一类多任务的多模态学习框架中保持解决冲突的优势。然而，事实与预期相反。图 1c 表明，传统帕累托方法（Sener & Koltun，2018）令人意外地失效，甚至不如将所有梯度等权相加的均匀基线。



(a) Kinetics Sounds. (b) Cityscapes. (c) Kinetics Sounds. (d) Kinetics Sounds.

图 1。(a) Kinetics Sounds 数据集（Arandjelovic & Zisserman，2017）的视频编码器中，多模态梯度与单模态梯度的余弦相似度。(b) 多任务数据集 Cityscapes（Cordts 等，2016）上的方法性能；结果来自 Sener & Koltun（2018）。(c) Kinetics Sounds 视频编码器中的多模态与单模态预测性能。Single loss（单一损失）表示使用一个相应学习目标单独训练模型的结果。(d) Kinetics Sounds 数据集中固定视频编码器的梯度幅值分布；每个计数对应一次 SGD 优化的小批量。Uniform baseline（均匀基线）是不进行特殊融合、将所有损失等权求和的基本方法。图中 Positive/Negative cosine similarity 分别为正/负余弦相似度，Iteration 为迭代次数，Gradient magnitude 为梯度幅值，Multimodal/Unimodal 为多模态/单模态；Multi-task scenario＝多任务场景；Single task＝单任务；Conventional Pareto＝传统帕累托；Our MMPareto＝本文 MMPareto；Increased/Decreased performance＝性能提高/下降。图 (b) 横轴为语义分割性能，纵轴为深度估计性能，向上箭头表示越高越好；图 (c) 横轴为多模态预测准确率，纵轴为视频预测准确率；图 (d) Count＝计数，Magnitude mean＝幅值均值（多模态 2.379，单模态 3.383），Magnitude covariance＝幅值协方差（多模态 0.053，单模态 0.162）。

为探索这一反直觉现象，我们首先分析多模态学习场景的性质。不同于典型多任务情况，多模态联合损失利用所有模态的信息进行优化，而单模态损失仅利用相应模态的信息。因此，多模态损失天然更容易学习；更低的训练误差和更快的收敛速度也验证了这一点（Wang 等，2020）。我们分析一组固定参数下的梯度幅值分布。图 1d 显示，多模态梯度幅值小于单模态梯度，其批采样协方差也更小。利用这些梯度幅值性质，我们进一步从理论上分析并通过实验证实：传统帕累托方法可能影响 SGD 噪声强度，进而使模型进入更尖锐的极小值，削弱模型泛化能力。

基于上述分析，妥善解决多模态场景中的梯度冲突十分必要。因此，我们提出多模态帕累托（MultiModal Pareto，MMPareto）算法，在梯度融合中分别考虑方向和幅值。它保证无害的单模态辅助：最终梯度具有所有学习目标共同的下降方向，并增强幅值以改善泛化。我们也分析方法的收敛

性。多类数据集上的结果表明，该方法有效缓解多模态学习不平衡问题，并可很好地应用于具有密集跨模态交互的模型，例如多模态 Transformer。如图 1c 所示，我们的方法同时提供出色的多模态和单模态性能。更重要的是，单模态性能甚至超过独立训练的单模态模型，这在以往很少实现。此外，我们验证了该方法也可扩展到任务难度明显不同的多任务场景，表明其可扩展性。

我们的贡献有三点。第一，发现了用于多模态学习不平衡问题的广泛使用的类多任务框架中，此前被忽视的梯度冲突。第二，从理论上分析帕累托方法在多模态情形下失效的原因，进而提出能够提供无害单模态辅助并增强泛化的 MMPareto 算法。第三，不同数据集上的实验验证了理论分析及优越性能。

2. 相关工作

2.1. 多模态学习不平衡

近期研究揭示了多模态学习不平衡问题：多模态模型倾向于偏爱特定模态，从而限制总体性能（Peng 等，2022；Huang 等，2022）。针对该问题已有若干方法，其共同重点是有针对性地增强各模态的优化（Wang 等，2020；Peng 等，2022；Wu 等，2022；Fan 等，2023）。例如，Xu 等（2023）关注对可区分特征分布要求更高的细粒度分类任务；Yang 等（2024）关注多模态鲁棒性；Wei 等（2024）提出基于 Shapley 值的样本级模态价值评估指标，用于观察并缓解细粒度模态差异。其中，直接引入针对性单模态约束的类多任务方法已表现出优越效果（Wang 等，2020；Du 等，2023；Fan 等，2023）。然而，在这种类多任务框架下，单模态编码器的优化同时受多模态联合学习目标与相应单模态学习目标控制，可能引发梯度冲突，损害主要的多模态学习。本文观察这种潜在冲突，并通过所提出的 MMPareto 算法加以减轻。我们的方法能够有效缓解多模态学习不平衡问题，获得显著改善。

2.2. 多任务学习中的帕累托融合

多任务学习的共享参数需要同时适应多个学习目标，因而在优化中可能出现冲突。因此，帕累托方法被用于融合不同梯度，找到所有目标共同的梯度，并最终收敛到它们的折中状态（Sener & Koltun，2018）。此外，帕累托融合思想从不同角度得到扩展，例如探索不同任务间更多的折中（Lin 等，2019），或提高收敛速度（Ma 等，2020），从而更好地服务多任务学习。类似地，我们在类多任务多模态框架的共享单模态编码器中观察到优化冲突。受帕累托融合成功经验启发，我们引入这一思想，却意外发现其失效。进一步分析发现，帕累托融合在多模态场景中损害了泛化；随后提出的 MMPareto 算法能够处理多模态场景及任务难度存在明显差异的多任务情况。

3. 方法

3.1. 类多任务的多模态框架

在多模态学习中，模型应整合多种模态的信息以产生正确预测。因此，通常存在以融合后的多模态特征预测为输入的多模态联合损失。然而，仅利用这一联合损失共同优化所有模态，可能导致优化过程由某一个模态主导，而其他模态严重欠优化（Peng 等，2022；Huang 等，2022）。为克服多模态学习不平衡问题，广泛使用针对各模态优化的单模态损失；这一做法已被验证能够有效缓解问题（Wang 等，2020）。在这些场景下，损失函数为：

$$\mathcal{L} = \mathcal{L}_m + \sum_{k=1}^{n} \mathcal{L}_u^k. \qquad (1)$$

其中， $\mathcal{L}_m$ 是多模态联合损失， $\mathcal{L}_u^k$ 是模态 k 的单模态损失， n 为模态数。我们主要考虑多模态判别任务，所有损失均为交叉熵损失函数。该类多任务多模态框架示意见图 2 左侧。

3.2. SGD 性质与假设

对于任意损失 $\mathcal{L}$，根据已有研究（Jastrzebski 等，2017），在 SGD 优化中，当批大小足够大时，由中心极限定理，第 t 个小批量 S 上参数 θ 的梯度

$$\mathbf{g}_S(\theta(t)) = \frac{1}{|S|}\sum_{i=1}^{|S|} \nabla_{\theta(t)} \mathcal{L}\left(X_i,\ Y_i\right)$$

是全梯度 $\mathbf{g}_N(\theta(t)) = \frac{1}{N}\sum_{i=1}^{N} \nabla_{\theta(t)} \mathcal{L}\left(X_i,\ Y_i\right)$ 的无偏估计：

$$\mathbf{g}_S(\theta(t)) \sim \mathcal{N}\left(\mathbf{g}_N(\theta(t)),\ \frac{1}{|S|} C\right). \qquad (2)$$

换言之， $\mathbf{g}_S(\theta(t))$ 是协方差为 $\frac{1}{|S|}C$ 的随机变量。 C 来自随机批采样。 N 是训练样本数， $\left(X_i,\ Y_i\right)$ 是一个样本。全梯度基于全部训练样本计算。

如式 (1)，多模态框架同时包含多模态和单模态损失函数。对模态 k 的单模态编码器参数 θ^k，第 t 次迭代时 $\mathcal{L}_m$ 与 $\mathcal{L}_u^k$ 的梯度满足：

$$\mathbf{g}_S^m\left(\theta^k(t)\right) \sim \mathcal{N}\left(\mathbf{g}_N^m\left(\theta^k(t)\right),\ \frac{1}{|S|} C^m\right), \qquad (3)$$

$$\mathbf{g}_S^u\left(\theta^k(t)\right) \sim \mathcal{N}\left(\mathbf{g}_N^u\left(\theta^k(t)\right),\ \frac{1}{|S|} C^u\right). \qquad (4)$$

其中 $\frac{1}{|S|}C^m$ 和 $\frac{1}{|S|}C^u$ 为批采样协方差。在多模态情形中，单模态损失仅接收基于相应模态数据的预测。相比之下，多模态损失利用所有模态数据提供的更充分信息进行优化，更易训练。已有研究证实，多模态损失往往比单模态损失收敛更快、训练误差更低（Wang 等，2020）。

在已有研究之外，我们还在不同数据集上分析了一组固定参数的梯度幅值分布，结果如图 1d 和图 4b；每个计数对应不同小批量。首先，多模态梯度幅值小于单模态梯度，可能源于更低的多模态误差（Chen 等，2018）。除幅值之外，多模态与单模态梯度变量的批采样协方差 $\frac{1}{|S|}C$ 也不同；多模态梯度协方差更小。原因可能在于，来自所有模态的更具判别力的信息能让分类更加确定，这与多模态学习通过增加模态来降低不确定性的动机一致（Trick 等，2019）。因此，多模态训练误差在不同批次间变化更小。总体而言，根据既有研究与我们的验证，可以概括多模态和单模态梯度性质，并提出假设 1。

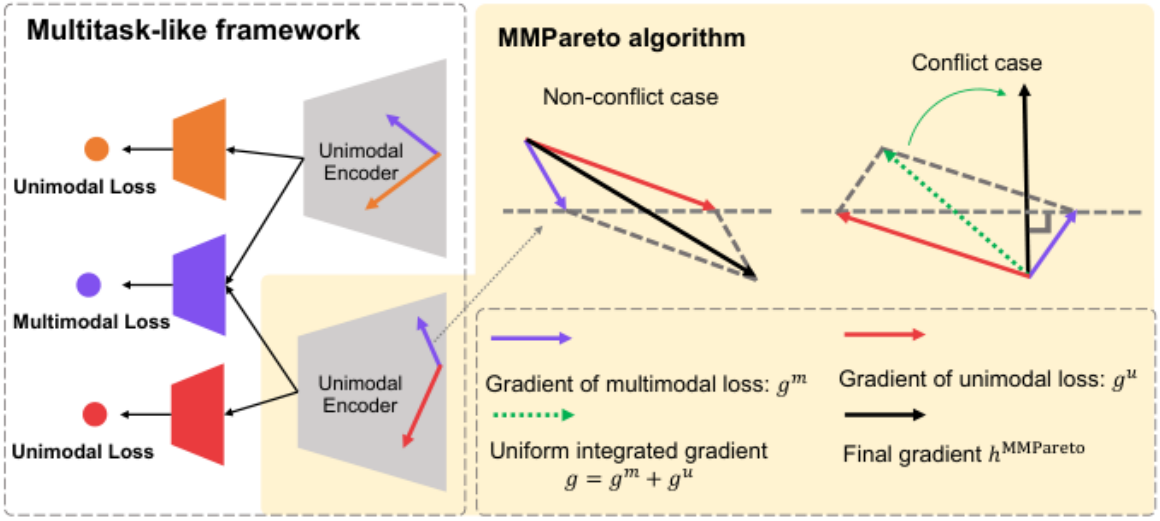


图 2。 多模态框架及 MMPareto 梯度融合策略示意图。图中文字：Multitask-like framework＝类多任务框架；Unimodal Encoder＝单模态编码器；Unimodal Loss＝单模态损失；Multimodal Loss＝多模态损失；Non-conflict case＝无冲突情况；Conflict case＝有冲突情况；多模态损失梯度为 $\mathbf{g}^m$，单模态损失梯度为 $\mathbf{g}^u$，均匀融合梯度为 $\mathbf{g} = \mathbf{g}^m + \mathbf{g}^u$，最终梯度为 $\mathbf{h}^{\text{MMPareto}}$。

假设 1。 在类多任务多模态场景中，对于共享的单模态编码器，相较于易学习的多模态损失，单模态损失的梯度往往具有更大的幅值和更大的批采样协方差。

3.3. 多模态学习中的帕累托融合

3.3.1. 帕累托融合

在多模态情形中，多模态损失与单模态损失紧密相关，但其梯度仍可能存在冲突，如图 1a。因此，需要解决如何妥善融合 $\mathbf{g}_S^m\left(\theta^k(t)\right)$ 与 $\mathbf{g}_S^u\left(\theta^k(t)\right)$ 的问题。这与多任务学习中帕累托方法的思想一致（Sener & Koltun，2018）。帕累托方法在每次迭代为梯度分配不同权重，并以其加权组合为最终梯度，提供有利于所有学习目标的下降方向。最终，参数可以收敛到一个折中状态，即帕累托最优状态：不损害任何其他目标，就不能改善任一目标。将帕累托融合引入多模态框架，避免多模态与单模态梯度冲突，是自然的做法。具体而言，在本文场景中，模态 k 的帕累托算法求解：

$$\min_{\alpha^m,\alpha^u\in\mathbb{R}} \parallel \alpha^m\mathbf{g}_S^m + \alpha^u\mathbf{g}_S^u \parallel^2, \quad \text{s.t. } \alpha^m,\ \alpha^u \geq 0,\ \ \alpha^m + \alpha^u = 1. \tag{5}$$

其中 $\parallel\cdot\parallel$ 表示 L_2 范数。为简洁起见，部分地方将模态 k 的 $\{\mathbf{g}_S^i\left(\theta^k(t)\right)\}_{i\in\{m,u\}}$ 简记为 $\{\mathbf{g}_S^i\}_{i\in\{m,u\}}$。该问题等价于寻找梯度向量族 $\{\mathbf{g}_S^i\}_{i\in\{m,u\}}$ 的凸包中的最小范数。Désidéri（2012）表明，该优化问题求得的最小范数要么为 0，相应参数为帕累托驻点（这是帕累托最优性的必要条件）；要么它能提供所有学习目标共同的下降方向。

3.3.2. 帕累托解析解

图 1c 表明，人们期望帕累托融合在类多任务多模态框架中发挥优势，结果却出人意料地失败。为探索深层原因，我们进一步分析帕累托融合的性质。根据假设 1，多模态梯度幅值通常小于单模态梯度，即 $\| \mathbf{g}_S^m \| < \| \mathbf{g}_S^u \|$ 。于是式 (5) 的解析解为：

$$\begin{cases} \alpha^m = 1, \ \alpha^u = 0, & \cos\beta \geq \dfrac{\| \mathbf{g}_S^m \|}{\| \mathbf{g}_S^u \|}, \\ \alpha^m = \dfrac{\left(\mathbf{g}_S^u - \mathbf{g}_S^m\right)^\top \mathbf{g}_S^u}{\| \mathbf{g}_S^m - \mathbf{g}_S^u \|^2}, \ \alpha^u = 1 - \alpha^m, \text{ otherwise.} \end{cases}$$

其中 otherwise 表示“其他情况”， β 为 $\mathbf{g}_S^m$ 和 $\mathbf{g}_S^u$ 的夹角。进一步分析此解析解：当 $\cos\beta \geq \| \mathbf{g}_S^m \| / \| \mathbf{g}_S^u \|$ 时，有 $\alpha^m > \alpha^u$ 。否则，同样有：

$$\begin{aligned} \alpha^m - \alpha^u &= \frac{\left(\mathbf{g}_S^u - \mathbf{g}_S^m\right)^\top \mathbf{g}_S^u}{\| \mathbf{g}_S^m - \mathbf{g}_S^u \|^2} - \left(1 - \frac{\left(\mathbf{g}_S^u - \mathbf{g}_S^m\right)^\top \mathbf{g}_S^u}{\| \mathbf{g}_S^m - \mathbf{g}_S^u \|^2}\right) \\ &= \frac{\| \mathbf{g}_S^u \|^2 - \| \mathbf{g}_S^u \| \ \| \mathbf{g}_S^m \| \cos\beta}{\| \mathbf{g}_S^m - \mathbf{g}_S^u \|^2} \\ &\quad - \frac{\| \mathbf{g}_S^m \|^2 - \| \mathbf{g}_S^u \| \ \| \mathbf{g}_S^m \| \cos\beta}{\| \mathbf{g}_S^m - \mathbf{g}_S^u \|^2} \\ &> 0. \qquad \left(\| \mathbf{g}_S^m \| < \| \mathbf{g}_S^u \| \right) \end{aligned}$$

备注 1。 传统帕累托方法会为幅值较小的多模态梯度赋予更大权重。

总之，如备注 1 所述，帕累托方法在融合时倾向于为多模态梯度 $\mathbf{g}_S^m$ 赋予更大的权重，即 $\alpha^m > \frac{1}{2}$ 。

3.3.3. 帕累托损害泛化的风险

本节沿用第 3.2 节的记号。训练时，多个损失的梯度分别计算，因此可以视为彼此独立（Fan 等，2022）。当不使用任何梯度融合策略时，即所有损失等权求和的均匀基线，最终梯度为 $\mathbf{h}_S\left(\theta^k(t)\right) = \mathbf{g}_S^m\left(\theta^k(t)\right) + \mathbf{g}_S^u\left(\theta^k(t)\right)$ 。由式 (3)、(4) 可知：

$$\mathbf{h}_S\left(\theta^k(t)\right) \sim \mathcal{N}\left(\mathbf{g}_N^m\left(\theta^k(t)\right) + \mathbf{g}_N^u\left(\theta^k(t)\right), \ \frac{C^m + C^u}{|S|}\right). \qquad (6)$$

随后使用最终梯度 $\mathbf{h}_S\left(\theta^k(t)\right)$ 更新 θ^k ：

$$\theta^k(t+1) = \theta^k(t) - \eta \mathbf{h}_S\left(\theta^k(t)\right), \qquad (7)$$

$$= \theta^k(t) - \eta \mathbf{h}_N\left(\theta^k(t)\right) + \eta \epsilon_t. \qquad (8)$$

其中， $\mathbf{h}_N\left(\theta^k(t)\right) = \mathbf{g}_N^m\left(\theta^k(t)\right) + \mathbf{g}_N^u\left(\theta^k(t)\right)$ ， $\eta > 0$ 为学习率。 $\epsilon_t \sim \mathcal{N}(0, \ (C^m + C^u)/|S|)$ 通常被视为 SGD 噪声项（Zhu 等，2018）。

接下来考虑使用传统帕累托梯度融合的 SGD 优化。每次迭代，帕累托方法返回权重 α^m 与 α^u，以融合 $\mathbf{g}_S^m\left(\theta^k(t)\right)$ 和 $\mathbf{g}_S^u\left(\theta^k(t)\right)$。融合后的最终梯度为 $\mathbf{h}_S^{\text{Pareto}}\left(\theta^k(t)\right) = 2\alpha^m\mathbf{g}_S^m\left(\theta^k(t)\right) + 2\alpha^u\mathbf{g}_S^u\left(\theta^k(t)\right)$，满足：

$$\mathbf{h}_S^{\text{Pareto}}\left(\theta^k(t)\right) \sim \mathcal{N}\left(\mathbf{h}_N^{\text{Pareto}}\left(\theta^k(t)\right),\ \frac{(2\alpha^m)^2C^m + (2\alpha^u)^2C^u}{|S|}\right). \tag{9}$$

其中 $\mathbf{h}_N^{\text{Pareto}}\left(\theta^k(t)\right) = 2\alpha^m\mathbf{g}_N^m\left(\theta^k(t)\right) + 2\alpha^u\mathbf{g}_N^u\left(\theta^k(t)\right)$。这里用 $2\alpha^i$ 作为梯度权重，使权重之和与均匀基线一致，即 $2\alpha^m + 2\alpha^u = 2$。使用帕累托融合时，参数更新为：

$$\theta^k(t+1) = \theta^k(t) - \eta\mathbf{h}_S^{\text{Pareto}}\left(\theta^k(t)\right), \tag{10}$$

$$= \theta^k(t) - \eta\mathbf{h}_N^{\text{Pareto}}\left(\theta^k(t)\right) + \eta\zeta_t. \tag{11}$$

SGD 噪声项为 $\zeta_t \sim \mathcal{N}\left(0,\ \frac{(2\alpha^m)^2C^m + (2\alpha^u)^2C^u}{|S|}\right)$。

根据假设 1，单模态梯度往往具有更大的批采样协方差。假设多模态与单模态梯度的协方差满足 $kC^m = C^u$，其中 $k > 1$。由此可探索 ζ_t 与 ϵ_t 的关系。当 ζ_t 的协方差小于 ϵ_t 时，应满足：

$$(2\alpha^m)^2C^m + (2\alpha^u)^2C^u < C^m + C^u, \tag{12}$$

$$(2\alpha^m)^2C^m + (2(1-\alpha^m))^2 \cdot kC^m < (k+1)C^m, \tag{13}$$

$$(2\alpha^m)^2 + 4k - 8\alpha^m k + (2\alpha^m)^2 k < k + 1, \tag{14}$$

$$\left(\alpha^m - \tfrac{1}{2}\right)((4k+4)\alpha^m + 2 - 6k) < 0. \tag{15}$$

因此，当 $\frac{1}{2} < \alpha^m < \frac{3k-1}{2k+2}$ 时，ζ_t 的协方差小于 ϵ_t，即 $\text{var}\left(\zeta_t\right) < \text{var}\left(\epsilon_t\right)$。此外，由备注 1，帕累托权重满足 $\frac{1}{2} < \alpha^m \leq 1$。结合取值范围，可得：

- 当 $k \leq 3$ 时，若 $\frac{1}{2} < \alpha^m < \frac{3k-1}{2k+2}$，则 $\text{var}\left(\zeta_t\right) < \text{var}\left(\epsilon_t\right)$。
- 当 $k > 3$ 时，$\frac{3k-1}{2k+2} > 1$，对所有帕累托权重 α^m 均有 $\text{var}\left(\zeta_t\right) < \text{var}\left(\epsilon_t\right)$。

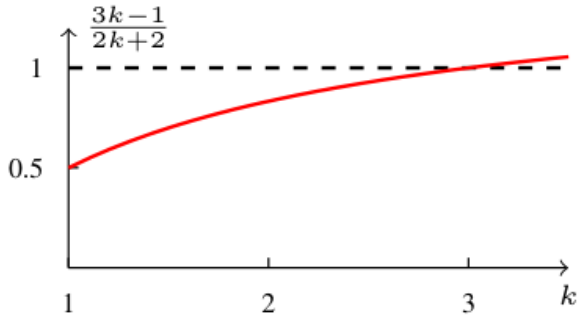


图 3。 $\frac{3k-1}{2k+2}$ 随 k 变化的取值。

此外，图 3 给出了 $\frac{3k-1}{2k+2}$ 随 k 的变化。当 $k \leq 3$ 时，随着 k 增大，该比值迅速增大。图 1d、图 4b 也表明，实验中单模态与多模态梯度的协方差之比通常超过 3。这些现象说明 $\mathrm{var}(\zeta_t) < \mathrm{var}(\epsilon_t)$ 在实践中可能经常发生。

根据已有研究，噪声项强度会影响 SGD 找到的极小值；更强噪声往往带来更平坦的极小值，而这类极小值通常具有良好的泛化能力（Hochreiter & Schmidhuber，1997；Keskar 等，2016；Neyshabur 等，2017）。因此，当 $\mathrm{var}(\zeta_t) < \mathrm{var}(\epsilon_t)$ 时，与式 (8) 中均匀基线的 SGD 噪声项相比，式 (11) 中传统帕累托融合的 SGD 噪声强度可能更小，进而使模型具有更尖锐的极小值，损害其泛化能力。

3.4. 多模态帕累托算法

上述分析表明，传统帕累托方法可能使模型进入更尖锐的极小值，削弱多模态学习的泛化能力。因此，必须妥善处理多模态场景中的梯度冲突。本文提出多模态帕累托（MMPareto）算法，在梯度融合时同时考虑方向和幅值，提供无害的单模态辅助：最终梯度具有所有学习目标共同的方向，同时增强幅值以改善泛化。该方法分别考虑有冲突和无冲突两种情况。完整算法见算法 1，图示见图 2。下文以模态 k 的编码器为例；所有模态编码器采用相同的融合方式。为简洁起见，省略 $\theta^k(t)$。

无冲突情况。首先考虑 $\cos\beta \geq 0$。此时 $\mathbf{g}_S^m$ 与 $\mathbf{g}_S^u$ 的余弦相似度为正。从方向上看，梯度向量族 $\{\mathbf{g}_S^i\}_{i\in\{m,u\}}$ 的任意凸组合对于所有学习目标都是共同的方向。因此，此时在融合中设定 $2\alpha^m = 2\alpha^u = 1$，而不采用帕累托解析解，以增强 SGD 噪声项。此设置下，最终梯度 $\mathbf{h}_S^{\mathrm{MMPareto}} \sim \mathcal{N}\left(\mathbf{g}_N^m + \mathbf{g}_N^u,\ (C^m + C^u)/|S|\right)$。噪声项为 $\xi_t \sim \mathcal{N}\left(0,\ (C^m + C^u)/|S|\right)$，其强度比式 (11) 中传统帕累托噪声项 ζ_t 更大。

有冲突情况。当 $\cos\beta < 0$ 时，梯度融合必须找到所有损失共同的方向，并增强 SGD 噪声强度。因此，首先求解式 (5) 的帕累托优化问题，得到能够提供无冲突方向的 α^m 与 α^u。然后增大最终梯度幅值以提高噪声项强度，并以均匀基线的幅值为基准，将其调整到适当范围：

$$\mathbf{h}_S^{\mathrm{MMPareto}} = \frac{2\alpha^m \mathbf{g}_S^m + 2\alpha^u \mathbf{g}_S^u}{\| 2\alpha^m \mathbf{g}_S^m + 2\alpha^u \mathbf{g}_S^u \|} \cdot \| \mathbf{g}_S^m + \mathbf{g}_S^u \| . \qquad (16)$$

此时最终梯度 $\mathbf{h}_S^{\mathrm{MMPareto}} = \lambda \mathbf{h}_S^{\mathrm{Pareto}}$，其中 $\lambda = \| \mathbf{g}_S^m + \mathbf{g}_S^u \| / \| 2\alpha^m \mathbf{g}_S^m + 2\alpha^u \mathbf{g}_S^u \|$。根据备注 1，幅值较小的多模态梯度具有更大权重，故有 $\| 2\alpha^m \mathbf{g}_S^m + 2\alpha^u \mathbf{g}_S^u \| < \| \mathbf{g}_S^m + \mathbf{g}_S^u \|$，相应地 $\lambda > 1$。于是，最终梯度满足：

$$\mathbf{h}_S^{\mathrm{MMPareto}} \sim \mathcal{N}\left(\lambda \mathbf{h}_N^{\mathrm{Pareto}},\ \lambda^2 \cdot \frac{(2\alpha^m)^2 C^m + (2\alpha^u)^2 C^u}{|S|}\right).$$

噪声项为 $\xi_t \sim \mathcal{N}\left(0,\ \lambda^2 \cdot \frac{(2\alpha^m)^2 C^m + (2\alpha^u)^2 C^u}{|S|}\right)$，强度大于式 (11) 中传统帕累托的噪声项 ζ_t。噪声强度得到增强，模型泛化能力也相应改善。

融合后，为进一步增强泛化，略微增大最终梯度的幅值：$\mathbf{h}_S^{\mathrm{MMPareto}} = \gamma \mathbf{h}_S^{\mathrm{MMPareto}}$，其中 $\gamma > 1$ 是重新缩放因子。

算法 1：MMPareto。 输入：训练数据集 $\mathcal{D}$ 、迭代次数 T 、初始化的单模态编码器参数 θ^k（$k \in \{1, 2, \ldots, n\}$）及其他参数 θ^{other} 。

1. 对 $t = 0, \ldots, T-1$ ：从 $\mathcal{D}$ 中采样新的小批量 S ；将批数据 S 输入模型进行前向传播；通过反向传播计算梯度；不使用梯度融合方法更新 θ^{other} 。
2. 对每个 $k = 1, \ldots, n$ ：获取第 k 个单模态编码器的 $\mathbf{g}_S^m$ 和 $\mathbf{g}_S^u$ ；计算 $\cos\beta$ ，其中 β 是两梯度夹角；求解式 (5)，得到 α^m, α^u 。
3. 若 $\| \alpha^m \mathbf{g}_S^m + \alpha^u \mathbf{g}_S^u \| = 0$ ，则找到帕累托驻点；结束该条件判断。
4. 若 $\cos\beta \geq 0$ ，则令 $2\alpha^m = 2\alpha^u = 1$ ；结束该条件判断。
5. 融合梯度： $\mathbf{h}'_S = 2\alpha^m \mathbf{g}_S^m + 2\alpha^u \mathbf{g}_S^u$ ；令 $\mathbf{h}_S^{\text{MMPareto}} = \left(\mathbf{h}'_S / \| \mathbf{h}'_S \|\right) \cdot \gamma \| \mathbf{g}_S^m + \mathbf{g}_S^u \|$ 。第一因子保持无冲突方向，第二因子增强幅值。
6. 用 $\mathbf{h}_S^{\text{MMPareto}}$ 更新 θ^k ；结束模态循环；结束训练迭代循环。

总之，MMPareto 同时提供无冲突方向和增强的 SGD 噪声强度，帮助模型收敛到更平坦的极小值，并获得更好的泛化。此外，我们分析该方法的收敛性。如备注 2 所述，算法保证收敛到帕累托驻点。详细证明和相关实验见附录 E、F。

备注 2。 所提出的 MMPareto 方法存在一个收敛到帕累托驻点的迭代序列。

> 译注（保留原文论证而不作静默修正）：原文把“分别计算梯度”作为独立性依据，并在推导中将依赖梯度的权重及缩放量按固定量处理；这些并非一般情况下自动成立的性质。算法在零范数分支仅写“找到帕累托驻点”，未明确停止后续归一化步骤；这里保留这一原始算法逻辑。附录 E 的其他证明假设问题也在相应位置说明。

4. 实验

4.1. 数据集与实验设置

CREMA-D（Cao 等，2014）是用于情感识别的视听数据集，涵盖 6 种常见情绪。Kinetics Sounds（Arandjelovic & Zisserman，2017）是包含 31 类人类动作的视听数据集。Colored-and-gray-MNIST（Kim 等，2019）是基于 MNIST（LeCun 等，1998）的合成数据集，每个实例包含灰度图像和单色彩色图像两种图像。ModelNet40（Wu 等，2015）是涵盖 40 类三维物体的数据集，可以根据多个二维视图对三维物体分类（Su 等，2015）。

除非另有说明，实验采用 ResNet-18（He 等，2016）为骨干网络，从头训练模型。单模态特征通过后期融合方式整合。具体而言，对 Colored-and-gray MNIST，我们与 Fan 等（2023）一样，构建含 4 个卷积层和 1 个平均池化层的神经网络作为编码器。训练时使用动量为 0.9 的 SGD，实验中设 $\gamma = 1.5$ 。更多细节见附录 B。

4.2. 多模态场景中的梯度冲突与幅值分布

我们在不同数据集上验证多模态与单模态梯度之间的方向冲突与幅值分布。首先，图 1a 与图 4a 展示了 Kinetics Sounds 和 CREMA-D 上的梯度余弦相似度。结果表明，两种梯度的更新方向确实存在冲突，即负余弦相似度，可能给相应共享单模态编码器的优化带来风险。这类冲突往往出现在训练早期，

而该阶段受到干扰可能显著损害模型能力（Liu 等，2020）。此外，如图 1d 和图 4b，我们在不同数据集上观察固定参数下的梯度幅值分布，每个计数对应不同小批量。结果表明，多模态梯度相较于单模态梯度具有更小的幅值和更小的批采样协方差。协方差差异甚至可能超过 3 倍，从而显著影响模型泛化。

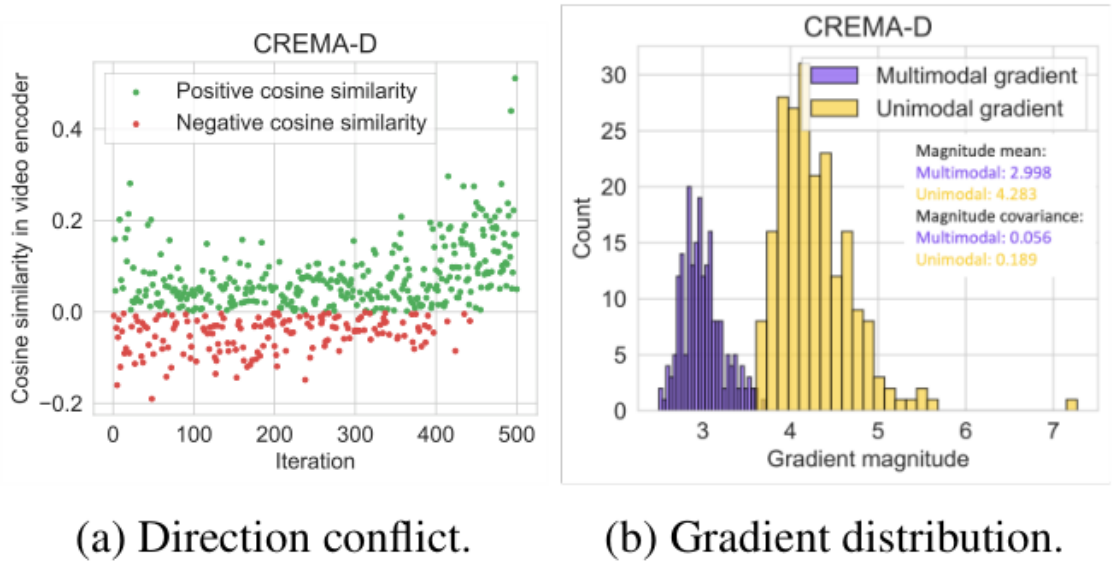
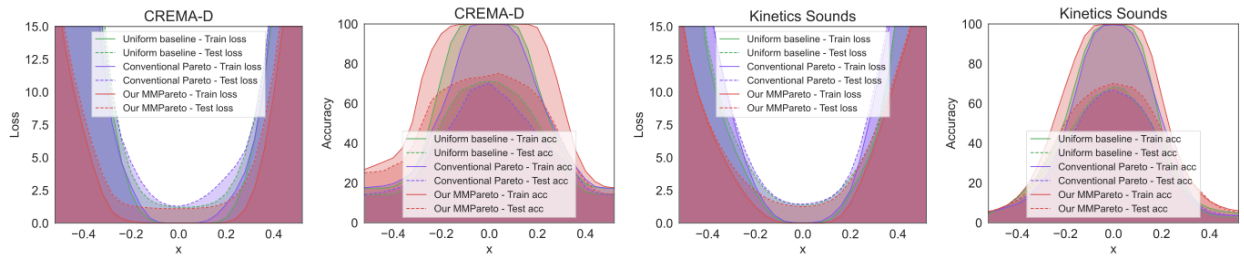


图 4。 (a) CREMA-D 视频编码器中，多模态与单模态损失梯度的余弦相似度（方向冲突）。(b) CREMA-D 视频编码器中的梯度幅值分布。Positive/Negative cosine similarity＝正/负余弦相似度；Iteration＝迭代次数；Gradient distribution＝梯度分布；纵轴 Cosine similarity in video encoder＝视频编码器中的余弦相似度；Count＝计数；Gradient magnitude＝梯度幅值；Multimodal/Unimodal gradient＝多模态/单模态梯度；Magnitude mean＝幅值均值（多模态 2.998，单模态 4.283）；Magnitude covariance＝幅值协方差（多模态 0.056，单模态 0.189）。

4.3. 损失景观分析

根据我们的分析，传统帕累托方法可能导致更尖锐的极小值，进而削弱模型泛化。为从经验上验证这一点，我们对均匀基线、传统帕累托和 MMPareto 的损失景观及相应准确率进行可视化。如图 5，与多模态和单模态损失等权求和的均匀基线相比，传统帕累托确实具有更尖锐的极小值，其损失与准确率变化更剧烈。而 MMPareto 所收敛到的极小值附近，其损失景观最平坦，因为它在优化中同时保证梯度方向无冲突和更强的 SGD 噪声强度。

此外，图 5 中视觉上更平坦的极小值始终对应更低的测试误差。例如，极小值更平坦的 MMPareto 具有更低测试误差和更高准确率。这一现象验证了更平坦的极小值通常泛化更好，支持前述分析。



(a) (b) (c) (d)

图 5。 均匀基线、传统帕累托及 MMPareto 的损失景观与相应准确率可视化。MMPareto 带来更平坦的极小值。可视化方法来自 Li 等（2018）。均匀基线是所有损失直接等权相加的基本方式。图 (a)、(b) 为 CREMA-D；图 (c)、(d) 为 Kinetics Sounds。Loss＝损失，Accuracy＝准确率；Train/Test loss＝训练/测试损失，Train/Test acc＝训练/测试准确率；Conventional Pareto＝传统帕累托，Our MMPareto＝本文 MMPareto。

4.4. 与相关不平衡学习方法比较

为验证 MMPareto 克服多模态学习不平衡问题的有效性，我们与近期方法比较：G-Blending（Wang 等，2020）、OGM-GE（Peng 等，2022）、Greedy（Wu 等，2022）、PMR（Fan 等，2023）和 AGM（Li 等，2023）。

我们还比较若干基本设置。Audio-only 和 Video-only 分别是独立训练的音频及视频单模态模型。Unimodal pre-trained & fine-tune 表示使用分别预训练的单模态编码器来微调多模态模型。One joint loss 只使用多模态联合损失；Uniform baseline 将多模态与单模态损失等权相加。为全面评估模型能力，除常用多模态性能外，还考察单模态性能。

Method	CREMA-D			Kinetics Sounds		
	Acc	Acc audio	Acc video	Acc	Acc audio	Acc video
Audio-only	-	61.69	-	-	<u>53.63</u>	-
Video-only	-	-	<u>56.05</u>	-	-	49.20
Unimodal pre-trained & fine-tune	71.51	60.08	**60.22**	68.75	53.49	<u>50.07</u>
One joint loss*	66.13	59.27	36.56	64.61	52.03	35.47
Uniform baseline	71.10	<u>63.44</u>	51.34	68.31	53.20	40.55
G-Blending (Wang et al., 2020)	<u>72.01</u>	60.62 (↓)	52.23	<u>68.90</u>	52.11 (↓)	41.35
OGM (Peng et al., 2022)*	69.19 (↓)	56.99 (↓)	40.05 (↓)	66.79 (↓)	51.09 (↓)	37.86 (↓)
Greedy (Wu et al., 2022)*	67.61 (↓)	60.69 (↓)	38.17 (↓)	65.32 (↓)	50.58 (↓)	35.97 (↓)
PMR (Fan et al., 2023)*	66.32 (↓)	59.95 (↓)	32.53 (↓)	65.70 (↓)	52.47 (↓)	34.52 (↓)
AGM (Li et al., 2023)*	70.06 (↓)	60.38 (↓)	37.54 (↓)	66.17 (↓)	51.31 (↓)	34.83 (↓)
MMPareto	**75.13**	**65.46**	55.24	**70.13**	**56.40**	**53.05**

表 1。 与多模态学习不平衡方法比较；粗体和下划线分别表示最佳与次佳。星号 * 表示：由于该方法不能直接给出单模态预测，单模态评估（Acc audio、Acc video）通过冻结训练好的单模态编码器并微调一个单模态分类器获得；这一评估方式借鉴 Peng 等（2022）。↓ 表示相比所有损失等权求和的均匀基线性能下降。表头 Method＝方法；Acc＝准确率；Acc audio/video＝音频/视频准确率。Audio-only＝仅音频；Video-only＝仅视频；Unimodal pre-trained & fine-tune＝单模态预训练后微调；One joint loss＝单一联合损失；Uniform baseline＝均匀基线。算法专名保持原文。

由表 1 可见，均匀基线能取得相当可观的性能，甚至优于或接近这些针对多模态学习不平衡的方法。可能原因是单模态损失的引入有效增强各模态学习，与比较方法的核心思路一致。进一步地，与现有方法相比，采用无冲突优化过程的 MMPareto 在多模态预测上获得显著提升。不仅如此，它还同时表现出出色的单模态性能，甚至优于独立训练的单模态模型。例如，在 CREMA-D 和 Kinetics Sounds 上，MMPareto 的音频准确率均优于 Audio-only。这在以往研究中很少实现。

此外，我们还在广泛使用的 Transformer 骨干 MBT（Nagrani 等，2021）上开展实验；该网络既包含单模态层，也包含跨模态交互层。与前述后期融合的 CNN 骨干相比，该 Transformer 框架中的单模态特征交互、融合更充分。实验分别采用从头训练及 ImageNet 预训练，结果见表 2。可观察到：首先，已有多模态学习不平衡方法在这些具有跨模态交互的更复杂场景下可能失效。例如，OGM-GE 在 CREMA-D 上甚至不如单一联合损失方法。相比之下，MMPareto 梯度融合策略不仅适用于 CNN 骨干，还能在具有复杂交互的 Transformer 框架中保持优越性能。此外，是否使用预训练不影响方法的有效性，体现其灵活性。

Method	CREMA-D				Kinetics Sounds			
	from scratch		with pretrain		from scratch		with pretrain	
	Acc	macro F1	Acc	macro F1	Acc	macro F1	Acc	macro F1
One joint loss	44.96	42.78	66.69	67.26	42.51	41.56	68.30	69.31
Uniform baseline	45.30	43.74	69.89	70.11	43.31	43.08	69.40	69.60
G-Blending (Wang et al., 2020)	46.38	45.16	69.91	70.01	44.69	44.19	69.41	69.47
OGM-GE (Peng et al., 2022)	42.88	39.34	65.73	65.88	41.79	41.09	69.55	69.53
Greedy (Wu et al., 2022)	44.49	42.76	66.67	67.26	43.31	43.08	69.62	69.75
PMR (Fan et al., 2023)	44.76	42.95	65.59	66.07	43.75	43.21	69.67	69.87
AGM (Li et al., 2023)	45.36	43.81	66.54	67.75	43.65	43.57	69.59	69.14
MMPareto	**48.66**	**48.17**	**70.43**	**71.17**	**45.20**	**45.26**	**70.28**	**70.11**

表 2。 与多模态学习不平衡方法比较；粗体和下划线分别表示最佳与次佳。网络为基于 Transformer 的 MBT 框架（Nagrani 等，2021）。from scratch＝从头训练；with pretrain＝使用预训练；Acc＝准确率；macro F1＝宏平均 F1。方法名称释义同表 1。

4.5. 与相关多任务方法比较

以往研究还使用其他策略来平衡多个学习目标。本节除传统帕累托（Sener & Koltun，2018）外，还比较若干代表方法：GradNorm（Chen 等，2018）、PCGrad（Yu 等，2020）和 MetaBalance（He 等，2022）。实验在覆盖六种模态类型的不同多模态数据集上进行。表 3 再次验证，传统帕累托不如均匀基线，在多模态场景中失效。此外，既有多任务方法也可能在多模态学习中无效。例如，GradNorm 在 ModelNet40 和 Kinetics Sounds 上都不如均匀基线。相比之下，专门考虑多模态学习性质的 MMPareto，在不同模态类型的各数据集上均保持优越性能。

Method	CG-MNIST		ModelNet40		Kinetics Sounds	
	Acc	macro F1	Acc	macro F1	Acc	macro F1
One joint loss	60.50	59.89	87.88	83.32	64.61	64.12
Uniform baseline	75.68	75.66	89.18	84.69	68.31	68.13
Conventional Pareto (Sener & Koltun, 2018)	62.00	61.85	88.05	83.01	66.64	66.17
GradNorm (Chen et al., 2018)	76.16	76.12	88.98	83.79	65.84	65.14
PCGrad (Yu et al., 2020)	79.35	77.14	89.59	84.44	69.11	68.75
MetaBalance (He et al., 2022)	79.18	77.87	89.63	84.87	68.90	68.62
MMPareto	**81.88**	**81.69**	**89.95**	**85.15**	**70.13**	**70.18**

表 3。 在 Colored-and-gray-MNIST、ModelNet40 和 Kinetics Sounds 上，与相关多任务方法比较。粗体与下划线分别表示最佳与次佳。CG-MNIST 为 Colored-and-gray-MNIST 简称。Conventional Pareto＝传统帕累托；Acc＝准确率；macro F1＝宏平均 F1；其余方法名称释义同表 1。

4.6. 扩展到多任务场景

为评估方法对具有类似性质（任务难度明显不同）的多任务场景的可扩展性，我们在 MultiMNIST（Sabour 等，2017）上开展实验。在 MultiMNIST 中，从原 MNIST 中选择两个不同数字的图像，将一个放左侧、另一个放右侧，合成为新图像；两项任务分别对两个数字分类。为增大任务难度差异，我们在图像右半部分添加 50% 的椒盐噪声；附录 C 给出若干样本。表 5 显示，多数多任务方法出现性能下降，例如 GradNorm、PCGrad 和传统帕累托。不出所料，MMPareto 可以扩展到该场景并获得可观性能，表明其理想的可扩展性。

除 MultiMNIST 外，我们也在典型多任务数据集 NYUv2 上实验，使用广泛采用的基准（Liu 等，2019），考虑语义分割和深度估计两项任务。如表 4，尽管方法基于多模态性质构建，与均匀基线相比，它在典型多任务数据集上也获得改进，甚至在深度估计任务取得最佳结果。这些结果表明方法的通用性。

Method	Segmentation - mIoU (Higher Better)	Segmentation - Pix Acc (Higher Better)	Depth - Abs Err (Lower Better)	Depth - Rel Err (Lower Better)
Uniform baseline	25.80	52.68	0.6309	0.2680
Conv Pareto (Sener & Koltun, 2018)	**27.66**	53.91	0.6284	0.2685
GradNorm (Chen et al., 2018)	26.17	53.41	0.6219	0.2738
PCGrad (Yu et al., 2020)	26.44	53.93	0.6337	0.2658
MetaBalance (He et al., 2022)	27.04	**53.99**	0.6258	0.2677
MMPareto	26.35	53.48	**0.6216**	**0.2656**

表 4。 NYUv2 上多任务方法比较。Conv Pareto＝传统帕累托。Segmentation - mIoU＝分割的平均交并比；Segmentation - Pix Acc＝分割的像素准确率；这两项越高越好。Depth - Abs Err＝深度绝对误差；Depth - Rel Err＝深度相对误差；这两项越低越好。

Method	Accuracy	
	Task 1	Task2
Uniform baseline	86.63	78.42
Conv Pareto (Sener & Koltun, 2018)	86.95	77.04 (↓)
GradNorm (Chen et al., 2018)	85.95(↓)	79.52
PCGrad (Yu et al., 2020)	84.74(↓)	76.44(↓)
MetaBalance (He et al., 2022)	87.07	79.53
MMPareto	**87.72**	**80.64**

表 5。 在图像右半部分添加 50% 椒盐噪声的 MultiMNIST 上的结果。均匀基线是所有损失等权相加的基本方式。Conv Pareto＝传统帕累托；Accuracy＝准确率；Task 1/Task 2＝任务 1/任务 2；↓ 表示相对均匀基线下降。

5. 讨论

本文在单模态与多模态目标学习难度存在差异的多模态场景中，识别出此前被忽视的梯度冲突，并提出 MMPareto 算法，以减轻冲突、缓解多模态学习不平衡。除了典型的判别式多模态场景，近期更多多模态场景（如多模态预训练）也迅速发展（Wang 等，2023；Zhang 等，2023；Chen 等，2023）。我们的方法也有望应用于 BLIP-2 等更一般的多模态场景，缓解多个学习目标间的潜在冲突。

未来工作与局限。 本文通过调整梯度幅值来增强 SGD 噪声项，改善模型泛化。实际上，多个损失的梯度协方差 $\frac{1}{|S|}C$ 及其相关性，也有望在梯度融合中为保证模型泛化提供可靠参考。因此，如何高效估计并利用这些协方差，是值得探索的后续方向。此外，当前收敛性分析使用相对理想的假设；但实践中，该方法在可接受范围内仅需适量迭代便可显著改善多模态学习。这也启发我们探索具有更严格收敛理论的多模态帕累托方法。

致谢

本研究得到国家自然科学基金（编号 62106272）与中国人民大学公共计算云支持。

影响声明

我们的方法也能在多方面为社会作出贡献，例如通过增强多传感器学习来帮助自动驾驶汽车。

参考文献

以下保留作者、期刊会议名称、页码及标识符以便准确检索；论文题名给出中文译名。

Arandjelovic, R. and Zisserman, A. 看、听与学习（Look, listen and learn）. In Proceedings of the IEEE International Conference on Computer Vision, pp. 609–617, 2017.

Baltrušaitis, T., Ahuja, C., and Morency, L.-P. 多模态机器学习：综述与分类体系（Multimodal machine learning: A survey and taxonomy）. IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(2):423–443, 2018.

Cao, H., Cooper, D. G., Keutmann, M. K., Gur, R. C., Nenkova, A., and Verma, R. CREMA-D：众包情感多模态演员数据集（Crema-d: Crowd-sourced emotional multimodal actors dataset）. IEEE Transactions on Affective Computing, 5(4):377–390, 2014.

Chen, F.-L., Zhang, D.-Z., Han, M.-L., Chen, X.-Y., Shi, J., Xu, S., and Xu, B. VLP：视觉语言预训练综述（Vlp: A survey on vision-language pre-training）. Machine Intelligence Research, 20(1):38–56, 2023.

Chen, H., Xie, W., Vedaldi, A., and Zisserman, A. VGGSound：大规模视听数据集（Vggsound: A large-scale audio-visual dataset）. In ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pp. 721–725. IEEE, 2020.

Chen, Z., Badrinarayanan, V., Lee, C.-Y., and Rabinovich, A. GradNorm：用于深度多任务网络自适应损失平衡的梯度归一化（Gradnorm: Gradient normalization for adaptive loss balancing in deep multitask networks）. In International Conference on Machine Learning, pp. 794–803. PMLR, 2018.

Cordts, M., Omran, M., Ramos, S., Rehfeld, T., Enzweiler, M., Benenson, R., Franke, U., Roth, S., and Schiele, B. 用于城市场景语义理解的 Cityscapes 数据集（The cityscapes dataset for semantic urban scene understanding）. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 3213–3223, 2016.

Désidéri, J.-A. 用于多目标优化的多梯度下降算法（MGDA）（Multiple-gradient descent algorithm (mgda) for multiobjective optimization）. Comptes Rendus Mathematique, 350(5–6):313–318, 2012.

Du, C., Teng, J., Li, T., Liu, Y., Yuan, T., Wang, Y., Yuan, Y., and Zhao, H. 论监督多模态学习中的单模态特征学习（On uni-modal feature learning in supervised multi-modal learning）. In International Conference on Machine Learning, pp. 8632–8656. PMLR, 2023.

Fan, C., Chen, W., Tian, J., Li, Y., He, H., and Jin, Y. MaxGNR：通过最大化梯度噪声比实现多任务学习的动态权重策略（Maxgnr: A dynamic weight strategy via maximizing gradient-to-noise ratio for multi-task learning）. In Proceedings of the Asian Conference on Computer Vision, pp. 1178–1193, 2022.

Fan, Y., Xu, W., Wang, H., Wang, J., and Guo, S. PMR：用于多模态学习的原型模态再平衡（Pmr: Prototypical modal rebalance for multimodal learning）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 20029–20038, 2023.

He, K., Zhang, X., Ren, S., and Sun, J. 用于图像识别的深度残差学习（Deep residual learning for image recognition）. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770–778, 2016.

He, Y., Feng, X., Cheng, C., Ji, G., Guo, Y., and Caverlee, J. MetaBalance：通过调整辅助任务梯度幅值改善多任务推荐（Metabalance: improving multi-task recommendations via adapting gradient magnitudes of auxiliary tasks）. In Proceedings of the ACM Web Conference 2022, pp. 2205–2215, 2022.

Hochreiter, S. and Schmidhuber, J. 平坦极小值（Flat minima）. Neural Computation, 9(1):1–42, 1997.

Huang, Y., Lin, J., Zhou, C., Yang, H., and Huang, L. 模态竞争：什么导致深度学习中多模态网络联合训练失败?（可证明的）（Modality competition: What makes joint training of multi-modal network fail in deep learning?(provably)）. In International Conference on Machine Learning, pp. 9226–9259. PMLR, 2022.

Jastrzebski, S., Kenton, Z., Arpit, D., Ballas, N., Fischer, A., Bengio, Y., and Storkey, A. 影响 SGD 极小值的三个因素（Three factors influencing minima in sgd）. arXiv preprint arXiv:1711.04623, 2017.

Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., Viola, F., Green, T., Back, T., Natsev, P., et al. Kinetics 人类动作视频数据集（The kinetics human action video dataset）. arXiv preprint arXiv:1705.06950, 2017.

Keskar, N. S., Mudigere, D., Nocedal, J., Smelyanskiy, M., and Tang, P. T. P. 论深度学习的大批量训练：泛化差距与尖锐极小值（On large-batch training for deep learning: Generalization gap and sharp minima）. arXiv preprint arXiv:1609.04836, 2016.

Kim, B., Kim, H., Kim, K., Kim, S., and Kim, J. 学会不学：使用有偏数据训练深度神经网络（Learning not to learn: Training deep neural networks with biased data）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 9012–9020, 2019.

LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. 应用于文档识别的基于梯度的学习（Gradient-based learning applied to document recognition）. Proceedings of the IEEE, 86(11):2278–2324, 1998.

Li, H., Xu, Z., Taylor, G., Studer, C., and Goldstein, T. 神经网络损失景观的可视化（Visualizing the loss landscape of neural nets）. Advances in Neural Information Processing Systems, 31, 2018.

Li, H., Li, X., Hu, P., Lei, Y., Li, C., and Zhou, Y. 通过自适应梯度调制提升多模态模型性能（Boosting multi-modal model performance with adaptive gradient modulation）. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 22214–22224, 2023.

Lin, X., Zhen, H.-L., Li, Z., Zhang, Q.-F., and Kwong, S. 帕累托多任务学习（Pareto multi-task learning）. Advances in Neural Information Processing Systems, 32, 2019.

Lin, Y.-M., Gao, Y., Gong, M.-G., Zhang, S.-J., Zhang, Y.-Q., and Li, Z.-Y. 多模态数据上的联邦学习：综合综述（Federated learning on multimodal data: A comprehensive survey）. Machine Intelligence Research, 20(4):539–553, 2023.

Liu, S., Johns, E., and Davison, A. J. 带注意力机制的端到端多任务学习（End-to-end multi-task learning with attention）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 1871–1880, 2019.

Liu, S., Niles-Weed, J., Razavian, N., and Fernandez-Granda, C. 早期学习正则化防止对噪声标签的记忆（Early-learning regularization prevents memorization of noisy labels）. Advances in Neural Information Processing Systems, 33:20331–20342, 2020.

Ma, P., Du, T., and Matusik, W. 多任务学习中的高效连续帕累托探索（Efficient continuous pareto exploration in multi-task learning）. In International Conference on Machine Learning, pp. 6522–6531. PMLR, 2020.

Nagrani, A., Yang, S., Arnab, A., Jansen, A., Schmid, C., and Sun, C. 多模态融合的注意力瓶颈（Attention bottlenecks for multimodal fusion）. Advances in Neural Information Processing Systems, 34:14200–14213, 2021.

Neyshabur, B., Bhojanapalli, S., McAllester, D., and Srebro, N. 探索深度学习中的泛化（Exploring generalization in deep learning）. Advances in Neural Information Processing Systems, 30, 2017.

Peng, X., Wei, Y., Deng, A., Wang, D., and Hu, D. 通过即时梯度调制实现平衡多模态学习（Balanced multimodal learning via on-the-fly gradient modulation）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 8238–8247, 2022.

Sabour, S., Frosst, N., and Hinton, G. E. 胶囊之间的动态路由（Dynamic routing between capsules）. Advances in Neural Information Processing Systems, 30, 2017.

Sener, O. and Koltun, V. 将多任务学习视为多目标优化（Multi-task learning as multi-objective optimization）. Advances in Neural Information Processing Systems, 31, 2018.

Su, H., Maji, S., Kalogerakis, E., and Learned-Miller, E. 用于三维形状识别的多视图卷积神经网络（Multi-view convolutional neural networks for 3d shape recognition）. In Proceedings of the IEEE International Conference on Computer Vision, pp. 945–953, 2015.

Trick, S., Koert, D., Peters, J., and Rothkopf, C. A. 人机交互中用于意图识别的多模态不确定性降低（Multimodal uncertainty reduction for intention recognition in human-robot interaction）. In 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp. 7009–7016. IEEE, 2019.

Wang, W., Tran, D., and Feiszli, M. 是什么让多模态分类网络的训练变得困难？（What makes training multi-modal classification networks hard?）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 12695–12705, 2020.

Wang, X., Chen, G., Qian, G., Gao, P., Wei, X.-Y., Wang, Y., Tian, Y., and Gao, W. 大规模多模态预训练模型：综合综述（Large-scale multi-modal pre-trained models: A comprehensive survey）. Machine Intelligence Research, 20(4):447–482, 2023.

Wei, Y., Hu, D., Tian, Y., and Li, X. 视听情境中的学习：回顾、分析与新视角（Learning in audio-visual context: A review, analysis, and new perspective）. arXiv preprint arXiv:2208.09579, 2022.

Wei, Y., Feng, R., Wang, Z., and Hu, D. 通过样本级模态价值评估增强多模态协作（Enhancing multimodal cooperation via sample-level modality valuation）. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024.

Wu, N., Jastrzebski, S., Cho, K., and Geras, K. J. 刻画并克服多模态深度神经网络学习的贪婪性质（Characterizing and overcoming the greedy nature of learning in multi-modal deep neural networks）. In International Conference on Machine Learning, pp. 24043–24055. PMLR, 2022.

Wu, Z., Song, S., Khosla, A., Yu, F., Zhang, L., Tang, X., and Xiao, J. 3D ShapeNets：体积形状的深度表示（3d shapenets: A deep representation for volumetric shapes）. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 1912–1920, 2015.

Xu, R., Feng, R., Zhang, S.-X., and Hu, D. MMCosine：面向平衡视听细粒度学习的多模态余弦损失（Mmcosine: Multi-modal cosine loss towards balanced audio-visual fine-grained learning）. In ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pp. 1–5. IEEE, 2023.

Yang, Z., Wei, Y., Liang, C., and Hu, D. 利用模态偏好量化并增强多模态鲁棒性（Quantifying and enhancing multi-modal robustness with modality preference）. arXiv preprint arXiv:2402.06244, 2024.

Yu, T., Kumar, S., Gupta, A., Levine, S., Hausman, K., and Finn, C. 多任务学习的梯度手术（Gradient surgery for multi-task learning）. Advances in Neural Information Processing Systems, 33:5824–5836, 2020.

Zadeh, A., Zellers, R., Pincus, E., and Morency, L.-P. MOSI：用于网络观点视频中情感强度与主观性分析的多模态语料库（Mosi: multimodal corpus of sentiment intensity and subjectivity analysis in online opinion videos）. arXiv preprint arXiv:1606.06259, 2016.

Zhang, L., Ruan, L., Hu, A., and Jin, Q. 从单语言到多语言的多模态预训练（Multimodal pre-training from monolingual to multilingual）. Machine Intelligence Research, 20(2):220–232, 2023.

Zhang, Q., Wei, Y., Han, Z., Fu, H., Peng, X., Deng, C., Hu, Q., Xu, C., Wen, J., Hu, D., et al. 低质量数据上的多模态融合：综合综述（Multimodal fusion on low-quality data: A comprehensive survey）. arXiv preprint arXiv:2404.18947, 2024.

Zhu, Z., Wu, J., Yu, B., Wu, L., and Ma, J. 随机梯度下降中的各向异性噪声：逃离尖锐极小值的行为及正则化效果（The anisotropic noise in stochastic gradient descent: Its behavior of escaping from sharp minima and regularization effects）. arXiv preprint arXiv:1803.00195, 2018.

附录 A. 参数说明

为方便读者，表 6 汇总所使用的参数说明。

表 6。所使用参数的说明。

参数	说明
n	模态总数
$\mathcal{L}_m$	多模态联合损失
$\mathcal{L}_u^k$	第 k 个模态的单模态损失
N	训练样本数
X_i	第 i 个数据样本的输入
Y_i	第 i 个数据样本的标签
$(X_i,\ Y_i)$	第 i 个数据样本
$\theta^k(t)$	第 t 次迭代时第 k 个模态单模态编码器的参数
S	第 t 个小批量的集合
$\frac{1}{\|S\|}C^m$	多模态联合损失的批采样协方差
$\frac{1}{\|S\|}C^u$	单模态损失的批采样协方差
$\mathbf{g}_S^m$ / $\mathbf{g}_S^m\left(\theta^k(t)\right)$	第 k 个模态编码器在第 t 次迭代的多模态梯度
$\mathbf{g}_S^u$ / $\mathbf{g}_S^u\left(\theta^k(t)\right)$	第 k 个模态编码器在第 t 次迭代的单模态梯度
α^m	帕累托优化问题中多模态梯度 $\mathbf{g}_S^m$ 的权重
α^u	帕累托优化问题中单模态梯度 $\mathbf{g}_S^u$ 的权重
β	$\mathbf{g}_S^m$ 与 $\mathbf{g}_S^u$ 的夹角
η	SGD 优化的学习率
γ	MMPareto 融合梯度的重新缩放因子
$\mathbf{h}_S\left(\theta^k(t)\right)$	均匀基线在第 t 次迭代的最终融合梯度
ϵ_t	均匀基线在第 t 次迭代的 SGD 噪声项
$\mathbf{h}_S^{\text{Pareto}}\left(\theta^k(t)\right)$	传统帕累托方法在第 t 次迭代的最终融合梯度
ζ_t	传统帕累托方法在第 t 次迭代的 SGD 噪声项

参数	说明
$\mathbf{h}_S^{\mathrm{MMPareto}}\left(\theta^k(t)\right)$	所提 MMPareto 方法在第 t 次迭代的最终融合梯度
ξ_t	所提 MMPareto 方法在第 t 次迭代的 SGD 噪声项

译注：表 6 原文使用 $\|S\|$，正文使用 $|S|$ 表示批大小；此处按原表保留，不作无标注更改。

附录 B. 数据集与实验设置

CREMA-D（Cao 等，2014）是用于情感识别的视听数据集，包含 7,442 个视频片段，每段时长 2 至 3 秒。视频内容为演员说出若干简短词语。该数据集涵盖 6 种情绪：愤怒、高兴、悲伤、中性、丢弃（discarding）、厌恶和恐惧。

译注：上句原文称“6 种”却列出七个词，并包含不寻常的 “discarding”；本译文忠实保留这一原文错误，不自行删改。

Kinetics Sounds（Arandjelovic & Zisserman，2017）是一个视听数据集，包含从 Kinetics（Kay 等，2017）选出的 31 类人类动作。所有视频均通过 Mechanical Turk 人工标注动作，并围绕动作裁剪为 10 秒。

Colored-and-gray-MNIST（Kim 等，2019）是基于 MNIST（LeCun 等，1998）的合成数据集。每个实例包含灰度图像和单色彩色图像两种图像。训练集中的单色图像，其颜色与数字标签高度相关；其他集合中的单色图像，其颜色与标签仅弱相关。

ModelNet40（Wu 等，2015）是包含三维物体的数据集，涵盖 40 类，包含 9,483 个训练样本及 2,468 个测试样本。可以根据物体前视与后视数据的二维视图对三维物体分类（Su 等，2015）。所有视图的数据是三维物体的二维图像集合。

除非另有说明，实验采用 ResNet-18（He 等，2016）骨干，模型从头训练。具体而言，视觉编码器以多帧为输入，并送入二维网络；音频编码器如 Chen 等（2020）一样，将 ResNet-18 的输入通道从三改为一，其余部分不变；其他模态编码器不作修改。CNN 骨干采用广泛使用的后期融合来整合单模态特征。Transformer 骨干采用 MBT（Nagrani 等，2021），具体包含 6 个单模态层以及 2 个跨模态交互层。对于 Colored-and-gray MNIST，仿照 Fan 等（2023）构建含 4 个卷积层和 1 个平均池化层的神经网络作为编码器。训练使用动量为 0.9 的 SGD，学习率设置为 10^{-3}。所有模型均在两张 NVIDIA RTX 3090 (Ti) 上训练。

附录 C. MultiMNIST 数据集样本

这里提供 MultiMNIST 的若干样本。在 MultiMNIST 中，从原始 MNIST 数据集挑选两个不同数字的图像，一个置于左侧，另一个置于右侧，合成为新的图像。两项任务分别对这两个数字分类。为增大任务难度差异，我们在图像右半部分加入 50% 椒盐噪声。



(a) Sample 1 without noise; Label: [5,1].



(b) Sample 1 with noise; Label: [5,1].



(c) Sample 2 without noise; Label: [0,3].



(d) Sample 2 with noise; Label: [0,3].

图 6。 MultiMNIST 数据集样本。(a) 样本 1，无噪声，标签 [5,1]；(b) 样本 1，有噪声，标签 [5,1]；(c) 样本 2，无噪声，标签 [0,3]；(d) 样本 2，有噪声，标签 [0,3]。

附录 D. 超过两个模态的情况

MMPareto 不限制模态数量。为验证超过两个模态时的性能，我们在 CMU-MOSI（Zadeh 等，2016）上实验。CMU-MOSI 是包含音频、视频、文本三种模态的情感分析数据集，提供话语级情感标签。该数据集由 93 个影评视频组成，被划分为 2,199 条话语。由表 7 可见，许多现有多模态学习不平衡方法只考虑两个模态，甚至无法扩展到更多模态。MMPareto 不受模态数限制，并能保持有效性。

Method	Acc	macro F1
One joint loss	75.07	73.16
Uniform baseline	75.95	73.93
G-Blending (Wang et al., 2020)	76.16	74.65
OGM* (Peng et al., 2022)	75.80	74.71
Greedy (Wu et al., 2022)	/	/
PMR* (Fan et al., 2023)	76.28	75.06
AGM (Li et al., 2023)	76.08	74.98
MMPareto	**76.53**	**75.59**

表 7。 三模态 CMU-MOSI 数据集上多模态学习不平衡方法的比较。Greedy 不能扩展到超过两个模态的情况。* 表示原始 OGM 与 PMR 同样只考虑两个模态，我们在保留核心策略的前提下将其扩展。Method＝方法；Acc＝准确率；macro F1＝宏平均 F1；“/”表示未提供结果；其余方法名称释义同表 1。

附录 E. MMPareto 收敛性证明

备注 2。 所提出的 MMPareto 方法存在一个收敛到帕累托驻点的迭代序列。

证明。 MMPareto 算法在每个训练迭代中首先求解优化问题：

$$\min_{\alpha^m,\alpha^u\in\mathbb{R}} \parallel \alpha^m\mathbf{g}_S^m + \alpha^u\mathbf{g}_S^u \parallel^2, \quad \text{s.t. } \alpha^m,\ \alpha^u \geq 0,\ \ \alpha^m + \alpha^u = 1. \tag{17}$$

为简洁起见，这里用 $\{\mathbf{g}_S^i\}_{i\in\{m,u\}}$ 代替 $\{\mathbf{g}_S^i\left(\theta^k(t)\right)\}_{i\in\{m,u\}}$。$\|\cdot\|$ 表示 L_2 范数。该问题等价于寻找梯度向量族 $\{\mathbf{g}_S^i\}_{i\in\{m,u\}}$ 凸包内的最小范数。将找到的最小范数记为 $\omega = \alpha^m\mathbf{g}_S^m + \alpha^u\mathbf{g}_S^u$。根据 Désidéri（2012），要么该优化问题的 ω 为零，相应参数为帕累托驻点（这是帕累托最优的必要条件）；要么 ω 能提供所有学习目标共同的下降方向。当最小范数 ω 不满足帕累托驻点条件时，分别考虑无冲突和有冲突情形。

首先分析无冲突情况，即 $\cos\beta \geq 0$，其中 β 是 $\mathbf{g}_S^m$ 与 $\mathbf{g}_S^u$ 的夹角。此时设 $2\alpha^m = 2\alpha^u = 1$，最终梯度 $\mathbf{h}_S^{\text{Pareto}} = \mathbf{g}_S^m + \mathbf{g}_S^u$ 的方向有益于全部损失，并具有增强的泛化能力。接着分析有冲突情况，即 $\cos\beta < 0$，将式 (17) 优化问题的结果作为 α^m 和 α^u。由上述论述，$\mathbf{h}_S^{\text{Pareto}} = 2\alpha^m\mathbf{g}_S^m + 2\alpha^u\mathbf{g}_S^u$ 能提供所有学习目标共同的方向。进一步增强最终梯度幅值，以增强 SGD 噪声强度，改善模型泛化。综上，MMPareto 的最终梯度始终能够提供所有学习目标共同的方向。

若训练迭代在有限步内停止，则已达到帕累托驻点。否则，迭代无限继续，生成共享参数 θ^k 的无限序列。由于损失函数 $\mathcal{L}_m$ 和 $\mathcal{L}_u^k$ 的值为正，并在优化过程中单调下降，因此它有界。故参数 θ^k 的序列本身也有界，并存在一个收敛到 θ^{k^*} 的子序列。

θ^{k*} 必然为帕累托驻点。换言之，此时最小范数 ω^* 为零。为证明这一点，反设与 θ^{k*} 对应的最小范数 ω^* 非零，那么一次新的迭代将可能使每个学习目标降低一个有限量，并找到参数 θ^k 的更优解。总体而言，所提出的 MMPareto 方法存在一个收敛到帕累托驻点的迭代序列。

> 译注（原文证明的限制）：原文将向量 ω 称为“最小范数”，此处保留其表述；原文从损失值有界直接推得参数序列有界，但未在这里给出紧致水平集或强制性等足以保证该推论的条件；共同下降方向也不自动保证固定步长随机迭代的每一步损失单调下降。以上为原文论证中的假设缺口，不是译文补充的定理。原文第 5 节亦承认收敛性分析依赖较理想的假设。

附录 F. MMPareto 的计算成本与收敛

本节考察梯度权重计算过程的时间成本以及 MMPareto 的收敛情况。表 8 记录每次迭代时间成本的均值与方差。结果表明，此过程耗时不多，对总体训练时间影响不大。

此外，我们考察找到帕累托驻点所需的迭代次数。根据表 9，方法通常在可接受范围内经过适量迭代即可收敛。

表 8。每次迭代中 MMPareto 计算的时间成本。

数据集	时间成本均值	时间成本方差
CREMA-D	0.11 s	1e-5
Kinetics Sounds	0.16 s	1e-5
CG-MNIST	0.05 s	1e-5
ModelNet40	0.10 s	1e-5

表 9。找到帕累托驻点的迭代次数。

数据集	音频编码器	视频编码器
CREMA-D	#3098	#1709
Kinetics Sounds	#10197	#7957