多重校准：面向（计算上可识别）大众的校准

Úrsula Hébert-Johnson[1]，Michael P. Kim[1]，Omer Reingold[1]，Guy N. Rothblum[2]

[1] 美国加利福尼亚州斯坦福大学计算机科学系；[2] 以色列雷霍沃特魏茨曼科学研究所计算机科学与应用数学系。通讯作者：Michael P. Kim mpk@cs.stanford.edu。

原载：第 35 届国际机器学习大会论文集，瑞典斯德哥尔摩，PMLR 80:1939–1948，2018。© 2018 作者。原文：PMLR 官方出版页。本文件为非官方中文全文翻译，包含官方补充材料；翻译与重新排版属于对原作的改编，采用 CC BY 4.0 许可。作者未审核或认可本译文。

摘要

我们提出并研究多重校准，将其作为机器学习中一种新的公平性度量，旨在减轻训练时引入的无意或恶意歧视（即使训练使用的是真实标注数据）。多重校准保证：对于能够由指定计算类别识别出的每一个子人群，都提供有意义的（经过校准的）预测。指定的类别可以非常丰富；尤其可以包含受保护群体中许多相互重叠的子群体。我们证明，在许多情境下，这种强有力的反歧视保护既可实现，又与准确预测的目标一致。在此过程中，我们提出学习多重校准预测器的算法，研究这一任务的计算复杂性，并揭示其与不可知学习模型之间的紧密联系。

1. 引言

机器学习得到的预测器正在为影响生活各方面的决策提供依据；从新闻推荐、刑事量刑，到医疗诊断，算法越来越多地被用来对个人进行预测。一个潜在风险是，这些预测器可能歧视受法律或伦理保护的群体。事实上，在包括图像分类（Buolamwini & Gebru, 2018）和自然语言任务（Bolukbasi et al., 2016）在内的许多学习任务中，人们已经充分记录了这种无意却有害的歧视。本文旨在减轻预测任务中此类算法歧视的风险。

学习算法的输出可能因多种原因而带有歧视性。第一，训练数据可能包含应予纠正的偏见。第二，对训练数据的分析可能无意中引入数据本身并不支持的偏见。本文关注后一种问题。

确实，即使给定准确的真实标注训练数据，典型的监督学习方法——选择使训练数据上的期望损失最小的模型——也可能选出一个对多数群体表现良好、却忽视少数群体的预测模型。考虑一家金融机构训练模型来预测申请人贷款违约概率的情形。如果平均而言，S 中的个体在经济上比多数群体更处于劣势，模型就可能给所有 $i \in S$ 指派一个固定的低概率，同时通过极其准确地预测多数群体而仍然获得良好的经验损失。这种模型歧视了 S 中资质合格的成员。更糟的是，拒绝批准有能力偿还贷款的成员，可能进一步加剧 S 的代表性不足。

针对这些问题，我们建立一个理论框架，以减轻预测任务中算法歧视的风险。具体而言，我们关注如下情境：学习者可以取得来自个体域 $\mathcal{X}$ 的少量真实标注数据样本 D。每个个体 $i \in D$ 都有一个布尔标签 $o_i \in \{0, 1\}$，表示学习者希望预测的某个随机事件（广告点击、偿还贷款、癌症诊断等）的结果。

我们假设，对每个 $i \in \mathcal{X}$，都存在一个决定结果 o_i 分布的底层概率 p_i^*。预测器 $f : \mathcal{X} \to [0, 1]$ 是将个体 $i \in \mathcal{X}$ 映射为真实参数估计值的映射。接下来讨论预测器应具备的性质，这些性质促成了我们对于公平性的新视角。

校准与多重校准。 如果不希望预测器 f 低估群体 $S \subseteq \mathcal{X}$ 的适合程度，就可以要求它在 S 上（近似）无偏，即对某个很小的 $\alpha \geq 0$，有 $\left|\mathbf{E}_{i \sim S}\left[f_i - p_i^*\right]\right| \leq \alpha$。这意味着 f 和 p^* 在 S 上的期望几乎相同。校准进一步加强了这一要求：对任一特定值 v，令 $S_v = \{i \in S : f_i = v\}$ 为 S 中预测概率为 v 的个体构成的子集，则要求

$$\left|\mathbf{E}_{i \sim S_v}\left[f_i - p_i^*\right]\right| = \left|v - \mathbf{E}_{i \sim S_v}\left[p_i^*\right]\right| \leq \alpha.$$

尽管这一概念已经排除某些歧视形式，但作为公平性概念，校准的主要弱点在于保障过于粗糙。Dwork et al. (2012) 已讨论群体公平性概念的弱点，并以此作为引入个体公平性概念的动机。一种在满足校准时仍然实施歧视的具体方法，是给 S 的每位成员都赋值 $\mathbf{E}_{i \sim S}\left[p_i^*\right]$。这种做法在 S 上完全校准，却会损害 S 中具有较大 p_i^* 值的合格成员。

校准通常应用于规模较大、往往互不相交的受保护群体；也就是说，只要求这些保障在由少数敏感属性（例如种族或性别）定义的人群中平均成立。更强的公平性定义应保证对每一个子人群的预测都得到校准，其中包括上例中 S 的合格成员。问题在于，利用少量带标签样本，在信息论意义上不可能达到这一要求，因为它本质上要求完美预测。因此，需要一种中间层次的定义，在保护重要子群体的愿望与小样本学习所面临的信息瓶颈之间取得平衡。

为了说明我们的概念，假设学习算法产生预测器 f。随后更多结果得到确定，审计者发现某个子人群 S 的结果优于 f 对其所作的预测。学习算法是否偷了懒，未能识别 S 更高的潜力？抑或 S 的个体只是运气好？我们如何分辨？为回答这些问题，我们采取如下观点：一方面，只能期望学习者产生一个在那些能够从现有数据中高效识别出的集合上得到校准的预测器；另一方面，我们要求学习者的预测器在每一个可高效识别的子集上都得到校准。这引出多重校准的定义，其非正式表述为：“如果预测器 f 相对于子人群族 $\mathcal{C}$ 中每个 $S \in \mathcal{C}$ 都得到校准，则称它相对于 $\mathcal{C}$ 是多重校准的。”

简言之，多重校准保证对指定子人群集合 $\mathcal{C}$ 所识别的每一个子人群作出高度准确的预测。我们的结果适用于任何集合系统 $\mathcal{C}$，但通常将 $\mathcal{C}$ 看作能够高效判定集合成员资格的子集族，例如由少量布尔特征的合取或者小型决策树定义的子人群。在这个意义上，$\mathcal{C}$ 可以是由某类有界计算识别的集合。随着 $\mathcal{C}$ 表达能力增强，公平性保障也更强：该计算类别中可以识别出的任何子人群都不会被忽略。

在前述房贷偿还例子中，如果 S 的合格成员能够由某个计算 $c \in \mathcal{C}$ 识别，则所得预测器不能忽略 S 内部的差异。我们强调，$\mathcal{C}$ 可以十分丰富，尤其可以包含受保护群体 S 的许多相互重叠的子群体。在这个意义上，多重校准远远超出针对少数敏感群体的校准，而是为所有计算上可识别的子集提供校准；计算上可识别这一概念由 $\mathcal{C}$ 的表达能力参数化。

1.1. 我们的贡献

我们从算法与复杂性理论的角度研究多重校准这一新概念。我们提出一种简单的通用算法，利用少量带标签样本，学习相对于任意给定类别 $\mathcal{C}$ 多重校准的预测器。该算法采用类似提升法的迭代方式，可视为函数梯度下降的一种变体。学习多重校准预测器时会出现若干细微问题，因为校准约束随预测器当前的预测值而变化。为保证少量训练样本下的泛化，我们利用了将差分隐私与稳健自适应数据分析联系起来的一系列新研究成果（Dwork et al., 2015a;b;c; Bassily et al., 2016）。

我们不对学得预测器的假设类作显式限制；相反，我们证明算法隐式地学到了一个能够良好泛化到未见数据的模型，这一点本身也可能具有独立价值。我们通过证明所学预测可以压缩，来说明这种隐式泛化，其意义类似于伪随机性中的分解引理（Trevisan et al., 2009）。用电路复杂性的语言来说，我们证明可以构造一个仅比 $\mathcal{C}$ 中的电路略大的电路，实现学得的预测器。由此可知，表示该预测器所需的空间和执行预测所需的时间都很高效。

我们还研究了针对具有结构的类别 $\mathcal{C}$ 学习多重校准预测器的计算复杂性，并揭示其与不可知学习（Haussler, 1992; Kearns et al., 1994）的复杂性之间的紧密联系。正面结果是：如果类别 $\mathcal{C}$ 存在高效的（弱）不可知学习器（Kalai et al., 2008; Feldman, 2010），就能以类似的效率在 $\mathcal{C}$ 上实现多重校准。另一方面，我们证明，在 $\mathcal{C}$ 定义的所有集合上学习多重校准预测器，至少和对 $\mathcal{C}$ 进行弱不可知学习一样困难。在这个意义上，相对于 $\mathcal{C}$ 学习多重校准预测器的复杂性，等价于对 $\mathcal{C}$ 进行弱不可知学习的复杂性。

最后，我们说明多重校准的目标与获得高效用预测的目标一致。具体而言，给定任何预测器 h，可以对 h 进行后处理，得到平方误差不高于 h 的多重校准预测器 f。计算 f 的复杂性仅比计算 h 略大。因此，与许多公平性概念不同，多重校准不会与预测能力冲突，而且可以与任何预测模型配合，基本不损失准确性。

2. 多重校准的预备知识

令 $\mathcal{X}$ 表示个体（特征向量）的定义域；我们希望预测某个事件是否会发生在各个个体身上。对每个 $i \in \mathcal{X}$，假设存在未知概率 $p_i^* \in [0, 1]$；我们不对 $p^* : \mathcal{X} \to [0, 1]$ 的结构作任何假设。特别地，假设结果中具有足够的不确定性，因此直接学习 p^* 可能很困难。令 $\mathcal{D}$ 表示支撑在 $\mathcal{X}$ 上的个体分布；对 $S \subseteq \mathcal{X}$，用 $i \sim S$ 表示在属于 S 的条件下从 $\mathcal{D}$ 抽样（见下方脚注 1）。在学习情境中，算法可以取得少量带标签个体 $D \subseteq \mathcal{X}$，其中每个 $i \in D$ 的标签都是一次独立伯努利试验的结果 $o_i \sim \mathrm{Ber}\left(p_i^*\right)$。给定这些样本，学习者的目标是产生满足多重校准的预测器 $f : \mathcal{X} \to [0, 1]$；其形式化定义如下。

脚注 1。为保证有意义的公平性，我们假设希望保护的子人群在分布 $\mathcal{D}$ 中具有充分的代表性，使随机样本能够包含这些人群。在实践中究竟需要多大程度的代表性，仍是值得今后进行实证研究的问题。

多重校准。对预测器所能期待的最基本性质是无偏性，即预测在期望意义上准确。

定义（期望准确性）。对任意 $\alpha > 0$ 和 $S \subseteq \mathcal{X}$，如果

$$\left|\mathbf{E}_{i \sim S}\left[f_i - p_i^*\right]\right| \leq \alpha, \qquad (1)$$

则称预测器 f 相对于 S 是 α-期望准确的（AE）。

这一条件是预测无偏的必要条件，却不足以防止所有形式的歧视；尤其是，一个预测器可以在集合 S 上无偏，同时引入数据并不支持的差异，人为地区别对待相似个体。校准通过考察由预测器 f 定义的类别 $S_v = \{i : f_i = v\}$ 上的期望值，减轻这种歧视。具体而言，相对于 S 的 α-校准要求：除 S 中比例为 α 的个体外，收到预测 v 的个体，其真实概率的均值与 v 的距离不超过 α。

定义（校准）。对任意 $v \in [0, 1]$、$S \subseteq \mathcal{X}$ 和预测器 f，令 $S_v = \{i : f_i = v\}$。对 $\alpha \in [0, 1]$，如果存在 $S' \subseteq S$，满足 $\Pr_{i\sim\mathcal{D}}[i \in S'] \geq (1-\alpha)\Pr_{i\sim\mathcal{D}}[i \in S]$，且对所有 $v \in [0, 1]$ 都有

$$\left|\mathbf{E}_{i\sim S_v \cap S'}\left[f_i - p_i^*\right]\right| \leq \alpha, \qquad (2)$$

则称 f 相对于 S 是 α-校准的。

注意，相对于 S 的 α-校准蕴含相对于 S 的 2α-AE。我们的定义只要求校准在每个 S 的 $1-\alpha$ 比例部分上成立，这是由于小样本学习以及需要离散化学得预测器的值域 $[0, 1]$ 而产生的技术性要求。

对于子集族 $\mathcal{C}$，如果预测器同时在所有 $S \in \mathcal{C}$ 上都是 α-校准的，就称它是 $(\mathcal{C}, \alpha)$-多重校准的。

定义（多重校准）。设 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是 $\mathcal{X}$ 的子集族，且 $\alpha \in [0, 1]$。如果对所有 $S \in \mathcal{C}$，f 相对于 S 都是 α-校准的，则称预测器 f 是 $(\mathcal{C}, \alpha)$-多重校准的。

离散化。即使允许任意预测 $f_i \in [0, 1]$，α-校准也是有意义的定义；但从计算角度，我们必须对 $v \in [0, 1]$ 保持某种离散化。形式上，使用如下技术性定义。

定义（λ-离散化）。设 $\lambda > 0$。$[0, 1]$ 的 λ-离散化记为 $\Lambda[0, 1] = \{\lambda/2, 3\lambda/2, \ldots, 1-\lambda/2\}$，即 $[0, 1]$ 上 $1/\lambda$ 个等距实数的集合。对 $v \in \Lambda[0, 1]$，令

$$\lambda(v) = [v - \lambda/2, v + \lambda/2)$$

为以 v 为中心的 λ-区间（最后一个区间例外，为 $[1-\lambda, 1]$）。

如果取 $\lambda = \alpha$，则一个 $(\mathcal{C}, \alpha)$-多重校准预测器的 λ-离散化是 $(\mathcal{C}, 2\alpha)$-多重校准的。

下文概述我们的结果，并介绍证明技术的基本思路。完整的结果和形式化证明留在补充材料中（另见存档版本 Hébert-Johnson et al., 2017）。

3. 学习多重校准预测器

首先需要回答，多重校准是否可行。例如，多重校准的要求可能强到必须非常精确地学习并表示一个任意复杂的函数 p^*，而这在我们的情境中可能不可行。第一个结果刻画表示多重校准预测器的复杂性。我们说明，多重校准确实可以高效实现：对任意 p^* 和任意大子集族 $\mathcal{C}$，都存在一个在 $\mathcal{C}$ 上 α-多重校准的预测器，其复杂性仅略高于描述 $\mathcal{C}$ 中集合所需的复杂性。为具体起见，下面的定理采用电路规模作为复杂性度量。

定理 1。 假设 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是一个集合族，对每个 $S \in \mathcal{C}$，存在规模为 s 的电路计算其成员资格，且 $\Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma$。对于任意 $p^* : \mathcal{X} \to [0, 1]$，存在一个 $(\mathcal{C}, \alpha)$-多重校准预测器，可由规模为 $O(s/\alpha^4\gamma)$ 的电路实现。

3.1. 算法

事实上，我们通过从带标签样本学习 $(\mathcal{C}, \alpha)$-多重校准预测器，以算法方式证明定理 1。算法是一个迭代过程。从高层看，算法维护候选预测器 f，并在每次迭代中修正某个违反校准的子集上的候选值，直到候选预测器在每个 $S \in \mathcal{C}$ 上都满足 α-校准。我们证明，即使 $\mathcal{C}$ 很大（例如相对于其他相关参数呈指数规模），更新次数以及所学模型的复杂性也都是有界的（关于 $1/\alpha, 1/\gamma$ 为多项式）。

回顾集合 S 上的校准要求：在子集 $S_v = \{i \in S : f_i = v\}$（下文始终称为“类别”）上，真实概率的期望 $\mathbf{E}_{i\sim S_v}[p_i^*]$ 与 v 接近。因此，在统计查询模型下最容易描述该算法：我们查询人群子集上的真实统计量的估计，并据此更新预测器。特别地，给定容差为 $\omega = O(\alpha\gamma)$ 的统计查询预言机，这些估计将足够准确，能够保证在满足 $\Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma$ 的集合 S 上实现 α-校准。

自适应泛化。 将算法改为从随机样本学习时，算法利用人群随机样本上的经验估计回答这些统计查询。标准的一致收敛论证（Kearns & Vazirani, 1994）说明，如果可能提出的查询集合预先固定，那么回答这些非自适应查询所需的样本复杂性可以界定为 $\widetilde{O}(\log|\mathcal{C}|/\omega^2)$。但注意，我们查询期望的类别 S_v 是自适应选择的（即依赖于先前查询的结果）。尤其是，类别 S_v 的定义依赖预测器 f 的当前值；因此，当我们依据统计查询结果更新 f 时，可能进行统计查询的类别集合也随之变化。在这种情况下，除非每次更新预测器都重新抽样，否则不能简单地运用集中不等式并取并合界来保证良好的泛化。

为避免这种样本复杂性的增长，我们利用近期揭示的差分隐私与自适应数据分析之间的联系（Dwork et al., 2015a;b;c; Bassily et al., 2016）。为回答统计查询，算法刻意通过所谓的“猜测并检验”预言机与数据交互。具体来说，每当算法需要知道集合 S 上某个统计查询的值时，我们不让它直接提问，而是要求它向预言机提交当前猜测 $f_S = \mathbf{E}_{i\sim S}[f_i]$，以及可接受的相对误差窗口 $\omega \in [0, 1]$。直观上，如果猜测远离以真实期望为中心的窗口，预言机就返回容差为 $\alpha\Pr_{i\sim\mathcal{D}}[i \in S]$ 的统计查询答案。反之，如果猜测足够接近真实值，预言机返回“√”，表示当前猜测接近期望，而不再透露另一个答案。

定义（猜测并检验预言机）。 设 $\widetilde{q} : 2^{\mathcal{X}} \times [0, 1] \times [0, 1] \to [0, 1] \cup \{\checkmark\}$。如果对 $S \subseteq \mathcal{X}$、$p_S = \mathbf{E}_{i\sim S}[p_i^*]$、$v \in [0, 1]$ 以及任意 $\alpha > 0$，$\widetilde{q}(S, v, \omega)$ 的响应满足以下条件，则称 $\widetilde{q}$ 为猜测并检验预言机：

- 如果 $|p_S - v| < 2\omega$，则 $\widetilde{q}(S, v, \omega) = \checkmark$；
- 如果 $|p_S - v| > 4\omega$，则 $\widetilde{q}(S, v, \omega) \in [0, 1]$；
- 如果 $\widetilde{q}(S, v, \omega) \neq \checkmark$，则

$$p_S - \omega \leq \widetilde{q}(S, v, \omega) \leq p_S + \omega.$$

注意，如果猜测满足 $|p_S - v| \in [2\omega, 4\omega]$，预言机既可以返回某个误差不超过 ω 的 $r \in [0, 1]$，也可以返回“√”。如果已知一系列猜测并检验查询的下界 $\omega_0 = \Pr_{i\sim\mathcal{D}}[i \in S]\omega$，就能利用容差 $\tau \le \omega_0$ 的统计查询预言机实现这些查询。采用这一框架的优势在于，它可以使用为差分隐私开发的工具实现（Hardt & Rothblum, 2010）。这使我们能够给出一种利用少量样本学习 $(\mathcal{C}, \alpha)$-多重校准预测器、并能够良好泛化的算法。

在定义这一机制之后，算法 1 给出了过程的具体描述。

$\mathcal{C}$ 的隐式表示。 尽管这一过程对任意集合族 $\mathcal{C}$ 都适用，但为了保证算法和学得预测器的效率，重要的是 $S \in \mathcal{C}$ 应具有某种隐式表示，即能够由决策树、神经网络等简单模型执行成员资格检验。特别地，尽管算法更新所有 $i \in \mathcal{X}$ 的预测，这种更新仍可以隐式完成：将成员资格检验组成一个“电路”，如果个体通过检验，再执行适当的加法。

算法 1：学习 $(\mathcal{C}, \alpha)$-多重校准预测器。

Algorithm 1 – Learning a $(\mathcal{C}, \alpha)$-multicalibrated predictor

Let $\alpha, \lambda > 0$ and let $\mathcal{C} \subseteq 2^{\mathcal{X}}$.
Let $\tilde{q}(\cdot, \cdot, \cdot)$ be a guess-and-check oracle.

- Initialize: $f = (1/2, \ldots, 1/2) \in [0,1]^{\mathcal{X}}$
- Repeat:
  - For each $S \in \mathcal{C}$ and $v \in \Lambda[0,1]$:
    - Let $S_v = S \cap \{i : f_i \in \lambda(v)\}$
    - if $\mathbf{Pr}_{i\sim\mathcal{D}}[i \in S_v] < \alpha\lambda \cdot \mathbf{Pr}_{i\sim\mathcal{D}}[i \in S]$: **continue**
    - Let $\bar{v} = \mathbf{E}_{i\sim S_v}[f_i]$
    - Let $r = \tilde{q}(S_v, \bar{v}, \alpha/4)$
    - If $r \neq \checkmark$: **update** $f_i \leftarrow f_i + (r - \bar{v})$ for all $i \in S_v$ (project onto $[0,1]$ if necessary)
  - If no S_v updated: **exit**
- For $v \in \Lambda[0,1]$:
  - Let $\bar{v} = \mathbf{E}_{i\sim\lambda(v)}[f_i]$
  - For $i \in \lambda(v)$: $f_i \leftarrow \bar{v}$
- Output f

算法 1 全文中文对照。 令 $\alpha, \lambda > 0$，且 $\mathcal{C} \subseteq 2^X$。令 $\widetilde{q}(\cdot, \cdot, \cdot)$ 为猜测并检验预言机。

1. 初始化：$f = (1/2, \ldots, 1/2) \in [0, 1]^X$。
2. 重复：
   - 对每个 $S \in \mathcal{C}$ 和 $v \in \Lambda[0, 1]$：
     - 令 $S_v = S \cap \{i : f_i \in \lambda(v)\}$。
     - 如果 $\Pr_{i \sim \mathcal{D}}[i \in S_v] < \alpha\lambda \Pr_{i \sim \mathcal{D}}[i \in S]$，则继续处理下一项。
     - 令 $\bar{v} = \mathbf{E}_{i \sim S_v}[f_i]$。
     - 令 $r = \widetilde{q}(S_v, \bar{v}, \alpha/4)$。
     - 如果 $r \neq \checkmark$，则对所有 $i \in S_v$ 更新 $f_i \leftarrow f_i + (r - \bar{v})$（必要时投影到 $[0, 1]$）。
   - 如果没有任何 S_v 被更新，则退出循环。
3. 对 $v \in \Lambda[0, 1]$：令 $\bar{v} = \mathbf{E}_{i \sim \lambda(v)}[f_i]$；对 $i \in \lambda(v)$，令 $f_i \leftarrow \bar{v}$。
4. 输出 f。

形式上，我们证明如下定理。

定理 2。 假设 $\mathcal{C} \subseteq 2^X$ 是一个集合族，对所有 $S \in \mathcal{C}$ 有 $\Pr_{i \sim \mathcal{D}}[i \in S] \geq \gamma$，并且成员资格可在时间 t 内判定。那么，以 $\lambda = \alpha$ 运行算法 1，可以从 $O\left(\log(|\mathcal{C}|)/\alpha^{11/2}\gamma^{3/2}\right)$ 个样本中，在 $O\left(|\mathcal{C}|\, t\, \mathrm{poly}\left(1/\alpha, 1/\gamma\right)\right)$ 时间内，学得一个相对于 p^* 为 $(\mathcal{C}, 2\alpha)$-多重校准的预测器 $f : \mathcal{X} \to [0, 1]$。

4. 多重校准与弱不可知学习

运行时间线性依赖 $|\mathcal{C}|$，因此自然希望开发对 $|\mathcal{C}|$ 仅有次多项式、乃至多对数依赖的学习过程。接下来的结果旨在刻画何时可以实现这一乐观目标，何时不可以。我们强调，定理 2 的算法对任意 $p^* : \mathcal{X} \to [0, 1]$ 和 $\mathcal{C}$ 都能学习多重校准预测器。当不能利用 p^* 的结构实现高效学习时，我们可能希望利用子集族 $\mathcal{C}$ 中存在的结构。事实上，我们揭示了学习多重校准预测器这一目标与弱不可知学习之间的联系；后者是在不可知提升法文献中引入的（Ben-David et al., 2001; Kalai et al., 2008; Kanade & Kalai, 2009; Feldman, 2010）。更形式化地，我们需要 Kalai et al. (2008) 和 Feldman (2010) 所定义的 (ρ, τ)-弱不可知学习器。这里描述 Feldman (2010) 中针对特定分布的学习器，定义中的样本和内积均相对于固定数据分布 $\mathcal{D}$。

定义（弱不可知学习器）。 设 $\rho \geq \tau > 0$、$\mathcal{C} \subseteq 2^X$，以及 $\mathcal{H} \subseteq [-1, 1]^X$。概念类 $\mathcal{C}$、假设类 $\mathcal{H}$ 的 (ρ, τ)-弱不可知学习器 $\mathcal{L}$ 解决如下承诺问题：给定带标签样本集合 $\{(i, y_i)\}$，其中 $i \sim \mathcal{D}$ 且 $y_i \in [-1, 1]$，如果存在 $c \in \mathcal{C}$ 满足 $\mathbf{E}_{i \sim \mathcal{D}}[c_i y_i] > \rho$，则 $\mathcal{L}$ 返回某个 $h \in \mathcal{H}$，满足 $\mathbf{E}_{i \sim \mathcal{D}}[h_i y_i] > \tau$。

直观地，如果某个概念 $c \in \mathcal{C}$ 与观测标签具有非平凡相关性，那么弱不可知学习器返回的假设 h（不一定属于 $\mathcal{C}$）也与观测标签具有非平凡相关性。通常取 $\rho = 1/p(d)$ 和 $\tau = 1/q(d)$，其中 $p(d) \leq q(d)$ 为多项式，且 $d = \log(|\mathcal{C}|)$。

由不可知学习实现高效多重校准。下一项结果说明：在 $\mathcal{C}$ 上进行高效弱不可知学习，蕴含可以高效学习 $\mathcal{C}$ 上的 α -多重校准预测器。

定理 3。设 $\rho, \tau > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$ 为某个概念类。如果 $\mathcal{C}$ 存在运行时间为 $T(|\mathcal{C}|, \rho, \tau)$ 的 (ρ, τ) -弱不可知学习器，那么只要 $\rho \leq \alpha^2\lambda\gamma/2$ 且 $\tau = \mathrm{poly}(\alpha, \lambda, \gamma)$，就存在一个算法，在 $O(T(|\mathcal{C}|, \rho, \tau)\mathrm{poly}(1/\alpha, 1/\lambda, 1/\gamma))$ 时间内，学得一个在 $\mathcal{C}' = \{S \in \mathcal{C} : \Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma\}$ 上为 $(\mathcal{C}, \alpha)$ -多重校准的预测器。

回顾我们的多重校准学习算法，它维护候选预测器 f，并迭代搜索某个使 f 未校准的集合 $S \in \mathcal{C}$。为了更快解决这个搜索问题，我们把搜索表述为：在由 $\mathcal{C}$ 导出的概念类上、以 $\mathcal{H} = \{h : \mathcal{X} \to [-1, 1]\}$ 为假设类进行弱不可知学习。

具体而言，考虑子集族 $\mathcal{C}$ 定义的概念类；对每个 $S \in \mathcal{C}$，包括概念 $c_S : \mathcal{X} \to \{-1, 1\}$，其中 $c_S(i) = 1$ 当且仅当 $i \in S$。我们说明如何设计个体的“标签” $\ell : \mathcal{X} \to [-1, 1]$，使得若 f 在任何 $S \in \mathcal{C}$ 上违反校准约束，则概念 c_S 在个体分布上与这些标签具有非平凡相关性，即对某个 $\rho > 0$ 有 $\langle c_S, \ell\rangle \geq \rho$。具体地，对每个 $v \in \Lambda[0, 1]$，考虑如下学习问题：对 $i \in \mathcal{X}_v$，令 $\ell_i = (f_i - o_i)/2$；对 $i \in \mathcal{X}\backslash\mathcal{X}_v$，令 $\ell_i = 0$。我们断言，如果某个 S_v 当前违反多重校准，则对 $i \sim \mathcal{D}$，带标签样本 (i, ℓ_i) 或 $(i, -\ell_i)$ 至少有一者满足 $\rho = \alpha\beta/2$ 的弱学习承诺。

因此，如果 f 在 $\mathcal{C}$ 上尚未多重校准，就保证存在某个概念 c_S 与标签具有非平凡相关性；而这一承诺恰好是 Kalai et al. (2008) 与 Feldman (2010) 所定义的弱不可知学习器所要求的。特别地，给定依照 $\mathcal{D}$ 抽取的带标签样本 $(i, \ell(i))$，如果存在与 ℓ 的相关性至少为 ρ 的概念 c_S，那么弱不可知学习器就会返回与 ℓ 的相关性为 τ 的假设 h，其中 $\tau < \rho$。困难在于，这一假设可能不属于概念类 $\mathcal{C}$，因此不能直接“修正”某个 $S \in \mathcal{C}$。不过，对个体的标记 ℓ 经过专门设计，使得给定假设 h 后，仍可提取出对 f 的更新，从全局上推进校准目标。只要 τ 有非平凡的下界，就能对调用弱学习器的次数给出上界。

由多重校准实现高效不可知学习。目前的结果表明，在对 p^* 或 $\mathcal{C}$ 作出适当结构假设时，学习多重校准预测器可以比一般情形的上界更高效。回到一般情形，我们可能会问这些结构假设是否必需；答案是肯定的。我们证明，对于最坏情形的 p^*，在 $\mathcal{C}$ 上学习多重校准预测器，至少和对 $\mathcal{C}$ 进行弱不可知学习一样困难。

定理 4。设 $\alpha, \gamma > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$ 为概念类。如果存在算法，可以在 $T(|\mathcal{C}|, \alpha, \gamma)$ 时间内，在 $\mathcal{C}' = \{S \in \mathcal{C} : \Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma\}$ 上学习 $(\mathcal{C}', \alpha)$ -多重校准预测器，那么对任意满足 $\tau \leq \min\{\rho - 2\gamma, \rho/4 - 4\alpha\}$ 的 $\rho, \tau > 0$，都可以在 $O(T(|\mathcal{C}|, \alpha, \gamma)\mathrm{poly}(1/\tau))$ 时间内实现 $\mathcal{C}$ 的 (ρ, τ) -弱不可知学习器。

具体而言，给定相对于 $\mathcal{C}$ 学习 α -多重校准预测器 f 的算法，我们说明如何实现 $\mathcal{C}$ 的弱不可知学习器（实际上，只需要预测器在 $\mathcal{C}' = \{S \in \mathcal{C} : \Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma\}$ 上多重校准）。这一归约的关键引理指出，如果某个 $c \in \mathcal{C}$ 与标签具有非平凡相关性，那么 f 也与 c 具有非平凡相关性。通常认为，不

可知学习是一个公认十分困难的计算问题。特别地，在密码学假设下（Valiant, 1984; Goldreich et al., 1984; Bogdanov & Rosen, 2017），这一结果意味着存在常数 $t > 0$，使任何针对任意 $\mathcal{C}$ 学习 $(\mathcal{C}, \alpha)$ -多重校准预测器的算法，都需要 $\Omega\left(|\mathcal{C}|^t\right)$ 时间。

综合这些结果，相对于类别 $\mathcal{C}$ 学习多重校准预测器的复杂性，等价于对 $\mathcal{C}$ 进行弱不可知学习的复杂性。

5. 类内最优预测

最后，我们再次关注多重校准预测器的效用。上文论证了，多重校准可以为群体提供强有力的反歧视保护。我们证明，这种保护（几乎）不会损失预测器的效用。这一结果丰富了不断发展的公平性与准确性权衡研究（Fish et al., 2016; Berk et al., 2017; Chouldechova & G’ Sell, 2017）。

定理 5。假设 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是 $\mathcal{X}$ 的子集族，$\mathcal{H}$ 是预测器集合。存在一个在 $\mathcal{C}$ 上 α -多重校准的预测器 f，使得

$$\mathbf{E}_{i\sim\mathcal{X}}\left[\left(f_i - p_i^*\right)^2\right] - \mathbf{E}_{i\sim\mathcal{X}}\left[\left(h_i^* - p_i^*\right)^2\right] < 6\alpha,$$

其中 $h^* = \operatorname{argmin}_{h\in\mathcal{H}}\mathbf{E}_{i\sim\mathcal{X}}\left[\left(h - p^*\right)^2\right]$。进一步，假设对所有 $S \in \mathcal{C}$ 有 $\Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma$，且 $S \in \mathcal{C}$ 的成员资格以及 $h \in \mathcal{H}$ 都可由规模至多为 s 的电路计算，则 f 可由规模至多 $O\left(s/\alpha^4\gamma\right)$ 的电路计算。

根据 $\mathcal{H}$ 的不同选择，可以对定理 5 作不同解释。假设某个复杂学习算法产生了性能卓越的预测器 h，但它可能任意违反校准。如果取 $\mathcal{H} = \{h\}$，这一结果就意味着：学习之后对 h 强制实施校准，并不会显著损害准确性。

换一个角度，也可以将 $\mathcal{H}$ 看作由有界复杂度电路类（例如 k 个变量的合取、半空间、规模为 s 的电路）实现的预测器集合。借助定理 1 和定理 2，本定理说明：对于任何这样的有界复杂度预测器类 $\mathcal{H}$，都存在一个复杂性相近的多重校准预测器，其性能与最好的 $h^* \in \mathcal{H}$ 相当。在这个意义上，只需少量额外复杂性，多重校准预测器便能实现“类内最优”预测。

与许多其他公平性概念不同，多重校准并不限制预测器的效用。进一步，为证明多重校准不会损害效用，我们实际上证明了一个强得多的陈述：如果对某个 $h \in \mathcal{H}$ 实施多重校准显著改变了 h 的预测（即 $\mathbf{E}_{i\sim\mathcal{D}}\left[\left(f_i - h_i\right)^2\right]$ 很大），那么这种改变意味着平方误差的改善。因此，多重校准要求与学习高效用预测器的目标一致。

下面介绍证明定理 5 的基本思路。考虑 $h \in \mathcal{H}$，并依据 h 的预测将 $\mathcal{X}$ 划分为若干集合；具体来说，先对每个 h 的值域进行 λ -离散化，从而将 $\mathcal{X}$ 划分为类别。令 $S_v(h) = \{i : h_i \in \lambda(v)\}$。注意，当 $v \neq v'$ 时，$S_v(h)$ 与 $S_{v'}(h)$ 不相交，且 $\bigcup_{v\in\Lambda[0,1]} S_v(h) = \mathcal{X}$。除了要求相对于 $S \in \mathcal{C}$ 校准以外，还可以要求对所有 $h \in \mathcal{H}$ 和 $v \in \Lambda[0, 1]$，在 $S_v(h)$ 上都校准。具体地，令 $\mathcal{S}(\mathcal{H}) = \{S_v(h)\}_{h\in\mathcal{H}, v\in\Lambda[0,1]}$；我们考虑在 $\mathcal{C}\cup\mathcal{S}(\mathcal{H})$ 上施加校准。这既保护 $\mathcal{C}$ 定义的群体，也提供如下引理所刻画的强效用保障。

引理。 假设 g 是 λ-离散化预测器，令 $\mathcal{S}(g) = \{S_v(g)\}_{v\in\Lambda[0,1]}$。设 f 为任意 $(\mathcal{S}(g), \alpha)$-多重校准预测器。那么对 $v \in \Lambda[0, 1]$，

$$\mathbf{E}_{i\sim S_v(g)}\left[(g_i - f_i)^2\right] - (4\alpha + \lambda) \le \mathbf{E}_{i\sim S_v(g)}\left[(g_i - p_i^*)^2\right] - \mathbf{E}_{i\sim S_v(g)}\left[(f_i - p_i^*)^2\right].$$

这一引理说明，在预测器的类别上进行校准，不仅能防止平方预测误差恶化超过一个很小的加性误差，还保证：如果校准显著改变了某一类别上的预测器，那么这种改变代表在该类别上向真实底层概率的显著推进。假定引理 5 成立，定理 5 随即成立。

注意，引理 5 表明，这种类内最优性质不仅在整个域 $\mathcal{X}$ 上成立，而且在某个 $h \in \mathcal{H}$ 所识别的每个足够大类别 $S_v(h)$ 上都成立。换言之，若 f 在 $\mathcal{S}(\mathcal{H})$ 上校准，则对每个类别 $S_v(h)$，其平均平方预测误差 $\mathbf{E}_{i\sim S_v(h)}\left[(f_i - p_i^*)^2\right]$ 至多比 h 在该集合上的预测差 6α。若把 $\mathcal{H}$ 看作定义“计算上可识别”类别集合 $\mathcal{S}(\mathcal{H})$，则任何在 $\mathcal{S}(\mathcal{H})$ 上校准的预测器，在这些计算上可识别类别上，都至少与识别出该群体的预测器一样公平、一样准确（允许很小的加性近似误差）。

6. 相关工作与讨论

校准。 校准在统计学与计量经济学、尤其是预测文献中得到了广泛研究。关于这一背景下的校准，可参见 Sandroni et al. (2003)、Foster & Hart (2015) 及其参考文献。校准也在预测支撑集合很大的结构化预测情境中得到研究（Kuleshov & Liang, 2015）。我们关于多重校准的算法结果，与在线学习文献中的工作相似（Blum & Mansour, 2007; Khot & Ponnuswami, 2008; Trevisan et al., 2009）。虽然这些工作在思想上类似，但其算法结果都不能直接应用到我们的多重校准情境。我们尚不知道此前有工作将校准与差分隐私或自适应数据分析联系起来。

均等与平衡。 分类公平性的其他研究往往考察基于均等性的公平概念。具体而言，统计均等（Dwork et al., 2012）和错误率平衡（Hardt et al., 2016）旨在对由种族、性别等敏感特征定义的不同群体施加某种同等对待要求。Hardt et al. (2016) 说明了如何通过“纠正”任意预测器的后处理步骤，获得与错误率平衡相关的均等化机会（equalized odds）。

尽管校准和平衡（以及其他相关变体）直觉上都是公平预测器应当具备的好性质（即使它们略显弱小），但在非退化情形下，两者不可能同时满足（Kleinberg et al., 2017; Chouldechova, 2017; Pleiss et al., 2017）。对于如何应对这种不相容性，存在大量讨论（Corbett-Davies et al., 2017）。平衡与校准之间的内在冲突，再加上我们关于校准始终与准确、高效用预测目标一致的观察，意味着平衡有时必然与获取预测效用相冲突。本文选择加强校准所蕴含的保护，而不是强制错误率平衡。诚然，在一些情境下，使各群体的机会均等化是好主意；但也有一些情境，校准才是更适当的公平性概念。

对于把错误率平衡作为公平性概念的一项具体批评是：给定基础发生率不同的两个群体 $S, T \subseteq \mathcal{X}$（即对 $i \in S, j \in T$，有 $p_i^* > p_j^*$），贝叶斯最优预测器 p^* 并不平衡。也就是说，即使完全掌握底层概率的信息，结果中的随机性仍会产生不同的假阳性率和假阴性率。因此，平衡可以视为一种后验公平性概念（相对于结果的公平性），而我们的多重校准则是先验公平性概念（相对于给定数据的公平性）。如果在给定数据后，预测结果仍然具有显著不确定性，我们认为应当考虑以多重校准替代错误率平衡。不过，如果不同子人群的结果不确定性差异很大，也可能出现严重歧视；这是一种信息论层面的歧视，多重校准或许有助于识别，却无法直接补救。

介于群体与个体之间。 多数公平性概念本质上是统计性的；大致而言，包括统计均等（Dwork et al., 2012）、错误率平衡（Hardt et al., 2016）和校准在内的定义，都要求不同群体平均而言得到公平对待（其中“公平”的含义各不相同）。Dwork et al. (2012) 在一项重要工作中批评了这些粗粒度统计定义，并提出旨在“相似个体应受到相似对待”的个体公平性概念。这种方法的主要挑战，是假设可以取得每一对个体之间与任务相关的度量。在希望从少量样本学习的实际情境中，不可能指望实现这种信息论意义上的公平。多重校准可被看作群体公平性（满足校准）与个体校准（紧密匹配 p_i^*）之间有意义的折中。本文提出的多重校准框架启发了后续工作：针对一般相似性度量，研究如何在统计性和个体性的“度量公平性”之间插值（Kim et al., 2018b）；也启发了关于二分类中多重期望准确性的进一步理论和实证研究（Kim et al., 2018a）。

同期独立开展的 Kearns et al. (2017) 也研究了通过要求性质在更丰富的集合族上成立，来加强群体公平性的保障。与本文不同，他们的定义要求这些集合族上满足平衡或统计均等。尽管动机相近，这两种子群体公平性方法仍有实质区别。举例来说，多重校准与取得高效用预测器的激励一致；而基于平衡的公平性概念未必如此。事实上，在本文情境中，多重校准的一个动机正是前面对平衡的批评，而在考虑“多重平衡”时，这些问题可能只会更加严重。

考虑 Dwork et al. (2012) 中预测未来学业成功的例子。在群体 S 中，最优秀的学生申请工程专业；而在一般人群 T 中，他们申请商科。若在两个群体内都强制商科申请人与工程申请人之间保持平衡，就会对两组中的合格申请人（即 S 中申请工程的学生和 T 中申请商科的学生）不公平。本质上，把个体空间细分为子群体会放大基础发生率的差异，进而导致不当对待。预防算法歧视是一件微妙的事，不同情境需要不同的保护概念。尽管如此，这些工作共同证明：有必要研究超出大型受保护群体范围、切实可行的歧视缓解方法。

纠正性差别对待。 多重校准是解决某类歧视的强大工具，但并非普遍适用。再次考虑房贷例子：过去获得贷款的 S 成员可能很少（因而没有足够样本在 S 内进行细粒度学习）；可用属性也可能太有限，无法识别 S 中资质合格的成员（极端地说，唯一可用属性可能就是是否属于 S）。在这些情况下，数据可能不足以支持多重校准提供有意义的保障。进一步，即使给算法无限丰富的数据，能够恢复精细的 p^* 值，也可能存在应当给予优待的情境：毕竟，S 成员的工资较低，可能源于历史歧视。因此，对于“平衡与 p^* 不一致”的顾虑，可以回答：“是的，而且我们正是有意如此！”Hardt et al. (2016) 确实提倡把强制均等化机会作为一种“纠正性差别对待”。虽然这种主张在许多情境中很重要，但多重校准为反歧视手段增添了另一件工具，我们相信它在许多情境中同样自然且可取。

再考虑一个多重校准适用、而均等化错误率未必适用的例子：假设一家基因组公司向个人提供患某些遗传病的概率预测。这些疾病在不同人群中的发生率不同；例如，泰-萨克斯病在一般人群中很罕见，却在阿什肯纳兹犹太人中常见得多。我们当然不希望通过降低对个体患病概率的预测来强制该群体满足平衡，因为他们本来就更可能患上该病。不过，我们也不希望公司只根据阿什肯纳兹身份这一特征作出预测。相反，施加多重校准将要求学习算法同时考察阿什肯纳兹和非阿什肯纳兹人群，以便在各组内准确预测（即使这意味着阿什肯纳兹人群具有较高的假阳性率）。在这种情况下，依据 p^* 看起来与促进公平性高度一致。

结论。 多重校准针对的是从数据学习的预测系统中可能出现的一种特定歧视。特别地，它要求学得的预测器准确反映数据中“计算上可识别”的差异，而不引入虚假的差异。多重校准最适合如下情境：个体层面的完美预测被认为是最公平的预测，但训练数据又不够丰富，无法作出完美预测。重要的是，在这

一背景下，并不存在公平性与效用之间的权衡！施加多重校准只会改善所得模型的预测能力。相反，本文识别并尝试解决的是“公平性与信息”之间的权衡：尽管无法利用少量训练数据实现信息论意义上的理想预测，我们证明，通过多重校准，可以实现对这一目标有意义的复杂性理论松弛。最后，我们认为多重校准与“纠正性差别对待”（例如 Hardt et al., 2016 的变换）之间的相互作用，是未来研究的重要方向。

致谢

作者感谢 Cynthia Dwork、Roy Frostig、Parikshit Gopalan、Moritz Hardt、Aditi Raghunathan、Jacob Steinhardt 和 Greg Valiant 就本研究进行的有益讨论。感谢匿名审稿人提供详细反馈。MPK 获 NSF 项目 CNS-122864 支持。OR 获 NSF 项目 CCF-1749750 支持。GNR 获 ISF 第 5219/17 号项目支持。

参考文献

下列条目保留作者姓名、刊物及检索信息，论文或著作题名译为中文。

- Bassily, R., Nissim, K., Smith, A., Steinke, T., Stemmer, U., and Ullman, J. 自适应数据分析的算法稳定性。见 Proceedings of the 48th Annual ACM SIGACT Symposium on Theory of Computing，1046–1059 页。ACM，2016。
- Ben-David, S., Long, P., and Mansour, Y. 不可知提升法。见 Computational Learning Theory，507–516 页。Springer，2001。
- Berk, R., Heidari, H., Jabbari, S., Joseph, M., Kearns, M., Morgenstern, J., Neel, S., and Roth, A. 公平回归的凸框架。FATML，2017。
- Blum, A. and Mansour, Y. 从外部遗憾到内部遗憾。Journal of Machine Learning Research，8(Jun):1307–1324，2007。
- Bogdanov, A. and Rosen, A. 伪随机函数：三十年后。见 Tutorials on the Foundations of Cryptography，79–158 页。Springer，2017。
- Bolukbasi, T., Chang, K.-W., Zou, J. Y., Saligrama, V., and Kalai, A. T. 男人之于程序员如同女人之于家庭主妇？词嵌入的去偏。见 Advances in Neural Information Processing Systems，4349–4357 页，2016。
- Buolamwini, J. and Gebru, T. 性别色调：商业性别分类中的交叉性准确率差异。见 Conference on Fairness, Accountability and Transparency，77–91 页，2018。
- Chouldechova, A. 具有差别影响的公平预测：再犯预测工具中的偏差研究。Big Data，2017。
- Chouldechova, A. and G’Sell, M. 更公平且更准确，但对谁而言？FATML，2017。
- Corbett-Davies, S., Pierson, E., Feller, A., Goel, S., and Huq, A. 算法决策与公平性的代价。KDD，2017。
- Dwork, C., Hardt, M., Pitassi, T., Reingold, O., and Zemel, R. S. 通过感知实现公平。见 Innovations in Theoretical Computer Science (ITCS)，214–226 页，2012。
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. 自适应数据分析与留出集复用中的泛化。见 Advances in Neural Information Processing Systems，2350–2358 页，2015a。

- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. 可复用留出集：在自适应数据分析中保持有效性。Science，349(6248):636–638，2015b。
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. L. 在自适应数据分析中保持统计有效性。见 Proceedings of the forty-seventh annual ACM symposium on Theory of computing，117–126 页。ACM，2015c。
- Feldman, V. 针对特定分布的不可知提升法。见 Proceedings of the First Symposium on Innovations in Computer Science10，2010。
- Fish, B., Kun, J., and Lelkes, Á. D. 一种基于置信度的公平性与准确性平衡方法。见 Proceedings of the 2016 SIAM International Conference on Data Mining，144–152 页。SIAM，2016。
- Foster, D. P. and Hart, S. 平滑校准、泄漏预测、有限记忆与纳什动态。技术报告，工作论文，2015。
- Goldreich, O., Goldwasser, S., and Micali, S. 如何构造随机函数。见 Foundations of Computer Science, 1984. 25th Annual Symposium on，464–479 页。IEEE，1984。
- Hardt, M. and Rothblum, G. N. 用于隐私保护数据分析的乘法权重机制。见 Foundations of Computer Science (FOCS), 2010 51st Annual IEEE Symposium on，61–70 页。IEEE，2010。
- Hardt, M., Price, E., and Srebro, N. 监督学习中的机会平等。见 Advances in Neural Information Processing Systems，3315–3323 页，2016。
- Haussler, D. 神经网络及其他学习应用中 PAC 模型的决策理论推广。Information and computation，100(1):78–150，1992。
- Hébert-Johnson, Ú., Kim, M. P., Reingold, O., and Rothblum, G. N. 面向（计算上可识别）大众的校准。arXiv Preprint，1711.08513，2017。
- Kalai, A. T., Mansour, Y., and Verbin, E. 关于不可知提升法与奇偶学习。见 Proceedings of the fortieth annual ACM symposium on Theory of computing，629–638 页。ACM，2008。
- Kanade, V. and Kalai, A. 基于势函数的不可知提升法。见 Bengio, Y., Schuurmans, D., Lafferty, J. D., Williams, C. K. I., and Culotta, A.（编），Advances in Neural Information Processing Systems 22，880–888 页。Curran Associates, Inc.，2009。网址：原文。
- Kearns, M., Neel, S., Roth, A., and Wu, Z. 防止公平性选区操纵：子群体公平性的审计与学习。arXiv preprint arXiv:1711.05144，2017。
- Kearns, M. J. and Vazirani, U. V. 计算学习理论导论。MIT press，1994。
- Kearns, M. J., Schapire, R. E., and Sellie, L. M. 走向高效不可知学习。Machine Learning，17(2-3):115–141，1994。
- Khot, S. and Ponnuswami, A. K. 利用时间选择函数最小化宽范围遗憾。见 COLT，81–86 页，2008。
- Kim, M. P., Ghorbani, A., and Zou, J. 多重准确性：用于分类公平性的黑箱后处理。arXiv preprint arXiv:1805.12317，2018a。
- Kim, M. P., Reingold, O., and Rothblum, G. N. 通过计算有界感知实现公平。arXiv preprint arXiv:1803.03239，2018b。

- Kleinberg, J., Mullainathan, S., and Raghavan, M. 公平确定风险分数中的内在权衡。ITCS，2017。
- Kuleshov, V. and Liang, P. S. 校准的结构化预测。见 Advances in Neural Information Processing Systems，3474–3482 页，2015。
- Pleiss, G., Raghavan, M., Wu, F., Kleinberg, J., and Weinberger, K. Q. 论公平性与校准。NIPS，2017。
- Sandroni, A., Smorodinsky, R., and Vohra, R. V. 具有许多检验规则的校准。Mathematics of operations Research，28(1):141–153，2003。
- Trevisan, L., Tulsiani, M., and Vadhan, S. 正则性、提升法与高效模拟每一种高熵分布。见 Computational Complexity, 2009. CCC’09. 24th Annual IEEE Conference on，126–136 页。IEEE，2009。
- Valiant, L. G. 可学习性理论。Communications of the ACM，27(11):1134–1142，1984。

多重校准：补充材料

官方补充材料：PMLR PDF，共 7 页。以下保持其独立的章节、引理和公式编号。

记号。 在整个补充材料中，我们使用 $\| x \|^2 = \mathbf{E}_{i\sim\mathcal{D}}\left[x_i^2\right]$，并使用 $\langle x, y\rangle = \mathbf{E}_{i\sim\mathcal{D}}\left[x_i \cdot y_i\right]$。

A. 学习多重校准预测器

这里使用多重校准的一个更具技术性的变体，它蕴含 $(\mathcal{C}, \alpha)$-多重校准。特别地，这一定义允许我们显式离散化数值 $v \in [0, 1]$。对于预测器 f，我们始终将所有 $S \in \mathcal{C}$ 和 $v \in \Lambda[0, 1]$ 对应的 $S_v(f) = \{i : f_i \in \lambda(v)\} \cap S$ 称为“类别”。

定义（$(\mathcal{C}, \alpha, \lambda)$-**多重校准**）。 令 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 为 $\mathcal{X}$ 的子集族。对于任意 $\alpha, \lambda > 0$，如果对所有 $S \in \mathcal{C}$、$v \in \Lambda[0, 1]$ 以及满足 $\Pr_{i\sim\mathcal{D}}\left[i \in S_v(f)\right] \geq \alpha\lambda \Pr_{i\sim\mathcal{D}}[i \in S]$ 的类别 $S_v(f)$，都有

$$\left|\mathbf{E}_{i\in S_v(f)}\left[f_i - p_i^*\right]\right| \leq \alpha,$$

则预测器 f 是 $(\mathcal{C}, \alpha, \lambda)$-多重校准的。

我们断言，如果学得满足 $(\mathcal{C}, \alpha, \lambda)$-多重校准的预测器，就能容易地将其转换为满足前述 $(\mathcal{C}, \alpha)$-多重校准概念的预测器。具体地，若对所有 $i \in S_v(f)$ 有 $f_i^\lambda = \mathbf{E}_{i\sim S_v(f)}\left[f_i\right]$，则令 f^λ 为预测器 f 的 λ-离散化。

引理 1。 设 $\alpha, \lambda > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是 $\mathcal{X}$ 的子集族。如果 f 在 $\mathcal{C}$ 上是 (α, λ)-多重校准的，则 f^λ 在 $\mathcal{C}$ 上是 $(\alpha + \lambda)$-多重校准的。

证明。 考虑满足 $\Pr_{i\sim\mathcal{D}}\left[i \in S_v(f)\right] < \alpha\lambda \Pr_{i\sim\mathcal{D}}[i \in S]$ 的类别 $S_v(f)$。由于 λ-离散化，这类类别至多有 $1/\lambda$ 个，因此它们的并集大小至多为 $(1/\lambda)\alpha\lambda \Pr_{i\sim\mathcal{D}}[i \in S] = \alpha \Pr_{i\sim\mathcal{D}}[i \in S]$。于是，对每个 $S \in \mathcal{C}$，存在子集 $S' \subseteq S$，满足 $\Pr_{i\sim\mathcal{D}}[i \in S'] \geq (1 - \alpha)\Pr_{i\sim\mathcal{D}}[i \in S]$，而且对所有 $v \in \Lambda[0, 1]$，

$\left|\mathbf{E}_{i\sim S_v(x)\cap S'}\left[f_i - p_i^*\right]\right| \le \alpha.$

此外， λ -离散化使 f_i 的值“移动”至多 λ，所以总体而言， f^λ 是 $(\alpha+\lambda)$ -校准的。□

本节通过分析算法 1、说明如何利用小样本实现算法，来证明定理 2。定理 1 是定理 2 的一个推论。

A.1. 定理 2 的证明

算法 1 遍历每个可能的类别 S_v，如果 S_v 足够大，就查询预言机。算法持续搜索未校准的类别，直到 f 在所有足够大的类别上的猜测都收到“√”。由猜测并检验预言机的定义，若查询对某个类别 S_v 返回“√”，则 $\bar{v}$ 距离真值 $\mathbf{E}_{i\sim S_v}\left[p_i^*\right]$ 至多 $4\omega = \alpha$。因此，根据循环停止条件，让所有 $i \in \lambda(v)$ 都接收 $f_i = \bar{v}$ 的预测器，将在每个大类别上满足 α -校准。最后，算法把 f 更新为 λ -离散化形式，所以由引理 1， f 是 $(\mathcal{C}, \alpha+\lambda)$ -多重校准的。此外，终止所需更新次数是有界的。

引理 2。假设 $\alpha, \lambda > 0$， $\mathcal{C} \subseteq 2^X$，并且对所有 $S \in \mathcal{C}$ 有 $\Pr_{i\sim\mathcal{D}}[i \in S] \ge \gamma$。算法 1 至多接收 $O\left(1/\alpha^3\lambda\gamma\right)$ 个 $r \in [0,1]$ 的猜测并检验响应，以及至多 $O\left(|\mathcal{C}|/\alpha^4\lambda\gamma\right)$ 个 $r = \checkmark$ 的响应之后，返回 f。

证明。对 $S_v = \{i : f_i \in \lambda(v)\} \cap S$ 上的某个非“√”响应，由猜测并检验预言机的性质，可用平方误差给出每次更新进展的下界。令 $\delta_v = r - \bar{v}$ 表示 $i \in S_v$ 的更新幅度。

$$
\begin{aligned}
&\|p^* - f\|^2 - \|p^* - f'\|^2 \\
&= \Pr_{i\sim\mathcal{D}}[i \in S_v] \cdot \mathop{\mathbf{E}}_{i\sim S_v}\left[(p_i^* - f_i)^2 - (p_i^* - \pi_{[0,1]}(f_i + \delta_v))^2\right] \\
&\ge \beta \cdot \mathop{\mathbf{E}}_{i\sim S_v}\left[(p_i^* - f_i)^2 - (p_i^* - (f_i + \delta_v))^2\right] \\
&= \beta \cdot \mathop{\mathbf{E}}_{i\sim S_v}\left[2\cdot(p_i^* - f_i)\cdot\delta_v - \delta_v^2\right] \\
&= \beta \cdot \left(2\delta_v \cdot \mathop{\mathbf{E}}_{i\sim S_v}\left[p_i^* - f_i\right] - \delta_v^2\right)
\end{aligned}
$$

令 $\nu_v = \mathbf{E}_{i\sim S_v}\left[p_i^* - f_i\right]$，并对某个 $|\tau| \le \omega$ 写成 $\delta_v = \nu - \tau$，可以整理为

$$2(\nu-\tau)\nu - (\nu-\tau)^2 = \nu^2 - \tau^2.$$

根据猜测并检验预言机的保证， $\nu \ge 2\omega$；取 $\omega \le \alpha/4$，可见势函数的进展至少为 $\beta\Omega\left(\alpha^2\right)$，其中 $\beta = \Pr_{i\sim\mathcal{D}}\left[i \in S_v\right] \ge \alpha\lambda\gamma$。

因为 $\| p^* \|^2 \le 1$，最多进行 $O\left(1/\alpha^3\lambda\gamma\right)$ 次更新，这也给出了非“√”响应数量的上界。采用 λ -离散化后，每个阶段至多需要考虑 $|\mathcal{C}|/\lambda$ 个类别，因此至多收到 $O\left(|\mathcal{C}|/\alpha^3\lambda^2\gamma\right)$ 个“√”响应。□

因此得到如下定理。

定理。 对于 $\alpha, \lambda > 0$ 和 $\mathcal{C} \subseteq 2^{\mathcal{X}}$，如果所有 $S \in \mathcal{C}$ 都满足 $|S| \geq \gamma N$，则存在一个统计查询算法，在 $O\left(|\mathcal{C}|/\alpha^3\lambda^2\gamma\right)$ 次查询内，学习相对于 $\mathcal{C}$ 的 (α, λ) -多重校准预测器。

再次注意，我们的输出事实上是 $(\mathcal{C}, \alpha + \lambda)$ -多重校准的；因此取 $\lambda = \alpha$，便能在 $O\left(|\mathcal{C}|/\alpha^5\gamma\right)$ 次查询内获得 $(\mathcal{C}, 2\alpha)$ -多重校准预测器。

A.2. 利用随机样本回答猜测并检验查询

接下来说明，可以用随机样本集实现猜测并检验预言机，同时保证良好的泛化。由此可以把学习 $(\mathcal{C}, \alpha, \lambda)$ -多重校准预测器的统计查询算法转化为从样本学习的算法。一个朴素方法，是每当算法更新预测器就重新抽样。假设 $\mathcal{C}$ 中所有 S 都满足 $|S| \geq \gamma N$；令 $\beta = \alpha\lambda\gamma$。每次更新取 $n = \widetilde{O}\left(\log(|\mathcal{C}|)/\alpha^2\beta^2\right)$ 个样本即可保证泛化，从而总体样本复杂性为 $\widetilde{O}\left(\log(|\mathcal{C}|)/\alpha^4\beta^4\right)$。我们说明如何进一步改进。具体地，存在一个差分隐私算法，可以准确回答整条猜测并检验查询序列。利用差分隐私与自适应数据分析的已知联系，再结合我们的近似校准概念只需要相对加性误差这一观察，可以保证算法只需 $\widetilde{O}\left(\log(|\mathcal{C}|)/\alpha^{5/2}\beta^{3/2}\right)$ 个随机样本即可泛化。

算法 1 只通过猜测并检验预言机与样本交互。因此，为得到算法的差分隐私实现，只需给出预言机的差分隐私实现（Dwork & Roth, 2014）。

考虑算法 1 向猜测并检验预言机提出的查询序列。如果序列 $\langle (S_1, v_1, \omega_1), \ldots, (S_k, v_k, \omega_k)\rangle$ 的 k 次查询中，至多 m 次返回某个 $r \in [0, 1]$，其余均返回“√”，则称之为猜测并检验查询的 (k, m) -序列。假设我们知道所有查询最小绝对误差 $\beta = \min_{j\in[k]}\Pr_{i\sim\mathcal{D}}\left[i \in S_j\right]\omega_j$ 的一个下界。如果算法 $\mathcal{A}$ 的响应满足猜测并检验性质，其中用 X 上的经验估计

$$\widehat{p}_S(X) = \frac{|S|}{|S\cap X|}\sum_{i\in S\cap X} o_i$$

替代 $\mathbf{E}_{i\sim S}\left[p_i^*\right]$，就称 $\mathcal{A}$ 根据随机样本 X 回答查询 (S, v, ω)。

可以利用隐私乘法权重机制中的技术，以差分隐私方式回答这种序列。

引理 3（Hardt & Rothblum, 2010）。 假设 $\varepsilon, \delta, \omega, \xi > 0$，$X \sim \left(\mathcal{X}\times\{0, 1\}\right)^n$ 是 n 个随机样本。则存在 (ε, δ) -差分隐私算法 $\mathcal{A}$，只要

$$n = \Omega\left(\sqrt{\frac{\log(k/\xi)\, m\log(1/\delta)}{\varepsilon\beta^2}}\right),$$

就能相对于 $\mathcal{A}$ 的随机性，以至少 $1 - \xi$ 的概率，根据 X 回答任意最小绝对误差为 β 的猜测并检验查询 (k, m) -序列。

利用这一差分隐私算法，可以应用 Dwork et al. (2015a;b;c) 和 Bassily et al. (2016) 提出的基于隐私的泛化界，说明只需适度增加样本复杂性，就能够回答全部 k 个猜测并检验查询。

定理。 令 $s_k = \langle (S_1, v_1, \omega), \ldots, (S_k, v_k, \omega) \rangle$ 是猜测并检验查询的 (k, m) -序列，并且对所有 $j \in [k]$ 有 $\Pr_{i \sim \mathcal{D}}[i \in S_j] \geq \beta$。存在算法 $\mathcal{A}$，给定 n 个随机样本 $X \sim (\mathcal{X} \times \{0,1\})^n$，只要

$$n = \Omega\left(\frac{\log(|\mathcal{C}|/\alpha\beta\xi)}{\alpha^{5/2}\beta^{3/2}}\right),$$

就能相对于 $\mathcal{A}$ 的随机性和 X 的抽取，以至少 $1-\xi$ 的概率回答 s_k，使得对所有 $j \in [k]$，响应 $\mathcal{A}(S_j, v_j, \widehat{\omega_j}; X)$ 满足窗口 $\omega = \alpha/4$ 的猜测并检验性质。

这一定理意味着，渐近地，相比预先知道查询的情况，只需将样本复杂性增加 $\sqrt{1/\alpha\beta}$ 倍，就能够回答自适应选择的 k 个查询。该定理通过专门针对猜测并检验预言机的要求，调整 Bassily et al. (2016) 的主要“迁移”定理（定理 3.4）的证明，并应用引理 3 描述的差分隐私机制而得。结合这些定理、算法 1，以及 $\beta = \alpha\lambda\gamma$，就得到一个从随机样本学习 α -多重校准预测器的算法。

定理。 假设 $\alpha, \lambda, \gamma, \xi > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$，且所有 $S \in \mathcal{C}$ 满足 $\Pr_{i \sim \mathcal{D}}[i \in S] \geq \gamma$。存在一个算法，可以从

$$n = O\left(\frac{\log(|\mathcal{C}|/\alpha\lambda\gamma\xi)}{\alpha^4\lambda^{3/2}\gamma^{3/2}}\right)$$

个样本中，以至少 $1-\xi$ 的概率学习 $(\mathcal{C}, \alpha, \lambda)$ -多重校准预测器。

A.3. 算法 1 的运行时间分析

这里对用于在 $\mathcal{C}$ 上学习 $(\mathcal{C}, \alpha, \lambda)$ -校准预测器的算法 1 作高层次运行时间分析。引理 2 声称，算法 1 收敛前所需猜测并检验查询数的上界为 $O(|\mathcal{C}|/\alpha^3\lambda^2\gamma)$。这里正式论证，每次查询都能在随机样本模型中以很小的额外开销实现，从而得到算法总体运行时间的上界。因为集合和预测器都隐式地表示为电路，所以这一上界不能由前面的分析直接推出。

断言。 算法 1 的运行时间为 $O(|\mathcal{C}|\, t\, \mathrm{poly}(1/\alpha, 1/\lambda, 1/\gamma))$，其中 t 是判定 $S \in \mathcal{C}$ 的成员资格所需时间的上界。

证明。 与前文一样，令 $\beta = \alpha\lambda\gamma$。首先，对每个 $S \in \mathcal{C}$，需要为 $O(1/\lambda)$ 个 $v \in \Lambda[0,1]$ 分别计算 $S_v = \{i : f_i \in \lambda(v)\} \cap S$ 的概率 $\Pr_{i \sim \mathcal{D}}[i \in S_v]$。方法是抽取 $i \sim \mathcal{D}$，判断 $i \in S$ 是否成立；如果成立，则检查当前 f_i。每次成员资格查询至多需要 t 时间；由与电路规模上界相同的论证，每次计算 f_i 至多需要 $O(t/\alpha^2\beta)$ 时间。取得 $\widetilde{O}(1/\lambda\beta^2)$ 个样本之后，就能以常数概率识别哪些 S_v 的密度 $\Pr_{i \sim \mathcal{D}}[i \in S_v] \geq \beta$。此外，如果该概率较大，就可通过拒绝采样从 S_v 抽样，并计算当前预测器来估计 $\bar{v}$。类似地，为回答猜测并检验查询，我们根据来自 S_v 的样本估计查询的真实经验值，并根据 $\bar{v}$ 与 $\sum_{i \in S_v} o_i$ 估计值之间带噪声的比较来响应。这些估计都可在 $\mathrm{poly}(1/\alpha, 1/\beta)$ 时间内计算。随后，对预测器的每次更新可在与算术运算位复杂性成正比的时间内实现，其上界为 t。对每个 $S \in \mathcal{C}$ 重复这一过程，得到 $O(|\mathcal{C}|\, t\, \mathrm{poly}(1/\alpha, 1/\lambda, 1/\gamma))$ 的上界。最后应用引理 2 中猜测并检验查询次数的上界，即得断言。

A.4. 多重校准预测器的电路复杂性

算法的一个有趣推论，是关于表示多重校准预测器所需复杂性的定理。事实上，仅凭多重校准的定义，不能立即看出多重校准预测器应当有简洁描述；毕竟，$\mathcal{C}$ 可能包含很多集合。我们论证，决定 $\mathcal{C}$ 上多重校准预测器 f 的电路复杂性的有效参数，不是 $\mathcal{C}$ 的基数，而是描述集合 $S \in \mathcal{C}$ 所需的电路复杂性，以及 $\mathcal{C}$ 中子集的大小和近似程度。

利用引理 2，可以看到算法 1 实际上提供了构建电路的方法，将个体映射为所学多重校准预测器 f 的概率。假设所有 $S \in \mathcal{C}$ 的成员资格都可由有界复杂度电路族确定，即对每个 $S \in \mathcal{C}$，存在规模至多为 s 的 c_S，满足 $c_S(i) = 1$ 当且仅当 $i \in S$。于是，可以利用这一电路族构建实现 f 的电路。假设实数保留 $b \geq \log(1/\alpha)$ 位精度。

定理。 假设 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是集合族，对每个 $S \in \mathcal{C}$，存在规模为 s 的电路计算其成员资格，且 $\Pr_{i\sim\mathcal{D}}[i \in S] \geq \gamma$。对任意 $p^* : \mathcal{X} \to [0, 1]$，存在一个 $(\mathcal{C}, \alpha)$-多重校准预测器，可由规模为 $O(s/\alpha^4\gamma)$ 的电路实现。

证明。 我们描述如何构建电路 c_f，使其在输入 i 时，输出算法学得预测器的预测 f_i。将 c_f 初始化为对所有 $i \in \mathcal{X}$ 均有 $c_f(i) = 1/2$ 的常数函数。整个过程中，根据 c_f 的当前输出更新它。

考虑算法 1 的某次迭代：对于由 $c_S \in \mathcal{C}$ 描述的某个 S，依据类别 $S_v = S \cap \{i : f_i \in \lambda(v)\}$ 更新 f。当猜测并检验查询返回某个 $r = \widetilde{q}(S_v, \bar{v}, \omega) \in [0, 1]$ 时，就会发生这种更新。我们的目标是实现对 f（即对 c_f）的更新，使所有 $i \in S_v$ 的新值 $f_i = r$，而所有其他值保持不变。

方法是检验成员资格 $i \in S$，并另外检验当前值 $c_f(i) = v$；如果两项检验均通过，就将 $c_f(i)$ 输出更新为 r。具体而言，在电路中放入一份 c_S，并硬编码 v 和 $\delta_v = r - \bar{v}$；如果 $c_S(i) = 1$，且 $c_f(i)$ 当前值属于 $\lambda(v)$，则更新 $c_f(i)$，在当前 f_i 估计上加上硬编码的 δ_v；如果任一检验失败，$c_f(i)$ 保持不变。这一逻辑可通过加减法电路实现 λ 精度，其布尔电路规模为 $O(b)$。将每次迭代对应的更新电路串接起来。用算法 1 学习 $(\alpha/2, \alpha/2)$-多重校准预测器只需要 $O(\alpha^4\gamma)$ 次更新。由这一上界，得到最终电路规模的 $O(\alpha^4\gamma)$ 上界。

> 译注：本段最后两处 $O(\alpha^4\gamma)$ 为官方补充材料原文如此；与本节定理及前文更新次数的倒数形式不一致，译文保留原式，不擅自修正。

B. 多重校准与弱不可知学习

B.1. 由弱不可知学习实现多重校准

本节说明如何使用弱不可知学习器，解决算法 1 每次迭代出现的搜索问题：即找出能向多重校准推进的更新。形式上，证明如下定理。

定理。设 $\rho, \tau > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$ 为某概念类。如果 $\mathcal{C}$ 存在运行时间为 $T(|\mathcal{C}|, \rho, \tau)$ 的 (ρ, τ)-弱不可知学习器，那么只要 $\rho \le \alpha^2\lambda\gamma/2$ 且 $\tau = \mathrm{poly}(\alpha, \lambda, \gamma)$，就存在一个算法，在 $O\big(T(|\mathcal{C}|, \rho, \tau)\mathrm{poly}(1/\alpha, 1/\lambda, 1/\gamma)\big)$ 时间内，学得一个在 $\mathcal{C}' = \{S \in \mathcal{C} : \Pr_{i\sim\mathcal{D}}[i \in S] \ge \gamma\}$ 上为 $(\mathcal{C}, \alpha)$-多重校准的预测器。

也就是说，如果存在一个算法，在个体分布上，以实值函数类 $\mathcal{H} = \{h : \mathcal{X} \to [-1, 1]\}$ 为假设类，能够以关于 $\log(|\mathcal{C}|), 1/\rho, 1/\tau$ 的多项式时间学习概念类 $\mathcal{C}$，那么就存在一个算法，以关于 $\log(|\mathcal{C}|), 1/\alpha, 1/\lambda, 1/\gamma$ 的多项式时间，学习在 $\mathcal{C}$ 中大集合上 α-多重校准的预测器。为使归约表述清晰，我们不尝试优化样本复杂性或运行时间。事实上，确切的样本复杂性和运行时间，将很大程度上取决于特定类别 $\mathcal{C}$ 的弱学习保证有多强。

我们利用 $\mathcal{C}$ 的弱学习器来学习 (α, λ)-多重校准预测器，从而证明该定理。回顾算法 1：维护预测器 f，并迭代寻找某个集合 $S \in \mathcal{C}$，使 f 在某个值 v 对应的 $S_v = \{i : f_i \in \lambda(v)\} \cap S$ 上违反校准约束。实际上，引理 2 的证明揭示，我们并不局限于在 $S \in \mathcal{C}$ 的 S_v 上更新。只要存在未校准的类别 S_v，我们能够找到在与 p^* 的 ℓ_2^2 距离上取得非平凡进展的更新，即使更新不对应任何 $S \in \mathcal{C}$，也能够界定迭代次数，直到不再有未校准类别。我们说明，弱不可知学习器允许找到这样的更新。

证明。整个证明中，令 $\beta = \alpha\lambda\gamma$、$\rho = \alpha\beta/2$，并对某个常数 $d \ge 1$ 令 $\tau = \rho^d$。将预测器 f 初始化为对所有 $i \in \mathcal{X}$ 有 $f_i = 1/2$ 的常数函数。

考虑算法 1 更新预测器 f 之后立即出现的搜索问题。令 $\mathcal{X}_v = \{i : f_i \in \lambda(v)\}$ 为预测落入以 v 为中心的 λ-区间的个体集合。目标是确定是否存在 $v \in \Lambda[0, 1]$ 和 $S \in \mathcal{C}$，使 $\Pr_{i\sim\mathcal{D}}[i \in S_v] \ge \beta$，并且

$$\big|\mathbf{E}_{i\sim S_v}[f_i - p_i^*]\big| \ge \alpha|S_v|. \qquad (1)$$

我们把这一搜索问题归约为在分布 $\mathcal{D}$ 上对 $\mathcal{C}$ 的弱不可知学习问题。对任意 $v \in \Lambda[0, 1]$，如果 $\Pr_{i\sim\mathcal{D}}[i \in \mathcal{X}_v] < \beta$，显然不存在满足 $\Pr_{i\sim\mathcal{D}}[i \in S_v] \ge \beta$ 的未校准类别 S_v；对每个 $v \in \Lambda[0, 1]$，从 $\mathcal{X}$ 随机抽取 $O\big(\log(1/\beta\xi)/\beta\big)$ 次，检验 $\mathcal{X}_v$ 是否足够大。

假设 f 在整个 $\mathcal{X}$ 上满足 $\tau/4$-校准；如果并非如此，就可对违反要求的值、对所有 $i \in \mathcal{X}_v$ 更新 f_i，按算法 1 的分析取得 $\Omega(\tau^2)$ 的进展。

对每个 $v \in \Lambda[0, 1]$，考虑如下学习问题。对 $i \in \mathcal{X}_v$，令 $\Delta_i = (f_i - o_i)/2$；对 $i \in \mathcal{X}\backslash\mathcal{X}_v$，令 $\Delta_i = 0$。我们断言，如果某个 S_v 满足式 (1)，那么对 $i \sim \mathcal{D}_{\mathcal{X}}$，带标签样本 (i, Δ_i) 或 $(i, -\Delta_i)$ 至少一者满足 $\rho = \alpha\beta/4$ 的弱学习承诺。注意，假设学习器取得足够样本，使使用结果得到的经验估计集中于底层期望附近；为保持表述清晰，本节不尝试优化样本复杂性。

断言。令 $c_S : \mathcal{X} \to \{-1, 1\}$ 为某个 $S \in \mathcal{C}$ 对应的布尔函数。对于 $v \in \Lambda[0, 1]$，如果 $S_v = \{i : f_i \in \lambda(v)\} \cap S$ 满足 $\mathbf{E}_{i\sim S_v}[f_i - p_i^*] \ge \alpha$，则

$$\langle c_S, \Delta\rangle \ge \rho.$$

注意，当式 (1) 去掉绝对值仍成立时，断言的假设得到满足。如果式 (1) 在相反方向成立，则断言对 $-\Delta$ 成立，论证完全相同。

$$
\begin{aligned}
\langle c_S, \Delta \rangle &= \frac{1}{2} \mathop{\mathbf{E}}_{i \sim \mathcal{D}} [(f_i - o_i) \cdot c_S(i)] \\
&= \frac{1}{2} \mathop{\mathbf{Pr}}_{i \sim \mathcal{D}} [i \in \mathcal{X}_v] \cdot \mathop{\mathbf{E}}_{i \sim \mathcal{X}_v} [(f_i - o_i) \cdot c_S(i)] \\
&= \frac{1}{2} \mathop{\mathbf{Pr}}_{i \sim \mathcal{D}} [i \in S_v] \cdot \mathop{\mathbf{E}}_{i \sim S_v} [(f_i - o_i)] \\
&\quad - \frac{1}{2} \mathop{\mathbf{Pr}}_{i \sim \mathcal{D}} [i \in \mathcal{X}_v \setminus S_v] \cdot \mathop{\mathbf{E}}_{i \sim \mathcal{X}_v \setminus S_v} [(f_i - o_i)] \\
&\geq \mathop{\mathbf{Pr}}_{i \sim \mathcal{D}} [i \in S_v] \cdot \mathop{\mathbf{E}}_{i \sim S_v} [(f_i - o_i)] - \tau/4 \qquad (2) \\
&\geq \beta\alpha/2 - \tau/4 \qquad (3) \\
&\geq \rho
\end{aligned}
$$

其中，不等式 (2) 来自 f 在 $\mathcal{X}$ 上 $\tau/4$ -校准的假设；式 (3) 来自 $\Pr_{i \sim \mathcal{D}}[i \in S_v] \geq \beta$ 以及关于 $\mathbf{E}_{i \sim S_v}[f_i - p_i^*]$ 的假设。注意 $\tau \leq \rho$，即可得到断言。

因此，由于 (ρ, τ) -弱不可知学习的承诺满足，学习器返回某个 $h : \mathcal{X} \to [-1, 1]$，在 $\mathcal{X}_v$ 上与 $f - p^*$ 具有非平凡相关性。特别地，如果把 h 用作更新步骤，对 $\eta = \Omega(\tau)$ 更新 $f_i \to v - \eta h_i$（必要时投影到 $[0, 1]$），那么每次更新都保证在 $\| f - p^* \|^2$ 上取得 $\tau^2\beta$ 的进展。分析与算法 1 的分析相同。□

B.2. 由多重校准实现弱不可知学习

本节证明反向归约。特别地，我们说明：对于概念类 $\mathcal{C}$，如果存在高效算法，得到相对于 $\mathcal{C}' = \{S \in \mathcal{C} : |S| \geq \gamma N\}$ 的 α -多重校准预测器，那么就有高效算法可以回答 $\mathcal{C}$ 上的弱不可知学习查询。

定理。设 $\alpha, \gamma > 0$，$\mathcal{C} \subseteq 2^{\mathcal{X}}$ 为概念类。如果存在算法，在 $T(|\mathcal{C}|, \alpha, \gamma)$ 时间内学习 $\mathcal{C}' = \{S \in \mathcal{C} : \Pr_{i \sim \mathcal{D}}[i \in S] \geq \gamma\}$ 上的 α -多重校准预测器，那么对任意满足 $\tau \leq \min\{\rho - 2\gamma, \rho/4 - 4\alpha\}$ 的 $\rho, \tau > 0$，可在 $O(T(|\mathcal{C}|, \alpha, \gamma)\mathrm{poly}(1/\tau))$ 时间内实现 $\mathcal{C}$ 的 (ρ, τ) -弱不可知学习器。

证明。假设希望利用从 $y \in [-1, 1]^N$ 抽取的观测，对 $\mathcal{C}$ 进行弱不可知学习。假设存在 $c_S \in \mathcal{C}$，使 $\langle c_S, y \rangle > \rho$。

需要处理两种情况。首先，假设 c_S 的支撑很小，即对应的 $S \in \mathcal{C}$ 满足 $|S| < \gamma$。那么 y 与对所有 $i \in \mathcal{X}$ 均为 $h(i) = -1$ 的常数假设之间，相关性至少为 $\rho - 2\gamma$。因此，对 $\tau < \rho - 2\gamma$，如果 c_S 支撑很小，就可以返回假设 -1。通过随机抽样，可在 $\mathrm{poly}(1/\tau)\log(1/\xi)$ 时间内，检验常数假设是否与 y 足够相关，成功概率至少为 $1 - \xi$。

接下来，假设 $|\mathbf{E}_{i\sim\mathcal{X}}[y_i]| < 2\omega$。由同样论证可知，$\Pr_{i\sim\mathcal{D}}[i \in S]\mathbf{E}_{i\sim S}[y_i] > \rho/2 - \omega$。假设在标签 y 上学得相对于 $\mathcal{C}' = \mathcal{C}\cup\{\mathcal{X}\}$ 的 α-多重校准预测器 f。这意味着，存在 $\mathcal{X}' \subseteq \mathcal{X}$，满足 $\Pr_{i\sim\mathcal{D}}[i \in \mathcal{X}'] \geq 1 - \alpha$，且对所有 $v \in [-1, 1]$，有 $v - \alpha \leq \mathbf{E}_{i\sim\mathcal{X}'_v}[y_i] \leq v + \alpha$。进而得到

$$\mathrm{sgn}(v)\mathbf{E}_{i\sim\mathcal{X}'_v}[y_i] \geq |v| - \alpha. \qquad (4)$$

然后令假设 $h^{(f)}$ 定义为 $h_i^{(f)} = \mathrm{sgn}(f_i)$。考虑其与 y 的内积。

$$\begin{aligned}
\langle h^{(f)}, y\rangle &= \mathop{\mathbf{E}}_{i\in\mathcal{X}}[h_i^{(f)} \cdot y_i] && (5)\\
&= \sum_{v\in[-1,1]} \mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i \in \mathcal{X}_v] \cdot \mathop{\mathbf{E}}_{i\in\mathcal{X}_v}[h_i^{(f)} \cdot y_i] && (6)\\
&\geq \sum_{v\in[-1,1]} \mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i \in \mathcal{X}_v] \cdot \mathrm{sgn}(v) \cdot \mathop{\mathbf{E}}_{i\in\mathcal{X}'_v}[y_i] - \alpha && (7)\\
&\geq \sum_{v\in[-1,1]} \mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i \in \mathcal{X}_v] \cdot |v| - 2\alpha && (8)\\
&\geq \sum_{v\in[-1,1]} \mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i \in \mathcal{X}'_v] \cdot \left|\mathop{\mathbf{E}}_{i\sim S'_v}[y_i]\right| - 3\alpha && (9)\\
&\geq \mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i \in S] \cdot \mathop{\mathbf{E}}_{i\sim S}[y_i] - 4\alpha && (10)\\
&\geq \frac{\rho}{2} - \omega - 4\alpha && (11)
\end{aligned}$$

最初的等式来自 $h^{(f)}$ 的定义；式 (7) 来自 $\mathcal{X}'$ 的选择以及 α-多重校准；式 (8) 对每个 $v \in [-1, 1]$ 应用式 (4)；式 (9) 对适当选择的 $S' \subseteq S$ 使用 α-多重校准，以 v 替代 S'_v 上 y 的经验均值；式 (10) 来自三角不等式；式 (11) 来自关于 $\mathbf{E}_{i\sim S}[y_i]$ 的假定不等式。

因此，由于选择 $\omega = \rho/4$，对于任何 $\tau \leq \rho/4 - 4\alpha$，$h^{(f)}$ 都满足 (ρ, τ)-弱不可知学习的保证。□

C. 类内最优预测

定理（类内最优预测）。 假设 $\mathcal{C} \subseteq 2^{\mathcal{X}}$ 是 $\mathcal{X}$ 的子集族， $\mathcal{H}$ 是预测器集合。那么存在一个在 $\mathcal{C}$ 上 α-多重校准的预测器 f，满足

$$\| f - p^* \|^2 - \| h^* - p^* \|^2 < 6\alpha,$$

其中 $h^* = \operatorname{argmin}_{h \in \mathcal{H}} \| h - p^* \|^2$。进一步，假设对所有 $S \in \mathcal{C}$ 有 $\Pr_{i \sim \mathcal{D}}[i \in S] \geq \gamma$，且 $S \in \mathcal{C}$ 的成员资格与 $h \in \mathcal{H}$ 均可由规模至多 s 的电路计算，则 f 可以由规模至多 $O\left(s/\alpha^4\gamma\right)$ 的电路计算。

定理的证明实际上揭示了更强的结论：如果 f 在集合 $\mathcal{S}(\mathcal{H})$ 上校准，那么对每个类别 $S_v(h) \in \mathcal{S}(\mathcal{H})$，只要 f 在该类别上显著不同于 h，即 $\mathbf{E}_{i \in S_v(h)}\left[\left(h_i - f_i\right)^2\right]$ 很大，则 f 相比 h，实际上在该类别上取得了显著更小的预测误差。引理 4 对此作形式化陈述。

引理 4。 设 g 为任意预测器，令 $\mathcal{S}(g) = \{S_v(g)\}_{v \in \Lambda[0,1]}$。设 f 为任意 $(\mathcal{S}(g), \alpha)$-多重校准预测器。那么对 $v \in \Lambda[0, 1]$，

$$\mathbf{E}_{i \sim S_v(g)}\left[\left(g_i - f_i\right)^2\right] - (4\alpha + \lambda) \leq \mathbf{E}_{i \sim S_v(g)}\left[\left(g_i - p_i^*\right)^2\right] - \mathbf{E}_{i \sim S_v(g)}\left[\left(f_i - p_i^*\right)^2\right].$$

因此，

$$\| g - p^* \|^2 - \| f - p^* \|^2 \geq \| g - f \|^2 - (4\alpha + \lambda).$$

这一引理说明，在预测器的类别上进行校准，不仅防止平方预测误差恶化超过一个小的加性近似量，而且保证：如果校准显著改变了某个类别上的预测器，那么这种改变代表向该类别的真实底层概率取得显著进展。假定引理 4 成立，即可得到定理。

证明。 注意，如果 f 在 $\mathcal{C}$ 上 α-多重校准，则它在任意 $\mathcal{C}' \subseteq \mathcal{C}$ 上也 α-多重校准。考虑对前文定义的集合族 $\mathcal{C} \cup \mathcal{S}(\mathcal{H})$ 强制校准。如果 f 是 $(\mathcal{C} \cup \mathcal{S}(\mathcal{H}), \alpha, \lambda)$-校准的，那么对所有 $h \in \mathcal{H}$，尤其对 h^*，它都是 $\left(\{S_v(h)\}_{v \in \Lambda[0,1]}, \alpha, \lambda\right)$-多重校准的。由引理 4 以及平方差非负，得到

$$\| h^* - p^* \|^2 - \| f - p^* \|^2 \geq \| f - h^* \|^2 - (4\alpha + \lambda) \geq -(4\alpha + \lambda).$$

该不等式足以证明准确性保证；不过，为同时保证预测器 f 能由小电路实现，需要更谨慎。具体而言，校准时忽略所有满足 $|S_v(h)| < \lambda\alpha N$ 的 $S_v(h)$。由于进行了 λ-离散化，至多存在 $1/\lambda$ 个类别，因此排除满足 $|S_v(h)| < \alpha\lambda N$ 的集合，至多额外引入 αN 的误差。取 $\lambda = \alpha$，可将平方预测误差之差界定为 $\| f - p^* \|^2 - \| h^* - p^* \|^2 \leq 6\alpha N$。最后，因为希望校准的集合基数至少为 $\alpha^2\gamma N$，应用引理 2 即得电路复杂性界。□

下面证明引理 4。该引理通过展开平方预测误差之差，并使用 α-校准的定义得到。

引理 4 的证明。令 S_{vu} 表示满足 $g_i \in \lambda(v)$ 且 $f_i = u$ 的个体 i 的集合。假设 f 在 $\mathcal{S}(g)$ 上 α-校准，则对每个 $S_v(g) \in \mathcal{S}(g)$，存在子集 $S'_v(g) \subseteq S_v(g)$，满足 $\Pr_{i\sim\mathcal{D}}[i \in S'_v(g)] \geq (1-\alpha)\Pr_{i\sim\mathcal{D}}[i \in S_v(y)]$，在该子集上 f 的预测近似正确。具体地，令 $S'_{vu} = S'_v(g) \cap S_u(f)$；若 f 相对于 $S_v(g)$ 是 α-校准的，就保证对所有 $u \in [0, 1]$，

$$\left|\mathbf{E}_{i\sim S'_{vu}}[p_i^* - u]\right| \leq \alpha. \qquad (12)$$

利用这一事实，以及 $S_v(g)$ 中剩余 α 比例部分对 $S_v(g)$ 上平方误差贡献至多 α，可将 g 与 f 在 $S_v(g)$ 上的平方误差之差写成：

$$\begin{aligned}
&\mathop{\mathbf{E}}_{i\sim S_v(g)}[(g_i - p_i^*)^2] - \mathop{\mathbf{E}}_{i\sim S_v(g)}[(f_i - p_i^*)^2] \\
&= \mathop{\mathbf{E}}_{i\sim S_v(g)}[(v - p_i^* + (g_i - v))^2] - \mathop{\mathbf{E}}_{i\sim S_v(g)}[(f_i - p_i^*)^2] \\
&\geq \mathop{\mathbf{E}}_{i\sim S_v(g)}[(v - p_i^*)^2] - \mathop{\mathbf{E}}_{i\sim S_v(g)}[(f_i - p_i^*)^2] \\
&\quad + 2\mathop{\mathbf{E}}_{i\sim S_v(g)}[(v - p_i^*)(g_i - v)] \\
&\geq \mathop{\mathbf{E}}_{i\sim S_v(g)}[(2(p_i^* - v)(f_i - v) - (f_i - v)^2)] - \lambda. \qquad (13)
\end{aligned}$$

式 (13) 利用如下观察：$(g_i - v)^2 \geq 0$；如果 $g_i \in \lambda(v)$，则 $|g_i - v| \leq \lambda/2$，而 $|v - p_i^*|$ 显然以 1 为上界。第一项可如下界定。

$$\begin{aligned}
&\mathop{\mathbf{E}}_{i\sim S_v(g)}[(p_i^* - v)(f_i - v)] \\
&= \sum_{u\in[0,1]} \mathop{\mathbf{Pr}}_{i\sim\mathcal{S}_v}[i \in S_{vu}] \cdot \mathop{\mathbf{E}}_{i\sim S_{vu}}[(p_i^* - v)(u - v)]
\end{aligned}$$

然后，对于每个 $u \in [0, 1]$，

$$
\begin{aligned}
&\mathop{\mathbf{E}}_{i\sim S_{vu}}[(p_i^*-v)(u-v)]\\
&=(u-v)\mathop{\mathbf{E}}_{i\sim S_{vu}}[p_i^*-v]\\
&=(u-v)\mathop{\mathbf{E}}_{i\sim S_{vu}}[u-v+p_i^*-u]\\
&=(u-v)^2+(u-v)\mathop{\mathbf{E}}_{i\sim S_{vu}}[p_i^*-u].
\end{aligned}
$$

此时注意 $|u-v|\le 1$。因此，可以用期望绝对值的负值，界定 S_{vu} 上期望的贡献：

$$
\begin{aligned}
&\ge (u-v)^2-|u-v|\cdot\left|\mathop{\mathbf{E}}_{i\sim S_{vu}}[p_i^*-u]\right|\\
&\ge (u-v)^2-(1-\alpha)\cdot\left|\mathop{\mathbf{E}}_{i\sim S'_{vu}}[p_i^*-u]\right|-\alpha\\
&\ge (u-v)^2-2\alpha
\end{aligned}
$$

对 $u\in[0,1]$ 求和，

$$
\begin{aligned}
&\sum_{u\in[0,1]}\mathop{\mathbf{Pr}}_{i\sim\mathcal{D}}[i\in S_{vu}]\cdot\left((u-v)^2-2\alpha\right)\\
&=\mathop{\mathbf{E}}_{i\sim S_v(g)}[(v-f_i)^2]-2\alpha,
\end{aligned}
$$

这里使用 α-校准并应用式 (12)，对 S_{vu} 上的求和进行界定。把这一界代入式 (13)，得到

$$
\begin{aligned}
&\mathop{\mathbf{E}}_{i\sim S_v(g)}\left[(g_i-p_i^*)^2-(f_i-p_i^*)^2\right]\\
&\geq 2\left(\mathop{\mathbf{E}}_{i\sim S_v(g)}[(v-f_i^*)^2]-2\alpha\right)-\lambda-\mathop{\mathbf{E}}_{i\sim S_v(g)}[(v-f_i)^2]\\
&=\mathop{\mathbf{E}}_{i\in S_v(g)}[(v-f_i^*)^2]-(4\alpha-\lambda).
\end{aligned}
$$

对 $v\in[0,1]$ 求和，可以得出

$$
\|g-p^*\|^2-\|f-p^*\|^2\geq\|f-g\|^2-(4\alpha-\lambda)
$$

即证得该引理。□

> 译注：上述证明按官方补充材料保留，包括 $S_v(x)$、$S_v(y)$、f_i^*、ρ 的两种取值、概率与基数/ N 的混用，以及结尾的 $4\alpha-\lambda$（与引理陈述的 $4\alpha+\lambda$ 不一致）。复杂推导以原文公式图像保留，避免将原稿不一致误改为译者推导。本译文并未声称修复这些原文问题。

补充材料参考文献

- Bassily, R., Nissim, K., Smith, A., Steinke, T., Stemmer, U., and Ullman, J. 自适应数据分析的算法稳定性。见 Proceedings of the 48th Annual ACM SIGACT Symposium on Theory of Computing，1046–1059 页。ACM，2016。
- Dwork, C. and Roth, A. 差分隐私的算法基础。Foundations and Trends® in Theoretical Computer Science，9(3–4):211–407，2014。
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. 自适应数据分析与留出集复用中的泛化。见 Advances in Neural Information Processing Systems，2350–2358 页，2015a。
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. 可复用留出集：在自适应数据分析中保持有效性。Science，349(6248):636–638，2015b。
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., and Roth, A. L. 在自适应数据分析中保持统计有效性。见 Proceedings of the forty-seventh annual ACM symposium on Theory of computing，117–126 页。ACM，2015c。
- Hardt, M. and Rothblum, G. N. 用于隐私保护数据分析的乘法权重机制。见 Foundations of Computer Science (FOCS), 2010 51st Annual IEEE Symposium on，61–70 页。IEEE，2010。