标签偏移与块状模态缺失下的多模态域适应

Multimodal domain adaptation under label shift and blockwise missing modalities

非官方中文全文译文 · arXiv:2608.01282v1 · 2026年8月2日

Zebin Wang[1]、Ziang Dou[2]、Molei Liu[2]、Tianxi Cai[1]

[1] 美国哈佛大学生物统计学系，马萨诸塞州波士顿 02115。
[2] 中国北京大学医学部生物统计学系，北京 100083。

来源与许可。 原作：arXiv 版本页面，原版 PDF。原作和本译文依据 Creative Commons 署名 4.0 国际许可（CC BY 4.0） 提供。翻译与重新排版：OpenAI ChatGPT，2026年10月26日。本译文不是作者认可的官方版本；译文的任何差错不应归于原作者。改动包括英文叙述、标题、图表说明及参考文献题名的中文翻译和版式重排；原始图表、显示公式及其编号以原版裁图保留，图内英文和表头另附中文释义。文献作者、刊名、卷页、年份、标识符和精确数学记号保留。原文全部正文、补充材料、证明和参考文献均在本译文范围内。

版本核对。 本次从官方链接取得的49页 v1 PDF 与仓库副本逐字节相同；SHA-256：`898072a89d7d75b15a9b33a61aaec8a3f21fc184692b7fc88c87abc4cf0a73ea`。三个原始图及图注已逐一检查，未发现第三方权利排除说明。原始 PDF 未作修改。

摘要

多模态域适应利用带标签的源数据集预测无标签目标人群的结局。不同来源可能观测不同的模态子集，并与目标人群存在分布偏移。在此情况下，用于对齐的跨模态模式依赖于结局分布，因此对未经调整的源数据直接对齐，可能错误表征目标人群。然而，当目标样本没有标签、且缺失的模态块使简单合并不可行时，结局分布的偏移无法直接测量。我们提出一种以参考模态为锚的域适应方法：利用在每个源域和目标域中均被观测的参考模态，估计目标结局分布，并在对齐之前对源观测重新加权。随后，将辅助模态映射到由目标域定义的共同表示；该表示由目标域内的典型相关分析（CCA）获得，并通过岭回归映射在各源域中重现。结局信息通过对齐表示上的密度比模型迁移。当源域的金标准标签稀疏时，我们进一步提出替代标签辅助方法，以实现稳健的域适应。我们建立了目标 CCA 与源岭映射的统一旋转匹配结果，并证明目标条件结局分布的一致性。模拟研究和肾细胞癌（RCC）应用表明，在分布偏移和块状模态缺失下，该方法能改善校准并保持稳定预测。

关键词： 块状缺失；域适应；标签偏移；多模态数据融合；数据对齐；替代变量。

1 引言

1.1 背景

多模态生物医学研究日益结合结构化电子健康记录（EHR）、临床文本、放射学报告、医学图像和分子测量（Lahat 等，2015；Baltrušaitis 等，2019）。但在实践中，这些数据往往跨医院、队列或日历时期汇集，而不是按照共同方案采集。某家医院可能收集影像而没有分子数据，另一家则可能只有结构化记录和临床文本。在同一家医院，新模态也可能只在较晚时期才可获得。因此，缺失常常以整个模态块的形式出现，并在不同来源之间存在系统性差异。同时，疾病复发等金标准结局可能需要专科医师审核和长期随访。这类结局在某些外部或历史源队列中可以观测，却在需要预测的目标人群中不可获得。于是自然产生了多模态域适应问题：利用带标签、部分观测的源数据，预测无标签目标人群的结局。

另一项困难是分布偏移。不同机构或不同时期的疾病患病率、患者构成和转诊模式可能不同。本文关注标签偏移，即源与目标人群的结局分布不同，而给定类别的特征分布保持稳定（Lipton 等，2018；Garg 等，2020）。对于多元结局，这既可能涉及各结局出现频率的变化，也可能涉及它们依赖关系的变化。即使给定结局的测量分布稳定，不同的结局混合比例也会改变特征边际分布和模态之间的关联。因此，直接合并源数据可能产生校准不良的目标预测。

核心挑战在于，标签偏移与块状缺失不能分开处理。不同来源观测不同的数据块，而且可能用不同坐标表示相同的潜在信息，辅助模态因而无法直接合并。但是，利用未经调整的源数据对齐这些模态同样可能产生误导，因为每个源域的跨模态模式反映的是其自身结局分布，而不是目标分布。因此，在学习与目标相关的对齐之前，必须考虑源到目标的分布偏移，而直接调整所需的目标标签又不可获得。我们研究的情形是：一个参考模态（例如编码和结构化 EHR 特征）在所有域中都可观测，辅助模态只在部分域中可观测，且源域金标准标签可能稀疏。

1.2 相关文献

本研究位于域适应与块状缺失协变量的数据整合两类文献的交汇处。域适应的许多统计研究以一个协变量向量为起点，其坐标在源和目标人群中具有相同含义，并在二者中均被观测。在协变量偏移下，重要性加权似然和增广估计方程在保留稳定条件结局模型的同时，处理协变量分布的变化（Shimodaira，2000；Liu 等，2023）。较新的半参数研究针对更广泛的分布偏移，提出了目标风险的高效和多重稳健估计量（Qiu 等，2024）。在标签偏移下，结局分布随人群变化，而给定结局的协变量分布保持稳定。Lee 等（2025a）在此条件下提出目标参数的双重灵活估计；Lee 等（2025b）研究基于源到目标结局密度比的半参数高效推断。标签偏移分类方法通过期望最大化、矩匹配或基于似然的校准估计目标类别比例（Saerens 等，2002；Lipton 等，2018；Garg 等，2020）。多源方法也把标签偏移修正与表示或分布对齐相结合。Redko 等（2019）联合估计目标类别比例与最优传输耦合；Li 等（2019）在对抗式表示学习中处理目标偏移，并把构造扩展到多域；Shui 等（2021）依据语义条件分布的相似性聚合多个发生目标偏移的源域；Xu 等（2025）研究源污染下的稳健多源标签偏移适应。这些工作表明，标签偏移修正不必只是固定表示之后的事后校准。然而，它们仍假定各域具有共同的可观测输入或表示空间，没有处理特定源域缺失整个模态块，以及由此产生的不可比较辅助坐标的对齐需求。

另一支统计文献研究块状缺失协变量的数据整合。结构化矩阵补全和整合因子方法从相互重叠的数据块中恢复低维信号（Cai 等，2016；Zhu 等，2020；Zhou 等，2023）。其他方法直接从观测块构造预测或推断程序，采用稀疏预测、多重插补、估计方程、投影或影响函数分解（Yu 等，2020；Xue 和

Qu，2021；Song 等，2024；Berrett，2024；Li 等，2024）。近期研究又通过多任务学习或源自适应表示检索处理异质来源（Sui 等，2026；Xu 和 Qu，2025）。针对块状缺失数据的最新表示学习方法包括 Liu 等（2026）的基于锚点的主成分方法，该方法在块状缺失和信号异质性下对齐组特异子空间；以及 Yu 等（2026）的 MOSAIC 框架，它学习共享与模态特异表示，在重叠缺失模式间借用信息，并使用焦点模式中的带标签个体校准最终预测器。这些工作处理的是表示恢复或模式特异的监督预测，而非标签偏移下对无标签目标人群的适应。特别地，它们没有利用从无标签目标数据推断出的目标结局混合分布来重加权跨模态对齐。在标签偏移下，源域跨模态关联对源结局分布求平均，因此可能不同于相应的目标关联。在修正这种差异之前学习的对齐，可能强调源特异关系，而非与目标有关的关系。

Zhao 等（2025）研究了多源多模态域适应本身，在协变量偏移下联合对齐模态和域。他们把每个域置于相同的多模态输入空间中，不允许某些源域完全缺少整种模态。Fan 等（2023）先从不完整视图学习共同潜在表示，再估计标签偏移权重并微调重加权分类器；其设定并未处理特定源域缺失整个模态块，或不同来源的辅助坐标不可比较的问题。Sui 等（2026）对某一任务完全缺失的数据源块进行插补，并从已观测任务响应学习共享与任务特异的特征响应映射。他们的监督多任务目标不包含无标签目标的结局混合分布，也不包含跨模态对齐之前的目标混合分布加权。本文同时研究三者：标签偏移下的无标签目标域、特定来源缺失整个模态块，以及将源观测重加权到目标结局混合分布后对不可比较辅助坐标进行对齐。跨域共享的参考模态识别目标结局混合分布，并支持面向目标的对齐。该框架既不要求共享的多模态输入空间，也不要求单一的共同潜在表示。

1.3 贡献

我们为标签偏移与块状模态缺失下的多模态域适应建立参考锚定框架。每个域中均可观测的参考模态识别由目标定义的锚点。参考模态不必是预测能力最强的数据块；其作用是提供识别目标结局分布所需的共同可观测结构，并连接无法在源域之间直接比较的辅助模态。贡献有三方面。

第一，我们提出面向目标的跨模态对齐识别策略。所有域均观测的参考模态提供可观测锚点，从而不必要求所有模态共享单一潜在表示。关键在于，源观测在对齐之前就重加权到目标结局分布，因为标签偏移会改变用于构造表示的边际跨模态关联。“先加权、后对齐”原则区别于两类既有方法：一类在共同输入空间中修正标签偏移，另一类在不使用目标结局混合分布的情况下对齐不完整模态。

第二，我们建立所得目标预测器的识别性和一致性。虽然降维和对齐矩阵依赖任意坐标选择，但我们证明所有目标和源对齐特征可在相差同一个旋转的意义下恢复。这消除了表示歧义；再结合单独的对齐似然比识别条件，便得到目标条件结局模型。

第三，我们利用替代变量进行校准和对齐，将框架扩展到源域金标准标签稀疏的情形，但不把替代结局当作估计对象。模拟研究和肾细胞癌应用显示，在标签偏移与模态块可用性差异同时存在时，目标校准和参考锚定对齐具有优势。

2 模型设定与记号

设有一个目标域，索引为 $m = 0$，以及 M 个源域，索引为 $m = 1, \ldots, M$。域 m 包含个体 $i = 1, \ldots, n_m$。共有 K 个模态，模态1为参考模态，模态 $2, \ldots, K$ 为辅助模态。记 $\mathcal{A}_m \subseteq \{1, \ldots, K\}$ 为域 m 中可观测的模态集合，所有域均有 $1 \in \mathcal{A}_m$。在主要设定中，目标域观测所分析的全部模态，因此限定到所选模态集合后，$\mathcal{A}_0 = \{1, \ldots, K\}$。掩蔽分析均相对于该所选集合解释。本文中，粗体小写表示个体层面的列向量，粗体大写表示按行堆叠后的矩阵。

对于域 m 中个体 i，模态 $k \in \mathcal{A}_m$ 的观测特征为 $\mathbf{x}_{k,i}^{(m)} \in \mathbb{R}^{d_k}$，数据矩阵为 $\mathbf{X}_k^{(m)} = \left(\mathbf{x}_{k,1}^{(m)}, \ldots, \mathbf{x}_{k,n_m}^{(m)}\right)^{\mathrm{T}}$。金标准结局为 $\mathbf{y}_i^{(m)} \in \mathcal{Y} = \{0, 1\}^d$。源域中，个体集合 $\mathcal{I}_m \subseteq \{1, \ldots, n_m\}$ 的金标准结局可观测，而拟合期间 $\mathcal{I}_0 = \varnothing$。可获得的替代证据记为 $\mathbf{s}_i^{(m)}$。全文中，$\mathcal{O}(q)$ 为 $q \times q$ 正交矩阵群；$\|\cdot\|_2$ 和 $\|\cdot\|_{\mathrm{F}}$ 分别为欧氏范数和 Frobenius 范数。

在域 m 中，金标准结局在有限状态空间 $\mathcal{Y}$ 上服从 $\mathbf{y}^{(m)} \sim \rho_y\left(\cdot; \theta^{(m)}\right)$。一个工作模型是 Ising 模型（Wainwright 和 Jordan，2008）：

$$\rho_y(\mathbf{y}; \boldsymbol{\theta}^{(m)}) = \frac{1}{C(\boldsymbol{\theta}^{(m)})} \exp\left\{ \sum_{1 \le a < b \le d} \theta_{ab}^{(m)} (2y_a - 1)(2y_b - 1) + \sum_{a=1}^{d} \theta_{aa}^{(m)} (2y_a - 1) \right\}. \tag{1}$$

参数 $\theta^{(m)}$ 可以跨域变化。我们把这种分布变化称为标签偏移。$d = 1$ 时即通常的类别先验偏移；$d > 1$ 时允许结局边际患病率及结局分量之间的依赖关系均发生变化。域特异模态载荷和模态块缺失不称为标签偏移，而由表示及对齐部分处理。

工作表示含有潜在参考因子 $\widetilde{\mathbf{u}}_i^{(m)} \in \mathbb{R}^h$ 和潜在辅助因子 $\widetilde{\mathbf{v}}_i^{(m)} \in \mathbb{R}^h$。给定结局，

$$\widetilde{\mathbf{u}}_i^{(m)} = \psi_u(\mathbf{y}_i^{(m)}) + \boldsymbol{\xi}_{u,i}^{(m)}, \qquad \widetilde{\mathbf{v}}_i^{(m)} = \psi_v(\mathbf{y}_i^{(m)}) + \boldsymbol{\xi}_{v,i}^{(m)},$$

其中噪声独立于 $\mathbf{y}_i^{(m)}$。辅助模态 $k \ge 2$ 仅观测坐标集合 $\mathcal{H}_k \subseteq \{1, \ldots, h\}$，并有 $\widetilde{\mathbf{v}}_{k,i}^{(m)} = \widetilde{\mathbf{v}}_{i,\mathcal{H}_k}^{(m)} \in \mathbb{R}^{\ell_k}$，$\ell_k = |\mathcal{H}_k|$。观测特征满足

$$\mathbf{x}_{1,i}^{(m)} = \mathbf{L}_1 \widetilde{\mathbf{u}}_i^{(m)} + \boldsymbol{\zeta}_{1,i}^{(m)}, \qquad \mathbf{x}_{k,i}^{(m)} = \mathbf{L}_k^{(m)} \widetilde{\mathbf{v}}_{k,i}^{(m)} + \boldsymbol{\zeta}_{k,i}^{(m)}, \quad k = 2, \ldots, K,$$

其中 $\mathbf{L}_1^{\mathrm{T}} \mathbf{L}_1 = \mathbf{I}_h$，$\{\mathbf{L}_k^{(m)}\}^{\mathrm{T}} \mathbf{L}_k^{(m)} = \mathbf{I}_{\ell_k}$。参考载荷跨域共享，辅助载荷则可随域而异；匹配部分处理的就是这种载荷异质性。

替代变量被视为关于金标准结局的证据。使用替代变量时，工作桥接条件为

$$\mathbf{s}_i^{(m)} \perp\!\!\!\perp \{\mathbf{x}_{k,i}^{(m)} : k \in \mathcal{A}_m\} \mid \mathbf{y}_i^{(m)}. \tag{2}$$

预测目标是未观测金标准结局的目标域条件分布。下面的理论研究给定保留的对齐表示时的该分布。当表示对结局充分时，它与全特征风险 $P\{\mathbf{y}_i^{(0)} = \mathbf{y} \mid \mathbf{x}_{k,i}^{(0)},\ k \in \mathcal{A}_0,\ \mathbf{s}_i^{(0)}\}$ 相同。若验证数据含目标金标准结局，则拟合时掩蔽，仅用于最终评价。

3 方法

3.1 概览 表示 匹配与迁移

所提程序分四阶段。首先，对每个观测模态应用预先指定的无监督表示学习方法，得到低维得分表示。其次，使用所有域均观测的参考得分，估计目标结局分布及相应标签偏移权重。第三，在对齐之前引入这些权重：在目标域拟合的 CCA 定义参考侧锚点，加权岭回归把源域观测到的辅助块映射到共同的目标锚定坐标系。第四，将对齐坐标获得的似然比估计与估计的目标结局分布结合，估计目标条件结局分布。当源域金标准结局稀疏或不可获得时，可选的替代变量部分提供工作结局状态概率，用于构造对齐权重和估计似然比。若目标替代测量可获得，也可作为额外结局证据。图1概括了四个阶段及可选的替代变量辅助路径。

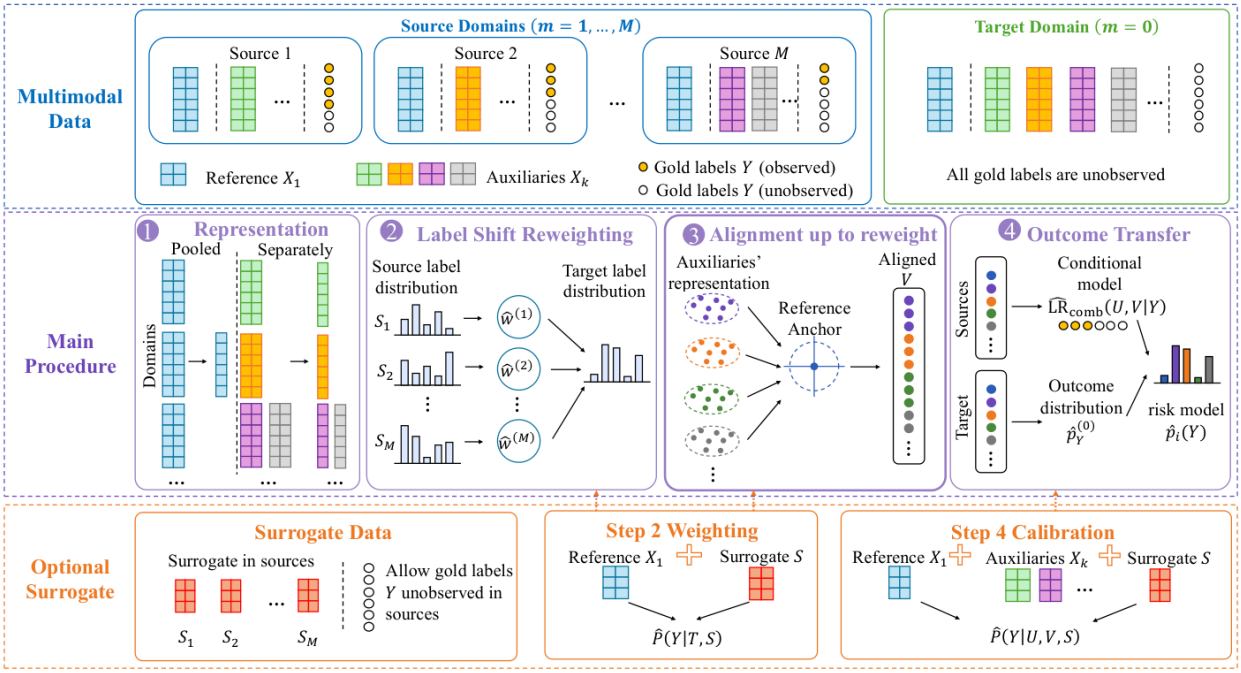


图1。 所提出的参考锚定多模态域适应程序的完整工作流程。图内文字：Source Domains＝源域；Target Domain＝目标域；Multimodal Data＝多模态数据；Reference＝参考；Auxiliaries＝辅助模态；Gold labels observed/unobserved＝金标准标签已观测/未观测；All gold labels are unobserved＝所有金标准标签均未观测；Main Procedure＝主要程序；Representation＝表示；Pooled＝合并；Separately＝分别；Domains＝域；Label Shift Reweighting＝标签偏移重加权；Source/Target label distribution＝源/目标标签分布；Alignment up to reweight＝重加权后对齐；Reference Anchor＝参考锚点；Aligned＝对齐后；Outcome Transfer＝结局迁移；Conditional model＝条件模型；Outcome distribution＝结局分布；risk model＝风险模型；Optional Surrogate＝可选替代变量；Surrogate Data＝替代数据；Surrogate in sources＝源域替代变量；Allow gold labels unobserved in sources＝允许源域金标准标签未观测；Step 2 Weighting＝步骤2加权；Step 4 Calibration＝步骤4校准。

3.2 表示学习与参考校准

本节区分表示的三个阶段：原始后端得分 $\widehat{\mathbf{T}}$、目标标准化得分 $(\widehat{\mathbf{R}}, \widehat{\mathbf{Z}})$ 和最终对齐坐标 $(\widehat{\mathbf{U}}, \widehat{\mathbf{V}})$。这一记号区分表示学习、目标加权标准化和跨域对齐。表示学习前，每个特征矩阵先在各自域内中心化，然后对每个观测模态应用预先指定的无监督方法，获得低维得分表示。

对于参考模态，按行合并中心化矩阵 $\widetilde{\mathbf{X}}_1^{(0)}, \ldots, \widetilde{\mathbf{X}}_1^{(M)}$，估计共同表示映射，再在每个域中应用该映射，得到原始参考得分矩阵 $\widehat{\mathbf{T}}_1^{(m)} \in \mathbb{R}^{n_m \times h}$，$m = 0, \ldots, M$。对每个域 m 和辅助模态 $k \in \mathcal{A}_m \backslash \{1\}$，分别拟合表示映射，得到 $\widehat{\mathbf{T}}_k^{(m)} \in \mathbb{R}^{n_m \times \ell_k}$。把二者第 i 行作为列向量，分别记为 $\widehat{\mathbf{t}}_{1,i}^{(m)}$ 和 $\widehat{\mathbf{t}}_{k,i}^{(m)}$。因此，参考得分跨域共享坐标系，辅助得分则可能具有域特异坐标系，后续再将其映射到共同的对齐坐标系。

令 $\mathbf{0}$ 为全零结局向量。在原始参考得分尺度上，定义参考似然比 $\mathrm{LR}_{\mathrm{ref}}(\mathbf{t} \mid \mathbf{y}) = p(\mathbf{t} \mid \mathbf{y}) / p(\mathbf{t} \mid \mathbf{0})$，其中 $\mathbf{y} \in \mathcal{Y}$。使用合并的带标签源配对 $\{(\widehat{\mathbf{t}}_{1,i}^{(m)}, \mathbf{y}_i^{(m)}) : i \in \mathcal{I}_m, m = 1, \ldots, M\}$ 估计该比值。可通过贝叶斯规则，把概率多分类器转换为相对于基线的这些比值；这是基于分类的密度比估计的标准方法（Sugiyama 等，2012）。从目标参考得分初始化目标结局分布参数：

$$\widehat{\boldsymbol{\theta}}_{\mathrm{init}}^{(0)} = \arg\max_{\boldsymbol{\theta}} \sum_{i=1}^{n_0} \log \left[\sum_{\mathbf{y} \in \mathcal{Y}} \rho_y(\mathbf{y}; \boldsymbol{\theta}) \widehat{\mathrm{LR}}_{\mathrm{ref}}(\widehat{\mathbf{t}}_{1,i}^{(0)} \mid \mathbf{y}) \right]. \tag{3}$$

对每个源域，通过最大化 $\sum_{i \in \mathcal{I}_m} \log \rho_y(\mathbf{y}_i^{(m)}; \theta)$ 估计 $\widehat{\theta}^{(m)}$。定义估计的结局状态比及其个体层面取值：

$$\widehat{\omega}_m(\mathbf{y}) = \frac{\rho_y(\mathbf{y}; \widehat{\boldsymbol{\theta}}_{\mathrm{init}}^{(0)})}{\rho_y(\mathbf{y}; \widehat{\boldsymbol{\theta}}^{(m)})}, \qquad \widehat{w}_i^{(m)} = \widehat{\omega}_m(\mathbf{y}_i^{(m)}), \quad i \in \mathcal{I}_m, \quad m = 1, \ldots, M. \tag{4}$$

因此，$\omega_m(\cdot)$ 表示结局状态比，$w_i^{(m)} = \omega_m\{\mathbf{y}_i^{(m)}\}$ 是在个体 i 处的取值；帽号表示估计量。用 $\mathcal{L}_m$ 表示对齐索引集。在目标域，令 $\widehat{w}_i^{(0)} = 1$，$\mathcal{L}_0 = \{1, \ldots, n_0\}$。对于 $m \geq 1$，金标准标签程序取 $\mathcal{L}_m = \mathcal{I}_m$；使用替代变量辅助权重时，将 $\mathcal{L}_m$ 扩展到具有所需模态和替代信息的全部个体。

3.3 目标校准的参考锚定匹配

$k = 1$ 时使用 $\widehat{\mathbf{t}}_{1,i}^{(m)}$，$k \geq 2$ 时使用 $\widehat{\mathbf{t}}_{k,i}^{(m)}$。定义目标加权均值与协方差：

$$\widehat{\boldsymbol{\mu}}_1^{(m)} = \frac{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} \widehat{\mathbf{t}}_{1,i}^{(m)}}{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)}}, \qquad \widehat{\boldsymbol{\Sigma}}_1^{(m)} = \frac{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} (\widehat{\mathbf{t}}_{1,i}^{(m)} - \widehat{\boldsymbol{\mu}}_1^{(m)})(\widehat{\mathbf{t}}_{1,i}^{(m)} - \widehat{\boldsymbol{\mu}}_1^{(m)})^{\mathrm{T}}}{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)}},$$

$$\widehat{\boldsymbol{\mu}}_k^{(m)} = \frac{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} \widehat{\mathbf{t}}_{k,i}^{(m)}}{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)}}, \qquad \widehat{\boldsymbol{\Sigma}}_k^{(m)} = \frac{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} (\widehat{\mathbf{t}}_{k,i}^{(m)} - \widehat{\boldsymbol{\mu}}_k^{(m)})(\widehat{\mathbf{t}}_{k,i}^{(m)} - \widehat{\boldsymbol{\mu}}_k^{(m)})^{\mathrm{T}}}{\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)}}.$$

标准化的对齐前得分定义为

$$\widehat{\mathbf{r}}_i^{(m)} = (\widehat{\boldsymbol{\Sigma}}_1^{(m)})^{-1/2}(\widehat{\mathbf{t}}_{1,i}^{(m)} - \widehat{\boldsymbol{\mu}}_1^{(m)}), \qquad \widehat{\mathbf{z}}_{k,i}^{(m)} = (\widehat{\boldsymbol{\Sigma}}_k^{(m)})^{-1/2}(\widehat{\mathbf{t}}_{k,i}^{(m)} - \widehat{\boldsymbol{\mu}}_k^{(m)}).$$

逆平方根为保留得分子空间上的谱逆。相应的行堆叠矩阵记为 $\widehat{\mathbf{R}}^{(m)}$ 和 $\widehat{\mathbf{Z}}_k^{(m)}$；它们是第4节所用总体对齐前得分 $\mathbf{R}^{(m)}$、$\mathbf{Z}_k^{(m)}$ 的经验对应量。

在目标域，将 $\widehat{\mathbf{z}}_i^{(0)} = \mathrm{col}\{\widehat{\mathbf{z}}_{2,i}^{(0)}, \ldots, \widehat{\mathbf{z}}_{K,i}^{(0)}\} \in \mathbb{R}^{d_z}$ 拼接起来，其中 $d_z = \sum_{k=2}^{K} \ell_k$。令 $\widehat{\boldsymbol{\Sigma}}_{rr}^{(0)}$、$\widehat{\boldsymbol{\Sigma}}_{zz}^{(0)}$、$\widehat{\boldsymbol{\Sigma}}_{rz}^{(0)}$ 为参考和辅助得分的经验目标协方差及交叉协方差矩阵。给定正则参数 $\lambda_z \geq 0$ 和秩 $r_0 \leq \min\left(h,\, d_z\right)$，通过求解典型相关分析（CCA；Hotelling，1936）得到目标锚点：

$$(\widehat{\mathbf{A}}^{(0)}, \widehat{\mathbf{B}}^{(0)}) = \underset{\mathbf{A},\mathbf{B}}{\arg\max}\, \mathrm{tr}\{\mathbf{A}^{\mathrm{T}}\widehat{\boldsymbol{\Sigma}}_{rz}^{(0)}\mathbf{B}\}, \tag{5}$$

约束为 $\mathbf{A}^{\mathrm{T}}\widehat{\boldsymbol{\Sigma}}_{rr}^{(0)}\mathbf{A} = \mathbf{I}_{r_0}$ 和 $\mathbf{B}^{\mathrm{T}}\left(\widehat{\boldsymbol{\Sigma}}_{zz}^{(0)} + \lambda_z \mathbf{I}_{d_z}\right)\mathbf{B} = \mathbf{I}_{r_0}$。我们的 CCA 是单侧正则化的：当不同辅助模态包含重叠、因而近乎冗余的信息时，辅助侧岭项 λ_z 稳定联合协方差（Hardoon 等，2004；Tenenhaus 和 Tenenhaus，2011）。重要的是，成对的左右典型基只能在相差同一个旋转的意义下定义。对于每个源域，通过加权岭回归把已观测辅助块映射到目标参考侧锚点。具体地，$\{\widehat{\mathbf{G}}_k^{(m)} : k \in \mathcal{A}_m \backslash \{1\}\}$ 由最小化以下加权岭目标获得：

$$\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} \left\| \left(\widehat{\mathbf{A}}^{(0)}\right)^{\mathrm{T}} \widehat{\mathbf{r}}_i^{(m)} - \sum_{k \in \mathcal{A}_m \backslash \{1\}} \mathbf{G}_k^{\mathrm{T}} \widehat{\mathbf{z}}_{k,i}^{(m)} \right\|_2^2 + \lambda_m \left(\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)} \right) \sum_{k \in \mathcal{A}_m \backslash \{1\}} \|\mathbf{G}_k\|_{\mathrm{F}}^2.$$

岭惩罚 λ_m 对辅助得分基的正交变换不变，并在共线或秩亏时稳定堆叠正规方程（Hastie，2020）。实验中，仅使用源域或中间域验证，从固定的正值网格选择 λ_m。记 $\widehat{\mathbf{B}}^{(0)} = \mathrm{col}\{\widehat{\mathbf{B}}_2^{(0)}, \ldots, \widehat{\mathbf{B}}_K^{(0)}\}$。最终对齐坐标为

$$\widehat{\mathbf{u}}_i^{(m)} = (\widehat{\mathbf{A}}^{(0)})^{\mathrm{T}}\widehat{\mathbf{r}}_i^{(m)}, \qquad \widehat{\mathbf{v}}_{k,i}^{(m)} = (\widehat{\mathbf{G}}_k^{(m)})^{\mathrm{T}}\widehat{\mathbf{z}}_{k,i}^{(m)}, \qquad \widehat{\mathbf{v}}_{k,i}^{(0)} = (\widehat{\mathbf{B}}_k^{(0)})^{\mathrm{T}}\widehat{\mathbf{z}}_{k,i}^{(0)}. \tag{6}$$

源岭重构使用逐块坐标之和，而结局迁移保留其有序集合。若经验辅助得分基变为 $\widehat{\mathbf{z}}_{k,i}^{(m)} \mapsto \{\mathbf{Q}_{z,k}^{(m)}\}^{\mathrm{T}}\widehat{\mathbf{z}}_{k,i}^{(m)}$，共同对齐基旋转为 $\mathbf{O} \in \mathcal{O}\left(r_0\right)$，则等价系数表示为 $\widehat{\mathbf{G}}_k^{(m)} \mapsto \{\mathbf{Q}_{z,k}^{(m)}\}^{\mathrm{T}}\widehat{\mathbf{G}}_k^{(m)}\mathbf{O}$，拟合坐标相应由 $\mathbf{O}^{\mathrm{T}}$ 旋转。因此，$\widehat{\mathbf{G}}_k^{(m)}$ 的元素依赖干扰得分基，而拟合坐标在相差共同对齐空间旋转 $\mathbf{O}$ 的意义下保持不变。在条件可迁移性下，式(4)的权重将源岭正规方程传输到目标结局混合分布。加权岭映射继而把已观测源辅助块匹配到目标 CCA 锚点。因此，方法的核心贡献是目标校准的参考锚定匹配：校准在对齐前去除标签混合偏差，匹配则解决域特异辅助坐标系问题。

3.4 结局迁移与替代桥接

在式(6)的对齐尺度上，使用合并的带标签源域估计密度比。对一般的对齐参考坐标 $\mathbf{U}$ 和逐块对齐辅助坐标 $\mathbf{V}_k$，定义似然比

$$\mathrm{LR}_{\mathrm{U},\mathrm{V}_k\mid\mathrm{Y}}(\mathbf{u},\mathbf{v}\mid\mathbf{y})=\frac{p(\mathbf{U}=\mathbf{u},\mathbf{V}_k=\mathbf{v}\mid\mathbf{y})}{p(\mathbf{U}=\mathbf{u},\mathbf{V}_k=\mathbf{v}\mid\mathbf{0})},\quad \mathrm{LR}_{\mathrm{U}}(\mathbf{u}\mid\mathbf{y})=\frac{p(\mathbf{U}=\mathbf{u}\mid\mathbf{y})}{p(\mathbf{U}=\mathbf{u}\mid\mathbf{0})}. \tag{7}$$

定义 $\widehat{\mathrm{LR}}_{\mathrm{V_k}\mid\mathrm{U},\mathrm{Y}}(\mathbf{v}\mid\mathbf{u},\,\mathbf{y})=\widehat{\mathrm{LR}}_{\mathrm{U},\mathrm{V_k}\mid\mathrm{Y}}(\mathbf{u},\,\mathbf{v}\mid\mathbf{y})/\widehat{\mathrm{LR}}_{\mathrm{U}}(\mathbf{u}\mid\mathbf{y})$，其中分子、分母是式(7)中比值的估计量。对于观测辅助集合为 $\mathcal{A}_m\backslash\{1\}$ 的域，将对齐似然比证据组合为

$$\widehat{\mathrm{LR}}^{(m)}_{\mathrm{comb}}\big(\mathbf{u};\{\mathbf{v}_k\}_{k\in\mathcal{A}_m\backslash\{1\}}\mid\mathbf{y}\big)=\widehat{\mathrm{LR}}_{\mathrm{U}}(\mathbf{u}\mid\mathbf{y})\prod_{k\in\mathcal{A}_m\backslash\{1\}}\widehat{\mathrm{LR}}_{\mathrm{V_k}\mid\mathrm{U},\mathrm{Y}}(\mathbf{v}_k\mid\mathbf{u},\mathbf{y}). \tag{8}$$

若给定 $(\mathbf{U},\,\mathbf{Y})$ 时各对齐辅助块条件独立，该乘积就是联合条件似然比。更一般地，它是基于可迁移对齐块构造的复合似然比。

通过剖面准则估计目标结局分布参数；这是最大似然标签偏移估计所用的有限状态似然比形式（Garg 等，2020；Alexandari 等，2020）：

$$\widehat{\boldsymbol{\theta}}^{(0)}=\arg\max_{\boldsymbol{\theta}}\frac{1}{n_0}\sum_{i=1}^{n_0}\log\left[\sum_{\mathbf{y}\in\mathcal{Y}}\rho_y(\mathbf{y};\boldsymbol{\theta})\widehat{\mathrm{LR}}^{(0)}_{\mathrm{comb}}\big(\widehat{\mathbf{u}}^{(0)}_i;\widehat{\mathbf{v}}^{(0)}_{2,i},\ldots,\widehat{\mathbf{v}}^{(0)}_{K,i}\mid\mathbf{y}\big)\right]. \tag{9}$$

目标条件结局分布估计为

$$\widehat{p}_i(\mathbf{y})=\frac{\rho_y(\mathbf{y};\widehat{\boldsymbol{\theta}}^{(0)})\widehat{\mathrm{LR}}^{(0)}_{\mathrm{comb}}\big(\widehat{\mathbf{u}}^{(0)}_i;\widehat{\mathbf{v}}^{(0)}_{2,i},\ldots,\widehat{\mathbf{v}}^{(0)}_{K,i}\mid\mathbf{y}\big)}{\sum_{\mathbf{y}'\in\mathcal{Y}}\rho_y(\mathbf{y}';\widehat{\boldsymbol{\theta}}^{(0)})\widehat{\mathrm{LR}}^{(0)}_{\mathrm{comb}}\big(\widehat{\mathbf{u}}^{(0)}_i;\widehat{\mathbf{v}}^{(0)}_{2,i},\ldots,\widehat{\mathbf{v}}^{(0)}_{K,i}\mid\mathbf{y}'\big)}. \tag{10}$$

软预测是在 $\widehat{p}_i$ 下的条件均值，硬预测使用 $\mathrm{argmax}_{\mathbf{y}\in\mathcal{Y}}\widehat{p}_i(\mathbf{y})$。

考虑仅源域有替代变量的情形：源域金标准结局不可获得，$m=1,\,\ldots,\,M$ 时观测替代结局 $\mathbf{s}_i^{(m)}$，目标域 $\mathbf{s}_i^{(0)}$ 不可获得。除式(2)外，假设条件替代分布 $p_S(\mathbf{s}\mid\mathbf{y})$ 在各源域不变，且相应替代桥可识别。对于个体表示 $\mathbf{f}$，令 $\widehat{\mathrm{LR}}_{\mathrm{br},S}(\mathbf{f}\mid\mathbf{y})$ 表示从源表示和替代变量估计的 $p(\mathbf{f}\mid\mathbf{y})/p(\mathbf{f}\mid\mathbf{0})$ 的替代桥估计量。在二元实现中，$Y\in\{0,\,1\}$、$S\in\mathbb{R}$；桥模型将 S 对 $\mathbf{f}$ 回归，再将拟合均值与 $S\mid Y$ 的可识别双成分模型结合。参考校准中，以 $\mathbf{f}$ 表示原始参考得分，相应比值记为 $\widehat{\mathrm{LR}}_{\mathrm{ref},S}$。在式(3)中用它替换 $\widehat{\mathrm{LR}}_{\mathrm{ref}}$，定义 $\widehat{\theta}^{(0)}_{\mathrm{init},S}$。为进行匹配，定义

$$\widehat{\mathbf{f}}^{(m)}_{i,\mathrm{pre}}=\mathrm{col}\left\{\widehat{\mathbf{t}}^{(m)}_{1,i},\widehat{\mathbf{t}}^{(m)}_{k,i}:k\in\mathcal{A}_m\setminus\{1\}\right\},$$

令 $\widehat{q}^{(m)}_{i,\mathrm{pre},S}(\mathbf{y})$ 为根据 $\big(\widehat{\mathbf{f}}^{(m)}_{i,\mathrm{pre}},\,\mathbf{s}_i^{(m)}\big)$ 得到的结局状态 $\mathbf{y}$ 的归一化工作权重，满足 $\sum_{\mathbf{y}\in\mathcal{Y}}\widehat{q}^{(m)}_{i,\mathrm{pre},S}(\mathbf{y})=1$。由于匹配之前辅助得分不可比较，该桥分别在每个源域拟合。对 $m=1,\,\ldots,\,M$，定义

$$\widehat{\boldsymbol{\theta}}^{(m)}_S=\arg\max_{\boldsymbol{\theta}}\sum_{i\in\mathcal{L}_m}\sum_{\mathbf{y}\in\mathcal{Y}}\widehat{q}^{(m)}_{i,\mathrm{pre},S}(\mathbf{y})\log\rho_y(\mathbf{y};\boldsymbol{\theta}), \tag{11}$$

$$\widehat{w}_{i,S}^{(m)} = \sum_{\mathbf{y}\in\mathcal{Y}} \widehat{q}_{i,\mathrm{pre},S}^{(m)}(\mathbf{y}) \frac{\rho_y(\mathbf{y};\widehat{\boldsymbol{\theta}}_{\mathrm{init},S}^{(0)})}{\rho_y(\mathbf{y};\widehat{\boldsymbol{\theta}}_S^{(m)})}, \qquad i \in \mathcal{L}_m. \tag{12}$$

式(12)的替代变量权重替换式(4)的金标签权重，而第3.3节的后续对齐步骤不变。对于每个域 $m = 0, \ldots, M$，将该域观测到的对齐辅助坐标求平均，为替代变量驱动的结局迁移构造共同维数表示：

$$\widehat{\mathbf{v}}_{\mathrm{agg},i}^{(m)} = \frac{1}{|\mathcal{A}_m \setminus \{1\}|} \sum_{k\in\mathcal{A}_m\setminus\{1\}} \widehat{\mathbf{v}}_{k,i}^{(m)}, \qquad \widehat{\mathbf{f}}_{i,\mathrm{al}}^{(m)} = \mathrm{col}\left\{\widehat{\mathbf{u}}_i^{(m)}, \widehat{\mathbf{v}}_{\mathrm{agg},i}^{(m)}\right\}.$$

令 $\widehat{\mathrm{LR}}_{\mathrm{comb},S}(\mathbf{f} \mid \mathbf{y})$ 为使用合并的源配对 $\{(\widehat{\mathbf{f}}_{i,\mathrm{al}}^{(m)}, \mathbf{s}_i^{(m)}) : i \in \mathcal{L}_m,\ m = 1, \ldots, M\}$ 估计的对齐替代桥比值。在式(9)中将似然比项替换为 $\widehat{\mathrm{LR}}_{\mathrm{comb},S}(\widehat{\mathbf{f}}_{i,\mathrm{al}}^{(0)} \mid \mathbf{y})$，定义 $\widehat{\theta}_S^{(0)}$。在式(10)中使用该参数和同一比值，得到目标条件结局分布估计。替代信息仅用于估计源侧权重和似然比；估计对象始终是目标金标准结局 $\mathbf{y}_i^{(0)}$ 的条件分布。

4 理论

4.1 总体坐标与识别目标

本节考虑使用 PCA（Jolliffe 和 Cadima，2016）学习表示、所有源个体的金标准结局标签均可观测、而目标结局在拟合时不可观测的情形。全文以 $\mathbf{T}$ 表示原始后端得分，$(\mathbf{R}, \mathbf{Z})$ 表示目标标准化得分，$(\mathbf{U}, \mathbf{V})$ 表示最终对齐坐标。不带帽的记号表示总体量，带帽表示经验对应量。各域样本相互独立，每个域内个体也独立。对域 m 的个体 i，总体标准化参考得分为 $\mathbf{r}_i^{(m)} \in \mathbb{R}^h$，辅助块 $k \in \mathcal{A}_m\setminus\{1\}$ 的总体标准化得分为 $\mathbf{z}_{k,i}^{(m)} \in \mathbb{R}^{\ell_k}$。令 $\mathbf{z}_i^{(m)} = \mathrm{col}\{\mathbf{z}_{k,i}^{(m)} : k \in \mathcal{A}_m\setminus\{1\}\}$，并分别用 $\mathbf{R}^{(m)}$、$\mathbf{Z}_k^{(m)}$、$\mathbf{Z}^{(m)}$ 表示相应行堆叠矩阵。域 m 的概率和期望分别记为 P_m, E_m；总体标签偏移比为 $\omega_m(\mathbf{y}) = \rho_y(\mathbf{y};\theta^{(0)})/\rho_y(\mathbf{y};\theta^{(m)})$，$m = 1, \ldots, M$。

带标签源个体的个体特异权重为 $w_i^{(m)} = \omega_m(\mathbf{y}_i^{(m)})$；目标域取 $w_i^{(0)} = 1$。专门以 $\omega_m(\cdot)$ 表示结局状态比，以 $w_i^{(m)}$ 表示在个体结局处的取值。令 $(\mathbf{A}^{(0)}, \mathbf{B}^{(0)})$ 为式(5)对应的正则化目标 CCA 问题的一对总体解。每个源域的总体岭对齐映射定义为以下惩罚总体目标的最优解：

$$\mathbf{G}^{(m)} = \arg\min_{\mathbf{G}} \left\{ E_m\left[\omega_m(\mathbf{y}^{(m)}) \left\| (\mathbf{A}^{(0)})^{\mathrm{T}}\mathbf{r}^{(m)} - \mathbf{G}^{\mathrm{T}}\mathbf{z}^{(m)} \right\|_2^2\right] + \lambda_m \|\mathbf{G}\|_{\mathrm{F}}^2 \right\}.$$

在按结局重新加权的源分布下，定义辅助得分协方差 $\boldsymbol{\Sigma}_{zz}^{(m)}$ 与辅助-参考交叉矩 $\boldsymbol{\Sigma}_{zr}^{(m)}$：

$$\boldsymbol{\Sigma}_{zz}^{(m)} = E_m\left[\omega_m(\mathbf{y}^{(m)})\mathbf{z}^{(m)}\mathbf{z}^{(m)\mathrm{T}}\right], \qquad \boldsymbol{\Sigma}_{zr}^{(m)} = E_m\left[\omega_m(\mathbf{y}^{(m)})\mathbf{z}^{(m)}\mathbf{r}^{(m)\mathrm{T}}\right].$$

由于 $E_m[\omega_m(\mathbf{y}^{(m)})] = 1$，它们确为结局重加权源分布下的矩。当 $\lambda_m > 0$ 时，$\boldsymbol{\Sigma}_{zz}^{(m)} + \lambda_m\mathbf{I}$ 正定，$\mathbf{I}$ 的维数为 $\dim(\mathbf{z}^{(m)})$。因此惩罚总体最优解唯一，且满足

$$\mathbf{G}^{(m)} = \left(\mathbf{\Sigma}_{zz}^{(m)} + \lambda_m \mathbf{I}\right)^{-1} \mathbf{\Sigma}_{zr}^{(m)} \mathbf{A}^{(0)}.$$

所以，$\mathbf{G}^{(m)}$ 是与经验岭对齐映射 $\widehat{\mathbf{G}}^{(m)}$ 使用相同惩罚参数 λ_m 的总体对应量。即使堆叠辅助得分共线或秩亏，正的岭正则化仍保证唯一性和稳定性（Hastie，2020）。将 $\mathbf{G}^{(m)}$ 按辅助块分为 $\mathrm{col}\{\mathbf{G}_k^{(m)} : k \in \mathcal{A}_m \backslash \{1\}\}$，并写 $\mathbf{B}^{(0)} = \mathrm{col}\{\mathbf{B}_2^{(0)}, \ldots, \mathbf{B}_K^{(0)}\}$；总体对齐坐标为

$$\begin{aligned}
\mathbf{u}_i^{(m)} &= \{\mathbf{A}^{(0)}\}^{\mathrm{T}} \mathbf{r}_i^{(m)} \in \mathbb{R}^{r_0}, \quad m = 0, \ldots, M, \\
\mathbf{v}_{k,i}^{(0)} &= \{\mathbf{B}_k^{(0)}\}^{\mathrm{T}} \mathbf{z}_{k,i}^{(0)} \in \mathbb{R}^{r_0}, \quad k = 2, \ldots, K, \\
\mathbf{v}_{k,i}^{(m)} &= \{\mathbf{G}_k^{(m)}\}^{\mathrm{T}} \mathbf{z}_{k,i}^{(m)} \in \mathbb{R}^{r_0}, \quad k \in \mathcal{A}_m \setminus \{1\}, \quad m \geq 1.
\end{aligned}$$

以 $\mathbf{v}_i^{(m)} = \mathrm{col}\{\mathbf{v}_{k,i}^{(m)} : k \in \mathcal{A}_m \backslash \{1\}\}$ 表示域 m 中已观测对齐辅助块的有序集合；相应行堆叠参考坐标、辅助块和有序辅助集合分别记为 $\mathbf{U}^{(m)}$、$\mathbf{V}_k^{(m)}$、$\mathbf{V}^{(m)}$。

我们区分得分基的两类干扰旋转。$\mathbf{Q}_r \in \mathcal{O}(h)$ 表示共同参考得分的基变换，$\mathbf{Q}_{z,k}^{(m)} \in \mathcal{O}\left(\ell_k\right)$ 表示域 m、模态 k 特异的辅助基变换。此外，$\mathbf{O} \in \mathcal{O}\left(r_0\right)$ 表示共同对齐空间唯一残留的旋转对称性。若个体得分向量改写为

$$\mathbf{r}_i^{(m)} \mapsto \mathbf{Q}_r^{\mathrm{T}} \mathbf{r}_i^{(m)}, \qquad \mathbf{z}_{k,i}^{(m)} \mapsto \left(\mathbf{Q}_{z,k}^{(m)}\right)^{\mathrm{T}} \mathbf{z}_{k,i}^{(m)},$$

则在共同对齐空间旋转 $\mathbf{O}$ 下，等价系数表示为

$$\mathbf{A}^{(0)} \mapsto \mathbf{Q}_r^{\mathrm{T}} \mathbf{A}^{(0)} \mathbf{O}, \qquad \mathbf{B}_k^{(0)} \mapsto \left(\mathbf{Q}_{z,k}^{(0)}\right)^{\mathrm{T}} \mathbf{B}_k^{(0)} \mathbf{O}, \qquad \mathbf{G}_k^{(m)} \mapsto \left(\mathbf{Q}_{z,k}^{(m)}\right)^{\mathrm{T}} \mathbf{G}_k^{(m)} \mathbf{O}.$$

因此，每个拟合的行堆叠块都按 $\mathbf{Z}_k^{(m)} \mathbf{G}_k^{(m)} \mapsto \mathbf{Z}_k^{(m)} \mathbf{G}_k^{(m)} \mathbf{O}$ 变换，同一个 $\mathbf{O}$ 作用于每个已观测对齐辅助块。对第 i 行为 $\mathbf{h}_i^{\mathrm{T}}$ 的矩阵 $\mathbf{H}$，定义加权矩阵范数 $\| \mathbf{H} \|_{\mathrm{F},m}^2 = \sum_i w_i^{(m)} \| \mathbf{h}_i \|_2^2 / \sum_i w_i^{(m)}$。使用单一确定性序列 $\Delta_n \to 0$ 描述原始标准化得分和二阶矩误差。目标 CCA、源岭映射及拟合坐标的误差均由该序列推导，而不包含在其定义中。对于 PCA 后端，补充材料给出由最差 PCA 特征子空间速率、结局权重速率和 $n_{\min}^{-1/2}$ 抽样波动构成的显式 Δ_n。

4.2 假设

假设1是标准标签偏移和重叠条件：结局患病率可随域变化，而保留得分的类条件分布保持稳定；它用于把目标矩表示成加权源矩（Lipton 等，2018；Garg 等，2020）。

假设1（标签偏移与重叠）。对每个源域 m 和结局状态 $\mathbf{y}$，

$$\begin{aligned}
&\rho_y(\mathbf{y}; \boldsymbol{\theta}^{(0)}) > 0 \quad \Longrightarrow \quad \rho_y(\mathbf{y}; \boldsymbol{\theta}^{(m)}) > 0, \\
&(\mathbf{r}^{(m)}, \mathbf{z}^{(m)}) \mid \{\mathbf{y}^{(m)} = \mathbf{y}\} \overset{d}{=} (\mathbf{r}^{(0)}, \mathbf{z}^{(m,0)}) \mid \{\mathbf{y}^{(0)} = \mathbf{y}\},
\end{aligned}$$

其中 $\mathbf{z}^{(m,0)}$ 含有源域 m 中观测到的目标辅助块，并以相应固定总体得分取向表示。经验得分基通过旋转 $\mathbf{Q}_{z,k}^{(m)}$ 与这些固定总体代表元联系。此外，$\sup_{m,\mathbf{y}} \omega_m(\mathbf{y}) < \infty$，上确界仅对目标概率为正的状态取。

令 $\mathbf{\Gamma}^{(0)} = \{\mathbf{\Sigma}_{rr}^{(0)}\}^{-1/2}\mathbf{\Sigma}_{rz}^{(0)}\{\mathbf{\Sigma}_{zz}^{(0)} + \lambda_z\mathbf{I}\}^{-1/2}$ 为总体正则化目标 CCA 算子，$\widehat{\mathbf{\Gamma}}^{(0)}$ 为其经验对应量。假设2汇集协方差集中、子空间恢复和岭稳定性的高层条件。标准文献提供这些单独要素（Koltchinskii 和 Lounici，2017；Yu 等，2015；Wedin，1972；Hastie，2020）；补充材料证明如何按本方法的特性将其组合成一个共同旋转。

假设2（稳定的正则化对齐）。域数、模态数和保留秩固定。相关总体二阶、四阶矩有界；用于标准化与正则化 CCA 的协方差矩阵在保留子空间上的特征值与零保持正距离。目标 CCA 算子满足 $\sigma_{r_0}\{\mathbf{\Gamma}^{(0)}\} - \sigma_{r_0+1}\{\mathbf{\Gamma}^{(0)}\} \geq \delta_{\mathrm{CCA}} > 0$。源岭参数满足 $0 < \underline{\lambda} \leq \lambda_m \leq \bar{\lambda} < \infty$。选取适当干扰得分旋转后，标准化得分误差、三个目标 CCA 矩误差，以及源辅助协方差和辅助-参考交叉矩误差，均一致为 $O_p(\Delta_n)$。从有限候选集选择的任何调参参数均一致满足这些条件。

补充材料中的 PCA 后端结果验证假设2，并将其显式速率通过 CCA 和岭回归传播。其他表示后端也可替代 PCA，只需验证相同的原始 $O_p(\Delta_n)$ 矩界。

令 $\mathbf{0}$ 为基线结局状态，定义目标对齐似然比

$$\mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{u}, \mathbf{v} \mid \mathbf{y}) = \frac{p_0(\mathbf{u}, \mathbf{v} \mid \mathbf{y})}{p_0(\mathbf{u}, \mathbf{v} \mid \mathbf{0})}. \tag{13}$$

贝叶斯规则给出

$$p_0(\mathbf{y} \mid \mathbf{u}, \mathbf{v}) = \frac{\rho_y(\mathbf{y}; \boldsymbol{\theta}^{(0)})\mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{u}, \mathbf{v} \mid \mathbf{y})}{\sum_{\mathbf{y}' \in \mathcal{Y}} \rho_y(\mathbf{y}'; \boldsymbol{\theta}^{(0)})\mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{u}, \mathbf{v} \mid \mathbf{y}')}. \tag{14}$$

假设3给出对齐似然比估计量和目标剖面准则的标准一致性与识别条件。建立共同旋转后，通过标准代入和 argmax 论证，得到目标结局参数及后验的一致性（Sugiyama 等，2012；van der Vaart，2000）。

假设3（对齐比值一致性与剖面识别）。对每个目标概率为正的 $\mathbf{y} \in \mathcal{Y}$，给定 $\mathbf{y}^{(0)} = \mathbf{y}$ 时 $\left(\mathbf{u}^{(0)}, \mathbf{v}^{(0)}\right)$ 的条件分布，相对于给定 $\mathbf{y}^{(0)} = \mathbf{0}$ 时的条件分布绝对连续。将估计坐标表示在引理2的共同取向中后，记

$$\mathrm{LR}_i(\mathbf{y}) = \mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}\{\mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)} \mid \mathbf{y}\},$$

对应的估计比值为

$$\widehat{\mathrm{LR}}_i(\mathbf{y}) = \widehat{\mathrm{LR}}^{(0)}_{\mathrm{comb}}\left(\widehat{\mathbf{u}}_i^{(0)}; \widehat{\mathbf{v}}_{2,i}^{(0)}, \ldots, \widehat{\mathbf{v}}_{K,i}^{(0)} \mid \mathbf{y}\right).$$

各比值非负，且 $\mathrm{LR}_i(\mathbf{0}) = \widehat{\mathrm{LR}}_i(\mathbf{0}) = 1$。用 $\kappa_n \to 0$ 表示在总体对齐坐标上的内在似然比估计与迁移速率。假设在估计坐标处求值后，有

$$\frac{1}{n_0}\sum_{i=1}^{n_0}\max_{\mathbf{y}\in\mathcal{Y}}\left|\widehat{\mathrm{LR}}_i(\mathbf{y}) - \mathrm{LR}_i(\mathbf{y})\right| = O_p(\kappa_n + \Delta_n), \qquad \frac{1}{n_0}\sum_{i=1}^{n_0}\max_{\mathbf{y}\in\mathcal{Y}}\left\{\mathrm{LR}_i(\mathbf{y}) + \widehat{\mathrm{LR}}_i(\mathbf{y})\right\} = O_p(1). \tag{15}$$

θ 的参数空间紧， $\rho_y(\mathbf{y};\theta)$ 关于 θ 连续，且在有限结局空间 y 上一致； $\inf_\theta \rho_y(\mathbf{0};\theta) > 0$ 。在式(9)中用 LR_i 替换 $\widehat{\mathrm{LR}_i}$ 所得的预言式剖面准则，一致收敛到一个确定性总体准则，后者唯一最大化点为 $\theta^{(0)}$ 。为了得到下述速率结论，要求 $\theta^{(0)}$ 为内点； ρ_y 在其邻域中二次连续可微且导数有界；负总体剖面 Hessian 在该邻域正定；预言式经验 Hessian 在该邻域一致收敛到总体对应量；在 $\theta^{(0)}$ 处的预言式经验得分为 $O_p\left(n_0^{-1/2}\right)$ 。

4.3 统一旋转对齐与后验一致性

引理1（目标分布传输）。 在假设1下，对每个源域 m 和每个平方可积可测函数 f ，

$$E_m\left[\omega_m\{\mathbf{y}^{(m)}\} f\{\mathbf{r}^{(m)}, \mathbf{z}^{(m)}\}\right] = E_0\left[f\{\mathbf{r}^{(0)}, \mathbf{z}^{(m,0)}\}\right]. \tag{16}$$

引理2（单一共同旋转恢复）。 在假设1、2下，存在干扰基旋转 $\mathbf{Q}_r \in \mathcal{O}(h)$ 、 $\mathbf{Q}_{z,k}^{(m)} \in \mathcal{O}\left(\ell_k\right)$ 和单个共同的 $\mathbf{O} \in \mathcal{O}\left(r_0\right)$ ，使得

$$\begin{aligned}\left\|\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{A}^{(0)}\mathbf{O}\right\|_{\mathrm{F}} + \max_{2\le k\le K}\left\|\widehat{\mathbf{B}}_k^{(0)} - \{\mathbf{Q}_{z,k}^{(0)}\}^{\mathrm{T}}\mathbf{B}_k^{(0)}\mathbf{O}\right\|_{\mathrm{F}} \\ + \max_{1\le m\le M}\max_{k\in\mathcal{A}_m\setminus\{1\}}\left\|\widehat{\mathbf{G}}_k^{(m)} - \{\mathbf{Q}_{z,k}^{(m)}\}^{\mathrm{T}}\mathbf{G}_k^{(m)}\mathbf{O}\right\|_{\mathrm{F}} = O_p(\Delta_n),\end{aligned} \tag{17}$$

并且

$$\max_{0\le m\le M}\left\{\left\|\widehat{\mathbf{U}}^{(m)} - \mathbf{U}^{(m)}\mathbf{O}\right\|_{\mathrm{F},m} + \sum_{k\in\mathcal{A}_m\setminus\{1\}}\left\|\widehat{\mathbf{V}}_k^{(m)} - \mathbf{V}_k^{(m)}\mathbf{O}\right\|_{\mathrm{F},m}\right\} = O_p(\Delta_n). \tag{18}$$

同一个 $\mathbf{O}$ 出现在目标 CCA 对、每个源岭块和每个拟合对齐坐标中。

引理2证明各拟合坐标相对于自身总体映射，可在同一共同取向下恢复。它不声称目标 CCA 映射 $\mathbf{B}^{(0)}$ 等于某个源岭映射 $\mathbf{G}^{(m)}$ ；共同取向本身也不意味着源到目标的似然比可迁移性。后者是由假设3单独提出的干扰条件。

原始系数矩阵 $\mathbf{G}_k^{(m)}$ 依赖干扰得分基，本质上不可识别。相反，每个拟合块和对齐坐标的有序集合，可在相差同一共同旋转的意义下识别。对一般个体对齐坐标 $\mathbf{u}, \mathbf{v}_k$ ，令 $\mathbf{v} = \mathrm{col}\{\mathbf{v}_2, \ldots, \mathbf{v}_K\}$ 。以下变换

$$(\mathbf{u}, \mathrm{col}\{\mathbf{v}_2, \ldots, \mathbf{v}_K\}) \longmapsto \left(\mathbf{O}^{\mathrm{T}}\mathbf{u}, \mathrm{col}\{\mathbf{O}^{\mathrm{T}}\mathbf{v}_2, \ldots, \mathbf{O}^{\mathrm{T}}\mathbf{v}_K\}\right)$$

可测且一一对应，所以变换后的坐标与 $(\mathbf{u}, \mathbf{v})$ 生成相同的 σ-代数。若 $p_0^{\mathbf{O}}$ 表示以变换坐标表达的条件分布，则

$$p_0^{\mathbf{O}}\left(\mathbf{y} \mid \mathbf{O}^{\mathrm{T}}\mathbf{u}, \mathrm{col}\{\mathbf{O}^{\mathrm{T}}\mathbf{v}_2, \ldots, \mathbf{O}^{\mathrm{T}}\mathbf{v}_K\}\right) = p_0(\mathbf{y} \mid \mathbf{u}, \mathbf{v}) \quad \text{almost surely.} \tag{19}$$

式(19)中的 almost surely 意为“几乎处处”。

定理1（目标条件结局分布的一致性与速率）。 假设1、2、3成立。如果式(9)的目标剖面准则被最大化至 $o_p(1)$ 精度，则

$$\widehat{\boldsymbol{\theta}}^{(0)} \xrightarrow{p} \boldsymbol{\theta}^{(0)}$$

并且

$$\frac{1}{n_0}\sum_{i=1}^{n_0}\sum_{\mathbf{y}\in\mathcal{Y}}\left|\widehat{p}_i(\mathbf{y}) - p_0\big(\mathbf{y}\mid \mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)}\big)\right| \xrightarrow{p} 0. \tag{20}$$

如果假设3中的局部可微性、内点性和非奇异 Hessian 条件成立，且拟合准则满足一阶条件，则

$$\left\|\widehat{\boldsymbol{\theta}}^{(0)} - \boldsymbol{\theta}^{(0)}\right\|_2 + \frac{1}{n_0}\sum_{i=1}^{n_0}\sum_{\mathbf{y}\in\mathcal{Y}}\left|\widehat{p}_i(\mathbf{y}) - p_0\big(\mathbf{y}\mid \mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)}\big)\right| = O_p\big(n_0^{-1/2} + \kappa_n + \Delta_n\big). \tag{21}$$

具有可积包络的局部 Lipschitz 比值求值映射，是从内在速率 κ_n 和坐标速率 Δ_n 推出所假设平均比值界的一种充分途径。因此，无需再引入其他误差速率符号。

该定理针对式(13)的精确目标似然比。若式(8)的复合构造不是精确联合比值，同样的论证给出其工作条件分布的一致性与相应速率，而非精确目标后验的一致性与速率。

4.4 证明概要

主要的非标准步骤，是证明单个旋转而非各域各自的旋转能够对齐所有估计坐标。其余传输恒等式、协方差集中、奇异子空间扰动、岭扰动和剖面估计论证均属标准程序。补充材料给出适当调整后的完整证明。

围绕 $\boldsymbol{\Gamma}^{(0)}$ 对 $\widehat{\boldsymbol{\Gamma}}^{(0)}$ 的对称扩张作标准扰动分析，可为目标 CCA 的左右基同时得到单个 $\mathbf{O}\in\mathcal{O}(r_0)$，因为成对典型向量张成联合不变子空间（Wedin，1972；Yu 等，2015）。目标参考坐标因此把相同的 $\mathbf{O}$ 带入每个源岭问题。

岭正规方程的正交等变性随后给出：对每个已观测源块，$\widehat{\mathbf{G}}_k^{(m)} = \{\mathbf{Q}_{z,k}^{(m)}\}^{\mathrm{T}}\mathbf{G}_k^{(m)}\mathbf{O} + O_p(\Delta_n)$。乘以估计得分矩阵后，干扰 $\mathbf{Q}$ 旋转相消，因此每个域都有 $\widehat{\mathbf{U}}^{(m)} = \mathbf{U}^{(m)}\mathbf{O} + O_p(\Delta_n)$ 和 $\widehat{\mathbf{V}}_k^{(m)} = \mathbf{V}_k^{(m)}\mathbf{O} + O_p(\Delta_n)$。所以模态可用性的块状差异决定哪些对齐块存在，但不会改变共同取向。假设3单独提供内在似然比速率 κ_n。剖面得分的一阶展开随后给出式(21)的参数和后验速率；补充材料明确给出 PCA 到 CCA 再到岭映射对 Δ_n 的贡献。

5 模拟研究

模拟研究围绕三个主要研究问题（RQ）评价所提方法。**RQ1：** 目标分布校准结合目标锚定 CCA 和正则化源映射，能否处理源-目标标签偏移与块状模态异质性？**RQ2：** 金标准标签稀疏时，替代桥能否恢复全标签程序的大部分准确性；加入少量金标准标签能否加快向全标签预言式方法的收敛？**RQ3：** 对齐与目标校准是否具有互补贡献，而非一个部分仅在补偿另一个部分造成的不稳定？因此，本文报告主要多元模拟、替代辅助模拟和消融研究。

5.1 模拟研究设定

主要多元模拟中，每次重复含一个无标签目标域和五个源域，每域400名个体。目标结局是由式(1)的 Ising 模型生成的三维二元向量，边际患病率为 $(0.22,\ 0.36,\ 0.40)$，成对交互为 $(0.45,\ 0.35,\ 0.30)$。扰动源结局分布使其偏离目标分布，但给定结局的潜在表示保持可迁移。每名个体有一个共享参考模态，以及由 $h = 5$ 潜在因子生成的四个秩亏辅助模态。

每次只改变一个压力因素：联合标签偏移幅度 δ、辅助载荷旋转 ε_{rot}、源金标签缺失率 p_{lab} 和块状源模态模式索引 p_{mod}。默认值为 $\delta = 0.24$、$\varepsilon_{\text{rot}} = 0.50$、$p_{\text{lab}} = 0.35$、$p_{\text{mod}} = 0$。目标金标准结局拟合时被掩蔽，只用于评价。比较方法包括直接源迁移、正交 Procrustes 迁移（Schönemann, 1966）、RGCCA（Tenenhaus 和 Tenenhaus，2011）、BONMI（Zhou 等，2023）、仅目标 PCA-EM（Jolliffe 和 Cadima，2016；Dempster 等，1977），以及两种原始特征学习器：含缺失块指示变量、可捕捉非线性特征效应和交互的 XGBoost（Chen 和 Guestrin，2016），和作为稀疏线性基准的 LASSO（Tibshirani，1996）。这两种学习器分别刻画灵活非线性预测与正则线性预测可达到的性能。对100次蒙特卡洛重复取平均，以目标宏平均 AUC 和目标均方误差（MSE）概括性能。

替代辅助模拟采用同一域适应问题的二元版本。目标患病率为0.22，标签偏移幅度固定为 $\delta = 0.24$，源域观测信号水平 $q = 0.80$ 的连续替代变量。每域样本量从25变到6400。比较替代辅助方法、仅参考替代学习器、直接和正交全标签迁移规则、使用全部源金标准标签的所提全标签预言式方法，以及额外使用20%源金标签进行校准的半监督变体。对于 RQ3，在 $\varepsilon_{\text{rot}} = 1$、其他扰动参数保持默认值时进行交叉消融，将目标 CCA/岭对齐和稳定化目标更新交叉组合成四种变体。

5.2 主要模拟

为回答 RQ1，图2展示四项扰动扫描下的目标宏平均 AUC 与 MSE；各设定详细结果见补充材料。对所有设定平均后，所提方法的宏平均 AUC 为0.9269，MSE 为0.1003，相比 Raw-X XGBoost，前者相对提高20.3%，后者相对降低51.8%。在最大标签偏移 $\delta = 0.40$ 下，相应改善为21.7%和59.5%；在旋转、源标签缺失及非嵌套模态模式配置下，所提方法的曲线保持稳定。这回答了 RQ1：目标分布校准处理源-目标结局偏移，目标锚定 CCA/岭匹配则为异质辅助块提供共同坐标系。

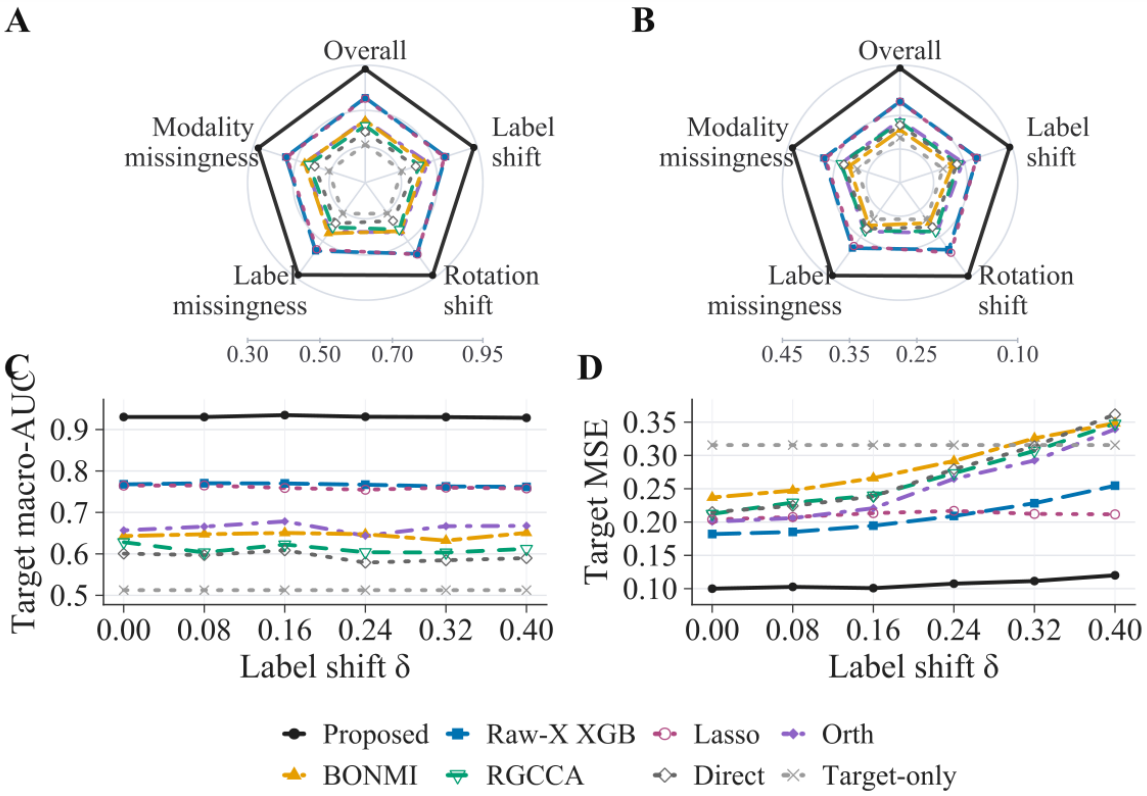


图2。 主要模拟。A、B 面板概括四项扰动扫描及总体性能，C、D 面板展示完整标签偏移轨迹。A、C 报告目标宏平均 AUC，越高越好；B、D 报告目标 MSE，越低越好。B 的径向刻度反向，因此两个雷达图中离中心越远均表示性能越好。对越来越大的标签偏移的稳健性，表现为 C 中高而平坦、D 中低而平坦的轨迹。结果为100次重复的蒙特卡洛均值。图中文字：Overall＝总体；Label shift＝标签偏移；Rotation shift＝旋转偏移；Label missingness＝标签缺失；Modality missingness＝模态缺失；Proposed＝所提方法；Raw-X XGB＝原始特征 XGBoost；Orth＝正交迁移；Direct＝直接迁移；Target-only＝仅目标。

5.3 替代辅助模拟

为回答 RQ2，图3展示目标 AUC、MSE 随每域样本量变化的情况。替代桥恢复了全标签基准的大部分性能。主要比较仅替代变量的所提方法、半监督变体与所提全标签预言式方法：样本量增加时，前两条曲线在排序与概率准确性上均迅速接近预言式基准。除最小样本情形外，普通 XGBoost 和 LASSO 改善较慢，与所提方法曲线仍明显分离，表明一般非线性或稀疏线性拟合不能替代目标校准的多模态迁移。每域 $n = 400$ 时，相比仅参考替代学习，仅替代变量方法将 AUC 提高20.4%、MSE 降低55.3%；相比直接全标签迁移，相应改善为18.8%和54.6%。随着样本增多，仅替代变量曲线逼近全标签预言式方法，$n = 6400$ 时 AUC 与预言式值的差距在0.3%以内。半监督替代变体进一步缩小差距，概率准确性尤为明显：$n = 6400$ 且使用20%源金标准标签校准时，其 MSE 为0.061，与全标签预言式值0.062基本相同。因此，替代变量本身提供了大部分排序信息，少量金标签则校准尺度，使程序更快逼近全标签预言式方法。这回答了 RQ2：当替代证据沿着与金标准标签相同的目标校准多模态迁移路径使用时，它是有效的。

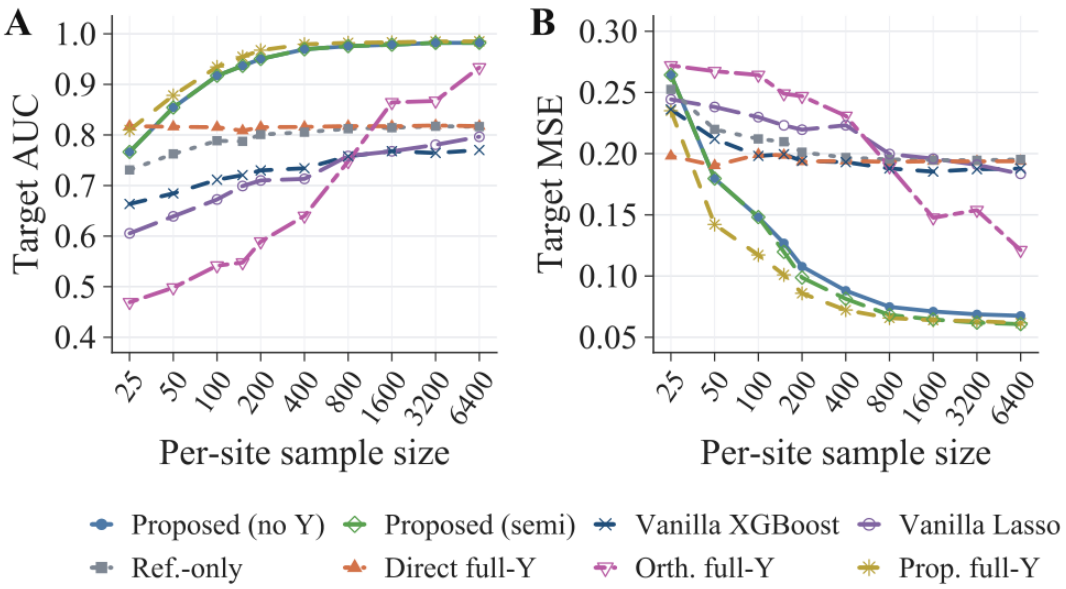


图3。 替代辅助模拟。A 报告目标 AUC，越高越好；B 报告目标 MSE，越低越好。样本量按每个源域计。关键曲线为 Proposed (no Y)＝所提方法（无金标签）、Proposed (semi)＝所提方法（半监督）、Prop. full-Y＝所提全标签方法。样本量增加时，前两条曲线与全标签预言式曲线的垂直距离缩小，表示仅凭替代信息及额外加入20%源金标准标签分别恢复了多少预言式性能。Vanilla XGBoost、Vanilla Lasso 是不含所提目标适应的非线性与稀疏线性基准。Ref.-only＝仅参考；Direct full-Y＝直接全标签；Orth. full-Y＝正交全标签；Per-site sample size＝每站点样本量。

5.4 对齐与校准消融

为回答 RQ3，交叉消融把额外的目标锚定 CCA/岭匹配与稳定化目标更新分离；关闭 CCA 开关时，初步结局重加权对齐仍然启用。去除目标锚定部分导致较大退化：宏平均 AUC 从0.9297降至0.8635，MSE 从0.0983升至0.1361。相比不更新变体，完整方法将 MSE 降低0.0069，但宏平均 AUC 也小幅降低0.0030。两部分均移除时，MSE 与分类误差最大。这些趋势回答了 RQ3：在载荷旋转下，目标锚定 CCA/岭映射贡献主要判别增益，稳定化目标更新主要改善后验概率尺度。因此两部分作用不同且相互补充。

6 真实数据分析

6.1 患者队列与模态

本节评价所提方法对肾切除术后12个月内肾细胞癌（RCC）复发的预测能力，关注三项突出挑战：（i）源和目标队列间的时间偏移；（ii）模态可用性的域特异异质性；（iii）医师判定复发结局的有限可用性。

评价队列含7713名患者：2000-2022年在 Mass General Brigham（MGB）医疗系统确诊 RCC 并接受肾切除术，术后12个月内观察到复发事件，或术后至少有12个月随访记录（Hou 等，2026）。入组时间定义为首次出现映射到 `PheCode 189.11`（肾恶性肿瘤，肾盂除外）的 ICD 编码的日历年份。2000-2016年入组者构成源队列，2017-2022年入组者构成目标队列。

主要分析包含按观测模态模式分组的全部5674名源患者，以及所有模态均可用的379名目标患者。其余1660名目标患者缺少一个或多个辅助模态，纳入补充分析。主要分析的6053名患者中，196名有医师判定的12个月复发标签；其余5857名的复发状态以 LATTE（标签高效的事件表型识别，LAbel-efficienT incidenT phEnotyping）生成的替代标签表示（Wen 等，2024；Hou 等，2026）。有医师判定标签时使用该标签，否则使用 LATTE 替代标签。

收集五种数据模态。（i）模态1含 $d_1 = 14$ 个由 NICE 整理的人口学和临床病理属性，包括 TNM 分期、基于病理的分级与组织学亚型（Hou 等，2026）。（ii）模态2含 $d_2 = 87$ 个医疗利用和编码 EHR 计数特征，包括 PheCode、RxNorm、CCS/PCS 和标准化 UMLS 概念唯一标识符（CUI）（Gronsbell 等，2025）。与 RCC 复发有关的 EHR 编码通过 ONCE 特征选择程序筛选（Xiong 等，2023）。（iii）模态3含 $d_3 = 14$ 个从术前 CT 放射学报告中提取、由 NILE 筛选的 UMLS CUI（Yu 等，2013），重点为肿瘤包膜、淋巴结侵袭和坏死等解剖特征。（iv）模态4含 $d_4 = 27$ 个原始 CT 图像定量特征，使用 nnU-Net 分割肿瘤（Isensee 等，2021），再由 PyRadiomics 提取（Van Griethuysen 等，2017）。（v）模态5含 $d_5 = 56$ 个残差图像-文本特征，用于表示报告语义嵌入未解释的 CT 信息（Radford 等，2021；Bannur 等，2023）。模态1是参考模态，其余均为辅助模态。

2000-2016年入组患者按模态可用性分为三个源域：$n_1 = 265$ 人有模态1、2；$n_2 = 4248$ 人有模态1、2、3；$n_3 = 1161$ 人有模态1、4、5。2017-2022年入组、模态完整的 $n_0 = 379$ 人构成目标域。目标复发标签在预处理、模型拟合、调参和目标适应全过程中均掩蔽，仅在最终评价时揭示。队列和模态构成见表1；其他真实数据配置见补充材料。

表1。 MGB-RCC 主要分析中的患者队列与模态构成。事件在有医师判定12个月复发标签时由其定义，否则使用 LATTE 替代标签。表头：Domain＝域；Cohort years＝队列年份；Observed modalities＝观测模态；Events＝事件数；Gold labels＝金标准标签数；Surrogate labels＝替代标签数；Pooled source＝合并源域；Total＝总计。$d_{\mathcal{A}_m}$ 为观测特征维数。

Domain	Cohort years	Observed modalities	n_m	$d_{\mathcal{A}_m}$	Events	Gold labels	Surrogate labels
Source, $m = 1$	2000–2016	{1, 2}	265	101	56	5	260
Source, $m = 2$	2000–2016	{1, 2, 3}	4,248	115	805	130	4,118
Source, $m = 3$	2000–2016	{1, 4, 5}	1,161	97	172	43	1,118
Target, $m = 0$	2017–2022	{1, 2, 3, 4, 5}	379	198	100	18	361
Pooled source	2000–2016	Heterogeneous	5,674	–	1,033	178	5,496
Total	2000–2022	–	6,053	–	1,133	196	5,857

6.2 任务 基线与评价方案

任务与基线模型。 主要任务是利用表1中的异质源域，预测晚期完整目标队列的12个月 RCC 复发。此设计评价在医师判定监督有限时，跨日历时间与模态模式的迁移。为防目标标签泄漏，在评价前固定目标 CCA 秩 $r_0 = 10$。比较方法为非线性梯度提升树 XGBoost（Chen 和 Guestrin，2016）；为每种模态配置分别拟合稀疏线性模型的类别特异 logistic LASSO（Tibshirani，1996）；学习正则化多块成分的 RGCCA（Tenenhaus 和 Tenenhaus，2011）；以及从块状重叠数据恢复共享低秩表示的 BONMI（Zhou 等，2023）。全部比较方法仅使用源域数据及其相应复发标签训练，再直接应用于目标数据。

评价方案。 主要指标为 Brier 技能评分（BSS）与绝对校准差。BSS 衡量相对于恒定预测器（预测值等于目标事件率）的概率预测改进（Brier，1950；Mason，2004）。该患病率基准防止模型仅因预测多数结局而显得有利。绝对校准差为平均预测风险与观察到的目标事件率之差的绝对值（Van Calster 等，2016）。标签偏移下，该指标尤其有用，因为它直接检验预测风险能否恢复目标事件率；AUC 则只衡量排序，即使存在系统性失校准也可能不变。另外报告 AUC 和平均精确率（AP）。参照 Robin 等（2011）、Collins 等（2016）等工作，对固定目标预测进行1000次按事件分层的患者级 bootstrap 重抽样，不重新拟合模型，以获得标准误。调参、bootstrap 和消融细节见补充材料。

表2。 完整目标队列的 BSS、校准差（Cal. gap）、AUC 和 AP。括号为 bootstrap 标准误。BSS、AUC、AP 越高越好，校准差越低越好；最优值加粗。Method＝方法；Proposed＝所提方法；Category-specific LASSO＝类别特异 LASSO。

Method	BSS	Cal. gap	AUC	AP
Proposed	**0.4194 (0.0485)**	**0.0015 (0.0070)**	**0.9027 (0.0153)**	0.7057 (0.0465)
XGBoost	0.3457 (0.0446)	0.0846 (0.0100)	0.9008 (0.0166)	**0.7564 (0.0363)**
Category-specific LASSO	0.3021 (0.0497)	0.0752 (0.0105)	0.8749 (0.0205)	0.6911 (0.0451)
RGCCA	0.1419 (0.0339)	0.1064 (0.0071)	0.8619 (0.0181)	0.6048 (0.0430)
BONMI	-0.0347 (0.0098)	0.0860 (0.0021)	0.5329 (0.0348)	0.3030 (0.0296)

6.3 结果

表2报告所提方法和基线的 BSS、校准差、AUC、AP。关键观察如下。（i）就总体概率准确性而言，最高 BSS 表明，即使目标队列患病率为26.39%、存在标签不平衡，所提方法仍比基线更准确估计患者级复发概率。（ii）就边际校准而言，最小校准差表明，在源队列18.21%到目标队列26.39%的复发率时间偏移下，所提方法的平均预测风险最接近观测目标事件率。如第6.2节所述，这种性能不是 AUC 所衡量的。（iii）就跨指标一致性而言，所提方法在 BSS、校准差和 AUC 上均排名第一，在 AP 上也有竞争力。这些指标评价互补方面，说明优势不局限于单一评价准则。结果支持将所提方法作为时间患病率偏移、模态可用性异质和医师判定监督有限情况下，12个月 RCC 复发预测的稳健方法。

补充材料

《标签偏移与块状模态缺失下的多模态域适应》补充材料

Z. Wang、Z. Dou、M. Liu、T. Cai

补充摘要

本补充材料提供单一共同旋转对齐和目标条件结局估计的证明、模拟研究的完整实现与数值细节，以及肾细胞癌复发分析的预先指定方案与支持性结果。理论使用单个原始表示速率，并将其显式传播经过 PCA、目标 CCA、源岭映射及拟合坐标。似然比估计与迁移仍是单独的干扰部分；在局部剖面曲率条件下，两部分得到端到端后验速率。模拟附录记录主要多元、替代辅助及交叉消融实验，包括原始特征和普通 XGBoost、LASSO 基准，以及正文图2、3对应的数值汇总。真实数据附录记录队列和标签构成、泄漏控制、主要完整目标分析、其他晚期目标配置、完整域匹配模态敏感性分析，以及交叉 CCA-目标 EM 消融。

关键词： 消融研究；域适应；多模态数据融合；肾细胞癌；补充证明；替代结局。

S1 单一共同旋转对齐与目标条件结局一致性的证明

S1.1 证明路线与总体记号

证明有两条分支。核心表示结果验证一个原始速率 Δ_n，经目标 CCA 和源岭映射传播，在一个共同旋转下恢复所有拟合坐标。结局分支将该坐标误差与最终对齐似然比学习器的内在速率 κ_n 结合。依赖顺序为

$$\begin{aligned}\text{PCA + weights + sampling} &\Longrightarrow \Delta_n \Longrightarrow \delta_{\mathrm{CCA}}^{-1}\Delta_n \text{ (CCA)}\\ &\Longrightarrow \{\underline{\lambda}^{-1}(1+\delta_{\mathrm{CCA}}^{-1})+\underline{\lambda}^{-2}\}\Delta_n \text{ (ridge)}\\ &\Longrightarrow \text{common-orientation fitted coordinates,}\\ \text{coordinate error} + \kappa_n &\Longrightarrow \text{evaluated ratio error} \Longrightarrow \widehat{\boldsymbol{\theta}}^{(0)} - \boldsymbol{\theta}^{(0)} \Longrightarrow \widehat{p} - p_0.\end{aligned}$$

图式中：PCA + weights + sampling＝PCA、权重与抽样；ridge＝岭映射；common-orientation fitted coordinates＝共同取向的拟合坐标；coordinate error＝坐标误差；evaluated ratio error＝求值后的比值误差。

在高层定理中，Δ_n 是 CCA 之前得分和矩事件的单一包络。PCA 后端只用四个可控输入构成它：结局权重误差、参考 PCA 误差、辅助 PCA 误差和通常的抽样波动。初始参考校准仅通过结局权重误差进入；代入标准化与经验矩是上述四个输入的结果，不再重复加入。后续引理把同一包络传播到 CCA、岭映射及拟合坐标。相反，κ_n 针对总体对齐坐标可获得时的最终似然比学习器；用拟合坐标替代总体坐标的稳定性消耗一次 Δ_n。不假设二者独立或存在相对次序。表示结果不蕴含似然比可迁移性；特别是共同取向并不使目标 CCA 映射等于源岭映射。因此假设6保留单独的比值条件。这种区分也允许其他表示后端通过验证相同原始 $O_p(\Delta_n)$ 得分和矩事件来替代 PCA。

目标域编号0，源域编号 $m = 1, \ldots, M$。以 n_m 表示域样本量，$n_{\min} = \min_{0\le m\le M} n_m$ 表示最小域样本量，$N_s = \sum_{m=1}^{M} n_m$ 表示总源样本量，$N = n_0 + N_s = \sum_{m=0}^{M} n_m$ 表示总样本量。结局取值于有限集 $\mathcal{Y}$。目标分布标准化之前，$\mathbf{t}_1^{(m)} \in \mathbb{R}^h$ 为总体原始参考得分，$\mathbf{t}_k^{(m)} \in \mathbb{R}^{\ell_k}$ 为 $k \in \mathcal{A}_m\backslash\{1\}$ 的原始辅助得分，令 $\mathbf{t}^{(m)} = \mathrm{col}\{\mathbf{t}_k^{(m)} : k \in \mathcal{A}_m\backslash\{1\}\}$。经验行堆叠矩阵为 $\widehat{\mathbf{T}}_1^{(m)}$、$\widehat{\mathbf{T}}_k^{(m)}$，总体对应量为 $\mathbf{T}_1^{(m)}$、$\mathbf{T}_k^{(m)}$。

设 $\omega_0(\mathbf{y}) \equiv 1$，并对每个源域 $m \ge 1$ 定义目标混合期望

$$E_m^{\mathrm{tar}}\{a\} = E_m\left[\omega_m(\mathbf{y}^{(m)})a\right] = \sum_{\mathbf{y}\in\mathcal{Y}} \rho_y(\mathbf{y};\boldsymbol{\theta}^{(0)}) E_m(a \mid \mathbf{y}^{(m)} = \mathbf{y}) \tag{S1.1}$$

令 $E_0^{\mathrm{tar}} = E_0$。特别地，$E_m\{\omega_m(\mathbf{y}^{(m)})\} = 1$。对每个可用得分块，定义目标分布均值和协方差

$$\begin{aligned}\boldsymbol{\mu}_{1,m} &= E_m^{\mathrm{tar}}(\mathbf{t}_1^{(m)}), & \mathbf{S}_{1,m} &= E_m^{\mathrm{tar}}\{(\mathbf{t}_1^{(m)} - \boldsymbol{\mu}_{1,m})(\mathbf{t}_1^{(m)} - \boldsymbol{\mu}_{1,m})^{\mathrm{T}}\},\\ \boldsymbol{\mu}_{k,m} &= E_m^{\mathrm{tar}}(\mathbf{t}_k^{(m)}), & \mathbf{S}_{k,m} &= E_m^{\mathrm{tar}}\{(\mathbf{t}_k^{(m)} - \boldsymbol{\mu}_{k,m})(\mathbf{t}_k^{(m)} - \boldsymbol{\mu}_{k,m})^{\mathrm{T}}\}.\end{aligned}$$

总体标准化得分为

$$\mathbf{r}^{(m)} = \mathbf{S}_{1,m}^{-1/2}(\mathbf{t}_1^{(m)} - \boldsymbol{\mu}_{1,m}), \qquad \mathbf{z}_k^{(m)} = \mathbf{S}_{k,m}^{-1/2}(\mathbf{t}_k^{(m)} - \boldsymbol{\mu}_{k,m}),$$

并令 $\mathbf{z}^{(m)} = \mathrm{col}\{\mathbf{z}_k^{(m)} : k \in \mathcal{A}_m\backslash\{1\}\}$。相应行堆叠矩阵为 $\mathbf{R}^{(m)}$、$\mathbf{Z}^{(m)}$；帽号表示代入标准化矩阵。对于目标域，记

$$\boldsymbol{\Sigma}_{rr}^{(0)} = E_0(\mathbf{r}^{(0)}\mathbf{r}^{(0)\mathrm{T}}), \qquad \boldsymbol{\Sigma}_{zz}^{(0)} = E_0(\mathbf{z}^{(0)}\mathbf{z}^{(0)\mathrm{T}}), \qquad \boldsymbol{\Sigma}_{rz}^{(0)} = E_0(\mathbf{r}^{(0)}\mathbf{z}^{(0)\mathrm{T}}).$$

总体正则化 CCA 算子为

$$\boldsymbol{\Gamma}^{(0)} = \{\boldsymbol{\Sigma}_{rr}^{(0)}\}^{-1/2}\boldsymbol{\Sigma}_{rz}^{(0)}(\boldsymbol{\Sigma}_{zz}^{(0)} + \lambda_z\mathbf{I})^{-1/2} = \mathbf{P}_\Gamma^{(0)}\mathbf{D}_\Gamma^{(0)}\{\mathbf{Q}_\Gamma^{(0)}\}^{\mathrm{T}}, \tag{S1.2}$$

其中 $\mathbf{P}_\Gamma^{(0)}$、$\mathbf{Q}_\Gamma^{(0)}$ 包含前 r_0 个左右奇异向量。用三个经验协方差矩阵替换总体矩阵，得到经验算子 $\widehat{\boldsymbol{\Gamma}}^{(0)}$。定义

$$\mathbf{A}^{(0)} = \{\boldsymbol{\Sigma}_{rr}^{(0)}\}^{-1/2}\mathbf{P}_\Gamma^{(0)}, \qquad \mathbf{B}^{(0)} = (\boldsymbol{\Sigma}_{zz}^{(0)} + \lambda_z\mathbf{I})^{-1/2}\mathbf{Q}_\Gamma^{(0)}.$$

将 $\mathbf{B}^{(0)} = \mathrm{col}\{\mathbf{B}_2^{(0)}, \ldots, \mathbf{B}_K^{(0)}\}$ 分块。源域 m 的正则化总体对齐映射，使用与正文相同的惩罚准则定义：

$$\mathbf{G}^{(m)} = \arg\min_{\mathbf{G}} \left\{ E_m\left[\omega_m(\mathbf{y}^{(m)})\left\|\{\mathbf{A}^{(0)}\}^{\mathrm{T}}\mathbf{r}^{(m)} - \mathbf{G}^{\mathrm{T}}\mathbf{z}^{(m)}\right\|_2^2\right] + \lambda_m\|\mathbf{G}\|_{\mathrm{F}}^2 \right\}. \tag{S1.3}$$

令 $d_{z,m} = \dim(\mathbf{z}^{(m)}) = \sum_{k\in\mathcal{A}_m\backslash\{1\}}\ell_k$，并定义

$$\boldsymbol{\Sigma}_{zz}^{(m)} = E_m^{\mathrm{tar}}\{\mathbf{z}^{(m)}\mathbf{z}^{(m)\mathrm{T}}\}, \qquad \boldsymbol{\Sigma}_{zr}^{(m)} = E_m^{\mathrm{tar}}\{\mathbf{z}^{(m)}\mathbf{r}^{(m)\mathrm{T}}\}. \tag{S1.4}$$

标准化得分在 E_m^{tar} 下均值为零，因此这些量是结局重加权源分布下的辅助得分协方差与辅助-参考交叉矩。若 $\lambda_m > 0$，则 $\boldsymbol{\Sigma}_{zz}^{(m)} + \lambda_m\mathbf{I}_{d_{z,m}}$ 正定，式(S1.3)的唯一最优解为

$$\mathbf{G}^{(m)} = \left\{\boldsymbol{\Sigma}_{zz}^{(m)} + \lambda_m\mathbf{I}_{d_{z,m}}\right\}^{-1}\boldsymbol{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}. \tag{S1.5}$$

将 $\mathbf{G}^{(m)} = \mathrm{col}\{\mathbf{G}_k^{(m)} : k \in \mathcal{A}_m\backslash\{1\}\}$ 分块。个体层面对齐坐标为

$$\begin{aligned}
\mathbf{u}_i^{(m)} &= \{\mathbf{A}^{(0)}\}^{\mathrm{T}}\mathbf{r}_i^{(m)} \in \mathbb{R}^{r_0}, \quad 0 \le m \le M,\\
\mathbf{v}_{k,i}^{(0)} &= \{\mathbf{B}_k^{(0)}\}^{\mathrm{T}}\mathbf{z}_{k,i}^{(0)} \in \mathbb{R}^{r_0}, \quad k = 2, \ldots, K,\\
\mathbf{v}_{k,i}^{(m)} &= \{\mathbf{G}_k^{(m)}\}^{\mathrm{T}}\mathbf{z}_{k,i}^{(m)} \in \mathbb{R}^{r_0}, \quad k \in \mathcal{A}_m \setminus \{1\}, \quad m \ge 1.
\end{aligned}$$

每个域中，按模态编号递增排列 $\mathbf{v}_i^{(m)} = \mathrm{col}\{\mathbf{v}_{k,i}^{(m)} : k \in \mathcal{A}_m\backslash\{1\}\}$。第 i 行分别为 $\mathbf{u}_i^{(m)\mathrm{T}}$、$\mathbf{v}_{k,i}^{(m)\mathrm{T}}$、$\mathbf{v}_i^{(m)\mathrm{T}}$ 的矩阵记为 $\mathbf{U}^{(m)}$、$\mathbf{V}_k^{(m)}$、$\mathbf{V}^{(m)}$。令 $q_0 = K - 1$。源域观测辅助索引递增写为 $k_{m,1} < \cdots < k_{m,q_m}$，其中 $q_m = |\mathcal{A}_m\backslash\{1\}|$。后续扰动界使用的经验行堆叠对应量明确为

$$
\begin{aligned}
\widehat{\mathbf{U}}^{(m)} &= \widehat{\mathbf{R}}^{(m)}\widehat{\mathbf{A}}^{(0)}, \qquad 0 \le m \le M,\\
\widehat{\mathbf{V}}_k^{(0)} &= \widehat{\mathbf{Z}}_k^{(0)}\widehat{\mathbf{B}}_k^{(0)}, \qquad k = 2, \dots, K,\\
\widehat{\mathbf{V}}_k^{(m)} &= \widehat{\mathbf{Z}}_k^{(m)}\widehat{\mathbf{G}}_k^{(m)}, \qquad k \in \mathcal{A}_m \setminus \{1\}, \quad m \ge 1,\\
\widehat{\mathbf{V}}^{(0)} &= \big[\widehat{\mathbf{Z}}_2^{(0)}\widehat{\mathbf{B}}_2^{(0)} \ \cdots \ \widehat{\mathbf{Z}}_K^{(0)}\widehat{\mathbf{B}}_K^{(0)}\big],\\
\widehat{\mathbf{V}}^{(m)} &= \big[\widehat{\mathbf{Z}}_{k_{m,1}}^{(m)}\widehat{\mathbf{G}}_{k_{m,1}}^{(m)} \ \cdots \ \widehat{\mathbf{Z}}_{k_{m,q_m}}^{(m)}\widehat{\mathbf{G}}_{k_{m,q_m}}^{(m)}\big], \qquad m \ge 1.
\end{aligned}
\tag{S1.6}
$$

最后两行按模态递增顺序水平拼接。因此，个体向量 $\mathbf{u}_i^{(m)}$、$\mathbf{v}_{k,i}^{(m)}$ 均为 r_0 维；$\mathbf{U}^{(m)}$、$\mathbf{V}_k^{(m)}$ 是 $n_m \times r_0$ 矩阵；$\mathbf{V}^{(m)}$ 是 $n_m \times q_m r_0$ 有序块矩阵。源岭重构本身则是 q_m 个拟合块之和。

以 $\mathbf{Q}_r \in \mathcal{O}(h)$ 和 $\mathbf{Q}_z^{(m)} = \mathrm{blockdiag}\{\mathbf{Q}_{z,k}^{(m)} : k \in \mathcal{A}_m \backslash \{1\}\}$ 表示对齐前得分基旋转。共同对齐空间旋转为 $\mathbf{O} \in \mathcal{O}(r_0)$。对行堆叠矩阵 $\mathbf{H}$，记

$$
\|\mathbf{H}\|_{\mathrm{F},m}^2 = \frac{\sum_{i \in \mathcal{L}_m} w_i^{(m)} \|\mathbf{h}_i\|_2^2}{\sum_{j \in \mathcal{L}_m} w_j^{(m)}}.
$$

带标签源个体有 $w_i^{(m)} = \omega_m\big(\mathbf{y}_i^{(m)}\big)$，目标域有 $w_i^{(0)} = 1$、$\mathcal{L}_0 = \{1, \ldots, n_0\}$。令

$$
\mathbf{W}_m = \frac{\mathrm{diag}\{w_i^{(m)} : i \in \mathcal{L}_m\}}{\sum_{j \in \mathcal{L}_m} w_j^{(m)}}, \qquad \mathbf{W}_0 = n_0^{-1}\mathbf{I},
$$

由 $\widehat{w}_i^{(m)}$ 同样定义 $\widehat{\mathbf{W}}_m$。经验岭矩为

$$
\widehat{\mathbf{\Sigma}}_{zz}^{(m)} = \widehat{\mathbf{Z}}^{(m)\mathrm{T}}\widehat{\mathbf{W}}_m\widehat{\mathbf{Z}}^{(m)}, \qquad \widehat{\mathbf{\Sigma}}_{zr}^{(m)} = \widehat{\mathbf{Z}}^{(m)\mathrm{T}}\widehat{\mathbf{W}}_m\widehat{\mathbf{R}}^{(m)}.
$$

正文的经验岭目标除以 $\sum_{i \in \mathcal{L}_m} \widehat{w}_i^{(m)}$ 不改变其最小化点。除后目标具有上述归一化矩矩阵及惩罚 λ_m，其正规方程为

$$
\widehat{\mathbf{G}}^{(m)} = \{\widehat{\mathbf{\Sigma}}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\}^{-1}\widehat{\mathbf{\Sigma}}_{zr}^{(m)}\widehat{\mathbf{A}}^{(0)}.
$$

因此经验和总体映射的惩罚尺度完全相同。单个序列 Δ_n 控制初始权重、标准化得分和二阶矩误差；CCA、岭和拟合坐标误差由其推导。

记号速览。粗体小写表示个体列向量，粗体大写表示行堆叠矩阵，帽号始终表示估计量。col 将个体块竖直堆叠；式(S1.6)的方括号则将行矩阵块水平拼接。原始记号表如下，随后逐行给出中文释义。

Symbol	Role
$\mathbf{T}_1^{(m)}, \mathbf{T}_k^{(m)}$	Raw backend score matrices before target-distribution standardization.
$\mathbf{R}^{(m)}, \mathbf{Z}^{(m)}$	Target-distribution standardized, pre-alignment reference and stacked auxiliary scores.
$\mathbf{A}^{(0)}, \mathbf{B}^{(0)}, \mathbf{G}^{(m)}$	Population target CCA maps and the regularized source alignment map; $\mathbf{G}_k^{(m)}$ is its block for modality k.
$\mathbf{\Sigma}_{zz}^{(m)}, \mathbf{\Sigma}_{zr}^{(m)}$	Outcome-reweighted auxiliary-score covariance and auxiliary–reference cross-moment defining the penalized population ridge target.
$\mathbf{u}_i^{(m)}, \mathbf{v}_{k,i}^{(m)}, \mathbf{v}_i^{(m)}$	Subject-level aligned reference vector, aligned auxiliary-block vector, and ordered auxiliary collection.
$\mathbf{U}^{(m)}, \mathbf{V}_k^{(m)}, \mathbf{V}^{(m)}$	Corresponding row-stacked reference matrix, auxiliary-block matrix, and ordered auxiliary matrix.
$\mathbf{Q}_r, \mathbf{Q}_{z,k}^{(m)}$	Arbitrary rotations of the raw score bases induced by PCA or another representation backend.
$\mathbf{O}$	One common aligned-space rotation.
$\omega_m(\mathbf{y}), w_i^{(m)}$	Outcome-state ratio and its subject-level evaluation; hats denote their estimators.
$n_m, n_{\min}, N_s, N$	Domain size, smallest domain size, total source size and total size, respectively.
$\mathrm{LR}_{\mathrm{U,V\mid Y}}^{(0)}(\mathbf{u}, \mathbf{v} \mid \mathbf{y}), \widehat{\mathrm{LR}}_i(\mathbf{y})$	Population target aligned likelihood ratio and its fitted-coordinate estimate; $\widehat{\mathrm{LR}}_i^{\circ}$ denotes the counterfactual population-coordinate output.
Δ_n	Single envelope for the pre-CCA score and moment events; for PCA its four inputs are weight, reference-PCA, auxiliary-PCA and sampling errors in (S1.18).
κ_n	Intrinsic rate of the final aligned likelihood-ratio learner at population coordinates; perturbing those coordinates is excluded.

- $\mathbf{T}_1^{(m)}$, $\mathbf{T}_k^{(m)}$：目标分布标准化前的原始后端得分矩阵。
- $\mathbf{R}^{(m)}$, $\mathbf{Z}^{(m)}$：目标分布标准化后的对齐前参考得分与堆叠辅助得分。
- $\mathbf{A}^{(0)}$, $\mathbf{B}^{(0)}$, $\mathbf{G}^{(m)}$：总体目标 CCA 映射及正则化源对齐映射；$\mathbf{G}_k^{(m)}$ 是模态 k 对应块。
- $\mathbf{\Sigma}_{zz}^{(m)}$, $\mathbf{\Sigma}_{zr}^{(m)}$：结局重加权辅助得分协方差与辅助-参考交叉矩，定义惩罚总体岭目标。
- $\mathbf{u}_i^{(m)}$, $\mathbf{v}_{k,i}^{(m)}$, $\mathbf{v}_i^{(m)}$：个体对齐参考向量、对齐辅助块向量和有序辅助集合。
- $\mathbf{U}^{(m)}$, $\mathbf{V}_k^{(m)}$, $\mathbf{V}^{(m)}$：相应行堆叠参考矩阵、辅助块矩阵、有序辅助矩阵。
- $\mathbf{Q}_r$, $\mathbf{Q}_{z,k}^{(m)}$：PCA 或其他表示后端引起的原始得分基任意旋转。
- $\mathbf{O}$：一个共同的对齐空间旋转。
- $\omega_m(\mathbf{y})$, $w_i^{(m)}$：结局状态比及其个体取值；帽号为估计量。
- n_m, $n_{\min}$, N_s, N：域样本量、最小域样本量、总源样本量及总样本量。
- $\mathrm{LR}_{\mathrm{U,V|Y}}^{(0)}(\mathbf{u}, \mathbf{v} \mid \mathbf{y})$, $\widehat{\mathrm{LR}}_i(\mathbf{y})$：总体目标对齐似然比及其拟合坐标估计；$\widehat{\mathrm{LR}}_i^{\circ}$ 为反事实的总体坐标输出。
- Δ_n：CCA 前得分与矩事件的单一包络；PCA 时四个输入为式(S1.18)中的权重、参考 PCA、辅助 PCA 和抽样误差。
- κ_n：总体坐标处最终对齐似然比学习器的内在速率，不包括这些坐标的扰动。

速率的来源与核算。 以下清单区分外部提供的不等式、方法特异推导及学习器假设，不再引入其他速率序列。

1. Δ_n **的输入**。 最大结局权重误差、参考 PCA 误差、辅助 PCA 误差和 $n_{\min}^{-1/2}$ 抽样波动。初始参考校准仅通过权重误差影响对齐。Garg 等（2020，定理3）以目标样本平方根倒数项加校准误差控制基于似然的标签偏移估计；若后者也是平方根阶，平滑变换给出平方根阶权重误差。协方差集中来自 Vershynin（2018，定理4.7.1、习题4.7.3）；总体间隙 Procrustes 因子来自 Yu 等（2015，定理2）。
2. **由** Δ_n **验证的量**。 引理 S1.2 依据上述输入、固定保留维数和有界重叠，推导标准化得分恢复及五个矩事件。它们不是额外加项。
3. **推导出的对齐误差**。 引理 S1.3 将所引子空间定理用于一个对称扩张，得到 $O_p\{\left(1+\delta_{\mathrm{CCA}}^{-1}\right)\Delta_n\}$；共同旋转是这里的推论。引理 S1.4 再通过正规方程、预解式恒等式和乘积分解控制岭映射及拟合坐标，无需新速率输入。
4. **学习器假设**。 假设6把 κ_n 赋予总体坐标似然比学习器，把 Δ_n 赋予完整拟合-求值映射在坐标扰动下的稳定性。正则参数 M 估计提供一条平滑有限维途径（van der Vaart，2000，第5章）。对于提升树，两项仍为假设：Chen 和 Guestrin（2016）说明算法，而不提供统计速率。
5. **推导出的目标速率**。 定理 S1.6 加入预言式目标得分项 $n_0^{-1/2}$，得到 $O_p\{n_0^{-1/2}+\kappa_n+\Delta_n\}$。

因此， Δ_n 是共同上包络，不是输入之和；后续证明不重复核算 Δ_n 或 κ_n。

本证明部分始终假设所有源金标准结局均被观测，因此对 $m \geq 1$， $\mathcal{L}_m = \{1, \ldots, n_m\}$；构造对齐矩时， $\mathcal{L}_m$ 即指这些个体。下述速率定理不涵盖可选替代桥。

S1.2 正则条件

假设4（标签偏移与重叠）。 对每个源域 m 和目标概率为正的结局状态 $\mathbf{y}$，保留总体得分子空间存在固定正交归一基，使得

$$(\mathbf{t}_1^{(m)}, \mathbf{t}^{(m)}) \mid \{\mathbf{y}^{(m)} = \mathbf{y}\} \overset{d}{=} (\mathbf{t}_1^{(0)}, \mathbf{t}^{(m,0)}) \mid \{\mathbf{y}^{(0)} = \mathbf{y}\}, \tag{S1.7}$$

且 $\omega_m(\mathbf{y}) = \rho_y\left(\mathbf{y}; \theta^{(0)}\right)/\rho_y\left(\mathbf{y}; \theta^{(m)}\right)$ 一致有界。 $\mathbf{t}^{(m,0)}$ 是目标辅助潜在得分代表元，限制到源域 m 观测的块，并在相应固定总体取向下表示。此等式是总体传输假设，不声称各域数值样本 PCA 坐标相同。引理 S1.2 的旋转将样本基与这些代表元匹配。由引理 S1.1，传输后的源均值和协方差等于目标混合均值和协方差，因此定义 $(\mathbf{r}, \mathbf{z})$ 的确定性总体标准化后，同一等式仍成立。

假设5（稳定的得分 CCA 与岭矩）。 域数、模态块数与保留秩固定，相关总体二阶、四阶矩有界。用于标准化的原始得分协方差保留特征值下界为 $c_0 > 0$；另有 $\lambda_{\min}\left(\mathbf{\Sigma}_{rr}^{(0)}\right) \geq c_0$ 和 $\lambda_{\min}\left(\mathbf{\Sigma}_{zz}^{(0)} + \lambda_z \mathbf{I}\right) \geq c_0$。式(S1.2)奇异值间隙满足 $\sigma_{r_0}\left(\mathbf{\Gamma}^{(0)}\right) - \sigma_{r_0+1}\left(\mathbf{\Gamma}^{(0)}\right) \geq \delta_{\mathrm{CCA}} > 0$。CCA 和岭调参参数固定，或从界一致成立的有限网格中选择，并且 $0 < \underline{\lambda} \leq \lambda_m \leq \bar{\lambda} < \infty$。对于确定序列 $\Delta_n \to 0$ 及适当得分旋转，以下原始误差一致为 $O_p\left(\Delta_n\right)$：

$$\max_m \|\widehat{\mathbf{R}}^{(m)} - \mathbf{R}^{(m)}\mathbf{Q}_r\|_{\mathrm{F},m} + \max_m \|\widehat{\mathbf{Z}}^{(m)} - \mathbf{Z}^{(m)}\mathbf{Q}_z^{(m)}\|_{\mathrm{F},m} = O_p(\Delta_n), \tag{S1.8}$$

$$\|\widehat{\mathbf{\Sigma}}_{rr}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{\Sigma}_{rr}^{(0)}\mathbf{Q}_r\|_{\mathrm{op}} + \|\widehat{\mathbf{\Sigma}}_{zz}^{(0)} - \mathbf{Q}_z^{(0)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(0)}\mathbf{Q}_z^{(0)}\|_{\mathrm{op}} = O_p(\Delta_n), \tag{S1.9}$$

$$\|\widehat{\mathbf{\Sigma}}_{rz}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{\Sigma}_{rz}^{(0)}\mathbf{Q}_z^{(0)}\|_{\mathrm{op}} = O_p(\Delta_n). \tag{S1.10}$$

源岭矩满足

$$\max_m \|\widehat{\mathbf{\Sigma}}_{zz}^{(m)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(m)}\mathbf{Q}_z^{(m)}\|_{\mathrm{op}} = O_p(\Delta_n), \tag{S1.11}$$

$$\max_m \|\widehat{\mathbf{\Sigma}}_{zr}^{(m)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{Q}_r\|_{\mathrm{op}} = O_p(\Delta_n). \tag{S1.12}$$

目标 CCA、源岭及拟合坐标误差不属于 Δ_n 的定义，而是下面推导的结论。

假设6（目标比值与剖面准则）。令

$$\mathrm{LR}_{\mathrm{U,V|Y}}^{(0)}(\mathbf{u}, \mathbf{v} \mid \mathbf{y}) = \frac{p_0(\mathbf{u}, \mathbf{v} \mid \mathbf{y})}{p_0(\mathbf{u}, \mathbf{v} \mid \mathbf{0})}.$$

将估计坐标表达在共同总体取向后，记 $\mathrm{LR}_i(\mathbf{y}) = \mathrm{LR}_{\mathrm{U,V|Y}}^{(0)}\{\mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)} \mid \mathbf{y}\}$，$\widehat{\mathrm{LR}}_i(\mathbf{y})$ 为估计目标坐标处的估计比值。为揭示两种比值误差来源而不引入其他速率，令 $\widehat{\mathrm{LR}}_i^{\circ}(\mathbf{y})$ 为同一个比值学习程序在源训练输入和目标求值输入均使用总体对齐坐标时的反事实输出。三个比值均非负，并在 $\mathbf{0}$ 归一为1。确定序列 $\kappa_n \to 0$ 表示该总体坐标学习器的内在估计与迁移速率，不包括已由 Δ_n 吸收的结局权重误差，也不包括任何坐标估计误差。假设

$$\frac{1}{n_0}\sum_{i=1}^{n_0} \max_{\mathbf{y}\in\mathcal{Y}} |\widehat{\mathrm{LR}}_i^{\circ}(\mathbf{y}) - \mathrm{LR}_i(\mathbf{y})| = O_p(\kappa_n), \tag{S1.13}$$

$$\frac{1}{n_0}\sum_{i=1}^{n_0} \max_{\mathbf{y}\in\mathcal{Y}} |\widehat{\mathrm{LR}}_i(\mathbf{y}) - \widehat{\mathrm{LR}}_i^{\circ}(\mathbf{y})| = O_p(\Delta_n), \tag{S1.14}$$

$$\frac{1}{n_0}\sum_{i=1}^{n_0} \max_{\mathbf{y}\in\mathcal{Y}} |\widehat{\mathrm{LR}}_i(\mathbf{y}) - \mathrm{LR}_i(\mathbf{y})| = O_p(\kappa_n + \Delta_n), \tag{S1.15}$$

$$\frac{1}{n_0}\sum_{i=1}^{n_0} \max_{\mathbf{y}\in\mathcal{Y}} \{\mathrm{LR}_i(\mathbf{y}) + \widehat{\mathrm{LR}}_i(\mathbf{y})\} = O_p(1). \tag{S1.16}$$

第三行由前两行及三角不等式推出；之所以列出，是因为剖面定理使用它。第一行是学习器特异条件。第二行是完整拟合-求值映射的稳定性条件，不只是目标点求值的稳定性。参数空间 Θ 紧，$\rho_y(\mathbf{y};\theta)$ 关于 θ 连续且在有限 $\mathcal{Y}$ 上一致，$\inf_{\theta\in\Theta}\rho_y(\mathbf{0};\theta) > 0$。预言式准则类

$$\ell_{\boldsymbol{\theta}}(\mathbf{u}, \mathbf{v}) = \log\left\{\sum_{\mathbf{y}\in\mathcal{Y}} \rho_y(\mathbf{y};\boldsymbol{\theta})\mathrm{LR}_{\mathrm{U,V|Y}}^{(0)}(\mathbf{u}, \mathbf{v} \mid \mathbf{y})\right\}$$

在 P_0 下为 Glivenko-Cantelli 类。其总体准则

$$\mathcal{M}(\boldsymbol{\theta}) = E_0\ell_{\boldsymbol{\theta}}(\mathbf{u}^{(0)}, \mathbf{v}^{(0)}) \tag{S1.17}$$

具有唯一最大化点 $\theta^{(0)}$。

为了获得速率结论， $\theta^{(0)}$ 为内点； ρ_y 在其邻域内二次连续可微、导数有界；负总体剖面 Hessian 在该处正定；预言式经验 Hessian 在邻域内一致收敛到总体对应量； $\theta^{(0)}$ 处的预言式经验剖面得分为 $O_p\left(n_0^{-1/2}\right)$；拟合准则满足一阶条件。对于平滑有限维比值学习器，局部强曲率和 Lipschitz 得分贡献，通过通常 M 估计扰动论证，为从式(S1.24)到式(S1.14)提供一条途径（van der Vaart，2000，第5章）。对于灵活的提升树学习器，式(S1.13)的内在速率和该坐标稳定性均保留为高层条件。

注（平均比值一致性的一种原始条件途径）。 标准支撑集与尾部条件足以导出式(S1.15)-(S1.16)。共同旋转后，假设存在目标概率趋近1的集合 $\mathcal{S}_n$，比值估计量在其趋零邻域上一致相合，总体比值在那里一致连续且有界，并满足

$$\frac{1}{n_0}\sum_{i=1}^{n_0}\mathbf{1}\{(\mathbf{u}_i^{(0)},\mathbf{v}_i^{(0)})\notin\mathcal{S}_n\}\max_{\mathbf{y}\in\mathcal{Y}}\{\mathrm{LR}_i(\mathbf{y})+\widehat{\mathrm{LR}}_i(\mathbf{y})\}=o_p(1).$$

结合式(S1.24)的坐标误差，连续模论证得到式(S1.15)； $\mathcal{S}_n$ 上的有界性与所示尾部条件给出式(S1.16)。

S1.3 传输与 PCA 后端验证

引理 S1.1（目标矩传输）。 在假设4下，对每个平方可积可测函数 f，

$$E_m\left[\omega_m(\mathbf{y}^{(m)})f\{\mathbf{t}_1^{(m)},\mathbf{t}^{(m)}\}\right]=E_0\left[f\{\mathbf{t}_1^{(0)},\mathbf{t}^{(m,0)}\}\right].$$

对标准化得分 $(\mathbf{r},\ \mathbf{z})$ 的可测函数，同一恒等式也成立。

证明。 对有限结局状态取条件期望。因子 $\omega_m(\mathbf{y})$ 消去源结局概率并用目标概率替代，再应用式(S1.7)。这就是标签偏移下通常的重要性加权恒等式（Lipton 等，2018；Garg 等，2020）。□

引理 S1.2（PCA 后端验证与原始速率）。 对每个域和观测块，假设按总体中心化的特征行独立同分布。对各域、块及确定向量 $\mathbf{a}$ 一致地，假设

$$\|\langle\mathbf{x},\mathbf{a}\rangle\|_{\psi_2}\le C_{\mathrm{sg}}\{\mathrm{var}(\langle\mathbf{x},\mathbf{a}\rangle)\}^{1/2}$$

其中 C_{sg} 固定，且协方差算子范数一致有界。原始参考块和辅助块维数记为 $d_1,\ d_k$，定义 $\mathbf{\Sigma}_{x,1}^{(m)}=\mathrm{var}\left(\mathbf{x}_1^{(m)}\right)$、 $\mathbf{\Sigma}_{x,k}^{(m)}=\mathrm{var}\left(\mathbf{x}_k^{(m)}\right)$。假设 $n_m/N\to\pi_m\in(0,\ 1)$。若 $\widehat{\mathbf{\Sigma}}_{x,1}^{(m)}$ 是域内样本协方差，令 $\widehat{\mathbf{\Sigma}}_1=\sum_{m=0}^{M}\left(n_m/N\right)\widehat{\mathbf{\Sigma}}_{x,1}^{(m)}$。合并参考块定义 $\bar{\mathbf{\Sigma}}_1=\sum_{m=0}^{M}\pi_m\mathbf{\Sigma}_{x,1}^{(m)}$；令 $\mathbf{D}_1$ 是其前 h 维特征空间的固定正交归一基，并假设第 h 处特征间隙 $\delta_1>0$。对辅助块 $(m,\ k)$， $\mathbf{D}_k^{(m)}$ 是 $\mathbf{\Sigma}_{x,k}^{(m)}$ 前 ℓ_k 维特征空间的固定正交归一基，对应间隙 $\delta_{k,m}>0$。这些基用于表示假设4的总体得分取向；改变基只会改变下面的旋转。

假设总体标准化协方差最小特征值至少为 $c_0>0$。选择单个确定序列 $\Delta_n\to0$，使得

$$\max_{1\le m\le M}\max_{\mathbf{y}\in\mathcal{Y}}|\widehat{\omega}_m(\mathbf{y})-\omega_m(\mathbf{y})| = O_p(\Delta_n),$$
$$\frac{\sqrt{h}}{\delta_1}\left[\max_{0\le m\le M}\left\{\sqrt{\frac{d_1}{n_m}}+\frac{d_1}{n_m}\right\}+\max_{0\le m\le M}\left|\frac{n_m}{N}-\pi_m\right|\right] = O(\Delta_n),$$
$$\max_{0\le m\le M}\max_{k\in\mathcal{A}_m\setminus\{1\}}\frac{\sqrt{\ell_k}}{\delta_{k,m}}\left\{\sqrt{\frac{d_k}{n_m}}+\frac{d_k}{n_m}\right\} = O(\Delta_n),\qquad n_{\min}^{-1/2} = O(\Delta_n). \tag{S1.18}$$

则存在共同参考旋转 $\mathbf{Q}_r$ 和域-块旋转 $\mathbf{Q}_{z,k}^{(m)}$，使得

$$\max_m n_m^{-1/2}\|\widehat{\mathbf{T}}_1^{(m)}-\mathbf{T}_1^{(m)}\mathbf{Q}_r\|_{\mathrm{F}}+\max_{m,k}n_m^{-1/2}\|\widehat{\mathbf{T}}_k^{(m)}-\mathbf{T}_k^{(m)}\mathbf{Q}_{z,k}^{(m)}\|_{\mathrm{F}} = O_p(\Delta_n). \tag{S1.19}$$

在代入式目标混合标准化之后，所有原始事件(S1.8)-(S1.12)均以同一速率 $O_p(\Delta_n)$ 成立。因此，只要 $\Delta_n\to 0$，PCA 后端即验证假设5的随机部分。等价地，可控性要求权重误差为 $o_p(1)$，且式(S1.18)每个确定性的 PCA、域比例与抽样表达式均趋零；下游引理不再对 Δ_n 增加其他随机要求。

证明。 每个域内，由 Vershynin（2018，定理4.7.1、习题4.7.3）的次高斯协方差集中可得

$$\|\widehat{\mathbf{\Sigma}}_x-\mathbf{\Sigma}_x\|_{\mathrm{op}} = O_p\{\sqrt{d/n}+d/n\},$$

分解 $\widehat{\mathbf{\Sigma}}_1-\bar{\mathbf{\Sigma}}_1$ 时，增加所示域比例项。Yu 等（2015，定理2）的总体间隙 Procrustes 界随后给出：参考基误差的阶为合并协方差误差乘 $\sqrt{h}/\delta_1$；辅助基同理为辅助协方差误差乘 $\sqrt{\ell_k}/\delta_{k,m}$。对于总体中心化特征矩阵 $\mathbf{X}_c$，

$$n^{-1}\|\mathbf{X}_c(\widehat{\mathbf{D}}-\mathbf{DQ})\|_{\mathrm{F}}^2 = \mathrm{tr}\{(\widehat{\mathbf{D}}-\mathbf{DQ})^{\mathrm{T}}\widehat{\mathbf{\Sigma}}_x(\widehat{\mathbf{D}}-\mathbf{DQ})\},$$

因此基速率给出式(S1.19)；样本中心化的阶相同或更小。

有界重叠使每个归一化源权重为 $O(n_m^{-1})$。由于 $\mathcal{Y}$ 有限，式(S1.18)首行对归一化加权一阶、二阶矩造成 $O_p(\Delta_n)$ 扰动。其余行保证原始得分恢复与经验波动也为 $O_p(\Delta_n)$；对固定保留得分维数，有界四阶矩使未扰动经验一阶、二阶矩波动为 $O_p\left(n_{\min}^{-1/2}\right)$。若对称正定矩阵 $\mathbf{C}$, $\widetilde{\mathbf{C}}$ 的最小特征值至少为 $c>0$，矩阵平方根函数演算给出

$$\|\widetilde{\mathbf{C}}^{-1/2}-\mathbf{C}^{-1/2}\|_{\mathrm{op}}\le\frac{1}{2c^{3/2}}\|\widetilde{\mathbf{C}}-\mathbf{C}\|_{\mathrm{op}};$$

此式来自逆平方根的预解式积分，见 Higham（2008，第6章）。对应总体特征值至少为 c_0，所以该结论以趋近1的概率适用。因此，展开标准化得分、目标 CCA 矩及源矩阵 $\widehat{\mathbf{\Sigma}}_{zz}^{(m)}$、$\widehat{\mathbf{\Sigma}}_{zr}^{(m)}$，得到全部五个原始事件，速率均为 $O_p(\Delta_n)$。标准化和矩估计因而已被验证，而不是作为新项加入。这是后端验证，不是新的 PCA 定理。□

注（后端速率的范围）。 引理 S1.2 提供充分后端条件。稳健协方差估计量、在自身分布条件下的有效秩协方差界（Koltchinskii 和 Lounici，2017），或非 PCA 后端，均可改为验证相同 $O_p(\Delta_n)$ 事件。式(S1.18)的权重条件与 PCA 分离。特别是 Garg 等（2020，定理3）的 MLLS 界把目标样本平方根倒

数项与校准误差区分开。在其曲率条件下，平方根阶校准误差、源结局概率的平方根阶估计，以及到 ω_m 的平滑变换，可验证式(S1.18)的权重行。Alexandari 等（2020）的实用校准研究为实现提供动机，但不作为速率定理使用。

S1.4 成对 CCA 源矩与岭映射

引理 S1.3（成对正则化 CCA 扰动）。 在假设5的结构条件及目标矩事件(S1.9)-(S1.10)下，存在一个 $\mathbf{O} \in \mathcal{O}(r_0)$，使得

$$\|\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{A}^{(0)}\mathbf{O}\|_{\mathrm{F}} + \|\widehat{\mathbf{B}}^{(0)} - \mathbf{Q}_z^{(0)\mathrm{T}}\mathbf{B}^{(0)}\mathbf{O}\|_{\mathrm{F}} = O_p\{(1+\delta_{\mathrm{CCA}}^{-1})\Delta_n\}. \tag{S1.20}$$

证明。 逆平方根扰动界（Higham，2008）和式(S1.9)-(S1.10)意味着

$$\|\widehat{\mathbf{\Gamma}}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{\Gamma}^{(0)}\mathbf{Q}_z^{(0)}\|_{\mathrm{op}} = O_p(\Delta_n).$$

将 Yu 等（2015，定理2）的总体间隙特征空间界用于对称扩张 $\begin{pmatrix} 0 & \mathbf{\Gamma}^{(0)} \\ \mathbf{\Gamma}^{(0)\mathrm{T}} & 0 \end{pmatrix}$。其领先正特征向量为堆叠对 $2^{-1/2}\mathrm{col}\left(\mathbf{p}_j,\ \mathbf{q}_j\right)$，因此该定理为联合特征空间提供一个 Procrustes 矩阵 $\mathbf{O}$，也就给 CCA 两侧提供相同的 $\mathbf{O}$。这一共同旋转结论来自将扰动定理用于一个扩张，而非分别扰动两个奇异子空间。经逆平方根变换回去便得式(S1.20)。Wedin 定理提供经典奇异子空间背景（Wedin，1972），但此处所用共同旋转是上述联合扩张的推论。□

引理 S1.4（单一共同旋转的岭传播）。 假设4、5下，令 $\mathbf{O}$ 为引理 S1.3 的旋转。总体岭映射等变：

$$\left[\mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(m)}\mathbf{Q}_z^{(m)} + \lambda_m\mathbf{I}_{d_{z,m}}\right]^{-1}\mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O} = \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{G}^{(m)}\mathbf{O}. \tag{S1.21}$$

此外，在固定源域集合上一致地，

$$\max_m \|\widehat{\mathbf{G}}^{(m)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{G}^{(m)}\mathbf{O}\|_{\mathrm{F}} = O_p\left(\left[\underline{\lambda}^{-1}(1+\delta_{\mathrm{CCA}}^{-1}) + \underline{\lambda}^{-2}\right]\Delta_n\right). \tag{S1.22}$$

同一个 $\mathbf{O}$ 满足

$$\begin{aligned}\|\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{A}^{(0)}\mathbf{O}\|_{\mathrm{F}} + \max_{2\le k\le K}\|\widehat{\mathbf{B}}_k^{(0)} - \mathbf{Q}_{z,k}^{(0)\mathrm{T}}\mathbf{B}_k^{(0)}\mathbf{O}\|_{\mathrm{F}} \\ + \max_m \max_{k\in\mathcal{A}_m\setminus\{1\}}\|\widehat{\mathbf{G}}_k^{(m)} - \mathbf{Q}_{z,k}^{(m)\mathrm{T}}\mathbf{G}_k^{(m)}\mathbf{O}\|_{\mathrm{F}} = O_p(\Delta_n),\end{aligned} \tag{S1.23}$$

$$\max_{0\le m\le M}\left\{\|\widehat{\mathbf{U}}^{(m)} - \mathbf{U}^{(m)}\mathbf{O}\|_{\mathrm{F},m} + \sum_{k\in\mathcal{A}_m\setminus\{1\}}\|\widehat{\mathbf{V}}_k^{(m)} - \mathbf{V}_k^{(m)}\mathbf{O}\|_{\mathrm{F},m}\right\} = O_p(\Delta_n). \tag{S1.24}$$

此处及下文较简洁的 $O_p(\Delta_n)$ 形式，使用了假设5中固定正 CCA 间隙和固定岭下界；式(S1.22)显示二者的显式贡献。

证明。 对式(S1.3)总体准则求导得到

$$\{\mathbf{\Sigma}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\}\mathbf{G}^{(m)} = \mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}. \tag{S1.25}$$

其 Hessian 是 $2\mathbf{I}_{r_0} \otimes \{\mathbf{\Sigma}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\}$，最小特征值至少 $2\underline{\lambda}$。所以准则严格凸，其唯一最小化点为式(S1.5)。若辅助得分通过 $\mathbf{Q}_z^{(m)}$、目标锚点通过 $\mathbf{O}$ 重新表示，则正规方程中的矩变为

$$\mathbf{\Sigma}_{zz}^{(m)} \mapsto \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(m)}\mathbf{Q}_z^{(m)}, \qquad \mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)} \mapsto \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O}.$$

把这两式代入闭式解，利用 $\mathbf{Q}_z^{(m)}\mathbf{Q}_z^{(m)\mathrm{T}} = \mathbf{I}_{d_{z,m}}$，得到

$$\begin{aligned}&\left[\mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(m)}\mathbf{Q}_z^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\right]^{-1}\mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O}\\ &\quad = \mathbf{Q}_z^{(m)\mathrm{T}}\{\mathbf{\Sigma}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\}^{-1}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O} = \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{G}^{(m)}\mathbf{O},\end{aligned}$$

即证明式(S1.21)。因此，岭正则化保留而非创造从目标 CCA 锚点继承的共同右旋转。

对于经验扰动，令

$$\widehat{\mathbf{M}} = \widehat{\mathbf{\Sigma}}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}, \qquad \mathbf{M} = \mathbf{Q}_z^{(m)\mathrm{T}}\{\mathbf{\Sigma}_{zz}^{(m)} + \lambda_m \mathbf{I}_{d_{z,m}}\}\mathbf{Q}_z^{(m)},$$

两个逆矩阵的算子范数均不超过 $\underline{\lambda}^{-1}$。由式(S1.12)和引理 S1.3,

$$\max_m \left\|\widehat{\mathbf{\Sigma}}_{zr}^{(m)}\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O}\right\|_{\mathrm{F}} = O_p\{(1 + \delta_{\mathrm{CCA}}^{-1})\Delta_n\}. \tag{S1.26}$$

利用式(S1.21)，加上再减去总体右端项，得

$$\widehat{\mathbf{G}}^{(m)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{G}^{(m)}\mathbf{O} = \widehat{\mathbf{M}}^{-1}\left\{\widehat{\mathbf{\Sigma}}_{zr}^{(m)}\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O}\right\} + (\widehat{\mathbf{M}}^{-1} - \mathbf{M}^{-1})\mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zr}^{(m)}\mathbf{A}^{(0)}\mathbf{O}. \tag{S1.27}$$

预解式恒等式 $\widehat{\mathbf{M}}^{-1} - \mathbf{M}^{-1} = \widehat{\mathbf{M}}^{-1}(\mathbf{M} - \widehat{\mathbf{M}})\mathbf{M}^{-1}$ 给出

$$\|\widehat{\mathbf{M}}^{-1} - \mathbf{M}^{-1}\|_{\mathrm{op}} \le \underline{\lambda}^{-2}\|\widehat{\mathbf{\Sigma}}_{zz}^{(m)} - \mathbf{Q}_z^{(m)\mathrm{T}}\mathbf{\Sigma}_{zz}^{(m)}\mathbf{Q}_z^{(m)}\|_{\mathrm{op}}. \tag{S1.28}$$

式(S1.26)、(S1.28)、总体矩有界性及精确分解共同证明式(S1.22)。取行块即得式(S1.23)的系数界；目标块结论来自引理 S1.3。拟合坐标的两个相关分解为

$$\begin{aligned}\widehat{\mathbf{U}}^{(m)} - \mathbf{U}^{(m)}\mathbf{O} &= (\widehat{\mathbf{R}}^{(m)} - \mathbf{R}^{(m)}\mathbf{Q}_r)\widehat{\mathbf{A}}^{(0)} + \mathbf{R}^{(m)}\mathbf{Q}_r(\widehat{\mathbf{A}}^{(0)} - \mathbf{Q}_r^{\mathrm{T}}\mathbf{A}^{(0)}\mathbf{O}),\\ \widehat{\mathbf{V}}_k^{(m)} - \mathbf{V}_k^{(m)}\mathbf{O} &= (\widehat{\mathbf{Z}}_k^{(m)} - \mathbf{Z}_k^{(m)}\mathbf{Q}_{z,k}^{(m)})\widehat{\mathbf{G}}_k^{(m)} + \mathbf{Z}_k^{(m)}\mathbf{Q}_{z,k}^{(m)}(\widehat{\mathbf{G}}_k^{(m)} - \mathbf{Q}_{z,k}^{(m)\mathrm{T}}\mathbf{G}_k^{(m)}\mathbf{O}),\end{aligned}$$

目标辅助块则将 $\mathbf{G}_k^{(m)}$ 替换成 $\mathbf{B}_k^{(0)}$。原始得分事件、有界二阶矩和系数界，使每一项在 $\|\cdot\|_{\mathrm{F},m}$ 下均为 $O_p(\Delta_n)$。对固定数量的块求和，证明式(S1.24)。乘积中干扰 $\mathbf{Q}$ 旋转相消，而单个右旋转 $\mathbf{O}$ 保留。所示预解式恒等式是岭回归需要的唯一额外稳定性论证。□

注（共同取向不能证明什么）。 式(S1.24)将每个拟合块与其自身映射定义的总体块比较。它既不声称 $\mathbf{B}_k^{(0)} = \mathbf{G}_k^{(m)}$，也不把源类条件密度传输到目标域。这个分布步骤是由假设6单独给出的似然比条件。

引理 S1.5（条件分布的旋转不变性）。 对一般目标个体坐标，记 $\mathbf{c} = \mathrm{col}\left(\mathbf{u},\ \mathbf{v}_2,\ \ldots,\ \mathbf{v}_K\right)$，定义

$$\mathbf{c}^{\mathbf{O}} = \mathrm{col}(\mathbf{O}^{\mathrm{T}}\mathbf{u}, \mathbf{O}^{\mathrm{T}}\mathbf{v}_2, \ldots, \mathbf{O}^{\mathrm{T}}\mathbf{v}_K). \tag{S1.29}$$

则

$$\sigma(\mathbf{c}) = \sigma(\mathbf{c}^{\mathbf{O}}), \qquad p_0^{\mathbf{O}}(\mathbf{y} \mid \mathbf{c}^{\mathbf{O}}) = p_0(\mathbf{y} \mid \mathbf{c}) \quad \textit{almost surely}, \tag{S1.30}$$

其中 $p_0^{\mathbf{O}}$ 表示在旋转坐标下表达的同一目标分布；almost surely 意为几乎处处。若 $f_{\mathbf{y}},\ f_{\mathbf{0}}$ 分别是给定结局状态 $\mathbf{y},\ \mathbf{0}$ 时 $\mathbf{c}$ 的目标条件 Lebesgue 密度，则其旋转坐标似然比满足

$$\mathrm{LR}^{(0),\mathbf{O}}_{\mathrm{U,V|Y}}(\mathbf{c}^{\mathbf{O}} \mid \mathbf{y}) = \mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{c} \mid \mathbf{y}). \tag{S1.31}$$

因此，总体剖面准则和目标后验不受残留共同旋转影响。

证明。 逐块施加 $\mathbf{O}$ 是可逆 Borel 映射，所以 $\mathbf{c}$ 与 $\mathbf{c}^{\mathbf{O}}$ 生成同一个 σ-代数，证明式(S1.30)。换元时，似然比分子和分母密度获得相同 Jacobian，二者抵消而得到式(S1.31)。代入剖面准则和贝叶斯公式，证明最后结论。□

S1.5 剖面与目标条件结局一致性

注（一个充分识别条件）。 令 $f_{\mathbf{y}}$ 为给定结局 $\mathbf{y}$ 时目标对齐坐标的密度。若 $f_{\mathbf{0}} > 0$，有限族 $\{f_{\mathbf{y}}\}$ 除零测集外线性无关，且 $\theta \mapsto \{\rho_y(\mathbf{y};\theta)\}$ 是单射，则假设6的唯一最大化点条件成立。事实上，令 $f_\theta = \sum_{\mathbf{y}} \rho_y(\mathbf{y};\theta) f_{\mathbf{y}}$，有

$$\mathcal{M}(\theta) - \mathcal{M}(\theta^{(0)}) = -\,\mathrm{KL}(f_{\theta^{(0)}}, f_\theta) \le 0,$$

等号首先识别混合概率，再识别 $\theta^{(0)}$。线性无关是充分而非必要条件。

定义

$$\mathcal{M}_n^0(\theta) = \frac{1}{n_0}\sum_{i=1}^{n_0} \log\left\{\sum_{\mathbf{y}\in\mathcal{Y}} \rho_y(\mathbf{y};\theta)\mathrm{LR}_i(\mathbf{y})\right\},$$
$$\widehat{\mathcal{M}}_n(\theta) = \frac{1}{n_0}\sum_{i=1}^{n_0} \log\left\{\sum_{\mathbf{y}\in\mathcal{Y}} \rho_y(\mathbf{y};\theta)\widehat{\mathrm{LR}}_i(\mathbf{y})\right\}.$$

定义目标条件结局分布

$$p_0(\mathbf{y} \mid \mathbf{u}, \mathbf{v}) = \frac{\rho_y(\mathbf{y};\boldsymbol{\theta}^{(0)})\mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{u},\mathbf{v} \mid \mathbf{y})}{\sum_{\mathbf{y}'\in\mathcal{Y}} \rho_y(\mathbf{y}';\boldsymbol{\theta}^{(0)})\mathrm{LR}^{(0)}_{\mathrm{U,V|Y}}(\mathbf{u},\mathbf{v} \mid \mathbf{y}')}.$$

定理 S1.6（目标剖面与条件结局速率）。 假设4-6下，若 $\widehat{\mathcal{M}}_n$ 最大化至 $o_p(1)$，则 $\widehat{\theta}^{(0)} \to {}_p\theta^{(0)}$，且

$$\frac{1}{n_0}\sum_{i=1}^{n_0}\sum_{\mathbf{y}\in\mathcal{Y}}\left|\widehat{p}_i(\mathbf{y}) - p_0\{\mathbf{y} \mid \mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)}\}\right| \xrightarrow{p} 0. \tag{S1.32}$$

在假设6的局部速率条件下，

$$\|\widehat{\boldsymbol{\theta}}^{(0)} - \boldsymbol{\theta}^{(0)}\|_2 + \frac{1}{n_0}\sum_{i=1}^{n_0}\sum_{\mathbf{y}\in\mathcal{Y}}\left|\widehat{p}_i(\mathbf{y}) - p_0\{\mathbf{y} \mid \mathbf{u}_i^{(0)}, \mathbf{v}_i^{(0)}\}\right| = O_p\{n_0^{-1/2} + \kappa_n + \Delta_n\}. \tag{S1.33}$$

无需假设相对次序。若 $\kappa_n = O(\Delta_n)$，对齐是较慢的干扰部分；若 $\Delta_n = O(\kappa_n)$，似然比学习较慢。保留求和是为了显示来源，但 $\kappa_n + \Delta_n$ 与 $\max(\kappa_n, \Delta_n)$ 同阶。基准为平方根倒数：样本量平方根速率意指 $\sqrt{n_{\min}}\Delta_n = O(1)$、$\sqrt{N_s}\kappa_n = O(1)$；任一缩放序列发散表示更慢收敛，趋零表示更快收敛。例如，当 $d_k/n_m \to 0$ 时，式(S1.18)中辅助 PCA 的主导项为 $\sqrt{\ell_k d_k}/\left(\delta_{k,m}\sqrt{n_m}\right)$，因此维数增长或特征间隙缩小会使 Δ_n 大于 $n_m^{-1/2}$。

对于 PCA 后端，允许的 Δ_n 由式(S1.18)显式给出。固定维数和固定特征间隙下，权重及域比例具有根 $n_{\min}$ 速率时，$\Delta_n = O\left(n_{\min}^{-1/2}\right)$；权重速率途径在引理 S1.2 后说明。若正确设定的平滑有限维比值程序进一步由正则参数 M 估计得到 $\kappa_n = O\left(N_s^{-1/2}\right)$（van der Vaart，2000，定理5.23），则式(S1.33)化为

$$O_p\{n_0^{-1/2} + N_s^{-1/2} + n_{\min}^{-1/2}\}. \tag{S1.34}$$

由于 $n_{\min} \le n_0$ 且 $n_{\min} \le N_s$，它也等于 $O_p\left(n_{\min}^{-1/2}\right)$。在引理 S1.2 的正极限域比例下，$n_{\min} \asymp n_0 \asymp N_s \asymp N$，同一特例可写为 $O_p\left(N^{-1/2}\right)$。这个特例带有条件，并不是 XGBoost 的速率：对提升树而言，κ_n 与坐标稳定性仍是由假设6给出的两项学习器特异条件。所示阶数不确定数值常数；常数取决于协方差和次高斯尺度、特征间隙倒数、岭下界、比值包络和剖面曲率。

证明。 基线比值等于1，且其结局概率一致为正，所以对数内每个混合量均与零保持正距离。因此式(S1.15)蕴含

$$\sup_{\boldsymbol{\theta}\in\Theta}|\widehat{\mathcal{M}}_n(\boldsymbol{\theta}) - \mathcal{M}_n^0(\boldsymbol{\theta})| = O_p(\kappa_n + \Delta_n) = o_p(1).$$

Glivenko-Cantelli、唯一最大化点条件及 argmax 定理给出参数一致性（van der Vaart，2000，定理5.7）。

对于速率，ρ_y 的一阶和二阶导数有界，使剖面得分与 Hessian 对有限比值向量局部 Lipschitz。因此，$\theta^{(0)}$ 处拟合得分等于预言式得分加 $O_p(\kappa_n + \Delta_n)$。围绕 $\theta^{(0)}$ 对拟合一阶条件作 Taylor 展开，结合正总体曲率，得

$$\|\widehat{\boldsymbol{\theta}}^{(0)} - \boldsymbol{\theta}^{(0)}\|_2 = O_p\{n_0^{-1/2} + \kappa_n + \Delta_n\}.$$

有限状态贝叶斯归一化也是 Lipschitz 的，其平均误差不超过某个常数乘以下量：

$$\|\widehat{\boldsymbol{\theta}}^{(0)} - \boldsymbol{\theta}^{(0)}\|_2 \left\{\frac{1}{n_0}\sum_i \max_{\mathbf{y}\in\mathcal{Y}} \widehat{\mathrm{LR}}_i(\mathbf{y})\right\} + \frac{1}{n_0}\sum_i \max_{\mathbf{y}\in\mathcal{Y}} |\widehat{\mathrm{LR}}_i(\mathbf{y}) - \mathrm{LR}_i(\mathbf{y})|.$$

式(S1.15)-(S1.16)证明式(S1.33)，一致性为其特例。引理 S1.5 消去共同旋转。代入所示 PCA 和比值速率即可得到最后两个特例。□

注（精确比值与工作比值）。 定理针对给定对齐坐标的真实目标分布。若实践中采用的温度调整复合比值不是精确联合比值，同一证明给出相应工作条件分布的一致性。这里明确区分二者，避免把工作复合模型表述成精确似然比恒等式。

S2 补充模拟细节与结果

S2.1 主要多元模拟

每次重复包含编号0的一个目标域，以及编号 $m = 1, \ldots, 5$ 的五个源域，每域400名个体。目标域观测全部五种模态；每个源域观测共享参考模态及预先指定的四种辅助模态子集。目标金标准结局在所有预处理、拟合和调参步骤中隐藏，只有预测固定后才重新合并。

目标结局是三维二元向量，其边际概率为

$$\boldsymbol{\pi}^{(0)} = (0.22, 0.36, 0.40)^{\mathrm{T}},$$

Ising 成对交互参数为 $(0.45,\ 0.35,\ 0.30)$。源域 m 的边际概率为

$$\boldsymbol{\pi}^{(m)} = \mathrm{clip}\{\boldsymbol{\pi}^{(0)} + \delta\mathbf{c}_m, 10^{-4}, 1 - 10^{-4}\}, \tag{S2.1}$$

截断逐分量进行，其中

$$\begin{pmatrix}\mathbf{c}_1^{\mathrm{T}}\\ \mathbf{c}_2^{\mathrm{T}}\\ \mathbf{c}_3^{\mathrm{T}}\\ \mathbf{c}_4^{\mathrm{T}}\\ \mathbf{c}_5^{\mathrm{T}}\end{pmatrix} = \begin{pmatrix}0.60 & 0.48 & 0.36\\ 0.80 & 0.64 & 0.48\\ 1.00 & 0.80 & 0.60\\ 1.20 & 0.96 & 0.72\\ 1.40 & 1.12 & 0.84\end{pmatrix}.$$

对每个源域，数值求解 Ising 主效应以达到式(S2.1)边际值，成对交互则固定。所以 δ 改变联合源结局分布，而不改变给定结局的条件特征分布。

令 $\mathbf{e}_{\mathbf{y}} = 2\mathbf{y} - \mathbf{1}$，并令

$$\mathbf{q}(\mathbf{y}) = (e_{y1}e_{y2}, e_{y1}e_{y3}, e_{y2}e_{y3})^{\mathrm{T}}.$$

独立生成列正交归一的矩阵 $\mathbf{P},\ \mathbf{Q} \in \mathbb{R}^{5\times 3}$，供参考与辅助潜在因子共享。状态特异高斯模板矩阵在八个结局状态上重新缩放，使 Frobenius 范数分别为0.04和0.13。条件潜在均值为

$$\psi_u(\mathbf{y}) = \mathbf{P}\,\mathrm{diag}(0.48, 0.43, 0.39)\mathbf{e}_\mathbf{y} + \mathbf{Q}\,\mathrm{diag}(0.03, 0.03, 0.03)\mathbf{q}(\mathbf{y}) + \mathbf{g}_u(\mathbf{y}),$$
$$\psi_v(\mathbf{y}) = \mathbf{P}\,\mathrm{diag}(1.34, 1.20, 1.07)\mathbf{e}_\mathbf{y} + \mathbf{Q}\,\mathrm{diag}(0.33, 0.33, 0.33)\mathbf{q}(\mathbf{y}) + \mathbf{g}_v(\mathbf{y}).$$

给定 $\mathbf{y}$，两个潜在因子独立：

$$\widetilde{\mathbf{u}} = \psi_u(\mathbf{y}) + \xi_u, \qquad \widetilde{\mathbf{v}} = \psi_v(\mathbf{y}) + \xi_v, \qquad \xi_u, \xi_v \sim N_5(\mathbf{0}, 0.70^2\mathbf{I}).$$

观测维数 $(d_1, \ldots, d_5) = (180, 150, 150, 130, 130)$。辅助模态2、3、4、5分别保留潜在坐标 $\{1, 2, 3\}$、$\{2, 3, 4\}$、$\{3, 4, 5\}$、$\{1, 4, 5\}$。以 $\mathbf{M}_k$ 表示对应对角掩码，有

$$\mathbf{x}_1^{(m)} = \mathbf{L}_1\widetilde{\mathbf{u}} + \boldsymbol{\epsilon}_1^{(m)}, \qquad \mathbf{x}_k^{(m)} = \mathbf{L}_k^{(m)}\mathbf{M}_k\widetilde{\mathbf{v}} + \boldsymbol{\epsilon}_k^{(m)}, \quad k = 2, \ldots, 5.$$

参考载荷 $\mathbf{L}_1$ 完全跨域共享。参考模态的测量误差标准差为0.26，各辅助模态为0.41。

对辅助模态 k，令 $\mathbf{L}_k$ 为共享正交归一载荷，$\widetilde{\mathbf{L}}_k^{(m)}$ 为独立生成的正交归一载荷。从高斯矩阵 $\mathbf{A}_k^{(m)}$ 定义

$$\mathbf{R}_k^{(m)}(\varepsilon_{\mathrm{rot}}) = \mathrm{qf}\left\{\mathbf{I} + \frac{\varepsilon_{\mathrm{rot}}}{\sqrt{5}}(\mathbf{A}_k^{(m)} - \mathbf{A}_k^{(m)\mathrm{T}})\right\},$$

并设

$$\mathbf{L}_k^{(m)} = \mathrm{qf}\left\{0.5\mathbf{L}_k\mathbf{R}_k^{(m)}(\varepsilon_{\mathrm{rot}}) + 0.5\widetilde{\mathbf{L}}_k^{(m)}\right\}.$$

其中 qf 表示 QR 分解的正交归一因子。不反转任何载荷符号。因此 $\varepsilon_{\mathrm{rot}}$ 控制共享载荷成分的旋转，独立子空间成分的权重保持0.5。

标签偏移、旋转和源标签扫描中的源模态集合为

$$\mathcal{A}_1 = \{1, 2\}, \quad \mathcal{A}_2 = \{1, 3\}, \quad \mathcal{A}_3 = \{1, 3, 4, 5\}, \quad \mathcal{A}_4 = \{1, 2, 5\}, \quad \mathcal{A}_5 = \{1, 4, 5\}.$$

源金标准结局以概率 p_{lab} 独立隐藏，仅当某个源域因此没有任何观测结局时才做确定性修复。p_{mod} 索引以下五种固定源模式配置，而不是独立删除模态：

p_{mod}	$\mathcal{A}_1$	$\mathcal{A}_2$	$\mathcal{A}_3$	$\mathcal{A}_4$	$\mathcal{A}_5$
0.0	$\{1,2\}$	$\{1,3\}$	$\{1,3,4,5\}$	$\{1,2,5\}$	$\{1,4,5\}$
0.1	$\{1,2\}$	$\{1,3\}$	$\{1,3,4,5\}$	$\{1,2,5\}$	$\{1,4\}$
0.2	$\{1,2\}$	$\{1,3\}$	$\{1,3,4,5\}$	$\{1,2\}$	$\{1,4,5\}$
0.3	$\{1,2\}$	$\{1,3\}$	$\{1,3,4\}$	$\{1,2,5\}$	$\{1,4,5\}$
0.4	$\{1,2\}$	$\{1,3\}$	$\{1,3,4\}$	$\{1,2,5\}$	$\{1,4\}$

这些配置非嵌套，因此增大 p_{mod} 不一定单调减少信息。四组一次改变一个因素的扫描为

$$\delta \in \{0, 0.08, 0.16, 0.24, 0.32, 0.40\}, \qquad \varepsilon_{\text{rot}} \in \{0, 0.2, 0.4, 0.6, 0.8, 1.0\},$$
$$p_{\text{lab}} \in \{0, 0.1, 0.2, 0.3, 0.4, 0.5\}, \qquad p_{\text{mod}} \in \{0, 0.1, 0.2, 0.3, 0.4\}.$$

默认值 $\delta = 0.24$、$\varepsilon_{\text{rot}} = 0.50$、$p_{\text{lab}} = 0.35$、$p_{\text{mod}} = 0$。每组扫描只改变一个量。在同一设定中，各方法对相同生成重复评价；同一组扫描各设定的种子安排也相匹配。

所提实现先将各特征块在域内中心化；参考模态用秩5的合并 PCA，各辅助模态用秩3的域内 PCA；仅在初始目标结局分布校准时使用未中心化参考投影。校准后，对源观测按估计目标结局分布重加权。程序先执行结局重加权逐块对齐，再使用秩5、单一联合目标 CCA 锚点及相应源岭回归映射。CCA 与源回归惩罚均为 10^{-4}。启用源重叠增广：若供体源的观测模式包含 $\mathcal{A}_m$，源模式 $\mathcal{A}_m$ 可以借用其记录，但先把供体记录限制到所需数据块。

参考密度比模型使用 XGBoost：200棵树、深度4、学习率0.05、行和列采样比例0.9、岭惩罚1（Chen 和 Guestrin，2016）。联合比值模型使用多项 logistic 回归，惩罚参数从 $\{0.2,\ 0.5,\ 1,\ 2\}$ 中通过三折分组验证选择，以源域为折。仅当辅助部分改善验证对数损失时才保留，并将其贡献乘0.5。

最终目标更新采用基于似然的标签偏移形式（Saerens 等，2002；Alexandari 等，2020；Garg 等，2020），最多120次迭代、容差 10^{-5}、初始阻尼0.4，必要时降到0.05以保证剖面似然不下降。如果迭代未收敛，或估计目标边际概率相对初始参考估计的 L_1 移动超过0.15，则将最终后验指数倾斜回这些初始边际值。这一不使用目标结局的保护机制，在标签偏移、旋转、标签缺失、模态模式扫描中分别有94.8%、94.2%、96.0%、95.0%的重复被触发。因此报告结果刻画的是稳定化目标更新，而非不受约束的 EM。

比较方法如下。

- **Raw-X XGBoost：** 合并带标签源行，拼接五个原始模态块，用缺失值表示缺失源块，并附加四个块可用性指示变量。使用50棵树、深度3、学习率0.05、行列采样比例0.9、岭惩罚1。不做源重加权、对齐或目标适应（Chen 和 Guestrin，2016）。
- **Raw-X LASSO：** 使用相同合并带标签源行及原始块布局。对每个二元结局，删除所有源域均缺失的列；以源数据中位数插补其余缺失值，自动生成缺失指示，再标准化特征。L_1 惩罚 logistic 模型通过至多五折分层交叉验证、按负 Brier 分数，从 10^{-3} 到 10^{2} 的12个对数等距 C 值中选择参数；随后使用 SAGA 拟合，最多4000次迭代、容差 10^{-3}。三个边际概率按独立乘积组合为八状态分布。不使用目标标签或适应步骤（Tibshirani，1996）。
- **直接迁移：** 使用局部 PCA 得分、合并源结局模型，不做跨域对齐或目标更新。**正交迁移：** 使用局部参考 PCA，在带标签源观测上进行子集未加权 Procrustes 对齐，不做目标校准（Schönemann，1966）。
- **RGCCA：** 秩5、$\tau = 0.5$、岭参数 10^{-4}（Tenenhaus 和 Tenenhaus，2011）。**BONMI：** 秩12（Zhou 等，2023）。二者均不使用目标结局或所提目标更新。
- **仅目标 PCA-EM：** 在目标域拟合 PCA，对前三个主成分得分分别拟合双成分高斯混合（Jolliffe 和 Cadima，2016；Dempster 等，1977），不使用源数据或目标结局。

宏平均 AUC 是三个分量 AUC 的平均值。目标 MSE 为

$$\mathrm{MSE} = \frac{1}{3n_0}\sum_{i=1}^{n_0}\sum_{a=1}^{3}\{\widehat{p}_{ia}^{(0)} - y_{ia}^{(0)}\}^2.$$

宏平均 AUC 越高、MSE 越低越好。

S2.2 主要模拟结果

在23个设定中，所提方法平均宏 AUC 为0.9269、平均 MSE 为0.1003。相对 Raw-X XGBoost，AUC 提高20.3%、MSE 降低51.8%；相对 Raw-X LASSO，相应变化为21.0%、51.9%。Raw-X XGBoost 与 Raw-X LASSO 总体几乎持平：按种子聚类的配对 XGBoost 减 LASSO AUC 差为0.0045（95%蒙特卡洛区间 -0.0066 至0.0157），LASSO 减 XGBoost MSE 差为0.0006（-0.0103至0.0114）。因此实验不支持非线性树学习器相对稀疏线性学习器具有稳定的总体优势。

所提方法在23个设定中的22个取得最大宏 AUC 和最小 MSE。唯一例外有助于理解结果：$\varepsilon_{\mathrm{rot}} = 0$ 时，Raw-X LASSO 宏 AUC 为0.9557、MSE 为0.0795，而所提方法为0.9369、0.0943。源辅助坐标系未旋转时，稀疏原始特征模型可直接利用近乎共享的线性结构。但其性能随旋转退化，$\varepsilon_{\mathrm{rot}} = 1$ 时宏 AUC 为0.7329、MSE 为0.2288，所提方法仍为0.9297、0.0983。因此这一例外强化而非削弱了对齐实验的解释。

标签偏移轨迹最清楚地区分排序与概率校准。所提宏 AUC 保持在0.9270-0.9323，而 Raw-X XGBoost MSE 从 $\delta = 0$ 的0.1820升至 $\delta = 0.40$ 的0.2546。在最大偏移时，所提方法的宏 AUC 比 Raw-X XGBoost 高21.7%，MSE 低59.5%。旋转扫描中，所提宏 AUC 范围为0.9245-0.9369，MSE 为0.0943-0.1035。源标签缺失下退化较缓；$p_{\mathrm{lab}} = 0.50$ 时宏 AUC 为0.9198、MSE 为0.1054。模态模式结果非单调，因为 p_{mod} 标记上述非嵌套模式，而不是有序删除概率。

表 S1。 正文图2雷达面板对应的设定等权汇总。每个扫描列对各设定蒙特卡洛均值求平均，Overall 列对全部23个设定求平均。宏 AUC 越高、MSE 越低越好；每列最优点估计加粗。Overall＝总体；Label shift＝标签偏移；Rotation＝旋转；Label missingness＝标签缺失；Modality pattern＝模态模式；Panel A＝目标宏 AUC；Panel B＝目标 MSE。其余方法名与正文一致。

Table S1: Setting-equal summaries corresponding to the radar panels of Figure 2 in the main paper. Each sweep column averages its setting-level Monte Carlo means, and the Overall column averages all 23 settings. Higher macro-AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	Overall	Label shift	Rotation	Label missingness	Modality pattern
Panel A: Target macro-AUC					
Proposed	**0.9269**	**0.9287**	**0.9299**	**0.9289**	**0.9187**
Raw-X XGBoost	0.7707	0.7667	0.7862	0.7666	0.7617
Raw-X LASSO	0.7661	0.7603	0.7902	0.7560	0.7563
Orthogonal	0.6469	0.6633	0.6411	0.6324	0.6517
BONMI	0.6437	0.6453	0.6313	0.6472	0.6521
RGCCA	0.6157	0.6124	0.6196	0.6049	0.6278
Direct	0.5809	0.5933	0.5612	0.5778	0.5935
Target-only	0.5119	0.5126	0.5110	0.5126	0.5112
Panel B: Target MSE					
Proposed	**0.1003**	**0.0996**	**0.0988**	**0.0986**	**0.1051**
Raw-X XGBoost	0.2080	0.2090	0.2033	0.2090	0.2114
Raw-X LASSO	0.2086	0.2109	0.1922	0.2166	0.2158
Orthogonal	0.2636	0.2540	0.2650	0.2705	0.2651
BONMI	0.2928	0.2860	0.3017	0.2923	0.2908
RGCCA	0.2694	0.2682	0.2700	0.2734	0.2653
Direct	0.2785	0.2721	0.2862	0.2804	0.2745
Target-only	0.3156	0.3156	0.3149	0.3156	0.3164

表 S2。 联合标签偏移。各值为每个设定100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。宏 AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标宏 AUC，B 面板为目标 MSE。

Table S2: Joint label shift. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications at each setting. Higher macro-AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$\delta = 0$	$\delta = 0.08$	$\delta = 0.16$	$\delta = 0.24$	$\delta = 0.32$	$\delta = 0.4$
Panel A: Target macro-AUC						
Proposed	**0.9283 (0.0035)**	**0.9280 (0.0030)**	**0.9323 (0.0028)**	**0.9273 (0.0031)**	**0.9292 (0.0032)**	**0.9270 (0.0033)**
Raw-X XGBoost	0.7678 (0.0095)	0.7705 (0.0091)	0.7700 (0.0091)	0.7670 (0.0093)	0.7628 (0.0096)	0.7617 (0.0090)
Raw-X LASSO	0.7648 (0.0122)	0.7651 (0.0119)	0.7591 (0.0125)	0.7549 (0.0126)	0.7600 (0.0124)	0.7580 (0.0124)
Orthogonal	0.6568 (0.0266)	0.6659 (0.0266)	0.6784 (0.0269)	0.6438 (0.0269)	0.6669 (0.0277)	0.6678 (0.0282)
BONMI	0.6432 (0.0248)	0.6475 (0.0244)	0.6507 (0.0247)	0.6475 (0.0229)	0.6323 (0.0240)	0.6508 (0.0239)
RGCCA	0.6283 (0.0231)	0.6036 (0.0228)	0.6227 (0.0223)	0.6041 (0.0219)	0.6033 (0.0230)	0.6122 (0.0233)
Direct	0.6007 (0.0255)	0.5970 (0.0256)	0.6086 (0.0248)	0.5791 (0.0257)	0.5847 (0.0259)	0.5898 (0.0250)
Target-only	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)
Panel B: Target MSE						
Proposed	**0.0992 (0.0022)**	**0.0991 (0.0022)**	**0.0956 (0.0022)**	**0.1008 (0.0024)**	**0.0997 (0.0023)**	**0.1031 (0.0025)**
Raw-X XGBoost	0.1820 (0.0018)	0.1852 (0.0018)	0.1946 (0.0019)	0.2091 (0.0021)	0.2283 (0.0022)	0.2546 (0.0023)
Raw-X LASSO	0.2039 (0.0073)	0.2075 (0.0074)	0.2134 (0.0081)	0.2168 (0.0081)	0.2122 (0.0077)	0.2116 (0.0075)
Orthogonal	0.2006 (0.0088)	0.2059 (0.0100)	0.2208 (0.0112)	0.2651 (0.0118)	0.2924 (0.0119)	0.3395 (0.0112)
BONMI	0.2369 (0.0125)	0.2474 (0.0127)	0.2661 (0.0134)	0.2917 (0.0129)	0.3258 (0.0135)	0.3483 (0.0130)
RGCCA	0.2123 (0.0086)	0.2293 (0.0090)	0.2399 (0.0091)	0.2733 (0.0092)	0.3069 (0.0095)	0.3477 (0.0093)
Direct	0.2150 (0.0076)	0.2243 (0.0089)	0.2384 (0.0093)	0.2793 (0.0098)	0.3139 (0.0095)	0.3617 (0.0085)
Target-only	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)

表 S3。 辅助载荷旋转。各值为每个设定100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。宏 AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标宏 AUC，B 面板为目标 MSE。

Table S3: Auxiliary loading rotation. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications at each setting. Higher macro-AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$\varepsilon_{\mathrm{rot}} = 0$	$\varepsilon_{\mathrm{rot}} = 0.2$	$\varepsilon_{\mathrm{rot}} = 0.4$	$\varepsilon_{\mathrm{rot}} = 0.6$	$\varepsilon_{\mathrm{rot}} = 0.8$	$\varepsilon_{\mathrm{rot}} = 1$
Panel A: Target macro-AUC						
Proposed	0.9369 (0.0029)	**0.9245 (0.0037)**	**0.9299 (0.0027)**	**0.9272 (0.0031)**	**0.9311 (0.0026)**	**0.9297 (0.0032)**
Raw-X XGBoost	0.9058 (0.0021)	0.7846 (0.0108)	0.7668 (0.0103)	0.7543 (0.0094)	0.7555 (0.0088)	0.7500 (0.0082)
Raw-X LASSO	**0.9557 (0.0012)**	0.8000 (0.0131)	0.7688 (0.0132)	0.7442 (0.0119)	0.7398 (0.0117)	0.7329 (0.0113)
Orthogonal	0.6228 (0.0297)	0.6498 (0.0271)	0.6494 (0.0267)	0.6441 (0.0269)	0.6411 (0.0270)	0.6394 (0.0269)
BONMI	0.6819 (0.0227)	0.6233 (0.0255)	0.6357 (0.0243)	0.6387 (0.0237)	0.6081 (0.0249)	0.6003 (0.0249)
RGCCA	0.6757 (0.0220)	0.6048 (0.0231)	0.6359 (0.0233)	0.6098 (0.0227)	0.6116 (0.0231)	0.5796 (0.0239)
Direct	0.5972 (0.0274)	0.5471 (0.0268)	0.5697 (0.0267)	0.5620 (0.0271)	0.5442 (0.0277)	0.5472 (0.0278)
Target-only	0.4996 (0.0124)	0.5133 (0.0123)	0.5113 (0.0121)	0.5155 (0.0130)	0.5127 (0.0131)	0.5137 (0.0122)
Panel B: Target MSE						
Proposed	0.0943 (0.0022)	**0.1035 (0.0029)**	**0.0987 (0.0022)**	**0.1005 (0.0024)**	**0.0975 (0.0021)**	**0.0983 (0.0024)**
Raw-X XGBoost	0.1686 (0.0010)	0.2032 (0.0026)	0.2085 (0.0023)	0.2124 (0.0021)	0.2126 (0.0021)	0.2145 (0.0019)
Raw-X LASSO	**0.0795 (0.0011)**	0.1896 (0.0087)	0.2076 (0.0085)	0.2225 (0.0074)	0.2254 (0.0074)	0.2288 (0.0071)
Orthogonal	0.2678 (0.0122)	0.2624 (0.0119)	0.2626 (0.0117)	0.2650 (0.0118)	0.2656 (0.0117)	0.2664 (0.0117)
BONMI	0.2731 (0.0129)	0.3084 (0.0147)	0.2981 (0.0138)	0.2958 (0.0134)	0.3157 (0.0142)	0.3188 (0.0141)
RGCCA	0.2485 (0.0096)	0.2732 (0.0098)	0.2626 (0.0099)	0.2732 (0.0097)	0.2755 (0.0098)	0.2869 (0.0103)
Direct	0.2701 (0.0101)	0.2891 (0.0105)	0.2833 (0.0105)	0.2867 (0.0103)	0.2957 (0.0109)	0.2925 (0.0106)
Target-only	0.3221 (0.0063)	0.3111 (0.0063)	0.3146 (0.0066)	0.3124 (0.0072)	0.3152 (0.0077)	0.3138 (0.0073)

表 S4。 源金标准结局缺失。各值为每个设定100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。宏 AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标宏 AUC，B 面板为目标 MSE。

Table S4: Missing source gold-standard outcomes. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications at each setting. Higher macro-AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$p_{\text{lab}} = 0$	$p_{\text{lab}} = 0.1$	$p_{\text{lab}} = 0.2$	$p_{\text{lab}} = 0.3$	$p_{\text{lab}} = 0.4$	$p_{\text{lab}} = 0.5$
Panel A: Target macro-AUC						
Proposed	**0.9344 (0.0025)**	**0.9310 (0.0029)**	**0.9328 (0.0029)**	**0.9279 (0.0035)**	**0.9276 (0.0035)**	**0.9198 (0.0043)**
Raw-X XGBoost	0.7679 (0.0098)	0.7684 (0.0096)	0.7680 (0.0093)	0.7693 (0.0091)	0.7652 (0.0095)	0.7607 (0.0092)
Raw-X LASSO	0.7579 (0.0130)	0.7570 (0.0128)	0.7576 (0.0127)	0.7563 (0.0125)	0.7531 (0.0126)	0.7541 (0.0121)
Orthogonal	0.6191 (0.0275)	0.6263 (0.0275)	0.6291 (0.0276)	0.6391 (0.0272)	0.6457 (0.0269)	0.6352 (0.0280)
BONMI	0.6456 (0.0228)	0.6462 (0.0228)	0.6467 (0.0228)	0.6476 (0.0229)	0.6482 (0.0229)	0.6490 (0.0226)
RGCCA	0.6048 (0.0219)	0.6044 (0.0220)	0.6050 (0.0220)	0.6049 (0.0219)	0.6038 (0.0220)	0.6065 (0.0219)
Direct	0.5748 (0.0265)	0.5764 (0.0263)	0.5775 (0.0262)	0.5796 (0.0259)	0.5772 (0.0255)	0.5812 (0.0247)
Target-only	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)	0.5126 (0.0129)
Panel B: Target MSE						
Proposed	**0.0950 (0.0020)**	**0.0970 (0.0020)**	**0.0961 (0.0022)**	**0.0989 (0.0026)**	**0.0993 (0.0024)**	**0.1054 (0.0028)**
Raw-X XGBoost	0.2084 (0.0022)	0.2086 (0.0021)	0.2087 (0.0021)	0.2084 (0.0021)	0.2095 (0.0021)	0.2104 (0.0021)
Raw-X LASSO	0.2156 (0.0085)	0.2164 (0.0084)	0.2156 (0.0082)	0.2167 (0.0082)	0.2168 (0.0080)	0.2186 (0.0078)
Orthogonal	0.2764 (0.0124)	0.2734 (0.0123)	0.2730 (0.0123)	0.2662 (0.0119)	0.2638 (0.0117)	0.2700 (0.0119)
BONMI	0.2953 (0.0131)	0.2943 (0.0130)	0.2934 (0.0130)	0.2921 (0.0129)	0.2908 (0.0128)	0.2882 (0.0126)
RGCCA	0.2750 (0.0094)	0.2745 (0.0094)	0.2740 (0.0093)	0.2733 (0.0092)	0.2728 (0.0091)	0.2711 (0.0092)
Direct	0.2839 (0.0106)	0.2824 (0.0103)	0.2815 (0.0102)	0.2793 (0.0098)	0.2792 (0.0096)	0.2762 (0.0090)
Target-only	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)	0.3156 (0.0069)

表 S5。 源模态模式索引。各值为每个设定100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。宏 AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标宏 AUC，B 面板为目标 MSE。

Table S5: Source modality-pattern index. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications at each setting. Higher macro-AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$p_{\text{mod}} = 0$	$p_{\text{mod}} = 0.1$	$p_{\text{mod}} = 0.2$	$p_{\text{mod}} = 0.3$	$p_{\text{mod}} = 0.4$
Panel A: Target macro-AUC					
Proposed	**0.9273 (0.0031)**	**0.9142 (0.0053)**	**0.9116 (0.0043)**	**0.9327 (0.0029)**	**0.9079 (0.0053)**
Raw-X XGBoost	0.7670 (0.0093)	0.7668 (0.0092)	0.7653 (0.0091)	0.7556 (0.0097)	0.7538 (0.0099)
Raw-X LASSO	0.7549 (0.0126)	0.7559 (0.0124)	0.7538 (0.0128)	0.7586 (0.0121)	0.7582 (0.0119)
Orthogonal	0.6438 (0.0269)	0.6789 (0.0272)	0.6750 (0.0262)	0.6257 (0.0308)	0.6349 (0.0290)
BONMI	0.6475 (0.0229)	0.6537 (0.0233)	0.6555 (0.0212)	0.6644 (0.0213)	0.6396 (0.0255)
RGCCA	0.6041 (0.0219)	0.6276 (0.0228)	0.6188 (0.0204)	0.6424 (0.0227)	0.6460 (0.0235)
Direct	0.5791 (0.0257)	0.5860 (0.0265)	0.6161 (0.0242)	0.5946 (0.0252)	0.5915 (0.0268)
Target-only	0.5126 (0.0129)	0.5049 (0.0130)	0.4976 (0.0133)	0.5343 (0.0128)	0.5066 (0.0136)
Panel B: Target MSE					
Proposed	**0.1008 (0.0024)**	**0.1063 (0.0034)**	**0.1111 (0.0029)**	**0.0955 (0.0021)**	**0.1119 (0.0030)**
Raw-X XGBoost	0.2091 (0.0021)	0.2081 (0.0020)	0.2090 (0.0019)	0.2159 (0.0021)	0.2149 (0.0022)
Raw-X LASSO	0.2168 (0.0081)	0.2176 (0.0078)	0.2156 (0.0081)	0.2151 (0.0075)	0.2136 (0.0073)
Orthogonal	0.2651 (0.0118)	0.2517 (0.0117)	0.2525 (0.0109)	0.2737 (0.0130)	0.2826 (0.0131)
BONMI	0.2917 (0.0129)	0.2886 (0.0133)	0.2894 (0.0119)	0.2808 (0.0123)	0.3037 (0.0149)
RGCCA	0.2733 (0.0092)	0.2676 (0.0098)	0.2667 (0.0082)	0.2585 (0.0095)	0.2601 (0.0101)
Direct	0.2793 (0.0098)	0.2754 (0.0101)	0.2643 (0.0091)	0.2728 (0.0093)	0.2810 (0.0109)
Target-only	0.3156 (0.0069)	0.3181 (0.0070)	0.3253 (0.0069)	0.3051 (0.0065)	0.3179 (0.0069)

S2.3 替代辅助模拟的设计与方法

替代实验使用主要数据生成机制的二元限制版本，保留一个目标域与五个源域、相同的五种原始模态维数和源模态模式、相同秩亏辅助坐标集合、参考及辅助测量误差标准差0.26及0.41、潜在噪声标准差0.70、辅助旋转 $\varepsilon_{\mathrm{rot}} = 0.50$ 、独立载荷子空间权重0.5。每域样本量取

$$\{25, 50, 100, 150, 200, 400, 800, 1600, 3200, 6400\},$$

每个取值重复100次。目标事件率为0.22，五个源事件率为

$$\pi^{(m)} = \mathrm{clip}\{0.22 + 0.24c_m, 0.05, 0.95\}, \qquad (c_1, \ldots, c_5) = (0.6, 0.8, 1.0, 1.2, 1.4),$$

即 $(0.364,\ 0.412,\ 0.460,\ 0.508,\ 0.556)$ 。参考与辅助潜在因子共享随机单位方向 $\mathbf{a} \in \mathbb{R}^5$ ：

$$\widetilde{\mathbf{u}} = 0.48(2Y - 1)\mathbf{a} + \boldsymbol{\xi}_u, \qquad \widetilde{\mathbf{v}} = 1.34(2Y - 1)\mathbf{a} + \boldsymbol{\xi}_v, \qquad \boldsymbol{\xi}_u, \boldsymbol{\xi}_v \sim N_5(\mathbf{0}, 0.70^2\mathbf{I}).$$

连续替代变量只在源域观测。取 $\Delta = 2\Phi^{-1}(0.80)$ ，

$$S \mid Y = y \sim N\{(2y - 1)\Delta/2, 1\}.$$

拟合期间既无目标 Y ，也无目标 S 。

替代变量变体使用合并秩5参考 PCA、域内秩3辅助 PCA、源替代分布的双成分高斯混合，以及 XGBoost 替代回归：60棵树、深度2、学习率0.04、行列采样比例0.9、岭惩罚1、最小子节点权重5。方法定义如下。

- **所提方法（无 Y ）：** 不使用任何源金标准标签。仅参考替代桥初始化目标患病率；在每个源域中，匹配前将 S 对参考及可用辅助得分回归，生成工作结局概率和期望标签偏移权重。权重进入参考锚定匹配，之后合并对齐替代桥产生目标似然比。
- **所提方法（半监督）：** 与无 Y 方法使用完全相同权重及对齐表示。按 Bernoulli 20%抽取的源金标准结局子集，仅用于给最终工作概率增加单调截距修正。只有合并金标签子集至少含150个观测且两个结局类别均存在时才启用校准；收缩参数为10。因此，该变体 AUC 与无 Y 方法完全相同，但 MSE 可改善。
- **仅参考：** 使用相同源替代信息，但排除全部辅助对齐和迁移项。**直接全 Y ：** 使用全部源金标准结局与参考表示，不做目标校准或跨域对齐。**正交全 Y ：** 使用全部源金标签及未加权正交对齐，但不使用目标 CCA 锚点。**所提全 Y ：** 在完整目标校准参考锚定程序中使用所有源金标签，作为所提方法的全标签基准。
- 最终的**普通 XGBoost**和**普通 LASSO**基线按行合并五个源域，拼接五个原始模态块，缺失源块用缺失值表示，不使用源站点指示变量。二者使用相同工作标签：Bernoulli 20%金标签掩码内用真实源 Y ，其他用 $\mathbf{1}(S > 0)$ 。普通 XGBoost 用250棵树、深度3、学习率0.05、行列采样比例0.9。普通 LASSO 用仅源中位数插补、缺失指示、标准化，以及按负 Brier 分数在12个 C 值上进行 L_1 logistic 交叉验证。二者都不使用标签偏移权重、EM、所提对齐或任何目标标签适应（Chen 和 Guestrin，2016；Tibshirani，1996）。

目标 AUC 和 MSE 相对于隐藏的二元目标结局评价。

S2.4 替代辅助模拟结果

每域 $n = 400$ 时，无 Y 方法 AUC 为0.9695、MSE 为0.0880。相比仅参考，AUC 提高20.4%、MSE 降低55.3%；相比直接全 Y，相应为18.8%、54.6%。半监督方法 AUC 相同，MSE 进一步降至 0.0814；所提全 Y 基准 AUC 为0.9794、MSE 为0.0722。

样本量增加时，无金标签替代桥接近所提全标签基准。$n = 6400$ 时，无 Y 方法 AUC 为0.9822，仅比全标签值0.9851低0.29%；MSE 为0.0676，对比全标签0.0617。半监督校准把 MSE 降至0.0608。在两个最大样本量下，其蒙特卡洛均值略低于全标签基准；不应将此解读为对预言式方法的系统性改进，因为差异相对于蒙特卡洛不确定性较小，且两个程序使用不同的校准工作模型。

直接学习器未恢复同样的样本量趋势。仅参考和直接全 Y 在 AUC 约0.82、MSE 约0.19处达到平台。普通 XGBoost、普通 LASSO 仅小幅改善，$n = 6400$ 时 AUC 分别为0.7702、0.7965，MSE 分别为 0.1878、0.1835。正交全 Y 最终改善排序，但概率准确性仍较差，$n = 6400$ 时 AUC 为0.9335、MSE 为0.1212。最小样本量时，所提全标签和替代程序本身也有较大波动；随着表示和桥估计量稳定，参考锚定路径的优势才变得系统化。

表 S6。 较小每域样本量的替代辅助模拟。各值为100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标 AUC，B 面板为目标 MSE。方法名释义与图3相同。

Table S6: Surrogate-assisted simulation at smaller per-domain sample sizes. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications. Higher AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$n = 25$	$n = 50$	$n = 100$	$n = 150$	$n = 200$
Panel A: Target AUC					
Proposed (no Y)	0.7665 (0.0154)	0.8543 (0.0120)	0.9171 (0.0066)	0.9367 (0.0041)	0.9504 (0.0034)
Proposed (semi)	0.7665 (0.0154)	0.8543 (0.0120)	0.9171 (0.0066)	0.9367 (0.0041)	0.9504 (0.0034)
Vanilla XGBoost	0.6635 (0.0162)	0.6844 (0.0136)	0.7115 (0.0136)	0.7206 (0.0134)	0.7299 (0.0139)
Vanilla LASSO	0.6055 (0.0189)	0.6391 (0.0167)	0.6725 (0.0171)	0.6991 (0.0169)	0.7101 (0.0157)
Ref.-only	0.7308 (0.0129)	0.7626 (0.0087)	0.7886 (0.0053)	0.7873 (0.0050)	0.8009 (0.0039)
Direct full-Y	**0.8175 (0.0105)**	0.8162 (0.0076)	0.8153 (0.0054)	0.8085 (0.0047)	0.8154 (0.0035)
Orth. full-Y	0.4692 (0.0291)	0.4981 (0.0328)	0.5417 (0.0375)	0.5477 (0.0352)	0.5891 (0.0384)
Prop. full-Y	0.8098 (0.0145)	**0.8782 (0.0124)**	**0.9345 (0.0055)**	**0.9546 (0.0032)**	**0.9676 (0.0027)**
Panel B: Target MSE					
Proposed (no Y)	0.2644 (0.0158)	0.1797 (0.0078)	0.1482 (0.0068)	0.1269 (0.0054)	0.1078 (0.0046)
Proposed (semi)	0.2644 (0.0158)	0.1797 (0.0078)	0.1482 (0.0068)	0.1197 (0.0051)	0.0988 (0.0041)
Vanilla XGBoost	0.2361 (0.0076)	0.2121 (0.0061)	0.1982 (0.0053)	0.1995 (0.0053)	0.1940 (0.0057)
Vanilla LASSO	0.2444 (0.0067)	0.2382 (0.0063)	0.2299 (0.0070)	0.2231 (0.0065)	0.2196 (0.0067)
Ref.-only	0.2525 (0.0099)	0.2198 (0.0062)	0.2121 (0.0043)	0.2098 (0.0039)	0.2012 (0.0030)
Direct full-Y	**0.1981 (0.0049)**	0.1903 (0.0029)	0.1993 (0.0026)	0.1988 (0.0019)	0.1935 (0.0017)
Orth. full-Y	0.2721 (0.0088)	0.2674 (0.0099)	0.2643 (0.0123)	0.2491 (0.0100)	0.2469 (0.0134)
Prop. full-Y	0.2351 (0.0162)	**0.1422 (0.0076)**	**0.1172 (0.0050)**	**0.1010 (0.0038)**	**0.0859 (0.0035)**

表 S7。 较大每域样本量的替代辅助模拟。各值为100次重复的蒙特卡洛均值，括号为蒙特卡洛标准误。AUC 越高、MSE 越低越好；每列最优点估计加粗。A 面板为目标 AUC，B 面板为目标 MSE。

Table S7: Surrogate-assisted simulation at larger per-domain sample sizes. Entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 replications. Higher AUC and lower MSE are preferred; the best point estimate in each column is shown in bold.

Method	$n = 400$	$n = 800$	$n = 1600$	$n = 3200$	$n = 6400$
Panel A: Target AUC					
Proposed (no Y)	0.9695 (0.0017)	0.9757 (0.0009)	0.9786 (0.0009)	0.9821 (0.0005)	0.9822 (0.0005)
Proposed (semi)	0.9695 (0.0017)	0.9757 (0.0009)	0.9786 (0.0009)	0.9821 (0.0005)	0.9822 (0.0005)
Vanilla XGBoost	0.7342 (0.0139)	0.7578 (0.0137)	0.7680 (0.0147)	0.7644 (0.0171)	0.7702 (0.0163)
Vanilla LASSO	0.7132 (0.0163)	0.7585 (0.0148)	0.7677 (0.0164)	0.7806 (0.0184)	0.7965 (0.0169)
Ref.-only	0.8055 (0.0024)	0.8123 (0.0020)	0.8144 (0.0013)	0.8172 (0.0009)	0.8165 (0.0007)
Direct full-Y	0.8159 (0.0024)	0.8175 (0.0019)	0.8173 (0.0013)	0.8188 (0.0009)	0.8175 (0.0007)
Orth. full-Y	0.6399 (0.0412)	0.7477 (0.0382)	0.8645 (0.0318)	0.8673 (0.0317)	0.9335 (0.0234)
Prop. full-Y	**0.9794 (0.0010)**	**0.9822 (0.0006)**	**0.9832 (0.0004)**	**0.9848 (0.0004)**	**0.9851 (0.0003)**
Panel B: Target MSE					
Proposed (no Y)	0.0880 (0.0032)	0.0749 (0.0014)	0.0711 (0.0009)	0.0687 (0.0007)	0.0676 (0.0005)
Proposed (semi)	0.0814 (0.0031)	0.0682 (0.0012)	0.0646 (0.0010)	**0.0620 (0.0005)**	**0.0608 (0.0004)**
Vanilla XGBoost	0.1931 (0.0046)	0.1879 (0.0043)	0.1854 (0.0043)	0.1873 (0.0049)	0.1878 (0.0045)
Vanilla LASSO	0.2232 (0.0070)	0.1997 (0.0057)	0.1959 (0.0064)	0.1910 (0.0070)	0.1835 (0.0065)
Ref.-only	0.1968 (0.0016)	0.1953 (0.0012)	0.1948 (0.0009)	0.1946 (0.0006)	0.1953 (0.0004)
Direct full-Y	0.1941 (0.0012)	0.1933 (0.0009)	0.1939 (0.0006)	0.1937 (0.0004)	0.1939 (0.0003)
Orth. full-Y	0.2309 (0.0139)	0.1895 (0.0124)	0.1477 (0.0125)	0.1539 (0.0141)	0.1212 (0.0098)
Prop. full-Y	**0.0722 (0.0016)**	**0.0657 (0.0010)**	**0.0640 (0.0007)**	0.0632 (0.0005)	0.0617 (0.0003)

S2.5 目标锚定 CCA 与目标更新的交叉消融

交叉消融在 $\varepsilon_{\text{rot}} = 1$、$\delta = 0.24$、$p_{\text{lab}} = 0.35$、基础源模态模式和每域400人下进行。四个实验单元使用相同100个蒙特卡洛种子。完整方法使用合并参考 PCA、域内辅助 PCA、初始目标校准的原始参考得分、结局重加权块对齐、秩5单一联合目标锚定 CCA 回归、源重叠增广和稳定化目标更新。

CCA 开关仅禁用目标锚定 CCA 回归步骤，之前的结局重加权块对齐、初始目标校准、密度比拟合和全部其他部分仍启用。因此该消融把额外的目标定义 CCA/岭匹配与重加权初步对齐分离，并不移除全部对齐操作。目标更新开关跳过稳定化更新，但保留初始参考目标分布估计。两开关交叉得到完整方法、移除目标锚定 CCA、移除目标更新、两者均移除四种配置。目标更新开启时，使用上文相同收敛及边际偏移保护机制。它在完整方法100次重复中的95次、移除目标锚定 CCA 的全部100次中触发。

移除目标锚定 CCA 导致较大退化：宏 AUC 从0.9297降至0.8635，MSE 从0.0983升至0.1361。配对的完整减消融 AUC 差为0.0662（95%蒙特卡洛区间0.0591-0.0733），保留该部分的配对 MSE 降低为0.0379（0.0332-0.0425）。Hamming 损失从0.1306升至0.1948，完全匹配准确率从0.6786降至0.5724。

目标更新影响较小，且主要涉及校准。相比不更新变体，完整方法 MSE 降低0.0069（0.0044-0.0094），Hamming 损失从0.1395降至0.1306，完全匹配准确率从0.6635升至0.6786。加入更新后宏 AUC 低0.0030，完整减不更新的配对区间为 -0.0047 至 -0.0012。状态患病率 L_1 降低为0.0213，区间为 -0.0022 至0.0448。两者均移除时，MSE、状态患病率误差和 Hamming 损失最大。总之，载荷旋转下，目标锚定 CCA 回归提供主要判别增益，稳定化目标更新主要改善后验概率尺度。

表 S8。 $\varepsilon_{\text{rot}} = 1$ 时的交叉消融。性能值为100次配对重复的蒙特卡洛均值，括号为蒙特卡洛标准误。配对对比为正态近似95%蒙特卡洛置信区间，方向统一为正值有利于完整方法：宏 AUC 用完整减消融，误差指标用消融减完整。Variant＝变体；Target-anchor CCA＝目标锚定 CCA；Target update＝目标更新；On/Off＝开启/关闭；State L1 error＝状态 L_1 误差；Hamming loss＝Hamming 损失；Exact match accuracy＝完全匹配准确率；Full proposed＝完整所提方法；ablated＝移除；Both components ablated＝两个部分均移除；Full method versus＝完整方法与所列变体比较。

Table S8: Crossed ablation at $\varepsilon_{\text{rot}} = 1$. Performance entries are Monte Carlo means with Monte Carlo standard errors in parentheses from 100 paired replications. Paired contrasts are normal-approximation 95% Monte Carlo confidence intervals and are oriented so that positive values favor the full method: full minus ablation for macro-AUC and ablation minus full for the error metrics.

Variant	Target-anchor CCA	Target update	Target macro-AUC	Target MSE	State L_1 error
Full proposed	On	On	0.9297 (0.0032)	**0.0983 (0.0024)**	**0.3423 (0.0133)**
Target update ablated	On	Off	**0.9326 (0.0032)**	0.1052 (0.0024)	0.3636 (0.0083)
Target-anchor CCA ablated	Off	On	0.8635 (0.0033)	0.1361 (0.0019)	0.3745 (0.0113)
Both components ablated	Off	Off	0.8627 (0.0033)	0.1417 (0.0020)	0.3886 (0.0100)

Variant	Hamming loss	Exact match accuracy
Full proposed	**0.1306 (0.0032)**	**0.6786 (0.0063)**
Target update ablated	0.1395 (0.0032)	0.6635 (0.0062)
Target-anchor CCA ablated	0.1948 (0.0029)	0.5724 (0.0047)
Both components ablated	0.2024 (0.0031)	0.5620 (0.0049)

Full method versus	Δmacro-AUC (95% CI)	ΔMSE (95% CI)	Δstate L_1 (95% CI)
Target-anchor CCA ablated	0.0662 (0.0591, 0.0733)	0.0379 (0.0332, 0.0425)	0.0322 (0.0087, 0.0558)
Target update ablated	-0.0030 (-0.0047, -0.0012)	0.0069 (0.0044, 0.0094)	0.0213 (-0.0022, 0.0448)
Both components ablated	0.0670 (0.0599, 0.0740)	0.0435 (0.0387, 0.0483)	0.0464 (0.0252, 0.0675)

S3 真实数据分析方案与支持性结果

S3.1 数据资源 队列构建与12个月终点

本分析复用正文所引两项 RCC 研究开发的患者级数据资源。EHR 研究提供已表型识别的 RCC 队列、NLP 生成的分期、分级与组织学变量，以及纵向 LATTE 复发输出。配套影像研究提供关联的术前 CT 扫描、报告概念、常规影像组学及残差影像组学特征。本分析在这些源文件上施加新的终点、时间划分与模态域方案，没有复用前述论文的预测目标或训练测试划分。

按人口学、肾切除术和分期标准排除后，工作队列剩8235人。若12个月内复发，或术后有至少12个月随访，则符合12个月分析资格。要求 `year_first_ICD` 代理变量非缺失后，剩7713名合格患者。病历复核患者的分析终点为医师判定指示量 `event12`；其他患者为 LATTE 生成指示量 $\mathbf{1}\{S_{\text{rec}} = 1,\ S_T \le 12\}$。所得混合终点包含240个医师判定标签和7473个替代标签。预处理及模型拟合前，移除直接编码复发状态、复发时间或12个月内死亡的变量。

S3.2 时间划分与模态域分配

时间划分在任何模型拟合前预先指定。`year_first_ICD` 不超过2016年的患者构成源/训练集，至少2017年的患者构成晚期目标/测试集。五个模态块分别为：（1）人口学及 NLP 临床病理变量；（2）纵向编码 EHR 与医疗利用汇总；（3）放射学报告概念；（4）常规 CT 影像组学；（5）残差影像组学特征。三个源域为 $1+2$、$1+2+3$、$1+4+5$；主要晚期目标域有全部五种模态 $1+2+3+4+5$。较小晚期目标配置 $1+2$、$1+2+3$ 及其合并分析保留为补充配置。

罕见的额外部分模态模式向下归入与其兼容、且完整观测的最大域：$1+2+4$ 归入 $1+2$；$1+2+3+4$ 或 $1+2+3+5$ 归入 $1+2+3$。不通过插补完全缺失的模态块，把任何患者向上分配。

表 S9。 预先指定时间划分下的队列和标签构成。合并源域和完整晚期目标行构成主要分析（$N=6053$），其余晚期目标行定义补充配置。事件指混合12个月终点：病历复核患者使用医师判定 `event12`，其余使用 LATTE 生成的 $S12$。Set＝数据集；Domain＝域；Events＝事件数；Gold n/Gold events＝金标签人数/事件数；Surrogate n/Surrogate events＝替代标签人数/事件数；Pooled＝合并。

Table S9: Cohort and label composition under the pre-specified temporal split. The pooled source and complete late-target rows form the primary analysis ($N = 6053$); the remaining late-target rows define supplementary configurations. Events refer to the mixed 12-month endpoint: physician-adjudicated `event12` for chart-reviewed patients and LATTE-derived $S12$ otherwise.

Set	Domain	n	Events	Gold n	Gold events	Surrogate n	Surrogate events
Source (≤ 2016)	1 + 2	265	56	5	0	260	56
Source (≤ 2016)	1 + 2 + 3	4248	805	130	17	4118	788
Source (≤ 2016)	1 + 4 + 5	1161	172	43	4	1118	168
Source (≤ 2016)	Pooled	5674	1033	178	21	5496	1012
Target (≥ 2017)	1 + 2	136	29	3	0	133	29
Target (≥ 2017)	1 + 2 + 3	1524	326	41	8	1483	318
Target (≥ 2017)	1 + 2 + 3 + 4 + 5	379	100	18	2	361	98
Target (≥ 2017)	Pooled	2039	455	62	10	1977	445

所有目标结局均不参与中心化、特征处理、成分构建、CCA 对齐、密度比估计、目标 EM、模型拟合和超参数选择。无标签目标协变量只进入预先指定的无监督适应步骤。全部预测固定后才合并回目标结局。

S3.3 主要分析与补充目标配置

正文第6节主要检验使用全部5674名源患者及其观测到的异质模态域，以及完整晚期目标域379名患者，总分析队列为6053人。因此，正文所列任何源域都没有被丢弃；每个源域通过可用块贡献信息，目标域提供模态1-5。晚期目标 $1+2$ 层（$n=136$，29个事件）、$1+2+3$ 层（$n=1524$，326个事件）和合并晚期目标队列（$n=2039$，455个事件）是仅记录在本补充材料的次要配置。它们有助于检查对目标侧模态可用性的稳健性，但不替代主要完整目标分析。

S3.4 模型实现 指标与不确定性

所提方法初始表示步骤使用确定性的站点内中心化，不使用 PCA；以模态1为参考块，CCA 锚点秩10，开启目标 EM，关闭源重叠增广。主要完整目标实验使用全部5674个源行，各自保留观测到的 $1+2$、$1+2+3$ 或 $1+4+5$ 域；379个完整目标行保留模态1-5。比较方法为直接迁移 XGBoost、类别特异 logistic LASSO、RGCCA、BONMI。每个比较器只使用允许的源行，不接受源重加权、标签偏移修正、目标 EM 或目标标签校准。

两个主要指标是 Brier 技能评分

$$\mathrm{BSS} = 1 - \frac{n^{-1}\sum_{i=1}^{n}(y_i - \widehat{p}_i)^2}{n^{-1}\sum_{i=1}^{n}(y_i - \bar{y})^2},$$

其中 $\bar{y}$ 为被评价目标样本事件率，以及绝对校准差 $|\widehat{\overline{p}} - \bar{y}|$。AUC 概括排序性能，AP 概括不同召回率水平的精确率。真实数据表按 BSS、校准差、AUC、AP 排列，消融表则聚焦 BSS、校准差两个核心指标。BSS、AUC、AP 越高、校准差越低越好。

各表给出点估计，括号内为固定预测的1000次分层患者级 bootstrap 标准误，不重新拟合模型。单个目标配置按事件状态分层，合并分析按事件状态和目标模态配置联合分层。消融采用1000次共同的事件分层重抽样，使实验单元标准误与配对差标准误来自同一组重抽样。

S3.5 仅替代标签行的终点敏感性

表 S10 将评价限制到终点为 LATTE 替代标签的目标行，保留主要拟合的预测。完整目标域中，所提方法仍有最高 BSS 0.4389（SE 0.0476）、最小校准差0.0080（SE 0.0084）和最高 AUC 0.9082（SE 0.0151）。XGBoost 仍有最高 AP 0.7662（SE 0.0361），所提方法为0.7238（SE 0.0454）。较小及合并目标配置的结果随指标而异，因此本敏感性分析支持主要完整目标的校准发现，但不表示对每个补充配置都全面占优。

表 S10。 使用主要拟合固定预测的仅替代标签行终点敏感性。括号是1000次分层患者级 bootstrap 标准误，不重新拟合。BSS、AUC、AP 越高、校准差越低越好；每个目标域内最优点估计加粗。Target domain＝目标域；Method＝方法；Cal. gap＝校准差；Category-specific LASSO＝类别特异 LASSO；Pooled＝合并。

Table S10: Surrogate-row-only endpoint sensitivity using the fixed predictions from the primary fits. Parentheses give standard errors from 1,000 stratified patient-level bootstrap resamples without model refitting. Higher BSS, AUC and AP and lower calibration gap are preferred. The best point estimate within each target domain is shown in **bold**.

Target domain	Method	BSS	Cal. gap	AUC	AP
1 + 2	Proposed	0.2335 (0.0914)	0.0397 (0.0199)	0.8488 (0.0344)	0.6429 (0.0678)
	XGBoost	0.3404 (0.0789)	0.0408 (0.0156)	0.8773 (0.0317)	0.6932 (0.0737)
	Category-specific LASSO	**0.3818 (0.0610)**	0.0220 (0.0121)	**0.9082 (0.0250)**	**0.7444 (0.0648)**
	RGCCA	0.0169 (0.0964)	**0.0150 (0.0146)**	0.7225 (0.0501)	0.4199 (0.0708)
	BONMI	-0.0199 (0.0200)	0.0394 (0.0037)	0.5305 (0.0649)	0.2492 (0.0437)
1 + 2 + 3	Proposed	0.3007 (0.0281)	0.0238 (0.0057)	0.8653 (0.0108)	0.6163 (0.0256)
	XGBoost	**0.3912 (0.0246)**	0.0355 (0.0050)	**0.9003 (0.0087)**	**0.7229 (0.0215)**
	Category-specific LASSO	0.3243 (0.0298)	**0.0116 (0.0058)**	0.8796 (0.0098)	0.6180 (0.0267)
	RGCCA	0.2377 (0.0257)	0.0189 (0.0049)	0.8341 (0.0126)	0.5628 (0.0258)
	BONMI	0.0420 (0.0085)	0.0300 (0.0018)	0.6619 (0.0180)	0.3762 (0.0239)
1 + 2 + 3 + 4 + 5	Proposed	**0.4389 (0.0476)**	**0.0080 (0.0084)**	**0.9082 (0.0151)**	0.7238 (0.0454)
	XGBoost	0.3461 (0.0463)	0.0907 (0.0103)	0.9044 (0.0160)	**0.7662 (0.0361)**
	Category-specific LASSO	0.3018 (0.0505)	0.0822 (0.0112)	0.8771 (0.0209)	0.6989 (0.0450)
	RGCCA	0.1404 (0.0359)	0.1131 (0.0072)	0.8680 (0.0181)	0.6242 (0.0448)
	BONMI	-0.0430 (0.0102)	0.0941 (0.0023)	0.5273 (0.0345)	0.3056 (0.0302)
Pooled	Proposed	0.3268 (0.0223)	**0.0191 (0.0051)**	0.8739 (0.0083)	0.6405 (0.0205)
	XGBoost	**0.3802 (0.0210)**	0.0459 (0.0040)	**0.8987 (0.0076)**	**0.7262 (0.0181)**
	Category-specific LASSO	0.3253 (0.0257)	0.0252 (0.0050)	0.8771 (0.0094)	0.6324 (0.0235)
	RGCCA	0.2051 (0.0201)	0.0358 (0.0042)	0.8261 (0.0102)	0.5445 (0.0206)
	BONMI	0.0230 (0.0065)	0.0423 (0.0014)	0.6228 (0.0149)	0.3389 (0.0178)

S3.6 完整域的匹配模态敏感性

表 S11 报告将 $1 + 4 + 5$ 源域和完整目标行都限制到模态1、4、5的敏感性分析。五种方法在该匹配模态设定下全部重新拟合，目标结局仍然隐藏。所提方法在每个报告指标上都有最佳点估计：BSS 0.3487（SE 0.0438）、校准差0.0379（SE 0.0103）、AUC 0.8858（SE 0.0167）、AP 0.6666（SE 0.0456）。该分析把参考锚定整合的价值，与主要完整目标分析中目标侧额外拥有模态2、3的价值区分开。

表 S11。 源和目标均保留模态1、4、5的完整域匹配模态敏感性（$n = 379$，100个事件）。括号为1000次按事件分层 bootstrap 标准误。BSS、AUC、AP 越高、校准差越低越好；每指标最佳点估计加粗。

Table S11: Complete-domain matched-modality sensitivity retaining modalities 1, 4 and 5 in both source and target (n = 379, 100 events). Parentheses give event-stratified bootstrap standard errors from 1,000 resamples. Higher BSS, AUC and AP and lower calibration gap are preferred. The best point estimate for each metric is shown in **bold**.

Method	BSS	Cal. gap	AUC	AP
Proposed	**0.3487 (0.0438)**	**0.0379 (0.0103)**	**0.8858 (0.0167)**	**0.6666 (0.0456)**
XGBoost	0.2288 (0.0538)	0.0862 (0.0106)	0.8520 (0.0209)	0.6109 (0.0476)
Category-specific LASSO	0.2529 (0.0451)	0.0720 (0.0095)	0.8481 (0.0213)	0.5941 (0.0448)
RGCCA	0.1103 (0.0371)	0.1160 (0.0078)	0.8253 (0.0215)	0.5581 (0.0432)
BONMI	0.1197 (0.0395)	0.1131 (0.0088)	0.8215 (0.0234)	0.5523 (0.0422)

S3.7 使用模态1 2 3的完整域敏感性

表 S12 报告保留模态1、2、3的互补匹配模态分析。所提方法 BSS 最高，为0.3938（SE 0.0471），校准差最小，为0.0113（SE 0.0092）。RGCCA 的 AUC 和 AP 最高，分别为0.9068（SE 0.0162）、0.7952（SE 0.0348），所提方法则分别为0.8946（SE 0.0159）、0.7103（SE 0.0448）。因此该配置再次支持所提方法的概率准确性和校准优势，但并非每个排序指标都占优。

表 S12。 源和目标均保留模态1、2、3的完整域匹配模态敏感性（$n = 379$，100个事件）。括号为1000次按事件分层 bootstrap 标准误。BSS、AUC、AP 越高、校准差越低越好；每指标最佳点估计加粗。

Table S12: Complete-domain matched-modality sensitivity retaining modalities 1, 2 and 3 in both source and target ($n = 379$, 100 events). Parentheses give event-stratified bootstrap standard errors from 1,000 resamples. Higher BSS, AUC and AP and lower calibration gap are preferred. The best point estimate for each metric is shown in **bold**.

Method	BSS	Cal. gap	AUC	AP
Proposed	**0.3938 (0.0471)**	**0.0113 (0.0092)**	0.8946 (0.0159)	0.7103 (0.0448)
XGBoost	0.3430 (0.0512)	0.0756 (0.0110)	0.8896 (0.0168)	0.7358 (0.0404)
Category-specific LASSO	0.3306 (0.0503)	0.0738 (0.0104)	0.8836 (0.0203)	0.7118 (0.0458)
RGCCA	0.3782 (0.0477)	0.0942 (0.0100)	**0.9068 (0.0162)**	**0.7952 (0.0348)**
BONMI	0.3093 (0.0457)	0.0950 (0.0093)	0.8742 (0.0214)	0.7357 (0.0408)

S3.8 CCA 与目标 EM 的交叉消融

消融研究固定主要完整目标队列、终点、模态规则、预处理和全部未移除设置，交叉两个二元部分：目标锚定 CCA/岭匹配，以及通过目标 EM 实现的目标结局分布更新。完整模型单元使用与参考配置相同的完整域预测；仅其余三个单元重新拟合。如表 S13，移除目标锚定 CCA/岭匹配使 BSS 降低0.0710（配对 SE 0.0260）、校准差增加0.0628（配对 SE 0.0116）。移除目标 EM 使 BSS 降低0.0195（配对 SE 0.0080）、校准差增加0.0366（配对 SE 0.0118）。两者均移除使 BSS 降低0.0702（配对 SE 0.0257）、校准差增加0.0621（配对 SE 0.0110）。保留目标锚定 CCA/岭匹配时，目标 EM 更新改善概率准确性与校准；缺少该匹配时，更新效果可忽略。这种交叉模式说明目标更新依赖充分对齐的表示，且目标锚定 CCA/岭匹配的贡献更大。

表 S13。 完整目标域（$n = 379$，100个事件）中目标锚定 CCA/岭匹配与目标 EM 的交叉消融。括号为1000次共同按事件分层 bootstrap 标准误。第二面板报告完整模型减消融的点差及配对 bootstrap 标准误。报告核心消融指标：BSS 越高、校准差越低越好。校准差之差为负表示有利于完整模型。Full model＝完整模型；CCA ablated＝移除 CCA；Target-EM ablated＝移除目标 EM；Both components ablated＝两个部分均移除；On/Off＝开启/关闭；Full model minus＝完整模型减去所列变体。

Table S13: Crossed ablation of the target-anchor CCA/ridge match-up and target-EM in the complete target domain (n = 379, 100 events). Parentheses give standard errors from 1,000 common event-stratified bootstrap resamples. The second panel reports full-model-minus-ablation point differences with paired bootstrap standard errors. The table reports the two core ablation rubrics: higher BSS and lower calibration gap are preferred. For calibration-gap differences, a negative value favors the full model.

Variant	CCA	Target-EM	BSS	Cal. gap
Full model	On	On	**0.4194 (0.0485)**	**0.0015 (0.0070)**
CCA ablated	Off	On	0.3484 (0.0447)	0.0642 (0.0097)
Target-EM ablated	On	Off	0.3999 (0.0444)	0.0381 (0.0105)
CCA + target-EM ablated	Off	Off	0.3492 (0.0460)	0.0636 (0.0101)

Full model minus	ΔBSS	ΔCal. gap
CCA ablated	0.0710 (0.0260)	−0.0628 (0.0116)
Target-EM ablated	0.0195 (0.0080)	−0.0366 (0.0118)
Both components ablated	0.0702 (0.0257)	−0.0621 (0.0110)

S3.9 缺失与解释

完全缺失的模态块通过规范域分配处理，而不是向上插补。已观测块内部使用预先指定、方法特异的预处理。XGBoost 使用其原生缺失值机制。类别特异 LASSO 使用仅源中位数插补、缺失指示和仅源标准化。所有从带标签数据估计的变换参数仅由源行学习。

主要完整目标评价379人中，18人有医师判定标签，361人有 LATTE 替代标签。合并次要晚期目标评价包含62个判定标签和1977个替代标签。因此，真实数据分析量化的是预先指定混合终点的迁移性能，不应解读为对12个月 RCC 复发进行的全医师判定外部验证。

参考文献

以下保留原文的60条完整书目信息，并逐条附中文题名，便于检索核对。作者姓名、刊会名及出版细节不意译。

[1] 带偏差修正校准的最大似然方法在标签偏移适应中难以超越。

Amr Alexandari, Anshul Kundaje, and Avanti Shrikumar. Maximum likelihood with bias-corrected calibration is hard-to-beat at label shift adaptation. In Hal Daumé III and Aarti Singh, editors, Proceedings of the 37th International Conference on Machine Learning, volume 119 of Proceedings of Machine Learning Research, pages 222–232. PMLR, 13–18 Jul 2020.

[2] 多模态机器学习综述与分类体系。

Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(2):423–443, 2019.

[3] 学习利用时间结构进行生物医学视觉语言处理。

Shruthi Bannur, Stephanie Hyland, Qianchu Liu, Fernando Perez-Garcia, Maximilian Ilse, Daniel C Castro, Benedikt Boecking, Harshita Sharma, Kenza Bouzid, Anja Thieme, et al. Learning to exploit temporal structure for biomedical vision-language processing. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 15016–15027, 2023.

[4] 通过广义方差分析分解对不完整数据进行高效估计。

Thomas B Berrett. Efficient estimation with incomplete data via generalised anova decompositions. arXiv preprint arXiv:2409.05729, 2024.

[5] 以概率形式表达的预报的验证。

Glenn W. Brier. Verification of forecasts expressed in terms of probability. Monthly Weather Review, 78(1): 1–3, 1950.

[6] 结构化矩阵补全及其在基因组数据整合中的应用。

Tianxi Cai, T Tony Cai, and Anru Zhang. Structured matrix completion with applications to genomic data integration. Journal of the American Statistical Association, 111(514):621–633, 2016.

[7] XGBoost 一种可扩展的树提升系统。

Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '16, page 785–794, New York, NY, USA, 2016. Association for Computing Machinery.

[8] 多变量预后模型外部验证的样本量考量 一项重抽样研究。

Gary S. Collins, Emmanuel O. Ogundimu, and Douglas G. Altman. Sample size considerations for the external validation of a multivariable prognostic model: A resampling study. Statistics in Medicine, 35 (2):214–226, 2016.

[9] 通过 EM 算法从不完整数据进行最大似然估计。

Arthur P Dempster, Nan M Laird, and Donald B Rubin. Maximum likelihood from incomplete data via the em algorithm. Journal of the royal statistical society: series B (methodological), 39(1):1–22, 1977.

[10] 标签偏移下的不完整多视图学习。

Ruidong Fan, Xiao Ouyang, Tingjin Luo, Dewen Hu, and Chenping Hou. Incomplete multi-view learning under label shift. IEEE Transactions on Image Processing, 32:3702–3716, 2023.

[11] 标签偏移估计的统一视角。

Saurabh Garg, Yifan Wu, Sivaraman Balakrishnan, and Zachary Lipton. A unified view of label shift estimation. Advances in Neural Information Processing Systems, 33:3290–3300, 2020.

[12] 用于转化研究的电子健康记录数据协调通用流程。

Jessica Gronsbell, Vidul Ayakulangara Panickan, Doudou Zhou, Chris Lin, Thomas Charlon, Chuan Hong, Xin Xiong, Linshanshan Wang, Jianhui Gao, Shirley Zhou, et al. A common pipeline for harmonizing electronic health record data for translational research. arXiv preprint arXiv:2509.08553, 2025.

[13] 典型相关分析概述及其在学习方法中的应用。

David R Hardoon, Sandor Szedmak, and John Shawe-Taylor. Canonical correlation analysis: An overview with application to learning methods. Neural computation, 16(12):2639–2664, 2004.

[14] 岭正则化 数据科学中的一个基本概念。

Trevor Hastie. Ridge regularization: An essential concept in data science. Technometrics, 62(4):426–433, 2020.

[15] 矩阵函数 理论与计算。

Nicholas J. Higham. Functions of Matrices: Theory and Computation. Society for Industrial and Applied Mathematics, Philadelphia, PA, 2008.

[16] 两组变量之间的关系。

Harold Hotelling. Relations between two sets of variates. Biometrika, 28(3/4):321–377, 1936. ISSN 00063444.

[17] 利用电子健康记录估计肾细胞癌复发率。

J Hou, J Wen, R Bhattacharya, Z Wang, S Morini Sweet, W Xu, A Elfiky, L Wang, R Srivastava, J Lu, et al. Estimate renal cell carcinoma recurrence rates using electronic health records. ESMO Real World Data and Digital Oncology, 12:100695, 2026.

[18] nnU-Net 面向深度学习生物医学图像分割的自配置方法。

Fabian Isensee, Paul F Jaeger, Simon AA Kohl, Jens Petersen, and Klaus H Maier-Hein. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation. Nature methods, 18(2): 203–211, 2021.

[19] 主成分分析综述与最新进展。

Ian T Jolliffe and Jorge Cadima. Principal component analysis: a review and recent developments. Philosophical transactions of the royal society A: Mathematical, Physical and Engineering Sciences, 374(2065): 20150202, 2016.

[20] 样本协方差算子的集中不等式与矩界。

Vladimir Koltchinskii and Karim Lounici. Concentration inequalities and moment bounds for sample covariance operators. Bernoulli, pages 110–133, 2017.

[21] 多模态数据融合 方法 挑战与前景概述。

Dana Lahat, Tülay Adali, and Christian Jutten. Multimodal data fusion: an overview of methods, challenges, and prospects. Proceedings of the IEEE, 103(9):1449–1477, 2015.

[22] 标签偏移下的双重灵活估计。

Seong-ho Lee, Yanyuan Ma, and Jiwei Zhao. Doubly flexible estimation under label shift. Journal of the American Statistical Association, 120(549):278–290, 2025a.

[23] 无监督域适应中标签偏移下的高效推断。

Seong-ho Lee, Yanyuan Ma, and Jiwei Zhao. Efficient inference under label shift in unsupervised domain adaptation. arXiv preprint arXiv:2508.17780, 2025b.

[24] 块状缺失与半监督数据的自适应高效学习。

Yiming Li, Ruoyu Wang, Ying Wei, and Molei Liu. Adaptive and efficient learning with blockwise missing and semi-supervised data. arXiv preprint arXiv:2405.18722, 2024.

[25] 论对抗域适应中的目标偏移。

Yitong Li, Michael Murias, Samantha Major, Geraldine Dawson, and David Carlson. On target shift in adversarial domain adaptation. In Proceedings of the Twenty-Second International Conference on Artificial Intelligence and Statistics, volume 89 of Proceedings of Machine Learning Research, pages 616–625. PMLR, 2019.

[26] 利用黑箱预测器检测并修正标签偏移。

Zachary Lipton, Yu-Xiang Wang, and Alexander Smola. Detecting and correcting for label shift with black box predictors. In International conference on machine learning, pages 3122–3130. PMLR, 2018.

[27] 采用半非参数干扰模型的增广迁移回归学习。

Molei Liu, Yi Zhang, Katherine P Liao, and Tianxi Cai. Augmented transfer regression learning with semi-non-parametric nuisance models. Journal of Machine Learning Research, 24(293):1–50, 2023.

[28] 块状缺失与信号异质性下的表示学习。

Ziqi Liu, Ye Tian, and Weijing Tang. Representation learning with blockwise missingness and signal heterogeneity. arXiv preprint arXiv:2602.11511, 2026.

[29] 论将气候态作为 Brier 与排序概率技能评分的参考策略。

Simon J Mason. On using “climatology” as a reference strategy in the brier and ranked probability skill scores. Monthly Weather Review, 132(7):1891–1895, 2004.

[30] 一般形式数据集偏移下的高效多重稳健风险估计。

Hongxiang Qiu, Eric Tchetgen Tchetgen, and Edgar Dobriban. Efficient and multiply robust risk estimation under general forms of dataset shift. The Annals of Statistics, 52(4):1796–1824, 2024.

[31] 从自然语言监督学习可迁移视觉模型。

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In International conference on machine learning, pages 8748–8763. PMLR, 2021.

[32] 目标偏移下多源域适应的最优传输。

Ievgen Redko, Nicolas Courty, Rémi Flamary, and Devis Tuia. Optimal transport for multi-source domain adaptation under target shift. In Proceedings of the Twenty-Second International Conference on Artificial Intelligence and Statistics, volume 89 of Proceedings of Machine Learning Research, pages 849–858. PMLR, 2019.

[33] pROC 用于分析与比较 ROC 曲线的 R 和 S+ 开源软件包。

Xavier Robin, Natacha Turck, Alexandre Hainard, Natalia Tiberti, Frédérique Lisacek, Jean-Charles Sanchez, and Markus Müller. pROC: An open-source package for R and S+ to analyze and compare ROC curves. BMC Bioinformatics, 12(1):77, 2011.

[34] 将分类器输出调整到新的先验概率 一种简单程序。

Marco Saerens, Patrice Latinne, and Christine Decaestecker. Adjusting the outputs of a classifier to new a priori probabilities: a simple procedure. Neural computation, 14(1):21–41, 2002.

[35] 正交 Procrustes 问题的广义解。

Peter H Schönemann. A generalized solution of the orthogonal procrustes problem. Psychometrika, 31(1): 1–10, 1966.

[36] 通过加权对数似然函数改善协变量偏移下的预测推断。

Hidetoshi Shimodaira. Improving predictive inference under covariate shift by weighting the log-likelihood function. Journal of statistical planning and inference, 90(2):227–244, 2000.

[37] 聚合多个发生目标偏移的源域。

Changjian Shui, Zijian Li, Jiaqi Li, Christian Gagné, Charles X Ling, and Boyu Wang. Aggregating from multiple target-shifted sources. In Proceedings of the 38th International Conference on Machine Learning, volume 139 of Proceedings of Machine Learning Research, pages 9638–9648. PMLR, 2021.

[38] 无需插补的块状缺失数据半监督推断。

Shanshan Song, Yuanyuan Lin, and Yong Zhou. Semi-supervised inference for block-wise missing data without imputation. Journal of Machine Learning Research, 25(99):1–36, 2024.

[39] 机器学习中的密度比估计。

Masashi Sugiyama, Taiji Suzuki, and Takafumi Kanamori. Density ratio estimation in machine learning. Cambridge University Press, 2012.

[40] 异质多源块状缺失数据的多任务学习。

Yang Sui, Qi Xu, Yang Bai, and Annie Qu. Multi-task learning for heterogeneous multi-source block-wise missing data. Journal of Computational and Graphical Statistics, pages 1–9, 2026.

[41] 正则化广义典型相关分析。

Arthur Tenenhaus and Michel Tenenhaus. Regularized generalized canonical correlation analysis. Psychometrika, 76(2):257–284, 2011.

[42] 通过 LASSO 进行回归收缩与选择。

Robert Tibshirani. Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society Series B: Statistical Methodology, 58(1):267–288, 1996.

[43] 风险模型校准层级的定义 从理想状态到经验数据。

Ben Van Calster, Daan Nieboer, Yvonne Vergouwe, Bavo De Cock, Michael J. Pencina, and Ewout W. Steyerberg. A calibration hierarchy for risk models was defined: From utopia to empirical data. Journal of Clinical Epidemiology, 74:167–176, 2016.

[44] 渐近统计学。

Aad W Van der Vaart. Asymptotic statistics, volume 3. Cambridge university press, 2000.

[45] 解码影像表型的计算影像组学系统。

Joost JM Van Griethuysen, Andriy Fedorov, Chintan Parmar, Ahmed Hosny, Nicole Aucoin, Vivek Narayan, Regina GH Beets-Tan, Jean-Christophe Fillion-Robin, Steve Pieper, and Hugo JWL Aerts. Computational radiomics system to decode the radiographic phenotype. Cancer research, 77(21):e104–e107, 2017.

[46] 高维概率及其数据科学应用导论。

Roman Vershynin. High-Dimensional Probability: An Introduction with Applications in Data Science. Number 47 in Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, Cambridge, 2018.

[47] 图模型 指数族与变分推断。

Martin J Wainwright and Michael I Jordan. Graphical models, exponential families, and variational inference. Foundations and Trends® in Machine Learning, 1(1-2):1–305, 2008.

[48] 与奇异值分解有关的扰动界。

Per-Åke Wedin. Perturbation bounds in connection with singular value decomposition. BIT Numerical Mathematics, 12(1):99–111, 1972.

[49] LATTE 从纵向电子健康记录进行标签高效的事件表型识别。

Jun Wen, Jue Hou, Clara-Lea Bonzel, Yihan Zhao, Victor M Castro, Vivian S Gainer, Dana Weisenfeld, Tianrun Cai, Yuk-Lam Ho, Vidul A Panickan, et al. Latte: Label-efficient incident phenotyping from longitudinal electronic health records. Patterns, 5(1), 2024.

[50] 知识驱动的在线多模态自动表型识别系统。

Xin Xiong, Sara Morini Sweet, Molei Liu, Chuan Hong, Clara-Lea Bonzel, Vidul Ayakulangara Panickan, Doudou Zhou, Linshanshan Wang, Lauren Costa, Yuk-Lam Ho, Alon Geva, Kenneth D. Mandl, Suchun Cheng, Zongqi Xia, Kelly Cho, J. Michael Gaziano, Katherine P. Liao, Tianxi Cai, and Tianrun Cai. Knowledge-driven online multimodal automated phenotyping system. medRxiv preprint 2023.09.29.23296239, 2023.

[51] 标签偏移下的稳健多源域适应。

Congbin Xu, Chengde Qian, Zhaojun Wang, and Changliang Zou. Robust multi-source domain adaptation under label shift. arXiv preprint arXiv:2503.02506, 2025.

[52] 异质数据整合的表示检索学习。

Qi Xu and Annie Qu. Representation retrieval learning for heterogeneous data integration. arXiv preprint arXiv:2503.09494, 2025.

[53] 模型选择中多源块状缺失数据的整合。

Fei Xue and Annie Qu. Integrating multisource block-wise missing data in model selection. Journal of the American Statistical Association, 116(536):1914–1927, 2021.

[54] 无需插补的块缺失多模态数据最优稀疏线性预测。

Guan Yu, Quefeng Li, Dinggang Shen, and Yufeng Liu. Optimal sparse linear prediction for block-missing multi-modality data without imputation. Journal of the American Statistical Association, 115(531): 1406–1419, 2020.

[55] 块状缺失下的模式校准多模态预测。

Junhan Yu, Kejian Zhang, Doudou Zhou, and Guojun Zhu. Pattern-calibrated multimodal prediction under blockwise missingness. arXiv preprint arXiv:2607.01821, 2026.

[56] NILE 面向电子健康记录的快速自然语言处理。

Sheng Yu, Tianrun Cai, and Tianxi Cai. Nile: fast natural language processing for electronic health records. arXiv preprint arXiv:1311.6063, 2013.

[57] 面向统计学家的 Davis-Kahan 定理实用变体。

Yi Yu, Tengyao Wang, and Richard J Samworth. A useful variant of the davis–kahan theorem for statisticians. Biometrika, 102(2):315–323, 2015.

[58] 多源多模态域适应。

Sicheng Zhao, Jing Jiang, Wenbo Tang, Jiankun Zhu, Hui Chen, Pengfei Xu, Björn W. Schuller, Jianhua Tao, Hongxun Yao, and Guiguang Ding. Multi-source multi-modal domain adaptation. Information Fusion, 117:102862, 2025.

[59] 通过块状重叠噪声矩阵补全进行多源学习。

Doudou Zhou, Tianxi Cai, and Junwei Lu. Multi-source learning via completion of block-wise overlapping noisy matrices. Journal of Machine Learning Research, 24(221):1–43, 2023.

[60] 具有块状缺失结构的多类型数据广义整合主成分分析。

Huichen Zhu, Gen Li, and Eric F Lock. Generalized integrative principal component analysis for multi-type data with block-wise missing structure. Biostatistics, 21(2):302–318, 2020.