朴素插补对高维线性模型产生隐式正则化

非官方中文全文译文

Alexis Ayme[1]、Claire Boyer[1]、Aymeric Dieuleveut[2]、Erwan Scornet[2]

[1] 法国巴黎，索邦大学、法国国家科学研究中心（CNRS），概率、统计与建模实验室（LPSM），F-75005。[2] 法国帕莱索，巴黎理工学院联盟综合理工学院，CMAP，UMR7641，91128。通信作者：Alexis Ayme（alexis.ayme@sorbonne-universite.fr）。

原文：Naive imputation implicitly regularizes high-dimensional linear models. 第40届国际机器学习大会论文集，美国夏威夷檀香山，PMLR 202:1320–1340，2023。版权所有 © 2023 原作者。

原文与许可：官方论文；CC BY 4.0；PMLR 出版协议。本译文为中文翻译与重新排版的改编作品，不代表作者或出版方认可。附录的长公式、逐行推导及原始图表以原文裁图保留，避免改变数学记号；中文正文覆盖全部论述。原文可疑等式或记号不作静默修订。

摘要

为预测而处理缺失值有两种不同途径：在拟合任何预测算法之前先插补，或者使用能够原生纳入缺失值的专门方法。虽然插补应用广泛且易于使用，但遗憾的是，随后若采用低容量预测器（如线性模型），它会产生偏差。然而，实践中朴素插补展现出良好的预测性能。本文研究在具有完全随机缺失（MCAR）数据的高维线性模型中，插补所产生的影响。我们证明，零值插补进行了一种隐式正则化，它与高维问题中常用的岭方法密切相关。利用这一联系，我们证明插补偏差受岭偏差控制，而后者会在高维下消失。对于预测器，我们主张在零值插补数据上采用平均随机梯度下降（SGD）策略。我们建立了其泛化误差上界，说明在 $d \gg \sqrt{n}$ 的情形下插补是良性的。实验展示了我们的发现。

1. 引言

缺失数据已成为现代数据科学的一个固有问题。事实上，大多数真实数据集都包含缺失项，原因多种多样，例如合并不同数据源、传感器故障，以及在敏感领域（如医疗）难以收集或访问数据等。一个简单但相当极端的办法是丢弃部分缺失的观测，但这会大幅缩减数据集规模，从而妨碍进一步的统计分析。因此，应当开发处理缺失值的专门方法。多数此类方法致力于模型估计，即使存在缺失值，也力图推断底层模型参数（参见 Rubin, 1976）。本文采用不同的思路：考虑训练输入和测试输入都含有缺失值的监督机器学习（ML）问题，其目标是构建预测函数，而不是准确估计真实模型参数。

含 NA 的预测。对缺失数据进行监督学习时，一种常见做法是先对数据集插补，再在补全后的数据集上训练任意预测器。插补技术既可以很简单（例如均值插补），也可以更复杂（Van Buuren & Groothuis-Oudshoorn, 2011；Yoon et al., 2018；Muzellec et al., 2020；Ipsen et al., 2022）。尽管这些广泛使用的两步策略缺乏深入的理论基础，但已有研究证明，只要所选预测器的逼近能力足够强，这些策略便具有一致性（参见 Josse et al., 2019；Le Morvan et al., 2021）。对于线性模型等低容量预测器，其他有理论依据的策略包括：按照所有可能的缺失模式分解预测任务（参见 Le Morvan et al., 2020b；Ayme et al., 2022），或者自动检测对预测有用的模式，从而突破逐模式预测器的组合

复杂性（参见 Le Morvan et al., 2020a 中专门设计的 NeuMiss 架构）。这些方法已被证明几乎最优（Ayme et al., 2022），因而可能对非常不利的缺失数据情形保持稳健。然而，随着缺失模式的种类爆炸式增长，它们本质上无法扩展到高维数据集。Agarwal et al. (2019) 提倡另一条路径：利用主成分回归（PCR）训练具有缺失输入的线性模型。但在这种情况下，样本外预测需要在训练集与测试集上重新训练预测器，以执行全局主成分分析；这明显不同于实践中大量使用的经典机器学习算法。

本文关注线性预测器的高维情形。我们将看到，这种情形更有利于用简单且廉价的插补方法处理缺失值，尤其是在完全随机缺失（MCAR）的情况下。

高维线性模型。 在输入完整的监督学习中，若在高维框架下训练线性模型等参数化方法，人们通常采用 ℓ^2 或岭正则化。一方面，这种正则化通过改善收敛速度来加快优化过程（Dieuleveut et al., 2017）；另一方面，它也提升训练所得预测器的泛化能力（Caponnetto & De Vito, 2007；Hsu et al., 2012）。一般而言，第二点适用于显式的 ℓ^2 正则化，但也有工作强调优化算法能够诱导隐式正则化，例如通过提前停止（Yao et al., 2007），以及最近在插值情形下通过梯度策略实现（Bartlett et al., 2020；Chizat & Bach, 2020；Pesme et al., 2021）。

贡献。 为实现监督学习，我们考虑将输入中的缺失项替换为零的零值插补策略，并形式化刻画它在回归任务中引入的偏差（第2节）。当缺失值属于完全随机缺失（MCAR）时，我们证明，在线性模型训练前进行零值插补会引入一种隐式正则化，它与岭回归的正则化密切相关（第3节）。我们通过实例说明，在高维情形中常见的设置下，例如输入的协方差矩阵为低秩时，这种偏差可以忽略。随后，我们主张在零值插补后的数据上采用平均随机梯度算法（SGD）（第4节）。这种预测器在计算上高效，尤其适合高维学习。对于这一策略，我们建立了适用于所有 d, n 的泛化界；在 $d \gg \sqrt{n}$ 时，MCAR 数据插补的影响得到缓和。这些理论结果为多数实践者采用的广泛使用的插补方法提供了依据，并得到第5节数值实验的支持。所有证明均见附录。

2. 背景与动机

2.1. 一般设置与记号

在监督学习背景下，考虑 $n \in \mathbb{N}$ 个输入/输出观测 $\big((X_i, Y_i)\big)_{i\in[n]}$，它们是一般随机对 $(X, Y) \in \mathbb{R}^d \times \mathbb{R}$ 的独立同分布副本。稍微滥用记号：我们始终用 $i \in [n]$ 的 X_i 表示位于 $\mathbb{R}^d$ 中的第 i 个观测，而用 $j \in [d]$ 的 X_j（或 $k \in [d]$ 的 X_k）表示一般输入 X 的第 j（或 k）个坐标（记号见附录A）。

缺失值。 在真实数据集中，输入协变量 $(X_i)_{i\in[n]}$ 往往仅被部分观测。为编码这种缺失信息，我们引入随机向量 $P \in \{0, 1\}^d$，称为掩码或缺失模式：若 X 的第 j 个坐标 X_j 缺失，则 $P_j = 0$，否则 $P_j = 1$。随机向量 $P_1, \ldots, P_n$ 假设为一般随机变量 $P \in \{0, 1\}^d$ 的独立同分布副本，并分别是 $X_1, \ldots, X_n$ 的缺失模式。注意，我们假设输出始终被观测到，只有输入向量的分量可能缺失。缺失数据通常分为三种类型，最初由 Rubin (1976) 提出。本文关注 MCAR 假设，即缺失模式与底层输入相互独立。

假设1（完全随机缺失，MCAR）。 随机对 (X, Y) 与关联于 X 的缺失模式 P 相互独立。

对于 $j \in [d]$，定义 $\rho_j := \mathbb{P}\left(P_j = 1\right)$，即 $1-\rho_j$ 是第 j 个特征上缺失值的期望比例。MCAR 数据的一种特殊情形不仅要求掩码与数据独立，还要求所有掩码分量相互独立，如下所述。

假设1′（Ho-MCAR：具有独立同质分量的 MCAR 模式）。随机对 (X, Y) 与关联于 X 的缺失模式 P 相互独立，并且 P 满足 $P \sim \mathcal{B}(\rho)^{\otimes d}$，其中 $0 < \rho \leq 1$，$1-\rho$ 为缺失值的期望比例，$\mathcal{B}$ 表示伯努利分布。

协变量的朴素插补。在任何学习任务中，一种常见的缺失值处理方式是先对缺失数据插补，获得完整数据集，然后应用标准机器学习算法。尤其是常数插补（使用经验均值，或者由专家提供的预言机常数），在实践者中非常常见。本文即使对于非中心化分布，也考虑朴素的零值插补。因此，对于 $i \in [n]$，零值插补后的观测 $\left(X_{\mathrm{imp}}\right)_i$ 为

$$\left(X_{\mathrm{imp}}\right)_i = P_i \odot X_i. \qquad (1)$$

风险。设 $f : \mathbb{R}^d \to \mathbb{R}$ 是基于完整 d 维输入的可测预测函数。其预测性能可用平方风险度量：

$$R(f) := \mathbb{E}\left[\left(Y - f(X)\right)^2\right]. \qquad (2)$$

相应地，记 $f^\star(X) = \mathbb{E}[Y \mid X]$ 为完整情形的贝叶斯预测器，$R^\star$ 为对应风险。

存在缺失数据时，仍可把预测函数 f 用于零值插补后的输入 X_{imp}，得到预测 $f\left(X_{\mathrm{imp}}\right)$。此时，$f$ 作用于插补数据的风险定义为

$$R_{\mathrm{imp}}(f) := \mathbb{E}\left[\left(Y - f\left(X_{\mathrm{imp}}\right)\right)^2\right]. \qquad (3)$$

对于从 $\mathbb{R}^d$ 到 $\mathbb{R}$ 的线性预测函数类 $\mathcal{F}$，分别定义

$$R^\star(\mathcal{F}) = \inf_{f \in \mathcal{F}} R(f), \qquad (4)$$

以及

$$R^\star_{\mathrm{imp}}(\mathcal{F}) = \inf_{f \in \mathcal{F}} R_{\mathrm{imp}}(f), \qquad (5)$$

它们分别是在完整输入数据和零值插补输入数据下，函数类 $\mathcal{F}$ 上风险的下确界。

对于任意 $x \in \mathbb{R}^d$ 和固定 $\theta \in \mathbb{R}^d$，线性预测函数 $f_\theta(x) = \theta^\top x$ 完全由参数 θ 确定，因此我们滥用记号，以 $R(\theta)$ 表示 $R\left(f_\theta\right)$，以 $R_{\mathrm{imp}}(\theta)$ 表示 $R_{\mathrm{imp}}\left(f_\theta\right)$。还记 $\theta^\star \in \mathbb{R}^d$（相应地，$\theta^\star_{\mathrm{imp}}$）为在线性函数类上达到最佳风险的参数，即 $R^\star(\mathcal{F}) = R\left(\theta^\star\right)$（相应地，$R^\star_{\mathrm{imp}}(\mathcal{F}) = R_{\mathrm{imp}}\left(\theta^\star_{\mathrm{imp}}\right)$）。

插补偏差。尽管将缺失数据插补为零的预处理步骤在实践中经常使用，但这种插补技术可能在预测中引入偏差。我们将插补偏差定义为

$$B_{\mathrm{imp}}(\mathcal{F}) := R^\star_{\mathrm{imp}}(\mathcal{F}) - R^\star(\mathcal{F}). \qquad (6)$$

该量表示完整数据下的最佳预测器与零值插补输入下的最佳预测器在预测性能上的差异。特别地，若该量较小，则插补数据下的最佳预测器风险接近全部数据可用时的最佳预测器风险。注意，存在缺失值时，人们可能关心贝叶斯预测器

$$f^{\star}_{\mathrm{mis}}\left(X_{\mathrm{imp}},\, P\right) = \mathbb{E}\left[Y \mid X_{\mathrm{imp}},\, P\right], \qquad (7)$$

以及它的风险 $R^{\star}_{\mathrm{mis}}$。

引理2.1。 假设回归模型 $Y = f^{\star}(X) + \epsilon$ 满足 ϵ 与 P 独立，则 $R^{\star} \le R^{\star}_{\mathrm{mis}}$。

直观而言，在经典假设 $\varepsilon \perp\!\!\!\perp P$ 下（参见 Josse et al., 2019；假设1保证此条件），缺失数据不可避免地使原始预测问题恶化。直接推论是，对于完整情形下正确设定的线性模型 $f^{\star} \in \mathcal{F}$，

$$R_{\mathrm{imp}}(\mathcal{F}) - R^{\star}_{\mathrm{mis}} \le B_{\mathrm{imp}}(\mathcal{F}). \qquad (8)$$

因此，本文集中分析先插补后回归策略相对于完整数据问题的偏差及超额风险（式(8)右端），从而控制相对于缺失数据情形的插补超额风险（式(8)左端）。

简而言之，$B_{\mathrm{imp}}(\mathcal{F})$ 描述了通过零值插补处理的缺失值如何增加学习问题的难度。第3节将严格研究，高维情形能够缓和这种影响。为提供直观认识，下面考察一个简单例子。

例2.2。 假设极度冗余的情形：所有协变量都相等，即对所有 $j \in [d]$，$X_j = X_1$，且 $\mathbb{E}\left[X_1^2\right] = 1$。再假设输出为 $Y = X_1$，并且假设1′在 $\rho = 1/2$ 时成立。由于输入冗余，所有满足 $\sum_{j=1}^{d} \theta_j = 1$ 的 θ 都使 $\theta \mapsto R(\theta)$ 最小。例如取 $\theta_1 = (1,\, 0,\, \ldots,\, 0)^{\top}$，则 $R^{\star} = R\left(\theta_1\right) = 0$，但

$$R_{\mathrm{imp}}\left(\theta_1\right) = \mathbb{E}\left[\left(X_1 - P_1 X_1\right)^2\right] = \frac{1}{2}.$$

这一 θ_1 的选择使插补数据风险与贝叶斯风险 $R^{\star} = 0$ 之间存在不可消除的差距。另一种参数选择实际上有助于缩小这一差距。利用协变量冗余，取 $\theta_2 = (2/d,\, 2/d,\, \ldots,\, 2/d)^{\top}$（它不再是原始风险的极小化参数），得到

$$R_{\mathrm{imp}}\left(\theta_2\right) = \mathbb{E}\left[\left(X_1 - \frac{2}{d}\sum_{j=1}^{d} P_j X_j\right)^2\right] = \frac{1}{d}.$$

因此，插补偏差 $B_{\mathrm{imp}}(\mathcal{F})$ 不超过 $1/d$，随维度增加而趋于零。这个例子还有两个重要观察。第一，即使 $\mathbb{E}X_1 \neq 0$，该界仍然有效，所以即使数据未中心化，零值插补仍然有意义。第二，$\| \theta_2 \|_2^2 = 4/d$，因此在高维下，适合插补后预测的候选参数似乎具有较小范数。第4节将在更一般的设置中证明这一点。

本文的目的是把例2.2的现象推广到限制较少的设置。受此例启发，我们集中分析输入变量之间共享信息的情形；对于线性模型，相关性承担这一角色。

协方差矩阵。 对一般完整输入 $X \in \mathbb{R}^d$，记 $\Sigma := \mathbb{E}\left[XX^{\top}\right]$ 为其协方差矩阵，具有奇异值分解

$$\Sigma = \sum_{j=1}^{d} \lambda_j v_j v_j^{\top}, \qquad (9)$$

其中 λ_j 和 v_j 分别是 Σ 的奇异值和奇异向量，且 $\lambda_1 \geq \cdots \geq \lambda_d$。对所有 $\theta \in \mathbb{R}^d$，相应的伪范数为

$$\| \theta \|_{\Sigma}^{2} := \theta^{\top} \Sigma \theta = \sum_{j=1}^{d} \lambda_j \left(v_j^{\top} \theta \right)^2.$$

对于最佳线性预测，$Y = X^{\top} \theta^{\star} + \epsilon$，噪声满足 $\mathbb{E}[\epsilon X] = 0$（一阶条件）。记 $\mathbb{E}\left[\epsilon^2\right] = \sigma^2$，则

$$\mathbb{E} Y^2 = \| \theta^{\star} \|_{\Sigma}^{2} + \sigma^2 = \sum_{j=1}^{d} \lambda_j \left(v_j^{\top} \theta^{\star} \right)^2 + \sigma^2. \qquad (10)$$

因此，$\lambda_j \left(v_j^{\top} \theta^{\star} \right)^2$ 可以解释为奇异方向 v_j 所解释的方差部分。

注2.3。在例2.2中，Σ 只有一个正奇异值 $\lambda_1 = d$，即全部方差集中在第一个奇异方向上。实际上，我们的分析将强调，奇异值适当衰减会使插补偏差较小。

此外，后续分析需要对 X 的二阶矩作如下假设。

假设2。存在 $L < \infty$，使得对所有 $j \in [d]$，$\mathbb{E}\left[X_j^2\right] \leq L^2$。

假设3。存在 $\ell > 0$，使得对所有 $j \in [d]$，$\mathbb{E}\left[X_j^2\right] \geq \ell^2$。

例如，对于标准化数据，假设2和3以 $L^2 = \ell^2 = 1$ 成立。

3. 线性模型的插补偏差

3.1. 插补的隐式正则化

岭回归广泛用于高维设置，尤其因其计算方面的优势。它相当于构造最小二乘估计的 ℓ^2 惩罚版本：

$$\widehat{\theta}_{\lambda} \in \underset{\theta \in \mathbb{R}^d}{\arg\min} \left\{ \frac{1}{n} \sum_{i=1}^{n} \left(Y_i - f_{\theta}(X_i) \right)^2 + \lambda \| \theta \|_2^2 \right\},$$

其中 $\lambda > 0$ 是惩罚参数。相应泛化风险可写为

$$R_{\lambda}(\theta) := R(\theta) + \lambda \| \theta \|_2^2.$$

命题3.1建立插补与岭惩罚之间的联系。

命题3.1。在假设1下，设 V 为 P 的协方差矩阵，即 $V_{ij} = \mathrm{Cov}\left(P_i, P_j\right)$，并令 $H = \mathrm{diag}\left(\rho_1, \ldots, \rho_d\right)$，其中 $\rho_j = \mathbb{P}\left(P_j = 1\right)$。则对所有 θ，

$$R_{\mathrm{imp}}(\theta) = R(H\theta) + \| \theta \|_{V \odot \Sigma}^{2}.$$

特别地，在假设1′、2和3下，若 $L^2 = \ell^2$，则

$$R_{\text{imp}}(\theta) = R(\rho\theta) + L^2\rho(1-\rho) \parallel \theta \parallel_2^2. \qquad (11)$$

这一结果揭示了其中起作用的隐式 ℓ^2 正则化：对零值插补后的 Ho-MCAR 数据进行标准回归，可以看作对完整数据进行岭回归，其强度 λ 取决于缺失值比例。更具体地，由式(11)，作用于插补样本的最优预测器满足

$$\theta^\star_{\text{imp}} = \frac{1}{L^2\rho} \arg\min_{\theta\in\mathbb{R}^d}\{R(\theta) + \lambda_{\text{imp}} \parallel \theta \parallel_2^2\},$$

其中 $\lambda_{\text{imp}} := L^2(1-\rho)/\rho$。第3.2和3.3节将利用这一对应关系控制插补偏差。

3.2. 具有 Ho-MCAR 缺失输入的线性模型的插补偏差

当输入具有 Ho-MCAR 缺失模式（假设1′）时，在线性模型中诱导的零值插补偏差 $B_{\text{imp}}(\mathcal{F})$，受到岭回归偏差某一特例的控制（例如 Hsu et al., 2012；Dieuleveut et al., 2017；Mourtada, 2019）。岭回归偏差一般定义为

$$B_{\text{ridge},\lambda}(\mathcal{F}) := \inf_{\theta\in\mathbb{R}^d}\{R_\lambda(\theta) - R^\star(\mathcal{F})\} \qquad (12)$$

$$= \lambda \parallel \theta^\star \parallel^2_{\Sigma(\Sigma+\lambda I)^{-1}}. \qquad (13)$$

定理3.2。 在假设1′、2和3下，

$$B_{\text{ridge},\lambda'_{\text{imp}}}(\mathcal{F}) \le B_{\text{imp}}(\mathcal{F}) \le B_{\text{ridge},\lambda_{\text{imp}}}(\mathcal{F}),$$

其中 $\lambda'_{\text{imp}} := \ell^2(1-\rho)/\rho$， $\lambda_{\text{imp}} = L^2(1-\rho)/\rho$。

正如从命题3.1可以预期的那样，零值插补偏差的上下界均为岭偏差，惩罚常数取决于缺失值比例。在 $\ell^2 = L^2$（二阶矩相同）的特殊情况下，插补偏差恰好等于常数为 $L^2(1-\rho)/\rho$ 的岭偏差。此外，在完全没有缺失数据（$\rho = 1$）的极端情况下，$\lambda_{\text{imp}} = 0$，偏差消失。相反，若缺失比例很高（$\rho \to 0$），则 $\lambda'_{\text{imp}} \to +\infty$，插补偏差等于朴素预测器的超额风险，即 $B_{\text{imp}}(\mathcal{F}) = R(0_{\mathbb{R}^d}) - R^\star(\mathcal{F})$。在一半数据可能缺失（$\rho = 1/2$）的中间情形，$\lambda_{\text{imp}} = L^2$。

因此，就统计保证而言，在插补输入上进行线性回归承受的偏差与岭惩罚相当，但超参数 λ_{imp} 是固定的。注意，在高维设置下执行标准岭回归时，理论上最佳的惩罚参数通常按 d/n 缩放（详见 Sridharan et al., 2008；Hsu et al., 2012；Mourtada & Rosasco, 2022）。如果 $\rho \gtrsim L^2 n/(d+n)$（等价于 $\lambda_{\text{imp}} \lesssim d/n$），则插补偏差小于采用最优超参数 $\lambda = d/n$ 的岭回归偏差，而这种偏差在应用中通常被接受。在此背景下，应用岭回归之前先进行零值插补，可以轻松处理缺失数据，而不显著增加总体偏差。

事实表明，在关于低秩协方差结构的经典假设下，可以控制随机设计岭回归的偏差，因而也可以控制插补偏差（Caponnetto & De Vito, 2007；Hsu et al., 2012；Dieuleveut et al., 2017）。以下所有例子均假设 $\mathrm{Tr}(\Sigma) = d$，标准化数据特别满足此条件。

例3.3（奇异值相等的低秩协方差矩阵）。考虑秩为 $r \ll d$ 且特征值恒定（$\lambda_1 = \cdots = \lambda_r = d/r$）的协方差矩阵。则 $\Sigma\big(\Sigma + \lambda_{\text{imp}} I\big)^{-1} \preccurlyeq \lambda_r^{-1}\Sigma = (r/d)\Sigma$，定理3.2给出

$$B_{\text{imp}}(\mathcal{F}) \le \lambda_{\text{imp}} \frac{r}{d} \parallel \theta^\star \parallel_\Sigma^2.$$

因此，当 $r \ll d$（低秩情形）时，插补偏差较小。实际上，对于固定维度，若协方差低秩，则变量之间存在大量冗余，这有助于抵消输入变量中缺失的信息，从而降低预测偏差。

注意，例3.3（$r \ll d$）推广了例2.2（$r = 1$），而且与后者不同，它具有旋转不变性。

注3.4。一阶条件（参见式(29)）意味着 $\parallel \theta^\star \parallel_\Sigma^2 + \sigma^2 = \mathbb{E}Y^2 = R\big(0_{\mathbb{R}^d}\big)$，它与维度 d 无关。因此，在所有上界中，$\parallel \theta^\star \parallel_\Sigma^2$ 都可替换为与维度无关的 $\mathbb{E}Y^2$。由此，例3.3及后续例子的上界可以解释为：若 $r \ll d$，朴素预测器的风险被除以 $d/r \gg 1$。因此，当秩固定而维度增加时，B_{imp} 趋于零。

例3.5（与 $\theta^\star$ 相容的低秩协方差矩阵）。考虑秩为 $r \ll d$ 的协方差矩阵，并假设 $\langle \theta^\star, v_1 \rangle^2 \ge \cdots \ge \langle \theta^\star, v_d \rangle^2$，意味着 $\theta^\star$ 可由 Σ 的前几个特征方向良好表示。定理3.2给出

$$B_{\text{imp}}(\mathcal{F}) \lesssim \lambda_{\text{imp}} \frac{r\big(\log(r) + 1\big)}{d} \parallel \theta^\star \parallel_\Sigma^2.$$

除一个对数因子外，该结果与例3.3类似；区别在于，对 Σ 特征值的假设被协方差结构与 $\theta^\star$ 相容的条件取代。若 $\theta^\star$ 能由最大特征值对应的方向很好地解释，则插补偏差仍然较低。这说明插补偏差不仅依赖 Σ 的谱结构，还依赖 $\theta^\star$。

例3.6（尖峰模型，Johnstone, 2001）。在该模型中，协方差矩阵可分解为 $\Sigma = \Sigma_{\le r} + \Sigma_{>r}$，其中 $\Sigma_{\le r}$ 对应具有较大特征值的数据低秩部分，$\Sigma_{>r}$ 对应残余的高维数据。假设 $\Sigma_{>r} \preccurlyeq \eta I$（算子范数较小），且 $\Sigma_{\le r}$ 的所有非零特征值相等，则定理3.2给出

$$B_{\text{imp}}(\mathcal{F}) \le \frac{\lambda_{\text{imp}}}{1-\eta} \frac{r}{d} \parallel \theta^\star \parallel_\Sigma^2 + \eta \parallel \theta^\star_{>r} \parallel_2^2,$$

其中 $\theta^\star_{>r}$ 是 $\theta^\star$ 在 $\Sigma_{>r}$ 值域上的投影。与例3.3不同，Σ 仅近似低秩，可以将 r 称为 Σ 的“有效秩”（参见 Bartlett et al., 2020）。上述上界含有一个 $O(r/d)$ 项（与例3.3相同），但也有不可压缩的部分 $\eta \parallel \theta^\star_{>r} \parallel_2^2$，它源自残余的、可能带噪声的高维数据。注意，若 $\theta^\star_{>r} = 0$（仅低维数据部分含有信息），则恢复例3.3中的同样速率。

3.3. 线性模型及一般 MCAR 设置下的插补偏差

定理3.2仅适用于 Ho-MCAR 设置，不包括掩码分量彼此依赖的情形。为在假设1下覆盖相关的 $P_1, \ldots, P_d$，回顾 $\rho_j := \mathbb{P}\big(P_j = 1\big)$ 是第 j 个分量不缺失的概率，定义与 P 关联的矩阵 $C \in \mathbb{R}^{d \times d}$：

$$C_{kj} := \frac{V_{k,j}}{\rho_k \rho_j}, \qquad (k,\ j) \in [d] \times [d]. \tag{14}$$

此外，在假设2下定义

$$\Lambda_{\mathrm{imp}} := L^2 \lambda_{\max}(C). \qquad (15)$$

以下结果建立一般 MCAR 设置下插补偏差的上界。

命题3.7。 在假设1和2下，

$$B_{\mathrm{imp}}(\mathcal{F}) \le B_{\mathrm{ridge},\Lambda_{\mathrm{imp}}}(\mathcal{F}).$$

该偏差界与定理3.2类似，但使用 $\lambda = \Lambda_{\mathrm{imp}}$，因此考虑了缺失模式各分量之间的相关性。注意，在假设1′下不存在相关性，$\Lambda_{\mathrm{imp}} = L^2(1-\rho)/\rho$，从而与定理3.2一致。下面的例子展示可以显式控制 Λ_{imp} 的一般情形。

例3.8（有限数量的相关性）。 若每个缺失模式分量最多与其他 $k-1$ 个分量相关，则 $\Lambda_{\mathrm{imp}} \le L^2 k \max_{j\in[d]}\{(1-\rho_j)/\rho_j\}$。

例3.9（无放回抽样）。 通过从 $[d]$ 中无放回抽取 k 个分量生成缺失模式，则 $\Lambda_{\mathrm{imp}} = L^2(k+1)/(d-k)$。特别地，若一半数据缺失（$k = d/2$），则 $\Lambda_{\mathrm{imp}} \le 3L^2$。

总之，我们证明，在任意 MCAR 设置下，插补偏差都受惩罚常数为 Λ_{imp} 的岭偏差控制。更具体地，上一节所有依赖协方差矩阵 Σ 与最佳预测器 $\theta^\star$ 特定结构的例子（例3.3、3.5和3.6）仍然成立，只需将 λ_{imp} 替换为 Λ_{imp}。此外，通过指定缺失数据的生成方式（如例3.8和3.9），可以控制插补偏差，并证明上述所有例子中的偏差在高维下都较小。

4. 零值插补数据上的 SGD

由于插补偏差只是问题的一部分，我们还需要为 $\theta^\star_{\mathrm{imp}}$ 提出合适的估计策略。为此，我们选择使用下述平均随机梯度算法（Polyak & Juditsky, 1992），在插补样本上训练线性预测器。随后，我们建立这一估计策略的超额风险泛化界。

4.1. 算法

给定初始值 $\theta_0 \in \mathbb{R}^d$ 和恒定学习率 $\gamma > 0$，平均 SGD 算法第 t 次迭代为

$$\theta_{\mathrm{imp},t} = \left[I - \gamma X_{\mathrm{imp},t} X_{\mathrm{imp},t}^\top\right]\theta_{\mathrm{imp},t-1} + \gamma Y_t X_{\mathrm{imp},t}. \qquad (16)$$

在单遍扫描数据后（提前停止），最终估计器 $\bar{\theta}_{\mathrm{imp},n}$ 由 Polyak-Ruppert 平均给出，即 $\bar{\theta}_{\mathrm{imp},n} = \frac{1}{n+1}\sum_{t=1}^{n}\theta_{\mathrm{imp},t}$。这种递推过程适合高维设置，也适用于模型误设（这里由缺失项引起），如 Bach & Moulines (2013) 所研究的那样。此外，它们在大规模数据集上很有竞争力，因为单遍扫描数据只需 $O(dn)$ 次运算。

4.2. 泛化界

我们的目标是推导上述算法在零值插补数据上训练后的预测性能泛化界。为此，需要对完整数据增加以下假设。

假设4。 存在 $\sigma > 0$ 和 $\kappa > 0$，满足 $\mathbb{E}\left[XX^{\top} \parallel X \parallel_2^2\right] \preccurlyeq \kappa \mathrm{Tr}(\Sigma)\Sigma$ 以及 $\mathbb{E}\left[\epsilon^2 \parallel X \parallel_2^2\right] \leq \sigma^2 \kappa \mathrm{Tr}(\Sigma)$，其中 $\epsilon = Y - X^{\top}\theta^{\star}$。

假设4是随机优化中经典的四阶矩假设（详见 Bach & Moulines, 2013；Dieuleveut et al., 2017）。例如，若 X 是高斯向量，则假设4的第一个条件以 $\kappa = 3$ 成立；或者当 X 几乎必然满足 $\parallel X \parallel_2 \leq \kappa \mathrm{Tr}(\Sigma)$ 时也成立。第二个条件例如在模型正确设定，或者噪声 ε 几乎必然有界时成立。注意，若第一部分成立，则第二部分也成立，且可取 $\sigma^2 \leq 2\mathbb{E}\left[Y^2\right] + 2\mathbb{E}\left[Y^4\right]^{1/2}$。

下面给出主要结果：零值插补数据上的 SGD 风险上界。

定理4.1。 在假设4下，选择恒定学习率 $\gamma = 1/\left(\kappa \mathrm{Tr}(\Sigma)\sqrt{n}\right)$，得到

$$\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right] - R^{\star}(\mathcal{F}) \lesssim \frac{\kappa \mathrm{Tr}(\Sigma)}{\sqrt{n}} \parallel \theta_{\mathrm{imp}}^{\star} - \theta_0 \parallel_2^2 + \frac{\sigma^2 + \parallel \theta^{\star} \parallel_{\Sigma}^2}{\sqrt{n}} + B_{\mathrm{imp}}(\mathcal{F}),$$

其中 $\theta^{\star}$ 和 $\theta_{\mathrm{imp}}^{\star}$ 分别是完整情形和缺失值插补情形的最佳线性预测器。

定理4.1给出了 $\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right]$ 与 $R^{\star}(\mathcal{F})$ 之差的上界，前者是训练与测试样本中的缺失值均经插补后，所估计线性预测器的平均风险，后者是完整情形下最佳线性预测器的风险。有趣的是，由引理 2.1，在正确设定的线性模型下，同样的界也适用于 $\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right] - R_{\mathrm{mis}}^{\star}$。定理4.1的泛化界同时考虑了方法的统计误差与优化误差。更准确地，上界可分解为：(i) 与初始条件相关的偏差；(ii) 所考虑方法的方差项；(iii) 前述插补偏差。

方差项(ii)依赖 Y 的二阶矩，因为 $\parallel \theta^{\star} \parallel_{\Sigma}^2 \leq \mathbb{E}Y^2$，并按慢速率 $1/\sqrt{n}$ 下降。如第3节所示，插补偏差以惩罚参数为 λ_{imp} 的岭偏差为上界；对于低秩数据，该偏差在高维下可控（参见第3.2节各例）。

初始条件引起的偏差(i)最为关键。事实上，$\mathrm{Tr}(\Sigma) = \mathbb{E}\left[\parallel X \parallel_2^2\right]$ 很可能随 d 增加，例如在假设2下，$\mathrm{Tr}(\Sigma) \leq dL^2$。此外，起点 θ_0 可能离 $\theta_{\mathrm{imp}}^{\star}$ 很远。幸运的是，引理4.2给出了 $\theta_{\mathrm{imp}}^{\star}$ 的一些性质。

引理4.2。 在假设1和3下，设 V 为命题3.1定义的 P 的协方差矩阵。如果 V 可逆，则

$$\parallel \theta_{\mathrm{imp}}^{\star} \parallel_2^2 \leq \frac{B_{\mathrm{imp}}(\mathcal{F})}{\ell^2 \lambda_{\min}(V)}. \qquad (17)$$

特别地，在假设1′下，

$$\parallel \theta_{\mathrm{imp}}^{\star} \parallel_2^2 \leq \frac{B_{\mathrm{imp}}(\mathcal{F})}{\ell^2 \rho(1-\rho)}. \qquad (18)$$

引理4.2用插补偏差控制最优预测器 $\theta^{\star}_{\mathrm{imp}}$ 的范数：若插补偏差小，则零值插补数据上的最优预测器具有较小范数。根据第3节，这特别适用于高维设置。因此，选择 $\theta_0 = 0$，便可在定理4.1中利用引理4.2的上界。这样的初始化使初始条件偏差不超过 $\kappa \mathrm{Tr}(\Sigma) \parallel \theta^{\star}_{\mathrm{imp}} \parallel_2^2/\sqrt{n}$。直观地，由于 $\theta^{\star}_{\mathrm{imp}}$ 位于一个小半径的 ℓ^2 球内，把 θ_0 选在该球中，例如取 $\theta_0 = 0$，是一个好的选择。

结合引理4.2，命题4.3建立了零值插补数据上 SGD 的最终上界。

命题4.3。 在假设1′、2、3和4下，第4.1节 SGD 策略以起点 $\theta_0 = 0$、学习率 $\gamma = 1/\left(d\kappa L^2\sqrt{n}\right)$ 得到的预测器 $\bar{\theta}_{\mathrm{imp},n}$ 满足

$$\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right] - R^{\star}(\mathcal{F}) \lesssim \left[\frac{L^2}{\ell^2}\frac{\kappa d}{\rho(1-\rho)\sqrt{n}} + 1\right] B_{\mathrm{imp}}(\mathcal{F}) + \frac{\sigma^2 + \parallel \theta^{\star} \parallel_{\Sigma}^2}{\sqrt{n}}.$$

这一上界的第一项包含插补偏差与初始条件偏差，第二项对应训练过程的方差。一旦 $d \gg \left(\ell^2/L^2\right)\rho(1-\rho)\sqrt{n}/\kappa$，相对于初始条件偏差，插补偏差便可忽略。

4.3. 例子

根据例3.3和3.6，只要 Σ 或 β 具有结构， $B_{\mathrm{imp}}(\mathcal{F})$ 就随维度下降。值得注意的是，推论4.4给出了命题4.3的上界实际上与维度无关的一些情形。

推论4.4。 假设命题4.3的各项假设成立。回顾 $\lambda_1 \geq \cdots \geq \lambda_d$ 是 Σ 的特征值，对应特征向量为 $v_1, \ldots, v_d$。

（i）例3.3：低秩 Σ。 若 Σ 的秩为 $r \ll d$，且非零奇异值相等，则

$$\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right] - R^{\star}(\mathcal{F}) \lesssim \frac{L^2}{\ell^2}\left[\frac{L^2\kappa}{\ell^2\rho\sqrt{n}} + \frac{1-\rho}{d}\right]\frac{r \parallel \theta^{\star} \parallel_{\Sigma}^2}{\rho} + \frac{\sigma^2}{\sqrt{n}}.$$

（ii）例3.6：尖峰模型。 若 $\Sigma = \Sigma_{\leq r} + \Sigma_{>r}$， $\Sigma_{>r} \preccurlyeq \ell^2\eta I$， $\Sigma_{\leq r}$ 具有低秩 $r \ll d$ 且非零奇异值相等，并且 $\theta^{\star}$ 在 $\Sigma_{>r}$ 值域上的投影满足 $\theta^{\star}_{>r} = 0$，则

$$\mathbb{E}\left[R_{\mathrm{imp}}\left(\bar{\theta}_{\mathrm{imp},n}\right)\right] - R^{\star}(\mathcal{F}) \lesssim \frac{L^2}{\ell^2}\left[\frac{L^2\kappa}{\ell^2\rho\sqrt{n}} + \frac{1-\rho}{d}\right]\frac{r \parallel \theta^{\star} \parallel_{\Sigma}^2}{\rho(1-\eta)} + \frac{\sigma^2}{\sqrt{n}}.$$

推论4.4在 Σ 和 $\theta^{\star}$ 具有某些特定结构时，建立了零值插补数据上 SGD 的风险上界。这些界同时考虑统计误差和优化误差，并表示为 d, n 的函数。由于 $\parallel \theta^{\star} \parallel_{\Sigma}^2$ 不超过与维度无关的 $\mathbb{E}Y^2$，只要 $d > \left(\ell^2/L^2\right)\rho(1-\rho)\sqrt{n}/\kappa$，推论4.4中的风险也能用与维度无关的量控制。

此外，推论4.4表明，当 $d \gg \left(\ell^2/L^2\right)\rho(1-\rho)\sqrt{n}/\kappa$ 时，相对于 SGD 的随机误差，插补偏差可忽略。因此，对于满足 $d \gg \left(\ell^2/L^2\right)\rho(1-\rho)\sqrt{n}/\kappa$ 的高维结构化问题，零值插补策略是一致的，其慢速率为 $1/\sqrt{n}$ 阶。

注4.5（关于慢速率的讨论）。 朴素插补与 SGD 相结合的一项重要局限是无法达到快速收敛率。事实上，在高维下，经典的快速率为 $\mathrm{Tr}\left(\Sigma(\Sigma+\lambda I)^{-1}\right)/n$，其中 λ 是惩罚超参数。量 $\mathrm{Tr}\left(\Sigma(\Sigma+\lambda I)^{-1}\right)$ 通常称为自由度，相对于 d 可以忽略，例如当 Σ 的特征值快速衰减时。然而，使用插补数据集时，数据协方差矩阵不再是 Σ，而是 $\Sigma_{\mathrm{imp}}=\mathbb{E}X_{\mathrm{imp}}X_{\mathrm{imp}}^{\top}$。因此，在假设1′（Ho-MCAR）下，$\Sigma_{\mathrm{imp}}$ 的所有特征值均大于 $\rho(1-\rho)$，这阻止了完整输入下可以出现的特征值衰减。利用自由度在半正定矩阵上的凹性，可以证明 $\mathrm{Tr}\left(\Sigma_{\mathrm{imp}}\left(\Sigma_{\mathrm{imp}}+\lambda I\right)^{-1}\right)\geq d\rho(1-\rho)/(1+\lambda)$，从而阻碍传统的快速率。

与 dropout 的联系。 Dropout 是深度学习中的经典正则化技术，在 SGD 每次迭代时随机丢弃一些神经元（Srivastava et al., 2014）。其正则化性质受到广泛关注（例如 Gal & Ghahramani, 2016）。有趣的是，将输入层的一个神经元置零等价于遮蔽对应特征。因此，对零值插补数据流运行第4节的 SGD，等价于训练一个没有隐藏层、只有一个输出神经元、并对输入层应用 dropout 的神经网络。我们的理论分析描述了这一特殊情况下 dropout 的隐式正则化影响。有趣的是，这也可以用于任何回归网络结构最后一层的微调。

其他插补方法。 本文证明了零值插补通过充当隐式正则化方法，减少高维设置中缺失数据的影响。只要满足以下条件，我们的结果也适用于更一般的插补过程：(i) 对所有缺失模式 p，插补函数的均值 $x\mapsto\mathbb{E}\left[X_{\mathrm{imp}}\mid X=x,\,P=p\right]$ 是线性的；(ii) 存在常数 l，使 $\mathbb{E}\left[\left(X-\mathbb{E}\left[X_{\mathrm{imp}}\mid X\right]\right)^2\right]\geq l^2$。条件(i)是插补后保持预测器线性的必要条件，而线性是本分析的核心。条件(ii)更令人意外，因为它要求插补平均而言不准确。这一性质恰恰是插补方法提供隐式正则化的基石。特别地，我们的分析可扩展到均值插补或标准高斯插补等经典策略。

5. 数值实验

数据模拟。 我们按照具有两种不同协方差结构的正态分布，生成 $n=500$ 个完整输入数据。首先，在低秩设置（例3.3和3.5）下，输出为 $Y=\beta^{\top}Z+\epsilon$，其中 $\beta\in\mathbb{R}^r$、$Z\sim\mathcal{N}(0,\,I_r)$、$\epsilon\sim\mathcal{N}(0,\,2)$；输入为 $X=AZ+\mu$，其中 $A\in\mathbb{R}^{d\times r}$ 是满秩矩阵，$\mu\in\mathbb{R}^d$ 为均值向量。注意，实验中改变维度 d，但固定 $r=5$。此外，完整模型可重写为 $Y=X^{\top}\theta^{\star}+\epsilon$，其中 $\theta^{\star}=\left(A^{\dagger}\right)^{\top}\beta$，$A^{\dagger}$ 是 A 的 Moore-Penrose 逆。其次，在尖峰模型（例3.6）中，将输入与输出分解为 $X=\left(X_1,\,X_2\right)\in\mathbb{R}^{d/2}\times\mathbb{R}^{d/2}$ 和 $Y=Y_1+Y_2$，其中 $\left(X_1,\,Y_1\right)$ 按上述低秩模型生成，而 $\left(X_2,\,Y_2\right)$ 由线性模型 $Y_2=\theta_2^{\top}X_2$、$X_2\sim\mathcal{N}\left(0,\,I_{d/2}\right)$ 给出，取 $\|\,\theta_2\,\|=0.2$。

模拟两种缺失数据情形，观测条目的比例 ρ 均为50%：(i) Ho-MCAR 设置（假设1′）；(ii) 自遮蔽 MNAR 设置，它与 MCAR 情形显著不同，因为是否缺失取决于底层值本身。更具体地，取 $\alpha\in\mathbb{R}^d$，使所有 $j\in[d]$ 都满足 $\mathbb{P}\left(P_j=1\mid X\right)=\left(1+e^{-\alpha_j X_j}\right)^{-1}$ 以及 $\mathbb{E}\left[P_j\right]=0.5$，即每个分量平均缺失50%的数据。

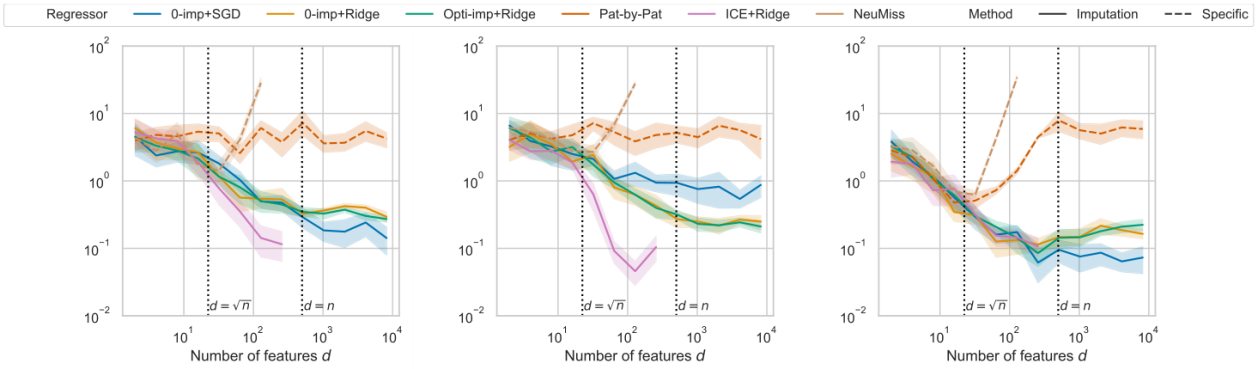
回归器。 对于两步策略，将不同插补器与不同回归器组合。考虑的插补器包括：与本文理论分析一致的零值插补（0-imp）；为每个输入变量选择最优常数的插补（Opti-imp），通过在增广数据 $\left(P\odot X,\,1_{d\times 1}-P\right)$ 上训练线性模型得到（参见 Le Morvan et al., 2020b，命题3.1）；以及基于链式方程的单次插补（ICE）（Van Buuren & Groothuis-Oudshoorn, 2011）[1]。后续回归器在 scikit-

learn（Pedregosa et al., 2011）中实现，采用平均 SGD（SGD，`SGDRegressor`），取 $\theta_0 = 0$、$\gamma = \left(d\sqrt{n}\right)^{-1}$（参见命题4.3），或采用岭回归器（`ridge`，通过留一交叉验证选择参数）。我们还评估了两种不进行预先插补的专门方法：逐模式回归器（Pat-by-Pat）（Le Morvan et al., 2020b; Ayme et al., 2022），以及专门为线性预测中的缺失数据设计的神经网络架构 NeuMiss（Le Morvan et al., 2020a）。

[1] scikit-learn（Pedregosa et al., 2011）中的 `IterativeImputer`。

数值结果。 图1(a)和(b)考虑 Ho-MCAR 模式与高斯输入，其协方差矩阵分别为低秩和尖峰结构。两步策略表现非常好，其中 ICE 插补器名列前茅，因为它非常适合这里的 MCAR 高斯数据。不过，朴素零值插补的预测性能仍然很有竞争力，而且计算高效，复杂度为 $O(nd)$；尤其相较于复杂度为 n^2d^3 阶的 ICE 更具优势。对于图1(b)，在较大 d 下，岭回归优于 SGD。注意，在 $d \geq \sqrt{n}$ 的情形，插补偏差相对于方法偏差可忽略，而岭回归的方法偏差较低。这说明，与插补诱导的隐式正则化相比，使用经过调节的超参数进行显式岭正则化有其益处。

在实践中，缺失数据并不总是 Ho-MCAR 类型，因此我们在自遮蔽数据上比较不同算法。图1(c)显示，相比 MCAR 设置，专门方法在更大的 d 下仍然有竞争力。这符合预期，因为这些方法本来就是为复杂的非随机缺失（MNAR）数据设计的。然而，它们仍受到维数灾难影响，在高维下相对于所有两步策略都效率低下。



(a) Ho-MCAR + Low-rank model (b) Ho-MCAR + Spiked model (c) Self-Masked + Low-rank model

图1。 当输入数据缺失50%时，风险随输入维度的变化（在 10^4 个测试样本上评估）。纵轴为 $R_{\text{mis}}(f) - R^\star = \mathbb{E}\left[\left(Y - f\left(X_{\text{imp}}, P\right)\right)^2\right] - \sigma^2$。图中显示10次重复的平均风险及95%置信区间。(a) Ho-MCAR + 低秩模型；(b) Ho-MCAR + 尖峰模型；(c) 自遮蔽 + 低秩模型。横轴：特征数 d；图例 Regressor 为回归器，Method 为方法类型，Imputation 为插补方法，Specific 为专门方法。各算法缩写与正文一致。

6. 讨论与结论

本文研究零值插补在高维线性模型中的影响。我们通过揭示其在处理 MCAR 数据时的隐式正则化机制，澄清了这种广泛使用的技术。我们证明，在高维情形中，它诱导的偏差类似于实践者通常接受的岭回归偏差。通过给出零值插补数据上 SGD 的泛化界，我们证明，这种两步过程既具有统计上的合理性，也具有计算上的吸引力。

在 MCAR 之外仍有待建立理论结果，以便正确分析和比较 MNAR 设置中的不同缺失数据处理策略（参见图1(c)）。将结果扩展到更广泛的函数类（不局限于线性函数），甚至扩展到分类框架，将有助于全面理解插补的性质。

致谢

本工作是 Alexis Ayme 博士论文的一部分，由巴黎市通过 Emergence(s) 项目 IntArtica 资助。

参考文献

以下保留作者、刊名、卷期、页码、年份与标识符，并翻译论文题名。

- Agarwal, A., Shah, D., Shen, D., and Song, D. 主成分回归的稳健性。Advances in Neural Information Processing Systems, 32, 2019。
- Ayme, A., Boyer, C., Dieuleveut, A., and Scornet, E. 含缺失值线性模型的近最优一致性速率。International Conference on Machine Learning, pp. 1211–1243. PMLR, 2022。
- Bach, F. and Moulines, E. 收敛率为 o (1/n) 的非强凸光滑随机逼近。Advances in Neural Information Processing Systems, 26, 2013。
- Bartlett, P. L., Long, P. M., Lugosi, G., and Tsigler, A. 线性回归中的良性过拟合。Proceedings of the National Academy of Sciences, 117(48):30063–30070, 2020。
- Caponnetto, A. and De Vito, E. 正则化最小二乘算法的最优速率。Foundations of Computational Mathematics, 7(3):331–368, 2007。
- Chizat, L. and Bach, F. 使用逻辑损失训练的宽两层神经网络中梯度下降的隐式偏差。Conference on Learning Theory, pp. 1305–1338. PMLR, 2020。
- Dieuleveut, A., Flammarion, N., and Bach, F. 最小二乘回归更困难、更好、更快、更强的收敛率。The Journal of Machine Learning Research, 18(1):3520–3570, 2017。
- Gal, Y. and Ghahramani, Z. 循环神经网络中 dropout 的有理论依据的应用。Advances in Neural Information Processing Systems, 29, 2016。
- Hsu, D., Kakade, S. M., and Zhang, T. 岭回归的随机设计分析。Conference on Learning Theory, pp. 9–1. JMLR Workshop and Conference Proceedings, 2012。
- Ipsen, N. B., Mattei, P.-A., and Frellsen, J. 如何处理监督深度学习中的缺失数据？ICLR 2022-10th International Conference on Learning Representations, 2022。
- Johnstone, I. M. 主成分分析中最大特征值的分布。The Annals of Statistics, 29(2):295–327, 2001. doi: 10.1214/aos/1009210544. URL: https://doi.org/10.1214/aos/1009210544。
- Josse, J., Prost, N., Scornet, E., and Varoquaux, G. 含缺失值监督学习的一致性。arXiv 预印本 arXiv:1902.06931, 2019。
- Le Morvan, M., Josse, J., Moreau, T., Scornet, E., and Varoquaux, G. NeuMiss 网络：含缺失值监督学习的可微编程。NeurIPS 2020 - 34th Conference on Neural Information Processing Systems, Vancouver / Virtual, Canada, December 2020a. URL: https://hal.archives-ouvertes.fr/hal-02888867。
- Le Morvan, M., Prost, N., Josse, J., Scornet, E., and Varoquaux, G. 含缺失值的线性生成数据上的线性预测器：非一致性与解决办法。International Conference on Artificial Intelligence and Statistics, pp. 3165–3174. PMLR, 2020b。

- Le Morvan, M., Josse, J., Scornet, E., and Varoquaux, G. 什么是适合含缺失值预测的良好插补？Advances in Neural Information Processing Systems, 34:11530–11540, 2021。
- Mourtada, J. 线性最小二乘的精确极小极大风险及样本协方差矩阵的下尾。arXiv 预印本 arXiv:1912.10754, 2019。
- Mourtada, J. and Rosasco, L. 随机设计岭回归的初等分析。arXiv 预印本 arXiv:2203.08564, 2022。
- Muzellec, B., Josse, J., Boyer, C., and Cuturi, M. 利用最优传输进行缺失数据插补。International Conference on Machine Learning, pp. 7130–7140. PMLR, 2020。
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. Scikit-learn：Python 中的机器学习。Journal of Machine Learning Research, 12:2825–2830, 2011。
- Pesme, S., Pillaud-Vivien, L., and Flammarion, N. 对角线性网络中 SGD 的隐式偏差：随机性的可证明益处。Advances in Neural Information Processing Systems, 34:29218–29230, 2021。
- Polyak, B. T. and Juditsky, A. B. 通过平均加速随机逼近。SIAM Journal on Control and Optimization, 30(4):838–855, 1992。
- Rubin, D. B. 推断与缺失数据。Biometrika, 63(3):581–592, 12 1976. ISSN 0006-3444. doi: 10.1093/biomet/63.3.581. URL: https://doi.org/10.1093/biomet/63.3.581。
- Sridharan, K., Shalev-Shwartz, S., and Srebro, N. 正则化目标的快速率。Advances in Neural Information Processing Systems, 21, 2008。
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. Dropout：防止神经网络过拟合的一种简单方法。The Journal of Machine Learning Research, 15(1):1929–1958, 2014。
- Van Buuren, S. and Groothuis-Oudshoorn, K. mice：R 中基于链式方程的多变量插补。Journal of Statistical Software, 45:1–67, 2011。
- Yao, Y., Rosasco, L., and Caponnetto, A. 梯度下降学习中的提前停止。Constructive Approximation, 26(2):289–315, 2007。
- Yoon, J., Jordon, J., and Schaar, M. GAIN：使用生成对抗网络进行缺失数据插补。International Conference on Machine Learning, pp. 5689–5698. PMLR, 2018。

附录

A. 记号

记号。 对两个向量或矩阵 a, b，记 $a \odot b$ 为 Hadamard 积（逐分量乘积）。$[n] = \{1, 2, \ldots, n\}$。对于两个对称矩阵 A, B， $A \preccurlyeq B$ 表示 $B - A$ 半正定。符号 $\lesssim$ 表示忽略一个通用常数因子后的不等式。表1汇总全文使用的记号。

表1：记号。

记号	含义
P	掩码
$\mathcal{F}$	线性函数集合
B_{imp}	插补偏差
Σ	$\mathbb{E}XX^{\top}$
λ_j	Σ 的特征值
v_j	Σ 的特征方向
Σ_P	$\mathbb{E}PP^{\top}$
L^2	最大二阶矩 $\max_j \mathbb{E}X_j^2$ （假设2）
ℓ^2	最小二阶矩 $\min_j \mathbb{E}X_j^2$ （假设3）
$\theta^\star$	完整数据上的最佳线性预测器
$\theta^\star_{\text{imp}}$	插补数据上的最佳线性预测器
r	Σ 的秩
ρ_j	MCAR 设置中第 j 个变量的观测条目的理论比例
V	与缺失模式关联的协方差矩阵
C	式(14)中使用 $\left(\rho_j\right)_j$ 重新归一化的协方差矩阵 V
κ	输入 X 的峰度

B. 主要结果的证明

B.1. 引理2.1的证明

证明基于条件期望的定义，并利用

$$R^\star = \mathbb{E}\left[(Y - \mathbb{E}[Y \mid X])^2\right].$$

注意，由 ϵ 与 P 独立，$\mathbb{E}[Y \mid X, P] = \mathbb{E}\left[f^\star(X) + \epsilon \mid X, P\right] = \mathbb{E}\left[f^\star(X) \mid X, P\right] = f^\star(X)$。因此，

$$
\begin{aligned}
R^\star &= \mathbb{E}\left[(Y - f^\star(X))^2\right] \\
&\le \mathbb{E}\left[(Y - \mathbb{E}[Y|X,P])^2\right] \\
&\le \mathbb{E}\left[(Y - \mathbb{E}[Y|X_{\text{imp}},P])^2\right] \\
&\le R^\star_{\text{mis}},
\end{aligned}
$$

这里利用了 $\mathbb{E}\left[Y \mid X_{\text{imp}}, P\right]$ 是 (X, P) 的可测函数。

B.2. 预备引理

记号。设 X_a 是 $\mathbb{R}^d$ 上服从分布 $\mathcal{L}_a$ 的随机变量，该分布是底层输入 X 的分布的修改版本。对 $f \in \mathcal{F}$，定义相应风险

$$R_a(f) = \mathbb{E}\left[\left(Y - f(X_a)\right)^2\right].$$

贝叶斯风险为

$$R_a^\star(\mathcal{F}) = \inf_{f\in\mathcal{F}} \mathbb{E}\left[\left(Y - f(X_a)\right)^2\right].$$

如果下确界可以达到，则记 $f_a^\star \in \arg\min_{f\in\mathcal{F}} R_a(f)$。两种风险分别涉及修改后的输入 X_a 和原始输入 X，其差异可由以下偏差度量：

$$B_a = R_a^\star(\mathcal{F}) - R^\star(\mathcal{F}).$$

一般分解。下一个引理的思路是把 $R_a(f)$ 与真实风险 $R(f)$ 比较。

引理B.1。如果 $(X_a \perp\!\!\!\perp Y) \mid X$，则对所有 $\theta \in \mathbb{R}^d$，

$$R_a(f_\theta) = R(g_\theta) + \| \theta \|_\Gamma^2,$$

其中 $g_\theta(X) = \theta^\top \mathbb{E}\left[X_a \mid X\right]$，$\Gamma = \mathbb{E}\left[(X_a - \mathbb{E}\left[X_a \mid X\right])(X_a - \mathbb{E}\left[X_a \mid X\right])^\top\right]$ 是积分条件协方差矩阵。因此，若存在可逆线性映射 H，使 $\mathbb{E}\left[X_a \mid X\right] = H^{-1}X$，则：

- 对所有 $\theta \in \mathbb{R}^d$，g_θ 是线性函数，且

$$R_a^\star(\mathcal{F}) = \inf_{\theta\in\mathbb{R}^d} \left\{ R\left(f_\theta\right) + \|\theta\|^2_{H^\top \Gamma H} \right\}. \tag{19}$$

- 若 $\lambda_{\max}\left(H\Gamma H^\top\right) \le \Lambda$，则

$$B_a(\mathcal{F}) \le \inf_{\theta\in\mathbb{R}^d} \left\{ R(f_\theta) + \Lambda \|\theta\|_2^2 \right\} = B_{\text{ridge},\Lambda}. \tag{20}$$

- 若 $\lambda_{\min}(\Gamma) \ge \mu > 0$，则

$$\|\theta_a^\star\|_2^2 \leq \frac{B_a(\mathcal{F})}{\mu}. \tag{21}$$

注B.2。 式(21)至关重要，因为偏差 $B_a(\mathcal{F})$ 的界实际上也给出了 $\|\theta_a^\star\|_2^2$ 的界。这对定理4.1尤其有用。

证明。

$$\begin{aligned}
R_a(f_\theta) &= \mathbb{E}\left[\left(Y-\theta^\top X_a\right)^2\right] \\
&= \mathbb{E}\left[\mathbb{E}\left[\left(Y-\mathbb{E}\left[\theta^\top X_a|X\right]+\mathbb{E}\left[\theta^\top X_a|X\right]-\theta^\top X_a\right)^2\middle|X\right]\right] \\
&= \mathbb{E}\left[\left(Y-\mathbb{E}\left[\theta^\top X_a|X\right]\right)^2\right]+\mathbb{E}\left[\mathbb{E}\left[\left(\mathbb{E}\left[\theta^\top X_a|X\right]-\theta^\top X_a\right)^2\middle|X\right]\right] \\
&= \mathbb{E}\left[\left(Y-g_\theta(X)\right)^2\right]+\mathbb{E}\left[\mathbb{E}\left[\left(\mathbb{E}\left[\theta^\top X_a|X\right]-\theta^\top X_a\right)^2\middle|X\right]\right] \\
&= R(g_\theta)+\mathbb{E}\left[\mathbb{E}\left[\left(\mathbb{E}\left[\theta^\top X_a|X\right]-\theta^\top X_a\right)^2\middle|X\right]\right].
\end{aligned}$$

因为 $\mathbb{E}\left[\mathbb{E}\left[\theta^\top X_a \mid X\right]-\theta^\top X_a \mid X\right]=0$。此外，

$$\begin{aligned}
\mathbb{E}\left[\mathbb{E}\left[\left(\mathbb{E}\left[\theta^\top X_a|Z\right]-\theta^\top X_a\right)^2|X\right]\right] &= \theta^\top \mathbb{E}\left[\left(\mathbb{E}\left[X_a|X\right]-X_a\right)\left(\mathbb{E}\left[X_a|X\right]-X_a\right)^\top\right]\theta \\
&= \mathbb{E}\left[\theta^\top \mathbb{E}\left[\left(\mathbb{E}\left[X_a|X\right]-X_a\right)\left(\mathbb{E}\left[X_a|X\right]-X_a\right)^\top|X\right]\theta\right] \\
&= \mathbb{E}\left[\|\theta\|^2_{\mathbb{E}\left[\left(\mathbb{E}[X_a|X]-X_a\right)\left(\mathbb{E}[X_a|X]-X_a\right)^\top|X\right]}\right] \\
&= \mathbb{E}\left[\|\theta\|_\Gamma^2\right].
\end{aligned}$$

最后，

$R_a(f_\theta) = R(g_\theta) + \|\theta\|_\Gamma^2$.

假设存在可逆矩阵 H 使得 $g_\theta(X)=\theta^\top H^{-1}X$，则 g_θ 是线性函数。通过变量替换 $\theta' = \left(H^{-1}\right)^\top\theta = \left(H^\top\right)^{-1}\theta$，即 $\theta = H^\top\theta'$，可得式(19)。因此，$g_{\theta'}(X)=\theta^\top X = f_\theta(X)$，并且

$$\begin{aligned}
R_a(f_{\theta'}) &= R(f_\theta)+\|H^\top\theta'\|_\Gamma^2 \\
&= R(f_\theta)+\|\theta'\|^2_{H\Gamma H^\top}.
\end{aligned}$$

随后利用 $H\Gamma H^\top \preccurlyeq \Lambda I$ 可证明式(20)。注意，不用上述变量替换，偏差可写为

$$B_a(\mathcal{F}) = R\left(g_{\theta_a^\star}\right) - R\left(f_{\theta^\star}\right) + \|\theta_a^\star\|_\Gamma^2. \tag{22}$$

由 $g_{\theta_a^\star}$ 的线性，$R\left(g_{\theta_a^\star}\right) \geq R\left(f_{\theta^\star}\right) = R^\star(\mathcal{F})$，因为 $g_{\theta_a^\star} \in \mathcal{F}$。

因此，$\| \theta_a^\star \|_\Gamma^2 \le B_a(\mathcal{F})$。假设 $\mu I \preccurlyeq \Gamma$，便得到式(21)，因为

$$\mu \left\|\theta_a^\star\right\|^2 \le \left\|\theta_a^\star\right\|_\Gamma^2 \le B_a(\mathcal{F}).$$

B.3. 第3节的证明

考虑零值插补数据，即 $X_{\text{imp}} = P \odot X$。在 MCAR 设置（假设1）下，

$$\mathbb{E}\left[X_{\text{imp}} \mid X\right] = H^{-1}X,$$

其中 $H = \operatorname{diag}\left(\rho_1^{-1}, \ldots, \rho_d^{-1}\right)$（始终缺失的变量被剔除），$\left(\rho_j\right)_{j\in[d]}$ 是各输入变量的观测率。

命题3.1的证明。对 $i, j \in [d]$，

$$\begin{aligned}\Gamma_{ij} = \mathbb{E}\left[\left((X_{\text{imp}})_i - \mathbb{E}\left[(X_{\text{imp}})_i \,|X\right]\right)\left((X_{\text{imp}})_j - \mathbb{E}\left[(X_{\text{imp}})_j \,|X\right]\right)\right] &= \mathbb{E}\left[X_i X_j (P_i - \mathbb{E}P_i)(P_j - \mathbb{E}P_j)\right] \\ &= \mathbb{E}\left[X_i X_j\right] \operatorname{Cov}(P_i, P_j), \\ &= \Sigma_{ij} V_{ij} \end{aligned} \tag{23}$$

因为 P 与 X 独立，V 的定义见命题3.1。因此，以 $\Gamma = \Sigma \odot V$ 应用引理B.1，即证明命题3.1的第一部分。至于第二部分，在 Ho-MCAR 假设下，$V = \rho(1-\rho)I$，因此 $\Gamma = \rho(1-\rho)\operatorname{diag}(\Sigma)$。此外，若 $L^2 = \ell^2$，则 $\operatorname{diag}(\Sigma) = L^2 I$，从而 $\Gamma = L^2\rho(1-\rho)I$。

定理3.2和命题3.7的证明。在假设1下，由于 H 是对角矩阵，

$$H^\top \Gamma H = \Sigma \odot C,$$

其中 C 由式(14)定义。

- 在假设1′下，$C = (1-\rho)I/\rho$。此外，在假设2（相应地，假设3）下，$\Sigma \odot C \preccurlyeq \left((1-\rho)/\rho\right)L^2 I = \lambda_{\text{imp}}$（相应地，$\Sigma \odot C \succcurlyeq \left((1-\rho)/\rho\right)\ell^2 I = \lambda'_{\text{imp}}$）。利用式(19)，得到

$$\inf_{\theta\in\mathbb{R}^d}\left\{R(\theta) + \lambda'_{\text{imp}}\|\theta\|_2^2\right\} \le R^\star_{\text{imp}} \le \inf_{\theta\in\mathbb{R}^d}\left\{R(\theta) + \lambda_{\text{imp}}\|\theta\|_2^2\right\}.$$

减去 $R^\star(\mathcal{F})$，有

$$B_{\text{ridge},\lambda'_{\text{imp}}} \le B_{\text{imp}} \le B_{\text{ridge},\lambda_{\text{imp}}},$$

至此完成定理3.2的证明。

- 在假设1下，有 $H\Gamma H^\top = \Sigma \odot C$。利用引理E.2，对所有 θ 得到

$$\|\theta\|_{H\Gamma H^\top}^2 = \|\theta\|_{\Sigma\odot C}^2 \le \lambda_{\max}(C)\|\theta\|_{\operatorname{diag}(\Sigma)}^2.$$

在假设2下， $\operatorname{diag}(\Sigma) \preccurlyeq L^2 I$ ，因此

$$\|\theta\|_{H\Gamma H^\top}^2 \le L^2 \lambda_{\max}(C)\,\|\theta\|_2^2 .$$

这说明 $\lambda_{\max}\left(H\Gamma H^\top\right) \le L^2\lambda_{\max}(C) = \Lambda_{\mathrm{imp}}$ 。利用式(19)即可得到命题3.7。

B.4. 引理4.2的证明

证明。 利用式(23)，有 $\Gamma = V \odot \Sigma$ 。由 $\lambda_{\min}(V) I \preccurlyeq V$ 和引理E.1，得到

$\lambda_{\min}(V) I \odot \Sigma \preccurlyeq \Gamma,$

等价地， $\lambda_{\min}(V) \odot \operatorname{diag}(\Sigma) \preccurlyeq \Gamma$ 。在假设3下， $\ell^2 I \preccurlyeq \operatorname{diag}(\Sigma)$ ，因此

$\ell^2 \lambda_{\min}(V) I \preccurlyeq \Gamma.$

所以 $\lambda_{\min}(\Gamma) \ge \ell^2 \lambda_{\min}(V)$ 。利用式(21)，得到引理4.2的第一部分：

$$\ell^2 \lambda_{\min}(V)\left\|\theta_{\mathrm{imp}}^\star\right\|_2^2 \le B_{\mathrm{imp}}(\mathcal{F}). \tag{24}$$

在假设1′下， $\lambda_{\min}(V) = \rho(1-\rho)$ ，于是

$$\ell^2 \rho(1-\rho)\left\|\theta_{\mathrm{imp}}^\star\right\|_2^2 \le B_{\mathrm{imp}}(\mathcal{F}), \tag{25}$$

这证明了引理4.2的第二部分。

C. 随机梯度下降

C.1. 定理4.1的证明

引理C.1。 假设 $(x_n,\ \xi_n) \in \mathcal{H}\times\mathcal{H}$ 对递增 σ -域序列 $(\mathcal{F}_n)$ 是 $\mathcal{F}_n$ 可测的， $n \ge 1$ 。假设对于所有 $n \ge 1$ ， $\mathbb{E}\left[\xi_n \mid \mathcal{F}_{n-1}\right] = 0$ ， $\mathbb{E}\left[\ \|\ \xi_n\ \|^{\ 2} \mid \mathcal{F}_{n-1}\right]$ 有限，且 $\mathbb{E}\left[\left(\ \|\ x_n\ \|^{\ 2} x_n \otimes x_n\right) \mid \mathcal{F}_{n-1}\right] \preccurlyeq R^2 H$ ，其中 $\mathbb{E}\left[x_n \otimes x_n \mid \mathcal{F}_{n-1}\right] = H$ ， $R > 0$ ，算子 H 可逆。考虑递推 $\alpha_n = \left(I - \gamma x_n \otimes x_n\right)\alpha_{n-1} + \gamma\xi_n$ ，并设 $\gamma R^2 \le 1$ 。则：

$$\left(1-\gamma R^2\right)\mathbb{E}\left[\langle \bar{\alpha}_{n-1}, H\bar{\alpha}_{n-1}\rangle\right] + \frac{1}{2n\gamma}\mathbb{E}\left\|\alpha_n\right\|^2 \preccurlyeq \frac{1}{2n\gamma}\left\|\alpha_0\right\|^2 + \frac{\gamma}{n}\sum_{k=1}^{n}\mathbb{E}\left\|\xi_k\right\|^2 .$$

证明。 思路是按以下取值使用引理C.1：

- $x_k = X_{\mathrm{imp},k}$ ， $y_k = Y_k$ ；
- $H = \Sigma_{\mathrm{imp}} = \mathbb{E}\left[X_{\mathrm{imp},k} X_{\mathrm{imp},k}^\top\right] = \Sigma_P \odot \Sigma$ ，其中 $\Sigma_P = \mathbb{E}\left[PP^\top\right]$ ；
- $\alpha_k = \theta_{\mathrm{imp},k} - \theta_{\mathrm{imp}}^\star$ ；

- $\xi_k = X_{\text{imp},k}\left(Y_k - X_{\text{imp},k}^\top \theta_{\text{imp}}^\star\right)$；
- $\gamma = 1/\left(2R^2\sqrt{n}\right)$；
- $R^2 = \kappa \text{Tr}\left(\Sigma\right)$。

在这些记号下，可以证明递推(16)导出递推 $\alpha_n = \left(I - \gamma x_n \otimes x_n\right)\alpha_{n-1} + \gamma\xi_n$，其中 $\alpha_0 = \theta_0 - \theta_{\text{imp}}^\star$。现在验证引理C.1的假设。

- 证明 $\mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \parallel X_{\text{imp}} \parallel_2^2\right] \preccurlyeq R^2\Sigma_{\text{imp}}$。事实上，

$$\mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \|X_{\text{imp}}\|_2^2\right] \preceq \mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \|X\|_2^2\right],$$

这里利用了 $\parallel X_{\text{imp}} \parallel_2^2 \leq \parallel X \parallel_2^2$ 以及 $0 \preccurlyeq X_{\text{imp}}X_{\text{imp}}^\top$。随后，

$$\begin{aligned}
\mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \|X\|_2^2\right] &= \mathbb{E}\mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \|X\|_2^2 |P\right] \\
&= \mathbb{E}\mathbb{E}\left[PP^\top \odot XX^\top \|X\|_2^2 |P\right] \\
&= \mathbb{E}\left[\Sigma_P \odot XX^\top \|X\|_2^2\right] \\
&= \Sigma_P \odot \left(\mathbb{E}\left[XX^\top \|X\|_2^2\right]\right).
\end{aligned}$$

根据假设4，$\mathbb{E}\left[XX^\top \parallel X \parallel_2^2\right] \preccurlyeq R^2\Sigma$，再由引理E.1得到

$$\mathbb{E}\left[X_{\text{imp}}X_{\text{imp}}^\top \|X_{\text{imp}}\|_2^2\right] \preceq R^2\Sigma_P \odot \Sigma = R^2\Sigma_{\text{imp}}.$$

- 定义 $\epsilon_{\text{imp}} = Y - X_{\text{imp}}^\top\theta_{\text{imp}}^\star = X^\top\theta^\star + \epsilon - X_{\text{imp}}^\top\theta_{\text{imp}}^\star$。首先，
  $\epsilon_{\text{imp}}^2 \leq 3\left(\left(X^\top\theta^\star\right)^2 + \epsilon^2 + \left(X_{\text{imp}}^\top\theta_{\text{imp}}^\star\right)^2\right)$，于是

$$\begin{aligned}
\mathbb{E}\left[\|\xi\|_2^2\right] &= \mathbb{E}\left[\epsilon_{\text{imp}}^2 \|X_{\text{imp}}\|_2^2\right] \\
&\leq 3\mathbb{E}\left[\left(\left(X^\top\theta^\star\right)^2 + \epsilon^2 + \left(X_{\text{imp}}^\top\theta_{\text{imp}}^\star\right)^2\right)\|X_{\text{imp}}\|_2^2\right] \\
&\leq 3\left(\mathbb{E}\left[\left(X^\top\theta^\star\right)^2 \|X\|_2^2\right] + \mathbb{E}\left[\epsilon^2 \|X\|_2^2\right] + \mathbb{E}\left[\left(X_{\text{imp}}^\top\theta_{\text{imp}}^\star\right)^2 \|X_{\text{imp}}\|_2^2\right]\right)
\end{aligned}$$

注意，利用假设4，

$$\begin{aligned}
\mathbb{E}\left[\left(X^\top\theta^\star\right)^2 \|X\|_2^2\right] &= \mathbb{E}\left[\theta^{\star\top}\left(XX^\top \|X\|_2^2\right)\theta^\star\right] \|\theta^\star\|_\Sigma^2 \\
&\leq R^2\theta^{\star\top}\Sigma\theta \\
&= R^2\|\theta^\star\|_\Sigma^2.
\end{aligned}$$

利用第一点，以同样方式有 $\mathbb{E}\left[\left(X_{\text{imp}}^{\top}\theta_{\text{imp}}^{\star}\right)^{2} \parallel X_{\text{imp}} \parallel_{2}^{2}\right] \leq \parallel \theta_{\text{imp}}^{\star} \parallel_{\Sigma_{\text{imp}}}^{2}$。由假设4，还有 $\mathbb{E}\left[\epsilon^{2} \parallel X \parallel_{2}^{2}\right] \leq \sigma^{2}R^{2}$。因此，

$$\begin{aligned}\mathbb{E}\left[\|\xi\|_{2}^{2}\right] &\leq 3R^{2}\left(\sigma^{2}+\|\theta^{\star}\|_{\Sigma}^{2}+\left\|\theta_{\text{imp}}^{\star}\right\|_{\Sigma_{\text{imp}}}^{2}\right)\\ &\leq 3R^{2}\left(\sigma^{2}+2\|\theta^{\star}\|_{\Sigma}^{2}\right),\end{aligned}$$

因为 $\parallel \theta^{\star} \parallel_{\Sigma}^{2} = R\left(\theta^{\star}\right) \leq R_{\text{imp}}\left(\theta_{\text{imp}}^{\star}\right) = \parallel \theta_{\text{imp}}^{\star} \parallel_{\Sigma_{\text{imp}}}^{2}$。

由此可以应用引理C.1，得到

$$\left(1-\frac{1}{2\sqrt{n}}\right)\mathbb{E}\left[\langle\bar{\theta}_{\text{imp},n}-\theta_{\text{imp}}^{\star},\Sigma_{\text{imp}}(\bar{\theta}_{\text{imp},n}-\theta_{\text{imp}}^{\star})\rangle\right]+\frac{1}{2n\gamma}\mathbb{E}\left\|\theta_{\text{imp},n}-\theta_{\text{imp}}^{\star}\right\|^{2} \leqslant \frac{1}{2n\gamma}\left\|\theta_{\text{imp}}^{\star}-\theta_{0}\right\|^{2}+\frac{\gamma}{n}\sum_{k=1}^{n}\mathbb{E}\left\|\xi_{k}\right\|^{2}.$$

选择 $\gamma = 1/\left(2R^{2}\sqrt{n}\right)$，得到

$$\mathbb{E}\left\|\bar{\theta}_{\text{imp},n}-\theta_{\text{imp}}^{\star}\right\|_{\Sigma_{\text{imp}}}^{2} \leqslant \frac{2R^{2}}{\sqrt{n}}\left\|\theta_{\text{imp}}^{\star}-\theta_{0}\right\|^{2}+4\frac{\sigma^{2}+2\left\|\theta^{\star}\right\|_{\Sigma}^{2}}{\sqrt{n}}.$$

利用下式，完成定理4.1的证明：

$$\mathbb{E}\left[R_{\text{imp}}\left(\bar{\theta}_{\text{imp}}\right)\right]-R^{\star}=\mathbb{E}\left[R_{\text{imp}}\left(\bar{\theta}_{\text{imp}}\right)\right]-R_{\text{imp}}^{\star}+R_{\text{imp}}^{\star}-R^{\star}=\mathbb{E}\left\|\bar{\theta}_{\text{imp},n}-\theta_{\text{imp}}^{\star}\right\|_{\Sigma_{\text{imp}}}^{2}+B_{\text{imp}}.$$

C.2. 命题4.3和推论4.4的证明

命题4.3的证明。 首先，在假设2下，$\operatorname{Tr}(\Sigma) \leq dL^{2}$。当 $\theta_{0}=0$ 时，由引理4.2，初始条件项满足

$$\frac{\kappa\operatorname{Tr}(\Sigma)}{\sqrt{n}}\left\|\theta_{\text{imp}}^{\star}\right\|_{2}^{2} \leq \frac{\kappa L^{2}d}{\sqrt{n}\ell^{2}\rho(1-\rho)}B_{\text{imp}}(\mathcal{F}), \tag{26}$$

将上述不等式用于定理4.1，就得到命题4.3。

推论4.4的证明。 得到所述上界需要注意：由定理3.2，$B_{\text{imp}} \leq B_{\text{ridge},\lambda_{\text{imp}}}$；在假设3下，$\operatorname{Tr}(\Sigma) \geq d\ell^{2}$。然后结合命题4.3和岭偏差界（见附录D）即可。

C.3. 其他结果

命题C.2。 若 X 满足 $\mathbb{E}\left[XX^{\top} \parallel X \parallel_{2}^{2}\right] \preccurlyeq \kappa\operatorname{Tr}(\Sigma)\Sigma$，则 $\mathbb{E}\left[\epsilon^{2} \parallel X \parallel_{2}^{2}\right] \leq \sigma^{2}\kappa\operatorname{Tr}(\Sigma)$，其中 $\sigma^{2} \leq 2\mathbb{E}\left[Y^{2}\right]+2\mathbb{E}\left[Y^{4}\right]^{1/2}$。

证明。

$$\begin{aligned}\mathbb{E}\left[\epsilon^2\left\|X\right\|_2^2\right] &= \mathbb{E}\left[\left(Y - X^\top\theta^\star\right)^2\left\|X\right\|_2^2\right] \\ &\le 2\mathbb{E}\left[\left(\left(X^\top\theta^\star\right)^2 + Y^2\right)\left\|X\right\|_2^2\right] \\ &\le 2\mathbb{E}\left[Y^2\left\|X\right\|_2^2\right] + 2\mathbb{E}\left[\left(X^\top\theta^\star\right)^2\left\|X\right\|_2^2\right].\end{aligned}$$

第一项：由 Cauchy-Schwarz 不等式,

$$\begin{aligned}\mathbb{E}\left[Y^2\left\|X\right\|_2^2\right]^2 &\le \mathbb{E}\left[Y^4\right]\mathbb{E}\left[\left\|X\right\|_2^4\right] \\ &\le \mathbb{E}\left[Y^4\right]\mathbb{E}\left[\mathrm{Tr}\left(XX^\top\left\|X\right\|_2^2\right)\right] \\ &\le \mathbb{E}\left[Y^4\right]\kappa\mathrm{Tr}(\Sigma)^2.\end{aligned}$$

第二项:

$$\begin{aligned}\mathbb{E}\left[\left(X^\top\theta^\star\right)^2\left\|X\right\|_2^2\right] &= \mathbb{E}\left[(\theta^\star)^\top XX^\top\left\|X\right\|_2^2\theta^\star\right] \\ &\le \kappa\mathrm{Tr}(\Sigma)\mathbb{E}\left[(\theta^\star)^\top\Sigma\theta^\star\right] \\ &\le \kappa\mathrm{Tr}(\Sigma)\left\|\theta^\star\right\|_2^2.\end{aligned}$$

$$\mathbb{E}\left[\epsilon^2\left\|X\right\|_2^2\right] \le \mathbb{E}\left[Y^4\right]^{\frac{1}{2}}\kappa\mathrm{Tr}(\Sigma) + \kappa\mathrm{Tr}(\Sigma)\left\|\theta^\star\right\|_\Sigma^2 \le \sigma^2\kappa\mathrm{Tr}(\Sigma)\left\|\theta^\star\right\|_\Sigma^2.$$

D. 各例的细节

回顾

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) = \lambda\left\|\theta^\star\right\|_{\Sigma(\Sigma+\lambda I)^{-1}}^2 \tag{27}$$

$$= \lambda\sum_{j=1}^{d}\frac{\lambda_j}{\lambda_j+\lambda}(v_j^\top\theta^\star)^2. \tag{28}$$

D.1. 低秩协方差矩阵（例3.3）

命题D.1（奇异值相等的低秩协方差矩阵）。 考虑秩为 $r \ll d$ 且特征值恒定（$\lambda_1 = \lambda_2 = \cdots = \lambda_r$）的协方差矩阵。则

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) = \lambda\frac{r}{\mathrm{Tr}(\Sigma)}\left\|\theta^\star\right\|_\Sigma^2.$$

证明。 利用 $\lambda_1 = \cdots = \lambda_r$ 和 $\sum_{j=1}^{r} \lambda_j = \mathrm{Tr}(\Sigma)$，有 $\lambda_1 = \cdots = \lambda_r = \mathrm{Tr}(\Sigma)/r$。于是 $\Sigma(\Sigma + \lambda I)^{-1} \preccurlyeq \lambda_r^{-1}\Sigma = (r/\mathrm{Tr}(\Sigma))\Sigma$。因此，

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) = \lambda \left\|\theta^\star\right\|^2_{\Sigma(\Sigma+\lambda I)^{-1}} = \lambda \frac{r}{\mathrm{Tr}(\Sigma)} \left\|\theta^\star\right\|^2_{\Sigma}.$$

D.2. 与 $\theta^\star$ 相容的低秩协方差矩阵（例3.5）

命题D.2（与 $\theta^\star$ 相容的低秩协方差矩阵）。 考虑秩为 $r \ll d$ 的协方差矩阵，假设 $\langle \theta^\star, v_1 \rangle^2 \geq \cdots \geq \langle \theta^\star, v_d \rangle^2$，则

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) \lesssim \lambda \frac{r(\log(r)+1)}{\mathrm{Tr}(\Sigma)} \left\|\theta^\star\right\|^2_{\Sigma}.$$

证明。 回顾

$$\left\|\theta^\star\right\|^2_{\Sigma} = \sum_{j=1}^{d} \lambda_j (v_j^\top \theta^\star)^2. \tag{29}$$

在例3.5的假设下，由 $\left(\lambda_j\right)_j$ 和 $\left(\left(v_j^\top \theta^\star\right)^2\right)_j$ 递减，对所有 $k \in [r]$，

$$\sum_{j=1}^{k} \lambda_j (v_k^\top \theta^\star)^2 \leq \left\|\theta^\star\right\|^2_{\Sigma}.$$

因此，对所有 $k \in [r]$，

$$(v_k^\top \theta^\star)^2 \leq \frac{\left\|\theta^\star\right\|^2_{\Sigma}}{\sum_{j=1}^{k} \lambda_j}.$$

利用 $\sum_{j=1}^{r} \lambda_j = \mathrm{Tr}(\Sigma)$ 和特征值递减，由引理E.3可得 $\sum_{j=1}^{k} \lambda_j \geq (k/r)\mathrm{Tr}(\Sigma)$。随后，

$$
\begin{aligned}
B_{\mathrm{ridge},\lambda}(\mathcal{F}) &= \lambda \sum_{k=1}^{r} \frac{\lambda_k}{\lambda_k + \lambda} (v_k^\top \theta^\star)^2 \\
&\le \lambda \sum_{k=1}^{r} (v_k^\top \theta^\star)^2 \\
&\le \lambda \|\theta^\star\|_\Sigma^2 \sum_{k=1}^{r} \frac{1}{\sum_{j=1}^{k} \lambda_j} \\
&\le \lambda \sum_{k=1}^{r} \frac{r}{k \mathrm{Tr}(\Sigma)} \\
&\le \lambda \frac{r}{\mathrm{Tr}(\Sigma)} \sum_{k=1}^{r} \frac{1}{k} \\
&\lesssim \lambda \frac{r}{\mathrm{Tr}(\Sigma)} (\log(r) + 1),
\end{aligned}
$$

最后一步使用 Euler-Maclaurin 公式的上界。

D.3. 尖峰协方差矩阵（例3.6）

命题D.3（尖峰模型）。 假设协方差矩阵分解为 $\Sigma = \Sigma_{\le r} + \Sigma_{>r}$。假设 $\Sigma_{>r} \preccurlyeq \eta I$ （算子范数较小），且 $\Sigma_{\le r}$ 的所有非零特征值相等，则

$$
B_{\mathrm{ridge},\lambda}(\mathcal{F}) \le \frac{r}{\mathrm{Tr}(\Sigma) - d\eta} \|\theta^\star\|_\Sigma^2 + \eta \|\theta^\star_{>}\|_2^2 .
$$

其中 $\theta^\star_{>r}$ 是 $\theta^\star$ 在 $\Sigma_{>r}$ 值域上的投影。

证明。 有

$$
\begin{aligned}
\Sigma(\Sigma + \lambda I)^{-1} &= \Sigma_{\le}(\Sigma + \lambda I)^{-1} + \Sigma_{>}(\Sigma + \lambda I)^{-1} \\
&\preceq \Sigma_{\le}(\Sigma_{\le} + \lambda I)^{-1} + \Sigma_{>}(\Sigma_{>} + \lambda I)^{-1} \\
&\preceq \frac{1}{\mu}\Sigma_{\le} + \frac{1}{\lambda}\Sigma_{>},
\end{aligned}
$$

其中 μ 是 $\Sigma_{\le}$ 的非零特征值。因此，

$$
\begin{aligned}
B_{\mathrm{ridge},\lambda}(\mathcal{F}) &= \|\theta^\star\|^2_{\lambda\Sigma(\Sigma+\lambda I)^{-1}} \\
&\le \|\theta^\star\|^2_{\frac{\lambda}{\mu}\Sigma_{\le}+\Sigma_{>}} \\
&\le \frac{\lambda}{\mu} \|\theta^\star\|_\Sigma^2 + \|\theta^\star\|^2_{\Sigma_{>}} .
\end{aligned}
$$

利用 $\lambda_{\max}(\Sigma_{>}) \le \eta$，有

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) \le \frac{\lambda}{\mu}\|\theta^\star\|_\Sigma^2 + \eta\|\theta^\star_{>}\|_2^2 .$$

由 Weyl 不等式，对所有 $j \in [d]$，$\lambda_j(\Sigma_{\le} + \Sigma_{>}) \le \lambda_j(\Sigma_{\le}) + \eta$。将这些不等式求和，得到

$\mathrm{Tr}(\Sigma) \le r\mu + d\eta.$

因此，

$$\mu \ge \frac{\mathrm{Tr}(\Sigma) - d\eta}{r}.$$

由此，

$$B_{\mathrm{ridge},\lambda}(\mathcal{F}) \le \frac{r}{\mathrm{Tr}(\Sigma) - d\eta}\|\theta^\star\|_\Sigma^2 + \eta\|\theta^\star_{>}\|_2^2 .$$

E. 技术引理

引理E.1。设 A, B, V 是三个非负对称矩阵。若 $A \preccurlyeq B$，则 $A \odot V \preccurlyeq B \odot V$。

证明。设 $X \sim \mathcal{N}(0, V)$，$\theta \in \mathbb{R}^d$，

$$\begin{aligned}
\|\theta\|_{A\odot V}^2 &= \theta^\top A \odot V\theta \\
&= \theta^\top \left(\left(\mathbb{E}XX^\top\right) \odot A\right)\theta \\
&= \mathbb{E}\left[\theta^\top \left(\left(XX^\top\right) \odot A\right)\theta\right] \\
&= \mathbb{E}\left[\sum_{i,j} \theta_i \left(\left(XX^\top\right) \odot A\right)_{ij} \theta_j\right] \\
&= \mathbb{E}\left[\sum_{i,j} \theta_i X_i X_j A_{ij} \theta_j\right] \\
&= \mathbb{E}\left[\sum_{i,j} \left(\theta_i X_i\right)\left(\theta_j X_j\right) A_{ij}\right] \\
&= \mathbb{E}\left[\|X \odot \theta\|_A^2\right] \\
&\le \mathbb{E}\left[\|X \odot \theta\|_B^2\right] \\
&= \|\theta\|_{B\odot V}^2 .
\end{aligned}$$

引理E.2。设 A, B 是两个非负对称矩阵，则 $A \odot B$ 是非负对称矩阵，且对所有 $\theta \in \mathbb{R}^d$，

$$\|\theta\|_{A\odot B}^2 \leq \lambda_{\max}(B)\,\|\theta\|_{\mathrm{diag(A)}}^2,$$

其中 $\mathrm{diag}(A)$ 是由 A 的对角项组成的对角矩阵。

证明。设 $X \sim \mathcal{N}(0,\, A)$，于是 $A = \mathbb{E}\left[XX^\top\right]$。对于 $\theta \in \mathbb{R}^d$，

$$\begin{aligned}
\|\theta\|_{A\odot B}^2 &= \theta^\top A \odot B\theta \\
&= \theta^\top \left(\left(\mathbb{E}XX^\top\right) \odot B\right)\theta \\
&= \mathbb{E}\left[\theta^\top \left(\left(XX^\top\right) \odot B\right)\theta\right] \\
&= \mathbb{E}\left[\sum_{i,j} \theta_i \left(\left(XX^\top\right) \odot B\right)_{ij} \theta_j\right] \\
&= \mathbb{E}\left[\sum_{i,j} \theta_i X_i X_j B_{ij} \theta_j\right] \\
&= \mathbb{E}\left[\sum_{i,j} \left(\theta_i X_i\right)\left(\theta_j X_j\right) B_{ij}\right] \\
&= \mathbb{E}\left[\left(X \odot \theta\right)^\top B\left(X \odot \theta\right)\right] \\
&\geq 0,
\end{aligned}$$

这里利用了 B 非负。因此，$A \odot B$ 非负。此外，

$$\begin{aligned}
\|\theta\|_{A\odot B}^2 &= \mathbb{E}\left[\left(X \odot \theta\right)^\top B\left(X \odot \theta\right)\right] \\
&\leq \lambda_{\max}(B)\mathbb{E}\left[\left(X \odot \theta\right)^\top \left(X \odot \theta\right)\right] \\
&= \lambda_{\max}(B)\mathbb{E}\left[\sum_i \theta_i^2 X_i^2\right] \\
&= \lambda_{\max}(B)\sum_i \theta_i^2 \mathbb{E}\left[X_i^2\right] \\
&= \lambda_{\max}(B)\sum_i \theta_i^2 A_{ii} \\
&= \lambda_{\max}(B)\,\|\theta\|_{\mathrm{diag}(A)}^2.
\end{aligned}$$

引理E.3。设 $\left(v_j\right)_{j\in[d]}$ 是非递增的正数序列，$S = \sum_{j=1}^d v_j$。对所有 $k \in [d]$，

$$\sum_{j=1}^{k} v_j \geq \frac{k}{d} S.$$

证明。 使用反证法。若 $\sum_{j=1}^{k} v_j < (k/d)S$，则利用 $\left(v_j\right)_{j\in[d]}$ 非递增，得到

$$k v_k < \frac{k}{d} S.$$

因此 $v_{k+1} < S/d$，将后面的元素相加，得到

$$\sum_{j=r+1}^{d} v_j < \frac{d-r}{d} S.$$

于是,

$$S = \sum_{j=1}^{k} v_j = \sum_{j=1}^{r} v_j + \sum_{j=r+1}^{d} v_j < \frac{k}{d} S + \frac{d-r}{d} S = S.$$

这就产生了矛盾。

F. 补充实验

为说明输入维度和缺失数据比例对偏差的影响，我们考虑第5节所述的低秩设置，改变维度 d 和缺失值比例 ρ，同时固定秩 $r = 5$。使用10,000个完整观测估计插补偏差。

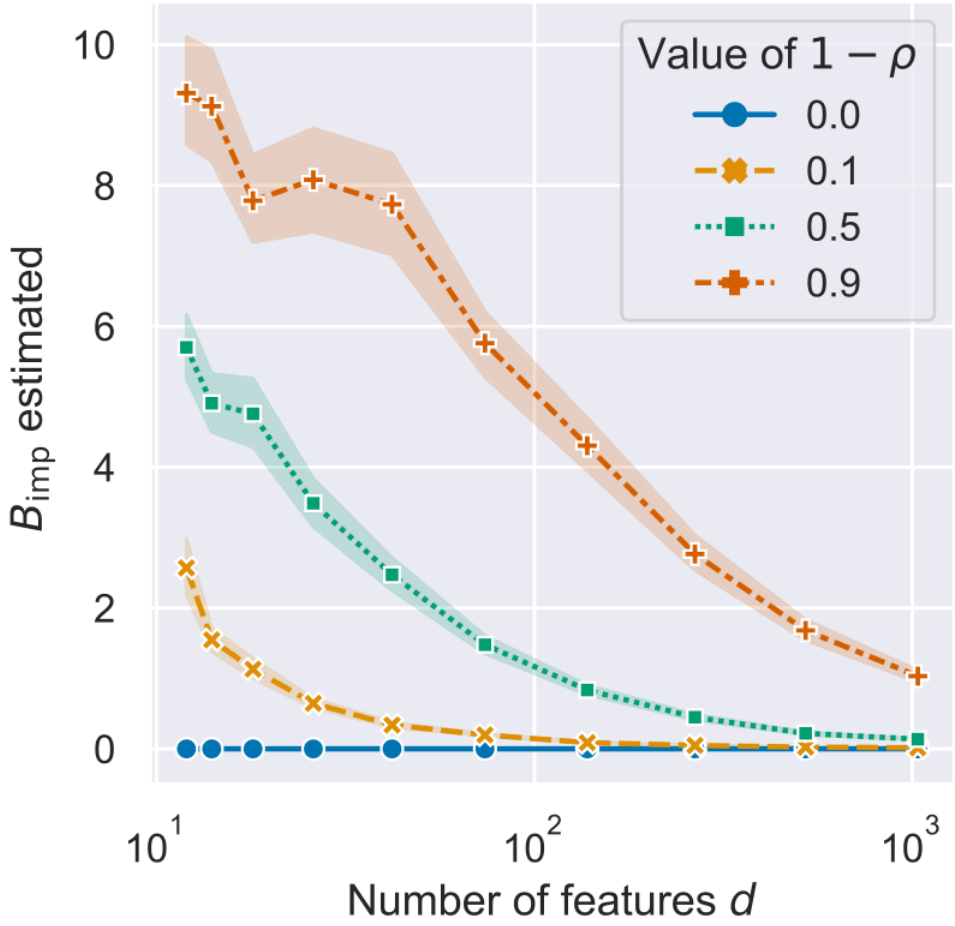


图2。 低秩设置（$r = 5$）下，使用 $n = 10000$ 个观测得到的估计插补偏差。横轴：特征数 d；纵轴：估计的 B_{imp}；图例：$1-\rho$ 的值，分别为0.0、0.1、0.5、0.9。