论多标签学习的一致性

On the Consistency of Multi-Label Learning

Wei Gao（高伟）、Zhi-Hua Zhou（周志华）
南京大学，计算机软件新技术国家重点实验室，中国南京 210093
邮箱：gaow@lamda.nju.edu.cn；zhouzh@lamda.nju.edu.cn
编辑：Sham Kakade、Ulrike von Luxburg

版本说明：本文为用户提供的 COLT 2011 会议版全文中文翻译，原载 JMLR: Workshop and Conference Proceedings 19 (2011)，341–358 页，共18页。它不是同题40页期刊版的译文。正文、定义、定理、证明、图1、致谢及参考文献均在翻译范围内。原文版权 © 2011 W. Gao & Z.-H. Zhou；本译本为非官方私人阅读译本。数学符号的含义与编号沿用原文；原稿中明显存在疑点的写法保留并单独标注，不把译文当作数学勘误版。

摘要

过去几年，多标签学习受到了广泛关注。人们提出了许多多标签学习方法，其中大多数使用替代损失函数，因为多标签损失通常具有非凸性和不连续性，难以直接优化。尽管这些方法有效，但据我们所知，尚无理论结果说明学习所得函数的风险是否收敛到贝叶斯风险。本文聚焦两种著名的多标签损失，即排序损失和汉明损失，证明了基于替代损失函数的多标签学习具有一致性的一个充要条件。我们的结果揭示了一个令人意外的事实：没有凸替代损失与这里的排序损失一致。受这一发现启发，我们引入部分排序损失，一些替代函数与该损失是一致的。对于汉明损失，我们说明，即使在确定性多标签分类中，一些近期的多标签学习方法也不一致，并给出了一个在确定性情形下具有一致性的替代损失函数。最后，我们讨论将多标签学习分解为一组二分类问题的方法的一致性。

关键词：一致性；多标签学习；替代损失；排序损失；汉明损失。

1 引言

在传统监督学习中，每个实例关联一个标签。但在实际应用中，一个对象通常同时与多个标签相关。例如，一篇关于国家教育服务的文档可能属于政府、教育等多个预定义主题；一幅包含森林的图像可能被标注为树木、山脉。为学习这类对象，过去几年多标签学习受到了广泛关注，并已发展出许多有效方法（Schapire and Singer, 2000；Elisseeff and Weston, 2002；Zhou and Zhang, 2007；Zhang and Zhou, 2007；Hsu et al., 2009；Dembczyński et al., 2010；Petterson and Caetano, 2010）。

学习算法的一致性，又称贝叶斯一致性，关注的是：随着训练样本量增加，所学函数的期望风险是否收敛到贝叶斯风险（Lin, 2002；Zhang, 2004b；Steinwart, 2005；Bartlett et al., 2006；Tewari and Bartlett, 2007；Duchi et al., 2010）。如今，人们普遍认为，一个好的学习器至少应在大样本下具有一致性。值得注意的是，尽管多标签学习已受到大量研究，关于它的理论问题仍很少被探索；特别是据我们所知，多标签学习的一致性虽然十分重要，却尚未得到研究。

本文围绕排序损失和汉明损失，对多标签学习的一致性进行理论研究。我们证明基于替代损失函数的多标签学习具有一致性的一个充要条件。分析表明，令人意外的是，任意凸替代损失与排序损失都不一致。基于这一发现，我们引入部分排序损失，一些替代损失函数与它一致；我们也证明，许多现有多标签学习方法甚至与部分排序损失也不一致。对于汉明损失，我们的分析说明，一些近期方法即使在确定性多标签分类中也不一致；我们给出了一个在确定性情形下与汉明损失一致的替代损失。最后，我们讨论通过把多标签问题转化为一组二分类问题来进行学习的方法的一致性。

本文其余部分安排如下：第2节简要介绍研究背景；第3节给出多标签学习一致性的充要条件；第4、5节分别研究相对于排序损失和汉明损失的一致性；第6节提供详细证明。

2 背景

设 $\mathcal{X}$ 为实例空间，$\mathcal{L}=\{1,\ 2,\ \ldots,\ Q\}$ 表示可能标签构成的有限集合。实例 $X\in\mathcal{X}$ 关联一个标签子集 $Y\subset\mathcal{L}$，称为相关标签；其补集 $\mathcal{L}\backslash Y$ 称为不相关标签。为便于讨论，我们将标签表示成二元向量 $Y=\left(y_1,\ y_2,\ \ldots,\ y_Q\right)$：若标签 i 与 X 相关，则 $y_i=+1$，否则为 -1。用 $\mathcal{Y}=\{+1,\ -1\}^Q$ 表示所有可能标签向量的集合。令 $\mathcal{D}$ 为 $\mathcal{X}\times\mathcal{Y}$ 上未知的潜在概率分布。对于整数 $m>0$，记 $[m]=\{1,\ 2,\ \ldots,\ m\}$；对于实数 r，$\lfloor r\rfloor$ 表示不大于 r 的最大整数。

概率框架下，多标签学习可形式化如下：给定依分布 $\mathcal{D}$ 独立同分布抽取的训练样本 $S=\{\left(X_1,\ Y_1\right),\ \left(X_2,\ Y_2\right),\ \ldots,\ \left(X_m,\ Y_m\right)\}$，目标是学习函数 $h:\mathcal{X}\to\mathcal{Y}$，以便为未见实例分配一组标签。一般而言，直接学习 h 并不容易，因此实践中通常改为学习实值向量函数

$$f=\left(f_1,\ f_2,\ \ldots,\ f_K\right):\mathcal{X}\to\mathbb{R}^K,\qquad K\in\mathbb{N},\ K>0,$$

其中常见选择是 $K=Q$ 或 $K=2^Q$。基于向量函数 f，可以获得预测函数 $F:\mathbb{R}^K\to\mathcal{Y}$，为实例分配相关标签集合。另一种常用方法是学习实值向量函数 $f=\left(f_1,\ f_2,\ \ldots,\ f_Q\right)$，使得对实例–标签对 $(X,\ Y)$，当 $y_i=+1$ 且 $y_j=-1$ 时有 $f_i(X)>f_j(X)$；此外还需学习函数 F，以确定相关标签的数量。

本质上，多标签学习方法尝试最小化函数 f 关于某种损失 L 的期望风险，即

$$R\left(f\right)=\mathbb{E}_{(X,Y)\sim\mathcal{D}}\left[L\left(f\left(X\right),\ Y\right)\right].\qquad(1)$$

注意，针对不同损失，f 可以是预测函数，也可以是实值函数向量。再记 $R^*=\inf_f R\left(f\right)$，即所有可测函数上的最小风险，例如贝叶斯风险。本文主要关注具有下界且具有间隔性的损失，定义如下。

定义1 若存在常数 B，使 $L(\cdot,\ \cdot)\geq B$，则称损失函数 L **有下界**。若存在常数 $\gamma>0$，使得对于任意 $X,\ X'\in\mathcal{X}$ 和 $Y,\ Y'\in\mathcal{Y}$，都有

$$L\left(f\left(X\right),\ Y\right)=L\left(f\left(X'\right),\ Y'\right)$$

或

$$\left|L\left(f\left(X\right),\ Y\right)-L\left(f\left(X'\right),\ Y'\right)\right|\geq\gamma,$$

则称 L **具有间隔性**（interval）。

多标签损失函数，也称评价准则，有很多种，例如排序损失、汉明损失、one-error、覆盖度和平均精度（Schapire and Singer, 2000；Zhang and Zhou, 2006）；准确率、精确率、召回率和 F_1（Godbole and Sarawagi, 2004；Qi et al., 2007）；子集准确率（Ghamrawi and McCallum, 2005）等。本文聚焦排序损失和汉明损失，其他损失留待未来讨论。

上述多标签损失都非凸且不连续，直接优化它们很困难，甚至不可能。实践中可行的方法是改用能够通过高效算法优化的替代损失函数。实际上，现有大多数多标签学习方法，例如提升算法 AdaBoost.MH（Schapire and Singer, 2000）、神经网络算法 BP-MIL（Zhang and Zhou, 2006）、SVM 风格算法（Elisseeff and Weston, 2002；Taskar et al., 2004；Hariharan et al., 2010）等，本质上都在优化指数损失、合页损失等替代损失。

一致性有许多定义，例如 Fisher 一致性（Lin, 2002）、无限样本一致性（Zhang, 2004a）、分类校准性（Bartlett et al., 2006；Tewari and Bartlett, 2007）、边一致性（Duchi et al., 2010）等。对基于优化替代损失的学习算法，其在二分类（Zhang, 2004b；Steinwart, 2005；Bartlett et al., 2006）、多分类（Zhang, 2004a；Tewari and Bartlett, 2007）以及学习排序（Cossock and Zhang, 2008；Xia et al., 2008；Duchi et al., 2010）中的一致性均已有充分研究。但多标签学习的一致性尚未被研究；据我们所知，本文首次给出了这方面的理论分析。

3 多标签一致性

给定实例 $X \in \mathcal{X}$，以 $p(X)$ 表示 $Y \in \mathcal{Y}$ 的条件概率向量，即

$$p(X) = \big(p_Y(X)\big)_{Y\in\mathcal{Y}} = \big(\Pr(Y \mid X)\big)_{Y\in\mathcal{Y}},$$

其中 $p(X) \in \Lambda$，Λ 是所有可能的条件概率分布向量构成的集合：

$$\Lambda = \Big\{p \in \mathbb{R}^{|\mathcal{Y}|} : \sum_{Y\in\mathcal{Y}} p_Y = 1,\ \ p_Y \geq 0\Big\}.$$

为简化记号，当上下文明确时，下文将省去 $p(X)$ 和 $f(X)$ 对实例 X 的依赖，分别记为 p 和 f。

对实例 $X \in \mathcal{X}$，定义 f 的条件风险为

$$l\big(p,\ f\big) = \sum_{Y\in\mathcal{Y}} p_Y L\big(f,\ Y\big) = \sum_{Y\in\mathcal{Y}} \Pr(Y \mid X) L\big(f(X),\ Y\big). \qquad (2)$$

容易得到期望风险与最小风险分别为

$$R\big(f\big) = \mathbb{E}_X\big[l\big(p,\ f\big)\big], \qquad R^* = \mathbb{E}_X\Big[\inf_f l\big(p,\ f\big)\Big].$$

进一步定义贝叶斯预测器集合

$$A\big(p\big) = \{f : l\big(p,\ f\big) = \inf_{f'} l\big(p,\ f'\big)\}.$$

因为 L 有下界且具有间隔性，所以 $A\big(p\big) \neq \varnothing$。

如前所述，多标签损失 L 通常非凸且不连续，直接最小化式(1)给出的风险很困难，甚至不可能。实践中通常使用替代损失 Ψ 代替 L。分别定义 f 的 Ψ-风险与贝叶斯 Ψ-风险为

$$R_\Psi(f) = \mathbb{E}_{X,Y}\left[\Psi\left(f(X),\ Y\right)\right], \qquad R_\Psi^* = \inf_f R_\Psi(f).$$

类似地，定义条件替代风险和条件贝叶斯替代风险为

$$W(p,\ f) = \sum_{Y\in\mathcal{Y}} p_Y \Psi(f,\ Y), \qquad W^*(p) = \inf_f W(p,\ f).$$

显然，$R_\Psi(f) = \mathbb{E}_X\left[W(p,\ f)\right]$，且 $R_\Psi^* = \mathbb{E}_X\left[W^*(p)\right]$。现在定义多标签一致性。

定义2 给定有下界的替代损失函数 Ψ，且对每个 $Y \in \mathcal{Y}$，$\Psi(\cdot,\ Y)$ 连续。若对每个 $p \in \Lambda$ 都有

$$W^*(p) < \inf_f\{W(p,\ f) : f \notin A(p)\},$$

则称 Ψ 相对于损失 L **多标签一致**。

以下定理说明，多标签一致性是由 Ψ-风险趋近贝叶斯 Ψ-风险推出 $R(f) \to R^*$ 的充要条件。

定理3 替代损失 Ψ 相对于损失 L 多标签一致，当且仅当对于任意函数序列 f_n，都有

$$R_\Psi(f_n) \to R_\Psi^* \quad \Rightarrow \quad R(f_n) \to R^*.$$

证明推迟到第6.1节，其思路受到 Zhang（2004a）以及 Tewari and Bartlett（2007）所用技术的启发。

4 相对于排序损失的一致性

排序损失关注的是：对于一个实例，有多少标签对的顺序被颠倒。对于实值向量函数 $f = \left(f_1,\ f_2,\ \ldots,\ f_Q\right)$，排序损失为

$$\begin{aligned} L_{\text{rankloss}}\left(f,\ (X,\ Y)\right) &= \sum_{y_i=-1,\, y_j=+1} a_Y I\left[f_i(X) \geq f_j(X)\right] \\ &= \sum_{y_i<y_j} a_Y I\left[f_i(X) \geq f_j(X)\right]. \end{aligned} \tag{3}$$

其中 a_Y 是非负惩罚系数，I 是示性函数：命题 π 成立时 $I[\pi] = 1$，否则为0。多标签学习中最常见的惩罚系数是

$$a_Y = \left|\{y_i : y_i = -1\}\right|^{-1} \left|\{y_j : y_j = +1\}\right|^{-1}.$$

本文考虑更一般的情形，即任意非负惩罚系数。容易看出排序损失有下界且具有间隔性，因为 $L_{\text{rankloss}}\left(f,\ (X,\ Y)\right) \geq 0$，并且对于任意 $X,\ X' \in \mathcal{X}$、$Y,\ Y' \in \mathcal{Y}$，有

$$L_{\text{rankloss}}\left(f,\ (X,\ Y)\right) = L_{\text{rankloss}}\left(f,\ (X',\ Y')\right)$$

或

$$|L_{\text{rankloss}}(f,\ (X,\ Y)) - L_{\text{rankloss}}(f,\ (X',\ Y'))| \geq \gamma,$$

其中

$$\gamma = \min\{|ia_Y - ja_{Y'}| > 0 : i,\ j \in [(Q - \lfloor Q/2 \rfloor)\lfloor Q/2 \rfloor]\}.$$

考虑式(3)，一种自然的替代损失选择是

$$\begin{aligned}\Psi(f(X),\ Y) &= \sum_{y_i=-1,\ y_j=+1} a_Y \phi\left(f_j(X) - f_i(X)\right) \\ &= \sum_{y_i<y_j} a_Y \phi\left(f_j(X) - f_i(X)\right), \qquad (4)\end{aligned}$$

其中 ϕ 是凸、单调不增的实值函数。Elisseeff and Weston（2002）选择合页损失 $\phi(x) = (1-x)_+$；Schapire and Singer（2000）、Dekel et al.（2004）、Zhang and Zhou（2006）选择指数损失 $\phi(x) = \exp(-x)$。

讨论之前，先引入记号。给定 $p \in \Lambda$ 及非负向量 $(a_Y)_{Y \in \mathcal{Y}}$，令

$$\Delta_{i,j} = \sum_{Y:\, y_i<y_j} p_Y a_Y, \qquad \delta(i,\ j;\ k,\ l) = \sum_{Y:\, y_i<y_j,\, y_k<y_l} p_Y a_Y.$$

容易得到以下结论。

引理4 对于向量 $p \in \Lambda$ 和非负向量 $(a_Y)_{Y \in \mathcal{Y}}$，以下性质成立：

1. $\Delta_{i,i} = 0$；
2. $\delta(i,\ j;\ k,\ l) = \delta(k,\ l;\ i,\ j)$；
3. 对每个 $k \neq i,\ j$，$\Delta_{i,j} = \delta(i,\ j;\ i,\ k) + \delta(i,\ j;\ k,\ j)$；
4. $\Delta_{i,k} + \Delta_{k,j} + \Delta_{j,i} = \Delta_{k,i} + \Delta_{i,j} + \Delta_{j,k}$；
5. 若 $\Delta_{i,j} \leq \Delta_{j,i}$ 且 $\Delta_{j,k} \leq \Delta_{k,j}$，则 $\Delta_{i,k} \leq \Delta_{k,i}$。

证明 性质1和2由定义立即得到。对于性质3，对每个满足 $y_i < y_j$ 的 $Y \in \mathcal{Y}$，都有 $y_i = -1$ 和 $y_j = +1$。对 y_k（$k \neq i,\ j$）只有两种可能：$+1$ 或 -1，因此得到性质3。对于性质4，利用性质3有

$$\begin{aligned}\Delta_{i,k} &= \delta(i,\ k;\ j,\ k) + \delta(i,\ k;\ i,\ j), & \Delta_{k,i} &= \delta(k,\ i;\ j,\ i) + \delta(k,\ i;\ k,\ j), \\ \Delta_{j,i} &= \delta(j,\ i;\ k,\ i) + \delta(j,\ i;\ j,\ k), & \Delta_{i,j} &= \delta(i,\ j;\ k,\ j) + \delta(i,\ j;\ i,\ k), \\ \Delta_{k,j} &= \delta(k,\ j;\ k,\ i) + \delta(k,\ j;\ i,\ j), & \Delta_{j,k} &= \delta(j,\ k;\ j,\ i) + \delta(j,\ k;\ i,\ k).\end{aligned}$$

结合性质2即得性质4。性质5由性质4推出。证毕。

引理5 对任意 $p \in \Lambda$ 及非负向量 $(a_Y)_{Y \in \mathcal{Y}}$，排序损失的贝叶斯预测器集合为

$$A(p) = \left\{ f :\ \forall\, i < j,\ \begin{array}{l} f_i > f_j,\ \Delta_{i,j} < \Delta_{j,i}; \\ f_i \neq f_j,\ \Delta_{i,j} = \Delta_{j,i}; \\ f_i < f_j,\ \text{otherwise} \end{array} \right\}.$$

证明 由式(2)中的条件风险定义，

$$\begin{aligned} l(p,\ f) &= \sum_{Y\in\mathcal{Y}} p_Y L_{\text{rankloss}}(f,\ (X,\ Y)) \\ &= \sum_{Y\in\mathcal{Y}} p_Y \sum_{y_i<y_j} a_Y I\left[f_i \geq f_j\right] \\ &= \sum_{Y\in\mathcal{Y}} p_Y \sum_{1\leq i,j\leq Q} a_Y I\left[f_i \geq f_j\right] I\left[y_i < y_j\right]. \end{aligned}$$

交换求和顺序，得到

$$\begin{aligned} l(p,\ f) &= \sum_{1\leq i,j\leq Q} I\left[f_i \geq f_j\right] \sum_{Y:\, y_i<y_j} p_Y a_Y \\ &= \sum_{1\leq i,j\leq Q} I\left[f_i \geq f_j\right] \Delta_{i,j} \\ &= \sum_{1\leq i<j\leq Q} (I\left[f_i \geq f_j\right] \Delta_{i,j} + I\left[f_i \leq f_j\right] \Delta_{j,i}). \end{aligned}$$

结合引理4的性质5即可完成证明。

下面的定理揭示，没有凸替代损失与排序损失一致，证明见第6.2节。

定理6 对任意凸函数 ϕ，替代损失

$$\Psi\left(f(X),\ Y\right) = \sum_{y_i<y_j} a_Y \phi\left(f_j(X) - f_i(X)\right)$$

相对于排序损失不具有多标签一致性。

直观地说，引理4的性质5意味着，$\{\Delta_{i,j}\}$ 通过“若 $\Delta_{i,j} \leq \Delta_{j,i}$，则 $i \succcurlyeq j$”为标签集合 $\mathcal{L} = \{1,\ 2,\ \ldots,\ Q\}$ 定义了一个顺序。注意，当 $i \succcurlyeq j$ 时，可能有 $\Delta_{i,j} = \Delta_{j,i}$。一个合理损失函数的贝叶斯预测器集合应包含所有与该顺序相容的函数，即在 $i \succcurlyeq j$ 时使 $f_i \geq f_j$ 的函数。式(3)的排序损失却对 $f_i < f_j$ 和 $f_i = f_j$ 使用相同惩罚，因此排除了部分与上述顺序相容的函数：当 $\Delta_{i,j} = \Delta_{j,i}$ 时，它实际上要求两个标签具有某个严格顺序。

举一个极端例子：若所有 $i \neq j$ 的 $\Delta_{i,j}$ 都相等，最小化凸替代损失 Ψ 会得到一个最优解 $f^* \in \{f : f_1 = f_2 = \cdots = f_Q\}$，但由引理5可知 $f^* \notin A(p)$。因此，对严格逆序与相等打分施加相同惩罚，妨碍了多标签一致性。

为克服这一缺陷，我们引入部分排序损失：

$$L_{\text{p-rankloss}}\left(f,\ (X,\ Y)\right) = \sum_{y_i<y_j} a_Y \left(I\left[f_i(X) > f_j(X)\right] + \tfrac{1}{2} I\left[f_i(X) = f_j(X)\right]\right). \qquad (5)$$

这种损失已常用于排序问题。它与排序损失的唯一差别，是对打分相等的项 $\sum_{y_i<y_j} I\left[f_i = f_j\right]$ 使用不同惩罚：排序损失使用 a_Y，部分排序损失使用 $a_Y/2$。仿照引理5的证明，可得部分排序损失的贝叶斯预测器集合：

$$A(p) = \{f : \forall\ i < j,\ \ f_i > f_j \ \text{ if } \ \Delta_{i,j} < \Delta_{j,i};\ \ f_i < f_j \ \text{ if } \ \Delta_{i,j} > \Delta_{j,i}\}. \qquad (6)$$

再考虑所有 $i \neq j$ 的 $\Delta_{i,j}$ 相等这一极端例子。容易看出，最小化替代损失 Ψ 所得最优解满足 $f^* \in \{f : f_1 = f_2 = \cdots = f_Q\} \subseteq A(p)$，体现出多标签一致性。

我们进一步研究一般情况。下面的定理给出了相对于部分排序损失多标签一致的一个充分条件。

定理7 若 $\phi : \mathbb{R} \to \mathbb{R}$ 可微、单调不增，并满足

$$\phi'(0) < 0, \qquad \phi(x) + \phi(-x) \equiv 2\phi(0), \qquad (7)$$

即对任意 $x \in \mathbb{R}$ 均有 $\phi(x) + \phi(-x) = 2\phi(0)$，则式(4)的替代损失 Ψ 相对于部分排序损失多标签一致。

定理7的证明见第6.3节。由该定理可得：

推论8 若

$$\phi(x) = -\arctan(x) \quad \text{or} \quad \phi(x) = \frac{1 - e^{2x}}{1 + e^{2x}},$$

则式(4)的替代损失相对于部分排序损失多标签一致。

注意，定理7不能直接用于 $\phi(x) = -cx^{2k+1}$（常数 $c > 0$、整数 $k \geq 0$），因为这种设置使替代损失 Ψ 无下界。不过，引入正则项可以解决这个问题。通过与定理7类似的证明，可得：

定理9 以下替代损失相对于部分排序损失多标签一致：

$$\Psi\big(f(X),\, Y\big) = \sum_{y_i < y_j} a_Y \phi\big(f_j(X) - f_i(X)\big) + \tau \Upsilon\big(f(X)\big),$$

其中 $\tau > 0$，$\phi(x) = -cx^{2k+1}$，$c > 0$ 为常数，$k \geq 0$ 为整数；Υ 是对称的，即

$$\Upsilon\big(\ldots,\, f_i(X),\, \ldots,\, f_j(X),\, \ldots\big) = \Upsilon\big(\ldots,\, f_j(X),\, \ldots,\, f_i(X),\, \ldots\big).$$

例如，很容易构造下述凸替代损失：

$$\Psi\big(f(X),\, Y\big) = \sum_{y_i < y_j} -a_Y\big(f_j(X) - f_i(X)\big) + \tau \sum_{i=1}^{Q} f_i^2(X),$$

它相对于部分排序损失多标签一致。

值得注意的是，这并不意味着式(4)中的任意凸替代损失都与部分排序损失一致。事实上，下述定理证明了许多非线性替代损失与部分排序损失不一致。

定理10 若 $\phi : \mathbb{R} \to \mathbb{R}$ 是凸、可微、非线性且单调不增的函数，则式(4)的替代损失 Ψ 相对于部分排序损失不具有多标签一致性。

证明见第6.4节。以下推论说明，一些当时先进的多标签学习方法（Schapire and Singer, 2000；Dekel et al., 2004；Zhang and Zhou, 2006）甚至不与部分排序损失多标签一致。

推论11 若 $\phi(x) = e^{-x}$ 或 $\phi(x) = \ln\left(1 + \exp(-x)\right)$，则式(4)的替代损失 Ψ 相对于部分排序损失不具有多标签一致性。

总之，Schapire and Singer（2000）的早期工作就提出把排序损失作为标准，许多当时先进的多标签学习方法采用式(4)的形式。然而，我们的分析说明，没有凸替代损失函数与排序损失一致。因此，排序损失可能不是好的多标签损失函数和评价准则。部分排序损失更合理，因为它允许许多（虽然不是所有）凸替代损失具有一致性。未来值得研究基于最小化部分排序损失的新方法，以及具有更好一致性的其他损失函数。

5 相对于汉明损失的一致性

汉明损失关注被错误分类的实例–标签对数量。对于给定的向量 f 和预测函数 F，汉明损失定义为

$$L_{\text{hamloss}}\left(F\left(f(X)\right),\ Y\right) = \frac{1}{Q}\sum_{i=1}^{Q} I\left[\widehat{y}_i \neq y_i\right],$$

其中 $\widehat{Y} = F\left(f(X)\right) = \left(\widehat{y}_1,\ \widehat{y}_2,\ \ldots,\ \widehat{y}_Q\right)$。

汉明损失显然有下界且具有间隔性，因为其取值在0和1之间；对于任意两个实例–标签对，对应损失要么相同，要么其绝对差至少为 $1/Q$。条件风险为

$$\begin{aligned} l\left(p,\ F\left(f(X)\right)\right) &= \sum_{Y\in\mathcal{Y}} p_Y L_{\text{hamloss}}(\widehat{Y},\ Y) \\ &= \frac{1}{Q}\sum_{Y\in\mathcal{Y}} p_Y \sum_{i=1}^{Q} I\left[\widehat{y}_i \neq y_i\right] \\ &= \frac{1}{Q}\sum_{i=1}^{Q}\Big(\sum_{Y\in\mathcal{Y},\, y_i=+1} p_Y I\left[\widehat{y}_i \neq +1\right] + \sum_{Y\in\mathcal{Y},\, y_i=-1} p_Y I\left[\widehat{y}_i \neq -1\right]\Big). \end{aligned}$$

相对于汉明损失的贝叶斯预测器集合为

$$A(p) = \left\{f = f(X) : \widehat{Y} = F(f),\ \widehat{y}_i = \operatorname{sgn}\left(\sum_{Y\in\mathcal{Y},\, y_i=+1} p_Y - \frac{1}{2}\right)\right\}. \qquad (8)$$

一种直接的多标签学习方法，是把每个标签子集当作一个新类别，然后学习 2^Q 个函数，即 $f = \left(f_Y\right)_{Y\in\mathcal{Y}}$。相应预测函数写为

$$F\left(f(X)\right) = \max_{Y\in\mathcal{Y}} f_Y(X). \qquad (9)$$

译注：原稿式(9)写作 max，按标签预测含义通常会使用 argmax；这里保留原式，不作无说明修改。

这一方法可视为多分类学习中一对其余策略的直接推广。考虑如下形式：

$$\Psi\left(f(X),\ Y\right) = \max_{\widehat{Y}\neq Y} \phi(\delta(\widehat{Y},\ Y) + f_{\widehat{Y}}(X) - f_Y(X)). \qquad (10)$$

Taskar et al.（2004）和 Hariharan et al.（2010）分别设置 $\phi(x) = \max(0,\ x)$、$\delta(Y,\ \widehat{Y}) = \sum_{i=1}^{Q} I\left[y_i \neq \widehat{y}_i\right]$。

进一步讨论前，将多标签分类分为确定性与非确定性两类。

定义12 在多标签分类中，若对每个 $X \in \mathcal{X}$，都存在一个标签向量 $Y \in \mathcal{Y}$ 使得 $P(Y \mid X) > 0.5$，则称该任务是**确定性的**，否则是**非确定性的**。

译注：此处“确定性”沿用作者定义，指某一标签向量条件概率大于0.5，并非要求其概率等于1。

确定性情形的一致性比非确定性情形更容易获得。例如，多种 SVM 形式对非确定性多分类不一致（Zhang, 2004a；Tewari and Bartlett, 2007），但 Zhang（2004a）指出它们在确定性情形下是一致的。下述引理说明，Taskar et al.（2004）及 Hariharan et al.（2010）的方法即使在确定性情况下，也不与汉明损失多标签一致。

引理13 对于确定性多标签分类，式(10)中取 $\delta(\widehat{Y}, Y) = \sum_{i=1}^{Q} I\left[y_i \neq \widehat{y_i}\right]$ 的替代损失 Ψ，相对于汉明损失不具有多标签一致性。

但如果改取 $\delta(\widehat{Y}, Y) = I[\widehat{Y} \neq Y]$，下述定理保证了该替代损失至少在确定性情况下与汉明损失多标签一致。

定理14 对确定性多标签分类，式(10)中取 $\delta(\widehat{Y}, Y) = I[Y \neq \widehat{Y}]$ 的替代损失 Ψ，相对于汉明损失多标签一致。

引理13与定理14的证明分别见第6.5节和第6.6节。

另一种选择，是把多标签任务转化为 Q 个独立二分类任务（Boutell et al., 2004）。此时目标是学习 Q 个函数 $f = \left(f_1, f_2, \ldots, f_Q\right)$，预测函数为

$$F\left(f(X)\right) = \left(\operatorname{sgn}\left[f_1(X)\right], \operatorname{sgn}\left[f_2(X)\right], \ldots, \operatorname{sgn}\left[f_Q(X)\right]\right).$$

常用替代损失为

$$\Psi\left(f(X), Y\right) = \sum_{i=1}^{Q} \phi\left(y_i f_i(X)\right), \qquad (11)$$

其中 ϕ 为凸函数。例如，Elisseeff and Weston（2002）取合页损失 $\phi(t) = (1-t)_+$，Schapire and Singer（2000）取指数损失 $\phi(t) = \exp(-t)$。条件替代风险为

$$\begin{aligned} W(p, f) &= \sum_{Y \in \mathcal{Y}} p_Y \Psi\left(f(X), Y\right) \\ &= \sum_{i=1}^{Q} \sum_{Y \in \mathcal{Y}} p_Y \phi\left(y_i f_i(X)\right) \\ &= \sum_{i=1}^{Q} \left(p_i^+ \phi\left(f_i(X)\right) + \left(1 - p_i^+\right) \phi\left(-f_i(X)\right)\right), \end{aligned}$$

其中 $p_i^+ = \sum_{Y:\, y_i = +1} p_Y$，$1 - p_i^+ = \sum_{Y:\, y_i = -1} p_Y$。为简洁起见，记

$$W_i\left(p_i^+, f_i\right) = p_i^+ \phi\left(f_i\right) + \left(1 - p_i^+\right) \phi\left(-f_i\right).$$

于是，最小化 $W(p,\ f)$ 等价于对所有 $1 \le i \le Q$ 分别最小化 $W_i(p_i^+,\ f_i)$，即

$$W^*(p) = \inf_f W(p,\ f) = \sum_{i=1}^{Q} \inf_{f_i} W_i(p_i^+,\ f_i).$$

二分类一致性已有充分研究（Zhang, 2004b；Bartlett et al., 2006）。基于 Bartlett et al.（2006），容易得到：

定理15 若凸函数 ϕ 满足 $\phi'(0) < 0$，则式(11)的替代损失 Ψ 相对于汉明损失一致。

由该定理显然可知，若 ϕ 为以下任一函数，式(11)的替代损失都与汉明损失一致：

- 指数损失：$\phi(x) = e^{-x}$；
- 合页损失：$\phi(x) = \max(0,\ 1 - x)$；
- 最小二乘损失：$\phi(x) = (1 - x)^2$；
- 逻辑回归损失：$\phi(x) = \ln\left(1 + \exp(-x)\right)$。

注意，本文不讨论如何在数据量很小或标签数很大的情况下学习实值函数 f。在这些场景中，很多标签或标签子集缺乏足够训练样本，这是一个挑战性问题，因此需要利用标签相关性。我们的分析假设训练数据足够，并忽略标签相关性。此外，我们没有讨论在排序损失和部分排序损失下如何确定相关标签的数量，而这在实践中也很困难。这些都是未来重要的研究问题。

6 证明

6.1 定理3的证明

首先引入几个有用的引理。

引理16 $W^*(p)$ 在 Λ 上连续。

证明 根据连续性的 Heine 定义，只需证明：对任意序列 $p^{(n)} \to p$，都有 $W^*(p^{(n)}) \to W^*(p)$。

设 B_r 是 $\mathbb{R}^K$ 中半径为 r 的闭球。由于 $|\mathcal{Y}|$ 有限，对任意序列 $p^{(n)} \to p$，下式关于 $f \in B_r$ 一致收敛：

$$\sum_{Y\in\mathcal{Y}} p_Y^{(n)} \Psi(f,\ Y) \to \sum_{Y\in\mathcal{Y}} p_Y \Psi(f,\ Y).$$

因此

$$\inf_{f\in B_r} \sum_{Y\in\mathcal{Y}} p_Y^{(n)} \Psi(f,\ Y) \to \inf_{f\in B_r} \sum_{Y\in\mathcal{Y}} p_Y \Psi(f,\ Y).$$

利用 $W^*(p^{(n)}) \le \inf_{f\in B_r} \sum_{Y\in\mathcal{Y}} p_Y^{(n)} \Psi(f,\ Y)$，令 $r \to \infty$，有

$$\limsup_{n\to\infty} W^*(p^{(n)}) \le W^*(p). \qquad (12)$$

记 $\mathcal{Y}' = \{Y : p_Y > 0,\ Y \in \mathcal{Y}\}$。因为 Ψ 有下界，设 $\Psi(\cdot,\cdot) \geq C$，其中 C 为常数。有

$$W^*(p^{(n)}) \geq \inf_f \sum_{Y\in\mathcal{Y}'} p_Y^{(n)}\Psi(f,\ Y) + C\sum_{Y\in\mathcal{Y}\setminus\mathcal{Y}'} p_Y^{(n)},$$

从而

$$\begin{aligned}\liminf_{n\to\infty} W^*(p^{(n)}) &\geq \liminf_{n\to\infty}\left(\inf_f \sum_{Y\in\mathcal{Y}'} p_Y^{(n)}\Psi(f,\ Y) + C\sum_{Y\in\mathcal{Y}\setminus\mathcal{Y}'} p_Y^{(n)}\right)\\ &= W^*(p).\end{aligned}$$

结合式(12)即完成证明。

引理17 若替代损失 Ψ 相对于损失 L 多标签一致，则对任意 $\epsilon > 0$，存在 $\delta > 0$，使得对每个 $p \in \Lambda$，

$$l(p,\ f) - \inf_{f'} l(p,\ f') \geq \epsilon \quad \Rightarrow \quad W(p,\ f) - W^*(p) \geq \delta.$$

证明 用反证法。假设 Ψ 多标签一致，并且存在 $\epsilon > 0$ 及序列 $\left(p^{(n)},\ f^{(n)}\right)$，使

$$l\left(p^{(n)},\ f^{(n)}\right) - \inf_{f'} l\left(p^{(n)},\ f'\right) \geq \epsilon,$$

而 $W\left(p^{(n)},\ f^{(n)}\right) \to W^*\left(p^{(n)}\right)$。由 Λ 的紧性，可取收敛子序列 n_k，使 $p^{(n_k)} \to p$，其中 $p \in \Lambda$。根据引理16,

$$W\left(p^{(n_k)},\ f^{(n_k)}\right) \to W^*(p).$$

仿照引理16的证明，记 $\mathcal{Y}' = \{Y : p_Y > 0,\ Y \in \mathcal{Y}\}$，有下列原稿推导:

$$\begin{aligned}\limsup_{n_k} W(\mathbf{p}, \mathbf{f}^{(n_k)}) &= \limsup_{n_k}\left(C\sum\nolimits_{Y\in\mathcal{Y}/\mathcal{Y}'} p_Y^{(n_k)} + \inf_{\mathbf{f}} \sum\nolimits_{Y\in\mathcal{Y}'} p_Y^{(n_k)}\Psi(\mathbf{f}^{(n_k)}, Y)\right)\\ &\leq \lim_{n_k} W(\mathbf{p}^{(n_k)}, \mathbf{f}^{(n_k)}) = W^*(\mathbf{p}).\end{aligned}$$

译注：此处公式按原稿第351页直接保留图像，其中的极限记号、下确界及概率下标均未作推定性修正。

根据 $W^*(p)$ 的定义，得到 $W\left(p,\ f^{(n_k)}\right) \to W^*(p)$。由于 Ψ 多标签一致，存在序列 $f^{(n_{k_i})}$，满足 $l\left(p,\ f^{(n_{k_i})}\right) \to \inf_{f'} l(p,\ f')$，这与假设 $l\left(p^{(n)},\ f^{(n)}\right) - \inf_{f'} l\left(p^{(n)},\ f'\right) \geq \epsilon$ 矛盾，因此引理成立。

定理3的证明。

“$\Rightarrow$” 首先引入新记号

$$H(\epsilon) = \inf_{p\in\Lambda, f}\left\{W(p,\ f) - \inf_{f'} W(p,\ f') : l(p,\ f) - \inf_{f'} l(p,\ f') \geq \epsilon\right\}.$$

显然 $H(0)=0$；由引理17，对 $\epsilon>0$ 有 $H(\epsilon)>0$。Zhang（2004a）的推论26保证，存在定义在 $[0,\ \infty]$ 上的凹函数 η，满足 $\eta(0)=0$、当 $\epsilon\to 0$ 时 $\eta(\epsilon)\to 0$，并且

$$R(f)-R^{*}\le\eta(R_{\Psi}(f)-R_{\Psi}^{*}).$$

因此，若 $R_{\Psi}(f)\to R_{\Psi}^{*}$，则 $R(f)\to R^{*}$。

“$\Leftarrow$”用反证法。假设 Ψ 不具有多标签一致性，则存在某个 p，使

$$W^{*}(p)=\inf_{f}\{W(p,\ f):f\notin A(p)\}.$$

取序列 $f^{(n)}\notin A(p)$，使 $W(p,\ f^{(n)})\to W^{*}(p)$。为简化讨论，令 $\mathcal{X}=\{x\}$，即只有一个实例，并令 $f_n(x)=f^{(n)}$。则

$$R_{\Psi}(f_n)=W(p,\ f^{(n)})\to W^{*}(p)=R_{\Psi}^{*},$$

这推出 $l(p,\ f^{(n)})\to\inf_{f}l(p,\ f)$，但它与下式矛盾：

$$l(p,\ f^{(n)})\ge\inf_{f}l(p,\ f)+\gamma(p),$$

其中 $\gamma(p)=\inf_{f\notin A(p)}l(p,\ f)-\inf_{f}l(p,\ f)>0$，因为 $f^{(n)}\notin A(p)$ 且 L 具有间隔性。证毕。

6.2 定理6的证明

用反证法。假设替代损失 Ψ 与排序损失多标签一致。于是

$$\begin{aligned}W(p,\ f)&=\sum_{Y\in\mathcal{Y}}p_Y\Psi(f,\ Y)=\sum_{Y\in\mathcal{Y}}p_Y a_Y\sum_{y_i<y_j}\phi\left(f_j-f_i\right)\\&=\sum_{1\le i<j\le Q}(\phi\left(f_j-f_i\right)\Delta_{i,j}+\phi\left(f_i-f_j\right)\Delta_{j,i}).\end{aligned}$$

考虑概率向量 $p=\left(p_Y\right)_{Y\in\mathcal{Y}}$ 和惩罚向量 $\left(a_Y\right)_{Y\in\mathcal{Y}}$，使对任意不同的 $Y_1,\ Y_2\in\mathcal{Y}$ 都有 $P_{Y_1}=P_{Y_2}$ 且 $a_{Y_1}=a_{Y_2}$。于是对任意 $1\le i\ne j,\ m\ne n\le Q$ 都有 $\Delta_{i,j}=\Delta_{m,n}$，从而

$$W(p,\ f)=\Delta_{1,2}\sum_{1\le i<j\le Q}(\phi\left(f_j-f_i\right)+\phi\left(f_i-f_j\right)).$$

由 ϕ 的凸性，最小化 $W(p,\ f)$ 得到

$$W^{*}(p)=W(p,\ \widehat{f})=\Delta_{1,2}\sum_{1\le i<j\le Q}2\phi(0)=Q(Q-1)\phi(0)\Delta_{1,2},$$

其中 $\widehat{f}$ 的各分量相等，即 $\widehat{f_1}=\widehat{f_2}=\cdots=\widehat{f_Q}$。由引理5，$\widehat{f}\notin A(p)$，因此

$$W^{*}(p)=\inf_{f}\{W(p,\ f):f\notin A(p)\}.$$

这就完成了证明。

6.3 定理7的证明

对于任意 $p \in \Lambda$ 和非负向量 $(a_Y)_{Y\in\mathcal{Y}}$，我们将证明：对所有满足 $W^*(p) = W(p,\ f)$ 的 f，若 $\Delta_{i,j} < \Delta_{j,i}$ 则 $f_i > f_j$；若 $\Delta_{i,j} > \Delta_{j,i}$ 则 $f_i < f_j$。不失一般性，只需证明当 $\Delta_{1,2} < \Delta_{2,1}$ 时 $f_1 > f_2$。

用反证法。假设存在向量 f，满足 $f_1 \le f_2$ 且 $W^*(p) = W(p,\ f)$。

先考虑 $f_1 < f_2$。引入另一个向量 f'，令 $f'_1 = f_2$、$f'_2 = f_1$，其他 $k \neq 1,\ 2$ 的分量保持 $f'_k = f_k$。由条件替代风险的定义，

$$W(p,\ f) = \sum_{1\le i<j\le Q} \left(\phi\left(f_j - f_i\right)\Delta_{i,j} + \phi\left(f_i - f_j\right)\Delta_{j,i}\right),$$

从而

$$\begin{aligned} W(p,\ f) - W(p,\ f') \ =\ & (\Delta_{1,2} - \Delta_{2,1})\left[\phi(f_2 - f_1) - \phi(f_1 - f_2)\right] \\ & + \sum_{i=3}^{Q} (\Delta_{1,i} - \Delta_{2,i})\left[\phi(f_i - f_1) - \phi(f_i - f_2)\right] \\ & + \sum_{i=3}^{Q} (\Delta_{i,1} - \Delta_{i,2})\left[\phi(f_1 - f_i) - \phi(f_2 - f_i)\right]. \end{aligned}$$

由引理4的性质4，

$$\Delta_{1,i} - \Delta_{2,i} - \Delta_{i,1} + \Delta_{i,2} = \Delta_{1,2} - \Delta_{2,1}. \qquad (13)$$

于是

$$\begin{aligned} W(p,\ f) - W(p,\ f') \ =\ & (\Delta_{1,2} - \Delta_{2,1})\left[\phi(f_2 - f_1) - \phi(f_1 - f_2) + \sum_{i=3}^{Q} \left(\phi(f_i - f_1) - \phi(f_i - f_2)\right)\right] \\ & + \sum_{i=3}^{Q} (\Delta_{i,1} - \Delta_{i,2})\left[\phi(f_1 - f_i) + \phi(f_i - f_1) - \phi(f_i - f_2) - \phi(f_2 - f_i)\right] \\ =\ & (\Delta_{1,2} - \Delta_{2,1})\left[\phi(f_2 - f_1) - \phi(f_1 - f_2)\right] \\ & + (\Delta_{1,2} - \Delta_{2,1})\sum_{i=3}^{Q} \left[\phi(f_i - f_1) - \phi(f_i - f_2)\right]. \end{aligned}$$

最后一个等号由条件 $\phi(x) + \phi(-x) \equiv 2\phi(0)$ 得到。对单调不增且 $\phi'(0) < 0$ 的函数 ϕ，任意 $z > 0$ 都满足 $\phi(z) < \phi(-z)$，并且 $\phi\left(f_i - f_1\right) \le \phi\left(f_i - f_2\right)$。由 $\Delta_{1,2} < \Delta_{2,1}$ 得 $W(p,\ f) > W(p,\ f')$，与 $W(p,\ f) = W^*(p)$ 矛盾。

再考虑 $f_1 = f_2$。对最优解，一阶条件为 $\partial W(p,\ f)/\partial f_i = 0$（$i = 1,\ 2$），即

$$\sum_{i\neq 1} \phi'\left(f_1 - f_i\right)\Delta_{i,1} = \sum_{i\neq 1} \phi'\left(f_i - f_1\right)\Delta_{1,i},$$

$$\sum_{i\neq 2} \phi'\left(f_i - f_2\right)\Delta_{2,i} = \sum_{i\neq 2} \phi'\left(f_2 - f_i\right)\Delta_{i,2}.$$

结合式(13)、 $f_1 = f_2$，以及由式(7)得到的 $\phi'(x) = \phi'(-x)$，有

$$(\Delta_{2,1} - \Delta_{1,2})\big(2\phi'(0) + \sum_{i\neq 1,2} \phi'(f_1 - f_i)\big) = 0.$$

但这不可能，因为 $\Delta_{1,2} < \Delta_{2,1}$ 且 $2\phi'(0) + \sum_{i\neq 1,2}\phi'(f_1 - f_i) \le 2\phi'(0) < 0$。证毕。

6.4 定理10的证明

根据 Rockafellar（1997），对于凸函数 ϕ，若 $x \le y$，则 $\phi'(x) \le \phi'(y)$；若 ϕ 可微且凸，则其导函数 ϕ' 在 $\mathbb{R}$ 上连续。因为 ϕ 单调不增，所以任意 $x \in \mathbb{R}$ 均有 $\phi'(x) \le 0$；不失一般性，假设 $\phi'(x) < 0$。

用反证法。假设对于某个非线性函数 ϕ，替代损失 Ψ 与部分排序损失多标签一致。由 ϕ' 的连续性，存在区间 $(c,\ d)$，其中 $c < d < 0$ 或 $0 < c < d$，满足

$$\phi'(x) < \phi'(y) \quad \text{for all} \quad x < y,\ \ x,\ y \in (c,\ d).$$

以下讨论 $0 < c < d$ 的情况； $c < d < 0$ 可类似处理。

先固定 $a \in (c,\ d)$，并引入新函数

$$G(x) = \big[\phi'(x-a) - \phi'(a-x)\big]\big[\phi'(a) + \phi'(x)\big] + \phi'(x)\big[\phi'(-a) - \phi'(a)\big].$$

容易发现 $G(a) = \phi'(a)\big[\phi'(-a) - \phi'(a)\big] > 0$，且 G 连续。因此，存在 $b > a$ 且 $b \in (c,\ d)$，使

$$G(b) = \big[\phi'(b-a) - \phi'(a-b)\big]\big[\phi'(a) + \phi'(b)\big] + \phi'(b)\big[\phi'(-a) - \phi'(a)\big] > 0,$$

从而

$$\frac{\phi'(b-a)\big(\phi'(a) + \phi'(b)\big) + \phi'(b)\phi'(-a)}{\phi'(a-b)\big(\phi'(a) + \phi'(b)\big) + \phi'(b)\phi'(a)} > 1. \qquad (14)$$

此外，由 $\phi'(a) < \phi'(b) < 0$ 与 $\phi'(-b) \le \phi'(-a) < 0$ 得

$$0 < \frac{\phi'(-a)}{\phi'(a)} \le \frac{\phi'(-b)}{\phi'(a)} < \frac{\phi'(-b)}{\phi'(b)}. \qquad (15)$$

考虑具有 $Q = 3$ 个标签的多标签分类问题，标签向量为

$$Y_1 = (-1,\ +1,\ +1), \qquad Y_2 = (+1,\ -1,\ -1),$$
$$Y_3 = (+1,\ +1,\ -1), \qquad Y_4 = (-1,\ -1,\ +1).$$

令 $f = (f_1,\ f_2,\ f_3)$，满足 $a = f_3 - f_1$、 $b = f_3 - f_2$，于是 $f_1 > f_2$。对任意概率向量 $p = \big(p_{Y_1},\ p_{Y_2},\ p_{Y_3},\ p_{Y_4}\big) \in \Lambda$ 和惩罚向量 $\big(a_{Y_1},\ a_{Y_2},\ a_{Y_3},\ a_{Y_4}\big)$，有

$$
\begin{aligned}
W(p,\ f)\ &= \Delta_{1,2}\phi(f_2 - f_1) + \Delta_{2,1}\phi(f_1 - f_2) \\
&\quad + \Delta_{1,3}\phi(f_3 - f_1) + \Delta_{3,1}\phi(f_1 - f_3) \\
&\quad + \Delta_{2,3}\phi(f_3 - f_2) + \Delta_{3,2}\phi(f_2 - f_3),
\end{aligned}
$$

其中 $\Delta_{1,2} = P_1$、$\Delta_{2,1} = P_2$、$\Delta_{1,3} = P_1 + P_4$、$\Delta_{3,1} = P_2 + P_3$、$\Delta_{2,3} = P_4$、$\Delta_{3,2} = P_3$；原稿写作 $P_i = p_{Y_1}a_{Y_1}$，$i = 1,\ 2,\ 3,\ 4$。下面构造某些 $\bar{p}$ 和 $\bar{a}$，使 $W^*(\bar{p}) = W(\bar{p},\ f)$ 且 $\Delta_{1,2} > \Delta_{2,1}$。

译注：这里原稿对所有 P_i 都使用下标 Y_1，疑为 Y_i 的排印错误；本译文明确保留其来源，不悄悄改动。

$W(p,\ f)$ 最优性的次梯度条件给出

$$
\begin{aligned}
\frac{\partial W}{\partial f_1} &= -P_1\phi'(a-b) + P_2\phi'(b-a) - (P_1 + P_4)\phi'(a) + (P_2 + P_3)\phi'(-a) = 0, \\
\frac{\partial W}{\partial f_2} &= P_1\phi'(a-b) - P_2\phi'(b-a) - P_4\phi'(b) + P_3\phi'(-b) = 0, \\
\frac{\partial W}{\partial f_3} &= (P_1 + P_4)\phi'(a) - (P_2 + P_3)\phi'(-a) + P_4\phi'(b) - P_3\phi'(-b) = 0.
\end{aligned}
$$

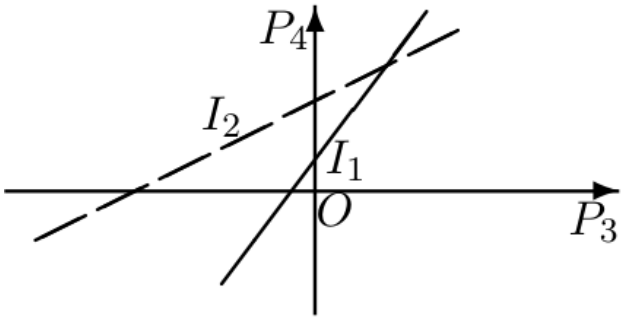


图1 直线 I_1（实线）与 I_2（虚线）分别对应式(16)和式(17)。图中横轴为 P_3，纵轴为 P_4，O 表示原点。

上述条件等价于

$$
P_1\phi'(a-b) - P_2\phi'(b-a) = P_4\phi'(b) - P_3\phi'(-b), \qquad (16)
$$

$$
-P_1\phi'(a) + P_2\phi'(-a) = P_4\big(\phi'(a) + \phi'(b)\big) - P_3\big(\phi'(-a) + \phi'(-b)\big). \qquad (17)
$$

由引理18，存在 $\bar{p} = \left(\bar{p}_{Y_1},\ \bar{p}_{Y_2},\ \bar{p}_{Y_3},\ \bar{p}_{Y_4}\right)$ 与 $\left(\bar{a}_{Y_1},\ \bar{a}_{Y_2},\ \bar{a}_{Y_3},\ \bar{a}_{Y_4}\right)$ 满足式(16)、(17)，且 $P_1 > P_2$。因此 $W(\bar{p},\ f) = W^*(\bar{p})$。由式(6)，$\Delta_{1,2} = P_1 > P_2 = \Delta_{2,1}$，同时 $f_1 > f_2$，故 $f \notin A(\bar{p})$。于是

$$
W^*(\bar{p}) = \inf_f\{W(\bar{p},\ f) : f \notin A(\bar{p})\},
$$

完成证明。

引理18 若对某些 $0 < a < b$，式(14)和式(15)成立，则存在 $P_1 > P_2 > 0$、$P_3 > 0$ 和 $P_4 > 0$ 满足式(16)、(17)。

证明 根据式(14)，令

$$1 < \frac{P_1}{P_2} < \frac{\phi'(b-a)\big(\phi'(a)+\phi'(b)\big)+\phi'(b)\phi'(-a)}{\phi'(a-b)\big(\phi'(a)+\phi'(b)\big)+\phi'(b)\phi'(a)}. \tag{18}$$

因为 $a < b$，有 $\phi'(a-b) \le \phi'(b-a) < 0$，从而

$$\frac{P_1}{P_2} > 1 \ge \frac{\phi'(b-a)}{\phi'(a-b)},$$

即 $P_1\phi'(a-b) - P_2\phi'(b-a) < 0$。因此式(16)对应图1中的直线 I_1。由式(15)又得

$$0 < \frac{\phi'(-a)+\phi'(-b)}{\phi'(a)+\phi'(b)} < \frac{\phi'(-b)}{\phi'(b)}.$$

如图1所示，为保证存在满足式(16)、(17)的 $P_3 > 0$ 和 $P_4 > 0$，需要

$$\frac{P_1\phi'(a-b) - P_2\phi'(b-a)}{\phi'(b)} < \frac{-P_1\phi'(a)+P_2\phi'(-a)}{\phi'(a)+\phi'(b)}.$$

该式显然由式(18)成立。证毕。

6.5 引理13的证明

考虑 $Q = 2$ 个标签的多标签分类任务，即 $\mathcal{L} = \{1, 2\}$，并令 $Y_1 = (-1, -1)$、$Y_2 = (-1, 1)$、$Y_3 = (1, 1)$、$Y_4 = (1, -1)$。假设 $p_{Y_4} = 0$，且

$$p_{Y_2} + p_{Y_3} < p_{Y_1} < 2p_{Y_2} + p_{Y_3}.$$

显然 $p_{Y_1} > 0.5$，故该多标签分类任务是确定性的。只需考虑 $f = \left(f_{Y_1}, f_{Y_2}, f_{Y_3}\right)$。结合式(8)和式(10)，得到

$$A(p) = \{f : f_{Y_1} \ge f_{Y_2} \text{ and } f_{Y_1} \ge f_{Y_3}\}.$$

还有

$$\begin{aligned} W(p, f) = {} & p_{Y_1}\max\{\phi\left(1 + f_{Y_2} - f_{Y_1}\right), \phi\left(2 + f_{Y_3} - f_{Y_1}\right)\} \\ & + p_{Y_2}\max\{\phi\left(1 + f_{Y_1} - f_{Y_2}\right), \phi\left(1 + f_{Y_3} - f_{Y_2}\right)\} \\ & + p_{Y_3}\max\{\phi\left(2 + f_{Y_1} - f_{Y_3}\right), \phi\left(1 + f_{Y_2} - f_{Y_3}\right)\}, \end{aligned}$$

以及

$$W^*(p) = W\left(p, f^*\right) = \inf_f W(p, f) = 2p_{Y_1} + 2p_{Y_3},$$

其中 $f^* = \left(f^*_{Y_1}, f^*_{Y_2}, f^*_{Y_3}\right)$，满足 $f^*_{Y_1} = f^*_{Y_3}$ 且 $f^*_{Y_1} = f^*_{Y_2} - 1$。因此该最优向量不属于 $A(p)$，从而不具有多标签一致性。

6.6 定理14的证明

先引入一个有用的引理。

引理19 对式(10)中取 $\delta(\widehat{Y},\ Y) = I[\widehat{Y} \neq Y]$ 的替代损失 Ψ，对任意 $p \in \Lambda$ 及满足 $W(p,\ f) = W^*(p)$ 的 f，若 $p_{Y_1} > p_{Y_2}$，则 $f_{Y_1} \geq f_{Y_2}$。

证明 用反证法。假设存在某个 $p \in \Lambda$ 和 f，使 $f_{Y_1} < f_{Y_2}$、$p_{Y_1} > p_{Y_2}$ 且 $W^*(p) = W(p,\ f)$。定义新的实值向量 f'，令 $f'_{Y_1} = f_{Y_2}$、$f'_{Y_2} = f_{Y_1}$，并对 $i \neq 1,\ 2$ 令 $f'_{Y_i} = f_{Y_i}$。于是

$$W(p,\ f) - W(p,\ f') = \left(p_{Y_1} - p_{Y_2}\right)[\max_{Y \neq Y_1} \phi\left(1 + f_Y(X) - f_{Y_1}(X)\right) - \max_{Y \neq Y_2} \phi\left(1 + f_Y(X) - f_{Y_2}(X)\right)].$$

由假设 $f_{Y_1} < f_{Y_2}$，有

$$\max_{Y \neq Y_1} \phi\left(1 + f_Y(X) - f_{Y_1}(X)\right) > \max_{Y \neq Y_2} \phi\left(1 + f_Y(X) - f_{Y_2}(X)\right),$$

从而 $W(p,\ f) - W(p,\ f') > 0$，与 $W^*(p) = W(p,\ f)$ 矛盾。证毕。

定理14的证明。不失一般性，考虑满足 $p_{Y_1} > p_{Y_2} \geq p_{Y_3} \geq \cdots \geq p_{Y_2Q}$ 且 $p_{Y_1} > 0.5$ 的概率向量 $p = (p_Y)_{Y \in \mathcal{Y}}$。由式(8)、(9)，容易得到

$$A(p) = \{f : f_{Y_1} > f_Y,\ \ Y \neq Y_1\}.$$

另一方面，由引理19，任意满足 $W(p,\ f) = W^*(p)$ 的 f 都满足

$$f_{Y_1} \geq f_{Y_2} \geq \cdots \geq f_{Y_2Q}.$$

因此，利用

$$W(p,\ f) = p_{Y_1}\phi\left(1 + f_{Y_2} - f_{Y_1}\right) + \sum_{Y \neq Y_1} p_Y \phi\left(1 + f_{Y_1} - f_Y\right)$$

以及 $p_{Y_1} > \sum_{Y \neq Y_1} p_Y$，即可完成证明。

致谢

作者感谢匿名审稿人提出的有益意见和建议，也感谢 Tong Zhang 阅读初稿。本研究获得中国国家重点基础研究发展计划（2010CB327903）、国家自然科学基金（61073097）和江苏省自然科学基金（BK2008018）支持。

参考文献

以下保留作者、出版物与页码等检索信息，论文及书籍题名附中文译名。

1. P. L. Bartlett, M. I. Jordan, J. D. McAuliffe. Convexity, classification, and risk bounds（凸性、分类与风险界）. Journal of the American Statistical Association, 101(473):138–156, 2006.
2. M. R. Boutell, J. Luo, X. Shen, C. M. Brown. Learning multi-label scene classification（学习多标签场景分类）. Pattern Recognition, 37(9):1757–1771, 2004.

3. D. Cossock, T. Zhang. Statistical analysis of bayes optimal subset ranking（贝叶斯最优子集排序的统计分析）. IEEE Transactions on Information Theory, 54(11):5140–5154, 2008.
4. O. Dekel, C. Manning, Y. Singer. Log-linear models for label ranking（用于标签排序的对数线性模型）. S. Thrun, L. K. Saul, B. Schölkopf（编）, Advances in Neural Information Processing Systems 16. MIT Press, Cambridge, MA, 2004.
5. K. Dembczyński, W. W. Cheng, E. Hüllermeier. Bayes optimal multilabel classification via probabilistic classifier chains（通过概率分类器链实现贝叶斯最优多标签分类）. Proceedings of the 27th International Conference on Machine Learning, 279–286, Haifa, Israel, 2010.
6. J. C. Duchi, L. W. Mackey, M. I. Jordan. On the consistency of ranking algorithms（论排序算法的一致性）. Proceedings of the 27th International Conference on Machine Learning, 327–334, Haifa, Israel, 2010.
7. A. Elisseeff, J. Weston. A kernel method for multi-labelled classification（用于多标签分类的核方法）. T. G. Dietterich, S. Becker, Z. Ghahramani（编）, Advances in Neural Information Processing Systems 14, 681–687. MIT Press, Cambridge, MA, 2002.
8. N. Ghamrawi, A. McCallum. Collective multi-label classification（集体多标签分类）. Proceedings of the 14th ACM International Conference on Information and Knowledge Management, 195–200, Bremen, Germany, 2005.
9. S. Godbole, S. Sarawagi. Discriminative methods for multi-labeled classification（多标签分类的判别式方法）. Proceedings of the 8th Pacific-Asia Conference on Knowledge Discovery and Data Mining, 22–30, Sydney, Australia, 2004.（原稿国家名拼作 Austrialia。）
10. B. Hariharan, L. Zelnik-Manor, S. Vishwanathan, M. Varma. Large scale max-margin multi-label classification with priors（带先验的大规模最大间隔多标签分类）. Proceedings of the 27th International Conference on Machine Learning, 423–430, Haifa, Israel, 2010.
11. D. Hsu, S. M. Kakade, J. Langford, T. Zhang. Multi-label prediction via compressed sensing（通过压缩感知进行多标签预测）. Y. Bengio, D. Schuurmans, J. Lafferty, C. K. I. Williams, A. Culotta（编）, Advances in Neural Information Processing Systems 22, 772–780. MIT Press, Cambridge, MA, 2009.
12. Y. Lin. Support vector machines and the bayes rule in classification（分类中的支持向量机与贝叶斯规则）. Data Mining and Knowledge Discovery, 6(3):259–275, 2002.
13. J. Petterson, T. Caetano. Reverse multi-label learning（反向多标签学习）. J. Lafferty, C. K. I. Williams, J. Shawe-Taylor, R. S. Zemel, A. Culotta（编）, Advances in Neural Information Processing Systems 23, 1912–1920. MIT Press, Cambridge, MA, 2010.
14. G.-J. Qi, X.-S. Hua, Y. Rui, J. Tang, T. Mei, H.-J. Zhang. Correlative multi-label video annotation（相关性多标签视频标注）. Proceedings of the 15th ACM International Conference on Multimedia, 17–26, Augsburg, Germany, 2007.
15. R. T. Rockafellar. Convex Analysis（凸分析）. Princeton University Press, Princeton, NJ, 1997.
16. R. E. Schapire, Y. Singer. BoosTexter: A boosting-based system for text categorization（BoosTexter：基于提升的文本分类系统）. Machine Learning, 39(2):135–168, 2000.

17. I. Steinwart. Consistency of support vector machines and other regularized kernel classifiers（支持向量机及其他正则化核分类器的一致性）. IEEE Transactions on Information Theory, 51(1):128–142, 2005.
18. B. Taskar, C. Guestrin, D. Koller. Max-margin markov networks（最大间隔马尔可夫网络）. S. Thrun, L. Saul, B. Schölkopf（编）, Advances in Neural Information Processing Systems 16. MIT Press, Cambridge, MA, 2004.
19. A. Tewari, P. L. Bartlett. On the consistency of multiclass classification methods（论多分类方法的一致性）. Journal of Machine Learning Research, 8:1007–1025, 2007.
20. F. Xia, T. Y. Liu, J. Wang, W. Zhang, H. Li. Listwise approach to learning to rank: Theory and algorithm（学习排序的列表式方法：理论与算法）. Proceedings of the 25th International Conference on Machine Learning, 1192–1199, Helsinki, Finland, 2008.
21. M.-L. Zhang, Z.-H. Zhou. Multi-label neural network with applications to functional genomics and text categorization（多标签神经网络及其在功能基因组学和文本分类中的应用）. IEEE Transactions on Knowledge and Data Engineering, 18(10):1338–1351, 2006.
22. M.-L. Zhang, Z.-H. Zhou. ML-KNN: A lazy learning approach to multi-label learning（ML-KNN：多标签学习的一种惰性学习方法）. Pattern Recognition, 40(7):2038–2048, 2007.
23. T. Zhang. Statistical analysis of some multi-category large margin classification methods（若干多类别大间隔分类方法的统计分析）. Journal of Machine Learning Research, 5:1225–1251, 2004a.
24. T. Zhang. Statistical behavior and consistency of classification methods based on convex risk minimization（基于凸风险最小化的分类方法的统计行为与一致性）. Annals of Statistics, 32(1):56–85, 2004b.
25. Z.-H. Zhou, M.-L. Zhang. Multi-instance multi-label learning with application to scene classification（多示例多标签学习及其在场景分类中的应用）. B. Schölkopf, J. Platt, T. Hofmann（编）, Advances in Neural Information Processing Systems 19, 1609–1616. MIT Press, Cambridge, MA, 2007.