基于语义不变性学习与原型建模的部分多视图多标签分类

非官方中文全文译文 · P150

Chengliang Liu[1]、Gehui Xu[1]、Jie Wen[1]、Yabo Liu[1]、Chao Huang[2]、Yong Xu[1]

[1] 哈尔滨工业大学计算机科学与技术学院，中国深圳。[2] 中山大学深圳校区网络空间安全学院，中国深圳。通信作者：Jie Wen（jiewen_pr@126.com）、Yong Xu（yongxu@ymail.com）。

原文：Partial Multi-View Multi-Label Classification via Semantic Invariance Learning and Prototype Modeling。第 41 届国际机器学习大会（ICML），奥地利维也纳；PMLR 235，2024。版权 © 2024 作者。官方来源：https://proceedings.mlr.press/v235/liu24bv.html 。原文依据 PMLR 出版协议以 CC BY 4.0 发布：https://proceedings.mlr.press/pmlr-license-agreement.html 。本中文译文为翻译改编，非作者审定版本；图、数值表及公式以原文清晰裁图保留，图题、表题、图例术语及全部论述译为中文。参考文献保留原语。翻译未改变原论文公式或数值；原文疑似笔误以译注标明，不静默修正。

摘要

部分多视图多标签学习的困难在于：在部分视图和标签不可用时，将多视图数据的一致性与多标签分类的任务相关性结合起来。本文寻求压缩跨视图表示，使共享信息所占比例最大，从而更好地预测语义标签。为此，我们建立与信息瓶颈理论一致的模型来学习跨视图共享表示，在保持特征有效性的同时尽量减少非共享信息，从而提高任务相关信息的纯度。进一步地，我们在潜在空间中对多标签原型实例建模，并以数据驱动方式学习标签相关性。我们的方法在多个公开数据集上优于现有最先进方法，同时对部分数据与完整数据都具有良好兼容性。最后，我们通过实验揭示：在多视图信息编码和压缩过程中，在保持信息平衡的前提下凝练共享信息至关重要。

1. 引言

多年来，人们一直致力于基于多角度、多层次和多样化信息，对目标对象进行评价或决策（Luo et al., 2023；Xiao et al., 2024；Luo et al., 2021；Liu et al., 2023d）。在数据分析和模式识别领域，多视图学习凭借其强大的表示学习潜力，被用于增强各种机器学习任务（Wu & Goodman, 2018；Wang et al., 2023）。无论是基于模态差异显著的多模态数据进行分类或回归，还是对来自同一模态的多特征数据进行特征学习，都可以统一到多视图学习的理论框架之下；该框架着重提取和利用语义不变性，以促进下游决策（Hwang et al., 2021；Zeng et al., 2023）。

近年来，得益于深度神经网络超越手工特征提取的强大映射能力，传统多视图学习方法，尤其是多视图表示学习方法，正逐渐被深度多视图学习网络替代（Wang et al., 2022；Liu et al., 2023e;f）。例如，有些工作采用深度自编码器提取视图特有特征，并使用对比学习在高层特征空间中聚合跨视图语义表示（Xu et al., 2022；Liu et al., 2023a；2024）。Castrejon 等尝试利用卷积神经网络，为跨模态场景图像学习与模态无关的共享表示（Castrejon et al., 2016）。Wen 等采用特征加权融合，在嵌入

空间中实现一致表示学习（Wen et al., 2023）。此外，Lee 等提出在最小化共享视图表示与原始数据之间互信息的同时学习任务相关信息（Lee & Van der Schaar, 2021）。显然，多视图学习理论的一个核心动机，是利用和挖掘多视图共享信息，消除或减少单视图表示中的冗余信息或不确定性。随着研究深入，一种更一般也更有挑战性的情形成为新的研究热点：部分或全部数据的某些视图缺失。我们将基于这种设置的任务称为不完整多视图学习（Liu et al., 2022；2023c）。

回顾多视图学习的发展轨迹，可以清楚看到：从无监督多视图聚类到有监督多视图分类，多视图学习正朝着与下游任务紧密结合的方向发展。本文关注一个具体而复杂的有监督任务：多标签分类。多视图学习与多标签分类的结合，极大地满足了现实应用场景的需求（Li & Chen, 2022）。

不同于单标签学习，多标签分类的重要特征是同时对样本与标签之间的关系以及标签之间的相关性进行建模（Bai et al., 2022）。现有显式建模标签相关性的工作可归为以下策略：（1）依据数据集统计信息计算类别对之间的条件概率，将其作为标签相关性的先验知识（You et al., 2020；Ma et al., 2021）。（2）在传统凸优化或神经网络反馈训练中动态学习标签相关性（Zhu et al., 2017）。另一类代表性方法着重直接学习各类别在潜在空间中的映射，尝试通过标签嵌入与样本嵌入的交互直接获得分类结果，或增强联合嵌入的判别能力（Bai et al., 2022；Hang & Zhang, 2021）。与不完整多视图学习类似，标签不完整性也被纳入问题设置，以便更符合现实情况。

针对上述复杂的部分多视图多标签分类（PMvMLC）问题，我们的解决方案包含两个主要部分：（1）最大化多视图融合表示中共享信息的比例。（2）增强多标签分类与多视图共享信息的任务相关性。具体而言，一方面，我们假设视图间共享信息表达了全部跨视图共性，其中包括最高层次的语义不变性，即对语义目标的描述在不同视图之间应具有唯一性。随后，我们以变分自编码器（VAE）作为表示学习框架，采用信息瓶颈理论对多视图数据的共享信息建模，在尽量减少任意视图中非全局共享私有信息的同时，逼近理想的多视图共享表示。另一方面，我们在潜在空间中对多标签原型实例建模，以增强多标签共享信息的任务相关性。具体来说，利用编码器对标签原型的分布建模，再在先验监督信息引导下，主动促进这些标签原型与样本嵌入表示的融合。

我们将这种基于语义不变性学习和原型建模的方法命名为 SIP，贡献概括如下：

- 提出基于信息瓶颈的 PMvMLC 框架，将多视图语义不变性学习与多标签原型表示学习结合起来。此外，方法能够处理任意视图和标签缺失情形，显示出较强的可扩展性。
- 不同于现有工作，我们主张通过提取多个视图之间的共享信息，可以有效压缩任务相关信息。所提出的信息瓶颈框架有效缓解了从部分多视图数据中提取共享信息的困难。
- 方法通过数据驱动方式在潜在空间中对标签原型建模，有效耦合了多视图表示学习与多标签分类任务。
- 在五个完整或不完整多视图多标签数据集上获得领先性能，且该语义不变性学习框架对其他多视图学习任务具有良好可扩展性。

2. 预备知识

给定包含 n 个带标签样本的 m 视图数据集，样本表示为 $\left(\{x^{(v)}\}_{v=1}^{m}, y\right)$，其中任一样本的第 v 个视图为 $x^{(v)} \in \mathbb{R}^{d_v}$，对应标签为 $y \in \{0, 1\}^c$，共有 c 个类别。进一步令 V 为已观测视图集合，$|V| \leq m$；于是缺失视图设置下的多视图数据可以写成 $\{x^{(v)}\}_{v \in V}$。类似地，对于部分标签设置，用 U 表示已知标签集合，$|U| \leq c$。我们的目标是在 $\{x^{(v)}\}_{v \in V}$（简记为 $\{x\}$）上学习跨视图表示 z，并根据 z 准确预测该样本的类别。

为此，受 Federici et al.（2020）的启发，可给出如下命题。

命题 2.1。 如果 z 包含所有视图共享的全部信息，则 z 足以预测 y。

换言之，语义信息包含在多视图共享信息中。因此，学习多视图共享信息有望在完整保留语义信息的同时，减小单个视图或部分视图私有信息对预测任务的影响。

3. 方法

3.1. 通过信息瓶颈原理学习共享信息

命题 2.1 说明，要获取任务相关的语义信息，就需要学习共享信息。在此基础上，我们进一步缩小 z 的范围，使其仅包含跨视图共享信息，并可得到如下结论。

推论 3.1。 令 z 包含且仅包含所有可用视图的共享信息，则条件互信息 $I\left(\{\bar{x}\}; z \mid x^{(v)}\right) = 0$，其中 $\{\{\bar{x}\}, x^{(v)}\} = \{x\}$。

推论 3.1 给出了获得理想 z 的必要条件。若只追求最小化上述条件互信息，必然导致 z 的信息坍塌。因此，考虑到跨视图表示 z 的信息来自原始多视图数据，我们构造最大化互信息 $I(x^{(v)}; z)$ 的目标，给出如下约束优化问题：

$$\begin{aligned} &\max \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} I\left(\mathbf{x}^{(v)}; \mathbf{z}\right) \\ &\textbf{s.t.}, \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} I\left(\{\bar{\mathbf{x}}\}; \mathbf{z} | \mathbf{x}^{(v)}\right) = 0 \end{aligned} \tag{1}$$

采用拉格朗日乘子法，问题（1）可转化为以下形式：

$$\max \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} \left(I\left(\mathbf{x}^{(v)}; \mathbf{z}\right) - \beta I\left(\{\bar{\mathbf{x}}\}; \mathbf{z} | \mathbf{x}^{(v)}\right)\right) \tag{2}$$

其中 $\beta \geq 0$ 是拉格朗日乘子。观察式（2）可知，它在形式上与信息瓶颈理论一致；β 也可以看作平衡信息有效性与紧凑性的权衡系数。式（2）的前一项旨在保持 z 从原始数据学得的信息量，后一项旨在压缩 z 中的信息，排除多视图非共享信息。对于前一项，有如下下界：

$$
\begin{aligned}
& I\left(\mathbf{x}^{(v)} ; \mathbf{z}\right) \\
= & \int \int p\left(\mathbf{x}^{(v)}, \mathbf{z}\right) \log \frac{p\left(\mathbf{x}^{(v)} | \mathbf{z}\right)}{p\left(\mathbf{x}^{(v)}\right)} d \mathbf{x}^{(v)} d \mathbf{z} \\
= & \int p\left(\mathbf{x}^{(v)}\right) \int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log p\left(\mathbf{x}^{(v)} | \mathbf{z}\right) d \mathbf{x}^{(v)} d \mathbf{z}+H\left(\mathbf{x}^{(v)}\right) \\
\geq & \int p\left(\mathbf{x}^{(v)}\right) \int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log p\left(\mathbf{x}^{(v)} | \mathbf{z}\right) d \mathbf{x}^{(v)} d \mathbf{z}
\end{aligned}
\tag{3}
$$

其中 p(·) 表示概率密度函数。由于式（3）难以处理，我们使用随机解码器 $q^v(x^{(v)} \mid z)$ 近似 $p(x^{(v)} \mid z)$，其输出记为 $\widehat{x}^{(v)}$，从而得到可用于最大化互信息的新变分下界：

$$
\begin{aligned}
& I\left(\mathbf{x}^{(v)} ; \mathbf{z}\right) \\
\geq & \int p\left(\mathbf{x}^{(v)}\right) \int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log p\left(\mathbf{x}^{(v)} | \mathbf{z}\right) d \mathbf{x}^{(v)} d \mathbf{z} \\
= & \int p\left(\mathbf{x}^{(v)}\right) \int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log q^v\left(\mathbf{x}^{(v)} | \mathbf{z}\right) d \mathbf{x}^{(v)} d \mathbf{z}+ \\
& \int p\left(\mathbf{x}^{(v)}\right) \int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log \frac{p\left(\mathbf{x}^{(v)} | \mathbf{z}\right)}{q^v\left(\mathbf{x}^{(v)} | \mathbf{z}\right)} d \mathbf{x}^{(v)} d \mathbf{z} \\
\geq & \mathbb{E}_{\mathbf{x}^{(v)} \sim p\left(\mathbf{x}^{(v)}\right)}\left[\int p\left(\mathbf{z} | \mathbf{x}^{(v)}\right) \log q^v\left(\mathbf{x}^{(v)} | \mathbf{z}\right) d \mathbf{z}\right]
\end{aligned}
\tag{4}
$$

对于模型（2）的后一项，得到以下优化目标：

$$
\begin{aligned}
& I\left(\{\bar{\mathbf{x}}\} ; \mathbf{z} | \mathbf{x}^{(v)}\right) \\
= & \int \int p(\{\mathbf{x}\}, \mathbf{z}) \log \frac{p(\{\mathbf{x}\}, \mathbf{z}) p\left(\mathbf{x}^{(v)}\right)}{p(\{\mathbf{x}\}) p\left(\mathbf{z}, \mathbf{x}^{(v)}\right)} d\{\mathbf{x}\} d \mathbf{z} \\
= & \int \int p(\{\mathbf{x}\}, \mathbf{z}) \log \frac{p(\mathbf{z} | \{\{\mathbf{x}\}\})}{p\left(\mathbf{z} | \mathbf{x}^{(v)}\right)} d\{\mathbf{x}\} d \mathbf{z}
\end{aligned}
\tag{5}
$$

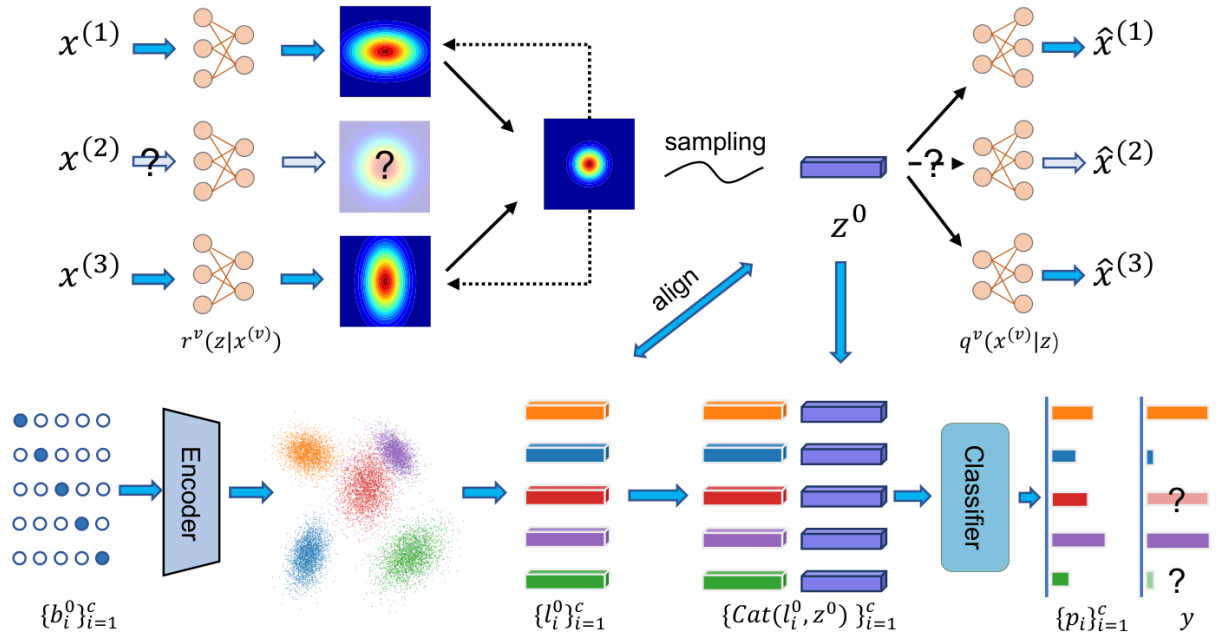
显然，式（5）也难以计算。本文使用两个随机编码器近似分布，即 $r^v(z \mid x^{(v)}) \approx p(z \mid x^{(v)})$。令 $r^v(z \mid x^{(v)}) := \mathcal{N}\left(f_\mu^v(x^{(v)}), f_{\sigma^2}^v(x^{(v)})I\right)$，其中两个编码器分别输出第 v 个视图的均值和方差，I 为单位矩阵。于是得到如下变分上界：

$$
\begin{aligned}
& I(\{\bar{\mathbf{x}}\}; \mathbf{z}|\mathbf{x}^{(v)}) \\
=& \int\int p(\{\mathbf{x}\}, \mathbf{z}) \log \frac{p(\mathbf{z}|\{\{\mathbf{x}\}\}) r^v(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)}) r^v(\mathbf{z}|\mathbf{x}^{(v)})} d\{\mathbf{x}\} d\mathbf{z} \\
=& \int\int p(\{\mathbf{x}\}, \mathbf{z}) \log \frac{p(\mathbf{z}|\{\mathbf{x}\})}{r^v(\mathbf{z}|\mathbf{x}^{(v)})} d\{\mathbf{x}\} d\mathbf{z} + \\
& \int\int p(\{\mathbf{x}\}, \mathbf{z}) \log \frac{r^v(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)})} d\{\mathbf{x}\} d\mathbf{z} \\
\leq& \int p(\{\mathbf{x}\}) D_{KL}(p(\mathbf{z}|\{\mathbf{x}\}) \| r^v(\mathbf{z}|\mathbf{x}^{(v)})) d\{\mathbf{x}\} \\
=& \mathbb{E}_{\{\mathbf{x}\} \sim p(\{\mathbf{x}\})}[D_{KL}(p(\mathbf{z}|\{\mathbf{x}\}) \| r^v(\mathbf{z}|\mathbf{x}^{(v)}))]
\end{aligned}
\tag{6}
$$

其中 $D_{KL}(\cdot \| \cdot)$ 表示 Kullback-Leibler 散度。结合式（4）与（6），式（2）的优化自然转化为最小化对应损失的上界：

$$
\begin{aligned}
\mathcal{L}_{IB} = \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} \big[& - \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z}|\{\mathbf{x}\})} \log q^v(\mathbf{x}^{(v)}|\mathbf{z}) \\
& + \beta D_{KL}(p(\mathbf{z}|\{\mathbf{x}\}) \| r^v(\mathbf{z}|\mathbf{x}^{(v)}))\big]
\end{aligned}
\tag{7}
$$

图 1：SIP 的主要框架。 上部为部分多视图共享信息学习，下部为数据驱动标签原型学习。上部使用自编码器作为骨干网络，并以专家乘积（PoE）方式融合多视图；下部通过简单编码器提取标签嵌入，并使其与多视图融合特征对齐。图中 sampling 为采样，align 为对齐，Encoder 为编码器，Classifier 为分类器，Cat 为拼接，问号表示缺失项。



有了式（7）的优化目标，一个重要问题是如何获得多个视图的联合后验 $p(z \mid \{x\})$。我们希望多视图联合分布中的共享信息来自全部视图，即每个视图向联合后验提供相同的共享信息。因此，我们采用具有“一票”特性的专家乘积 PoE（Hinton, 2002）来获得多视图联合后验。随后按照 Wu & Goodman（2018），将其定义为：

$$p(\mathbf{z}|\{\mathbf{x}\}) \propto p(\mathbf{z}) \prod_{v \in \mathcal{V}} p(\mathbf{z}|\mathbf{x}^{(v)}) := r(\mathbf{z}) \prod_{v \in \mathcal{V}} r^v(\mathbf{z}|\mathbf{x}^{(v)}) \quad (8)$$

在基本实现中，r(z) 被定义为标准高斯分布 $r(z) := \mathcal{N}(0, I)$。我们希望融合视图尽可能展现全部视图的共性。此外，PoE 融合能够保持表示的概率分布性质，这对于计算基于信息论的目标函数十分重要。

3.2. 学习标签原型表示

得到跨视图联合分布后，一种简单方法是直接构建神经网络分类器，对样本潜在空间表示到相应多标签的映射建模。然而，如引言所述，考虑标签相关性是多标签学习与单标签分类的重要区别。以往方法或者使用预训练词向量模型直接获得标签嵌入（Ma et al., 2021），或者引入先验标签相关性来监督标签嵌入学习（You et al., 2020；Hang & Zhang, 2021）。这些方法在标签与标签关系建模方面缺乏灵活性和适应性，尤其是在标签缺失时。受 Bai et al.（2022）启发，我们倾向于以数据驱动方式学习标签原型表示。

与聚类中心类似，标签原型被视为语义目标在嵌入空间中的投影。训练良好的标签原型能够帮助模型捕获更有判别力的信息，以用于多标签分类。为显式建模标签语义概念的表达，我们采用随机编码器拟合每个类别原型的分布，即 $l_i \sim \mathcal{N}\left(\mu_i, \sigma_i^2 I\right)$；均值和方差分别由编码器 $g_\mu(b_i)$ 与 $g_{\sigma^2}(b_i)$ 输出。$b_i \in \mathbb{R}^c$ 是一个可用张量，初始化为第 i 位为 1 的独热向量。接着使用重参数化技巧，从 l_i 分布采样 s 次，获得潜在空间中的标签原型表示：

$$l_i^0 = \frac{1}{s}\sum_{d=1}^{s}(\mu_i + \sigma_i \odot \delta^d) \tag{9}$$

其中 δ^d 表示从标准高斯分布取得的第 d 次样本，$\odot$ 表示 Hadamard 逐元素乘积。

初步建模潜在空间中每个标签原型的分布之后，我们进一步考虑标签间的相关性。通常，一个特定标签的出现可能意味着与其相关的其他标签也共同出现，我们将这一现象定义为标签相关性。引入标签相关性有助于避免将多标签分类简单当作多个二分类问题。然而，依据统计方法人工设计和计算标签相关性缺乏灵活性，因此我们希望样本在标签原型建模中发挥主导作用。直观上，标签原型应表示属于该类别样本的几何中心。为此，我们通过最小化欧氏空间中原型与样本的距离，促使标签原型靠近相应样本。具体地，按照式（9）采样跨视图表示 z^0 及其对应标签原型 $\{l_j^0 \mid j \in C\}$，其中 C 表示属于 z^0 的已知正标签集合，然后最小化它们在欧氏空间中的距离：

$$\mathcal{L}_{PA} = \| \frac{1}{|\mathcal{C}|}\sum_{j\in\mathcal{C}} l_j^0 - z^0 \|_2^2 \tag{10}$$

其中 L_{PA} 是原型聚合损失。根据式（10），同时出现的标签原型将靠近样本的跨视图表示，从而间接促进标签原型之间的相关性学习。

3.3. 多标签分类与目标函数

学习有判别力的标签原型，是为了得到更好的分类结果。现有工作通过计算标签嵌入与样本嵌入的内积，预测样本属于每个类别的概率（Bai et al., 2022）。然而，我们认为手动指定样本与标签的距离度量过于依赖经验。本文提出通过一个简单神经网络测量样本与标签原型的相似性：

$$p_i = \omega(f_c(z^0 \circledcirc l_i^0)) \tag{11}$$

其中圆形拼接符号表示拼接操作，f_c 是简单全连接层，ω(·) 为 Sigmoid 激活函数。最终获得样本被标记为第 i 类的预测概率 p_i。目标函数还包括多标签交叉熵损失，以赋予整个多标签学习模型最大的任务相关性。每个样本与预测对的交叉熵损失为：

$$\mathcal{L}_{CE} = \frac{1}{|\mathcal{U}|}\sum_{i\in\mathcal{U}}[y_i \log p_i + (1-y_i)\log(1-p_i)] \quad (12)$$

其中 y_i 表示 y 中第 i 类的正或负掩码。考虑到某些标签未知，在计算交叉熵损失时，忽略缺失标签对应的项。这种简单有效的方式可以尽量降低标签不确定性对任务相关性学习的影响。

【译注：原文式（12）整体未写负号；此处保留原式，不将其静默改为通常的负交叉熵形式。】

现在，将各部分目标函数直接相加，得到总体优化目标：

$$\mathcal{L} = \mathcal{L}_{IB} + \alpha\mathcal{L}_{PA} + \mathcal{L}_{CE} \quad (13)$$

其中 α 为权衡系数，损失函数是在单样本情形下定义的。

回顾共享信息学习、标签原型学习和多标签分类这三个部分，共享信息学习是自监督的，其余部分是有监督学习。一种自然想法是，将自监督学习作为有监督学习的预训练过程（Khosla et al., 2020）。然而，在我们的情形中，自监督学习得到的共享信息直接作用于任务相关的标签原型学习，因此在联合框架下同时执行这两类任务，不会造成显著的性能下降，同时还可保持更好的可复现性。

算法 1 给出了所提模型的训练过程。注意，在训练期间，我们通过最小化目标函数来调整网络参数，包括生成标签原型所用的参数 $\{b_i\}_{i=1}^{c}$；在测试阶段，标签原型不会随输入变化而更新。

算法 1：所提模型的训练过程

1. 输入：不完整多视图数据 $\left(\{x^{(v)}\}_{v=1}^{m}, y\right)$、已观测视图集合 V、已知标签集合 U、训练轮数 k、权衡系数 α 和 β。
2. 输出：模型参数。
3. 将参数 $\{b_i\}_{i=1}^{c}$ 初始化为单位矩阵 $I \in \{0, 1\}^{c\times c}$。
4. 对 t = 1,...,k 循环。
5. 用均值与方差编码器，计算每个可用视图上的跨视图表示条件分布 $\{r^v(z \mid x^{(v)}) \mid v \in V\}$。
6. 按照式（8）获得跨视图表示 z 的分布。
7. 仿照式（9）从 z 的分布采样 z^0。
8. 使用 z^0 和解码器计算条件分布 $\{q^v(x^{(v)} \mid z) \mid v \in V\}$。
9. 计算 c 个原型表示条件分布。原算法的分布记为 $\{l_i \sim \mathcal{N}\left(g_{\sigma^2}^{v}(b_i), g_{\sigma^2}^{v}(b_i)I\right) \mid i = 1, \ldots, c\}$。【译注：原算法均值项也写为方差编码器；正文 3.2 节则为 $g_{\mu}(b_i)$，此处记录原算法记号差异。】
10. 按式（9），从相应的 l_i 分布采样每个 l_i^0。
11. 计算总损失 $L = L_{IB} + \alpha L_{PA} + L_{CE}$。
12. 根据 L 更新模型参数。
13. 结束循环。

4. 实验

4.1. 实验设置

数据集。 与以往工作（Liu et al., 2023a；Tan et al., 2018；Li & Chen, 2022；Liu et al., 2023b）一致，我们在实验中采用五个广泛认可的多视图多标签数据库：Corel5k（Duygulu et al., 2002）、Pascal07（Everingham et al., 2009）、ESPGame（Von Ahn & Dabbish, 2004）、IAPRTC12（Henning et al., 2006）及 MIRFLICKR（Huiskes & Lew, 2008）。这五个数据库均包含六种不同特征：GIST、HSV、DenseHue、DenseSift、RGB 和 LAB。数据集的更多信息见附录。

不完整多视图部分多标签数据预处理。 按照现有工作（Tan et al., 2018；Li & Chen, 2022；Liu et al., 2023a），为模拟现实场景中的数据缺失设置，我们需要基于上述五个完整数据集生成部分多视图多标签数据。具体过程为：随机使每个视图中 50% 的实例不可用，同时确保每个样本至少有一个可用视图；再随机去掉每个样本 50% 的正标签和负标签，生成部分多标签数据。以 0 填充缺失视图和标签，使维度保持不变。最后，随机选择整个数据集的 70% 作为训练集，以全面评估所提方法。

比较方法。 实验选择八种先进方法与 SIP 比较：C2AE（Yeh et al., 2017）、GLOCAL（Zhu et al., 2017）、CDMM（Zhao et al., 2021）、DM2L（Ma & Chen, 2021）、LVSL（Zhao et al., 2022）、iMVWL（Tan et al., 2018）、NAIM3L（Li & Chen, 2022）及 DICNet（Liu et al., 2023a）。必须强调，由于问题设置复杂，并非所有比较方法都完全适合缺失多视图和部分多标签设置，例如 C2AE、GLOCAL、CDMM、DM2L、LVSL。具体而言，C2AE、GLOCAL 和 DM2L 只能处理单视图部分多标签情形；CDMM 和 LVSL 则是完整多视图多标签分类模型，不具备缺失数据处理能力。为使上述五种方法适应当前设置，我们作如下调整：（1）对单视图方法，在每个视图上分别实验并记录最佳结果。（2）对面向完整多视图数据的方法，使用相应视图可用实例的均值填充不可用实例。（3）对不支持部分多标签数据的方法，直接把未知标签视为负标签。比较方法的更多信息见附录。

评价指标。 与以往工作（Tan et al., 2018；Li & Chen, 2022）相似，我们采用六种常用指标评价 SIP：排序损失（RL）、平均精度（AP）、汉明损失（HL）、曲线下面积（AUC；原文作 “area under the adaptation curve”）、单错误（OE）及覆盖度（Cov）。注意，我们以 1-RL、1-HL、1-OE 和 1-Cov 作为最终结果，因此六项指标都是数值越大，性能越好。

表 1：五个数据集上视图缺失率和标签缺失率均为 50% 时，九种方法的实验结果。 每个数值右下角的小数为标准差；Ave.R 为六项指标的平均名次。Data 为数据集，Metric 为指标；AP、1-HL、1-RL、AUC、1-OE、1-Cov 含义见上文。所有实验数值完整保留。

Data	Metric	C2AE	GLOCAL	CDMM	DM2L	LVSL	iMVWL	NAIM3L	DICNet	SIP
Corel5k	AP	$0.227_{0.008}$	$0.285_{0.004}$	$0.354_{0.004}$	$0.262_{0.005}$	$0.342_{0.004}$	$0.283_{0.008}$	$0.309_{0.004}$	$0.381_{0.004}$	$0.418_{0.009}$
	1-HL	$0.980_{0.002}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.987_{0.000}$	$0.978_{0.000}$	$0.987_{0.000}$	$0.988_{0.000}$	$0.988_{0.000}$
	1-RL	$0.804_{0.010}$	$0.840_{0.003}$	$0.884_{0.003}$	$0.843_{0.002}$	$0.881_{0.003}$	$0.865_{0.005}$	$0.878_{0.002}$	$0.882_{0.004}$	$0.911_{0.003}$
	AUC	$0.806_{0.010}$	$0.843_{0.003}$	$0.888_{0.003}$	$0.845_{0.002}$	$0.884_{0.003}$	$0.868_{0.005}$	$0.881_{0.002}$	$0.884_{0.004}$	$0.913_{0.003}$
	1-OE	$0.246_{0.016}$	$0.327_{0.010}$	$0.410_{0.007}$	$0.295_{0.014}$	$0.391_{0.009}$	$0.311_{0.015}$	$0.350_{0.009}$	$0.468_{0.007}$	$0.489_{0.016}$
	1-Cov	$0.596_{0.016}$	$0.648_{0.006}$	$0.723_{0.007}$	$0.647_{0.005}$	$0.718_{0.006}$	$0.702_{0.008}$	$0.725_{0.005}$	$0.727_{0.011}$	$0.787_{0.009}$
	Ave.R	8.83	6.33	2.83	6.83	3.83	6.83	4.33	2.17	**1.00**
Pascal07	AP	$0.485_{0.008}$	$0.496_{0.004}$	$0.508_{0.005}$	$0.471_{0.008}$	$0.504_{0.005}$	$0.437_{0.018}$	$0.488_{0.003}$	$0.505_{0.012}$	$0.555_{0.010}$
	1-HL	$0.908_{0.002}$	$0.927_{0.000}$	$0.931_{0.001}$	$0.928_{0.001}$	$0.930_{0.000}$	$0.882_{0.004}$	$0.928_{0.001}$	$0.929_{0.001}$	$0.931_{0.001}$
	1-RL	$0.745_{0.009}$	$0.767_{0.004}$	$0.812_{0.004}$	$0.761_{0.005}$	$0.806_{0.003}$	$0.736_{0.015}$	$0.783_{0.001}$	$0.783_{0.008}$	$0.830_{0.004}$
	AUC	$0.765_{0.010}$	$0.786_{0.003}$	$0.838_{0.003}$	$0.779_{0.004}$	$0.832_{0.002}$	$0.767_{0.015}$	$0.811_{0.001}$	$0.809_{0.006}$	$0.850_{0.005}$
	1-OE	$0.438_{0.008}$	$0.443_{0.005}$	$0.419_{0.008}$	$0.420_{0.011}$	$0.419_{0.008}$	$0.362_{0.023}$	$0.421_{0.006}$	$0.427_{0.015}$	$0.464_{0.018}$
	1-Cov	$0.680_{0.010}$	$0.703_{0.004}$	$0.759_{0.003}$	$0.692_{0.004}$	$0.751_{0.003}$	$0.677_{0.015}$	$0.727_{0.002}$	$0.731_{0.006}$	$0.783_{0.006}$
	Ave.R	7.17	5.33	2.83	6.67	3.83	8.83	4.83	4.00	**1.00**
ESPGame	AP	$0.202_{0.006}$	$0.221_{0.002}$	$0.289_{0.003}$	$0.212_{0.002}$	$0.285_{0.003}$	$0.244_{0.005}$	$0.246_{0.002}$	$0.297_{0.002}$	$0.311_{0.004}$
	1-HL	$0.971_{0.002}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.982_{0.000}$	$0.983_{0.000}$	$0.972_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$	$0.983_{0.000}$
	1-RL	$0.772_{0.006}$	$0.780_{0.004}$	$0.832_{0.001}$	$0.781_{0.001}$	$0.829_{0.001}$	$0.808_{0.002}$	$0.818_{0.002}$	$0.832_{0.001}$	$0.849_{0.002}$
	AUC	$0.777_{0.006}$	$0.784_{0.004}$	$0.836_{0.001}$	$0.785_{0.001}$	$0.833_{0.002}$	$0.813_{0.002}$	$0.824_{0.002}$	$0.836_{0.001}$	$0.853_{0.002}$
	1-OE	$0.262_{0.018}$	$0.317_{0.005}$	$0.396_{0.005}$	$0.294_{0.006}$	$0.389_{0.004}$	$0.343_{0.013}$	$0.339_{0.003}$	$0.439_{0.007}$	$0.455_{0.007}$
	1-Cov	$0.497_{0.011}$	$0.496_{0.006}$	$0.574_{0.004}$	$0.488_{0.003}$	$0.567_{0.005}$	$0.548_{0.004}$	$0.571_{0.003}$	$0.593_{0.003}$	$0.628_{0.005}$
	Ave.R	8.67	7.33	2.33	7.50	3.67	6.17	4.33	1.83	**1.00**
IAPRTC12	AP	$0.224_{0.007}$	$0.256_{0.002}$	$0.305_{0.004}$	$0.234_{0.003}$	$0.304_{0.004}$	$0.237_{0.003}$	$0.261_{0.001}$	$0.323_{0.001}$	$0.331_{0.006}$
	1-HL	$0.965_{0.002}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.969_{0.000}$	$0.980_{0.000}$	$0.981_{0.000}$	$0.980_{0.000}$
	1-RL	$0.806_{0.005}$	$0.825_{0.002}$	$0.862_{0.002}$	$0.823_{0.002}$	$0.861_{0.002}$	$0.833_{0.002}$	$0.848_{0.001}$	$0.873_{0.001}$	$0.885_{0.003}$
	AUC	$0.807_{0.005}$	$0.830_{0.001}$	$0.864_{0.002}$	$0.825_{0.001}$	$0.863_{0.001}$	$0.835_{0.001}$	$0.850_{0.001}$	$0.874_{0.000}$	$0.886_{0.002}$
	1-OE	$0.300_{0.031}$	$0.378_{0.007}$	$0.432_{0.008}$	$0.340_{0.006}$	$0.429_{0.009}$	$0.352_{0.008}$	$0.390_{0.005}$	$0.468_{0.002}$	$0.463_{0.009}$
	1-Cov	$0.523_{0.009}$	$0.534_{0.003}$	$0.597_{0.004}$	$0.529_{0.004}$	$0.597_{0.004}$	$0.564_{0.005}$	$0.592_{0.004}$	$0.649_{0.001}$	$0.675_{0.007}$
	Ave.R	9.00	6.33	2.67	7.50	3.33	6.67	5.00	1.83	**1.00**
MIRFLICKR	AP	$0.505_{0.008}$	$0.537_{0.002}$	$0.570_{0.002}$	$0.514_{0.006}$	$0.553_{0.002}$	$0.490_{0.012}$	$0.551_{0.002}$	$0.589_{0.005}$	$0.614_{0.004}$
	1-HL	$0.853_{0.004}$	$0.874_{0.001}$	$0.886_{0.001}$	$0.878_{0.001}$	$0.885_{0.001}$	$0.839_{0.002}$	$0.882_{0.001}$	$0.888_{0.002}$	$0.891_{0.001}$
	1-RL	$0.821_{0.003}$	$0.832_{0.001}$	$0.856_{0.001}$	$0.831_{0.003}$	$0.856_{0.001}$	$0.803_{0.008}$	$0.844_{0.001}$	$0.863_{0.004}$	$0.877_{0.002}$
	AUC	$0.810_{0.004}$	$0.828_{0.001}$	$0.846_{0.001}$	$0.828_{0.003}$	$0.844_{0.001}$	$0.787_{0.012}$	$0.837_{0.001}$	$0.849_{0.004}$	$0.860_{0.003}$
	1-OE	$0.505_{0.020}$	$0.552_{0.005}$	$0.631_{0.004}$	$0.510_{0.008}$	$0.607_{0.004}$	$0.511_{0.022}$	$0.585_{0.003}$	$0.637_{0.007}$	$0.662_{0.008}$
	1-Cov	$0.590_{0.005}$	$0.605_{0.003}$	$0.640_{0.001}$	$0.604_{0.005}$	$0.636_{0.001}$	$0.572_{0.013}$	$0.631_{0.002}$	$0.652_{0.007}$	$0.678_{0.003}$
	Ave.R	8.17	6.17	3.00	6.83	3.83	8.67	5.00	2.00	**1.00**

4.2. 实验结果与分析

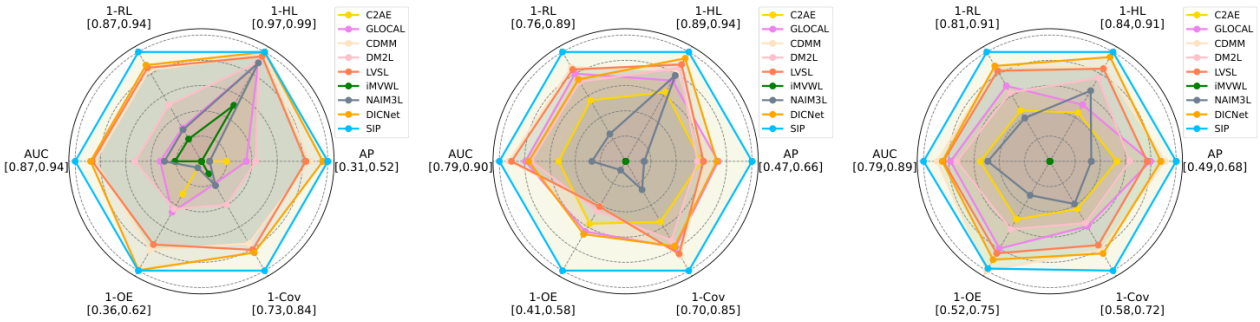
我们在五个数据集上将 SIP 与其他先进方法比较，六项指标的实验结果见表 1，其中视图和标签的不完整率均设为 50%。为便于直观比较，还计算了每种方法在六项指标上的平均名次（Ave.R）。从表 1 可观察到：

- 原文称，与其他竞争方法相比，SIP 在全部指标上达到最佳性能，在全部数据集上排名第一，充分验证了其在 PMvMLC 任务上的有效性。
- 可以观察到，能够处理不完整视图和部分标签的 DICNet 与 SIP，比只能用于标签缺失或理想情形的方法表现更好。这为未来多视图多标签分类模型的设计提供了启示。

【译注：本节原文两处写“其他九种方法”，而实验实际为八种基线加 SIP 共九种；此外，“全部指标最佳”的概括与表 1 中个别数值并不完全一致。此处保留作者结论，同时提示以表中数值为准。】

为了进一步确认模型对完整多视图数据具有良好适应性，图 2 的雷达图给出了九种方法在三个视图和标签均完整的数据集上的结果，另外两个数据库的结果见附录。显然，与其他方法（包括专为理想完整情形设计的方法）相比，SIP 仍取得具有竞争力的性能，显示了模型的泛化能力。

图 2：九种方法在三个无缺失视图或标签的完整数据集上的实验结果。 雷达图中心表示最差结果，顶点表示最佳结果，共考虑六项指标。子图（a）Corel5k；（b）Pascal07；（c）MIRFLICKR。



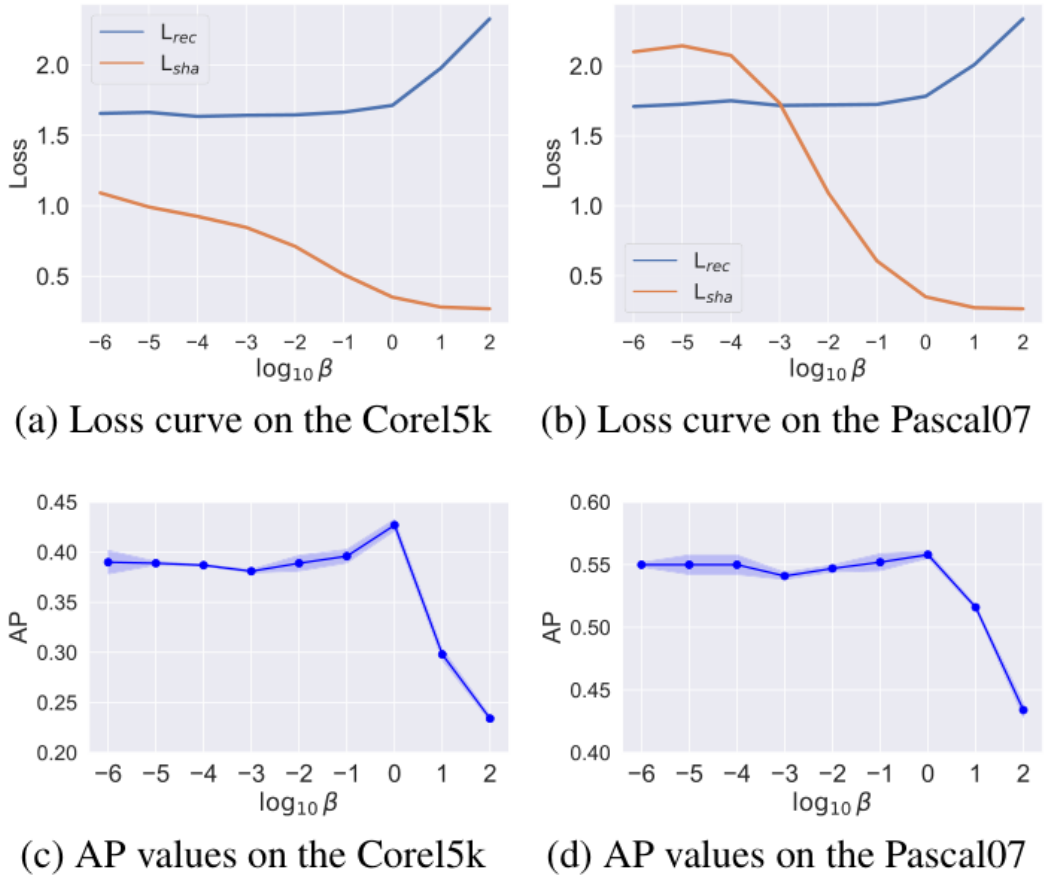
(a) Corel5k (b) Pascal07 (c) MIRFLICKR

4.3. 信息瓶颈建模中的平衡分析

尽管比较实验确认了 SIP 的总体有效性，为进一步探究信息瓶颈原理对该任务的作用机制，我们调整式（7）的超参数 β，研究各组成部分对跨视图共享信息的影响。为方便起见，将式（7）的第一部分记作 L_{rec}，第二部分记作 L_{sha}。图 3 绘制了 Corel5k 和 Pascal07 数据集在一半视图和标签可用时，采用相同训练轮数得到的 AP 及两项损失随 β 变化的曲线。

图 3 显示出清楚的趋势：随着 β 增大，L_{rec} 逐渐增加，而 L_{sha} 逐渐减小。回顾 L_{IB} 的两个组成部分，第一项负责保证跨视图表示 z 与原始数据相关；第二项负责约束所学 z 尽可能仅包含可用视图的共享信息。β 较小时，模型学到的跨视图表示包含大量视图非共享信息，这对重构原始数据十分有利。逐渐增大 β，可以有效增加 z 中共享信息的比例，因而降低 L_{sha}。β 过大时，模型过分关注减少 z 中的非共享信息，导致 z 难以保留足够的重构信息；这对应图 3a 和 3b 中 β 大于 10^0 后 L_{rec} 的突然上升。结合图 3c、3d 可知，β 为 10^0 时，模型在最小化重构损失与最大化共享信息占比之间达到平衡，从而获得最佳性能。

图 3：不同信息平衡参数 β 对损失与 AP 的影响。（a）Corel5k 上的损失曲线；（b）Pascal07 上的损失曲线；（c）Corel5k 上的 AP；（d）Pascal07 上的 AP。横轴为 $\log_{10}\beta$，Loss 为损失，蓝色区域表示标准差。

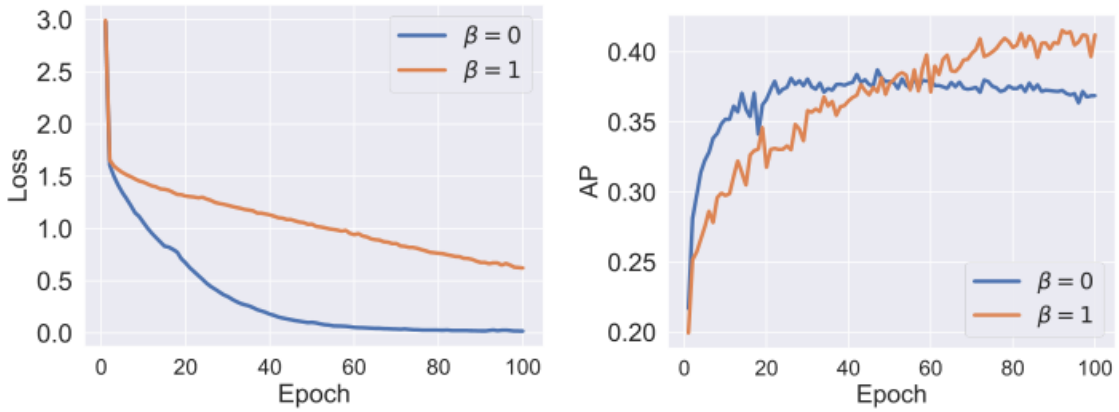


4.4. 挖掘共享信息的分析

第 4.3 节讨论了信息瓶颈方法中压缩信息与保持信息的平衡。这里，我们尝试移除共享信息学习，观察模型训练过程中发生的变化。具体而言，训练时分别把 β 设为 0 和 1，随后在每轮训练后记录训练集交叉熵损失和测试集 AP，以分析 β 对分类性能的影响。图 4 给出 Corel5k 在视图和标签缺失率均为 50% 时的实验结果。

从图中可见，与不压缩信息相比，学习紧凑共享信息使模型在训练阶段的分类损失收敛更慢。不过，尽管非共享冗余信息加速了对训练集的拟合，却在测试集上表现出明显过拟合。这一现象支持我们的观点：学习共享信息能够提高模型提取高层语义信息的能力。

图 4：挖掘共享信息对 SIP 训练的影响。 Corel5k 中已知视图和标签均为 50%。（a）训练集交叉熵；（b）测试集 AP。Epoch 为训练轮次，Loss 为损失；两条曲线分别对应 β=0 和 β=1。



(a) Cross entropy on training set　　(b) AP values of test set

4.5. 消融研究

为评价 SIP 各组成部分的有效性，我们在 Corel5k 和 Pascal07 两个数据库上进行大量消融实验，视图和标签可用率均设为 50%。所考察的目标函数部分为 L_{IB} 与 L_{PA}。对 L_{IB}，我们将其两项分开进行消融实验；原文此处写作 $L_{IB} = L_{sha} + \beta L_{rec}$。结果列于表 2。可以看到，$L_{IB}$ 的两个组成部分均对模型性能作出显著贡献。对于不同数据库，L_{sha} 和 L_{rec} 的影响不同，因为在保持有效信息平衡的同时利用共享信息的难度不同。另外，一个有趣现象是：移除 L_{rec} 后，增加 L_{sha} 并不会提高性能，反而导致性能显著下降。这是因为，在不保证有效信息的前提下压缩共享信息，会导致 z 缺乏足够的预测信息。

【译注：本节上述分解式中 β 的位置与式（7）及第 4.3 节命名不一致；这里保留原文并提示该记号问题。】

表 2：两个数据集上视图缺失率和标签缺失率均为 50% 时的消融结果。 w/o 表示“去除”；L_{sha} 和 L_{rec} 表示 L_{IB} 的两个项。Method 为方法。各项指标含义与表 1 相同。

Method	Corel5k						Pascal07					
	AP	1-HL	1-RL	AUC	1-OE	1-Cov	AP	1-HL	1-RL	AUC	1-OE	1-Cov
SIP w/o $\mathcal{L}_{sha}$ $\mathcal{L}_{rec}$ $\mathcal{L}_{PA}$	0.345	0.987	0.874	0.877	0.423	0.729	0.535	0.931	0.813	0.836	0.454	0.763
SIP w/o $\mathcal{L}_{sha}$ $\mathcal{L}_{PA}$	0.383	0.987	0.898	0.901	0.454	0.761	0.547	0.929	0.825	0.847	0.464	0.777
SIP w/o $\mathcal{L}_{rec}$ $\mathcal{L}_{PA}$	0.387	0.988	0.873	0.876	0.469	0.726	0.511	0.931	0.786	0.813	0.440	0.736
SIP w/o $\mathcal{L}_{PA}$	0.415	0.987	0.912	0.912	0.487	0.790	0.549	0.931	0.826	0.847	0.461	0.778
SIP w/o $\mathcal{L}_{rec}$	0.257	0.987	0.853	0.855	0.290	0.678	0.516	0.931	0.792	0.817	0.443	0.742
SIP w/o $\mathcal{L}_{sha}$	0.383	0.987	0.898	0.900	0.467	0.762	0.550	0.930	0.827	0.848	0.463	0.780
SIP	0.418	0.988	0.911	0.913	0.489	0.787	0.555	0.931	0.830	0.850	0.464	0.783

5. 结论

本文假设，视图之间的共享信息涵盖所有跨视图共性，包括最高层次的语义不变性；与语义目标相关的描述在不同视图之间应表现出唯一性。基于这一假设，我们针对 PMvMLC 任务提出通用语义不变性学习方法 SIP，其对视图缺失和标签不完整具有良好兼容性。该方法将多视图多标签学习问题分为跨视图表示学习与多标签原型学习两部分。首先，基于共享信息能够为语义任务预测提供充分条件的思想，我

们利用信息瓶颈理论学习有效信息，同时最小化跨视图表示中的非共享信息，从而最大化全部视图间的共享信息。此外，我们尝试利用数据潜在表示驱动标签原型学习，显式建模标签相关性。最后，通过广泛实验验证方法有效性，并深入讨论了方法成功的关键：在提取多视图信息与压缩共享信息之间取得平衡。

致谢

本工作部分受到国家自然科学基金（项目编号 62372136、62301621）以及广东省基础与应用基础研究基金（项目编号 2024A1515030213）的支持。

影响声明

本文工作的目标是推动机器学习领域发展。我们的工作可能带来多种社会影响，但我们认为没有需要在此特别强调的影响。

参考文献

以下完整保留原文参考文献信息与原语，供检索核对。

1. Bai, J., Kong, S., and Gomes, C. P. Gaussian mixture variational autoencoder with contrastive learning for multilabel classification. In International Conference on Machine Learning, pp. 1383–1398. PMLR, 2022.

2. Castrejon, L., Aytar, Y., Vondrick, C., Pirsiavash, H., and Torralba, A. Learning aligned cross-modal representations from weakly aligned data. In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 2940–2949, 2016.

3. Duygulu, P., Barnard, K., de Freitas, J. F., and Forsyth, D. A. Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary. In European Conference on Computer Vision, pp. 97–112, 2002.

4. Everingham, M., Van Gool, L., Williams, C. K., Winn, J., and Zisserman, A. The pascal visual object classes (voc) challenge. International journal of computer vision, 88: 303–308, 2009.

5. Federici, M., Dutta, A., Forré, P., Kushman, N., and Akata, Z. Learning robust representations via multiview information bottleneck. In International Conference on Learning Representations, 2020. URL https://openreview.net/forum?id=B1xwcyHFDr.

6. Hang, J.-Y. and Zhang, M.-L. Collaborative learning of label semantics and deep label-specific features for multi-label classification. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(12):9860–9871, 2021.

7. Henning, M., Thomas, D., et al. The iapr benchmark: Anew evaluation resource for visual information systems. In International Conference on Language Resources and Evaluation, pp. 1–11, 2006.

8. Hinton, G. E. Training products of experts by minimizing contrastive divergence. Neural computation, 14(8):1771– 1800, 2002.

9. Huiskes, M. J. and Lew, M. S. The mir flickr retrieval evaluation. In ACM international conference on Multimedia information retrieval, pp. 39–43, 2008.

10. Hwang, H., Kim, G.-H., Hong, S., and Kim, K.-E. Multiview representation learning via total correlation objective. Advances in Neural Information Processing Systems, 34:12194–12207, 2021.

11. Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., and Krishnan, D. Supervised contrastive learning. Advances in neural information processing systems, 33:18661–18673, 2020.

12. Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), Proceedings of the 17th International Conference on Machine Learning (ICML 2000), pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.

13. Lee, C. and Van der Schaar, M. A variational information bottleneck approach to multi-omics data integration. In International Conference on Artificial Intelligence and Statistics, pp. 1513–1521. PMLR, 2021.

14. Li, X. and Chen, S. A concise yet effective model for nonaligned incomplete multi-view and missing multi-label learning. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(10):5918–5932, 2022.

15. Liu, C., Wu, Z., Wen, J., Xu, Y., and Huang, C. Localized sparse incomplete multi-view clustering. IEEE Transactions on Multimedia, pp. 5539–5551, 2022.

16. Liu, C., Wen, J., Luo, X., Huang, C., Wu, Z., and Xu, Y. Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8807–8815, 2023a.

17. Liu, C., Wen, J., Luo, X., and Xu, Y. Incomplete multiview multi-label learning via label-guided masked view- and category-aware transformers. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8816–8824, 2023b.

18. Liu, C., Wen, J., Wu, Z., Luo, X., Huang, C., and Xu, Y. Information recovery-driven deep incomplete multiview clustering network. IEEE Transactions on Neural Networks and Learning Systems, pp. 1–11, 2023c.

19. Liu, C., Wen, J., Liu, Y., Huang, C., Wu, Z., Luo, X., and Xu, Y. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. Advances in Neural Information Processing Systems, 36, 2024.

20. Liu, J., Liu, X., Yang, Y., Liao, Q., and Xia, Y. Contrastive multi-view kernel learning. 45(8):9552–9566, 2023d.

21. Liu, Y., Wang, J., Huang, C., Wang, Y., and Xu, Y. Cigar: Cross-modality graph reasoning for domain adaptive object detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 23776–23786, 2023e.

22. Liu, Y., Wang, J., Xiao, L., Liu, C., Wu, Z., and Xu, Y. Foregroundness-aware task disentanglement and self-paced curriculum learning for domain adaptive object detection. IEEE Transactions on Neural Networks and Learning Systems, pp. 1–12, 2023f. doi: 10.1109/TNNLS.2023.3331778.

23. Luo, X., Pu, Z., Xu, Y., Wong, W. K., Su, J., Dou, X., Ye, B., Hu, J., and Mou, L. Mvdrnet: Multi-view diabetic retinopathy detection by combining dcnns and attention mechanisms. Pattern Recognition, 120:108104, 2021.

24. Luo, X., Liu, C., Wong, W., Wen, J., Jin, X., and Xu, Y. Mvcinn: multi-view diabetic retinopathy detection using a deep cross-interaction neural network. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pp. 8993–9001, 2023.

25. Ma, Q., Yuan, C., Zhou, W., and Hu, S. Label-specific dual graph neural network for multi-label text classification. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), pp. 3855–3864, 2021.

26. Ma, Z. and Chen, S. Expand globally, shrink locally: Discriminant multi-label learning with missing labels. Pattern Recognition, 111:107675, 2021.

27. Tan, Q., Yu, G., Domeniconi, C., and et al. Incomplete multi-view weak-label learning. In Ijcai, pp. 2703–2709, 2018.

28. Von Ahn, L. and Dabbish, L. Labeling images with a computer game. In SIGCHI conference on Human factors in computing systems, pp. 319–326, 2004.

29. Wang, Q., Tao, Z., Gao, Q., and Jiao, L. Multi-view subspace clustering via structured multi-pathway network. IEEE Transactions on Neural Networks and Learning Systems, 2022.

30. Wang, Q., Tao, Z., Xia, W., Gao, Q., Cao, X., and Jiao, L. Adversarial multiview clustering networks with adaptive fusion. IEEE transactions on neural networks and learning systems, 34:7635–7647, 2023.

31. Wen, J., Liu, C., Deng, S., Liu, Y., Fei, L., Yan, K., and Xu, Y. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views. IEEE Transactions on Neural Networks and Learning Systems, 2023.

32. Wu, M. and Goodman, N. Multimodal generative models for scalable weakly-supervised learning. Advances in neural information processing systems, 31, 2018.

33. Xiao, Y., Chen, J., Liu, B., Zhao, L., Kong, X., and Hao, Z. A new multi-view multi-label model with privileged information learning. Information Sciences, 656:119911, 2024.

34. Xu, J., Tang, H., Ren, Y., Peng, L., Zhu, X., and He, L. Multi-level feature learning for contrastive multi-view clustering. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 16051– 16060, 2022.

35. Yeh, C.-K., Wu, W.-C., Ko, W.-J., and Wang, Y.-C. F. Learning deep latent space for multi-label classification. In AAAI Conference on Artificial Intelligence, volume 31, 2017.

36. You, R., Guo, Z., Cui, L., Long, X., Bao, Y., and Wen, S. Cross-modality attention with semantic graph embedding for multi-label classification. In Proceedings of the AAAI conference on artificial intelligence, volume 34, pp. 12709–12716, 2020.

37. Zeng, P., Yang, M., Lu, Y., Zhang, C., Hu, P., and Peng, X. Semantic invariant multi-view clustering with fully incomplete information. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023.

38. Zhao, D., Gao, Q., Lu, Y., Sun, D., and Cheng, Y. Consistency and diversity neural network multi-view multi-label learning. Knowledge-Based Systems, 218:106841, 2021.

39. Zhao, D., Gao, Q., Lu, Y., and Sun, D. Non-aligned multiview multi-label classification via learning view-specific labels. IEEE Transactions on Multimedia, 2022.

40. Zhu, Y., Kwok, J. T., and Zhou, Z.-H. Multi-label learning with global and local label correlation. IEEE Transactions on Knowledge and Data Engineering, 30(6):1081–1094, 2017.

附录 A. 共享信息学习模型的完整推导

本节给出模型（2）的详细推导:

$$\max \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} (I(\mathbf{x}^{(v)}; \mathbf{z}) - \beta I(\{\bar{\mathbf{x}}\}; \mathbf{z} | \mathbf{x}^{(v)})) \tag{14}$$

对于模型（2）的前一项，有:

$$
\begin{aligned}
& I(\mathbf{x}^{(v)};\mathbf{z}) \\
=& \int\int p(\mathbf{x}^{(v)},\mathbf{z}) \log \frac{p(\mathbf{x}^{(v)}|\mathbf{z})}{p(\mathbf{x}^{(v)})} d\mathbf{x}^{(v)} d\mathbf{z} \\
=& \Big[\int\int p(\mathbf{x}^{(v)},\mathbf{z}) \log p(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} + \\
& \int p(\mathbf{z}|\mathbf{x}^{(v)}) \int p(\mathbf{x}^{(v)}) \log \frac{1}{p(\mathbf{x}^{(v)})} d\mathbf{x}^{(v)} d\mathbf{z} \Big] \\
=& \Big[\int\int p(\mathbf{x}^{(v)},\mathbf{z}) \log p(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} + H(\mathbf{x}^{(v)}) \Big]
\end{aligned}
\tag{15}
$$

由于信息熵 $H(x^{(v)}) \geq 0$，有:

$$
\begin{aligned}
& I(\mathbf{x}^{(v)};\mathbf{z}) \\
\geq & \int\int p(\mathbf{x}^{(v)},\mathbf{z}) \log p(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} \\
= & \int p(\mathbf{x}^{(v)}) \int p(\mathbf{z}|\mathbf{x}^{(v)}) \log q^{v}(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} + \\
& \int p(\mathbf{z}) \int p(\mathbf{x}^{(v)}|\mathbf{z}) \log \frac{p(\mathbf{x}^{(v)}|\mathbf{z})}{q^{v}(\mathbf{x}^{(v)}|\mathbf{z})} d\mathbf{x}^{(v)} d\mathbf{z} \\
= & \int p(\mathbf{x}^{(v)}) \int p(\mathbf{z}|\mathbf{x}^{(v)}) \log q^{v}(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} + \\
& \int p(\mathbf{z}) D_{KL}(p(\mathbf{x}^{(v)}|\mathbf{z}) \| q^{v}(\mathbf{x}^{(v)}|\mathbf{z})) d\mathbf{x}^{(v)} d\mathbf{z}
\end{aligned}
\tag{16}
$$

由于 $D_{KL}\big(p(x^{(v)} \mid z) \parallel q(x^{(v)} \mid z)\big) \geq 0$，可得:

$$
\begin{aligned}
& I(\mathbf{x}^{(v)};\mathbf{z}) \\
\geq & \int p(\mathbf{x}^{(v)}) \int p(\mathbf{z}|\mathbf{x}^{(v)}) \log q^{v}(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} \\
= & \int\int p(\mathbf{x}^{(v)},\mathbf{z}) \log q^{v}(\mathbf{x}^{(v)}|\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z}
\end{aligned}
\tag{17}
$$

此外，有:

$$
\begin{aligned}
\int\int p(\mathbf{x}^{(v)},\mathbf{z}) d\mathbf{x}^{(v)} d\mathbf{z} &= \int\int\int p(\mathbf{x}^{(v)},\{\bar{\mathbf{x}}\},\mathbf{z}) d\mathbf{x}^{(v)} d\{\bar{\mathbf{x}}\} d\mathbf{z} \\
&= \int\int p(\{\mathbf{x}\},\mathbf{z}) d\{\mathbf{x}\} d\mathbf{z}
\end{aligned}
\tag{18}
$$

将式（18）代入式（17），得到:

$$
\begin{aligned}
& I(\mathbf{x}^{(v)};\mathbf{z}) \\
\geq & \int\int p(\{\mathbf{x}\},\mathbf{z})\log q^{v}(\mathbf{x}^{(v)}|\mathbf{z})d\{\mathbf{x}\}d\mathbf{z} \\
= & \int p(\{\mathbf{x}\})\int p(\mathbf{z}|\{\mathbf{x}\})\log q^{v}(\mathbf{x}^{(v)}|\mathbf{z})d\{\mathbf{x}\}d\mathbf{z} \\
= & \mathbb{E}_{\mathbf{x}\sim p(\{\mathbf{x}\})}[\int p(\mathbf{z}|\{\mathbf{x}\})\log q^{v}(\mathbf{x}^{(v)}|\mathbf{z})d\mathbf{z}]
\end{aligned}
\tag{19}
$$

对于模型（2）的后一项，有：

$$
\begin{aligned}
& I(\{\bar{\mathbf{x}}\};\mathbf{z}|\mathbf{x}^{(v)}) \\
= & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\{\mathbf{x}\},\mathbf{z})p(\mathbf{x}^{(v)})}{p(\{\mathbf{x}\})p(\mathbf{z},\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z} \\
= & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\mathbf{z}|\{\{\mathbf{x}\}\})}{p(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z} \\
= & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\mathbf{z}|\{\mathbf{x}\})}{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z}+ \\
& \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z} \\
= & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\mathbf{z}|\{\mathbf{x}\})}{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z}+ \\
& \int p(\{\mathbf{x}\})\int p(\mathbf{z}|\{\mathbf{x}\})\log\frac{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z} \\
= & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\mathbf{z}|\{\mathbf{x}\})}{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z}+ \\
& \int p(\mathbf{x}^{(v)})\int p(\mathbf{z}|\mathbf{x}^{(v)})\log\frac{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)})}d\mathbf{x}^{(v)}d\mathbf{z}
\end{aligned}
\tag{20}
$$

由于：

$$
\begin{aligned}
& \int p(\mathbf{x}^{(v)})\int p(\mathbf{z}|\mathbf{x}^{(v)})\log\frac{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}{p(\mathbf{z}|\mathbf{x}^{(v)})}d\mathbf{x}^{(v)}d\mathbf{z} \\
= & -\int p(\mathbf{x}^{(v)})D_{KL}(p(\mathbf{z}|\mathbf{x}^{(v)})\|r^{v}(\mathbf{z}|\mathbf{x}^{(v)}))d\mathbf{x}^{(v)}d\mathbf{z} \\
\leq & 0
\end{aligned}
\tag{21}
$$

式（20）有如下上界：

$$
\begin{aligned}
& I(\{\bar{\mathbf{x}}\};\mathbf{z}|\mathbf{x}^{(v)}) \\
\leq & \int\int p(\{\mathbf{x}\},\mathbf{z})\log\frac{p(\mathbf{z}|\{\mathbf{x}\})}{r^{v}(\mathbf{z}|\mathbf{x}^{(v)})}d\{\mathbf{x}\}d\mathbf{z} \\
= & \int p(\{\mathbf{x}\})D_{KL}(p(\mathbf{z}|\{\mathbf{x}\})\|r^{v}(\mathbf{z}|\mathbf{x}^{(v)}))d\{\mathbf{x}\} \\
= & \mathbb{E}_{\{\mathbf{x}\}\sim p(\{\mathbf{x}\})}[D_{KL}(p(\mathbf{z}|\{\mathbf{x}\})\|r^{v}(\mathbf{z}|\mathbf{x}^{(v)}))]
\end{aligned}
\tag{22}
$$

结合式（19）与（22），得到与模型（2）对应的损失函数：

$$\mathcal{L}_{IB} = \frac{1}{|\mathcal{V}|}\sum_{v\in\mathcal{V}}\Big[-\mathbb{E}_{\mathbf{z}\sim p(\mathbf{z}|\{\mathbf{x}\})}\log q^{v}(\mathbf{x}^{(v)}|\mathbf{z}) + \beta D_{KL}(p(\mathbf{z}|\{\mathbf{x}\})\|r^{v}(\mathbf{z}|\mathbf{x}^{(v)}))\Big] \tag{23}$$

【译注：上述积分及微分记号按原公式保留，包括原文式（16）、（21）等处的记号写法；未擅自校正原推导。】

附录 B. PoE 融合与采样

PoE 融合公式如下：

$$\mu_{poe} = \frac{\sum_{v\in\mathcal{V}}\mu_v\frac{1}{\sigma_v^2}}{\sum_{v\in\mathcal{V}}\frac{1}{\sigma_v^2}+1}, \qquad \sigma_{poe}^2 = \frac{1}{\sum_{v\in\mathcal{V}}\frac{1}{\sigma_v^2}+1}, \tag{24}$$

其中 μ_{poe} 和 σ_{poe}^2 分别是多个视图融合后的均值和方差； μ_v 与 σ_v^2 分别表示第 v 个视图的均值和方差。于是 $p(z \mid \{x\}) \sim \mathcal{N}(\mu_{poe}, \sigma_{poe}^2 I)$。

与式（9）一样，从分布 $p(z \mid \{x\})$ 采样 z^0：

$$z^0 = \frac{1}{s}\sum_{d=1}^{s}(\mu_{poe} + \sigma_{poe}\odot\delta^d). \tag{25}$$

附录 C. 五个数据集的统计信息

本节在表 3 中给出实验所用五个数据集的详细信息。

表 3：实验中五个多视图多标签数据集的详细信息。 Dataset 为数据集，#Sample 为样本数，#Label 为标签数，#View 为视图数，#Label/#Sample 为每个样本平均标签数。依次为：Corel5k（4999、260、6、3.40），IAPRTC12（19627、291、6、5.72），ESPGame（20770、268、6、4.69），Pascal07（9963、20、6、1.47），MIRFLICKR（25000、38、6、4.72）。

Dataset	# Sample	# Label	# View	# Label/#Sample
Corel5k	4999	260	6	3.40
IAPRTC12	19627	291	6	5.72
ESPGame	20770	268	6	4.69
Pascal07	9963	20	6	1.47
MIRFLICKR	25000	38	6	4.72

附录 D. 八种比较方法的统计信息

本节在表 4 中给出八种比较方法的详细信息。

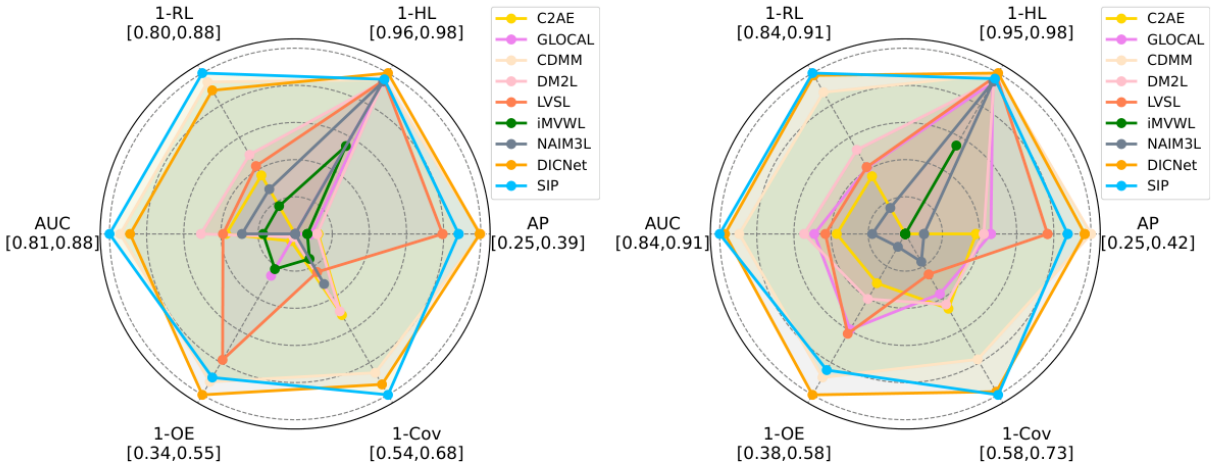
表 4：八种比较方法的简要信息。 Method 为方法，Sources 为发表来源；Multi-view 表示方法是否针对多视图数据设计；Missing-view 和 Missing-label 分别表示其是否兼容缺失视图和部分标签。勾号表示支持，叉号表示不支持。C2AE、GLOCAL、DM2L 仅支持部分标签；CDMM、LVSL 支持多视图但不支持视图或标签缺失；iMVWL、NAIM3L、DICNet 三项均支持。来源按原表保留。

Method	Sources	Multi-view	Missing-view	Missing-label
C2AE	AAAI '17	✗	✗	✓
GLOCAL	TKDE '17	✗	✗	✓
CDMM	KBS '20	✓	✗	✗
DM2L	PR '21	✗	✗	✓
LVSL	TMM '22	✓	✗	✗
iMVWL	IJCAI '18	✓	✓	✓
NAIM3L	TPAMI '22	✓	✓	✓
DICNet	AAAI '23	✓	✓	✓

附录 E. 五个完整数据集上的补充实验结果

本节在图 5 中展示九种方法在另外两个无任何视图和标签缺失的数据集上的结果。

图 5：九种方法在两个无缺失视图或标签的完整数据集上的实验结果。 雷达图中心表示最差结果，顶点表示最佳结果，共考虑六项评价指标。子图（a）ESPGame；（b）MIRFLICKR。指标含义与正文相同。



(a) ESPGame　　(b) MIRFLICKR

【译注：附录标题写“五个”，正文说“两个”；图 5b 原文标注为 MIRFLICKR，与图 2c 的数据集名称相同。此处保留原标注，不推测应替换为何数据集。】

附录 F. 实现细节

实验中，所有比较方法的参数均设为其代码或论文推荐的值。对于 SIP，五个数据集均采用批大小 128、潜在特征维数 512、学习率 0.001，并使用随机梯度下降（SGD）优化器训练模型。 z^0 和 l_i^0 的采样次数均设为 10。编码器主要由六个全连接（FC）层组成，最后三层共享参数；解码器主要由三个 FC 层组成。为避免随机性影响，所有方法的实验均重复多次，并在最终结果中报告均值与方差。全部实验均在 Ubuntu 系统、3090 GPU 和 PyTorch 2.1.1 框架上运行。

附录 G. 局限性

尽管该方法已在 PMvMLC 任务上展示有效性，并为利用共享信息进行预测提供启示，仍存在限制其更广泛应用的局限。一项挑战是评价“共享信息足以支持准确预测”这一假设，尤其是处理模态差异很大的异构多视图数据时，例如文本、图像和音频。此外，尽管已有许多技术用于估计信息容量，采用更精细的估计器仍有望提高准确性。