# 半监督三重稳健归纳迁移学习

**Semi-supervised Triply Robust Inductive Transfer Learning · 非官方中文全文译文**

Tianxi Cai[1,2,*]，Mengyan Li[3,*]，Molei Liu[4,*]。

1. 哈佛大学陈曾熙公共卫生学院生物统计系。
2. 哈佛医学院生物医学信息学系。
3. 本特利大学数学科学系。
4. 哈佛大学梅尔曼公共卫生学院生物统计系。

作者按姓氏字母顺序排列。联系邮箱：mengyanli@bentley.edu。

**来源、许可与翻译说明。** 原文为 arXiv:2209.04977v2，版本日期为2024年10月22日，作者为 Tianxi Cai、Mengyan Li、Molei Liu。原文及本中文译文采用 Creative Commons 署名4.0国际许可（CC BY 4.0）。本译文由 dot 辅助制作，属于中文翻译及重新排版，非作者审定稿，不表示作者或 arXiv 对译文的认可。原图、表格和独立陈列公式以清晰裁图保留，图表标题、说明和算法步骤另译为中文；图表内方法名、变量及数值保持原样。行内数学符号重新排版。原文可能的拼写或记号不一致在必要处以译注注明，不作无声修正。

**覆盖范围。** 本译文完整覆盖上述精确版本 PDF 的35页，包括摘要、第1至6节、算法1、公式(1)至(9)、定理1至3、备注1至5、表1至4、图1、致谢、披露声明及全部参考文献。该 PDF 和其官方 TeX 包均未包含正文所引用的外部《补充材料》S.1至S.11；相关假设、完整证明及补充实验不在这35页中，故本文件不声称已翻译这些缺失的外部材料。正文中的补充材料引用均按原文保留。

## 摘要

本文提出半监督三重稳健归纳迁移学习（Semi-supervised Triply Robust Inductive transFer LEarning，STRIFLE）方法。该方法整合标签丰富的源总体与标签稀缺的目标总体中的异质数据，同时利用大量无标签数据，以提高目标总体中的学习精度。具体而言，我们考虑高维协变量偏移情形，采用密度比模型和插补模型这两个干扰模型，有效结合迁移学习与替代变量辅助的半监督学习策略，实现三重稳健性。STRIFLE 假设目标总体与源总体在同时给定替代特征 $\mathbf{S}$ 和预测变量 $\mathbf{X}$ 时，结局 $Y$ 的条件分布相同；但由于 $\mathbf{S}$ 和 $\mathbf{X}$ 可能存在协变量偏移，允许两个总体中 $Y \mid \mathbf{X}$ 的真实底层模型不同。与双重稳健性不同，即使两个干扰模型均误设，或者两个总体中 $Y \mid \mathbf{S}, \mathbf{X}$ 的分布不同，只要偏移后的源总体与目标总体足够相似，三重稳健的 STRIFLE 估计量仍能部分利用源总体。此外，在额外计入可迁移性检测产生的误差项后，可以保证其不劣于仅使用目标总体的替代变量辅助半监督估计量。我们从理论上确立这些理想性质，并通过广泛模拟研究验证其有限样本表现。利用与电子健康记录相连接的基因组数据，我们将较大欧洲裔源总体的知识迁移至非裔美国人目标总体，使用 STRIFLE 估计量训练其2型糖尿病多基因风险预测模型。

**关键词：** 协变量偏移；替代变量辅助的半监督学习；高维数据；迁移学习；模型误设；稳健性。

# 1 引言

## 1.1 背景

精准医疗方法对临床照护至关重要（Ashley，2016）。对临床结局和治疗反应进行可靠而精确的个体化预测，是成功管理疾病的基础。对于不太可能对标准疗法产生反应的患者，应考虑更积极的治疗；对于预后良好的患者，则可考虑毒性更低的方案。遗传学进展以及电子健康记录（EHR）日益广泛的可用性，为建立准确的个体化风险预测模型带来更多机会。将这些模型用于床旁诊疗，使精确的个体化患者照护成为临床现实（Hodson，2016）。

然而，个体化风险预测建模在实践中面临若干挑战。第一项挑战是不同亚总体之间的异质性和不平衡。当前普遍采用的预测建模方案应用于异质且含噪的 EHR 和基因组数据时，往往表现出偏差，倾向于优先追求总体准确率，而牺牲代表性不足群体的表征。这会因数据完整程度不一、分布差异和编码偏差而造成性能差距。例如，全基因组关联研究（GWAS）的参与者中约79%具有欧洲血统。这种不平衡，加上不同祖源总体之间的遗传差异，使多基因风险评分在欧洲裔群体中的准确性达到其他群体的数倍（West 等，2017；Ferryman 和 Pitcan，2018；Martin 等，2019）。异质性的存在以及代表性不足群体的相对较小样本量，凸显出对稳健迁移学习技术的需求，以有效提高这些亚总体中的预测精度，并实现精准医疗中的公平性。

第二项挑战源于缺少训练监督预测模型所需的临床结局直接观测。准确的临床结局数据通常需要大量人工病历审阅，难以规模化。诊断编码等替代来源容易获取，却缺乏准确性。要高效利用有限的标签数据和不完美的替代变量，关键是引入**半监督（SS）学习**策略，融合有标签与无标签观测中的信息。第三项挑战来自特征空间的高维性：遗传标记等候选预测变量的数量，以及来自 EHR 的候选替代变量数量，都可能很大。

近年来，无论低维还是高维情形，迁移学习和半监督学习均取得了很大进展。但是，在目标标签数据很少时，同时利用源总体和目标总体大量无标签数据的半监督稳健迁移学习研究仍然稀缺。我们希望通过开发 STRIFLE 方法填补这一空白，有效利用这种数据结构，改善代表性不足目标总体中风险建模的估计和预测精度。具体而言，我们考虑协变量偏移情形：预测变量 $\mathbf{X}$ 与标签的替代变量 $\mathbf{S}$ 在目标总体和源总体中可以具有不同分布。我们假设给定 $\mathbf{X}$ 和 $\mathbf{S}$ 后，两个总体中结局 $Y$ 的条件分布相同；但允许仅给定 $\mathbf{X}$ 时，结局 $Y$ 的条件分布不同。在 EHR 应用中，由于 $\mathbf{S}$ 对响应往往具有很强的预测能力，与 $Y \mid \mathbf{X}$ 相比，$Y \mid \mathbf{X}, \mathbf{S}$ 在不同总体间通常更一致。两个总体都分别有少量有标签观测和大量无标签观测。此外，候选预测变量和替代变量的数量可以远超有标签观测数量。

## 1.2 相关文献与本文贡献

我们的工作与统计学习领域近年的几条研究路线密切相关。本节分别介绍这些路线，并结合现有文献概述我们的方法创新与贡献。

**替代变量辅助的半监督学习**。 近年来，大量研究探讨如何利用大量无标签数据，在有标签数据较少时提高估计和预测精度（例如 Zhu，2005；Chakrabortty 和 Cai，2018；Gronsbell 等，2022）。此外，在生物医学和 EHR 研究中，无标签观测往往具备对疾病状态高度有预测力的替代变量，例如诊断编码、药物处方和实验室检查。为提高学习精度，Hou 等（2021）提出稳健的替代变量辅助半监督（SAS）方法，通过稀疏的工作插补模型，联合使用候选预测变量（如遗传变异）和 EHR 替代特征，

对未观测结局（如疾病状态）进行插补。Zhang 等（2022）提出一种半监督方法，将高维稀疏估计量向从带替代变量的无标签数据中导出的方向收缩，从而自适应纳入 EHR 替代变量中的先验知识。但是，这些现有方法都不能处理源总体与目标总体之间的协变量偏移，因而可能导致目标参数估计有偏或效率低下。

**协变量偏移校正**。 训练数据（源）与测试数据（目标）之间的协变量分布偏移近年来受到广泛研究。然而，重要性加权方法（例如 Huang 等，2006）对于密度比模型误设或估计误差过大并不稳健。近年来，人们开发了双重稳健的协变量偏移校正方法（例如 Liu 等，2020；Zhang 等，2021；Zhou 等，2022）。受半参数理论启发，这些方法引入 $Y$ 的插补模型，以增广重要性加权估计方程。当密度比模型或插补模型中任意一个正确设定时，所得估计量就是有效的。这种策略的主要局限在于，它完全依赖源总体的标签，当两个模型均误设时无法给出有效估计。如果 $Y$ 的条件模型在源总体和目标总体之间发生变化，这一局限会进一步加剧。在本文考虑的情形下，由于目标总体中可获得少量有标签数据，因此存在克服该局限的空间。

**知识迁移回归**。 近期，Bastani（2021）、Li 等（2022）、Tian 和 Feng（2022）及 Li 等（2023）提出 trans-Lasso：它是一种采用 Lasso 惩罚（Tibshirani，1996）、适用于高维线性模型及广义线性模型（GLM）的迁移学习方法，通过自适应借用潜在可迁移源数据的信息，提高目标总体中的学习精度。其核心思想是，通过 Lasso 惩罚，将用源标签数据学习到的源估计量向目标参数收缩。基于 trans-Lasso 框架，Li 等（2021）提出联邦迁移学习方法，整合不同总体和多家医疗机构的异质数据。与本文不同，已有 trans-Lasso 方法既不校正源数据与目标数据间的协变量偏移，也不纳入具有替代变量的目标无标签观测。我们的理论和数值研究将验证，这在本文情形下可能造成很大的效率损失。

**半监督迁移学习**。 我们提出的 STRIFLE 方法还与半监督迁移学习文献有关：在这类研究中，目标数据含有丰富的无标签样本以辅助迁移学习，有时源数据也是如此。例如，Abuduweili 等（2021）提出面向深度学习的自适应一致性正则化方法，其中包含两个惩罚项，分别确保自适应知识迁移，以及有标签和无标签目标样本之间的表示一致性。Jakubovitz 等（2023）通过在大量目标无标签数据上引入基于互信息（或 Lautum 信息）的正则化项，提高神经网络（NN）的可迁移性。在与本文更接近的统计学习背景下，Zhang 等（2023a）针对存在协变量偏移的目标总体均值估计，开发了双重稳健半监督方法。Zhang 等（2023b）进一步将该框架推广到因果效应的半监督迁移学习。然而，这条研究路线尚未解决迁移学习的一些主要挑战，包括目标模型的模型偏移和高维性，也未充分处理参数化干扰模型可能发生的误设。

**本文贡献**。 我们提出的 STRIFLE 方法突出之处在于，它既由替代变量辅助，又由模型辅助。借助具有预测能力的替代变量，我们在矩约束下使用工作性干扰插补模型，对目标无标签观测的结局进行插补。为整合标签丰富的源总体，我们在估计插补模型时引入一个工作性干扰密度比模型，并将其嵌入带惩罚的迁移学习过程。这一新颖的嵌入式密度比模型使用两个总体的无标签观测进行估计，有望提高源总体的可迁移性。

简单拼接迁移学习和半监督学习容易受到模型误设影响，实践中可能得出错误结果；与之不同，STRIFLE 以两个干扰模型为桥梁，统一迁移学习和 SAS 技术，实现“三重稳健性”。文献中的“双重稳健性”是在两个干扰模型至少一个设定正确时获得稳健性；在此基础上，我们利用少量可用的目标标签数据，通过偏差校正步骤与可迁移性检测过程，引入第三层稳健性。三重稳健性有三个关键特征。首先，它超越双重稳健性，对干扰模型误设具有更强韧性：即使两个干扰模型均误设，只要根据工作密度比模型偏移后的源总体与目标总体足够相似，STRIFLE 仍能部分利用源标签数据来提高统计效率。其

次，即使给定 $\mathbf{S}$ 和 $\mathbf{X}$ 后 $Y$ 的条件分布在总体间相同这一假设可能被违反，只要偏移后的源插补模型与目标插补模型足够相似，方法仍然稳健。第三，STRIFLE 是一种自适应迁移方法：在计入可迁移性检测带来的附加误差项后，可以保证其不劣于仅使用目标总体的 SAS 估计量。此外，我们的框架不限于 Lasso 惩罚，还允许 SCAD（Fan 和 Li，2001）、MCP（Zhang，2010）等非凸惩罚。据我们所知，这是首个在借用源总体信息的同时利用两个总体的无标签观测、从而达到更高稳健性水平的工作。

### 1.3 论文结构

第2节介绍问题设定、STRIFLE 算法概览和详细方法；第3节建立 STRIFLE 估计量的理论性质；第4节通过模拟研究考察其有限样本表现；第5节以欧洲裔总体为源，基于单核苷酸多态性（SNP）和 EHR 特征，应用 STRIFLE 算法为非裔美国人（AA）总体建立2型糖尿病（T2D）多基因风险预测模型；第6节以讨论结束全文。

## 2 方法

### 2.1 问题设定

对第 $i$ 个观测，$Y_i \in \mathbb{R}$ 表示结局变量，$\mathbf{X}_i \in \mathbb{R}^p$ 表示 $p$ 维候选预测变量，其首元素为截距项；$\mathbf{S}_i \in \mathbb{R}^q$ 表示 $Y_i$ 的 $q$ 维替代变量。记 $\mathcal{T}$ 和 $\mathcal{S}$ 分别为目标总体和源总体；$L$ 和 $U$ 分别标识有标签及无标签子集；$\mathcal{I}_{\iota,\mathrm{J}}$ 表示目标/源、有标签/无标签总体中观测的索引集，其中 $\iota \in \{\mathcal{T}, \mathcal{S}\}$，$\mathrm{J} \in \{L, U\}$。假设仅在有标签子集中观测到 $Y$，而有标签和无标签数据中均可观测到 $\mathbf{Z} = \left(\mathbf{X}^\top, \mathbf{S}^\top\right)^\top$。记目标和源总体的观测数据分别为 $\mathcal{D}_{\mathcal{T}} = \mathcal{D}_{\mathcal{T},L} \cup \mathcal{D}_{\mathcal{T},U}$ 和 $\mathcal{D}_{\mathcal{S}} = \mathcal{D}_{\mathcal{S},L} \cup \mathcal{D}_{\mathcal{S},U}$，其中

$$\mathcal{D}_{\iota,L} = \{\left(Y_i, \mathbf{Z}_i^\top\right)^\top : i \in \mathcal{I}_{\iota,L}\}, \qquad \mathcal{D}_{\iota,U} = \{\mathbf{Z}_i : i \in \mathcal{I}_{\iota,U}\}, \qquad \iota = \mathcal{T}, \mathcal{S}.$$

令 $|\mathcal{I}_{\mathcal{T},L}| = n_{\mathcal{T}}$、$|\mathcal{I}_{\mathcal{T},U}| = N_{\mathcal{T}}$、$|\mathcal{I}_{\mathcal{S},L}| = n_{\mathcal{S}}$、$|\mathcal{I}_{\mathcal{S},U}| = N_{\mathcal{S}}$、$d = p + q$，以及 $n = n_{\mathcal{S}} + n_{\mathcal{T}}$。我们考虑高维情形，其中 $p$ 和 $q$ 随 $n_{\mathcal{T}}$ 增长，而且可以远大于 $n_{\mathcal{T}}$ 和 $n$；允许 $n_{\mathcal{S}}$ 与 $n_{\mathcal{T}}$ 自由变化。尽管本研究主要受半监督背景启发，我们的理论结果也适用于 $N_{\mathcal{T}} \le n_{\mathcal{T}}$ 的情形。

对 $\iota \in \{\mathcal{T}, \mathcal{S}\}$，记 $p_{\mathbf{Z}}^{(\iota)}$、$p_{Y|\mathbf{Z}}^{(\iota)}$、$p_{\mathbf{S}|\mathbf{X}}^{(\iota)}$ 和 $p_{Y|\mathbf{X}}^{(\iota)}$ 分别为总体 $\iota$ 中 $\mathbf{Z}_i$ 的概率密度、给定 $\mathbf{Z}_i$ 后 $Y_i$ 的条件密度、给定 $\mathbf{X}_i$ 后 $\mathbf{S}_i$ 的条件密度，以及给定 $\mathbf{X}_i$ 后 $Y_i$ 的条件密度。本文考虑协变量偏移结构，即假设 $p_{Y|\mathbf{Z}}^{(\mathcal{S})}(y, \mathbf{z}) = p_{Y|\mathbf{Z}}^{(\mathcal{T})}(y, \mathbf{z})$，但允许 $p_{\mathbf{Z}}^{(\mathcal{S})}(\mathbf{z})$ 与 $p_{\mathbf{Z}}^{(\mathcal{T})}(\mathbf{z})$ 不同。具体而言，我们允许 $p_{\mathbf{S}|\mathbf{X}}^{(\mathcal{S})} \neq p_{\mathbf{S}|\mathbf{X}}^{(\mathcal{T})}$，因此 $p_{Y|\mathbf{X}}^{(\mathcal{S})}$ 可以不同于 $p_{Y|\mathbf{X}}^{(\mathcal{T})}$。记 $E_\iota(\cdot)$ 为对总体 $\iota \in \{\mathcal{S}, \mathcal{T}\}$ 的分布取期望。

我们的目标是在工作模型 $E_{\mathcal{T}}\left(Y_i \mid \mathbf{X}_i\right) = g\left(\mathbf{X}_i^\top \boldsymbol{\beta}\right)$ 下，为 $\mathcal{T}$ 中的 $Y \mid \mathbf{X}$ 建立预测模型；其中 $g(\cdot)$ 是已知逆连接函数。具体目标是估计下式的解 $\boldsymbol{\beta}_0 \in \mathbb{R}^p$：

$$E_{\mathcal{T}}[\mathbf{X}_i\{Y_i - g(\mathbf{X}_i^\top \boldsymbol{\beta})\}] = \mathbf{0}. \tag{1}$$

我们允许 $g\left(\mathbf{X}_i^\top \boldsymbol{\beta}\right)$ 对 $E_{\mathcal{T}}\left(Y_i \mid \mathbf{X}_i\right)$ 而言为误设模型，也允许 $\boldsymbol{\beta}_0$ 稠密。虽然 $\mathbf{S}_i$ 可能包含关于 $Y_i$ 的很强信息，式(1)中的结局预测模型并不纳入 $\mathbf{S}_i$。在建立 T2D 多基因风险预测模型这一动机实例中，$Y$ 为 T2D 状态，$\mathbf{S}$ 包含 EHR 特征，例如糖化血红蛋白（HbA1c）检测的记录和二甲双胍处方，$\mathbf{X}$

则包含人口统计学变量及遗传标记。尽管这些替代变量是疾病状态的含噪代理，可以用于插补缺失的 $Y$，但如果预测是在结局 $Y$ 或其含噪代理 $\mathbf{S}$ 确定之前的某个基线时点开展，那么它们并不适合作为预测变量。

## 2.2 STRIFLE 算法概览

首先概述 STRIFLE 流程。为利用无标签数据和替代变量，STRIFLE 在 $Y \mid \mathbf{Z}$ 的工作插补模型 $m(\mathbf{Z}) = E_{\mathcal{T}}(Y \mid \mathbf{Z}) = E_{\mathcal{S}}(Y \mid \mathbf{Z}) = g(\mathbf{Z}^{\mathsf{T}}\theta)$ 下，采用一系列稳健插补策略。对任意拟合插补模型 $\widehat{m}(\mathbf{Z}) = g(\mathbf{Z}^{\mathsf{T}}\widehat{\theta})$，记 $\bar{\theta}$ 为样本量趋于无穷时 $\widehat{\theta}$ 的极限，$\overline{m}(\mathbf{Z}) = g(\mathbf{Z}^{\mathsf{T}}\bar{\theta})$ 为极限插补模型。利用拟合插补模型，构造 $\beta_0$ 的半监督估计量

$$\widehat{\beta}(\widehat{\theta}) = \underset{\beta \in \Omega_\beta}{\operatorname{argmin}} \{\mathcal{L}^{\beta}_{N_{\mathcal{T}}+n_{\mathcal{T}}}(\beta; \widehat{\theta}) + p_{\lambda_\beta}(\beta)\},$$

其中

$$\mathcal{L}^{\boldsymbol{\beta}}_{N_{\mathcal{T}}+n_{\mathcal{T}}}(\boldsymbol{\beta}; \widehat{\boldsymbol{\theta}}) = -\frac{1}{N_{\mathcal{T}}+n_{\mathcal{T}}}\left[\sum_{i \in \mathcal{I}_{\mathcal{T},U}} Q\{g(\mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta}), g(\mathbf{z}_i^{\mathsf{T}}\widehat{\boldsymbol{\theta}})\} + \sum_{i \in \mathcal{I}_{\mathcal{T},L}} Q\{g(\mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta}), y_i\}\right], \qquad (2)$$

$Q(\cdot, \cdot)$ 是去掉离散参数后的对数（准）似然函数，即 $Q\{g(\mathbf{x}_i^{\mathsf{T}}\beta), \widehat{m}(\mathbf{z}_i)\} = \widehat{m}(\mathbf{z}_i)\mathbf{x}_i^{\mathsf{T}}\beta - G(\mathbf{x}_i^{\mathsf{T}}\beta)$，$Q\{g(\mathbf{x}_i^{\mathsf{T}}\beta), y_i\} = y_i\mathbf{x}_i^{\mathsf{T}}\beta - G(\mathbf{x}_i^{\mathsf{T}}\beta)$，$G(u) = \int_0^u g(u')\,du'$。$p_{\lambda_\beta}(\beta)$ 是作用于 $\beta$、调节参数为 $\lambda_\beta$ 的惩罚函数，$\Omega_\beta$ 是 $p$ 维参数空间，其详细定义见第3节。

根据式(1)对 $\beta_0$ 的定义，容易证明，只要满足下式，$\widehat{\beta}$ 就是 $\beta_0$ 的相合估计量：

$$E_{\mathcal{T}}[\mathbf{X}_i\{Y_i - \bar{m}(\mathbf{Z}_i)\}] = \mathbf{0}. \qquad (3)$$

保证 $\widehat{\beta}$ 相合的直接方式，是像 Hou 等（2021）那样，仅依赖目标标签数据估计 $\theta$。但这样会错失利用 $\mathcal{S}$ 中丰富标签数据的机会。在 $p^{(\mathcal{S})}_{Y|\mathbf{Z}} = p^{(\mathcal{T})}_{Y|\mathbf{Z}}$，但 $p^{(\mathcal{S})}_{Y|\mathbf{X}}$ 可以与 $p^{(\mathcal{T})}_{Y|\mathbf{X}}$ 相差很大的协变量偏移情形下，如果估计 $m(\mathbf{z})$ 时能够借用 $\mathcal{S}$ 中的有用信息，就能提高 $\beta_0$ 的学习精度。因此，STRIFLE 算法的核心策略是利用 $\mathcal{S}$ 中的有用信息，对 $\theta$ 进行稳健而高效的估计。

具体而言，我们使用工作密度比模型，以双重稳健的方式提高源数据的可迁移性。注意，当工作插补模型和密度比模型都误设时，$\theta$ 的估计可能不相合。为此，我们使用有限的目标标签数据进行偏差校正。但如果工作模型严重失真，$n_{\mathcal{T}}$ 可能不足以完成充分的偏差校正。为避免负迁移，我们加入可迁移性检测步骤。如果偏移后的源插补模型与目标插补模型差异过大，就不使用源数据。STRIFLE 对 $\theta$ 的估计包含三个关键部分：

1. 拟合工作密度比模型，将 $w(\mathbf{z}) = p^{(\mathcal{T})}_{\mathbf{Z}}(\mathbf{z})/p^{(\mathcal{S})}_{\mathbf{Z}}(\mathbf{z})$ 估计为 $\widehat{w}(\mathbf{z})$。
2. 构造插补参数 $\theta$ 的初始仅目标估计量 $\widehat{\theta}^{(\mathcal{T})}$，并使用 $\mathcal{D}_{\mathcal{T}} \cup \mathcal{D}_{\mathcal{S}}$ 和 $\widehat{w}(\mathbf{z})$ 构造元学习估计量 $\widehat{\theta}^{(\text{meta})}$。
3. 将 $\widehat{\theta}^{(\mathcal{T})}$ 与 $\widehat{\theta}^{(\text{meta})}$ 作凸组合，构造 $\theta$ 的 STRIFLE 估计量 $\widehat{\theta}^{(\text{STRIFLE})}$，以克服潜在负迁移。

最终，$\boldsymbol{\beta}$ 的 STRIFLE 估计量为 $\widehat{\boldsymbol{\beta}}^{(\mathrm{STRIFLE})} = \widehat{\boldsymbol{\beta}}\left(\widehat{\theta}^{(\mathrm{STRIFLE})}\right)$。下面逐一说明各部分。

### 2.3 密度比模型的估计

为提高源总体潜在的可迁移性并高效利用源数据，我们利用两个总体中的大量无标签观测，为 $p_{\mathbf{Z}}^{(\mathcal{T})}(\mathbf{z})/p_{\mathbf{Z}}^{(\mathcal{S})}(\mathbf{z})$ 拟合工作密度比模型：

$$w(\mathbf{z}) = \exp\{\mathbf{f}(\mathbf{z})^{\top}\boldsymbol{\zeta}\}, \tag{4}$$

其中 $\mathbf{f}(\cdot) \in \mathbb{R}^{L}$ 是可用于捕捉非线性效应的基函数向量。式(4)涵盖广泛的模型。$\mathbf{f}(\cdot)$ 可以由与协变量偏移有关的先验知识给出，也可以直接从无标签数据中估计。采用估计基函数 $\widehat{\mathbf{f}}(\mathbf{z})$ 的方法与多种机器学习（ML）技术相兼容。例如，多层神经网络的最后一层是简单的线性分类器（Papyan 等，2020），所以可以使用无标签数据拟合神经网络，并去掉最后一层来获得 $\widehat{\mathbf{f}}(\mathbf{z})$。然而，应认识到，即使使用机器学习方法估计密度比，模型误设和过大误差的挑战依然存在，Dukes 等（2021）对此有讨论。因此，第2.4与2.5节中的偏差校正和可迁移性检测仍有必要。这一问题在很大程度上与机器学习方法可能的非凸性、复杂的调参过程，以及模型复杂度和无标签样本规模的平衡有关。第3节的理论结果是在 $\mathbf{f}(\cdot)$ 已知的假设下推导的。关于 $\widehat{\mathbf{f}}(\mathbf{z})$ 和机器学习方法的进一步讨论见备注1。

关于 $\boldsymbol{\zeta}$ 的估计，有一个关键观察：若 $w(\mathbf{z})$ 正确设定，则对任意可测函数 $\mathbf{h}(\mathbf{z})$，都有 $E_{\mathcal{S}}\{w(\mathbf{Z}_i)\mathbf{h}(\mathbf{Z}_i)\} = E_{\mathcal{T}}\{\mathbf{h}(\mathbf{Z}_i)\}$。本文取 $\mathbf{h}(\mathbf{z}) = \mathbf{f}(\mathbf{z})$，这也是 Tan（2020）以及 Imai 和 Ratkovic（2014）采用的选择。其他 $\mathbf{h}(\mathbf{z})$ 也可用于构造 $\boldsymbol{\zeta}$ 的损失函数，参见补充材料第 S.1 节。我们将总体参数 $\boldsymbol{\zeta}_0$ 定义为

$$E_{\mathcal{S}}\left[\exp\{\mathbf{f}(\mathbf{Z}_i)^{\top}\boldsymbol{\zeta}\}\right] - E_{\mathcal{T}}\{\mathbf{f}(\mathbf{Z}_i)^{\top}\boldsymbol{\zeta}\}$$

的最小化解。可以使用许多标准估计量估计 $\boldsymbol{\zeta}_0$。理论推导不局限于任何特定估计量，只要求其收敛速度满足第3节的假设1。

一种这样的估计量可以写为 $\hat{\boldsymbol{\zeta}} = \operatorname{argmin}_{\boldsymbol{\zeta}\in\Omega_{\boldsymbol{\zeta}}}\{\mathcal{L}_N^{w}(\boldsymbol{\zeta}) + p_{\lambda_{\boldsymbol{\zeta}}}(\boldsymbol{\zeta})\}$，其中

$$\mathcal{L}_N^{w}(\boldsymbol{\zeta}) = N_{\mathcal{S}}^{-1}\sum_{i\in\mathcal{I}_{\mathcal{S},U}}\exp\{\mathbf{f}(\mathbf{z}_i)^{\top}\boldsymbol{\zeta}\} - N_{\mathcal{T}}^{-1}\sum_{i\in\mathcal{I}_{\mathcal{T},U}}\mathbf{f}(\mathbf{z}_i)^{\top}\boldsymbol{\zeta}.$$

$p_{\lambda_{\boldsymbol{\zeta}}}(\boldsymbol{\zeta})$ 是调节参数为 $\lambda_{\boldsymbol{\zeta}}$ 的惩罚函数，$\Omega_{\boldsymbol{\zeta}}$ 是 $\boldsymbol{\zeta}$ 的可行参数空间。可选择岭惩罚、Lasso、SCAD 等常见惩罚函数。此处及下文略微复用记号，以 $p_{\lambda}(\cdot)$ 表示调节参数为 $\lambda$ 的不同类型惩罚函数。补充材料第 S.2 节证明，采用 Lasso 惩罚且 $\Omega_{\boldsymbol{\zeta}} = \mathbb{R}^{L}$ 时得到的 $\hat{\boldsymbol{\zeta}}$ 满足假设1。

### 2.4 插补模型的仅目标学习与元学习

接下来为 $m(\mathbf{z})$ 中的 $\theta$ 构造两个估计量：一个只使用 $\mathcal{D}_{\mathcal{T},L}$，另一个通过元学习组合 $\mathcal{D}_{\mathcal{T}}$ 和 $\mathcal{D}_{\mathcal{S}}$。这些估计量旨在可能存在模型误设的情况下，同时保证目标参数 $\boldsymbol{\beta}_0$ 估计的稳健性和效率。为此，先给出关于 $m(\mathbf{z})$ 估计的两个关键观察。第一，只要用满足矩条件(3)的 $\overline{m}(\mathbf{z})$ 的任意相合估计量插补缺失标签，就能够利用目标无标签观测相合地估计 $\boldsymbol{\beta}_0$。定义

$$\bar{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}} E_{\mathcal{T}}\left[Q\left\{g(\mathbf{X}_i^{\top}\boldsymbol{\theta}), Y_i\right\}\right], \tag{5}$$

其中 $Q\{g(\mathbf{z}_i^{\top}\theta),\ y_i\} = y_i\mathbf{z}_i^{\top}\theta - G(\mathbf{z}_i^{\top}\theta)$。即使插补模型误设，所得 $\overline{m}(\mathbf{z}) = g(\mathbf{z}^{\top}\bar{\theta})$ 也满足矩条件(3)。利用目标标签数据，$\bar{\theta}$ 的一个直接估计量为

$$\widehat{\theta}^{(\mathcal{T})} = \arg\min_{\theta\in\Omega_\theta^{(\mathcal{T})}}\Big[-n_{\mathcal{T}}^{-1}\sum_{i\in\mathcal{I}_{\mathcal{T},L}} Q\{g(\mathbf{z}_i^{\top}\theta),\ y_i\} + p_\lambda(\theta)\Big],$$

其中 $p_\lambda(\theta)$ 是对 $\theta$ 的惩罚函数，调节参数为 $\lambda$；$\Omega_\theta^{(\mathcal{T})}$ 是 $\theta$ 的可行参数空间。在高维情形的标准正则条件下，$\widehat{\theta}^{(\mathcal{T})}$ 收敛至 $\bar{\theta}$。将 $\widehat{\theta}^{(\mathcal{T})}$ 代入式(2)，即得到 $\boldsymbol{\beta}_0$ 的 SAS 估计量。

第二个关键观察是，在本文协变量偏移设定及矩条件(3)下，只要插补模型或密度比模型正确设定，就有 $E_{\mathcal{S}}\left[w_0(\mathbf{Z}_i)\mathbf{Z}_i\{Y_i - \overline{m}(\mathbf{Z}_i)\}\right] = \mathbf{0}$。进一步定义

$$\boldsymbol{\theta}^* = \arg\max_{\boldsymbol{\theta}}\left\{\frac{n_{\mathcal{S}}}{n}E_{\mathcal{S}}\left[w_0(\mathbf{Z}_i)Q\left\{g(\mathbf{Z}_i^{\top}\boldsymbol{\theta}), Y_i\right\}\right] + \frac{n_{\mathcal{T}}}{n}E_{\mathcal{T}}\left[Q\left\{g(\mathbf{Z}_i^{\top}\boldsymbol{\theta}), Y_i\right\}\right]\right\}, \tag{6}$$

以及 $m^*(\mathbf{z}) = g(\mathbf{z}^{\top}\theta^*)$。当 $m(\mathbf{z})$ 或 $w(\mathbf{z})$ 中任意一个正确设定时，$\theta^* = \bar{\theta}$，可以通过最大化式(6)的经验版本估计 $\bar{\theta}$，得到其双重稳健估计量。然而，当两个模型均误设，或 $p_{Y|\mathbf{Z}}$ 在总体间不同时，$\theta^* \neq \bar{\theta}$，这种方式可能产生 $\bar{\theta}$ 的有偏估计。

受 oracle Trans-Lasso 思想启发（Li 等，2022；Tian 和 Feng，2022），我们提出嵌入密度比的两步元学习算法，通过校正潜在偏差 $\delta_0 = \bar{\theta} - \theta^*$ 来估计 $\bar{\theta}$，如算法1所示。不同于 oracle Trans-Lasso，我们处理的损失函数更复杂，其中嵌入了估计的工作密度比。

**算法1：对 $\bar{\theta}$ 的稳健元学习**。

**第1步**。使用 $\mathcal{D}_{\mathcal{S},L}\cup\mathcal{D}_{\mathcal{T},L}$ 和 $\widehat{w}(\mathbf{z}) = \exp(\mathbf{z}^{\top}\hat{\zeta})$，将 $\theta^*$ 估计为 $\widetilde{\theta} = \mathrm{argmin}_{\theta\in\Omega_\theta}\{\mathcal{L}_n(\theta;\hat{\zeta}) + p_{\lambda_\theta}(\theta)\}$，其中

$$\mathcal{L}_n(\boldsymbol{\theta};\boldsymbol{\zeta}) = -\frac{1}{n}\sum_{i\in\mathcal{I}_{\mathcal{S},L}\cup\mathcal{I}_{\mathcal{T},L}} w(\mathbf{z}_i;\boldsymbol{\zeta})^{I(i\in\mathcal{I}_{\mathcal{S},L})}Q\left\{g(\boldsymbol{\theta}^{\top}\mathbf{z}_i), y_i\right\}, \tag{7}$$

$I(i\in\mathcal{I}_{\mathcal{S},L})$ 是指示函数，$p_{\lambda_\theta}(\theta)$ 是作用于 $\theta$、调节参数为 $\lambda_\theta$ 的惩罚函数，$\Omega_\theta$ 是可行参数空间，详细定义见第3节。

**第2步**。使用 $\mathcal{D}_{\mathcal{T},L}$ 和 $\widetilde{\theta}$ 估计 $\delta_0$：$\widehat{\delta} = \mathrm{argmin}_{\delta\in\Omega_\delta}\{\mathcal{L}_{n_{\mathcal{T}}}^{(\mathcal{T})}(\widetilde{\theta}+\delta) + p_{\lambda_\delta}(\delta)\}$，构造元学习估计量 $\widehat{\theta}^{(\mathrm{meta})} = \widetilde{\theta} + \widehat{\delta}$，其中

$$\mathcal{L}_{n_{\mathcal{T}}}^{(\mathcal{T})}(\widetilde{\boldsymbol{\theta}}+\boldsymbol{\delta}) := -\frac{1}{n_{\mathcal{T}}}\sum_{i\in\mathcal{I}_{\mathcal{T},L}} Q[g\{\mathbf{z}_i^{\top}(\widetilde{\boldsymbol{\theta}}+\boldsymbol{\delta})\}, y_i], \tag{8}$$

$p_{\lambda_\delta}(\delta)$ 是对 $\delta$ 的惩罚函数，调节参数为 $\lambda_\delta$；$\Omega_\delta$ 为可行参数空间，详细定义见第3节。略微复用记号，$p_{\lambda_\theta}$ 和 $p_{\lambda_\delta}$ 可以是不同惩罚函数，其调节参数分别为 $\lambda_\theta$ 和 $\lambda_\delta$。

在第1步中，通过最小化式(6)负值的经验版本并加上惩罚函数，估计 $\theta^*$。在协变量偏移情形下，只要两个工作模型至少有一个正确设定，就有 $\delta_0 = \mathbf{0}$，且在标准高维条件下，$\widetilde{\theta}$ 是 $\bar{\theta}$ 的相合估计量。此时可充分利用源标签数据。当 $\theta^* \neq \bar{\theta}$，但 $\delta_0$ 相对接近零时，借助第2步的偏差校正，仍可部分利用源标签数据，从而使元学习估计量 $\widehat{\theta}^{(\text{meta})}$ 继续优于仅目标估计量 $\widehat{\theta}^{(\mathcal{T})}$。然而，如果 $\delta_0$ 过于稠密，以至于有限目标标签数据无法完整恢复它，第2步便不能充分校正 $\widetilde{\theta}$ 中的偏差。第3节的理论分析和第4节的数值研究均验证了这一负迁移现象。下面详细说明如何在 STRIFLE 估计的最后一步克服它。

## 2.5 插补模型的 STRIFLE 估计量

为克服负迁移，我们把 $\bar{\theta}$ 的 STRIFLE 估计量定义为 $\widehat{\theta}^{(\mathcal{T})}$ 和 $\widehat{\theta}^{(\text{meta})}$ 的凸组合，并通过数据拆分估计组合权重。具体而言，将 $\mathcal{I}_{\mathcal{T},L}$ 中的数据随机分成两半，记为 $\mathcal{I}^{(1)}_{\mathcal{T},L}$ 和 $\mathcal{I}^{(2)}_{\mathcal{T},L}$。使用 $\mathcal{I}^{(k)}_{\mathcal{T},L}$ 中的数据构造仅目标估计量 $\widehat{\theta}^{(\mathcal{T},k)}$，使用 $\mathcal{I}_{\mathcal{S},L}$ 及 $\mathcal{I}^{(k)}_{\mathcal{T},L}$ 中的数据，根据算法1构造元学习估计量 $\widehat{\theta}^{(\text{meta},k)}$。剩余的 $\mathcal{I}_{\mathcal{T},L}\backslash\mathcal{I}^{(k)}_{\mathcal{T},L}$ 数据用于估计凸组合系数。受 Tian 和 Feng（2022）启发，我们考虑二元系数 $\rho \in \{0, 1\}$，以判断 $\mathcal{S}$ 是否可迁移。估计该系数时，比较下列损失在 $\widehat{\theta}^{(\mathcal{T},k)}$ 和 $\widehat{\theta}^{(\text{meta},k)}$ 处的取值：

$$\mathcal{L}^{\rho^{(-k)}}_{n_\mathcal{T}/2}(\theta) = \frac{2}{n_\mathcal{T}} \sum_{i\in\mathcal{I}_{\mathcal{T},L}\backslash\mathcal{I}^{(k)}_{\mathcal{T},L}} \{G(\mathbf{z}_i^\top\theta) - y_i\mathbf{z}_i^\top\theta\}.$$

为减轻数据拆分造成的效率损失，可以采用交叉拟合，并令

$$\widehat{\rho} = I\left\{\frac{1}{2}\sum_{k=1}^{2}\mathcal{L}^{\rho^{(-k)}}_{n_\mathcal{T}/2}(\widehat{\boldsymbol{\theta}}^{(\text{meta},k)}) \leq \frac{1}{2}\sum_{k=1}^{2}\mathcal{L}^{\rho^{(-k)}}_{n_\mathcal{T}/2}(\widehat{\boldsymbol{\theta}}^{(\mathcal{T},k)}) - \epsilon_0\right\}, \tag{9}$$

其中 $\epsilon_0$ 是为获得理论保证而选择的非负常数。关于 $\epsilon_0$ 的选择，详见补充材料第 S.4 节。

最终，$\bar{\theta}$ 的 STRIFLE 估计量定义为 $\widehat{\theta}^{(\text{STRIFLE})} = \widehat{\rho}\,\widehat{\theta}^{(\text{meta})} + (1-\widehat{\rho})\widehat{\theta}^{(\mathcal{T})}$。即使 $\delta_0$ 显著偏离零向量，在额外计入估计 $\rho$ 的误差后，该估计量仍不劣于 $\widehat{\theta}^{(\mathcal{T})}$。因此，$\widehat{\beta}^{(\text{STRIFLE})}$ 在计入可迁移性检测的附加误差后，不劣于仅使用目标总体的 SAS 估计量。当 $\delta_0$ 等于或接近零，而且 $n_\mathcal{S}$ 远大于 $n_\mathcal{T}$ 时，$\widehat{\beta}^{(\text{STRIFLE})}$ 的效率可以显著高于 SAS 估计量。

## 3 理论结果

首先介绍一些记号。对向量 $\mathbf{v}=\left(v_1,\ \ldots,\ v_p\right)^{\mathsf{T}}\in\mathbb{R}^p$，定义 $\parallel\mathbf{v}\parallel_0=|\mathrm{supp}(\mathbf{v})|$，其中 $\mathrm{supp}(\mathbf{v})=\{j:v_j\neq 0\}$，$|A|$ 表示集合 $A$ 的基数。对于 $S\subseteq\{1,\ \ldots,\ p\}$，令 $\mathbf{v}_S=\{v_j:j\in S\}$，$S^c$ 为 $S$ 的补集。记 $\parallel\mathbf{v}\parallel_\infty=\max_{1\le j\le p}|v_j|$，并对 $r\in(0,\ 1]$ 定义 $\parallel\mathbf{v}\parallel_r=\sum_{j=1}^{p}|v_j|^r$。对 $r\in[0,\ 1]$，定义 $\mathbb{B}_r^p(R)=\{\mathbf{v}\in\mathbb{R}^p:\ \parallel\mathbf{v}\parallel_r\le R\}$。对于两个正数列 $a_n$、$b_n$，用 $a_n\precsim b_n$ 表示存在某个常数 $C>0$ 使 $a_n\le Cb_n$；用 $a_n\asymp b_n$ 表示存在常数 $C,\ C'>0$ 使 $C\le a_n/b_n\le C'$。

接着引入密度比估计收敛速度的假设，这是 STRIFLE 估计量理论基础中的必要条件。

**假设1**。记 $\Omega_0$ 为事件 $\parallel\hat{\boldsymbol{\zeta}}-\boldsymbol{\zeta}_0\parallel_1\le C_\zeta$ 且 $\parallel\hat{\boldsymbol{\zeta}}-\boldsymbol{\zeta}_0\parallel_2^2=o(1)$，其中 $C_\zeta$ 是正常数；当样本量趋于无穷时，$\mathrm{pr}\left(\Omega_0\right)$ 趋于1。

**备注1**。如第2.3节所述，密度比模型的估计具有很大灵活性。为简化理论推导，本文聚焦于基函数 $\mathbf{f}(\cdot)$ 预先指定的参数模型 $\exp\{\mathbf{f}(\mathbf{z})^{\mathsf{T}}\boldsymbol{\zeta}\}$，并允许该模型误设。如补充材料第 S.1 节详述，密度比估计可以重新表述为二分类任务，因此能够使用机器学习技术。在这种情况下，假设1可修改为：“$E_{\mathcal{S}}\left[\{\widehat{w}(\mathbf{Z})-w_0(\mathbf{Z})\}^2\right]=o(1)$，且当样本量趋于无穷时，$\sup_{\mathbf{Z}}w_0(\mathbf{Z})/\widehat{w}(\mathbf{Z})$ 以趋于1的概率有界。”只要两个总体都提供足够多的无标签数据，关于机器学习方法收敛速度的近期进展，例如深度神经网络（Farrell 等，2020，2021）和广义随机森林（Athey 等，2019），便能保证这些方法在相应条件下不会损害 STRIFLE 估计量的理论表现。

关于稀疏性假设，与 Li 等（2022）类似，我们允许 $\boldsymbol{\delta}_0$ 具有软稀疏性。对于 $\bar{\boldsymbol{\theta}}$，考虑两种稀疏性情形。在情形1中，与现有 TransLasso 研究（Li 等，2022；Tian 和 Feng，2022；Li 等，2021，2023）一样，假设 $\bar{\boldsymbol{\theta}}$ 为 $l_0$ 稀疏。在情形2中，假设 $\bar{\boldsymbol{\theta}}$ 和 $\boldsymbol{\delta}_0$ 对某个固定 $r\in[0,\ 1]$ 均为 $l_r$ 稀疏，因此 $\boldsymbol{\theta}^*=\bar{\boldsymbol{\theta}}-\boldsymbol{\delta}_0$ 也为 $l_r$ 稀疏。本节只详细给出 $\bar{\boldsymbol{\theta}}$ 为 $l_0$ 稀疏、$\boldsymbol{\delta}_0$ 为 $l_1$ 稀疏时的理论结果，因为该具体情形简明且易于解释。备注3简要说明其他情形下的理论发现。一般情形的详细理论结果置于补充材料第 S.5至S.8 节。

关于设计矩阵、模型、惩罚函数以及 $\boldsymbol{\delta}_0$、$\bar{\boldsymbol{\theta}}$、$\boldsymbol{\beta}_0$ 稀疏性的其他假设 S1至S5，见补充材料第 S.3 节。简言之，在 $\bar{\boldsymbol{\theta}}$ 为 $l_0$ 稀疏、$\boldsymbol{\delta}_0$ 为 $l_1$ 稀疏的情形下，假设

$$\boldsymbol{\delta}_0\in\mathbb{B}_1^d\left(R_{\delta,1}\right),\qquad R_{\delta,1}\precsim\sqrt{n_{\mathcal{T}}/\log d},$$

$$\bar{\boldsymbol{\theta}}\in\mathbb{B}_r^d\left(R_{\bar{\theta},r}\right),\qquad \boldsymbol{\beta}_0\in\mathbb{B}_r^p\left(R_{\beta,r}\right),$$

$$R_{\bar{\theta},r}\precsim\left(n_{\mathcal{T}}/\log d\right)^{1-r/2},\qquad R_{\beta,r}\precsim\{\left(N_{\mathcal{T}}+n_{\mathcal{T}}\right)/\log d\}^{1-r/2},\qquad r=0,\ 1.$$

略微复用记号，把 $\bar{\boldsymbol{\theta}}$ 和 $\boldsymbol{\beta}_0$ 的真实支撑集分别记为 $S_\theta$ 和 $S_\beta$，基数分别为 $s_\theta$ 和 $s_\beta$。还假设 $\lambda_\theta\asymp\sqrt{n^{-1}\log d}$、$\lambda_\delta\asymp\sqrt{n_{\mathcal{T}}^{-1}\log d}$，以及 $\lambda_\beta\asymp\sqrt{\left(N_{\mathcal{T}}+n_{\mathcal{T}}\right)^{-1}\log p}$。我们在 Negahban 等（2012）以及 Loh 和 Wainwright（2015）的框架下建立理论结果，允许使用 SCAD、MCP 等非凸惩罚。为便于理论推导，与 Loh 和 Wainwright（2015）类似，定义可行参数空间为

$\Omega_\theta = \{\theta \in \mathbb{R}^d : \| \theta \|_1 \le R_{\bar\theta,1}\}$,

$\Omega_\delta = \{\delta \in \mathbb{R}^d : \| \delta \|_1 \le R_{\delta,1}\}$, $\Omega_\beta = \{\beta \in \mathbb{R}^p : \| \beta \|_1 \le R_{\beta,1}\}$.

注意，如果加惩罚后的损失函数为凸函数，可行参数空间可以扩展为 $\Omega_\theta = \Omega_\delta = \mathbb{R}^d$、$\Omega_\beta = \mathbb{R}^p$。

### 3.1 插补参数 STRIFLE 估计量的理论性质

首先在下述定理中建立 $\widehat{\theta}^{(\text{meta})}$ 的误差界，证明见补充材料第 S.6 节。

**定理1**。 假设1及假设 S1至S4 成立，则有

$$\|\widehat{\boldsymbol{\theta}}^{(\text{meta})} - \bar{\boldsymbol{\theta}}\|_1 = O_p\left\{ s_{\boldsymbol{\theta}}\sqrt{\frac{log\ d}{n}} + \|\boldsymbol{\delta}_0\|_1 + \sqrt{\frac{n}{log\ d}}\mathrm{Err}_{\boldsymbol{\zeta}}\left(1 \vee \sqrt{\frac{\mathrm{n}}{\mathrm{n}_{\mathcal{T}}}}\mathrm{Err}_{\boldsymbol{\zeta}}\right)\right\},$$

$$and \quad \|\widehat{\boldsymbol{\theta}}^{(\text{meta})} - \bar{\boldsymbol{\theta}}\|_2^2 = O_p\left\{ s_{\boldsymbol{\theta}}\frac{log\ d}{n} + \sqrt{\frac{log\ d}{n_{\mathcal{T}}}}\|\boldsymbol{\delta}_0\|_1 \wedge \|\boldsymbol{\delta}_0\|_1^2 + \mathrm{Err}_{\boldsymbol{\zeta}}\left(1 \vee \frac{\mathrm{n}}{\mathrm{n}_{\mathcal{T}}}\mathrm{Err}_{\boldsymbol{\zeta}}\right)\right\},$$

上式两行分别给出 $l_1$ 误差与平方 $l_2$ 误差的界，其中

$\mathrm{Err}_\zeta = n_S^2 n^{-2}(\| \hat\zeta - \zeta_0 \|_2^2 + n_S^{-1}\log d \| \hat\zeta - \zeta_0 \|_1^2)$.

**备注2**。 正如一位审稿人所指出的，定理1中的 $l_1$ 误差率不优于 $\| \widetilde{\theta} - \theta^* \|_1 + \| \theta^* - \bar\theta \|_1$ 的阶，这意味着当 $\delta_0$ 为 $l_1$ 稀疏时，算法1中第2步的偏差校正不会改善 $l_1$ 误差率。这源于将 $l_1$ 类型惩罚应用于 $l_1$ 稀疏参数的内在性质，与 Li 等（2022，2023）证明的极小极大结果一致。Negahban 等（2012）还表明，在高维线性模型中，采用可分解惩罚估计 $l_1$ 稀疏参数时，惩罚估计量的 $l_1$ 误差就是参数自身的 $l_1$ 范数，这也是极小极大速率（Raskutti 等，2011）。不过，这一步偏差校正有助于改善 $l_2$ 误差。此外，如果考虑 $l_r$ 稀疏的 $\delta_0$，其中 $r \in [0, 1)$，则 $\| \widehat{\theta}^{(\text{meta})} - \bar\theta \|_1$ 的阶可以优于 $\| \widetilde{\theta} - \theta^* \|_1 + \| \theta^* - \bar\theta \|_1$。详细结果见补充材料的推论 S1、S2。例如，当 $\bar\theta$ 和 $\delta_0$ 均为 $l_0$ 稀疏，且 $\| \delta_0 \|_0 \lesssim s_\theta$ 时，有

$$\| \widetilde{\theta} - \theta^* \|_1 = O_p\left(s_\theta\sqrt{n^{-1}\log d} + \mathrm{Err}_\zeta\sqrt{n/\log d}\right),$$

以及

$$\| \widehat{\theta}^{(\text{meta})} - \bar\theta \|_1 = O_p\{ s_\theta\sqrt{n^{-1}\log d} + \| \delta_0 \|_0\sqrt{n_{\mathcal{T}}^{-1}\log d} + \mathrm{Err}_\zeta\sqrt{n/\log d}\left(1 \vee \sqrt{n/n_{\mathcal{T}}}\mathrm{Err}_\zeta\right)\}.$$

当 $\| \delta_0 \|_0\sqrt{n_{\mathcal{T}}^{-1}\log d} = o\left(\| \delta_0 \|_1\right)$ 时，偏差校正步骤有帮助。

在典型半监督情形下，$\max(n_S, n_{\mathcal{T}}) = o\{\min(N_S, N_{\mathcal{T}})\}$，这使 $\hat\zeta$ 的估计误差成为高阶项，误差界可以简化为

$$\| \widehat{\theta}^{(\text{meta})} - \bar\theta \|_1 = O_p\left(s_\theta\sqrt{n^{-1}\log d} + \| \delta_0 \|_1\right),$$

$$\| \widehat{\theta}^{(\text{meta})} - \bar{\theta} \|_2^2 = O_p\Big(s_\theta n^{-1}\log d + \sqrt{n_{\mathcal{T}}^{-1}\log d}\ \| \delta_0 \|_1 \wedge \| \delta_0 \|_1^2\Big).$$

当 $w(\mathbf{z})$ 或 $m(\mathbf{z})$ 正确设定时，$\delta_0 = \mathbf{0}$，于是

$$\| \widehat{\theta}^{(\text{meta})} - \bar{\theta} \|_1 = O_p\Big(s_\theta\sqrt{n^{-1}\log d}\Big), \qquad \| \widehat{\theta}^{(\text{meta})} - \bar{\theta} \|_2^2 = O_p\big(s_\theta n^{-1}\log d\big).$$

这就是样本量为 $n = n_{\mathcal{S}} + n_{\mathcal{T}}$ 时的标准高维误差率。换言之，源标签数据已被充分利用，以提高 $\bar{\theta}$ 的估计精度。当 $\| \delta_0 \|_1 = o\Big(s_\theta\sqrt{n_{\mathcal{T}}^{-1}\log d}\Big)$ 时，即使两个工作模型均误设，仍可通过部分利用源标签观测提高估计精度。当 $s_\theta\sqrt{n_{\mathcal{T}}^{-1}\log d} = o\big(\| \delta_0 \|_1\big)$ 时，误差率比仅目标估计量更差，开始出现负迁移。

**备注3**。 在情形2中，对固定的 $r \in [0, 1]$，$\delta_0$ 与 $\bar{\theta}$ 都是 $l_r$ 稀疏。由补充材料推论 S2，当 $\| \bar{\theta} \|_r = o\big(\| \delta_0 \|_r\big)$ 时，开始出现负迁移。这与以下直觉一致：若偏移后的源参数与目标参数之间的差异比目标参数本身更稠密，那么算法1中使用目标标签数据的第2步，就无法充分校正 $\widetilde{\theta}$ 的偏差，所得元学习估计量因此劣于仅目标估计量。

定理2给出 $\widehat{\theta}^{(\text{STRIFLE})}$ 的误差上界；该估计量在 $\| \delta_0 \|_1$ 较大时能够克服负迁移。证明见补充材料第 S.7 节。

**定理2**。 假设1及假设 S1至S4 成立，则有

$$\|\widehat{\boldsymbol{\theta}}^{(\text{STRIFLE})} - \bar{\boldsymbol{\theta}}\|_2^2 = O_p\left[\left\{\frac{\log d}{n}s_{\boldsymbol{\theta}} + \sqrt{\frac{\log d}{n_{\mathcal{T}}}}\|\boldsymbol{\delta}_0\|_1 \wedge \|\boldsymbol{\delta}_0\|_1^2 + \mathrm{Err}_{\boldsymbol{\zeta}}\left(1 \vee \frac{\mathrm{n}}{\mathrm{n}_{\mathcal{T}}}\mathrm{Err}_{\boldsymbol{\zeta}}\right)\right\} \wedge \left(\frac{\log d}{n_{\mathcal{T}}}s_{\boldsymbol{\theta}} + n_{\mathcal{T}}^{-1/2}\right)\right].$$

可见，当 $n_{\mathcal{T}}^{1/2}/\log d \precsim s_\theta$ 时，保证 $\| \widehat{\theta}^{(\text{STRIFLE})} - \bar{\theta} \|_2^2$ 不劣于仅目标估计量 $\widehat{\theta}^{(\mathcal{T})}$ 的相应误差。当 $s_\theta = o\Big(n_{\mathcal{T}}^{1/2}/\log d\Big)$ 时，确实需要为可迁移性检测步骤付出代价。一般 $l_r$ 稀疏情形下也证明了类似结果，见补充材料定理 S2。

## 3.2 结局模型参数 STRIFLE 估计量的理论性质

有了三重稳健估计量 $\widehat{\theta}^{(\text{STRIFLE})}$，我们可以利用目标无标签数据，稳健地提高 $\beta_0$ 的学习精度。与 SAS 估计量类似，当 $n_{\mathcal{T}} = o\big(N_{\mathcal{T}}\big)$ 时，允许 $\beta_0$ 远比 $\bar{\theta}$ 稠密。下述定理建立 $\widehat{\beta}^{(\text{STRIFLE})}$ 的误差上界，证明见补充材料第 S8 节。

**定理3**。 在假设1及假设 S1至S5 下，令 $\varrho = n_{\mathcal{T}}/\big(n_{\mathcal{T}} + N_{\mathcal{T}}\big)$，则有

$$\|\widehat{\boldsymbol{\beta}}^{(\text{STRIFLE})} - \boldsymbol{\beta}_0\|_2^2 = O_p\left((1-\varrho)\left[\left\{s_{\boldsymbol{\theta}}\frac{\log d}{n} + \sqrt{\frac{\log d}{n_{\mathcal{T}}}}\|\boldsymbol{\delta}_0\|_1 \wedge \|\boldsymbol{\delta}_0\|_1^2 + \mathrm{Err}_{\boldsymbol{\zeta}}\left(1 \vee \frac{\mathrm{n}}{\mathrm{n}_{\mathcal{T}}}\mathrm{Err}_{\boldsymbol{\zeta}}\right)\right\} \wedge \left(\frac{\log d}{n_{\mathcal{T}}}s_{\boldsymbol{\theta}} + n_{\mathcal{T}}^{-1/2}\right)\right] + s_{\boldsymbol{\beta}}\frac{\log p}{N_{\mathcal{T}} + n_{\mathcal{T}}}\right).$$

**备注4**。即使 $N_{\mathcal{T}} \lesssim n_{\mathcal{T}}$，只要 $(1-\varrho)s_\theta n_{\mathcal{T}}^{-1}\log d \lesssim s_\beta n_{\mathcal{T}}^{-1}\log p$ 且 $(1-\varrho)n_{\mathcal{T}}^{1/2}/\log p \lesssim s_\beta$，就能保证 $\widehat{\beta}^{(\mathrm{STRIFLE})}$ 不劣于仅目标监督估计量。对于具有强预测性替代变量的 EHR 应用，$\bar{\theta}$ 通常比 $\beta_0$ 稀疏得多；对于 SNP 信号弱而稠密的多基因风险模型，上述条件也通常成立。当 $s_\beta = o\{(1-\varrho)n_{\mathcal{T}}^{1/2}/\log p\}$ 时，可迁移性检测产生的误差会占主导地位。

**表1**。在半监督情形下，忽略 $\mathrm{Err}_\zeta$ 且 $1-\varrho \asymp 1$ 时，三种方法估计 $\beta_0$ 的平方 $l_2$ 误差界比较。公共项为 $\Delta_\beta = s_\beta(N_{\mathcal{T}} + n_{\mathcal{T}})^{-1}\log p$；$\mathrm{cutoff}_1 = s_\theta n^{-1}\sqrt{n_{\mathcal{T}}\log d}$；$\mathrm{cutoff}_2 = s_\theta\sqrt{n_{\mathcal{T}}^{-1}\log d}\vee(\log d)^{-1/2}$。表内 Method＝方法；Meta＝元学习；cutoff＝分界值。

| Method | SAS | Meta | STRIFLE |
|---|---|---|---|
| $0 \le \|\delta_0\|_1 \lesssim \mathrm{cutoff}_1$ | $\Delta_\beta + s_\theta n_\tau^{-1}\log d$ | $\Delta_\beta + s_\theta n^{-1}\log d$ | $\Delta_\beta + s_\theta n^{-1}\log d$ |
| $\mathrm{cutoff}_1 \ll \|\delta_0\|_1 \lesssim \mathrm{cutoff}_2$ | $\Delta_\beta + s_\theta n_\tau^{-1}\log d$ | $\Delta_\beta + \sqrt{n_\tau^{-1}\log d}\|\delta_0\|_1$ | $\Delta_\beta + \sqrt{n_\tau^{-1}\log d}\|\delta_0\|_1$ |
| $\|\delta_0\|_1 \gg \mathrm{cutoff}_2$ | $\Delta_\beta + s_\theta n_\tau^{-1}\log d$ | $\Delta_\beta + \sqrt{n_\tau^{-1}\log d}\|\delta_0\|_1$ | $\Delta_\beta + s_\theta n_\tau^{-1}\log d + n_\tau^{-1/2}$ |

**备注5**。如表1总结，在半监督情形下，当 $\mathrm{Err}_\zeta$ 可忽略且 $1-\varrho \asymp 1$ 时，如果 $\| \delta_0 \|_1 = o\left(s_\theta\sqrt{n_{\mathcal{T}}^{-1}\log d}\right)$，则 $\widehat{\beta}^{(\mathrm{meta})} = \widehat{\beta}\left(\widehat{\theta}^{(\mathrm{meta})}\right)$ 和 $\widehat{\beta}^{(\mathrm{STRIFLE})}$ 都能成功迁移有用的源信息，从而优于 SAS 估计量。当两个总体之间经过模型辅助后的异质性过大，即 $s_\theta\sqrt{n_{\mathcal{T}}^{-1}\log d} = o\left(\| \delta_0 \|_1\right)$ 时，由于负迁移，$\widehat{\beta}^{(\mathrm{meta})}$ 比 SAS 估计量更差。然而，$\widehat{\beta}^{(\mathrm{STRIFLE})}$ 的平方 $l_2$ 误差以 SAS 估计量的相应误差加上可迁移性检测误差为上界；当 $n_{\mathcal{T}}^{1/2}/\log d \lesssim s_\theta$ 时，后者可忽略。综上，$\widehat{\beta}^{(\mathrm{STRIFLE})}$ 对干扰模型误设、$p_{Y|\mathbf{Z}}$ 偏移以及负迁移具有三重稳健性。

## 4 模拟研究

本节从估计精度和预测精度两方面评估 STRIFLE 估计量的有限样本表现。将其与四种基准方法比较：（i）监督估计量 SUP，直接使用 $\mathcal{I}_{\mathcal{T},L}$ 中的数据估计 $\beta_0$；（ii）SAS 估计量，先用 $\mathcal{I}_{\mathcal{T},L}$ 中的数据估计 $m(\mathbf{z})$，再通过最小化式(2)利用 $\mathcal{I}_{\mathcal{T},U}$ 中的数据；（iii）协变量偏移估计量 CS，先使用 $\mathcal{I}_{\mathcal{T},U}$ 与 $\mathcal{I}_{\mathcal{S},U}$ 中的数据估计 $w(\mathbf{z})$，再通过最小化

$$-n^{-1}\sum_{i\in\mathcal{I}_{\mathcal{S},L}\cup\mathcal{I}_{\mathcal{T},L}}\widehat{w}(\mathbf{z}_i)^{I(i\in\mathcal{I}_{\mathcal{S},L})}Q\{g(\mathbf{x}_i^{\mathrm{T}}\beta),\, y_i\} + \lambda_\beta \| \beta \|_1$$

估计 $\beta_0$；（iv）Li 等（2021）提出的监督迁移学习估计量 SUPTrans，通过三步迁移过程利用源标签数据，对 $\beta_0$ 作出更强稀疏性假设，但不利用无标签数据。

全文模拟均考虑二元结局，$g(\cdot)$ 为逆 logit 函数；为方便计算，所有模型均采用 Lasso 惩罚。所有 Lasso 调节参数都通过5折交叉验证选取。固定 $n_{\mathcal{T}} = 150$，$N_{\mathcal{T}} = N_{\mathcal{S}} = 10000$，$q = 30$；令 $p = 150$ 或1000，$n_{\mathcal{S}} = 150$ 或1200。由于 $N_{\mathcal{S}}$ 和 $N_{\mathcal{T}}$ 远大于 $d$，估计 $\zeta \in \mathbb{R}^d$ 时，先最小化 $\mathcal{L}_N^w(\zeta) + \lambda_\zeta \| \zeta \|_2^2$，其中取较小 $\lambda_\zeta$ 以稳定优化；再应用阈值为 $10\sqrt{\log d/(N_{\mathcal{S}} + N_{\mathcal{T}})}$ 的硬阈值处理。

我们不是分别为 $\mathcal{T}$ 和 $\mathcal{S}$ 生成数据，而是先为 $\mathcal{D}_{\mathcal{S}}\cup\mathcal{D}_{\mathcal{T}}$ 生成 $\mathbf{Z}_i$ 和 $Y_i$，再随机生成成员变量 $R_i = I\big(i \in \mathcal{I}_{\mathcal{S},L}\cup\mathcal{I}_{\mathcal{S},U}\big)$，当 $R_i = 1$ 时将第 $i$ 个观测分配到源总体。具体而言，生成 $\mathbf{Z}_i$ 时模拟 EHR 特征的零膨胀离散分布。首先生成潜变量 $\mathbf{W}_i \sim N(\mathbf{0},\, \mathbf{\Sigma})$，其中 $\mathbf{\Sigma} = \big[\nu^{|j-k|}\big]_{d\times d}$，$j,\, k = 1,\, \ldots,\, d$。然后生成 $X_{ij} = a\big(W_{ij}\big)$（$j = 1,\, \ldots,\, p$），以及

$$S_{i1} = a\Big(\sum_{j=1}^{5} X_{ij} + W_{i,p+1}\Big), \qquad S_{i2} = a\Big(\sum_{j=3}^{7} X_{ij} + W_{i,p+2}\Big),$$

$$S_{i3} = a\Big(\sum_{j=6}^{10} X_{ij} + W_{i,p+3}\Big), \qquad S_{ij} = a\big(W_{i,p+j}\big), \quad j = 4,\, \ldots,\, q,$$

其中变换 $a(t) = \big[\log\big(1 + e^{t}\big)\big]$，$[x]$ 表示取 $x$ 的整数部分。将 $\mathbf{X}$ 和 $\mathbf{S}$ 标准化为均值0、方差1。考虑 $\nu = 0$，对应 $\mathbf{\Sigma} = \mathbf{I}_p$；以及 $\nu = 0.1$，允许 $\mathbf{W}_i$ 各元素之间存在弱相关。〔译注：原文此处写作 $\mathbf{I}_p$，而此前将 $\mathbf{\Sigma}$ 定义为 $d\times d$ 矩阵；此处按原文保留。〕考虑 $Y_i \mid \mathbf{Z}_i$ 的两个模型：

$$(\mathrm{M}_{\mathrm{cor}}) \quad \mathrm{logit}\{\Pr(Y_i = 1 \mid \mathbf{Z}_i)\} = 0.2 - X_{i1} + X_{i2} - X_{i3} + 2S_{i1} - 2S_{i2} + 2S_{i3};$$

$$(\mathrm{M}_{\mathrm{mis}}) \quad \mathrm{logit}\{\Pr(Y_i = 1 \mid \mathbf{Z}_i)\} = -X_{i1} + X_{i2} + X_{i3}^2 - S_{i2} + 2S_{i3} + \frac{2S_{i1}}{1 + \exp(-X_{i1}S_{i1}^2)}.$$

在 $\big(M_{\mathrm{cor}}\big)$ 下，插补模型 $m(\mathbf{z}) = g\big(\mathbf{z}^{\mathsf{T}}\theta\big)$ 正确设定；在 $\big(M_{\mathrm{mis}}\big)$ 下误设。对于 $\big(M_{\mathrm{mis}}\big)$ 的误设情形，当 $\nu = 0.1$ 时，$\bar{\theta}$ 是软稀疏的。考虑用于生成 $R_i$ 的两个模型：

$$(\mathrm{W}_{\mathrm{cor}}) \quad \mathrm{logit}\{\Pr(R_i = 0 \mid \mathbf{Z}_i)\} = X_{i1} - X_{i2} - X_{i3} + S_{i1},$$

$$(\mathrm{W}_{\mathrm{mis}}) \quad \mathrm{logit}\{\Pr(R_i = 0 \mid \mathbf{Z}_i)\} = 1.8S_{i2} - 2S_{i3} + S_{i1}\left[1 + \frac{X_{i1} + X_{i2}}{1 + \exp\{-(\sum_{j=3}^{10} X_{ij})\}}\right].$$

拟合参数化密度比模型(4)时，取 $\mathbf{f}(\mathbf{z}) = \mathbf{z}$，从而在 $\big(W_{\mathrm{cor}}\big)$ 下式(4)正确设定，在 $\big(W_{\mathrm{mis}}\big)$ 下误设。在 $\mathbf{Z}$ 的两种相关结构、$n_{\mathcal{S}}$ 的两个取值以及 $p$ 的两个取值下，组合 $\big(M_{\mathrm{cor}}\big)$、$\big(M_{\mathrm{mis}}\big)$、$\big(W_{\mathrm{cor}}\big)$、$\big(W_{\mathrm{mis}}\big)$，得到四种模型配置。

为考察不同估计量可能带来的负迁移，并展示 STRIFLE 估计量的三重稳健性，我们进一步考虑 $m(\mathbf{z})$ 和 $w(\mathbf{z})$ 都严重误设的模拟情形。理论分析提示，当 $s_{\theta}\sqrt{n_{\mathcal{T}}\log d} = o\big(\,\|\,\delta_0\,\|_{\,1}\big)$ 时，中间的 Meta 估计量可能出现更加明显的负迁移。〔译注：此处根号内的 $n_{\mathcal{T}}$ 按原文保留；与第3节所列阈值的 $n_{\mathcal{T}}^{-1}$ 不同。〕为此，在 $\nu = 0$ 时，分别由下列模型生成 $Y_i$ 和 $R_i$：

$$(\mathrm{M}'_{\mathrm{mis}}) \quad \mathrm{logit}\{\Pr(Y_i = 1 \mid \mathbf{Z}_i)\} = -1 - 2X_{i1} + 2X_{i2}^2 + 2X_{i3}X_{i4} + 4S_{i1}^2 - 4S_{i2}^2 + \frac{1}{1 + \exp\{-X_{i3}(S_{i3}^2 + S_{i4})\}},$$

$$(\mathrm{W}'_{\mathrm{mis}}) \quad \mathrm{logit}\{\Pr(R_i = 0 \mid \mathbf{Z}_i)\} = 4X_{i1} - 4X_{i2} - 6S_{i1}^2 + 6S_{i2}^2 - \frac{2S_{i3}(X_{i1} + X_{i2})}{1 + \exp\{-(\sum_{j=3}^{10} S_{ij})\}},$$

其余设置与前述相同。

对每种设置进行500次模拟重复，以评估各估计量的平均表现。指标包括 $\widehat{\boldsymbol{\beta}}$ 的 $p$ 个分量上的平均绝对偏差（|Bias|）、 $\widehat{\boldsymbol{\beta}}$ 的 $l_2$ 误差（$l_2$ Err），以及使用 $\widehat{\boldsymbol{\beta}}^{\top}\mathbf{X}$ 对 $Y$ 分类时的 ROC 曲线下面积（AUC）。AUC 使用10000个目标无标签观测计算。首先，表2汇总 $p = 1000$ 且 $m(\mathbf{z})$、$w(\mathbf{z})$ 至少一个正确设定，即 $\boldsymbol{\delta}_0 = \mathbf{0}$ 的结果。在考察的所有设置中，STRIFLE 通常通过成功利用目标无标签数据和充分利用源标签数据，在估计与预测精度上优于 SUP、SAS、CS 和 SUPTrans。当 $n_{\mathcal{S}}$ 远大于 $n_{\mathcal{T}}$ 时，STRIFLE 显著优于 SAS，因为可以从源总体借用更多有用信息；SAS 不使用 $w(\mathbf{z})$，但同样对 $m(\mathbf{z})$ 的误设稳健。当未经 $w(\mathbf{z})$ 偏移的源总体与目标总体在 $\boldsymbol{\beta}$ 上的异质性很大、 $N_{\mathcal{T}}$ 远大于 $n_{\mathcal{S}}$，和/或 $s_{\boldsymbol{\beta}}$ 所反映的稠密程度远高于 $s_{\boldsymbol{\theta}}$ 时，STRIFLE 也显著优于 SUPTrans。此外， $\nu = 0.1$ 时 STRIFLE 的表现与 $\nu = 0$ 时非常接近，说明 $\overline{\boldsymbol{\theta}}$ 为软稀疏时也可使用 STRIFLE。

**表2**。 五种不同方法在三种建模配置下的平均绝对偏差（$|\text{Bias}| \times 10^{-2}$）、平均 $l_2$ 误差（$l_2$ Err）和 ROC 曲线下面积（AUC）。三种配置为：C1：$(M_{\text{cor}}) + (W_{\text{cor}})$；C2：$(M_{\text{mis}}) + (W_{\text{cor}})$；C3：$(M_{\text{cor}}) + (W_{\text{mis}})$。取 $p = 1000$，$\nu = 0$ 和0.1，$n_{\mathcal{S}} = 150$ 和1200。Both correct＝两者均正确；misspecified＝误设。粗体强调原文选定的优值。

| | \|Bias\| | $l_2$ Err | AUC | \|Bias\| | $l_2$ Err | AUC | \|Bias\| | $l_2$ Err | AUC |
|---|---|---|---|---|---|---|---|---|---|
| $\nu = 0$ | (C1) Both correct | | | (C2) $m(\mathbf{z})$ misspecified | | | (C3) $w(\mathbf{z})$ misspecified | | |
| SUP | 0.86 | 1.16 | 0.72 | 0.99 | 1.39 | 0.62 | 0.92 | 1.33 | 0.61 |
| SAS | 0.81 | 1.06 | 0.75 | 0.93 | 1.29 | 0.67 | 0.84 | 1.16 | 0.69 |
| $\text{CS}_{n_{\mathcal{S}}=150}$ | 0.84 | 1.11 | 0.73 | 0.96 | 1.31 | 0.65 | 0.89 | 1.27 | 0.63 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=150}$ | 0.89 | 1.23 | 0.73 | 1.01 | 1.39 | 0.66 | 0.94 | 1.28 | 0.64 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=150}$ | **0.78** | **0.95** | **0.76** | **0.89** | **1.18** | **0.70** | **0.81** | **1.10** | **0.70** |
| $\text{CS}_{n_{\mathcal{S}}=1200}$ | 0.77 | 0.84 | 0.77 | 0.84 | 0.93 | 0.73 | 0.85 | 1.08 | 0.68 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=1200}$ | 0.82 | 0.95 | 0.79 | 0.90 | 1.02 | **0.76** | 0.88 | 1.07 | 0.69 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=1200}$ | **0.72** | **0.64** | **0.80** | **0.79** | **0.78** | 0.76 | **0.74** | **0.77** | **0.75** |
| $\nu = 0.1$ | (C1) Both correct | | | (C2) $m(\mathbf{z})$ misspecified | | | (C3) $w(\mathbf{z})$ misspecified | | |
| SUP | 0.87 | 1.20 | 0.71 | 1.01 | 1.40 | 0.63 | 0.95 | 1.38 | 0.60 |
| SAS | 0.83 | 1.11 | 0.73 | 0.95 | 1.29 | 0.69 | 0.86 | 1.23 | 0.69 |
| $\text{CS}_{n_{\mathcal{S}}=150}$ | 0.85 | 1.14 | 0.72 | 0.97 | 1.30 | 0.67 | 0.91 | 1.32 | 0.63 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=150}$ | 0.91 | 1.28 | 0.71 | 1.02 | 1.40 | 0.67 | 0.96 | 1.34 | 0.63 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=150}$ | **0.80** | **1.00** | **0.75** | **0.90** | **1.18** | **0.71** | **0.84** | **1.16** | **0.70** |
| $\text{CS}_{n_{\mathcal{S}}=1200}$ | 0.77 | 0.84 | 0.77 | 0.85 | 0.92 | 0.75 | 0.86 | 1.09 | 0.69 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=1200}$ | 0.83 | 0.96 | 0.79 | 0.91 | 1.02 | **0.77** | 0.90 | 1.11 | 0.70 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=1200}$ | **0.73** | **0.67** | **0.80** | **0.80** | **0.80** | 0.77 | **0.75** | **0.80** | **0.75** |

表3汇总配置 C4：$(M_{\text{mis}}) + (W_{\text{mis}})$ 及 C5：$(M'_{\text{mis}}) + (W'_{\text{mis}})$ 的结果，其中 C5 的模型误设更严重。为作说明，我们也纳入 $\widehat{\boldsymbol{\beta}}^{(\text{meta})}$ 的结果，该估计量在严重模型误设下预计会遭受负迁移。正如预期，C5 下 Meta 和 CS 估计量都因负迁移而不如 SAS。但 STRIFLE 保持了与 SAS 相当的表现，显示出对异质性的适应能力及抵御负迁移的能力。另一方面，在两个总体合理相似、 $\|\boldsymbol{\delta}_0\|_1$ 较小的 C4 下，STRIFLE 仍能部分利用源数据并优于 SAS。SUPTrans 的表现虽会随 $n_{\mathcal{S}}$ 从150增至1200而改善，但在两种配置下仍差于 STRIFLE，因为它未能有效利用有预测能力的替代变量和无标签数据。

**表3**。 六种方法在两个干扰模型均误设的两种配置下，平均绝对偏差（$|\text{Bias}| \times 10^{-2}$）、平均 $l_2$ 误差（$l_2$ Err）和 ROC 曲线下面积（AUC）。配置为 C4：$(M_{\text{mis}}) + (W_{\text{mis}})$，C5：$(M'_{\text{mis}}) + (W'_{\text{mis}})$；$p = 1000$，$\nu = 0$，$n_{\mathcal{S}} = 150$ 和1200。 C4中不出现负迁移，而C5中存在负迁移。

| | \|Bias\| | $l_2$ Err | AUC | \|Bias\| | $l_2$ Err | AUC |
|---|---|---|---|---|---|---|
| $\nu = 0$ | (C4) $(M_{\text{mis}}) + (W_{\text{mis}})$ | | | (C5) $(M'_{\text{mis}}) + (W'_{\text{mis}})$ | | |
| SUP | 1.03 | 1.51 | 0.61 | 0.94 | 1.32 | 0.73 |
| SAS | 0.90 | 1.24 | 0.73 | **0.86** | **1.08** | **0.78** |
| $\text{CS}_{n_{\mathcal{S}}=150}$ | 1.00 | 1.42 | 0.65 | 1.09 | 1.91 | 0.63 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=150}$ | 1.04 | 1.53 | 0.62 | 0.96 | 1.35 | 0.73 |
| $\text{Meta}_{n_{\mathcal{S}}=150}$ | **0.86** | **1.09** | **0.75** | 0.95 | 1.39 | 0.73 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=150}$ | 0.87 | 1.11 | 0.74 | 0.87 | 1.12 | 0.77 |
| $\text{CS}_{n_{\mathcal{S}}=1200}$ | 0.90 | 1.09 | 0.74 | 1.18 | 2.68 | 0.60 |
| $\text{SUPTrans}_{n_{\mathcal{S}}=1200}$ | 0.96 | 1.26 | 0.68 | 0.94 | 1.32 | 0.76 |
| $\text{Meta}_{n_{\mathcal{S}}=1200}$ | **0.78** | **0.75** | **0.79** | 0.97 | 1.48 | 0.69 |
| $\text{STRIFLE}_{n_{\mathcal{S}}=1200}$ | 0.78 | 0.76 | 0.79 | 0.87 | 1.13 | 0.77 |

$p = 150$ 的结果汇总于补充材料第 S.10 节的表 S1、S2。我们进一步探索在 CS、Meta 和 STRIFLE 中使用基于尺度化共轭梯度反向传播的10层神经网络估计 $w(\mathbf{z})$。当 $N_{\mathcal{S}}$ 和 $N_{\mathcal{T}}$ 充分大，且 $w(\mathbf{z}) = \exp(\mathbf{z}^\intercal \boldsymbol{\zeta})$ 正确设定时，神经网络与对 $\boldsymbol{\zeta}$ 作惩罚参数估计的表现相当。当 $w(\mathbf{z})$ 误设但结构相对简单时，神经网络更具优势。在 C3 和 C4 中，神经网络提高了源标签数据的可迁移性。相比之下，在 $w(\mathbf{z})$ 严重误设且含复杂非线性的 C5 中，神经网络与 $\boldsymbol{\zeta}$ 的惩罚参数估计给出相似结果。采用神经网络的 Meta 仍不如 SAS，表明存在负迁移。总之，当 $N_{\mathcal{S}}$ 和 $N_{\mathcal{T}}$ 不足以支撑复杂机器学习模型时，密度比估计误差可能造成负迁移，因此偏差校正与可迁移性检测步骤必不可少。此外，我们也研究了在 SAS 和 STRIFLE 中，以目标样本患病率为阈值将 $g(\mathbf{z}_i^\intercal \widehat{\boldsymbol{\theta}})$ 二值化后再插补的影响。在模拟研究中，这种做法的结果略差于直接使用 $g(\mathbf{z}_i^\intercal \widehat{\boldsymbol{\theta}})$ 插补。

## 5 非裔美国人的2型糖尿病遗传风险预测

本节应用 STRIFLE 方法，利用 Mass General Brigham（MGB）生物样本库的 SNP 和 EHR 数据，为 AA 总体建立 T2D 多基因风险预测模型。在该研究中，超过87%的参与者具有欧洲血统，而 AA 仅约占5%。我们选择 AA 群体作为目标总体，欧洲祖源群体作为源总体。二元响应变量 $Y$ 表示通过人工病历审阅得到的 T2D 标签，两个总体中这种标签的数量都有限。AA 总体有 $n_{\mathcal{T}} = 95$ 个有标签观测、$N_{\mathcal{T}} = 2900$ 个无标签观测；欧洲裔总体有 $n_{\mathcal{S}} = 1137$ 个有标签观测、$N_{\mathcal{S}} = 50242$ 个无标签观测。

我们的目标是借助较大欧洲裔总体的数据和替代变量 $\mathbf{S}$ 的观测，为 AA 目标总体建立基于 SNP、年龄和性别预测 $Y$ 的多基因风险模型。$\mathbf{S}$ 包含 Hong 等（2021）通过知识图谱选取的 T2D 相关 EHR 编码计数。由于不同人口统计学总体的《国际疾病分类》（ICD）计费编码可能存在系统性编码偏差，我们移除 ICD 编码，仅使用76项实验室检查和药物处方作为替代变量。例如，替代变量包括 HbA1c 检查次数和二甲双胍处方数量；二甲双胍是控制 T2D 患者血糖的常见药物。所有计数变量因分布偏斜，均

作 $x \mapsto \log(1+x)$ 变换。从既往报道能够预测 T2D、低密度脂蛋白或高密度脂蛋白胆固醇相关的 SNP 中（Kozak 和 Anunciado-Koza，2009；Rodrigues 等，2013），进一步去掉次要等位基因频率小于0.08，以及 SNP 之间相关性大于0.5的 SNP，最终确定248个 SNP。加上年龄和性别，共有250个候选预测变量组成 $\mathbf{X}$。我们在各总体内分别将 $\mathbf{X}$ 和 $\mathbf{S}$ 标准化为均值0、方差1。

与模拟研究类似，使用 STRIFLE、SUP、CS、SUPTrans 和 SAS 建立 T2D 多基因风险预测模型。采用10折交叉验证选取调节参数。为比较不同方法的表现，通过10折交叉验证估计样本外 AUC 和均方误差（MSE）；MSE 定义为 T2D 预测概率与真实二元 T2D 状态之差的平方的平均值。将该过程重复20次，报告每种方法的平均样本外 AUC 和 MSE。我们还使用源标签数据估计 $\boldsymbol{\beta}$，再在目标标签数据上验证，以展示总体间的潜在异质性，将该方法记为 SUPSource。表4表明，STRIFLE 成功利用源总体和目标无标签数据，获得最佳的估计与预测精度。

**表4**。SUP、CS、SUPTrans、SAS 和 STRIFLE 对 $\boldsymbol{\beta}_0$ 估计的预测精度（AUC）和估计精度（MSE），并与在目标标签数据上评估的源监督估计量 SUPSource 比较。Source Estimate＝源估计；Target Estimate＝目标估计。

| | Source Estimate | Target Estimate | | | | |
|---|---|---|---|---|---|---|
| | SUPSource | SUP | CS | SUPTrans | SAS | STRIFLE |
| AUC | 0.77 | 0.66 | 0.77 | 0.76 | 0.79 | **0.85** |
| MSE | 0.21 | 0.21 | 0.21 | 0.20 | 0.19 | **0.17** |

所有方法得到的 $\boldsymbol{\beta}_0$ 估计值列于补充材料第 S.11 节。图1进一步展示各方法中绝对值超过0.1的主要信号的系数估计。与预期一致，年龄在所有方法中都是最显著的预测变量，估计效应量也相近。性别虽然在源总体中的系数较大，但在 SUP、SAS 和 STRIFLE 中并未被识别为有信息量的预测变量。与 Grant 等（2006）的发现一致，所有方法都选择了 SNP rs7903146，这反映出该位点与 T2D 已知的关联。总体上，SUPSource 选择的 SNP 与其他方法明显不同，凸显出总体之间的异质性以及 $E_{\mathcal{S}}(Y \mid \mathbf{X})$ 与 $E_{\mathcal{T}}(Y \mid \mathbf{X})$ 的差异。因此，为实现算法公平性，应对欧洲裔和 AA 祖源群体采用不同的 T2D 风险预测模型。对于 AA 人群，根据 STRIFLE，与 T2D 关联最显著的两个 SNP 是 rs174546 和 rs7903146：前者与脂肪酸去饱和酶密切相关（Billings 和 Florez，2010；Sergeant 等，2012）；Palmer 等（2011）则提示后者是 AA 人群中糖尿病易感性的因果变异。

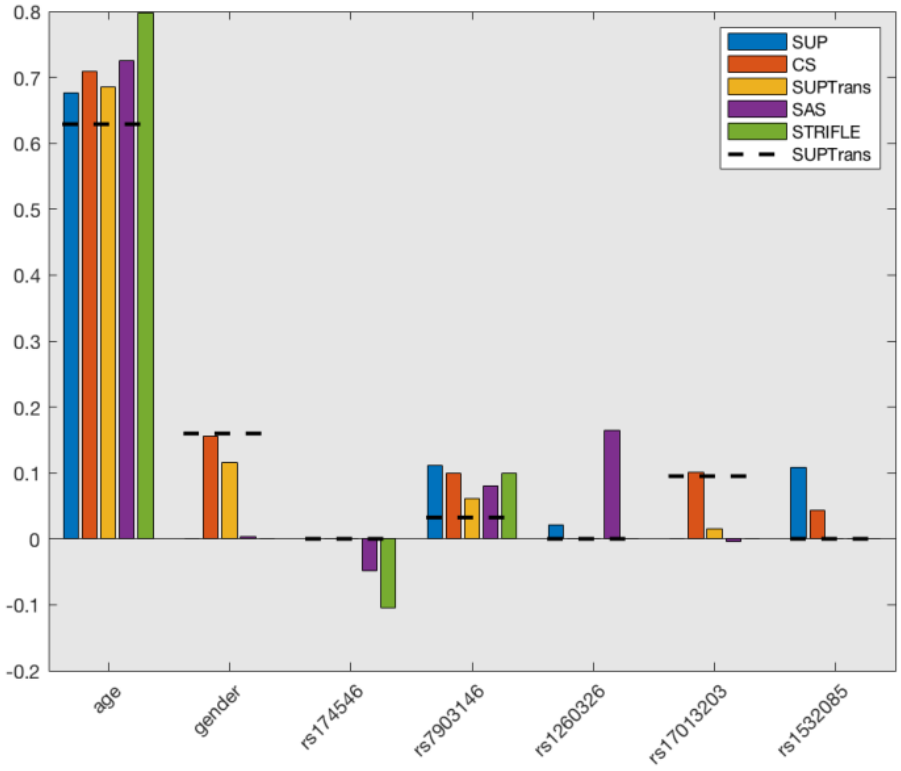



**图1**。 以 SUPSource 为参照，展示 SUP、CS、SUPTrans、SAS 和 STRIFLE 中绝对值大于0.1的主要信号对应的 $\beta_0$ 估计。图内 age＝年龄，gender＝性别，其余横轴项目为 SNP 位点，纵轴为系数估计值，方法缩写保留原样。〔译注：原图注将 STRIFLE 拼作“STIFLE”；图中虚线图例原写作“SUPTrans”，但原图注将参照方法说明为 SUPSource。本译文保留原图，不擅自改图。〕

## 6 结论与讨论

本文在半监督学习框架下提出一种自适应迁移学习方法。不同于其他已有方法，我们的方法既由模型辅助，又由替代变量辅助。与现有非模型辅助的迁移学习方法相比，在两个总体均有大量无标签观测时，密度比模型可以得到相对良好的估计，因而提高源总体的可迁移性；这种数据情形在大规模生物医学研究中很常见。通过采用包含强预测性替代变量的插补模型，可以有效利用目标无标签观测，并放宽最终结局模型的稀疏性假设；这在实践中非常重要，例如多基因风险预测模型中的 SNP 信号通常较弱而稠密。我们并非粗略拼接这两种策略，而是仔细构造方法，尤其是估计方程，使其对严重模型误设、分布假设被违反和负迁移都保持稳健。

所提出的三重稳健迁移过程聚焦于协变量偏移情形下插补模型的估计。事实上，由于 $p_{Y|\mathbf{X}}^{(\mathcal{T})}$ 可以不同于 $p_{Y|\mathbf{X}}^{(\mathcal{S})}$，只有在密度比模型正确设定时，才能通过迁移源无标签观测来改善 $\boldsymbol{\beta}$ 的估计速率。如何在半监督框架中直接对结局模型，即对 $\boldsymbol{\beta}$，稳健而高效地开展迁移学习，值得进一步研究，但超出了本文范围。此外，定理1、2中的理论结果，也为受限强凸条件下其他高维非凸问题的迁移学习提供了启示。

### 致谢

作者感谢编辑、副编辑及三位审稿人提出建设性意见和建议，这些意见显著改进了本文。本研究获美国国立卫生研究院（NIH）项目 R01LM013614、R01HL089778，以及本特利大学健康与商业中心资助。

### 披露声明

作者声明没有需要披露的利益冲突。

## 参考文献

以下保留原文全部43条参考文献的作者、年份及出版信息，并提供中文题名；英文题名同时保留，便于检索。原文书目信息未作时效更新。

**[1]** Abuduweili, A., Li, X., Shi, H., Xu, C.-Z. & Dou, D. (2021), Adaptive consistency regularization for semi-supervised transfer learning, in ‘Proceedings of the IEEE/CVF conference on computer vision and pattern recognition’, pp. 6923–6932.

中文题名：半监督迁移学习的自适应一致性正则化。

**[2]** Ashley, E. A. (2016), ‘Towards precision medicine’, Nature Reviews Genetics **17**(9), 507–522.

中文题名：迈向精准医疗。

**[3]** Athey, S., Tibshirani, J. & Wager, S. (2019), ‘Generalized random forests’, The Annals of Statistics **47**(2), 1148–1178.

中文题名：广义随机森林。

**[4]** Bastani, H. (2021), ‘Predicting with proxies: Transfer learning in high dimension’, Management Science **67**(5), 2964–2984.

中文题名：借助代理变量进行预测：高维迁移学习。

**[5]** Billings, L. K. & Florez, J. C. (2010), ‘The genetics of type 2 diabetes: what have we learned from gwas?’, Annals of the New York Academy of Sciences **1212**(1), 59–77.

中文题名：2型糖尿病的遗传学：我们从全基因组关联研究中学到了什么。

**[6]** Chakrabortty, A. & Cai, T. (2018), ‘Efficient and adaptive linear regression in semi-supervised settings’, The Annals of Statistics **46**(4), 1541–1572.

中文题名：半监督情形下高效且自适应的线性回归。

**[7]** Dukes, O., Vansteelandt, S. & Whitney, D. (2021), ‘On doubly robust inference for double machine learning’, arXiv preprint arXiv:2107.06124 .

中文题名：关于双重机器学习的双重稳健推断。

**[8]** Fan, J. & Li, R. (2001), ‘Variable selection via nonconcave penalized likelihood and its oracle properties’, Journal of the American statistical Association **96**(456), 1348–1360.

中文题名：通过非凹惩罚似然进行变量选择及其预言性质。

**[9]** Farrell, M. H., Liang, T. & Misra, S. (2020), ‘Deep learning for individual heterogeneity: An automatic inference framework’, arXiv preprint arXiv:2010.14694 .

中文题名：用于个体异质性的深度学习：自动推断框架。

**[10]** Farrell, M. H., Liang, T. & Misra, S. (2021), ‘Deep neural networks for estimation and inference’, Econometrica **89**(1), 181–213.

中文题名：用于估计和推断的深度神经网络。

**[11]** Ferryman, K. & Pitcan, M. (2018), ‘Fairness in precision medicine’.

中文题名：精准医疗中的公平性。

**[12]** Grant, S. F., Thorleifsson, G., Reynisdottir, I., Benediktsson, R., Manolescu, A., Sainz, J., Helgason, A., Stefansson, H., Emilsson, V., Helgadottir, A. et al. (2006), ‘Variant of transcription factor 7-like 2 (tcf7l2) gene confers risk of type 2 diabetes’, Nature genetics **38**(3), 320–323.

中文题名：转录因子7样蛋白2（TCF7L2）基因变异带来2型糖尿病风险。

**[13]** Gronsbell, J., Liu, M., Tian, L. & Cai, T. (2022), ‘Efficient evaluation of prediction rules in semi-supervised settings under stratified sampling’, Journal of the Royal Statistical Society Series B: Statistical Methodology .

中文题名：分层抽样下半监督情形中的预测规则高效评估。

**[14]** Hodson, R. (2016), ‘Precision medicine’, Nature **537**(7619), S49–S49.

中文题名：精准医疗。

**[15]** Hong, C., Rush, E., Liu, M., Zhou, D., Sun, J., Sonabend, A., Castro, V. M., Schubert, P., Panickan, V. A., Cai, T. et al. (2021), ‘Clinical knowledge extraction via sparse embedding regression (keser) with multi-center large scale electronic health record data’, NPJ digital medicine **4**(1), 1–11.

中文题名：利用多中心大规模电子健康记录数据，通过稀疏嵌入回归（KESER）提取临床知识。

**[16]** Hou, J., Guo, Z. & Cai, T. (2021), ‘Surrogate assisted semi-supervised inference for high dimensional risk prediction’, arXiv preprint arXiv:2105.01264 .

中文题名：面向高维风险预测的替代变量辅助半监督推断。

**[17]** Huang, J., Gretton, A., Borgwardt, K., Schölkopf, B. & Smola, A. (2006), ‘Correcting sample selection bias by unlabeled data’, Advances in neural information processing systems **19**.

中文题名：使用无标签数据校正样本选择偏差。

**[18]** Imai, K. & Ratkovic, M. (2014), ‘Covariate balancing propensity score’, Journal of the Royal Statistical Society Series B: Statistical Methodology **76**(1), 243–263.

中文题名：协变量平衡倾向评分。

**[19]** Jakubovitz, D., Uliel, D., Rodrigues, M. & Giryes, R. (2023), ‘An information-theoretic approach to semi-supervised transfer learning’, arXiv preprint arXiv:2306.06731 .

中文题名：半监督迁移学习的信息论方法。

**[20]** Kozak, L. & Anunciado-Koza, R. (2009), ‘Ucp1: its involvement and utility in obesity’, International journal of obesity **32**(S7), S32.

中文题名：UCP1：其在肥胖中的参与及应用价值。

**[21]** Li, S., Cai, T. & Duan, R. (2021), ‘Targeting underrepresented populations in precision medicine: A federated transfer learning approach’, arXiv preprint arXiv:2108.12112 .

中文题名：面向精准医疗中代表性不足的总体：联邦迁移学习方法。

**[22]** Li, S., Cai, T. T. & Li, H. (2022), ‘Transfer learning for high-dimensional linear regression: Prediction, estimation and minimax optimality’, Journal of the Royal Statistical Society Series B: Statistical Methodology **84**(1), 149–173.

中文题名：高维线性回归的迁移学习：预测、估计与极小极大最优性。

**[23]** Li, S., Zhang, L., Cai, T. T. & Li, H. (2023), ‘Estimation and inference for high-dimensional generalized linear models with knowledge transfer’, Journal of the American Statistical Association pp. 1–12.

中文题名：具有知识迁移的高维广义线性模型的估计与推断。

**[24]** Liu, M., Zhang, Y., Liao, P. K. & Cai, T. (2020), ‘Augmented transfer regression learning with semi-non-parametric nuisance models’, arXiv preprint arXiv:2010.02521 .

中文题名：使用半非参数干扰模型的增广迁移回归学习。

**[25]** Loh, P.-L. & Wainwright, M. J. (2015), ‘Regularized m-estimators with nonconvexity: Statistical and algorithmic theory for local optima’, The Journal of Machine Learning Research **16**(1), 559–616.

中文题名：具有非凸性的正则化M估计量：局部最优解的统计与算法理论。

**[26]** Martin, A. R., Kanai, M., Kamatani, Y., Okada, Y., Neale, B. M. & Daly, M. J. (2019), ‘Clinical use of current polygenic risk scores may exacerbate health disparities’, Nature genetics **51**(4), 584–591.

中文题名：现有多基因风险评分的临床使用可能加剧健康差距。

**[27]** Negahban, S. N., Ravikumar, P., Wainwright, M. J., Yu, B. et al. (2012), ‘A unified framework for high-dimensional analysis of $m$ -estimators with decomposable regularizers’, Statistical science **27**(4), 538–557.

中文题名：具有可分解正则化项的M估计量高维分析统一框架。

**[28]** Palmer, N. D., Hester, J. M., An, S. S., Adeyemo, A., Rotimi, C., Langefeld, C. D., Freedman, B. I., Ng, M. C. & Bowden, D. W. (2011), ‘Resequencing and analysis of variation in the tcf7l2 gene in african americans suggests that snp rs7903146 is the causal diabetes susceptibility variant’, Diabetes **60**(2), 662–668.

中文题名：非裔美国人TCF7L2基因的重测序与变异分析提示SNP rs7903146是糖尿病易感性的因果变异。

**[29]** Papyan, V., Han, X. & Donoho, D. L. (2020), ‘Prevalence of neural collapse during the terminal phase of deep learning training’, Proceedings of the National Academy of Sciences **117**(40), 24652–24663.

中文题名：深度学习训练终末阶段神经坍缩的普遍性。

**[30]** Raskutti, G., Wainwright, M. J. & Yu, B. (2011), ‘Minimax rates of estimation for high-dimensional linear regression over $l_q$ -balls’, IEEE transactions on information theory **57**(10), 6976–6994.

中文题名：在 $l_q$ 球上的高维线性回归估计的极小极大速率。

**[31]** Rodrigues, A. C., Sobrino, B., Genvigir, F. D. V., Willrich, M. A. V., Arazi, S. S., Dorea, E. L., Bernik, M. M. S., Bertolami, M., Faludi, A. A., Brion, M. et al. (2013), ‘Genetic variants in genes related to lipid metabolism and atherosclerosis, dyslipidemia and atorvastatin response’, Clinica Chimica Acta **417**, 8–11.

中文题名：与脂质代谢相关基因中的遗传变异及动脉粥样硬化、血脂异常和阿托伐他汀反应。

**[32]** Sergeant, S., Hugenschmidt, C. E., Rudock, M. E., Ziegler, J. T., Ivester, P., Ainsworth, H. C., Vaidya, D., Case, L. D., Langefeld, C. D., Freedman, B. I. et al. (2012), ‘Differences in arachidonic acid levels and fatty acid desaturase (fads) gene variants in african americans and european americans with diabetes or the metabolic syndrome’, British Journal of Nutrition **107**(4), 547–555.

中文题名：患糖尿病或代谢综合征的非裔美国人与欧裔美国人之间，花生四烯酸水平及脂肪酸去饱和酶（FADS）基因变异的差异。

**[33]** Tan, Z. et al. (2020), ‘Model-assisted inference for treatment effects using regularized calibrated estimation with high-dimensional data’, Annals of Statistics **48**(2), 811–837.

中文题名：使用高维数据的正则化校准估计开展治疗效应的模型辅助推断。

**[34]** Tian, Y. & Feng, Y. (2022), ‘Transfer learning under high-dimensional generalized linear models’, Journal of the American Statistical Association pp. 1–14.

中文题名：高维广义线性模型下的迁移学习。

**[35]** Tibshirani, R. (1996), ‘Regression shrinkage and selection via the lasso’, Journal of the Royal Statistical Society: Series B (Methodological) **58**(1), 267–288.

中文题名：通过Lasso进行回归收缩与选择。

**[36]** West, K. M., Blacksher, E. & Burke, W. (2017), ‘Genomics, health disparities, and missed opportunities for the nation’s research agenda’, Jama **317**(18), 1831–1832.

中文题名：基因组学、健康差距以及国家研究议程错失的机会。

**[37]** Zhang, C.-H. (2010), ‘Nearly unbiased variable selection under minimax concave penalty’, The Annals of statistics **38**(2), 894–942.

中文题名：极小极大凹惩罚下的近乎无偏变量选择。

**[38]** Zhang, Y., Chakrabortty, A. & Bradic, J. (2021), ‘Double robust semi-supervised inference for the mean: Selection bias under mar labeling with decaying overlap’, arXiv preprint arXiv:2104.06667 .

中文题名：均值的双重稳健半监督推断：重叠程度衰减时随机缺失标注下的选择偏差。

**[39]** Zhang, Y., Chakrabortty, A. & Bradic, J. (2023a), ‘Double robust semi-supervised inference for the mean: Selection bias under mar labeling with decaying overlap’, Information and Inference: A Journal of the IMA **12**(3), iaad021.

中文题名：均值的双重稳健半监督推断：重叠程度衰减时随机缺失标注下的选择偏差。

**[40]** Zhang, Y., Chakrabortty, A. & Bradic, J. (2023b), ‘Semi-supervised causal inference: Generalizable and double robust inference for average treatment effects under selection bias with decaying overlap’, arXiv preprint arXiv:2305.12789 .

中文题名：半监督因果推断：重叠程度衰减的选择偏差下，平均治疗效应的可推广双重稳健推断。

**[41]** Zhang, Y., Liu, M., Neykov, M. & Cai, T. (2022), ‘Prior adaptive semi-supervised learning with application to ehr phenotyping’, Journal of Machine Learning Research **23**(83), 1–25.

中文题名：先验自适应半监督学习及其在EHR表型识别中的应用。

**[42]** Zhou, D., Liu, M., Li, M. & Cai, T. (2022), ‘Doubly robust augmented model accuracy transfer inference with high dimensional features’, arXiv preprint arXiv:2208.05134 .

中文题名：具有高维特征的双重稳健增广模型准确性迁移推断。

**[43]** Zhu, X. J. (2005), ‘Semi-supervised learning literature survey’.

中文题名：半监督学习文献综述。