半参数共形预测

Semiparametric conformal prediction · 非官方中文全文译文

Ji Won Park（Prescient Design, Genentech）；Kyunghyun Cho（Prescient Design, Genentech；纽约大学数据科学中心）。

原始出版物：Park, J. W. 与 Cho, K.（2025），Proceedings of the 28th International Conference on Artificial Intelligence and Statistics，PMLR 258:3880–3888。官方论文页面。原文及本译文按 CC BY 4.0 提供。本文为中文翻译与重新排版，不代表作者或出版方认可；原始图表保留，图注、表注及术语另附中文。原文中的符号、公式编号及可能的排印问题按原文保留，必要时明确标注。

原文首页出版脚注译文：“第27届国际人工智能与统计会议（AISTATS）2024论文集，西班牙瓦伦西亚。PMLR：卷号待定。版权 © 2024 归作者所有。”译注：该脚注保留了模板信息；正式出版信息以官方 PMLR 页面所列 AISTATS 2025、卷258 为准。

摘要

许多对风险敏感的应用，需要针对多个可能相互关联的目标变量给出经过良好校准的预测集，而预测算法在这些变量上的误差也可能彼此相关。本文旨在构造共形预测集，同时考虑向量值非一致性分数的联合相关结构。借鉴多元分位数与半参数统计的丰富文献，我们提出一种估计分数的 $1-\alpha$ 分位数的算法，其中 α 是用户指定的误覆盖率。具体而言，我们利用非参数藤 copula 灵活地估计分数的联合累积分布函数（CDF），并利用分位数的影响函数提高分位数估计的渐近效率。藤分解使我们的方法能够良好地扩展到大量目标。除保证渐近精确覆盖外，该方法在一系列实际回归问题中也能达到期望的覆盖率和有竞争力的效率，包括校准集中标签随机缺失的问题。

1 引言

工业与制药应用中的许多问题都可以表述为多目标回归，即根据输入特征预测取值于 $\mathbb{R}^d$ 的向量目标。例如，在药物发现早期，需要联合刻画候选分子的 ADME（吸收、分布、代谢和排泄）性质。支配这些性质的复杂生物物理过程，会表现为测量结果之间的相关性，而且这种相关性往往在尾部尤其明显（Jain 等，2017；Niepel 等，2019；Du 等，2023）。

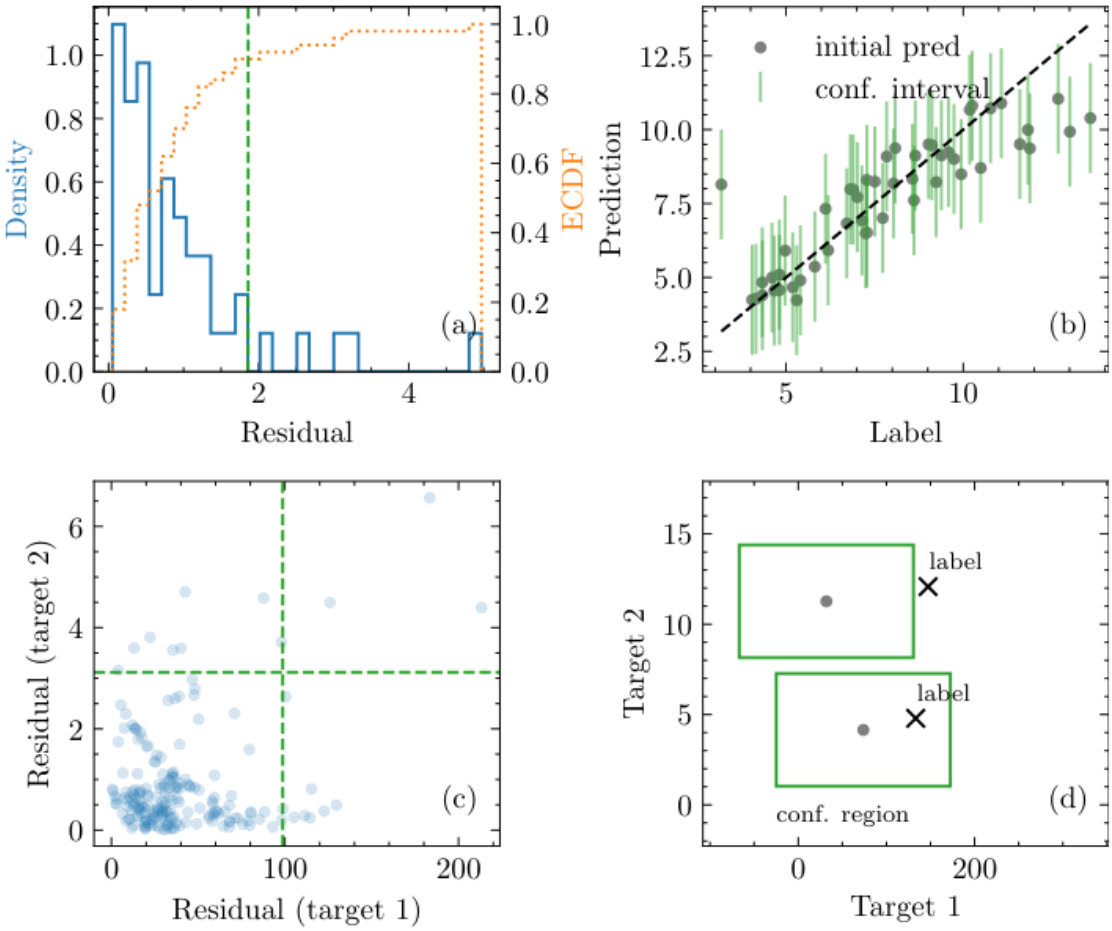


图1。 上：单目标拆分共形预测（CP）。(a) 中的绿色虚线标记校准分数的 $1-\alpha$ 分位数，它确定 (b) 中测试预测周围的置信区间。下：针对两个目标的独立拆分 CP；(c) 中的绿色虚线标记 $\sqrt{1-\alpha}$ 分位数。(d) 展示两个测试实例的大型预测集。图中文字：Density＝密度；ECDF＝经验累积分布函数；Prediction＝预测；Residual＝残差；Label＝标签；initial pred＝初始预测；conf. interval＝置信区间；Target＝目标；conf. region＝置信区域。

我们经常需要的是刻画不确定性的预测集，而非点估计（Eklund 等，2015；Cortes-Ciriano 和 Bender，2020）。药物化学家可以根据某个分子的不确定性，决定是否在湿实验室中测试它。表达不确定性的一种方式，是在指定覆盖水平下给出置信度。共形预测（CP）是一个强大的框架：它可以包装任意底层预测算法，为任意数据分布产生有效的置信集（Gammerman 等，1998；Saunders 等，1999；Vovk 等，2005）。随机变量 Y 的 $1-\alpha$ 水平置信集记为 $\Gamma_{1-\alpha}$；若其包含 Y 真值的概率至少为 $1-\alpha$，即 $\mathbb{P}\left[Y \in \Gamma_{1-\alpha}\right] \geq 1-\alpha$，该置信集就是有效的。

秩与分位数的概念是 CP 算法的核心（Kuchibhotla，2020）。在 $1-\alpha$ 水平下，通过提取非一致性分数的 $1-\alpha$ 分位数来构造置信集；该分数衡量预测偏离标签的程度。例如，在单目标回归的拆分 CP 中（Papadopoulos 等，2002；Lei 等，2015），可以把分数定义为绝对误差，对校准集上计算出的分数排序，从而取得 $1-\alpha$ 分位数，如图1(a,b)所示。

也可以针对每个目标独立应用 CP，不考虑分数之间的相关性（Papadopoulos 等，2002）。此时与单目标情形一样进行排序，但对每个目标 j 使用边际水平 $1-\alpha_j > 1-\alpha$，使其满足所需的整体覆盖水平 $1-\alpha$。然而，把分数视为独立会失去潜在的效率增益，即获得更紧预测的机会（Neeven 和

Smirnov，2018）。图1(c,d)展示双目标回归的独立 CP。在各边际上设置 $1-\alpha_j=\sqrt{1-\alpha}$ 会产生较大的置信集。一般而言，随着 d 增大，$1-\alpha_j$ 被迫更加接近1，而校准集可能不足以支持如此极端的水平。

我们改为把各目标的分数视为取值于 $\mathbb{R}^d$ 的随机向量 S，从而联合建模目标。关键问题变成：如何定义观测到的 S 的 $1-\alpha$ 分位数？尽管 $\mathbb{R}$ 中的秩与分位数构成非参数统计的基础（Lehmann 等，1975），但当 $d>1$ 时，$\mathbb{R}^d$ 中不存在典范排序。已有多种多元分位数概念，包括基于统计深度（Liu，1990；Zuo，2003）和几何的方法（Chaudhuri，1996；Hallin 等，2010）。我们基于 Messoudi 等（2021）的工作；他们提出使用 copula，这是一种用于建模多元随机变量依赖结构的统计工具（Nelsen，2006）。copula 可用于估计分数的联合 CDF：$F(s)=\mathbb{P}\left[S_1\le s_1,\ \ldots,\ S_d\le s_d\right]$，其中 $s\in\mathbb{R}^d$。分位数就是其广义逆，即 p 水平曲线 $F^{-1}(p)=\{s\in\mathbb{R}^d: F(s)=p\}$。图2展示了对相关分数（灰点）拟合的 copula 等值线（彩色轮廓）。当 $1-\alpha=0.9$ 时，0.9水平线上包含的分位数范数小于独立目标方法的分位数（绿点），说明联合建模可以得到更高效的预测集。

我们方法的主要创新，是把确定 $F^{-1}(1-\alpha)$ 的任务视为半参数推断问题。我们的目标是在用非参数模型灵活估计 F 的同时，确保对特定关注估量（即分位数 $F^{-1}(1-\alpha)$）的推断仍然稳健而精确。

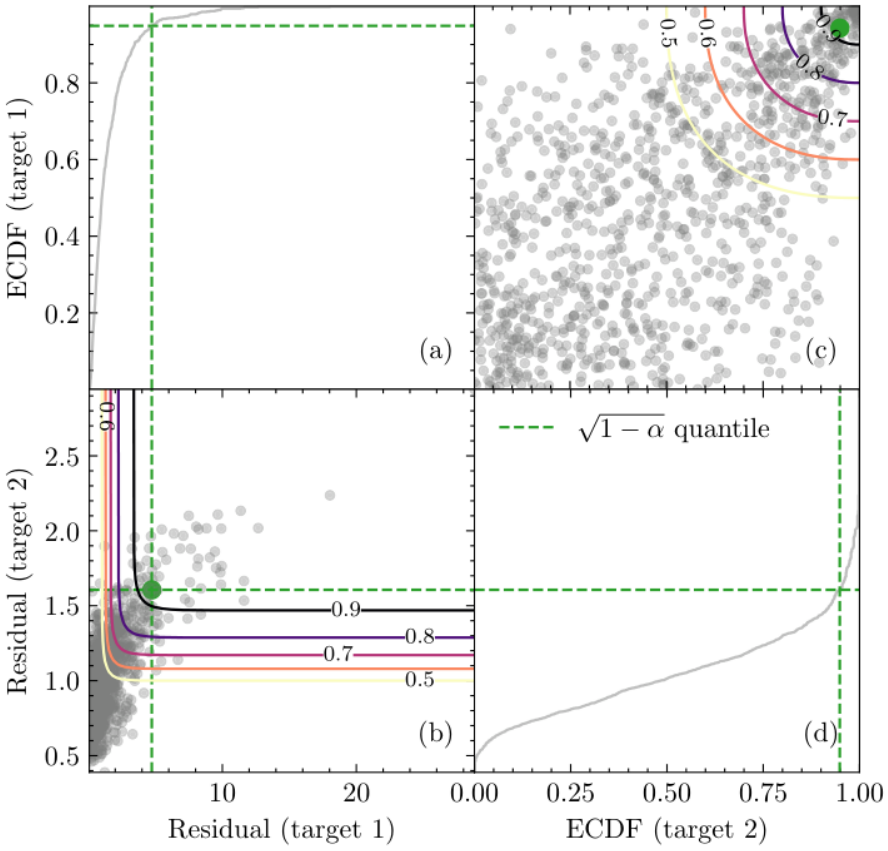


图2。 具有上尾相关性及长尾边际的分数。相较于各分数独立的 $\sqrt{0.9}$ 分位数（绿点），联合0.9分位数可以产生更高效的预测集。(a,d)：分数的边际经验 CDF，由此提取 $\sqrt{0.9}$ 分位数。(b)：分数及其联合 CDF 等值线，黑线表示0.9水平。(c)：在 copula 空间中观察的(b)。ECDF＝经验累积分布函数；Residual＝残差；target＝目标；quantile＝分位数。

作为对先前工作的更新，我们使用藤 copula（Bedford 和 Cooke，2002）估计 F，具体采用表达能力更强的非参数变体（Nagler 等，2017）。藤 copula 将高维密度分解成二元密度的乘积，因此能良好地扩展到许多目标。此前 CP 中的 copula 应用仅限于经验 copula 或少量参数族；当观测稀疏或模型误设时，它们可能出现偏差（Messoudi 等，2021；Sun 和 Yu，2024）。我们还说明，一种特定的 copula 模型能够处理校准集中随机缺失（MAR）的目标标签。

推断出 F 后，我们并非简单使用分位数的代入估计，而是针对这一特定泛函，利用其影响函数（Hampel，1974）计算一步估计量（Le Cam，1956）。影响函数最好理解为：针对 F 的微小扰动，泛函所具有的广义梯度。这一去偏估计量专门面向所关注的分位数估量，具有更好的理论性质，如 $\sqrt{n}$ 相合性和渐近正态性（Hines 等，2022）。

贡献：（1）提出用非参数藤 copula 灵活估计多元共形校准中非一致性分数的联合分布（第5.1节）。（2）提出半参数一步估计量，对构造预测集所用的 $1-\alpha$ 分数分位数去偏（第5.2节）。（3）证明本方法的预测集具有渐近精确覆盖，并给出一个具有有限样本分布无关有效性的变体。（4）在多种真实回归问题上实证展示本方法的有效性和效率（第6.2节）。

2 相关工作

大量工作致力于把共形化分位数回归（Romano 等，2019）扩展到多个目标（Kong 和 Mizera，2012；Paindaveine 和 Šiman，2011；Feldman 等，2023）。与此同时，也有研究试图提高某些多目标预测器类别中完整 CP 的计算效率（Johnstone 和 Ndiaye，2022；Nouretdinov 等，2001）。我们的重点是不对底层算法增加额外假设而改进校准步骤。

当响应变量有多个时，一种常见方法是设计单个标量分数，例如向量值预测与标签之间的 L_2 距离（Kuleshov 等，2018；Johnstone 和 Cox，2021；Messoudi 等，2022；Feldman 等，2023）。但这意味着必须选择目标聚合方式，而且所得分数对不同目标预测和标签之间的相对尺度敏感。此外，计算分数需要观察全部 d 个目标的标签；当 d 很大时，这可能并不现实。

另一种方法是分别对每个目标的预测进行共形化（Neeven 和 Smirnov，2018）。逐目标计算非一致性分数，并为目标 j 提取 $1-\alpha_j$ 分位数，使 $\prod_j\left(1-\alpha_j\right)=1-\alpha$。若平等对待所有目标，就对全部 j 设置 $1-\alpha_j=(1-\alpha)^{1/d}>1-\alpha$。注意，随着 d 增大，$(1-\alpha)^{1/d}$ 趋近1，从而产生低效的预测集。这种极端水平也要求校准数据集足够大。

若分数高度相关，就可以利用依赖结构提高效率。Messoudi 等（2021）率先用 copula 联合建模向量分数的分布。Sun 和 Yu（2024）将此思想应用于多步时间序列预测。以往工作使用的经验 copula 在观测稀疏时可能不稳定，尤其是在接近所关注分位数水平的上尾。Messoudi 等（2021）还使用 Gumbel 和高斯等简单参数 copula；它们可提供更平滑的拟合，但可能受到模型误设的影响。第4节回顾 copula。

3 问题设定

考虑多元回归任务：给定数据集 $\{(X^{(i)}, Y^{(i)})\}_{i\in\mathcal{J}}$，输入特征为 $X^{(i)} \in \mathcal{X}$，向量值标签为 $Y^{(i)} \in \mathbb{R}^d$。该数据集可视为从联合分布 $P_{XY} = P_X \times P_{Y|X}$ 抽取的 $|\mathcal{J}|$ 个可交换样本。给定新的测试点 X^* 和预先指定的误覆盖水平 $\alpha \in [0, 1)$，我们希望确定具有有效覆盖的集合 $\Gamma_{1-\alpha}(X^*) \subset \mathbb{R}^d$。

定义1（边际有效性）。若集合 $\Gamma_{1-\alpha}$ 包含响应 Y^* 的概率至少为 $1-\alpha$，则称其在水平 $1-\alpha$ 下边际有效：

$$\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}(X^*)\right] \geq 1 - \alpha. \qquad (1)$$

注1：此条件弱于条件有效性 $\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}(X^*) \mid X^*\right] \geq 1-\alpha$。

假设算法 $\widehat{f} : \mathcal{X} \to \mathbb{R}^d$ 根据输入预测多个响应。我们的目标是为这个此后称为“底层”算法的模型配备有效置信集。正文始终假设 $\widehat{f}$ 为点预测器；第17节则给出条件密度估计器 $\widehat{f} : \mathcal{X} \to \mathbb{R}^d \times \mathbb{R}^d_+$ 的结果，该估计器输出高斯预测分布的均值和方差。

4 背景

共形预测（CP）在不对数据分布 P_{XY} 作任何假设的情况下构造预测集（Vovk 等，2005）。只要数据可交换，就保证该集合在有限样本下边际有效。CP 最初在直推式设定下提出（Gammerman 等，1998；Saunders 等，1999；Vovk 等，2005）。本文关注拆分（归纳式）CP（Papadopoulos 等，2002；Lei 等，2018）：把索引集为 $\mathcal{J}$ 的带标签数据集 $\{(X^{(i)}, Y^{(i)})\}_{i\in\mathcal{J}}$ 分成用于拟合底层算法 $\widehat{f}$ 的正式训练数据 $\mathcal{J}_{\text{train}}$，以及用于共形化的校准数据 $\mathcal{J}_{\text{cal}}$。

注2：为清晰起见，我们用拆分 CP 表述框架，但它也适用于完整（直推式）CP（Vovk 等，2005）、CV（Vovk，2015）以及 jackknife（Barber 等，2021）变体。

校准涉及非一致性分数 $V(X, Y, \widehat{f})$，它衡量查询点 (X, Y) 偏离 $\widehat{f}$ 从训练集学到的模式的程度。数值越大，表示不一致程度越高。

先考虑 $d = 1$ 的回归情况，把分数定义为绝对误差：$V(X^{(i)}, Y^{(i)}, \widehat{f}) = \left|\widehat{f}(X^{(i)}) - Y^{(i)}\right| = : S^{(i)} \in \mathbb{R}_+$。给定误覆盖率 $\alpha \in [0, 1]$ 和测试输入 $X^* \in \mathcal{X}$，共形集收集产生最小分数的结果：

$$\Gamma_{1-\alpha}(X^*) = \{Y \in \mathbb{R} : V(X^*, Y, \widehat{f}) \leq Q_{1-\alpha}\}. \qquad (2)$$

其中 $Q_{1-\alpha}$ 是在大小为 $n = |\mathcal{J}_{\text{cal}}|$ 的校准集上计算的分数 $\{S^{(i)}\}$ 中第 $\lceil (1-\alpha)(n+1) \rceil$ 小的值。等价地，

$$\widehat{F}(Q_{1-\alpha}) = \frac{\lceil (1-\alpha)(n+1) \rceil}{n+1}. \qquad (3)$$

其中 $\widehat{F}(s) = \frac{1}{n}\sum_{i\in\mathcal{I}_{\text{cal}}} \mathbb{1}\left[S^{(i)} \le s\right]$ 是经验 CDF。应用式(2)可得置信区间 $\left[\widehat{f}\left(X^*\right) - Q_{1-\alpha},\ \widehat{f}\left(X^*\right) + Q_{1-\alpha}\right]$。更多细节参见 Shafer 和 Vovk（2008）以及 Angelopoulos 和 Bates（2021）。

当 $d > 1$ 时，可采用逐目标绝对误差作为分数：

$$V\left(X^{(i)},\ Y^{(i)},\ \widehat{f}\right)_j = \left|\widehat{f}\left(X_j^{(i)}\right) - Y_j^{(i)}\right| = \ : S_j^{(i)}. \qquad (4)$$

上标 $i \in \mathcal{I}_{\text{cal}}$ 仍索引实例，下标 $j \in [d]$ 索引目标维度。所得多元分数可以写成：

$$S^{(i)} = \left[S_1^{(i)},\ \ldots,\ S_j^{(i)}\right] \in \mathbb{R}_+^d. \qquad (5)$$

随后用向量偏序 $\preccurlyeq$ 重新定义式(2)中的 $\le$ 运算符：

$$\Gamma_{1-\alpha}\left(X^*\right) = \{Y \in \mathbb{R}^d : V\left(X^*,\ Y,\ \widehat{f}\right) \preccurlyeq Q_{1-\alpha}\}. \qquad (6)$$

对 $v,\ w \in \mathbb{R}^d$，当 $v_1 \le w_1,\ \ldots,\ v_d \le w_d$ 时，$v \preccurlyeq w$。为解决剩下的问题，即如何对式(3)中的分数向量 CDF $\widehat{F}$ 建模，我们转向 copula。

Copula 是非常适合建模多元随机变量依赖结构的统计工具。

定义2（Copula）。给定随机向量 $S = \left[S_1,\ \ldots,\ S_d\right]$，记各分量变量 S_j（$j \in [d]$）的边际 CDF 为 $F_j\left(s_j\right) = \mathbb{P}\left[S_j \le s_j\right]$。$S$ 的 copula $C : [0,\ 1]^d \to [0,\ 1]$ 是 $U = \left[F_1\left(S_1\right),\ \ldots,\ F_d\left(S_d\right)\right]$ 的联合 CDF：

$$C\left(u_1,\ \ldots,\ u_d\right) = \mathbb{P}\left[F(S) \preccurlyeq u\right]. \qquad (7)$$

注意，每个 $F_j\left(S_j\right)$ 都是 S_j 的概率积分变换（PIT），服从区间 $[0,\ 1]$ 上的均匀分布。因此，在消除边际分布中的全部复杂性后，copula 函数把随机变量连接（耦合）起来，刻画它们的依赖结构。下述定理确立其存在性和唯一性。

定理1（Sklar 定理，Sklar，1959）。若随机向量 S 的联合 CDF 为 F、边际 CDF 为 $F_1,\ \ldots,\ F_d$，则存在 copula $C : [0,\ 1]^d \to [0,\ 1]$，使 $F\left(s_1,\ \ldots,\ s_d\right) = C\left(F_1\left(s_1\right),\ \ldots,\ F_d\left(s_d\right)\right)$。若 $F_1,\ \ldots,\ F_d$ 连续，则 copula 唯一。相应的 copula 密度为 $f\left(u_1,\ \ldots,\ u_d\right) = c\left(F_1\left(s_1\right),\ \ldots,\ F_d\left(s_d\right)\right)f_1\left(s_1\right)\cdots f_d\left(s_d\right)$，其中 $f_1,\ \ldots,\ f_d$ 是 S 的边际密度。

因此，对 F 的估计分解为：（1）估计边际分布 $F_1,\ \ldots,\ F_d$；（2）估计 copula 函数 C。核密度估计（KDE）和经验 CDF 可对（1）进行非参数建模。对（2），可以根据观测到的相关结构，选择高斯、Gumbel、Clayton 等参数 copula 族，再用极大似然或矩匹配估计参数。但参数方法容易受到模型误设影响。

当单个标准 copula 模型不足以描述依赖时，藤 copula（又称成对 copula 构造）能够容纳任意复杂度的依赖。它是一种分层模型，由组织在一系列嵌套树中的二元 copula 模块构成，这些树也称规则（R-）藤，或简称藤（Joe，1994）。主要思想是把 d 维 copula 密度分解成 $d(d-1)/2$ 个二元条件

copula 密度的乘积。因此，拟合藤归结为选择二元 copula 模型及藤结构。二元 copula 可用非参数方式估计（Chen 和 Huang，2007；Geenens 等，2017；Nagler 等，2017）。关于非参数藤 copula 估计的更多细节见第9节。

虽然非参数藤 copula 能够灵活估计 F，但在 CP 中，我们只关心其分位数泛函 $F^{-1}(1-\alpha)$。半参数方法帮助我们围绕这个特定目标定制推断。

半参数推断指对非参数估量（即真实数据分布 P 的泛函）进行推断。这种方法也称目标化学习或去偏学习，近年来已成为一种主要范式（Van der Laan 等，2011）。若所关注的目标泛函是“光滑”的（具体含义见下文），即使对 P 的估计收敛速度较慢，有时仍能赋予估计量 $\sqrt{n}$ 相合性和渐近正态性等参数性质（Murphy 和 Van der Vaart，2000；Van der Laan 等，2011；Kennedy，2022；Hines 等，2022）。

设 P 属于 Polish 样本空间 $(\mathcal{Z}, \mathcal{A})$ 上的概率测度集合 $\mathcal{P}$。目标估量为 $\Psi(P)$，其中 $\Psi : \mathcal{P} \to \mathbb{R}$ 是可测泛函。先介绍以下关键概念。

定义3（有效影响函数）。 考虑如下混合模型，

$$P_t = (1-t)P + t\widetilde{P}, \qquad (8)$$

它称为参数子模型，由 P 与任意 $\widetilde{P} \in \mathcal{P}$ 以参数 $t \in [0, 1]$ 混合而成。Ψ 在 P 处朝向 $\widetilde{P}$ 的路径导数为：

$$\lim_{t\to 0} \frac{\Psi(P_t) - \Psi(P)}{t} = \left.\frac{d\Psi(P_t)}{dt}\right|_{t=0}. \qquad (9)$$

由 Riesz 表示定理，若此导数存在，就能找到唯一的表示函数 $\psi_P : \mathcal{Z} \to \mathbb{R}$，其在 P 下方差有限，使得

$$\left.\frac{d\Psi(P_t)}{dt}\right|_{t=0} = \mathbb{E}_{\widetilde{P}-P}\big[\psi_P(Z)\big] = \mathbb{E}_{\widetilde{P}}\big[\psi_P(Z)\big]. \qquad (10)$$

第二个等号来自把 ψ_P 限制为均值零函数，因为中间表达式对 ψ_P 的常数平移不敏感。当式(10)对任意“正则”参数子模型（其分数 $\widetilde{P}(Z)/P(Z) - 1$ 的方差有限）都存在且有限时，ψ_P 称为有效影响函数（EIF），Ψ 称为路径可微（Van Der Vaart，1991）。EIF 是一阶分布导数，刻画 $\Psi(P)$ 对 P 变化的敏感程度（Robins 等，2017；Kennedy，2022）。

设我们观测到 n 个数据点 $Z^{(i)} \overset{\text{i.i.d.}}{\sim} P$，其中 $i \in [n]$。可利用观测得到 P 的估计 $\widehat{P}$，进而得到代入估计量 $\Psi(\widehat{P})$。记 $\mathbb{P}_n$ 为这些观测的经验分布，相应密度为 $\frac{1}{n}\sum_{i=1}^{n}\delta_{Z^{(i)}}$。以下过程使用基于 EIF 的加性项修正 $\Psi(\widehat{P})$。

定义4。 一步估计量（Le Cam，1956；Pfanzagl 和 Pfanzagl，1982；Newey 等，1998）为

$$\Psi_{\text{1-step}}(\widehat{P}) = \Psi(\widehat{P}) + \mathbb{E}_{\mathbb{P}_n}\Big[\psi_{\widehat{P}}\big(Z^{(i)}\big)\Big]. \qquad (11)$$

为理解它为何优于代入估计，考虑分布的 Taylor 展开：

$$\Psi(P) = \Psi(\widehat{P}) + \left.\frac{d\Psi(P_t)}{dt}\right|_{t=1} (0-1) + r_2(P, \widehat{P}),$$

其中 r_2 是余项（Yiu 等，2023）。像式(10)一样应用 Riesz 表示定理，得

$$\left.\frac{d\Psi(P_t)}{dt}\right|_{t=1} = -\mathbb{E}_P\left[\psi_{\widehat{P}}(Z)\right],$$

所以

$$\Psi(P) = \Psi(\widehat{P}) + \mathbb{E}_P\left[\psi_{\widehat{P}}\right] + r_2(P, \widehat{P}).$$

把 $\widehat{P}$ 的估计误差记为 ε，可以预期 $r_2 \sim O(\varepsilon^2)$。这说明 $\Psi(\widehat{P}) + \mathbb{E}_P\left[\psi_{\widehat{P}}\right]$ 应优于代入估计量 $\Psi(\widehat{P})$。但 P 当然未知，因此我们改为对 $\mathbb{P}_n$ 求期望。图3帮助把一步修正理解为线性投影（Fisher 和 Kennedy，2021）。一步估计的介绍见第11节。

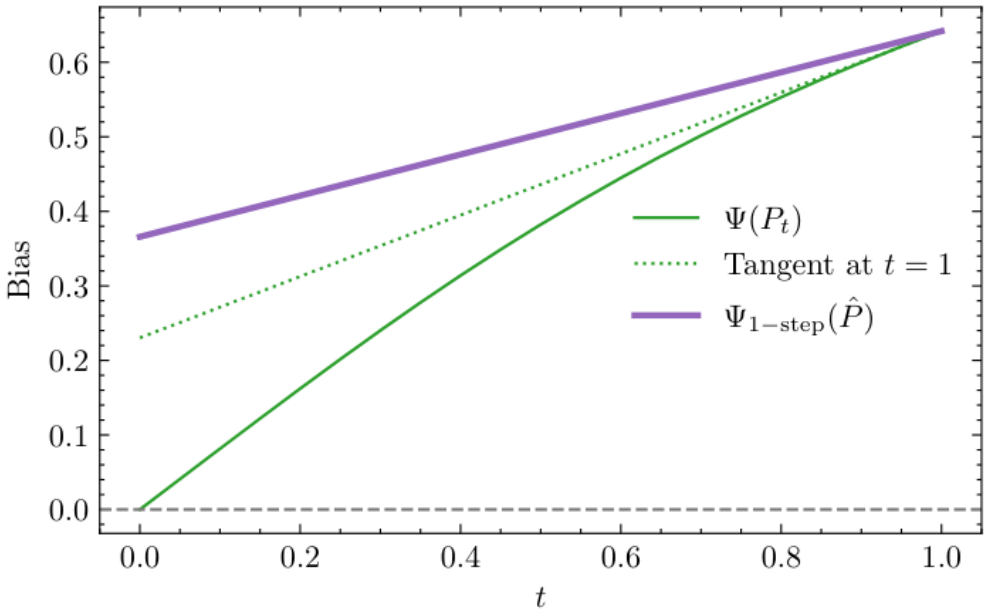


图3。 将一步修正可视化为线性投影。真实目标估量为 $\Psi(P)$；绿色实线是偏差 $\Psi(P_t) - \Psi(P)$，其中 P_t 定义于式(8)。一步估计量（紫色实线）可以理解为用经验分布近似其在 $t = 1$ 处的切线斜率（绿色虚线）。Bias＝偏差；Tangent at $t = 1 = t = 1$ 处的切线。

5 半参数 CP

如第3节所述，选择底层预测算法 $\widehat{f} : \mathcal{X} \to \mathbb{R}$ 和逐目标非一致性分数函数 $V\left(X_j, Y_j, \widehat{f}\right)$，会在校准集上产生 $\mathbb{R}^d$ 中的分数向量，如式(4)、(5)所定义。我们以灵活的非参数方式估计分数分布（第5.1节），并对估计分布的代入分位数施加一步修正（第5.2节），从而稳健地估计其 $1-\alpha$ 分位数。完整算法见算法1。

5.1 非参数密度估计

受 copula 非参数估计近期进展（Chen 和 Huang，2007）启发，我们提出使用第4节所述的非参数藤 copula，对分数向量分布 F 建模。首先获得经验边际 CDF：

$$\widehat{F}_j(s) = \frac{1}{n+1} \sum_{i \in \mathcal{I}_{\text{cal}} \cup \{\infty\}} \mathbb{1}\left[S_j^{(i)} \le s\right], \qquad (12)$$

其中 $S_j^{(\infty)} \equiv \infty$，且仍有 $n = |\mathcal{I}_{\text{cal}}|$。回顾一下，上标 $i \in [n]$ 索引实例，下标 $j \in [d]$ 索引向量分量。所得均匀边际向量可写为

$$U^{(i)} := \left[\widehat{F}_1\left(S_1^{(i)}\right), \ldots, \widehat{F}_d\left(S_d^{(i)}\right)\right] \in [0,\,1]^d. \qquad (13)$$

对于作为藤基本模块的二元 copula，我们选择变换局部似然核估计器（TLL），它允许在受限于 $[0,\,1]^2$ 的 copula 空间中应用 KDE（Geenens，2014）。所得非参数藤 copula $\widehat{C} : [0,\,1]^d \to [0,\,1]$ 给出最终估计的 CDF：

$$\widehat{F}(s) = \widehat{C}\left(\widehat{F}_1(s_1), \ldots, \widehat{F}_d(s_d)\right). \qquad (14)$$

copula 密度的参数（包括核带宽和藤结构）使用赤池信息准则（AIC）进行拟合；AIC 是非参数模型的相合模型选择准则（Akaike，1974）。随后可通过对密度进行成对 Monte-Carlo（MC）积分得到 CDF。我们使用 pyvinecopulib 库（Vatter 和 Nagler，2024）完成拟合与模型选择。

5.2 半参数修正

得到 $\widehat{F}$ 后，首先计算代入分位数：

$$\Psi(\widehat{F}) = \{s \in \mathbb{R}^d : \widehat{F}(s) \ge 1 - \alpha\}. \qquad (15)$$

它表示图2所示 $\widehat{F}$ 的 $(1-\alpha)$ 水平曲线。注意分位数不唯一；$(1-\alpha)$ 水平曲线上的任意分位数都可以。选择哪个分位数用于校准，取决于我们对多个目标之间相对效率的偏好。假设希望得到 L_1 范数最小的分位数。可以先通过优化在 copula 空间中寻找分位数，再利用逆 PIT 映射回分数空间，以得到水平曲线上的这个点：

$$U^* = \operatorname{argmin}_{U \in [0,1]^d} \| U \|_1 \quad \text{s.t. } \widehat{C}(U) \ge 1 - \alpha, \qquad (16)$$

$$\Psi(\widehat{F}) = Q_{1-\alpha}\left(U^*\right) = \left[\widehat{F}_1^{-1}\left(U_1^*\right), \ldots, \widehat{F}_d^{-1}\left(U_d^*\right)\right]. \qquad (17)$$

我们使用 CMA-ES 算法（Hansen 等，2003）优化式(16)中的 copula。

我们对 U^* 而不是 $\Psi(\widehat{F})$ 施加一步修正。广义 $1-\alpha$ 分位数的 EIF 为

$$\psi_{\widehat{C}}(\widetilde{u}) = \frac{(1-\alpha) - \mathbb{1}\left[\widetilde{u} \preccurlyeq U^*\right]}{\left|\nabla \widehat{C}\left(U^*\right)\right|^2} \nabla \widehat{C}\left(U^*\right), \qquad (18)$$

其中 $\mathbb{1}[b]$ 是指示函数：b 为真时取1，否则取0。推导见第10节。因此，U^* 的一步估计量为

$$U_{\text{1-step}} = U^{*} + \frac{1}{n}\sum_{i=1}^{n} \psi_{\widehat{C}}\left(U^{(i)}\right). \qquad (19)$$

随后可再次用式(17)，把 $U_{\text{1-step}}$ 映射到分数空间，得到 $\Psi_{\text{1-step}}(\widehat{F})$。

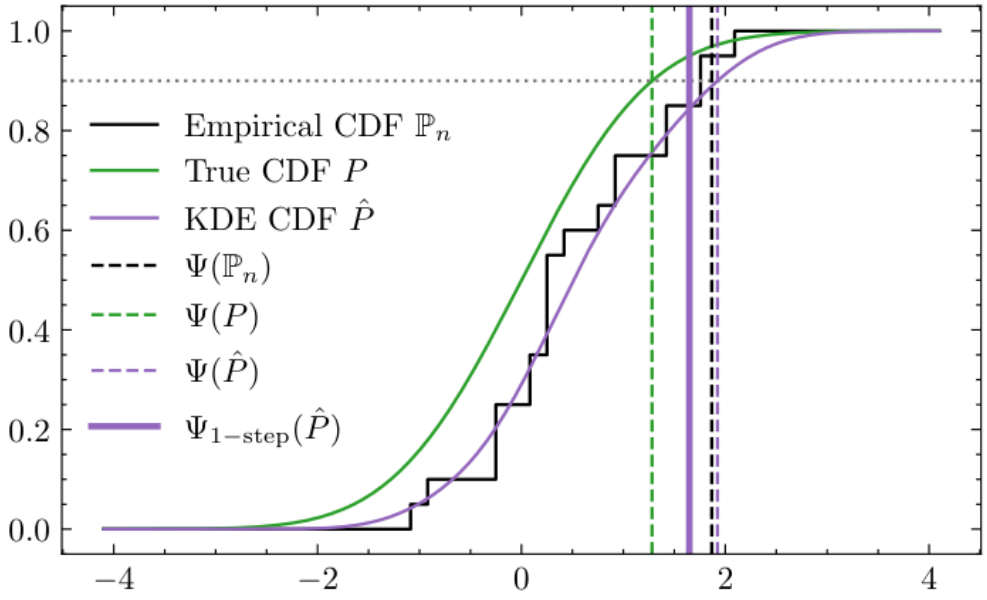


图4。 根据20个样本预测某分布的0.9分位数。标准 CP 使用经验估计（黑色虚线）。与 KDE 的代入估计（紫色虚线）相比，一步修正估计（紫色实线）更接近真实分位数（绿色虚线）。Empirical CDF＝经验 CDF；True CDF＝真实 CDF；KDE CDF＝核密度估计 CDF。

图4说明单目标情形的一步估计：我们希望根据 $n = 20$ 个样本，估计真实分数分布（绿色曲线）的 $1 - \alpha = 0.9$ 分位数（绿色虚线）。标准 CP 取经验 CDF（黑色曲线），提取 $\lceil (n+1)(1-\alpha) \rceil / (n+1)$ 分位数（黑色虚线）。我们的方法通过拟合 CDF 的非参数模型（紫色曲线）来“扩充”分数。在这里，代入分位数（紫色虚线）与经验分位数非常接近，两者都高估了分位数，而修正后的估计（紫色实线）给出了更好的近似。

本方法最终的预测集见式(6)。与 Messoudi 等（2021）一样，它呈超矩形形状。例如，若 $V(X, Y, \widehat{f})_j = |Y_j - \widehat{f}(X_j)|$，逐目标区间为

$$\Gamma_{1-\alpha}(X^{*})_j = \{y \in \mathbb{R} : |y - \widehat{f}(X^{*})_j| \le Q_{1-\alpha,j}\}, \qquad (20)$$

其中 $Q_{1-\alpha}$ 可以取 $\Psi(\widehat{F})$ 或 $\Psi_{\text{1-step}}(\widehat{F})$。

5.3 理论结果

下面非正式地陈述本方法的理论保证。由定理2，算法1的覆盖渐近精确；由定理3，其具有近似有效性。完整证明见第13节。我们作如下假设：

- 分数向量 S 的真实分布 F^{*} 绝对连续。

· 在标准的光滑性和带宽条件下，非参数 copula 估计量 $\widehat{F}$ 一致相合，即当 $n \to \infty$ 时，$\sup_{s\in\mathbb{R}^d}\widehat{F}(s) - F^*(s) \xrightarrow{p} 0$。

定理2（渐近相合性）。在上述正则条件下，算法1中使用一步修正 U^* 构造的预测集 $\Gamma_{1-\alpha}$，对于测试点 $\left(X^*, Y^*\right)$ 满足

$$\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}\left(X^*\right)\right] \to 1-\alpha \quad n \to \infty.$$

也就是说，其覆盖渐近精确。

该结论来自 copula 估计量 $\widehat{F}$ 的一致相合性（从而其分位数相合），以及一步估计量的渐近正态性。

定理3（近似有效性）。假设真实分布 F^* 与估计分布 $\widehat{F}$ 之间的全变差（TV）距离以 ϵ 为界，即

$$\sup_S |F^*(S) - \widehat{F}(S)| \le \epsilon.$$

那么，算法1中使用代入分位数 U 或一步修正分位数 U^* 构造的预测集 $\Gamma_{1-\alpha}$ 在 $1-\alpha-\epsilon$ 水平下边际有效：

$$\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}\left(X^*\right)\right] \ge 1-\alpha-\epsilon.$$

证明思路如下：由数据处理不等式，F^* 与 $\widehat{F}$ 的 TV 距离是它们相应分位数之间 TV 距离的上界。对于 $\widehat{F}$ 的分位数与一步修正分位数，同样成立，因为修正项不会增加额外信息。

有限样本有效性。第12节还介绍了算法2，它是算法1的一个变体，把校准集进一步分成 $\mathcal{I}_{\text{cal},1}$ 与 $\mathcal{I}_{\text{cal},2}$。用 $\mathcal{I}_{\text{cal},1}$ 构造所有 $j \in [d]$ 的经验 CDF $\widehat{F}_j$，再用大小为 $n' = |\mathcal{I}_{\text{cal},2}|$ 的集合 $\mathcal{I}_{\text{cal},2}$ 拟合经验 copula $\widehat{C}$，从中提取 $\lceil (1-\alpha)(n'+1)/(n'+1) \rceil$ 分位数。由定理5，这个额外拆分提供有限样本有效性，因为它使 $\mathcal{I}_{\text{cal},2}$ 与测试集的向量边际 U 可交换。

译注：本节沿用原文对 U、U^* 的记号及分位数取整位置。原文在式(15)用不等式定义集合但在文字中称其为水平曲线；上述一致相合表达式未加绝对值；这些均按原文保留，不作未标明的理论修正。定理2原文概率表达式缺少右方括号，本译文仅补齐括号。

算法1：半参数共形预测

1. **输入：** 带标签数据 $\mathcal{I}$，测试输入 $\mathcal{I}_{\text{test}}$，目标覆盖水平 $1-\alpha$。
2. **输出：** 对所有 $i \in \mathcal{I}_{\text{test}}$ 的预测集 $\Gamma_{1-\alpha}\left(X^{(i)}\right)$。
3. 将 $\mathcal{I}$ 分为 $\mathcal{I}_{\text{train}}$ 和 $\mathcal{I}_{\text{cal}}$。
4. 在 $\mathcal{I}_{\text{train}}$ 上训练底层算法 $\widehat{f}$。
5. 对每个 $i \in \mathcal{I}_{\text{cal}}$：
6. 　对每个 $j \in [d]$：
7. 　　$S_j^{(i)} \leftarrow V\left(X_j^{(i)}, Y_j^{(i)}, \widehat{f}\right)$。
8. 　结束内层循环。
9. 结束外层循环。

10. 对每个 $i \in \mathcal{I}_{\text{cal}}$：
11. 　对每个 $j \in [d]$：
12. 　　$\widehat{F}_j(s) \leftarrow$ 式(12)（边际 ECDF）。
13. 　　$U_j^{(i)} \leftarrow \widehat{F}_j\left(S_j^{(i)}\right)$（均匀边际）。
14. 　结束内层循环。
15. 结束外层循环。
16. 在 $\{U^{(i)}\}_{i \in \mathcal{I}_{\text{cal}}}$ 上拟合 copula $\widehat{C}$。
17. $U^* \leftarrow$ 式(16)。
18. $Q_{1-\alpha} \leftarrow$ 式(17)中的 $Q_{1-\alpha}\left(U^*\right)$。
19. 若启用修正（correction 为 True）：
20. 　$U^* \leftarrow$ 式(19)中的 $U_{\text{1-step}}$。
21. 　$Q_{1-\alpha} \leftarrow$ 式(17)中的 $Q_{1-\alpha}\left(U^*\right)$。
22. 结束条件语句。
23. 对每个 $i \in \mathcal{I}_{\text{test}}$：
24. 　$\Gamma_{1-\alpha}\left(X^{(i)}\right) \leftarrow$ 式(6)。
25. 结束循环。
26. **返回** $\Gamma_{1-\alpha}\left(X^{(i)}\right)$，对所有 $i \in \mathcal{I}_{\text{test}}$。

6 实验

设定。 我们研究具有 d 个实值目标的回归问题中的拆分共形校准方案。在 $\mathcal{I}_{\text{train}}$ 上拟合的底层算法 $\widehat{f}$ 是多任务 Lasso 点预测器（Tibshirani，1996）。对于包括本方法在内、基于向量分数的校准方案，选择式(4)中的 L_1 非一致性分数。在同一个大小为 $n = |\mathcal{I}_{\text{cal}}|$ 的校准集上计算分数。固定 $1 - \alpha = 0.9$，并把数据随机分为训练集、校准集和测试集。

基线。 我们比较在分数定义和 $\widehat{F}$ 估计方式上有所不同的校准方案。表3给出所有方案的详细对比。

- 对每个目标独立在 $(1-\alpha)^{1/d}$ 水平应用一元校准（independent）。
- 对定义为预测误差 L_2 范数的标量分数应用校准：$V\left(X, Y, \widehat{f}\right) = \| Y - \widehat{f}(X) \|_2$（Feldman 等，2023）。
- 在向量分数上拟合经验 copula，并施加 $U_1^* = \cdots = U_d^*$ 约束（Messoudi 等，2021）。
- 在向量分数上拟合 TLL R-vine（本方法，代入估计）。
- 对上述方法施加一步修正（本方法，修正估计）。

注3：L_2 分数定义会产生 d 维球形预测集。L_1 范数会产生交叉多胞体（菱形的 d 维推广），L_∞ 范数会产生超立方体。

评价指标。 对每种校准方案评价覆盖率和效率。覆盖率为测试集 $\mathcal{I}_{\text{test}}$ 上的经验覆盖：

$$\text{Coverage} = \frac{1}{|\mathcal{I}_{\text{test}}|} \sum_{i \in \mathcal{I}_{\text{test}}} \mathbb{1}\left[Y^{(i)} \in \Gamma_{1-\alpha}\left(X^{(i)}\right)\right]. \qquad (21)$$

该值越接近目标覆盖率 $1-\alpha$ 越好。注意，无信息量的大预测集可通过过覆盖而满足有效性，例如 $\Gamma_{1-\alpha}=\mathbb{R}^d$ 会得到 Coverage $=1\geq 1-\alpha$。我们希望有效预测集同时高效，即尺寸较小，所以还报告其（超）体积：

$$\text{Efficiency}=\frac{1}{|\mathcal{J}_{\text{test}}|}\sum_{i\in\mathcal{J}_{\text{test}}}\log\text{Vol}\left(\Gamma_{1-\alpha}\left(X^{(i)}\right)\right). \qquad (22)$$

6.1 合成示例

我们使用 Liang 和 Lai（2021）的青霉素生产模拟器生成数据。该函数输入七个控制青霉素生产的参数，输出三个实值目标（$d=3$），即青霉素产量、生产时间和二氧化碳排放量。为模拟测量误差，加入尺度等于无噪声函数输出10%的随机高斯误差，使 $Y=f_0(X)+\varepsilon$，其中 f_0 为测试函数，$\varepsilon\sim\mathcal{N}\left(0,\,\left(f_0(X)/10\right)^2\right)$。更多细节见第15.1节。

如表1所示，修正后的方法达到最接近名义水平0.9的覆盖率，并且在有效方案中效率最高。一步修正在覆盖率和效率两方面都改进了代入估计。图5说明覆盖率改进适用于所有目标水平。图6展示两个青霉素目标的真实分布、估计分布与经验分布的等值线。

另一方面，独立方案被迫仅用 $n\approx 100$ 个校准实例，提取 $\lceil(0.9)^{1/d}(n+1)\rceil/(n+1)\approx 0.97$ 水平的经验边际分位数，因此过于保守（Messoudi 等，2021）。它无法利用残差相关性，尤其是由目标量（尾部）相关性引起的尾部相关性，如图8和图9所示。

标量分数的低效率更加严重，因为 L_1 分数把来自分布差异极大的各目标的残差聚合起来。在本例中，相较青霉素产量的残差，CO_2 排放量的残差具有较长的上尾（见图8）。因此分数被 CO_2 残差主导，所得分位数很大。

第14节给出完整实验，其中包括算法2、其他类型的标量分数（L_2 和 L_∞ 范数），以及一种“拆分”标量分数方法：进一步拆分校准集，在标量化之前对分数归一化。

表1。 青霉素数据上的指标（$d=3,\ n=96$）。报告十个随机种子下的均值 ± 标准误。目标覆盖率为0.9。效率值越低越好。

方法	覆盖率	效率 ↓
独立	0.96 ± 0.00	4.1 ± 0.1
标量分数	0.93 ± 0.01	4.5 ± 0.1
经验 copula	0.93 ± 0.01	3.7 ± 0.1
代入（本方法）	0.91 ± 0.01	3.7 ± 0.2
修正（本方法）	0.90 ± 0.00	3.5 ± 0.1
代入，拆分（本方法）	0.92 ± 0.02	3.6 ± 0.3
修正，拆分（本方法）	0.90 ± 0.03	3.5 ± 0.4

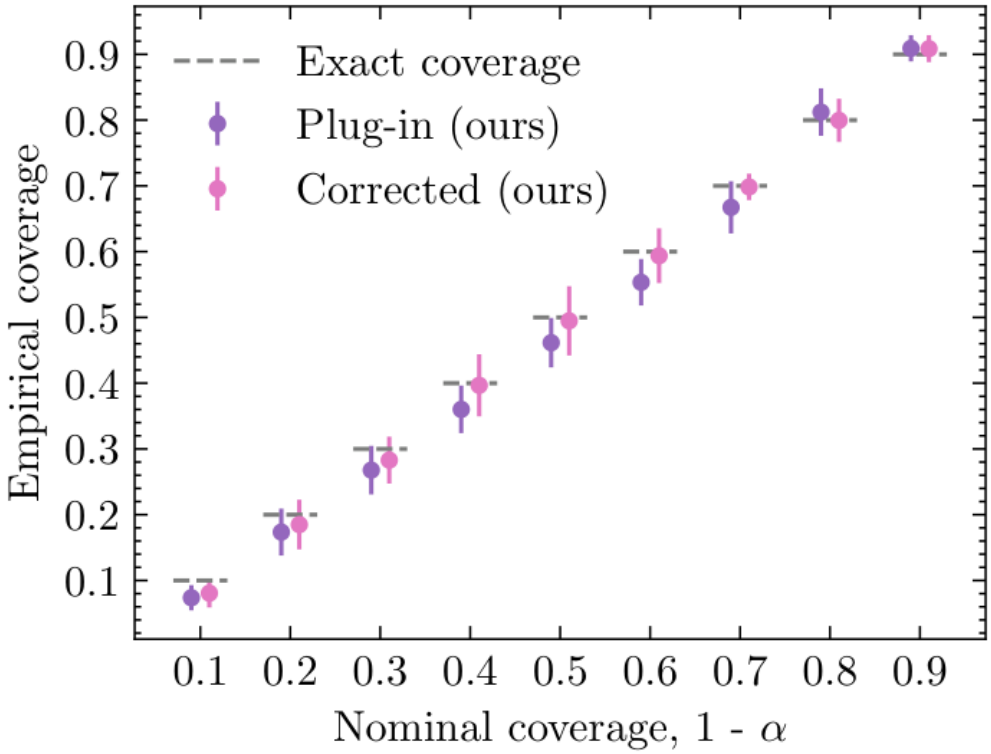


图5。 对青霉素数据集，一步修正在所有目标水平上提高代入估计的覆盖率。误差条是十个随机种子间的标准差。Nominal coverage＝名义覆盖率；Empirical coverage＝经验覆盖率；Exact coverage＝精确覆盖；Plug-in (ours)＝代入（本方法）；Corrected (ours)＝修正（本方法）。

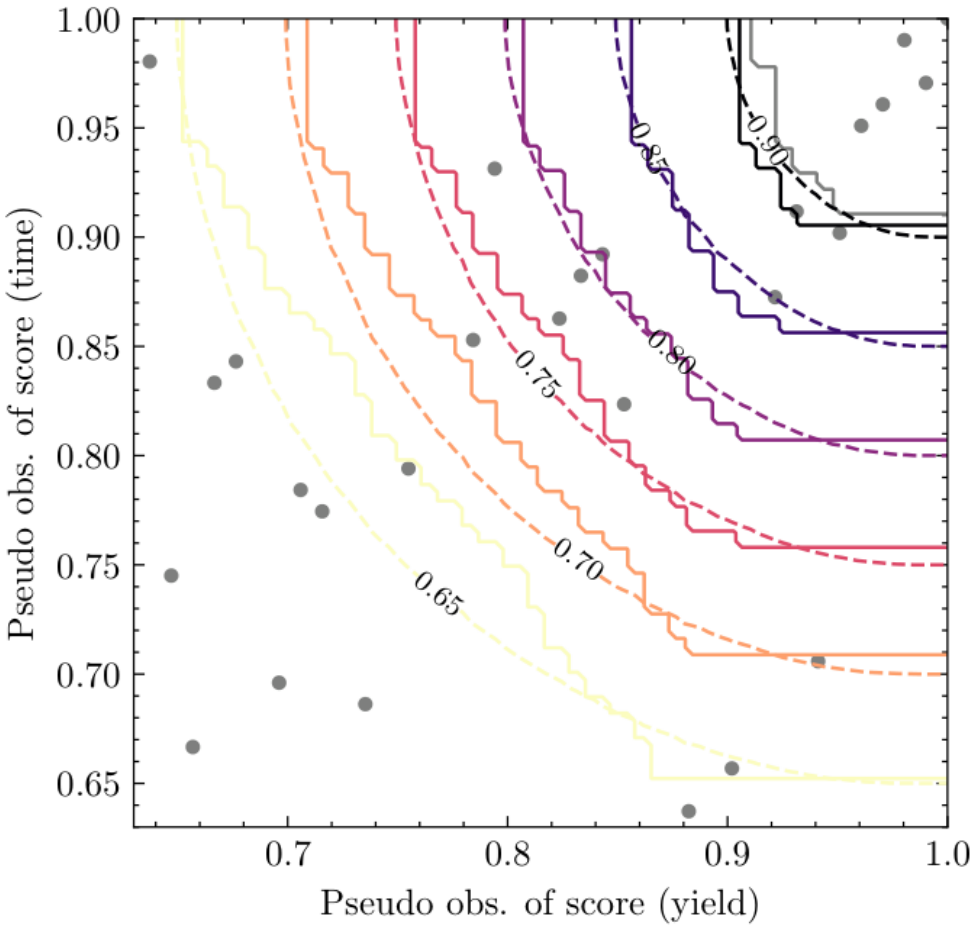


图6。 copula 空间中不同分位数水平下估计（虚线）与真实（实线）的等值线。在0.9水平，估计曲线（黑色虚线）位于真实曲线（黑色实线）和根据96个点计算的经验曲线（灰色实线）之间；其中部分点显示为灰点。Pseudo obs. of score (yield/time)＝分数的伪观测（产量/时间）。

表2。 实际数据上的指标。报告五个随机种子下的均值 ± 标准误。目标覆盖率为0.9；效率值越低越好。为便于阅读，将原表分为六个数据集，各数值保持不变。

数据集与方法	覆盖率	效率 ↓
Stock（$d = 6,\ n = 63$）：独立	0.90 ± 0.01	−2.4 ± 0.2
Stock：标量分数	0.90 ± 0.01	−1.8 ± 0.3
Stock：经验 copula	0.50 ± 0.05	−4.7 ± 0.5
Stock：代入（本方法）	0.87 ± 0.02	−2.9 ± 0.2
Stock：修正（本方法）	0.90 ± 0.02	−2.8 ± 0.2
Caco2+（$d = 6,\ n = 137$）：独立	0.95 ± 0.01	12.2 ± 0.1
Caco2+：标量分数	0.92 ± 0.01	28.3 ± 0.1
Caco2+：经验 copula	0.42 ± 0.08	8.4 ± 0.4
Caco2+：代入（本方法）	0.90 ± 0.01	11.0 ± 0.1
Caco2+：修正（本方法）	0.93 ± 0.01	11.5 ± 0.2

数据集与方法	覆盖率	效率 ↓
rf1（$d = 8,\ n = 225$）：独立	0.96 ± 0.01	29.2 ± 0.5
rf1：标量分数	0.92 ± 0.00	27.7 ± 0.3
rf1：经验 copula	0.42 ± 0.12	21.2 ± 2.6
rf1：代入（本方法）	0.91 ± 0.01	25.0 ± 0.2
rf1：修正（本方法）	0.91 ± 0.01	25.1 ± 0.3
rf2（$d = 8,\ n = 225$）：独立	0.96 ± 0.01	29.2 ± 0.5
rf2：标量分数	0.92 ± 0.01	27.7 ± 0.3
rf2：经验 copula	0.42 ± 0.12	21.2 ± 2.6
rf2：代入（本方法）	0.90 ± 0.01	25.0 ± 0.2
rf2：修正（本方法）	0.91 ± 0.01	25.1 ± 0.3
scm1d（$d = 16,\ n = 448$）：独立	0.96 ± 0.01	114.1 ± 0.4
scm1d：标量分数	0.89 ± 0.01	109.0 ± 0.3
scm1d：经验 copula	0.75 ± 0.05	108.5 ± 0.8
scm1d：代入（本方法）	0.92 ± 0.01	111.4 ± 0.1
scm1d：修正（本方法）	0.91 ± 0.01	110.7 ± 0.2
scm20d（$d = 16,\ n = 448$）：独立	0.96 ± 0.01	114.1 ± 0.4
scm20d：标量分数	0.89 ± 0.01	109.0 ± 0.3
scm20d：经验 copula	0.75 ± 0.05	108.5 ± 0.8
scm20d：代入（本方法）	0.92 ± 0.01	111.4 ± 0.2
scm20d：修正（本方法）	0.90 ± 0.01	110.6 ± 0.2

6.2 真实数据集

表2报告多种真实数据集上的性能，这些数据集有6、8或16个目标，以及不同大小的校准集。在所有这些问题中，修正后的方案都是有效的，且其经验覆盖率最接近0.9。同时，它在有效方案中效率最高。对 Stock（Liu 和 Yeh，2017）、Caco2+（Wang 等，2016；Park 等，2024）和 rf2（Spyromitros-Xioufis 等，2016），修正对于使代入估计达到有效性（覆盖率超过0.9）起到关键作用。同时，它没有显著损害效率。

对于其他校准方案，观察到与合成示例相似的模式。独立方法倾向于过覆盖；在 Stock 数据集上，它给出无限大的预测集，因为我们只有 $n = 63$ 个实例，却要从中提取经验 $\lceil (0.9)^{1/6} \times 64 \rceil / 64 \approx 0.98$ 分位数。标量分数的过覆盖更严重，导致非常大的预测集。经验 copula 因接近目标分位数的上尾样本有限而呈现高方差，其覆盖率也大幅低于名义水平。

译注：本节原文对 Stock 的“无限大预测集”描述与表2中有限效率值并不一致；第6.1节讨论标量 L_1 分数，而基线列表采用 L_2。译文保留原文叙述与表格，不代作者更正。

7 局限性

与 Messoudi 等（2021）的算法一样，我们的算法仅保证近似的有限样本有效性。如果根据 n 个数据点构造的分数 copula 估计 $\widehat{C}$ 显著偏离 $n \to \infty$ 极限下的“真实”copula，可能损失覆盖率。Messoudi 等（2021）考虑的参数 copula 族容易受到模型误设偏差影响；我们旨在通过非参数藤最小化此问题。

本工作使用 CMA-ES（Hansen 等，2003），即一种无需梯度的进化算法，来优化 copula。使用基于梯度的算法可以提高这一步的效率，特别是当 d 较大时。经验 copula 和某些参数 copula 类别适用于梯度下降算法（Sun 和 Yu，2024），而非参数藤的梯度计算更为复杂。我们将此留待未来研究。

8 结论

我们改进了多目标回归设定下的共形校准。当目标数量相对于校准集大小较多时，经验分位数提取受到维数灾难影响，并可能因为非一致性分数上端极值处样本有限而呈现高方差。以往学习联合分数分布并利用其光滑性的方法，仅限于容易发生模型误设的参数 copula 族。相比之下，本方法指定一个非参数模型以获得充分灵活性，同时通过一步半参数修正控制所关注分位数估量的代入偏差。我们已展示，本方法在一系列高维回归问题上产生具有期望覆盖率和有竞争力效率的预测集。由于不对底层算法或分数函数的形式作任何假设，它可方便地插入校准步骤。

未来一个有趣的方向，是根据关于目标依赖结构的领域知识来指定藤结构。当某个目标变量占主导时，可以使用 C-vine；对 Sun 和 Yu（2024）考虑的时间变量，则可以使用 D-vine。

致谢

感谢 Robert Tibshirani 和 Anastasios Angelopoulos 提供富有洞见的反馈。

参考文献

以下逐条保留原文的作者、年份、出版来源、卷期页码及标识符；题名译成中文。期刊、出版社、人名及软件名保留原名以便检索。原文未列出的信息不补造。

1. Akaike, H. (1974). 统计模型识别的新视角。IEEE Transactions on Automatic Control, 19(6):716–723。
2. Angelopoulos, A. N. 与 Bates, S. (2021). 共形预测与分布无关不确定性量化的平易入门。arXiv 预印本 arXiv:2107.07511。
3. Barber, R. F., Candès, E. J., Ramdas, A. 与 Tibshirani, R. J. (2021). 使用 jackknife+ 的预测推断。Annals of Statistics, 49(1):486–507。
4. Bedford, T. 与 Cooke, R. M. (2001). 用藤建模的条件依赖随机变量的概率密度分解。Annals of Mathematics and Artificial Intelligence, 32:245–268。
5. Bedford, T. 与 Cooke, R. M. (2002). 藤：依赖随机变量的一种新图模型。The Annals of Statistics, 30(4):1031–1068。
6. Chaudhuri, P. (1996). 关于多元数据分位数的一种几何概念。Journal of the American Statistical Association, 91(434):862–872。

7. Chen, S. X. 与 Huang, T.-M. (2007). 用于依赖建模的 copula 函数非参数估计。Canadian Journal of Statistics, 35(2):265–282。
8. Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W. 与 Robins, J. (2018). 处理效应与结构参数的双重/去偏机器学习。
9. Cortes-Ciriano, I. 与 Bender, A. (2020). 计算药物发现中共形预测的概念与应用。见 Artificial Intelligence in Drug Discovery，第63–101页。Royal Society of Chemistry。
10. Czado, C. 与 Nagler, T. (2022). 基于藤 copula 的建模。Annual Review of Statistics and Its Application, 9(1):453–477。
11. Dissmann, J., Brechmann, E. C., Czado, C. 与 Kurowicka, D. (2013). 规则藤 copula 的选择与估计及其在金融收益中的应用。Computational Statistics & Data Analysis, 59:52–69。
12. Du, B.-X., Xu, Y., Yiu, S.-M., Yu, H. 与 Shi, J.-Y. (2023). 自适应辅助任务选择下通过多任务图学习预测 ADMET 性质。Iscience, 26(11)。
13. Eklund, M., Norinder, U., Boyer, S. 与 Carlsson, L. (2015). 共形预测在药物发现流程中的应用。Annals of Mathematics and Artificial Intelligence, 74:117–132。
14. Feldman, J. 与 Kowal, D. R. (2024). 面向多元、混合及缺失数据的非参数 copula 模型。Journal of Machine Learning Research, 25(164):1–50。
15. Feldman, S., Bates, S. 与 Romano, Y. (2023). 基于表示学习的校准多输出分位数回归。Journal of Machine Learning Research, 24(24):1–48。
16. Fisher, A. 与 Kennedy, E. H. (2021). 通过可视化交流和教授影响函数的直观理解。The American Statistician, 75(2):162–172。
17. Gammerman, A., Vovk, V. 与 Vapnik, V. (1998). 通过直推学习，卷 UAI’98。
18. Geenens, G. (2014). 单位区间上核密度估计的 Probit 变换。Journal of the American Statistical Association, 109(505):346–358。
19. Geenens, G., Charpentier, A. 与 Paindaveine, D. (2017). copula 密度非参数核估计的 Probit 变换。Bernoulli, 23(3):1848–1873。
20. Genest, C., Ghoudi, K. 与 Rivest, L.-P. (1995). 多元分布族中依赖参数的半参数估计过程。Biometrika, 82(3):543–552。
21. Hallin, M., Paindaveine, D., Siŕman, M., Wei, Y., Serfling, R., Zuo, Y., Kong, L. 与 Mizera, I. (2010). 多元分位数与多输出回归分位数：从 l_1 优化到半空间深度［含讨论和答复］。The Annals of Statistics，第635–703页。
22. Hampel, F. R. (1974). 影响曲线及其在稳健估计中的作用。Journal of the American Statistical Association, 69(346):383–393。
23. Hansen, N., Müller, S. D. 与 Koumoutsakos, P. (2003). 降低采用协方差矩阵自适应的去随机化进化策略（CMA-ES）的时间复杂度。Evolutionary Computation, 11(1):1–18。
24. Hines, O., Dukes, O., Diaz-Ordaz, K. 与 Vansteelandt, S. (2022). 揭开基于有效影响函数的统计学习的神秘面纱。The American Statistician, 76(3):292–304。
25. Jain, T., Sun, T., Durand, S., Hall, A., Houston, N. R., Nett, J. H., Sharkey, B., Bobrowicz, B., Caffry, I., Yu, Y. 等 (2017). 临床阶段抗体全景的生物物理性质。Proceedings of the National Academy of Sciences, 114(5):944–949。
26. Joe, H. (1994). 多元极值分布及其在环境数据中的应用。Canadian Journal of Statistics, 22(1):47–64。

27. Joe, H. (2005). 基于 copula 模型的两阶段估计方法的渐近效率。Journal of Multivariate Analysis, 94(2):401–419。
28. Johnstone, C. 与 Cox, B. (2021). 用于稳健优化的共形不确定性集。见 Conformal and Probabilistic Prediction and Applications，第72–90页。PMLR。
29. Johnstone, C. 与 Ndiaye, E. (2022). 多维中的精确和近似共形推断。arXiv 预印本 arXiv:2210.17405。
30. Kennedy, E. H. (2022). 半参数双重稳健目标化双重机器学习：综述。arXiv 预印本 arXiv:2203.06469。
31. Koenker, R. 与 Bassett Jr, G. (1978). 回归分位数。Econometrica: Journal of the Econometric Society，第33–50页。
32. Kong, L. 与 Mizera, I. (2012). 分位数层析：对多元数据使用分位数。Statistica Sinica，第1589–1610页。
33. Kuchibhotla, A. K. (2020). 可交换性、共形预测与秩检验。arXiv 预印本 arXiv:2005.06095。
34. Kuleshov, A., Bernstein, A. 与 Burnaev, E. (2018). 流形学习中的共形预测。见 Conformal and Probabilistic Prediction and Applications，第234–253页。PMLR。
35. Le Cam, L. (1956). 关于估计与假设检验的渐近理论。见 Proceedings of the Third Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Contributions to the Theory of Statistics，卷3，第129–157页。University of California Press。
36. Lehmann, E. L. 等 (1975). 基于秩的统计方法。Nonparametrics。San Francisco, CA, Holden-Day, 2。
37. Lei, J., G’ Sell, M., Rinaldo, A., Tibshirani, R. J. 与 Wasserman, L. (2018). 回归的分布无关预测推断。Journal of the American Statistical Association, 113(523):1094–1111。
38. Lei, J., Rinaldo, A. 与 Wasserman, L. (2015). 探索函数型数据的一种共形预测方法。Annals of Mathematics and Artificial Intelligence, 74:29–43。
39. Lei, J. 与 Wasserman, L. (2014). 非参数回归的分布无关预测带。Journal of the Royal Statistical Society Series B: Statistical Methodology, 76(1):71–96。
40. Liang, Q. 与 Lai, L. (2021). 可扩展贝叶斯优化加速青霉素生产过程优化。见 NeurIPS 2021 AI for Science Workshop。
41. Liu, R. Y. (1990). 关于基于随机单纯形的数据深度概念。The Annals of Statistics，第405–414页。
42. Liu, Y.-C. 与 Yeh, I.-C. (2017). 使用混合设计和神经网络构建股票选择决策支持系统。Neural Computing and Applications, 28:521–535。
43. Messoudi, S., Destercke, S. 与 Rousseau, S. (2021). 面向多目标回归的基于 copula 的共形预测。Pattern Recognition, 120:108101。
44. Messoudi, S., Destercke, S. 与 Rousseau, S. (2022). 面向多目标回归的椭球共形推断。见 Conformal and Probabilistic Prediction with Applications，第294–306页。PMLR。
45. Murphy, S. A. 与 Van der Vaart, A. W. (2000). 关于剖面似然。Journal of the American Statistical Association, 95(450):449–465。
46. Nagler, T., Schellhase, C. 与 Czado, C. (2017). 简化藤 copula 模型的非参数估计：方法比较。Dependence Modeling, 5(1):99–120。
47. Napoles, O. M., Cooke, R. 与 Kurowicka, D. (2010). 关于 n 个节点上藤与规则藤的数量。

48. Neeven, J. 与 Smirnov, E. (2018). 共形堆叠天气预报。见 Conformal and Probabilistic Prediction and Applications，第220–233页。PMLR。
49. Nelsen, R. B. (2006). Copula 导论。Springer。
50. Newey, W. K., Hsieh, F. 与 Robins, J. (1998). 欠平滑与偏差修正的泛函估计。工作论文。
51. Niepel, M., Hafner, M., Mills, C. E., Subramanian, K., Williams, E. H., Chung, M., Gaudio, B., Barrette, A. M., Stern, A. D., Hu, B. 等 (2019). 关于哺乳动物细胞系药物反应测定可重复性的多中心研究。Cell Systems, 9(1):35–48。
52. Nouretdinov, I., Melluish, T. 与 Vovk, V. (2001). 岭回归置信机。见 ICML，第385–392页。Citeseer。
53. Paindaveine, D. 与 Siv̊man, M. (2011). 关于方向性多输出分位数回归。Journal of Multivariate Analysis, 102(2):193–212。
54. Papadopoulos, H., Proedrou, K., Vovk, V. 与 Gammerman, A. (2002). 回归的归纳置信机。见 Elomaa, T., Mannila, H. 与 Toivonen, H. 编，Machine Learning: ECML 2002，第345–356页。Springer Berlin Heidelberg。
55. Park, J. W., Tagasovska, N., Maser, M., Ra, S. 与 Cho, K. (2024). Botied：具有并列多元秩的多目标贝叶斯优化。ICML。
56. Pfanzagl, J. 与 Pfanzagl, J. (1982). 泛函的渐近有效估计量的存在性。Contributions to a General Asymptotic Statistical Theory，第196–210页。
57. Robins, J. M., Li, L., Mukherjee, R., Tchetgen, E. T. 与 van der Vaart, A. (2017). 结构化高维模型上泛函的极小极大估计。The Annals of Statistics, 45(5):1951–1987。
58. Romano, Y., Patterson, E. 与 Candes, E. (2019). 共形化分位数回归。Advances in Neural Information Processing Systems, 32。
59. Rubin, D. B. (1976). 推断与缺失数据。Biometrika, 63(3):581–592。
60. Saunders, C., Gammerman, A. 与 Vovk, V. (1999). 具有置信度和可信度的直推学习。见 Proceedings of the Sixteenth International Joint Conference on Artificial Intelligence，第722–726页。Morgan Kaufmann Publishers Inc。
61. Shafer, G. 与 Vovk, V. (2008). 共形预测教程。Journal of Machine Learning Research, 9(3)。
62. Sklar, M. (1959). n 维分布函数及其边际。见 Annales de l’ISUP，卷8，第229–231页。
63. Spyromitros-Xioufis, E., Tsoumakas, G., Groves, W. 与 Vlahavas, I. (2016). 通过输入空间扩展进行多目标回归：把目标作为输入。Machine Learning, 104:55–98。
64. Sun, S. H. 与 Yu, R. (2024). 多步时间序列预测的 copula 共形预测。见 The Twelfth International Conference on Learning Representations。
65. Tibshirani, R. (1996). 通过 lasso 进行回归收缩与选择。Journal of the Royal Statistical Society Series B: Statistical Methodology, 58(1):267–288。
66. Van der Laan, M. J., Rose, S. 等 (2011). 目标化学习：观察与实验数据的因果推断，卷4。Springer。
67. Van Der Vaart, A. (1991). 关于可微泛函。The Annals of Statistics，第178–204页。
68. Vatter, T. 与 Nagler, T. (2024). pyvinecopulib。Zenodo，DOI: 10.5281/zenodo.10435751。
69. Vovk, V. (2015). 交叉共形预测器。Annals of Mathematics and Artificial Intelligence, 74(1–2):9–28。

70. Vovk, V., Gammerman, A. 与 Shafer, G. (2005). 随机世界中的算法学习，卷29。Springer。
71. Wang, N.-N., Dong, J., Deng, Y.-H., Zhu, M.-F., Wen, M., Yao, Z.-J., Lu, A.-P., Wang, J.-B. 与 Cao, D.-S. (2016). 药物发现中的 ADME 性质评价：结合 NSGA-II 与提升法预测 Caco-2 细胞通透性。Journal of Chemical Information and Modeling, 56(4):763–773。
72. Yiu, A., Fong, E., Holmes, C. 与 Rousseau, J. (2023). 半参数后验修正。arXiv 预印本 arXiv:2306.06059。
73. Zuo, Y. (2003). 基于投影的深度函数及相关中位数。The Annals of Statistics, 31(5):1460–1490。

检查清单

1. 对所有提出的模型与算法，检查是否包含：
   - **(a)** 对数学设定、假设、算法和/或模型的清晰说明。［是］
   - **(b)** 对任意算法性质与复杂度（时间、空间、样本量）的分析。［是］
   - **(c)** （可选）匿名源代码，说明全部依赖项，包括外部库。［是］
2. 对任意理论主张，检查是否包含：
   - **(a)** 所有理论结果的完整假设陈述。［是］
   - **(b)** 所有理论结果的完整证明。［是］
   - **(c)** 对所有假设的清晰解释。［是］
3. 对所有呈现实证结果的图表，检查是否包含：
   - **(a)** 重现主要实验结果所需的代码、数据和说明（作为补充材料或 URL）。［是］
   - **(b)** 所有训练细节（如数据拆分、超参数及其选择方式）。［是］
   - **(c)** 对具体度量或统计量及误差条的清晰定义（例如，多次运行实验后相对于随机种子的变化）。［是］
   - **(d)** 所用计算基础设施的说明（例如 GPU 类型、内部集群或云服务商）。［是］
4. 如果使用已有资源（例如代码、数据、模型），或整理/发布新资源，检查是否包含：
   - **(a)** 如果工作使用已有资源，对创作者的引用。［是］
   - **(b)** 如适用，资源的许可信息。［不适用］
   - **(c)** 如适用，以补充材料或 URL 提供新资源。［是］
   - **(d)** 关于数据提供者/整理者同意的信息。［不适用］
   - **(e)** 如适用，讨论敏感内容，例如个人可识别信息或冒犯性内容。［不适用］
5. 如果使用众包或开展涉及人类参与者的研究，检查是否包含：
   - **(a)** 向参与者提供的完整说明文字及截图。［不适用］
   - **(b)** 对参与者潜在风险的说明；如适用，附机构审查委员会（IRB）批准链接。［不适用］
   - **(c)** 支付给参与者的估计时薪，以及参与者报酬总支出。［不适用］

半参数共形预测：补充材料

9 非参数藤 copula

本节介绍非参数藤 copula 的估计与模型选择过程。首先简要介绍 copula 和藤 copula 的基本概念。

9.1 Copula

设 $S = [S_1, \ldots, S_d]$ 是一个 d 维连续随机向量，其联合分布函数为 F，联合密度函数为 f；对 $j \in [d]$，边际分布函数和边际密度函数分别为 F_j 和 f_j。Sklar 定理（定理1）保证存在 copula $C : [0, 1]^d \to [0, 1]$，使得

$$F(s_1, \ldots, s_d) = C(F_1(s_1), \ldots, F_d(s_d)). \tag{23}$$

对于绝对连续分布，C 是唯一的。边际量 $u_j := F_j(s_j)$（$j \in [d]$）由概率积分变换（PIT）得到，服从均匀分布。这是因为

$$\mathbb{P}[F_j(S_j) \le u_i] = \mathbb{P}[S_j \le F_j^{-1}(u_j)] = F_j\left(F_j^{-1}(u_j)\right) = u_j, \quad \forall j \in [d].$$

因此，C 是定义在均匀分布边际量上的分布函数。

对式（23）求偏导，得到 copula 密度 $c : [0, 1]^d \to [0, 1]$：

$$f(s_1, \ldots, s_d) = \frac{\partial^d F(s_1, \ldots, s_d)}{\partial s_1 \cdots \partial s_d} = \underbrace{\frac{\partial^d C(u_1, \ldots, u_d)}{\partial u_1 \cdots \partial u_d}}_{=: c(u_1, \ldots, u_d)} \prod_{i=1}^{d} \frac{dF_i(s_i)}{ds_i} = c(u_1, \ldots, u_d) \prod_{i=1}^{d} f_i(s_i). \tag{24}$$

为了基于数据集 $\{(s_1^{(i)}, \ldots, s_d^{(i)})\}_{i=1}^n$ 建模联合分布，可以分别为每个变量指定边际模型，再用 copula 模型通过两步过程将它们连接（耦合）起来。第一步，应用 PIT 得到近似均匀分布的伪观测值：

$$u^{(i)} = \left(F_1(s_1^{(i)}), \ldots, F_d(s_d^{(i)})\right), \quad \forall i \in [d].$$

对所有 $j \in [d]$ 的 F_j 使用参数化边际模型，就得到边际推断（IFM）方法（Joe，2005）。本文采用经验边际分布（Genest 等，1995）。

第二步，指定 copula 模型，并通过最大似然估计或矩匹配估计其参数。参数化 copula 族，例如椭圆族（包括高斯 copula 和 t-copula）与阿基米德族（包括 Gumbel、Clayton 和 Frank copula），对对称性和尾部依赖的假设可能具有较强限制。选择单一参数化 copula 意味着每一对变量都具有相同类型的尾部依赖，而实际应用未必如此。

9.2 藤 copula

藤 copula 是由二元构件组成的灵活模型。我们基本沿用 Czado 和 Nagler（2022）的论述，以 $d = 3$ 为例说明成对 copula 分解。联合密度可以分解为：

$$f(s_1, s_2, s_3) = f_{3|12}(s_3 \mid s_1, s_2) f_{2|1}(s_2 \mid s_1) f_1(s_1). \tag{25}$$

记 $F_{j|k,\ldots,l}$ 和 $f_{j|k,\ldots,l}$ 分别为给定 $S_k, \ldots, S_l$ 时 S_j 的条件分布与条件密度。还用 $c_{i,j;k}(\cdot, \cdot; s_k)$ 表示与给定 $S_k = s_k$ 时 S_i, S_j 的条件密度相对应的条件 copula 密度，也称为成对 copula。由定理1可得

$$f_{3|12}(s_3 \mid s_1, s_2) = \frac{f_{13|2}(s_1, s_3 \mid s_2)}{f_{1|2}(s_1 \mid s_2)} = \frac{c_{13;2}(F_{1|2}(s_1 \mid s_2), F_{3|2}(s_3 \mid s_2); s_2) \cancel{f_{1|2}(s_1 \mid s_2)} f_{3|2}(s_3 \mid s_2)}{\cancel{f_{1|2}(s_1 \mid s_2)}}. \tag{26}$$

条件密度 $f_{2|1}$ 和分布 $F_{2|1}$ 可以写为

$$f_{2|1}(s_2 \mid s_1) = c_{12}(F_1(s_1), F_2(s_2)) f_2(s_2), \tag{27}$$

类似地,

$$f_{3|2}(s_3 \mid s_2) = c_{23}(F_2(s_2), F_3(s_3)) f_3(s_3). \tag{28}$$

将式（26）、（27）和（28）代入式（25），得到

$$f(s_1, s_2, s_3) = c_{13;2}(F_{1|2}(s_1 \mid s_2), F_{3|2}(s_3 \mid s_2); s_2)\, c_{23}(F_2(s_2), F_3(s_3))\, c_{12}(F_1(s_1), F_2(s_2)) f_3(s_3) f_2(s_2) f_1(s_1). \tag{29}$$

联合密度还存在另外两种分解:

$$f(s_1, s_2, s_3) = c_{23;1}(F_{2|1}(s_2 \mid s_1), F_{3|1}(s_3 \mid s_1); s_1)\, c_{13}(F_1(s_1), F_3(s_3))\, c_{12}(F_1(s_1), F_2(s_2)) f_3(s_3) f_2(s_2) f_1(s_1),$$

$$f(s_1, s_2, s_3) = c_{12;3}(F_{1|3}(s_1 \mid s_3), F_{2|1}(s_2 \mid s_1); s_3)\, c_{13}(F_1(s_1), F_3(s_3))\, c_{23}(F_2(s_2), F_3(s_3)) f_3(s_3) f_2(s_2) f_1(s_1).$$

这三种分解都包含形如 $c_{ij;k}(\cdot, \cdot; s_k)$ 的成对 copula 项。通常，我们作出简化假设，忽略其对 s_k 的显式依赖，由函数的自变量来承载这种依赖。因此，式（29）的简化成对 copula 构造（PCC）为下式；它不再是精确分解:

$$\begin{aligned} f(s_1, s_2, s_3; \theta) = {} & c_{13;2}(F_{1|2}(s_1 \mid s_2), F_{3|2}(s_3 \mid s_2); \theta_{13;2})\, c_{23}(F_2(s_2), F_3(s_3); \theta_{23}) \\ & c_{12}(F_1(s_1), F_2(s_2), \theta_{12}) f_3(s_3) f_2(s_2) f_1(s_1), \end{aligned} \tag{30}$$

其中，$\theta = (\theta_{13;2}, \theta_{23}, \theta_{12})$ 为参数化 copula 密度 $c_{13;2}$、c_{23} 和 c_{12} 的参数向量。为了从数据集 $\{(s_1^{(i)}, s_2^{(i)}, s_3^{(i)})\}_{i=1}^n$ 估计 θ，可以沿用第9.1节概述的两步过程：先生成伪观测值 $\{u^{(i)}\}_{i=1}^n = \{(u_1^{(i)}, u_2^{(i)}, u_3^{(i)})\}_{i=1}^n$，再通过例如最大似然估计来估计 θ：

$$\theta^* = \operatorname{argmax}_\theta \ell\left(\{u^{(i)}\}_{i=1}^n; \theta\right)$$

$$\ell\left(\{u^{(i)}\}_{i=1}^n; \theta\right) = \prod_{i=1}^n c_{13;2}(C_{1|2}(u_1^{(i)} \mid u_2^{(i)}; \theta_{12}), C_{3|2}(u_1^{(i)} \mid u_2^{(i)}; \theta_{23}); \theta_{13;2})\, c_{23}(u_2^{(i)}, u_3^{(i)}; \theta_{23})\, c_{12}(u_1^{(i)}, u_2^{(i)}; \theta_{12}).$$

如果参数化 copula 族不足以拟合伪观测值，非参数方法可以提供更灵活的拟合。变换局部似然核估计器（TLL）的表现良好（Geenens，2014；Nagler 等，2017）。本文选用以 TLL 为构件的藤 copula。

上述 PCC 可以推广到一般的 d。正则藤（R-vine）树结构为定义有效分解提供了框架（Bedford 和 Cooke，2001，2002）。正则藤是一串相互连接的树，其中一棵树的边成为下一棵树的节点。形式上，若图集合 $\mathcal{V} = (T_1, \ldots, T_{d-1})$ 满足以下条件，则它是 d 个元素上的正则藤：

1. T_1 是节点集为 $N_1 = \{1, \ldots, d\}$、边集为 E_1 的树。
2. 对于 $j \geq 2$，T_j 是节点集为 $N_j = E_{j-1}$、边集为 E_j 的树。
3. **邻近条件：**对于 $j \geq 2$ 及 $\{a, b\} \in E_j$，有 $|a \cap b| = 1$。也就是说，若 T_j 中两个节点之间有一条边，则它们在 T_{j-1} 中对应的两条边共享一个节点。

每条边都对应一个成对 copula。式（30）的例子具有藤结构 $N_1 = \{1, 2, 3\}$、$E_1 = \{\{1, 2\}, \{2, 3\}\}$、$N_2 = \{\{1, 2\}, \{2, 3\}\}$ 和 $E_2 = \{1, 3; 2\}$，图7给出了其图示。为简化节点集与边集的记号，定义给定边 $e \in E_k$ 所对应的完全并集：

$$A_e := \{k \in N_1 \mid \exists e_1 \in E_1, \ldots, e_{k-1} \in E_{k-1} \text{ s.t. } j \in e_1 \in \ldots \in e_{k-1} \in e\}.$$

边 $e = \{a, b\}$ 对应成对 copula $c_{a,b;D_e}$，其中 e 的条件集为 $D_e = A_a \cap A_b$，被条件化集合 $C_{e,a}, C_{e,b}$ 分别为 $C_{e,a} = A_a \backslash D_e$ 和 $C_{e,b} = A_b \backslash D_e$。例如，若边 $e = \{a, b\}$ 的 $a = \{1, 2\}$、$b = \{2, 3\}$，则 $A_a = \{1, 2\}$、$A_b = \{2, 3\}$，且 $D_e = \{2\}$。于是，被条件化集合为 $C_{e,a} = \{1\}$ 和 $C_{e,b} = \{3\}$。

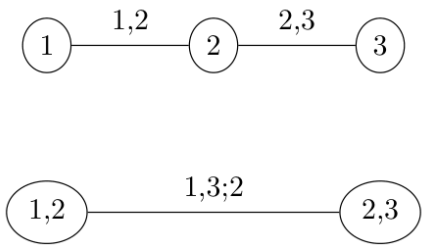


图7：式（30）中的 PCC 所对应藤结构的图示。

综上，可以用三元组 $(\mathcal{F}, \mathcal{V}, \mathcal{B})$ 所指定的正则藤分布，对随机向量 $S = (S_1, \ldots, S_d)$ 的 d 元联合分布建模。其中，$\mathcal{F} = (F_1, \ldots, F_d)$ 是边际分布函数的元组，$\mathcal{V}$ 是藤结构，而 $\mathcal{B} = \{C_e \mid e \in E_j;\ j \in [d-1]\}$ 是二元 copula C_e 的集合；它们对应给定 S_{D_e} 时 $S_{C_{e,a}}$ 和 $S_{C_{e,a}}$ 的条件分布。

定理4（正则藤分布的存在性，Bedford 和 Cooke，2002）。给定三元组 $(\mathcal{F}, \mathcal{V}, \mathcal{B})$，存在一个有效的 d 维分布 F，其密度为

$$f_{1,\ldots,d}(s_1, \ldots, s_d) = f_1(s_1) \times \cdots \times f_d(s_d) \times \prod_{i=1}^{d-1} \prod_{e \in E_i} c_{c_{e,a}, c_{e,b}; D_e}\left(F_{c_{e,a}|D_e}(s_{c_{e,a}} \mid s_{D_e}), F_{c_{e,b}|D_e}(s_{c_{e,b}} \mid s_{D_e})\right),$$

并且满足

$$F_{c_{e,a}, c_{e,b}|D_e}(s_{c_{e,a}}, s_{c_{e,b}} \mid s_{D_e}) = C_e\left(F_{c_{e,a}|D_e}(s_{c_{e,a}} \mid s_{D_e}), F_{c_{e,b}|D_e}(s_{c_{e,b}} \mid s_{D_e})\right).$$

二元 copula 的参数可以通过最大似然进行估计。虽然有效藤结构的数量随 d 超指数增长，为 $d!\times 2^{(d-2)(d-3)/2-1}$（Napoles 等，2010），Dissmann 等（2013）的贪心选择算法仍能实现高效探索。

10 有效影响函数

本节推导分位数估计目标的有效影响函数（EIF）。我们采用点质量污染方法：沿单个观测值 $\tilde{s}$ 处的点质量方向扰动估计目标，从而得到式（8）中 $\widetilde{P}=\delta_{\tilde{s}}$ 的混合参数子模型：

$$P_t=(1-t)P+t\delta_{\tilde{s}}. \tag{31}$$

然后取

$$\psi_P(\tilde{s})=\left.\frac{d\Psi(P_t)}{dt}\right|_{t=0}, \tag{32}$$

这也称为 Gâteaux 导数。

10.1 单变量分位数

这里的推导基本沿用 Hines 等（2022）的表述。感兴趣的估计目标是 $\Psi_{1-\alpha}(P)=F^{-1}(1-\alpha)$。该分位数可以隐式写为

$$\int_{-\infty}^{\Psi_{1-\alpha}(P)} f(s)ds=1-\alpha,$$

其中 f 是密度函数。

用参数子模型表示，有

$$\int_{-\infty}^{\Psi_{1-\alpha}(P_t)} f_t(s)ds=1-\alpha,$$

其中 $f_t(s)=(1-t)f(s)+t\delta_{\tilde{s}}(s)$。

利用莱布尼茨积分法则对两边关于 t 求导，得到

$$f_t\left(\Psi_{1-\alpha}(P_t)\right)\frac{d\Psi_{1-\alpha}(P_t)}{dt}+\int_{-\infty}^{\Psi_{1-\alpha}(P_t)}\frac{df_t(s)}{dt}ds=0.$$

由 $F_t(s)=(1-t)F(s)+t\mathbb{1}\left[\tilde{s}\le s\right]$，

$$
\begin{aligned}
\frac{d\Psi_{1-\alpha}(P_t)}{dt} &= \frac{-1}{f_t\left(\Psi_{1-\alpha}(P_t)\right)} \int_{-\infty}^{\Psi_{1-\alpha}(P_t)} \frac{df_t(s)}{dt} ds \\
&= \frac{1}{f_t\left(\Psi_{1-\alpha}(P_t)\right)} \int_{-\infty}^{\Psi_{1-\alpha}(P_t)} \left(f(s) - \delta_{\tilde{s}}(s)\right) ds \\
&= \frac{F(F_t^{-1}(1-\alpha)) - \mathbb{1}[\tilde{s} \leq \Psi_{1-\alpha}(P_t)]}{f_t\left(\Psi_{1-\alpha}(P_t)\right)}.
\end{aligned}
$$

在 $t = 0$ 处求值，便得到

$$
\begin{aligned}
\psi_P(\tilde{s}) &= \frac{1 - \alpha - \mathbb{1}[\tilde{s} \leq \Psi_{1-\alpha}(P)]}{f\left(\Psi_{1-\alpha}(P)\right)} \\
&= \frac{\mathbb{1}[\Psi_{1-\alpha}(P) \leq \tilde{s}] - \alpha}{f\left(\Psi_{1-\alpha}(P)\right)}. \quad \square
\end{aligned}
$$

分位数回归使用的 pinball 损失为 $l_{1-\alpha}(x) = x(\mathbb{1}[x \geq 0] - \alpha)$（Koenker 和 Bassett Jr，1978）。可以看出，最后一个表达式的分子就是其导数 $l'_{1-\alpha}(x) = \mathbb{1}[x \geq 0] - \alpha$，即 $l'_{1-\alpha}\left(\tilde{s} - \Psi_{1-\alpha}(P)\right)$。

10.2 多变量分位数

当 $d > 1$ 时，参数子模型为 $F_t(s) = (1-t)F(s) + t\mathbb{1}\left[\tilde{s}_1 \leq s_1, \ldots, \tilde{s}_d \leq s_d\right]$，其中 $s = \left[s_1, \ldots, s_d\right]$。我们采用与前面类似的方法，但直接使用 CDF，以避免处理多重积分。为简化记号，先定义 $\Psi_{1-\alpha}(P_t) := g(t)$ 和 $\Psi_{1-\alpha}(P) := g$。

参数子模型下的分位数满足

$$
(1-t)F(g(t)) + t\mathbb{1}[\underbrace{\tilde{s}_1 \leq g(t)_1, \ldots, \tilde{s}_d \leq g(t)_d}_{\tilde{s} \preccurlyeq g(t)}] = 1 - \alpha.
$$

对等式两边关于 t 求导，并令 $t = 0$，得到

$$
\begin{aligned}
& -F(g) + \left.\frac{\partial F}{\partial s_1}\right|_{s=g} \frac{dg_1}{dt} + \cdots + \left.\frac{\partial F}{\partial s_d}\right|_{s=g} \frac{dg_d}{dt} + \mathbb{1}[\tilde{s} \preccurlyeq g] = 0 \\
\implies & -(1-\alpha) + \left.\frac{\partial F}{\partial s_1}\right|_{s=g} \frac{dg_1}{dt} + \cdots + \left.\frac{\partial F}{\partial s_d}\right|_{s=g} \frac{dg_d}{dt} + \mathbb{1}[\tilde{s} \preccurlyeq g] = 0 \\
\implies & \left.\frac{\partial F}{\partial s_1}\right|_{s=g} \frac{dg_1}{dt} + \cdots + \left.\frac{\partial F}{\partial s_d}\right|_{s=g} \frac{dg_d}{dt} = (1-\alpha) - \mathbb{1}[\tilde{s} \preccurlyeq g].
\end{aligned} \tag{33}
$$

回顾 EIF 为

$$
\psi_P(\tilde{s}) = \left(\frac{dg_1}{dt}, \ldots, \frac{dg_d}{dt}\right).
$$

定义梯度 $\nabla F = \left(\partial F/\partial s_1, \ldots, \partial F/\partial s_d\right)$，并假设 $\psi_P(\tilde{s})$ 与 $\nabla F(g)$ 成正比：

$$\psi_P(\tilde{s}) = \lambda \nabla F(g). \tag{34}$$

于是可将式（33）改写为

$$\begin{aligned} &\nabla F(g) \cdot (\lambda \nabla F(g)) = (1-\alpha) - \mathbb{1}[\tilde{s} \preccurlyeq g] \\ &\implies \lambda |\nabla F(g)|^2 = (1-\alpha) - \mathbb{1}[\tilde{s} \preccurlyeq g] \\ &\implies \lambda = \frac{(1-\alpha) - \mathbb{1}[\tilde{s} \preccurlyeq g]}{|\nabla F(g)|^2}, \end{aligned} \tag{35}$$

其中 $|\cdot|_2$ 为 L_2 范数。因此，由式（34）和式（35）共同得到

$$\psi_P(\tilde{s}) = \frac{(1-\alpha) - \mathbb{1}[\tilde{s} \preccurlyeq g]}{|\nabla F(g)|^2} \nabla F(g).$$

注意，当 $d = 1$ 时，上式化为

$$\psi_P(\tilde{s}) = \frac{(1-\alpha) - \mathbb{1}[\tilde{s} \le g]}{f(g)^2} f(g) = \frac{(1-\alpha) - \mathbb{1}[\tilde{s} \le g]}{f(g)} = \frac{(1-\alpha) - (1 - \mathbb{1}[g \le \tilde{s}])}{f(g)} = \frac{\mathbb{1}[g \le \tilde{s}] - \alpha}{f(g)},$$

这就恢复了第10.1节的结果。

11 路径可微的估计目标

本节从缩减代入偏差的角度介绍一步估计。基于代入偏差的分解，我们将说明，非参数估计之后的一步修正有助于控制造成偏差的主导项。再次将真实的数据生成分布记为 P，将感兴趣的估计目标记为 $\Psi(P)$。假设已经得到了 P 的数据自适应估计 $\widehat{P}$。定义参数子模型：

$$P_t = (1-t)P + t\hat{P}.$$

$\Psi(P)$ 在 $t = 1$ 附近的分布泰勒展开（也称为 von Mises 展开）可写为：

$$\Psi(P) = \Psi(\hat{P}) + \left.\frac{d\Psi(P_t)}{dt}\right|_{t=1} (0-1) + r_2(P, \hat{P}) = \Psi(\hat{P}) + \mathbb{E}_P[\psi_{\hat{P}}] + r_2(P, \hat{P}), \tag{36}$$

其中 r_2 是余项。下文采用记号 $\mathbb{E}_P[\cdot] = P[\cdot]$。现在考虑经过缩放的代入偏差：

$$\sqrt{n}\left(\Psi(\hat{P}) - \Psi(P)\right) = -\sqrt{n}P[\psi_{\hat{P}}] - \sqrt{n}r_2(P, \hat{P}) \tag{37}$$

$$= \sqrt{n}\left(\mathbb{P}_n - P\right)[\psi_P] + \sqrt{n}\mathbb{P}_n[\psi_{\hat{P}}] - \sqrt{n}\left(\mathbb{P}_n - P\right)[\psi_P] - \sqrt{n}\mathbb{P}_n[\psi_{\hat{P}}] - \sqrt{n}P[\psi_{\hat{P}}] - \sqrt{n}r_2(P, \hat{P}) \tag{38}$$

$$= \sqrt{n}\left(\mathbb{P}_n - P\right)[\psi_P] + \sqrt{n}\left(\mathbb{P}_n - P\right)[\psi_{\hat{P}} - \psi_P] - \sqrt{n}P[\psi_{\hat{P}}] - \sqrt{n}r_2(P, \hat{P}) \tag{39}$$

$$= \underbrace{\sqrt{n}\mathbb{P}_n[\psi_P]}_{\text{(a)}} - \underbrace{\sqrt{n}P[\psi_P]}_{\text{(b)}} + \underbrace{\sqrt{n}\left(\mathbb{P}_n - P\right)[\psi_{\hat{P}} - \psi_P]}_{\text{(c)}} - \underbrace{\sqrt{n}P[\psi_{\hat{P}}]}_{\text{(d)}} - \underbrace{\sqrt{n}r_2(P, \hat{P})}_{\text{(e)}}. \tag{40}$$

由于影响函数满足 $P\left[\psi_P\right]=0$，项（b）等于0；根据中心极限定理，项（a）渐近收敛于以0为中心的正态分布。如 Hines 等（2022）所述，也可以证明，在一定条件下，项（c）和项（e）同样收敛于0。

然而，漂移项（d）仍然存在，在某些情况下甚至可能发散。值得注意的是，即使用 ψ_P 代替 $\psi_{\widehat{P}}$，它也不会收敛于0。我们希望去除这一项：

$$(\mathrm{d})=\sqrt{n}P[\psi_{\hat{P}}]\approx\sqrt{n}\mathbb{P}_n[\psi_{\hat{P}}]=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\psi_{\hat{P}}(S^{(i)}).$$

一步估计量只是对代入估计量进行调整，使该项造成的偏差为0：

$$\Psi_{1\text{-step}}(\hat{P})=\Psi(\hat{P})+\frac{1}{n}\sum_{i=1}^{n}\psi_{\hat{P}}(S^{(i)}). \tag{41}$$

由于涉及数据自适应估计 $\widehat{P}$，经验过程项（c）的渐近行为较难分析。为便于分析，假设拟合 $\widehat{P}$ 所使用的数据集，与用于对 EIF 求期望的数据集相互独立，这样便可以条件于 $\widehat{P}$。于是，由切比雪夫不等式，

$$P[\left(\psi_{\hat{P}}-\psi_P\right)^2|\hat{P}]=o_p(1)\implies(\mathrm{c})\coloneqq\sqrt{n}\left(\mathbb{P}_n-P\right)\left[\psi_{\hat{P}}-\psi_P\right]=o_p(1). \tag{42}$$

而 $P\left[\left(\psi_{\widehat{P}}-\psi_P\right)^2\mid\widehat{P}\right]=o_p(1)$ 的一个充分条件，是 $\widehat{P}$ 依概率收敛于 P。因此，预留一个独立的数据子集来拟合 $\widehat{P}$，有助于缩减项（c）。关于 K 折交叉验证的分析，可参见 Van der Laan 等（2011）及 Chernozhukov 等（2018）。在实验中，我们发现项（c）的影响较小，因此选择尽可能多地使用数据进行一次性 copula 拟合，而不采用 K 折划分（这会增加我们方法的计算开销），也不留出一个子集（这会损害 copula 的拟合）。

12 划分算法

我们给出算法2，它是算法1的一种变体，额外划分一次校准集。原文以橙色标示与算法1的差异（本译文重新排版，保留逐行步骤）。校准集的一个子集用于计算边际 ECDF，另一个用于拟合 copula。根据定理5，这一变体保证有限样本、分布无关的有效性。

算法2：半参数共形预测——划分版本

1. **输入：**带标签数据 $\mathcal{I}$，测试输入 $\mathcal{I}_{\text{test}}$，目标覆盖水平 $1-\alpha$。
2. **输出：** $i\in\mathcal{I}_{\text{test}}$ 的预测集 $\Gamma_{1-\alpha}\left(X^{(i)}\right)$。
3. 将 $\mathcal{I}$ 划分为 $\mathcal{I}_{\text{train}}$、$\mathcal{I}_{\text{cal,1}}$ 和 $\mathcal{I}_{\text{cal,2}}$。
4. 在 $\mathcal{I}_{\text{train}}$ 上训练基础算法 $\widehat{f}$。
5. **对于** $i\in\mathcal{I}_{\text{cal}}$：
6. 　**对于** $j\in[d]$：
7. 　　$S_j^{(i)}\leftarrow V\left(X_j^{(i)},\,Y_j^{(i)},\,\widehat{f}\right)$。
8. 　**结束循环**。

9. **结束循环**。
10. **对于** $i \in \mathcal{I}_{\text{cal},1}$：
11. 　**对于** $j \in [d]$：
12. 　　$\widehat{F}_j(s) \leftarrow$ 式（12）。▷ 边际 ECDF
13. 　　$U_j^{(i)} \leftarrow \widehat{F}_j\left(S_j^{(i)}\right)$。▷ 均匀边际量
14. 　**结束循环**。
15. **结束循环**。
16. 在 $\{U^{(i)}\}_{i\in\mathcal{I}_{\text{cal},2}}$ 上拟合 copula $\widehat{C}$。
17. $U^* \leftarrow$ 式（16）。
18. $Q_{1-\alpha} \leftarrow$ 式（17）的 $Q_{1-\alpha}\left(U^*\right)$。
19. **如果** correction 为 True：
20. 　$U^* \leftarrow$ 式（19）的 $U_{\text{1-step}}$。
21. 　$Q_{1-\alpha} \leftarrow$ 式（17）的 $Q_{1-\alpha}\left(U^*\right)$。
22. **结束条件语句**。
23. **对于** $i \in \mathcal{I}_{\text{test}}$：
24. 　$\Gamma_{1-\alpha}\left(X^{(i)}\right) \leftarrow$ 式（6）。
25. **结束循环**。
26. **返回** $\Gamma_{1-\alpha}\left(X^{(i)}\right),\ \forall\, i \in \mathcal{I}_{\text{test}}$。

13 理论结果

定理2。

证明。将 F^* 的 $(1-\alpha)$ 分位数定义为

$$Q_{1-\alpha} = \inf_s\{||s||_1 : F^*(s) = 1-\alpha\},$$

令 $\widehat{Q}_{1-\alpha}$ 为由 $\widehat{F}$ 得到的代入估计量。由于在所述正则条件下，分位数泛函 $\Psi : F \mapsto Q_{1-\alpha}$ 是 Hadamard 可微的，有

$$\sqrt{n}\left(\hat{Q}_{1-\alpha} - Q_{1-\alpha}\right) = \frac{1}{\sqrt{n}}\sum_{i=1}^{n}\psi(S^{(i)}) + o_p(1),$$

其中 $\psi : \mathbb{R}^d \to \mathbb{R}^d$ 是分位数泛函的 EIF。一步修正估计量定义为

$$\hat{Q}_{1-\alpha}^{\text{1-step}} = \hat{Q}_{1-\alpha} + \frac{1}{n}\sum_{i=1}^{n}\psi(S^{(i)}).$$

于是可得

$$\sqrt{n}\left(\hat{Q}_{1-\alpha}^{\text{1-step}} - Q_{1-\alpha}\right) = o_p(1),$$

因此，$\widehat{Q}_{1-\alpha}^{\text{1-step}}$ 是 $Q_{1-\alpha}$ 的 $\sqrt{n}$ 一致估计量。

现在考虑一个测试点 $\left(X^*,\, Y^*\right)$，其对应的非一致性分数为 $S^* = V\left(X^*,\, Y^*,\, \widehat{f}\,\right)$。由于预测集定义为

$$\Gamma_{1-\alpha}(X^*) = \{Y \in \mathbb{R}^d : V(X^*, Y, \hat{f}) \preceq \hat{Q}_{1-\alpha}^{\text{1-step}}\},$$

我们有

$$\mathbb{P}\big(Y^* \in \Gamma_{1-\alpha}(X^*)\big) = \mathbb{P}\big(S^* \preceq \hat{Q}_{1-\alpha}^{\text{1-step}}\big).$$

根据 $\widehat{F}$ 的定义，并利用 $\widehat{F}$ 的一致相合性以及 F^* 的连续性，有

$$\hat{F}\big(\hat{Q}_{1-\alpha}^{\text{1-step}}\big) \xrightarrow{p} F^*\big(Q_{1-\alpha}\big) = 1 - \alpha.$$

因此，当 $n \to \infty$ 时，

$$\mathbb{P}\big(S^* \preceq \hat{Q}_{1-\alpha}^{\text{1-step}}\big) = \hat{F}\big(\hat{Q}_{1-\alpha}^{\text{1-step}}\big) \to 1 - \alpha.$$

定理3。

证明。我们假设

$$\sup_S \left|F^*(S) - \hat{F}(S)\right| \le \epsilon.$$

令 $\widehat{Q}_{1-\alpha}$ 为 $\widehat{F}$ 的 $(1-\alpha)$ 分位数，即

$$\hat{F}(\hat{Q}_{1-\alpha}) = 1 - \alpha.$$

回顾使用代入分位数的预测集定义为

$$\Gamma_{1-\alpha}(X^*) = \{Y \in \mathbb{R}^d : V(X^*, Y, \hat{f}) \preccurlyeq \hat{Q}_{1-\alpha}\}.$$

注意，从分布 F 到分位数的映射在 TV 距离下是 Lipschitz 连续的。更确切地说，根据数据处理不等式——对任意可测函数 g，均有

$$d_{\text{TV}}\big(P \circ g^{-1}, Q \circ g^{-1}\big) \le d_{\text{TV}}(P, Q),$$

——对于分位数

$$A(F') = \inf_s \{||s||_1 : F' = 1-\alpha\},$$

有

$$\left|A(F) - A(\hat{F})\right| \le \sup_S \left|F^*(S) - \hat{F}(S)\right| \le \epsilon.$$

由于 $\widehat{F}\left(\widehat{Q}_{1-\alpha}\right) = 1-\alpha$，因此

$$F^*(\hat{Q}_{1-\alpha}) \ge 1-\alpha-\epsilon.$$

此时覆盖率为

$$\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}(X^*)\right] = \mathbb{P}\left[V(X^*, Y^*, \hat{f}) \le \hat{Q}_{1-\alpha}\right] = F^*(\hat{Q}_{1-\alpha}) \ge 1-\alpha-\epsilon.$$

这就是所要证明的结果。如果改用一步修正分位数构造预测集 $\Gamma_{1-\alpha}^{\text{1-step}}$，那么按其设计，修正项不会在 $\widehat{F}$ 的估计误差之外引入额外误差。因此，同样的论证适用，我们再次得到

$$\mathbb{P}\left[Y^* \in \Gamma_{1-\alpha}^{\text{1-step}}(X^*)\right] \ge 1-\alpha-\epsilon.$$

定理5（算法2的有限样本有效性）。假设完整数据集（包括校准数据和测试点）具有可交换性，且校准集被划分为两个互不相交的子集：

$$I_{\text{cal}} = I_{\text{cal},1} \cup I_{\text{cal},2},$$

其中，集合 $\mathcal{I}_{\text{cal},1}$ 用于构建边际经验 CDF 并拟合 copula，集合 $\mathcal{I}_{\text{cal},2}$（$n' \equiv |\mathcal{I}_{\text{cal},2}|$）用于构建经验 copula，并从中提取 $\lceil (1-\alpha)(n'+1) \rceil / (n'+1)$ 分位数。那么，用来自 $\mathcal{I}_{\text{cal},2}$ 的分位数 $Q_{1-\alpha}$ 构造的预测集

$$\Gamma_{1-\alpha}(X^*) = \{y \in \mathbb{R}^d : V(X^*, y, \hat{f}) \preceq Q_{1-\alpha}\},$$

满足

$$\mathbb{P}\Big(Y^* \in \Gamma_{1-\alpha}(X^*)\Big) \ge 1-\alpha.$$

证明。由于数据具有可交换性，将校准集划分为 $\mathcal{I}_{\text{cal},1}$ 和 $\mathcal{I}_{\text{cal},2}$ 的过程，保证了在 $\mathcal{I}_{\text{cal},2}$ 上计算的分数独立于从 $\mathcal{I}_{\text{cal},1}$ 获得的边际估计和 copula 估计。将 $\mathcal{I}_{\text{cal},2}$ 中各样本的分数记为 $S_1, S_2, \ldots, S_{n'}$，并令 S^* 为测试点 $\left(X^*, Y^*\right)$ 的分数。根据构造，分数 $S_1, \ldots, S_{n'}$ 与 S^* 具有可交换性。

令 $Q_{1-\alpha}$ 为 n' 个校准分数的第 $\lceil (1-\alpha)(n'+1) \rceil$ 个次序统计量。根据标准共形预测论证（例如 Vovk 等，2005；Lei 和 Wasserman，2014），S^* 在 $n'+1$ 个分数中的秩服从均匀分布。因此有

$$\mathbb{P}\Big(S^* \preceq Q_{1-\alpha}\Big) \geq \frac{\lceil (n'+1)(1-\alpha) \rceil}{n'+1} \geq 1-\alpha.$$

由于预测集定义为

$$\Gamma_{1-\alpha}(X^*) = \{y \in \mathbb{R}^d : V(X^*, y, \hat{f}) \preceq Q_{1-\alpha}\},$$

所以

$$\mathbb{P}\Big(Y^* \in \Gamma_{1-\alpha}(X^*)\Big) = \mathbb{P}\Big(S^* \preceq Q_{1-\alpha}\Big) \geq 1-\alpha.$$

14 校准方案

表3总结了实验中的各种校准方案。

表3：各种共形校准方案。

方法	**说明**	**向量分数?**	$\widehat{F}$ **的估计**	**需要优化?**
独立	对每个目标分别进行水平为 $(1-\alpha)^{1/d}$ 的单变量校准	是	ECDF	否
标量分数	对定义为 L_1 范数的标量分数进行校准	否	ECDF	否
经验 copula	在向量分数上拟合经验 copula（Messoudi 等，2021）	是	ECDF 边际，经验 copula	是
代入（本文）	在向量分数上拟合 TLL R-vine	是	ECDF 边际，TLL R-vine	是
修正（本文）	对上述方法应用一步修正	是	ECDF 边际，TLL R-vine	是

表4包含青霉素数据（$d = 3$）上的完整实验结果，其中采用更大的校准集（$n = 200$），以容纳需要额外划分校准集的方法。如果第二个子集 $\mathcal{I}_{\text{cal},2}$ 中的校准点过少，会产生无限大的预测集。这些方法标为“划分”。

对于采用额外划分的标量分数方法，第一个子集 $\mathcal{I}_{\text{cal},1}$ 用来计算各目标分数的均值和标准差，再据此标准化 $\mathcal{I}_{\text{cal},2}$ 的分数，以进行通常的排序。可以将其视为采用了“经拟合的目标聚合方案”，但它仍具有标量分数的根本局限：没有考虑联合相关结构。此外，如果像我们已经做的那样，可以不付出额外代价而在所有地方对标签进行标准化，那么仅用校准子集直接标准化分数可能是一种浪费。我们观察到，划分标量分数方法仍会过度覆盖，因为它们没有进行联合排序。

表4：青霉素数据（$d = 3$, $n = 200$）上的指标。报告十个随机种子下的均值 ± 标准误。目标覆盖率为0.9；效率指标越低越好。

方法	覆盖率	效率 ↓
独立	0.95 ± 0.00	4.0 ± 0.1
标量分数（L_2）	0.92 ± 0.00	4.3 ± 0.1
标量分数（L_1）	0.92 ± 0.00	4.6 ± 0.1
标量分数（L_∞）	0.92 ± 0.00	4.0 ± 0.1
经验 copula	0.91 ± 0.01	3.6 ± 0.1
标量分数（L_2），划分	0.93 ± 0.01	4.4 ± 0.1
标量分数（L_1），划分	0.93 ± 0.01	4.8 ± 0.2
标量分数（L_∞），划分	0.93 ± 0.01	4.0 ± 0.1
代入（本文）	0.92 ± 0.00	3.6 ± 0.2
修正（本文）	0.90 ± 0.00	3.6 ± 0.1
代入，划分（本文）	0.92 ± 0.03	3.8 ± 0.2
修正，划分（本文）	0.92 ± 0.03	3.8 ± 0.2

15 补充实验细节

15.1 合成示例

青霉素生产模拟器（Liang 和 Lai，2021）是一个数值测试函数，接收控制青霉素生产的七个输入参数——培养体积、生物量、浓度、温度、葡萄糖浓度、底物进料速率、底物进料浓度和质子浓度——并输出三个实值目标标签：青霉素产量、生产时间以及排放的二氧化碳副产物数量。如图8所示，目标量高度相关，从而导致图9中的残差也相关。残差还具有上尾，因为其中很可能包含了那10%的实验误差。

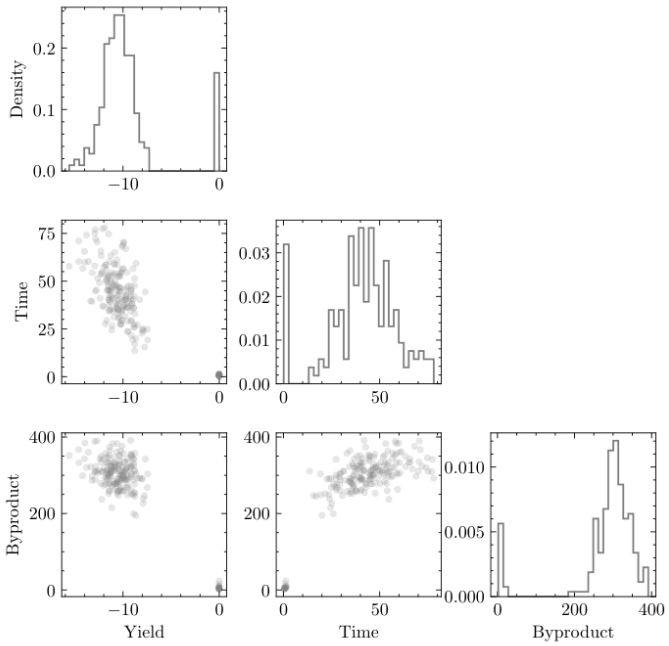


图8：高度相关的目标量。图内：Density＝密度；Yield＝产量；Time＝时间；Byproduct＝副产物。

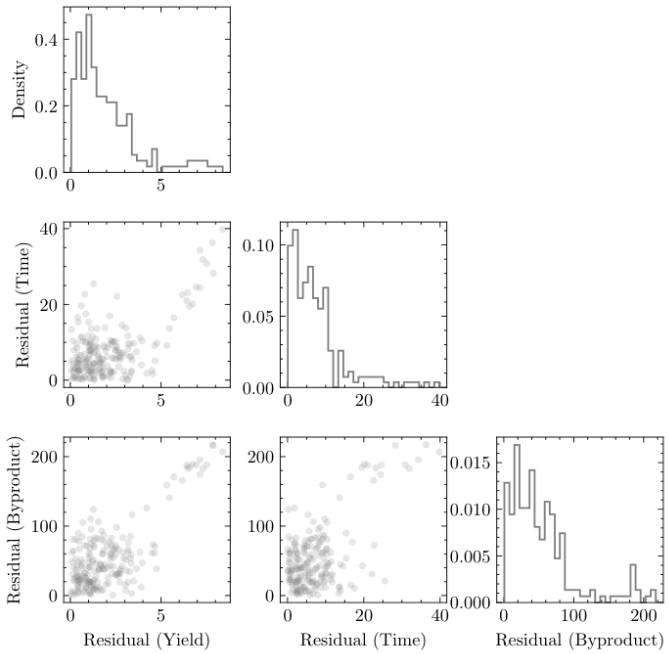


图9：高度相关的残差。图内：Density＝密度；Residual (Yield)＝产量残差；Residual (Time)＝时间残差；Residual (Byproduct)＝副产物残差。

图10绘出了随着校准点数 n 增加，各方法在十个随机种子下覆盖率的均值和标准差。对于0.9的目标覆盖率，我们的修正方法始终在0.91—0.92水平上提供有效覆盖。n 较小时，我们的“代入”方法在十个随机种子下的平均覆盖率为0.91，但标准差较高（0.1）；一步修正会适当地向上调整覆盖率。对于所有 n，我们的方法的覆盖率方差均与“独立”和“标量分数”基线相似，并在 $n \sim 200$ 时缩小至0.04。

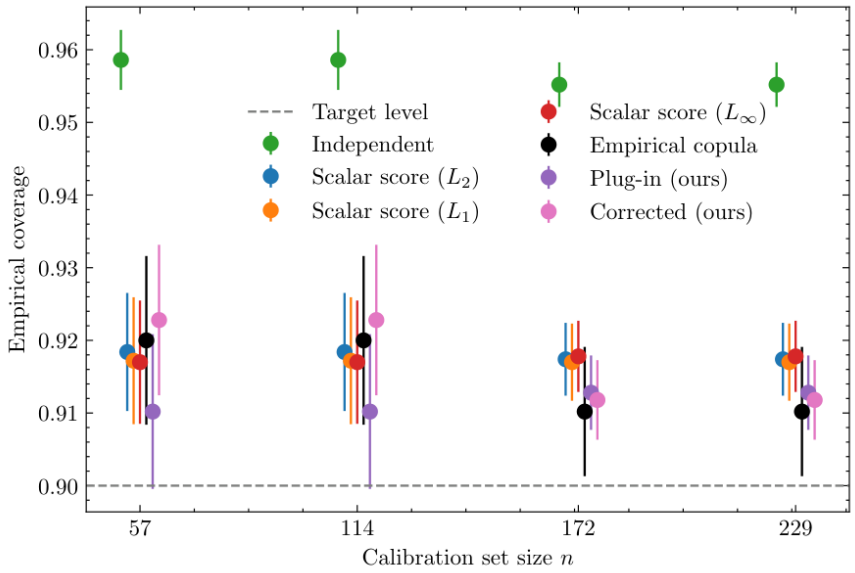


图10：在青霉素数据集（$d = 3$）上，一步修正在所有校准集规模 n 下都提高了代入估计的覆盖率。误差条表示十个随机种子下的标准差。图内：Empirical coverage＝经验覆盖率；Calibration set size n ＝校准集规模 n；Target level＝目标水平；Independent＝独立；Scalar score＝标量分数；Empirical copula＝经验 copula；Plug-in (ours)＝代入（本文）；Corrected (ours)＝修正（本文）。

15.2 真实数据

图11绘出了 rf1 数据集（$d = 6,\ n = 225$）上不同 α 对应的校准覆盖率。与第6.2节的观察一致，由于目标分位数附近上尾中的样本有限，经验 copula 具有较大的方差。在 $1 - \alpha \geq 0.4$ 时，其覆盖率明显低于 $1 - \alpha$。

16 随机缺失数据

随着 d 增大，在许多实际场景中，可能没有多少数据点同时观测到全部 d 个目标变量。我们使用青霉素生产数据的前两个目标（$d = 2$），模拟一种随机缺失（MAR）情形（Rubin，1976）：只有当另一个目标的观测值超过某个阈值时，才观测到一个目标。具体而言，我们生成数据 $\{\left(X^{(i)},\ Y^{(i)}\right)\}_{i=1}^{420}$，并模拟缺失性变量 $\{Z_1^{(i)}\}_{i=1}^{420}$；若观测到 Y_1，则 $Z_1 = 1$，否则为0。如果 Y_1 缺失，分数 S_1 也无法计算。另一方面，变量 Y_2 始终被观测到。我们将缺失性定义如下：

$$Z_1^{(i)} = \mathbb{1}[Y_2^{(i)} \leq 50],$$

由此约有40%的 Y_1 缺失。我们将420个数据点划分为300个训练实例和120个校准实例。基础模型是单变量 Lasso 回归器，对每个目标仅使用已观测标签分别训练（Tibshirani，1996）。此外，还模拟了500个完全观测的测试实例。

如图12所示，如果只使用两个目标标签都被观测到的校准实例，会产生有偏的分位数估计。为纳入 Y_1 缺失的校准实例，我们使用 EM 算法拟合具有缺失值插补的高斯 copula（Feldman 和 Kowal, 2024）。表5表明，所有不进行插补的方法都因缺失性引入的偏差而过度覆盖；而我们采用插补 copula 的方法达到期望的0.9覆盖率，并给出效率最高的预测集。

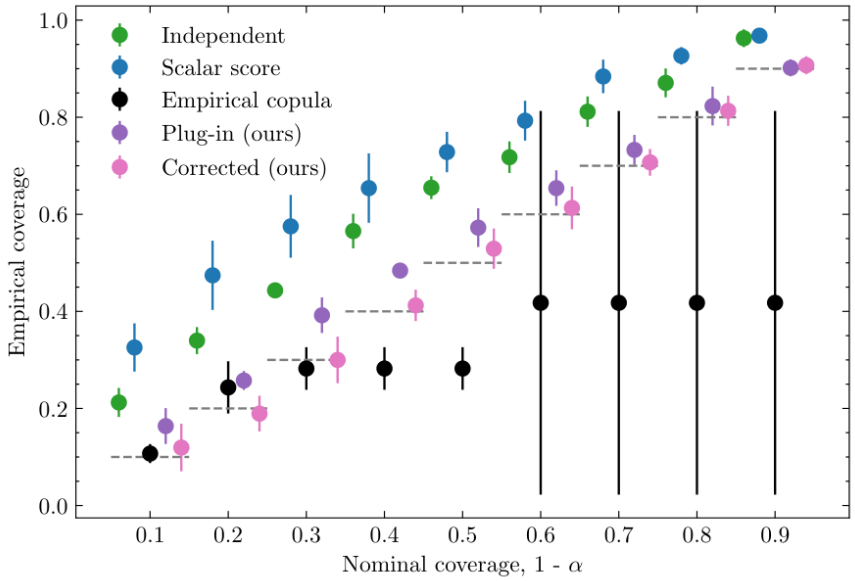


图11： 对于 rf1 数据集（$d = 8$），一步修正在所有目标水平下均提高了代入估计的覆盖率。误差条表示五个随机种子下的标准差。图内：Empirical coverage＝经验覆盖率；Nominal coverage, $1-\alpha$ ＝名义覆盖率 $1-\alpha$；Independent＝独立；Scalar score＝标量分数；Empirical copula＝经验 copula；Plug-in (ours)＝代入（本文）；Corrected (ours)＝修正（本文）。

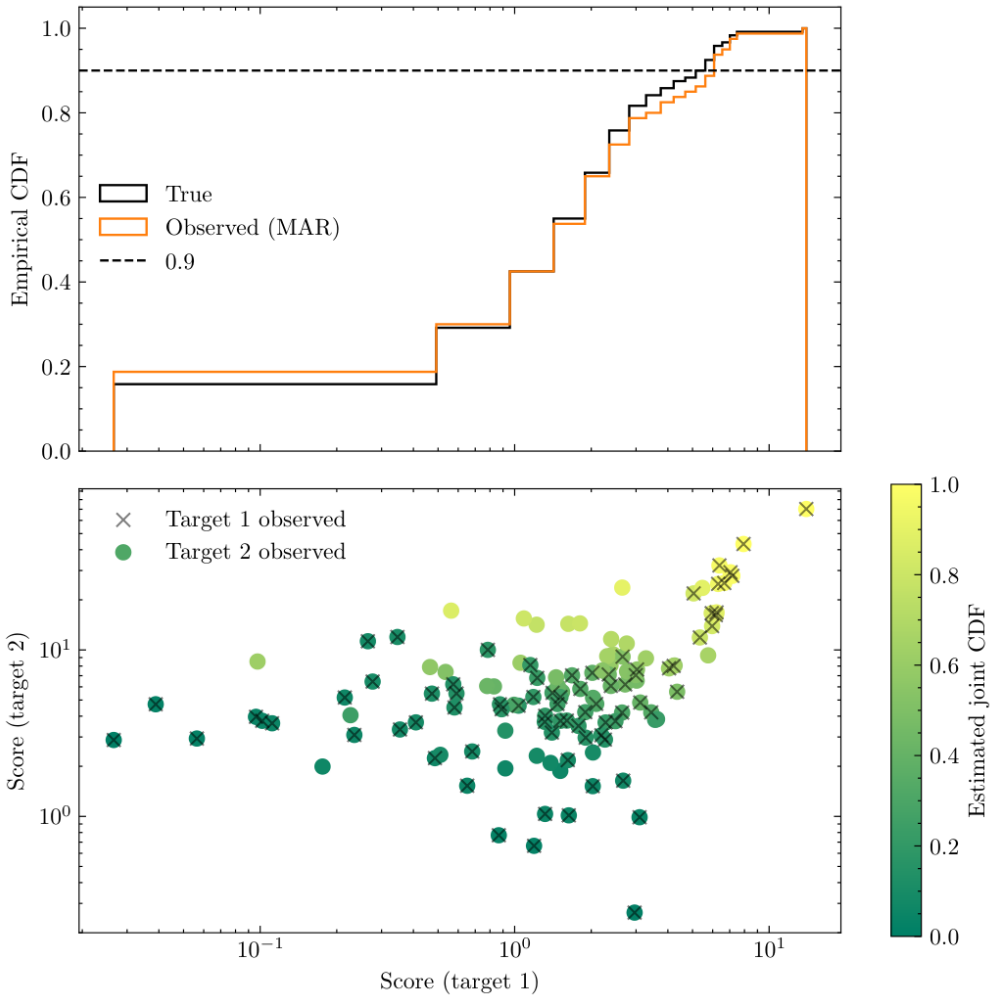


图12：目标标签随机缺失的一种情形：仅当目标2的观测值超过某个值时，才能观测到目标1的标签。根据观测值计算的目标1经验 CDF 与目标1的真实 CDF 不同，因此只使用完全观测的校准实例会导致有偏的分位数估计。图内：Empirical CDF＝经验 CDF；True＝真实；Observed (MAR)＝观测到的（随机缺失）；Target 1 observed＝目标1已观测；Target 2 observed＝目标2已观测；Score (target 1/2)＝分数（目标1/2）；Estimated joint CDF＝估计的联合 CDF。

表5：训练集和校准集中的标签随机缺失时，青霉素数据上的指标。报告五个随机种子下的均值 ± 标准误。目标覆盖率为0.9；效率指标越低越好。

方法	覆盖率	效率 ↓
独立	0.96 ± 0.01	6.7 ± 0.0
标量分数	0.94 ± 0.01	7.2 ± 0.2
经验 copula	0.94 ± 0.01	6.4 ± 0.1
代入（本文）	0.92 ± 0.01	6.2 ± 0.1
修正（本文）	0.92 ± 0.01	6.2 ± 0.1
带插补的代入（本文）	0.90 ± 0.00	6.0 ± 0.0
带插补的修正（本文）	0.91 ± 0.00	6.1 ± 0.0

17 其他基础算法

我们还进行了以条件密度估计器 $\widehat{f} : \mathcal{X} \to \mathbb{R}^d \times \mathbb{R}_+^d$ 为基础模型的实验，该模型输出因子化高斯预测分布的均值和方差。青霉素数据上的结果见表6。该模型是一个隐藏维度为32的两层多层感知机（MLP），训练目标为最小化高斯对数似然：

$$L(\theta) = \sum_{i=1}^{n_{\text{train}}} \sum_{j=1}^{d} \log \sigma_j + \frac{\left(Y_j^{(i)} - \mu_j\right)^2}{2\sigma_j^2},$$

其中，$\mu_j = \mu_j\left(X^{(i)}; \theta\right)$ 和 $\sigma_j = \sigma_j\left(X^{(i)}; \theta\right)$ 分别是目标 j 的高斯预测分布的学习均值和标准差；该分布由 MLP 参数 θ 参数化，n_{train} 是训练集规模。为保证数值稳定性，我们用 $\log\sigma_j^2$ 对 σ_j 进行参数化。

表6：以高斯条件密度估计器为基础模型时，青霉素数据（$d = 3$）上的指标。报告五个随机种子下的均值 ± 标准误。目标覆盖率为0.9；效率指标越低越好。

方法	覆盖率	效率 ↓
独立	0.96 ± 0.01	7.9 ± 0.2
标量分数	0.95 ± 0.01	6.9 ± 0.1
经验 copula	0.95 ± 0.01	7.9 ± 0.3
代入（本文）	0.94 ± 0.02	7.7 ± 0.6
修正（本文）	0.92 ± 0.01	7.0 ± 0.2

> **译者说明（原文内部差异）：** 本译文保留原文的公式与论证，不作数学修正。算法2与定理5对两个校准子集用途的表述不同；定理2和定理3的证明按原文照译。第15.1节称输入为七个参数，但列举的名称数量不一致；第15.2节正文写 $d = 6$，图11图注写 $d = 8$；第16节正文及图12图注写“超过”，但缺失性公式使用 ≤ 50。这些差异均来自原文。