共享模式子模型用于含缺失值的预测

Sharing Pattern Submodels for Prediction with Missing Values

Lena Stempfle，Ashkan Panahi，Fredrik D. Johansson

查尔姆斯理工大学，计算机科学与工程系，瑞典哥德堡。

stempfle@chalmers.se；ashkan.panahi@chalmers.se；fredrik.johansson@chalmers.se。

原文出处： 第三十七届 AAAI 人工智能会议（AAAI-23），第 9882–9890 页。

非官方中文全文译文，仅供用户私人阅读。 依据用户上传的 9 页原始 PDF 制作，保留原作者及出版方的权利声明：Copyright © 2023, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved. 图、表及主要陈列公式保留原稿裁图和排印，并配中文说明。这里完整覆盖所提供的 9 页文件；正文多次引用的附录 A、B、C 及其中图表、完整证明不在这份文件内，未补写或冒充已译。文末译注与原文内容明确区分。

摘要

缺失值在机器学习的许多应用中不可避免，并在训练阶段和测试阶段都带来挑战。当变量按重复出现的模式缺失时，分别拟合模式子模型已被提出作为一种解决方案。然而，独立拟合各模型不能高效利用所有可用数据。反之，在完整数据集上拟合单一共享模型依赖于插补；当缺失情况取决于未观测因素时，这往往会导致有偏结果。我们提出另一种方法，称为共享模式子模型。该方法：（i）在测试时存在缺失值的情况下仍能稳健预测；（ii）保持或提高模式子模型的预测能力；（iii）具有简短的模型描述，从而改善可解释性。我们通过诱导稀疏性的正则化实现参数共享，并证明其能够得到一致估计。最后，我们给出共享模型达到最优的条件，即使缺失情况和目标结果都依赖于未观测变量，这些条件仍然适用。在合成数据与真实数据集上的分类、回归实验表明，我们的模型在模式特化与信息共享之间取得了良好的权衡。

1 引言

机器学习模型经常用于输入部分缺失的场景，缺失既可能发生在训练时，也可能发生在预测时（Rubin 1976）。如果处理不当，缺失值会增大偏差，或者使模型在部署时必须先插补未观测变量才能使用（Liu, Zachariah, and Stoica 2020；Le Morvan et al. 2020a）。如果缺失取决于与预测目标相关的未观测因素，那么“某个变量没有被测量”这一事实本身就可能具有预测性，这被称为信息性缺失（Rubin 1976；Marlin 2008）。很多时候，仅插补缺失值并不充分；让模型同时依据部分观测的数据以及指示哪些变量缺失的标记进行预测，可能更有益（Jones 1996；Groenwold et al. 2012）。正如 Le Morvan et al.（2020b）指出的，即便是最简单的回归模型——线性模型——在存在缺失值时也尚未得到充分研究，仍然呈现出出人意料的挑战。

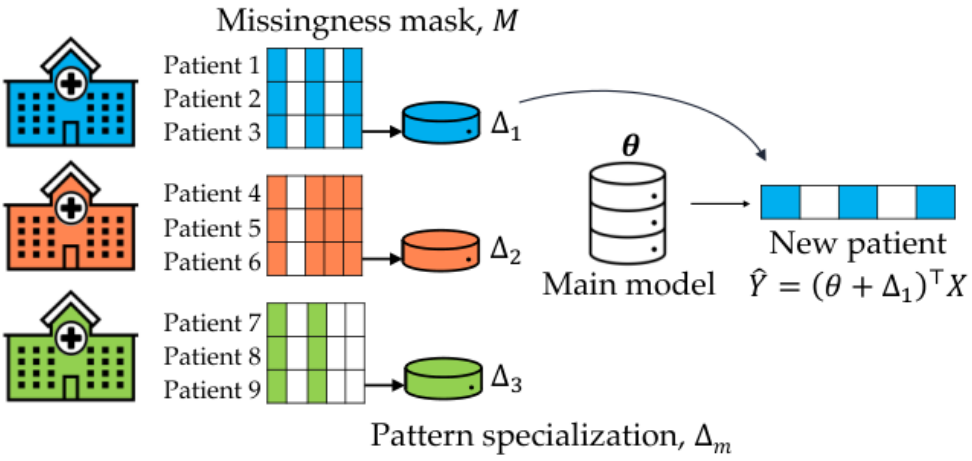


图 1： 主模型 θ 与三个诊所的模式子模型之间的系数共享。这些诊所具有不同的缺失值模式。如果没有特化项 Δ_m，在不同模式的诊所之间共享平均预测，可能对任何一个诊所都不是最优方案。反之，分别为各诊所拟合模型，不能高效利用所有可用数据，并会导致较高方差。

图内文字：Missingness mask＝缺失掩码；Patient 1–9＝患者 1–9；Main model＝主模型；Pattern specialization＝模式特化；New patient＝新患者。图示中的患者是示意编号。

当数据生成过程（DGP）中存在决定测量哪些变量的结构性原因时，就会出现模式缺失：样本按照反复出现的已测量与缺失变量模式分组（Little 1993）。图 1 展示了一个例子：来自三个不同诊所的患者，各诊所系统性地收集略有不同的测量值。为简单起见，假定每个诊所的缺失值模式各不相同。这样，模式特定模型同时也是站点特定模型。

模式子模型已被提出用于这种场景，即对每个模式下的样本分别拟合一个模型（Mercaldo and Blume 2020；Marshall et al. 2002）。这种方法不依赖插补，相比黑箱方法还可能改善可解释性（Rudin 2019），但它可能具有较高方差，尤其是不同模式的数量较多、每个模式的样本较少时。此外，如果拟合出的模型在不同模式之间差异显著，就可能难以比较其预测，或检查预测是否合理。值得注意的是，模式子模型忽略了各模式共享同一个预测任务这一事实。然而，在图 1 的场景中，如果不同诊所采用不同的测量方式，或者以不同方式治疗患者，所有诊所共用同一个模型也可能并非最优，并产生较高偏差。

我们提出共享模式子模型（SPSM）：不同缺失模式的子模型共享系数，同时允许有限的特化。这样可以促进子模型间的信息有效利用。在期望子模型相似、且每个模式样本量较小时，它能在预测能力和方差之间取得有利的权衡。此外，不同模式之间差异较少、差异幅度较小的模型，也更容易被领域专家解释。

第 3 节介绍 SPSM。第 4 节证明，在线性高斯系统中，模式之间共享系数的模型可能是最优的，即使预测目标依赖于缺失变量以及缺失模式本身。最后，我们在真实世界与合成数据上进行实验评估，将 SPSM 与基线分类器和回归方法进行比较，特别关注 SPSM 如何提高样本效率与模型稀疏性（第 5 节）。

2 测试时存在缺失值的预测

令 $X = [X_1, \ldots, X_d]^\top$ 为包含 d 个随机变量的向量，取值于 $\mathcal{X} \subseteq \mathbb{R}^d$；令 $M = [M_1, \ldots, M_d]^\top$ 为取值于 $\mathcal{M} \subseteq \{0, 1\}^d$ 的随机缺失掩码，其中 $M_j = 1$ 表示变量 X_j 缺失。进一步令 $\widetilde{X} \in (\mathbb{R} \cup \{\mathrm{NA}\})^d$ 表示按照 M 混合了已观测值与缺失值的 X，并定义

$$X_{\neg M} = \left[X_j : M_j = 0\right]^\top \in \mathbb{R}^{d - \|M\|_1}$$

为掩码 M 下的已观测协变量向量。我们关注的结果 $Y \in \mathbb{R}$ 可以依赖于 X 的所有分量，无论这些分量已观测还是缺失，也可以依赖于 M。令 $k = |\mathcal{M}|$ 为可能的缺失模式数。[1] 进一步假设变量 X, M, Y 服从某个固定、未知的联合分布 p。这里使用的变量之间所假定的（因果）依赖关系，与选择性缺失（Little 1993）最为接近，见附录中的图 4。

我们的目标是利用函数 $f : (\mathbb{R} \cup \{\mathrm{NA}\})^d \to \mathbb{R}$，在 X 具有缺失模式 M 的情况下预测 Y。我们希望最小化分布 p 上相对于平方损失的风险：

$$\min_f R(f), \text{ where } R(f) := \mathbb{E}_{\tilde{X}, Y \sim p}[(f(\tilde{X}) - Y)^2]\,. \quad (1)$$

假定 Y 具有中心化的加性噪声：

$$Y = g(X, M) + \epsilon \text{ where } \mathbb{E}[\epsilon] = 0, \quad (2)$$

则 Y 的贝叶斯最优预测器为 $f^* = \mathbb{E}\left[Y \mid X_{\neg M}, M\right]$。一般而言，已观测值 $X_{\neg M}$ 不足以预测 Y；即便 Y 不直接依赖于 M，f^* 也可能直接依赖掩码 M（Le Morvan et al. 2021）。

学习 f 的一种常见策略是先插补 $\widetilde{X}$ 中的缺失值，再利用观测或插补后的协变量 $X^I \in \mathbb{R}$ 拟合模型，这被称为先插补再回归估计。尽管插补很有用，但在测试时存在缺失值的情况下，它并不总是最优（Le Morvan et al. 2021），而且通常假设数据是随机缺失（MAR）的（Carpenter and Kenward 2012；Seaman et al. 2013）。

[1] 在实际场景中，我们预计 k 远小于最坏情况下的模式数量 2^d。

2.1 模式子模型

当不同缺失模式的数量 k 较少时，可以为每个模式分别学习预测器 f_m。这一思想称为模式子模型（PSM）（Mercaldo and Blume 2020；Marshall et al. 2002）：这是一组旨在最小化各缺失模式下经验风险的模型。设

$$D = \{\left(\widetilde{x}^{(1)}, m^{(1)}, y^{(1)}\right), \ldots, \left(\widetilde{x}^{(n)}, m^{(n)}, y^{(n)}\right)\}$$

为包含 n 个样本的数据集，部分观测的特征 $\widetilde{x}^{(i)}$ 对应于缺失模式 $m^{(i)}$，这些样本独立同分布地采自 p。可以在适当的模型类 $\mathcal{F}$ 和正则化函数 $\mathcal{R}$ 下，通过最小化正则化经验风险来学习 PSM：

$$\min_{\{f_m\}\in\mathcal{F}^k} \quad \frac{1}{n}\sum_{i=1}^{n} L\big(f_{m^{(i)}}(\tilde{x}^{(i)}), y^{(i)}\big) + \sum_{m\in\mathcal{M}} \mathcal{R}(f_m) \quad (3)$$

Mercaldo and Blume（2020）考虑了线性回归和逻辑回归模型 $f_m = \sigma\left(\theta_m^{\mathsf{T}} x\right)$，其中 σ 为恒等函数或逻辑函数，损失 L 则相应选取。目标函数（3）对于 m 是可分离的，因此可以对每个模式独立求解。然而，在小样本情形下，这往往会导致较高方差，因为每个模式仅对应所有可用样本中的一部分。如果没有结构性假设，模式数 k 会随 d 呈指数增长，相关讨论见第 6 节。

PSM 能够在测试时存在缺失值的情况下进行预测，并根据模式 m 自适应，而不依赖于插补或 MAR 等缺失机制假设。然而，预测目标以及贝叶斯最优模型 f^* 对模式 m 的依赖可能很小；所有 m 的最优子模型可能共享大量结构。接下来，我们提出利用这些结构来降低方差、提高可解释性的估计器。

3 共享模式子模型

我们提出共享模式子模型（SPSM）：针对变量缺失模式进行特化、并在学习过程中共享信息的线性预测模型。通过将各子模型向一个主模型正则化，并求解由此形成的耦合优化问题，可以实现共享。尽管线性模型的表达能力有限，但由于它们具有更好的可解释性，往往仍被发现是对非线性函数的有用近似。

拟合 SPSM。令 $\theta \in \mathbb{R}^d$ 表示在所有缺失模式下用于预测的主模型系数，并定义 $\theta_{\neg m} = \left[\theta_j : m_j = 0\right]^{\mathsf{T}} \in \mathbb{R}^{d_m}$ 为模式 m 下已观测变量所对应的系数子集。需要强调的是，$\theta_{\neg m}$ 对 m 的依赖仅在于从 θ 中选择子集；这些系数在不同模式之间共享。类似地，定义 $\Delta_{\neg m} \in \mathbb{R}^{d_m}$ 为这些系数针对模式 m 的特化。与 $\theta_{\neg m}$ 不同，$\Delta_{\neg m}$ 的取值对每个模式 m 都是独有的。注意，模型 f_m 仅依赖于 X 的已观测分量。在回归任务中，我们学习如下形式的共享模式子模型：

$$f_m(x) := (\theta_{\neg m} + \Delta_{\neg m})^{\top} x_{\neg m}, \quad \text{for all} \;\; m \in \mathcal{M} \qquad (4)$$

其中，模型通过求解下述问题得到，且 $\lambda_m \geq 0$、$\gamma \geq 0$：

$$\begin{aligned}\underset{\theta,\{\Delta_{\neg m}\}}{\text{minimize}} \quad & \frac{1}{n}\sum_{i=1}^{n}\left((\theta_{\neg m^{(i)}} + \Delta_{\neg m^{(i)}})^{\top} x^{(i)}_{\neg m^{(i)}} - y^{(i)}\right)^2 \\ & + \frac{\gamma}{n}\|\theta\| + \sum_{m\in\mathcal{M}} \frac{\lambda_m}{n_m}\|\Delta_{\neg m}\|_1 \,. \qquad (5)\end{aligned}$$

n_m 是模式 m 的样本数，$\lambda_m > 0$ 和 $\gamma > 0$ 是正则化参数。为简洁起见，式中省略了模式特定和共享的截距。该优化问题是凸的，实验中我们采用 L-BFGS-B（Byrd et al. 1995）寻找 θ 和 Δ_m 的最优值。在分类任务中，将平方损失替换为逻辑损失。无论是哪种情形，我们都将（5）的解称为 SPSM。

对于惩罚项 $\|\theta\|$，我们使用 ℓ_1 或 ℓ_2 范数，以权衡主模型的偏差与方差。较大的 λ_m 会对模型系数针对缺失模式 m 的特化施加更强的正则化，因此更大的 λ_m 倾向于得到更小的 $\|\Delta_m\|_1$ 和更多的系数共享。在实验中，我们令所有模式的 λ_m 都取同一个值 λ。对 Δ 使用 ℓ_1 正则化，是因为我们希望得到稀疏解，使大多数特化系数为零。

一致性。 对固定的 λ, γ，当样本量趋于无穷大时，（5）的极小化解之和 $\theta^*_{\neg m} + \Delta^*_{\neg m}$ 收敛到各模式 m 的贝叶斯最优预测器 f^*_m 的最佳线性近似。我们在附录 A.2 中正式陈述这一结论，并利用标准论证给出证明概要。该结论与是否共享参数无关，Δ^* 不一定稀疏。第 4 节进一步证明，在线性高斯场景中，我们的方法还会恢复真实过程的稀疏性。在大样本极限下，这或许不会有助于降低方差，但稀疏性会提高可解释性。

为什么 SPSM 具有可解释性？ 比较模式特化项，能够帮助领域专家判断子模型有多相似，以及它们如何受缺失值影响。我们认为，如果特化项包含更少的非零系数，即 $\Delta_{\neg m}$ 是稀疏的，那么这组子模型就更容易解释。稀疏性通常是可解释性的有用度量（Rudin 2019），因为它意味着只有部分输入特征会影响预测，从而降低模型的有效复杂度（Miller 1956；Cowan 2010）。

4 共享模型的最优性

本节给出最优模式子模型具有稀疏特化项，即在模式之间共享参数的条件，以及 SPSM 在大样本极限下收敛到这类模型的条件。我们分析如下数据生成过程：结果 Y 线性地依赖于 X 的所有分量（模型只能访问其中已观测的子集），以及模式 M，但不依赖于 X 与 M 的交互：

$$Y = \theta^\top X + \alpha_M + \epsilon\,, \text{ with } \epsilon \sim \mathcal{N}(0, \sigma_Y^2). \qquad (6)$$

其中，α_M 是模式特定的截距。如果没有 α_M，这就是插补方法经常针对的场景，因为结果是完整 X 的参数化函数。然而，我们知道测试时 X 也会部分缺失，并且允许 M 任意依赖于 X。在这种情况下，插补既未必是必要的，也未必是充分的。

下面研究 X 为高斯变量时的这一场景。在此情形中，我们可以精确刻画最优模型及其稀疏性。

4.1 线性高斯数据生成过程中的稀疏性

回顾一下，$X_{\neg m}$ 与 $\theta_{\neg m}$ 分别表示模式 m 下仅保留已观测变量的协变量与系数；相应地，定义 X_m 与 θ_m 表示缺失变量部分。对于满足（6）的结果，模式 m 下的贝叶斯最优模型为：

$$\mathbb{E}[Y \mid X_{\neg m}, M = m] = {\theta_{\neg m}}^\top X_{\neg m} + \xi_m \qquad (7)$$

其中，$\xi_m = \theta_m^\top \mathbb{E}_{X_m}[X_m \mid X_{\neg m}] + \alpha_m$，表示直接使用真实系统中 $\theta_{\neg m}$ 对应的系数、但仅保留已观测变量进行朴素预测时的偏差。忽略 ξ_m 等同于先进行零值插补再预测，这一般是有偏的。因此，ξ_m 刻画了模式子模型达到无偏所需要的特化项。为进一步分析，我们研究下列场景。

条件 1（线性高斯数据生成过程）。 协变量 $X = [X_1, \ldots, X_d]^\top$ 为高斯变量， $X \sim \mathcal{N}(\mu, \Sigma)$，均值为 μ，协方差矩阵为 Σ。结果 Y 与（6）一样为线性高斯，参数为 $(\theta, \{\alpha_m\}, \sigma_Y)$。 M 可以是任意的。

与条件 1 一致，令 $\Sigma_{\neg m,m}$ 表示 Σ 的一个子矩阵：行仅保留模式 m 下已观测变量对应的部分，列仅保留模式 m 下缺失变量对应的部分。类似地定义 $\Sigma_{\neg m,\neg m}$ 和 $\Sigma_{m,\neg m}$。全文假设 Σ 可逆，从而分布非退化。在实践中可以通过岭正则化处理非退化情形。

命题 1。 假设协变量 X 与结果 Y 满足条件 1，即为线性高斯。则任意缺失掩码 $m \in \mathcal{M}$ 下的贝叶斯最优预测器为：

$$f_m^* = \mathbb{E}[Y \mid X_{\neg m}, m] = (\theta_{\neg m} + \Delta_{\neg m})^\top X_{\neg m} + C_m$$

其中， $C_m \in \mathbb{R}$ 相对于 $X_{\neg m}$ 是常数，并且

$$\Delta_{\neg m} = (\Sigma^{-1}_{\neg m,\neg m})\Sigma_{\neg m,m}\theta_m \ .$$

命题 1 表明，对于线性高斯系统，缺失模式 m 下的贝叶斯最优模型与带有模式特定截距的 SPSM 具有相同形式，结合了主模型系数 θ 与特化项 $\Delta_{\neg m}$。这一结论在附录 A.3 中证明。

在非线性数据生成过程中，最优修正项 $\Delta_{\neg m}$ 可能不是相对于 $X_{\neg m}$ 的常数。Le Morvan et al.（2020a）的 NeuMiss 模型利用深度神经网络，将这些修正项学习为输入和缺失掩码的函数。然而，该方法不具备这里所追求的稀疏线性模型的可解释性。即便在这种更一般的情形下，SPSM 仍可能取得较好的偏差—方差权衡。事实上，我们在未必为线性的真实数据上发现，SPSM 往往优于强非线性基线。

什么时候稀疏性是最优的? 与 LASSO（Tibshirani 1996）等其他诱导稀疏的正则化估计器一样，SPSM 通过将某些模型参数收缩为零来降低方差。在适当条件下，当训练集不断增大时，我们期望所学到的稀疏性对应于数据生成过程自身的性质。对于 LASSO，这意味着恢复结果系数向量中的零值。对于 SPSM，目标函数（5）用于学习形如 $(\theta_{\neg m} + \Delta_{\neg m})^\top X_{\neg m}$ 的子模型，其中 θ 在模式之间共享，而 $\Delta_{\neg m}$ 稀疏。自然的问题是：什么时候可以期望“真实”或“最优”的 $\Delta_{\neg m}$ 是稀疏的? 如果确实稀疏，又什么时候能用 SPSM 恢复这种稀疏性? 正如下面将看到的，即使 Y 依赖于 X 中所有协变量，最优特化项 $\Delta_{\neg m}$ 仍然可能是稀疏的。

假设条件 1，即线性高斯数据生成过程成立，系统参数为 $(\mu, \Sigma, \theta, \{\alpha_m\}, \sigma_Y)$。我们可以利用协变量的交互性，刻画贝叶斯最优模型 $(\theta, \{\Delta_{\neg m}\})$ 中的稀疏性，见命题 1。如果给定其余所有协变量后，变量 X_j 与 $X_{j'}$ 统计独立，就称它们无交互。众所周知，对于高斯 X，如果精度矩阵 $S = \Sigma^{-1}$ 满足 $S_{j,j'} = 0$，则 X_j 与 $X_{j'}$ 无交互。

命题 2（最优模型中的稀疏性）。 假设协变量 $j \in [d]$ 在模式 m 下已观测，即 $m_j = 0$，并假设 X_j 与模式 m 下每个缺失的协变量 $X_{j'}$ 都无交互。那么 $(\Delta_{\neg m})_j = 0$。

命题 2 表明，Δ 中的稀疏性部分由已观测和未观测协变量的协方差模式决定。例如，如果变量 j 与模式 m 下的所有缺失变量都不相关，则无需对该变量进行特化。反之，对于具有预测性（$\theta_j \neq 0$）且具有冗余性（可由同样具有预测性的未观测特征很好地复现）的特征 j，就需要特化，即 $(\Delta_{\neg m})_j \neq 0$。这是因为在主模型中，冗余变量可以共同承担预测任务；当它们被缺失情况分隔开时，就必须各自独立承担。这说明，一般而言，单一模型结合零值插补的预测方式并非最优。

SPSM 的一致性。 在条件 1 下的大样本极限中，可以证明 SPSM 能够恢复最优模型参数中最大程度的稀疏性。如果真实系统参数本身也是稀疏的，SPSM 也能学到这些参数。

定理 1。 假定条件 1 对命题 1 中的参数 $(\theta, \{\Delta_{\neg m}\})$ 成立，并且对每个协变量 j，满足 $m_j = 0$ 且 $(\Delta_{\neg m})_j = 0$ 的模式 m 的数量，严格大于满足 $m'_j = 0$ 且 $(\Delta_{\neg m'})_j \neq 0$ 的模式 m' 的数量。那么，当 $\gamma = 0$ 且固定 $\lambda > 0$ 时，真实参数 $(\theta, \{\Delta_{\neg m}\})$ 是（5）在大样本极限 $n \to \infty$ 下的唯一解。

证明概要。 完整证明见附录 A.5。主要步骤包括证明：SPSM 的目标函数（5）在渐近意义下由风险项主导，而其极小化解之和 $(\theta^*_{\neg m} + \Delta^*_{\neg m})$，与对每个缺失模式 m 独立拟合得到的最优回归系数 $(\widehat{\theta}_{\neg m})$ 一致。对任意 $\lambda > 0$，正则化都会使解趋向于在 $\Delta^*_{\neg m}$ 中具有最大程度稀疏性的解。

4.2 与其他方法的关系

当正则化参数 γ, λ_m 取某些极端值时，SPSM 与其他方法一致，见表 1。

	$\gamma < \infty$	$\gamma \to \infty$
$\lambda_m \to \infty$	Zero imputation	Constant
$0 < \lambda_m < \infty$	Sharing model	Pattern submodel
$\lambda_m = 0$	No sharing	Pattern submodel

表 1： 在不使用模式特定截距的前提下，SPSM 的极端情形及其等价方法。表中 Zero imputation＝零值插补；Constant＝常数模型；Sharing model＝共享模型；Pattern submodel＝模式子模型；No sharing＝不共享。

首先，完全共享模型（$\lambda_m \to \infty, \gamma < \infty$）等同于在零值插补之后，用全部样本拟合单个模型。令所有 m 的 $\Delta_{\neg m} = 0$，并注意到

$$\theta_{\neg m^{(i)}}{}^{\top} x^{(i)}_{\neg m^{(i)}} = \theta^{\top} I_0(\tilde{x}^{(i)})$$

即可看出这一点。其中，$I_0(\tilde{x})$ 将 $\tilde{x}$ 中的缺失值替换为 0。在这种设置下，子模型的系数不能随 m 自适应。我们的实现允许拟合模式特定截距，这些截距不受 λ_m 正则化。其次，$(\lambda_m < \infty, \gamma \to \infty)$ 对应于不共享参数的标准 PSM（Mercaldo and Blume 2020），或 Le Morvan et al.（2020b）的

ExpandedLR 方法。这种等价关系的确切性质取决于所选择的正则化。[2] 在这种设置下，每个子模型 $\widehat{f_m}$ 都与其余模型完全独立地拟合。最后，在线性高斯情形中，具有最优参数 $(\theta, \{\Delta_{\neg m}\})$ 的 SPSM 隐式地进行了一次完美的线性插补：

$$\mathbb{E}[X_m \mid X_{\neg m}] = X_{\neg m}\Sigma^{-1}_{\neg m,\neg m}\Sigma_{\neg m,m},$$

并将主模型的参数 θ_m 应用于插补值。如果有大量样本，直接学习插补可能可行。然而，如果 $X_{\neg m}$ 与 X_m 中的变量从未被共同观测，插补就不再可行。相比之下，只要每个模式的样本足够多，SPSM 仍能够为每个模式学习最优子模型。

[2] Mercaldo and Blume（2020）采用了两阶段估计过程，即 relaxed LASSO（Meinshausen 2007）。

5 实验

我们在模拟数据和真实数据上评估所提出的 SPSM 模型[3]，旨在回答两个主要问题：在较小和较大的样本量下，SPSM 的准确性与包括先插补再回归在内的基线模型相比如何？模式特化项 Δ 中的稀疏性又如何影响模型性能与解释？

实验设置。 SPSM 算法在对类别特征进行独热编码之前，先识别训练集中的所有缺失模式。对于测试时未在训练阶段出现过的模式，删除变量，直到恢复出最接近的训练模式。SPSM 的线性和逻辑回归变体均使用 SciPy Python 软件包中的 L-BFGS-B 求解器训练（Virtanen et al. 2020）。我们的实现支持对主模型参数 θ 使用 ℓ_1 或 ℓ_2 正则化，对模式特定偏移 Δ 使用 ℓ_1 正则化。这包含不共享的模式子模型（$\lambda_m < \infty, \gamma \to \infty$），以及完全共享模型（$\lambda_m \to \infty, \gamma < \infty$）这两种特殊情形。实验中，$\gamma$ 的候选值为 $[0,\ 0.1,\ 1,\ 5,\ 10,\ 100]$，所有模式共用的 $\lambda_m = \lambda$ 的候选值为 $[1,\ 5,\ 10,\ 100,\ 1000,\ 1e8]$。主模型和每个模式都加入不受正则化的截距。我们不要求模式达到某个最小样本量，但实现支持这一功能，见附录表 8。对于测试数据中未在训练集出现过的缺失模式，删除变量，直到恢复出最接近的训练模式。

我们将线性和逻辑回归模型与下列基线方法比较：插补加岭回归或逻辑回归（Ridge/LR）；插补加具有单个隐藏层的多层感知机（MLP）；以及默认支持缺失值的 XGBoost（XGB）（Chen et al. 2019）。最后，还比较模式子模型（PSM）（Mercaldo and Blume 2020）。需要注意，我们的 PSM 实现基于 SPSM 实现的一种特殊情形：正则化在所有模式上共同施加，而非在每个模式内分别施加。超参数依据验证集选择。插补方法包括零值插补（I_0）、均值插补（I_μ），以及 SciKit-Learn 的迭代插补（I_{it}）（Pedregosa et al. 2011；Van Buuren 2018）。XGB 对缺失值的处理记为 I_n。方法实现、超参数和评价指标的细节见附录 B.2。

[3] 复现实验的代码及附录可从 https://github.com/Healthy-AI/spsm 获取。

5.1 模拟数据

我们使用模拟数据来展示共享模式子模型与基线在命题 1 所讨论情形中的行为，重点关注偏差与方差。从多元高斯分布 $\mathcal{N}(0, \Sigma)$ 中采样 d 个输入特征 X，其中协方差矩阵 Σ 由一个簇结构确定：将特征划分为 k 个大小相等的簇。定义 $\Sigma_{ii} = 1$；如果 i, j 属于不同簇，则 $\Sigma_{i \neq j} = 0$；如果二者属于同一簇，则 $\Sigma_{i \neq j} = c$。在保证 Σ 保持半正定的前提下，选择尽可能大的 c。

每个簇 $c \in \{1, \ldots, k\}$ 在结果函数 $Y = \theta^{\top} X + \epsilon$ 中由一个特征 $i(c)$ 代表，其中 $\beta_{i(c)} \sim \mathcal{N}(0, 1)$，其余特征的 $\theta_j = 0$。对每个样本独立生成 $\epsilon \sim \mathcal{N}(0, 1)$。我们考虑三种缺失设置。设置 A 中，如果 $X_{i(c)} > -0.5$，则簇 c 中的每个变量都缺失。设置 B 中，如果 $X_{i(c)} > -0.5$，则除均匀随机选中的一个变量外，簇 c 中的每个变量都缺失。这两种设置都满足命题 1 的条件，但通过让结果变量直接依赖于可能无法由已观测变量恢复的缺失值，被设计为违反 MAR。设置 C 遵循完全随机缺失（MCAR）：各变量独立地以 0.2 的概率缺失。我们生成的数据取 $d = 20$、$k = 5$。

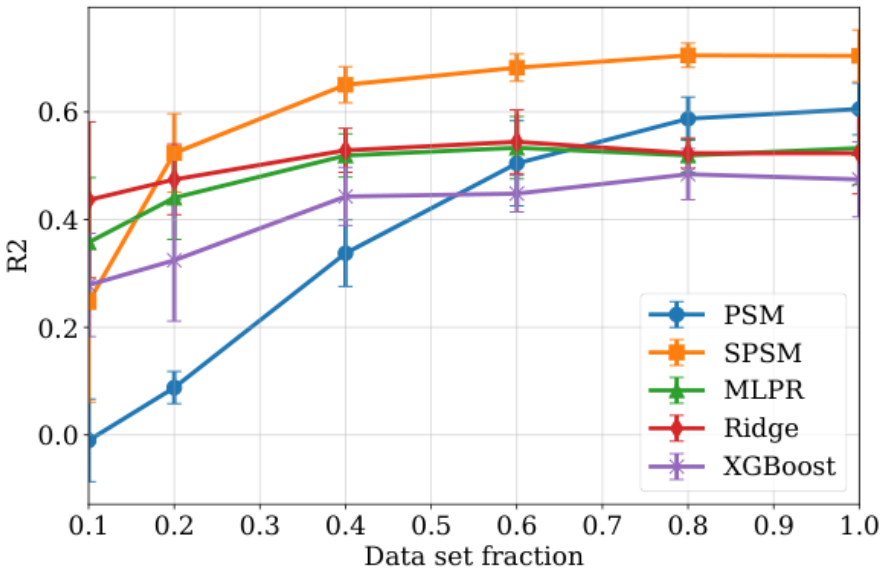


图 2： 模拟数据设置 A 上的性能，越高越好。误差条表示 5 次随机数据划分的标准差。完整数据集包含 $n = 2000$ 个样本。横轴 Data set fraction＝数据集比例；纵轴为决定系数 R^2。

图 2 展示了设置 A 中测试集上的决定系数 R^2。注意，使用插补的方法在初期表现较好，但很快进入平台期，这说明其偏差相对较高；每种数据集规模所使用的插补方法均根据验证误差选择。SPSM 和 PSM 在使用全部样本时都能获得更高的 R^2。小样本时 SPSM 优于 PSM，说明其方差更低。当训练集规模比例为 0.2 时，SPSM 模型包含 42 个非零模式特定系数；比例为 0.8 时包含 68 个。设置 B 和 C 的结果见附录 C.1。即便在 MCAR 设置 C 中，PSM 仍明显差于其他方法，其原因是独立拟合模式特定模型导致了过大的方差。

5.2 真实世界任务

下面介绍用于分类和回归的两个医疗数据集。非医疗领域 HOUSING 数据集（De Cock 2011）的更多信息见附录 C.3。

ADNI。 数据取自公开可用的阿尔茨海默病神经影像倡议（ADNI）数据库。[4] ADNI 收集临床数据、神经影像与遗传数据（Weiner et al. 2010）。分类任务是预测患者的诊断是否会在基线诊断 2 年后发生变化。回归任务是根据基线时可用的数据，预测 2 年随访时 ADAS13（阿尔茨海默病评估量表）认知测试的结果（Mofrad et al. 2021）。

SUPPORT。 我们使用“了解治疗预后、偏好、结局与风险的研究”（SUPPORT）数据（Knaus et al. 1995）。该研究旨在使用生理学评分（SPS），对重症住院成年人在 180 天内的生存情况建模。按照 Mercaldo and Blume（2020）的做法，回归任务预测 SPS；分类任务预测患者的 SPS 是否高于中位数，因此按定义两类标签比例为 50/50。我们通过给缺失“动脉血氧分压”这一协变量的受试者的 SPS 值增加 25 个单位，模拟他们的 MNAR 设置。

[4] http://adni.loni.usc.edu

5.3 结果

Regression	R^2	**# Coefficients**
ADNI		
Ridge, I_μ	0.66 (0.59, 0.73)	37 + 0
XGB, I_μ	0.41 (0.31, 0.50)	—
MLP, I_0	0.62 (0.55, 0.69)	—
PSM	0.51 (0.43, 0.60)	0 + 430
SPSM	0.66 (0.59, 0.73)	37 + 21
SUPPORT		
Ridge, I_0	0.38 (0.35, 0.42)	11 + 0
XGB, I_n	0.30 (0.27, 0.34)	—
MLP, I_μ	0.56 (0.53, 0.59)	—
PSM	0.52 (0.49, 0.56)	0 + 188
SPSM	0.53 (0.50, 0.56)	11 + 91

表 2（上，回归部分）： ADNI 与 SUPPORT 任务的结果及各自所用的插补方法，插补方法定义见实验设置。还报告共享模型中的非零系数数量 k 与模式特定模型中的非零系数数量 l，写为 $k + l$。表头 Regression＝回归；Classification＝分类；# Coefficients＝系数数量；Accuracy＝准确率；AUC＝ROC 曲线下面积。

Classification	AUC	Accuracy
ADNI		
LR, I_0	0.85 (0.80, 0.90)	0.85 (0.74, 0.94)
XGB, I_n	0.80 (0.74, 0.86)	0.84 (0.73, 0.94)
MLP, I_0	0.86 (0.78, 0.89)	0.84 (0.73, 0.94)
PSM	0.81 (0.75, 0.87)	0.84 (0.74, 0.95)
SPSM	0.86 (0.81, 0.90)	0.85 (0.75, 0.96)
SUPPORT		
LR, I_0	0.83 (0.81, 0.85)	0.77 (0.74, 0.79)
XGB, I_0	0.85 (0.83, 0.87)	0.78 (0.75, 0.81)
MLP, I_0	0.86 (0.85, 0.88)	0.79 (0.76, 0.81)
PSM	0.84 (0.83, 0.86)	0.78 (0.75, 0.81)
SPSM	0.85 (0.83, 0.86)	0.78 (0.75, 0.80)

表 2（续）： 分类结果。

表 2 报告了医疗数据上的结果。对于回归任务，还给出了线性模型使用的非零系数数量。此外，图 3 和附录图 7 考察了预测性能随数据集规模的变化。平均误差的统计不确定性通过其平方根来度量，该量是一个标准差，并以测试集上的 95% 置信区间表示。HOUSING 数据的结果见附录 C.3。

对于 ADNI 回归任务，SPSM 和 Ridge 表现最好，R^2 为 0.66，且对预测具有相同的置信程度。根据验证性能，SPSM 选择了 $\gamma = 10.0, \lambda = 50$。PSM 的 R^2 为 0.51，似乎无法在 ADNI 上从模式特定性中获益。相比之下，SPSM 利用系数共享，使得系数数量显著少于 PSM。对于 SUPPORT 回归任务，PSM 与 SPSM 的结果几乎相同，R^2 为 0.52–0.53，预测的置信区间部分重叠。不过，由于子模型之间共享系数，SPSM 使用的系数数量少于 PSM。SPSM 的最佳正则化参数是 $\gamma = 0.1, \lambda = 5.0$，低于 ADNI 的相应值，这与更大的数据集规模一致。SUPPORT 回归任务上表现最好的模型是 MLP，R^2 为 0.56。然而，MLP 的黑箱性质不利于分析缺失模式的影响。对 Ridge、XGB 和 MLP，均值与零值插补获得了最好的验证性能。

总之，SPSM 在两个数据集上都稳定地位于表现最好的模型之列，并具有相当紧的置信区间。在 ADNI 分类任务中，SPSM、MLP 和 LR 获得了最高的预测准确率（0.84–0.85）与 ROC 曲线下面积（AUC，0.85–0.86）。各方法在 ADNI 上的表现相近。SPSM 选择了 $\gamma = 0, \lambda = 1.0$，这表明采用了适度的系数共享。对于 SUPPORT 数据，所有模型几乎处于同一性能水平。XGB 和 MLP 略优于 SPSM（$\gamma = 0.1, \lambda = 10.0$）以及 PSM。在 ADNI 与 SUPPORT 上，LR、XGB 和 MLP 主要使用零值插补。在全部任务中，SPSM 与其他方法相比表现相当或更好。两个数据集分类结果较紧的置信区间，表明结果均值具有较高确定性。

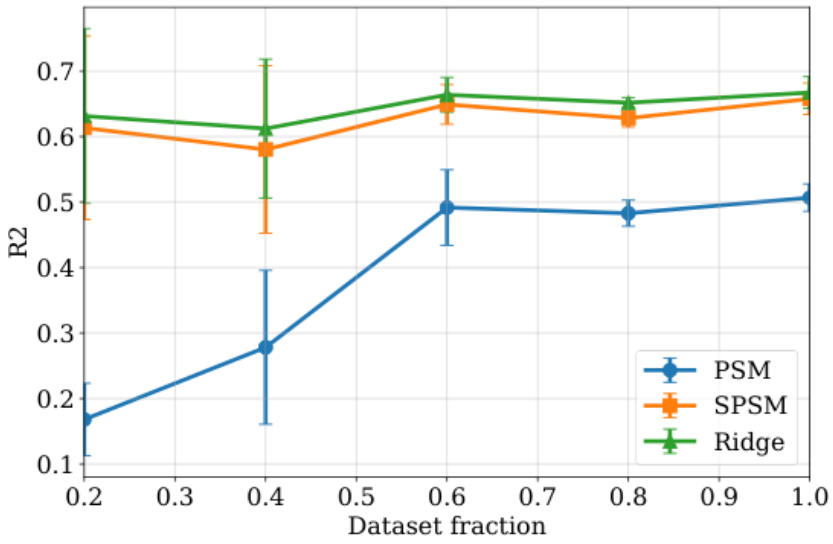


图 3： ADNI 回归任务上的性能。误差条表示对数据进行 5 次随机子采样得到的标准差。SPSM 与 Ridge 性能相同，而 PSM 表现较差，这表明模式特化对 ADNI 回归任务基本无关紧要。横轴 Dataset fraction＝数据集比例；纵轴为 R^2。

非医疗数据与系数特化。 与前面那些可从共享系数中获益的数据集不同，在 HOUSING 数据上可以看到非线性估计的明显优势，具体表现为基于树的 XGB 方法，见表 9。它的 R^2 为 0.76，在回归任务中优于其他基线，证实了该数据集的非线性。我们也没有看到同样的特化收益：PSM、SPSM 并不优于带插补的 Ridge。所有缺失值指示变量在 XGB 中都没有表现出显著的特征重要性，这可能说明没有必要进行模式特化。HOUSING 数据的结果见附录 C.3。

不同训练集规模下的性能。 图 3 展示了线性模型在不同 ADNI 数据比例上训练时的测试 R^2。各数据集分别子采样为完整数据集的 0.2、0.4、0.6、0.8、1.0。尤其在数据比例较小时，SPSM 相比 PSM 受益于系数共享和更低方差的数据。采用均值插补的 Ridge 表现相当。SUPPORT 的对应图见附录图 7。SPSM 与 PSM 在不同数据比例下的表现同样良好，而 Ridge 相比这两种模式子模型的误差较高。

SPSM 中的模式特化。 我们考察 ADNI 回归任务中 SPSM 的模式特化项 Δ 的可解释性。表 3 给出主模型 θ 与模式 4 的模式特定系数 Δ_4。附录表 7 给出了所有满足 $\Delta_{\neg m} \neq 0$ 的模式 m。模式 4 的基线诊断中，淀粉样蛋白 β（ABETA）以及 TAU、PTAU 蛋白的测量值缺失。

Missing features in pattern 4:
ABETA, TAU and PTAU at baseline (bl)

Feature	Δ_4	θ	$\theta + \Delta_4$
Age	-0.140	0.121	-0.019
FDG-PET	-0.090	-0.039	-0.129
Whole Brain (bl)	0.000	-0.045	-0.044
Fusiform	0.016	0.021	0.037
ICV	0.001	0.093	0.094
Intercept	-0.10	0.18	

表 3： 使用 ADNI 数据进行 SPSM 回归时的 Δ_4 示例。针对一个随机种子，SPSM 使用 $\gamma = 10$ 和 $\lambda = 13$。共有 10 种缺失模式，其中 4 种具有非零的 Δ 系数和模式特定截距。系数对应于标准化后的变量。表中模式 4 的缺失特征为基线时的 ABETA、TAU、PTAU；Age＝年龄；Whole Brain (bl)＝基线全脑；Fusiform＝梭状回；ICV＝颅内容积；Intercept＝截距。

这三个特征的缺失会影响模式特化：对于影像检查 FDG-PET（氟脱氧葡萄糖），其系数的绝对值增大，使它在预测中具有更高权重。类似地，当 ABETA、TAU 和 PTAU 缺失时，Fusiform（脑体积）与 ICV（颅内容积）的系数绝对值及预测重要性都会提高。相比之下，AGE 特征的最终系数为 −0.019，而主模型中为 0.121，说明该特征在模式 4 下对预测的影响减弱。

如表 3 所示，将 SPSM 用于表格数据，可以用简短的描述表达模式特化，从而帮助构建简单而有意义的模型。我们对 Δ 强制施加稀疏性，以限制子模型之间差异的数量，并列出全部满足 $\Delta_{\neg m}(j) \neq 0$、即具有特化系数的特征 j；在示例中有五个。这样，这组子模型更容易被解释，也能够为用户，例如医务人员，提供决策支持。关于 SPSM 可解释性性质的更详细分析，见附录 C.4。

可解释性与准确性之间的权衡。 可解释性—准确性权衡对 SPSM 的实际应用尤其关键。经验结果未提供显著证据表明，所提出的稀疏正则化会损害预测准确性，见表 2、图 3。不过，在实际场景中，领域专家可能愿意以少量性能损失换取更简单的模型。此时，可以通过改变超参数来衡量这种权衡，以找到合适的平衡，见图 8。参数选择基于验证集，并与测试集结果相符。我们在 SUPPORT 上观察到一定的参数敏感性，它支持共享，但仅支持适度共享。

6 相关工作

模式混合缺失指的是可以由独立的缺失机制分量，以及依赖于该模式的协变量模型来良好描述的分布（Rubin 1976；Little 1993）。本文中的模式缺失指自然形成的缺失模式，它既可能依赖于已观测协变量，也可能不依赖（Marshall et al. 2002）。Mercaldo and Blume（2020）、Le Morvan et al.（2020b）以及 Bertsimas, Delarue, and Pauphilet（2021）定义了模式子模型，以灵活处理测试时缺失。Le Morvan et al.（2020b）的 ExpandedLR 与模式子模型有关。然而，他们既没有研究模型之间的系数共享，也没有从理论上分析何时最优子模型具有部分相同的系数，即共享以及特化项中的稀疏性。Marshall et al.（2002）介绍了一步扫掠方法，它使用测试时由完整观测和不完整数据获得的估计系数与增广协方差矩阵。

在一项很新、在原文写作时尚未发表的工作中，Bertsimas, Delarue, and Pauphilet（2021）提出了两种处理测试时缺失的预测方法。第一种为仿射自适应回归：通过一个关于缺失模式的线性函数给出系数修正，从而对共享模型进行特化。当变量数 d 小于模式数（后者可能以 2^d 增长），且结果对缺失掩码变化并不平滑时，这可能会引入显著偏差。由此形成的偏差—方差权衡不同于我们的方法，而且与本文不同，该方法未通过理论分析加以论证。第二种为有限自适应回归：开始时将各模式放入同一个模型，再递归地将它们划分为子集。

已有若干深度学习方法可以处理测试时缺失，它们可以显式尝试插补缺失值，也可以不进行显式插补（Bengio and Gingras 1995；Che et al. 2018；Le Morvan et al. 2020a,b；Nazabal et al. 2020）。第 4.1 节简要讨论过的 NeuMiss 网络提出了一种新的非线性形式：与缺失指示变量相乘（Le Morvan et al. 2020a）。NeuMiss 将协变量和缺失掩码同时作为输入，用深度神经网络近似特化项 $\Delta_{\neg m}^{\mathsf{T}} X_{\neg m}$，以及各模式的偏置，并在模式之间共享参数。NeuMiss 与上面介绍的仿射自适应回归相似，因为它们的模式特化项都是输入和掩码的函数；二者在这一点上均不同于 SPSM。此外，两种方法都没有尝试学习稀疏特化项，例如都未对 Δ 施加 ℓ_1 正则化。

7 结论

我们提出了共享模式子模型（SPSM），用于测试时存在缺失值的预测。通过正则化使模式系数特化项稀疏，从而实现参数共享，并分析了 SPSM 的一致性性质。我们刻画了一些场景：即使预测目标依赖于缺失值以及缺失模式本身，信息共享仍然是最优的。

在合成与真实数据上的实验结果表明，SPSM 不依赖插补，在所有数据集上都能够达到与基线相当或略好的性能。值得注意的是，所提出的方法从不劣于不共享的模式子模型，因为后者没有高效利用可用数据。虽然 SPSM 只能学习线性模型，但它并不局限于从线性系统中学习。一个有趣的研究方向是，识别其他为可解释性而设计、也能够从这种共享中获益的模型类别。

致谢

感谢 Devdatt Dubhashi 和 Marine Le Morvan 的支持以及富有成果的讨论。

本研究部分得到 WASP（瓦伦堡人工智能、自主系统与软件项目）的支持，该项目由 Knut and Alice Wallenberg 基金会资助。

计算工作使用了瑞典国家计算基础设施（SNIC）在查尔姆斯计算科学与工程中心（C3SE）提供的资源，这些资源部分由瑞典研究理事会通过资助协议 2018-05973 资助。

本文准备过程中使用的数据取自阿尔茨海默病神经影像倡议（ADNI）数据库（adni.loni.usc.edu）。因此，ADNI 研究人员对 ADNI 的设计与实施作出了贡献，和／或提供了数据，但未参与本报告的分析或撰写。ADNI 研究人员完整名单见：http://adni.loni.usc.edu/wp-content/uploads/how_to_apply/ADNI_Acknowledgement_List.pdf 。

参考文献

以下保留原稿完整书目信息，并为题名附中文译文。为便于逐项核对而增加序号；正文仍沿用原稿的作者—年份引用方式。

1. Bengio, Y.; and Gingras, F. 1995. Recurrent neural networks for missing or asynchronous data. ［用于缺失或异步数据的循环神经网络。］Advances in neural information processing systems, 8.

2. Bertsimas, D.; Delarue, A.; and Pauphilet, J. 2021. Prediction with Missing Data. ［缺失数据下的预测。］ArXiv, abs/2104.03158.

3. Byrd, R. H.; Lu, P.; Nocedal, J.; and Zhu, C. 1995. A limited memory algorithm for bound constrained optimization. ［用于边界约束优化的有限内存算法。］SIAM Journal on scientific computing, 16(5): 1190–1208.

4. Carpenter, J.; and Kenward, M. 2012. Multiple imputation and its application. ［多重插补及其应用。］John Wiley & Sons.

5. Che, Z.; Purushotham, S.; Cho, K.; Sontag, D.; and Liu, Y. 2018. Recurrent neural networks for multivariate time series with missing values. ［用于含缺失值的多变量时间序列的循环神经网络。］Scientific reports, 8(1): 1–12.

6. Chen, T.; He, T.; Benesty, M.; and Khotilovich, V. 2019. Package ‘xgboost’. ［xgboost软件包。］R version, 90.

7. Cowan, N. 2010. The magical mystery four: How is working memory capacity limited, and why? ［神奇而神秘的四：工作记忆容量如何受到限制，又为何如此？］Current directions in psychological science, 19(1): 51–57.

8. De Cock, D. 2011. Ames, Iowa: Alternative to the Boston housing data as an end of semester regression project. ［艾奥瓦州艾姆斯：作为学期末回归项目的波士顿住房数据替代方案。］Journal of Statistics Education, 19(3).

9. Groenwold, R. H.; White, I. R.; Donders, A. R.; Carpenter, J. R.; Altman, D. G.; and Moons, K. G. 2012. Missing covariate data in clinical research: when and when not to use the missing-indicator method for analysis. ［临床研究中的协变量缺失数据：何时应当、何时不应使用缺失指示方法分析。］CMAJ : Canadian Medical Association journal = journal de l’Association medicale canadienne, 184(11): 1265–1269.

10. Jones, M. P. 1996. Indicator and stratification methods for missing explanatory variables in multiple linear regression. ［多元线性回归中解释变量缺失的指示变量方法与分层方法。］Journal of the American statistical association, 91(433): 222–230.

11. Knaus, W. A.; Harrell, F. E.; Lynn, J.; Goldman, L.; Phillips, R. S.; Connors, A. F.; Dawson, N. V.; Fulkerson, W. J.; Califf, R. M.; Desbiens, N.; et al. 1995. The SUPPORT prognostic model: Objective estimates of survival for seriously ill hospitalized adults. ［SUPPORT 预后模型：重症住院成年人生存情况的客观估计。］Annals of internal medicine, 122(3): 191–203.

12. Le Morvan, M.; Josse, J.; Moreau, T.; Scornet, E.; and Varoquaux, G. 2020a. NeuMiss networks: differentiable programming for supervised learning with missing values. ［NeuMiss 网络：用于含缺失值的监督学习的可微编程。］arXiv:2007.01627.

13. Le Morvan, M.; Josse, J.; Scornet, E.; and Varoquaux, G. 2021. What’s a good imputation to predict with missing values? ［含缺失值的预测需要怎样的良好插补？］Advances in Neural Information Processing Systems, 34.

14. Le Morvan, M.; Prost, N.; Josse, J.; Scornet, E.; and Varoquaux, G. 2020b. Linear predictor on linearly-generated data with missing values: non consistency and solutions. ［含缺失值的线性生成数据上的线性预测器：非一致性及其解决方案。］In Chiappa, S.; and Calandra, R., eds., Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics, volume 108 of Proceedings of Machine Learning Research, 3165–3174. PMLR.

15. Little, R. J. 1993. Pattern-mixture models for multivariate incomplete data. ［多变量不完整数据的模式混合模型。］Journal of the American Statistical Association, 88(421): 125–134.

16. Liu, X.; Zachariah, D.; and Stoica, P. 2020. Robust Prediction When Features are Missing. ［特征缺失时的稳健预测。］IEEE Signal Processing Letters, 27: 720–724.

17. Marlin, B. M. 2008. Missing Data Problems in Machine Learning. ［机器学习中的缺失数据问题。］Ph.D. thesis, University of Toronto.

18. Marshall, G.; Warner, B.; MaWhinney, S.; and Hammermeister, K. 2002. Prospective prediction in the presence of missing data. ［存在缺失数据时的前瞻性预测。］Statistics in medicine, 21(4): 561–570.

19. Meinshausen, N. 2007. Relaxed lasso. ［松弛 LASSO。］Computational Statistics & Data Analysis, 52(1): 374–393.

20. Mercaldo, S. F.; and Blume, J. D. 2020. Missing data and prediction: the pattern submodel. ［缺失数据与预测：模式子模型。］Biostatistics, 21(2): 236–252.

21. Miller, G. A. 1956. The magical number seven, plus or minus two: Some limits on our capacity for processing information. ［神奇的数字七，加或减二：我们信息加工能力的若干限制。］Psychological review, 63(2): 81.

22. Mofrad, S. A.; Lundervold, A. J.; Vik, A.; and Lundervold, A. S. 2021. Cognitive and MRI trajectories for prediction of Alzheimer’s disease. ［用于预测阿尔茨海默病的认知与 MRI 轨迹。］Scientific Reports, 11(1): 1–10.

23. Nazabal, A.; Olmos, P. M.; Ghahramani, Z.; and Valera, I. 2020. Handling incomplete heterogeneous data using vaes. ［使用变分自编码器处理不完整异质数据。］Pattern Recognition, 107: 107501.

24. Pedregosa, F.; Varoquaux, G.; Gramfort, A.; Michel, V.; Thirion, B.; Grisel, O.; Blondel, M.; Prettenhofer, P.; Weiss, R.; Dubourg, V.; Vanderplas, J.; Passos, A.; Cournapeau, D.; Brucher, M.; Perrot, M.; and Duchesnay, E. 2011. Scikit-learn: Machine Learning in Python. ［Scikit-learn：Python 中的机器学习。］Journal of Machine Learning Research, 12: 2825–2830.

25. Rubin, D. B. 1976. Inference and missing data. ［统计推断与缺失数据。］Biometrika, 63(3): 581–592.

26. Rudin, C. 2019. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. ［不要再为高风险决策解释黑箱机器学习模型，而应改用可解释模型。］Nature Machine Intelligence, 1(5): 206–215.

27. Seaman, S.; Galati, J.; Jackson, D.; and Carlin, J. 2013. What is meant by “missing at random”？［“随机缺失”是什么意思？］Statistical Science, 28(2): 257–268.

28. Tibshirani, R. 1996. Regression shrinkage and selection via the lasso. ［通过 LASSO 进行回归收缩与选择。］Journal of the Royal Statistical Society: Series B (Methodological), 58(1): 267–288.

29. Van Buuren, S. 2018. Flexible Imputation of Missing Data (2nd ed.). ［缺失数据的灵活插补，第 2 版。］Chapman and Hall/CRC, Boca Raton, FL.

30. Virtanen, P.; Gommers, R.; Oliphant, T. E.; Haberland, M.; Reddy, T.; Cournapeau, D.; Burovski, E.; Peterson, P.; Weckesser, W.; Bright, J.; et al. 2020. SciPy 1.0: fundamental algorithms for scientific computing in Python. ［SciPy 1.0：Python 科学计算的基础算法。］Nature methods, 17(3): 261–272.

31. Weiner, M. W.; Aisen, P. S.; Jack Jr., C. R.; Jagust, W. J.; Trojanowski, J. Q.; Shaw, L.; Saykin, A. J.; Morris, J. C.; Cairns, N.; Beckett, L. A.; Toga, A.; Green, R.; Walter, S.; Soares, H.; Snyder, P.; Siemers, E.; Potter, W.; Cole, P. E.; Schmidt, M.; and Initiative, A. D. N. 2010. The Alzheimer’s Disease Neuroimaging Initiative: Progress report and future plans. ［阿尔茨海默病神经影像倡议：进展报告与未来计划。］Alzheimer’s & Dementia, 6(3): 202–211.e7.

译者校对说明

以下说明不属于原文，也不替代原文的数学论证或实验结果。

- 本文件完整覆盖用户提供的 9 页会议稿。正文所引附录 A.2、A.3、A.5、B.2、C.1、C.3、C.4，以及附录图 4、7、8 和表 7、8、9，均不在该文件中。本译文保留这些回引，不补造完整证明或实验结果。
- 第 2 节原文将插补后的协变量写为 $X^I \in \mathbb{R}$；本译文保留该写法，没有自行补上维度上标 d。
- 第 4.1 节关于岭正则化的句子，原文使用的是“non-degenerate case”（非退化情形），本译文未改成其相反词。
- 第 5.1 节原文在结果函数中使用 θ，随后写 $\beta_{i(c)} \sim \mathcal{N}(0,\ 1)$，同时继续用 $\theta_j = 0$ 描述其他特征；这些符号按原稿保留。
- 实验设置给出的 λ 候选集合，与后文报告的 $\lambda = 50$、表 3 的 $\lambda = 13$ 并不完全一致；本译文保留所有原值，不自行改数或补充未提供的参数搜索说明。