面向部分多视图不完整多标签分类的任务增强跨视图插补网络

Task-Augmented Cross-View Imputation Network for Partial Multi-View Incomplete Multi-Label Classification

Lian Zhao[a]，**Jie Wen**[b]，**Xiaohuan Lu**[a,*]，**Wai Keung Wong**[c,d]，**Jiang Long**[a]，**Wulin Xie**[a]

a 贵州大学大数据与信息工程学院，中国贵阳。
b 哈尔滨工业大学（深圳）深圳市视觉目标检测与识别重点实验室，中国深圳。
c 香港理工大学时装及纺织学院，中国香港。
d 香港人工智能设计研究所，中国香港。

* 通信作者：Xiaohuan Lu；电子邮箱：xhlu3@gzu.edu.cn。

原稿信息与译本范围　本译本依据用户提供的 16 页 PDF 制作，来源为用户上传的 Pro_Residual_Exploration ZIP 中对应论文。原稿侧边标识为 arXiv:2409.07931v2 [cs.CV]，日期 2025 年 3 月 24 日；首页页脚为“提交至 Neural Networks 的预印本”，日期 2025 年 3 月 25 日。两处日期均据原稿保留。此为非官方、私人使用的中文全文译本，不表示公开发表、公共许可或新增转载授权；原文作者、出版及其他权利仍归原权利人。图表和编号公式保留原稿图像，以保全数值、上下标、粗体、斜体及特殊数学字形；图内英文另附中文释义。正文所有章节、算法、致谢和 54 条参考文献均译出。所提供文件不含附录、独立证明或作者简介，正文也未指向另行提供的补充材料，故不补造这些内容。

摘要

在现实场景中，由于数据采集受到限制，以及标注过程不可靠，多视图多标签学习经常面临训练数据不完整的挑战。多视图特征的缺失妨碍了对样本的全面理解，使分类所必需的关键细节被遗漏。针对这一问题，我们提出任务增强跨视图插补网络（TACVI-Net），用于处理部分多视图不完整多标签分类。具体而言，我们采用一个两阶段网络，提取与任务高度相关的特征，以恢复缺失视图。在第一阶段，我们利用信息瓶颈理论，通过视图特定的编码器-分类器架构提取任务相关信息，获得每个视图的判别性表示。在第二阶段，我们采用基于自编码器的多视图重构网络，提取增强特征的高层语义表示并恢复缺失数据，从而辅助最终的分类任务。在五个数据集上的大量实验表明，TACVI-Net 优于其他最先进的方法。

关键词：任务增强；跨视图插补；部分多视图学习；不完整多标签分类。

1 引言

近年来，随着表示学习方法取得显著进展，传统单视图数据分析方法逐渐显露其局限，难以充分适应日益多样化的应用需求 [1][2][3]。因此，多视图数据整合已成为突破单一数据源固有壁垒、缓解信息不足的重要途径 [4][5]。这一趋势伴随着数据采集技术的迅速发展，使来自各种媒介或具有不同风格的海量

多视图数据不断涌现，为全面而准确地描述观测目标提供了更多可能 [6][7]。简言之，多视图数据是针对同一对象从不同观测角度采集的一系列互补信息集合 [8][9]。例如，医学诊断中通过 X 射线、CT 扫描和磁共振成像（MRI）获取的三种独特视觉信息，可构成一个多视图数据集；在四个不同位置采集的视网膜图像，也可构成另一个多视图视网膜数据集 [10]。更常见的是，融合文本、图像、视频等多种数据类型的多视图或多模态数据集，已被用于网页分类等许多应用场景 [11][12]。

与此同时，人们观察到，单标签数据往往不足以充分反映现实场景的复杂性 [13]。例如，一张花朵图片还可能需要“冬季”或“温室”等标签，这表明多标签能够提供更全面的类别特征空间，并更准确地保留标签间关系 [14]。考虑到多标签分类任务中对象的多样性，研究者创新性地将多视图学习与多标签分类相结合。这种整合不仅使来自不同视角的数据得到充分利用，还提供了捕捉目标对象内部以及标签之间复杂关系的机会 [15]。这些优势共同提升了分类性能，使多视图多标签分类（MVMLC）成为备受关注的研究领域 [16]。

过去几年中，研究者提出了许多 MVMLC 方法，例如感知潜在语义的 MvMLC [17]、多视图概率模型 LCBM [18]，以及基于标签-特征依赖最大化的方法 [19]。然而，MVMLC 假定所有视图及其对应标签均完整，这一前提并不总是符合现实情况 [20][21]。例如，视频资料中经常缺失音轨，文本描述也可能不完整；同样，在社交媒体平台传播的多媒体内容，常因用户参与程度不同而存在标注不完整的情况。这些实际情形使现实数据集普遍面临多视图特征与类别信息均不完整的挑战。本文将此定义为“部分多视图不完整多标签分类（PMVIMLC）”[22]。

为解决这一问题，近年来已有多种 PMVIMLC 方法被提出。Tan 等人最初提出 iMvWL 模型，基于矩阵分解构建共享低维子空间 [16]；Li 等人提出 NAIM3L 模型，保留标签结构的全局一致性与局部性质 [23]。但这些模型依赖浅层机器学习技术探索特征和标签中的信息，因此从数据中提取高阶判别特征的能力受到限制。为此，Liu 等人开发了 DICNet 模型，从多视图数据中提取更深层的语义表示 [12]。然而，上述模型引入缺失视图指示矩阵以绕过未知视图，仅依赖可用数据进行分类，未能充分利用潜在的跨视图互补信息及缺失数据的内在关系，因而并非最优 [24]。尽管直接恢复缺失数据本身具有挑战性，我们仍提出构建具备这种能力的模型，以克服上述局限。

鉴于这一问题，我们提出面向部分多视图不完整多标签分类的任务增强跨视图插补网络（TACVI-Net）。TACVI-Net 旨在处理任意视图缺失情形，并通过有效的视图补全增强表示学习。原始数据可能包含与任务无关的冗余信息 [25]；若直接用其填补缺失数据，可能导致这些信息累积。因此，受信息瓶颈理论启发，我们设计了基于变分编码的视图特定编码器-分类器架构。该架构能够获得与任务高度相关的增强特征，有效避免无关冗余信息对模型性能的影响。

当视图特征缺失时，选择恰当的填补策略以提供充分、有用的信息至关重要。考虑到多视图之间存在共享语义信息，我们通过视图编码器将每个输入视图转换成隐藏表示，并将其合并为联合表示，形成融合的共享表示。随后，通过视图解码器利用这一融合共享表示重构缺失数据，再将其与已有数据整合为完整数据集。这样就能获得更充分的信息，以利用不同视图之间的一致性与互补性，进而提升最终分类性能。

综上，TACVI-Net 的贡献如下：

- 我们提出一种新的两阶段框架，将任务相关信息的获取与缺失视图补全相结合。第一阶段提取任务相关特征，第二阶段旨在获得完整多视图数据，以提高分类过程的准确性。

- 不同于既有的缺失视图恢复方法，我们在恢复之前利用信息瓶颈理论消除与任务无关的冗余信息，有效防止这类信息导致的噪声累积。这保证模型能够专注于挖掘和利用数据中的有用信息，从而增强缺失视图恢复的可靠性。
- 我们在基于自编码器的架构中采用插补策略，增加可用信息量，从而增强模型理解和捕捉多个视图之间一致性与互补信息的能力。多个数据集上的实验结果验证了本方法的优越性。

2 预备知识

本节给出 PMVIMLC 的问题定义及相关符号的表示规则。此外，由于本任务与多视图学习和多标签分类密切相关，我们依次介绍多视图多标签分类，以及部分多视图不完整多标签分类的相关工作。

2.1 问题描述与相关符号

对于 PMVIMLC 任务，我们采用如下记号：$\{X_l\}_{l=1}^{m}$ 和 Y 分别表示原始多视图数据及对应标签，m 是视图总数。每个 $X_l = \{x_{l_1}, x_{l_2}, \ldots, x_{l_n}\} \in R^{n \times d_{l_x}}$ 包含第 l 个视图中各实例的属性，其中 n 表示实例数，d_{l_x} 表示该视图的特征维数。具体而言，x_{l_i} 表示从第 l 个视角观测到的第 i 个样本的属性。

标签矩阵为 $Y = \{y_1, y_2, \ldots, y_n\} \in \{0, 1\}^{n \times c}$，其中 c 表示标签数。$Y_{i,j} = 1$ 表示第 i 个实例具有第 j 个标签，否则 $Y_{i,j} = 0$。具体而言，y_i 表示第 i 个样本所有可能标签的状态。

为了进一步考虑数据缺失，我们引入缺失视图指示矩阵 $U \in \{0, 1\}^{n \times m}$。当第 i 个样本在第 j 个视图中存在时，$U_{i,j} = 1$；否则 $U_{i,j} = 0$。同样，$G \in \{0, 1\}^{n \times c}$ 是缺失标签指示矩阵，$G_{i,j} = 1$ 表示第 i 个实例的第 j 个标签已知，$G_{i,j} = 0$ 则表示其状态未知。预处理时，将特征矩阵 $\{X_l\}_{l=1}^{m}$ 和标签矩阵 Y 中的缺失值置为 0。

给定上述视图完整或不完整、标签完整或不完整的多视图训练数据，PMVIMLC 任务的目标是训练一个模型，使其能够为每个视图完整或不完整的多视图样本准确预测完整标签集合。为便于读者快速辨识关键符号，表 1 汇总了本文使用的主要记号。

表 1　本文使用的主要记号。

Notation	Explanation
n	the number of all samples
m	the number of all views
c	the number of all classes
d_{l_x}	the dimension of X_l
d_{l_v}	the dimension of V_l, $V_l^{'}$ and T_l
d_e	the dimension of Z_l, Z_T^l, $\widehat{Z}$ and $\widehat{Z_T}$
X_l	original data of view l ($R^{n\times d_{l_x}}$)
V_l	related-task data of view l ($R^{n\times d_{l_v}}$)
$V_l^{'}$	reconstructed related-task data of view l ($R^{n\times d_{l_v}}$)
T_l	complete data of view l ($R^{n\times d_{l_v}}$)
Z_l	embedding feature of V_l ($R^{n\times d_e}$)
$\widehat{Z}$	fusion feature of all imcomplete views ($R^{n\times d_e}$)
Z_T^l	embedding feature of T_l ($R^{n\times d_e}$)
$\widehat{Z_T}$	fusion feature of all complete views ($R^{n\times d_e}$)
Y	real label matrix ($\{0,1\}^{n\times c}$)
$Y^{'}$	predictive label matrix ($[0,1]^{n\times c}$)
U	missing-view indication matrix ($\{0,1\}^{n\times m}$)
G	missing-label indication matrix ($\{0,1\}^{n\times c}$)
$\mathfrak{Э}_l$	encoder for the first stage of X_l
$\mathfrak{C}_l$	classifier for the first stage of V_l
Ψ_l	encoder for the second stage of V_l and T_l
Φ_l	decoder for obtaining reconstructed feature $V_l^{'}$
$\mathbb{C}$	classifier for the second stage of fusion feature $\widehat{Z_T}$

表 1 的中文释义如下（符号的特殊字形以原表为准）：

记号	含义
n； m； c	分别为全部样本数、全部视图数、全部类别数
d_{l_x}	X_l 的维数
d_{l_v}	V_l、V'_l 和 T_l 的维数
d_e	Z_l、Z_T^l、$\widehat{Z}$ 和 $\widehat{Z}_T$ 的维数
X_l	第 l 个视图的原始数据，$R^{n\times d_{l_x}}$
V_l	第 l 个视图的任务相关数据，$R^{n\times d_{l_v}}$
V'_l	第 l 个视图重构出的任务相关数据，$R^{n\times d_{l_v}}$
T_l	第 l 个视图的完整数据，$R^{n\times d_{l_v}}$
Z_l； Z_T^l	分别是 V_l 和 T_l 的嵌入特征，均为 $R^{n\times d_e}$
$\widehat{Z}$； $\widehat{Z}_T$	分别是所有不完整视图和所有完整视图的融合特征，均为 $R^{n\times d_e}$
Y； Y'	真实标签矩阵 $\{0,\ 1\}^{n\times c}$；预测标签矩阵 $[0,\ 1]^{n\times c}$
U； G	缺失视图指示矩阵 $\{0,\ 1\}^{n\times m}$；缺失标签指示矩阵 $\{0,\ 1\}^{n\times c}$
$\mathfrak{I}_l$	第一阶段用于 X_l 的编码器
$\mathbb{C}_l$	第一阶段用于 V_l 的分类器
Ψ_l； Φ_l	第二阶段用于 V_l 和 T_l 的编码器；用于获得重构特征 V'_l 的解码器
$\mathbb{C}$	第二阶段用于融合特征 $\widehat{Z}_T$ 的分类器

2.2 相关工作

2.2.1 多视图多标签分类

MVMLC 研究同时包含多个视图和多个标签的数据，因而复杂度显著增加。与只依赖单一视图的多标签分类方法相比，引入多视图学习策略已被证明能够更有效地解决这类问题，这推动了相关研究的大幅增长。例如，Zhang 等人提出利用矩阵分解在核空间中对齐不同视图的潜在模式，以利用多视图之间的互补信息 [17]。Wu 等人提出 SIMM，在共享子空间上施加正交约束，以提取多个视图的独特信息，同时优化对抗损失与多标签损失，获得跨视图共享信息 [26]。Zhang 等人提出 RAIN，通过多头注意力机制促进交互和语义标签嵌入，强化标签关联，并基于学习到的标签嵌入动态获得特定标签表示 [27]。Sun 等人提出生成模型 LCBM，利用伯努利混合模型融合多视图特征，并建立标签间依赖关系 [18]。

Zhao 等人提出的 CDMM 使用非线性核神经网络为各视图建立独立分类器，以保证视图间一致性，并引入 Hilbert-Schmidt 准则增强视图间多样性 [28]。Yu 等人提出 M3AL，结合多视图自表示学习来优化信息分离，并采用独特的查询策略，根据共享信息、个体信息和视图差异，选择信息量大的样本-标签对用于主动学习 [29]。Zhao 等人针对未对齐多视图多标签分类提出 LVSL，旨在统一系统中捕捉视图特定标签信息及低层标签结构。该方法利用视图与标签之间的结构一致性，并增强标签空间信息 [30]。Lyu 等人提出 D-VSM，采用 DeepGCN 在单个视图层面直接编码特征表示，既保留各视图的独特信息，也促进跨视图信息的有效耦合 [31]。Yin 等人提出 MMDOM，通过一阶和二阶相似度矩阵，使低维共享子空间同时保留数据的局部与全局结构，从而有效保护流形结构 [32]。Xiao 等人开发了基于 SVM 的 MVMLP，通过加强各视图输出的相似性获得共识信息，同时让不同视图互为特权信息，以引入互补性 [33]。

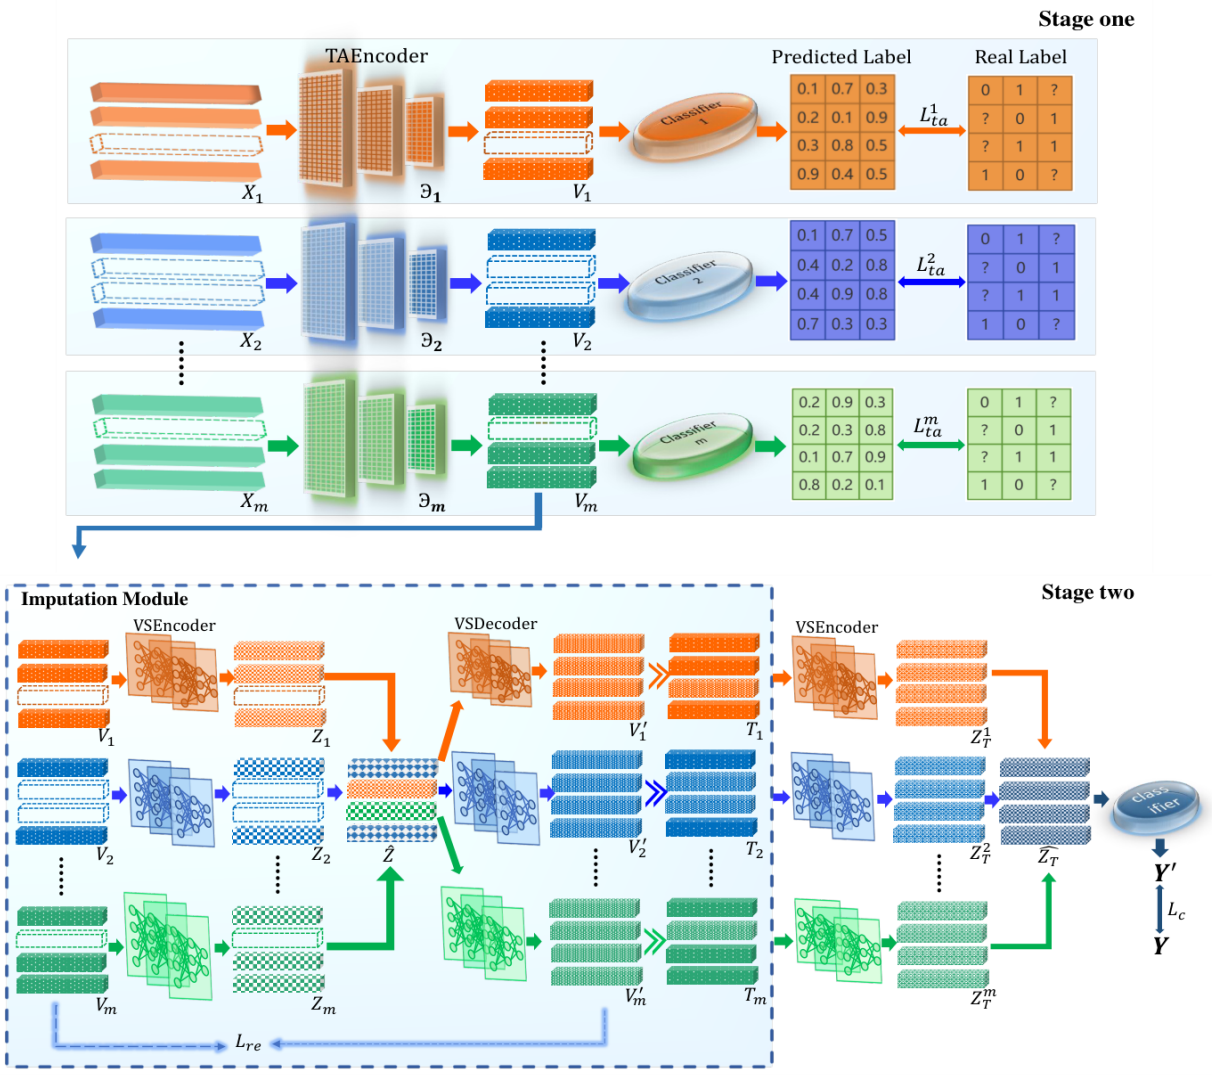
2.2.2 部分多视图不完整多标签分类

MVMLC 研究主要依赖数据完整性假设，未能充分考虑实际应用中可能存在的不完整性。因此，PMVIMLC 任务受到研究者的广泛关注，他们致力于开发解决多视图多标签数据不完整问题的方法。例如，Tan 等人提出 iMVWL，整合局部标签关联学习、共享子空间和预测器，优化跨视图关系并利用弱标签信息 [16]。Zhu 等人提出 GLMVML-IVL，旨在学习特定标签特征、伪类别标签矩阵、低秩假设矩阵、全局与局部标签相关性以及互补信息，从而提供更细致的视角 [34]。Li 等人提出 NAIM3L，通过在共同标签空间中对齐所有多视图标签，进一步处理未对齐多视图多标签数据的学习问题 [23]。Qu 等人提出主动学习方法 iMVMAL，适配欠完备自编码器，并利用指示矩阵处理缺失数据，从而有效学习样本的共享特征和个体特征 [35]。Liu 等人提出 IMVPML，通过低秩和稀疏分解进行标签清洗，构建跨视图共享子空间，并利用图正则化保证标注准确性与子空间之间的正交性 [36]。

Liu 等人提出 DICNet，将对比学习引入多视图学习框架。该方法缩小正样本对的距离，同时扩大负样本对的距离，从而增强模型跨不同视图提取信息的能力 [12]。Liu 等人还提出 MTD，将多视图深度学习方法中常见的单通道视图级表示解耦为共享表示与视图特定表示，以充分利用不同视图之间的互补性与一致性信息 [37]。Tan 等人主张应用信息论增强和精炼原本不完整的数据集，所采用的理论框架能够平衡可用信息，突出对任务至关重要的部分 [38]。Liu、Xu 等人提出的 SIP 模型尝试压缩跨视图表示，使共享信息量最大化，从而更好地预测语义标签 [39]。

然而，尽管上述方法提供了多种应对 PMVIMLC 的策略，仍存在三个关键局限：（1）某些模型的训练计算成本很高；（2）部分方法对视图-标签交互建模不足，无法捕捉复杂依赖关系；（3）绕过或剔除缺失视图数据，可能导致信息利用不充分。为克服这些问题，我们提出联合探索多个视图与标签之间的交互，恢复与缺失数据有关的信息，再将恢复的信息作为增量信息，以突破现有方法的性能限制。

图 1　TACVI-Net 示意图。TAEncoder 表示基于变分编码的任务增强编码器；VSEncoder 和 VSDecoder 分别表示视图特定编码器和解码器，二者采用相互对称的结构，并均基于多层感知机（MLP）。



图中文字对照：Stage one／Stage two＝第一／第二阶段；Predicted Label＝预测标签；Real Label＝真实标签；Classifier＝分类器；Imputation Module＝插补模块。虚线空缺表示缺失视图，问号表示未知标签；其余符号与表 1 及正文公式对应。

3 所提出的方法

本节深入考察模型设计背后的动机，并全面分析本方法的总体架构与核心组成部分。

3.1 动机

一方面，众所周知，在分类任务中，不同视图共享相同的高层语义信息，因为它们描述的是同一个抽象目标。这意味着，只要能捕捉共享的高层语义信息，就可以根据学习到的模式反向推断缺失信息 [24]。基于上述分析，我们设计了具有自编码器架构的跨视图插补模块：编码器旨在学习多视图的高层语义表示，解码器则利用跨视图融合的高层表示重构缺失视图信息，引导模型填补数据空缺。

另一方面，给定原始数据通常含有许多冗余特征 [40]，盲目地直接用原始数据插补缺失值可能使冗余不断累积。为应对这一挑战，受信息瓶颈理论 [41][42] 启发，我们提出面向任务的特征增强网络，识别并选择与任务最相关的特征子集，以确保在插补之前获得干净特征。

基于上述动机与考虑，我们最终尝试将面向任务的特征增强与跨视图插补结合，用于 PMVIMLC 任务。同时，为使视图插补服务于 PMVIMLC，采用两阶段训练方式优化网络：

- 第一阶段：面向任务的特征增强。
- 第二阶段：跨视图插补与增强分类。

总体框架如图 1 所示。第一阶段重点从各视图提取任务相关特征。第二阶段以第一阶段获得的特征作为输入，恢复缺失视图，形成完整多视图数据。随后，网络利用补全后的多视图数据进行分类预测，从根本上提高分类准确性与鲁棒性。

3.2 面向任务的特征增强

在处理缺失多视图数据恢复这一复杂问题时，我们认识到，原始数据经常包含与任务无关的冗余信息，这可能削弱后续插补过程的有效性，并影响最终分类结果 [38][41]。因此，在插补之前，我们希望获得高质量、具有判别性且紧凑的表示 V_l，使其集中包含任务相关信息，以替代初始视图的冗余特征 X_l。根据信息瓶颈原理 [43]，可以通过最小化如下问题实现这一目标：

$$L_{ta}^{l} = -I(V_l; Y) + \delta I(V_l; X_l) \tag{1}$$

其中，$I(V_l; Y)$ 表示第 l 个视图 V_l 与真实标签 Y 的互信息；我们希望尽可能将其最大化，以获得更多任务相关信息，增强模型对任务的理解。$I(V_l; X_l)$ 表示 V_l 与 X_l 之间的互信息；我们希望将其最小化，以滤除与任务执行无关的额外信息。通过这种方式，可以区分有用信息与噪声，确保模型从不同视图学习面向任务的特征。在整个过程中，引入统一调节因子 δ，以平衡所有视图中任务相关信息的保留。

然而，直接计算互信息往往具有很高的计算复杂度。为缓解这一困难，首先受 [38][44][45] 启发，我们将第一项 $-I(V_l; Y)$ 近似为一种广义的常见交叉熵损失：

$$-I(V_l; Y) = \frac{1}{nc} \sum_{i=1}^{n} \sum_{j=1}^{c} \left[\left(1 - Y_{i,j}\right) \log\left(1 - Y'_{l_{i,j}}\right) + Y_{i,j} \log Y'_{l_{i,j}} \right] \tag{2}$$

其中，n 为样本总数，c 为标签总数，Y'_l 是第一阶段分类器 $\mathbb{C}_l$ 的输出，即该分类器作用于 V_l 得到 Y'_l。这种近似既保留了对任务相关信息的高度敏感性，也显著降低计算负担，提高算法的实际可行性。

接下来，对于第二项 $I(V_l; X_l)$，我们引入变分编码-解码技术 [46]。为更清楚地展开后续讨论，先解释互信息的基本概念。给定 V_l 与 X_l，将其联合概率分布记为 $p(V_l, X_l)$，边缘概率分布分别记为 $p(V_l)$ 与 $p(X_l)$，则互信息 $I(V_l; X_l)$ 定义为：

$$I(V_l; X_l) = H(V_l) - H(V_l|X_l) = \mathbb{E}_{p(V_l, X_l)} \left[\log \left(\frac{p(V_l, X_l)}{p(V_l)\, p(X_l)} \right) \right] \tag{3}$$

其中，$\mathbb{E}$ 表示期望，$H(V_l)$ 与 $H(V_l \mid X_l)$ 分别表示熵与条件熵。

显然，将 $p(V_l, X_l) = p(V_l \mid X_l)p(X_l)$ 代入式（3），可得到如下上界：

$$I(V_l; X_l) \leq \mathbb{E}_{p(V_l, X_l)}\left[\log \frac{p(V_l|X_l)}{p(V_l)}\right]. \tag{4}$$

为便于计算，可以将 $p(V_l)$ 任意设为多元高斯 $N(V_l \mid 0, I)$，作为近似概率分布；将 $p(V_l \mid X_l)$ 设为另一个多元高斯 $N(V_l \mid \mu_l, \sum_l)$。其中，均值 $\{\mu_l^{(i)} \subseteq R^{d_{l_v}}\}_{i=1}^n$ 和对角协方差矩阵 $\{\sum_l^{(i)} \subseteq R^{d_{l_v} \times d_{l_v}}\}_{i=1}^n$ 都与 X_l 有关。为了确定 μ_l 与 $\sum_l$，采用专门的多层感知机（MLP）TAEncoder，以数据矩阵 $X_l \in R^{n \times d_{l_x}}$ 为输入，生成两个矩阵 $\mathcal{P}_l \in R^{n \times d_{l_v}}$ 与 $\mathcal{Q}_l \in R^{n \times d_{l_v}}$，分别与 V_l 的均值和标准差相关。因此，可通过 $V_l = \mathcal{P}_l + \varpi \odot \mathcal{Q}_l$ 生成 V_l [43]。这里，ϖ 是从标准高斯分布抽取的矩阵，$\odot$ 表示 Hadamard 积。

随后，将两个高斯分布 $p(V_l)$ 与 $p(V_l \mid X_l)$ 代入上界公式（4），再进行分解与化简。这一步不仅将这些分布拆分为多个一维高斯分布，还用经验分布近似边缘概率分布 $p(X_l)$。经过这一过程，第二项 $I(V_l; X_l)$ 可改写为如下损失：

$$I(V_l; X_l) = \frac{1}{2nd_{l_v}} \sum_{i=1}^{n} \sum_{j=1}^{d_{l_v}} \left[(\mathcal{Q}_{l_{i,j}})^2 - \log(\mathcal{Q}_{l_{i,j}})^2 + (\mathcal{P}_{l_{i,j}})^2 - 1\right] \tag{5}$$

其中，d_{l_v} 表示第 l 个视图 V_l 的特征维数。

最后，将式（2）与式（5）结合，建立第一阶段优化的最终目标函数：

$$\begin{aligned} L_{ta}^{l} = & \frac{1}{nc} \sum_{i=1}^{n} \sum_{j=1}^{c} \left[\left(1 - Y_{i,j}\right) \log\left(1 - Y'_{l_{i,j}}\right) + Y_{i,j} \log Y'_{l_{i,j}}\right] U_{i,l} G_{i,j} \\ & + \frac{\delta}{2nd_{l_v}} \sum_{i=1}^{n} \sum_{j=1}^{d_{l_v}} \left[(\mathcal{Q}_{l_{i,j}})^2 - \log(\mathcal{Q}_{l_{i,j}})^2 + (\mathcal{P}_{l_{i,j}})^2 - 1\right] U_{i,l} \end{aligned} \tag{6}$$

U 为缺失视图指示矩阵，G 为缺失标签指示矩阵；二者用于系统地排除缺失视图与缺失标签对模型训练过程造成的不利干扰 [12][13]。

3.3 跨视图插补

上一小节利用第一阶段网络，在滤除冗余信息的同时，深入捕捉了多视图中与任务高度相关的信息。在此基础上，我们进一步提出新的跨视图插补模块，以恢复缺失视图并提升性能。

不同于关注数据浅层特征的传统方法，我们选择深度自编码器提取多视图数据的高层嵌入特征。具体而言，通过由 MLP 构成的视图特定编码器（VSEncoder），将第一阶段获得的任务相关特征投影至嵌入空间。这样既保证提取的高层嵌入特征保留视图特定语义信息，又使不同视图在嵌入空间中对齐到相同维数，便于后续特征融合。第 l 个视图的形式化表达式为：

$$Z_l = \Psi_l(V_l, \vartheta_l) \tag{7}$$

其中，$Z_l \in R^{n\times d_e}$ 是从视图 l 提取的嵌入特征，Ψ_l 是第 l 个视图的编码器，ϑ_l 是与 Ψ_l 对应的网络参数。

利用 VSEncoder 获得各视图的嵌入特征后，为充分利用并有效互补各视图的独特信息，我们采用简单而高效的多视图加权融合策略 [37]，通过分配权重系统地合并所有视图，形成统一、全面的表示：

$$\widehat{Z_{i,:}} = \sum_{l=1}^{m} \frac{Z_{l_{i,:}} U_{i,l}}{\sum_{l'} U_{i,l'}} \tag{8}$$

其中，$\widehat{Z}_{i,:} \in R^{d_e}$ 表示第 i 个样本的融合表示，$Z_{l_{i,:}} \in R^{d_e}$ 表示第 l 个视图中第 i 个样本的判别特征。$U_{i,l}$ 和 $U_{i,l'}$ 的取值为 1 或 0，m 为视图总数。

利用上述视图级信息的共享特性，学习全面的样本表示 $\widehat{Z}$，意味着当样本缺失某些视图时，可以训练与 $\widehat{Z}$ 相连的对称跨视图解码模块 VSDecoder，重构所有视图的数据，尤其补全原先缺失的部分，即：

$$V_l^{'} = \Phi_l\left(\widehat{Z}, \zeta_l\right) \tag{9}$$

其中，$V'_l \in R^{n\times d_{l_v}}$ 是第 l 个视图的重构特征，Φ_l 是第 l 个视图的解码器，ζ_l 是其对应的网络参数。虽然完整、准确地恢复所有缺失信息存在固有困难，但由于共享表示 $\widehat{Z}$ 内含跨视图的相似知识，这一策略仍能有效推断接近真实数据的预测值。由于无法直接获得用于衡量重构数据准确性的监督信息，我们采用替代策略：利用可用的初始数据，施加称为加权重构损失的约束 [37]：

$$L_{re} = \frac{1}{nm} \sum_{i=1}^{n} \sum_{l=1}^{m} \frac{1}{d_{l_v}} \| V_{l_{i,:}}^{'} - V_{l_{i,:}} \|_2^2 \, U_{i,l} \tag{10}$$

其中，$V'_{l_{i,:}}$ 是第 l 个视图中第 i 个样本 $V_{l_{i,:}}$ 所对应的重构实例。这样，尽管缺乏直接的判别指导，仍可引导模型关注关键信息的保留与重构，从而间接促进学习过程 [24]。最后，如图 1 所示，将解码重构得到的特征填入原样本中缺失视图的位置，获得完整视图集合 $\{T_l\}_{l=1}^{m}$。该集合含有更多信息，因此能够更好地利用跨视图的一致性与互补性，促进最终分类。

3.4 不完整多标签分类

获得完整视图 $\{T_l\}_{l=1}^{m}$ 后，将其用于最终的不完整多标签分类任务。首先，采用视图特定编码器 $\{\Psi_l\}_{l=1}^{m}$ 捕捉每个 T_l 中的深层语义信息：

$$Z_T^l = \Psi_l(T_l, \lambda_l) \tag{11}$$

其中，$Z_T^l \in R^{n\times d_e}$ 是 T_l 的高层特征，λ_l 为与 Ψ_l 对应的网络参数。

然后，我们希望形成能够充分刻画多视图数据的统一、一致表示。然而，不同视图对这种表示的贡献可能不同。考虑到不同视图具有不同的判别能力，以及数据完整性增强后各视图相对价值的可挖掘性，在原先缺失的视图得到补全之后，我们改用具有可学习权重的加权融合方式，替代多视图数据不完整时使用的固定权重融合方法 [47]：

$$\widehat{Z_{T_{i,:}}} = \frac{1}{m}\sum_{l=1}^{m}\sigma_l Z^l_{T_{i,:}} \tag{12}$$

$\widehat{Z}_{T_{i,:}} \in R^{d_e}$ 表示融合表示 $\widehat{Z}_T \in R^{n\times d_e}$ 中第 i 个样本的表示， $\widehat{Z}_T$ 作为下一分类层的输入。$Z^l_{T_{i,:}} \in R^{d_e}$ 表示第 l 个视图中第 i 个样本的判别特征；$\{\sigma_l\}_{l=1}^{m}$ 表示经 softmax 处理的可学习权重。

最后，我们构建从联合特征空间到多标签分类空间的直接映射，具体由两个线性层和 sigmoid 激活函数实现，为每个样本的每个潜在类别独立生成概率分数。这些概率分数经 sigmoid 变换限制在 0 与 1 之间。数学上，这一分类过程可抽象为 $\{\mathbb{C}: \widehat{Z}_T \in R^{n\times d_e} \to Y' \in [0,\ 1]^{n\times c}\}$，其中 Y' 表示为 n 个样本预测的 c 个类别的概率分布， $\mathbb{C}$ 表示分类器。

为处理标签缺失，我们采用缺失标签指示矩阵 G 调整 BCE 损失函数 [36][48]，得到加权二元交叉熵损失函数，用于衡量预测标签 Y' 与真实标签 Y 之间的差异，并据此指导模型训练：

$$L_c = -\frac{1}{nc}\sum_{i=1}^{n}\sum_{j=1}^{c}\left[Y_{i,j}\log Y'_{i,j} + \left(1 - Y_{i,j}\right)\log\left(1 - Y'_{i,j}\right)\right]G_{i,j} \tag{13}$$

将式（10）与式（13）结合，得到第二阶段的总体目标函数：

$$L_{fc} = L_c + \alpha L_{re} \tag{14}$$

其中， α 为 L_{re} 的惩罚系数，用于平衡分类损失 L_c 与重构损失 L_{re} 的相对重要性。

算法 1　TACVI-Net 的训练过程（原版）。

Algorithm 1 Training process of TACVI-Net

Input: Partial multi-view data $\{X_l\}_{l=1}^m$, accompanied by a missing-view indicator matrix $U \in \{0,1\}^{n\times m}$; Incomplete multi-label matrix $Y \in R^{n\times c}$, accompanied by a missing-label indication matrix $G \in \{0,1\}^{n\times c}$; batch size B; maximum number of iterations T; learning rate l_r; hyper-parameters α and $\{\delta_l\}_{l=1}^m$.
Initialization: Fill in missing elements with 0, initialize TAEncoder $\{\ni_l\}_{l=1}^m$, VSEncoder $\{\Psi_l\}_{l=1}^m$, VSDecoder $\{\Phi_l\}_{l=1}^m$, classifiers $\left\{\complement_l\right\}_{l=1}^m$ and $\mathbb{C}$.
procedure Stage one
for $l = 1$ to m **do**
　calculate $V_l = \ni_l(X_l)$, $Y_l^{'} = \complement_l(V_l)$;
　calculate L_{ta}^l by Eq.(6);
　update $\ni_l$ and $\complement_l$;
end for
end procedure
procedure Stage two
for $t = 1$ to T **do**
　calculate multi-view embedding feature Z_l by Eq.(7);
　calculate fusion feature $\widehat{Z}$ by Eq.(8);
　calculate reconstructed feature $V_l^{'}$ by Eq.(9);
　calculate reconstructed loss L_{re} by Eq.(10);
　complete missing data in X_l with $V_l^{'}$ to get new data T_l;
　calculate multi-view embedding feature Z_T^l by Eq.(11);
　calculate fusion feature $\widehat{Z_T}$ by Eq.(12);
　calculate classification loss L_c by Eq.(13);
　update Ψ_l, Φ_l, $\mathbb{C}$ and σ_l;
end for
end procedure
Output: Trained model

算法 1 中文译文

输入：部分多视图数据 $\{X_l\}_{l=1}^m$，以及缺失视图指示矩阵 $U \in \{0,\ 1\}^{n\times m}$；不完整多标签矩阵 $Y \in R^{n\times c}$，以及缺失标签指示矩阵 $G \in \{0,\ 1\}^{n\times c}$；批大小 B；最大迭代次数 T；学习率 lr；超参数 α 与 $\{\delta_l\}_{l=1}^m$。

初始化：以 0 填补缺失元素；初始化各视图的 TAEncoder、VSEncoder $\{\Psi_l\}_{l=1}^m$、VSDecoder $\{\Phi_l\}_{l=1}^m$、第一阶段各视图分类器及第二阶段分类器 $\mathbb{C}$。TAEncoder 与第一阶段分类器的原始特殊记号见表 1。

过程：第一阶段

1. 对 $l = 1, \ldots, m$ 循环：
   - 计算 V_l，即 TAEncoder 作用于 X_l 的输出；计算 Y'_l，即第一阶段分类器作用于 V_l 的输出。
   - 由式（6）计算 L_{ta}^l。
   - 更新第 l 个视图的 TAEncoder 和第一阶段分类器。
2. 结束循环，结束第一阶段过程。

过程：第二阶段

1. 对 $t = 1, \ldots, T$ 循环：
   - 由式（7）计算多视图嵌入特征 Z_l。
   - 由式（8）计算融合特征 $\widehat{Z}$。
   - 由式（9）计算重构特征 V'_l。
   - 由式（10）计算重构损失 L_{re}。
   - 用 V'_l 补全 X_l 中的缺失数据，得到新数据 T_l。
   - 由式（11）计算多视图嵌入特征 Z_T^l。
   - 由式（12）计算融合特征 $\widehat{Z}_T$。
   - 由式（13）计算分类损失 L_c。
   - 更新 Ψ_l、Φ_l、$\mathbb{C}$ 和 σ_l。
2. 结束循环，结束第二阶段过程。

输出： 训练后的模型。

> **译注（不改动原文公式或算法）：** 原稿式（2）及式（6）的交叉熵项未写通常使用的前置负号，与式（13）的写法不同；本译本按原式保留。原稿协方差使用求和形字形 $\sum_l$，均值／标准差相关矩阵使用花体 $\mathcal{P}_l$、$\mathcal{Q}_l$，也照原样保留。正文第 3.2 节使用统一 δ，算法输入则写 $\{\delta_l\}_{l=1}^m$。算法写“补全 X_l”，而第 3.3 节及表 1 将重构与补全特征置于 V_l 的 d_{l_v} 维空间；此处不擅自消除原稿的记号差异。正文分别以 ϑ_l、λ_l 表示同名编码器 Ψ_l 的网络参数，译文亦保留二者。

4 实验

本节介绍数据集配置、对比方法，并详细分析实验结果。

4.1 实验设置

4.1.1 数据集

依照既有研究 [12][16][23]，我们选择五个广泛使用的多视图多标签数据集验证所提出的模型：Corel5k、Pascal07、ESPGame、IAPRTC12 和 MIRFLICKR。每个数据集均包括六个视图，具体为 GIST、HSV、HUE、SIFT、RGB 和 LAB。表 2 简要汇总了这些数据集，详细说明如下。

表 2　五个多视图多标签数据集的统计信息。

dataset	#sample	#label	#label/#sample
Corel5k	4999	260	3.396
Pascal07	9963	20	1.465
ESPGame	20770	268	4.686
IAPRTC12	19627	291	5.719
MIRFLICKR	25000	38	4.716

表头依次表示：数据集、样本数、标签数、每个样本的标签数。对应数值如下。

数据集	样本数	标签数	每个样本的标签数
Corel5k	4999	260	3.396
Pascal07	9963	20	1.465
ESPGame	20770	268	4.686
IAPRTC12	19627	291	5.719
MIRFLICKR	25000	38	4.716

Corel5k [49]：包含 4,999 幅图像，标注了 260 个类别。每幅图像至少属于其中一个类别。

Pascal07 [50]：是视觉目标检测与识别领域广泛使用的资源，包含 9,963 幅图像及 20 个目标类别，许多图像含有同一目标的多个实例。

ESPGame [51]：包含来自游戏的 20,770 幅图像，每幅图像被标注一个或多个标签。

IAPRTC12 [52]：包含 19,627 个图像样本和 291 个类别，是一个规模较大的图像集合。

MIRFLICKR [53]：由来自 Flickr 网站的 25,000 幅图像构成，共采用 38 个不同标签。

4.1.2 不完整多视图多标签数据的构造

上述五个数据集均具有完整视图和标签，因而不能直接用于评估模型在数据缺失情形下的有效性。遵循 [12][16][23] 的做法，我们将完整数据集预处理成部分多视图不完整多标签数据集。具体而言，在每个视图中随机使 $a\%$ 的样本缺失，同时保证每个样本至少存在于一个视图，由此生成部分多视图数据集。然后，对每个类别随机移除 $b\%$ 的正标签及负标签，以模拟标签缺失。最后，将数据集随机划分为三个子集：70% 用于训练、15% 用于验证、15% 用于测试。视图与标签中的任意缺失元素均替换为 0。

4.1.3 对比方法

实验中，我们将 TACVI-Net 与四个经典模型及五种近期流行方法比较：GLOCAL [54]、CDMM [28]、iMvML [16]、NAIM3L [23]、DICNet [12]、AIMNet [48]、MTD [37]、SIP [39] 和 ATSINet [38]。

由于第 2.2 节未详细讨论 GLOCAL 和 AIMNet，这里对其作简要介绍。GLOCAL 强调从全局与局部角度探索标签相关性。AIMNet 是一种注意力诱导的缺失实例填补技术，尝试通过跨视图联合注意力，在嵌入空间中近似缺失实例的潜在特征。GLOCAL 只能用于单视图的不完整多标签分类；为适配这一特点，我们分别对每个视图独立实验，并选取最佳结果表征其多视图分类性能。此外，由于 CDMM 不具备处理缺失数据的能力，我们采用均值填补策略对其作适当调整。

实验重复进行十次，记录结果的均值与标准差。在优化过程中，选择验证集上表现最佳的模型参数，再于测试集评估，获得最终实验结果。

> 译注：此处原稿写作“iMvML”，其他位置及表 3、表 4 写作“iMvWL”或“iMVWL”；均指向参考文献 [16]，译文保留这些原稿拼写差异。另，第 4.1.1 节原稿数据集列表写作“Pascalo7”（字母 o），按表 2 及后文明确对应的数据集记为 Pascal07。

4.1.4 评价指标

与以往研究 [12][16][23] 一致，我们采用四个常用的多标签分类评价指标评估模型性能：平均精度（AP）、汉明损失（HL）、排序损失（RL），以及接收者操作特征曲线下面积（AUC）。为了使指标更直观地反映模型性能，将 HL 转换为 1-HL，并将 RL 转换为 1-RL。因此，对每个指标而言，数值越高表示性能越好。

4.1.5 实现细节

TACVI-Net 使用 Python 语言和 PyTorch 框架实现。模型训练采用随机梯度下降（SGD）优化器，动量设为 0.9，批大小为 128，学习率为 0.0001。模型运行于 Ubuntu 操作系统，配备 RTX3080Ti GPU。

4.2 实验结果与分析

表 3 给出十种方法在五个数据集上的实验结果，条件为：50% 的实例缺失、50% 的标签缺失，并仅使用 70% 的样本训练。每个结果右下方的数字表示标准差。为了考察视图与标签不同缺失程度对模型性能的影响，我们将一种缺失率固定为 50%，另一种缺失率依次设为 30%、50% 和 70%，结果见图 2。此外，还扩展实验，分别考察视图与标签缺失率取 30%、50% 和 70% 的情况，如图 3 所示。

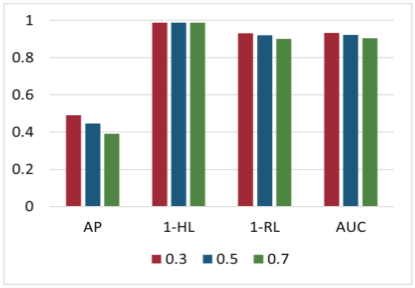
表 3　在五个数据集上，视图缺失率 50%、标签缺失率 50%、训练样本比例 70% 时，十种方法的实验结果。数值越高越好。原表题注称粗体表示最优与次优结果；图像同时保留原表实际存在的粗体及下划线标记。

DATA	METRIC	GLOCAL [54]	CDMM [28]	iMvWL [16]	NAIM3L [23]	DICNet [12]
Corel5k	AP	0.285±0.004	0.354±0.004	0.283±0.008	0.309±0.004	0.381±0.004
	1-HL	0.987±0.000	0.987±0.000	0.978±0.000	0.987±0.000	**0.988±0.000**
	1-RL	0.840±0.003	0.884±0.003	0.865±0.005	0.878±0.002	0.882±0.004
	AUC	0.843±0.003	0.888±0.003	0.868±0.005	0.881±0.002	0.884±0.004
Pascal07	AP	0.496±0.004	0.508±0.005	0.437±0.018	0.488±0.003	0.505±0.012
	1-HL	0.927±0.000	0.931±0.001	0.882±0.004	0.928±0.001	0.929±0.001
	1-RL	0.767±0.004	0.812±0.004	0.736±0.015	0.783±0.001	0.783±0.008
	AUC	0.786±0.003	0.838±0.003	0.767±0.015	0.811±0.001	0.809±0.006
ESPGame	AP	0.221±0.002	0.289±0.003	0.244±0.005	0.246±0.002	0.297±0.002
	1-HL	0.982±0.000	**0.983±0.000**	0.972±0.000	**0.983±0.000**	**0.983±0.000**
	1-RL	0.780±0.004	0.832±0.001	0.808±0.002	0.818±0.002	0.832±0.001
	AUC	0.784±0.004	0.836±0.001	0.813±0.002	0.824±0.002	0.836±0.001
IAPRTC12	AP	0.256±0.002	0.305±0.004	0.237±0.003	0.261±0.001	0.323±0.001
	1-HL	0.980±0.000	**0.981±0.000**	0.969±0.000	0.980±0.000	**0.981±0.000**
	1-RL	0.825±0.002	0.862±0.002	0.833±0.002	0.848±0.001	0.873±0.001
	AUC	0.830±0.001	0.864±0.002	0.835±0.001	0.850±0.001	0.874±0.000
MIRFLICKR	AP	0.537±0.002	0.570±0.002	0.490±0.012	0.551±0.002	0.589±0.005
	1-HL	0.874±0.001	0.886±0.001	0.839±0.002	0.882±0.001	0.888±0.002
	1-RL	0.832±0.001	0.856±0.001	0.803±0.008	0.844±0.001	0.863±0.004
	AUC	0.828±0.001	0.846±0.001	0.787±0.012	0.837±0.001	0.849±0.004

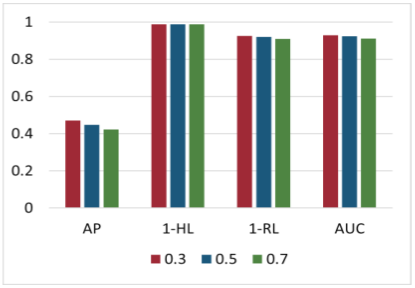
DATA	METRIC	AIMNet [48]	MTD [37]	SIP [39]	ATSINet [38]	TACVI-Net
Corel5k	AP	0.400±0.010	0.415±0.008	0.418±0.009	0.436±0.007	**0.447±0.011**
	1-HL	**0.988±0.000**	**0.988±0.000**	**0.988±0.000**	**0.988±0.000**	**0.988±0.000**
	1-RL	0.902±0.002	0.893±0.004	0.911±0.003	0.917±0.002	**0.921±0.002**
	AUC	0.905±0.003	0.896±0.004	0.913±0.003	0.920±0.002	**0.923±0.002**
Pascal07	AP	0.548±0.008	0.551±0.004	0.555±0.010	0.581±0.009	**0.588±0.009**
	1-HL	0.931±0.001	0.932±0.001	0.931±0.001	0.934±0.001	**0.935±0.001**
	1-RL	0.831±0.004	0.831±0.003	0.830±0.004	0.849±0.005	**0.853±0.005**
	AUC	0.851±0.004	0.851±0.003	0.850±0.005	0.868±0.004	**0.871±0.004**
ESPGame	AP	0.305±0.004	0.306±0.003	0.311±0.004	0.319±0.004	**0.334±0.005**
	1-HL	**0.983±0.000**	**0.983±0.000**	**0.983±0.000**	**0.983±0.000**	**0.983±0.000**
	1-RL	0.846±0.002	0.837±0.002	0.849±0.002	0.859±0.002	**0.863±0.002**
	AUC	0.850±0.002	0.842±0.002	0.853±0.002	0.863±0.002	**0.866±0.001**
IAPRTC12	AP	0.329±0.005	0.332±0.003	0.331±0.006	0.361±0.004	**0.368±0.005**
	1-HL	**0.981±0.000**	**0.981±0.000**	0.980±0.000	**0.981±0.000**	**0.981±0.000**
	1-RL	0.883±0.003	0.875±0.002	0.885±0.003	0.898±0.003	**0.901±0.002**
	AUC	0.885±0.003	0.876±0.001	0.886±0.002	0.899±0.002	**0.901±0.002**
MIRFLICKR	AP	0.602±0.004	0.607±0.004	0.614±0.004	0.631±0.003	**0.633±0.003**
	1-HL	0.890±0.001	0.891±0.001	0.891±0.001	**0.895±0.001**	**0.895±0.001**
	1-RL	0.873±0.002	0.875±0.002	0.877±0.002	0.887±0.001	**0.888±0.001**
	AUC	0.861±0.001	0.862±0.002	0.860±0.003	0.872±0.003	**0.873±0.002**

表 3 为便于阅读，按列拆成上下两部分，并在两部分重复“数据集（DATA）／指标（METRIC）”列；所有模型列、数值、标准差与强调格式均保留。模型依次为 GLOCAL、CDMM、iMvWL、NAIM3L、DICNet、AIMNet、MTD、SIP、ATSINet 和 TACVI-Net。

图 2　Corel5k 在两种情形下的性能：（a）标签缺失率固定为 50%，改变视图缺失比例；（b）视图缺失率固定为 50%，改变标签缺失比例。



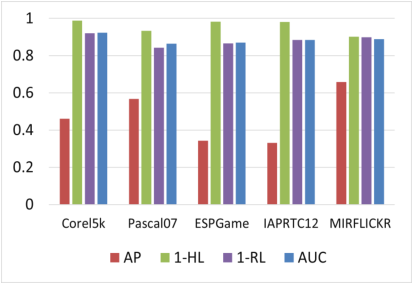
(a) missing-view ratios



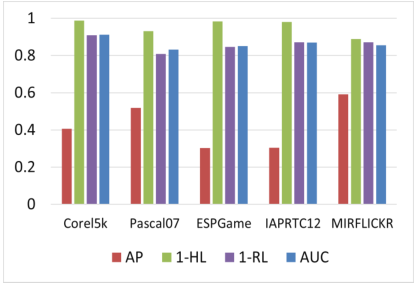
(b) missing-label ratios

图中文字：missing-view ratios＝视图缺失率；missing-label ratios＝标签缺失率。图例 0.3、0.5、0.7 分别对应 30%、50%、70%。横轴为 AP、1-HL、1-RL、AUC，纵轴为指标值。

图 3　在不同视图缺失率和标签缺失率下，所有数据集的更多实验结果。（a）视图缺失率 30%、标签缺失率 70%；（b）视图缺失率 70%、标签缺失率 30%。



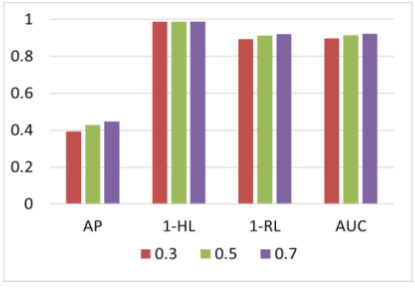
(a) 30% view-missing ratio and 70% label-missing ratio



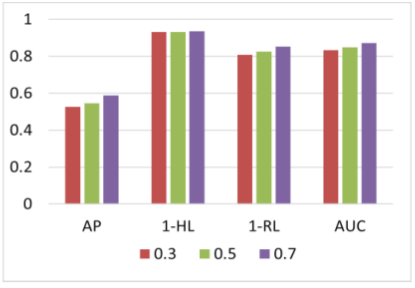
(b) 70% view-missing ratio and 30% label-missing ratio

图中横轴为五个数据集，图例为 AP、1-HL、1-RL、AUC，纵轴为指标值。

图 4　在视图缺失率与标签缺失率均为 50% 时，不同训练样本比例的性能：（a）Corel5k；（b）Pascal07。



(a) Corel5k



(b) Pascal07

图例 0.3、0.5、0.7 表示训练样本比例，横轴为四项评价指标，纵轴为指标值。

根据表 3、图 2、图 3 和图 4，可以直接得到以下关键观察：

- 表 3 的综合分析表明，所提出的方法在大多数选定评价指标上显著优于现有方法，验证了其有效性，并表现出明显优势。此外，DICNet、ATSINet 等方法优于前四种方法，这是因为它们精心设计了深度学习架构，专门应对 PMVIMLC 任务的复杂性。这说明深度学习在揭示该挑战内在复杂性方面具有突出潜力，也体现了其处理复杂问题的能力。
- 图 2 和图 3 提供了有力证据：视图不完整以及标签缺失对模型整体性能指标具有明显负面影响。随着数据集缺失程度增大，这种影响显著加重，凸显了模型对数据不完整性的脆弱性。更重要的是，即使数据缺失比例相同，影响模型有效性的主要障碍仍来自视图信息不足，其影响超过部分标签缺失。这表明采用有效缺失视图恢复策略十分紧迫且重要。
- 图 4 展示了模型在不同训练样本比例下的性能。虽然这些比例对模型效果的影响并不十分突出，但总体趋势是：随着训练样本比例提高，模型性能倾向于改善。因此，实验采用 70% 的训练样本比例是合适的。

虽然 TACVI-Net 主要针对 PMVIMLC，我们也进一步评估了视图与标签均完整时的模型性能，结果见表 4。值得注意的是，模型在 MVMLC 情形下仍保持优越性能，说明本方法不仅适用于 PMVIMLC，也适用于 MVMLC。

表 4　视图与标签完整时，不同方法在五个数据集上的实验结果。数值越高越好；粗体表示最佳结果。

DATA	METRIC	GLOCAL [54]	CDMM [28]	iMvWL [16]	NAIM3L [23]
Corel5k	AP	0.386±0.006	0.489±0.004	0.313±0.005	0.327±0.004
	1-HL	0.987±0.000	0.988±0.000	0.979±0.000	0.987±0.000
	1-RL	0.891±0.002	0.926±0.001	0.884±0.002	0.890±0.002
	AUC	0.895±0.002	0.929±0.001	0.887±0.002	0.893±0.002
Pascal07	AP	0.610±0.005	0.589±0.006	0.468±0.004	0.496±0.003
	1-HL	0.926±0.000	0.931±0.001	0.888±0.001	0.929±0.001
	1-RL	0.866±0.002	0.873±0.003	0.763±0.007	0.795±0.001
	AUC	0.879±0.002	0.893±0.002	0.793±0.005	0.822±0.001
ESPGame	AP	0.264±0.002	0.392±0.002	0.260±0.004	0.251±0.002
	1-HL	0.983±0.000	0.983±0.000	0.972±0.000	0.983±0.000
	1-RL	0.804±0.003	0.875±0.001	0.817±0.001	0.825±0.001
	AUC	0.810±0.003	0.878±0.001	0.822±0.001	0.830±0.002
IAPRTC12	AP	0.330±0.003	0.424±0.003	0.250±0.004	0.267±0.001
	1-HL	0.980±0.000	**0.982±0.000**	0.969±0.000	0.980±0.000
	1-RL	0.871±0.002	0.905±0.001	0.842±0.002	0.854±0.001
	AUC	0.877±0.002	0.906±0.001	0.843±0.002	0.855±0.001
MIRFLICKR	AP	0.643±0.003	0.665±0.003	0.493±0.022	0.555±0.002
	1-HL	0.874±0.001	0.896±0.001	0.840±0.004	0.882±0.001
	1-RL	0.876±0.006	0.894±0.001	0.806±0.015	0.847±0.001
	AUC	0.869±0.005	0.880±0.001	0.789±0.022	0.839±0.001

DATA	METRIC	DICNet [12]	MTD [37]	ATSINet [38]	TACVI-Net
Corel5k	AP	0.509±0.002	0.523±0.003	0.543±0.012	**0.567±0.011**
	1-HL	0.989±0.000	0.989±0.000	0.989±0.000	**0.990±0.000**
	1-RL	0.929±0.001	0.931±0.001	0.949±0.003	**0.953±0.002**
	AUC	0.931±0.000	0.934±0.001	0.951±0.002	**0.955±0.002**
Pascal07	AP	0.608±0.003	0.648±0.006	0.681±0.007	**0.698±0.009**
	1-HL	0.937±0.001	0.940±0.001	0.943±0.006	**0.944±0.001**
	1-RL	0.859±0.003	0.886±0.003	0.904±0.004	**0.910±0.005**
	AUC	0.876±0.002	0.897±0.003	0.914±0.004	**0.918±0.004**
ESPGame	AP	0.391±0.001	0.397±0.002	0.373±0.005	**0.410±0.005**
	1-HL	**0.984±0.000**	**0.984±0.000**	0.983±0.000	**0.984±0.000**
	1-RL	0.871±0.003	0.880±0.001	0.888±0.002	**0.898±0.002**
	AUC	0.874±0.004	0.883±0.001	0.891±0.001	**0.901±0.001**
IAPRTC12	AP	0.418±0.006	0.443±0.003	0.451±0.004	**0.470±0.005**
	1-HL	**0.982±0.000**	**0.982±0.000**	**0.982±0.000**	**0.982±0.000**
	1-RL	0.912±0.003	0.918±0.002	0.930±0.002	**0.934±0.002**
	AUC	0.911±0.003	0.918±0.002	0.931±0.002	**0.935±0.002**
MIRFLICKR	AP	0.659±0.004	0.681±0.004	0.701±0.003	**0.712±0.004**
	1-HL	0.902±0.001	0.906±0.001	0.910±0.001	**0.911±0.001**
	1-RL	0.895±0.001	0.907±0.002	0.916±0.001	**0.920±0.001**
	AUC	0.876±0.002	0.888±0.002	0.898±0.001	**0.901±0.001**

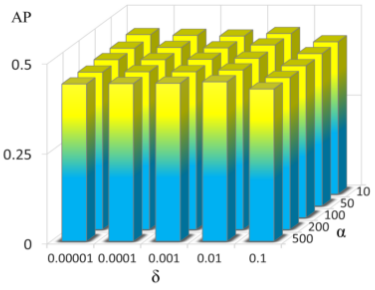
表 4 按列拆成上下两部分，重复数据集与指标列。列标题依次为数据集、指标、GLOCAL、CDMM、iMvWL、NAIM3L、DICNet、MTD、ATSINet、TACVI-Net；保留原表中的下划线与粗体。

4.3 超参数分析

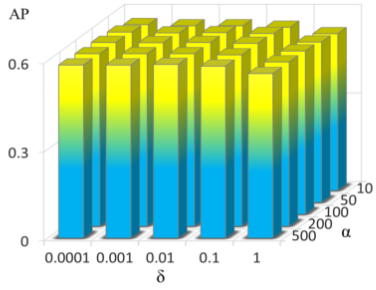
TACVI-Net 有两个需要在训练前设置的超参数：δ 与 α。为研究模型对这两个超参数的敏感性，我们分别在各自取值范围内调整参数，并在视图缺失率 50%、标签缺失率 50%、训练样本比例 70% 的 Corel5k 和 Pascal07 上，根据 AP 指标进行测试。整个实验严格保持其他无关超参数不变，以确保结论准确、实验严谨。

如图 5 所示，在 Corel5k 上，当 $\delta \in \left[10^{-5}, 10^{-2}\right]$、$\alpha \in [10, 50]$ 时；以及在 Pascal07 上，当 $\delta \in \left[10^{-4}, 10^{-2}\right]$、$\alpha \in [10, 500]$ 时，模型均保持相对稳定且令人满意的表现。进一步分析图 5（a）和（b）可见，Corel5k 的最佳超参数组合为 $\delta = 10^{-2}$、$\alpha = 50$；Pascal07 的最佳组合为 $\delta = 10^{-2}$、$\alpha = 500$。

图 5　实例缺失率 50%、标签缺失率 50%、训练样本比例 70% 时的超参数敏感性实验：（a）Corel5k；（b）Pascal07。



(a) Corel5k



(b) Pascal07

图中两个水平轴分别表示 δ 与 α，竖轴表示 AP。原稿图 5 题注中的“Corkl5k”按上下文明确对应的数据集译为 Corel5k。

4.4 消融实验

消融研究在三个有代表性的数据集上评估 TACVI-Net 各模块的性能。实验使用各视图中 50% 的实例，其中另有 50% 的实例存在标签缺失，并将 70% 的样本用于训练。为深入考察各组件的有效性，我们采用两方面的分析。首先，从基础模型中移除两个可分离的损失函数 L_{ta}^{l} 和 L_{re}，建立基线；随后将这些损失逐个重新加入基线，细致考察其对提升模型性能的独立贡献。与此同时，为全面评价数据插补策略的有效性，另进行不采用数据插补的对照实验。这种直接比较突出显示了插补技术对整体模型性能的深刻影响。

表 5　在 Corel5k、Pascal07 和 ESPGame 上，视图缺失率 50%、标签缺失率 50%、训练样本比例 70% 时，TACVI-Net 的消融实验结果。

Backbone	L_{ta}^{l}	L_{re}	Corel5k AP	Corel5k AUC	Pascal07 AP	Pascal07 AUC	ESPGame AP	ESPGame AUC
✓			0.338	0.863	0.533	0.839	0.276	0.827
✓	✓		0.375	0.881	0.545	0.845	0.295	0.839
✓		✓	0.419	0.915	0.571	0.863	0.315	0.858
✓	✓	✓	0.447	0.923	0.588	0.871	0.334	0.866
without imputation			0.392	0.907	0.560	0.855	0.305	0.848

表中文字：Backbone＝骨干网络；without imputation＝不使用插补；勾号表示启用相应组件。各数据集列均依次给出 AP 和 AUC。

相关结果汇总于表 5。可以看出，TACVI-Net 的每个组件都重要且有益，突出体现了各组件对最终分类性能提升的作用。此外，去除插补后，模型指标明显下降，说明插补策略确实能够缓解信息不足的问题。

> 译注：第 4.2 节原稿关于图 3 的正文提及 30%、50%、70%，但所提供的图 3 实际只绘制了题注标明的两种交叉组合；译文同时保留正文与图示，不补画未提供的实验结果。第 4.4 节文字对缺失实例的表述也照原意翻译，实验条件以表 5 原题注明确给出的“视图缺失 50%、标签缺失 50%”并列呈现。

5 结论

本文提出任务增强跨视图插补网络（TACVI-Net），不同于以往借助对缺失信息的假设来绕过不完整视图的方法。TACVI-Net 采用新的两阶段策略，在填补缺失数据的同时限制冗余信息累积，使模型拥有充分而有用的信息，学习视图间的一致性与互补性，从而提升分类性能。五个数据集上的大量实验证实了 TACVI-Net 的优越表现，体现了其应对部分多视图不完整多标签分类挑战的创新能力。

不过，本方法尚未充分考虑不同视图之间的质量差异。因此，未来研究将更深入地探索如何在融合过程中有效评估并利用各视图的质量，从而进一步提升多视图学习的鲁棒性与整体性能。

6 致谢

本研究得到贵州大学基础研究计划（[2024] 04）和贵州省基础研究计划（自然科学）（黔科合基础-[2024]青年 093）支持。

参考文献

以下保留原稿的作者、年份、期刊／会议、卷号、页码、文章号及可见网址，并在原文题名之后提供中文题名。书目信息中的大小写、年份与拼写按所提供原稿保留；不依据外部检索擅自更新。参考文献属于原文内容，不表示本译本另行获取或译出了这些被引文献。

[1] Z. Dou, N. Peng, W. Hou, X. Xie, X. Ma, Learning multi-level topology representation for multi-view clustering with deep non-negative matrix factorization, Neural Networks 182 (2025) 106856.

中文题名：利用深度非负矩阵分解学习多层拓扑表示以进行多视图聚类。

[2] Z. Jiang, T. Luo, X. Liang, Deep incomplete multi-view learning network with insufficient label information, in: Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, 2024, pp. 12919–12927.

中文题名：标签信息不足条件下的深度不完整多视图学习网络。

[3] Z. Lin, L. Ou-Yang, Inferring gene regulatory networks from single-cell gene expression data via deep multi-view contrastive learning, Briefings in Bioinformatics 24 (2023) bbac586.

中文题名：通过深度多视图对比学习从单细胞基因表达数据推断基因调控网络。

[4] L. Li, H. He, Bipartite graph based multi-view clustering, IEEE transactions on knowledge and data engineering 34 (2020) 3111–3125.

中文题名：基于二部图的多视图聚类。

[5] M. Lohith, Y. S. K. Manjunath, M. Eshwarappa, Multimodal biometric person authentication using face, ear and periocular region based on convolution neural networks, International Journal of Image and Graphics 23 (2023) 2350019.

中文题名：基于卷积神经网络，利用人脸、耳部和眼周区域进行多模态生物特征身份认证。

[6] L. Zhao, Y. Xiao, B. Liu, Z. Hao, Multi-view partial label machine, Information Sciences 586 (2022) 310–325.

中文题名：多视图偏标记机。

[7] J. Ravi, R. Narmadha, A systematic literature review on multimodal image fusion models with challenges and future research trends, International Journal of Image and Graphics (2023) 2550039.

中文题名：多模态图像融合模型的系统性文献综述：挑战与未来研究趋势。

[8] L. Li, Z. Wan, H. He, Incomplete multi-view clustering with joint partition and graph learning, IEEE Transactions on Knowledge and Data Engineering 35 (2021) 589–602.

中文题名：联合划分与图学习的不完整多视图聚类。

[9] Y. Sun, L. Ou-Yang, D.-Q. Dai, Wmlrr: A weighted multi-view low rank representation to identify cancer subtypes from multiple types of omics data, IEEE/ACM Transactions on Computational Biology and Bioinformatics 18 (2021) 2891–2897.

中文题名：WMLRR：通过加权多视图低秩表示从多种组学数据识别癌症亚型。

[10] X. Luo, W. Wang, Y. Xu, Z. Lai, X. Jin, B. Zhang, D. Zhang, A deep convolutional neural network for diabetic retinopathy detection via mining local and long-range dependence, CAAI Transactions on Intelligence Technology 9 (2024) 153–166.

中文题名：通过挖掘局部与长程依赖检测糖尿病视网膜病变的深度卷积神经网络。

[11] X. Lu, L. Zhu, Z. Cheng, L. Nie, H. Zhang, Online multi-modal hashing with dynamic query-adaption, in: Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval, 2019, pp. 715–724.

中文题名：具有动态查询适应的在线多模态哈希。

[12] C. Liu, J. Wen, X. Luo, C. Huang, Z. Wu, Y. Xu, Dicnet: Deep instance-level contrastive network for double incomplete multi-view multi-label classification, in: Proceedings of the AAAI conference on artificial intelligence, volume 37, 2023, pp. 8807–8815.

中文题名：DICNet：用于双重不完整多视图多标签分类的深度实例级对比网络。

[13] S. Ou, Z. Xue, Y. Li, M. Liang, Y. Cai, J. Wu, View-category interactive sharing transformer for incomplete multi-view multi-label learning, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024, pp. 27467–27476.

中文题名：用于不完整多视图多标签学习的视图-类别交互共享 Transformer。

[14] S. Chen, R. Wang, J. Lu, A meta-framework for multi-label active learning based on deep reinforcement learning, Neural Networks 162 (2023) 258–270.

中文题名：基于深度强化学习的多标签主动学习元框架。

[15] X. Ma, S. Tan, X. Xie, X. Zhong, J. Deng, Joint multi-label learning and feature extraction for temporal link prediction, Pattern Recognition 121 (2022) 108216.

中文题名：用于时序链接预测的联合多标签学习与特征提取。

[16] Q. Tan, G. Yu, C. Domeniconi, J. Wang, Z. Zhang, Incomplete multi-view weak-label learning., in: Ijcai, 2018, pp. 2703–2709.

中文题名：不完整多视图弱标签学习。

[17] C. Zhang, Z. Yu, Q. Hu, P. Zhu, X. Liu, X. Wang, Latent semantic aware multi-view multi-label classification, in: Proceedings of the AAAI conference on artificial intelligence, volume 32, 2018.

中文题名：感知潜在语义的多视图多标签分类。

[18] S. Sun, D. Zong, Lcbm: a multi-view probabilistic model for multi-label classification, IEEE transactions on pattern analysis and machine intelligence 43 (2020) 2682–2696.

中文题名：LCBM：用于多标签分类的多视图概率模型。

[19] D. Zhao, Q. Gao, Y. Lu, D. Sun, Learning view-specific labels and label-feature dependence maximization for multi-view multi-label classification, Applied Soft Computing 124 (2022) 109071.

中文题名：学习视图特定标签并最大化标签-特征依赖的多视图多标签分类。

[20] L. Zhao, Y. Xiao, B. Liu, Partial label learning with heterogeneous domain adaptation, Neurocomputing 594 (2024) 127822.

中文题名：具有异构域适应的偏标记学习。

[21] Y. Ren, X. Chen, J. Xu, J. Pu, Y. Huang, X. Pu, C. Zhu, X. Zhu, Z. Hao, L. He, A novel federated multi-view clustering method for unaligned and incomplete data fusion, Information Fusion 108 (2024) 102357.

中文题名：用于未对齐与不完整数据融合的新型联邦多视图聚类方法。

[22] J. Pu, C. Cui, X. Chen, Y. Ren, X. Pu, Z. Hao, S. Y. Philip, L. He, Adaptive feature imputation with latent graph for deep incomplete multi-view clustering, in: Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, 2024, pp. 14633–14641.

中文题名：用于深度不完整多视图聚类的潜在图自适应特征插补。

[23] X. Li, S. Chen, A concise yet effective model for non-aligned incomplete multi-view and missing multi-label learning, IEEE Transactions on Pattern Analysis and Machine Intelligence 44 (2021) 5918–5932.

中文题名：面向未对齐不完整多视图与缺失多标签学习的简洁有效模型。

[24] C. Liu, J. Wen, Z. Wu, X. Luo, C. Huang, Y. Xu, Information recovery-driven deep incomplete multiview clustering network, IEEE Transactions on Neural Networks and Learning Systems (2023).

中文题名：信息恢复驱动的深度不完整多视图聚类网络。

[25] J. Xu, Y. Ren, X. Shi, H. T. Shen, X. Zhu, Untie: Clustering analysis with disentanglement in multi-view information fusion, Information Fusion 100 (2023) 101937.

中文题名：Untie：通过多视图信息融合中的解耦进行聚类分析。

[26] X. Wu, Q.-G. Chen, Y. Hu, D. Wang, X. Chang, X. Wang, M.-L. Zhang, Multi-view multi-label learning with view-specific information extraction., in: IJCAI, 2019, pp. 3884–3890.

中文题名：提取视图特定信息的多视图多标签学习。

[27] Y. Zhang, J. Shen, C. Yu, C. Wang, Relation-aware alignment attention network for multi-view multi-label learning, in: Database Systems for Advanced Applications: 26th International Conference, DASFAA 2021, Taipei, Taiwan, April 11–14, 2021, Proceedings, Part II 26, Springer, 2021, pp. 465–482.

中文题名：用于多视图多标签学习的关系感知对齐注意力网络。

[28] D. Zhao, Q. Gao, Y. Lu, D. Sun, Y. Cheng, Consistency and diversity neural network multi-view multi-label learning, Knowledge-Based Systems 218 (2021) 106841.

中文题名：兼顾一致性与多样性的神经网络多视图多标签学习。

[29] G. Yu, Y. Xing, J. Wang, C. Domeniconi, X. Zhang, Multiview multi-instance multilabel active learning, IEEE Transactions on Neural Networks and Learning Systems 33 (2021) 4311–4321.

中文题名：多视图多实例多标签主动学习。

[30] D. Zhao, Q. Gao, Y. Lu, D. Sun, Non-aligned multi-view multi-label classification via learning view-specific labels, IEEE Transactions on Multimedia 25 (2022) 7235–7247.

中文题名：通过学习视图特定标签进行未对齐多视图多标签分类。

[31] G. Lyu, X. Deng, Y. Wu, S. Feng, Beyond shared subspace: A view-specific fusion for multi-view multi-label learning, in: Proceedings of the AAAI Conference on Artificial Intelligence, volume 36, 2022, pp. 7647–7654.

中文题名：超越共享子空间：用于多视图多标签学习的视图特定融合。

[32] J. Yin, W. Zhang, Multi-view multi-label learning with double orders manifold preserving, Applied Intelligence 53 (2023) 14703–14716.

中文题名：保持双阶流形结构的多视图多标签学习。

[33] Y. Xiao, J. Chen, B. Liu, L. Zhao, X. Kong, Z. Hao, A new multi-view multi-label model with privileged information learning, Information Sciences 656 (2024) 119911.

中文题名：具有特权信息学习的新型多视图多标签模型。

[34] C. Zhu, P. Wang, L. Ma, R. Zhou, L. Wei, Global and local multi-view multi-label learning with incomplete views and labels, Neural Computing and Applications 32 (2020) 15007–15028.

中文题名：视图和标签不完整条件下的全局与局部多视图多标签学习。

[35] C. Qu, K. Wang, H. Zhang, G. Yu, C. Domeniconi, Incomplete multi-view multi-label active learning, in: 2021 IEEE International Conference on Data Mining (ICDM), IEEE, 2021, pp. 1294–1299.

中文题名：不完整多视图多标签主动学习。

[36] X. Liu, L. Sun, S. Feng, Incomplete multi-view partial multi-label learning, Applied Intelligence 52 (2022) 3289–3302.

中文题名：不完整多视图偏多标签学习。

[37] C. Liu, J. Wen, Y. Liu, C. Huang, Z. Wu, X. Luo, Y. Xu, Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning, Advances in Neural Information Processing Systems 36 (2024).

中文题名：用于不完整多视图弱多标签学习的掩码双通道解耦框架。

[38] X. Tan, C. Zhao, C. Liu, J. Wen, Z. Tang, A two-stage information extraction network for incomplete multi-view multi-label classification, in: Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, 2024, pp. 15249–15257.

中文题名：用于不完整多视图多标签分类的两阶段信息提取网络。

[39] C. Liu, G. Xu, J. Wen, Y. Liu, C. Huang, Y. Xu, Partial multi-view multi-label classification via semantic invariance learning and prototype modeling, in: Forty-first International Conference on Machine Learning, 2024.

中文题名：通过语义不变性学习与原型建模进行部分多视图多标签分类。

[40] X. Liu, L. Wang, J. Zhang, J. Yin, H. Liu, Global and local structure preservation for feature selection, IEEE transactions on neural networks and learning systems 25 (2013) 1083–1095.

中文题名：用于特征选择的全局与局部结构保持。

[41] N. Tishby, F. C. Pereira, W. Bialek, The information bottleneck method, arXiv preprint physics/0004057 (2000).

中文题名：信息瓶颈方法。

[42] N. Tishby, N. Zaslavsky, Deep learning and the information bottleneck principle, in: 2015 ieee information theory workshop (itw), IEEE, 2015, pp. 1–5.

中文题名：深度学习与信息瓶颈原理。

[43] D. P. Kingma, M. Welling, Auto-encoding variational bayes, arXiv preprint arXiv:1312.6114 (2013).

中文题名：自编码变分贝叶斯。

[44] A. Achille, S. Soatto, Information dropout: Learning optimal representations through noisy computation, IEEE transactions on pattern analysis and machine intelligence 40 (2018) 2897–2905.

中文题名：信息 Dropout：通过含噪计算学习最优表示。

[45] R. A. Amjad, B. C. Geiger, Learning representations for neural network-based classification using the information bottleneck principle, IEEE transactions on pattern analysis and machine intelligence 42 (2019) 2225–2239.

中文题名：利用信息瓶颈原理学习神经网络分类表示。

[46] S. Bang, P. Xie, H. Lee, W. Wu, E. Xing, Explaining a black-box by using a deep variational information bottleneck approach, in: Proceedings of the AAAI conference on artificial intelligence, volume 35, 2021, pp. 11396–11404.

中文题名：使用深度变分信息瓶颈方法解释黑箱。

[47] D. J. Trosten, S. Lokse, R. Jenssen, M. Kampffmeyer, Reconsidering representation alignment for multi-view clustering, in: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021, pp. 1255–1265.

中文题名：重新审视多视图聚类中的表示对齐。

[48] C. Liu, J. Jia, J. Wen, Y. Liu, X. Luo, C. Huang, Y. Xu, Attention-induced embedding imputation for incomplete multi-view partial multi-label classification, in: Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, 2024, pp. 13864–13872.

中文题名：用于不完整多视图偏多标签分类的注意力诱导嵌入插补。

[49] P. Duygulu, K. Barnard, J. F. de Freitas, D. A. Forsyth, Object recognition as machine translation: Learning a lexicon for a fixed image vocabulary, in: Computer Vision—ECCV 2002: 7th European Conference on Computer Vision Copenhagen, Denmark, May 28–31, 2002 Proceedings, Part IV 7, Springer, 2002, pp. 97–112.

中文题名：将目标识别视为机器翻译：为固定图像词汇学习词典。

[50] M. Everingham, L. Van Gool, C. Williams, J. Winn, A. Zisserman, The pascal visual object classes challenge 2007 (voc2007) results http://www. pascal-network. org/challenges, in: VOC/voc2007/workshop/index. html, 2007.

中文题名：PASCAL 视觉目标类别挑战赛 2007（VOC2007）结果。

[51] L. Von Ahn, L. Dabbish, Labeling images with a computer game, in: Proceedings of the SIGCHI conference on Human factors in computing systems, 2004, pp. 319–326.

中文题名：通过电脑游戏标注图像。

[52] M. Grubinger, P. Clough, H. Müller, T. Deselaers, The iapr tc-12 benchmark: A new evaluation resource for visual information systems, in: International workshop ontoImage, volume 2, 2006.

中文题名：IAPR TC-12 基准：面向视觉信息系统的新评估资源。

[53] M. J. Huiskes, M. S. Lew, The mir flickr retrieval evaluation, in: Proceedings of the 1st ACM international conference on Multimedia information retrieval, 2008, pp. 39–43.

中文题名：MIR Flickr 检索评估。

[54] Y. Zhu, J. T. Kwok, Z.-H. Zhou, Multi-label learning with global and local label correlation, IEEE Transactions on Knowledge and Data Engineering 30 (2017) 1081–1094.

中文题名：利用全局与局部标签相关性的多标签学习。