基于拉普拉斯张量秩的张量化多视图多标签分类

非官方中文全文译文 · P173

Qiyu Zhong[1]，Yi Shan[12]，Haobo Wang[3]，Zhen Yang[1]，Gengyu Lyu[1]

[1] 北京工业大学计算机学院，中国；[2] Idealism Beijing Technology Co., Ltd.，北京，中国；[3] 浙江大学软件学院，宁波，中国。通信作者：Gengyu Lyu（lyugengyu@gmail.com）。

原文：Tensorized Multi-View Multi-Label Classification via Laplace Tensor Rank，第42届国际机器学习大会论文集，温哥华，加拿大，PMLR 267，2025。© 2025 作者。官方来源：https://proceedings.mlr.press/v267/zhong25c.html 。论文按 CC BY 4.0 发布；本文件为中文翻译与重新排版，并非作者或出版方认可的版本。图表数值、公式编号与参考文献按原文保留；译者提示与原文明确区分。图1包含第三方网页与游戏画面，保留仅用于呈现原论文的研究示例，不表示其底层素材另获 CC BY 授权。

摘要

在多视图多标签分类（MVML）中，每个对象具有多个异构视图，并带有多个标签。处理此类问题的关键，在于如何捕获跨视图的一致性关联，同时挖掘多标签语义关系。现有 MVML 方法通常采用两个独立的组成部分分别处理这两个问题，忽视了它们潜在的交互关系。为解决这一问题，我们提出一种新的张量化 MVML 方法，称为 TMvML。该方法构建 MVML 张量分类器，在挖掘全面的跨视图特征关联的同时，刻画完整的多标签语义关系。具体而言，我们首先将 MVML 映射矩阵重构成一个 MVML 张量分类器。随后，旋转该张量分类器，并引入低秩张量约束，同时保证视图层面的特征一致性与标签层面的语义共现。为更好地刻画低秩张量结构，我们设计了一种新的拉普拉斯张量秩（Laplace Tensor Rank，LTR），作为张量秩更紧的替代形式，捕获张量空间内的高阶纤维关联。通过上述操作，本方法能够借助一个简洁的 LTR 张量分类器，轻松处理 MVML 的两个关键挑战，同时提取跨视图一致性关联与多标签语义关系。大量实验表明，TMvML 显著优于现有最先进的方法。



图1. MVML 网页分类示例。图内新闻标题：“《黑神话：悟空》在 Steam 上销量突破2000万份”；图内新闻正文：“9月20日——动作角色扮演游戏《黑神话：悟空》发售仅一个月，在数字发行平台 Steam 上的销量已超过2000万份，收入超过9.61亿美元。”文字、图像和视频构成不同视图。这是原论文所用新闻示例的文字翻译，并非本译文独立核实的当前销量或营收数据。

1．引言

多视图多标签学习（MVML）旨在从训练数据中学习，其中每个样本由若干异构特征表示，同时关联多个语义标签（Lyu et al., 2024）。不同于单视图多标签数据，MVML 数据融入来自不同视图的互补信息，因此能够更全面地描述对象。这一特点自然促成了它在众多复杂数据分析任务中的广泛应用（Liu et al., 2024d; Fu et al., 2024）。例如，在新闻网页分类中（图1），一则新闻网页可以由文字、图像与视频特征刻画，并标注“悟空”“销量”和“Steam”等多个类别标签。MVML 提供了一种有效框架，用来学习所需的多标签分类器，将异构特征与对应标签联系起来，并对新网页作出合适的预测。

从 MVML 数据中学习的关键，是如何高效整合异构特征，同时全面刻画所有相关标签。例如，Zhao et al.（2023）提出一种名为 LVSL 的 MVML 方法，通过学习不同视图的贡献权重，并对标签关联矩阵施加低秩约束，寻找跨视图关联与多标签关系。Zhong et al.（2024）提出一种基于非负矩阵分解的 MVML 方法 GNAM，学习不同视图之间的个体信息和公共信息，并利用动态标签关联矩阵提高识别性能。尽管这些 MVML 方法已经取得具有竞争力的性能提升，但它们仍面临两个主要挑战：（1）一方面，这些方法建立在矩阵理论之上，只关注每对视图之间的一阶或二阶关系，未能探索整个视图空间内的高阶关联。（2）另一方面，它们将跨视图一致性关联的提取与多标签语义刻画分离开来，忽略了特征表示和语义表达之间潜在的交互作用，不可避免地导致次优结果。

为解决上述问题，我们提出一种基于拉普拉斯张量秩的张量化多视图多标签分类方法（TMvML），首次尝试利用张量化 MVML 分类器，同时实现高阶特征关联提取与多标签语义关系刻画。具体而言，我们首先将多视图多标签映射矩阵重构成统一的 MVML 张量分类器，以刻画多维数据的结构。然后，旋转张量分类器并引入低秩张量约束，以捕获嵌入映射张量中的高阶信息：沿第三维（特征特定维），比较正面切片的每一行（标签特定）和每一列（视图特定）。为了更好地刻画低秩张量结构，我们设计了

一种新的张量秩近似——拉普拉斯张量秩（LTR），保留较大的奇异值，丢弃较小的奇异值（去除噪声信息），从而获得精确的低秩张量表示。大量实验结果表明，所提出的 TMvML 显著优于其他最先进方法。本文的主要贡献总结如下：

- 提出一种新的张量化 MVML 分类方法 TMvML，首次尝试设计简洁的低秩 MVML 张量分类器，同时挖掘跨视图特征关联并刻画多标签语义关系。
- 为了更好地刻画低秩张量结构，设计新的张量秩近似 LTR，保留较大的奇异值，丢弃较小的奇异值，获得精确的低秩张量表示。
- 大量比较结果与详细实验分析表明，所提出的 TMvML 方法相对于其他最先进方法，可以取得显著更优的性能。

2．相关工作

2.1．多标签学习（MLL）

MLL 关注从具有多个标签的数据中学习，其挑战在于如何完整刻画多标签语义关系（Liu et al., 2024a; Zhang & Zhang, 2024）。现有研究主要采用不同策略探索标签关联，以增强语义表达。例如，Xie & Huang（2022）提出一种名为 PML-NI 的偏多标签学习方法，通过具有低秩性质的迹范数捕获多标签分类器的线性关联。Sun et al.（2022）提出全局-局部标签关联方法（GLC），引入标签系数矩阵，利用多个子空间中的全局标签结构，并使用标签流形正则项捕获局部标签关联。Si et al.（2023）提出高秩高阶方法 HOMI，利用自表示保持标签矩阵的秩不变，并显式表示标签间的高阶关联。

2.2．多视图学习（MVL）

MVL 通过探索隐藏在不同视图中的共识与互补信息，处理具有多种异构视图特征的数据（Jiang et al., 2021; Zhang et al., 2024; Xu et al., 2024; 2023a;b）。依据是否探索多视图表示间的高阶关联，现有 MVL 方法大致可分为非张量方法和基于张量的方法。非张量方法采用矩阵层面的约束，探索单个视图内部或每对视图之间的点对点关系。例如，Cao et al.（2015）对成对亲和矩阵使用 Hilbert-Schmidt 独立性准则（HSIC），使模型结构具有多样性。Jiang et al.（2024）融合特征投影与相似性图，同时进行特征选择和统一图学习。基于张量的方法天然适于利用视图间的高阶关联。Xie et al.（2018）通过最小化张量核范数（TNN），将低秩约束由矩阵层面扩展到张量层面，以捕获高阶一致性。为了进一步增强对低秩张量的刻画，Ji & Feng（2025）引入一种新的张量秩近似——增强张量秩，它对噪声更鲁棒，能够探索不同视图之间的高阶一致性。

2.3．多视图多标签学习（MVML）

MVML 可以视为 MVL 与 MLL 的结合，需要同时处理两者的问题（Lu et al., 2023; Liu et al., 2024c; Wei et al., 2025）。例如，Tan et al.（2021）提出一种名为 ICM2L 的 MVML 方法，通过公共子空间捕获共享模式，利用个体分类器捕获视图特定特征，并引入标签关联矩阵提升识别性能。Lyu et al.（2024）提出标签驱动的视图特定融合方法，直接编码各视图特征以构建统一的多标签分类器，并利用基于 Transformer 的语义感知标签图捕获标签关联。Liu et al.（2024b）提出注意力诱导的 MVML 方法，利用联合注意力获得的置信度给特征加权，并使用弱标签关联矩阵和图注意力网络指导分类。

3．所提出的方法

3.1．符号

形式上，我们以粗体大写字母 $\mathbf{X}$ 表示矩阵，粗体小写字母 $\mathbf{x}$ 表示向量，花体字母表示张量 $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$。对于三阶张量 $\mathcal{X}$，$\mathcal{X}^k$ 表示第 k 个正面切片；$\mathcal{X}(:, i, j)$、$\mathcal{X}(i, :, j)$ 和 $\mathcal{X}(i, j, :)$ 分别表示模1、模2、模3纤维；$\mathcal{X}_f = \mathrm{fft}(\mathcal{X}, [], 3)$ 表示沿张量第三维进行快速傅里叶变换（FFT）。给定 MVML 数据集 $\mathcal{D} = \{(X^v, Y) \mid 1 \le v \le V\}$，其中每个 $X^v = \left[x_1^v, x_2^v, \ldots, x_n^v\right]^\top \in \mathbb{R}^{n \times d_v}$ 表示第 v 个视图下 n 个实例的特征向量，$Y \in \{0, 1\}^{n \times q}$ 为标签矩阵。

3.2．模型构建

本文提出张量化 MVML 方法 TMvML，构建低秩 MVML 张量分类器，在全面提取跨视图特征关联的同时，建模完整的多标签语义关系。为了更好地刻画低秩张量结构，我们开发新的拉普拉斯张量秩（LTR），作为更精确的张量秩替代，使模型能够全面探索多视图与多标签信息，提升性能。

3.2.1．MVML 张量分类器

在传统多视图多标签学习任务中，标签矩阵 Y 通常通过特征空间 X^v 的线性映射 W^v 近似：

$$\min_{W^v} \sum_{v=1}^{V} \| Y - X^v W^v \|_F^2 + \sum_{v=1}^{V} R(W^v). \qquad (1)$$

其中 $W^v = \left[w_1^v, w_2^v, \ldots, w_{d_v}^v\right]^\top$ 为第 v 个视图的映射矩阵。多标签空间中广泛存在标签共现现象（Read et al., 2011），导致特征映射矩阵 W^v 具有线性依赖性。因此，研究者通常将 $R(\cdot)$ 设为低秩约束项，以捕获这一内在性质。

遗憾的是，虽然式（1）可能探索了多标签语义关系，它仍独立处理每个视图，忽略不同视图之间的特征关联。为克服这一局限，我们不仅应保留对各个 W^v 的低秩约束，还需要通过对所有视图施加低秩约束，进一步保证共识原则。受张量能够刻画多维数据低秩结构这一事实启发，我们将其引入式（1），得到张量化 MVML 目标函数：

$$\begin{aligned} \min_{W^v, E, A^v, Z^v} \ & \sum_{v=1}^{V} \| Y - Z^v W^v \|_F^2 + \mathcal{T}(\mathcal{W}) + \| E \|_{2,1} \\ \text{s.t.} \ & \forall\, v, \ X^v = Z^v A^v + E^v, \ A^v (A^v)^T = I, \\ & \mathcal{W} = \Phi\left(W^1, \ldots, W^V\right). \qquad (2) \end{aligned}$$

其中，第 v 个视图的低维表示矩阵 $Z^v \in \mathbb{R}^{n \times k}$ 与基矩阵 $A^v \in \mathbb{R}^{k \times d_v}$ 通过矩阵分解获得。$\mathcal{T}(\cdot)$ 是张量秩或其近似。$E^v \in \mathbb{R}^{n \times d_v}$ 表示重构误差。$\Phi(\cdot)$ 将不同分类器 $W^v \in \mathbb{R}^{k \times q}$ 合并为三阶张量，并将其维度旋转为 $q \times V \times k$，构成张量分类器 $\mathcal{W}$，如图2所示。

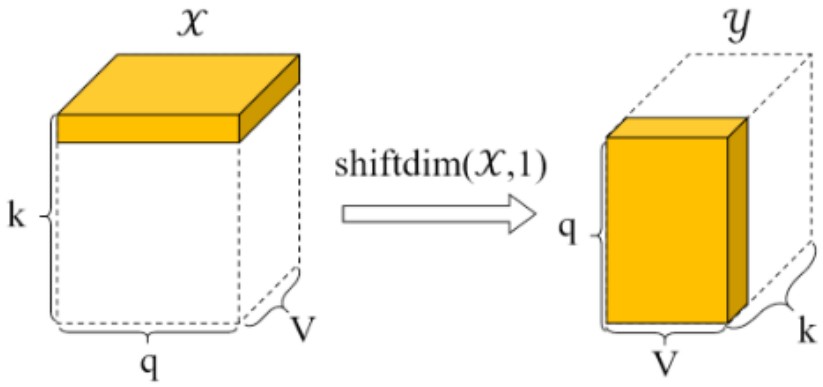


图2. 本方法中旋转后的系数张量。原始维度为 $k\times q\times V$，经旋转后为 $q\times V\times k$。

注1［$\Phi(\cdot)$ **的优越性**］。直接施加张量低秩约束仍不够有效。为在张量空间内更好地同时建模标签层面和视图层面的低秩约束，我们对系数张量 $\mathcal{W}\in\mathbb{R}^{k\times q\times V}$ 进行旋转，将其变换为 $\mathcal{W}\in\mathbb{R}^{q\times V\times k}$，如图2。该旋转将 $q\times V$ 平面重新定位为正面切片，从而通过比较这一平面的每一行（标签特定）和每一列（视图特定），探索不同视图与标签之间的交互。对张量的所有正面切片施加约束后，旋转张量提供更深入的认识，增强了对视图与标签高阶关联的探索。

3.2.2．拉普拉斯张量秩

为更好地刻画低秩张量结构，我们设计一种新的拉普拉斯张量秩（LTR），定义如下。

定义1。给定张量 $\mathcal{W}\in\mathbb{R}^{n_1\times n_2\times n_3}$，其拉普拉斯张量秩定义为:

$$\begin{aligned}\|\mathcal{W}\|_{\mathrm{LTR}} &= \frac{1}{n_3}\sum_{k=1}^{n_3}\|W_f^k\|_{\mathrm{LTR}}\\ &= \frac{1}{n_3}\sum_{k=1}^{n_3}\sum_{i=1}^{h}\left(1-\exp\left(-\frac{e^{\delta}S_f^k(i,\,i)}{\delta}\right)\right).\end{aligned}\tag{3}$$

其中 $0<\delta\le 1$，$h=\min(n_1,\,n_2)$，$\mathcal{S}_f$ 由傅里叶域中的 t-SVD $\mathcal{W}_f=\mathcal{U}_f\mathcal{S}_f\mathcal{V}_f^{\mathsf{T}}$ 得到。

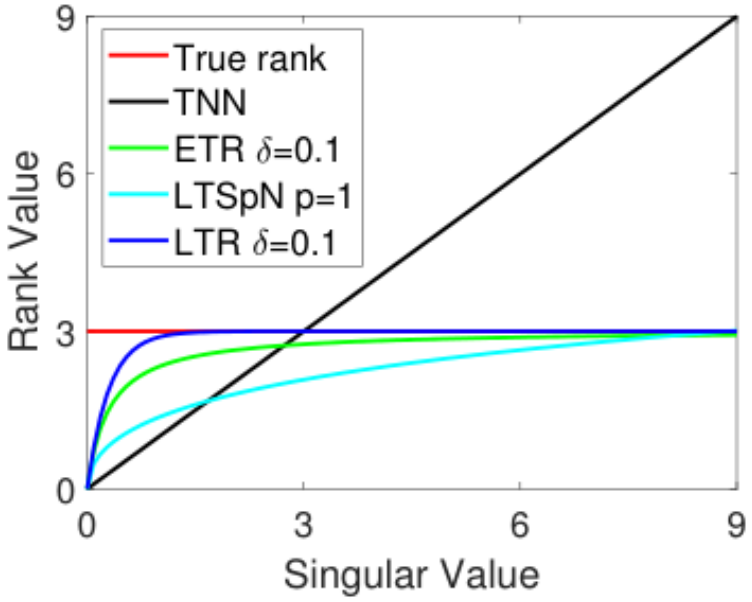


图3. 随奇异值增加，不同方法对真实秩函数的近似比较。纵轴：秩值；横轴：奇异值；图例：真实秩、TNN、ETR（$\delta = 0.1$）、LTSpN（$p = 1$）、LTR（$\delta = 0.1$）。

注2［LTR 的优越性］。LTR 采用的近似函数为 $f_{\mathrm{LTR}}(x) = 1 - \exp\left(-e^{\delta}x/\delta\right)$，受到拉普拉斯函数（Lu et al., 2015）的启发。首先，它满足 $f_{\mathrm{LTR}}(0) = 0$，与真实秩函数一致。我们将 LTR 与其他现有方法比较，即 TNN（Xie et al., 2018）、 LTS_pN （Guo et al., 2022）和 ETR（Ji & Feng, 2025）。图3中，LTR 对秩的近似最好，尤其对于较大的奇异值以及接近零的奇异值。当 $x \to +\infty$ 时， $f_{\mathrm{LTR}}(x) \to 1$，相较 TNN、 LTS_pN 和 ETR，它是更好的真实秩替代。当 $x \to 0$ 时，容易证明：

$$f_{\mathrm{LTR}}(x) \approx \frac{e^{\delta^2}x}{\delta + x} \gg \log(1 + x^p) \gg x.$$

这意味着 LTR 对接近零的奇异值施加更强的惩罚。因此， $\| \mathcal{W} \|_{\mathrm{LTR}}$ 能够稳健地惩罚与噪声有关的小奇异值，保留有价值的大奇异值，并确保 $\mathcal{W}$ 具有空间低秩结构，以捕获高阶纤维关联。

译者提示：上式的指数与渐近关系按原文排印保留；其近似主张未在译文中另行修正。

3.2.3．TMvML 的最终目标函数

结合式（2）和式（3），所提出的 TMvML 表示为：

$$\begin{aligned} \min_{\mathcal{W},E,A^v,Z^v} \ & \sum_{v=1}^{V} \| S(Y - Z^v W^v) \|_F^2 + \alpha \| E \|_{2,1} + \beta \| \mathcal{W} \|_{\mathrm{LTR}} \\ \text{s.t.} \quad & \forall\, v,\ X^v = Z^v A^v + E^v,\ A^v (A^v)^T = I, \\ & \mathcal{W} = \Phi\left(W^1, \ldots, W^V\right),\ E = \left[E^1, \ldots, E^V\right]. \end{aligned} \tag{4}$$

其中 α 与 β 为两个权衡参数。沿误差矩阵的列作纵向拼接，即 $E = \left[E^1; E^2; \ldots; E^V\right]$，能够强制每个视图中 E^v 的列具有联合一致的幅值（Liu et al., 2012）。为了确保多视图表示能够预测已知标签，我们设计筛选矩阵 $S \in \mathbb{R}^{n \times n}$ 选择带标签样本：若第 i 个样本带标签，则 $S_{ii} = 1$，否则 $S_{ii} = 0$。

译者提示：原文式（4）的逗号拼接、此段的分号纵向拼接，以及后文的横向拼接说法并不完全一致，均按原文保留。

3.3．优化

利用交替方向乘子法（ADMM）的原理（Lin et al., 2011），我们引入可分离变量 $\mathcal{G}$，将式（4）转化为无约束拉格朗日优化问题：

$$\begin{aligned} & L(\{W^v\}_{v=1}^V, E^v, \{A^v\}_{v=1}^V, \mathcal{G}, \{Z^v\}_{v=1}^V, B^v, \mathcal{C}) \\ &= \sum_{v=1}^{V} \| S(Y - Z^v W^v) \|_F^2 + \alpha \| E \|_{2,1} + \beta \| \mathcal{G} \|_{\mathrm{LTR}} \\ &\quad + \frac{\rho}{2} \| \mathcal{W} - \mathcal{G} \|_F^2 + \langle \mathcal{C}, \mathcal{W} - \mathcal{G} \rangle \\ &\quad + \sum_{v=1}^{V} \left(\langle B^v, X^v - Z^v A^v - E^v \rangle + \frac{\mu}{2} \| X^v - Z^v A^v - E^v \|_F^2 \right). \end{aligned} \tag{5}$$

其中张量 $\mathcal{C}$ 和矩阵 B^v 为两个拉格朗日乘子，μ 与 ρ 为惩罚参数。接下来，通过以下五个子问题求解式（5）的变量。

Z^v 子问题。利用 S 的对角性质，将问题分为带标签部分和无标签部分求解。对于带标签部分，固定其他变量，将式（5）关于 Z^v 的导数置零，得到：

$$\begin{aligned} & 2Y_l(W^v)^\top - 2Z_l^v W^v (W^v)^\top + B_l A^\top \\ & + \mu \left(X_l^v A^\top - Z_l^v A A^\top - E_l^v A^\top \right) = 0. \end{aligned} \tag{6}$$

其中下标 l 和 u 分别表示对应带标签数据和无标签数据的变量。Z_l^v 的更新规则为：

$$Z_l^v = \frac{2Y_l(W^v)^\top + B_l A^\top + \mu X_l^v A^\top - \mu E_l^v A^\top}{2W^v(W^v)^\top + \mu I}. \tag{7}$$

相应地，对无标签部分，按下式更新 Z_u^v：

$$Z_u^v = \frac{B_u A^\top + \mu X_u^v A^\top - \mu E_u^v A^\top}{\mu I}. \tag{8}$$

得到 Z_l^v 和 Z_u^v 后，所有数据对应的公共表示为 $Z^v = \left[Z_l^v, Z_u^v \right]$。

E^v 子问题。固定其他变量，E^v 子问题表示为：

$$\min_E \frac{\alpha}{\mu} \| E \|_{2,1} + \frac{1}{2} \| E - \widehat{E} \|_F^2. \tag{9}$$

其中 $\widehat{E}$ 由矩阵 $X^v - Z^v A^v + \mu^{-1} B^v$ 沿列横向拼接构成。根据 Liu et al.（2019），可通过 $\ell_{2,1}$ 最小化阈值算子求得解：

$$E_{:,i}^* = \begin{cases} \dfrac{\| \widehat{E}_{:,i} \|_2 - \alpha/\mu}{\| \widehat{E}_{:,i} \|_2} \widehat{E}_{:,i}, & \| \widehat{E}_{:,i} \|_2 > \alpha/\mu, \\ 0, & \text{otherwise.} \end{cases} \tag{10}$$

这里 $\widehat{E}_{:,i}$ 表示 $\widehat{E}$ 的第 i 列；otherwise 意为“其他情况”。

$\mathcal{G}$ **子问题**。固定其他变量，$\mathcal{G}$ 子问题表示为：

$$\min_{\mathcal{G}} \beta \| \mathcal{G} \|_{\mathrm{LTR}} + \frac{\rho}{2} \left\| \mathcal{G} - \left(\mathcal{W} + \frac{\mathcal{C}}{\rho} \right) \right\|_F^2. \tag{11}$$

定理3.1。设 $\mathcal{A} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$，其 t-SVD 为 $\mathcal{A} = \mathcal{U} * \mathcal{S} * \mathcal{V}^T$，且 $\gamma > 0$。拉普拉斯张量秩最小化问题可描述如下：

$$\min_{\mathcal{G}} \gamma \| \mathcal{G} \|_{\mathrm{LTR}} + \frac{1}{2} \| \mathcal{G} - \mathcal{A} \|_F^2. \tag{12}$$

其最优解为：

$$\mathcal{G}^* = \mathcal{U} * \mathrm{ifft}\left(\mathrm{Prox}_{f,\gamma}\left(\mathcal{S}_f \right), [], 3 \right) * \mathcal{V}^{\top}. \tag{13}$$

其中 $\mathrm{ifft}\left(\mathrm{Prox}_{f,\gamma}\left(\mathcal{S}_f \right), [], 3 \right) \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ 是 f-对角张量，$\mathrm{Prox}_{f,\gamma}\left(S_f^k(i,\, i) \right)$ 满足：

$$\underset{x \geq 0}{\mathrm{argmin}} \ \frac{1}{2}\left(x - S_f^k(i,\, i) \right)^2 + \gamma f(x), \tag{14}$$

其中 $f(x) = 1 - \exp\left(- e^{\delta} x / \delta \right)$。

证明。在傅里叶域中，根据 FFT 的线性性及 $\| \mathcal{G} \|_F^2 = n_3^{-1} \| \mathcal{G}_f \|_F^2$，目标函数 $\frac{1}{2} \| \mathcal{G} - \mathcal{A} \|^2 + \gamma \| \mathcal{G} \|_{\mathrm{LTR}}$ 可以重写为：

$$\begin{aligned} & \frac{1}{2} \| \mathcal{G} - \mathcal{A} \|_F^2 + \gamma \| \mathcal{G} \|_{\mathrm{LTR}} \\ &= \frac{1}{2n_3} \| \mathcal{G}_f - \mathcal{A}_f \|_F^2 + \frac{\gamma}{n_3} \sum_{k=1}^{n_3} \| G_f^k \|_{\mathrm{LTR}} \\ &= \frac{1}{n_3} \sum_{k=1}^{n_3} \left[\frac{1}{2} \| G_f^k - A_f^k \|_F^2 + \gamma \| G_f^k \|_{\mathrm{LTR}} \right]. \end{aligned} \tag{15}$$

因此，原张量优化问题可以解耦为 n_3 个独立的矩阵优化问题：

$$\underset{G_f^k}{\mathrm{argmin}} \ \frac{1}{2} \| G_f^k - A_f^k \|_F^2 + \gamma \| G_f^k \|_{\mathrm{LTR}}. \tag{16}$$

这里 $1 \leq k \leq n_3$，A^k 的 SVD 为 $U_f^k S_f^k \left(V_f^k \right)^H$。由于酉变换不改变奇异值，施加于奇异值的 LTR 函数显然是酉不变函数。根据 Kang et al.（2015），式（16）的最优解为：

$$G_f^{*k} = U_f^k \mathrm{Prox}_{f,\gamma}\left(S_f^k \right) \left(V_f^k \right)^H. \tag{17}$$

其中 $\mathrm{Prox}_{f,\gamma}\left(S_f^k(i,\, i) \right) = \mathrm{argmin}_{x \geq 0} \frac{1}{2}\left(x - S_f^k(i,\, i) \right)^2 + \gamma f(x)$，且 $f(x) = 1 - \exp\left(- e^{\delta} x / \delta \right)$。

鉴于定理3.1中的式（14）是凹函数与凸函数的组合，我们可利用 DC 规划（Tao & An, 1997）推导闭式解：

$$\tau^{\text{iter+1}} = \left(S_f^k(i,\ i) - \frac{\beta \cdot \partial f\left(\tau^{\text{iter}}\right)}{\rho} \right)_+ . \qquad (18)$$

其中 $\tau = \text{Prox}_{f,\gamma}\left(S_f^k(i,\ i)\right)$，iter 表示迭代次数。

W^{υ} **子问题**。固定其他变量，将式（5）关于 W^{υ} 的导数置零，得到：

$$W^{\upsilon} = \left(2(Z^{\upsilon})^{\top} S^{\top} S Z^{\upsilon} + \rho I\right)^{-1} \cdot \left(- C^{\upsilon} + 2(Z^{\upsilon})^{\top} S^{\top} S Y + \rho G^{\upsilon}\right). \qquad (19)$$

A^{υ} **子问题**。固定其他变量，A^{υ} 子问题为：

$$A^{\upsilon *} = \underset{A^{\upsilon}(A^{\upsilon})^{\top} = I}{\text{argmin}} \text{Tr}\left((A^{\upsilon})^{\top} M^{\upsilon}\right). \qquad (20)$$

其中 $M^{\upsilon} = (Z^{\upsilon})^{\top}\left(\mu X^{\upsilon} + B^{\upsilon} - \mu E^{\upsilon}\right)$。$A^{\upsilon}$ 的最优解为 $U^{\upsilon}(V^{\upsilon})^{\top}$，$U^{\upsilon}$ 和 V^{υ} 分别为 M^{υ} 的左、右奇异矩阵。最后，拉格朗日乘子与惩罚参数更新如下：

$$\begin{cases} B^{\upsilon} = B^{\upsilon} + \mu\left(X^{\upsilon} - Z^{\upsilon} A^{\upsilon} - E^{\upsilon}\right), \\ \mathcal{C} = \mathcal{C} + \rho\left(\mathcal{W} - \mathcal{G}\right), \\ \mu = \eta_{\mu}\mu, \qquad \rho = \eta_{\rho}\rho. \end{cases} \qquad (21)$$

其中 $\eta_{\mu},\ \eta_{\rho} > 1$ 用来加速收敛。

在整个模型训练过程中，我们首先初始化所需变量，再重复上述步骤，直至算法收敛或达到最大迭代次数。最后，根据 $\widehat{Y} = V^{-1}\sum_{\upsilon=1}^{V} Z_u^{\upsilon} W^{\upsilon}$ 对未见实例作出预测。算法1总结了所提出的 TMvML 方法的完整过程。

算法1. TMvML 的训练过程

输入：训练样本 $\{X^v\}_{v=1}^{V}$；标签矩阵 Y；权衡参数 α 和 β；迭代次数 t；收敛阈值 ε。

输出：预测标签矩阵 $\widehat{Y}$。

第1行：初始化 W^v, E^v, A^v, Z^v, B^v, $\mathcal{G}$, $\mathcal{C}$, μ, ρ。

第3行：由式（4）计算损失 L_0。

第4行：对 $i = 1, 2, \ldots, t$ 开始迭代循环。

第5行：对 $v = 1, 2, \ldots, V$ 开始视图循环。

第6行：由式（7）与式（8）优化 Z^v。

第7行：由式（10）优化 E^v。

第8行：由式（19）优化 W^v。

第9行：由式（20）优化 A^v。

第10行：由式（21）优化 B^v。

第11行：结束视图循环。

第12行：由式（18）优化 $\mathcal{G}$。

第13行：由式（21）优化 $\mathcal{C}$, μ, ρ。

第14行：由式（4）优化 L_i。

第15行：若 $|L_i - L_{i-1}| \leq \varepsilon$，则退出。

第16行：结束迭代循环。

译者提示：原算法行号从1跳到3，没有第2行；上述步骤保留其全部操作。

3.4．计算复杂度分析

TMvML 的计算复杂度主要由第3.3节五个子问题的求解决定，其中 $\{Z^v, E^v, \mathcal{G}, A^v, W^v\}$ 所需的时间复杂度分别为 $O(nk^2 + nkd + nqk)$、$O(nd)$、$O(dqV\log(Vd) + qV^2d)$、$O(nk^2 + nkq)$、$O\left(k^2(d)^2\right)$。d 为多视图数据的最大维数。在实验中，由于 $n \gg q$、$n \gg k$、$n \gg d_{\max}$，TMvML 的总体计算复杂度为 $O(tnk^2)$，其中 t 为迭代次数，在全部数据集上通常不超过50。

4．实验

4.1．实验设置

为验证 TMvML 的有效性，我们在六个广泛使用的 MVML 数据集上开展深入实验分析，包括 Emotions、Yeast、Corel5k、Plant、Human 和 Espgame。数据集可从 Mulan 网站下载：http://mulan.sourceforge.net/datasets-mlc.html 。表1汇总这些数据集的详细特征。

表1. 所用数据集的特征：样本数 n、视图数 v、类别数 q，以及所有视图中的最大／最小维数 $d_{\max}$, $d_{\min}$。

数据集	n	v	q	$d_{\max}$	$d_{\min}$
Emotions	593	2	6	64	8
Plant	978	2	12	400	40
Yeast	2417	2	14	79	24
Human	3106	2	14	400	40
Corel5k	4999	6	260	4096	100
Espgame	20770	6	268	4096	100

比较研究采用六种最先进的 MVML 方法，包括 LrMMC（Liu et al., 2015）、SIMM（Wu et al., 2019）、FIMAN（Wu et al., 2020）、ICM2L（Tan et al., 2021）、ML-BVAE（Fu et al., 2024）和 IMvMLC（Wen et al., 2024）。各方法参数按照相应文献的建议配置。

此外，我们采用多标签学习中五种广泛使用的评价指标衡量算法性能：平均精度（Average Precision，AP）、汉明损失（Hamming Loss，HL）、单错误率（One Error，OE）、排序损失（Ranking Loss，RL）和覆盖率（Coverage，COV）。上述指标的形式化定义见 Gibaja & Ventura（2015）。对每个数据集，随机选择70%的数据用于训练，10%用于验证，20%用于测试。

4.2．实验结果

为确保比较可靠，每种算法运行五次，表2记录指标的平均结果与标准差，最优性能以粗体突出显示。从180项比较（6个数据集 × 6种比较方法 × 5个指标）可以观察到：

- 在所用六个数据集中，TMvML 在 Emotions、Yeast、Plant 和 Human 数据集上优于全部比较方法。在 Espgame 和 Corel5k 数据集上，也分别在86.67%和96.67%的情况下优于其他方法。
- 在五个评价指标中，TMvML 在平均精度、单错误率和覆盖率上，在所有情况下均取得最佳性能。在排序损失和汉明损失上，也分别在94.44%和91.67%的情况下优于其他方法。
- 相比非张量方法（如 ICM2L），TMvML 在全部所用数据集上表现出显著优势。这归功于其张量架构能够利用低秩张量性质，捕获跨视图与标签的高阶关联。
- 相比采用独立组成部分挖掘视图关系与标签关系的方法，TMvML 在所有数据集上均表现优异。我们将这一成功归因于所设计的张量分类器，它能够同时挖掘跨视图高阶关联并刻画多标签语义关系。

表2. 实验结果（均值 ± 标准差）。↑表示越高越好；↓表示越低越好。为保留所有数值、精度及粗体标识，以下按原表完整重现，分为两段；metrics 为“指标”。

	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Emotions	AP ↑	0.763±0.020	0.634±0.043	0.806±0.027	0.572±0.022	0.782±0.021	0.567±0.004	**0.811±0.020**
	HL ↓	0.216±0.011	0.307±0.004	0.231±0.013	0.317±0.012	0.330±0.021	0.342±0.007	**0.210±0.016**
	OE ↓	0.338±0.032	0.501±0.092	0.258±0.042	0.568±0.029	0.303±0.032	0.578±0.016	**0.248±0.041**
	RL ↓	0.161±0.016	0.344±0.047	0.161±0.026	0.423±0.035	0.183±0.019	0.432±0.004	**0.160±0.016**
	COV ↓	2.198±0.094	0.457±0.051	7.796±0.189	3.163±0.242	1.873±0.037	3.091±0.027	**0.300±0.070**
	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Yeast	AP ↑	0.610±0.013	0.712±0.014	0.740±0.007	0.712±0.007	0.738±0.006	0.695±0.001	**0.771±0.008**
	HL ↓	0.255±0.020	0.241±0.011	0.216±0.004	0.232±0.004	0.313±0.007	0.231±0.001	**0.208±0.005**
	OE ↓	0.309±0.028	0.253±0.021	0.257±0.013	0.253±0.012	0.248±0.009	0.264±0.001	**0.215±0.007**
	RL ↓	0.275±0.011	0.218±0.018	0.187±0.005	0.204±0.007	0.180±0.005	0.213±0.001	**0.167±0.007**
	COV ↓	10.32±0.195	7.368±0.293	6.673±0.074	6.706±0.094	6.538±0.094	6.687±0.031	**0.470±0.002**
	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Corel5k	AP ↑	0.215±0.010	0.292±0.004	0.430±0.007	0.286±0.000	0.333±0.008	0.210±0.000	**0.440±0.008**
	HL ↓	0.013±0.000	0.013±0.018	0.018±0.000	0.013±0.000	0.158±0.008	0.020±0.000	**0.013±0.000**
	OE ↓	0.776±0.015	0.614±0.012	0.489±0.017	0.626±0.008	0.613±0.019	0.797±0.000	**0.476±0.013**
	RL ↓	0.173±0.004	0.160±0.005	**0.085±0.000**	0.188±0.008	0.114±0.003	0.174±0.001	0.108±0.003
	COV ↓	96.72±1.300	95.99±3.146	53.94±0.790	108.7±4.792	70.80±2.256	98.383±0.283	**0.266±0.006**

	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Plant	AP ↑	0.464±0.016	0.369±0.029	0.492±0.030	0.505±0.020	0.544±0.017	0.587±0.047	**0.608±0.007**
	HL ↓	0.115±0.002	0.090±0.001	0.238±0.011	0.090±0.001	0.202±0.038	0.920±0.006	**0.087±0.004**
	OE ↓	0.668±0.018	0.809±0.037	0.696±0.031	0.705±0.032	0.652±0.027	0.637±0.064	**0.570±0.006**
	RL ↓	0.371±0.014	0.378±0.025	0.277±0.028	0.238±0.012	0.210±0.015	0.853±0.027	**0.168±0.015**
	COV ↓	4.256±0.147	4.325±0.270	3.216±0.350	2.749±0.141	2.461±0.171	1.715±0.317	**0.169±0.013**
	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Espgame	AP ↑	0.170±0.003	0.304±0.002	0.284±0.002	0.257±0.001	0.273±0.001	0.226±0.000	**0.306±0.001**
	HL ↓	0.028±0.000	0.017±0.000	0.028±0.000	**0.017±0.000**	0.021±0.002	0.027±0.000	0.026±0.000
	OE ↓	0.992±0.001	0.536±0.004	0.628±0.004	0.615±0.010	0.615±0.013	0.692±0.000	**0.506±0.002**
	RL ↓	0.410±0.003	0.164±0.003	0.154±0.002	0.211±0.002	**0.141±0.000**	0.207±0.000	**0.141±0.002**
	COV ↓	210.9±1.020	110.1±1.260	102.8±1.183	136.5 ±1.681	92.21±0.113	143.124±0.012	**0.409±0.008**
	metrics	LrMMC	SIMM	FIMAN	ML-BVAE	IMvMLC	ICM2L	TMVML
Human	AP ↑	0.480±0.006	0.495±0.042	0.583±0.015	0.536±0.010	0.600±0.010	0.603±0.034	**0.631±0.010**
	HL ↓	0.096±0.002	0.085±0.001	0.151±0.002	0.085±0.001	0.112±0.006	0.920±0.002	**0.083±0.003**
	OE ↓	0.673±0.009	0.663±0.034	0.585±0.020	0.659±0.014	0.578±0.015	0.595±0.054	**0.542±0.016**
	RL ↓	0.358±0.006	0.261±0.046	0.186±0.011	0.181±0.008	0.149±0.007	0.879±0.016	**0.136±0.004**
	COV ↓	5.281±0.072	3.797±0.640	2.817±0.095	2.666±0.112	2.271±0.099	1.832±0.211	**0.150±0.003**

> 译者提示：表2中比较方法与 TMvML 的 COV 数值尺度明显不同；部分原始数值（如 ICM2L 的 HL）亦可能令人疑惑。本译文不更改原始数值，也不替作者重新解释实验结论。

为全面评估 TMvML 的优越性，我们使用 Friedman 检验（Demšar, 2006）判断多种算法是否具有相同性能。表3列出各评价指标的 Friedman 统计量 τ_F 以及临界值。根据表3，在0.05显著性水平下，所有评价指标均拒绝“所有算法表现相同”的原假设。因此，我们选择事后 Bonferroni-Dunn 检验（Demšar, 2006），进一步说明这些方法间的差异。图4展示各评价指标的 CD 图，每种算法的平均秩标在坐标轴上。由图4可以清楚观察到，所提出的 TMvML 在所有评价指标上始终排名第一。

表3. 各评价指标的 Friedman 统计量 τ_F。显著性水平 $\alpha = 0.05$ 时，临界值为2.421；方法数7，数据集数6。

评价指标	τ_F
平均精度	8.696
汉明损失	4.805
单错误率	7.714
排序损失	13.129
覆盖率	7.600

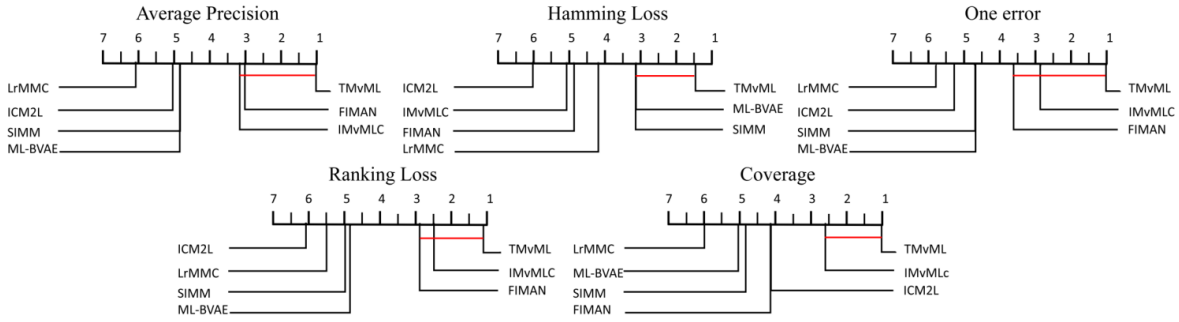


图4. 所提出的 TMvML 与所有其他比较算法在五种评价指标上的 Bonferroni-Dunn 检验比较（显著性水平0.05，CD = 3.213）。五个子图依次为平均精度、汉明损失、单错误率、排序损失与覆盖率。

5．进一步分析

5.1．消融研究

为评估所提出的拉普拉斯张量秩（LTR）的贡献，我们开展额外的消融研究。具体而言，将 TMvML 与两个变体比较：分别以最先进的增强张量秩（ETR）（Ji & Feng, 2025）和传统张量核范数（TNN）（Xie et al., 2018）替换式（4）中的 LTR，记为 TMvML-ETR 和 TMvML-TNN。如图5所示，当参数 δ 在 $\{10^{-4}, \ldots, 1\}$ 范围内变化时，TMvML 在大多数情况下始终优于 TMvML-ETR 和 TMvML-TNN，并在最优设置下取得最佳分类性能。这一现象归因于这些方法处理奇异值的方式不同。LTR 和 ETR 对各个奇异值施加不同惩罚，而 TNN 对所有奇异值采用统一缩放，因而忽视了张量数据中大、小奇异值的差异性信息。特别是，相比 ETR，LTR 将较大奇异值对应的秩近似保留在1，有效刻画低秩张量结构。此外，由于参数 δ 对不同约束的影响方式不同，TMvML-ETR 在少数情况下可能优于 TMvML。

我们还进一步分析参数 δ 对分类结果的影响。如图5所示，δ 具有显著影响。Emotions 在 $\delta = 10^{-4}$ 时取得最佳分类结果，而 Corel5k 在 $\delta = 10^{-1}$ 时达到峰值。主要原因在于，δ 决定奇异值惩罚的强度，不同数据集的奇异值分布又有所不同，因此每个数据集都需要合适的参数，才能使学到的低秩表示张量具有更好的判别能力。

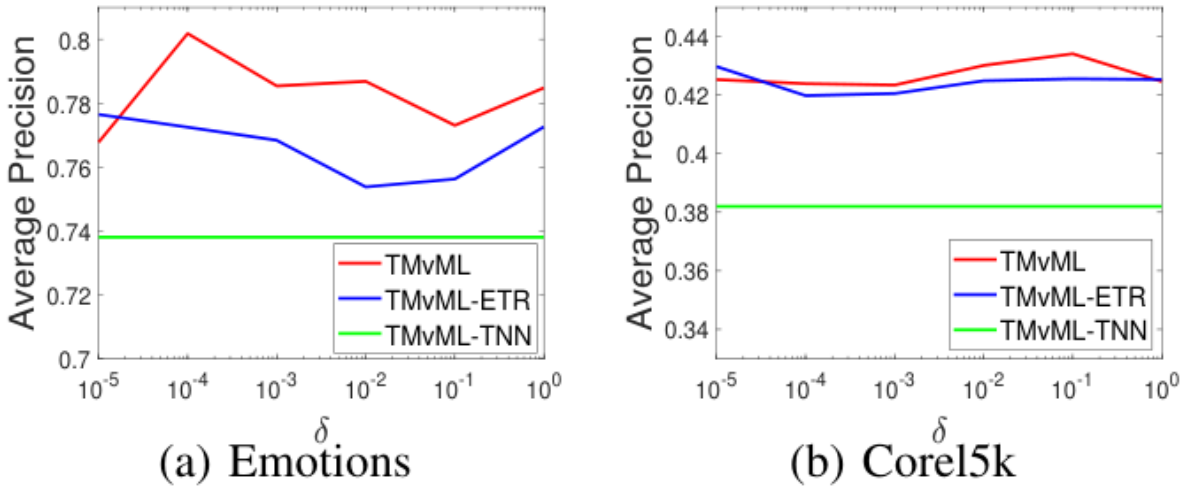


图5. Emotions 与 Corel5k 数据集上，TMvML 和 TMvML-ETR 的平均精度随 δ 变化的情况。图中亦保留 TMvML-TNN 曲线；纵轴为平均精度，横轴为 δ。（a）Emotions；（b）Corel5k。

5.2．参数敏感性

我们研究 TMvML 对两个关键超参数 α 和 β 的敏感性。将 α 在 $\{10^{-1}, 10^{0}, ..., 10^{5}\}$ 内变化，β 在 $\{10^{-5}, 10^{-4}, ..., 10^{0}\}$ 内变化。根据图6，当超参数 α 约为 10^{2} 至 10^{5}，β 约为 10^{-5} 至 10^{0} 时，TMvML 的性能稳定。这一现象表明，所提出的 TMvML 在较宽的参数范围内均具有稳定性能，也从经验上证明其效率与鲁棒性。

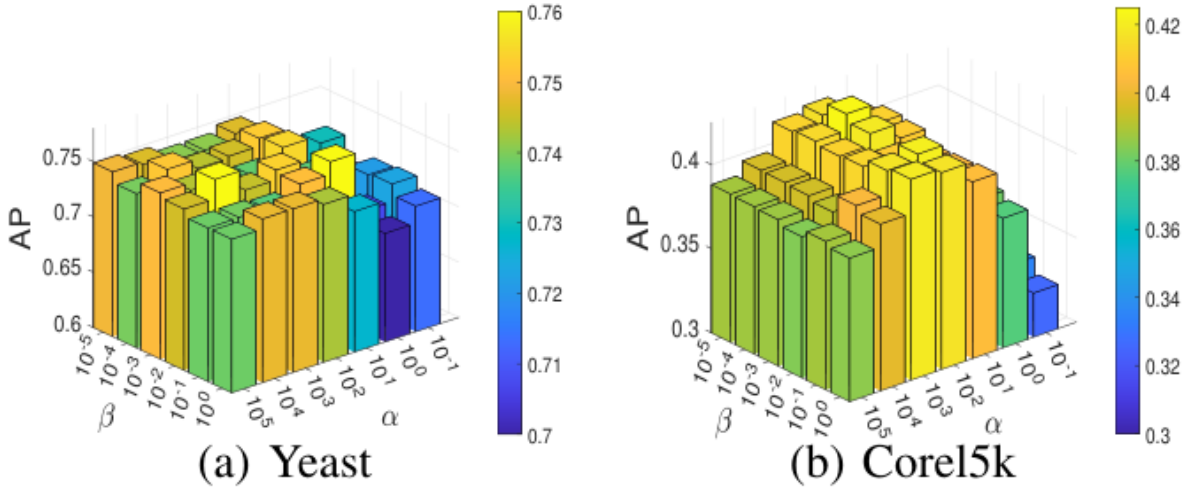


图6. 在 Yeast 和 Corel5k 数据集上，不同 α 与 β 配置下 TMvML 的参数敏感性分析。AP 为平均精度；（a）Yeast；（b）Corel5k。

5.3．收敛性分析

我们进一步分析所提出 TMvML 的收敛性。图7展示 TMvML 在 Emotions 和 Corel5k 数据集上的收敛曲线。由图7可见，目标函数值在迭代开始时急剧下降，随后随着迭代次数增加逐渐稳定。在其他数据集上也观察到相似的收敛结果，从经验上验证了 TMvML 的收敛性。

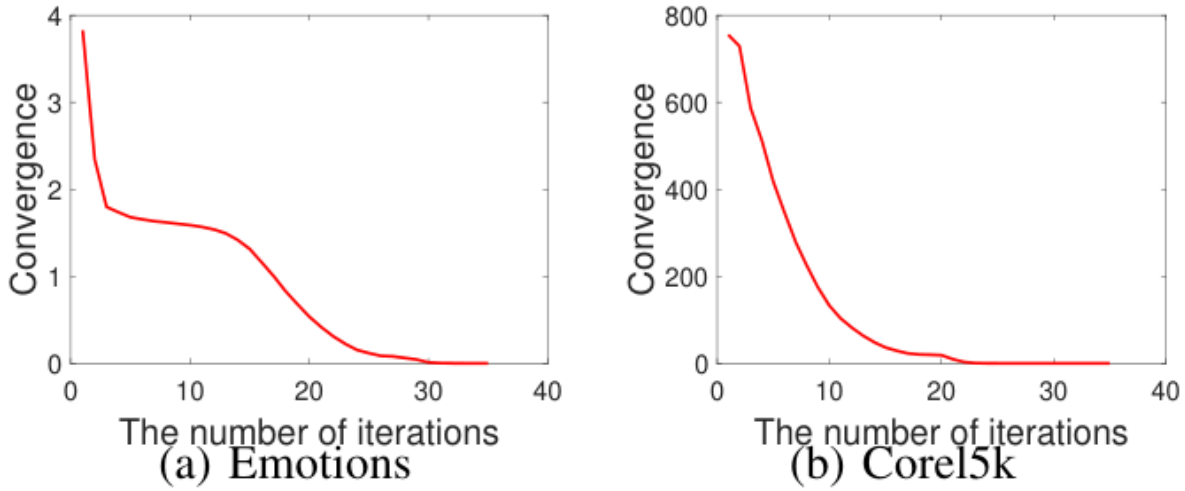


图7. TMvML 在 Emotions 和 Corel5k 数据集上的收敛性分析。横轴：迭代次数；纵轴：收敛曲线所示目标函数值；（a）Emotions；（b）Corel5k。

6．结论

本文提出基于拉普拉斯张量秩的张量化多视图多标签分类方法（TMvML），首次尝试使用张量化低秩 MVML 分类器，同时实现高阶特征关联提取与多标签语义关联刻画。为了更好地刻画张量低秩结构，我们设计新的拉普拉斯张量秩（LTR），作为更紧的张量秩替代，有效捕获高阶纤维关联。大量结果表明，所提出的 TMvML 显著优于其他最先进方法。

影响声明

本文工作的目标是推进机器学习领域的发展。我们的工作可能带来许多潜在的社会影响，但我们认为其中没有需要在这里特别强调的方面。

致谢

本工作得到以下项目支持：国家自然科学基金（编号62306020），北京市科学技术协会青年人才托举工程（编号BYESS2024199），北京市自然科学基金（编号L244009），北京工业大学国家级大学生创新创业训练计划（编号GJDC2025-01-32），国家社会科学基金重大项目（编号22&ZD147），以及国家重点研发计划（编号2023YFB3107100）。

参考文献

以下完整保留原文参考文献的作者、英文题名、刊物、年份、页码及链接，以便准确检索和核对；按原文阅读顺序排列，共41条。

Bartle, R. G. and Sherbert, D. R. Introduction to real analysis. John Wiley & Sons, Inc., 2000.

Cao, X., Zhang, C., Fu, H., Liu, S., and Zhang, H. Diversity-induced multi-view subspace clustering. In IEEE Conference on Computer Vision and Pattern Recognition, pp. 586–594, 2015.

Demšar, J. Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7 (Jan):1–30, 2006.

Fu, K., Du, C., Wang, S., and He, H. Multi-view multi-label fine-grained emotion decoding from human brain activity. IEEE Transactions on Neural Networks and Learning Systems, 35(7):9026–9040, 2024.

Gibaja, E. and Ventura, S. A tutorial on multilabel learning. ACM Computing Surveys, 47(3):1–38, 2015.

Guo, J., Sun, Y., Gao, J., Hu, Y., and Yin, B. Logarithmic schatten-p p norm minimization for tensorial multi-view subspace clustering. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(3):3396–3410, 2022.

Ji, J. and Feng, S. Anchors crash tensor: Efficient and scalable tensorial multi-view subspace clustering. IEEE Transactions on Pattern Analysis and Machine Intelligence, pp. 1–17, 2025.

Jiang, B., Xiang, J., Wu, X., He, W., Hong, L., and Sheng, W. Robust adaptive-weighting multi-view classification. In Proceedings of the 30th ACM International Conference on Information & Knowledge Management, pp. 3117– 3121, 2021.

Jiang, B., Wu, X., Zhou, X., Cohn, A. G., Liu, Y., Sheng, W., and Chen, H. Semi-supervised multi-view feature selection with adaptive graph learning. IEEE Transactions on Neural Networks and Learning Systems, 35(3): 3615–3629, 2024.

Kang, Z., Peng, C., and Cheng, Q. Robust pca via nonconvex rank approximation. In IEEE International Conference on Data Mining, pp. 211–220, 2015.

Lewis, A. S. and Sendov, H. S. Nonsmooth analysis of singular values. part i: Theory. Set-Valued Analysis, 13: 213–241, 2005.

Lin, Z., Chen, M., and Ma, Y. The augmented lagrange multiplier method for exact recovery of corrupted low-rank matrices. arXiv preprint arXiv:1009.5055, 2010.

Lin, Z., Liu, R., and Su, Z. Linearized alternating direction method with adaptive penalty for low-rank representation. Advances in Neural Information Processing Systems, 24, 2011.

Liu, B., Xu, N., Fang, X., and Geng, X. Correlation-induced label prior for semi-supervised multi-label learning. In Forty-first International Conference on Machine Learning, 2024a. URL https://openreview.net/forum?id=IuvpVcGUOB.

Liu, C., Jia, J., Wen, J., Liu, Y., Luo, X., Huang, C., and Xu, Y. Attention-induced embedding imputation for incomplete multi-view partial multi-label classification. In AAAI Conference on Artificial Intelligence, volume 38, pp. 13864–13872, 2024b.

Liu, C., Wen, J., Liu, Y., Huang, C., Wu, Z., Luo, X., and Xu, Y. Masked two-channel decoupling framework for incomplete multi-view weak multi-label learning. Advances in Neural Information Processing Systems, 36, 2024c.

Liu, C., Xu, G., Wen, J., Liu, Y., Huang, C., and Xu, Y. Partial multi-view multi-label classification via semantic invariance learning and prototype modeling. In Forty-first International Conference on Machine Learning, 2024d. URL https://openreview.net/forum?id=5ap1MmUqO6.

Liu, G., Lin, Z., Yan, S., Sun, J., Yu, Y., and Ma, Y. Robust recovery of subspace structures by low-rank representation. IEEE Transactions on Pattern Analysis and Machine Intelligence, 35(1):171–184, 2012.

Liu, M., Luo, Y., Tao, D., Xu, C., and Wen, Y. Low-rank multi-view learning in matrix completion for multi-label image classification. In AAAI Conference on Artificial Intelligence, pp. 2778–2784, 2015.

Liu, Y., Zhang, X., Tang, G., and Wang, D. Multi-view subspace clustering based on tensor schatten-p norm. In IEEE International Conference on Big Data, pp. 5048– 5055, 2019.

Lu, C., Tang, J., Yan, S., and Lin, Z. Nonconvex nonsmooth low rank minimization via iteratively reweighted nuclear norm. IEEE Transactions on Image Processing, 25(2): 829–839, 2015.

Lu, X., Feng, S., Lyu, G., Jin, Y., and Lang, C. Distance-preserving embedding adaptive bipartite graph multi-view learning with application to multi-label classification. ACM Transactions on Knowledge Discovery from Data, 17(2):1–21, 2023.

Lyu, G., Yang, Z., Deng, X., and Feng, S. L-vsm: Label-driven view-specific fusion for multiview multilabel classification. IEEE Transactions on Neural Networks and Learning Systems, 2024.

Read, J., Pfahringer, B., Holmes, G., and Frank, E. Classifier chains for multi-label classification. Machine Learning, 85:333–359, 2011.

Si, C., Jia, Y., Wang, R., Zhang, M.-L., Feng, Y., and Qu, C. Multi-label classification with high-rank and high-order label correlations. IEEE Transactions on Knowledge and Data Engineering, 36(8):4076–4088, 2023.

Sun, L., Feng, S., Liu, J., Lyu, G., and Lang, C. Global-local label correlation for partial multi-label learning. IEEE Transactions on Multimedia, 24:581–593, 2022.

Tan, Q., Yu, G., Wang, J., Domeniconi, C., and Zhang, X. Individuality- and commonality-based multiview multilabel learning. IEEE Transactions on Cybernetics, 51(3): 1716–1727, 2021. doi: 10.1109/TCYB.2019.2950560.

Tao, P. D. and An, L. H. Convex analysis approach to dc programming: theory, algorithms and applications. Acta mathematica vietnamica, 22(1):289–355, 1997.

Wei, H., Deng, Y., Hai, Q., Lin, Y., Yang, Z., and Lyu, G. Multi-view multi-label classification via view-label matching selection. In AAAI Conference on Artificial Intelligence, pp. 1–9, 2025.

Wen, J., Liu, C., Deng, S., Liu, Y., Fei, L., Yan, K., and Xu, Y. Deep double incomplete multi-view multi-label learning with incomplete labels and missing views. IEEE Transactions on Neural Networks and Learning Systems, 35(8):11396–11408, 2024. doi: 10.1109/TNNLS.2023.3260349.

Wu, J.-H., Wu, X., Chen, Q.-G., Hu, Y., and Zhang, M.-L. Feature-induced manifold disambiguation for multi-view partial multi-label learning. In ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pp. 557–565, 2020.

Wu, X., Chen, Q.-G., Hu, Y., Wang, D., Chang, X., Wang, X., and Zhang, M.-L. Multi-view multi-label learning with view-specific information extraction. In International Joint Conference on Artificial Intelligence, pp. 3884–3890, 2019.

Xie, M.-K. and Huang, S.-J. Partial multi-label learning with noisy label identification. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(7):3676– 3687, 2022.

Xie, Y., Tao, D., Zhang, W., Liu, Y., Zhang, L., and Qu, Y. On unifying multi-view self-representations for clustering by tensor multi-rank minimization. International Journal of Computer Vision, 126:1157–1179, 2018.

Xu, J., Chen, S., Ren, Y., Shi, X., Shen, H., Niu, G., and Zhu, X. Self-weighted contrastive learning among multiple views for mitigating representation degeneration. In Advances in Neural Information Processing Systems, volume 36, pp. 1119–1131, 2023a.

Xu, J., Chen, S., Ren, Y., Shi, X., Shen, H., Niu, G., and Zhu, X. Self-weighted contrastive learning among multiple views for mitigating representation degeneration. Advances in neural information processing systems, 36: 1119–1131, 2023b.

Xu, J., Ren, Y., Wang, X., Feng, L., Zhang, Z., Niu, G., and Zhu, X. Investigating and mitigating the side effects of noisy views for self-supervised clustering algorithms in practical multi-view scenarios. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 22957–22966, 2024.

Zhang, C., Fang, Y., Liang, X., Wu, X., Jiang, B., et al. Efficient multi-view unsupervised feature selection with adaptive structure learning and inference. In Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24), pp. 5443–5452, 2024.

Zhang, Y. and Zhang, M.-L. Generalization analysis for multi-label learning. In Forty-first International Conference on Machine Learning, 2024. URL https://openreview.net/forum?id=W4mLp5KuKl.

Zhao, D., Gao, Q., Lu, Y., and Sun, D. Non-aligned multiview multi-label classification via learning view-specific labels. IEEE Transactions on Multimedia, 25:7235–7247, 2023.

Zhong, Q., Lyu, G., and Yang, Z. Align while fusion: A generalized nonaligned multiview multilabel classification method. IEEE Transactions on Neural Networks and Learning Systems, 2024.

附录A．定理3.2的证明

定理A.1。 设 $\{P_k = \left(Z_k^v,\ E_k^v,\ A_k^v,\ W_k^v,\ B_k^v,\ \mathcal{C}_k,\ \mathcal{G}_k\right)\}_{k=0}^{\infty}$ 是算法1生成的序列，则序列 $\{P_k\}$ 满足以下两条性质：

1. $\{P_k\}$ 有界；
2. $\{P_k\}$ 的任意聚点都是算法1的 KKT 点。

为证明定理3.2，我们先引入两个重要引理。

引理A.2（Lin et al., 2010）。 设 H 为实 Hilbert 空间，赋有内积 $\langle\cdot,\ \cdot\rangle$、范数 $\|\cdot\|$ 及其对偶范数 $\|\cdot\|_{\text{dual}}$；设 $y \in \partial \|x\|$，其中 $\partial f(x)$ 为 $f(\cdot)$ 的次梯度。则当 $x \neq 0$ 时，$\|y\|_{\text{dual}} = 1$；当 $x = 0$ 时，$\|y\|_{\text{dual}} \leq 1$。

引理A.3（Lewis & Sendov, 2005）。 假设 $F : \mathbb{R}^{m\times n} \to \mathbb{R}$ 定义为 $F(X) = f \circ \sigma(X) = f\left(\sigma_1(X),\ \ldots,\ \sigma_r(X)\right)$，其中 $X = U\text{Diag}(\sigma(X))V^T$ 为矩阵 $X \in \mathbb{R}^{m\times n}$ 的 SVD，$r = \min(m,\ n)$，且 $f : \mathbb{R}^r \to \mathbb{R}$ 在 $\sigma(X)$ 处可微并绝对对称。那么，$F(X)$ 在 X 处的次微分为：

$$\frac{\partial F(X)}{\partial X} = U\text{Diag}\left(\partial f(\sigma(X))\right)V^T,$$

其中：

$$\partial f(\sigma(X)) = \left(\frac{\partial f\left(\sigma_1(x)\right)}{\partial X},\ \ldots,\ \frac{\partial f\left(\sigma_r(x)\right)}{\partial X}\right).$$

证明。第一部分的证明： 在第 $k+1$ 次迭代中，由 E_{k+1} 的更新规则，应该满足一阶最优性条件：

$$
\begin{aligned}
0 &= \alpha\partial \left\|\mathbf{E}_{k+1}^{v}\right\|_{2,1} \\
&\quad + \mu_k(\mathbf{E}_{k+1}^{v} - (\mathbf{X}^{v} - \mathbf{Z_{k+1}}^{v}\mathbf{A}^{v} + \mathbf{B}_{k}^{v}/\mu_k)) \\
&= \alpha\partial \left\|\mathbf{E}_{k+1}^{v}\right\|_{2,1} - \mathbf{B}_{k+1}^{v},
\end{aligned} \tag{22}
$$

于是得到:

$$\frac{1}{\alpha}\left[B_{k+1}^{v}\right]_{i,j} = \partial \parallel \left[E_{k+1}^{v}\right]_{:,j} \parallel_2.$$

其中 $\left[B_{k+1}^{v}\right]_{i,j}$ 和 $\left[E_{k+1}^{v}\right]_{i,j}$ 分别为 B_{k+1}^{v} 和 E_{k+1}^{v} 的第 j 列。由于 ℓ_2 范数自对偶，根据引理A.2，有 $\parallel \alpha^{-1}\left[B_{k+1}^{v}\right]_{:,j} \parallel_2 \geq 1$。因此序列 $\{B_{k+1}^{v}\}$ 有界。

接下来，证明序列 $\{\mathcal{C}_{k+1}\}$ 有界。根据 $\mathcal{G}$ 的更新规则，一阶最优性条件成立:

$$\partial \parallel \mathcal{G}_{k+1} \parallel_{\mathrm{LTR}} = \mathcal{C}_{t+1}. \tag{23}$$

设 $\mathcal{U} * \mathcal{S} * \mathcal{V}^{T}$ 是张量 $\mathcal{G}$ 的 t-SVD。根据引理A.3与 LTR 的定义，有:

$$
\begin{aligned}
&\|\partial \|\mathcal{G}_{k+1}\|_{\mathrm{LTR}} \|_F^2 \\
&= \left\| \frac{1}{n_3}\mathcal{U} * ifft(\partial(\mathcal{S}_f), [], 3) * \mathcal{V}^{T} \right\|_F^2 \\
&= \frac{1}{n_3^3} \|\partial f(\mathcal{S}_f)\|_F^2 \\
&\leq \frac{1}{n_3^3} \sum_{i=1}^{n_3} \sum_{j=1}^{min(n_1,n_2)} \left[\partial f(\mathcal{S}_f^{v}(j,j))\right]^2 \\
&\leq \frac{e^{2\delta} min(n_1, n_2)}{\delta^2 n_3^2}
\end{aligned} \tag{24}
$$

其中第二个不等式来自 $\partial f(x) \leq e^{\delta}/\delta$， $f_{\mathrm{LTR}}(x) = 1 - \exp\left(-e^{\delta}x/\delta\right)$ 为我们的秩近似函数。因此 $\partial \parallel \mathcal{G}_{k+1} \parallel_{\mathrm{LTR}}$ 有界，同时序列 $\{\mathcal{C}_{k+1}\}$ 也有界。

此外，由求解 TMvML 的算法中的迭代方法，可推导出:

$$
\begin{aligned}
&\mathcal{L}_{\mu_k,\rho_k}(\mathbf{Z}_{k+1}^v,\mathbf{W}_{k+1}^v,\mathbf{E}_{k+1}^v,\mathbf{A}_{k+1}^v,\mathcal{G}_{k+1},\mathbf{B}_k^v,\mathcal{C}_k)\\
&\le \mathcal{L}_{\mu_k,\rho_k}(\mathbf{Z}_k^v,\mathbf{W}_k^v,\mathbf{E}_k^v,\mathbf{A}_k^v,\mathcal{G}_k,\mathbf{B}_k^v,\mathcal{C}_k)\\
&= \mathcal{L}_{\mu_{k-1},\rho_{k-1}}(\mathbf{Z}_k^v,\mathbf{W}_k^v,\mathbf{E}_k^v,\mathbf{A}_k^v,\mathcal{G}_k,\mathbf{B}_{k-1}^v,\mathcal{C}_{k-1})\\
&+ \frac{\rho_k+\rho_{k-1}}{2\rho_{k-1}^2}\left\|\mathcal{C}_k-\mathcal{C}_{k-1}\right\|_F^2\\
&+ \frac{\mu_k+\mu_{k-1}}{2\mu_{k-1}^2}\sum_{v=1}^{V}\left\|\mathbf{B}_k^v-\mathbf{B}_{k-1}^v\right\|_F^2,
\end{aligned}
\tag{25}
$$

因此，将式（25）两边从 $k=1$ 至 n 求和：

$$
\begin{aligned}
&\mathcal{L}_{\mu_k,\rho_k}(\mathbf{Z}_{k+1}^v,\mathbf{W}_{k+1}^v,\mathbf{E}_{k+1}^v,\mathbf{A}_{k+1}^v,\mathcal{G}_{k+1},\mathbf{B}_k^v,\mathcal{C}_k)\\
&\le \mathcal{L}_{\mu_0,\rho_0}(\mathbf{Z}_1^v,\mathbf{W}_1^v,\mathbf{E}_1^v,\mathbf{A}_1^v,\mathcal{G}_1,\mathbf{B}_0^v,\mathcal{C}_0)\\
&+ \sum_{k=1}^{n}\frac{\rho_k+\rho_{k-1}}{2\rho_{k-1}^2}\left\|\mathcal{C}_k-\mathcal{C}_{k-1}\right\|_F^2\\
&+ \sum_{k=1}^{n}\left(\frac{\mu_k+\mu_{k-1}}{2\mu_{k-1}^2}\sum_{v=1}^{V}\left\|\mathbf{B}_k^v-\mathbf{B}_{k-1}^v\right\|_F^2\right)
\end{aligned}
\tag{26}
$$

注意到：

$$
\sum_{k=1}^{n}\frac{\mu_k+\mu_{k+1}}{2\mu_{k-1}^2}<\infty,\quad \sum_{k=1}^{n}\frac{\rho_k+\rho_{k+1}}{2\rho_{k-1}^2}<\infty
\tag{27}
$$

注意，$L_{\mu_0,\rho_0}(Z_1^v,\ W_1^v,\ E_1^v,\ A_1^v,\ \mathcal{G}_1,\ B_0^v,\ \mathcal{C}_0)$ 有限，序列 $\{B_k^v\}$、$\{\mathcal{C}_k\}$ 以及 $\sum_{k=1}^{n}(\mu_k+\mu_{k+1})/\left(2\mu_{k-1}^2\right)$ 和 $\sum_{k=1}^{n}(\rho_k+\rho_{k+1})/\left(2\rho_{k-1}^2\right)$ 均有界。因此 $L_{\mu_k,\rho_k}(Z_{k+1}^v,\ W_{k+1}^v,\ E_{k+1}^v,\ A_{k+1}^v,\ \mathcal{G}_{k+1},\ B_k^v,\ \mathcal{C}_k)$ 有界。

注意：

$$
\begin{aligned}
&\mathcal{L}_{\mu_k,\rho_k}(\mathbf{Z}_{k+1}^v,\mathbf{W}_{k+1}^v,\mathbf{E}_{k+1}^v,\mathbf{A}_{k+1}^v,\mathcal{G}_{k+1},\mathbf{B}_k^v,\mathcal{C}_k)\\
&=\alpha\left\|\mathbf{E}_{k+1}\right\|_{2,1}+\beta\|\mathcal{G}_{k+1}\|_{\mathrm{LTR}}+\sum_{v=1}^{V}\left\|\mathbf{S}\left(\mathbf{Y}-\mathbf{Z}_{k+1}^v\mathbf{W}_{k+1}^v\right)\right\|_{\mathrm{F}}^2\\
&+\sum_{v=1}^{V}\left((\mathbf{B}_k^v,\mathbf{X}^v-\mathbf{Z}_{k+1}^v\mathbf{A}_{k+1}^v-\mathbf{E}_{k+1}^v)+\frac{\mu_k}{2}\left\|\mathbf{X}^v-\mathbf{Z}_{k+1}^v\mathbf{A}_{k+1}^v-\mathbf{E}_{k+1}^v\right\|_F^2\right)\\
&+\langle\mathcal{C}_k,\mathcal{W}_{k+1}-\mathcal{G}_{k+1}\rangle+\frac{\rho_k}{2}\left\|\mathcal{W}_{k+1}-\mathcal{G}_{k+1}\right\|_F^2,
\end{aligned}
\tag{28}
$$

式（28）的每一项均非负。由于 $L_{\mu_k,\rho_k}(Z_{k+1}^{\upsilon}, W_{k+1}^{\upsilon}, E_{k+1}^{\upsilon}, A_{k+1}^{\upsilon}, \mathcal{G}_{k+1}, B_k^{\upsilon}, \mathcal{C}_k)$ 有界，可以推导式（28）中的每一项都有界。因此，$\| \mathcal{G}_{k+1} \|_{\mathrm{LTR}}$ 的有界性意味着 $\mathcal{G}_{k+1}$ 的所有奇异值都有界。此外，根据下式：

$$\|\mathcal{G}_{k+1}\|_F^2 = \frac{1}{n_3}\|\mathcal{G}_{f,k+1}\|_F^2 = \frac{1}{n_3}\sum_{i=1}^{n_3}\sum_{j=1}^{min(n_1,n_2)}\left(\mathcal{S}_f^i(j,j)\right)^2, \tag{29}$$

可以推出序列 $\{\mathcal{G}_{k+1}\}$ 有界，随后很容易证明 $\{Z_{k+1}\}$ 与 $\{A_{k+1}\}$ 的有界性。因此，可得算法1所生成序列 $\left(Z_k^{\upsilon}, E_k^{\upsilon}, A_k^{\upsilon}, W_k^{\upsilon}, B_k^{\upsilon}, \mathcal{C}_k, \mathcal{G}_k\right)_{k=0}^{\infty}$ 的结论。

2）第二部分的证明： 根据 Weierstrass-Bolzano 定理（Bartle & Sherbert, 2000），序列 $\{P_k\}_{k=1}^{\infty}$ 至少存在一个聚点，将其中一个记为 P^*。则有：

$$\lim_{k\to\infty}\left(Z_k^{\upsilon}, E_k^{\upsilon}, A_k^{\upsilon}, W_k^{\upsilon}, B_k^{\upsilon}, \mathcal{C}_k, \mathcal{G}_k\right) = \left(Z_*^{\upsilon}, E_*^{\upsilon}, A_*^{\upsilon}, W_*^{\upsilon}, B_*^{\upsilon}, \mathcal{C}_*, \mathcal{G}_*\right).$$

由 $\mathcal{C}$ 和 B^{υ} 的更新规则，有以下等式：

$$X^{\upsilon} - Z_{k+1}^{\upsilon}A_{K+1}^{\upsilon} - E_{k+1}^{\upsilon} = \left(B_{k+1}^{\upsilon} - B_k^{\upsilon}\right)/\mu_t,$$

$$\mathcal{W}_{k+1} - \mathcal{G}_{k+1} = \left(\mathcal{C}_{k+1} - \mathcal{C}_k\right)/\rho_t.$$

由序列 $\{\mathcal{C}_k\}$ 和 $\{B_k^{\upsilon}\}$ 的有界性，以及 $\lim_{k\to\infty}\mu_k = \infty$，有：

$$\lim_{k\to\infty}\left(X^{\upsilon} - Z_{k+1}^{\upsilon}A_{K+1}^{\upsilon} - E_{k+1}^{\upsilon}\right) = \lim_{k\to\infty}\left(B_{k+1}^{\upsilon} - B_k^{\upsilon}\right)/\mu_t = 0,$$

$$\lim_{k\to\infty}\left(\mathcal{W}_{k+1} - \mathcal{G}_{k+1}\right) = \lim_{k\to\infty}\left(\mathcal{C}_{k+1} - \mathcal{C}_k\right)/\rho_t = 0.$$

于是可得：

$$X^{\upsilon} - Z_*^{\upsilon}A_*^{\upsilon} - E_*^{\upsilon} = 0, \qquad \mathcal{W}_* - \mathcal{G}_* = 0.$$

此外，由 E_{k+1}^{υ} 和 $\mathcal{G}_{k+1}$ 的一阶最优性条件，可推得：

$$0 = \alpha\partial\ \| E_{k+1}^{\upsilon} \|_{2,1} - B_{k+1}^{\upsilon} \quad \Rightarrow \quad B_*^{\upsilon} = \alpha\partial\ \| E_*^{\upsilon} \|_{2,1},$$

$$0 = \beta\partial\ \| \mathcal{G}_{k+1} \|_{\mathrm{LTR}} - \mathcal{C}_{k+1} \quad \Rightarrow \quad \mathcal{C}_* = \beta\partial\ \| \mathcal{G}_* \|_{\mathrm{LTR}}.$$

因此，求解 TMvML 的算法生成的序列 $\{P_k\}_{k=1}^{\infty}$ 的聚点 P^* 满足 KKT 条件。

> 译者提示（不属于原论文）：本附录标题引用“定理3.2”，但正文中只标出了定理3.1。原文有若干记号及论证疑点：引理A.2之后使用“⩾1”推出有界；式（23）使用 $t+1$ 且未写 β；式（27）下标与前两式不一致；式（28）的乘子内积项不必非负；有界且饱和的 LTR 函数值本身不能推出奇异值有界；从存在聚点直接写出全序列极限还需要额外条件。原文中 K, k, t 等下标混用亦照录。以上公式与推理忠实保留原文，并不表示译者验证或修正了证明。

附录B．更多实验结果

本节给出全部六个具有挑战性的数据集上的实验结果，包括张量旋转和拉普拉斯张量秩（LTR）的消融研究。

LTR 的消融研究： 表4报告在六个数据集上开展的 LTR 消融实验结果。具体而言，表4比较 TMvML 与其变体 TMvML-TNN，后者用张量核范数（TNN）（Xie et al., 2018）替代 LTR 来捕获低秩张量结构。实验结果表明，TMvML 在所有数据集上始终优于 TMvML-TNN。这一有力证据表明，在对多视图多标签学习任务中的复杂高阶关联建模时，所提出的 LTR 比传统 TNN 更有效。

表4. TMvML 与 TMvML-TNN 的性能。AP 为平均精度，Cov 为覆盖率。

		Emotions	Yeast	Corel5k	Plant	Espgame	Human
TMvML	AP	**0.811**	**0.771**	**0.440**	**0.608**	**0.306**	**0.631**
TMvML-TNN	AP	0.738	0.747	0.382	0.601	0.270	0.621
TMvML	Cov	**0.300**	**0.460**	**0.266**	**0.169**	**0.409**	**0.150**
TMvML-TNN	Cov	0.344	0.467	0.279	0.171	0.452	0.162

张量旋转的消融研究： 表5报告在六个数据集上开展的张量旋转消融实验结果。具体而言，表5将 TMvML 与去掉旋转操作的变体（记为 TMvML-NoRot）比较。结果表明，TMvML 在所有数据集上始终优于 TMvML-NoRot。这一显著的性能差距突出说明，旋转对于同时提取跨视图一致性关联与多标签语义关系发挥着关键作用。

表5. TMvML 与 TMvML-NoRot 的性能。AP 为平均精度，Cov 为覆盖率。

		Emotions	Yeast	Corel5k	Plant	Espgame	Human
TMvML	AP	**0.811**	**0.771**	**0.440**	**0.608**	**0.306**	**0.631**
TMvML-NoRot	AP	0.628	0.733	0.231	0.511	0.191	0.532
TMvML	Cov	**0.300**	**0.470**	**0.266**	**0.169**	**0.409**	**0.150**
TMvML-NoRot	Cov	0.473	0.485	0.350	0.210	0.498	0.185

> 译者提示：表4的 TMvML 在 Yeast 上 Cov 为0.460，而表5及表2为0.470；原始差异予以保留。