基于核均值嵌入的神经网络可训练校准度量

非官方中文全文译文 · P163 · 正文及官方补充材料

Aviral Kumar[1] · Sunita Sarawagi[1] · Ujjwal Jain[1]

[1] 印度孟买，印度理工学院孟买分校，计算机科学与工程系。通讯作者：Aviral Kumar aviralkumar2907@gmail.com。

原文：Trainable Calibration Measures For Neural Networks From Kernel Mean Embeddings。第35届国际机器学习大会论文集，瑞典斯德哥尔摩，PMLR 80:2805–2814，2018。版权 © 2018 作者。

原始出版页面：https://proceedings.mlr.press/v80/kumar18a.html。依据 PMLR 出版协议的 Creative Commons Attribution 4.0 International（CC BY 4.0）授权制作；许可：https://creativecommons.org/licenses/by/4.0/。本译文将英文翻译为中文并重新排版，公式和图表采用原版裁图以精确保留符号与数值，配以完整中文说明；非作者或出版方认可的官方译本。正文10页、官方补充材料2页均纳入。原文中存在的符号或表述不一致按原样保留，译者说明明确区分。

摘要

最近的研究发现，现代神经网络的校准效果不佳，主要表现为过度自信。熵惩罚和温度平滑等方法通过压低置信度来改善校准，但这样做也会损害许多本来就应当具有高置信度的预测。我们提出一种更有原则的修正方法，在训练期间最小化一个显式的校准误差。我们提出 MMCE，一种基于再生核希尔伯特空间（RKHS）核的校准度量；它可以与负似然损失一起高效训练，而无需仔细调整超参数。从理论上看，MMCE 也是一种合理的校准度量：它在完美校准时达到最小值，其有限样本估计具有一致性和快速收敛率。针对多种网络架构进行的大量实验表明，MMCE 是一种快速、稳定且准确的方法，可以在最大限度保留高置信度预测数量的同时，最小化校准误差指标。

1. 引言

最近，Guo et al. (2017) 得出了一个令人惊讶的观察：用负对数似然训练、准确率很高的深度神经网络，其预测置信概率的校准效果却很差；这不同于采用相同目标训练的传统模型（Niculescu-Mizil & Caruana, 2005）。校准效果差意味着，即使网络以超过0.99的置信度给出预测（而它常常如此！），预测标签正确的比例也可能远低于99%。这种缺乏校准的现象，在医疗诊断（Caruana et al., 2015; Crowson et al., 2016; Jiang et al., 2012）、自动驾驶车辆的障碍物检测（Bojarski et al., 2016），以及其他将学习模型接入决策系统或由人解释模型输出的应用中，都是严重的问题。此外，校准还有助于检测样本分布外的实例（Hendrycks & Gimpel, 2017; Lee et al., 2018; Liang et al., 2018），并且对公平性也有用（Pleiss et al., 2017）。

现代神经网络校准不佳的一个主要原因，是其容量很大，从而负对数似然（NLL）会发生过拟合，而0/1误差却不发生过拟合（Zhang et al., 2017）。这表现为预测过度自信。最近，Guo et al. (2017) 实验研究了几种在训练结束后应用的已知校准修正方法，发现对 logits 进行简单的温度缩放最有效。第二

种选择是在训练期间就考虑校准。Pereyra et al. (2017) 提议向 NLL 目标中加入熵正则项，以抑制过度自信。我们表明，温度缩放和熵正则化虽然都能够降低总体校准误差，但在这个过程中也不必要地压低了合理的高置信度预测。第三类方法通过变分贝叶斯网络（Louizos & Welling, 2017），或者其委员会式对应方法（Lakshminarayanan et al., 2017），建模完整的预测不确定性；然而这些方法的训练过于消耗资源。

我们提出一种实用且有原则的修正方法：在训练期间，将校准误差和分类误差一起最小化。我们利用通用核所诱导的 RKHS 函数的能力，将校准误差表示为一个可处理的积分概率度量，称为**最大均值校准误差（Maximum Mean Calibration Error，MMCE）**。这类似于使用 RKHS 核的 MMD 来表示两个概率分布之间距离的方式（Muandet et al., 2017; Li et al., 2015）。我们表明，MMCE 是校准的一致估计量，并以 $1/\sqrt{m}$ 的速率收敛到其期望值。此外，MMCE 很容易在现有的小批量梯度下降框架中进行优化。

覆盖七个数据集的实验表明，使用 MMCE 训练能够显著降低校准误差，同时适度提高准确率。MMCE 实现这一点时，并不压制高置信度预测。例如，在 CIFAR-10 上，MMCE 以99.7%的置信度给出72%的预测，而温度缩放只以99.6%的置信度给出40%的预测，熵缩放则只以96.9%的置信度给出7%的预测。在医疗诊断等应用中，这一点非常重要，因为只有高置信度预测才能节省人工筛查的成本。这项研究说明，设计良好的训练方法能够同时改善校准和准确率，而不必严重减少高置信度预测的数量。

2. 问题设定

我们关注改善多分类模型的校准。令 $\mathcal{Y} = \{1, 2, \ldots, K\}$ 表示类别标签集合，$\mathcal{X}$ 表示输入空间。令 $N_\theta(y \mid x)$ 表示神经网络对输入 $x \in \mathcal{X}$ 预测的概率分布，θ 表示网络参数。对于真实标签为 y_i 的实例 x_i，网络预测标签 $\widehat{y_i} = \operatorname{argmax}_{y \in \mathcal{Y}} N_\theta(y \mid x_i)$。当 $\widehat{y_i} = y_i$ 时，预测的正确性分数为 $c_i = 1$，否则为0；其置信度分数为 $r_i = N_\theta(\widehat{y_i} \mid x_i)$。如果在所有 $(x_i, y_i) \in \mathcal{D}$ 且 $r_i = \alpha$ 的实例中，$c_i = 1$ 的概率为 α，那么模型 $N_\theta(y \mid x)$ 在数据分布 $\mathcal{D}$ 上是良好校准的。例如，从 $\mathcal{D}$ 中抽取一个样本，如果有100个实例以0.7的置信度被预测，那么当 $N_\theta(y \mid x)$ 在 $\mathcal{D}$ 上良好校准时，我们期望其中70个预测正确。更形式化地，我们用 $P_{\theta,\mathcal{D}}(r, c)$ 表示 $N_\theta(y \mid x)$ 在 $\mathcal{D}$ 上的预测所产生的 r 和 c 值的分布。当 $N_\theta(y \mid x)$ 在数据分布 $\mathcal{D}$ 上良好校准时，有：

$$P_{\theta,\mathcal{D}}(c = 1 | r = I_\alpha) = \alpha \quad \forall \alpha \in [0, 1] \qquad (1)$$

其中，I_α 表示 α 周围的一个很小的非零区间。由此可以定义期望校准误差（ECE）：

$$\mathrm{ECE}(P_{\theta,\mathcal{D}}) = E_{P_{\theta,\mathcal{D}}(r)}\left[\left|E_{P_{\theta,\mathcal{D}}(c|r)}[c] - r\right|\right] \qquad (2)$$

为了在数据样本 $D \sim P_{\theta,\mathcal{D}}$ 上估计 ECE，我们将 r 的取值范围 $[0, 1]$ 划分为 B 个等宽的箱。随后，对每一个箱 $B_j = \left[j/B, \left(j+1\right)/B\right]$，将落入该箱的实例的正确性分数与置信度分数之差汇总起来：

$$\mathrm{ECE}(D) = \frac{1}{|D|}\sum_{j=0}^{B-1}\Big|\sum_{i\in D_j} c_i - \sum_{i\in D_j} r_i\Big| \qquad (3)$$

$$s.t.\ \ D_j = \{i \in D, r_i \in [\frac{j}{B}, \frac{j+1}{B}]\}$$

式中 s.t. 表示“满足如下条件”。

我们希望模型具有低 ECE 和高准确率。注意，最小化 ECE 的模型不一定具有高准确率。例如，一个总是预测多数类、且置信度等于该类别先验概率的模型，其 ECE 为0，但它并不准确。

幸运的是，用于训练神经网络的负对数似然损失（$\mathrm{NLL} = -\sum_{(x,y)\sim\mathcal{D}} \log N_\theta(y \mid x)$）间接地优化了准确率和校准。当 $N_\theta(y \mid x)$ 与真实数据分布 $\mathcal{D}$ 一致时，NLL 达到最小值，因此显然具有良好校准（Hastie et al., 2001）。线性逻辑回归等常用分类器，以及 Platt 缩放等优化 NLL 目标的校准方法，都能得到良好校准的模型（Niculescu-Mizil & Caruana, 2005）。不幸的是，在高容量神经网络上，由于过拟合，NLL 无法最小化校准误差。

我们探索在训练过程中，与 NLL 一起直接优化校准的方法。需要选择一个可训练的函数 $\mathrm{CE}(D, \theta)$ 来度量校准误差，并按如下方式与 NLL 联合优化：

$$\min_\theta \mathrm{NLL}(D, \theta) + \lambda\,\mathrm{CE}(D, \theta) \qquad (4)$$

这里不能使用 $\mathrm{ECE}(D)$，因为它关于 r 高度不连续，因而关于 θ 也高度不连续。下一节中，我们提出一种称为 MMCE 的新校准度量；它是可训练的，并满足合理度量的其他性质，这些性质将在第4节讨论。

3. 基于核嵌入的可训练校准度量

我们的目标是设计一个函数，作为校准误差的可优化替代量。本节提出这样一种度量：当且仅当模型校准时，它等于0；其有限样本估计具有一致性和快速收敛率。此外，我们通过实验表明，可以使用现有的批量随机梯度算法，对网络参数 θ 优化这一度量。

我们的方法基于在再生核希尔伯特空间（RKHS）的函数上定义积分概率度量。这类方法已经成为机器学习中的有力工具，并被成功用于比较两个分布（Gretton et al., 2012; Li et al., 2015）、拟合优度检验以及类别比例估计（Iyer et al., 2014）等任务；综述见 Muandet et al. (2017)。本文展示如何使用它们定义一个可处理的校准误差度量。

令 $\mathcal{H}$ 表示由通用核 $k(\cdot, \cdot)$ 和典范特征映射 $\phi : [0, 1] \mapsto \mathcal{H}$ 诱导的再生核希尔伯特空间。在 $P_{\theta,\mathcal{D}}(r, c)$ 上定义最大均值校准误差（MMCE）如下：

$$\mathrm{MMCE}(P(r,c)) = \left\| E_{(r,c)\sim P}[(c-r)\phi(r)] \right\|_{\mathcal{H}} \quad (5)$$

其中，$\|\cdot\|_{\mathcal{H}}$ 表示希尔伯特空间 $\mathcal{H}$ 中的范数。为简化记号，我们用 $P(r,\ c)$ 代替 $P_{\theta,\mathcal{D}}(r,\ c)$。第4节的定理1表明，只要核 $k(\cdot,\ \cdot)$ 是通用核，MMCE 为0当且仅当 $P(r,\ c)$ 在 $\mathcal{D}$ 上校准。对于样本 $D \sim P$，其中 $D = \{(r_1,\ c_1),\ \ldots,\ (r_m,\ c_m)\}$，有限样本估计为：

$$\mathrm{MMCE}_m(D) = \left\| \sum_{(r_i,c_i)\in D} \frac{(c_i - r_i)\phi(r_i)}{m} \right\|_{\mathcal{H}} \quad (6)$$

在第4节的定理2中，我们证明上述估计具有一致性，并以 $1/\sqrt{m}$ 的速率收敛到 $\mathrm{MMCE}(P(r,\ c))$。

上述表达式可以用核改写为：

$$\mathrm{MMCE}_m^2(D) = \sum_{i,j\in D} \frac{(c_i - r_i)(c_j - r_j)k(r_i, r_j)}{m^2} \quad (7)$$

3.1. 在训练过程中最小化 MMCE

在数据集 D 上训练 θ 时，我们最小化 NLL 与 MMCE 的加权组合：前者降低分类误差，后者降低校准误差。训练在实例的小批量 D_b 上进行。我们发现，D_b 的大小约为100就已足够。

$$\min_{\theta} \sum_{(x_i,y_i)\in D_b} \log N_\theta(y_i|x_i) + \lambda_1 \left(\mathrm{MMCE}_m^2(D_b,\theta)\right)^{\frac{1}{2}} \quad (8)$$

MMCE 关于 r 可微，但由于计算预测标签时存在 argmax 步骤，它严格来说并不关于 θ 可微。在反向传播期间，我们将梯度通过 r 项传递，而不通过预测步骤传递。

训练期间使用 MMCE 的一个问题是，预测错误的样本（即 $c = 0$）通常比测试数据中更少。通过对实例重新加权，使正确样本和错误样本具有相等的权重，我们得到了更好的结果。如果 m 表示大小为 n 的批量中正确实例的数量，那么我们给正确实例赋予权重 m/n，给错误实例赋予权重 $m/(m-n)$。加权估计变为：

$$\begin{aligned}\mathrm{MMCE}_w^2(D) = &\sum_{c_i=c_j=0} \frac{r_i r_j k(r_i, r_j)}{(m-n)(m-n)} \\ &+ \sum_{c_i=c_j=1} \frac{(1-r_i)(1-r_j)k(r_i, r_j)}{n^2} \\ &- 2 \sum_{c_i=1, c_j=0} \frac{(1-r_i) r_j k(r_i, r_j)}{(m-n)n}\end{aligned} \tag{9}$$

第6节将对 MMCE 的这两种形式进行实验比较。

> 译者说明：式(8)中对数似然项的正号，以及式(9)前文字中 m, n 的定义与式(9)分母之间的不一致，均为原版印刷内容；本译文未作静默修正。

3.2. MMCE 为什么有效?

从理论上看，MMCE 仅在完美校准时才精确等于0，因此最小化它是合理的。我们进一步尝试解释 MMCE 在实践中为何有效。由式(6)可见，MMCE 通过比较成对实例来进行置信度校准，而 NLL 则逐个处理实例。为了理解这为什么能够防止过度自信的预测，考虑式(9)的最后一项。现在考虑一个简单的例子：假设一个批量中存在实例 x，它以0.99的高置信度被错误分类；其他所有被正确分类的实例 x 的置信度都约为1。式(9)的第三项将 x 与这些高置信度、分类正确的实例 x 配对。这会对 x 的置信度施加向下的压力，使其小于1。相反，NLL 会持续将 x 的置信度推向1，直至发生过拟合。

我们提供实验依据，说明 MMCE 确实能够防止 NLL 过拟合。图1给出了 MMCE 和基线方法的测试 NLL 随训练轮数增加而变化的曲线。基线模型的测试 NLL 比使用 MMCE 训练的模型更容易呈现过拟合。当一个批量中同时包含分类正确和分类错误的实例时，MMCE 最有效。如果训练准确率为100%，MMCE 将与 NLL 完全一致，也就无法防止过拟合。

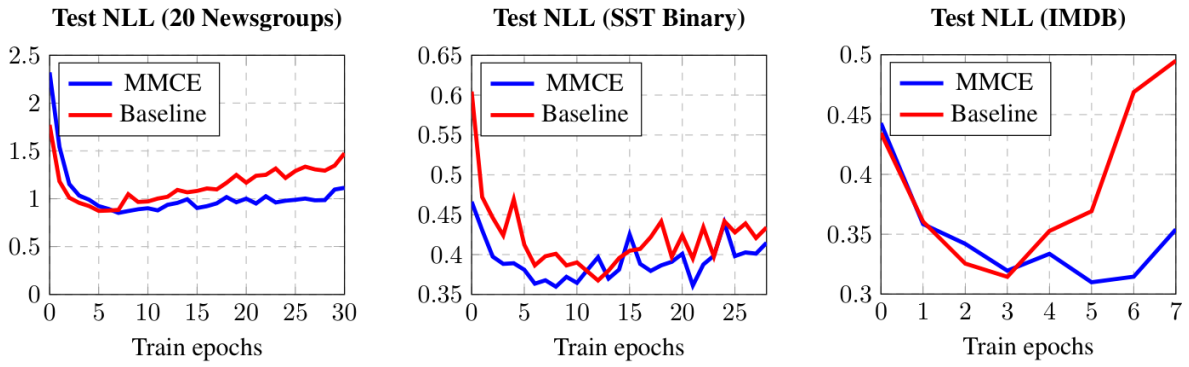


图1. 三个数据集／模型上，MMCE 与基线方法的测试 NLL 随训练进程变化的曲线。注意，基线往往会对训练数据过拟合，而 MMCE 较为稳定，与基线相比过拟合程度小得多。图中 Test NLL 为测试负对数似然；Train epochs 为训练轮数；Baseline 为基线；三个面板依次对应20 Newsgroups、SST 二分类和 IMDB。

4. MMCE 的性质分析

本节证明 MMCE 及其有限样本估计的理论性质。首先，我们证明 $\mathrm{MMCE}(P)$ 是一种忠实的校准误差度量，当且仅当 P 完美校准时等于0。然后，我们给出有限样本下 MMCE 的大偏差界。最后，说明 MMCE 与 ECE 之间的关系。

4.1. MMCE 与完美校准

定理1. 设 $P(r,\, c)$ 是定义在空间 $\mathcal{X} = \big([0,\, 1]\times\{0,\, 1\}\big)$ 上的概率测度，且 $P(r \mid c = 1)$ 和 $P(r \mid c = 0)$ 是 Borel 概率测度。设 k 是通用核。MMCE 度量（式(5)）为0当且仅当 P 完美校准。这意味着 MMCE 是一个适当评分规则（Parry et al., 2011）。

证明。 首先，我们为校准定义一个比 MMCE 更一般、但难以计算的积分概率度量。令 $\mathcal{C}(r)$ 表示 $r \in [0,\, 1]$ 上所有连续有界函数所构成的空间。该度量定义为：

$$M(\mathcal{C}, P) = \sup_{f\in\mathcal{C}} E_{(r,c)\sim P(r,c)}\left[(c - r)f(r)\right] \qquad (10)$$

我们先证明，对校准的 P， $M(\mathcal{C},\, P)$ 为0。上式右端为 $\int_{r=0}^{1} f(r)\left[(1 - r)\,\mathrm{d}P(r,\, c = 1) - r\,\mathrm{d}P(r,\, c = 0)\right]$。这个量为0，因为式(1)意味着 $P\big(I_r,\, c = 1\big)\cdot(1 - r) = r\cdot P\big(I_r,\, c = 0\big)$，而积分只是这一等式的连续形式。

我们证明逆命题，即当 P 未校准时， M 非零。对于未校准的 P，式(1)至少在一个具有非零测度的区间 $I \subseteq \mathbb{R}$ 上不成立，将其记为 $I_0 = \big[r_0,\, r_0 + \delta\big]$，其中 $\delta > 0$。此外，由于 $P(r \mid c)$ 是 Borel 测度，可以假设函数 $P\big(I_0,\, c = 1\big)\cdot\big(1 - r_0\big) - r_0\cdot P\big(I_0,\, c = 0\big)$ 是右连续的，并在 $\delta \to 0$ 时收敛到某个 $s_0 \neq 0$。随后可以选择 $f_0(r) \in \mathcal{C}(r)$，使其为一个正的斜坡函数，在 I_0 的中心达到峰值，并在区间外下降到0。对这个选择， $E_P\big((c - r)f_0(r)\big)$ 保证非零。

接下来，将不实用的函数类 $\mathcal{C}$ 替换为由核 $k(\cdot,\, \cdot)$ 定义的 RKHS 空间 $\mathcal{H}$ 的单位球上的函数 $\mathcal{F}$。如果 k 是通用核，那么对于每个 $f \in \mathcal{C}$ 及 $\epsilon > 0$，都存在函数 $f' \in \mathcal{F}$，满足 $\max_r|f(r) - f'(r)| < \epsilon$。将这一性质与上述结论结合，就可证明：只要 $k(\cdot,\, \cdot)$ 是通用核，$M(\mathcal{F},\, P)$ 为0当且仅当 P 校准。

最后证明 $M(\mathcal{F},\, P) = \mathrm{MMCE}(P)$：

$$
\begin{aligned}
M(\mathcal{F}, P) &= \sup_{f \in \mathcal{F}} E_{P(r,c)}[(c-r)f(r)] \\
&= \sup_{f \in \mathcal{F}} E_{(r,c)\sim P(r,c)}[(c-r)\langle \phi(r), f \rangle] \\
&= \| E_{r,c\sim P}[(c-r)\phi(r)] \|_{\mathcal{H}} = \mathrm{MMCE}(P)
\end{aligned} \tag{11}
$$

其中第一和第二个等式来自 RKHS 函数的特征映射性质。证毕。

4.2. MMCE 的大偏差界

定理2. 令 $K = \max_{r\in[0,1]} k(r, r)$，$m$ 为样本 D 的大小。以大于 $1-\delta$ 的概率，有：

$$
|MMCE_m(D) - MMCE(P)| < \sqrt{\frac{K}{m}}\left(4 + \sqrt{-2\log\delta}\right)
$$

证明见补充材料第1节。

4.3. 与 ECE 的关系

定理3. $\mathrm{MMCE}(P(r, c)) \le K^{1/2}\mathrm{ECE}(P(r, c))$，其中 $K = \max_r k(r, r)$。

证明见补充材料第2节。

5. 相关工作

在经典决策理论中，概率预测的校准长期以来一直在评分规则这一主题下受到研究（Parry et al., 2011）。在机器学习中，已经提出许多不同的方法来改善分类器的校准，包括 Platt 缩放（Platt, 1999）、保序回归（Zadrozny & Elkan, 2002）以及贝叶斯分箱（Naeini et al., 2015）等。Niculescu-Mizil & Caruana (2005) 的系统研究发现，逻辑回归分类器和当时（2005年）的神经网络校准良好；对于那些未校准的模型（例如 SVM），Platt 缩放是最好的修正方法。Candela et al. (2005) 讨论了校准误差的度量方法，并强调 NLL 可能过拟合。Kuleshov & Liang (2015) 研究了结构化预测的校准，Kuleshov & Ermon (2017) 则展示了如何在在线对抗环境中进行校准。

对于现代神经网络，最近的一项系统研究（Guo et al., 2017）发现，它们的校准效果令人意外地差。该研究比较了几种传统的事后修正方法，发现温度缩放能够提供最好的校准。另一项近期工作提出在训练期间使用熵正则项，惩罚过度自信的预测（Pereyra et al., 2017）。这两种方法共同的缺点在于，它们不加区分地压低所有预测的置信度，使最终应用无法享受到高置信度预测带来的益处。

贝叶斯推断是一种获得更好预测不确定性的有原则的方法（Louizos & Welling, 2017），但会带来显著更高的训练成本。Lakshminarayanan et al. (2017) 提出对一组模型的预测取平均，不过这种方法也很消耗资源。

我们用核嵌入来度量校准误差，这与 MMD 使用核嵌入来度量分布间距离的方式类似（Gretton et al., 2012）。最近，MMD 被用于训练多种神经网络，包括 Li et al. (2015) 的生成模型，以及 Yan et al. (2017) 的无监督领域适应模型。有关定义在核嵌入上的其他度量，请参见 Muandet et al. (2017)。据我们所知，之前尚无使用核嵌入定义校准误差的工作。

6. 实验

我们在涵盖图像、自然语言处理和时间序列的七个数据集以及六种网络架构上，将使用 MMCE 进行校准的方法与现有校准方法进行比较。我们证明，使用 MMCE 训练的模型不仅能够给出校准更好、更准确的预测，而且与现有方法相比，它能在更高的置信度水平上实现这些目标。我们还评估了使用二次型 MMCE 损失训练带来的计算开销，并表明运行时间增加不超过10%。[1]

[1] 部分代码已公开，完整代码将发布于 https://github.com/aviralkumar2907/MMCE。（此处为原文脚注，描述的是论文发表时状态。）

数据集。 实验中使用的数据集如下：

1. **CIFAR-10**（Krizhevsky et al., a）： 来自10个类别的32×32彩色图像。训练／验证／测试集分别包含45,000／5,000／10,000张图像。
2. **CIFAR-100**（Krizhevsky et al., b）： 与上述数据集相同，但包含100个类别。
3. **Caltech Birds 200**（Welinder et al., 2010）： 从 ImageNet 中选取的200种鸟类图像。训练／验证／测试集分别包含5994／2897／2897张图像。
4. **20 Newsgroups**：根据内容分为20个类别的新闻文章。训练／验证／测试集分别包含15098／900／3999篇文档。
5. **IMDB 评论**（Maas et al., 2011）： 用于情感分类的两极性电影评论。训练／验证／测试集的规模分别为25000／5000／20000。
6. **加州大学欧文分校人类活动识别（HAR）**（Anguita et al., 2013）： 来自手机、对应六种人体动作的时间序列。训练／验证／测试集分别包含6653／699／2947个实例。
7. **斯坦福情感树库（SST）**（Socher et al., 2012）： 以带有情感标注的解析树表示的电影评论。每个样本同时包含一个二分类标签和一个细粒度的五分类标签。我们使用二分类版本。训练／验证／测试集分别包含6920／872／1821篇文档。

模型。 对前三个图像数据集，我们采用当时先进的卷积网络，如 Resnet（He et al., 2016）、Wide Resnet（Zagoruyko & Komodakis, 2016）和 Inception v3（Krause et al., 2016）。每种模型均使用不同的大小（深度／层数）。在20 Newsgroups 上，我们训练一个全局池化卷积网络（Lin et al., 2013）。在 IMDB 评论上，我们使用层次注意力网络的一个版本（Yang et al., 2016）。在 UCI HAR 上使用 LSTM。在 SST 二分类上使用 TreeLSTM 模型（Tai et al., 2015）。我们采用公开可用的模型：CIFAR-10 Resnet 来自 Tensorflow (2018)；CIFAR-10 Wide Resnet 和 CIFAR-100 的所有模型

来自 Xin Pan (2018)；Birds CUB 数据集模型来自 Vispedia (2018)；IMDB 数据集模型来自 Ilya Ivanov (2018)；20 Newsgroups 模型来自 Keras Team (2018)；HAR 数据集模型来自 Guillaume Chevalier (2017)；SST TreeLSTM 来自 Nicolas Pinchaud (2017)。

实验设置。 用于平衡 MMCE 相对于 NLL 权重的 λ 通过交叉验证选择。由于 r, r' 都是概率，我们对所有任务使用同一个核 $k(r, r')$。我们选择宽度为0.4的通用拉普拉斯核 $k(r, r') = \exp(-|r - r'|/0.4)$。校准误差使用 ECE 度量，采用20个箱，每个箱的宽度为0.05。批量大小设为128，除非代码库的默认批量大小更大。例如，IMDB HAN 代码库的默认批量大小为256，UCI HAR 的批量大小为1500。优化器和超参数的其他细节均保持所下载源代码中基础模型的设置不变。一个例外是，SST 的批量大小固定为25，即默认值。

比较方法。 我们比较以下方法：

Baseline（基线）。 所有任务的基线模型都使用负对数似然训练。所有基线模型均从公开来源下载，并配备其表现最好的正则化手段，如 dropout 和权重惩罚。

Baseline+T。 Guo et al. (2017) 比较了使用验证数据集对基线模型进行校准的六种方法。其中，温度缩放的 ECE 表现最好，也是唯一不会降低基线准确率的方法。我们与这一方法比较，并用 Baseline+T 表示经温度校准的基线模型。

MMCE、MMCE_m、MMCE+T。 这些是我们基于 MMCE 的方法的变体。MMCE 指式(9)中的加权版本 MMCE_w，MMCE_m 指式(7)中的未加权版本。温度缩放也可以用于使用 MMCE 训练的模型，我们将其称为 MMCE+T 方法。

熵惩罚。 我们还与 Pereyra et al. (2017) 的方法比较；该方法将熵惩罚作为正则项加入，以减少现代神经网络校准不佳的主要原因之一——过度自信。

核回归。 MMCE 使用核来度量校准。另一种传统的基于核的度量是 Nardaya-Watson 核回归器。我们使用它得到 $P(c = 1 \mid r)$ 的平滑估计，然后最小化该估计与 r 的距离，从而按式(1)实现校准。这样得到一个可训练的校准误差度量：

$$\sum_{i \in D} \left(r_i - \frac{\sum_{j \in D} k(r_i, r_j) c_j}{\sum_{j \in D} k(r_i, r_j)} \right)^2 . \qquad (12)$$

我们将其用作式(4)中的 $\text{CE}(D, \theta)$。

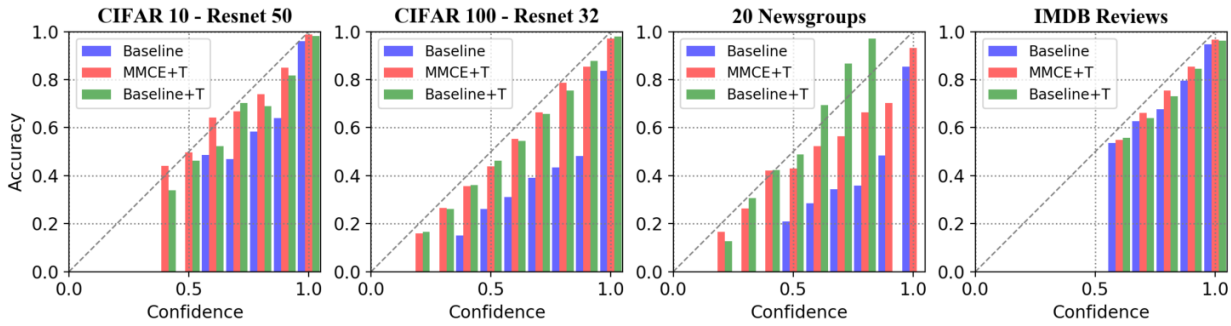


图2. 展示 Baseline、MMCE+T 和 Baseline+T 校准情况的可靠性图。横轴是划分为10个等宽箱的预测置信度，纵轴是在相应置信度箱中的准确率。完美的度量应当落在直线上。绘图时，删除了落入数据点数量不足总数0.5%的箱。图中 Confidence 为置信度，Accuracy 为准确率；四个面板依次对应 CIFAR-10／Resnet 50、CIFAR-100／Resnet 32、20 Newsgroups、IMDB 评论。

评估指标。 我们使用三种不同的校准误差度量（Candela et al., 2005）比较这些方法：期望校准误差 ECE（见第2节）、Brier 分数 $\frac{1}{|D|}\sum_{(x_i,y_i)\sim D}\sum_v\left(c_{i,v}-r_{i,v}\right)^2$，以及 NLL。我们还测量经过校准的高置信度预测所占的比例，以奖励那些无需压低正确的高置信度分数就能实现校准的方法。

6.1. 结果

MMCE 相对于基线的收益。 首先评估 MMCE 能否在不降低准确率的情况下，有效减少相对于基线的校准误差。表1和表2汇总了不同数据集与架构组合上的结果。从表1第3列和第4列可以看到，MMCE 训练始终带来较低的 ECE 值。例如，在 CIFAR-10 上，三个模型的 ECE 均降低至原来的约四分之一。用 Brier 分数和 NLL 度量时，校准误差的下降同样明显（表2）。MMCE 还提高了基线准确率，这表明准确率（由 NLL 优化）与校准（由 MMCE 优化）并非相互正交。

这里的所有模型都使用 MMCE 从头训练。但我们也表明，MMCE 可以用于微调预训练模型。补充材料表1比较了基线模型与使用我们的 $\text{NLL}+\lambda\text{MMCE}$ 目标进行微调的模型在 ECE 和准确率上的表现。我们发现，使用 MMCE 微调有助于改善校准，尽管改善幅度不及从头训练。

与温度缩放比较。 在表1最后两列，我们比较温度缩放（TS）对基线模型和 MMCE 训练模型的 ECE 的影响。温度缩放不改变准确率。我们发现，两个模型经 TS 后，校准都有改善（ECE 下降）。总体而言，MMCE+T 的校准最好。在20 Newsgroups 上，MMCE+T 相对于 Baseline+T 的提升尤其大。由表2可见，就 Brier 分数和 NLL 而言，MMCE 即使不使用 TS，相对于 baseline+TS 也能带来更大的校准误差下降。

一个自然的问题是：温度缩放为什么还能改善 MMCE？我们猜测，原因是引入了一个不同的验证数据集。在验证数据集上使用 MMCE（而不是 NLL）进行 TS，也会得到相似的 ECE 下降。但在相对于基线的改进中，MMCE 的贡献远大于 TS。MMCE+T 的 ECE 下降中，70%来自 MMCE 训练，只有额外的30%来自在验证数据集上的 TS。

我们进一步超越汇总 ECE 数值，使用图2的可靠性图比较 Baseline、Baseline+T 和 MMCE+T。在可靠性图中，完美校准的模型应当落在对角线上；位于对角线下方的模型过度自信，位于对角线上方的模型则低估置信度。Baseline 过度自信，温度缩放对其进行了显著修正。然而，在20 Newsgroups 上，TS 使 Baseline 模型摆向了相反的方向，变成置信度不足！

我们进一步表明，TS 在其他几个数据集上也造成置信度损失，只是损失发生在置信度非常高的区域，未反映在汇总 ECE 数值中。由于问题在于过度自信，我们关注以极高置信度——具体为0.99——给出的预测子集。对于每种方法，定义置信集合（CS99），其中包含置信度高于0.99的预测。只要 CS99 中的准确率高于99%，我们就希望 CS99 尽可能大。结果见表4。过度自信的基线自然获得了最大的 CS99，但在全部五种情形下，其准确率都低于99%的承诺。对基线应用温度缩放确实修正了准确率，但此时置信集合的规模小得多。相比之下，无论是否使用 TS，MMCE 都给出多得多的高置信度预测。例如，在 CIFAR-10（Resnet 110）上，温度缩放将 CS99 的规模从89%降到了40%，而 MMCE 在不降低准确率的情况下将其提高到了72%。如前所述，从神经网络实际部署的角度看，高置信度预测较少（或者完全没有）并不是好事。

E#	**Dataset**	**Model**	**ECE**		**Accuracy**		**ECE with Temperature**	
			Baseline	MMCE	Baseline	MMCE	Baseline+T	MMCE+T
1	MNIST	LeNet 5	0.5%	**0.2%**	99.24%	99.26%	–	–
2	CIFAR 10	Resnet 50	4.3%	**1.2%**	93.1%	93.4%	**0.9%**	1.1%
3	CIFAR 10	Resnet 110	4.6%	**1.1%**	93.7%	94.0%	1.21%	**1.19%**
4	CIFAR 10	Wide Resnet 28-10	4.5%	**1.6%**	94.1%	94.2%	**1.0%**	1.1%
5	CIFAR 100	Resnet 32	19.6%	**6.9%**	67.0%	67.7%	2.5%	**1.4%**
6	CIFAR 100	Wide Resnet 28-10	15.0%	**8.9%**	74.0%	76.6%	2.5%	**2.3%**
7	Birds CUB 200	Inception-v3	2.6%	**2.3%**	78.2%	77.9%	2.0%	**1.4%**
8	20 Newsgroups	Global Pooling CNN	16.5%	**6.5%**	74.2%	73.9%	15.8%	**6.2%**
9	IMDB Reviews	HAN	4.9%	**0.4%**	86.8%	86.3%	1.0%	**0.2%**
10	SST Binary	Tree LSTM	7.4%	**5.9%**	88.6%	88.7%	**1.8%**	3.6%
11	HAR time series	LSTM	7.6%	**5.9%**	89.4%	90.3%	3.8%	**3.7%**

表1. Baseline 与 MMCE 从头训练后，以及使用验证数据集进行温度缩放后的 ECE 和准确率。模型用其名称及网络大小标识。列标题依次为：实验编号（E#）、数据集（Dataset）、模型（Model）、ECE〔基线／MMCE〕、准确率（Accuracy）〔基线／MMCE〕、温度缩放后的 ECE〔Baseline+T／MMCE+T〕。数据集名称中，Birds CUB 200 指 CUB 200 鸟类数据集，IMDB Reviews 指 IMDB 评论，SST Binary 指 SST 二分类，HAR time series 指 HAR 时间序列；Global Pooling CNN 指全局池化卷积神经网络。破折号表示原表未报告数值。

E#	Brier Score			Test NLL		
	Base	MMCE	B+T	Base	MMCE	B+T
2	0.121	**0.090**	0.111	0.31	**0.21**	0.23
4	0.087	0.085	**0.082**	0.24	0.18	0.18
5	0.522	**0.445**	0.467	1.74	**1.24**	1.26
6	0.340	**0.338**	**0.338**	0.96	0.94	**0.93**
7	0.318	**0.312**	0.317	0.87	**0.86**	**0.86**
8	0.401	**0.365**	0.380	1.34	**0.97**	1.02
9	0.197	**0.189**	0.190	0.33	**0.30**	0.31
10	0.220	**0.209**	0.218	0.42	**0.40**	0.41
11	0.183	**0.172**	0.178	0.49	**0.34**	0.38

表2. Baseline、MMCE 与 Baseline+T（B+T）在从头训练后以及使用验证数据集进行温度缩放后的 Brier 分数和 NLL 值。实验编号（E#）可在表1查找。Brier Score 为 Brier 分数，Test NLL 为测试负对数似然；Base 为基线，B+T 为基线加温度缩放。所有数值与强调格式保留原表。

有些应用依赖高置信度预测，例如神经网络在医学和医疗中的应用。置信度校准的理想目标，应当不仅是获得准确的预测，而且是获得高置信度预测。压低较大的置信度值并不是发掘现代高容量网络潜力的最佳方式；我们需要像 MMCE 这样的训练时方法，逐步消除错误的高置信度预测。

与其他正则化方法比较。 接下来，我们将 MMCE 与熵惩罚比较，发现熵惩罚确实能显著降低 ECE，尽管其目标是修正过度自信，而不是校准。不过，它与温度缩放有同样的缺点：不加区分地压低置信度，导致高置信度预测很少，见表4。例如，在 CIFAR-10 上，以0.99作为置信度阈值，MMCE 对72%的实例给出预测，准确率为99.7%；使用熵惩罚则只有7%，而且准确率仅为97%，说明置信度超过0.99的箱中存在失校准。

核回归正则项（式(12)）未能有效改善校准。这令人意外，因为 Nardaya-Watson 回归器的收敛率为 $m^{-4/5}$，优于我们方法的 $m^{-1/2}$。一种可能原因是，它关于 θ 的梯度不利于优化目标，这也许是因为核出现在分母中。相比之下，MMCE 的核只出现在分子中，有利于基于梯度的优化。

MMCE：加权与未加权。 在第3节式(7)处，我们说明了设计加权 MMCE 估计量的动机：克服训练数据天然具有高准确率的偏置。在表3中可以看到，与原始 MMCE 版本相比，这一版本（最后一列）确实在大多数情形下显著提高了准确率。

Dataset	Model	MMCE_m		Kernel Regression		Entropy penalty		MMCE	
		ECE	Acc%	ECE	Acc%	ECE	Acc%	ECE	Acc%
CIFAR 10	Resnet 50	3.2%	93.2%	4.9%	93.1%	1.8%	93.0%	**1.2%**	93.4%
CIFAR 10	Resnet 110	4.1%	93.6%	4.5%	93.6%	2.1%	93.8%	**1.2%**	94.0%
CIFAR 10	Wide Resnet 28-10	3.0%	95.0%	3.1%	95.1%	2.8%	94.7%	**1.6%**	94.2%
CIFAR 100	Wide Resnet 28-10	10.4%	77.1%	12.2%	78.6%	9.3%	77.9%	**8.9%**	76.6%
HAR time series	LSTM	5.5%	89.8%	7.0%	90.2%	**2.7%**	91.8%	5.9%	90.3%
20 Newsgroups	Global Pool CNN	15.8%	75.1%	18.8%	75.1%	**2.3%**	74.2%	6.5%	73.9%
IMDB Reviews	HAN	3.6%	86.6%	3.2%	85.7%	0.6%	86.6%	**0.4%**	86.3%

表3. 使用 $\text{NLL} + \lambda\text{CE}$ 训练的不同方法的 ECE 和准确率。注意，熵惩罚在不降低准确率的情况下减少了 ECE。核回归只在某些情形下有帮助，而加权 MMCE 明显优于未加权版本 MMCE_m。列标题 Dataset 为数据集，Model 为模型，Kernel Regression 为核回归，Entropy penalty 为熵惩罚；各方法的 ECE 为期望校准误差，Acc% 为准确率百分比。Global Pool CNN 为全局池化卷积神经网络，IMDB Reviews 为 IMDB 评论，HAR time series 为 HAR 时间序列。

Dataset	Model	Baseline		Baseline + T		MMCE		MMCE + T		Entropy	
		|CS99|	Acc.	|CS99|	Acc.	|CS99|	Acc.	|CS99|	Acc.	|CS99|	Acc.
CIFAR 10	Resnet 110	89	97.65	40	99.57	72	99.69	68	99.79	7	96.96
CIFAR 10	Resnet 50	86	98.04	51	99.68	67	99.68	66	99.71	26	98.04
IMDB	HAN	48	98.28	12	99.48	19.3	99.40	19.1	99.24	18.6	99.20
20 NewsG	Global Pool	61	92.07	0	–	45	96.26	42	96.73	7	97.14
Birds	Inception v3	55	98.68	40	99.31	48	99.34	41	99.40	37	99.01

表4. 以超过99%的置信度给出预测的测试实例比例，以及这些预测的准确率。注意，与 MMCE 相比，温度缩放和熵惩罚等修正方法将更多数据点移出了高置信度区域。Dataset 为数据集，Model 为模型，Baseline 为基线，Entropy 为熵惩罚；每种方法下的 $|\text{CS99}|$ 表示上述实例的百分比，Acc. 表示准确率百分比；20 NewsG 为20 Newsgroups，Birds 为鸟类数据集，Global Pool 为全局池化。

校准权重 λ 的调整。图3展示，在 $\text{NLL} + \lambda\text{CE}$ 训练目标中，将 MMCE 或熵正则项用作 CE 时，λ 的不同取值对 ECE 的影响。我们发现，与熵正则项相比，MMCE 在 λ 变化时明显更加稳定。例如，在20 Newsgroups 上，熵正则项在6处达到最小值，并在两侧急剧上升；MMCE 则逐渐走向其平坦的最小值区域。MMCE 的准确率数值（图中未显示）也不会随 λ 发生太大变化。

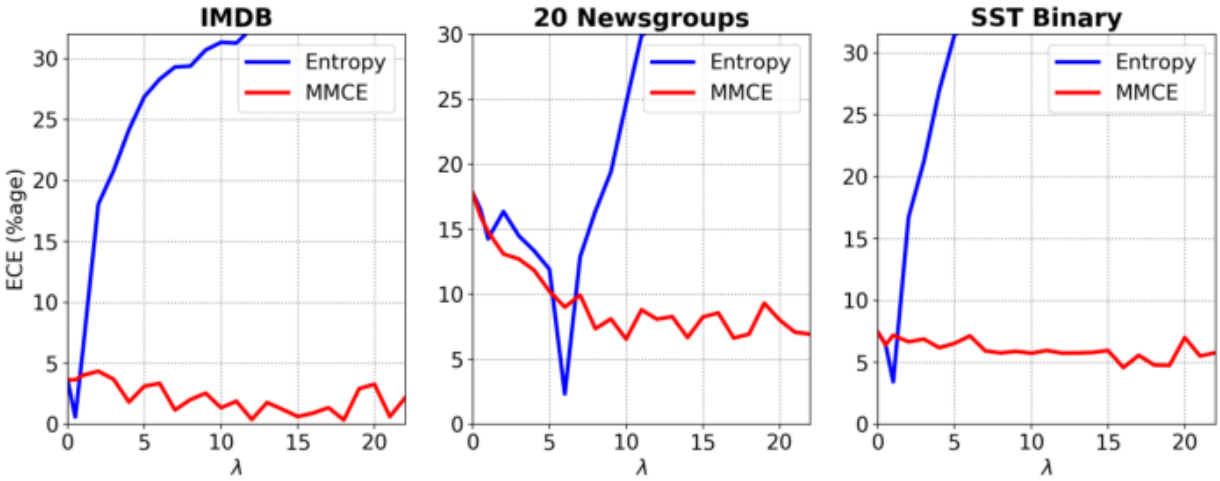


图3. 以熵惩罚和 MMCE 为正则项时，ECE 随正则化权重 λ 的变化。注意，熵惩罚有尖锐的峰，而 MMCE 的趋势稳定。为了使图形更清楚，纵轴值在约30处截断。图中 ECE 为期望校准误差，Entropy 为熵惩罚；三个面板分别对应 IMDB、20 Newsgroups 和 SST 二分类。

计算效率。 我们比较了基线模型与 MMCE 训练模型每个训练轮次的运行时间（使用 NVIDIA Titan X GPU，见补充材料表2）。尽管 MMCE 随实例数量呈二次增长，我们发现 MMCE 算法每轮的实际运行时间比基线增加不超过10%。这是因为 MMCE 具有快速收敛性质，即使在构成一个批量的约100个实例上，也能被可靠估计。

总之，实验表明，使用 MMCE 训练是一种快速、稳定且准确的方法，能够在最大限度保留高置信度预测的同时，最小化校准误差。

7. 结论

我们提出了 MMCE，这是一种利用 RKHS 空间中的通用核定义的新校准误差度量。我们对 MMCE 进行了理论分析，证明它仅在模型校准时才达到最小值，其有限样本估计具有一致性，并以 $1/\sqrt{m}$ 的速率收敛。这一度量可用于联合训练网络参数，同时最小化准确率方面的误差和校准误差。联合目标易于训练，不像熵正则项等类似正则化方法那样需要非常仔细地调整超参数。此外，其运行时间开销很小，不像贝叶斯网络等方法，在建模预测不确定性时付出巨大性能代价。

我们的模型不仅提供低 ECE 和高准确率，而且能够产生更多高置信度预测；这不同于以往不加区分地压低较大置信度分数的平滑方法。实验表明，现代神经网络面临的问题，与其说是过度自信，不如说是校准不佳。像 MMCE 这样精心设计的训练目标，可以在不降低置信度的情况下修正校准不佳的问题。

未来，我们计划将 MMCE 应用于结构化预测任务的校准，例如用于翻译的序列到序列模型。

致谢。 感谢所有匿名审稿人的意见，以及他们指出统计学中有关评分规则的工作。感谢印度理工学院孟买分校课题组成员，特别是 Shiv Shankar，参与讨论。衷心感谢 NVIDIA 公司提供 Titan X GPU 的支持。

参考文献

以下保留全部作者、出处、年份、卷页、标识符与链接，文献题名及说明译为中文。

- Anguita, D., Ghio, A., Oneto, L., Parra, X., and L Reyes-Ortiz, J. 使用智能手机进行人类活动识别的公共领域数据集。2013年1月。
- Bojarski, M., Testa, D. D., Dworakowski, D., Firner, B., Flepp, B., Goyal, P., Jackel, L. D., Monfort, M., Muller, U., Zhang, J., Zhang, X., Zhao, J., and Zieba, K. 自动驾驶汽车的端到端学习。CoRR, abs/1604.07316, 2016。http://arxiv.org/abs/1604.07316。
- Candela, J. Q., Rasmussen, C. E., Sinz, F. H., Bousquet, O., and Schölkopf, B. 预测不确定性评估挑战。载于 Machine Learning Challenges, Evaluating Predictive Uncertainty, Visual Object Classification and Recognizing Textual Entailment（机器学习挑战：预测不确定性评估、视觉目标分类与文本蕴含识别），第一届 PASCAL 机器学习挑战研讨会 MLCW 2005，英国南安普敦，2005年4月11–13日，修订精选论文，第1–27页，2005。
- Caruana, R., Lou, Y., Gehrke, J., Koch, P., Sturm, M., and Elhadad, N. 用于医疗的可理解模型：预测肺炎风险与医院30天再入院。载于第21届 KDD 2015 论文集，KDD ’15，第1721–1730页，美国纽约，2015。ACM。ISBN 978-1-4503-3664-2。DOI: 10.1145/2783258.2788613。
- Crowson, C. S., Atkinson, E. J., and Therneau, T. M. 预后风险评分的校准评估。Statistical Methods in Medical Research, 25(4):1692–1706, 2016。
- Gretton, A., Borgwardt, K. M., Rasch, M. J., Schölkopf, B., and Smola, A. J. 核两样本检验。Journal of Machine Learning Research, 13:723–773, 2012。
- Guillaume Chevalier. 用于人类活动识别的 LSTM。https://github.com/guillaume-chevalier/LSTM-Human-Activity-Recognition，2017。在线；访问日期：2018年1月27日。
- Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. 论现代神经网络的校准。载于第34届国际机器学习大会论文集，ICML 2017，澳大利亚新南威尔士州悉尼，2017年8月6–11日，第1321–1330页，2017。
- Hastie, T., Tibshirani, R., and Friedman, J. 《统计学习基础》。Springer 统计学丛书。Springer New York Inc.，美国纽约，2001。
- He, K., Zhang, X., Ren, S., and Sun, J. 用于图像识别的深度残差学习。CVPR, 2016。
- Hendrycks, D. and Gimpel, K. 检测神经网络误分类样本与分布外样本的基线方法。载于 ICLR, 2017。
- Ilya Ivanov. IMDB HAN 模型。https://github.com/ilivans/tf-rnn-attention，2018。在线；访问日期：2018年1月27日。
- Iyer, A., Nath, S., and Sarawagi, S. 用于类别比例估计的最大均值差异：收敛界与核选择。载于 ICML, 2014。
- Jiang, X., Osl, M., Kim, J., and Ohno-Machado, L. 校准预测模型估计以支持个性化医疗。Journal of the American Medical Informatics Association, 19(2):263–274, 2012。DOI: 10.1136/amiajnl-2011-000291。
- Keras Team. Keras 预训练词嵌入示例。https://github.com/keras-team/keras/blob/master/examples/pretrained_word_embeddings.py，2018。在线；访问日期：2018年1月24日。

- Krause, J., Sapp, B., Howard, A., Zhou, H., Toshev, A., Duerig, T., Philbin, J., and Fei-Fei, L. 噪声数据在细粒度识别中的惊人有效性。载于 Leibe, B., Matas, J., Sebe, N., and Welling, M.（编），Computer Vision – ECCV 2016，第301–320页，Cham，2016。Springer International Publishing。
- Krizhevsky, A., Nair, V., and Hinton, G. CIFAR-10（加拿大高等研究院）。a。http://www.cs.toronto.edu/~kriz/cifar.html。
- Krizhevsky, A., Nair, V., and Hinton, G. CIFAR-100（加拿大高等研究院）。b。http://www.cs.toronto.edu/~kriz/cifar.html。
- Kuleshov, V. and Ermon, S. 在对抗者面前在线估计不确定性。载于 AAAI, 2017。
- Kuleshov, V. and Liang, P. S. 经过校准的结构化预测。载于 Cortes, C., Lawrence, N. D., Lee, D. D., Sugiyama, M., and Garnett, R.（编），NIPS，第3474–3482页，2015。
- Lakshminarayanan, B., Pritzel, A., and Blundell, C. 使用深度集成进行简单且可扩展的预测不确定性估计。载于 NIPS，第6405–6416页，2017。
- Lee, K., Lee, H., Lee, K., and Shin, J. 训练置信度校准的分类器以检测分布外样本。载于 ICLR, 2018。
- Li, Y., Swersky, K., and Zemel, R. 生成矩匹配网络。载于 Bach, F. and Blei, D.（编），ICML，PMLR 第37卷，第1718–1727页，法国里尔，2015年7月7–9日。PMLR。
- Liang, S., Li, Y., and Srikant, R. 提高神经网络中分布外图像检测的可靠性。ICLR, 2018。
- Lin, M., Chen, Q., and Yan, S. 网络中的网络。CoRR, abs/1312.4400, 2013。
- Louizos, C. and Welling, M. 用于变分贝叶斯神经网络的乘法归一化流。载于 ICML，第70卷，第2218–2227页，2017。
- Maas, A. L., Daly, R. E., Pham, P. T., Huang, D., Ng, A. Y., and Potts, C. 学习用于情感分析的词向量。载于 ACL: HLT 论文集，2011年6月。
- Muandet, K., Fukumizu, K., Sriperumbudur, B. K., and Schölkopf, B. 分布的核均值嵌入：综述及其延伸。Foundations and Trends in Machine Learning, 10(1-2):1–141, 2017。
- Naeini, M. P., Cooper, G. F., and Hauskrecht, M. 使用贝叶斯分箱获得良好校准的概率。载于 AAAI, 2015。
- Nicolas Pinchaud. Tree LSTM 的快速小批量版本。https://github.com/nicolaspi/treelstm，2017。在线；访问日期：2018年1月31日。
- Niculescu-Mizil, A. and Caruana, R. 使用监督学习预测良好的概率。载于 ICML, 2005。
- Parry, M., Dawid, A. P., and Lauritzen, S. 适当局部评分规则。ArXiv e-prints，2011年1月。
- Pereyra, G., Tucker, G., Chorowski, J., Kaiser, L., and Hinton, G. E. 通过惩罚高置信度输出分布对神经网络进行正则化。ICLR workshop, 2017。
- Platt, J. C. 支持向量机的概率输出及其与正则化似然方法的比较。载于 Advances in Large Margin Classifiers，第61–74页。MIT Press，1999。
- Pleiss, G., Raghavan, M., Wu, F., Kleinberg, J. M., and Weinberger, K. Q. 论公平性与校准。载于 NIPS，第5684–5693页，2017。
- Socher, R., Huval, B., Manning, C. D., and Ng, A. Y. 通过递归矩阵–向量空间实现语义组合性。载于 EMNLP, 2012。
- Tai, K. S., Socher, R., and Manning, C. D. 利用树结构长短期记忆网络改进语义表示。载于 ACL, 2015。

- Tensorflow. CIFAR-10 模型。https://github.com/tensorflow/models/tree/master/official/resnet，2018。在线；访问日期：2018年1月21日。
- Vispedia. 分类：Birds CUB 200 数据集。https://github.com/visipedia/tf_classification，2018。在线；访问日期：2018年1月26日。
- Welinder, P., Branson, S., Mita, T., Wah, C., Schroff, F., Belongie, S., and Perona, P. Caltech-UCSD Birds 200。技术报告 CNS-TR-2010-001，加州理工学院，2010。
- Xin Pan. CIFAR-100 模型。https://github.com/tensorflow/models/tree/master/research/resnet，2018。在线；访问日期：2018年1月21日。
- Yan, H., Ding, Y., Li, P., Wang, Q., Xu, Y., and Zuo, W. 注意类别权重偏置：用于无监督领域适应的加权最大均值差异。载于 2017 IEEE CVPR 2017，美国夏威夷檀香山，2017年7月21–26日，第945–954页，2017。
- Yang, Z., Yang, D., Dyer, C., He, X., Smola, A. J., and Hovy, E. H. 用于文档分类的层次注意力网络。载于 HLT-NAACL, 2016。
- Zadrozny, B. and Elkan, C. 将分类器分数转换为准确的多类别概率估计。载于 ACM SIGKDD, 2002。
- Zagoruyko, S. and Komodakis, N. 宽残差网络。CoRR, abs/1605.07146, 2016。
- Zhang, C., Bengio, S., Hardt, M., Recht, B., and Vinyals, O. 理解深度学习需要重新思考泛化。ICLR, 2017。

补充材料

基于核均值嵌入的神经网络可训练校准度量

Aviral Kumar[1] · Sunita Sarawagi[1] · Ujjwal Jain[1]

[1] 印度孟买，印度理工学院孟买分校，计算机科学与工程系。通讯作者：Aviral Kumar aviralkumar2907@gmail.com。

第35届国际机器学习大会论文集，瑞典斯德哥尔摩，PMLR 80，2018。版权 © 2018 作者。官方补充材料：https://proceedings.mlr.press/v80/kumar18a/kumar18a-supp.pdf。

补充材料 1. 定理2的证明

证明。 我们的证明技术与 Gretton et al. (2012) 针对 MMD 的证明技术类似。定义 $g(D) = |\text{MMCE}_m(D) - \text{MMCE}(P)|$。在 MMCE_m 的表达式中，当将一个样本 (r_i, c_i) 替换为另一个随机样本时， $g(D)$ 的最大变化为 $2\sqrt{K}/m$。应用 McDiarmid 不等式可得：

$$\Pr(g(\mathrm{D}) - E_{\mathrm{D}}[g(\mathrm{D})] > \epsilon) < \exp(-\frac{m\epsilon^2}{2K}) \qquad (1)$$

接下来，从 MMCE 的定义出发，给出 $E_D[g(D)]$ 的上界。

$$
\begin{aligned}
&E_{\mathrm{D}}[|\mathrm{MMCE}_m(\mathrm{D}) - \mathrm{MMCE}(P)|] \\
&= E_{\mathrm{D}}[|\sup_{f\in\mathcal{F}}[\sum_{i=1}^{m}\frac{(c_i - r_i)f(r_i)}{m}] - \sup_{f\in\mathcal{F}} E_P[(c-r)f(r)]|] \\
&\leq E_{\mathrm{D}}\sup_f\left|\sum_{i=1}^{m}\frac{(c_i - r_i)f(r_i)1}{m} - E_P[(c-r)f(r)]\right| \\
&= E_{\mathrm{D}}\sup_f\left|\sum_{i=1}^{m}\frac{(c_i - r_i)f(r_i)}{m} - E_{\mathrm{D}'}[\sum_{i=1}^{m}\frac{(c'_i - r'_i)f(r'_i)}{m}]\right| \\
&\leq E_{\mathrm{D},\mathrm{D}'}\sup_f\left|\sum_{i=1}^{m}\frac{(c_i - r_i)f(r_i)}{m} - \sum_{i=1}^{m}\frac{(c'_i - r'_i)f(r'_i)}{m}\right| \\
&= E_{\mathrm{D},\mathrm{D}',\sigma}\sup_f\left|\sum_{i=1}^{m}\sigma_i\left(\frac{(c_i - r_i)f(r_i)}{m} - \frac{(c'_i - r'_i)f(r'_i)}{m}\right)\right| \\
&\leq 2\sqrt{\frac{4K}{m}}
\end{aligned}
$$

在上式中，σ_i 表示以相同概率取值 $+1$ 或 -1 的随机变量；最后一个不等式来自 Bartlett & Mendelson (2002) 的引理22。结合补充材料式(1)与上述结果，得到：

$$
\Pr\left(g(D) > 4\sqrt{\frac{K}{m}} + \epsilon\right) < \exp\left(-\frac{m\epsilon^2}{2K}\right).
$$

整理各项，并将右端替换为 δ，即可证明所需的不等式。证毕。

补充材料 2. 定理3的证明

证明。 从右端开始：

Proof. Starting from the RHS,

$$\begin{aligned}\mathrm{ECE}(P(r,c)) &= \mathbb{E}_r\left[\left|r - \frac{p(c=1,r)}{p(r)}\right|\right] \\ &= \mathbb{E}_r\left[\left|\frac{r\cdot p(c=0,r)-(1-r)\cdot p(c=1,r)}{p(r)}\right|\right] \\ &= \int_r |r\cdot p(c=0,r) - (1-r)\cdot p(c=1,r)|dr\end{aligned}$$

Now, we can rewrite

上图中的 “Proof. Starting from the RHS” 意为“证明。从右端开始”；“Now, we can rewrite” 意为“现在，可以改写为”：

$$\mathrm{MMCE}(P(r,c)) = \sup_{f\in\mathcal{F}} \sum_c \int_r (c-r)\cdot f(r) dP(r,c)$$

$$= \int_r \big((1-r)\cdot p(c=1,r) - r\cdot p(c=0,r)\big)\cdot f(r)dr$$

容易看出，$M\left(\mathcal{D}_L,\ P(r,\ c)\right) = \mathrm{ECE}\left(P(r,\ c)\right)$，其中 $\mathcal{D}_L = \{f \mid \| f \|_\infty \le L\}$。我们选择 $f(r) = L\cdot\mathrm{sign}\left((1-r)\cdot p(c=1,\ r) - r\cdot p(c=0,\ r)\right)$。注意，集合 $\mathcal{D}_L$ 还包含不连续函数。相比之下，$\mathrm{MMCE}(P) = M\left(\mathcal{F}_K,\ P\right)$，其中 $\mathcal{F}_K$ 是 RKHS 中连续函数构成的空间，最大核值限制为 K。当 $L \ge \sqrt{K}$ 时，$\mathcal{F}_K$ 包含于 $\mathcal{D}_L$。这就证明了所需结果。

> 译者说明：这里关于 $M\left(\mathcal{D}_L,\ P\right)$ 的等式及最后一步的论述，按官方补充材料原文保留，未增补或更正原证明。

补充材料 3. 使用 MMCE 微调

表1给出若干模型在训练完成后使用 MMCE 微调时的 ECE 和准确率数值。

Dataset	Model	Improvement	
		Accuracy	ECE
MNIST	LeNet 5	+0.02%	-0.30%
CIFAR 10	Resnet 50	-0.02%	-2.05%
CIFAR 10	Resnet 110	+0.01%	-2.50%
CIFAR 100	Resnet 32	+1.20%	-2.58%

补充表1. 使用 MMCE 微调预训练模型时，相对于基线的 ECE 和准确率变化。Dataset 为数据集，Model 为模型，Improvement 为改变量，Accuracy 为准确率，ECE 为期望校准误差。正负号和全部百分比保留原表。

补充材料 4. 运行时间比较

表2汇总了分别使用 MMCE+NLL 与 NLL 目标训练时，每个训练轮次的运行时间。平均而言，MMCE 相对于基线带来的开销不超过10%。

Dataset	Model	Baseline	MMCE
CIFAR 10	Resnet 50	4.6s	4.7s
CIFAR 10	Resnet 110	10.5s	11.1s
CIFAR 100	W. Resnet 28-10	48.0s	55.0s
CIFAR 100	Resnet 32	11.5s	11.5s
20 Newsgroups	Global Pool	5.7s	6.0s
IMDB Reviews	HAN	226.0s	227.0s
UCI HAR	LSTM	0.6s	0.7s

补充表2. 不同模型和数据集上，基线与 MMCE 方法每个训练轮次的运行时间，单位为秒。Dataset 为数据集，Model 为模型，Baseline 为基线，MMCE 为本文方法；W. Resnet 指 Wide Resnet，Global Pool 指全局池化，IMDB Reviews 指 IMDB 评论。原表中的 s 表示秒。

补充材料参考文献

- Bartlett, P. L. and Mendelson, S. Rademacher 复杂度与高斯复杂度：风险界与结构性结果。Journal of Machine Learning Research, 3:463–482, 2002。
- Gretton, A., Borgwardt, K. M., Rasch, M. J., Schölkopf, B., and Smola, A. J. 核两样本检验。Journal of Machine Learning Research, 13:723–773, 2012。